

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	25
Direitos Autorais e Uso da Obra	25
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	25
Prefácio	26
Identificação da Disciplina	27
EMENTA	27
OBJETIVO GERAL	27
OBJETIVOS ESPECÍFICOS	27
CONTEÚDO PROGRAMÁTICO	28
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	28
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	28
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	28
METODOLOGIA	29
AVALIAÇÃO	29
CRITÉRIOS DE AVALIAÇÃO	29
BIBLIOGRAFIA BÁSICA	30
BIBLIOGRAFIA COMPLEMENTAR	30
 I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multi- variada	 31
1 Vetores e representação dos dados multivariados	32
1.1 Escalares, vetores e matrizes	33
1.1.1 Vetor-coluna, vetor-linha e transposição	36
1.2 O espaço $\mathbb{R}^p$	37
1.3 Representação matricial de um conjunto de dados	40
1.3.1 Espaço das observações e espaço das variáveis	42
1.4 Operações elementares com vetores	43
1.4.1 Soma e subtração	43
1.4.2 Multiplicação por escalar	44
1.4.3 Combinações lineares	46
1.5 Produto interno, norma, ângulo e distância euclidiana	48
1.5.1 Produto interno euclidiano	48

1.5.2	Norma euclidiana	49
1.5.3	Desigualdade de Cauchy–Schwarz	50
1.5.4	Ângulo entre vetores	53
1.5.5	Distância euclidiana	55
1.5.6	Desigualdade triangular	57
1.5.7	Produto externo	58
1.6	Síntese do capítulo	60
2	Álgebra matricial aplicada	62
2.1	Operações matriciais fundamentais	63
2.1.1	Soma e subtração de matrizes	63
2.1.2	Produto matriz-vetor	66
2.1.3	Produto entre matrizes	69
2.1.4	Propriedades do produto matricial	74
2.2	Transposição, simetria e traço	75
2.2.1	Transposição	75
2.2.2	Matrizes simétricas	77
2.2.3	Traço	81
2.3	Identidade, inversa, determinante, posto e sistemas lineares	85
2.3.1	Matriz identidade	85
2.3.2	Matriz inversa	86
2.3.3	Determinante	89
2.3.4	Interpretação geométrica do determinante	93
2.3.5	Posto	94
2.3.6	Sistemas lineares	97
2.3.7	Aprofundamento: pseudoinversa	101
2.4	Matrizes ortogonais, diagonais e triangulares	103
2.4.1	Matrizes ortogonais	103
2.4.2	Matrizes diagonais	106
2.4.3	Matrizes triangulares	108
2.4.4	Aprofundamento: sistemas triangulares	110
2.5	Formas bilineares, formas quadráticas e positividade	112
2.5.1	Formas bilineares	112
2.5.2	Formas quadráticas	116
2.5.3	Positividade	123
2.5.4	Superfícies de nível	129
2.6	Aprofundamento: matrizes particionadas e complemento de Schur	130
2.6.1	Matrizes particionadas	130
2.6.2	Soma e multiplicação por escalar	132
2.6.3	Transposição por blocos	132
2.6.4	Multiplicação por blocos	133
2.6.5	Complemento de Schur	135
2.6.6	Eliminação por blocos	136

2.6.7	Determinante de uma matriz particionada	138
2.6.8	Inversão em blocos	139
2.6.9	Positividade e complemento de Schur	140
2.7	Síntese do capítulo	143
3	Espaços vetoriais, bases e projeções	146
3.1	Espaços, subespaços e geração	147
3.1.1	Subespaços vetoriais	149
3.1.2	Subespaço gerado	151
3.2	Independência linear, bases e dimensão	154
3.2.1	Independência linear	154
3.2.2	Independência linear e posto	156
3.2.3	Bases	158
3.2.4	Coordenadas em uma base	159
3.2.5	Base canônica	161
3.2.6	Bases ortogonais e ortonormais	162
3.2.7	Dimensão	165
3.3	Espaços fundamentais de uma matriz	167
3.3.1	Espaço nulo	167
3.3.2	Espaço coluna	170
3.3.3	Espaço linha	173
3.3.4	Espaço nulo à esquerda	174
3.3.5	Extensão de uma base	176
3.3.6	Teorema Posto–Nulidade	177
3.3.7	Os quatro espaços fundamentais	181
3.3.8	Complemento ortogonal	181
3.3.9	Relações de ortogonalidade	182
3.4	Produtos internos, bases ortonormais e matrizes de Gram	184
3.4.1	Aprofundamento: produtos internos e geometrias induzidas	184
3.4.2	Matrizes de Gram	189
3.4.3	Propriedades da matriz de Gram	191
3.4.4	Matrizes de Gram e bases ortonormais	193
3.4.5	Produtos cruzados em uma matriz de dados	194
3.4.6	Propriedades do complemento ortogonal	195
3.4.7	Dimensão do complemento ortogonal	197
3.4.8	Decomposição ortogonal	200
3.4.9	Decomposição dos espaços fundamentais	202
3.5	Projeções ortogonais	203
3.5.1	Projeção sobre uma direção	204
3.5.2	Projeção sobre um subespaço com base ortonormal	209
3.5.3	Projeção sobre o espaço coluna de uma matriz	212
3.5.4	Propriedades da matriz de projeção	216
3.5.5	Aprofundamento: projeção residual e complemento ortogonal	220

3.5.6	Projeção como melhor aproximação	225
3.5.7	Aprofundamento: projeções e mínimos quadrados	228
3.6	Síntese do capítulo	232
4	Transformações lineares	235
4.1	Transformações lineares e representação matricial	236
4.1.1	Transformação determinada por uma base	238
4.1.2	Representação matricial nas bases canônicas	240
4.1.3	Núcleo e imagem de uma transformação linear	242
4.1.4	Imagem de um subespaço	243
4.2	Transformação de vetores e matrizes de dados	244
4.2.1	Novas variáveis como combinações lineares	246
4.2.2	Dimensão da configuração transformada	248
4.2.3	Efeito sobre diferenças e produtos internos	252
4.2.4	Transformação das matrizes de produtos internos	253
4.3	Composição, invertibilidade e perda de informação	254
4.3.1	Composição de transformações lineares	255
4.3.2	A ordem das transformações	256
4.3.3	Transformação inversa	259
4.3.4	Injetividade, sobrejetividade e bijetividade	260
4.3.5	Perda de informação	265
4.3.6	Redução de dimensionalidade	266
4.3.7	Transformações singulares	267
4.4	Transformações geométricas	268
4.4.1	Rotação	269
4.4.2	Reflexão	270
4.4.3	Escalonamento	272
4.4.4	Cisalhamento	273
4.4.5	Projeção	275
4.4.6	Comparação geométrica	276
4.4.7	Determinante, volume e orientação	277
4.5	Transformações ortogonais	279
4.5.1	Transformação de uma matriz de dados	281
4.5.2	Determinante e orientação	282
4.5.3	Matrizes ortogonais e bases ortonormais	283
4.5.4	Comparação com transformações não ortogonais	284
4.6	Mudanças de coordenadas e representação em bases	286
4.6.1	Conversão entre duas bases	288
4.6.2	Representação de uma transformação em bases gerais	289
4.6.3	Representação de um operador em uma nova base	292
4.6.4	Transformação ativa e mudança passiva	294
4.6.5	Mudança de coordenadas de uma matriz de dados	295

4.7	Transformações afins e pré-processamento	296
4.7.1	Translação	298
4.7.2	Transformação afim de uma matriz de dados	298
4.7.3	Centralização	299
4.7.4	Escalonamento das variáveis	303
4.7.5	Padronização	304
4.7.6	Ordem entre centralização e escalonamento	305
4.7.7	Composição e inversão de transformações afins	306
4.7.8	Comparação das operações de pré-processamento	308
4.8	Síntese do capítulo	308
5	Autovalores, autovetores e decomposição espectral	316
5.1	Direções invariantes, autovalores e autoespaços	317
5.2	Equação característica, multiplicidades e diagonalização	326
5.2.1	Determinação dos autovalores e autoespaços	328
5.2.2	Autovalores complexos de matrizes reais	330
5.2.3	Independência entre autovetores	331
5.2.4	Multiplicidades algébrica e geométrica	333
5.2.5	Diagonalização	338
5.2.6	Potências de uma matriz diagonalizável	341
5.3	Matrizes simétricas e decomposição espectral	342
5.3.1	Decomposição espectral do exemplo condutor	348
5.3.2	Forma aditiva da decomposição espectral	350
5.3.3	Projetores sobre autoespaços	351
5.3.4	Não unicidade da matriz de autovetores	353
5.4	Consequências da decomposição espectral	354
5.4.1	Traço, determinante, posto e invertibilidade	354
5.4.2	Formas quadráticas em coordenadas espectrais	358
5.4.3	Superfícies de nível em coordenadas espectrais	363
5.5	Quociente de Rayleigh	366
5.5.1	Representação espectral	367
5.5.2	Formulação com restrição de norma	373
5.5.3	Multiplicadores de Lagrange	374
5.5.4	Direções sucessivas	379
5.6	Funções espectrais de matrizes	383
5.6.1	Ação sobre os autoespaços	384
5.6.2	Potências inteiras	385
5.6.3	Inversa espectral	386
5.6.4	Raiz quadrada principal	387
5.6.5	Raiz quadrada inversa	388
5.6.6	Pseudoinversa espectral	389
5.6.7	Exponencial e logaritmo matriciais	391

5.7	Aprofundamento: autovalores generalizados	392
5.7.1	Quociente de Rayleigh generalizado	395
5.7.2	Redução a um problema espectral ordinário	398
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	401
5.7.4	Diagonalização simultânea por congruência	403
5.8	Síntese do capítulo	409
6	Decomposição em Valores Singulares	415
6.1	Definição e formas da Decomposição em Valores Singulares	416
6.1.1	Vetores singulares	420
6.1.2	Interpretação como composição de transformações	422
6.1.3	SVD completa	423
6.1.4	SVD compacta	424
6.1.5	SVD compacta e SVD truncada	425
6.1.6	Aprofundamento: não unicidade dos vetores singulares	431
6.2	Construção da SVD e relação com a decomposição espectral	433
6.2.1	Propriedades das matrizes de Gram associadas	434
6.2.2	Construção dos pares singulares	439
6.2.3	Construção da SVD compacta	444
6.2.4	Decomposições espectrais associadas	448
6.2.5	Exemplo de construção da SVD	450
6.2.6	Relação com a decomposição espectral de matrizes simétricas	453
6.2.7	Aprofundamento: SVD de matrizes simétricas indefinidas	454
6.3	Interpretação geométrica da SVD	455
6.3.1	Imagem da bola unitária	457
6.3.2	Alteração dos comprimentos	460
6.3.3	Exemplo geométrico no plano	465
6.3.4	Transformações com núcleo não trivial	466
6.4	Espaços fundamentais, posto e normas	468
6.4.1	Espaço coluna e espaço linha	469
6.4.2	Projetores ortogonais	473
6.4.3	Posto e nulidades	477
6.4.4	Produto interno de Frobenius	478
6.4.5	Normas e valores singulares	480
6.4.6	Invariância ortogonal	482
6.4.7	Determinante e invertibilidade	483
6.4.8	Aprofundamento: condicionamento e posto numérico	484
6.5	SVD de uma matriz de dados	490
6.5.1	Dualidade entre observações e variáveis	491
6.5.2	Coordenadas das observações nas direções singulares à direita	492
6.5.3	Coordenadas das variáveis nas direções singulares à esquerda	494
6.5.4	Matrizes de Gram da matriz de dados	495
6.5.5	Representação exata das observações	496

6.5.6	Centralização da matriz de dados	499
6.5.7	Antecipação: relação com a matriz de covariâncias amostral	500
6.5.8	Magnitude quadrática da matriz centralizada	502
6.5.9	Representação exata e aproximação	505
6.6	Forma expandida e aproximações de posto reduzido	506
6.6.1	Ortogonalidade dos componentes singulares	508
6.6.2	SVD truncada na forma expandida	510
6.6.3	Erros produzidos pelo truncamento	511
6.6.4	Teorema de Eckart–Young–Mirsky	514
6.6.5	Aprofundamento: demonstração e unicidade da melhor aproximação . .	515
6.6.6	Exemplo de aproximação de posto 1	522
6.6.7	Aproximação de uma matriz de dados	524
6.7	Pseudoinversa e soluções de mínimos quadrados	527
6.7.1	Relação com a pseudoinversa espectral	529
6.7.2	Aprofundamento: caracterização de Moore–Penrose	530
6.7.3	Pseudoinversa e projetores	536
6.7.4	Sistemas lineares compatíveis	538
6.7.5	Mínimos quadrados	541
6.7.6	Expressão da solução nas direções singulares	548
6.7.7	Aprofundamento: instabilidade e pseudoinversa truncada	549
6.7.8	Exemplo com o sistema condutor	552
6.8	Síntese do capítulo	554
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	563
7.1	Funções, variações e diferenciais	563
7.1.1	Tipos de funções	563
7.1.2	Convenções de derivação	566
7.1.3	Variação de uma função	567
7.1.4	Diferencial	569
7.1.5	Aproximação ao longo de uma direção	571
7.1.6	Diferenciabilidade de funções vetoriais	571
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	574
7.2.1	Gradiente e derivada direcional	574
7.2.2	Gradiente e conjuntos de nível	577
7.2.3	Jacobiana	580
7.2.4	Regra da cadeia	582
7.2.5	Hessiana	584
7.3	Aproximações de Taylor e classificação local	586
7.3.1	Aproximação de Taylor de primeira ordem	586
7.3.2	Aproximação de Taylor de segunda ordem	588
7.3.3	Pontos estacionários	589
7.3.4	Classificação pela Hessiana	591
7.3.5	Caso inconclusivo	594

7.4	Convexidade e concavidade	595
7.4.1	Conjuntos convexos	595
7.4.2	Funções convexas	596
7.4.3	Caracterização de primeira ordem	597
7.4.4	Caracterização pela Hessiana	597
7.4.5	Consequências para otimização	600
7.4.6	Funções quadráticas	601
7.5	Otimização sem restrições	603
7.5.1	Método de Newton	603
7.6	Otimização com restrições de igualdade	607
7.6.1	Multiplicadores de Lagrange	608
7.6.2	Relação com problemas de autovalores	614
7.6.3	Restrições lineares	615
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	617
7.7.1	Formas lineares e bilineares	617
7.7.2	Derivadas de formas quadráticas	618
7.7.3	Derivadas da norma euclidiana	621
7.7.4	Funções de resíduos lineares	621
7.7.5	Equações normais	623
7.7.6	Mínimos quadrados ponderados	626
7.7.7	Funções compostas de resíduos	628
7.7.8	Mínimos quadrados não lineares	629
7.8	Diferenciais matriciais e cálculo por traços	631
7.8.1	Regras básicas do diferencial matricial	632
7.8.2	Identities de traço	633
7.8.3	Função linear de uma matriz	634
7.8.4	Derivadas da norma de Frobenius	635
7.8.5	Funções quadráticas de uma matriz	636
7.8.6	Funções matriciais de resíduos	638
7.8.7	Ponderação de observações e respostas	642
7.9	Derivadas de inversas, determinantes e log-determinantes	644
7.9.1	Diferencial da matriz inversa	644
7.9.2	Diferencial do determinante	646
7.9.3	Diferencial do log-determinante	648
7.9.4	Segunda variação do log-determinante	649
7.9.5	Traço envolvendo uma matriz inversa	651
7.9.6	Forma quadrática com matriz inversa	652
7.9.7	Crítério com log-determinante e traço	653
7.9.8	Parâmetros matriciais simétricos	657
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	657
7.10.1	Operador de vetorização	658
7.10.2	Produto de Kronecker	659
7.10.3	Identidade de vetorização	661

7.10.4	Aprofundamento: derivadas vetorizadas e parâmetros matriciais	662
7.11	Integração múltipla e mudança de variáveis	675
7.11.1	Integrais múltiplas	675
7.11.2	Teoremas de Tonelli e Fubini	676
7.11.3	Densidades multivariadas	678
7.11.4	Distribuições marginais	679
7.11.5	Esperanças de funções escalares, vetoriais e matriciais	681
7.11.6	Mudança de variáveis	682
7.11.7	Transformação de densidades	684
7.11.8	Transformações afins	685
7.11.9	Interpretação geométrica do determinante Jacobiano	687
7.11.10	Coordenadas polares	688
7.11.11	Transformações elipsoidais	689
7.11.12	Aprofundamento: diferenciação sob o sinal de integração	690
7.12	Aprofundamento: aplicações à estimação e à inferência	697
7.12.1	Log-verossimilhança e vetor escore	697
7.12.2	Informação observada e informação de Fisher	698
7.12.3	Newton–Raphson	700
7.12.4	Método do escore de Fisher	701
7.12.5	Expansão local de uma raiz do escore	703
7.12.6	Método delta	704
7.13	Síntese do capítulo	710
Exercícios de fixação do Módulo I		713
Parte I — Exercícios sem uso de computador		713
Parte II — Exercícios com uso do R		729
 II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Mul-		
tivariada		739
8	Matrizes de covariâncias e correlações	740
8.1	Momentos, centralização e covariância	741
8.1.1	Vetor de médias e centralização	741
8.1.2	Momentos de segunda ordem	742
8.1.3	Covariância entre duas variáveis	744
8.2	Matriz de covariâncias populacional	749
8.2.1	Definição e interpretação dos elementos	749
8.2.2	Variâncias e covariâncias de combinações lineares	750
8.2.3	Propriedades estruturais e singularidade	753
8.3	Covariâncias entre vetores e transformações	759
8.3.1	Covariâncias cruzadas e vetores particionados	759
8.3.2	Transformações afins da média e da covariância	765

8.4	Padronização e matriz de correlações	769
8.4.1	Matriz de correlações populacional	769
8.4.2	Propriedades, escala e independência	774
8.5	Geometria e medidas globais da dispersão	780
8.5.1	Eixos espectrais e elipsoide de covariância	780
8.5.2	Variância total, variância generalizada e volume	787
8.6	Distância de Mahalanobis	793
8.6.1	Interpretação geométrica e espectral	794
8.6.2	Branqueamento e esferização	797
8.7	Representação descritiva a partir dos dados	802
8.7.1	Centralização, SQPC e matriz de covariâncias observada	802
8.7.2	Matriz de correlações e covariâncias cruzadas observadas	806
8.8	Decomposição da dispersão por grupos	812
8.8.1	Dispersão total, intragrupos e entre grupos	814
8.8.2	Somas de quadrados e traço das matrizes de dispersão	820
8.8.3	Esperança das matrizes de dispersão por grupos	823
8.8.4	Propriedades e limites de posto	828
8.9	Síntese do capítulo	831
9	Distribuição Normal Multivariada	837
9.1	Definição e construção	838
9.1.1	Definição por combinações lineares	838
9.1.2	Construção afim a partir do vetor normal padrão	840
9.1.3	Determinação pelos parâmetros	843
9.2	Densidade da normal multivariada	846
9.2.1	Função densidade e log-densidade	846
9.2.2	Superfícies de igual densidade	849
9.3	Transformações e distribuições marginais	851
9.3.1	Fechamento sob transformações afins	851
9.3.2	Combinações lineares	853
9.3.3	Distribuições marginais	855
9.3.4	Padronização marginal e branqueamento	857
9.4	Independência e distribuições condicionais	859
9.4.1	Independência entre blocos conjuntamente normais	859
9.4.2	Distribuição condicional	862
9.4.3	Média e covariância condicionais	866
9.4.4	Caso bivariado	868
9.5	Distância de Mahalanobis e regiões de probabilidade	871
9.5.1	Distribuição qui-quadrado	871
9.5.2	Regiões elipsoidais de probabilidade	873
9.5.3	Avaliação de uma observação fixa	875
9.6	Comparação entre distribuições normais	877
9.6.1	Médias distintas e covariância comum	878

9.6.2	Covariâncias distintas	879
9.7	Alcance da hipótese de normalidade	881
9.7.1	Resultados que não exigem normalidade	881
9.7.2	Resultados específicos da família normal	882
9.7.3	Passagem do modelo populacional para a inferência	883
9.8	Aprofundamento: Normal Singular	884
9.9	Síntese do capítulo	893
10	Estatísticas Amostrais e Estimação	896
10.1	Da população à amostra	897
10.1.1	Amostra aleatória multivariada	898
10.1.2	Matriz aleatória da amostra e matriz observada	900
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	901
10.2	Propriedades dos estimadores multivariados	904
10.2.1	Viés e variabilidade	905
10.2.2	Erro quadrático médio e funções de perda	906
10.2.3	Consistência	908
10.2.4	Eficiência	909
10.2.5	Suficiência	910
10.2.6	Equivariância	914
10.3	Métodos de estimação	917
10.3.1	Método dos momentos	917
10.3.2	Verossimilhança e máxima verossimilhança	920
10.3.3	Invariância da máxima verossimilhança	928
10.4	Estimação do vetor de médias	931
10.4.1	Vetor de médias amostrais	932
10.4.2	Não viesamento, variabilidade e erro quadrático médio	934
10.4.3	Combinações lineares	936
10.4.4	Consistência e equivariância	938
10.4.5	Variabilidade entre amostras	940
10.5	SQPC e estimação da matriz de covariâncias	941
10.5.1	SQPC como estatística aleatória	941
10.5.2	Decomposição em torno de um centro arbitrário	943
10.5.3	Esperança da SQPC	944
10.5.4	Estimador não viesado da matriz de covariâncias	946
10.5.5	Estimador com divisor n : momentos e máxima verossimilhança	948
10.5.6	Consistência dos estimadores de covariância	950
10.5.7	Transformações, posto e singularidade	952
10.6	Estimação de covariâncias cruzadas e correlações	956
10.6.1	Covariâncias cruzadas entre blocos	956
10.6.2	Matriz de correlações amostral	962
10.6.3	Propriedades estruturais	963
10.6.4	Transformações de localização e escala	967

10.7	Aprofundamento: dimensão, estabilidade e extensões da estimação	969
10.7.1	Relação entre p e n	970
10.7.2	Condicionamento e inversão	972
10.7.3	Regularização	974
10.7.4	Pseudoinversa e regularização	979
10.7.5	Sensibilidade e robustez	980
10.8	Exemplo integrado	981
10.9	Síntese do capítulo	989
11	Modelo Linear Multivariado e Hipóteses Lineares	993
11.1	Formulação do modelo linear multivariado	994
11.1.1	Resposta vetorial e matriz de respostas	994
11.1.2	Estrutura matricial do modelo	997
11.1.3	Estrutura de médias e covariâncias residuais	998
11.1.4	Forma vetorizada	999
11.1.5	Distribuição normal matricial	1000
11.1.6	Transformações da resposta	1003
11.2	Estimação da matriz de parâmetros	1004
11.2.1	Mínimos quadrados	1004
11.2.2	Estimador sob posto completo	1005
11.2.3	Esperança e matriz de covariâncias	1007
11.2.4	Relação com máxima verossimilhança	1009
11.2.5	Modelo contendo somente intercepto	1010
11.3	Valores ajustados, resíduos e projeções	1012
11.3.1	Valores ajustados e resíduos	1013
11.3.2	Ortogonalidade	1014
11.3.3	Esperança dos valores ajustados e dos resíduos	1015
11.3.4	Covariâncias dos valores ajustados e dos resíduos	1016
11.3.5	Representação dos ajustes e resíduos	1017
11.3.6	Conexão com o modelo contendo somente intercepto	1018
11.4	SQPC residual e estimação da covariância	1019
11.4.1	Construção da SQPC residual	1020
11.4.2	Esperança e graus de liberdade	1022
11.4.3	Estimação da covariância residual	1025
11.4.4	Estimador de máxima verossimilhança	1027
11.4.5	Posto e singularidade	1028
11.4.6	Modelo contendo somente intercepto	1030
11.5	Decomposição da variação multivariada	1032
11.5.1	SQPC total	1032
11.5.2	SQPC associada ao modelo	1033
11.5.3	Decomposição entre modelo e resíduo	1035
11.5.4	Combinações lineares das respostas	1037
11.5.5	Modelos sem intercepto	1038

11.5.6	Modelo de grupos como caso particular	1039
11.6	Posto, parametrização e estimabilidade	1042
11.6.1	Delineamento com posto deficiente	1042
11.6.2	Pseudoinversa e unicidade do ajuste	1043
11.6.3	Funções estimáveis	1044
11.6.4	Estimador de uma função estimável	1047
11.6.5	Parametrizações equivalentes	1047
11.7	Hipóteses lineares multivariadas	1048
11.7.1	Combinações dos termos do modelo	1048
11.7.2	Combinações das respostas	1050
11.7.3	Hipótese linear geral	1051
11.7.4	Estimabilidade da hipótese	1052
11.7.5	SQPC da hipótese	1053
11.7.6	Modelos encaixados	1056
11.7.7	Casos particulares	1058
11.8	Exemplo integrado	1060
11.9	Síntese do capítulo	1069
12	Inferência Multivariada	1074
12.1	Distribuições amostrais exatas e assintóticas	1075
12.1.1	Distribuição da média amostral sob normalidade	1075
12.1.2	Teorema Central do Limite multivariado	1078
12.2	Distribuição de Wishart	1080
12.2.1	Construção e parametrização	1081
12.2.2	Suporte, posto e definição positiva	1083
12.2.3	Momentos	1084
12.2.4	Formas quadráticas	1086
12.2.5	Aditividade	1087
12.2.6	Transformações lineares	1087
12.2.7	Aprofundamento: densidade da distribuição de Wishart	1089
12.2.8	Distribuição da SQPC e da covariância amostral	1090
12.2.9	Independência entre média e covariância	1095
12.3	Distribuições no modelo linear multivariado	1097
12.3.1	Distribuição do estimador da matriz de parâmetros	1098
12.3.2	Distribuição de funções estimáveis	1100
12.3.3	Distribuição da SQPC residual	1102
12.3.4	Independência entre estimação e SQPC residual	1104
12.3.5	Distribuição da SQPC da hipótese sob H_0	1106
12.4	Princípios da inferência multivariada	1110
12.4.1	Testes globais e hipóteses simultâneas	1111
12.4.2	Razão de verossimilhanças	1112
12.4.3	Resultado assintótico de Wilks	1114
12.4.4	Razão de verossimilhanças em modelos normais encaixados	1116

12.5	Inferência sobre um vetor de médias	1119
12.5.1	Covariância conhecida	1120
12.5.2	Estatística T^2 de Hotelling	1122
12.5.3	Relações com os casos assintótico e univariado	1125
12.5.4	Região de confiança elipsoidal	1126
12.5.5	Geometria da região	1127
12.5.6	Intervalos simultâneos	1128
12.5.7	Hipóteses lineares sobre o vetor de médias	1130
12.5.8	Relação com o modelo linear multivariado	1134
12.6	Comparação entre dois vetores de médias	1135
12.6.1	Duas amostras independentes	1136
12.6.2	Covariâncias populacionais distintas	1143
12.6.3	Observações pareadas	1144
12.7	Condições e limites da inferência clássica	1149
12.7.1	Independência, normalidade e covariância comum	1149
12.7.2	Posto, dimensão e tamanho amostral	1152
12.7.3	Aprofundamento: alta dimensão e robustez	1155
12.8	Síntese do Módulo 2	1158
12.8.1	Passagem para o Módulo 3	1160
Exercícios de fixação do Módulo II		1161
Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador		1162
Parte II — Exercícios com uso do R		1172
 III Módulo III — Formulação Matemática e Estatística das Técnicas Multi-variadas		 1177
13 Problemas e estruturas das técnicas multivariadas		1178
13.1	Do problema estatístico à técnica multivariada	1179
13.2	Classes de problemas multivariados	1181
13.2.1	Redução de dimensionalidade	1181
13.2.2	Representação de estruturas latentes	1181
13.2.3	Formação de grupos	1182
13.2.4	Representação de dissimilaridades	1182
13.2.5	Representação de associações em tabelas de contingência	1182
13.2.6	Comparação de vetores de médias	1183
13.2.7	Discriminação e classificação	1183
13.2.8	Associação entre blocos de variáveis	1183
13.2.9	Decomposição de preferências	1184
13.3	Diferentes formas de classificar as técnicas	1184
13.3.1	Interdependência e dependência	1184

13.3.2	Exploratórias, descritivas, preditivas e inferenciais	1184
13.3.3	Supervisionadas e não supervisionadas	1185
13.4	Estruturas matemáticas recorrentes	1186
13.4.1	Combinações lineares e projeções	1186
13.4.2	Formas quadráticas e problemas espectrais	1187
13.4.3	SVD e representações de baixa dimensão	1187
13.4.4	Distâncias, matrizes de Gram e métricas	1187
13.4.5	Covariâncias entre blocos	1188
13.4.6	Modelos lineares e probabilísticos	1188
13.5	Mesmas estruturas, diferentes interpretações	1190
13.6	Relações entre as técnicas	1191
13.7	Síntese	1192
14	Formulação da Análise de Componentes Principais	1193
14.1	O problema de redução de dimensionalidade	1193
14.2	Componentes principais como combinações lineares	1196
14.3	Primeira componente principal	1197
14.4	Componentes principais sucessivas	1198
14.5	Formulação espectral	1201
14.6	Variância total e proporção de variância	1202
14.7	Subespaço principal e projeção	1207
14.8	Reconstrução a partir das componentes principais	1212
14.9	Formulação amostral	1217
14.10	Formulação da ACP pela SVD	1220
14.11	Aproximação de posto reduzido	1222
14.12	ACP baseada na matriz de correlações	1224
14.13	Interpretação geométrica da ACP	1227
14.13.1	Relação com o elipsoide de covariâncias	1228
14.13.2	Redução de dimensão como projeção	1229
14.14	Coeficientes e relação das variáveis com as componentes	1229
14.15	Propriedades da solução	1233
14.15.1	Invariância a translações	1234
14.15.2	Dependência da escala	1234
14.15.3	Indeterminação do sinal	1235
14.15.4	Multiplicidade de autovalores	1236
14.15.5	Autovalores próximos	1237
14.15.6	Singularidade e dimensão efetiva	1238
14.16	Papel da distribuição probabilística	1239
14.17	Formulação descritiva, populacional e inferencial	1240
14.18	Limites da representação por componentes principais	1242
14.19	Síntese	1243

15	Formulação da Análise Fatorial	1245
15.1	O problema da estrutura latente	1245
15.2	Modelo de fatores comuns	1246
15.3	Hipóteses do modelo ortogonal	1248
15.4	Estrutura da matriz de covariâncias	1252
15.4.1	Covariâncias entre variáveis	1254
15.4.2	Variâncias das variáveis	1255
15.5	Comunalidades e especificidades	1255
15.6	Cargas fatoriais e associação com os fatores	1258
15.7	Geometria das cargas fatoriais	1259
15.8	Matriz de covariâncias comuns	1262
15.9	Identificação do modelo fatorial	1263
15.9.1	Escala dos fatores	1264
15.9.2	Indeterminação do sinal	1264
15.9.3	Indeterminação rotacional	1265
15.10	Rotação dos eixos fatoriais	1267
15.11	Contagem de parâmetros e identificação	1268
15.12	Fatores ortogonais e fatores oblíquos	1270
15.13	Reparametrização do espaço fatorial	1272
15.14	Matriz de padrões e matriz de estrutura	1275
15.15	Rotação e estrutura simples	1277
15.16	Formulação populacional e amostral	1278
15.17	Matriz reproduzida e resíduos	1280
15.18	O problema de estimação	1282
15.18.1	Fatores principais	1283
15.18.2	Mínimos quadrados	1284
15.19	Modelo fatorial normal	1284
15.20	Estimação por máxima verossimilhança	1286
15.20.1	Ajuste global e graus de liberdade	1288
15.21	Soluções admissíveis e casos de fronteira	1290
15.22	Escores fatoriais	1291
15.23	Distribuição condicional dos fatores	1292
15.24	Pressupostos e limites do modelo	1294
15.24.1	Linearidade e estrutura de segunda ordem	1295
15.24.2	Diagonalidade da estrutura específica	1296
15.24.3	Número de fatores	1296
15.24.4	Dependência do conjunto e da escala das variáveis	1297
15.24.5	Papel da normalidade	1297
15.25	Análise Fatorial e Análise de Componentes Principais	1298
15.26	Síntese	1300
16	Formulação da Análise de Agrupamentos	1303
16.1	O problema de formação de grupos	1303

16.2	Representação dos objetos e proximidade	1305
16.3	Dissimilaridades entre objetos	1305
16.3.1	Efeito da escala	1307
16.4	Partições	1308
16.4.1	Partições rígidas, difusas e probabilísticas	1309
16.5	Homogeneidade interna e separação	1310
16.6	Agrupamento por centroides	1310
16.6.1	Dispersão dentro e entre grupos	1311
16.6.2	Formulação das K -médias	1312
16.6.3	O centroide como minimizador	1315
16.6.4	Partição para centroides fixados	1316
16.6.5	Geometria das regiões de alocação	1317
16.6.6	Existência e não unicidade da solução	1320
16.6.7	Natureza do problema de otimização	1321
16.6.8	Formulação populacional do critério das K -médias	1321
16.6.9	Efeito de transformações sobre as K -médias	1323
16.7	Estrutura dos métodos hierárquicos	1324
16.7.1	Ligações simples, completa e média	1326
16.7.2	Empates e não unicidade da hierarquia	1328
16.7.3	Método de Ward e dispersão intragrupos	1328
16.7.4	Dendrograma e níveis de fusão	1332
16.7.5	Ultramétrica induzida pela hierarquia	1332
16.7.6	Uma partição e uma hierarquia representam objetos diferentes	1336
16.8	Diferentes definições matemáticas de grupo	1337
16.8.1	Formulação probabilística de grupos	1337
16.8.2	Não unicidade dos rótulos em modelos de mistura	1340
16.8.3	Grupos definidos por densidade	1340
16.9	Dependência da solução e limites da formulação	1341
16.10	Ausência de classes naturais automáticas	1343
16.11	Relações com outras técnicas multivariadas	1343
16.11.1	Agrupamentos e ACP	1344
16.11.2	Agrupamentos e MDS	1345
16.11.3	Agrupamentos e Análise Discriminante	1345
16.11.4	Agrupamentos e MANOVA	1346
16.12	Síntese	1346
17	Formulação do Escalonamento Multidimensional	1349
17.1	O problema de reconstrução geométrica	1349
17.2	Configuração e indeterminações geométricas	1351
17.2.1	Translação	1351
17.2.2	Transformações ortogonais	1352
17.2.3	Centralização da configuração	1354

17.3	Da distância ao produto interno	1355
17.3.1	Matriz das dissimilaridades quadráticas	1356
17.4	Formulação do MDS clássico	1359
17.4.1	Solução espectral	1359
17.4.2	Reprodução euclidiana exata	1362
17.4.3	Dimensão da configuração	1364
17.4.4	Representação em dimensão reduzida	1365
17.4.5	Multiplicidade espectral e não unicidade	1367
17.4.6	Euclideanidade e autovalores negativos	1369
17.5	MDS clássico e Análise de Componentes Principais	1372
17.6	Formulações baseadas diretamente no ajuste das distâncias	1374
17.6.1	MDS métrico	1375
17.6.2	MDS não métrico	1376
17.6.3	Função de <i>stress</i>	1379
17.6.4	Representação métrica e ordinal	1380
17.6.5	Indeterminações nas formulações baseadas em <i>stress</i>	1381
17.7	Dependência da representação	1382
17.8	Ausência de um modelo probabilístico universal	1383
17.9	Relações com outras técnicas multivariadas	1384
17.9.1	MDS e Análise de Agrupamentos	1384
17.9.2	MDS e ACP	1385
17.9.3	MDS e Análise de Correspondência	1386
17.10	Limites da interpretação geométrica	1386
17.11	Síntese	1388
18	Formulação da Análise de Correspondência	1391
18.1	O problema de associação em uma tabela de contingência	1392
18.2	Frequências marginais, massas e perfis	1393
18.2.1	Distribuições condicionais observadas	1395
18.2.2	Independência como referência	1397
18.3	Geometria dos perfis	1398
18.4	Inércia e afastamento da independência	1401
18.5	Padronização dos desvios da independência	1402
18.5.1	Inércia como norma matricial	1404
18.6	Relação algébrica com a estatística qui-quadrado	1405
18.7	Formulação pela decomposição em valores singulares	1406
18.7.1	Decomposição da inércia	1408
18.7.2	Representação em dimensão reduzida	1410
18.7.3	Multiplicidade dos valores singulares e não unicidade	1411
18.8	Coordenadas da Análise de Correspondência	1412
18.8.1	Sistema de coordenadas padrão	1412
18.8.2	Sistema de coordenadas principais	1414
18.8.3	Distâncias entre perfis e coordenadas principais	1416

18.8.4	Relações baricêntricas	1420
18.9	Reconstrução dos desvios da independência	1424
18.10	Representação conjunta de linhas e colunas	1428
18.10.1	O significado das proximidades	1429
18.11	Contribuição para as dimensões	1429
18.12	Qualidade de representação	1431
18.13	Formulação descritiva e inferencial	1434
18.13.1	Distribuição populacional da tabela	1435
18.13.2	Resultado assintótico de Pearson	1436
18.13.3	Teste global e dimensões da Correspondência	1438
18.13.4	Inércia e tamanho da amostra	1439
18.14	Relações com a ACP e o MDS	1440
18.14.1	Relação com a Análise de Componentes Principais	1440
18.14.2	Relação com o Escalonamento Multidimensional	1442
18.15	Pressupostos e limites da representação	1443
18.15.1	Condições da tabela ativa	1443
18.15.2	Massas pequenas e frequências nulas	1444
18.15.3	Sinais, multiplicidades e orientação	1445
18.15.4	Proximidade entre linhas e colunas	1446
18.15.5	Associação e causalidade	1446
18.16	Síntese	1448
19	Formulação da MANOVA	1451
19.1	O problema de comparação multivariada	1452
19.2	A hipótese no modelo linear multivariado	1453
19.2.1	Matrizes de hipótese e erro	1455
19.3	Hipótese e erro em uma combinação linear das respostas	1457
19.4	Problema espectral da MANOVA	1459
19.4.1	Padronização pela dispersão residual	1462
19.5	Crítérios multivariados	1465
19.5.1	Forma determinantal	1466
19.5.2	Agregação das raízes transformadas	1469
19.5.3	Soma das raízes características	1471
19.5.4	Direção característica dominante	1472
19.6	Uma mesma estrutura, quatro formas de agregação	1473
19.7	Base probabilística dos critérios	1475
19.7.1	Papel da covariância residual comum	1479
19.7.2	Lambda de Wilks e razão de verossimilhanças	1480
19.8	Casos particulares	1482
19.8.1	Uma única resposta	1482
19.8.2	Dois populações	1484
19.9	Geometria da MANOVA	1487
19.9.1	Geometria após padronização pelo erro	1489

19.10	Invariância a transformações lineares das respostas	1491
19.11	Existência, posto e identificação das direções	1494
19.11.1	Posto da matriz de hipótese	1495
19.11.2	Não singularidade da matriz de erro	1497
19.11.3	Estimabilidade da hipótese	1499
19.11.4	Identificação das direções características	1501
19.12	Pressupostos e limites	1503
19.12.1	Estrutura correta da média	1503
19.12.2	Estimabilidade da hipótese	1504
19.12.3	Independência entre unidades	1504
19.12.4	Covariância residual comum	1504
19.12.5	Não singularidade da covariância residual	1505
19.12.6	Normalidade multivariada	1506
19.12.7	Multicolinearidade e dependência exata entre respostas	1507
19.13	Relações com outras técnicas	1507
19.13.1	ANOVA	1508
19.13.2	T^2 de Hotelling	1508
19.13.3	Regressão multivariada	1509
19.13.4	Análise Discriminante	1510
19.14	Síntese	1510
20	Formulação da Análise Discriminante	1513
20.1	O problema de discriminação e classificação	1514
20.2	Classificação como problema de decisão	1515
20.2.1	Distribuição prévia das classes	1515
20.2.2	Densidades condicionais e probabilidades posteriores	1516
20.3	Perda e risco de classificação	1517
20.3.1	Minimização do risco condicional	1519
20.3.2	Perda zero-um	1520
20.4	Discriminação linear sob normalidade	1521
20.4.1	Fronteiras entre classes	1524
20.4.2	Relação com a distância de Mahalanobis	1526
20.5	Discriminação quadrática	1527
20.5.1	Fronteiras quadráticas	1530
20.6	Da regra populacional à regra estimada	1532
20.6.1	Amostra com classes conhecidas	1533
20.6.2	Covariância comum na LDA	1534
20.6.3	Probabilidades <i>a priori</i> : especificação ou estimação	1535
20.7	Regra estimada da LDA	1536
20.8	Regra estimada da QDA	1538
20.9	Regra populacional e regra estimada	1539
20.10	O que as regras probabilísticas resolvem	1541

20.11	Formulação geométrica de Fisher	1542
20.11.1	Dispersões populacionais dentro e entre grupos	1542
20.11.2	Critério populacional de Fisher	1546
20.12	Formulação amostral de Fisher	1548
20.13	Dispersão depois de uma projeção	1550
20.14	Direções discriminantes e autovalores generalizados	1552
20.14.1	Geometria pela dispersão intragrupos	1553
20.14.2	Número de direções discriminantes	1556
20.15	Representação no subespaço discriminante	1557
20.16	Relação espectral com a MANOVA	1560
20.17	O caso de dois grupos	1561
20.17.1	Formulação populacional para dois grupos	1563
20.18	Relação entre Fisher e a discriminação linear normal	1564
20.18.1	Relação amostral	1566
20.18.2	Mais de dois grupos	1566
20.19	Existência e singularidade	1567
20.19.1	Formulação populacional de Fisher	1567
20.19.2	Formulação amostral de Fisher	1568
20.19.3	LDA estimada	1569
20.19.4	QDA estimada	1570
20.20	Identificação das direções discriminantes	1571
20.21	Pressupostos e limites	1572
20.21.1	Grupos previamente definidos	1573
20.21.2	Normalidade e estrutura das covariâncias	1574
20.21.3	Independência das unidades da amostra de treinamento	1575
20.21.4	Probabilidades <i>a priori</i> e perdas	1575
20.21.5	Sobreposição entre as populações	1576
20.22	Relações com outras técnicas	1576
20.23	Síntese	1578
21	Formulação da Correlação Canônica	1581
21.1	O problema de associação entre dois blocos	1582
21.2	Estrutura de covariâncias em blocos	1584
21.2.1	Ausência de associação linear entre os blocos	1586
21.3	Variáveis canônicas e função objetivo	1588
21.4	Da normalização ao branqueamento	1593
21.5	Solução pela Decomposição em Valores Singulares	1596
21.6	Pares canônicos sucessivos	1600
21.6.1	Número de correlações canônicas positivas	1604
21.7	Formulação equivalente por autovalores	1606
21.7.1	O papel do branqueamento na geometria	1613
21.8	Interpretação das variáveis canônicas	1616
21.8.1	Coefficientes canônicos	1617

21.8.2	Associação com a variável canônica do próprio bloco	1617
21.8.3	Associação com a variável canônica do outro bloco	1619
21.8.4	Associação bivariada e associação canônica	1621
21.9	Variância extraída e redundância	1622
21.9.1	Variância extraída	1622
21.9.2	Índice de redundância	1623
21.9.3	Correlação canônica e ângulo	1624
21.10	Formulação amostral	1626
21.10.1	População e amostra	1630
21.11	Invariância, existência e identificação	1631
21.11.1	Invariância a transformações lineares não singulares	1631
21.12	Existência da solução clássica	1635
21.12.1	Existência na amostra	1636
21.12.2	Existência na amostra	1636
21.12.3	Dimensão conjunta e correlações amostrais iguais a um	1637
21.12.4	Multicolinearidade e condicionamento	1640
21.13	Identificação das direções canônicas	1641
21.13.1	Correlação canônica simples	1641
21.13.2	Correlações repetidas	1642
21.13.3	Correlações nulas	1643
21.13.4	População e amostra	1644
21.14	Pressupostos e limites	1644
21.14.1	Existência de segundos momentos	1645
21.14.2	Não singularidade dentro dos blocos	1645
21.14.3	Normalidade multivariada	1646
21.14.4	Unidades observacionais	1647
21.14.5	Dimensão amostral e sensibilidade	1648
21.14.6	Interpretação associativa	1649
21.15	Relações com outras técnicas	1649
21.15.1	Análise de Componentes Principais	1649
21.15.2	Regressão e regressão multivariada	1650
21.15.3	MANOVA	1651
21.15.4	Análise Discriminante	1652
21.16	Síntese	1653

22 Formulação da Análise Conjunta 1657

22.1	O problema da decomposição de preferências	1658
22.2	Preferência e utilidade	1661
22.3	Utilidades parciais	1663
22.4	Modelo aditivo de utilidade	1664
22.4.1	Resposta quantitativa e utilidade sistemática	1666
22.5	Aditividade	1667
22.6	Compensação entre atributos	1668

22.7	Interações entre atributos	1669
22.8	Da utilidade à representação matricial	1671
22.9	Codificação dos níveis	1672
22.10	Representação matricial do modelo	1674
22.11	Categoria de referência	1676
22.12	Codificação por efeitos	1680
22.13	Por que a identificação é necessária	1681
22.14	Identificação do modelo	1683
22.14.1	Parametrização irrestrita	1684
22.14.2	Parametrização restrita	1685
22.15	Restrições de identificação	1685
22.15.1	Eliminação de uma categoria	1686
22.15.2	Restrição de soma zero	1686
22.16	Equivalência entre parametrizações	1687
22.17	Diferenças de utilidade e funções estimáveis	1689
22.17.1	Diferenças entre perfis	1691
22.17.2	Diferenças entre níveis	1692
22.17.3	Novo perfil	1692
22.18	Um exemplo de equivalência entre codificações	1693
22.19	Posto e complexidade do modelo	1694
22.19.1	Inclusão de interações	1695
22.20	Do modelo identificado ao delineamento dos perfis	1696
22.21	Delineamento dos perfis	1697
22.21.1	Delineamento fatorial completo	1698
22.21.2	Delineamento fracionário	1699
22.21.3	Ortogonalidade	1700
22.21.4	Balanceamento	1702
22.21.5	Delineamento e estimabilidade	1703
22.22	Estimação das utilidades	1704
22.23	Utilidades sistemáticas ajustadas	1707
22.23.1	Utilidade estimada de um perfil	1708
22.24	Interpretação das preferências	1710
22.24.1	Comparação entre níveis	1710
22.25	Amplitude das utilidades de um atributo	1711
22.25.1	Importância relativa estimada	1713
22.26	Preferências individuais e agregadas	1714
22.26.1	Modelo individual	1714
22.26.2	Modelo agregado	1716
22.26.3	Extensões para heterogeneidade	1717
22.27	Diferentes formas de resposta	1718
22.27.1	Avaliação quantitativa	1719
22.27.2	Resposta ordinal	1720
22.27.3	Ordenação	1721

22.27.4	Comparação pareada	1722
22.27.5	Escolha	1722
22.28	Utilidade aleatória	1723
22.29	Natureza relativa da utilidade	1725
22.29.1	Preferência ordinal	1725
22.29.2	Avaliação quantitativa	1726
22.29.3	Escolha	1727
22.30	Pressupostos e limites	1728
22.30.1	Pressupostos estruturais	1728
22.30.2	Condições algébricas	1729
22.30.3	Pressupostos probabilísticos	1730
22.30.4	Generalização	1731
22.31	Relações com outras formulações estatísticas	1731
22.31.1	Modelo linear	1731
22.31.2	Delineamento experimental	1733
22.31.3	Modelos de escolha	1733
22.32	Síntese da Análise Conjunta	1734
22.33	Síntese do Módulo 3	1737

Referências	1739
--------------------	-------------

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual antecede os algoritmos, os procedimentos computacionais e a interpretação aplicada. Essa organização permite compreender por que cada técnica assume determinada forma e quais fundamentos são necessários para utilizá-la adequadamente.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;
- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;

- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar os problemas estatísticos que dão origem às principais técnicas multivariadas;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados
 Álgebra matricial aplicada
 Espaços vetoriais, bases e projeções
 Transformações lineares
 Autovalores, autovetores e decomposição espectral
 Decomposição em valores singulares
 Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações
 Distribuição normal multivariada
 Estatísticas amostrais e estimação
 Modelo linear multivariado e hipóteses lineares
 Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas
 Análise de Componentes Principais
 Análise Fatorial
 Análise de Agrupamentos
 Escalonamento Multidimensional
 Análise de Correspondência

Análise Multivariada de Variância
Análise Discriminante
Correlação Canônica
Análise Conjunta

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a verificação dos pressupostos e a interpretação dos resultados.

AValiação

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2018)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações com vetores, o produto interno, a norma, o ângulo, a distância euclidiana e o produto externo.

Convenções gerais de notação

As convenções abaixo indicam apenas como os objetos serão representados. Seus significados e propriedades serão definidos ao longo do capítulo.

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{.j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_i^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;
- o símbolo $\top$ indica transposição;

- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$ representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{\cdot j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j .

Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Neste momento, o vetor é utilizado apenas para organizar as medidas. A comparação geométrica de variáveis com unidades diferentes exigirá atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i\cdot}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{\cdot j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i\cdot}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{\cdot j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i\cdot}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_i^\top$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_j$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. A representação dos vetores em $\mathbb{R}^p$ será desenvolvida na próxima seção.

1.2 O espaço $\mathbb{R}^p$

Os valores observados de p variáveis quantitativas podem ser organizados em um vetor com p componentes. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço $\mathbb{R}^p$). O espaço $\mathbb{R}^p$ é o conjunto

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ no qual são representadas as unidades observacionais será denominado **espaço das observações**. Cada vetor representa uma unidade, e cada componente corresponde a uma variável.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;
- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.3 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{\cdot 1} \ \mathbf{x}_{\cdot 2} \ \cdots \ \mathbf{x}_{\cdot p}].$$

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = \begin{bmatrix} 5 & 7 \end{bmatrix}.$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.3.1 Espaço das observações e espaço das variáveis

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{\cdot j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

No **espaço das observações**, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às variáveis.

No **espaço das variáveis**, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{\cdot j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.4 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.4.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.4.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

A norma do vetor resultante satisfaz

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;




Figura 1.3: Soma de vetores pela regra do paralelogramo.

- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.4.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

As operações anteriores produzem novos vetores ou novas variáveis. A próxima operação tem natureza diferente: o produto interno associa dois vetores a um número real e permite construir as noções de comprimento, ângulo, ortogonalidade e distância.

1.5 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

1.5.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. *Linearidade no segundo argumento*

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. *Não negatividade*

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. *Positividade definida*

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0}.$$

1.5.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.

Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.5.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Meyer, 2023)

Comprovação. Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha \langle \mathbf{x}, \mathbf{y} \rangle - \alpha \langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2 \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha \langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2 \|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

Substituindo o valor escolhido para α ,

$$\begin{aligned}
0 &\leq \|\mathbf{x}\|^2 - 2 \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \langle \mathbf{x}, \mathbf{y} \rangle \\
&\quad + \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \right)^2 \|\mathbf{y}\|^2 \\
&= \|\mathbf{x}\|^2 - \frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2}.
\end{aligned}$$

Logo,

$$\frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2} \leq \|\mathbf{x}\|^2.$$

Como $\|\mathbf{y}\|^2 > 0$, podemos multiplicar os dois lados por esse valor e obter

$$\langle \mathbf{x}, \mathbf{y} \rangle^2 \leq \|\mathbf{x}\|^2 \|\mathbf{y}\|^2.$$

Tomando a raiz quadrada dos dois lados,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Resta examinar quando ocorre a igualdade. Na construção anterior, a igualdade é satisfeita se, e somente se,

$$\langle \mathbf{x} - \alpha \mathbf{y}, \mathbf{x} - \alpha \mathbf{y} \rangle = 0.$$

Pela positividade definida do produto interno, isso ocorre se, e somente se,

$$\mathbf{x} - \alpha \mathbf{y} = \mathbf{0},$$

ou seja,

$$\mathbf{x} = \alpha \mathbf{y}.$$

Portanto, quando $\mathbf{y} \neq \mathbf{0}$, a igualdade ocorre se, e somente se, $\mathbf{x}$ é múltiplo escalar de $\mathbf{y}$.

Reunindo os dois casos, concluímos que a igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. $\square$

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.5.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.5.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as observações.




Figura 1.6: Os vetores x e y são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

A padronização e outras geometrias serão estudadas nos capítulos posteriores.

1.5.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer, 2023)

Comprovação. Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2. \end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2. \end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

□

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.5.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do **produto externo**.

Definição 1.14 (Produto externo). Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, o **produto externo** de $\mathbf{x}$ e $\mathbf{y}$, denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

é definido como a matriz em $\mathbb{R}^{p \times q}$

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$[\text{ext}(\mathbf{x}, \mathbf{y})]_{ij} = x_i y_j.$$

O resultado do produto externo é uma matriz.

A estrutura do produto externo pode ser observada por suas colunas. Como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = [y_1 \mathbf{x} \quad y_2 \mathbf{x} \quad \cdots \quad y_q \mathbf{x}],$$

cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

O produto externo é

$$\begin{aligned} \text{ext}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} 1(3) & 1(-1) & 1(4) \\ 2(3) & 2(-1) & 2(4) \end{bmatrix} \\ &= \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}. \end{aligned}$$

O resultado possui dimensão 2×3 , correspondente às dimensões de $\mathbf{x}$ e $\mathbf{y}$, respectivamente.

O produto interno e o produto externo produzem objetos de naturezas diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz. No próximo capítulo, após a definição do produto matricial, o produto externo será relacionado às operações entre matrizes e vetores, e suas propriedades matriciais serão desenvolvidas.

1.6 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos. O próximo capítulo desenvolverá as operações e as propriedades matriciais necessárias para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo será retomado como um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas bilineares e quadráticas. As seções finais introduzem matrizes particionadas e complemento de Schur, preparando estruturas que serão utilizadas posteriormente na formulação de resultados multivariados.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{r \times s}$. As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \iff n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. Comutatividade

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. Associatividade

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. Existência do elemento neutro

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A},$$

em que $\mathbf{0}_{n \times p}$ é o elemento neutro de dimensão $n \times p$:

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

4. Existência do elemento oposto

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$ e $\alpha, \beta \in \mathbb{R}$. A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. *Elemento neutro da multiplicação escalar*

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial, apresentado a seguir, utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. A definição a seguir reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelas linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelas colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_1 - \mathbf{a}_2 \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a seguinte matriz em $\mathbb{R}^{n \times r}$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

i Produto interno e produto externo como produtos matriciais

As operações entre vetores apresentadas anteriormente também podem ser expressas por meio do produto matricial.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno** pode ser escrito como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Como

$$\mathbf{x}^\top \in \mathbb{R}^{1 \times p} \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^{p \times 1},$$

o produto possui dimensão 1×1 e corresponde a um escalar:

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

De forma semelhante, para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

o **produto externo**, anteriormente denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

pode ser escrito como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \mathbf{xy}^\top.$$

Nesse caso,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \text{e} \quad \mathbf{y}^\top \in \mathbb{R}^{1 \times q},$$

de modo que

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

Portanto, a ordem e a orientação dos vetores determinam objetos diferentes:

$$\mathbf{x}^\top \mathbf{y} \text{ é um escalar}$$

enquanto

$$\mathbf{xy}^\top \text{ é uma matriz.}$$

Exemplo 2.5 (Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

A matriz

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 3 & 6 & 4 \\ 1 & 5 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{bmatrix} \in \mathbb{R}^{3 \times 4}$$

é obtida escrevendo as colunas de $\mathbf{X}$ como linhas. A operação de transposição e suas propriedades serão formalizadas adiante.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{X}\mathbf{a} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

Considere agora o produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}.$$

Esse produto possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \langle \mathbf{x}_{\cdot 1}, \mathbf{x}_{\cdot 2} \rangle = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \langle \mathbf{x}_1, \mathbf{x}_2 \rangle = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos serão retomados no estudo de matrizes de Gram, produtos cruzados, covariâncias e decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. Associatividade

$$(\mathbf{A}\mathbf{B})\mathbf{C} = \mathbf{A}(\mathbf{B}\mathbf{C}).$$

2. Distributividade à esquerda

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbf{B} + \mathbf{A}\mathbf{C}.$$

3. Distributividade à direita

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{A}\mathbf{C} + \mathbf{B}\mathbf{C}.$$

4. Compatibilidade com a multiplicação por escalar

Para $\alpha \in \mathbb{R}$,

$$(\alpha\mathbf{A})\mathbf{B} = \alpha(\mathbf{A}\mathbf{B}) = \mathbf{A}(\alpha\mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{A}\mathbf{B}$ e $\mathbf{B}\mathbf{A}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{A}\mathbf{B} \neq \mathbf{B}\mathbf{A}.$$

Exemplo 2.6 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja $\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}$. A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

Proposição 2.4 (Propriedades da transposição). *Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes com dimensões compatíveis e seja $\alpha \in \mathbb{R}$. Então,*

1. $(\mathbf{A}^\top)^\top = \mathbf{A}$,
2. $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$,
3. $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ e
4. $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.
5. Em particular, para vetores $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, $(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top$.

A última propriedade mostra que a transposição de um produto inverte a ordem dos fatores. Em particular, ela será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

2.2.2 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x} \in \mathbb{R}^p$, tem-se

$$(\mathbf{x}\mathbf{x}^\top)^\top = \mathbf{x}\mathbf{x}^\top.$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.8 (Matriz antissimétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Aprofundamento

A decomposição seguinte mostra que toda matriz quadrada pode ser separada em uma parte simétrica e uma parte antissimétrica. A parte simétrica será particularmente importante no estudo das formas quadráticas.

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser escrita de maneira única como*

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn; Johnson, 2013)

Comprovação. A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas. □

Exemplo 2.10 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.3 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada. Apesar de sua definição simples, essa operação permite representar de forma compacta somas de quadrados, produtos internos, formas quadráticas e diversas expressões matriciais utilizadas em Estatística Multivariada.

Definição 2.9 (Traço de uma matriz). Seja $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$. O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Cálculo do traço). Para $\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix}$, tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Proposição 2.5 (Propriedades básicas do traço). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha, \beta \in \mathbb{R}$. Então,*

1. *Linearidade:*

$$\text{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{tr}(\mathbf{A}) + \beta \text{tr}(\mathbf{B}).$$

2. *Invariância à transposição:*

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

3. *Traço da matriz identidade:*

$$\text{tr}(\mathbf{I}_n) = n.$$

Consequentemente,

$$\text{tr}(\alpha \mathbf{I}_n) = \alpha n.$$

4. *Propriedade cíclica:* se $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$, então

$$\text{tr}(\mathbf{CD}) = \text{tr}(\mathbf{DC}).$$

(Harville, 1997)

A primeira propriedade mostra que o traço é uma operação linear. A segunda decorre do fato de que a transposição não modifica os elementos da diagonal principal. A quarta permite reorganizar produtos matriciais dentro do traço, desde que seja preservada a ordem cíclica dos fatores.

A propriedade cíclica pode ser demonstrada diretamente a partir da definição do produto matricial.

Comprovação. Como $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$,

$$\text{tr}(\mathbf{CD}) = \sum_{i=1}^n (\mathbf{CD})_{ii} = \sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji}.$$

Trocando a ordem das somas,

$$\sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji} = \sum_{j=1}^p \sum_{i=1}^n d_{ji} c_{ij} = \text{tr}(\mathbf{DC}).$$

□

Proposição 2.6 (Ciclicidade para vários fatores). *Para matrizes com dimensões compatíveis, os fatores de um produto podem ser deslocados ciclicamente dentro do traço. Por exemplo,*

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A propriedade é **cíclica**. Portanto, a ordem relativa dos fatores é preservada. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Proposição 2.7 (Traço, produto interno e produto externo). *Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\text{tr}(\mathbf{xy}^\top) = \mathbf{y}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Como $\mathbf{xy}^\top = \text{ext}(\mathbf{x}, \mathbf{y})$, também podemos escrever

$$\text{tr}[\text{ext}(\mathbf{x}, \mathbf{y})] = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Em particular,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Essa propriedade estabelece uma ligação direta entre o traço e as operações vetoriais introduzidas anteriormente.

Proposição 2.8 (Traço de produtos matriciais). *Para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$,*

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ij}.$$

Consequentemente,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

Pela propriedade cíclica,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \text{tr}(\mathbf{A} \mathbf{A}^\top).$$

Portanto, o traço permite representar a soma dos quadrados de todos os elementos de uma matriz. Essa expressão será retomada posteriormente no estudo da norma de Frobenius, de matrizes de produtos cruzados e de decomposições matriciais.

Exemplo 2.12 (Traço de produtos matriciais). Considere $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} 1 & 3 \\ -2 & 3 \end{bmatrix}$.

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -9 & 9 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} -1 & 13 \\ -7 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

seus traços são iguais:

$$\text{tr}(\mathbf{AB}) = 0 + 9 = 9$$

e

$$\text{tr}(\mathbf{BA}) = -1 + 10 = 9.$$

O traço será utilizado repetidamente na representação de somas de quadrados, produtos cruzados, variâncias totais, formas quadráticas e expressões de verossimilhança. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.10 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos podem ser representados pelo **delta de Kronecker**,

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

de modo que

$$(\mathbf{I}_n)_{ij} = \delta_{ij}.$$

O delta de Kronecker será utilizado posteriormente para representar de forma compacta relações de ortogonalidade e ortonormalidade.

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.11 (Matriz inversa). Uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.2 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

Comprovação. Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única. □

Exemplo 2.14 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.3 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

Comprovação. Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

□

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.12 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.13 (Determinante). Para uma matriz de ordem um,

$$\mathbf{A} = [a_{11}],$$

define-se

$$\det(\mathbf{A}) = a_{11}.$$

Para $n \geq 2$, seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O determinante de $\mathbf{A}$ pode ser calculado recursivamente pela expansão em cofatores de qualquer linha fixa i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna fixa j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Em cada termo, o cofator C_{ij} envolve o determinante de uma matriz de ordem $n - 1$. O caso de ordem um encerra a definição recursiva.

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e rea-

lizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais, que serão estudadas posteriormente.

Proposição 2.9 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.4 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere uma matriz quadrada

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{n \times n}.$$

As colunas de $\mathbf{A}$ podem ser interpretadas como vetores em $\mathbb{R}^n$. Esses vetores determinam uma região geométrica cuja medida depende de suas direções e comprimentos.

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

corresponde à medida do paralelepípedo determinado pelas colunas de $\mathbf{A}$:

- em uma dimensão, corresponde a um comprimento;
- em duas dimensões, corresponde à área do paralelogramo determinado pelas duas colunas;
- em três dimensões, corresponde ao volume do paralelepípedo determinado pelas três colunas;
- em $\mathbb{R}^n$, corresponde ao volume n -dimensional determinado pelas n colunas.

Como a matriz identidade $\mathbf{I}_n$ possui determinante igual a 1, suas colunas determinam uma região de volume unitário. Assim, $|\det(\mathbf{A})|$ também pode ser interpretado como o fator pelo qual esse volume unitário é ampliado ou reduzido quando os vetores canônicos são substituídos pelas colunas de $\mathbf{A}$.

O sinal do determinante acrescenta informação sobre a orientação dos vetores:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é nulo.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

No último caso, as colunas não determinam todas as direções necessárias para formar um volume n -dimensional. Em $\mathbb{R}^2$, por exemplo, duas colunas alinhadas formam uma região de área zero; em $\mathbb{R}^3$, três colunas contidas em um mesmo plano formam uma região de volume zero.

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.

2.3.5 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.14 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura será importante posteriormente nas decomposições matriciais, em que uma matriz poderá ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.5 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer, 2023)

Exemplo 2.18 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.15 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\&\vdots \\a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n.\end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.6 (Existência e quantidade de soluções). *Sejam*

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- a solução é única se

$$\text{posto}(\mathbf{A}) = p;$$

- existem infinitas soluções se

$$\text{posto}(\mathbf{A}) < p.$$

Definição 2.16 (Sistema linear homogêneo). Um **sistema linear homogêneo** é um sistema da forma

$$\mathbf{Ax} = \mathbf{0},$$

em que

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{0} \in \mathbb{R}^n.$$

Portanto, um sistema homogêneo é um caso particular de sistema linear no qual todos os termos independentes são iguais a zero.

Todo sistema homogêneo possui pelo menos a **solução trivial**

$$\mathbf{x} = \mathbf{0}.$$

Dependendo da matriz $\mathbf{A}$, também podem existir **soluções não triviais**, isto é, soluções para as quais

$$\mathbf{x} \neq \mathbf{0}.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.19 (Sistema com solução única). Considere

$$2x_1 + x_2 = 5,$$

$$x_1 + x_2 = 3.$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.20 (Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4. \end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5. \end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.3.7 Aprofundamento: pseudoinversa

Leitura de aprofundamento

A pseudoinversa permite estender a resolução de sistemas lineares para matrizes retangulares ou singulares. Sua construção será desenvolvida no capítulo sobre decomposição em valores singulares. Nesta seção, são apresentadas sua definição e suas principais consequências.

Definição 2.17 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Harville, 1997)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+\mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{AA}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção de $\mathbf{A}^+$, sua interpretação por projeções e sua relação com o posto serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.18 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.21 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.7 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Comprovação. Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

□

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.19 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag} \left(\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} \right).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1x_1 \\ d_2x_2 \\ \vdots \\ d_nx_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.22 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.20 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$$\mathbf{U}^\top \text{ é triangular inferior.}$$

Da mesma forma,

$$\mathbf{L}^\top \text{ é triangular superior.}$$

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.23 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Aprofundamento: sistemas triangulares

Leitura de aprofundamento

Os sistemas triangulares mostram como a estrutura de uma matriz pode simplificar a resolução de equações. Esses procedimentos também aparecem nas decomposições matriciais estudadas posteriormente.

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.24 (Sistema triangular superior). Considere o sistema

$$\begin{aligned} x_1 + 2x_2 - x_3 &= 4, \\ 2x_2 + 3x_3 &= 7, \\ x_3 &= 1. \end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{L}\mathbf{x} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar e são lineares em cada argumento separadamente. Quando uma forma bilinear é avaliada utilizando o mesmo vetor em seus dois argumentos, obtém-se uma função de um único vetor, denominada forma quadrática.

Essa relação permite conectar propriedades das matrizes, como simetria e positividade, a expressões escalares que aparecem frequentemente na análise multivariada, entre elas produtos internos, normas, variâncias e distâncias.

2.5.1 Formas bilineares

Definição 2.21 (Forma bilinear). Uma função

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **forma bilinear** quando é linear separadamente em cada argumento.

Isso significa que, para quaisquer

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e quaisquer

$$\beta \in \mathbb{R},$$

tem-se

$$g(\mathbf{x} + \beta \mathbf{z}, \mathbf{y}) = g(\mathbf{x}, \mathbf{y}) + \beta g(\mathbf{z}, \mathbf{y})$$

e

$$g(\mathbf{x}, \mathbf{z} + \beta \mathbf{y}) = g(\mathbf{x}, \mathbf{z}) + \beta g(\mathbf{x}, \mathbf{y}).$$

A bilinearidade significa, portanto, que, mantendo um dos argumentos fixo, a forma bilinear é uma função linear do outro argumento.

Fixado $\mathbf{y} \in \mathbb{R}^p$, a função

$$\mathbf{x} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{x}$. Analogamente, fixado $\mathbf{x} \in \mathbb{R}^p$, a função

$$\mathbf{y} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{y}$.

Um caso particularmente importante para a estatística são as formas bilineares simétricas.

Definição 2.22 (Forma bilinear simétrica). Uma forma bilinear

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **simétrica** quando

$$g(\mathbf{x}, \mathbf{y}) = g(\mathbf{y}, \mathbf{x})$$

para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

Exemplo 2.25 (Produto interno como forma bilinear simétrica). O produto interno usual em $\mathbb{R}^p$,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle,$$

é um exemplo de forma bilinear simétrica, pois,

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle,$$

ou, equivalentemente,

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}.$$

Nem toda forma bilinear é simétrica.

Exemplo 2.26 (Bilinearidade e ausência de simetria). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$$

e os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

A função

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é dada por

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2y_1 + y_2 \\ -y_1 + 3y_2 \end{bmatrix} \\ &= 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2. \end{aligned}$$

Para verificar a linearidade no primeiro argumento, sejam $\mathbf{x}_1, \mathbf{x}_2, \mathbf{y} \in \mathbb{R}^2$ e $\beta \in \mathbb{R}$. Então,

$$\begin{aligned} g(\mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) &= (\mathbf{x}_1 + \beta \mathbf{x}_2)^\top \mathbf{A} \mathbf{y} \\ &= \mathbf{x}_1^\top \mathbf{A} \mathbf{y} + \beta \mathbf{x}_2^\top \mathbf{A} \mathbf{y} \\ &= g(\mathbf{x}_1, \mathbf{y}) + \beta g(\mathbf{x}_2, \mathbf{y}). \end{aligned}$$

Analogamente, para $\mathbf{x}, \mathbf{y}_1, \mathbf{y}_2 \in \mathbb{R}^2$,

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}_1 + \beta \mathbf{y}_2) &= \mathbf{x}^\top \mathbf{A} (\mathbf{y}_1 + \beta \mathbf{y}_2) \\ &= \mathbf{x}^\top \mathbf{A} \mathbf{y}_1 + \beta \mathbf{x}^\top \mathbf{A} \mathbf{y}_2 \\ &= g(\mathbf{x}, \mathbf{y}_1) + \beta g(\mathbf{x}, \mathbf{y}_2). \end{aligned}$$

Portanto, g é linear em cada argumento separadamente e, assim, é uma forma bilinear.

Para verificar se a forma bilinear é simétrica, invertem-se os dois argumentos. Tem-se

$$g(\mathbf{y}, \mathbf{x}) = 2x_1y_1 - x_1y_2 + x_2y_1 + 3x_2y_2.$$

Por outro lado,

$$g(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2.$$

As duas expressões diferem nos termos cruzados. Portanto, em geral,

$$g(\mathbf{x}, \mathbf{y}) \neq g(\mathbf{y}, \mathbf{x}),$$

e a forma bilinear não é simétrica.

De modo geral, uma forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é simétrica se, e somente se, sua matriz representante é simétrica, isto é, $\mathbf{A} = \mathbf{A}^\top$.

Uma forma bilinear também pode ser avaliada utilizando o mesmo vetor em seus dois argumentos. Assim, em vez de considerar

$$g(\mathbf{x}, \mathbf{y}),$$

podemos considerar

$$g(\mathbf{x}, \mathbf{x}).$$

Essa avaliação produz uma função de um único vetor e conduz às formas quadráticas.

2.5.2 Formas quadráticas

Definição 2.23 (Forma quadrática). Seja

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma forma bilinear. A função

$$Q : \mathbb{R}^p \longrightarrow \mathbb{R}$$

definida por

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x})$$

é denominada **forma quadrática** associada a g .

Se a forma bilinear possui representação matricial

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p.$$

A forma bilinear depende de dois argumentos e é linear em cada um deles separadamente. A forma quadrática, por sua vez, depende de um único argumento e, em geral, não é uma função linear desse vetor.

De fato, para qualquer $\alpha \in \mathbb{R}$,

$$\begin{aligned} Q(\alpha \mathbf{x}) &= g(\alpha \mathbf{x}, \alpha \mathbf{x}) \\ &= \alpha^2 g(\mathbf{x}, \mathbf{x}) \\ &= \alpha^2 Q(\mathbf{x}). \end{aligned}$$

Assim,

$$Q(\alpha \mathbf{x}) = \alpha^2 Q(\mathbf{x}).$$

A expressão quadrática pode ser interpretada como a avaliação da forma bilinear sobre a diagonal do produto cartesiano,

$$\{(\mathbf{x}, \mathbf{x}) : \mathbf{x} \in \mathbb{R}^p\} \subset \mathbb{R}^p \times \mathbb{R}^p.$$

O produto interno fornece um exemplo imediato dessa construção.

Exemplo 2.27 (Produto interno e norma ao quadrado). Considere a forma bilinear dada pelo produto interno usual,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Ao utilizar o mesmo vetor nos dois argumentos,

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x}) = \langle \mathbf{x}, \mathbf{x} \rangle.$$

Pela definição da norma euclidiana,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2.$$

Portanto,

$$Q(\mathbf{x}) = \|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

A matriz representante dessa forma quadrática é

$$\mathbf{I}_p.$$

Em geral, se

$$\mathbf{A} = (a_{ij})_{p \times p},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j. \quad (2.1)$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= ax_1^2 + (b+c)x_1x_2 + dx_2^2. \end{aligned}$$

Esse desenvolvimento mostra uma diferença importante entre formas bilineares e formas quadráticas.

Na forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

os elementos a_{ij} e a_{ji} podem produzir contribuições distintas porque os dois vetores não precisam ser iguais.

Na forma quadrática

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

os termos fora da diagonal aparecem combinados. No caso bidimensional, por exemplo, b e c aparecem somente por meio da soma

$$b + c.$$

Consequentemente, a matriz que aparece em uma representação

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

não é necessariamente única quando matrizes não simétricas são admitidas. Matrizes que diferem apenas por uma parcela antissimétrica produzem a mesma forma quadrática.

Entretanto, toda forma quadrática possui uma única matriz simétrica que a representa. Essa propriedade é apresentada na proposição seguinte.

Proposição 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Então $\mathbf{S}$ é simétrica e, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Além disso, $\mathbf{S}$ é a única matriz simétrica que representa essa forma quadrática.

Comprovação. A matriz $\mathbf{A}$ pode ser escrita como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica.

De fato,

$$\mathbf{S}^\top = \mathbf{S}$$

e

$$\mathbf{K}^\top = -\mathbf{K}.$$

Assim,

$$\begin{aligned}\mathbf{x}^\top \mathbf{A} \mathbf{x} &= \mathbf{x}^\top (\mathbf{S} + \mathbf{K}) \mathbf{x} \\ &= \mathbf{x}^\top \mathbf{S} \mathbf{x} + \mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

O termo

$$\mathbf{x}^\top \mathbf{K} \mathbf{x}$$

é um escalar. Portanto,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = (\mathbf{x}^\top \mathbf{K} \mathbf{x})^\top.$$

Utilizando a transposição do produto,

$$\begin{aligned}\mathbf{x}^\top \mathbf{K} \mathbf{x} &= \mathbf{x}^\top \mathbf{K}^\top \mathbf{x} \\ &= -\mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

Logo,

$$2\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0$$

e, consequentemente,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0.$$

Portanto,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Resta mostrar a unicidade da representação simétrica.

Suponha que $\mathbf{S}_1$ e $\mathbf{S}_2$ sejam duas matrizes simétricas que representem a mesma forma quadrática. Então,

$$\mathbf{x}^\top \mathbf{S}_1 \mathbf{x} = \mathbf{x}^\top \mathbf{S}_2 \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Definindo

$$\mathbf{D} = \mathbf{S}_1 - \mathbf{S}_2,$$

a matriz $\mathbf{D}$ também é simétrica e satisfaz

$$\mathbf{x}^\top \mathbf{D} \mathbf{x} = 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\begin{aligned} 0 &= (\mathbf{x} + \mathbf{y})^\top \mathbf{D} (\mathbf{x} + \mathbf{y}) \\ &= \mathbf{x}^\top \mathbf{D} \mathbf{x} + \mathbf{x}^\top \mathbf{D} \mathbf{y} + \mathbf{y}^\top \mathbf{D} \mathbf{x} + \mathbf{y}^\top \mathbf{D} \mathbf{y}. \end{aligned}$$

Como $\mathbf{D}$ é simétrica,

$$\mathbf{y}^\top \mathbf{D} \mathbf{x} = \mathbf{x}^\top \mathbf{D} \mathbf{y},$$

e os termos quadráticos são nulos. Assim,

$$2\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Logo,

$$\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Em particular, tomando os vetores da base canônica,

$$\mathbf{x} = \mathbf{e}_i \quad \text{e} \quad \mathbf{y} = \mathbf{e}_j,$$

obtém-se

$$\mathbf{e}_i^\top \mathbf{D} \mathbf{e}_j = d_{ij} = 0$$

para todos i e j .

Portanto,

$$\mathbf{D} = \mathbf{0},$$

o que implica

$$\mathbf{S}_1 = \mathbf{S}_2.$$

□

Assim, embora uma forma quadrática possa possuir diferentes representações por matrizes não simétricas, sua representação por uma matriz simétrica é única.

Por essa razão, no estudo de formas quadráticas, pode-se trabalhar sem perda de generalidade com matrizes simétricas.

Observe que essa propriedade é específica das formas quadráticas. Para uma forma bilinear geral,

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

a parte antissimétrica de $\mathbf{A}$ pode contribuir para o valor da expressão quando

$$\mathbf{x} \neq \mathbf{y}.$$

Quando os dois argumentos coincidem, essa contribuição desaparece.

Exemplo 2.28 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

A forma quadrática associada a $\mathbf{A}$ é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então,

$$Q(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuada os produtos,

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtem-se

$$\begin{aligned} Q(\mathbf{x}) &= 2(1)^2 + 2(1)(2) + 3(2)^2 \\ &= 2 + 4 + 12 \\ &= 18. \end{aligned}$$

2.5.3 Positividade

Como toda forma quadrática pode ser representada por uma única matriz simétrica, propriedades importantes da forma quadrática podem ser estudadas a partir dos valores assumidos por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com $\mathbf{A}$ simétrica.

A classificação em positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida depende do sinal assumido por essa expressão.

Definição 2.24 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica e considere a forma quadrática

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \succ \mathbf{0};$$

- **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \succeq \mathbf{0};$$

- **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \prec \mathbf{0};$$

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \preceq \mathbf{0};$$

- **indefinida** quando existem vetores não nulos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Para matrizes indefinidas, não se utiliza uma relação de ordem do tipo $\mathbf{A} \succeq \mathbf{0}$ ou $\mathbf{A} \preceq \mathbf{0}$.

As notações $\succ$, $\succeq$, $\prec$ e $\preceq$ expressam a ordem de Löwner para matrizes simétricas. Em particular,

$$\begin{aligned} \mathbf{A} \succ \mathbf{0} &\iff \mathbf{A} \text{ é positiva definida,} \\ \mathbf{A} \succeq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida positiva,} \\ \mathbf{A} \prec \mathbf{0} &\iff \mathbf{A} \text{ é negativa definida,} \\ \mathbf{A} \preceq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida negativa.} \end{aligned}$$

produto interno usual fornece um exemplo imediato de forma quadrática associada a uma matriz positiva definida.

Como

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \|\mathbf{x}\|^2,$$

tem-se

$$Q(\mathbf{x}) > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Portanto, a matriz identidade

$$\mathbf{I}_p$$

é positiva definida.

Outro exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo.

Para

$$\mathbf{x}, \mathbf{z} \in \mathbb{R}^p,$$

considere

$$\mathbf{x}\mathbf{x}^\top.$$

Então,

$$\begin{aligned}\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} &= (\mathbf{z}^\top \mathbf{x}) (\mathbf{x}^\top \mathbf{z}) \\ &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\text{rank}(\mathbf{x}\mathbf{x}^\top) = 1.$$

Assim, quando $p > 1$, existem vetores não nulos $\mathbf{z}$ ortogonais a $\mathbf{x}$. Para esses vetores,

$$\mathbf{x}^\top \mathbf{z} = 0$$

e, portanto,

$$\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} = 0.$$

Logo, para $p > 1$ e $\mathbf{x} \neq \mathbf{0}$, a matriz

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva, mas não positiva definida.

Esse tipo de matriz terá importância particular na construção das matrizes de covariâncias, que envolvem somas de produtos externos de vetores de desvios.

Exemplo 2.29 (Classificação de formas quadráticas). Considere inicialmente

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

Como

$$2x_1^2 + 3x_2^2 > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0},$$

a matriz $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

Portanto, $\mathbf{B}$ é semidefinida positiva.

Entretanto, para vetores não nulos da forma

$$\mathbf{x} = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}, \quad x_2 \neq 0,$$

tem-se

$$Q(\mathbf{x}) = 0.$$

Assim, $\mathbf{B}$ não é positiva definida.

Finalmente, considere

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

A forma quadrática associada é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{x}) = 1 > 0.$$

Por outro lado, para

$$\mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{y}) = -1 < 0.$$

Portanto, a forma quadrática assume valores positivos e negativos, e a matriz $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérbolas. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Aprofundamento: matrizes particionadas e complemento de Schur

Leitura de aprofundamento

Esta seção pode ser utilizada como referência nos capítulos posteriores. As operações por blocos e o complemento de Schur serão retomados no estudo de covariâncias particionadas, distribuições condicionais, regressão entre blocos e correlação canônica.

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.25 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.30 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.31 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

Matrizes particionadas permitem tratar uma matriz de grande dimensão a partir de blocos menores. Em vários problemas, é útil eliminar um desses blocos e estudar a estrutura que permanece no outro. O **complemento de Schur** é a matriz que surge naturalmente nesse processo de eliminação.

Definição 2.26 (Complemento de Schur). Considere a matriz quadrada particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Os blocos diagonais $\mathbf{A}_{11}$ e $\mathbf{A}_{22}$ são quadrados. Quando um deles é invertível, podemos utilizá-lo para eliminar os efeitos dos blocos fora da diagonal.

Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, enquanto $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

A expressão pode ser compreendida como uma correção do bloco diagonal original. Por exemplo,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

parte de $\mathbf{A}_{11}$ e retira a parcela associada às relações que passam pelo segundo bloco. Essa interpretação ficará mais clara ao observarmos a eliminação por blocos.

2.6.6 Eliminação por blocos

Suponha que $\mathbf{A}_{22}$ seja invertível. Queremos eliminar o bloco $\mathbf{A}_{12}$, isto é, produzir uma matriz equivalente cuja posição superior direita seja ocupada por uma matriz nula.

Para isso, considere

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Multiplicando $\mathbf{E}$ por $\mathbf{A}$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Efetuada o produto por blocos,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{A}_{12} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{22} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Como $\mathbf{A}_{22}^{-1}\mathbf{A}_{22} = \mathbf{I}_q$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Portanto, o complemento de Schur aparece exatamente como o bloco que permanece depois da eliminação de $\mathbf{A}_{12}$ utilizando $\mathbf{A}_{22}$.

Como

$$\mathbf{E}^{-1} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix},$$

também podemos escrever

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Essa fatoração é consequência direta da eliminação por blocos.

Um caso simples ajuda a reconhecer a estrutura. Para uma matriz 2×2 ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

com $d \neq 0$, o complemento de Schur de d é

$$a - bd^{-1}c.$$

Como veremos a seguir,

$$\det(\mathbf{A}) = d(a - bd^{-1}c) = ad - bc,$$

recuperando a expressão usual do determinante de uma matriz 2×2 .

Exemplo 2.32 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Como $\mathbf{A}_{22} = \mathbf{I}_2$, tem-se $\mathbf{A}_{22}^{-1} = \mathbf{I}_2$. Logo,

$$\begin{aligned} \mathbf{A}_{11.2} &= \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.7 Determinante de uma matriz particionada

A eliminação por blocos mostra uma das principais utilidades do complemento de Schur: calcular o determinante de uma matriz particionada utilizando determinantes de matrizes menores.

Teorema 2.8 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd; Vandenberghe, 2004)

Comprovação. Suponha que $\mathbf{A}_{22}$ seja invertível. Pela eliminação por blocos apresentada anteriormente,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Como $\mathbf{E}$ é triangular por blocos e possui matrizes identidade na diagonal,

$$\det(\mathbf{E}) = 1.$$

Portanto,

$$\det(\mathbf{EA}) = \det(\mathbf{A}).$$

A matriz $\mathbf{EA}$ também é triangular por blocos. Assim,

$$\det(\mathbf{EA}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

A segunda identidade é obtida de forma análoga, eliminando o bloco $\mathbf{A}_{21}$ a partir de $\mathbf{A}_{11}$. $\square$

No Exemplo [2.32](#),

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = 3.$$

Consequentemente,

$$\det(\mathbf{A}) = 3.$$

2.6.8 Inversão em blocos

O complemento de Schur também permite obter a inversa de uma matriz particionada. A origem da expressão pode ser entendida a partir da mesma fatoração obtida pela eliminação por blocos.

Se $\mathbf{A}_{22}$ é invertível,

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{11.2}$ também é invertível, os dois fatores são invertíveis. Como a inversa de um produto inverte a ordem dos fatores, a inversa de $\mathbf{A}$ pode ser construída a partir das inversas dessas duas matrizes mais simples.

Proposição 2.11 (Inversa em blocos). *Considere a matriz particionada*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e o complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1} & \mathbf{B}_{22} \end{bmatrix},$$

com o bloco $(2, 2)$ dado por

$$\mathbf{B}_{22} = \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}.$$

(Boyd; Vandenberghe, 2004)

A expressão pode parecer extensa, mas sua estrutura é determinada pela eliminação anterior. O bloco $\mathbf{A}_{11.2}^{-1}$ representa a parte de $\mathbf{A}_{11}$ que permanece depois da eliminação do segundo bloco.

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.9 Positividade e complemento de Schur

Outra aplicação importante ocorre em matrizes simétricas. O complemento de Schur permite verificar a definição positiva de uma matriz particionada por meio de matrizes de menor dimensão.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^{\top} & \mathbf{A}_{22} \end{bmatrix}.$$

Para estudar se $\mathbf{A}$ é positiva definida, consideramos sua forma quadrática. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y}.$$

Quando $\mathbf{A}_{22}$ é invertível, os termos envolvendo $\mathbf{y}$ podem ser reorganizados completando a forma quadrática:

$$\begin{aligned} & \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top) \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

O primeiro termo contém exatamente o complemento de Schur de $\mathbf{A}_{22}$.

Teorema 2.9 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então $\mathbf{A}$ é positiva definida se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Boyd; Vandenberghe, 2004)

Comprovação. Pela decomposição da forma quadrática,

$$\begin{aligned} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} &= \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

Suponha inicialmente que $\mathbf{A}_{11.2}$ e $\mathbf{A}_{22}$ sejam positivas definidas.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Logo, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela da decomposição é igual a zero. Portanto,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0.$$

Assim, $\mathbf{A}_{11 \cdot 2}$ é positiva definida. □

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22 \cdot 1}$.

O complemento de Schur aparece sempre que uma matriz particionada é estudada após a eliminação de um dos blocos. Por isso, ele será útil em diferentes partes da Análise Multivariada.

Algebricamente, o termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a correção associada ao segundo bloco, enquanto

$$\mathbf{A}_{11 \cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa o primeiro bloco depois dessa correção.

Essa interpretação é puramente matricial e vale para matrizes particionadas gerais.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada,

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix},$$

o complemento

$$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

adquire uma interpretação estatística adicional. Ele representa a matriz de covariâncias da parcela do primeiro bloco que permanece após o ajuste linear pelo segundo bloco. Sob normalidade conjunta, essa mesma matriz corresponde à covariância condicional do primeiro bloco dado o segundo.

Essa estrutura será retomada no estudo de covariâncias condicionais, regressão entre blocos e distribuição normal multivariada.

2.7 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{A}\mathbf{x}$	Produz produtos internos pelas linhas e combinações lineares pelas colunas
Produto matricial	$\mathbf{A}_{n \times p} \mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma bilinear	$\mathbf{x}^\top \mathbf{A} \mathbf{y}$	Relaciona dois vetores por meio de uma matriz
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{A} \mathbf{x} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida.

As seções sobre pseudoinversa, sistemas triangulares, matrizes particionadas e complemento de Schur funcionam como aprofundamentos. Esses resultados serão retomados quando sua utilização estatística se tornar necessária.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas bilineares e quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

Convenções para espaços vetoriais e subespaços

As convenções vetoriais e matriciais apresentadas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- V e W representam espaços vetoriais ou subespaços vetoriais;
- S representa, em geral, um subespaço de $\mathbb{R}^p$;
- $\mathcal{B}$ representa uma base;
- $\mathcal{B}_W$ representa uma base associada ao subespaço W ;
- $\dim(V)$ representa a dimensão do espaço vetorial V ;
- $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ representa o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$;
- $[\mathbf{x}]_{\mathcal{B}}$ representa o vetor de coordenadas de $\mathbf{x}$ em relação à base $\mathcal{B}$;
- $S^\perp$ representa o complemento ortogonal de S ;
- $\mathcal{C}(\mathbf{A})$ representa o espaço coluna de $\mathbf{A}$;
- $\mathcal{L}(\mathbf{A})$ representa o espaço linha de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A})$ representa o espaço nulo de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A}^\top)$ representa o espaço nulo de $\mathbf{A}^\top$;
- $\oplus$ representa soma direta de subespaços;
- $\text{proj}_S(\mathbf{x})$ representa a projeção ortogonal de $\mathbf{x}$ sobre S ;
- $\mathbf{P}_S$ representa uma matriz de projeção ortogonal sobre S ;
- $\mathbf{G}$ representa, quando indicado, uma matriz de Gram.

Quando uma base for escrita como

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\},$$

a ordem dos vetores será considerada fixada sempre que forem utilizadas coordenadas em relação a essa base.

Os vetores continuarão sendo representados por letras minúsculas em negrito, como $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{v}$, enquanto matrizes serão representadas por letras maiúsculas em negrito, como $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{Q}$.

As definições e propriedades específicas de cada espaço, base, decomposição ou operador serão apresentadas nas seções correspondentes.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e são satisfeitas as seguintes propriedades:

1. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$,

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}.$$

2. Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$,

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}).$$

3. Existe um vetor $\mathbf{0} \in V$ tal que, para todo $\mathbf{x} \in V$,

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

4. Para todo $\mathbf{x} \in V$, existe um vetor $-\mathbf{x} \in V$ tal que

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0}.$$

5. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$ e $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y}.$$

6. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x}.$$

7. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}.$$

8. Para todo $\mathbf{x} \in V$,

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais de adição e multiplicação por escalar, é um espaço vetorial. Seus elementos são vetores com p componentes reais. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e, para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

seu inverso aditivo é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

Os elementos de um espaço vetorial não precisam ser necessariamente vetores numéricos. Por exemplo, o conjunto de todas as matrizes reais de dimensão $n \times p$,

$$\mathbb{R}^{n \times p},$$

também é um espaço vetorial com as operações usuais de adição de matrizes e multiplicação por escalar. Nesse caso, os elementos do espaço vetorial são matrizes.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Proposição 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer, 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

Geometricamente, S é uma reta paralela a W , mas deslocada e sem passar pela origem.

A Figura 3.1 compara uma reta que é subespaço de $\mathbb{R}^2$ com uma reta paralela que não é subespaço.




Figura 3.1: Comparação entre uma reta que é subespaço de $\mathbb{R}^2$ e uma reta que não é subespaço.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem e, por isso, não é um subespaço de $\mathbb{R}^2$.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é o conjunto de todas as suas combinações lineares,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

A notação

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$$

indica o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Exemplo 3.5 (Espaço e subespaço gerado). Considere o espaço vetorial

$$V = \mathbb{R}^3.$$

Primeiro, considere os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}.$$

Como qualquer vetor de $\mathbb{R}^3$ pode ser obtido escolhendo adequadamente α_1 , α_2 e α_3 ,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} = \mathbb{R}^3.$$

Nesse caso, o subespaço gerado coincide com o próprio espaço V .

Considere agora apenas os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

As combinações lineares desses vetores são da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ 0 \end{bmatrix}.$$

Portanto,

$$W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} : x_1, x_2 \in \mathbb{R} \right\}.$$

O conjunto W é o plano $x_3 = 0$ contido em $\mathbb{R}^3$. Assim,

$$W \subsetneq V,$$

Os dois casos mostram que um subespaço gerado pode coincidir com todo o espaço ou possuir dimensão menor. Em um espaço vetorial de dimensão finita, um subespaço não pode ter dimensão maior que a do espaço que o contém.

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.6 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes.

Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.7 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

3.2.2 Independência linear e posto

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k], \quad \mathbf{A} \in \mathbb{R}^{p \times k}.$$

As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se,

$$\text{posto}(\mathbf{A}) = k.$$

Assim, o número de vetores linearmente independentes entre as colunas de $\mathbf{A}$ é determinado pelo posto da matriz.

Como

$$\text{posto}(\mathbf{A}) \leq \min(p, k),$$

não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Proposição 3.2 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*

2. Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.
3. Todo subconjunto de um conjunto linearmente independente também é linearmente independente.
4. Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.
5. Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.

A última propriedade fornece uma interpretação direta da redundância.

Proposição 3.3 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

Comprovação. Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente. $\square$

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.8 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.9 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.1 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Comprovação. Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única. □

Definição 3.6 (Coordenadas em uma base). Se

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.10 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

As coordenadas de um vetor em uma base são os coeficientes que indicam quanto de cada vetor da base é necessário para reconstruir esse vetor por combinação linear. Assim, o vetor de coordenadas não é o próprio vetor, mas a representação desse vetor em relação à base escolhida.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

A partir deste ponto, considere um subespaço $S \subseteq \mathbb{R}^p$ com o produto interno euclidiano.

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

de S é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base $\mathcal{B}$ de S é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker, a condição de ortonormalidade pode ser escrita como

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Teorema 3.2 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt. (Meyer, 2023)

Esse resultado garante que a geometria de um subespaço de dimensão finita pode ser descrita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Proposição 3.4 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de um subespaço $S \subseteq \mathbb{R}^p$, então todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Cada coordenada de $\mathbf{x}$ na base $\mathcal{B}$ pode ser obtida separadamente por

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}, \quad j = 1, \dots, k.$$

Portanto,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal, então $\mathbf{b}_j^\top \mathbf{b}_j = 1$ para todo j , de modo que

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

e

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Assim, em uma base ortogonal, cada coordenada pode ser determinada por meio de um produto interno, sem a necessidade de resolver simultaneamente um sistema linear. (Meyer, 2023)

Comprovação. Como $\mathcal{B}$ é uma base de S , todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados à esquerda por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal,

$$\mathbf{b}_j^\top \mathbf{b}_i = 0 \quad \text{para} \quad i \neq j.$$

Assim, todos os termos da soma com $i \neq j$ são nulos, restando

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j.$$

Como $\mathbf{b}_j \neq \mathbf{0}$,

$$\mathbf{b}_j^\top \mathbf{b}_j = \|\mathbf{b}_j\|^2 > 0,$$

e, portanto,

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Se a base é ortonormal, então $\|\mathbf{b}_j\| = 1$ e, conseqüentemente,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

Logo,

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

o que fornece diretamente as coordenadas de $\mathbf{x}$ na base ortonormal. $\square$

A Figura 3.3 compara três bases de $\mathbb{R}^2$ e destaca a diferença entre independência linear e ortogonalidade.




Figura 3.3: Comparação entre uma base canônica, uma base oblôqua e uma base ortonormal rotacionada de $\mathbb{R}^2$. O símbolo de ângulo reto identifica os pares de vetores ortogonais.

Na primeira e na terceira bases, os vetores são ortogonais e possuem norma igual a 1, como indicado pelos marcadores de ângulo reto. Portanto, ambas são bases ortonormais. Na base oblôqua, os vetores continuam sendo linearmente independentes e, por isso, formam uma base de $\mathbb{R}^2$, mas não são ortogonais.

3.2.7 Dimensão

Um espaço vetorial é denominado **finito-dimensional** quando possui uma base formada por um número finito de vetores.

Para que a dimensão possa ser definida pelo número de vetores de uma base, é necessário estabelecer primeiro que esse número não depende da base escolhida.

Teorema 3.3 (Número de vetores de uma base). *Se um espaço vetorial V possui uma base finita, então todas as bases de V são finitas e possuem a mesma quantidade de vetores. (Meyer, 2023)*

Definição 3.10 (Dimensão). Se as bases de um espaço vetorial finito-dimensional V possuem k vetores, a **dimensão** de V é definida por

$$\dim(V) = k.$$

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.11 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Proposição 3.5 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz está associada a subespaços determinados por suas linhas, por suas colunas e pelas soluções de sistemas lineares homogêneos. Esses subespaços permitem relacionar o posto, a dependência linear e as soluções de sistemas lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Serão estudados quatro subespaços associados a $\mathbf{A}$:

- o espaço coluna;
- o espaço linha;
- o espaço nulo;
- o espaço nulo à esquerda.

Os dois primeiros são construídos a partir das colunas e das linhas da matriz. Os dois últimos são determinados pelas soluções dos sistemas homogêneos associados, respectivamente, a $\mathbf{A}$ e a $\mathbf{A}^\top$.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\}.$$

Quando $\mathbf{A}$ é interpretada como a matriz associada a uma transformação linear, esse espaço corresponde ao **núcleo** da transformação. Essa interpretação será formalizada no capítulo seguinte.

O espaço nulo reúne todos os vetores $\mathbf{x} \in \mathbb{R}^p$ que são anulados pela multiplicação por $\mathbf{A}$, isto é, aqueles para os quais $\mathbf{Ax} = \mathbf{0}$.

Proposição 3.6 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

Comprovação. O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço. □

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.12 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_p] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \dots, \mathbf{a}_p \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + \cdots + x_p \mathbf{a}_p, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Como

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + \cdots + x_p \mathbf{a}_p,$$

o conjunto de todos os vetores que podem ser escritos na forma $\mathbf{Ax}$ coincide com o espaço gerado pelas colunas de $\mathbf{A}$:

$$\mathcal{C}(\mathbf{A}) = \{ \mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p \}.$$

Essa caracterização permite relacionar diretamente o espaço coluna à existência de soluções de sistemas lineares.

Proposição 3.7 (Consistência de um sistema linear). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Comprovação. Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{Ax},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_{.1} + \dots + x_p \mathbf{a}_{.p}.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtém-se

$$\mathbf{Ax} = \mathbf{b}.$$

□

Exemplo 3.13 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \mathbf{a}_3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base de $\mathcal{C}(\mathbf{A})$ pode ser formada por quaisquer vetores linearmente independentes que gerem esse espaço. Quando se deseja obter uma base selecionando colunas da própria matriz $\mathbf{A}$, as posições das colunas pivô podem ser identificadas por escalonamento. Nesse procedimento, os vetores da base são as colunas correspondentes da matriz original, e não as colunas da matriz escalonada.

3.3.3 Espaço linha

Definição 3.13 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.14 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.14 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto, todo vetor de $\mathcal{N}(\mathbf{A}^\top)$ é ortogonal a cada coluna de $\mathbf{A}$ e, conseqüentemente, a toda combinação linear dessas colunas. A relação entre o espaço nulo à esquerda e o complemento ortogonal do espaço coluna será formalizada adiante.

Exemplo 3.15 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Extensão de uma base

Uma base de um subespaço pode ser completada acrescentando vetores até formar uma base de todo o espaço. Esse resultado será utilizado na demonstração do Teorema Posto–Nulidade.

Teorema 3.4 (Extensão de uma base). *Seja W um subespaço de um espaço vetorial V de dimensão finita. Se*

$$\mathcal{B}_W = \{\mathbf{u}_1, \dots, \mathbf{u}_s\}$$

é uma base de W , então existem vetores $\mathbf{z}_1, \dots, \mathbf{z}_r \in V$ tais que

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

é uma base de V . (Meyer, 2023)

Comprovação. Se $\mathcal{B}_W$ já gera V , então $\mathcal{B}_W$ é uma base de V e nada precisa ser acrescentado. Caso contrário, existe um vetor $\mathbf{z}_1 \in V$ que não pertence ao subespaço gerado por $\mathcal{B}_W$. Assim,

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1\}$$

é linearmente independente.

Se esse conjunto ainda não gera V , escolhe-se um vetor $\mathbf{z}_2 \in V$ que não pertence ao subespaço gerado pelos vetores já selecionados. O novo conjunto continua linearmente independente.

Repetindo esse procedimento, acrescentam-se vetores enquanto o conjunto obtido não gerar V . Como V possui dimensão finita, não é possível acrescentar indefinidamente vetores linearmente independentes. Portanto, após um número finito de etapas, obtém-se um conjunto

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

que é linearmente independente e gera V . Logo, esse conjunto é uma base de V . $\square$

3.3.6 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.5 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Meyer, 2023)

Comprovação. Considere uma base do espaço nulo,

$$\mathcal{B}_\mathcal{N} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Pelo Teorema 3.4, essa base de $\mathcal{N}(\mathbf{A})$ pode ser completada para formar uma base de $\mathbb{R}^p$. Assim, existem vetores $\mathbf{w}_1, \dots, \mathbf{w}_r \in \mathbb{R}^p$ tais que

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$.

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j.$$

Portanto,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

geram $\mathcal{C}(\mathbf{A})$.

Para verificar a independência linear, suponha que

$$\sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j = \mathbf{0}.$$

Então,

$$\mathbf{A} \left(\sum_{j=1}^r \beta_j \mathbf{w}_j \right) = \mathbf{0},$$

de modo que

$$\sum_{j=1}^r \beta_j \mathbf{w}_j \in \mathcal{N}(\mathbf{A}).$$

Esse vetor também pertence a

$$\text{span}\{\mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$, a interseção entre esses dois subespaços contém somente o vetor nulo. Assim,

$$\beta_1 = \dots = \beta_r = 0.$$

Logo,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

formam uma base de $\mathcal{C}(\mathbf{A})$. Portanto,

$$r = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Logo,

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = p.$$

□

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Exemplo 3.16 (Aplicação do Teorema Posto–Nulidade). Para a matriz utilizada nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Assim, para $\mathbf{A} \in \mathbb{R}^{2 \times 3}$,

$$1 + 2 = 3,$$

confirmando que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = 3.$$

Aplicando o resultado a $\mathbf{A}^\top$,

$$1 + 1 = 2,$$

de modo que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = 2.$$

Os resultados correspondem, respectivamente, às dimensões dos espaços ambientes $\mathbb{R}^3$ e $\mathbb{R}^2$.

3.3.7 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os quatro espaços se organizam em dois espaços ambientes. O espaço coluna e o espaço nulo à esquerda são subespaços de $\mathbb{R}^n$, enquanto o espaço linha e o espaço nulo são subespaços de $\mathbb{R}^p$.

3.3.8 Complemento ortogonal

Definição 3.15 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S . Essa definição permite descrever relações importantes entre os quatro espaços fundamentais de uma matriz.

3.3.9 Relações de ortogonalidade

Teorema 3.6 (Ortogonalidade entre os espaços fundamentais). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{Ax} = \mathbf{0}.$$

Cada componente de $\mathbf{Ax}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, conseqüentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{Ax}$ é, portanto, igual a zero, de modo que

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

□

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

em $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

em $\mathbb{R}^n$.

A decomposição dos espaços ambientes em somas diretas desses pares será obtida posteriormente a partir do resultado geral sobre complementos ortogonais.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Além da geometria euclidiana, é possível definir outras geometrias atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Aprofundamento: produtos internos e geometrias induzidas

Leitura de aprofundamento

Esta subseção generaliza o produto interno euclidiano por meio de matrizes positivas definidas e apresenta as normas, distâncias e relações de ortogonalidade associadas a essa generalização. Esses conceitos serão retomados no estudo da distância de Mahalanobis, de geometrias determinadas por matrizes de covariâncias e de problemas de mínimos quadrados ponderados.

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.16 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Proposição 3.8 (Propriedades do produto interno induzido). *Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$,*

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn; Johnson, 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.17 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.1.1 Norma e distância induzidas

Definição 3.17 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.18 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned}\|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{[2 \quad 1] \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}.\end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.1.2 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no capítulo anterior.

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^{\top} \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.1.3 Relação com a geometria euclidiana

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned}\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}).\end{aligned}$$

Assim, o produto interno induzido por $\mathbf{M}$ pode ser interpretado como o produto interno euclidiano entre os vetores $\mathbf{C} \mathbf{x}$ e $\mathbf{C} \mathbf{y}$. Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma. Analogamente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$$




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

pode ser igual a zero mesmo quando $\mathbf{x} \neq \mathbf{y}$. Portanto, essa expressão define, em geral, uma **pseudodistância**.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.2 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.18 (Matriz de Gram). Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$ e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.19 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.3 Propriedades da matriz de Gram

Proposição 3.9 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$.

(Horn; Johnson, 2013)

Comprovação. A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

Além disso,

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = 0$$

se, e somente se,

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Portanto, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.
Para demonstrar a igualdade dos núcleos, suponha inicialmente que

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{c}^\top$,

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} = \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

Logo,

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

e, portanto,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}).$$

Reciprocamente, se

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

então

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{V}^\top \mathbf{0} = \mathbf{0},$$

de modo que

$$\mathcal{N}(\mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}^\top \mathbf{V}).$$

Assim,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}).$$

Como $\mathbf{V}^\top \mathbf{V}$ e $\mathbf{V}$ possuem o mesmo número de colunas, a igualdade das nulidades e o Teorema Posto–Nulidade implicam

$$\text{posto}(\mathbf{V}^\top \mathbf{V}) = \text{posto}(\mathbf{V}).$$

□

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são linearmente dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.4 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.20 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.5 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela [3.2](#) resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij}x_{ik}$
$\mathbf{X}\mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.4.6 Propriedades do complemento ortogonal

O complemento ortogonal, introduzido anteriormente na descrição dos espaços fundamentais de uma matriz, será agora estudado para um subespaço arbitrário de $\mathbb{R}^p$.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Proposição 3.10 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

Comprovação. O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$(\alpha\mathbf{x} + \beta\mathbf{y})^\top \mathbf{s} = \alpha\mathbf{x}^\top \mathbf{s} + \beta\mathbf{y}^\top \mathbf{s} = 0.$$

Portanto,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$. □

Exemplo 3.21 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$

Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.4.7 Dimensão do complemento ortogonal

Proposição 3.11 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$

Comprovação. Seja

$$\dim(S) = k.$$

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Pelo Teorema 3.4, essa base de S pode ser completada para formar uma base de $\mathbb{R}^p$. Aplicando o processo de Gram–Schmidt aos vetores acrescentados, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k+1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

e, portanto,

$$\alpha_i = 0, \quad i = 1, \dots, k.$$

Logo,

$$\mathbf{x} = \sum_{j=k+1}^p \alpha_j \mathbf{q}_j,$$

de modo que

$$\{\mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}$$

é uma base de $S^\perp$.

Assim,

$$\dim(S^\perp) = p - k,$$

e, como $\dim(S) = k$,

$$\dim(S) + \dim(S^\perp) = p.$$

□

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Outra consequência importante é

$$(S^\perp)^\perp = S.$$

De fato,

$$S \subseteq (S^\perp)^\perp,$$

pois todo vetor de S é ortogonal a todos os vetores de $S^\perp$. Além disso,

$$\begin{aligned} \dim \left((S^\perp)^\perp \right) &= p - \dim(S^\perp) \\ &= p - (p - k) \\ &= k \\ &= \dim(S). \end{aligned}$$

Como um subespaço está contido no outro e ambos possuem a mesma dimensão,

$$(S^\perp)^\perp = S.$$

3.4.8 Decomposição ortogonal

Teorema 3.7 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

O símbolo $\oplus$ representa uma **soma direta**: cada vetor de $\mathbb{R}^p$ possui uma única decomposição como soma de um vetor pertencente a S e um vetor pertencente a $S^\perp$.

Comprovação. Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned}\mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0.\end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

e

$$\mathbf{r}_1, \mathbf{r}_2 \in S^\perp.$$

Então,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{r}_2 - \mathbf{r}_1.$$

O lado esquerdo pertence a S , enquanto o lado direito pertence a $S^\perp$. Portanto, esse vetor pertence a

$$S \cap S^\perp = \{\mathbf{0}\}.$$

Assim,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{0}$$

e

$$\mathbf{r}_2 - \mathbf{r}_1 = \mathbf{0}.$$

Logo,

$$\mathbf{s}_1 = \mathbf{s}_2 \quad \text{e} \quad \mathbf{r}_1 = \mathbf{r}_2.$$

Portanto, a decomposição é única. □

A decomposição separa $\mathbf{x}$ em duas componentes únicas: $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$. Na seção seguinte, veremos que $\mathbf{x}_S$ é precisamente a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.4.9 Decomposição dos espaços fundamentais

A decomposição ortogonal pode ser aplicada diretamente aos quatro espaços fundamentais de uma matriz.

Proposição 3.12 (Decomposição dos espaços fundamentais). *Para uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$,*

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

De fato, pelo Teorema 3.6,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Aplicando o Teorema 3.7,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

com $\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$ e $\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A})$.

Analogamente,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

e, portanto,

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^\top},$$

com $\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$ e $\mathbf{y}_{\mathcal{N}^\top} \in \mathcal{N}(\mathbf{A}^\top)$.

Os quatro espaços fundamentais formam, portanto, dois pares de subespaços ortogonais complementares: um em $\mathbb{R}^p$ e outro em $\mathbb{R}^n$.

3.5 Projeções ortogonais

O Teorema 3.7 estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor $\mathbf{x} \in \mathbb{R}^p$ admite uma decomposição única em uma componente pertencente a S e outra pertencente a $S^\perp$. Essa decomposição permite definir a projeção ortogonal sobre um subespaço.

Definição 3.19 (Projeção ortogonal). Seja S um subespaço de $\mathbb{R}^p$. Pela decomposição ortogonal, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

com $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

A **projeção ortogonal de $\mathbf{x}$ sobre S** é definida por

$$\text{proj}_S(\mathbf{x}) = \mathbf{x}_S.$$

Consequentemente,

$$\mathbf{x} - \text{proj}_S(\mathbf{x}) \in S^\perp.$$

A forma da projeção depende de como o subespaço S é representado. Começaremos pelo caso mais simples, em que S possui dimensão 1.

3.5.1 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Proposição 3.13 (Projeção sobre uma direção). *Se*

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

então a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Como $\mathbf{u}^\top \mathbf{x}$ é um escalar, pode-se escrever

$$\frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}).$$

Pela associatividade da multiplicação matricial,

$$\mathbf{u} (\mathbf{u}^\top \mathbf{x}) = (\mathbf{u} \mathbf{u}^\top) \mathbf{x}.$$

Portanto,

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}) \\ &= \frac{1}{\mathbf{u}^\top \mathbf{u}} (\mathbf{u} \mathbf{u}^\top) \mathbf{x} = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.22 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned}\mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top\mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{P}_S\mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição e destaca a ortogonalidade entre a projeção e o resíduo.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

3.5.2 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Proposição 3.14 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Meyer, 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.23 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.5.3 Projecção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subsecção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projecção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Proposição 3.15 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre $\mathcal{C}(\mathbf{A})$ é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_\mathbf{A} \mathbf{x},$$

em que

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz $\mathbf{P}_\mathbf{A}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$, e não da base particular escolhida para representá-lo.

De fato, suponha que outra base do mesmo subespaço seja organizada em uma matriz

$$\mathbf{B} = \mathbf{A} \mathbf{R},$$

em que $\mathbf{R} \in \mathbb{R}^{k \times k}$ é invertível. Então

$$\begin{aligned} \mathbf{P}_\mathbf{B} &= \mathbf{B} (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \\ &= \mathbf{A} \mathbf{R} (\mathbf{R}^\top \mathbf{A}^\top \mathbf{A} \mathbf{R})^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} \mathbf{R} \mathbf{R}^{-1} (\mathbf{A}^\top \mathbf{A})^{-1} (\mathbf{R}^\top)^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_\mathbf{A}. \end{aligned}$$

Portanto, bases diferentes do mesmo subespaço produzem a mesma matriz de projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_\mathbf{A} = \mathbf{A} \mathbf{A}^\top.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top.$$

Portanto,

$$\mathbf{Q}\mathbf{Q}^\top$$

é o caso ortonormal da expressão geral

$$\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Exemplo 3.24 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned}
\mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\
&= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\
&= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}.
\end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.5.4 Propriedades da matriz de projeção

Proposição 3.16 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top},$$

então:

1. $\mathbf{P}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{P}_{\mathbf{A}}$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
4. $\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp} = \mathcal{N}(\mathbf{A}^{\top})$;
5. $\text{posto}(\mathbf{P}_{\mathbf{A}}) = \text{posto}(\mathbf{A}) = k$.

Comprovação. A simetria decorre de

$$\begin{aligned} \mathbf{P}_{\mathbf{A}}^{\top} &= \left[\mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \right]^{\top} \\ &= \mathbf{A} \left[(\mathbf{A}^{\top} \mathbf{A})^{-1} \right]^{\top} \mathbf{A}^{\top} \\ &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{P}_{\mathbf{A}}, \end{aligned}$$

pois $\mathbf{A}^{\top} \mathbf{A}$ e sua inversa são simétricas.

Para verificar a idempotência,

$$\begin{aligned} \mathbf{P}_{\mathbf{A}}^2 &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{P}_{\mathbf{A}}. \end{aligned}$$

Para determinar o espaço coluna, observe inicialmente que, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_{\mathbf{A}} \mathbf{x} = \mathbf{A} \left[(\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \mathbf{x} \right].$$

Portanto,

$$\mathbf{P}_{\mathbf{A}} \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

e, conseqüentemente,

$$\mathcal{C}(\mathbf{P}_{\mathbf{A}}) \subseteq \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A}),$$

então existe $\mathbf{c} \in \mathbb{R}^k$ tal que

$$\mathbf{y} = \mathbf{A}\mathbf{c}.$$

Assim,

$$\begin{aligned}\mathbf{P}_\mathbf{A}\mathbf{y} &= \mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top\mathbf{A}\mathbf{c} \\ &= \mathbf{A}\mathbf{c} \\ &= \mathbf{y}.\end{aligned}$$

Logo,

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{P}_\mathbf{A}),$$

e, portanto,

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}).$$

Para determinar o espaço nulo, observe que

$$\begin{aligned}\mathbf{A}^\top\mathbf{P}_\mathbf{A} &= \mathbf{A}^\top\mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top \\ &= \mathbf{A}^\top.\end{aligned}$$

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{P}_\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top\mathbf{x} = \mathbf{A}^\top\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{A}^\top \mathbf{x} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{0}.$$

Assim,

$$\mathcal{N}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Finalmente, como

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}),$$

tem-se

$$\text{posto}(\mathbf{P}_\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Como as k colunas de $\mathbf{A}$ são linearmente independentes,

$$\text{posto}(\mathbf{A}) = k.$$

Portanto,

$$\text{posto}(\mathbf{P}_\mathbf{A}) = k.$$

□

A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.5.5 Aprofundamento: projeção residual e complemento ortogonal

Leitura de aprofundamento

Esta seção desenvolve a matriz que projeta um vetor sobre o complemento ortogonal de um subespaço. Essa representação será retomada no estudo de mínimos quadrados, da Decomposição em Valores Singulares e do modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

com colunas linearmente independentes e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}} \mathbf{x}.$$

Definição 3.20 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Proposição 3.17 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
3. $\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$ e $\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}$;
4. $\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
6. se $\mathbf{A}$ possui posto k , então $\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k$.

Comprovação. Como $\mathbf{P}_{\mathbf{A}}$ é simétrica,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^\top &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}}.\end{aligned}$$

Portanto, $\mathbf{M}_{\mathbf{A}}$ é simétrica.

Para verificar a idempotência,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^2 &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^2 \\ &= \mathbf{I}_p - 2\mathbf{P}_{\mathbf{A}} + \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}},\end{aligned}$$

pois

$$\mathbf{P}_{\mathbf{A}}^2 = \mathbf{P}_{\mathbf{A}}.$$

Além disso,

$$\begin{aligned}\mathbf{P}_A \mathbf{M}_A &= \mathbf{P}_A (\mathbf{I}_p - \mathbf{P}_A) \\ &= \mathbf{P}_A - \mathbf{P}_A^2 \\ &= \mathbf{0},\end{aligned}$$

e, de forma análoga,

$$\mathbf{M}_A \mathbf{P}_A = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{M}_A \mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{M}_A \mathbf{x} \in \mathcal{N}(\mathbf{P}_A).$$

Como

$$\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp,$$

tem-se

$$\mathcal{C}(\mathbf{M}_A) \subseteq \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{P}_A \mathbf{y} = \mathbf{0},$$

e, portanto,

$$\begin{aligned}\mathbf{M}_A \mathbf{y} &= (\mathbf{I}_p - \mathbf{P}_A) \mathbf{y} \\ &= \mathbf{y}.\end{aligned}$$

Assim,

$$\mathcal{C}(\mathbf{A})^\perp \subseteq \mathcal{C}(\mathbf{M}_\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{M}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Agora, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{x}.$$

Consequentemente,

$$\mathbf{M}_\mathbf{A} \mathbf{x} = \mathbf{0},$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{M}_\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{M}_\mathbf{A}),$$

então

$$(\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \mathbf{P}_\mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{P}_\mathbf{A} \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

segue que

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Finalmente,

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\dim \mathcal{C}(\mathbf{A}) = k,$$

o teorema da dimensão do complemento ortogonal fornece

$$\dim \mathcal{C}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

Logo,

$$\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

□

3.5.6 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.8 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer, 2023)

Comprovação. Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

□

Portanto, a projeção ortogonal pode ser caracterizada equivalentemente como

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Assim, projetar ortogonalmente $\mathbf{x}$ sobre S equivale a encontrar, entre todos os vetores pertencentes a S , aquele que está mais próximo de $\mathbf{x}$ segundo a distância euclidiana.

Quando $S = \mathcal{C}(\mathbf{A})$, com $\mathbf{A} \in \mathbb{R}^{p \times k}$, todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente, o problema de melhor aproximação pode ser escrito como

$$\hat{\mathbf{c}} \in \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor mais próximo de $\mathbf{x}$ em $\mathcal{C}(\mathbf{A})$ é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa formulação estabelece a ligação entre projeção ortogonal e mínimos quadrados. O desenvolvimento algébrico dessa relação é apresentado a seguir como aprofundamento.

3.5.7 Aprofundamento: projeções e mínimos quadrados

Leitura de aprofundamento

Esta seção desenvolve algebricamente a relação entre projeção ortogonal e mínimos quadrados. As equações normais, os resíduos, as matrizes de projeção e a pseudoinversa serão retomados na Decomposição em Valores Singulares e no modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^k} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.8, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.21 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A} \hat{\boldsymbol{\beta}} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\boldsymbol{\beta}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\boldsymbol{\beta}} \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\ &= \mathbf{P}_\mathbf{A} \mathbf{b}, \end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned} \hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\ &= \mathbf{M}_\mathbf{A} \mathbf{b}. \end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Proposição 3.18 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub; Van Loan, 2013)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, o problema de mínimos quadrados pode possuir diferentes vetores de coeficientes que produzem o mesmo ajuste. Portanto, $\hat{\beta}$ pode não ser único.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$.

Utilizando a pseudoinversa de Moore–Penrose (ver Definição 2.17),

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

de modo que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^+.$$

A pseudoinversa foi introduzida no capítulo anterior. Sua construção por meio da Decomposição em Valores Singulares será desenvolvida posteriormente.

As projeções ponderadas podem ser obtidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será retomada no estudo de problemas de mínimos quadrados ponderados.

3.6 Síntese do capítulo

Os espaços vetoriais permitem organizar conjuntos de vetores que preservam as operações de adição e multiplicação por escalar. Dentro desses espaços, os subespaços representam estruturas lineares de menor dimensão, enquanto bases fornecem conjuntos de vetores linearmente independentes capazes de gerar todo o espaço considerado. Fixada uma base, cada vetor pode ser representado de maneira única por suas coordenadas nessa base.

A dimensão quantifica o número de direções independentes necessárias para representar um espaço. Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

essa ideia conduz aos quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}), \mathcal{L}(\mathbf{A}), \mathcal{N}(\mathbf{A}) \text{ e } \mathcal{N}(\mathbf{A}^\top).$$

Se $r = \text{posto}(\mathbf{A})$, suas dimensões são

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

As matrizes de Gram organizam produtos internos entre conjuntos de vetores. Para uma matriz $\mathbf{V}$,

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

é simétrica e semidefinida positiva, e sua estrutura permite relacionar produtos internos, independência linear e posto.

A decomposição ortogonal estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor pode ser escrito de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com $\text{proj}_S(\mathbf{x}) \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , a matriz de projeção é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Se $S = \mathcal{C}(\mathbf{A})$ e as colunas de $\mathbf{A}$ são linearmente independentes, a mesma projeção pode ser escrita como

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção ortogonal possui ainda uma interpretação por otimização:

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Essa propriedade estabelece a ligação entre geometria, projeções e problemas de mínimos quadrados.

As partes de aprofundamento generalizam a geometria euclidiana por meio de produtos internos induzidos por matrizes positivas definidas e desenvolvem a matriz de projeção residual, as equações normais, o caso de posto deficiente e a pseudoinversa. Esses resultados serão retomados quando sua utilização se tornar necessária nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- interpretar geração, dependência e independência linear;
- identificar bases e determinar dimensões;
- representar vetores por coordenadas em uma base;
- distinguir bases gerais, ortogonais e ortonormais;
- determinar e interpretar os quatro espaços fundamentais de uma matriz;
- relacionar posto, nulidade e dimensão;
- interpretar as relações de ortogonalidade entre os espaços fundamentais;
- construir e interpretar matrizes de Gram;
- determinar complementos ortogonais e decomposições ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar a projeção ortogonal como problema de melhor aproximação;
- reconhecer a relação geométrica entre projeções e mínimos quadrados.

No próximo capítulo, as matrizes serão estudadas como representações de transformações lineares entre espaços vetoriais. Os conceitos de base, dimensão, posto, espaços fundamentais e projeções desenvolvidos aqui permitirão interpretar como essas transformações atuam sobre vetores e subespaços. O espaço nulo e o espaço coluna também serão relacionados, nesse novo contexto, ao núcleo e à imagem da transformação associada a uma matriz.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada **transformação linear**.

No capítulo anterior, o espaço nulo e o espaço coluna foram definidos diretamente a partir de uma matriz. Neste capítulo, essas estruturas serão também interpretadas, respectivamente, como o núcleo e a imagem da transformação linear associada à matriz.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

Convenções para transformações lineares

As convenções vetoriais e matriciais estabelecidas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $T : V \rightarrow W$ representa uma transformação entre os espaços vetoriais V e W ;
- V representa o domínio e W o contradomínio da transformação;
- $\mathbf{x} \in V$ representa um vetor do domínio e $T(\mathbf{x}) \in W$ sua imagem pela transformação;
- $T_{\mathbf{A}}$ representa a transformação linear associada à matriz $\mathbf{A}$;
- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ quando utilizada na forma $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$;
- $\ker(T)$ representa o núcleo de uma transformação linear;
- $\text{Im}(T)$ representa a imagem de uma transformação linear;
- $\mathcal{E}_p$ representa a base canônica de $\mathbb{R}^p$;
- $[T]_{\mathcal{C} \leftarrow \mathcal{B}}$ representa a matriz de uma transformação em relação a uma base $\mathcal{B}$ do domínio e a uma base $\mathcal{C}$ do contradomínio.

As relações entre essas notações e os espaços fundamentais das matrizes serão estabelecidas ao longo do capítulo.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha\mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

Proposição 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

Comprovação. Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned}
T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\
&= T(\mathbf{u}) + T(-\mathbf{v}) \\
&= T(\mathbf{u}) - T(\mathbf{v}).
\end{aligned}$$

□

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Proposição 4.2 (Determinação de uma transformação por uma base). *Seja V um espaço vetorial de dimensão finita e seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_k).$$

(Meyer, 2023)

Comprovação. Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_k T(\mathbf{v}_k).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio fica determinada de maneira única. □

Exemplo 4.1 (Transformação determinada pelas imagens de uma base). Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\ &= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}. \end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Portanto, a matriz que representa T na base canônica é

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix},$$

cujas colunas são precisamente

$$T(\mathbf{e}_1) \quad \text{e} \quad T(\mathbf{e}_2).$$

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \dots + x_p T(\mathbf{e}_p) \\ &= x_1 \mathbf{a}_1 + \dots + x_p \mathbf{a}_p \\ &= \mathbf{A}\mathbf{x}. \end{aligned}$$

Isso estabelece a existência de uma matriz que representa T nas bases canônicas.

Para verificar a unicidade, suponha que outra matriz

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

também satisfaça

$$T(\mathbf{x}) = \mathbf{C}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Aplicando essa igualdade aos vetores da base canônica,

$$\mathbf{C}\mathbf{e}_j = T(\mathbf{e}_j) = \mathbf{A}\mathbf{e}_j, \quad j = 1, \dots, p.$$

Como $\mathbf{A}\mathbf{e}_j$ e $\mathbf{C}\mathbf{e}_j$ correspondem, respectivamente, às j -ésimas colunas de $\mathbf{A}$ e $\mathbf{C}$, todas as colunas das duas matrizes são iguais. Portanto,

$$\mathbf{C} = \mathbf{A}.$$

A matriz representante de T nas bases canônicas é, assim, única.

Proposição 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

(Meyer, 2023)

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned} T_{\mathbf{A}}(\alpha\mathbf{u} + \beta\mathbf{v}) &= \mathbf{A}(\alpha\mathbf{u} + \beta\mathbf{v}) \\ &= \alpha\mathbf{A}\mathbf{u} + \beta\mathbf{A}\mathbf{v} \\ &= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}). \end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Núcleo e imagem de uma transformação linear

Dois subespaços descrevem aspectos fundamentais da ação de uma transformação linear: os vetores do domínio que são enviados ao vetor nulo e os vetores do contradomínio que podem ser obtidos pela transformação.

Definição 4.2 (Núcleo e imagem de uma transformação linear). Seja

$$T : V \longrightarrow W$$

uma transformação linear.

O **núcleo** de T é o conjunto

$$\ker(T) = \{\mathbf{x} \in V : T(\mathbf{x}) = \mathbf{0}\}.$$

A **imagem** de T é o conjunto

$$\text{Im}(T) = \{T(\mathbf{x}) : \mathbf{x} \in V\}.$$

O núcleo é um subespaço do domínio V , enquanto a imagem é um subespaço do contradomínio W .

Para a transformação matricial

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax},$$

o núcleo é

$$\begin{aligned}\ker(T_{\mathbf{A}}) &= \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\} \\ &= \mathcal{N}(\mathbf{A}),\end{aligned}$$

e a imagem é

$$\begin{aligned}\operatorname{Im}(T_{\mathbf{A}}) &= \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p\} \\ &= \mathcal{C}(\mathbf{A}).\end{aligned}$$

Relação com os subespaços associados a uma matriz

O **espaço nulo** e o **espaço coluna** estudados no capítulo anterior correspondem, respectivamente, ao **núcleo** e à **imagem** da transformação linear associada à matriz $\mathbf{A}$:

$$\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}}), \quad \mathcal{C}(\mathbf{A}) = \operatorname{Im}(T_{\mathbf{A}}).$$

Se

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

o **contradomínio** é $\mathbb{R}^q$, enquanto a imagem é o subespaço efetivamente alcançado pela transformação,

$$\operatorname{Im}(T_{\mathbf{A}}) \subseteq \mathbb{R}^q.$$

4.1.4 Imagem de um subespaço

Considere um subespaço

$$S = \operatorname{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \cdots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Proposição 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Comprovação. A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A} \mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X} \mathbf{A}^\top.$$

□

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q] .$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q] .$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}_{\cdot j} = \mathbf{X}\mathbf{w}_j .$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip} .$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.2 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} .$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} ,$$

tem-se

$$\begin{aligned}
\mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\
&= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\
&= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}.
\end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned}
\mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\
&= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\
&= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}.
\end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}_{.1} = \mathbf{x}_{.1} + \mathbf{x}_{.2}.$$

A segunda é

$$\mathbf{y}_{.2} = 2\mathbf{x}_{.1} - \mathbf{x}_{.2}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, todas as observações transformadas pertencem a um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Assim, a dimensão da configuração transformada não pode exceder $\text{posto}(\mathbf{A})$, embora possa ser menor, dependendo da configuração original dos dados.

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando $r < p$, a transformação possui núcleo não trivial e elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, como a transformação modifica produtos internos, comprimentos e distâncias. Quando $\mathbf{A}$ possui posto completo nas colunas, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e determina um produto interno no domínio. Quando $\mathbf{A}$ não possui posto completo nas colunas, essa matriz é apenas semidefinida positiva e algumas direções são eliminadas pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

para os quais

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}^\top \mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Proposição 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

A ordem de aplicação das transformações é importante. Quando duas transformações atuam sobre o mesmo espaço,

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e

$$T_2 : \mathbb{R}^p \longrightarrow \mathbb{R}^p,$$

representadas, respectivamente, por

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{p \times p},$$

as duas composições

$$T_2 \circ T_1$$

e

$$T_1 \circ T_2$$

estão definidas. Suas matrizes representantes são, respectivamente,

$$\mathbf{BA}$$

e

$$\mathbf{AB}.$$

Como a multiplicação de matrizes não é, em geral, comutativa,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente, em geral,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

A igualdade pode ocorrer para transformações particulares, mas não constitui uma propriedade geral da composição.

Exemplo 4.3 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.3 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{Ax},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Proposição 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Comprovação. Tem-se

$$\begin{aligned} (\mathbf{BA})(\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B}(\mathbf{AA}^{-1})\mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1})(\mathbf{BA}) &= \mathbf{A}^{-1}(\mathbf{B}^{-1}\mathbf{B})\mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

□

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.4 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Proposição 4.7 (Caracterizações por núcleo, imagem e posto). *Seja*

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

com $\mathbf{A} \in \mathbb{R}^{q \times p}$. Então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

(Meyer, 2023)

Comprovação. Suponha inicialmente que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{Ax}_1 = \mathbf{Ax}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema [3.5](#),

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

Como $\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}})$, tem-se

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

Por outro lado, $T_{\mathbf{A}}$ é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à sua imagem. Como

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}),$$

a sobrejetividade equivale a

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim \mathcal{C}(\mathbf{A}) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

□

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando o Proposição 4.7 com o Teorema 2.5, obtém-se o resultado seguinte.

Proposição 4.8 (Equivalências para uma transformação linear associada a uma matriz quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $T_{\mathbf{A}}$ é invertível;
5. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
6. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
7. $\text{posto}(\mathbf{A}) = p$;
8. $\det(\mathbf{A}) \neq 0$;
9. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$

Propriedade	Condição geométrica	Condição matricial
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \ker(T_{\mathbf{A}}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \ker(T_{\mathbf{A}})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo núcleo da transformação, que coincide com o espaço nulo da matriz associada.

Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

O espaço nulo possui dimensão $p-r$. Portanto, existem $p-r$ direções linearmente independentes no domínio que são anuladas pela transformação, enquanto a imagem possui dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar

$$\text{posto}(\mathbf{A})$$

como a dimensão da imagem da transformação, isto é, como o número máximo de direções linearmente independentes que podem compor o espaço transformado. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam a posição da configuração em relação aos eixos coordenados sem deformar sua geometria, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;

- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}_\theta \mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}_\theta^\top \mathbf{Q}_\theta = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}_\theta^{-1} = \mathbf{Q}_\theta^\top = \mathbf{Q}_{-\theta}.$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}_\theta) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada **reflexão de Householder**.

Observe que as duas construções preservam componentes diferentes. A matriz $2\mathbf{u}\mathbf{u}^\top - \mathbf{I}$ preserva a componente na direção de $\mathbf{u}$ e inverte as componentes ortogonais a ela, enquanto $\mathbf{I} - 2\mathbf{u}\mathbf{u}^\top$ preserva as componentes ortogonais a $\mathbf{u}$ e inverte a componente na direção de $\mathbf{u}$.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é reescalada por um fator próprio, de modo que comprimentos, ângulos e proporções podem ser alterados. Se algum fator s_j for negativo, além da alteração de escala ocorre a inversão do sentido da coordenada correspondente.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned} y_1 &= x_1 + kx_2, \\ y_2 &= x_2. \end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det\left(\mathbf{C}_{ij}(k)\right) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

As projeções ortogonais foram desenvolvidas no capítulo anterior a partir da decomposição de um vetor em componentes pertencentes a subespaços ortogonais. Aqui, interessa interpretá-las como transformações lineares.

Considere uma direção unitária

$$\mathbf{u} \in \mathbb{R}^p, \quad \|\mathbf{u}\| = 1,$$

e o subespaço

$$S = \text{span}\{\mathbf{u}\}.$$

A matriz da projeção ortogonal sobre S é

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top,$$

de modo que

$$T_{\mathbf{P}_S}(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

Como estudado no capítulo anterior,

$$\mathbf{P}_S^2 = \mathbf{P}_S$$

e

$$\mathbf{P}_S^\top = \mathbf{P}_S.$$

Do ponto de vista das transformações lineares,

$$\text{Im}(T_{\mathbf{P}_S}) = S$$

e

$$\ker(T_{\mathbf{P}_S}) = S^\perp.$$

Assim, a projeção preserva a componente pertencente a S e elimina toda a componente pertencente a $S^\perp$.

Para uma projeção sobre uma única direção,

$$\text{posto}(\mathbf{P}_S) = 1.$$

Consequentemente, quando $p > 1$,

$$\det(\mathbf{P}_S) = 0,$$

e a transformação não é invertível. Vetores que diferem apenas por uma componente pertencente a $S^\perp$ possuem a mesma imagem.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário. Como todos os painéis utilizam a mesma escala, alterações de forma, área e dimensão podem ser comparadas diretamente.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

A rotação altera a posição do quadrado em relação aos eixos coordenados sem modificar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme modifica os comprimentos nas direções coordenadas e transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área, mostrando que preservar área não implica preservar ângulos ou comprimentos. A projeção elimina uma direção e reduz a figura a um segmento de reta.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Proposição 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$E \subseteq \mathbb{R}^p$$

um conjunto mensurável com volume p -dimensional finito. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se

$$\det(\mathbf{A}) = 0,$$

então

$$\text{posto}(\mathbf{A}) < p,$$

de modo que a imagem $\mathbf{A}E$ está contida em um subespaço próprio de $\mathbb{R}^p$. Consequentemente,

$$\text{Vol}_p(\mathbf{A}E) = 0.$$

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

Quando a transformação é invertível, o sinal do determinante descreve o efeito sobre a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida.

Se $\det(\mathbf{A}) = 0$, a transformação não é invertível, sua imagem possui dimensão inferior a p e o volume p -dimensional é reduzido a zero.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}_\theta$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Reescala direções coordenadas
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.18, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Proposição 4.10 (Preservação da geometria euclidiana). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, a transformação*

$$T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x}$$

preserva:

1. o produto interno;
2. as normas;
3. as distâncias euclidianas;
4. os ângulos entre vetores não nulos;
5. a ortogonalidade.

Comprovação. Pelo Teorema 2.7,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Portanto, o produto interno entre quaisquer dois vetores é preservado.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2.\end{aligned}$$

Como as normas são não negativas,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|.\end{aligned}$$

Logo, todas as distâncias euclidianas entre pares de vetores são preservadas.

Para vetores não nulos, o ângulo θ entre $\mathbf{x}$ e $\mathbf{y}$ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como o produto interno e as normas são preservados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados.

Em particular, se

$$\mathbf{x}^\top \mathbf{y} = 0,$$

então

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0,$$

e a ortogonalidade é preservada. □

Assim, transformações ortogonais preservam integralmente as relações métricas determinadas pelo produto interno euclidiano. Elas podem alterar a orientação da configuração, mas não deformam sua geometria interna.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Proposição 4.11 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top. \end{aligned}$$

□

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados não nulos.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Proposição 4.12 (Determinante de uma matriz ortogonal). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então*

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

Consequentemente,

$$|\det(\mathbf{Q})| = 1,$$

e a transformação preserva volumes p -dimensionais.

Comprovação. Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned} 1 &= \det(\mathbf{Q}^\top \mathbf{Q}) \\ &= \det(\mathbf{Q}^\top) \det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2. \end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Logo,

$$|\det(\mathbf{Q})| = 1.$$

□

No plano, a preservação do volume p -dimensional corresponde à preservação de áreas; em $\mathbb{R}^3$, corresponde à preservação de volumes.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no Capítulo 2. Portanto, as colunas de $\mathbf{Q}$ possuem norma unitária e são ortogonais duas a duas.

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também formam um conjunto ortonormal.

Uma matriz ortogonal admite, portanto, duas interpretações que devem ser distinguidas:

- como matriz de uma transformação linear que preserva a geometria euclidiana;
- como matriz cujas colunas constituem uma base ortonormal de $\mathbb{R}^p$.

Na primeira interpretação, a matriz atua sobre o vetor e modifica sua posição no espaço. Na segunda, seus vetores-coluna definem um sistema de coordenadas. A relação entre essas duas interpretações será desenvolvida na seção seguinte.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções inicialmente ortogonais. O marcador de ângulo reto identifica os casos em que a ortogonalidade é preservada.

A rotação e a reflexão mantêm a circunferência unitária e preservam o ângulo reto entre as duas direções. O escalonamento não uniforme transforma a circunferência em uma elipse; embora as duas direções coordenadas permaneçam ortogonais neste exemplo particular, seus comprimentos são alterados e a transformação não é ortogonal. O cisalhamento deforma a circunferência e também altera o ângulo entre as direções.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções inicialmente ortogonais.

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$, com a ordem dos vetores fixada. Como definido no capítulo anterior, a matriz formada pelos vetores da base é

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes, $\mathbf{B}$ é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Assim, $\mathbf{B}$ converte as coordenadas de $\mathbf{x}$ na base $\mathcal{B}$ em suas coordenadas na base canônica, enquanto $\mathbf{B}^{-1}$ realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{B}^{\top}\mathbf{B} = \mathbf{I}_p.$$

Logo,

$$\mathbf{B}^{-1} = \mathbf{B}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{\top}\mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top}\mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top}\mathbf{x} \end{bmatrix},$$

de modo que cada coordenada é obtida pelo produto interno entre $\mathbf{x}$ e o vetor correspondente da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$,

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\},$$

e as respectivas matrizes

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p]$$

e

$$\mathbf{C} = [\mathbf{c}_1 \quad \dots \quad \mathbf{c}_p].$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{C}[\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{C}[\mathbf{x}]_{\mathcal{C}} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando à esquerda por $\mathbf{C}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.5 (Matriz de mudança de base). A **matriz de mudança de base de $\mathcal{B}$ para $\mathcal{C}$** é

$$\mathbf{C}^{-1}\mathbf{B}.$$

Ela transforma as coordenadas de um vetor na base $\mathcal{B}$ em suas coordenadas na base $\mathcal{C}$:

$$[\mathbf{x}]_{\mathcal{C}} = (\mathbf{C}^{-1}\mathbf{B}) [\mathbf{x}]_{\mathcal{B}}.$$

O sentido da conversão deve ser observado na ordem das matrizes:

$$\mathcal{B} \longrightarrow \mathcal{C} \quad \Longleftrightarrow \quad \mathbf{C}^{-1}\mathbf{B}.$$

No sentido contrário, a matriz de mudança de base é

$$\mathbf{B}^{-1}\mathbf{C}.$$

As duas matrizes são inversas entre si:

$$\mathbf{B}^{-1}\mathbf{C} = (\mathbf{C}^{-1}\mathbf{B})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio, com matriz

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p],$$

e seja $\mathcal{C}$ uma base do contradomínio, com matriz

$$\mathbf{C} = [\mathbf{c}_1 \quad \cdots \quad \mathbf{c}_q].$$

Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{C}^{-1}T(\mathbf{x}) \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Proposição 4.13 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

A fórmula pode ser interpretada pela sequência das operações, da direita para a esquerda:

$$[\mathbf{x}]_{\mathcal{B}} \xrightarrow{\mathbf{B}} \mathbf{x} \xrightarrow{\mathbf{A}} T(\mathbf{x}) \xrightarrow{\mathbf{C}^{-1}} [T(\mathbf{x})]_{\mathcal{C}}.$$

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.4 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{C}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}
[T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{C}^{-1} \mathbf{A} \mathbf{B} \\
&= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\
&= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}.
\end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio,

$$[T]_{\mathcal{B} \leftarrow \mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Quando conveniente, essa matriz será denotada abreviadamente por

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Definição 4.6 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{D}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Proposição 4.14 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{D}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{D}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{D}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{D}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

Comprovação. Para o determinante,

$$\begin{aligned} \det(\mathbf{D}) &= \det(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}). \end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{D}) &= \text{tr}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \text{tr}(\mathbf{A} \mathbf{P} \mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}). \end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) = \text{posto}(\mathbf{A}).$$

□

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}_{\theta}$,

$$\mathbf{Q}_{\theta}^{-1} = \mathbf{Q}_{\theta}^{\top} = \mathbf{Q}_{(-\theta)}.$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$

Portanto, embora uma mesma matriz ortogonal possa aparecer nas duas interpretações, o sentido da operação é distinto: na transformação ativa, $\mathbf{Q}$ atua sobre o vetor; na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$, a conversão das coordenadas é realizada por $\mathbf{Q}^{-1} = \mathbf{Q}^\top$.

A Figura 4.7 compara as duas interpretações.




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa por $\mathbf{Q}$	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base formada pelas colunas de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.7 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui dimensão $n \times q$ e contém n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

As dimensões da transformação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} + \underbrace{\mathbf{1}_n}_{n \times 1} \underbrace{\mathbf{b}^\top}_{1 \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned}
\mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\
&= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\
&= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.
\end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. Em contraste, a aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Além disso,

$$\mathbf{H}_n = \mathbf{H}_n^\top$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Portanto, $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

seu núcleo é

$$\mathcal{N}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\},$$

e sua imagem é o subespaço

$$\mathcal{C}(\mathbf{H}_n) = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\} = \text{span}\{\mathbf{1}_n\}^\perp.$$

Assim, multiplicar uma variável observada por $\mathbf{H}_n$ equivale a projetá-la ortogonalmente sobre o subespaço dos vetores cujas componentes somam zero.

Como $\mathbf{H}_n$ é simétrica e

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{1}_n^\top \mathbf{H}_n \mathbf{X} = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Proposição 4.15 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Logo, as duas diferenças possuem a mesma norma. □

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica, em geral, distâncias e ângulos. Alguns pares particulares de vetores podem manter sua relação angular, mas a geometria euclidiana não é preservada para todos os vetores. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada pela matriz positiva definida

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas. Quando todas as escalas são iguais, isto é,

$$\mathbf{L} = \ell \mathbf{I}_p,$$

o escalonamento é uniforme: todas as distâncias são multiplicadas pelo mesmo fator $1/\ell$ e os ângulos são preservados.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1, desde que todas as variáveis apresentem desvio-padrão amostral positivo.

A interpretação da padronização como transformação afim considera $\mathbf{m}$ e $\mathbf{L}$ fixados. Quando o vetor de médias e os desvios-padrão são calculados a partir da própria matriz de dados $\mathbf{X}$, esses elementos passam a depender dos dados. Nesse caso, para os valores calculados de $\mathbf{m}$ e $\mathbf{L}$, cada observação é submetida à transformação afim

$$\mathbf{x} \mapsto \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}),$$

mas a operação completa que associa a matriz original $\mathbf{X}$ à matriz padronizada $\mathbf{Z}$ é dependente dos dados e não constitui, globalmente, uma transformação afim de $\mathbf{X}$.

Para duas observações padronizadas,

$$\begin{aligned}\mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j) .\end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j) .$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}) .$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x} ,$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m} .$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1} \mathbf{m} .$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim de $\mathbb{R}^p$ em $\mathbb{R}^p$ é invertível se, e somente se, sua parte linear $\mathbf{A}$ é invertível.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos. O mesmo vetor de escalas é utilizado no escalonamento e na padronização, permitindo separar visualmente o efeito da alteração de escala do efeito da centralização.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as diferenças nem as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e, em geral, modifica comprimentos, distâncias e ângulos. A padronização combina esses dois efeitos: centraliza a nuvem e reescala suas coordenadas.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão para um vetor	Linear como função de $\mathbf{x}$?	Mantém a origem fixa?
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalação	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares podem modificar direção, escala ou dimensão, mas mantêm necessariamente a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando consideradas como operações sobre uma observação individual e para parâmetros de localização e escala fixados. Quando a centralização de uma matriz de dados é escrita como $\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$, a operação é linear no espaço das matrizes.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Para uma transformação

$$T : V \longrightarrow W,$$

tem-se

$$T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica, entre outras consequências,

$$T(\mathbf{0}) = \mathbf{0},$$

e permite determinar uma transformação linear a partir de sua ação sobre uma base do domínio.

Fixadas as bases do domínio e do contradomínio, uma transformação linear possui uma representação matricial única. Em particular, nas bases canônicas, uma transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Quando as observações ocupam as linhas de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea das observações é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^{\top}.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada, enquanto cada coluna corresponde a uma combinação linear das variáveis originais.

A matriz associada à transformação permite relacionar os conceitos desenvolvidos neste capítulo aos espaços fundamentais estudados anteriormente:

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o núcleo reúne os vetores eliminados pela transformação, enquanto a imagem contém todos os vetores que podem ser produzidos por ela. Pelo teorema posto-nulidade,

$$\dim \ker(T_{\mathbf{A}}) + \dim \operatorname{Im}(T_{\mathbf{A}}) = p,$$

ou, equivalentemente,

$$\dim \mathcal{N}(\mathbf{A}) + \operatorname{posto}(\mathbf{A}) = p.$$

O posto é, portanto, a dimensão da imagem da transformação. Quando o núcleo contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem e ocorre perda de informação.

Para uma transformação quadrada, as condições

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\},$$

$$\operatorname{Im}(T_{\mathbf{A}}) = \mathbb{R}^p,$$

$$\operatorname{posto}(\mathbf{A}) = p,$$

$$\det(\mathbf{A}) \neq 0$$

e a existência de $\mathbf{A}^{-1}$ são equivalentes.

A composição de transformações corresponde ao produto de suas matrizes. Se T_1 é representada por $\mathbf{A}_1$ e T_2 por $\mathbf{A}_2$, então

$$[T_2 \circ T_1] = \mathbf{A}_2 \mathbf{A}_1.$$

A matriz situada à direita atua primeiro. Como o produto matricial não é comutativo, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas ilustram diferentes efeitos possíveis sobre uma configuração. Rotações e reflexões são transformações ortogonais e preservam a geometria euclidiana. Escalonamentos alteram as escalas das direções coordenadas; cisalhamentos modificam, em geral, ângulos e comprimentos; projeções eliminam componentes pertencentes ao complemento do subespaço sobre o qual se projeta.

Para uma transformação quadrada,

$$|\det(\mathbf{A})|$$

representa o fator de alteração do volume p -dimensional. Quando $\det(\mathbf{A}) \neq 0$, seu sinal informa também o efeito sobre a orientação: valores positivos preservam a orientação e valores negativos a invertem. Se

$$\det(\mathbf{A}) = 0,$$

a transformação reduz a dimensão e o volume p -dimensional da imagem é igual a zero.

As transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos e, consequentemente, normas, distâncias, ângulos e ortogonalidade. Além disso,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) \in \{-1, 1\},$$

de modo que também preservam volumes p -dimensionais.

As colunas de uma matriz ortogonal formam uma base ortonormal e satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij}.$$

Essa propriedade estabelece a ligação entre transformações ortogonais e sistemas de coordenadas ortonormais.

Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

é uma base de $\mathbb{R}^p$ e

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p],$$

então

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Para duas bases $\mathcal{B}$ e $\mathcal{C}$, com matrizes $\mathbf{B}$ e $\mathbf{C}$, respectivamente, a conversão das coordenadas de $\mathcal{B}$ para $\mathcal{C}$ é

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Se uma transformação é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Quando a mesma base é utilizada no domínio e no contradomínio,

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B},$$

de modo que as duas matrizes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa e a mudança passiva de coordenadas devem ser diferenciadas. Se $\mathbf{Q}$ é ortogonal, na transformação ativa,

$$\mathbf{y} = \mathbf{Q}\mathbf{x},$$

enquanto, na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top}\mathbf{x}.$$

Na primeira situação, o vetor é transformado em relação a eixos fixos. Na segunda, o vetor geométrico permanece o mesmo e apenas sua representação em coordenadas é alterada.

As transformações afins generalizam as transformações lineares por meio da inclusão de uma translação:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização de uma observação em torno de um vetor fixo é uma transformação afim, enquanto o escalonamento é uma transformação linear diagonal. A padronização combina essas duas operações.

Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Como

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

a matriz $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Sua imagem é

$$\mathcal{C}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\}^\perp,$$

o subespaço dos vetores cujas componentes somam zero.

A Tabela 4.6 reúne algumas das principais expressões desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$	Transforma simultaneamente as observações
Núcleo	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$	Reúne os vetores enviados ao vetor nulo
Imagem	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$	Reúne os vetores alcançados pela transformação
Composição	$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{A}_2 \mathbf{A}_1 \mathbf{x}$	Aplica T_1 antes de T_2
Transformação inversa	$\mathbf{x} = \mathbf{A}^{-1} \mathbf{y}$	Recupera o vetor original quando $\mathbf{A}$ é invertível
Rotação	$\mathbf{Q}_\theta \mathbf{x}$	Preserva a geometria e a orientação

Objeto ou operação	Expressão	Interpretação
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria; seu efeito sobre a orientação é determinado pelo determinante
Escalonamento	$\mathbf{L}\mathbf{x}$	Reescala direções coordenadas
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração preservando volume no caso elementar
Projeção ortogonal	$\mathbf{P}_S\mathbf{x}$	Mantém a componente em S e elimina a componente em $S^\perp$
Coordenadas em uma base	$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}$	Representa o mesmo vetor na base $\mathcal{B}$
Mudança de $\mathcal{B}$ para $\mathcal{C}$	$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}$	Converte coordenadas entre bases
Transformação em bases gerais	$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}$	Representa a transformação nas bases escolhidas
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização dos dados	$\mathbf{X}_c = \mathbf{H}_n\mathbf{X}$	Projeta cada variável no subespaço de média zero
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

Ao final deste capítulo, o estudante deverá ser capaz de:

- reconhecer e verificar a linearidade de uma transformação;
- construir a matriz de uma transformação a partir da imagem de uma base;
- relacionar núcleo e imagem de uma transformação ao espaço nulo e ao espaço coluna da matriz associada;
- interpretar posto, injetividade, sobrejetividade, bijetividade e perda de informação;
- representar a composição e a inversão de transformações por operações matriciais;
- interpretar geometricamente rotações, reflexões, escalonamentos, cisalhamentos e projeções;
- relacionar o determinante à alteração de volume, à orientação e à redução de dimensão;
- reconhecer transformações ortogonais e interpretar as propriedades geométricas que elas preservam;
- converter coordenadas entre bases;
- representar uma transformação linear em bases distintas do domínio e do contradomínio;
- distinguir transformação ativa e mudança passiva de coordenadas;
- interpretar transformações afins, centralização, escalonamento e padronização;

- reconhecer a matriz de centralização como uma matriz de projeção ortogonal.

No próximo capítulo, serão estudadas direções especiais para as quais a ação de uma transformação linear produz um múltiplo escalar do próprio vetor,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Essas direções conduzem aos conceitos de autovetores, autovalores, autoespaços e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Vimos também que a matriz de um operador depende da base utilizada para representá-lo. Uma mudança de base pode produzir uma matriz mais simples, embora o operador linear permaneça o mesmo. Neste capítulo, procuraremos bases especialmente adaptadas à ação do operador.

Algumas direções possuem um comportamento particularmente simples: quando um vetor pertence a uma dessas direções, sua imagem permanece na mesma reta que passa pela origem. A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço.

Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. A diagonalização pode, portanto, ser interpretada como uma mudança para um sistema de coordenadas em que a transformação atua separadamente sobre cada direção da base.

Para matrizes simétricas reais, essa simplificação possui propriedades adicionais: todos os autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permitirá interpretar formas quadráticas, matrizes positivas definidas, elipsoides, funções de matrizes e problemas de otimização. Essas estruturas serão retomadas nos capítulos de SVD, covariâncias e técnicas multivariadas.

Convenções de notação

Ao longo deste capítulo:

- λ representa um autovalor;

- $\mathbf{v}$ representa um autovetor;
- $\mathcal{E}_\lambda$ representa o autoespaço associado a λ ;
- $m_a(\lambda)$ e $m_g(\lambda)$ representam, respectivamente, as multiplicidades algébrica e geométrica;
- $\mathcal{B}_\mathbf{A}$ representa uma base de autovetores de $\mathbf{A}$, quando tal base existe;
- $\mathbf{B}_\mathbf{A}$ representa a matriz formada pelos vetores da base $\mathcal{B}_\mathbf{A}$;
- $\Lambda_\mathbf{A}$ representa a matriz diagonal dos autovalores correspondente à ordenação escolhida dos autovetores;
- $\mathbf{Q}_\mathbf{A}$ representa uma matriz ortogonal de autovetores quando $\mathbf{A}$ é simétrica;
- Π_λ representa o projetor espectral associado ao autoespaço de λ ;
- $\mathcal{R}_\mathbf{A}(\mathbf{x})$ representa o quociente de Rayleigh.

Salvo indicação contrária, as interpretações geométricas serão desenvolvidas em espaços vetoriais reais. Autovalores e autovetores complexos serão considerados explicitamente quando necessário.

5.1 Direções invariantes, autovalores e autoespaços

Definição 5.1 (Subespaço invariante). Considere

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p.$$

O subespaço $\mathcal{W}$ é **invariante sob $\mathbf{A}$** quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo

$$\mathbf{w} \in \mathcal{W}.$$

Isso significa que a multiplicação por $\mathbf{A}$ transforma vetores de $\mathcal{W}$ em vetores que permanecem no próprio subespaço $\mathcal{W}$.

Um caso particularmente importante ocorre quando o subespaço invariante possui dimensão 1.

Seja

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span}\{\mathbf{v}\} = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Como $\mathbf{v} \neq \mathbf{0}$, o conjunto $\{\mathbf{v}\}$ é uma base de $\mathcal{W}$ e, portanto,

$$\dim(\mathcal{W}) = 1.$$

Geometricamente, $\mathcal{W}$ corresponde a uma reta que passa pela origem e está contida em $\mathbb{R}^p$.

Se $\mathcal{W}$ é invariante sob $\mathbf{A}$, então

$$\mathbf{A}\mathbf{v} \in \mathcal{W}.$$

Como todos os vetores de $\mathcal{W}$ são múltiplos escalares de $\mathbf{v}$, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Assim, a ação de $\mathbf{A}$ sobre $\mathbf{v}$ mantém sua imagem na mesma reta gerada por $\mathbf{v}$. A magnitude pode ser alterada e, dependendo do sinal de λ , também pode ocorrer mudança de sentido.

Exemplo 5.1 (Uma reta invariante em $\mathbb{R}^2$). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

e o vetor

$$\mathbf{v} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\},$$

que corresponde à reta

$$x_2 = x_1$$

em $\mathbb{R}^2$.

Aplicando $\mathbf{A}$ ao vetor $\mathbf{v}$,

$$\begin{aligned} \mathbf{A}\mathbf{v} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= 3\mathbf{v}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v} \in \mathcal{W},$$

e a reta $\mathcal{W}$ é invariante sob $\mathbf{A}$. Nesse caso, a transformação multiplica os vetores dessa direção por um fator igual a 3, sem retirar suas imagens da reta.

A relação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

observada nesse caso conduz às definições de autovalor e autovetor.

Definição 5.2 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.2 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{Ax} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$. As retas tracejadas em cinza representam as duas direções invariantes.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

Um autovetor não é único. Se $\mathbf{v}$ é um autovetor associado ao autovalor λ , então qualquer múltiplo não nulo de $\mathbf{v}$ também é um autovetor associado ao mesmo autovalor.

Proposição 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

Comprovação. Como

$$\mathbf{Av} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned} \mathbf{A}(c\mathbf{v}) &= c\mathbf{Av} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}). \end{aligned}$$




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ . □

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.3 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Proposição 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

Comprovação. Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda\mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$. □

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição do autoespaço transforma a busca por autovetores em um problema de núcleo. Para um valor fixado de λ , existem autovetores associados precisamente quando

$$\mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p) \neq \{\mathbf{0}\}.$$

Resta, portanto, determinar quais valores de λ tornam esse núcleo não trivial. Essa condição equivale à singularidade de $\mathbf{A} - \lambda \mathbf{I}_p$ e conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo.

Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.1 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Comprovação. Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$. □

Definição 5.4 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn; Johnson, 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ($\theta = \frac{\pi}{2}$),

$$\mathbf{Q}_{\frac{\pi}{2}} = \begin{bmatrix} \cos\left(\frac{\pi}{2}\right) & -\sin\left(\frac{\pi}{2}\right) \\ \sin\left(\frac{\pi}{2}\right) & \cos\left(\frac{\pi}{2}\right) \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovalores reais e, conseqüentemente, não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando a mesma matriz é considerada como um operador em $\mathbb{C}^2$, ela possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente no contexto real. Em particular, toda matriz simétrica real possui autovalores reais e admite uma base ortonormal de autovetores reais.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.2 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

Comprovação. A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \dots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes. $\square$

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.5 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Exemplo 5.3 (Mesma multiplicidade algébrica e diferentes multiplicidades geométricas). Considere as matrizes

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Polinômio característico e multiplicidade algébrica

Para $\mathbf{A}_1$,

$$\begin{aligned} p_{\mathbf{A}_1}(\lambda) &= \det(\mathbf{A}_1 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Para $\mathbf{A}_2$,

$$\begin{aligned} p_{\mathbf{A}_2}(\lambda) &= \det(\mathbf{A}_2 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 1 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Portanto, as duas matrizes possuem o mesmo polinômio característico,

$$p(\lambda) = (2 - \lambda)^2,$$

e, conseqüentemente, o mesmo autovalor,

$$\lambda = 2.$$

Como o fator $(2 - \lambda)$ aparece duas vezes no polinômio característico, o autovalor $\lambda = 2$ possui multiplicidade algébrica

$$m_a(2) = 2$$

para ambas as matrizes.

Autoespaço de $\mathbf{A}_1$

Para determinar o autoespaço associado a $\lambda = 2$, procuramos todos os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$\mathbf{A}_1 \mathbf{v} = 2\mathbf{v}.$$

Essa equação pode ser escrita como

$$(\mathbf{A}_1 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando a matriz,

$$\begin{aligned}\mathbf{A}_1 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.\end{aligned}$$

Assim, o sistema a ser resolvido é

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

ou seja,

$$\begin{cases} 0 = 0, \\ 0 = 0. \end{cases}$$

O sistema não impõe nenhuma restrição sobre v_1 e v_2 . Portanto, ambos são livres e qualquer vetor de $\mathbb{R}^2$ pertence ao espaço nulo de $\mathbf{A}_1 - 2\mathbf{I}_2$.

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_1 - 2\mathbf{I}_2) = \mathbb{R}^2.$$

Como

$$\dim(\mathbb{R}^2) = 2,$$

temos

$$m_g(2) = \dim(E_2) = 2.$$

Assim, todo vetor não nulo de $\mathbb{R}^2$ é um autovetor de $\mathbf{A}_1$ associado ao autovalor $\lambda = 2$.

Autoespaço de $\mathbf{A}_2$

Para $\mathbf{A}_2$, procuramos novamente os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$(\mathbf{A}_2 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando,

$$\begin{aligned} \mathbf{A}_2 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Efetuando a multiplicação,

$$\begin{bmatrix} v_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

o que corresponde ao sistema

$$\begin{cases} v_2 = 0, \\ 0 = 0. \end{cases}$$

Nesse caso, v_2 deve ser igual a zero, enquanto v_1 permanece livre. Assim, todo vetor do autoespaço possui a forma

$$\mathbf{v} = \begin{bmatrix} v_1 \\ 0 \end{bmatrix} = v_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_2 - 2\mathbf{I}_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}.$$

Esse autoespaço possui uma única direção linearmente independente. Portanto,

$$m_g(2) = \dim(E_2) = 1.$$

As duas matrizes possuem, portanto, o mesmo autovalor $\lambda = 2$ e a mesma multiplicidade algébrica,

$$m_a(2) = 2,$$

mas apresentam multiplicidades geométricas diferentes:

$$m_g(2) = \begin{cases} 2, & \text{para } \mathbf{A}_1, \\ 1, & \text{para } \mathbf{A}_2. \end{cases}$$

A diferença decorre da dimensão dos respectivos autoespaços. Para $\mathbf{A}_1$, o autoespaço é todo o plano $\mathbb{R}^2$; para $\mathbf{A}_2$, o autoespaço é apenas a reta gerada por $(1, 0)^\top$.

A Figura 5.2 compara as estruturas dos dois autoespaços.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

No capítulo anterior, vimos que a matriz de um operador depende da base utilizada para representá-lo. A diagonalização corresponde à escolha de uma base particularmente conveniente: uma base formada por autovetores.

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e suponha que exista uma base de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

A matriz dessa base é

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Como os vetores da base são linearmente independentes, $\mathbf{B}_{\mathbf{A}}$ é invertível.

Se

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad j = 1, \dots, p,$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

então

$$\mathbf{A}\mathbf{B}_{\mathbf{A}} = \mathbf{B}_{\mathbf{A}}\Lambda_{\mathbf{A}}.$$

Multiplicando à esquerda por $\mathbf{B}_{\mathbf{A}}^{-1}$,

$$\mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Definição 5.6 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existe uma base $\mathcal{B}_{\mathbf{A}}$ de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Equivalentemente, existem uma matriz invertível $\mathbf{B}_{\mathbf{A}}$ e uma matriz diagonal $\Lambda_{\mathbf{A}}$ tais que

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A ordem das colunas de $\mathbf{B}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Pela notação de mudança de base desenvolvida no capítulo anterior,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Assim, $\Lambda_{\mathbf{A}}$ é a matriz do mesmo operador quando tanto o domínio quanto o contradomínio são representados na base de autovetores.

Para qualquer vetor $\mathbf{x} \in \mathbb{R}^p$, suas coordenadas nessa base são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{x},$$

de modo que

$$\mathbf{x} = \mathbf{B}_{\mathbf{A}} \mathbf{z}.$$

Nas coordenadas da base de autovetores,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}} [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Como

$$\Lambda_{\mathbf{A}} \mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix},$$

a transformação atua separadamente sobre cada coordenada: a componente correspondente ao autovetor $\mathbf{v}_j$ é multiplicada por λ_j .

A diagonalização é, portanto, uma mudança para um sistema de coordenadas no qual as direções da base são invariantes e a ação do operador deixa de misturar coordenadas.

Teorema 5.3 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;
2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;
3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;
4. a soma das dimensões dos autoespaços é igual a p ;
5. para cada autovalor λ ,

$$m_g(\lambda) = m_a(\lambda).$$

(Horn; Johnson, 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.2 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \\ &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{B}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{B}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Assim, a aplicação repetida do operador pode ser analisada coordenada a coordenada na base de autovetores: após k aplicações, a coordenada associada a $\mathbf{v}_j$ é multiplicada por λ_j^k .

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.4 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

- 1. todos os autovalores de $\mathbf{A}$ são reais;*
- 2. autoespaços associados a autovalores distintos são ortogonais;*
- 3. existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_\mathbf{A} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

(Horn; Johnson, 2013)

Comprovação. Para demonstrar que os autovalores são reais, considere um autovalor possivelmente complexo λ e um autovetor complexo não nulo $\mathbf{z}$, de modo que

$$\mathbf{A}\mathbf{z} = \lambda\mathbf{z}.$$

Como $\mathbf{A}$ é real e simétrica, ela também é hermitiana:

$$\mathbf{A}^* = \mathbf{A},$$

em que $*$ representa a transposta conjugada.

Multiplicando a equação de autovalor à esquerda por $\mathbf{z}^*$,

$$\mathbf{z}^* \mathbf{A} \mathbf{z} = \lambda \mathbf{z}^* \mathbf{z}.$$

A quantidade

$$\mathbf{z}^* \mathbf{A} \mathbf{z}$$

é real, pois

$$(\mathbf{z}^* \mathbf{A} \mathbf{z})^* = \mathbf{z}^* \mathbf{A}^* \mathbf{z} = \mathbf{z}^* \mathbf{A} \mathbf{z}.$$

Além disso,

$$\mathbf{z}^* \mathbf{z} > 0.$$

Portanto,

$$\lambda = \frac{\mathbf{z}^* \mathbf{A} \mathbf{z}}{\mathbf{z}^* \mathbf{z}}$$

é real.

Considere agora dois autovetores reais $\mathbf{v}_i$ e $\mathbf{v}_j$, associados a autovalores distintos λ_i e λ_j . Como

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j\mathbf{v}_j,$$

tem-se

$$\begin{aligned}\lambda_i\mathbf{v}_i^\top\mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}\mathbf{v}_j \\ &= \lambda_j\mathbf{v}_i^\top\mathbf{v}_j.\end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j)\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Portanto, os autoespaços associados a autovalores distintos são ortogonais.

A existência de uma base ortonormal de autovetores pode ser demonstrada por indução sobre a ordem p da matriz. Para $p = 1$, o resultado é imediato.

Suponha agora $p > 1$. Pelo Teorema Fundamental da Álgebra, o polinômio característico de $\mathbf{A}$ possui pelo menos uma raiz em $\mathbb{C}$. Pela primeira parte da demonstração, essa raiz é real. Denote-a por λ_1 .

Como

$$\det(\mathbf{A} - \lambda_1\mathbf{I}_p) = 0,$$

a matriz real

$$\mathbf{A} - \lambda_1\mathbf{I}_p$$

é singular e possui um vetor não nulo real em seu núcleo. Normalizando esse vetor, obtém-se um autovetor unitário $\mathbf{q}_1$.

Considere o complemento ortogonal

$$\mathcal{W} = \text{span} \{ \mathbf{q}_1 \}^\perp.$$

Para qualquer $\mathbf{x} \in \mathcal{W}$,

$$\mathbf{q}_1^\top \mathbf{x} = 0.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \mathbf{q}_1^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{q}_1)^\top \mathbf{x} \\ &= \lambda_1 \mathbf{q}_1^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{x} \in \mathcal{W},$$

e $\mathcal{W}$ é invariante sob $\mathbf{A}$.

A restrição de $\mathbf{A}$ a $\mathcal{W}$ permanece simétrica. Como

$$\dim(\mathcal{W}) = p - 1,$$

a hipótese de indução garante uma base ortonormal

$$\mathbf{q}_2, \dots, \mathbf{q}_p$$

de $\mathcal{W}$ formada por autovetores da restrição e, consequentemente, de $\mathbf{A}$.

Assim,

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$ composta por autovetores de $\mathbf{A}$.

Organizando esses vetores nas colunas de

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

tem-se

$$\mathbf{Q}_A^\top \mathbf{Q}_A = \mathbf{I}_p.$$

Portanto,

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Definindo

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a relação

$$\mathbf{A} \mathbf{Q}_A = \mathbf{Q}_A \Lambda_A$$

fornece

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

□

A representação

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela é uma diagonalização ortogonal.

Considere a base ortonormal de autovetores

$$\mathcal{B}_A = \{\mathbf{q}_1, \dots, \mathbf{q}_p\}.$$

A matriz dessa base é

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p].$$

Assim, no caso simétrico, a matriz da base de autovetores introduzida na seção anterior pode ser escolhida ortogonal:

$$\mathbf{B}_A = \mathbf{Q}_A,$$

com

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Pela notação de coordenadas desenvolvida no capítulo anterior,

$$[\mathbf{x}]_{\mathcal{B}_A} = \mathbf{Q}_A^\top \mathbf{x}.$$

Denotando

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_A},$$

tem-se

$$\mathbf{x} = \mathbf{Q}_A \mathbf{z}.$$

A matriz do operador nessa base é

$$[T_A]_{\mathcal{B}_A \leftarrow \mathcal{B}_A} = \mathbf{Q}_A^\top \mathbf{A} \mathbf{Q}_A = \Lambda_A.$$

Consequentemente,

$$[T_A(\mathbf{x})]_{\mathcal{B}_A} = \Lambda_A [\mathbf{x}]_{\mathcal{B}_A}.$$

Em coordenadas canônicas,

$$\begin{aligned} \mathbf{A} \mathbf{x} &= \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top \mathbf{x} \\ &= \mathbf{Q}_A \Lambda_A \mathbf{z}. \end{aligned}$$

A ação da matriz pode ser interpretada em três etapas:

1. $\mathbf{Q}_A^\top$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. Λ_A multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_A$ reconstrói o vetor nas coordenadas canônicas.

Assim, uma matriz simétrica atua por fatores escalares independentes em direções ortogonais. Quando algum autovalor é negativo, o escalonamento na direção correspondente inclui também a inversão do sentido.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.4 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \mathbf{q}_2\}$$

é uma base ortonormal de autovetores de $\mathbb{R}^2$.

A matriz dessa base é a matriz ortogonal

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a circunferência unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária em $\mathbb{R}^p$ são determinados por

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por fatores escalares independentes.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{Ax} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Proposição 5.3 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn; Johnson, 2013)

Comprovação. As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Proposição 3.16, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned} \Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h \mathbf{Q}_h^\top \mathbf{Q}_\ell \mathbf{Q}_\ell^\top \\ &= \mathbf{0}. \end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

□

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_{\lambda} = \mathbf{q}\mathbf{q}^{\top}.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_{\mathbf{A}}$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Proposição 5.4 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

Comprovação. Pela propriedade cíclica do traço,

$$\begin{aligned} \text{tr}(\mathbf{A}) &= \text{tr}(\mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \text{tr}(\Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}}) \\ &= \text{tr}(\Lambda_{\mathbf{A}}) \\ &= \sum_{j=1}^p \lambda_j. \end{aligned}$$

Para o determinante,

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{Q}_{\mathbf{A}}) \det(\Lambda_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \det(\Lambda_{\mathbf{A}}), \end{aligned}$$

pois

$$\det(\mathbf{Q}_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_{\mathbf{A}}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ são semelhantes, pois

$$\Lambda_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{A} \mathbf{Q}_{\mathbf{A}}.$$

Como a multiplicação à esquerda e à direita por matrizes invertíveis preserva o posto, $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned} \dim \mathcal{N}(\mathbf{A}) &= p - \text{posto}(\mathbf{A}) \\ &= \# \{j : \lambda_j = 0\}. \end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos. □

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Proposição 5.5 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}$$

é a decomposição espectral de uma matriz simétrica, então

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^{\perp},$$

ou, equivalentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

Comprovação. Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores associados a autovalores nulos são ortogonais aos autovetores associados a autovalores não nulos, e juntos formam uma base ortonormal de $\mathbb{R}^p$, os dois subespaços são complementos ortogonais. $\square$

O autoespaço associado ao autovalor zero reúne exatamente as direções eliminadas pela transformação. Os autoespaços associados a autovalores não nulos constituem, em conjunto, a imagem da transformação.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.23, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são determinadas pelos sinais dos autovalores, enquanto o valor assumido para um vetor específico depende também de suas coordenadas espectrais $z_1, \dots, z_p$.

Exemplo 5.5 (Forma quadrática em coordenadas espectrais). Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 3 \quad \text{e} \quad \lambda_2 = 1,$$

com autovetores ortonormais associados

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{Q}_\mathbf{A} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda_\mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral de $\mathbf{A}$ é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Considere agora o vetor

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Nas coordenadas originais, a forma quadrática é

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} \\ &= 14. \end{aligned}$$

Equivalentemente, escrevendo a forma quadrática em função das coordenadas originais,

$$q_{\mathbf{A}}(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 2x_2^2.$$

Observe a presença do produto cruzado $2x_1x_2$.

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{Q}_{\mathbf{A}}^\top = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{z} &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$z_1 = \frac{3}{\sqrt{2}} \quad \text{e} \quad z_2 = \frac{1}{\sqrt{2}}.$$

Nas coordenadas espectrais, a mesma forma quadrática é

$$\begin{aligned}
q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\
&= \lambda_1 z_1^2 + \lambda_2 z_2^2 \\
&= 3 \left(\frac{3}{\sqrt{2}} \right)^2 + 1 \left(\frac{1}{\sqrt{2}} \right)^2 \\
&= 3 \left(\frac{9}{2} \right) + \frac{1}{2} \\
&= 14.
\end{aligned}$$

Assim, nas coordenadas espectrais,

$$q_{\mathbf{A}}(\mathbf{x}) = 3z_1^2 + z_2^2,$$

sem produtos cruzados. A mudança de coordenadas não altera o valor da forma quadrática; ela apenas a expressa em uma base na qual a matriz é diagonal.

Proposição 5.6 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn; Johnson, 2013)

Comprovação. Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos. $\square$

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{(c/\lambda_j)} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.6 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^\top \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^\top \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

O termo cruzado $2x_1x_2$ presente nas coordenadas canônicas desaparece nas coordenadas espectrais porque os eixos coordenados passam a coincidir com as direções principais da forma quadrática.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh

Definição 5.7 (Quociente de Rayleigh). Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$. O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma euclidiana de $\mathbf{a}$.

Quando $\mathbf{A}$ é definida positiva, a forma quadrática também pode ser escrita como

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{A}},$$

em que $\langle \cdot, \cdot \rangle_{\mathbf{A}}$ é o produto interno induzido por $\mathbf{A}$, definido em Definição 3.16.

A divisão por $\|\mathbf{a}\|^2$ remove o efeito da magnitude do vetor. Consequentemente, o quociente de Rayleigh depende da direção determinada por $\mathbf{a}$, e não de seu comprimento.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}). \end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

As coordenadas de $\mathbf{a}$ na base espectral são

$$\mathbf{z} = [\mathbf{a}]_{\mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{a},$$

de modo que

$$\mathbf{a} = \mathbf{Q}_\mathbf{A} \mathbf{z}.$$

Como $\mathbf{Q}_\mathbf{A}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \mathbf{\Lambda}_\mathbf{A} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

Portanto,

$$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é, portanto, uma média ponderada dos autovalores. Para uma base espectral fixada, ω_j mede a proporção do comprimento ao quadrado de $\mathbf{a}$ associada à direção $\mathbf{q}_j$.

Quando um autovalor λ possui multiplicidade maior que 1, a quantidade intrínseca ao autoespaço correspondente é a soma dos pesos associados aos vetores de uma base ortonormal desse autoespaço. Essa soma é igual à proporção do comprimento ao quadrado da projeção de $\mathbf{a}$ sobre $\mathcal{E}_\lambda$.

Teorema 5.5 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço associado a λ_p . (Horn; Johnson, 2013)

Comprovação. Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido. □

Se o maior autovalor é simples, a reta que maximiza o quociente é

$$\text{span}\{\mathbf{q}_1\}.$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

Exemplo 5.7 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da circunferência unitária.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.

5.5.2 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição de norma separa a escolha da **direção** da escolha da magnitude do vetor. De fato,

$$(c\mathbf{a})^{\top} \mathbf{A} (c\mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}.$$

Portanto, sem uma normalização, o valor da forma quadrática pode ser alterado simplesmente pelo escalonamento do vetor, mesmo quando sua direção permanece a mesma.

Se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

o problema de maximização sem restrição é ilimitado superiormente. Analogamente, se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} < 0,$$

o problema de minimização sem restrição é ilimitado inferiormente.

A condição

$$\mathbf{a}^{\top} \mathbf{a} = 1$$

elimina esse efeito de escala e restringe a otimização às direções representadas por vetores unitários.

5.5.3 Multiplicadores de Lagrange

Em diferentes problemas da Estatística Multivariada, procura-se uma **direção** no espaço das variáveis que torne máxima ou mínima alguma quantidade de interesse. Essa quantidade pode representar, por exemplo, variabilidade, separação entre grupos ou associação entre conjuntos de variáveis.

Uma direção pode ser representada por um vetor $\mathbf{a}$. Entretanto, os vetores $\mathbf{a}$ e $c\mathbf{a}$, para $c \neq 0$, representam a mesma direção, embora tenham comprimentos diferentes. Por isso, quando o interesse está apenas na direção, é conveniente impor a normalização

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Essa restrição faz com que a busca seja realizada sobre o conjunto dos vetores unitários. Geometricamente, em $\mathbb{R}^p$, esses vetores formam a esfera unitária.

Considere agora a forma quadrática

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica. O problema consiste em investigar como o valor de $f(\mathbf{a})$ varia quando a direção $\mathbf{a}$ percorre a esfera unitária.

5.5.3.1 O que é um ponto estacionário sob uma restrição?

Em um problema sem restrições, um ponto estacionário de uma função diferenciável é um ponto no qual seu gradiente é nulo. Em um problema com restrição, essa condição precisa ser modificada, pois nem todas as direções de deslocamento são permitidas.

Neste caso, $\mathbf{a}$ deve permanecer sobre a esfera

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um ponto é estacionário para o problema restrito quando pequenas alterações de $\mathbf{a}$ que respeitam essa restrição não produzem, em primeira ordem, aumento ou redução da função objetivo.

Geometricamente, isso ocorre quando o gradiente da função objetivo não possui componente na direção tangente à superfície da restrição. De forma equivalente, o gradiente da função objetivo deve ser proporcional ao gradiente da função que define a restrição.

Essa condição é obtida pelo método dos multiplicadores de Lagrange.

Considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem para um ponto estacionário é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A} \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que as direções estacionárias do problema são precisamente direções de autovetores de $\mathbf{A}$. O multiplicador de Lagrange η é o autovalor associado à direção encontrada.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \eta \mathbf{a}^\top \mathbf{a} \\ &= \eta,\end{aligned}$$

pois $\mathbf{a}^\top \mathbf{a} = 1$.

Assim, quando $\mathbf{a}$ é um autovetor unitário associado ao autovalor λ ,

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Portanto, há uma correspondência direta:

direção estacionária $\leftrightarrow$ autovetor

e

valor da forma quadrática nessa direção $\leftrightarrow$ autovalor.

Como $\mathbf{A}$ é simétrica, seus autovalores são reais. Além disso, pelos resultados do quociente de Rayleigh, para todo vetor unitário $\mathbf{a}$,

$$\lambda_{\min} \leq \mathbf{a}^\top \mathbf{A} \mathbf{a} \leq \lambda_{\max}.$$

Os extremos são atingidos nos autoespaços associados ao menor e ao maior autovalor. Consequentemente,

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\max},$$

e

$$\min_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\min}.$$

Assim:

- o maior autovalor fornece o máximo global da forma quadrática sobre a esfera unitária;
- o menor autovalor fornece o mínimo global;

- os demais autovalores correspondem a valores estacionários intermediários;
- os autovetores associados fornecem as respectivas direções.

Teorema 5.6 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e considere*

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}$$

restrita aos vetores que satisfazem

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um vetor unitário $\mathbf{a}$ é um ponto estacionário de f sobre a esfera unitária se, e somente se, $\mathbf{a}$ é um autovetor de $\mathbf{A}$.

Se

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a},$$

então

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Em particular, o maior autovalor corresponde ao máximo global da função sobre a esfera unitária, e o menor autovalor corresponde ao mínimo global.

Este resultado permite compreender por que autovalores e autovetores surgem repetidamente em técnicas multivariadas. Em muitos casos, a técnica procura uma direção $\mathbf{a}$ que torne máxima uma quantidade expressa por uma forma quadrática.

Na Análise de Componentes Principais, por exemplo, para um vetor aleatório $\mathbf{X}$ com matriz de covariâncias Σ , a variância da combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

é

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A primeira componente principal procura a direção unitária que maximiza essa variância:

$$\max_{\mathbf{a}^\top \mathbf{a} = 1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo resultado anterior, a solução é um autovetor associado ao maior autovalor de Σ . Portanto,

maior autovalor $\longrightarrow$ maior variância possível

e

autovetor correspondente $\longrightarrow$ direção de maior variabilidade.

As componentes seguintes são obtidas acrescentando restrições de ortogonalidade às direções já encontradas. Isso conduz sucessivamente aos demais autovetores e autovalores.

A mesma estrutura reaparece, com modificações, em outros problemas multivariados. Na análise discriminante, procura-se uma direção que produza grande separação entre grupos em relação à variabilidade dentro dos grupos. Na MANOVA, determinadas direções maximizam a variação associada à hipótese em relação à variação residual. Na correlação canônica, procuram-se combinações lineares de dois conjuntos de variáveis que apresentem associação máxima.

Nesses casos, a função a ser otimizada envolve frequentemente uma razão entre duas formas quadráticas,

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{B} \mathbf{a}},$$

e a condição de estacionariedade conduz ao problema de autovalores generalizados

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{B} \mathbf{a}.$$

Assim, autovalores e autovetores aparecem nessas técnicas porque representam soluções de problemas de otimização sobre direções: os autovetores fornecem as direções de interesse e os autovalores quantificam o valor atingido pelo critério nessas direções.

5.5.4 Direções sucessivas

O problema de otimização anterior identifica uma direção associada ao maior autovalor de $\mathbf{A}$. Em muitas aplicações, entretanto, interessa obter não apenas uma direção ótima, mas uma sequência de direções que representem aspectos distintos da estrutura da matriz.

Depois de encontrar a primeira direção, pode-se procurar uma segunda direção que maximize a mesma forma quadrática, mas que seja ortogonal à primeira. O procedimento pode ser repetido sucessivamente, impondo que cada nova direção seja ortogonal às anteriormente obtidas.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição

$$\mathbf{a}^\top \mathbf{q}_1 = 0$$

impede que $\mathbf{a}$ possua componente na direção de $\mathbf{q}_1$. Assim, se $\mathbf{a}$ for escrito na base espectral,

$$\mathbf{a} = z_1 \mathbf{q}_1 + z_2 \mathbf{q}_2 + \dots + z_p \mathbf{q}_p,$$

a condição de ortogonalidade implica

$$z_1 = 0.$$

Portanto, a otimização passa a ocorrer apenas no subespaço gerado por

$$\mathbf{q}_2, \dots, \mathbf{q}_p.$$

Nesse subespaço, o maior autovalor disponível é λ_2 . Assim, o maior valor da forma quadrática é λ_2 , atingido na direção de $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.7 (Caracterização variacional de direções sucessivas). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

e seja

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação. Então, para $k = 1, \dots, p$,

$$\lambda_k = \max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por $\mathbf{q}_k$ e, quando λ_k possui multiplicidade maior que 1, por qualquer autovetor unitário associado a λ_k que satisfaça as restrições de ortogonalidade. (Horn; Johnson, 2013)

Comprovação. Como

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$, qualquer vetor $\mathbf{a}$ pode ser escrito como

$$\mathbf{a} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{a}.$$

As restrições

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1,$$

implicam

$$z_1 = \dots = z_{k-1} = 0.$$

Portanto,

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como os autovetores são ortonormais e $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Nas coordenadas espectrais,

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \sum_{j=k}^p \lambda_j z_j^2.$$

Como os autovalores estão ordenados de forma decrescente,

$$\lambda_j \leq \lambda_k, \quad j \geq k.$$

Logo,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \sum_{j=k}^p \lambda_j z_j^2 \\ &\leq \lambda_k \sum_{j=k}^p z_j^2 \\ &= \lambda_k.\end{aligned}$$

O limite é atingido tomando

$$\mathbf{a} = \mathbf{q}_k,$$

pois $\mathbf{q}_k$ possui norma unitária, é ortogonal a $\mathbf{q}_1, \dots, \mathbf{q}_{k-1}$ e satisfaz

$$\mathbf{A} \mathbf{q}_k = \lambda_k \mathbf{q}_k.$$

Assim,

$$\mathbf{q}_k^\top \mathbf{A} \mathbf{q}_k = \lambda_k.$$

Portanto,

$$\max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j=0, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_k.$$

□

Quando há autovalores repetidos, as direções individuais dentro do autoespaço correspondente não são unicamente determinadas. Diferentes bases ortonormais desse autoespaço produzem o mesmo valor da função objetivo e representam o mesmo subespaço espectral. Assim, o subespaço associado ao autovalor repetido é bem determinado, embora a escolha particular dos autovetores que formam uma base desse subespaço não seja única.

A caracterização variacional relaciona, portanto, três objetos fundamentais:

forma quadrática $\longleftrightarrow$ problema de otimização $\longleftrightarrow$ estrutura espectral.

Além de identificar os valores extremos, essa caracterização permite obter sucessivamente as direções ortogonais associadas aos autovalores ordenados da matriz.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar real definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.8 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função real definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Proposição 5.7 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn; Johnson, 1991)

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_{\lambda}$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

□

Portanto, todo autovetor de $\mathbf{A}$ associado a λ também é autovetor de $f(\mathbf{A})$, agora associado ao autovalor $f(\lambda)$. Mais geralmente, todo o autoespaço $\mathcal{E}_{\lambda}$ de $\mathbf{A}$ permanece invariante sob $f(\mathbf{A})$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^k \mathbf{Q}_{\mathbf{A}}^{\top},$$

com

$$\Lambda_{\mathbf{A}}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_{\mathbf{A}}$ fornece

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Exemplo 5.8 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.9 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a raiz quadrada principal de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{A} \succ 0$, a raiz quadrada principal é invertível e

$$\mathbf{A}^{-1/2} = (\mathbf{A}^{1/2})^{-1}.$$

Além disso,

$$\mathbf{A}^{-1} = \mathbf{A}^{-1/2} \mathbf{A}^{-1/2}$$

e

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned}\mathbf{A}^{-1/2}\mathbf{A}\mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\Lambda_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A}\mathbf{I}_p\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p.\end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2}\mathbf{x}$$

reescala as componentes espectrais de $\mathbf{x}$ segundo os fatores $1/\sqrt{\lambda_j}$. Além disso, converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned}\mathbf{x}^\top \mathbf{A}^{-1}\mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2}\mathbf{A}^{-1/2}\mathbf{x} \\ &= \mathbf{z}^\top \mathbf{z} \\ &= \|\mathbf{z}\|^2.\end{aligned}$$

Quando $\mathbf{A}$ for uma matriz de covariâncias $\Sigma \succ 0$, essa construção será retomada no branqueamento. Para um vetor com média μ , a transformação correspondente será aplicada ao vetor centralizado,

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu).$$

Nesse caso, a distância de Mahalanobis será interpretada como uma distância euclidiana nas coordenadas branqueadas.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.10 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A pseudoinversa de Moore–Penrose de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^+ \mathbf{Q}_{\mathbf{A}}^\top,$$

em que

$$\Lambda_{\mathbf{A}}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa atua separadamente sobre os autoespaços: nas direções associadas a autovalores não nulos, aplica o fator $1/\lambda$; no autoespaço associado ao autovalor zero, sua ação é nula. Assim, ela inverte a transformação sobre sua imagem e mantém eliminadas as componentes pertencentes ao núcleo.

Exemplo 5.9 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned}\mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz simétrica positiva definida, define-se o **logaritmo principal** por

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^\top.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição adicional
$\mathbf{A}^k$	λ_j^k	$k \in \{0, 1, 2, \dots\}$
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	nenhuma além da simetria assumida na seção
$\exp(\mathbf{A})$	e^{λ_j}	nenhuma além da simetria assumida na seção
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais atuam separadamente sobre os autoespaços, transformando cada autovalor λ no valor escalar $f(\lambda)$. Essa construção permite obter diretamente potências, inversas, raízes e pseudoinversas e mostra como certas transformações matriciais podem ser compreendidas como reescalonamentos das direções espectrais.

Em particular, a raiz quadrada e a raiz quadrada inversa permitem converter problemas definidos por uma geometria induzida por uma matriz positiva definida em problemas euclidianos equivalentes. Essa ideia será utilizada imediatamente na formulação dos autovalores generalizados.

5.7 Aprofundamento: autovalores generalizados

Leitura de aprofundamento

Esta seção apresenta uma extensão do problema ordinário de autovalores para situações em que duas formas quadráticas são consideradas simultaneamente. Embora esse desenvolvimento não seja necessário para acompanhar os resultados centrais da decompo-

sição espectral, ele fornece uma base matemática importante para técnicas multivariadas que envolvem a comparação entre diferentes estruturas de variabilidade, separação ou associação.

Ao longo da seção, serão apresentados os autovalores generalizados, o quociente de Rayleigh generalizado, a ortogonalidade em uma métrica definida por uma matriz positiva definida e a redução do problema generalizado a um problema espectral ordinário.

Alguns problemas de Estatística Multivariada envolvem a comparação entre duas formas quadráticas, em vez da otimização de uma única forma quadrática relativamente à norma euclidiana. Nesses casos, surge naturalmente o problema de autovalores generalizados,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

em que $\mathbf{A}$ é simétrica e $\mathbf{M}$ é simétrica positiva definida.

Essa estrutura generaliza o problema ordinário de autovalores, recuperado quando

$$\mathbf{M} = \mathbf{I}_p.$$

Os autovalores generalizados serão úteis posteriormente em problemas que envolvem a comparação entre diferentes medidas de variabilidade, separação ou associação. A leitura a seguir desenvolve a formulação matemática desse problema e sua relação com o quociente de Rayleigh e a decomposição espectral.

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.16, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.11 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda \mathbf{M}) \mathbf{v} = \mathbf{0}.$$

Existem soluções não triviais se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Essa equação é a equação característica generalizada do par $(\mathbf{A}, \mathbf{M})$ e determina seus autovalores generalizados.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.12 (Quociente de Rayleigh generalizado). Sejam $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica e $\mathbf{M} \in \mathbb{R}^{p \times p}$ simétrica positiva definida. Para $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$, o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|_{\mathbf{M}}^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma induzida por $\mathbf{M}$,

$$\|\mathbf{a}\|_{\mathbf{M}}^2 = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{M}} = \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Como $\mathbf{M} \succ \mathbf{0}$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o denominador é sempre positivo e o quociente está definido para todo vetor não nulo.

No quociente de Rayleigh ordinário, a normalização é realizada pela norma euclidiana,

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

No caso generalizado, essa normalização é substituída pela norma induzida por $\mathbf{M}$. Assim, o comprimento do vetor passa a ser medido segundo a geometria determinada por essa matriz.

Assim como no caso ordinário, o quociente é invariante à escala. Para qualquer escalar $c \neq 0$,

$$\begin{aligned}
\mathcal{R}_{\mathbf{A},\mathbf{M}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top \mathbf{M}(c\mathbf{a})} \\
&= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{M} \mathbf{a}} \\
&= \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}).
\end{aligned}$$

Portanto, o valor do quociente depende da direção determinada por $\mathbf{a}$, e não de sua magnitude segundo a norma induzida por $\mathbf{M}$.

Essa invariância permite escolher, em cada direção, um representante com norma unitária na geometria determinada por $\mathbf{M}$. Consequentemente, o problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição equivale a

$$\|\mathbf{a}\|_{\mathbf{M}} = 1$$

e, portanto, fixa o comprimento de $\mathbf{a}$ segundo a geometria induzida por $\mathbf{M}$.

Para determinar os pontos estacionários desse problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{M} \mathbf{a}) = 2\mathbf{M} \mathbf{a}.$$

Assim,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A} \mathbf{a} - 2\eta \mathbf{M} \mathbf{a}.$$

A condição de primeira ordem

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0}$$

produz

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que todo ponto estacionário $\mathbf{a}$ é um autovetor generalizado do par $(\mathbf{A}, \mathbf{M})$ e que o multiplicador η é o autovalor generalizado correspondente.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Sob a normalização

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1,$$

segue que

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta.$$

Além disso,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \eta.$$

Portanto, em um autovetor generalizado normalizado, o valor do quociente de Rayleigh generalizado coincide com o autovalor generalizado correspondente.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, a matriz $\mathbf{M}$ é invertível, e a equação generalizada também poderia ser escrita como

$$\mathbf{M}^{-1} \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Entretanto, mesmo que $\mathbf{A}$ e $\mathbf{M}$ sejam simétricas, a matriz $\mathbf{M}^{-1} \mathbf{A}$ não precisa ser simétrica. Para preservar a estrutura simétrica e poder aplicar diretamente o Teorema Espectral, é preferível transformar o problema utilizando a raiz quadrada de $\mathbf{M}$.

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2} \mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} = \lambda \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\widetilde{\mathbf{A}}^\top = \widetilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido no problema espectral ordinário

$$\widetilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u},$$

para uma matriz simétrica. Consequentemente, todos os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$ são reais e os resultados do Teorema Espectral podem ser aplicados à matriz $\widetilde{\mathbf{A}}$.

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \widetilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{a}$$

transforma a geometria induzida por $\mathbf{M}$ em geometria euclidiana, pois

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{u}^\top \mathbf{u}.$$

Equivalentemente,

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Geometricamente, $\mathbf{M}^{-1/2}$ transforma a esfera unitária euclidiana no elipsoide

$$\{\mathbf{a} \in \mathbb{R}^p : \mathbf{a}^\top \mathbf{M} \mathbf{a} = 1\}.$$

O problema generalizado pode, portanto, ser estudado como um problema de Rayleigh ordinário no sistema de coordenadas em que a métrica definida por $\mathbf{M}$ se torna euclidiana.

Quando $\mathbf{M}$ representar posteriormente uma matriz de covariâncias, essa mesma estrutura estará relacionada ao branqueamento. Aqui, porém, $\mathbf{M}$ representa genericamente a matriz que define a geometria do problema.

Teorema 5.8 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_p .

Comprovação. A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.5 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados. $\square$

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Proposição 5.8 (Ortogonalidade e base de autovetores generalizados). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$.*

Se $\mathbf{v}_i$ e $\mathbf{v}_j$ são autovetores generalizados associados a autovalores distintos λ_i e λ_j , então

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Além disso, existe uma base de $\mathbb{R}^p$ formada por autovetores generalizados

$$\mathcal{B}_g = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

que pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \delta_{ij}.$$

(Horn; Johnson, 2013)

Comprovação. Para autovalores distintos,

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{M} \mathbf{v}_i$$

e

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{M} \mathbf{v}_j.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \lambda_i \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= (\mathbf{A} \mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j. \end{aligned}$$

Portanto,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Para mostrar a existência de uma base completa, considere

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Como $\widetilde{\mathbf{A}}$ é simétrica, o Teorema Espectral garante uma base ortonormal de autovetores

$$\{\mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

Defina

$$\mathbf{v}_j = \mathbf{M}^{-1/2} \mathbf{u}_j.$$

Esses vetores são autovetores generalizados e

$$\begin{aligned} \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= \mathbf{u}_i^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}_j \\ &= \mathbf{u}_i^\top \mathbf{u}_j \\ &= \delta_{ij}. \end{aligned}$$

Assim, mesmo quando há autovalores generalizados repetidos, pode-se escolher uma base ortonormal segundo o produto interno induzido por $\mathbf{M}$. $\square$

5.7.4 Diagonalização simultânea por congruência

Considere a decomposição espectral

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \Lambda_g \mathbf{Q}_g^\top,$$

em que

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{B}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

Como $\mathbf{M}^{-1/2}$ é invertível e $\mathbf{Q}_g$ é ortogonal, $\mathbf{B}_g$ é invertível. Suas colunas formam uma base $\mathbf{M}$ -ortonormal de autovetores generalizados.

De fato,

$$\begin{aligned} \mathbf{A} \mathbf{B}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \Lambda_g \\ &= \mathbf{M} \mathbf{B}_g \Lambda_g. \end{aligned}$$

Além disso,

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p,\end{aligned}$$

e

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \Lambda_g.\end{aligned}$$

Portanto,

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

O par $(\mathbf{A}, \mathbf{M})$ é, assim, reduzido simultaneamente por uma transformação de congruência:

$$(\mathbf{A}, \mathbf{M}) \longrightarrow (\Lambda_g, \mathbf{I}_p).$$

Essa operação deve ser distinguida da semelhança

$$\mathbf{B}^{-1} \mathbf{A} \mathbf{B},$$

utilizada para representar um único operador em outra base. Na congruência, as matrizes aparecem multiplicadas pela transposta da matriz de base à esquerda e pela própria matriz à direita.

Como

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p,$$

segue que

$$\mathbf{B}_g^{-1} = \mathbf{B}_g^\top \mathbf{M}.$$

Assim, se

$$\mathbf{a} = \mathbf{B}_g \mathbf{z},$$

então as coordenadas de $\mathbf{a}$ nessa base são

$$\mathbf{z} = \mathbf{B}_g^{-1} \mathbf{a} = \mathbf{B}_g^\top \mathbf{M} \mathbf{a}.$$

Nessas coordenadas,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, portanto, a mesma forma do quociente de Rayleigh ordinário quando expresso na base $\mathbf{M}$ -ortonormal de autovetores generalizados.

Exemplo 5.10 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{b}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{b}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas da matriz da base

$$\mathbf{B}_g = [\mathbf{b}_{g,1} \quad \mathbf{b}_{g,2}],$$

obtêm-se

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_2$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Este capítulo desenvolveu a estrutura espectral das transformações lineares quadradas. O ponto de partida foi a identificação de direções invariantes, isto é, direções nas quais a ação de uma matriz reduz-se à multiplicação por um escalar.

Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

com $\mathbf{v} \neq \mathbf{0}$, o escalar λ é um autovalor e $\mathbf{v}$ é um autovetor correspondente. O conjunto formado pelo vetor nulo e por todos os autovetores associados a λ constitui o autoespaço

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovalores são determinados pela condição

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0.$$

A multiplicidade algébrica $m_a(\lambda)$ registra a multiplicidade de λ como raiz do polinômio característico, enquanto a multiplicidade geométrica

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda)$$

mede a dimensão do autoespaço correspondente.

Quando $\mathbf{A}$ possui p autovetores linearmente independentes, eles formam uma base

$$\mathcal{B}_\mathbf{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\},$$

cujas matrizes são

$$\mathbf{B}_\mathbf{A} = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_p].$$

Nessa base,

$$[T_\mathbf{A}]_{\mathcal{B}_\mathbf{A} \leftarrow \mathcal{B}_\mathbf{A}} = \mathbf{B}_\mathbf{A}^{-1} \mathbf{A} \mathbf{B}_\mathbf{A} = \Lambda_\mathbf{A},$$

e, portanto,

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}.$$

A diagonalização é, assim, uma mudança para coordenadas nas quais o operador atua separadamente sobre cada direção da base de autovetores.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores. Nesse caso, a matriz da base pode ser escolhida ortogonal,

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

com

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top,$$

e obtém-se a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Equivalentemente,

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Agrupando autovalores repetidos, essa representação pode ser escrita em termos dos projetores espectrais:

$$\mathbf{A} = \sum_h \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Essa forma mostra que uma matriz simétrica atua projetando o vetor sobre autoespaços ortogonais e aplicando a cada componente o autovalor correspondente.

A decomposição espectral também permite recuperar diretamente propriedades da matriz:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

e

$$\text{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\},$$

contando as multiplicidades.

Além disso,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \left\{ \mathbf{q}_j : \lambda_j = 0 \right\},$$

enquanto

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \left\{ \mathbf{q}_j : \lambda_j \neq 0 \right\}.$$

Para matrizes simétricas,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp.$$

A mesma decomposição simplifica as formas quadráticas. Se

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x},$$

então

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são, portanto, determinadas pelos sinais dos autovalores. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides cujos eixos estão alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

é uma média ponderada dos autovalores. Para

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

tem-se

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

O máximo e o mínimo são atingidos nos autoespaços associados aos autovalores extremos. A otimização de uma forma quadrática sob a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

conduz à condição

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}.$$

Autovalores e autovetores podem, portanto, ser interpretados também como valores e direções estacionárias de problemas de otimização quadrática.

A decomposição espectral permite ainda definir funções de matrizes simétricas. Se f está definida no espectro de $\mathbf{A}$,

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Equivalentemente,

$$f(\mathbf{A}) = \sum_h f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Assim, a função espectral preserva os autoespaços e transforma cada autovalor λ no escalar $f(\lambda)$. Potências, inversas, raízes quadradas, raízes quadradas inversas, pseudoinversas, exponenciais e logaritmos são casos particulares dessa construção, sob as condições necessárias à definição de cada função.

Quando a geometria do problema é determinada por uma matriz simétrica positiva definida $\mathbf{M}$, surge o problema de autovalores generalizados

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

com $\mathbf{A} = \mathbf{A}^\top$ e $\mathbf{M} \succ 0$.

O quociente correspondente é

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

converte esse problema em um problema de Rayleigh ordinário para a matriz simétrica

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Consequentemente, os autovalores generalizados são reais e pode-se escolher uma base de autovetores generalizados cuja matriz $\mathbf{B}_g$ satisfaz

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

A Tabela 5.2 reúne as expressões principais desenvolvidas no capítulo.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica direções invariantes
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Projeto espectral	$\Pi_\lambda = \mathbf{Q}_\lambda \mathbf{Q}_\lambda^\top$	Projeta sobre o autoespaço associado a λ
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}$	Caracteriza valores e direções espectrais por otimização
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda \mathbf{M} \mathbf{v}$	Compara duas formas quadráticas

Objeto	Expressão	Interpretação
Base generalizada	$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$	Define ortonormalidade na geometria induzida por $\mathbf{M}$
Diagonalização por congruência	$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g$	Reduz simultaneamente as duas formas quadráticas

Ao final deste capítulo, o estudante deverá ser capaz de:

- identificar autovalores, autovetores e autoespaços e interpretar seu significado geométrico;
- distinguir multiplicidades algébrica e geométrica;
- determinar quando uma matriz é diagonalizável;
- interpretar a diagonalização como mudança para uma base de autovetores;
- aplicar o Teorema Espectral a matrizes simétricas reais;
- interpretar projetores e subespaços espectrais;
- relacionar autovalores a traço, determinante, posto, núcleo, imagem e positividade;
- representar formas quadráticas em coordenadas espectrais;
- formular problemas de otimização por meio do quociente de Rayleigh;
- construir e interpretar funções espectrais de matrizes;
- compreender inversas, raízes e pseudoinversas pela ação sobre os autovalores;
- formular e transformar problemas de autovalores generalizados;
- distinguir ortogonalidade euclidiana de ortogonalidade segundo uma matriz positiva definida.

A decomposição espectral fornece uma descrição particularmente simples para matrizes simétricas quadradas. Entretanto, matrizes de dados e muitas transformações de interesse são retangulares ou não simétricas e, portanto, não admitem diretamente essa decomposição. O próximo capítulo amplia essas ideias por meio da **Decomposição em Valores Singulares**, relacionando matrizes retangulares aos espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ e conectando valores singulares, espaços fundamentais, posto e aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma matriz real e $T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ a transformação linear associada;
- $r = \text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$;
- $d_1 \geq \dots \geq d_r > 0$ representam os valores singulares positivos de $\mathbf{A}$;
- $\mathbf{v}_j \in \mathbb{R}^p$ representa um vetor singular à direita;
- $\mathbf{u}_j \in \mathbb{R}^q$ representa um vetor singular à esquerda;
- $\mathbf{U}$, $\mathbf{D}$ e $\mathbf{V}$ representam os fatores da SVD completa;
- $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ representam os fatores da SVD compacta;
- $\mathbf{U}_k$, $\mathbf{D}_k$ e $\mathbf{V}_k$ representam os fatores de uma SVD truncada;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\|\mathbf{A}\|_2$ e $\|\mathbf{A}\|_F$ representam, respectivamente, as normas espectral e de Frobenius.

As convenções estabelecidas nos capítulos anteriores para núcleo, imagem, espaço coluna, espaço linha e bases ortonormais permanecem válidas.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

*Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub; Van Loan, 2013)*

A demonstração será apresentada posteriormente, após a construção da SVD a partir das decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$.

Definição 6.1 (Matriz diagonal retangular). Seja

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

A matriz $\mathbf{D}$ é denominada **diagonal retangular** quando existem escalares

$$d_1, \dots, d_s$$

tais que

$$D_{ij} = \begin{cases} d_i, & i = j \leq s, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, apenas os elementos da diagonal principal podem ser diferentes de zero.

No bloco diagonal de ordem s , essa condição pode ser escrita de forma compacta utilizando a delta de Kronecker:

$$D_{ij} = d_i \delta_{ij}, \quad i, j = 1, \dots, s.$$

Se

$$q > p,$$

então $s = p$ e $\mathbf{D}$ possui $q - p$ linhas nulas abaixo de sua parte diagonal.

Se

$$p > q,$$

então $s = q$ e $\mathbf{D}$ possui $p - q$ colunas nulas à direita de sua parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_p \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Nesse caso, a parte diagonal possui $p = \min(q, p)$ elementos e as $q - p$ linhas restantes são nulas.

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Agora, a parte diagonal possui $q = \min(q, p)$ elementos e as $p - q$ colunas restantes são nulas.

Como

$$s = \min(q, p),$$

a matriz $\mathbf{D}$ possui s posições diagonais. Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos. Ordenando-os de forma decrescente,

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto, quando $r < s$,

$$d_{r+1} = \cdots = d_s = 0.$$

Assim, o número de valores singulares positivos é exatamente o posto de $\mathbf{A}$ e, conseqüentemente, a dimensão da imagem da transformação linear associada:

$$r = \text{posto}(\mathbf{A}) = \dim(\text{Im}(T_{\mathbf{A}})).$$

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.2 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A} \mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;
- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{z} = \mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base ortonormal dos vetores singulares à direita,

$$\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

Assim,

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_V}.$$

Na segunda etapa,

$$\mathbf{Dz}$$

multiplica separadamente as coordenadas pelas entradas diagonais de $\mathbf{D}$. Como $\mathbf{D} \in \mathbb{R}^{q \times p}$ pode ser retangular, essa etapa também realiza a passagem entre as dimensões do domínio e do contradomínio.

Na terceira etapa, $\mathbf{U}$ reconstrói o resultado nas coordenadas canônicas de $\mathbb{R}^q$ a partir da base ortonormal

$$\mathcal{B}_U = \{\mathbf{u}_1, \dots, \mathbf{u}_q\}.$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.3 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.4 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva todos os r valores singulares positivos e fornece a representação exata

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

A SVD truncada conserva apenas parte desses componentes singulares.

Para

$$1 \leq k < r,$$

defina

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k] \in \mathbb{R}^{q \times k},$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

Definição 6.5 (SVD truncada). Seja

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a matriz

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$$

é denominada **SVD truncada de posto k** de $\mathbf{A}$.

Como $k < r$, a SVD truncada descarta componentes associados a valores singulares positivos. Portanto, em geral,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ possui posto k e constitui uma aproximação de $\mathbf{A}$. As propriedades de otimalidade dessa aproximação e os erros decorrentes do truncamento serão estudados posteriormente.

A terminologia empregada para as diferentes formas da SVD não é uniforme na literatura. Dependendo da referência, aparecem expressões como **SVD reduzida**, **SVD fina** (*thin SVD*), **SVD econômica** (*economy-sized SVD*) e **SVD compacta**, nem sempre com exatamente o mesmo significado (Demmel, 2000; Driscoll; Braun, 2022; Sidi, 2017).

Para evitar ambiguidades, neste capítulo serão utilizadas as seguintes convenções:

- **SVD completa**, para a representação que utiliza bases ortonormais completas dos espaços de origem e de chegada;
- **SVD compacta**, para a representação exata que conserva somente os $r = \text{posto}(\mathbf{A})$ valores singulares positivos e os vetores singulares correspondentes;

- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

Exemplo 6.1 (SVD completa, compacta e truncada de uma matriz retangular). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \\ 2 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

A matriz possui posto

$$r = 3$$

e seus valores singulares, em ordem decrescente, são aproximadamente

$$d_1 = 4.1780, \quad d_2 = 2.1600, \quad d_3 = 1.3706.$$

Os valores apresentados a seguir estão arredondados a quatro casas decimais. Por esse motivo, as decomposições numéricas devem ser interpretadas a menos de arredondamento.

SVD completa

Uma SVD completa de $\mathbf{A}$ é

$$\mathbf{A} \approx \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que

$$\mathbf{U} \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 & -0.6014 & -0.2239 \\ 0.5461 & -0.2239 & 0.5466 & 0.5614 & -0.1943 \\ 0.3803 & -0.6954 & -0.3419 & -0.4142 & -0.2887 \\ 0.4348 & 0.4111 & -0.6965 & 0.3743 & -0.1295 \\ 0.4126 & -0.0779 & -0.0136 & -0.1073 & 0.9011 \end{bmatrix} \in \mathbb{R}^{5 \times 5},$$

$$\mathbf{D} \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

e

$$\mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

As colunas de $\mathbf{U}$ são os vetores singulares à esquerda,

$$\mathbf{u}_1, \dots, \mathbf{u}_5,$$

e as colunas de $\mathbf{V}$ são os vetores singulares à direita,

$$\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3.$$

Os três primeiros pares de vetores singulares estão associados aos três valores singulares positivos:

$$(\mathbf{u}_1, \mathbf{v}_1) \leftrightarrow d_1 = 4.1780,$$

$$(\mathbf{u}_2, \mathbf{v}_2) \leftrightarrow d_2 = 2.1600,$$

e

$$(\mathbf{u}_3, \mathbf{v}_3) \leftrightarrow d_3 = 1.3706.$$

As duas últimas colunas de $\mathbf{U}$ completam uma base ortonormal de $\mathbb{R}^5$. Elas correspondem às duas linhas nulas de $\mathbf{D}$.

SVD compacta

Como

$$r = \text{posto}(\mathbf{A}) = 3,$$

a SVD compacta conserva somente os três valores singulares positivos e os vetores singulares correspondentes:

$$\mathbf{A} \approx \mathbf{U}_3 \mathbf{D}_3 \mathbf{V}_3^\top,$$

com

$$\mathbf{U}_3 \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 \\ 0.5461 & -0.2239 & 0.5466 \\ 0.3803 & -0.6954 & -0.3419 \\ 0.4348 & 0.4111 & -0.6965 \\ 0.4126 & -0.0779 & -0.0136 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

$$\mathbf{D}_3 \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \end{bmatrix} \in \mathbb{R}^{3 \times 3},$$

e

$$\mathbf{V}_3 = \mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

A representação continua sendo exata antes do arredondamento numérico. A SVD compacta elimina apenas as duas colunas adicionais de $\mathbf{U}$ e as duas linhas nulas correspondentes de $\mathbf{D}$.

Como

$$r = p = 3,$$

todos os vetores singulares à direita participam da SVD compacta. Por isso,

$$\mathbf{V}_3 = \mathbf{V}.$$

SVD truncada de posto 2

Considere agora a conservação apenas dos dois maiores valores singulares,

$$d_1 = 4.1780 \quad \text{e} \quad d_2 = 2.1600.$$

A SVD truncada de posto 2 utiliza

$$\mathbf{U}_2 \approx \begin{bmatrix} 0.4449 & 0.5397 \\ 0.5461 & -0.2239 \\ 0.3803 & -0.6954 \\ 0.4348 & 0.4111 \\ 0.4126 & -0.0779 \end{bmatrix} \in \mathbb{R}^{5 \times 2},$$

$$\mathbf{D}_2 \approx \begin{bmatrix} 4.1780 & 0 \\ 0 & 2.1600 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

e

$$\mathbf{V}_2 \approx \begin{bmatrix} 0.6506 & 0.7406 \\ 0.5576 & -0.3155 \\ 0.5156 & -0.5933 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Assim,

$$\mathbf{A}_2 = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top$$

é uma aproximação de posto 2 da matriz original. Numericamente,

$$\mathbf{A}_2 \approx \begin{bmatrix} 2.0726 & 0.6688 & 0.2667 \\ 1.1260 & 1.4248 & 1.4631 \\ -0.0788 & 1.3598 & 1.7103 \\ 1.8394 & 0.7330 & 0.4098 \\ 0.9969 & 1.0143 & 0.9885 \end{bmatrix}.$$

Como o terceiro valor singular positivo foi descartado,

$$\mathbf{A}_2 \neq \mathbf{A}.$$

As três formas podem ser comparadas pelas dimensões de seus fatores:

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD completa	$\mathbf{U} : 5 \times 5$	$\mathbf{D} : 5 \times 3$	$\mathbf{V} : 3 \times 3$	d_1, d_2, d_3	Exato
SVD compacta	$\mathbf{U}_3 : 5 \times 3$	$\mathbf{D}_3 : 3 \times 3$	$\mathbf{V}_3 : 3 \times 3$	d_1, d_2, d_3	Exato
SVD truncada	$\mathbf{U}_2 : 5 \times 2$	$\mathbf{D}_2 : 2 \times 2$	$\mathbf{V}_2 : 3 \times 2$	d_1, d_2	Aproximado

A SVD completa apresenta bases ortonormais completas dos espaços de origem e de chegada. A SVD compacta mantém somente as direções associadas aos valores singulares positivos, sem perder informação necessária à reconstrução de $\mathbf{A}$. A SVD truncada conserva apenas parte dessas direções e, por isso, produz uma aproximação de posto menor.

6.1.6 Aprofundamento: não unicidade dos vetores singulares

Leitura de aprofundamento

Esta seção examina a não unicidade dos vetores singulares. Embora os valores singulares sejam determinados pela matriz, os vetores singulares associados podem admitir diferentes representações.

Serão considerados três casos: a mudança simultânea de sinal de pares de vetores singulares, a liberdade de escolha de bases ortonormais quando um valor singular positivo possui multiplicidade maior que um e a escolha das bases associadas ao valor singular zero.

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d\mathbf{U}_d \mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d(\mathbf{U}_d \mathbf{R})(\mathbf{V}_d \mathbf{R})^\top &= d\mathbf{U}_d \mathbf{R} \mathbf{R}^\top \mathbf{V}_d^\top \\ &= d\mathbf{U}_d \mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das duas matrizes de Gram associadas a $\mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Essas matrizes já apareceram no estudo dos espaços das variáveis e das observações. A SVD mostra agora que seus espectros estão diretamente relacionados e que essa relação permite construir bases ortonormais adaptadas à transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A} \mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Propriedades das matrizes de Gram associadas

As matrizes

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A}\mathbf{A}^\top$$

são matrizes de Gram associadas, respectivamente, às colunas e às linhas de $\mathbf{A}$.

Pela Proposição 3.9, ambas são simétricas e semidefinidas positivas. Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{A}\mathbf{A}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{A}\mathbf{A}^\top) = \text{posto}(\mathbf{A}).$$

Assim, se

$$r = \text{posto}(\mathbf{A}),$$

cada uma dessas matrizes possui exatamente r autovalores positivos, considerando suas multiplicidades.

Como ambas são simétricas, o Teorema 5.4 garante a existência de bases ortonormais de autovetores. Como também são semidefinidas positivas, todos os seus autovalores são não negativos.

Proposição 6.1 (Espectros das matrizes de Gram associadas). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *se esses autovalores são ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

podem-se definir

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r;$$

3. *os núcleos satisfazem*

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A} \mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então,

$$\mathbf{Ax} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}^\top \mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top \mathbf{A}),$$

então

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{x}^\top$,

$$\begin{aligned} 0 &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} \\ &= \|\mathbf{Ax}\|^2. \end{aligned}$$

Portanto,

$$\mathbf{Ax} = \mathbf{0},$$

e

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}).$$

Assim,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

O mesmo argumento, aplicado a $\mathbf{A}^\top$, fornece

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

Considere agora um autovalor positivo λ de

$$\mathbf{A}^\top \mathbf{A}$$

e um autovetor unitário $\mathbf{v}$ associado:

$$\mathbf{A}^\top \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Como $\lambda > 0$, defina

$$\mathbf{u} = \frac{\mathbf{A} \mathbf{v}}{\sqrt{\lambda}}.$$

Esse vetor possui norma unitária, pois

$$\begin{aligned} \mathbf{u}^\top \mathbf{u} &= \frac{\mathbf{v}^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\lambda} \\ &= \frac{\lambda \mathbf{v}^\top \mathbf{v}}{\lambda} \\ &= 1. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top \mathbf{u} &= \frac{\mathbf{A} \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\mathbf{A}^\top \mathbf{A} \mathbf{v})}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\lambda \mathbf{v})}{\sqrt{\lambda}} \\ &= \lambda \mathbf{u}. \end{aligned}$$

Portanto, todo autovalor positivo de

$$\mathbf{A}^\top \mathbf{A}$$

também é autovalor de

$$\mathbf{A}\mathbf{A}^\top.$$

O argumento inverso é obtido começando por um autovetor de

$$\mathbf{A}\mathbf{A}^\top$$

e definindo

$$\mathbf{v} = \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}.$$

Para $\lambda > 0$, as aplicações

$$\mathbf{v} \mapsto \frac{\mathbf{A}\mathbf{v}}{\sqrt{\lambda}}$$

e

$$\mathbf{u} \mapsto \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}$$

estabelecem aplicações lineares inversas entre o autoespaço de $\mathbf{A}^\top \mathbf{A}$ associado a λ e o autoespaço de $\mathbf{A}\mathbf{A}^\top$ associado ao mesmo autovalor. Portanto, esses autoespaços possuem a mesma dimensão e as multiplicidades dos autovalores positivos coincidem.

Como

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A}) = r,$$

existem exatamente r autovalores positivos. O mesmo ocorre para

$$\mathbf{A}\mathbf{A}^\top.$$

Definindo

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r,$$

obtêm-se r números positivos associados aos autovalores positivos comuns às duas matrizes de Gram. A construção a seguir mostrará que esses números são precisamente os valores singulares positivos de $\mathbf{A}$. $\square$

As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos pares singulares

Suponha inicialmente que

$$\mathbf{A} \neq \mathbf{0}.$$

Então,

$$r = \text{posto}(\mathbf{A}) \geq 1.$$

O caso

$$\mathbf{A} = \mathbf{0}$$

será tratado diretamente na demonstração do Teorema [6.1](#).

A construção começa pela matriz

$$\mathbf{A}^\top \mathbf{A},$$

que atua em

$$\mathbb{R}^p,$$

o domínio da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Seus autovetores associados aos autovalores positivos determinarão os **vetores singulares à direita**. A aplicação de $\mathbf{A}$ a essas direções, seguida de normalização, produzirá os **vetores singulares à esquerda** em $\mathbb{R}^q$.

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Particione a matriz de autovetores como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

contém os autovetores associados aos autovalores positivos e

$$\mathbf{V}_0 = [\mathbf{v}_{r+1} \quad \cdots \quad \mathbf{v}_p]$$

contém os autovetores associados ao autovalor zero.

Pela Proposição 6.1,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Portanto, as colunas de $\mathbf{V}_0$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{V}_r$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A})^\perp = \mathcal{C}(\mathbf{A}^\top).$$

Proposição 6.2 (Construção dos pares singulares positivos). *Para cada*

$$j = 1, \dots, r,$$

defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Então:

1. *os vetores*

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais;

2. *para cada $j = 1, \dots, r$,*

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j;$$

3. os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

Comprovação. Para $i, j \leq r$,

$$\begin{aligned}\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.\end{aligned}$$

Como os vetores

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Pela definição de $\mathbf{u}_j$,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Além disso,

$$\begin{aligned}\mathbf{A}^\top\mathbf{u}_j &= \frac{\mathbf{A}^\top\mathbf{A}\mathbf{v}_j}{d_j} \\ &= \frac{d_j^2\mathbf{v}_j}{d_j} \\ &= d_j\mathbf{v}_j.\end{aligned}$$

Cada $\mathbf{u}_j$ pertence a

$$\mathcal{C}(\mathbf{A}),$$

pois

$$\mathbf{u}_j = \frac{1}{d_j}\mathbf{A}\mathbf{v}_j.$$

Como existem

$$r = \text{posto}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A})$$

vetores ortonormais desse tipo, eles formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

□

A construção estabelece uma correspondência entre duas direções ortonormais:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p \quad \xrightarrow{\mathbf{A}} \quad d_j\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q \quad \xrightarrow{\mathbf{A}^\top} \quad d_j\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p.$$

Assim, $\mathbf{v}_j$ é uma direção singular à direita, $\mathbf{u}_j$ é a direção singular à esquerda correspondente e d_j é o fator de escalonamento que relaciona as duas.

6.2.3 Construção da SVD compacta

Reúna os vetores singulares à esquerda em

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r]$$

e defina

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r).$$

As relações

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j, \quad j = 1, \dots, r,$$

podem ser escritas simultaneamente como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r.$$

Proposição 6.3 (SVD compacta obtida dos pares singulares). *Com as matrizes $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ definidas anteriormente,*

$$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Portanto,

$$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$$

é a SVD compacta de $\mathbf{A}$, e

$$d_1, \dots, d_r$$

são seus valores singulares positivos.

Comprovação. Como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal,

$$\mathbf{I}_p = \mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top.$$

As colunas de $\mathbf{V}_0$ pertencem a

$$\mathcal{N}(\mathbf{A}),$$

de modo que

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$

Assim,

$$\begin{aligned} \mathbf{A} &= \mathbf{A} \mathbf{I}_p \\ &= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\ &= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

□

A SVD compacta utiliza exatamente as direções que participam da transformação:

- as colunas de $\mathbf{V}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A}^\top)$;
- $\mathbf{D}_r$ contém os fatores de escalonamento positivos;
- as colunas de $\mathbf{U}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A})$.

A construção anterior permite concluir a demonstração do Teorema [6.1](#).

Comprovação. Se

$$\mathbf{A} = \mathbf{0},$$

tome

$$\mathbf{U} = \mathbf{I}_q, \quad \mathbf{V} = \mathbf{I}_p$$

e

$$\mathbf{D} = \mathbf{0}_{q \times p}.$$

Então,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Suponha agora que

$$\mathbf{A} \neq \mathbf{0}.$$

Pela Proposição 6.3,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de $\mathbf{U}_r$ formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A}^\top)^\perp.$$

Complete esse conjunto com uma base ortonormal

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_q$$

de

$$\mathcal{N}(\mathbf{A}^\top).$$

Defina

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0] \in \mathbb{R}^{q \times q},$$

em que

$$\mathbf{U}_0 = [\mathbf{u}_{r+1} \quad \dots \quad \mathbf{u}_q].$$

A matriz $\mathbf{U}$ é ortogonal.

A matriz

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0] \in \mathbb{R}^{p \times p}$$

já foi obtida da decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

e também é ortogonal.

Defina

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

como a matriz diagonal retangular cujos primeiros r elementos diagonais são

$$d_1, \dots, d_r$$

e cujos demais elementos são nulos.

Como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$$

e

$$\mathbf{A}\mathbf{V}_0 = \mathbf{0},$$

tem-se

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{D}.$$

Multiplicando à direita por $\mathbf{V}^\top$,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Isso demonstra a existência da SVD completa. □

6.2.4 Decomposições espectrais associadas

Proposição 6.4 (Decomposições espectrais induzidas pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Comprovação. Utilizando a SVD compacta,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

Como as colunas de $\mathbf{U}_r$ são ortonormais,

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Analogamente,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

□

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A} \mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A} \mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

As duas decomposições também identificam os espaços aos quais pertencem os vetores singulares:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q.$$

Portanto, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio. Os valores singulares positivos realizam a ligação entre esses dois espaços.

6.2.5 Exemplo de construção da SVD

Exemplo 6.2 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned} \mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

O segundo é

$$\begin{aligned} \mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}. \end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A} \mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A} \mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, pode-se escolher uma SVD na qual, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

6.2.7 Aprofundamento: SVD de matrizes simétricas indefinidas

Leitura de aprofundamento

Esta seção examina a relação entre a decomposição espectral e a SVD quando uma matriz simétrica possui autovalores negativos. Nesse caso, os valores singulares correspondem aos módulos dos autovalores, enquanto seus sinais são incorporados a uma das matrizes ortogonais da SVD.

Esse desenvolvimento complementa o caso semidefinido positivo apresentado anteriormente, mas não é necessário para acompanhar as aplicações principais da SVD às matrizes de Gram, às matrizes de dados e às estruturas de covariância.

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j)|\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_{\mathbf{A}},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_{\mathbf{A}} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_{\mathbf{A}}\mathbf{\Lambda}_{\mathbf{A}}\mathbf{Q}_{\mathbf{A}}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como a transformação leva a bola unitária do domínio a um elipsoide contido na imagem de $\mathbf{A}$, cujos semieixos são determinados pelos valores e vetores singulares. O comportamento da esfera unitária dependerá da existência ou não de direções pertencentes ao núcleo.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \sum_{j=1}^p \alpha_j \mathbf{Av}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Proposição 6.5 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto $r \geq 1$. A imagem da bola unitária por $\mathbf{A}$ é o elipsoide sólido de dimensão r , contido em $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$

Em particular,

$$\mathbf{A}(\mathcal{B}_p) \subseteq \mathcal{C}(\mathbf{A}),$$

e a dimensão desse elipsoide é

$$\dim(\mathcal{C}(\mathbf{A})) = r.$$

No caso extremo $\mathbf{A} = \mathbf{0}$, a imagem da bola unitária reduz-se ao conjunto $\{\mathbf{0}\}$.

Comprovação. Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

$$\mathbf{x} = \sum_{j=1}^r \frac{\beta_j}{d_j} \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1,$$

de modo que $\mathbf{x} \in \mathcal{B}_p$. Além disso,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{u}_j = \mathbf{y}.$$

Logo, o conjunto apresentado coincide com a imagem da bola unitária. □

O comportamento da esfera unitária depende da existência de um núcleo não trivial.

Se $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso, a imagem da esfera unitária

$$\mathcal{S}_{p-1} = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| = 1\}$$

é a fronteira relativa do elipsoide

$$\mathbf{A}(\mathcal{B}_p)$$

no subespaço $\mathcal{C}(\mathbf{A})$.

Por outro lado, se

$$r < p,$$

então

$$\dim(\mathcal{N}(\mathbf{A})) = p - r > 0.$$

Nesse caso, a imagem da esfera unitária coincide com a imagem da bola unitária:

$$\mathbf{A}(\mathcal{S}_{p-1}) = \mathbf{A}(\mathcal{B}_p).$$

De fato, para qualquer ponto do elipsoide cuja componente nas direções $\mathbf{v}_1, \dots, \mathbf{v}_r$ tenha norma menor que 1, pode-se acrescentar uma componente pertencente ao núcleo até obter um vetor de norma 1, sem alterar sua imagem por $\mathbf{A}$.

Finalmente, se

$$r < q,$$

o elipsoide não ocupa todo o espaço de chegada. Ele está contido no subespaço de dimensão r

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a geometria da imagem da bola revela simultaneamente os fatores de escala da transformação e a dimensão de sua imagem.

6.3.2 Alteração dos comprimentos

Os valores singulares permitem determinar os fatores extremos de alteração dos comprimentos produzidos pela transformação.

Proposição 6.6 (Extremos da alteração dos comprimentos). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto $r \geq 1$, com valores singulares positivos ordenados como

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0.$$

Então, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

Consequentemente,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p,$$

então

$$d_p \|\mathbf{x}\| \leq \|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|$$

para todo $\mathbf{x} \in \mathbb{R}^p$, e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se

$$r < p,$$

então

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

Comprovação. Escreva $\mathbf{x}$ na base ortonormal dos vetores singulares à direita:

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j.$$

Como essa base é ortonormal,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2.$$

Por outro lado,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Como

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais,

$$\|\mathbf{Ax}\|^2 = \sum_{j=1}^r d_j^2 \alpha_j^2.$$

Como

$$d_j \leq d_1, \quad j = 1, \dots, r,$$

segue que

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^r d_j^2 \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^r \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_1^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, tomando

$$\mathbf{x} = \mathbf{v}_1,$$

pois

$$\|\mathbf{Av}_1\| = \|d_1 \mathbf{u}_1\| = d_1.$$

Logo,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Suponha agora que $\mathbf{A}$ possua posto coluna completo. Nesse caso,

$$r = p$$

e

$$d_p > 0.$$

Como

$$d_j \geq d_p, \quad j = 1, \dots, p,$$

tem-se

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^p d_j^2 \alpha_j^2 \\
&\geq d_p^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_p^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \geq d_p \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, para

$$\mathbf{x} = \mathbf{v}_p,$$

de modo que

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Finalmente, se

$$r < p,$$

então

$$\dim \mathcal{N}(\mathbf{A}) = p - r > 0.$$

Logo, existe um vetor unitário

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Para esse vetor,

$$\mathbf{Ax}_0 = \mathbf{0},$$

e, portanto,

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

□

O maior valor singular d_1 representa, portanto, o maior fator de ampliação produzido pela transformação. Quando $\mathbf{A}$ possui posto coluna completo, o menor valor singular d_p representa o menor fator de alteração de comprimento entre vetores unitários. Quando o posto coluna não é completo, existem direções unitárias eliminadas pela transformação, e o menor comprimento possível da imagem é zero.

Esses extremos serão retomados posteriormente na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.3 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;
- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal de $\mathbb{R}^2$ e identificam duas direções sobre a circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

Neste exemplo, as bases singulares do domínio e do contradomínio são distintas. A matriz $\mathbf{V}^\top$ expressa os pontos da circunferência nas coordenadas da base formada por $\mathbf{v}_1$ e $\mathbf{v}_2$. Como essa transformação é ortogonal, a circunferência permanece uma circunferência. Em seguida, $\mathbf{D}$ realiza a deformação, multiplicando os comprimentos nas duas direções por d_1 e d_2 . Finalmente, $\mathbf{U}$ orienta os semieixos da elipse nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$ no espaço de chegada.

6.3.4 Transformações com núcleo não trivial

Quando

$$r < p,$$

a transformação possui núcleo não trivial e elimina $p - r$ direções linearmente independentes do domínio. Geometricamente, a imagem da bola unitária passa a ter dimensão inferior à dimensão do domínio.

Exemplo 6.4 (Colapso de uma direção pela transformação). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A ação da transformação sobre um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

é

$$\mathbf{A}_0 \mathbf{x} = \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix}.$$

Portanto, toda a direção

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

é eliminada, pois

$$\mathbf{A}_0 \mathbf{e}_2 = \mathbf{0}.$$

De fato,

$$\mathcal{N}(\mathbf{A}_0) = \text{span} \{ \mathbf{e}_2 \}.$$

A bola unitária de $\mathbb{R}^2$ é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

Assim, a imagem possui dimensão 1, que coincide com

$$\text{posto}(\mathbf{A}_0) = 1.$$

O valor singular positivo $d_1 = 2$ determina o comprimento do único semieixo não nulo, enquanto o valor singular $d_2 = 0$ identifica a direção eliminada pela transformação.

De modo geral:

- cada valor singular positivo produz um semieixo não nulo da imagem;
- existem exatamente r semieixos não nulos;
- o núcleo possui dimensão $p - r$ e contém todas as direções que são transformadas no vetor nulo;
- a dimensão do elipsoide resultante é r ;
- o elipsoide está contido em $\mathcal{C}(\mathbf{A})$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores e normas diretamente a partir dos vetores e valores singulares. Aspectos relacionados ao condicionamento numérico serão apresentados posteriormente como leitura de aprofundamento.

6.4 Espaços fundamentais, posto e normas

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Proposição 6.7 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_q\} = \mathcal{C}(\mathbf{U}_0).$$

(Golub; Van Loan, 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{U}_r) \subseteq \mathcal{C}(\mathbf{A}).$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r).$$

Aplicando o mesmo argumento a

$$\mathbf{A}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top,$$

obtém-se

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r).$$

Considere agora a base ortonormal completa

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma decomposição única da forma

$$\mathbf{x} = \mathbf{V}_r \alpha + \mathbf{V}_0 \beta.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top (\mathbf{V}_r \alpha + \mathbf{V}_0 \beta) \\ &= \mathbf{U}_r \mathbf{D}_r \alpha, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_0 = \mathbf{0}.$$

Como $\mathbf{D}_r$ é invertível,

$$\mathbf{Ax} = \mathbf{0}$$

se, e somente se,

$$\alpha = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A})$$

se, e somente se,

$$\mathbf{x} = \mathbf{V}_0 \beta.$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

Aplicando o mesmo raciocínio a $\mathbf{A}^\top$,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Assim, a SVD completa fornece bases ortonormais simultaneamente para os quatro espaços fundamentais de $\mathbf{A}$. $\square$

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.4.

Tabela 6.4: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

A identificação das bases dos quatro espaços fundamentais permite construir diretamente seus projetores ortogonais.

Proposição 6.8 (Projetores dos espaços fundamentais pela SVD). *Considere a SVD completa escrita como*

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Então, os projetores ortogonais sobre os quatro espaços fundamentais são

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^{\top}$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

Comprovação. Pela Proposição 6.7,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r)$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Como as colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ são ortonormais, a Proposição 3.14 fornece

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top.$$

Além disso, como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U} \mathbf{U}^\top = \mathbf{I}_q.$$

Portanto,

$$\mathbf{U}_r \mathbf{U}_r^\top + \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q,$$

de onde

$$\mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

Aplicando o mesmo argumento a

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

obtêm-se

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

□

Como são projetores ortogonais, essas matrizes são simétricas e idempotentes, conforme as propriedades estudadas no Capítulo 3.

Exemplo 6.5 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{ \mathbf{0} \}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned} \mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}. \end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

Pela SVD, o posto de $\mathbf{A}$ é exatamente o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r = \# \{j : d_j > 0\}.$$

Como consequência do Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Essas dimensões também são visualizadas diretamente na SVD completa:

- as r colunas de $\mathbf{V}_r$ formam uma base do espaço linha;
- as $p - r$ colunas de $\mathbf{V}_0$ formam uma base do núcleo de $\mathbf{A}$;
- as r colunas de $\mathbf{U}_r$ formam uma base do espaço coluna;
- as $q - r$ colunas de $\mathbf{U}_0$ formam uma base do núcleo de $\mathbf{A}^\top$.

É importante distinguir essas dimensões do número de posições diagonais nulas de $\mathbf{D}$. Como

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui apenas

$$s = \min(q, p)$$

posições diagonais, existem

$$s - r$$

valores singulares nulos entre essas posições, enquanto as dimensões dos dois núcleos são, respectivamente,

$$p - r \quad \text{e} \quad q - r.$$

Assim, em matrizes retangulares, a estrutura completa dos núcleos não deve ser inferida apenas pela quantidade de elementos diagonais nulos de $\mathbf{D}$.

A Tabela 6.5 reúne as principais relações entre os valores e vetores singulares e a estrutura da transformação.

Tabela 6.5: Relação entre a SVD e a estrutura da matriz.

Estrutura ou propriedade	Caracterização pela SVD
Posto	Número de valores singulares positivos
Imagem $\mathcal{C}(\mathbf{A})$	Vetores singulares à esquerda associados a $d_j > 0$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	Vetores singulares à direita associados a $d_j > 0$
Núcleo $\mathcal{N}(\mathbf{A})$	Vetores singulares à direita associados à parte nula
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	Vetores singulares à esquerda associados à parte nula
Ampliação máxima	d_1
Menor fator positivo de escala	d_r

Se $r < p$, a menor norma de $\mathbf{A}\mathbf{x}$ entre todos os vetores unitários do domínio é zero, pois existem vetores unitários no núcleo. O valor d_r descreve o menor fator **positivo** de escala, isto é, a menor ação da transformação quando restrita ao espaço linha $\mathcal{C}(\mathbf{A}^\top)$.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.6 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \text{tr} (\mathbf{A}^\top \widetilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \tilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.7 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr} (\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.8 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Proposição 6.9 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub; Van Loan, 2013)

Comprovação. Pela Proposição 6.6,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Como, pela Definição 6.8,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|,$$

segue imediatamente que

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius, utilizando a Proposição 6.4,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Portanto,

$$\begin{aligned} \|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\ &= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\ &= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\ &= \text{tr}(\mathbf{D}_r^2) \\ &= \sum_{j=1}^r d_j^2. \end{aligned}$$

Logo,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

□

Se $\mathbf{A} = \mathbf{0}$, então não há valores singulares positivos e, diretamente pelas definições,

$$\|\mathbf{A}\|_2 = \|\mathbf{A}\|_F = 0.$$

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Proposição 6.10 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub; Van Loan, 2013)

Comprovação. Para a norma espectral, como $\mathbf{Q}_1$ preserva normas,

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2 \mathbf{x}\| = \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\|.$$

Como $\mathbf{Q}_2$ é ortogonal, a transformação

$$\mathbf{z} = \mathbf{Q}_2 \mathbf{x}$$

preserva a norma e percorre todos os vetores unitários quando $\mathbf{x}$ percorre a esfera unitária. Portanto,

$$\begin{aligned} \|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 &= \max_{\|\mathbf{x}\|=1} \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\| \\ &= \max_{\|\mathbf{z}\|=1} \|\mathbf{A} \mathbf{z}\| \\ &= \|\mathbf{A}\|_2. \end{aligned}$$

Para a norma de Frobenius,

$$\begin{aligned}
\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F^2 &= \text{tr} \left[(\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2) \right] \\
&= \text{tr} (\mathbf{Q}_2^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}_2) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A} \mathbf{Q}_2 \mathbf{Q}_2^\top) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A}) \\
&= \|\mathbf{A}\|_F^2.
\end{aligned}$$

Logo, ambas as normas são invariantes sob multiplicações ortogonais. $\square$

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p = q,$$

de modo que não existem direções singulares associadas ao valor zero. Assim, as formas compacta e completa possuem as mesmas dimensões e podem ser escritas com os mesmos fatores:

$$\mathbf{U}_r = \mathbf{U}, \quad \mathbf{D}_r = \mathbf{D}, \quad \mathbf{V}_r = \mathbf{V}.$$

6.4.8 Aprofundamento: condicionamento e posto numérico

Leitura de aprofundamento

Esta seção apresenta duas extensões de natureza numérica da interpretação dos valores singulares. A primeira utiliza a razão entre os valores singulares extremos para avaliar o condicionamento de uma transformação. A segunda distingue o posto algébrico do posto numérico obtido após a adoção de uma tolerância computacional.

Esses conceitos são importantes para estabilidade numérica, problemas inversos e algoritmos matriciais, mas não são necessários para acompanhar os resultados centrais sobre espaços fundamentais, aproximações de posto reduzido e aplicações estatísticas da SVD.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

Quando

$$\text{posto}(\mathbf{A}) = s,$$

a matriz possui o maior posto possível para suas dimensões e todos os seus s valores singulares são positivos:

$$d_1 \geq \dots \geq d_s > 0.$$

Definição 6.9 (Número de condição na norma espectral). Para uma matriz de posto máximo,

$$\text{posto}(\mathbf{A}) = s,$$

define-se o **número de condição na norma espectral** por

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Quando

$$\text{posto}(\mathbf{A}) < s,$$

adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

(Golub; Van Loan, 2013)

O número de condição compara o maior e o menor fatores positivos de escala associados à parte ativa da transformação.

Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

os valores singulares extremos possuem magnitudes semelhantes. Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são transformadas por fatores muito maiores que outras.

É importante distinguir **núcleo não trivial**, **deficiência de posto** e **mau condicionamento**.

A deficiência de posto ocorre quando

$$\text{posto}(\mathbf{A}) < \min(q, p).$$

Entretanto, uma matriz retangular pode possuir núcleo não trivial mesmo apresentando posto máximo.

Por exemplo, se

$$q < p$$

e

$$\text{posto}(\mathbf{A}) = q,$$

então $\mathbf{A}$ possui posto linha completo e, portanto, posto máximo. Mesmo assim,

$$\dim \mathcal{N}(\mathbf{A}) = p - q > 0.$$

Assim, existem direções do domínio que são transformadas no vetor nulo.

Nesse caso, a transformação não é injetiva em todo o domínio $\mathbb{R}^p$. Sua restrição ao espaço linha,

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp,$$

é, entretanto, injetiva.

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{A}\mathbf{x}\|.$$

Portanto, para matrizes largas de posto linha completo, o número de condição finito descreve a variação dos fatores de escala sobre o espaço linha, isto é, sobre a parte do domínio na qual a transformação atua de forma injetiva.

Se

$$q \geq p$$

e

$$\text{posto}(\mathbf{A}) = p,$$

então $\mathbf{A}$ possui posto coluna completo e

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso,

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Para uma matriz quadrada invertível,

$$q = p = r,$$

tem-se também

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Portanto,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p},$$

de modo que

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Uma matriz de posto máximo com número de condição elevado é denominada **mal condicionada**. Valores singulares positivos muito pequenos indicam direções nas quais a transformação produz forte contração. Ao inverter a ação da matriz nessas direções, pequenas perturbações podem ser amplificadas.

Esse fenômeno será retomado posteriormente na discussão da pseudoinversa.

Exemplo 6.6 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

Nesse caso, as duas direções singulares são transformadas pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por um fator igual a 2, enquanto a segunda é contraída por um fator igual a 0,02.

A inversão da segunda componente exige um fator

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem ser fortemente ampliadas quando se procura inverter a transformação.

6.4.8.1 Posto exato e posto numérico

Matematicamente, o posto é determinado exatamente pelos valores singulares positivos:

$$\text{posto}(\mathbf{A}) = \# \{j : d_j > 0\}.$$

Em cálculos computacionais, entretanto, valores que seriam exatamente nulos em aritmética exata podem aparecer como números positivos muito pequenos em razão de arredondamentos, aproximações ou ruído.

Por isso, pode-se adotar uma tolerância

$$\tau \geq 0$$

e tratar como numericamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

Definição 6.10 (Posto numérico). Fixada uma tolerância $\tau \geq 0$, o **posto numérico** de $\mathbf{A}$ é definido por

$$r_\tau(\mathbf{A}) = \# \{j : d_j > \tau\}.$$

Diferentemente do posto algébrico, o posto numérico depende da tolerância adotada.

A escolha de τ pode depender de fatores como:

- precisão numérica;
- escala da matriz;
- dimensões da matriz;
- finalidade da análise;
- nível de perturbação ou ruído considerado relevante.

Portanto, dois valores devem ser distinguidos:

$$\text{posto}(\mathbf{A}) = \#\{j : d_j > 0\}$$

e

$$r_\tau(\mathbf{A}) = \#\{j : d_j > \tau\}.$$

Essa distinção será particularmente útil quando forem estudadas aproximações de posto reduzido. Nessas aproximações, valores singulares matematicamente positivos podem ser descartados deliberadamente quando sua contribuição é considerada pequena.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, a SVD recupera a dupla representação da matriz de dados introduzida no Capítulo 1:

- as colunas de $\mathbf{V}_r$ pertencem a $\mathbb{R}^p$ e determinam direções no espaço em que as observações são representadas;
- as colunas de $\mathbf{U}_r$ pertencem a $\mathbb{R}^n$ e determinam direções no espaço em que as variáveis são representadas.

Os mesmos valores singulares conectam essas duas representações.

6.5.1 Dualidade entre observações e variáveis

A SVD relaciona diretamente as duas representações da matriz de dados: as observações como vetores em $\mathbb{R}^p$ e as variáveis como vetores em $\mathbb{R}^n$.

Proposição 6.11 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

então

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

Consequentemente, para

$$j = 1, \dots, r,$$

tem-se

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, o mesmo valor singular d_j relaciona uma direção $\mathbf{v}_j$ no espaço das observações $\mathbb{R}^p$ a uma direção $\mathbf{u}_j$ no espaço das variáveis $\mathbb{R}^n$.

Comprovação. Multiplicando a SVD compacta à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{V}_r^\top\mathbf{V}_r = \mathbf{I}_r.$$

Transpondo a SVD compacta,

$$\mathbf{X}^\top = \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top.$$

Multiplicando à direita por $\mathbf{U}_r$,

$$\begin{aligned}\mathbf{X}^\top\mathbf{U}_r &= \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top\mathbf{U}_r \\ &= \mathbf{V}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{U}_r^\top\mathbf{U}_r = \mathbf{I}_r.$$

As relações correspondentes a cada coluna seguem diretamente dessas duas identidades matriciais. $\square$

6.5.2 Coordenadas das observações nas direções singulares à direita

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Pela Proposição 6.11,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações na base ortonormal

$$\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$$

do espaço linha

$$\mathcal{C}(\mathbf{X}^\top) \subseteq \mathbb{R}^p.$$

Como cada observação pertence a esse subespaço, as r coordenadas são suficientes para representá-la exatamente.

Se a linha i de $\mathbf{X}$ corresponde ao vetor

$$\mathbf{x}_i \in \mathbb{R}^p,$$

então

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Portanto, z_{ij} é a coordenada da observação i na direção singular $\mathbf{v}_j$.

A j -ésima coluna de $\mathbf{Z}$ é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Assim, $\mathbf{v}_j$ determina a direção utilizada para representar as observações, enquanto $\mathbf{u}_j$ descreve como as coordenadas correspondentes se distribuem entre as n unidades observacionais.

6.5.3 Coordenadas das variáveis nas direções singulares à esquerda

A relação dual é

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top.$$

Defina

$$\mathbf{W} = \mathbf{U}_r^\top \mathbf{X} \in \mathbb{R}^{r \times p}.$$

Cada coluna de $\mathbf{X}$ representa uma variável como vetor em $\mathbb{R}^n$. Se

$$\mathbf{x}^{(j)} \in \mathbb{R}^n$$

denota a j -ésima variável, então a j -ésima coluna de $\mathbf{W}$ contém suas coordenadas na base ortonormal

$$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$$

do espaço coluna

$$\mathcal{C}(\mathbf{X}) \subseteq \mathbb{R}^n.$$

Para a direção singular ℓ ,

$$\mathbf{u}_\ell^\top \mathbf{x}^{(j)} = d_\ell v_{j\ell}.$$

Portanto, os elementos de $\mathbf{V}_r$, escalonados pelos valores singulares, também descrevem as coordenadas das variáveis na base singular à esquerda.

As relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam, assim, a dualidade entre o espaço das observações e o espaço das variáveis.

6.5.4 Matrizes de Gram da matriz de dados

As duas matrizes de Gram associadas a $\mathbf{X}$ descrevem relações entre objetos diferentes.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

reúne os produtos internos entre as colunas de $\mathbf{X}$, isto é, entre as variáveis representadas como vetores em $\mathbb{R}^n$.

A matriz

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

reúne os produtos internos entre as linhas de $\mathbf{X}$, isto é, entre as observações representadas como vetores em $\mathbb{R}^p$.

Pela Proposição 6.4,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto, as duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ determina uma direção no espaço das observações;
- $\mathbf{u}_j \in \mathbb{R}^n$ determina uma direção no espaço das variáveis.

Essa dualidade também pode ser útil quando as dimensões da matriz são muito diferentes. Se

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Se

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

possui ordem menor.

Em ambos os casos, os valores próprios positivos são os mesmos e correspondem aos quadrados dos valores singulares de $\mathbf{X}$.

6.5.5 Representação exata das observações

Proposição 6.12 (Preservação da geometria pelas coordenadas singulares). *Seja*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de dados e defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Então,

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top$$

e

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Consequentemente, para quaisquer observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell,$$

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

Comprovação. Como

$$\mathbf{Z} = \mathbf{U}_r \mathbf{D}_r,$$

segue da SVD compacta que

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{Z} \mathbf{V}_r^\top.$$

Além disso,

$$\begin{aligned} \mathbf{Z} \mathbf{Z}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned}$$

Pela Proposição 6.4,

$$\mathbf{X} \mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Os elementos dessas duas matrizes são os produtos internos entre pares de observações. Logo,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Tomando $i = \ell$, obtém-se

$$\|\mathbf{x}_i\|^2 = \|\mathbf{z}_i\|^2.$$

Finalmente,

$$\begin{aligned}
\|\mathbf{x}_i - \mathbf{x}_\ell\|^2 &= \|\mathbf{x}_i\|^2 + \|\mathbf{x}_\ell\|^2 - 2\mathbf{x}_i^\top \mathbf{x}_\ell \\
&= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_\ell\|^2 - 2\mathbf{z}_i^\top \mathbf{z}_\ell \\
&= \|\mathbf{z}_i - \mathbf{z}_\ell\|^2.
\end{aligned}$$

□

A reconstrução de cada observação pode ser escrita como

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto,

$$\mathbf{x}_i \in \mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

as observações podem ser representadas exatamente por apenas r coordenadas, sem alteração de seus produtos internos, normas ou distâncias euclidianas.

Essa situação pode ocorrer mesmo quando $\mathbf{X}$ possui o maior posto possível para suas dimensões. Por exemplo, se

$$n < p$$

e

$$r = n,$$

a matriz possui posto linha completo, mas ainda assim

$$r < p.$$

Nesse caso, as observações ocupam um subespaço de dimensão r dentro de $\mathbb{R}^p$ e sua representação por $\mathbf{Z}$ é exata.

6.5.6 Centralização da matriz de dados

A posição da nuvem depende de seu centro. Para estudar os afastamentos em relação ao vetor de médias, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Proposição 6.13 (Vetores singulares à esquerda de uma matriz centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados centralizada, então

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r,$$

e as colunas da matriz de coordenadas

$$\mathbf{Z} = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

também possuem média igual a zero.

Comprovação. Como as colunas de $\mathbf{X}_c$ estão centralizadas,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD compacta,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui colunas ortonormais, segue que

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{z}_j = 0.$$

□

6.5.7 Antecipação: relação com a matriz de covariâncias amostral

A definição estatística e as propriedades da matriz de covariâncias amostral serão desenvolvidas nos capítulos posteriores dedicados à covariância e às estatísticas amostrais. Neste ponto, interessa apenas sua relação algébrica com a SVD da matriz centralizada.

Para $n \geq 2$, adotando temporariamente a notação

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtem-se o seguinte resultado.

Proposição 6.14 (Relação entre a SVD e a covariância amostral). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Consequentemente:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$ associados aos autovalores positivos;
- os autovalores positivos de $\mathbf{S}$ são

$$\lambda_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r;$$

- tem-se

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) = r.$$

Comprovação. Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \\ &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top, \end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

A expressão obtida é uma decomposição espectral de $\mathbf{S}$ em seu subespaço associado aos autovalores positivos. Portanto, os autovetores correspondentes são as colunas de $\mathbf{V}_r$ e os autovalores positivos são

$$\frac{d_j^2}{n-1}.$$

Como $\mathbf{D}_r$ possui exatamente r elementos diagonais positivos,

$$\text{posto}(\mathbf{S}) = r.$$

□

A centralização impõe ainda uma restrição ao posto. Como

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n - 1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n - 1, p).$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz de covariâncias amostral é necessariamente singular.

Essas relações serão retomadas posteriormente em sua formulação estatística. Aqui, elas mostram que a SVD da matriz centralizada determina diretamente a estrutura espectral da matriz de covariâncias amostral.

6.5.8 Magnitude quadrática da matriz centralizada

Proposição 6.15 (Magnitude quadrática da nuvem centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Além disso, se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

então

$$\|\mathbf{X}_c\|_F^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Consequentemente,

$$\sum_{j=1}^r d_j^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Comprovação. Pela Proposição 6.9,

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Por outro lado,

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1) \mathbf{S}.$$

Logo,

$$\begin{aligned} \|\mathbf{X}_c\|_F^2 &= \operatorname{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= (n-1) \operatorname{tr}(\mathbf{S}). \end{aligned}$$

□

Se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias das observações, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

Portanto,

$$\sum_{j=1}^r d_j^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

A soma dos quadrados dos valores singulares da matriz centralizada representa, assim, a soma quadrática total dos afastamentos das observações em relação ao centro da nuvem.

Como $\text{tr}(\mathbf{S})$ é a soma dos elementos diagonais de $\mathbf{S}$, ela corresponde à soma das variâncias amostrais das p variáveis.

A centralização é essencial para essa interpretação. Para uma matriz não centralizada,

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2$$

mede a soma dos quadrados das posições em relação à origem, e não a dispersão das observações em torno de seu vetor de médias.

Exemplo 6.7 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned}\mathbf{Z} &= \mathbf{X}\mathbf{V}_2 \\ &= \mathbf{U}_2\mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}.\end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das observações. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta fornece a representação exata

$$\mathbf{X} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Como todos os r componentes associados a valores singulares positivos são mantidos:

- a matriz é reconstruída exatamente;
- os produtos internos entre as observações são preservados;
- as normas das observações são preservadas;
- as distâncias euclidianas entre as observações são preservadas;

- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão menor pode ser construída conservando apenas os primeiros k pares singulares, com

$$k < r.$$

Nesse caso, componentes associados a valores singulares positivos são deliberadamente descartados e a reconstrução deixa de ser exata.

A distinção fundamental é, portanto:

- a **SVD compacta** omite dos fatores completos apenas direções associadas à parte nula da transformação e preserva exatamente a matriz;
- a **SVD truncada** descarta também componentes associados a valores singulares positivos e produz uma aproximação.

A forma expandida da SVD permitirá identificar separadamente a contribuição de cada componente singular e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta também pode ser expressa como uma soma de componentes matriciais associados aos pares singulares.

Proposição 6.16 (Forma expandida da SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

possui posto 1 e satisfaz

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

Comprovação. Escrevendo

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

tem-se

$$\begin{aligned} \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top. \end{aligned}$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Multiplicar por $d_j > 0$ não altera o posto, de modo que

$$\text{posto}(d_j \mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Para a norma espectral, se $\|\mathbf{x}\| = 1$,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top \mathbf{x}\| &= d_j |\mathbf{v}_j^\top \mathbf{x}| \|\mathbf{u}_j\| \\ &\leq d_j. \end{aligned}$$

A igualdade é atingida para

$$\mathbf{x} = \mathbf{v}_j.$$

Portanto,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = d_j.$$

Para a norma de Frobenius,

$$\begin{aligned}\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F^2 &= d_j^2 \operatorname{tr}(\mathbf{v}_j \mathbf{u}_j^\top \mathbf{u}_j \mathbf{v}_j^\top) \\ &= d_j^2 (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\ &= d_j^2.\end{aligned}$$

Logo,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

□

A expressão

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é denominada **forma expandida da SVD**.

Cada componente singular representa uma transformação de posto 1: a componente do vetor de entrada na direção $\mathbf{v}_j$ é multiplicada por d_j e enviada para a direção $\mathbf{u}_j$.

Como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0,$$

os componentes singulares estão ordenados de acordo com suas magnitudes nas normas espectral e de Frobenius.

6.6.1 Ortogonalidade dos componentes singulares

Proposição 6.17 (Ortogonalidade dos componentes singulares). *Para*

$$i \neq j,$$

os componentes singulares

$$d_i \mathbf{u}_i \mathbf{v}_i^\top$$

e

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius:

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

Comprovação. Pelo produto interno de Frobenius,

$$\begin{aligned} \left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F &= d_i d_j \operatorname{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\ &= d_i d_j (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i). \end{aligned}$$

Como os vetores singulares são ortonormais, para $i \neq j$,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Logo,

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

□

Como a forma expandida é uma soma de componentes ortogonais segundo o produto interno de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Essa igualdade fornece uma decomposição pitagórica da magnitude quadrática total da matriz entre seus componentes singulares.

6.6.2 SVD truncada na forma expandida

Retomando a Definição 6.5, a aproximação de posto k pode ser expressa diretamente a partir da forma expandida da SVD.

Se

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

então

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Assim, truncar a SVD corresponde a conservar as primeiras k parcelas singulares e descartar

$$\sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa representação permitirá quantificar o erro produzido pelo truncamento e estabelecer as propriedades de otimalidade de $\mathbf{A}_k$.

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.3 Erros produzidos pelo truncamento

Proposição 6.18 (Decomposição e erros da SVD truncada). *Se*

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r,$$

então

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Além disso,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0,$$

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2,$$

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Comprovação. Pela forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Subtraindo

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

obtém-se

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Pela Proposição 6.17, os componentes associados a índices diferentes são ortogonais segundo o produto interno de Frobenius. Como $\mathbf{A}_k$ utiliza os índices

$$1, \dots, k$$

e a diferença utiliza

$$k+1, \dots, r,$$

segue que

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Aplicando a decomposição pitagórica,

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Portanto,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Por outro lado, a matriz residual

$$\mathbf{A} - \mathbf{A}_k$$

possui valores singulares positivos

$$d_{k+1}, d_{k+2}, \dots, d_r.$$

Pela Proposição 6.9, sua norma espectral é igual ao maior desses valores:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

□

A proporção da magnitude quadrática de Frobenius preservada pela aproximação pode ser escrita como

$$\eta_k = \frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}.$$

A proporção descartada é

$$1 - \eta_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

Para uma matriz genérica, η_k mede exclusivamente a proporção de sua magnitude quadrática, segundo a norma de Frobenius, representada pelos primeiros k componentes singulares. Essa quantidade não deve ser interpretada automaticamente como proporção de variância ou de informação estatística.

Quando $\mathbf{A}$ é uma matriz de dados centralizada, entretanto,

$$\|\mathbf{A}\|_F^2$$

corresponde à soma quadrática total dos afastamentos das observações em relação ao centro da nuvem. Nesse contexto específico, η_k representa a proporção dessa dispersão quadrática preservada pelos primeiros k componentes singulares.

A norma espectral descreve outro aspecto do erro. Como

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1},$$

o primeiro valor singular descartado determina o maior erro produzido pelo truncamento sobre qualquer vetor unitário:

$$d_{k+1} = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

Esse máximo é atingido, por exemplo, na direção

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

Assim, a norma espectral mede um erro de pior caso, enquanto a norma de Frobenius agrega quadraticamente os erros associados a todos os componentes singulares descartados.

6.6.4 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.2 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub; Van Loan, 2013)

6.6.5 Aprofundamento: demonstração e unicidade da melhor aproximação

Leitura de aprofundamento

O Teorema de Eckart–Young–Mirsky estabelece a otimalidade da SVD truncada sem exigir que sua demonstração seja utilizada nas aplicações posteriores.

Nesta leitura de aprofundamento, demonstra-se a otimalidade separadamente nas normas espectral e de Frobenius e examina-se quando a melhor aproximação de posto reduzido é ou não única.

Comprovação. Considere inicialmente a norma espectral e uma matriz arbitrária

$$\tilde{\mathbf{A}}$$

com

$$\text{posto}(\tilde{\mathbf{A}}) \leq k.$$

Defina o subespaço

$$\mathcal{S}_{k+1} = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_{k+1} \}.$$

Como

$$\dim(\mathcal{S}_{k+1}) = k + 1$$

e a restrição de $\widetilde{\mathbf{A}}$ a esse subespaço possui imagem de dimensão no máximo k , existe um vetor unitário

$$\mathbf{x} \in \mathcal{S}_{k+1}$$

tal que

$$\widetilde{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Escreva

$$\mathbf{x} = \sum_{j=1}^{k+1} \alpha_j \mathbf{v}_j,$$

com

$$\sum_{j=1}^{k+1} \alpha_j^2 = 1.$$

Então,

$$\begin{aligned} \left\| (\mathbf{A} - \widetilde{\mathbf{A}}) \mathbf{x} \right\|^2 &= \left\| \mathbf{A} \mathbf{x} \right\|^2 \\ &= \sum_{j=1}^{k+1} d_j^2 \alpha_j^2 \\ &\geq d_{k+1}^2 \sum_{j=1}^{k+1} \alpha_j^2 \\ &= d_{k+1}^2. \end{aligned}$$

Logo,

$$\left\| \mathbf{A} - \widetilde{\mathbf{A}} \right\|_2 \geq d_{k+1}.$$

Para a SVD truncada,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Portanto, $\mathbf{A}_k$ atinge o limite inferior e é uma solução ótima na norma espectral.

Para a norma de Frobenius, considere o projetor ortogonal

$$\mathbf{P}$$

sobre o espaço coluna de $\tilde{\mathbf{A}}$. Como

$$\text{posto}(\tilde{\mathbf{A}}) \leq k,$$

tem-se

$$\text{posto}(\mathbf{P}) \leq k.$$

Além disso,

$$\mathbf{P}\tilde{\mathbf{A}} = \tilde{\mathbf{A}}.$$

A diferença pode ser decomposta como

$$\mathbf{A} - \tilde{\mathbf{A}} = (\mathbf{I}_q - \mathbf{P}) \mathbf{A} + (\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}).$$

As duas parcelas são ortogonais segundo o produto interno de Frobenius, pois a primeira possui colunas no complemento ortogonal de $\mathcal{C}(\mathbf{P})$, enquanto a segunda possui colunas em $\mathcal{C}(\mathbf{P})$.

Assim,

$$\begin{aligned} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 &= \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 \\ &\quad + \|\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 \\ &\geq \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2. \end{aligned}$$

A primeira parcela pode ser escrita como

$$\|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 = \|\mathbf{A}\|_F^2 - \|\mathbf{P}\mathbf{A}\|_F^2.$$

Considere uma base ortonormal

$$\mathbf{w}_1, \dots, \mathbf{w}_s, \quad s \leq k,$$

do espaço projetado por $\mathbf{P}$. Então,

$$\mathbf{P} = \sum_{i=1}^s \mathbf{w}_i \mathbf{w}_i^\top$$

e

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{i=1}^s \mathbf{w}_i^\top \mathbf{AA}^\top \mathbf{w}_i. \end{aligned}$$

Usando a decomposição espectral

$$\mathbf{AA}^\top = \sum_{j=1}^r d_j^2 \mathbf{u}_j \mathbf{u}_j^\top,$$

tem-se

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{j=1}^r d_j^2 \text{tr}(\mathbf{Pu}_j \mathbf{u}_j^\top) \\ &= \sum_{j=1}^r d_j^2 \mathbf{u}_j^\top \mathbf{Pu}_j. \end{aligned}$$

Defina

$$c_j = \mathbf{u}_j^\top \mathbf{Pu}_j = \|\mathbf{Pu}_j\|^2.$$

Como $\mathbf{P}$ é um projetor ortogonal,

$$0 \leq c_j \leq 1.$$

Além disso,

$$\begin{aligned}
\sum_{j=1}^r c_j &= \sum_{j=1}^r \mathbf{u}_j^\top \mathbf{P} \mathbf{u}_j \\
&\leq \text{tr}(\mathbf{P}) \\
&= \text{posto}(\mathbf{P}) \\
&\leq k.
\end{aligned}$$

Portanto,

$$\|\mathbf{P}\mathbf{A}\|_F^2 = \sum_{j=1}^r c_j d_j^2,$$

com

$$0 \leq c_j \leq 1$$

e

$$\sum_{j=1}^r c_j \leq k.$$

Como os valores singulares estão ordenados, sob as restrições,

$$0 \leq c_j \leq 1 \quad \text{e} \quad \sum_j c_j \leq k,$$

a soma ponderada é maximizada atribuindo peso 1 aos k maiores valores d_j^2 e peso 0 aos demais. Como

$$d_1^2 \geq \dots \geq d_r^2,$$

segue que

$$\|\mathbf{P}\mathbf{A}\|_F^2 \leq \sum_{j=1}^k d_j^2.$$

Portanto,

$$\begin{aligned}\|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &\geq \|\mathbf{A}\|_F^2 - \sum_{j=1}^k d_j^2 \\ &= \sum_{j=k+1}^r d_j^2.\end{aligned}$$

Para

$$\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^\top,$$

tem-se

$$\mathbf{P}\mathbf{A} = \mathbf{A}_k.$$

Além disso,

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Logo, $\mathbf{A}_k$ também atinge o limite inferior na norma de Frobenius. $\square$

O teorema mostra que nenhuma matriz de posto no máximo k pode apresentar erro menor que $\mathbf{A}_k$ nas duas normas consideradas.

Na norma espectral, o erro ótimo é determinado exclusivamente pelo primeiro valor singular descartado,

$$d_{k+1}.$$

Na norma de Frobenius, o erro ótimo depende de toda a parcela espectral descartada,

$$\sqrt{\sum_{j=k+1}^r d_j^2}.$$

6.6.5.1 Unicidade da aproximação

A otimalidade estabelecida pelo Teorema 6.2 não implica, em geral, que a matriz aproximante seja única. A situação depende também da norma considerada.

Na norma de Frobenius, a melhor aproximação de posto no máximo k é única quando há separação estrita entre os valores singulares que ficam em lados opostos do truncamento:

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o ponto de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de subespaços dentro desse bloco singular podem produzir aproximações ótimas distintas.

Na norma espectral, a matriz

$$\mathbf{A}_k$$

é sempre uma aproximação ótima, mas a aproximação ótima pode não ser única mesmo quando

$$d_k > d_{k+1}.$$

Isso ocorre porque outras matrizes de posto no máximo k podem produzir o mesmo erro máximo

$$d_{k+1}.$$

Portanto, a condição

$$d_k > d_{k+1}$$

garante unicidade da melhor aproximação na norma de Frobenius, mas não deve ser utilizada como critério geral de unicidade na norma espectral.

Quando

$$k \geq r,$$

não há truncamento de componentes singulares positivos e a representação exata é

$$\mathbf{A}_k = \mathbf{A},$$

com erro igual a zero.

6.6.6 Exemplo de aproximação de posto 1

Exemplo 6.8 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

Neste exemplo, as normas espectral e de Frobenius do erro coincidem porque a matriz residual possui apenas um valor singular positivo. Quando mais de um componente singular é descartado, os dois erros são, em geral, diferentes.

6.6.7 Aproximação de uma matriz de dados

A SVD truncada possui uma interpretação direta como projeção das observações em um subespaço de menor dimensão.

Proposição 6.19 (SVD truncada como projeção das observações). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados e

$$1 \leq k < r,$$

então sua aproximação truncada satisfaz

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X} \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{P}_k = \mathbf{V}_k \mathbf{V}_k^\top$$

é o projetor ortogonal sobre

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \},$$

cada linha de $\mathbf{X}_k$ é a projeção ortogonal da observação correspondente sobre $\mathcal{S}_k$.

Se

$$\mathbf{Z}_k = \mathbf{X}\mathbf{V}_k,$$

então

$$\mathbf{Z}_k = \mathbf{U}_k\mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k\mathbf{V}_k^\top.$$

Comprovação. Pela relação

$$\mathbf{X}\mathbf{V}_k = \mathbf{U}_k\mathbf{D}_k,$$

tem-se

$$\begin{aligned}\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top &= \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top \\ &= \mathbf{X}_k.\end{aligned}$$

Como as colunas de $\mathbf{V}_k$ são ortonormais,

$$\mathbf{P}_k = \mathbf{V}_k\mathbf{V}_k^\top$$

é o projetor ortogonal sobre $\mathcal{S}_k$.

Portanto, para cada observação $\mathbf{x}_i$,

$$\hat{\mathbf{x}}_{i,k} = \mathbf{P}_k\mathbf{x}_i$$

e, equivalentemente,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij}\mathbf{v}_j.$$

O resíduo correspondente é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij}\mathbf{v}_j.$$

□

A matriz

$$\mathbf{Z}_k \in \mathbb{R}^{n \times k}$$

fornece uma representação das observações em k coordenadas. A multiplicação por

$$\mathbf{V}_k^\top$$

reconstrói suas aproximações no espaço original $\mathbb{R}^p$.

Além disso,

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2 = \sum_{j=k+1}^r d_j^2.$$

Pelo Teorema 6.2, nenhuma matriz de posto no máximo k possui erro de reconstrução menor na norma de Frobenius. Em particular, entre as representações obtidas pela projeção das observações em subespaços lineares de dimensão no máximo k , o subespaço

$$\mathcal{S}_k = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

minimiza a soma dos erros quadráticos de reconstrução.

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a proporção da dispersão quadrática total da nuvem preservada pelas primeiras k direções singulares.

Essa relação será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, ela deve ser interpretada como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada e a pseudoinversa utilizam os mesmos componentes singulares com finalidades distintas.

Na aproximação de posto reduzido, componentes associados a valores singulares positivos são deliberadamente descartados:

$$\mathbf{A} \longrightarrow \mathbf{A}_k.$$

Na pseudoinversa, todos os componentes associados a valores singulares positivos são mantidos, mas os fatores de escala são invertidos:

$$d_j \longrightarrow \frac{1}{d_j}, \quad j = 1, \dots, r.$$

As direções associadas à parte nula da transformação não são invertidas.

Essa construção conduz à pseudoinversa de Moore–Penrose e, a partir dela, às soluções de sistemas lineares e problemas de mínimos quadrados.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Se $r \geq 1$, todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos. Portanto,

$$\mathbf{D}_r^{-1} = \text{diag} \left(\frac{1}{d_1}, \dots, \frac{1}{d_r} \right)$$

está bem definida.

Se $r = 0$, então $\mathbf{A} = \mathbf{0}$ e sua pseudoinversa será definida como a matriz nula de dimensão $p \times q$.

Definição 6.11 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

No caso $\mathbf{A} = \mathbf{0}$, define-se

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz os escalonamentos de $\mathbf{A}$ nas direções associadas aos valores singulares positivos e anula as componentes pertencentes a

$$\mathcal{N}(\mathbf{A}^\top).$$

Assim, ela atua como uma inversão entre os subespaços

$$\mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

nos quais a ação de $\mathbf{A}$ é não nula.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio de sua decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

então

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que cada autovalor não nulo é substituído por seu inverso e os autovalores nulos permanecem iguais a zero.

A definição baseada na SVD,

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

estende essa construção para qualquer matriz real, inclusive matrizes retangulares e não simétricas.

Quando $\mathbf{A}$ é quadrada e invertível,

$$r = p = q,$$

todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Portanto, a inversa usual constitui um caso particular da pseudoinversa.

6.7.2 Aprofundamento: caracterização de Moore–Penrose

Leitura de aprofundamento

A pseudoinversa foi definida anteriormente a partir da SVD. Existe também uma caracterização independente dessa decomposição: a pseudoinversa de Moore–Penrose é a única matriz que satisfaz simultaneamente quatro identidades algébricas.

Esta seção apresenta essas condições, verifica que a matriz construída pela SVD as satisfaz e demonstra sua unicidade. A caracterização é importante na teoria de inversas generalizadas, mas não é necessária para acompanhar as aplicações posteriores da pseudoinversa a projeções e mínimos quadrados.

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.3 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente o caso

$$\mathbf{A} = \mathbf{0}.$$

A matriz

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}$$

satisfaz imediatamente as quatro condições de Moore–Penrose.

Além disso, se uma matriz

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

satisfaz essas condições para $\mathbf{A} = \mathbf{0}$, a segunda condição fornece

$$\mathbf{GAG} = \mathbf{G}.$$

Como $\mathbf{A} = \mathbf{0}$,

$$\mathbf{GAG} = \mathbf{0},$$

e, portanto,

$$\mathbf{G} = \mathbf{0}.$$

Logo, a pseudoinversa também é única nesse caso.

Suponha agora

$$\mathbf{A} \neq \mathbf{0}.$$

Então

$$r = \text{posto}(\mathbf{A}) \geq 1,$$

e, pela SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Então,

$$\begin{aligned} \mathbf{A} \mathbf{A}^+ \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{A}. \end{aligned}$$

De modo semelhante,

$$\begin{aligned} \mathbf{A}^+ \mathbf{A} \mathbf{A}^+ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{A}^+. \end{aligned}$$

Além disso,

$$\mathbf{A} \mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top,$$

que são matrizes simétricas. Portanto, a matriz definida pela SVD satisfaz as quatro condições de Moore–Penrose.

Para demonstrar a unicidade, suponha que

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

também satisfaça as quatro condições.

A matriz $\mathbf{A} \mathbf{G}$ é simétrica e

$$\begin{aligned} (\mathbf{A} \mathbf{G})^2 &= \mathbf{A} \mathbf{G} \mathbf{A} \mathbf{G} \\ &= (\mathbf{A} \mathbf{G} \mathbf{A}) \mathbf{G} \\ &= \mathbf{A} \mathbf{G}. \end{aligned}$$

Logo, $\mathbf{A} \mathbf{G}$ é um projetor ortogonal.

Sua imagem está contida em $\mathcal{C}(\mathbf{A})$. Além disso, se

$$\mathbf{y} = \mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{G}\mathbf{y} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x} = \mathbf{y}.$$

Portanto,

$$\mathbf{A}\mathbf{G} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top.$$

De maneira análoga, $\mathbf{G}\mathbf{A}$ é simétrica e idempotente.

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Reciprocamente, se

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0},$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{G}\mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Como $\mathbf{G}\mathbf{A}$ é um projetor ortogonal,

$$\mathbf{G}\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})^\perp} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top.$$

Da condição

$$\mathbf{GAG} = \mathbf{G},$$

segue que

$$\mathcal{C}(\mathbf{G}) \subseteq \mathcal{C}(\mathbf{GA}) = \mathcal{C}(\mathbf{A}^\top).$$

Considere agora um vetor singular à esquerda $\mathbf{u}_j$, com $j \leq r$. Como

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

tem-se

$$\mathbf{AGu}_j = \mathbf{u}_j.$$

Como

$$\mathbf{Gu}_j \in \mathcal{C}(\mathbf{A}^\top),$$

esse vetor pode ser escrito como

$$\mathbf{Gu}_j = \sum_{\ell=1}^r c_\ell \mathbf{v}_\ell.$$

Aplicando $\mathbf{A}$,

$$\mathbf{u}_j = \sum_{\ell=1}^r c_\ell d_\ell \mathbf{u}_\ell.$$

Pela unicidade das coordenadas na base ortonormal,

$$c_\ell = \begin{cases} 1/d_j, & \ell = j, \\ 0, & \ell \neq j. \end{cases}$$

Portanto,

$$\mathbf{Gu}_j = \frac{1}{d_j} \mathbf{v}_j.$$

Considere, por fim,

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top).$$

Como $\mathbf{A}\mathbf{G}$ projeta sobre $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Além disso,

$$\mathbf{G}\mathbf{u} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \cap \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

segue que

$$\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Assim, $\mathbf{G}$ atua sobre a base ortonormal formada pelas colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ exatamente como

$$\mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Logo,

$$\mathbf{G} = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top = \mathbf{A}^+.$$

Portanto, a pseudoinversa de Moore–Penrose existe e é única. □

6.7.3 Pseudoinversa e projetores

Os produtos envolvendo $\mathbf{A}$ e sua pseudoinversa recuperam os projetores ortogonais dos quatro espaços fundamentais.

Proposição 6.20 (Projetores determinados pela pseudoinversa). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

então

$$\mathbf{A} \mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Consequentemente,

$$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

Comprovação. Pela definição da pseudoinversa,

$$\begin{aligned} \mathbf{A} \mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Pela Proposição 6.8,

$$\mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Analogamente,

$$\begin{aligned}\mathbf{A}^+ \mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.\end{aligned}$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathcal{C}(\mathbf{A}^\top)^\perp = \mathcal{N}(\mathbf{A}),$$

os projetores sobre os complementos ortogonais são

$$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

□

A Tabela 6.6 resume essas relações.

Tabela 6.6: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A} \mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+ \mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A}$	$\mathcal{N}(\mathbf{A})$

Os dois produtos atuam em espaços diferentes. A matriz

$$\mathbf{A}\mathbf{A}^+ \in \mathbb{R}^{q \times q}$$

atua no contradomínio e seleciona a componente pertencente à imagem da transformação.

Por outro lado,

$$\mathbf{A}^+\mathbf{A} \in \mathbb{R}^{p \times p}$$

atua no domínio e seleciona a componente pertencente ao espaço linha, isto é, ao complemento ortogonal do núcleo de $\mathbf{A}$.

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

A pseudoinversa permite caracterizar a compatibilidade do sistema, descrever todas as suas soluções e identificar aquela de menor norma.

Proposição 6.21 (Sistemas compatíveis pela pseudoinversa). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

é compatível se, e somente se,

$$\mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Quando o sistema é compatível, o conjunto de todas as soluções é

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

em que

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Entre todas essas soluções,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única de menor norma euclidiana.

Se

$$r = p,$$

o núcleo de $\mathbf{A}$ é trivial e a solução é única.

Comprovação. O sistema é compatível exatamente quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Pela Proposição 6.20,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Suponha que o sistema seja compatível. Então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se $\mathbf{x}$ é qualquer outra solução,

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x}_0.$$

Logo,

$$\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0},$$

e, portanto,

$$\mathbf{x} - \mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma}.$$

Além disso,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\boldsymbol{\gamma} \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\mathbf{x}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\boldsymbol{\gamma}\|^2.$$

A menor norma é obtida somente quando

$$\boldsymbol{\gamma} = \mathbf{0}.$$

Portanto,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de menor norma.

Finalmente, se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e nenhuma componente adicional pode ser acrescentada à solução. □

6.7.5 Mínimos quadrados

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

pode-se procurar um vetor $\mathbf{x}$ cuja imagem $\mathbf{Ax}$ esteja o mais próxima possível de $\mathbf{b}$.

O problema é

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o erro mínimo é zero e o problema coincide com a resolução de um sistema compatível.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe solução exata e busca-se a melhor aproximação possível dentro do espaço coluna de $\mathbf{A}$.

Definição 6.12 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma **solução de mínimos quadrados** de

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

A pseudoinversa fornece diretamente todas as soluções desse problema.

Proposição 6.22 (Mínimos quadrados pela pseudoinversa). *Para qualquer*

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor ajustado de mínimos quadrados é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b}.$$

O resíduo é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+)\mathbf{b}$$

e satisfaz

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top),$$

ou, equivalentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Consequentemente, uma solução de mínimos quadrados satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

O conjunto de todas as soluções de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todos os minimizadores,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é o único de menor norma euclidiana.

Comprovação. Pela Proposição 6.20,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{A}\mathbf{A}^+.$$

Defina

$$\hat{\mathbf{b}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

e

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}}.$$

Como $\hat{\mathbf{b}}$ é a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$,

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathbf{b} - \mathbf{A}\mathbf{x} = \mathbf{r} + (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}),$$

em que

$$\mathbf{r} \perp (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}).$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 = \|\mathbf{r}\|^2 + \|\hat{\mathbf{b}} - \mathbf{Ax}\|^2.$$

Assim,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 \geq \|\mathbf{r}\|^2,$$

com igualdade se, e somente se,

$$\mathbf{Ax} = \hat{\mathbf{b}}.$$

Como

$$\mathbf{A}(\mathbf{A}^+\mathbf{b}) = \mathbf{AA}^+\mathbf{b} = \hat{\mathbf{b}},$$

o vetor

$$\mathbf{A}^+\mathbf{b}$$

é uma solução de mínimos quadrados.

Além disso, um vetor $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados se, e somente se,

$$\mathbf{A}\hat{\mathbf{x}} = \hat{\mathbf{b}} = \mathbf{AA}^+\mathbf{b}.$$

Nesse caso, seu resíduo é

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} = \mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Portanto,

$$\mathbf{A}^\top(\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0},$$

o que equivale às equações normais

$$\mathbf{A}^\top\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^\top\mathbf{b}.$$

Reciprocamente, se $\hat{\mathbf{x}}$ satisfaz as equações normais, então

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathbf{A}\hat{\mathbf{x}} \in \mathcal{C}(\mathbf{A}),$$

a decomposição

$$\mathbf{b} = \mathbf{A}\hat{\mathbf{x}} + (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}})$$

é ortogonal. Pela unicidade da projeção ortogonal,

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \hat{\mathbf{b}}.$$

Logo, $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados.

Para caracterizar todos os minimizadores, observe que

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

se, e somente se,

$$\mathbf{A}(\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b}) = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b} \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

com

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Finalmente,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\gamma \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\hat{\mathbf{x}}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\gamma\|^2.$$

A menor norma é obtida unicamente quando

$$\gamma = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de mínimos quadrados de menor norma. □

A decomposição geométrica correspondente é

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Como essas parcelas são ortogonais,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.5.1 Caso de posto coluna completo

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível, e

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Portanto,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

6.7.5.2 Caso de posto linha completo

Se

$$r = q \leq p,$$

então

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Logo, para todo

$$\mathbf{b} \in \mathbb{R}^q,$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

é compatível.

Nesse caso,

$$\mathbf{AA}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{AA}^\top)^{-1}.$$

A solução

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a solução exata de menor norma.

6.7.6 Expressão da solução nas direções singulares

A forma expandida da pseudoinversa permite interpretar diretamente a solução de menor norma nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.7 Aprofundamento: instabilidade e pseudoinversa truncada

Leitura de aprofundamento

A pseudoinversa inverte os valores singulares positivos. Como consequência, valores singulares muito pequenos podem produzir grandes fatores de amplificação na solução. Esta seção examina a sensibilidade da pseudoinversa a perturbações e apresenta a pseudoinversa truncada como uma forma de evitar a inversão de algumas direções singulares. Essas ideias pertencem ao estudo de problemas inversos e regularização e não são necessárias para acompanhar os resultados centrais de mínimos quadrados desenvolvidos neste capítulo.

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned}\Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j.\end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Como os valores singulares positivos de $\mathbf{A}^+$ são

$$\frac{1}{d_r} \geq \dots \geq \frac{1}{d_1},$$

tem-se, para $r \geq 1$,

$$\|\mathbf{A}^+\|_2 = \frac{1}{d_r}.$$

Consequentemente,

$$\|\Delta \hat{\mathbf{x}}\| \leq \frac{1}{d_r} \|\varepsilon\|.$$

O menor valor singular positivo controla, portanto, a maior amplificação possível de uma perturbação pela pseudoinversa.

Esse comportamento relaciona:

- valores singulares positivos pequenos;
- forte amplificação nas direções correspondentes da pseudoinversa;
- sensibilidade a perturbações;
- instabilidade de problemas inversos.

Quando $\mathbf{A}$ possui posto máximo, um menor valor singular muito pequeno em relação a d_1 corresponde também a um número de condição elevado. Se a matriz não possui posto máximo, o número de condição definido anteriormente é infinito, enquanto a pseudoinversa continua invertendo somente os valores singulares positivos.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.7.1 Pseudoinversa truncada

Considere a aproximação truncada

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Sua pseudoinversa de Moore–Penrose é

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

Ela pode ser utilizada como uma inversão truncada de $\mathbf{A}$, conservando somente os k maiores valores singulares.

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.8 Exemplo com o sistema condutor

Exemplo 6.9 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuando os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned}
\hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\
&= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\
&= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}.
\end{aligned}$$

O vetor ajustado é

$$\begin{aligned}
\hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\
&= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\
&= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\begin{aligned}
\mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\
&= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}.
\end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão dos fatores de escala associados aos valores singulares positivos;
- anulação das componentes pertencentes a $\mathcal{N}(\mathbf{A}^\top)$;
- construção dos projetores sobre $\mathcal{C}(\mathbf{A})$ e $\mathcal{C}(\mathbf{A}^\top)$;
- solução de sistemas lineares compatíveis;
- seleção da solução exata de menor norma quando há não unicidade;
- solução de problemas de mínimos quadrados;
- seleção da solução de mínimos quadrados de menor norma quando há vários minimizadores.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares estende a ideia de decomposição espectral a qualquer matriz real. Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existe uma decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo d_j ,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

Se

$$r = \text{posto}(\mathbf{A}),$$

a SVD compacta é

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r), \quad d_1 \geq \dots \geq d_r > 0.$$

A SVD compacta é uma representação exata. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

descarta parcelas associadas a valores singulares positivos e produz uma aproximação de posto reduzido.

A construção da SVD decorre das decomposições espectrais das duas matrizes de Gram:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Seus autovalores positivos são

$$d_1^2, \dots, d_r^2.$$

Assim, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio.

Geometricamente, a imagem da bola unitária é um elipsoide de dimensão r contido em

$$\mathcal{C}(\mathbf{A}),$$

com semieixos

$$d_1 \mathbf{u}_1, \dots, d_r \mathbf{u}_r.$$

Os valores singulares medem, portanto, os fatores de escala nas direções singulares. Em particular,

$$\|\mathbf{A}\|_2 = d_1,$$

de modo que o maior valor singular é o maior fator de ampliação produzido pela transformação.

A SVD também fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \},$$

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \},$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_r \},$$

e

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{v}_{r+1}, \dots, \mathbf{v}_p \}.$$

Consequentemente,

$$\dim(\mathcal{N}(\mathbf{A})) = p - r$$

e

$$\dim(\mathcal{N}(\mathbf{A}^\top)) = q - r.$$

As normas espectral e de Frobenius possuem representações simples em termos dos valores singulares:

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a SVD compacta fornece

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Como

$$\mathbf{X} = \mathbf{Z} \mathbf{V}_r^\top,$$

essa representação é exata quando são mantidos todos os r componentes singulares positivos.

Além disso,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top,$$

de modo que a representação compacta preserva os produtos internos, as normas e as distâncias euclidianas entre as observações.

Analogamente,

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top$$

fornece as coordenadas das variáveis nas direções singulares à esquerda.

Quando a matriz de dados está centralizada,

$$\mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Adotando a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Assim, os vetores singulares à direita de $\mathbf{X}_c$ determinam as direções espectrais associadas aos autovalores positivos de $\mathbf{S}$, enquanto

$$\frac{d_j^2}{n-1}$$

são os autovalores positivos correspondentes.

Essa relação antecipa uma das principais conexões entre a SVD e as técnicas de redução de dimensionalidade que serão desenvolvidas posteriormente.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

representa a matriz como uma soma de componentes singulares de posto 1, ortogonais entre si segundo o produto interno de Frobenius.

Na norma de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

é uma decomposição pitagórica da magnitude quadrática total da matriz.

O Teorema de Eckart–Young–Mirsky estabelece que

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é uma solução do problema de melhor aproximação de $\mathbf{A}$ entre todas as matrizes de posto no máximo k , tanto na norma espectral quanto na norma de Frobenius. Os erros mínimos são

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A norma espectral mede o maior erro remanescente em uma direção unitária, enquanto a norma de Frobenius agrega quadraticamente todas as parcelas descartadas.

A pseudoinversa de Moore–Penrose é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

com $\mathbf{A}^+ = \mathbf{0}$ quando $\mathbf{A} = \mathbf{0}$.

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução de mínimos quadrados de menor norma.

Quando

$$r < p,$$

podem existir outros minimizadores, obtidos pela adição de componentes pertencentes a

$$\mathcal{N}(\mathbf{A}).$$

A pseudoinversa seleciona, entre todos eles, o único vetor de menor norma euclidiana.

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b},$$

isto é, a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$, enquanto o resíduo

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+) \mathbf{b}$$

pertence a

$$\mathcal{N}(\mathbf{A}^\top).$$

A Tabela 6.7 reúne as relações principais.

Tabela 6.7: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Utiliza bases ortonormais completas no domínio e no contradomínio
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata usando somente os componentes associados aos valores singulares positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Relaciona uma direção do domínio a uma direção do contradomínio

Objeto	Expressão	Interpretação
Matrizes de Gram	$\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$	Determinam os quadrados dos valores singulares e os vetores singulares correspondentes
Posto	$r = \#\{j : d_j > 0\}$	Dimensão da imagem da transformação
Norma espectral	$\ \mathbf{A}\ _2 = d_1$	Maior fator de ampliação da transformação
Norma de Frobenius	$\ \mathbf{A}\ _F^2 = \sum_{j=1}^r d_j^2$	Magnitude quadrática total da matriz
Coordenadas das observações	$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$	Representação das observações nas direções singulares à direita
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$	Aproximação ótima de posto no máximo k
Erro espectral	$\ \mathbf{A} - \mathbf{A}_k\ _2 = d_{k+1}$	Maior erro do truncamento sobre vetores unitários
Erro de Frobenius	$\ \mathbf{A} - \mathbf{A}_k\ _F^2 = \sum_{j=k+1}^r d_j^2$	Magnitude quadrática total dos componentes descartados
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$	Inverte os fatores de escala associados aos valores singulares positivos
Projeter no espaço coluna	$\mathbf{A} \mathbf{A}^+$	Projeta sobre $\mathcal{C}(\mathbf{A})$
Projeter no espaço linha	$\mathbf{A}^+ \mathbf{A}$	Projeta sobre $\mathcal{C}(\mathbf{A}^\top)$
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}$	Seleciona a solução de mínimos quadrados de menor norma

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir as formas completa, compacta e truncada da SVD;
- diferenciar uma representação compacta exata de uma aproximação truncada de posto reduzido;
- relacionar a SVD às decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$;
- interpretar geometricamente os valores e vetores singulares;
- identificar o posto e os quatro espaços fundamentais por meio da SVD;
- construir os projetores ortogonais associados aos espaços fundamentais;
- calcular e interpretar as normas espectral e de Frobenius a partir dos valores singulares;
- interpretar a dualidade entre observações e variáveis em uma matriz de dados;
- representar exatamente as observações em coordenadas singulares e compreender a preservação de produtos internos e distâncias;

- relacionar a SVD de uma matriz centralizada à estrutura espectral de sua matriz de covariâncias amostral;
- representar uma matriz como soma de componentes singulares ortogonais de posto 1;
- construir aproximações de posto reduzido e determinar seus erros nas normas espectral e de Frobenius;
- aplicar o Teorema de Eckart–Young–Mirsky;
- construir e interpretar a pseudoinversa de Moore–Penrose;
- distinguir solução exata, solução de mínimos quadrados e solução de mínimos quadrados de menor norma;
- interpretar mínimos quadrados como um problema de projeção ortogonal.

Ideia central do capítulo

A Decomposição em Valores Singulares descreve uma matriz por meio de pares de direções ortonormais no domínio e no contradomínio e dos fatores de escala que relacionam essas direções. Essa estrutura revela o posto e os espaços fundamentais, fornece representações exatas ou aproximadas de menor dimensão e permite construir projetores, pseudoinversas e soluções de mínimos quadrados.

A SVD encerra o percurso dedicado às principais estruturas de Álgebra Linear utilizadas neste módulo. Matrizes, espaços vetoriais, transformações lineares, decomposição espectral e SVD fornecem, em conjunto, a base geométrica e matricial para representar estruturas multivariadas.

O próximo capítulo desenvolve **Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada**. Gradientes, Hessianas, multiplicadores de Lagrange, diferenciais matriciais, traços, determinantes e integrais completarão os fundamentos matemáticos necessários para formular problemas de otimização, estimação e transformação de variáveis nos capítulos seguintes.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Neste capítulo, salvo indicação em contrário, $\|\cdot\|$ aplicada a vetores denota a norma euclidiana definida em Definição 1.10.

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2,$$

em que $\|\cdot\|_F$ denota a norma de Frobenius definida em Definição 6.7.

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{A}\mathbf{X}\mathbf{B}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Representação de primeira ordem
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a forma da transformação linear que representa localmente a variação da função e, conseqüentemente, a dimensão do gradiente, da Jacobiana ou do operador diferencial utilizado para representá-la.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa o incremento utilizado como argumento da transformação linear que define o diferencial. Assim,

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}$$

é linear em $d\mathbf{x}$.

A notação diferencial é frequentemente interpretada de maneira informal como uma variação infinitesimal. Formalmente, porém, o diferencial é a aplicação linear que fornece a parte de primeira ordem da variação da função.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana estão associados à mesma ideia de aproximação linear local, mas correspondem a contradomínios diferentes. Para uma função escalar, o gradiente fornece a representação vetorial da aplicação linear que define o diferencial. Para uma função vetorial, a Jacobiana fornece a representação matricial dessa aplicação linear.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Proposição 7.1 (Direções de maior crescimento e redução). *Se f é diferenciável em $\mathbf{x}$ e*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior taxa de redução de primeira ordem ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

Comprovação. Pelo Teorema 1.1,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. Aplicando o mesmo argumento à direção oposta, obtém-se o resultado para a maior taxa de redução de primeira ordem. $\square$

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação de primeira ordem não distingue direções de crescimento ou redução, e o comportamento local passa a depender de termos de ordem superior.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^\top \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

Suponha que as derivadas parciais das componentes de $\mathbf{g}$ existam no ponto $\mathbf{x}$. A matriz Jacobiana de $\mathbf{g}$ nesse ponto é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \cdots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} g_1 \\ g_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

Assim, a parte linear local de uma transformação afim é exatamente a matriz $\mathbf{A}$, enquanto o termo de translação desaparece na diferenciação.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.1 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x})) \mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem do produto reflete a composição das aplicações lineares: sobre uma perturbação $\mathbf{h}_{\mathbf{x}} \in \mathbb{R}^p$, atua primeiro $\mathbf{J}_{\mathbf{g}}(\mathbf{x})$ e, sobre o resultado, atua $\mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x}))$. Por isso, na representação matricial, a Jacobiana de $\mathbf{h}$ aparece à esquerda.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})^{\top} \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^{\top} \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função com derivadas parciais de segunda ordem no ponto considerado. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

O segundo diferencial é uma forma quadrática no incremento $d\mathbf{x}$ e descreve a contribuição local de segunda ordem da função.

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a segunda taxa de variação de f ao longo da reta que passa por $\mathbf{x}$ na direção $\mathbf{u}$ e fornece a medida de curvatura direcional utilizada neste capítulo.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned}\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2.\end{aligned}$$

Ela é positiva para todo vetor não nulo. Para vetores unitários, a segunda taxa de variação é maior nas direções com maior componente em módulo no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^{\top} (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2} \right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2 \left(x_2 - \frac{1}{2} \right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.2 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0). \end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a variação local de primeira ordem;
- a Hessiana determina a variação local de segunda ordem.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece. Se a forma quadrática associada à Hessiana é não degenerada, ela fornece o termo dominante da variação local. Quando essa forma se anula em alguma direção, termos de ordem superior podem ser necessários para determinar o comportamento da função.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Proposição 7.2 (Condição necessária de primeira ordem). *Se f é diferenciável em um ponto interior $\mathbf{x}^*$ de seu domínio e possui nesse ponto um máximo ou mínimo local, então*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Comprovação. Se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \neq \mathbf{0},$$

considere a direção unitária

$$\mathbf{u} = \frac{\nabla_{\mathbf{x}} f(\mathbf{x}^*)}{\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\|}.$$

Então,

$$D_{\mathbf{u}} f(\mathbf{x}^*) = \|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| > 0,$$

enquanto

$$D_{-\mathbf{u}} f(\mathbf{x}^*) = -\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| < 0.$$

Assim, existem direções locais de aumento e de redução, o que contradiz a existência de um extremo local interior. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

□

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

tem-se

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

A recíproca da proposição anterior não é verdadeira em geral: um ponto estacionário pode ser mínimo local, máximo local ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.3 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável em uma vizinhança de um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^$ é um mínimo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^$ é um máximo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*)$$

é indefinida, então $\mathbf{x}^$ é um ponto de sela.*

Se a Hessiana é apenas semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)

Comprovação. Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Considere inicialmente

$$\mathbf{H} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Como $\mathbf{H}$ é simétrica e positiva definida, seu menor autovalor satisfaz

$$\lambda_{\min}(\mathbf{H}) > 0.$$

Portanto,

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} \geq \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2.$$

Além disso,

$$o(\|\mathbf{h}\|^2) = \varepsilon(\mathbf{h}) \|\mathbf{h}\|^2,$$

com

$$\varepsilon(\mathbf{h}) \rightarrow 0$$

quando $\mathbf{h} \rightarrow \mathbf{0}$.

Logo, para $\mathbf{h}$ suficientemente pequeno,

$$|\varepsilon(\mathbf{h})| < \frac{1}{4} \lambda_{\min}(\mathbf{H}).$$

Assim,

$$\begin{aligned} f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) &\geq \frac{1}{2} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 - \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &= \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &> 0 \end{aligned}$$

para todo $\mathbf{h} \neq \mathbf{0}$ suficientemente pequeno. Portanto, $\mathbf{x}^*$ é um mínimo local estrito.

O caso de Hessiana negativa definida é obtido aplicando o mesmo argumento a $-f$, produzindo um máximo local estrito.

Se a Hessiana é indefinida, existem vetores unitários $\mathbf{u}_1$ e $\mathbf{u}_2$ tais que

$$\mathbf{u}_1^\top \mathbf{H} \mathbf{u}_1 > 0$$

e

$$\mathbf{u}_2^\top \mathbf{H} \mathbf{u}_2 < 0.$$

Considere perturbações da forma

$$\mathbf{h} = t\mathbf{u}_j.$$

Então,

$$f(\mathbf{x}^* + t\mathbf{u}_j) - f(\mathbf{x}^*) = \frac{1}{2}t^2\mathbf{u}_j^\top \mathbf{H}\mathbf{u}_j + o(t^2).$$

Para $|t|$ suficientemente pequeno, o sinal dessa diferença coincide com o sinal da forma quadrática. Assim, a função assume valores maiores que

$$f(\mathbf{x}^*)$$

em uma direção e menores em outra, arbitrariamente próximos de $\mathbf{x}^*$. Portanto, $\mathbf{x}^*$ é um ponto de sela. $\square$

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0, 0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1-t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, conjuntos afins como hiperplanos, bolas e regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.4 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.5 (Critério da Hessiana para convexidade). *Considere uma função*

$$f : \mathcal{C} \longrightarrow \mathbb{R}$$

duas vezes continuamente diferenciável em um conjunto convexo aberto

$$\mathcal{C} \subseteq \mathbb{R}^p.$$

Então, f é convexa em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Analogamente, f é côncava em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Além disso, se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa. Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente côncava.

(Boyd; Vandenberghe, 2004)

Comprovação. Considere dois pontos distintos

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e defina

$$g(t) = f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})), \quad 0 \leq t \leq 1.$$

Como $\mathcal{C}$ é convexo, todo o segmento entre $\mathbf{x}$ e $\mathbf{y}$ pertence a $\mathcal{C}$.

Pela regra da cadeia,

$$g''(t) = (\mathbf{y} - \mathbf{x})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) (\mathbf{y} - \mathbf{x}).$$

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{z}) \succeq \mathbf{0}$$

para todo $\mathbf{z} \in \mathcal{C}$, então

$$g''(t) \geq 0,$$

e, portanto, g é convexa em $[0, 1]$. Como isso vale para qualquer segmento contido em $\mathcal{C}$, f é convexa.

Reciprocamente, se f é convexa, então a restrição de f a qualquer reta é convexa. Para qualquer

$$\mathbf{x} \in \mathcal{C}$$

e qualquer direção

$$\mathbf{u} \in \mathbb{R}^p,$$

considere

$$h(t) = f(\mathbf{x} + t\mathbf{u})$$

para t suficientemente próximo de zero. A convexidade de h implica

$$h''(0) \geq 0.$$

Como

$$h''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u},$$

tem-se

$$\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u} \geq 0$$

para todo $\mathbf{u}$. Logo,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}.$$

O resultado para funções côncavas segue aplicando o argumento a $-f$.

Se a Hessiana é positiva definida em todo ponto, então, para $\mathbf{x} \neq \mathbf{y}$,

$$g''(t) > 0$$

ao longo do segmento. Logo, g é estritamente convexa, e portanto f é estritamente convexa. O caso de Hessiana negativa definida é análogo. $\square$

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

A condição

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

em todo o domínio é suficiente para convexidade estrita, mas não é necessária. Uma função estritamente convexa pode possuir Hessiana singular em pontos isolados. Por exemplo,

$$f(x) = x^4$$

é estritamente convexa em $\mathbb{R}$, embora

$$f''(0) = 0.$$

7.4.5 Consequências para otimização

Proposição 7.3 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa e existe um ponto estacionário $\mathbf{x}^$, então esse ponto é o único minimizador global. (Boyd; Vandenberghe, 2004)*

Comprovação. Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$. $\square$

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

De fato, como $\mathbf{A}$ é simétrica,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}).$$

Assim, existe

$$\mathbf{z} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{b}^\top \mathbf{z} \neq 0.$$

Ao longo da reta

$$\mathbf{x} = t\mathbf{z},$$

o termo quadrático é nulo e

$$f(t\mathbf{z}) = -t\mathbf{b}^\top \mathbf{z} + c,$$

que pode tender a $-\infty$ escolhendo o sinal apropriado de t .

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

A Proposição 7.2 estabelece a condição necessária de primeira ordem para extremos locais interiores, enquanto o Teorema 7.3 utiliza a Hessiana para classificar pontos estacionários quando o teste de segunda ordem é conclusivo.

No caso convexo, a Proposição 7.3 mostra que um ponto estacionário é minimizador global. Esses resultados fornecem as condições de otimalidade; a questão seguinte é construir um procedimento iterativo para localizar esses pontos.

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top (\mathbf{x} - \mathbf{x}^{(t)}) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}). \end{aligned}$$

Defina

$$\mathbf{g}^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$$

e

$$\mathbf{H}^{(t)} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}).$$

Escrevendo

$$\mathbf{d} = \mathbf{x} - \mathbf{x}^{(t)},$$

o modelo quadrático local pode ser representado por

$$m_t(\mathbf{d}) = f(\mathbf{x}^{(t)}) + (\mathbf{g}^{(t)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{H}^{(t)} \mathbf{d}.$$

Seu gradiente em relação a $\mathbf{d}$ é

$$\nabla_{\mathbf{d}} m_t(\mathbf{d}) = \mathbf{g}^{(t)} + \mathbf{H}^{(t)} \mathbf{d}.$$

Se

$$\mathbf{H}^{(t)} \succ \mathbf{0},$$

o modelo quadrático é estritamente convexo e possui um único minimizador. Esse minimizador, denominado **direção de Newton**, satisfaz

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}.$$

Quando $\mathbf{H}^{(t)}$ é invertível,

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

A atualização de Newton com passo completo é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)},$$

ou, equivalentemente,

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver o sistema linear

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

sem calcular explicitamente a inversa da Hessiana.

Se a Hessiana é apenas invertível, mas não positiva definida, a solução desse sistema é um ponto estacionário do modelo quadrático, mas pode não ser seu minimizador. Nesse caso, a direção de Newton também pode deixar de ser uma direção de descida para a função original.

Proposição 7.4 (Direção de Newton como direção de descida). *Suponha que*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) \neq \mathbf{0}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \succ \mathbf{0}.$$

Então a direção de Newton $\mathbf{d}^{(t)}$ é uma direção de descida para f em $\mathbf{x}^{(t)}$, isto é,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

Comprovação. Como

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)},$$

tem-se

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} = -(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

Como $\mathbf{H}^{(t)} \succ \mathbf{0}$, também

$$(\mathbf{H}^{(t)})^{-1} \succ \mathbf{0}.$$

Logo, para $\mathbf{g}^{(t)} \neq \mathbf{0}$,

$$(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)} > 0,$$

e, portanto,

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

□

O passo completo corresponde a

$$\alpha_t = 1.$$

Uma forma mais geral da atualização é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \alpha_t \mathbf{d}^{(t)}, \quad 0 < \alpha_t \leq 1.$$

A escolha de $\alpha_t < 1$ produz um passo de Newton amortecido. Esse recurso pode ser utilizado quando o modelo quadrático local ainda não representa adequadamente a função ao longo de um passo completo.

Assim, a construção da direção e a escolha do comprimento da etapa são operações distintas. Métodos numéricos de otimização costumam combinar a direção de Newton com procedimentos de controle da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana constante e positiva definida, uma etapa completa de Newton conduz exatamente ao único minimizador,

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b},$$

independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, as linhas da Jacobiana das restrições são linearmente independentes. O espaço tangente ao conjunto viável é então

$$\mathcal{T}_{\mathbf{x}} = \mathcal{N}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})).$$

Portanto, uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

O espaço normal correspondente é

$$\mathcal{T}_{\mathbf{x}}^{\perp} = \mathcal{C}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})^{\top}),$$

isto é, o espaço gerado pelos gradientes das restrições.

Em um ótimo local regular $\mathbf{x}^*$, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{T}_{\mathbf{x}^*}.$$

Consequentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{T}_{\mathbf{x}^*}^\perp = \mathcal{C} \left[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \right].$$

7.6.1 Multiplicadores de Lagrange

Teorema 7.6 (Condição de Lagrange). *Considere funções continuamente diferenciáveis*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

e

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m.$$

Seja $\mathbf{x}^*$ um ótimo local do problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)$$

sejam linearmente independentes.

Essa condição equivale a

$$\text{posto } [\mathbf{J}_c(\mathbf{x}^*)] = m.$$

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_c(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

Comprovação. Como $\mathbf{x}^*$ é um ótimo local regular, a derivada direcional da função objetivo é nula em todas as direções tangentes ao conjunto viável. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{N}[\mathbf{J}_c(\mathbf{x}^*)].$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{N}[\mathbf{J}_c(\mathbf{x}^*)]^\perp.$$

Pelo Teorema 3.6,

$$\mathcal{N}[\mathbf{J}_c(\mathbf{x}^*)]^\perp = \mathcal{C}[\mathbf{J}_c(\mathbf{x}^*)^\top].$$

Assim, existe um vetor

$$\mu^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{J}_c(\mathbf{x}^*)^\top \mu^*.$$

Definindo

$$\lambda^* = -\mu^*,$$

obtém-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

□

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

Sob a condição de regularidade do teorema, as condições necessárias de primeira ordem podem ser escritas como

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Essas condições identificam candidatos a ótimo restrito. No caso geral, elas não são suficientes para garantir mínimo ou máximo. A classificação exige condições adicionais sobre a função objetivo, as restrições e a variação de segunda ordem nas direções tangentes.

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere o problema

$$\max_{\mathbf{x}} \mathbf{a}^\top \mathbf{x},$$

em que

$$\mathbf{a} \neq \mathbf{0},$$

sujeito à restrição

$$\mathbf{x}^\top \mathbf{x} = 1.$$

A restrição exige que $\mathbf{x}$ tenha norma euclidiana unitária:

$$\|\mathbf{x}\| = 1.$$

Escrevendo-a na forma

$$c(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} - 1 = 0,$$

o problema pode ser tratado pelos multiplicadores de Lagrange.

Para manter a formulação como um problema de minimização, considere a função objetivo

$$f(\mathbf{x}) = -\mathbf{a}^\top \mathbf{x}.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^\top \mathbf{x} + \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

As condições de primeira ordem são obtidas diferenciando a lagrangiana em relação a $\mathbf{x}$ e ao multiplicador λ .

Em relação a $\mathbf{x}$,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a} + 2\lambda \mathbf{x}.$$

Portanto, em um ponto candidato à solução,

$$-\mathbf{a} + 2\lambda \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}.$$

Em relação a λ ,

$$\frac{\partial \mathcal{L}(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{x}^\top \mathbf{x} - 1.$$

Assim, a segunda condição de primeira ordem simplesmente recupera a restrição:

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Substituindo

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}$$

na restrição,

$$\left(\frac{1}{2\lambda} \mathbf{a} \right)^\top \left(\frac{1}{2\lambda} \mathbf{a} \right) = 1,$$

e, portanto,

$$\frac{\mathbf{a}^\top \mathbf{a}}{4\lambda^2} = 1.$$

Como

$$\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|^2,$$

segue que

$$4\lambda^2 = \|\mathbf{a}\|^2,$$

ou

$$\lambda = \pm \frac{\|\mathbf{a}\|}{2}.$$

Consequentemente, existem dois pontos candidatos:

$$\mathbf{x}_1 = \frac{\mathbf{a}}{\|\mathbf{a}\|}$$

e

$$\mathbf{x}_2 = -\frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

Para identificar qual deles maximiza a função objetivo original, avalie

$$\mathbf{a}^\top \mathbf{x}.$$

No primeiro ponto,

$$\mathbf{a}^\top \mathbf{x}_1 = \mathbf{a}^\top \frac{\mathbf{a}}{\|\mathbf{a}\|} = \frac{\|\mathbf{a}\|^2}{\|\mathbf{a}\|} = \|\mathbf{a}\|.$$

No segundo,

$$\mathbf{a}^\top \mathbf{x}_2 = -\|\mathbf{a}\|.$$

Logo, o máximo é atingido em

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|},$$

e o valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Geometricamente, a solução mostra que, entre todos os vetores unitários, o produto interno com $\mathbf{a}$ é máximo quando $\mathbf{x}$ possui a mesma direção e o mesmo sentido de $\mathbf{a}$.

O resultado também coincide com o caso de igualdade no Teorema 1.1, pois

$$\mathbf{a}^\top \mathbf{x} \leq \|\mathbf{a}\| \|\mathbf{x}\| = \|\mathbf{a}\|,$$

e a igualdade ocorre quando $\mathbf{x}$ é proporcional a $\mathbf{a}$.

Se $\mathbf{a} = \mathbf{0}$, a função objetivo é constante e todo vetor unitário satisfaz

$$\mathbf{a}^\top \mathbf{x} = 0.$$

Nesse caso, todo vetor que satisfaz a restrição é uma solução ótima.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Portanto, todo ponto regular estacionário do problema restrito é um autovetor de $\mathbf{A}$, e o valor da função objetivo nesse ponto é o autovalor correspondente.

Pelo Teorema 5.5, desenvolvido no capítulo de decomposição espectral,

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\max}(\mathbf{A}),$$

e

$$\min_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\min}(\mathbf{A}).$$

Assim, os multiplicadores de Lagrange produzem a equação de autovalores como condição de estacionariedade, enquanto o resultado espectral identifica quais desses pontos realizam os extremos globais.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica,

$$\mathbf{C} \in \mathbb{R}^{m \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^m.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

Esse sistema em blocos reúne as condições de primeira ordem do problema restrito.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e $\mathbf{C}$ possui posto linha completo, a função objetivo é estritamente convexa e o conjunto definido por

$$\mathbf{C}\mathbf{x} = \mathbf{d}$$

é afim. Quando esse conjunto é não vazio, as condições de primeira ordem identificam o único minimizador global.

Mais geralmente, para uma matriz $\mathbf{A}$ semidefinida positiva, a unicidade depende de a forma quadrática ser positiva nas direções viáveis não nulas, isto é,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} > 0$$

para todo

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{C}\mathbf{z} = \mathbf{0}.$$

Sem condições desse tipo, a resolução do sistema fornece apenas candidatos que satisfazem as condições de primeira ordem.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Derivadas de formas quadráticas

As formas quadráticas foram definidas em Definição 2.23, e a Proposição 2.10 mostrou que seu valor depende apenas da parte simétrica da matriz. O objetivo agora é obter suas derivadas.

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Proposição 7.5 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

Comprovação. Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana. □

Utilizando a classificação de positividade apresentada em Definição 2.24, se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, todos os vetores da forma

$$\mathbf{x} = \mu + \mathbf{z}, \quad \mathbf{z} \in \mathcal{N}(\mathbf{A}),$$

também minimizam a função. Portanto, a unicidade ocorre quando

$$\mathbf{A} \succ \mathbf{0}.$$

7.7.3 Derivadas da norma euclidiana

Retomando a norma euclidiana definida em Definição 1.10,

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Portanto,

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{Ax})^\top (\mathbf{b} - \mathbf{Ax}).$$

Pela regra da cadeia,

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{Ax}).\end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

A Hessiana é constante e não depende de $\mathbf{x}$. Além disso,

$$\mathbf{z}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z} = \|\mathbf{Az}\|^2 \geq 0,$$

para todo

$$\mathbf{z} \in \mathbb{R}^p.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

As equações normais já foram introduzidas geometricamente em Definição 3.21, a partir da projeção sobre o espaço coluna. No Capítulo 6, Proposição 6.22 apresentou a solução por meio da SVD e da pseudoinversa. Nesta seção, o mesmo resultado será obtido a partir da condição de primeira ordem do cálculo diferencial.

7.7.5 Equações normais

Proposição 7.6 (Caracterização dos mínimos quadrados pelas equações normais). *Considere*

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2,$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é minimizador global de f se, e somente se, satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}.$$

Se $\mathbf{A}$ possui posto coluna completo, o minimizador é único e dado por

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Comprovação. A derivação anterior fornece

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Logo, f é convexa. Pelo Proposição 7.3, um ponto é minimizador global se, e somente se, seu gradiente é nulo. Portanto,

$$\nabla_{\mathbf{x}} f(\hat{\mathbf{x}}) = \mathbf{0}$$

se, e somente se,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

de modo que f é estritamente convexa e possui, no máximo, um minimizador. Como

$$\mathbf{A}^\top \mathbf{A}$$

é invertível, esse minimizador é

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

□

A condição

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}$$

mostra que o resíduo de mínimos quadrados é ortogonal ao espaço coluna de $\mathbf{A}$.

O caso de posto deficiente, o conjunto de todos os minimizadores e a solução de menor norma foram estabelecidos em Proposição 6.22. Aqui, o objetivo é destacar que as equações normais surgem diretamente da condição de primeira ordem do problema de otimização.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos não negativos

$$\omega_1, \dots, \omega_q \geq 0$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Como Ω é diagonal e, portanto, simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, em qualquer minimizador, o resíduo satisfaz a condição de ortogonalidade ponderada

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Quando

$$\Omega \succ \mathbf{0},$$

retoma-se o produto interno induzido definido em Definição 3.16:

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^{\top} \Omega \mathbf{v}.$$

A condição anterior corresponde, portanto, à ortogonalidade do resíduo ao espaço coluna de $\mathbf{A}$ nessa geometria ponderada.

Se Ω é singular, a mesma condição algébrica permanece válida, mas a forma ponderada é apenas semidefinida positiva e não define um produto interno em todo o espaço.

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^{\top} \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^{\top} \Omega \mathbf{A})^{-1} \mathbf{A}^{\top} \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

Quando

$$\Omega \succ \mathbf{0},$$

o critério pode ser escrito utilizando a norma induzida de Definição 3.17:

$$f_{\omega}(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|_{\Omega}^2,$$

com

$$\|\mathbf{z}\|_{\Omega}^2 = \mathbf{z}^{\top} \Omega \mathbf{z}.$$

Assim, os mínimos quadrados ponderados correspondem a uma projeção segundo a geometria induzida por Ω .

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma classe ampla de funções de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual duas vezes diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Proposição 7.7 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Comprovação. Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x}). \end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^{\top} + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana. □

A Hessiana possui, portanto, duas parcelas com papéis distintos:

$$\underbrace{2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x})}_{\text{parcela de primeira ordem dos resíduos}} + \underbrace{2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x})}_{\text{correção de não linearidade}} .$$

O primeiro termo da Hessiana,

$$2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}),$$

é semidefinido positivo. Isso não implica, porém, que a função de mínimos quadrados não linear seja convexa, pois a segunda parcela da Hessiana pode ser indefinida.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos ou quando as Hessianas das funções residuais têm contribuição reduzida na região considerada, a segunda parcela pode ser desprezada aproximadamente. Nesse caso,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}).$$

No caso linear,

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}}^2 r_i(\mathbf{x}) = \mathbf{0}$$

para todo i . Portanto, a segunda parcela desaparece exatamente e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Retomando a convenção estabelecida no início do capítulo, o gradiente matricial é

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius definido em Definição 6.6,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr} (\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

Assim como o gradiente de uma função escalar de vetor representa o diferencial segundo o produto interno euclidiano, o gradiente matricial representa o diferencial segundo o produto interno de Frobenius.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço foi definido em Definição 2.9, e suas propriedades algébricas foram estabelecidas em Proposição 2.5 e Proposição 2.8. Para o cálculo matricial, serão utilizadas especialmente as permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}}\phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Proposição 7.8 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

Comprovação. O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

□

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Derivadas da norma de Frobenius

Pela Definição 6.7,

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

De fato, essa função é estritamente convexa em $\mathbf{X}$, pois sua segunda variação em uma perturbação não nula $d\mathbf{X}$ é

$$d^2\phi = 2\|d\mathbf{X}\|_F^2 > 0.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}\mathbf{X}\Gamma + \mathbf{A}^\top\mathbf{X}\Gamma^\top.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

A dimensão do gradiente coincide com a dimensão do argumento:

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{m \times n}.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_{\cdot 1}, \dots, \mathbf{x}_{\cdot n},$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_{\cdot j}^\top \mathbf{A} \mathbf{x}_{\cdot j}.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_{\cdot 1}, \dots, 2\mathbf{A}\mathbf{x}_{\cdot n}.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{XB}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{XB} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Se $\mathbf{X}$ não possui posto coluna completo, os minimizadores não são únicos. A solução de mínimos quadrados de menor norma de Frobenius é

$$\widehat{\mathbf{B}}^\star = \mathbf{X}^+ \mathbf{Y}.$$

Mais geralmente, todos os minimizadores podem ser escritos como

$$\widehat{\mathbf{B}} = \mathbf{X}^+ \mathbf{Y} + (\mathbf{I}_k - \mathbf{X}^+ \mathbf{X}) \mathbf{C},$$

em que

$$\mathbf{C} \in \mathbb{R}^{k \times p}$$

é arbitrária.

A parcela adicional pertence ao núcleo da transformação

$$\mathbf{B} \mapsto \mathbf{XB}$$

e, portanto, não altera os valores ajustados.

Assim, quando o critério utilizado é simplesmente a norma de Frobenius dos resíduos, o problema matricial pode ser interpretado como p problemas de mínimos quadrados que compartilham a mesma matriz de delineamento.

Proposição 7.9 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{XB}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa se, e somente se, $\mathbf{X}$ possui posto coluna completo.

Comprovação. Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa.

Reciprocamente, se $\mathbf{X}$ não possui posto coluna completo, existe

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{X}\mathbf{z} = \mathbf{0}.$$

Escolha qualquer vetor não nulo

$$\mathbf{c} \in \mathbb{R}^p$$

e defina

$$d\mathbf{B} = \mathbf{z}\mathbf{c}^\top.$$

Então

$$d\mathbf{B} \neq \mathbf{0},$$

mas

$$\mathbf{X} d\mathbf{B} = \mathbf{0}.$$

Portanto,

$$d^2Q = 0$$

em uma direção não nula, e a função não é estritamente convexa. □

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

Como

$$\Omega \succeq \mathbf{0}$$

e

$$\Sigma \succ \mathbf{0},$$

o critério também pode ser escrito como

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \left\| \Omega^{1/2} \mathcal{E}(\mathbf{B}) \Sigma^{-1/2} \right\|_F^2.$$

Essa forma mostra que a ponderação atua simultaneamente nas duas dimensões da matriz residual.

A matriz Ω atua no espaço das observações e pondera as linhas da matriz de resíduos. A matriz Σ^{-1} atua no espaço das respostas e define a geometria utilizada para combinar as colunas da matriz de resíduos.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \operatorname{tr} \left[(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B} \right].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{X} \mathbf{B} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, ou equivalentemente, se as colunas de

$$\Omega^{1/2} \mathbf{X}$$

são linearmente independentes, então o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Para Σ fixa e positiva definida, a ponderação invertível no espaço das respostas altera o valor do critério e sua geometria, mas não altera o conjunto de minimizadores em relação a $\mathbf{B}$.

Isso ocorre porque

$$\Sigma^{-1}$$

é invertível e pode ser eliminada da condição de primeira ordem.

A ponderação das observações por Ω , por outro lado, permanece nas equações normais e pode modificar o estimador.

Os diferenciais matriciais e as identidades de traço permitem agora tratar funções em que a própria matriz variável aparece no interior de uma inversa ou de um determinante. Essas estruturas são particularmente importantes quando o parâmetro pertence ao conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

A matriz inversa e o determinante foram definidos em Definição 2.11 e Definição 2.13, enquanto a relação entre determinante e invertibilidade foi estabelecida em Teorema 2.4. A classificação das matrizes simétricas por positividade foi apresentada em Definição 2.24.

Nesta seção, esses objetos são retomados como funções de uma matriz variável. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Proposição 7.10 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019)

Comprovação. Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

□

Quando $\mathbf{X} \succ \mathbf{0}$ e a perturbação

$$d\mathbf{X} \succeq \mathbf{0},$$

tem-se

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \succeq \mathbf{0},$$

e, portanto,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \preceq \mathbf{0}.$$

Assim, a inversão reverte a ordem de Loewner: aumentos semidefinidos positivos da matriz produzem variações semidefinidas negativas de sua inversa.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Proposição 7.11 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019)

Comprovação. Considere uma perturbação $\mathbf{H}$ e a função

$$g(t) = \det(\mathbf{X} + t\mathbf{H}).$$

Como $\mathbf{X}$ é invertível,

$$g(t) = \det(\mathbf{X}) \det(\mathbf{I}_p + t\mathbf{X}^{-1}\mathbf{H}).$$

Pela multilinearidade do determinante,

$$\det(\mathbf{I}_p + t\mathbf{M}) = 1 + t \operatorname{tr}(\mathbf{M}) + o(t).$$

Aplicando essa expansão com

$$\mathbf{M} = \mathbf{X}^{-1}\mathbf{H},$$

obtém-se

$$g(t) = \det(\mathbf{X}) [1 + t \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}) + o(t)].$$

Logo,

$$g'(0) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}).$$

Como $\mathbf{H}$ representa uma perturbação arbitrária,

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}d\mathbf{X}).$$

□

Como

$$d \det(\mathbf{X}) = \operatorname{tr}[(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X}],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X})\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X})\mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

A restrição

$$\mathbf{X} \succ \mathbf{0}$$

garante simultaneamente que $\mathbf{X}$ é invertível e que

$$\det(\mathbf{X}) > 0,$$

de modo que o logaritmo real do determinante está bem definido.

Proposição 7.12 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

Comprovação. Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \text{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \text{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente. □

Para uma matriz real invertível, não necessariamente simétrica, pode-se considerar

$$\phi(\mathbf{X}) = \log |\det(\mathbf{X})|.$$

Como o determinante não se anula no conjunto das matrizes invertíveis, seu sinal permanece constante em uma vizinhança suficientemente pequena de cada matriz invertível. Nesse domínio,

$$d \log |\det(\mathbf{X})| = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}),$$

e, portanto,

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}.$$

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2\phi = -\text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Logo,

$$d^2\phi \leq 0.$$

Proposição 7.13 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas.

(Boyd; Vandenberghe, 2004)

Comprovação. O conjunto das matrizes simétricas positivas definidas é convexo. Para toda matriz

$$\mathbf{X} \succ \mathbf{0}$$

e toda direção simétrica não nula $\mathbf{H}$,

$$d^2\phi[\mathbf{H}, \mathbf{H}] = -\|\mathbf{X}^{-1/2}\mathbf{H}\mathbf{X}^{-1/2}\|_F^2 < 0.$$

Logo, a restrição de ϕ a qualquer segmento não degenerado do cone positivo definido possui segunda derivada negativa. Portanto,

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava nesse domínio. □

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}\mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\text{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Observe que o gradiente possui a mesma dimensão de $\mathbf{X}$,

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{p \times p}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^\top \mathbf{X}^{-1} \mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top \mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}} \phi = -(\mathbf{X}^{-1} \mathbf{a})(\mathbf{X}^{-1} \mathbf{a})^\top.$$

Essa matriz é semidefinida negativa.

Consequentemente, para uma perturbação

$$\mathbf{H} \succeq \mathbf{0},$$

tem-se

$$d\phi[\mathbf{H}] = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top \mathbf{H}] \leq 0.$$

Assim, aumentar $\mathbf{X}$ segundo a ordem de Loewner não aumenta a forma quadrática inversa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^\top \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}} \phi = 2\mathbf{X}^{-1} \mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{xx}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere $n > 0$ e o critério

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dQ &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma}Q = \frac{n}{2}\Sigma^{-1} - \frac{1}{2}\Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

A condição de primeira ordem é

$$n\Sigma^{-1} = \Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n\Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Proposição 7.14 (Minimização do critério de covariância). *Considere*

$$n > 0$$

e uma matriz

$$\mathbf{G} \succ \mathbf{0}.$$

Então, a função

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Comprovação. Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\mathrm{tr}(\Sigma^{-1}\mathbf{G}) = \mathrm{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$Q(\Sigma) = \frac{1}{2} [\mathrm{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$Q(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

$$z = n.$$

Como cada parcela

$$z_j - n \log z_j$$

possui mínimo único em $z_j = n$, o mínimo global exige

$$z_1 = \cdots = z_p = n.$$

Portanto,

$$\mathbf{Z} = n\mathbf{I}_p.$$

Essa igualdade equivale a

$$\Sigma = \frac{1}{n}\mathbf{G}.$$

□

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido.

Além disso, o critério é ilimitado inferiormente. De fato, escolhendo uma direção unitária

$$\mathbf{u} \in \mathcal{N}(\mathbf{G}),$$

pode-se fazer o autovalor de Σ associado a essa direção tender a zero. Nessa direção, o termo

$$\text{tr}(\Sigma^{-1}\mathbf{G})$$

não recebe contribuição, enquanto

$$\log \det(\Sigma) \longrightarrow -\infty.$$

Portanto,

$$Q(\Sigma) \longrightarrow -\infty,$$

e o problema não possui minimizador no cone positivo definido.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

Nesta seção, o núcleo necessário para os capítulos seguintes é formado por três ideias:

- o operador vec ;
- o produto de Kronecker;
- a identidade que relaciona vec e produtos matriciais.

As subseções posteriores sobre Hessianas vetorizadas, matriz de comutação, meia vetorização, matrizes de duplicação e eliminação e Jacobianas de transformações matriciais serão apresentadas como aprofundamento. Elas são úteis em desenvolvimentos mais avançados de cálculo matricial e inferência, mas não são necessárias para uma primeira leitura do restante do livro.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11} \mathbf{C} & \cdots & a_{1n} \mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1} \mathbf{C} & \cdots & a_{mn} \mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1)(\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Proposição 7.15 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{A}\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

A identidade mostra que uma transformação que atua simultaneamente à esquerda e à direita de uma matriz pode ser representada como uma transformação linear usual sobre o vetor formado por seus elementos.

Assim,

$$\mathbf{X} \mapsto \mathbf{A}\mathbf{X}\mathbf{\Gamma}$$

corresponde, após vetorização, a

$$\text{vec}(\mathbf{X}) \mapsto (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X}\mathbf{\Gamma}.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \mathbf{\Gamma}.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \mathbf{\Gamma}^\top \otimes \mathbf{A}.$$

7.10.4 Aprofundamento: derivadas vetorizadas e parâmetros matriciais

Leitura de aprofundamento

As subseções seguintes desenvolvem ferramentas úteis quando parâmetros matriciais precisam ser tratados explicitamente como vetores. Elas permitem representar Hessianas, transposições, parâmetros simétricos e Jacobianas matriciais por meio de vec , produto de Kronecker e matrizes especiais.

Esses resultados são importantes em desenvolvimentos avançados de inferência multivariada e cálculo matricial, mas podem ser omitidos em uma primeira leitura sem comprometer a continuidade dos capítulos seguintes.

7.10.4.1 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr} (\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec} (\nabla_{\mathbf{X}} \phi)^\top d \text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec} (\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.4.2 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec} (\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned}\text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}).\end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Proposição 7.16 (Convexidade da forma quadrática matricial). *Considere*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}\Gamma),$$

em que

$$\mathbf{A} = \mathbf{A}^\top \in \mathbb{R}^{m \times m}$$

e

$$\Gamma = \Gamma^\top \in \mathbb{R}^{n \times n}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então ϕ é convexa em $\mathbf{X}$.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então ϕ é estritamente convexa.

Comprovação. A Hessiana vetorizada é

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2 (\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então

$$\Gamma \otimes \mathbf{A} \succeq \mathbf{0}.$$

Logo, a Hessiana é semidefinida positiva e ϕ é convexa.

Se ambas as matrizes são positivas definidas, então

$$\Gamma \otimes \mathbf{A} \succ \mathbf{0}.$$

Nesse caso, a Hessiana é positiva definida e ϕ é estritamente convexa. □

7.10.4.3 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^\top.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^\top$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.4.4 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{A}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior de $\mathbf{A}$, incluindo a diagonal.

Quando

$$\mathbf{A} = \mathbf{S} = \mathbf{S}^\top,$$

o operador vech contém exatamente os elementos distintos de $\mathbf{S}$. Por isso, ele fornece uma parametrização sem redundância do espaço das matrizes simétricas.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos. A redução ocorre porque uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos. Assim, vech fornece uma parametrização sem redundância do espaço das matrizes simétricas.

7.10.4.5 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.4.6 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é a matriz de seleção que satisfaz

$$\text{vech}(\mathbf{A}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{A})$$

para toda matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \neq \mathbf{I}_{p^2}.$$

A matriz $\mathbf{L}_p^{\text{elim}}$ conserva apenas os elementos correspondentes à parte triangular inferior, enquanto $\mathbf{D}_p^{\text{dup}}$ reconstrói uma matriz impondo simetria. Portanto, esse produto não recupera arbitrariamente uma matriz não simétrica.

Para uma matriz simétrica $\mathbf{S}$, entretanto,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S}) = \text{vec}(\mathbf{S}).$$

7.10.4.7 Diferenciais de parâmetros simétricos

Proposição 7.17 (Gradiente em relação aos elementos distintos de uma matriz simétrica).
Considere um parâmetro matricial

$$\Sigma = \Sigma^\top \in \mathbb{R}^{p \times p}$$

e uma função escalar

$$\phi(\Sigma).$$

Suponha que seu diferencial possa ser escrito como

$$d\phi = \text{tr} [\mathbf{G}^\top d\Sigma],$$

em que

$$d\Sigma = d\Sigma^\top.$$

Então,

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

Em particular, quando

$$\mathbf{G} = \nabla_\Sigma \phi,$$

tem-se

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\nabla_\Sigma \phi).$$

Comprovação. Como

$$\text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} \text{vech}(\Sigma),$$

tem-se

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Além disso,

$$d\phi = \text{vec}(\mathbf{G})^\top d \text{vec}(\Sigma).$$

Substituindo,

$$d\phi = \text{vec}(\mathbf{G})^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Logo,

$$d\phi = \left[(\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}) \right]^\top d \text{vech}(\Sigma),$$

de onde segue

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

□

A parametrização por

$$\text{vech}(\Sigma)$$

remove a redundância existente em

$$\text{vec}(\Sigma),$$

pois uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos livres.

7.10.4.8 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^{\top} \mathbf{X} + \mathbf{X}^{\top} d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned} \text{vec}(d\mathbf{X}^{\top} \mathbf{X}) &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^{\top}) \\ &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}). \end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^{\top} d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^{\top}) \text{vec}(d\mathbf{X}).$$

Logo,

$$d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) = [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ \times d \operatorname{vec}(\mathbf{X}).$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica, a representação por

$$\operatorname{vec}(\mathbf{X}^\top \mathbf{X})$$

contém elementos repetidos. Uma representação sem redundância é obtida por

$$\operatorname{vech}(\mathbf{X}^\top \mathbf{X}).$$

Aplicando a matriz de eliminação,

$$d \operatorname{vech}(\mathbf{X}^\top \mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) \\ = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \operatorname{vec}(\mathbf{X}).$$

Assim, a Jacobiana relativa somente aos elementos distintos de $\mathbf{X}^\top \mathbf{X}$ é

$$\mathbf{J}_{\operatorname{vech} \circ \mathcal{G}}(\mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}).$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

O bloco de aprofundamento mostrou como vec e o produto de Kronecker podem ser estendidos para representar derivadas de ordem superior e parâmetros matriciais com restrições estruturais.

Para a continuidade do livro, as ideias essenciais a reter desta seção são

$$\text{vec}(\mathbf{A}\mathbf{X}\mathbf{\Gamma}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e o fato de que matrizes simétricas possuem apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças, momentos e distribuições marginais de vetores aleatórios contínuos. A mudança de variáveis permite, adicionalmente, transformar regiões de integração e determinar densidades após transformações do vetor aleatório.

Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$. Nesta seção, integrais múltiplas, marginalização, esperanças e mudança de variáveis constituem o núcleo necessário para os capítulos probabilísticos seguintes. A diferenciação sob o sinal de integração será apresentada posteriormente como aprofundamento.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

O produto cartesiano corresponde ao caso mais simples. Para regiões mais gerais, os limites de uma integral podem depender das demais variáveis. Em duas dimensões, por exemplo, uma região da forma

$$\mathcal{D} = \{(x_1, x_2) : a < x_1 < b, c(x_1) < x_2 < d(x_1)\}$$

conduz a

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2 = \int_a^b \int_{c(x_1)}^{d(x_1)} f(x_1, x_2) dx_2 dx_1,$$

quando as condições de integração correspondentes são satisfeitas.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.7 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.8 (Teorema de Fubini). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow \mathbb{R}$$

é mensurável e absolutamente integrável, isto é,

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então, para quase todo $x_1 \in \mathcal{D}_1$,

$$x_2 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_2$, e, para quase todo $x_2 \in \mathcal{D}_2$,

$$x_1 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_1$.

Além disso,

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) \, dx_1 \, dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) \, dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) \, dx_1 \right] dx_2. \end{aligned}$$

(Axler, 2020)

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Definição 7.15 (Densidade conjunta). O vetor aleatório $\mathbf{X}$ é absolutamente contínuo em relação à medida de Lebesgue em $\mathbb{R}^p$ quando existe uma função mensurável

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty]$$

tal que, para todo conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

tem-se

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A função $f_{\mathbf{X}}$ é denominada **densidade conjunta** de $\mathbf{X}$.

Tomando

$$\mathcal{A} = \mathbb{R}^p,$$

segue necessariamente que

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Proposição 7.18 (Densidades marginais). *Considere o vetor aleatório absolutamente contínuo particionado como*

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2).$$

Então, uma densidade marginal de $\mathbf{X}_1$ é

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2,$$

e uma densidade marginal de $\mathbf{X}_2$ é

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

Comprovação. Como a densidade conjunta é não negativa, o Teorema 7.7 permite integrar sucessivamente suas componentes.

Para qualquer conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^{p_1},$$

tem-se

$$\begin{aligned} P(\mathbf{X}_1 \in \mathcal{A}) &= \int_{\mathcal{A} \times \mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 d\mathbf{x}_2 \\ &= \int_{\mathcal{A}} \left[\int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \right] d\mathbf{x}_1. \end{aligned}$$

Portanto,

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2$$

é uma densidade marginal de $\mathbf{X}_1$. O argumento para $\mathbf{X}_2$ é análogo. $\square$

A marginalização elimina as componentes que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 \, dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções escalares, vetoriais e matriciais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.9 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol, 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

o elemento de volume transforma-se segundo

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Proposição 7.19 (Densidade de uma transformação invertível). *Considere um vetor aleatório absolutamente contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$, tal que*

$$P(\mathbf{X} \in \mathcal{D}) = 1,$$

e uma transformação

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

satisfazendo as condições do Teorema 7.9.

Defina

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}).$$

Então, para

$$\mathbf{y} \in \mathcal{G},$$

a densidade de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Para

$$\mathbf{y} \notin \mathcal{G},$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{y}) = 0.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é globalmente injetiva, a fórmula anterior não pode ser aplicada diretamente com uma única inversa. Sob condições de regularidade, pode-se particionar o domínio em regiões nas quais a transformação seja injetiva e somar as contribuições correspondentes às diferentes pré-imagens.

Esse caso não será desenvolvido em detalhe neste capítulo.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0,35x_1x_2 \\ x_2 + 0,20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0,35x_2 & 0,35x_1 \\ 0,40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0,35x_2 - 0,14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

A parametrização polar não é uma transformação globalmente bijetiva em todas as escolhas possíveis de domínio: a origem possui representação angular não única e o ângulo é periódico. Para a aplicação da fórmula de mudança de variáveis, trabalha-se em regiões adequadas de injetividade; as fronteiras envolvidas possuem medida nula e não alteram o valor das integrais usuais.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e sua raiz quadrada principal simétrica positiva definida

$$\Sigma^{1/2}.$$

Considere a transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned}\mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).\end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsoides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Aprofundamento: diferenciação sob o sinal de integração

Leitura de aprofundamento

A diferenciação sob o sinal de integração é utilizada para justificar formalmente identidades envolvendo funções de verossimilhança, vetor escore e informação de Fisher.

Esse conteúdo é importante para desenvolvimentos inferenciais mais formais, mas pode ser omitido em uma primeira leitura. Para a continuidade imediata dos capítulos probabilísticos, basta reter que a troca entre derivação e integração exige condições de regularidade e não pode ser realizada automaticamente.

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.10 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.11 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. *para todo $\theta \in \mathcal{V}$, a função*

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. *exista $\delta > 0$ tal que*

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. *para quase todo $\mathbf{x} \in \mathcal{D}$, a função*

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. *exista uma função integrável*

$$M_j : \mathcal{D} \rightarrow [0, \infty)$$

tal que, para quase todo

$$\mathbf{x} \in \mathcal{D},$$

a desigualdade

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

seja válida para todo t com $|t| < \delta$;

5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Comprovação. Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \mapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x})\mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

$$\begin{aligned} \lim_{m \rightarrow \infty} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \int_{\mathcal{D}} \lim_{m \rightarrow \infty} q_m(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}. \end{aligned}$$

Por outro lado,

$$\begin{aligned} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \frac{\int_{\mathcal{D}} h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) d\mathbf{x} - \int_{\mathcal{D}} h(\mathbf{x}, \theta_0) d\mathbf{x}}{t_m} \\ &= \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m}. \end{aligned}$$

Logo,

$$\lim_{m \rightarrow \infty} \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Como a sequência $t_m \rightarrow 0$ foi escolhida arbitrariamente, a derivada parcial existe e satisfaz a igualdade enunciada. $\square$

Quando as condições do Teorema 7.11 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.11 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned} \mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}. \end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

X

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A parte de aprofundamento mostrou, adicionalmente, como condições de dominação podem justificar a diferenciação de integrais parametrizadas e identidades utilizadas posteriormente em inferência.

Para a continuidade do livro, as ideias centrais a reter são:

- probabilidades são obtidas por integração da densidade conjunta;
- densidades marginais são obtidas integrando as componentes que se deseja eliminar;
- esperanças de vetores e matrizes são calculadas componente a componente;
- mudanças de variáveis exigem o determinante absoluto da Jacobiana;
- transformações afins produzem fatores de volume constantes;
- transformações elipsoidais convertem geometria esférica e elipsoidal.

7.12 Aprofundamento: aplicações à estimação e à inferência

Leitura de aprofundamento

As subseções seguintes mostram como as ferramentas de cálculo desenvolvidas neste capítulo aparecem em problemas de estimação e inferência.

O objetivo é apresentar apenas a estrutura matemática dessas aplicações. As propriedades probabilísticas dos estimadores, as condições de regularidade, as distribuições assintóticas e os procedimentos inferenciais serão desenvolvidos nos capítulos específicos do Módulo II. Este bloco pode ser omitido em uma primeira leitura sem comprometer a continuidade imediata do livro.

As aplicações seguintes envolvem gradientes, Hessianas, expansões de Taylor, diferenciação sob o sinal de integração e cálculo matricial. Elas antecipam, em nível matemático, conceitos que serão retomados posteriormente.

7.12.1 Log-verossimilhança e vetor escore

Considere observações independentes

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

provenientes de um mesmo modelo paramétrico com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros e Θ é o espaço paramétrico.

Nessas condições, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.16 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Se um estimador de máxima verossimilhança é um ponto interior do espaço paramétrico e a log-verossimilhança é diferenciável nesse ponto, então deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.17 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Se

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}$$

e

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

então

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \prec \mathbf{0},$$

e o teste da Hessiana fornece uma condição suficiente para que $\hat{\theta}$ seja um máximo local estrito da log-verossimilhança.

Em um ponto arbitrário do espaço paramétrico, a matriz

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta)$$

não precisa ser positiva semidefinida e pode, inclusive, ser indefinida.

Em um ponto estacionário interior que seja máximo local,

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \preceq \mathbf{0},$$

de modo que

$$\mathcal{J}_n(\hat{\theta}) \succeq \mathbf{0}.$$

A informação observada pode ser singular quando, por exemplo:

- há parâmetros localmente não identificados;
- existem redundâncias na parametrização;
- a log-verossimilhança apresenta direções localmente planas.

Máximos na fronteira exigem tratamento separado, pois as condições usuais de ponto estacionário e o teste irrestrito da Hessiana não os caracterizam adequadamente.

Definição 7.18 (Informação de Fisher). Suponha que o vetor escore possua segundo momento finito. A informação de Fisher da amostra é definida por

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathbf{s}_n(\theta) \mathbf{s}_n(\theta)^{\top}].$$

(Casella; Berger, 2002)

Sob condições de regularidade que permitem diferenciar a densidade sob o sinal de integração,

$$E_{\theta} [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais que justificam a relação entre a primeira e a segunda derivadas da log-verossimilhança,

$$\begin{aligned} \mathcal{J}_n(\theta) &= -E_{\theta} [\nabla_{\theta}^2 \ell_n(\theta)] \\ &= E_{\theta} [\mathcal{J}_n(\theta)]. \end{aligned}$$

Assim, em modelos regulares, a informação de Fisher coincide com a esperança da informação observada. Como o escore possui esperança nula nessas condições,

$$\mathcal{J}_n(\theta) = \text{Cov}_{\theta} [\mathbf{s}_n(\theta)].$$

Essas identidades não devem ser utilizadas automaticamente. Sua validade depende das condições de regularidade, incluindo a possibilidade de intercambiar derivação e integração e o comportamento do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_{\theta}^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_{\theta}^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = -\mathbf{s}_n(\theta^{(t)}),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

Essa é a aplicação do método de Newton à equação

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

Quando

$$\mathcal{J}_n(\theta^{(t)}) \succ \mathbf{0},$$

a direção

$$\mathbf{d}^{(t)} = \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)})$$

é uma direção local de aumento da log-verossimilhança, pois

$$\mathbf{s}_n(\theta^{(t)})^\top \mathbf{d}^{(t)} > 0$$

quando o escore é não nulo.

Ainda assim, um passo completo pode não aumentar a log-verossimilhança quando o ponto atual está distante da solução. Em aplicações numéricas, podem ser utilizados controles do comprimento da etapa.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada

$$\mathcal{J}_n(\theta)$$

pela informação de Fisher

$$\mathcal{J}_n(\theta).$$

Sob as condições de regularidade para as quais

$$\mathcal{J}_n(\theta) = E_\theta [\mathcal{J}_n(\theta)],$$

essa substituição pode ser interpretada como a troca da curvatura observada pela curvatura esperada da log-verossimilhança.

Quando

$$\mathcal{J}_n(\theta^{(t)})$$

é invertível, a direção $\mathbf{d}^{(t)}$ é obtida pela solução de

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = \mathbf{s}_n(\theta^{(t)}),$$

seguida da atualização

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Assim, Newton–Raphson utiliza

$$\mathcal{J}_n(\theta),$$

enquanto o método do escore de Fisher utiliza

$$\mathcal{J}_n(\theta).$$

Quando a identidade de informação é válida, a primeira representa a curvatura observada e a segunda sua correspondente curvatura esperada.

As atualizações coincidem quando as duas matrizes são iguais no ponto considerado ou, mais geralmente, quando produzem a mesma solução para a equação que determina a direção da etapa.

7.12.5 Expansão local de uma raiz do escore

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned}\mathbf{0} &= \mathbf{s}_n(\hat{\theta}) \\ &\approx \mathbf{s}_n(\theta_0) + \nabla_{\theta}^2 \ell_n(\theta_0) (\hat{\theta} - \theta_0).\end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n(\theta_0) = -\mathcal{J}_n(\theta_0),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa expressão é uma aproximação local de primeira ordem. A obtenção de uma representação assintótica rigorosa exige controlar o termo restante da expansão e substituir a informação observada por um limite apropriado.

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.12 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q$$

diferenciável no ponto

$$\theta.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A demonstração formal utiliza a aproximação de Taylor de primeira ordem juntamente com resultados probabilísticos sobre convergência em distribuição. Esses resultados serão desenvolvidos no módulo inferencial; neste capítulo interessa principalmente a origem diferencial da matriz

$$\mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta)(\hat{\theta} - \theta).$$

A matriz

$$\mathbf{V}_{\mathbf{g}} = \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}$$

é a matriz de covariâncias da distribuição limite de

$$\sqrt{n} \left[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \right].$$

Por isso, denomina-se

$$\frac{1}{n} \mathbf{V}_{\mathbf{g}}$$

matriz de covariâncias assintótica de

$$\mathbf{g}(\hat{\theta}).$$

Em aplicações, é comum utilizá-la como aproximação da matriz de covariâncias do estimador para amostras grandes. A convergência em distribuição, isoladamente, não garante convergência dos segundos momentos; essa interpretação requer condições adicionais de regularidade.

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância assintótica é

$$\frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_2}{\theta_1} \\ -\frac{1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n} \left(\hat{\theta} - \theta \right) \xrightarrow{d} N_2 \left(\mathbf{0}, \Xi \right),$$

então

$$\sqrt{n} \left(\frac{\hat{\theta}_1}{\hat{\theta}_2} - \frac{\theta_1}{\theta_2} \right)$$

converge em distribuição para uma normal com variância assintótica

$$\nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.25 (Estimação de um vetor de médias). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

Exemplo 7.26 (Critério do modelo linear multivariado). Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere o critério

$$\begin{aligned} Q(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} Q = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Observe que, para Σ fixa e positiva definida, o minimizador em relação a $\mathbf{B}$ não depende de Σ . Isso decorre do fato de que Σ^{-1} é invertível e desaparece da condição de primeira ordem.

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_\mathcal{E} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^\top (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_\mathcal{E}).$$

Se

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_\mathcal{E}.$$

A condição

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo.

Se $\mathbf{X}$ possui posto coluna completo k , a matriz residual pode ser escrita como

$$\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}} = (\mathbf{I}_n - \mathbf{P}_\mathbf{X}) \mathbf{Y},$$

em que

$$\text{posto}(\mathbf{I}_n - \mathbf{P}_\mathbf{X}) = n - k.$$

Consequentemente,

$$\text{posto}(\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}) \leq \min(p, n - k).$$

Assim, uma condição necessária para

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

é

$$n - k \geq p.$$

Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério é ilimitado inferiormente no cone das matrizes positivas definidas. Em particular, pode-se fazer um autovalor de Σ tender a zero em uma direção pertencente ao núcleo de $\mathbf{G}_{\mathcal{E}}$ sem produzir aumento compensatório no termo de traço.

Aqui o modelo foi utilizado apenas como uma aplicação conjunta de gradientes matriciais, log-determinante e diferenciação de funções envolvendo matrizes inversas.

A interpretação probabilística do critério, as propriedades dos estimadores, suas distribuições e a formulação de hipóteses serão desenvolvidas posteriormente nos capítulos de estimação, modelo linear multivariado e inferência.

O bloco de aprofundamento mostrou como as ferramentas de cálculo deste capítulo aparecem em problemas de estimação e inferência:

Tabela 7.2: Relações entre as ferramentas de cálculo e suas aplicações estatísticas.

Ferramenta matemática	Aplicação estatística
Gradiente	Vetor escore
Hessiana	Informação observada
Esperança da curvatura	Informação de Fisher
Expansão de Taylor	Aproximações locais e método delta
Cálculo matricial	Estimação de parâmetros vetoriais e matriciais

Essas relações devem ser entendidas neste capítulo como aplicações das ferramentas matemáticas. Sua interpretação estatística completa será retomada no Módulo II.

7.13 Síntese do capítulo

O capítulo reuniu as ferramentas de cálculo necessárias para estudar funções de vetores e matrizes e para formular problemas posteriores da Estatística Multivariada.

No cálculo diferencial, o gradiente representa a variação de primeira ordem de uma função escalar, a Jacobiana representa a transformação linear local de uma função vetorial e a Hessiana descreve sua curvatura. Essas estruturas sustentam aproximações de Taylor e condições de otimalidade.

A otimização utiliza essas derivadas de formas diferentes. Em problemas sem restrições, pontos estacionários e a definitude da Hessiana permitem caracterizar soluções locais, enquanto a convexidade fornece resultados globais. Em problemas com restrições de igualdade, os multiplicadores de Lagrange incorporam a geometria do conjunto viável. As funções de resíduos mostram como essas ferramentas conduzem às equações normais e aos problemas de mínimos quadrados.

No cálculo matricial, os diferenciais e as identidades de traço permitem trabalhar diretamente com parâmetros matriciais. Derivadas de inversas, determinantes e log-determinantes serão utilizadas em critérios que envolvem matrizes de covariâncias. A vetorização e o produto de Kronecker fornecem uma representação vetorial para transformações entre matrizes.

O cálculo integral completa essa estrutura ao permitir a obtenção de probabilidades, expectativas e densidades marginais. O Teorema da Mudança de Variáveis mostra como o determinante Jacobiano modifica elementos de volume e densidades sob transformações. Transformações afins e elipsoidais conectam essa ideia às formas quadráticas e às matrizes positivas definidas.

As principais relações estabelecidas no capítulo podem ser resumidas da seguinte forma:

Tabela 7.3: Relações entre as ferramentas do cálculo e seus usos posteriores.

Estrutura matemática	Papel nos capítulos seguintes
Derivadas	Aproximação local e otimização
Diferenciais matriciais	Manipulação e estimação de parâmetros matriciais
Integração e Jacobianos	Construção e transformação de distribuições multivariadas

A Tabela 7.4 reúne algumas das identidades de uso recorrente.

Tabela 7.4: Identidades selecionadas de cálculo vetorial e matricial.

Função ou transformação	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Os blocos de aprofundamento desenvolveram ferramentas que não são necessárias para uma primeira leitura do capítulo, entre elas derivadas vetorizadas e parametrização de matrizes simétricas, diferenciação sob o sinal de integração e aplicações do cálculo à estimação e à inferência. Esses resultados poderão ser retomados quando forem necessários nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- interpretar derivadas como aproximações locais;
- utilizar Taylor e a Hessiana em problemas de otimização;
- formular condições de primeira ordem com e sem restrições;
- derivar critérios quadráticos e equações normais;
- utilizar diferenciais e identidades de traço em funções matriciais;
- diferenciar expressões envolvendo inversas, determinantes e log-determinantes;
- utilizar vec, produto de Kronecker e sua identidade de vetorização;
- calcular probabilidades, expectativas e densidades marginais por integração;
- aplicar mudanças de variáveis e interpretar o determinante Jacobiano.

O Capítulo 7 encerra o **Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada**.

Antes do início do Módulo II, os **Exercícios de fixação do Módulo I** retomam de forma integrada os principais conceitos desenvolvidos ao longo dos sete capítulos. Os exercícios articulam representação matricial dos dados, projeções, transformações lineares, formas quadráticas, autovalores e autovetores, SVD, pseudoinversa e cálculo vetorial e matricial em problemas que serão utilizados posteriormente na Estatística Multivariada.

O capítulo seguinte inicia o **Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada** com o estudo das matrizes de covariâncias e correlações. Gradientes, formas quadráticas, transformações lineares, integrais, projeções e produtos matriciais fornecerão

as ferramentas matemáticas para descrever a variabilidade conjunta de vetores aleatórios e sustentar os desenvolvimentos probabilísticos e inferenciais posteriores.

Exercícios de fixação do Módulo I

Os exercícios deste módulo retomam os fundamentos matemáticos desenvolvidos nos capítulos anteriores e os utilizam em problemas que reaparecerão ao longo da Estatística Multivariada.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades e operações com vetores e matrizes, bem como suas interpretações algébricas e geométricas. As matrizes foram escolhidas para permitir resultados exatos e favorecer a compreensão das relações entre Álgebra Linear, Geometria e Cálculo.

Na segunda parte, o **R** ou **Python** será utilizado para estender essas mesmas ideias a matrizes de maior dimensão e a conjuntos de dados. O objetivo não é substituir os cálculos matriciais por funções prontas, mas utilizar a computação para aplicar e verificar propriedades estudadas no Módulo I.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos no Módulo I (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de propriedades como simetria, ortogonalidade, independência linear, posto, invertibilidade, definição positiva ou outras condições específicas, essas condições devem ser verificadas ou justificadas.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Exercícios sem uso de computador

Exercício 7.1 (Transformação de variáveis em uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 2 & 2 \\ 3 & 0 & 1 \end{bmatrix},$$

em que as linhas representam quatro observações e as colunas representam três variáveis.

Considere também a transformação

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

1. Escreva, para uma observação genérica

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

as duas componentes de

$$\mathbf{y} = \mathbf{Ax}.$$

2. Interprete cada nova componente como uma combinação linear das variáveis originais.
3. Determine a matriz de dados transformada utilizando

$$\mathbf{Y} = \mathbf{XA}^\top.$$

4. Indique as dimensões de $\mathbf{X}$, $\mathbf{A}$ e $\mathbf{Y}$ e explique por que a transformação reduziu o número de variáveis de três para duas.
5. Determine o posto de $\mathbf{A}$.
6. Determine a dimensão de $\mathcal{N}(\mathbf{A})$ e explique o significado desse resultado em termos de perda de informação.
7. Sabendo apenas $\mathbf{y} = \mathbf{Ax}$, discuta se é possível recuperar unicamente o vetor original $\mathbf{x}$.

Exercício 7.2 (Centralização como projeção). Considere $n = 4$ e defina

$$\mathbf{H}_4 = \mathbf{I}_4 - \frac{1}{4}\mathbf{1}_4\mathbf{1}_4^\top.$$

1. Escreva explicitamente a matriz $\mathbf{H}_4$.

2. Verifique que

$$\mathbf{H}_4^\top = \mathbf{H}_4$$

e

$$\mathbf{H}_4^2 = \mathbf{H}_4.$$

3. Mostre que

$$\mathbf{H}_4 \mathbf{1}_4 = \mathbf{0}.$$

4. Aplique $\mathbf{H}_4$ à matriz $\mathbf{X}$ do Exercício 7.1:

$$\mathbf{X}_c = \mathbf{H}_4 \mathbf{X}.$$

5. Verifique diretamente que

$$\mathbf{1}_4^\top \mathbf{X}_c = \mathbf{0}^\top.$$

6. Interprete a igualdade anterior em termos das médias das variáveis.

Exercício 7.3 (Centralização e reescalonamento das variáveis). Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times 3}$$

e a matriz diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix}.$$

1. Determine $\mathbf{D}^{-1}$.

2. Considere inicialmente uma matriz já centralizada $\mathbf{X}_c$ e defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}^{-1}.$$

Explique o efeito dessa transformação sobre cada uma das três variáveis.

3. Explique por que $\mathbf{D}^{-1}$ atua à direita da matriz de dados.
4. Compare essa operação com a centralização

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

explicando por que $\mathbf{H}_n$ atua à esquerda enquanto $\mathbf{D}^{-1}$ atua à direita.

5. Escreva, em uma única expressão, a transformação que primeiro centraliza $\mathbf{X}$ e depois reescala suas variáveis.
6. A centralização e o reescalonamento atuam no mesmo espaço? Justifique utilizando as dimensões de $\mathbf{H}_n$ e $\mathbf{D}^{-1}$.

Exercício 7.4 (Duas matrizes de Gram para os mesmos dados). Considere a matriz centralizada

$$\mathbf{X}_c = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 2 \\ 0 & -2 \end{bmatrix}.$$

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Indique as dimensões das duas matrizes.
3. Qual das duas matrizes contém os produtos internos entre as colunas de $\mathbf{X}_c$?
4. Qual contém os produtos internos entre as linhas de $\mathbf{X}_c$?
5. Determine o posto das duas matrizes.
6. Determine os autovalores positivos de cada matriz.
7. Verifique que os autovalores positivos coincidem.
8. Relacione esse resultado à construção da SVD de uma matriz retangular.

Exercício 7.5 (Projeção, ajuste e resíduos). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

1. Verifique que as colunas de $\mathbf{X}$ são linearmente independentes.
2. Determine

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

3. Verifique que

$$\mathbf{P}_X^\top = \mathbf{P}_X$$

e

$$\mathbf{P}_X^2 = \mathbf{P}_X.$$

4. Calcule

$$\hat{\mathbf{y}} = \mathbf{P}_X \mathbf{y}.$$

5. Determine o vetor de resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

6. Verifique que

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

7. Identifique o subespaço ao qual pertence $\hat{\mathbf{y}}$.
8. Identifique o subespaço ao qual pertence $\mathbf{e}$.
9. Interprete geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

Exercício 7.6 (Um problema de mínimos quadrados por três perspectivas). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

O objetivo é determinar o vetor que minimiza

$$\|\mathbf{b} - \mathbf{Ax}\|^2.$$

Resolva o problema das três formas seguintes.

1. Determine a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$ e obtenha, a partir dela, o vetor ajustado.
2. Resolva as equações normais

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}.$$

3. Calcule

$$\mathbf{A}^\top \mathbf{A}$$

e determine os valores singulares de $\mathbf{A}$.

4. Construa uma SVD compacta de $\mathbf{A}$.
5. Construa a pseudoinversa

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$$

e obtenha

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}.$$

6. Compare as soluções obtidas pelas três abordagens.
7. Compare também os vetores ajustados e os resíduos.
8. Explique por que projeções, equações normais e pseudoinversa conduzem ao mesmo problema de aproximação.

Exercício 7.7 (Forma quadrática e direções privilegiadas). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. Calcule $q(\mathbf{x})$ para

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

2. Determine os autovalores de $\mathbf{A}$.
3. Determine uma base ortonormal de autovetores.
4. Calcule a forma quadrática em cada autovetor unitário.
5. Determine

$$\max_{\|\mathbf{x}\|=1} q(\mathbf{x})$$

e

$$\min_{\|\mathbf{x}\|=1} q(\mathbf{x}).$$

6. Relacione os valores encontrados aos autovalores de $\mathbf{A}$.

Exercício 7.8 (Norma euclidiana e norma induzida). Considere

$$\mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

responda:

1. Calcule as normas euclidianas de $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{z}$.
2. Calcule as normas induzidas por $\mathbf{M}$,

$$\|\mathbf{v}\|_{\mathbf{M}} = \sqrt{\mathbf{v}^{\top} \mathbf{M} \mathbf{v}}.$$

3. Calcule a distância euclidiana entre $\mathbf{x}$ e $\mathbf{y}$.
4. Calcule a distância induzida por $\mathbf{M}$ entre os mesmos vetores.
5. Qual coordenada recebe maior peso na geometria induzida por $\mathbf{M}$?
6. Explique por que duas geometrias diferentes podem produzir avaliações diferentes da proximidade entre observações.

Exercício 7.9 (Matrizes particionadas e complemento de Schur). Considere a matriz simétrica

$$\mathbf{M} = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

particionada como

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^{\top} & \mathbf{D} \end{bmatrix},$$

em que

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{D} = [2].$$

1. Verifique que $\mathbf{A}$ é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Calcule o complemento de Schur de $\mathbf{A}$ em $\mathbf{M}$,

$$\mathbf{S} = \mathbf{D} - \mathbf{B}^{\top} \mathbf{A}^{-1} \mathbf{B}.$$

4. Verifique que $\mathbf{S} > 0$.
5. Utilize a identidade por blocos

$$\det(\mathbf{M}) = \det(\mathbf{A}) \det(\mathbf{S})$$

para calcular $\det(\mathbf{M})$.

6. Confirme o resultado calculando diretamente o determinante de $\mathbf{M}$.

Exercício 7.10 (Direção que maximiza uma medida de dispersão). Considere

$$\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Para um vetor unitário $\mathbf{a}$, defina

$$D(\mathbf{a}) = \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

1. Determine os autovalores de $\mathbf{S}$.
2. Determine uma base ortonormal de autovetores.
3. Resolva

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

4. Determine a direção que minimiza $D(\mathbf{a})$ sob a mesma restrição.
5. Calcule o valor da forma quadrática nas duas direções.
6. Se $\mathbf{S}$ representasse uma matriz de dispersão de duas variáveis, interprete a direção associada ao maior autovalor.
7. Interprete também a direção associada ao menor autovalor.

Exercício 7.11 (Maximização de uma razão entre duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 12 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Resolva

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}}.$$

1. Mostre, por multiplicadores de Lagrange ou pelo quociente de Rayleigh generalizado, que as direções candidatas satisfazem

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{B} \mathbf{x}.$$

2. Determine os autovalores generalizados.
3. Determine um autovetor associado a cada autovalor generalizado.
4. Normalize os autovetores segundo a geometria de $\mathbf{B}$, impondo

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1.$$

5. Determine o valor máximo do quociente.
6. Determine também o valor mínimo.
7. Verifique que os dois autovetores podem ser escolhidos de modo que

$$\mathbf{x}_1^\top \mathbf{B} \mathbf{x}_2 = 0.$$

8. Compare essa ortogonalidade com a ortogonalidade euclidiana usual.

Exercício 7.12 (Transformação de um problema generalizado). Utilize as matrizes $\mathbf{A}$ e $\mathbf{B}$ do Exercício 7.11.

1. Determine a raiz quadrada principal

$$\mathbf{B}^{1/2}$$

e sua inversa

$$\mathbf{B}^{-1/2}.$$

2. Construa

$$\mathbf{C} = \mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2}.$$

3. Determine os autovalores de $\mathbf{C}$.

4. Compare-os com os autovalores generalizados obtidos no exercício anterior.

5. Considere a transformação

$$\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}.$$

Mostre que

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = \mathbf{z}^\top \mathbf{z}.$$

6. Mostre que

$$\frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}} = \frac{\mathbf{z}^\top \mathbf{C} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

7. Explique por que a transformação converte um problema em geometria induzida por $\mathbf{B}$ em um problema espectral euclidiano.

Exercício 7.13 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

1. Calcule

$$\mathbf{A}^\top \mathbf{A}.$$

2. Determine os autovalores de $\mathbf{A}^\top \mathbf{A}$.

3. Determine os valores singulares positivos de $\mathbf{A}$ em ordem decrescente.

4. Determine os vetores singulares à direita correspondentes.

5. Utilize

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}$$

para construir os vetores singulares à esquerda.

6. Verifique que os vetores obtidos são ortonormais.

7. Construa

$$\mathbf{U}_r, \quad \mathbf{D}_r, \quad \mathbf{V}_r.$$

8. Verifique diretamente que

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

9. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A})$.

10. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A}^\top)$.

Exercício 7.14 (Aproximação de posto reduzido). Utilize a matriz e a SVD do Exercício 7.13.

1. Escreva

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + d_2 \mathbf{u}_2 \mathbf{v}_2^\top.$$

2. Construa a aproximação de posto 1

$$\mathbf{A}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1^\top.$$

3. Determine explicitamente

$$\mathbf{A} - \mathbf{A}_1.$$

4. Calcule

$$\|\mathbf{A} - \mathbf{A}_1\|_F.$$

5. Verifique que, neste caso,

$$\|\mathbf{A} - \mathbf{A}_1\|_F = d_2.$$

6. Calcule

$$\|\mathbf{A}\|_F^2.$$

7. Verifique que

$$\|\mathbf{A}\|_F^2 = d_1^2 + d_2^2.$$

8. Calcule

$$\frac{d_1^2}{d_1^2 + d_2^2}.$$

9. Interprete essa razão como a parcela da magnitude quadrática da matriz preservada pela aproximação de posto 1.

Exercício 7.15 (Gradiente e Hessiana de um critério de mínimos quadrados). Considere

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

1. Desenvolva $Q(\beta)$ como uma expressão quadrática em β .

2. Obtenha

$$\nabla_{\beta} Q(\beta).$$

3. Obtenha

$$\nabla_{\beta}^2 Q(\beta).$$

4. Mostre que, se $\mathbf{X}$ possui posto completo de colunas,

$$\mathbf{X}^{\top} \mathbf{X} \succ \mathbf{0}.$$

5. Conclua que a Hessiana é positiva definida.

6. Mostre que o ponto estacionário é o único minimizador global.
7. Aplique o resultado a

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix},$$

determinando $\hat{\beta}$ exatamente.

8. Compare a solução com aquela obtida geometricamente no Exercício 7.5.

Exercício 7.16 (Multiplicadores de Lagrange e autovalores). Considere uma matriz real simétrica $\mathbf{A}$ e o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

1. Construa a função lagrangiana.
2. Diferencie-a em relação a $\mathbf{x}$.
3. Diferencie-a em relação ao multiplicador de Lagrange.
4. Mostre que as condições de primeira ordem conduzem a uma equação da forma

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}.$$

5. Explique por que o problema de otimização se transforma em um problema de autovalores.
6. Resolva completamente o problema para

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

7. Determine também o mínimo sob a mesma restrição.
8. Compare os resultados com os obtidos no Exercício 7.10.

Exercício 7.17 (Vetorização e produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Adote a convenção de que $\text{vec}(\mathbf{X})$ empilha as colunas de $\mathbf{X}$.

1. Calcule diretamente

$$\mathbf{Y} = \mathbf{AXB}.$$

2. Determine

$$\text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{Y}).$$

3. Construa

$$\mathbf{B}^\top \otimes \mathbf{A}.$$

4. Calcule

$$(\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

5. Verifique a identidade

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

6. Compare as dimensões da transformação matricial com as dimensões de sua representação vetorizada.

Exercício 7.18 (Diferenciação de um critério matricial). Considere, para

$$\Sigma \succ \mathbf{0},$$

a função

$$Q(\Sigma) = 2 \log \det(\Sigma) + \text{tr}(\mathbf{G}\Sigma^{-1}),$$

em que

$$\mathbf{G} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Utilize diferenciais para obter

$$dQ.$$

2. Mostre que um ponto estacionário deve satisfazer

$$2\Sigma^{-1} - \Sigma^{-1}\mathbf{G}\Sigma^{-1} = \mathbf{0}.$$

3. Resolva essa equação para Σ .
4. Verifique que a matriz obtida é positiva definida.

Exercício 7.19 (Transformação afim, Jacobiana e alteração de área). Considere

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

1. Calcule $\det(\mathbf{A})$ e mostre que a transformação é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Escreva a transformação inversa

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

4. Determine a matriz Jacobiana da transformação de $\mathbf{x}$ para $\mathbf{y}$.
5. Determine o determinante Jacobiano.
6. Considere a região

$$0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1.$$

Determine as imagens de seus quatro vértices.

7. Descreva geometricamente a região transformada.
8. Determine sua área.
9. Compare a razão entre a área transformada e a área original com

$$|\det(\mathbf{A})|.$$

Parte II — Exercícios com uso do R

Nesta parte, utilize preferencialmente operações matriciais do R. Quando uma função pronta reproduzir diretamente um resultado estudado no Módulo I, utilize-a apenas depois da construção matricial, como forma de conferência.

Em comparações envolvendo posto, autovalores teoricamente nulos ou valores singulares numericamente nulos, considere a possibilidade de pequenos erros de arredondamento computacional e utilize uma tolerância numérica adequada.

Exercício 7.20 (Centralização matricial dos dados `USArrests`). Considere as quatro variáveis quantitativas do conjunto de dados `USArrests`.

1. Armazene a matriz de dados em um objeto $\mathbf{X}$.
2. Determine n e p a partir da própria matriz.
3. Construa explicitamente

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

4. Obtenha

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

- Verifique numericamente que as médias das colunas de $\mathbf{X}_c$ são zero, admitindo apenas diferenças de arredondamento.
- Verifique numericamente que

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

- Determine o posto numérico de $\mathbf{H}_n$.
- Verifique que

$$\mathbf{H}_n \mathbf{1}_n \approx \mathbf{0}.$$

- Somente ao final, compare $\mathbf{X}_c$ com o resultado produzido por

```
scale(X, center = TRUE, scale = FALSE)
```

- Explique geometricamente o papel de $\mathbf{H}_n$.

Exercício 7.21 (Matrizes de Gram e seus espectros). Utilize a matriz centralizada $\mathbf{X}_c$ obtida no Exercício 7.20.

- Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

- Compare as dimensões das duas matrizes.
- Determine seus postos numéricos.
- Calcule os autovalores de ambas.
- Para identificar os autovalores numericamente positivos, utilize uma tolerância relativa, por exemplo,

$$\lambda_j > 10^{-10} \lambda_{\max}.$$

6. Compare os autovalores positivos de $\mathbf{G}_V$ e $\mathbf{G}_O$.
7. Explique por que uma matriz 4×4 e uma matriz 50×50 contêm o mesmo espectro não nulo.
8. Relacione os resultados aos valores singulares de $\mathbf{X}_c$.

Exercício 7.22 (Construção de novas variáveis por transformação linear). Considere apenas as quatro variáveis quantitativas de `iris`, formando

$$\mathbf{X} \in \mathbb{R}^{150 \times 4}.$$

Defina

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & -1 & 0 & 0 \end{bmatrix}.$$

1. Obtenha

$$\mathbf{Y} = \mathbf{XA}^\top.$$

2. Escreva explicitamente cada uma das três novas variáveis como combinação das quatro variáveis originais.
3. Verifique as dimensões de $\mathbf{Y}$.
4. Determine o posto de $\mathbf{A}$.
5. Determine a dimensão de $\mathcal{N}(\mathbf{A})$.
6. Discuta se a transformação preserva toda a informação necessária para reconstruir as quatro variáveis originais.
7. Centralize $\mathbf{X}$.
8. Aplique a mesma transformação à matriz centralizada.
9. Verifique as médias das três variáveis transformadas após a centralização.
10. Explique por que uma transformação linear de dados centralizados continua produzindo variáveis com média amostral zero.

Exercício 7.23 (Busca da direção de maior dispersão). Utilize as variáveis quantitativas de `USArrests`.

1. Centralize a matriz de dados e denote o resultado por $\mathbf{X}_c$.

2. Construa

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

3. Obtenha os autovalores e autovetores de $\mathbf{S}$ utilizando `eigen()`.
4. Identifique a direção unitária $\mathbf{a}_1$ associada ao maior autovalor.
5. Calcule

$$\mathbf{a}_1^\top \mathbf{S} \mathbf{a}_1.$$

6. Compare o resultado com o maior autovalor de $\mathbf{S}$.
7. Gere um grande número de vetores aleatórios em $\mathbb{R}^4$ e normalize cada um para norma unitária.
8. Para cada vetor $\mathbf{a}$, calcule

$$\mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

9. Compare o maior valor encontrado entre as direções aleatórias com o maior autovalor de $\mathbf{S}$.
10. Explique o que esse experimento numérico mostra sobre o quociente de Rayleigh.
11. Repita a análise após padronizar as quatro variáveis para variância unitária.
12. Compare a nova direção de máxima dispersão com aquela obtida utilizando as variáveis apenas centralizadas e discuta o efeito da mudança de escala.

Não utilize `prcomp()` neste exercício.

Exercício 7.24 (Projeção e reconstrução a partir de uma direção). Utilize $\mathbf{X}_c$ e a direção $\mathbf{a}_1$ obtidas no Exercício 7.23.

1. Calcule as coordenadas das observações na direção $\mathbf{a}_1$:

$$\mathbf{z}_1 = \mathbf{X}_c \mathbf{a}_1.$$

2. Verifique as dimensões de $\mathbf{z}_1$.
3. Reconstrua a parcela da matriz de dados associada a essa direção:

$$\widehat{\mathbf{X}}_1 = \mathbf{z}_1 \mathbf{a}_1^\top.$$

4. Verifique que $\widehat{\mathbf{X}}_1$ possui posto 1.
5. Calcule

$$\mathbf{E}_1 = \mathbf{X}_c - \widehat{\mathbf{X}}_1.$$

6. Calcule

$$\|\mathbf{X}_c\|_F^2, \quad \|\widehat{\mathbf{X}}_1\|_F^2, \quad \|\mathbf{E}_1\|_F^2.$$

7. Verifique numericamente que

$$\|\mathbf{X}_c\|_F^2 \approx \|\widehat{\mathbf{X}}_1\|_F^2 + \|\mathbf{E}_1\|_F^2.$$

8. Verifique também que

$$\langle \widehat{\mathbf{X}}_1, \mathbf{E}_1 \rangle_F \approx 0.$$

9. Interprete o que foi preservado e o que foi descartado pela projeção.

Exercício 7.25 (SVD e decomposição espectral da matriz de dados). Utilize a matriz centralizada de `USArrests`.

1. Calcule sua SVD utilizando `svd()`.
2. Extraia $\mathbf{U}$, os valores singulares e $\mathbf{V}$.
3. Construa explicitamente a matriz diagonal $\mathbf{D}$.
4. Verifique numericamente que

$$\mathbf{X}_c \approx \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

5. Verifique que

$$\mathbf{X}_c^\top \mathbf{X}_c \approx \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

6. Calcule

```
eigen(t(Xc) %*% Xc)
```

e compare os autovetores obtidos com os vetores singulares à direita.

7. Compare os autovalores de $\mathbf{X}_c^\top \mathbf{X}_c$ com os quadrados dos valores singulares.
8. Explique por que vetores produzidos por `eigen()` e `svd()` podem diferir apenas pelo sinal.
9. Relacione as colunas de $\mathbf{V}$ a direções no espaço das variáveis.

Exercício 7.26 (Aproximações de posto reduzido em uma matriz de dados). Utilize a SVD obtida no Exercício 7.25.

Para

$$k = 1, 2, 3,$$

construa

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Para cada valor de k :

1. determine o posto numérico de $\mathbf{X}_{c,k}$;
2. calcule

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F;$$

3. verifique numericamente que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 \approx \sum_{j=k+1}^r d_j^2;$$

4. calcule

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2};$$

5. interprete essa quantidade em termos da magnitude quadrática preservada pela aproximação;
6. compare os erros para $k = 1$, $k = 2$ e $k = 3$;
7. explique por que o erro não pode aumentar quando k cresce.

Não utilize `prcomp()` para construir as aproximações.

Exercício 7.27 (Mínimos quadrados com duas variáveis respostas). Utilize o conjunto de dados `mtcars`.

Considere como respostas:

- `mpg`;
- `qsec`;

e como variáveis explicativas:

- `intercepto`;
- `wt`;
- `hp`.

Construa

$$\mathbf{Y} \in \mathbb{R}^{n \times 2}$$

e

$$\mathbf{X} \in \mathbb{R}^{n \times 3}.$$

1. Verifique as dimensões das duas matrizes.
2. Verifique que $\mathbf{X}$ possui posto completo de colunas.
3. Calcule

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

4. Determine as dimensões de $\widehat{\mathbf{B}}$.
5. Interprete suas duas colunas.
6. Calcule

$$\widehat{\mathbf{Y}} = \mathbf{X} \widehat{\mathbf{B}}$$

e

$$\mathbf{E} = \mathbf{Y} - \widehat{\mathbf{Y}}.$$

7. Verifique numericamente que

$$\mathbf{X}^\top \mathbf{E} \approx \mathbf{0}.$$

8. Ajuste separadamente, utilizando `lm()`, um modelo para `mpg` e outro para `qsec`.
9. Compare os coeficientes das duas regressões com as colunas de $\widehat{\mathbf{B}}$.

Exercício 7.28 (Posto deficiente e pseudoinversa). Utilize `mtcars` e considere `mpg` como vetor-resposta.

Construa uma matriz de delineamento cujas colunas sejam

$$\mathbf{1}, \quad \text{wt}, \quad 2 \text{ wt}.$$

1. Determine o posto da matriz de delineamento.
2. Compare o posto com o número de colunas.
3. Calcule seus valores singulares.
4. Identifique quais valores singulares devem ser considerados numericamente positivos utilizando uma tolerância adequada.
5. Tente utilizar diretamente

$$(\mathbf{X}^\top \mathbf{X})^{-1}$$

e explique o problema encontrado.

6. Construa manualmente a pseudoinversa de $\mathbf{X}$ a partir de sua SVD, invertendo apenas os valores singulares considerados positivos.
7. Obtenha

$$\hat{\beta}^+ = \mathbf{X}^+ \mathbf{y}.$$

8. Calcule

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}^+.$$

9. Determine um vetor não nulo

$$\mathbf{h} \in \mathcal{N}(\mathbf{X}).$$

10. Para diferentes valores de γ , construa

$$\hat{\beta}(\gamma) = \hat{\beta}^+ + \gamma \mathbf{h}.$$

11. Verifique que todos esses vetores produzem o mesmo vetor ajustado.

12. Compare numericamente

$$\|\hat{\beta}(\gamma)\|$$

para vários valores positivos e negativos de γ .

13. Verifique que a solução fornecida pela pseudoinversa possui a menor norma euclidiana.

14. Relacione a não unicidade dos coeficientes ao núcleo de $\mathbf{X}$.

Exercício 7.29 (Vetorização de um modelo com várias respostas). Retome as matrizes $\mathbf{X}$, $\mathbf{Y}$ e $\widehat{\mathbf{B}}$ do Exercício 7.27.

A relação matricial é

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\mathbf{B}}.$$

1. Construa em R

$$\text{vec}(\widehat{\mathbf{Y}})$$

empilhando as colunas.

2. Construa

$$\text{vec}(\widehat{\mathbf{B}}).$$

3. Construa

$$\mathbf{I}_2 \otimes \mathbf{X}.$$

4. Verifique suas dimensões.

5. Verifique numericamente que

$$\text{vec}(\widehat{\mathbf{Y}}) = (\mathbf{I}_2 \otimes \mathbf{X}) \text{vec}(\widehat{\mathbf{B}}).$$

6. Compare as dimensões dos dois lados da igualdade.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a variar no mesmo sentido, em sentidos opostos ou se apresentam relações lineares de redundância.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, caracterizar relações lineares entre as componentes e representar geometricamente a dispersão conjunta (Johnson; Wichern, 2007).

A matriz de correlações resulta da padronização das covariâncias pelos desvios-padrão das variáveis. Seus elementos são adimensionais e permitem comparar a intensidade e o sentido das associações lineares entre variáveis medidas em diferentes unidades.

O objetivo deste capítulo é desenvolver essas estruturas nos níveis populacional e descritivo dos dados observados. As propriedades inferenciais das estatísticas amostrais serão estudadas no Capítulo 10. A distribuição normal multivariada, apresentada no próximo capítulo, utilizará a matriz de covariâncias para construir um modelo probabilístico para a variabilidade conjunta.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathcal{R} \in \mathbb{R}^{p \times p}$ representa a matriz de correlações populacional;
- $\boldsymbol{\Sigma}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas entre os vetores aleatórios $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias populacionais;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa uma matriz de dados observada, com observações nas linhas e variáveis nas colunas;
- $\bar{\mathbf{x}} \in \mathbb{R}^p$ representa o vetor de médias calculado a partir dos dados observados;
- $\mathbf{H}_n = \mathbf{I}_n - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top$ representa a matriz de centralização;
- $\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$ representa a matriz de dados centralizada;
- $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$ representa a matriz total de somas de quadrados e produtos cruzados;
- $\mathbf{S} \in \mathbb{R}^{p \times p}$ e $\mathbf{R} \in \mathbb{R}^{p \times p}$ representam, respectivamente, as matrizes de covariâncias e

- de correlações calculadas a partir dos dados observados;
- $\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp})$ representa a matriz diagonal das variâncias observadas;
- $\mathbf{S}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas calculada entre dois blocos de variáveis observadas;
- $\mathbf{X}$, $\mathbf{T}$, $\mathbf{S}$ e $\mathbf{R}$ representam, respectivamente, a média amostral, a matriz de somas de quadrados e produtos cruzados centralizados, a matriz de covariâncias amostral e a matriz de correlações amostral consideradas como objetos aleatórios; suas propriedades serão desenvolvidas no Capítulo 10;
- $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ representam as parcelas intragrupos e entre grupos da matriz total de somas de quadrados e produtos cruzados;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam, respectivamente, as somas de quadrados total, intragrupos e entre grupos obtidas pelos traços de $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam essas somas de quadrados consideradas como objetos aleatórios;
- $QM_{\text{intra}} = SQ_{\text{intra}}/(n - K)$ e $QM_{\text{entre}} = SQ_{\text{entre}}/(K - 1)$ representam os quadrados médios intragrupos e entre grupos no caso escalar;
- Σ^+ representa a pseudoinversa de Moore–Penrose de Σ quando a matriz de covariâncias é singular.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, formas quadráticas, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais e pseudoinversa permanecem válidas.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Retomando Definição 1.2, considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com realização $\mathbf{x} \in \mathbb{R}^p$. Quando n realizações são observadas, sua organização em uma matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ segue a representação estabelecida na Definição 1.6.

Suponha inicialmente que $E(|X_j|) < \infty$ para $j = 1, \dots, p$. O **vetor de médias populacional** é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \in \mathbb{R}^p. \quad (8.1)$$

O vetor μ determina a localização média da distribuição no espaço das observações. Subtraindo esse vetor de $\mathbf{X}$, obtém-se o vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu. \quad (8.2)$$

Pela linearidade da esperança,

$$E(\mathbf{X}_c) = E(\mathbf{X}) - \mu = \mathbf{0}.$$

A centralização corresponde a uma translação da distribuição, levando seu vetor de médias à origem. Como estabelecido na Proposição 4.15, a subtração do mesmo vetor de todos os pontos preserva as distâncias entre pares de realizações. Portanto, a centralização altera a localização, mas não a geometria relativa da nuvem de pontos.

A centralização da matriz de dados observada será retomada posteriormente neste capítulo, quando forem construídas a matriz de produtos cruzados e a matriz de covariâncias observada.

8.1.2 Momentos de segunda ordem

O estudo das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante também a existência dos primeiros momentos. Além disso, para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz aplicada a variáveis aleatórias de segundo momento finito fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

Portanto, os produtos cruzados necessários à construção das covariâncias possuem esperança finita.

A matriz de segundos momentos em relação à origem é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top) \in \mathbb{R}^{p \times p}.$$

O produto $\mathbf{X}\mathbf{X}^\top$ é o produto externo definido na Definição 1.14. Seus elementos são

$$[\mathbf{X}\mathbf{X}^\top]_{jk} = X_j X_k,$$

de modo que

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1 X_2) & \cdots & E(X_1 X_p) \\ E(X_2 X_1) & E(X_2^2) & \cdots & E(X_2 X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_p X_1) & E(X_p X_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Seus elementos dependem, portanto, da localização da distribuição e de sua variabilidade conjunta.

Para descrever a dispersão em torno do vetor de médias, utiliza-se o segundo momento central:

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Expandindo o produto e utilizando $E(\mathbf{X}) = \mu$,

$$\begin{aligned} \Sigma &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top \\ &= \mathbf{M}_2 - \mu\mu^\top. \end{aligned} \tag{8.3}$$

A identidade Equação 8.3 é a versão matricial da relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está, portanto, no ponto de referência: $\mathbf{M}_2$ descreve segundos momentos em relação à origem, enquanto Σ descreve a variabilidade em torno da média.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com segundos momentos finitos e médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se X e Y são variáveis aleatórias com segundos momentos finitos e médias $\mu_X = E(X)$ e $\mu_Y = E(Y)$, a **covariância populacional** entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva indica predominância de desvios de mesmo sinal;
- uma covariância negativa indica predominância de desvios de sinais opostos;
- uma covariância nula indica ausência de associação linear registrada pela covariância.

A Figura 8.1 apresenta configurações com covariâncias positiva, aproximadamente nula e negativa.




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

Na primeira configuração, a nuvem de pontos tende a se alongar em uma direção crescente; na terceira, em uma direção decrescente. A configuração central não apresenta orientação linear predominante. O valor da covariância depende também das escalas das variáveis e, por isso,

seu módulo não fornece isoladamente uma medida comparável de intensidade entre diferentes pares de variáveis.

Expandindo o produto dos desvios,

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.\end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.4)$$

A expressão Equação 8.4 relaciona a covariância ao momento conjunto $E(XY)$ e aos primeiros momentos das duas variáveis.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.5)$$

A identidade Equação 8.5 mostra que translações não alteram a covariância. Mudanças de escala multiplicam a covariância pelo produto dos fatores aplicados às duas variáveis. Quando somente um desses fatores é negativo, o sinal da covariância é invertido.

Essa dependência das unidades impede a comparação direta entre covariâncias associadas a pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, por exemplo, sua covariância com outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.6)$$

O limite Equação 8.6 será utilizado posteriormente para mostrar que a correlação pertence ao intervalo $[-1, 1]$.

Covariância nula e independência

Covariância nula não implica independência em uma distribuição geral. A covariância registra associação linear de segunda ordem, e relações não lineares podem produzir covariância igual a zero.

Exemplo 8.1 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X , possui média zero e segundo momento finito.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Como ε é independente de X ,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Para calcular a covariância entre X e Y , utiliza-se

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Como $Y = X^2 + \varepsilon$,

$$\begin{aligned} E(XY) &= E[X(X^2 + \varepsilon)] \\ &= E(X^3) + E(X\varepsilon) \\ &= 0. \end{aligned}$$

Além disso,

$$E(X)E(Y) = 0,$$

pois $E(X) = 0$. Portanto,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0.$$

Apesar da covariância nula, X e Y não são independentes. Para verificar isso, considere a esperança condicional de Y dado $X = x$. Como

$$\begin{aligned} E(Y \mid X = x) &= E(X^2 + \varepsilon \mid X = x) \\ &= x^2 + E(\varepsilon \mid X = x). \end{aligned}$$

Como ε é independente de X ,

$$E(\varepsilon \mid X = x) = E(\varepsilon) = 0.$$

Portanto,

$$E(Y \mid X = x) = x^2.$$

Assim, a média condicional de Y depende do valor de X . Se X e Y fossem independentes, a distribuição condicional de Y dado $X = x$ seria a mesma distribuição marginal de Y e, consequentemente,

$$E(Y \mid X = x) = E(Y),$$

não dependendo de x . Logo, X e Y são dependentes, apesar de apresentarem covariância nula.

A Figura 8.2 ilustra essa relação.

A configuração parabólica evidencia uma dependência que não produz orientação linear global. O exemplo delimita a informação fornecida pela covariância e mostra por que o valor zero não deve ser interpretado, sem hipóteses adicionais, como independência.

As variâncias das componentes e as covariâncias entre todos os pares de componentes podem ser reunidas em uma única matriz.




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

Definição 8.2 (Matriz de covariâncias populacional). Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com vetor de médias μ e segundos momentos finitos. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top] \in \mathbb{R}^{p \times p}. \quad (8.7)$$

O elemento situado na linha j e na coluna k de Σ é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.8)$$

Os elementos da diagonal principal são as variâncias,

$$\sigma_{jj} = \text{Var}(X_j),$$

e os elementos fora da diagonal são as covariâncias entre componentes distintos.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

tem-se

$$\sigma_{jk} = \sigma_{kj},$$

e Σ é simétrica. Para p componentes, existem p variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas, totalizando

$$\frac{p(p+1)}{2}$$

elementos distintos.

As unidades dos elementos dependem das variáveis envolvidas. Se X_j é medida em uma unidade u_j , então

$$\sigma_{jj}$$

é expressa em u_j^2 . Para $j \neq k$,

$$\sigma_{jk}$$

é expressa em $u_j u_k$. Essa dependência das unidades motiva a construção posterior da matriz de correlações.

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ possui a forma

$$Y = \mathbf{a}^\top \mathbf{X}, \quad \mathbf{a} \in \mathbb{R}^p.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação e define uma direção no espaço das variáveis. A combinação linear, já utilizada no Módulo 1, adquire aqui uma interpretação probabilística: sua média e sua variância são determinadas por μ e Σ .

Proposição 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \tag{8.9}$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}, \tag{8.10}$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \tag{8.11}$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}.$$

Além disso,

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu} = \mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}).$$

Consequentemente,

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}] \\ &= \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned}$$

De modo análogo,

$$\begin{aligned} \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{b}] \\ &= \mathbf{a}^\top \Sigma \mathbf{b}. \end{aligned}$$

□

A expressão Equação 8.10 mostra que a matriz de covariâncias determina a variabilidade de todas as combinações lineares das componentes. A quantidade

$$\mathbf{a}^\top \Sigma \mathbf{a}$$

é uma forma quadrática no sentido de Definição 2.23. Quando $\|\mathbf{a}\| = 1$, ela representa a variância da projeção de $\mathbf{X}$ sobre a direção unitária $\mathbf{a}$.

Essa relação constitui a ligação entre a matriz de covariâncias e a geometria desenvolvida no Módulo 1: diferentes direções podem apresentar diferentes níveis de dispersão.

Exemplo 8.2 (Matriz de covariâncias com três variáveis). Considere

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

As variâncias das três componentes são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9, \quad \text{Var}(X_3) = 1,$$

e as covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1,5,$$

$$\text{Cov}(X_1, X_3) = -0,8,$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere a combinação linear

$$Y = X_1 + 0,5X_2 - X_3,$$

com vetor de coeficientes

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação 8.10,

$$\begin{aligned} \text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\ &= \begin{bmatrix} 1 & 0,5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix} \\ &= 10,35. \end{aligned}$$

A variância da combinação depende das variâncias individuais, das covariâncias e dos coeficientes utilizados. A covariância negativa entre X_1 e X_3 , por exemplo, contribui positivamente para $\text{Var}(Y)$ porque os coeficientes dessas duas componentes possuem sinais opostos.

8.2.3 Propriedades estruturais e singularidade

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. A classificação de positividade de matrizes foi estabelecida na Definição 2.24; aqui ela adquire uma interpretação probabilística direta, pois a forma quadrática associada a Σ representa uma variância (Eaton, 2007).

Proposição 8.2 (Caracterização estrutural das matrizes de covariâncias). *Uma matriz $\mathbf{C} \in \mathbb{R}^{p \times p}$ é matriz de covariâncias de algum vetor aleatório com segundos momentos finitos se, e somente se,*

$$\mathbf{C} = \mathbf{C}^\top$$

e

$$\mathbf{C} \succeq \mathbf{0}.$$

Consequentemente, toda matriz de covariâncias possui elementos diagonais não negativos, autovalores não negativos e submatrizes principais positivas semidefinidas.

Comprovação. Se

$$\mathbf{C} = \text{Cov}(\mathbf{X}),$$

a simetria decorre de

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j).$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{C} \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Logo, $\mathbf{C}$ é positiva semidefinida.

Reciprocamente, suponha que $\mathbf{C}$ seja real, simétrica e positiva semidefinida. Pelo Teorema 5.4 e pela raiz quadrada principal definida na Definição 5.9, existe uma matriz simétrica positiva semidefinida $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}, \quad j = 1, \dots, p.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{X} = \mathbf{C}^{1/2} \mathbf{U}.$$

Como

$$E(\mathbf{U}) = \mathbf{0},$$

tem-se

$$E(\mathbf{X}) = \mathbf{C}^{1/2} E(\mathbf{U}) = \mathbf{0}.$$

Além disso,

$$E(\mathbf{U}\mathbf{U}^\top) = \mathbf{I}_p.$$

Logo,

$$\begin{aligned}
\text{Cov}(\mathbf{X}) &= E(\mathbf{X}\mathbf{X}^\top) \\
&= E(\mathbf{C}^{1/2}\mathbf{U}\mathbf{U}^\top\mathbf{C}^{1/2}) \\
&= \mathbf{C}^{1/2}E(\mathbf{U}\mathbf{U}^\top)\mathbf{C}^{1/2} \\
&= \mathbf{C}^{1/2}\mathbf{I}_p\mathbf{C}^{1/2} \\
&= \mathbf{C}.
\end{aligned}$$

Portanto, toda matriz real simétrica positiva semidefinida pode ocorrer como matriz de covariâncias. $\square$

Essa construção estabelece apenas a existência de um vetor aleatório com matriz de covariâncias $\mathbf{C}$ e não exige uma família de distribuições específica.

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

também deve ser positiva semidefinida. Logo,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

o que equivale a

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

Esse resultado recupera, no nível matricial, o limite apresentado na Equação 8.6.

A simetria, isoladamente, não é suficiente para caracterizar uma matriz de covariâncias.

Exemplo 8.3 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica. Entretanto, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2.\end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de uma combinação linear, o que é impossível. A matriz é, portanto, simétrica, mas não positiva semidefinida.

Quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$, a matriz Σ é positiva definida. Pela Equação 8.10, isso significa que toda combinação linear não trivial das componentes possui variância positiva.

A situação muda quando Σ é singular. Nesse caso, aparecerá a expressão **quase certamente**. Seja U uma variável aleatória definida em um espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e seja $c \in \mathbb{R}$. Escrever

$$U = c \quad \text{quase certamente}$$

significa que

$$P(\{\omega \in \Omega : U(\omega) = c\}) = P(U = c) = 1.$$

Equivalentemente, a igualdade pode falhar apenas em um conjunto de resultados de probabilidade zero.

Proposição 8.3 (Caracterização da singularidade da matriz de covariâncias). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

Comprovação. Como Σ é simétrica e positiva semidefinida, o Teorema 5.4 garante uma decomposição com autovalores não negativos. A matriz é singular se, e somente se, pelo menos um desses autovalores é zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ no núcleo de Σ e, portanto,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ .

Pela Equação 8.10,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}),$$

o que estabelece a equivalência entre as duas condições seguintes.

Uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser zero. Portanto,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

□

A última condição da Proposição 8.3 também pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade de Σ corresponde à existência de uma relação afim exata e não trivial entre as componentes do vetor aleatório.

Em termos geométricos, os vetores pertencentes a

$$\mathcal{N}(\Sigma)$$

determinam direções de variância nula. Como Σ é simétrica, a relação entre núcleo e espaço coluna desenvolvida no Módulo 1 permite escrever

$$\mathcal{N}(\Sigma)^\perp = \mathcal{C}(\Sigma).$$

Consequentemente,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma) \quad \text{quase certamente.}$$

Se

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade do vetor centralizado está restrita a um subespaço de dimensão r . O vetor original está, portanto, restrito quase certamente ao subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

A matriz de covariâncias também pode ser utilizada para descrever conjuntamente dois vetores aleatórios distintos. Essa extensão produz matrizes retangulares de covariâncias cruzadas e permite representar as relações lineares entre dois blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam segundos momentos finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}, \quad (8.12)$$

em que $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ possuem segundos momentos finitos e médias μ_X e μ_Y , respectivamente.

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para $j = 1, \dots, p$ e $k = 1, \dots, q$. Portanto,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A orientação da matriz depende da ordem dos vetores. Invertendo essa ordem,

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (8.13)$$

Assim,

$$\Sigma_{XY} \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} \in \mathbb{R}^{q \times p}.$$

Mesmo quando $p = q$, não se tem em geral

$$\Sigma_{XY} = \Sigma_{YX},$$

pois uma matriz de covariâncias cruzadas não precisa ser simétrica.

Proposição 8.4 (Covariância entre combinações de dois vetores). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Para quaisquer vetores fixos*

$$\mathbf{a} \in \mathbb{R}^p \quad e \quad \mathbf{b} \in \mathbb{R}^q,$$

tem-se

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (8.14)$$

Comprovação. As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} & \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\ &= E \left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b} \right] \\ &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \end{aligned}$$

□

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

se, e somente se,

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para todos os vetores $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$. Nesse caso, nenhuma combinação linear do primeiro bloco possui covariância não nula com uma combinação linear do segundo.

A condição

$$\Sigma_{XY} = \mathbf{0}$$

não implica, em uma distribuição geral, independência entre os vetores. Essa relação será retomada no Capítulo 9 sob a distribuição normal multivariada.

Os dois vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{V} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix},$$

e sua matriz de covariâncias pode ser representada por blocos, conforme a estrutura de matrizes particionadas definida na Definição 2.25:

$$\Sigma_V = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.15)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor, enquanto os blocos fora da diagonal descrevem as covariâncias entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa condição restringe conjuntamente seus blocos. Em particular, Σ_{XY} não pode ser especificada arbitrariamente depois de fixadas Σ_{XX} e Σ_{YY} .

8.3.1.1 Complemento de Schur e dispersão residual

O complemento de Schur já foi definido na Definição 2.26. Aplicado à matriz de covariâncias particionada, ele recebe uma interpretação estatística de segunda ordem.

Suponha que

$$\Sigma_{YY} \succ \mathbf{0}.$$

O complemento de Schur de Σ_{YY} em Σ_V é

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}. \quad (8.16)$$

Pelo resultado de positividade do complemento de Schur no Teorema 2.9,

$$\Sigma_{XX.Y} \succeq \mathbf{0}.$$

A expressão também pode ser interpretada diretamente como uma covariância residual.

Proposição 8.5 (Complemento de Schur e covariância residual). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos, vetores de médias

$$\mu_X = E(\mathbf{X}) \quad e \quad \mu_Y = E(\mathbf{Y}),$$

e matriz de covariâncias conjunta

$$\text{Cov} \left(\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \right) = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}.$$

Se

$$\Sigma_{YY} \succ \mathbf{0},$$

o complemento de Schur

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$$

é a menor matriz de covariâncias residuais, segundo a ordem de Loewner, entre as matrizes obtidas ao aproximar linearmente $\mathbf{X}_c$ por $\mathbf{LY}_c$, com

$$\mathbf{L} \in \mathbb{R}^{p \times q}.$$

Para

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1},$$

tem-se

$$\text{Cov}(\mathbf{R}_{\mathbf{L}^*}) = \Sigma_{XX.Y},$$

e, para qualquer

$$\mathbf{L} \in \mathbb{R}^{p \times q},$$

tem-se

$$\text{Cov}(\mathbf{R}_{\mathbf{L}}) - \Sigma_{XX.Y} \succeq \mathbf{0},$$

em que

$$\mathbf{R}_{\mathbf{L}} = \mathbf{X}_c - \mathbf{LY}_c,$$

$$\mathbf{X}_c = \mathbf{X} - \mu_X \quad e \quad \mathbf{Y}_c = \mathbf{Y} - \mu_Y$$

Comprovação. Para uma matriz arbitrária $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_{\mathbf{L}}) = \Sigma_{XX} - \mathbf{L}\Sigma_{YX} - \Sigma_{XY}\mathbf{L}^{\top} + \mathbf{L}\Sigma_{YY}\mathbf{L}^{\top}.$$

Substituindo

$$\mathbf{L}^{\star} = \Sigma_{XY}\Sigma_{YY}^{-1},$$

a expressão pode ser reorganizada como

$$\begin{aligned} \text{Cov}(\mathbf{R}_{\mathbf{L}}) &= \Sigma_{XX.Y} \\ &\quad + (\mathbf{L} - \mathbf{L}^{\star})\Sigma_{YY}(\mathbf{L} - \mathbf{L}^{\star})^{\top}. \end{aligned}$$

Como Σ_{YY} é positiva definida,

$$(\mathbf{L} - \mathbf{L}^{\star})\Sigma_{YY}(\mathbf{L} - \mathbf{L}^{\star})^{\top} \succeq \mathbf{0}.$$

A diferença entre a covariância residual correspondente a qualquer $\mathbf{L}$ e aquela obtida com $\mathbf{L}^{\star}$ é, portanto, positiva semidefinida. $\square$

Essa interpretação depende apenas dos segundos momentos e não exige normalidade. Sob normalidade conjunta, o mesmo complemento de Schur aparecerá no Capítulo 9 como matriz de covariâncias da distribuição condicional de um bloco dado o outro.

Exemplo 8.4 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix}.$$

Para as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2,$$

os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação 8.14,

$$\begin{aligned} \text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\ &= [1 \quad -2] \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\ &= -7. \end{aligned}$$

A covariância entre U e V resulta conjuntamente das covariâncias entre todas as componentes que participam das duas combinações lineares.

8.3.2 Transformações afins da média e da covariância

As transformações afins foram definidas na Definição 4.7. No contexto probabilístico, interessa determinar como elas modificam a média e a matriz de covariâncias.

Considere

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r.$$

Proposição 8.6 (Média e covariância sob transformação afim). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ_X e matriz de covariâncias Σ_{XX} . Para*

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c}, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r,$$

tem-se

$$E(\mathbf{U}) = \mathbf{A}\mu_X + \mathbf{c} \quad (8.17)$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \quad (8.18)$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{A}\mathbf{X} + \mathbf{c}) = \mathbf{A}\mu_X + \mathbf{c}.$$

O vetor transformado centralizado é

$$\begin{aligned} \mathbf{U} - E(\mathbf{U}) &= \mathbf{A}\mathbf{X} + \mathbf{c} - \mathbf{A}\mu_X - \mathbf{c} \\ &= \mathbf{A}(\mathbf{X} - \mu_X). \end{aligned}$$

Portanto,

$$\begin{aligned} \text{Cov}(\mathbf{U}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \end{aligned}$$

□

A ausência do vetor $\mathbf{c}$ na Equação 8.18 confirma que translações alteram a localização, mas não a matriz de covariâncias.

Quando

$$r = 1 \quad \text{e} \quad \mathbf{A} = \mathbf{a}^\top,$$

a expressão reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a},$$

recuperando Equação 8.10.

Se $\mathbf{A}$ é diagonal,

$$\mathbf{A} = \text{diag}(a_1, \dots, a_p),$$

então

$$\text{Cov}(a_j X_j, a_k X_k) = a_j a_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(a_j X_j) = a_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal no sentido de Definição 2.18,

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Como $\mathbf{Q}^\top = \mathbf{Q}^{-1}$, essa transformação produz uma matriz semelhante a Σ_{XX} e preserva seus autovalores. A interpretação estatística dessa propriedade será retomada na geometria da covariância.

Exemplo 8.5 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e

$$\mathbf{U} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As componentes transformadas são

$$U_1 = X_1 + X_2$$

e

$$U_2 = X_1 - X_2.$$

Pela expressão Equação 8.18,

$$\begin{aligned}\text{Cov}(\mathbf{U}) &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}.\end{aligned}$$

Logo,

$$\text{Var}(U_1) = 17, \quad \text{Var}(U_2) = 9$$

e

$$\text{Cov}(U_1, U_2) = -5.$$

A transformação modifica simultaneamente as variâncias das componentes e a covariância entre elas.

As covariâncias cruzadas também se transformam de maneira compatível.

Proposição 8.7 (Covariância cruzada sob transformações afins). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Considere*

$$\mathbf{U} = \mathbf{A}_X\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{A}_Y\mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{A}_X \in \mathbb{R}^{r \times p}, \quad \mathbf{A}_Y \in \mathbb{R}^{s \times q}, \quad \mathbf{c} \in \mathbb{R}^r, \quad \mathbf{d} \in \mathbb{R}^s.$$

Então,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \quad (8.19)$$

Comprovação. Após a centralização,

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}_X (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{A}_Y (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E \left[\mathbf{A}_X (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{A}_Y^\top \right] \\ &= \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \end{aligned}$$

□

As expressões Equação 8.18 e Equação 8.19 mostram que a matriz de covariâncias responde de maneira sistemática às transformações lineares. A padronização das componentes constitui um caso particular dessa estrutura.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar as escalas marginais, suponha que

$$\sigma_{jj} = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias populacionais por

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}). \quad (8.20)$$

Como todas as variâncias são positivas,

$$\mathbf{D}_{\Sigma} \succ \mathbf{0}$$

e existem as matrizes diagonais

$$\mathbf{D}_{\Sigma}^{1/2} = \text{diag} \left(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}} \right)$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Definição 8.4 (Vetor aleatório padronizado). Se $\mathbf{X} \in \mathbb{R}^p$ possui média μ e variâncias marginais positivas, o vetor aleatório marginalmente padronizado correspondente é

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu), \quad (8.21)$$

em que $\mathbf{D}_{\Sigma} \succ \mathbf{0}$ é a matriz diagonal das variâncias populacionais e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Sua componente j é

$$Z_j = \frac{X_j - \mu_j}{\sqrt{\sigma_{jj}}}.$$

Assim,

$$E(Z_j) = 0$$

e

$$\text{Var}(Z_j) = 1.$$

Em forma vetorial,

$$E(\mathbf{Z}) = \mathbf{0}.$$

Aplicando Equação 8.18,

$$\text{Cov}(\mathbf{Z}) = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Definição 8.5 (Matriz de correlações populacional). A **matriz de correlações populacional** de $\mathbf{X} \in \mathbb{R}^p$ é

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}, \quad (8.22)$$

em que Σ é a matriz de covariâncias de $\mathbf{X}$ e

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}),$$

com

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

O símbolo $\mathcal{R}$ é reservado à matriz populacional. Posteriormente, $\mathbf{R}$ representará a matriz de correlações amostral, enquanto $\mathbf{R}$ representará seu valor calculado a partir de uma amostra observada.

A matriz $\mathcal{R}$ possui a forma

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sqrt{\sigma_{jj}\sigma_{kk}}}. \quad (8.23)$$

Equivalentemente,

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

A correlação é adimensional porque o numerador e o denominador de Equação 8.23 possuem as mesmas unidades.

A relação entre covariâncias e correlações pode ser invertida:

$$\Sigma = \mathbf{D}_{\Sigma}^{1/2} \mathcal{R} \mathbf{D}_{\Sigma}^{1/2}. \quad (8.24)$$

Portanto, Σ pode ser decomposta em dois elementos:

- $\mathbf{D}_{\Sigma}$ registra as variâncias e, consequentemente, as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear após a remoção dessas escalas.

A matriz de correlações isoladamente não permite recuperar as variâncias originais.

Exemplo 8.6 (Matriz de correlações obtida por uma transformação de padronização). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com vetor de médias μ e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix}.$$

Os desvios-padrão populacionais são

$$\sqrt{\sigma_{11}} = 4 \quad \text{e} \quad \sqrt{\sigma_{22}} = 5.$$

Portanto,

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 16 & 0 \\ 0 & 25 \end{bmatrix}$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix}.$$

Considere a transformação de padronização

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu).$$

Ela pode ser escrita como a transformação afim

$$\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

com

$$\mathbf{A} = \mathbf{D}_{\Sigma}^{-1/2}$$

e

$$\mathbf{c} = -\mathbf{D}_{\Sigma}^{-1/2}\boldsymbol{\mu}.$$

Utilizando Proposição 8.6,

$$\text{Cov}(\mathbf{Z}) = \mathbf{A}\Sigma\mathbf{A}^{\top}.$$

Como $\mathbf{A}$ é diagonal e simétrica,

$$\begin{aligned}\text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.\end{aligned}$$

Essa é precisamente a matriz de correlações populacional,

$$\mathcal{R} = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.$$

De fato,

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \frac{12}{\sqrt{16 \cdot 25}} = \frac{12}{20} = 0,6.$$

O exemplo mostra duas formas equivalentes de chegar ao mesmo resultado. Pela transformação do vetor,

$$\text{padronizar } \mathbf{X} \implies \text{Cov}(\mathbf{Z}).$$

Equivalentemente, pode-se transformar diretamente a matriz de covariâncias:

$$\Sigma \implies \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Em ambas as perspectivas, as variâncias tornam-se unitárias e a covariância entre as componentes padronizadas passa a coincidir com sua correlação.

8.4.2 Propriedades, escala e independência

Proposição 8.8 (Caracterização das matrizes de correlações). *Uma matriz*

$$\mathbf{C} \in \mathbb{R}^{p \times p}$$

é matriz de correlações de algum vetor aleatório com variâncias marginais positivas se, e somente se,

$$\mathbf{C} = \mathbf{C}^{\top},$$

$$\mathbf{C} \succeq \mathbf{0}$$

e

$$c_{jj} = 1, \quad j = 1, \dots, p.$$

Consequentemente, toda matriz de correlações possui:

1. elementos no intervalo $[-1, 1]$;
2. autovalores reais e não negativos;
3. traço igual a p .

Comprovação. Se $\mathbf{C} = \mathcal{R}$ é uma matriz de correlações, então

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Como Σ é simétrica,

$$\mathcal{R}^{\top} = \mathcal{R}.$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \mathcal{R} \mathbf{a} &= \left(\mathbf{D}_\Sigma^{-1/2} \mathbf{a} \right)^\top \Sigma \left(\mathbf{D}_\Sigma^{-1/2} \mathbf{a} \right) \\ &\geq 0,\end{aligned}$$

de modo que

$$\mathcal{R} \succeq \mathbf{0}.$$

A diagonal é unitária porque

$$\rho_{jj} = \frac{\sigma_{jj}}{\sqrt{\sigma_{jj}\sigma_{jj}}} = 1.$$

Reciprocamente, suponha que $\mathbf{C}$ seja simétrica, positiva semidefinida e possua diagonal unitária. Pela raiz quadrada principal definida na Definição 5.9, existe $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{Z} = \mathbf{C}^{1/2} \mathbf{U}.$$

Tem-se

$$\text{Cov}(\mathbf{Z}) = \mathbf{C}^{1/2} \mathbf{I}_p \mathbf{C}^{1/2} = \mathbf{C}.$$

Como a diagonal de $\mathbf{C}$ é unitária, todas as componentes de $\mathbf{Z}$ possuem variância igual a um. Logo, sua matriz de covariâncias coincide com sua matriz de correlações, e $\mathbf{C}$ é uma matriz de correlações válida.

Pela desigualdade de Cauchy–Schwarz,

$$|c_{jk}| \leq \sqrt{c_{jj}c_{kk}} = 1.$$

Como $\mathbf{C}$ é simétrica e positiva semidefinida, seus autovalores são reais e não negativos. Finalmente,

$$\text{tr}(\mathbf{C}) = \sum_{j=1}^p c_{jj} = p.$$

□

Se Σ possui variâncias marginais positivas, então $\mathbf{D}_\Sigma^{-1/2}$ é invertível e a padronização preserva a definição positiva. Assim,

$$\mathcal{R} \succ \mathbf{0} \quad \Longleftrightarrow \quad \Sigma \succ \mathbf{0}.$$

Os valores extremos da correlação correspondem a relações lineares exatas entre as variáveis padronizadas. Para $j \neq k$,

$$\rho_{jk} = 1 \quad \Longleftrightarrow \quad Z_k = Z_j \quad \text{quase certamente,}$$

enquanto

$$\rho_{jk} = -1 \quad \Longleftrightarrow \quad Z_k = -Z_j \quad \text{quase certamente.}$$

Portanto, uma correlação de módulo igual a 1 implica uma relação linear exata entre as duas variáveis e, conseqüentemente, a singularidade da matriz de covariâncias do par correspondente.

Além disso, não basta que cada correlação, considerada isoladamente, pertença ao intervalo $[-1, 1]$ para que uma matriz seja uma matriz de correlações válida; a matriz completa também deve ser positiva semidefinida.

Exemplo 8.7 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0,9 & 0,9 \\ 0,9 & 1 & -0,9 \\ 0,9 & -0,9 & 1 \end{bmatrix}.$$

Todos os elementos pertencem ao intervalo $[-1, 1]$, a matriz é simétrica e sua diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2,888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Logo, $\mathbf{A}$ não é uma matriz de correlações.

O exemplo mostra que as correlações entre pares devem ser compatíveis com uma única estrutura conjunta positiva semidefinida.

Duas componentes X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como suas variâncias são positivas,

$$\rho_{jk} = 0 \iff \sigma_{jk} = 0.$$

Essa condição não implica independência em uma distribuição geral, conforme ilustrado no Exemplo 8.1.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

e, portanto,

$$\text{Cov}(X_j, X_k) = 0.$$

Assim,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca depende de hipóteses adicionais.

Uma matriz de correlações diagonal necessariamente é

$$\mathcal{R} = \mathbf{I}_p.$$

Nesse caso, todas as componentes são duas a duas não correlacionadas. Essa propriedade não garante, por si só, independência conjunta. A relação especial entre ausência de correlação e independência sob normalidade conjunta será estabelecida no Capítulo 9.

Considere agora uma mudança de localização e escala aplicada separadamente às componentes:

$$Y_j = c_j X_j + d_j, \quad c_j \neq 0.$$

Tem-se

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk},$$

enquanto

$$\text{Var}(Y_j) = c_j^2 \sigma_{jj}.$$

Consequentemente,

$$\text{Corr}(Y_j, Y_k) = \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \quad (8.25)$$

Se $c_j > 0$ e $c_k > 0$,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Portanto, translações e mudanças positivas de unidade não alteram a correlação. A multiplicação de uma variável por uma constante negativa inverte o sinal de suas correlações, sem alterar seus módulos.

Exemplo 8.8 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.2:

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

A matriz das variâncias marginais é

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de modo que

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.22,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2} \\ &= \begin{bmatrix} 1 & 0,25 & -0,4 \\ 0,25 & 1 & 0 \\ -0,4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1,5}{\sqrt{4 \cdot 9}} = 0,25,$$

enquanto

$$\rho_{13} = \frac{-0,8}{\sqrt{4 \cdot 1}} = -0,4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

tem-se

$$|\rho_{13}| > |\rho_{12}|.$$

A covariância entre X_1 e X_2 possui maior módulo nas unidades originais, mas a associação linear padronizada entre X_1 e X_3 é mais intensa. A comparação evidencia a diferença entre a informação fornecida por covariâncias e por correlações.

A matriz de covariâncias preserva as variâncias e as unidades originais das componentes. A matriz de correlações descreve a mesma estrutura de segunda ordem após a padronização marginal, atribuindo variância unitária a todas as componentes. Essa mudança de escala pode alterar a geometria da dispersão e será considerada na interpretação espectral das duas matrizes.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais e elipsoide de covariância

A expressão Equação 8.10 mostra que a matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa quantidade representa a dispersão ao longo da direção unitária $\mathbf{a}$. A interpretação espectral das formas quadráticas foi desenvolvida no Capítulo 5. Aplicando o Teorema 5.4 à matriz simétrica positiva semidefinida Σ ,

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top, \quad (8.26)$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j \geq 0.$$

A transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.27)$$

expressa o vetor centralizado nas coordenadas da base de autovetores. Pela regra de transformação da covariância,

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \Lambda. \quad (8.28)$$

Portanto,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Cov}(Y_j, Y_k) = 0, \quad j \neq k.$$

Os autovetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. O autovalor λ_j quantifica a variância ao longo do eixo $\mathbf{q}_j$.

Se

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

o resultado sobre os extremos do quociente de Rayleigh no Teorema 5.5 fornece

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.29)$$

Os valores extremos são alcançados nos autovetores correspondentes. Assim, a decomposição espectral identifica direções ortogonais nas quais as covariâncias desaparecem e as variâncias são dadas diretamente pelos autovalores.

Neste capítulo, essa decomposição é utilizada somente para descrever a geometria da dispersão. A seleção de eixos espectrais para construir uma representação de dimensão reduzida pertence à formulação da Análise de Componentes Principais.

Exemplo 8.9 (Obtenção dos eixos de maior e menor variabilidade). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Queremos determinar a direção unitária

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

na qual a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

apresenta a maior variância possível.

Pela expressão Equação 8.10,

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto, o problema é

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Esse é precisamente o tipo de problema de otimização com restrição estudado no Módulo 1. Como maximizar uma função equivale a minimizar seu negativo, a condição necessária de Lagrange estabelecida no Teorema 7.6 aplica-se também a este problema. Considere

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \Sigma \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1).$$

Como Σ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \Sigma \mathbf{a}) = 2\Sigma \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é, portanto,

$$2\Sigma \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0},$$

ou

$$\Sigma \mathbf{a} = \eta \mathbf{a}. \quad (8.30)$$

Assim, as direções estacionárias do problema são autovetores de Σ , e os multiplicadores de Lagrange correspondentes são seus autovalores.

Para determiná-los,

$$\det(\Sigma - \eta \mathbf{I}_2) = 0.$$

Logo,

$$\begin{aligned} \det \begin{bmatrix} 4-\eta & 2 \\ 2 & 4-\eta \end{bmatrix} &= (4-\eta)^2 - 4 \\ &= \eta^2 - 8\eta + 12 \\ &= (\eta - 6)(\eta - 2). \end{aligned}$$

Os autovalores são, portanto,

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2.$$

Para $\lambda_1 = 6$,

$$(\Sigma - 6\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = a_2.$$

Impondo a restrição de norma unitária,

$$a_1^2 + a_2^2 = 1,$$

podemos escolher

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 2$,

$$(\Sigma - 2\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = -a_2,$$

e podemos escolher

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo resultado dos extremos do quociente de Rayleigh no Teorema 5.5,

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_1 = 6,$$

alcançado na direção $\mathbf{q}_1$, enquanto

$$\min_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_2 = 2,$$

alcançado na direção $\mathbf{q}_2$.

Consequentemente,

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 6$$

e

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 2.$$

Reunindo os autovetores em

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

a transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu)$$

produz

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

O cálculo mostra concretamente a conexão entre **variância de uma combinação linear, otimização restrita e decomposição espectral**: os autovetores da matriz de covariâncias surgem como as direções estacionárias da variância sob a restrição de norma unitária, e os autovalores fornecem as variâncias nessas direções.

Neste ponto, o objetivo é somente compreender a geometria da matriz de covariâncias. A utilização dessas direções para construir uma técnica de redução de dimensionalidade será desenvolvida posteriormente na Análise de Componentes Principais.

Quando Σ é diagonal, os eixos espectrais coincidem com os eixos coordenados. No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \quad (8.31)$$

tem-se, para qualquer vetor unitário $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2.$$

A condição Equação 8.31 descreve uma estrutura de segunda ordem isotrópica: a variância é a mesma em todas as direções. Essa condição, isoladamente, não implica que a distribuição de $\mathbf{X}$ seja esfericamente simétrica.

Suponha agora que

$$\Sigma \succ \mathbf{0}.$$

Para $c > 0$, considere

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.32)$$

A interpretação das superfícies de nível de formas quadráticas positivas definidas foi estabelecida no Capítulo 5. Neste caso, utilizando Equação 8.26 e definindo

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

a condição que define $\mathcal{E}_c$ torna-se

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.33)$$

Portanto:

- o centro é μ ;
- os eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo associado a $\mathbf{q}_j$ possui comprimento $c\sqrt{\lambda_j}$.

Assim, autovalores maiores correspondem a maior extensão da dispersão na direção associada.

A Figura 8.3 mostra essa geometria no caso bidimensional.




Figura 8.3: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias determina, assim, uma geometria de segunda ordem para a dispersão conjunta.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido somente por μ e Σ . Sem uma hipótese adicional sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma probabilidade específica nem interpretá-lo como região de confiança. A interpretação probabilística dessas superfícies será desenvolvida no Capítulo 9 para a distribuição normal multivariada.

Quando Σ é singular, a variabilidade está restrita ao subespaço

$$\mathcal{C}(\Sigma).$$

A raiz quadrada principal definida na Definição 5.9 permite representar o elipsoide degenerado por

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}, \quad (8.34)$$

em que

$$r = \text{posto}(\Sigma) < p.$$

Esse conjunto está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

e possui r semieixos não nulos, com comprimentos $c\sqrt{\lambda_j}$ para os autovalores positivos. A pseudoinversa será utilizada mais adiante para expressar a mesma geometria no contexto da distância de Mahalanobis.

8.5.2 Variância total, variância generalizada e volume

Uma matriz de covariâncias contém toda a estrutura de segunda ordem do vetor aleatório. Algumas funções escalares de Σ resumem aspectos específicos dessa dispersão, mas nenhuma delas substitui a matriz completa.

Definição 8.6 (Variância total). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância total** é

$$V_T(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.35)$$

Pela definição de traço na Definição 2.9,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.36)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.37)$$

A variância total também possui uma interpretação em termos de esperança matemática. Mais geralmente, seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$ um vetor fixo. Então,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}). \quad (8.38)$$

De fato,

$$\mathbf{X} - \mathbf{a} = (\mathbf{X} - \mu) + (\mu - \mathbf{a}),$$

e, ao expandir a forma quadrática, os termos cruzados possuem esperança nula porque

$$E(\mathbf{X} - \mu) = \mathbf{0}.$$

Além disso,

$$E[(\mathbf{X} - \mu)^\top \mathbf{A} (\mathbf{X} - \mu)] = \text{tr}(\mathbf{A}\Sigma).$$

Tomando

$$\mathbf{A} = \mathbf{I}_p \quad \text{e} \quad \mathbf{a} = \mu,$$

obtem-se

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \text{tr} (\Sigma) . \quad (8.39)$$

Portanto, a variância total é o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu vetor de médias.

Mais geralmente, tomando $\mathbf{A} = \mathbf{I}_p$,

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] = \text{tr} (\Sigma) + \|\mu - \mathbf{a}\|^2 . \quad (8.40)$$

Essa expressão mostra que μ minimiza o afastamento quadrático médio:

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] \geq E \left[\|\mathbf{X} - \mu\|^2 \right] .$$

Como

$$\text{tr} (\Sigma) = \sum_{j=1}^p \lambda_j ,$$

segue também que

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \sum_{j=1}^p \lambda_j .$$

Assim, a mesma quantidade pode ser interpretada como soma das variâncias marginais, soma das variâncias nos eixos espectrais ou afastamento euclidiano quadrático médio em relação ao centro.

Definição 8.7 (Variância média). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , com autovalores $\lambda_1, \dots, \lambda_p$, sua **variância média** é

$$\text{VM} (\mathbf{X}) = \frac{1}{p} \text{tr} (\Sigma) = \frac{1}{p} \sum_{j=1}^p \lambda_j .$$

A variância total e a variância média dependem das escalas das componentes. Quando as variáveis possuem unidades distintas, sua interpretação requer cautela.

Outra medida utiliza o determinante da matriz de covariâncias.

Definição 8.8 (Variância generalizada). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância generalizada** é

$$V_G(\mathbf{X}) = \det(\Sigma). \quad (8.41)$$

Pelas propriedades do determinante e pela decomposição espectral,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.42)$$

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se pelo menos um autovalor é zero,

$$\det(\Sigma) = 0,$$

mesmo que exista variabilidade nas demais direções. Nesse caso, o valor zero indica que a dispersão ocupa um subespaço de dimensão inferior a p ; não indica ausência de variabilidade.

A variância generalizada não deve ser confundida com o volume do elipsoide de covariância. A relação entre as duas quantidades envolve a raiz quadrada do determinante (Johnson; Wichern, 2007).

Proposição 8.9 (Volume do elipsoide de covariância). *Se*

$$p \geq 1, \quad \mu \in \mathbb{R}^p, \quad \Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}$$

e

$$c > 0,$$

considere o elipsoide

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}.$$

Seu volume p -dimensional é

$$\text{Vol}_p(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.43)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

Comprovação. O elipsoide é a imagem da bola

$$\mathcal{B}_c = \{\mathbf{u} \in \mathbb{R}^p : \|\mathbf{u}\| \leq c\}$$

pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{u}.$$

A translação não altera o volume. Pelo Proposição 4.9, a transformação linear multiplica volumes por

$$|\det(\Sigma^{1/2})| = \det(\Sigma)^{1/2}.$$

Como

$$\text{Vol}_p(\mathcal{B}_c) = \kappa_p c^p,$$

obtem-se Equação 8.43. □

Portanto,

$$\det(\Sigma)^{1/2}$$

é o fator associado à escala de volume da dispersão, enquanto

$$\det(\Sigma)$$

é a variância generalizada.

Exemplo 8.10 (Variância total e variância generalizada). Considere

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = \text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16$$

e

$$\det(\Sigma_2) = 7.$$

A primeira configuração distribui a variabilidade igualmente entre os dois eixos. A segunda concentra maior variabilidade em uma direção e menor variabilidade na outra. A igualdade das variâncias totais não implica, portanto, igualdade da geometria da dispersão.

As unidades também diferem entre essas medidas. Se as componentes possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 \cdots u_p^2,$$

enquanto

$$\det(\Sigma)^{1/2}$$

possui unidade

$$u_1 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

Considere agora uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela expressão Equação 8.18,

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.$$

Consequentemente,

$$\det(\Sigma_{YY}) = \det(\mathbf{A})^2 \det(\Sigma_{XX}). \quad (8.44)$$

Para a escala de volume,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.45)$$

Essa expressão é compatível com o fator de alteração de volume desenvolvido na Proposição 4.9.

Quando $\mathbf{A}$ é ortogonal, $|\det(\mathbf{A})| = 1$ e a transformação preserva os autovalores de Σ . Consequentemente, preserva a variância total, a variância generalizada e os comprimentos dos semieixos do elipsoide, alterando somente sua orientação no sistema de coordenadas.

A forma quadrática que define o elipsoide fornece também uma medida de afastamento adaptada à estrutura de covariâncias. Essa medida é a distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana utiliza a mesma geometria em todas as direções. Em dados multivariados, entretanto, um deslocamento pode representar um afastamento pequeno em uma direção de grande variabilidade e um afastamento expressivo em outra direção de pequena variabilidade.

A distância de Mahalanobis incorpora essa estrutura por meio da matriz de covariâncias. No caso univariado, ela reduz o afastamento $|x - \mu|$ à sua escala natural,

$$\frac{|x - \mu|}{\sigma}.$$

Definição 8.9 (Distância de Mahalanobis). Se $\Sigma \in \mathbb{R}^{p \times p}$ é positiva definida, a **distância de Mahalanobis** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação a Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.46)$$

Em particular, a distância de $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.47)$$

8.6.1 Interpretação geométrica e espectral

O quadrado da distância de Mahalanobis de $\mathbf{x}$ ao vetor de médias é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.48)$$

Como $\Sigma^{-1} \succ \mathbf{0}$, ela define o produto interno induzido apresentado na Definição 3.16 e a norma correspondente de Definição 3.17. Assim, Equação 8.46 é uma distância métrica, sem necessidade de repetir aqui a demonstração das propriedades métricas desenvolvidas no Módulo 1.

Quando

$$\Sigma = \mathbf{I}_p,$$

a distância de Mahalanobis coincide com a distância euclidiana. Quando $p = 1$,

$$d_M(x, \mu) = \frac{|x - \mu|}{\sigma}.$$

A medida é adimensional, pois a inversa da matriz de covariâncias compensa as unidades presentes no vetor de diferenças.

A interpretação espectral decorre diretamente de Equação 8.26. Se

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

então

$$d_M^2(\mathbf{x}, \mu) = \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \quad (8.49)$$

Essa expressão mostra como a distância de Mahalanobis incorpora a geometria da dispersão. Cada componente u_j representa o deslocamento de $\mathbf{x} - \mu$ na direção do autovetor correspondente, enquanto λ_j é a variância nessa direção.

Cada deslocamento é, portanto, ponderado pelo inverso da variância na direção correspondente. Um mesmo deslocamento geométrico recebe menor peso em uma direção de grande variabilidade e maior peso em uma direção de pequena variabilidade.

Exemplo 8.11 (Afastamentos em direções com variâncias distintas). Considere dois eixos espectrais com

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Um afastamento de magnitude 2 ao longo do primeiro eixo produz

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

O mesmo afastamento ao longo do segundo produz

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro, mas o segundo apresenta maior distância de Mahalanobis porque se encontra em uma direção com menor dispersão populacional.

As superfícies de igual distância,

$$d_M(\mathbf{x}, \mu) = c,$$

são exatamente as fronteiras dos elipsoides definidos na Equação 8.32. Isso reforça a interpretação geométrica da distância de Mahalanobis: pontos pertencentes à mesma superfície elipsoidal apresentam o mesmo afastamento em relação ao centro quando a estrutura de covariâncias é considerada.

A Figura 8.4 compara dois deslocamentos com a mesma distância euclidiana ao centro, mas orientados segundo eixos de dispersão distintos.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A medida compara o deslocamento com a quantidade de variabilidade disponível na direção em que ele ocorre.




Figura 8.4: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

8.6.2 Branqueamento e esferização

Uma forma alternativa de compreender a geometria associada à matriz de covariâncias consiste em transformar as coordenadas de modo que a variabilidade resultante seja a mesma em todas as direções.

Seja $\mathbf{X}$ um vetor aleatório com vetor de médias μ e matriz de covariâncias $\Sigma \succ \mathbf{0}$. Uma transformação linear da forma

$$\mathbf{Z} = \mathbf{W}(\mathbf{X} - \mu)$$

é denominada **branqueamento** (*whitening*) quando a matriz $\mathbf{W}$ é escolhida de modo que

$$\text{Cov}(\mathbf{Z}) = \mathbf{W}\Sigma\mathbf{W}^\top = \mathbf{I}_p.$$

Assim, as componentes do vetor branqueado possuem variância unitária e covariâncias nulas entre si. O termo **esferização** enfatiza a interpretação geométrica da mesma transformação: os elipsoides associados à estrutura de covariâncias são transformados em esferas.

Essa interpretação refere-se à estrutura de segunda ordem do vetor aleatório, representada pela matriz de covariâncias. Em geral, o branqueamento não implica que toda a distribuição do vetor transformado seja esfericamente simétrica.

A raiz quadrada inversa de uma matriz positiva definida foi construída no Capítulo 5 a partir da raiz quadrada principal dada na Definição 5.9. Uma escolha para a matriz de branqueamento é

$$\mathbf{W} = \Sigma^{-1/2},$$

pois

$$\Sigma^{-1/2}\Sigma\Sigma^{-1/2} = \mathbf{I}_p.$$

Essa escolha é denominada **branqueamento simétrico**. Ela remove simultaneamente as diferenças de variância e as covariâncias entre as componentes. Para um ponto $\mathbf{x}$, a transformação correspondente é

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu). \quad (8.50)$$

Para o vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2}(\mathbf{X} - \mu),$$

tem-se

$$E(\mathbf{Z}) = \mathbf{0} \quad \text{e} \quad \text{Cov}(\mathbf{Z}) = \mathbf{I}_p. \quad (8.51)$$

A transformação de branqueamento também permite interpretar diretamente a distância de Mahalanobis. De Equação 8.50,

$$\begin{aligned} \|\mathbf{z}\|^2 &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Logo,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.52)$$

A distância de Mahalanobis é, portanto, a distância euclidiana após a centralização e o branqueamento.

A esperança da distância quadrática de Mahalanobis também depende apenas da matriz de covariâncias. Como

$$d_M^2(\mathbf{X}, \mu) = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu),$$

a expressão Equação 8.38, com

$$\mathbf{A} = \Sigma^{-1},$$

fornece

$$\begin{aligned} E[d_M^2(\mathbf{X}, \mu)] &= \text{tr}(\Sigma^{-1} \Sigma) \\ &= \text{tr}(\mathbf{I}_p) \\ &= p. \end{aligned} \quad (8.53)$$

Esse resultado utiliza apenas a existência de μ e $\Sigma \succ \mathbf{0}$; não requer normalidade. No Capítulo 9, a hipótese de normalidade multivariada permitirá caracterizar não apenas essa esperança, mas a distribuição completa da distância quadrática de Mahalanobis.

Exemplo 8.12 (Branqueamento a partir da decomposição espectral). Retome a matriz de covariâncias do Exemplo 8.9,

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Sua decomposição espectral é

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

Utilizando a raiz quadrada inversa desenvolvida no Módulo 1,

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top,$$

em que

$$\Lambda^{-1/2} = \begin{bmatrix} 1/\sqrt{6} & 0 \\ 0 & 1/\sqrt{2} \end{bmatrix}.$$

Defina

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu).$$

Então,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top\mathbf{Q}\Lambda\mathbf{Q}^\top\mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\mathbf{I}_2\mathbf{Q}^\top \\ &= \mathbf{I}_2. \end{aligned}$$

A transformação pode ser compreendida em três etapas:

$$\begin{aligned} \mathbf{X} - \mu &\xrightarrow{\mathbf{Q}^\top} \text{coordenadas nos eixos espectrais} \\ &\xrightarrow{\Lambda^{-1/2}} \text{reescalonamento para variância unitária} \\ &\xrightarrow{\mathbf{Q}} \mathbf{Z}. \end{aligned}$$

O primeiro passo expressa o vetor na base de autovetores de Σ , na qual a matriz de covariâncias é diagonal. O segundo divide cada coordenada por $\sqrt{\lambda_j}$, tornando todas as variâncias iguais a 1. O terceiro retorna ao sistema original de coordenadas por meio da transformação ortogonal $\mathbf{Q}$.

Considere agora um ponto cuja diferença em relação ao centro é

$$\mathbf{x} - \mu = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Suas coordenadas espectrais são

$$\mathbf{Q}^\top (\mathbf{x} - \mu) = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

Pela expressão Equação 8.49,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= \frac{(\sqrt{2})^2}{6} + \frac{(\sqrt{2})^2}{2} \\ &= \frac{2}{6} + \frac{2}{2} \\ &= \frac{4}{3}. \end{aligned}$$

Por outro lado,

$$\left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|^2 = \frac{4}{3}.$$

Assim, o exemplo verifica concretamente a identidade

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|.$$

A decomposição espectral, a raiz matricial, o branqueamento e a distância de Mahalanobis aparecem, portanto, como partes de uma mesma construção geométrica.

O branqueamento não é único. De fato, se $\mathbf{Q}_0$ é uma matriz ortogonal, então

$$\mathbf{W} = \mathbf{Q}_0 \Sigma^{-1/2}$$

também satisfaz

$$\mathbf{W} \Sigma \mathbf{W}^\top = \mathbf{I}_p.$$

Portanto, diferentes transformações podem produzir vetores com matriz de covariâncias igual à identidade. Essas versões diferem por uma transformação ortogonal e, conseqüentemente, preservam as distâncias euclidianas no espaço branqueado.

A padronização marginal e o branqueamento devem ser distinguidos. Pela expressão Equação 8.22, a padronização marginal produz

$$\text{Cov} \left(\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \right) = \mathcal{R}.$$

Assim, a padronização marginal torna as variâncias iguais a 1, mas a matriz resultante pode apresentar correlações não nulas fora da diagonal. O branqueamento, por sua vez, utiliza a estrutura completa da matriz de covariâncias e produz

$$\text{Cov} (\mathbf{Z}) = \mathbf{I}_p.$$

Se

$$\mathbf{z}_D = \mathbf{D}_\Sigma^{-1/2} (\mathbf{x} - \mu),$$

a relação

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}$$

implica

$$d_M^2(\mathbf{x}, \mu) = \mathbf{z}_D^\top \mathcal{R}^{-1} \mathbf{z}_D. \quad (8.54)$$

Assim, a padronização marginal remove as escalas individuais, enquanto $\mathcal{R}^{-1}$ incorpora a associação linear remanescente. Somente quando

$$\mathcal{R} = \mathbf{I}_p$$

a distância de Mahalanobis coincide com a distância euclidiana entre as coordenadas marginalmente padronizadas.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são objetos populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão conjunta podem ser representadas por quantidades calculadas diretamente a partir das observações.

Nesta seção,

$$\bar{\mathbf{x}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}$$

representam valores obtidos de uma matriz de dados específica. Quando as linhas dessa matriz forem consideradas realizações de uma amostra aleatória, esses valores corresponderão a realizações das estatísticas

$$\bar{\mathbf{X}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}.$$

As propriedades dessas estatísticas como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Centralização, SQPC e matriz de covariâncias observada

Considere $n \geq 2$ observações de p variáveis organizadas, conforme Definição 1.6, em

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p$$

representa a i -ésima observação.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \in \mathbb{R}^p, \quad (8.55)$$

em que

$$\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n.$$

A matriz de dados centralizada é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.56)$$

Cada linha de $\mathbf{X}_c$ é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e suas colunas satisfazem

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.57)$$

Retomando a matriz de centralização utilizada no Capítulo 4,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

tem-se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.58)$$

A operação remove a localização das colunas sem alterar as diferenças entre as observações, conforme a propriedade estabelecida na Proposição 4.15.

Definição 8.10 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SQPC, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Equivalentemente,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.59)$$

A sigla **SQPC** significa **Somas de Quadrados e Produtos Cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*. O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

Quando $j = k$, t_{jj} é a soma dos quadrados dos desvios da variável j . Quando $j \neq k$, t_{jk} é a soma dos produtos cruzados entre as variáveis j e k .

Como

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram das colunas centralizadas no sentido de Definição 3.18. Assim, pelas propriedades estabelecidas na Proposição 3.9,

$$\mathbf{T} = \mathbf{T}^\top,$$

$$\mathbf{T} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

A centralização impõe

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top,$$

de modo que as colunas de $\mathbf{X}_c$ pertencem ao subespaço ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (8.60)$$

A matriz $\mathbf{T}$ registra a dispersão sem uma normalização pelo número de observações.

Definição 8.11 (Matriz de covariâncias observada). A **matriz de covariâncias observada** é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.61)$$

Seu elemento (j, k) é

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k). \quad (8.62)$$

Os elementos diagonais são as variâncias calculadas para as colunas,

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

e os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas.

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$,

$$\mathbf{S} = \mathbf{S}^\top, \quad \mathbf{S} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

Portanto,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1). \quad (8.63)$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

Essa singularidade decorre da dimensão dos dados centralizados. Suas consequências para estimação e regularização serão tratadas no Capítulo 10.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{S} \mathbf{a} &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \end{aligned} \tag{8.64}$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas determinada por $\mathbf{a}$. Portanto, Equação 8.64 é a contraparte descritiva de Equação 8.10.

O divisor $n-1$ é utilizado aqui como convenção para a matriz de covariâncias observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será estabelecida no Capítulo 10.

8.7.2 Matriz de correlações e covariâncias cruzadas observadas

Suponha que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias observadas por

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}). \tag{8.65}$$

Definição 8.12 (Matriz de correlações observada). A **matriz de correlações observada** é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \tag{8.66}$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.67)$$

A matriz $\mathbf{R}$ é simétrica, positiva semidefinida e possui diagonal unitária. Como $\mathbf{D}_S^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Em particular,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}.$$

A relação inversa é

$$\mathbf{S} = \mathbf{D}_S^{1/2} \mathbf{R} \mathbf{D}_S^{1/2}. \quad (8.68)$$

Defina agora a matriz das colunas centralizadas e padronizadas,

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2} \in \mathbb{R}^{n \times p}. \quad (8.69)$$

Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}} &= \frac{1}{n-1} \mathbf{D}_S^{-1/2} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_S^{-1/2} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}. \quad (8.70)$$

A expressão Equação 8.70 mostra que $\mathbf{R}$ é, a menos do fator $1/(n-1)$, uma matriz de Gram das colunas padronizadas.

Exemplo 8.13 (Da matriz de dados às matrizes de covariâncias e correlações). Considere quatro observações de duas variáveis organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}.$$

Aqui,

$$n = 4 \quad \text{e} \quad p = 2.$$

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{4} \mathbf{X}^\top \mathbf{1}_4 = \begin{bmatrix} 2,5 \\ 2,5 \end{bmatrix}.$$

Portanto, a matriz centralizada é

$$\begin{aligned} \mathbf{X}_c &= \mathbf{X} - \mathbf{1}_4 \bar{\mathbf{x}}^\top \\ &= \begin{bmatrix} -1,5 & -0,5 \\ -0,5 & -1,5 \\ 0,5 & 1,5 \\ 1,5 & 0,5 \end{bmatrix}. \end{aligned}$$

A matriz total de somas de quadrados e produtos cruzados é

$$\begin{aligned} \mathbf{T} &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são as somas dos quadrados dos desvios de cada variável. O elemento fora da diagonal é a soma dos produtos cruzados.

Como

$$n - 1 = 3,$$

a matriz de covariâncias observada é

$$\begin{aligned}\mathbf{S} &= \frac{1}{3}\mathbf{T} \\ &= \begin{bmatrix} 5/3 & 1 \\ 1 & 5/3 \end{bmatrix}.\end{aligned}$$

Assim,

$$s_{11} = s_{22} = \frac{5}{3}$$

e

$$s_{12} = 1.$$

A matriz diagonal das variâncias observadas é

$$\mathbf{D}_S = \begin{bmatrix} 5/3 & 0 \\ 0 & 5/3 \end{bmatrix}.$$

Como as duas variâncias são iguais,

$$\mathbf{D}_S^{-1/2} = \sqrt{\frac{3}{5}}\mathbf{I}_2.$$

Logo,

$$\begin{aligned}\mathbf{R} &= \mathbf{D}_S^{-1/2}\mathbf{S}\mathbf{D}_S^{-1/2} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.\end{aligned}$$

Também podemos obter diretamente a correlação entre as duas colunas:

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{1}{\sqrt{(5/3)(5/3)}} = \frac{3}{5} = 0,6.$$

O exemplo reúne as etapas da construção descritiva desenvolvida nesta seção. A partir da matriz de dados $\mathbf{X}$, calcula-se o vetor de médias $\bar{\mathbf{x}}$ e obtém-se a matriz centralizada $\mathbf{X}_c$. A matriz SQPC $\mathbf{T}$ registra a dispersão sem normalização, $\mathbf{S}$ introduz a normalização por $n - 1$ e $\mathbf{R}$ remove as escalas marginais por meio da padronização.

Nesse ponto, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ são valores calculados a partir da matriz de dados observada. Sua interpretação como realizações de estatísticas amostrais e suas propriedades inferenciais serão desenvolvidas no Capítulo 10.

Se $\mathbf{x}_{\text{pad},j}$ representa a coluna j de $\mathbf{X}_{\text{pad}}$, então

$$\|\mathbf{x}_{\text{pad},j}\|^2 = n - 1.$$

Consequentemente,

$$r_{jk} = \frac{\mathbf{x}_{\text{pad},j}^\top \mathbf{x}_{\text{pad},k}}{\|\mathbf{x}_{\text{pad},j}\| \|\mathbf{x}_{\text{pad},k}\|}. \quad (8.71)$$

Assim, a correlação observada entre duas variáveis é o cosseno do ângulo entre suas colunas centralizadas e padronizadas no espaço das observações. Essa interpretação utiliza diretamente a geometria de produtos internos desenvolvida no Módulo 1.

A representação descritiva também se estende a dois blocos de variáveis. Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais. Se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y},$$

define-se:

Definição 8.13 (Matriz de covariâncias cruzadas observada). A **matriz de covariâncias cruzadas observada** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y} \in \mathbb{R}^{p \times q}. \quad (8.72)$$

Sua orientação satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.73)$$

Para

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância observada entre as combinações

$$\mathbf{u} = \mathbf{X}\mathbf{a}$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}$$

é

$$s_{uv} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (8.74)$$

A expressão Equação 8.74 é a contraparte descritiva de Equação 8.14.

Se as duas matrizes forem concatenadas,

$$[\mathbf{X} \quad \mathbf{Y}],$$

a matriz de covariâncias observada correspondente possui a estrutura

$$\begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \quad (8.75)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto de variáveis, enquanto os blocos fora da diagonal registram as covariâncias entre os dois conjuntos.

A matriz $\mathbf{T}$ descreve a dispersão conjunta de todas as observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão admite uma decomposição adicional.

8.8 Decomposição da dispersão por grupos

Considere as n observações distribuídas em K grupos não vazios. O grupo k contém n_k observações, com

$$n_1 + \cdots + n_K = n.$$

Represente a observação i do grupo k por

$$\mathbf{x}_{ik} \in \mathbb{R}^p, \quad i = 1, \dots, n_k, \quad k = 1, \dots, K.$$

O vetor de médias do grupo k é

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathbf{x}_{ik}. \quad (8.76)$$

A média total satisfaz

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \mathbf{x}_{ik} = \frac{1}{n} \sum_{k=1}^K n_k \bar{\mathbf{x}}_k. \quad (8.77)$$

A dispersão total das observações em torno da média geral pode ser separada em duas fontes:

- **dispersão intragrupos:** afastamentos das observações em relação à média do grupo ao qual pertencem;
- **dispersão entre grupos:** afastamentos das médias dos grupos em relação à média total.

Essa decomposição distingue, portanto, a variabilidade existente **dentro dos grupos** daquela associada às **diferenças entre seus centros**. Em várias técnicas multivariadas, essa distinção será fundamental para avaliar se os grupos apresentam centros suficientemente separados em relação à variabilidade existente internamente.

Geometricamente, para cada observação, o deslocamento em relação à média total pode ser percorrido em duas etapas: primeiro, da observação até a média de seu grupo e, depois, da média do grupo até a média total. Assim,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (8.78)$$

A Figura 8.5 ilustra essas duas componentes. Os afastamentos das observações em relação aos respectivos centros representam a dispersão intragrupos, enquanto os afastamentos dos centros dos grupos em relação à média total representam a dispersão entre grupos.




Figura 8.5: Decomposição geométrica da dispersão em componentes intragrupos e entre grupos.

8.8.1 Dispersão total, intragrupos e entre grupos

A matriz total é

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top. \quad (8.79)$$

Definição 8.14 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top \in \mathbb{R}^{p \times p}. \quad (8.80)$$

Cada termo mede o afastamento de uma observação em relação ao centro de seu próprio grupo.

Definição 8.15 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \in \mathbb{R}^{p \times p}. \quad (8.81)$$

A ponderação por n_k registra o número de observações representadas por cada média de grupo. Assim, um mesmo afastamento $\bar{\mathbf{x}}_k - \bar{\mathbf{x}}$ contribui mais para a dispersão entre grupos quando corresponde a um grupo com maior número de observações.

Proposição 8.10 (Decomposição da dispersão total). *Para qualquer partição das n observações em K grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.82)$$

Comprovação. Pela decomposição vetorial apresentada na Equação 8.78,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}).$$

Ao formar o produto externo e somar sobre as observações, surgem duas parcelas quadráticas e dois termos cruzados. Para cada grupo,

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem. A soma das primeiras parcelas produz $\mathbf{T}_{\text{intra}}$, enquanto

$$\sum_{i=1}^{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top = n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top.$$

Somando sobre os grupos, obtém-se

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

□

Exemplo 8.14 (Decomposição da dispersão em dois grupos). Considere quatro observações de duas variáveis, distribuídas em dois grupos:

Grupo	X_1	X_2
1	1	1
1	3	1
2	3	5
2	5	5

Assim,

$$n_1 = n_2 = 2, \quad n = 4, \quad K = 2.$$

As médias dos grupos são

$$\bar{\mathbf{x}}_1 = \frac{1}{2} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right] = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{2} \left[\begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

A média total é

$$\begin{aligned} \bar{\mathbf{x}} &= \frac{1}{4} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix}. \end{aligned}$$

Podemos agora calcular separadamente as três matrizes da decomposição.

Dispersão intragrupos.

No primeiro grupo,

$$\mathbf{x}_{11} - \bar{\mathbf{x}}_1 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{21} - \bar{\mathbf{x}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua contribuição para a dispersão intragrupos é

$$\begin{aligned} \mathbf{T}_{\text{intra},1} &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} -1 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

No segundo grupo,

$$\mathbf{x}_{12} - \bar{\mathbf{x}}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{22} - \bar{\mathbf{x}}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

de modo que

$$\mathbf{T}_{\text{intra},2} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{T}_{\text{intra}} &= \mathbf{T}_{\text{intra},1} + \mathbf{T}_{\text{intra},2} \\ &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned} \tag{8.83}$$

Toda a dispersão dentro dos grupos ocorre, neste exemplo, na primeira variável. A segunda variável é constante dentro de cada grupo.

Dispersão entre grupos.

Os afastamentos das médias dos grupos em relação à média total são

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 - \bar{\mathbf{x}} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Como ambos os grupos possuem duas observações,

$$\begin{aligned} \mathbf{T}_{\text{entre}} &= 2 \begin{bmatrix} -1 \\ -2 \end{bmatrix} \begin{bmatrix} -1 & -2 \end{bmatrix} + 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.84}$$

Nesse caso, a diferença entre os centros dos grupos envolve simultaneamente as duas variáveis.

Dispersão total.

Calculando diretamente os desvios das quatro observações em relação a

$$\bar{\mathbf{x}} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

obtém-se

$$\begin{aligned} \mathbf{T} &= \begin{bmatrix} -2 \\ -2 \end{bmatrix} \begin{bmatrix} -2 & -2 \end{bmatrix} + \begin{bmatrix} 0 \\ -2 \end{bmatrix} \begin{bmatrix} 0 & -2 \end{bmatrix} \\ &\quad + \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.85}$$

A identidade Equação 8.82 pode então ser verificada diretamente:

$$\begin{aligned}\mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}} &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix} \\ &= \mathbf{T}.\end{aligned}$$

A decomposição também pode ser examinada em direções específicas. Para

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

que seleciona a primeira variável,

$$\mathbf{a}_1^\top \mathbf{T} \mathbf{a}_1 = 8,$$

com

$$\mathbf{a}_1^\top \mathbf{T}_{\text{intra}} \mathbf{a}_1 = 4$$

e

$$\mathbf{a}_1^\top \mathbf{T}_{\text{entre}} \mathbf{a}_1 = 4.$$

Assim,

$$8 = 4 + 4.$$

Metade da dispersão de X_1 decorre de diferenças dentro dos grupos e metade das diferenças entre seus centros.

Para

$$\mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

que seleciona a segunda variável,

$$\mathbf{a}_2^\top \mathbf{T} \mathbf{a}_2 = 16,$$

enquanto

$$\mathbf{a}_2^\top \mathbf{T}_{\text{intra}} \mathbf{a}_2 = 0$$

e

$$\mathbf{a}_2^\top \mathbf{T}_{\text{entre}} \mathbf{a}_2 = 16.$$

Portanto,

$$16 = 0 + 16.$$

A variável X_2 não apresenta dispersão dentro dos grupos neste conjunto de dados; toda a sua dispersão total está associada à diferença entre as médias dos dois grupos.

O exemplo mostra que a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

expressa simultaneamente a decomposição da dispersão em todas as direções. Para qualquer combinação linear das variáveis, a dispersão total dessa combinação também se decompõe nas parcelas intragrupos e entre grupos, conforme Equação 8.86.

A identidade Equação 8.82 é algébrica e depende somente da partição das observações e das definições das médias total e de grupo (Renchert; Christensen, 2012). Normalidade, independência e outros pressupostos probabilísticos não são necessários para estabelecê-la.

Para qualquer direção

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.86)$$

Se

$$y_{ik} = \mathbf{a}^\top \mathbf{x}_{ik},$$

então Equação 8.86 corresponde exatamente à decomposição univariada

$$\sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y})^2 = \sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y}_k)^2 + \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2. \quad (8.87)$$

A decomposição matricial reúne simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.2 Somas de quadrados e traço das matrizes de dispersão

As matrizes $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes de somas de quadrados e produtos cruzados e descrevem simultaneamente a dispersão das diferentes variáveis e suas associações.

O traço dessas matrizes reúne apenas os termos quadráticos da diagonal e fornece uma medida escalar de dispersão. Defina

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Essas quantidades constituem as somas de quadrados total, intragrupos e entre grupos, respectivamente. No caso univariado, elas coincidem com as somas de quadrados usuais da análise de variância. No caso multivariado, correspondem à soma das somas de quadrados das p variáveis.

Como o traço soma as contribuições das diferentes variáveis, essas quantidades dependem das escalas em que as variáveis são expressas. Sua interpretação conjunta é mais direta quando as variáveis possuem unidades comparáveis ou quando uma padronização apropriada foi realizada.

Para a matriz de dispersão total,

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top,$$

tem-se

$$\begin{aligned}
\text{tr}(\mathbf{T}) &= \sum_{k=1}^K \sum_{i=1}^{n_k} \text{tr} \left[(\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top \right] \\
&= \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2.
\end{aligned} \tag{8.88}$$

Portanto,

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2. \tag{8.89}$$

Assim, SQ_{total} é a soma dos quadrados das distâncias euclidianas das observações à média total.

Analogamente,

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}_k\|^2 \tag{8.90}$$

mede a soma dos quadrados dos afastamentos das observações em relação aos centros de seus respectivos grupos.

Por sua vez,

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2 \tag{8.91}$$

mede a soma ponderada dos quadrados das distâncias entre os centros dos grupos e a média total.

Como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade do traço fornece

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}. \tag{8.92}$$

Equivalentemente,

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \tag{8.93}$$

Ao tomar o traço da decomposição matricial, recupera-se uma identidade escalar análoga à decomposição de somas de quadrados familiar da análise de variância:

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

A decomposição matricial

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é mais informativa, pois preserva também os produtos cruzados entre as variáveis. O traço resume essa estrutura matricial em uma única soma de quadrados.

Assim, a decomposição matricial da dispersão também produz uma decomposição da quantidade total de dispersão medida pelas distâncias euclidianas quadráticas.

Dividindo essas somas por n , obtêm-se medidas médias da dispersão quadrática. Por exemplo,

$$\frac{SQ_{\text{total}}}{n} = \frac{1}{n} \text{tr}(\mathbf{T}) = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2.$$

Essa quantidade representa o afastamento quadrático médio das observações em relação à média total. De modo correspondente,

$$\frac{SQ_{\text{intra}}}{n}$$

e

$$\frac{SQ_{\text{entre}}}{n}$$

representam, respectivamente, as contribuições médias da dispersão intragrupos e entre grupos.

8.8.3 Esperança das matrizes de dispersão por grupos

Até este ponto, a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

foi tratada como uma identidade algébrica para os dados observados. É possível também examinar essas matrizes como objetos aleatórios e calcular suas esperanças, desde que se especifique uma estrutura probabilística para as observações.

Suponha que, para cada grupo $k = 1, \dots, K$,

$$\mathbf{X}_{ik}, \quad i = 1, \dots, n_k,$$

sejam vetores aleatórios independentes, com

$$E(\mathbf{X}_{ik}) = \mu_k$$

e matriz de covariâncias comum

$$\text{Cov}(\mathbf{X}_{ik}) = \Sigma.$$

Não é necessário assumir normalidade.

Defina a média populacional ponderada dos grupos por

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k. \quad (8.94)$$

Considere ainda a matriz

$$\mathbf{B}_\mu = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^\top, \quad (8.95)$$

que representa a dispersão entre os vetores de médias populacionais dos grupos.

Quando as matrizes de dispersão são consideradas objetos aleatórios, as somas de quadrados correspondentes também são objetos aleatórios. Defina

$$\text{SQ}_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Suas realizações observadas são, respectivamente,

$$SQ_{\text{total}}, \quad SQ_{\text{intra}} \quad \text{e} \quad SQ_{\text{entre}}.$$

Para a matriz de dispersão intragrupos,

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top,$$

tem-se

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma. \quad (8.96)$$

Tomando o traço dos dois lados e utilizando a linearidade do traço e da esperança,

$$E(SQ_{\text{intra}}) = (n - K) \text{tr}(\Sigma).$$

Consequentemente,

$$E\left(\frac{SQ_{\text{intra}}}{n - K}\right) = \text{tr}(\Sigma).$$

Dentro de cada grupo, os vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, a centralização pela média do grupo reduz em uma unidade a dimensão disponível, fazendo com que o grupo k contribua com $n_k - 1$ graus de liberdade. Portanto,

$$\sum_{k=1}^K (n_k - 1) = n - K.$$

A quantidade $n - K$ corresponde, assim, aos graus de liberdade intragrupos familiares da análise de variância. A divisão por $n - K$ antecipa a construção dos quadrados médios utilizada em ANOVA e planejamento de experimentos.

Para a dispersão entre grupos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}) (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top,$$

a esperança é

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_\mu. \quad (8.97)$$

Essa expressão contém duas parcelas com interpretações distintas. O termo

$$(K - 1)\Sigma$$

representa a variabilidade decorrente do fato de que as médias amostrais dos grupos variam de amostra para amostra, enquanto

$$\mathbf{B}_\mu$$

representa a separação efetiva entre os vetores de médias populacionais.

Em particular, se

$$\mu_1 = \cdots = \mu_K,$$

então

$$\mathbf{B}_\mu = \mathbf{0},$$

mas, ainda assim,

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma.$$

Tomando o traço na Equação 8.97,

$$E(\text{SQ}_{\text{entre}}) = (K - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Consequentemente,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{K-1}\right) = \text{tr}(\Sigma) + \frac{\text{tr}(\mathbf{B}_{\mu})}{K-1}.$$

Quando os grupos possuem o mesmo vetor de médias populacional,

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$\mathbf{B}_{\mu} = \mathbf{0}.$$

Nesse caso,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{K-1}\right) = E\left(\frac{\text{SQ}_{\text{intra}}}{n-K}\right) = \text{tr}(\Sigma).$$

Portanto, quando não existe separação entre os vetores de médias populacionais, as somas de quadrados intragrupos e entre grupos, após a divisão pelas respectivas quantidades $n - K$ e $K - 1$, possuem a mesma esperança.

Isso ocorre porque as médias amostrais dos grupos não coincidem exatamente, mesmo quando seus vetores de médias populacionais são iguais.

Por fim, como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade da esperança fornece

$$\begin{aligned} E(\mathbf{T}) &= E(\mathbf{T}_{\text{intra}}) + E(\mathbf{T}_{\text{entre}}) \\ &= (n-1)\Sigma + \mathbf{B}_{\mu}. \end{aligned} \tag{8.98}$$

Tomando o traço,

$$E(\text{SQ}_{\text{total}}) = (n-1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_{\mu}). \tag{8.99}$$

Além disso,

$$\text{SQ}_{\text{total}} = \text{SQ}_{\text{intra}} + \text{SQ}_{\text{entre}},$$

que é a versão aleatória da decomposição observada

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

Quando todos os grupos possuem o mesmo vetor de médias populacional,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Esses resultados dependem apenas de momentos de primeira e segunda ordem e da independência entre as observações; a normalidade não é necessária. Distribuições amostrais e resultados inferenciais associados a essas matrizes serão tratados posteriormente.

No caso univariado, as matrizes reduzem-se a escalares e a decomposição assume a forma familiar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

As divisões

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n-K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K-1}$$

correspondem aos quadrados médios familiares da análise de variância e do planejamento de experimentos.

No contexto multivariado, contudo, as matrizes completas de somas de quadrados e produtos cruzados preservam informações adicionais sobre as associações entre as variáveis. Por essa razão, métodos multivariados posteriores utilizarão $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, e não apenas seus traços.

8.8.4 Propriedades e limites de posto

Independentemente das hipóteses probabilísticas utilizadas na subseção anterior, as propriedades estruturais a seguir decorrem diretamente das definições das matrizes de dispersão.

Proposição 8.11 (Estrutura das matrizes de dispersão por grupos). *As matrizes*

$$\mathbf{T}, \quad \mathbf{T}_{\text{intra}} \quad e \quad \mathbf{T}_{\text{entre}}$$

são simétricas e positivas semidefinidas. Além disso,

$$\mathbf{0} \preceq \mathbf{T}_{\text{intra}} \preceq \mathbf{T}$$

e

$$\mathbf{0} \preceq \mathbf{T}_{\text{entre}} \preceq \mathbf{T}.$$

Seus postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K), \quad (8.100)$$

e

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1). \quad (8.101)$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{k=1}^K \sum_{i=1}^{n_k} [\mathbf{a}^\top (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{k=1}^K n_k [\mathbf{a}^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})]^2 \geq 0.$$

Logo, as duas parcelas são positivas semidefnidas. Pela identidade Equação 8.82,

$$\mathbf{T} - \mathbf{T}_{\text{intra}} = \mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T} - \mathbf{T}_{\text{entre}} = \mathbf{T}_{\text{intra}} \succeq \mathbf{0},$$

o que estabelece as relações na ordem de Loewner.

O limite para $\mathbf{T}$ foi obtido na Equação 8.60.

Dentro do grupo k , os n_k vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, os vetores centralizados desse grupo geram um subespaço de dimensão no máximo $n_k - 1$. Considerando todos os grupos,

$$\sum_{k=1}^K (n_k - 1) = n - K,$$

e, portanto,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K).$$

Para a parcela entre grupos,

$$\sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) = \mathbf{0}.$$

Os K vetores

$$\sqrt{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})$$

geram, portanto, um subespaço de dimensão no máximo $K - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

□

Os limites podem ser estritos quando existem relações lineares adicionais entre as variáveis ou entre os vetores de médias dos grupos.

As relações na ordem de Loewner implicam, para qualquer direção $\mathbf{a}$,

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}$$

e

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}.$$

Assim, a dispersão intragrupos ou entre grupos em uma direção não pode exceder a dispersão total na mesma direção.

Dois casos extremos auxiliam a interpretação. Se

$$\bar{\mathbf{x}}_1 = \cdots = \bar{\mathbf{x}}_K = \bar{\mathbf{x}},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0}.$$

Se, por outro lado, todas as observações de cada grupo coincidem com a respectiva média,

$$\mathbf{x}_{ik} = \bar{\mathbf{x}}_k,$$

então

$$\mathbf{T}_{\text{intra}} = \mathbf{0}.$$

Neste capítulo, a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é inicialmente desenvolvida como uma decomposição algébrica da dispersão observada e, sob hipóteses explícitas de independência e covariância comum, recebe também uma interpretação por meio das esperanças das matrizes de dispersão. Distribuições amostrais, testes de hipóteses e sua formulação no modelo linear multivariado serão desenvolvidos posteriormente.

No Capítulo 11, uma estrutura correspondente será obtida a partir do modelo linear multivariado e de matrizes de projeção. Graus de liberdade, estimadores de covariâncias residuais e hipóteses lineares pertencem àquele contexto.

8.9 Síntese do capítulo

A matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X})$$

representa a estrutura de segunda ordem de um vetor aleatório. Sua diagonal contém as variâncias das componentes, e seus elementos fora da diagonal registram covariâncias. Para qualquer combinação linear,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a},$$

de modo que a matriz de covariâncias determina a dispersão em todas as direções.

A padronização marginal conduz à matriz de correlações

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2},$$

que preserva a estrutura de associação linear após a retirada das escalas marginais.

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto o traço e o determinante produzem resumos escalares distintos. A variância total é

$$\text{tr}(\Sigma) = \sum_{j=1}^p \sigma_{jj} = \sum_{j=1}^p \lambda_j,$$

e também pode ser interpretada como o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu centro:

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma).$$

Mais geralmente, para uma matriz simétrica $\mathbf{A}$ e um vetor fixo $\mathbf{a}$,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A} \Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}).$$

A variância generalizada é

$$\det(\Sigma),$$

e, quando $\Sigma \succ \mathbf{0}$, a distância de Mahalanobis

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

mede afastamentos levando em conta simultaneamente escalas e covariâncias. Sua esperança populacional satisfaz

$$E[d_M^2(\mathbf{X}, \mu)] = p.$$

A transformação de **branqueamento** (*whitening*), também denominada **esferização**, transforma a estrutura de covariâncias em identidade. No branqueamento simétrico,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_p.$$

Nesse espaço transformado, a distância de Mahalanobis coincide com a distância euclidiana. A padronização marginal e o branqueamento diferem porque a primeira produz matriz de covariâncias igual a $\mathcal{R}$, enquanto o branqueamento produz $\mathbf{I}_p$.

No nível descritivo, as mesmas estruturas são representadas por

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c, \quad \mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A sigla **SQPC** significa **somas de quadrados e produtos cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*.

Quando as observações estão organizadas em grupos,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa a dispersão observada dentro dos grupos da dispersão associada às diferenças entre seus centros. As matrizes completas preservam tanto as somas de quadrados de cada variável quanto os produtos cruzados entre variáveis.

Tomando o traço, obtém-se a decomposição escalar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}},$$

em que

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}), \quad SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

No caso univariado, essa identidade coincide com a decomposição de somas de quadrados familiar da análise de variância. Os correspondentes quadrados médios são

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n - K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K - 1}.$$

No contexto multivariado, entretanto, as matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ contêm informação adicional sobre os produtos cruzados e, por isso, são mais informativas do que seus traços.

Sob independência entre as observações e matriz de covariâncias comum Σ nos grupos, as matrizes de dispersão também admitem interpretações probabilísticas. Se

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k$$

e

$$\mathbf{B}_{\mu} = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^{\top},$$

então

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma,$$

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_{\mu},$$

e

$$E(\mathbf{T}) = (n - 1)\Sigma + \mathbf{B}_\mu.$$

Tomando os traços,

$$E(\text{SQ}_{\text{intra}}) = (n - K) \text{tr}(\Sigma)$$

e

$$E(\text{SQ}_{\text{entre}}) = (K - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Definindo os quadrados médios como objetos aleatórios por

$$\text{QM}_{\text{intra}} = \frac{\text{SQ}_{\text{intra}}}{n - K}$$

e

$$\text{QM}_{\text{entre}} = \frac{\text{SQ}_{\text{entre}}}{K - 1},$$

quando

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$E(\text{QM}_{\text{intra}}) = E(\text{QM}_{\text{entre}}) = \text{tr}(\Sigma).$$

Essa igualdade antecipa a lógica dos quadrados médios da análise de variância, enquanto a formulação multivariada posterior utilizará as matrizes completas de somas de quadrados e produtos cruzados.

A Tabela 8.1 reúne os principais objetos do capítulo.

Tabela 8.1: Principais objetos desenvolvidos no capítulo.

Nível	Objeto	Símbolo	Função
Populacional	vetor de médias	μ	localização

Nível	Objeto	Símbolo	Função
Populacional	matriz de covariâncias	Σ	dispersão conjunta
Populacional	matriz de correlações	$\mathcal{R}$	associação linear padronizada
Populacional	covariância cruzada	Σ_{XY}	associação linear entre blocos
Geométrico	variância total	$\text{tr}(\Sigma)$	dispersão quadrática média
Geométrico	variância generalizada	$\det(\Sigma)$	dispersão multidimensional global
Geométrico	distância de Mahalanobis	d_M	afastamento ajustado à dispersão
Geométrico	branqueamento	$\Sigma^{-1/2}$	transformação para covariância identidade
Dados observados	média	$\bar{\mathbf{x}}$	centro das observações
Dados observados	SQPC	$\mathbf{T}$	dispersão não normalizada
Dados observados	covariância	$\mathbf{S}$	dispersão calculada dos dados
Dados observados	correlação	$\mathbf{R}$	associação linear padronizada nos dados
Dados agrupados	dispersão intragrupos	$\mathbf{T}_{\text{intra}}$	dispersão dentro dos grupos
Dados agrupados	dispersão entre grupos	$\mathbf{T}_{\text{entre}}$	dispersão entre os centros dos grupos
Dados agrupados	decomposição matricial	$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$	separação da dispersão por grupos
Dados agrupados	somas de quadrados	$SQ_{\text{total}}, SQ_{\text{intra}}, SQ_{\text{entre}}$	resumos escalares obtidos pelos traços das matrizes de dispersão
Dados agrupados	quadrados médios	$QM_{\text{intra}}, QM_{\text{entre}}$	somas de quadrados ajustadas pelos respectivos graus de liberdade

Ao final deste capítulo, o estudante deverá ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- calcular e interpretar variâncias e covariâncias de combinações lineares;
- reconhecer as condições estruturais, a singularidade e o posto de matrizes de covariâncias e correlações;
- interpretar a decomposição espectral, a variância total, a variância generalizada e a geometria dos elipsoides de dispersão;
- relacionar formas quadráticas e esperanças matemáticas à estrutura de covariâncias;
- interpretar a distância de Mahalanobis e sua relação com o branqueamento e a esferização;
- distinguir padronização marginal e branqueamento;
- distinguir parâmetros populacionais, estatísticas amostrais e valores calculados de dados observados;
- decompor a dispersão observada em parcelas total, intragrupos e entre grupos;
- relacionar os traços das matrizes de dispersão às somas de quadrados total, intragrupos e entre grupos;
- reconhecer a relação entre somas de quadrados, graus de liberdade e quadrados médios, estabelecendo a conexão com a análise de variância;
- interpretar, sob hipóteses probabilísticas apropriadas, as esperanças das matrizes de dispersão e das correspondentes somas de quadrados e quadrados médios.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas, em geral, não determina sua distribuição conjunta. O próximo capítulo introduz a **Distribuição Normal Multivariada**, na qual o vetor de médias e a matriz de covariâncias determinam completamente a distribuição. Serão desenvolvidas suas distribuições marginais e condicionais e, no caso não singular, sua função densidade. Nesse contexto, a distância quadrática de Mahalanobis deixará de ser apenas uma construção geométrica baseada em momentos de segunda ordem e passará a possuir uma distribuição probabilística específica.

9 Distribuição Normal Multivariada

O Capítulo 8 desenvolveu o vetor de médias na Equação 8.1, a matriz de covariâncias na Definição 8.2 e a geometria da dispersão na Equação 8.32. Em uma distribuição geral, essas estruturas de primeira e segunda ordem não determinam completamente a distribuição conjunta. Diferentes distribuições podem possuir o mesmo vetor de médias e a mesma matriz de covariâncias.

Na família normal multivariada, o vetor de médias e a matriz de covariâncias determinam a distribuição. Além disso, transformações afins e distribuições marginais permanecem normais, e a estrutura de covariâncias assume consequências probabilísticas específicas, como a equivalência entre não correlação e independência para componentes conjuntamente normais.

O objetivo deste capítulo é construir a distribuição normal multivariada e relacionar suas propriedades probabilísticas à estrutura desenvolvida no capítulo anterior. Serão estudadas a função densidade, as distribuições marginais e condicionais, a independência entre blocos, a padronização, o branqueamento e a distribuição da distância quadrática de Mahalanobis. A sequência principal considera $\Sigma \succ \mathbf{0}$; o caso em que a matriz de covariâncias é singular será reunido em Seção 9.8.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\mu \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathbf{X} \sim N_p(\mu, \Sigma)$ indica uma distribuição normal multivariada de dimensão p , parametrizada pelo vetor de médias e pela matriz de covariâncias;
- $\mathbf{Z}$ representa um vetor normal multivariado padrão, cuja dimensão será indicada pelo contexto; por exemplo, $\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r)$ em dimensão r ;
- $\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias marginais;
- $\sigma_j = \sqrt{\sigma_{jj}}$ representa o desvio-padrão marginal da componente X_j ;
- $\mathcal{R}$ representa a matriz de correlações populacional;
- $\mathbf{X}_1$ e $\mathbf{X}_2$ representam blocos de um vetor normal particionado, com matrizes de covariâncias Σ_{11} e Σ_{22} e covariâncias cruzadas Σ_{12} e Σ_{21} ;
- $\Sigma_{11.2}$ representa o complemento de Schur de Σ_{22} em Σ ;
- $d_M^2(\mathbf{x}, \mu)$ representa a distância quadrática de Mahalanobis de um ponto fixo $\mathbf{x}$ ao centro populacional;

- D_M^2 representa a distância quadrática de Mahalanobis considerada como variável aleatória;
- χ_p^2 representa a distribuição qui-quadrado com p graus de liberdade, e $\chi_{p;1-\alpha}^2$ representa seu quantil de ordem $1 - \alpha$.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

Uma maneira de caracterizar a normalidade multivariada é examinar todas as projeções lineares do vetor. Na definição a seguir, admite-se também uma normal univariada com variância zero (Eaton, 2007). A relação desse caso com matrizes de covariâncias singulares será desenvolvida em Seção 9.8.

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se também variância igual a zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pela Proposição 8.1 do Capítulo 8, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu$$

quase certamente.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Assim, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente considerada separadamente não garante normalidade

multivariada. A definição exige que **todas as combinações lineares** das componentes possuam distribuição normal.

Portanto,

$$X_j \text{ normal para todo } j$$

não implica, isoladamente,

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ representa a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece que toda projeção unidimensional de um vetor normal multivariado possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A definição anterior também permite construir vetores normais multivariados a partir de variáveis normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ \vdots \\ Z_r \end{bmatrix},$$

com

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e componentes mutuamente independentes.

Para qualquer $\mathbf{c} \in \mathbb{R}^r$,

$$\mathbf{c}^\top \mathbf{Z} = \sum_{j=1}^r c_j Z_j$$

é uma variável normal. Além disso,

$$E(\mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_r.$$

Logo,

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A transformação afim definida na Definição 4.7 permite transportar essa distribuição para outros vetores de médias e outras estruturas de covariância.

Proposição 9.1 (Construção afim de um vetor normal). *O vetor*

$$\mathbf{X} = \mu + \mathbf{AZ} \tag{9.3}$$

satisfaz

$$\mathbf{X} \sim N_p(\mu, \mathbf{AA}^\top), \tag{9.4}$$

em que

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

$\mathbf{A} \in \mathbb{R}^{p \times r}$ e $\mu \in \mathbb{R}^p$.

Comprovação. Pelo resultado de transformação da covariância na Proposição 8.6,

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top = \mathbf{AA}^\top. \tag{9.5}$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{AZ} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

A última parcela é uma combinação linear das componentes de $\mathbf{Z}$ e, portanto, possui distribuição normal. Assim, $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$, o que caracteriza $\mathbf{X}$ como normal multivariado. $\square$

A matriz $\mathbf{A}$ determina como as componentes independentes de $\mathbf{Z}$ são combinadas. A transformação pode introduzir covariâncias entre as componentes de $\mathbf{X}$, mesmo que as componentes do vetor inicial sejam independentes.

Pela Proposição 8.2, uma matriz de covariâncias é simétrica e positiva semidefinida. Reciprocamente, toda matriz real simétrica e positiva semidefinida admite uma fatoração

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

De fato, pelo Teorema 5.4,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com autovalores não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\Lambda^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \Sigma.$$

Consequentemente, qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica positiva semidefinida Σ podem parametrizar uma distribuição normal multivariada.

Se Σ é positiva semidefinida, mas não positiva definida, obtém-se o caso singular, que será definido e desenvolvido em Seção 9.8. Na sequência principal, considere

$$\Sigma \succ \mathbf{0}.$$

A raiz quadrada principal definida em Definição 5.9 é invertível e pode ser utilizada como matriz da construção afim, pois

$$\Sigma^{1/2}\Sigma^{1/2} = \Sigma.$$

Assim, se

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

o vetor

$$\mathbf{Y} = \mu + \Sigma^{1/2} \mathbf{Z}$$

possui distribuição

$$\mathbf{Y} \sim N_p(\mu, \Sigma).$$

9.1.3 Determinação pelos parâmetros

O vetor de médias μ e a matriz de covariâncias Σ descrevem características de primeira e segunda ordem, mas, por si sós, não determinam uma distribuição conjunta. Na família normal multivariada, esses parâmetros determinam a distribuição, pois todas as projeções lineares são normais e seus parâmetros são determinados por μ e Σ .

Nesta seção será utilizada a notação de **igualdade em distribuição**. Para vetores aleatórios $\mathbf{X}$ e $\mathbf{Y}$ em $\mathbb{R}^p$, escrever

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

significa que os dois vetores possuem a mesma distribuição conjunta. Equivalentemente, para todo

$$\mathbf{x} = (x_1, \dots, x_p)^\top \in \mathbb{R}^p,$$

tem-se

$$P(X_1 \leq x_1, \dots, X_p \leq x_p) = P(Y_1 \leq x_1, \dots, Y_p \leq x_p).$$

A igualdade em distribuição não significa que

$$\mathbf{X} = \mathbf{Y}$$

quase certamente. Os vetores podem, inclusive, estar definidos em espaços de probabilidade distintos.

O resultado geral que permite passar das distribuições das projeções à distribuição conjunta é o Teorema de Cramér–Wold (Eaton, 2007).

Teorema 9.1 (Teorema de Cramér–Wold). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^p$$

vetores aleatórios. Então,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo

$$\mathbf{a} \in \mathbb{R}^p.$$

(Eaton, 2007)

A implicação direta decorre da aplicação da mesma transformação linear a vetores com a mesma distribuição. A implicação inversa estabelece que a coleção das distribuições de todas as projeções lineares determina a distribuição conjunta.

Leitura de aprofundamento

O Teorema de Cramér–Wold é um resultado geral e não depende da hipótese de normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

Aqui, sua função é justificar que duas distribuições normais multivariadas com o mesmo vetor de médias e a mesma matriz de covariâncias são a mesma distribuição.

Proposição 9.2 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

e

$$\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a}$. Pelo Teorema 9.1,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

□

Essa propriedade explica por que a notação

$$N_p(\mu, \Sigma)$$

é suficiente para identificar uma distribuição normal multivariada.

Como consequência, quando

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a construção anterior permite escrever

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.2 Densidade da normal multivariada

A partir deste ponto, considere

$$\Sigma \succ \mathbf{0}.$$

Então,

$$\Sigma^{-1}$$

existe e

$$\det(\Sigma) > 0,$$

permitindo representar a distribuição normal multivariada por uma densidade em relação à medida de Lebesgue em $\mathbb{R}^p$.

9.2.1 Função densidade e log-densidade

Proposição 9.3 (Densidade da normal multivariada). *A densidade de*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

é

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.8)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Comprovação. Pela representação Equação 9.7,

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z},$$

com

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Como as componentes de $\mathbf{Z}$ são normais padrão independentes, sua densidade conjunta é

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{(2\pi)^{p/2}} \exp\left(-\frac{1}{2}\mathbf{z}^\top \mathbf{z}\right).$$

Considere a transformação afim

$$\mathbf{x} = \mu + \Sigma^{1/2}\mathbf{z}.$$

Como $\Sigma^{1/2}$ é invertível,

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu).$$

A Jacobiana da transformação inversa é a matriz constante $\Sigma^{-1/2}$, de modo que

$$|\det(\Sigma^{-1/2})| = \det(\Sigma)^{-1/2}.$$

Aplicando a transformação de densidades estabelecida na Proposição 7.19,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= f_{\mathbf{Z}}[\Sigma^{-1/2}(\mathbf{x} - \mu)] \det(\Sigma)^{-1/2} \\ &= \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right\}. \end{aligned}$$

□

A derivação mostra a função desempenhada pelos dois termos matriciais da densidade. O determinante surge da alteração de volume provocada pela transformação afim, enquanto a matriz inversa aparece ao expressar o afastamento de $\mathbf{x}$ nas coordenadas da normal padrão obtidas pelo branqueamento.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$. Probabilidades são atribuídas a regiões:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}, \quad (9.9)$$

para conjuntos mensuráveis $\mathcal{A} \subseteq \mathbb{R}^p$.

A forma quadrática no expoente é a distância quadrática de Mahalanobis definida na Definição 8.9:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Assim,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left[-\frac{1}{2} d_M^2(\mathbf{x}, \mu) \right]. \quad (9.10)$$

Para μ e Σ fixos, a posição de $\mathbf{x}$ afeta a densidade somente por meio de sua distância de Mahalanobis ao vetor de médias. Como

$$c \mapsto \exp \left(-\frac{c}{2} \right)$$

é estritamente decrescente para $c \geq 0$, pontos mais afastados do centro segundo essa métrica possuem menor densidade.

A log-densidade é

$$\begin{aligned} \log f_{\mathbf{X}}(\mathbf{x}) &= -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned} \quad (9.11)$$

A expressão reúne uma constante dependente da dimensão, um termo associado à escala volumétrica da dispersão e um termo associado ao afastamento do ponto em relação ao centro. No Capítulo 10, essa mesma estrutura aparecerá na função de verossimilhança de uma amostra normal multivariada.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e Equação 9.8 reduz-se a

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

O vetor μ determina a localização da distribuição. Como

$$d_M^2(\mathbf{x}, \mu) \geq 0$$

e a igualdade ocorre em $\mathbf{x} = \mu$, a densidade atinge seu máximo no centro:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}. \quad (9.12)$$

A matriz Σ determina a escala, a orientação e a forma das superfícies de igual densidade. A geometria desses elipsoides foi desenvolvida no Capítulo 8 na Equação 8.32; a novidade probabilística é que, na distribuição normal, essa mesma geometria organiza os valores da densidade.

9.2.2 Superfícies de igual densidade

Para $c > 0$, considere

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) = c\}. \quad (9.13)$$

Para todo $\mathbf{x} \in \mathcal{S}_c$,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{c}{2}\right).$$

Portanto, $\mathcal{S}_c$ é uma superfície de igual densidade.

Pela representação espectral em Equação 8.33, essas superfícies são elipsoidais. Seus eixos e extensões são determinados pela estrutura espectral de Σ . No modelo normal, dois pontos possuem a mesma densidade se, e somente se, apresentam a mesma distância de Mahalanobis ao vetor de médias.

A Figura 9.1 mostra essa correspondência para uma distribuição normal bivariada.

As curvas de nível são elipses centradas em μ . Todos os pontos sobre uma mesma curva apresentam a mesma distância de Mahalanobis ao centro e, conseqüentemente, a mesma densidade.

A região interna correspondente é

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.14)$$

Neste ponto, c é apenas uma constante positiva. Mais adiante, a distribuição de D_M^2 permitirá escolher valores de c associados a probabilidades populacionais específicas.




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

9.3 Transformações e distribuições marginais

A construção na Proposição 9.1 partiu de um vetor normal padrão. Uma propriedade mais geral da família normal é o fechamento sob transformações afins. Essa propriedade permite obter distribuições de combinações lineares, projeções, subvectores e transformações de padronização sem recalculas densidades por integração.

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

$\mathbf{A} \in \mathbb{R}^{m \times p}$ e $\mathbf{b} \in \mathbb{R}^m$.

Proposição 9.4 (Fechamento da família normal sob transformações afins). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação afim

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \tag{9.15}$$

satisfaz

$$\mathbf{Y} \sim N_m(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top), \tag{9.16}$$

em que

$$\mathbf{A} \in \mathbb{R}^{m \times p} \quad e \quad \mathbf{b} \in \mathbb{R}^m.$$

Comprovação. Pela Proposição 8.6,

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^m$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}.\end{aligned}$$

Como $\mathbf{X}$ é normal multivariado,

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição de uma constante preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado. $\square$

As fórmulas para média e covariância são válidas para vetores aleatórios gerais com segundos momentos finitos. O resultado específico da família normal é o **fechamento distribucional**: se $\mathbf{X}$ possui distribuição normal multivariada, então $\mathbf{A}\mathbf{X} + \mathbf{b}$ também possui distribuição normal multivariada.

A matriz $\mathbf{A}$ não precisa possuir posto completo. Consequentemente, a matriz de covariâncias transformada

$$\mathbf{A}\Sigma\mathbf{A}^\top$$

pode não ser positiva definida. Esse caso será retomado em Seção 9.8.

Exemplo 9.1 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

Logo,

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \end{aligned}$$

e a matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

O exemplo mostra que uma transformação afim modifica simultaneamente localização e covariância, mas preserva a família normal.

9.3.2 Combinações lineares

Uma combinação linear é o caso $m = 1$ de Proposição 9.4.

Para $\mathbf{a} \in \mathbb{R}^p$ e $b \in \mathbb{R}$,

$$Y = \mathbf{a}^\top \mathbf{X} + b$$

satisfaz

$$Y \sim N(\mathbf{a}^\top \mu + b, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.17)$$

A expressão fornece diretamente a distribuição de somas, diferenças, contrastes, médias ponderadas e projeções lineares.

Exemplo 9.2 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

Quando $\sigma_{12} > 0$, a covariância aumenta a variância da soma e reduz a variância da diferença. Para $\sigma_{12} < 0$, ocorre o efeito inverso.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

quase certamente.

9.3.3 Distribuições marginais

As distribuições marginais de subvetores também podem ser obtidas como transformações lineares.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.18)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Proposição 9.5 (Distribuições marginais da normal multivariada). *Os blocos marginais de um vetor normal multivariado particionado satisfazem*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.19)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.20)$$

Esse resultado considera a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Comprovação. O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

com

$$\mathbf{A}_1 = \begin{bmatrix} \mathbf{I}_{p_1} & \mathbf{0} \end{bmatrix}.$$

Pela Proposição 9.4,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1\mu, \mathbf{A}_1\Sigma\mathbf{A}_1^\top).$$

A estrutura particionada fornece

$$\mathbf{A}_1\mu = \mu_1$$

e

$$\mathbf{A}_1\Sigma\mathbf{A}_1^\top = \Sigma_{11}.$$

O segundo bloco é obtido de forma análoga. □

A distribuição marginal de um bloco depende de seu vetor de médias e de sua própria matriz de covariâncias. A matriz Σ_{12} não aparece nos parâmetros marginais, mas participa da estrutura de dependência conjunta.

Exemplo 9.3 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0,5 \\ -1 & 0,5 & 2 \end{bmatrix} \right).$$

Selecioneando X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas componentes correspondentes de μ , e a matriz de covariâncias marginal é a submatriz principal associada às variáveis selecionadas.

9.3.4 Padronização marginal e branqueamento

O Capítulo 8 definiu na Equação 8.20 a matriz

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Suponha

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

A padronização marginal é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \boldsymbol{\mu}). \quad (9.21)$$

Pela Proposição 9.4 e pela definição de $\mathcal{R}$ na Definição 8.5,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.22)$$

com

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Cada componente padronizada satisfaz

$$Z_{\text{pad},j} \sim N(0, 1),$$

mas as componentes não são necessariamente independentes.

Padronização não implica independência

A padronização marginal produz componentes com média zero e variância unitária, mas preserva as correlações existentes entre elas.

Assim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}).$$

As componentes serão independentes precisamente quando

$$\mathcal{R} = \mathbf{I}_p,$$

resultado que será formalizado na seção seguinte.

Quando

$$\Sigma \succ \mathbf{0},$$

o Capítulo 8 mostrou na Equação 8.51 que o branqueamento simétrico transforma a estrutura de segunda ordem em covariância identidade. Sob normalidade multivariada, é possível determinar também a distribuição completa do vetor transformado.

O branqueamento simétrico é dado por

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.23)$$

Pelo fechamento da família normal,

$$\begin{aligned} \mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p). \end{aligned} \quad (9.24)$$

A diferença entre as duas transformações é, portanto,

$$\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R})$$

e

$$\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A padronização marginal transforma as variâncias em um e preserva as correlações. O branqueamento transforma toda a matriz de covariâncias em identidade.

A consequência adicional da normalidade conjunta é probabilística: como será formalizado na seção seguinte, uma matriz de covariâncias diagonal implica independência das componentes dentro de um vetor conjuntamente normal. Portanto, as componentes do vetor branqueado são independentes.

Como discutido no Capítulo 8, o branqueamento não é único. No caso normal, essa não unicidade preserva também a distribuição normal padrão. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

pois

$$\mathbf{Q}_0 \mathbf{I}_p \mathbf{Q}_0^\top = \mathbf{I}_p.$$

O branqueamento simétrico constitui uma escolha específica entre transformações que produzem covariância identidade.

A próxima seção utiliza uma propriedade específica da normalidade conjunta: para blocos pertencentes ao mesmo vetor normal multivariado, covariância cruzada nula é equivalente à independência.

9.4 Independência e distribuições condicionais

Quando os segundos momentos existem, a independência entre dois blocos implica covariância cruzada nula. A implicação inversa, entretanto, não é válida sem hipóteses adicionais. Na família normal multivariada, a normalidade conjunta estabelece a equivalência entre independência e covariância cruzada nula.

A normalidade conjunta também permite determinar a distribuição condicional de um bloco a partir da estrutura de covariâncias. Nesse desenvolvimento, o complemento de Schur, definido na Definição 2.26 e aplicado à matriz de covariâncias no Capítulo 8, passa a ter uma interpretação probabilística: ele corresponde à matriz de covariâncias condicional.

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.25)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Se os dois blocos são independentes, então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A normalidade conjunta permite estabelecer também a implicação inversa.

Nesta seção, quando o símbolo $\perp$ aparece entre vetores aleatórios, a notação

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

significa que $\mathbf{X}_1$ e $\mathbf{X}_2$ são **independentes**. Esse uso deve ser distinguido da ortogonalidade geométrica, também representada pelo símbolo $\perp$ nos capítulos de Álgebra Linear.

Proposição 9.6 (Independência de blocos conjuntamente normais). *Para dois blocos conjuntamente normais,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}, \quad (9.26)$$

considerando a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2).$$

Comprovação. Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então a independência implica

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

Para a implicação inversa, suponha

$$\Sigma_{12} = \mathbf{0}.$$

Como

$$\Sigma_{21} = \Sigma_{12}^\top,$$

a matriz de covariâncias conjunta assume a forma

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Existem matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^\top$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^\top.$$

Considere vetores normais padrão independentes $\mathbf{Z}_1$ e $\mathbf{Z}_2$ e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Por construção,

$$\mathbf{Y}_1 \perp \mathbf{Y}_2.$$

Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Pela Proposição 9.2,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

$$\mathbf{X}_1 \perp \mathbf{X}_2.$$

□

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então

$$X_1, \dots, X_p$$

são mutuamente independentes.

Esse resultado é uma consequência específica da normalidade conjunta. Sem essa hipótese, uma matriz de covariâncias diagonal garante covariância nula entre componentes, mas não implica independência.

A normalidade deve ser conjunta

A equivalência

$$\text{Cov}(X_i, X_j) = 0 \quad \Longleftrightarrow \quad X_i \perp X_j$$

exige que X_i e X_j pertençam ao mesmo vetor normal multivariado.

A normalidade de cada variável considerada separadamente não é suficiente para essa conclusão.

9.4.2 Distribuição condicional

Considere novamente

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

e suponha

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0},$$

de modo que Σ_{22}^{-1} existe.

Na notação condicional, a barra vertical $|$ deve ser lida como **dado**. Assim,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$$

representa o vetor $\mathbf{X}_1$ condicionado ao valor $\mathbf{X}_2 = \mathbf{x}_2$, e o subscrito $1 | 2$ será utilizado para identificar quantidades condicionais relativas ao primeiro bloco dado o segundo.

Proposição 9.7 (Distribuição condicional da normal multivariada). *A distribuição condicional de um bloco de um vetor normal multivariado particionado é normal multivariada:*

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1} \left(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2} \right). \quad (9.27)$$

Esse resultado considera a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad \mathbf{x}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{22} \succ \mathbf{0}.$$

A média condicional é

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) \quad (9.28)$$

e a matriz de covariâncias condicional é

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.29)$$

A matriz $\Sigma_{11 \cdot 2}$ é o complemento de Schur de Σ_{22} em Σ , definido em Equação 8.16.

Comprovação. Considere

$$\mathbf{L}^* = \Sigma_{12} \Sigma_{22}^{-1}$$

e defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \mathbf{L}^* (\mathbf{X}_2 - \mu_2). \quad (9.30)$$

Os vetores $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são obtidos conjuntamente por uma transformação afim de $\mathbf{X}$. Pela Proposição 9.4,

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \mathbf{L}^* \Sigma_{22} \\ &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pela Proposição 9.6,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.31)$$

Além disso,

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Pela Proposição 8.5,

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Portanto,

$$\mathbf{E}_{1|2} \sim N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando Equação 9.30,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Condicionando em

$$\mathbf{X}_2 = \mathbf{x}_2,$$

a parcela que depende de $\mathbf{X}_2$ torna-se

$$\mu_{1|2}(\mathbf{x}_2).$$

Como $\mathbf{E}_{1|2}$ é independente de $\mathbf{X}_2$, sua distribuição permanece

$$N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2})$$

após o condicionamento. Portanto,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2}).$$

□

A demonstração fornece a decomposição

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.32)$$

com

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

Consequentemente,

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2). \quad (9.33)$$

No Capítulo 8, na Proposição 8.5, a expressão

$$\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2)$$

surgiu como o melhor ajuste linear de $\mathbf{X}_1$ em função de $\mathbf{X}_2$, utilizando apenas informações de primeira e segunda ordem.

Sob normalidade conjunta, ocorre um resultado mais forte:

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2).$$

Assim, na família normal multivariada, o melhor ajuste linear coincide exatamente com a esperança condicional, e a matriz de covariâncias do resíduo linear coincide com a matriz de covariâncias condicional.

9.4.3 Média e covariância condicionais

A média condicional

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

depende do valor condicionado.

O vetor

$$\mathbf{x}_2 - \mu_2$$

representa o afastamento do bloco conhecido em relação à sua média. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média de $\mathbf{X}_1$.

Quando

$$\mathbf{x}_2 = \mu_2,$$

tem-se

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

A matriz de covariâncias condicional é

$$\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Ela não depende do valor específico de $\mathbf{x}_2$. Assim, diferentes valores do bloco condicionante deslocam o centro da distribuição condicional, mas não alteram sua matriz de covariâncias.

Como $\Sigma \succ \mathbf{0}$, a propriedade de positividade do complemento de Schur fornece

$$\Sigma_{11.2} \succ \mathbf{0}. \quad (9.34)$$

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11.2} = \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.35)$$

Como

$$\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \succeq \mathbf{0},$$

segue que

$$\Sigma_{11.2} \preceq \Sigma_{11}. \quad (9.36)$$

Portanto, para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} \text{Var}[\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{a}^\top \Sigma_{11.2} \mathbf{a} \\ &\leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}. \end{aligned}$$

Condicionar no segundo bloco não aumenta a variância de nenhuma combinação linear do primeiro bloco.

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se simultaneamente

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1$$

e

$$\Sigma_{11.2} = \Sigma_{11}.$$

Nesse caso, a distribuição condicional coincide com a distribuição marginal, como consequência da independência entre os blocos estabelecida na Proposição 9.6.

9.4.4 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.37)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad -1 < \rho < 1.$$

A média condicional de X_1 dado $X_2 = x_2$ é

$$\begin{aligned} E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2} (x_2 - \mu_2) \\ &= \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2). \end{aligned} \quad (9.38)$$

A variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2\sigma_1^2\sigma_2^2}{\sigma_2^2} \\ &= \sigma_1^2 (1 - \rho^2). \end{aligned} \quad (9.39)$$

Portanto,

$$X_1 | X_2 = x_2 \sim N \left[\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right]. \quad (9.40)$$

O sinal de ρ determina a direção do deslocamento da média condicional. Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média de X_1 para valores maiores; se $\rho < 0$, o deslocamento ocorre em sentido oposto.

A variância condicional depende de ρ^2 e não do valor observado x_2 . Quanto maior $|\rho|$, menor é a variabilidade remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

obtém-se

$$E(X_1 | X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 | X_2 = x_2) = \sigma_1^2.$$

A distribuição condicional coincide, então, com a marginal. Isso é consistente com Proposição 9.6, pois, sob normalidade conjunta, $\rho = 0$ implica independência entre X_1 e X_2 .

Exemplo 9.4 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0,8,$$

e a variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = 1) &= 1 - 0,8^2 \\ &= 0,36. \end{aligned}$$

Logo,

$$X_1 \mid X_2 = 1 \sim N(0,8,0,36).$$

O desvio-padrão condicional é

$$\sqrt{0,36} = 0,6.$$

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

No primeiro painel, a linha horizontal identifica o valor condicionado $X_2 = 1$. O ponto sobre essa linha indica a média da distribuição condicional de X_1 .

O segundo painel mostra

$$X_1 \mid X_2 = 1 \sim N(0,8,0,36).$$

Em relação à distribuição marginal $N(0,1)$, a média passa de 0 para 0,8 e a variância passa de 1 para 0,36. O exemplo ilustra duas propriedades gerais: a média condicional depende do valor condicionado, enquanto a matriz de covariâncias condicional não depende desse valor.

O branqueamento desenvolvido anteriormente permite agora obter uma segunda consequência probabilística da normalidade: a distribuição exata da distância quadrática de Mahalanobis.

9.5 Distância de Mahalanobis e regiões de probabilidade

O Capítulo 8 definiu em Definição 8.9 a distância de Mahalanobis como uma medida geométrica adaptada à estrutura de covariâncias. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a distância quadrática ao vetor de médias possui uma distribuição probabilística conhecida.

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A variável aleatória

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \quad (9.41)$$

representa a distância quadrática de Mahalanobis entre uma realização aleatória e o centro populacional.

9.5.1 Distribuição qui-quadrado

Proposição 9.8 (Distribuição da distância quadrática de Mahalanobis). *A distância quadrática de Mahalanobis*

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2, \quad (9.42)$$

para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Comprovação. Pelo branqueamento na Equação 9.23,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

As componentes

$$Z_1, \dots, Z_p$$

são, portanto, normais padrão independentes.

Além disso,

$$\begin{aligned} D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\ &= [\Sigma^{-1/2} (\mathbf{X} - \mu)]^\top [\Sigma^{-1/2} (\mathbf{X} - \mu)] \\ &= \mathbf{Z}^\top \mathbf{Z} \\ &= \sum_{j=1}^p Z_j^2. \end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Logo,

$$D_M^2 \sim \chi_p^2.$$

□

Como $\Sigma \succ \mathbf{0}$, a dimensão da distribuição é p , que determina os graus de liberdade da distribuição qui-quadrado.

Consequentemente,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \tag{9.43}$$

A escala de D_M^2 depende, portanto, da dimensão. Sob o modelo normal, seu valor esperado é p , e não zero.

A igualdade

$$E(D_M^2) = p$$

não depende da normalidade multivariada. No Capítulo 8, Equação 8.53 obteve esse resultado a partir apenas da estrutura de segunda ordem, para qualquer vetor aleatório com vetor de médias μ e matriz de covariâncias positiva definida Σ .

A hipótese de normalidade fornece um resultado mais forte:

$$D_M^2 \sim \chi_p^2.$$

Assim, no presente capítulo, além do valor esperado, passa-se a conhecer a distribuição completa da distância quadrática de Mahalanobis, incluindo sua variância e seus quantis.

No espaço branqueado,

$$D_M^2 = \|\mathbf{Z}\|^2.$$

Assim, a distância quadrática de Mahalanobis no espaço original corresponde ao quadrado da distância euclidiana à origem no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado

$$D_M^2 \sim \chi_p^2$$

utiliza os parâmetros populacionais μ e Σ .

Se esses parâmetros forem substituídos por estimativas obtidas a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 .

A distinção entre parâmetros populacionais e quantidades estimadas a partir da amostra será desenvolvida nos Capítulos 10 e 12.

9.5.2 Regiões elipsoidais de probabilidade

Definição 9.2 (Região elipsoidal de probabilidade). Para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a região elipsoidal de probabilidade $1 - \alpha$ é

$$\mathcal{E}_{1-\alpha} = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p;1-\alpha}^2 \right\}, \quad (9.44)$$

em que $0 < \alpha < 1$ e $\chi_{p;1-\alpha}^2$ é o quantil de ordem $1 - \alpha$ da distribuição χ_p^2 .

Consequentemente,

$$P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) = 1 - \alpha.$$

Pela Proposição 9.8,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P[D_M^2 \leq \chi_{p;1-\alpha}^2] \\ &= P[\chi_p^2 \leq \chi_{p;1-\alpha}^2] \\ &= 1 - \alpha. \end{aligned} \tag{9.45}$$

Portanto, $\mathcal{E}_{1-\alpha}$ é uma região populacional que contém uma realização de $\mathbf{X}$ com probabilidade $1 - \alpha$.

Sua fronteira é

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p;1-\alpha}^2.$$

A geometria é a mesma dos elipsoides de Mahalanobis definidos na Equação 8.32 no Capítulo 8. A novidade do modelo normal é a calibração probabilística da constante. Como naquele capítulo o elipsoide foi definido por

$$d_M^2(\mathbf{x}, \mu) \leq c^2,$$

a região de probabilidade $1 - \alpha$ é obtida fazendo

$$c^2 = \chi_{p;1-\alpha}^2,$$

ou, equivalentemente,

$$c = \sqrt{\chi_{p;1-\alpha}^2}.$$

No espaço branqueado, a região corresponde à esfera

$$\{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p;1-\alpha}^2\},$$

de raio

$$\sqrt{\chi_{p;1-\alpha}^2}.$$

As superfícies de igual densidade e as fronteiras das regiões elipsoidais de probabilidade possuem a mesma forma geométrica porque ambas são determinadas por valores constantes de d_M^2 . A diferença está na escolha da constante: nas regiões de probabilidade, ela é determinada por um quantil da distribuição χ_p^2 .

Região de probabilidade e região de confiança

A região

$$\mathcal{E}_{1-\alpha}$$

refere-se à posição de uma **realização de $\mathbf{X}$** quando os parâmetros populacionais μ e Σ são conhecidos.

Ela não é uma região de confiança para μ .

Regiões de confiança para parâmetros populacionais serão construídas no Capítulo 12 a partir de distribuições amostrais.

9.5.3 Avaliação de uma observação fixa

Considere agora um ponto fixo

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.46)$$

O ponto está dentro de $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p;1-\alpha}^2. \quad (9.47)$$

Se

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p;1-\alpha}^2,$$

a observação está fora da região que contém probabilidade populacional $1 - \alpha$.

Essa comparação descreve a posição de um valor já observado em relação ao modelo. Depois que $\mathbf{x}_0$ foi fixado, não se atribui a ele probabilidade de pertencer à região: ele está dentro ou fora dela.

Também pode ser calculada a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)] . \quad (9.48)$$

A quantidade p_M mede, sob o modelo populacional completamente especificado, a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada.

Um valor pequeno indica que $\mathbf{x}_0$ se encontra em uma região de afastamentos pouco frequentes sob a distribuição especificada. Essa interpretação depende de μ e Σ serem parâmetros populacionais conhecidos e não constitui, neste ponto, um procedimento inferencial para detecção de observações atípicas com parâmetros estimados.

Exemplo 9.5 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix} .$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} .$$

Logo,

$$\begin{aligned} d_M^2(\mathbf{x}_0, \mu) &= \begin{bmatrix} 3 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\ &= \frac{7}{3} \\ &\approx 2,33. \end{aligned}$$

Para a região que contém probabilidade 0,95,

$$\chi_{2;0,95}^2 \approx 5,99.$$

Como

$$2,33 < 5,99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

A probabilidade de cauda associada à distância observada é

$$\begin{aligned} p_M &= P(\chi_2^2 \geq 2,33) \\ &\approx 0,31. \end{aligned}$$

Assim, aproximadamente 31% dos vetores gerados pelo modelo apresentam distância quadrática de Mahalanobis ao centro pelo menos tão grande quanto a observada. O ponto, portanto, não apresenta um afastamento particularmente extremo em relação à distribuição especificada.

O exemplo utiliza parâmetros populacionais conhecidos. Se o vetor de médias e a matriz de covariâncias fossem substituídos por estimativas amostrais, seria necessário utilizar a teoria inferencial apropriada.

Os resultados desta seção mostram a passagem da geometria da distância de Mahalanobis e de seus elipsoides, desenvolvida em Definição 8.9 e Equação 8.32, para uma interpretação probabilística. Sob normalidade multivariada e $\Sigma \succ \mathbf{0}$, a forma quadrática de Mahalanobis possui distribuição χ_p^2 , permitindo calibrar os elipsoides por probabilidades populacionais.

A comparação entre duas distribuições normais permite observar, em seguida, como mudanças no vetor de médias e na matriz de covariâncias modificam suas posições, formas e densidades. Essa comparação será utilizada somente como motivação para técnicas de discriminação desenvolvidas posteriormente.

9.6 Comparação entre distribuições normais

Considere duas populações descritas por distribuições normais multivariadas:

$$\mathbf{X}_1 \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{X}_2 \sim N_p(\mu_2, \Sigma_2),$$

com

$$\Sigma_1 \succ \mathbf{0} \quad \text{e} \quad \Sigma_2 \succ \mathbf{0}.$$

Os vetores de médias determinam a localização das distribuições, enquanto as matrizes de covariâncias determinam sua dispersão, orientação e forma. A comparação entre duas distribuições normais permite observar como esses dois componentes da parametrização atuam conjuntamente.

9.6.1 Médias distintas e covariância comum

Suponha

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As duas distribuições possuem superfícies de igual densidade com a mesma forma, orientação e extensão, mas centradas em pontos diferentes.

Pela log-densidade na Equação 9.11, ambas contêm o termo quadrático

$$-\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x}.$$

Ao comparar as duas log-densidades, esse termo é comum e se cancela. De fato,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \end{aligned} \tag{9.49}$$

A log-razão entre as densidades é, portanto, uma função afim de $\mathbf{x}$.

Consequentemente, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : f_1(\mathbf{x}) = f_2(\mathbf{x})\}$$

é um hiperplano.

A matriz de covariâncias comum influencia a orientação desse hiperplano por meio do vetor

$$\Sigma^{-1}(\mu_1 - \mu_2),$$

que determina sua direção normal. Assim, a separação entre os centros é avaliada segundo a geometria induzida pela matriz de covariâncias comum.

9.6.2 Covariâncias distintas

Considere agora

$$\Sigma_1 \neq \Sigma_2.$$

As distribuições podem diferir não somente quanto à localização, mas também quanto à forma, orientação e extensão de suas superfícies de igual densidade.

Nesse caso, as log-densidades envolvem as formas quadráticas

$$-\frac{1}{2}(\mathbf{x} - \mu_1)^\top \Sigma_1^{-1}(\mathbf{x} - \mu_1)$$

e

$$-\frac{1}{2}(\mathbf{x} - \mu_2)^\top \Sigma_2^{-1}(\mathbf{x} - \mu_2).$$

Como as matrizes inversas são diferentes, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral. Expandindo a diferença entre as log-densidades,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2}\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x} \\ &\quad + \mathbf{x}^\top (\Sigma_1^{-1}\mu_1 - \Sigma_2^{-1}\mu_2) \\ &\quad - \frac{1}{2}(\mu_1^\top \Sigma_1^{-1}\mu_1 - \mu_2^\top \Sigma_2^{-1}\mu_2) \\ &\quad - \frac{1}{2} \log \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right). \end{aligned} \tag{9.50}$$

A presença do termo

$$\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x}$$

faz com que a log-razão seja, em geral, uma função quadrática de $\mathbf{x}$.

Assim, o conjunto de pontos nos quais

$$f_1(\mathbf{x}) = f_2(\mathbf{x})$$

é determinado, em geral, por uma equação quadrática em $\mathbf{x}$. Sua geometria pode, portanto, diferir substancialmente do hiperplano obtido no caso de covariância comum.

A Figura 9.3 ilustra as duas situações.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

No primeiro painel, as duas distribuições apresentam superfícies de nível com a mesma forma e orientação, deslocadas para centros diferentes. No segundo, as diferenças entre as matrizes de covariâncias modificam também a extensão e a orientação dessas superfícies.

A comparação mostra duas estruturas algébricas que serão utilizadas posteriormente. Com uma matriz de covariâncias comum, a comparação das log-densidades elimina os termos quadráticos comuns e produz uma expressão afim. Com matrizes de covariâncias distintas, permanecem, em geral, termos quadráticos.

Esses resultados serão retomados na formulação da Análise Discriminante. A construção de regras de classificação, probabilidades a priori, custos de decisão e estimação dos parâmetros pertence aos módulos posteriores.

9.7 Alcance da hipótese de normalidade

A distribuição normal multivariada acrescenta uma estrutura probabilística específica aos objetos desenvolvidos nos capítulos anteriores. É importante distinguir quais resultados dependem dessa hipótese e quais permanecem válidos para vetores aleatórios mais gerais.

9.7.1 Resultados que não exigem normalidade

Diversos resultados utilizados neste capítulo dependem somente da existência dos momentos necessários.

Para um vetor aleatório com média μ e matriz de covariâncias Σ ,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}$$

não exigem normalidade.

Da mesma forma, para

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

as relações

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

são propriedades gerais dos primeiros e segundos momentos.

A matriz de covariâncias continua simétrica e positiva semidefinida, conforme Proposição 8.2; a distância de Mahalanobis continua definindo a geometria apresentada na Definição 8.9 quando a matriz de covariâncias é positiva definida; e o complemento de Schur continua representando a covariância do resíduo do melhor ajuste linear entre blocos, conforme Proposição 8.5. Esses resultados foram desenvolvidos no Capítulo 8 sem hipótese de normalidade.

Também não depende da normalidade a esperança de uma forma quadrática centrada. Para uma matriz simétrica $\mathbf{A}$,

$$E \left[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a}) \right] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}),$$

desde que existam os momentos de segunda ordem necessários.

Em particular, quando $\Sigma \succ \mathbf{0}$,

$$E \left[(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \right] = p.$$

Portanto, o valor esperado da distância quadrática de Mahalanobis é uma propriedade de segunda ordem e não uma consequência específica da normalidade.

Esses resultados descrevem estruturas de primeira e segunda ordem. Eles não determinam, por si mesmos, a distribuição conjunta.

9.7.2 Resultados específicos da família normal

A hipótese de normalidade conjunta produz propriedades adicionais.

Entre os resultados desenvolvidos neste capítulo estão:

- o vetor de médias e a matriz de covariâncias determinam completamente a distribuição;
- transformações afins preservam a família normal;
- distribuições marginais de subvectores permanecem normais;
- covariância cruzada nula entre blocos conjuntamente normais equivale à independência;
- distribuições condicionais permanecem normais;
- a esperança condicional entre blocos é uma função afim do bloco condicionante;
- a matriz de covariâncias condicional é o complemento de Schur correspondente;
- quando $\Sigma \succ \mathbf{0}$, o branqueamento produz componentes normais padrão independentes;
- quando $\Sigma \succ \mathbf{0}$, a distância quadrática de Mahalanobis populacional possui distribuição χ_p^2 .

A equivalência

$$\Sigma_{12} = \mathbf{0} \iff \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo da diferença entre uma propriedade geral de covariância e uma propriedade específica da família normal.

A implicação

$$\mathbf{X}_1 \perp \mathbf{X}_2 \implies \Sigma_{12} = \mathbf{0}$$

vale, quando os segundos momentos existem, sem normalidade. A implicação inversa requer a estrutura normal conjunta estabelecida na Proposição 9.6.

De maneira semelhante, a igualdade

$$E(D_M^2) = p$$

decorre apenas da estrutura de segunda ordem, mas a afirmação

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

é específica do modelo normal multivariado sob $\Sigma \succ \mathbf{0}$.

Assim, conhecer apenas μ e Σ permite determinar a esperança dessa forma quadrática, mas não sua distribuição completa. A distribuição qui-quadrado estabelecida na Proposição 9.8 depende da normalidade multivariada.

Assim, a normalidade transforma relações entre médias, covariâncias e formas quadráticas em afirmações sobre distribuições completas.

9.7.3 Passagem do modelo populacional para a inferência

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais que caracterizam a distribuição, sem abordar sua estimação a partir de uma amostra. Essa escolha permitiu estudar diretamente as propriedades da distribuição

$$N_p(\mu, \Sigma).$$

Em uma aplicação estatística, esses parâmetros são geralmente desconhecidos. A observação de uma amostra introduz uma nova distinção entre:

- parâmetros populacionais;
- estatísticas aleatórias;
- estimadores;
- valores calculados a partir dos dados observados.

Essa distinção modifica alguns resultados. Por exemplo,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não autoriza substituir diretamente μ e Σ por estimativas e manter a mesma distribuição.

Da mesma forma, conhecer a forma da densidade normal não é suficiente para realizar inferência sobre parâmetros desconhecidos. É necessário especificar uma amostra aleatória, construir estatísticas e estudar suas propriedades e distribuições amostrais.

O Capítulo 10 inicia essa passagem. O modelo probabilístico permanece o ponto de partida, mas os parâmetros populacionais passam a ser relacionados a estatísticas e estimadores construídos a partir da amostra.

9.8 Aprofundamento: Normal Singular

Leitura de aprofundamento

A sequência principal do capítulo considerou

$$\Sigma \succ \mathbf{0},$$

de modo que a matriz de covariâncias é invertível e a distribuição possui densidade em todo $\mathbb{R}^p$.

Quando Σ é positiva semidefinida, mas não positiva definida, a distribuição normal multivariada é singular. Nesse caso, parte das direções apresenta variância zero e a variabilidade fica restrita a um subespaço de dimensão inferior a p .

Esta seção reúne a definição, a representação em dimensão reduzida, o suporte, a densidade no suporte, o branqueamento e a forma generalizada de Mahalanobis no caso singular.

Definição 9.3 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\mu, \Sigma)$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\Sigma) = r < p.$$

Como toda matriz de covariâncias é positiva semidefinida, esse caso equivale a

$$\Sigma \succeq \mathbf{0} \quad \text{e} \quad \Sigma \not\succ \mathbf{0}.$$

A distribuição é **não singular** quando

$$\text{posto}(\Sigma) = p,$$

equivalentemente,

$$\Sigma \succ \mathbf{0}.$$

A normal singular surge quando existem relações lineares exatas entre as componentes do vetor. Se, por exemplo,

$$X_3 = X_1 + X_2$$

quase certamente, uma das componentes não acrescenta uma nova direção de variabilidade e a matriz de covariâncias não possui posto completo.

O caso singular também pode resultar de uma transformação linear que reduz a dimensão. Se

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \in \mathbb{R}^m$$

e

$$\text{posto}(\mathbf{A}) < m,$$

então

$$\text{posto}(\mathbf{A}\Sigma\mathbf{A}^\top) \leq \text{posto}(\mathbf{A}) < m.$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

é singular.

A distribuição normal singular fornece, portanto, um modelo probabilístico para vetores normais sujeitos a restrições lineares exatas ou representados em um espaço ambiente de dimensão maior que sua dimensão probabilística efetiva.

A singularidade de uma matriz de covariâncias amostral, entretanto, não implica que a matriz de covariâncias populacional seja singular. Como será formalizado em Equação 10.81, quando

$p \geq n$, a matriz de covariâncias amostral possui posto no máximo $n - 1$ e é necessariamente singular, mesmo que a matriz populacional seja positiva definida.

Nos desenvolvimentos a seguir, considere

$$1 \leq r = \text{posto}(\Sigma) < p.$$

O caso extremo $r = 0$ será apresentado ao final da seção.

Como Σ é simétrica e positiva semidefinida, Teorema 5.4 e Proposição 5.6 garantem que sua decomposição espectral reduzida pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top. \quad (9.51)$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

possui colunas ortonormais associadas aos r autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Por Proposição 5.5,

$$\mathcal{C}(\Sigma) = \mathcal{C}(\mathbf{Q}_r).$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top.$$

Logo, uma representação da distribuição singular é

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.52)$$

Por Proposição 8.3, a singularidade de Σ implica, para qualquer vetor aleatório com essa matriz de covariâncias,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente. Na família normal, a representação na Equação 9.52 permite uma conclusão mais forte: o subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

constitui o suporte da distribuição.

Proposição 9.9 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

o suporte da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Consequentemente,

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.53)$$

Comprovação. Pela representação Equação 9.52,

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}.$$

Como $\Lambda_r^{1/2}$ é invertível,

$$\mathcal{C}(\mathbf{A}_r) = \mathcal{C}(\mathbf{Q}_r) = \mathcal{C}(\Sigma).$$

Portanto,

$$\mathbf{A}_r \mathbf{Z} \in \mathcal{C}(\Sigma)$$

quase certamente, o que fornece Equação 9.53.

Além disso, $\mathbf{A}_r$ possui posto coluna r . A aplicação

$$\mathbf{z} \mapsto \mu + \mathbf{A}_r \mathbf{z}$$

é uma transformação afim bijetiva entre $\mathbb{R}^r$ e

$$\mu + \mathcal{C}(\Sigma).$$

Como a normal padrão em $\mathbb{R}^r$ possui densidade positiva em todo $\mathbb{R}^r$, todo conjunto relativamente aberto e não vazio desse subespaço afim possui probabilidade positiva. Assim, esse subespaço é o suporte da distribuição. $\square$

A mesma estrutura pode ser caracterizada pelo núcleo da matriz de covariâncias. Se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

e, consequentemente,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

quase certamente.

As direções do núcleo são, portanto, direções sem variabilidade probabilística.

A normal singular não possui densidade em relação à medida de Lebesgue de dimensão p em $\mathbb{R}^p$, pois toda a probabilidade está concentrada no suporte

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão $r < p$. Nesse suporte, entretanto, a distribuição possui densidade relativamente à medida de volume r -dimensional, como será mostrado a seguir.

Exemplo 9.6 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Equivalentemente,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1 e

$$X_2 = 2X_1$$

quase certamente. Portanto, toda a distribuição está concentrada na reta

$$x_2 = 2x_1.$$

Embora o vetor tenha duas componentes, sua dimensão probabilística efetiva é 1.

Densidade no suporte da normal singular

Por Proposição 9.9, a distribuição está concentrada no subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão

$$r = \text{posto}(\Sigma).$$

Retomando Equação 9.51,

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top, \quad \Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r),$$

a Definição 5.10 fornece

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\det(\Lambda_r) = \prod_{j=1}^r \lambda_j > 0,$$

a densidade relativamente à medida de volume r -dimensional no suporte afim pode ser escrita como

$$f_{\text{sup}}(\mathbf{x}) = \frac{1}{(2\pi)^{r/2} \det(\Lambda_r)^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \right], \quad (9.54)$$

para

$$\mathbf{x} \in \mu + \mathcal{C}(\Sigma).$$

Essa expressão utiliza a mesma estrutura de Equação 9.8, mas somente nas r direções em que existe variabilidade (Anderson, 2003; Rao, 1973).

A conexão com uma normal não singular de dimensão r decorre diretamente de Equação 9.52. Defina

$$\mathbf{Y} = \Lambda_r^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

Por Proposição 9.1,

$$\mathbf{Y} \sim N_r(\mathbf{0}, \Lambda_r).$$

Assim, Equação 9.52 pode ser escrita como

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{Q}_r \mathbf{Y}. \quad (9.55)$$

Portanto, a normal singular em $\mathbb{R}^p$ corresponde à representação de uma normal não singular de dimensão r no subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

Branqueamento no caso singular

Se

$$\text{posto}(\Sigma) = r < p,$$

a matriz $\Sigma^{1/2}$ é singular e não possui inversa ordinária. Utilizando

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

pode-se definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.56)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.57)$$

Essa transformação expressa a distribuição em suas r direções de variância positiva e realiza o branqueamento no espaço efetivo da normal singular. Assim, embora o vetor original pertença a $\mathbb{R}^p$, sua parte aleatória pode ser representada por um vetor normal padrão de dimensão r .

Proposição 9.10 (Forma generalizada de Mahalanobis no caso normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad 1 \leq r = \text{posto}(\Sigma) < p,$$

a forma quadrática generalizada de Mahalanobis

$$D_{M,+}^2 = (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \quad (9.58)$$

satisfaz

$$D_{M,+}^2 \sim \chi_r^2, \quad (9.59)$$

em que Σ^+ é a pseudoinversa de Moore–Penrose de Σ .

Comprovação. Considere a decomposição espectral reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pelo branqueamento reduzido na Equação 9.56,

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu) \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A pseudoinversa de Σ é

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente,

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r \\ &= \sum_{j=1}^r Z_{rj}^2. \end{aligned}$$

As componentes de $\mathbf{Z}_r$ são normais padrão independentes. Portanto,

$$\mathbf{Z}_r^\top \mathbf{Z}_r \sim \chi_r^2.$$

□

Consequentemente,

$$E(D_{M,+}^2) = r$$

e

$$\text{Var}(D_{M,+}^2) = 2r.$$

Assim, no caso singular, a escala da forma generalizada de Mahalanobis é determinada pela dimensão efetiva r da distribuição, e não pela dimensão ambiente p .

Uma região de probabilidade $1 - \alpha$ no suporte efetivo pode ser definida por

$$\mathcal{E}_{1-\alpha}^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r;1-\alpha}^2 \right\}. \quad (9.60)$$

Pela Proposição 9.10,

$$P\left[\mathbf{X} \in \mathcal{E}_{1-\alpha}^{(r)}\right] = 1 - \alpha.$$

A calibração utiliza a dimensão efetiva r , e não a dimensão ambiente p .

Se

$$r = 0,$$

então

$$\Sigma = \mathbf{0}$$

e

$$\mathbf{X} = \mu$$

quase certamente. Nesse caso extremo, a distribuição está concentrada em um único ponto.

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição singular atribui probabilidade 1 ao seu suporte afim.

9.9 Síntese do capítulo

A distribuição normal multivariada estabelece um modelo probabilístico para um vetor aleatório em que a estrutura conjunta é completamente determinada pelo vetor de médias e pela matriz de covariâncias.

A Tabela 9.1 reúne os principais resultados.

Tabela 9.1: Principais estruturas e resultados da distribuição normal multivariada.

Estrutura	Resultado
Definição	$\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a} \in \mathbb{R}^p$
Parametrização	$\mathbf{X} \sim N_p(\mu, \Sigma)$ é determinada por μ e Σ
Construção	$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}$, com $\Sigma = \mathbf{A}\mathbf{A}^\top$

Estrutura	Resultado
Caso singular	se $\text{posto}(\Sigma) = r < p$, o suporte é $\mu + \mathcal{C}(\Sigma)$ e a densidade é definida relativamente ao volume r -dimensional nesse subespaço
Caso não singular	se $\Sigma \succ \mathbf{0}$, o suporte é $\mathbb{R}^p$ e existe densidade em relação à medida de Lebesgue em $\mathbb{R}^p$
Transformação afim	$\mathbf{A}\mathbf{X} + \mathbf{b}$ permanece normal
Marginalização	subvectores de um vetor normal multivariado permanecem normais
Independência	$\Sigma_{12} = \mathbf{0}$ equivale à independência entre blocos conjuntamente normais
Condicionamento	a distribuição condicional é normal, com média afim e covariância dada por complemento de Schur
Branqueamento	se $\Sigma \succ \mathbf{0}$, produz $N_p(\mathbf{0}, \mathbf{I}_p)$; no caso singular, o branqueamento reduzido produz $N_r(\mathbf{0}, \mathbf{I}_r)$
Mahalanobis	$D_M^2 \sim \chi_p^2$ no caso não singular
Regiões de probabilidade	$D_M^2 \leq \chi_{p;1-\alpha}^2$ define uma região populacional de probabilidade $1 - \alpha$
Caso singular de Mahalanobis	$D_{M,+}^2 \sim \chi_r^2$, com $r = \text{posto}(\Sigma)$
Comparação de distribuições	covariância comum produz log-razão afim; covariâncias distintas produzem, em geral, log-razão quadrática

A definição por combinações lineares e a representação afim mostram duas caracterizações complementares da família normal multivariada. A primeira descreve a distribuição por suas projecções unidimensionais; a segunda mostra como sua estrutura conjunta é determinada por μ e Σ .

Quando $\Sigma \succ \mathbf{0}$, a distribuição possui densidade em $\mathbb{R}^p$, o branqueamento produz uma normal padrão multivariada e a distância quadrática de Mahalanobis possui distribuição χ_p^2 . A normalidade fornece, assim, uma interpretação probabilística para a geometria da covariância e da distância de Mahalanobis desenvolvida no Capítulo 8.

Quando Σ é singular, a distribuição permanece normal, mas sua variabilidade fica restrita ao subespaço afim $\mu + \mathcal{C}(\Sigma)$. A dimensão probabilística efetiva passa a ser $r = \text{posto}(\Sigma)$, e a pseudoinversa permite estender ao suporte a densidade, o branqueamento e a forma quadrática de Mahalanobis.

Transformações afins e marginalizações preservam a família normal. Sob normalidade conjunta, covariância cruzada nula equivale à independência entre blocos, e o complemento de Schur fornece a matriz de covariâncias da distribuição condicional.

Ao término deste capítulo, deve-se ser capaz de:

- caracterizar uma distribuição normal multivariada por combinações lineares;
- construir vetores normais por transformações afins de vetores normais padrão;
- distinguir distribuições normais singulares e não singulares;
- identificar o suporte e a dimensão probabilística efetiva de uma normal singular;
- interpretar a densidade normal multivariada e suas superfícies de nível;
- obter distribuições de transformações afins, combinações lineares e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância cruzada nula e independência sob normalidade conjunta;
- determinar média e matriz de covariâncias de uma distribuição condicional;
- interpretar o complemento de Schur como covariância condicional;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis populacional e interpretar regiões elipsoidais de probabilidade;
- comparar distribuições normais com covariância comum e com covariâncias distintas por meio de suas log-densidades;
- distinguir resultados gerais de segunda ordem daqueles que dependem da normalidade.

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais que caracterizam a distribuição, sem abordar sua estimação a partir de uma amostra. O Capítulo 10 introduz a amostra aleatória multivariada e distingue parâmetros, estatísticas, estimadores e estimativas. Essa passagem permitirá estudar como o vetor de médias e a matriz de covariâncias podem ser estimados a partir dos dados e quais propriedades podem ser atribuídas aos respectivos estimadores.

10 Estatísticas Amostrais e Estimação

O Capítulo 8 desenvolveu o vetor de médias populacional na Equação 8.1 e a matriz de covariâncias populacional na Definição 8.2. O Capítulo 9, por sua vez, formulou a distribuição normal multivariada na Definição 9.1. Até esse ponto, μ e Σ foram tratados como parâmetros populacionais. Em uma aplicação estatística, esses parâmetros geralmente são desconhecidos e precisam ser estimados a partir de uma amostra.

O objetivo deste capítulo é passar dos objetos populacionais às estatísticas definidas sobre uma amostra multivariada e estudar sua utilização como estimadores. Serão desenvolvidos o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados (SQPC), os estimadores da matriz de covariâncias, a matriz de correlações amostral e as covariâncias cruzadas entre blocos de variáveis.

Os métodos dos momentos e da máxima verossimilhança serão utilizados como princípios de construção de estimadores. As propriedades matemáticas e os resultados de cálculo matricial estabelecidos no Módulo 1 serão retomados somente quando necessários.

As distribuições amostrais exatas, a distribuição de Wishart, a independência entre o vetor de médias e a matriz de covariâncias amostrais sob normalidade e os procedimentos de inferência serão desenvolvidos no Capítulo 12. Neste capítulo, o objetivo é construir os principais estimadores de localização, dispersão e associação, estudar suas propriedades e examinar limitações associadas ao tamanho amostral e à dimensão.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório populacional;
- $\mathbf{X}_1, \dots, \mathbf{X}_n$ representam os vetores aleatórios que compõem a amostra;
- $\mathbf{x}_1, \dots, \mathbf{x}_n$ representam suas realizações;
- $\mathcal{X} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória da amostra;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa a matriz de dados observada;
- μ , Σ e $\mathcal{R}$ representam, respectivamente, o vetor de médias, a matriz de covariâncias e a matriz de correlações populacionais;
- $\bar{\mathbf{X}}$ representa o vetor de médias amostrais como estatística aleatória, enquanto $\bar{\mathbf{x}}$ representa seu valor observado;
- $\mathbf{T}$ representa a matriz total de somas de quadrados e produtos cruzados (SQPC) como estatística aleatória, e $\mathbf{T}$ sua realização observada;

- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória, e $\mathbf{S}$ seu valor observado;
- $\mathbf{R}$ representa a matriz de correlações amostral como estatística aleatória, e $\mathbf{R}$ seu valor observado;
- T_{jk} , S_{jk} e R_{jk} representam elementos das respectivas matrizes aleatórias, enquanto t_{jk} , s_{jk} e r_{jk} representam seus valores observados;
- $\mathbf{G} = G(\mathcal{X})$ será utilizada como notação genérica para uma estatística, evitando conflito com o símbolo $\mathbf{T}$ reservado à matriz SQPC;
- $\hat{\theta}$ representa um estimador de um parâmetro θ , e $\hat{\theta}_{\text{obs}}$ o valor assumido pelo estimador após a observação da amostra.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordem, o vetor de médias e a matriz de covariâncias definidos na Equação 8.1 e Definição 8.2 satisfazem

$$E(\mathbf{X}) = \mu \in \mathbb{R}^p$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma \in \mathbb{R}^{p \times p}.$$

Os parâmetros são características fixas da distribuição populacional. A aleatoriedade introduzida pelo processo de amostragem está nos vetores que compõem a amostra e, consequentemente, nas estatísticas definidas a partir deles.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e identicamente distribuídos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A notação

$$\stackrel{\text{iid}}{\sim}$$

indica que os vetores aleatórios são independentes e identicamente distribuídos segundo a mesma distribuição.

A condição de distribuição idêntica estabelece que todas as unidades são regidas pela mesma distribuição populacional. A independência estabelece que a realização de uma unidade não altera a distribuição das demais unidades.

Quando a distribuição populacional possui densidade em relação a uma medida comum, a independência implica

$$f_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_\theta(\mathbf{x}_i). \quad (10.2)$$

A independência também implica a fatoração da função de distribuição conjunta da amostra:

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.3)$$

Essas fatorações dizem respeito à independência **entre unidades amostrais**. A dependência entre as componentes de um mesmo vetor continua representada pela distribuição multivariada F_θ .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j na unidade i .

A independência entre

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre

$$X_{i1}, \dots, X_{ip}.$$

As componentes de uma mesma unidade podem apresentar covariâncias e outras formas de dependência.

Quando os segundos momentos existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_\ell) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No modelo normal multivariado definido na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A definição do vetor de médias amostrais, da matriz SQPC, da matriz de covariâncias amostral e da matriz de correlações amostral não exige normalidade. Neste capítulo, a hipótese normal será utilizada especificamente na obtenção dos estimadores de máxima verossimilhança de μ e Σ . As distribuições amostrais exatas e os resultados inferenciais associados serão desenvolvidos no Capítulo 12.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra, uma realização de $\mathcal{X}$ é denotada por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.6)$$

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é a matriz aleatória da amostra;
- $\mathbf{X}$ é a matriz de dados observada;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;
- $\mathbf{x}_i$ é sua realização;
- X_{ij} é uma variável aleatória;
- x_{ij} é o valor observado correspondente.

Se o suporte de $\mathbf{X}$ é

$$\mathcal{S}_{\mathbf{X}} \subseteq \mathbb{R}^p,$$

o espaço das possíveis amostras é

$$\mathcal{S}_{\mathbf{X}}^n.$$

No caso em que

$$\mathcal{S}_{\mathbf{X}} = \mathbb{R}^p,$$

esse espaço pode ser identificado com

$$(\mathbb{R}^p)^n$$

ou, equivalentemente, com o conjunto das matrizes reais $n \times p$.

Uma estatística associa a cada possível realização da amostra uma quantidade escalar, vetorial ou matricial. Antes da observação da amostra, ela constitui um objeto aleatório; após a observação, obtém-se seu valor calculado a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

Neste capítulo, as principais quantidades populacionais de interesse são o vetor de médias μ , definido na Equação 8.1, a matriz de covariâncias Σ , definida na Definição 8.2, e a matriz de correlações $\mathcal{R}$, definida na Definição 8.5.

A matriz $\mathcal{R}$ é determinada por Σ e, portanto, não constitui um parâmetro adicional quando a matriz de covariâncias já integra a parametrização do modelo.

No modelo normal multivariado não singular definido na Definição 9.1, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Considere a matriz aleatória da amostra

$$\mathcal{X} \in \mathbb{R}^{n \times p}.$$

Uma estatística é uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{T},$$

cujas regras de cálculo não contêm parâmetros populacionais desconhecidos, em que $\mathcal{T}$ é o espaço em que o resultado assume valores.

A estatística correspondente é

$$\mathbf{G} = G(\mathcal{X}). \quad (10.7)$$

O espaço $\mathcal{T}$ pode ser escalar, vetorial ou matricial, de acordo com a estatística considerada.

Embora a expressão da estatística não contenha parâmetros desconhecidos, sua distribuição amostral pode depender dos parâmetros da distribuição populacional.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i. \quad (10.8)$$

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de uma estatística é denominada **distribuição amostral**. Ela descreve como a estatística varia entre as possíveis realizações da amostra aleatória de tamanho n .

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_\theta$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{G} = G(\mathcal{X})$$

descreve a variabilidade da estatística entre as possíveis realizações da amostra.

A distribuição populacional e a distribuição amostral correspondem, portanto, a objetos probabilísticos distintos. O Capítulo 12 estudará distribuições amostrais específicas das estatísticas introduzidas neste capítulo.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Considere um parâmetro

$$\theta \in \Theta \subseteq \mathcal{A},$$

em que $\mathcal{A}$ é o espaço em que o parâmetro é representado.

Um estimador de θ é uma estatística definida por uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{A},$$

de modo que

$$\hat{\theta} = G(\mathcal{X}). \quad (10.10)$$

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X}). \quad (10.11)$$

Todo estimador é uma estatística, mas nem toda estatística precisa ser utilizada para estimar um parâmetro. A função atribuída à estatística depende do objetivo da análise.

Assim,

$$\bar{\mathbf{X}}$$

é um estimador de μ , enquanto

$$\bar{\mathbf{x}}$$

é a estimativa obtida para uma amostra específica.

Mais adiante, a matriz de covariâncias amostral

$$\mathbf{S}$$

será definida como estimador de Σ , enquanto

$$\mathbf{s}$$

representará sua realização observada.

O erro de estimação é

$$\hat{\theta} - \theta. \quad (10.12)$$

Como o estimador é uma função da amostra aleatória, o erro de estimação também é aleatório. Sua distribuição permite avaliar propriedades do procedimento de estimação.

Um mesmo parâmetro pode possuir diferentes estimadores. Para Σ , por exemplo, serão estudados o estimador não viesado

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e, sob o modelo normal multivariado, o estimador de máxima verossimilhança

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T},$$

ambos construídos a partir da matriz SQPC $\mathbf{T}$ definida na Definição 8.10.

A estimação pontual utiliza uma estimativa única para representar o parâmetro. A estimação por regiões utiliza conjuntos construídos para quantificar a incerteza associada ao processo amostral. Neste capítulo será desenvolvida a estimação pontual. As regiões de confiança serão tratadas no Capítulo 12.

A comparação entre estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência e equivariância serão examinados a seguir. Questões de sensibilidade e robustez serão retomadas posteriormente como aprofundamento.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem estimar o mesmo parâmetro e apresentar comportamentos distintos ao longo das possíveis amostras.

Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = G(\mathcal{X}) \in \mathbb{R}^r.$$

A avaliação de $\hat{\theta}$ depende de sua distribuição amostral e do critério utilizado para comparar procedimentos. Viés, variabilidade, erro quadrático médio e comparações de eficiência podem ser considerados para um tamanho amostral fixo. A consistência e a eficiência assintótica tratam do comportamento de sequências de estimadores quando n aumenta. A suficiência examina a informação preservada pela redução da amostra, enquanto a equivariância descreve a coerência do procedimento sob transformações (Casella; Berger, 2002). Questões de sensibilidade e robustez serão tratadas posteriormente como aprofundamento.

10.2.1 Viés e variabilidade

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés (*Bias* em inglês) de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é

$$E(\hat{\theta}_j) - \theta_j.$$

A ausência de viés descreve o comportamento médio do procedimento sobre as possíveis amostras. Ela não garante que uma estimativa particular esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\hat{\Theta} \in \mathbb{R}^{a \times b},$$

define-se, elemento a elemento,

$$\text{Bias}(\hat{\Theta}) = E(\hat{\Theta}) - \Theta. \quad (10.14)$$

A variabilidade de um estimador vetorial é descrita por

$$\text{Cov}(\hat{\theta}) = E \left[\{ \hat{\theta} - E(\hat{\theta}) \} \{ \hat{\theta} - E(\hat{\theta}) \}^{\top} \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias de seus componentes e os elementos fora da diagonal são as covariâncias entre eles.

Para qualquer $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^{\top} \hat{\theta}) = \mathbf{a}^{\top} \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr} [\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

Essa medida-resumo depende da escala e da parametrização e não substitui a matriz de covariâncias quando a dependência entre os componentes do estimador é relevante.

Para um estimador matricial, uma representação da variabilidade é

$$\text{Cov} [\text{vec}(\hat{\Theta})].$$

O operador vec , definido na Definição 7.9, transforma a matriz estimada em um vetor e permite representar conjuntamente a variabilidade de todos os seus elementos.

Viés e variabilidade descrevem aspectos diferentes do desempenho de um estimador. Um procedimento pode apresentar pequeno viés e grande variabilidade, ou maior viés e menor variabilidade. Para comparar conjuntamente essas duas fontes de erro, é necessário especificar como os desvios entre estimador e parâmetro serão avaliados.

10.2.2 Erro quadrático médio e funções de perda

A comparação entre estimadores requer especificar como diferentes erros são avaliados. Essa escolha é formalizada por uma **função de perda**. Para uma perda L , o **risco** do estimador é seu valor esperado sob o parâmetro θ :

$$R(\theta, \hat{\theta}) = E_{\theta} [L(\hat{\theta}, \theta)].$$

Assim, diferentes funções de perda podem conduzir a diferentes critérios de comparação entre estimadores (Casella; Berger, 2002).

Para um estimador vetorial, considere a perda quadrática euclidiana

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.16)$$

Essa escolha atribui o mesmo peso às coordenadas na parametrização utilizada. Outros problemas podem exigir ponderações ou perdas diferentes.

Definição 10.6 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = E \left[\|\hat{\theta} - \theta\|^2 \right]. \quad (10.17)$$

Proposição 10.1 (Decomposição do erro quadrático médio). *Se $\hat{\theta}$ possui segundos momentos finitos, então*

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.18)$$

Comprovação. Escreva

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + \text{Bias}(\hat{\theta}).$$

O primeiro termo possui média zero. Ao expandir o quadrado da norma e tomar esperança, o termo cruzado desaparece. Além disso,

$$E \left[\|\hat{\theta} - E(\hat{\theta})\|^2 \right] = \text{tr} [\text{Cov}(\hat{\theta})].$$

Substituindo essas relações, obtém-se Equação 10.18. □

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})].$$

A decomposição na Equação 10.18 também pode ser vista como uma aplicação de Equação 8.38, tomando a matriz identidade e considerando $\hat{\theta}$ como vetor aleatório com média $E(\hat{\theta})$.

A ausência de viés não implica EQM mínimo. Um estimador viesado pode apresentar menor risco quadrático se a redução de variabilidade compensar o viés. Essa ideia será retomada na seção de regularização.

Para parâmetros matriciais, uma escolha correspondente é a perda baseada na norma de Frobenius definida na Definição 6.7:

$$L_F(\widehat{\Theta}, \Theta) = \|\widehat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\widehat{\Theta}) = E \left[\|\widehat{\Theta} - \Theta\|_F^2 \right]. \quad (10.19)$$

Equivalentemente,

$$\begin{aligned} \text{EQM}_F(\widehat{\Theta}) &= \text{tr} \left\{ \text{Cov} [\text{vec}(\widehat{\Theta})] \right\} \\ &\quad + \|\text{Bias}(\widehat{\Theta})\|_F^2. \end{aligned} \quad (10.20)$$

A norma de Frobenius corresponde a uma escolha específica de perda. Em problemas de estimação de matrizes de covariâncias, outros critérios podem atribuir pesos diferentes a autovalores, direções ou erros de inversão.

10.2.3 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta (Vaart, 1998).

Definição 10.7 (Consistência). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma sequência de estimadores

$$\widehat{\theta}_n \in \mathbb{R}^r,$$

com r fixo quando $n \rightarrow \infty$.

A sequência $\widehat{\theta}_n$ é consistente para θ quando

$$\widehat{\theta}_n \xrightarrow{P} \theta \quad (10.21)$$

quando

$$n \longrightarrow \infty.$$

A notação

$$\xrightarrow{P}$$

indica **convergência em probabilidade**. Isso significa que, para todo $\varepsilon > 0$,

$$P(\|\hat{\theta}_n - \theta\| > \varepsilon) \rightarrow 0. \quad (10.22)$$

Na formulação clássica deste capítulo, a dimensão do parâmetro é mantida fixa enquanto n aumenta. Quando a dimensão também varia com n , é necessário declarar o regime dimensional e a métrica utilizada para avaliar o erro. Essa distinção será retomada na seção de aprofundamento sobre alta dimensão.

Não viesamento e consistência descrevem propriedades diferentes. O não viesamento compara a esperança do estimador com o parâmetro para um tamanho amostral dado, enquanto a consistência descreve o que acontece com o erro de estimação quando n aumenta. Uma propriedade não deve ser interpretada como sinônimo da outra.

10.2.4 Eficiência

Para estimadores vetoriais não viesados, uma comparação natural considera suas matrizes de covariâncias. Considere dois estimadores

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2,$$

ambos não viesados para θ .

Diz-se que $\hat{\theta}_1$ é uniformemente pelo menos tão eficiente quanto $\hat{\theta}_2$, segundo a ordem de Löwner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.23)$$

Equivalentemente,

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0}.$$

Consequentemente, para todo $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2).$$

No caso vetorial, não existe necessariamente um estimador que seja mais preciso em todos os aspectos. Cada vetor $\mathbf{a} \in \mathbb{R}^r$ define uma combinação linear $\mathbf{a}^\top \hat{\theta}$ e, portanto, uma direção

na qual a variabilidade dos estimadores pode ser comparada. Um estimador pode apresentar menor variabilidade em determinadas direções e maior variabilidade em outras.

A ordem de Löwner declara $\hat{\theta}_1$ pelo menos tão eficiente quanto $\hat{\theta}_2$ somente quando a desigualdade anterior vale para **todas** as direções **a**. Por isso, trata-se de uma ordem parcial: podem existir duas matrizes de covariâncias para as quais nenhum dos estimadores apresenta menor variabilidade em todas as direções.

Quando duas matrizes de covariâncias não são comparáveis pela ordem de Löwner, pode-se adotar um critério escalar que resuma algum aspecto de sua variabilidade. Um exemplo é

$$\text{tr} [\text{Cov}(\hat{\theta})],$$

que soma as variâncias dos componentes do estimador. Essa escolha estabelece um critério particular de comparação; outra função de perda pode produzir uma ordenação diferente.

Para estimadores viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. É necessário considerar um risco que incorpore viés e variabilidade.

A eficiência assintótica compara as matrizes que aparecem nas distribuições-limite de sequências de estimadores. Sob condições de regularidade, estimadores de máxima verossimilhança podem atingir limites associados à informação de Fisher definida na Definição 7.18. Os resultados assintóticos correspondentes não serão desenvolvidos neste capítulo e serão retomados no contexto inferencial do Capítulo 12.

10.2.5 Suficiência

Uma estatística suficiente resume a amostra sem perder informação sobre o parâmetro no modelo considerado. Depois de conhecida essa estatística, a distribuição condicional dos dados restantes não depende do parâmetro (Casella; Berger, 2002).

Definição 10.8 (Estatística suficiente). Considere uma amostra aleatória

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

cujas distribuições pertence a uma família indexada por

$$\theta \in \Theta,$$

e uma estatística definida por

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{G},$$

de modo que

$$\mathbf{G} = G(\mathcal{X}).$$

A estatística $\mathbf{G}$ é **suficiente para** θ quando a distribuição condicional de $\mathcal{X}$ dado $\mathbf{G}$ é a mesma para todos os valores de $\theta \in \Theta$ para os quais essa distribuição condicional está definida.

A função G reduz a amostra à estatística $\mathbf{G}$. A suficiência estabelece que, após conhecida essa estatística, a parte restante da variabilidade da amostra não contém dependência adicional em relação a θ .

A suficiência pode ser entendida como uma redução dos dados sem perda de informação sobre θ no contexto do modelo considerado. Isso não significa que seja possível reconstruir a amostra original a partir de $\mathbf{G}$, mas que a parte da amostra não representada por $\mathbf{G}$ deixa de depender do parâmetro.

A definição de suficiência é formulada em termos de uma distribuição condicional, que nem sempre é a forma mais conveniente para verificar a propriedade diretamente. Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério equivalente baseado na forma da densidade ou da função de probabilidade conjunta.

Teorema 10.1 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família de distribuições indexada por*

$$\theta \in \Theta$$

e dominada por uma medida comum ν , com densidade conjunta

$$f_\theta : \mathcal{X} \longrightarrow [0, \infty)$$

em relação a ν .

Considere também uma estatística definida por

$$G : \mathcal{X} \longrightarrow \mathcal{G}.$$

A estatística $G(\mathcal{X})$ é suficiente para θ se, e somente se, existem funções não negativas

$$q_\theta : \mathcal{G} \longrightarrow [0, \infty), \quad \theta \in \Theta,$$

e

$$r : \mathcal{X} \longrightarrow [0, \infty),$$

com r independente de θ , tais que

$$f_{\theta}(\mathbf{x}) = q_{\theta}[G(\mathbf{x})] r(\mathbf{x}) \quad (10.24)$$

para ν -quase todo $\mathbf{x} \in \mathcal{X}$ e para todo $\theta \in \Theta$.

(Casella; Berger, 2002)

A fatoração separa a densidade conjunta em duas partes. A primeira,

$$q_{\theta}[G(\mathbf{x})],$$

contém toda a dependência em relação a θ e utiliza os dados somente por meio de $G(\mathbf{x})$. A segunda,

$$r(\mathbf{x}),$$

pode depender da amostra completa, mas não depende do parâmetro. Por isso, para estudar θ , a informação contida nos dados entra na verossimilhança por meio da estatística suficiente.

No modelo normal multivariado definido na Definição 9.1, o vetor de médias amostrais e a matriz SQPC formam conjuntamente uma estatística suficiente para μ e Σ (Anderson, 2003).

Proposição 10.2 (Suficiência no modelo normal multivariado). *No modelo normal multivariado, a estatística*

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para o parâmetro

$$(\mu, \Sigma),$$

quando

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Nesse resultado,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias amostrais e

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top \quad (10.25)$$

é a matriz SQPC.

Comprovação. Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}.$$

A identidade de decomposição em torno da média fornece

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top, \end{aligned}$$

em que $\mathbf{T}$ é a matriz SQPC observada definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, toda a dependência da densidade conjunta em relação a μ e Σ ocorre por meio de

$$(\bar{\mathbf{x}}, \mathbf{T}).$$

O resultado segue de Teorema 10.1. □

A suficiência não implica, por si só, ausência de viés, consistência ou eficiência. Ela descreve a quantidade de informação sobre o parâmetro preservada pela estatística, e não a qualidade de um estimador construído a partir dela. Sob o modelo considerado, reduzir a amostra a uma estatística suficiente não elimina informação sobre θ .

10.2.6 Equivariância

Uma transformação dos dados pode induzir uma transformação correspondente no parâmetro. Um procedimento equivariante respeita essa relação.

Definição 10.9 (Equivariância de um estimador). Considere um espaço amostral $\mathcal{X}$, um espaço amostral transformado $\mathcal{Y}$ e espaços paramétricos Θ e Ψ .

Sejam

$$h : \mathcal{X} \longrightarrow \mathcal{Y}$$

uma transformação dos dados e

$$g : \Theta \longrightarrow \Psi$$

a transformação correspondente do parâmetro.

Considere uma regra de estimação

$$G_{\Theta} : \mathcal{X} \longrightarrow \Theta$$

para $\theta \in \Theta$ e a regra correspondente

$$G_{\Psi} : \mathcal{Y} \longrightarrow \Psi$$

para

$$\psi = g(\theta).$$

As regras de estimação são **equivariantes** em relação a h e g quando

$$G_{\Psi} [h(\mathcal{X})] = g[G_{\Theta}(\mathcal{X})]. \quad (10.26)$$

A função h atua sobre os dados, enquanto g atua sobre o parâmetro. Por isso, as duas funções não precisam possuir a mesma forma.

Considere, por exemplo, a transformação afim dos dados

$$h : \mathbf{X}_i \mapsto \mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

Nesse caso, h é a transformação aplicada a cada vetor observado da amostra.

Para o vetor de médias, o parâmetro populacional é

$$\theta = \mu,$$

e a transformação correspondente no espaço paramétrico é

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Portanto,

$$\mu_Y = g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Para a matriz de covariâncias, o parâmetro populacional é

$$\theta = \Sigma,$$

e, por Proposição 8.6, a transformação correspondente é

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Portanto,

$$\Sigma_Y = g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Esse exemplo mostra que uma mesma transformação h aplicada aos dados pode induzir transformações diferentes no espaço paramétrico. Para a média,

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d},$$

enquanto, para a covariância,

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Assim, a forma de g depende do parâmetro considerado, mesmo quando a transformação h dos dados permanece a mesma.

Para estimar μ , a regra de estimação é

$$G_1(\mathcal{X}) = \bar{\mathbf{X}}.$$

Aplicando a mesma regra aos dados transformados,

$$G_1[h(\mathcal{X})] = \bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d} = g_1[G_1(\mathcal{X})].$$

Portanto, o vetor de médias amostrais é equivariante em relação a essa transformação afim.

Para estimar Σ , a regra de estimação é

$$G_2(\mathcal{X}) = \mathbf{S}_X.$$

Para os dados transformados,

$$G_2[h(\mathcal{X})] = \mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top = g_2[G_2(\mathcal{X})].$$

Assim, a matriz de covariâncias amostral também é equivariante em relação à transformação considerada.

A equivariância descreve como um estimador responde a uma transformação dos **dados**: transformar os dados e depois estimar deve produzir o mesmo resultado que estimar primeiro e aplicar a transformação correspondente ao parâmetro.

Essa propriedade deve ser distinguida da invariância da máxima verossimilhança. Nesse segundo caso, parte-se de um estimador de máxima verossimilhança já obtido para θ e utiliza-se uma função desse estimador para estimar uma função do parâmetro.

As propriedades desta seção respondem a perguntas diferentes sobre um procedimento de estimação:

- **viés** compara o valor médio do estimador com o parâmetro;

- **variabilidade** descreve quanto o estimador muda entre amostras;
- **erro quadrático médio** combina viés e variabilidade segundo uma função de perda;
- **consistência** descreve o comportamento do estimador quando o tamanho amostral aumenta;
- **eficiência** compara a variabilidade de procedimentos concorrentes;
- **suficiência** examina quanta informação sobre o parâmetro é preservada por uma estatística;
- **equivariância** examina a coerência do estimador diante de transformações dos dados.

Essas propriedades não estabelecem uma ordenação universal entre estimadores. Um procedimento pode apresentar vantagens segundo um critério e desvantagens segundo outro. A escolha depende do parâmetro de interesse, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise.

Os métodos dos momentos e da máxima verossimilhança fornecem dois princípios gerais para construir os estimadores estudados a seguir.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos relaciona momentos populacionais a seus correspondentes amostrais. A máxima verossimilhança escolhe os valores dos parâmetros que tornam os dados observados mais compatíveis com o modelo especificado (Casella; Berger, 2002).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. Além disso, o princípio utilizado para construir um estimador deve ser distinguido das propriedades estudadas na seção anterior. Em particular, obter um estimador pelo método dos momentos ou pela máxima verossimilhança não garante, por si só, ausência de viés, consistência, eficiência, suficiência, equivariância ou robustez.

Algumas propriedades podem ser demonstradas sob condições adicionais sobre o modelo e o processo amostral. Outras decorrem da própria estrutura de um método. Essas distinções serão indicadas ao apresentar cada procedimento.

10.3.1 Método dos momentos

Definição 10.10 (Estimador pelo método dos momentos). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma função

$$\mathbf{q} : \mathbb{R}^p \longrightarrow \mathbb{R}^r$$

tal que

$$E_{\theta} [\|\mathbf{q}(\mathbf{X})\|] < \infty$$

para os valores de θ considerados.

Defina

$$\mathbf{m} : \Theta \longrightarrow \mathbb{R}^r$$

por

$$\mathbf{m}(\theta) = E_{\theta} [\mathbf{q}(\mathbf{X})]. \quad (10.27)$$

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

defina

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.28)$$

Um **estimador pelo método dos momentos** de θ é qualquer solução

$$\hat{\theta}_{\text{MM}} \in \Theta$$

do sistema

$$\mathbf{m}(\hat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.29)$$

A existência e a unicidade do estimador dependem dos momentos escolhidos e da forma da função $\mathbf{m}$. Assim, o método substitui os momentos populacionais, que dependem do parâmetro desconhecido, pelos correspondentes momentos calculados a partir da amostra e resolve as equações resultantes em relação a θ .

O sistema pode não possuir solução, possuir mais de uma solução ou produzir valores que não pertençam a Θ .

Propriedades dos estimadores de momentos

A propriedade que define o método é a correspondência entre os momentos populacionais e seus análogos amostrais expressa na Equação 10.29. Essa construção, isoladamente, não garante que o estimador obtido seja não viesado, eficiente, suficiente, equivariante ou robusto.

A consistência também não decorre apenas do método. Sob condições como existência dos momentos utilizados, convergência dos momentos amostrais para seus correspondentes populacionais, identificação do parâmetro por esses momentos e continuidade adequada da solução, estimadores de momentos podem ser consistentes.

Portanto, as propriedades apresentadas na seção anterior devem ser verificadas para o estimador e o modelo considerados.

Para o vetor de médias populacional,

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{x}},$$

de modo que

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{x}}. \quad (10.30)$$

Para a matriz de covariâncias, considere o segundo momento não central

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

Pela identidade Equação 8.3,

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top.$$

Substituindo os momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned} \hat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \end{aligned} \quad (10.31)$$

A matriz no numerador é a versão aleatória da matriz total de somas de quadrados e produtos cruzados (SQPC) definida, para dados observados, na Definição 8.10. Será denotada por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.32)$$

Portanto,

$$\hat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}. \quad (10.33)$$

Essa construção utiliza apenas momentos de primeira e segunda ordem e não exige a hipótese de normalidade multivariada. O divisor n surge aqui diretamente do princípio do método dos momentos; posteriormente, ele também será obtido pela máxima verossimilhança sob o modelo normal.

A matriz $\mathbf{T}$ será desenvolvida em detalhes na seção dedicada à SQPC. Para cada realização da amostra, ela produz a matriz $\mathbf{T}$ definida na Definição 8.10.

Restrições do espaço paramétrico

Resolver as equações de momentos não garante que a solução obtida satisfaça todas as restrições impostas ao parâmetro. Em modelos com condições de positividade, ordem, posto ou outras restrições estruturais, é necessário verificar se a solução pertence efetivamente ao espaço paramétrico Θ .

10.3.2 Verossimilhança e máxima verossimilhança

Definição 10.11 (Função de verossimilhança). Considere um espaço paramétrico Θ e uma família de distribuições indexada por

$$\theta \in \Theta,$$

na qual cada observação possui densidade ou função de probabilidade

$$f(\mathbf{x}; \theta)$$

em um espaço amostral $\mathcal{X}$.

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

e uma realização observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X},$$

a função de verossimilhança, para os dados observados fixados, é a função

$$L(\cdot; \mathbf{x}_1, \dots, \mathbf{x}_n) : \Theta \longrightarrow [0, \infty)$$

definida por

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.34)$$

Na verossimilhança, os dados observados são mantidos fixos e θ varia em Θ . Portanto, L não é, em geral, uma distribuição de probabilidade sobre θ .

A log-verossimilhança é

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \log L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n),$$

e, sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.35)$$

Como o logaritmo é estritamente crescente, a verossimilhança e a log-verossimilhança possuem os mesmos pontos de máximo.

Definição 10.12 (Estimador de máxima verossimilhança). Considere a função de verossimilhança definida na Definição 10.11 e suponha que

$$\arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}) \neq \emptyset.$$

Um **estimador de máxima verossimilhança** de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

que seleciona um elemento desse conjunto:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.36)$$

Se o conjunto de máximos contiver mais de um elemento, qualquer elemento selecionado segundo a regra de estimação adotada é um estimador de máxima verossimilhança.

Como o logaritmo é estritamente crescente, a mesma regra pode ser obtida maximizando a log-verossimilhança:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} \ell(\theta; \mathcal{X}).$$

Após a observação da amostra, a estimativa correspondente satisfaz

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A notação $\arg \max$ representa o conjunto dos valores do parâmetro em que o máximo é atingido. Assim, a definição admite a possibilidade de mais de um máximo. A existência e a unicidade do estimador precisam ser verificadas no modelo e no espaço paramétrico considerados.

Propriedades dos estimadores de máxima verossimilhança

A maximização da verossimilhança não garante, em amostras finitas, que o estimador seja não viesado ou apresente erro quadrático médio mínimo. Também não garante, por si só, suficiência, equivariância em relação a transformações dos dados ou robustez.

Sob condições de regularidade e identificabilidade, estimadores de máxima verossimilhança podem ser consistentes, assintoticamente normais e assintoticamente eficientes. Esses resultados dependem das condições do modelo e não são consequências incondicionais do procedimento de maximização.

Uma propriedade estrutural específica da máxima verossimilhança é a **invariância em relação a funções do parâmetro**: quando o estimador de máxima verossimilhança existe, uma função apropriada desse estimador fornece o estimador de máxima verossimilhança da função correspondente do parâmetro. Essa propriedade será formalizada adiante.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

Considere uma amostra do modelo normal multivariado definido na Definição 9.1:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Pela densidade normal multivariada na Equação 9.8 e pela independência das unidades amostrais, para uma amostra observada a verossimilhança é

$$L(\mu, \Sigma) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \quad (10.37)$$

A log-verossimilhança é

$$\begin{aligned} \ell(\mu, \Sigma) = & -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ & - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu). \end{aligned} \quad (10.38)$$

Considere a matriz SQPC observada $\mathbf{T}$, definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.39)$$

Separando o afastamento em relação a μ no desvio em relação à média amostral e no deslocamento da própria média, obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top. \end{aligned} \quad (10.40)$$

A forma quadrática presente na log-verossimilhança pode ser reescrita utilizando o traço. Pela relação entre traço e produto externo em Proposição 2.7 e pela propriedade cíclica em Exemplo 2.12, para um vetor $\mathbf{z}$ e uma matriz compatível $\mathbf{A}$,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} = \text{tr}(\mathbf{A} \mathbf{z} \mathbf{z}^\top).$$

Consequentemente,

$$\begin{aligned}
& \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \\
&= \text{tr} \left[\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] \\
&= \text{tr} (\Sigma^{-1} \mathbf{T}) + n (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu),
\end{aligned}$$

em que a última igualdade utiliza Equação 10.40. Assim, a log-verossimilhança pode ser escrita como

$$\begin{aligned}
\ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\
&\quad - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}) \\
&\quad - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu).
\end{aligned} \tag{10.41}$$

Para Σ fixa, o último termo é não positivo na log-verossimilhança e atinge seu maior valor quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, obtém-se a log-verossimilhança perfilada

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{T}}{n} \right) \right] \right\}, \tag{10.42}$$

em que C não depende de Σ .

Desconsiderando a constante C , maximizar Equação 10.42 equivale a minimizar

$$\frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Essa expressão possui exatamente a forma do critério estudado na Proposição 7.14, com

$$\mathbf{G} = \mathbf{T}.$$

Assim, quando $\mathbf{T} \succ \mathbf{0}$, aquele resultado pode ser aplicado diretamente para obter o minimizador.

Proposição 10.3 (Estimadores de máxima verossimilhança no modelo normal). *No evento amostral em que o máximo da verossimilhança existe, os estimadores no modelo normal multivariado são*

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}} \quad (10.43)$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}. \quad (10.44)$$

O resultado considera

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, o máximo existe e é único quando

$$\text{posto}(\mathbf{T}) = p,$$

e, nesse caso,

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}}$$

e

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

Comprovação. A maximização em relação a μ decorre de Equação 10.41. Como

$$\Sigma^{-1} \succ \mathbf{0},$$

tem-se

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente em

$$\mu = \bar{\mathbf{x}}.$$

Para a maximização em relação a Σ , a log-verossimilhança perfilada na Equação 10.42 mostra que é equivalente minimizar

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Sob a hipótese

$$\text{posto}(\mathbf{T}) = p,$$

tem-se

$$\mathbf{T} \succ \mathbf{0}.$$

Aplicando Proposição 7.14 com $\mathbf{G} = \mathbf{T}$, o minimizador único é

$$\Sigma = \frac{\mathbf{T}}{n}.$$

Logo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

□

Pelo limite de posto da matriz SQPC estabelecido na Equação 8.60,

$$\text{posto}(\mathbf{T}) \leq \min(p, n-1).$$

Consequentemente, uma condição necessária para posto completo é

$$n \geq p+1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois as colunas da matriz centralizada ainda podem ser linearmente dependentes. Sob uma distribuição normal multivariada não singular e

$$n \geq p+1,$$

a condição

$$\text{posto}(\mathbf{T}) = p$$

ocorre quase certamente.

Se $\mathbf{T}$ é singular, a verossimilhança não possui máximo no espaço

$$\{\Sigma : \Sigma \succ \mathbf{0}\}.$$

De fato, pelo Teorema 5.4, escreva

$$\mathbf{T} = \mathbf{Q} \text{diag}(t_1, \dots, t_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$t_j > 0, \quad j = 1, \dots, r, \quad r < p.$$

Para $\varepsilon > 0$, considere

$$\Sigma_\varepsilon = \mathbf{Q} \text{diag}\left(\frac{t_1}{n}, \dots, \frac{t_r}{n}, \varepsilon, \dots, \varepsilon\right) \mathbf{Q}^\top.$$

Então,

$$\text{tr}(\Sigma_\varepsilon^{-1} \mathbf{T}) = nr,$$

enquanto

$$\log \det(\Sigma_\varepsilon) \longrightarrow -\infty$$

quando

$$\varepsilon \longrightarrow 0.$$

Consequentemente, a log-verossimilhança cresce sem limite ao longo dessa sequência, e o máximo não é atingido no espaço das matrizes positivas definidas.

A matriz

$$\frac{\mathbf{T}}{n}$$

continua sendo bem definida e positiva semidefinida e coincide com o estimador obtido pelo método dos momentos. Quando essa matriz é singular, ela não constitui o estimador de máxima verossimilhança no modelo cujo espaço paramétrico exige

$$\Sigma \succ \mathbf{0}.$$

Quando o máximo existe, o estimador de Σ utiliza o divisor n . Mais adiante será mostrado que esse estimador é viesado para Σ e que o divisor $n - 1$ produz o estimador não viesado usual.

O modelo normal mostrou um caso em que método dos momentos e máxima verossimilhança conduzem às mesmas expressões para μ e Σ . Essa coincidência, porém, é específica do modelo considerado. Retornando à comparação geral entre os dois princípios de construção, suas relações com as propriedades estudadas anteriormente podem ser resumidas da seguinte forma:

Tabela 10.1: Relação entre os métodos de estimação e as propriedades estudadas na seção anterior.

Propriedade	Método dos momentos	Máxima verossimilhança
Não viesamento em amostras finitas	Não é garantido pelo método	Não é garantido pelo método
Consistência	Pode ser obtida sob condições de convergência, identificação e continuidade	Pode ser obtida sob condições de regularidade e identificação
Eficiência em amostras finitas	Não é garantida	Não é garantida
Eficiência assintótica	Não é uma propriedade geral do método	Pode ocorrer sob condições de regularidade
Suficiência	Não é garantida pelo método	Não é garantida apenas pela maximização
Equivariância sob transformações dos dados	Depende do estimador e da transformação	Depende do estimador e da transformação
Invariância sob funções do parâmetro	Não é uma propriedade geral do método	É uma propriedade estrutural da máxima verossimilhança, quando o estimador existe
Robustez	Não é garantida	Não é garantida

A Tabela 10.1 distingue propriedades que decorrem da própria construção do método daquelas que exigem hipóteses adicionais sobre o modelo, a amostra ou o estimador específico.

10.3.3 Invariância da máxima verossimilhança

A máxima verossimilhança possui uma propriedade que permite estimar funções do parâmetro sem realizar uma nova maximização desde o início (Casella; Berger, 2002).

Considere uma função

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e defina

$$\psi = g(\theta).$$

Para cada

$$\psi \in \Psi,$$

defina a verossimilhança perfilada por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.45)$$

A função g não precisa ser injetiva, contínua ou monótona para a propriedade de invariância apresentada a seguir.

Proposição 10.4 (Invariância da máxima verossimilhança). *Considere*

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e suponha que

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta).$$

Então

$$g(\hat{\theta}_{\text{MV}}) \in \arg \max_{\psi \in \Psi} L_g(\psi).$$

Portanto,

$$\hat{\psi}_{\text{MV}} = g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de

$$\psi = g(\theta).$$

Comprovação. Defina

$$\widehat{\psi} = g\left(\widehat{\theta}_{\text{MV}}\right).$$

Como a fibra

$$\{\theta \in \Theta : g(\theta) = \widehat{\psi}\}$$

contém $\widehat{\theta}_{\text{MV}}$, tem-se

$$L_g\left(\widehat{\psi}\right) = L\left(\widehat{\theta}_{\text{MV}}\right).$$

Nenhum outro valor de ψ pode apresentar verossimilhança perfilada superior, pois isso implicaria a existência de algum θ cuja verossimilhança superasse o máximo global. Portanto,

$$\widehat{\psi} = g\left(\widehat{\theta}_{\text{MV}}\right)$$

é um estimador de máxima verossimilhança de ψ . □

A invariância da máxima verossimilhança deve ser distinguida da equivariância.

- **Equivariância** relaciona uma transformação dos dados à transformação correspondente do estimador.
- **Invariância da máxima verossimilhança** aplica uma função do parâmetro ao estimador de máxima verossimilhança já obtido.

Considere a matriz de correlações populacional definida na Definição 8.5:

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Quando o estimador de máxima verossimilhança de Σ existe e possui diagonal positiva, a invariância fornece

$$\widehat{\mathcal{R}}_{\text{MV}} = \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2} \widehat{\Sigma}_{\text{MV}} \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2}. \quad (10.46)$$

Como correlações são preservadas por mudanças positivas de escala, conforme Equação 8.25, o fator comum que distingue as matrizes de covariâncias com divisores n e $n - 1$ se cancela na padronização. Assim, a matriz na Equação 10.46 coincide com a matriz de correlações calculada a partir da covariância amostral com divisor $n - 1$.

A propriedade pode ser aplicada também a funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma)$$

e, quando o estimador é positivo definido,

$$\Sigma^{-1}.$$

A invariância é uma propriedade de otimização. Ela não implica ausência de viés, consistência automática ou estabilidade numérica. Em particular, a inversão de uma matriz estimada mal condicionada pode amplificar pequenas perturbações.

Os dois métodos apresentados produzem, no modelo normal, o mesmo estimador para μ e a mesma matriz com divisor n para Σ . A seção seguinte examina primeiro o vetor de médias amostrais e suas propriedades.

10.4 Estimação do vetor de médias

O vetor de médias populacional μ , definido na Equação 8.1, descreve a localização da população em $\mathbb{R}^p$. A seção anterior mostrou que o método dos momentos e, sob o modelo normal multivariado, a máxima verossimilhança conduzem ao vetor de médias amostrais como estimador de μ . Nesta seção, esse estimador será estudado quanto às propriedades apresentadas anteriormente.

Considere a amostra aleatória multivariada definida na Equação 10.1 e suponha que

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n.$$

Os resultados sobre esperança, variabilidade, erro quadrático médio e consistência utilizam a independência entre as unidades amostrais e os momentos indicados acima. A normalidade multivariada será necessária apenas quando o vetor de médias amostrais for interpretado como estimador de máxima verossimilhança no modelo normal.

10.4.1 Vetor de médias amostrais

Retomando a Equação 10.8, o vetor de médias amostrais é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

com

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.47)$$

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n. \quad (10.48)$$

Após a observação dos dados,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.49)$$

Pelo método dos momentos, a Equação 10.30 fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}.$$

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança existe, a Equação 10.43 fornece

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}.$$

Portanto,

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}. \quad (10.50)$$

A mesma estatística é, portanto, obtida por dois princípios de construção diferentes. A partir deste ponto, o interesse recai sobre as propriedades de $\bar{\mathbf{X}}$ como estimador de μ . Essas propriedades não decorrem do fato de o estimador ter sido obtido pelo método dos momentos ou pela máxima verossimilhança; elas serão verificadas diretamente sob as hipóteses declaradas nesta seção.

Além de sua interpretação como estimativa de μ , o valor observado $\bar{\mathbf{x}}$ possui uma caracterização geométrica: ele é o centroide da nuvem de pontos e minimiza a soma dos quadrados das distâncias euclidianas das observações a um centro comum.

Proposição 10.5 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor $\bar{\mathbf{x}}$ é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.51)$$

Comprovação. Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Somando os quadrados das normas,

$$\begin{aligned} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\ &\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\ &\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \end{aligned}$$

Pela propriedade de centralização estabelecida na Equação 8.57,

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}.$$

Logo,

$$\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \quad (10.52)$$

A primeira parcela não depende de $\mathbf{m}$, e a segunda é não negativa e se anula somente em

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador. □

A identidade Equação 10.52 será reutilizada na construção da matriz SQPC e na decomposição da dispersão em torno de centros distintos.

10.4.2 Não viesamento, variabilidade e erro quadrático médio

Proposição 10.6 (Esperança e covariância do vetor de médias amostrais). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\bar{\mathbf{X}}) = \mu \quad (10.53)$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \quad (10.54)$$

Comprovação. Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right).$$

Como as unidades amostrais são independentes,

$$\text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right) = \sum_{i=1}^n \text{Cov}(\mathbf{X}_i) = n\Sigma.$$

Portanto,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

□

Consequentemente,

$$\text{Bias}(\bar{\mathbf{X}}) = \mathbf{0}.$$

O vetor de médias amostrais é, portanto, não viesado para μ .

Elemento a elemento,

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov}(\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

A matriz de covariâncias do erro de estimação é obtida multiplicando Σ pelo fator $1/n$. Assim, o aumento do tamanho amostral reduz a magnitude das variâncias e covariâncias, preservando a estrutura relativa determinada por Σ .

Como $\bar{\mathbf{X}}$ é não viesado, a decomposição do erro quadrático médio na Equação 10.18 reduz-se ao termo de variabilidade. Sob a perda quadrática euclidiana,

$$\begin{aligned} \text{EQM}(\bar{\mathbf{X}}) &= \text{tr} [\text{Cov}(\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr}(\Sigma). \end{aligned} \quad (10.55)$$

Como a variância total populacional foi definida na Equação 8.35 por

$$\text{tr}(\Sigma),$$

Equação 10.55 mostra que o erro quadrático médio sob perda euclidiana corresponde à variância total dividida pelo tamanho amostral.

Esses resultados estabelecem o não viesamento, a matriz de covariâncias e o erro quadrático médio de $\bar{\mathbf{X}}$. Eles não estabelecem, por si só, eficiência, pois essa propriedade exige comparar o estimador com procedimentos concorrentes segundo um critério especificado.

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

O correspondente estimador é

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Aplicando Proposição 8.1 ao vetor aleatório $\bar{\mathbf{X}}$, cuja média e matriz de covariâncias são dadas na Proposição 10.6,

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \mu,$$

e

$$\begin{aligned}\text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.\end{aligned}\tag{10.56}$$

Cada vetor $\mathbf{a}$ define uma combinação linear dos componentes de $\bar{\mathbf{X}}$ e, geometricamente, especifica uma direção juntamente com uma escala. Sua variabilidade é determinada por

$$\frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Para comparar apenas direções, pode-se considerar vetores $\mathbf{a}$ de norma unitária. Nesse caso, direções com maior variância populacional também produzem maior variabilidade entre as estimativas das respectivas combinações lineares. Essa é a mesma interpretação utilizada anteriormente na comparação de matrizes de covariâncias pela ordem de Löwner.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Mais geralmente, para

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\mu$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n} \mathbf{C}\Sigma\mathbf{C}^\top. \quad (10.57)$$

Essas expressões serão retomadas no estudo de contrastes e hipóteses lineares.

10.4.4 Consistência e equivariância

Proposição 10.7 (Consistência do vetor de médias amostrais). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independentes, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

com segundos momentos finitos. Para dimensão p fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad (10.58)$$

quando $n \rightarrow \infty$.

Comprovação. Por Equação 10.55,

$$E\left[\|\bar{\mathbf{X}} - \mu\|^2\right] = \frac{\text{tr}(\Sigma)}{n}.$$

Para $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$P(\|\bar{\mathbf{X}} - \mu\| > \varepsilon) \leq \frac{E[\|\bar{\mathbf{X}} - \mu\|^2]}{\varepsilon^2} \\ = \frac{\text{tr}(\Sigma)}{n\varepsilon^2} \rightarrow 0.$$

Logo,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

□

A prova utiliza segundos momentos finitos. Para dimensão fixa, a consistência também pode ser obtida por leis dos grandes números sob condições de integrabilidade mais gerais.

A equivariância do vetor de médias amostrais foi utilizada anteriormente como exemplo de Definição 10.9. O resultado é registrado a seguir para referência posterior.

Proposição 10.8 (Equivariância afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \tag{10.59}$$

Como, por Equação 8.17,

$$\mu_Y = \mathbf{C}\mu + \mathbf{d},$$

a transformação aplicada ao estimador acompanha exatamente a transformação correspondente do parâmetro populacional.

Até este ponto, foram estabelecidas propriedades distintas do vetor de médias amostrais: ele é não viesado, possui matriz de covariâncias Σ/n , tem erro quadrático médio $\text{tr}(\Sigma)/n$ sob perda euclidiana, é consistente sob as condições especificadas e é equivariante em relação a transformações afins. Essas propriedades foram demonstradas para o estimador concreto e não decorrem simplesmente do método utilizado para construí-lo.

10.4.5 Variabilidade entre amostras

O vetor $\bar{\mathbf{X}}$ é uma estatística aleatória, enquanto $\bar{\mathbf{x}}$ é sua realização para uma amostra observada. Se o processo de amostragem fosse repetido, diferentes amostras produziriam diferentes valores de $\bar{\mathbf{x}}$. A distribuição desses valores corresponde à distribuição amostral do estimador.

A Figura 10.1 apresenta 250 realizações de $\bar{\mathbf{X}}$ para amostras de tamanhos 5 e 50 geradas de uma mesma distribuição normal bivariada. A normalidade é utilizada apenas para gerar a ilustração; o resultado na Equação 10.54 depende apenas da independência das unidades amostrais e da existência dos segundos momentos.




Figura 10.1: Vetores de médias amostrais obtidos em 250 amostras de uma distribuição normal bivariada, para tamanhos amostrais 5 e 50.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Para $n = 50$, a nuvem é mais concentrada do que para $n = 5$, em concordância com a redução da matriz de covariâncias por $1/n$.

A figura **não representa ainda um resultado sobre a forma exata da distribuição amostral de $\bar{\mathbf{X}}$** . Essa distribuição será estudada no Capítulo 12.

O vetor de médias amostrais estima a localização da população. A estimação da dispersão exige considerar os desvios das observações em relação a esse centro. Esses desvios conduzem à matriz SQPC e aos estimadores da matriz de covariâncias.

10.5 SQPC e estimação da matriz de covariâncias

O vetor de médias amostrais descreve a localização da amostra. A estimação da matriz de covariâncias exige representar como as observações se dispersam conjuntamente em torno desse centro.

O Capítulo 8 definiu a matriz total de somas de quadrados e produtos cruzados (SQPC) na Definição 8.10 e a matriz de covariâncias observada na Definição 8.11. A seção sobre métodos de estimação mostrou ainda que o método dos momentos conduz à matriz SQPC dividida por n e que, sob o modelo normal multivariado e as condições de existência do máximo, a máxima verossimilhança conduz à mesma expressão.

Nesta seção, a SQPC e as matrizes de covariâncias correspondentes passam a ser tratadas como estatísticas aleatórias. O objetivo é comparar os estimadores de Σ resultantes de diferentes critérios e estudar suas propriedades.

Considere a amostra aleatória multivariada definida na Equação 10.1, com unidades independentes e

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

e suponha que os segundos momentos sejam finitos.

10.5.1 SQPC como estatística aleatória

A matriz aleatória da amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Retomando a matriz de centralização utilizada na Equação 8.58,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

define-se a matriz aleatória centralizada por

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}. \quad (10.60)$$

Suas linhas são

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Definição 10.13 (Matriz SQPC amostral). A **matriz de somas de quadrados e produtos cruzados (SQPC) amostral** é a estatística

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.61)$$

Equivalentemente,

$$\mathbf{T} = \mathcal{X}_c^\top \mathcal{X}_c = \mathcal{X}^\top \mathbf{H}_n \mathcal{X}. \quad (10.62)$$

Após a observação da amostra,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.63)$$

A matriz $\mathbf{T}$ é exatamente a matriz SQPC observada definida na Definição 8.10 e escrita matricialmente na Equação 8.59. A diferença de notação é probabilística: $\mathbf{T}$ representa a estatística aleatória, enquanto $\mathbf{T}$ representa sua realização observada.

O elemento (j, k) de $\mathbf{T}$ é

$$\mathsf{T}_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.64)$$

Na diagonal,

$$\mathbf{T}_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a soma de quadrados centralizada da variável j . Fora da diagonal, $\mathbf{T}_{jk}$ é o produto cruzado centralizado entre as variáveis j e k .

Após a observação da amostra, os elementos correspondentes de $\mathbf{T}$ são denotados por t_{jk} .

10.5.2 Decomposição em torno de um centro arbitrário

A caracterização do centroide na Equação 10.52 mostrou, em termos de distâncias quadráticas, como a dispersão em torno de um centro arbitrário pode ser decomposta em uma parcela em torno da média amostral e outra associada ao deslocamento do centro. Para a estimação da matriz de covariâncias, utiliza-se a versão matricial dessa decomposição.

Proposição 10.9 (Decomposição da SQPC em torno de um centro arbitrário). *Para qualquer vetor fixo*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \\ = \mathbf{T} + n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \tag{10.65}$$

Comprovação. Escreva

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo na soma dos produtos externos, surgem quatro parcelas. Os dois termos cruzados contêm

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

e, portanto, se anulam. Restam

$$\mathbf{T}$$

e

$$n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^\top,$$

o que fornece Equação 10.65. □

Para

$$\mathbf{c} = \mu,$$

obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top. \end{aligned} \tag{10.66}$$

Essa identidade separa a dispersão das observações em torno do centro populacional em duas parcelas: a dispersão em torno da média amostral e o afastamento entre a média amostral e a média populacional.

10.5.3 Esperança da SQPC

A identidade anterior permite obter a esperança de $\mathbf{T}$ sem assumir normalidade.

Proposição 10.10 (Esperança da SQPC). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{T}) = (n-1)\Sigma. \tag{10.67}$$

Comprovação. Tomando esperança no lado esquerdo de Equação 10.66,

$$E \left[\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] = \sum_{i=1}^n \Sigma = n\Sigma.$$

Para a segunda parcela do lado direito,

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] = n \text{Cov} (\bar{\mathbf{X}}).$$

Por Equação 10.54,

$$n \text{Cov} (\bar{\mathbf{X}}) = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{T}) + \Sigma,$$

e segue que

$$E(\mathbf{T}) = (n-1)\Sigma.$$

□

O fator $n-1$ surge porque a SQPC utiliza desvios em relação à média estimada a partir da própria amostra. A centralização impõe

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

de modo que os n vetores de desvios satisfazem uma restrição linear. Assim, a centralização reduz em uma unidade a dimensão associada às variações em torno da média amostral.

A relação

$$E(\mathbf{T}) = (n-1)\Sigma$$

depende apenas da independência entre as unidades amostrais e da existência dos segundos momentos necessários; a normalidade multivariada não é exigida. A distribuição completa de $\mathbf{T}$ sob normalidade será tratada no Capítulo 12.

10.5.4 Estimador não viesado da matriz de covariâncias

Definição 10.14 (Matriz de covariâncias amostral). Para $n \geq 2$, define-se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}, \quad (10.68)$$

em que $\mathbf{T}$ é definida na Definição 10.13.

Proposição 10.11 (Não viesamento da matriz de covariâncias amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes, possuem segundos momentos finitos e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{S}) = \Sigma. \quad (10.69)$$

Portanto, $\mathbf{S}$ é um estimador não viesado de Σ .

Comprovação. Por Equação 10.68 e Equação 10.67,

$$\begin{aligned} E(\mathbf{S}) &= \frac{1}{n-1} E(\mathbf{T}) \\ &= \frac{1}{n-1} (n-1) \Sigma \\ &= \Sigma. \end{aligned}$$

□

Após a observação, obtém-se a matriz de covariâncias observada definida na Definição 8.11:

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.70)$$

Componente a componente,

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.71)$$

Para $j = k$,

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Assim,

$$\mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}.$$

Após a observação da amostra, os elementos correspondentes de $\mathbf{S}$ são denotados por s_{jk} .

A divisão por $n-1$ corrige o viés associado à centralização pela média amostral. Ela não é escolhida para garantir semidefinição positiva. Como a matriz SQPC observada satisfaz

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram, conforme Definição 3.18, e suas propriedades de simetria e semidefinição positiva decorrem da Proposição 3.9. A multiplicação por $1/(n-1) > 0$ preserva essas propriedades em $\mathbf{S}$.

O não viesamento de $\mathbf{S}$ foi obtido utilizando apenas segundos momentos. Uma caracterização de sua variabilidade completa exigiria estudar

$$\text{Cov}[\text{vec}(\mathbf{S})],$$

utilizando o operador definido na Definição 7.9. De modo correspondente, o erro quadrático médio matricial sob a perda baseada na norma de Frobenius definida na Definição 6.7 envolveria

$$E \left[\|\mathbf{S} - \Sigma\|_F^2 \right].$$

Essas quantidades dependem, em geral, de momentos de quarta ordem. Por isso, diferentemente do que ocorreu com o vetor de médias amostrais, os segundos momentos assumidos nesta seção não são suficientes para determinar a variabilidade completa ou o EQM de $\mathbf{S}$. Sob normalidade, resultados mais específicos serão obtidos a partir da distribuição amostral da matriz de covariâncias no Capítulo 12.

10.5.5 Estimador com divisor n : momentos e máxima verossimilhança

Pelo método dos momentos, a Equação 10.33 fornece

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado não singular e quando o máximo existe, a Equação 10.44 fornece a mesma estatística:

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Portanto, no modelo normal e nas condições de existência do estimador de máxima verossimilhança,

$$\widehat{\Sigma}_{\text{MM}} = \widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

tem-se, sob o modelo normal,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (10.72)$$

Por Equação 10.67,

$$E \left(\frac{\mathbf{T}}{n} \right) = \frac{n-1}{n} \Sigma.$$

Portanto, como estimador de Σ ,

$$\text{Bias} \left(\frac{\mathbf{T}}{n} \right) = -\frac{1}{n} \Sigma.$$

Esse resultado vale para o estimador pelo método dos momentos sem exigir normalidade. Sob o modelo normal e nas condições de existência do máximo, a mesma estatística é também o estimador de máxima verossimilhança. Nesse caso,

$$E \left(\widehat{\Sigma}_{\text{MV}} \right) = \frac{n-1}{n} \Sigma \quad (10.73)$$

e

$$\text{Bias} \left(\widehat{\Sigma}_{\text{MV}} \right) = -\frac{1}{n} \Sigma. \quad (10.74)$$

Assim, o viés é uma propriedade da estatística $\mathbf{T}/n$ como estimador de Σ , e não uma consequência do método utilizado para obtê-la.

A comparação entre

$$\frac{\mathbf{T}}{n} \quad \text{e} \quad \frac{\mathbf{T}}{n-1}$$

mostra novamente que o princípio utilizado para construir um estimador e suas propriedades estatísticas são questões distintas. A primeira matriz resulta diretamente do método dos momentos e, sob normalidade, também da máxima verossimilhança; a segunda utiliza a correção necessária para obter não viesamento.

Quando n aumenta,

$$\frac{n-1}{n} \rightarrow 1,$$

de modo que a diferença relativa entre os dois estimadores desaparece.

Dois divisores, dois critérios

A matriz

$$\frac{\mathbf{T}}{n}$$

surge como estimador de momentos e, sob o modelo normal e as condições de existência do máximo, como estimador de máxima verossimilhança.

A matriz

$$\frac{\mathbf{T}}{n-1}$$

é construída para satisfazer

$$E(\mathbf{S}) = \Sigma.$$

Nenhum dos dois divisores é universalmente “correto” sem especificar o critério de estimação.

Sob o modelo normal multivariado, Proposição 10.2 estabeleceu que

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para

$$(\mu, \Sigma).$$

Como, para n fixado,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é uma transformação bijetiva de $\mathbf{T}$, o par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

preserva a mesma informação sobre os parâmetros. Essa afirmação é conjunta: ela não significa que $\mathbf{S}$ isoladamente seja suficiente para (μ, Σ) .

10.5.6 Consistência dos estimadores de covariância

O não viesamento é uma propriedade para tamanho amostral fixo. A consistência descreve o comportamento quando n aumenta.

Proposição 10.12 (Consistência da matriz de covariâncias amostral). *Considere uma amostra aleatória i.i.d.*

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

em que

$$\mathbf{X}_i \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu,$$

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

e

$$E(\|\mathbf{X}_i\|^2) < \infty.$$

Se o número p de variáveis permanece fixo quando $n \rightarrow \infty$, então

$$\mathbf{S} \xrightarrow{P} \Sigma. \quad (10.75)$$

Comprovação. Pela identidade

$$\frac{1}{n} \mathbf{T} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^\top - \bar{\mathbf{X}} \bar{\mathbf{X}}^\top, \quad (10.76)$$

a matriz com divisor n pode ser escrita como diferença entre o segundo momento amostral não central e o produto externo da média amostral.

Para cada par (j, k) , a condição de segundos momentos finitos implica

$$E(|X_j X_k|) < \infty.$$

Pela Lei dos Grandes Números,

$$\frac{1}{n} \sum_{i=1}^n X_{ij} X_{ik} \xrightarrow{P} E(X_j X_k),$$

e

$$\bar{X}_j \xrightarrow{P} \mu_j.$$

Logo, elemento a elemento,

$$\frac{1}{n} \mathbf{T} \xrightarrow{P} E(\mathbf{X}\mathbf{X}^\top) - \mu\mu^\top = \Sigma.$$

Como p é fixo,

$$\mathbf{S} = \frac{n}{n-1} \left(\frac{\mathbf{T}}{n} \right) \xrightarrow{P} \Sigma.$$

□

Pela mesma argumentação,

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n} \xrightarrow{P} \Sigma \quad (10.77)$$

sempre que a expressão é considerada como estatística. No modelo normal positivo definido, sua interpretação como estimador de máxima verossimilhança requer adicionalmente a existência do máximo discutida anteriormente.

A consistência apresentada aqui corresponde ao regime clássico de **dimensão fixa**. Quando p aumenta com n , a convergência deve ser analisada segundo o regime dimensional e a norma de interesse.

10.5.7 Transformações, posto e singularidade

As propriedades algébricas da matriz SQPC observada decorrem de sua representação de Gram na Equação 8.59 e do limite de posto estabelecido na Equação 8.60. Como essas propriedades valem para cada realização da amostra, elas também caracterizam as estatísticas $\mathbf{T}$ e $\mathbf{S}$ amostra a amostra.

Transformações afins. A equivariância da matriz de covariâncias amostral foi utilizada anteriormente como exemplo de Definição 10.9. Para referência, se

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

então

$$\mathbf{T}_Y = \mathbf{C}\mathbf{T}_X\mathbf{C}^\top \quad (10.78)$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \quad (10.79)$$

A translação $\mathbf{d}$ desaparece pela centralização. Como a matriz populacional satisfaz, pela Proposição 8.6,

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top,$$

a transformação da estatística acompanha exatamente a transformação correspondente do parâmetro.

Simetria e semidefinição positiva. Pela representação de Gram na Equação 8.59 e pelas propriedades de matrizes de Gram na Proposição 3.9, para qualquer realização da amostra,

$$\mathbf{T} = \mathbf{T}^\top \quad \text{e} \quad \mathbf{T} \succeq \mathbf{0}.$$

Como

$$\mathbf{S} = \frac{1}{n-1}\mathbf{T},$$

a matriz $\mathbf{S}$ também é simétrica e positiva semidefinida. Assim, em aritmética exata, o estimador não produz autovalores negativos.

Variância de combinações lineares. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{X}_i - \bar{\mathbf{X}})]^2. \quad (10.80)$$

A forma quadrática é a variância amostral da variável projetada

$$\mathbf{a}^\top \mathbf{X}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0$$

se, e somente se, os valores observados da combinação linear $\mathbf{a}^\top \mathbf{X}_i$ são constantes na amostra.

Posto. Pelo resultado estabelecido na Equação 8.60, para qualquer realização da amostra,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n-1). \quad (10.81)$$

Como $\mathbf{S}$ é obtida por multiplicação de $\mathbf{T}$ por uma constante positiva,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}). \quad (10.82)$$

Uma condição necessária para

$$\mathbf{S} \succ \mathbf{0}$$

é, portanto,

$$n \geq p+1.$$

Mesmo quando essa desigualdade é satisfeita, a definição positiva depende de as colunas de $\mathbf{X}_c$ possuírem posto completo.

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

A singularidade significa que existe algum vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p$$

tal que

$$\mathbf{S}\mathbf{a} = \mathbf{0}.$$

Equivalentemente,

$$\mathbf{a}^\top \mathbf{S}\mathbf{a} = 0,$$

de modo que a combinação linear correspondente apresenta variância amostral nula.

Inversão. Quando

$$\mathbf{S} \succ \mathbf{0},$$

sua inversa existe e pode ser utilizada em formas quadráticas e métricas baseadas na covariância estimada.

Se $\mathbf{S}$ é singular, $\mathbf{S}^{-1}$ não existe. A utilização de pseudoinversas ou de estimadores regularizados corresponde a escolhas distintas e será discutida na seção de aprofundamento.

Forma quadrática com covariância estimada

A distância de Mahalanobis foi definida na Definição 8.9 utilizando os parâmetros populacionais. Sob normalidade, Proposição 9.8 estabelece a distribuição qui-quadrado da forma correspondente quando μ e Σ são conhecidos.

Substituir esses parâmetros por quantidades estimadas, como $\bar{\mathbf{x}}$ e $\mathbf{S}$, produz outra estatística. Portanto, a distribuição

$$D_M^2 \sim \chi_p^2$$

não pode ser transferida diretamente para uma forma quadrática construída com estimadores.

As distribuições apropriadas para estatísticas que envolvem parâmetros estimados serão estudadas no Capítulo 12.

Até este ponto, foram estabelecidas propriedades distintas dos estimadores de Σ . A matriz $\mathbf{S} = \mathbf{T}/(n-1)$ é não viesada, enquanto $\mathbf{T}/n$ é viesada em amostras finitas, embora seja obtida pelo método dos momentos e, sob normalidade e existência do máximo, também pela máxima verossimilhança. Ambos os estimadores são consistentes no regime de dimensão fixa sob as condições especificadas. Além disso, a matriz de covariâncias amostral é equivariante sob transformações afins, positiva semidefinida em cada realização e possui posto limitado por $\min(p, n-1)$.

Esses resultados não estabelecem eficiência em amostras finitas, e a avaliação completa da variabilidade ou do erro quadrático médio matricial exige hipóteses adicionais sobre momentos de ordem superior.

O posto e a estabilidade numérica da matriz de covariâncias amostral tornam-se especialmente relevantes quando p não é pequeno em relação a n . Antes de discutir esse regime, serão construídos os estimadores correspondentes para covariâncias entre blocos e para correlações.

10.6 Estimação de covariâncias cruzadas e correlações

Em diversos problemas multivariados, as variáveis são organizadas em blocos observados sobre as mesmas unidades amostrais. As covariâncias cruzadas descrevem associações lineares entre variáveis pertencentes a blocos distintos, enquanto as correlações removem as escalas marginais dessas associações.

O Capítulo 8 definiu a matriz de covariâncias cruzadas populacional na Definição 8.3, a matriz de covariâncias cruzadas observada na Definição 8.13 e a matriz de correlações observada na Definição 8.12. Nesta seção, os objetos correspondentes são tratados como estatísticas aleatórias e utilizados na estimação de suas contrapartes populacionais.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q.$$

A matriz de covariâncias cruzadas populacional

$$\Sigma_{XY}$$

foi definida na Definição 8.3. Sua orientação satisfaz, conforme Equação 8.13,

$$\Sigma_{YX} = \Sigma_{XY}^{\top}.$$

Para o vetor conjunto

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

a estrutura em blocos da matriz de covariâncias segue Equação 8.15. Neste capítulo, será denotada por

$$\Sigma_{\text{conj}} = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.83)$$

Para estimar Σ_{XY} , é necessária uma amostra **pareada**:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ correspondem à mesma unidade amostral. Alterar a correspondência entre as linhas dos dois blocos modifica as covariâncias cruzadas.

Organize as observações nas matrizes aleatórias

$$\mathcal{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} \in \mathbb{R}^{n \times q}.$$

Após a centralização,

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.15 (Matriz de somas de produtos cruzados entre blocos). A **matriz de somas de produtos cruzados entre os dois blocos** é

$$\mathbf{T}_{XY} = \mathcal{X}_c^\top \mathcal{Y}_c. \quad (10.84)$$

Equivalentemente,

$$\mathbf{T}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (10.85)$$

Após a observação,

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.86)$$

A inversão da ordem dos blocos produz

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top$$

e

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 10.16 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$, a matriz de covariâncias cruzadas amostral é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}, \quad (10.87)$$

em que $\mathbf{T}_{XY}$ é a matriz de somas de produtos cruzados entre os blocos definida na Definição 10.15.

Após a observação da amostra, obtém-se a matriz de covariâncias cruzadas observada definida na Definição 8.13:

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.88)$$

Seu elemento (j, k) é

$$S_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.89)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{S}_{XY}$ é denotado por $s_{X_j Y_k}$.

Proposição 10.13 (Não viesamento da covariância cruzada amostral). *Considere uma amostra pareada i.i.d. do vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

com segundos momentos finitos. Então,

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.90)$$

Comprovação. A matriz de covariâncias amostral do vetor conjunto é

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}.$$

Pelo não viesamento da matriz de covariâncias amostral estabelecido na Equação 10.69,

$$E(\mathbf{S}_{\text{conj}}) = \Sigma_{\text{conj}}.$$

A igualdade entre os blocos superiores direitos fornece

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}.$$

□

O método dos momentos aplicado à matriz de covariâncias do vetor conjunto conduz ao estimador

$$\widehat{\Sigma}_{\text{conj}, \text{MM}} = \frac{1}{n} \mathbf{T}_{\text{conj}}.$$

Consequentemente, o bloco correspondente à covariância cruzada é

$$\widehat{\Sigma}_{XY, \text{MM}} = \frac{1}{n} \mathbf{T}_{XY}.$$

Sob normalidade conjunta não singular,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_{\text{conj}} \right),$$

o estimador de máxima verossimilhança da matriz conjunta de covariâncias, quando existe, utiliza também o divisor n . Portanto,

$$\widehat{\Sigma}_{XY, \text{MM}} = \widehat{\Sigma}_{XY, \text{MV}} = \frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY}. \quad (10.91)$$

Se

$$n \geq p + q + 1$$

e a distribuição normal conjunta é não singular, a matriz SQPC do vetor conjunto possui posto $p + q$ quase certamente. Nessas condições, o estimador positivo definido de máxima verossimilhança da matriz conjunta existe quase certamente.

Por Equação 10.90,

$$E\left(\frac{1}{n}\mathbf{T}_{XY}\right) = \frac{n-1}{n}\Sigma_{XY}.$$

Assim,

$$\text{Bias}\left(\frac{1}{n}\mathbf{T}_{XY}\right) = -\frac{1}{n}\Sigma_{XY}.$$

Esse viés pertence à estatística $\mathbf{T}_{XY}/n$ como estimador de Σ_{XY} e não depende da hipótese de normalidade. A normalidade é necessária apenas para interpretar essa mesma estatística como o bloco cruzado do estimador de máxima verossimilhança da matriz conjunta.

A consistência também pode ser obtida diretamente a partir da matriz de covariâncias do vetor conjunto. Sob as condições da Proposição 10.12, aplicadas ao vetor de dimensão $p + q$,

$$\mathbf{S}_{\text{conj}} \xrightarrow{P} \Sigma_{\text{conj}}.$$

Consequentemente, cada um de seus blocos converge para o bloco populacional correspondente e, em particular,

$$\mathbf{S}_{XY} \xrightarrow{P} \Sigma_{XY}. \quad (10.92)$$

Como

$$\frac{1}{n}\mathbf{T}_{XY} = \frac{n-1}{n}\mathbf{S}_{XY},$$

também se obtém

$$\frac{1}{n}\mathbf{T}_{XY} \xrightarrow{P} \Sigma_{XY}.$$

A transformação da covariância cruzada amostral acompanha a transformação do parâmetro populacional estabelecida na Equação 8.19. Se

$$\mathbf{U} = \mathbf{CX} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{D}\mathbf{Y} + \mathbf{d},$$

então

$$\mathbf{S}_{UV} = \mathbf{C}\mathbf{S}_{XY}\mathbf{D}^\top. \quad (10.93)$$

Portanto, $\mathbf{S}_{XY}$ é equivariante em relação a essas transformações afins dos dois blocos. Os vetores de localização $\mathbf{c}$ e $\mathbf{d}$ desaparecem após a centralização.

Para

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

segue que

$$\mathbf{S}_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.94)$$

Diferentemente de uma matriz de covariâncias de um único vetor, $\mathbf{S}_{XY}$ é, em geral, retangular quando $p \neq q$. Mesmo quando $p = q$, ela não precisa ser simétrica. Os dois blocos satisfazem

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top.$$

Por isso, propriedades como simetria e semidefinição positiva não devem ser atribuídas isoladamente à matriz de covariâncias cruzadas. Essas propriedades pertencem à matriz de covariâncias do vetor conjunto, da qual $\mathbf{S}_{XY}$ é um bloco.

O posto satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.95)$$

Esse limite restringirá posteriormente técnicas que utilizam simultaneamente dois conjuntos de variáveis.

10.6.2 Matriz de correlações amostral

A matriz de correlações amostral é obtida pela padronização das covariâncias pelas variâncias marginais correspondentes.

Considere

$$\mathbf{S} = (S_{jk})$$

e defina a matriz diagonal das variâncias amostrais por

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Definição 10.17 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas, a matriz de correlações amostral é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.96)$$

em que

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Após a observação da amostra, obtém-se a matriz $\mathbf{R}$ definida na Definição 8.12:

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.97)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) da estatística aleatória $\mathbf{R}$ é

$$R_{jk} = \frac{S_{jk}}{\sqrt{S_{jj}S_{kk}}}. \quad (10.98)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{R}$ é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}.$$

Consequentemente,

$$R_{jj} = 1$$

e, para a realização observada,

$$r_{jj} = 1.$$

A interpretação geométrica da correlação observada foi estabelecida na Equação 8.71, que identifica r_{jk} com o cosseno do ângulo entre as colunas centralizadas e padronizadas. Aqui, a ênfase recai sobre $\mathbf{R}$ como estatística utilizada para estimar a matriz populacional $\mathcal{R}$.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Se

$$S_{jj} = 0$$

a correspondente padronização não existe.

10.6.3 Propriedades estruturais

Proposição 10.14 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, $\mathbf{R}$ é:*

1. *simétrica;*
2. *positiva semidefinida;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.99)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.100)$$

Comprovação. A simetria decorre da simetria de $\mathbf{S}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \mathbf{R} \mathbf{a} &= \left(\mathbf{D}_S^{-1/2} \mathbf{a} \right)^\top \mathbf{S} \left(\mathbf{D}_S^{-1/2} \mathbf{a} \right) \\ &\geq 0.\end{aligned}$$

Logo, $\mathbf{R}$ é positiva semidefinida.

A diagonal unitária decorre de

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1.$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definitude positiva. $\square$

Uma matriz simétrica com diagonal unitária e elementos em $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A positividade semidefinida também é necessária.

Como

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}),$$

uma condição necessária para definitude positiva é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois ainda podem existir dependências lineares entre as colunas centralizadas.

Quando

$$p \geq n,$$

a matriz de correlações, se definida, é necessariamente singular.

Para uma realização observada,

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.101)$$

A padronização remove as escalas marginais, mas não altera o posto.

A matriz de correlações populacional é uma função da matriz de covariâncias,

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Substituindo Σ pelo estimador de momentos

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T},$$

obtem-se um estimador por substituição de $\mathcal{R}$. Como o fator comum $1/n$ aparece tanto nas covariâncias quanto nas variâncias marginais, ele se cancela na padronização. A matriz resultante é

$$\mathbf{R}.$$

Assim, $\mathbf{R}$ pode ser obtida pela padronização do estimador de momentos de Σ .

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança de Σ existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Novamente, o fator comum $(n-1)/n$ cancela-se na transformação de covariâncias em correlações. Pela Proposição 10.4,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}. \quad (10.102)$$

Assim, no modelo normal considerado e nas condições de existência do máximo, a mesma matriz de correlações amostral também é obtida pela máxima verossimilhança.

Essa coincidência não implica não viesamento. Em geral,

$$E(R_{jk}) \neq \rho_{jk}.$$

A razão é que a correlação amostral é uma função não linear das variâncias e covariâncias amostrais.

Por outro lado, se

$$\mathbf{S} \xrightarrow{P} \Sigma$$

e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

Considere a transformação

$$g(\mathbf{A}) = \mathbf{D}_A^{-1/2} \mathbf{A} \mathbf{D}_A^{-1/2},$$

em que

$$\mathbf{D}_A = \text{diag}(a_{11}, \dots, a_{pp}).$$

Essa transformação converte uma matriz de covariâncias em sua matriz de correlações e é contínua quando os elementos de sua diagonal são positivos.

O **teorema do mapeamento contínuo** estabelece que, se uma sequência de estatísticas converge em probabilidade e uma função é contínua no limite, então a sequência obtida pela aplicação dessa função também converge em probabilidade (Vaart, 1998).

Como

$$\mathbf{S} \xrightarrow{P} \Sigma$$

no regime de dimensão fixa e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

a transformação g é contínua em Σ . Portanto,

$$g(\mathbf{S}) \xrightarrow{P} g(\Sigma).$$

Como

$$g(\mathbf{S}) = \mathbf{R}$$

e

$$g(\Sigma) = \mathcal{R},$$

segue que

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \quad (10.103)$$

Portanto, a matriz de correlações amostral é consistente para a matriz de correlações populacional, embora suas entradas possam ser viesadas em amostras finitas.

10.6.4 Transformações de localização e escala

O efeito populacional das mudanças de localização e escala sobre a correlação foi estabelecido na Equação 8.25. Para uma realização observada, considere

$$y_{ij} = a_j + b_j x_{ij}, \quad b_j \neq 0.$$

A localização a_j desaparece após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \operatorname{sgn}(b_j) \operatorname{sgn}(b_k) r_{X_j X_k}. \quad (10.104)$$

Fatores de escala positivos preservam a correlação. Quando apenas um dos fatores b_j e b_k é negativo, o sinal da correlação é invertido. Mudanças de localização não alteram a correlação.

Em forma matricial, para

$$\mathbf{Y} = \mathbf{X} \mathbf{D}_b + \mathbf{1}_n \mathbf{a}^\top,$$

com

$$\mathbf{D}_b = \operatorname{diag}(b_1, \dots, b_p),$$

defina

$$\mathbf{D}_{\operatorname{sgn}} = \operatorname{diag}[\operatorname{sgn}(b_1), \dots, \operatorname{sgn}(b_p)].$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\operatorname{sgn}} \mathbf{R}_X \mathbf{D}_{\operatorname{sgn}}. \quad (10.105)$$

Se todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X.$$

Para dois blocos, defina as matrizes diagonais aleatórias

$$\mathbf{D}_X = \text{diag} (S_{X_1 X_1}, \dots, S_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (S_{Y_1 Y_1}, \dots, S_{Y_q Y_q}).$$

Quando todas as variâncias amostrais envolvidas são positivas, define-se a matriz de correlações cruzadas amostral por

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2}. \quad (10.106)$$

Seu elemento (j, k) é

$$R_{X_j Y_k} = \frac{S_{X_j Y_k}}{\sqrt{S_{X_j X_j} S_{Y_k Y_k}}}.$$

Após a observação da amostra,

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2},$$

em que

$$\mathbf{D}_X = \text{diag} (s_{X_1 X_1}, \dots, s_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (s_{Y_1 Y_1}, \dots, s_{Y_q Y_q}).$$

Seu elemento observado é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}}.$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top$$

e, após a observação,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top.$$

A matriz de correlações do vetor conjunto assume a forma

$$\mathbf{R}_{\text{conj}} = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix}. \quad (10.107)$$

Até este ponto, foram estabelecidas propriedades distintas das estatísticas utilizadas para representar associações entre variáveis. A matriz $\mathbf{S}_{XY}$ é não viesada e consistente para Σ_{XY} sob as condições especificadas, enquanto $\mathbf{T}_{XY}/n$ apresenta o mesmo fator de viés observado na estimação da matriz de covariâncias e, sob normalidade conjunta e existência do máximo, também corresponde ao estimador de máxima verossimilhança do bloco cruzado.

A matriz de correlações amostral $\mathbf{R}$ remove as escalas marginais, preserva a semidefinição positiva e o posto da matriz de covariâncias quando está definida, é consistente no regime de dimensão fixa, mas suas entradas não são, em geral, estimadores não viesados das correlações populacionais. Sob o modelo normal, a invariância da máxima verossimilhança conduz à mesma matriz $\mathbf{R}$.

As matrizes de covariâncias e correlações cruzadas serão utilizadas posteriormente em métodos que relacionam dois conjuntos de variáveis. O objetivo neste capítulo é estabelecer sua estimação e as propriedades necessárias para esses desenvolvimentos.

A próxima seção examina situações em que a dimensão, a redundância ou a sensibilidade das estatísticas clássicas dificultam a estimação da matriz de covariâncias.

10.7 Aprofundamento: dimensão, estabilidade e extensões da estimação

Esta seção examina situações em que a dimensão, o condicionamento ou a sensibilidade das estatísticas amostrais exigem cuidados adicionais. Os resultados anteriores trataram dos estimadores clássicos da média e da matriz de covariâncias. A regularização e a estimação robusta modificam esses procedimentos para tratar, respectivamente, problemas de instabilidade e de sensibilidade.

Uma matriz de covariâncias não estruturada de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. Assim, o número de parâmetros de dispersão a estimar cresce quadraticamente com p , enquanto o número de unidades amostrais permanece igual a n .

Regularização e robustez respondem a problemas diferentes. A regularização procura reduzir a instabilidade associada à dimensão, à redundância, ao tamanho amostral ou ao mau condicionamento. A estimação robusta procura reduzir a sensibilidade do procedimento a determinadas formas de contaminação ou desvios do modelo. As duas abordagens podem ser combinadas, mas tratam de problemas distintos.

10.7.1 Relação entre p e n

O limite de posto estabelecido na Equação 10.81,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1),$$

permite distinguir diferentes regimes dimensionais.

Dimensão fixa. No regime clássico,

$$p$$

permanece fixo enquanto

$$n \longrightarrow \infty.$$

Sob as condições da Proposição 10.12,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Como p é fixo, a convergência dos elementos implica convergência em qualquer norma matricial sobre $\mathbb{R}^{p \times p}$, pois todas essas normas são equivalentes em dimensão finita.

Dimensão crescente. Quando

$$p = p_n$$

também aumenta com n , os resultados obtidos para dimensão fixa não podem ser transferidos automaticamente. Um regime de referência é

$$\frac{p_n}{n} \longrightarrow c, \quad 0 < c < 1.$$

Nesse regime, a matriz de covariâncias amostral pode possuir posto completo e, ainda assim, apresentar elevada variabilidade em seu espectro.

O controle dos erros de estimação elemento a elemento não garante, por si só, controle do erro matricial em norma espectral. Consequentemente, boa estimação das covariâncias individuais não assegura automaticamente boa estimação dos autovalores, autovetores, determinante, inversa ou formas quadráticas que dependem da matriz inversa.

Além disso, o número de covariâncias fora da diagonal é

$$\frac{p(p-1)}{2},$$

e todas são estimadas a partir das mesmas n unidades.

Não existe um valor universal de p/n que separe matrizes estáveis e instáveis. O comportamento depende também da estrutura de Σ , da separação entre seus autovalores, da distribuição populacional e da função da matriz utilizada posteriormente.

Dimensão maior ou igual ao tamanho amostral. Se

$$p \geq n,$$

Equação 10.81 implica

$$\text{posto}(\mathbf{S}) \leq n - 1 < p.$$

Logo, a matriz de covariâncias amostral é necessariamente singular.

Essa singularidade não implica singularidade de Σ . Ela pode decorrer exclusivamente do número limitado de direções amostrais disponíveis após a centralização.

Posto amostral e posto populacional

Quando

$$p \geq n,$$

$\mathbf{S}$ é singular por construção, mesmo que a matriz populacional satisfaça

$$\Sigma \succ \mathbf{0}.$$

A singularidade da matriz amostral, portanto, não constitui evidência suficiente de singularidade da matriz de covariâncias populacional.

10.7.2 Condicionamento e inversão

Considere uma realização positiva definida,

$$\mathbf{S} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p),$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

A inversa é

$$\mathbf{S}^{-1} = \mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^\top.$$

Autovalores pequenos de $\mathbf{S}$ tornam-se pesos elevados em $\mathbf{S}^{-1}$.

O número de condição espectral foi definido na Definição 6.9. Para uma matriz simétrica positiva definida,

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.108)$$

Quanto maior essa razão, maior é a diferença entre as escalas espectrais extremas da matriz. Quando

$$\ell_{\min}(\mathbf{S}) \longrightarrow 0,$$

tem-se

$$\kappa_2(\mathbf{S}) \longrightarrow \infty.$$

Se $\mathbf{S}$ é singular, o número de condição associado à inversão é infinito. Portanto, invertibilidade e bom condicionamento são propriedades distintas.

O mau condicionamento torna a inversa sensível a erros de estimação: pequenas perturbações em $\mathbf{S}$ podem produzir alterações acentuadas em

$$\mathbf{S}^{-1}.$$

O determinante também depende de todo o espectro:

$$\det(\mathbf{S}) = \prod_{j=1}^p \ell_j.$$

Já a estabilidade dos autovetores depende não somente da magnitude dos autovalores, mas também de sua separação. Autovalores muito próximos podem produzir direções individuais sensíveis a pequenas perturbações.

Considere, por exemplo, a contraparte amostral da forma quadrática utilizada na distância de Mahalanobis definida na Definição 8.9:

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Nas coordenadas dos autovetores de $\mathbf{S}$,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Assim, erros na estimação de autovalores pequenos podem ser amplificados pela inversão, pois essas direções recebem pesos proporcionais a $1/\ell_j$.

Inversão computacional

A existência de $\mathbf{S}^{-1}$ não significa que seja necessário formá-la explicitamente. Quando o objetivo é calcular

$$\mathbf{S}^{-1}\mathbf{b},$$

é preferível, em geral, resolver o sistema

$$\mathbf{S}\mathbf{x} = \mathbf{b}.$$

Essa escolha não elimina o mau condicionamento, mas evita uma inversão explícita desnecessária.

10.7.3 Regularização

A regularização substitui a matriz de covariâncias amostral por um estimador que combina $\mathbf{S}$ com restrições ou valores de referência previamente especificados. O objetivo pode ser reduzir variabilidade, melhorar o condicionamento ou produzir uma matriz invertível.

Uma classe simples combina $\mathbf{S}$ com uma matriz-alvo (Ledoit; Wolf, 2004).

Definição 10.18 (Estimador de covariância por contração). Considere uma matriz-alvo fixada

$$\Gamma \in \mathbb{R}^{p \times p}, \quad \Gamma \succeq \mathbf{0},$$

e um peso

$$0 \leq \lambda \leq 1.$$

Define-se o estimador por contração

$$\widehat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \quad (10.109)$$

Para

$$\lambda = 0,$$

recupera-se $\mathbf{S}$. Para

$$\lambda = 1,$$

o estimador coincide com o alvo.

A contração geralmente introduz viés. Sua avaliação deve considerar conjuntamente viés e variabilidade por meio de uma função de perda e do risco correspondente.

A consistência também depende da forma como a regularização varia com o tamanho amostral. Se $\lambda \in (0, 1]$ e Γ são fixos e

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

então

$$\widehat{\Sigma}_\lambda \xrightarrow{P} (1 - \lambda)\Sigma + \lambda\Gamma.$$

Portanto, com $\lambda > 0$ fixo, o estimador não é, em geral, consistente para Σ . Se a matriz-alvo Γ é fixa e o peso passa a depender de n , com

$$\lambda_n \rightarrow 0,$$

então

$$\widehat{\Sigma}_{\lambda_n} = (1 - \lambda_n)\mathbf{S} + \lambda_n \Gamma \xrightarrow{P} \Sigma,$$

sempre que

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Assim, nesse caso, a intensidade da regularização desaparece assintoticamente e a consistência da matriz de covariâncias amostral é preservada.

Em aplicações, o alvo e o peso podem ser estimados a partir dos próprios dados. Nesse caso,

$$\widehat{\Sigma}_{\hat{\lambda}} = (1 - \hat{\lambda})\mathbf{S} + \hat{\lambda}\hat{\Gamma}. \quad (10.110)$$

A aleatoriedade de $\hat{\lambda}$ e de $\hat{\Gamma}$ passa, então, a fazer parte das propriedades do estimador.

A matriz-alvo precisa ser compatível com as unidades e escalas das variáveis. Um alvo diagonal preserva as escalas marginais e reduz as covariâncias. Um alvo esférico $\tau\mathbf{I}_p$ pressupõe que uma escala comum possua interpretação. Para matrizes de correlações, a identidade $\mathbf{I}_p$ constitui uma escolha natural de referência. O alvo também pode representar relações previamente especificadas entre as variáveis, como covariâncias nulas ou uma estrutura de correlação definida antes da estimação.

A identidade $\mathbf{I}_p$ não é um alvo neutro para uma matriz de covariâncias quando as variáveis são medidas em unidades ou escalas distintas.

Um alvo esférico adaptado à escala observada pode utilizar

$$\hat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}), \quad (10.111)$$

levando a

$$\widehat{\Sigma}_{\lambda} = (1 - \lambda)\mathbf{S} + \lambda\hat{\tau}\mathbf{I}_p. \quad (10.112)$$

Essa escolha pressupõe que uma variância média comum tenha significado para as variáveis consideradas. Além disso, a definitude positiva produzida pelo componente esférico exige $\hat{\tau} > 0$. Como $\mathbf{S} \succeq \mathbf{0}$, essa condição equivale a haver variabilidade amostral positiva em pelo menos uma direção.

Outro alvo é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(\mathbf{S}_{11}, \dots, \mathbf{S}_{pp})$$

com

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.113)$$

Nesse caso, as variâncias amostrais permanecem inalteradas e as covariâncias são multiplicadas por $1 - \lambda$.

Proposição 10.15 (Definitude positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\hat{\Sigma}_{\lambda} \succ \mathbf{0}. \quad (10.114)$$

Comprovação. Para qualquer $\mathbf{a} \neq \mathbf{0}$,

$$\mathbf{a}^{\top} \hat{\Sigma}_{\lambda} \mathbf{a} = (1 - \lambda)\mathbf{a}^{\top} \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^{\top} \Gamma \mathbf{a}.$$

A primeira parcela é não negativa e a segunda é estritamente positiva. Logo,

$$\mathbf{a}^{\top} \hat{\Sigma}_{\lambda} \mathbf{a} > 0.$$

□

Com um alvo esférico,

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0,$$

e uma decomposição

$$\mathbf{S} = \mathbf{Q} \text{diag}(\mathbf{L}_1, \dots, \mathbf{L}_p) \mathbf{Q}^\top,$$

obtém-se

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \text{diag}[(1 - \lambda)\mathbf{L}_1 + \lambda\tau, \dots, (1 - \lambda)\mathbf{L}_p + \lambda\tau] \mathbf{Q}^\top. \quad (10.115)$$

Portanto,

$$\mathbf{L}_{j,\lambda} = (1 - \lambda)\mathbf{L}_j + \lambda\tau. \quad (10.116)$$

Se

$$\mathbf{L}_j = 0$$

e

$$\lambda > 0,$$

então

$$\mathbf{L}_{j,\lambda} = \lambda\tau > 0.$$

A contração esférica afasta os autovalores de zero e pode melhorar o condicionamento. Esse efeito algébrico não garante redução do erro de estimação. A escolha do alvo e de λ deve ser avaliada segundo a função de perda e o risco considerados.

A Figura 10.2 compara o espectro da covariância amostral com uma versão regularizada.

No regime $p < n$, a regularização desloca os autovalores na direção do alvo. No regime $p \geq n$, os autovalores nulos decorrentes do limite de posto são substituídos por valores positivos.

A figura mostra um efeito algébrico da regularização. A escolha de λ e do alvo é um problema estatístico distinto e não será desenvolvida algoritmicamente neste capítulo.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

10.7.4 Pseudoinversa e regularização

A pseudoinversa de Moore–Penrose foi definida na Definição 6.11. Para uma matriz de covariâncias amostral com decomposição espectral reduzida

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que Λ_r contém os r autovalores positivos, tem-se

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.117)$$

A pseudoinversa e a regularização resolvem problemas matemáticos diferentes.

Para visualizar essa diferença, considere

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\ell_1, \dots, \ell_p) \mathbf{Q}^\top,$$

com

$$\ell_j \geq 0.$$

A pseudoinversa atribui os pesos

$$\begin{cases} 1/\ell_j, & \ell_j > 0, \\ 0, & \ell_j = 0. \end{cases}$$

Considere agora

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

com

$$0 < \lambda \leq 1 \quad \text{e} \quad \tau > 0.$$

Sua inversa é

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1 - \lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.118)$$

Se

$$\ell_j = 0,$$

a pseudoinversa atribui peso zero, enquanto a inversa regularizada atribui

$$\frac{1}{\lambda\tau}.$$

A pseudoinversa não modifica $\mathbf{S}$; ela substitui a inversão usual por sua extensão de Moore–Penrose. Os autovalores positivos continuam recebendo pesos $1/\ell_j$, mesmo quando são muito pequenos, enquanto as direções associadas a autovalores nulos recebem peso zero.

A regularização modifica a própria matriz utilizada para estimar Σ e define outro procedimento estatístico. Na contração esférica, os autovalores são afastados de zero e a inversão passa a utilizar pesos finitos determinados pelos autovalores regularizados. Portanto, pseudoinversa e regularização tratam a singularidade por mecanismos diferentes.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ ou por uma inversa regularizada modifica a estatística utilizada. Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica não podem ser transferidas automaticamente para essas substituições.

10.7.5 Sensibilidade e robustez

O vetor de médias e a matriz de covariâncias amostrais podem sofrer alterações arbitrariamente grandes quando uma observação é substituída por outra suficientemente afastada da maior parte dos dados (Maronna et al., 2019).

Considere a substituição de uma observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.119)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

A alteração não possui limite uniforme quando $\mathbf{x}_k^*$ pode se afastar arbitrariamente dos demais dados. Assim, uma única observação pode produzir uma mudança arbitrariamente grande na média amostral.

Na matriz de covariâncias, os produtos externos

$$(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

fazem com que observações afastadas possam modificar simultaneamente dispersões, covariâncias e direções espectrais.

Uma observação extrema não deve ser identificada automaticamente como erro. Ela pode representar uma unidade válida situada em uma região pouco frequente da população, uma observação proveniente de outra população ou um erro de registro ou medição. O comportamento extremo também pode indicar que a distribuição possui caudas mais pesadas, assimetria ou heterogeneidade não representadas pelo modelo adotado.

A decisão de manter, corrigir ou excluir uma observação exige conhecimento do processo de coleta e do contexto.

Estimadores robustos de localização e dispersão procuram limitar determinados tipos de sensibilidade. Sua comparação depende de quanto as estimativas se alteram diante de observações contaminadas, da eficiência sob o modelo adotado como referência, da equivariância, das condições de existência em função de n e p , do custo computacional e do parâmetro de localização ou dispersão que o procedimento pretende estimar. Nenhum procedimento apresenta o melhor desempenho em todos esses critérios.

Observações extremas, alta dimensão e má especificação correspondem a problemas diferentes. Observações extremas podem alterar fortemente estimadores sensíveis. A alta dimensão afeta o número de parâmetros a estimar, o posto e a estabilidade da matriz. A má especificação ocorre quando a distribuição ou a estrutura assumida pelo modelo não representa adequadamente o processo que gerou os dados. Esses problemas podem ocorrer simultaneamente, mas exigem tratamentos diferentes.

A avaliação de uma matriz de covariâncias estimada depende da finalidade da análise. Tamanho amostral e dimensão determinam restrições de posto; o espectro informa sobre direções de variabilidade e condicionamento; as escalas das variáveis influenciam a interpretação e a escolha de alvos de regularização; e a sensibilidade das estimativas deve ser considerada quando observações extremas ou desvios do modelo podem alterar substancialmente os resultados.

O exemplo integrado a seguir reúne os principais objetos construídos no capítulo em uma única amostra.

10.8 Exemplo integrado

O exemplo reúne a estimação da localização, da dispersão e das relações entre dois blocos de variáveis. Como os cálculos são realizados para uma amostra observada, os resultados numéricos são estimativas, representadas pelos correspondentes objetos observados.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 2 \\ 3 & 5 & 3 \\ 3 & 6 & 3 \\ 5 & 7 & 4 \\ 5 & 6 & 6 \\ 6 & 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 9 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A correspondência entre as linhas de $\mathbf{X}$ e $\mathbf{Y}$ precisa ser preservada para a estimação das covariâncias cruzadas.

Os valores foram escolhidos para que as médias sejam inteiras e os produtos cruzados possam ser calculados sem arredondamento. Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 6 \\ 4 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

As matrizes centralizadas são, portanto,

$$\mathbf{X}_c = \begin{bmatrix} -2 & -2 & -2 \\ -1 & -1 & -1 \\ -1 & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 2 \\ 2 & 2 & 2 \end{bmatrix}$$

e

$$\mathbf{Y}_c = \begin{bmatrix} -3 & -2 \\ -1 & -3 \\ 0 & 0 \\ 1 & 2 \\ -1 & -1 \\ 4 & 4 \end{bmatrix}.$$

Em ambas as matrizes, cada coluna soma zero, como exige a centralização pela média amostral.

Para o primeiro bloco, a matriz SQPC observada é

$$\mathbf{T}_X = \mathbf{X}_c^\top \mathbf{X}_c.$$

Os elementos da diagonal são somas de quadrados. Por exemplo,

$$t_{11} = (-2)^2 + (-1)^2 + (-1)^2 + 1^2 + 1^2 + 2^2 = 12.$$

Os elementos fora da diagonal são somas de produtos cruzados. Por exemplo,

$$\begin{aligned} t_{12} &= (-2)(-2) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(0) + (2)(2) \\ &= 10. \end{aligned}$$

Calculando os demais elementos da mesma forma,

$$\mathbf{T}_X = \begin{bmatrix} 12 & 10 & 12 \\ 10 & 10 & 9 \\ 12 & 9 & 14 \end{bmatrix}. \quad (10.120)$$

A simetria decorre de $t_{jk} = t_{kj}$, de modo que somente a diagonal e uma das partes triangulares precisam ser calculadas diretamente.

A matriz de covariâncias amostral utiliza o divisor

$$n - 1 = 5.$$

Logo,

$$\begin{aligned}\mathbf{S}_X &= \frac{1}{5} \mathbf{T}_X \\ &= \begin{bmatrix} 2,4 & 2,0 & 2,4 \\ 2,0 & 2,0 & 1,8 \\ 2,4 & 1,8 & 2,8 \end{bmatrix}.\end{aligned}\tag{10.121}$$

A matriz $\mathbf{S}_X$ é a realização observada do estimador não viesado $\mathbf{S}_X$ de Σ_{XX} , cujo não viesamento foi estabelecido na Equação 10.69.

Sob o modelo normal multivariado definido na Definição 9.1, nesta amostra

$$\text{posto}(\mathbf{T}_X) = 3.$$

Portanto, a condição de posto completo da Proposição 10.3 é satisfeita. Assim, a estimativa de máxima verossimilhança da matriz de covariâncias é

$$\begin{aligned}\widehat{\Sigma}_{XX, \text{MV, obs}} &= \frac{1}{6} \mathbf{T}_X \\ &= \begin{bmatrix} 2 & 5/3 & 2 \\ 5/3 & 5/3 & 3/2 \\ 2 & 3/2 & 7/3 \end{bmatrix}.\end{aligned}\tag{10.122}$$

As duas matrizes estão relacionadas por

$$\widehat{\Sigma}_{XX, \text{MV, obs}} = \frac{5}{6} \mathbf{S}_X.$$

Como diferem apenas pelo fator escalar positivo $5/6$, possuem os mesmos autovetores e o mesmo posto. Seus autovalores diferem pelo fator $5/6$, enquanto o número de condição espectral permanece inalterado.

Em cálculos manuais, os valores exatos devem ser mantidos enquanto possível. Por isso, a estimativa de máxima verossimilhança foi apresentada em forma fracionária. O arredondamento deve ser realizado apenas na apresentação dos resultados que não admitem uma representação exata simples. Utilizar valores já arredondados de médias, covariâncias, correlações ou autovetores em cálculos posteriores pode acumular erros e produzir resultados diferentes dos obtidos a partir dos valores exatos.

Neste exemplo, $\mathbf{T}_X$ é exata e $\mathbf{S}_X = \mathbf{T}_X/5$ possui representação decimal finita. Para calcular correlações, pode-se utilizar diretamente

$$r_{jk} = \frac{t_{jk}}{\sqrt{t_{jj}t_{kk}}},$$

pois o divisor comum de $\mathbf{S}_X$ se cancela. Autovalores e números de condição apresentados em forma decimal devem ser calculados com os valores não arredondados e arredondados apenas ao final.

A matriz de correlações observada é

$$\mathbf{R}_X \approx \begin{bmatrix} 1,000 & 0,913 & 0,926 \\ 0,913 & 1,000 & 0,761 \\ 0,926 & 0,761 & 1,000 \end{bmatrix}. \quad (10.123)$$

As três correlações são positivas. A maior ocorre entre X_1 e X_3 ,

$$r_{13} \approx 0,926,$$

e a menor entre X_2 e X_3 ,

$$r_{23} \approx 0,761.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 \approx 6,579, \quad \ell_2 \approx 0,560 \quad \text{e} \quad \ell_3 \approx 0,061.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e

$$\mathbf{S}_X \succ \mathbf{0}.$$

Seu número de condição espectral é aproximadamente

$$\kappa_2(\mathbf{S}_X) = \frac{\ell_1}{\ell_3} \approx 108,3.$$

O valor de $\kappa_2(\mathbf{S}_X)$ foi calculado com os autovalores antes do arredondamento. Dividir os valores exibidos, já arredondados, pode produzir uma aproximação ligeiramente diferente.

Portanto, $\mathbf{S}_X$ é invertível, mas seus autovalores apresentam magnitudes bastante distintas. O valor relativamente elevado de $\kappa_2(\mathbf{S}_X)$ mostra que invertibilidade e bom condicionamento são propriedades distintas.

Para estimar as relações entre os dois blocos, utiliza-se

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c.$$

Por exemplo, o elemento correspondente a X_1 e Y_1 é

$$\begin{aligned} t_{X_1 Y_1} &= (-2)(-3) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(-1) + (2)(4) \\ &= 15. \end{aligned}$$

Os demais produtos cruzados fornecem

$$\mathbf{T}_{XY} = \begin{bmatrix} 15 & 16 \\ 16 & 17 \\ 13 & 13 \end{bmatrix}. \quad (10.124)$$

Logo, pela definição de covariância cruzada observada na Definição 8.13,

$$\mathbf{S}_{XY} = \frac{1}{5} \mathbf{T}_{XY} = \begin{bmatrix} 3,0 & 3,2 \\ 3,2 & 3,4 \\ 2,6 & 2,6 \end{bmatrix}. \quad (10.125)$$

Por exemplo,

$$s_{X_3 Y_1} = 2,6$$

é a covariância amostral entre X_3 e Y_1 .

A inversão da ordem dos blocos segue Equação 8.73:

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 3,0 & 3,2 & 2,6 \\ 3,2 & 3,4 & 2,6 \end{bmatrix}.$$

Para o segundo bloco,

$$\mathbf{T}_Y = \mathbf{Y}_c^\top \mathbf{Y}_c = \begin{bmatrix} 28 & 28 \\ 28 & 34 \end{bmatrix},$$

de modo que

$$\mathbf{S}_Y = \frac{1}{5} \mathbf{T}_Y = \begin{bmatrix} 5,6 & 5,6 \\ 5,6 & 6,8 \end{bmatrix}.$$

Reunindo as cinco variáveis,

$$\mathbf{X}_{\text{conj}} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

a matriz SQPC conjunta possui a forma em blocos

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} \mathbf{T}_X & \mathbf{T}_{XY} \\ \mathbf{T}_{YX} & \mathbf{T}_Y \end{bmatrix}.$$

Numericamente,

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} 12 & 10 & 12 & 15 & 16 \\ 10 & 10 & 9 & 16 & 17 \\ 12 & 9 & 14 & 13 & 13 \\ 15 & 16 & 13 & 28 & 28 \\ 16 & 17 & 13 & 28 & 34 \end{bmatrix}.$$

Como $n - 1 = 5$,

$$\mathbf{S}_{\text{conj}} = \frac{1}{5} \mathbf{T}_{\text{conj}} = \begin{bmatrix} 2,4 & 2,0 & 2,4 & 3,0 & 3,2 \\ 2,0 & 2,0 & 1,8 & 3,2 & 3,4 \\ 2,4 & 1,8 & 2,8 & 2,6 & 2,6 \\ 3,0 & 3,2 & 2,6 & 5,6 & 5,6 \\ 3,2 & 3,4 & 2,6 & 5,6 & 6,8 \end{bmatrix}. \quad (10.126)$$

A organização em blocos permite identificar diretamente as covariâncias internas de $\mathbf{X}$, as covariâncias internas de $\mathbf{Y}$ e as covariâncias cruzadas entre os dois conjuntos.

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_{\text{conj}}) \leq 5.$$

A matriz conjunta centralizada é

$$\mathbf{X}_{\text{conj},c} = \begin{bmatrix} -2 & -2 & -2 & -3 & -2 \\ -1 & -1 & -1 & -1 & -3 \\ -1 & 0 & -1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 2 \\ 1 & 0 & 2 & -1 & -1 \\ 2 & 2 & 2 & 4 & 4 \end{bmatrix}.$$

Seu escalonamento fornece cinco pivôs, de modo que

$$\text{posto}(\mathbf{X}_{\text{conj},c}) = 5.$$

Como

$$\mathbf{T}_{\text{conj}} = \mathbf{X}_{\text{conj},c}^{\top} \mathbf{X}_{\text{conj},c},$$

segue de Equação 8.60 que

$$\text{posto}(\mathbf{S}_{\text{conj}}) = 5.$$

Portanto,

$$\mathbf{S}_{\text{conj}} \succ \mathbf{0}.$$

O caso $n = 6$ e $p = 5$ está exatamente no limite $n = p + 1$. Esse tamanho amostral permite posto completo, mas não o garante para uma amostra arbitrária.

O exemplo mostra como uma única amostra produz realizações dos principais objetos definidos no capítulo. Os vetores $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ estimam as médias populacionais, enquanto $\mathbf{T}_X$ é a realização da estatística SQPC. A divisão de $\mathbf{T}_X$ por $n - 1$ produz a estimativa não viesada $\mathbf{S}_X$; a divisão por n produz a estimativa pelo método dos momentos e, sob o modelo normal e as condições de existência do máximo, também a estimativa de máxima verossimilhança.

A matriz $\mathbf{R}_X$ utiliza a mesma informação de covariância após a remoção das escalas marginais. O posto completo de $\mathbf{S}_X$ garante sua invertibilidade, mas o número de condição mostra que essa propriedade não garante estabilidade da inversão.

O pareamento das linhas de $\mathbf{X}$ e $\mathbf{Y}$ determina os produtos cruzados em $\mathbf{T}_{XY}$ e, conseqüentemente, as covariâncias em $\mathbf{S}_{XY}$. A matriz conjunta reúne em um único objeto as covariâncias internas dos dois blocos e as covariâncias entre eles.

Todos os valores apresentados são realizações obtidas nesta amostra. Não viesamento, consistência, eficiência e outras propriedades dos estimadores descrevem seu comportamento ao considerar as possíveis amostras geradas pelo modelo.

10.9 Síntese do capítulo

Este capítulo estabeleceu a relação entre parâmetros populacionais, estatísticas amostrais, estimadores e suas realizações observadas.

A distinção central envolve quatro objetos. O parâmetro θ é uma característica fixa da distribuição populacional. Uma amostra aleatória $\mathcal{X}$ produz estatísticas por meio de funções dos dados,

$$\mathbf{G} = G(\mathcal{X}).$$

Quando uma estatística é utilizada para estimar θ , ela constitui um estimador,

$$\hat{\theta} = G(\mathcal{X}).$$

Após a observação da amostra, a realização

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X})$$

é a estimativa do parâmetro. Portanto, todo estimador é uma estatística, mas nem toda estatística é utilizada como estimador.

Para uma amostra multivariada i.i.d., o vetor de médias amostrais estima μ , enquanto a matriz de covariâncias amostral estima Σ :

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

e

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

em que $\mathbf{T}$ é a matriz SQPC amostral definida na Definição 10.13.

O método dos momentos e a máxima verossimilhança são princípios de construção de estimadores. O método utilizado não determina, por si só, as propriedades do estimador obtido.

O método dos momentos fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}$$

e

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado e quando o máximo existe, a máxima verossimilhança conduz às mesmas estatísticas.

A segunda estatística é viesada em amostras finitas, enquanto

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é não viesada. As duas são consistentes para Σ no regime de dimensão fixa sob as condições estabelecidas no capítulo.

Os resultados na Proposição 10.6 e Equação 10.69 fornecem

$$E(\bar{\mathbf{X}}) = \mu, \quad \text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}, \quad E(\mathbf{S}) = \Sigma.$$

No regime de dimensão fixa, Proposição 10.7 e Proposição 10.12 estabelecem

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad \text{e} \quad \mathbf{S} \xrightarrow{P} \Sigma.$$

Para variáveis organizadas em dois blocos pareados,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}$$

estima a matriz de covariâncias cruzadas. Quando as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}$$

fornece a matriz de correlações amostral.

A Tabela 10.2 reúne os principais objetos do capítulo.

Tabela 10.2: Relação entre parâmetros, estatísticas, estimadores e valores observados utilizados no capítulo.

Parâmetro ou objeto	Estatística/estimador	Propriedade destacada	Valor observado
μ	$\bar{\mathbf{X}}$	Não viesado e consistente; MM; MV sob normalidade e existência do máximo	$\bar{\mathbf{x}}$
Σ	$\mathbf{S} = \mathbf{T}/(n-1)$	Não viesado e consistente	$\mathbf{S}$
Σ	$\mathbf{T}/n$	MM; MV sob normalidade e existência do máximo; viesado em amostras finitas e consistente	$\mathbf{T}/n$
SQPC amostral	$\mathbf{T}$	Estatística que reúne somas de quadrados e produtos cruzados	$\mathbf{T}$
Σ_{XY}	$\mathbf{S}_{XY}$	Não viesado e consistente	$\mathbf{S}_{XY}$
$\mathcal{R}$	$\mathbf{R}$	Em geral viesado, mas consistente; MV sob normalidade e existência do máximo	$\mathbf{R}$

As propriedades estudadas respondem a perguntas diferentes. O viés compara a esperança do estimador com o parâmetro; a variabilidade descreve quanto o estimador muda entre amostras; o erro quadrático médio combina erro sistemático e variabilidade segundo uma função de perda; a consistência descreve o comportamento quando n aumenta; e a eficiência compara estimadores concorrentes segundo sua variabilidade ou risco. A suficiência verifica se uma redução da amostra preserva a informação sobre o parâmetro, enquanto a equivariância descreve a resposta do estimador a transformações dos dados. A robustez examina quanto o procedimento pode ser alterado pelas formas de contaminação ou perturbação consideradas.

A estrutura de posto

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1)$$

mostra por que dimensão e tamanho amostral precisam ser considerados conjuntamente. Quando $p \geq n$, a covariância amostral é necessariamente singular. Mesmo quando existe uma inversa, seu uso pode ser instável quando alguns autovalores são pequenos.

Pseudoinversa e regularização tratam singularidade e condicionamento por mecanismos diferentes. A pseudoinversa mantém $\mathbf{S}$ e modifica a operação utilizada para trabalhar com suas direções de variância nula. A regularização substitui $\mathbf{S}$ por outro estimador, por exemplo combinando-a com uma matriz-alvo. Essa modificação pode afastar autovalores de zero e melhorar o condicionamento, mas também altera viés, risco e consistência. Com peso de contração fixo e alvo diferente de Σ , a consistência para Σ não é garantida.

Ao término deste capítulo, deve-se ser capaz de:

- distinguir parâmetro, estatística, estimador, estimativa e distribuição amostral;
- avaliar viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência, equivariância e robustez;
- distinguir os princípios do método dos momentos e da máxima verossimilhança;
- construir o vetor de médias amostrais, a matriz SQPC e os estimadores da matriz de covariâncias;
- explicar a origem e a função dos divisores n e $n - 1$;
- construir estimadores de covariâncias cruzadas e correlações;
- analisar posto, singularidade e condicionamento de matrizes estimadas;
- distinguir pseudoinversa, regularização e estimação robusta segundo o problema que cada procedimento procura tratar.

O Capítulo 11 utiliza a matriz de covariâncias populacional de Definição 8.2, o modelo normal multivariado de Definição 9.1 e os estimadores desenvolvidos neste capítulo para construir o **modelo linear multivariado**. Nesse modelo, várias variáveis-resposta são relacionadas simultaneamente a uma matriz de delineamento, produzindo uma matriz de parâmetros, valores ajustados, resíduos e matrizes SQPC associadas às fontes de variação.

11 Modelo Linear Multivariado e Hipóteses Lineares

O Capítulo 10 desenvolveu a estimação do vetor de médias e da matriz de covariâncias a partir de uma amostra aleatória multivariada. O vetor de médias amostrais e suas propriedades foram estabelecidos em Proposição 10.6, enquanto a matriz de covariâncias amostral foi definida em Definição 10.14 e seu não viesamento foi estabelecido em Proposição 10.11. Nesse contexto, todas as unidades compartilhavam o mesmo vetor de médias populacional.

O modelo linear multivariado substitui essa média comum por uma estrutura de médias que pode variar entre as unidades segundo características conhecidas. Essa formulação permite representar, em um mesmo modelo, regressões com várias respostas, comparações entre grupos, efeitos de fatores e efeitos de covariáveis.

O modelo é escrito como

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

em que:

- $\mathbf{y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

Aqui, n é o número de unidades, p é o número de respostas observadas em cada unidade e q é o número de termos representados na matriz de delineamento. Esses termos podem incluir intercepto, indicadores de grupos ou tratamentos e covariáveis quantitativas.

O objetivo deste capítulo é formular o modelo, estimar $\mathbf{B}$, interpretar valores ajustados e resíduos por meio de projeções, construir a SQPC residual, estimar a matriz de covariâncias dos erros, decompor a dispersão observada e representar hipóteses lineares sobre parâmetros e combinações das respostas (Rencher; Christensen, 2012).

No caso de grupos, essa estrutura relacionará a variação residual e a variação associada ao modelo às matrizes de dispersão intragrupos e entre grupos definidas em Definição 8.14 e Definição 8.15.

As distribuições amostrais utilizadas na construção de testes e regiões de confiança serão desenvolvidas no Capítulo 12.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{Y}_i \in \mathbb{R}^p$ representa o vetor aleatório de respostas da unidade i ;
- $\mathbf{y}_i \in \mathbb{R}^p$ representa uma realização desse vetor;
- $\mathbf{y} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de respostas;
- $\mathbf{Y} \in \mathbb{R}^{n \times p}$ representa a matriz observada de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ representa a matriz de delineamento;
- $\mathbf{z}_i^\top$ representa a linha i de $\mathbf{Z}$;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ representa a matriz de parâmetros;
- $\varepsilon_i \in \mathbb{R}^p$ representa o vetor aleatório de erros da unidade i ;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de erros;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias entre as respostas de uma mesma unidade;
- $\widehat{\mathbf{B}}$ representa um estimador de $\mathbf{B}$;
- $\widehat{\mathbf{U}}$ representará a matriz aleatória de resíduos e $\widehat{\mathbf{U}}$ sua realização observada;
- $\mathbf{E}_{\text{res}}$ representará a SQPC residual como estatística aleatória e $\mathbf{E}$ sua realização observada;
- $\mathbf{T}$ continuará representando a SQPC total observada;
- $\mathbf{T}_{\text{mod}}$ representará a dispersão dos valores ajustados pelo modelo em torno da média geral;
- $\mathbf{H}$ ficará reservada à SQPC associada a uma hipótese linear.

A letra $\mathbf{Z}$ é utilizada para o delineamento para preservar $\mathbf{X}$ como símbolo da matriz de dados nos capítulos anteriores.

11.1 Formulação do modelo linear multivariado

11.1.1 Resposta vetorial e matriz de respostas

No modelo linear univariado, cada unidade fornece uma única resposta. No caso multivariado, a unidade i fornece simultaneamente

$$\mathbf{Y}_i = \begin{bmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{ip} \end{bmatrix} \in \mathbb{R}^p. \quad (11.1)$$

As componentes podem apresentar dependência. O modelo deve, portanto, representar simultaneamente:

1. a estrutura das médias das p respostas;
2. a variabilidade de cada resposta;
3. as covariâncias entre respostas observadas na mesma unidade.

Considere

$$\mathbf{z}_i = \begin{bmatrix} z_{i1} \\ \vdots \\ z_{iq} \end{bmatrix} \in \mathbb{R}^q,$$

contendo os valores dos q termos do modelo para a unidade i .

Um termo pode representar, por exemplo, o intercepto, o pertencimento a um grupo ou tratamento, o valor de uma covariável quantitativa ou outro efeito especificado no modelo. A matriz de delineamento reúne essas informações para todas as unidades.

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1p} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qp} \end{bmatrix} \in \mathbb{R}^{q \times p}. \quad (11.2)$$

A coluna j de $\mathbf{B}$ contém os coeficientes do modelo para a resposta j . A linha h reúne os coeficientes associados ao mesmo termo da matriz de delineamento para as p respostas.

Assim, uma covariável ou um efeito de grupo pode atuar de maneira diferente sobre cada resposta, embora todas utilizem a mesma matriz $\mathbf{Z}$.

A média condicional do vetor de respostas da unidade i é

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i. \quad (11.3)$$

Equivalentemente, em forma de vetor linha,

$$E(\mathbf{Y}_i^\top \mid \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{B}.$$

Definição 11.1 (Modelo linear multivariado para uma unidade). O vetor de respostas da unidade i é representado por

$$\mathbf{Y}_i = \mathbf{B}^\top \mathbf{z}_i + \varepsilon_i, \quad (11.4)$$

em que

$$\mathbf{Y}_i, \varepsilon_i \in \mathbb{R}^p, \quad \mathbf{z}_i \in \mathbb{R}^q, \quad \mathbf{B} \in \mathbb{R}^{q \times p}.$$

Componente a componente,

$$Y_{ij} = \mathbf{z}_i^\top \beta_j + \varepsilon_{ij}, \quad j = 1, \dots, p, \quad (11.5)$$

em que β_j é a coluna j de $\mathbf{B}$.

As equações das diferentes respostas compartilham a mesma matriz de delineamento. O carácter multivariado do modelo decorre da análise conjunta dessas respostas e da estrutura de covariâncias dos respectivos erros.

Para reunir as n unidades, defina a matriz aleatória

Definição 11.2 (Matriz aleatória de respostas).

$$\mathbf{y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \mathbf{Y}_2^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} = \begin{bmatrix} Y_{11} & \dots & Y_{1p} \\ Y_{21} & \dots & Y_{2p} \\ \vdots & \ddots & \vdots \\ Y_{n1} & \dots & Y_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.6)$$

Após a observação,

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.7)$$

A matriz de delineamento é

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times q}. \quad (11.8)$$

Neste capítulo, o modelo e os resultados de estimação são formulados condicionalmente a $\mathbf{Z}$. Assim, a matriz de delineamento é tratada como conhecida. Essa convenção abrange tanto delineamentos fixados previamente quanto análises condicionais aos valores observados das variáveis explicativas.

11.1.2 Estrutura matricial do modelo

Organize os vetores de erros nas linhas de

$$\mathcal{E} = \begin{bmatrix} \varepsilon_1^\top \\ \vdots \\ \varepsilon_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.9)$$

Definição 11.3 (Modelo linear multivariado). O modelo linear multivariado é

$$\mathcal{Y} = \mathbf{ZB} + \mathcal{E}. \quad (11.10)$$

em que:

- $\mathcal{Y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

A matriz de médias condicionais é

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}. \quad (11.11)$$

Portanto, a estrutura sistemática do modelo pertence ao espaço coluna de $\mathbf{Z}$. Cada coluna de

$$\mathbf{ZB}$$

é uma combinação linear das colunas do delineamento.

Se

$$r = \text{posto}(\mathbf{Z}), \quad (11.12)$$

então

$$r \leq \min(n, q).$$

O valor r é o número de colunas linearmente independentes de $\mathbf{Z}$ e, portanto, a dimensão do espaço de médias representado pelo delineamento.

Quando

$$r = q,$$

a matriz de delineamento possui posto coluna completo. O caso $r < q$ será examinado posteriormente, quando forem discutidas a unicidade dos coeficientes e as funções estimáveis.

11.1.3 Estrutura de médias e covariâncias residuais

A primeira condição do modelo é

Definição 11.4 (Média residual nula).

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}, \quad i = 1, \dots, n. \quad (11.13)$$

Consequentemente,

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i.$$

A segunda condição descreve a dependência entre as respostas de uma mesma unidade e entre unidades distintas.

Definição 11.5 (Estrutura de covariâncias dos erros). Para cada unidade,

$$\varepsilon_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

e assume-se que os segundos momentos condicionais existem.

A matriz de covariâncias condicional é comum às unidades:

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n, \quad (11.14)$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0}.$$

Além disso,

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}_{p \times p}, \quad i \neq \ell. \quad (11.15)$$

A matriz

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix}$$

é a matriz de covariâncias residuais entre as p respostas.

Assim,

$$\text{Var}(Y_{ij} \mid \mathbf{Z}) = \sigma_{jj},$$

e, para duas respostas da mesma unidade,

$$\text{Cov}(Y_{ij}, Y_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

A expressão “covariância residual” indica a variabilidade que permanece após a estrutura de médias $\mathbf{ZB}$ ter sido especificada. Ela não deve ser confundida com a covariância marginal das respostas quando suas médias variam entre unidades.

As condições anteriores implicam que a dependência entre respostas é permitida **dentro de uma unidade**, enquanto erros de unidades distintas são não correlacionados. Sob normalidade conjunta, a covariância cruzada nula entre unidades implica independência por Proposição 9.6.

11.1.4 Forma vetorizada

A forma matricial

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$$

será a representação principal do modelo neste capítulo. Quando for necessário reunir todas as respostas em um único vetor, podem ser utilizados o operador vec e o produto de Kronecker definidos em Definição 7.9 e Definição 7.10.

Pela identidade de Proposição 7.15,

$$\text{vec}(\mathbf{ZB}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \quad (11.16)$$

de modo que

$$\text{vec}(\mathbf{y}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}) + \text{vec}(\mathcal{E}). \quad (11.17)$$

Proposição 11.1 (Covariância do erro vetorizado). *Se*

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

então

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.18)$$

Consequentemente,

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.19)$$

A forma vetorizada será utilizada como representação auxiliar em resultados de covariância e distribuição. Os cálculos de ajuste, resíduos e decomposição da variação serão desenvolvidos diretamente na forma matricial.

11.1.5 Distribuição normal matricial

A normalidade não é necessária para definir o modelo linear multivariado nem para obter os resultados de mínimos quadrados desenvolvidos neste capítulo. Ela será utilizada para obter distribuições amostrais exatas no Capítulo 12.

A distribuição normal matricial fornece uma notação compacta para representar conjuntamente a distribuição das linhas e das colunas de uma matriz aleatória (Gupta; Nagar, 1999).

Definição 11.6 (Distribuição normal matricial). *Se*

$$\mathcal{A} \in \mathbb{R}^{n \times p},$$

diz-se que

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V})$$

quando

$$\text{vec}(\mathcal{A}) \sim N_{np}[\text{vec}(\Xi), \mathbf{V} \otimes \mathbf{U}]. \quad (11.20)$$

Aqui,

$$\Xi \in \mathbb{R}^{n \times p}, \quad \mathbf{U} \in \mathbb{R}^{n \times n}, \quad \mathbf{V} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{U} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{V} \succeq \mathbf{0}.$$

A distribuição normal multivariada utilizada no lado direito de Equação 11.20 é a distribuição definida em Definição 9.1.

Neste capítulo será utilizado apenas o caso em que

$$\mathbf{U} = \mathbf{I}_n$$

e

$$\mathbf{V} = \Sigma.$$

A matriz $\mathbf{I}_n$ representa a ausência de dependência entre unidades, enquanto Σ representa as covariâncias entre as p respostas de uma mesma unidade.

Definição 11.7 (Modelo linear normal multivariado). Considere

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p},$$

e

$$\mathcal{E} \in \mathbb{R}^{n \times p}.$$

Se

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0},$$

o modelo linear normal multivariado é definido por

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}_{n \times p}, \mathbf{I}_n, \Sigma). \quad (11.21)$$

Equivalentemente,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma). \quad (11.22)$$

Pela definição da normal matricial,

$$\text{vec}(\mathbf{y}) \mid \mathbf{Z} \sim N_{np}[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n]. \quad (11.23)$$

A mesma estrutura pode ser lida por unidade:

$$\mathbf{Y}_i \mid \mathbf{Z} \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n, \quad (11.24)$$

com independência condicional entre as unidades.

A matriz Σ continua desempenhando o papel estabelecido nos Capítulos 8 e 9: suas diagonais são as variâncias residuais das respostas e seus elementos fora da diagonal descrevem a dependência linear residual entre elas.

Para uma resposta específica j , a coluna correspondente satisfaz

$$\mathbf{Y}_{\cdot j} \mid \mathbf{Z} \sim N_n(\mathbf{Z}\beta_j, \sigma_{jj}\mathbf{I}_n). \quad (11.25)$$

Para duas respostas j e k ,

$$\text{Cov}(\mathbf{Y}_{\cdot j}, \mathbf{Y}_{\cdot k} \mid \mathbf{Z}) = \sigma_{jk}\mathbf{I}_n. \quad (11.26)$$

Assim, ajustar separadamente as p equações produz os mesmos estimadores de mínimos quadrados para os coeficientes quando todas utilizam a mesma matriz $\mathbf{Z}$. A formulação conjunta mantém explícita a covariância entre as respostas e permite formular posteriormente hipóteses que envolvem várias respostas simultaneamente.

Sob normalidade, a mesma estrutura também permite relacionar mínimos quadrados e máxima verossimilhança. Essa relação será desenvolvida após a obtenção do estimador de $\mathbf{B}$.

11.1.6 Transformações da resposta

Uma transformação linear das respostas preserva a estrutura do modelo.

Considere

$$\mathbf{W}_i = \mathbf{A}^\top \mathbf{Y}_i,$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times s}.$$

Em forma matricial,

$$\mathcal{W} = \mathcal{Y} \mathbf{A}.$$

Logo,

$$\mathcal{W} = \mathbf{Z}(\mathbf{B}\mathbf{A}) + \mathcal{E}\mathbf{A}. \quad (11.27)$$

A matriz de parâmetros transformada é

$$\mathbf{B}_W = \mathbf{B}\mathbf{A},$$

e a matriz de covariâncias residuais é

$$\Sigma_W = \mathbf{A}^\top \Sigma \mathbf{A},$$

em concordância com Proposição 8.6.

Sob normalidade, Proposição 9.4 fornece

$$\mathcal{W} \mid \mathbf{Z} \sim N_{n \times s}(\mathbf{Z}\mathbf{B}\mathbf{A}, \mathbf{I}_n, \mathbf{A}^\top \Sigma \mathbf{A}). \quad (11.28)$$

Essa propriedade será utilizada posteriormente para formular hipóteses sobre combinações lineares das respostas.

O modelo está agora especificado em termos de sua estrutura de médias e de covariâncias. A próxima etapa é estimar a matriz de parâmetros $\mathbf{B}$ a partir da matriz observada de respostas.

11.2 Estimação da matriz de parâmetros

A estimação de $\mathbf{B}$ consiste em determinar a estrutura de médias

$$\mathbf{ZB}$$

que melhor aproxima a matriz observada de respostas $\mathbf{Y}$ segundo o critério adotado.

Como todas as respostas utilizam a mesma matriz de delineamento, cada coluna de $\mathbf{B}$ pode ser estimada pelo modelo linear correspondente àquela resposta. A formulação matricial reúne os p ajustes e mantém explícita a estrutura necessária para estudar conjuntamente os coeficientes e a covariância residual entre as respostas (Rencher; Christensen, 2012).

11.2.1 Mínimos quadrados

Considere uma matriz candidata

$$\mathbf{B}^* \in \mathbb{R}^{q \times p}.$$

A matriz de resíduos correspondente é

$$\mathbf{Y} - \mathbf{ZB}^*.$$

Definição 11.8 (Critério de mínimos quadrados multivariado). O critério de mínimos quadrados é

$$Q(\mathbf{B}^*) = \|\mathbf{Y} - \mathbf{ZB}^*\|_F^2. \quad (11.29)$$

Equivalentemente,

$$Q(\mathbf{B}^*) = \text{tr} \left[(\mathbf{Y} - \mathbf{ZB}^*)^\top (\mathbf{Y} - \mathbf{ZB}^*) \right]. \quad (11.30)$$

A norma de Frobenius foi definida em Definição 6.7. Neste problema,

$$Q(\mathbf{B}^*) = \sum_{j=1}^p \|\mathbf{y}_{\cdot j} - \mathbf{Zb}_j^*\|^2, \quad (11.31)$$

em que $\mathbf{y}_{\cdot j}$ é a coluna j de $\mathbf{Y}$ e $\mathbf{b}_j^*$ é a coluna correspondente de $\mathbf{B}^*$.

Portanto, minimizar $Q(\mathbf{B}^*)$ equivale a minimizar separadamente a soma de quadrados residual de cada uma das p respostas.

Por essa razão, as covariâncias fora da diagonal de Σ não participam da obtenção do estimador de mínimos quadrados de $\mathbf{B}$ quando todas as respostas utilizam a mesma matriz $\mathbf{Z}$. Elas determinam, porém, a covariância entre os estimadores de respostas distintas e serão utilizadas na estimação da covariância residual e nas hipóteses que envolvem várias respostas simultaneamente.

As equações normais e sua derivação por cálculo matricial foram estabelecidas em Definição 3.21 e Proposição 7.6. Aplicadas ao modelo atual, elas assumem a forma

$$\mathbf{Z}^\top \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.32)$$

Equivalentemente,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}}) = \mathbf{0}_{q \times p}. \quad (11.33)$$

Se

$$\widehat{\mathbf{U}} = \mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}},$$

então

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}. \quad (11.34)$$

Cada coluna da matriz de resíduos é, portanto, ortogonal ao espaço coluna de $\mathbf{Z}$. Essa propriedade é a versão multivariada da decomposição de mínimos quadrados estabelecida em Proposição 3.18.

11.2.2 Estimador sob posto completo

Suponha

$$\text{posto}(\mathbf{Z}) = q. \quad (11.35)$$

Nesse caso,

$$q \leq n$$

e

$$\mathbf{Z}^\top \mathbf{Z} \succ \mathbf{0}.$$

Proposição 11.2 (Estimador de mínimos quadrados sob posto completo). *Se*

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de mínimos quadrados de $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.36)$$

Após a observação das respostas,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (11.37)$$

A unicidade do minimizador decorre da definição positiva de

$$\mathbf{Z}^\top \mathbf{Z}.$$

A convexidade do critério e a caracterização do minimizador global por meio das equações normais foram desenvolvidas em Proposição 7.9 e não precisam ser novamente demonstradas aqui.

Para a resposta j , a coluna correspondente é

$$\hat{\beta}_j = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{\cdot j}, \quad (11.38)$$

em que

$$\mathbf{Y}_{\cdot j} = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{nj} \end{bmatrix}.$$

Assim, cada coluna de $\widehat{\mathbf{B}}$ coincide com o estimador de mínimos quadrados obtido para a resposta correspondente. A formulação matricial reúne esses estimadores em um único objeto.

11.2.3 Esperança e matriz de covariâncias

Substituindo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

em Equação 11.36,

$$\begin{aligned}\widehat{\mathbf{B}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.\end{aligned}\tag{11.39}$$

A segunda parcela representa o erro de estimação.

Proposição 11.3 (Esperança e covariância do estimador da matriz de parâmetros). *Considere*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

Se

$$\text{posto}(\mathbf{Z}) = q,$$

então

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}\tag{11.40}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.\tag{11.41}$$

Comprovação. De Equação 11.39 e da condição

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

segue imediatamente que

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}.$$

Para a covariância, defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então,

$$\widehat{\mathbf{B}} - \mathbf{B} = \mathbf{A}_Z \mathcal{E}.$$

Pela identidade de vetorização em Proposição 7.15,

$$\text{vec}(\widehat{\mathbf{B}} - \mathbf{B}) = (\mathbf{I}_p \otimes \mathbf{A}_Z) \text{vec}(\mathcal{E}).$$

Aplicando a estrutura de covariâncias dos erros,

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{A}_Z \mathbf{A}_Z^\top).$$

Como

$$\mathbf{A}_Z \mathbf{A}_Z^\top = (\mathbf{Z}^\top \mathbf{Z})^{-1},$$

obtém-se Equação 11.41. □

O resultado mostra duas fontes distintas de variabilidade:

$$\Sigma$$

descreve a variabilidade residual e a associação entre as respostas, enquanto

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a precisão dos coeficientes.

Para duas respostas j e k ,

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k | \mathbf{Z}) = \sigma_{jk} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.42)$$

Para $j = k$,

$$\text{Cov}(\hat{\beta}_j | \mathbf{Z}) = \sigma_{jj} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.43)$$

Assim, estimadores associados a respostas diferentes são correlacionados sempre que os erros dessas respostas apresentam covariância residual diferente de zero.

11.2.4 Relação com máxima verossimilhança

Sob o modelo linear normal multivariado, a log-verossimilhança para uma matriz observada de respostas $\mathbf{Y}$, a menos de termos que não dependem dos parâmetros, const é

$$\begin{aligned} \ell(\mathbf{B}, \Sigma; \mathbf{Y}) = \text{const} - \frac{n}{2} \log \det(\Sigma) \\ - \frac{1}{2} \text{tr} [\Sigma^{-1} (\mathbf{Y} - \mathbf{ZB})^\top (\mathbf{Y} - \mathbf{ZB})]. \end{aligned} \quad (11.44)$$

Para $\Sigma \succ \mathbf{0}$ fixada, o primeiro termo não depende de $\mathbf{B}$. Portanto, maximizar a log-verossimilhança em relação a $\mathbf{B}$ equivale a minimizar o termo quadrático residual.

Aplicando ao termo quadrático residual o procedimento de diferenciação matricial utilizado em Proposição 7.6, obtém-se

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ é invertível,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) = \mathbf{0},$$

que coincide com a equação normal de mínimos quadrados em Equação 11.33.

Proposição 11.4 (Mínimos quadrados e máxima verossimilhança). *Considere o modelo linear normal multivariado com*

$$\text{posto}(\mathbf{Z}) = q.$$

Para qualquer $\Sigma \succ \mathbf{0}$ fixada, o maximizador da verossimilhança em relação a $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Consequentemente, sempre que o estimador de máxima verossimilhança conjunto de

$$(\mathbf{B}, \Sigma)$$

existir no espaço paramétrico considerado,

$$\widehat{\mathbf{B}}_{\text{MV}} = \widehat{\mathbf{B}}. \quad (11.45)$$

A coincidência ocorre porque todas as respostas utilizam a mesma matriz de delineamento $\mathbf{Z}$ e porque Σ atua sobre a dependência entre as respostas, não sobre a estrutura entre as unidades.

Assim, Σ determina a covariância conjunta dos coeficientes estimados, mas não modifica a expressão de $\widehat{\mathbf{B}}$.

Esse resultado depende da estrutura do modelo e não se transfere automaticamente para situações em que as respostas utilizam delineamentos diferentes ou em que existe dependência residual entre unidades.

A existência do estimador conjunto de máxima verossimilhança da matriz de covariâncias será examinada na seção dedicada à SQPC residual.

11.2.5 Modelo contendo somente intercepto

O modelo mais simples ocorre quando todas as unidades possuem o mesmo vetor de médias:

$$\mathbf{Y}_i = \mu + \varepsilon_i, \quad i = 1, \dots, n. \quad (11.46)$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Como

$$\mathbf{Z}^\top \mathbf{Z} = n,$$

tem-se

$$\widehat{\mathbf{B}} = \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} = \bar{\mathbf{Y}}^\top. \quad (11.47)$$

Após a observação,

$$\widehat{\mathbf{B}}_{\text{obs}} = \bar{\mathbf{y}}^\top.$$

Portanto, Equação 11.47 recupera o estimador do vetor de médias estudado em Proposição 10.6.

Além disso,

$$\text{Cov}(\bar{\mathbf{Y}}) = \frac{\Sigma}{n},$$

recuperando diretamente Equação 10.54.

O modelo contendo somente intercepto é, assim, um caso particular do problema de estimação desenvolvido no Capítulo 10. No modelo linear multivariado geral, a única média comum é substituída por vetores de médias que variam entre as unidades segundo os termos representados em $\mathbf{Z}$.

11.3 Valores ajustados, resíduos e projeções

A estimação de $\mathbf{B}$ determina uma matriz de médias ajustadas pertencente ao espaço coluna da matriz de delineamento. A projeção ortogonal sobre um espaço coluna foi estabelecida em Proposição 3.15.

Seja

$$r = \text{posto}(\mathbf{Z}).$$

O projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z})$$

pode ser escrito como

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+, \quad (11.48)$$

em que $\mathbf{Z}^+$ é a pseudoinversa de Moore–Penrose definida em Definição 6.11.

Essa expressão depende apenas do espaço coluna de $\mathbf{Z}$ e permanece válida mesmo quando $\mathbf{Z}$ não possui posto coluna completo. A questão da unicidade dos coeficientes será tratada posteriormente na seção sobre estimabilidade.

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

essa expressão reduz-se a

$$\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top. \quad (11.49)$$

O projetor sobre o complemento ortogonal é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z. \quad (11.50)$$

As propriedades gerais dos projetores ortogonais foram desenvolvidas em Proposição 3.15 e Definição 3.20. Em particular,

$$\mathbf{P}_Z^\top = \mathbf{P}_Z, \quad \mathbf{P}_Z^2 = \mathbf{P}_Z,$$

$$\mathbf{M}_Z^\top = \mathbf{M}_Z, \quad \mathbf{M}_Z^2 = \mathbf{M}_Z,$$

e

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{M}_Z \mathbf{P}_Z = \mathbf{0}. \quad (11.51)$$

Além disso,

$$\text{posto}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r. \quad (11.52)$$

Essas dimensões terão interpretação direta nos graus de liberdade associados ao ajuste e ao resíduo.

11.3.1 Valores ajustados e resíduos

Definição 11.9 (Valores ajustados). A matriz aleatória de valores ajustados é

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.53)$$

Após a observação,

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y}. \quad (11.54)$$

Como

$$\mathbf{P}_Z \mathbf{Z} = \mathbf{Z},$$

tem-se

$$\begin{aligned} \hat{\mathbf{y}} &= \mathbf{P}_Z (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{Z}\mathbf{B} + \mathbf{P}_Z \mathcal{E}. \end{aligned} \quad (11.55)$$

Portanto, os valores ajustados preservam a estrutura sistemática do modelo e incorporam a projeção dos erros sobre o espaço do delineamento.

Definição 11.10 (Resíduos). A matriz aleatória de resíduos é

$$\widehat{\mathcal{U}} = \mathcal{Y} - \widehat{\mathcal{Y}} = \mathbf{M}_Z \mathcal{Y}. \quad (11.56)$$

Após a observação,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} = \mathbf{M}_Z \mathbf{Y}. \quad (11.57)$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

segue que

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}. \quad (11.58)$$

Os resíduos são, portanto, a parcela dos erros pertencente ao complemento ortogonal de

$$\mathcal{C}(\mathbf{Z}).$$

Para cada realização,

$$\mathbf{Y} = \widehat{\mathbf{Y}} + \widehat{\mathbf{U}}. \quad (11.59)$$

A decomposição ocorre coluna a coluna: cada vetor de respostas observadas é separado em sua projeção sobre o espaço do modelo e em um resíduo ortogonal a esse espaço.

11.3.2 Ortogonalidade

As equações normais já forneceram

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Além disso,

$$\begin{aligned} \widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} &= \mathbf{Y}^\top \mathbf{P}_Z \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{0}. \end{aligned} \quad (11.60)$$

Assim, para quaisquer respostas j e k ,

$$\hat{\mathbf{y}}_{.j}^\top \hat{\mathbf{u}}_{.k} = 0.$$

A ortogonalidade não ocorre somente entre o ajuste e o resíduo da mesma resposta. Como o mesmo par de projetores atua sobre todas as colunas de $\mathbf{Y}$, qualquer coluna ajustada é ortogonal a qualquer coluna residual.

Consequentemente,

$$\|\mathbf{Y}\|_F^2 = \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2. \quad (11.61)$$

Essa identidade refere-se aos produtos internos em relação à origem. Quando o modelo contém intercepto, a decomposição da dispersão em torno do vetor de médias amostrais será expressa posteriormente por SQPCs.

11.3.3 Esperança dos valores ajustados e dos resíduos

Proposição 11.5 (Esperança dos valores ajustados e dos resíduos). *Sob*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

tem-se

$$E(\hat{\mathbf{y}} \mid \mathbf{Z}) = \mathbf{ZB} \quad (11.62)$$

e

$$E(\widehat{\mathbf{U}} \mid \mathbf{Z}) = \mathbf{0}. \quad (11.63)$$

De fato,

$$\begin{aligned} E(\hat{\mathbf{y}} \mid \mathbf{Z}) &= \mathbf{P}_Z E(\mathbf{y} \mid \mathbf{Z}) \\ &= \mathbf{P}_Z \mathbf{ZB} \\ &= \mathbf{ZB}, \end{aligned}$$

enquanto

$$\begin{aligned} E(\widehat{\mathcal{U}} \mid \mathbf{Z}) &= \mathbf{M}_Z \mathbf{Z} \mathbf{B} \\ &= \mathbf{0}. \end{aligned}$$

Os valores ajustados são, portanto, não viesados para a matriz de médias representável pelo modelo, enquanto os resíduos possuem média condicional nula.

11.3.4 Covariâncias dos valores ajustados e dos resíduos

A forma vetorizada permite obter diretamente suas matrizes de covariâncias.

Como

$$\text{vec}(\mathbf{P}_Z \mathcal{E}) = (\mathbf{I}_p \otimes \mathbf{P}_Z) \text{vec}(\mathcal{E}),$$

tem-se

Proposição 11.6 (Covariâncias dos valores ajustados e dos resíduos). *Sob*

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

vale

$$\text{Cov}[\text{vec}(\widehat{\mathcal{Y}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{P}_Z \tag{11.64}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathcal{U}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z. \tag{11.65}$$

Além disso,

$$\text{Cov}[\text{vec}(\widehat{\mathcal{Y}}), \text{vec}(\widehat{\mathcal{U}}) \mid \mathbf{Z}] = \mathbf{0}. \tag{11.66}$$

A última igualdade decorre de

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{0}.$$

Os valores ajustados e os resíduos são, portanto, não correlacionados. Sob o modelo normal matricial, eles são conjuntamente normais e, conseqüentemente, independentes. A utilização dessa independência na construção das distribuições amostrais será retomada no Capítulo 12.

As matrizes

$$\Sigma \otimes \mathbf{P}_Z$$

e

$$\Sigma \otimes \mathbf{M}_Z$$

também mostram que o ajuste pode induzir dependência entre valores ajustados ou resíduos associados a unidades distintas. Embora os erros originais sejam não correlacionados entre unidades, os valores ajustados e os resíduos resultam de projeções que utilizam conjuntamente todas as observações.

A análise de medidas de influência e alavancagem pertence ao diagnóstico de modelos e não será desenvolvida neste capítulo.

11.3.5 Representação dos ajustes e resíduos

A Figura 11.1 apresenta um modelo com uma variável explicativa e duas respostas. As duas colunas da matriz de respostas utilizam o mesmo espaço de ajuste, mas possuem coeficientes e resíduos próprios.

Os segmentos verticais representam os resíduos de cada resposta. O mesmo projetor $\mathbf{P}_Z$ determina as posições ajustadas nas duas colunas, enquanto a associação residual entre as respostas não é representada diretamente nos painéis.

Essa associação será resumida pela SQPC residual.




Figura 11.1: Valores observados, retas ajustadas e resíduos para duas respostas modeladas pela mesma variável explicativa.

11.3.6 Conexão com o modelo contendo somente intercepto

Quando

$$\mathbf{Z} = \mathbf{1}_n,$$

tem-se

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top = \mathbf{H}_n. \quad (11.67)$$

Assim,

$$\widehat{\mathbf{Y}} = \mathbf{1}_n \bar{\mathbf{y}}^\top,$$

enquanto

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y}.$$

A matriz residual coincide, nesse caso, com a matriz de respostas centralizada. Portanto, a centralização utilizada nos Capítulos 8 e 10 aparece como um caso particular da projeção residual no modelo linear multivariado.

A próxima seção utilizará

$$\widehat{\mathbf{U}}$$

para construir a SQPC residual, determinar seus graus de liberdade e estimar a matriz de covariâncias Σ .

11.4 SQPC residual e estimação da covariância

A matriz de resíduos

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{y}$$

contém os desvios das respostas em relação aos valores ajustados pelo modelo. Os produtos cruzados entre esses resíduos formam uma matriz que descreve a dispersão conjunta que permanece após o ajuste e permite estimar

$$\Sigma,$$

a matriz de covariâncias dos erros.

No modelo contendo somente intercepto, essa construção recupera a SQPC amostral dos Capítulos 8 e 10. No modelo linear geral, o ajuste remove um espaço de médias de dimensão

$$r = \text{posto}(\mathbf{Z}),$$

restando um espaço residual de dimensão $n - r$.

11.4.1 Construção da SQPC residual

Definição 11.11 (SQPC residual). A SQPC residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}}. \quad (11.68)$$

Como

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{Y},$$

e $\mathbf{M}_Z$ é simétrica e idempotente,

$$\mathbf{E}_{\text{res}} = \mathcal{Y}^\top \mathbf{M}_Z \mathcal{Y}. \quad (11.69)$$

Após a observação,

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.70)$$

O elemento (j, k) de $\mathbf{E}$ é

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}. \quad (11.71)$$

Para $j = k$,

$$e_{jj} = \sum_{i=1}^n \hat{u}_{ij}^2$$

é a soma de quadrados residual da resposta j . Para $j \neq k$, e_{jk} é o produto cruzado residual entre as respostas j e k .

Como

$$\mathcal{Y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

e

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathcal{E}, \quad (11.72)$$

e, conseqüentemente,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}. \quad (11.73)$$

A SQPC residual depende do espaço de médias removido pelo ajuste por meio de $\mathbf{M}_Z$, mas não depende do valor específico de $\mathbf{B}$.

Como toda matriz de Gram, $\mathbf{E}$ é simétrica e positiva semidefinida. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

$$\begin{aligned} \mathbf{a}^\top \mathbf{E} \mathbf{a} &= \|\widehat{\mathbf{U}} \mathbf{a}\|^2 \\ &\geq 0. \end{aligned} \quad (11.74)$$

A forma quadrática corresponde à soma de quadrados residual da combinação linear das respostas

$$\mathbf{Y} \mathbf{a}.$$

De fato,

$$\widehat{\mathbf{u}}_{\mathbf{a}} = \mathbf{M}_Z \mathbf{Y} \mathbf{a} = \widehat{\mathbf{U}} \mathbf{a},$$

e

$$\widehat{\mathbf{u}}_{\mathbf{a}}^\top \widehat{\mathbf{u}}_{\mathbf{a}} = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.75)$$

Se as respostas forem transformadas por

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{p \times s},$$

então

$$\widehat{\mathbf{U}}^* = \widehat{\mathbf{U}} \mathbf{A}$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (11.76)$$

Essa transformação é coerente com a regra populacional

$$\Sigma^* = \mathbf{A}^\top \Sigma \mathbf{A}$$

e será utilizada posteriormente em hipóteses sobre combinações das respostas.

11.4.2 Esperança e graus de liberdade

A dimensão do espaço residual é determinada pelo posto da matriz de delineamento.

Como

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z,$$

tem-se

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r.$$

Definição 11.12 (Graus de liberdade residuais). Se

$$r = \text{posto}(\mathbf{Z}),$$

os graus de liberdade residuais são

$$\nu_E = n - r. \quad (11.77)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e, portanto,

$$\nu_E = n - q.$$

A expressão utiliza r , e não simplesmente o número de colunas de $\mathbf{Z}$, porque somente as r direções linearmente independentes do espaço do modelo consomem graus de liberdade. Colunas redundantes não aumentam a dimensão do espaço de médias ajustado.

Proposição 11.7 (Esperança da SQPC residual). *Sob a estrutura do modelo linear multivariado,*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

com

$$r = \text{posto}(\mathbf{Z}),$$

tem-se

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \quad (11.78)$$

Comprovação. Pela Equação 11.73,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

Considere o elemento (j, k) :

$$[\mathbf{E}_{\text{res}}]_{jk} = \varepsilon_{\cdot j}^\top \mathbf{M}_Z \varepsilon_{\cdot k}.$$

Escrevendo

$$\mathbf{M}_Z = (m_{i\ell}),$$

obtém-se

$$[\mathbf{E}_{\text{res}}]_{jk} = \sum_{i=1}^n \sum_{\ell=1}^n m_{i\ell} \varepsilon_{ij} \varepsilon_{\ell k}.$$

Para $i \neq \ell$,

$$E(\varepsilon_{ij}\varepsilon_{\ell k} \mid \mathbf{Z}) = 0,$$

enquanto, para $i = \ell$,

$$E(\varepsilon_{ij}\varepsilon_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

Logo,

$$\begin{aligned} E\left[\left[\mathbf{E}_{\text{res}}\right]_{jk} \mid \mathbf{Z}\right] &= \sum_{i=1}^n m_{ii} \sigma_{jk} \\ &= \text{tr}(\mathbf{M}_Z) \sigma_{jk} \\ &= (n - r) \sigma_{jk}. \end{aligned}$$

Como a igualdade vale para todos os elementos,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma.$$

□

A expressão generaliza Proposição 10.10, que estabelece

$$E(\mathbf{T}) = (n - 1)\Sigma.$$

No modelo contendo somente intercepto,

$$r = 1,$$

de modo que

$$n - r = n - 1.$$

No modelo linear geral, cada direção independente utilizada para representar a estrutura de médias reduz em uma unidade a dimensão do espaço residual.

11.4.3 Estimação da covariância residual

Definição 11.13 (Estimador residual da matriz de covariâncias). Se

$$r = \text{posto}(\mathbf{Z})$$

e

$$n - r > 0,$$

define-se

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}. \quad (11.79)$$

Após a observação,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}. \quad (11.80)$$

Proposição 11.8 (Não viesamento do estimador residual). Se

$$r = \text{posto}(\mathbf{Z}), \quad n - r > 0,$$

e

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

então

$$E(\widehat{\Sigma} \mid \mathbf{Z}) = \Sigma. \quad (11.81)$$

Portanto, $\widehat{\Sigma}$ é um estimador não viesado da matriz de covariâncias dos erros.

Comprovação. Por Equação 11.79 e Equação 11.78,

$$\begin{aligned} E(\widehat{\Sigma} \mid \mathbf{Z}) &= \frac{1}{n-r} E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) \\ &= \frac{1}{n-r} (n-r) \Sigma \\ &= \Sigma. \end{aligned}$$

□

Componente a componente,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{e_{jk}}{n-r}. \quad (11.82)$$

Assim,

$$\hat{\sigma}_{jj,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij}^2$$

estima a variância residual da resposta j , enquanto, para $j \neq k$,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

estima a covariância residual entre as respostas j e k .

A matriz de correlações residuais pode ser obtida pela mesma padronização utilizada nos Capítulos 8 e 10, desde que as variâncias residuais estimadas sejam positivas. Não é necessário introduzir uma nova construção: aplica-se

$$\mathbf{D}^{-1/2} \widehat{\Sigma}_{\text{obs}} \mathbf{D}^{-1/2}$$

com a matriz diagonal correspondente às variâncias residuais estimadas.

Covariância total e covariância residual

A matriz de covariâncias calculada diretamente das respostas descreve a variabilidade conjunta observada antes do ajuste.

A matriz

$$\widehat{\Sigma}_{\text{obs}}$$

descreve a variabilidade que permanece depois de removida a estrutura de médias pertencente a

$$\mathcal{C}(\mathbf{Z}).$$

Por isso, em geral, as duas matrizes não coincidem.

11.4.4 Estimador de máxima verossimilhança

Sob o modelo normal matricial, depois da maximização em relação à estrutura de médias, a parte da log-verossimilhança que depende de Σ é, a menos de constantes,

$$\ell_c(\Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{E}). \quad (11.83)$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

o máximo no espaço

$$\Sigma \succ \mathbf{0}$$

é alcançado em

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}. \quad (11.84)$$

Como

$$E(\mathbf{E}_{\text{res}} | \mathbf{Z}) = (n - r)\Sigma,$$

a estatística com divisor n satisfaz

$$E\left(\frac{\mathbf{E}_{\text{res}}}{n} | \mathbf{Z}\right) = \frac{n - r}{n} \Sigma.$$

Portanto, seu viés é

$$-\frac{r}{n} \Sigma.$$

Assim, o divisor $n - r$ produz o estimador não viesado, enquanto o divisor n é utilizado pela máxima verossimilhança sob normalidade e existência do máximo. Essa relação generaliza Equação 10.72, na qual os divisores correspondentes são $n - 1$ e n .

Existência do estimador de máxima verossimilhança

A expressão

$$\frac{\mathbf{E}}{n}$$

é a estimativa de máxima verossimilhança de Σ no modelo normal não singular somente quando

$$\mathbf{E} \succ \mathbf{0}.$$

Se $\mathbf{E}$ é singular, a verossimilhança não possui máximo no interior do espaço

$$\Sigma \succ \mathbf{0}.$$

A matriz $\mathbf{E}/n$ continua sendo calculável, mas perde essa interpretação de máxima verossimilhança no modelo positivo definido.

11.4.5 Posto e singularidade

A SQPC residual possui a forma de Gram

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}.$$

Portanto,

$$\text{posto}(\mathbf{E}) = \text{posto}(\widehat{\mathbf{U}}).$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r,$$

obtém-se:

Proposição 11.9 (Posto da SQPC residual). *Se*

$$r = \text{posto}(\mathbf{Z}),$$

a SQPC residual observada

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}$$

satisfaz

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.85)$$

Consequentemente, se

$$p > n - r,$$

então $\mathbf{E}$ é necessariamente singular.

Uma condição necessária para

$$\mathbf{E} \succ \mathbf{0}$$

é

$$n - r \geq p. \quad (11.86)$$

Para uma amostra arbitrária, essa desigualdade não é suficiente: também é necessário

$$\text{posto}(\widehat{\mathbf{U}}) = p.$$

Portanto, uma condição necessária para que a SQPC residual seja positiva definida é haver pelo menos p dimensões residuais,

$$n - r \geq p.$$

A desigualdade, isoladamente, não garante posto completo em uma amostra arbitrária; também é necessário que os resíduos observados gerem p direções linearmente independentes.

O limite de posto é a extensão de Equação 10.81, que no caso de uma única média fornece

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Questões de condicionamento, pseudoinversa e regularização continuam pertinentes às matrizes residuais, mas não serão novamente desenvolvidas aqui. O condicionamento foi discutido em Equação 10.108, a pseudoinversa em Equação 10.117 e a regularização por contração em Definição 10.18.

11.4.6 Modelo contendo somente intercepto

Considere

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$r = 1,$$

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{H}_n.$$

Logo,

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y},$$

e a SQPC residual observada é

$$\begin{aligned} \mathbf{E} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \end{aligned} \tag{11.87}$$

Essa matriz é exatamente a SQPC total observada

$$\mathbf{T}$$

definida em Definição 8.10 e correspondente à realização da estatística aleatória definida em Definição 10.13.

Como

$$n - r = n - 1,$$

obtém-se

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - 1} = \mathbf{S}, \quad (11.88)$$

recuperando Definição 10.14.

Sob normalidade e quando a SQPC possui posto completo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n},$$

em concordância com Equação 10.44.

Portanto, no modelo contendo somente intercepto,

$$\mathbf{E} = \mathbf{T}$$

e

$$\frac{\mathbf{E}}{n - 1} = \mathbf{S}.$$

Assim, a SQPC residual e o estimador não viesado da covariância residual recuperam exatamente os objetos estudados nos Capítulos 8 e 10. O modelo linear multivariado substitui a remoção de uma única média pela remoção de toda a estrutura de médias representada por

$$\mathcal{C}(\mathbf{Z}).$$

A próxima seção separa a SQPC total em uma parcela associada ao modelo e uma parcela residual.

11.5 Decomposição da variação multivariada

Quando o espaço coluna de $\mathbf{Z}$ contém o vetor $\mathbf{1}_n$, a dispersão das respostas em torno do vetor de médias amostrais pode ser decomposta em uma parcela associada ao modelo e uma parcela residual. Essa condição é satisfeita, por exemplo, quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

No caso univariado, essa separação produz as somas de quadrados utilizadas na análise de variância. No modelo multivariado, cada parcela é representada por uma matriz SQPC, preservando também os produtos cruzados entre as respostas.

A principal decomposição é

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

em que $\mathbf{T}$ representa a dispersão total em torno da média geral, $\mathbf{T}_{\text{mod}}$ representa a dispersão dos valores ajustados em torno da média geral e $\mathbf{E}$ representa a dispersão residual em torno dos valores ajustados.

11.5.1 SQPC total

A SQPC total observada foi definida em Definição 8.10. Aplicada à matriz de respostas,

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y}, \quad (11.89)$$

em que $\mathbf{H}_n$ é a matriz de centralização utilizada em Equação 8.58:

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Equivalentemente,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top, \quad (11.90)$$

com

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n.$$

A matriz $\mathbf{T}$ descreve a dispersão conjunta das respostas antes da remoção da estrutura explicada pelo delineamento.

11.5.2 SQPC associada ao modelo

Suponha que a direção constante pertença ao espaço do modelo, isto é,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}). \quad (11.91)$$

Essa condição é satisfeita quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

Defina o projetor sobre o espaço das constantes por

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (11.92)$$

Como

$$\mathcal{C}(\mathbf{1}_n) \subseteq \mathcal{C}(\mathbf{Z}),$$

tem-se

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1. \quad (11.93)$$

Consequentemente,

$$\mathbf{P}_Z - \mathbf{P}_1$$

é o projetor ortogonal sobre a parte de $\mathcal{C}(\mathbf{Z})$ ortogonal à direção constante. Essa parte representa as variações ajustadas pelo modelo em torno da média geral.

Seu posto é

$$\text{posto}(\mathbf{P}_Z - \mathbf{P}_1) = r - 1, \quad (11.94)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Definição 11.14 (SQPC associada ao modelo, corrigida pela média geral). Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

define-se

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \quad (11.95)$$

em que $\mathbf{P}_Z$ é o projetor sobre $\mathcal{C}(\mathbf{Z})$ e

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

é o projetor sobre a direção constante.

Se

$$\mathcal{C}(\mathbf{Z}) = \mathcal{C}(\mathbf{1}_n),$$

então

$$\mathbf{P}_Z = \mathbf{P}_1$$

e, conseqüentemente,

$$\mathbf{T}_{\text{mod}} = \mathbf{0}.$$

Assim, $\mathbf{T}_{\text{mod}}$ quantifica somente a variação ajustada que excede a representação da média geral.

A matriz

$$\mathbf{T}_{\text{mod}}$$

mede a dispersão dos valores ajustados pelo modelo em torno da média geral. No modelo de grupos, essa matriz coincide com a dispersão entre grupos. Em modelos com covariáveis, ela representa conjuntamente a variação dos valores ajustados em torno da média geral.

Se

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y},$$

então os valores ajustados centralizados são

$$\widehat{\mathbf{Y}}_c = \widehat{\mathbf{Y}} - \mathbf{1}_n \bar{\mathbf{y}}^\top = (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

Logo,

$$\mathbf{T}_{\text{mod}} = \widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c. \quad (11.96)$$

Para qualquer combinação linear das respostas,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} = \|(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} \mathbf{a}\|^2. \quad (11.97)$$

Portanto, $\mathbf{T}_{\text{mod}}$ reúne, para todas as combinações lineares das respostas, as somas de quadrados dos valores ajustados em torno da respectiva média geral.

11.5.3 Decomposição entre modelo e resíduo

Sob a condição

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

considere

$$\mathbf{H}_n = \mathbf{I}_n - \mathbf{P}_1$$

e

$$\mathbf{I}_n = \mathbf{P}_Z + \mathbf{M}_Z.$$

segue que

$$\mathbf{H}_n = (\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z. \quad (11.98)$$

Além disso,

$$(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{M}_Z = \mathbf{0}.$$

Assim, as duas parcelas correspondem a subespaços ortogonais.

Proposição 11.10 (Decomposição da SQPC total). *Se*

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

então

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}, \quad (11.99)$$

em que

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Comprovação. Substituindo Equação 11.98 na definição de $\mathbf{T}$,

$$\begin{aligned} \mathbf{T} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \mathbf{Y}^\top [(\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z] \mathbf{Y} \\ &= \mathbf{T}_{\text{mod}} + \mathbf{E}. \end{aligned}$$

□

A decomposição pode ser escrita também como

$$\begin{aligned} &\sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top \\ &= \sum_{i=1}^n (\hat{\mathbf{y}}_i - \bar{\mathbf{y}}) (\hat{\mathbf{y}}_i - \bar{\mathbf{y}})^\top \\ &\quad + \sum_{i=1}^n (\mathbf{y}_i - \hat{\mathbf{y}}_i) (\mathbf{y}_i - \hat{\mathbf{y}}_i)^\top. \end{aligned} \quad (11.100)$$

A primeira parcela à direita é $\mathbf{T}_{\text{mod}}$ e a segunda é $\mathbf{E}$.

As dimensões dos subespaços correspondentes fornecem

$$n - 1 = (r - 1) + (n - r). \quad (11.101)$$

A Tabela 11.1 resume as dimensões dos três subespaços envolvidos.

Tabela 11.1: Decomposição das dimensões associadas à SQPC total quando a direção constante pertence ao espaço do modelo.

Fonte	Projetor	Graus de liberdade
Total corrigido pela média geral	$\mathbf{H}_n$	$n - 1$
Modelo corrigido pela média geral	$\mathbf{P}_Z - \mathbf{P}_1$	$r - 1$
Residual	$\mathbf{M}_Z$	$n - r$

Os graus de liberdade correspondem aos postos dos projetores no espaço das unidades. Eles não devem ser confundidos com os postos das matrizes de SQPC, que também dependem de p .

Em particular,

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{mod}}) \leq \min(p, r - 1),$$

e

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.102)$$

11.5.4 Combinações lineares das respostas

A decomposição matricial contém, simultaneamente, as decomposições correspondentes a todas as combinações lineares das respostas.

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} + \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.103)$$

Cada termo possui interpretação univariada:

$$\mathbf{a}^\top \mathbf{T} \mathbf{a}$$

é a soma de quadrados total de $\mathbf{Y}\mathbf{a}$,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a}$$

é a soma de quadrados associada ao modelo, e

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

é a soma de quadrados residual.

Essa relação é suficiente, neste capítulo, para mostrar como a decomposição matricial preserva simultaneamente as decomposições das respostas originais e de suas combinações lineares. A utilização conjunta dessas matrizes em procedimentos inferenciais será desenvolvida no Capítulo 12 e, posteriormente, na formulação das técnicas multivariadas.

11.5.5 Modelos sem intercepto

Se

$$\mathbf{1}_n \notin \mathcal{C}(\mathbf{Z}),$$

a decomposição corrigida

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}$$

não se aplica na forma anterior, porque $\mathbf{P}_Z - \mathbf{P}_1$ não é, em geral, um projetor.

Permanece válida a decomposição em relação à origem,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.104)$$

Essa identidade não deve ser interpretada como uma decomposição da dispersão em torno da média amostral. No restante deste capítulo, a decomposição total–modelo–resíduo será utilizada principalmente quando a direção constante pertence ao espaço coluna de $\mathbf{Z}$.

11.5.6 Modelo de grupos como caso particular

Considere K grupos não vazios. Uma parametrização particularmente simples utiliza uma coluna indicadora para cada grupo. Para três grupos, por exemplo, a matriz de delineamento possui a forma

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ \vdots & \vdots & \vdots \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ \vdots & \vdots & \vdots \\ 0 & 0 & 1 \end{bmatrix},$$

em que cada linha identifica o grupo da respectiva unidade.

Na parametrização por médias de grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

em que $\mathcal{J}_k$ representa o conjunto dos índices das unidades pertencentes ao grupo k . Assim,

$$E(\mathbf{Y}_i \mid i \in \mathcal{J}_k) = \mu_k.$$

O estimador de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} \bar{\mathbf{y}}_1^\top \\ \vdots \\ \bar{\mathbf{y}}_K^\top \end{bmatrix}. \quad (11.105)$$

Portanto, o vetor ajustado para cada unidade é a média amostral do grupo ao qual ela pertence.

A SQPC residual é

$$\mathbf{E} = \sum_{k=1}^K \sum_{i \in \mathcal{J}_k} (\mathbf{y}_i - \bar{\mathbf{y}}_k) (\mathbf{y}_i - \bar{\mathbf{y}}_k)^\top. \quad (11.106)$$

Pela definição de dispersão intragrupos em Definição 8.14,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}. \quad (11.107)$$

Assim, a SQPC residual do modelo de grupos mede exatamente a dispersão das observações em torno das médias de seus respectivos grupos.

A parcela associada ao modelo é

$$\mathbf{T}_{\text{mod}} = \sum_{k=1}^K n_k (\bar{\mathbf{y}}_k - \bar{\mathbf{y}}) (\bar{\mathbf{y}}_k - \bar{\mathbf{y}})^\top. \quad (11.108)$$

Por Definição 8.15,

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}. \quad (11.109)$$

Portanto,

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}, \quad (11.110)$$

recuperando Proposição 8.10 como um caso particular do modelo linear multivariado.

Os graus de liberdade também se decompõem como

$$n - 1 = (K - 1) + (n - K). \quad (11.111)$$

A Figura 11.2 representa geometricamente as duas parcelas dessa decomposição. Os segmentos que ligam cada observação à média de seu grupo representam desvios intragrupos, enquanto os segmentos tracejados que ligam as médias dos grupos à média geral representam os deslocamentos responsáveis pela dispersão entre grupos.

As cruzes representam as médias dos grupos e o asterisco representa a média geral. Os segmentos internos aos grupos visualizam os termos associados a $\mathbf{T}_{\text{intra}}$, enquanto os deslocamentos das médias dos grupos em relação à média geral visualizam a estrutura associada a $\mathbf{T}_{\text{entre}}$.

A decomposição depende do espaço de médias representado por $\mathbf{Z}$, e não de uma parametrização específica desse espaço. Essa distinção motiva a discussão de posto, parametrização e estimabilidade da próxima seção.




Figura 11.2: Dispersão intragrupos e deslocamento das médias dos grupos em relação à média geral.

11.6 Posto, parametrização e estimabilidade

A expressão

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

exige

$$\text{posto}(\mathbf{Z}) = q.$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente independentes e os coeficientes de $\mathbf{B}$ são determinados pela parametrização adotada.

Alguns modelos, especialmente aqueles que representam grupos ou fatores, podem ser escritos com colunas redundantes em $\mathbf{Z}$. Diferentes valores dos coeficientes podem então representar exatamente a mesma estrutura de médias

$$\mathbf{Z}\mathbf{B}.$$

Por isso, é necessário distinguir a unicidade dos coeficientes da unicidade dos valores ajustados e das combinações de parâmetros que se deseja interpretar.

11.6.1 Delineamento com posto deficiente

Considere

$$\mathbf{Z} \in \mathbb{R}^{n \times q}$$

com

$$r = \text{posto}(\mathbf{Z}) < q. \quad (11.112)$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente dependentes. Portanto, existe pelo menos um vetor não nulo

$$\mathbf{d} \in \mathbb{R}^q$$

tal que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Consequentemente, alterações dos coeficientes em direções pertencentes ao núcleo de $\mathbf{Z}$ não modificam a estrutura de médias.

Definição 11.15 (Matrizes de parâmetros equivalentes). Duas matrizes

$$\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{q \times p}$$

são equivalentes em relação a $\mathbf{Z}$ quando

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2. \quad (11.113)$$

Assim, quando $r < q$, os coeficientes individuais de $\mathbf{B}$ podem não ser únicos, embora a matriz de médias

$$\mathbf{Z}\mathbf{B}$$

continue unicamente determinada pelo modelo.

11.6.2 Pseudoinversa e unicidade do ajuste

A pseudoinversa de Moore–Penrose e sua relação com mínimos quadrados foram desenvolvidas em Definição 6.11 e Proposição 6.22.

Quando

$$r < q,$$

a matriz

$$\mathbf{Z}^\top \mathbf{Z}$$

é singular, mas o problema de mínimos quadrados continua tendo solução. Uma delas é

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}. \quad (11.114)$$

Proposição 11.11 (Unicidade dos valores ajustados sob posto deficiente). *Mesmo quando os coeficientes de mínimos quadrados não são únicos, todas as soluções produzem a mesma matriz de valores ajustados,*

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.115)$$

Consequentemente, também são únicos

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

e

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Portanto, a deficiência de posto pode impedir a interpretação única de determinados coeficientes sem impedir o cálculo dos valores ajustados, dos resíduos e da SQPC residual.

Os graus de liberdade residuais continuam sendo determinados pelo posto efetivo,

$$\nu_E = n - r,$$

e o estimador não viesado da covariância residual permanece

$$\hat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}.$$

11.6.3 Funções estimáveis

Quando os coeficientes de $\mathbf{B}$ não são individualmente identificados, ainda podem existir combinações deles que sejam determinadas unicamente pela estrutura de médias. Essas combinações são particularmente importantes em modelos com fatores, nos quais comparações entre grupos podem ser estimáveis mesmo quando uma parametrização utiliza coeficientes redundantes.

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina os termos do modelo representados nas linhas de $\mathbf{B}$.

Definição 11.16 (Função linear estimável). Para

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

a função

$$\mathbf{CB}$$

é estimável quando existe uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times g}$$

tal que

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{CB}$$

para toda matriz de parâmetros $\mathbf{B}$.

Como

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB},$$

a condição anterior equivale a

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}. \tag{11.116}$$

Portanto, a estimabilidade depende do espaço linha de $\mathbf{Z}$.

Proposição 11.12 (Caracterização das funções estimáveis). *Para*

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

são equivalentes:

1. $\mathbf{CB}$ é estimável;
2. as linhas de $\mathbf{C}$ pertencem ao espaço linha de $\mathbf{Z}$,

$$\mathcal{C}(\mathbf{C}^\top) \subseteq \mathcal{C}(\mathbf{Z}^\top);$$

3. vale

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

Em particular,

$$\mathbf{CB} \text{ é estimável} \iff \mathbf{C} = \mathbf{CZ}^+\mathbf{Z}. \quad (11.117)$$

Comprovação. Pela definição de estimabilidade, deve existir uma matriz $\mathbf{A}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z}.$$

Isso ocorre exatamente quando cada linha de $\mathbf{C}$ pertence ao espaço linha de $\mathbf{Z}$.

Como

$$\mathbf{Z}^+\mathbf{Z}$$

é o projetor ortogonal sobre esse espaço, a mesma condição pode ser escrita como

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

□

A caracterização também pode ser expressa diretamente em termos das parametrizações equivalentes.

Se

$$\mathbf{ZB}_1 = \mathbf{ZB}_2,$$

então

$$\mathbf{CB}$$

é estimável se

$$\mathbf{CB}_1 = \mathbf{CB}_2$$

para todas as matrizes de parâmetros equivalentes.

Isso ocorre precisamente porque $\mathbf{C}$ elimina as componentes pertencentes ao núcleo de $\mathbf{Z}$.

11.6.4 Estimador de uma função estimável

Quando $\mathbf{CB}$ é estimável, pode-se utilizar

$$\widehat{\Theta}_C = \mathbf{CZ}^+ \mathbf{y}. \quad (11.118)$$

Como

$$\mathbf{C} = \mathbf{CZ}^+ \mathbf{Z},$$

tem-se

$$E(\widehat{\Theta}_C | \mathbf{Z}) = \mathbf{CB}. \quad (11.119)$$

Portanto, uma função estimável possui o mesmo valor independentemente da representação utilizada para os coeficientes redundantes. Essa propriedade permitirá formular contrastes e hipóteses sobre efeitos do modelo sem depender da parametrização escolhida.

11.6.5 Parametrizações equivalentes

Diferentes matrizes de delineamento podem representar o mesmo conjunto de estruturas de médias.

Se

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \quad (11.120)$$

então

$$\mathbf{P}_{\mathbf{Z}_1} = \mathbf{P}_{\mathbf{Z}_2},$$

e, para a mesma matriz de respostas, os dois modelos produzem os mesmos valores ajustados, resíduos e SQPC residual.

Essa situação ocorre, por exemplo, quando um fator é representado por diferentes sistemas de codificação. Os coeficientes individuais podem mudar de interpretação, mas as médias ajustadas e os contrastes estimáveis permanecem os mesmos.

O objeto que caracteriza a estrutura de médias é, portanto,

$$\mathcal{C}(\mathbf{Z}),$$

e não uma lista específica de coeficientes.

Deficiência de posto e mau condicionamento são problemas distintos. A deficiência de posto corresponde a dependências lineares exatas entre as colunas de $\mathbf{Z}$; o mau condicionamento pode ocorrer mesmo com posto completo e tornar os coeficientes sensíveis a pequenas perturbações. O número de condição definido em Definição 6.9 e a SVD definida em Definição 6.3 podem ser utilizados no diagnóstico desse problema.

A distinção entre coeficientes individuais e funções estimáveis permite formular comparações que não dependem da parametrização adotada. Na próxima seção, essas comparações serão expressas como hipóteses lineares sobre os termos do modelo e sobre as respostas.

11.7 Hipóteses lineares multivariadas

O modelo linear multivariado permite formular hipóteses sobre termos do modelo, diferenças entre grupos e combinações das respostas. A formulação será construída progressivamente, começando por combinações das linhas de $\mathbf{B}$ e, depois, incorporando combinações de suas colunas (Rao, 1973; Rencher; Christensen, 2012).

11.7.1 Combinações dos termos do modelo

Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}.$$

A matriz

$$\mathbf{C}_1 \mathbf{B} \in \mathbb{R}^{g \times p}$$

combina os termos representados nas linhas de $\mathbf{B}$.

Se

$$\mathbf{c}_1^\top \in \mathbb{R}^{1 \times q}$$

é uma linha de $\mathbf{C}_1$, então

$$\mathbf{c}_1^\top \mathbf{B} \in \mathbb{R}^{1 \times p}$$

contém a mesma combinação dos termos para todas as p respostas.

Por exemplo, se a linha h de $\mathbf{B}$ corresponde a um único termo do modelo,

$$\mathbf{c}_1^\top = \mathbf{e}_h^\top$$

seleciona os coeficientes desse termo nas p respostas.

No modelo parametrizado diretamente pelas médias de K grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

uma combinação

$$\mathbf{c}_1^\top \mathbf{B} = \sum_{k=1}^K c_{1k} \mu_k^\top$$

é um contraste entre os vetores de médias quando

$$\sum_{k=1}^K c_{1k} = 0.$$

Por exemplo,

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

produz

$$\mathbf{c}_1^\top \mathbf{B} = (\mu_1 - \mu_2)^\top.$$

Assim, uma única linha de $\mathbf{C}_1$ pode representar uma comparação entre grupos, enquanto várias linhas permitem representar simultaneamente diferentes contrastes.

11.7.2 Combinações das respostas

A multiplicação à direita de $\mathbf{B}$ atua sobre as respostas. Considere

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

Então,

$$\mathbf{BC}_2 \in \mathbb{R}^{q \times s}$$

contém os efeitos do modelo sobre as s combinações de respostas definidas por $\mathbf{C}_2$.

Para uma única combinação, considere

$$\mathbf{c}_2 \in \mathbb{R}^p$$

e defina

$$W_i = \mathbf{c}_2^\top \mathbf{Y}_i.$$

Sua média condicional é

$$E(W_i | \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{BC}_2, \quad (11.121)$$

e sua variância residual é

$$\text{Var}(W_i | \mathbf{Z}) = \mathbf{c}_2^\top \Sigma \mathbf{c}_2. \quad (11.122)$$

Para várias combinações simultâneas,

$$\mathbf{y}_{C_2} = \mathbf{y} \mathbf{C}_2,$$

e

$$\mathbf{y}_{C_2} = \mathbf{Z}(\mathbf{BC}_2) + \mathcal{E} \mathbf{C}_2. \quad (11.123)$$

A matriz de covariâncias residuais correspondente é

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2. \quad (11.124)$$

Portanto, $\mathbf{C}_1$ atua sobre os termos do modelo e $\mathbf{C}_2$ atua sobre as respostas.

11.7.3 Hipótese linear geral

Combinando as duas operações anteriores, define-se

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 \in \mathbb{R}^{g \times s}, \quad (11.125)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

As linhas de Θ correspondem às combinações dos termos definidas por $\mathbf{C}_1$, enquanto suas colunas correspondem às combinações das respostas definidas por $\mathbf{C}_2$.

Definição 11.17 (Hipótese linear geral multivariada). Para

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

a hipótese linear geral é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0, \quad (11.126)$$

em que

$$\Theta_0 \in \mathbb{R}^{g \times s}$$

contém os valores especificados pela hipótese.

Quando

$$\Theta_0 = \mathbf{0},$$

obtém-se

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mathbf{0}. \quad (11.127)$$

Se

$$\mathbf{C}_2 = \mathbf{I}_p,$$

a hipótese envolve os termos do modelo em todas as respostas:

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0.$$

Se

$$g = s = 1,$$

obtém-se a hipótese escalar

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = \theta_0. \quad (11.128)$$

11.7.4 Estimabilidade da hipótese

A hipótese deve envolver uma combinação dos parâmetros determinada pelo modelo. Pela caracterização da seção anterior,

$$\mathbf{C}_1 \mathbf{B}$$

é estimável quando

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (11.129)$$

Nessa situação,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2 \quad (11.130)$$

é um estimador de

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2,$$

e, após a observação,

$$\widehat{\Theta}_{\text{obs}} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2. \quad (11.131)$$

Sua esperança condicional satisfaz

$$E(\widehat{\Theta} | \mathbf{Z}) = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2. \quad (11.132)$$

Para construir a SQPC associada à hipótese, defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}. \quad (11.133)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}_1^{\top}. \quad (11.134)$$

No caso escalar, com uma combinação dos termos $\mathbf{c}_1$ e uma combinação das respostas $\mathbf{c}_2$,

$$\text{Var}(\mathbf{c}_1^{\top} \widehat{\mathbf{B}} \mathbf{c}_2 \mid \mathbf{Z}) = [\mathbf{c}_1^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{c}_1] (\mathbf{c}_2^{\top} \Sigma \mathbf{c}_2), \quad (11.135)$$

quando $\mathbf{Z}$ possui posto coluna completo.

A primeira parcela depende do delineamento e da combinação dos termos do modelo; a segunda depende da variabilidade residual da combinação das respostas.

Para as construções seguintes, $\mathbf{C}_1$ será considerada sem linhas redundantes. Assim,

$$\text{posto}(\mathbf{C}_1) = g,$$

e os graus de liberdade associados à hipótese são

$$\nu_H = g. \quad (11.136)$$

11.7.5 SQPC da hipótese

A SQPC da hipótese representa o afastamento observado em relação à hipótese, ponderado pela variabilidade decorrente do delineamento.

Definição 11.18 (SQPC da hipótese linear). Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times s}.$$

Suponha que as combinações dos termos especificadas por $\mathbf{C}_1$ sejam estimáveis, isto é,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}.$$

Para a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

o afastamento observado é

$$\widehat{\Delta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2 - \Theta_0 \in \mathbb{R}^{g \times s}. \quad (11.137)$$

Defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \in \mathbb{R}^{g \times g}.$$

Quando

$$\mathbf{V}_{C_1} \succ \mathbf{0},$$

a **SQPC da hipótese linear** é

$$\mathbf{H} = \widehat{\Delta}^{\top} \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \in \mathbb{R}^{s \times s}. \quad (11.138)$$

A matriz

$$\mathbf{H} \in \mathbb{R}^{s \times s}$$

é simétrica e positiva semidefinida,

$$\mathbf{H} \succeq \mathbf{0},$$

e satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(g, s). \quad (11.139)$$

Se

$$\widehat{\Delta} = \mathbf{0},$$

então

$$\mathbf{H} = \mathbf{0}.$$

Para as mesmas combinações de respostas, a SQPC residual é

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2. \quad (11.140)$$

Portanto, a hipótese produz o par

$$(\mathbf{H}, \mathbf{E}_{C_2}).$$

A matriz $\mathbf{H}$ representa a variação associada ao afastamento da hipótese, enquanto $\mathbf{E}_{C_2}$ representa a variação residual das mesmas combinações de respostas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se simplesmente o par

$$(\mathbf{H}, \mathbf{E}),$$

que será utilizado posteriormente na MANOVA.

As distribuições amostrais dessas matrizes serão estudadas no Capítulo 12. Os critérios específicos que comparam $\mathbf{H}$ e $\mathbf{E}$ pertencem ao Módulo 3.

11.7.6 Modelos encaixados

Uma hipótese sobre determinados termos do modelo também pode ser representada pela comparação entre um modelo completo e um modelo reduzido (Christensen, 2011).

Considere matrizes de delineamento $\mathbf{Z}_F$ e $\mathbf{Z}_R$ tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F). \quad (11.141)$$

O modelo reduzido representa um subconjunto das estruturas de médias disponíveis no modelo completo.

Defina

$$r_F = \text{posto}(\mathbf{Z}_F) \quad \text{e} \quad r_R = \text{posto}(\mathbf{Z}_R).$$

Seus projetores são

$$\mathbf{P}_F = \mathbf{Z}_F \mathbf{Z}_F^+$$

e

$$\mathbf{P}_R = \mathbf{Z}_R \mathbf{Z}_R^+.$$

Como os espaços são encaixados,

$$\mathbf{P}_F - \mathbf{P}_R$$

é o projetor sobre as direções acrescentadas pelo modelo completo e possui posto

$$\text{posto}(\mathbf{P}_F - \mathbf{P}_R) = r_F - r_R. \quad (11.142)$$

As SQPCs residuais são

$$\mathbf{E}_F = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_F) \mathbf{Y}$$

e

$$\mathbf{E}_R = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_R) \mathbf{Y}.$$

Proposição 11.13 (Decomposição das SQPCs de modelos encaixados). *Se*

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

e $\mathbf{P}_R$ e $\mathbf{P}_F$ são os projetores sobre os espaços dos modelos reduzido e completo, respectivamente, então

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \quad (11.143)$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}. \quad (11.144)$$

Equivalentemente,

$$\mathbf{H} = \mathbf{E}_R - \mathbf{E}_F. \quad (11.145)$$

Portanto, $\mathbf{H}$ mede a redução da SQPC residual obtida quando as direções presentes no modelo completo são acrescentadas ao modelo reduzido.

Os graus de liberdade correspondentes são

$$\nu_H = r_F - r_R \quad (11.146)$$

e

$$\nu_E = n - r_F. \quad (11.147)$$

Para combinações de respostas definidas por $\mathbf{C}_2$,

$$\mathbf{H}_{C_2} = \mathbf{C}_2^\top \mathbf{H} \mathbf{C}_2$$

e

$$\mathbf{E}_{F,C_2} = \mathbf{C}_2^\top \mathbf{E}_F \mathbf{C}_2. \quad (11.148)$$

A formulação por $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ identifica a função paramétrica examinada; a formulação por modelos encaixados mostra quanto a inclusão dos termos correspondentes reduz a variação residual.

11.7.7 Casos particulares

A forma geral inclui diferentes perguntas sem necessidade de construir uma notação específica para cada uma.

11.7.7.1 Comparação entre vetores de médias de grupos

Na parametrização por médias de grupos, considere

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} = \mathbf{0}^\top$$

equivale a

$$H_0 : \mu_1 = \mu_2. \quad (11.149)$$

Várias linhas em $\mathbf{C}_1$ permitem representar simultaneamente diferentes contrastes entre grupos. Essa é a estrutura que será utilizada posteriormente na MANOVA.

11.7.7.2 Efeito de um termo em todas as respostas

Se a linha h de $\mathbf{B}$ representa um termo específico do modelo, tome

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} = \mathbf{0}^\top \quad (11.150)$$

afirma que esse termo possui coeficiente nulo para todas as respostas.

11.7.7.3 Efeito sobre uma combinação das respostas

Para

$$\mathbf{c}_1 \in \mathbb{R}^q$$

e

$$\mathbf{c}_2 \in \mathbb{R}^p,$$

a hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = 0 \quad (11.151)$$

examina o efeito definido por $\mathbf{c}_1$ sobre a combinação de respostas definida por $\mathbf{c}_2$.

Por exemplo,

$$\mathbf{c}_2 = \mathbf{e}_j - \mathbf{e}_k$$

representa a diferença entre as respostas j e k .

11.7.7.4 Igualdade do efeito em duas respostas

Tomando

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$H_0 : \mathbf{e}_h^\top \mathbf{B} (\mathbf{e}_j - \mathbf{e}_k) = 0, \quad (11.152)$$

equivalente a

$$H_0 : \beta_{hj} = \beta_{hk}.$$

Esses casos mostram a função das duas matrizes. A matriz $\mathbf{C}_1$ combina termos do modelo, enquanto $\mathbf{C}_2$ combina respostas.

A estrutura que seguirá para o Capítulo 12 é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

acompanhada das matrizes SQPC associadas à hipótese e ao resíduo.

11.8 Exemplo integrado

Exemplo 11.1 (Regressão multivariada com uma covariável e duas respostas). Considere seis unidades. Para cada unidade, registra-se uma variável explicativa quantitativa x e duas respostas Y_1 e Y_2 .

Unidade	x	Y_1	Y_2
1	1	3	8
2	2	5	7
3	3	4	7
4	4	8	5
5	5	9	4
6	6	11	3

A matriz observada de respostas é

$$\mathbf{Y} = \begin{bmatrix} 3 & 8 \\ 5 & 7 \\ 4 & 7 \\ 8 & 5 \\ 9 & 4 \\ 11 & 3 \end{bmatrix},$$

e a matriz de delineamento, contendo intercepto e a covariável, é

$$\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{bmatrix}. \quad (11.153)$$

Nesse modelo,

$$\mathbf{B} = \begin{bmatrix} \beta_{01} & \beta_{02} \\ \beta_{11} & \beta_{12} \end{bmatrix},$$

em que a primeira linha contém os interceptos e a segunda contém os efeitos de x sobre as duas respostas.

Como

$$q = 2$$

e

$$\text{posto}(\mathbf{Z}) = 2,$$

a matriz de delineamento possui posto coluna completo. Portanto, $\mathbf{Z}^\top \mathbf{Z}$ é invertível e a estimativa de mínimos quadrados de $\mathbf{B}$ é única.

Tem-se

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 6 & 21 \\ 21 & 91 \end{bmatrix}$$

e

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{105} \begin{bmatrix} 91 & -21 \\ -21 & 6 \end{bmatrix}.$$

Estimação da matriz de parâmetros

A estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Numericamente,

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 16/15 & 139/15 \\ 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,067 & 9,267 \\ 1,600 & -1,029 \end{bmatrix}. \quad (11.154)$$

Portanto, as equações ajustadas são

$$\hat{Y}_1 = 1,067 + 1,600x$$

e

$$\hat{Y}_2 = 9,267 - 1,029x.$$

Para um aumento de uma unidade em x , a média ajustada de Y_1 aumenta em aproximadamente 1,600, enquanto a média ajustada de Y_2 diminui em aproximadamente 1,029.

A Figura 11.3 mostra simultaneamente as duas respostas, seus ajustes e os respectivos resíduos.




Figura 11.3: Respostas observadas, ajustes lineares e resíduos do exemplo integrado.

A figura evidencia as inclinações em sentidos opostos das duas respostas. Os segmentos tracejados ligam cada observação ao valor ajustado correspondente e representam graficamente os resíduos que serão reunidos na matriz $\widehat{\mathbf{U}}$.

A matriz de valores ajustados é

$$\widehat{\mathbf{Y}} = \mathbf{Z}\widehat{\mathbf{B}}_{\text{obs}} \approx \begin{bmatrix} 2,667 & 8,238 \\ 4,267 & 7,210 \\ 5,867 & 6,181 \\ 7,467 & 5,152 \\ 9,067 & 4,124 \\ 10,667 & 3,095 \end{bmatrix}. \quad (11.155)$$

Consequentemente,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} \approx \begin{bmatrix} 0,333 & -0,238 \\ 0,733 & -0,210 \\ -1,867 & 0,819 \\ 0,533 & -0,152 \\ -0,067 & -0,124 \\ 0,333 & -0,095 \end{bmatrix}. \quad (11.156)$$

As equações normais garantem

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Em particular, como o modelo contém intercepto, os resíduos somam zero em cada resposta.

SQPC residual e covariância residual

A SQPC residual é

$$\begin{aligned} \mathbf{E} &= \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \\ &= \begin{bmatrix} 68/15 & -28/15 \\ -28/15 & 86/105 \end{bmatrix} \\ &\approx \begin{bmatrix} 4,533 & -1,867 \\ -1,867 & 0,819 \end{bmatrix}. \end{aligned} \quad (11.157)$$

Como

$$n = 6$$

e

$$r = 2,$$

os graus de liberdade residuais são

$$\nu_E = n - r = 4.$$

A estimativa não viesada da matriz de covariâncias residual é

$$\begin{aligned}\widehat{\Sigma}_{\text{obs}} &= \frac{\mathbf{E}}{4} \\ &= \begin{bmatrix} 17/15 & -7/15 \\ -7/15 & 43/210 \end{bmatrix} \\ &\approx \begin{bmatrix} 1,133 & -0,467 \\ -0,467 & 0,205 \end{bmatrix}.\end{aligned}\tag{11.158}$$

A covariância residual estimada é negativa. Isso indica que, depois de removida a relação linear com x , desvios positivos de uma resposta tendem a ocorrer juntamente com desvios negativos da outra neste conjunto de dados.

Sob o modelo normal matricial, como $\mathbf{E} \succ \mathbf{0}$, a estimativa de máxima verossimilhança é

$$\begin{aligned}\widehat{\Sigma}_{\text{MV,obs}} &= \frac{\mathbf{E}}{6} \\ &\approx \begin{bmatrix} 0,756 & -0,311 \\ -0,311 & 0,137 \end{bmatrix}.\end{aligned}\tag{11.159}$$

A diferença entre as duas estimativas decorre dos divisores:

$$n - r = 4$$

para o estimador não viesado e

$$n = 6$$

para a máxima verossimilhança sob normalidade.

Decomposição da SQPC total

Como o modelo contém intercepto,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

A SQPC total é

$$\mathbf{T} = \begin{bmatrix} 148/3 & -92/3 \\ -92/3 & 58/3 \end{bmatrix} \approx \begin{bmatrix} 49,333 & -30,667 \\ -30,667 & 19,333 \end{bmatrix}. \quad (11.160)$$

A parcela associada à covariável, além do intercepto, é

$$\mathbf{T}_{\text{mod}} = \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \quad (11.161)$$

Utilizando os valores exatos das matrizes,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

Assim, a dispersão total em torno da média é decomposta na parcela associada à covariável e na parcela residual.

Os graus de liberdade apresentam a decomposição correspondente:

$$5 = 1 + 4,$$

isto é,

$$n - 1 = (r - 1) + (n - r).$$

Hipótese sobre o efeito da covariável

Considere a hipótese de que x não apresenta efeito linear sobre nenhuma das duas respostas.

Para seleccionar a segunda linha de $\mathbf{B}$, defina

$$\mathbf{C}_1 = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Como as duas respostas são mantidas,

$$\mathbf{C}_2 = \mathbf{I}_2.$$

A hipótese é

$$H_0 : \mathbf{C}_1 \mathbf{B} = \mathbf{0}^\top,$$

ou, equivalentemente,

$$H_0 : \beta_{11} = \beta_{12} = 0. \quad (11.162)$$

O afastamento observado em relação à hipótese nula é

$$\widehat{\Delta} = \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} = [8/5 \quad -36/35] \approx [1,600 \quad -1,029]. \quad (11.163)$$

Nesse caso, $\widehat{\Delta}$ é exatamente o vetor formado pelas duas inclinações estimadas, pois a hipótese especifica que ambas devem ser iguais a zero.

A matriz associada à variabilidade desse contraste é escalar:

$$\begin{aligned} \mathbf{V}_{C_1} &= \mathbf{C}_1 (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}_1^\top \\ &= \frac{2}{35} \\ &\approx 0,057. \end{aligned} \quad (11.164)$$

A SQPC da hipótese é

$$\begin{aligned} \mathbf{H} &= \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \\ &= \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \\ &\approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \end{aligned} \quad (11.165)$$

Nesse caso,

$$\mathbf{H} = \mathbf{T}_{\text{mod}}.$$

O modelo completo contém intercepto e covariável, enquanto o modelo sob H_0 contém apenas o intercepto. Portanto, $\mathbf{H}$ representa exatamente a redução da SQPC residual obtida pela inclusão da covariável.

Como o modelo reduzido contém somente a média geral,

$$\mathbf{E}_R = \mathbf{T},$$

e

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}.$$

Assim, a hipótese sobre a covariável produz o par

$$(\mathbf{H}, \mathbf{E}),$$

formado pela variação associada ao efeito examinado e pela variação residual.

A decisão inferencial sobre essa hipótese será construída no Capítulo 12.

Hipótese sobre uma combinação das respostas

A mesma estrutura permite avaliar o efeito da covariável sobre uma combinação específica das respostas.

Considere

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A resposta transformada é

$$Y_1 - Y_2.$$

A hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{c}_2 = 0 \tag{11.166}$$

afirma que a covariável não apresenta efeito sobre a diferença entre as duas respostas.

A estimativa é

$$\begin{aligned} \hat{\theta} &= \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} \mathbf{c}_2 \\ &= \frac{92}{35} \\ &\approx 2,629. \end{aligned}$$

Como

$$V_{C_1} = \frac{2}{35},$$

a SQPC da hipótese para essa combinação de respostas é o escalar

$$\begin{aligned} H_{c_2} &= \frac{\hat{\theta}^2}{V_{C_1}} \\ &= \frac{4232}{35} \\ &\approx 120,914. \end{aligned}$$

A SQPC residual dessa resposta transformada é

$$\begin{aligned} E_{c_2} &= \mathbf{c}_2^\top \mathbf{E} \mathbf{c}_2 \\ &= \frac{318}{35} \\ &\approx 9,086. \end{aligned} \tag{11.167}$$

A hipótese sobre a diferença $Y_1 - Y_2$ produz, portanto, o par escalar

$$(H_{c_2}, E_{c_2}) = \left(\frac{4232}{35}, \frac{318}{35} \right).$$

O exemplo mostra duas formas de utilizar o mesmo ajuste. Com $\mathbf{C}_2 = \mathbf{I}_2$, examina-se simultaneamente o efeito da covariável nas duas respostas. Com

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

examina-se o efeito da covariável sobre a diferença entre elas.

A construção das estatísticas de teste a partir desses pares pertence aos capítulos posteriores.

Neste exemplo, uma única matriz de delineamento produziu sucessivamente

$$\widehat{\mathbf{B}}_{\text{obs}}, \quad \widehat{\mathbf{Y}}, \quad \widehat{\mathbf{U}}, \quad \mathbf{E}, \quad \widehat{\Sigma}_{\text{obs}}$$

e as matrizes associadas às hipóteses examinadas. No modelo de grupos desenvolvido anteriormente, a mesma estrutura produz

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{H} = \mathbf{T}_{\text{entre}}$$

quando a hipótese compara os vetores de médias dos grupos. Essa correspondência será utilizada posteriormente na MANOVA e na Análise Discriminante.

11.9 Síntese do capítulo

O modelo linear multivariado representa conjuntamente p respostas observadas nas mesmas n unidades:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz $\mathbf{Z}$ contém os q termos do modelo, $\mathbf{B}$ determina seus efeitos sobre as p respostas e

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}$$

é a estrutura de médias condicionais. A matriz

$$\Sigma$$

descreve a covariância residual entre as respostas de uma mesma unidade.

Quando $\mathbf{Z}$ possui posto coluna completo, a matriz de parâmetros é estimada por

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

O ajuste depende do espaço coluna de $\mathbf{Z}$. Os valores ajustados e os resíduos são

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}$$

e

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y},$$

com

$$\mathbf{P}_Z + \mathbf{M}_Z = \mathbf{I}_n.$$

Assim, cada resposta é decomposta em uma parcela pertencente ao espaço do modelo e uma parcela residual.

A SQPC residual

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{U}}^{\top} \widehat{\mathbf{U}}$$

satisfaz

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Assim,

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

é um estimador não viesado da matriz de covariâncias residual.

Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

a dispersão em torno da média geral satisfaz

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

com graus de liberdade

$$n - 1 = (r - 1) + (n - r).$$

No modelo de grupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}},$$

de modo que

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}.$$

Assim, Proposição 8.10 passa a ser representada como um caso particular da decomposição de um modelo de médias. Essa correspondência fornece a estrutura matricial utilizada posteriormente na ANOVA/MANOVA e na Análise Discriminante.

Quando

$$\text{posto}(\mathbf{Z}) < q,$$

os coeficientes podem não ser únicos, embora os valores ajustados e os resíduos permaneçam determinados pelo espaço coluna de $\mathbf{Z}$. As comparações de interesse devem então ser formuladas por funções estimáveis, como

$$\mathbf{CB},$$

com

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A hipótese linear multivariada geral é

$$H_0 : \mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0.$$

A matriz $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas. A hipótese produz duas matrizes construídas sobre as mesmas combinações de respostas:

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta}$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2.$$

A primeira representa a variação associada ao afastamento da hipótese; a segunda representa a variação residual correspondente. Quando $\mathbf{C}_2 = \mathbf{I}_p$, obtém-se o par

$$(\mathbf{H}, \mathbf{E}),$$

que será utilizado posteriormente na MANOVA.

A Tabela 11.3 reúne os principais objetos utilizados no capítulo.

Tabela 11.3: Principais objetos do modelo linear multivariado.

Objeto	Expressão	Papel
estrutura de médias	$\mathbf{ZB}$	determina os vetores de médias permitidos pelo modelo
estimador dos parâmetros	$\widehat{\mathbf{B}}$	estima os coeficientes associados aos termos e às respostas
projektor do modelo	$\mathbf{P}_Z$	produz os valores ajustados
projektor residual	$\mathbf{M}_Z$	produz os resíduos
SQPC residual	$\mathbf{E}$	representa a variação que permanece após o ajuste
SQPC do modelo	$\mathbf{T}_{\text{mod}}$	representa a dispersão dos valores ajustados em torno da média geral
modelo de grupos	$\mathbf{E} = \mathbf{T}_{\text{intra}}, \mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}$	relaciona o modelo linear à decomposição intra e entre grupos
função estimável	$\mathbf{CB}$	representa comparações determinadas pelo modelo
hipótese geral	$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$	combina termos do modelo e respostas
SQPC da hipótese	$\mathbf{H}$	representa a variação associada ao afastamento da hipótese

Ao concluir este capítulo, o estudante deve ser capaz de:

- formular um modelo linear para várias respostas e interpretar $\mathbf{Z}$, $\mathbf{B}$ e Σ ;
- obter valores ajustados e resíduos por meio das projeções associadas a $\mathbf{Z}$;
- construir a SQPC residual e estimar a matriz de covariâncias dos erros;
- decompor a dispersão total em parcelas associada ao modelo e residual;
- relacionar, no modelo de grupos, as matrizes $\mathbf{H}$ e $\mathbf{E}$ às dispersões entre e dentro dos grupos;

- distinguir unicidade dos coeficientes de estimabilidade de combinações dos parâmetros;
- interpretar a função de $\mathbf{C}_1$ e de $\mathbf{C}_2$ em uma hipótese linear;
- formular hipóteses na forma $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$ e construir as SQPCs correspondentes.

Este capítulo construiu os estimadores, as projeções e as matrizes SQPC que representam a variação associada ao modelo, ao resíduo e às hipóteses lineares. O Capítulo 12 desenvolverá as distribuições amostrais desses objetos e mostrará como utilizá-los na construção de testes e regiões de confiança no contexto multivariado.

12 Inferência Multivariada

Os capítulos anteriores construíram os objetos sobre os quais será formulada a inferência multivariada. A matriz de covariâncias populacional foi definida em Definição 8.2, a distribuição normal multivariada em Definição 9.1, o vetor de médias amostral e suas propriedades em Proposição 10.6, e a matriz de covariâncias amostral em Definição 10.14. O modelo linear multivariado foi definido em Definição 11.3 e sua hipótese linear geral em Definição 11.17.

O objetivo deste capítulo é obter distribuições amostrais para esses objetos e utilizá-las na construção de testes de hipóteses e regiões de confiança. A distribuição de Wishart descreverá as matrizes SQPC sob normalidade, enquanto a estatística T^2 de Hotelling permitirá realizar inferência sobre vetores de médias quando a matriz de covariâncias populacional é desconhecida.

Os resultados exatos serão desenvolvidos principalmente sob normalidade multivariada. Resultados assintóticos serão utilizados quando a distribuição exata não estiver disponível ou quando o objetivo for descrever o comportamento limite das estatísticas. As duas situações serão distinguidas porque dependem de condições diferentes.

O capítulo também obterá as distribuições dos estimadores e das matrizes SQPC construídas no modelo linear multivariado. Esses resultados encerram a base probabilística e inferencial do Módulo 2 e serão utilizados na formulação das técnicas do Módulo 3.

Convenções de notação

Neste capítulo:

- $\bar{\mathbf{X}}$ representa o vetor de médias amostral como estatística aleatória e $\bar{\mathbf{x}}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória e $\mathbf{S}$ sua realização observada;
- $\mathbf{T}$ representa a SQPC amostral aleatória e $\mathbf{T}$ sua realização observada;
- $\mathbf{W}$ representa uma matriz aleatória com distribuição de Wishart;
- $\mathbf{E}_{\text{res}}$ e $\mathbf{E}$ representam, respectivamente, a SQPC residual aleatória e sua realização observada;
- $\mathbf{H}$ e $\mathbf{H}$ representam, respectivamente, a SQPC da hipótese aleatória e sua realização observada;
- $\mathbf{Z}$ continua representando a matriz de delineamento do modelo linear multivariado;
- $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas nas hipóteses lineares

definidas no Capítulo 11;

- $\mathbf{M}_Z$ permanece reservada ao projetor residual;
- $\mathbf{A}$ será utilizada posteriormente para formular hipóteses lineares diretamente sobre o vetor de médias.

As convenções preservam a distinção entre objetos populacionais, estatísticas aleatórias e realizações observadas estabelecida nos capítulos anteriores.

12.1 Distribuições amostrais exatas e assintóticas

A inferência estatística utiliza a distribuição amostral de uma estatística para quantificar sua variabilidade e calibrar procedimentos como testes e regiões de confiança. Essa distribuição pode ser conhecida exatamente sob um modelo probabilístico especificado ou aproximada por seu comportamento limite quando o tamanho amostral cresce.

Definição 12.1 (Resultados exatos e assintóticos). Um **resultado exato** é válido para o tamanho amostral considerado sem recorrer a um argumento limite. Quando o resultado é distribucional, ele fornece a distribuição da estatística sob as hipóteses probabilísticas especificadas.

Um **resultado assintótico** descreve o comportamento limite de uma estatística quando o tamanho amostral tende ao infinito. Sua utilização em amostras finitas constitui uma aproximação cuja qualidade depende das condições do problema.

Neste capítulo, os resultados exatos dependerão principalmente da normalidade multivariada. Os resultados assintóticos considerarão, salvo indicação em contrário, o regime

$$p \text{ fixo} \quad \text{e} \quad n \rightarrow \infty. \quad (12.1)$$

Essa distinção deve ser mantida também na interpretação: uma distribuição exata decorre do modelo probabilístico especificado, enquanto uma distribuição limite decorre de um argumento de convergência.

12.1.1 Distribuição da média amostral sob normalidade

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

independente e identicamente distribuída, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

O vetor de médias amostral é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Por Proposição 10.6,

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Esses resultados dependem dos momentos correspondentes, mas não da normalidade multivariada.

A normalidade acrescenta a distribuição exata da estatística.

Proposição 12.1 (Distribuição da média amostral sob normalidade). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

então

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.2)$$

O resultado é exato para qualquer $n \geq 1$.

Comprovação. A média amostral é uma combinação linear dos vetores normais independentes. Por Proposição 9.4, sua distribuição é normal multivariada.

Como Proposição 10.6 fornece

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

obtem-se Equação 12.2. □

A proposição mostra a diferença entre propriedades de um estimador e sua distribuição amostral. A igualdade

$$E(\bar{\mathbf{X}}) = \mu$$

expressa ausência de viés. Já

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

descreve toda a distribuição da estatística sob o modelo normal.

Se

$$\Sigma \succ \mathbf{0},$$

a média amostral pode ser branqueada:

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (12.3)$$

Aplicando o resultado qui-quadrado da distância de Mahalanobis estabelecido em Proposição 9.8,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \sim \chi_p^2. \quad (12.4)$$

O fator n aparece porque

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

de modo que

$$\left(\frac{\Sigma}{n}\right)^{-1} = n\Sigma^{-1}.$$

A expressão em Equação 12.4 fornece a base do procedimento inferencial para o vetor de médias quando Σ é conhecida. O caso em que Σ precisa ser estimada exigirá a distribuição da matriz de covariâncias amostral.

12.1.2 Teorema Central do Limite multivariado

Fora da família normal, a distribuição de

$$\bar{\mathbf{X}}$$

depende da distribuição conjunta da população. Em dimensão fixa, o Teorema Central do Limite multivariado fornece uma aproximação normal sob condições mais gerais (Vaart, 1998).

Teorema 12.1 (Teorema Central do Limite multivariado). *Considere, para dimensão fixa p , vetores aleatórios independentes e identicamente distribuídos*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu$$

e matriz de covariâncias finita

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma). \quad (12.5)$$

Comprovação. Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

considere

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \mu).$$

As variáveis

$$\mathbf{a}^\top \mathbf{X}_1, \dots, \mathbf{a}^\top \mathbf{X}_n$$

são independentes e identicamente distribuídas, com média

$$\mathbf{a}^\top \mu$$

e variância finita

$$\mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema Central do Limite univariado,

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Como a convergência vale para todo vetor fixo $\mathbf{a}$, o Teorema de Cramér–Wold em Teorema 9.1 implica Equação 12.5. $\square$

O resultado permite escrever, em sentido assintótico,

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right). \quad (12.6)$$

A mesma expressão possui, portanto, dois significados distintos:

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma distribuição **exata** quando a população é normal multivariada, enquanto

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma aproximação **assintótica** sob as condições do Teorema 12.1.

Se

$$\Sigma \succ \mathbf{0},$$

então

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \mathbf{I}_p), \quad (12.7)$$

e, pelo teorema da aplicação contínua,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} \chi_p^2. \quad (12.8)$$

Assim, a mesma forma quadrática possui distribuição qui-quadrado exata sob normalidade e distribuição limite qui-quadrado sob as condições do TCL multivariado.

Alcance da aproximação assintótica

O Teorema 12.1 considera dimensão p fixa e exige a existência dos momentos de segunda ordem.

O resultado não justifica automaticamente a inferência clássica quando há dependência entre unidades, inexistência de segundos momentos ou crescimento de p juntamente com n . Além disso, a substituição de Σ por uma matriz de covariâncias estimada introduz outra fonte de aleatoriedade que precisa ser considerada separadamente.

A distribuição da média amostral descreve a incerteza associada à localização. Quando Σ é desconhecida, a inferência depende também da distribuição da matriz que estima a dispersão. Sob normalidade multivariada, essa distribuição é obtida a partir da distribuição de Wishart.

12.2 Distribuição de Wishart

A inferência sobre uma matriz de covariâncias exige conhecer a distribuição das matrizes de produtos cruzados que a originam. No caso univariado, somas de quadrados de variáveis normais padronizadas conduzem à distribuição qui-quadrado. A distribuição de Wishart estende essa construção para somas de produtos externos de vetores normais e ocupa, na inferência normal multivariada, papel análogo ao da distribuição qui-quadrado na inferência univariada (Muirhead, 1982).

12.2.1 Construção e parametrização

Considere vetores aleatórios independentes

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \in \mathbb{R}^p$$

tais que

$$\mathbf{U}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 1, \dots, \nu,$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0}.$$

Cada produto externo

$$\mathbf{U}_j \mathbf{U}_j^\top$$

é uma matriz simétrica e positiva semidefinida.

Definição 12.2 (Distribuição de Wishart). Se

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma),$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0},$$

então a matriz aleatória

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{U}_j \mathbf{U}_j^{\top} \quad (12.9)$$

segue uma distribuição de Wishart com ν graus de liberdade e matriz de escala Σ .

Escreve-se

$$\mathbf{W} \sim W_p(\nu, \Sigma). \quad (12.10)$$

Nesta parametrização,

$$\Sigma$$

é denominada **matriz de escala** e ν é o número de graus de liberdade. A relação

$$E(\mathbf{W}) = \nu \Sigma$$

será estabelecida em Proposição [12.3](#).

A parametrização é indicada explicitamente porque diferentes convenções para a matriz de escala podem ser encontradas na literatura.

Quando

$$p = 1,$$

a matriz Wishart possui um único elemento. Se

$$\Sigma = [\sigma^2],$$

então

$$W = \sum_{j=1}^{\nu} U_j^2$$

e

$$\frac{W}{\sigma^2} \sim \chi_{\nu}^2. \quad (12.11)$$

Assim, a distribuição qui-quadrado é o caso univariado da distribuição de Wishart.

12.2.2 Suporte, posto e definição positiva

Organize os vetores geradores nas linhas da matriz

$$\mathcal{U} = \begin{bmatrix} \mathbf{U}_1^\top \\ \vdots \\ \mathbf{U}_\nu^\top \end{bmatrix} \in \mathbb{R}^{\nu \times p}.$$

Então,

$$\mathbf{W} = \mathcal{U}^\top \mathcal{U}. \quad (12.12)$$

Portanto, $\mathbf{W}$ é uma matriz de Gram no sentido de Definição 3.18. Por Proposição 3.9,

$$\mathbf{W} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{W}) = \text{posto}(\mathcal{U}) \leq \min(\nu, p).$$

Proposição 12.2 (Posto de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, com

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade 1,

$$\text{posto}(\mathbf{W}) = \min(\nu, p). \quad (12.13)$$

Consequentemente:

- se $\nu \geq p$, então $\mathbf{W} \succ \mathbf{0}$ com probabilidade 1;
- se $\nu < p$, então $\text{posto}(\mathbf{W}) = \nu$ com probabilidade 1 e a matriz é singular.

Como $\Sigma \succ \mathbf{0}$, cada vetor gerador possui distribuição normal não singular. A distribuição conjunta das entradas de $\mathcal{U}$ é contínua, e o conjunto das matrizes cujo posto é menor que $\min(\nu, p)$ possui probabilidade zero. Assim, a matriz de Gram atinge quase certamente o maior posto permitido por suas dimensões (Muirhead, 1982).

A condição

$$\nu \geq p$$

é, portanto, necessária e suficiente para a definição positiva quase certa na construção com graus de liberdade inteiros e

$$\Sigma \succ \mathbf{0}.$$

12.2.3 Momentos

A esperança da matriz Wishart é obtida diretamente da construção por produtos externos.

Proposição 12.3 (Momentos de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, então

$$E(\mathbf{W}) = \nu \Sigma. \quad (12.14)$$

Para os elementos da matriz,

$$\text{Cov}(W_{jk}, W_{\ell m}) = \nu (\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}). \quad (12.15)$$

Comprovação. Pela construção em Equação 12.9,

$$W_{jk} = \sum_{h=1}^{\nu} U_{hj} U_{hk}.$$

Como

$$E(U_{hj} U_{hk}) = \sigma_{jk},$$

segue que

$$E(W_{jk}) = \nu\sigma_{jk}.$$

Portanto,

$$E(\mathbf{W}) = \nu\Sigma.$$

A expressão para

$$\text{Cov}(W_{jk}, W_{\ell m})$$

decorre dos momentos de quarta ordem do vetor normal de média zero e da independência entre os ν vetores geradores (Muirhead, 1982). $\square$

Em particular,

$$\text{Var}(W_{jj}) = 2\nu\sigma_{jj}^2, \quad (12.16)$$

e, para $j \neq k$,

$$\text{Var}(W_{jk}) = \nu(\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2). \quad (12.17)$$

Dividindo pelos graus de liberdade,

$$E\left(\frac{\mathbf{W}}{\nu}\right) = \Sigma.$$

Além disso, Equação 12.15 implica

$$\text{Cov}\left(\frac{W_{jk}}{\nu}, \frac{W_{\ell m}}{\nu}\right) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{\nu}.$$

Portanto, para Σ fixa, a variabilidade dos elementos de $\mathbf{W}/\nu$ diminui à medida que ν aumenta.

12.2.4 Formas quadráticas

A analogia com a distribuição qui-quadrado também aparece em qualquer direção fixa do espaço das variáveis.

Proposição 12.4 (Forma quadrática de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2, então, para qualquer

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

vale

$$\frac{\mathbf{a}^\top \mathbf{W} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_\nu^2. \quad (12.18)$$

Comprovação. De Equação 12.9,

$$\mathbf{a}^\top \mathbf{W} \mathbf{a} = \sum_{j=1}^{\nu} (\mathbf{a}^\top \mathbf{U}_j)^2.$$

Por Proposição 9.4,

$$\mathbf{a}^\top \mathbf{U}_j \sim N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Assim, as variáveis

$$\frac{\mathbf{a}^\top \mathbf{U}_j}{\sqrt{\mathbf{a}^\top \Sigma \mathbf{a}}}$$

são normais padrão independentes. A soma de seus quadrados possui distribuição χ_ν^2 . $\square$

Assim, cada projeção univariada de uma matriz Wishart recupera a estrutura qui-quadrado correspondente à variância naquela direção.

12.2.5 Aditividade

Proposição 12.5 (Aditividade da distribuição de Wishart). *Se*

$$\mathbf{W}_1 \sim W_p(\nu_1, \Sigma)$$

e

$$\mathbf{W}_2 \sim W_p(\nu_2, \Sigma)$$

são independentes e possuem a mesma matriz de escala, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\nu_1 + \nu_2, \Sigma). \quad (12.19)$$

Comprovação. Pela construção da distribuição, as duas matrizes podem ser representadas por somas de, respectivamente, ν_1 e ν_2 produtos externos de vetores normais independentes com a mesma matriz de covariâncias Σ .

A soma das duas matrizes reúne

$$\nu_1 + \nu_2$$

produtos externos independentes e, portanto, possui a distribuição indicada. $\square$

A condição de escala comum é necessária para esse resultado. Matrizes Wishart independentes com matrizes de escala distintas não podem, em geral, ser somadas mantendo a mesma forma Wishart.

12.2.6 Transformações lineares

A transformação de uma matriz Wishart acompanha a transformação da matriz de covariâncias dos vetores normais que a geram.

Proposição 12.6 (Transformação linear de uma matriz Wishart). *Considere*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2.

Se

$$\mathbf{L} \in \mathbb{R}^{r \times p}$$

possui posto linha completo,

$$\text{posto}(\mathbf{L}) = r,$$

então

$$\mathbf{LWL}^\top \sim W_r(\nu, \mathbf{L}\Sigma\mathbf{L}^\top). \quad (12.20)$$

Comprovação. Pela construção,

$$\mathbf{LWL}^\top = \sum_{j=1}^{\nu} (\mathbf{LU}_j)(\mathbf{LU}_j)^\top.$$

Por Proposição 9.4,

$$\mathbf{LU}_j \sim N_r(\mathbf{0}, \mathbf{L}\Sigma\mathbf{L}^\top).$$

Como as transformações são aplicadas separadamente aos vetores independentes, os vetores transformados permanecem independentes.

Como $\mathbf{L}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{L}\Sigma\mathbf{L}^\top \succ \mathbf{0}.$$

Logo, a soma possui a distribuição apresentada. $\square$

Se $\mathbf{L}$ não possui posto linha completo,

$$\mathbf{L}\Sigma\mathbf{L}^\top$$

é singular e a distribuição fica restrita ao subespaço imagem de $\mathbf{L}$. Essa extensão singular não será necessária na sequência principal.

Tomando

$$\mathbf{L} = \Sigma^{-1/2},$$

com a raiz quadrada principal definida em Definição 5.9, obtém-se

$$\Sigma^{-1/2} \mathbf{W} \Sigma^{-1/2} \sim W_p(\nu, \mathbf{I}_p). \quad (12.21)$$

A transformação remove a matriz de escala da distribuição, de modo análogo ao branqueamento normal em Equação 9.23.

12.2.7 Aprofundamento: densidade da distribuição de Wishart

Leitura de aprofundamento

Os resultados inferenciais deste capítulo utilizam principalmente a construção por produtos externos, o posto, os momentos, a aditividade e as transformações da distribuição de Wishart.

A densidade é apresentada como aprofundamento porque será útil para relacionar a distribuição de Wishart a verossimilhanças envolvendo matrizes de covariâncias.

A construção em Definição 12.2 utiliza um número inteiro de vetores normais. A família Wishart não singular admite uma extensão para graus de liberdade reais

$$\nu > p - 1$$

por meio de sua densidade no cone das matrizes simétricas positivas definidas (Muirhead, 1982).

Proposição 12.7 (Densidade da distribuição de Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com

$$\nu > p - 1$$

e

$$\Sigma \succ \mathbf{0},$$

então sua densidade é

$$f_{\mathbf{W}}(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-p-1)/2} \exp \left[-\frac{1}{2} \text{tr} (\Sigma^{-1} \mathbf{W}) \right]}{2^{\nu p/2} |\Sigma|^{\nu/2} \Gamma_p(\nu/2)}, \quad (12.22)$$

para

$$\mathbf{W} \succ \mathbf{0}.$$

A função gama multivariada é

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad (12.23)$$

definida para

$$a > \frac{p-1}{2}.$$

Quando a Wishart é construída pela soma de ν produtos externos e

$$\nu < p,$$

a matriz é singular com probabilidade 1. Nesse caso, sua distribuição está concentrada em matrizes positivas semidefinidas de posto ν e não possui a densidade anterior no cone positivo definido.

A sequência inferencial deste capítulo utilizará graus de liberdade inteiros provenientes do tamanho amostral ou do posto de matrizes de projeção.

12.2.8 Distribuição da SQPC e da covariância amostral

Retomando Definição 10.13,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Por Definição 10.14,

$$\mathbf{S} = \frac{\mathbf{T}}{n-1}.$$

Por Proposição 10.10,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Sob normalidade multivariada, a distribuição completa dessa estatística pode ser estabelecida.

Teorema 12.2 (Distribuição da SQPC e da covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\mathbf{T} = (n-1)\mathbf{S} \sim W_p(n-1, \Sigma). \quad (12.24)$$

Comprovação. Organize a amostra na matriz aleatória

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix}.$$

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

cuja primeira linha seja

$$\frac{1}{\sqrt{n}}\mathbf{1}_n^\top,$$

e defina a matriz transformada

$$\mathcal{X}^* = \mathbf{Q}\mathcal{X}.$$

Sua primeira linha satisfaz

$$(\mathbf{X}_1^*)^\top = \sqrt{n} \bar{\mathbf{X}}^\top. \quad (12.25)$$

As demais linhas são combinações lineares cujos coeficientes somam zero. Portanto,

$$E(\mathbf{X}_j^*) = \mathbf{0}, \quad j = 2, \dots, n.$$

A covariância cruzada entre duas linhas transformadas é

$$\text{Cov}(\mathbf{X}_j^*, \mathbf{X}_k^*) = [\mathbf{Q}\mathbf{Q}^\top]_{jk} \Sigma = \delta_{jk} \Sigma.$$

As linhas transformadas são conjuntamente normais. Por Proposição 9.6, as covariâncias cruzadas nulas implicam independência. Assim,

$$\mathbf{X}_2^*, \dots, \mathbf{X}_n^* \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma).$$

A matriz de centralização pode ser escrita como

$$\mathbf{H}_n = \mathbf{Q}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{I}_{n-1} \end{bmatrix} \mathbf{Q}.$$

Utilizando a forma matricial da SQPC estabelecida em Equação 10.62,

$$\begin{aligned} \mathbf{T} &= \mathcal{X}^\top \mathbf{H}_n \mathcal{X} \\ &= \sum_{j=2}^n \mathbf{X}_j^* (\mathbf{X}_j^*)^\top. \end{aligned}$$

Essa é a soma de $n - 1$ produtos externos de vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Pela Definição 12.2,

$$\mathbf{T} \sim W_p(n - 1, \Sigma).$$

□

A esperança obtida pela distribuição de Wishart é consistente com Proposição 10.10 e Proposição 10.11.

A informação nova é a distribuição amostral completa:

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma).$$

Pela Proposição 12.4, para qualquer

$$\mathbf{a} \neq \mathbf{0},$$

tem-se

$$\frac{(n-1)\mathbf{a}^\top \mathbf{S} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_{n-1}^2. \quad (12.26)$$

Assim, a variância amostral de qualquer combinação linear fixa possui a mesma estrutura qui-quadrado conhecida do caso univariado.

Para os elementos de $\mathbf{S}$,

$$\text{Cov}(S_{jk}, S_{\ell m}) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{n-1}. \quad (12.27)$$

Em particular,

$$\text{Var}(S_{jj}) = \frac{2\sigma_{jj}^2}{n-1}$$

e, para $j \neq k$,

$$\text{Var}(S_{jk}) = \frac{\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2}{n-1}.$$

Esses resultados são exatos sob normalidade multivariada.

A matriz de covariâncias amostral possui, com probabilidade 1,

$$\text{posto}(\mathbf{S}) = \min(p, n-1). \quad (12.28)$$

Portanto, sob

$$\Sigma \succ \mathbf{0},$$

a condição

$$n > p \tag{12.29}$$

é necessária e suficiente para que

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1.

Quando

$$p \geq n,$$

a matriz $\mathbf{S}$ é necessariamente singular. Essa restrição dimensional terá consequência direta para a forma clássica da estatística T^2 de Hotelling.

Sob o modelo normal, Equação 10.44 fornece

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}.$$

Sempre que sua interpretação como estimador de máxima verossimilhança no espaço

$$\Sigma \succ \mathbf{0}$$

for válida,

$$n\widehat{\Sigma}_{\text{MV}} = \mathbf{T} \sim W_p(n-1, \Sigma). \tag{12.30}$$

A distribuição continua envolvendo $n-1$ graus de liberdade, pois a média populacional também foi estimada a partir da amostra.

12.2.9 Independência entre média e covariância

A transformação ortogonal utilizada na prova do Teorema 12.2 separa a informação amostral associada à localização da informação associada à dispersão.

A primeira linha transformada depende exclusivamente de

$$\bar{\mathbf{X}},$$

enquanto

$$\mathbf{T}$$

e, conseqüentemente,

$$\mathbf{S},$$

dependem apenas das demais linhas.

Teorema 12.3 (Independência entre média e covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

também vale

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.31)$$

Comprovação. Na prova de Teorema 12.2, a primeira linha de $\mathcal{X}^*$ depende apenas de

$$\bar{\mathbf{X}},$$

enquanto $\mathbf{T}$ depende apenas das demais linhas transformadas.

Esses dois blocos são independentes por Proposição 9.6. Portanto,

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

segue também

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

□

A independência é um resultado **exato da amostragem normal**. Ela não decorre somente da independência entre as observações.

O que depende da normalidade

As propriedades

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

não exigem normalidade multivariada.

Em contraste,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

são resultados exatos da amostragem normal.

Para uma população geral, a distribuição de $\mathbf{S}$ depende de características adicionais da distribuição, incluindo momentos de ordem superior, e a média e a covariância amostrais não são, em geral, independentes.

Temos, portanto, sob amostragem normal, o par

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

e

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

com

$$\bar{\mathbf{X}} \perp \mathbf{S}. \tag{12.32}$$

O par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

combina uma distribuição normal para a localização, uma distribuição Wishart para a dispersão e independência entre os dois objetos. Essa estrutura normal–Wishart será utilizada posteriormente na construção da estatística T^2 de Hotelling.

No modelo linear multivariado, a mesma organização reaparece. O vetor de médias amostral é substituído pelo estimador de $\mathbf{B}$, enquanto a SQPC amostral é substituída pela SQPC residual. Os $n-1$ graus de liberdade do problema de uma única média passam a ser os $n-r$ graus de liberdade residuais do modelo.

12.3 Distribuições no modelo linear multivariado

O modelo linear normal multivariado foi definido em Definição 11.7. Nesta seção, a normalidade será utilizada para obter as distribuições amostrais exatas dos estimadores e das matrizes SQPC construídas no Capítulo 11.

Retomando Equação 11.22,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma), \quad \Sigma \succ \mathbf{0}. \quad (12.33)$$

A matriz de delineamento é considerada fixa, ou a análise é condicionada em seus valores observados. Defina

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r,$$

em concordância com Equação 11.77.

A estrutura probabilística será desenvolvida em três etapas: distribuição do estimador dos parâmetros, distribuição da SQPC residual e distribuição da SQPC associada a uma hipótese linear.

12.3.1 Distribuição do estimador da matriz de parâmetros

Suponha inicialmente que

$$r = q.$$

Nesse caso, o estimador de mínimos quadrados definido em Equação 11.36 é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Por Equação 11.39,

$$\widehat{\mathbf{B}} = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.$$

Assim, $\widehat{\mathbf{B}}$ é uma transformação afim da matriz normal de erros.

Proposição 12.8 (Distribuição do estimador da matriz de parâmetros). *Sob o modelo linear normal multivariado e*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$\widehat{\mathbf{B}} \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{B}, (\mathbf{Z}^\top \mathbf{Z})^{-1}, \Sigma \right]. \quad (12.34)$$

Equivalentemente,

$$\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z} \sim N_{pq} \left[\text{vec}(\mathbf{B}), \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]. \quad (12.35)$$

Comprovação. Defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então

$$\widehat{\mathbf{B}} = \mathbf{B} + \mathbf{A}_Z \mathcal{E}.$$

Pela transformação da distribuição normal matricial,

$$\mathbf{A}_Z \mathcal{E} \mid \mathbf{Z} \sim N_{q \times p}(\mathbf{0}, \mathbf{A}_Z \mathbf{A}_Z^\top, \Sigma).$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

segue o resultado. □

A distribuição em Equação 12.34 contém como momentos os resultados de Proposição 11.3. A matriz

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a variabilidade dos coeficientes, enquanto

$$\Sigma$$

descreve a dependência residual entre as respostas.

Quando

$$r < q,$$

os coeficientes de $\mathbf{B}$ podem não ser únicos. Nesse caso, a inferência deve ser formulada sobre as funções estimáveis caracterizadas em Proposição 11.12.

12.3.2 Distribuição de funções estimáveis

O Capítulo 11 caracterizou as funções estimáveis do modelo linear multivariado. Sob normalidade, a distribuição exata de seu estimador decorre de uma transformação linear da matriz de erros.

Proposição 12.9 (Distribuição de uma função estimável). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2, \mathbf{V}_{C_1}, \Sigma_{C_2}). \quad (12.36)$$

Nesse resultado,

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2$$

e

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2.$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

satisfaz a condição de estimabilidade

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z},$$

enquanto

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

As matrizes de covariâncias são

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \quad (12.37)$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^{\top} \Sigma \mathbf{C}_2. \quad (12.38)$$

Sob essas condições,

$$\mathbf{V}_{C_1} \succ \mathbf{0} \quad e \quad \Sigma_{C_2} \succ \mathbf{0}.$$

Equivalentemente,

$$\text{vec}(\widehat{\Theta}) \mid \mathbf{Z} \sim N_{gs} \left[\text{vec}(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2), \Sigma_{C_2} \otimes \mathbf{V}_{C_1} \right]. \quad (12.39)$$

Comprovação. Pela estimabilidade,

$$\mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z} = \mathbf{C}_1.$$

Portanto,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 + \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2.$$

A segunda parcela é uma transformação bilateral da matriz normal de erros, com matriz de covariâncias entre linhas $\mathbf{V}_{C_1}$ e matriz de covariâncias entre colunas Σ_{C_2} . Isso fornece Equação 12.36. $\square$

A matriz $\mathbf{V}_{C_1}$ representa a variabilidade associada às combinações dos termos do modelo, enquanto Σ_{C_2} representa a covariância residual das combinações de respostas. A normalidade acrescenta a distribuição amostral exata à estrutura construída no Capítulo 11.

12.3.3 Distribuição da SQPC residual

Por Definição 11.11,

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

pode-se escrever

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

A matriz

$$\mathbf{M}_Z$$

é um projetor ortogonal de posto

$$\nu_E = n - r.$$

Proposição 12.10 (Distribuição da SQPC residual). *Sob o modelo linear normal multivariado, se*

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r \geq 1,$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.40)$$

Comprovação. Seja

$$\mathbf{Q}_E \in \mathbb{R}^{n \times (n-r)}$$

uma matriz cujas colunas formam uma base ortonormal de

$$\mathcal{C}(\mathbf{M}_Z).$$

Como $\mathbf{M}_Z$ é o projetor ortogonal sobre esse espaço,

$$\mathbf{M}_Z = \mathbf{Q}_E \mathbf{Q}_E^\top.$$

Defina

$$\mathcal{E}^* = \mathbf{Q}_E^\top \mathcal{E}.$$

Pela transformação da normal matricial,

$$\mathcal{E}^* \mid \mathbf{Z} \sim N_{(n-r) \times p}(\mathbf{0}, \mathbf{I}_{n-r}, \Sigma).$$

Portanto, suas $n - r$ linhas são vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\begin{aligned} \mathbf{E}_{\text{res}} &= \mathcal{E}^\top \mathbf{Q}_E \mathbf{Q}_E^\top \mathcal{E} \\ &= (\mathcal{E}^*)^\top \mathcal{E}^*. \end{aligned}$$

Pela construção da distribuição de Wishart,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma).$$

□

A esperança fornecida pela distribuição de Wishart coincide com Proposição 11.7.

Como o estimador residual foi definido em Equação 11.79 por

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r},$$

segue que

$$(n - r)\widehat{\Sigma} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.41)$$

O posto da SQPC residual é, com probabilidade 1,

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r). \quad (12.42)$$

Assim,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq p. \quad (12.43)$$

A condição é a contraparte probabilística do limite de posto discutido no Capítulo 11 e decorre diretamente de Proposição 12.2.

12.3.4 Independência entre estimação e SQPC residual

Para uma função estimável,

$$\widehat{\Theta} - \Theta = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2,$$

enquanto os resíduos satisfazem

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}.$$

Como

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

as duas parcelas correspondem a projeções ortogonais dos erros.

Proposição 12.11 (Independência entre estimação paramétrica e resíduos). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \perp \widehat{\mathcal{U}} \mid \mathbf{Z}.$$

Consequentemente,

$$\widehat{\Theta} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.44)$$

Comprovação. As duas matrizes são transformações lineares da mesma matriz normal de erros e, portanto, são conjuntamente normais.

Como

$$\mathbf{C}_1 \mathbf{Z} + \mathbf{M}_Z = \mathbf{0},$$

a covariância cruzada entre as duas transformações é nula. Por Proposição 9.6, segue a independência.

Como $\mathbf{E}_{\text{res}}$ é função dos resíduos, a segunda independência também é obtida. $\square$

Quando $\mathbf{Z}$ possui posto coluna completo, tomando

$$\mathbf{C}_1 = \mathbf{I}_q \quad \text{e} \quad \mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.45)$$

Esse resultado generaliza a independência entre média e covariância amostrais. No modelo contendo somente intercepto,

$$\widehat{\mathbf{B}} = \bar{\mathbf{X}}^\top$$

e

$$\mathbf{E}_{\text{res}} = (n - 1)\mathbf{S}.$$

Papel da normalidade

A ortogonalidade entre as projeções garante covariância cruzada nula entre as parcelas estimada e residual.

A conclusão de **independência** utiliza adicionalmente a normalidade conjunta. Fora do modelo normal, ortogonalidade das projeções não implica, por si só, independência entre as estatísticas correspondentes.

12.3.5 Distribuição da SQPC da hipótese sob H_0

Sob o modelo linear normal multivariado, a SQPC associada à hipótese e a SQPC residual correspondente possuem distribuições Wishart independentes. Esse resultado fornece a estrutura probabilística que será utilizada posteriormente na inferência multivariada do modelo linear.

Proposição 12.12 (Distribuições da SQPC da hipótese e da SQPC residual). *Sob o modelo linear normal multivariado, com*

$$\Sigma \succ \mathbf{0},$$

considere a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (12.46)$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}, \quad \text{posto}(\mathbf{C}_1) = g,$$

representa g funções estimáveis linearmente independentes.

Além disso,

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

Defina

$$r = \text{posto}(\mathbf{Z}), \quad n - r \geq 1,$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2.$$

O afastamento aleatório da hipótese é

$$\mathcal{D} = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{Y} \mathbf{C}_2 - \Theta_0. \quad (12.47)$$

Além disso,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}.$$

Sob H_0 ,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{V}_{C_1}, \Sigma_{C_2}). \quad (12.48)$$

Defina

$$\mathbf{H} = \mathcal{D}^{\top} \mathbf{V}_{C_1}^{-1} \mathcal{D} \quad (12.49)$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^{\top} \mathbf{E}_{\text{res}} \mathbf{C}_2. \quad (12.50)$$

Então,

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_{C_2}) \quad (12.51)$$

e

$$\mathbf{E}_{C_2} \mid \mathbf{Z} \sim W_s(n - r, \Sigma_{C_2}). \quad (12.52)$$

Além disso,

$$\mathbf{H} \perp \mathbf{E}_{C_2} \mid \mathbf{Z}. \quad (12.53)$$

Comprovação. Sob H_0 ,

$$\mathbf{V}_{C_1}^{-1/2} \mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{I}_g, \Sigma_{C_2}).$$

Portanto, suas g linhas são vetores independentes com distribuição

$$N_s(\mathbf{0}, \Sigma_{C_2}).$$

Como

$$\mathbf{H} = (\mathbf{V}_{C_1}^{-1/2} \mathcal{D})^\top (\mathbf{V}_{C_1}^{-1/2} \mathcal{D}),$$

Definição 12.2 fornece

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_{C_2}).$$

Por Proposição 12.6,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2 \mid \mathbf{Z} \sim W_s(n - r, \Sigma_{C_2}).$$

A independência decorre de Proposição 12.11. □

As duas matrizes possuem a mesma matriz de escala,

$$\Sigma_{C_2},$$

mas graus de liberdade diferentes:

- g corresponde ao número de combinações linearmente independentes dos termos do modelo definidas por $\mathbf{C}_1$;
- $n - r$ corresponde à dimensão do espaço residual.

Como

$$\text{posto}(\mathbf{C}_1) = g \quad \text{e} \quad \text{posto}(\mathbf{C}_2) = s,$$

a hipótese contém gs restrições escalares independentes.

O grau de liberdade da distribuição Wishart de $\mathbf{H}$ é, entretanto, g , porque a SQPC da hipótese é construída a partir de g vetores aleatórios no espaço das s combinações de respostas.

Por Proposição 12.2,

$$\text{posto}(\mathbf{H}) = \min(g, s)$$

e

$$\text{posto}(\mathbf{E}_{C_2}) = \min(n - r, s)$$

com probabilidade 1.

Em particular,

$$\mathbf{E}_{C_2} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq s. \quad (12.54)$$

Sob a hipótese alternativa

Defina

$$\Delta_0 = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 - \Theta_0. \quad (12.55)$$

Quando

$$\Delta_0 \neq \mathbf{0},$$

a SQPC $\mathbf{H}$ possui distribuição Wishart não central. A matriz

$$\mathbf{E}_{C_2}$$

mantém sua distribuição Wishart central e permanece independente de $\mathbf{H}$ (Muirhead, 1982).

A não centralidade incorpora o afastamento entre $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ e Θ_0 e será relevante para o estudo do poder. Sua parametrização detalhada não será necessária neste capítulo.

As distribuições obtidas nesta seção fornecem a estrutura probabilística geral para hipóteses lineares multivariadas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma)$$

e

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

com independência entre as duas matrizes. Esse par constitui a base probabilística das matrizes de hipótese e erro que serão utilizadas posteriormente na MANOVA.

O passo seguinte é estabelecer como uma hipótese conjunta é transformada em uma regra inferencial, distinguindo testes globais, razão de verossimilhanças e resultados exatos ou assintóticos.

12.4 Princípios da inferência multivariada

Uma hipótese multivariada pode impor simultaneamente várias restrições sobre um vetor, uma matriz ou uma função dos parâmetros. Um teste global avalia essas restrições como uma única afirmação estatística, considerando a dependência entre seus componentes.

No modelo linear multivariado, por exemplo,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$$

é a hipótese geral definida em Definição 11.17. De forma semelhante,

$$H_0 : \mu = \mu_0$$

é uma única hipótese sobre o vetor de médias, ainda que envolva p componentes.

O nível α controla a probabilidade de rejeitar H_0 quando ela é verdadeira. Para uma alternativa especificada, o poder é a probabilidade de rejeitar H_0 quando essa alternativa é verdadeira. Na inferência multivariada, essas probabilidades dependem da forma como as várias componentes são reunidas na estatística de teste.

12.4.1 Testes globais e hipóteses simultâneas

Considere uma hipótese vetorial

$$H_0 : \mu = \mu_0.$$

Ela implica as igualdades coordenadas

$$\mu_j = \mu_{0j}, \quad j = 1, \dots, p,$$

mas a realização de p testes marginais separados não é equivalente a um teste global do vetor.

Se cada teste marginal possui nível α e os testes são independentes, a probabilidade de pelo menos uma rejeição incorreta sob a hipótese global é

$$1 - (1 - \alpha)^p. \quad (12.56)$$

Por exemplo, para

$$p = 5$$

e

$$\alpha = 0,05,$$

essa probabilidade é

$$1 - 0,95^5 \approx 0,226.$$

Quando as estatísticas são dependentes, a expressão anterior não se aplica diretamente, mas a conclusão permanece: realizar vários testes marginais no mesmo nível não garante controle do nível global.

Teste global e análise posterior

Um teste global avalia uma hipótese conjunta e utiliza a estrutura de dependência entre seus componentes.

A rejeição da hipótese global não identifica, por si só, quais componentes ou combinações lineares são responsáveis pelo afastamento. Essa investigação exige procedimentos posteriores, como contrastes ou intervalos simultâneos, com controle adequado da multiplicidade.

A distribuição da estatística sob H_0 determina a calibração do teste. Quando sua distribuição amostral exata é conhecida, os valores críticos e o valor- p podem ser obtidos diretamente dessa distribuição. Quando apenas uma distribuição limite é conhecida, a calibração é assintótica.

Sob alternativas, algumas estatísticas passam a depender de parâmetros de não centralidade que incorporam o afastamento de H_0 em relação à variabilidade do problema. Esses parâmetros são utilizados no estudo do poder, mas suas distribuições detalhadas não serão desenvolvidas neste capítulo.

12.4.2 Razão de verossimilhanças

A razão de verossimilhanças fornece um princípio geral para comparar o melhor ajuste permitido por uma hipótese nula com o melhor ajuste disponível no modelo irrestrito (Casella; Berger, 2002).

A hipótese nula restringe o espaço paramétrico do modelo irrestrito a um subconjunto de valores admissíveis.

Definição 12.3 (Estatística da razão de verossimilhanças). Considere um parâmetro

$$\vartheta \in \mathcal{P}$$

e a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0, \quad \emptyset \neq \mathcal{P}_0 \subseteq \mathcal{P}.$$

Suponha que, para as realizações consideradas,

$$0 < \sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y}) < \infty.$$

A estatística da razão de verossimilhanças é

$$\Lambda_{\text{RV}}(\mathcal{Y}) = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathcal{Y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y})}. \quad (12.57)$$

Para uma realização observada $\mathbf{y}$, o valor observado da estatística é

$$\Lambda_{\text{RV,obs}} = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})}.$$

Como

$$\mathcal{P}_0 \subseteq \mathcal{P},$$

tem-se

$$0 \leq \Lambda_{\text{RV}} \leq 1.$$

Valores próximos de 1 indicam que a restrição imposta por H_0 produz pequena redução na verossimilhança máxima. Valores reduzidos indicam maior incompatibilidade entre a hipótese nula e os dados observados.

É conveniente utilizar a transformação

$$-2 \log \Lambda_{\text{RV}}.$$

Quando os máximos são atingidos e

$$\hat{\vartheta}$$

e

$$\tilde{\vartheta}$$

denotam, respectivamente, os estimadores de máxima verossimilhança irrestrito e restrito,

$$-2 \log \Lambda_{\text{RV}} = 2 \left[\ell(\hat{\vartheta}) - \ell(\tilde{\vartheta}) \right], \quad (12.58)$$

em que

$$\ell(\vartheta) = \log L(\vartheta; \mathbf{y}).$$

A estatística é não negativa e cresce à medida que as restrições impostas por H_0 reduzem o máximo da verossimilhança.

A distribuição de

$$-2 \log \Lambda_{\text{RV}}$$

depende do modelo. Em alguns problemas, existe uma distribuição exata ou uma transformação exata para uma distribuição conhecida. Quando essa distribuição não está disponível, modelos paramétricos regulares admitem uma aproximação assintótica fornecida pelo teorema de Wilks.

12.4.3 Resultado assintótico de Wilks

Teorema 12.4 (Resultado assintótico de Wilks). *Considere um espaço paramétrico*

$$\mathcal{P} \subseteq \mathbb{R}^k,$$

com k fixo quando $n \rightarrow \infty$, e um parâmetro verdadeiro

$$\vartheta_0 \in \text{int}(\mathcal{P}).$$

Considere a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0,$$

em que, em uma vizinhança de ϑ_0 ,

$$\mathcal{P}_0 = \{\vartheta \in \mathcal{P} : \mathbf{h}(\vartheta) = \mathbf{0}\},$$

com

$$\mathbf{h} : \mathcal{P} \longrightarrow \mathbb{R}^d$$

continuamente diferenciável e

$$\text{posto}[\mathbf{J}_{\mathbf{h}}(\vartheta_0)] = d,$$

com d fixo.

Seja

$$\ell_n(\vartheta) = \log L_n(\vartheta).$$

Suponha que:

1. *o modelo seja identificável;*

2. $\ell_n(\vartheta)$ seja duas vezes continuamente diferenciável em uma vizinhança de ϑ_0 ;
3. exista uma matriz

$$\mathbf{I}(\vartheta_0) \succ \mathbf{0}$$

tal que

$$\frac{1}{\sqrt{n}} \nabla \ell_n(\vartheta_0) \xrightarrow{d} N_k[\mathbf{0}, \mathbf{I}(\vartheta_0)];$$

4. para toda sequência

$$\vartheta_n \xrightarrow{P} \vartheta_0,$$

tem-se

$$-\frac{1}{n} \nabla^2 \ell_n(\vartheta_n) \xrightarrow{P} \mathbf{I}(\vartheta_0);$$

5. os estimadores de máxima verossimilhança irrestrito e restrito existem e satisfazem

$$\hat{\vartheta}_n \xrightarrow{P} \vartheta_0$$

e

$$\tilde{\vartheta}_n \xrightarrow{P} \vartheta_0$$

sob H_0 .

Então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2. \quad (12.59)$$

O número d corresponde ao número de restrições localmente independentes impostas por H_0 e satisfaz

$$d = \dim(\mathcal{P}) - \dim(\mathcal{P}_0)$$

na vizinhança de ϑ_0 .

(Vaart, 1998)

O resultado é assintótico (Vaart, 1998). Para uma amostra grande, uma região crítica aproximada de nível α é

$$-2 \log \Lambda_{\text{RV}} > \chi_{d;1-\alpha}^2. \quad (12.60)$$

O correspondente valor- p aproximado é

$$P[\chi_d^2 \geq -2 \log \Lambda_{\text{RV,obs}}]. \quad (12.61)$$

O número

$$d$$

não deve ser obtido simplesmente pela contagem de todas as expressões escritas na hipótese. Ele corresponde ao número de restrições **localmente independentes** ou, equivalentemente em situações regulares, à diferença entre as dimensões dos espaços paramétricos irrestrito e restrito.

Situações não regulares

A aproximação qui-quadrado do Teorema 12.4 não se aplica automaticamente quando:

- o parâmetro verdadeiro está na fronteira do espaço paramétrico;
- o modelo não é identificável;
- há restrições redundantes;
- a informação de Fisher é singular;
- a dimensão do parâmetro cresce com o tamanho amostral.

Nessas situações, a distribuição limite pode ser diferente de uma qui-quadrado convencional.

O **teorema de Wilks** em Teorema 12.4 é um resultado assintótico geral sobre razões de verossimilhanças. Ele deve ser distinguido da **lambda de Wilks**, que é uma estatística matricial específica utilizada posteriormente na MANOVA.

12.4.4 Razão de verossimilhanças em modelos normais encaixados

O princípio da razão de verossimilhanças pode ser aplicado aos modelos lineares multivariados encaixados de Proposição 11.13.

Considere a comparação entre um modelo completo e um modelo reduzido encaixado. A matriz **H** representa a redução da SQPC residual obtida pela inclusão, no modelo completo, dos termos ausentes no modelo reduzido.

Sob o modelo normal matricial com matriz de covariâncias residual comum, a verossimilhança maximizada é proporcional a $|\mathbf{E}|^{-n/2}$. A razão de verossimilhanças pode, portanto, ser expressa por meio dos determinantes das SQPCs residuais dos dois modelos.

Proposição 12.13 (Razão de verossimilhanças em modelos normais encaixados). *Considere modelos lineares normais multivariados completo e reduzido, definidos sobre as mesmas n unidades, com matriz de covariâncias residual comum*

$$\Sigma \succ \mathbf{0},$$

e tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F).$$

Se suas SQPCs residuais $\mathbf{E}_F$ e $\mathbf{E}_R$ são positivas definidas e

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H} \tag{12.62}$$

e

$$\mathbf{H} \succeq \mathbf{0},$$

então

$$\Lambda_{\text{RV}} = \left(\frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} \right)^{n/2}. \tag{12.63}$$

Equivalentemente,

$$\Lambda_{\text{RV}} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}. \tag{12.64}$$

A razão de determinantes

$$\Lambda_{\text{W}} = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \tag{12.65}$$

é denominada **lambda de Wilks**. Assim,

$$\Lambda_{RV} = \Lambda_W^{n/2}. \quad (12.66)$$

Portanto, Λ_{RV} e Λ_W são funções monotônicas uma da outra e conduzem à mesma ordenação das evidências contra H_0 .

Neste capítulo, a lambda de Wilks aparece como consequência da razão de verossimilhanças em modelos normais encaixados. Sua distribuição e sua utilização como critério específico da MANOVA serão desenvolvidas no Módulo 3.

Como

$$\mathbf{H} \succeq \mathbf{0},$$

a imposição das restrições do modelo reduzido não diminui a SQPC residual na ordem de Löwner:

$$\mathbf{E}_R \succeq \mathbf{E}_F.$$

Quando ambas são positivas definidas,

$$|\mathbf{E}_R| \geq |\mathbf{E}_F|,$$

e, portanto,

$$0 < \Lambda_{RV} \leq 1.$$

Valores de Λ_W próximos de 1 indicam pequena diferença entre os ajustes completo e reduzido. Valores menores indicam maior redução da dispersão residual quando os termos adicionais do modelo completo são incluídos.

A decomposição desse critério por raízes características e sua relação com os demais critérios multivariados pertencem à MANOVA.

Existência da forma por determinantes

A expressão em Equação 12.63 exige que as matrizes residuais relevantes sejam positivas definidas.

Sob o modelo normal, uma condição suficiente para

$$\mathbf{E}_F \succ \mathbf{0}$$

com probabilidade 1 é

$$n - r_F \geq p,$$

em que

$$r_F = \text{posto}(\mathbf{Z}_F).$$

Como

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H}$$

e

$$\mathbf{H} \succcurlyeq \mathbf{0},$$

a definição positiva de $\mathbf{E}_F$ implica a definição positiva de $\mathbf{E}_R$.

Quando a SQPC residual é singular, a razão de determinantes clássica deixa de estar disponível na forma anterior. Pseudoinversas, pseudodeterminantes ou regularização definem procedimentos diferentes e não preservam automaticamente a distribuição nula utilizada pela inferência clássica.

A razão de verossimilhanças fornece um princípio geral para comparar modelos restritos e irrestritos. Para a inferência sobre um único vetor de médias, entretanto, existem distribuições exatas mais específicas.

Quando Σ é conhecida, a forma quadrática da média amostral conduz diretamente a uma distribuição qui-quadrado. Quando Σ é desconhecida e precisa ser estimada por $\mathbf{S}$, a distribuição muda e conduz à estatística T^2 de Hotelling.

12.5 Inferência sobre um vetor de médias

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succcurlyeq \mathbf{0}.$$

O objetivo inicial é testar

$$H_0 : \mu = \mu_0$$

contra

$$H_1 : \mu \neq \mu_0,$$

em que

$$\mu_0 \in \mathbb{R}^p$$

é conhecido.

A distribuição da média amostral foi estabelecida em Proposição 12.1. A forma da estatística de teste depende de a matriz populacional Σ ser conhecida ou precisar ser substituída por sua estimativa amostral.

12.5.1 Covariância conhecida

Pela Proposição 12.1,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right).$$

Sob H_0 ,

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu_0) \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

Definição 12.4 (Estatística para a média com covariância conhecida). Quando $\Sigma \succ \mathbf{0}$ é conhecida, define-se

$$Q_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.67)$$

A forma quadrática utiliza a distância de Mahalanobis definida em Definição 8.9. Como

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

o fator n ajusta a distância à variabilidade da média amostral, e não à variabilidade de uma observação individual.

Proposição 12.14 (Distribuição com covariância conhecida). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$ conhecida, então, sob

$$H_0 : \mu = \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2. \quad (12.68)$$

O resultado decorre de Proposição 9.8 aplicado à distribuição da média amostral em Proposição 12.1. A matriz de covariâncias da média é Σ/n , o que produz a forma em Equação 12.67.

Assim, um teste de nível α rejeita H_0 quando

$$Q_{\mu, \text{obs}} > \chi_{p; 1-\alpha}^2, \quad (12.69)$$

em que

$$Q_{\mu, \text{obs}} = n \left(\bar{\mathbf{x}} - \mu_0 \right)^\top \Sigma^{-1} \left(\bar{\mathbf{x}} - \mu_0 \right). \quad (12.70)$$

O valor- p é

$$P(\chi_p^2 \geq Q_{\mu, \text{obs}}). \quad (12.71)$$

Sob uma alternativa fixa, a distribuição torna-se qui-quadrado não central, com parâmetro

$$\lambda_\mu = n \left(\mu - \mu_0 \right)^\top \Sigma^{-1} \left(\mu - \mu_0 \right). \quad (12.72)$$

Assim, a não centralidade cresce com o tamanho amostral e com o afastamento entre μ e μ_0 medido na geometria de Σ . Esse parâmetro será utilizado apenas como referência para a interpretação do poder.

Quando

$$p = 1,$$

obtém-se

$$Q_\mu = \frac{n(\bar{X} - \mu_0)^2}{\sigma^2},$$

que corresponde ao quadrado da estatística normal padronizada utilizada no teste de uma média com variância conhecida.

12.5.2 Estatística T^2 de Hotelling

Na maior parte das aplicações,

$$\Sigma$$

é desconhecida e precisa ser estimada. A substituição de Σ por $\mathbf{S}$ não preserva a distribuição qui-quadrado de Equação 12.68, porque a matriz utilizada na forma quadrática passa a ser aleatória.

Os resultados obtidos anteriormente fornecem

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

por Proposição 12.1,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

por Teorema 12.2, e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

por Teorema 12.3.

A estatística T^2 combina esses três resultados.

Definição 12.5 (Estatística T^2 de Hotelling para uma amostra). A estatística para testar

$$H_0 : \mu = \mu_0$$

quando Σ é desconhecida e $\mathbf{S} \succ \mathbf{0}$ é

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0). \quad (12.73)$$

A forma clássica de T^2 exige

$$\mathbf{S} \succ \mathbf{0},$$

pois utiliza $\mathbf{S}^{-1}$.

Como

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

Proposição 12.2 mostra que, sob $\Sigma \succ \mathbf{0}$,

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > p. \tag{12.74}$$

O fator n aparece porque a matriz de covariâncias da média é

$$\frac{\Sigma}{n}.$$

A expressão de T^2 tem a mesma forma quadrática utilizada na distância de Mahalanobis, mas emprega a matriz aleatória $\mathbf{S}$ no lugar de Σ . Portanto, trata-se de uma forma de Mahalanobis **estimada**, cuja distribuição precisa incorporar a variabilidade da estimação da covariância.

Proposição 12.15 (Distribuição exata de T^2). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \mu = \mu_0,$$

vale

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}. \quad (12.75)$$

Esse resultado utiliza conjuntamente a distribuição normal da média, a distribuição Wishart da covariância amostral e a independência entre esses dois objetos (Anderson, 2003; Rencher; Christensen, 2012).

Quando Σ é conhecida, somente a média amostral é aleatória na forma quadrática e obtém-se uma distribuição χ_p^2 . Quando Σ é substituída por $\mathbf{S}$, a incerteza da covariância estimada também participa da estatística. A transformação em Equação 12.75 incorpora essa fonte adicional de variabilidade e produz a distribuição F exata.

Após a observação,

$$\mathbf{T}_{\text{obs}}^2 = n (\bar{\mathbf{x}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0). \quad (12.76)$$

Defina

$$\mathbf{F}_{\text{obs}} = \frac{n-p}{p(n-1)} \mathbf{T}_{\text{obs}}^2. \quad (12.77)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}, \quad (12.78)$$

ou, equivalentemente, quando

$$\mathbf{F}_{\text{obs}} > F_{p, n-p; 1-\alpha}.$$

O valor- p é

$$P(F_{p, n-p} \geq \mathbf{F}_{\text{obs}}). \quad (12.79)$$

A rejeição informa que o vetor populacional não coincide com μ_0 . Ela não identifica, isoladamente, quais componentes ou combinações lineares são responsáveis pelo afastamento.

Sob uma alternativa fixa, a transformação de $\mathbf{T}^2$ possui distribuição F não central, com o mesmo parâmetro λ_μ definido em Equação 12.72. Essa distribuição é utilizada em estudos de poder e não será desenvolvida adicionalmente neste capítulo.

12.5.3 Relações com os casos assintótico e univariado

Quando p permanece fixo e

$$n \longrightarrow \infty,$$

a consistência de $\mathbf{S}$ estabelecida em Proposição 10.12 implica, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \quad (12.80)$$

Portanto, a distribuição qui-quadrado fornece uma aproximação assintótica. Sob normalidade e em amostras finitas, a distribuição F em Equação 12.75 é o resultado exato.

Quando

$$p = 1,$$

a matriz de covariâncias amostral reduz-se à variância amostral S . Assim,

$$\mathbf{T}^2 = \frac{n(\bar{X} - \mu_0)^2}{S} = t^2, \quad (12.81)$$

em que

$$t = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sqrt{S}} \sim t_{n-1}$$

sob H_0 .

Assim, o teste T^2 de uma amostra é a extensão multivariada do teste t de Student.

A estatística também é invariante a transformações afins com parte linear não singular. Se

$$\mathbf{Y}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b}, \quad \det(\mathbf{A}) \neq 0,$$

então Proposição 8.6 fornece

$$\mathbf{S}_Y = \mathbf{A} \mathbf{S} \mathbf{A}^\top.$$

Como

$$(\mathbf{A} \mathbf{S} \mathbf{A}^\top)^{-1} = \mathbf{A}^{-\top} \mathbf{S}^{-1} \mathbf{A}^{-1},$$

os fatores $\mathbf{A}$ se cancelam na forma quadrática e o valor de T^2 permanece inalterado.

12.5.4 Região de confiança elipsoidal

A região de confiança para μ é obtida reunindo todos os vetores que não seriam rejeitados pelo teste T^2 ao nível α . Essa inversão do teste produz uma região simultânea para todo o vetor de médias.

Proposição 12.16 (Região de confiança para o vetor de médias). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

defina

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.82)$$

Então,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{X}} - \theta)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \theta) \leq c_{\alpha,p,n} \right\} \quad (12.83)$$

possui cobertura

$$P(\mu \in \mathcal{C}_{1-\alpha}) = 1 - \alpha. \quad (12.84)$$

Após a observação,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : (\theta - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\theta - \bar{\mathbf{x}}) \leq \frac{c_{\alpha,p,n}}{n} \right\}. \quad (12.85)$$

A dualidade entre teste e região de confiança fornece

$$\mu_0 \in \mathcal{C}_{1-\alpha} \iff T_{\text{obs}}^2(\mu_0) \leq c_{\alpha,p,n}. \quad (12.86)$$

12.5.5 Geometria da região

A região observada é um elipsoide centrado em

$$\bar{\mathbf{x}}.$$

Considere a decomposição espectral

$$\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Em coordenadas espectrais, sua fronteira é

$$\sum_{j=1}^p \frac{z_j^2}{c_{\alpha,p,n} \lambda_j / n} = 1. \quad (12.87)$$

Consequentemente, os eixos do elipsoide são os autovetores de $\mathbf{S}$ e o comprimento do j -ésimo semieixo é

$$a_j = \sqrt{\frac{c_{\alpha,p,n} \lambda_j}{n}}. \quad (12.88)$$

A forma da região é a mesma estrutura elipsoidal de Equação 8.32, agora centrada em $\bar{\mathbf{x}}$ e escalada pela constante inferencial $c_{\alpha,p,n}/n$. A orientação e os comprimentos dos eixos decorrem da decomposição espectral utilizada em Equação 8.26.

A Figura 12.1 mostra, no caso bidimensional, como a covariância altera a orientação da região de confiança.




Figura 12.1: Efeito da matriz de covariâncias sobre a forma e a orientação da região de confiança para o vetor de médias.

Na primeira configuração da Figura 12.1, os eixos permanecem alinhados às coordenadas originais. Na segunda, a covariância positiva produz rotação do elipsoide. A região reflete, portanto, tanto as variâncias marginais quanto a dependência entre as componentes.

Interpretação da cobertura

Antes da observação dos dados,

$$\mathcal{C}_{1-\alpha}$$

é uma região aleatória que contém o verdadeiro vetor μ com probabilidade $1 - \alpha$.

Depois da observação, a região está fixada. Na interpretação frequentista, o parâmetro não passa a ser aleatório; a cobertura refere-se ao comportamento do procedimento em repetições amostrais.

12.5.6 Intervalos simultâneos

Cada vetor

$$\mathbf{a} \in \mathbb{R}^p$$

define uma combinação linear $\mathbf{a}^\top \mu$. Como todos esses funcionais são obtidos da mesma região elipsoidal, é possível construir intervalos com cobertura simultânea para todas as direções.

Proposição 12.17 (Intervalos simultâneos de Hotelling). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

e

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha},$$

os intervalos

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}, \quad \mathbf{a} \in \mathbb{R}^p, \quad (12.89)$$

possuem cobertura simultânea $1 - \alpha$ para todas as combinações lineares.

Comprovação. Se

$$\mu \in \mathcal{C}_{1-\alpha},$$

então

$$(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}}) \leq \frac{c_{\alpha,p,n}}{n}.$$

Pela desigualdade de Cauchy–Schwarz na geometria induzida por $\mathbf{S}$,

$$|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \sqrt{(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}})}.$$

Substituindo o limite da região, obtém-se Equação 12.89 simultaneamente para todas as direções $\mathbf{a}$. $\square$

Após a observação dos dados,

$$\mathbf{a}^\top \mu \in \mathbf{a}^\top \bar{\mathbf{x}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}. \quad (12.90)$$

Para

$$\mathbf{a} = \mathbf{e}_j,$$

obtém-se o intervalo simultâneo para uma componente:

$$\mu_j \in \bar{x}_j \pm \sqrt{\frac{c_{\alpha,p,n} S_{jj}}{n}}. \quad (12.91)$$

Para

$$\mathbf{a} = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$\mu_j - \mu_k \in \bar{x}_j - \bar{x}_k \pm \sqrt{\frac{c_{\alpha,p,n}}{n} (S_{jj} + S_{kk} - 2S_{jk})}. \quad (12.92)$$

Os intervalos de Hotelling fornecem cobertura simultânea para todas as combinações lineares $\mathbf{a}^\top \mu$. Quando o interesse está restrito a um conjunto finito e previamente especificado de combinações, procedimentos como Bonferroni utilizam uma família de inferências menor e podem produzir intervalos mais estreitos, dependendo da estrutura de covariâncias e do número de comparações.

12.5.7 Hipóteses lineares sobre o vetor de médias

A hipótese

$$H_0 : \mu = \mu_0$$

especifica todo o vetor de médias. Em outros problemas, o interesse está restrito a determinadas combinações lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{h \times p},$$

com

$$\text{posto}(\mathbf{A}) = h \leq p,$$

e

$$\mathbf{d} \in \mathbb{R}^h.$$

A hipótese é

$$H_0 : \mathbf{A}\mu = \mathbf{d}. \quad (12.93)$$

Cada linha de $\mathbf{A}$ define uma restrição linear. A condição de posto linha completo elimina restrições redundantes.

Defina

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

A distribuição decorre diretamente de Proposição 9.4.

Como $\mathbf{A}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

A média e a covariância amostrais transformadas são

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}}$$

e

$$\mathbf{S}_U = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Assim, o problema reduz-se exatamente à inferência sobre um vetor de médias de dimensão h .

12.5.7.1 Covariância conhecida

Quando Σ é conhecida, defina

$$Q_A = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.94)$$

Sob H_0 ,

$$Q_A \sim \chi_h^2. \quad (12.95)$$

Esse é Proposição 12.14 aplicado ao vetor transformado $\mathbf{U}_i$. Portanto, os graus de liberdade são determinados pelas h combinações linearmente independentes presentes na hipótese, e não pela dimensão original p .

12.5.7.2 Covariância desconhecida

Sob normalidade,

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > h. \quad (12.96)$$

Proposição 12.18 (Distribuição para hipóteses lineares sobre a média). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

e

$$\mathbf{A} \in \mathbb{R}^{h \times p}, \quad 1 \leq h \leq p, \quad \text{posto}(\mathbf{A}) = h, \quad \mathbf{d} \in \mathbb{R}^h, \quad n > h,$$

então, sob

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

a estatística

$$\mathbf{T}_A^2 = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}) \quad (12.97)$$

satisfaz

$$\frac{n-h}{h(n-1)} \mathbf{T}_A^2 \sim F_{h,n-h}. \quad (12.98)$$

O resultado é Proposição 12.15 aplicado aos vetores transformados

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i \in \mathbb{R}^h.$$

Por isso, a condição dimensional passa de $n > p$ para $n > h$.

Assim, um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{A,\text{obs}}^2 > \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha}, \quad (12.99)$$

em que

$$\mathbf{T}_{A,\text{obs}}^2 = n (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d}). \quad (12.100)$$

Uma consequência importante é que a condição dimensional depende de

$$h,$$

e não necessariamente de p .

Assim, mesmo quando

$$p \geq n$$

e a matriz completa

$$\mathbf{S}$$

é singular, uma hipótese de dimensão reduzida ainda pode admitir a inferência clássica se

$$n > h$$

e

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top$$

for não singular.

Quando

$$h = 1,$$

com

$$\mathbf{A} = \mathbf{a}^\top,$$

a hipótese

$$H_0 : \mathbf{a}^\top \mu = d$$

reduz-se ao teste t univariado aplicado à combinação linear

$$\mathbf{a}^\top \mathbf{X}.$$

Quando

$$h = p, \quad \mathbf{A} = \mathbf{I}_p, \quad \mathbf{d} = \mu_0,$$

recupera-se o teste T^2 para o vetor completo de médias.

12.5.8 Relação com o modelo linear multivariado

O modelo de uma única população pode ser escrito como

$$y = \mathbf{1}_n \mu^\top + \mathcal{E}.$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Na hipótese geral de Definição 11.17,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

tome

$$\mathbf{C}_1 = [1], \quad \mathbf{C}_2 = \mathbf{A}^\top$$

e

$$\Theta_0 = \mathbf{d}^\top.$$

Então,

$$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mu^\top \mathbf{A}^\top = (\mathbf{A} \mu)^\top.$$

Portanto,

$$H_0 : \mathbf{A} \mu = \mathbf{d}$$

é um caso particular da hipótese linear geral do Capítulo 11.

Essa correspondência mostra que o teste T^2 para uma média, as hipóteses sobre combinações lineares e a inferência no modelo linear multivariado utilizam a mesma estrutura. A próxima seção estende o problema à comparação entre dois vetores de médias.

12.6 Comparação entre dois vetores de médias

A comparação entre dois vetores de médias depende da relação entre as unidades que produziram as observações. Duas estruturas serão consideradas:

- **amostras independentes**, formadas por unidades distintas;
- **observações pareadas**, nas quais cada unidade ou par fornece duas medições relacionadas.

Nos dois casos, o parâmetro de interesse é uma diferença entre vetores de médias. O delineamento determina, porém, a matriz de covariâncias dessa diferença e, consequentemente, a estatística utilizada na inferência.

12.6.1 Duas amostras independentes

Considere duas amostras mutuamente independentes:

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A especificação de uma mesma matriz

$$\Sigma$$

para as duas populações é parte do modelo utilizado pelo procedimento clássico com covariância agrupada.

O parâmetro de interesse é

$$\delta = \mu_1 - \mu_2 \in \mathbb{R}^p. \quad (12.101)$$

Considere a hipótese

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (12.102)$$

contra

$$H_1 : \mu_1 - \mu_2 \neq \delta_0.$$

A igualdade dos vetores de médias corresponde ao caso

$$\delta_0 = \mathbf{0}.$$

12.6.1.1 Distribuição da diferença entre as médias

Aplicando Proposição 12.1 separadamente às duas amostras,

$$\bar{\mathbf{X}}_1 \sim N_p \left(\mu_1, \frac{\Sigma}{n_1} \right)$$

e

$$\bar{\mathbf{X}}_2 \sim N_p \left(\mu_2, \frac{\Sigma}{n_2} \right).$$

Como as amostras são independentes,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left[\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right]. \quad (12.103)$$

Para simplificar as expressões seguintes, defina o fator

$$n_{\text{ef}} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} = \frac{n_1 n_2}{n_1 + n_2}. \quad (12.104)$$

Então,

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma}{n_{\text{ef}}}.$$

A notação n_{ef} será utilizada apenas como fator de escala da covariância da diferença entre as médias. Ela não representa o número total de observações nem os graus de liberdade do procedimento.

12.6.1.2 Covariância agrupada

Como Σ é desconhecida, as duas amostras fornecem estimativas da mesma matriz de covariâncias populacional. Essas estimativas são combinadas ponderando cada SQPC pelos respectivos graus de liberdade:

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.105)$$

A matriz $\mathbf{S}_p$ é denominada **matriz de covariâncias agrupada**.

Após a observação,

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.106)$$

Por Teorema 12.2, sob o modelo de covariância comum,

$$(n_h - 1)\mathbf{S}_h \sim W_p(n_h - 1, \Sigma), \quad h = 1, 2.$$

Como as duas amostras são independentes, essas matrizes Wishart também são independentes. Portanto, Proposição 12.5 pode ser aplicada às duas SQPCs.

Proposição 12.19 (Distribuição da covariância agrupada). *Se as duas amostras são independentes, cada amostra é formada por observações i.i.d. normais multivariadas em $\mathbb{R}^p$ e ambas possuem matriz de covariâncias comum*

$$\Sigma \succ \mathbf{0},$$

com

$$n_1 \geq 2 \quad e \quad n_2 \geq 2,$$

então

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma). \quad (12.107)$$

Além disso,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \perp \mathbf{S}_p. \quad (12.108)$$

Comprovação. Pela aditividade da distribuição de Wishart,

$$\begin{aligned} & (n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2 \\ & \sim W_p(n_1 + n_2 - 2, \Sigma). \end{aligned}$$

A matriz no lado esquerdo é

$$(n_1 + n_2 - 2)\mathbf{S}_p.$$

Sob normalidade, em cada amostra a média é independente da respectiva matriz de covariâncias. A independência entre as duas amostras implica então a independência entre

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$$

e

$$\mathbf{S}_p.$$

□

A distribuição em Equação 12.107 fornece

$$E(\mathbf{S}_p) = \Sigma.$$

Além disso, por Proposição 12.2,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1. Portanto,

$$\mathbf{S}_p \succ \mathbf{0}$$

com probabilidade 1 quando

$$n_1 + n_2 - 2 \geq p. \quad (12.109)$$

12.6.1.3 Estatística T^2 para duas amostras

Definição 12.6 (Estatística T^2 para duas amostras independentes). Para testar

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

quando

$$\mathbf{S}_p \succ \mathbf{0},$$

define-se

$$T_{\text{ind}}^2 = n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right), \quad (12.110)$$

em que

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}$$

e

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}.$$

A estatística possui a mesma forma quadrática do T^2 de uma amostra. O vetor de afastamento é agora

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0,$$

e sua variabilidade é estimada pela matriz de covariâncias agrupada.

Proposição 12.20 (Distribuição exata de T^2 para duas amostras). *Se as duas amostras são independentes e*

$$\mathbf{X}_{1i} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma), \quad i = 1, \dots, n_1,$$

e

$$\mathbf{X}_{2i} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma), \quad i = 1, \dots, n_2,$$

com

$$\Sigma \succ \mathbf{0}, \quad n_1 \geq 2, \quad n_2 \geq 2,$$

e

$$n_1 + n_2 - 2 \geq p,$$

então, sob

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

tem-se

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} \mathsf{T}_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}. \quad (12.111)$$

Comprovação. Sob H_0 , o vetor

$$\mathbf{V} = \sqrt{n_{\text{ef}}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)$$

satisfaz

$$\mathbf{V} \sim N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\mathbf{W} = (n_1 + n_2 - 2) \mathbf{S}_p$$

satisfaz, por Proposição [12.19](#),

$$\mathbf{W} \sim W_p(n_1 + n_2 - 2, \Sigma)$$

e

$$\mathbf{V} \perp \mathbf{W}.$$

A mesma estrutura normal–Wishart utilizada em Proposição [12.15](#) fornece

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} \mathsf{T}_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}.$$

□

Para os dados observados,

$$\mathbf{T}_{\text{ind,obs}}^2 = n_{\text{ef}} \begin{pmatrix} \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \end{pmatrix}^\top \mathbf{S}_p^{-1} \begin{pmatrix} \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \end{pmatrix}. \quad (12.112)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{ind,obs}}^2 > \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.113)$$

Defina

$$c_{\alpha, p, n_1, n_2} = \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.114)$$

A inversão do teste fornece uma região de confiança de nível $1 - \alpha$ para

$$\delta = \mu_1 - \mu_2 :$$

$$\mathcal{C}_{\delta, 1 - \alpha} = \left\{ \theta \in \mathbb{R}^p : n_{\text{ef}} \begin{pmatrix} \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \end{pmatrix}^\top \mathbf{S}_p^{-1} \begin{pmatrix} \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \end{pmatrix} \leq c_{\alpha, p, n_1, n_2} \right\}. \quad (12.115)$$

A região é um elipsoide centrado em

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2,$$

com orientação determinada pela matriz de covariâncias agrupada.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

os intervalos derivados dessa região são

$$\mathbf{a}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) \pm \sqrt{\frac{c_{\alpha, p, n_1, n_2}}{n_{\text{ef}}} \mathbf{a}^\top \mathbf{S}_p \mathbf{a}}. \quad (12.116)$$

Esses intervalos fornecem cobertura simultânea para todas as combinações lineares de δ .

Quando

$$p = 1,$$

o procedimento reduz-se ao quadrado do teste t para duas amostras independentes com variâncias populacionais iguais:

$$T_{\text{ind}}^2 = t_{\text{pooled}}^2. \quad (12.117)$$

12.6.2 Covariâncias populacionais distintas

O procedimento anterior foi construído sob

$$\Sigma_1 = \Sigma_2.$$

Se

$$\Sigma_1 \neq \Sigma_2,$$

a diferença entre as médias continua tendo, sob normalidade,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left(\mu_1 - \mu_2, \frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2} \right). \quad (12.118)$$

Entretanto, a matriz agrupada satisfaz

$$E(\mathbf{S}_p) = \frac{(n_1 - 1)\Sigma_1 + (n_2 - 1)\Sigma_2}{n_1 + n_2 - 2},$$

e não estima diretamente

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}.$$

Consequentemente, a estrutura normal-Wishart utilizada em Proposição 12.20 deixa de ser válida com a matriz agrupada, e a transformação para a distribuição F não é mais exata.

Papel da homogeneidade das covariâncias

A igualdade

$$\Sigma_1 = \Sigma_2$$

não é necessária para o T^2 de uma amostra nem para o procedimento pareado.

Ela é uma hipótese específica do procedimento de duas amostras independentes que utiliza a covariância agrupada.

Quando as covariâncias populacionais são distintas, o problema inferencial é diferente e requer outro procedimento ou outra aproximação. A simples substituição de $\mathbf{S}_p$ por uma matriz alternativa não preserva automaticamente a distribuição F clássica.

12.6.3 Observações pareadas

No delineamento pareado, considere

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

em que os pares são independentes entre si, mas as duas medições dentro de cada par podem ser dependentes.

O número

$$n$$

representa o número de pares completos.

Defina

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i. \quad (12.119)$$

O vetor médio das diferenças é

$$\delta = E(\mathbf{D}_i) = \mu_X - \mu_Y. \quad (12.120)$$

Sua matriz de covariâncias é

$$\Sigma_D = \Sigma_X + \Sigma_Y - \Sigma_{XY} - \Sigma_{YX}. \quad (12.121)$$

A expressão mostra por que a associação dentro dos pares deve ser preservada: ela participa diretamente da variabilidade das diferenças.

A hipótese é

$$H_0 : \delta = \delta_0. \quad (12.122)$$

Para comparar diretamente as duas condições,

$$\delta_0 = \mathbf{0}.$$

Depois de formar as diferenças, cada par produz um único vetor

$$\mathbf{D}_i.$$

A comparação entre as duas condições passa, portanto, a ser uma inferência sobre o vetor médio de uma única população de diferenças:

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Suponha

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}.$$

A média amostral das diferenças é

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{i=1}^n \mathbf{D}_i = \bar{\mathbf{X}} - \bar{\mathbf{Y}}. \quad (12.123)$$

A matriz de covariâncias amostral é

$$\mathbf{S}_D = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{D}_i - \bar{\mathbf{D}}) (\mathbf{D}_i - \bar{\mathbf{D}})^\top. \quad (12.124)$$

Quando as matrizes são calculadas sobre os mesmos pares completos,

$$\mathbf{S}_D = \mathbf{S}_X + \mathbf{S}_Y - \mathbf{S}_{XY} - \mathbf{S}_{YX}. \quad (12.125)$$

A decomposição populacional em Equação 12.121 utiliza a covariância cruzada definida em Definição 8.3. Sua contraparte amostral em Equação 12.125 utiliza a matriz definida em Definição 10.16.

Definição 12.7 (Estatística T^2 para observações pareadas). Para os vetores de diferenças pareadas

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i, \quad i = 1, \dots, n,$$

com vetor de médias amostrais $\bar{\mathbf{D}}$ e matriz de covariâncias amostral $\mathbf{S}_D \succ \mathbf{0}$, define-se

$$\mathsf{T}_{\text{par}}^2 = n \left(\bar{\mathbf{D}} - \delta_0 \right)^\top \mathbf{S}_D^{-1} \left(\bar{\mathbf{D}} - \delta_0 \right). \quad (12.126)$$

Proposição 12.21 (Distribuição exata de T^2 para observações pareadas). Se

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \delta = \delta_0,$$

tem-se

$$\frac{n-p}{p(n-1)} \mathsf{T}_{\text{par}}^2 \sim F_{p, n-p}. \quad (12.127)$$

A proposição é Proposição 12.15 aplicada à amostra

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Por isso, o número de observações utilizado no teste é o número de pares completos.

Para os dados observados,

$$\mathbf{T}_{\text{par,obs}}^2 = n (\bar{\mathbf{d}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \delta_0). \quad (12.128)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{par,obs}}^2 > \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.129)$$

Quando

$$p = 1,$$

recupera-se o quadrado do teste t pareado:

$$\mathbf{T}_{\text{par}}^2 = \mathbf{t}_{\text{par}}^2. \quad (12.130)$$

Aplicando Proposição 12.16 à população de diferenças, obtém-se a região de confiança de nível $1 - \alpha$

$$\mathcal{C}_{D,1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{D}} - \theta)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \theta) \leq c_{\alpha,p,n} \right\}, \quad (12.131)$$

em que $c_{\alpha,p,n}$ foi definida em Equação 12.82.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

Proposição 12.17 fornece

$$\mathbf{a}^\top \bar{\mathbf{D}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S}_D \mathbf{a}}. \quad (12.132)$$

Assim, teste, região de confiança e intervalos simultâneos do caso pareado são os resultados de uma amostra aplicados aos vetores de diferenças.

Preservação do pareamento

O procedimento deve ser aplicado às diferenças construídas com a correspondência correta entre as unidades.

Tratar as duas condições como amostras independentes elimina da análise a covariância intrapar e utiliza uma estrutura de variabilidade diferente daquela determinada pelo delineamento.

A normalidade necessária ao resultado exato refere-se à distribuição dos vetores

$$\mathbf{D}_i,$$

e não exige, separadamente, que cada uma das duas condições possua distribuição marginal normal multivariada.

A Tabela 12.1 resume a diferença entre os dois delineamentos.

Tabela 12.1: Comparação entre o T^2 para amostras independentes e para observações pareadas.

Característica	Amostras independentes	Observações pareadas
unidade básica	observações distintas	par de medições relacionadas
parâmetro	$\mu_1 - \mu_2$	$E(\mathbf{D})$
matriz usada na forma quadrática	covariância comum estimada por $\mathbf{S}_p$	covariância das diferenças estimada por $\mathbf{S}_D$
dependência entre as duas medições	não há correspondência entre unidades das duas amostras	incorporada em Σ_{XY} e Σ_{YX} e, portanto, em Σ_D
graus de liberdade da matriz de covariâncias	$n_1 + n_2 - 2$	$n - 1$
condição clássica de inversão	$n_1 + n_2 - 2 \geq p$	$n > p$
redução univariada	teste t com variâncias iguais	teste t pareado

Os dois procedimentos utilizam a mesma lógica inferencial, mas estimam estruturas de variabilidade distintas. Essa diferença será retomada na seção seguinte ao organizar as condições necessárias à inferência multivariada clássica.

12.7 Condições e limites da inferência clássica

Os resultados desenvolvidos neste capítulo dependem da estrutura probabilística da amostra, das hipóteses específicas de cada procedimento e do posto das matrizes envolvidas. Essas condições não são intercambiáveis: uma hipótese necessária para um procedimento pode ser irrelevante para outro.

Quatro aspectos organizam a validade da inferência clássica:

1. independência entre as unidades amostrais na estrutura especificada pelo delineamento;
2. normalidade multivariada quando se utilizam distribuições exatas normal–Wishart;
3. covariância comum nos procedimentos que a pressupõem;
4. posto suficiente das matrizes utilizadas nas formas quadráticas, inversas e determinantes.

12.7.1 Independência, normalidade e covariância comum

12.7.1.1 Independência

Nos resultados para uma amostra,

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são consideradas independentes.

Para duas amostras independentes, exige-se também independência entre as duas amostras. No delineamento pareado, admite-se dependência entre as duas medições de um mesmo par, mas os pares devem ser independentes entre si.

No modelo linear multivariado clássico,

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n$$

expressa a ausência de covariância residual entre unidades distintas.

A independência é determinada principalmente pelo processo de amostragem e pelo delineamento do estudo. Se existe dependência entre unidades e ela não é incorporada ao modelo, expressões como

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}$$

podem deixar de representar a variabilidade efetiva da média amostral.

Consequentemente, estatísticas construídas com essa estrutura podem apresentar níveis de significância e coberturas diferentes dos valores nominais.

Independência e delineamento

A independência não é estabelecida por um teste aplicado aos valores observados. Ela deve ser avaliada a partir da forma como as unidades foram selecionadas, agrupadas e mensuradas.

Dependência espacial, temporal, hierárquica ou decorrente de medidas repetidas exige uma estrutura probabilística compatível com o delineamento.

12.7.1.2 Normalidade multivariada

A normalidade multivariada sustenta os principais resultados exatos deste capítulo. Sob esse modelo foram estabelecidas:

- a distribuição normal da média em Proposição 12.1;
- a distribuição Wishart da SQPC amostral em Teorema 12.2;
- a independência entre média e covariância amostrais em Teorema 12.3;
- a distribuição F exata do T^2 em Proposição 12.15;
- as distribuições Wishart e as independências associadas ao modelo linear multivariado em Proposição 12.12.

Esses resultados devem ser distinguidos das propriedades que dependem apenas de momentos. Por exemplo, Proposição 10.6 e Proposição 10.11 não exigem normalidade.

Fora do modelo normal, a distribuição Wishart e as independências utilizadas para construir as distribuições exatas deixam, em geral, de estar disponíveis. No regime de dimensão fixa de Equação 12.1, resultados assintóticos podem ainda ser obtidos.

Se as observações são i.i.d., possuem matriz de covariâncias finita e positiva definida, e as condições de Teorema 12.1 e Proposição 10.12 são satisfeitas, então, sob

$$H_0 : \mu = \mu_0,$$

o Teorema Central do Limite multivariado e o teorema de Slutsky fornecem

$$T^2 \xrightarrow{d} \chi_p^2. \quad (12.133)$$

Essa convergência não implica que

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$$

seja uma distribuição exata em amostras finitas fora do modelo normal.

Exato e assintótico

A normalidade não é necessária para definir médias, covariâncias, matrizes SQPC ou formas quadráticas.

Neste capítulo, ela é utilizada para obter determinadas distribuições amostrais **exatas**. Fora desse modelo, uma aproximação assintótica depende das condições do resultado limite utilizado e do regime em que n e p variam.

12.7.1.3 Covariância comum

A hipótese

$$\Sigma_1 = \Sigma_2$$

não pertence a todos os procedimentos multivariados.

Ela foi utilizada especificamente no teste de duas amostras independentes com covariância agrupada, pois permite obter

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma).$$

Quando

$$\Sigma_1 \neq \Sigma_2,$$

a covariância da diferença entre as médias é a apresentada em Equação 12.118,

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2},$$

e a matriz agrupada não conduz à distribuição F exata da Proposição 12.20.

No procedimento pareado, essa hipótese não é necessária. A matriz relevante é

$$\Sigma_D = \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i).$$

No modelo linear multivariado clássico, a estrutura

$$\text{Cov}(\varepsilon_i | \mathbf{Z}) = \Sigma$$

supõe uma matriz residual comum às unidades representadas pelo modelo.

Assim, a homogeneidade deve ser entendida como uma hipótese do **procedimento que utiliza uma matriz de covariâncias comum**, e não como uma condição universal da inferência multivariada.

12.7.2 Posto, dimensão e tamanho amostral

As formas clássicas das estatísticas utilizam matrizes inversas. A condição necessária depende da dimensão efetivamente utilizada em cada problema.

12.7.2.1 Uma amostra

Sob normalidade não singular,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1)$$

com probabilidade 1.

Portanto,

$$\mathbf{S}^{-1}$$

existe com probabilidade 1 se, e somente se,

$$n > p.$$

Essa é também a condição que torna positivo o segundo grau de liberdade

$$n - p$$

da distribuição

$$F_{p, n-p}.$$

12.7.2.2 Hipóteses de dimensão reduzida

Para

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

com

$$\text{posto}(\mathbf{A}) = h,$$

a matriz relevante é

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

A condição clássica passa a ser

$$n > h.$$

Portanto, a singularidade da matriz completa $\mathbf{S}$ não impede necessariamente a inferência sobre combinações previamente especificadas de dimensão menor.

12.7.2.3 Duas amostras independentes

Sob normalidade e covariância comum,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1.

A inversão clássica requer

$$n_1 + n_2 - 2 \geq p.$$

Sob essa condição,

$$n_1 + n_2 - p - 1 > 0,$$

como necessário para a distribuição F da Proposição [12.20](#).

12.7.2.4 Modelo linear multivariado

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

e

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r)$$

com probabilidade 1.

Logo,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

Para combinações de respostas definidas por

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

com posto coluna completo,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2$$

é positiva definida com probabilidade 1 quando

$$n - r \geq s,$$

conforme Equação [12.54](#).

Portanto, a condição de posto depende da dimensão do objeto que efetivamente participa da inferência. Uma matriz de covariâncias completa pode ser singular e, ainda assim, determinadas

combinações previamente especificadas admitirem inferência clássica em um espaço de menor dimensão.

Existência e estabilidade

A existência de uma inversa é uma condição algébrica; sua estabilidade depende também da separação entre os autovalores da matriz.

O efeito do condicionamento sobre a inversão de matrizes de covariâncias foi discutido em Equação 10.108. Assim, uma matriz pode possuir posto completo e ainda produzir formas quadráticas sensíveis a pequenas perturbações dos dados.

A Tabela 12.2 resume as condições centrais dos procedimentos desenvolvidos neste capítulo.

Tabela 12.2: Condições centrais para os resultados exatos da inferência multivariada clássica.

Procedimento	Estrutura probabilística para o resultado exato	Condição principal de posto
média com Σ conhecida	normalidade da média amostral	$\Sigma \succ \mathbf{0}$
T^2 de uma amostra	amostra normal multivariada	$n > p$
T^2 para $\mathbf{A}\mu = \mathbf{d}$	amostra normal multivariada	$n > h$
duas amostras independentes	normalidade, independência e covariância comum	$n_1 + n_2 - 2 \geq p$
observações pareadas	normalidade dos vetores de diferenças	$n > p$
modelo linear multivariado	normalidade matricial dos erros	$n - r \geq p$ para $\mathbf{E} \succ \mathbf{0}$
combinações de s respostas	normalidade matricial dos erros	$n - r \geq s$ para $\mathbf{E}_{C_2} \succ \mathbf{0}$

12.7.3 Aprofundamento: alta dimensão e robustez

A teoria desenvolvida neste capítulo é predominantemente uma teoria de **dimensão fixa**, na qual a informação amostral cresce enquanto a dimensão permanece constante. Quando a dimensão é grande em relação ao tamanho amostral, singularidade e instabilidade tornam-se parte central do problema.

12.7.3.1 Alta dimensão

Os limites de posto estabelecidos neste capítulo mostram que a inferência clássica baseada em inversas deixa de estar disponível quando a dimensão ultrapassa os graus de liberdade

correspondentes. Para uma amostra, por exemplo, Equação 10.81 implica que

$$p \geq n$$

torna $\mathbf{S}$ necessariamente singular. Situações análogas ocorrem para a covariância agrupada quando

$$p > n_1 + n_2 - 2$$

e para a SQPC residual do modelo linear quando

$$p > n - r.$$

O Capítulo 10 distinguiu duas respostas algébricas a problemas dessa natureza: a pseudoinversa em Equação 10.117 e a regularização da matriz de covariâncias em Definição 10.18. Nenhuma dessas substituições preserva automaticamente as distribuições inferenciais derivadas neste capítulo para a inversa clássica.

Por exemplo, substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ modifica a estatística T^2 e não permite utilizar automaticamente

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}.$$

O mesmo ocorre quando $\mathbf{S}$ é substituída por um estimador regularizado.

Uma alternativa diferente consiste em formular previamente a hipótese em um espaço de menor dimensão. Isso ocorre em

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

e, no modelo linear, em

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Nesse caso, a condição de posto depende da dimensão das combinações efetivamente examinadas. Se essas combinações forem escolhidas a partir dos próprios dados, entretanto, o processo de seleção também integra o procedimento inferencial.

Testes específicos para alta dimensão, regularização inferencial, reamostragem e procedimentos baseados em projeções possuem distribuições e critérios próprios e não serão desenvolvidos neste capítulo.

12.7.3.2 Sensibilidade e robustez

O Capítulo 10 mostrou que a média e a matriz de covariâncias amostrais podem ser fortemente afetadas por observações suficientemente afastadas dos demais dados. Para a média, esse efeito foi explicitado em Equação 10.119; para a matriz de covariâncias, a sensibilidade decorre dos produtos externos utilizados em sua construção.

Essa propriedade afeta diretamente a inferência deste capítulo porque estatísticas como T^2 utilizam simultaneamente

$$\bar{\mathbf{X}}$$

e

$$\mathbf{S}^{-1}.$$

Uma observação influente pode, portanto, modificar tanto o vetor de afastamento quanto a matriz utilizada para ponderá-lo. Isso não significa que toda observação extrema seja um erro nem permite classificar universalmente um procedimento como robusto ou não robusto. O efeito depende da distribuição, da dimensão, do tamanho amostral e da configuração dos dados.

Sob independência entre as unidades, existência dos momentos requeridos e em dimensão fixa, resultados assintóticos podem continuar válidos fora da normalidade. Essa validade assintótica não transforma em exatas as distribuições finitas derivadas da estrutura normal–Wishart.

Substituir $\bar{\mathbf{X}}$ ou $\mathbf{S}$ por estimadores robustos define outro procedimento estatístico e exige uma distribuição nula ou um método de calibração apropriado.

Alcance desta seção

O objetivo é delimitar os procedimentos clássicos desenvolvidos neste capítulo. Diagnósticos detalhados, estimação robusta, regularização, testes de alta dimensão e métodos de reamostragem possuem desenvolvimentos próprios e não serão tratados neste módulo.

As condições desta seção delimitam quais resultados do capítulo são exatos, quais dependem de aproximações assintóticas e quando as formas clássicas deixam de estar definidas. Com essas fronteiras estabelecidas, o Módulo 2 reúne os objetos probabilísticos, amostrais, de estimação, modelagem e inferência que serão utilizados pelas técnicas multivariadas do Módulo 3.

12.8 Síntese do Módulo 2

O Módulo 2 desenvolveu a base probabilística e inferencial necessária para estudar conjuntamente várias variáveis. O percurso começou com a representação da variabilidade conjunta por meio das covariâncias, introduziu a distribuição normal multivariada como modelo probabilístico, passou à construção e avaliação de estimadores, ampliou a estrutura da média por meio do modelo linear multivariado e concluiu com distribuições amostrais e procedimentos de inferência.

O percurso do módulo começou com a matriz de covariâncias populacional definida em Definição 8.2 e com a representação da variabilidade conjunta construída no Capítulo 8. A distribuição normal multivariada de Definição 9.1 acrescentou um modelo probabilístico para esses objetos.

No Capítulo 10, o vetor de médias amostral em Equação 10.8 e a matriz de covariâncias amostral definida em Definição 10.14 estabeleceram a passagem dos parâmetros populacionais para estatísticas e estimadores.

O Capítulo 11 generalizou a estrutura da média por meio do modelo linear multivariado de Definição 11.3,

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

e organizou hipóteses estimáveis na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

definida em Definição 11.17.

Neste capítulo, a distribuição de Wishart transformou as matrizes SQPC em objetos inferenciais. Em particular, Teorema 12.2 estabelece a distribuição da covariância amostral sob normalidade, enquanto Teorema 12.3 fornece a independência entre média e covariância amostrais.

No modelo linear multivariado, a mesma estrutura aparece nas matrizes de hipótese e erro. Sob H_0 , Proposição 12.12 fornece distribuições Wishart para $\mathbf{H}$ e para a SQPC residual correspondente, com independência entre elas. Esse resultado constitui a base probabilística que será reutilizada na MANOVA.

A inferência sobre vetores de médias foi organizada pela estatística T^2 de Hotelling. Quando Σ é conhecida, a forma quadrática possui distribuição qui-quadrado; quando a covariância é estimada por $\mathbf{S}$, Proposição 12.15 fornece uma transformação exata para a distribuição F . A mesma estrutura foi estendida a hipóteses $H_0 : \mathbf{A}\mu = \mathbf{d}$, à comparação de duas amostras independentes e às diferenças pareadas.

A razão de verossimilhanças forneceu uma formulação geral para comparar modelos sob restrições. No modelo linear normal, essa comparação levou à lambda de Wilks,

$$\Lambda_W = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|},$$

relacionando diretamente a redução da dispersão residual às matrizes $\mathbf{H}$ e $\mathbf{E}$.

Os resultados exatos deste módulo dependem das hipóteses probabilísticas e das condições de posto declaradas em cada procedimento. Fora dessas condições, resultados assintóticos, pseudoinversas ou regularização definem problemas inferenciais diferentes e não preservam automaticamente as distribuições clássicas.

A Tabela Tabela 12.3 reúne os objetos centrais dos cinco capítulos.

Tabela 12.3: Objetos centrais dos capítulos do Módulo 2.

Capítulo	Objeto central	Papel no Módulo 2
8. Matrizes de covariâncias e correlações	Σ e matrizes de dispersão	representa variabilidade, dependência e geometria
9. Distribuição Normal Multivariada	$N_p(\mu, \Sigma)$	estabelece o principal modelo probabilístico do módulo
10. Estatísticas Amostrais e Estimação	$\bar{\mathbf{X}}, \mathbf{T}$ e $\mathbf{S}$	relaciona parâmetros populacionais, estatísticas e estimadores
11. Modelo Linear Multivariado e Hipóteses Lineares	$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$ e $\mathbf{C}_1\mathbf{B}\mathbf{C}_2$	organiza médias, resíduos, SQPCs e hipóteses estimáveis
12. Inferência Multivariada	Wishart, T^2 , $(\mathbf{H}, \mathbf{E})$ e Λ_W	fornece distribuições amostrais, testes e regiões de confiança

Ao concluir o Módulo 2, o estudante deve ser capaz de:

- distinguir parâmetros populacionais, estatísticas amostrais, estimadores, estimativas e distribuições amostrais;
- interpretar a matriz de covariâncias e a distribuição normal multivariada como bases da modelagem probabilística conjunta;
- reconhecer a distribuição de Wishart e sua relação com matrizes SQPC e estimadores de covariância;
- formular e interpretar o modelo linear multivariado e hipóteses da forma $\mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0$;
- utilizar o T^2 de Hotelling para formular inferência sobre vetores de médias e combinações lineares;

- interpretar as matrizes $\mathbf{H}$ e $\mathbf{E}$ como variação associada à hipótese e ao resíduo;
- distinguir resultados exatos de aproximações assintóticas e identificar as condições de normalidade, independência, posto e delineamento que sustentam cada procedimento.

12.8.1 Passagem para o Módulo 3

Os dois primeiros módulos construíram a linguagem que será utilizada na formulação das técnicas multivariadas.

O Módulo 1 forneceu a base matemática formada por vetores, matrizes, subespaços, transformações, decomposições e ferramentas de cálculo.

O Módulo 2 acrescentou a estrutura probabilística e inferencial, abrangendo covariâncias, distribuições multivariadas, estimação, modelos lineares e procedimentos de inferência.

O Módulo 3 combinará essas duas estruturas para formular problemas multivariados específicos.

Matrizes de covariâncias serão decompostas ou modeladas. Projeções serão utilizadas para construir representações de menor dimensão. Distâncias e produtos internos serão utilizados para representar proximidades e formar grupos. Tabelas de contingência serão transformadas em estruturas geométricas. Matrizes de hipótese e erro serão retomadas na comparação multivariada de grupos. Modelos probabilísticos serão utilizados na discriminação e classificação. Dois blocos de variáveis serão relacionados por combinações lineares.

A passagem para o Módulo 3 corresponde, portanto, à mudança de uma teoria geral dos objetos multivariados para a formulação de técnicas destinadas a problemas estatísticos específicos.

Exercícios de fixação do Módulo II

Os exercícios deste módulo retomam os fundamentos probabilísticos e inferenciais desenvolvidos nos Capítulos 8 a 12 e os articulam com os resultados matemáticos estudados no Módulo I.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades, operações com vetores e matrizes e procedimentos de inferência. Na segunda, o R será utilizado para aplicar essas estruturas a conjuntos de dados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos nos Módulos I e II (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de normalidade, independência, existência de momentos, definição positiva, invertibilidade, posto, tamanho amostral, graus de liberdade ou outra hipótese específica, essa condição deve ser indicada.

Em particular, ao longo desta lista deve-se distinguir três situações:

1. resultados que permanecem válidos sem a hipótese de normalidade multivariada, desde que sejam satisfeitas as condições específicas necessárias, como existência de momentos e independência das unidades;
2. resultados exatos para amostras finitas cuja validade depende da normalidade multivariada;
3. resultados assintóticos que podem ser obtidos, sob condições próprias, quando o tamanho amostral cresce e a dimensão permanece fixa.

O fato de uma estatística poder ser calculada não significa que uma distribuição de referência utilizada para realizar inferência seja válida. Da mesma forma, o aumento do tamanho amostral pode justificar determinados resultados assintóticos, mas não transforma uma distribuição de amostra finita em um resultado exato fora das condições em que ela foi derivada.

A robustez de um procedimento diante de desvios da normalidade também não deve ser tratada como uma propriedade universal. Sua avaliação depende, entre outros aspectos, da intensidade e do tipo de desvio da distribuição, da presença de observações extremas, da dimensão e do tamanho amostral.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador

Exercício 12.1 (Covariância, correlação e transformação de escala). Considere as matrizes

$$\Sigma_A = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\Sigma_B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

Um estudante afirma que ambas podem representar matrizes de covariâncias porque são simétricas e possuem elementos diagonais positivos.

1. Verifique, separadamente para Σ_A e Σ_B , se estão satisfeitas as condições necessárias para que uma matriz real seja uma matriz de covariâncias. Em particular, verifique utilizando um dos critérios estudados no Módulo I. Apresente os cálculos utilizados e conclua, para cada matriz, se ela pode ou não representar uma matriz de covariâncias.
2. Para a matriz identificada no item anterior como uma matriz de covariâncias válida, determine numericamente a matriz de correlações correspondente. Verifique, no resultado obtido, os valores da diagonal e do elemento fora da diagonal.
3. Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

cujas matrizes de covariâncias sejam a matriz válida identificada no item 1. Para a combinação linear

$$Y = X_1 - X_2,$$

escreva o vetor de coeficientes da combinação linear, determine numericamente $\text{Var}(Y)$ utilizando uma forma quadrática e explique como o termo de covariância entre X_1 e X_2 participa do valor obtido.

4. Para o mesmo vetor $\mathbf{X}$, considere a transformação

$$Z_1 = X_1 \quad \text{e} \quad Z_2 = 10X_2.$$

Utilize a propriedade de transformação da matriz de covariâncias, sem retornar às definições escalares de variância e covariância. Calcule numericamente:

- $\text{Var}(Z_2)$;
- $\text{Cov}(Z_1, Z_2)$;
- $\text{Corr}(Z_1, Z_2)$.

Compare cada resultado com a quantidade correspondente para X_1 e X_2 .

5. Classifique como verdadeira ou falsa a afirmação a seguir e justifique sua resposta utilizando os resultados obtidos nos itens anteriores e a diferença entre covariância e correlação:

Quanto maior a covariância entre duas variáveis, mais forte é necessariamente a associação linear entre elas.

6. Considere agora que nenhuma distribuição probabilística específica, em particular a normal multivariada, tenha sido assumida para $\mathbf{X}$. Indique quais resultados utilizados nos itens 1 a 5 continuam válidos desde que existam os momentos de primeira e segunda ordem necessários. Explique por que a definição e as propriedades algébricas da matriz de covariâncias não dependem da hipótese de normalidade multivariada.

Exercício 12.2 (Normalidade conjunta, independência e condicionamento). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \right).$$

1. Determine a distribuição marginal do vetor

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix}.$$

Apresente explicitamente o vetor de médias e a matriz de covariâncias dessa distribuição marginal. Em seguida, determine se X_1 e X_3 são independentes e indique o resultado da distribuição normal multivariada que permite estabelecer essa conclusão.

2. Considere agora os blocos

$$\mathbf{X}_A = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e X_3 . Extraia da matriz de covariâncias de $\mathbf{X}$ o bloco de covariâncias cruzadas entre $\mathbf{X}_A$ e X_3 . A partir desse bloco e das propriedades da distribuição normal multivariada, determine se $\mathbf{X}_A$ e X_3 são independentes. Justifique a conclusão.

3. Determine a distribuição condicional

$$\mathbf{X}_A \mid X_3 = 0.$$

Para isso, particione o vetor de médias e a matriz de covariâncias de acordo com os dois blocos considerados. Apresente numericamente o vetor de médias condicionais e a matriz de covariâncias condicionais e escreva a distribuição normal resultante.

4. Suponha agora que fossem conhecidos apenas o vetor de médias e a matriz de covariâncias apresentados no enunciado, sem assumir que $\mathbf{X}$ possui distribuição normal multivariada. Reavalie separadamente:

- a conclusão de independência entre X_1 e X_3 ;
- a conclusão sobre a independência entre $\mathbf{X}_A$ e X_3 ;
- a forma da distribuição condicional de $\mathbf{X}_A$ dado $X_3 = 0$.

Para cada caso, indique o que ainda pode ser concluído somente a partir das médias e covariâncias conhecidas e o que dependia especificamente da normalidade conjunta. Em particular, explique por que covariância nula não implica, em geral, independência e por que a distribuição condicional não é determinada, em uma população arbitrária, apenas pelos dois primeiros momentos.

Exercício 12.3 (Estatística, estimador e estimativa da matriz de covariâncias). Uma amostra aleatória de tamanho $n = 6$ de um vetor com $p = 3$ componentes produziu a matriz SQPC observada

$$\mathbf{T} = \begin{bmatrix} 10 & 2 & 0 \\ 2 & 5 & 1 \\ 0 & 1 & 4 \end{bmatrix}.$$

1. Explique a função de cada um dos objetos a seguir no problema de estimação da matriz de covariâncias:
- a estatística aleatória $\mathbf{T}$;
 - sua realização observada $\mathbf{T}$;

- o parâmetro populacional Σ ;
- um estimador de Σ ;
- a estimativa obtida após a observação da amostra.

Em sua resposta, deixe explícita a diferença entre um objeto aleatório, seu valor observado e o parâmetro populacional que se pretende estimar.

2. A partir de $\mathbf{T}$, calcule numericamente:

- a estimativa não viesada de Σ ;
- a estimativa de máxima verossimilhança de Σ sob o modelo normal multivariado, quando o máximo da verossimilhança existe.

Identifique o divisor utilizado em cada caso. Em seguida, explique por que os dois divisores são diferentes e qual propriedade de cada estimador está sendo considerada em sua construção.

3. Verifique se $\mathbf{T}$ é positiva definida utilizando um critério estudado no Módulo I e apresente a verificação realizada. A partir desse resultado, determine o posto de $\mathbf{T}$ e conclua se, para esta amostra, a estimativa de máxima verossimilhança calculada no item 2 pertence ao espaço das matrizes de covariâncias positivas definidas exigido pelo modelo normal não singular.
4. Os dois estimadores utilizados no item 2 são diferentes para uma amostra finita. Explique por que essa diferença não impede que ambos sejam consistentes para Σ quando p permanece fixo e $n \rightarrow \infty$. Em sua justificativa, relacione os dois estimadores por meio de seus divisores e indique o que ocorre com essa diferença relativa quando n aumenta.
5. Suponha agora que as observações sejam i.i.d. de uma população multivariada que **não** possui distribuição normal, mas possui vetor de médias e matriz de covariâncias finitos. Para cada afirmação a seguir, indique se ela permanece válida, deixa de ser válida em geral ou necessita de hipóteses adicionais:

- $E(\bar{\mathbf{X}}) = \mu$;
- $\text{Cov}(\bar{\mathbf{X}}) = \Sigma/n$;
- $E(\mathbf{S}) = \Sigma$;
- $\mathbf{S} \xrightarrow{P} \Sigma$ quando $n \rightarrow \infty$ e p permanece fixo;
- $(n-1)\mathbf{S}$ possui exatamente distribuição de Wishart;
- $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes.

Explique também por que a matriz $\mathbf{T}/n$ continua podendo ser calculada para uma amostra não normal, mas não deve ser chamada automaticamente de estimativa de máxima verossimilhança de Σ sem que seja especificado um modelo probabilístico cuja verossimilhança conduza a esse estimador.

Exercício 12.4 (Estrutura e hipótese em um modelo linear multivariado). Considere um modelo linear multivariado com $n = 4$ unidades e duas variáveis-resposta:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz de delineamento possui duas colunas: a primeira corresponde ao intercepto e a segunda a uma covariável. Suponha que

$$\text{posto}(\mathbf{Z}) = 2,$$

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{Z}^\top \mathbf{Y} = \begin{bmatrix} 8 & 12 \\ 2 & -2 \end{bmatrix}.$$

Após o ajuste, a SQPC residual observada é

$$\mathbf{E} = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix}.$$

1. Utilize o resultado de mínimos quadrados para o caso em que $\mathbf{Z}$ possui posto completo e calcule numericamente $\widehat{\mathbf{B}}_{\text{obs}}$. Apresente a matriz estimada completa e suas dimensões.
2. Utilizando a organização das linhas e colunas de $\widehat{\mathbf{B}}_{\text{obs}}$, identifique explicitamente:
 - quais elementos correspondem aos interceptos das duas variáveis-resposta;
 - quais elementos correspondem aos coeficientes da covariável nas duas variáveis-resposta;
 - qual coluna reúne os coeficientes do modelo para a primeira resposta;
 - qual coluna reúne os coeficientes do modelo para a segunda resposta.

A interpretação solicitada neste item refere-se à posição e à função dos coeficientes no modelo, pois não foi atribuído um significado específico à covariável.

3. Determine numericamente:
 - o posto r da matriz de delineamento;
 - os graus de liberdade residuais $n - r$;
 - a estimativa não viesada da matriz de covariâncias dos erros.

Apresente a matriz de covariâncias residual estimada.

4. Formule a hipótese de que a covariável não possui efeito linear sobre nenhuma das duas variáveis-resposta na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe as dimensões dessas matrizes e mostre que a hipótese resultante equivale a impor simultaneamente que os dois coeficientes associados à covariável sejam iguais a zero. Justifique também por que essa função de $\mathbf{B}$ é estimável no modelo considerado.

5. O estimador de mínimos quadrados de cada coluna de $\mathbf{B}$ coincide com o estimador obtido ao ajustar separadamente um modelo linear para cada variável-resposta utilizando a mesma matriz $\mathbf{Z}$. Explique por que essa equivalência na estimação dos coeficientes não torna desnecessária a matriz de covariâncias residual. Em sua resposta, indique qual informação sobre a relação entre as respostas é registrada pelos elementos fora da diagonal dessa matriz.

Exercício 12.5 (Resultados exatos, ausência de normalidade e resultados assintóticos). Considere as afirmações a seguir.

I. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

então o vetor de médias amostrais possui exatamente uma distribuição normal multivariada, a SQPC amostral possui distribuição de Wishart e o vetor de médias amostrais é independente da matriz de covariâncias amostral.

II. Para qualquer população com vetor de médias e matriz de covariâncias finitos,

$$(n-1)\mathbf{S}$$

possui exatamente uma distribuição de Wishart.

III. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são i.i.d., possuem vetor de médias μ e matriz de covariâncias finita Σ e a dimensão p permanece fixa, então

$$\sqrt{n}(\bar{\mathbf{X}} - \mu)$$

converge em distribuição para uma distribuição normal multivariada quando $n \rightarrow \infty$, mesmo que a população de origem não possua distribuição normal multivariada.

IV. Se o modelo é identificável, o parâmetro verdadeiro pertence ao interior do espaço paramétrico, log-verossimilhança duas vezes continuamente diferenciável em uma vizinhança do parâmetro verdadeiro, possibilidade de trocar diferenciação e integração ou esperança, a matriz de informação de Fisher é positiva definida, as restrições impostas por H_0 são regulares e a dimensão paramétrica permanece fixa quando $n \rightarrow \infty$, então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_{\nu}^2,$$

em que ν corresponde ao número de restrições independentes impostas por H_0 . Portanto, a distribuição qui-quadrado obtida pelo Teorema de Wilks é assintótica e, em geral, não corresponde à distribuição exata da estatística em amostras finitas.

V. Se a população não possui distribuição normal multivariada, então, mesmo sob amostragem i.i.d. e existência de segundos momentos finitos, o vetor de médias amostrais deixa de ser não viesado para μ e a matriz de covariâncias amostral deixa de ser não viesada e consistente para Σ .

VI. Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0} \quad \text{e} \quad n > p.$$

Para testar

$$H_0 : \mu = \mu_0,$$

considere a estatística

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0).$$

Sob H_0 , a normalidade multivariada das observações, a independência entre as unidades amostrais, a definição positiva de Σ e a condição $n > p$ permitem obter o resultado exato

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}.$$

Se a população não possui distribuição normal multivariada, mas as observações são i.i.d., possuem vetor de médias μ , matriz de covariâncias finita e positiva definida Σ , a matriz de covariâncias amostral satisfaz

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

e p permanece fixo quando

$$n \rightarrow \infty,$$

então, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2.$$

Portanto, fora da normalidade multivariada, a distribuição qui-quadrado é um resultado assintótico. Esse resultado não implica que a transformação de $\mathbf{T}^2$ para a distribuição F permaneça exata em amostras finitas.

Para cada afirmação:

1. Classifique a afirmação como **correta** ou **incorreta** e apresente uma justificativa baseada em um resultado estudado nos capítulos.
2. Para cada afirmação classificada como incorreta, escreva uma versão corrigida, modificando apenas as hipóteses ou a conclusão necessárias para que ela se torne válida.
3. Para cada resultado utilizado, liste explicitamente as hipóteses necessárias à sua validade e indique quais delas já aparecem na respectiva afirmação. Considere, quando pertinente, amostragem i.i.d., independência das unidades, normalidade multivariada, existência de momentos, definição positiva de Σ , dimensão p fixa e condições de regularidade do modelo.

Ao final, explique por que as duas afirmações a seguir são inadequadas:

Se os dados não são normais, os métodos clássicos deixam de funcionar.

e

Se a amostra é grande, os pressupostos deixam de ser importantes.

Em sua resposta, distinga a perda de uma **distribuição exata em amostra finita** da possibilidade de utilizar um **resultado assintótico**, e explique por que independência, existência de momentos e o regime dimensional continuam sendo relevantes quando n cresce.

Exercício 12.6 (T^2 de Hotelling, normalidade e o papel do delineamento). Um estudo mede duas variáveis nos mesmos 10 indivíduos antes e depois de uma intervenção. Para cada indivíduo, define-se o vetor de diferenças

$$\mathbf{D}_i = \mathbf{X}_{i,\text{depois}} - \mathbf{X}_{i,\text{antes}}, \quad i = 1, \dots, 10.$$

Os vetores de diferenças produziram

$$\bar{\mathbf{d}} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\mathbf{S}_D = \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix}.$$

Deseja-se avaliar se houve alteração média conjunta nas duas variáveis após a intervenção.

Admita inicialmente que as condições necessárias para a distribuição exata de T^2 sejam satisfeitas e utilize

$$F_{2,8;0,95} = 4,46.$$

1. Defina o vetor populacional de médias das diferenças μ_D e formule as hipóteses nula e alternativa para avaliar a ausência de alteração média conjunta. Em seguida, explique por que, após a construção dos vetores $\mathbf{D}_i$, o problema pode ser tratado como um problema de uma amostra aplicado aos vetores de diferenças.
2. Identifique explicitamente as condições necessárias para utilizar a distribuição exata de T^2 neste problema. Sua resposta deve considerar:
 - a distribuição conjunta dos vetores $\mathbf{D}_i$;
 - a independência entre indivíduos;
 - a definição positiva da matriz de covariâncias populacional das diferenças;
 - a relação entre o tamanho amostral n e a dimensão p .

Verifique numericamente a condição que envolve n e p .

3. Calcule a estatística T^2 para o teste da hipótese formulada no item 1. Em seguida, utilize a transformação estudada no capítulo para obter a estatística com distribuição F , informe seus graus de liberdade, compare o valor calculado com o valor crítico fornecido e apresente:
 - a decisão estatística ao nível de significância de 5%;
 - a conclusão no contexto da alteração média conjunta das duas variáveis.
4. Escreva a matriz de covariâncias do vetor de diferenças $\mathbf{D}_i$ em função das matrizes de covariâncias das medidas “antes” e “depois” e das covariâncias cruzadas entre essas duas medidas. Utilize essa expressão para explicar precisamente qual informação sobre a dependência dentro de cada indivíduo seria ignorada se as observações “antes” e “depois” fossem tratadas como duas amostras independentes.
5. Suponha, em outro estudo, que as duas condições sejam aplicadas a dois grupos constituídos por indivíduos distintos. Sob independência entre os grupos, normalidade multivariada e uma matriz de covariâncias populacional comum, indique:
 - qual estimador da matriz de covariâncias comum deve ser utilizado;
 - qual versão da estatística T^2 deve ser utilizada para comparar os vetores de médias dos dois grupos;
 - qual característica do delineamento distingue esse problema do problema pareado apresentado no início da questão.
6. Retorne ao estudo pareado original e suponha agora que a normalidade multivariada dos vetores de diferenças $\mathbf{D}_i$ não seja uma hipótese razoável.
 - a. Explique quais quantidades calculadas nos itens anteriores continuam podendo ser obtidas normalmente a partir da amostra, como $\bar{\mathbf{d}}$, $\mathbf{S}_D$ e o valor numérico de T^2 .
 - b. Explique por que, com $n = 10$, a transformação de T^2 para a distribuição F deixa de possuir, em geral, a justificativa de uma distribuição exata.
 - c. Suponha que, em vez de 10 indivíduos, uma sequência de estudos forneça amostras i.i.d. cada vez maiores de vetores de diferenças, com $p = 2$ fixo, segundos momentos finitos e matriz $\Sigma_D \succ \mathbf{0}$. Indique qual distribuição assintótica de T^2 pode ser utilizada sob H_0 quando $n \rightarrow \infty$.
 - d. Explique por que o resultado do item anterior não permite afirmar que a calibração finita pela distribuição F se tornou exata fora da normalidade.

Parte II — Exercícios com uso do R

Nesta parte, os cálculos solicitados devem ser construídos preferencialmente por meio de operações matriciais no R. Quando existir uma função pronta que reproduza diretamente um resultado estudado nos Módulos I ou II, utilize-a somente depois de realizar a construção matricial correspondente e apenas como forma de conferência.

Os códigos devem ser reprodutíveis e os resultados numéricos devem ser acompanhados das interpretações solicitadas. Nos procedimentos inferenciais, identifique as condições que sustentam a distribuição utilizada. A obtenção de uma estatística de teste ou de um valor- p pelo software não constitui, por si só, evidência de que as hipóteses probabilísticas do procedimento sejam satisfeitas.

Exercício 12.7 (Modelo linear multivariado com os dados `swiss`). Utilize o conjunto de dados `swiss`.

Considere como variáveis-resposta:

- `Fertility`;
- `Infant.Mortality`.

Construa

$$\mathbf{Y} = [\text{Fertility} \quad \text{Infant.Mortality}]$$

e uma matriz de delineamento $\mathbf{Z}$ cujas colunas, nesta ordem, correspondam a:

1. `intercepto`;
2. `Agriculture`;
3. `Education`.
4. Determine n , p , q e o posto r de $\mathbf{Z}$. Calcule os graus de liberdade residuais $n - r$. Em seguida, obtenha $\widehat{\mathbf{B}}_{\text{obs}}$ diretamente por operações matriciais e apresente a matriz com as linhas identificadas por `Intercepto`, `Agriculture` e `Education` e as colunas por `Fertility` e `Infant.Mortality`.

Somente depois desse cálculo, ajuste separadamente com `lm()` os dois modelos univariados correspondentes e verifique se seus coeficientes coincidem, salvo diferenças de arredondamento, com as respectivas colunas de $\widehat{\mathbf{B}}_{\text{obs}}$.

5. Calcule a matriz de valores ajustados e a matriz de resíduos $\widehat{\mathbf{U}}$. Verifique numericamente a condição

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}$$

calculando $\mathbf{Z}^\top \widehat{\mathbf{U}}$ e examinando se seus elementos são numericamente próximos de zero.

Explique por que essa propriedade decorre do ajuste por mínimos quadrados e não constitui uma verificação de normalidade dos erros.

6. Construa a SQPC residual

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}$$

e calcule o estimador não viesado da matriz de covariâncias residual. Interprete:

- os elementos da diagonal como variâncias residuais das duas respostas;
- o elemento fora da diagonal como covariância residual entre **Fertility** e **Infant.Mortality** após considerados os efeitos lineares de **Agriculture** e **Education**.

Como a direção constante pertence ao espaço coluna de $\mathbf{Z}$, construa também $\mathbf{T}$ e $\mathbf{T}_{\text{mod}}$ e verifique numericamente

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

7. Formule, na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

a hipótese de que o coeficiente de **Education** é igual a zero simultaneamente nas duas variáveis-resposta. Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe suas dimensões e verifique a condição de estimabilidade.

Não realize um teste multivariado dessa hipótese. O objetivo é construir corretamente a restrição matricial correspondente aos coeficientes de **Education**.

8. Considere os resultados obtidos nos itens anteriores e classifique-os em três grupos:
- a. resultados que decorrem da álgebra de mínimos quadrados e podem ser calculados sem assumir normalidade multivariada dos erros;

b. propriedades de esperança e covariância dos estimadores que exigem condições sobre a média, a independência entre unidades e a estrutura de covariâncias dos erros, mas não necessariamente normalidade;

c. resultados inferenciais exatos, como distribuições normais matriciais, distribuições de Wishart e independência entre estimadores e SQPC residual, cuja derivação depende da normalidade multivariada dos erros.

Para cada grupo, identifique pelo menos um resultado utilizado nesta questão e indique as condições necessárias.

Exercício 12.8 (Comparação multivariada entre regiões dos Estados Unidos). Utilize o conjunto `USArrests` e associe cada estado à sua região por meio dos objetos `state.name` e `state.region`.

Uma possibilidade para construir o vetor de regiões é

```
regiao <- state.region[
  match(
    rownames(USArrests),
    state.name
  )
]
```

Considere apenas os estados classificados nas regiões **South** e **Northeast**. Em cada região, utilize conjuntamente as quatro variáveis quantitativas de `USArrests`.

1. Determine:

- os tamanhos amostrais n_1 e n_2 ;
- a dimensão p ;
- os vetores de médias amostrais;
- as matrizes de covariâncias amostrais.

Calcule também

$$\nu = n_1 + n_2 - 2$$

e verifique se a relação entre ν e p satisfaz a condição dimensional necessária à construção da estatística clássica T^2 para duas amostras.

2. Construa matricialmente a matriz de covariâncias agrupada $\mathbf{S}_p$ e verifique se ela é invertível. Em seguida, calcule a estatística T^2 de Hotelling para testar

$$H_0 : \mu_{\text{South}} = \mu_{\text{Northeast}}.$$

Transforme T^2 para a estatística com distribuição F correspondente e informe:

- o valor de T^2 ;
- o valor da estatística F ;
- os graus de liberdade;
- o valor- p ;
- a decisão ao nível de significância de 5%;
- a conclusão sobre a igualdade dos vetores de médias populacionais.

A conclusão deve se referir ao vetor de quatro médias analisado conjuntamente, e não a cada variável separadamente.

3. A distribuição F utilizada no item anterior é exata sob condições específicas. Identifique explicitamente:

- a independência entre as duas amostras;
- a independência das unidades dentro de cada amostra;
- a normalidade multivariada em cada população;
- a igualdade das matrizes de covariâncias populacionais;
- a definição positiva da matriz de covariâncias comum;
- a condição dimensional necessária à inversão da matriz utilizada em T^2 .

Indique quais dessas condições são características do delineamento e quais são hipóteses sobre as distribuições populacionais.

4. Examine graficamente as quatro variáveis em cada região utilizando gráficos adequados para identificar assimetria acentuada e observações extremas. Utilize também gráficos quantil-quantil normais para cada variável.

A partir desses gráficos, descreva os principais desvios observados em relação à normalidade marginal. Não conclua que a distribuição é normal multivariada apenas porque uma ou mais variáveis apresentam comportamento aproximadamente normal em análises marginais.

Explique por que essas análises podem fornecer informações sobre a plausibilidade da normalidade, mas não demonstram que a hipótese de normalidade multivariada seja satisfeita.

5. Suponha que a normalidade multivariada não seja considerada razoável para esses dados.
- a.** Indique quais das seguintes quantidades continuam perfeitamente definidas como estatísticas calculadas a partir da amostra:
- os vetores de médias amostrais;
 - as matrizes de covariâncias amostrais;
 - a matriz de covariâncias agrupada;
 - o valor numérico de T^2 .
- b.** Explique por que a ausência de normalidade não impede o cálculo dessas quantidades, mas elimina, em geral, a justificativa para afirmar que a transformação de T^2 possui exatamente a distribuição F utilizada no item 2.
- c.** Considere uma sequência de estudos em que $p = 4$ permanece fixo, $n_1 \rightarrow \infty$, $n_2 \rightarrow \infty$, $n_1/(n_1 + n_2) \rightarrow \lambda \in (0, 1)$, as unidades são independentes, as duas populações possuem segundos momentos finitos e compartilham uma matriz de covariâncias positiva definida Σ . Explique por que resultados assintóticos podem ser utilizados para a inferência sobre a diferença entre os vetores de médias mesmo sem normalidade multivariada.
- d.** Explique por que o crescimento dos tamanhos amostrais não transforma a distribuição F de amostra finita, derivada sob normalidade multivariada e matriz de covariâncias comum, em uma distribuição exata fora dessas condições.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13 Problemas e estruturas das técnicas multivariadas

Os Módulos 1 e 2 estabeleceram a base matemática, geométrica, probabilística e inferencial utilizada na Análise Multivariada. Vetores e matrizes fornecem a representação dos dados; distâncias, produtos internos e projeções descrevem sua geometria; autovetores e vetores singulares identificam direções relevantes, enquanto autovalores e valores singulares quantificam magnitudes associadas a essas direções; matrizes de covariâncias e correlações descrevem a estrutura de variabilidade conjunta e de associação linear; e os modelos probabilísticos e inferenciais permitem formular conclusões sobre populações multivariadas.

Neste módulo, esses conhecimentos serão combinados para formular as principais técnicas multivariadas. Cada técnica será tratada como uma construção que articula o problema estatístico aos objetos matemáticos, probabilísticos e inferenciais já desenvolvidos, tornando explícitas as ligações entre esses fundamentos e a solução obtida. O ponto de partida passa a ser o problema estatístico. Redução de dimensionalidade, representação de estruturas latentes, formação de grupos, representação de dissimilaridades, análise de associações em tabelas de contingência, comparação de vetores de médias, discriminação de grupos, associação entre blocos de variáveis e decomposição de preferências exigem formulações distintas (Johnson; Wichern, 2007).

Uma mesma estrutura matemática pode aparecer em técnicas diferentes. A decomposição espectral pode identificar direções de maior variabilidade, fornecer coordenadas para uma representação geométrica ou participar da determinação de direções de separação entre grupos. O significado estatístico depende do objeto analisado e do critério utilizado.

A formulação das técnicas deste módulo será organizada pelos elementos apresentados na Tabela 13.1.

Tabela 13.1: Elementos utilizados na formulação das técnicas multivariadas.

Elemento	Função na formulação
Problema estatístico	Define o objetivo da análise
Estrutura dos dados	Estabelece a forma como a informação está organizada
Objeto matemático	Representa a informação relevante para a técnica

Elemento	Função na formulação
Critério ou modelo	Determina a propriedade otimizada, decomposta ou modelada
Solução	Produce direções, coordenadas, grupos, parâmetros ou funções
Interpretação	Atribui significado estatístico e geométrico à solução

O objetivo deste capítulo é organizar os principais problemas da Análise Multivariada, identificar as estruturas compartilhadas pelas técnicas que serão desenvolvidas nos capítulos seguintes e explicitar como os fundamentos dos Módulos 1 e 2 passam a compor sua formulação.

13.1 Do problema estatístico à técnica multivariada

A presença de várias variáveis em um conjunto de dados caracteriza o contexto multivariado, mas não determina a técnica a ser utilizada. A escolha depende da estrutura que será analisada e do objetivo estabelecido.

Considere a matriz de dados $\mathbf{X}$ definida na Definição 1.6. A mesma matriz pode ser utilizada para construir combinações lineares que concentrem variabilidade, identificar grupos de observações semelhantes ou, quando os grupos são conhecidos, determinar direções que os separem. O conjunto de dados permanece o mesmo, enquanto o objeto de interesse e o critério de solução se modificam.

A Tabela 13.2 reúne as principais correspondências que serão desenvolvidas neste módulo.

Tabela 13.2: Correspondência entre problemas, estruturas e técnicas multivariadas.

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar a variabilidade em menor dimensão	Σ , $\mathbf{S}$, $\mathcal{R}$, $\mathbf{R}$ ou matriz de dados centralizada	Maximização da variância e aproximação de posto reduzido	Análise de Componentes Principais
Explicar associações por dimensões não observadas	Matriz de covariâncias ou correlações	Modelo de fatores comuns	Análise Fatorial
Formar grupos de objetos semelhantes	Matriz de dados ou de dissimilaridades	Critérios de proximidade, dispersão ou ligação	Análise de Agrupamentos

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar proximidades em poucas dimensões	Matriz de dissimilaridades	Reconstrução geométrica ou minimização de discrepâncias	Escalonamento Multidimensional
Representar associações entre categorias	Tabela de contingência	Geometria do qui-quadrado e decomposição da inércia	Análise de Correspondência
Comparar conjuntamente várias respostas	Matrizes de hipótese e erro	Crítérios multivariados de teste	Análise de Variância Multivariada
Separar grupos conhecidos e classificar observações	Médias, covariâncias e dispersões de grupos	Crítério de Fisher ou regra de decisão probabilística	Análise Discriminante
Relacionar dois conjuntos de variáveis	Covariâncias dentro e entre blocos	Maximização da correlação entre combinações lineares	Correlação Canônica
Decompor preferências por atributos	Delineamento de perfis e respostas de preferência	Modelo de utilidade	Análise Conjunta

Os objetos utilizados nessa tabela já começaram a ser construídos nos módulos anteriores. A matriz de dados definida na Definição 1.6 permite trabalhar diretamente com observações e variáveis. A matriz de covariâncias populacional Σ , definida na Definição 8.2, e sua correspondente observada $\mathbf{S}$, definida na Definição 8.11, descrevem a variabilidade conjunta. A matriz de correlações observada $\mathbf{R}$, definida na Definição 8.12, corresponde à estrutura obtida após a padronização marginal das variáveis.

A escolha entre covariâncias e correlações não altera o objetivo estatístico da técnica, mas modifica a representação da variabilidade utilizada na formulação e pode, conseqüentemente, modificar a solução. A matriz de covariâncias preserva as escalas originais, enquanto a matriz de correlações atribui variância unitária às variáveis. Essa diferença será retomada no Capítulo 14 ao formular a Análise de Componentes Principais (ACP) a partir de $\mathbf{S}$ ou $\mathbf{R}$.

Outras técnicas utilizam estruturas diferentes. Agrupamentos e Escalonamento Multidimensional (MDS - *Multidimensional Scaling*) podem partir de dissimilaridades entre objetos. A Análise de Correspondência parte de frequências organizadas em uma tabela de contingência. A Análise de Variância Multivariada (MANOVA - *Multivariate Analysis of Variance*) utiliza a estrutura do modelo linear multivariado. A Correlação Canônica trabalha com dois blocos

de variáveis. A Análise Conjunta utiliza perfis construídos pela combinação de atributos e níveis.

A estrutura de entrada delimita a informação disponível para a técnica. Uma matriz de covariâncias resume relações de segunda ordem entre variáveis. Uma matriz de dissimilaridades representa relações entre pares de objetos. Uma tabela de contingência registra frequências conjuntas entre categorias. A formulação deve preservar essa diferença.

13.2 Classes de problemas multivariados

As técnicas deste módulo podem ser organizadas de acordo com o problema estatístico que resolvem. Essa classificação estabelece a função de cada método antes de sua formulação matemática.

13.2.1 Redução de dimensionalidade

A redução de dimensionalidade substitui uma representação de dimensão elevada por outra de menor dimensão, preservando uma característica definida da informação original.

Na Análise de Componentes Principais, o critério é a variabilidade. As novas dimensões são combinações lineares escolhidas para concentrar sucessivamente a variância. A formulação utilizará projeções, decomposição espectral e decomposição em valores singulares (SVD - *Singular Value Decomposition*) desenvolvidas no Módulo 1.

O mesmo objetivo geral de representar dados em poucas dimensões aparece em outras técnicas, com critérios diferentes. O Escalonamento Multidimensional procura representar relações de proximidade, enquanto a Análise de Correspondência representa associações entre perfis. A propriedade que se procura representar faz parte da definição do problema.

13.2.2 Representação de estruturas latentes

A Análise Fatorial procura representar as associações entre variáveis observadas por meio de um número menor de fatores não observados.

Nesse caso, a matriz de covariâncias passa a ser objeto de um modelo. A formulação separa a parcela de variabilidade associada aos fatores comuns da parcela específica de cada variável.

Essa estrutura distingue a Análise Fatorial da ACP. A ACP procura uma representação da variabilidade observada. A Análise Fatorial especifica um modelo para explicar a covariação entre as variáveis.

13.2.3 Formação de grupos

A Análise de Agrupamentos organiza objetos em grupos sem utilizar classes conhecidas previamente. A solução depende da representação dos objetos, da medida de proximidade e do critério que define a estrutura de grupos.

A distância euclidiana definida na Definição 1.13 fornece uma medida de proximidade já estabelecida no Módulo 1. Outras medidas de proximidade e dissimilaridade serão introduzidas quando necessárias nos capítulos específicos. Na Análise de Agrupamentos, a medida adotada passa a participar da geometria do problema. Métodos baseados em centroides, critérios de ligação ou outras estruturas podem produzir agrupamentos diferentes para os mesmos dados.

Sem um modelo probabilístico explícito, os grupos obtidos representam a solução do critério adotado e não correspondem automaticamente a populações distintas.

13.2.4 Representação de dissimilaridades

O Escalonamento Multidimensional constrói uma configuração de pontos a partir de relações de proximidade entre objetos. O objetivo é obter coordenadas cujas distâncias representem, exatamente ou aproximadamente, as dissimilaridades disponíveis (Borg; Groenen; Mair, 2018).

No MDS clássico, a relação entre distâncias e produtos internos permite reconstruir uma matriz de Gram e obter coordenadas por decomposição espectral. Essa formulação utilizará diretamente a distância euclidiana definida na Definição 1.13, a matriz de Gram de Definição 3.18, a preservação das distâncias pela centralização estabelecida na Proposição 4.15 e os resultados espectrais sintetizados na Tabela 5.2.

Em outras formulações, o ajuste é definido diretamente pela discrepância entre as distâncias da configuração e as relações de dissimilaridade que se deseja representar. No MDS não métrico, a informação preservada é principalmente a ordenação dessas relações.

A estrutura difere da Análise de Agrupamentos. O agrupamento procura uma partição ou hierarquia; o MDS procura uma configuração geométrica.

13.2.5 Representação de associações em tabelas de contingência

A Análise de Correspondência parte de uma tabela de frequências e representa os desvios em relação à independência entre suas categorias.

A técnica utiliza perfis, massas, distância qui-quadrado e uma decomposição de baixa dimensão baseada em SVD (Greenacre, 2017). A geometria resultante difere daquela utilizada para dados quantitativos porque linhas e colunas possuem ponderações determinadas por suas frequências marginais.

O capítulo específico mostrará como a inércia total está relacionada ao afastamento da independência e como sua decomposição produz as dimensões da representação.

13.2.6 Comparação de vetores de médias

Na MANOVA, a comparação de vetores de médias constitui um caso importante de um problema mais geral: testar hipóteses sobre funções estimáveis dos parâmetros de um modelo linear multivariado com várias respostas.

O modelo definido na Definição 11.3 e a hipótese linear geral de Definição 11.17 fornecem a estrutura necessária. A formulação da MANOVA acrescentará os critérios construídos a partir das matrizes de hipótese e erro, sem reconstruir a teoria do modelo linear desenvolvida no Módulo 2.

A análise conjunta das respostas distingue a MANOVA de uma coleção de análises univariadas separadas.

13.2.7 Discriminação e classificação

A Análise Discriminante utiliza grupos conhecidos durante a construção da solução. Seu objetivo pode ser representar as direções de maior separação entre esses grupos ou construir regras de classificação para novas observações.

A formulação geométrica utiliza a relação entre dispersão entre grupos e dispersão dentro dos grupos. A formulação probabilística trata a classificação como um problema de decisão estatística, combinando distribuições condicionais, probabilidades *a priori* e perdas para construir regras de classificação. A distribuição normal multivariada definida na Definição 9.1 e a distância de Mahalanobis definida na Definição 8.9 fornecem parte dessa base.

A Análise Discriminante e a MANOVA compartilham estruturas de dispersão entre e dentro dos grupos, mas possuem objetivos diferentes (Huberty; Olejnik, 2006).

13.2.8 Associação entre blocos de variáveis

A Correlação Canônica considera dois conjuntos de variáveis observados nas mesmas unidades. O objetivo é construir combinações lineares dos dois blocos cuja correlação seja máxima.

A matriz de covariância cruzada Σ_{XY} , definida na Definição 8.3, representa a associação entre os blocos. Sua correspondente observada $\mathbf{S}_{XY}$ foi definida na Definição 8.13.

No Capítulo 21, essas matrizes serão combinadas às covariâncias internas de cada bloco para formular as variáveis e correlações canônicas.

13.2.9 Decomposição de preferências

A Análise Conjunta relaciona respostas de preferência às características que definem alternativas ou perfis.

Em uma formulação aditiva, a preferência é representada por contribuições associadas aos níveis dos atributos. Quando a resposta é métrica, essa estrutura pode ser formulada por meio de um modelo linear cuja matriz de delineamento registra a composição dos perfis.

O problema exige ainda condições de identificação decorrentes da codificação dos atributos e níveis. Esses elementos serão introduzidos no Capítulo 22.

13.3 Diferentes formas de classificar as técnicas

A classificação pelo problema estatístico será a principal organização adotada neste módulo. Outras classificações permitem comparar diferentes características das técnicas.

13.3.1 Interdependência e dependência

Nas técnicas de interdependência, a análise não estabelece previamente uma variável resposta que será explicada pelas demais. ACP, Análise Fatorial, Agrupamentos, Escalonamento Multidimensional e Análise de Correspondência são exemplos usuais.

Nas técnicas de dependência, alguma estrutura previamente definida orienta a análise. A MANOVA possui respostas e efeitos determinados pelo delineamento. A Análise Discriminante utiliza grupos conhecidos. A Análise Conjunta utiliza respostas de preferência.

A Correlação Canônica requer uma qualificação nessa classificação. Em classificações usuais das técnicas multivariadas, ela é frequentemente incluída entre as técnicas de dependência porque os dois blocos de variáveis são definidos previamente. Entretanto, sua formulação matemática básica é simétrica: nenhum dos blocos desempenha necessariamente o papel de resposta, e o critério maximiza a associação entre combinações lineares construídas nos dois conjuntos.

13.3.2 Exploratórias, descritivas, preditivas e inferenciais

Uma técnica exploratória identifica padrões ou estruturas nos dados. Uma técnica descritiva resume uma configuração observada. Uma técnica preditiva produz uma regra aplicável a novas observações. Uma técnica inferencial utiliza a variabilidade amostral para formular conclusões sobre parâmetros ou populações.

Essas finalidades podem coexistir. A ACP é predominantemente exploratória e descritiva em muitas aplicações, embora exista teoria inferencial para componentes populacionais. A

Análise Discriminante descreve a separação entre grupos e também pode produzir regras de classificação. A MANOVA possui finalidade principalmente inferencial.

13.3.3 Supervisionadas e não supervisionadas

Métodos supervisionados utilizam uma informação externa que orienta a construção da solução. Os rótulos dos grupos desempenham esse papel na Análise Discriminante, enquanto o delineamento define os efeitos avaliados na MANOVA.

Métodos não supervisionados constroem a estrutura diretamente a partir dos dados, sem utilizar classes ou respostas previamente especificadas. ACP e Análise de Agrupamentos são exemplos.

Essa classificação não descreve com a mesma precisão todas as técnicas do módulo. Análise Fatorial, Análise de Correspondência e MDS são caracterizadas de forma mais adequada pelo problema estatístico e pela estrutura que procuram representar.

A Tabela 13.3 resume essas classificações.

Tabela 13.3: Classificações complementares das técnicas estudadas no Módulo 3.

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
ACP	Redução de dimensionalidade	Interdependência	Exploratória e descritiva	Não supervisionada
Análise Fatorial	Estrutura latente	Interdependência	Exploratória ou inferencial	Sem resposta externa na formulação exploratória
Análise de Agrupamentos	Formação de grupos	Interdependência	Exploratória e descritiva	Não supervisionada
Escalonamento Multidimensional	Representação de dissimilaridades	Interdependência	Exploratória e descritiva	Não supervisionada
Análise de Correspondência	Associação em tabelas	Interdependência	Exploratória e descritiva	Não supervisionada
MANOVA	Comparação de vetores de médias	Dependência	Inferencial	Delineamento conhecido
Análise Discriminante	Discriminação e classificação	Dependência	Descritiva e preditiva	Grupos conhecidos

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
Correlação Canônica	Associação entre blocos	Dependência em classificações usuais; formulação simétrica	Descritiva e inferencial	Blocos definidos previamente
Análise Conjunta	Decomposição de preferências	Dependência	Explicativa e preditiva	Resposta de preferência observada

A classificação pelo problema estatístico permanece mais diretamente ligada à formulação das técnicas. Por essa razão, os capítulos seguintes serão organizados pelo problema, pelo objeto matemático e pelo critério ou modelo utilizado.

13.4 Estruturas matemáticas recorrentes

As técnicas deste módulo reutilizam um conjunto relativamente pequeno de estruturas desenvolvidas anteriormente. O objetivo desta seção é estabelecer as conexões necessárias, sem repetir definições e demonstrações dos Módulos 1 e 2.

13.4.1 Combinações lineares e projeções

As combinações lineares definidas na Definição 1.8 constroem novas variáveis e novas direções a partir das variáveis originais. Para um vetor aleatório $\mathbf{X}$, sua forma é

$$Y = \mathbf{a}^\top \mathbf{X}.$$

O significado de $\mathbf{a}$ depende do critério da técnica. Na ACP, seus coeficientes definem uma direção de variabilidade. Na Análise Discriminante, definem uma direção de separação entre grupos. Na Correlação Canônica, duas combinações são construídas simultaneamente, uma em cada bloco.

As projeções ortogonais definidas na Definição 3.19 permitem representar observações em subespaços. Essa geometria será utilizada no Capítulo 14 para interpretar a ACP como projeção sobre um subespaço principal.

13.4.2 Formas quadráticas e problemas espectrais

As formas quadráticas definidas na Definição 2.23 aparecem na variância de combinações lineares, em distâncias ponderadas e em diferentes medidas de dispersão. Quando o critério depende da direção escolhida, surgem problemas de otimização espectral.

O quociente de Rayleigh definido na Definição 5.7 relaciona a otimização de uma forma quadrática aos autovalores de uma matriz simétrica. O resultado de Teorema 5.5 será aplicado no Capítulo 14 à matriz de covariâncias para formular as componentes principais.

Quando duas formas quadráticas são comparadas, o quociente de Rayleigh generalizado de Definição 5.12 conduz ao problema de autovalores generalizados descrito no Teorema 5.8. Essa estrutura será retomada na Análise Discriminante e na MANOVA e, em uma formulação equivalente, na Correlação Canônica.

A decomposição espectral, sintetizada na Tabela 5.2, fornece as direções e magnitudes associadas a uma matriz simétrica. A interpretação dessas direções depende da matriz que foi construída.

13.4.3 SVD e representações de baixa dimensão

A decomposição em valores singulares relaciona os espaços de linhas e colunas de uma matriz e permite construir aproximações de posto reduzido. Suas propriedades foram sintetizadas na Tabela 6.7.

No Módulo 3, a SVD aparecerá em diferentes contextos. Na ACP, será aplicada à matriz de dados centralizada. Na Análise de Correspondência, será aplicada a uma matriz de desvios padronizados da independência. Na Correlação Canônica, poderá ser aplicada a uma matriz que representa a associação entre dois blocos após transformações determinadas por suas covariâncias.

O mecanismo algébrico é compartilhado, mas a matriz decomposta e o significado estatístico de seus fatores são diferentes.

13.4.4 Distâncias, matrizes de Gram e métricas

Distâncias organizam relações de proximidade entre observações; quando uma técnica admite dissimilaridades mais gerais, elas serão especificadas no capítulo correspondente. A distância euclidiana já foi definida na Definição 1.13. A matriz de Gram definida na Definição 3.18 organiza produtos internos e estabelece a ligação entre coordenadas e distâncias.

No MDS clássico, essa relação será utilizada no sentido inverso. A partir das distâncias, será construída uma matriz de Gram cuja decomposição espectral fornecerá coordenadas para os objetos.

Na Análise de Agrupamentos, as distâncias participam da definição dos grupos. A mesma matriz de dissimilaridades pode, portanto, alimentar técnicas com resultados diferentes.

A distância de Mahalanobis, definida na Definição 8.9, acrescenta a estrutura de dispersão à geometria. A expressão em eixos espectrais apresentada em Equação 8.49 mostra que o afastamento é ponderado pela variabilidade existente em cada direção. Essa estrutura será retomada na formulação probabilística da Análise Discriminante.

13.4.5 Covariâncias entre blocos

A covariância cruzada representa a associação linear entre dois vetores aleatórios. O Módulo 2 definiu esse objeto na Definição 8.3 e apresentou sua versão observada na Definição 8.13.

Essa estrutura será utilizada diretamente na Correlação Canônica. As covariâncias internas dos blocos controlam a variabilidade de cada conjunto, enquanto a covariância cruzada representa a associação que será maximizada por combinações lineares.

A formulação transforma um problema entre dois conjuntos de variáveis em um problema de associação entre dois espaços.

13.4.6 Modelos lineares e probabilísticos

O modelo linear multivariado definido na Definição 11.3 organiza conjuntamente várias respostas, um delineamento e uma matriz de parâmetros. A hipótese linear geral de Definição 11.17 fornece a estrutura para testar combinações desses parâmetros.

A MANOVA será formulada diretamente a partir desses resultados. O novo conteúdo será a construção e interpretação dos critérios multivariados associados às matrizes de hipótese e erro.

A Análise Conjunta também poderá utilizar uma estrutura linear, mas com interpretação própria. A matriz de delineamento representa os níveis dos atributos que compõem os perfis, enquanto os coeficientes representam contribuições para a preferência.

Outras técnicas acrescentam estruturas probabilísticas específicas à sua formulação. A Análise Fatorial especifica um modelo para a matriz de covariâncias utilizando fatores comuns e variâncias específicas; determinadas formas de estimação, como a máxima verossimilhança sob um modelo normal, acrescentam hipóteses probabilísticas específicas. A Análise Discriminante pode utilizar distribuições condicionais aos grupos para construir regras de classificação. Quando a normalidade multivariada é utilizada, sua definição e suas propriedades são as estabelecidas na Definição 9.1.

Essas hipóteses probabilísticas devem ser distinguidas das estruturas algébricas e geométricas utilizadas na formulação das técnicas. A normalidade multivariada, por exemplo, não constitui uma condição geral para toda construção baseada em combinações lineares, formas quadráticas,

projeções ou decomposições matriciais. Quando uma hipótese distribucional for necessária para estimação ou inferência, essa função será explicitada no capítulo correspondente.

Da mesma forma, quando uma técnica utilizar máxima verossimilhança ou comparação de modelos por verossimilhanças, serão retomadas a função de verossimilhança definida na Definição 10.11 e a razão de verossimilhanças definida na Definição 12.3. Os resultados inferenciais também preservarão a distinção entre resultados exatos e assintóticos estabelecida na Definição 12.1.

A Tabela 13.4 reúne essas conexões.

Tabela 13.4: Estruturas dos Módulos 1 e 2 reutilizadas na formulação das técnicas.

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Combinações lineares	Construção de novas direções ou variáveis	ACP, Discriminante, Correlação Canônica
Projeções	Representação em subespaços e direções discriminantes	ACP, Discriminante
Formas quadráticas	Medida de variabilidade, distância ou separação	ACP, Discriminante, MANOVA
Autovalores e autovetores	Magnitudes e direções extremas de matrizes simétricas	ACP, MDS clássico
Autovalores e autovetores generalizados	Comparação entre formas quadráticas e determinação de direções extremas	Discriminante, MANOVA, Correlação Canônica
SVD	Associação entre espaços e aproximação de baixa dimensão	ACP, Correspondência, Correlação Canônica
Distâncias	Representação da proximidade entre objetos	Agrupamentos, MDS
Matriz de Gram	Relação entre distâncias, produtos internos e coordenadas	MDS clássico
Covariâncias e correlações	Representação da variabilidade conjunta e da associação linear	ACP, Fatorial, Discriminante, Correlação Canônica
Covariância cruzada	Associação linear entre dois blocos	Correlação Canônica
Dispersão dentro e entre grupos	Comparação da estrutura de grupos	Agrupamentos, Discriminante, MANOVA
Modelo linear multivariado	Representação conjunta de respostas e efeitos	MANOVA

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Normal multivariada	Formulações probabilísticas e resultados inferenciais sob hipóteses específicas	Fatorial por máxima verossimilhança, Discriminante, MANOVA
Função e razão de verossimilhanças	Estimação e comparação de modelos sob hipóteses probabilísticas	Fatorial por máxima verossimilhança, MANOVA

13.5 Mesmas estruturas, diferentes interpretações

Uma operação matemática adquire significado estatístico a partir do objeto ao qual é aplicada.

A decomposição espectral de uma matriz de covariâncias fornece direções de variabilidade. A decomposição espectral de uma matriz de Gram reconstruída a partir de distâncias fornece coordenadas para uma configuração. Um problema de autovalores generalizados envolvendo duas matrizes de dispersão produz direções que comparam essas fontes de variabilidade.

A SVD apresenta a mesma característica. Aplicada à matriz de dados centralizada, participa da formulação da ACP. Aplicada aos desvios padronizados de uma tabela de contingência, produz os eixos da Análise de Correspondência. Aplicada a uma estrutura que relaciona dois blocos de variáveis, produz pares associados à Correlação Canônica.

A Tabela 13.5 resume essas diferenças.

Tabela 13.5: Exemplos de estruturas matemáticas com diferentes significados estatísticos.

Operação matemática	Objeto analisado	Significado da solução
Decomposição espectral	Matriz de covariâncias	Direções e variâncias principais
Decomposição espectral	Matriz de Gram derivada de distâncias	Coordenadas de uma configuração
Autovalores generalizados	Dispersão entre e dentro dos grupos	Direções de separação
Autovalores generalizados	Matrizes de hipótese e erro	Dimensões associadas ao efeito multivariado
SVD	Matriz de dados centralizada	Direções, escores e representação de baixa dimensão
SVD	Desvios padronizados da independência	Eixos de associação entre categorias

Operação matemática	Objeto analisado	Significado da solução
SVD	Associação transformada entre dois blocos	Pares de direções canônicas

A interpretação de um autovalor, autovetor, valor singular, vetor singular ou coordenada exige, portanto, a identificação da matriz de origem e do critério que definiu sua construção.

13.6 Relações entre as técnicas

Algumas técnicas apresentam estruturas matemáticas próximas, mas resolvem problemas diferentes. A Tabela 13.6 reúne as distinções que serão retomadas ao longo do módulo.

Tabela 13.6: Relações conceituais entre técnicas do Módulo 3.

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Análise Fatorial	Covariâncias, correlações e baixa dimensão	ACP representa variabilidade; Fatorial modela covariação por fatores comuns
Agrupamentos e Discriminante	Estrutura de grupos e medidas de separação	Agrupamentos constrói grupos; Discriminante utiliza grupos conhecidos
Agrupamentos e MDS	Dissimilaridades entre objetos	Agrupamentos produz partições ou hierarquias; MDS produz coordenadas
ACP e MDS clássico	Representações espectrais de baixa dimensão	ACP parte de variáveis e covariâncias; MDS parte de distâncias
MANOVA e Discriminante	Dispersão entre e dentro dos grupos	MANOVA testa efeitos; Discriminante representa separação e classifica
ACP e Correlação Canônica	Combinações lineares	ACP maximiza variância em um bloco; Canônica maximiza associação entre dois blocos
ACP e Correspondência	Decomposições de baixa dimensão	ACP utiliza geometria de covariâncias; Correspondência utiliza perfis e geometria qui-quadrado

A relação entre ACP e Análise Fatorial será retomada imediatamente após a formulação dessas técnicas. A conexão entre ACP e MDS aparecerá quando as dissimilaridades forem distâncias euclidianas derivadas de dados quantitativos. A relação entre MANOVA e Análise Discriminante será estabelecida a partir das estruturas de dispersão associadas aos grupos.

Essas conexões mostram por que a técnica deve ser identificada pelo problema estatístico e não pela operação matricial utilizada.

13.7 Síntese

As técnicas multivariadas deste módulo utilizam os fundamentos construídos nos Módulos 1 e 2 para resolver problemas estatísticos específicos. A formulação de cada técnica combina uma estrutura de dados, um objeto matemático e um critério ou modelo.

Combinações lineares e projeções produzem novas direções e representações. Formas quadráticas e problemas espectrais permitem otimizar variabilidade e separação. A SVD fornece representações de baixa dimensão e relaciona diferentes espaços. Distâncias e matrizes de Gram conectam proximidades e coordenadas. Matrizes de covariâncias representam a estrutura de variabilidade conjunta de segunda ordem e quantificam associações lineares. Covariâncias cruzadas relacionam blocos. Modelos lineares organizam respostas e efeitos. Modelos probabilísticos acrescentam hipóteses que permitem desenvolver formas específicas de estimação e inferência. A interpretação de cada técnica resulta, assim, da integração entre essas estruturas e o problema estatístico que determinou sua formulação.

Os capítulos seguintes utilizarão esses resultados sem reconstruir seus fundamentos. O Capítulo 14 inicia esse percurso com a Análise de Componentes Principais, formulada a partir da variância de combinações lineares, do quociente de Rayleigh, da decomposição espectral, das projeções e da SVD.

14 Formulação da Análise de Componentes Principais

A Análise de Componentes Principais (ACP) representa a variabilidade de um conjunto de variáveis por meio de combinações lineares ordenadas segundo a variância que concentram (Jolliffe, 2002).

Sua formulação reutiliza os fundamentos dos módulos anteriores sobre combinações lineares, projeções ortogonais, quociente de Rayleigh, decomposição espectral, SVD e matrizes de covariâncias e correlações. O mesmo problema pode ser caracterizado pela maximização sucessiva da variância, pela projeção sobre subespaços principais e pela aproximação de posto reduzido da matriz de dados centralizada.

O capítulo desenvolve essas formulações e suas relações. A ACP depende da estrutura de segunda ordem e não exige normalidade multivariada para sua definição; a normalidade acrescenta propriedades probabilísticas e resultados inferenciais específicos.

14.1 O problema de redução de dimensionalidade

Considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com vetor de médias μ e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Cada realização $\mathbf{x} \in \mathbb{R}^p$ representa uma unidade por meio de p coordenadas. Quando várias dessas coordenadas apresentam associação linear, a variabilidade conjunta pode estar concentrada em um número menor de direções.

Essa situação pode ser entendida geometricamente. Uma nuvem de pontos em $\mathbb{R}^2$ pode apresentar grande extensão em uma direção e pequena extensão na direção ortogonal, como será ilustrado na Figura 14.1. Embora duas coordenadas sejam necessárias para representar exatamente cada ponto, uma única direção pode concentrar a maior parte da dispersão da nuvem. Em dimensão p , o mesmo princípio conduz à procura de um subespaço de dimensão $k < p$ que represente adequadamente a variabilidade dos dados.

A ACP não seleciona diretamente k variáveis dentre as p variáveis originais. Ela constrói novas variáveis como combinações lineares das componentes de $\mathbf{X}$. Cada nova variável corresponde a uma direção no espaço das variáveis.

O vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

tem média nula e preserva a matriz de covariâncias de $\mathbf{X}$. A centralização separa a localização da distribuição de sua estrutura de dispersão. Por isso, a formulação populacional da ACP pode ser construída diretamente a partir de $\mathbf{X}_c$ e de Σ .

Uma direção unitária

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

produz a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}_c.$$

Como $\mathbf{a}$ possui norma unitária, Y representa a coordenada de $\mathbf{X}_c$ na direção definida por $\mathbf{a}$. Pelo resultado sobre momentos de combinações lineares apresentado na Proposição 8.1,

$$E(Y) = 0$$

e

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A variância da combinação linear depende, portanto, da direção $\mathbf{a}$. Algumas direções podem apresentar grande dispersão, enquanto outras apresentam pequena dispersão.

A ACP utiliza essa diferença para ordenar as direções. O primeiro objetivo consiste em encontrar a direção unitária de maior variabilidade. Depois são procuradas novas direções, ortogonais às anteriores, que preservem sucessivamente a maior variabilidade restante.

A Figura 14.1 representa uma nuvem bidimensional com variabilidade distinta segundo diferentes direções. A primeira direção principal acompanha a maior extensão da nuvem, enquanto a segunda é ortogonal à primeira e representa a variabilidade remanescente.




Figura 14.1: As direções principais acompanham os eixos de maior e menor variabilidade da nuvem de observações.

A maior dispersão ocorre na direção da primeira componente. A segunda componente representa a maior variabilidade possível entre as direções ortogonais à primeira. A figura transforma a ideia de maximização da variância em uma propriedade geométrica da nuvem.

A redução de dimensionalidade ocorre quando apenas as primeiras $k < p$ direções são mantidas. A qualidade dessa representação depende da concentração da variabilidade nessas direções. Quando grande parte da variância total se concentra nas primeiras componentes, poucas direções podem representar adequadamente os dados. Quando a variabilidade se distribui de forma mais uniforme entre as componentes, a redução de dimensão implica perda proporcionalmente maior de informação.

14.2 Componentes principais como combinações lineares

A j -ésima componente principal populacional tem a forma

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c = \mathbf{a}_j^\top (\mathbf{X} - \boldsymbol{\mu}),$$

em que

$$\mathbf{a}_j \in \mathbb{R}^p$$

é o vetor de coeficientes da componente.

É importante distinguir os objetos envolvidos na formulação:

- $\mathbf{a}_j$ define uma direção no espaço das variáveis;
- Y_j é uma variável aleatória obtida pela projeção de $\mathbf{X}_c$ nessa direção;
- a variância de Y_j quantifica a dispersão populacional representada pela direção;
- posteriormente, a versão amostral de $\mathbf{a}_j$ permitirá calcular os escores das observações.

Para duas combinações lineares,

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

e

$$Y_\ell = \mathbf{a}_\ell^\top \mathbf{X}_c,$$

tem-se

$$\text{Cov}(Y_j, Y_\ell) = \mathbf{a}_j^\top \boldsymbol{\Sigma} \mathbf{a}_\ell.$$

Assim, a matriz Σ determina simultaneamente a variabilidade de cada direção e a covariância entre diferentes combinações lineares.

A restrição de norma unitária é necessária porque a variância depende da escala do vetor de coeficientes. Para qualquer constante c ,

$$\text{Var}(c\mathbf{a}^\top \mathbf{X}_c) = c^2 \mathbf{a}^\top \Sigma \mathbf{a}.$$

Sem controlar a norma de $\mathbf{a}$, a variância poderia ser aumentada apenas multiplicando os coeficientes por uma constante. A condição

$$\mathbf{a}^\top \mathbf{a} = 1$$

remove esse efeito de escala e transforma o problema em uma escolha de direção.

14.3 Primeira componente principal

A primeira componente principal é definida pela direção unitária que apresenta a maior variância.

O problema é

$$\max_{\mathbf{a}_1 \in \mathbb{R}^p} \mathbf{a}_1^\top \Sigma \mathbf{a}_1,$$

sujeito a

$$\mathbf{a}_1^\top \mathbf{a}_1 = 1.$$

Esse problema já possui a forma estudada no Módulo 1. O quociente de Rayleigh foi definido na Definição 5.7 e seus extremos foram caracterizados no Teorema 5.5. Aplicando esse resultado à matriz simétrica e semidefinida positiva Σ , o máximo é igual ao maior autovalor da matriz de covariâncias.

A variação do quociente de Rayleigh segundo a direção foi ilustrada na Figura 5.4. Na ACP, a matriz utilizada naquele problema passa a ser Σ , e o máximo do quociente corresponde à maior variância possível de uma combinação linear com coeficientes de norma unitária.

Se os autovalores de Σ forem ordenados como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

e $\mathbf{a}_1$ for um autovetor unitário associado a λ_1 , então

$$\Sigma \mathbf{a}_1 = \lambda_1 \mathbf{a}_1.$$

A primeira componente principal é

$$Y_1 = \mathbf{a}_1^\top \mathbf{X}_c,$$

e sua variância é

$$\begin{aligned} \text{Var}(Y_1) &= \mathbf{a}_1^\top \Sigma \mathbf{a}_1 \\ &= \mathbf{a}_1^\top \lambda_1 \mathbf{a}_1 \\ &= \lambda_1. \end{aligned}$$

Portanto,

$$\text{Var}(Y_1) = \lambda_1.$$

O maior autovalor possui uma interpretação estatística direta: ele é a maior variância que pode ser obtida por uma combinação linear das variáveis com vetor de coeficientes de norma unitária.

O autovetor correspondente fornece a direção em que essa variância é alcançada. A primeira componente principal transforma esse resultado geométrico em uma nova variável.

A derivação por multiplicadores de Lagrange não precisa ser reconstruída aqui. O resultado geral que relaciona a otimização de uma forma quadrática aos autovetores já foi demonstrado no Teorema 5.6. A ACP utiliza esse resultado com

$$\mathbf{A} = \Sigma.$$

14.4 Componentes principais sucessivas

A primeira direção concentra a maior variabilidade possível em uma única coordenada. As componentes seguintes devem acrescentar novas direções sem repetir a informação linear já representada.

A segunda componente principal é definida como a combinação linear de maior variância entre as direções unitárias ortogonais à primeira:

$$\max_{\mathbf{a}_2 \in \mathbb{R}^p} \mathbf{a}_2^\top \Sigma \mathbf{a}_2,$$

sujeito a

$$\mathbf{a}_2^\top \mathbf{a}_2 = 1$$

e

$$\mathbf{a}_2^\top \mathbf{a}_1 = 0.$$

O mesmo princípio é aplicado sucessivamente. Para $j = 1, \dots, p$, a j -ésima direção principal resolve

$$\max_{\mathbf{a}_j \in \mathbb{R}^p} \mathbf{a}_j^\top \Sigma \mathbf{a}_j,$$

sujeito a

$$\mathbf{a}_j^\top \mathbf{a}_j = 1$$

e

$$\mathbf{a}_j^\top \mathbf{a}_\ell = 0, \quad \ell = 1, \dots, j-1.$$

A caracterização variacional de direções sucessivas já foi estabelecida no Teorema 5.7. Aplicando esse resultado a Σ , obtém-se

$$\Sigma \mathbf{a}_j = \lambda_j \mathbf{a}_j, \quad j = 1, \dots, p.$$

Assim, pode-se escolher uma base ortonormal de autovetores da matriz de covariâncias, ordenada de acordo com os autovalores decrescentes, para definir as direções principais. Quando um autovalor possui multiplicidade maior que um, os autovetores individuais dentro do autoespaço correspondente não são únicos; essa questão será retomada ao discutir as propriedades da solução.

A j -ésima componente principal é

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

e possui variância

$$\text{Var}(Y_j) = \lambda_j.$$

Para $j \neq \ell$,

$$\begin{aligned}\text{Cov}(Y_j, Y_\ell) &= \mathbf{a}_j^\top \Sigma \mathbf{a}_\ell \\ &= \lambda_\ell \mathbf{a}_j^\top \mathbf{a}_\ell \\ &= 0.\end{aligned}$$

Logo, as componentes principais são não correlacionadas:

$$\text{Cov}(Y_j, Y_\ell) = 0, \quad j \neq \ell.$$

Duas propriedades diferentes aparecem nessa construção. Os vetores de coeficientes são ortogonais,

$$\mathbf{a}_j^\top \mathbf{a}_\ell = 0,$$

enquanto as componentes principais são não correlacionadas,

$$\text{Cov}(Y_j, Y_\ell) = 0.$$

A primeira propriedade pertence à geometria dos vetores de coeficientes. A segunda pertence à estrutura probabilística das variáveis construídas. Na ACP, a equação de autovetores

$$\Sigma \mathbf{a}_\ell = \lambda_\ell \mathbf{a}_\ell$$

faz a ligação entre essas duas propriedades.

A ausência de correlação não implica independência em uma distribuição geral. Se $\mathbf{X}$ possui distribuição normal multivariada, qualquer transformação linear também é normal, conforme Proposição 9.4. Nesse caso, o vetor das componentes principais é normal multivariado e possui matriz de covariâncias diagonal. Pelo resultado de independência para blocos normais de Proposição 9.6, as componentes principais são independentes.

A normalidade, portanto, acrescenta uma propriedade probabilística às componentes, mas não participa da definição da ACP.

14.5 Formulação espectral

Reunindo os vetores de coeficientes em

$$\mathbf{A} = \begin{pmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_p \end{pmatrix},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

A matriz $\mathbf{A}$ é ortogonal. Pelo Teorema Espectral de Teorema 5.4,

$$\Sigma = \mathbf{A} \Lambda \mathbf{A}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p).$$

As componentes podem ser reunidas no vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_p \end{pmatrix} = \mathbf{A}^\top \mathbf{X}_c.$$

Como

$$E(\mathbf{X}_c) = \mathbf{0},$$

tem-se

$$E(\mathbf{Y}) = \mathbf{0}.$$

Pela regra de transformação da matriz de covariâncias estabelecida na Equação 8.18,

$$\text{Cov}(\mathbf{A}^\top \mathbf{X}_c) = \mathbf{A}^\top \Sigma \mathbf{A}.$$

Substituindo a decomposição espectral,

$$\begin{aligned}\text{Cov}(\mathbf{Y}) &= \mathbf{A}^\top \mathbf{A} \mathbf{\Lambda} \mathbf{A}^\top \mathbf{A} \\ &= \mathbf{\Lambda}.\end{aligned}$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}.$$

A transformação para componentes principais diagonaliza a estrutura de covariâncias. As variáveis originais podem apresentar covariâncias diferentes de zero; no novo sistema de coordenadas, toda a variabilidade aparece distribuída ao longo de eixos não correlacionados.

A transformação completa

$$\mathbf{X}_c \mapsto \mathbf{Y} = \mathbf{A}^\top \mathbf{X}_c$$

não reduz a dimensão. Ela representa o mesmo vetor em uma base ortonormal diferente. Pela propriedade de preservação geométrica das transformações ortogonais estabelecida na Proposição 4.10, produtos internos, normas e distâncias são preservados quando todas as p componentes são mantidas.

A redução ocorre somente quando a transformação é seguida pela retenção das primeiras $k < p$ coordenadas.

14.6 Variância total e proporção de variância

A variância total foi definida na Definição 8.6 por

$$V_T = \text{tr}(\Sigma).$$

Pela relação entre traço e autovalores estabelecida na Proposição 5.4,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Por outro lado,

$$\text{Cov}(\mathbf{Y}) = \Lambda,$$

de modo que

$$\text{tr}[\text{Cov}(\mathbf{Y})] = \sum_{j=1}^p \lambda_j.$$

Assim,

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

A ACP completa redistribui, entre novas coordenadas, a mesma variabilidade total presente nas variáveis originais. A ordenação dos autovalores concentra as maiores parcelas nas primeiras componentes.

Se

$$\text{tr}(\Sigma) > 0,$$

a proporção da variância total associada à componente j é

$$\pi_j = \frac{\lambda_j}{\sum_{\ell=1}^p \lambda_\ell}.$$

Para as primeiras k componentes, a proporção acumulada é

$$\Pi_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{\ell=1}^p \lambda_\ell}.$$

A variabilidade representada pelas primeiras k direções é

$$\sum_{j=1}^k \lambda_j,$$

enquanto a variabilidade associada às direções descartadas é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição pode ser resumida pela Tabela 14.1.

Tabela 14.1: Relação entre componentes principais, direções, autovalores e variância representada, quando a variância total é positiva.

Componente	Direção	Variância	Proporção da variância total
Y_1	$\mathbf{a}_1$	λ_1	$\lambda_1 / \sum_{\ell=1}^p \lambda_\ell$
Y_2	$\mathbf{a}_2$	λ_2	$\lambda_2 / \sum_{\ell=1}^p \lambda_\ell$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Y_p	$\mathbf{a}_p$	λ_p	$\lambda_p / \sum_{\ell=1}^p \lambda_\ell$

Exemplo 14.1 (Componentes principais de duas variáveis). Considere um vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}.$$

A decomposição espectral fornece os autovalores

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{a}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

e

$$\mathbf{a}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

A primeira componente principal é

$$Y_1 = \frac{(X_1 - \mu_1) + (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_1) = 6.$$

A segunda componente é

$$Y_2 = \frac{(X_1 - \mu_1) - (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_2) = 2.$$

Como

$$\Sigma \mathbf{a}_2 = \lambda_2 \mathbf{a}_2$$

e

$$\mathbf{a}_1^\top \mathbf{a}_2 = 0,$$

tem-se

$$\begin{aligned}\text{Cov}(Y_1, Y_2) &= \mathbf{a}_1^\top \Sigma \mathbf{a}_2 \\ &= \lambda_2 \mathbf{a}_1^\top \mathbf{a}_2 \\ &= 0.\end{aligned}$$

Portanto, as duas componentes são não correlacionadas.

A variância total é

$$\text{tr}(\Sigma) = 4 + 4 = 8,$$

que coincide com

$$\lambda_1 + \lambda_2 = 6 + 2 = 8.$$

A primeira componente representa

$$\frac{6}{8} = 75\%$$

da variabilidade total, enquanto a segunda representa

$$\frac{2}{8} = 25\%.$$

Se a representação for reduzida de duas para uma dimensão, a direção

$$\mathbf{a}_1$$

preserva 75% da variabilidade e descarta 25%. Nesse exemplo, a redução de dimensão possui interpretação direta: a maior parte da dispersão ocorre na direção em que as duas variáveis se deslocam conjuntamente.

A Figura 14.2 mostra, em um exemplo didático, duas leituras complementares dos autovalores. O primeiro painel apresenta a variância associada individualmente a cada componente. O segundo apresenta a proporção acumulada da variância representada pelas primeiras componentes.




Figura 14.2: Os autovalores quantificam a variância de cada componente, e sua soma acumulada determina a proporção da variabilidade representada pelas primeiras dimensões.

A concentração dos primeiros autovalores determina a capacidade de redução linear de dimensão. Quando Π_k é elevada para um valor pequeno de k , o subespaço principal representa grande

parcela da variabilidade total. A proporção acumulada descreve a decomposição da variância, mas não estabelece um limite para a escolha do número de componentes.

A formulação até este ponto mostra que a ACP transforma o problema estatístico de preservar variabilidade em poucas direções em um problema espectral já resolvido matematicamente no Módulo 1. O passo seguinte consiste em mostrar que as primeiras k direções também definem um subespaço que maximiza a variabilidade projetada e minimiza o erro quadrático de reconstrução.

14.7 Subespaço principal e projeção

As primeiras $k < p$ componentes principais definem um subespaço de dimensão k no qual a variabilidade de $\mathbf{X}$ será representada.

Considere uma base ortonormal de autovetores de Σ ,

$$\mathbf{a}_1, \dots, \mathbf{a}_p,$$

ordenada de modo que

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Defina

$$\mathbf{A}_k = (\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k) \in \mathbb{R}^{p \times k}.$$

Como esses vetores são ortonormais,

$$\mathbf{A}_k^\top \mathbf{A}_k = \mathbf{I}_k.$$

Suas colunas geram um subespaço que maximiza a variabilidade projetada em dimensão k .

Definição 14.1 (Subespaço principal). Seja

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias, com autovalores ordenados como

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0,$$

e seja

$$\mathbf{a}_1, \dots, \mathbf{a}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação.

Para $1 \leq k \leq p$, um **subespaço principal de dimensão k** é

$$\mathcal{S}_k = \text{span} \{ \mathbf{a}_1, \dots, \mathbf{a}_k \}.$$

Se $k < p$ e

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único. Se

$$\lambda_k = \lambda_{k+1},$$

podem existir diferentes subespaços principais de dimensão k que preservam a mesma variabilidade máxima.

A matriz de projeção ortogonal sobre um subespaço principal $\mathcal{S}_k$ é

$$\mathbf{P}_k = \mathbf{A}_k \mathbf{A}_k^\top.$$

Essa expressão é uma aplicação direta da projeção sobre um subespaço com base ortonormal desenvolvida na Proposição 3.14.

As coordenadas de $\mathbf{X}_c$ nesse subespaço são

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c = \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix}.$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}_k) &= \mathbf{A}_k^\top \Sigma \mathbf{A}_k \\ &= \text{diag}(\lambda_1, \dots, \lambda_k). \end{aligned}$$

Portanto, a variância total das coordenadas mantidas é

$$\text{tr} [\text{Cov} (\mathbf{Y}_k)] = \sum_{j=1}^k \lambda_j.$$

Esse resultado fornece uma interpretação conjunta das primeiras k componentes. A ACP não procura somente a melhor primeira direção e depois as seguintes de forma isolada. O conjunto das primeiras k direções determina um subespaço que concentra a maior variabilidade possível entre os subespaços lineares de mesma dimensão.

Considere qualquer matriz

$$\mathbf{Q} = (\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k) \in \mathbb{R}^{p \times k},$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

A projeção de $\mathbf{X}_c$ sobre o subespaço gerado por $\mathbf{Q}$ possui coordenadas

$$\mathbf{Q}^\top \mathbf{X}_c$$

e variância total

$$\text{tr} (\mathbf{Q}^\top \Sigma \mathbf{Q}) = \sum_{j=1}^k \mathbf{q}_j^\top \Sigma \mathbf{q}_j.$$

O resultado para uma única direção se estende ao conjunto das primeiras k direções.

Proposição 14.1 (Variabilidade máxima do subespaço principal). *Seja*

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias com autovalores

$$\lambda_1 \geq \cdots \geq \lambda_p \geq 0.$$

Para $1 \leq k \leq p$ e qualquer matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$

Portanto, a maior variância total que pode ser preservada por uma projeção ortogonal em um subespaço de dimensão k é

$$\sum_{j=1}^k \lambda_j.$$

Esse máximo é atingido por qualquer subespaço principal $\mathcal{S}_k$ de Definição 14.1.

Se $k < p$ e

$$\lambda_k > \lambda_{k+1},$$

o subespaço que maximiza a variância é único. Se

$$\lambda_k = \lambda_{k+1},$$

o subespaço maximizador pode não ser único.

Comprovação. Pelo Teorema Espectral de Teorema 5.4,

$$\Sigma = \mathbf{A} \mathbf{\Lambda} \mathbf{A}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_1 \geq \dots \geq \lambda_p.$$

Defina

$$\mathbf{B} = \mathbf{A}^\top \mathbf{Q}.$$

Como $\mathbf{A}$ é ortogonal e as colunas de $\mathbf{Q}$ são ortonormais,

$$\mathbf{B}^\top \mathbf{B} = \mathbf{I}_k.$$

Logo,

$$\begin{aligned} \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) &= \text{tr}(\mathbf{B}^\top \Lambda \mathbf{B}) \\ &= \sum_{i=1}^p \lambda_i w_i, \end{aligned}$$

em que

$$w_i = \sum_{j=1}^k b_{ij}^2.$$

Como

$$\mathbf{B} \mathbf{B}^\top$$

é um projetor ortogonal,

$$0 \leq w_i \leq 1$$

e

$$\sum_{i=1}^p w_i = \text{tr}(\mathbf{B} \mathbf{B}^\top) = k.$$

Como os autovalores estão em ordem decrescente, a soma

$$\sum_{i=1}^p \lambda_i w_i$$

não pode exceder a soma dos k maiores autovalores. Portanto,

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$

A igualdade é atingida tomando

$$\mathbf{Q} = \mathbf{A}_k.$$

Se

$$\lambda_k > \lambda_{k+1},$$

a separação entre os k maiores autovalores e os demais determina unicamente o subespaço maximizador. Quando há empate na fronteira,

$$\lambda_k = \lambda_{k+1},$$

diferentes escolhas de direções dentro do autoespaço correspondente podem produzir subespaços de dimensão k com o mesmo valor máximo. $\square$

Para $k = 1$, o resultado recupera a direção de variância máxima. Para $k > 1$, estabelece que as primeiras componentes definem conjuntamente um subespaço que concentra a maior variabilidade possível.

A distinção entre a unicidade do subespaço e a unicidade dos autovetores individuais será retomada na seção sobre multiplicidade de autovalores.

14.8 Reconstrução a partir das componentes principais

As primeiras k componentes fornecem as coordenadas de $\mathbf{X}_c$ no subespaço principal. A projeção no espaço original é obtida por

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{Y}_k.$$

Como

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c,$$

segue que

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{A}_k^\top \mathbf{X}_c = \mathbf{P}_k \mathbf{X}_c.$$

O vetor $\tilde{\mathbf{X}}_{c,k}$ é a representação de $\mathbf{X}_c$ obtida utilizando apenas as primeiras k direções principais.

A parcela não representada é

$$\mathbf{E}_k = \mathbf{X}_c - \tilde{\mathbf{X}}_{c,k} = (\mathbf{I}_p - \mathbf{P}_k) \mathbf{X}_c.$$

A matriz de projeção residual foi definida na Definição 3.20, e a ortogonalidade entre a projeção e o resíduo decorre de Proposição 3.17. Portanto,

$$\|\mathbf{X}_c\|^2 = \|\tilde{\mathbf{X}}_{c,k}\|^2 + \|\mathbf{E}_k\|^2.$$

Tomando esperanças, a variabilidade total também se decompõe em parcela representada e parcela não representada:

$$E(\|\mathbf{X}_c\|^2) = E(\|\tilde{\mathbf{X}}_{c,k}\|^2) + E(\|\mathbf{E}_k\|^2).$$

A primeira parcela é

$$E(\|\tilde{\mathbf{X}}_{c,k}\|^2) = \sum_{j=1}^k \lambda_j,$$

enquanto, pela definição de variância total na Definição 8.6,

$$E(\|\mathbf{X}_c\|^2) = \text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Consequentemente,

$$E(\|\mathbf{E}_k\|^2) = \sum_{j=k+1}^p \lambda_j.$$

A variabilidade descartada pela redução de dimensão corresponde exatamente à soma dos autovalores associados às direções excluídas.

Proposição 14.2 (Variância preservada e erro de reconstrução). *Seja*

$$\mathbf{X} \in \mathbb{R}^p$$

um vetor aleatório com segundos momentos finitos, vetor de médias μ e matriz de covariâncias Σ . Defina

$$\mathbf{X}_c = \mathbf{X} - \mu.$$

Para $1 \leq k \leq p$, considere uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

e a projeção ortogonal

$$\tilde{\mathbf{X}}_{c,\mathbf{Q}} = \mathbf{Q}\mathbf{Q}^\top \mathbf{X}_c.$$

O erro quadrático médio de reconstrução é

$$E \left[\left\| \mathbf{X}_c - \tilde{\mathbf{X}}_{c,\mathbf{Q}} \right\|^2 \right] = \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}).$$

Consequentemente, maximizar a variância preservada,

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}),$$

equivale a minimizar o erro quadrático médio de reconstrução.

Para um subespaço principal de dimensão k ,

$$\text{variância preservada} = \sum_{j=1}^k \lambda_j$$

e o erro mínimo é

$$\min_{\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k} E \left[\left\| \mathbf{X}_c - \mathbf{Q}\mathbf{Q}^\top \mathbf{X}_c \right\|^2 \right] = \sum_{j=k+1}^p \lambda_j.$$

Comprovação. Como

$$\mathbf{Q}\mathbf{Q}^\top$$

é um projetor ortogonal,

$$\mathbf{I}_p - \mathbf{Q}\mathbf{Q}^\top$$

também é simétrica e idempotente. Portanto,

$$\begin{aligned} E \left[\|\mathbf{x}_c - \mathbf{Q}\mathbf{Q}^\top \mathbf{x}_c\|^2 \right] &= E \left[\mathbf{x}_c^\top (\mathbf{I}_p - \mathbf{Q}\mathbf{Q}^\top) \mathbf{x}_c \right] \\ &= \text{tr} \left[(\mathbf{I}_p - \mathbf{Q}\mathbf{Q}^\top) \Sigma \right] \\ &= \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}). \end{aligned}$$

Como o primeiro termo não depende de $\mathbf{Q}$, minimizar o erro equivale a maximizar

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}).$$

Pela Proposição 14.1, o valor máximo é

$$\sum_{j=1}^k \lambda_j.$$

Como

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j,$$

o erro mínimo é

$$\sum_{j=k+1}^p \lambda_j.$$

□

A decomposição de um vetor em projeção e resíduo ortogonal foi apresentada na Figura 3.5. Na ACP, o mesmo princípio é aplicado simultaneamente à nuvem de observações, utilizando como subespaço uma direção ou um subespaço principal.

A Figura 14.3 representa a redução de duas para uma dimensão. Cada observação é projetada sobre a primeira direção principal. Os segmentos vermelhos representam os resíduos de reconstrução.




Figura 14.3: A redução para uma componente substitui cada observação por sua projeção sobre a primeira direção principal; os segmentos ortogonais representam o erro de reconstrução.

Os pontos azuis são as observações centralizadas, os pontos verdes são suas representações utilizando somente a primeira componente e os segmentos vermelhos correspondem à parcela

descartada. A ACP escolhe um subespaço principal que minimiza conjuntamente esses resíduos quadráticos entre todos os subespaços de mesma dimensão.

Essa equivalência conecta duas interpretações da técnica. A ACP pode ser formulada como busca das direções que preservam maior variabilidade ou como busca do subespaço que produz menor perda quadrática na reconstrução.

14.9 Formulação amostral

A formulação populacional define as componentes em termos de Σ , que geralmente é desconhecida. A aplicação da técnica utiliza uma amostra para estimar suas direções e variâncias.

Considere uma realização amostral com $n \geq 2$ observações, organizada na matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com média observada $\bar{\mathbf{x}}$ e matriz centralizada

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A matriz de covariâncias observada foi definida na Definição 8.11 como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

A versão amostral da ACP substitui a matriz populacional Σ por $\mathbf{S}$.

Considere a decomposição espectral

$$\mathbf{S} = \widehat{\mathbf{A}} \widehat{\Lambda} \widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\Lambda} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p),$$

com

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0,$$

e

$$\widehat{\mathbf{A}} = (\hat{\mathbf{a}}_1 \quad \cdots \quad \hat{\mathbf{a}}_p).$$

A Tabela 14.2 sintetiza a distinção entre os principais objetos populacionais e amostrais da ACP.

Tabela 14.2: Correspondência entre objetos populacionais e amostrais na ACP.

Objeto	População	Amostra observada
Matriz de covariâncias	Σ	$\mathbf{S}$
Direção principal j	$\mathbf{a}_j$	$\hat{\mathbf{a}}_j$
Variância da componente j	λ_j	$\hat{\lambda}_j$
Componente principal	$Y_j = \mathbf{a}_j^\top (\mathbf{X} - \mu)$	definida a partir da direção estimada $\hat{\mathbf{a}}_j$
Coordenada de uma observação	realização de Y_j	escore t_{ij}

A direção $\hat{\mathbf{a}}_j$ é obtida a partir da amostra. Quando a direção populacional correspondente é identificável, ela pode ser interpretada como estimativa dessa direção; a relação entre a solução amostral e a populacional será retomada na seção sobre formulação populacional e inferência.

Para a observação i , o escore na componente j é

$$t_{ij} = \hat{\mathbf{a}}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Definição 14.2 (Escore de uma componente principal). Considere a observação

$$\mathbf{x}_i \in \mathbb{R}^p,$$

sua versão centralizada

$$\mathbf{x}_i - \bar{\mathbf{x}},$$

e uma direção principal amostral unitária

$$\hat{\mathbf{a}}_j \in \mathbb{R}^p.$$

O escore da observação i na componente principal j é sua coordenada nessa direção:

$$t_{ij} = \hat{\mathbf{a}}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Os escores de todas as observações nas k primeiras componentes são reunidos em

$$\mathbf{T}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k,$$

em que

$$\widehat{\mathbf{A}}_k = (\hat{\mathbf{a}}_1 \quad \dots \quad \hat{\mathbf{a}}_k).$$

A matriz

$$\mathbf{T}_k \in \mathbb{R}^{n \times k}$$

fornece a representação das n observações no espaço principal de dimensão k .

Os elementos de $\hat{\mathbf{a}}_j$ são os **coeficientes da componente principal**. Os elementos da coluna correspondente de $\mathbf{T}_k$ são os **escores**. Esses objetos desempenham funções diferentes: os coeficientes definem a direção e os escores localizam as observações nessa direção.

A matriz centralizada reconstruída a partir das primeiras k componentes é

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{T}_k \widehat{\mathbf{A}}_k^\top.$$

Substituindo a definição dos escores,

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \widehat{\mathbf{A}}_k \widehat{\mathbf{A}}_k^\top.$$

Assim, a reconstrução amostral também é uma projeção ortogonal sobre o subespaço principal estimado.

Para retornar às unidades e à localização originais, adiciona-se novamente o vetor de médias:

$$\widetilde{\mathbf{X}}_k = \widetilde{\mathbf{X}}_{c,k} + \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A centralização remove a localização antes da determinação das direções principais; a reconstrução final restitui essa localização.

14.10 Formulação da ACP pela SVD

A formulação amostral pode ser obtida diretamente da matriz centralizada sem formar previamente $\mathbf{S}$.

Se

$$r = \text{posto}(\mathbf{X}_c) > 0,$$

considere a SVD compacta definida na Definição 6.4:

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

em que

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}, \quad \mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Os valores singulares são ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

a relação entre a SVD da matriz centralizada e a decomposição espectral da covariância, estabelecida na Proposição 6.14, fornece

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto, para as componentes associadas a autovalores positivos,

$$\hat{\mathbf{a}}_j = \mathbf{v}_j$$

e

$$\hat{\lambda}_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r.$$

Os vetores singulares à direita da matriz centralizada são as direções principais amostrais associadas à variabilidade positiva. O quadrado de cada valor singular, dividido por $n - 1$, é a variância observada da componente correspondente.

Se

$$r < p,$$

as $p - r$ componentes restantes possuem autovalor zero. A SVD compacta não precisa fornecer uma base para esse complemento nulo, pois essas direções não acrescentam variabilidade à representação.

A interpretação geométrica da SVD foi apresentada na Figura 6.1. Na ACP amostral, a matriz decomposta passa a ser $\mathbf{X}_c$. Os vetores singulares à direita fornecem as direções no espaço das variáveis, enquanto os produtos dos vetores singulares à esquerda pelos valores singulares fornecem as coordenadas das observações nessas direções.

Essa relação mostra que a decomposição espectral de $\mathbf{S}$ e a SVD de $\mathbf{X}_c$ não constituem duas técnicas diferentes. Para as componentes de variância positiva, elas fornecem duas formas de obter a mesma solução amostral da ACP.

Os escores também são obtidos diretamente pela SVD:

$$\begin{aligned}\mathbf{T}_r &= \mathbf{X}_c \mathbf{V}_r \\ &= \mathbf{U}_r \mathbf{D}_r.\end{aligned}$$

Assim, a SVD separa naturalmente os elementos da representação:

- $\mathbf{V}_r$ contém as direções principais associadas à variabilidade positiva no espaço das variáveis;
- $\mathbf{U}_r \mathbf{D}_r$ contém os escores das observações;
- $\mathbf{D}_r$ determina a magnitude da variabilidade em cada direção.

A centralização também limita o número de componentes com variância positiva. Pelo resultado de posto da matriz de covariâncias observada estabelecido na Equação 8.63,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1).$$

Portanto, existem no máximo

$$\min(p, n - 1)$$

componentes principais com variância amostral positiva.

Em particular, quando $p \geq n$, a matriz $\mathbf{S}$ é necessariamente singular. Essa singularidade amostral não implica que a matriz populacional Σ seja singular; ela pode decorrer apenas do número de direções disponíveis na amostra após a centralização.

14.11 Aproximação de posto reduzido

A SVD permite conectar diretamente a redução de dimensionalidade ao problema de aproximação matricial.

Para

$$1 \leq k < r,$$

mantendo apenas os k primeiros termos da SVD,

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Pelo Teorema de Eckart–Young–Mirsky de Teorema 6.2, $\mathbf{X}_{c,k}$ é uma melhor aproximação de $\mathbf{X}_c$ entre todas as matrizes de posto não superior a k , segundo a norma de Frobenius.

Se

$$d_k > d_{k+1},$$

essa melhor aproximação é única. Quando

$$d_k = d_{k+1},$$

podem existir diferentes aproximações de posto não superior a k que atingem o mesmo erro mínimo.

Além disso, pela relação entre projeção e SVD estabelecida na Proposição 6.19,

$$\mathbf{X}_{c,k} = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{T}_k = \mathbf{X}_c \mathbf{V}_k,$$

também se obtém

$$\mathbf{X}_{c,k} = \mathbf{T}_k \mathbf{V}_k^\top.$$

Essas três expressões representam o mesmo objeto:

$$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top = \mathbf{T}_k \mathbf{V}_k^\top.$$

A primeira expressão mostra a aproximação de posto reduzido; a segunda mostra a projeção sobre um subespaço principal; a terceira mostra a reconstrução a partir dos escores e das direções principais.

O erro quadrático total da aproximação é

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Como

$$d_j^2 = (n-1)\hat{\lambda}_j,$$

segue que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 = (n-1) \sum_{j=k+1}^r \hat{\lambda}_j.$$

A parcela da soma de quadrados preservada pela aproximação é

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2} = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{j=1}^r \hat{\lambda}_j}.$$

Essa expressão coincide com a proporção de variância observada representada pelas primeiras k componentes.

A equivalência entre as formulações pode ser resumida pela Tabela 14.3.

Tabela 14.3: Formulações relacionadas da Análise de Componentes Principais.

Formulação	Objeto otimizado ou decomposto	Solução
Variância	$\mathbf{a}^\top \Sigma \mathbf{a}$ ou $\mathbf{a}^\top \mathbf{S} \mathbf{a}$	Autovetores associados aos maiores autovalores

Formulação	Objeto otimizado ou decomposto	Solução
Subespaço	Variância total da projeção em dimensão k	Subespaço gerado pelas primeiras k direções
Reconstrução	Erro quadrático da representação	Projeção sobre um subespaço principal
SVD	Matriz de dados centralizada $\mathbf{X}_c$	Vetores singulares à direita associados à variabilidade positiva
Aproximação matricial	$\ \mathbf{X}_c - \mathbf{B}\ _F$ com $\text{posto}(\mathbf{B}) \leq k$	$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$

A ACP pode, portanto, ser compreendida simultaneamente como um problema estatístico de preservação da variabilidade, um problema geométrico de projeção e um problema matricial de aproximação de posto reduzido. Os resultados dos Módulos 1 e 2 mostram por que essas três perspectivas conduzem à mesma solução.

14.12 ACP baseada na matriz de correlações

A formulação anterior utiliza a matriz de covariâncias. Quando as variáveis possuem escalas ou unidades de medida diferentes, pode ser definido outro problema: realizar a ACP após padronizar cada variável para variância unitária.

A matriz de correlações populacional $\mathcal{R}$ foi definida na Definição 8.5, sob a condição de que todas as variâncias marginais populacionais sejam positivas, e sua correspondente observada $\mathbf{R}$ foi definida na Definição 8.12, sob a condição de que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

No nível observado, defina

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

Como

$$s_{jj} > 0, \quad j = 1, \dots, p,$$

a matriz $\mathbf{D}_S$ é positiva definida e $\mathbf{D}_S^{-1/2}$ existe. Assim,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

O Módulo 2 estabeleceu na Equação 8.70 a relação entre a matriz de correlações e as colunas centralizadas e padronizadas. Para manter essa notação distinta da matriz de delineamento $\mathbf{Z}$ utilizada na Definição 11.3, neste capítulo denotaremos a matriz padronizada por

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2}.$$

Assim,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}.$$

Realizar a ACP de $\mathbf{R}$ equivale, portanto, a realizar a ACP sobre as colunas centralizadas e padronizadas de $\mathbf{X}$.

Se

$$\mathbf{R} = \mathbf{A}_R \Lambda_R \mathbf{A}_R^\top,$$

as direções principais são obtidas no espaço das variáveis padronizadas. Os autovalores

$$\lambda_{R1}, \dots, \lambda_{Rp}$$

representam as variâncias das componentes construídas a partir dessas variáveis.

Como a diagonal de $\mathbf{R}$ é formada por valores iguais a 1,

$$\text{tr}(\mathbf{R}) = p.$$

Logo,

$$\sum_{j=1}^p \lambda_{Rj} = p.$$

A proporção da variância padronizada representada pela componente j é

$$\frac{\lambda_{Rj}}{p},$$

e a proporção acumulada nas primeiras k componentes é

$$\frac{\sum_{j=1}^k \lambda_{Rj}}{p}.$$

A utilização de **S** ou **R** corresponde a **duas formulações diferentes da ACP**.

Na ACP baseada em **S**, as variáveis preservam suas escalas e variâncias originais. Uma variável com maior variabilidade pode exercer maior influência sobre as primeiras componentes.

Na ACP baseada em **R**, todas as variáveis entram na análise com variância unitária. As diferenças de escala marginal são removidas antes da decomposição.

A Tabela 14.4 resume essa distinção.

Tabela 14.4: Diferenças entre a ACP baseada em covariâncias e em correlações.

Aspecto	ACP por covariâncias	ACP por correlações
Matriz de entrada	S	R
Dados equivalentes	Centralizados	Centralizados e padronizados
Variâncias marginais	Mantidas nas unidades originais	Iguais a 1
Variância total	$\text{tr}(\mathbf{S})$	p
Influência da escala	Preservada	Removida pela padronização
Problema resolvido	Representar a variabilidade nas escalas originais	Representar a variabilidade após igualar as escalas marginais

A Figura 14.4 ilustra o efeito da padronização. Os dois painéis representam as mesmas observações, antes e depois da padronização marginal. A mudança das escalas altera a geometria e, conseqüentemente, as direções principais.

A seta vermelha representa a primeira direção principal em cada geometria. A padronização remove as diferenças de escala marginal entre as variáveis e, nesse exemplo, modifica a direção que maximiza a variância.

A escolha entre as duas matrizes faz parte da definição do problema estatístico. Ela não deve ser tratada como uma decisão puramente computacional.

A padronização modifica a geometria da nuvem de dados por meio de um escalonamento diferente em cada eixo. Conseqüentemente, os autovetores, os autovalores, os escores e o subespaço principal podem mudar.

Essa distinção será importante também no próximo capítulo. A Análise Fatorial pode ser formulada sobre uma matriz de covariâncias ou de correlações, mas seu objetivo será diferente: em vez de decompor a variabilidade total em direções principais, será especificado um modelo para a estrutura de covariação entre as variáveis.




Figura 14.4: A ACP baseada em covariâncias preserva as escalas originais, enquanto a ACP baseada em correlações utiliza a geometria das variáveis padronizadas.

14.13 Interpretação geométrica da ACP

A formulação espectral da ACP possui uma interpretação geométrica direta. A matriz

$$\mathbf{A} = (\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_p)$$

é ortogonal e suas colunas formam uma base ortonormal de $\mathbb{R}^p$. A transformação

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \boldsymbol{\mu})$$

expressa o vetor centralizado em relação a essa nova base.

Quando todas as p componentes são mantidas, não há redução de dimensão nem perda de informação. A transformação corresponde a uma mudança ortogonal de coordenadas. Comprimentos, ângulos e distâncias euclidianas são preservados, conforme Proposição 4.10.

A mudança de base possui uma finalidade específica: alinhar os novos eixos às direções de dispersão determinadas pela matriz de covariâncias. No sistema original, a matriz Σ pode possuir elementos fora da diagonal. No sistema das componentes principais,

$$\text{Cov}(\mathbf{Y}) = \Lambda,$$

e a estrutura de covariâncias torna-se diagonal.

Geometricamente, a ACP escolhe os eixos principais da dispersão.

A Figura 14.5 compara a mesma nuvem no sistema das variáveis originais e no sistema das componentes principais. No primeiro, a dispersão está inclinada em relação aos eixos coordenados. No segundo, os eixos coincidem com as direções principais e a matriz de covariâncias é diagonal.




Figura 14.5: A transformação completa para componentes principais representa a mesma nuvem em uma base ortonormal alinhada às direções de dispersão.

A transformação ortogonal completa preserva a geometria da nuvem. A diferença está na orientação dos eixos. No sistema das componentes, a dispersão está alinhada às coordenadas e as covariâncias entre componentes são nulas.

14.13.1 Relação com o elipsoide de covariâncias

A geometria da matriz de covariâncias foi estudada no Módulo 2. Quando $\Sigma \succ \mathbf{0}$, o elipsoide definido na Equação 8.33 possui eixos orientados pelos autovetores e extensões determinadas pelos autovalores, como ilustrado na Figura 8.3.

A Figura 8.3, construída no estudo da geometria da matriz de covariâncias, pode agora ser reinterpretada em termos da ACP: seus eixos espectrais são as direções das componentes principais e os quadrados de suas extensões são proporcionais aos respectivos autovalores.

A ACP utiliza exatamente essas direções.

A primeira componente principal está associada ao eixo de maior dispersão do elipsoide. A segunda está associada ao eixo ortogonal de segunda maior dispersão, e assim sucessivamente.

Portanto, a decomposição

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top$$

possui duas leituras complementares:

- estatisticamente, λ_j é a variância da componente Y_j ;
- geometricamente, $\mathbf{a}_j$ determina uma direção principal da dispersão.

A transformação completa apenas realinha os eixos de coordenadas com os eixos do elipsoide.

14.13.2 Redução de dimensão como projeção

A redução de dimensão foi formalizada na Proposição 14.2 e representada geometricamente na Figura 14.3. Manter as primeiras k componentes equivale a substituir cada observação centralizada por sua projeção ortogonal sobre um subespaço principal $\mathcal{S}_k$ de Definição 14.1.

A variabilidade preservada corresponde às primeiras k direções, enquanto a parcela descartada pertence ao complemento ortogonal. Essa construção reúne os resultados do Módulo 1 sobre projeções, decomposição espectral e aproximação de posto reduzido e lhes atribui uma função específica na ACP.

14.14 Coeficientes e relação das variáveis com as componentes

Os elementos do vetor

$$\mathbf{a}_j = \begin{pmatrix} a_{1j} \\ \vdots \\ a_{pj} \end{pmatrix}$$

são os **coeficientes da j -ésima componente principal**. Eles definem a combinação linear

$$Y_j = \sum_{i=1}^p a_{ij} (X_i - \mu_i).$$

Esses coeficientes determinam a direção da componente no espaço das variáveis. Eles não devem ser confundidos com as correlações entre as variáveis originais e a componente.

A relação entre esses dois objetos pode ser obtida diretamente a partir da matriz de covariâncias.

Para a variável X_i ,

$$\begin{aligned}\text{Cov}(X_i, Y_j) &= \text{Cov}\left[X_i, \mathbf{a}_j^\top (\mathbf{X} - \mu)\right] \\ &= \sum_{\ell=1}^p a_{\ell j} \text{Cov}(X_i, X_\ell) \\ &= (\Sigma \mathbf{a}_j)_i.\end{aligned}$$

Como

$$\Sigma \mathbf{a}_j = \lambda_j \mathbf{a}_j,$$

segue que

$$\text{Cov}(X_i, Y_j) = \lambda_j a_{ij}.$$

Além disso,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Var}(X_i) = \sigma_{ii}.$$

Se

$$\sigma_{ii} > 0$$

e

$$\lambda_j > 0,$$

então a correlação está definida e

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} a_{ij}}{\sqrt{\sigma_{ii}}}.$$

Proposição 14.3 (Correlação entre uma variável e uma componente principal). *Considere a ACP populacional baseada na matriz de covariâncias Σ . Para uma variável X_i com*

$$\sigma_{ii} > 0$$

e uma componente principal

$$Y_j = \mathbf{a}_j^\top (\mathbf{X} - \mu)$$

associada a um autovalor

$$\lambda_j > 0,$$

tem-se

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} a_{ij}}{\sqrt{\sigma_{ii}}}.$$

Na ACP populacional baseada na matriz de correlações $\mathcal{R}$, suponha que as variâncias marginais sejam positivas, como exigido na Definição 8.5. Considere a variável padronizada $X_{i,\text{pad}}$ e uma componente

$$Y_{Rj}$$

construída a partir do autovetor $\mathbf{a}_{Rj}$ associado a

$$\lambda_{Rj} > 0.$$

Como

$$\text{Var}(X_{i,\text{pad}}) = 1,$$

tem-se

$$\text{Corr}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\lambda_{Rj}} a_{R,ij}.$$

A exigência de autovalor positivo decorre da própria definição de correlação. Se

$$\lambda_j = 0,$$

então

$$\text{Var}(Y_j) = 0,$$

e a correlação entre Y_j e qualquer variável não está definida.

A expressão mostra que o coeficiente a_{ij} e a correlação entre X_i e Y_j representam objetos diferentes.

A diferença entre os coeficientes da componente e as correlações com as variáveis pode ser visualizada na Figura 14.6. O exemplo utiliza uma matriz de covariâncias com variâncias marginais diferentes.




Figura 14.6: Os coeficientes definem a direção da componente, enquanto as correlações medem a associação de cada variável com a componente.

Os coeficientes pertencem ao vetor unitário que define a direção principal. As correlações dependem também da variância da componente e da variância de cada variável. Por isso, as duas medidas não são intercambiáveis.

O coeficiente indica a participação da variável na definição da direção. A correlação indica a intensidade da associação linear da variável com a componente construída.

Essa distinção será importante no capítulo seguinte. Na Análise Fatorial, as cargas fatoriais pertencem ao próprio modelo de covariâncias e terão interpretação diferente dos coeficientes de uma componente principal.

Na formulação amostral baseada em $\mathbf{S}$, se

$$s_{ii} > 0$$

e

$$\hat{\lambda}_j > 0,$$

então

$$\widehat{\text{Corr}}(X_i, Y_j) = \frac{\sqrt{\hat{\lambda}_j} \hat{a}_{ij}}{\sqrt{s_{ii}}}.$$

Quando a ACP é realizada sobre $\mathbf{R}$, cada variável padronizada possui variância observada igual a 1. Para uma componente com

$$\hat{\lambda}_{Rj} > 0,$$

denotando por $X_{i,\text{pad}}$ a variável padronizada e por Y_{Rj} a componente correspondente,

$$\widehat{\text{Corr}}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\hat{\lambda}_{Rj}} \hat{a}_{R,ij}.$$

A interpretação substantiva das componentes pode utilizar conjuntamente os coeficientes e as associações das variáveis com as componentes. A formulação matemática deve preservar a distinção entre os dois objetos.

14.15 Propriedades da solução

A ACP herda propriedades da matriz de covariâncias e da decomposição espectral. Algumas delas possuem consequências diretas para a interpretação das componentes.

14.15.1 Invariância a translações

Considere uma transformação de localização

$$\mathbf{X}^* = \mathbf{X} + \mathbf{c},$$

com $\mathbf{c} \in \mathbb{R}^p$ constante.

A média passa a ser

$$\mu^* = \mu + \mathbf{c},$$

mas

$$\mathbf{X}^* - \mu^* = \mathbf{X} - \mu.$$

Consequentemente,

$$\text{Cov}(\mathbf{X}^*) = \Sigma.$$

As direções principais e os autovalores não se alteram. A ACP baseada em covariâncias é, portanto, invariante a translações.

A centralização não modifica a dispersão; ela apenas desloca a origem para o centro da nuvem.

14.15.2 Dependência da escala

A invariância a translações não se estende a mudanças individuais de escala.

Considere

$$\mathbf{X}^* = \mathbf{D}\mathbf{X},$$

em que $\mathbf{D}$ é diagonal e contém fatores de escala positivos, possivelmente diferentes entre as variáveis.

A nova matriz de covariâncias é

$$\Sigma^* = \mathbf{D}\Sigma\mathbf{D}.$$

Em geral, os autovetores de Σ^* não coincidem com os de Σ . Assim, uma mudança nas unidades de medida pode alterar as componentes principais obtidas a partir da matriz de covariâncias.

Essa propriedade explica a diferença entre ACP por covariâncias e ACP por correlações. A padronização não é uma operação neutra: ela redefine a geometria na qual a variabilidade será medida.

14.15.3 Indeterminação do sinal

Se

$$\Sigma \mathbf{a}_j = \lambda_j \mathbf{a}_j,$$

então

$$\Sigma(-\mathbf{a}_j) = \lambda_j(-\mathbf{a}_j).$$

Portanto, $\mathbf{a}_j$ e $-\mathbf{a}_j$ representam a mesma direção principal.

Se o sinal do vetor de coeficientes for invertido,

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_e$$

passa a ser

$$Y_j^* = -Y_j.$$

Os escores também mudam de sinal, mas a variância, o subespaço gerado e a qualidade da representação permanecem inalterados.

A orientação positiva ou negativa de um eixo principal é, portanto, arbitrária.

Essa propriedade é especialmente importante na comparação de resultados produzidos por diferentes programas ou diferentes decomposições numéricas. Duas soluções podem apresentar sinais opostos e ainda representar exatamente a mesma componente.

14.15.4 Multiplicidade de autovalores

A situação muda quando um autovalor possui multiplicidade maior que um.

Os conceitos de multiplicidade algébrica e geométrica foram definidos na Definição 5.5. Como Σ é simétrica, o Teorema Espectral garante uma base ortonormal em cada autoespaço.

Considere, por exemplo,

$$\lambda_j = \lambda_{j+1}.$$

Nesse caso, qualquer base ortonormal do autoespaço associado pode ser utilizada. Os vetores

$$\mathbf{a}_j \quad \text{e} \quad \mathbf{a}_{j+1}$$

não são individualmente determinados de forma única.

O objeto determinado de forma única é o autoespaço associado ao autovalor repetido.

Essa distinção afeta a interpretação. Quando um autovalor é simples, sua direção principal é determinada até mudança de sinal. Quando há multiplicidade, diferentes rotações ortogonais dentro do autoespaço produzem conjuntos diferentes de autovetores igualmente válidos.

A ACP identifica, nesse caso, o subespaço de variabilidade associado ao autovalor repetido, e não eixos individuais únicos.

A não unicidade das bases de um autoespaço com multiplicidade foi ilustrada na Figura 5.2. Na ACP, essa propriedade implica que um autovalor repetido identifica o autoespaço correspondente, mas não uma direção principal individual única.

Essa propriedade também explica a condição de unicidade apresentada na Definição 14.1 e Proposição 14.1. Se a redução para dimensão k ocorre em uma fronteira com

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único. Se

$$\lambda_k = \lambda_{k+1},$$

a retenção de apenas parte do autoespaço correspondente pode produzir diferentes subespaços principais de dimensão k com a mesma variabilidade máxima.

14.15.5 Autovalores próximos

Mesmo sem igualdade exata, autovalores muito próximos podem produzir direções amostrais instáveis.

Se duas variâncias principais populacionais são semelhantes, pequenas alterações na matriz de covariâncias observada podem modificar consideravelmente os autovetores estimados. Quando essas duas direções formam um bloco espectral separado dos demais autovalores, o subespaço gerado conjuntamente por elas pode ser mais estável do que os autovetores considerados individualmente.

A Figura 14.7 compara duas estruturas de covariância. No primeiro painel, a diferença entre os autovalores produz um eixo principal claramente destacado. No segundo, os autovalores próximos produzem uma dispersão quase circular, de modo que a orientação dos eixos individuais é menos determinada pela estrutura da nuvem.




Figura 14.7: Autovalores bem separados determinam direções principais marcadas; autovalores próximos produzem uma geometria em que as direções individuais são menos distintas.

A separação entre os autovalores determina quão distinta é a orientação associada a cada eixo. Quando os autovalores são próximos, pequenas alterações da matriz de covariâncias podem produzir mudanças perceptíveis nos autovetores.

Esse comportamento diferencia a estabilidade dos autovalores, dos autovetores individuais e dos subespaços principais. A interpretação de uma componente isolada exige maior cuidado quando não há separação clara entre os autovalores correspondentes (Anderson, 2003).

14.15.6 Singularidade e dimensão efetiva

A matriz de covariâncias pode ser singular. O Módulo 2 relacionou essa situação à existência de combinações lineares com variância zero na Proposição 8.3.

Se

$$\text{posto}(\Sigma) = r < p,$$

então exatamente r autovalores são positivos:

$$\lambda_1 \geq \dots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \dots = \lambda_p = 0.$$

A variabilidade populacional está inteiramente contida em um subespaço de dimensão r .

As componentes associadas aos autovalores nulos possuem variância zero e não acrescentam uma nova dimensão de variabilidade.

Nesse caso, a redução de p para r dimensões pode ser realizada sem perda de variância.

No nível amostral, a centralização impõe

$$\text{posto}(\mathbf{X}_c) \leq n - 1.$$

Por isso,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Quando

$$p \geq n,$$

a matriz de covariâncias observada é necessariamente singular. A SVD permite representar diretamente o subespaço de variabilidade observado sem exigir a inversão de $\mathbf{S}$.

14.16 Papel da distribuição probabilística

A definição das componentes principais depende da existência da matriz de covariâncias. Portanto, a formulação populacional exige momentos de segunda ordem finitos.

Não é necessário assumir

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

para definir

$$Y_j = \mathbf{a}_j^\top (\mathbf{X} - \mu),$$

obter os autovalores de Σ ou construir o subespaço principal.

A ACP é, nesse sentido, uma técnica espectral definida a partir da estrutura de segunda ordem.

A normalidade produz consequências adicionais.

Se

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

no sentido de Definição 9.1, então, pela propriedade de transformação afim apresentada na Proposição 9.4,

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \mu)$$

também é normal multivariado:

$$\mathbf{Y} \sim N_p(\mathbf{0}, \Lambda).$$

Como sua matriz de covariâncias é diagonal, o resultado de independência para blocos normais de Proposição 9.6 implica independência entre as componentes.

Assim, sob normalidade,

$$Y_j \perp Y_\ell, \quad j \neq \ell.$$

Sem normalidade conjunta, a ACP garante desconexão,

$$\text{Cov}(Y_j, Y_\ell) = 0,$$

mas não independência.

Essa distinção é importante porque a propriedade definidora da ACP é a organização da variância e da covariância, não a independência probabilística das componentes.

14.17 Formulação descritiva, populacional e inferencial

A ACP pode ser considerada em níveis conceitualmente distintos.

Na formulação **descritiva**, a matriz de dados observada é o objeto de interesse. A decomposição procura representar aquela configuração de observações em dimensão menor. Autovalores, direções e escores descrevem a estrutura presente nos dados.

Na formulação **populacional**, existe uma matriz de covariâncias

$$\Sigma$$

que caracteriza a estrutura de segunda ordem de uma população. Seus autovalores, autovetores e subespaços principais são então quantidades populacionais derivadas de sua decomposição espectral.

Quando uma amostra aleatória é utilizada para estudar essa estrutura populacional, entra-se no problema de **estimação**. Os conceitos de parâmetro, estimador e estimativa foram definidos na Definição 10.4. No Módulo 2, a matriz de covariâncias amostral aleatória é denotada por

$$\mathbf{S},$$

enquanto sua realização após a observação da amostra é representada por

$$\mathbf{S}.$$

Assim, os objetos

$$\lambda_j \quad \text{e} \quad \mathbf{a}_j$$

são características da matriz populacional, enquanto

$$\hat{\lambda}_j \quad \text{e} \quad \hat{\mathbf{a}}_j$$

são obtidos a partir da matriz de covariâncias observada.

A relação entre essas duas estruturas pode ser compreendida a partir da consistência da matriz de covariâncias amostral. Sob as condições de Proposição 10.12, observações i.i.d., segundos momentos finitos e dimensão p fixa,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Como os autovalores ordenados de uma matriz simétrica variam continuamente com seus elementos, segue, para cada j ,

$$\hat{\lambda}_j \xrightarrow{P} \lambda_j.$$

Para uma direção principal individual, é necessária ainda separação espectral. Se λ_j é simples, a direção populacional é identificada até mudança de sinal, e a direção amostral correspondente pode ser orientada para estimá-la.

Quando o interesse está em um conjunto de direções, o objeto relevante é o subespaço que elas geram. Se um bloco de autovalores de interesse está separado dos autovalores restantes, o subespaço espectral correspondente pode ser estimado mesmo que existam multiplicidades dentro desse bloco.

Quando um autovalor é repetido, os autovetores individuais dentro do autoespaço correspondente não são parâmetros identificados separadamente. Nesse caso, o objeto populacional a ser estimado é o próprio autoespaço.

A **inferência** acrescenta a análise da variabilidade amostral dessas estimativas. Sob normalidade multivariada, a teoria clássica fornece distribuições e aproximações para autovalores, autovetores e funções dessas quantidades (Anderson, 2003). Resultados assintóticos também podem ser desenvolvidos sob condições mais gerais, mas sua derivação não é necessária para a formulação da técnica.

Esta seção distingue a descrição da estrutura observada, a formulação de uma estrutura populacional e o problema de estimação e inferência quando uma amostra é utilizada para estudá-la.

A ACP pode ser empregada de forma descritiva para representar uma matriz de dados observada ou inserida em um problema estatístico no qual autovalores, direções e subespaços amostrais estimam estruturas populacionais.

14.18 Limites da representação por componentes principais

A ACP resolve um problema definido de forma precisa: encontrar combinações lineares e subespaços que preservem variabilidade segundo uma matriz de covariâncias ou correlações. Os limites da técnica decorrem diretamente dessa formulação e são sintetizados na Tabela 14.5.

Tabela 14.5: Limites decorrentes da formulação clássica da Análise de Componentes Principais.

Aspecto	Consequência para a ACP
Critério de importância	As componentes são ordenadas pela variância. Uma direção de pequena variabilidade pode ser relevante para outro objetivo estatístico.
Estrutura representada	As componentes são combinações lineares e utilizam covariâncias ou correlações. Estruturas essencialmente não lineares podem não ser concentradas em poucas componentes.
Conjunto de variáveis	Inclusão, exclusão, transformação ou mudança de escala altera a matriz analisada e pode modificar toda a solução.
Sensibilidade da matriz de entrada	Valores extremos podem alterar variâncias, covariâncias, correlações e, conseqüentemente, autovalores e autovetores.
Redução de dimensão	Quando são descartadas direções com autovalores positivos, parte da variabilidade original deixa de ser representada.

Se

$$k < r,$$

a variabilidade descartada é

$$\sum_{j=k+1}^r \lambda_j$$

no nível populacional e

$$\sum_{j=k+1}^r \hat{\lambda}_j$$

no nível observado.

A redução preserva toda a variabilidade somente quando as dimensões excluídas possuem autovalores nulos. Nos demais casos, a ACP controla a perda segundo o critério de máxima variabilidade preservada, equivalentemente ao menor erro quadrático de reconstrução.

14.19 Síntese

A Análise de Componentes Principais representa a variabilidade de um vetor aleatório por combinações lineares ortogonais. Para

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

a combinação

$$Y_j = \mathbf{a}_j^\top \mathbf{X}_c$$

possui variância

$$\text{Var}(Y_j) = \mathbf{a}_j^\top \Sigma \mathbf{a}_j.$$

A maximização sucessiva dessa variância, sob restrições de norma unitária e ortogonalidade, conduz aos autovetores de Σ . Os autovalores correspondentes são as variâncias das componentes,

$$\text{Var}(Y_j) = \lambda_j,$$

e permitem quantificar a parcela da variabilidade total representada pelas primeiras dimensões.

As primeiras k direções geram o subespaço principal

$$\mathcal{S}_k = \text{span} \{ \mathbf{a}_1, \dots, \mathbf{a}_k \}.$$

Esse subespaço maximiza a variabilidade projetada entre os subespaços de mesma dimensão e, de forma equivalente, minimiza o erro quadrático médio de reconstrução.

Na formulação amostral, a matriz de covariâncias observada é obtida a partir da matriz de dados centralizada. Sua SVD relaciona diretamente direções principais, escores, autovalores e aproximações de posto reduzido. A ACP baseada na matriz de correlações corresponde

à aplicação da mesma construção às variáveis padronizadas e, por isso, pode produzir uma geometria diferente daquela obtida com a matriz de covariâncias.

A definição da ACP exige momentos de segunda ordem finitos, mas não normalidade multivariada. A normalidade acrescenta propriedades probabilísticas, como a independência das componentes descorrelacionadas, e sustenta parte da teoria inferencial clássica.

A identificação das direções depende da estrutura espectral. Autovalores simples identificam autovetores até mudança de sinal; autovalores repetidos identificam os respectivos autoespaços. Para redução a k dimensões, a separação

$$\lambda_k > \lambda_{k+1}$$

identifica unicamente o subespaço principal de dimensão k .

A ACP integra, portanto, combinações lineares, formas quadráticas, quociente de Rayleigh, autovalores, projeções, SVD e covariâncias para resolver um problema de redução dimensional pela preservação máxima da variabilidade.

No próximo capítulo, a matriz de covariâncias deixa de ser apenas decomposta em direções de variabilidade e passa a ser modelada por uma estrutura de fatores comuns e variâncias específicas, conduzindo à Análise Fatorial.

15 Formulação da Análise Fatorial

A Análise Fatorial representa a estrutura de covariâncias entre variáveis observadas por meio de um número menor de variáveis latentes, denominadas **fatores comuns**. O modelo assume que parte das covariâncias entre as variáveis pode ser atribuída a esses fatores, enquanto a variabilidade restante é específica de cada variável (Lawley; Maxwell, 1971).

Diferentemente da ACP, que decompõe a variabilidade total em direções, a Análise Fatorial especifica um modelo para a matriz de covariâncias. No modelo ortogonal, sua estrutura é

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi,$$

em que $\mathbf{L}\mathbf{L}^\top$ representa a parcela comum da covariância e Ψ representa a variabilidade específica.

A formulação reutiliza a matriz de covariâncias populacional definida na Definição 8.2, a noção de posto na Definição 2.14 e, na formulação probabilística posterior, a distribuição normal multivariada na Definição 9.1. O capítulo desenvolve o modelo de fatores comuns, suas condições de identificação, a indeterminação rotacional, as formulações ortogonal e oblíqua, a estimação e o problema dos escores fatoriais.

Neste capítulo, $\mathbf{L}$ será utilizada exclusivamente para a matriz de cargas fatoriais.

15.1 O problema da estrutura latente

Considere o vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p,$$

com segundos momentos finitos, vetor de médias

$$\mu = E(\mathbf{X})$$

e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Os elementos fora da diagonal de Σ registram as covariâncias entre pares de variáveis e, portanto, sua associação linear. Na Análise Fatorial, essa estrutura é representada a partir de uma hipótese: parte das covariâncias entre as variáveis observadas é atribuída à influência conjunta de um número menor de fatores não diretamente observados.

Considere

$$\mathbf{F} = \begin{pmatrix} F_1 \\ \vdots \\ F_m \end{pmatrix} \in \mathbb{R}^m,$$

com

$$1 \leq m < p$$

na formulação de baixa dimensão adotada neste capítulo.

As componentes de $\mathbf{F}$ são variáveis aleatórias latentes. Elas não correspondem a colunas observadas da matriz de dados. Sua existência é postulada pelo modelo para representar a estrutura de covariâncias entre as variáveis observadas.

A redução de dimensão na Análise Fatorial possui, portanto, natureza diferente daquela obtida pela ACP. Na ACP, novas variáveis são construídas diretamente como combinações lineares das variáveis observadas. Na Análise Fatorial, as variáveis observadas são representadas como funções lineares de fatores latentes acrescidas de parcelas específicas.

Os fatores comuns representam a parcela compartilhada da estrutura de covariâncias. Os fatores específicos representam a variabilidade de cada variável que não é atribuída aos fatores comuns. As condições que permitem essa decomposição serão estabelecidas no modelo ortogonal.

15.2 Modelo de fatores comuns

O modelo básico representa o vetor observado como a soma de três parcelas:

1. localização média;
2. contribuição dos fatores comuns;
3. contribuição específica.

Definição 15.1 (Modelo de fatores comuns). Considere um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos e vetor de médias

$$\boldsymbol{\mu} = E(\mathbf{X}) .$$

Sejam

$$\mathbf{F} \in \mathbb{R}^m$$

um vetor aleatório de fatores comuns e

$$\varepsilon \in \mathbb{R}^p$$

um vetor aleatório de fatores específicos, ambos com segundos momentos finitos e satisfazendo

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo de fatores comuns é

$$\mathbf{X} = \boldsymbol{\mu} + \mathbf{L}\mathbf{F} + \varepsilon, \tag{15.1}$$

em que

$$\mathbf{L} \in \mathbb{R}^{p \times m}$$

é a matriz de cargas fatoriais.

Os elementos do modelo são organizados na Tabela [15.1](#).

Tabela 15.1: Elementos do modelo de fatores comuns.

Objeto	Dimensão	Função no modelo
$\mathbf{X}$	$p \times 1$	Vetor de variáveis observadas
$\boldsymbol{\mu}$	$p \times 1$	Vetor de médias
$\mathbf{F}$	$m \times 1$	Vetor de fatores comuns latentes

Objeto	Dimensão	Função no modelo
$\mathbf{L}$	$p \times m$	Matriz de cargas fatoriais
ε	$p \times 1$	Vetor de fatores específicos
Ψ	$p \times p$	Matriz de covariâncias dos fatores específicos no modelo ortogonal

A i -ésima variável pode ser escrita como

$$X_i = \mu_i + l_{i1}F_1 + l_{i2}F_2 + \cdots + l_{im}F_m + \varepsilon_i. \quad (15.2)$$

A linha i da matriz de cargas será denotada por

$$\mathbf{l}_i^\top = (l_{i1} \quad \cdots \quad l_{im}).$$

Assim,

$$X_i - \mu_i = \mathbf{l}_i^\top \mathbf{F} + \varepsilon_i.$$

A carga l_{ij} representa o coeficiente associado ao fator F_j na expressão linear da variável X_i . Sua interpretação depende da escala dos fatores, da escala das variáveis e da parametrização utilizada.

A Figura 15.1 representa a estrutura de um modelo com dois fatores e três variáveis observadas. As setas azuis representam as contribuições dos fatores comuns e as setas vermelhas representam os fatores específicos.

A figura mostra a estrutura linear postulada pelo modelo. Sob as hipóteses do modelo ortogonal estabelecidas a seguir, as covariâncias entre variáveis distintas são atribuídas à parcela comum, enquanto os fatores específicos não acrescentam covariâncias entre variáveis distintas.

15.3 Hipóteses do modelo ortogonal

A expressão na Equação 15.1 ainda não determina a estrutura de covariâncias. Para isso, são estabelecidas condições sobre os fatores comuns e os fatores específicos.

Na formulação ortogonal padronizada dos fatores,

$$E(\mathbf{F}) = \mathbf{0}$$




Figura 15.1: Estrutura do modelo de fatores comuns: as variáveis observadas recebem contribuições dos fatores comuns e dos fatores específicos.

e

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m.$$

Os fatores específicos satisfazem

$$E(\varepsilon) = \mathbf{0}$$

e

$$\text{Cov}(\varepsilon) = \Psi,$$

com

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0.$$

Além disso,

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Essas condições são reunidas na definição a seguir.

Definição 15.2 (Modelo fatorial ortogonal). Considere o modelo de fatores comuns da Definição 15.1, com

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo é denominado **fatorial ortogonal padronizado** quando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, atribui variância unitária a cada fator e estabelece covariâncias nulas entre fatores distintos. A ortogonalidade, nesse contexto, refere-se à estrutura de covariâncias dos fatores.

A diagonalidade de Ψ estabelece

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \forall i \neq j.$$

Consequentemente, a parcela específica do modelo não acrescenta covariância entre variáveis distintas.

Essa condição estabelece **não correlação** entre os fatores específicos. A independência entre esses fatores exige hipóteses probabilísticas adicionais. Quando posteriormente for adotado um modelo normal com estrutura probabilística apropriada, a relação entre não correlação e independência poderá ser fortalecida.

A condição

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}$$

separa, em termos de covariância, a parcela comum da parcela específica.

Essas hipóteses são suficientes para obter a estrutura de segunda ordem que define o modelo fatorial ortogonal básico. A normalidade multivariada não é necessária para essa decomposição da covariância. Seu papel aparecerá posteriormente na formulação probabilística do modelo, na estimação por máxima verossimilhança e na distribuição condicional dos fatores.

15.4 Estrutura da matriz de covariâncias

O vetor de médias observadas, definido matricialmente na Equação 8.55, será denotado por

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A matriz de dados centralizada, definida na Equação 8.56, é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

De Equação 15.1,

$$\mathbf{X} - \mu = \mathbf{L}\mathbf{F} + \varepsilon.$$

Pelas condições de média do modelo,

$$E(\mathbf{X}) = \mu.$$

Para a matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\mathbf{L}\mathbf{F} + \varepsilon) \\ &= \mathbf{L} \text{Cov}(\mathbf{F}) \mathbf{L}^\top + \text{Cov}(\varepsilon) \\ &\quad + \mathbf{L} \text{Cov}(\mathbf{F}, \varepsilon) + \text{Cov}(\varepsilon, \mathbf{F}) \mathbf{L}^\top. \end{aligned}$$

A regra de transformação da covariância utilizada nessa expressão foi estabelecida na Proposição 8.6.

Pelas hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Portanto,

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi. \quad (15.3)$$

Proposição 15.1 (Estrutura de covariâncias do modelo fatorial ortogonal). *Sob as hipóteses na Definição 15.2, a matriz de covariâncias de $\mathbf{X}$ é*

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi,$$

em que

$$\mathbf{L}\mathbf{L}^\top \succeq \mathbf{0}$$

e

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p) \succeq \mathbf{0}.$$

A expressão na Equação 15.3 é o núcleo matemático da Análise Fatorial.

A matriz

$$\mathbf{L}\mathbf{L}^\top$$

é a matriz de covariâncias da parcela comum do modelo. Como

$$\mathbf{L} \in \mathbb{R}^{p \times m},$$

tem-se

$$\text{posto}(\mathbf{L}\mathbf{L}^\top) \leq m.$$

Assim, a estrutura comum é representada por uma matriz semidefinida positiva cujo posto é limitado pelo número de fatores.

A matriz

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

contém as variâncias específicas.

A decomposição

$$\Sigma = \underbrace{\mathbf{L}\mathbf{L}^\top}_{\text{estrutura comum}} + \underbrace{\Psi}_{\text{estrutura específica}}$$

mostra a diferença essencial em relação à ACP. A Análise Fatorial não procura uma decomposição espectral completa de Σ . Ela procura representar a matriz de covariâncias por uma estrutura comum de posto reduzido acrescida de uma matriz diagonal de variâncias específicas.

15.4.1 Covariâncias entre variáveis

Considere duas variáveis distintas X_i e X_j . Pelo modelo,

$$X_i - \mu_i = \mathbf{l}_i^\top \mathbf{F} + \varepsilon_i$$

e

$$X_j - \mu_j = \mathbf{l}_j^\top \mathbf{F} + \varepsilon_j.$$

Sob as hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(X_i, X_j) = \mathbf{l}_i^\top \mathbf{l}_j, \quad i \neq j.$$

Equivalentemente,

$$\sigma_{ij} = \sum_{h=1}^m l_{ih} l_{jh}, \quad i \neq j. \quad (15.4)$$

A covariância entre duas variáveis observadas é, portanto, reproduzida pelo produto interno entre seus vetores de cargas.

Esse resultado fornece uma interpretação geométrica importante. As linhas de $\mathbf{L}$ podem ser vistas como vetores em $\mathbb{R}^m$. Variáveis cujos vetores de cargas apresentam grande produto interno positivo possuem covariância positiva segundo o modelo; vetores com produto interno negativo correspondem a covariância negativa; e vetores ortogonais correspondem a covariância nula entre as variáveis no modelo fatorial ortogonal.

Essa geometria será representada mais adiante por meio dos vetores de cargas.

15.4.2 Variâncias das variáveis

Para uma variável X_i ,

$$\begin{aligned}\text{Var}(X_i) &= \text{Var}(\mathbf{l}_i^\top \mathbf{F} + \varepsilon_i) \\ &= \mathbf{l}_i^\top \mathbf{l}_i + \psi_i.\end{aligned}$$

Portanto,

$$\sigma_{ii} = \sum_{h=1}^m l_{ih}^2 + \psi_i. \quad (15.5)$$

A variância de cada variável é decomposta em uma parcela comum e uma parcela específica.

15.5 Comunalidades e especificidades

A decomposição da Equação 15.5 permite definir duas quantidades próprias da Análise Fatorial.

Definição 15.3 (Comunalidade). No modelo fatorial ortogonal na Definição 15.2, a **comunalidade** da variável X_i é

$$h_i^2 = \mathbf{l}_i^\top \mathbf{l}_i = \sum_{h=1}^m l_{ih}^2. \quad (15.6)$$

A comunalidade é a quantidade da variância de X_i atribuída à parcela comum do modelo.

Definição 15.4 (Especificidade). No modelo fatorial ortogonal na Definição 15.2, a **especificidade** da variável X_i é

$$\psi_i = \text{Var}(\varepsilon_i), \quad \psi_i \geq 0.$$

Assim,

$$\text{Var}(X_i) = h_i^2 + \psi_i. \quad (15.7)$$

A comunalidade e a especificidade pertencem à decomposição da variância de **cada variável**. Elas não correspondem à decomposição da variância total em componentes sucessivamente ordenadas, como ocorre na ACP.

Quando as variáveis estão padronizadas,

$$\text{Var}(X_i) = 1,$$

e, portanto,

$$1 = h_i^2 + \psi_i. \quad (15.8)$$

Nesse caso,

$$0 \leq h_i^2 \leq 1$$

e

$$0 \leq \psi_i \leq 1.$$

Como a variância total da variável padronizada é igual a 1, a comunalidade h_i^2 também pode ser interpretada como a proporção de sua variância atribuída aos fatores comuns, enquanto ψ_i é a proporção atribuída ao fator específico.

A soma das comunalidades pode ser escrita como

$$\sum_{i=1}^p h_i^2 = \text{tr}(\mathbf{L}\mathbf{L}^\top).$$

Como

$$\text{tr}(\Sigma) = \text{tr}(\mathbf{L}\mathbf{L}^\top) + \text{tr}(\Psi),$$

a variância total também admite a decomposição

$$\text{tr}(\Sigma) = \sum_{i=1}^p h_i^2 + \sum_{i=1}^p \psi_i. \quad (15.9)$$

A interpretação dessa identidade difere daquela utilizada na ACP. Na ACP, os autovalores distribuem a variância total entre componentes principais. Na Análise Fatorial, a identidade separa a variabilidade atribuída à estrutura comum da variabilidade específica das variáveis.

Exemplo 15.1 (Modelo com um fator comum). Considere três variáveis padronizadas e centralizadas representadas por um único fator comum,

$$\mathbf{X} = \mathbf{L}\mathbf{F} + \varepsilon,$$

com

$$\mathbf{L} = \begin{pmatrix} 0,80 \\ 0,70 \\ 0,60 \end{pmatrix}$$

e

$$\Psi = \begin{pmatrix} 0,36 & 0 & 0 \\ 0 & 0,51 & 0 \\ 0 & 0 & 0,64 \end{pmatrix}.$$

As communalidades são

$$h_1^2 = 0,80^2 = 0,64,$$

$$h_2^2 = 0,70^2 = 0,49$$

e

$$h_3^2 = 0,60^2 = 0,36.$$

Como as variáveis são padronizadas,

$$h_i^2 + \psi_i = 1$$

para cada variável.

A matriz de covariâncias comuns é

$$\mathbf{L}\mathbf{L}^\top = \begin{pmatrix} 0,64 & 0,56 & 0,48 \\ 0,56 & 0,49 & 0,42 \\ 0,48 & 0,42 & 0,36 \end{pmatrix}.$$

Somando as variâncias específicas,

$$\mathcal{R} = \mathbf{L}\mathbf{L}^\top + \Psi = \begin{pmatrix} 1 & 0,56 & 0,48 \\ 0,56 & 1 & 0,42 \\ 0,48 & 0,42 & 1 \end{pmatrix}.$$

As correlações entre variáveis distintas são reproduzidas pelo fator comum. Por exemplo,

$$\text{Corr}(X_1, X_2) = 0,80 \times 0,70 = 0,56.$$

A primeira variável apresenta comunalidade 0,64, de modo que 64% de sua variância padronizada é atribuída ao fator comum e 36% é atribuída ao fator específico. Para a terceira variável, essas parcelas são 36% e 64%, respectivamente.

O exemplo mostra que a Análise Fatorial procura representar simultaneamente as covariâncias entre as variáveis e a decomposição de suas variâncias em parcelas comum e específica.

15.6 Cargas fatoriais e associação com os fatores

A matriz $\mathbf{L}$ reúne as cargas fatoriais do modelo. Seus elementos aparecem tanto na representação das variáveis quanto na matriz de covariâncias reproduzida.

No modelo ortogonal,

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \text{Cov}(\mathbf{L}\mathbf{F} + \varepsilon, \mathbf{F}).$$

Como

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

e

$$\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0},$$

segue que

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \mathbf{L}. \tag{15.10}$$

Portanto,

$$\text{Cov}(X_i, F_j) = l_{ij}.$$

Essa igualdade decorre da parametrização em que os fatores possuem variância unitária.

A carga fatorial coincide com a correlação entre X_i e F_j somente quando a variável observada também possui variância unitária. De forma geral, se $\sigma_{ii} > 0$,

$$\text{Corr}(X_i, F_j) = \frac{l_{ij}}{\sqrt{\sigma_{ii}}}. \quad (15.11)$$

Para variáveis padronizadas,

$$\sigma_{ii} = 1,$$

e então

$$\text{Corr}(X_i, F_j) = l_{ij}.$$

Essa distinção é semelhante àquela estabelecida no capítulo anterior entre coeficientes das componentes principais e correlações das variáveis com as componentes. Na Análise Fatorial, entretanto, as cargas são parâmetros do próprio modelo de covariâncias.

A formulação construída até este ponto mostra que o problema da estrutura latente pode ser expresso por

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi.$$

O passo seguinte consiste em analisar a geometria da matriz de cargas e uma propriedade que distingue profundamente a Análise Fatorial da ACP: diferentes matrizes de cargas podem produzir exatamente a mesma estrutura de covariâncias comuns. Essa indeterminação conduz ao problema de identificação e às rotações fatoriais.

15.7 Geometria das cargas fatoriais

No modelo ortogonal, cada linha da matriz de cargas

$$\mathbf{l}_i^\top = (l_{i1} \quad \cdots \quad l_{im})$$

pode ser representada como um vetor em $\mathbb{R}^m$.

Essa representação reúne duas propriedades obtidas anteriormente:

$$h_i^2 = \mathbf{l}_i^\top \mathbf{l}_i = \|\mathbf{l}_i\|^2$$

e, para $i \neq j$,

$$\sigma_{ij} = \mathbf{l}_i^\top \mathbf{l}_j.$$

Portanto, o comprimento do vetor de cargas da variável X_i determina sua comunalidade, enquanto o produto interno entre os vetores de cargas de duas variáveis determina a covariância comum reproduzida entre elas.

Aplicando a relação entre produto interno e ângulo definida em Definição 1.11, para $\mathbf{l}_i \neq \mathbf{0}$ e $\mathbf{l}_j \neq \mathbf{0}$,

$$\sigma_{ij} = \mathbf{l}_i^\top \mathbf{l}_j = \|\mathbf{l}_i\| \|\mathbf{l}_j\| \cos(\theta_{ij}),$$

em que $\theta_{ij} \in [0, \pi]$ é o ângulo entre os vetores de cargas $\mathbf{l}_i$ e $\mathbf{l}_j$. Assim, a covariância comum depende simultaneamente dos comprimentos dos vetores e de sua orientação relativa.

Vetores próximos em direção produzem produto interno positivo. Vetores orientados em sentidos aproximadamente opostos produzem produto interno negativo. Vetores aproximadamente ortogonais produzem pequena covariância comum.

A Figura 15.2 representa quatro variáveis em um modelo com dois fatores. O comprimento de cada vetor está associado à comunalidade e sua orientação descreve a relação da variável com os fatores.

Os vetores de X_1 e X_2 apresentam orientações semelhantes e, portanto, produto interno positivo. A variável X_3 está mais associada à segunda direção fatorial. A posição de X_4 mostra que uma variável pode apresentar sinais diferentes de associação com os dois fatores.

O círculo unitário fornece uma referência geométrica para variáveis padronizadas. Nesse caso,

$$h_i^2 \leq 1,$$

de modo que os vetores de cargas permanecem no interior ou sobre a circunferência.

Essa representação não transforma os fatores em variáveis observadas. Ela representa os parâmetros que relacionam cada variável observada às dimensões latentes especificadas pelo modelo.




Figura 15.2: Geometria das cargas em um modelo com dois fatores. O comprimento de cada vetor determina a communalidade e o produto interno entre vetores determina a covariância comum entre as variáveis.

15.8 Matriz de covariâncias comuns

A estrutura fatorial comum pode ser isolada pela diferença entre a matriz total de covariâncias e a matriz de especificidades.

Defina

$$\Sigma_{\text{com}} = \Sigma - \Psi.$$

Pela Equação 15.3,

$$\Sigma_{\text{com}} = \mathbf{L}\mathbf{L}^\top. \quad (15.12)$$

Definição 15.5 (Matriz de covariâncias comuns). No modelo fatorial ortogonal na Definição 15.2, a **matriz de covariâncias comuns** é

$$\Sigma_{\text{com}} = \mathbf{L}\mathbf{L}^\top.$$

Seus elementos diagonais são as communalidades e seus elementos fora da diagonal são as covariâncias reproduzidas pelos fatores comuns.

A diagonal de Σ_{com} é

$$\text{diag}(\Sigma_{\text{com}}) = \begin{pmatrix} h_1^2 \\ \vdots \\ h_p^2 \end{pmatrix},$$

enquanto, para $i \neq j$,

$$(\Sigma_{\text{com}})_{ij} = \sigma_{ij}.$$

Na formulação populacional exata do modelo básico, toda covariância entre variáveis distintas é atribuída aos fatores comuns. As variâncias possuem uma parcela adicional representada por Ψ .

Quando as variáveis são padronizadas,

$$\Sigma = \mathcal{R},$$

e a matriz comum possui diagonal formada pelas communalidades:

$$\mathcal{R}_{\text{com}} = \mathcal{R} - \Psi.$$

Como Ψ é diagonal, $\mathcal{R}_{\text{com}}$ e $\mathcal{R}$ possuem os mesmos elementos fora da diagonal. A diferença ocorre na diagonal: os valores unitários de $\mathcal{R}$ são substituídos pelas comunalidades h_i^2 na matriz comum.

A dimensão da estrutura comum é limitada pelo número de fatores. Como

$$\text{posto}(\mathbf{L}\mathbf{L}^\top) \leq m,$$

a Análise Fatorial procura representar uma matriz de covariâncias de dimensão p por uma estrutura comum cujo posto é, no máximo, $m < p$.

Essa redução de posto pertence apenas à parcela comum. A matriz total

$$\Sigma = \Sigma_{\text{com}} + \Psi$$

pode continuar apresentando posto completo porque as variâncias específicas acrescentam variabilidade nas direções das variáveis observadas.

Esse ponto distingue novamente a Análise Fatorial da aproximação de posto reduzido utilizada na ACP. Uma aproximação espectral truncada de Σ produz diretamente uma matriz de posto reduzido. O modelo fatorial acrescenta uma matriz diagonal e procura preservar a estrutura específica de cada variável.

15.9 Identificação do modelo fatorial

A equação

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi$$

não determina automaticamente valores únicos para todos os parâmetros.

Na formulação de segunda ordem desenvolvida até aqui, a identificação diz respeito às características de $\mathbf{L}$ e Ψ que podem ser determinadas de forma única a partir de Σ . Quando uma distribuição probabilística completa for especificada posteriormente, o conceito de identificação poderá ser considerado em relação à distribuição das variáveis observadas.

Algumas indeterminações decorrem diretamente da parametrização dos fatores. Entre elas estão a escala, o sinal e a orientação dos eixos fatoriais.

15.9.1 Escala dos fatores

Considere, inicialmente, um único fator:

$$\mathbf{X} = \mu + \mathbf{L}\mathbf{F} + \varepsilon.$$

Para qualquer constante não nula c ,

$$\mathbf{L}\mathbf{F} = (cl) \left(\frac{F}{c} \right).$$

Logo, sem uma restrição adicional, a escala da carga e a escala do fator podem ser modificadas simultaneamente sem alterar a parte comum do modelo.

No modelo ortogonal padronizado, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a variância de cada fator e remove essa indeterminação de escala.

15.9.2 Indeterminação do sinal

Se uma coluna de $\mathbf{L}$ e o fator correspondente tiverem seus sinais invertidos simultaneamente, o produto permanece inalterado.

Para o fator F_j ,

$$\mathbf{l}_j F_j = (-\mathbf{l}_j) (-F_j).$$

Portanto, o sinal de um fator não é determinado pelo modelo.

Essa propriedade é semelhante à indeterminação de sinal dos autovetores observada na ACP, mas sua origem pertence agora à representação do produto entre carga e fator latente.

15.9.3 Indeterminação rotacional

A indeterminação mais importante ocorre quando

$$m \geq 2.$$

Considere uma matriz ortogonal

$$\mathbf{T} \in \mathbb{R}^{m \times m},$$

definida na Definição 2.18, de modo que

$$\mathbf{T}^\top \mathbf{T} = \mathbf{T} \mathbf{T}^\top = \mathbf{I}_m.$$

Defina

$$\mathbf{L}^* = \mathbf{L} \mathbf{T}$$

e

$$\mathbf{F}^* = \mathbf{T}^\top \mathbf{F}.$$

Então,

$$\begin{aligned} \mathbf{L}^* \mathbf{F}^* &= \mathbf{L} \mathbf{T} \mathbf{T}^\top \mathbf{F} \\ &= \mathbf{L} \mathbf{F}. \end{aligned}$$

Além disso,

$$\begin{aligned} \text{Cov}(\mathbf{F}^*) &= \mathbf{T}^\top \text{Cov}(\mathbf{F}) \mathbf{T} \\ &= \mathbf{T}^\top \mathbf{T} \\ &= \mathbf{I}_m. \end{aligned}$$

A nova representação continua sendo ortogonal.

Para a matriz de covariâncias comuns,

$$\begin{aligned} \mathbf{L}^* \mathbf{L}^{*\top} &= \mathbf{L} \mathbf{T} \mathbf{T}^\top \mathbf{L}^\top \\ &= \mathbf{L} \mathbf{L}^\top. \end{aligned}$$

Portanto,

$$\mathbf{L}^* \mathbf{L}^{*\top} = \mathbf{L} \mathbf{L}^\top. \quad (15.13)$$

Proposição 15.2 (Indeterminação rotacional do modelo fatorial ortogonal). *Considere um modelo fatorial ortogonal com*

$$\mathbf{L} \in \mathbb{R}^{p \times m}$$

e seja

$$\mathbf{T} \in \mathbb{R}^{m \times m}$$

qualquer matriz ortogonal. Então a matriz de cargas

$$\mathbf{L}^* = \mathbf{L} \mathbf{T}$$

produz a mesma matriz de covariâncias comuns:

$$\mathbf{L}^* \mathbf{L}^{*\top} = \mathbf{L} \mathbf{L}^\top.$$

Além disso, com

$$\mathbf{F}^* = \mathbf{T}^\top \mathbf{F},$$

a parcela comum do modelo é preservada e

$$\text{Cov}(\mathbf{F}^*) = \mathbf{I}_m.$$

Assim, a estrutura de covariâncias do modelo não determina uma orientação ortogonal única para os fatores.

O resultado utiliza diretamente as propriedades das transformações ortogonais desenvolvidas no Módulo 1, em particular a preservação do produto interno estabelecida no Teorema 2.7.

A indeterminação rotacional mostra que diferentes matrizes de cargas relacionadas por transformações ortogonais podem representar a mesma matriz

$$\mathbf{L} \mathbf{L}^\top.$$

Esse resultado demonstra a não unicidade da orientação dos fatores. Ele não implica, por si só, que $\mathbf{LL}^\top$ e Ψ sejam identificáveis de forma única a partir de Σ ; essa questão requer condições adicionais de identificação.

15.10 Rotação dos eixos fatoriais

A rotação modifica a representação das cargas em relação aos eixos fatoriais. No caso de uma rotação ortogonal, ela preserva exatamente a matriz de covariâncias comuns e, conseqüentemente, a matriz de covariâncias reproduzida quando Ψ é mantida.

A Figura 15.3 compara uma matriz de cargas com uma solução obtida por uma rotação ortogonal. Para fins ilustrativos, os eixos são girados em 35° . Esse valor não corresponde a um critério específico de rotação: em uma aplicação, a orientação é determinada pelo critério adotado. Os vetores mudam de coordenadas em relação aos eixos, mas seus comprimentos e produtos internos são preservados.




Figura 15.3: Uma rotação ortogonal modifica as coordenadas das cargas, mas preserva comprimentos, produtos internos, communalidades e a matriz de covariâncias comuns.

A rotação altera os coeficientes individuais da matriz de cargas. As communalidades permanecem invariantes porque

$$\|\mathbf{l}_i^\top \mathbf{T}\|^2 = \|\mathbf{l}_i\|^2.$$

As covariâncias comuns também permanecem invariantes porque

$$(\mathbf{l}_i^\top \mathbf{T}) (\mathbf{l}_j^\top \mathbf{T})^\top = \mathbf{l}_i^\top \mathbf{l}_j.$$

Assim, a rotação ortogonal modifica a parametrização das cargas sem alterar a estrutura comum reproduzida.

A variância comum total também permanece inalterada:

$$\text{tr}(\mathbf{L}\mathbf{L}^\top) = \sum_{j=1}^m \|\mathbf{l}_{\cdot j}\|^2.$$

A distribuição dessa quantidade entre fatores individuais, entretanto, pode mudar após a rotação. Em geral,

$$\sum_{i=1}^p l_{ij}^2$$

não é preservada separadamente para cada coluna j .

Por isso, fatores rotacionados não devem ser interpretados como uma sequência ordenada de parcelas invariantes da variância total, como ocorre com as componentes principais. A rotação preserva a estrutura comum global, mas redistribui sua representação entre os eixos fatoriais.

A rotação deve ser distinguida da estimação inicial. Primeiro é obtida uma solução que reproduz a estrutura de covariâncias segundo determinado critério. Depois, uma transformação pode ser aplicada às cargas para selecionar outra representação da estrutura fatorial.

O objetivo de uma rotação interpretativa é escolher uma estrutura de cargas cuja organização favoreça uma interpretação mais simples. A diferença entre rotações ortogonais e oblíquas será estabelecida nas seções seguintes; somente depois dessa distinção serão apresentados critérios específicos de rotação.

15.11 Contagem de parâmetros e identificação

A matriz simétrica Σ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

No modelo ortogonal com m fatores, a matriz de cargas possui

$$pm$$

elementos e a matriz diagonal Ψ possui

$$p$$

variâncias específicas.

Uma contagem direta produziria

$$pm + p$$

parâmetros. Essa parametrização contém, entretanto, matrizes de cargas relacionadas por rotações ortogonais que produzem a mesma matriz de covariâncias.

Em pontos regulares da parametrização, supondo em particular que

$$\text{posto}(\mathbf{L}) = m,$$

a indeterminação rotacional possui

$$\frac{m(m-1)}{2}$$

dimensões. Assim, a dimensão usual da parametrização exploratória ortogonal, após descontar essa indeterminação, é

$$pm + p - \frac{m(m-1)}{2}. \quad (15.14)$$

Uma condição necessária de contagem é, portanto,

$$pm + p - \frac{m(m-1)}{2} \leq \frac{p(p+1)}{2}. \quad (15.15)$$

Essa desigualdade compara a dimensão usual da parametrização com o número de elementos distintos de Σ . Ela constitui uma condição necessária de disponibilidade de informação em pontos regulares, mas não é, isoladamente, uma condição suficiente de identificação.

Contagem de parâmetros e identificação

Ter número de elementos observáveis igual ou superior à dimensão da parametrização não garante, por si só, identificação do modelo. A identificação também depende da estrutura

das cargas, das restrições impostas e da posição do parâmetro no espaço paramétrico.

Para selecionar uma parametrização particular, podem ser impostas restrições adicionais às cargas ou à orientação dos fatores. Essas restrições assumem formas diferentes conforme o tipo de modelo e o objetivo da análise.

Na Análise Fatorial Exploratória, a indeterminação rotacional é reconhecida como parte da estrutura da técnica, e diferentes orientações podem ser escolhidas posteriormente para interpretação. Em modelos fatoriais confirmatórios, restrições previamente especificadas sobre cargas e covariâncias fatoriais passam a desempenhar papel explícito na identificação.

O desenvolvimento completo das condições algébricas de identificação pertence à teoria de modelos de variáveis latentes e não é necessário para a formulação deste capítulo.

15.12 Fatores ortogonais e fatores oblíquos

A formulação desenvolvida até aqui utilizou fatores com matriz de covariâncias

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m.$$

Essa condição define a formulação ortogonal padronizada: os fatores possuem variância unitária e covariâncias nulas entre si.

O modelo pode ser generalizado permitindo covariâncias diferentes de zero entre os fatores.

Definição 15.6 (Modelo fatorial oblíquo). Considere o modelo de fatores comuns na Definição 15.1,

$$\mathbf{X} = \mu + \mathbf{L}\mathbf{F} + \varepsilon,$$

com

$$\mathbf{L} \in \mathbb{R}^{p \times m}.$$

O modelo é denominado **fatorial oblíquo** quando

$$\text{Cov}(\mathbf{F}) = \Phi,$$

em que

$$\Phi \in \mathbb{R}^{m \times m}, \quad \Phi \succeq \mathbf{0},$$

e continuam válidas as condições

$$E(\mathbf{F}) = \mathbf{0},$$

$$E(\varepsilon) = \mathbf{0},$$

$$\text{Cov}(\varepsilon) = \Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A matriz Φ é a matriz de covariâncias dos fatores. Quando a escala de cada fator é fixada em variância unitária,

$$\text{diag}(\Phi) = \mathbf{1}_m,$$

e Φ passa a ser também a matriz de correlações entre os fatores.

A matriz de covariâncias das variáveis observadas é

$$\Sigma = \mathbf{L}\Phi\mathbf{L}^\top + \Psi. \tag{15.16}$$

De fato,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\mathbf{L}\mathbf{F} + \varepsilon) \\ &= \mathbf{L} \text{Cov}(\mathbf{F}) \mathbf{L}^\top + \text{Cov}(\varepsilon) \\ &= \mathbf{L}\Phi\mathbf{L}^\top + \Psi. \end{aligned}$$

No caso particular

$$\Phi = \mathbf{I}_m,$$

recupera-se o modelo fatorial ortogonal na Definição [15.2](#).

No modelo oblíquo, a parcela comum da covariância é

$$\Sigma_{\text{com}} = \mathbf{L}\Phi\mathbf{L}^\top.$$

Assim, para a variável X_i ,

$$h_i^2 = \mathbf{l}_i^\top \Phi \mathbf{l}_i. \quad (15.17)$$

A expressão

$$h_i^2 = \sum_{j=1}^m l_{ij}^2$$

é, portanto, específica da formulação ortogonal com fatores de variância unitária.

A comparação entre as duas formulações é sintetizada na Tabela 15.2.

Tabela 15.2: Estruturas dos modelos fatoriais ortogonal e oblíquo.

Aspecto	Modelo ortogonal padronizado	Modelo oblíquo
Covariância dos fatores	$\mathbf{I}_m$	Φ
Relação entre fatores	Covariâncias nulas	Podem existir covariâncias diferentes de zero
Covariância comum	$\mathbf{L}\mathbf{L}^\top$	$\mathbf{L}\Phi\mathbf{L}^\top$
Comunalidade de X_i	$\mathbf{l}_i^\top \mathbf{l}_i$	$\mathbf{l}_i^\top \Phi \mathbf{l}_i$
Covariância variável–fator	$\mathbf{L}$	$\mathbf{L}\Phi$

15.13 Reparametrização do espaço fatorial

A relação entre representações fatoriais pode ser compreendida por meio de transformações das coordenadas latentes.

Considere uma matriz não singular

$$\mathbf{T} \in \mathbb{R}^{m \times m}$$

e defina

$$\mathbf{F}^* = \mathbf{T}^{-1}\mathbf{F}.$$

Então,

$$\mathbf{F} = \mathbf{T}\mathbf{F}^*,$$

e o modelo pode ser escrito como

$$\mathbf{X} - \mu = \mathbf{L}^*\mathbf{F}^* + \varepsilon,$$

com

$$\mathbf{L}^* = \mathbf{L}\mathbf{T}.$$

A matriz de covariâncias dos novos fatores é

$$\Phi^* = \mathbf{T}^{-1}\Phi\mathbf{T}^{-\top}.$$

Consequentemente,

$$\begin{aligned}\mathbf{L}^*\Phi^*\mathbf{L}^{*\top} &= \mathbf{L}\mathbf{T}\mathbf{T}^{-1}\Phi\mathbf{T}^{-\top}\mathbf{T}^\top\mathbf{L}^\top \\ &= \mathbf{L}\Phi\mathbf{L}^\top.\end{aligned}$$

Proposição 15.3 (Invariância da estrutura comum por reparametrização). *Considere uma representação fatorial com*

$$\mathbf{L} \in \mathbb{R}^{p \times m}$$

e

$$\text{Cov}(\mathbf{F}) = \Phi.$$

Se

$$\mathbf{T} \in \mathbb{R}^{m \times m}$$

é não singular e cargas, fatores e covariâncias fatoriais são transformados conjuntamente por

$$\mathbf{L}^* = \mathbf{L}\mathbf{T},$$

$$\mathbf{F}^* = \mathbf{T}^{-1} \mathbf{F}$$

e

$$\Phi^* = \mathbf{T}^{-1} \Phi \mathbf{T}^{-\top},$$

então

$$\mathbf{L}^* \Phi^* \mathbf{L}^{*\top} = \mathbf{L} \Phi \mathbf{L}^\top.$$

Portanto, a matriz de covariâncias comuns permanece inalterada sob essa reparametrização.

A indeterminação rotacional do modelo ortogonal, apresentada na Proposição 15.2, é um caso particular desse resultado.

Se inicialmente

$$\Phi = \mathbf{I}_m$$

e $\mathbf{T}$ é ortogonal, então

$$\Phi^* = \mathbf{I}_m,$$

e os fatores transformados continuam ortogonais.

Se $\mathbf{T}$ é não ortogonal, a matriz

$$\Phi^* = \mathbf{T}^{-1} \mathbf{T}^{-\top}$$

pode possuir elementos fora da diagonal. A nova representação passa, então, a utilizar fatores correlacionados.

O que permanece invariável é a estrutura comum reproduzida,

$$\mathbf{L} \Phi \mathbf{L}^\top,$$

enquanto as coordenadas utilizadas para representar essa estrutura podem mudar.

15.14 Matriz de padrões e matriz de estrutura

Quando os fatores são correlacionados, os coeficientes que aparecem diretamente no modelo e as associações entre variáveis e fatores deixam de coincidir.

A matriz

$$\mathbf{L}$$

contém os coeficientes que aparecem em

$$\mathbf{X} - \mu = \mathbf{L}\mathbf{F} + \varepsilon.$$

Ela é denominada **matriz de padrões**.

Por outro lado,

$$\begin{aligned}\text{Cov}(\mathbf{X}, \mathbf{F}) &= \text{Cov}(\mathbf{L}\mathbf{F} + \varepsilon, \mathbf{F}) \\ &= \mathbf{L}\Phi.\end{aligned}$$

Defina

$$\Gamma_{\text{cov}} = \mathbf{L}\Phi. \quad (15.18)$$

Essa matriz contém as covariâncias entre as variáveis observadas e os fatores.

Quando os fatores possuem variância unitária, defina

$$\mathbf{D}_{\Sigma} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Se

$$\sigma_{ii} > 0, \quad i = 1, \dots, p,$$

a matriz das correlações entre as variáveis observadas e os fatores é

$$\Gamma = \mathbf{D}_{\Sigma}^{-1/2} \mathbf{L}\Phi. \quad (15.19)$$

Quando as variáveis observadas também estão padronizadas,

$$\mathbf{D}_{\Sigma} = \mathbf{I}_p,$$

e, portanto,

$$\Gamma = \mathbf{L}\Phi.$$

Definição 15.7 (Matrizes de padrões e de estrutura). Considere um modelo fatorial oblíquo com fatores de variância unitária e variáveis observadas com variâncias positivas.

A **matriz de padrões** é

$$\mathbf{L},$$

formada pelos coeficientes que relacionam diretamente as variáveis observadas aos fatores no modelo linear.

A **matriz de estrutura** é

$$\Gamma = \mathbf{D}_{\Sigma}^{-1/2} \mathbf{L}\Phi,$$

cujos elementos são as correlações entre as variáveis observadas e os fatores.

Se as variáveis observadas são padronizadas,

$$\Gamma = \mathbf{L}\Phi.$$

No modelo ortogonal padronizado,

$$\Phi = \mathbf{I}_m.$$

Se as variáveis observadas também são padronizadas,

$$\Gamma = \mathbf{L}.$$

Assim, matriz de padrões e matriz de estrutura coincidem nessa parametrização ortogonal padronizada.

No modelo oblíquo, elas geralmente diferem. Um elemento da matriz de padrões representa o coeficiente diretamente associado a determinado fator no modelo, enquanto um elemento da matriz de estrutura representa a correlação da variável com esse fator. Como os fatores podem estar correlacionados, essas duas quantidades não precisam coincidir.

Essa distinção orienta a interpretação das soluções oblíquas. Uma correlação elevada entre uma variável e um fator pode resultar do coeficiente diretamente associado a esse fator e das correlações existentes entre os fatores.

15.15 Rotação e estrutura simples

A indeterminação rotacional permite escolher, entre representações equivalentes da estrutura comum, uma orientação das cargas que favoreça sua interpretação.

A rotação é aplicada após a obtenção de uma solução fatorial inicial. Ela não constitui um método de extração ou de estimação da matriz de covariâncias. Seu papel é selecionar outra parametrização do espaço fatorial preservando a estrutura compatível com a classe de transformação adotada.

Uma orientação frequentemente procurada é a de **estrutura simples**, na qual cada variável apresenta cargas concentradas em um número reduzido de fatores e cargas pequenas nos demais.

As rotações podem ser classificadas em duas classes principais.

Nas **rotações ortogonais**, a transformação satisfaz

$$\mathbf{T}^T \mathbf{T} = \mathbf{I}_m,$$

de modo que os fatores permanecem não correlacionados. Se

$$\mathbf{L}^* = \mathbf{L}\mathbf{T},$$

então

$$\mathbf{L}^* \mathbf{L}^{*\top} = \mathbf{L} \mathbf{L}^T.$$

Consequentemente, a matriz de covariâncias comuns e as communalidades são preservadas. Em uma solução com dois fatores, uma transformação ortogonal pode ser visualizada como uma rotação dos eixos por determinado ângulo θ , mas esse ângulo não é fixado previamente pelo método. Os eixos permanecem perpendiculares entre si, formando 90° , enquanto sua orientação é escolhida segundo o critério de rotação. Com mais de dois fatores, a transformação ortogonal não é descrita, em geral, por um único ângulo.

O **Varimax** é um critério de rotação ortogonal que procura tornar mais contrastantes os quadrados das cargas dentro de cada fator, favorecendo uma estrutura em que cada fator apresente algumas cargas elevadas e outras próximas de zero (Kaiser, 1958). O **Equamax**

também é ortogonal e pertence à família de critérios Orthomax; ele combina características do Varimax, que favorece a simplificação dos fatores, e do Quartimax, que favorece a simplificação das variáveis.

Nas **rotações oblíquas**, a transformação não precisa ser ortogonal e os fatores podem tornar-se correlacionados. A estrutura comum deve então ser representada por

$$\mathbf{L}\Phi\mathbf{L}^\top,$$

com

$$\Phi \neq \mathbf{I}_m$$

em geral. O **Promax** é um procedimento de rotação oblíqua que parte usualmente de uma solução ortogonal, em geral obtida por Varimax, e constrói uma estrutura-alvo na qual as cargas maiores são acentuadas em relação às menores por meio de uma transformação de potência. Em seguida, uma transformação não ortogonal aproxima a solução dessa estrutura-alvo (Hendrickson; White, 1964). Como consequência, os eixos fatoriais não precisam permanecer perpendiculares e os fatores podem apresentar correlações. O Promax não possui um ângulo de rotação fixo: os ângulos entre os eixos resultam da solução obtida, enquanto o parâmetro de potência controla a acentuação da estrutura-alvo, e não um ângulo geométrico.

Nessa classe de soluções, a interpretação exige distinguir a matriz de padrões $\mathbf{L}$, a matriz de estrutura Γ e a matriz de correlações fatoriais Φ .

A formulação matemática completa dos critérios de rotação e seus algoritmos pertence à etapa metodológica posterior. Neste capítulo, interessa compreender o objetivo desses critérios, distinguir as transformações ortogonais das oblíquas e identificar quais características do modelo são preservadas em cada caso.

15.16 Formulação populacional e amostral

No nível populacional, o modelo fatorial especifica uma estrutura para a matriz de covariâncias. No modelo ortogonal,

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi.$$

Os parâmetros de interesse incluem as cargas fatoriais, as variâncias específicas e, no modelo oblíquo, as covariâncias ou correlações entre os fatores, conforme a parametrização adotada.

Na prática, Σ é desconhecida. A informação disponível provém de uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

cuja realização é organizada na matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

Denote o vetor de médias observadas por

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

e a matriz de dados centralizada por

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A matriz de covariâncias observada $\mathbf{S}$, definida na Definição 8.11, e a matriz de correlações observada $\mathbf{R}$, definida na Definição 8.12, fornecem as estruturas de segunda ordem utilizadas no ajuste.

Após a escolha do número de fatores e de uma parametrização apropriada, a formulação amostral procura estimar

$$\mathbf{L}, \quad \Psi$$

e, no caso oblíquo,

$$\Phi.$$

As estimativas serão denotadas por

$$\widehat{\mathbf{L}}, \quad \widehat{\Psi}$$

e

$$\widehat{\Phi},$$

respectivamente.

Como discutido nas seções de identificação e rotação, a matriz de cargas não é determinada unicamente sem restrições ou convenções adicionais. Portanto, uma matriz $\widehat{\mathbf{L}}$ representa uma parametrização particular da estrutura fatorial estimada.

No modelo ortogonal, a matriz de covariâncias reproduzida é

$$\widehat{\Sigma}_{\text{fat}} = \widehat{\mathbf{L}}\widehat{\mathbf{L}}^\top + \widehat{\Psi}. \quad (15.20)$$

No modelo oblíquo,

$$\widehat{\Sigma}_{\text{fat}} = \widehat{\mathbf{L}}\widehat{\Phi}\widehat{\mathbf{L}}^\top + \widehat{\Psi}.$$

Quando a análise é baseada em correlações, a matriz reproduzida será denotada por

$$\widehat{\mathcal{R}}_{\text{fat}},$$

com parametrização correspondente às variáveis padronizadas.

No caso ortogonal,

$$\widehat{\mathcal{R}}_{\text{fat}} = \widehat{\mathbf{L}}\widehat{\mathbf{L}}^\top + \widehat{\Psi}.$$

A escolha entre $\mathbf{S}$ e $\mathbf{R}$ modifica a estrutura que está sendo modelada. Na análise baseada em $\mathbf{S}$, as variâncias e covariâncias permanecem nas escalas originais. Na análise baseada em $\mathbf{R}$, as variáveis são padronizadas e as comunalidades e especificidades passam a decompor variâncias unitárias.

Essa distinção é análoga à discutida na ACP, mas seu efeito deve ser interpretado no contexto do modelo fatorial. A padronização modifica a matriz de segunda ordem que o modelo procura reproduzir e, conseqüentemente, pode modificar cargas, comunalidades e especificidades.

15.17 Matriz reproduzida e resíduos

A adequação da representação da estrutura de segunda ordem pode ser examinada pela diferença entre a matriz observada e a matriz reproduzida.

Para uma análise baseada em covariâncias, a matriz de resíduos é

$$\mathbf{E}_S = \mathbf{S} - \widehat{\Sigma}_{\text{fat}}. \quad (15.21)$$

Para uma análise baseada em correlações,

$$\mathbf{E}_R = \mathbf{R} - \widehat{\mathcal{R}}_{\text{fat}}. \quad (15.22)$$

Os elementos fora da diagonal dessas matrizes representam covariâncias ou correlações observadas que não foram reproduzidas pela estrutura comum estimada.

No modelo populacional exato,

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi$$

no caso ortogonal, ou

$$\Sigma = \mathbf{L}\Phi\mathbf{L}^\top + \Psi$$

no caso oblíquo.

A matriz residual populacional correspondente é, então, nula.

Na amostra, a igualdade exata entre a matriz observada e a matriz reproduzida não é esperada em geral. Mesmo quando o modelo populacional é corretamente especificado, $\mathbf{S}$ ou $\mathbf{R}$ apresentam variabilidade amostral. Além disso, uma estrutura com determinado número de fatores pode não representar adequadamente a matriz populacional que gerou os dados.

A Figura 15.4 representa a decomposição de uma matriz de covariâncias em sua parcela comum e sua parcela específica.




Figura 15.4: Decomposição de uma matriz de covariâncias em estrutura comum, produzida pelas cargas fatoriais, e estrutura específica diagonal.

A matriz comum reproduz as covariâncias entre variáveis distintas e contribui também para as variâncias da diagonal. A matriz específica acrescenta somente variabilidade própria a cada variável. A soma das duas parcelas produz a matriz total especificada pelo modelo.

15.18 O problema de estimação

Diferentemente da ACP, a Análise Fatorial não fornece, em geral, todos os parâmetros do modelo por uma única decomposição direta da matriz observada. É necessário estabelecer um critério para aproximar a estrutura observada pela estrutura permitida pelo modelo.

Para uma análise baseada em covariâncias, o problema pode ser representado genericamente por

$$\min_{\theta} D[\mathbf{S}, \Sigma(\theta)], \quad (15.23)$$

em que θ reúne os parâmetros livres e, no modelo ortogonal,

$$\Sigma(\theta) = \mathbf{L}\mathbf{L}^{\top} + \Psi.$$

No modelo oblíquo,

$$\Sigma(\theta) = \mathbf{L}\Phi\mathbf{L}^{\top} + \Psi.$$

A função

$$D[\mathbf{S}, \Sigma(\theta)]$$

mede a discrepância entre a matriz de covariâncias observada e a matriz reproduzida.

Quando a análise é baseada em correlações, a mesma ideia é aplicada substituindo $\mathbf{S}$ por $\mathbf{R}$ e utilizando uma parametrização correspondente às variáveis padronizadas.

Diferentes métodos de estimação correspondem a diferentes critérios de ajuste ou diferentes estratégias para obter os parâmetros da estrutura fatorial. O objetivo deste capítulo é apresentar sua estrutura matemática, sem desenvolver os algoritmos iterativos utilizados para calculá-los.

A estimação deve ser distinguida da rotação. O método de estimação procura obter uma estrutura fatorial compatível com a matriz observada. A rotação atua posteriormente sobre uma representação dessa estrutura, segundo as propriedades estudadas nas seções anteriores.

15.18.1 Fatores principais

Uma abordagem procura concentrar a decomposição espectral na parte comum da matriz de covariâncias ou correlações.

No nível populacional, para o modelo ortogonal,

$$\Sigma_{\text{com}} = \Sigma - \Psi = \mathbf{L}\mathbf{L}^\top.$$

Se Ψ fosse conhecida, a matriz comum, por ser simétrica e positiva semidefinida, poderia ser decomposta pelo Teorema Espectral do Teorema 5.4. Como

$$\text{posto}(\Sigma_{\text{com}}) \leq m,$$

até m direções seriam suficientes para representar sua parte de variância positiva quando o modelo possui m fatores.

Na amostra, entretanto, as especificidades e comunalidades são desconhecidas. Para uma análise baseada em correlações, uma matriz reduzida pode ser construída substituindo a diagonal unitária de $\mathbf{R}$ por estimativas das comunalidades:

$$\mathbf{R}_{\text{red}} = \begin{pmatrix} \hat{h}_1^2 & r_{12} & \cdots & r_{1p} \\ r_{21} & \hat{h}_2^2 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & \hat{h}_p^2 \end{pmatrix}. \quad (15.24)$$

A decomposição dessa matriz procura representar a parcela comum da estrutura de correlações, e não a variância total padronizada.

Esse procedimento distingue o método de **fatores principais** da ACP baseada em $\mathbf{R}$. Na ACP, a diagonal da matriz de correlações permanece igual a

$$1,$$

porque toda a variância padronizada participa da decomposição. Na abordagem por fatores principais, a diagonal é substituída por estimativas das comunalidades porque a variabilidade específica não pertence à estrutura comum que se pretende representar.

As comunalidades e as cargas dependem umas das outras. Por isso, sua estimação pode envolver atualizações sucessivas. Os valores iniciais das comunalidades e o algoritmo utilizado para atualizá-las pertencem à implementação do método e não serão desenvolvidos neste capítulo.

15.18.2 Mínimos quadrados

Outra possibilidade é estimar os parâmetros pela minimização dos resíduos entre a matriz observada e a matriz reproduzida.

Para uma análise baseada em covariâncias, uma formulação de mínimos quadrados não ponderados pode ser escrita como

$$F_{\text{MQ}}(\mathbf{L}, \Psi) = \|\mathbf{S} - \mathbf{L}\mathbf{L}^\top - \Psi\|_F^2. \quad (15.25)$$

A norma de Frobenius, definida na Definição 6.7, mede conjuntamente os desvios entre os elementos da matriz observada e da matriz reproduzida.

No modelo ortogonal, como Ψ é diagonal, as covariâncias fora da diagonal são reproduzidas exclusivamente pela parcela

$$\mathbf{L}\mathbf{L}^\top.$$

Os elementos diagonais são decompostos entre comunalidades e especificidades.

Critérios ponderados podem atribuir pesos diferentes aos resíduos, inclusive em função de sua variabilidade amostral. Essas extensões modificam a função de discrepância, mas preservam o mesmo objetivo estrutural: aproximar a matriz observada por uma matriz pertencente à classe especificada pelo modelo fatorial.

15.19 Modelo fatorial normal

A estrutura de segunda ordem desenvolvida até aqui não exige normalidade. Uma formulação probabilística mais específica pode ser obtida impondo distribuições aos fatores comuns e aos fatores específicos.

Definição 15.8 (Modelo fatorial normal). Considere o modelo fatorial ortogonal na Definição 15.2.

O modelo é denominado **fatorial normal ortogonal** quando

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m),$$

$$\varepsilon \sim N_p(\mathbf{0}, \Psi),$$

e

$$\mathbf{F} \perp \varepsilon.$$

A variável observada é

$$\mathbf{X} = \mu + \mathbf{L}\mathbf{F} + \varepsilon.$$

A definição de normal multivariada adotada na Definição 9.1 admite também matrizes de covariâncias singulares. Portanto, a formulação probabilística acima continua fazendo sentido quando alguma especificidade é nula.

Como $\mathbf{F}$ e ε são vetores normais independentes, sua distribuição conjunta é normal. Pela estabilidade da normal multivariada sob transformações afins, estabelecida na Proposição 9.4,

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi. \quad (15.26)$$

A normalidade acrescenta uma especificação distributiva à estrutura de segunda ordem do modelo.

Além disso, como ε é conjuntamente normal e Ψ é diagonal, os fatores específicos são independentes. Essa conclusão utiliza a propriedade de independência entre blocos normais estabelecida na Proposição 9.6.

A hipótese

$$\mathbf{F} \perp \varepsilon$$

também é mais forte do que a condição de covariância cruzada nula utilizada no modelo de segunda ordem.

Essa formulação probabilística permite utilizar a função de verossimilhança definida na Definição 10.11 e o princípio de máxima verossimilhança formalizado na Definição 10.12.

15.20 Estimação por máxima verossimilhança

Considere

$$\theta \in \Theta_{\text{fat}},$$

em que θ reúne os parâmetros livres de uma parametrização identificada do modelo e

$$\Sigma(\theta) = \mathbf{L}\mathbf{L}^\top + \Psi.$$

Para que a densidade normal multivariada não singular, sua inversa e seu log-determinante sejam utilizados na forma seguinte, restringe-se a estimação a valores de θ para os quais

$$\Sigma(\theta) \succ \mathbf{0}. \quad (15.27)$$

Considere então uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p[\mu, \Sigma(\theta)].$$

Para um valor fixado de θ , a maximização em relação à média produz

$$\hat{\mu} = \bar{\mathbf{x}},$$

como no resultado geral da Proposição 10.3.

Defina a matriz de covariâncias com divisor n ,

$$\mathbf{S}_{\text{MV}} = \frac{1}{n} \mathbf{X}_c^\top \mathbf{X}_c. \quad (15.28)$$

Como a matriz $\mathbf{S}$ utilizada descritivamente no livro possui divisor $n - 1$,

$$\mathbf{S}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Desconsiderando termos que não dependem de θ , a log-verossimilhança concentrada pode ser escrita como

$$\ell(\theta) = C - \frac{n}{2} \left\{ \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \right\}. \quad (15.29)$$

A condição na Equação 15.27 garante que o determinante seja positivo e que a inversa da matriz modelada exista.

Maximizar a verossimilhança equivale, portanto, a minimizar

$$\log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] .$$

Se, adicionalmente,

$$\mathbf{S}_{\text{MV}} \succ \mathbf{0},$$

pode-se definir a função de discrepância normalizada

$$\begin{aligned} F_{\text{ML}}(\theta) &= \log |\Sigma(\theta)| \\ &\quad + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \\ &\quad - \log |\mathbf{S}_{\text{MV}}| - p. \end{aligned} \tag{15.30}$$

A constante foi escolhida de modo que

$$F_{\text{ML}} = 0$$

quando

$$\Sigma(\theta) = \mathbf{S}_{\text{MV}}.$$

Se $\mathbf{S}_{\text{MV}}$ é singular, a log-verossimilhança concentrada na Equação 15.29 continua definida para matrizes modeladas positivas definidas, mas a forma normalizada na Equação 15.30 não pode ser utilizada diretamente porque

$$\log |\mathbf{S}_{\text{MV}}|$$

não é finito.

A presença simultânea do log-determinante e da inversa da matriz de covariâncias decorre diretamente da densidade normal multivariada. As ferramentas de cálculo matricial necessárias para diferenciar esse critério já foram desenvolvidas no Capítulo 7, incluindo o diferencial do log-determinante na Proposição 7.12.

A estimação por máxima verossimilhança pode ser expressa por

$$\hat{\theta}_{\text{MV}} \in \arg \min_{\theta \in \Theta_{\text{fat}}} F_{\text{ML}}(\theta),$$

quando a forma normalizada está definida.

O espaço paramétrico deve respeitar as condições do modelo, entre elas

$$\psi_i \geq 0, \quad i = 1, \dots, p,$$

e

$$\Sigma(\theta) \succ \mathbf{0}.$$

A solução não é obtida, em geral, por uma única decomposição matricial explícita. Métodos numéricos são utilizados para resolver o problema de otimização. O desenvolvimento desses algoritmos pertence à implementação da técnica (Lawley; Maxwell, 1971).

15.20.1 Ajuste global e graus de liberdade

A formulação por máxima verossimilhança permite comparar o modelo fatorial com o modelo normal de covariâncias sem restrições estruturais.

Uma matriz simétrica $p \times p$ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

Em um ponto regular do modelo fatorial ortogonal exploratório com m fatores, após considerar a indeterminação rotacional conforme Equação 15.14, a dimensão da estrutura de covariâncias modelada é

$$pm + p - \frac{m(m-1)}{2}.$$

Assim, o número de restrições independentes impostas à matriz de covariâncias é

$$\nu_{\text{fat}} = \frac{p(p+1)}{2} - pm - p + \frac{m(m-1)}{2}. \quad (15.31)$$

Essa quantidade fornece os graus de liberdade usuais do teste de ajuste quando o modelo está identificado e as condições regulares necessárias são satisfeitas.

Quando

$$\mathbf{S}_{\text{MV}} \succ \mathbf{0},$$

o modelo normal irrestrito possui estimativa de máxima verossimilhança

$$\hat{\Sigma}_{\text{sat}} = \mathbf{S}_{\text{MV}}.$$

Se

$$\hat{\theta}_{\text{MV}}$$

é a estimativa sob o modelo fatorial, a estatística da razão de verossimilhanças pode ser escrita como

$$-2 \log \Lambda_{\text{RV}} = n F_{\text{ML}}(\hat{\theta}_{\text{MV}}). \quad (15.32)$$

O resultado assintótico de Wilks foi estabelecido no Teorema 12.4. Aplicado a uma parametrização identificada do modelo fatorial, ele exige as condições regulares correspondentes, incluindo solução populacional interior, diferenciabilidade apropriada, identificabilidade e informação de Fisher não singular para os parâmetros livres.

Sob essas condições e mantendo p e m fixos enquanto

$$n \rightarrow \infty,$$

se o modelo fatorial está corretamente especificado,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi^2_{\nu_{\text{fat}}}. \quad (15.33)$$

A distribuição qui-quadrado é, portanto, um **resultado assintótico**, e não uma distribuição exata em amostras finitas.

Esse resultado também esclarece por que identificação e interioridade não são detalhes apenas algébricos. Elas participam das condições necessárias para que a aproximação assintótica regular possa ser utilizada.

O número de fatores modifica diretamente a classe de matrizes representáveis. Aumentar m amplia essa classe e reduz

$$\nu_{\text{fat}}.$$

A determinação prática do número de fatores envolve critérios adicionais e será tratada na etapa aplicada. Neste capítulo, m é considerado parte da especificação do modelo.

15.21 Soluções admissíveis e casos de fronteira

As variâncias específicas pertencem ao espaço paramétrico somente quando

$$\psi_i \geq 0, \quad i = 1, \dots, p.$$

Uma solução com

$$\psi_i < 0$$

é uma solução imprópria, pois atribui valor negativo a uma quantidade definida como variância.

Como

$$\sigma_{ii} = h_i^2 + \psi_i,$$

uma especificidade negativa corresponderia a

$$h_i^2 > \sigma_{ii}.$$

Para variáveis padronizadas,

$$\sigma_{ii} = 1,$$

e, portanto,

$$h_i^2 > 1.$$

Problemas envolvendo estimativas de especificidades na fronteira ou fora do espaço admissível são tradicionalmente associados aos chamados **casos de Heywood** na literatura de Análise Fatorial (Lawley; Maxwell, 1971).

Também podem ocorrer soluções na fronteira com

$$\psi_i = 0.$$

Nesse caso,

$$h_i^2 = \sigma_{ii},$$

e toda a variância da variável é atribuída à parcela comum do modelo.

Para uma variável padronizada,

$$h_i^2 = 1.$$

Fronteira do espaço paramétrico

Uma solução com variância específica nula pertence à fronteira do espaço paramétrico. Resultados inferenciais assintóticos obtidos sob hipóteses de solução interior, como a aplicação regular de Wilks na Equação 15.33, não podem ser transferidos automaticamente para essa situação.

Esses casos mostram que a existência de uma solução numérica não garante, por si só, uma solução admissível nem o atendimento às condições regulares utilizadas pela teoria inferencial.

15.22 Escores fatoriais

Os fatores comuns aparecem no modelo como variáveis aleatórias latentes:

F.

Eles não são componentes observadas da matriz de dados e não são obtidos diretamente por uma transformação determinística das variáveis observadas, como ocorre com os escores da ACP.

Essa diferença produz o **problema dos escores fatoriais**.

Considere uma observação

$$\mathbf{x} \in \mathbb{R}^p.$$

Depois que os parâmetros do modelo são conhecidos ou estimados, pode-se procurar uma representação da posição dessa observação em relação aos fatores latentes. Essa representação é denominada **escore fatorial**.

Definição 15.9 (Escore fatorial). Um **escore fatorial** é uma estimativa ou predição do valor dos fatores latentes associado a uma observação, obtida a partir das variáveis observadas e de um modelo fatorial especificado ou ajustado.

A Tabela 15.3 sintetiza as funções distintas desempenhadas pelos fatores, pelas cargas e pelos escores fatoriais.

Tabela 15.3: Distinção entre fatores, cargas e escores fatoriais.

Objeto	Natureza
$\mathbf{F}$	Vetor aleatório latente especificado pelo modelo
$\mathbf{L}$	Matriz de parâmetros que relaciona fatores e variáveis
$\mathbf{f}_i$	Realização latente dos fatores associada à unidade i , não diretamente observada
$\hat{\mathbf{f}}_i$	Escore utilizado para estimar ou prever $\mathbf{f}_i$

Essa distinção é importante. As cargas fatoriais são parâmetros da estrutura de covariâncias, enquanto os escores são quantidades associadas às unidades observacionais.

A formulação normal permite compreender probabilisticamente por que a obtenção dos escores é um problema de predição.

15.23 Distribuição condicional dos fatores

Considere o modelo fatorial normal ortogonal na Definição 15.8 e suponha, adicionalmente, que

$$\Sigma \succ \mathbf{0}.$$

Tem-se

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m)$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi.$$

Além disso,

$$\begin{aligned}\text{Cov}(\mathbf{F}, \mathbf{X}) &= \text{Cov}[\mathbf{F}, \mathbf{L}\mathbf{F} + \varepsilon] \\ &= \text{Cov}(\mathbf{F}) \mathbf{L}^\top \\ &= \mathbf{L}^\top.\end{aligned}$$

Portanto, o vetor conjunto

$$\begin{pmatrix} \mathbf{F} \\ \mathbf{X} \end{pmatrix}$$

possui distribuição normal com vetor de médias

$$\begin{pmatrix} \mathbf{0} \\ \mu \end{pmatrix}$$

e matriz de covariâncias

$$\begin{pmatrix} \mathbf{I}_m & \mathbf{L}^\top \\ \mathbf{L} & \Sigma \end{pmatrix}. \quad (15.34)$$

Como

$$\Sigma \succ \mathbf{0},$$

o resultado de distribuição condicional normal da Proposição 9.7 pode ser aplicado. Assim,

$$\mathbf{F} \mid (\mathbf{X} = \mathbf{x}) \sim N_m \left[\mathbf{L}^\top \Sigma^{-1} (\mathbf{x} - \mu), \mathbf{I}_m - \mathbf{L}^\top \Sigma^{-1} \mathbf{L} \right]. \quad (15.35)$$

Consequentemente,

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \mathbf{L}^\top \Sigma^{-1} (\mathbf{x} - \mu), \quad (15.36)$$

e

$$\text{Cov}(\mathbf{F} \mid \mathbf{X}) = \mathbf{I}_m - \mathbf{L}^\top \Sigma^{-1} \mathbf{L}. \quad (15.37)$$

A média condicional fornece uma predição natural dos fatores sob o modelo normal:

$$\hat{\mathbf{f}} = \mathbf{L}^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}). \quad (15.38)$$

Quando os parâmetros são desconhecidos, uma versão amostral pode ser obtida substituindo-os por estimativas compatíveis com o modelo ajustado.

A expressão evidencia uma diferença importante em relação à ACP. Depois que as direções principais são determinadas, o escore de uma componente é uma coordenada calculada diretamente pela projeção da observação. No modelo fatorial, o fator permanece latente mesmo quando

$$\mathbf{X} = \mathbf{x}$$

é conhecido.

Quando

$$\text{Cov}(\mathbf{F} \mid \mathbf{X}) \neq \mathbf{0},$$

a observação das variáveis não determina exatamente o valor dos fatores. Permanece variabilidade condicional sobre o vetor latente.

Essa é uma manifestação probabilística da **indeterminação dos escores fatoriais**. Além disso, mesmo para uma mesma solução fatorial, diferentes critérios de predição ou estimação podem produzir escores distintos.

A média condicional utilizada acima corresponde a um critério específico sob o modelo normal. Outros métodos de obtenção de escores, incluindo critérios baseados em regressão ou mínimos quadrados, serão tratados na etapa aplicada.

15.24 Pressupostos e limites do modelo

Os pressupostos da Análise Fatorial exercem funções diferentes. Alguns pertencem à própria especificação do modelo de fatores comuns. Outros são necessários apenas para determinados métodos de estimação ou resultados inferenciais.

A Tabela 15.4 organiza essas distinções.

Tabela 15.4: Pressupostos e limites da formulação fatorial.

Aspecto	Papel na formulação
Linearidade	As variáveis observadas são representadas linearmente pelos fatores e pelos fatores específicos
Estrutura comum de baixa dimensão	A parcela comum da matriz de covariâncias deve ser compatível com um número reduzido de fatores
Diagonalidade de Ψ	No modelo básico, os fatores específicos de variáveis distintas possuem covariância nula
Não correlação entre fatores e fatores específicos	Separa, em termos de covariância, as parcelas comum e específica
Identificação	A parametrização deve permitir determinar as características do modelo que constituem o objeto de interesse
Admissibilidade	As variâncias específicas devem ser não negativas e a matriz reproduzida deve ser uma matriz de covariâncias válida
Normalidade	Não é necessária para o modelo de segunda ordem; integra o modelo fatorial normal e sustenta a verossimilhança normal e resultados inferenciais correspondentes
Número de fatores	Determina a dimensão da estrutura comum e a classe de matrizes de covariâncias representáveis
Conjunto e escala das variáveis	Alterações nas variáveis ou em suas escalas modificam a estrutura de covariâncias ou correlações modelada

15.24.1 Linearidade e estrutura de segunda ordem

O modelo básico especifica

$$\mathbf{X} - \mu = \mathbf{L}\mathbf{F} + \varepsilon.$$

Consequentemente, a formulação desenvolvida neste capítulo descreve uma estrutura linear baseada em momentos de segunda ordem.

Associações entre as variáveis que não sejam adequadamente representadas por covariâncias podem não ser capturadas por um modelo fatorial linear simples.

A formulação básica também não implica, por si só, que os fatores expliquem toda forma de dependência probabilística entre as variáveis. O objeto diretamente modelado é sua estrutura de covariâncias.

15.24.2 Diagonalidade da estrutura específica

A condição

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

é um pressuposto definidor do modelo de fatores comuns básico.

Ela implica

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j.$$

Portanto, no modelo básico, as covariâncias entre variáveis distintas devem ser reproduzidas pela parcela comum.

Se permanecer as covariâncias sistemáticas entre fatores específicos de variáveis diferentes, a estrutura

$$\mathbf{LL}^\top + \Psi$$

no modelo ortogonal pode ser insuficiente para representar a matriz de covariâncias.

A diagonalidade de Ψ estabelece covariâncias nulas entre fatores específicos distintos. Ela não implica independência em uma formulação probabilística geral. No modelo fatorial normal na Definição 15.8, a normalidade conjunta permite fortalecer essa conclusão para independência.

15.24.3 Número de fatores

Para valores pequenos de m , o modelo impõe uma estrutura mais restritiva à matriz de covariâncias. À medida que m aumenta, cresce a flexibilidade da parcela comum.

Um número insuficiente de fatores pode deixar covariâncias sistemáticas sem representação. Um número excessivo pode reduzir a utilidade da representação latente, aumentar a complexidade da parametrização e agravar problemas de identificação ou estabilidade.

O número de fatores faz parte da especificação do problema. Os critérios operacionais para sua escolha não pertencem à formulação desenvolvida neste capítulo e serão tratados posteriormente.

15.24.4 Dependência do conjunto e da escala das variáveis

Os fatores são definidos em relação ao conjunto de variáveis incluído no modelo.

Adicionar, retirar ou transformar variáveis modifica

$$\Sigma$$

ou

$$\mathcal{R}$$

e pode modificar a estrutura fatorial obtida.

Mudanças individuais de escala também modificam a matriz de covariâncias e, portanto, podem alterar uma análise baseada em

$$\Sigma.$$

A utilização de uma matriz de correlações remove as diferenças de escala marginal antes do ajuste, mas define outro problema estatístico, assim como ocorreu na ACP.

Os fatores não devem, portanto, ser interpretados como objetos independentes do conjunto de variáveis e da forma como sua estrutura de segunda ordem foi definida.

15.24.5 Papel da normalidade

A decomposição

$$\Sigma = \mathbf{LL}^\top + \Psi$$

não exige normalidade multivariada. Ela decorre das hipóteses sobre médias e covariâncias do modelo de fatores comuns.

A normalidade é introduzida na Definição 15.8 para especificar uma distribuição conjunta para fatores, fatores específicos e variáveis observadas. Essa hipótese sustenta a formulação da verossimilhança normal, a inferência correspondente e a distribuição condicional dos fatores.

A estrutura de segunda ordem

$$\Sigma = \mathbf{LL}^\top + \Psi$$

não depende dessa hipótese. A normalidade pertence à formulação probabilística específica, e não à definição geral do modelo de fatores comuns.

15.25 Análise Fatorial e Análise de Componentes Principais

A Análise de Componentes Principais e a Análise Fatorial utilizam matrizes de covariâncias ou correlações, mas resolvem problemas estatísticos distintos. Essa diferença pode agora ser formulada matematicamente com maior precisão.

Na ACP,

$$\Sigma = \mathbf{A}\mathbf{A}^\top,$$

em que

$$= \text{diag}(\lambda_1, \dots, \lambda_p).$$

Os autovetores definem as direções principais e os autovalores representam as variâncias das componentes.

No modelo fatorial ortogonal,

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi.$$

A matriz $\mathbf{L}$ contém cargas fatoriais e, em geral, suas colunas não são autovetores de Σ .

A Tabela 15.5 reúne as diferenças estruturais.

Tabela 15.5: Diferenças matemáticas e estatísticas entre ACP e Análise Fatorial.

Aspecto	ACP	Análise Fatorial
Problema	Representar a variabilidade em poucas direções	Representar as covariâncias por fatores latentes
Objeto populacional	Σ ou $\mathcal{R}$	Σ ou $\mathcal{R}$
Estrutura matemática	Decomposição espectral	Modelo de covariâncias
Formulação ortogonal	$\Sigma = \mathbf{A}\mathbf{A}^\top$	$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi$
Variabilidade considerada	Variância total	Variância comum separada da específica
Dimensões de menor ordem	Combinações lineares determinadas pelas variáveis observadas	Variáveis latentes especificadas pelo modelo

Aspecto	ACP	Análise Fatorial
Diagonal da matriz analisada	Participa integralmente da decomposição	É decomposta entre comunalidade e especificidade
Coeficientes principais	Autovetores	Cargas fatoriais
Não unicidade	Autovetores associados a autovalores simples são determinados até sinal; multiplicidades identificam subespaços	Após fixada a escala dos fatores, permanecem indeterminações de sinal e rotação
Escores	Coordenadas calculadas pela projeção das observações	Estimativas ou predições de valores latentes, dependentes do critério adotado
Normalidade	Não necessária para definir a técnica	Não necessária para o modelo de segunda ordem; integra a formulação normal e a inferência correspondente

Uma decomposição espectral truncada de Σ não resolve, em geral, o problema fatorial.

Na ACP,

$$\Sigma_k = \mathbf{A}_k \mathbf{D}_k \mathbf{A}_k^\top,$$

em que

$$\mathbf{D}_k = \text{diag}(\lambda_1, \dots, \lambda_k),$$

é uma aproximação de posto reduzido da matriz de covariâncias inteira.

Na Análise Fatorial, o modelo populacional postula

$$\Sigma = \mathbf{L}\mathbf{L}^\top + \Psi$$

no caso ortogonal.

Somente a parcela

$$\mathbf{L}\mathbf{L}^\top$$

possui posto limitado pelo número de fatores. A matriz diagonal

$$\Psi$$

permanece explicitamente no modelo e representa variabilidade específica.

No ajuste amostral, procura-se então uma estrutura dessa forma que reproduza adequadamente

$$\mathbf{S}$$

ou

$$\mathbf{R},$$

segundo o método de estimação escolhido.

Portanto, utilizar uma ACP com o mesmo número de dimensões não equivale a estimar um modelo de fatores comuns. As duas técnicas podem produzir representações de menor dimensão, mas resolvem problemas estatísticos diferentes.

A formulação deste capítulo corresponde à Análise Fatorial Exploratória, na qual a estrutura de cargas apresenta indeterminação rotacional. Modelos fatoriais confirmatórios e modelos de equações estruturais acrescentam restrições previamente especificadas e problemas próprios de identificação e estimação. Essas extensões não serão desenvolvidas aqui.

15.26 Síntese

A Análise Fatorial representa a estrutura de covariâncias entre variáveis observadas por meio de fatores comuns e fatores específicos. No modelo ortogonal,

$$\mathbf{X} = \mu + \mathbf{LF} + \varepsilon,$$

com

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m, \quad \text{Cov}(\varepsilon) = \Psi, \quad \text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0},$$

o que conduz a

$$\Sigma = \mathbf{LL}^\top + \Psi.$$

A parcela

$$\mathbf{L}\mathbf{L}^\top$$

representa a covariância comum e possui posto não superior ao número de fatores. A matriz diagonal Ψ reúne as variâncias específicas.

Para cada variável, a variância é decomposta entre comunalidade e especificidade. No modelo ortogonal padronizado,

$$h_i^2 = \sum_{j=1}^m l_{ij}^2,$$

e os produtos internos entre os vetores de cargas reproduzem as covariâncias comuns.

A escala dos fatores precisa ser fixada para definir as cargas, e a solução permanece sujeita a indeterminações de sinal e rotação. As rotações ortogonais preservam fatores não correlacionados; as oblíquas permitem

$$\Phi \neq \mathbf{I}_m$$

e conduzem à estrutura

$$\Sigma = \mathbf{L}\Phi\mathbf{L}^\top + \Psi.$$

Nesse caso, matriz de padrões, matriz de estrutura e matriz de correlações fatoriais representam objetos distintos.

No nível amostral, diferentes critérios podem ser utilizados para estimar uma estrutura fatorial compatível com a matriz de covariâncias ou correlações observada. Fatores principais e mínimos quadrados formulam o problema a partir da reprodução da estrutura de segunda ordem. Sob normalidade multivariada, a máxima verossimilhança acrescenta uma formulação probabilística e inferencial.

Os fatores são variáveis latentes. Os escores fatoriais são estimativas ou predições de suas posições e dependem do critério utilizado; não correspondem a coordenadas observadas diretamente.

A diferença em relação à ACP decorre do problema formulado. A ACP decompõe a variabilidade total em direções principais. A Análise Fatorial modela a matriz de covariâncias separando variabilidade comum e específica por meio de variáveis latentes.

O capítulo integra transformações lineares, posto, matrizes de covariâncias, identificação, normal multivariada, estimação e distribuições condicionais na formulação de um modelo de estrutura latente.

No próximo capítulo, o objeto deixa de ser a covariância entre variáveis. A Análise de Agrupamentos organizará observações em grupos a partir de medidas de proximidade e critérios de homogeneidade, sem classes previamente conhecidas.

16 Formulação da Análise de Agrupamentos

A Análise de Agrupamentos organiza objetos em grupos a partir de uma representação dos dados, de uma medida de proximidade e de um critério que define a organização procurada (Everitt et al., 2011; Johnson; Wichern, 2007).

Sua formulação reutiliza os fundamentos do Módulo 1 sobre matrizes de dados, distâncias, normas e geometrias induzidas e a decomposição da dispersão desenvolvida no Módulo 2. Esses objetos serão utilizados para formular partições, hierarquias e diferentes definições matemáticas de grupo.

Os elementos que definem o problema são organizados na Tabela 16.1.

Tabela 16.1: Elementos que definem um problema de Análise de Agrupamentos.

Elemento	Objeto	Papel na análise
Representação dos objetos	matriz de dados $\mathbf{X}$ ou matriz de dissimilaridades Δ	determina a informação disponível para comparar os objetos
Proximidade	distância, dissimilaridade ou similaridade	estabelece o significado de objetos próximos
Organização	partição $\mathcal{P}$ ou estrutura hierárquica	representa os grupos construídos
Critério	função de perda, dispersão ou ligação	permite comparar diferentes organizações
Solução	grupos de objetos	resulta da otimização ou da regra de construção adotada

A mesma coleção de observações pode produzir agrupamentos diferentes quando um desses elementos é alterado. Por isso, a Análise de Agrupamentos não possui uma definição universal de grupo independente da representação, da proximidade e do critério utilizado.

16.1 O problema de formação de grupos

Considere n objetos representados pelas linhas da matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

conforme Definição 1.6.

Os grupos não são conhecidos previamente. O objetivo é construir uma organização dos índices das observações de modo que objetos pertencentes ao mesmo grupo apresentem maior proximidade segundo o critério adotado, enquanto objetos atribuídos a grupos diferentes apresentem maior separação.

Essa formulação distingue a Análise de Agrupamentos da Análise Discriminante, que utilizará grupos previamente conhecidos. Aqui, a própria organização dos objetos faz parte da solução.

A Figura 16.1 mostra uma mesma configuração bidimensional organizada de duas formas. A figura ilustra que os pontos observados, isoladamente, não determinam qual partição deve ser escolhida.




Figura 16.1: Diferentes partições de uma mesma configuração de observações.

As duas organizações mantêm os mesmos pontos e alteram somente a regra utilizada para reuni-los. A figura representa uma característica da técnica: a estrutura de grupos deve ser interpretada em relação ao critério que a produziu.

16.2 Representação dos objetos e proximidade

A matriz de dados não é a única forma de entrada da Análise de Agrupamentos. Quando as coordenadas dos objetos estão disponíveis, a proximidade pode ser calculada a partir das linhas de $\mathbf{X}$. Quando as relações entre os objetos já são fornecidas diretamente, a análise pode partir de uma matriz de dissimilaridades.

A distância euclidiana já foi definida em Definição 1.13. Para duas observações $\mathbf{x}_i$ e $\mathbf{x}_j$, utilizaremos diretamente

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Não é necessário reconstruir suas propriedades métricas neste capítulo. O resultado será aplicado para definir a geometria de métodos como as K -médias e o método de Ward.

O Módulo 1 também estabeleceu em Definição 3.17 que uma matriz positiva definida pode modificar a geometria utilizada para medir comprimentos e distâncias. Assim, diferentes escolhas de métrica podem atribuir diferentes proximidades ao mesmo conjunto de observações. A distância de Mahalanobis constitui uma aplicação estatística dessa estrutura e já foi definida em Definição 8.9.

A Análise de Agrupamentos também pode receber como entrada uma matriz

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

na qual δ_{ij} representa a dissimilaridade entre os objetos i e j .

16.3 Dissimilaridades entre objetos

Definição 16.1 (Dissimilaridade). Seja

$$\mathcal{J} = \{1, \dots, n\}$$

um conjunto de objetos. Uma **dissimilaridade** é uma função

$$\delta : \mathcal{J} \times \mathcal{J} \longrightarrow [0, \infty),$$

na qual valores maiores representam menor proximidade entre os objetos.

Neste capítulo, serão consideradas dissimilaridades que satisfazem

$$\delta(i, i) = 0, \quad i \in \mathcal{I},$$

e

$$\delta(i, j) = \delta(j, i), \quad i, j \in \mathcal{I}.$$

Não será exigido que

$$\delta(i, j) > 0 \quad \text{para} \quad i \neq j,$$

nem que seja satisfeita a desigualdade triangular.

A matriz associada a δ é

$$\Delta = (\delta_{ij}), \quad \delta_{ij} = \delta(i, j).$$

Assim, uma distância métrica pode ser utilizada como dissimilaridade, mas uma dissimilaridade não precisa satisfazer todas as propriedades exigidas de uma distância métrica (Everitt et al., 2011).

A possibilidade de

$$\delta(i, j) = 0$$

para objetos distintos será particularmente relevante quando forem estudadas dissimilaridades produzidas por estruturas hierárquicas.

De forma correspondente, uma similaridade atribui valores maiores a objetos considerados mais semelhantes. A transformação entre similaridade e dissimilaridade depende da medida adotada e não constitui uma operação universal.

A distinção entre matriz de atributos e matriz de dissimilaridades é sintetizada na Tabela 16.2.

Tabela 16.2: Formas de representação utilizadas na Análise de Agrupamentos.

Representação	Informação disponível	Consequência para a formulação
$\mathbf{X} \in \mathbb{R}^{n \times p}$	valores das p variáveis para cada objeto	a proximidade é construída a partir das coordenadas

Representação	Informação disponível	Consequência para a formulação
$\Delta \in \mathbb{R}^{n \times n}$	dissimilaridades entre pares de objetos	o agrupamento pode ser formulado diretamente sobre as relações entre objetos

A escolha entre essas representações também delimita os métodos disponíveis. O critério das K -médiãs, por exemplo, utiliza explicitamente centroides no espaço das variáveis e requer as coordenadas das observações. Métodos hierárquicos podem ser formulados diretamente a partir de uma matriz de dissimilaridades, desde que a regra de ligação seja compatível com a informação disponível.

16.3.1 Efeito da escala

A dependência das distâncias em relação à escala já foi discutida no Módulo 1, e a padronização das variáveis foi formalizada no Módulo 2. A matriz de dados padronizados observada está dada em Equação 8.69. Neste capítulo, esses resultados têm uma consequência específica: modificar a escala modifica as proximidades utilizadas para construir os grupos.

A Figura 16.2 mostra essa consequência para uma configuração bidimensional. A figura não redefine a padronização; ela mostra seu efeito sobre o problema de agrupamento.




Figura 16.2: Mudanças de escala alteram a geometria utilizada para comparar as observações.

A ampliação da segunda coordenada aumenta sua contribuição para as distâncias. Um método baseado nessas distâncias passa a comparar os mesmos objetos segundo outra geometria.

A padronização deve ser entendida da mesma forma. Ela não constitui uma exigência geral da Análise de Agrupamentos. Sua utilização altera a contribuição relativa das variáveis e, portanto, altera o problema geométrico resolvido pelo método.

16.4 Partições

Uma das formas mais comuns de representar um agrupamento é por meio de uma partição rígida do conjunto de objetos.

Seja

$$\mathcal{I} = \{1, \dots, n\}$$

o conjunto dos índices das observações.

Definição 16.2 (Partição em grupos). Uma **partição em K grupos** é uma coleção

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

de subconjuntos não vazios de $\mathcal{I}$ que satisfaz

$$C_k \cap C_\ell = \emptyset, \quad k \neq \ell,$$

e

$$\bigcup_{k=1}^K C_k = \mathcal{I}.$$

As duas condições estabelecem que:

- um objeto não pertence simultaneamente a dois grupos distintos;
- todos os objetos são atribuídos a algum grupo.

O número de elementos do grupo C_k será denotado por

$$n_k = |C_k|,$$

com

$$\sum_{k=1}^K n_k = n.$$

A partição é um objeto combinatório. Ela informa quais observações pertencem ao mesmo grupo, mas não determina sozinha o critério utilizado para obtê-la.

Uma representação equivalente pode ser construída por indicadores de pertinência,

$$g_{ik} = \begin{cases} 1, & i \in C_k, \\ 0, & i \notin C_k. \end{cases}$$

Para uma partição rígida,

$$\sum_{k=1}^K g_{ik} = 1, \quad i = 1, \dots, n. \quad (16.1)$$

16.4.1 Partições rígidas, difusas e probabilísticas

A partição rígida não é a única forma possível de representar agrupamentos.

Em uma estrutura **difusa**, pode-se associar a cada objeto um grau de pertencimento

$$u_{ik} \in [0, 1],$$

geralmente sujeito a

$$\sum_{k=1}^K u_{ik} = 1.$$

Em uma estrutura **probabilística**, podem ser atribuídas probabilidades

$$P(G_i = k \mid \mathbf{x}_i)$$

às diferentes possibilidades de pertencimento.

Essas representações não são equivalentes à partição rígida. Elas correspondem a diferentes definições matemáticas da associação entre um objeto e um grupo.

O desenvolvimento principal deste capítulo utilizará partições rígidas porque elas permitem formular diretamente os critérios geométricos de K -médias e dos métodos hierárquicos. As formulações probabilísticas serão retomadas posteriormente para mostrar outra interpretação possível de grupo.

16.5 Homogeneidade interna e separação

Uma partição só se torna uma solução de agrupamento depois que se estabelece um critério para comparar diferentes partições.

Considere

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um critério baseado em homogeneidade interna deve assumir valores melhores quando objetos pertencentes ao mesmo grupo apresentam pequena dispersão segundo a geometria escolhida.

Um critério baseado em separação deve favorecer grupos suficientemente distintos entre si.

Essas duas propriedades são relacionadas, mas não são equivalentes em qualquer método. A forma exata de medi-las depende da definição matemática de grupo adotada.

Para agrupamentos representados por centroides e distância euclidiana quadrática, a homogeneidade interna pode ser expressa por somas de quadrados. Essa escolha conduz ao critério das K -médias e permite utilizar diretamente a decomposição da dispersão estabelecida no Módulo 2.

A caracterização da média como centroide e como minimizadora da soma das distâncias euclidianas quadráticas já foi estabelecida em Proposição 10.5. Essa propriedade será aplicada a cada grupo da partição.

16.6 Agrupamento por centroides

Uma partição pode ser representada geometricamente por um ponto que resume cada grupo. Para

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

com

$$n_k = |C_k|,$$

o **centroide** do grupo C_k será denotado por

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i. \quad (16.2)$$

A notação $\mathbf{c}_k$ distingue o centro calculado a partir das observações de um vetor de médias populacional μ_k , que será utilizado posteriormente em técnicas formuladas a partir de populações ou grupos previamente definidos.

No agrupamento por centroides, a proximidade entre uma observação e um grupo é determinada por sua distância ao centro correspondente. Essa representação conduz naturalmente a critérios baseados na dispersão das observações em torno dos centroides.

16.6.1 Dispersão dentro e entre grupos

A decomposição da dispersão para grupos já foi estabelecida no Módulo 2. A matriz de dispersão intragrupos foi definida em Definição 8.14, a matriz entre grupos em Definição 8.15, e Proposição 8.10 demonstrou que

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Naquele resultado, os grupos eram considerados conhecidos. Na Análise de Agrupamentos, a mesma decomposição adquire outra função: a partição passa a ser desconhecida e deve ser construída.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

a matriz intragrupos pode ser escrita, utilizando os centroides de Equação 16.2, como

$$\mathbf{T}_{\text{intra}}(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} (\mathbf{x}_i - \mathbf{c}_k) (\mathbf{x}_i - \mathbf{c}_k)^\top. \quad (16.3)$$

Tomando o traço,

$$\begin{aligned}
\text{tr} [\mathbf{T}_{\text{intra}}(\mathcal{P})] &= \sum_{k=1}^K \sum_{i \in C_k} \text{tr} [(\mathbf{x}_i - \mathbf{c}_k)(\mathbf{x}_i - \mathbf{c}_k)^\top] \\
&= \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2.
\end{aligned} \tag{16.4}$$

A expressão em Equação 16.4 transforma a matriz de dispersão do Módulo 2 em um critério escalar para comparar partições.

Quanto menores forem as distâncias quadráticas das observações aos centroides de seus grupos, menor será

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Como a matriz total $\mathbf{T}$ não depende da partição e

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue também que

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \tag{16.5}$$

Para K fixado, reduzir a dispersão intragrupos aumenta a parcela da dispersão atribuída aos centroides dos grupos em relação ao centroide global. Essa relação fornece a formulação utilizada pelas K -médias.

16.6.2 Formulação das K -médias

O método das K -médias define os grupos pela minimização da soma das distâncias euclidianas quadráticas das observações aos centroides correspondentes (Everitt et al., 2011; Johnson; Wichern, 2007; MacQueen, 1967).

Definição 16.3 (Critério das K -médias). Para um número fixado de grupos K , com

$$1 \leq K \leq n,$$

considere os indicadores de pertinência g_{ik} e os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p.$$

O critério conjunto das K -médias é

$$Q_K(\{g_{ik}\}, \mathbf{c}_1, \dots, \mathbf{c}_K) = \sum_{i=1}^n \sum_{k=1}^K g_{ik} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.6)$$

sujeito a

$$g_{ik} \in \{0, 1\},$$

$$\sum_{k=1}^K g_{ik} = 1, \quad i = 1, \dots, n,$$

e

$$\sum_{i=1}^n g_{ik} \geq 1, \quad k = 1, \dots, K.$$

As duas primeiras restrições estabelecem uma atribuição rígida: g_{ik} é binário e cada observação pertence a exatamente um dos K grupos. A terceira restrição garante que todos os K grupos sejam não vazios.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

o critério após a minimização em relação aos centros é

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.7)$$

em que

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i.$$

A propriedade de que esses centroides minimizam o critério para uma partição fixada decorre de Proposição 10.5. Sua aplicação à notação dos grupos utilizada neste capítulo é registrada em Proposição 16.1.

A solução global pode ser representada por

$$\mathcal{P}^* \in \arg \min_{\mathcal{P}} J_K(\mathcal{P}), \quad (16.8)$$

em que a minimização é realizada sobre as partições admissíveis de $\{1, \dots, n\}$ em K grupos não vazios.

Pela relação em Equação 16.4,

$$J_K(\mathcal{P}) = \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})]. \quad (16.9)$$

Assim, as K -médias utilizam diretamente a estrutura de dispersão introduzida no Módulo 2. A diferença está no papel dos grupos: naquele módulo, a partição era dada; aqui, ela é parte do problema de otimização.

A partir de Equação 16.5,

$$J_K(\mathcal{P}) = \text{tr}(\mathbf{T}) - \text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})].$$

Como

$$\text{tr}(\mathbf{T})$$

é constante para a mesma matriz de dados, minimizar o critério das K -médias equivale a maximizar

$$\text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})]. \quad (16.10)$$

Como a dispersão entre grupos pode ser escrita em função dos centroides e de seus tamanhos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\mathbf{c}_k - \bar{\mathbf{x}}) (\mathbf{c}_k - \bar{\mathbf{x}})^\top,$$

tem-se

$$\text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\mathbf{c}_k - \bar{\mathbf{x}}\|^2. \quad (16.11)$$

As duas formulações descrevem, portanto, o mesmo problema para K fixado: minimizar a dispersão quadrática das observações em torno dos centroides equivale a maximizar a dispersão ponderada dos centroides dos grupos em torno do centroide global.

16.6.3 O centroide como minimizador

A caracterização geral da média amostral como centroide foi estabelecida em Proposição 10.5. A identidade de decomposição correspondente foi obtida em Equação 10.52.

Aplicando esses resultados às observações pertencentes a um grupo não vazio C , obtém-se diretamente a propriedade utilizada nas K -médias.

Proposição 16.1 (Centroide e soma de quadrados). *Considere um grupo não vazio C com*

$$n_C = |C|$$

observações e centroide

$$\mathbf{c}_C = \frac{1}{n_C} \sum_{i \in C} \mathbf{x}_i.$$

Aplicando Equação 10.52 às observações do grupo C , para qualquer

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\sum_{i \in C} \|\mathbf{x}_i - \mathbf{c}\|^2 = \sum_{i \in C} \|\mathbf{x}_i - \mathbf{c}_C\|^2 + n_C \|\mathbf{c} - \mathbf{c}_C\|^2. \quad (16.12)$$

Consequentemente,

$$\arg \min_{\mathbf{c} \in \mathbb{R}^p} \sum_{i \in C} \|\mathbf{x}_i - \mathbf{c}\|^2 = \{\mathbf{c}_C\}.$$

A proposição é, portanto, a aplicação de Proposição 10.5 a cada subconjunto de observações definido pela partição.

O uso da média como representante do grupo decorre da distância euclidiana quadrática adotada pelo critério. Outras funções de perda podem produzir representantes diferentes.

16.6.4 Partição para centroides fixados

Considere agora os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K$$

como fixados.

Se for considerada somente a restrição de que cada observação pertença a exatamente um grupo, a contribuição de $\mathbf{x}_i$ ao critério é minimizada atribuindo-a a qualquer centro pertencente a

$$\arg \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.13)$$

Assim, a minimização ponto a ponto é obtida pela atribuição ao centroide mais próximo. Em caso de empate, mais de uma atribuição pode produzir a mesma contribuição mínima.

Há, entretanto, uma distinção entre essa regra ponto a ponto e o problema conjunto de Definição 16.3. Nesse problema, também é exigido que todos os K grupos sejam não vazios.

Se a regra de Equação 16.13 produzir pelo menos uma observação associada a cada centroide, a atribuição obtida é também solução do subproblema com centroides fixados sujeito às restrições completas de Definição 16.3.

Se algum centroide não receber observações, a restrição

$$\sum_{i=1}^n g_{ik} \geq 1$$

impede que o problema admissível seja resolvido exclusivamente por minimizações independentes para cada observação. Nesse caso, a exigência de não vacuidade deve ser considerada conjuntamente na atribuição.

Os dois resultados anteriores são sintetizados na Tabela 16.3.

Tabela 16.3: Estrutura do critério das K -médias quando se fixa uma das partes do problema.

Elemento fixado	Consequência do critério
Partição $\mathcal{P}$	cada centro ótimo é o centroide das observações do grupo

Elemento fixado	Consequência do critério
Centroides $\mathbf{c}_1, \dots, \mathbf{c}_K$	a regra ponto a ponto atribui cada observação a um centroide de menor distância; ela resolve também o problema com grupos não vazios quando essa atribuição é admissível

Essa estrutura está na base dos procedimentos iterativos utilizados para calcular soluções das K -médias. Os algoritmos, as estratégias de inicialização, o tratamento computacional de grupos vazios e os critérios de parada pertencem à implementação da técnica e não serão desenvolvidos neste capítulo.

16.6.5 Geometria das regiões de alocação

Para centroides fixados, a regra em Equação 16.13 divide o espaço em regiões formadas pelos pontos mais próximos de cada centroide.

Para dois centroides $\mathbf{c}_k$ e $\mathbf{c}_\ell$, a fronteira entre suas regiões satisfaz

$$\|\mathbf{x} - \mathbf{c}_k\|^2 = \|\mathbf{x} - \mathbf{c}_\ell\|^2.$$

Expandindo as duas normas,

$$\mathbf{x}^\top \mathbf{x} - 2\mathbf{c}_k^\top \mathbf{x} + \mathbf{c}_k^\top \mathbf{c}_k = \mathbf{x}^\top \mathbf{x} - 2\mathbf{c}_\ell^\top \mathbf{x} + \mathbf{c}_\ell^\top \mathbf{c}_\ell.$$

Os termos

$$\mathbf{x}^\top \mathbf{x}$$

se cancelam, resultando em

$$2(\mathbf{c}_\ell - \mathbf{c}_k)^\top \mathbf{x} = \mathbf{c}_\ell^\top \mathbf{c}_\ell - \mathbf{c}_k^\top \mathbf{c}_k. \quad (16.14)$$

A fronteira é, portanto, um hiperplano.

As regiões definidas simultaneamente por todos os centroides formam uma partição de Voronoi do espaço. Uma região de Voronoi pode não conter nenhuma das observações disponíveis para uma determinada configuração de centros; isso não altera sua definição geométrica.

Essa geometria explica por que as K -médias favorecem grupos associados a regiões convexas em torno de centros.

A Figura 16.3 representa uma solução com três centroides. As regiões de fundo indicam qual centroide é o mais próximo em cada posição do plano, enquanto os símbolos maiores identificam os centroides da solução.




Figura 16.3: Centroides e regiões de alocação definidas pela distância euclidiana.

A figura mostra duas propriedades da formulação. Cada grupo é representado por um centroide, e a alocação é determinada pela geometria euclidiana relativa a esses centros. A forma dos grupos obtidos pelo critério está vinculada a essa representação.

Exemplo 16.1 (Comparação de duas partições). Considere quatro observações unidimensionais,

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 8, \quad x_4 = 9,$$

e duas partições candidatas com

$$K = 2.$$

Na primeira,

$$\mathcal{P}_1 = \{\{1, 2\}, \{3, 4\}\}.$$

Os centroides são

$$c_1 = 1,5$$

e

$$c_2 = 8,5.$$

Logo,

$$\begin{aligned} J_2(\mathcal{P}_1) &= (1 - 1,5)^2 + (2 - 1,5)^2 \\ &\quad + (8 - 8,5)^2 + (9 - 8,5)^2 \\ &= 1. \end{aligned}$$

Considere agora

$$\mathcal{P}_2 = \{\{1, 3\}, \{2, 4\}\}.$$

Os centroides são

$$c_1 = 4,5$$

e

$$c_2 = 5,5.$$

Nesse caso,

$$\begin{aligned} J_2(\mathcal{P}_2) &= (1 - 4,5)^2 + (8 - 4,5)^2 \\ &\quad + (2 - 5,5)^2 + (9 - 5,5)^2 \\ &= 49. \end{aligned}$$

O critério atribui valor menor à primeira partição porque as observações estão muito mais concentradas em torno dos respectivos centroides.

O exemplo também mostra que o método não procura apenas separar pontos distantes. A solução é definida pela soma global das dispersões quadráticas dentro dos grupos.

16.6.6 Existência e não unicidade da solução

Para uma matriz de dados finita e um valor fixado de

$$1 \leq K \leq n,$$

existe pelo menos uma partição que minimiza Equação 16.7.

O número de partições possíveis das n observações em K grupos não vazios é finito. Como

$$J_K(\mathcal{P}) \geq 0$$

para toda partição admissível, o menor valor do critério é atingido por pelo menos uma delas.

A existência de um mínimo global não implica unicidade.

Podem existir duas partições distintas

$$\mathcal{P}_1 \neq \mathcal{P}_2$$

tais que

$$J_K(\mathcal{P}_1) = J_K(\mathcal{P}_2) = \min_{\mathcal{P}} J_K(\mathcal{P}).$$

Também há uma indeterminação de rótulos. As coleções

$$\{C_1, C_2, \dots, C_K\}$$

e

$$\{C_{\pi(1)}, C_{\pi(2)}, \dots, C_{\pi(K)}\},$$

para qualquer permutação π , representam a mesma partição substantiva.

Essa indeterminação é diferente daquela encontrada na Análise Fatorial. Na Análise Fatorial, diferentes orientações podem representar a mesma estrutura de covariâncias. Nas K -médias, os

rótulos dos grupos são arbitrários e podem ainda existir diferentes partições geométricas com o mesmo valor mínimo.

16.6.7 Natureza do problema de otimização

O problema completo das K -médias combina duas escolhas:

- a atribuição de cada observação a um grupo;
- a posição dos centroides.

Para uma partição fixada, Proposição 16.1 fornece diretamente os centroides ótimos.

Para centroides fixados, Equação 16.13 fornece a minimização ponto a ponto do critério. Quando essa atribuição produz todos os grupos não vazios, ela também resolve o subproblema sujeito às restrições completas de Definição 16.3.

O problema conjunto permanece combinatório e não é resolvido globalmente apenas pela alternância dessas duas operações. Procedimentos iterativos podem atingir diferentes soluções conforme sua inicialização.

Essa distinção será importante também na formulação populacional: resultados de consistência para o minimizador global empírico não devem ser interpretados automaticamente como resultados de consistência para qualquer algoritmo utilizado para aproximá-lo.

Estratégias computacionais para inicialização, tratamento de grupos vazios, repetição e comparação de soluções serão tratadas na etapa de implementação.

O valor de K também faz parte da especificação do problema em Equação 16.8. Modificar K altera o conjunto de partições admissíveis e o problema de otimização considerado. Os critérios utilizados para escolher o número de grupos pertencem à condução aplicada da análise e não serão desenvolvidos neste capítulo.

16.6.8 Formulação populacional do critério das K -médias

A formulação das K -médias também pode ser expressa no nível populacional.

Considere um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

satisfazendo

$$E(\|\mathbf{X}\|^2) < \infty, \quad (16.15)$$

e considere K centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p.$$

O risco quadrático de quantização é

$$R_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = E \left[\min_{1 \leq k \leq K} \|\mathbf{X} - \mathbf{c}_k\|^2 \right]. \quad (16.16)$$

A condição em Equação 16.15 garante que esse risco seja finito para qualquer conjunto fixo de centros finitos.

Uma solução populacional, quando o mínimo é atingido, pertence a

$$\arg \min_{\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p} R_K(\mathbf{c}_1, \dots, \mathbf{c}_K).$$

Para uma amostra aleatória multivariada, conforme Definição 10.1, a esperança populacional é substituída por sua média empírica:

$$\widehat{R}_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = \frac{1}{n} \sum_{i=1}^n \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.17)$$

Para centros fixados,

$$n\widehat{R}_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = \sum_{i=1}^n \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2.$$

Para

$$1 \leq K \leq n,$$

minimizando também em relação aos centros e utilizando Proposição 16.1, o valor ótimo empírico coincide com o menor critério obtido entre as partições em K grupos não vazios:

$$\min_{\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p} n\widehat{R}_K(\mathbf{c}_1, \dots, \mathbf{c}_K) = \min_{\mathcal{P}} J_K(\mathcal{P}). \quad (16.18)$$

A formulação populacional esclarece o significado estatístico do critério: a solução amostral procura uma configuração de centros que minimize empiricamente a distância quadrática ao centro mais próximo.

Essa interpretação também delimita o alcance de resultados de consistência. A teoria clássica de consistência das K -médias relaciona minimizadores globais do risco empírico a soluções do problema de quantização populacional, sob condições adicionais sobre a distribuição e sobre a solução (Pollard, 1981).

Esse resultado diz respeito ao problema de otimização estatístico definido pelo critério. Ele não implica que qualquer procedimento iterativo empregado para calcular uma solução alcance necessariamente o minimizador global empírico. Também não demonstra, por si só, a existência de classes naturais independentes da função objetivo adotada.

16.6.9 Efeito de transformações sobre as K -médias

A formulação por distância euclidiana permite recuperar diretamente resultados geométricos do Módulo 1.

Uma translação comum

$$\mathbf{x}_i^* = \mathbf{x}_i + \mathbf{b}$$

também desloca cada centroide:

$$\mathbf{c}_k^* = \mathbf{c}_k + \mathbf{b}.$$

Consequentemente,

$$\|\mathbf{x}_i^* - \mathbf{c}_k^*\|^2 = \|\mathbf{x}_i - \mathbf{c}_k\|^2.$$

O critério das K -médias é, portanto, invariante a uma translação comum das observações.

O mesmo ocorre sob uma transformação ortogonal

$$\mathbf{x}_i^* = \mathbf{Q}\mathbf{x}_i.$$

A preservação de produtos internos, normas, ângulos e distâncias por transformações ortogonais foi estabelecida em Proposição 4.10. Aplicada às observações e aos centroides, essa propriedade mantém as distâncias utilizadas pelo critério das K -médias.

Os centroides transformados são

$$\mathbf{c}_k^* = \mathbf{Q}\mathbf{c}_k,$$

e

$$\|\mathbf{Q}(\mathbf{x}_i - \mathbf{c}_k)\|^2 = \|\mathbf{x}_i - \mathbf{c}_k\|^2.$$

Assim, rotações e reflexões ortogonais preservam o valor do critério e a estrutura geométrica da solução, salvo a transformação das próprias coordenadas.

Mudanças individuais de escala não apresentam essa propriedade. Como já ilustrado em Figura 16.2, elas modificam as distâncias relativas e podem alterar a partição ótima.

A Tabela 16.4 resume essas consequências.

Tabela 16.4: Efeito de transformações geométricas sobre o critério das K -médias.

Transformação das observações	Efeito sobre as distâncias euclidianas	Efeito sobre o problema das K -médias
translação comum	preservadas	preserva o critério e a partição correspondente
rotação ortogonal	preservadas	preserva o critério e transforma rigidamente a solução
reflexão ortogonal	preservadas	preserva o critério e transforma rigidamente a solução
escala comum por $a \neq 0$	multiplicadas por $ a $	multiplica J_K por a^2 , sem alterar a ordenação das partições
escalas diferentes por variável	alteradas de forma desigual	pode alterar a partição ótima

Essa análise mostra que transformações que preservam as distâncias euclidianas, ou que multiplicam todas elas pelo mesmo fator, preservam a ordenação das partições segundo o critério das K -médias.

A formulação por centroides representa uma definição específica de grupo: grupos são caracterizados pela compactação quadrática em torno de centros. Os métodos hierárquicos utilizam outra estrutura. Em vez de procurar diretamente uma única partição que minimize uma função global, eles constroem uma sequência de agrupamentos aninhados a partir de uma regra de proximidade entre conjuntos.

16.7 Estrutura dos métodos hierárquicos

As K -médias procuram diretamente uma partição para um número K previamente fixado de grupos. Os métodos hierárquicos utilizam outra representação: constroem uma sequência de partições relacionadas por inclusão (Everitt et al., 2011; Johnson; Wichern, 2007).

Os métodos hierárquicos podem ser construídos de forma aglomerativa ou divisiva. Nos procedimentos **aglomerativos**, grupos menores são sucessivamente reunidos. Nos procedimentos **divisivos**, parte-se de grupos maiores que são progressivamente subdivididos. O desenvolvimento deste capítulo será concentrado nos métodos aglomerativos, pois eles permitem relacionar diretamente a matriz de dissimilaridades às regras de ligação e ao dendrograma.

Em um procedimento aglomerativo, parte-se da partição formada por n grupos unitários,

$$\mathcal{P}_n = \{\{1\}, \dots, \{n\}\},$$

e, a cada etapa, dois grupos são fundidos. Após uma fusão, obtém-se uma nova partição com um grupo a menos, até chegar a

$$\mathcal{P}_1 = \{\{1, \dots, n\}\}.$$

As partições sucessivas são aninhadas: um grupo formado em determinada etapa permanece contido em algum grupo das etapas posteriores.

Definição 16.4 (Hierarquia de agrupamentos). Uma **hierarquia aglomerativa** é uma sequência de partições

$$\mathcal{P}_n, \mathcal{P}_{n-1}, \dots, \mathcal{P}_1,$$

na qual $\mathcal{P}_{r-1}$ é obtida de $\mathcal{P}_r$ pela fusão de exatamente dois grupos.

A construção da hierarquia exige uma regra para comparar grupos. O Módulo 1 forneceu a distância entre observações em Definição 1.13 e outras geometrias por meio de normas induzidas. No agrupamento hierárquico, essa informação deve ser estendida de pares de observações para pares de conjuntos.

Considere dois grupos não vazios

$$A \subseteq \{1, \dots, n\}$$

e

$$B \subseteq \{1, \dots, n\}.$$

Uma **regra de ligação** define uma dissimilaridade

$$D(A, B)$$

entre esses grupos. Diferentes regras utilizam de maneiras distintas as dissimilaridades entre seus elementos e, por isso, podem produzir hierarquias diferentes a partir da mesma matriz Δ .

16.7.1 Ligações simples, completa e média

Três regras podem ser construídas diretamente a partir das dissimilaridades entre pares de objetos.

Na **ligação simples**,

$$D_{\text{simples}}(A, B) = \min_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.19)$$

A proximidade entre os grupos é determinada pelo par mais próximo. A fusão pode, portanto, ocorrer quando existe uma conexão curta entre dois conjuntos, mesmo que outros elementos estejam relativamente afastados.

Na **ligação completa**,

$$D_{\text{completa}}(A, B) = \max_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.20)$$

A comparação é determinada pelo par mais distante. Essa definição favorece fusões nas quais todos os elementos dos dois grupos permanecem relativamente próximos.

Na **ligação média**,

$$D_{\text{media}}(A, B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} \delta_{ij}. \quad (16.21)$$

A dissimilaridade entre os grupos corresponde à média das dissimilaridades entre todos os pares formados por um elemento de A e um elemento de B .

As três regras utilizam a mesma matriz de dissimilaridades, mas representam noções distintas de proximidade entre conjuntos.

A Tabela 16.5 compara as três definições de proximidade entre grupos.

Tabela 16.5: Critérios de ligação construídos a partir das dissimilaridades entre objetos.

Regra de ligação	Dissimilaridade entre A e B	Estrutura privilegiada
simples	menor dissimilaridade entre pares	conexão entre elementos próximos
completa	maior dissimilaridade entre pares	controle da maior dissimilaridade entre os grupos candidatos à fusão
média	média das dissimilaridades entre pares	proximidade média entre os conjuntos

A diferença entre os critérios pode ser observada mesmo com poucos objetos. Considere dois grupos

$$A = \{1, 2\}$$

e

$$B = \{3, 4\},$$

com dissimilaridades entre seus elementos dadas por

$$\delta_{13} = 2, \quad \delta_{14} = 8, \quad \delta_{23} = 3, \quad \delta_{24} = 7.$$

Então,

$$D_{\text{simples}}(A, B) = 2,$$

$$D_{\text{completa}}(A, B) = 8$$

e

$$D_{\text{media}}(A, B) = \frac{2 + 8 + 3 + 7}{4} = 5.$$

Não há contradição entre os três resultados. Cada valor responde a uma definição diferente da proximidade entre grupos.

A escolha da ligação faz, portanto, parte da definição matemática do agrupamento hierárquico.

16.7.2 Empates e não unicidade da hierarquia

Em cada etapa do procedimento aglomerativo, o critério de ligação pode apresentar mais de um par de grupos com o mesmo menor valor.

Suponha, por exemplo, que

$$D(A, B) = D(C, D) = \min_{G \neq H} D(G, H).$$

Nesse caso, o critério não determina sozinho qual das fusões deve ocorrer primeiro.

Uma regra de desempate pode selecionar um dos pares. Dependendo da configuração das dissimilaridades e da regra de ligação, escolhas diferentes em uma etapa de empate podem produzir sequências posteriores diferentes e, conseqüentemente, hierarquias distintas.

Portanto, assim como ocorreu nas K -médias, a solução hierárquica não deve ser considerada automaticamente única.

Há ainda uma diferença entre dois tipos de não unicidade:

- a ordem gráfica das folhas de um dendrograma pode ser alterada sem modificar a hierarquia representada;
- empates no critério de fusão podem, em determinadas situações, produzir hierarquias efetivamente diferentes.

A primeira é apenas uma não unicidade de representação gráfica. A segunda pertence ao próprio procedimento de construção da solução.

16.7.3 Método de Ward e dispersão intragrupos

O método de Ward utiliza uma construção diferente das três ligações anteriores. Na formulação desenvolvida aqui, os objetos possuem coordenadas em um espaço euclidiano e a decisão de fusão é baseada no aumento da dispersão quadrática intragrupos (Ward, 1963).

Essa interpretação depende da estrutura euclidiana que permite definir centroides e somas de quadrados. Uma matriz arbitrária de dissimilaridades não possui, por si só, a mesma interpretação em termos de SSCP.

Essa formulação permite reutilizar diretamente a matriz $\mathbf{T}_{\text{intra}}$ definida em Definição 8.14 e a decomposição de Proposição 8.10.

Considere dois grupos A e B , com tamanhos

$$n_A = |A|, \quad n_B = |B|,$$

e centroides

$$\mathbf{c}_A = \frac{1}{n_A} \sum_{i \in A} \mathbf{x}_i$$

e

$$\mathbf{c}_B = \frac{1}{n_B} \sum_{i \in B} \mathbf{x}_i.$$

Após a fusão,

$$C = A \cup B,$$

o novo centroide é

$$\mathbf{c}_C = \frac{n_A \mathbf{c}_A + n_B \mathbf{c}_B}{n_A + n_B}. \quad (16.22)$$

Antes da fusão, a contribuição desses dois grupos para a dispersão intragrupos é

$$J(A) + J(B) = \sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_A\|^2 + \sum_{i \in B} \|\mathbf{x}_i - \mathbf{c}_B\|^2.$$

Depois da fusão, a contribuição passa a ser

$$J(A \cup B) = \sum_{i \in A \cup B} \|\mathbf{x}_i - \mathbf{c}_C\|^2.$$

O aumento produzido pela fusão é

$$\Delta_{\text{Ward}}(A, B) = J(A \cup B) - J(A) - J(B). \quad (16.23)$$

A identidade geral de decomposição em torno do centroide, estabelecida em Equação 10.52 e especializada em Equação 16.12, pode ser aplicada separadamente aos grupos A e B .

Para as observações de A ,

$$\sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_C\|^2 = \sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_A\|^2 + n_A \|\mathbf{c}_A - \mathbf{c}_C\|^2.$$

Analogamente,

$$\sum_{i \in B} \|\mathbf{x}_i - \mathbf{c}_C\|^2 = \sum_{i \in B} \|\mathbf{x}_i - \mathbf{c}_B\|^2 + n_B \|\mathbf{c}_B - \mathbf{c}_C\|^2.$$

Substituindo essas expressões em Equação 16.23,

$$\Delta_{\text{Ward}}(A, B) = n_A \|\mathbf{c}_A - \mathbf{c}_C\|^2 + n_B \|\mathbf{c}_B - \mathbf{c}_C\|^2.$$

De Equação 16.22,

$$\mathbf{c}_A - \mathbf{c}_C = \frac{n_B}{n_A + n_B} (\mathbf{c}_A - \mathbf{c}_B)$$

e

$$\mathbf{c}_B - \mathbf{c}_C = -\frac{n_A}{n_A + n_B} (\mathbf{c}_A - \mathbf{c}_B).$$

Logo,

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2. \quad (16.24)$$

Proposição 16.2 (Incremento de dispersão no método de Ward). *A fusão de dois grupos A e B aumenta a soma de quadrados intragrupos em*

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2.$$

O método de Ward seleciona, em cada etapa, uma fusão que produz o menor aumento em

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Se houver mais de um par com o mesmo menor incremento, aplica-se a mesma ressalva sobre empates discutida anteriormente.

A expressão em Equação 16.24 apresenta duas componentes. A distância entre os centroides mede sua separação geométrica, enquanto

$$\frac{n_A n_B}{n_A + n_B}$$

incorpora os tamanhos dos grupos.

Ward e K -médias compartilham, portanto, a mesma estrutura de dispersão quadrática. A diferença está na forma como a solução é construída. As K -médias procuram uma partição global para um K fixado. Ward constrói sucessivamente uma hierarquia e, em cada etapa, seleciona uma fusão que produz o menor aumento local da dispersão intragrupos entre as fusões disponíveis.

Essa distinção é importante: o procedimento de Ward não resolve, em geral, o problema global das K -médias para cada valor de K . Mesmo que os dois métodos utilizem a mesma noção de dispersão quadrática, a construção hierárquica impõe que fusões realizadas em etapas anteriores não sejam posteriormente desfeitas.

A Figura 16.4 representa a diferença conceitual entre ligação simples, ligação completa e Ward para dois grupos.




Figura 16.4: Diferentes critérios utilizam diferentes características para medir a proximidade entre dois grupos.

Na ligação simples, apenas o par mais próximo determina a comparação. Na ligação completa, utiliza-se o par mais afastado. Em Ward, a distância entre centroides participa de uma expressão ponderada pelos tamanhos dos grupos e determina o aumento produzido na dispersão intragrupos.

A ligação média não aparece na figura porque utiliza simultaneamente todos os pares entre os dois grupos e não pode ser representada por um único segmento.

16.7.4 Dendrograma e níveis de fusão

A sequência produzida por um método hierárquico pode ser representada por um dendrograma.

Cada folha corresponde a um objeto. As junções representam fusões entre grupos, e a altura associada a uma fusão registra o nível atribuído a essa fusão pelo critério utilizado.

Definição 16.5 (Dendrograma). Um **dendrograma** é uma representação gráfica de uma hierarquia de agrupamentos na qual as folhas representam os objetos e as alturas das junções registram os níveis associados às fusões entre grupos.

O dendrograma representa toda a sequência de partições produzida pelo método. Uma partição específica com K grupos corresponde a uma etapa da sequência hierárquica.

Quando as alturas de fusão distinguem essa etapa das fusões adjacentes, a mesma partição pode ser representada por um corte horizontal no dendrograma.

Em situações com fusões no mesmo nível, um corte horizontal pode não distinguir todas as etapas intermediárias produzidas por uma regra sequencial de desempate. A hierarquia deve, portanto, ser entendida primariamente como a sequência de partições construída pelo procedimento; o corte do dendrograma é uma representação dessa estrutura.

Essa operação também não deve ser confundida com a escolha do número de grupos. O dendrograma contém as partições aninhadas produzidas pelo critério; a decisão sobre qual delas utilizar pertence à etapa de análise e validação.

A Figura 16.5 apresenta uma hierarquia simples construída a partir de seis objetos.

O eixo vertical do dendrograma deve ser interpretado segundo o critério utilizado. Na ligação simples, por exemplo, a altura pode ser expressa pela dissimilaridade no nível em que a fusão ocorre. No método de Ward, o nível está associado ao incremento da dispersão intragrupos, podendo sua escala gráfica depender da convenção adotada na implementação.

Por isso, alturas obtidas por critérios diferentes não representam necessariamente a mesma quantidade matemática ou estatística.

16.7.5 Ultramétrica induzida pela hierarquia

Uma hierarquia com níveis de fusão também induz uma nova dissimilaridade entre os objetos.

Para dois objetos i e j , considere o menor nível da hierarquia em que eles passam a pertencer ao mesmo grupo. Denote esse valor por

$$d_{\text{cop}}(i, j).$$




Figura 16.5: Representação hierárquica das fusões entre seis objetos. A altura registra o nível da fusão.

Essa quantidade é denominada **dissimilaridade cofenética**.

Definição 16.6 (Dissimilaridade cofenética). Considere uma hierarquia aglomerativa cujas fusões possuem níveis não decrescentes.

A **dissimilaridade cofenética** entre os objetos i e j é o menor nível da hierarquia no qual ambos passam a pertencer ao mesmo grupo:

$$d_{\text{cop}}(i, j).$$

Por convenção,

$$d_{\text{cop}}(i, i) = 0.$$

Para formular a propriedade geométrica induzida pela hierarquia, é útil distinguir pseudoultramétrica de ultramétrica.

Definição 16.7 (Pseudoultramétrica e ultramétrica). Seja

$$d_U : \mathcal{J} \times \mathcal{J} \longrightarrow [0, \infty)$$

uma função sobre o conjunto de objetos

$$\mathcal{J} = \{1, \dots, n\}.$$

Ela é uma **pseudoultramétrica** quando satisfaz

$$d_U(i, i) = 0,$$

$$d_U(i, j) = d_U(j, i)$$

e, para quaisquer $i, j, k \in \mathcal{J}$,

$$d_U(i, k) \leq \max \{d_U(i, j), d_U(j, k)\}. \quad (16.25)$$

Uma pseudoultramétrica é uma **ultramétrica** quando também satisfaz

$$d_U(i, j) > 0 \quad \text{para} \quad i \neq j.$$

A desigualdade em Equação 16.25 é mais forte do que a desigualdade triangular usual.

Quando os níveis de fusão são não decrescentes, a dissimilaridade cofenética satisfaz essa desigualdade.

Para verificar a propriedade, considere três objetos i , j e k e defina

$$h = \max \{d_{\text{cop}}(i, j), d_{\text{cop}}(j, k)\}.$$

No nível h , os objetos i e j já pertencem ao mesmo grupo e os objetos j e k também pertencem ao mesmo grupo.

Como cada nível da hierarquia é uma partição, o grupo que contém j nesse nível é único. Portanto, i , j e k pertencem ao mesmo grupo no nível h .

Consequentemente,

$$d_{\text{cop}}(i, k) \leq h,$$

isto é,

$$d_{\text{cop}}(i, k) \leq \max \{d_{\text{cop}}(i, j), d_{\text{cop}}(j, k)\}.$$

Assim, sob níveis de fusão não decrescentes, a dissimilaridade cofenética é uma **pseudoultramétrica**.

Se, adicionalmente, objetos distintos somente puderem tornar-se pertencentes ao mesmo grupo em níveis estritamente positivos, então

$$d_{\text{cop}}(i, j) > 0 \quad \text{para} \quad i \neq j,$$

e a dissimilaridade cofenética é uma ultramétrica no sentido estrito.

Essa distinção é compatível com Definição 16.1, na qual foi permitido que objetos distintos apresentem dissimilaridade zero.

A estrutura hierárquica cria, portanto, uma geometria própria a partir das fusões. Essa geometria não precisa reproduzir exatamente a matriz de dissimilaridades original

Δ .

O método transforma a estrutura inicial de proximidades em uma coleção de grupos aninhados e, quando os níveis são monotônicos, em uma pseudoultramétrica cofenética.

16.7.6 Uma partição e uma hierarquia representam objetos diferentes

As K -médias produzem diretamente uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um método hierárquico produz uma coleção ordenada de partições aninhadas.

Essa diferença modifica o tipo de informação fornecida pela técnica e é sintetizada na Tabela 16.6.

Tabela 16.6: Estruturas produzidas por diferentes formulações de agrupamento.

Estrutura	Resultado principal	Critério
K -médias	uma partição para K fixado	minimização da dispersão quadrática intragrupos
ligação simples	uma hierarquia	menor dissimilaridade entre grupos
ligação completa	uma hierarquia	maior dissimilaridade entre grupos
ligação média	uma hierarquia	média das dissimilaridades entre grupos
Ward	uma hierarquia	menor aumento da dispersão intragrupos

A existência de diferentes critérios mostra que “grupo” não corresponde a um único objeto matemático.

Nas K -médias, um grupo é representado por proximidade a um centroide. Na ligação simples, a formação de grupos depende da conectividade produzida por pares próximos. Na ligação completa, controla-se a maior dissimilaridade entre elementos de grupos candidatos à fusão. Na ligação média, considera-se conjuntamente o conjunto de dissimilaridades entre os dois grupos. Em Ward, a fusão é avaliada por seu efeito sobre a dispersão quadrática intragrupos.

Além disso, uma partição selecionada de uma hierarquia não é equivalente a uma solução obtida diretamente pela otimização de um critério para o mesmo número de grupos. A hierarquia conserva as fusões realizadas anteriormente e, portanto, restringe as partições que podem aparecer nas etapas posteriores.

Essa diferença será ampliada na próxima seção ao considerar formulações nas quais grupos são definidos como componentes de uma distribuição probabilística ou como regiões de elevada densidade.

16.8 Diferentes definições matemáticas de grupo

As formulações anteriores mostram que a expressão **grupo** não identifica um único objeto matemático. Nas K -médias, um grupo é organizado em torno de um centroide. Nos métodos hierárquicos, sua formação depende de uma regra de ligação e da sequência de fusões.

Outras formulações podem definir grupos a partir de modelos probabilísticos ou de regiões de concentração das observações. Essas abordagens não constituem versões equivalentes de um mesmo critério. Elas atribuem significados diferentes à estrutura procurada.

A Tabela 16.7 sintetiza algumas dessas definições.

Tabela 16.7: Diferentes definições matemáticas de grupo.

Formulação	Representação de um grupo	Estrutura utilizada
centroides	conjunto de observações próximas de um centro	distância e dispersão quadrática
ligação simples	conjunto conectado por elementos próximos	menor dissimilaridade entre grupos
ligação completa	conjunto cuja maior separação é controlada	maior dissimilaridade entre grupos
Ward	conjunto cuja fusão produz pequeno aumento da dispersão	SSCP intragrupos
modelo de mistura	componente de uma distribuição probabilística	densidades e probabilidades de pertencimento
densidade	região conectada de elevada concentração	densidade e conectividade

A tabela explica por que métodos diferentes podem produzir soluções distintas sem que uma delas seja necessariamente incorreta. Cada método resolve um problema diferente e define matematicamente o que será entendido por grupo.

16.8.1 Formulação probabilística de grupos

Os critérios estudados até aqui foram formulados principalmente por distâncias, dispersões e relações entre conjuntos. Uma definição diferente pode ser obtida por meio de um modelo probabilístico (Everitt et al., 2011).

Considere uma variável categórica latente

$$G \in \{1, \dots, K\},$$

com

$$P(\mathbf{G} = k) = \pi_k, \quad \pi_k > 0,$$

e

$$\sum_{k=1}^K \pi_k = 1.$$

Condicionalmente à componente k ,

$$\mathbf{X} \mid \mathbf{G} = k$$

possui densidade

$$f_k(\mathbf{x}; \theta_k).$$

Pela lei da probabilidade total, a densidade marginal de $\mathbf{X}$ é

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k). \quad (16.26)$$

Definição 16.8 (Modelo de mistura para agrupamento). Um **modelo de mistura** representa a distribuição das observações como uma combinação de K componentes,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k),$$

em que

$$\pi_k = P(\mathbf{G} = k)$$

é a proporção ou probabilidade a priori da componente k , e

$$f_k(\mathbf{x}; \theta_k)$$

descreve a distribuição de $\mathbf{X}$ condicionada a

$$\mathbf{G} = k.$$

Nessa formulação, o grupo é representado por uma variável aleatória categórica não observada. Para uma observação $\mathbf{x}$ tal que

$$f(\mathbf{x}) > 0,$$

o teorema de Bayes fornece

$$P(G = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x}; \theta_k)}{\sum_{\ell=1}^K \pi_\ell f_\ell(\mathbf{x}; \theta_\ell)}. \quad (16.27)$$

Essas probabilidades fornecem uma representação probabilística do pertencimento aos grupos. Diferentemente de uma partição rígida,

$$P(G = k \mid \mathbf{X} = \mathbf{x})$$

pode assumir valores entre 0 e 1 para várias componentes. Uma classificação rígida pode ser construída posteriormente, por exemplo escolhendo uma componente com maior probabilidade posterior, mas essa decisão não faz parte da definição do modelo de mistura.

A formulação utiliza os fundamentos probabilísticos do Módulo 2, mas resolve um problema diferente daquele da Análise Fatorial.

No modelo de fatores comuns de Definição 15.1, as variáveis latentes são contínuas e são utilizadas para representar a estrutura de covariâncias entre variáveis observadas.

No modelo de mistura, a variável latente

G

é categórica e indica a componente da distribuição associada à observação.

A normalidade multivariada não é necessária para definir um modelo de mistura em geral. Ela aparece somente quando se escolhem, especificamente, densidades componentes normais multivariadas.

16.8.2 Não unicidade dos rótulos em modelos de mistura

Os rótulos das componentes de uma mistura não possuem significado intrínseco.

Considere uma permutação

$$\tau : \{1, \dots, K\} \longrightarrow \{1, \dots, K\}.$$

Reordenar simultaneamente as proporções e os parâmetros das componentes não modifica a densidade marginal:

$$\sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k) = \sum_{k=1}^K \pi_{\tau(k)} f_{\tau(k)}(\mathbf{x}; \theta_{\tau(k)}).$$

Portanto, os nomes atribuídos às componentes são arbitrários.

Essa indeterminação de rótulos é análoga, nesse aspecto, à arbitrariedade dos nomes dos grupos em uma partição. Condições adicionais de identificação podem ser necessárias para determinar outros aspectos dos parâmetros de uma mistura, dependendo da família de distribuições especificada.

Os métodos de estimação dos parâmetros de misturas e os algoritmos utilizados para calculá-los pertencem à implementação da técnica e não serão desenvolvidos neste capítulo.

A formulação probabilística também não estabelece que toda componente encontrada corresponda a uma classe substantiva existente fora do modelo. Os grupos são componentes da distribuição especificada, e sua interpretação depende da adequação dessa representação ao problema analisado.

16.8.3 Grupos definidos por densidade

Uma terceira noção pode ser formulada diretamente a partir da concentração da distribuição no espaço das observações.

Se $\mathbf{X}$ possui densidade

$$f(\mathbf{x}),$$

considere, para um nível

$$\lambda > 0,$$

o conjunto de nível superior

$$L_\lambda = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) \geq \lambda\}. \quad (16.28)$$

As componentes conectadas de

$$L_\lambda$$

podem ser utilizadas para representar regiões distintas de elevada densidade.

Essa definição permite considerar grupos com formas que não precisam ser adequadamente representadas por centroides ou regiões de Voronoi. O critério passa a depender da existência de regiões densas separadas por regiões de menor concentração.

A própria estrutura obtida depende do nível

$$\lambda.$$

À medida que o nível varia, componentes conectadas podem aparecer, desaparecer, dividir-se ou unir-se. Portanto, também nessa formulação o conceito de grupo depende de um critério matemático previamente especificado.

A noção de grupo baseada em densidade explica por que métodos construídos para esse objetivo podem produzir soluções muito diferentes das K -médias. Os procedimentos não estão necessariamente produzindo respostas diferentes para uma mesma função objetivo; eles procuram estruturas diferentes.

Métodos computacionais específicos baseados em densidade serão tratados posteriormente. Neste capítulo, essa formulação serve para mostrar que proximidade a um centroide, conectividade hierárquica, componentes probabilísticas e regiões de elevada densidade constituem conceitos distintos de grupo.

16.9 Dependência da solução e limites da formulação

A Análise de Agrupamentos não possui um conjunto único de pressupostos probabilísticos. As K -médias e os métodos hierárquicos estudados neste capítulo podem ser formulados geometricamente, sem hipótese de normalidade multivariada ou de um modelo probabilístico gerador. Nos modelos de mistura, uma família de distribuições é especificada e suas hipóteses passam a integrar o modelo. Nas formulações baseadas em densidade, a distribuição ou uma representação de sua concentração participa da própria definição dos grupos.

A solução também depende das escolhas que definem o problema. A Tabela 16.8 resume essas dependências.

Tabela 16.8: Elementos dos quais depende uma solução de agrupamento.

Elemento modificado	Estrutura alterada	Consequência possível
conjunto de variáveis	representação dos objetos	proximidades e grupos podem mudar
escala das variáveis	geometria do espaço	variáveis recebem pesos relativos diferentes
métrica ou dissimilaridade	relação de proximidade	pares considerados próximos podem mudar
número K	conjunto de partições ou componentes consideradas	muda o problema formulado
regra de ligação	proximidade entre grupos	muda a hierarquia
função objetivo	definição de agrupamento	muda a estrutura procurada
modelo probabilístico	significado da variável latente de grupo	mudam componentes e probabilidades posteriores
nível ou critério de densidade	definição de região concentrada	mudam forma, número e conectividade dos grupos

Adicionar, retirar ou transformar variáveis modifica a representação

$$\mathbf{x}_i \in \mathbb{R}^p$$

e pode alterar as relações de proximidade. Mudanças de escala e de métrica modificam a geometria utilizada para comparar os objetos. A padronização também altera essa geometria ao modificar os pesos relativos das variáveis.

A forma de grupo procurada depende do critério. As K -médias representam cada grupo por um centroide e utilizam regiões de Voronoi; a ligação simples utiliza conectividade por pares próximos; a ligação completa utiliza a maior dissimilaridade entre os grupos candidatos à fusão; Ward utiliza o incremento da dispersão quadrática intragrupos; e métodos baseados em densidade utilizam regiões de elevada concentração e conectividade. Essas formulações definem objetos matemáticos distintos.

A solução também pode não ser única. Nas K -médias, diferentes partições podem atingir o mesmo mínimo, além da arbitrariedade dos rótulos. Nos métodos hierárquicos, empates podem produzir diferentes sequências de fusões. Nos modelos de mistura, permutações dos rótulos das componentes representam a mesma densidade marginal, além de eventuais questões adicionais de identificação.

Assim, os pressupostos e os limites devem ser interpretados relativamente à formulação específica. A dependência da representação, da proximidade e do critério decorre da própria definição do problema de agrupamento.

16.10 Ausência de classes naturais automáticas

A Análise de Agrupamentos é uma técnica não supervisionada: os rótulos dos grupos não são observados previamente.

Esse fato impõe uma diferença importante em relação à Análise Discriminante. Uma partição encontrada nos dados não demonstra automaticamente a existência de populações distintas que tenham gerado as observações.

No caso das K -médias, uma solução global é definida pela minimização de

$$J_K.$$

No método de Ward, a hierarquia é construída a partir dos incrementos de dispersão intragrupos.

Nas ligações simples, completa e média, a hierarquia decorre das respectivas definições de proximidade entre conjuntos.

Em uma mistura probabilística, os grupos são componentes de um modelo especificado.

Em uma formulação por densidade, os grupos dependem das regiões de concentração definidas pelo critério adotado.

Cada conclusão deve ser interpretada relativamente à estrutura matemática ou probabilística que produziu a solução.

Grupos encontrados e grupos substantivos

Uma solução de agrupamento estabelece uma organização dos objetos segundo uma representação e um critério definidos. A correspondência entre essa organização matemática e categorias substantivas do problema exige informação externa aos critérios de agrupamento.

Esse limite distingue a capacidade de encontrar uma estrutura matemática da interpretação substantiva dessa estrutura.

16.11 Relações com outras técnicas multivariadas

A Análise de Agrupamentos reutiliza objetos já presentes nos capítulos anteriores, mas atribui a eles uma nova função.

A Tabela 16.9 compara essas relações.

Tabela 16.9: Relações entre a Análise de Agrupamentos e outras técnicas multivariadas.

Técnica	Objeto relacionado	Função na técnica
ACP	matriz de dados e geometria das observações	construir uma representação de menor dimensão
Análise Fatorial	variáveis observadas e matriz de covariâncias	modelar a estrutura de covariâncias por fatores latentes contínuos
Agrupamentos	matriz de dados ou dissimilaridades	construir grupos
MDS	matriz de dissimilaridades	construir uma configuração geométrica que procure representar as proximidades
MANOVA	dispersão intragrupos e entre grupos	testar hipóteses sobre diferenças entre grupos conhecidos
Análise Discriminante	médias, dispersões e distribuições de grupos	construir direções de separação ou regras de classificação

16.11.1 Agrupamentos e ACP

A ACP pode produzir novas coordenadas para as observações. Quando são mantidas todas as componentes correspondentes a uma transformação ortogonal da representação utilizada como entrada, as distâncias euclidianas são preservadas por Proposição 4.10.

Quando apenas

$$k < p$$

componentes são mantidas, as observações são projetadas sobre o subespaço principal definido em Definição 14.1, como representado em Figura 14.3. Nesse caso, as distâncias passam a ser calculadas na configuração projetada e podem diferir das distâncias anteriores à redução.

A interpretação também depende da representação utilizada pela ACP. Se a análise foi realizada sobre variáveis padronizadas, a preservação pela transformação ortogonal refere-se à geometria do espaço padronizado, e não à geometria das variáveis em suas escalas originais.

Assim, utilizar ACP antes de um agrupamento modifica o problema sempre que ocorre redução efetiva de dimensão ou mudança prévia da representação dos dados.

16.11.2 Agrupamentos e MDS

Agrupamentos e Escalonamento Multidimensional podem partir da mesma matriz

$$\Delta.$$

A diferença está no objeto procurado.

Na Análise de Agrupamentos,

$$\Delta$$

é utilizada para construir partições ou hierarquias.

No MDS, ela será utilizada para obter coordenadas

$$\mathbf{y}_1, \dots, \mathbf{y}_n$$

cujas distâncias procurem representar as dissimilaridades fornecidas.

A representação pode ser exata em situações específicas, mas, em geral, o problema consiste em encontrar uma configuração que preserve ou aproxime a estrutura de proximidades segundo o critério do método.

Essa relação prepara diretamente o próximo capítulo.

16.11.3 Agrupamentos e Análise Discriminante

Na Análise de Agrupamentos, os grupos fazem parte da solução.

Na Análise Discriminante, os grupos são conhecidos previamente e fazem parte da informação utilizada para construir direções de separação ou regras de classificação.

A primeira técnica procura uma organização dos objetos. A segunda utiliza classes previamente observadas para estudar sua separação e, em formulações classificatórias, atribuir novas observações a essas classes.

16.11.4 Agrupamentos e MANOVA

A conexão com MANOVA aparece na decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

já estabelecida em Proposição 8.10.

Nas K -médias, a partição é desconhecida e procura-se reduzir

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Na MANOVA, os grupos serão dados pelo delineamento e as matrizes de dispersão serão utilizadas para formular um problema inferencial sobre diferenças entre vetores de médias.

O mesmo objeto matricial assume funções distintas. Nas K -médias, a dispersão intragrupos define um critério de otimização para construir a partição. Na MANOVA, as matrizes de dispersão participam de um problema inferencial para grupos conhecidos. Na Análise Discriminante, elas serão utilizadas para construir direções de separação entre grupos também conhecidos.

Essa comparação reforça uma característica recorrente do Módulo 3: a operação matemática não determina, sozinha, a técnica. O significado estatístico depende do problema ao qual o objeto é aplicado.

16.12 Síntese

A Análise de Agrupamentos organiza objetos sem utilizar classes previamente conhecidas. Sua formulação depende da representação dos objetos, da definição de proximidade e do critério utilizado para caracterizar os grupos.

Quando as observações são representadas pelas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

as proximidades podem ser construídas a partir de suas coordenadas. Quando as relações entre os objetos são fornecidas diretamente, a análise pode partir de uma matriz de dissimilaridades

$$\Delta \in \mathbb{R}^{n \times n}.$$

Uma partição rígida em K grupos é representada por

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Nas K -médias, a solução minimiza a dispersão quadrática intragrupos,

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2 = \text{tr}(\mathbf{T}_{\text{intra}}).$$

O centróide aparece porque a média minimiza a soma das distâncias euclidianas quadráticas às observações do grupo. A decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

mostra que, para K fixado, minimizar a dispersão intragrupos equivale a maximizar a dispersão entre os centroides.

Os métodos hierárquicos produzem uma sequência aninhada de partições. Ligações simples, completa e média diferem pela forma como definem a proximidade entre grupos. O método de Ward utiliza o incremento

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2$$

na dispersão intragrupos. O dendrograma representa a sequência de fusões e seus níveis, podendo induzir uma estrutura cofenética ultramétrica quando as condições correspondentes são satisfeitas.

Partições e hierarquias não esgotam o conceito de grupo. Nos modelos de mistura, os grupos correspondem a componentes de uma distribuição probabilística,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k),$$

enquanto formulações baseadas em densidade utilizam regiões de elevada concentração e conectividade. Cada construção define matematicamente um conceito diferente de grupo.

Normalidade multivariada não constitui pressuposto geral da Análise de Agrupamentos. Métodos geométricos podem ser definidos sem modelo probabilístico; modelos de mistura incorporam as hipóteses das distribuições escolhidas.

A solução depende das variáveis, das escalas, da medida de proximidade, do número de grupos, da função objetivo, da regra de ligação ou do modelo adotado. Empates e simetrias também podem produzir não unicidade. Por isso, a organização encontrada deve ser interpretada

relativamente à estrutura matemática ou probabilística que a definiu e não implica, por si só, a existência de classes substantivas externas aos dados.

O capítulo integra distâncias, normas, dispersões, partições, otimização e modelos probabilísticos para formular diferentes problemas de agrupamento.

No próximo capítulo, a matriz de dissimilaridades permanece como possível objeto de entrada, mas o objetivo muda. O Escalonamento Multidimensional utilizará essas relações para construir uma configuração geométrica cujas distâncias representem ou aproximem as proximidades observadas.

17 Formulação do Escalonamento Multidimensional

O Escalonamento Multidimensional, ou MDS, representa relações de dissimilaridade entre objetos por meio de coordenadas em um espaço geométrico. A matriz de entrada pode ser a mesma utilizada na Análise de Agrupamentos, mas o objetivo muda: em vez de formar grupos, procura-se construir uma configuração cujas distâncias representem as dissimilaridades observadas.

No MDS clássico, a relação entre distâncias euclidianas e produtos internos permite reconstruir uma matriz de Gram a partir das dissimilaridades. A decomposição espectral dessa matriz fornece as coordenadas da configuração (Gower, 1966; Torgerson, 1952).

Os elementos principais da formulação são apresentados na Tabela 17.1.

Tabela 17.1: Elementos da formulação do Escalonamento Multidimensional.

Elemento	Objeto matemático	Papel no MDS
Informação de entrada	$\Delta = (\delta_{ij})$	registra as dissimilaridades entre os objetos
Configuração	$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$	fornece coordenadas aos objetos
Distâncias configuracionais	d_{ij}	medem a separação entre os pontos reconstruídos
Produtos internos	$\mathbf{G}$	descrevem a geometria da configuração centralizada
Solução clássica	decomposição espectral de $\mathbf{G}$	produz as coordenadas principais

17.1 O problema de reconstrução geométrica

Considere n objetos para os quais estão disponíveis dissimilaridades

$$\delta_{ij}, \quad i, j = 1, \dots, n.$$

A noção de dissimilaridade foi introduzida em Definição 16.1. Neste capítulo, consideraremos inicialmente uma matriz simétrica

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

com

$$\delta_{ij} \geq 0,$$

$$\delta_{ii} = 0$$

e

$$\delta_{ij} = \delta_{ji}.$$

Não se exige, neste ponto, que objetos distintos apresentem dissimilaridade estritamente positiva nem que Δ satisfaça a desigualdade triangular. Essas propriedades passam a ser relevantes quando se deseja interpretar a dissimilaridade como uma distância métrica.

O objetivo é encontrar pontos

$$\mathbf{x}_1^{(\text{MDS})}, \dots, \mathbf{x}_n^{(\text{MDS})} \in \mathbb{R}^k$$

e reuni-los nas linhas da configuração

$$\mathbf{X}_{\text{MDS},k} = \begin{pmatrix} \mathbf{x}_1^{(\text{MDS})\top} \\ \vdots \\ \mathbf{x}_n^{(\text{MDS})\top} \end{pmatrix} \in \mathbb{R}^{n \times k}. \quad (17.1)$$

A distância euclidiana entre dois pontos da configuração é

$$d_{ij}(\mathbf{X}_{\text{MDS},k}) = \|\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}\|, \quad (17.2)$$

utilizando a distância definida em Definição 1.13.

Uma representação euclidiana exata ocorre quando

$$d_{ij}(\mathbf{X}_{\text{MDS},k}) = \delta_{ij}$$

para todos os pares de objetos.

Em muitos problemas, essa igualdade não pode ser obtida na dimensão escolhida. Em outros, pode não existir uma configuração euclidiana exata em dimensão alguma. A representação passa então a ser aproximada, e o significado dessa aproximação dependerá da formulação adotada.

A distinção entre entrada e saída é sintetizada na Tabela 17.2.

Tabela 17.2: Quantidades de entrada e de saída no Escalonamento Multidimensional.

Quantidade	Natureza	Interpretação
δ_{ij}	observada ou fornecida	dissimilaridade entre os objetos i e j
$\mathbf{x}_i^{(\text{MDS})}$	construída pela técnica	coordenadas do objeto i
d_{ij}	derivada da configuração	distância entre os pontos reconstruídos

O problema do MDS é relacional. Não é necessário conhecer originalmente as variáveis que deram origem às diferenças entre os objetos. Uma matriz de dissimilaridades pode ser calculada a partir de uma matriz de dados, obtida por comparações entre objetos ou fornecida diretamente pelo problema analisado.

Essa característica distingue o MDS da ACP. A ACP parte de coordenadas das observações e constrói outra representação dessas mesmas observações. O MDS pode partir somente das relações entre pares de objetos e procurar coordenadas compatíveis com essas relações.

17.2 Configuração e indeterminações geométricas

Uma matriz de distâncias não determina a posição absoluta nem a orientação absoluta de uma configuração no espaço. Algumas transformações modificam as coordenadas sem modificar as distâncias entre os pontos.

17.2.1 Translação

Considere uma configuração

$$\mathbf{X}_{\text{MDS},k}$$

e um vetor

$$\mathbf{a} \in \mathbb{R}^k.$$

A translação comum de todos os pontos produz

$$\mathbf{x}_i^* = \mathbf{x}_i^{(\text{MDS})} + \mathbf{a}.$$

As diferenças permanecem inalteradas:

$$\mathbf{x}_i^* - \mathbf{x}_j^* = \mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}.$$

Consequentemente,

$$\|\mathbf{x}_i^* - \mathbf{x}_j^*\| = \|\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}\|.$$

Essa propriedade é um caso da preservação das distâncias por centralização e translação estabelecida em Proposição 4.15.

17.2.2 Transformações ortogonais

Considere agora

$$\mathbf{O} \in \mathbb{R}^{k \times k}$$

ortogonal e a configuração transformada

$$\mathbf{X}_{\text{MDS},k}^* = \mathbf{X}_{\text{MDS},k} \mathbf{O}.$$

A diferença entre duas linhas transformadas é

$$\left(\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})} \right)^\top \mathbf{O}.$$

Como transformações ortogonais preservam normas e distâncias por Proposição 4.10,

$$d_{ij}(\mathbf{X}_{\text{MDS},k}^*) = d_{ij}(\mathbf{X}_{\text{MDS},k}). \quad (17.3)$$

rotações e reflexões modificam a orientação da configuração sem modificar sua estrutura de distâncias.




Figura 17.1: Configurações relacionadas por translação e transformação ortogonal preservam as mesmas distâncias entre os objetos.

A Figura 17.1 mostra uma configuração e duas representações obtidas por transformações que preservam todas as distâncias entre os objetos.

A localização e a orientação dos eixos não são determinadas pelas distâncias. O objeto geométrico identificado pela informação de distâncias é, portanto, uma classe de configurações equivalentes por translação e transformação ortogonal.

A centralização, introduzida a seguir, escolhe um representante dessa classe quanto à translação. Ela não elimina a indeterminação por rotações ou reflexões.

No MDS clássico, uma mudança global de escala não constitui a mesma indeterminação. Se

$$\mathbf{X}_{\text{MDS},k}^* = c\mathbf{X}_{\text{MDS},k},$$

então

$$d_{ij}^* = |c|d_{ij}.$$

Quando os valores de Δ possuem escala fixada, essa transformação modifica as distâncias que se pretende reproduzir e, portanto, modifica o problema. A questão da escala assumirá outra forma nas formulações não métricas, nas quais a informação principal pode estar na ordenação das dissimilaridades.

17.2.3 Centralização da configuração

Como a translação não altera as distâncias, pode-se escolher uma origem conveniente sem perda da informação relacional.

No Módulo 2, a matriz de centralização foi utilizada para escrever

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

em Equação 8.58, com

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

No MDS, a mesma matriz será utilizada para escolher, entre as configurações equivalentes por translação, aquela cujo centroide está na origem.

Definição 17.1 (Configuração centralizada no MDS). Uma configuração

$$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$$

é **centralizada** quando

$$\mathbf{1}_n^\top \mathbf{X}_{\text{MDS},k} = \mathbf{0}^\top. \quad (17.4)$$

Se uma configuração não satisfaz essa condição, sua versão centralizada é

$$\mathbf{X}_{\text{MDS},k,c} = \mathbf{H}_n \mathbf{X}_{\text{MDS},k}.$$

Pela propriedade de Proposição 4.15, a centralização não modifica as distâncias entre suas linhas.

A condição em Equação 17.4 não cria uma nova geometria. Ela fixa apenas a indeterminação de translação, escolhendo a configuração cujo centroide coincide com a origem.

17.3 Da distância ao produto interno

A solução clássica do MDS combina a distância euclidiana definida em Definição 1.13 com a matriz de Gram de Definição 3.18 para converter informação sobre distâncias em informação sobre produtos internos.

Considere uma configuração centralizada

$$\mathbf{X}_{\text{MDS}} \in \mathbb{R}^{n \times r},$$

e sua matriz de Gram

$$\mathbf{G} = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top. \quad (17.5)$$

O elemento

$$g_{ij} = \mathbf{x}_i^{(\text{MDS})\top} \mathbf{x}_j^{(\text{MDS})}$$

é o produto interno entre os pontos i e j .

A distância quadrática entre esses pontos satisfaz

$$\begin{aligned} d_{ij}^2 &= \|\mathbf{x}_i^{(\text{MDS})} - \mathbf{x}_j^{(\text{MDS})}\|^2 \\ &= \mathbf{x}_i^{(\text{MDS})\top} \mathbf{x}_i^{(\text{MDS})} + \mathbf{x}_j^{(\text{MDS})\top} \mathbf{x}_j^{(\text{MDS})} - 2\mathbf{x}_i^{(\text{MDS})\top} \mathbf{x}_j^{(\text{MDS})} \\ &= g_{ii} + g_{jj} - 2g_{ij}. \end{aligned} \quad (17.6)$$

A matriz de Gram determina, portanto, todas as distâncias euclidianas da configuração.

O MDS clássico utiliza essa relação no sentido inverso: parte das distâncias ou dissimilaridades fornecidas e reconstrói uma matriz que poderá ser interpretada como matriz de Gram quando forem satisfeitas as condições geométricas apropriadas.

17.3.1 Matriz das dissimilaridades quadráticas

Defina

$$\Delta^{(2)} = (\delta_{ij}^2). \quad (17.7)$$

Quando Δ corresponde às distâncias de uma configuração euclidiana centralizada, considere o vetor formado pela diagonal de sua matriz de Gram,

$$\mathbf{g} = \begin{pmatrix} g_{11} \\ \vdots \\ g_{nn} \end{pmatrix}.$$

A identidade em Equação 17.6 pode então ser escrita matricialmente como

$$\Delta^{(2)} = \mathbf{g}\mathbf{1}_n^\top + \mathbf{1}_n\mathbf{g}^\top - 2\mathbf{G}. \quad (17.8)$$

Essa expressão contém os produtos internos e os termos associados às normas individuais dos pontos. A centralização permite eliminar os dois primeiros termos.

Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se

$$\mathbf{H}_n \mathbf{g} \mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}$$

e

$$\mathbf{H}_n \mathbf{1}_n \mathbf{g}^\top \mathbf{H}_n = \mathbf{0}.$$

Além disso, como a configuração é centralizada,

$$\mathbf{1}_n^\top \mathbf{X}_{\text{MDS}} = \mathbf{0}^\top,$$

e, portanto,

$$\mathbf{G} \mathbf{1}_n = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top \mathbf{1}_n = \mathbf{0}.$$

Da mesma forma,

$$\mathbf{1}_n^\top \mathbf{G} = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{H}_n \mathbf{G} \mathbf{H}_n = \mathbf{G}. \quad (17.9)$$

Multiplicando Equação 17.8 à esquerda e à direita por $\mathbf{H}_n$,

$$\begin{aligned} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n &= \mathbf{H}_n \mathbf{g} \mathbf{1}_n^\top \mathbf{H}_n + \mathbf{H}_n \mathbf{1}_n \mathbf{g}^\top \mathbf{H}_n - 2\mathbf{H}_n \mathbf{G} \mathbf{H}_n \\ &= -2\mathbf{G}. \end{aligned}$$

Logo,

$$\mathbf{G} = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n. \quad (17.10)$$

Proposição 17.1 (Reconstrução da matriz de Gram por dupla centralização). *Considere uma configuração euclidiana centralizada e seja*

$$\Delta^{(2)} = (d_{ij}^2)$$

sua matriz de distâncias quadráticas. Então sua matriz de Gram é

$$\mathbf{G} = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n.$$

A operação em Equação 17.10 é denominada **dupla centralização**. Ela converte a informação expressa em distâncias quadráticas em uma matriz de produtos internos.

O resultado possui uma hipótese importante: em Proposição 17.1, $\Delta^{(2)}$ é a matriz de **distâncias euclidianas quadráticas de uma configuração**. Nessas condições, a matriz obtida é exatamente sua matriz de Gram centralizada.

Para uma matriz de dissimilaridades geral, a mesma operação algébrica pode ser aplicada e define-se

$$\mathbf{G}_\Delta = -\frac{1}{2} \mathbf{H}_n \Delta^{(2)} \mathbf{H}_n. \quad (17.11)$$

Nesse caso, chamar $\mathbf{G}_\Delta$ de **matriz de Gram reconstruída** antecipa uma questão que ainda precisa ser verificada: ela será efetivamente a matriz de Gram de uma configuração euclidiana se possuir a estrutura necessária para isso.

Em particular, como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se sempre

$$\mathbf{G}_\Delta \mathbf{1}_n = \mathbf{0},$$

e

$$\mathbf{1}_n^\top \mathbf{G}_\Delta = \mathbf{0}^\top.$$

Portanto, a dupla centralização produz uma matriz simétrica e centralizada sempre que Δ é simétrica.

A propriedade decisiva que falta verificar é a semidefinição positiva.

Quando

$$\mathbf{G}_\Delta \succeq \mathbf{0},$$

a matriz pode ser representada como uma matriz de Gram euclidiana, e sua decomposição espectral fornecerá coordenadas para uma configuração correspondente.

Quando $\mathbf{G}_\Delta$ possui autovalores negativos, essa interpretação euclidiana exata não é possível na formulação clássica.

A estrutura espectral de $\mathbf{G}_\Delta$ será, portanto, o ponto de partida para a formulação do MDS clássico.

17.4 Formulação do MDS clássico

A dupla centralização transforma a matriz de dissimilaridades em um objeto ao qual se aplicam diretamente os resultados espectrais do Módulo 1. A matriz

$$\mathbf{G}_\Delta = -\frac{1}{2}\mathbf{H}_n\Delta^{(2)}\mathbf{H}_n$$

é simétrica. Quando as dissimilaridades correspondem a distâncias euclidianas, ela é também semidefinida positiva e pode ser interpretada como a matriz de Gram de uma configuração centralizada.

O MDS clássico utiliza essa matriz para recuperar as coordenadas dos objetos (Gower, 1966; Torgerson, 1952).

17.4.1 Solução espectral

Pelo Teorema Espectral estabelecido em Teorema 5.4, a matriz simétrica $\mathbf{G}_\Delta$ admite uma decomposição

$$\mathbf{G}_\Delta = \mathbf{Q}\mathbf{D}_G\mathbf{Q}^\top, \quad (17.12)$$

em que

$$\mathbf{Q}^\top\mathbf{Q} = \mathbf{I}_n$$

e

$$\mathbf{D}_G = \text{diag}(\lambda_1, \dots, \lambda_n),$$

com os autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n.$$

Considere inicialmente o caso em que

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Se existem r autovalores estritamente positivos,

$$\lambda_1 \geq \dots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \dots = \lambda_n = 0,$$

defina

$$\mathbf{Q}_+ = (\mathbf{q}_1 \quad \dots \quad \mathbf{q}_r)$$

e

$$\mathbf{D}_+ = \text{diag}(\lambda_1, \dots, \lambda_r).$$

Uma configuração é então dada por

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2}. \quad (17.13)$$

De fato,

$$\begin{aligned} \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top &= \mathbf{Q}_+ \mathbf{D}_+^{1/2} \mathbf{D}_+^{1/2} \mathbf{Q}_+^\top \\ &= \mathbf{Q}_+ \mathbf{D}_+ \mathbf{Q}_+^\top \\ &= \mathbf{G}_\Delta. \end{aligned} \quad (17.14)$$

Assim, a construção espectral fornece uma matriz de coordenadas cuja matriz de Gram coincide com aquela reconstruída a partir das dissimilaridades.

Definição 17.2 (Coordenadas principais). As colunas de

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2}$$

são denominadas **coordenadas principais** da configuração clássica.

A coordenada associada ao autovalor $\lambda_j > 0$ é

$$\sqrt{\lambda_j} \mathbf{q}_j.$$

Como

$$\mathbf{G}_\Delta \mathbf{1}_n = \mathbf{0},$$

o vetor $\mathbf{1}_n$ pertence ao espaço nulo de $\mathbf{G}_\Delta$. Os autovetores associados aos autovalores positivos são ortogonais a esse espaço e, portanto,

$$\mathbf{1}_n^\top \mathbf{Q}_+ = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_{\text{MDS}} = \mathbf{0}^\top.$$

A solução espectral já produz, portanto, uma configuração centralizada.

A posição de cada objeto na dimensão j é determinada pelos elementos de

$$\sqrt{\lambda_j} \mathbf{q}_j.$$

O autovalor controla a magnitude quadrática global das coordenadas naquele eixo, pois

$$\left\| \sqrt{\lambda_j} \mathbf{q}_j \right\|^2 = \lambda_j. \quad (17.15)$$

Nesse contexto, λ_j quantifica a contribuição quadrática daquele eixo para a geometria centralizada da configuração. Essa interpretação não exige atribuir aos autovalores o significado de variâncias de variáveis aleatórias.

Quando um autovalor positivo é simples, o autovetor correspondente é determinado até mudança de sinal. Quando um autovalor possui multiplicidade maior que um, diferentes bases ortonormais podem ser escolhidas no mesmo autoespaço. As configurações correspondentes são relacionadas por transformações ortogonais e preservam as distâncias pela propriedade de Proposição 4.10.

17.4.2 Reprodução euclidiana exata

A construção anterior conduz à condição que determina quando uma matriz de dissimilaridades pode ser representada exatamente por distâncias euclidianas.

Teorema 17.1 (Condição para representação euclidiana). *Considere uma matriz simétrica de dissimilaridades*

$$\Delta = (\delta_{ij}),$$

com

$$\delta_{ij} \geq 0$$

e

$$\delta_{ii} = 0.$$

Defina

$$\mathbf{G}_\Delta = -\frac{1}{2}\mathbf{H}_n\Delta^{(2)}\mathbf{H}_n.$$

Existe uma configuração de pontos em um espaço euclidiano cujas distâncias reproduzem exatamente Δ se, e somente se,

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Nesse caso, uma configuração centralizada é dada por Equação 17.13.

Comprovação. Suponha inicialmente que Δ seja produzida por uma configuração euclidiana centralizada

$$\mathbf{X}_{\text{MDS}}.$$

Pela proposição de dupla centralização em Proposição 17.1,

$$\mathbf{G}_\Delta = \mathbf{X}_{\text{MDS}}\mathbf{X}_{\text{MDS}}^\top.$$

Pelas propriedades das matrizes de Gram estabelecidas em Proposição 3.9,

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Isso estabelece a necessidade.

Considere agora

$$\mathbf{G}_\Delta \succeq \mathbf{0}.$$

Pela decomposição espectral, pode-se construir

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+ \mathbf{D}_+^{1/2},$$

de modo que

$$\mathbf{G}_\Delta = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top.$$

Denote por

$$\mathbf{g}_\Delta = \text{diag}(\mathbf{G}_\Delta)$$

o vetor formado pelos elementos diagonais de $\mathbf{G}_\Delta$.

Como $\Delta^{(2)}$ é simétrica e possui diagonal nula, a transformação por dupla centralização admite a relação inversa

$$\Delta^{(2)} = \mathbf{g}_\Delta \mathbf{1}_n^\top + \mathbf{1}_n \mathbf{g}_\Delta^\top - 2\mathbf{G}_\Delta. \quad (17.16)$$

Por outro lado, as distâncias quadráticas da configuração construída a partir de $\mathbf{G}_\Delta$ satisfazem

$$d_{ij}^2 = g_{ii} + g_{jj} - 2g_{ij}.$$

Portanto,

$$d_{ij}^2 = \delta_{ij}^2.$$

Como ambas as quantidades são não negativas,

$$d_{ij} = \delta_{ij}.$$

Logo, a configuração construída reproduz exatamente as dissimilaridades. □

A simetria e a diagonal nula de Δ não são suficientes para garantir uma representação euclidiana. A compatibilidade com essa geometria é determinada pela semidefinição positiva da matriz de Gram reconstruída.

A Tabela 17.3 resume a interpretação espectral.

Tabela 17.3: Interpretação dos autovalores da matriz de Gram reconstruída.

Estrutura de $\mathbf{G}_\Delta$	Consequência para a representação
todos os autovalores são não negativos	existe representação euclidiana exata
$\mathbf{G}_\Delta \succeq \mathbf{0}$ possui r autovalores positivos	a dimensão mínima de uma representação euclidiana exata é r
existem autovalores nulos	as direções correspondentes não acrescentam dimensão
existe pelo menos um autovalor negativo	não existe representação euclidiana exata das dissimilaridades na formulação clássica

17.4.3 Dimensão da configuração

Quando

$$\mathbf{G}_\Delta \succeq \mathbf{0},$$

a dimensão mínima de uma representação euclidiana exata é

$$r = \text{posto}(\mathbf{G}_\Delta). \quad (17.17)$$

De fato, se uma configuração

$$\mathbf{X}_{\text{MDS}} \in \mathbb{R}^{n \times k}$$

representa exatamente a geometria, então

$$\mathbf{G}_\Delta = \mathbf{X}_{\text{MDS}} \mathbf{X}_{\text{MDS}}^\top.$$

Pela propriedade de posto das matrizes de Gram estabelecida em Proposição 3.9,

$$\text{posto}(\mathbf{G}_\Delta) = \text{posto}(\mathbf{X}_{\text{MDS}}) \leq k.$$

Logo, qualquer representação exata exige

$$k \geq \text{posto}(\mathbf{G}_\Delta).$$

Por outro lado, Equação 17.13 constrói uma configuração exatamente em

$$r = \text{posto}(\mathbf{G}_\Delta)$$

dimensões.

Como

$$\mathbf{G}_\Delta \mathbf{1}_n = \mathbf{0},$$

tem-se

$$\text{posto}(\mathbf{G}_\Delta) \leq n - 1.$$

Assim, qualquer conjunto de n objetos cujas dissimilaridades sejam euclidianas admite uma representação exata em no máximo $n - 1$ dimensões.

A Figura 17.2 ilustra a reconstrução de uma configuração bidimensional a partir apenas das distâncias entre os objetos.

A configuração reconstruída pode aparecer rotacionada ou refletida em relação à original. Essa diferença não representa erro de reconstrução, pois as transformações ortogonais preservam as distâncias conforme Equação 17.3.

17.4.4 Representação em dimensão reduzida

Uma matriz de distâncias pode admitir representação euclidiana exata em dimensão

$$r,$$

mas o objetivo da análise pode ser construir uma representação com

$$k < r$$

dimensões.

Considere




Figura 17.2: Reconstrução espectral de uma configuração a partir das distâncias. A orientação pode mudar, mas as distâncias entre os objetos são preservadas.

$$\mathbf{G}_{\Delta} \succeq \mathbf{0}$$

com decomposição

$$\mathbf{G}_{\Delta} = \sum_{j=1}^r \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top},$$

em que

$$\lambda_1 \geq \dots \geq \lambda_r > 0.$$

A aproximação construída pelas primeiras k componentes espectrais é

$$\mathbf{G}_k = \sum_{j=1}^k \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top} = \mathbf{Q}_k \mathbf{D}_k \mathbf{Q}_k^{\top}, \quad (17.18)$$

com

$$\mathbf{Q}_k = (\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k)$$

e

$$\mathbf{D}_k = \text{diag}(\lambda_1, \dots, \lambda_k).$$

A configuração correspondente é

$$\mathbf{X}_{\text{MDS},k} = \mathbf{Q}_k \mathbf{D}_k^{1/2}. \quad (17.19)$$

Como $\mathbf{G}_\Delta$ é semidefinida positiva, seus valores singulares coincidem com seus autovalores não negativos. O resultado de Eckart–Young–Mirsky estabelecido em Teorema 6.2 implica que $\mathbf{G}_k$ é uma melhor aproximação de posto no máximo k de $\mathbf{G}_\Delta$, tanto na norma espectral quanto na norma de Frobenius.

Em particular,

$$\|\mathbf{G}_\Delta - \mathbf{G}_k\|_F^2 = \sum_{j=k+1}^r \lambda_j^2 \quad (17.20)$$

e

$$\|\mathbf{G}_\Delta - \mathbf{G}_k\|_2 = \lambda_{k+1}, \quad (17.21)$$

quando

$$k < r.$$

O resultado tem um significado específico no MDS clássico: a redução dimensional aproxima a **matriz de produtos internos reconstruída**.

17.4.5 Multiplicidade espectral e não unicidade

A redução dimensional exige distinguir a não unicidade dos eixos daquela que pode ocorrer na própria escolha do subespaço retido.

Se

$$\lambda_k > \lambda_{k+1},$$

o subespaço gerado pelas k primeiras direções espectrais é determinado de forma única. Mesmo nesse caso, uma base ortonormal dentro de um autoespaço associado a autovalores repetidos

pode ser modificada sem alterar o subespaço correspondente, e a configuração permanece não identificada quanto a transformações ortogonais.

Se, entretanto,

$$\lambda_k = \lambda_{k+1},$$

o corte ocorre no interior de um autoespaço associado a um autovalor de multiplicidade maior que um. Nesse caso, diferentes subespaços de dimensão k podem ser selecionados dentro desse autoespaço e produzir aproximações com o mesmo erro ótimo em norma de Frobenius.

Portanto, quando o corte ocorre no interior de um autoespaço associado a um autovalor repetido, a não unicidade pode atingir o próprio subespaço k -dimensional utilizado na representação reduzida, além da orientação de suas bases.

Essa situação é análoga à discutida na ACP para autovalores repetidos e decorre da mesma estrutura espectral.

As distâncias na configuração reduzida são

$$d_{ij}^{(k)} = \|\mathbf{x}_{i,k}^{(\text{MDS})} - \mathbf{x}_{j,k}^{(\text{MDS})}\|.$$

Em geral,

$$d_{ij}^{(k)} \neq \delta_{ij}$$

quando

$$k < r.$$

A aproximação espectral ótima da matriz de Gram não deve ser confundida com a minimização direta de uma função de discrepância definida sobre as distâncias originais. O critério otimizado em Equação 17.18 é matricial; outras formulações de MDS adotam funções objetivo diretamente baseadas nas distâncias. Essa distinção separa o MDS clássico espectral das formulações baseadas em *stress*.

A soma dos autovalores positivos é

$$\text{tr}(\mathbf{G}_\Delta) = \sum_{j=1}^r \lambda_j = \|\mathbf{X}_{\text{MDS}}\|_F^2. \quad (17.22)$$

Para uma configuração centralizada,

$$\text{tr}(\mathbf{G}_\Delta) = \sum_{i=1}^n \|\mathbf{x}_i^{(\text{MDS})}\|^2.$$

Essa quantidade corresponde à soma quadrática total da configuração em relação ao centroide.

A razão

$$\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^r \lambda_j} \quad (17.23)$$

descreve, no caso euclidiano, a parcela dessa soma quadrática representada pelas primeiras k coordenadas principais.

Essa é uma medida da representação espectral da geometria. Embora sua forma seja semelhante à proporção de variância explicada utilizada na ACP, sua interpretação deve permanecer vinculada ao objeto inicial do MDS: uma matriz de dissimilaridades.

17.4.6 Euclideanidade e autovalores negativos

A condição de Teorema 17.1 separa dois problemas diferentes que podem produzir perda de fidelidade na representação.

No primeiro,

$$\mathbf{G}_\Delta \succeq \mathbf{0},$$

mas sua dimensão exata é maior do que a dimensão escolhida para a representação. A discrepância decorre da **redução de dimensão**.

No segundo, $\mathbf{G}_\Delta$ possui pelo menos um autovalor negativo. Nesse caso, as dissimilaridades já não admitem uma representação euclidiana exata antes de qualquer redução dimensional.

Considere uma decomposição na qual existem autovalores positivos

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

eventuais autovalores nulos e autovalores negativos.

A presença de qualquer

$$\lambda_j < 0$$

impede escrever

$$\mathbf{G}_\Delta = \mathbf{X}\mathbf{X}^\top$$

para uma matriz real de coordenadas euclidianas, porque toda matriz da forma

$$\mathbf{X}\mathbf{X}^\top$$

é semidefinida positiva por Proposição 3.9.

Os autovalores negativos não representam dimensões euclidianas adicionais. Eles registram incompatibilidade entre a estrutura de dissimilaridades e a representação euclidiana procurada pelo MDS clássico.

A Tabela 17.4 distingue as duas situações.

Tabela 17.4: Diferença entre redução dimensional e não euclideanidade das dissimilaridades.

Situação	Estrutura espectral	Origem da discrepância
representação euclidiana exata	$\mathbf{G}_\Delta \succeq \mathbf{0}$ e todas as dimensões positivas são mantidas	não há discrepância
redução dimensional	$\mathbf{G}_\Delta \succeq \mathbf{0}$, mas apenas $k < r$ dimensões são mantidas	truncamento de uma configuração euclidiana
dissimilaridades não euclidianas	$\mathbf{G}_\Delta$ possui autovalores negativos	incompatibilidade anterior à redução dimensional

Uma configuração euclidiana aproximada pode ser construída utilizando somente a parte positiva da decomposição espectral,

$$\mathbf{G}_+ = \sum_{\lambda_j > 0} \lambda_j \mathbf{q}_j \mathbf{q}_j^\top. \quad (17.24)$$

As coordenadas correspondentes são

$$\mathbf{X}_+ = \mathbf{Q}_+ \mathbf{D}_+^{1/2}.$$

Entretanto,

$$\mathbf{G}_+ \neq \mathbf{G}_\Delta$$

quando existem autovalores negativos. Consequentemente, as distâncias produzidas por $\mathbf{X}_+$ não reproduzem exatamente as dissimilaridades originais.

Descartar os autovalores negativos não transforma a matriz original em uma representação euclidiana exata. A operação substitui a estrutura original por uma geometria euclidiana aproximada.

Considere, por exemplo,

$$\Delta = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 3 \\ 1 & 3 & 0 \end{pmatrix}.$$

A desigualdade triangular é violada, pois

$$3 > 1 + 1.$$

A dupla centralização fornece uma matriz de Gram com autovalores

$$4, 5, \quad 0, \quad -\frac{5}{6}.$$

O autovalor negativo confirma, pela condição de Teorema 17.1, que não existe uma configuração euclidiana cujas distâncias sejam exatamente

$$1, \quad 1, \quad 3$$

para os três pares.

A violação da desigualdade triangular já é suficiente, neste exemplo, para mostrar que essas três dissimilaridades não podem ser distâncias euclidianas. A análise espectral fornece a mesma incompatibilidade na forma exigida pela formulação geral do MDS clássico.

A interpretação dos autovalores deve, portanto, considerar seus sinais antes da escolha da dimensão. Autovalores positivos fornecem as dimensões disponíveis para uma representação euclidiana; autovalores nulos não acrescentam dimensão; autovalores negativos indicam que a matriz de dissimilaridades não pertence exatamente à classe de matrizes de distâncias euclidianas considerada pelo MDS clássico.

Procedimentos destinados a modificar dissimilaridades não euclidianas podem ser utilizados em aplicações específicas. Essas correções alteram a matriz de entrada e pertencem à etapa metodológica da análise. Neste capítulo, o ponto necessário é reconhecer a não euclideanidade e distingui-la da simples redução da dimensão.

O MDS clássico pode, assim, ser entendido como uma reconstrução espectral de uma geometria a partir de dissimilaridades. Quando essas dissimilaridades são as próprias distâncias euclidianas entre observações de uma matriz de dados, essa construção se relaciona diretamente com uma representação já obtida por outro caminho na Análise de Componentes Principais.

17.5 MDS clássico e Análise de Componentes Principais

O MDS clássico e a ACP podem produzir representações espectrais muito próximas, mas partem de objetos diferentes. A ACP utiliza uma matriz de dados, de covariâncias ou de correlações. O MDS clássico utiliza uma matriz de distâncias ou dissimilaridades. A relação entre as duas técnicas aparece quando as distâncias fornecidas ao MDS são calculadas a partir das próprias observações em uma geometria euclidiana.

Considere uma matriz de dados centralizada

$$\mathbf{X}_c \in \mathbb{R}^{n \times p},$$

com decomposição em valores singulares

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top, \quad (17.25)$$

em que

$$r = \text{posto}(\mathbf{X}_c).$$

Essa é a estrutura de SVD já utilizada na formulação da ACP. A relação entre a SVD e os espectros das matrizes de Gram foi estabelecida em Proposição 6.1.

Considere agora a matriz de distâncias euclidianas entre as linhas de $\mathbf{X}_c$. Como a matriz já está centralizada,

$$\mathbf{H}_n \mathbf{X}_c = \mathbf{X}_c.$$

A dupla centralização dessas distâncias recupera a matriz de Gram das observações:

$$\mathbf{G}_\Delta = \mathbf{X}_c \mathbf{X}_c^\top. \quad (17.26)$$

Substituindo Equação 17.25,

$$\begin{aligned}\mathbf{G}_\Delta &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.\end{aligned}\tag{17.27}$$

Assim, os autovalores positivos de $\mathbf{G}_\Delta$ são

$$d_1^2, \dots, d_r^2,$$

e os autovetores correspondentes podem ser escolhidos como as colunas de

$$\mathbf{U}_r.$$

Pela formulação do MDS clássico,

$$\mathbf{X}_{\text{MDS}} = \mathbf{U}_r \mathbf{D}_r.\tag{17.28}$$

Os escores das componentes principais foram definidos em Definição 14.2. Considerando as r direções associadas aos valores singulares positivos, sua matriz é

$$\mathbf{T}_r = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.\tag{17.29}$$

Logo, sob escolhas compatíveis das bases espectrais,

$$\mathbf{X}_{\text{MDS}} = \mathbf{T}_r.\tag{17.30}$$

Quando existem valores singulares repetidos, diferentes bases ortonormais podem ser escolhidas nos subespaços correspondentes. As configurações resultantes permanecem equivalentes por transformações ortogonais nesses subespaços e preservam as mesmas distâncias.

Proposição 17.2 (Relação entre MDS clássico e escores da ACP). *Quando a matriz de entrada do MDS clássico contém as distâncias euclidianas entre as linhas de uma matriz de dados centralizada, as coordenadas principais do MDS coincidem, até transformações ortogonais admissíveis, com os escores da ACP obtidos pela SVD dessa mesma matriz.*

A equivalência decorre do fato de que as duas técnicas chegam ao mesmo produto

$$\mathbf{X}_c \mathbf{X}_c^\top$$

por caminhos diferentes.

Na ACP, as coordenadas são construídas diretamente a partir da matriz de dados.

No MDS clássico, o mesmo produto é reconstruído a partir das distâncias pela dupla centralização.

A relação é resumida na Tabela 17.5.

Tabela 17.5: Relação entre a Análise de Componentes Principais e o MDS clássico.

Aspecto	ACP	MDS clássico
entrada	matriz de dados, covariâncias ou correlações	matriz de distâncias ou dissimilaridades
objeto espectral	covariância, correlação ou produtos cruzados	matriz de Gram reconstruída
informação priorizada	variabilidade das coordenadas	geometria entre os objetos
solução	componentes e escores	coordenadas principais
coincidência	quando a mesma geometria euclidiana das observações é utilizada	quando as distâncias derivam dessa mesma representação

A equivalência exige que as duas técnicas utilizem a mesma geometria de entrada. Se a ACP for realizada sobre variáveis padronizadas, as distâncias correspondentes devem ser calculadas entre as observações também padronizadas para que a relação anterior permaneça válida.

Se a ACP utiliza a matriz original centralizada e o MDS utiliza outra medida de dissimilaridade, os problemas deixam de ser equivalentes.

A diferença de interpretação também permanece. Na ACP, os eixos estão associados a combinações lineares das variáveis originais. No MDS, as coordenadas são construídas para representar relações entre objetos e não precisam corresponder a combinações diretamente interpretáveis das variáveis que eventualmente originaram as dissimilaridades.

O MDS clássico baseado em dupla centralização também é denominado **análise de coordenadas principais** em diversos contextos (Gower, 1966).

17.6 Formulações baseadas diretamente no ajuste das distâncias

O MDS clássico resolve o problema por reconstrução da matriz de Gram. Outras formulações definem a solução diretamente pela discrepância entre as distâncias produzidas por uma configuração e determinadas proximidades-alvo.

Considere novamente uma configuração

$$\mathbf{X}_{\text{MDS},k}$$

e suas distâncias

$$d_{ij} = d_{ij}(\mathbf{X}_{\text{MDS},k}).$$

Para formular o ajuste, é útil distinguir três quantidades.

Definição 17.3 (Dissimilaridade, disparidade e distância). No MDS baseado em ajuste de distâncias:

- δ_{ij} é a **dissimilaridade de entrada** entre os objetos i e j ;
- $\hat{\delta}_{ij}$ é a **disparidade**, isto é, o valor-alvo associado à dissimilaridade segundo a transformação admitida pela formulação;
- d_{ij} é a **distância configuracional** produzida pelas coordenadas da configuração.

A distinção é importante porque, em geral,

$$\delta_{ij}, \quad \hat{\delta}_{ij} \quad \text{e} \quad d_{ij}$$

não representam o mesmo objeto.

As disparidades podem ser escritas de modo geral como

$$\hat{\delta}_{ij} = f(\delta_{ij}), \tag{17.31}$$

em que as restrições impostas a f determinam quais características das dissimilaridades serão preservadas.

17.6.1 MDS métrico

No MDS métrico, as magnitudes das dissimilaridades possuem significado quantitativo para o ajuste. A transformação utilizada para obter as disparidades é especificada ou restringida de modo a preservar essa informação métrica.

Uma formulação geral considera pesos

$$w_{ij} \geq 0$$

e procura uma configuração que reduza

$$\sigma(\mathbf{X}_{\text{MDS},k}) = \sum_{i < j} w_{ij} [d_{ij} - \hat{\delta}_{ij}]^2. \quad (17.32)$$

A função em Equação 17.32 mede a discrepância quadrática entre as distâncias da configuração e as disparidades que constituem o alvo do ajuste.

Quando

$$w_{ij} = 1$$

para todos os pares, cada relação entre objetos recebe o mesmo peso.

Pesos diferentes permitem representar formulações em que determinadas proximidades contribuem de forma diferente para o critério. O desenvolvimento da escolha desses pesos pertence à etapa metodológica.

A formulação métrica baseada em *stress* e o MDS clássico não devem ser identificados como o mesmo problema de otimização.

No MDS clássico, a solução espectral aproxima ou reconstrói a matriz de Gram.

No ajuste métrico por Equação 17.32, o critério é definido diretamente sobre diferenças entre distâncias e disparidades.

As duas formulações podem produzir representações relacionadas, mas seus objetivos matemáticos não são idênticos.

17.6.2 MDS não métrico

No MDS não métrico, a informação principal está na **ordenação** das dissimilaridades, e não necessariamente em suas diferenças numéricas (Kruskal, 1964).

Se

$$\delta_{ij} < \delta_{rs},$$

as disparidades devem respeitar a mesma ordenação:

$$\hat{\delta}_{ij} \leq \hat{\delta}_{rs}. \quad (17.33)$$

Essa condição pode ser expressa restringindo a transformação

$$f$$

em Equação 17.31 a ser monótona não decrescente.

A monotonicidade permite modificar as diferenças numéricas entre as dissimilaridades sem inverter sua ordem.

O problema não consiste, em geral, em fixar primeiro uma transformação monótona e depois estimar apenas a configuração. A formulação envolve conjuntamente:

- uma configuração $\mathbf{X}_{\text{MDS},k}$;
- disparidades $\hat{\delta}_{ij}$ compatíveis com a ordenação das dissimilaridades.

Pode-se representar a estrutura do problema considerando o conjunto de disparidades admissíveis

$$\mathcal{M}(\Delta) = \left\{ \left(\hat{\delta}_{ij} \right)_{i < j} : \begin{array}{l} \text{existe } f : [0, \infty) \rightarrow [0, \infty) \text{ monótona não decrescente,} \\ \hat{\delta}_{ij} = f(\delta_{ij}), \quad i < j \end{array} \right\}.$$

Essa definição garante simultaneamente a não negatividade das disparidades e a preservação da ordenação das dissimilaridades. Na formulação adotada aqui, se

$$\delta_{ij} = \delta_{rs},$$

então

$$\hat{\delta}_{ij} = \hat{\delta}_{rs},$$

pois ambas as disparidades são obtidas pela mesma função f . Outras convenções para o tratamento de empates podem ser adotadas em formulações específicas e pertencem à etapa metodológica da técnica.

Uma formulação baseada na discrepância quadrática procura então reduzir

$$\sum_{i < j} w_{ij} \left[d_{ij}(\mathbf{X}_{\text{MDS},k}) - \hat{\delta}_{ij} \right]^2$$

em relação à configuração e às disparidades admissíveis,

$$\left(\hat{\delta}_{ij} \right)_{i < j} \in \mathcal{M}(\Delta).$$

Assim, configuração e disparidades participam conjuntamente do ajuste. Os procedimentos utilizados para realizar essa otimização e para obter as disparidades monotônicas pertencem à implementação da técnica e não serão desenvolvidos neste capítulo.

Por exemplo, considere

$$\delta_{12} = 1, \quad \delta_{13} = 2, \quad \delta_{14} = 10.$$

Uma formulação métrica trata a diferença entre 2 e 10 como informação quantitativa relevante.

Uma formulação não métrica preserva prioritariamente a relação

$$\delta_{12} < \delta_{13} < \delta_{14},$$

permitindo que as disparidades ajustadas assumam espaçamentos diferentes, desde que essa ordenação seja respeitada.

A Tabela 17.6 compara as duas formulações.

Tabela 17.6: Diferença entre formulações métricas e não métricas do MDS.

Aspecto	MDS métrico	MDS não métrico
informação principal	magnitude das dissimilaridades	ordenação das dissimilaridades
transformação f	especificada ou metricamente restringida	monótona não decrescente
alvo do ajuste	relações quantitativas entre dissimilaridades	relações ordinais entre dissimilaridades
configuração	distâncias próximas das disparidades	distâncias próximas de disparidades monotônicas
objetos ajustados	principalmente a configuração, dadas as disparidades especificadas pelo modelo	configuração e disparidades admissíveis sob a restrição ordinal
indeterminação de escala	depende da parametrização adotada	pode ocorrer quando apenas a ordem é relevante

O MDS não métrico não elimina a geometria euclidiana da configuração. Os pontos continuam sendo representados em

$$\mathbb{R}^k$$

e suas relações continuam sendo medidas por distâncias configuracionais. O que muda é a quantidade de informação exigida da matriz de dissimilaridades.

17.6.3 Função de *stress*

Uma função de *stress* mede a discrepância entre as distâncias produzidas pela configuração e as disparidades utilizadas como alvos do ajuste.

Para pesos

$$w_{ij} \geq 0$$

e uma configuração não degenerada tal que

$$\sum_{i < j} w_{ij} d_{ij}^2 > 0,$$

uma forma normalizada específica de *stress* é (Kruskal, 1964)

$$\text{Stress} = \sqrt{\frac{\sum_{i < j} w_{ij} (d_{ij} - \hat{\delta}_{ij})^2}{\sum_{i < j} w_{ij} d_{ij}^2}}. \quad (17.34)$$

Na expressão, a diferença

$$d_{ij} - \hat{\delta}_{ij}$$

mede a discrepância de cada par, w_{ij} determina sua contribuição para o critério e o denominador normaliza a discrepância pela escala global das distâncias configuracionais.

Valores menores de *stress* indicam maior proximidade, segundo essa definição, entre as distâncias da configuração e as disparidades.

No MDS métrico, as disparidades são determinadas pela relação quantitativa especificada para as dissimilaridades. No MDS não métrico, elas também participam do ajuste, sujeitas às restrições de monotonicidade.

A expressão em Equação 17.34 não constitui uma definição universal de *stress*. Diferentes formulações podem utilizar outras normalizações, outros pesos ou outras formas de relacionar dissimilaridades, disparidades e distâncias.

Consequentemente, valores de *stress* obtidos sob definições diferentes não são necessariamente comparáveis.

O papel da função neste capítulo é estabelecer a diferença entre uma representação espectral baseada na matriz de Gram e uma representação obtida pela minimização direta de discrepâncias entre proximidades.

Os critérios práticos utilizados para avaliar a magnitude do *stress*, escolher a dimensão ou comparar soluções pertencem à etapa aplicada da análise.

17.6.4 Representação métrica e ordinal

A diferença entre as duas formulações pode ser visualizada por meio da relação entre dissimilaridades e distâncias configuracionais.

Na representação métrica, espera-se que diferenças quantitativas entre as dissimilaridades sejam refletidas pelas distâncias.

Na representação não métrica, a condição principal é a preservação da ordem.

A Figura 17.3 apresenta essas duas situações de forma esquemática.




Figura 17.3: Relações entre dissimilaridades e distâncias em representações métrica e não métrica.

No painel métrico, a linha de referência representa igualdade entre dissimilaridades e distâncias. Os pontos permanecem próximos dessa relação quantitativa.

No painel não métrico, o traçado crescente representa a preservação da ordenação. A forma da relação pode ser não linear sem que a ordem dos pares seja invertida.

Essa representação é uma forma simplificada do tipo de relação visualizada em diagramas de Shepard. O diagnóstico detalhado desses diagramas será tratado posteriormente.

17.6.5 Indeterminações nas formulações baseadas em *stress*

As indeterminações por translação, rotação e reflexão permanecem nas formulações baseadas em *stress* sempre que o critério depende apenas das distâncias configuracionais.

Se

$$\mathbf{X}_{\text{MDS},k}^* = \mathbf{1}_n \mathbf{a}^\top + \mathbf{X}_{\text{MDS},k} \mathbf{O},$$

com

$$\mathbf{O}^\top \mathbf{O} = \mathbf{I}_k,$$

então as distâncias entre os pontos permanecem inalteradas.

Consequentemente, o valor de Equação 17.34 também permanece inalterado, desde que as mesmas disparidades sejam utilizadas.

A escala exige tratamento separado.

No MDS métrico, quando as disparidades possuem escala quantitativa fixada, multiplicar todas as coordenadas por uma constante altera as distâncias e, em geral, altera o ajuste.

No MDS não métrico, quando a formulação permite reescalar conjuntamente as distâncias e as disparidades sem alterar as restrições de ordem e a normalização do critério, a escala global da configuração não é identificada pelo *stress*.

Assim, as indeterminações da configuração dependem da informação que a formulação preserva: as transformações rígidas decorrem da utilização de distâncias, enquanto a possível indeterminação de escala no MDS não métrico decorre do caráter ordinal das proximidades e da forma adotada para o critério.

A identificação da configuração deve, portanto, ser interpretada em relação à formulação específica.

17.7 Dependência da representação

O MDS representa a geometria definida pela matriz de entrada e pelo critério utilizado para construir a configuração. A solução não deve, portanto, ser interpretada independentemente das dissimilaridades que lhe deram origem.

A Tabela 17.7 organiza os principais elementos dos quais a representação depende.

Tabela 17.7: Elementos que definem a representação produzida pelo MDS.

Elemento	Efeito sobre o problema
definição de δ_{ij}	determina quais relações entre objetos são consideradas próximas ou distantes
transformação das dissimilaridades	determina a informação quantitativa ou ordinal preservada
dimensão k	limita a complexidade geométrica da configuração
pesos w_{ij}	modificam a contribuição relativa dos pares no critério
critério de ajuste	define o significado de melhor representação
restrições geométricas	determinam a classe de configurações admissíveis

A escolha da dimensão faz parte da formulação sempre que se procura representar a estrutura em um espaço de dimensão inferior à necessária para sua reprodução exata.

No MDS clássico, quando

$$\mathbf{G}_{\Delta} \succeq \mathbf{0}$$

e

$$k < \text{posto}(\mathbf{G}_{\Delta}),$$

essa escolha determina o posto da aproximação espectral da matriz de Gram.

Nas formulações baseadas em *stress*, a dimensão determina o espaço

$$\mathbb{R}^k$$

no qual as coordenadas serão procuradas.

Em ambas as situações, modificar k modifica o problema de representação. Os procedimentos utilizados para escolher operacionalmente a dimensão serão tratados posteriormente.

A dependência em relação à matriz de entrada também deve ser enfatizada. Dois conjuntos de dissimilaridades construídos para os mesmos objetos podem produzir configurações diferentes se representarem conceitos diferentes de proximidade.

A configuração deve, portanto, ser interpretada como uma representação de

$$\Delta,$$

e não como uma geometria absoluta dos objetos.

17.8 Ausência de um modelo probabilístico universal

A formulação básica do MDS não exige que

$$\Delta$$

seja uma estatística proveniente de uma amostra aleatória multivariada. As dissimilaridades podem corresponder a medidas diretamente observadas, distâncias calculadas a partir de dados, avaliações de semelhança ou quantidades estimadas.

Quando

$$\Delta$$

é tratada como uma matriz fixa, a formulação é geométrica e descritiva. Se as dissimilaridades forem estimadas ou produzidas por um mecanismo aleatório, a configuração também passa a depender de quantidades aleatórias, mas sua distribuição amostral não decorre apenas das equações do MDS.

A inferência exige, nesse caso, um modelo probabilístico para o mecanismo que produz ou estima as dissimilaridades. Por isso, normalidade multivariada não constitui pressuposto geral da técnica.

A dupla centralização, a reconstrução da matriz de Gram, a solução espectral do MDS clássico, as coordenadas principais e as funções de *stress* podem ser definidas sem normalidade. Hipóteses distributivas pertencem às formulações probabilísticas específicas utilizadas para estudar a variabilidade das proximidades ou das configurações.

17.9 Relações com outras técnicas multivariadas

O Escalonamento Multidimensional compartilha objetos matemáticos com outras técnicas do Módulo 3, mas atribui a eles funções diferentes. A distinção entre as técnicas depende do problema resolvido, do objeto de entrada e do significado da representação construída.

A Tabela 17.8 sintetiza as relações mais próximas.

Tabela 17.8: Relações entre o MDS e outras técnicas multivariadas.

Técnica	Objeto de entrada relacionado	Estrutura construída
ACP	matriz de dados, covariâncias ou correlações	componentes e escores associados à variabilidade
Agrupamentos	matriz de dados ou dissimilaridades	partições ou hierarquias
MDS	matriz de dissimilaridades	configuração geométrica de objetos
Análise de Correspondência	tabela de contingência	configuração geométrica de perfis na métrica qui-quadrado

17.9.1 MDS e Análise de Agrupamentos

O capítulo anterior mostrou que uma matriz

$$\Delta = (\delta_{ij})$$

pode ser utilizada para construir grupos. No MDS, a mesma matriz pode servir para construir coordenadas.

A diferença está no objeto procurado.

Na Análise de Agrupamentos, uma solução pode assumir a forma de uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

ou de uma hierarquia de partições.

No MDS, procura-se uma configuração

$$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$$

cujas distâncias procurem representar as relações registradas em

$$\Delta.$$

Objetos próximos em uma configuração de MDS apresentam pequena distância segundo a geometria representada, mas essa proximidade não estabelece automaticamente a existência de um grupo.

A definição de grupo exige um critério adicional, como os desenvolvidos no capítulo de Análise de Agrupamentos.

De forma correspondente, uma partição obtida por agrupamento não fornece necessariamente uma representação geométrica de todas as relações entre os objetos. Ela resume essas relações segundo o critério utilizado para construir os grupos.

Assim, MDS e Agrupamentos podem utilizar a mesma informação de entrada e responder a perguntas diferentes.

17.9.2 MDS e ACP

A relação matemática entre MDS clássico e ACP foi estabelecida em Proposição [17.2](#).

Quando as dissimilaridades são as distâncias euclidianas entre as observações de uma mesma matriz de dados centralizada,

$$\mathbf{X}_c,$$

a dupla centralização recupera

$$\mathbf{G}_\Delta = \mathbf{X}_c \mathbf{X}_c^\top,$$

e as coordenadas principais do MDS coincidem, até as indeterminações ortogonais admissíveis, com os escores obtidos pela SVD dessa representação.

Essa equivalência não elimina a diferença entre os problemas.

A ACP começa com coordenadas das observações e procura direções que organizem sua variabilidade.

O MDS pode começar somente com relações entre pares de objetos e procura construir coordenadas que representem essas relações.

Além disso, na ACP as direções possuem relação explícita com as variáveis originais por meio dos vetores de coeficientes e das quantidades derivadas dessas variáveis. Em um MDS construído apenas a partir de uma matriz de dissimilaridades, essa informação pode não estar disponível.

Quando as dissimilaridades utilizadas no MDS não são as distâncias euclidianas da mesma representação utilizada na ACP, a equivalência estabelecida em Proposição 17.2 deixa de existir.

17.9.3 MDS e Análise de Correspondência

A Análise de Correspondência também produzirá coordenadas para representar relações em baixa dimensão, mas a origem da geometria será diferente.

No MDS, parte-se de uma matriz geral de dissimilaridades entre um conjunto de objetos.

Na Análise de Correspondência, o ponto de partida será uma tabela de contingência. Suas linhas e colunas serão transformadas em perfis, e a geometria será ponderada pelas massas associadas às categorias.

A distância relevante deixará de ser uma distância euclidiana ordinária aplicada diretamente às frequências e passará a envolver a métrica qui-quadrado dos perfis.

Também haverá uma diferença na estrutura da representação. No MDS, a configuração representa um conjunto de objetos definidos pela matriz de dissimilaridades. Na Análise de Correspondência, linhas e colunas da tabela participarão de uma representação dual obtida a partir de uma decomposição matricial ponderada.

As duas técnicas compartilham, portanto, a construção de coordenadas geométricas e o uso de decomposições espectrais ou singulares, mas representam objetos e métricas diferentes.

Essa relação prepara diretamente o capítulo seguinte.

17.10 Limites da interpretação geométrica

Uma configuração de MDS representa relações definidas pela matriz de dissimilaridades. Sua interpretação depende da forma como essas dissimilaridades foram construídas, da dimensão escolhida e do critério utilizado para obter a configuração.

Se dois objetos aparecem próximos, essa proximidade deve ser interpretada segundo o significado de

$$\delta_{ij}$$

e segundo a fidelidade da representação. Alterar a definição das dissimilaridades pode modificar a geometria mesmo quando os objetos permanecem os mesmos. A configuração representa, portanto, a estrutura de

$$\Delta,$$

e não uma geometria absoluta dos objetos.

As distâncias também não determinam uma orientação absoluta. Se

$$\mathbf{O}^\top \mathbf{O} = \mathbf{I}_k,$$

então

$$\mathbf{X}_{\text{MDS},k}$$

e

$$\mathbf{X}_{\text{MDS},k} \mathbf{O}$$

possuem as mesmas distâncias. Rotações e reflexões podem modificar as coordenadas sem alterar a geometria representada. Assim, os eixos não recebem significado substantivo automático. Sua interpretação exige informação adicional sobre os objetos ou sobre variáveis externas relacionadas à configuração.

A redução dimensional introduz outra limitação. Quando

$$\mathbf{G}_\Delta \succeq \mathbf{0}$$

e

$$k < \text{posto}(\mathbf{G}_\Delta),$$

a configuração de dimensão k aproxima uma geometria euclidiana que admite representação exata em dimensão maior. No MDS clássico, essa aproximação é realizada por uma matriz de Gram de posto reduzido; nas formulações baseadas em *stress*, a perda é medida pela discrepância entre distâncias configuracionais e disparidades.

Essa situação deve ser distinguida da não euclideanidade. Se

$$\mathbf{G}_\Delta$$

possui autovalores negativos, as dissimilaridades não admitem representação euclidiana exata na formulação clássica. No primeiro caso, a perda decorre do truncamento de uma geometria

euclidiana existente; no segundo, a própria matriz de entrada não corresponde exatamente a uma geometria euclidiana.

A configuração também não estabelece, por si só, a existência de grupos ou de observações atípicas. Regiões visualmente próximas ou separadas descrevem relações geométricas segundo a matriz de entrada. A definição de grupos exige um critério adicional, e a caracterização de uma observação como atípica exige uma referência estatística ou substantiva própria.

17.11 Síntese

O Escalonamento Multidimensional representa relações entre n objetos por uma configuração

$$\mathbf{X}_{\text{MDS},k} \in \mathbb{R}^{n \times k}$$

cujas distâncias procuram reproduzir uma matriz de dissimilaridades

$$\Delta = (\delta_{ij}).$$

No MDS clássico, a ligação entre distâncias e produtos internos permite reconstruir a matriz de Gram centralizada por

$$\mathbf{G}_{\Delta} = -\frac{1}{2}\mathbf{H}_n\Delta^{(2)}\mathbf{H}_n.$$

Quando

$$\mathbf{G}_{\Delta} \succeq \mathbf{0},$$

as dissimilaridades admitem representação euclidiana exata. Se

$$\mathbf{G}_{\Delta} = \mathbf{Q}_+\mathbf{D}_+\mathbf{Q}_+^{\top},$$

uma configuração correspondente é

$$\mathbf{X}_{\text{MDS}} = \mathbf{Q}_+\mathbf{D}_+^{1/2}.$$

A dimensão mínima da representação exata é o posto de

$$\mathbf{G}_{\Delta}.$$

Quando apenas k dimensões são retidas, a decomposição espectral fornece uma aproximação de posto reduzido da matriz de Gram. Se o corte espectral ocorre entre autovalores distintos, o subespaço retido é identificado; se ocorre no interior de uma multiplicidade, diferentes subespaços podem produzir o mesmo erro ótimo. Em qualquer caso, posição e orientação absolutas da configuração permanecem indeterminadas pelas distâncias.

Autovalores negativos de

$$\mathbf{G}_\Delta$$

possuem significado diferente da redução dimensional: indicam que as dissimilaridades não admitem representação euclidiana exata na formulação clássica.

Quando as dissimilaridades são distâncias euclidianas calculadas entre as linhas de uma matriz de dados centralizada, a dupla centralização recupera sua matriz de Gram e estabelece a relação entre o MDS clássico e os escores da ACP.

Nas formulações baseadas diretamente no ajuste das proximidades, distinguem-se a dissimilaridade observada

$$\delta_{ij},$$

a disparidade utilizada como alvo

$$\hat{\delta}_{ij}$$

e a distância configuracional

$$d_{ij}.$$

O MDS métrico preserva informação quantitativa segundo a transformação admitida, enquanto o MDS não métrico procura preservar principalmente a ordenação das dissimilaridades. Uma função de *stress* quantifica a discrepância entre a configuração e as disparidades segundo o critério adotado.

A formulação básica do MDS é geométrica e não exige normalidade multivariada. Quando as dissimilaridades são aleatórias ou estimadas, a inferência depende do modelo probabilístico utilizado para explicar sua geração.

A configuração deve ser interpretada pelas relações geométricas determinadas pela matriz de entrada. Os eixos não possuem significado substantivo automático, e a visualização de separações não define, por si só, grupos ou observações atípicas.

O capítulo integra distâncias, produtos internos, centralização, matrizes de Gram, decomposição espectral e aproximações de posto reduzido para resolver um problema de reconstrução geométrica.

No próximo capítulo, o objeto de entrada passa a ser uma tabela de contingência. A Análise de Correspondência construirá uma geometria ponderada para os perfis de linhas e colunas a partir dos desvios em relação à independência e da métrica qui-quadrado.

18 Formulação da Análise de Correspondência

A Análise de Correspondência representa geometricamente a associação entre as categorias de duas variáveis qualitativas a partir de uma tabela de contingência. A técnica compara os perfis observados com a estrutura correspondente à independência em uma geometria ponderada pelas frequências marginais (Greenacre, 2017).

Os desvios da independência são padronizados pelas massas e organizados em uma matriz cuja SVD fornece as dimensões da associação, suas inércias e as coordenadas das categorias de linhas e colunas.

O capítulo desenvolve a formulação matemática e estatística da Análise de Correspondência simples. Critérios operacionais de escolha da dimensão, interpretação aplicada de mapas, categorias suplementares, implementação computacional e extensões serão tratados posteriormente.

Os elementos da formulação são organizados na Tabela 18.1.

Tabela 18.1: Elementos da formulação da Análise de Correspondência.

Elemento	Objeto	Papel na análise
dados observados	tabela de contingência $\mathbf{N}$	registra as frequências conjuntas
distribuição observada	matriz $\mathbf{P}$	expressa frequências relativas
pesos marginais	massas $\mathbf{r}$ e $\mathbf{c}$	determinam a importância relativa das categorias
representação interna	perfis de linhas e de colunas	descreve distribuições condicionais observadas
referência	independência	fornece a estrutura sem associação
geometria	distância qui-quadrado	compara perfis com ponderação pelas massas
estrutura matricial	desvios padronizados $\mathbf{Q}_{CA}$	reúne os desvios da independência
solução	SVD de $\mathbf{Q}_{CA}$	produz inércias e coordenadas

18.1 O problema de associação em uma tabela de contingência

Considere duas variáveis qualitativas, uma com I categorias e outra com J categorias. As frequências observadas são organizadas na tabela

$$\mathbf{N} = (n_{ij}) \in \mathbb{R}^{I \times J},$$

em que

$$n_{ij} \geq 0$$

representa a frequência conjunta observada da categoria i da variável das linhas com a categoria j da variável das colunas.

O total observado é

$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}, \quad n > 0. \quad (18.1)$$

A condição $n > 0$ permite definir a matriz de frequências relativas observadas

$$\mathbf{P} = \frac{1}{n} \mathbf{N} = (p_{ij}) \in \mathbb{R}^{I \times J}. \quad (18.2)$$

Assim,

$$p_{ij} = \frac{n_{ij}}{n} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

A matriz $\mathbf{P}$ descreve a **distribuição relativa observada** na tabela. Neste desenvolvimento geométrico, $\mathbf{P}$ é construída diretamente a partir das frequências observadas. Uma distribuição conjunta populacional será introduzida somente quando o modelo probabilístico para a tabela for considerado na seção inferencial.

A análise procura determinar como $\mathbf{P}$ se afasta da estrutura correspondente à independência e representar esse afastamento em poucas dimensões.

A tabela possui duas leituras complementares. Comparando as linhas, investigam-se diferenças entre as distribuições das categorias das colunas condicionadas a cada linha. Comparando as colunas, investigam-se diferenças entre as distribuições das categorias das linhas condicionadas a cada coluna.

18.2 Frequências marginais, massas e perfis

Defina os vetores de frequências relativas marginais observadas por

$$\mathbf{r} = \mathbf{P}\mathbf{1}_J = \begin{pmatrix} r_1 \\ \vdots \\ r_I \end{pmatrix} \in \mathbb{R}^I \quad (18.3)$$

e

$$\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I = \begin{pmatrix} c_1 \\ \vdots \\ c_J \end{pmatrix} \in \mathbb{R}^J. \quad (18.4)$$

Cada elemento satisfaz

$$r_i = \sum_{j=1}^J p_{ij}, \quad i = 1, \dots, I,$$

e

$$c_j = \sum_{i=1}^I p_{ij}, \quad j = 1, \dots, J.$$

Como $\mathbf{P}$ possui soma total igual a 1,

$$\mathbf{1}_I^\top \mathbf{r} = 1$$

e

$$\mathbf{1}_J^\top \mathbf{c} = 1.$$

Definição 18.1 (Massas de linhas e colunas). Considere uma matriz de frequências relativas

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J},$$

com

$$p_{ij} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

As **massas das linhas** são as frequências relativas marginais

$$r_i = \sum_{j=1}^J p_{ij}, \quad i = 1, \dots, I,$$

e as **massas das colunas** são

$$c_j = \sum_{i=1}^I p_{ij}, \quad j = 1, \dots, J.$$

Em forma vetorial,

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \in \mathbb{R}^I$$

e

$$\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I \in \mathbb{R}^J.$$

As matrizes diagonais associadas são

$$\mathbf{D}_r = \text{diag}(r_1, \dots, r_I) \in \mathbb{R}^{I \times I}$$

e

$$\mathbf{D}_c = \text{diag}(c_1, \dots, c_J) \in \mathbb{R}^{J \times J}.$$

A definição de massa permite valores nulos. Entretanto, a geometria da Análise de Correspondência utiliza divisões pelas massas e as matrizes

$$\mathbf{D}_r^{-1}, \quad \mathbf{D}_c^{-1}, \quad \mathbf{D}_r^{-1/2} \quad \text{e} \quad \mathbf{D}_c^{-1/2}.$$

Por isso, no desenvolvimento da análise ativa considera-se

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J. \quad (18.5)$$

Categorias de massa nula não participam da geometria ativa porque seus perfis não estão definidos. O tratamento dessas categorias será retomado nos limites da representação.

18.2.1 Distribuições condicionais observadas

A Análise de Correspondência compara distribuições condicionais observadas, denominadas perfis.

Definição 18.2 (Perfis de linhas e de colunas). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas com massas de linhas e colunas dadas por Definição 18.1.

Para uma linha i com

$$r_i > 0,$$

o **perfil da linha** i é

$$\mathbf{p}_{i\cdot} = \begin{pmatrix} \frac{p_{i1}}{r_i} \\ \vdots \\ \frac{p_{iJ}}{r_i} \end{pmatrix} \in \mathbb{R}^J. \quad (18.6)$$

Para uma coluna j com

$$c_j > 0,$$

o perfil da coluna j é

$$\mathbf{p}_{\cdot|j} = \begin{pmatrix} \frac{p_{1j}}{c_j} \\ \vdots \\ \frac{p_{Ij}}{c_j} \end{pmatrix} \in \mathbb{R}^I. \quad (18.7)$$

Cada perfil possui soma unitária:

$$\mathbf{1}_J^\top \mathbf{p}_{i|\cdot} = 1$$

e

$$\mathbf{1}_I^\top \mathbf{p}_{\cdot|j} = 1.$$

Sob Equação 18.5, os perfis de linhas podem ser reunidos na matriz

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}, \quad (18.8)$$

enquanto os perfis de colunas são organizados em

$$\mathbf{P}^{(c)} = \mathbf{D}_c^{-1} \mathbf{P}^\top \in \mathbb{R}^{J \times I}. \quad (18.9)$$

O perfil médio das linhas, ponderado pelas massas r_i , é

$$\sum_{i=1}^I r_i \mathbf{p}_{i|\cdot} = \mathbf{c}, \quad (18.10)$$

pois, para cada componente j ,

$$\sum_{i=1}^I r_i \frac{p_{ij}}{r_i} = \sum_{i=1}^I p_{ij} = c_j.$$

De forma dual,

$$\sum_{j=1}^J c_j \mathbf{p}_{\cdot|j} = \mathbf{r}. \quad (18.11)$$

Assim, $\mathbf{c}$ é o centro ponderado da nuvem dos perfis de linhas e $\mathbf{r}$ é o centro ponderado da nuvem dos perfis de colunas.

18.2.2 Independência como referência

Para a distribuição relativa observada, a estrutura de independência associada às marginais $\mathbf{r}$ e $\mathbf{c}$ é

$$p_{ij} = r_i c_j, \quad (18.12)$$

ou, em forma matricial,

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top. \quad (18.13)$$

Nesse caso, como as massas ativas são positivas,

$$\frac{p_{ij}}{r_i} = c_j,$$

de modo que

$$\mathbf{p}_{i| \cdot} = \mathbf{c}$$

para todas as linhas.

Analogamente,

$$\frac{p_{ij}}{c_j} = r_i,$$

e todos os perfis de colunas coincidem com

$$\mathbf{r}.$$

A independência corresponde, portanto, ao colapso de cada nuvem de perfis em seu respectivo centro.

Quando

$$\mathbf{P} \neq \mathbf{r}\mathbf{c}^\top,$$

as diferenças

$$p_{ij} - r_i c_j$$

representam os desvios observados em relação à estrutura de independência.

Esses desvios ainda não levam em conta a importância relativa das marginais. A geometria da Análise de Correspondência surge ao ponderá-los pelas massas das categorias.

18.3 Geometria dos perfis

A Análise de Correspondência compara os perfis utilizando uma geometria ponderada pelas massas marginais.

No Módulo 1, o produto interno induzido e sua norma foram definidos em Definição 3.16 e Definição 3.17. Sob Equação 18.5,

$$\mathbf{D}_c^{-1}$$

e

$$\mathbf{D}_r^{-1}$$

são matrizes diagonais positivas definidas e, portanto, definem produtos internos nos espaços de perfis de linhas e de colunas.

Essa estrutura conduz à distância qui-quadrado.

Definição 18.3 (Distância qui-quadrado entre perfis). Considere uma matriz

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

de frequências relativas cujas massas satisfazem

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J.$$

Se

$$\mathbf{p}_{i|\cdot}, \mathbf{p}_{i'|\cdot} \in \mathbb{R}^J$$

são dois perfis de linhas, sua **distância qui-quadrado** é definida por

$$d_{\chi^2}^2(i, i') = \left(\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot} \right)^\top \mathbf{D}_c^{-1} \left(\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot} \right). \quad (18.14)$$

Equivalentemente,

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^J \frac{1}{c_j} \left(\frac{p_{ij}}{r_i} - \frac{p_{i'j}}{r_{i'}} \right)^2.$$

Se

$$\mathbf{p}_{\cdot|j}, \mathbf{p}_{\cdot|j'} \in \mathbb{R}^I$$

são dois perfis de colunas, sua distância qui-quadrado é

$$d_{\chi^2}^2(j, j') = \left(\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'} \right)^\top \mathbf{D}_r^{-1} \left(\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'} \right). \quad (18.15)$$

Equivalentemente,

$$d_{\chi^2}^2(j, j') = \sum_{i=1}^I \frac{1}{r_i} \left(\frac{p_{ij}}{c_j} - \frac{p_{ij'}}{c_{j'}} \right)^2.$$

A distância qui-quadrado é, portanto, uma distância euclidiana em coordenadas reescaladas pelas massas. Para as linhas,

$$d_{\chi^2}(i, i') = \left\| \mathbf{D}_c^{-1/2} \left(\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot} \right) \right\|,$$

e, para as colunas,

$$d_{\chi^2}(j, j') = \left\| \mathbf{D}_r^{-1/2} \left(\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'} \right) \right\|.$$

As ponderações

$$\frac{1}{c_j}$$

e

$$\frac{1}{r_i}$$

fazem com que uma mesma diferença absoluta entre perfis tenha peso maior quando ocorre em uma categoria de menor massa.

A distância de uma linha ao centro da nuvem é

$$d_{\chi^2}^2(i, \mathbf{c}) = \left(\mathbf{p}_{i\cdot} - \mathbf{c} \right)^\top \mathbf{D}_c^{-1} \left(\mathbf{p}_{i\cdot} - \mathbf{c} \right), \quad (18.16)$$

ou, utilizando

$$\frac{p_{ij}}{r_i} - c_j = \frac{p_{ij} - r_i c_j}{r_i},$$

tem-se

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i^2 c_j}. \quad (18.17)$$

De forma dual,

$$d_{\chi^2}^2(j, \mathbf{r}) = \sum_{i=1}^I \frac{(p_{ij} - r_i c_j)^2}{c_j^2 r_i}. \quad (18.18)$$

18.4 Inércia e afastamento da independência

Definição 18.4 (Inércia total). Considere uma matriz de frequências relativas

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

com todas as massas de linhas e colunas estritamente positivas.

A **inércia total** da tabela é a dispersão qui-quadrado ponderada dos perfis de linhas em torno de seu centro $\mathbf{c}$:

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}). \quad (18.19)$$

Substituindo Equação 18.17 em Equação 18.19,

$$\begin{aligned} \mathcal{J} &= \sum_{i=1}^I r_i \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i^2 c_j} \\ &= \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \end{aligned} \quad (18.20)$$

Utilizando a formulação dual em Equação 18.18,

$$\begin{aligned} \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}) &= \sum_{j=1}^J c_j \sum_{i=1}^I \frac{(p_{ij} - r_i c_j)^2}{c_j^2 r_i} \\ &= \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} \\ &= \mathcal{J}. \end{aligned}$$

Portanto,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}). \quad (18.21)$$

Sob massas positivas, cada termo de Equação 18.20 é não negativo. Consequentemente,

$$\mathcal{J} = 0$$

se, e somente se,

$$p_{ij} = r_i c_j$$

para todo

$$i = 1, \dots, I \quad \text{e} \quad j = 1, \dots, J,$$

isto é,

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top.$$

A inércia total quantifica, portanto, o afastamento global da distribuição observada em relação à estrutura de independência na geometria qui-quadrado.

18.5 Padronização dos desvios da independência

A expressão de Equação 18.20 sugere reunir os desvios

$$p_{ij} - r_i c_j$$

em uma única matriz, padronizando-os pelas massas correspondentes.

Definição 18.5 (Matriz de desvios padronizados). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas cujas massas

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

são estritamente positivas.

A matriz de desvios padronizados da Análise de Correspondência é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2} \in \mathbb{R}^{I \times J}. \quad (18.22)$$

Seu elemento (i, j) é

$$q_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}. \quad (18.23)$$

A matriz $\mathbf{Q}_{\text{CA}}$ representa, em coordenadas ponderadas, os desvios da distribuição observada em relação à independência.

Ela também possui restrições lineares decorrentes das próprias marginais. Como

$$\mathbf{P}\mathbf{1}_J = \mathbf{r}$$

e

$$\mathbf{c}^\top \mathbf{1}_J = 1,$$

segue que

$$\begin{aligned} \mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J &= \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{1}_J \\ &= \mathbf{D}_r^{-1/2} (\mathbf{r} - \mathbf{r}) \\ &= \mathbf{0}. \end{aligned} \quad (18.24)$$

Analogamente,

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}. \quad (18.25)$$

Como

$$\mathbf{D}_c^{1/2} \mathbf{1}_J \neq \mathbf{0}$$

e

$$\mathbf{D}_r^{1/2} \mathbf{1}_I \neq \mathbf{0}$$

sob massas positivas, $\mathbf{Q}_{\text{CA}}$ possui um vetor não nulo em seu núcleo à direita e um vetor não nulo no núcleo de sua transposta. Portanto,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq J - 1$$

e

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq I - 1.$$

Consequentemente,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1). \quad (18.26)$$

Essa restrição explica por que a Análise de Correspondência possui, no máximo,

$$\min(I - 1, J - 1)$$

dimensões não nulas.

18.5.1 Inércia como norma matricial

Pela norma de Frobenius definida em Definição 6.7,

$$\begin{aligned} \|\mathbf{Q}_{\text{CA}}\|_F^2 &= \sum_{i=1}^I \sum_{j=1}^J q_{ij}^2 \\ &= \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \end{aligned}$$

Comparando com Equação 18.20,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2. \quad (18.27)$$

Proposição 18.1 (Formas equivalentes da inércia). *Considere uma matriz de frequências relativas*

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

com massas

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J.$$

Se $\mathcal{J}$ é a inércia total de Definição 18.4 e $\mathbf{Q}_{\text{CA}}$ é a matriz de desvios padronizados de Definição 18.5, então

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c})$$

e, equivalentemente,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}),$$

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}$$

e

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

As equivalências foram obtidas diretamente de Equação 18.17, Equação 18.18 e da definição da norma de Frobenius. A inércia possui, portanto, três leituras compatíveis:

- dispersão da nuvem dos perfis de linhas;
- dispersão da nuvem dos perfis de colunas;
- magnitude matricial dos desvios padronizados da independência.

Essas não são três medidas diferentes. São três representações do mesmo afastamento da independência.

18.6 Relação algébrica com a estatística qui-quadrado

Para a tabela observada, a estatística de Pearson calculada a partir das frequências marginais é

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - nr_i c_j)^2}{nr_i c_j}. \quad (18.28)$$

Como

$$n_{ij} = np_{ij},$$

tem-se

$$\begin{aligned}\chi^2 &= \sum_{i=1}^I \sum_{j=1}^J \frac{n^2(p_{ij} - r_i c_j)^2}{nr_i c_j} \\ &= n \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}.\end{aligned}$$

Por Equação 18.20,

$$\chi^2 = n\mathcal{J}. \quad (18.29)$$

A identidade

$$\chi^2 = n\mathcal{J}$$

é **algébrica e exata para a tabela observada**. Ela não depende de normalidade multivariada nem, por si só, de uma aproximação assintótica.

Sua interpretação como estatística de teste exige um modelo probabilístico para a geração da tabela e será retomada na seção de formulação inferencial. A distinção é importante: a inércia e a identidade acima pertencem à estrutura descritiva e geométrica da Análise de Correspondência; a distribuição de referência de χ^2 pertence à inferência.

18.7 Formulação pela decomposição em valores singulares

A matriz de desvios padronizados

$$\mathbf{Q}_{CA} \in \mathbb{R}^{I \times J}$$

é, em geral, retangular. Sua decomposição utiliza diretamente a SVD desenvolvida no Módulo 1.

Defina

$$K = \text{posto}(\mathbf{Q}_{CA}).$$

Por Equação 18.26,

$$0 \leq K \leq \min(I - 1, J - 1).$$

Se

$$K = 0,$$

então

$$\mathbf{Q}_{\text{CA}} = \mathbf{0},$$

e, por Proposição 18.1,

$$\mathcal{J} = 0.$$

Nesse caso, a distribuição relativa observada coincide com a estrutura de independência,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top,$$

e não existem dimensões não nulas de associação a decompor.

Considere, portanto, no restante desta seção,

$$K \geq 1.$$

Pela SVD compacta de Definição 6.4,

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top, \tag{18.30}$$

com

$$\mathbf{U} \in \mathbb{R}^{I \times K}, \quad \mathbf{D} \in \mathbb{R}^{K \times K}, \quad \mathbf{V} \in \mathbb{R}^{J \times K},$$

satisfazendo

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_K,$$

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_K$$

e

$$\mathbf{D} = \text{diag}(d_1, \dots, d_K),$$

em que

$$d_1 \geq d_2 \geq \dots \geq d_K > 0.$$

Os vetores singulares à esquerda descrevem direções no espaço ponderado das categorias das linhas, enquanto os vetores singulares à direita descrevem as direções correspondentes no espaço ponderado das categorias das colunas.

A SVD acopla essas duas representações por meio dos mesmos valores singulares.

18.7.1 Decomposição da inércia

Definição 18.6 (Inércia principal). Considere a SVD compacta

$$\mathbf{Q}_{CA} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

de uma matriz de desvios padronizados com posto

$$K \geq 1,$$

em que

$$\mathbf{D} = \text{diag}(d_1, \dots, d_K)$$

e

$$d_\ell > 0, \quad \ell = 1, \dots, K.$$

A inércia principal da dimensão ℓ é

$$\lambda_\ell = d_\ell^2, \quad \ell = 1, \dots, K. \tag{18.31}$$

Pela relação entre a norma de Frobenius e os valores singulares estabelecida em Proposição 6.9,

$$\|\mathbf{Q}_{\text{CA}}\|_F^2 = \sum_{\ell=1}^K d_\ell^2.$$

Como

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2$$

por Equação 18.27, segue que

$$\mathcal{J} = \sum_{\ell=1}^K \lambda_\ell. \quad (18.32)$$

A SVD decompõe, portanto, a inércia total em parcelas não negativas associadas às diferentes dimensões da associação.

Utilizando a identidade exata

$$\chi^2 = n\mathcal{J}$$

de Equação 18.29,

$$\chi^2 = n \sum_{\ell=1}^K \lambda_\ell. \quad (18.33)$$

Essa igualdade continua sendo uma decomposição algébrica da estatística observada. A distribuição inferencial de χ^2 será considerada posteriormente e não é necessária para definir as inércias principais.

Como

$$\lambda_\ell > 0,$$

a proporção da inércia associada à dimensão ℓ é

$$\frac{\lambda_\ell}{\sum_{h=1}^K \lambda_h}. \quad (18.34)$$

Para

$$1 \leq k \leq K,$$

a proporção acumulada da inércia representada pelas primeiras k dimensões é

$$\frac{\sum_{\ell=1}^k \lambda_{\ell}}{\sum_{\ell=1}^K \lambda_{\ell}}. \quad (18.35)$$

Essas proporções descrevem a decomposição da **inércia qui-quadrado**. Embora a expressão seja formalmente semelhante à proporção de variância explicada da ACP, o objeto decomposto é diferente: na Análise de Correspondência, decompõem-se os desvios padronizados da independência.

18.7.2 Representação em dimensão reduzida

Considere

$$1 \leq k < K.$$

Defina

$$\mathbf{U}_k = (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k) \in \mathbb{R}^{I \times k},$$

$$\mathbf{V}_k = (\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_k) \in \mathbb{R}^{J \times k}$$

e

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}.$$

A SVD truncada é

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^{\top}. \quad (18.36)$$

Pelo Teorema de Eckart–Young–Mirsky em Teorema 6.2,

$$\mathbf{Q}_{\text{CA},k}$$

é uma melhor aproximação de posto no máximo k de

$$\mathbf{Q}_{CA}$$

em norma de Frobenius.

O erro quadrático de aproximação é

$$\begin{aligned}\|\mathbf{Q}_{CA} - \mathbf{Q}_{CA,k}\|_F^2 &= \sum_{\ell=k+1}^K d_\ell^2 \\ &= \sum_{\ell=k+1}^K \lambda_\ell.\end{aligned}\tag{18.37}$$

A quantidade

$$\mathcal{J}_k = \sum_{\ell=1}^k \lambda_\ell\tag{18.38}$$

é a parcela da inércia total representada pelas primeiras k dimensões.

Consequentemente,

$$\mathcal{J} = \mathcal{J}_k + \sum_{\ell=k+1}^K \lambda_\ell.$$

O resultado de posto reduzido deve ser interpretado em relação ao objeto efetivamente decomposto. Na Análise de Correspondência, a SVD truncada fornece uma aproximação ótima, em norma de Frobenius, da **matriz ponderada de desvios da independência**.

Ela não corresponde à aproximação da tabela de frequências brutas segundo uma distância euclidiana ordinária.

18.7.3 Multiplicidade dos valores singulares e não unicidade

A SVD também exige distinguir a unicidade da aproximação de posto reduzido da escolha das bases utilizadas para representá-la.

Se

$$d_k > d_{k+1},$$

a melhor aproximação de posto no máximo k fornecida pelo truncamento é única como matriz. Se, entretanto,

$$d_k = d_{k+1},$$

o corte ocorre no interior de um subespaço singular associado a um valor singular repetido. Nesse caso, podem existir diferentes aproximações de posto k com o mesmo erro mínimo.

Portanto, quando a fronteira do truncamento atravessa uma multiplicidade, o subespaço retido pode não ser identificado unicamente.

Há ainda outra forma de não unicidade. Se um valor singular repetido está inteiramente contido entre as dimensões mantidas, diferentes bases ortonormais podem ser escolhidas no subespaço singular correspondente. As matrizes de vetores singulares mudam, mas a estrutura representada permanece a mesma.

Em particular, dentro de um bloco associado ao mesmo valor singular, pode-se realizar uma transformação ortogonal compatível nos vetores singulares à esquerda e à direita sem modificar

$$\mathbf{Q}_{CA}.$$

Essa indeterminação será refletida na orientação das coordenadas da Análise de Correspondência e deve ser distinguida da perda de informação produzida pelo truncamento.

18.8 Coordenadas da Análise de Correspondência

A SVD é realizada sobre uma matriz em que os desvios da independência já foram ponderados pelas massas das categorias. As coordenadas da Análise de Correspondência transformam os vetores singulares novamente para os espaços dos perfis de linhas e de colunas.

Duas escalas serão importantes: coordenadas padrão e coordenadas principais.

18.8.1 Sistema de coordenadas padrão

Definição 18.7 (Coordenadas padrão). Considere uma tabela de frequências relativas

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

com massas de linhas e colunas estritamente positivas e seja

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$$

sua SVD compacta, com

$$K = \text{posto}(\mathbf{Q}_{\text{CA}}) \geq 1.$$

As **coordenadas padrão das linhas** são as linhas da matriz

$$\mathbf{A}_r = \mathbf{D}_r^{-1/2}\mathbf{U} \in \mathbb{R}^{I \times K}, \quad (18.39)$$

e as **coordenadas padrão das colunas** são as linhas de

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2}\mathbf{V} \in \mathbb{R}^{J \times K}. \quad (18.40)$$

Como

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_K,$$

tem-se

$$\begin{aligned} \mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r &= \mathbf{U}^\top \mathbf{D}_r^{-1/2} \mathbf{D}_r \mathbf{D}_r^{-1/2} \mathbf{U} \\ &= \mathbf{U}^\top \mathbf{U} \\ &= \mathbf{I}_K. \end{aligned} \quad (18.41)$$

Da mesma forma,

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_K. \quad (18.42)$$

As colunas das coordenadas padrão são, portanto, ortonormais segundo os produtos internos ponderados pelas massas.

18.8.2 Sistema de coordenadas principais

Definição 18.8 (Coordenadas principais). Sob as mesmas condições de Definição 18.7, sejam

$$\mathbf{A}_r \in \mathbb{R}^{I \times K}$$

e

$$\mathbf{A}_c \in \mathbb{R}^{J \times K}$$

as coordenadas padrão, e seja

$$\mathbf{D} = \text{diag}(d_1, \dots, d_K)$$

a matriz dos valores singulares positivos.

As **coordenadas principais das linhas** são

$$\mathbf{F}_r = \mathbf{A}_r \mathbf{D} = \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D} \in \mathbb{R}^{I \times K}, \quad (18.43)$$

e as **coordenadas principais das colunas** são

$$\mathbf{F}_c = \mathbf{A}_c \mathbf{D} = \mathbf{D}_c^{-1/2} \mathbf{V} \mathbf{D} \in \mathbb{R}^{J \times K}. \quad (18.44)$$

As coordenadas principais incorporam os valores singulares e, portanto, a magnitude da associação representada em cada dimensão.

Para as linhas,

$$\begin{aligned} \mathbf{F}_r^\top \mathbf{D}_r \mathbf{F}_r &= \mathbf{D} \mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r \mathbf{D} \\ &= \mathbf{D}^2. \end{aligned} \quad (18.45)$$

Se

$$f_{i\ell}^{(r)}$$

denota a coordenada principal da linha i na dimensão ℓ , então o elemento diagonal ℓ da igualdade anterior fornece

$$\sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = d_\ell^2 = \lambda_\ell. \quad (18.46)$$

Analogamente,

$$\mathbf{F}_c^\top \mathbf{D}_c \mathbf{F}_c = \mathbf{D}^2 \quad (18.47)$$

e, se

$$f_{j\ell}^{(c)}$$

denota a coordenada principal da coluna j na dimensão ℓ ,

$$\sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2 = d_\ell^2 = \lambda_\ell. \quad (18.48)$$

Cada inércia principal possui, portanto, uma representação dual:

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2.$$

A mesma dimensão singular descreve simultaneamente a dispersão ponderada das coordenadas das linhas e a dispersão ponderada das coordenadas das colunas.

Essa dualidade não significa que os pontos de linhas e colunas pertençam originalmente ao mesmo espaço de perfis. As linhas são perfis em

$$\mathbb{R}^J,$$

enquanto as colunas são perfis em

$$\mathbb{R}^I.$$

A SVD fornece dimensões acopladas que permitem representar as duas nuvens segundo a mesma estrutura de associação.

18.8.3 Distâncias entre perfis e coordenadas principais

As coordenadas principais preservam exatamente a geometria qui-quadrado quando todas as

$$K$$

dimensões associadas aos valores singulares positivos são mantidas.

Considere a matriz dos perfis de linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}.$$

Como

$$\mathbf{P} = \mathbf{D}_r \mathbf{P}^{(r)},$$

e

$$\mathbf{r} = \mathbf{D}_r \mathbf{1}_I,$$

tem-se

$$\mathbf{P} - \mathbf{r} \mathbf{c}^\top = \mathbf{D}_r (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top).$$

Logo,

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{1/2} (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2}. \quad (18.49)$$

Multiplicando à esquerda por

$$\mathbf{D}_r^{-1/2},$$

obtém-se

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{D}_r^{-1/2} \mathbf{Q}_{\text{CA}}.$$

Substituindo a SVD de Equação [18.30](#),

$$\begin{aligned} (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} &= \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D} \mathbf{V}^\top \\ &= \mathbf{F}_r \mathbf{V}^\top. \end{aligned} \quad (18.50)$$

A linha i da matriz à esquerda é

$$(\mathbf{p}_{i|\cdot} - \mathbf{c})^\top \mathbf{D}_c^{-1/2},$$

isto é, o perfil da linha i centralizado em torno do perfil médio e expresso na geometria qui-quadrado.

Para duas linhas i e i' , a diferença entre essas representações é

$$(\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1/2}.$$

Sua norma euclidiana quadrática é

$$\begin{aligned} &(\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}) \\ &= d_{\chi^2}^2(i, i'). \end{aligned}$$

Por Equação 18.50, a mesma diferença pode ser escrita como

$$(\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)})^\top \mathbf{V}^\top,$$

em que

$$\mathbf{f}_i^{(r)} \in \mathbb{R}^K$$

é a linha i de $\mathbf{F}_r$.

Como

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_K,$$

a transformação por $\mathbf{V}^\top$ preserva a norma dos vetores pertencentes ao espaço gerado pelas colunas de $\mathbf{V}$. Portanto,

$$d_{\chi^2}^2(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|^2. \quad (18.51)$$

De forma dual, se

$$\mathbf{f}_j^{(c)} \in \mathbb{R}^K$$

é a linha j de $\mathbf{F}_c$, então

$$d_{\chi^2}^2(j, j') = \left\| \mathbf{f}_j^{(c)} - \mathbf{f}_{j'}^{(c)} \right\|^2. \quad (18.52)$$

Proposição 18.2 (Preservação das distâncias qui-quadrado). *Considere uma matriz de frequências relativas*

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

com massas de linhas e colunas estritamente positivas e seja

$$K = \text{posto}(\mathbf{Q}_{\text{CA}}) \geq 1.$$

Se

$$\mathbf{F}_r \in \mathbb{R}^{I \times K}$$

e

$$\mathbf{F}_c \in \mathbb{R}^{J \times K}$$

são as coordenadas principais obtidas mantendo todas as dimensões associadas aos valores singulares positivos de $\mathbf{Q}_{\text{CA}}$, então, para quaisquer linhas i e i' ,

$$d_{\chi^2}^2(i, i') = \left\| \mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)} \right\|^2,$$

e, para quaisquer colunas j e j' ,

$$d_{\chi^2}^2(j, j') = \left\| \mathbf{f}_j^{(c)} - \mathbf{f}_{j'}^{(c)} \right\|^2.$$

O resultado explica por que uma geometria originalmente ponderada pode ser representada por distâncias euclidianas usuais entre as coordenadas principais.

A ponderação pelas massas é incorporada antes da SVD, por meio de

$$\mathbf{D}_r^{-1/2}$$

e

$$\mathbf{D}_c^{-1/2}.$$

Depois dessa transformação, a SVD fornece coordenadas euclidianas que reproduzem a distância qui-quadrado entre perfis quando toda a estrutura não nula é mantida.

Se apenas as primeiras

$$k < K$$

dimensões forem utilizadas, denote por

$$\mathbf{f}_{i,k}^{(r)} \in \mathbb{R}^k$$

o vetor formado pelas primeiras k coordenadas principais da linha i . Então,

$$\left\| \mathbf{f}_{i,k}^{(r)} - \mathbf{f}_{i',k}^{(r)} \right\|^2 \leq d_{\chi^2}^2(i, i'),$$

pois as parcelas quadráticas associadas às dimensões descartadas são não negativas.

A igualdade ocorre quando as dimensões omitidas não contribuem para a diferença entre os dois perfis.

O mesmo raciocínio vale para as colunas.

A representação reduzida preserva, portanto, apenas a parcela da geometria qui-quadrado contida nas dimensões mantidas. Essa característica prepara a interpretação das relações baricêtricas, que mostrarão como as posições das linhas e das colunas estão acopladas pela própria tabela de correspondência.

18.8.4 Relações baricêntricas

A representação das linhas e das colunas não resulta de duas análises separadas. As duas nuvens são construídas a partir da mesma matriz de frequências relativas observadas

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

e da mesma decomposição em valores singulares de

$$\mathbf{Q}_{\text{CA}}.$$

Considere, como nas seções anteriores, massas de linhas e colunas estritamente positivas,

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

e a SVD compacta

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

com

$$K = \text{posto}(\mathbf{Q}_{\text{CA}}) \geq 1.$$

As coordenadas padrão e principais são, respectivamente,

$$\mathbf{A}_r = \mathbf{D}_r^{-1/2} \mathbf{U}, \quad \mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V},$$

e

$$\mathbf{F}_r = \mathbf{A}_r \mathbf{D}, \quad \mathbf{F}_c = \mathbf{A}_c \mathbf{D}.$$

A estrutura das marginais implica que as coordenadas padrão possuem centro ponderado nulo.

De Equação [18.24](#),

$$\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}.$$

Substituindo a SVD,

$$\mathbf{U} \mathbf{D} \mathbf{V}^\top \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}.$$

Como $\mathbf{U}$ possui colunas ortonormais e $\mathbf{D}$ é invertível na SVD compacta,

$$\mathbf{V}^\top \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}.$$

Logo,

$$\begin{aligned} \mathbf{c}^\top \mathbf{A}_c &= \mathbf{1}_J^\top \mathbf{D}_c \mathbf{D}_c^{-1/2} \mathbf{V} \\ &= \mathbf{1}_J^\top \mathbf{D}_c^{1/2} \mathbf{V} \\ &= \mathbf{0}^\top. \end{aligned} \tag{18.53}$$

De forma dual,

$$\mathbf{r}^\top \mathbf{A}_r = \mathbf{0}^\top.$$

As coordenadas principais também possuem centro ponderado nulo, pois

$$\mathbf{r}^\top \mathbf{F}_r = \mathbf{r}^\top \mathbf{A}_r \mathbf{D} = \mathbf{0}^\top$$

e

$$\mathbf{c}^\top \mathbf{F}_c = \mathbf{c}^\top \mathbf{A}_c \mathbf{D} = \mathbf{0}^\top.$$

Essas propriedades permitem estabelecer a ligação direta entre as posições das linhas e das colunas.

Partindo de

$$\mathbf{Q}_{\text{CA}} \mathbf{V} = \mathbf{U} \mathbf{D},$$

tem-se

$$\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2} \mathbf{V} = \mathbf{U} \mathbf{D}.$$

Como

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V},$$

segue que

$$\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{A}_c = \mathbf{U} \mathbf{D}.$$

Utilizando

$$\mathbf{c}^\top \mathbf{A}_c = \mathbf{0}^\top,$$

obtém-se

$$\mathbf{D}_r^{-1/2} \mathbf{P} \mathbf{A}_c = \mathbf{U} \mathbf{D}.$$

Multiplicando à esquerda por

$$\mathbf{D}_r^{-1/2},$$

resulta

$$\mathbf{F}_r = \mathbf{D}_r^{-1} \mathbf{P} \mathbf{A}_c. \quad (18.54)$$

De forma dual,

$$\mathbf{F}_c = \mathbf{D}_c^{-1} \mathbf{P}^\top \mathbf{A}_r. \quad (18.55)$$

As equações Equação 18.54 e Equação 18.55 são denominadas **relações baricêntricas** ou **relações de transição**.

Para uma linha

$$i \in \{1, \dots, I\},$$

a linha correspondente de Equação 18.54 fornece

$$\mathbf{f}_i^{(r)} = \sum_{j=1}^J \frac{p_{ij}}{r_i} \mathbf{a}_j^{(c)}, \quad (18.56)$$

em que

$$\mathbf{f}_i^{(r)} \in \mathbb{R}^K$$

é o vetor de coordenadas principais da linha i e

$$\mathbf{a}_j^{(c)} \in \mathbb{R}^K$$

é o vetor de coordenadas padrão da coluna j .

Os coeficientes

$$\frac{p_{ij}}{r_i}$$

são não negativos e satisfazem

$$\sum_{j=1}^J \frac{p_{ij}}{r_i} = 1.$$

Eles são exatamente os elementos do perfil da linha i .

Consequentemente, a coordenada principal da linha i é o **baricentro**, ou centro ponderado, das coordenadas padrão das colunas, utilizando como pesos o próprio perfil dessa linha.

Analogamente, para uma coluna

$$j \in \{1, \dots, J\},$$

tem-se

$$\mathbf{f}_j^{(c)} = \sum_{i=1}^I \frac{p_{ij}}{c_j} \mathbf{a}_i^{(r)}, \quad (18.57)$$

em que

$$\mathbf{f}_j^{(c)} \in \mathbb{R}^K$$

é o vetor de coordenadas principais da coluna j e

$$\mathbf{a}_i^{(r)} \in \mathbb{R}^K$$

é o vetor de coordenadas padrão da linha i .

Os pesos

$$\frac{p_{ij}}{c_j}$$

formam o perfil da coluna j e também são não negativos, com soma igual a 1.

Assim, cada categoria de uma variável é posicionada em função da distribuição condicional observada das categorias da outra variável.

Uma linha que concentra grande parte de seu perfil em determinadas colunas tende a ser posicionada na direção das coordenadas padrão correspondentes a essas colunas. O resultado dual vale para as colunas.

As relações baricênticas são exatas em todas as K dimensões não nulas. Quando apenas as primeiras $k < K$ dimensões são exibidas, as mesmas relações permanecem válidas coordenada a coordenada para as dimensões retidas, embora o mapa represente apenas parte da estrutura total da associação.

A Figura 18.1 ilustra essa propriedade para uma tabela simples. As coordenadas principais de uma linha são apresentadas no mesmo sistema das coordenadas padrão das colunas que participam de seu baricentro.

A figura representa uma relação de centro ponderado. Ela **não** afirma que a distância euclidiana entre um ponto de linha e um ponto de coluna seja uma distância qui-quadrado definida pela técnica.

18.9 Reconstrução dos desvios da independência

A SVD também permite reconstruir a distribuição relativa observada como a soma de sua estrutura de independência e dos termos associados às dimensões da correspondência.

De Equação 18.22,

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{rc}^\top) \mathbf{D}_c^{-1/2}.$$

Logo,

$$\mathbf{P} - \mathbf{rc}^\top = \mathbf{D}_r^{1/2} \mathbf{Q}_{CA} \mathbf{D}_c^{1/2}.$$

Substituindo a SVD,




Figura 18.1: Relação baricêntrica entre uma linha e as coordenadas padrão das colunas. A posição da linha é a média ponderada das posições das colunas, com pesos dados pelo perfil da própria linha.

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r^{1/2} \mathbf{U} \mathbf{D} \mathbf{V}^\top \mathbf{D}_c^{1/2}.$$

Como

$$\mathbf{U} = \mathbf{D}_r^{1/2} \mathbf{A}_r$$

e

$$\mathbf{V} = \mathbf{D}_c^{1/2} \mathbf{A}_c,$$

obtém-se

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r \mathbf{A}_r \mathbf{D} \mathbf{A}_c^\top \mathbf{D}_c. \quad (18.58)$$

O elemento (i, j) dessa igualdade é

$$p_{ij} - r_i c_j = r_i c_j \sum_{\ell=1}^K d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}. \quad (18.59)$$

Portanto,

$$p_{ij} = r_i c_j \left[1 + \sum_{\ell=1}^K d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (18.60)$$

Apesar do identificador interno de Equação 18.60, a quantidade

$$p_{ij}$$

neste capítulo é a **frequência relativa observada** definida em Equação 18.2. Ela não deve ser confundida com uma probabilidade conjunta populacional, que será introduzida somente na formulação inferencial.

A expressão separa duas parcelas.

A primeira,

$$r_i c_j,$$

é a frequência relativa correspondente à estrutura de independência construída a partir das marginais observadas.

A segunda,

$$r_i c_j \sum_{\ell=1}^K d_{\ell} a_{i\ell}^{(r)} a_{j\ell}^{(c)},$$

reconstrói o desvio observado em relação à independência por meio das dimensões da associação.

Cada dimensão contribui com o termo

$$r_i c_j d_{\ell} a_{i\ell}^{(r)} a_{j\ell}^{(c)}.$$

O sinal desse produto indica a direção do desvio reconstruído naquela dimensão, enquanto sua magnitude depende simultaneamente:

- das massas r_i e c_j ;
- do valor singular d_{ℓ} ;
- das coordenadas padrão da linha e da coluna.

Quando apenas as primeiras

$$1 \leq k < K$$

dimensões são mantidas, a reconstrução truncada é

$$\tilde{p}_{ij}^{(k)} = r_i c_j \left[1 + \sum_{\ell=1}^k d_{\ell} a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (18.61)$$

Essa expressão corresponde à aproximação de posto reduzido

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^{\top}$$

definida em Equação 18.36.

Quando

$$k < K,$$

a reconstrução é uma aproximação algébrica da estrutura de associação observada. Ela não impõe, por si só, que

$$\tilde{p}_{ij}^{(k)} \geq 0$$

para todas as células.

Consequentemente, a matriz truncada não deve ser interpretada automaticamente como uma nova distribuição conjunta válida.

A redução dimensional possui, portanto, duas leituras da mesma aproximação:

- aproximar a matriz ponderada de desvios da independência;
- reconstruir a associação observada utilizando apenas as dimensões singulares retidas.

18.10 Representação conjunta de linhas e colunas

A Análise de Correspondência fornece coordenadas para as duas margens da tabela. Para representar linhas e colunas simultaneamente, é necessário especificar quais sistemas de coordenadas serão utilizados para cada nuvem.

A Tabela 18.2 reúne três representações particularmente úteis para compreender essa geometria.

Tabela 18.2: Sistemas de coordenadas para representar linhas e colunas na Análise de Correspondência.

Representação	Linhas	Colunas	Propriedade principal
métrica das linhas	principais $\mathbf{F}_r$	padrão $\mathbf{A}_c$	preserva a geometria das linhas e explicita sua relação baricêntrica com as colunas
métrica das colunas	padrão $\mathbf{A}_r$	principais $\mathbf{F}_c$	preserva a geometria das colunas e explicita sua relação baricêntrica com as linhas
simétrica	principais $\mathbf{F}_r$	principais $\mathbf{F}_c$	representa ambas as nuvens em escalas associadas às inércias principais

Na representação métrica das linhas, as distâncias euclidianas entre os pontos de linhas reproduzem exatamente suas distâncias qui-quadrado quando todas as dimensões não nulas são

mantidas. As colunas aparecem em coordenadas padrão e participam diretamente das relações baricêntricas das linhas.

Na representação métrica das colunas ocorre a relação dual.

Na representação simétrica, linhas e colunas são expressas por coordenadas principais. Essa representação é útil para examinar simultaneamente as duas margens, mas não cria uma métrica qui-quadrado comum entre pontos pertencentes a margens diferentes.

18.10.1 O significado das proximidades

Dentro da nuvem das linhas, proximidades representam semelhança entre perfis de colunas segundo a distância qui-quadrado. A interpretação dual vale dentro da nuvem das colunas.

A distância gráfica entre um ponto de linha e um ponto de coluna não corresponde, em geral, a uma distância qui-quadrado definida pela técnica. Portanto, a proximidade visual entre categorias pertencentes a margens diferentes não constitui uma medida métrica direta de associação.

A interpretação conjunta utiliza os perfis, as relações baricêntricas, os sinais e magnitudes das coordenadas e a reconstrução dos desvios em Equação 18.59. Essa distinção deve ser preservada especialmente nos mapas simétricos, nos quais as duas nuvens são representadas no mesmo plano, embora provenham de espaços de perfis diferentes.

18.11 Contribuição para as dimensões

A identidade de Equação 18.46 mostra que, para cada dimensão

$$\ell = 1, \dots, K,$$

a inércia principal pode ser decomposta entre as categorias das linhas:

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2.$$

De forma dual,

$$\lambda_\ell = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2.$$

Como

$$\lambda_\ell = d_\ell^2 > 0,$$

essas decomposições permitem definir a parcela da inércia do eixo atribuída a cada categoria.

Definição 18.9 (Contribuição para uma dimensão). Considere uma Análise de Correspondência com massas de linhas e colunas estritamente positivas e

$$K = \text{posto}(\mathbf{Q}_{\text{CA}}) \geq 1.$$

Se

$$\mathbf{F}_r = (f_{i\ell}^{(r)}) \in \mathbb{R}^{I \times K}$$

e

$$\mathbf{F}_c = (f_{j\ell}^{(c)}) \in \mathbb{R}^{J \times K}$$

são as coordenadas principais e

$$\lambda_\ell = d_\ell^2 > 0, \quad \ell = 1, \dots, K,$$

é a inércia principal da dimensão ℓ , a **contribuição da linha i para a dimensão ℓ** é

$$\text{ctr}_{i\ell}^{(r)} = \frac{r_i (f_{i\ell}^{(r)})^2}{\lambda_\ell}, \quad i = 1, \dots, I. \quad (18.62)$$

A **contribuição da coluna j para a dimensão ℓ** é

$$\text{ctr}_{j\ell}^{(c)} = \frac{c_j (f_{j\ell}^{(c)})^2}{\lambda_\ell}, \quad j = 1, \dots, J. \quad (18.63)$$

Pelas identidades de dispersão das coordenadas principais,

$$\sum_{i=1}^I \text{ctr}_{i\ell}^{(r)} = 1 \quad (18.64)$$

e

$$\sum_{j=1}^J \text{ctr}_{j\ell}^{(c)} = 1. \quad (18.65)$$

A contribuição mede a parcela da inércia de uma dimensão atribuída a determinada categoria.

Ela depende simultaneamente da massa e da posição da categoria:

$$r_i \left(f_{i\ell}^{(r)} \right)^2$$

para uma linha e

$$c_j \left(f_{j\ell}^{(c)} \right)^2$$

para uma coluna.

Por isso, a magnitude isolada de uma coordenada não determina a contribuição. Uma categoria com posição extrema pode ter contribuição limitada se possuir massa pequena; inversamente, uma categoria de maior massa pode contribuir substancialmente mesmo com coordenada menos extrema.

A contribuição não mede a qualidade com que uma categoria é representada por uma dimensão. Essa é outra decomposição, considerada a seguir.

18.12 Qualidade de representação

Como as coordenadas principais completas preservam a geometria qui-quadrado, a distância de uma linha i ao centro da nuvem pode ser decomposta pelas dimensões da correspondência:

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{\ell=1}^K \left(f_{i\ell}^{(r)} \right)^2. \quad (18.66)$$

De forma dual,

$$d_{\chi^2}^2(j, \mathbf{r}) = \sum_{\ell=1}^K \left(f_{j\ell}^{(c)} \right)^2.$$

A parcela dessa distância associada a uma dimensão é utilizada para avaliar a qualidade da representação da categoria.

Definição 18.10 (Qualidade de representação por dimensão). Considere uma Análise de Correspondência com

$$K \geq 1$$

dimensões não nulas e coordenadas principais

$$\mathbf{F}_r = (f_{i\ell}^{(r)}) \in \mathbb{R}^{I \times K}$$

e

$$\mathbf{F}_c = (f_{j\ell}^{(c)}) \in \mathbb{R}^{J \times K}.$$

Para uma linha i tal que

$$d_{\chi^2}(i, \mathbf{c}) > 0,$$

a **qualidade de representação da linha i na dimensão ℓ** é

$$\cos_{i\ell}^2 = \frac{(f_{i\ell}^{(r)})^2}{d_{\chi^2}^2(i, \mathbf{c})}, \quad \ell = 1, \dots, K. \quad (18.67)$$

Para uma coluna j tal que

$$d_{\chi^2}(j, \mathbf{r}) > 0,$$

a **qualidade de representação da coluna j na dimensão ℓ** é

$$\cos_{j\ell}^2 = \frac{(f_{j\ell}^{(c)})^2}{d_{\chi^2}^2(j, \mathbf{r})}. \quad (18.68)$$

Para uma linha com distância positiva ao centro,

$$\sum_{\ell=1}^K \cos_{i\ell}^2 = 1.$$

Analogamente, para uma coluna com distância positiva ao centro,

$$\sum_{\ell=1}^K \cos_{j\ell}^2 = 1.$$

Assim,

$$\cos_{i\ell}^2$$

mede a parcela da distância quadrática da linha i ao centro representada pela dimensão ℓ , enquanto

$$\cos_{j\ell}^2$$

possui a interpretação dual para a coluna j .

Se uma categoria coincide com o centro de sua nuvem, sua distância é zero e todos os seus escores principais são nulos. Nesse caso, a razão que define o $\cos^2$ possui a forma

$$\frac{0}{0}$$

e a qualidade de representação por dimensão não é definida. Geometricamente, não existe uma direção não nula da categoria em relação ao centro cuja decomposição precise ser avaliada.

Para as primeiras

$$1 \leq k \leq K$$

dimensões, a qualidade acumulada da representação de uma linha é

$$\sum_{\ell=1}^k \cos_{i\ell}^2. \quad (18.69)$$

Essa quantidade representa a parcela da distância quadrática da categoria ao centro contida no subespaço formado pelas primeiras k dimensões.

A mesma construção vale para as colunas.

As diferenças entre contribuição e qualidade de representação são sintetizadas na Tabela [18.3](#).

Tabela 18.3: Diferença entre contribuição e qualidade de representação na Análise de Correspondência.

Medida	Numerador	Quantidade de referência	Interpretação
contribuição	$r_i(f_{i\ell}^{(r)})^2$ ou $c_j(f_{j\ell}^{(c)})^2$	inércia da dimensão λ_ℓ	participação da categoria na construção da dimensão
$\cos^2$	$(f_{i\ell}^{(r)})^2$ ou $(f_{j\ell}^{(c)})^2$	distância quadrática da própria categoria ao centro	parcela da posição da categoria representada pela dimensão

A contribuição distribui a **inércia de uma dimensão entre as categorias**.

O $\cos^2$ distribui a **distância de uma categoria entre as dimensões**.

São, portanto, decomposições realizadas em sentidos distintos.

Uma categoria pode contribuir fortemente para a construção de uma dimensão sem que essa dimensão represente grande parte de sua distância total ao centro. Da mesma forma, uma categoria pode ser muito bem representada por determinado eixo e, ainda assim, contribuir pouco para a inércia desse eixo se possuir massa pequena.

Essas medidas devem ser interpretadas depois que a estrutura geométrica da técnica foi estabelecida. Critérios operacionais baseados em contribuições médias, limiares de $\cos^2$, seleção automática de categorias ou regras de leitura de mapas pertencem à etapa aplicada e não são necessários para a formulação matemática da Análise de Correspondência.

18.13 Formulação descritiva e inferencial

A identidade

$$\chi^2 = n\mathcal{I}$$

estabelecida em Equação 18.29 relaciona diretamente a estatística de Pearson calculada para a tabela observada com a inércia total utilizada na representação geométrica.

Essa identidade é algébrica. Ela não exige, por si só, que a tabela seja tratada como realização de um modelo probabilístico.

Na Análise de Correspondência,

$$\mathcal{J}$$

descreve e decompõe geometricamente o afastamento observado em relação à estrutura

$$\mathbf{P} = \mathbf{rc}^\top.$$

Para atribuir significado inferencial a

$$\chi^2,$$

é necessário introduzir uma distribuição populacional e um mecanismo de amostragem.

18.13.1 Distribuição populacional da tabela

Considere uma população na qual duas variáveis categóricas possuem, respectivamente,

$$I \geq 2$$

e

$$J \geq 2$$

categorias.

Denote por

$$\pi_{ij} = P(\mathbf{A} = i, \mathbf{B} = j),$$

com

$$\pi_{ij} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J \pi_{ij} = 1,$$

as probabilidades populacionais das células.

As probabilidades marginais são

$$\pi_{i.} = \sum_{j=1}^J \pi_{ij}, \quad i = 1, \dots, I,$$

e

$$\pi_{.j} = \sum_{i=1}^I \pi_{ij}, \quad j = 1, \dots, J.$$

A hipótese populacional de independência é

$$H_0 : \pi_{ij} = \pi_{i.}\pi_{.j}, \quad i = 1, \dots, I, \quad j = 1, \dots, J. \quad (18.70)$$

Observe a mudança de nível estatístico. Na parte geométrica do capítulo,

$$p_{ij}, \quad r_i \quad \text{e} \quad c_j$$

são quantidades calculadas a partir da tabela observada.

Nesta seção,

$$\pi_{ij}, \quad \pi_{i.} \quad \text{e} \quad \pi_{.j}$$

são parâmetros da distribuição populacional.

18.13.2 Resultado assintótico de Pearson

Considere uma amostra de tamanho n formada por observações independentes da distribuição conjunta anterior. O vetor das frequências celulares

$$(N_{11}, \dots, N_{IJ})$$

possui distribuição multinomial com parâmetros

$$n$$

e

$$(\pi_{11}, \dots, \pi_{IJ}).$$

A estatística de Pearson da tabela observada continua sendo aquela definida em Equação 18.28,

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - nr_i c_j)^2}{nr_i c_j}.$$

Proposição 18.3 (Distribuição assintótica da estatística de Pearson sob independência).
Considere uma tabela de contingência $I \times J$, com

$$I \geq 2, \quad J \geq 2,$$

obtida de uma amostra multinomial de tamanho n , mantendo I e J fixos.

Suponha que, sob

$$H_0 : \pi_{ij} = \pi_{i \cdot} \pi_{\cdot j},$$

todas as probabilidades marginais satisfaçam

$$\pi_{i \cdot} > 0, \quad i = 1, \dots, I,$$

e

$$\pi_{\cdot j} > 0, \quad j = 1, \dots, J.$$

Então, quando

$$n \longrightarrow \infty,$$

a estatística de Pearson satisfaz

$$\chi^2 \xrightarrow{d} \chi^2_{(I-1)(J-1)}. \quad (18.71)$$

O resultado é **assintótico**, e não uma identidade distribucional exata para amostras finitas.

A teoria geral de testes, distribuições assintóticas e valores- p foi desenvolvida no Módulo 2. Aqui, esse resultado é utilizado apenas para delimitar a relação entre a representação geométrica da Correspondência e o teste global de independência.

A identidade

$$\chi^2 = n\mathcal{J}$$

e o limite

$$\chi^2 \xrightarrow{d} \chi^2_{(I-1)(J-1)}$$

pertencem, portanto, a níveis diferentes:

- a primeira é uma igualdade algébrica para a tabela observada;
- o segundo é um resultado probabilístico assintótico sob um modelo amostral e sob H_0 .

Essa separação é importante porque a Análise de Correspondência pode ser utilizada descritivamente mesmo quando não se pretende realizar um teste formal de independência (Beh; Lombardo, 2014; Greenacre, 2017).

18.13.3 Teste global e dimensões da Correspondência

A rejeição de

$$H_0$$

indica que a distribuição conjunta populacional não é compatível com a estrutura de independência segundo o modelo considerado.

Isso não significa que cada dimensão obtida pela SVD corresponda automaticamente a uma hipótese inferencial populacional distinta.

As dimensões resultam da decomposição da matriz observada

$$\mathbf{Q}_{CA}$$

e de sua inércia,

$$\mathcal{J} = \sum_{\ell=1}^K \lambda_{\ell}.$$

O teste de Pearson, por outro lado, é global.

Consequentemente, o teste global de independência e a decomposição geométrica respondem a problemas distintos. O teste de Pearson avalia evidência estatística global contra a independência populacional, enquanto a Análise de Correspondência descreve como o afastamento observado da independência se distribui entre as dimensões.

A primeira interpretação é inferencial. A segunda constitui o problema descritivo central desenvolvido neste capítulo.

18.13.4 Inércia e tamanho da amostra

A relação

$$\chi^2 = n\mathcal{J}$$

também mostra que significância estatística e magnitude geométrica da associação não são a mesma quantidade.

Considere a multiplicação de todas as frequências observadas por um mesmo inteiro positivo

$$a \geq 1,$$

de modo que

$$\mathbf{N}^* = a\mathbf{N}.$$

O novo total é

$$n^* = an.$$

Entretanto,

$$\mathbf{P}^* = \frac{\mathbf{N}^*}{n^*} = \frac{a\mathbf{N}}{an} = \mathbf{P}.$$

Consequentemente, permanecem inalterados:

$$\mathbf{r}, \quad \mathbf{c}, \quad \mathbf{Q}_{CA}, \quad \mathcal{J},$$

os valores singulares e todas as coordenadas da representação.

Por outro lado,

$$\chi^{2*} = n^* \mathcal{J} = a \chi^2.$$

A geometria da Correspondência depende das frequências **relativas** observadas. A magnitude da estatística de Pearson também depende do tamanho total da tabela.

Assim, uma pequena inércia pode estar associada a uma estatística de teste elevada quando n é grande. Inversamente, uma estrutura geometricamente perceptível não garante, por si só, rejeição de independência em uma amostra pequena.

18.14 Relações com a ACP e o MDS

A Análise de Correspondência reutiliza estruturas matemáticas já encontradas em outras técnicas de representação do Módulo 3. A semelhança algébrica não significa que os problemas estatísticos sejam os mesmos.

18.14.1 Relação com a Análise de Componentes Principais

Considere novamente a matriz dos perfis de linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}.$$

Por Equação 18.49,

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{1/2} (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2}. \quad (18.72)$$

Essa expressão mostra três operações anteriores à SVD:

1. os perfis de linhas são centralizados em torno de $\mathbf{c}$;
2. as linhas são ponderadas por suas massas por meio de $\mathbf{D}_r^{1/2}$;
3. as coordenadas dos perfis são reescaladas pelas massas das colunas por meio de $\mathbf{D}_c^{-1/2}$.

A SVD é aplicada à matriz resultante.

A relação com a ACP aparece na procura de uma representação de posto reduzido de uma matriz centralizada e na decomposição da dispersão entre dimensões ortogonais.

A diferença está na geometria e no objeto de entrada.

Na ACP, a estrutura é construída a partir de variáveis quantitativas e de sua variabilidade, utilizando uma matriz de covariâncias, correlações ou uma matriz de dados correspondente.

Na Análise de Correspondência, a estrutura parte de perfis derivados de uma tabela de contingência e utiliza a geometria qui-quadrado determinada pelas massas marginais.

A inércia é

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}),$$

com

$$d_{\chi^2}^2(i, i') = (\mathbf{p}_{i| \cdot} - \mathbf{p}_{i'| \cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i| \cdot} - \mathbf{p}_{i'| \cdot}).$$

A Análise de Correspondência pode, assim, ser relacionada a uma análise de componentes de perfis em uma geometria ponderada, mas não deve ser identificada simplesmente como uma ACP aplicada a variáveis qualitativas (Greenacre, 2017).

A comparação é sintetizada na Tabela 18.4.

Tabela 18.4: Relação entre a ACP e a Análise de Correspondência.

Aspecto	ACP	Análise de Correspondência
objeto inicial	matriz de dados quantitativos ou matriz de covariâncias/correlações	tabela de contingência
unidades representadas centro	observações e/ou variáveis vetor de médias	categorias de linhas e colunas perfis marginais $\mathbf{c}$ e $\mathbf{r}$
pesos das unidades	usualmente iguais na formulação básica	massas r_i e c_j
geometria	euclidiana ou padronizada	qui-quadrado
quantidade decomposta	variância	inércia
ferramenta espectral	autovalores ou SVD	SVD dos desvios padronizados

18.14.2 Relação com o Escalonamento Multidimensional

O Escalonamento Multidimensional parte de relações de dissimilaridade e procura construir coordenadas que representem essa geometria.

Na Análise de Correspondência, as distâncias entre perfis não são fornecidas externamente. Elas são construídas a partir da própria tabela por meio da métrica qui-quadrado.

Para os perfis de linhas, defina

$$\Delta_{\chi^2}^{(r)} = (d_{\chi^2}(i, i')) \in \mathbb{R}^{I \times I}.$$

Por Proposição 18.2, quando todas as K dimensões não nulas são mantidas,

$$d_{\chi^2}(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|.$$

Portanto,

$$\Delta_{\chi^2}^{(r)}$$

é uma matriz de distâncias euclidianas na representação transformada dos perfis.

Se o MDS clássico for aplicado a essas distâncias, sua configuração reproduzirá a mesma geometria das linhas, até as indeterminações de translação e transformação ortogonal próprias do MDS.

A construção dual vale para as colunas.

A diferença está no ponto de partida:

- no MDS, uma matriz de dissimilaridades é fornecida à técnica;
- na Correspondência, a distância qui-quadrado é derivada da própria tabela e depende das massas marginais.

Além disso, a Correspondência possui uma dualidade específica entre duas nuvens, de linhas e colunas, acopladas pela mesma SVD e pelas relações baricêntricas. Essa estrutura não faz parte da formulação geral do MDS.

A Tabela 18.5 resume os três problemas.

Tabela 18.5: Diferentes problemas de representação na ACP, no MDS e na Análise de Correspondência.

Técnica	Estrutura representada	Geometria ou critério
ACP	variabilidade de observações quantitativas	variância e projeção
MDS	relações de dissimilaridade entre objetos	fidelidade das distâncias ou dos produtos internos
Correspondência	associação entre categorias de uma tabela	distância qui-quadrado e inércia

A presença de SVD, autovalores ou aproximações de posto reduzido não determina, sozinha, a técnica. O significado estatístico decorre do objeto de entrada, da geometria e do problema que a decomposição resolve.

18.15 Pressupostos e limites da representação

A formulação da Análise de Correspondência é predominantemente geométrica e descritiva. Algumas condições, entretanto, são necessárias para que os objetos utilizados pela técnica estejam definidos e para delimitar sua interpretação.

18.15.1 Condições da tabela ativa

A tabela deve satisfazer

$$n_{ij} \geq 0$$

e

$$n > 0,$$

condições que permitem definir

$$\mathbf{P} = \frac{1}{n} \mathbf{N}.$$

A geometria ativa pressupõe ainda massas estritamente positivas,

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

para que estejam definidas as inversas e raízes quadradas inversas de $\mathbf{D}_r$ e $\mathbf{D}_c$. Linhas ou colunas com massa nula não possuem perfis ativos definidos e não participam diretamente da geometria formulada neste capítulo.

18.15.2 Massas pequenas e frequências nulas

Massas estritamente positivas, mas pequenas, não impedem matematicamente a análise. Como a métrica qui-quadrado utiliza pesos inversos às massas, diferenças envolvendo categorias pouco frequentes podem exercer influência elevada sobre a geometria. Essa característica decorre da própria definição da métrica.

Uma frequência celular

$$n_{ij} = 0$$

também não impede a análise quando as massas correspondentes permanecem positivas. Nesse caso,

$$p_{ij} = 0$$

e o desvio

$$p_{ij} - r_i c_j$$

continua definido. Uma linha ou coluna inteiramente nula é diferente porque produz massa marginal zero. Zeros estruturais exigem interpretação segundo o mecanismo que define a tabela.

Na formulação inferencial, frequências pequenas podem afetar a qualidade da aproximação assintótica da estatística de Pearson. Essa questão deve ser distinguida da geometria da Correspondência e será tratada na etapa aplicada. ### Dimensão da representação

Por Equação [18.26](#),

$$K = \text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1).$$

Quando apenas

$$1 \leq k < K$$

dimensões são mantidas, a parcela da inércia representada é

$$\frac{\sum_{\ell=1}^k \lambda_{\ell}}{\sum_{\ell=1}^K \lambda_{\ell}}.$$

Uma representação em duas dimensões não implica que a associação observada seja intrinsecamente bidimensional.

Quando

$$k < K,$$

o mapa é uma representação de posto reduzido da associação observada.

18.15.3 Sinais, multiplicidades e orientação

Para qualquer dimensão singular, a troca simultânea

$$\mathbf{u}_{\ell} \mapsto -\mathbf{u}_{\ell}$$

e

$$\mathbf{v}_{\ell} \mapsto -\mathbf{v}_{\ell}$$

não modifica

$$d_{\ell} \mathbf{u}_{\ell} \mathbf{v}_{\ell}^{\top}.$$

Consequentemente, o sinal absoluto de um eixo não possui significado estatístico.

Quando um valor singular possui multiplicidade maior que um, os vetores singulares individuais no subespaço correspondente não são únicos.

Se a multiplicidade está completamente contida entre as dimensões mantidas, diferentes bases ortonormais representam o mesmo subespaço.

Se o truncamento ocorre na fronteira de uma multiplicidade,

$$d_k = d_{k+1},$$

o próprio subespaço de dimensão k escolhido para a representação reduzida pode não ser único.

Assim, devem ser interpretadas principalmente estruturas invariantes, como o subespaço representado, distâncias dentro de cada nuvem, inércias e relações entre perfis, e não o sinal absoluto de coordenadas individuais.

18.15.4 Proximidade entre linhas e colunas

As distâncias euclidianas entre linhas em coordenadas principais completas reproduzem as distâncias qui-quadrado entre seus perfis. O mesmo vale para as colunas.

A distância gráfica entre um ponto de linha e um ponto de coluna, entretanto, não possui, em geral, essa interpretação.

A Figura 18.2 ilustra a representação simultânea das duas nuvens.

O mapa permite examinar simultaneamente as duas margens, mas sua leitura deve respeitar a geometria de cada nuvem.

A interpretação cruzada entre linhas e colunas é fundamentada principalmente pelos perfis, pelas relações baricêntricas e pela reconstrução dos desvios da independência, e não pela distância gráfica direta entre símbolos de tipos diferentes.

18.15.5 Associação e causalidade

A Análise de Correspondência descreve associações entre categorias observadas em uma tabela.

A existência de inércia positiva,

$$\mathcal{J} > 0,$$

indica apenas que




Figura 18.2: Representação conjunta das categorias de linhas e colunas. Distâncias dentro da mesma nuvem possuem interpretação geométrica própria; a distância entre uma linha e uma coluna não corresponde, em geral, a uma distância qui-quadrado.

$$\mathbf{P} \neq \mathbf{r}\mathbf{c}^\top$$

para a tabela observada.

Mesmo quando o teste global fornece evidência estatística de associação populacional, essa associação não estabelece uma relação causal entre as variáveis.

Da mesma forma, uma dimensão da Correspondência não deve ser interpretada automaticamente como uma variável latente substantiva. Ela é uma direção singular que organiza os desvios padronizados da independência.

Sua interpretação substantiva depende dos perfis, das categorias que contribuem para a dimensão e do conhecimento sobre o problema analisado.

18.16 Síntese

A Análise de Correspondência representa a associação entre as categorias de duas variáveis qualitativas a partir de uma tabela de contingência

$$\mathbf{N} = (n_{ij}) \in \mathbb{R}^{I \times J}.$$

A matriz de frequências relativas

$$\mathbf{P} = \frac{1}{n} \mathbf{N}$$

define as massas marginais

$$\mathbf{r} = \mathbf{P}\mathbf{1}_J \quad \text{e} \quad \mathbf{c} = \mathbf{P}^\top \mathbf{1}_I,$$

que determinam os pesos da geometria e os perfis condicionais de linhas e colunas.

Sob independência, a estrutura de referência é

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top.$$

Os desvios dessa estrutura são reunidos na matriz padronizada

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

Sua norma de Frobenius ao quadrado é a inércia total,

$$\mathcal{J} = \|\mathbf{Q}_{CA}\|_F^2,$$

e, para a tabela observada,

$$\chi^2 = n\mathcal{J}.$$

Essa identidade é algébrica e deve ser distinguida da distribuição assintótica da estatística de Pearson sob um modelo amostral e sob a hipótese populacional de independência.

A SVD

$$\mathbf{Q}_{CA} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$$

decompõe o afastamento da independência em dimensões ortogonais. As inércias principais são

$$\lambda_\ell = d_\ell^2,$$

e satisfazem

$$\mathcal{J} = \sum_{\ell=1}^K \lambda_\ell, \quad K \leq \min(I-1, J-1).$$

As coordenadas principais preservam, quando todas as dimensões não nulas são mantidas, as distâncias qui-quadrado entre perfis da mesma margem. A dualidade entre linhas e colunas é expressa pelas relações baricêntricas, mas não define uma distância qui-quadrado direta entre um ponto de linha e um ponto de coluna.

A contribuição de uma categoria mede sua participação na inércia de determinada dimensão. O $\cos^2$ mede a parcela da distância da própria categoria ao centro representada por essa dimensão. As duas medidas correspondem a decomposições diferentes e não devem ser confundidas.

A formulação geométrica da Análise de Correspondência é descritiva e não exige normalidade multivariada. A inferência global de independência requer um modelo probabilístico para a tabela e condições que sustentem a aproximação assintótica da estatística de Pearson.

A técnica compartilha com a ACP a decomposição de uma estrutura centralizada por direções ortogonais e compartilha com o MDS a representação geométrica de distâncias. Seu objeto e sua métrica são próprios: perfis de uma tabela de contingência, ponderados pelas massas e comparados pela distância qui-quadrado.

O capítulo integra frequências relativas, distribuições condicionais, métricas ponderadas, normas, posto, SVD e inferência para decompor geometricamente os desvios da independência.

No próximo capítulo, os grupos ou condições passam a ser conhecidos e o problema deixa de ser a representação da associação entre categorias. A MANOVA utilizará o modelo linear multivariado para comparar conjuntamente vetores de médias por meio das matrizes de hipótese e erro e de autovalores generalizados.

19 Formulação da MANOVA

A Análise de Variância Multivariada, MANOVA, testa hipóteses sobre funções estimáveis dos parâmetros de um modelo linear com várias respostas. O problema inclui comparações de vetores de médias associados a grupos, tratamentos, fatores, covariáveis ou outros termos representados no delineamento.

O modelo linear multivariado, definido em Definição 11.3, é

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

com

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p}$$

e

$$\mathcal{E} \in \mathbb{R}^{n \times p}.$$

A MANOVA utiliza esse modelo para comparar a variação atribuída a uma hipótese com a variação residual conjunta. Essa construção produz as matrizes de hipótese e erro e conduz a um problema de autovalores generalizados. Os critérios de Wilks, Pillai, Hotelling–Lawley e Roy são funções das raízes obtidas desse mesmo problema (Anderson, 2003; Rencher; Christensen, 2012).

O capítulo desenvolve essa formulação e distingue sua estrutura algébrica e geométrica da teoria probabilística utilizada na inferência clássica. Algoritmos, diagnósticos, procedimentos posteriores à rejeição da hipótese e extensões serão tratados posteriormente.

Os elementos da formulação são resumidos na Tabela 19.1.

Tabela 19.1: Elementos da formulação da MANOVA.

Elemento	Objeto	Papel na MANOVA
respostas	$\mathcal{Y}$	reúne as p respostas observadas nas mesmas unidades
delineamento	$\mathbf{Z}$	representa grupos, tratamentos, covariáveis e demais termos
parâmetros	$\mathbf{B}$	determina os vetores de médias condicionais
hipótese	$\mathbf{C}_1 \mathbf{B} = \Theta_0$	especifica uma função estimável sobre todas as respostas
variação atribuída à hipótese	$\mathbf{H}$	mede o afastamento observado em relação a H_0
variação residual	$\mathbf{E}$	mede a variabilidade conjunta não explicada pelo modelo
comparação direcional	$\mathbf{a}^\top \mathbf{H} \mathbf{a} / \mathbf{a}^\top \mathbf{E} \mathbf{a}$	compara hipótese e erro para uma combinação das respostas
solução espectral	raízes características	resume as direções de maior efeito relativo
critérios de teste	Wilks, Pillai, Hotelling–Lawley e Roy	agregam as mesmas raízes de formas distintas

19.1 O problema de comparação multivariada

Considere inicialmente $K \geq 2$ grupos e um vetor de p respostas para cada unidade,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

Se o vetor de médias do grupo k é

$$\mu_k = \begin{pmatrix} \mu_{k1} \\ \vdots \\ \mu_{kp} \end{pmatrix} \in \mathbb{R}^p, \quad k = 1, \dots, K,$$

a hipótese de igualdade entre os grupos é

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_K. \quad (19.1)$$

A alternativa afirma que pelo menos dois desses vetores de médias diferem.

Quando

$$p = 1,$$

a hipótese em Equação 19.1 é univariada e a comparação pode ser expressa pela razão entre uma soma de quadrados associada ao efeito e uma soma de quadrados residual.

Quando

$$p > 1,$$

o afastamento entre os grupos possui direção no espaço das respostas. Uma diferença pequena em cada resposta considerada isoladamente pode formar uma combinação linear com separação relevante, enquanto diferenças marginais aparentemente grandes podem refletir informação redundante entre respostas associadas.

A MANOVA considera simultaneamente a magnitude das diferenças entre os vetores de médias, a variabilidade residual de cada resposta e as covariâncias residuais entre as respostas.

Por isso, o problema não é equivalente a realizar p análises de variância independentes. A estrutura conjunta é representada por matrizes de somas de quadrados e produtos cruzados.

19.2 A hipótese no modelo linear multivariado

O caso de grupos é uma aplicação do modelo linear multivariado, e não uma formulação separada. Indicadores de grupos, tratamentos, fatores e covariáveis podem ser incorporados à matriz

Z.

No Módulo 2, a hipótese linear geral foi definida em Definição 11.17 como

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0, \quad (19.2)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times s}.$$

A matriz $\mathbf{C}_1$ combina ou contrasta os termos do modelo, enquanto $\mathbf{C}_2$ seleciona ou combina as respostas.

Para testar efeitos sobre todas as p respostas originais, toma-se

$$\mathbf{C}_2 = \mathbf{I}_p.$$

Nesse caso,

$$s = p$$

na notação da hipótese bilateral do Módulo 2, e a hipótese torna-se

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0, \tag{19.3}$$

em que

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times p}.$$

Essa será a formulação utilizada no restante deste capítulo.

Consideraremos $\mathbf{C}_1$ sem linhas redundantes,

$$\text{posto}(\mathbf{C}_1) = g, \tag{19.4}$$

e a função

$$\mathbf{C}_1 \mathbf{B}$$

estimável. Pela condição matricial de estimabilidade estabelecida em Equação 11.117,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (19.5)$$

Nessas condições, os graus de liberdade associados à hipótese são

$$\nu_H = g. \quad (19.6)$$

No problema de comparação entre K grupos, uma matriz $\mathbf{C}_1$ apropriada pode representar os contrastes necessários para expressar Equação 19.1. Quando se testa o efeito completo de grupos, existem

$$G - 1$$

contrastos linearmente independentes e, portanto,

$$g = G - 1. \quad (19.7)$$

A hipótese de igualdade de vetores de médias é, assim, um caso particular da hipótese linear geral já construída no Módulo 2.

19.2.1 Matrizes de hipótese e erro

A SQPC associada à hipótese foi definida em Definição 11.18. Especializando aquela construção para

$$\mathbf{C}_2 = \mathbf{I}_p,$$

denote por

$$\mathbf{H} \in \mathbb{R}^{p \times p}$$

a SQPC observada da hipótese em Equação 19.3.

Sob as condições de estimabilidade anteriores,

$$\mathbf{H} = \mathbf{H}^\top \succeq \mathbf{0}.$$

A matriz $\mathbf{H}$ reúne a variação associada ao afastamento observado de

$$\mathbf{C}_1 \mathbf{B} = \Theta_0.$$

Sua diagonal contém as parcelas correspondentes às respostas individuais, enquanto seus elementos fora da diagonal contêm os produtos cruzados associados aos afastamentos entre respostas.

A SQPC residual foi definida em Definição 11.11. Após a observação,

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \in \mathbb{R}^{p \times p}.$$

Ela satisfaz

$$\mathbf{E} = \mathbf{E}^\top \succeq \mathbf{0}.$$

A matriz $\mathbf{E}$ reúne a variabilidade residual das respostas e suas covariâncias residuais na escala de somas de quadrados e produtos cruzados.

No caso de um fator com grupos, $\mathbf{H}$ e $\mathbf{E}$ correspondem às estruturas multivariadas análogas às somas de quadrados entre grupos e dentro dos grupos. Essa relação já foi construída no modelo linear multivariado; aqui, essas matrizes passam a constituir os dois objetos comparados pela MANOVA.

A Tabela 19.2 distingue suas funções.

Tabela 19.2: Funções das matrizes de hipótese e erro na MANOVA.

Matriz	Origem	Interpretação
$\mathbf{H}$	hipótese testada	variação multivariada associada ao afastamento observado de H_0
$\mathbf{E}$	resíduos do modelo	variação multivariada residual utilizada como referência

Se

$$\mathbf{H} = \mathbf{0},$$

não existe afastamento observado da hipótese nas funções paramétricas consideradas.

Entretanto, a magnitude de $\mathbf{H}$ isoladamente não determina a relevância desse afastamento. Uma mesma variação associada à hipótese possui significado diferente quando a variabilidade residual é pequena ou grande.

A MANOVA compara, portanto, a estrutura de

$$\mathbf{H}$$

com a estrutura de

$$\mathbf{E}.$$

19.3 Hipótese e erro em uma combinação linear das respostas

Considere uma combinação linear das p respostas definida por

$$\mathbf{W} = \mathbf{a}^\top \mathbf{Y}, \quad \mathbf{a} \in \mathbb{R}^p. \quad (19.8)$$

Aplicando a mesma combinação linear às matrizes observadas de hipótese e erro, obtêm-se os escalares

$$h(\mathbf{a}) = \mathbf{a}^\top \mathbf{H} \mathbf{a} \quad (19.9)$$

e

$$e(\mathbf{a}) = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (19.10)$$

As duas expressões são formas quadráticas.

A quantidade

$$h(\mathbf{a})$$

mede a variação atribuída à hipótese na combinação das respostas definida por $\mathbf{a}$, enquanto

$$e(\mathbf{a})$$

mede a variação residual dessa mesma combinação.

Para a formulação espectral clássica desenvolvida a seguir, suponha

$$\mathbf{E} \succ \mathbf{0}. \quad (19.11)$$

Então,

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0},$$

e pode-se definir

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (19.12)$$

A expressão em Equação 19.12 é exatamente o quociente de Rayleigh generalizado definido em Definição 5.12, aplicado ao par

$$(\mathbf{H}, \mathbf{E}).$$

Essa identificação é o ponto em que a estrutura estatística da MANOVA encontra o problema espectral desenvolvido no Módulo 1.

A teoria geral não precisa ser reconstruída: as matrizes $\mathbf{H}$ e $\mathbf{E}$ fornecem, respectivamente, as formas quadráticas do numerador e do denominador.

A razão é invariante à escala de $\mathbf{a}$. Para qualquer

$$c \neq 0,$$

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}).$$

Portanto, interessa a direção determinada por $\mathbf{a}$, e não seu comprimento.

Uma direção apresenta grande razão hipótese/erro quando a combinação correspondente das respostas exibe variação associada à hipótese elevada relativamente à variabilidade residual nessa mesma combinação.

19.4 Problema espectral da MANOVA

O problema passa a ser identificar as direções nas quais Equação 19.12 assume seus valores extremos.

Pelo resultado de Teorema 5.8, aplicado ao par simétrico

$$(\mathbf{H}, \mathbf{E}),$$

com

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

os extremos do problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}} \quad (19.13)$$

são determinados pelos autovalores generalizados que satisfazem

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}. \quad (19.14)$$

Essa é precisamente a estrutura definida em Definição 5.11.

Definição 19.1 (Raízes características da MANOVA). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{H} \succeq \mathbf{0}$$

e

$$\mathbf{E} \succ \mathbf{0}.$$

As **raízes características da MANOVA** são os autovalores generalizados

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$$

do par

$$(\mathbf{H}, \mathbf{E}),$$

isto é, os valores para os quais existe

$$\mathbf{a}_j \in \mathbb{R}^p, \quad \mathbf{a}_j \neq \mathbf{0},$$

satisfazendo

$$\mathbf{H}\mathbf{a}_j = \lambda_j \mathbf{E}\mathbf{a}_j.$$

Se

$$r_H = \text{posto}(\mathbf{H}),$$

então exatamente r_H raízes são positivas:

$$\lambda_1 \geq \dots \geq \lambda_{r_H} > 0 = \lambda_{r_H+1} = \dots = \lambda_p,$$

quando

$$r_H < p.$$

A afirmação sobre o número de raízes positivas pode ser vista diretamente pela redução do problema generalizado a um problema espectral simétrico.

Defina

$$\mathbf{K}_{\mathbf{H}\mathbf{E}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}.$$

Como

$$\mathbf{E}^{-1/2}$$

é invertível,

$$\text{posto}(\mathbf{K}_{\mathbf{H}\mathbf{E}}) = \text{posto}(\mathbf{H}) = r_H.$$

Além disso,

$$\mathbf{K}_{\text{HE}} \succeq \mathbf{0}.$$

Logo, $\mathbf{K}_{\text{HE}}$ possui exatamente r_H autovalores positivos, e esses autovalores são as raízes generalizadas do par

$$(\mathbf{H}, \mathbf{E}).$$

Consequentemente,

$$r_H = \text{posto}(\mathbf{H}) \leq p. \quad (19.15)$$

Para a hipótese

$$\mathbf{C}_1 \mathbf{B} = \Theta_0,$$

com

$$\text{posto}(\mathbf{C}_1) = g,$$

a construção de $\mathbf{H}$ em Definição 11.18 implica

$$\text{posto}(\mathbf{H}) \leq \min(p, g).$$

Portanto,

$$r_H \leq \min(p, g). \quad (19.16)$$

No caso do efeito completo de K grupos,

$$g = K - 1,$$

e

$$r_H \leq \min(p, G - 1). \quad (19.17)$$

Assim, mesmo quando existem muitas respostas, o número de direções não nulas em que um efeito de grupos pode aparecer é limitado pelo número de contrastes independentes da hipótese.

A maior raiz,

$$\lambda_1,$$

é o maior valor possível do quociente em Equação 19.12.

Pela propriedade estabelecida em Proposição 5.8, os autovetores generalizados podem ser escolhidos de modo que

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_\ell = \delta_{j\ell}. \quad (19.18)$$

Em particular,

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_\ell = 0, \quad j \neq \ell.$$

As direções características não precisam ser ortogonais na geometria euclidiana usual. Elas podem ser escolhidas ortonormais segundo o produto interno induzido por

$$\mathbf{E}.$$

As raízes subsequentes descrevem, nessa geometria residual, direções adicionais de comparação entre hipótese e erro.

19.4.1 Padronização pela dispersão residual

A relação com a geometria euclidiana torna-se explícita ao transformar o problema pela matriz de erro.

Como

$$\mathbf{E} \succ \mathbf{0},$$

sua raiz quadrada principal e sua inversa existem por Definição 5.9.

Defina

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z}.$$

Substituindo em

$$\mathbf{H}\mathbf{a} = \lambda \mathbf{E}\mathbf{a}$$

e multiplicando à esquerda por

$$\mathbf{E}^{-1/2},$$

obtém-se

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \mathbf{z} = \lambda \mathbf{z}. \quad (19.19)$$

Defina

$$\mathbf{K}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (19.20)$$

Como

$$\mathbf{H} = \mathbf{H}^{\top} \succeq \mathbf{0},$$

e

$$\mathbf{E}^{-1/2}$$

é simétrica,

$$\mathbf{K}_{\text{HE}} = \mathbf{K}_{\text{HE}}^{\top} \succeq \mathbf{0}.$$

O problema generalizado da MANOVA é, portanto, equivalente ao problema espectral ordinário

$$\mathbf{K}_{\text{HE}} \mathbf{z} = \lambda \mathbf{z}.$$

Se

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

então

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = \mathbf{z}^\top \mathbf{K}_{\text{HE}} \mathbf{z}.$$

Logo,

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{z}^\top \mathbf{K}_{\text{HE}} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}. \quad (19.21)$$

A transformação por

$$\mathbf{E}^{-1/2}$$

converte, assim, a geometria definida pela variação residual em uma geometria euclidiana.

Nesse sistema de coordenadas, a matriz de erro é normalizada e

$$\mathbf{K}_{\text{HE}}$$

representa a magnitude da hipótese relativamente à estrutura residual.

As raízes

$$\lambda_1, \dots, \lambda_{r_H}$$

são os autovalores positivos dessa matriz e quantificam as intensidades da hipótese nas direções espectrais do espaço residual padronizado.

Essa construção explica por que a MANOVA não pode ser reduzida à comparação isolada dos elementos diagonais de

$$\mathbf{H}$$

e

E.

As direções relevantes dependem da estrutura completa das duas matrizes, incluindo seus produtos cruzados.

A hipótese matricial é, desse modo, convertida em uma coleção ordenada de razões hipótese/erro. Os quatro critérios clássicos da MANOVA serão construídos a partir dessa mesma coleção de raízes.

19.5 Critérios multivariados

As raízes características

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

resumem a comparação entre a variação atribuída à hipótese e a variação residual nas diferentes direções do espaço das respostas.

Se

$$r_H = \text{posto}(\mathbf{H}),$$

então apenas

$$\lambda_1, \dots, \lambda_{r_H}$$

são positivas, quando

$$r_H > 0,$$

e as demais são nulas.

A hipótese multivariada não é avaliada testando separadamente cada raiz. Os critérios clássicos agregam a coleção de raízes em uma única estatística global.

Para facilitar algumas dessas representações, defina as raízes transformadas

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j}, \quad j = 1, \dots, p. \quad (19.22)$$

Como

$$\lambda_j \geq 0,$$

tem-se

$$0 \leq \theta_j < 1.$$

A transformação

$$\lambda \mapsto \frac{\lambda}{1 + \lambda}$$

é estritamente crescente em

$$[0, \infty),$$

de modo que as raízes λ_j e θ_j preservam a mesma ordenação. A transformação apenas coloca cada razão hipótese/erro em uma escala limitada.

19.5.1 Forma determinantal

Considere

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{H} \succeq \mathbf{0}$$

e

$$\mathbf{E} \succ \mathbf{0}.$$

A matriz

$$\mathbf{E} + \mathbf{H}$$

também é positiva definida e, portanto, possui determinante positivo.

A razão

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} \quad (19.23)$$

compara, por meio de seus determinantes, a dispersão residual multivariada do modelo irrestrito com a do modelo sujeito às restrições da hipótese.

Como

$$\begin{aligned} |\mathbf{E} + \mathbf{H}| &= |\mathbf{E} (\mathbf{I}_p + \mathbf{E}^{-1} \mathbf{H})| \\ &= |\mathbf{E}| |\mathbf{I}_p + \mathbf{E}^{-1} \mathbf{H}|, \end{aligned}$$

segue que

$$\Lambda_W = \frac{1}{|\mathbf{I}_p + \mathbf{E}^{-1} \mathbf{H}|}.$$

Os autovalores de

$$\mathbf{E}^{-1} \mathbf{H}$$

são as raízes características

$$\lambda_1, \dots, \lambda_p.$$

Logo,

$$|\mathbf{I}_p + \mathbf{E}^{-1} \mathbf{H}| = \prod_{j=1}^p (1 + \lambda_j),$$

e

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}. \quad (19.24)$$

As raízes nulas não modificam o produto. Assim, quando

$$r_H > 0,$$

a expressão também pode ser escrita como

$$\Lambda_{\text{W}} = \prod_{j=1}^{r_H} \frac{1}{1 + \lambda_j}.$$

Em termos de Equação 19.22,

$$\Lambda_{\text{W}} = \prod_{j=1}^p (1 - \theta_j). \quad (19.25)$$

Definição 19.2 (Lambda de Wilks). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

e sejam

$$\lambda_1, \dots, \lambda_p$$

as raízes características do par

$$(\mathbf{H}, \mathbf{E}).$$

A lambda de Wilks é

$$\Lambda_{\text{W}} = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} = \prod_{j=1}^p \frac{1}{1 + \lambda_j}.$$

Ela satisfaz

$$0 < \Lambda_{\text{W}} \leq 1,$$

e

$$\Lambda_{\text{W}} = 1$$

se, e somente se,

$$\mathbf{H} = \mathbf{0}.$$

Quanto maiores forem as raízes, menores serão os fatores

$$\frac{1}{1 + \lambda_j}.$$

Por isso, valores menores de

$$\Lambda_W$$

correspondem a maior afastamento relativo entre hipótese e erro.

A estrutura multiplicativa faz com que todas as raízes contribuam para o critério. Uma única raiz elevada pode reduzir substancialmente o produto, mas várias raízes moderadas também podem produzir uma lambda pequena.

A ligação da lambda de Wilks com a razão de verossimilhanças será retomada após a apresentação dos quatro critérios.

19.5.2 Agregação das raízes transformadas

Outra forma de resumir as raízes utiliza as quantidades transformadas

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j}.$$

Definição 19.3 (Traço de Pillai). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

e sejam

$$\lambda_1, \dots, \lambda_p$$

as raízes características do par

$$(\mathbf{H}, \mathbf{E}).$$

O traço de Pillai é

$$V = \text{tr} [\mathbf{H} (\mathbf{H} + \mathbf{E})^{-1}] = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}. \quad (19.26)$$

Portanto,

$$V = \sum_{j=1}^p \theta_j.$$

Se

$$\mathbf{H} = \mathbf{0},$$

todas as raízes são nulas e

$$V = 0.$$

Para cada dimensão,

$$0 \leq \frac{\lambda_j}{1 + \lambda_j} < 1.$$

Assim, uma raiz que cresce indefinidamente produz uma contribuição que se aproxima de 1, em vez de crescer sem limite.

O critério agrega aditivamente as razões hipótese/erro após essa transformação limitada (Pillai, 1955).

19.5.3 Soma das raízes características

O traço de Hotelling–Lawley utiliza diretamente as raízes características, sem transformá-las para uma escala limitada.

Definição 19.4 (Traço de Hotelling–Lawley). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

e sejam

$$\lambda_1, \dots, \lambda_p$$

as raízes características do par

$$(\mathbf{H}, \mathbf{E}).$$

O traço de Hotelling–Lawley é

$$U = \text{tr}(\mathbf{E}^{-1}\mathbf{H}) = \sum_{j=1}^p \lambda_j. \quad (19.27)$$

Como

$$\lambda_j \geq 0,$$

tem-se

$$U \geq 0.$$

Além disso,

$$U = 0$$

se, e somente se,

$$\mathbf{H} = \mathbf{0}.$$

Diferentemente do traço de Pillai, as contribuições

$$\lambda_j$$

não possuem limite superior. Uma direção com razão hipótese/erro muito elevada pode, portanto, exercer forte influência sobre o valor do critério.

19.5.4 Direção característica dominante

O quarto critério concentra toda a comparação na direção de maior razão entre hipótese e erro.

Definição 19.5 (Maior raiz de Roy). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

e sejam

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0$$

as raízes características do par

$$(\mathbf{H}, \mathbf{E}).$$

A maior raiz de Roy é

$$\Theta_R = \lambda_1 = \max_{1 \leq j \leq p} \lambda_j. \quad (19.28)$$

Pela caracterização do quociente de Rayleigh generalizado,

$$\Theta_R = \max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (19.29)$$

Assim, a maior raiz de Roy é a maior razão hipótese/erro que pode ser obtida entre todas as combinações lineares não nulas das respostas.

Se

$$\mathbf{H} = \mathbf{0},$$

então

$$\Theta_R = 0.$$

Ao contrário de Wilks, Pillai e Hotelling–Lawley, que utilizam toda a coleção de raízes, Roy utiliza somente a direção característica dominante.

19.6 Uma mesma estrutura, quatro formas de agregação

Os quatro critérios não correspondem a quatro decomposições diferentes da MANOVA.

Todos são funções da mesma coleção de raízes características

$$\lambda_1, \dots, \lambda_p$$

obtida do problema

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}.$$

As raízes nulas não contribuem para nenhum dos critérios, de modo que as expressões também podem ser restritas às primeiras

$$r_H = \text{posto}(\mathbf{H})$$

raízes positivas.

A Tabela 19.3 resume as diferenças.

Tabela 19.3: Critérios clássicos da MANOVA como funções das mesmas raízes características.

Critério	Expressão em função das raízes	Forma de agregação	Evidência crescente contra H_0
Wilks	$\prod_{j=1}^p (1 + \lambda_j)^{-1}$	produto	valores menores
Pillai	$\sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}$	soma das raízes transformadas	valores maiores
Hotelling–Lawley	$\sum_{j=1}^p \lambda_j$	soma direta	valores maiores
Roy	λ_1	maior raiz	valores maiores

Considere duas situações hipotéticas.

Na primeira, uma única raiz é muito elevada e as demais são pequenas. Na segunda, o afastamento da hipótese está distribuído entre várias raízes moderadas.

A maior raiz de Roy enfatiza especialmente a primeira situação, pois utiliza somente

$$\lambda_1.$$

O traço de Hotelling–Lawley utiliza todas as raízes e mantém diretamente suas magnitudes.

O traço de Pillai utiliza todas as raízes, mas limita a contribuição de cada uma pela transformação

$$\frac{\lambda_j}{1 + \lambda_j}.$$

A lambda de Wilks combina multiplicativamente todas as raízes por meio dos fatores

$$\frac{1}{1 + \lambda_j}.$$

Os critérios podem, portanto, produzir sensibilidades diferentes diante da mesma distribuição do efeito entre as direções características.

Essa diferença não altera sua origem comum: todos resumem a relação espectral entre

H

e

E.

As distribuições de referência e as transformações utilizadas para converter esses critérios em testes com níveis de significância especificados dependem das dimensões e dos graus de liberdade envolvidos. O desenvolvimento operacional dessas calibrações não é necessário para explicar a formulação matemática da técnica e será tratado posteriormente.

19.7 Base probabilística dos critérios

Até este ponto,

H

e

E

foram tratadas como matrizes **observadas**.

As raízes

$$\lambda_1, \dots, \lambda_p$$

e os quatro critérios podem ser calculados algebricamente sempre que as condições matriciais necessárias forem satisfeitas. A normalidade multivariada não é necessária para definir essas quantidades.

Para transformá-las em estatísticas de teste com a teoria de referência clássica, é necessário introduzir o modelo probabilístico.

Considere novamente

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

e denote por

$$\mathbf{e}_i \in \mathbb{R}^p$$

a linha i da matriz aleatória de erros.

Na formulação normal clássica, assume-se

$$\mathbf{e}_1, \dots, \mathbf{e}_n$$

independentes, com

$$\mathbf{e}_i \sim N_p(\mathbf{0}, \Sigma), \quad i = 1, \dots, n, \quad (19.30)$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}$$

satisfaz

$$\Sigma \succ \mathbf{0}.$$

A mesma matriz

$$\Sigma$$

é utilizada para todas as unidades, enquanto a média das respostas é determinada por

$$\mathbf{ZB}.$$

Considere a hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q},$$

$$\text{posto}(\mathbf{C}_1) = g$$

e

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}.$$

Pelos graus de liberdade residuais definidos em Definição 11.12,

$$\nu_E = n - \text{posto}(\mathbf{Z}),$$

conforme Equação 11.77.

Para distinguir as estatísticas matriciais aleatórias de suas realizações observadas, denote por

$$\mathbf{H}$$

a SQPC aleatória associada à hipótese e por

$$\mathbf{E}_{\text{res}}$$

a SQPC residual aleatória.

Especializando Proposição 12.12 para

$$\mathbf{C}_2 = \mathbf{I}_p,$$

tem-se, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma), \quad (19.31)$$

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(\nu_E, \Sigma) \quad (19.32)$$

e

$$\mathbf{H} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (19.33)$$

Esses resultados não precisam ser novamente demonstrados aqui. Eles foram obtidos no Módulo 2 a partir do modelo linear normal multivariado e da distribuição de Wishart.

Há duas consequências estruturais importantes.

Primeiro, as duas matrizes aleatórias possuem a mesma matriz de escala

$$\Sigma.$$

Segundo, sob H_0 , elas são independentes.

É essa estrutura normal–Wishart que fornece a base probabilística dos testes clássicos da MANOVA.

A matriz

$$\mathbf{H}$$

pode ser singular. De fato, se

$$g < p,$$

então

$$\text{posto}(\mathbf{H}) \leq g < p.$$

Isso é compatível com a formulação da MANOVA, pois somente as raízes correspondentes ao posto da hipótese podem ser positivas.

A situação da matriz de erro é diferente. Para a formulação clássica baseada em

$$\mathbf{E}^{-1},$$

é necessário que a realização residual seja positiva definida.

Sob

$$\mathbf{E}_{\text{res}} \sim W_p(\nu_E, \Sigma)$$

com

$$\Sigma \succ \mathbf{0},$$

a condição

$$\nu_E \geq p$$

garante

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

quase certamente.

As implicações de posto e singularidade serão retomadas na seção de existência da formulação clássica.

19.7.1 Papel da covariância residual comum

A matriz

$$\Sigma$$

define a estrutura populacional da variabilidade residual conjunta.

No problema de grupos, assumir uma única matriz

$$\Sigma$$

significa que as diferentes condições possuem a mesma geometria residual, embora seus vetores de médias possam diferir.

Essa estrutura comum é o fundamento populacional da utilização de uma única matriz observada

$$\mathbf{E}$$

como referência para comparar os efeitos presentes em

$$\mathbf{H}.$$

Depois da transformação pela métrica residual, a mesma matriz de erro é utilizada para medir todas as direções da hipótese.

Se diferentes grupos possuem matrizes de covariâncias populacionais distintas, uma única matriz residual agrupada deixa de representar exatamente a dispersão de todas as populações.

Isso não impede o cálculo puramente algébrico de

$$\mathbf{H}, \quad \mathbf{E}$$

e dos critérios quando as matrizes necessárias existem, mas modifica a justificativa probabilística do procedimento clássico e sua distribuição nula.

Procedimentos heterocedásticos, robustos, permutacionais ou regularizados constituem outras formulações e não serão desenvolvidos neste capítulo.

19.7.2 Lambda de Wilks e razão de verossimilhanças

Entre os quatro critérios, a lambda de Wilks possui uma ligação direta com a razão de verossimilhanças do modelo linear normal multivariado.

Para modelos lineares multivariados encaixados, a decomposição das SQPCs estabelecida em Proposição 11.13 fornece

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H},$$

em que $\mathbf{E}_F$ é a SQPC residual do modelo completo e $\mathbf{E}_R$ é a SQPC residual do modelo reduzido.

Sob normalidade, a razão de verossimilhanças foi escrita em Equação 12.64 como

$$\Lambda_{RV} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}.$$

A razão de determinantes

$$\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|}$$

foi definida em Equação 12.65 como a lambda de Wilks.

Na notação da MANOVA,

$$\mathbf{E}_F = \mathbf{E}$$

e

$$\mathbf{E}_R = \mathbf{E} + \mathbf{H}.$$

Portanto,

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}$$

e, pela relação já estabelecida no Módulo 2,

$$\Lambda_{RV} = \Lambda_W^{n/2}. \quad (19.34)$$

A razão de verossimilhanças e a lambda de Wilks são, portanto, funções monotônicas uma da outra no modelo normal considerado.

A formulação por determinantes evidencia a comparação entre modelos completo e reduzido.

A formulação

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}$$

evidencia a mesma comparação como agregação das razões hipótese/erro nas direções características.

Essas duas representações explicam simultaneamente a origem inferencial e a origem espectral da lambda de Wilks (Wilks, 1932).

Os outros três critérios também são estatísticas construídas a partir da mesma estrutura aleatória

$$(\mathbf{H}, \mathbf{E}_{\text{res}}),$$

mas não correspondem simplesmente à razão de verossimilhanças do modelo normal.

A teoria de suas distribuições de referência depende de

$$p, \quad g \quad \text{e} \quad \nu_E,$$

além das hipóteses probabilísticas utilizadas.

O ponto necessário neste capítulo é separar claramente três níveis:

- **estrutura algébrica:** $\mathbf{H}$, $\mathbf{E}$ e suas raízes características;
- **estatísticas globais:** Wilks, Pillai, Hotelling–Lawley e Roy;
- **inferência clássica:** distribuição dos critérios derivada da estrutura normal–Wishart sob H_0 .

Essa separação permite compreender por que os critérios podem ser calculados sem normalidade, ao mesmo tempo em que suas calibrações clássicas dependem do modelo probabilístico.

19.8 Casos particulares

A formulação matricial da MANOVA deve recuperar procedimentos já conhecidos quando a dimensão da resposta ou o posto da hipótese são reduzidos. Esses casos ajudam a interpretar as raízes características e mostram que ANOVA, T^2 de Hotelling e MANOVA pertencem à mesma estrutura de comparação entre hipótese e erro.

19.8.1 Uma única resposta

Considere

$$p = 1.$$

Nesse caso,

$$\mathbf{H} = (H)$$

e

$$\mathbf{E} = (E)$$

são matrizes 1×1 . Sob a condição

$$E > 0,$$

existe no máximo uma raiz característica não nula, dada por

$$\lambda = \frac{H}{E}. \quad (19.35)$$

Os quatro critérios tornam-se

$$\Lambda_W = \frac{1}{1 + \lambda},$$

$$V = \frac{\lambda}{1 + \lambda},$$

$$U = \lambda$$

e

$$\Theta_R = \lambda.$$

Todos são funções monotônicas da mesma razão

$$\frac{H}{E}.$$

Se

$$\nu_H$$

e

$$\nu_E$$

são, respectivamente, os graus de liberdade da hipótese e do erro, a estatística usual da ANOVA é construída a partir das médias quadráticas:

$$F = \frac{H/\nu_H}{E/\nu_E} = \frac{\nu_E}{\nu_H} \lambda. \quad (19.36)$$

Assim, quando existe uma única resposta, os quatro critérios multivariados e a estatística F contêm a mesma informação sobre a razão entre variação atribuída à hipótese e variação residual.

A MANOVA recupera, portanto, a estrutura da ANOVA quando

$$p = 1.$$

A diferença essencial no caso multivariado aparece quando

$$p > 1,$$

pois a relação entre hipótese e erro deixa de ser descrita por uma única razão escalar e passa a depender das diferentes direções do espaço das respostas.

19.8.2 Duas populações

Considere agora duas populações, com vetores de médias

$$\mu_1, \mu_2 \in \mathbb{R}^p,$$

e a hipótese

$$H_0 : \mu_1 = \mu_2.$$

Há somente um contraste independente entre os dois grupos. Portanto,

$$g = 1$$

e

$$\text{posto}(\mathbf{H}) \leq 1.$$

Consequentemente, existe no máximo uma raiz característica positiva,

$$\lambda_1.$$

Nessa situação,

$$\Lambda_W = \frac{1}{1 + \lambda_1},$$

$$V = \frac{\lambda_1}{1 + \lambda_1},$$

$$U = \lambda_1$$

e

$$\Theta_R = \lambda_1.$$

Os quatro critérios são novamente funções monotônicas de uma única quantidade.

Considere o caso clássico de duas amostras independentes de tamanhos

$$n_1 \quad \text{e} \quad n_2,$$

provenientes de populações com matriz de covariâncias comum.

Defina a diferença observada entre os vetores de médias amostrais por

$$\mathbf{d} = \bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2 \in \mathbb{R}^p$$

e seja

$$\mathbf{S}_p \in \mathbb{R}^{p \times p}$$

a matriz de covariâncias agrupada observada definida em Equação 12.106.

A matriz residual de somas de quadrados e produtos cruzados é

$$\mathbf{E} = (n_1 + n_2 - 2)\mathbf{S}_p.$$

A matriz associada à hipótese de igualdade dos dois vetores de médias é

$$\mathbf{H} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top.$$

Como

$$\text{posto}(\mathbf{d} \mathbf{d}^\top) \leq 1,$$

a matriz $\mathbf{H}$ possui posto no máximo 1.

Supondo

$$\mathbf{E} \succ \mathbf{0},$$

a única raiz potencialmente positiva é

$$\lambda_1 = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d}^\top \mathbf{E}^{-1} \mathbf{d}.$$

Por outro lado, a estatística definida em Definição 12.6 é

$$T^2 = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d}^\top \mathbf{S}_p^{-1} \mathbf{d}.$$

Como

$$\mathbf{E}^{-1} = \frac{1}{n_1 + n_2 - 2} \mathbf{S}_p^{-1},$$

segue que

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}. \quad (19.37)$$

A relação é algébrica e mostra que a comparação de duas populações por T^2 e a MANOVA de dois grupos são construídas a partir da mesma razão multivariada entre diferença de médias e dispersão residual.

A direção característica correspondente pode ser escolhida proporcionalmente a

$$\mathbf{E}^{-1} (\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2).$$

De fato, tomando

$$\mathbf{a} = \mathbf{E}^{-1} \mathbf{d},$$

tem-se

$$\mathbf{E} \mathbf{a} = \mathbf{d},$$

enquanto

$$\begin{aligned} \mathbf{H} \mathbf{a} &= \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top \mathbf{E}^{-1} \mathbf{d} \\ &= \lambda_1 \mathbf{d} \\ &= \lambda_1 \mathbf{E} \mathbf{a}. \end{aligned}$$

Essa direção combina as respostas levando em conta a estrutura residual de covariâncias.

Com três ou mais grupos, ou com qualquer hipótese para a qual

$$\text{posto}(\mathbf{H}) > 1,$$

várias raízes podem ser positivas. É nesse caso que as diferentes formas de agregação utilizadas por Wilks, Pillai, Hotelling–Lawley e Roy podem produzir resumos efetivamente distintos da mesma estrutura espectral.

19.9 Geometria da MANOVA

A equação

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

mostra que a geometria da MANOVA é definida relativamente à variabilidade residual.

Como

$$\mathbf{E} \succ \mathbf{0},$$

pode-se impor a normalização

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1 \tag{19.38}$$

sem perda de generalidade, pois o quociente de Rayleigh generalizado é invariante à multiplicação de $\mathbf{a}$ por um escalar não nulo.

Sob essa restrição, maximizar

$$\frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}$$

equivale a maximizar

$$\mathbf{a}^\top \mathbf{H} \mathbf{a}.$$

A restrição

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

fixa a variação residual da combinação linear definida por $\mathbf{a}$.

Assim, uma direção com valor elevado de

$$\mathbf{a}^\top \mathbf{H} \mathbf{a}$$

é uma combinação das respostas na qual o efeito associado à hipótese é grande depois de controlar a escala residual dessa mesma combinação.

Se

$$\mathbf{a}_j$$

é um autovetor generalizado satisfazendo

$$\mathbf{H} \mathbf{a}_j = \lambda_j \mathbf{E} \mathbf{a}_j$$

e normalizado de modo que

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_j = 1,$$

então

$$\begin{aligned} \mathbf{a}_j^\top \mathbf{H} \mathbf{a}_j &= \lambda_j \mathbf{a}_j^\top \mathbf{E} \mathbf{a}_j \\ &= \lambda_j. \end{aligned} \tag{19.39}$$

Cada raiz característica pode, portanto, ser interpretada como a magnitude da hipótese na correspondente direção quando a variação residual dessa combinação foi normalizada para 1.

Além disso, as direções podem ser escolhidas de modo que

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_\ell = 0, \quad j \neq \ell,$$

conforme Equação 19.18.

A ortogonalidade relevante não é, em geral, a ortogonalidade euclidiana usual. Ela é definida pela métrica induzida por

$$\mathbf{E}.$$

19.9.1 Geometria após padronização pelo erro

A transformação introduzida em Equação 19.19 torna essa geometria explícita.

Defina

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Como

$$\mathbf{E} \succ \mathbf{0},$$

a transformação é invertível e

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z}.$$

Então,

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = \mathbf{z}^\top \mathbf{z}.$$

Consequentemente, a restrição

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

transforma-se em

$$\mathbf{z}^\top \mathbf{z} = 1.$$

O elipsoide definido pela forma quadrática residual é convertido na esfera unitária da geometria euclidiana.

Ao mesmo tempo,

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = \mathbf{z}^\top \mathbf{K}_{\text{HE}} \mathbf{z},$$

em que

$$\mathbf{K}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}$$

foi definida em Equação 19.20.

O problema torna-se

$$\max_{\mathbf{z}^T \mathbf{z} = 1} \mathbf{z}^T \mathbf{K}_{\text{HE}} \mathbf{z}. \quad (19.40)$$

Esse é o problema de Rayleigh ordinário para a matriz simétrica semidefinida positiva

$$\mathbf{K}_{\text{HE}}.$$

A primeira direção transformada é um autovetor associado ao maior autovalor

$$\lambda_1,$$

e as direções seguintes podem ser escolhidas ortonormais e associadas às demais raízes positivas.

A transformação não elimina a variabilidade residual do problema. Ela a incorpora à mudança de coordenadas por

$$\mathbf{E}^{-1/2},$$

fazendo com que a comparação entre hipótese e erro seja expressa em uma geometria euclidiana padronizada.

Assim, a MANOVA não procura simplesmente direções em que

$$\mathbf{H}$$

seja grande.

Ela procura direções em que o efeito representado por $\mathbf{H}$ seja grande **relativamente à estrutura residual representada por $\mathbf{E}$** .

Essa distinção é central. Uma direção pode apresentar grande diferença absoluta entre grupos e, ainda assim, produzir raiz pequena se também apresentar grande dispersão residual. Inversamente, um afastamento absoluto moderado pode produzir uma razão elevada quando ocorre em uma direção de baixa variabilidade residual.

19.10 Invariância a transformações lineares das respostas

A formulação da MANOVA não deve depender da base particular utilizada para representar o mesmo espaço de respostas.

Considere uma matriz não singular

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e transforme as respostas por

$$\mathbf{y}^* = \mathbf{y}\mathbf{A}. \quad (19.41)$$

No modelo transformado,

$$\mathbf{y}^* = \mathbf{Z}\mathbf{B}^* + \mathcal{E}^*,$$

com

$$\mathbf{B}^* = \mathbf{B}\mathbf{A}$$

e

$$\mathcal{E}^* = \mathcal{E}\mathbf{A}.$$

Para representar a mesma hipótese no novo sistema de coordenadas, transforma-se também seu valor de referência:

$$\Theta_0^* = \Theta_0\mathbf{A}.$$

Assim,

$$\mathbf{C}_1\mathbf{B} = \Theta_0$$

se, e somente se,

$$\mathbf{C}_1\mathbf{B}^* = \Theta_0^*.$$

As matrizes observadas de hipótese e erro transformam-se por congruência:

$$\mathbf{H}^* = \mathbf{A}^\top \mathbf{H} \mathbf{A} \quad (19.42)$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (19.43)$$

Como $\mathbf{A}$ é não singular,

$$\mathbf{H}^* \succeq \mathbf{0}$$

sempre que

$$\mathbf{H} \succeq \mathbf{0},$$

e

$$\mathbf{E}^* \succ \mathbf{0}$$

sempre que

$$\mathbf{E} \succ \mathbf{0}.$$

Proposição 19.1 (Invariância das raízes características). *Sejam*

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{H} \succeq \mathbf{0} \quad e \quad \mathbf{E} \succ \mathbf{0}.$$

Considere uma matriz não singular

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{H}^* = \mathbf{A}^\top \mathbf{H} \mathbf{A}$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}.$$

Então os pares

$$(\mathbf{H}, \mathbf{E})$$

e

$$(\mathbf{H}^*, \mathbf{E}^*)$$

possuem as mesmas raízes características, incluindo suas multiplicidades.

Comprovação. As raízes características do par transformado são os valores de λ que satisfazem

$$\det(\mathbf{H}^* - \lambda \mathbf{E}^*) = 0.$$

Pelas definições de $\mathbf{H}^*$ e $\mathbf{E}^*$,

$$\begin{aligned} \det(\mathbf{H}^* - \lambda \mathbf{E}^*) &= \det[\mathbf{A}^\top (\mathbf{H} - \lambda \mathbf{E}) \mathbf{A}] \\ &= \det(\mathbf{A}^\top) \det(\mathbf{H} - \lambda \mathbf{E}) \det(\mathbf{A}) \\ &= \det(\mathbf{A})^2 \det(\mathbf{H} - \lambda \mathbf{E}). \end{aligned}$$

Como

$$\det(\mathbf{A}) \neq 0,$$

as duas equações características possuem exatamente os mesmos zeros, com as mesmas multiplicidades. $\square$

Como os quatro critérios clássicos dependem apenas das raízes

$$\lambda_1, \dots, \lambda_p,$$

eles também permanecem invariantes sob transformações lineares não singulares das respostas, desde que a hipótese seja expressa no sistema transformado correspondente.

Essa propriedade inclui mudanças de unidades realizadas por fatores não nulos e mudanças invertíveis de coordenadas no espaço das respostas.

As coordenadas das direções características, entretanto, dependem da representação escolhida.

Se

$$\mathbf{a}_j$$

é uma direção característica no sistema original, defina

$$\mathbf{a}_j^* = \mathbf{A}^{-1}\mathbf{a}_j.$$

Então a combinação linear das respostas é preservada:

$$\mathcal{Y}^*\mathbf{a}_j^* = \mathcal{Y}\mathbf{A}\mathbf{A}^{-1}\mathbf{a}_j = \mathcal{Y}\mathbf{a}_j.$$

Além disso,

$$\begin{aligned}\mathbf{H}^*\mathbf{a}_j^* &= \mathbf{A}^\top \mathbf{H} \mathbf{A} \mathbf{A}^{-1} \mathbf{a}_j \\ &= \mathbf{A}^\top \mathbf{H} \mathbf{a}_j \\ &= \lambda_j \mathbf{A}^\top \mathbf{E} \mathbf{a}_j \\ &= \lambda_j \mathbf{E}^* \mathbf{a}_j^*.\end{aligned}$$

Portanto, as coordenadas dos vetores mudam com a base, enquanto as raízes que quantificam a relação entre hipótese e erro permanecem invariantes.

Essa distinção é importante para a interpretação: os coeficientes numéricos de uma direção característica dependem das unidades e da base utilizadas para representar as respostas, mas a estrutura espectral da comparação entre hipótese e erro não depende de uma mudança invertível de coordenadas.

19.11 Existência, posto e identificação das direções

A formulação espectral desenvolvida neste capítulo utilizou a condição

$$\mathbf{E} \succ \mathbf{0}.$$

Essa condição possui papel algébrico e geométrico. Ela garante a existência de

$$\mathbf{E}^{-1}, \quad \mathbf{E}^{1/2} \quad \text{e} \quad \mathbf{E}^{-1/2},$$

e assegura que

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0}.$$

Consequentemente, o quociente de Rayleigh generalizado

$$\frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}$$

está definido em todas as direções não nulas e o problema generalizado pode ser convertido no problema espectral simétrico de Equação [19.19](#).

A existência da formulação clássica depende, entretanto, de outras condições relacionadas ao posto da hipótese, ao posto da matriz residual e à estimabilidade da função paramétrica testada.

19.11.1 Posto da matriz de hipótese

Considere a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q},$$

$$\text{posto}(\mathbf{C}_1) = g$$

e função

$$\mathbf{C}_1 \mathbf{B}$$

estimável.

A construção da SQPC da hipótese implica

$$\text{posto}(\mathbf{H}) \leq \min(p, g). \quad (19.44)$$

Como

$$r_H = \text{posto}(\mathbf{H}),$$

existem exatamente

$$r_H$$

raízes características positivas, conforme Definição 19.1.

Portanto,

$$r_H \leq \min(p, g),$$

como estabelecido em Equação 19.16.

No caso do efeito completo de um fator com

$$K$$

grupos,

$$g = K - 1,$$

e, conseqüentemente,

$$r_H \leq \min(p, K - 1).$$

O número de respostas não determina sozinho o número de direções relevantes para a hipótese.

Uma hipótese de baixo posto pode produzir apenas poucas raízes positivas mesmo quando

$$p$$

é elevado.

Esse resultado possui uma interpretação estatística direta: o número de direções nas quais a hipótese pode produzir separação é limitado simultaneamente pela dimensão do espaço das respostas e pelo número de restrições linearmente independentes impostas pelo contraste testado.

19.11.2 Não singularidade da matriz de erro

A matriz residual observada

$$\mathbf{E} = \widehat{\mathbf{U}}^{\top} \widehat{\mathbf{U}}$$

possui posto no máximo

$$\min(p, \nu_E),$$

em que

$$\nu_E = n - \text{posto}(\mathbf{Z})$$

é o número de graus de liberdade residuais.

Consequentemente, uma condição necessária para que

$$\mathbf{E}$$

possa ser positiva definida é

$$\nu_E \geq p. \tag{19.45}$$

A condição é apenas necessária em termos puramente algébricos: mesmo quando

$$\nu_E \geq p,$$

dependências lineares exatas entre as colunas residuais observadas podem tornar

$$\mathbf{E}$$

singular.

Sob o modelo linear normal multivariado utilizado na seção probabilística,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p\left(\nu_E, \Sigma\right),$$

com

$$\Sigma \succ \mathbf{0},$$

a condição

$$\nu_E \geq p$$

garante

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

quase certamente.

Nesse caso, a inversa e a raiz quadrada inversa utilizadas na formulação clássica existem com probabilidade 1.

Quando

$$p > \nu_E,$$

tem-se necessariamente

$$\text{posto}(\mathbf{E}) \leq \nu_E < p,$$

de modo que

$$\mathbf{E}$$

é singular.

Nesse cenário, a formulação clássica baseada em

$$\mathbf{E}^{-1}$$

e

$$\mathbf{E}^{-1/2}$$

não pode ser aplicada diretamente.

Pseudoinversas, regularização e métodos desenvolvidos para situações de alta dimensão alteram o problema espectral ou sua teoria inferencial e pertencem ao tratamento metodológico posterior.

19.11.3 Estimabilidade da hipótese

A existência de

$$\mathbf{H}$$

como representação de uma hipótese estatisticamente identificada exige que a função paramétrica testada seja estimável.

No modelo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

a matriz

$$\mathbf{B}$$

é identificada de forma usual quando

$$\mathbf{Z}$$

possui posto completo de colunas.

Entretanto, posto deficiente de

$$\mathbf{Z}$$

não implica que nenhuma hipótese possa ser testada.

Para a hipótese utilizada neste capítulo,

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

é necessário que

$$\mathbf{C}_1\mathbf{B}$$

seja estimável.

A condição foi escrita em Equação 19.5 como

$$\mathbf{C}_1 = \mathbf{C}_1\mathbf{Z}^+\mathbf{Z}.$$

Quando essa condição é satisfeita, o valor de

$$\mathbf{C}_1\mathbf{B}$$

não depende da escolha particular de uma solução para

$$\mathbf{B}$$

em uma parametrização não identificada.

Assim, o objeto inferencial da MANOVA é a **função estimável especificada pela hipótese**, e não necessariamente cada elemento de

$$\mathbf{B}$$

considerado isoladamente.

A hipótese linear geral definida em Definição 11.17 permite a formulação bilateral

$$\mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \boldsymbol{\Theta}_0.$$

Neste capítulo foi utilizado

$$\mathbf{C}_2 = \mathbf{I}_p$$

para testar simultaneamente o efeito sobre as respostas originais.

19.11.4 Identificação das direções características

As raízes características positivas

$$\lambda_1, \dots, \lambda_{r_H}$$

são determinadas pelo par

$$(\mathbf{H}, \mathbf{E}).$$

Os autovetores generalizados correspondentes possuem as indeterminações próprias de problemas espectrais.

Considere uma raiz positiva simples

$$\lambda_j.$$

Se

$$\mathbf{a}_j$$

satisfaz

$$\mathbf{H}\mathbf{a}_j = \lambda_j \mathbf{E}\mathbf{a}_j,$$

então, para qualquer

$$c \neq 0,$$

o vetor

$$c\mathbf{a}_j$$

satisfaz a mesma equação.

A direção, e não o comprimento do vetor, é o objeto determinado pelo problema.

Utilizando a normalização

$$\mathbf{a}_j^\top \mathbf{E} \mathbf{a}_j = 1,$$

a indeterminação de escala é eliminada e permanece a indeterminação de sinal:

$$\mathbf{a}_j \quad \text{e} \quad -\mathbf{a}_j$$

representam a mesma direção.

Se uma raiz positiva possui multiplicidade maior que 1, os autovetores individuais associados não são determinados unicamente.

Nesse caso, o objeto identificado é o **subespaço característico** associado à raiz repetida. Diferentes bases ortonormais segundo a métrica de

$$\mathbf{E}$$

podem representar o mesmo subespaço sem alterar as raízes nem os quatro critérios globais.

As raízes nulas também podem possuir alta multiplicidade. As direções pertencentes ao subespaço associado a

$$\lambda = 0$$

não representam variação atribuída à hipótese relativamente ao erro, pois

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = 0$$

nessas direções.

Por isso, a interpretação substantiva das combinações lineares concentra-se normalmente nas direções associadas às raízes positivas.

A distinção entre raízes e direções é importante:

- as raízes quantificam a intensidade relativa da hipótese;
- as direções indicam combinações das respostas em que essa intensidade é observada;
- em caso de multiplicidade, o subespaço pode estar identificado mesmo quando uma base particular não está.

19.12 Pressupostos e limites

A MANOVA reúne três níveis distintos de estrutura:

- o modelo para as médias;
- a comparação algébrica entre hipótese e erro;
- a teoria probabilística utilizada para realizar inferência.

As condições necessárias não possuem todas a mesma função.

19.12.1 Estrutura correta da média

O modelo pressupõe que

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

Assim, grupos, tratamentos, covariáveis e demais efeitos relevantes devem estar representados adequadamente em

$$\mathbf{Z}.$$

Uma especificação inadequada da estrutura média modifica os resíduos e, conseqüentemente,

$$\mathbf{E}.$$

Ela também modifica o significado da variação atribuída à hipótese e representada por

$$\mathbf{H}.$$

Portanto, uma raiz elevada não possui interpretação isolada da hipótese e do modelo que produziram essas duas matrizes.

19.12.2 Estimabilidade da hipótese

A hipótese precisa corresponder a uma função estimável do modelo.

Para a formulação utilizada neste capítulo,

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

isso exige a condição de Equação 19.5.

Essa é uma condição de **identificação do objeto inferencial**. Ela não decorre de normalidade e deve ser verificada antes da construção de uma interpretação probabilística para o teste.

19.12.3 Independência entre unidades

Na formulação probabilística clássica, as linhas da matriz de erros são independentes:

$$\mathbf{e}_1, \dots, \mathbf{e}_n.$$

A dependência entre as componentes de uma mesma resposta vetorial é permitida e representada por

$$\Sigma.$$

O que a formulação clássica exclui é dependência não modelada entre unidades distintas.

Medidas repetidas, séries temporais, observações agrupadas, estruturas espaciais ou outros mecanismos de dependência entre unidades exigem modelos de covariância apropriados. A MANOVA clássica formulada neste capítulo não incorpora automaticamente essas estruturas.

19.12.4 Covariância residual comum

A formulação normal clássica utiliza

$$\text{Cov}(\mathbf{e}_i | \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n.$$

Portanto, a mesma matriz de covariâncias residual é utilizada para todas as unidades.

No caso de grupos, isso corresponde à homogeneidade das matrizes de covariâncias populacionais dentro dos grupos.

Essa condição fornece uma geometria residual comum e justifica a utilização de uma única matriz

$$\mathbf{E}$$

para padronizar as diferentes direções da hipótese.

Se diferentes grupos possuem matrizes de covariâncias distintas, a matriz residual combinada deixa de representar exatamente a dispersão de todas as populações sob um único

$$\Sigma.$$

Os critérios ainda podem ser calculados algebricamente quando as matrizes necessárias existem, mas a teoria inferencial clássica baseada na estrutura normal–Wishart deixa de corresponder exatamente ao mecanismo gerador considerado.

19.12.5 Não singularidade da covariância residual

A formulação clássica considera

$$\Sigma \succ \mathbf{0}.$$

Isso exclui relações lineares exatas entre as respostas no modelo populacional.

A condição populacional

$$\Sigma \succ \mathbf{0}$$

não deve ser confundida com a condição amostral

$$\mathbf{E} \succ \mathbf{0}.$$

A primeira pertence ao modelo probabilístico.

A segunda depende também do número de graus de liberdade residuais e da configuração observada dos resíduos.

Sob normalidade e

$$\nu_E \geq p,$$

a distribuição Wishart fornece

$$\mathbf{E} \succ \mathbf{0}$$

quase certamente.

19.12.6 Normalidade multivariada

A hipótese

$$\mathbf{e}_i \sim N_p(\mathbf{0}, \Sigma)$$

não é necessária para construir:

$$\mathbf{H}, \quad \mathbf{E},$$

o quociente

$$\frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}},$$

as raízes características ou os quatro critérios clássicos, desde que as operações matriciais envolvidas estejam definidas.

A normalidade é utilizada na teoria inferencial clássica para obter as distribuições Wishart de

$$\mathbf{H}$$

e

$$\mathbf{E}_{\text{res}},$$

sua independência sob

$$H_0$$

e, a partir dessa estrutura, as distribuições de referência dos critérios.

Portanto, deve-se distinguir:

- **formulação algébrica:** existe independentemente da normalidade;
- **modelo probabilístico clássico:** introduz normalidade, independência entre unidades e covariância residual comum;
- **inferência clássica:** utiliza a estrutura normal–Wishart para calibrar os critérios.

Transformações aproximadas dos critérios, procedimentos robustos, métodos de reamostragem, testes por permutação e formulações heterocedásticas pertencem à etapa metodológica e não serão desenvolvidos neste capítulo.

19.12.7 Multicolinearidade e dependência exata entre respostas

Correlação elevada entre respostas não invalida, por si só, a formulação multivariada.

A própria MANOVA utiliza as covariâncias entre respostas para construir

$$\mathbf{E}$$

e determinar as direções características.

O problema estrutural ocorre quando existe dependência linear exata suficiente para tornar a matriz residual singular.

Nesse caso,

$$\mathbf{E}^{-1}$$

não existe e a formulação espectral clássica adotada neste capítulo deixa de estar disponível diretamente.

Assim, deve-se distinguir forte associação entre respostas de singularidade da estrutura residual.

19.13 Relações com outras técnicas

A MANOVA compartilha objetos matemáticos com outras técnicas, mas seu objetivo é específico: testar hipóteses sobre parâmetros de um modelo linear com múltiplas respostas.

19.13.1 ANOVA

Quando

$$p = 1,$$

as matrizes

$$\mathbf{H}$$

e

$$\mathbf{E}$$

reduzem-se a escalares e existe no máximo uma raiz característica.

Por Equação [19.36](#),

$$F = \frac{\nu_E}{\nu_H} \lambda.$$

Assim, os quatro critérios multivariados tornam-se transformações monotônicas da mesma razão utilizada na ANOVA.

A MANOVA preserva a lógica de comparação entre hipótese e erro, substituindo somas de quadrados escalares por matrizes de somas de quadrados e produtos cruzados.

19.13.2 T^2 de Hotelling

Quando a hipótese de comparação entre dois grupos possui uma única direção independente,

$$g = 1,$$

e existe no máximo uma raiz positiva.

No caso clássico de duas amostras independentes, Equação [19.37](#) estabelece

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}.$$

A MANOVA de dois grupos e o teste

$$T^2$$

de Hotelling utilizam, portanto, a mesma estrutura de comparação multivariada.

19.13.3 Regressão multivariada

MANOVA e regressão multivariada são casos do mesmo modelo

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

A distinção principal está na natureza dos termos representados em

$$\mathbf{Z}$$

e nas hipóteses formuladas sobre

$$\mathbf{B}.$$

Indicadores e contrastes podem representar grupos e fatores; variáveis quantitativas podem representar covariáveis ou preditores contínuos.

Em ambos os casos, hipóteses estimáveis sobre

$$\mathbf{C}_1\mathbf{B}$$

podem ser avaliadas pela mesma construção de matrizes de hipótese e erro.

Portanto, a MANOVA não deve ser entendida como um modelo inteiramente separado da regressão multivariada. Ela utiliza a teoria do modelo linear multivariado para testar efeitos conjuntos sobre várias respostas.

19.13.4 Análise Discriminante

No problema de grupos conhecidos, as matrizes que aparecem na MANOVA possuem correspondentes diretos na formulação geométrica da Análise Discriminante.

A matriz de hipótese contém a estrutura associada às diferenças entre grupos, enquanto a matriz de erro contém a estrutura de dispersão dentro dos grupos.

Por isso, o problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

também aparecerá na formulação discriminante de Fisher.

A coincidência algébrica não implica coincidência de objetivos.

Na MANOVA, as matrizes de hipótese e erro são utilizadas para testar diferenças na função paramétrica multivariada especificada pela hipótese. Na Análise Discriminante, estruturas correspondentes de dispersão entre e dentro dos grupos serão utilizadas para construir combinações das variáveis que favoreçam separação, discriminação e classificação.

Assim, as mesmas matrizes e o mesmo problema de autovalores generalizados podem receber interpretações estatísticas diferentes segundo o objetivo da técnica.

19.14 Síntese

A MANOVA é formulada no modelo linear multivariado

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

e testa funções estimáveis dos parâmetros. Para a hipótese

$$H_0 : \mathbf{C}_1\mathbf{B} = \Theta_0,$$

a variação associada ao afastamento da hipótese é representada por

$$\mathbf{H} \succeq \mathbf{0},$$

enquanto a variação residual é representada por

$$\mathbf{E} \succeq \mathbf{0}.$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

cada combinação linear das respostas definida por $\mathbf{a} \neq \mathbf{0}$ pode ser avaliada pelo quociente

$$\mathcal{R}_{\mathbf{H},\mathbf{E}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}.$$

Os valores extremos desse quociente são obtidos pelo problema de autovalores generalizados

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}.$$

Equivalentemente, a transformação

$$\mathbf{K}_{\mathbf{H}\mathbf{E}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}$$

converte a comparação em um problema espectral simétrico na geometria em que a dispersão residual foi padronizada.

Se

$$r_H = \text{posto}(\mathbf{H}),$$

existem exatamente r_H raízes positivas, com

$$r_H \leq \min(p, g).$$

Essas raízes quantificam a magnitude da hipótese relativamente ao erro nas direções características.

Os quatro critérios clássicos agregam a mesma coleção de raízes de formas diferentes:

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j},$$

$$V = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j},$$

$$U = \sum_{j=1}^p \lambda_j$$

e

$$\Theta_R = \lambda_1.$$

Wilks utiliza uma agregação multiplicativa; Pillai soma raízes transformadas para uma escala limitada; Hotelling–Lawley soma diretamente as raízes; Roy utiliza apenas a direção dominante. Os quatro critérios descrevem, portanto, a mesma estrutura espectral por funções distintas.

A construção das matrizes, das raízes e dos critérios é algébrica e não exige normalidade multivariada. Sob o modelo linear normal, a estrutura normal–Wishart fornece a base probabilística da inferência clássica e da relação entre a lambda de Wilks e a razão de verossimilhanças.

A formulação exige ainda distinguir estimabilidade da hipótese, posto e não singularidade da estrutura residual, independência entre unidades, covariância residual comum e normalidade. Essas condições desempenham papéis diferentes: algumas garantem que os objetos algébricos estejam definidos e outras sustentam a interpretação probabilística dos testes.

Quando $p = 1$, a estrutura reduz-se à comparação univariada entre hipótese e erro. Em problemas com uma única direção independente, a MANOVA relaciona-se ao T^2 de Hotelling. MANOVA e regressão multivariada pertencem ao mesmo modelo linear e diferem principalmente pelos termos representados no delineamento e pelas hipóteses formuladas.

A MANOVA integra modelo linear multivariado, funções estimáveis, formas quadráticas, produtos internos induzidos, autovalores generalizados, decomposição espectral, normal multivariada e distribuição Wishart para testar efeitos conjuntos sobre várias respostas.

No próximo capítulo, os grupos permanecem conhecidos, mas o objetivo muda. A Análise Discriminante utilizará estruturas de dispersão entre e dentro dos grupos para construir direções de separação e, em sua formulação probabilística, regras para classificar novas observações.

20 Formulação da Análise Discriminante

A Análise Discriminante estuda problemas com grupos previamente conhecidos e unidades descritas por vetores de características quantitativas. Seus objetivos incluem representar a separação entre os grupos e construir regras para classificar novas observações.

Duas formulações serão utilizadas. Na formulação probabilística, as classes são descritas por distribuições condicionais e a classificação é tratada como um problema de decisão envolvendo probabilidades *a priori*, perdas e probabilidades posteriores. Na formulação geométrica de Fisher, procuram-se combinações lineares que maximizem a separação entre grupos relativamente à dispersão intragrupos (Anderson, 2003; Fisher, 1936; Johnson; Wichern, 2007; Rencher; Christensen, 2012).

As duas construções resolvem problemas distintos, embora possam produzir estruturas matemáticas relacionadas sob condições específicas. O capítulo desenvolve a regra de Bayes, as regras discriminantes linear e quadrática sob normalidade, o critério de Fisher e sua formulação por autovalores generalizados.

Parâmetros populacionais, quantidades amostrais e regras estimadas serão distinguidos explicitamente. Algoritmos, regularização, seleção de variáveis e avaliação preditiva pertencem à etapa metodológica posterior.

Os elementos centrais são sintetizados na Tabela 20.1.

Tabela 20.1: Formulações complementares da Análise Discriminante.

Formulação	Objeto de partida	Problema	Resultado
decisão estatística	densidades condicionais, probabilidades <i>a priori</i> e perdas	escolher uma ação para uma nova observação	regra de Bayes
normal com covariância comum	μ_k, Σ e π_k	minimizar risco sob perda zero-um	regra discriminante linear
normal com covariâncias distintas	μ_k, Σ_k e π_k	minimizar risco sob perda zero-um	regra discriminante quadrática
geométrica de Fisher	dispersões intragrupos e entre grupos	maximizar separação relativa	direções e coordenadas discriminantes

20.1 O problema de discriminação e classificação

Considere uma variável aleatória de classe

$$C \in \{1, \dots, K\}, \quad K \geq 2,$$

e um vetor aleatório de características

$$\mathbf{x} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p.$$

Para cada classe

$$k \in \{1, \dots, K\},$$

existe uma distribuição condicional de

$$\mathbf{x} \mid C = k.$$

Uma realização

$$\mathbf{x} \in \mathbb{R}^p$$

representa os valores observados das características de uma unidade.

Durante a construção da técnica, os rótulos das unidades utilizadas para caracterizar os grupos são conhecidos. Por isso, a Análise Discriminante pertence aos problemas supervisionados.

Na classificação, procura-se uma regra

$$\psi : \mathbb{R}^p \longrightarrow \{1, \dots, K\}$$

que associe uma nova observação

$$\mathbf{x}$$

a uma das classes.

A qualidade preditiva de uma regra estimada constitui um problema adicional. Taxas de erro observadas, matrizes de confusão, validação cruzada e outros procedimentos de avaliação não serão confundidos com a formulação matemática da regra.

20.2 Classificação como problema de decisão

A classificação pode ser formulada como um problema de decisão. No Módulo 2, funções de perda e risco foram introduzidas no contexto da estimação; aqui, esses conceitos são aplicados a ações de classificação e complementados por probabilidades *a priori*, probabilidades posteriores e pela regra de Bayes.

Para cada

$$\mathbf{x} \in \mathbb{R}^p,$$

deve-se escolher uma ação

$$a \in \mathcal{A}, \quad \mathcal{A} = \{1, \dots, K\},$$

em que a ação

$$a = g$$

significa classificar a observação na classe k .

A decisão depende de três objetos:

1. probabilidades *a priori* das classes;
2. distribuições condicionais das características;
3. perdas associadas às possíveis decisões.

20.2.1 Distribuição prévia das classes

Definição 20.1 (Probabilidades a priori das classes). Seja

$$C \in \{1, \dots, K\}$$

uma variável aleatória de classe.

As **probabilidades a priori** são

$$\pi_k = P(C = k), \quad k = 1, \dots, K,$$

tais que

$$\pi_k > 0$$

e

$$\sum_{k=1}^K \pi_k = 1.$$

As probabilidades *a priori* descrevem a distribuição das classes antes da observação das características da nova unidade.

Elas são parâmetros do problema de decisão. Não devem ser confundidas automaticamente com proporções de grupos observadas em uma amostra. A relação entre probabilidades populacionais e estimativas amostrais será discutida posteriormente.

20.2.2 Densidades condicionais e probabilidades posteriores

Suponha que, para cada classe k ,

$$\mathbf{X} \mid C = k$$

possua densidade

$$f_k(\mathbf{x}) = f(\mathbf{x} \mid C = k).$$

Para uma observação $\mathbf{x}$ tal que

$$\sum_{h=1}^G \pi_h f_h(\mathbf{x}) > 0,$$

o teorema de Bayes fornece

$$P(C = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{h=1}^G \pi_h f_h(\mathbf{x})}. \quad (20.1)$$

A probabilidade posterior combina dois tipos de informação.

O fator

$$\pi_k$$

representa a frequência probabilística da classe antes de observar $\mathbf{x}$.

O fator

$$f_k(\mathbf{x})$$

mede a densidade atribuída à observação $\mathbf{x}$ pela distribuição condicional da classe.

A probabilidade posterior, isoladamente, não determina a decisão quando diferentes erros de classificação possuem consequências distintas. A função de perda incorpora essas consequências ao problema.

20.3 Perda e risco de classificação

Definição 20.2 (Perda de classificação). Considere o conjunto de ações

$$\mathcal{A} = \{1, \dots, K\}$$

e as classes verdadeiras

$$g \in \{1, \dots, K\}.$$

Uma **função de perda de classificação** é uma função

$$L : \mathcal{A} \times \{1, \dots, K\} \longrightarrow [0, \infty)$$

tal que

$$L(a, g)$$

quantifica a consequência de escolher a ação a quando a classe verdadeira é k .

Os valores

$$L(g, g)$$

correspondem às decisões corretas, enquanto

$$L(a, g), \quad a \neq g,$$

correspondem aos diferentes tipos de erro.

A teoria não exige que todos os erros possuam a mesma consequência.

Definição 20.3 (Risco condicional de classificação). Considere

$$\mathbf{C} \in \{1, \dots, K\},$$

o conjunto de ações

$$\mathcal{A} = \{1, \dots, K\},$$

uma função de perda

$$L : \mathcal{A} \times \{1, \dots, K\} \longrightarrow [0, \infty)$$

e uma observação

$$\mathbf{x} \in \mathbb{R}^p$$

para a qual as probabilidades posteriores

$$P(\mathbf{C} = k \mid \mathbf{X} = \mathbf{x})$$

estão definidas.

O **risco condicional** de escolher

$$a \in \mathcal{A}$$

é

$$R(a \mid \mathbf{x}) = \sum_{k=1}^K L(a, g) P(C = k \mid \mathbf{X} = \mathbf{x}). \quad (20.2)$$

O risco é uma esperança condicional da perda: para uma observação fixa $\mathbf{x}$, cada possível consequência é ponderada pela probabilidade posterior da respectiva classe verdadeira.

20.3.1 Minimização do risco condicional

Definição 20.4 (Regra de Bayes para classificação). Considere o conjunto de ações

$$\mathcal{A} = \{1, \dots, K\}$$

e, para cada

$$\mathbf{x} \in \mathbb{R}^p,$$

riscos condicionais

$$R(a \mid \mathbf{x}), \quad a \in \mathcal{A}.$$

O conjunto das ações de Bayes é

$$\mathcal{A}_B(\mathbf{x}) = \arg \min_{a \in \mathcal{A}} R(a \mid \mathbf{x}). \quad (20.3)$$

Uma **regra de Bayes** é qualquer função

$$\psi_B : \mathbb{R}^p \longrightarrow \mathcal{A}$$

tal que

$$\psi_B(\mathbf{x}) \in \mathcal{A}_B(\mathbf{x})$$

para todo $\mathbf{x}$ em que os riscos estejam definidos.

Quando existem várias ações minimizadoras, uma convenção de desempate determina uma regra unívoca.

A regra ótima depende conjuntamente:

- das distribuições condicionais;
- das probabilidades *a priori*;
- da função de perda.

Portanto, o problema de classificação não é determinado somente pela geometria dos grupos no espaço das características.

20.3.2 Perda zero-um

Um caso particular é

$$L(a, g) = \begin{cases} 0, & a = g, \\ 1, & a \neq g. \end{cases} \quad (20.4)$$

Nesse caso,

$$\begin{aligned} R(a | \mathbf{x}) &= \sum_{g \neq a} P(C = g | \mathbf{X} = \mathbf{x}) \\ &= 1 - P(C = a | \mathbf{X} = \mathbf{x}). \end{aligned}$$

Assim, minimizar o risco equivale a maximizar a probabilidade posterior.

O conjunto das classes ótimas é

$$\arg \max_{k \in \{1, \dots, K\}} P(C = k | \mathbf{X} = \mathbf{x}).$$

Por Equação 20.1, o denominador é comum a todas as classes. Portanto,

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \pi_k f_k(\mathbf{x}). \quad (20.5)$$

Quando

$$f_k(\mathbf{x}) > 0$$

para todas as classes, a mesma comparação pode ser realizada por

$$\log \pi_k + \log f_k(\mathbf{x}), \quad (20.6)$$

pois o logaritmo é estritamente crescente em

$$(0, \infty).$$

A regra de máxima probabilidade posterior é, portanto, um **caso particular** da regra de Bayes associado à perda zero-um.

Com perdas assimétricas, maximizar a posterior não é necessariamente ótimo. Nesse caso, a decisão continua sendo determinada por Equação 20.3.

Essa distinção será importante posteriormente: probabilidades *a priori* e perdas pertencem ao problema de decisão, enquanto o critério geométrico de Fisher é construído a partir das dispersões entre e dentro dos grupos.

20.4 Discriminação linear sob normalidade

Considere agora a especialização probabilística em que

$$\mathbf{X} \mid C = k \sim N_p(\mu_k, \Sigma), \quad k = 1, \dots, K, \quad (20.7)$$

com

$$\mu_k \in \mathbb{R}^p$$

e matriz de covariâncias comum

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}.$$

Além disso, considere probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

A normalidade não foi necessária para definir a regra de Bayes. Ela passa a ser utilizada agora para especificar explicitamente as densidades

$$f_k(\mathbf{x}).$$

O capítulo sobre a distribuição normal multivariada mostrou em Equação 9.49 que a comparação entre duas log-densidades normais com a mesma matriz de covariâncias é afim em $\mathbf{x}$.

A Análise Discriminante utiliza esse resultado dentro do problema de decisão.

Sob perda zero-um, deve-se comparar

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A log-densidade normal da classe k contém

$$-\frac{1}{2} \log |\Sigma| - \frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k),$$

além do termo

$$-\frac{p}{2} \log(2\pi).$$

Como

$$\Sigma$$

é comum a todas as classes,

$$-\frac{p}{2} \log(2\pi)$$

e

$$-\frac{1}{2} \log |\Sigma|$$

não participam da comparação entre grupos.

Expandindo a forma quadrática,

$$\begin{aligned} & -\frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k) \\ &= -\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x} + \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k. \end{aligned}$$

O termo

$$-\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x}$$

também é comum a todas as classes.

Restam apenas os termos que dependem de k .

Definição 20.5 (Função discriminante linear). Considere

$$K \geq 2$$

classes com

$$\mathbf{X} \mid C = k \sim N_p(\mu_k, \Sigma), \quad k = 1, \dots, K,$$

em que

$$\mu_k \in \mathbb{R}^p, \quad \Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0},$$

e probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Sob perda zero-um, a **função discriminante linear** da classe k é

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k. \quad (20.8)$$

A regra discriminante linear escolhe qualquer classe que maximize essa função:

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k(\mathbf{x}). \quad (20.9)$$

Quando o máximo é único, a classificação é determinada sem necessidade de convenção adicional de desempate.

A sigla LDA, de *Linear Discriminant Analysis*, é tradicional. A função

$$\delta_k(\mathbf{x})$$

é, matematicamente, **afim** em $\mathbf{x}$:

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \mathbf{b}_k + c_k,$$

com

$$\mathbf{b}_k = \Sigma^{-1} \mu_k$$

e

$$c_k = -\frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k.$$

A denominação “linear” refere-se convencionalmente à estrutura das fronteiras de decisão, que serão hiperplanos.

20.4.1 Fronteiras entre classes

Considere duas classes distintas

$$g \neq h.$$

A fronteira de decisão entre elas é o conjunto de pontos para os quais

$$\delta_k(\mathbf{x}) = \delta_h(\mathbf{x}).$$

Substituindo Equação 20.8,

$$\begin{aligned} 0 &= \mathbf{x}^\top \Sigma^{-1} (\mu_k - \mu_h) \\ &\quad - \frac{1}{2} (\mu_k^\top \Sigma^{-1} \mu_k - \mu_h^\top \Sigma^{-1} \mu_h) + \log \frac{\pi_k}{\pi_h}. \end{aligned} \tag{20.10}$$

A equação possui a forma

$$\mathbf{x}^\top \mathbf{v} + b = 0,$$

e define um hiperplano sempre que

$$\mathbf{v} = \Sigma^{-1} (\mu_k - \mu_h) \neq \mathbf{0}.$$

Se

$$\mu_k \neq \mu_h,$$

a positividade definida de

$$\Sigma$$

garante

$$\mathbf{v} \neq \mathbf{0}.$$

O vetor normal ao hiperplano é, portanto,

$$\Sigma^{-1} (\mu_k - \mu_h). \quad (20.11)$$

A diferença bruta entre os vetores de médias,

$$\mu_k - \mu_h,$$

não determina sozinha a orientação da fronteira.

Ela é transformada por

$$\Sigma^{-1},$$

de modo que variâncias e covariâncias alteram a direção relevante para discriminar as classes.

As probabilidades *a priori* entram apenas pelo termo

$$\log \frac{\pi_k}{\pi_h}.$$

Mantidos os vetores de médias e a matriz de covariâncias, alterar as probabilidades *a priori* desloca o hiperplano, mas não modifica seu vetor normal.

Há um caso degenerado importante. Se

$$\mu_k = \mu_h,$$

as duas classes possuem a mesma densidade condicional sob o modelo de covariância comum. A comparação entre elas é determinada somente pelas probabilidades *a priori*; nesse caso, não existe uma fronteira hiperplana não trivial produzida pelas características.

20.4.2 Relação com a distância de Mahalanobis

A distância de Mahalanobis foi definida em Definição 8.9. Para a classe k ,

$$d_M^2(\mathbf{x}, \mu_k; \Sigma) = (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k).$$

Essa forma quadrática é exatamente a quantidade que aparece no expoente da densidade normal multivariada.

Sob o modelo em Equação 20.7 e perda zero-um, a comparação entre classes pode ser escrita como

$$-\frac{1}{2}d_M^2(\mathbf{x}, \mu_k; \Sigma) + \log \pi_k. \quad (20.12)$$

Consequentemente,

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} \left\{ d_M^2(\mathbf{x}, \mu_k; \Sigma) - 2 \log \pi_k \right\}. \quad (20.13)$$

Essa forma evidencia dois componentes distintos da decisão:

- a posição de $\mathbf{x}$ relativamente ao centro da classe segundo a geometria de Mahalanobis;
- o peso probabilístico *a priori* atribuído à classe.

Se

$$\pi_1 = \dots = \pi_G = \frac{1}{G},$$

o termo

$$-2 \log \pi_k$$

é comum a todas as classes e pode ser retirado da comparação.

Assim,

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} d_M^2(\mathbf{x}, \mu_k; \Sigma). \quad (20.14)$$

Sob normalidade, covariância comum, probabilidades *a priori* iguais e perda zero-um, a regra de Bayes classifica, portanto, pela menor distância de Mahalanobis ao centro populacional da classe.

A conexão com os fundamentos do Módulo 2 é direta. A mesma matriz

$$\Sigma$$

que determina a forma dos elipsoides da distribuição normal determina também a métrica utilizada para comparar a nova observação com os centroides.

A classificação não utiliza uma proximidade euclidiana bruta. Ela utiliza uma geometria que incorpora simultaneamente:

- as escalas das variáveis;
- suas variâncias;
- suas covariâncias.

Essa interpretação não exige reconstruir a teoria da distância de Mahalanobis: ela mostra como uma estrutura geométrica já estabelecida passa a determinar uma regra probabilística de classificação.

A LDA apresentada até aqui é uma **regra populacional**: utiliza

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_G,$$

que são parâmetros populacionais.

Na prática, esses parâmetros geralmente não são conhecidos e precisam ser estimados a partir de observações com classes conhecidas. A distinção entre a regra populacional e sua versão estimada será estabelecida após a formulação da discriminação quadrática.

20.5 Discriminação quadrática

A estrutura linear da seção anterior decorreu da hipótese de que todas as classes compartilham a mesma matriz de covariâncias.

Considere agora

$$\mathbf{X} \mid C = k \sim N_p(\mu_k, \Sigma_k), \quad k = 1, \dots, K, \quad (20.15)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e

$$\Sigma_k \in \mathbb{R}^{p \times p}, \quad \Sigma_k \succ \mathbf{0}.$$

Considere também probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

A regra de Bayes continua sendo determinada pelas probabilidades posteriores e pela função de perda. A diferença em relação à LDA está no modelo utilizado para as distribuições condicionais.

Sob perda zero-um, deve-se comparar

$$\log \pi_k + \log f_k(\mathbf{x}).$$

Para a distribuição normal da classe k ,

$$\begin{aligned} \log f_k(\mathbf{x}) = & -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma_k| \\ & - \frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k). \end{aligned}$$

O primeiro termo é comum a todas as classes, mas os demais dependem de k .

Diferentemente do que ocorreu em Equação 20.7, não existe agora uma única matriz de covariâncias que permita cancelar os termos quadráticos em $\mathbf{x}$.

A comparação de log-densidades normais com matrizes de covariâncias distintas foi estabelecida em Equação 9.50. Como as matrizes inversas dependem da classe, permanecem, em geral, termos quadráticos em $\mathbf{x}$.

Definição 20.6 (Função discriminante quadrática). Considere

$$K \geq 2$$

classes com

$$\mathbf{X} \mid \mathbf{C} = k \sim N_p(\mu_k, \Sigma_k), \quad k = 1, \dots, K,$$

em que

$$\mu_k \in \mathbb{R}^p,$$

$$\Sigma_k \in \mathbb{R}^{p \times p}, \quad \Sigma_k \succ \mathbf{0},$$

e probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Sob perda zero-um, a **função discriminante quadrática** da classe k é

$$\delta_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k) + \log \pi_k. \quad (20.16)$$

A regra discriminante quadrática escolhe qualquer classe que maximize o escore:

$$\psi_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k^Q(\mathbf{x}). \quad (20.17)$$

Quando o máximo é único, a classe fica determinada sem convenção adicional de desempate.

A denominação *Quadratic Discriminant Analysis* decorre da presença de uma forma quadrática específica para cada classe.

Expandindo-a,

$$\begin{aligned} & -\frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k) \\ &= -\frac{1}{2} \mathbf{x}^\top \Sigma_k^{-1} \mathbf{x} + \mathbf{x}^\top \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma_k^{-1} \mu_k. \end{aligned}$$

Como

$$\Sigma_k^{-1}$$

depende da classe, o coeficiente do termo quadrático

$$\mathbf{x}^\top \Sigma_k^{-1} \mathbf{x}$$

também depende de k .

Duas partes da função possuem papéis distintos.

A forma

$$(\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k)$$

é a distância de Mahalanobis quadrática entre a observação e o centro da classe segundo a geometria própria daquela população.

Já o termo

$$\log |\Sigma_k|$$

é parte do fator de normalização da densidade normal e penaliza classes segundo sua dispersão multivariada.

Geometricamente,

$$|\Sigma_k|^{1/2}$$

é proporcional ao fator de volume dos elipsoides definidos por uma mesma distância de Mahalanobis. Portanto, duas classes podem atribuir a um ponto a mesma distância de Mahalanobis e ainda produzir funções discriminantes distintas porque suas distribuições possuem diferentes concentrações no espaço.

20.5.1 Fronteiras quadráticas

Considere duas classes

$$g \neq h.$$

Sua fronteira de decisão é o conjunto de pontos que satisfazem

$$\delta_k^Q(\mathbf{x}) = \delta_h^Q(\mathbf{x}).$$

Subtraindo as duas funções, obtém-se uma equação que contém o termo

$$\frac{1}{2} \mathbf{x}^\top (\Sigma_h^{-1} - \Sigma_k^{-1}) \mathbf{x}.$$

Além dele, aparecem termos lineares em $\mathbf{x}$ e termos constantes determinados pelos vetores de médias, determinantes das covariâncias e probabilidades *a priori*.

Assim, a fronteira pode ser escrita na forma geral

$$\mathbf{x}^\top \mathbf{A}_{gh} \mathbf{x} + \mathbf{b}_{gh}^\top \mathbf{x} + c_{gh} = 0, \quad (20.18)$$

em que

$$\mathbf{A}_{gh} = \frac{1}{2} (\Sigma_h^{-1} - \Sigma_k^{-1}).$$

Em geral,

$$\mathbf{A}_{gh} \neq \mathbf{0},$$

e a fronteira pertence à família das superfícies quadráticas.

Se, porém,

$$\Sigma_k = \Sigma_h,$$

então

$$\mathbf{A}_{gh} = \mathbf{0}.$$

Quando todas as classes compartilham

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

os termos quadráticos e os log-determinantes comuns cancelam-se para todas as comparações entre classes. A QDA reduz-se então à estrutura da LDA em Equação 20.8.

Portanto, a linearidade ou quadraticidade da fronteira não é uma escolha gráfica posterior. Ela decorre diretamente da estrutura probabilística atribuída às matrizes de covariâncias condicionais.

A Figura 20.1 ilustra essa diferença para duas classes normais. No primeiro painel, a mesma matriz de covariâncias é utilizada para ambas as populações e a fronteira é uma reta. No segundo, cada população possui sua própria matriz de covariâncias e a fronteira pode ser curva.




Figura 20.1: Fronteiras de decisão para duas populações normais. As elipses delimitam regiões de concentração de 75%. Com covariância comum, a LDA produz uma fronteira linear; com covariâncias distintas, a QDA pode produzir uma fronteira quadrática.

A diferença visual entre as fronteiras é uma consequência das hipóteses probabilísticas. Na LDA, os termos quadráticos comuns cancelam-se. Na QDA, esse cancelamento não ocorre quando as matrizes de covariâncias diferem.

20.6 Da regra populacional à regra estimada

As funções discriminantes formuladas até aqui utilizam parâmetros populacionais.

Na LDA, são necessários

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_G.$$

Na QDA, são necessários

$$\mu_1, \dots, \mu_K, \quad \Sigma_1, \dots, \Sigma_K, \quad \pi_1, \dots, \pi_G.$$

Essas quantidades são parâmetros fixos da distribuição populacional.

Em uma aplicação, elas geralmente são desconhecidas. Os grupos conhecidos na amostra fornecem informação para estimá-las.

A distinção entre estimador e estimativa foi formalizada em Definição 10.4. Neste capítulo, ela se aplica aos parâmetros das distribuições condicionais:

- **parâmetro:** característica fixa e desconhecida da população;
- **estimador:** estatística aleatória utilizada para estimar o parâmetro;
- **estimativa:** valor assumido pelo estimador após a observação dos dados;
- **regra estimada:** regra obtida substituindo os parâmetros desconhecidos por suas estimativas.

20.6.1 Amostra com classes conhecidas

Considere uma amostra de treinamento com

$$n = \sum_{k=1}^K n_k$$

observações, em que

$$n_k \geq 1$$

é o número de unidades observadas da classe k .

Para a classe k , sejam

$$\mathbf{X}_{1g}, \dots, \mathbf{X}_{n_k g} \in \mathbb{R}^p$$

os vetores aleatórios da amostra.

Aplicando a média amostral de Equação 10.8 separadamente às observações da classe k , obtém-se

$$\bar{\mathbf{X}}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathbf{x}_{ik} \in \mathbb{R}^p. \quad (20.19)$$

Após a observação dos dados, conforme Equação 10.9,

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathbf{x}_{ig}. \quad (20.20)$$

Quando

$$n_k \geq 2,$$

a matriz de covariâncias amostral definida em Definição 10.14, aplicada às observações da classe k , é

$$\mathbf{S}_k = \frac{1}{n_k - 1} \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top. \quad (20.21)$$

Sua realização observada, correspondente à matriz de covariâncias de Definição 8.11, é

$$\mathbf{S}_k = \frac{1}{n_k - 1} \sum_{i=1}^{n_k} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_k)^\top. \quad (20.22)$$

Essas estatísticas são definidas sem exigir normalidade multivariada. Sob o modelo normal discriminante, elas são utilizadas para estimar os parâmetros das distribuições condicionais das classes.

20.6.2 Covariância comum na LDA

Se o modelo populacional supõe

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

as informações de dispersão dentro das classes podem ser reunidas.

No modelo linear de grupos, Equação 11.107 estabelece que a SQPC residual observada coincide com a dispersão intragrupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}.$$

Aplicando o estimador residual de covariância de Definição 11.13 ao modelo com K grupos, cujo posto é K , obtém-se, para

$$n > K,$$

a matriz de covariâncias agrupada

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}, \quad (20.23)$$

e, após a observação,

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}. \quad (20.24)$$

Essa é a estimativa agrupada da matriz de covariâncias comum utilizada na formulação amostral clássica da LDA.

Quando

$$n_k \geq 2, \quad k = 1, \dots, K,$$

a relação também pode ser escrita como

$$\mathbf{S}_p = \frac{\sum_{k=1}^K (n_k - 1) \mathbf{S}_k}{n - K}.$$

Assim, a mesma matriz de dispersão intragrupos que aparece na formulação de Fisher fornece a estimativa de covariância comum utilizada na LDA.

20.6.3 Probabilidades *a priori*: especificação ou estimação

As probabilidades

$$\pi_1, \dots, \pi_G$$

também precisam ser conhecidas ou especificadas para construir a regra populacional de Bayes.

Quando a amostra constitui uma amostra aleatória representativa da mistura populacional das classes, uma possibilidade é o estimador empírico

$$\hat{\pi}_k = \frac{n_k}{n}. \quad (20.25)$$

Entretanto,

$$\frac{n_k}{n}$$

não deve ser utilizado automaticamente como probabilidade *a priori*.

Em delineamentos que fixam artificialmente os tamanhos dos grupos, estudos caso-controle, amostragens desbalanceadas por planejamento ou situações em que prevalências externas são conhecidas, as proporções amostrais podem não representar

$$P(C = k).$$

As probabilidades *a priori* podem, portanto:

- ser conhecidas por informação populacional;
- ser especificadas como parte do problema de decisão;
- ser estimadas a partir da amostra quando o mecanismo amostral permite essa interpretação.

Esse ponto é independente da estimação dos vetores de médias e das matrizes de covariâncias.

20.7 Regra estimada da LDA

Suponha que, após observar a amostra de treinamento, estejam disponíveis

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K,$$

uma matriz agrupada

$$\mathbf{S}_p \succ \mathbf{0}$$

e valores positivos

$$\hat{\pi}_1, \dots, \hat{\pi}_K$$

tais que

$$\sum_{k=1}^K \hat{\pi}_k = 1.$$

Definição 20.7 (Função discriminante linear estimada). Considere

$$K \geq 2,$$

vetores

$$\bar{\mathbf{x}}_k \in \mathbb{R}^p, \quad k = 1, \dots, K,$$

uma matriz

$$\mathbf{S}_p \in \mathbb{R}^{p \times p}, \quad \mathbf{S}_p \succ \mathbf{0},$$

e valores

$$\hat{\pi}_k > 0, \quad \sum_{k=1}^K \hat{\pi}_k = 1.$$

A **função discriminante linear estimada** da classe k é

$$\hat{\delta}_k(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k - \frac{1}{2} \bar{\mathbf{x}}_k^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k + \log \hat{\pi}_k, \quad \mathbf{x} \in \mathbb{R}^p. \quad (20.26)$$

A regra *plug-in* correspondente é

$$\hat{\psi}_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \hat{\delta}_k(\mathbf{x}). \quad (20.27)$$

A expressão possui a mesma forma algébrica da regra populacional, mas seus elementos têm natureza estatística diferente.

Na regra populacional,

$$\mu_k, \quad \Sigma, \quad \pi_k$$

são parâmetros.

Na regra estimada,

$$\bar{\mathbf{x}}_k, \quad \mathbf{S}_p, \quad \hat{\pi}_k$$

são valores obtidos a partir de uma amostra de treinamento ou especificados a partir de informação externa.

Antes de observar a amostra, os estimadores correspondentes são aleatórios. Portanto, a própria regra estimada varia de uma amostra de treinamento para outra.

Essa variabilidade é distinta da aleatoriedade de uma nova observação a ser classificada.

20.8 Regra estimada da QDA

Na QDA, cada classe possui sua própria matriz de covariâncias.

Suponha que, após a observação da amostra,

$$\mathbf{S}_k \succ \mathbf{0}, \quad k = 1, \dots, K,$$

e que estejam disponíveis

$$\bar{\mathbf{x}}_k$$

e

$$\hat{\pi}_k > 0.$$

Definição 20.8 (Função discriminante quadrática estimada). Sob as condições anteriores, a **função discriminante quadrática estimada** da classe k é

$$\hat{\delta}_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\mathbf{S}_k| - \frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_k)^\top \mathbf{S}_k^{-1} (\mathbf{x} - \bar{\mathbf{x}}_k) + \log \hat{\pi}_k. \quad (20.28)$$

A regra *plug-in* é

$$\hat{\psi}_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \hat{\delta}_k^Q(\mathbf{x}). \quad (20.29)$$

A QDA exige estimar

$$G$$

matrizes de covariâncias distintas, enquanto a LDA utiliza uma única matriz agrupada.

Essa diferença possui consequências de posto e quantidade de informação necessária por grupo, que serão examinadas posteriormente na seção sobre existência e singularidade.

O ponto importante nesta etapa é distinguir a **forma do modelo** da **estimação de seus parâmetros**.

A hipótese

$$\Sigma_1 = \cdots = \Sigma_K$$

define a estrutura populacional da LDA.

A utilização de

$$\mathbf{S}_p$$

é uma etapa de estimação dessa estrutura.

Analogamente, a hipótese de matrizes populacionais específicas

$$\Sigma_k$$

define a QDA, enquanto

$$\mathbf{S}_k$$

são suas estimativas amostrais usuais.

20.9 Regra populacional e regra estimada

A Tabela 20.2 sintetiza os níveis que não devem ser confundidos.

Tabela 20.2: Distinção entre parâmetros populacionais, estimativas e funções discriminantes estimadas.

Papel	LDA	QDA
médias populacionais	μ_k	μ_k
covariância populacional	Σ comum	Σ_k específica
probabilidades <i>a priori</i>	π_k	π_k
estimativa da média	$\bar{\mathbf{x}}_k$	$\bar{\mathbf{x}}_k$
estimativa de covariância	$\mathbf{S}_p$	$\mathbf{S}_k$

Papel	LDA	QDA
probabilidade <i>a priori</i> utilizada na regra estimada	$\hat{\pi}_k$ ou valor especificado	$\hat{\pi}_k$ ou valor especificado
função populacional	$\delta_k(\mathbf{x})$	$\delta_k^Q(\mathbf{x})$
função estimada	$\hat{\delta}_k(\mathbf{x})$	$\hat{\delta}_k^Q(\mathbf{x})$

A substituição de parâmetros por estimativas não altera apenas a notação.

A regra populacional de Bayes é definida em relação à distribuição verdadeira e à função de perda especificada.

A regra *plug-in* utiliza uma aproximação dessa regra construída a partir da informação amostral.

Mesmo que o modelo normal esteja corretamente especificado, a regra estimada não coincide necessariamente com a regra populacional porque

$$\bar{\mathbf{x}}_k \neq \mu_k,$$

$$\mathbf{S}_p \neq \Sigma$$

ou

$$\mathbf{S}_k \neq \Sigma_k$$

em uma amostra finita.

Essa diferença decorre diretamente da distinção entre estimador e estimativa estabelecida em Definição 10.4: os estimadores são variáveis aleatórias e diferentes amostras podem produzir diferentes regras discriminantes estimadas.

A avaliação de quanto essa variabilidade afeta a classificação exige estudar o desempenho da regra estimada em novas observações. Esse problema pertence à etapa metodológica posterior e não será desenvolvido aqui.

20.10 O que as regras probabilísticas resolvem

As funções em Equação 20.8 e Equação 20.16 surgem de um problema de decisão.

Seu objetivo é determinar, para uma observação

$$\mathbf{x},$$

qual ação minimiza o risco condicional.

Sob perda zero-um, isso equivale a selecionar a classe de maior probabilidade posterior.

A estrutura populacional das duas regras é sintetizada na Tabela 20.3.

Tabela 20.3: Comparação entre as formulações discriminantes linear e quadrática sob normalidade.

Aspecto	LDA	QDA
modelo condicional	$N_p(\mu_k, \Sigma)$	$N_p(\mu_k, \Sigma_k)$
covariância	comum a todas as classes	específica de cada classe
função discriminante	afim em $\mathbf{x}$	quadrática em $\mathbf{x}$
fronteira entre duas classes	hiperplano	superfície quadrática em geral
geometria de distância	uma única métrica de Mahalanobis	uma métrica de Mahalanobis para cada classe
probabilidades <i>a priori</i>	entram por $\log \pi_k$	entram por $\log \pi_k$
perda considerada nas fórmulas apresentadas	zero-um	zero-um
resultado imediato	regra populacional de classificação	regra populacional de classificação

A construção probabilística não procura uma direção única que maximize a separação entre os grupos.

Ela compara diretamente os modelos condicionais das classes no espaço original das características e produz uma regra de decisão.

A formulação geométrica de Fisher parte de outro problema.

Nela, os rótulos conhecidos serão utilizados para decompor a dispersão em componentes dentro e entre os grupos e procurar combinações lineares nas quais a separação entre eles seja grande relativamente à dispersão intragrupos.

Essa nova formulação utilizará diretamente os fundamentos sobre esperança, covariância, formas quadráticas e autovalores generalizados desenvolvidos nos Módulos 1 e 2.

20.11 Formulação geométrica de Fisher

A formulação probabilística desenvolvida nas seções anteriores produz uma regra para decidir a classe de uma nova observação. A formulação de Fisher parte de outro problema: construir combinações lineares das características que evidenciem a separação entre grupos previamente conhecidos.

Esse problema pode ser formulado tanto em nível populacional quanto em nível amostral.

A formulação populacional permite identificar qual estrutura de dispersão se pretende representar. A formulação amostral substitui essa estrutura pelas dispersões calculadas a partir das observações com rótulos conhecidos.

Nenhuma dessas formulações exige, para ser definida, que as distribuições condicionais sejam normais.

20.11.1 Dispersões populacionais dentro e entre grupos

Considere novamente

$$C \in \{1, \dots, K\},$$

com

$$P(C = k) = \pi_k, \quad \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1,$$

e um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos.

Para cada classe, defina

$$\mu_k = E(\mathbf{X} \mid C = k) \in \mathbb{R}^p$$

e

$$\Sigma_k = \text{Cov}(\mathbf{X} \mid C = k) \in \mathbb{R}^{p \times p}.$$

A média marginal de

$$\mathbf{X}$$

é

$$\mu = E(\mathbf{X}) = \sum_{k=1}^K \pi_k \mu_k. \quad (20.30)$$

Definição 20.9 (Dispersões populacionais de Fisher). Considere

$$\mathbf{C} \in \{1, \dots, K\},$$

com

$$P(\mathbf{C} = k) = \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1,$$

e

$$E(\|\mathbf{X}\|^2) < \infty.$$

Se

$$\mu_k = E(\mathbf{X} \mid \mathbf{C} = k)$$

e

$$\Sigma_k = \text{Cov}(\mathbf{X} \mid \mathbf{C} = k),$$

defina a **dispersão populacional intragrupos** por

$$\Sigma_W = \sum_{k=1}^K \pi_k \Sigma_k \in \mathbb{R}^{p \times p}, \quad (20.31)$$

e a **dispersão populacional entre grupos** por

$$\Sigma_B = \sum_{k=1}^K \pi_k (\mu_k - \mu) (\mu_k - \mu)^\top \in \mathbb{R}^{p \times p}, \quad (20.32)$$

em que

$$\mu = \sum_{k=1}^K \pi_k \mu_k.$$

As duas matrizes são simétricas e semidefinidas positivas:

$$\Sigma_W \succeq \mathbf{0}$$

e

$$\Sigma_B \succeq \mathbf{0}.$$

A primeira resume a variabilidade existente **dentro das classes**, enquanto a segunda resume a variabilidade dos vetores de médias das classes em torno da média marginal.

Essas duas componentes recuperam a matriz de covariâncias marginal de

$$\mathbf{X}.$$

Proposição 20.1 (Decomposição populacional da covariância por grupos). *Considere*

$$\mathbf{C} \in \{1, \dots, K\},$$

com

$$P(\mathbf{C} = k) = \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1,$$

e

$$E(\|\mathbf{X}\|^2) < \infty.$$

Defina

$$\mu_k = E(\mathbf{X} \mid \mathbf{C} = k), \quad \mu = \sum_{k=1}^K \pi_k \mu_k,$$

$$\Sigma_W = \sum_{k=1}^K \pi_k \text{Cov}(\mathbf{X} \mid \mathbf{C} = k)$$

e

$$\Sigma_B = \sum_{k=1}^K \pi_k (\mu_k - \mu)(\mu_k - \mu)^\top.$$

Então,

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B. \quad (20.33)$$

Comprovação. Escreva

$$\mathbf{X} - \mu = (\mathbf{X} - \mu_{\mathbf{C}}) + (\mu_{\mathbf{C}} - \mu),$$

em que

$$\mu_{\mathbf{C}} = E(\mathbf{X} \mid \mathbf{C}).$$

Ao desenvolver o produto externo e tomar esperança, os termos cruzados são nulos porque

$$E[\mathbf{X} - \mu_{\mathbf{C}} \mid \mathbf{C}] = \mathbf{0}.$$

Assim,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= E[\text{Cov}(\mathbf{X} \mid \mathbf{C})] \\ &\quad + \text{Cov}[E(\mathbf{X} \mid \mathbf{C})] \\ &= \Sigma_W + \Sigma_B. \end{aligned}$$

□

Essa é a versão populacional da decomposição da dispersão que, para os dados observados, foi estabelecida em Proposição [8.10](#):

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

As duas decomposições não devem ser confundidas.

Em

$$\Sigma_W \quad \text{e} \quad \Sigma_B,$$

os objetos são parâmetros populacionais.

Em

$$\mathbf{T}_{\text{intra}} \quad \text{e} \quad \mathbf{T}_{\text{entre}},$$

os objetos são matrizes calculadas a partir de uma amostra observada.

20.11.2 Critério populacional de Fisher

Considere uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

e a combinação linear

$$Z = \mathbf{a}^\top \mathbf{X}.$$

Dentro da classe k ,

$$\text{Var}(Z \mid \mathbf{C} = k) = \mathbf{a}^\top \Sigma_k \mathbf{a}.$$

A média ponderada dessas variâncias é

$$\sum_{k=1}^K \pi_k \text{Var}(Z \mid \mathbf{C} = k) = \mathbf{a}^\top \Sigma_W \mathbf{a}. \quad (20.34)$$

Por outro lado, a variabilidade das médias condicionais projetadas é

$$\sum_{k=1}^K \pi_k \left[\mathbf{a}^\top (\mu_k - \mu) \right]^2 = \mathbf{a}^\top \Sigma_B \mathbf{a}. \quad (20.35)$$

Definição 20.10 (Critério populacional de Fisher). Sejam

$$\Sigma_B, \Sigma_W \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\Sigma_B \succeq \mathbf{0} \quad \text{e} \quad \Sigma_W \succ \mathbf{0}.$$

Para

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

o **critério populacional de Fisher** é

$$J_F^{(P)}(\mathbf{a}) = \frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}. \quad (20.36)$$

O numerador mede a separação dos vetores de médias das classes depois da projeção.

O denominador mede a dispersão média existente dentro das classes nessa mesma direção.

Portanto, Fisher não procura simplesmente uma direção em que os vetores de médias estejam distantes. A separação é avaliada relativamente à variabilidade interna das populações.

Essa formulação requer segundos momentos finitos e, na forma clássica acima, positividade definida de

$$\Sigma_W.$$

Ela **não exige normalidade multivariada**.

Também não exige

$$\Sigma_1 = \cdots = \Sigma_K.$$

Se as covariâncias forem comuns,

$$\Sigma_k = \Sigma, \quad k = 1, \dots, K,$$

então

$$\Sigma_W = \Sigma,$$

situação que posteriormente estabelecerá uma ligação direta entre Fisher e a LDA.

20.12 Formulação amostral de Fisher

Considere agora uma amostra com grupos conhecidos, contendo

$$n_k$$

observações no grupo k e

$$n = \sum_{k=1}^K n_k$$

observações no total.

As matrizes de dispersão intragrupos e entre grupos foram definidas no Módulo 2 em Definição 8.14 e Definição 8.15:

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_k)^\top$$

e

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top.$$

Pela propriedade estabelecida em Proposição 8.10,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Esses resultados não precisam ser novamente demonstrados.

Para relacioná-los à formulação populacional, observe que

$$\frac{1}{n} \mathbf{T}_{\text{intra}}$$

e

$$\frac{1}{n}\mathbf{T}_{\text{entre}}$$

são os análogos empíricos das duas parcelas de dispersão quando os pesos dos grupos são

$$\frac{n_k}{n}.$$

A multiplicação de ambas as matrizes por um mesmo escalar positivo não altera o quociente de Fisher. Portanto,

$$\frac{\mathbf{a}^\top(\mathbf{T}_{\text{entre}}/n)\mathbf{a}}{\mathbf{a}^\top(\mathbf{T}_{\text{intra}}/n)\mathbf{a}} = \frac{\mathbf{a}^\top\mathbf{T}_{\text{entre}}\mathbf{a}}{\mathbf{a}^\top\mathbf{T}_{\text{intra}}\mathbf{a}}.$$

Assim, a formulação amostral pode ser escrita diretamente em termos das matrizes de dispersão já construídas no Módulo 2.

Os pesos

$$n_k$$

presentes em

$$\mathbf{T}_{\text{entre}}$$

são pesos da decomposição da **amostra observada**. Eles não devem ser confundidos automaticamente com as probabilidades *a priori*

$$\pi_k$$

utilizadas na regra de Bayes.

Em particular, quando os tamanhos dos grupos são fixados pelo delineamento, as proporções

$$\frac{n_k}{n}$$

podem não representar as prevalências populacionais.

20.13 Dispersão depois de uma projeção

Considere

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

e a combinação linear

$$Z = \mathbf{a}^\top \mathbf{x}. \quad (20.37)$$

Depois da projeção, a dispersão amostral dentro dos grupos é

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}, \quad (20.38)$$

enquanto a dispersão amostral entre os centroides é

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (20.39)$$

A primeira quantidade aumenta quando as observações permanecem muito dispersas em torno de seus respectivos centroides depois da projeção.

A segunda aumenta quando os centroides permanecem separados na direção escolhida.

Definição 20.11 (Critério amostral de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Para

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

o critério amostral de Fisher é

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}. \quad (20.40)$$

O quociente é invariante à escala de $\mathbf{a}$. Para todo

$$c \neq 0,$$

$$J_F(c\mathbf{a}) = J_F(\mathbf{a}).$$

Portanto, Fisher escolhe uma **direção**, e não um vetor com comprimento determinado.

Maximizar

$$J_F(\mathbf{a})$$

significa encontrar uma combinação das características em que a separação entre os grupos seja grande relativamente à dispersão que permanece dentro deles.

Essa é uma projeção supervisionada: os rótulos entram diretamente na construção de

$$\mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{entre}}.$$

A Figura 20.2 compara duas projeções das mesmas observações. A primeira utiliza a direção que une os centroides. A segunda incorpora a dispersão intragrupos por meio do critério de Fisher. Para tornar comparáveis as projeções, seus escores são expressos relativamente à dispersão intragrupos.

A figura ilustra o papel do denominador de Equação 20.40: uma diferença entre centroides é mais informativa quando ocorre em uma direção na qual a dispersão intragrupos é relativamente pequena.




Figura 20.2: Projeção das mesmas duas classes na direção que une os centroides e na direção de Fisher. A direção discriminante aumenta a separação entre os grupos relativamente à dispersão intragrupos.

20.14 Direções discriminantes e autovalores generalizados

O critério de Fisher é exatamente o quociente de Rayleigh generalizado definido em Definição 5.12, aplicado ao par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}}).$$

Pelo resultado geral de Teorema 5.8, a maximização de

$$J_F(\mathbf{a})$$

conduz ao problema

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}. \quad (20.41)$$

Esse é o mesmo tipo de problema matemático utilizado no capítulo de MANOVA.

A técnica, entretanto, atribui outro significado às soluções.

Na MANOVA, as raízes são agregadas para construir critérios de teste.

Na formulação de Fisher, os autovetores são utilizados como direções para representar a separação entre grupos.

20.14.1 Geometria pela dispersão intragrupos

Como

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

sua raiz quadrada principal e sua inversa existem.

Defina

$$\mathbf{u} = \mathbf{T}_{\text{intra}}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u},$$

e Equação [20.41](#) torna-se

$$\mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u} = \lambda \mathbf{u}. \quad (20.42)$$

Defina

$$\mathbf{K}_F = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (20.43)$$

A matriz

$$\mathbf{K}_F$$

é simétrica e semidefinida positiva.

Além disso, como

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

é invertível,

$$\text{posto}(\mathbf{K}_F) = \text{posto}(\mathbf{T}_{\text{entre}}). \quad (20.44)$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}). \quad (20.45)$$

Como

$$\mathbf{K}_F \succeq \mathbf{0},$$

ela possui exatamente

$$r_F$$

autovalores positivos.

Esses autovalores são exatamente as raízes positivas do problema generalizado de Fisher.

Definição 20.12 (Direções discriminantes de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Se

$$r_F \geq 1,$$

as **direções discriminantes de Fisher** são autovetores generalizados

$$\mathbf{a}_1, \dots, \mathbf{a}_{r_F} \in \mathbb{R}^p$$

associados às raízes positivas

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{r_F} > 0$$

do problema

$$\mathbf{T}_{\text{entre}} \mathbf{a}_j = \lambda_j \mathbf{T}_{\text{intra}} \mathbf{a}_j.$$

Se

$$r_F = 0,$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva entre os centroides.

A primeira direção satisfaz

$$J_F(\mathbf{a}_1) = \lambda_1 = \max_{\mathbf{a} \neq \mathbf{0}} J_F(\mathbf{a}).$$

Pela ortogonalidade dos autovetores generalizados estabelecida em Proposição 5.8, as direções podem ser escolhidas de modo que

$$\mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_\ell = 0, \quad j \neq \ell. \quad (20.46)$$

Essa ortogonalidade é definida pela geometria intragrupos.

Em geral,

$$\mathbf{a}_j^\top \mathbf{a}_\ell$$

não precisa ser zero.

Uma normalização conveniente é

$$\mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_j = 1. \quad (20.47)$$

Sob essa normalização,

$$\begin{aligned} \mathbf{a}_j^\top \mathbf{T}_{\text{entre}} \mathbf{a}_j &= \lambda_j \mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_j \\ &= \lambda_j. \end{aligned} \quad (20.48)$$

Assim, cada raiz mede a separação entre grupos na correspondente direção depois que a dispersão intragrupos foi normalizada para 1.

20.14.2 Número de direções discriminantes

Pelo limite de posto da dispersão entre grupos estabelecido em Equação 8.101,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

Como

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}),$$

segue que

$$r_F \leq \min(p, K - 1). \quad (20.49)$$

Esse limite possui uma interpretação direta.

Os K centroides centralizados em torno da média global satisfazem uma relação linear ponderada e, portanto, podem gerar no máximo

$$K - 1$$

direções independentes de separação.

Assim:

- dois grupos produzem no máximo uma direção discriminante;
- três grupos produzem no máximo duas;
- em geral, K grupos produzem no máximo $K - 1$ direções.

O limite também não pode ultrapassar a dimensão original

$$p.$$

Por isso,

$$\min(p, K - 1)$$

é o número máximo possível de dimensões discriminantes não nulas.

20.15 Representação no subespaço discriminante

As direções

$$\mathbf{a}_1, \dots, \mathbf{a}_{r_F}$$

definem um subespaço supervisionado para representar as observações.

Definição 20.13 (Coordenadas discriminantes). Considere

$$r_F \geq 1$$

direções discriminantes

$$\mathbf{a}_1, \dots, \mathbf{a}_{r_F} \in \mathbb{R}^p$$

e uma média global amostral

$$\bar{\mathbf{x}} \in \mathbb{R}^p.$$

A **coordenada discriminante** j de uma observação

$$\mathbf{x} \in \mathbb{R}^p$$

é

$$z_j(\mathbf{x}) = \mathbf{a}_j^\top (\mathbf{x} - \bar{\mathbf{x}}), \quad j = 1, \dots, r_F. \quad (20.50)$$

O vetor de coordenadas discriminantes é

$$\mathbf{z}(\mathbf{x}) = \begin{pmatrix} z_1(\mathbf{x}) \\ \vdots \\ z_{r_F}(\mathbf{x}) \end{pmatrix} \in \mathbb{R}^{r_F}. \quad (20.51)$$

A centralização em torno de

$$\bar{\mathbf{x}}$$

coloca a média global na origem da representação.

O uso de

$$\mathbf{a}_j^\top \mathbf{x}$$

sem centralização preservaria todas as diferenças entre observações e centroides; modificaria apenas a origem das coordenadas.

O centroide discriminante da classe k na dimensão j é

$$\bar{z}_{gj} = \mathbf{a}_j^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (20.52)$$

A representação discriminante possui dimensão

$$r_F \leq \min(p, K - 1).$$

Ela é uma redução de dimensionalidade **supervisionada**, pois depende dos rótulos conhecidos.

Alterar os grupos modifica

$$\mathbf{T}_{\text{intra}}, \quad \mathbf{T}_{\text{entre}}$$

e, conseqüentemente, pode modificar tanto o subespaço discriminante quanto suas direções.

A magnitude isolada dos coeficientes de uma direção deve ser interpretada com cautela. Esses coeficientes dependem da escala das características e de suas relações de dispersão e covariância. Procedimentos operacionais para interpretar coeficientes, correlações estruturais e contribuições das variáveis serão tratados posteriormente.




Figura 20.3: Representação de três grupos em duas características originais e nas duas coordenadas discriminantes de Fisher. As coordenadas são construídas especificamente para representar a separação entre os grupos.

A Figura 20.3 mostra três grupos observados em três características. O primeiro painel utiliza apenas duas características originais. O segundo utiliza as duas direções discriminantes disponíveis para os três grupos e incorpora informação das três características.

No segundo painel, as direções utilizadas satisfazem a geometria do problema generalizado. A matriz

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

transforma inicialmente a dispersão intragrupos, e os autovetores de

$$\mathbf{K}_F$$

determinam as direções de maior separação entre os centroides nesse espaço transformado.

A diferença em relação à ACP é estrutural.

A ACP escolhe direções em função da variabilidade total da nuvem.

Fisher escolhe direções em função da razão entre duas fontes de dispersão definidas pelos grupos.

20.16 Relação espectral com a MANOVA

A semelhança entre Fisher e MANOVA não é apenas formal.

Na comparação de grupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{H} = \mathbf{T}_{\text{entre}}. \quad (20.53)$$

Logo, os problemas

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e

$$\mathbf{T}_{\text{entre}}\mathbf{a} = \lambda\mathbf{T}_{\text{intra}}\mathbf{a}$$

são o mesmo problema espectral quando representam a mesma estrutura de grupos.

Isso significa que as raízes e os subespaços característicos coincidem.

O objetivo estatístico, porém, muda.

Na MANOVA, as raízes são agregadas em critérios como Wilks, Pillai, Hotelling–Lawley e Roy para avaliar uma hipótese sobre diferenças entre grupos.

Na formulação de Fisher, os autovetores associados às raízes positivas são utilizados para construir direções e coordenadas de separação.

A mesma estrutura de autovalores generalizados sustenta, portanto, duas técnicas porque cada uma faz uma pergunta estatística diferente.

Essa distinção prepara o caso de dois grupos, no qual a direção de Fisher pode ser escrita explicitamente e sua relação com a regra discriminante linear normal torna-se particularmente transparente.

20.17 O caso de dois grupos

Quando

$$G = 2,$$

a dispersão entre grupos possui posto no máximo 1. Portanto, existe no máximo uma direção discriminante com raiz positiva.

Defina a diferença entre os centroides amostrais por

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 \in \mathbb{R}^p. \quad (20.54)$$

Para dois grupos,

$$\mathbf{T}_{\text{entre}} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top. \quad (20.55)$$

Como

$$\mathbf{d} \mathbf{d}^\top$$

possui posto no máximo 1, segue imediatamente que

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq 1.$$

Se

$$\mathbf{d} = \mathbf{0},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação positiva entre os centroides amostrais.

Considere, portanto,

$$\mathbf{d} \neq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Substituindo Equação 20.55 em Equação 20.41,

$$\frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}.$$

Para uma raiz positiva,

$$\mathbf{d}^\top \mathbf{a} \neq 0,$$

pois, caso contrário, o lado esquerdo seria nulo e, como

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

teríamos

$$\lambda = 0.$$

Assim, para a direção associada à raiz positiva,

$$\mathbf{T}_{\text{intra}} \mathbf{a}_1 \propto \mathbf{d}.$$

Como

$$\mathbf{T}_{\text{intra}}$$

é invertível,

$$\mathbf{a}_1 \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (20.56)$$

Essa expressão mostra por que a direção de Fisher não corresponde, em geral, simplesmente à reta que une os centroides.

O vetor

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$$

representa a separação bruta entre os grupos.

A multiplicação por

$$\mathbf{T}_{\text{intra}}^{-1}$$

modifica essa direção de acordo com a dispersão e as associações existentes dentro dos grupos.

Em direções com grande dispersão intragrupos, uma determinada diferença entre os centroides recebe menor importância relativa. Em direções com pequena dispersão intragrupos, uma diferença de mesma magnitude pode assumir maior importância discriminante.

Esse é exatamente o significado geométrico do denominador do critério de Fisher.

20.17.1 Formulação populacional para dois grupos

A mesma estrutura aparece no problema populacional.

Considere

$$P(C = 1) = \pi_1, \quad P(C = 2) = \pi_2,$$

com

$$\pi_1 + \pi_2 = 1,$$

e defina

$$\mathbf{d}_\mu = \mu_1 - \mu_2.$$

A dispersão entre grupos de Equação 20.32 reduz-se a

$$\Sigma_B = \pi_1 \pi_2 \mathbf{d}_\mu \mathbf{d}_\mu^\top.$$

Se

$$\Sigma_W \succ \mathbf{0}$$

e

$$\mu_1 \neq \mu_2,$$

a direção populacional de Fisher satisfaz

$$\mathbf{a}_F \propto \Sigma_W^{-1} (\mu_1 - \mu_2).$$

Essa expressão não exige normalidade. Ela decorre da estrutura de segundos momentos e do problema de Rayleigh generalizado.

20.18 Relação entre Fisher e a discriminação linear normal

A formulação probabilística da LDA e a formulação geométrica de Fisher partem de problemas estatísticos distintos.

A relação entre elas torna-se particularmente simples no caso de dois grupos com covariância populacional comum.

Considere

$$\mathbf{X} \mid \mathbf{C} = k \sim N_p(\mu_k, \Sigma), \quad g = 1, 2,$$

com

$$\Sigma \succ \mathbf{0}.$$

Na formulação probabilística, a fronteira da LDA sob perda zero-um possui vetor normal

$$\Sigma^{-1} (\mu_1 - \mu_2), \quad (20.57)$$

conforme Equação 20.11.

Na formulação populacional de Fisher, a igualdade das covariâncias condicionais implica

$$\Sigma_W = \pi_1 \Sigma + \pi_2 \Sigma = \Sigma.$$

Portanto,

$$\mathbf{a}_F \propto \Sigma^{-1} (\mu_1 - \mu_2). \quad (20.58)$$

Assim, sob covariância comum, a direção de Fisher e o vetor normal à fronteira da LDA são paralelos (Anderson, 2003; Fisher, 1936; Johnson; Wichern, 2007).

Essa coincidência é uma equivalência de **direção**.

Ela não torna os dois problemas estatísticos idênticos.

Fisher resolve

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}},$$

e obtém uma direção que maximiza a separação relativa entre as populações.

A LDA, por sua vez, resolve um problema de decisão. Sob perda zero-um, ela compara

$$\delta_1(\mathbf{x})$$

e

$$\delta_2(\mathbf{x})$$

para determinar em qual lado da fronteira uma nova observação será classificada.

A posição dessa fronteira depende também dos termos

$$-\frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k$$

e

$$\log \pi_k.$$

As probabilidades *a priori* podem, portanto, deslocar a fronteira sem alterar sua orientação.

Se a função de perda não for zero-um, os custos associados às decisões também podem alterar a regra ótima, enquanto o critério geométrico de Fisher permanece inalterado.

Por isso,

direção discriminante e regra de classificação são objetos distintos.

20.18.1 Relação amostral

Na amostra, a matriz de covariâncias agrupada definida em Equação 20.24 satisfaz

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}. \quad (20.59)$$

Consequentemente,

$$\mathbf{S}_p^{-1} = (n - K) \mathbf{T}_{\text{intra}}^{-1}.$$

Para dois grupos,

$$\mathbf{S}_p^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$

Assim, quando a mesma matriz agrupada de covariâncias é utilizada, a orientação estimada da fronteira da LDA coincide, até escala, com a direção amostral de Fisher.

Novamente, a equivalência é da direção. A função discriminante estimada ainda contém

$$\log \hat{\pi}_k$$

e os termos constantes necessários para definir a posição da fronteira e realizar a classificação.

20.18.2 Mais de dois grupos

Quando

$$G > 2,$$

a matriz

$$\mathbf{T}_{\text{entre}}$$

pode possuir posto maior que 1.

A formulação de Fisher fornece

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1)$$

direções com raízes positivas.

A LDA, entretanto, não precisa projetar uma observação nessas direções para classificá-la. A regra populacional compara diretamente

$$\delta_1(\mathbf{x}), \dots, \delta_G(\mathbf{x})$$

no espaço original.

As direções de Fisher podem ser utilizadas para representação discriminante de baixa dimensão, enquanto a LDA define uma regra probabilística de decisão.

As duas construções compartilham a estrutura de médias e dispersão intragrupos, mas continuam respondendo a perguntas diferentes.

20.19 Existência e singularidade

As formulações clássicas de Fisher, LDA e QDA utilizam inversas de matrizes de dispersão ou covariância.

A existência dessas inversas é uma questão algébrica que deve ser distinguida das hipóteses probabilísticas utilizadas para justificar os modelos de classificação.

20.19.1 Formulação populacional de Fisher

O critério populacional em Equação 20.36 foi formulado supondo

$$\Sigma_W \succ \mathbf{0}.$$

Essa condição garante

$$\mathbf{a}^\top \Sigma_W \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0}$$

e permite utilizar

$$\Sigma_W^{-1} \quad \text{e} \quad \Sigma_W^{-1/2}.$$

A positividade definida de

$$\Sigma_W$$

não exige normalidade.

Ela é uma condição sobre a estrutura de segundo momento dentro das classes.

20.19.2 Formulação amostral de Fisher

Na formulação amostral clássica foi assumido

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Como

$$\mathbf{T}_{\text{intra}}$$

é formada a partir de dados centralizados separadamente em cada um dos K grupos, seu posto satisfaz

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K). \quad (20.60)$$

Consequentemente, uma condição necessária para

$$\mathbf{T}_{\text{intra}}$$

possuir posto completo é

$$n - K \geq p. \quad (20.61)$$

Essa condição não é suficiente para um conjunto de dados arbitrário.

Mesmo quando

$$n - K \geq p,$$

relações lineares exatas entre as características dentro dos grupos podem tornar

$$\mathbf{T}_{\text{intra}}$$

singular.

Quando

$$p > n - K,$$

a singularidade é inevitável.

Nesse caso, a formulação clássica baseada em

$$\mathbf{T}_{\text{intra}}^{-1}$$

e

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

não está definida diretamente.

Pseudoinversas, regularização ou redução preliminar de dimensão constituem outras formulações e serão tratadas posteriormente.

20.19.3 LDA estimada

Na regra populacional da LDA foi assumido

$$\Sigma \succ \mathbf{0}.$$

Na regra *plug-in*, essa matriz é substituída por

$$\mathbf{S}_p.$$

Como

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}},$$

as duas matrizes possuem o mesmo posto.

Portanto,

$$\mathbf{S}_p$$

é invertível se, e somente se,

$$\mathbf{T}_{\text{intra}}$$

é invertível.

Assim, a LDA estimada e a formulação amostral clássica de Fisher compartilham o mesmo problema de singularidade da dispersão intragrupos.

20.19.4 QDA estimada

Na QDA, cada classe possui uma matriz de covariâncias própria.

A regra populacional clássica supõe

$$\Sigma_k \succ \mathbf{0}, \quad k = 1, \dots, K.$$

Na regra estimada, cada matriz é substituída por

$$\mathbf{S}_k.$$

Como

$$\mathbf{S}_k$$

é construída a partir de

$$n_k$$

observações centralizadas pelo próprio centroide,

$$\text{posto}(\mathbf{S}_k) \leq \min(p, n_k - 1).$$

Logo,

$$n_k - 1 \geq p \tag{20.62}$$

é condição necessária para que a covariância amostral usual da classe k possa possuir posto completo.

A QDA precisa satisfazer essa condição separadamente em cada grupo.

Por isso, sua formulação *plug-in* clássica exige mais informação por classe do que a LDA quando

$$p$$

é elevado.

20.20 Identificação das direções discriminantes

As direções de Fisher apresentam as indeterminações próprias de um problema de autovalores generalizados.

Considere uma raiz positiva simples

$$\lambda_j$$

e um autovetor

$$\mathbf{a}_j$$

satisfazendo

$$\mathbf{T}_{\text{entre}} \mathbf{a}_j = \lambda_j \mathbf{T}_{\text{intra}} \mathbf{a}_j.$$

Para qualquer

$$c \neq 0,$$

o vetor

$$c\mathbf{a}_j$$

satisfaz a mesma equação.

Portanto, o comprimento do autovetor não é identificado pelo problema.

Com a normalização de Equação 20.47,

$$\mathbf{a}_j^\top \mathbf{T}_{\text{intra}} \mathbf{a}_j = 1,$$

a indeterminação de escala é eliminada, mas permanece a indeterminação de sinal:

$$\mathbf{a}_j \quad \text{e} \quad -\mathbf{a}_j$$

representam o mesmo eixo discriminante.

A mudança de sinal produz

$$z_j(\mathbf{x}) \mapsto -z_j(\mathbf{x}),$$

mas não altera distâncias ao longo do eixo, separação dos centroides ou o subespaço representado.

Se uma raiz positiva possui multiplicidade maior que 1, os autovetores individuais associados não são únicos.

Diferentes bases ortonormais segundo a métrica

$$\mathbf{T}_{\text{intra}}$$

podem representar o mesmo autoespaço.

Nesse caso, o objeto identificado é o **subespaço discriminante associado à raiz repetida**, e não uma base particular.

Essa distinção deve ser preservada quando coordenadas discriminantes são interpretadas individualmente.

20.21 Pressupostos e limites

A Análise Discriminante reúne três construções que não possuem exatamente os mesmos requisitos:

1. o critério geométrico de Fisher;
2. a regra normal linear;
3. a regra normal quadrática.

A Tabela 20.4 separa as principais condições.

Tabela 20.4: Condições associadas às formulações de Fisher, LDA e QDA.

Condição	Fisher	LDA normal	QDA normal
grupos previamente definidos	necessária	necessária	necessária
segundos momentos finitos	necessários para a formulação populacional	satisfeitos sob normalidade	satisfeitos sob normalidade
normalidade multivariada	não necessária para definir Fisher	necessária para a derivação normal da regra apresentada	necessária para a derivação normal da regra apresentada
covariância comum entre grupos	não necessária	assumida	não assumida
matriz não singular na formulação clássica	$\Sigma_W \succ 0$ ou $\mathbf{T}_{\text{intra}} \succ 0$	$\Sigma \succ 0$ e, na regra estimada, $\mathbf{S}_p$ invertível	$\Sigma_k \succ 0$ e, na regra estimada, $\mathbf{S}_k$ invertível
probabilidades <i>a priori</i>	não entram no critério	entram na regra de decisão	entram na regra de decisão
função de perda	não entra no critério	as funções apresentadas correspondem à perda zero-um	as funções apresentadas correspondem à perda zero-um

20.21.1 Grupos previamente definidos

A Análise Discriminante pressupõe que os rótulos utilizados na construção da técnica possuem significado previamente estabelecido.

Na formulação de Fisher, esses rótulos determinam

$$\mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{entre}}.$$

Na formulação probabilística, eles determinam quais observações caracterizam cada distribuição condicional.

A técnica não descobre automaticamente a existência de classes naturais.

Se os rótulos forem inadequados ao problema substantivo, uma solução matemática bem definida continuará descrevendo a separação ou classificação relativamente a esses rótulos.

20.21.2 Normalidade e estrutura das covariâncias

A normalidade multivariada não é necessária para definir as dispersões populacionais de Fisher, o critério

$$J_F^{(P)}(\mathbf{a})$$

ou sua versão amostral.

A normalidade entra nas formulações LDA e QDA apresentadas neste capítulo porque permite escrever explicitamente as densidades condicionais e derivar as regras de Bayes correspondentes.

Na LDA,

$$\Sigma_1 = \cdots = \Sigma_K = \Sigma.$$

É essa igualdade que faz com que os termos quadráticos em

$$\mathbf{x}$$

sejam comuns às classes e se cancelem na comparação.

Na QDA, as matrizes

$$\Sigma_k$$

podem diferir e esse cancelamento não ocorre.

A distinção entre fronteiras lineares e quadráticas é, portanto, consequência direta da estrutura probabilística assumida.

20.21.3 Independência das unidades da amostra de treinamento

Os estimadores usuais de médias e covariâncias apresentados neste capítulo pressupõem o esquema amostral clássico em que as unidades de treinamento fornecem informação independente sobre as populações consideradas.

Dependência temporal, espacial, longitudinal ou por agrupamentos pode modificar a estrutura amostral dos estimadores e não é incorporada automaticamente pelas fórmulas usuais de LDA e QDA.

Essa é uma questão da estrutura probabilística dos dados, e não do problema algébrico de Fisher isoladamente.

20.21.4 Probabilidades *a priori* e perdas

As probabilidades

$$\pi_k$$

pertencem ao modelo de decisão.

Elas representam a ocorrência ou o peso prévio atribuído às classes antes da observação de

$$\mathbf{x}.$$

Sob perda zero-um, aparecem nas funções discriminantes por meio de

$$\log \pi_k.$$

A função de perda possui papel distinto.

Quando decisões erradas possuem consequências diferentes, a regra ótima é aquela que minimiza

$$R(a \mid \mathbf{x}),$$

e não necessariamente a classe de maior posterior.

Portanto:

- probabilidades *a priori*;
- probabilidades posteriores;
- função de perda;

pertencem ao problema de classificação.

Nenhum desses objetos participa do critério geométrico de Fisher.

20.21.5 Sobreposição entre as populações

Mesmo com os parâmetros populacionais conhecidos e o modelo corretamente especificado, pode existir erro inevitável de classificação.

Se duas classes atribuem densidade positiva às mesmas regiões do espaço das características, então uma observação localizada nessas regiões não revela determinísticamente sua classe de origem.

A regra de Bayes escolhe a ação de menor risco condicional, mas o risco mínimo pode ser positivo.

Assim, erro de classificação não é necessariamente evidência de erro de estimação ou inadequação da técnica.

Parte dele pode resultar da própria sobreposição das distribuições populacionais.

A avaliação empírica do desempenho de uma regra estimada — incluindo validação cruzada, amostras de teste, matriz de confusão e medidas de desempenho — pertence à etapa metodológica posterior.

20.22 Relações com outras técnicas

A relação mais direta ocorre com a MANOVA. Na comparação de grupos,

$$\mathbf{H} = \mathbf{T}_{\text{entre}}$$

e

$$\mathbf{E} = \mathbf{T}_{\text{intra}},$$

conforme Equação 20.53. Assim, o problema espectral

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

da MANOVA coincide com

$$\mathbf{T}_{\text{entre}}\mathbf{a} = \lambda\mathbf{T}_{\text{intra}}\mathbf{a}$$

na formulação de Fisher quando as matrizes representam a mesma estrutura de grupos.

As raízes e os subespaços característicos são os mesmos, mas recebem funções estatísticas diferentes. Na MANOVA, as raízes são utilizadas para construir critérios de teste sobre efeitos multivariados. Em Fisher, os autovetores associados às raízes positivas definem direções de separação. A formulação probabilística da Análise Discriminante acrescenta ainda uma regra de decisão para classificar novas observações.

A relação com a ACP decorre do uso comum de combinações lineares e problemas espectrais. A ACP procura direções de grande variabilidade total,

$$\mathbf{v}^\top \mathbf{S} \mathbf{v},$$

enquanto Fisher maximiza

$$\frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

A diferença decorre do uso dos rótulos de grupo. Uma direção de grande variância total não precisa produzir boa separação entre classes. A Tabela 20.5 sintetiza essa distinção.

Tabela 20.5: Diferença entre as projeções da ACP e de Fisher.

Aspecto	ACP	Fisher
informação sobre grupos	não utilizada	utilizada
objeto matricial principal	covariância ou correlação total	dispersões entre e dentro dos grupos
critério	variância total	separação entre grupos relativa à dispersão intragrupos
tipo de representação	não supervisionada em relação aos grupos	supervisionada
dimensão máxima não nula	limitada pelo posto da matriz de covariâncias/dados	$\min(p, K - 1)$
interpretação das direções	variabilidade	separação relativa

Análise Discriminante e Análise de Agrupamentos também utilizam centroides, distâncias e dispersões, mas partem de informações distintas. Na Discriminante, os grupos são conhecidos e seus rótulos participam da construção. Em Agrupamentos, os grupos precisam ser definidos a partir dos dados.

A relação com a Correlação Canônica aparece quando a informação de classe é representada por variáveis indicadoras ou contrastes. Sob codificações e ponderações apropriadas, o subespaço

obtido pode ser relacionado ao subespaço discriminante de Fisher. Essa conexão será retomada no próximo capítulo.

20.23 Síntese

A Análise Discriminante reúne uma formulação probabilística para classificação e uma formulação geométrica para separação entre grupos conhecidos.

Na formulação de decisão, cada classe possui probabilidade *a priori*

$$\pi_k$$

e densidade condicional

$$f_k(\mathbf{x}).$$

Para uma função de perda $L(a, g)$, a regra de Bayes escolhe uma ação que minimize o risco condicional

$$R(a \mid \mathbf{x}).$$

Sob perda zero-um, essa regra equivale a selecionar uma classe que maximize

$$P(\mathbf{C} = k \mid \mathbf{X} = \mathbf{x}),$$

ou, de forma equivalente,

$$\pi_g f_g(\mathbf{x}).$$

Quando

$$\mathbf{X} \mid \mathbf{C} = k \sim N_p(\mu_k, \Sigma)$$

com covariância comum, os termos quadráticos comuns às classes se cancelam e a regra é determinada pelas funções discriminantes lineares

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k.$$

Quando as matrizes de covariâncias

$$\Sigma_k$$

diferem entre as classes, esse cancelamento deixa de ocorrer e a função discriminante passa a conter termos quadráticos em $\mathbf{x}$, produzindo a QDA.

As regras populacionais dependem de parâmetros desconhecidos. Na prática amostral, médias, covariâncias e, quando apropriado, probabilidades *a priori* são substituídas por estimativas. Essa passagem distingue parâmetros, estimadores, estimativas e regras discriminantes estimadas.

Na formulação geométrica de Fisher, a variabilidade é decomposta em dispersões dentro e entre os grupos. Para uma direção

$$\mathbf{a},$$

a separação populacional é medida por

$$J_F^{(P)}(\mathbf{a}) = \frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}},$$

e sua versão amostral utiliza

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

Quando

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

a maximização conduz ao problema de autovalores generalizados

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}.$$

As direções associadas às raízes positivas formam o subespaço discriminante, cuja dimensão satisfaz

$$r_F \leq \min(p, K - 1).$$

Raízes simples identificam direções até mudança de sinal. Raízes repetidas identificam os respectivos subespaços, e não uma base particular.

No caso de dois grupos,

$$\mathbf{a}_1 \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$

Sob normalidade e covariância comum, a direção populacional correspondente é proporcional a

$$\Sigma^{-1} (\mu_1 - \mu_2),$$

que também determina a orientação da fronteira da LDA. Essa coincidência relaciona as duas formulações, mas não iguala seus objetivos: Fisher constrói direções de separação, enquanto a LDA constrói uma regra de decisão.

A normalidade multivariada não é necessária para definir o critério de Fisher. Ela é utilizada na derivação das regras normais LDA e QDA. A covariância comum é específica da LDA, enquanto probabilidades *a priori* e perdas pertencem ao problema de decisão.

As formulações clássicas também dependem de condições de posto e não singularidade. Na amostra, a possibilidade de inverter as matrizes de dispersão ou covariância depende da dimensão, do tamanho dos grupos e da estrutura das variáveis.

A Análise Discriminante integra decisão estatística, teorema de Bayes, normal multivariada, distância de Mahalanobis, formas quadráticas, decomposição da dispersão, projeções e autovalores generalizados. Sua relação espectral com a MANOVA mostra como a mesma estrutura matricial pode sustentar inferência sobre grupos ou construção de direções discriminantes, conforme o problema estatístico formulado.

No próximo capítulo, os grupos deixam de organizar a análise. A Correlação Canônica considerará dois blocos de variáveis quantitativas e construirá combinações lineares de cada bloco cuja correlação seja máxima.

21 Formulação da Correlação Canônica

A Correlação Canônica estuda a associação linear entre dois blocos de variáveis quantitativas observados sobre as mesmas unidades. A técnica constrói uma combinação linear de cada bloco e procura maximizar a correlação entre essas combinações (Anderson, 2003; Johnson; Wichern, 2007; Mardia; Kent; Taylor, 2024).

Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com

$$p, q \geq 1,$$

definidos sobre a mesma população e com segundos momentos finitos. Os dois blocos desempenham papéis matematicamente simétricos na formulação básica.

As variáveis canônicas são combinações centradas da forma

$$U_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X)$$

e

$$V_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y).$$

O primeiro par maximiza a correlação entre os dois blocos. Os pares seguintes representam dimensões adicionais de associação linear sob restrições que evitam repetir as dimensões anteriores.

O capítulo mostra como esse problema conduz ao branqueamento das estruturas intrabloco e à SVD da covariância cruzada branqueada. Também desenvolve a formulação equivalente por autovalores generalizados, a interpretação geométrica, as quantidades amostrais e as condições de existência e identificação.

Algoritmos, escolha prática do número de dimensões, diagnósticos extensos, regularização e aplicações serão tratados posteriormente.

A estrutura geral é resumida na Tabela 21.1.

Tabela 21.1: Elementos da formulação da Correlação Canônica.

Elemento	Objeto	Papel na Correlação Canônica
primeiro bloco	$\mathbf{X} \in \mathbb{R}^p$	conjunto de variáveis do primeiro domínio
segundo bloco	$\mathbf{Y} \in \mathbb{R}^q$	conjunto de variáveis do segundo domínio
associação entre blocos	$\Sigma_{XY} \in \mathbb{R}^{p \times q}$	reúne as covariâncias cruzadas
estrutura interna do primeiro bloco	$\Sigma_{XX} \in \mathbb{R}^{p \times p}$	representa variâncias e covariâncias de $\mathbf{X}$
estrutura interna do segundo bloco	$\Sigma_{YY} \in \mathbb{R}^{q \times q}$	representa variâncias e covariâncias de $\mathbf{Y}$
combinação do primeiro bloco	$\mathbf{U} = \mathbf{a}^\top (\mathbf{X} - \mu_X)$	resume linearmente o primeiro bloco
combinação do segundo bloco	$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y)$	resume linearmente o segundo bloco
função objetivo	$\text{Corr}(\mathbf{U}, \mathbf{V})$	mede a associação entre as duas combinações
solução matricial	SVD de uma covariância cruzada branqueada	determina correlações e direções canônicas
resultado	$\rho_1, \dots, \rho_m$	correlações canônicas ordenadas

21.1 O problema de associação entre dois blocos

Considere um primeiro conjunto de características representado por

$$\mathbf{X} = (X_1, \dots, X_p)^\top$$

e um segundo conjunto representado por

$$\mathbf{Y} = (Y_1, \dots, Y_q)^\top.$$

Uma análise baseada somente nas correlações

$$\text{Corr}(X_h, Y_k), \quad h = 1, \dots, p, \quad k = 1, \dots, q,$$

descreve associações entre pares específicos de variáveis.

Entretanto, a associação entre os dois blocos pode estar distribuída simultaneamente por várias componentes.

Uma combinação

$$U = a_1 (X_1 - \mu_{X_1}) + \cdots + a_p (X_p - \mu_{X_p})$$

pode concentrar um padrão do primeiro bloco que esteja fortemente associado a outra combinação,

$$V = b_1 (Y_1 - \mu_{Y_1}) + \cdots + b_q (Y_q - \mu_{Y_q}),$$

mesmo quando nenhuma correlação bivariada isolada resume adequadamente essa relação.

A questão estatística é, portanto, encontrar

$$\mathbf{a} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^q$$

que façam as duas combinações lineares apresentar a maior correlação possível.

A diferença em relação a outras técnicas baseadas em projeções está na função objetivo.

Na ACP, uma direção é escolhida para maximizar a variabilidade de um único conjunto.

Na formulação de Fisher, uma direção é escolhida para maximizar a separação entre grupos relativamente à dispersão intragrupos.

Na Correlação Canônica, **duas direções são escolhidas simultaneamente**, uma em cada bloco, com o objetivo de maximizar a associação entre as duas combinações produzidas.

Por isso, a solução não será determinada apenas pela variabilidade existente dentro de cada conjunto nem apenas pelas covariâncias cruzadas. Ela dependerá da relação entre essas duas estruturas.

21.2 Estrutura de covariâncias em blocos

Como os vetores possuem segundos momentos finitos, existem

$$E(\mathbf{X}) = \mu_X \in \mathbb{R}^p$$

e

$$E(\mathbf{Y}) = \mu_Y \in \mathbb{R}^q.$$

Pela estrutura da matriz de covariâncias de um vetor particionado estabelecida em Equação 8.15, para o vetor conjunto

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} \in \mathbb{R}^{p+q},$$

tem-se

$$\Sigma = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \in \mathbb{R}^{(p+q) \times (p+q)}. \quad (21.1)$$

Os blocos diagonais,

$$\Sigma_{XX} = \text{Cov}(\mathbf{X}) \in \mathbb{R}^{p \times p}$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}) \in \mathbb{R}^{q \times q},$$

descrevem as estruturas internas de variabilidade e covariância dos dois conjuntos.

O bloco

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) \in \mathbb{R}^{p \times q}$$

é a matriz de covariâncias cruzadas definida em Definição 8.3.

Sua transposta é

$$\Sigma_{YX} = \Sigma_{XY}^\top \in \mathbb{R}^{q \times p}.$$

A matriz

$$\Sigma_{XY}$$

contém a informação de associação linear que conecta os blocos.

Entretanto, suas entradas não podem ser avaliadas isoladamente da variabilidade interna representada por

$$\Sigma_{XX} \quad \text{e} \quad \Sigma_{YY}.$$

Uma covariância cruzada de determinada magnitude possui significado diferente quando as variâncias das combinações envolvidas também são grandes ou pequenas.

A Correlação Canônica irá separar essas funções. As estruturas internas dos dois blocos serão utilizadas para definir as métricas de normalização, enquanto

$$\Sigma_{XY}$$

determinará a ligação entre eles.

Na formulação clássica desenvolvida neste capítulo, será assumido

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0}.$$

Essas condições garantem variância positiva para toda combinação linear não nula de cada bloco e, posteriormente, a existência de

$$\Sigma_{XX}^{-1/2} \quad \text{e} \quad \Sigma_{YY}^{-1/2}.$$

Não se exige normalidade conjunta para essa construção.

21.2.1 Ausência de associação linear entre os blocos

O resultado estabelecido em Proposição 8.4 fornece, para quaisquer

$$\mathbf{a} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^q,$$

a identidade

$$\text{Cov} \left[\mathbf{a}^\top (\mathbf{X} - \mu_X), \mathbf{b}^\top (\mathbf{Y} - \mu_Y) \right] = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (21.2)$$

Assim, se

$$\Sigma_{XY} = \mathbf{0}, \quad (21.3)$$

então

$$\text{Cov} \left[\mathbf{a}^\top (\mathbf{X} - \mu_X), \mathbf{b}^\top (\mathbf{Y} - \mu_Y) \right] = 0$$

para **todas** as combinações lineares dos dois blocos.

Nesse caso, nenhuma escolha de

$$\mathbf{a} \quad \text{e} \quad \mathbf{b}$$

produz covariância linear diferente de zero entre as combinações.

A recíproca também vale.

Se

$$\mathbf{a}^\top \Sigma_{XY} \mathbf{b} = 0$$

para todos

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

então

$$\Sigma_{XY} = \mathbf{0}.$$

Por exemplo, tomando os vetores das bases canônicas,

$$\mathbf{a} = \mathbf{e}_h, \quad \mathbf{b} = \mathbf{e}_k,$$

obtém-se

$$\text{Cov}(X_h, Y_k) = 0$$

para todo

$$h = 1, \dots, p \quad \text{e} \quad k = 1, \dots, q.$$

Portanto,

$$\Sigma_{XY}$$

é o objeto populacional que reúne toda a associação **linear** entre os dois conjuntos.

Se o vetor conjunto

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix}$$

possui distribuição normal multivariada, o resultado de Proposição 9.6 implica

$$\Sigma_{XY} = \mathbf{0} \quad \Longleftrightarrow \quad \mathbf{X} \perp \mathbf{Y}. \quad (21.4)$$

Essa equivalência depende da normalidade conjunta.

Fora desse modelo,

$$\Sigma_{XY} = \mathbf{0}$$

significa ausência de associação linear entre os blocos, mas não implica independência em geral.

Essa distinção será mantida ao longo do capítulo: a **Correlação Canônica populacional pode ser definida sem normalidade**, enquanto a normalidade conjunta acrescenta propriedades probabilísticas e sustenta parte da teoria inferencial clássica.

21.3 Variáveis canônicas e função objetivo

Considere as combinações lineares centradas

$$\mathbf{U} = \mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y), \quad (21.5)$$

com

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{b} \in \mathbb{R}^q.$$

Pela variância de combinações lineares estabelecida em Proposição 8.1,

$$\text{Var}(\mathbf{U}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a}, \quad (21.6)$$

e

$$\text{Var}(\mathbf{V}) = \mathbf{b}^\top \Sigma_{YY} \mathbf{b}. \quad (21.7)$$

Além disso, aplicando Proposição 8.4,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (21.8)$$

Sob

$$\Sigma_{XX} \succ \mathbf{0} \quad \text{e} \quad \Sigma_{YY} \succ \mathbf{0},$$

se

$$\mathbf{a} \neq \mathbf{0} \quad \text{e} \quad \mathbf{b} \neq \mathbf{0},$$

então

$$\text{Var}(\mathbf{U}) > 0 \quad \text{e} \quad \text{Var}(\mathbf{V}) > 0.$$

A correlação está, portanto, definida e é

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \frac{\mathbf{a}^\top \Sigma_{XY} \mathbf{b}}{\sqrt{\mathbf{a}^\top \Sigma_{XX} \mathbf{a}} \sqrt{\mathbf{b}^\top \Sigma_{YY} \mathbf{b}}}. \quad (21.9)$$

Essa expressão contém três estruturas diferentes:

- o numerador mede a covariância entre as combinações dos dois blocos;
- a primeira forma quadrática do denominador mede a variância da combinação de $\mathbf{X}$;
- a segunda mede a variância da combinação de $\mathbf{Y}$.

A função objetivo é invariante a mudanças de escala dos coeficientes. Se

$$c \neq 0 \quad \text{e} \quad d \neq 0,$$

então

$$\text{Corr}[(c\mathbf{a})^\top \mathbf{X}, (d\mathbf{b})^\top \mathbf{Y}] = \text{sgn}(cd) \text{Corr}(\mathbf{U}, \mathbf{V}).$$

Portanto, os comprimentos de

$$\mathbf{a} \quad \text{e} \quad \mathbf{b}$$

não são determinados pelo problema.

Uma normalização natural é fixar as variâncias das duas combinações:

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1 \quad (21.10)$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1. \quad (21.11)$$

Sob essas restrições,

$$\text{Var}(\mathbf{U}) = \text{Var}(\mathbf{V}) = 1$$

e

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (21.12)$$

A procura pela maior correlação transforma-se, assim, em um problema de maximização de uma **forma bilinear** sujeito a duas restrições quadráticas.

Essa estrutura é diferente do quociente de Rayleigh generalizado utilizado na MANOVA e na Análise Discriminante.

Naquelas técnicas, um único vetor aparece em duas formas quadráticas.

Na Correlação Canônica, existem dois vetores,

$$\mathbf{a} \quad \text{e} \quad \mathbf{b},$$

pertencentes a espaços de dimensões que podem ser diferentes, e o termo que conecta os dois blocos é

$$\mathbf{a}^\top \Sigma_{XY} \mathbf{b}.$$

Essa diferença é a razão matemática pela qual a SVD de uma matriz retangular aparecerá naturalmente na solução.

Definição 21.1 (Primeiro par canônico). Sejam

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos, médias

$$\mu_X = E(\mathbf{X})$$

e

$$\mu_Y = E(\mathbf{Y}),$$

e matrizes

$$\Sigma_{XX} = \text{Cov}(\mathbf{X}) \succ \mathbf{0},$$

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}) \succ \mathbf{0}$$

e

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) \in \mathbb{R}^{p \times q}.$$

O **primeiro par canônico** é formado por

$$\mathbf{U}_1 = \mathbf{a}_1^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V}_1 = \mathbf{b}_1^\top (\mathbf{Y} - \mu_Y),$$

em que

$$\mathbf{a}_1 \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b}_1 \in \mathbb{R}^q$$

resolvem

$$\max_{\mathbf{a} \in \mathbb{R}^p, \mathbf{b} \in \mathbb{R}^q} \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \tag{21.13}$$

sujeito a

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1.$$

O valor máximo

$$\rho_1 = \text{Corr}(\mathbf{U}_1, \mathbf{V}_1)$$

é a **primeira correlação canônica**.

As restrições definem conjuntos compactos porque

$$\Sigma_{XX} \succ \mathbf{0} \quad \text{e} \quad \Sigma_{YY} \succ \mathbf{0}.$$

Como a função

$$(\mathbf{a}, \mathbf{b}) \mapsto \mathbf{a}^\top \Sigma_{XY} \mathbf{b}$$

é contínua, o máximo existe.

Além disso, por ser uma correlação,

$$-1 \leq \rho_1 \leq 1.$$

Se uma solução produzir valor negativo, substituir

$$\mathbf{a}_1$$

por

$$-\mathbf{a}_1$$

ou

$$\mathbf{b}_1$$

por

$$-\mathbf{b}_1$$

preserva as restrições e troca o sinal da correlação.

Por convenção, escolhe-se a orientação de modo que

$$0 \leq \rho_1 \leq 1.$$

Se

$$\Sigma_{XY} = \mathbf{0},$$

então

$$\rho_1 = 0.$$

Reciprocamente, sob a positividade definida dos blocos internos, se

$$\rho_1 = 0,$$

então nenhuma combinação linear dos dois blocos possui correlação diferente de zero e, portanto,

$$\Sigma_{XY} = \mathbf{0}.$$

A próxima etapa consiste em transformar as duas restrições quadráticas em restrições euclidianas. Esse é o papel do **branqueamento** por

$$\Sigma_{XX}^{-1/2} \quad \text{e} \quad \Sigma_{YY}^{-1/2},$$

que permitirá converter o problema bilinear em uma maximização resolvida diretamente pela decomposição em valores singulares.

21.4 Da normalização ao branqueamento

As restrições

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1$$

mostram que os coeficientes dos dois blocos são normalizados segundo geometrias diferentes.

No primeiro bloco, a forma quadrática

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a}$$

mede a variância da combinação de $\mathbf{X}$, enquanto, no segundo,

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b}$$

mede a variância da combinação de $\mathbf{Y}$.

A solução torna-se mais transparente quando essas duas geometrias são transformadas em geometria euclidiana.

Como

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0},$$

as raízes quadradas principais dessas matrizes são positivas definidas e não singulares, conforme Definição 5.9. Portanto,

$$\Sigma_{XX}^{-1/2}$$

e

$$\Sigma_{YY}^{-1/2}$$

existem.

Defina

$$\mathbf{u} = \Sigma_{XX}^{1/2} \mathbf{a} \tag{21.14}$$

e

$$\mathbf{v} = \Sigma_{YY}^{1/2} \mathbf{b}. \tag{21.15}$$

Como as transformações são invertíveis,

$$\mathbf{a} = \Sigma_{XX}^{-1/2} \mathbf{u}$$

e

$$\mathbf{b} = \Sigma_{YY}^{-1/2} \mathbf{v}.$$

As restrições de variância tornam-se

$$\mathbf{u}^\top \mathbf{u} = 1$$

e

$$\mathbf{v}^\top \mathbf{v} = 1. \quad (21.16)$$

Ao substituir essas expressões em Equação 21.12, obtém-se

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \mathbf{u}^\top \left(\Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2} \right) \mathbf{v}. \quad (21.17)$$

Defina

$$\mathbf{K}_{CCA} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2} \in \mathbb{R}^{p \times q}. \quad (21.18)$$

A matriz $\mathbf{K}_{CCA}$ reúne a associação cruzada depois que as estruturas internas de covariância dos dois blocos foram padronizadas.

Essa interpretação pode ser vista diretamente sobre os vetores aleatórios. O branqueamento simétrico foi definido em Equação 8.50, e Equação 8.51 estabeleceu que essa transformação produz matriz de covariâncias identidade.

Aplicando-o separadamente aos dois blocos, defina

$$\mathbf{X}^* = \Sigma_{XX}^{-1/2} (\mathbf{X} - \mu_X) \quad (21.19)$$

e

$$\mathbf{Y}^* = \Sigma_{YY}^{-1/2} (\mathbf{Y} - \mu_Y). \quad (21.20)$$

Por Equação 8.51,

$$\text{Cov}(\mathbf{X}^*) = \mathbf{I}_p$$

e

$$\text{Cov}(\mathbf{Y}^*) = \mathbf{I}_q.$$

Além disso,

$$\text{Cov}(\mathbf{X}^*, \mathbf{Y}^*) = \mathbf{K}_{\text{CCA}}. \quad (21.21)$$

Portanto, o branqueamento transforma cada bloco em um vetor com matriz de covariâncias identidade e preserva, em

$$\mathbf{K}_{\text{CCA}},$$

a estrutura de associação linear existente entre eles.

É importante interpretar corretamente a expressão “remove a estrutura interna”. O branqueamento não elimina informação dos blocos. Ele incorpora suas variâncias e covariâncias à transformação de coordenadas, de modo que o problema restante possa ser analisado segundo a geometria euclidiana.

A maximização canônica passa então a ser

$$\max_{\|\mathbf{u}\|=\|\mathbf{v}\|=1} \mathbf{u}^\top \mathbf{K}_{\text{CCA}} \mathbf{v}. \quad (21.22)$$

Temos agora uma forma bilinear entre vetores pertencentes a dois espaços euclidianos que podem possuir dimensões diferentes.

Essa é precisamente a estrutura para a qual a Decomposição em Valores Singulares fornece a solução natural.

21.5 Solução pela Decomposição em Valores Singulares

Defina

$$m = \min(p, q).$$

A partir da SVD completa definida em Definição 6.3, podem ser retidos os m pares de vetores singulares associados às posições da diagonal retangular da decomposição.

Escreva

$$\mathbf{K}_{\text{CCA}} = \mathbf{L} \mathbf{D}_\rho \mathbf{R}^\top, \quad (21.23)$$

em que

$$\mathbf{L} = (\mathbf{l}_1 \quad \cdots \quad \mathbf{l}_m) \in \mathbb{R}^{p \times m},$$

$$\mathbf{R} = (\mathbf{r}_1 \quad \cdots \quad \mathbf{r}_m) \in \mathbb{R}^{q \times m},$$

e

$$\mathbf{D}_\rho = \text{diag}(\rho_1, \dots, \rho_m) \in \mathbb{R}^{m \times m}.$$

Os valores singulares são ordenados de modo que

$$\rho_1 \geq \rho_2 \geq \cdots \geq \rho_m \geq 0. \quad (21.24)$$

As colunas de $\mathbf{L}$ e $\mathbf{R}$ são ortonormais:

$$\mathbf{L}^\top \mathbf{L} = \mathbf{I}_m$$

e

$$\mathbf{R}^\top \mathbf{R} = \mathbf{I}_m.$$

Para cada

$$j = 1, \dots, m,$$

as relações singulares são

$$\mathbf{K}_{\text{CCA}} \mathbf{r}_j = \rho_j \mathbf{l}_j \quad (21.25)$$

e

$$\mathbf{K}_{\text{CCA}}^\top \mathbf{l}_j = \rho_j \mathbf{r}_j. \quad (21.26)$$

Combinando a desigualdade de Cauchy–Schwarz de Teorema 1.1 com a caracterização do maior valor singular em Proposição 6.6,

$$\max_{\|\mathbf{u}\|=\|\mathbf{v}\|=1} \mathbf{u}^\top \mathbf{K}_{\text{CCA}} \mathbf{v} = \rho_1.$$

Uma solução é

$$\mathbf{u}_1 = \mathbf{l}_1$$

e

$$\mathbf{v}_1 = \mathbf{r}_1.$$

Retornando às coordenadas originais,

$$\mathbf{a}_1 = \Sigma_{XX}^{-1/2} \mathbf{l}_1 \quad (21.27)$$

e

$$\mathbf{b}_1 = \Sigma_{YY}^{-1/2} \mathbf{r}_1. \quad (21.28)$$

Esses coeficientes satisfazem

$$\mathbf{a}_1^\top \Sigma_{XX} \mathbf{a}_1 = 1$$

e

$$\mathbf{b}_1^\top \Sigma_{YY} \mathbf{b}_1 = 1.$$

A correlação entre as correspondentes variáveis canônicas é

$$\text{Corr}(\mathbf{U}_1, \mathbf{V}_1) = \rho_1.$$

Como se trata de uma correlação,

$$0 \leq \rho_1 \leq 1.$$

A mesma construção aplicada aos demais pares de vetores singulares produz as dimensões canônicas sucessivas.

Definição 21.2 (Correlações canônicas). Sejam

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos e matrizes de covariâncias

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0}.$$

Seja

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) \in \mathbb{R}^{p \times q}$$

e defina

$$\mathbf{K}_{CCA} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}.$$

Para

$$m = \min(p, q),$$

as **correlações canônicas** são os valores singulares

$$\rho_1 \geq \cdots \geq \rho_m \geq 0$$

de

$$\mathbf{K}_{CCA}.$$

Para cada j , uma escolha correspondente de coeficientes canônicos é

$$\mathbf{a}_j = \Sigma_{XX}^{-1/2} \mathbf{l}_j$$

e

$$\mathbf{b}_j = \Sigma_{YY}^{-1/2} \mathbf{r}_j,$$

em que

$$\mathbf{l}_j \quad \text{e} \quad \mathbf{r}_j$$

são vetores singulares associados a ρ_j .

A definição mostra que as correlações canônicas não são selecionadas dentre as correlações bivariadas originais.

Elas resultam da otimização sobre **todas as combinações lineares admissíveis dos dois blocos**, depois de incorporadas as estruturas internas de covariância de cada conjunto.

21.6 Pares canônicos sucessivos

Para

$$j = 1, \dots, m,$$

defina

$$\mathbf{a}_j = \Sigma_{XX}^{-1/2} \mathbf{l}_j \tag{21.29}$$

e

$$\mathbf{b}_j = \Sigma_{YY}^{-1/2} \mathbf{r}_j. \tag{21.30}$$

As variáveis canônicas correspondentes são

$$U_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X)$$

e

$$V_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y). \tag{21.31}$$

A expressão “pares sucessivos” descreve problemas de otimização sujeitos às restrições impostas pelas dimensões anteriormente obtidas; ela não corresponde simplesmente à ordenação posterior dos valores singulares.

Depois de obtidos os pares

$$(\mathbf{U}_1, \mathbf{V}_1), \dots, (\mathbf{U}_{j-1}, \mathbf{V}_{j-1}),$$

o j -ésimo par maximiza

$$\text{Corr}(\mathbf{U}, \mathbf{V})$$

entre combinações unitariamente padronizadas que sejam não correlacionadas, dentro de cada bloco, com as variáveis canônicas anteriormente obtidas.

Equivalentemente, para

$$j \geq 2,$$

procura-se maximizar

$$\mathbf{a}^\top \Sigma_{XY} \mathbf{b} \tag{21.32}$$

sujeito a

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1,$$

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1,$$

e, para

$$k = 1, \dots, j-1,$$

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a}_k = 0$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b}_k = 0. \tag{21.33}$$

Depois do branqueamento, essas restrições tornam-se simplesmente

$$\mathbf{u}^\top \mathbf{l}_k = 0$$

e

$$\mathbf{v}^\top \mathbf{r}_k = 0, \quad k < j.$$

A caracterização variacional dos valores singulares mostra então que o valor máximo do j -ésimo problema é

$$\rho_j.$$

Portanto,

$$\rho_1 \geq \rho_2 \geq \cdots \geq \rho_m \geq 0$$

representa uma sequência de associações lineares máximas sujeitas à exclusão das dimensões canônicas já utilizadas.

A ortogonalidade dos vetores singulares produz diretamente a estrutura de covariâncias das variáveis canônicas.

Para

$$j, \ell \in \{1, \dots, m\},$$

tem-se

$$\begin{aligned} \text{Cov}(\mathbf{U}_j, \mathbf{U}_\ell) &= \mathbf{a}_j^\top \Sigma_{XX} \mathbf{a}_\ell \\ &= \mathbf{l}_j^\top \mathbf{l}_\ell. \end{aligned}$$

Logo,

$$\text{Cov}(\mathbf{U}_j, \mathbf{U}_\ell) = \begin{cases} 1, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (21.34)$$

Analogamente,

$$\text{Cov}(\mathbf{V}_j, \mathbf{V}_\ell) = \begin{cases} 1, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (21.35)$$

Para variáveis pertencentes a blocos diferentes,

$$\begin{aligned} \text{Cov}(\mathbf{U}_j, \mathbf{V}_\ell) &= \mathbf{l}_j^\top \mathbf{K}_{\text{CCA}} \mathbf{r}_\ell \\ &= \rho_\ell \mathbf{l}_j^\top \mathbf{l}_\ell. \end{aligned}$$

Consequentemente,

$$\text{Cov}(\mathbf{U}_j, \mathbf{V}_\ell) = \begin{cases} \rho_j, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (21.36)$$

Como todas as variáveis canônicas possuem variância unitária, essas covariâncias são também correlações.

Se

$$\mathbf{U} = \begin{pmatrix} \mathbf{U}_1 \\ \vdots \\ \mathbf{U}_m \end{pmatrix}$$

e

$$\mathbf{V} = \begin{pmatrix} \mathbf{V}_1 \\ \vdots \\ \mathbf{V}_m \end{pmatrix},$$

as relações anteriores podem ser reunidas como

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_m, \quad (21.37)$$

$$\text{Cov}(\mathbf{V}) = \mathbf{I}_m \quad (21.38)$$

e

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{D}_\rho. \quad (21.39)$$

A transformação canônica produz, portanto, pares ordenados de variáveis com variância unitária.

Dentro de cada bloco, variáveis canônicas pertencentes a dimensões distintas são não correlacionadas.

Entre os blocos, cada

$$U_j$$

possui correlação

$$\rho_j$$

com

$$V_j$$

e correlação zero com as demais variáveis canônicas do segundo conjunto.

Isso esclarece o significado de sucessão na CCA: cada novo par descreve uma dimensão adicional de associação linear que não repete as dimensões canônicas anteriores.

21.6.1 Número de correlações canônicas positivas

Como

$$\Sigma_{XX}^{-1/2}$$

e

$$\Sigma_{YY}^{-1/2}$$

são não singulares,

$$\text{posto}(\mathbf{K}_{\text{CCA}}) = \text{posto}(\Sigma_{XY}). \quad (21.40)$$

Defina

$$r_C = \text{posto}(\Sigma_{XY}).$$

Como

$$\Sigma_{XY} \in \mathbb{R}^{p \times q},$$

tem-se

$$r_C \leq \min(p, q) = m. \quad (21.41)$$

Pela relação entre posto e valores singulares, exatamente

$$r_C$$

correlações canônicas são positivas:

$$\rho_1 \geq \cdots \geq \rho_{r_C} > 0.$$

Se

$$r_C < m,$$

então

$$\rho_{r_C+1} = \cdots = \rho_m = 0.$$

Portanto, o número de dimensões com associação linear canônica positiva é determinado pelo posto da matriz de covariâncias cruzadas.

Se

$$\Sigma_{XY} = \mathbf{0},$$

então

$$r_C = 0$$

e

$$\rho_1 = \cdots = \rho_m = 0.$$

Nesse caso, não existe associação linear entre nenhuma combinação dos dois blocos.

No outro extremo, se

$$\rho_j = 1,$$

existem combinações lineares unitariamente padronizadas

$$U_j$$

e

$$V_j$$

com correlação perfeita.

Como ambas possuem variância 1, após escolha consistente do sinal,

$$\text{Var}(U_j - V_j) = 0.$$

Assim,

$$U_j = V_j$$

quase certamente, a menos de uma constante que é nula porque as variáveis canônicas foram construídas a partir de vetores centrados.

Uma correlação canônica igual a 1 representa, portanto, uma relação linear exata entre combinações não triviais dos dois blocos.

21.7 Formulação equivalente por autovalores

A SVD é a formulação mais direta da Correlação Canônica porque o problema original envolve simultaneamente dois vetores de coeficientes,

$$\mathbf{a} \quad \text{e} \quad \mathbf{b},$$

e uma matriz retangular,

$$\Sigma_{XY}.$$

Entretanto, a mesma solução pode ser expressa por problemas de autovalores.

Pela relação entre SVD e os espectros das matrizes de Gram estabelecida em Proposição 6.1, as matrizes

$$\mathbf{K}_{\text{CCA}} \mathbf{K}_{\text{CCA}}^{\top} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{K}_{\text{CCA}}^{\top} \mathbf{K}_{\text{CCA}} \in \mathbb{R}^{q \times q}$$

possuem os mesmos autovalores positivos, dados pelos quadrados dos valores singulares de $\mathbf{K}_{\text{CCA}}$.

Consequentemente,

$$\mathbf{K}_{\text{CCA}} \mathbf{K}_{\text{CCA}}^{\top} \mathbf{l}_j = \rho_j^2 \mathbf{l}_j \quad (21.42)$$

e

$$\mathbf{K}_{\text{CCA}}^{\top} \mathbf{K}_{\text{CCA}} \mathbf{r}_j = \rho_j^2 \mathbf{r}_j, \quad (21.43)$$

com autovalores positivos

$$\rho_1^2, \dots, \rho_{r_C}^2.$$

Substituindo Equação 21.18 no primeiro problema,

$$\Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX} \Sigma_{XX}^{-1/2} \mathbf{l}_j = \rho_j^2 \mathbf{l}_j.$$

Como

$$\mathbf{l}_j = \Sigma_{XX}^{1/2} \mathbf{a}_j,$$

multiplicar à esquerda por

$$\Sigma_{XX}^{1/2}$$

produz

$$\Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}\mathbf{a}_j = \rho_j^2\Sigma_{XX}\mathbf{a}_j. \quad (21.44)$$

Analogamente,

$$\Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY}\mathbf{b}_j = \rho_j^2\Sigma_{YY}\mathbf{b}_j. \quad (21.45)$$

Esses são problemas de autovalores generalizados do mesmo tipo definido em Definição 5.11.

No primeiro bloco, o par matricial é

$$(\Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}, \Sigma_{XX}),$$

com dimensões

$$p \times p.$$

No segundo bloco, o par é

$$(\Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY}, \Sigma_{YY}),$$

com dimensões

$$q \times q.$$

Os dois problemas possuem os mesmos autovalores **positivos**,

$$\rho_1^2, \dots, \rho_{r_C}^2.$$

Quando

$$p \neq q,$$

a matriz quadrada de maior dimensão pode possuir autovalores nulos adicionais que não correspondem a novos pares canônicos.

As equações Equação 21.44 e Equação 21.45 não representam duas soluções independentes.

Para cada

$$j = 1, \dots, m,$$

as relações singulares implicam

$$\Sigma_{XY}\mathbf{b}_j = \rho_j \Sigma_{XX}\mathbf{a}_j \quad (21.46)$$

e

$$\Sigma_{YX}\mathbf{a}_j = \rho_j \Sigma_{YY}\mathbf{b}_j. \quad (21.47)$$

Quando

$$\rho_j > 0,$$

a primeira relação fornece

$$\mathbf{a}_j = \frac{1}{\rho_j} \Sigma_{XX}^{-1} \Sigma_{XY} \mathbf{b}_j,$$

enquanto a segunda fornece

$$\mathbf{b}_j = \frac{1}{\rho_j} \Sigma_{YY}^{-1} \Sigma_{YX} \mathbf{a}_j.$$

Assim, em cada dimensão com correlação positiva, a direção de um bloco determina a direção correspondente do outro, respeitadas as normalizações e a convenção de sinal.

A formulação por autovalores conecta a Correlação Canônica aos problemas espectrais utilizados anteriormente em MANOVA e Análise Discriminante.

Há, entretanto, uma diferença estrutural importante.

Na MANOVA e na formulação de Fisher, o problema é introduzido diretamente como uma comparação entre duas formas quadráticas de um mesmo vetor.

Na Correlação Canônica, o ponto de partida é uma **maximização bilinear entre dois vetores pertencentes a blocos distintos**. O branqueamento transforma as restrições em normas euclidianas, a SVD resolve simultaneamente os dois lados do problema e somente depois a eliminação de um dos vetores produz os problemas de autovalores.

Por isso, os autovalores dessa formulação são

$$\rho_j^2,$$

isto é, os quadrados das correlações canônicas, enquanto os valores singulares de

$$\mathbf{K}_{\text{CCA}}$$

são diretamente

$$\rho_j.$$

Geometria da Correlação Canônica

A interpretação geométrica da Correlação Canônica deve acomodar dois blocos que podem possuir dimensões diferentes,

$$p \neq q.$$

Por isso, não é adequado identificar diretamente os espaços de coeficientes

$$\mathbb{R}^p \quad \text{e} \quad \mathbb{R}^q.$$

A geometria relevante pode ser construída no espaço das variáveis aleatórias centradas e quadrado-integráveis.

Considere

$$L_0^2 = \{A : E(A) = 0, E(A^2) < \infty\},$$

identificando variáveis aleatórias iguais quase certamente.

Nesse espaço, defina o produto interno

$$\langle A, B \rangle = E(AB) = \text{Cov}(A, B). \quad (21.48)$$

Como as variáveis são centradas,

$$\|A\|^2 = \langle A, A \rangle = \text{Var}(A).$$

Defina o subespaço gerado pelas combinações lineares centradas do primeiro bloco,

$$\mathcal{H}_X = \text{span} \{ \mathbf{X}_1 - E(\mathbf{X}_1), \dots, \mathbf{X}_p - E(\mathbf{X}_p) \} \subset L_0^2,$$

e, analogamente,

$$\mathcal{H}_Y = \text{span} \{ \mathbf{Y}_1 - E(\mathbf{Y}_1), \dots, \mathbf{Y}_q - E(\mathbf{Y}_q) \} \subset L_0^2.$$

Sob

$$\Sigma_{XX} \succ \mathbf{0},$$

nenhuma combinação linear não trivial das componentes centradas de

$$\mathbf{X}$$

possui variância zero. Portanto,

$$\dim(\mathcal{H}_X) = p.$$

Analogamente,

$$\Sigma_{YY} \succ \mathbf{0}$$

implica

$$\dim(\mathcal{H}_Y) = q.$$

Uma variável canônica

$$\mathbf{U} = \mathbf{a}^\top (\mathbf{X} - \mu_X)$$

pertence a

$$\mathcal{H}_X,$$

enquanto

$$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y)$$

pertence a

$$\mathcal{H}_Y.$$

Sob as normalizações

$$\text{Var}(\mathbf{U}) = \text{Var}(\mathbf{V}) = 1,$$

tem-se

$$\|\mathbf{U}\| = \|\mathbf{V}\| = 1$$

e

$$\text{Corr}(\mathbf{U}, \mathbf{V}) = \langle \mathbf{U}, \mathbf{V} \rangle .$$

Assim, o primeiro problema canônico pode ser escrito como

$$\rho_1 = \max_{\substack{\mathbf{U} \in \mathcal{H}_X, \|\mathbf{U}\|=1 \\ \mathbf{V} \in \mathcal{H}_Y, \|\mathbf{V}\|=1}} \langle \mathbf{U}, \mathbf{V} \rangle . \quad (21.49)$$

Essa é precisamente a caracterização do cosseno do menor ângulo principal entre os subespaços

$$\mathcal{H}_X \quad \text{e} \quad \mathcal{H}_Y.$$

Se

$$\theta_1 \in \left[0, \frac{\pi}{2}\right]$$

é o primeiro ângulo principal, então

$$\rho_1 = \cos \theta_1 . \quad (21.50)$$

21.7.1 O papel do branqueamento na geometria

A relação com a SVD torna-se particularmente clara quando os blocos são branqueados.

Considere

$$\mathbf{X}^* = \Sigma_{XX}^{-1/2} (\mathbf{X} - \mu_X)$$

e

$$\mathbf{Y}^* = \Sigma_{YY}^{-1/2} (\mathbf{Y} - \mu_Y).$$

Como

$$\text{Cov}(\mathbf{X}^*) = \mathbf{I}_p,$$

as componentes de

$$\mathbf{X}^*$$

formam um sistema ortonormal em

$$\mathcal{H}_X$$

segundo o produto interno de Equação [21.48](#).

De modo análogo, as componentes de

$$\mathbf{Y}^*$$

formam um sistema ortonormal em

$$\mathcal{H}_Y.$$

A matriz

$$\mathbf{K}_{\text{CCA}} = \text{Cov}(\mathbf{X}^*, \mathbf{Y}^*)$$

é, portanto, a matriz de produtos internos entre duas bases ortonormais desses subespaços.

Sua entrada

$$[\mathbf{K}_{\text{CCA}}]_{hk}$$

é o produto interno entre a componente branqueada h do primeiro bloco e a componente branqueada k do segundo.

A SVD de

$$\mathbf{K}_{\text{CCA}}$$

determina os ângulos principais entre

$$\mathcal{H}_X$$

e

$$\mathcal{H}_Y.$$

Se

$$m = \min(p, q),$$

existem m ângulos principais,

$$0 \leq \theta_1 \leq \theta_2 \leq \dots \leq \theta_m \leq \frac{\pi}{2},$$

e

$$\rho_j = \cos \theta_j, \quad j = 1, \dots, m. \quad (21.51)$$

Como o cosseno é decrescente em

$$\left[0, \frac{\pi}{2}\right],$$

a ordenação dos ângulos produz

$$\rho_1 \geq \rho_2 \geq \dots \geq \rho_m \geq 0.$$

Se

$$r_C = \text{posto}(\Sigma_{XY}),$$

então

$$\rho_j > 0, \quad j = 1, \dots, r_C,$$

e

$$\rho_j = 0, \quad j = r_C + 1, \dots, m,$$

quando

$$r_C < m.$$

Consequentemente,

$$\theta_j < \frac{\pi}{2}, \quad j \leq r_C,$$

enquanto as dimensões com correlação canônica nula satisfazem

$$\theta_j = \frac{\pi}{2}.$$

A interpretação é direta:

- ρ_j próximo de 1 corresponde a um pequeno ângulo principal;
- ρ_j próximo de 0 corresponde a direções próximas da ortogonalidade;
- $\rho_j = 0$ corresponde à ortogonalidade naquela dimensão canônica;
- $\rho_j = 1$ corresponde a ângulo principal igual a zero.

Quando

$$\rho_j = 1,$$

existe uma variável unitária pertencente simultaneamente aos dois subespaços.

Equivalentemente, existem combinações lineares centradas e não triviais dos dois blocos que, após escolha consistente do sinal, coincidem quase certamente.

A geometria fornece, assim, outra interpretação da CCA: a técnica procura sucessivamente as direções de maior alinhamento entre os subespaços lineares gerados pelos dois conjuntos de variáveis.

Essa interpretação é equivalente à formulação por SVD. O branqueamento constrói bases ortonormais em cada subespaço e a SVD da matriz de produtos internos entre essas bases fornece os cossenos dos ângulos principais.

21.8 Interpretação das variáveis canônicas

As correlações

$$\rho_1, \dots, \rho_m$$

quantificam a intensidade das associações lineares canônicas entre os dois blocos. A interpretação de cada dimensão exige distinguir os coeficientes que constroem as combinações, as cargas que relacionam as variáveis às combinações de seu próprio bloco e as cargas cruzadas que relacionam cada variável à combinação do outro bloco.

Considere o par j ,

$$U_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X)$$

e

$$V_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y),$$

normalizado de modo que

$$\text{Var}(U_j) = \text{Var}(V_j) = 1.$$

21.8.1 Coeficientes canônicos

Os elementos de

$$\mathbf{a}_j$$

e

$$\mathbf{b}_j$$

são os **coeficientes canônicos**.

Eles determinam diretamente como as variáveis de cada bloco são combinadas para produzir

$$\mathbf{U}_j \quad \text{e} \quad \mathbf{V}_j.$$

Esses coeficientes dependem da escala das variáveis e, principalmente, da estrutura de covariâncias existente dentro de cada bloco.

Quando variáveis de um mesmo conjunto são fortemente associadas, diferentes coeficientes podem compensar-se na construção de uma mesma combinação.

Por isso, a magnitude isolada de um coeficiente não deve ser interpretada como medida direta da associação da correspondente variável com a dimensão canônica.

21.8.2 Associação com a variável canônica do próprio bloco

Definição 21.3 (Cargas canônicas). Sejam

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos, médias

$$\mu_X = E(\mathbf{X}), \quad \mu_Y = E(\mathbf{Y}),$$

e matrizes de covariâncias

$$\Sigma_{XX} \succ \mathbf{0} \quad \text{e} \quad \Sigma_{YY} \succ \mathbf{0}.$$

Considere

$$\mathbf{a}_j \in \mathbb{R}^p, \quad \mathbf{b}_j \in \mathbb{R}^q,$$

e as variáveis canônicas

$$\mathbf{U}_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X),$$

$$\mathbf{V}_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y),$$

normalizadas de modo que

$$\text{Var}(\mathbf{U}_j) = \text{Var}(\mathbf{V}_j) = 1.$$

A **carga canônica** da variável $\mathbf{X}_h$ sobre $\mathbf{U}_j$ é

$$\ell_{hj}^{(X)} = \text{Corr}(\mathbf{X}_h, \mathbf{U}_j), \quad h = 1, \dots, p. \quad (21.52)$$

A carga canônica da variável $\mathbf{Y}_k$ sobre $\mathbf{V}_j$ é

$$\ell_{kj}^{(Y)} = \text{Corr}(\mathbf{Y}_k, \mathbf{V}_j), \quad k = 1, \dots, q. \quad (21.53)$$

Como

$$\text{Var}(\mathbf{U}_j) = 1,$$

tem-se

$$\text{Cov}(\mathbf{X}, \mathbf{U}_j) = \Sigma_{XX} \mathbf{a}_j.$$

Consequentemente,

$$\ell_{hj}^{(X)} = \frac{[\Sigma_{XX} \mathbf{a}_j]_h}{\sqrt{[\Sigma_{XX}]_{hh}}}. \quad (21.54)$$

De modo análogo,

$$\ell_{kj}^{(Y)} = \frac{[\Sigma_{YY}\mathbf{b}_j]_k}{\sqrt{[\Sigma_{YY}]_{kk}}}. \quad (21.55)$$

As cargas são correlações e, portanto,

$$-1 \leq \ell_{hj}^{(X)} \leq 1$$

e

$$-1 \leq \ell_{kj}^{(Y)} \leq 1.$$

Uma carga de grande magnitude indica forte associação linear entre a variável original e a variável canônica de seu próprio bloco.

A Tabela 21.2 sintetiza a diferença de interpretação entre coeficientes e cargas canônicas.

Tabela 21.2: Diferença entre coeficientes e cargas canônicas.

Quantidade	Interpretação
coeficiente canônico	participação da variável na construção da combinação linear
carga canônica	correlação da variável original com a combinação obtida

Um coeficiente numericamente pequeno não implica necessariamente carga pequena, e vice-versa, porque os coeficientes também dependem da estrutura de covariâncias dentro do bloco.

21.8.3 Associação com a variável canônica do outro bloco

Também é possível relacionar uma variável original à variável canônica construída no outro bloco.

Definição 21.4 (Cargas cruzadas). Sejam

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos e médias

$$\mu_X = E(\mathbf{X}), \quad \mu_Y = E(\mathbf{Y}).$$

Considere o par canônico

$$\mathbf{U}_j = \mathbf{a}_j^\top (\mathbf{X} - \mu_X), \quad \mathbf{V}_j = \mathbf{b}_j^\top (\mathbf{Y} - \mu_Y),$$

com

$$\text{Var}(\mathbf{U}_j) = \text{Var}(\mathbf{V}_j) = 1$$

e

$$\text{Corr}(\mathbf{U}_j, \mathbf{V}_j) = \rho_j.$$

Para

$$h = 1, \dots, p,$$

a **carga cruzada** da variável X_h sobre a variável canônica do segundo bloco é

$$\ell_{hj}^{(X,V)} = \text{Corr}(X_h, \mathbf{V}_j).$$

Para

$$k = 1, \dots, q,$$

a **carga cruzada** da variável Y_k sobre a variável canônica do primeiro bloco é

$$\ell_{kj}^{(Y,U)} = \text{Corr}(Y_k, \mathbf{U}_j).$$

A relação

$$\Sigma_{XY} \mathbf{b}_j = \rho_j \Sigma_{XX} \mathbf{a}_j$$

implica

$$\begin{aligned} \text{Cov}(\mathbf{X}, \mathbf{V}_j) &= \Sigma_{XY} \mathbf{b}_j \\ &= \rho_j \Sigma_{XX} \mathbf{a}_j. \end{aligned}$$

Como

$$\text{Var}(\mathbf{U}_j) = \text{Var}(\mathbf{V}_j) = 1,$$

segue que

$$\ell_{hj}^{(X,V)} = \rho_j \ell_{hj}^{(X)}. \quad (21.56)$$

Analogamente,

$$\ell_{kj}^{(Y,U)} = \rho_j \ell_{kj}^{(Y)}. \quad (21.57)$$

As cargas cruzadas combinam a associação da variável original com a dimensão canônica de seu próprio bloco e a intensidade da associação entre as duas variáveis canônicas, medida por ρ_j .

Assim, uma variável pode possuir carga canônica elevada e carga cruzada moderada quando

$$\rho_j$$

é moderado ou pequeno.

21.8.4 Associação bivariada e associação canônica

A Figura 21.1 ilustra por que a Correlação Canônica não se reduz ao exame das correlações cruzadas individuais.

No exemplo, cada variável dos dois blocos compartilha parte de duas fontes de variação. Nenhum par isolado concentra toda a associação disponível, enquanto as combinações canônicas podem reunir simultaneamente a informação distribuída entre várias variáveis.

O painel da esquerda utiliza o par de variáveis originais com maior correlação cruzada em módulo.

O painel da direita utiliza as combinações que maximizam a correlação entre os blocos.

O aumento da associação decorre da possibilidade de combinar informação distribuída entre várias variáveis.

A Correlação Canônica não cria uma associação ausente nos dados. Ela procura as combinações lineares em que a associação representada por

$$\Sigma_{XY}$$

se manifesta com maior intensidade relativamente às estruturas internas dos dois blocos.




Figura 21.1: Comparação entre a maior correlação cruzada individual e a primeira correlação canônica. As combinações lineares podem reunir uma associação distribuída entre várias variáveis dos dois blocos.

21.9 Variância extraída e redundância

A correlação canônica

$$\rho_j$$

mede a intensidade da associação entre

$$U_j \quad \text{e} \quad V_j.$$

Entretanto, ela não informa quanto cada variável canônica representa as variáveis originais de seu próprio bloco.

Para descrever esse segundo aspecto, podem ser utilizadas as cargas canônicas.

21.9.1 Variância extraída

Para o primeiro bloco, defina

$$VE_{X,j} = \frac{1}{p} \sum_{h=1}^p \left(\ell_{hj}^{(X)} \right)^2. \quad (21.58)$$

Para o segundo bloco,

$$VE_{Y,j} = \frac{1}{q} \sum_{k=1}^q \left(\ell_{kj}^{(Y)} \right)^2. \quad (21.59)$$

Como cada carga é uma correlação, seu quadrado representa a proporção da variância da correspondente variável padronizada associada linearmente à variável canônica considerada.

Assim,

$$VE_{X,j}$$

e

$$VE_{Y,j}$$

são médias dessas proporções dentro de cada bloco.

Essas quantidades não são determinadas apenas por

$$\rho_j.$$

Duas variáveis canônicas podem possuir correlação elevada entre si e, ainda assim, apresentar cargas pequenas em muitas das variáveis originais.

21.9.2 Índice de redundância

As cargas cruzadas permitem combinar a representação interna de um bloco com a associação canônica entre os blocos.

Como

$$\ell_{hj}^{(X,V)} = \rho_j \ell_{hj}^{(X)},$$

tem-se

$$\begin{aligned}\frac{1}{p} \sum_{h=1}^p \left(\ell_{hj}^{(X,V)} \right)^2 &= \frac{1}{p} \sum_{h=1}^p \rho_j^2 \left(\ell_{hj}^{(X)} \right)^2 \\ &= VE_{X,j} \rho_j^2.\end{aligned}$$

Define-se, portanto,

$$Red_{X|Y,j} = VE_{X,j} \rho_j^2. \quad (21.60)$$

Analogamente,

$$Red_{Y|X,j} = VE_{Y,j} \rho_j^2. \quad (21.61)$$

Os índices de redundância distinguem duas informações:

- $VE_{X,j}$ ou $VE_{Y,j}$ resume quanto a dimensão canônica representa, em média, as variáveis padronizadas do próprio bloco;
- ρ_j^2 incorpora quanto essa dimensão está linearmente associada à dimensão correspondente do outro bloco.

A redundância não deve ser interpretada como efeito causal nem como coeficiente geral de determinação entre os dois vetores aleatórios.

Ela é uma medida descritiva construída a partir das cargas e da correlação de um par canônico específico.

Uma correlação canônica elevada pode coexistir com redundância baixa se as duas combinações estiverem fortemente associadas entre si, mas representarem apenas uma parcela pequena das variáveis originais.

Neste capítulo, variância extraída e redundância são utilizadas apenas em nível conceitual. Critérios operacionais para julgar magnitudes, selecionar pares ou avaliar estabilidade serão tratados posteriormente.

21.9.3 Correlação canônica e ângulo

A interpretação de Equação 21.51 é ilustrada na Figura 21.2.

Depois que as estruturas internas dos dois blocos são incorporadas pelo branqueamento, as correlações canônicas podem ser interpretadas como cossenos de ângulos principais entre os subespaços gerados pelos dois conjuntos.

Cada painel representa, em um plano auxiliar, duas direções unitárias cujo produto interno é




Figura 21.2: Interpretação geométrica de uma correlação canônica como cosseno de um ângulo principal. Correlações maiores correspondem a direções mais alinhadas entre os dois subespaços.

$$\rho.$$

Como

$$\rho = \cos \theta,$$

correlações maiores correspondem a ângulos menores.

A figura é apenas uma representação bidimensional da relação angular. Os ângulos principais da CCA são definidos entre

$$\mathcal{H}_X \quad \text{e} \quad \mathcal{H}_Y$$

no espaço

$$L^2_0,$$

e não entre os espaços de coeficientes

$$\mathbb{R}^p \quad \text{e} \quad \mathbb{R}^q.$$

21.10 Formulação amostral

A solução populacional depende das matrizes

$$\Sigma_{XX}, \quad \Sigma_{XY}, \quad \Sigma_{YY}.$$

As matrizes de covariâncias amostrais foram definidas como estatísticas aleatórias em Definição 10.14, enquanto suas realizações observadas foram definidas em Definição 8.11.

Antes da observação dos dados,

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY}, \quad \mathbf{S}_{YY}$$

são estatísticas aleatórias utilizadas para estimar

$$\Sigma_{XX}, \quad \Sigma_{XY}, \quad \Sigma_{YY}.$$

Após a observação,

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY}, \quad \mathbf{S}_{YY}$$

são suas realizações.

Para uma amostra de

$$n \geq 2$$

unidades observadas simultaneamente nos dois blocos, organize os dados nas matrizes

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{Y} \in \mathbb{R}^{n \times q}.$$

Se

$$\mathbf{X}_c$$

e

$$\mathbf{Y}_c$$

denotam as matrizes centralizadas, então, pela definição de matriz de covariâncias observada,

$$\mathbf{S}_{XX} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{S}_{YY} = \frac{1}{n-1} \mathbf{Y}_c^\top \mathbf{Y}_c.$$

A covariância cruzada observada definida em Definição 8.13 é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c \in \mathbb{R}^{p \times q},$$

e sua contraparte como estatística aleatória foi definida em Definição 10.16. Sua contraparte como estatística aleatória,

$$\mathbf{S}_{XY},$$

foi definida em Definição 10.16.

Na formulação amostral clássica, suponha

$$\mathbf{S}_{XX} \succ \mathbf{0}$$

e

$$\mathbf{S}_{YY} \succ \mathbf{0}.$$

Define-se então

$$\widehat{\mathbf{K}}_{\text{CCA}} = \mathbf{S}_{XX}^{-1/2} \mathbf{S}_{XY} \mathbf{S}_{YY}^{-1/2} \in \mathbb{R}^{p \times q}. \quad (21.62)$$

Se

$$m = \min(p, q),$$

escreva a decomposição

$$\widehat{\mathbf{K}}_{\text{CCA}} = \widehat{\mathbf{L}}\widehat{\mathbf{D}}_{\rho}\widehat{\mathbf{R}}^{\top}, \quad (21.63)$$

em que

$$\widehat{\mathbf{L}} \in \mathbb{R}^{p \times m},$$

$$\widehat{\mathbf{R}} \in \mathbb{R}^{q \times m}$$

possuem colunas ortonormais e

$$\widehat{\mathbf{D}}_{\rho} = \text{diag}(\hat{\rho}_1, \dots, \hat{\rho}_m),$$

com

$$1 \geq \hat{\rho}_1 \geq \dots \geq \hat{\rho}_m \geq 0.$$

Os valores

$$\hat{\rho}_j$$

são as **correlações canônicas amostrais**.

Como as duas matrizes utilizadas no branqueamento são invertíveis,

$$\text{posto}(\widehat{\mathbf{K}}_{\text{CCA}}) = \text{posto}(\mathbf{S}_{XY}).$$

Defina

$$\hat{r}_C = \text{posto}(\mathbf{S}_{XY}).$$

Então exatamente

$$\hat{r}_C$$

correlações canônicas amostrais são positivas.

Os coeficientes canônicos amostrais são

$$\hat{\mathbf{a}}_j = \mathbf{S}_{XX}^{-1/2} \hat{\mathbf{l}}_j, \quad (21.64)$$

e

$$\hat{\mathbf{b}}_j = \mathbf{S}_{YY}^{-1/2} \hat{\mathbf{r}}_j, \quad (21.65)$$

para

$$j = 1, \dots, m.$$

Eles satisfazem

$$\hat{\mathbf{a}}_j^\top \mathbf{S}_{XX} \hat{\mathbf{a}}_\ell = \delta_{j\ell}$$

e

$$\hat{\mathbf{b}}_j^\top \mathbf{S}_{YY} \hat{\mathbf{b}}_\ell = \delta_{j\ell}.$$

Os escores canônicos observados são

$$\hat{\mathbf{u}}_j = \mathbf{X}_c \hat{\mathbf{a}}_j \in \mathbb{R}^n \quad (21.66)$$

e

$$\hat{\mathbf{v}}_j = \mathbf{Y}_c \hat{\mathbf{b}}_j \in \mathbb{R}^n. \quad (21.67)$$

Como

$$\mathbf{S}_{XX} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

tem-se

$$\frac{1}{n-1} \hat{\mathbf{u}}_j^\top \hat{\mathbf{u}}_\ell = \delta_{j\ell}.$$

Analogamente,

$$\frac{1}{n-1} \hat{\mathbf{v}}_j^\top \hat{\mathbf{v}}_\ell = \delta_{j\ell}.$$

Além disso,

$$\begin{aligned}\frac{1}{n-1}\hat{\mathbf{u}}_j^\top \hat{\mathbf{v}}_\ell &= \hat{\mathbf{a}}_j^\top \mathbf{S}_{XY} \hat{\mathbf{b}}_\ell \\ &= \hat{\rho}_j \delta_{j\ell}.\end{aligned}$$

Portanto, os escores do mesmo par possuem correlação amostral

$$\hat{\rho}_j,$$

enquanto escores pertencentes a pares canônicos distintos são não correlacionados segundo a estrutura construída pela solução.

21.10.1 População e amostra

A distinção entre os dois níveis deve ser mantida.

Na população, a técnica é determinada por

$$\Sigma_{XX}, \quad \Sigma_{XY}, \quad \Sigma_{YY},$$

e produz

$$\rho_j, \quad \mathbf{a}_j, \quad \mathbf{b}_j.$$

Na amostra observada, utilizam-se

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY}, \quad \mathbf{S}_{YY},$$

obtendo

$$\hat{\rho}_j, \quad \hat{\mathbf{a}}_j, \quad \hat{\mathbf{b}}_j.$$

Antes da observação dos dados, a aplicação da mesma construção às matrizes aleatórias

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY}, \quad \mathbf{S}_{YY}$$

produz estatísticas aleatórias.

Nesta seção,

$$\hat{\rho}_j, \quad \hat{\mathbf{a}}_j, \quad \hat{\mathbf{b}}_j$$

denotam suas realizações após a observação da amostra e são utilizadas como estimativas das estruturas canônicas populacionais, respeitadas as condições de identificação das raízes e dos subespaços canônicos.

A forma matemática da solução permanece a mesma: primeiro são consideradas as estruturas internas dos dois blocos, depois a covariância cruzada é expressa nas geometrias branqueadas e, finalmente, a SVD identifica as associações lineares máximas.

A existência dessas operações na população e na amostra, bem como a identificação das direções quando existem raízes repetidas, serão examinadas a seguir.

21.11 Invariância, existência e identificação

A formulação clássica da Correlação Canônica utiliza inversas e raízes quadradas inversas das matrizes de covariâncias intrabloco. Por isso, antes de interpretar coeficientes e correlações canônicas, é necessário distinguir três questões:

- quais mudanças de representação preservam a solução;
- quando a solução clássica existe;
- quais elementos da solução são identificados unicamente.

21.11.1 Invariância a transformações lineares não singulares

Uma propriedade estrutural importante da CCA é que as correlações canônicas não dependem da base utilizada para representar cada bloco, desde que a mudança de coordenadas seja invertível.

Considere transformações

$$\mathbf{X}^\dagger = \mathbf{P}\mathbf{X}$$

e

$$\mathbf{Y}^\dagger = \mathbf{Q}\mathbf{Y},$$

em que

$$\mathbf{P} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{Q} \in \mathbb{R}^{q \times q}.$$

Quando

$$\mathbf{P}$$

e

$$\mathbf{Q}$$

são não singulares, cada transformação apenas fornece uma nova base para o mesmo espaço de combinações lineares do respectivo bloco.

Proposição 21.1 (Invariância das correlações canônicas). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos e matrizes de covariâncias

$$\Sigma_{XX} \succ \mathbf{0} \quad e \quad \Sigma_{YY} \succ \mathbf{0}.$$

Considere matrizes não singulares

$$\mathbf{P} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{Q} \in \mathbb{R}^{q \times q},$$

e defina

$$\mathbf{X}^\dagger = \mathbf{P}\mathbf{X}, \quad \mathbf{Y}^\dagger = \mathbf{Q}\mathbf{Y}.$$

Então

$$(\mathbf{X}, \mathbf{Y})$$

e

$$(\mathbf{X}^\dagger, \mathbf{Y}^\dagger)$$

possuem as mesmas correlações canônicas, incluindo suas multiplicidades.

Comprovação. Como

$$E(\mathbf{X}^\dagger) = \mathbf{P}\mu_X,$$

as combinações lineares centradas do bloco transformado são

$$\mathbf{a}_\dagger^\top (\mathbf{X}^\dagger - E(\mathbf{X}^\dagger)) = \mathbf{a}_\dagger^\top \mathbf{P} (\mathbf{X} - \mu_X).$$

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

escolha

$$\mathbf{a}_\dagger = \mathbf{P}^{-\top} \mathbf{a}.$$

Então

$$\mathbf{a}_\dagger^\top (\mathbf{X}^\dagger - E(\mathbf{X}^\dagger)) = \mathbf{a}^\top (\mathbf{X} - \mu_X).$$

Como

$$\mathbf{P}$$

é não singular, a correspondência

$$\mathbf{a} \longleftrightarrow \mathbf{a}_\dagger$$

é bijetiva. Portanto, o conjunto de todas as combinações lineares centradas possíveis do primeiro bloco é preservado.

Analogamente, com

$$\mathbf{b}_{\dagger} = \mathbf{Q}^{-\top} \mathbf{b},$$

tem-se

$$\mathbf{b}_{\dagger}^{\top} (\mathbf{Y}^{\dagger} - E(\mathbf{Y}^{\dagger})) = \mathbf{b}^{\top} (\mathbf{Y} - \mu_Y).$$

Assim, os dois problemas possuem exatamente os mesmos pares possíveis de variáveis lineares centradas. Consequentemente, os máximos sucessivos de suas correlações são iguais. $\square$

A invariância inclui, como casos particulares:

- mudanças de unidades;
- reescalamentos por constantes não nulas;
- rotações;
- mudanças invertíveis de base dentro de cada bloco.

Além disso, adicionar constantes às variáveis não altera a CCA, porque as combinações são construídas a partir dos vetores centralizados.

Portanto, padronizar as variáveis por desvios-padrão positivos não altera as correlações canônicas.

O que se modifica são os coeficientes utilizados para expressar as mesmas combinações na nova base.

Se

$$\mathbf{a}_j$$

é um vetor de coeficientes no sistema original, então o vetor correspondente no sistema transformado é

$$\mathbf{a}_j^{\dagger} = \mathbf{P}^{-\top} \mathbf{a}_j. \quad (21.68)$$

Analogamente,

$$\mathbf{b}_j^{\dagger} = \mathbf{Q}^{-\top} \mathbf{b}_j. \quad (21.69)$$

Por isso, as correlações canônicas descrevem a associação entre os **espaços lineares gerados pelos blocos**, enquanto os coeficientes dependem das coordenadas utilizadas para representar esses espaços.

Essa distinção também explica por que coeficientes canônicos obtidos em escalas diferentes não devem ser comparados diretamente como medidas absolutas de importância.

21.12 Existência da solução clássica

Na população, a construção por branqueamento exige

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0}.$$

Essas condições garantem a existência de

$$\Sigma_{XX}^{-1}, \quad \Sigma_{YY}^{-1},$$

e de

$$\Sigma_{XX}^{-1/2}, \quad \Sigma_{YY}^{-1/2}.$$

Se existir

$$\mathbf{a} \neq \mathbf{0}$$

tal que

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 0,$$

então a combinação

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

possui variância zero e o primeiro bloco contém uma dependência linear populacional exata.

Nesse caso,

$$\Sigma_{XX}$$

é singular.

O mesmo argumento vale para

$$\Sigma_{YY}.$$

A formulação clássica apresentada neste capítulo pressupõe que essas redundâncias exatas não estejam presentes na representação adotada.

21.12.1 Existência na amostra

21.12.2 Existência na amostra

O limite de posto da matriz de covariâncias observada foi estabelecido em Equação 8.63. Aplicando-o separadamente aos dois blocos,

$$\text{posto}(\mathbf{S}_{XX}) \leq \min(p, n - 1)$$

e

$$\text{posto}(\mathbf{S}_{YY}) \leq \min(q, n - 1).$$

Consequentemente,

$$n - 1 \geq p$$

e

$$n - 1 \geq q \tag{21.70}$$

são condições necessárias para que

$$\mathbf{S}_{XX}$$

e

$$\mathbf{S}_{YY}$$

possam possuir posto completo.

Essas condições não são suficientes para um conjunto de dados arbitrário.

Mesmo quando

$$n - 1 \geq p \quad \text{e} \quad n - 1 \geq q,$$

relações lineares exatas entre as variáveis de um bloco podem tornar sua matriz de covariâncias singular.

Quando

$$p > n - 1$$

ou

$$q > n - 1,$$

a singularidade é inevitável e a formulação clássica baseada nas inversas das matrizes amostrais não pode ser utilizada diretamente.

Pseudoinversas, regularização e versões da CCA destinadas a situações de alta dimensão constituem formulações adicionais e não serão desenvolvidas neste capítulo.

21.12.3 Dimensão conjunta e correlações amostrais iguais a um

A invertibilidade separada de

$$\mathbf{S}_{XX}$$

e

$$\mathbf{S}_{YY}$$

não elimina todos os problemas associados à alta dimensão.

As colunas de

$$\mathbf{X}_c$$

e

$$\mathbf{Y}_c$$

pertencem ao subespaço

$$\mathcal{H}_n = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\},$$

cuja dimensão é

$$n - 1.$$

Suponha que

$$\mathbf{S}_{XX}$$

e

$$\mathbf{S}_{YY}$$

tenham posto completo. Então

$$\dim [\text{Col}(\mathbf{X}_c)] = p$$

e

$$\dim [\text{Col}(\mathbf{Y}_c)] = q.$$

Como ambos são subespaços de

$$\mathcal{H}_n,$$

a fórmula da dimensão da soma fornece

$$\begin{aligned} & \dim [\text{Col}(\mathbf{X}_c) \cap \text{Col}(\mathbf{Y}_c)] \\ &= p + q - \dim [\text{Col}(\mathbf{X}_c) + \text{Col}(\mathbf{Y}_c)] \\ &\geq p + q - (n - 1). \end{aligned} \tag{21.71}$$

Assim, se

$$p + q > n - 1, \quad (21.72)$$

a interseção é necessariamente não trivial.

Existe, portanto,

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{z} = \mathbf{X}_c \mathbf{a} = \mathbf{Y}_c \mathbf{b}$$

para determinados vetores não nulos

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q.$$

As duas combinações amostrais são idênticas e, portanto, possuem correlação igual a

$$1.$$

Mais precisamente, sob as hipóteses anteriores, existem pelo menos

$$p + q - (n - 1)$$

dimensões comuns sempre que essa quantidade é positiva. Consequentemente, a solução amostral pode conter várias correlações canônicas exatamente iguais a 1.

Esse resultado é importante porque mostra que uma correlação canônica amostral perfeita pode ser consequência da própria relação entre dimensão e tamanho amostral, e não necessariamente evidência de uma relação populacional perfeita entre os blocos.

A existência algébrica de uma solução não garante, portanto, que sua estimação seja informativa ou estável.

21.12.4 Multicolinearidade e condicionamento

Mesmo quando

$$\mathbf{S}_{XX}$$

e

$$\mathbf{S}_{YY}$$

são formalmente positivas definidas, autovalores muito pequenos tornam

$$\mathbf{S}_{XX}^{-1/2}$$

ou

$$\mathbf{S}_{YY}^{-1/2}$$

sensíveis a pequenas perturbações nos dados.

Essa sensibilidade pode afetar:

- os coeficientes canônicos;
- os subespaços estimados;
- as correlações canônicas, especialmente quando a separação entre valores singulares é pequena.

Não existe garantia geral de que as combinações canônicas permaneçam estáveis quando as matrizes intrablocos são mal condicionadas.

O problema é particularmente importante porque a CCA utiliza simultaneamente:

$$\mathbf{S}_{XX}^{-1/2}, \quad \mathbf{S}_{XY} \quad \text{e} \quad \mathbf{S}_{YY}^{-1/2}.$$

Assim, instabilidade dentro de qualquer um dos dois blocos pode propagar-se para a matriz

$$\widehat{\mathbf{K}}_{CCA}.$$

Diagnósticos de condicionamento, regularização e versões esparsas ou penalizadas pertencem à etapa metodológica posterior.

21.13 Identificação das direções canônicas

As correlações canônicas são os valores singulares de

$$\mathbf{K}_{\text{CCA}}.$$

Por isso, sua identificação segue as propriedades da SVD desenvolvidas no Módulo 1.

21.13.1 Correlação canônica simples

Suponha que

$$\rho_j > 0$$

seja um valor singular simples.

O par de vetores singulares

$$(\mathbf{l}_j, \mathbf{r}_j)$$

é determinado até uma mudança simultânea de sinal:

$$(\mathbf{l}_j, \mathbf{r}_j)$$

e

$$(-\mathbf{l}_j, -\mathbf{r}_j)$$

satisfazem as mesmas relações singulares.

Consequentemente,

$$(\mathbf{a}_j, \mathbf{b}_j)$$

e

$$(-\mathbf{a}_j, -\mathbf{b}_j)$$

produzem

$$(\mathbf{U}_j, \mathbf{V}_j)$$

e

$$(-\mathbf{U}_j, -\mathbf{V}_j).$$

A correlação permanece

$$\rho_j.$$

Portanto, a orientação dos eixos canônicos não possui significado intrínseco.

Uma convenção de sinal pode ser adotada para facilitar a apresentação, mas não altera a solução matemática.

21.13.2 Correlações repetidas

Suponha que uma correlação canônica positiva

$$\rho$$

possua multiplicidade

$$d > 1.$$

Os vetores singulares individuais associados não são únicos. Se

$$\mathbf{L}_\rho \in \mathbb{R}^{p \times d}$$

e

$$\mathbf{R}_\rho \in \mathbb{R}^{q \times d}$$

são bases ortonormais dos subespaços singulares correspondentes, então, para qualquer matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{d \times d},$$

as bases

$$\mathbf{L}_\rho \mathbf{Q}$$

e

$$\mathbf{R}_\rho \mathbf{Q}$$

produzem outra representação válida do mesmo bloco canônico.

A rotação é coordenada nos dois lados porque

$$\mathbf{K}_{\text{CCA}} \mathbf{R}_\rho = \rho \mathbf{L}_\rho.$$

Assim, os objetos identificados são:

- o subespaço canônico do primeiro bloco;
- o subespaço canônico correspondente do segundo bloco;
- a correlação canônica comum ρ .

Os eixos individuais escolhidos dentro desses subespaços dependem da base adotada e não possuem identificação própria.

Essa distinção é particularmente importante para interpretar:

- coeficientes;
- cargas;
- cargas cruzadas;

associados individualmente a dimensões com correlações repetidas.

21.13.3 Correlações nulas

Quando

$$\rho_j = 0,$$

as relações

$$\mathbf{K}_{\text{CCA}} \mathbf{r}_j = \mathbf{0}$$

e

$$\mathbf{K}_{\text{CCA}}^{\top} \mathbf{l}_j = \mathbf{0}$$

não determinam uma associação positiva entre um par particular de direções.

Os subespaços associados ao valor singular zero podem possuir alta dimensão e suas bases não são, em geral, únicas.

Por isso, a interpretação substantiva concentra-se normalmente nas dimensões associadas às correlações positivas.

21.13.4 População e amostra

A mesma questão aparece na estimação.

Quando

$$\rho_j$$

é positiva, simples e separada das demais correlações canônicas, existe uma correspondência natural entre a dimensão populacional e a correspondente dimensão amostral, a menos das convenções de sinal.

Quando valores populacionais são repetidos ou muito próximos, coeficientes amostrais individuais podem variar consideravelmente mesmo que o subespaço estimado permaneça próximo do subespaço populacional.

Portanto, a interpretação de coeficientes individuais exige considerar a identificação espectral da solução.

21.14 Pressupostos e limites

A Correlação Canônica pode ser formulada a partir de momentos de segunda ordem. Suas condições algébricas devem ser distinguidas das hipóteses necessárias à inferência clássica.

21.14.1 Existência de segundos momentos

Para definir

$$\Sigma_{XX}, \quad \Sigma_{XY} \quad \text{e} \quad \Sigma_{YY},$$

é suficiente assumir, por exemplo,

$$E(\|\mathbf{X}\|^2) < \infty$$

e

$$E(\|\mathbf{Y}\|^2) < \infty.$$

A técnica descreve associação **linear** entre os blocos por meio dessas covariâncias.

Relações não lineares que não produzam estrutura de covariância cruzada podem não ser detectadas.

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

significa ausência de associação linear entre todas as combinações dos dois blocos, mas não implica independência em geral.

21.14.2 Não singularidade dentro dos blocos

A formulação clássica por branqueamento exige

$$\Sigma_{XX} \succ \mathbf{0}$$

e

$$\Sigma_{YY} \succ \mathbf{0}.$$

Na amostra, exige-se analogamente

$$\mathbf{S}_{XX} \succ \mathbf{0}$$

e

$$\mathbf{S}_{YY} \succ \mathbf{0}.$$

Essas são condições algébricas para as inversas e raízes quadradas inversas utilizadas na solução clássica.

Elas não decorrem da normalidade.

21.14.3 Normalidade multivariada

A normalidade conjunta de

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix}$$

não é necessária para definir:

$$\rho_j, \quad \mathbf{a}_j, \quad \mathbf{b}_j,$$

nem para obter a solução pela SVD das matrizes de covariâncias populacionais.

A normalidade acrescenta propriedades probabilísticas.

Em particular, sob normalidade conjunta,

$$\Sigma_{XY} = \mathbf{0}$$

é equivalente à independência dos blocos, conforme Equação 21.4.

Além disso, a normalidade sustenta a teoria inferencial clássica para hipóteses sobre as correlações canônicas e sobre a independência entre os conjuntos.

Essas distribuições de referência e suas transformações não serão desenvolvidas neste capítulo.

21.14.4 Unidades observacionais

A formulação amostral usual pressupõe que as linhas de

$$\mathbf{X}$$

e

$$\mathbf{Y}$$

correspondam às mesmas unidades e que o pareamento entre os dois blocos seja preservado.

A covariância cruzada

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c$$

depende dessa correspondência.

Permutar as unidades de um bloco independentemente do outro altera, em geral,

$$\mathbf{S}_{XY}$$

e destrói a estrutura de associação que a técnica pretende representar.

Para interpretar as matrizes amostrais como estimadores de uma única estrutura populacional e desenvolver a inferência clássica, considera-se usualmente que os pares

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

formam uma amostra de unidades independentes e identicamente distribuídas da distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

Dependências temporais, espaciais, longitudinais ou hierárquicas requerem estrutura probabilística adicional.

21.14.5 Dimensão amostral e sensibilidade

Na amostra, a existência da solução clássica depende do posto das matrizes intrablocos. Como as matrizes centralizadas possuem posto não superior a $n - 1$, as condições

$$n - 1 \geq p$$

e

$$n - 1 \geq q$$

são necessárias para que

$$\mathbf{S}_{XX}$$

e

$$\mathbf{S}_{YY}$$

possam possuir posto completo.

Essa condição não elimina o fenômeno de correlações canônicas amostrais iguais a 1. Quando

$$p + q > n - 1,$$

os espaços coluna dos dois blocos centralizados apresentam interseção não trivial, podendo surgir correlações perfeitas por razões geométricas associadas à dimensão amostral.

Devem ser distinguidas, portanto, a dimensão de cada bloco, que controla a possibilidade de inversão das matrizes intrablocos, e a dimensão conjunta dos subespaços amostrais, que pode produzir interseções e correlações iguais a 1. A solução clássica pode existir algebricamente e ainda apresentar comportamento degenerado em amostras de alta dimensão.

Como a CCA depende de médias e covariâncias, observações influentes podem modificar

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY} \quad \text{e} \quad \mathbf{S}_{YY},$$

alterando correlações, coeficientes, cargas e subespaços canônicos estimados. Diagnósticos, análise de sensibilidade e procedimentos robustos serão tratados posteriormente.

21.14.6 Interpretação associativa

A CCA é simétrica em relação aos dois blocos. Uma correlação canônica elevada indica forte associação linear entre determinadas combinações dos conjuntos, mas não determina direção causal, dependência funcional ou efeito de um bloco sobre o outro.

Essas interpretações dependem do delineamento e do contexto científico, e não da maximização canônica isoladamente.

21.15 Relações com outras técnicas

21.15.1 Análise de Componentes Principais

ACP e Correlação Canônica constroem combinações lineares, mas resolvem problemas diferentes.

Na ACP, para um único vetor aleatório com matriz de covariâncias

$$\Sigma,$$

a primeira direção resolve

$$\max_{\mathbf{a}^\top \mathbf{a} = 1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

O objetivo é maximizar variância.

Na CCA, duas direções são escolhidas simultaneamente para maximizar

$$\text{Corr} \left[\mathbf{a}^\top (\mathbf{X} - \mu_X), \mathbf{b}^\top (\mathbf{Y} - \mu_Y) \right].$$

A comparação é resumida na Tabela 21.3.

Tabela 21.3: Diferenças estruturais entre ACP e Correlação Canônica.

Aspecto	ACP	Correlação Canônica
número de blocos	um	dois
função objetivo	variância	correlação entre combinações
estrutura principal	covariância interna	covariâncias internas e cruzada
transformação central	decomposição espectral	branqueamento dos dois blocos

Aspecto	ACP	Correlação Canônica
decomposição natural	autovalores ou SVD	SVD da covariância cruzada branqueada
resultado	componentes	pares canônicos

Uma direção de grande variância em um bloco não precisa ser a direção que apresenta maior associação com o outro bloco.

A CCA privilegia associação **entre** conjuntos, e não variabilidade interna isoladamente.

21.15.2 Regressão e regressão multivariada

Regressão e Correlação Canônica utilizam estruturas de covariância entre conjuntos, mas diferem quanto ao papel atribuído aos blocos.

Na regressão multivariada, um bloco é definido como resposta e o outro como conjunto de preditores.

A relação é, portanto, direcional no modelo:

$$E(\mathbf{Y} \mid \mathbf{X})$$

é modelada em função de

$$\mathbf{X}.$$

Na Correlação Canônica, os dois blocos são tratados simetricamente. O problema consiste em encontrar simultaneamente uma combinação de cada lado com máxima correlação.

Um caso particular estabelece uma conexão direta.

Suponha

$$q = 1,$$

de modo que o segundo bloco contém apenas uma variável escalar

$$Y$$

com variância

$$\sigma_Y^2 > 0.$$

Então existe uma única correlação canônica potencialmente positiva e

$$\rho_1^2 = \frac{\Sigma_{YX} \Sigma_{XX}^{-1} \Sigma_{XY}}{\sigma_Y^2}. \quad (21.73)$$

A quantidade do lado direito é o coeficiente de determinação populacional da projeção linear de

$\mathbf{Y}$

sobre o espaço gerado pelas componentes de

$\mathbf{X}$.

Assim, a correlação múltipla é um caso particular da Correlação Canônica quando um dos blocos possui dimensão 1.

A conexão não elimina a diferença conceitual: regressão formula uma relação de resposta condicionada a preditores, enquanto CCA formula associação simétrica entre espaços lineares.

21.15.3 MANOVA

A relação com MANOVA aparece quando um dos blocos representa adequadamente o espaço de um efeito e o outro contém as respostas quantitativas.

No capítulo de MANOVA, as raízes características

$$\lambda_j$$

foram transformadas por

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j},$$

conforme Equação [19.22](#).

Em uma representação canônica do mesmo efeito — por exemplo, utilizando uma codificação apropriada do espaço de contrastes associado aos grupos e, quando necessário, considerando o ajuste pelos demais termos do modelo — as correlações canônicas correspondentes satisfazem

$$\rho_j^2 = \frac{\lambda_j}{1 + \lambda_j}. \quad (21.74)$$

A qualificação da representação é importante.

A relação não afirma que qualquer bloco arbitrário de indicadores produz automaticamente as raízes da MANOVA. Os dois problemas precisam representar o mesmo subespaço de efeito e a mesma estrutura residual.

Quando essa correspondência é estabelecida, a transformação mostra que:

- λ_j mede hipótese relativamente ao erro na formulação da MANOVA;
- ρ_j^2 mede o alinhamento canônico correspondente entre o espaço das respostas e o espaço associado ao efeito.

A mesma estrutura espectral recebe, portanto, interpretações diferentes segundo o problema estatístico formulado.

21.15.4 Análise Discriminante

A relação com a Análise Discriminante aparece de forma semelhante.

Considere um bloco quantitativo

X

e um segundo bloco que represente adequadamente a informação de grupos por indicadores ou contrastes.

A associação canônica entre esses blocos depende da parcela da variabilidade de

X

associada às diferenças entre os grupos.

Na formulação de Fisher, essa mesma estrutura aparece na comparação entre

T_{entre}

e

T_{intra}.

Sob codificação e ponderação apropriadas, os subespaços canônico e discriminante estão relacionados.

A Tabela 21.4 sintetiza os diferentes objetivos associados a essa estrutura compartilhada.

Tabela 21.4: Diferentes interpretações de uma estrutura espectral compartilhada.

Técnica	Uso da estrutura compartilhada
MANOVA	testar uma hipótese multivariada sobre diferenças entre grupos
Fisher	construir direções que maximizam separação relativa
Correlação Canônica	medir associação entre o bloco quantitativo e o espaço que representa os grupos

Essa relação foi antecipada no capítulo de Análise Discriminante e mostra por que técnicas aparentemente diferentes podem produzir subespaços relacionados quando são construídas a partir das mesmas estruturas de covariância.

21.16 Síntese

A Correlação Canônica estuda a associação linear entre dois vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \qquad \text{e} \qquad \mathbf{Y} \in \mathbb{R}^q$$

observados sobre as mesmas unidades. Sua estrutura de segunda ordem é representada por

$$\Sigma = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix},$$

em que os blocos diagonais descrevem as covariâncias internas dos conjuntos e

$$\Sigma_{XY}$$

representa sua associação linear cruzada.

A técnica procura combinações

$$\mathbf{U} = \mathbf{a}^\top \left(\mathbf{X} - \mu_X \right)$$

e

$$\mathbf{V} = \mathbf{b}^\top (\mathbf{Y} - \mu_Y)$$

que maximizem

$$\text{Corr}(\mathbf{U}, \mathbf{V}).$$

As restrições

$$\mathbf{a}^\top \Sigma_{XX} \mathbf{a} = 1$$

e

$$\mathbf{b}^\top \Sigma_{YY} \mathbf{b} = 1$$

fixam as variâncias das combinações e transformam o problema em uma maximização bilinear.

O branqueamento das estruturas intrabloco produz

$$\mathbf{K}_{CCA} = \Sigma_{XX}^{-1/2} \Sigma_{XY} \Sigma_{YY}^{-1/2}.$$

A SVD

$$\mathbf{K}_{CCA} = \mathbf{L} \mathbf{D}_\rho \mathbf{R}^\top$$

fornece diretamente as correlações canônicas

$$\rho_1 \geq \dots \geq \rho_m \geq 0, \quad m = \min(p, q),$$

e os coeficientes podem ser recuperados por

$$\mathbf{a}_j = \Sigma_{XX}^{-1/2} \mathbf{l}_j, \quad \mathbf{b}_j = \Sigma_{YY}^{-1/2} \mathbf{r}_j.$$

O número de correlações canônicas positivas é determinado por

$$\text{posto}(\Sigma_{XY}).$$

A mesma solução pode ser expressa pelos problemas de autovalores generalizados

$$\Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}\mathbf{a}_j = \rho_j^2\Sigma_{XX}\mathbf{a}_j$$

e

$$\Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY}\mathbf{b}_j = \rho_j^2\Sigma_{YY}\mathbf{b}_j.$$

Os valores singulares da matriz branqueada são ρ_j , enquanto os autovalores das formulações generalizadas são ρ_j^2 .

Geometricamente, as correlações canônicas são os cossenos dos ângulos principais entre os subespaços lineares gerados pelos dois blocos:

$$\rho_j = \cos \theta_j.$$

Assim, a CCA procura sucessivamente as direções de maior alinhamento entre esses subespaços depois de remover a geometria interna de cada conjunto.

A interpretação exige distinguir coeficientes, cargas, cargas cruzadas e redundância. Os coeficientes constroem as combinações; as cargas relacionam as variáveis originais às combinações de seu próprio bloco; as cargas cruzadas relacionam variáveis às combinações do bloco oposto; e a redundância combina a representação interna de um bloco com a associação canônica entre os conjuntos.

Na amostra, as matrizes populacionais são substituídas por

$$\mathbf{S}_{XX}, \quad \mathbf{S}_{XY}, \quad \mathbf{S}_{YY},$$

produzindo correlações, coeficientes e subespaços canônicos amostrais. A formulação clássica exige posto suficiente para que as matrizes intrabloco sejam invertíveis. A dimensão conjunta também importa: quando

$$p + q > n - 1,$$

podem surgir correlações canônicas amostrais iguais a 1 por interseção dos subespaços centralizados.

A normalidade conjunta não é necessária para definir a CCA. Ela sustenta parte da inferência clássica e, nesse modelo, permite relacionar

$$\Sigma_{XY} = \mathbf{0}$$

à independência entre os blocos.

As correlações canônicas são invariantes a transformações lineares não singulares realizadas separadamente dentro de cada bloco, embora os coeficientes dependam da base escolhida. Correlações positivas simples identificam os pares de direções até mudança simultânea de sinal; multiplicidades identificam subespaços canônicos, e não bases particulares.

A CCA integra covariância cruzada, formas bilineares, mudanças de base, raízes quadradas de matrizes positivas definidas, branqueamento, SVD, autovalores generalizados, posto e geometria de subespaços. Sua forma matemática decorre diretamente do problema de maximizar a associação entre duas combinações lineares depois de normalizada a variabilidade interna dos dois blocos.

No próximo capítulo, a estrutura deixa de relacionar dois blocos de variáveis. A Análise Conjunta representará alternativas por atributos e níveis e formulará a preferência por meio de uma função de utilidade e de uma matriz de delineamento.

22 Formulação da Análise Conjunta

A Análise Conjunta relaciona avaliações, preferências ou escolhas às características que descrevem alternativas. Cada alternativa é representada por uma combinação de **atributos** e **níveis**, e o objetivo é decompor a preferência global em contribuições associadas a essas características (Green; Rao, 1971; Green; Srinivasan, 1978).

Na formulação aditiva clássica, essa decomposição é representada por uma função de utilidade cuja parte sistemática reúne contribuições dos atributos e de seus níveis (Green; Rao, 1971; Luce; Tukey, 1964). A representação dos perfis por uma matriz de delineamento conecta o problema aos fundamentos de codificação, posto, identificação, estimabilidade e modelo linear desenvolvidos nos Módulos 1 e 2.

A forma da resposta observada pode variar entre avaliações quantitativas, respostas ordinais, ordenações, comparações e escolhas. O mecanismo estatístico que relaciona a utilidade à observação deve ser compatível com essa forma de resposta.

O capítulo desenvolve a representação dos perfis, o modelo aditivo de utilidade, as parametrizações dos níveis, a identificação, o delineamento e a estimação conceitual das preferências. Procedimentos de construção de delineamentos ótimos, algoritmos específicos, modelos de escolha em detalhe, validação e aplicações serão tratados posteriormente.

A estrutura da técnica é resumida na Tabela 22.1.

Tabela 22.1: Elementos da formulação da Análise Conjunta.

Elemento	Representação	Papel
atributo	A_j	dimensão utilizada para descrever a alternativa
níveis do atributo	$\mathcal{L}_j$	valores ou categorias admitidos pelo atributo
alternativa ou perfil	$\mathbf{x}_i$	combinação específica dos níveis dos atributos
utilidade parcial	$u_j(x_{ij})$	contribuição associada ao nível do atributo j
utilidade sistemática	V_i	combinação das contribuições previstas pelo modelo
resposta	depende da forma de coleta	informação observada sobre preferência

Elemento	Representação	Papel
delineamento	$\mathbf{Z}$	representação matricial dos níveis presentes nos perfis
parâmetros	β	coeficientes associados à parametrização escolhida
resultado estrutural	utilidades e contrastes	decomposição das preferências segundo atributos e níveis

A diferença em relação às técnicas anteriores é, portanto, estrutural. ACP, Correspondência e Correlação Canônica utilizam decomposições matriciais para encontrar direções. MANOVA e Análise Discriminante utilizam matrizes de dispersão e problemas de autovalores generalizados. Na Análise Conjunta, a estrutura principal é um **modelo de preferência construído a partir da representação dos perfis em uma matriz de delineamento**.

22.1 O problema da decomposição de preferências

Considere os atributos

$$A_1, \dots, A_m.$$

Cada atributo A_j possui um conjunto de níveis

$$\mathcal{L}_j = \{\ell_{j1}, \dots, \ell_{jL_j}\}.$$

Definição 22.1 (Atributos e níveis). Considere

$$m \geq 1.$$

Para cada

$$j = 1, \dots, m,$$

um **atributo**

$$A_j$$

é uma característica utilizada para diferenciar as alternativas.

O conjunto

$$\mathcal{L}_j = \{\ell_{j1}, \dots, \ell_{jL_j}\}, \quad L_j \geq 2,$$

é o conjunto de **níveis** do atributo A_j .

Cada nível

$$\ell_{j\ell} \in \mathcal{L}_j$$

representa um dos valores ou categorias admitidos para esse atributo na construção das alternativas.

Atributo e nível desempenham papéis diferentes.

O atributo define **qual característica varia** entre as alternativas. Os níveis definem **quais valores dessa característica são considerados no estudo**.

A Tabela 22.2 apresenta um exemplo abstrato de atributos e níveis utilizados na formação de perfis.

Tabela 22.2: Exemplo abstrato de atributos e níveis na formação de perfis.

Atributo	Níveis possíveis
A_1 : tipo	nível 1, nível 2
A_2 : tamanho	pequeno, médio, grande
A_3 : preço	baixo, intermediário, alto

Uma alternativa corresponde a uma escolha simultânea de um nível de cada atributo.

Definição 22.2 (Perfil). Considere

$$m \geq 1$$

atributos com conjuntos de níveis

$$\mathcal{L}_1, \dots, \mathcal{L}_m.$$

Um **perfil** é um elemento

$$\mathbf{x}_i = (x_{i1}, \dots, x_{im})^\top \in \mathcal{L}_1 \times \dots \times \mathcal{L}_m, \quad (22.1)$$

em que

$$x_{ij} \in \mathcal{L}_j$$

especifica o nível do atributo j presente no perfil i .

Por exemplo,

$$\mathbf{x}_i = (\text{nível 2, médio, baixo})^\top$$

representa uma alternativa específica formada pela combinação de três níveis.

Se todos os perfis possíveis forem considerados, o número total de combinações é

$$N_{\text{perf}} = \prod_{j=1}^m L_j. \quad (22.2)$$

O crescimento é multiplicativo. Por isso, mesmo um número moderado de atributos pode produzir um conjunto de alternativas muito grande.

Essa característica terá uma consequência importante posteriormente: **a construção dos perfis determina a informação disponível para separar os efeitos dos atributos.**

Antes disso, é necessário distinguir dois objetos:

- **o perfil apresentado**, determinado pelos níveis dos atributos;
- **a resposta ao perfil**, que contém informação sobre a preferência.

O perfil constitui a estrutura explicativa da alternativa. A resposta é a informação observada utilizada para relacionar essa estrutura à preferência.

22.2 Preferência e utilidade

Preferência e utilidade não são sinônimos.

A preferência estabelece uma relação entre alternativas. A utilidade fornece uma representação numérica dessa relação.

Considere dois perfis,

$$\mathbf{x}_i \quad \text{e} \quad \mathbf{x}_h.$$

Se

$$\mathbf{x}_i$$

é preferido a

$$\mathbf{x}_h,$$

uma representação de utilidade orientada no sentido de maior preferência satisfaz

$$U(\mathbf{x}_i) > U(\mathbf{x}_h).$$

Definição 22.3 (Utilidade). Considere

$$m \geq 1$$

atributos com conjuntos de níveis

$$\mathcal{L}_1, \dots, \mathcal{L}_m$$

e o conjunto de perfis

$$\mathcal{X} = \mathcal{L}_1 \times \dots \times \mathcal{L}_m.$$

Denote por

$$\succsim$$

uma relação de preferência sobre

$$\mathcal{X}$$

que admita representação numérica.

Uma **função de utilidade** que representa essa preferência é uma função

$$U : \mathcal{X} \longrightarrow \mathbb{R}$$

tal que, para quaisquer

$$\mathbf{x}_i, \mathbf{x}_h \in \mathcal{X},$$

$$\mathbf{x}_i \succeq \mathbf{x}_h \iff U(\mathbf{x}_i) \geq U(\mathbf{x}_h).$$

Segundo a orientação adotada neste capítulo, valores maiores de

$$U(\mathbf{x})$$

representam maior preferência pelo perfil $\mathbf{x}$.

Essa formulação distingue explicitamente a **relação de preferência** da função numérica utilizada para representá-la.

A utilidade permite substituir comparações entre alternativas por comparações entre valores numéricos.

Entretanto, seu valor deve ser interpretado relativamente à representação utilizada.

Uma afirmação como

$$U(\mathbf{x}_i) = 8$$

não possui, isoladamente, significado absoluto.

São especialmente relevantes comparações como

$$U(\mathbf{x}_i) - U(\mathbf{x}_h).$$

A forma exata da indeterminação de localização ou escala depende do tipo de resposta e do modelo utilizado.

Em avaliações quantitativas, a escala observada fornece uma referência distinta daquela existente em respostas puramente ordinais.

Em modelos probabilísticos de escolha, diferenças de utilidade e a escala do componente aleatório desempenham outro papel.

Essas situações serão separadas posteriormente.

22.3 Utilidades parciais

A Análise Conjunta procura representar a utilidade de um perfil por componentes associados aos atributos.

Para cada atributo j , considere uma função definida sobre seus níveis.

Definição 22.4 (Utilidade parcial). Considere um atributo

$$A_j$$

com conjunto de níveis

$$\mathcal{L}_j.$$

Uma **função de utilidade parcial** para esse atributo é uma função

$$u_j : \mathcal{L}_j \longrightarrow \mathbb{R}.$$

Para um nível

$$x_{ij} \in \mathcal{L}_j,$$

a quantidade

$$u_j(x_{ij})$$

representa a contribuição associada a esse nível na estrutura de utilidade considerada.

Essa definição torna explícito que a utilidade parcial não é inicialmente um coeficiente de regressão.

Ela é uma **função sobre os níveis do atributo**.

Os coeficientes aparecerão posteriormente quando essas funções forem representadas por uma determinada codificação matricial.

A comparação entre níveis de um mesmo atributo é especialmente importante.

Para

$$a, b \in \mathcal{L}_j,$$

a diferença

$$u_j(a) - u_j(b) \tag{22.3}$$

representa a diferença de contribuição associada à substituição do nível b pelo nível a , segundo a estrutura de utilidade adotada.

A utilidade parcial também é relativa ao problema estudado. Sua interpretação depende:

- dos níveis incluídos no atributo;
- dos demais atributos considerados;
- da forma adotada para representar a utilidade;
- posteriormente, da parametrização utilizada.

Essa dependência ficará especialmente clara quando diferentes codificações produzirem coeficientes distintos para as mesmas utilidades ou contrastes ajustados.

22.4 Modelo aditivo de utilidade

A formulação clássica supõe que a parte sistemática da utilidade de um perfil possa ser representada pela soma das contribuições dos atributos.

Definição 22.5 (Modelo aditivo de utilidade). Considere

$$m \geq 1$$

atributos com conjuntos de níveis

$$\mathcal{L}_1, \dots, \mathcal{L}_m,$$

um perfil

$$\mathbf{x}_i = (x_{i1}, \dots, x_{im})^\top \in \mathcal{L}_1 \times \dots \times \mathcal{L}_m,$$

funções de utilidade parcial

$$u_j : \mathcal{L}_j \longrightarrow \mathbb{R}, \quad j = 1, \dots, m,$$

e uma constante

$$\beta_0 \in \mathbb{R}.$$

O modelo aditivo de utilidade sistemática é

$$V_i = V(\mathbf{x}_i) = \beta_0 + \sum_{j=1}^m u_j(x_{ij}). \quad (22.4)$$

A quantidade

$$V_i$$

representa a parcela sistemática da utilidade que o modelo associa às características do perfil.

A constante

$$\beta_0$$

estabelece um nível de referência comum à representação, enquanto

$$u_j(x_{ij})$$

representa a contribuição atribuída ao nível observado no atributo j .

A forma aditiva não é uma consequência puramente algébrica. Ela é uma **hipótese estrutural sobre a representação da preferência**.

Sua base está na ideia de separabilidade: a contribuição de cada atributo pode ser representada por uma função própria e essas contribuições podem ser somadas (Luce; Tukey, 1964).

22.4.1 Resposta quantitativa e utilidade sistemática

A utilidade sistemática não deve ser confundida com a resposta observada.

Considere inicialmente uma situação em que o participante fornece uma resposta quantitativa para cada perfil.

Para o perfil i , represente a resposta aleatória por

$$Y_i.$$

Uma formulação estatística inicial é

$$Y_i = V_i + \varepsilon_i,$$

ou, utilizando Equação 22.4,

$$Y_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}) + \varepsilon_i. \quad (22.5)$$

Nessa expressão,

$$\varepsilon_i$$

representa a parcela aleatória da resposta que não é representada pela estrutura sistemática incluída no modelo.

Após observar a resposta, sua realização será denotada por

$$y_i.$$

Essa distinção antecipa a separação já utilizada no Módulo 2 entre:

- variável aleatória;
- parâmetro;
- estimador;
- realização observada.

A equação Equação 22.5 ainda não exige uma distribuição normal para

$$\varepsilon_i.$$

Aditividade da utilidade e normalidade dos erros são hipóteses de naturezas diferentes.

A primeira define a forma da parte sistemática do modelo. A segunda, quando adotada, pertence a uma especificação probabilística particular e pode ser necessária para determinados resultados inferenciais.

Neste capítulo, a normalidade não será tratada como pressuposto geral da Análise Conjunta.

A conexão com o modelo linear surgirá quando as funções

$$u_j(\cdot)$$

forem representadas numericamente por meio de uma codificação dos níveis.

22.5 Aditividade

A hipótese de aditividade significa que a contribuição sistemática total é obtida pela soma das contribuições dos atributos.

Considere, para simplificar, dois atributos

$$A \quad \text{e} \quad B.$$

Para níveis

$$a \in \mathcal{L}_A \quad \text{e} \quad b \in \mathcal{L}_B,$$

o modelo aditivo possui a forma

$$V(a, b) = \beta_0 + u_A(a) + u_B(b). \quad (22.6)$$

Considere agora outro nível

$$a' \in \mathcal{L}_A.$$

A diferença provocada pela substituição de a por a' é

$$V(a', b) - V(a, b) = u_A(a') - u_A(a). \quad (22.7)$$

O lado direito não depende de

b .

Portanto, dentro da estrutura aditiva, a diferença associada à mudança de nível em um atributo não se modifica segundo o nível assumido pelo outro atributo.

Essa propriedade caracteriza a ausência de interação na formulação básica.

22.6 Compensação entre atributos

A estrutura aditiva também permite que diferenças de contribuição em atributos distintos se compensem.

Considere dois perfis,

$$\mathbf{x}_i \quad \text{e} \quad \mathbf{x}_h.$$

Pelo modelo aditivo,

$$\begin{aligned} V_i - V_h &= \left[\beta_0 + \sum_{j=1}^m u_j(x_{ij}) \right] - \left[\beta_0 + \sum_{j=1}^m u_j(x_{hj}) \right] \\ &= \sum_{j=1}^m [u_j(x_{ij}) - u_j(x_{hj})]. \end{aligned} \quad (22.8)$$

Uma alternativa pode apresentar contribuição menor em um atributo e contribuição maior em outro.

A comparação global depende da soma das diferenças.

Essa propriedade é denominada **compensação**: uma redução relativa de utilidade associada a determinada característica pode ser compensada por ganhos associados a outras.

A compensação é uma consequência da estrutura aditiva.

Ela não deve ser assumida automaticamente quando o problema substantivo contém:

- requisitos obrigatórios;
- limiares;
- restrições;

- características não compensatórias.

Nesses casos, a forma aditiva pode não representar adequadamente a estrutura de preferência.

22.7 Interações entre atributos

A hipótese aditiva também pode ser insuficiente quando a contribuição associada a um atributo depende do nível assumido por outro.

Para dois atributos, uma extensão é

$$V(a, b) = \beta_0 + u_A(a) + u_B(b) + u_{AB}(a, b), \quad (22.9)$$

em que

$$u_{AB} : \mathcal{L}_A \times \mathcal{L}_B \longrightarrow \mathbb{R}$$

representa uma contribuição específica da combinação dos níveis

$$(a, b).$$

Nesse caso,

$$\begin{aligned} V(a', b) - V(a, b) &= u_A(a') - u_A(a) \\ &\quad + u_{AB}(a', b) - u_{AB}(a, b). \end{aligned}$$

A diferença pode agora depender de

$$b.$$

Assim, com interação, a contribuição associada a uma mudança de nível em um atributo não pode ser descrita inteiramente sem considerar os níveis dos atributos com os quais ele interage.

A Figura 22.1 ilustra essa diferença. No modelo aditivo, a diferença entre os níveis do primeiro atributo permanece constante para os diferentes níveis do segundo. Com interação, essa diferença se modifica.

No painel aditivo, a mudança de A_1 para A_2 produz a mesma diferença de utilidade para B_1 e B_2 .




Figura 22.1: Aditividade e interação entre dois atributos. Linhas paralelas representam um efeito do atributo A que não depende do nível de B; linhas não paralelas indicam interação.

No painel com interação, o efeito de alterar o nível de A depende do nível de B .

A inclusão de interações aumenta a complexidade da representação. Mais contribuições precisam ser associadas às combinações de níveis e, posteriormente, mais parâmetros precisam ser representados na matriz de delineamento.

Consequentemente, o conjunto de perfis precisa fornecer informação suficiente para distinguir os efeitos que o modelo pretende representar.

Essa observação prepara a próxima etapa da formulação: transformar atributos e níveis em uma **representação matricial**.

As funções

$$u_j : \mathcal{L}_j \longrightarrow \mathbb{R}$$

ainda descrevem contribuições conceituais dos níveis. Para estimá-las a partir dos dados, será necessário escolher uma codificação e construir uma matriz

Z

cujas colunas representem os parâmetros ou contrastes correspondentes.

É nessa passagem que os fundamentos de **transformações, dependência linear, espaço coluna, núcleo, posto e identificação** dos Módulos 1 e 2 passam a determinar diretamente quais utilidades e contrastes podem ser estimados.

22.8 Da utilidade à representação matricial

O modelo em Equação 22.5 ainda está escrito em termos das funções

$$u_j(x_{ij}).$$

Para estimar essas contribuições a partir das respostas observadas, os níveis dos atributos precisam ser representados numericamente.

Essa passagem não altera o problema substantivo. O perfil continua sendo uma combinação de níveis,

$$\mathbf{x}_i = (x_{i1}, \dots, x_{im})^\top,$$

mas cada nível passa a ser associado a um vetor numérico utilizado na construção do modelo.

A representação será organizada na **matriz de delineamento**

$$\mathbf{Z}.$$

Cada linha de

$$\mathbf{Z}$$

representará um perfil segundo uma codificação previamente escolhida, enquanto suas colunas representarão os termos que o modelo pretende distinguir.

Depois dessa codificação, a utilidade sistemática poderá ser escrita como

$$V_i = \mathbf{z}_i^\top \beta,$$

conectando a Análise Conjunta diretamente aos fundamentos de:

- matriz de delineamento;
- espaço coluna;

- espaço linha;
- núcleo;
- posto;
- parametrização;
- identificação;
- funções estimáveis;

desenvolvidos nos Módulos 1 e 2.

A particularidade da técnica está na origem substantiva desses objetos: as colunas de

Z

são construídas a partir dos atributos, níveis e efeitos que se deseja representar.

22.9 Codificação dos níveis

Considere o atributo

A_j

com conjunto de níveis

$\mathcal{L}_j$.

Uma codificação associa a cada nível desse atributo um vetor numérico.

Definição 22.6 (Codificação de um atributo). Considere um atributo

A_j

com conjunto de níveis

$$\mathcal{L}_j = \{\ell_{j1}, \dots, \ell_{jL_j}\}.$$

Uma **codificação** do atributo A_j é uma função

$$c_j : \mathcal{L}_j \longrightarrow \mathbb{R}^{d_j}, \quad (22.10)$$

em que

$$d_j \geq 1$$

é o número de coordenadas utilizadas para representar os níveis desse atributo na parametrização considerada.

Assim, se o perfil i apresenta o nível

$$x_{ij} \in \mathcal{L}_j,$$

esse nível é representado por

$$c_j(x_{ij}) \in \mathbb{R}^{d_j}.$$

A codificação transforma, portanto, a informação categórica do perfil em coordenadas numéricas que podem ocupar colunas de uma matriz de delineamento.

Em um modelo aditivo contendo apenas efeitos principais e intercepto, a linha correspondente ao perfil i pode ser escrita como

$$\mathbf{z}_i^\top = (1 \quad c_1(x_{i1})^\top \quad \cdots \quad c_m(x_{im})^\top). \quad (22.11)$$

Se

$$d_j$$

coordenadas são utilizadas para o atributo j , então

$$\mathbf{z}_i \in \mathbb{R}^d,$$

com

$$d = 1 + \sum_{j=1}^m d_j. \quad (22.12)$$

O primeiro termo corresponde ao intercepto.

Os demais são determinados pelas codificações escolhidas.

A codificação não é um detalhe computacional. Ela determina o significado dos coeficientes contidos em

$$\beta.$$

Diferentes codificações podem representar o mesmo conjunto de utilidades sistemáticas utilizando parâmetros numericamente diferentes.

Essa distinção será central para compreender identificação.

22.10 Representação matricial do modelo

Considere

$$N \geq 1$$

avaliações quantitativas correspondentes a perfis

$$\mathbf{x}_1, \dots, \mathbf{x}_N.$$

Para cada perfil, seja

$$\mathbf{z}_i^\top \in \mathbb{R}^{1 \times d}$$

a linha construída a partir de sua codificação.

Reunindo as N linhas,

$$\mathbf{Z} = \begin{pmatrix} \mathbf{z}_1^\top \\ \vdots \\ \mathbf{z}_N^\top \end{pmatrix} \in \mathbb{R}^{N \times d}. \quad (22.13)$$

As dimensões possuem interpretações distintas:

- N é o número de avaliações representadas;
- d é o número de coeficientes da parametrização utilizada.

O vetor

$$\beta \in \mathbb{R}^d$$

reúne o intercepto e os coeficientes associados à codificação dos efeitos incluídos no modelo.

A utilidade sistemática do perfil i é

$$V_i = \mathbf{z}_i^\top \beta.$$

Reunindo todos os perfis,

$$\mathbf{V} = \mathbf{Z}\beta, \quad (22.14)$$

em que

$$\mathbf{V} = \begin{pmatrix} V_1 \\ \vdots \\ V_N \end{pmatrix} \in \mathbb{R}^N.$$

Para respostas quantitativas, defina o vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_N \end{pmatrix} \in \mathbb{R}^N$$

e o vetor aleatório de erros

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_N \end{pmatrix} \in \mathbb{R}^N.$$

O modelo torna-se

$$\mathbf{Y} = \mathbf{Z}\beta + \varepsilon. \quad (22.15)$$

Após a observação das respostas, obtém-se a realização

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix} \in \mathbb{R}^N.$$

A equação Equação 22.15 é a especialização, para uma única resposta, do modelo linear definido em Definição 11.3.

A Análise Conjunta não exige uma nova teoria de mínimos quadrados.

Sua especificidade está em responder:

- como os perfis dão origem às linhas de $\mathbf{Z}$;
- como atributos e níveis dão origem às colunas de $\mathbf{Z}$;
- quais parâmetros podem ser identificados;
- como os coeficientes são interpretados como contrastes ou contribuições de utilidade.

É importante não identificar automaticamente cada componente de

$$\beta$$

com uma utilidade parcial absoluta.

O significado de cada coeficiente depende da codificação utilizada.

22.11 Categoria de referência

Considere um atributo

$$A_j$$

com

$$L_j$$

níveis.

Uma forma de produzir uma parametrização identificada consiste em escolher um dos níveis como categoria de referência.

Nesse caso, são utilizadas

$$L_j - 1$$

colunas.

Suponha, por exemplo, que o atributo A possua três níveis,

$$A_1, \quad A_2, \quad A_3,$$

e que

$$A_1$$

seja escolhido como referência.

Defina

$$z_{A2} = \begin{cases} 1, & A = A_2, \\ 0, & \text{caso contrário,} \end{cases}$$

e

$$z_{A3} = \begin{cases} 1, & A = A_3, \\ 0, & \text{caso contrário.} \end{cases}$$

A codificação é, portanto,

$$c_A(A_1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

$$c_A(A_2) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

e

$$c_A(A_3) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

A contribuição parametrizada desse atributo é

$$\beta_{A2}z_{A2} + \beta_{A3}z_{A3}.$$

O nível

$$A_1$$

não possui coeficiente próprio nessa representação.

Sua contribuição é incorporada à origem definida pelo intercepto e pelas categorias de referência escolhidas para os atributos.

A mudança para uma codificação por referência também reparametriza o intercepto. Se

$$\ell_{j0}$$

é o nível de referência do atributo j , então, partindo de uma representação aditiva arbitrária,

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}),$$

o intercepto da parametrização por referência incorpora as contribuições dos níveis omitidos:

$$\beta_0^{(\text{ref})} = \beta_0 + \sum_{j=1}^m u_j(\ell_{j0}).$$

Os coeficientes associados aos níveis não omitidos passam a representar diferenças em relação às respectivas referências. Para simplificar a notação, o intercepto reparametrizado continuará sendo denotado por

$$\beta_0$$

nas expressões seguintes.

Nessa parametrização,

$$\beta_{A2} = u_A(A_2) - u_A(A_1) \tag{22.16}$$

e

$$\beta_{A3} = u_A(A_3) - u_A(A_1). \tag{22.17}$$

Os coeficientes são, portanto, **contrastes em relação ao nível de referência**.

Considere agora dois atributos:

- A , com níveis A_1, A_2, A_3 ;
- B , com níveis B_1, B_2 .

Utilizando

$$A_1 \quad \text{e} \quad B_1$$

como referências, a matriz de delineamento de todos os seis perfis pode ser representada pela Tabela 22.3.

Tabela 22.3: Exemplo de codificação por categoria de referência para dois atributos.

Perfil	A	B	intercepto	z_{A2}	z_{A3}	z_{B2}
1	A_1	B_1	1	0	0	0
2	A_1	B_2	1	0	0	1
3	A_2	B_1	1	1	0	0
4	A_2	B_2	1	1	0	1
5	A_3	B_1	1	0	1	0
6	A_3	B_2	1	0	1	1

O modelo correspondente é

$$V_i = \beta_0 + \beta_{A2}z_{i,A2} + \beta_{A3}z_{i,A3} + \beta_{B2}z_{i,B2}. \quad (22.18)$$

Para o perfil

$$(A_1, B_1),$$

todas as colunas indicadoras são iguais a zero e

$$V(A_1, B_1) = \beta_0.$$

Para

$$(A_2, B_1),$$

tem-se

$$V(A_2, B_1) = \beta_0 + \beta_{A2}.$$

Portanto,

$$V(A_2, B_1) - V(A_1, B_1) = \beta_{A2}.$$

A interpretação do coeficiente está diretamente vinculada à categoria escolhida como referência.

Se outra categoria fosse utilizada, os coeficientes mudariam, embora as diferenças ajustadas entre os mesmos perfis pudessem permanecer iguais.

22.12 Codificação por efeitos

Outra possibilidade consiste em representar os níveis de cada atributo por contrastes associados a uma restrição de soma zero.

A Tabela 22.4 apresenta uma possível codificação por efeitos para um atributo com três níveis.

Tabela 22.4: Exemplo de codificação por efeitos para um atributo com três níveis.

Nível	z_1	z_2
A_1	1	0
A_2	0	1
A_3	-1	-1

Nesse caso,

$$c_A(A_1) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad c_A(A_2) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad c_A(A_3) = \begin{pmatrix} -1 \\ -1 \end{pmatrix}.$$

A contribuição parametrizada do atributo é

$$\beta_{A1}z_1 + \beta_{A2}z_2.$$

As utilidades parciais são representadas por

$$u_A(A_1) = \beta_{A1},$$

$$u_A(A_2) = \beta_{A2}$$

e

$$u_A(A_3) = -\beta_{A1} - \beta_{A2}. \quad (22.19)$$

Consequentemente,

$$u_A(A_1) + u_A(A_2) + u_A(A_3) = 0. \quad (22.20)$$

A restrição de soma zero estabelece uma origem para a representação das utilidades parciais do atributo.

O nível representado por

$$(-1, -1)$$

não possui utilidade zero.

Sua utilidade é recuperada a partir dos demais parâmetros por Equação 22.19.

Assim:

- na codificação por referência, os coeficientes são diferenças em relação a um nível escolhido;
- na codificação por efeitos, as contribuições são expressas relativamente a uma restrição de soma zero.

As duas parametrizações podem representar o mesmo conjunto de utilidades sistemáticas, embora seus coeficientes tenham significados e valores numéricos diferentes.

22.13 Por que a identificação é necessária

A necessidade de uma codificação identificada pode ser vista diretamente pela estrutura da matriz de delineamento.

Suponha que um atributo possua

$$L_j$$

níveis e que sejam incluídas simultaneamente:

- uma coluna de intercepto;
- uma coluna indicadora para cada um dos L_j níveis.

Para cada perfil, exatamente uma das indicadoras do atributo é igual a 1.

Logo,

$$\mathbf{1}_N = \mathbf{z}_{j1} + \cdots + \mathbf{z}_{jL_j}, \quad (22.21)$$

em que

$$\mathbf{z}_{j\ell} \in \mathbb{R}^N$$

é a coluna indicadora correspondente ao nível ℓ do atributo j .

A coluna do intercepto é, portanto, combinação linear das colunas indicadoras.

Consequentemente,

$$\text{posto}(\mathbf{Z}) < d.$$

Existe então um vetor

$$\mathbf{d} \neq \mathbf{0}$$

tal que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Ou seja,

$$\mathbf{d} \in \mathcal{N}(\mathbf{Z}).$$

Para qualquer vetor de parâmetros

$$\beta,$$

tem-se

$$\begin{aligned} \mathbf{Z}(\beta + \mathbf{d}) &= \mathbf{Z}\beta + \mathbf{Z}\mathbf{d} \\ &= \mathbf{Z}\beta. \end{aligned} \quad (22.22)$$

Portanto,

$$\beta$$

e

$$\beta + \mathbf{d}$$

produzem exatamente o mesmo vetor de utilidades sistemáticas.

O problema não é a inexistência de uma representação dos perfis.

O problema é que **mais de um vetor de coeficientes representa a mesma estrutura sistemática**.

22.14 Identificação do modelo

A identificação pode ser formulada diretamente como uma propriedade da aplicação linear determinada pela matriz de delineamento.

Definição 22.7 (Identificação na Análise Conjunta). Considere

$$\mathbf{Z} \in \mathbb{R}^{N \times d}$$

e um espaço paramétrico

$$\Theta \subseteq \mathbb{R}^d.$$

A parametrização é **identificada em** Θ quando a aplicação

$$\beta \mapsto \mathbf{Z}\beta$$

é injetiva em Θ .

Equivalentemente, para quaisquer

$$\beta_1, \beta_2 \in \Theta,$$

a igualdade

$$\mathbf{Z}\beta_1 = \mathbf{Z}\beta_2$$

implica

$$\beta_1 = \beta_2.$$

Quando

$$\Theta = \mathbb{R}^d,$$

a parametrização é identificada se, e somente se,

$$\mathcal{N}(\mathbf{Z}) = \{\mathbf{0}\}.$$

Como

$$\mathbf{Z} \in \mathbb{R}^{N \times d},$$

o Teorema Posto–Nulidade de Teorema 3.5 mostra que essa condição equivale a

$$\text{posto}(\mathbf{Z}) = d.$$

Essa definição distingue dois casos.

22.14.1 Parametrização irrestrita

Se

$$\Theta = \mathbb{R}^d,$$

a identificação exige posto coluna completo.

22.14.2 Parametrização restrita

Se são impostas restrições, como

$$\sum_{\ell=1}^{L_j} u_j(\ell) = 0,$$

o espaço paramétrico deixa de ser todo

$$\mathbb{R}^d.$$

Nesse caso, não é necessário que uma representação redundante seja injetiva sobre todo o espaço original; é necessário que ela seja injetiva **sobre o espaço que satisfaz as restrições de identificação**.

Essa distinção é importante porque categoria de referência e soma zero resolvem a mesma indeterminação por caminhos diferentes.

A relação Equação 22.22 é a versão vetorial, para uma resposta, da equivalência de matrizes de parâmetros definida em Definição 11.15 e Equação 11.113 no modelo linear multivariado.

A pseudoinversa de Moore–Penrose, definida em Definição 6.11, permite selecionar uma solução de mínimos quadrados mesmo quando

$$\mathbf{Z}$$

possui posto deficiente.

Entretanto, Proposição 11.11 estabelece que, nesse caso, os coeficientes podem permanecer não únicos mesmo quando os valores ajustados são únicos. Portanto, a pseudoinversa não transforma uma parametrização não identificada em identificada.

A identificação decorre da estrutura do espaço paramétrico e do delineamento, e não do algoritmo utilizado para calcular uma solução.

22.15 Restrições de identificação

Duas estratégias básicas permitem remover a redundância provocada pela inclusão simultânea do intercepto e de todas as indicadoras.

22.15.1 Eliminação de uma categoria

Na codificação por referência, uma categoria de cada atributo é omitida.

Para um modelo aditivo contendo apenas intercepto e efeitos principais, são utilizados

$$L_j - 1$$

coeficientes para o atributo j .

Assim,

$$d = 1 + \sum_{j=1}^m (L_j - 1). \quad (22.23)$$

O primeiro termo corresponde ao intercepto.

Cada atributo acrescenta exatamente o número de graus de liberdade necessário para representar diferenças entre seus níveis.

22.15.2 Restrição de soma zero

Outra possibilidade é representar as utilidades dos níveis impondo

$$\sum_{\ell=1}^{L_j} u_j(\ell) = 0. \quad (22.24)$$

Essa restrição remove uma dimensão de indeterminação.

Embora existam

$$L_j$$

valores de utilidade parcial associados aos níveis, apenas

$$L_j - 1$$

podem variar livremente.

Portanto, nas duas estratégias, o atributo possui

$$L_j - 1$$

graus de liberdade.

A parametrização determina **como esses graus de liberdade são expressos**, não quantos existem.

Esse ponto impede uma interpretação equivocada: eliminar uma categoria não significa afirmar que a contribuição substantiva desse nível seja nula.

Da mesma forma, impor soma zero não significa que as utilidades tenham uma origem natural em zero.

Ambas são convenções utilizadas para identificar a representação.

22.16 Equivalência entre parametrizações

Diferentes codificações podem produzir matrizes de delineamento distintas sem alterar o espaço de utilidades sistemáticas que o modelo consegue representar.

Considere

$$\mathbf{Z}_1 \in \mathbb{R}^{N \times d_1}$$

e

$$\mathbf{Z}_2 \in \mathbb{R}^{N \times d_2},$$

correspondentes a duas parametrizações dos mesmos efeitos.

Se

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \tag{22.25}$$

então as duas matrizes representam o mesmo conjunto de vetores possíveis de utilidade sistemática.

Para qualquer

$\mathbf{v}$

pertencente a esse espaço, podem existir vetores

$$\beta_1 \quad \text{e} \quad \beta_2$$

tais que

$$\mathbf{V} = \mathbf{Z}_1\beta_1 = \mathbf{Z}_2\beta_2. \quad (22.26)$$

Os vetores

$$\beta_1$$

e

$$\beta_2$$

não precisam:

- possuir a mesma dimensão;
- possuir os mesmos valores;
- atribuir o mesmo significado aos seus componentes.

O que permanece igual é a estrutura sistemática representada no espaço dos perfis.

Esse resultado aplica à Análise Conjunta a ideia geral de que o modelo depende do espaço coluna de

$$\mathbf{Z},$$

e não de uma base particular utilizada para representá-lo.

Consequentemente,

coeficientes de uma codificação não são, por si só, objetos invariantes da preferência.

O significado substantivo deve ser procurado em quantidades preservadas entre parametrizações equivalentes, como:

- utilidades sistemáticas dos perfis;
- diferenças entre perfis;
- contrastes entre níveis que sejam estimáveis.

22.17 Diferenças de utilidade e funções estimáveis

Considere dois perfis com vetores de delineamento

$$\mathbf{z}_i \quad \text{e} \quad \mathbf{z}_h.$$

Suas utilidades sistemáticas são

$$V_i = \mathbf{z}_i^\top \boldsymbol{\beta}$$

e

$$V_h = \mathbf{z}_h^\top \boldsymbol{\beta}.$$

A diferença é

$$\begin{aligned} V_i - V_h &= \mathbf{z}_i^\top \boldsymbol{\beta} - \mathbf{z}_h^\top \boldsymbol{\beta} \\ &= (\mathbf{z}_i - \mathbf{z}_h)^\top \boldsymbol{\beta}. \end{aligned} \tag{22.27}$$

Essa diferença é uma função linear dos parâmetros.

Quando

$$\mathbf{Z}$$

possui posto deficiente, nem toda função de

$$\boldsymbol{\beta}$$

é identificada pela estrutura sistemática

$$\mathbf{Z}\boldsymbol{\beta}.$$

Algebricamente, uma função linear

$$\mathbf{c}^\top \boldsymbol{\beta}$$

é invariável entre todos os vetores de parâmetros equivalentes quando

$$\mathbf{c} \in \mathcal{C}(\mathbf{Z}^\top).$$

Para relacionar essa propriedade à **estimabilidade estatística** definida no Módulo 2, considere uma resposta quantitativa satisfazendo

$$E(\varepsilon \mid \mathbf{Z}) = \mathbf{0},$$

de modo que

$$E(\mathbf{Y} \mid \mathbf{Z}) = \mathbf{Z}\beta.$$

Então, pela definição de Definição 11.16 e pela caracterização de Proposição 11.12, a função

$$\mathbf{c}^\top \beta$$

é linearmente estimável se, e somente se,

$$\mathbf{c} \in \mathcal{C}(\mathbf{Z}^\top). \quad (22.28)$$

Assim, a mesma condição de espaço linha possui duas leituras relacionadas:

- algebricamente, determina quais funções permanecem iguais entre parametrizações equivalentes;
- estatisticamente, sob o modelo de médias, determina quais funções lineares admitem estimadores lineares não viesados.

A condição possui uma interpretação direta.

Se

$$\mathbf{c}$$

pertence ao espaço linha de

$$\mathbf{Z},$$

existe

$$\mathbf{a} \in \mathbb{R}^N$$

tal que

$$\mathbf{c}^\top = \mathbf{a}^\top \mathbf{Z}.$$

Então,

$$\mathbf{c}^\top \beta = \mathbf{a}^\top \mathbf{Z} \beta,$$

de modo que essa função depende apenas da estrutura sistemática

$$\mathbf{Z} \beta,$$

e não da escolha de um representante particular entre vetores de parâmetros equivalentes.

Esse é o motivo matemático pelo qual determinados contrastes podem ser interpretados mesmo sob parametrizações redundantes.

22.17.1 Diferenças entre perfis

Para Equação [22.27](#), o vetor do contraste é

$$\mathbf{c} = \mathbf{z}_i - \mathbf{z}_h.$$

Quando

$$\mathbf{c} \in \mathcal{C}(\mathbf{Z}^\top),$$

a diferença

$$V_i - V_h$$

é uma função estimável.

Para perfis já representados pelas linhas da própria matriz de delineamento, diferenças entre seus valores sistemáticos pertencem naturalmente à estrutura representada pelo modelo.

22.17.2 Diferenças entre níveis

Considere dois níveis

$$a, b \in \mathcal{L}_j.$$

A diferença

$$u_j(a) - u_j(b)$$

é especialmente relevante porque não depende da escolha de uma origem comum para todas as utilidades daquele atributo.

Sua estimabilidade, entretanto, depende de o delineamento permitir distinguir o contraste correspondente.

Portanto, a existência conceitual de dois níveis não garante, por si só, que sua diferença possa ser estimada a partir dos perfis observados.

22.17.3 Novo perfil

Considere um novo perfil com vetor de codificação

$$\mathbf{z}_0^\top.$$

Sua utilidade sistemática é

$$V_0 = \mathbf{z}_0^\top \beta.$$

Se

$$\mathbf{Z}$$

possui posto deficiente, essa quantidade é estimável somente quando

$$\mathbf{z}_0 \in \mathcal{C}(\mathbf{Z}^\top). \quad (22.29)$$

Assim, uma parametrização pode ajustar unicamente os perfis utilizados na construção do modelo sem permitir a determinação de toda combinação arbitrária de níveis.

Essa distinção será importante quando examinarmos o delineamento dos perfis.

22.18 Um exemplo de equivalência entre codificações

Considere novamente o atributo A com três níveis.

Suponha que, sob codificação por efeitos, as utilidades parciais sejam

$$u_A(A_1) = 2,$$

$$u_A(A_2) = -0,5$$

e

$$u_A(A_3) = -1,5.$$

A restrição de soma zero é satisfeita:

$$2 - 0,5 - 1,5 = 0.$$

As diferenças relativamente a

$$A_1$$

são

$$u_A(A_2) - u_A(A_1) = -2,5$$

e

$$u_A(A_3) - u_A(A_1) = -3,5.$$

Se

$$A_1$$

for escolhido como categoria de referência, os coeficientes correspondentes serão

$$\beta_{A2}^{(\text{ref})} = -2,5$$

e

$$\beta_{A3}^{(\text{ref})} = -3, 5.$$

Os valores numéricos dos parâmetros mudaram porque seu significado mudou.

Entretanto, as diferenças entre os níveis são preservadas.

Por exemplo,

$$u_A(A_2) - u_A(A_3) = 1$$

em ambas as representações.

A ordenação também permanece:

$$u_A(A_1) > u_A(A_2) > u_A(A_3).$$

O exemplo distingue dois objetos:

- **parâmetro da codificação**, cujo valor depende da base escolhida;
- **contraste estimável de preferência**, que pode permanecer invariável entre parametrizações equivalentes.

Essa distinção será retomada posteriormente na interpretação das utilidades estimadas.

22.19 Posto e complexidade do modelo

A identificação depende da eliminação das redundâncias introduzidas pela codificação e de o conjunto de perfis fornecer informação suficiente para separar os efeitos incluídos no modelo.

No modelo aditivo contendo apenas efeitos principais, uma parametrização identificada utiliza

$$d = 1 + \sum_{j=1}^m (L_j - 1)$$

parâmetros.

Para que todos esses coeficientes possam ser identificados por uma parametrização irrestrita, é necessário que

$$\text{posto}(\mathbf{Z}) = d. \tag{22.30}$$

Como

$$\mathbf{Z} \in \mathbb{R}^{N \times d},$$

tem-se necessariamente

$$d \leq N.$$

Essa condição é necessária, mas não suficiente: mesmo com

$$N \geq d,$$

uma seleção inadequada de perfis pode produzir colunas linearmente dependentes.

22.19.1 Inclusão de interações

Se forem incluídas interações entre dois atributos

$$A_j \quad \text{e} \quad A_h,$$

com

$$L_j$$

e

$$L_h$$

níveis, respectivamente, a interação acrescenta

$$(L_j - 1)(L_h - 1) \tag{22.31}$$

graus de liberdade em uma parametrização identificada.

A estrutura sistemática pode então assumir a forma

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}) + \sum_{j < h} u_{jh}(x_{ij}, x_{ih}).$$

Incluir uma interação significa acrescentar ao modelo novas funções que precisam ser distinguíveis a partir dos perfis observados.

O aumento da complexidade produz, portanto, duas consequências simultâneas:

- aumenta o número de colunas necessárias para representar o modelo;
- aumenta a quantidade e a diversidade de perfis necessárias para que essas colunas sejam linearmente independentes.

Não basta acrescentar termos formalmente à equação.

É necessário que

Z

contenha informação suficiente para separar seus efeitos.

Esse é o ponto de ligação entre **modelo e delineamento**.

As colunas são determinadas pelos efeitos que se pretende representar.

As linhas são determinadas pelos perfis que se decide observar.

O posto de

Z

resulta da interação entre essas duas escolhas.

A próxima etapa consiste, portanto, em examinar como a construção dos perfis determina quais efeitos podem ser identificados e estimados.

22.20 Do modelo identificado ao delineamento dos perfis

A matriz

Z

é determinada conjuntamente pelos efeitos incluídos no modelo e pelos perfis efetivamente apresentados ou observados. Os efeitos determinam suas colunas, enquanto os perfis determinam suas linhas.

Assim, uma codificação que elimine redundâncias estruturais entre os parâmetros ainda pode produzir uma matriz de delineamento com posto deficiente quando o conjunto de perfis não

fornece informação suficiente para separar os efeitos incluídos. Nesse caso, alguns coeficientes deixam de ser individualmente identificados, embora determinadas funções lineares possam permanecer estimáveis.

Consequentemente,

$$\text{posto}(\mathbf{Z})$$

depende simultaneamente da parametrização do modelo e das combinações de níveis presentes no delineamento.

No delineamento fatorial completo, todos os elementos de

$$\mathcal{L}_1 \times \cdots \times \mathcal{L}_m$$

são utilizados. Quando apenas parte dessas combinações é observada, obtém-se um delineamento fracionário.

A adequação do delineamento depende de sua capacidade de produzir posto e espaço linha suficientes para os efeitos e contrastes de interesse. O número de perfis, isoladamente, não determina essa propriedade.

22.21 Delineamento dos perfis

Se o atributo j possui

$$L_j$$

níveis, o conjunto completo de perfis contém

$$N_{\text{perf}} = \prod_{j=1}^m L_j$$

combinações, conforme Equação [22.2](#).

A escolha de quais desses perfis serão apresentados determina as linhas da matriz

$$\mathbf{Z}.$$

Por isso, delineamento e estimabilidade não constituem etapas independentes.

22.21.1 Delineamento fatorial completo

No **delineamento fatorial completo**, todas as combinações possíveis dos níveis dos atributos são incluídas.

Considere, por exemplo, três atributos com

$$L_1 = 2, \quad L_2 = 3 \quad \text{e} \quad L_3 = 2.$$

O número de perfis possíveis é

$$N_{\text{perf}} = 2 \times 3 \times 2 = 12.$$

O delineamento contém, portanto, todas as combinações

$$\mathcal{L}_1 \times \mathcal{L}_2 \times \mathcal{L}_3.$$

Para uma parametrização sem redundância estrutural, o delineamento fatorial completo fornece informação para distinguir todos os efeitos principais correspondentes aos atributos incluídos.

Além disso, como todas as combinações dos níveis estão presentes, podem ser representadas interações entre atributos até a ordem permitida pelo modelo fatorial completo, desde que a parametrização correspondente respeite os graus de liberdade disponíveis.

Por exemplo, dois atributos com

$$L_j$$

e

$$L_h$$

níveis possuem uma interação com

$$(L_j - 1)(L_h - 1)$$

graus de liberdade, conforme Equação [22.31](#).

O delineamento completo oferece uma estrutura particularmente transparente para separar esses efeitos porque nenhuma combinação de níveis foi deliberadamente removida.

Sua limitação aparece no crescimento do número de perfis:

$$N_{\text{perf}} = \prod_{j=1}^m L_j.$$

O crescimento é multiplicativo.

Com muitos atributos ou muitos níveis, exigir que um participante avalie todas as alternativas pode tornar a coleta inviável ou excessivamente extensa.

Essa limitação motiva os delineamentos fracionários.

22.21.2 Delineamento fracionário

Seja

$$\mathcal{P} = \mathcal{L}_1 \times \cdots \times \mathcal{L}_m$$

o conjunto completo de perfis.

Um **delineamento fracionário** utiliza um subconjunto

$$\mathcal{P}_F \subsetneq \mathcal{P}.$$

A redução do conjunto de perfis significa que algumas linhas da matriz que corresponderia ao delineamento completo deixam de ser observadas.

Se

$$\mathbf{Z}_F$$

denota a matriz resultante, então a pergunta relevante passa a ser se

$$\mathbf{Z}_F$$

continua permitindo identificar ou estimar os efeitos de interesse.

A remoção de perfis pode:

- preservar todos os efeitos principais;
- confundir determinados efeitos entre si;
- impedir a separação de algumas interações;
- reduzir o posto da matriz de delineamento.

Consequentemente, um delineamento não é “fracionário” apenas porque possui menos perfis. Ele precisa ser analisado relativamente à estrutura paramétrica que se pretende estimar.

Considere uma função linear dos parâmetros,

$$\mathbf{c}^\top \boldsymbol{\beta}.$$

Pelo resultado de estimabilidade discutido anteriormente, ela somente pode ser determinada pela estrutura sistemática quando

$$\mathbf{c} \in \mathcal{C}(\mathbf{Z}_F^\top).$$

Assim, perfis diferentes podem produzir conjuntos diferentes de funções estimáveis mesmo quando utilizam:

- os mesmos atributos;
- os mesmos níveis;
- o mesmo número de perfis.

É a estrutura linear produzida pelas combinações escolhidas que determina a informação disponível.

Os procedimentos para construir delineamentos fracionários eficientes serão tratados posteriormente.

Aqui, o ponto central é:

reduzir o número de perfis significa reduzir ou reorganizar as linhas de $\mathbf{Z}$, e essa alteração pode modificar seu posto e seu espaço linha.

22.21.3 Ortogonalidade

Além do posto, a organização geométrica das colunas da matriz de delineamento influencia a separação dos efeitos.

Considere duas colunas

$$\mathbf{z}_h, \mathbf{z}_k \in \mathbb{R}^N$$

que representem dois contrastes ou termos não constantes do modelo.

Elas são ortogonais quando

$$\mathbf{z}_h^\top \mathbf{z}_k = 0. \quad (22.32)$$

Quando existe intercepto, as codificações dos efeitos podem ser escolhidas de modo que suas colunas também sejam ortogonais a

$$\mathbf{1}_N.$$

Equivalentemente, pode-se examinar a ortogonalidade após retirar de cada coluna sua componente constante.

Se

$$\tilde{\mathbf{z}}_h = \mathbf{z}_h - \bar{z}_h \mathbf{1}_N$$

e

$$\tilde{\mathbf{z}}_k = \mathbf{z}_k - \bar{z}_k \mathbf{1}_N,$$

a condição

$$\tilde{\mathbf{z}}_h^\top \tilde{\mathbf{z}}_k = 0$$

indica ausência de associação linear entre as duas colunas depois de removida a componente associada ao intercepto.

Para blocos inteiros de colunas,

$$\mathbf{Z}_A$$

e

$$\mathbf{Z}_B,$$

a condição correspondente é

$$\mathbf{Z}_A^\top \mathbf{Z}_B = \mathbf{0},$$

quando as colunas já foram construídas na parametrização apropriada.

A ortogonalidade simplifica

$$\mathbf{Z}^\top \mathbf{Z}$$

e permite separar mais diretamente a informação associada a diferentes termos do modelo.

Entretanto:

ortogonalidade e identificação não são a mesma propriedade.

Uma matriz pode conter colunas não ortogonais e ainda possuir posto completo.

Nesse caso, os parâmetros continuam identificados, embora as informações associadas aos diferentes efeitos não estejam geometricamente separadas.

Por outro lado, colunas ortogonais não resolvem uma parametrização que contenha redundâncias adicionais.

A condição fundamental para a identificação irrestrita continua sendo

$$\text{posto}(\mathbf{Z}) = d.$$

22.21.4 Balanceamento

O **balanceamento** refere-se à frequência com que os níveis dos atributos aparecem no conjunto de perfis.

Para um atributo

$$A_j$$

com

$$L_j$$

níveis, um delineamento perfeitamente balanceado apresenta cada nível com a mesma frequência.

Se

$$N$$

perfis são utilizados e essa igualdade é possível, cada nível aparece

$$\frac{N}{L_j}$$

vezes.

Em um delineamento fatorial completo, cada nível de um atributo aparece igualmente muitas vezes porque está combinado com todas as configurações possíveis dos demais atributos.

Em um delineamento fracionário, o balanceamento depende da seleção realizada.

Balanceamento e ortogonalidade são conceitos relacionados, mas não equivalentes.

O balanceamento controla **frequências marginais dos níveis**.

A ortogonalidade controla **produtos internos entre colunas ou subespaços de efeitos**.

Um delineamento pode apresentar níveis balanceados e ainda produzir associação entre determinadas colunas.

Em estruturas fatoriais apropriadas, a combinação de balanceamento, cruzamento dos níveis e codificações por contrastes pode produzir ortogonalidade entre efeitos, mas isso deve resultar da estrutura do delineamento e não ser assumido apenas a partir das frequências marginais.

22.21.5 Delineamento e estimabilidade

As propriedades anteriores podem ser organizadas da seguinte forma:

Tabela 22.5: Propriedades da matriz de delineamento na Análise Conjunta.

Propriedade	Interpretação
posto	possibilidade de determinar unicamente os parâmetros da parametrização
espaço linha	conjunto de funções lineares dos parâmetros que podem ser estimadas
ortogonalidade	separação linear da informação associada aos efeitos
balanceamento	distribuição das frequências dos níveis entre os perfis
número de perfis	limite dimensional para a quantidade de parâmetros representável

Nenhuma dessas propriedades, isoladamente, substitui as demais.

Em particular,

$$N \geq d$$

é apenas uma condição necessária para que uma matriz

$$\mathbf{Z} \in \mathbb{R}^{N \times d}$$

possa possuir posto coluna completo.

A condição efetiva é

$$\text{posto}(\mathbf{Z}) = d.$$

Esse resultado conecta a escolha substantiva dos perfis à existência de uma solução única para o problema de mínimos quadrados.

22.22 Estimação das utilidades

Considere agora uma resposta quantitativa.

Para

$$N$$

avaliações, defina o vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_N \end{pmatrix} \in \mathbb{R}^N,$$

e considere o modelo

$$\mathbf{Y} = \mathbf{Z}\beta + \varepsilon,$$

com

$$\mathbf{Z} \in \mathbb{R}^{N \times d}, \quad \beta \in \mathbb{R}^d$$

e

$$\varepsilon \in \mathbb{R}^N.$$

Suponha

$$\text{posto}(\mathbf{Z}) = d.$$

O resultado de Proposição 11.2, aplicado ao caso de uma única resposta, fornece o **estimador de mínimos quadrados**

$$\hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (22.33)$$

Essa expressão é uma estatística aleatória porque depende de

$$\mathbf{Y}.$$

Após observar as respostas,

$$\mathbf{Y} = \mathbf{y},$$

obtém-se a **estimativa observada**

$$\hat{\beta}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (22.34)$$

Essa distinção é a mesma estabelecida no Módulo 2 entre Equação 11.36 e Equação 11.37.

A existência e a unicidade dessa solução dependem, nessa formulação clássica, de

$$\text{posto}(\mathbf{Z}) = d.$$

Não é necessário assumir normalidade para obter a solução de mínimos quadrados.

O critério é a especialização para uma única resposta daquele definido em Definição 11.8:

$$Q(\beta) = \|\mathbf{y} - \mathbf{Z}\beta\|^2. \quad (22.35)$$

Sob posto completo,

$$\mathbf{Z}^\top \mathbf{Z} \succ \mathbf{0},$$

de modo que o critério é estritamente convexo em

$$\beta$$

e possui um único minimizador.

Portanto, é necessário distinguir:

- **posto completo**, que garante unicidade algébrica do minimizador;
- **estrutura da esperança do erro**, que determina propriedades como não viés;
- **estrutura de variância e dependência dos erros**, que afeta precisão e inferência;
- **normalidade**, que somente entra quando uma formulação probabilística específica a exige.

Por exemplo, se

$$E(\varepsilon \mid \mathbf{Z}) = \mathbf{0},$$

então

$$E(\mathbf{Y} \mid \mathbf{Z}) = \mathbf{Z}\beta. \quad (22.36)$$

Sob as condições de Proposição 11.3, sua especialização para uma única resposta fornece

$$E(\hat{\beta} \mid \mathbf{Z}) = \beta.$$

Assim, o estimador de mínimos quadrados é não viesado para o vetor de parâmetros associado à parametrização escolhida.

Não se deve, entretanto, concluir automaticamente que cada componente de

$$\hat{\beta}_{\text{obs}}$$

é uma “utilidade parcial” diretamente comparável.

Seu significado depende da codificação.

Na codificação por referência, alguns componentes são contrastes com um nível de referência.

Na codificação por efeitos, as utilidades dos níveis são recuperadas segundo as restrições impostas.

22.23 Utilidades sistemáticas ajustadas

A quantidade substantivamente representada pelo modelo é

$$\mathbf{V} = \mathbf{Z}\beta.$$

Substituindo os parâmetros pela estimativa observada, obtém-se

$$\widehat{\mathbf{V}} = \mathbf{Z}\hat{\beta}_{\text{obs}}. \quad (22.37)$$

Para o perfil i ,

$$\widehat{V}_i = \mathbf{z}_i^\top \hat{\beta}_{\text{obs}}. \quad (22.38)$$

Os valores ajustados foram definidos no modelo linear em Definição 11.9. No caso de uma única resposta,

$$\widehat{\mathbf{V}} = \mathbf{Z}\hat{\beta}_{\text{obs}}$$

é a especialização de Equação 11.54.

Sob posto coluna completo, o projetor sobre o espaço do delineamento é dado por Equação 11.49. Portanto,

$$\widehat{\mathbf{V}} = \mathbf{P}_{\mathbf{Z}}\mathbf{y} \in \mathcal{C}(\mathbf{Z}).$$

Pela propriedade de projeção sobre o espaço coluna estabelecida em Proposição 3.15,

$$\widehat{\mathbf{V}}$$

é a projeção ortogonal de

$$\mathbf{y}$$

sobre

$$\mathcal{C}(\mathbf{Z}).$$

Na Análise Conjunta, esse espaço representa o conjunto de padrões de utilidade sistemática que podem ser produzidos pelos atributos, níveis e efeitos incluídos no modelo.

22.23.1 Utilidade estimada de um perfil

Considere um modelo aditivo com três atributos,

$$A, \quad B \quad \text{e} \quad C.$$

Para o perfil

$$(A = a, B = b, C = c),$$

a utilidade sistemática é

$$V(a, b, c) = \beta_0 + u_A(a) + u_B(b) + u_C(c).$$

Depois da estimação, as contribuições recuperadas segundo a parametrização escolhida produzem

$$\hat{V}(a, b, c) = \hat{\beta}_{0,\text{obs}} + \hat{u}_A(a) + \hat{u}_B(b) + \hat{u}_C(c). \quad (22.39)$$

A Figura 22.2 ilustra essa soma em um exemplo numérico.

Cada parcela representa uma contribuição segundo uma parametrização identificada, e a soma determina a utilidade sistemática estimada do perfil.

A figura também evidencia a natureza compensatória do modelo aditivo.

No exemplo, a contribuição associada ao nível observado do atributo B é negativa, enquanto as demais contribuições são positivas.

A utilidade global é determinada pela soma das parcelas.

As alturas individuais das barras, entretanto, dependem da parametrização utilizada.

Uma mudança de origem nas utilidades parciais pode modificar as parcelas individuais sem alterar:

- a utilidade ajustada do perfil;
- diferenças ajustadas entre perfis;
- contrastes estimáveis correspondentes.




Figura 22.2: Decomposição da utilidade sistemática estimada de um perfil em uma constante e contribuições associadas aos níveis dos atributos. A soma das parcelas determina a utilidade do perfil segundo a parametrização adotada.

22.24 Interpretação das preferências

A estimação permite reconstruir utilidades e contrastes associados aos níveis.

A interpretação deve privilegiar quantidades compatíveis com a parametrização e com a estrutura do modelo.

22.24.1 Comparação entre níveis

Considere dois níveis

$$a, b \in \mathcal{L}_j.$$

A diferença

$$u_j(a) - u_j(b)$$

representa, no modelo aditivo, a diferença de contribuição entre esses níveis.

Depois da estimação,

$$\hat{u}_j(a) - \hat{u}_j(b)$$

é o contraste estimado correspondente.

Se

$$\hat{u}_j(a) > \hat{u}_j(b),$$

o nível a possui maior contribuição estimada para a utilidade sistemática que o nível b , dentro da estrutura especificada.

Em um modelo puramente aditivo, essa diferença não depende dos níveis assumidos pelos demais atributos.

Quando existem interações envolvendo

$$A_j,$$

a contribuição da mudança de nível precisa incorporar os termos de interação correspondentes e deixa de ser representada apenas por

$$u_j(a) - u_j(b).$$

22.25 Amplitude das utilidades de um atributo

Considere o modelo aditivo sem interações.

Para o atributo

$$A_j,$$

defina a amplitude populacional das utilidades parciais por

$$R_j = \max_{\ell \in \mathcal{L}_j} u_j(\ell) - \min_{\ell \in \mathcal{L}_j} u_j(\ell). \quad (22.40)$$

A amplitude satisfaz

$$R_j \geq 0.$$

Ela mede a maior diferença de contribuição possível entre os níveis daquele atributo **dentro do conjunto de níveis incluído no estudo**.

Como diferenças permanecem inalteradas quando uma mesma constante é adicionada a todas as utilidades parciais de um atributo, a amplitude não depende da escolha de uma origem arbitrária para essas utilidades.

Se

$$\sum_{h=1}^m R_h > 0,$$

pode-se definir uma medida normalizada.

Definição 22.8 (Importância relativa de um atributo). Considere um modelo aditivo com

$$m \geq 1$$

atributos e funções de utilidade parcial

$$u_j : \mathcal{L}_j \longrightarrow \mathbb{R}, \quad j = 1, \dots, m.$$

Para cada atributo, defina

$$R_j = \max_{\ell \in \mathcal{L}_j} u_j(\ell) - \min_{\ell \in \mathcal{L}_j} u_j(\ell).$$

Se

$$\sum_{h=1}^m R_h > 0,$$

a **importância relativa** do atributo j é

$$I_j = \frac{R_j}{\sum_{h=1}^m R_h}. \quad (22.41)$$

Então,

$$0 \leq I_j \leq 1$$

e

$$\sum_{j=1}^m I_j = 1.$$

Se

$$R_1 = \dots = R_m = 0,$$

a expressão está indeterminada porque não existe variação de utilidade entre os níveis considerados.

22.25.1 Importância relativa estimada

Depois de estimar as utilidades parciais, define-se

$$\widehat{R}_j = \max_{\ell \in \mathcal{L}_j} \widehat{u}_j(\ell) - \min_{\ell \in \mathcal{L}_j} \widehat{u}_j(\ell). \quad (22.42)$$

Se

$$\sum_{h=1}^m \widehat{R}_h > 0,$$

a importância relativa estimada é

$$\widehat{I}_j = \frac{\widehat{R}_j}{\sum_{h=1}^m \widehat{R}_h}. \quad (22.43)$$

Essa distinção separa a quantidade definida pela estrutura populacional de utilidade de sua versão calculada a partir dos dados observados.

A importância relativa não constitui um parâmetro independente das utilidades parciais.

Ela é uma função derivada de suas amplitudes.

Além disso, depende explicitamente de

$$\mathcal{L}_j.$$

Se forem considerados níveis mais afastados entre si, a amplitude

$$R_j$$

pode aumentar mesmo sem alteração da estrutura de preferência que relaciona utilidade e característica subjacente.

Por isso:

a importância relativa não é uma propriedade absoluta do atributo; ela é definida relativamente aos níveis incluídos no estudo.

A interpretação também depende da hipótese aditiva.

Quando existem interações, a contribuição de um atributo pode variar segundo os níveis dos demais, e

$$R_j$$

calculado apenas a partir dos efeitos principais não resume toda a participação daquele atributo na utilidade.

22.26 Preferências individuais e agregadas

A preferência pode variar entre participantes.

Até aqui,

$$\beta$$

foi utilizado para representar uma única estrutura paramétrica.

Essa estrutura pode corresponder:

- a um participante específico;
- a um modelo comum imposto a vários participantes.

Essas duas situações devem ser distinguidas.

22.26.1 Modelo individual

Considere o participante

$$r.$$

Se ele fornece

$$N_r$$

respostas quantitativas, defina

$$\mathbf{Y}_r \in \mathbb{R}^{N_r},$$

$$\mathbf{Z}_r \in \mathbb{R}^{N_r \times d},$$

e

$$\varepsilon_r \in \mathbb{R}^{N_r}.$$

Um modelo individual pode ser escrito como

$$\mathbf{Y}_r = \mathbf{Z}_r \beta_r + \varepsilon_r. \quad (22.44)$$

O vetor

$$\beta_r \in \mathbb{R}^d$$

representa os parâmetros de preferência daquele participante segundo a parametrização escolhida.

Em geral, para participantes distintos,

$$\beta_r \neq \beta_{r'}.$$

A heterogeneidade pode ocorrer:

- na magnitude das diferenças entre níveis;
- na ordenação dos níveis;
- na importância relativa dos atributos;
- em interações ou outros componentes da estrutura de preferência.

Se

$$\text{posto}(\mathbf{Z}_r) = d,$$

um modelo linear individual com resposta quantitativa pode ser estimado por mínimos quadrados.

Entretanto, isso exige que cada participante forneça informação suficiente para identificar todos os parâmetros de seu próprio modelo.

22.26.2 Modelo agregado

Outra possibilidade consiste em assumir uma estrutura comum,

$$\beta,$$

para um conjunto de

$$R$$

participantes.

Considere os vetores

$$\mathbf{Y}_1, \dots, \mathbf{Y}_R$$

e as matrizes

$$\mathbf{Z}_1, \dots, \mathbf{Z}_R.$$

Empilhando as respostas,

$$\mathbf{Y} = \begin{pmatrix} \mathbf{Y}_1 \\ \vdots \\ \mathbf{Y}_R \end{pmatrix},$$

e as matrizes de delineamento,

$$\mathbf{Z} = \begin{pmatrix} \mathbf{Z}_1 \\ \vdots \\ \mathbf{Z}_R \end{pmatrix},$$

um modelo agregado pode ser escrito como

$$\mathbf{Y} = \mathbf{Z}\beta + \varepsilon. \tag{22.45}$$

Nesse modelo,

$$\beta$$

é um único vetor utilizado para representar uma estrutura comum de preferência para o conjunto de participantes.

Ele **não deve ser interpretado automaticamente como a média aritmética dos vetores individuais**

$$\beta_1, \dots, \beta_R.$$

A relação entre um ajuste agregado e parâmetros individuais depende, entre outros fatores:

- dos delineamentos $\mathbf{Z}_r$;
- do número de respostas fornecidas por cada participante;
- de eventuais ponderações;
- da estrutura probabilística adotada.

Mesmo quando o ajuste agregado descreve adequadamente uma tendência central, ele pode ocultar heterogeneidade.

Por exemplo, um contraste agregado próximo de zero pode resultar de:

- preferências individuais próximas de zero;
- fortes preferências positivas em parte dos participantes e fortes preferências negativas em outra parte.

Essas estruturas são substantivamente diferentes.

Por isso, um resultado agregado deve ser interpretado como característica do **modelo comum ajustado ao conjunto de observações**, e não como demonstração de homogeneidade individual.

22.26.3 Extensões para heterogeneidade

A heterogeneidade entre participantes pode ser representada, em formulações mais amplas, por:

- modelos individuais;
- segmentação;
- efeitos aleatórios;
- modelos hierárquicos;
- classes latentes.

Essas extensões não serão desenvolvidas neste capítulo.

O ponto estrutural a reter é que:

- um modelo individual permite que cada participante possua seus próprios parâmetros;

- um modelo agregado impõe ou estima uma estrutura comum;
- a escolha entre essas formulações altera o significado de β e a estrutura probabilística das observações.

A presença de várias respostas do mesmo participante também antecipa uma questão importante para a etapa seguinte: as observações fornecidas pelo mesmo indivíduo não devem ser tratadas automaticamente como independentes em procedimentos inferenciais.

Até aqui, entretanto, foi considerada uma resposta **quantitativa**, para a qual a relação entre resposta e utilidade pôde ser inicialmente formulada por um modelo linear.

A Análise Conjunta não se restringe a esse tipo de dado.

Avaliações ordinais, ordenações, comparações pareadas e escolhas fornecem informações diferentes sobre a preferência e exigem outras ligações entre a utilidade sistemática e a resposta observada.

Essa distinção será examinada a seguir.

22.27 Diferentes formas de resposta

A mesma estrutura de atributos e perfis pode ser utilizada com diferentes tipos de resposta.

Entretanto, o tipo de resposta determina **qual informação sobre a preferência foi observada** e, conseqüentemente, qual modelo estatístico pode relacionar essa informação à utilidade sistemática.

A Tabela 22.6 resume as principais situações.

Tabela 22.6: Formas de resposta na Análise Conjunta.

Resposta observada	Informação fornecida	Estrutura estatística compatível
avaliação quantitativa	intensidade da avaliação na escala utilizada	modelo linear
categoria ordinal	posição em uma escala ordenada	modelo ordinal
ordenação de perfis	ordem relativa das alternativas	modelo para postos ou ordenações
comparação pareada	preferência entre duas alternativas	modelo probabilístico de comparação
escolha	alternativa selecionada em um conjunto	modelo de utilidade aleatória

Os perfis continuam sendo representados por seus atributos e níveis, e sua parte sistemática pode continuar sendo construída a partir de

$$V_i = \mathbf{z}_i^\top \beta.$$

O que se modifica é o mecanismo que conecta

$$V_i$$

à informação observada.

Essa distinção é essencial: uma avaliação numérica, uma ordenação e uma escolha não constituem diferentes escalas de uma mesma variável aleatória. Elas fornecem informações estatisticamente distintas sobre a preferência.

22.27.1 Avaliação quantitativa

Quando a resposta é uma avaliação quantitativa tratada como métrica, pode-se considerar

$$Y_i = \mathbf{z}_i^\top \beta + \varepsilon_i.$$

As diferenças numéricas da escala observada participam diretamente da formulação.

Após a observação,

$$Y_i = y_i.$$

A utilização de mínimos quadrados discutida anteriormente corresponde a essa situação.

Normalidade não é necessária para definir a utilidade sistemática nem para calcular a solução de mínimos quadrados.

Hipóteses adicionais sobre

$$\varepsilon$$

são necessárias apenas conforme as propriedades probabilísticas ou inferenciais que se deseje estabelecer.

22.27.2 Resposta ordinal

Considere uma resposta

$$Y_i$$

assumindo categorias ordenadas.

A informação

$$Y_i > Y_h$$

expressa uma ordenação entre as respostas, mas as diferenças numéricas entre os códigos das categorias não precisam possuir interpretação métrica.

Por exemplo, se as categorias forem codificadas por

$$1, 2, 3, 4, 5,$$

não decorre da ordinalidade que a diferença entre as categorias 1 e 2 represente a mesma diferença de preferência que entre 4 e 5.

Portanto, substituir automaticamente a resposta ordinal em

$$Y_i = \mathbf{z}_i^\top \beta + \varepsilon_i$$

como se os códigos fossem quantitativos altera a informação fornecida pela escala.

Uma formulação estatística para respostas ordinais deve respeitar a ordem das categorias sem pressupor, apenas a partir dos códigos, distâncias métricas iguais entre elas.

Os modelos específicos não serão desenvolvidos neste capítulo.

22.27.3 Ordenação

Em uma tarefa de ordenação, um conjunto de

$$K$$

perfis pode produzir uma observação como

$$\mathbf{x}_{i_1} \succ \mathbf{x}_{i_2} \succ \cdots \succ \mathbf{x}_{i_K}.$$

Essa resposta informa que

$$\mathbf{x}_{i_1}$$

é preferido a

$$\mathbf{x}_{i_2},$$

que é preferido a

$$\mathbf{x}_{i_3},$$

e assim sucessivamente.

Não se observa diretamente a magnitude das diferenças de utilidade.

Assim,

$$V_{i_1} - V_{i_2}$$

e

$$V_{i_2} - V_{i_3}$$

não podem ser comparadas quantitativamente apenas a partir das posições na ordenação.

A resposta contém informação relativa sobre a ordem das alternativas e exige uma formulação compatível com esse tipo de observação.

22.27.4 Comparação pareada

Considere dois perfis,

$$i \quad \text{e} \quad h.$$

Em uma comparação pareada, observa-se qual dos dois é preferido.

A parte sistemática relevante aparece por meio da diferença

$$V_i - V_h.$$

Se

$$V_i$$

e

$$V_h$$

fossem as únicas componentes da decisão, uma regra determinística selecionaria o perfil com maior valor.

Em uma formulação probabilística, são acrescentados componentes aleatórios às utilidades, de modo que a preferência observada passa a fornecer informação probabilística sobre essa diferença.

22.27.5 Escolha

Em uma tarefa de escolha, o participante observa simultaneamente um conjunto de alternativas e seleciona uma delas.

Para o participante

$$r,$$

denote por

$$\mathcal{C}_r$$

o conjunto de alternativas disponíveis na tarefa considerada.

O que se observa é uma decisão do tipo

$$i \in \mathcal{C}_r \quad \text{foi escolhido.}$$

A utilidade não é observada diretamente.

Ela funciona como uma variável latente utilizada para representar o mecanismo que produz a escolha.

Essa situação conduz à formulação por utilidade aleatória.

22.28 Utilidade aleatória

Considere o participante

$$r$$

e uma alternativa

$$i \in \mathcal{C}_r.$$

A utilidade aleatória é representada por

$$U_{ir} = V_{ir} + \varepsilon_{ir}, \quad (22.46)$$

em que

$$V_{ir}$$

é a parcela sistemática da utilidade e

$$\varepsilon_{ir}$$

é uma parcela aleatória não observada.

A parte sistemática pode ser escrita como

$$V_{ir} = \mathbf{z}_{ir}^\top \beta, \quad (22.47)$$

em uma formulação com parâmetros comuns.

Em um modelo individual, o mesmo papel pode ser desempenhado por

$$\beta_r.$$

Portanto, a representação dos atributos permanece a mesma: o vetor

$$\mathbf{z}_{ir}$$

continua sendo construído a partir dos níveis que caracterizam a alternativa.

O que muda é a relação entre a utilidade sistemática e a resposta observada.

A alternativa

$$i$$

é escolhida quando sua utilidade é maior que a das demais alternativas disponíveis:

$$U_{ir} > U_{hr}, \quad \forall h \in \mathcal{C}_r, h \neq i.$$

Consequentemente,

$$\begin{aligned} P(i \text{ escolhido} \mid \mathcal{C}_r) \\ = P(V_{ir} + \varepsilon_{ir} > V_{hr} + \varepsilon_{hr}, \forall h \in \mathcal{C}_r, h \neq i). \end{aligned} \quad (22.48)$$

A expressão anterior utiliza desigualdades estritas entre as utilidades. Quando a especificação probabilística implica probabilidade zero de empate, nenhuma regra adicional é necessária.

Se empates puderem ocorrer com probabilidade positiva, o mecanismo de observação deve incluir também uma regra de desempate. Essa convenção pertence ao modelo de escolha e não altera a decomposição sistemática

$$V_{ir} = \mathbf{z}_{ir}^\top \beta.$$

A distribuição conjunta atribuída aos termos

$$\varepsilon_{ir}, \quad i \in \mathcal{C}_r,$$

determina a forma específica das probabilidades de escolha.

Portanto, a expressão Equação 22.48 ainda não define um modelo de escolha particular.

Ela estabelece apenas sua estrutura geral.

Modelos específicos acrescentam hipóteses sobre a distribuição dos componentes aleatórios e, a partir dessas hipóteses, obtêm funções particulares para as probabilidades de escolha.

Essas formulações e seus procedimentos de estimação pertencem ao desenvolvimento metodológico posterior (Green; Srinivasan, 1990).

A ligação estrutural que interessa neste capítulo é:

- atributos e níveis determinam $\mathbf{z}_{ir}$;
- os parâmetros determinam V_{ir} ;
- o componente aleatório completa a utilidade latente;
- a escolha observada fornece informação relativa sobre as utilidades das alternativas presentes em $\mathcal{C}_r$.

A Análise Conjunta e os modelos de escolha estão, portanto, relacionados, mas não são conceitos idênticos.

A Análise Conjunta organiza a decomposição da preferência em atributos e níveis.

Um modelo de escolha fornece uma formulação probabilística específica para o mecanismo pelo qual uma dessas alternativas é selecionada.

22.29 Natureza relativa da utilidade

A interpretação da utilidade depende da informação observada e do modelo utilizado.

Não existe uma única afirmação sobre “a escala da utilidade” que seja válida indistintamente para avaliações quantitativas, ordenações e escolhas.

22.29.1 Preferência ordinal

Considere duas alternativas,

$$i \quad \text{e} \quad h,$$

tais que

$$U_i > U_h.$$

Se

$$g : \mathbb{R} \longrightarrow \mathbb{R}$$

é estritamente crescente, então

$$g(U_i) > g(U_h).$$

Portanto, a transformação preserva a ordenação.

Quando a informação disponível é apenas ordinal, os números atribuídos às utilidades servem para representar a ordem das alternativas.

Entretanto, isso não significa que uma transformação monotônica arbitrária preserve a **estrutura aditiva**

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}).$$

A ordenação pode ser preservada enquanto a forma funcional do modelo deixa de ser aditiva.

Assim, devem ser distinguidos:

- a representação ordinal da preferência;
- a parametrização aditiva utilizada pela Análise Conjunta.

22.29.2 Avaliação quantitativa

No modelo linear,

$$E(Y_i | \mathbf{z}_i) = \mathbf{z}_i^\top \beta,$$

a localização e a escala das utilidades ajustadas estão vinculadas à escala na qual

$$Y_i$$

foi medida.

Uma mudança de unidades da resposta modifica numericamente os parâmetros do modelo.

Portanto, nessa formulação, a utilidade não é tratada apenas como uma ordenação abstrata.

Ela é relacionada à escala quantitativa adotada para a resposta.

22.29.3 Escolha

Nos modelos de escolha, a decisão depende das comparações entre utilidades dentro do conjunto

$$\mathcal{C}_r.$$

Se uma mesma constante

$$c$$

for adicionada à utilidade de todas as alternativas,

$$U_{ir}^* = U_{ir} + c,$$

então

$$U_{ir}^* > U_{hr}^*$$

se, e somente se,

$$U_{ir} > U_{hr}.$$

Assim, uma localização comum das utilidades não é determinada pelas escolhas.

A mesma ideia pode ser vista pelas diferenças:

$$U_{ir}^* - U_{hr}^* = U_{ir} - U_{hr}.$$

Além disso, multiplicar todas as utilidades por uma constante positiva preserva sua ordenação:

$$cU_{ir} > cU_{hr}, \quad c > 0.$$

Em modelos probabilísticos específicos, a escala dos parâmetros sistemáticos está ligada à escala adotada para o componente aleatório.

Por isso, são necessárias restrições de localização e escala para identificar uma parametrização probabilística de escolha.

O modo exato de impor essas restrições depende do modelo de escolha e não será desenvolvido aqui.

A afirmação de que “a utilidade é relativa” deve, portanto, ser qualificada:

- em preferências ordinais, interessa primordialmente a ordenação;
- em avaliações métricas, localização e escala estão ligadas à resposta observada;
- em escolhas, comparações dependem de diferenças de utilidade, e a parametrização probabilística exige convenções de localização e escala.

22.30 Pressupostos e limites

As condições da Análise Conjunta desempenham funções diferentes. Algumas especificam a estrutura substantiva da utilidade, outras garantem identificação e estimabilidade, e outras pertencem ao modelo probabilístico utilizado para relacionar utilidade e resposta.

22.30.1 Pressupostos estruturais

Os perfis devem ser descritos por atributos e níveis compatíveis com o problema de preferência. A interpretação permanece condicionada ao domínio

$$\mathcal{L}_1 \times \cdots \times \mathcal{L}_m$$

considerado no estudo. Características substantivamente relevantes que não sejam representadas pelos atributos não podem ter suas contribuições separadas diretamente pelo modelo.

Na formulação aditiva,

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}),$$

as contribuições dos atributos são somadas. Essa hipótese pertence à forma da utilidade sistemática e não decorre da codificação nem do método de estimação. Interações podem ser incluídas quando a contribuição de um atributo depende dos níveis dos demais.

A aditividade também introduz uma estrutura compensatória: contribuições desfavoráveis em alguns atributos podem ser compensadas por contribuições favoráveis em outros. Essa representação pode ser inadequada diante de requisitos obrigatórios, limiares, restrições ou mecanismos não compensatórios.

As utilidades parciais e as importâncias relativas dependem dos níveis incluídos no estudo. Alterações em

$$\mathcal{L}_j$$

podem modificar

$$R_j$$

e

$$I_j$$

sem que isso corresponda necessariamente a uma mudança na estrutura de preferência dos participantes.

22.30.2 Condições algébricas

A codificação dos níveis deve produzir uma parametrização identificada relativamente ao delineamento observado. Para

$$\beta \in \mathbb{R}^d,$$

sem restrições adicionais, a identificação exige

$$\text{posto}(\mathbf{Z}) = d,$$

ou, equivalentemente,

$$\mathcal{N}(\mathbf{Z}) = \{\mathbf{0}\}.$$

Em parametrizações restritas, a aplicação

$$\beta \mapsto \mathbf{Z}\beta$$

deve ser injetiva no espaço que satisfaz as restrições. Categoria de referência e soma zero são formas distintas de eliminar a mesma indeterminação estrutural.

O delineamento também deve fornecer informação suficiente para os efeitos incluídos. Uma função linear

$$\mathbf{c}^\top \beta$$

é estimável, sob a formulação correspondente do modelo linear, quando

$$\mathbf{c} \in \mathcal{C}(\mathbf{Z}^\top).$$

A inclusão de interações ou de outros efeitos aumenta as exigências sobre o espaço linha de $\mathbf{Z}$. O número de perfis é necessário para estabelecer um limite dimensional, mas não garante, isoladamente, posto ou estimabilidade.

22.30.3 Pressupostos probabilísticos

O modelo probabilístico deve ser compatível com a forma da resposta. Avaliações quantitativas, categorias ordinais, ordenações, comparações e escolhas fornecem informações distintas sobre a preferência, embora possam compartilhar uma mesma estrutura sistemática de utilidade.

Na formulação quantitativa,

$$\mathbf{Y} = \mathbf{Z}\beta + \varepsilon,$$

a condição

$$E(\varepsilon \mid \mathbf{Z}) = \mathbf{0}$$

é distinta de hipóteses sobre variância, independência ou distribuição dos erros. Normalidade não é necessária para definir o modelo aditivo nem para calcular a solução ordinária de mínimos quadrados; ela pode ser acrescentada quando uma formulação inferencial específica a exigir.

Quando um mesmo participante fornece várias avaliações ou realiza várias tarefas de escolha, as respostas pertencem à mesma unidade observacional e não devem ser consideradas automaticamente independentes. A estrutura de dependência intraparticipante pertence ao modelo probabilístico da coleta. Modelos para medidas repetidas, efeitos aleatórios, classes latentes ou estruturas hierárquicas serão tratados posteriormente.

A Tabela 22.7 resume essas distinções.

Tabela 22.7: Natureza das principais condições da Análise Conjunta.

Natureza	Condição	Papel
estrutural	atributos e níveis adequadamente definidos	determina quais características podem ser representadas
estrutural	aditividade, quando adotada	permite decompor a utilidade em soma de contribuições

Natureza	Condição	Papel
estrutural	compensação	permite troca entre contribuições dos atributos
algébrica	identificação	garante unicidade da parametrização no espaço considerado
algébrica	posto e estimabilidade	determina quais efeitos e contrastes podem ser recuperados
probabilística	modelo compatível com a resposta	conecta utilidade e observação
probabilística	estrutura dos erros	determina propriedades probabilísticas da estimação
amostral	dependência intraparticipante	representa adequadamente respostas repetidas da mesma unidade
contextual	domínio de atributos, níveis e participantes	delimita a generalização das utilidades

22.30.4 Generalização

As utilidades estimadas são definidas relativamente aos atributos, níveis, perfis, participantes, mecanismos de resposta e modelos considerados no estudo. Alterar esses elementos modifica o problema estatístico e pode modificar as utilidades ou importâncias obtidas.

Assim, utilidades e importâncias relativas não constituem características universais dos atributos independentemente da construção do estudo.

22.31 Relações com outras formulações estatísticas

22.31.1 Modelo linear

A relação matemática mais direta da formulação quantitativa é com o modelo linear.

Considere

$$\mathbf{Y} = \mathbf{Z}\beta + \varepsilon.$$

Os fundamentos desenvolvidos anteriormente sobre:

- espaço coluna;
- projeções;
- posto;
- mínimos quadrados;
- identificação;
- funções estimáveis;

aplicam-se diretamente.

A Análise Conjunta acrescenta uma interpretação substantiva específica aos seus elementos.

As linhas de

Z

representam perfis ou avaliações de perfis.

As colunas representam atributos, contrastes, interações ou outros efeitos construídos a partir das características das alternativas.

O vetor

β

parametriza as contribuições utilizadas para representar a preferência.

Assim, não é a equação linear que torna um modelo uma Análise Conjunta.

O que caracteriza a formulação é a construção de

Z

a partir dos atributos e níveis e a interpretação de seus efeitos em termos de utilidade ou preferência.

22.31.2 Delineamento experimental

A ligação com o delineamento experimental aparece diretamente na construção dos perfis.

Os atributos desempenham papel análogo ao de fatores e seus níveis definem as condições combinadas nas alternativas.

Um perfil corresponde a uma combinação dessas condições.

Consequentemente, conceitos como:

- fatorial completo;
- fracionamento;
- balanceamento;
- ortogonalidade;
- confundimento;
- posto;

possuem interpretação direta na construção de

Z.

A função do delineamento é determinar quais efeitos podem ser separados a partir dos perfis observados.

Na Análise Conjunta, entretanto, o objetivo substantivo não é simplesmente comparar tratamentos.

Os perfis são construídos para permitir a decomposição de avaliações, preferências ou escolhas em contribuições relacionadas às características das alternativas.

22.31.3 Modelos de escolha

Quando a resposta é uma escolha, a relação linear direta entre uma resposta métrica e

$\mathbf{Z}\beta$

deixa de representar o mecanismo de observação.

A estrutura passa a ser

$$U_{ir} = \mathbf{z}_{ir}^T \beta + \varepsilon_{ir}.$$

Os mesmos atributos e parâmetros continuam determinando a parte sistemática da utilidade.

A diferença está no fato de que a observação é uma decisão entre alternativas.

A distribuição dos componentes aleatórios transforma diferenças de utilidade em probabilidades de escolha.

Assim, Análise Conjunta e modelos de escolha compartilham:

- representação das alternativas por atributos;
- parametrização das contribuições dos níveis;
- comparação entre utilidades.

Mas desempenham funções conceituais distintas.

A Análise Conjunta organiza a decomposição da preferência segundo as características das alternativas.

O modelo de escolha especifica probabilisticamente como essas utilidades produzem a alternativa observada.

Modelos específicos, funções de probabilidade e algoritmos de estimação serão tratados posteriormente.

22.32 Síntese da Análise Conjunta

A Análise Conjunta representa alternativas por combinações de níveis de

$$m$$

atributos. Um perfil

$$\mathbf{x}_i \in \mathcal{L}_1 \times \cdots \times \mathcal{L}_m$$

é associado a uma utilidade sistemática. Na formulação aditiva,

$$V_i = \beta_0 + \sum_{j=1}^m u_j(x_{ij}),$$

em que

$$u_j : \mathcal{L}_j \longrightarrow \mathbb{R}$$

representa a contribuição dos níveis do atributo j .

A codificação transforma os níveis em vetores numéricos e cada perfil produz uma linha

$$\mathbf{z}_i^\top$$

da matriz de delineamento. A estrutura sistemática passa então a ser escrita como

$$\mathbf{V} = \mathbf{Z}\beta.$$

Essa representação conecta a Análise Conjunta aos fundamentos de espaço coluna, núcleo, posto, identificação e funções estimáveis. Quando

$$\mathbf{Z}\mathbf{d} = \mathbf{0}$$

para algum

$$\mathbf{d} \neq \mathbf{0},$$

os vetores

$$\beta \quad \text{e} \quad \beta + \mathbf{d}$$

produzem a mesma utilidade sistemática. Categoria de referência e restrições de soma zero são formas de eliminar as redundâncias introduzidas pela parametrização.

Diferentes codificações podem produzir coeficientes distintos e preservar as mesmas utilidades sistemáticas e contrastes estimáveis. O significado substantivo deve, portanto, ser atribuído às quantidades invariantes à parametrização, e não aos valores numéricos isolados dos coeficientes.

O delineamento determina as linhas de

$$\mathbf{Z}$$

e, conseqüentemente, participa da identificação e da estimabilidade. Delineamentos completos incluem todas as combinações dos níveis; delineamentos fracionários utilizam subconjuntos dessas combinações e precisam preservar informação suficiente para os efeitos de interesse.

Para avaliações quantitativas,

$$\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$$

permite utilizar diretamente a teoria do modelo linear. Sob posto coluna completo,

$$\hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y},$$

e os valores sistemáticos ajustados pertencem a

$$\mathcal{C}(\mathbf{Z}).$$

Normalidade não é necessária para definir essa solução.

A amplitude das utilidades de um atributo,

$$R_j = \max_{\ell \in \mathcal{L}_j} u_j(\ell) - \min_{\ell \in \mathcal{L}_j} u_j(\ell),$$

permite definir, quando o denominador é positivo,

$$I_j = \frac{R_j}{\sum_{h=1}^m R_h}.$$

Essa importância é relativa aos níveis considerados e deve ser interpretada dentro da estrutura do modelo, especialmente quando existem interações.

A preferência pode ser modelada individualmente, por parâmetros

$$\beta_r,$$

ou de forma agregada por uma estrutura comum. Um ajuste agregado não implica homogeneidade das preferências individuais.

A forma da resposta determina a ligação probabilística com a utilidade. Avaliações quantitativas podem conduzir a modelos lineares; respostas ordinais, ordenações, comparações e escolhas exigem mecanismos compatíveis com a informação observada. Nos modelos de escolha, a utilidade aleatória

$$U_{ir} = V_{ir} + \varepsilon_{ir}$$

relaciona a estrutura sistemática às decisões entre alternativas.

A Análise Conjunta integra representação de perfis, parametrização, matriz de delineamento, posto, identificação, estimabilidade, projeções e modelos probabilísticos. Sua forma matemática decorre da hipótese de que a preferência pode ser representada por contribuições associadas às características das alternativas.

22.33 Síntese do Módulo 3

O Módulo 3 mostrou como os fundamentos matemáticos, probabilísticos e estatísticos dos Módulos 1 e 2 se combinam na formulação de diferentes técnicas multivariadas. Cada técnica parte de um problema próprio, utiliza objetos compatíveis com esse problema e define sua solução por uma função objetivo, decomposição matricial ou modelo estatístico.

A Tabela 22.8 reúne essas estruturas.

Tabela 22.8: Problemas, objetos e estruturas matemáticas das técnicas apresentadas no Módulo 3.

Técnica	Problema estatístico	Objeto principal	Estrutura da solução	Resultado fundamental
ACP	reduzir dimensão preservando variabilidade	dados ou matriz de covariâncias/correlações	autovalores, projeções e SVD	componentes e escores
Análise Fatorial	representar covariâncias por fatores latentes	matriz de covariâncias/correlações	modelo de covariância	fatores e cargas
Agrupamentos	formar grupos sem rótulos prévios	dados ou dissimilaridades	distâncias, partições e critérios de dispersão	grupos
MDS	representar dissimilaridades geometricamente	matriz de dissimilaridades	matriz de Gram e decomposição espectral	coordenadas
Correspondência	representar associação entre categorias	tabela de contingência	perfis, métrica qui-quadrado e SVD	coordenadas de linhas e colunas
MANOVA	comparar funções paramétricas multivariadas	respostas e delineamento	modelo linear, $\mathbf{H}$, $\mathbf{E}$ e autovalores generalizados	critérios de teste e direções associadas ao efeito
Discriminante	separar grupos e classificar	dados com grupos conhecidos	critério de Fisher ou regras probabilísticas	direções e regras de classificação
Correlação Canônica	associar dois blocos	covariâncias particionadas	branqueamento, SVD e autovalores generalizados	pares canônicos

Técnica	Problema estatístico	Objeto principal	Estrutura da solução	Resultado fundamental
Análise Conjunta	decompor preferências	perfis, atributos e respostas	modelo de utilidade e matriz de delineamento	utilidades e contrastes

As mesmas estruturas matemáticas reaparecem porque resolvem problemas gerais de representação, otimização e modelagem. Autovalores e SVD identificam direções e subespaços; projeções produzem representações de menor dimensão; distâncias e produtos internos definem geometrias; matrizes de covariâncias e de dispersão descrevem variabilidade e associação; matrizes de delineamento representam efeitos; modelos probabilísticos relacionam estruturas observadas e parâmetros.

O significado dessas estruturas depende do problema estatístico. Uma decomposição espectral pode representar variabilidade na ACP, separação relativa na MANOVA e na Análise Discriminante ou associação entre blocos na Correlação Canônica. Uma matriz de distâncias pode sustentar agrupamentos ou uma reconstrução geométrica no MDS. Uma matriz de delineamento pode representar efeitos de um modelo linear ou atributos e níveis na Análise Conjunta.

A compreensão de uma técnica multivariada exige, portanto, identificar quatro elementos: o problema estatístico formulado, o objeto matemático que representa os dados, o critério ou modelo que define a solução e a interpretação permitida por essa estrutura.

Os Módulos 1 e 2 forneceram os fundamentos necessários para essas formulações. O Módulo 3 mostrou como esses fundamentos se integram na construção das principais técnicas multivariadas.

A etapa seguinte poderá desenvolver algoritmos, critérios operacionais, diagnóstico, validação, implementação computacional e interpretação aplicada mantendo explícita a estrutura matemática e estatística que sustenta cada método.

Referências

ANDERSON, Theodore W. **An Introduction to Multivariate Statistical Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

APOSTOL, Tom M. **Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability**. 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. **Métodos multivariados de análise estatística**. 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. **Measure, Integration & Real Analysis**. Cham: Springer, 2020. v. 282

BEH, Eric J.; LOMBARDO, Rosaria (ORGS.). **Correspondence Analysis: Theory, Practice and New Strategies**. Chichester: John Wiley & Sons, 2014.

BORG, Ingwer; GROENEN, Patrick J. F.; MAIR, Patrick. **Applied Multidimensional Scaling and Unfolding**. 2. ed. Cham: Springer, 2018. p. 122

BOYD, Stephen; VANDENBERGHE, Lieven. **Convex Optimization**. Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury, 2002.

CHRISTENSEN, Ronald. **Plane Answers to Complex Questions: The Theory of Linear Models**. 4. ed. New York: Springer, 2011. p. 494

DEMMELE, James W. **Singular Value Decomposition**. In: BAI, Zhaojun *et al.* (Orgs.). **Templates for the Solution of Algebraic Eigenvalue Problems: A Practical Guide**. Philadelphia: Society for Industrial; Applied Mathematics, 2000. p. 135–147.

DRISCOLL, Tobin A.; BRAUN, Richard J. **Fundamentals of Numerical Computation: Julia Edition**. Philadelphia: Society for Industrial; Applied Mathematics, 2022. p. 614

EATON, Morris L. **Multivariate Statistics: A Vector Space Approach**. Beachwood, OH:

Institute of Mathematical Statistics, 2007. v. 53 p. 512

EVERITT, Brian S. *et al.* **Cluster Analysis**. 5. ed. Chichester: John Wiley & Sons, 2011. p. 352

FISHER, Ronald A. **The Use of Multiple Measurements in Taxonomic Problems**. **Annals of Eugenics**, v. 7, n. 2, p. 179–188, 1936.

GOLUB, Gene H.; VAN LOAN, Charles F. **Matrix Computations**. 4. ed. Baltimore: Johns Hopkins University Press, 2013.

GOWER, John C. **Some Distance Properties of Latent Root and Vector Methods Used in Multivariate Analysis**. **Biometrika**, v. 53, n. 3–4, p. 325–338, 1966.

GREEN, Paul E.; RAO, Vithala R. **Conjoint Measurement for Quantifying Judgmental Data**. **Journal of Marketing Research**, v. 8, n. 3, p. 355–363, 1971.

GREEN, Paul E.; SRINIVASAN, V. **Conjoint Analysis in Consumer Research: Issues and Outlook**. **Journal of Consumer Research**, v. 5, n. 2, p. 103–123, 1978.

GREEN, Paul E.; SRINIVASAN, V. **Conjoint Analysis in Marketing: New Developments with Implications for Research and Practice**. **Journal of Marketing**, v. 54, n. 4, p. 3–19, 1990.

GREENACRE, Michael. **Correspondence Analysis in Practice**. 3. ed. Boca Raton: CRC Press, 2017.

GUPTA, Arjun K.; NAGAR, Daya K. **Matrix Variate Distributions**. Boca Raton: Chapman & Hall/CRC, 1999.

HAIR, Jr., Joseph F. *et al.* **Multivariate Data Analysis**. 8. ed. Andover: Cengage Learning, 2018.

HARVILLE, David A. **Matrix Algebra From a Statistician's Perspective**. New York: Springer, 1997. p. 634

HENDRICKSON, Alan E.; WHITE, Paul Owen. **Promax: A Quick Method for Rotation to Oblique Simple Structure**. **British Journal of Statistical Psychology**, v. 17, n. 1, p. 65–70, 1964.

HORN, Roger A.; JOHNSON, Charles R. **Topics in Matrix Analysis**. Cambridge: Cambridge University Press, 1991.

HORN, Roger A.; JOHNSON, Charles R. **Matrix Analysis**. 2. ed. Cambridge: Cambridge

University Press, 2013.

HUBERTY, Carl J.; OLEJNIK, Stephen. **Applied MANOVA and Discriminant Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2006.

JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.

JOLLIFFE, Ian T. **Principal Component Analysis**. 2. ed. New York: Springer, 2002. p. 488

KAISER, Henry F. **The Varimax Criterion for Analytic Rotation in Factor Analysis**. **Psychometrika**, v. 23, n. 3, p. 187–200, 1958.

KRUSKAL, Joseph B. **Multidimensional Scaling by Optimizing Goodness of Fit to a Nonmetric Hypothesis**. **Psychometrika**, v. 29, n. 1, p. 1–27, 1964.

LAWLEY, D. N.; MAXWELL, A. E. **Factor Analysis as a Statistical Method**. 2. ed. London: Butterworths, 1971.

LEDOIT, Olivier; WOLF, Michael. **A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices**. **Journal of Multivariate Analysis**, v. 88, n. 2, p. 365–411, 2004.

LUCE, R. Duncan; TUKEY, John W. **Simultaneous Conjoint Measurement: A New Type of Fundamental Measurement**. **Journal of Mathematical Psychology**, v. 1, n. 1, p. 1–27, 1964.

MACQUEEN, James. Some Methods for Classification and Analysis of Multivariate Observations. *In*: Berkeley: University of California Press, 1967. Disponível em: <<https://projecteuclid.org/euclid.bsmsp/1200512992>>. Acesso em: 3 ago. 2026

MAGNUS, Jan R.; NEUDECKER, Heinz. **Matrix Differential Calculus with Applications in Statistics and Econometrics**. 3. ed. Chichester: John Wiley & Sons, 2019. p. 504

MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. **Métodos Estatísticos Multivariados: Uma Introdução**. 4. ed. Porto Alegre: Bookman, 2019. p. 254

MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. **Multivariate Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2024. p. 592

MARONNA, Ricardo A. *et al.* **Robust Statistics: Theory and Methods (with R)**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464

MEYER, Carl D. **Matrix Analysis and Applied Linear Algebra**. 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991

MINGOTI, Sueli Aparecida. **Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada**. Belo Horizonte: Editora UFMG, 2005.

MUIRHEAD, Robb J. **Aspects of Multivariate Statistical Theory**. New York: John Wiley & Sons, 1982.

PILLAI, K. C. S. **Some New Test Criteria in Multivariate Analysis**. **The Annals of Mathematical Statistics**, v. 26, n. 1, p. 117–121, 1955.

POLLARD, David. **Strong Consistency of k -Means Clustering**. **The Annals of Statistics**, v. 9, n. 1, p. 135–140, 1981.

RAO, C. Radhakrishna. **Linear Statistical Inference and Its Applications**. 2. ed. New York: John Wiley & Sons, 1973.

RENCHE, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2012.

SIDI, Avram. **Vector Extrapolation Methods with Applications**. Philadelphia: Society for Industrial; Applied Mathematics, 2017. p. 381

TORGERSON, Warren S. **Multidimensional Scaling: I. Theory and Method**. **Psychometrika**, v. 17, n. 4, p. 401–419, 1952.

VAART, A. W. van der. **Asymptotic Statistics**. Cambridge: Cambridge University Press, 1998. p. 462

WARD, Jr., Joe H. **Hierarchical Grouping to Optimize an Objective Function**. **Journal of the American Statistical Association**, v. 58, n. 301, p. 236–244, 1963.

WILKS, Samuel S. **Certain Generalizations in the Analysis of Variance**. **Biometrika**, v. 24, n. 3–4, p. 471–494, 1932.