

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	13
Direitos Autorais e Uso da Obra	13
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	13
Prefácio	14
Identificação da Disciplina	15
EMENTA	15
OBJETIVO GERAL	15
OBJETIVOS ESPECÍFICOS	15
CONTEÚDO PROGRAMÁTICO	16
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	16
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	16
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	16
METODOLOGIA	17
AVALIAÇÃO	17
CRITÉRIOS DE AVALIAÇÃO	17
BIBLIOGRAFIA BÁSICA	18
BIBLIOGRAFIA COMPLEMENTAR	18
 I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multi-	
 variada	19
 1 Vetores e representação dos dados multivariados	20
1.1 Escalares, vetores e matrizes	21
1.1.1 Vetor-coluna, vetor-linha e transposição	24
1.2 O espaço $\mathbb{R}^p$	25
1.3 Representação matricial de um conjunto de dados	28
1.3.1 Espaço das observações e espaço das variáveis	30
1.4 Operações elementares com vetores	31
1.4.1 Soma e subtração	31
1.4.2 Multiplicação por escalar	32
1.4.3 Combinações lineares	34
1.5 Produto interno, norma, ângulo e distância euclidiana	36
1.5.1 Produto interno euclidiano	36

1.5.2	Norma euclidiana	37
1.5.3	Desigualdade de Cauchy–Schwarz	38
1.5.4	Ângulo entre vetores	41
1.5.5	Distância euclidiana	43
1.5.6	Desigualdade triangular	45
1.5.7	Produto externo	46
1.6	Síntese do capítulo	48
2	Álgebra matricial aplicada	50
2.1	Operações matriciais fundamentais	51
2.1.1	Soma e subtração de matrizes	51
2.1.2	Produto matriz-vetor	54
2.1.3	Produto entre matrizes	57
2.1.4	Propriedades do produto matricial	62
2.2	Transposição, simetria e traço	63
2.2.1	Transposição	63
2.2.2	Matrizes simétricas	65
2.2.3	Traço	69
2.3	Identidade, inversa, determinante, posto e sistemas lineares	73
2.3.1	Matriz identidade	73
2.3.2	Matriz inversa	74
2.3.3	Determinante	77
2.3.4	Interpretação geométrica do determinante	81
2.3.5	Posto	82
2.3.6	Sistemas lineares	85
2.3.7	Aprofundamento: pseudoinversa	89
2.4	Matrizes ortogonais, diagonais e triangulares	91
2.4.1	Matrizes ortogonais	91
2.4.2	Matrizes diagonais	94
2.4.3	Matrizes triangulares	96
2.4.4	Aprofundamento: sistemas triangulares	98
2.5	Formas bilineares, formas quadráticas e positividade	100
2.5.1	Formas bilineares	100
2.5.2	Formas quadráticas	104
2.5.3	Positividade	111
2.5.4	Superfícies de nível	117
2.6	Aprofundamento: matrizes particionadas e complemento de Schur	118
2.6.1	Matrizes particionadas	118
2.6.2	Soma e multiplicação por escalar	120
2.6.3	Transposição por blocos	120
2.6.4	Multiplicação por blocos	121
2.6.5	Complemento de Schur	123
2.6.6	Eliminação por blocos	124

2.6.7	Determinante de uma matriz particionada	126
2.6.8	Inversão em blocos	127
2.6.9	Positividade e complemento de Schur	128
2.7	Síntese do capítulo	131
3	Espaços vetoriais, bases e projeções	134
3.1	Espaços, subespaços e geração	135
3.1.1	Subespaços vetoriais	137
3.1.2	Subespaço gerado	139
3.2	Independência linear, bases e dimensão	142
3.2.1	Independência linear	142
3.2.2	Independência linear e posto	144
3.2.3	Bases	146
3.2.4	Coordenadas em uma base	147
3.2.5	Base canônica	149
3.2.6	Bases ortogonais e ortonormais	150
3.2.7	Dimensão	153
3.3	Espaços fundamentais de uma matriz	155
3.3.1	Espaço nulo	155
3.3.2	Espaço coluna	158
3.3.3	Espaço linha	161
3.3.4	Espaço nulo à esquerda	162
3.3.5	Extensão de uma base	164
3.3.6	Teorema Posto–Nulidade	165
3.3.7	Os quatro espaços fundamentais	169
3.3.8	Complemento ortogonal	169
3.3.9	Relações de ortogonalidade	170
3.4	Produtos internos, bases ortonormais e matrizes de Gram	172
3.4.1	Aprofundamento: produtos internos e geometrias induzidas	172
3.4.2	Matrizes de Gram	177
3.4.3	Propriedades da matriz de Gram	179
3.4.4	Matrizes de Gram e bases ortonormais	181
3.4.5	Produtos cruzados em uma matriz de dados	182
3.4.6	Propriedades do complemento ortogonal	183
3.4.7	Dimensão do complemento ortogonal	185
3.4.8	Decomposição ortogonal	188
3.4.9	Decomposição dos espaços fundamentais	190
3.5	Projeções ortogonais	191
3.5.1	Projeção sobre uma direção	192
3.5.2	Projeção sobre um subespaço com base ortonormal	197
3.5.3	Projeção sobre o espaço coluna de uma matriz	200
3.5.4	Propriedades da matriz de projeção	204
3.5.5	Aprofundamento: projeção residual e complemento ortogonal	208

3.5.6	Projeção como melhor aproximação	213
3.5.7	Aprofundamento: projeções e mínimos quadrados	216
3.6	Síntese do capítulo	220
4	Transformações lineares	223
4.1	Transformações lineares e representação matricial	224
4.1.1	Transformação determinada por uma base	226
4.1.2	Representação matricial nas bases canônicas	228
4.1.3	Núcleo e imagem de uma transformação linear	230
4.1.4	Imagem de um subespaço	231
4.2	Transformação de vetores e matrizes de dados	232
4.2.1	Novas variáveis como combinações lineares	234
4.2.2	Dimensão da configuração transformada	236
4.2.3	Efeito sobre diferenças e produtos internos	240
4.2.4	Transformação das matrizes de produtos internos	241
4.3	Composição, invertibilidade e perda de informação	242
4.3.1	Composição de transformações lineares	243
4.3.2	A ordem das transformações	244
4.3.3	Transformação inversa	247
4.3.4	Injetividade, sobrejetividade e bijetividade	248
4.3.5	Perda de informação	253
4.3.6	Redução de dimensionalidade	254
4.3.7	Transformações singulares	255
4.4	Transformações geométricas	256
4.4.1	Rotação	257
4.4.2	Reflexão	258
4.4.3	Escalonamento	260
4.4.4	Cisalhamento	261
4.4.5	Projeção	263
4.4.6	Comparação geométrica	264
4.4.7	Determinante, volume e orientação	265
4.5	Transformações ortogonais	267
4.5.1	Transformação de uma matriz de dados	269
4.5.2	Determinante e orientação	270
4.5.3	Matrizes ortogonais e bases ortonormais	271
4.5.4	Comparação com transformações não ortogonais	272
4.6	Mudanças de coordenadas e representação em bases	274
4.6.1	Conversão entre duas bases	276
4.6.2	Representação de uma transformação em bases gerais	277
4.6.3	Representação de um operador em uma nova base	280
4.6.4	Transformação ativa e mudança passiva	282
4.6.5	Mudança de coordenadas de uma matriz de dados	283

4.7	Transformações afins e pré-processamento	284
4.7.1	Translação	286
4.7.2	Transformação afim de uma matriz de dados	286
4.7.3	Centralização	287
4.7.4	Escalonamento das variáveis	291
4.7.5	Padronização	292
4.7.6	Ordem entre centralização e escalonamento	293
4.7.7	Composição e inversão de transformações afins	294
4.7.8	Comparação das operações de pré-processamento	296
4.8	Síntese do capítulo	296
5	Autovalores, autovetores e decomposição espectral	304
5.1	Direções invariantes, autovalores e autoespaços	305
5.2	Equação característica, multiplicidades e diagonalização	314
5.2.1	Determinação dos autovalores e autoespaços	316
5.2.2	Autovalores complexos de matrizes reais	318
5.2.3	Independência entre autovetores	319
5.2.4	Multiplicidades algébrica e geométrica	321
5.2.5	Diagonalização	326
5.2.6	Potências de uma matriz diagonalizável	329
5.3	Matrizes simétricas e decomposição espectral	330
5.3.1	Decomposição espectral do exemplo condutor	336
5.3.2	Forma aditiva da decomposição espectral	338
5.3.3	Projetores sobre autoespaços	339
5.3.4	Não unicidade da matriz de autovetores	341
5.4	Consequências da decomposição espectral	342
5.4.1	Traço, determinante, posto e invertibilidade	342
5.4.2	Formas quadráticas em coordenadas espectrais	346
5.4.3	Superfícies de nível em coordenadas espectrais	351
5.5	Quociente de Rayleigh	354
5.5.1	Representação espectral	355
5.5.2	Formulação com restrição de norma	361
5.5.3	Multiplicadores de Lagrange	362
5.5.4	Direções sucessivas	367
5.6	Funções espectrais de matrizes	371
5.6.1	Ação sobre os autoespaços	372
5.6.2	Potências inteiras	373
5.6.3	Inversa espectral	374
5.6.4	Raiz quadrada principal	375
5.6.5	Raiz quadrada inversa	376
5.6.6	Pseudoinversa espectral	377
5.6.7	Exponencial e logaritmo matriciais	379

5.7	Aprofundamento: autovalores generalizados	380
5.7.1	Quociente de Rayleigh generalizado	383
5.7.2	Redução a um problema espectral ordinário	386
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	389
5.7.4	Diagonalização simultânea por congruência	391
5.8	Síntese do capítulo	397
6	Decomposição em Valores Singulares	403
6.1	Definição e formas da Decomposição em Valores Singulares	404
6.1.1	Vetores singulares	408
6.1.2	Interpretação como composição de transformações	410
6.1.3	SVD completa	411
6.1.4	SVD compacta	412
6.1.5	SVD compacta e SVD truncada	413
6.1.6	Aprofundamento: não unicidade dos vetores singulares	419
6.2	Construção da SVD e relação com a decomposição espectral	421
6.2.1	Propriedades das matrizes de Gram associadas	422
6.2.2	Construção dos pares singulares	427
6.2.3	Construção da SVD compacta	432
6.2.4	Decomposições espectrais associadas	436
6.2.5	Exemplo de construção da SVD	438
6.2.6	Relação com a decomposição espectral de matrizes simétricas	441
6.2.7	Aprofundamento: SVD de matrizes simétricas indefinidas	442
6.3	Interpretação geométrica da SVD	443
6.3.1	Imagem da bola unitária	445
6.3.2	Alteração dos comprimentos	448
6.3.3	Exemplo geométrico no plano	453
6.3.4	Transformações com núcleo não trivial	454
6.4	Espaços fundamentais, posto e normas	456
6.4.1	Espaço coluna e espaço linha	457
6.4.2	Projetores ortogonais	461
6.4.3	Posto e nulidades	465
6.4.4	Produto interno de Frobenius	466
6.4.5	Normas e valores singulares	468
6.4.6	Invariância ortogonal	470
6.4.7	Determinante e invertibilidade	471
6.4.8	Aprofundamento: condicionamento e posto numérico	472
6.5	SVD de uma matriz de dados	478
6.5.1	Dualidade entre observações e variáveis	479
6.5.2	Coordenadas das observações nas direções singulares à direita	480
6.5.3	Coordenadas das variáveis nas direções singulares à esquerda	482
6.5.4	Matrizes de Gram da matriz de dados	483
6.5.5	Representação exata das observações	484

6.5.6	Centralização da matriz de dados	487
6.5.7	Antecipação: relação com a matriz de covariâncias amostral	488
6.5.8	Magnitude quadrática da matriz centralizada	490
6.5.9	Representação exata e aproximação	493
6.6	Forma expandida e aproximações de posto reduzido	494
6.6.1	Ortogonalidade dos componentes singulares	496
6.6.2	SVD truncada na forma expandida	498
6.6.3	Erros produzidos pelo truncamento	499
6.6.4	Teorema de Eckart–Young–Mirsky	502
6.6.5	Aprofundamento: demonstração e unicidade da melhor aproximação . .	503
6.6.6	Exemplo de aproximação de posto 1	510
6.6.7	Aproximação de uma matriz de dados	512
6.7	Pseudoinversa e soluções de mínimos quadrados	515
6.7.1	Relação com a pseudoinversa espectral	517
6.7.2	Aprofundamento: caracterização de Moore–Penrose	518
6.7.3	Pseudoinversa e projetores	524
6.7.4	Sistemas lineares compatíveis	526
6.7.5	Mínimos quadrados	529
6.7.6	Expressão da solução nas direções singulares	536
6.7.7	Aprofundamento: instabilidade e pseudoinversa truncada	537
6.7.8	Exemplo com o sistema condutor	540
6.8	Síntese do capítulo	542
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	551
7.1	Funções, variações e diferenciais	551
7.1.1	Tipos de funções	551
7.1.2	Convenções de derivação	554
7.1.3	Variação de uma função	555
7.1.4	Diferencial	557
7.1.5	Aproximação ao longo de uma direção	559
7.1.6	Diferenciabilidade de funções vetoriais	559
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	562
7.2.1	Gradiente e derivada direcional	562
7.2.2	Gradiente e conjuntos de nível	565
7.2.3	Jacobiana	568
7.2.4	Regra da cadeia	570
7.2.5	Hessiana	572
7.3	Aproximações de Taylor e classificação local	574
7.3.1	Aproximação de Taylor de primeira ordem	574
7.3.2	Aproximação de Taylor de segunda ordem	576
7.3.3	Pontos estacionários	577
7.3.4	Classificação pela Hessiana	579
7.3.5	Caso inconclusivo	582

7.4	Convexidade e concavidade	583
7.4.1	Conjuntos convexos	583
7.4.2	Funções convexas	584
7.4.3	Caracterização de primeira ordem	585
7.4.4	Caracterização pela Hessiana	585
7.4.5	Consequências para otimização	588
7.4.6	Funções quadráticas	589
7.5	Otimização sem restrições	591
7.5.1	Método de Newton	591
7.6	Otimização com restrições de igualdade	595
7.6.1	Multiplicadores de Lagrange	596
7.6.2	Relação com problemas de autovalores	602
7.6.3	Restrições lineares	603
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	605
7.7.1	Formas lineares e bilineares	605
7.7.2	Derivadas de formas quadráticas	606
7.7.3	Derivadas da norma euclidiana	609
7.7.4	Funções de resíduos lineares	609
7.7.5	Equações normais	611
7.7.6	Mínimos quadrados ponderados	614
7.7.7	Funções compostas de resíduos	616
7.7.8	Mínimos quadrados não lineares	617
7.8	Diferenciais matriciais e cálculo por traços	619
7.8.1	Regras básicas do diferencial matricial	620
7.8.2	Identities de traço	621
7.8.3	Função linear de uma matriz	622
7.8.4	Derivadas da norma de Frobenius	623
7.8.5	Funções quadráticas de uma matriz	624
7.8.6	Funções matriciais de resíduos	626
7.8.7	Ponderação de observações e respostas	630
7.9	Derivadas de inversas, determinantes e log-determinantes	632
7.9.1	Diferencial da matriz inversa	632
7.9.2	Diferencial do determinante	634
7.9.3	Diferencial do log-determinante	636
7.9.4	Segunda variação do log-determinante	637
7.9.5	Traço envolvendo uma matriz inversa	639
7.9.6	Forma quadrática com matriz inversa	640
7.9.7	Crítério com log-determinante e traço	641
7.9.8	Parâmetros matriciais simétricos	645
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	645
7.10.1	Operador de vetorização	646
7.10.2	Produto de Kronecker	647
7.10.3	Identidade de vetorização	649

7.10.4	Aprofundamento: derivadas vetorizadas e parâmetros matriciais	650
7.11	Integração múltipla e mudança de variáveis	663
7.11.1	Integrais múltiplas	663
7.11.2	Teoremas de Tonelli e Fubini	664
7.11.3	Densidades multivariadas	666
7.11.4	Distribuições marginais	667
7.11.5	Esperanças de funções escalares, vetoriais e matriciais	669
7.11.6	Mudança de variáveis	670
7.11.7	Transformação de densidades	672
7.11.8	Transformações afins	673
7.11.9	Interpretação geométrica do determinante Jacobiano	675
7.11.10	Coordenadas polares	676
7.11.11	Transformações elipsoidais	677
7.11.12	Aprofundamento: diferenciação sob o sinal de integração	678
7.12	Aprofundamento: aplicações à estimação e à inferência	685
7.12.1	Log-verossimilhança e vetor escore	685
7.12.2	Informação observada e informação de Fisher	686
7.12.3	Newton–Raphson	688
7.12.4	Método do escore de Fisher	689
7.12.5	Expansão local de uma raiz do escore	691
7.12.6	Método delta	692
7.13	Síntese do capítulo	698
Exercícios de fixação do Módulo I		701
Parte I — Exercícios sem uso de computador		701
Parte II — Exercícios com uso do R		718
 II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Mul-		
tivariada		727
 8 Matrizes de covariâncias e correlações		728
8.1	Momentos, centralização e covariância	729
8.1.1	Vetor de médias e centralização	729
8.1.2	Momentos de segunda ordem	730
8.1.3	Covariância entre duas variáveis	732
8.2	Matriz de covariâncias populacional	735
8.2.1	Definição e interpretação dos elementos	735
8.2.2	Variâncias e covariâncias de combinações lineares	738
8.2.3	Propriedades estruturais e singularidade	740
8.3	Covariâncias entre vetores e transformações	746
8.3.1	Covariâncias cruzadas e vetores particionados	746
8.3.2	Transformações afins da média e da covariância	752

8.4	Padronização e matriz de correlações	756
8.4.1	Matriz de correlações populacional	756
8.4.2	Propriedades, escala e independência	760
8.5	Geometria e medidas globais da dispersão	766
8.5.1	Eixos espectrais e elipsoide de covariância	766
8.5.2	Variância total, variância generalizada e volume	774
8.6	Distância de Mahalanobis	780
8.6.1	Interpretação geométrica e espectral	780
8.6.2	Branqueamento e esferização	782
8.7	Representação descritiva a partir dos dados	788
8.7.1	Centralização, SQPC e matriz de covariâncias observada	789
8.7.2	Matriz de correlações e covariâncias cruzadas observadas	793
8.8	Decomposição da dispersão por grupos	798
8.8.1	Dispersão total, intragrupos e entre grupos	799
8.8.2	Somas de quadrados e traço das matrizes de dispersão	806
8.8.3	Esperança das matrizes de dispersão por grupos	809
8.8.4	Propriedades e limites de posto	814
8.9	Síntese do capítulo	817
9	Distribuição Normal Multivariada	824
9.1	Definição e construção	825
9.1.1	Definição por combinações lineares	825
9.1.2	Construção afim a partir do vetor normal padrão	827
9.1.3	Determinação pelos parâmetros	830
9.1.4	Aprofundamento: caso singular e suporte efetivo	832
9.2	Densidade no caso não singular	837
9.2.1	Função densidade e log-densidade	837
9.2.2	Superfícies de igual densidade	840
9.3	Transformações e distribuições marginais	842
9.3.1	Fechamento sob transformações afins	842
9.3.2	Combinações lineares	844
9.3.3	Distribuições marginais	846
9.3.4	Padronização marginal e branqueamento	847
9.4	Independência e distribuições condicionais	850
9.4.1	Independência entre blocos conjuntamente normais	850
9.4.2	Distribuição condicional	853
9.4.3	Média e covariância condicionais	857
9.4.4	Caso bivariado	859
9.5	Distância de Mahalanobis e regiões de probabilidade	861
9.5.1	Distribuição qui-quadrado	862
9.5.2	Regiões elipsoidais de probabilidade	864
9.5.3	Avaliação de uma observação fixa	866
9.5.4	Aprofundamento: caso singular	868

9.6	Comparação entre distribuições normais	871
9.6.1	Médias distintas e covariância comum	872
9.6.2	Covariâncias distintas	873
9.7	Alcance da hipótese de normalidade	874
9.7.1	Resultados que não exigem normalidade	875
9.7.2	Resultados específicos da família normal	876
9.7.3	Passagem do modelo populacional para a inferência	877
9.8	Síntese do capítulo	878
10	Estatísticas Amostrais e Estimação	881
10.1	Da população à amostra	882
10.1.1	Amostra aleatória multivariada	883
10.1.2	Matriz aleatória da amostra e matriz observada	885
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	886
10.2	Propriedades dos estimadores multivariados	889
10.2.1	Viés e variabilidade	889
10.2.2	Erro quadrático médio e funções de perda	891
10.2.3	Consistência	893
10.2.4	Eficiência	894
10.2.5	Suficiência	895
10.2.6	Equivariância	898
10.3	Métodos de estimação	901
10.3.1	Método dos momentos	901
10.3.2	Verossimilhança e máxima verossimilhança	904
10.3.3	Invariância da máxima verossimilhança	912
10.4	Estimação do vetor de médias	914
10.4.1	Vetor de médias amostrais	914
10.4.2	Não viesamento, variabilidade e erro quadrático médio	917
10.4.3	Combinações lineares	919
10.4.4	Consistência e equivariância	921
10.4.5	Variabilidade entre amostras	923
10.5	SQPC e estimação da matriz de covariâncias	924
10.5.1	SQPC como estatística aleatória	924
10.5.2	Decomposição em torno de um centro arbitrário	926
10.5.3	Esperança da SQPC	927
10.5.4	Estimador não viesado da matriz de covariâncias	929
10.5.5	Estimador com divisor n : momentos e máxima verossimilhança	931
10.5.6	Consistência dos estimadores de covariância	933
10.5.7	Transformações, posto e singularidade	935
10.6	Estimação de covariâncias cruzadas e correlações	938
10.6.1	Covariâncias cruzadas entre blocos	939
10.6.2	Matriz de correlações amostral	944
10.6.3	Propriedades estruturais	946

10.6.4	Transformações de localização e escala	950
10.7	Aprofundamento: dimensão, estabilidade e extensões da estimação	952
10.7.1	Relação entre p e n	953
10.7.2	Condicionamento e inversão	955
10.7.3	Regularização	957
10.7.4	Pseudoinversa e regularização	962
10.7.5	Sensibilidade e robustez	963
10.8	Exemplo integrado	964
10.9	Síntese do capítulo	972

III Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas 976

11	Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas	977
11.1	Problemas e estruturas das técnicas multivariadas	977
11.2	Formulação da Análise de Componentes Principais	977
11.3	Formulação da Análise Fatorial	977
11.4	Formulação da Análise de Agrupamentos	977
11.5	Formulação do Escalonamento Multidimensional	977
11.6	Formulação da Análise de Correspondência	977
11.7	Formulação da MANOVA	977
11.8	Formulação da Análise Discriminante	977
11.9	Formulação da Correlação Canônica	977
11.10	Formulação da Análise Conjunta	977

Referências 978

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual antecede os algoritmos, os procedimentos computacionais e a interpretação aplicada. Essa organização permite compreender por que cada técnica assume determinada forma e quais fundamentos são necessários para utilizá-la adequadamente.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;
- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;

- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar os problemas estatísticos que dão origem às principais técnicas multivariadas;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados
 Álgebra matricial aplicada
 Espaços vetoriais, bases e projeções
 Transformações lineares
 Autovalores, autovetores e decomposição espectral
 Decomposição em valores singulares
 Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações
 Distribuição normal multivariada
 Estatísticas amostrais e estimação
 Modelo linear multivariado e hipóteses lineares
 Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas
 Análise de Componentes Principais
 Análise Fatorial
 Análise de Agrupamentos
 Escalonamento Multidimensional
 Análise de Correspondência

Análise Multivariada de Variância
Análise Discriminante
Correlação Canônica
Análise Conjunta

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a verificação dos pressupostos e a interpretação dos resultados.

AValiação

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2018)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações com vetores, o produto interno, a norma, o ângulo, a distância euclidiana e o produto externo.

Convenções gerais de notação

As convenções abaixo indicam apenas como os objetos serão representados. Seus significados e propriedades serão definidos ao longo do capítulo.

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{.j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_{i.}^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;
- o símbolo $\top$ indica transposição;

- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$ representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{\cdot j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j .

Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Neste momento, o vetor é utilizado apenas para organizar as medidas. A comparação geométrica de variáveis com unidades diferentes exigirá atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i\cdot}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{\cdot j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i\cdot}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{\cdot j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i\cdot}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_i^\top$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_{\cdot j}$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. A representação dos vetores em $\mathbb{R}^p$ será desenvolvida na próxima seção.

1.2 O espaço $\mathbb{R}^p$

Os valores observados de p variáveis quantitativas podem ser organizados em um vetor com p componentes. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço $\mathbb{R}^p$). O espaço $\mathbb{R}^p$ é o conjunto

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ no qual são representadas as unidades observacionais será denominado **espaço das observações**. Cada vetor representa uma unidade, e cada componente corresponde a uma variável.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;
- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.3 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{\cdot 1} \ \mathbf{x}_{\cdot 2} \ \cdots \ \mathbf{x}_{\cdot p}].$$

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = \begin{bmatrix} 5 & 7 \end{bmatrix}.$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.3.1 Espaço das observações e espaço das variáveis

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{.j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

No **espaço das observações**, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às variáveis.

No **espaço das variáveis**, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{.j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.4 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.4.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.4.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

A norma do vetor resultante satisfaz

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;




Figura 1.3: Soma de vetores pela regra do paralelogramo.

- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.4.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

As operações anteriores produzem novos vetores ou novas variáveis. A próxima operação tem natureza diferente: o produto interno associa dois vetores a um número real e permite construir as noções de comprimento, ângulo, ortogonalidade e distância.

1.5 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

1.5.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. *Linearidade no segundo argumento*

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. *Não negatividade*

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. *Positividade definida*

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0}.$$

1.5.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.

Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.5.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Meyer, 2023)

Comprovação. Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha \langle \mathbf{x}, \mathbf{y} \rangle - \alpha \langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2 \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha \langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2 \|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

Substituindo o valor escolhido para α ,

$$\begin{aligned}
0 &\leq \|\mathbf{x}\|^2 - 2 \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \langle \mathbf{x}, \mathbf{y} \rangle \\
&\quad + \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \right)^2 \|\mathbf{y}\|^2 \\
&= \|\mathbf{x}\|^2 - \frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2}.
\end{aligned}$$

Logo,

$$\frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2} \leq \|\mathbf{x}\|^2.$$

Como $\|\mathbf{y}\|^2 > 0$, podemos multiplicar os dois lados por esse valor e obter

$$\langle \mathbf{x}, \mathbf{y} \rangle^2 \leq \|\mathbf{x}\|^2 \|\mathbf{y}\|^2.$$

Tomando a raiz quadrada dos dois lados,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Resta examinar quando ocorre a igualdade. Na construção anterior, a igualdade é satisfeita se, e somente se,

$$\langle \mathbf{x} - \alpha \mathbf{y}, \mathbf{x} - \alpha \mathbf{y} \rangle = 0.$$

Pela positividade definida do produto interno, isso ocorre se, e somente se,

$$\mathbf{x} - \alpha \mathbf{y} = \mathbf{0},$$

ou seja,

$$\mathbf{x} = \alpha \mathbf{y}.$$

Portanto, quando $\mathbf{y} \neq \mathbf{0}$, a igualdade ocorre se, e somente se, $\mathbf{x}$ é múltiplo escalar de $\mathbf{y}$.

Reunindo os dois casos, concluímos que a igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. $\square$

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.5.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.5.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as observações.




Figura 1.6: Os vetores x e y são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

A padronização e outras geometrias serão estudadas nos capítulos posteriores.

1.5.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer, 2023)

Comprovação. Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2. \end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2. \end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

□

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.5.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do **produto externo**.

Definição 1.14 (Produto externo). Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, o **produto externo** de $\mathbf{x}$ e $\mathbf{y}$, denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

é definido como a matriz em $\mathbb{R}^{p \times q}$

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$[\text{ext}(\mathbf{x}, \mathbf{y})]_{ij} = x_i y_j.$$

O resultado do produto externo é uma matriz.

A estrutura do produto externo pode ser observada por suas colunas. Como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = [y_1 \mathbf{x} \quad y_2 \mathbf{x} \quad \cdots \quad y_q \mathbf{x}],$$

cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

O produto externo é

$$\begin{aligned} \text{ext}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} 1(3) & 1(-1) & 1(4) \\ 2(3) & 2(-1) & 2(4) \end{bmatrix} \\ &= \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}. \end{aligned}$$

O resultado possui dimensão 2×3 , correspondente às dimensões de $\mathbf{x}$ e $\mathbf{y}$, respectivamente.

O produto interno e o produto externo produzem objetos de naturezas diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz. No próximo capítulo, após a definição do produto matricial, o produto externo será relacionado às operações entre matrizes e vetores, e suas propriedades matriciais serão desenvolvidas.

1.6 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos. O próximo capítulo desenvolverá as operações e as propriedades matriciais necessárias para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo será retomado como um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas bilineares e quadráticas. As seções finais introduzem matrizes particionadas e complemento de Schur, preparando estruturas que serão utilizadas posteriormente na formulação de resultados multivariados.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{r \times s}$. As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \iff n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. Comutatividade

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. Associatividade

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. Existência do elemento neutro

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A},$$

em que $\mathbf{0}_{n \times p}$ é o elemento neutro de dimensão $n \times p$:

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

4. Existência do elemento oposto

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$ e $\alpha, \beta \in \mathbb{R}$. A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. *Elemento neutro da multiplicação escalar*

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial, apresentado a seguir, utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. A definição a seguir reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelas linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelas colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_1 - \mathbf{a}_2 \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a seguinte matriz em $\mathbb{R}^{n \times r}$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

i Produto interno e produto externo como produtos matriciais

As operações entre vetores apresentadas anteriormente também podem ser expressas por meio do produto matricial.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno** pode ser escrito como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Como

$$\mathbf{x}^\top \in \mathbb{R}^{1 \times p} \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^{p \times 1},$$

o produto possui dimensão 1×1 e corresponde a um escalar:

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

De forma semelhante, para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

o **produto externo**, anteriormente denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

pode ser escrito como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \mathbf{xy}^\top.$$

Nesse caso,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \text{e} \quad \mathbf{y}^\top \in \mathbb{R}^{1 \times q},$$

de modo que

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

Portanto, a ordem e a orientação dos vetores determinam objetos diferentes:

$$\mathbf{x}^\top \mathbf{y} \text{ é um escalar}$$

enquanto

$$\mathbf{xy}^\top \text{ é uma matriz.}$$

Exemplo 2.5 (Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

A matriz

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 3 & 6 & 4 \\ 1 & 5 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{bmatrix} \in \mathbb{R}^{3 \times 4}$$

é obtida escrevendo as colunas de $\mathbf{X}$ como linhas. A operação de transposição e suas propriedades serão formalizadas adiante.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{X}\mathbf{a} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

Considere agora o produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}.$$

Esse produto possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \langle \mathbf{x}_{\cdot 1}, \mathbf{x}_{\cdot 2} \rangle = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \langle \mathbf{x}_1, \mathbf{x}_2 \rangle = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos serão retomados no estudo de matrizes de Gram, produtos cruzados, covariâncias e decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. Associatividade

$$(\mathbf{A}\mathbf{B})\mathbf{C} = \mathbf{A}(\mathbf{B}\mathbf{C}).$$

2. Distributividade à esquerda

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbf{B} + \mathbf{A}\mathbf{C}.$$

3. Distributividade à direita

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{A}\mathbf{C} + \mathbf{B}\mathbf{C}.$$

4. Compatibilidade com a multiplicação por escalar

Para $\alpha \in \mathbb{R}$,

$$(\alpha \mathbf{A})\mathbf{B} = \alpha(\mathbf{A}\mathbf{B}) = \mathbf{A}(\alpha \mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{A}\mathbf{B}$ e $\mathbf{B}\mathbf{A}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{A}\mathbf{B} \neq \mathbf{B}\mathbf{A}.$$

Exemplo 2.6 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja $\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}$. A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

Proposição 2.4 (Propriedades da transposição). *Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes com dimensões compatíveis e seja $\alpha \in \mathbb{R}$. Então,*

1. $(\mathbf{A}^\top)^\top = \mathbf{A}$,
2. $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$,
3. $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ e
4. $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.
5. Em particular, para vetores $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, $(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top$.

A última propriedade mostra que a transposição de um produto inverte a ordem dos fatores. Em particular, ela será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

2.2.2 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x} \in \mathbb{R}^p$, tem-se

$$(\mathbf{x}\mathbf{x}^\top)^\top = \mathbf{x}\mathbf{x}^\top.$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.8 (Matriz antissimétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Aprofundamento

A decomposição seguinte mostra que toda matriz quadrada pode ser separada em uma parte simétrica e uma parte antissimétrica. A parte simétrica será particularmente importante no estudo das formas quadráticas.

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser escrita de maneira única como*

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn; Johnson, 2013)

Comprovação. A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas. □

Exemplo 2.10 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.3 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada. Apesar de sua definição simples, essa operação permite representar de forma compacta somas de quadrados, produtos internos, formas quadráticas e diversas expressões matriciais utilizadas em Estatística Multivariada.

Definição 2.9 (Traço de uma matriz). Seja $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$. O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Cálculo do traço). Para $\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix}$, tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Proposição 2.5 (Propriedades básicas do traço). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha, \beta \in \mathbb{R}$. Então,*

1. *Linearidade:*

$$\text{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{tr}(\mathbf{A}) + \beta \text{tr}(\mathbf{B}).$$

2. *Invariância à transposição:*

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

3. *Traço da matriz identidade:*

$$\text{tr}(\mathbf{I}_n) = n.$$

Consequentemente,

$$\text{tr}(\alpha \mathbf{I}_n) = \alpha n.$$

4. *Propriedade cíclica:* se $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$, então

$$\text{tr}(\mathbf{CD}) = \text{tr}(\mathbf{DC}).$$

(Harville, 1997)

A primeira propriedade mostra que o traço é uma operação linear. A segunda decorre do fato de que a transposição não modifica os elementos da diagonal principal. A quarta permite reorganizar produtos matriciais dentro do traço, desde que seja preservada a ordem cíclica dos fatores.

A propriedade cíclica pode ser demonstrada diretamente a partir da definição do produto matricial.

Comprovação. Como $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$,

$$\text{tr}(\mathbf{CD}) = \sum_{i=1}^n (\mathbf{CD})_{ii} = \sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji}.$$

Trocando a ordem das somas,

$$\sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji} = \sum_{j=1}^p \sum_{i=1}^n d_{ji} c_{ij} = \text{tr}(\mathbf{DC}).$$

□

Proposição 2.6 (Ciclicidade para vários fatores). *Para matrizes com dimensões compatíveis, os fatores de um produto podem ser deslocados ciclicamente dentro do traço. Por exemplo,*

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A propriedade é **cíclica**. Portanto, a ordem relativa dos fatores é preservada. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Proposição 2.7 (Traço, produto interno e produto externo). *Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\text{tr}(\mathbf{xy}^\top) = \mathbf{y}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Como $\mathbf{xy}^\top = \text{ext}(\mathbf{x}, \mathbf{y})$, também podemos escrever

$$\text{tr}[\text{ext}(\mathbf{x}, \mathbf{y})] = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Em particular,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Essa propriedade estabelece uma ligação direta entre o traço e as operações vetoriais introduzidas anteriormente.

Proposição 2.8 (Traço de produtos matriciais). *Para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$,*

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ij}.$$

Consequentemente,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

Pela propriedade cíclica,

$$\operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \operatorname{tr}(\mathbf{A} \mathbf{A}^\top).$$

Portanto, o traço permite representar a soma dos quadrados de todos os elementos de uma matriz. Essa expressão será retomada posteriormente no estudo da norma de Frobenius, de matrizes de produtos cruzados e de decomposições matriciais.

Exemplo 2.12 (Traço de produtos matriciais). Considere $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} 1 & 3 \\ -2 & 3 \end{bmatrix}$.

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -9 & 9 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} -1 & 13 \\ -7 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

seus traços são iguais:

$$\operatorname{tr}(\mathbf{AB}) = 0 + 9 = 9$$

e

$$\operatorname{tr}(\mathbf{BA}) = -1 + 10 = 9.$$

O traço será utilizado repetidamente na representação de somas de quadrados, produtos cruzados, variâncias totais, formas quadráticas e expressões de verossimilhança. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.10 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos podem ser representados pelo **delta de Kronecker**,

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

de modo que

$$(\mathbf{I}_n)_{ij} = \delta_{ij}.$$

O delta de Kronecker será utilizado posteriormente para representar de forma compacta relações de ortogonalidade e ortonormalidade.

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.11 (Matriz inversa). Uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.2 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

Comprovação. Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única. □

Exemplo 2.14 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.3 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

Comprovação. Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

□

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.12 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.13 (Determinante). Para uma matriz de ordem um,

$$\mathbf{A} = [a_{11}],$$

define-se

$$\det(\mathbf{A}) = a_{11}.$$

Para $n \geq 2$, seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O determinante de $\mathbf{A}$ pode ser calculado recursivamente pela expansão em cofatores de qualquer linha fixa i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna fixa j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Em cada termo, o cofator C_{ij} envolve o determinante de uma matriz de ordem $n - 1$. O caso de ordem um encerra a definição recursiva.

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e rea-

lizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais, que serão estudadas posteriormente.

Proposição 2.9 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.4 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere uma matriz quadrada

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{n \times n}.$$

As colunas de $\mathbf{A}$ podem ser interpretadas como vetores em $\mathbb{R}^n$. Esses vetores determinam uma região geométrica cuja medida depende de suas direções e comprimentos.

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

corresponde à medida do paralelepípedo determinado pelas colunas de $\mathbf{A}$:

- em uma dimensão, corresponde a um comprimento;
- em duas dimensões, corresponde à área do paralelogramo determinado pelas duas colunas;
- em três dimensões, corresponde ao volume do paralelepípedo determinado pelas três colunas;
- em $\mathbb{R}^n$, corresponde ao volume n -dimensional determinado pelas n colunas.

Como a matriz identidade $\mathbf{I}_n$ possui determinante igual a 1, suas colunas determinam uma região de volume unitário. Assim, $|\det(\mathbf{A})|$ também pode ser interpretado como o fator pelo qual esse volume unitário é ampliado ou reduzido quando os vetores canônicos são substituídos pelas colunas de $\mathbf{A}$.

O sinal do determinante acrescenta informação sobre a orientação dos vetores:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é nulo.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

No último caso, as colunas não determinam todas as direções necessárias para formar um volume n -dimensional. Em $\mathbb{R}^2$, por exemplo, duas colunas alinhadas formam uma região de área zero; em $\mathbb{R}^3$, três colunas contidas em um mesmo plano formam uma região de volume zero.

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.

2.3.5 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.14 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura será importante posteriormente nas decomposições matriciais, em que uma matriz poderá ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.5 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer, 2023)

Exemplo 2.18 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.15 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n. \end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.6 (Existência e quantidade de soluções). *Sejam*

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- a solução é única se

$$\text{posto}(\mathbf{A}) = p;$$

- existem infinitas soluções se

$$\text{posto}(\mathbf{A}) < p.$$

Definição 2.16 (Sistema linear homogêneo). Um **sistema linear homogêneo** é um sistema da forma

$$\mathbf{A}\mathbf{x} = \mathbf{0},$$

em que

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{0} \in \mathbb{R}^n.$$

Portanto, um sistema homogêneo é um caso particular de sistema linear no qual todos os termos independentes são iguais a zero.

Todo sistema homogêneo possui pelo menos a **solução trivial**

$$\mathbf{x} = \mathbf{0}.$$

Dependendo da matriz $\mathbf{A}$, também podem existir **soluções não triviais**, isto é, soluções para as quais

$$\mathbf{x} \neq \mathbf{0}.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.19 (Sistema com solução única). Considere

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3. \end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.20 (Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4. \end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5. \end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.3.7 Aprofundamento: pseudoinversa

Leitura de aprofundamento

A pseudoinversa permite estender a resolução de sistemas lineares para matrizes retangulares ou singulares. Sua construção será desenvolvida no capítulo sobre decomposição em valores singulares. Nesta seção, são apresentadas sua definição e suas principais consequências.

Definição 2.17 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Harville, 1997)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+\mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{AA}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção de $\mathbf{A}^+$, sua interpretação por projeções e sua relação com o posto serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.18 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.21 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.7 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Comprovação. Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

□

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.19 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag} \left(\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} \right).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1x_1 \\ d_2x_2 \\ \vdots \\ d_nx_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.22 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.20 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$$\mathbf{U}^\top \text{ é triangular inferior.}$$

Da mesma forma,

$$\mathbf{L}^\top \text{ é triangular superior.}$$

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.23 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Aprofundamento: sistemas triangulares

Leitura de aprofundamento

Os sistemas triangulares mostram como a estrutura de uma matriz pode simplificar a resolução de equações. Esses procedimentos também aparecem nas decomposições matriciais estudadas posteriormente.

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.24 (Sistema triangular superior). Considere o sistema

$$\begin{aligned} x_1 + 2x_2 - x_3 &= 4, \\ 2x_2 + 3x_3 &= 7, \\ x_3 &= 1. \end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{L}\mathbf{x} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar e são lineares em cada argumento separadamente. Quando uma forma bilinear é avaliada utilizando o mesmo vetor em seus dois argumentos, obtém-se uma função de um único vetor, denominada forma quadrática.

Essa relação permite conectar propriedades das matrizes, como simetria e positividade, a expressões escalares que aparecem frequentemente na análise multivariada, entre elas produtos internos, normas, variâncias e distâncias.

2.5.1 Formas bilineares

Definição 2.21 (Forma bilinear). Uma função

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **forma bilinear** quando é linear separadamente em cada argumento.

Isso significa que, para quaisquer

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e quaisquer

$$\beta \in \mathbb{R},$$

tem-se

$$g(\mathbf{x} + \beta \mathbf{z}, \mathbf{y}) = g(\mathbf{x}, \mathbf{y}) + \beta g(\mathbf{z}, \mathbf{y})$$

e

$$g(\mathbf{x}, \mathbf{z} + \beta \mathbf{y}) = g(\mathbf{x}, \mathbf{z}) + \beta g(\mathbf{x}, \mathbf{y}).$$

A bilinearidade significa, portanto, que, mantendo um dos argumentos fixo, a forma bilinear é uma função linear do outro argumento.

Fixado $\mathbf{y} \in \mathbb{R}^p$, a função

$$\mathbf{x} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{x}$. Analogamente, fixado $\mathbf{x} \in \mathbb{R}^p$, a função

$$\mathbf{y} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{y}$.

Um caso particularmente importante para a estatística são as formas bilineares simétricas.

Definição 2.22 (Forma bilinear simétrica). Uma forma bilinear

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **simétrica** quando

$$g(\mathbf{x}, \mathbf{y}) = g(\mathbf{y}, \mathbf{x})$$

para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

Exemplo 2.25 (Produto interno como forma bilinear simétrica). O produto interno usual em $\mathbb{R}^p$,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle,$$

é um exemplo de forma bilinear simétrica, pois,

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle,$$

ou, equivalentemente,

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}.$$

Nem toda forma bilinear é simétrica.

Exemplo 2.26 (Bilinearidade e ausência de simetria). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$$

e os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

A função

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é dada por

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2y_1 + y_2 \\ -y_1 + 3y_2 \end{bmatrix} \\ &= 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2. \end{aligned}$$

Para verificar a linearidade no primeiro argumento, sejam $\mathbf{x}_1, \mathbf{x}_2, \mathbf{y} \in \mathbb{R}^2$ e $\beta \in \mathbb{R}$. Então,

$$\begin{aligned} g(\mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) &= (\mathbf{x}_1 + \beta \mathbf{x}_2)^\top \mathbf{A} \mathbf{y} \\ &= \mathbf{x}_1^\top \mathbf{A} \mathbf{y} + \beta \mathbf{x}_2^\top \mathbf{A} \mathbf{y} \\ &= g(\mathbf{x}_1, \mathbf{y}) + \beta g(\mathbf{x}_2, \mathbf{y}). \end{aligned}$$

Analogamente, para $\mathbf{x}, \mathbf{y}_1, \mathbf{y}_2 \in \mathbb{R}^2$,

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}_1 + \beta \mathbf{y}_2) &= \mathbf{x}^\top \mathbf{A} (\mathbf{y}_1 + \beta \mathbf{y}_2) \\ &= \mathbf{x}^\top \mathbf{A} \mathbf{y}_1 + \beta \mathbf{x}^\top \mathbf{A} \mathbf{y}_2 \\ &= g(\mathbf{x}, \mathbf{y}_1) + \beta g(\mathbf{x}, \mathbf{y}_2). \end{aligned}$$

Portanto, g é linear em cada argumento separadamente e, assim, é uma forma bilinear.

Para verificar se a forma bilinear é simétrica, invertem-se os dois argumentos. Tem-se

$$g(\mathbf{y}, \mathbf{x}) = 2x_1y_1 - x_1y_2 + x_2y_1 + 3x_2y_2.$$

Por outro lado,

$$g(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2.$$

As duas expressões diferem nos termos cruzados. Portanto, em geral,

$$g(\mathbf{x}, \mathbf{y}) \neq g(\mathbf{y}, \mathbf{x}),$$

e a forma bilinear não é simétrica.

De modo geral, uma forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é simétrica se, e somente se, sua matriz representante é simétrica, isto é, $\mathbf{A} = \mathbf{A}^\top$.

Uma forma bilinear também pode ser avaliada utilizando o mesmo vetor em seus dois argumentos. Assim, em vez de considerar

$$g(\mathbf{x}, \mathbf{y}),$$

podemos considerar

$$g(\mathbf{x}, \mathbf{x}).$$

Essa avaliação produz uma função de um único vetor e conduz às formas quadráticas.

2.5.2 Formas quadráticas

Definição 2.23 (Forma quadrática). Seja

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma forma bilinear. A função

$$Q : \mathbb{R}^p \longrightarrow \mathbb{R}$$

definida por

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x})$$

é denominada **forma quadrática** associada a g .

Se a forma bilinear possui representação matricial

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p.$$

A forma bilinear depende de dois argumentos e é linear em cada um deles separadamente. A forma quadrática, por sua vez, depende de um único argumento e, em geral, não é uma função linear desse vetor.

De fato, para qualquer $\alpha \in \mathbb{R}$,

$$\begin{aligned} Q(\alpha \mathbf{x}) &= g(\alpha \mathbf{x}, \alpha \mathbf{x}) \\ &= \alpha^2 g(\mathbf{x}, \mathbf{x}) \\ &= \alpha^2 Q(\mathbf{x}). \end{aligned}$$

Assim,

$$Q(\alpha \mathbf{x}) = \alpha^2 Q(\mathbf{x}).$$

A expressão quadrática pode ser interpretada como a avaliação da forma bilinear sobre a diagonal do produto cartesiano,

$$\{(\mathbf{x}, \mathbf{x}) : \mathbf{x} \in \mathbb{R}^p\} \subset \mathbb{R}^p \times \mathbb{R}^p.$$

O produto interno fornece um exemplo imediato dessa construção.

Exemplo 2.27 (Produto interno e norma ao quadrado). Considere a forma bilinear dada pelo produto interno usual,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Ao utilizar o mesmo vetor nos dois argumentos,

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x}) = \langle \mathbf{x}, \mathbf{x} \rangle.$$

Pela definição da norma euclidiana,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2.$$

Portanto,

$$Q(\mathbf{x}) = \|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

A matriz representante dessa forma quadrática é

$$\mathbf{I}_p.$$

Em geral, se

$$\mathbf{A} = (a_{ij})_{p \times p},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j. \quad (2.1)$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= ax_1^2 + (b+c)x_1x_2 + dx_2^2. \end{aligned}$$

Esse desenvolvimento mostra uma diferença importante entre formas bilineares e formas quadráticas.

Na forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

os elementos a_{ij} e a_{ji} podem produzir contribuições distintas porque os dois vetores não precisam ser iguais.

Na forma quadrática

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

os termos fora da diagonal aparecem combinados. No caso bidimensional, por exemplo, b e c aparecem somente por meio da soma

$$b + c.$$

Consequentemente, a matriz que aparece em uma representação

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

não é necessariamente única quando matrizes não simétricas são admitidas. Matrizes que diferem apenas por uma parcela antissimétrica produzem a mesma forma quadrática.

Entretanto, toda forma quadrática possui uma única matriz simétrica que a representa. Essa propriedade é apresentada na proposição seguinte.

Proposição 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Então $\mathbf{S}$ é simétrica e, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Além disso, $\mathbf{S}$ é a única matriz simétrica que representa essa forma quadrática.

Comprovação. A matriz $\mathbf{A}$ pode ser escrita como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica.

De fato,

$$\mathbf{S}^\top = \mathbf{S}$$

e

$$\mathbf{K}^\top = -\mathbf{K}.$$

Assim,

$$\begin{aligned}\mathbf{x}^\top \mathbf{A} \mathbf{x} &= \mathbf{x}^\top (\mathbf{S} + \mathbf{K}) \mathbf{x} \\ &= \mathbf{x}^\top \mathbf{S} \mathbf{x} + \mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

O termo

$$\mathbf{x}^\top \mathbf{K} \mathbf{x}$$

é um escalar. Portanto,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = (\mathbf{x}^\top \mathbf{K} \mathbf{x})^\top.$$

Utilizando a transposição do produto,

$$\begin{aligned}\mathbf{x}^\top \mathbf{K} \mathbf{x} &= \mathbf{x}^\top \mathbf{K}^\top \mathbf{x} \\ &= -\mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

Logo,

$$2\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0$$

e, conseqüentemente,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0.$$

Portanto,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Resta mostrar a unicidade da representação simétrica.

Suponha que $\mathbf{S}_1$ e $\mathbf{S}_2$ sejam duas matrizes simétricas que representem a mesma forma quadrática. Então,

$$\mathbf{x}^\top \mathbf{S}_1 \mathbf{x} = \mathbf{x}^\top \mathbf{S}_2 \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Definindo

$$\mathbf{D} = \mathbf{S}_1 - \mathbf{S}_2,$$

a matriz $\mathbf{D}$ também é simétrica e satisfaz

$$\mathbf{x}^\top \mathbf{D} \mathbf{x} = 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\begin{aligned} 0 &= (\mathbf{x} + \mathbf{y})^\top \mathbf{D} (\mathbf{x} + \mathbf{y}) \\ &= \mathbf{x}^\top \mathbf{D} \mathbf{x} + \mathbf{x}^\top \mathbf{D} \mathbf{y} + \mathbf{y}^\top \mathbf{D} \mathbf{x} + \mathbf{y}^\top \mathbf{D} \mathbf{y}. \end{aligned}$$

Como $\mathbf{D}$ é simétrica,

$$\mathbf{y}^\top \mathbf{D} \mathbf{x} = \mathbf{x}^\top \mathbf{D} \mathbf{y},$$

e os termos quadráticos são nulos. Assim,

$$2\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Logo,

$$\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Em particular, tomando os vetores da base canônica,

$$\mathbf{x} = \mathbf{e}_i \quad \text{e} \quad \mathbf{y} = \mathbf{e}_j,$$

obtem-se

$$\mathbf{e}_i^\top \mathbf{D} \mathbf{e}_j = d_{ij} = 0$$

para todos i e j .

Portanto,

$$\mathbf{D} = \mathbf{0},$$

o que implica

$$\mathbf{S}_1 = \mathbf{S}_2.$$

□

Assim, embora uma forma quadrática possa possuir diferentes representações por matrizes não simétricas, sua representação por uma matriz simétrica é única.

Por essa razão, no estudo de formas quadráticas, pode-se trabalhar sem perda de generalidade com matrizes simétricas.

Observe que essa propriedade é específica das formas quadráticas. Para uma forma bilinear geral,

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

a parte antissimétrica de $\mathbf{A}$ pode contribuir para o valor da expressão quando

$$\mathbf{x} \neq \mathbf{y}.$$

Quando os dois argumentos coincidem, essa contribuição desaparece.

Exemplo 2.28 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

A forma quadrática associada a $\mathbf{A}$ é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então,

$$Q(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuada os produtos,

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtem-se

$$\begin{aligned} Q(\mathbf{x}) &= 2(1)^2 + 2(1)(2) + 3(2)^2 \\ &= 2 + 4 + 12 \\ &= 18. \end{aligned}$$

2.5.3 Positividade

Como toda forma quadrática pode ser representada por uma única matriz simétrica, propriedades importantes da forma quadrática podem ser estudadas a partir dos valores assumidos por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com $\mathbf{A}$ simétrica.

A classificação em positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida depende do sinal assumido por essa expressão.

Definição 2.24 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica e considere a forma quadrática

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \succ \mathbf{0};$$

- **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \succeq \mathbf{0};$$

- **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \prec \mathbf{0};$$

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \preceq \mathbf{0};$$

- **indefinida** quando existem vetores não nulos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Para matrizes indefinidas, não se utiliza uma relação de ordem do tipo $\mathbf{A} \succeq \mathbf{0}$ ou $\mathbf{A} \preceq \mathbf{0}$.

As notações $\succ$, $\succeq$, $\prec$ e $\preceq$ expressam a ordem de Löwner para matrizes simétricas. Em particular,

$$\begin{aligned} \mathbf{A} \succ \mathbf{0} &\iff \mathbf{A} \text{ é positiva definida,} \\ \mathbf{A} \succeq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida positiva,} \\ \mathbf{A} \prec \mathbf{0} &\iff \mathbf{A} \text{ é negativa definida,} \\ \mathbf{A} \preceq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida negativa.} \end{aligned}$$

produto interno usual fornece um exemplo imediato de forma quadrática associada a uma matriz positiva definida.

Como

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \|\mathbf{x}\|^2,$$

tem-se

$$Q(\mathbf{x}) > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Portanto, a matriz identidade

$$\mathbf{I}_p$$

é positiva definida.

Outro exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo.

Para

$$\mathbf{x}, \mathbf{z} \in \mathbb{R}^p,$$

considere

$$\mathbf{xx}^\top.$$

Então,

$$\begin{aligned}\mathbf{z}^\top (\mathbf{xx}^\top) \mathbf{z} &= (\mathbf{z}^\top \mathbf{x}) (\mathbf{x}^\top \mathbf{z}) \\ &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{xx}^\top$$

é semidefinida positiva.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\text{rank}(\mathbf{xx}^\top) = 1.$$

Assim, quando $p > 1$, existem vetores não nulos $\mathbf{z}$ ortogonais a $\mathbf{x}$. Para esses vetores,

$$\mathbf{x}^\top \mathbf{z} = 0$$

e, portanto,

$$\mathbf{z}^\top (\mathbf{xx}^\top) \mathbf{z} = 0.$$

Logo, para $p > 1$ e $\mathbf{x} \neq \mathbf{0}$, a matriz

$$\mathbf{xx}^\top$$

é semidefinida positiva, mas não positiva definida.

Esse tipo de matriz terá importância particular na construção das matrizes de covariâncias, que envolvem somas de produtos externos de vetores de desvios.

Exemplo 2.29 (Classificação de formas quadráticas). Considere inicialmente

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

Como

$$2x_1^2 + 3x_2^2 > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0},$$

a matriz $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

Portanto, $\mathbf{B}$ é semidefinida positiva.

Entretanto, para vetores não nulos da forma

$$\mathbf{x} = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}, \quad x_2 \neq 0,$$

tem-se

$$Q(\mathbf{x}) = 0.$$

Assim, $\mathbf{B}$ não é positiva definida.

Finalmente, considere

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

A forma quadrática associada é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{x}) = 1 > 0.$$

Por outro lado, para

$$\mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{y}) = -1 < 0.$$

Portanto, a forma quadrática assume valores positivos e negativos, e a matriz $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérboles. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Aprofundamento: matrizes particionadas e complemento de Schur

Leitura de aprofundamento

Esta seção pode ser utilizada como referência nos capítulos posteriores. As operações por blocos e o complemento de Schur serão retomados no estudo de covariâncias particionadas, distribuições condicionais, regressão entre blocos e correlação canônica.

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.25 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.30 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.31 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

Matrizes particionadas permitem tratar uma matriz de grande dimensão a partir de blocos menores. Em vários problemas, é útil eliminar um desses blocos e estudar a estrutura que permanece no outro. O **complemento de Schur** é a matriz que surge naturalmente nesse processo de eliminação.

Definição 2.26 (Complemento de Schur). Considere a matriz quadrada particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Os blocos diagonais $\mathbf{A}_{11}$ e $\mathbf{A}_{22}$ são quadrados. Quando um deles é invertível, podemos utilizá-lo para eliminar os efeitos dos blocos fora da diagonal.

Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, enquanto $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

A expressão pode ser compreendida como uma correção do bloco diagonal original. Por exemplo,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

parte de $\mathbf{A}_{11}$ e retira a parcela associada às relações que passam pelo segundo bloco. Essa interpretação ficará mais clara ao observarmos a eliminação por blocos.

2.6.6 Eliminação por blocos

Suponha que $\mathbf{A}_{22}$ seja invertível. Queremos eliminar o bloco $\mathbf{A}_{12}$, isto é, produzir uma matriz equivalente cuja posição superior direita seja ocupada por uma matriz nula.

Para isso, considere

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Multiplicando $\mathbf{E}$ por $\mathbf{A}$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Efetuando o produto por blocos,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{A}_{12} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{22} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Como $\mathbf{A}_{22}^{-1}\mathbf{A}_{22} = \mathbf{I}_q$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Portanto, o complemento de Schur aparece exatamente como o bloco que permanece depois da eliminação de $\mathbf{A}_{12}$ utilizando $\mathbf{A}_{22}$.

Como

$$\mathbf{E}^{-1} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix},$$

também podemos escrever

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Essa fatoração é consequência direta da eliminação por blocos.

Um caso simples ajuda a reconhecer a estrutura. Para uma matriz 2×2 ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

com $d \neq 0$, o complemento de Schur de d é

$$a - bd^{-1}c.$$

Como veremos a seguir,

$$\det(\mathbf{A}) = d(a - bd^{-1}c) = ad - bc,$$

recuperando a expressão usual do determinante de uma matriz 2×2 .

Exemplo 2.32 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Como $\mathbf{A}_{22} = \mathbf{I}_2$, tem-se $\mathbf{A}_{22}^{-1} = \mathbf{I}_2$. Logo,

$$\begin{aligned} \mathbf{A}_{11.2} &= \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.7 Determinante de uma matriz particionada

A eliminação por blocos mostra uma das principais utilidades do complemento de Schur: calcular o determinante de uma matriz particionada utilizando determinantes de matrizes menores.

Teorema 2.8 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd; Vandenberghe, 2004)

Comprovação. Suponha que $\mathbf{A}_{22}$ seja invertível. Pela eliminação por blocos apresentada anteriormente,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Como $\mathbf{E}$ é triangular por blocos e possui matrizes identidade na diagonal,

$$\det(\mathbf{E}) = 1.$$

Portanto,

$$\det(\mathbf{EA}) = \det(\mathbf{A}).$$

A matriz $\mathbf{EA}$ também é triangular por blocos. Assim,

$$\det(\mathbf{EA}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

A segunda identidade é obtida de forma análoga, eliminando o bloco $\mathbf{A}_{21}$ a partir de $\mathbf{A}_{11}$. $\square$

No Exemplo 2.32,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = 3.$$

Consequentemente,

$$\det(\mathbf{A}) = 3.$$

2.6.8 Inversão em blocos

O complemento de Schur também permite obter a inversa de uma matriz particionada. A origem da expressão pode ser entendida a partir da mesma fatoração obtida pela eliminação por blocos.

Se $\mathbf{A}_{22}$ é invertível,

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{11.2}$ também é invertível, os dois fatores são invertíveis. Como a inversa de um produto inverte a ordem dos fatores, a inversa de $\mathbf{A}$ pode ser construída a partir das inversas dessas duas matrizes mais simples.

Proposição 2.11 (Inversa em blocos). *Considere a matriz particionada*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e o complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1} & \mathbf{B}_{22} \end{bmatrix},$$

com o bloco $(2, 2)$ dado por

$$\mathbf{B}_{22} = \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}.$$

(Boyd; Vandenberghe, 2004)

A expressão pode parecer extensa, mas sua estrutura é determinada pela eliminação anterior. O bloco $\mathbf{A}_{11.2}^{-1}$ representa a parte de $\mathbf{A}_{11}$ que permanece depois da eliminação do segundo bloco.

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.9 Positividade e complemento de Schur

Outra aplicação importante ocorre em matrizes simétricas. O complemento de Schur permite verificar a definição positiva de uma matriz particionada por meio de matrizes de menor dimensão.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^{\top} & \mathbf{A}_{22} \end{bmatrix}.$$

Para estudar se $\mathbf{A}$ é positiva definida, consideramos sua forma quadrática. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y}.$$

Quando $\mathbf{A}_{22}$ é invertível, os termos envolvendo $\mathbf{y}$ podem ser reorganizados completando a forma quadrática:

$$\begin{aligned} & \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top) \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

O primeiro termo contém exatamente o complemento de Schur de $\mathbf{A}_{22}$.

Teorema 2.9 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então $\mathbf{A}$ é positiva definida se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Boyd; Vandenberghe, 2004)

Comprovação. Pela decomposição da forma quadrática,

$$\begin{aligned} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} &= \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

Suponha inicialmente que $\mathbf{A}_{11.2}$ e $\mathbf{A}_{22}$ sejam positivas definidas.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Logo, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela da decomposição é igual a zero. Portanto,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0.$$

Assim, $\mathbf{A}_{11 \cdot 2}$ é positiva definida. □

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22 \cdot 1}$.

O complemento de Schur aparece sempre que uma matriz particionada é estudada após a eliminação de um dos blocos. Por isso, ele será útil em diferentes partes da Análise Multivariada.

Algebricamente, o termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a correção associada ao segundo bloco, enquanto

$$\mathbf{A}_{11 \cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa o primeiro bloco depois dessa correção.

Essa interpretação é puramente matricial e vale para matrizes particionadas gerais.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada,

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix},$$

o complemento

$$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

adquire uma interpretação estatística adicional. Ele representa a matriz de covariâncias da parcela do primeiro bloco que permanece após o ajuste linear pelo segundo bloco. Sob normalidade conjunta, essa mesma matriz corresponde à covariância condicional do primeiro bloco dado o segundo.

Essa estrutura será retomada no estudo de covariâncias condicionais, regressão entre blocos e distribuição normal multivariada.

2.7 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{A}\mathbf{x}$	Produce produtos internos pelas linhas e combinações lineares pelas colunas
Produto matricial	$\mathbf{A}_{n \times p} \mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{A}\mathbf{B})^\top = \mathbf{B}^\top \mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma bilinear	$\mathbf{x}^\top \mathbf{A} \mathbf{y}$	Relaciona dois vetores por meio de uma matriz
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{A} \mathbf{x} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida.

As seções sobre pseudoinversa, sistemas triangulares, matrizes particionadas e complemento de Schur funcionam como aprofundamentos. Esses resultados serão retomados quando sua utilização estatística se tornar necessária.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas bilineares e quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

Convenções para espaços vetoriais e subespaços

As convenções vetoriais e matriciais apresentadas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- V e W representam espaços vetoriais ou subespaços vetoriais;
- S representa, em geral, um subespaço de $\mathbb{R}^p$;
- $\mathcal{B}$ representa uma base;
- $\mathcal{B}_W$ representa uma base associada ao subespaço W ;
- $\dim(V)$ representa a dimensão do espaço vetorial V ;
- $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ representa o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$;
- $[\mathbf{x}]_{\mathcal{B}}$ representa o vetor de coordenadas de $\mathbf{x}$ em relação à base $\mathcal{B}$;
- $S^\perp$ representa o complemento ortogonal de S ;
- $\mathcal{C}(\mathbf{A})$ representa o espaço coluna de $\mathbf{A}$;
- $\mathcal{L}(\mathbf{A})$ representa o espaço linha de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A})$ representa o espaço nulo de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A}^\top)$ representa o espaço nulo de $\mathbf{A}^\top$;
- $\oplus$ representa soma direta de subespaços;
- $\text{proj}_S(\mathbf{x})$ representa a projeção ortogonal de $\mathbf{x}$ sobre S ;
- $\mathbf{P}_S$ representa uma matriz de projeção ortogonal sobre S ;
- $\mathbf{G}$ representa, quando indicado, uma matriz de Gram.

Quando uma base for escrita como

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\},$$

a ordem dos vetores será considerada fixada sempre que forem utilizadas coordenadas em relação a essa base.

Os vetores continuarão sendo representados por letras minúsculas em negrito, como $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{v}$, enquanto matrizes serão representadas por letras maiúsculas em negrito, como $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{Q}$.

As definições e propriedades específicas de cada espaço, base, decomposição ou operador serão apresentadas nas seções correspondentes.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e são satisfeitas as seguintes propriedades:

1. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$,

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}.$$

2. Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$,

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}).$$

3. Existe um vetor $\mathbf{0} \in V$ tal que, para todo $\mathbf{x} \in V$,

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

4. Para todo $\mathbf{x} \in V$, existe um vetor $-\mathbf{x} \in V$ tal que

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0}.$$

5. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$ e $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y}.$$

6. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x}.$$

7. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}.$$

8. Para todo $\mathbf{x} \in V$,

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais de adição e multiplicação por escalar, é um espaço vetorial. Seus elementos são vetores com p componentes reais. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e, para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

seu inverso aditivo é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

Os elementos de um espaço vetorial não precisam ser necessariamente vetores numéricos. Por exemplo, o conjunto de todas as matrizes reais de dimensão $n \times p$,

$$\mathbb{R}^{n \times p},$$

também é um espaço vetorial com as operações usuais de adição de matrizes e multiplicação por escalar. Nesse caso, os elementos do espaço vetorial são matrizes.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Proposição 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer, 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

Geometricamente, S é uma reta paralela a W , mas deslocada e sem passar pela origem.

A Figura 3.1 compara uma reta que é subespaço de $\mathbb{R}^2$ com uma reta paralela que não é subespaço.




Figura 3.1: Comparação entre uma reta que é subespaço de $\mathbb{R}^2$ e uma reta que não é subespaço.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem e, por isso, não é um subespaço de $\mathbb{R}^2$.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é o conjunto de todas as suas combinações lineares,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

A notação

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$$

indica o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Exemplo 3.5 (Espaço e subespaço gerado). Considere o espaço vetorial

$$V = \mathbb{R}^3.$$

Primeiro, considere os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}.$$

Como qualquer vetor de $\mathbb{R}^3$ pode ser obtido escolhendo adequadamente α_1 , α_2 e α_3 ,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} = \mathbb{R}^3.$$

Nesse caso, o subespaço gerado coincide com o próprio espaço V .

Considere agora apenas os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

As combinações lineares desses vetores são da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ 0 \end{bmatrix}.$$

Portanto,

$$W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} : x_1, x_2 \in \mathbb{R} \right\}.$$

O conjunto W é o plano $x_3 = 0$ contido em $\mathbb{R}^3$. Assim,

$$W \subsetneq V,$$

Os dois casos mostram que um subespaço gerado pode coincidir com todo o espaço ou possuir dimensão menor. Em um espaço vetorial de dimensão finita, um subespaço não pode ter dimensão maior que a do espaço que o contém.

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.6 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes.

Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.7 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

3.2.2 Independência linear e posto

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k], \quad \mathbf{A} \in \mathbb{R}^{p \times k}.$$

As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se,

$$\text{posto}(\mathbf{A}) = k.$$

Assim, o número de vetores linearmente independentes entre as colunas de $\mathbf{A}$ é determinado pelo posto da matriz.

Como

$$\text{posto}(\mathbf{A}) \leq \min(p, k),$$

não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Proposição 3.2 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*

2. Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.
3. Todo subconjunto de um conjunto linearmente independente também é linearmente independente.
4. Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.
5. Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.

A última propriedade fornece uma interpretação direta da redundância.

Proposição 3.3 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

Comprovação. Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente. $\square$

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.8 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.9 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.1 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Comprovação. Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única. □

Definição 3.6 (Coordenadas em uma base). Se

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.10 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

As coordenadas de um vetor em uma base são os coeficientes que indicam quanto de cada vetor da base é necessário para reconstruir esse vetor por combinação linear. Assim, o vetor de coordenadas não é o próprio vetor, mas a representação desse vetor em relação à base escolhida.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

A partir deste ponto, considere um subespaço $S \subseteq \mathbb{R}^p$ com o produto interno euclidiano.

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

de S é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base $\mathcal{B}$ de S é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker, a condição de ortonormalidade pode ser escrita como

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Teorema 3.2 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt. (Meyer, 2023)

Esse resultado garante que a geometria de um subespaço de dimensão finita pode ser descrita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Proposição 3.4 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de um subespaço $S \subseteq \mathbb{R}^p$, então todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Cada coordenada de $\mathbf{x}$ na base $\mathcal{B}$ pode ser obtida separadamente por

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}, \quad j = 1, \dots, k.$$

Portanto,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal, então $\mathbf{b}_j^\top \mathbf{b}_j = 1$ para todo j , de modo que

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

e

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Assim, em uma base ortogonal, cada coordenada pode ser determinada por meio de um produto interno, sem a necessidade de resolver simultaneamente um sistema linear. (Meyer, 2023)

Comprovação. Como $\mathcal{B}$ é uma base de S , todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados à esquerda por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal,

$$\mathbf{b}_j^\top \mathbf{b}_i = 0 \quad \text{para} \quad i \neq j.$$

Assim, todos os termos da soma com $i \neq j$ são nulos, restando

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j.$$

Como $\mathbf{b}_j \neq \mathbf{0}$,

$$\mathbf{b}_j^\top \mathbf{b}_j = \|\mathbf{b}_j\|^2 > 0,$$

e, portanto,

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Se a base é ortonormal, então $\|\mathbf{b}_j\| = 1$ e, consequentemente,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

Logo,

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

o que fornece diretamente as coordenadas de $\mathbf{x}$ na base ortonormal. $\square$

A Figura 3.3 compara três bases de $\mathbb{R}^2$ e destaca a diferença entre independência linear e ortogonalidade.




Figura 3.3: Comparação entre uma base canônica, uma base oblíqua e uma base ortonormal rotacionada de $\mathbb{R}^2$. O símbolo de ângulo reto identifica os pares de vetores ortogonais.

Na primeira e na terceira bases, os vetores são ortogonais e possuem norma igual a 1, como indicado pelos marcadores de ângulo reto. Portanto, ambas são bases ortonormais. Na base oblíqua, os vetores continuam sendo linearmente independentes e, por isso, formam uma base de $\mathbb{R}^2$, mas não são ortogonais.

3.2.7 Dimensão

Um espaço vetorial é denominado **finito-dimensional** quando possui uma base formada por um número finito de vetores.

Para que a dimensão possa ser definida pelo número de vetores de uma base, é necessário estabelecer primeiro que esse número não depende da base escolhida.

Teorema 3.3 (Número de vetores de uma base). *Se um espaço vetorial V possui uma base finita, então todas as bases de V são finitas e possuem a mesma quantidade de vetores. (Meyer, 2023)*

Definição 3.10 (Dimensão). Se as bases de um espaço vetorial finito-dimensional V possuem k vetores, a **dimensão** de V é definida por

$$\dim(V) = k.$$

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.11 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Proposição 3.5 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz está associada a subespaços determinados por suas linhas, por suas colunas e pelas soluções de sistemas lineares homogêneos. Esses subespaços permitem relacionar o posto, a dependência linear e as soluções de sistemas lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Serão estudados quatro subespaços associados a $\mathbf{A}$:

- o espaço coluna;
- o espaço linha;
- o espaço nulo;
- o espaço nulo à esquerda.

Os dois primeiros são construídos a partir das colunas e das linhas da matriz. Os dois últimos são determinados pelas soluções dos sistemas homogêneos associados, respectivamente, a $\mathbf{A}$ e a $\mathbf{A}^\top$.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\}.$$

Quando $\mathbf{A}$ é interpretada como a matriz associada a uma transformação linear, esse espaço corresponde ao **núcleo** da transformação. Essa interpretação será formalizada no capítulo seguinte.

O espaço nulo reúne todos os vetores $\mathbf{x} \in \mathbb{R}^p$ que são anulados pela multiplicação por $\mathbf{A}$, isto é, aqueles para os quais $\mathbf{Ax} = \mathbf{0}$.

Proposição 3.6 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

Comprovação. O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço. □

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.12 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_{.1} \quad \mathbf{a}_{.2} \quad \cdots \quad \mathbf{a}_{.p}] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_{.1}, \dots, \mathbf{a}_{.p} \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p},$$

o conjunto de todos os vetores que podem ser escritos na forma $\mathbf{Ax}$ coincide com o espaço gerado pelas colunas de $\mathbf{A}$:

$$\mathcal{C}(\mathbf{A}) = \{ \mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p \}.$$

Essa caracterização permite relacionar diretamente o espaço coluna à existência de soluções de sistemas lineares.

Proposição 3.7 (Consistência de um sistema linear). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Comprovação. Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{Ax},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_{.1} + \dots + x_p \mathbf{a}_{.p}.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtém-se

$$\mathbf{Ax} = \mathbf{b}.$$

□

Exemplo 3.13 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \mathbf{a}_3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base de $\mathcal{C}(\mathbf{A})$ pode ser formada por quaisquer vetores linearmente independentes que gerem esse espaço. Quando se deseja obter uma base selecionando colunas da própria matriz $\mathbf{A}$, as posições das colunas pivô podem ser identificadas por escalonamento. Nesse procedimento, os vetores da base são as colunas correspondentes da matriz original, e não as colunas da matriz escalonada.

3.3.3 Espaço linha

Definição 3.13 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.14 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.14 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto, todo vetor de $\mathcal{N}(\mathbf{A}^\top)$ é ortogonal a cada coluna de $\mathbf{A}$ e, conseqüentemente, a toda combinação linear dessas colunas. A relação entre o espaço nulo à esquerda e o complemento ortogonal do espaço coluna será formalizada adiante.

Exemplo 3.15 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Extensão de uma base

Uma base de um subespaço pode ser completada acrescentando vetores até formar uma base de todo o espaço. Esse resultado será utilizado na demonstração do Teorema Posto–Nulidade.

Teorema 3.4 (Extensão de uma base). *Seja W um subespaço de um espaço vetorial V de dimensão finita. Se*

$$\mathcal{B}_W = \{\mathbf{u}_1, \dots, \mathbf{u}_s\}$$

é uma base de W , então existem vetores $\mathbf{z}_1, \dots, \mathbf{z}_r \in V$ tais que

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

é uma base de V . (Meyer, 2023)

Comprovação. Se $\mathcal{B}_W$ já gera V , então $\mathcal{B}_W$ é uma base de V e nada precisa ser acrescentado. Caso contrário, existe um vetor $\mathbf{z}_1 \in V$ que não pertence ao subespaço gerado por $\mathcal{B}_W$. Assim,

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1\}$$

é linearmente independente.

Se esse conjunto ainda não gera V , escolhe-se um vetor $\mathbf{z}_2 \in V$ que não pertence ao subespaço gerado pelos vetores já selecionados. O novo conjunto continua linearmente independente.

Repetindo esse procedimento, acrescentam-se vetores enquanto o conjunto obtido não gerar V . Como V possui dimensão finita, não é possível acrescentar indefinidamente vetores linearmente independentes. Portanto, após um número finito de etapas, obtém-se um conjunto

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

que é linearmente independente e gera V . Logo, esse conjunto é uma base de V . $\square$

3.3.6 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.5 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Meyer, 2023)

Comprovação. Considere uma base do espaço nulo,

$$\mathcal{B}_\mathcal{N} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Pelo Teorema 3.4, essa base de $\mathcal{N}(\mathbf{A})$ pode ser completada para formar uma base de $\mathbb{R}^p$. Assim, existem vetores $\mathbf{w}_1, \dots, \mathbf{w}_r \in \mathbb{R}^p$ tais que

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$.

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j.$$

Portanto,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

geram $\mathcal{C}(\mathbf{A})$.

Para verificar a independência linear, suponha que

$$\sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j = \mathbf{0}.$$

Então,

$$\mathbf{A} \left(\sum_{j=1}^r \beta_j \mathbf{w}_j \right) = \mathbf{0},$$

de modo que

$$\sum_{j=1}^r \beta_j \mathbf{w}_j \in \mathcal{N}(\mathbf{A}).$$

Esse vetor também pertence a

$$\text{span}\{\mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$, a interseção entre esses dois subespaços contém somente o vetor nulo. Assim,

$$\beta_1 = \dots = \beta_r = 0.$$

Logo,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

formam uma base de $\mathcal{C}(\mathbf{A})$. Portanto,

$$r = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Logo,

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = p.$$

□

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Exemplo 3.16 (Aplicação do Teorema Posto–Nulidade). Para a matriz utilizada nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Assim, para $\mathbf{A} \in \mathbb{R}^{2 \times 3}$,

$$1 + 2 = 3,$$

confirmando que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = 3.$$

Aplicando o resultado a $\mathbf{A}^\top$,

$$1 + 1 = 2,$$

de modo que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = 2.$$

Os resultados correspondem, respectivamente, às dimensões dos espaços ambientes $\mathbb{R}^3$ e $\mathbb{R}^2$.

3.3.7 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os quatro espaços se organizam em dois espaços ambientes. O espaço coluna e o espaço nulo à esquerda são subespaços de $\mathbb{R}^n$, enquanto o espaço linha e o espaço nulo são subespaços de $\mathbb{R}^p$.

3.3.8 Complemento ortogonal

Definição 3.15 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S . Essa definição permite descrever relações importantes entre os quatro espaços fundamentais de uma matriz.

3.3.9 Relações de ortogonalidade

Teorema 3.6 (Ortogonalidade entre os espaços fundamentais). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Cada componente de $\mathbf{A}\mathbf{x}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, conseqüentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{A}\mathbf{x}$ é, portanto, igual a zero, de modo que

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

□

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

em $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

em $\mathbb{R}^n$.

A decomposição dos espaços ambientes em somas diretas desses pares será obtida posteriormente a partir do resultado geral sobre complementos ortogonais.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Além da geometria euclidiana, é possível definir outras geometrias atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Aprofundamento: produtos internos e geometrias induzidas

Leitura de aprofundamento

Esta subseção generaliza o produto interno euclidiano por meio de matrizes positivas definidas e apresenta as normas, distâncias e relações de ortogonalidade associadas a essa generalização. Esses conceitos serão retomados no estudo da distância de Mahalanobis, de geometrias determinadas por matrizes de covariâncias e de problemas de mínimos quadrados ponderados.

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.16 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Proposição 3.8 (Propriedades do produto interno induzido). *Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$,*

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn; Johnson, 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.17 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.1.1 Norma e distância induzidas

Definição 3.17 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.18 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned}\|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{[2 \quad 1] \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}.\end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.1.2 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no capítulo anterior.

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^{\top} \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.1.3 Relação com a geometria euclidiana

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned}\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}).\end{aligned}$$

Assim, o produto interno induzido por $\mathbf{M}$ pode ser interpretado como o produto interno euclidiano entre os vetores $\mathbf{C} \mathbf{x}$ e $\mathbf{C} \mathbf{y}$. Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma. Analogamente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$$




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

pode ser igual a zero mesmo quando $\mathbf{x} \neq \mathbf{y}$. Portanto, essa expressão define, em geral, uma **pseudodistância**.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.2 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.18 (Matriz de Gram). Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$ e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.19 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.3 Propriedades da matriz de Gram

Proposição 3.9 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$.

(Horn; Johnson, 2013)

Comprovação. A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

Além disso,

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = 0$$

se, e somente se,

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Portanto, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.
Para demonstrar a igualdade dos núcleos, suponha inicialmente que

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{c}^\top$,

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} = \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

Logo,

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

e, portanto,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}).$$

Reciprocamente, se

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

então

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{V}^\top \mathbf{0} = \mathbf{0},$$

de modo que

$$\mathcal{N}(\mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}^\top \mathbf{V}).$$

Assim,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}).$$

Como $\mathbf{V}^\top \mathbf{V}$ e $\mathbf{V}$ possuem o mesmo número de colunas, a igualdade das nulidades e o Teorema Posto–Nulidade implicam

$$\text{posto}(\mathbf{V}^\top \mathbf{V}) = \text{posto}(\mathbf{V}).$$

□

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são linearmente dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.4 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.20 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.5 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela [3.2](#) resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij} x_{ik}$
$\mathbf{X} \mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.4.6 Propriedades do complemento ortogonal

O complemento ortogonal, introduzido anteriormente na descrição dos espaços fundamentais de uma matriz, será agora estudado para um subespaço arbitrário de $\mathbb{R}^p$.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k \right\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Proposição 3.10 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

Comprovação. O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$(\alpha\mathbf{x} + \beta\mathbf{y})^\top \mathbf{s} = \alpha\mathbf{x}^\top \mathbf{s} + \beta\mathbf{y}^\top \mathbf{s} = 0.$$

Portanto,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$. □

Exemplo 3.21 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$

Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.4.7 Dimensão do complemento ortogonal

Proposição 3.11 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$

Comprovação. Seja

$$\dim(S) = k.$$

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Pelo Teorema 3.4, essa base de S pode ser completada para formar uma base de $\mathbb{R}^p$. Aplicando o processo de Gram–Schmidt aos vetores acrescentados, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k+1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

e, portanto,

$$\alpha_i = 0, \quad i = 1, \dots, k.$$

Logo,

$$\mathbf{x} = \sum_{j=k+1}^p \alpha_j \mathbf{q}_j,$$

de modo que

$$\{\mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}$$

é uma base de $S^\perp$.

Assim,

$$\dim(S^\perp) = p - k,$$

e, como $\dim(S) = k$,

$$\dim(S) + \dim(S^\perp) = p.$$

□

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Outra consequência importante é

$$(S^\perp)^\perp = S.$$

De fato,

$$S \subseteq (S^\perp)^\perp,$$

pois todo vetor de S é ortogonal a todos os vetores de $S^\perp$. Além disso,

$$\begin{aligned} \dim \left((S^\perp)^\perp \right) &= p - \dim(S^\perp) \\ &= p - (p - k) \\ &= k \\ &= \dim(S). \end{aligned}$$

Como um subespaço está contido no outro e ambos possuem a mesma dimensão,

$$(S^\perp)^\perp = S.$$

3.4.8 Decomposição ortogonal

Teorema 3.7 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

O símbolo $\oplus$ representa uma **soma direta**: cada vetor de $\mathbb{R}^p$ possui uma única decomposição como soma de um vetor pertencente a S e um vetor pertencente a $S^\perp$.

Comprovação. Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned}\mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0.\end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

e

$$\mathbf{r}_1, \mathbf{r}_2 \in S^\perp.$$

Então,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{r}_2 - \mathbf{r}_1.$$

O lado esquerdo pertence a S , enquanto o lado direito pertence a $S^\perp$. Portanto, esse vetor pertence a

$$S \cap S^\perp = \{\mathbf{0}\}.$$

Assim,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{0}$$

e

$$\mathbf{r}_2 - \mathbf{r}_1 = \mathbf{0}.$$

Logo,

$$\mathbf{s}_1 = \mathbf{s}_2 \quad \text{e} \quad \mathbf{r}_1 = \mathbf{r}_2.$$

Portanto, a decomposição é única. □

A decomposição separa $\mathbf{x}$ em duas componentes únicas: $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$. Na seção seguinte, veremos que $\mathbf{x}_S$ é precisamente a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.4.9 Decomposição dos espaços fundamentais

A decomposição ortogonal pode ser aplicada diretamente aos quatro espaços fundamentais de uma matriz.

Proposição 3.12 (Decomposição dos espaços fundamentais). *Para uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$,*

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

De fato, pelo Teorema 3.6,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Aplicando o Teorema 3.7,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

com $\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$ e $\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A})$.

Analogamente,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

e, portanto,

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^\top},$$

com $\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$ e $\mathbf{y}_{\mathcal{N}^\top} \in \mathcal{N}(\mathbf{A}^\top)$.

Os quatro espaços fundamentais formam, portanto, dois pares de subespaços ortogonais complementares: um em $\mathbb{R}^p$ e outro em $\mathbb{R}^n$.

3.5 Projeções ortogonais

O Teorema 3.7 estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor $\mathbf{x} \in \mathbb{R}^p$ admite uma decomposição única em uma componente pertencente a S e outra pertencente a $S^\perp$. Essa decomposição permite definir a projeção ortogonal sobre um subespaço.

Definição 3.19 (Projeção ortogonal). Seja S um subespaço de $\mathbb{R}^p$. Pela decomposição ortogonal, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

com $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

A **projeção ortogonal de $\mathbf{x}$ sobre S** é definida por

$$\text{proj}_S(\mathbf{x}) = \mathbf{x}_S.$$

Consequentemente,

$$\mathbf{x} - \text{proj}_S(\mathbf{x}) \in S^\perp.$$

A forma da projeção depende de como o subespaço S é representado. Começaremos pelo caso mais simples, em que S possui dimensão 1.

3.5.1 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Proposição 3.13 (Projeção sobre uma direção). *Se*

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

então a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Como $\mathbf{u}^\top \mathbf{x}$ é um escalar, pode-se escrever

$$\frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}).$$

Pela associatividade da multiplicação matricial,

$$\mathbf{u} (\mathbf{u}^\top \mathbf{x}) = (\mathbf{u} \mathbf{u}^\top) \mathbf{x}.$$

Portanto,

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}) \\ &= \frac{1}{\mathbf{u}^\top \mathbf{u}} (\mathbf{u} \mathbf{u}^\top) \mathbf{x} = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.22 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned}\mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top\mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{P}_S\mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição e destaca a ortogonalidade entre a projeção e o resíduo.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

3.5.2 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Proposição 3.14 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Meyer, 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.23 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.5.3 Projecção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subsecção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projecção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Proposição 3.15 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre $\mathcal{C}(\mathbf{A})$ é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_\mathbf{A} \mathbf{x},$$

em que

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz $\mathbf{P}_\mathbf{A}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$, e não da base particular escolhida para representá-lo.

De fato, suponha que outra base do mesmo subespaço seja organizada em uma matriz

$$\mathbf{B} = \mathbf{A} \mathbf{R},$$

em que $\mathbf{R} \in \mathbb{R}^{k \times k}$ é invertível. Então

$$\begin{aligned} \mathbf{P}_\mathbf{B} &= \mathbf{B} (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \\ &= \mathbf{A} \mathbf{R} (\mathbf{R}^\top \mathbf{A}^\top \mathbf{A} \mathbf{R})^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} \mathbf{R} \mathbf{R}^{-1} (\mathbf{A}^\top \mathbf{A})^{-1} (\mathbf{R}^\top)^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_\mathbf{A}. \end{aligned}$$

Portanto, bases diferentes do mesmo subespaço produzem a mesma matriz de projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_\mathbf{A} = \mathbf{A} \mathbf{A}^\top.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top.$$

Portanto,

$$\mathbf{Q}\mathbf{Q}^\top$$

é o caso ortonormal da expressão geral

$$\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Exemplo 3.24 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned}
\mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\
&= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\
&= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}.
\end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.5.4 Propriedades da matriz de projeção

Proposição 3.16 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top,$$

então:

1. $\mathbf{P}_A$ é simétrica;
2. $\mathbf{P}_A$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})$;
4. $\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\text{posto}(\mathbf{P}_A) = \text{posto}(\mathbf{A}) = k$.

Comprovação. A simetria decorre de

$$\begin{aligned} \mathbf{P}_A^\top &= \left[\mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \right]^\top \\ &= \mathbf{A} \left[(\mathbf{A}^\top \mathbf{A})^{-1} \right]^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_A, \end{aligned}$$

pois $\mathbf{A}^\top \mathbf{A}$ e sua inversa são simétricas.

Para verificar a idempotência,

$$\begin{aligned} \mathbf{P}_A^2 &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_A. \end{aligned}$$

Para determinar o espaço coluna, observe inicialmente que, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{x} = \mathbf{A} \left[(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \right].$$

Portanto,

$$\mathbf{P}_A \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

e, conseqüentemente,

$$\mathcal{C}(\mathbf{P}_A) \subseteq \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A}),$$

então existe $\mathbf{c} \in \mathbb{R}^k$ tal que

$$\mathbf{y} = \mathbf{A}\mathbf{c}.$$

Assim,

$$\begin{aligned}\mathbf{P}_\mathbf{A}\mathbf{y} &= \mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top\mathbf{A}\mathbf{c} \\ &= \mathbf{A}\mathbf{c} \\ &= \mathbf{y}.\end{aligned}$$

Logo,

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{P}_\mathbf{A}),$$

e, portanto,

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}).$$

Para determinar o espaço nulo, observe que

$$\begin{aligned}\mathbf{A}^\top\mathbf{P}_\mathbf{A} &= \mathbf{A}^\top\mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top \\ &= \mathbf{A}^\top.\end{aligned}$$

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{P}_\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top\mathbf{x} = \mathbf{A}^\top\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{A}^\top \mathbf{x} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{0}.$$

Assim,

$$\mathcal{N}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Finalmente, como

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}),$$

tem-se

$$\text{posto}(\mathbf{P}_\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Como as k colunas de $\mathbf{A}$ são linearmente independentes,

$$\text{posto}(\mathbf{A}) = k.$$

Portanto,

$$\text{posto}(\mathbf{P}_\mathbf{A}) = k.$$

□

A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.5.5 Aprofundamento: projeção residual e complemento ortogonal

Leitura de aprofundamento

Esta seção desenvolve a matriz que projeta um vetor sobre o complemento ortogonal de um subespaço. Essa representação será retomada no estudo de mínimos quadrados, da Decomposição em Valores Singulares e do modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

com colunas linearmente independentes e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}} \mathbf{x}.$$

Definição 3.20 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Proposição 3.17 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
3. $\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$ e $\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}$;
4. $\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
6. se $\mathbf{A}$ possui posto k , então $\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k$.

Comprovação. Como $\mathbf{P}_{\mathbf{A}}$ é simétrica,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^\top &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}}.\end{aligned}$$

Portanto, $\mathbf{M}_{\mathbf{A}}$ é simétrica.

Para verificar a idempotência,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^2 &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^2 \\ &= \mathbf{I}_p - 2\mathbf{P}_{\mathbf{A}} + \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}},\end{aligned}$$

pois

$$\mathbf{P}_{\mathbf{A}}^2 = \mathbf{P}_{\mathbf{A}}.$$

Além disso,

$$\begin{aligned}\mathbf{P}_A \mathbf{M}_A &= \mathbf{P}_A (\mathbf{I}_p - \mathbf{P}_A) \\ &= \mathbf{P}_A - \mathbf{P}_A^2 \\ &= \mathbf{0},\end{aligned}$$

e, de forma análoga,

$$\mathbf{M}_A \mathbf{P}_A = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{M}_A \mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{M}_A \mathbf{x} \in \mathcal{N}(\mathbf{P}_A).$$

Como

$$\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp,$$

tem-se

$$\mathcal{C}(\mathbf{M}_A) \subseteq \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{P}_A \mathbf{y} = \mathbf{0},$$

e, portanto,

$$\begin{aligned}\mathbf{M}_A \mathbf{y} &= (\mathbf{I}_p - \mathbf{P}_A) \mathbf{y} \\ &= \mathbf{y}.\end{aligned}$$

Assim,

$$\mathcal{C}(\mathbf{A})^\perp \subseteq \mathcal{C}(\mathbf{M}_\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{M}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Agora, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{x}.$$

Consequentemente,

$$\mathbf{M}_\mathbf{A} \mathbf{x} = \mathbf{0},$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{M}_\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{M}_\mathbf{A}),$$

então

$$(\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \mathbf{P}_\mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{P}_\mathbf{A} \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

segue que

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Finalmente,

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\dim \mathcal{C}(\mathbf{A}) = k,$$

o teorema da dimensão do complemento ortogonal fornece

$$\dim \mathcal{C}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

Logo,

$$\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

□

3.5.6 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.8 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer, 2023)

Comprovação. Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

□

Portanto, a projeção ortogonal pode ser caracterizada equivalentemente como

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Assim, projetar ortogonalmente $\mathbf{x}$ sobre S equivale a encontrar, entre todos os vetores pertencentes a S , aquele que está mais próximo de $\mathbf{x}$ segundo a distância euclidiana.

Quando $S = \mathcal{C}(\mathbf{A})$, com $\mathbf{A} \in \mathbb{R}^{p \times k}$, todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente, o problema de melhor aproximação pode ser escrito como

$$\hat{\mathbf{c}} \in \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor mais próximo de $\mathbf{x}$ em $\mathcal{C}(\mathbf{A})$ é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa formulação estabelece a ligação entre projeção ortogonal e mínimos quadrados. O desenvolvimento algébrico dessa relação é apresentado a seguir como aprofundamento.

3.5.7 Aprofundamento: projeções e mínimos quadrados

Leitura de aprofundamento

Esta seção desenvolve algebricamente a relação entre projeção ortogonal e mínimos quadrados. As equações normais, os resíduos, as matrizes de projeção e a pseudoinversa serão retomados na Decomposição em Valores Singulares e no modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^k} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.8, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.21 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A} \hat{\boldsymbol{\beta}} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\boldsymbol{\beta}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\boldsymbol{\beta}} \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\ &= \mathbf{P}_\mathbf{A} \mathbf{b}, \end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned} \hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\ &= \mathbf{M}_\mathbf{A} \mathbf{b}. \end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Proposição 3.18 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub; Van Loan, 2013)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, o problema de mínimos quadrados pode possuir diferentes vetores de coeficientes que produzem o mesmo ajuste. Portanto, $\hat{\beta}$ pode não ser único.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$.

Utilizando a pseudoinversa de Moore–Penrose (ver Definição 2.17),

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

de modo que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^+.$$

A pseudoinversa foi introduzida no capítulo anterior. Sua construção por meio da Decomposição em Valores Singulares será desenvolvida posteriormente.

As projeções ponderadas podem ser obtidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será retomada no estudo de problemas de mínimos quadrados ponderados.

3.6 Síntese do capítulo

Os espaços vetoriais permitem organizar conjuntos de vetores que preservam as operações de adição e multiplicação por escalar. Dentro desses espaços, os subespaços representam estruturas lineares de menor dimensão, enquanto bases fornecem conjuntos de vetores linearmente independentes capazes de gerar todo o espaço considerado. Fixada uma base, cada vetor pode ser representado de maneira única por suas coordenadas nessa base.

A dimensão quantifica o número de direções independentes necessárias para representar um espaço. Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

essa ideia conduz aos quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}), \mathcal{L}(\mathbf{A}), \mathcal{N}(\mathbf{A}) \text{ e } \mathcal{N}(\mathbf{A}^\top).$$

Se $r = \text{posto}(\mathbf{A})$, suas dimensões são

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

As matrizes de Gram organizam produtos internos entre conjuntos de vetores. Para uma matriz $\mathbf{V}$,

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

é simétrica e semidefinida positiva, e sua estrutura permite relacionar produtos internos, independência linear e posto.

A decomposição ortogonal estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor pode ser escrito de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com $\text{proj}_S(\mathbf{x}) \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , a matriz de projeção é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Se $S = \mathcal{C}(\mathbf{A})$ e as colunas de $\mathbf{A}$ são linearmente independentes, a mesma projeção pode ser escrita como

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção ortogonal possui ainda uma interpretação por otimização:

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Essa propriedade estabelece a ligação entre geometria, projeções e problemas de mínimos quadrados.

As partes de aprofundamento generalizam a geometria euclidiana por meio de produtos internos induzidos por matrizes positivas definidas e desenvolvem a matriz de projeção residual, as equações normais, o caso de posto deficiente e a pseudoinversa. Esses resultados serão retomados quando sua utilização se tornar necessária nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- interpretar geração, dependência e independência linear;
- identificar bases e determinar dimensões;
- representar vetores por coordenadas em uma base;
- distinguir bases gerais, ortogonais e ortonormais;
- determinar e interpretar os quatro espaços fundamentais de uma matriz;
- relacionar posto, nulidade e dimensão;
- interpretar as relações de ortogonalidade entre os espaços fundamentais;
- construir e interpretar matrizes de Gram;
- determinar complementos ortogonais e decomposições ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar a projeção ortogonal como problema de melhor aproximação;
- reconhecer a relação geométrica entre projeções e mínimos quadrados.

No próximo capítulo, as matrizes serão estudadas como representações de transformações lineares entre espaços vetoriais. Os conceitos de base, dimensão, posto, espaços fundamentais e projeções desenvolvidos aqui permitirão interpretar como essas transformações atuam sobre vetores e subespaços. O espaço nulo e o espaço coluna também serão relacionados, nesse novo contexto, ao núcleo e à imagem da transformação associada a uma matriz.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada **transformação linear**.

No capítulo anterior, o espaço nulo e o espaço coluna foram definidos diretamente a partir de uma matriz. Neste capítulo, essas estruturas serão também interpretadas, respectivamente, como o núcleo e a imagem da transformação linear associada à matriz.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

Convenções para transformações lineares

As convenções vetoriais e matriciais estabelecidas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $T : V \rightarrow W$ representa uma transformação entre os espaços vetoriais V e W ;
- V representa o domínio e W o contradomínio da transformação;
- $\mathbf{x} \in V$ representa um vetor do domínio e $T(\mathbf{x}) \in W$ sua imagem pela transformação;
- $T_{\mathbf{A}}$ representa a transformação linear associada à matriz $\mathbf{A}$;
- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ quando utilizada na forma $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$;
- $\ker(T)$ representa o núcleo de uma transformação linear;
- $\text{Im}(T)$ representa a imagem de uma transformação linear;
- $\mathcal{E}_p$ representa a base canônica de $\mathbb{R}^p$;
- $[T]_{\mathcal{C} \leftarrow \mathcal{B}}$ representa a matriz de uma transformação em relação a uma base $\mathcal{B}$ do domínio e a uma base $\mathcal{C}$ do contradomínio.

As relações entre essas notações e os espaços fundamentais das matrizes serão estabelecidas ao longo do capítulo.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha\mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

Proposição 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

Comprovação. Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned}
T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\
&= T(\mathbf{u}) + T(-\mathbf{v}) \\
&= T(\mathbf{u}) - T(\mathbf{v}).
\end{aligned}$$

□

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Proposição 4.2 (Determinação de uma transformação por uma base). *Seja V um espaço vetorial de dimensão finita e seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_k).$$

(Meyer, 2023)

Comprovação. Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_k T(\mathbf{v}_k).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio fica determinada de maneira única. □

Exemplo 4.1 (Transformação determinada pelas imagens de uma base). Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\ &= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}. \end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Portanto, a matriz que representa T na base canônica é

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix},$$

cujas colunas são precisamente

$$T(\mathbf{e}_1) \quad \text{e} \quad T(\mathbf{e}_2).$$

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \dots + x_p T(\mathbf{e}_p) \\ &= x_1 \mathbf{a}_1 + \dots + x_p \mathbf{a}_p \\ &= \mathbf{A}\mathbf{x}. \end{aligned}$$

Isso estabelece a existência de uma matriz que representa T nas bases canônicas.

Para verificar a unicidade, suponha que outra matriz

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

também satisfaça

$$T(\mathbf{x}) = \mathbf{C}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Aplicando essa igualdade aos vetores da base canônica,

$$\mathbf{C}\mathbf{e}_j = T(\mathbf{e}_j) = \mathbf{A}\mathbf{e}_j, \quad j = 1, \dots, p.$$

Como $\mathbf{A}\mathbf{e}_j$ e $\mathbf{C}\mathbf{e}_j$ correspondem, respectivamente, às j -ésimas colunas de $\mathbf{A}$ e $\mathbf{C}$, todas as colunas das duas matrizes são iguais. Portanto,

$$\mathbf{C} = \mathbf{A}.$$

A matriz representante de T nas bases canônicas é, assim, única.

Proposição 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

(Meyer, 2023)

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned} T_{\mathbf{A}}(\alpha\mathbf{u} + \beta\mathbf{v}) &= \mathbf{A}(\alpha\mathbf{u} + \beta\mathbf{v}) \\ &= \alpha\mathbf{A}\mathbf{u} + \beta\mathbf{A}\mathbf{v} \\ &= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}). \end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Núcleo e imagem de uma transformação linear

Dois subespaços descrevem aspectos fundamentais da ação de uma transformação linear: os vetores do domínio que são enviados ao vetor nulo e os vetores do contradomínio que podem ser obtidos pela transformação.

Definição 4.2 (Núcleo e imagem de uma transformação linear). Seja

$$T : V \longrightarrow W$$

uma transformação linear.

O **núcleo** de T é o conjunto

$$\ker(T) = \{\mathbf{x} \in V : T(\mathbf{x}) = \mathbf{0}\}.$$

A **imagem** de T é o conjunto

$$\text{Im}(T) = \{T(\mathbf{x}) : \mathbf{x} \in V\}.$$

O núcleo é um subespaço do domínio V , enquanto a imagem é um subespaço do contradomínio W .

Para a transformação matricial

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax},$$

o núcleo é

$$\begin{aligned}\ker(T_{\mathbf{A}}) &= \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\} \\ &= \mathcal{N}(\mathbf{A}),\end{aligned}$$

e a imagem é

$$\begin{aligned}\operatorname{Im}(T_{\mathbf{A}}) &= \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p\} \\ &= \mathcal{C}(\mathbf{A}).\end{aligned}$$

Relação com os subespaços associados a uma matriz

O **espaço nulo** e o **espaço coluna** estudados no capítulo anterior correspondem, respectivamente, ao **núcleo** e à **imagem** da transformação linear associada à matriz $\mathbf{A}$:

$$\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}}), \quad \mathcal{C}(\mathbf{A}) = \operatorname{Im}(T_{\mathbf{A}}).$$

Se

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

o **contradomínio** é $\mathbb{R}^q$, enquanto a imagem é o subespaço efetivamente alcançado pela transformação,

$$\operatorname{Im}(T_{\mathbf{A}}) \subseteq \mathbb{R}^q.$$

4.1.4 Imagem de um subespaço

Considere um subespaço

$$S = \operatorname{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \cdots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Proposição 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Comprovação. A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A} \mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X} \mathbf{A}^\top.$$

□

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q] .$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q] .$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}_{\cdot j} = \mathbf{X}\mathbf{w}_j .$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip} .$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.2 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} .$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} ,$$

tem-se

$$\begin{aligned}
\mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\
&= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\
&= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}.
\end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned}
\mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\
&= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\
&= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}.
\end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}_{.1} = \mathbf{x}_{.1} + \mathbf{x}_{.2}.$$

A segunda é

$$\mathbf{y}_{.2} = 2\mathbf{x}_{.1} - \mathbf{x}_{.2}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, todas as observações transformadas pertencem a um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Assim, a dimensão da configuração transformada não pode exceder $\text{posto}(\mathbf{A})$, embora possa ser menor, dependendo da configuração original dos dados.

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando $r < p$, a transformação possui núcleo não trivial e elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, como a transformação modifica produtos internos, comprimentos e distâncias. Quando $\mathbf{A}$ possui posto completo nas colunas, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e determina um produto interno no domínio. Quando $\mathbf{A}$ não possui posto completo nas colunas, essa matriz é apenas semidefinida positiva e algumas direções são eliminadas pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

para os quais

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}^\top \mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Proposição 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

A ordem de aplicação das transformações é importante. Quando duas transformações atuam sobre o mesmo espaço,

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e

$$T_2 : \mathbb{R}^p \longrightarrow \mathbb{R}^p,$$

representadas, respectivamente, por

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{p \times p},$$

as duas composições

$$T_2 \circ T_1$$

e

$$T_1 \circ T_2$$

estão definidas. Suas matrizes representantes são, respectivamente,

$$\mathbf{BA}$$

e

$$\mathbf{AB}.$$

Como a multiplicação de matrizes não é, em geral, comutativa,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente, em geral,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

A igualdade pode ocorrer para transformações particulares, mas não constitui uma propriedade geral da composição.

Exemplo 4.3 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.3 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{Ax},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Proposição 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Comprovação. Tem-se

$$\begin{aligned} (\mathbf{BA})(\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B}(\mathbf{AA}^{-1})\mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1})(\mathbf{BA}) &= \mathbf{A}^{-1}(\mathbf{B}^{-1}\mathbf{B})\mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

□

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.4 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Proposição 4.7 (Caracterizações por núcleo, imagem e posto). *Seja*

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

com $\mathbf{A} \in \mathbb{R}^{q \times p}$. Então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

(Meyer, 2023)

Comprovação. Suponha inicialmente que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema [3.5](#),

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

Como $\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}})$, tem-se

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

Por outro lado, $T_{\mathbf{A}}$ é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à sua imagem. Como

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}),$$

a sobrejetividade equivale a

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim \mathcal{C}(\mathbf{A}) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

□

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando o Proposição 4.7 com o Teorema 2.5, obtém-se o resultado seguinte.

Proposição 4.8 (Equivalências para uma transformação linear associada a uma matriz quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $T_{\mathbf{A}}$ é invertível;
5. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
6. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
7. $\text{posto}(\mathbf{A}) = p$;
8. $\det(\mathbf{A}) \neq 0$;
9. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$

Propriedade	Condição geométrica	Condição matricial
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \ker(T_{\mathbf{A}}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \ker(T_{\mathbf{A}})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo núcleo da transformação, que coincide com o espaço nulo da matriz associada.

Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

O espaço nulo possui dimensão $p-r$. Portanto, existem $p-r$ direções linearmente independentes no domínio que são anuladas pela transformação, enquanto a imagem possui dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar

$$\text{posto}(\mathbf{A})$$

como a dimensão da imagem da transformação, isto é, como o número máximo de direções linearmente independentes que podem compor o espaço transformado. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam a posição da configuração em relação aos eixos coordenados sem deformar sua geometria, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;

- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}_\theta \mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}_\theta^\top \mathbf{Q}_\theta = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}_\theta^{-1} = \mathbf{Q}_\theta^\top = \mathbf{Q}_{-\theta}.$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}_\theta) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada **reflexão de Householder**.

Observe que as duas construções preservam componentes diferentes. A matriz $2\mathbf{u}\mathbf{u}^\top - \mathbf{I}$ preserva a componente na direção de $\mathbf{u}$ e inverte as componentes ortogonais a ela, enquanto $\mathbf{I} - 2\mathbf{u}\mathbf{u}^\top$ preserva as componentes ortogonais a $\mathbf{u}$ e inverte a componente na direção de $\mathbf{u}$.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é reescalada por um fator próprio, de modo que comprimentos, ângulos e proporções podem ser alterados. Se algum fator s_j for negativo, além da alteração de escala ocorre a inversão do sentido da coordenada correspondente.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned} y_1 &= x_1 + kx_2, \\ y_2 &= x_2. \end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det\left(\mathbf{C}_{ij}(k)\right) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

As projeções ortogonais foram desenvolvidas no capítulo anterior a partir da decomposição de um vetor em componentes pertencentes a subespaços ortogonais. Aqui, interessa interpretá-las como transformações lineares.

Considere uma direção unitária

$$\mathbf{u} \in \mathbb{R}^p, \quad \|\mathbf{u}\| = 1,$$

e o subespaço

$$S = \text{span}\{\mathbf{u}\}.$$

A matriz da projeção ortogonal sobre S é

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top,$$

de modo que

$$T_{\mathbf{P}_S}(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

Como estudado no capítulo anterior,

$$\mathbf{P}_S^2 = \mathbf{P}_S$$

e

$$\mathbf{P}_S^\top = \mathbf{P}_S.$$

Do ponto de vista das transformações lineares,

$$\text{Im}(T_{\mathbf{P}_S}) = S$$

e

$$\ker(T_{\mathbf{P}_S}) = S^\perp.$$

Assim, a projeção preserva a componente pertencente a S e elimina toda a componente pertencente a $S^\perp$.

Para uma projeção sobre uma única direção,

$$\text{posto}(\mathbf{P}_S) = 1.$$

Consequentemente, quando $p > 1$,

$$\det(\mathbf{P}_S) = 0,$$

e a transformação não é invertível. Vetores que diferem apenas por uma componente pertencente a $S^\perp$ possuem a mesma imagem.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário. Como todos os painéis utilizam a mesma escala, alterações de forma, área e dimensão podem ser comparadas diretamente.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

A rotação altera a posição do quadrado em relação aos eixos coordenados sem modificar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme modifica os comprimentos nas direções coordenadas e transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área, mostrando que preservar área não implica preservar ângulos ou comprimentos. A projeção elimina uma direção e reduz a figura a um segmento de reta.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Proposição 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$E \subseteq \mathbb{R}^p$$

um conjunto mensurável com volume p -dimensional finito. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se

$$\det(\mathbf{A}) = 0,$$

então

$$\text{posto}(\mathbf{A}) < p,$$

de modo que a imagem $\mathbf{A}E$ está contida em um subespaço próprio de $\mathbb{R}^p$. Consequentemente,

$$\text{Vol}_p(\mathbf{A}E) = 0.$$

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

Quando a transformação é invertível, o sinal do determinante descreve o efeito sobre a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida.

Se $\det(\mathbf{A}) = 0$, a transformação não é invertível, sua imagem possui dimensão inferior a p e o volume p -dimensional é reduzido a zero.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}_\theta$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Reescala direções coordenadas
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.18, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Proposição 4.10 (Preservação da geometria euclidiana). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, a transformação*

$$T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x}$$

preserva:

1. o produto interno;
2. as normas;
3. as distâncias euclidianas;
4. os ângulos entre vetores não nulos;
5. a ortogonalidade.

Comprovação. Pelo Teorema 2.7,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Portanto, o produto interno entre quaisquer dois vetores é preservado.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2.\end{aligned}$$

Como as normas são não negativas,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|.\end{aligned}$$

Logo, todas as distâncias euclidianas entre pares de vetores são preservadas.

Para vetores não nulos, o ângulo θ entre $\mathbf{x}$ e $\mathbf{y}$ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como o produto interno e as normas são preservados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados.

Em particular, se

$$\mathbf{x}^\top \mathbf{y} = 0,$$

então

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0,$$

e a ortogonalidade é preservada. □

Assim, transformações ortogonais preservam integralmente as relações métricas determinadas pelo produto interno euclidiano. Elas podem alterar a orientação da configuração, mas não deformam sua geometria interna.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Proposição 4.11 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top. \end{aligned}$$

□

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados não nulos.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Proposição 4.12 (Determinante de uma matriz ortogonal). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então*

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

Consequentemente,

$$|\det(\mathbf{Q})| = 1,$$

e a transformação preserva volumes p -dimensionais.

Comprovação. Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned} 1 &= \det(\mathbf{Q}^\top \mathbf{Q}) \\ &= \det(\mathbf{Q}^\top) \det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2. \end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Logo,

$$|\det(\mathbf{Q})| = 1.$$

□

No plano, a preservação do volume p -dimensional corresponde à preservação de áreas; em $\mathbb{R}^3$, corresponde à preservação de volumes.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no Capítulo 2. Portanto, as colunas de $\mathbf{Q}$ possuem norma unitária e são ortogonais duas a duas.

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também formam um conjunto ortonormal.

Uma matriz ortogonal admite, portanto, duas interpretações que devem ser distinguidas:

- como matriz de uma transformação linear que preserva a geometria euclidiana;
- como matriz cujas colunas constituem uma base ortonormal de $\mathbb{R}^p$.

Na primeira interpretação, a matriz atua sobre o vetor e modifica sua posição no espaço. Na segunda, seus vetores-coluna definem um sistema de coordenadas. A relação entre essas duas interpretações será desenvolvida na seção seguinte.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções inicialmente ortogonais. O marcador de ângulo reto identifica os casos em que a ortogonalidade é preservada.

A rotação e a reflexão mantêm a circunferência unitária e preservam o ângulo reto entre as duas direções. O escalonamento não uniforme transforma a circunferência em uma elipse; embora as duas direções coordenadas permaneçam ortogonais neste exemplo particular, seus comprimentos são alterados e a transformação não é ortogonal. O cisalhamento deforma a circunferência e também altera o ângulo entre as direções.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções inicialmente ortogonais.

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$, com a ordem dos vetores fixada. Como definido no capítulo anterior, a matriz formada pelos vetores da base é

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes, $\mathbf{B}$ é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Assim, $\mathbf{B}$ converte as coordenadas de $\mathbf{x}$ na base $\mathcal{B}$ em suas coordenadas na base canônica, enquanto $\mathbf{B}^{-1}$ realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{B}^{\top}\mathbf{B} = \mathbf{I}_p.$$

Logo,

$$\mathbf{B}^{-1} = \mathbf{B}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{\top}\mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top}\mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top}\mathbf{x} \end{bmatrix},$$

de modo que cada coordenada é obtida pelo produto interno entre $\mathbf{x}$ e o vetor correspondente da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$,

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\},$$

e as respectivas matrizes

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p]$$

e

$$\mathbf{C} = [\mathbf{c}_1 \quad \dots \quad \mathbf{c}_p].$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{C}[\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{C}[\mathbf{x}]_{\mathcal{C}} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando à esquerda por $\mathbf{C}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.5 (Matriz de mudança de base). A **matriz de mudança de base de $\mathcal{B}$ para $\mathcal{C}$** é

$$\mathbf{C}^{-1}\mathbf{B}.$$

Ela transforma as coordenadas de um vetor na base $\mathcal{B}$ em suas coordenadas na base $\mathcal{C}$:

$$[\mathbf{x}]_{\mathcal{C}} = (\mathbf{C}^{-1}\mathbf{B}) [\mathbf{x}]_{\mathcal{B}}.$$

O sentido da conversão deve ser observado na ordem das matrizes:

$$\mathcal{B} \longrightarrow \mathcal{C} \quad \Longleftrightarrow \quad \mathbf{C}^{-1}\mathbf{B}.$$

No sentido contrário, a matriz de mudança de base é

$$\mathbf{B}^{-1}\mathbf{C}.$$

As duas matrizes são inversas entre si:

$$\mathbf{B}^{-1}\mathbf{C} = (\mathbf{C}^{-1}\mathbf{B})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio, com matriz

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p],$$

e seja $\mathcal{C}$ uma base do contradomínio, com matriz

$$\mathbf{C} = [\mathbf{c}_1 \quad \cdots \quad \mathbf{c}_q].$$

Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{C}^{-1}T(\mathbf{x}) \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Proposição 4.13 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

A fórmula pode ser interpretada pela sequência das operações, da direita para a esquerda:

$$[\mathbf{x}]_{\mathcal{B}} \xrightarrow{\mathbf{B}} \mathbf{x} \xrightarrow{\mathbf{A}} T(\mathbf{x}) \xrightarrow{\mathbf{C}^{-1}} [T(\mathbf{x})]_{\mathcal{C}}.$$

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.4 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{C}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}
[T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{C}^{-1} \mathbf{A} \mathbf{B} \\
&= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\
&= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}.
\end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio,

$$[T]_{\mathcal{B} \leftarrow \mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Quando conveniente, essa matriz será denotada abreviadamente por

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Definição 4.6 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{D}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Proposição 4.14 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{D}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{D}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{D}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{D}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

Comprovação. Para o determinante,

$$\begin{aligned} \det(\mathbf{D}) &= \det(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}). \end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{D}) &= \text{tr}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \text{tr}(\mathbf{A} \mathbf{P} \mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}). \end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) = \text{posto}(\mathbf{A}).$$

□

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}_{\theta}$,

$$\mathbf{Q}_{\theta}^{-1} = \mathbf{Q}_{\theta}^{\top} = \mathbf{Q}(-\theta).$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$

Portanto, embora uma mesma matriz ortogonal possa aparecer nas duas interpretações, o sentido da operação é distinto: na transformação ativa, $\mathbf{Q}$ atua sobre o vetor; na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$, a conversão das coordenadas é realizada por $\mathbf{Q}^{-1} = \mathbf{Q}^\top$.

A Figura 4.7 compara as duas interpretações.




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Qx}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa por $\mathbf{Q}$	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base formada pelas colunas de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.7 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui dimensão $n \times q$ e contém n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

As dimensões da transformação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} + \underbrace{\mathbf{1}_n}_{n \times 1} \underbrace{\mathbf{b}^\top}_{1 \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned}
\mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\
&= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\
&= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.
\end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. Em contraste, a aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Além disso,

$$\mathbf{H}_n = \mathbf{H}_n^\top$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Portanto, $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

seu núcleo é

$$\mathcal{N}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\},$$

e sua imagem é o subespaço

$$\mathcal{C}(\mathbf{H}_n) = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\} = \text{span}\{\mathbf{1}_n\}^\perp.$$

Assim, multiplicar uma variável observada por $\mathbf{H}_n$ equivale a projetá-la ortogonalmente sobre o subespaço dos vetores cujas componentes somam zero.

Como $\mathbf{H}_n$ é simétrica e

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{1}_n^\top \mathbf{H}_n \mathbf{X} = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Proposição 4.15 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Logo, as duas diferenças possuem a mesma norma. □

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica, em geral, distâncias e ângulos. Alguns pares particulares de vetores podem manter sua relação angular, mas a geometria euclidiana não é preservada para todos os vetores. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada pela matriz positiva definida

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas. Quando todas as escalas são iguais, isto é,

$$\mathbf{L} = \ell \mathbf{I}_p,$$

o escalonamento é uniforme: todas as distâncias são multiplicadas pelo mesmo fator $1/\ell$ e os ângulos são preservados.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1, desde que todas as variáveis apresentem desvio-padrão amostral positivo.

A interpretação da padronização como transformação afim considera $\mathbf{m}$ e $\mathbf{L}$ fixados. Quando o vetor de médias e os desvios-padrão são calculados a partir da própria matriz de dados $\mathbf{X}$, esses elementos passam a depender dos dados. Nesse caso, para os valores calculados de $\mathbf{m}$ e $\mathbf{L}$, cada observação é submetida à transformação afim

$$\mathbf{x} \mapsto \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}),$$

mas a operação completa que associa a matriz original $\mathbf{X}$ à matriz padronizada $\mathbf{Z}$ é dependente dos dados e não constitui, globalmente, uma transformação afim de $\mathbf{X}$.

Para duas observações padronizadas,

$$\begin{aligned}\mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j) .\end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j) .$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}) .$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x} ,$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m} .$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1} \mathbf{m} .$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim de $\mathbb{R}^p$ em $\mathbb{R}^p$ é invertível se, e somente se, sua parte linear $\mathbf{A}$ é invertível.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos. O mesmo vetor de escalas é utilizado no escalonamento e na padronização, permitindo separar visualmente o efeito da alteração de escala do efeito da centralização.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as diferenças nem as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e, em geral, modifica comprimentos, distâncias e ângulos. A padronização combina esses dois efeitos: centraliza a nuvem e reescala suas coordenadas.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão para um vetor	Linear como função de $\mathbf{x}$?	Mantém a origem fixa?
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalação	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares podem modificar direção, escala ou dimensão, mas mantêm necessariamente a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando consideradas como operações sobre uma observação individual e para parâmetros de localização e escala fixados. Quando a centralização de uma matriz de dados é escrita como $\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$, a operação é linear no espaço das matrizes.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Para uma transformação

$$T : V \longrightarrow W,$$

tem-se

$$T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica, entre outras consequências,

$$T(\mathbf{0}) = \mathbf{0},$$

e permite determinar uma transformação linear a partir de sua ação sobre uma base do domínio.

Fixadas as bases do domínio e do contradomínio, uma transformação linear possui uma representação matricial única. Em particular, nas bases canônicas, uma transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Quando as observações ocupam as linhas de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea das observações é

$$\mathbf{Y} = \mathbf{XA}^{\top}.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada, enquanto cada coluna corresponde a uma combinação linear das variáveis originais.

A matriz associada à transformação permite relacionar os conceitos desenvolvidos neste capítulo aos espaços fundamentais estudados anteriormente:

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o núcleo reúne os vetores eliminados pela transformação, enquanto a imagem contém todos os vetores que podem ser produzidos por ela. Pelo teorema posto-nulidade,

$$\dim \ker(T_{\mathbf{A}}) + \dim \operatorname{Im}(T_{\mathbf{A}}) = p,$$

ou, equivalentemente,

$$\dim \mathcal{N}(\mathbf{A}) + \operatorname{posto}(\mathbf{A}) = p.$$

O posto é, portanto, a dimensão da imagem da transformação. Quando o núcleo contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem e ocorre perda de informação.

Para uma transformação quadrada, as condições

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\},$$

$$\operatorname{Im}(T_{\mathbf{A}}) = \mathbb{R}^p,$$

$$\operatorname{posto}(\mathbf{A}) = p,$$

$$\det(\mathbf{A}) \neq 0$$

e a existência de $\mathbf{A}^{-1}$ são equivalentes.

A composição de transformações corresponde ao produto de suas matrizes. Se T_1 é representada por $\mathbf{A}_1$ e T_2 por $\mathbf{A}_2$, então

$$[T_2 \circ T_1] = \mathbf{A}_2 \mathbf{A}_1.$$

A matriz situada à direita atua primeiro. Como o produto matricial não é comutativo, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas ilustram diferentes efeitos possíveis sobre uma configuração. Rotações e reflexões são transformações ortogonais e preservam a geometria euclidiana. Escalonamentos alteram as escalas das direções coordenadas; cisalhamentos modificam, em geral, ângulos e comprimentos; projeções eliminam componentes pertencentes ao complemento do subespaço sobre o qual se projeta.

Para uma transformação quadrada,

$$|\det(\mathbf{A})|$$

representa o fator de alteração do volume p -dimensional. Quando $\det(\mathbf{A}) \neq 0$, seu sinal informa também o efeito sobre a orientação: valores positivos preservam a orientação e valores negativos a invertem. Se

$$\det(\mathbf{A}) = 0,$$

a transformação reduz a dimensão e o volume p -dimensional da imagem é igual a zero.

As transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos e, consequentemente, normas, distâncias, ângulos e ortogonalidade. Além disso,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) \in \{-1, 1\},$$

de modo que também preservam volumes p -dimensionais.

As colunas de uma matriz ortogonal formam uma base ortonormal e satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij}.$$

Essa propriedade estabelece a ligação entre transformações ortogonais e sistemas de coordenadas ortonormais.

Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

é uma base de $\mathbb{R}^p$ e

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p],$$

então

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Para duas bases $\mathcal{B}$ e $\mathcal{C}$, com matrizes $\mathbf{B}$ e $\mathbf{C}$, respectivamente, a conversão das coordenadas de $\mathcal{B}$ para $\mathcal{C}$ é

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Se uma transformação é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Quando a mesma base é utilizada no domínio e no contradomínio,

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B},$$

de modo que as duas matrizes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa e a mudança passiva de coordenadas devem ser diferenciadas. Se $\mathbf{Q}$ é ortogonal, na transformação ativa,

$$\mathbf{y} = \mathbf{Q}\mathbf{x},$$

enquanto, na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top}\mathbf{x}.$$

Na primeira situação, o vetor é transformado em relação a eixos fixos. Na segunda, o vetor geométrico permanece o mesmo e apenas sua representação em coordenadas é alterada.

As transformações afins generalizam as transformações lineares por meio da inclusão de uma translação:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização de uma observação em torno de um vetor fixo é uma transformação afim, enquanto o escalonamento é uma transformação linear diagonal. A padronização combina essas duas operações.

Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Como

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

a matriz $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Sua imagem é

$$\mathcal{C}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\}^\perp,$$

o subespaço dos vetores cujas componentes somam zero.

A Tabela 4.6 reúne algumas das principais expressões desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$	Transforma simultaneamente as observações
Núcleo	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$	Reúne os vetores enviados ao vetor nulo
Imagem	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$	Reúne os vetores alcançados pela transformação
Composição	$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{A}_2 \mathbf{A}_1 \mathbf{x}$	Aplica T_1 antes de T_2
Transformação inversa	$\mathbf{x} = \mathbf{A}^{-1} \mathbf{y}$	Recupera o vetor original quando $\mathbf{A}$ é invertível
Rotação	$\mathbf{Q}_\theta \mathbf{x}$	Preserva a geometria e a orientação

Objeto ou operação	Expressão	Interpretação
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria; seu efeito sobre a orientação é determinado pelo determinante
Escalonamento	$\mathbf{L}\mathbf{x}$	Reescala direções coordenadas
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração preservando volume no caso elementar
Projeção ortogonal	$\mathbf{P}_S\mathbf{x}$	Mantém a componente em S e elimina a componente em $S^\perp$
Coordenadas em uma base	$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}$	Representa o mesmo vetor na base $\mathcal{B}$
Mudança de $\mathcal{B}$ para $\mathcal{C}$	$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}$	Converte coordenadas entre bases
Transformação em bases gerais	$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}$	Representa a transformação nas bases escolhidas
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização dos dados	$\mathbf{X}_c = \mathbf{H}_n\mathbf{X}$	Projeta cada variável no subespaço de média zero
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

Ao final deste capítulo, o estudante deverá ser capaz de:

- reconhecer e verificar a linearidade de uma transformação;
- construir a matriz de uma transformação a partir da imagem de uma base;
- relacionar núcleo e imagem de uma transformação ao espaço nulo e ao espaço coluna da matriz associada;
- interpretar posto, injetividade, sobrejetividade, bijetividade e perda de informação;
- representar a composição e a inversão de transformações por operações matriciais;
- interpretar geometricamente rotações, reflexões, escalonamentos, cisalhamentos e projeções;
- relacionar o determinante à alteração de volume, à orientação e à redução de dimensão;
- reconhecer transformações ortogonais e interpretar as propriedades geométricas que elas preservam;
- converter coordenadas entre bases;
- representar uma transformação linear em bases distintas do domínio e do contradomínio;
- distinguir transformação ativa e mudança passiva de coordenadas;
- interpretar transformações afins, centralização, escalonamento e padronização;

- reconhecer a matriz de centralização como uma matriz de projeção ortogonal.

No próximo capítulo, serão estudadas direções especiais para as quais a ação de uma transformação linear produz um múltiplo escalar do próprio vetor,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Essas direções conduzem aos conceitos de autovetores, autovalores, autoespaços e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Vimos também que a matriz de um operador depende da base utilizada para representá-lo. Uma mudança de base pode produzir uma matriz mais simples, embora o operador linear permaneça o mesmo. Neste capítulo, procuraremos bases especialmente adaptadas à ação do operador.

Algumas direções possuem um comportamento particularmente simples: quando um vetor pertence a uma dessas direções, sua imagem permanece na mesma reta que passa pela origem. A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço.

Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. A diagonalização pode, portanto, ser interpretada como uma mudança para um sistema de coordenadas em que a transformação atua separadamente sobre cada direção da base.

Para matrizes simétricas reais, essa simplificação possui propriedades adicionais: todos os autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permitirá interpretar formas quadráticas, matrizes positivas definidas, elipsoides, funções de matrizes e problemas de otimização. Essas estruturas serão retomadas nos capítulos de SVD, covariâncias e técnicas multivariadas.

Convenções de notação

Ao longo deste capítulo:

- λ representa um autovalor;

- $\mathbf{v}$ representa um autovetor;
- $\mathcal{E}_\lambda$ representa o autoespaço associado a λ ;
- $m_a(\lambda)$ e $m_g(\lambda)$ representam, respectivamente, as multiplicidades algébrica e geométrica;
- $\mathcal{B}_\mathbf{A}$ representa uma base de autovetores de $\mathbf{A}$, quando tal base existe;
- $\mathbf{B}_\mathbf{A}$ representa a matriz formada pelos vetores da base $\mathcal{B}_\mathbf{A}$;
- $\Lambda_\mathbf{A}$ representa a matriz diagonal dos autovalores correspondente à ordenação escolhida dos autovetores;
- $\mathbf{Q}_\mathbf{A}$ representa uma matriz ortogonal de autovetores quando $\mathbf{A}$ é simétrica;
- Π_λ representa o projetor espectral associado ao autoespaço de λ ;
- $\mathcal{R}_\mathbf{A}(\mathbf{x})$ representa o quociente de Rayleigh.

Salvo indicação contrária, as interpretações geométricas serão desenvolvidas em espaços vetoriais reais. Autovalores e autovetores complexos serão considerados explicitamente quando necessário.

5.1 Direções invariantes, autovalores e autoespaços

Definição 5.1 (Subespaço invariante). Considere

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p.$$

O subespaço $\mathcal{W}$ é **invariante sob $\mathbf{A}$** quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo

$$\mathbf{w} \in \mathcal{W}.$$

Isso significa que a multiplicação por $\mathbf{A}$ transforma vetores de $\mathcal{W}$ em vetores que permanecem no próprio subespaço $\mathcal{W}$.

Um caso particularmente importante ocorre quando o subespaço invariante possui dimensão 1.

Seja

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span}\{\mathbf{v}\} = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Como $\mathbf{v} \neq \mathbf{0}$, o conjunto $\{\mathbf{v}\}$ é uma base de $\mathcal{W}$ e, portanto,

$$\dim(\mathcal{W}) = 1.$$

Geometricamente, $\mathcal{W}$ corresponde a uma reta que passa pela origem e está contida em $\mathbb{R}^p$.

Se $\mathcal{W}$ é invariante sob $\mathbf{A}$, então

$$\mathbf{A}\mathbf{v} \in \mathcal{W}.$$

Como todos os vetores de $\mathcal{W}$ são múltiplos escalares de $\mathbf{v}$, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Assim, a ação de $\mathbf{A}$ sobre $\mathbf{v}$ mantém sua imagem na mesma reta gerada por $\mathbf{v}$. A magnitude pode ser alterada e, dependendo do sinal de λ , também pode ocorrer mudança de sentido.

Exemplo 5.1 (Uma reta invariante em $\mathbb{R}^2$). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

e o vetor

$$\mathbf{v} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\},$$

que corresponde à reta

$$x_2 = x_1$$

em $\mathbb{R}^2$.

Aplicando $\mathbf{A}$ ao vetor $\mathbf{v}$,

$$\begin{aligned} \mathbf{A}\mathbf{v} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= 3\mathbf{v}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v} \in \mathcal{W},$$

e a reta $\mathcal{W}$ é invariante sob $\mathbf{A}$. Nesse caso, a transformação multiplica os vetores dessa direção por um fator igual a 3, sem retirar suas imagens da reta.

A relação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

observada nesse caso conduz às definições de autovalor e autovetor.

Definição 5.2 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.2 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{Ax} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$. As retas tracejadas em cinza representam as duas direções invariantes.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

Um autovetor não é único. Se $\mathbf{v}$ é um autovetor associado ao autovalor λ , então qualquer múltiplo não nulo de $\mathbf{v}$ também é um autovetor associado ao mesmo autovalor.

Proposição 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

Comprovação. Como

$$\mathbf{Av} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned} \mathbf{A}(c\mathbf{v}) &= c\mathbf{Av} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}). \end{aligned}$$




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ . □

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.3 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Proposição 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

Comprovação. Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda\mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$. □

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição do autoespaço transforma a busca por autovetores em um problema de núcleo. Para um valor fixado de λ , existem autovetores associados precisamente quando

$$\mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p) \neq \{\mathbf{0}\}.$$

Resta, portanto, determinar quais valores de λ tornam esse núcleo não trivial. Essa condição equivale à singularidade de $\mathbf{A} - \lambda \mathbf{I}_p$ e conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo.

Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.1 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Comprovação. Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$. □

Definição 5.4 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn; Johnson, 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ($\theta = \frac{\pi}{2}$),

$$\mathbf{Q}_{\frac{\pi}{2}} = \begin{bmatrix} \cos\left(\frac{\pi}{2}\right) & -\sin\left(\frac{\pi}{2}\right) \\ \sin\left(\frac{\pi}{2}\right) & \cos\left(\frac{\pi}{2}\right) \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovalores reais e, conseqüentemente, não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando a mesma matriz é considerada como um operador em $\mathbb{C}^2$, ela possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente no contexto real. Em particular, toda matriz simétrica real possui autovalores reais e admite uma base ortonormal de autovetores reais.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.2 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

Comprovação. A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \dots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes. $\square$

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.5 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Exemplo 5.3 (Mesma multiplicidade algébrica e diferentes multiplicidades geométricas). Considere as matrizes

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Polinômio característico e multiplicidade algébrica

Para $\mathbf{A}_1$,

$$\begin{aligned} p_{\mathbf{A}_1}(\lambda) &= \det(\mathbf{A}_1 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Para $\mathbf{A}_2$,

$$\begin{aligned} p_{\mathbf{A}_2}(\lambda) &= \det(\mathbf{A}_2 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 1 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Portanto, as duas matrizes possuem o mesmo polinômio característico,

$$p(\lambda) = (2 - \lambda)^2,$$

e, conseqüentemente, o mesmo autovalor,

$$\lambda = 2.$$

Como o fator $(2 - \lambda)$ aparece duas vezes no polinômio característico, o autovalor $\lambda = 2$ possui multiplicidade algébrica

$$m_a(2) = 2$$

para ambas as matrizes.

Autoespaço de $\mathbf{A}_1$

Para determinar o autoespaço associado a $\lambda = 2$, procuramos todos os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$\mathbf{A}_1 \mathbf{v} = 2\mathbf{v}.$$

Essa equação pode ser escrita como

$$(\mathbf{A}_1 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando a matriz,

$$\begin{aligned}\mathbf{A}_1 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.\end{aligned}$$

Assim, o sistema a ser resolvido é

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

ou seja,

$$\begin{cases} 0 = 0, \\ 0 = 0. \end{cases}$$

O sistema não impõe nenhuma restrição sobre v_1 e v_2 . Portanto, ambos são livres e qualquer vetor de $\mathbb{R}^2$ pertence ao espaço nulo de $\mathbf{A}_1 - 2\mathbf{I}_2$.

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_1 - 2\mathbf{I}_2) = \mathbb{R}^2.$$

Como

$$\dim(\mathbb{R}^2) = 2,$$

temos

$$m_g(2) = \dim(E_2) = 2.$$

Assim, todo vetor não nulo de $\mathbb{R}^2$ é um autovetor de $\mathbf{A}_1$ associado ao autovalor $\lambda = 2$.

Autoespaço de $\mathbf{A}_2$

Para $\mathbf{A}_2$, procuramos novamente os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$(\mathbf{A}_2 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando,

$$\begin{aligned} \mathbf{A}_2 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Efetuando a multiplicação,

$$\begin{bmatrix} v_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

o que corresponde ao sistema

$$\begin{cases} v_2 = 0, \\ 0 = 0. \end{cases}$$

Nesse caso, v_2 deve ser igual a zero, enquanto v_1 permanece livre. Assim, todo vetor do autoespaço possui a forma

$$\mathbf{v} = \begin{bmatrix} v_1 \\ 0 \end{bmatrix} = v_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_2 - 2\mathbf{I}_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}.$$

Esse autoespaço possui uma única direção linearmente independente. Portanto,

$$m_g(2) = \dim(E_2) = 1.$$

As duas matrizes possuem, portanto, o mesmo autovalor $\lambda = 2$ e a mesma multiplicidade algébrica,

$$m_a(2) = 2,$$

mas apresentam multiplicidades geométricas diferentes:

$$m_g(2) = \begin{cases} 2, & \text{para } \mathbf{A}_1, \\ 1, & \text{para } \mathbf{A}_2. \end{cases}$$

A diferença decorre da dimensão dos respectivos autoespaços. Para $\mathbf{A}_1$, o autoespaço é todo o plano $\mathbb{R}^2$; para $\mathbf{A}_2$, o autoespaço é apenas a reta gerada por $(1, 0)^\top$.

A Figura 5.2 compara as estruturas dos dois autoespaços.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

No capítulo anterior, vimos que a matriz de um operador depende da base utilizada para representá-lo. A diagonalização corresponde à escolha de uma base particularmente conveniente: uma base formada por autovetores.

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e suponha que exista uma base de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

A matriz dessa base é

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Como os vetores da base são linearmente independentes, $\mathbf{B}_{\mathbf{A}}$ é invertível.

Se

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad j = 1, \dots, p,$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

então

$$\mathbf{A}\mathbf{B}_{\mathbf{A}} = \mathbf{B}_{\mathbf{A}}\Lambda_{\mathbf{A}}.$$

Multiplicando à esquerda por $\mathbf{B}_{\mathbf{A}}^{-1}$,

$$\mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Definição 5.6 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existe uma base $\mathcal{B}_{\mathbf{A}}$ de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Equivalentemente, existem uma matriz invertível $\mathbf{B}_{\mathbf{A}}$ e uma matriz diagonal $\Lambda_{\mathbf{A}}$ tais que

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A ordem das colunas de $\mathbf{B}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Pela notação de mudança de base desenvolvida no capítulo anterior,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Assim, $\Lambda_{\mathbf{A}}$ é a matriz do mesmo operador quando tanto o domínio quanto o contradomínio são representados na base de autovetores.

Para qualquer vetor $\mathbf{x} \in \mathbb{R}^p$, suas coordenadas nessa base são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{x},$$

de modo que

$$\mathbf{x} = \mathbf{B}_{\mathbf{A}} \mathbf{z}.$$

Nas coordenadas da base de autovetores,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}} [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Como

$$\Lambda_{\mathbf{A}} \mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix},$$

a transformação atua separadamente sobre cada coordenada: a componente correspondente ao autovetor $\mathbf{v}_j$ é multiplicada por λ_j .

A diagonalização é, portanto, uma mudança para um sistema de coordenadas no qual as direções da base são invariantes e a ação do operador deixa de misturar coordenadas.

Teorema 5.3 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

- 1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;*
- 2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;*
- 3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. a soma das dimensões dos autoespaços é igual a p ;*
- 5. para cada autovalor λ ,*

$$m_g(\lambda) = m_a(\lambda).$$

(Horn; Johnson, 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.2 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \\ &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{B}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{B}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Assim, a aplicação repetida do operador pode ser analisada coordenada a coordenada na base de autovetores: após k aplicações, a coordenada associada a $\mathbf{v}_j$ é multiplicada por λ_j^k .

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.4 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

- 1. todos os autovalores de $\mathbf{A}$ são reais;*
- 2. autoespaços associados a autovalores distintos são ortogonais;*
- 3. existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_\mathbf{A} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

(Horn; Johnson, 2013)

Comprovação. Para demonstrar que os autovalores são reais, considere um autovalor possivelmente complexo λ e um autovetor complexo não nulo $\mathbf{z}$, de modo que

$$\mathbf{A}\mathbf{z} = \lambda\mathbf{z}.$$

Como $\mathbf{A}$ é real e simétrica, ela também é hermitiana:

$$\mathbf{A}^* = \mathbf{A},$$

em que $*$ representa a transposta conjugada.

Multiplicando a equação de autovalor à esquerda por $\mathbf{z}^*$,

$$\mathbf{z}^* \mathbf{A} \mathbf{z} = \lambda \mathbf{z}^* \mathbf{z}.$$

A quantidade

$$\mathbf{z}^* \mathbf{A} \mathbf{z}$$

é real, pois

$$(\mathbf{z}^* \mathbf{A} \mathbf{z})^* = \mathbf{z}^* \mathbf{A}^* \mathbf{z} = \mathbf{z}^* \mathbf{A} \mathbf{z}.$$

Além disso,

$$\mathbf{z}^* \mathbf{z} > 0.$$

Portanto,

$$\lambda = \frac{\mathbf{z}^* \mathbf{A} \mathbf{z}}{\mathbf{z}^* \mathbf{z}}$$

é real.

Considere agora dois autovetores reais $\mathbf{v}_i$ e $\mathbf{v}_j$, associados a autovalores distintos λ_i e λ_j . Como

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j\mathbf{v}_j,$$

tem-se

$$\begin{aligned}\lambda_i\mathbf{v}_i^\top\mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}\mathbf{v}_j \\ &= \lambda_j\mathbf{v}_i^\top\mathbf{v}_j.\end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j)\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Portanto, os autoespaços associados a autovalores distintos são ortogonais.

A existência de uma base ortonormal de autovetores pode ser demonstrada por indução sobre a ordem p da matriz. Para $p = 1$, o resultado é imediato.

Suponha agora $p > 1$. Pelo Teorema Fundamental da Álgebra, o polinômio característico de $\mathbf{A}$ possui pelo menos uma raiz em $\mathbb{C}$. Pela primeira parte da demonstração, essa raiz é real. Denote-a por λ_1 .

Como

$$\det(\mathbf{A} - \lambda_1\mathbf{I}_p) = 0,$$

a matriz real

$$\mathbf{A} - \lambda_1\mathbf{I}_p$$

é singular e possui um vetor não nulo real em seu núcleo. Normalizando esse vetor, obtém-se um autovetor unitário $\mathbf{q}_1$.

Considere o complemento ortogonal

$$\mathcal{W} = \text{span} \{ \mathbf{q}_1 \}^\perp.$$

Para qualquer $\mathbf{x} \in \mathcal{W}$,

$$\mathbf{q}_1^\top \mathbf{x} = 0.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \mathbf{q}_1^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{q}_1)^\top \mathbf{x} \\ &= \lambda_1 \mathbf{q}_1^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{x} \in \mathcal{W},$$

e $\mathcal{W}$ é invariante sob $\mathbf{A}$.

A restrição de $\mathbf{A}$ a $\mathcal{W}$ permanece simétrica. Como

$$\dim(\mathcal{W}) = p - 1,$$

a hipótese de indução garante uma base ortonormal

$$\mathbf{q}_2, \dots, \mathbf{q}_p$$

de $\mathcal{W}$ formada por autovetores da restrição e, consequentemente, de $\mathbf{A}$.

Assim,

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$ composta por autovetores de $\mathbf{A}$.

Organizando esses vetores nas colunas de

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

tem-se

$$\mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}} = \mathbf{I}_p.$$

Portanto,

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Definindo

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a relação

$$\mathbf{A} \mathbf{Q}_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}$$

fornece

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

□

A representação

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela é uma diagonalização ortogonal.

Considere a base ortonormal de autovetores

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\}.$$

A matriz dessa base é

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_p].$$

Assim, no caso simétrico, a matriz da base de autovetores introduzida na seção anterior pode ser escolhida ortogonal:

$$\mathbf{B}_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}},$$

com

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Pela notação de coordenadas desenvolvida no capítulo anterior,

$$[\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x}.$$

Denotando

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}},$$

tem-se

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z}.$$

A matriz do operador nessa base é

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{A} \mathbf{Q}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Consequentemente,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}} [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Em coordenadas canônicas,

$$\begin{aligned} \mathbf{A} \mathbf{x} &= \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x} \\ &= \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{z}. \end{aligned}$$

A ação da matriz pode ser interpretada em três etapas:

1. $\mathbf{Q}_{\mathbf{A}}^{\top}$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. $\Lambda_{\mathbf{A}}$ multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_{\mathbf{A}}$ reconstrói o vetor nas coordenadas canônicas.

Assim, uma matriz simétrica atua por fatores escalares independentes em direções ortogonais. Quando algum autovalor é negativo, o escalonamento na direção correspondente inclui também a inversão do sentido.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.4 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \mathbf{q}_2\}$$

é uma base ortonormal de autovetores de $\mathbb{R}^2$.

A matriz dessa base é a matriz ortogonal

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a circunferência unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária em $\mathbb{R}^p$ são determinados por

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por fatores escalares independentes.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{Ax} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Proposição 5.3 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn; Johnson, 2013)

Comprovação. As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Proposição 3.16, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned} \Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h \mathbf{Q}_h^\top \mathbf{Q}_\ell \mathbf{Q}_\ell^\top \\ &= \mathbf{0}. \end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

□

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_{\lambda} = \mathbf{q}\mathbf{q}^{\top}.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_{\mathbf{A}}$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Proposição 5.4 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

Comprovação. Pela propriedade cíclica do traço,

$$\begin{aligned} \text{tr}(\mathbf{A}) &= \text{tr}(\mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \text{tr}(\Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}}) \\ &= \text{tr}(\Lambda_{\mathbf{A}}) \\ &= \sum_{j=1}^p \lambda_j. \end{aligned}$$

Para o determinante,

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{Q}_{\mathbf{A}}) \det(\Lambda_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \det(\Lambda_{\mathbf{A}}), \end{aligned}$$

pois

$$\det(\mathbf{Q}_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_{\mathbf{A}}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ são semelhantes, pois

$$\Lambda_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{A} \mathbf{Q}_{\mathbf{A}}.$$

Como a multiplicação à esquerda e à direita por matrizes invertíveis preserva o posto, $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned} \dim \mathcal{N}(\mathbf{A}) &= p - \text{posto}(\mathbf{A}) \\ &= \# \{j : \lambda_j = 0\}. \end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos. □

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Proposição 5.5 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}$$

é a decomposição espectral de uma matriz simétrica, então

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^{\perp},$$

ou, equivalentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

Comprovação. Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores associados a autovalores nulos são ortogonais aos autovetores associados a autovalores não nulos, e juntos formam uma base ortonormal de $\mathbb{R}^p$, os dois subespaços são complementos ortogonais. $\square$

O autoespaço associado ao autovalor zero reúne exatamente as direções eliminadas pela transformação. Os autoespaços associados a autovalores não nulos constituem, em conjunto, a imagem da transformação.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.23, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são determinadas pelos sinais dos autovalores, enquanto o valor assumido para um vetor específico depende também de suas coordenadas espectrais $z_1, \dots, z_p$.

Exemplo 5.5 (Forma quadrática em coordenadas espectrais). Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 3 \quad \text{e} \quad \lambda_2 = 1,$$

com autovetores ortonormais associados

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{Q}_\mathbf{A} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda_\mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral de $\mathbf{A}$ é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Considere agora o vetor

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Nas coordenadas originais, a forma quadrática é

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} \\ &= 14. \end{aligned}$$

Equivalentemente, escrevendo a forma quadrática em função das coordenadas originais,

$$q_{\mathbf{A}}(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 2x_2^2.$$

Observe a presença do produto cruzado $2x_1x_2$.

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x}.$$

Como

$$\mathbf{Q}_{\mathbf{A}}^{\top} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{z} &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$z_1 = \frac{3}{\sqrt{2}} \quad \text{e} \quad z_2 = \frac{1}{\sqrt{2}}.$$

Nas coordenadas espectrais, a mesma forma quadrática é

$$\begin{aligned}
q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\
&= \lambda_1 z_1^2 + \lambda_2 z_2^2 \\
&= 3 \left(\frac{3}{\sqrt{2}} \right)^2 + 1 \left(\frac{1}{\sqrt{2}} \right)^2 \\
&= 3 \left(\frac{9}{2} \right) + \frac{1}{2} \\
&= 14.
\end{aligned}$$

Assim, nas coordenadas espectrais,

$$q_{\mathbf{A}}(\mathbf{x}) = 3z_1^2 + z_2^2,$$

sem produtos cruzados. A mudança de coordenadas não altera o valor da forma quadrática; ela apenas a expressa em uma base na qual a matriz é diagonal.

Proposição 5.6 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn; Johnson, 2013)

Comprovação. Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos. $\square$

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{(c/\lambda_j)} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.6 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^\top \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^\top \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

O termo cruzado $2x_1x_2$ presente nas coordenadas canônicas desaparece nas coordenadas espectrais porque os eixos coordenados passam a coincidir com as direções principais da forma quadrática.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh

Definição 5.7 (Quociente de Rayleigh). Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$. O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma euclidiana de $\mathbf{a}$.

Quando $\mathbf{A}$ é definida positiva, a forma quadrática também pode ser escrita como

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{A}},$$

em que $\langle \cdot, \cdot \rangle_{\mathbf{A}}$ é o produto interno induzido por $\mathbf{A}$, definido em Definição 3.16.

A divisão por $\|\mathbf{a}\|^2$ remove o efeito da magnitude do vetor. Consequentemente, o quociente de Rayleigh depende da direção determinada por $\mathbf{a}$, e não de seu comprimento.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}). \end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

As coordenadas de $\mathbf{a}$ na base espectral são

$$\mathbf{z} = [\mathbf{a}]_{\mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{a},$$

de modo que

$$\mathbf{a} = \mathbf{Q}_\mathbf{A} \mathbf{z}.$$

Como $\mathbf{Q}_\mathbf{A}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda_\mathbf{A} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

Portanto,

$$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é, portanto, uma média ponderada dos autovalores. Para uma base espectral fixada, ω_j mede a proporção do comprimento ao quadrado de $\mathbf{a}$ associada à direção $\mathbf{q}_j$.

Quando um autovalor λ possui multiplicidade maior que 1, a quantidade intrínseca ao autoespaço correspondente é a soma dos pesos associados aos vetores de uma base ortonormal desse autoespaço. Essa soma é igual à proporção do comprimento ao quadrado da projeção de $\mathbf{a}$ sobre $\mathcal{E}_\lambda$.

Teorema 5.5 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço associado a λ_p . (Horn; Johnson, 2013)

Comprovação. Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido. □

Se o maior autovalor é simples, a reta que maximiza o quociente é

$$\text{span}\{\mathbf{q}_1\}.$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

Exemplo 5.7 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da circunferência unitária.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.

5.5.2 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição de norma separa a escolha da **direção** da escolha da magnitude do vetor. De fato,

$$(c\mathbf{a})^{\top} \mathbf{A} (c\mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}.$$

Portanto, sem uma normalização, o valor da forma quadrática pode ser alterado simplesmente pelo escalonamento do vetor, mesmo quando sua direção permanece a mesma.

Se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

o problema de maximização sem restrição é ilimitado superiormente. Analogamente, se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} < 0,$$

o problema de minimização sem restrição é ilimitado inferiormente.

A condição

$$\mathbf{a}^{\top} \mathbf{a} = 1$$

elimina esse efeito de escala e restringe a otimização às direções representadas por vetores unitários.

5.5.3 Multiplicadores de Lagrange

Em diferentes problemas da Estatística Multivariada, procura-se uma **direção** no espaço das variáveis que torne máxima ou mínima alguma quantidade de interesse. Essa quantidade pode representar, por exemplo, variabilidade, separação entre grupos ou associação entre conjuntos de variáveis.

Uma direção pode ser representada por um vetor $\mathbf{a}$. Entretanto, os vetores $\mathbf{a}$ e $c\mathbf{a}$, para $c \neq 0$, representam a mesma direção, embora tenham comprimentos diferentes. Por isso, quando o interesse está apenas na direção, é conveniente impor a normalização

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Essa restrição faz com que a busca seja realizada sobre o conjunto dos vetores unitários. Geometricamente, em $\mathbb{R}^p$, esses vetores formam a esfera unitária.

Considere agora a forma quadrática

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica. O problema consiste em investigar como o valor de $f(\mathbf{a})$ varia quando a direção $\mathbf{a}$ percorre a esfera unitária.

5.5.3.1 O que é um ponto estacionário sob uma restrição?

Em um problema sem restrições, um ponto estacionário de uma função diferenciável é um ponto no qual seu gradiente é nulo. Em um problema com restrição, essa condição precisa ser modificada, pois nem todas as direções de deslocamento são permitidas.

Neste caso, $\mathbf{a}$ deve permanecer sobre a esfera

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um ponto é estacionário para o problema restrito quando pequenas alterações de $\mathbf{a}$ que respeitam essa restrição não produzem, em primeira ordem, aumento ou redução da função objetivo.

Geometricamente, isso ocorre quando o gradiente da função objetivo não possui componente na direção tangente à superfície da restrição. De forma equivalente, o gradiente da função objetivo deve ser proporcional ao gradiente da função que define a restrição.

Essa condição é obtida pelo método dos multiplicadores de Lagrange.

Considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem para um ponto estacionário é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A} \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que as direções estacionárias do problema são precisamente direções de autovetores de $\mathbf{A}$. O multiplicador de Lagrange η é o autovalor associado à direção encontrada.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \eta \mathbf{a}^\top \mathbf{a} \\ &= \eta,\end{aligned}$$

pois $\mathbf{a}^\top \mathbf{a} = 1$.

Assim, quando $\mathbf{a}$ é um autovetor unitário associado ao autovalor λ ,

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Portanto, há uma correspondência direta:

direção estacionária $\leftrightarrow$ autovetor

e

valor da forma quadrática nessa direção $\leftrightarrow$ autovalor.

Como $\mathbf{A}$ é simétrica, seus autovalores são reais. Além disso, pelos resultados do quociente de Rayleigh, para todo vetor unitário $\mathbf{a}$,

$$\lambda_{\min} \leq \mathbf{a}^\top \mathbf{A} \mathbf{a} \leq \lambda_{\max}.$$

Os extremos são atingidos nos autoespaços associados ao menor e ao maior autovalor. Consequentemente,

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\max},$$

e

$$\min_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\min}.$$

Assim:

- o maior autovalor fornece o máximo global da forma quadrática sobre a esfera unitária;
- o menor autovalor fornece o mínimo global;

- os demais autovalores correspondem a valores estacionários intermediários;
- os autovetores associados fornecem as respectivas direções.

Teorema 5.6 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e considere*

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}$$

restrita aos vetores que satisfazem

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um vetor unitário $\mathbf{a}$ é um ponto estacionário de f sobre a esfera unitária se, e somente se, $\mathbf{a}$ é um autovetor de $\mathbf{A}$.

Se

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a},$$

então

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Em particular, o maior autovalor corresponde ao máximo global da função sobre a esfera unitária, e o menor autovalor corresponde ao mínimo global.

Este resultado permite compreender por que autovalores e autovetores surgem repetidamente em técnicas multivariadas. Em muitos casos, a técnica procura uma direção $\mathbf{a}$ que torne máxima uma quantidade expressa por uma forma quadrática.

Na Análise de Componentes Principais, por exemplo, para um vetor aleatório $\mathbf{X}$ com matriz de covariâncias Σ , a variância da combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

é

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A primeira componente principal procura a direção unitária que maximiza essa variância:

$$\max_{\mathbf{a}^\top \mathbf{a} = 1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo resultado anterior, a solução é um autovetor associado ao maior autovalor de Σ . Portanto,

maior autovalor $\longrightarrow$ maior variância possível

e

autovetor correspondente $\longrightarrow$ direção de maior variabilidade.

As componentes seguintes são obtidas acrescentando restrições de ortogonalidade às direções já encontradas. Isso conduz sucessivamente aos demais autovetores e autovalores.

A mesma estrutura reaparece, com modificações, em outros problemas multivariados. Na análise discriminante, procura-se uma direção que produza grande separação entre grupos em relação à variabilidade dentro dos grupos. Na MANOVA, determinadas direções maximizam a variação associada à hipótese em relação à variação residual. Na correlação canônica, procuram-se combinações lineares de dois conjuntos de variáveis que apresentem associação máxima.

Nesses casos, a função a ser otimizada envolve frequentemente uma razão entre duas formas quadráticas,

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{B} \mathbf{a}},$$

e a condição de estacionariedade conduz ao problema de autovalores generalizados

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{B} \mathbf{a}.$$

Assim, autovalores e autovetores aparecem nessas técnicas porque representam soluções de problemas de otimização sobre direções: os autovetores fornecem as direções de interesse e os autovalores quantificam o valor atingido pelo critério nessas direções.

5.5.4 Direções sucessivas

O problema de otimização anterior identifica uma direção associada ao maior autovalor de $\mathbf{A}$. Em muitas aplicações, entretanto, interessa obter não apenas uma direção ótima, mas uma sequência de direções que representem aspectos distintos da estrutura da matriz.

Depois de encontrar a primeira direção, pode-se procurar uma segunda direção que maximize a mesma forma quadrática, mas que seja ortogonal à primeira. O procedimento pode ser repetido sucessivamente, impondo que cada nova direção seja ortogonal às anteriormente obtidas.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição

$$\mathbf{a}^\top \mathbf{q}_1 = 0$$

impede que $\mathbf{a}$ possua componente na direção de $\mathbf{q}_1$. Assim, se $\mathbf{a}$ for escrito na base espectral,

$$\mathbf{a} = z_1 \mathbf{q}_1 + z_2 \mathbf{q}_2 + \dots + z_p \mathbf{q}_p,$$

a condição de ortogonalidade implica

$$z_1 = 0.$$

Portanto, a otimização passa a ocorrer apenas no subespaço gerado por

$$\mathbf{q}_2, \dots, \mathbf{q}_p.$$

Nesse subespaço, o maior autovalor disponível é λ_2 . Assim, o maior valor da forma quadrática é λ_2 , atingido na direção de $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.7 (Caracterização variacional de direções sucessivas). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

e seja

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação. Então, para $k = 1, \dots, p$,

$$\lambda_k = \max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por $\mathbf{q}_k$ e, quando λ_k possui multiplicidade maior que 1, por qualquer autovetor unitário associado a λ_k que satisfaça as restrições de ortogonalidade. (Horn; Johnson, 2013)

Comprovação. Como

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$, qualquer vetor $\mathbf{a}$ pode ser escrito como

$$\mathbf{a} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{a}.$$

As restrições

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1,$$

implicam

$$z_1 = \dots = z_{k-1} = 0.$$

Portanto,

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como os autovetores são ortonormais e $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Nas coordenadas espectrais,

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \sum_{j=k}^p \lambda_j z_j^2.$$

Como os autovalores estão ordenados de forma decrescente,

$$\lambda_j \leq \lambda_k, \quad j \geq k.$$

Logo,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \sum_{j=k}^p \lambda_j z_j^2 \\ &\leq \lambda_k \sum_{j=k}^p z_j^2 \\ &= \lambda_k.\end{aligned}$$

O limite é atingido tomando

$$\mathbf{a} = \mathbf{q}_k,$$

pois $\mathbf{q}_k$ possui norma unitária, é ortogonal a $\mathbf{q}_1, \dots, \mathbf{q}_{k-1}$ e satisfaz

$$\mathbf{A} \mathbf{q}_k = \lambda_k \mathbf{q}_k.$$

Assim,

$$\mathbf{q}_k^\top \mathbf{A} \mathbf{q}_k = \lambda_k.$$

Portanto,

$$\max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j=0, j=1,\dots,k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_k.$$

□

Quando há autovalores repetidos, as direções individuais dentro do autoespaço correspondente não são unicamente determinadas. Diferentes bases ortonormais desse autoespaço produzem o mesmo valor da função objetivo e representam o mesmo subespaço espectral. Assim, o subespaço associado ao autovalor repetido é bem determinado, embora a escolha particular dos autovetores que formam uma base desse subespaço não seja única.

A caracterização variacional relaciona, portanto, três objetos fundamentais:

forma quadrática $\longleftrightarrow$ problema de otimização $\longleftrightarrow$ estrutura espectral.

Além de identificar os valores extremos, essa caracterização permite obter sucessivamente as direções ortogonais associadas aos autovalores ordenados da matriz.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar real definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.8 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função real definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Proposição 5.7 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn; Johnson, 1991)

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_{\lambda}$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

□

Portanto, todo autovetor de $\mathbf{A}$ associado a λ também é autovetor de $f(\mathbf{A})$, agora associado ao autovalor $f(\lambda)$. Mais geralmente, todo o autoespaço $\mathcal{E}_{\lambda}$ de $\mathbf{A}$ permanece invariante sob $f(\mathbf{A})$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{Q}_\mathbf{A}^\top,$$

com

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_\mathbf{A}$ fornece

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top.$$

Exemplo 5.8 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.9 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a raiz quadrada principal de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{A} \succ 0$, a raiz quadrada principal é invertível e

$$\mathbf{A}^{-1/2} = (\mathbf{A}^{1/2})^{-1}.$$

Além disso,

$$\mathbf{A}^{-1} = \mathbf{A}^{-1/2} \mathbf{A}^{-1/2}$$

e

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned}\mathbf{A}^{-1/2}\mathbf{A}\mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\Lambda_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A}\mathbf{I}_p\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p.\end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2}\mathbf{x}$$

reescala as componentes espectrais de $\mathbf{x}$ segundo os fatores $1/\sqrt{\lambda_j}$. Além disso, converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned}\mathbf{x}^\top \mathbf{A}^{-1}\mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2}\mathbf{A}^{-1/2}\mathbf{x} \\ &= \mathbf{z}^\top \mathbf{z} \\ &= \|\mathbf{z}\|^2.\end{aligned}$$

Quando $\mathbf{A}$ for uma matriz de covariâncias $\Sigma \succ 0$, essa construção será retomada no branqueamento. Para um vetor com média μ , a transformação correspondente será aplicada ao vetor centralizado,

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu).$$

Nesse caso, a distância de Mahalanobis será interpretada como uma distância euclidiana nas coordenadas branqueadas.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.10 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A pseudoinversa de Moore–Penrose de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^+ \mathbf{Q}_{\mathbf{A}}^\top,$$

em que

$$\Lambda_{\mathbf{A}}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa atua separadamente sobre os autoespaços: nas direções associadas a autovalores não nulos, aplica o fator $1/\lambda$; no autoespaço associado ao autovalor zero, sua ação é nula. Assim, ela inverte a transformação sobre sua imagem e mantém eliminadas as componentes pertencentes ao núcleo.

Exemplo 5.9 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned}\mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz simétrica positiva definida, define-se o **logaritmo principal** por

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^\top.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição adicional
$\mathbf{A}^k$	λ_j^k	$k \in \{0, 1, 2, \dots\}$
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	nenhuma além da simetria assumida na seção
$\exp(\mathbf{A})$	e^{λ_j}	nenhuma além da simetria assumida na seção
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais atuam separadamente sobre os autoespaços, transformando cada autovalor λ no valor escalar $f(\lambda)$. Essa construção permite obter diretamente potências, inversas, raízes e pseudoinversas e mostra como certas transformações matriciais podem ser compreendidas como reescalonamentos das direções espectrais.

Em particular, a raiz quadrada e a raiz quadrada inversa permitem converter problemas definidos por uma geometria induzida por uma matriz positiva definida em problemas euclidianos equivalentes. Essa ideia será utilizada imediatamente na formulação dos autovalores generalizados.

5.7 Aprofundamento: autovalores generalizados

Leitura de aprofundamento

Esta seção apresenta uma extensão do problema ordinário de autovalores para situações em que duas formas quadráticas são consideradas simultaneamente. Embora esse desenvolvimento não seja necessário para acompanhar os resultados centrais da decompo-

sição espectral, ele fornece uma base matemática importante para técnicas multivariadas que envolvem a comparação entre diferentes estruturas de variabilidade, separação ou associação.

Ao longo da seção, serão apresentados os autovalores generalizados, o quociente de Rayleigh generalizado, a ortogonalidade em uma métrica definida por uma matriz positiva definida e a redução do problema generalizado a um problema espectral ordinário.

Alguns problemas de Estatística Multivariada envolvem a comparação entre duas formas quadráticas, em vez da otimização de uma única forma quadrática relativamente à norma euclidiana. Nesses casos, surge naturalmente o problema de autovalores generalizados,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

em que $\mathbf{A}$ é simétrica e $\mathbf{M}$ é simétrica positiva definida.

Essa estrutura generaliza o problema ordinário de autovalores, recuperado quando

$$\mathbf{M} = \mathbf{I}_p.$$

Os autovalores generalizados serão úteis posteriormente em problemas que envolvem a comparação entre diferentes medidas de variabilidade, separação ou associação. A leitura a seguir desenvolve a formulação matemática desse problema e sua relação com o quociente de Rayleigh e a decomposição espectral.

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.16, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.11 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda \mathbf{M}) \mathbf{v} = \mathbf{0}.$$

Existem soluções não triviais se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Essa equação é a equação característica generalizada do par $(\mathbf{A}, \mathbf{M})$ e determina seus autovalores generalizados.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.12 (Quociente de Rayleigh generalizado). Sejam $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica e $\mathbf{M} \in \mathbb{R}^{p \times p}$ simétrica positiva definida. Para $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$, o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|_{\mathbf{M}}^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma induzida por $\mathbf{M}$,

$$\|\mathbf{a}\|_{\mathbf{M}}^2 = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{M}} = \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Como $\mathbf{M} \succ \mathbf{0}$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o denominador é sempre positivo e o quociente está definido para todo vetor não nulo.

No quociente de Rayleigh ordinário, a normalização é realizada pela norma euclidiana,

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

No caso generalizado, essa normalização é substituída pela norma induzida por $\mathbf{M}$. Assim, o comprimento do vetor passa a ser medido segundo a geometria determinada por essa matriz.

Assim como no caso ordinário, o quociente é invariante à escala. Para qualquer escalar $c \neq 0$,

$$\begin{aligned}
\mathcal{R}_{\mathbf{A},\mathbf{M}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top \mathbf{M}(c\mathbf{a})} \\
&= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{M} \mathbf{a}} \\
&= \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}).
\end{aligned}$$

Portanto, o valor do quociente depende da direção determinada por $\mathbf{a}$, e não de sua magnitude segundo a norma induzida por $\mathbf{M}$.

Essa invariância permite escolher, em cada direção, um representante com norma unitária na geometria determinada por $\mathbf{M}$. Consequentemente, o problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição equivale a

$$\|\mathbf{a}\|_{\mathbf{M}} = 1$$

e, portanto, fixa o comprimento de $\mathbf{a}$ segundo a geometria induzida por $\mathbf{M}$.

Para determinar os pontos estacionários desse problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{M} \mathbf{a}) = 2\mathbf{M} \mathbf{a}.$$

Assim,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A} \mathbf{a} - 2\eta \mathbf{M} \mathbf{a}.$$

A condição de primeira ordem

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0}$$

produz

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que todo ponto estacionário $\mathbf{a}$ é um autovetor generalizado do par $(\mathbf{A}, \mathbf{M})$ e que o multiplicador η é o autovalor generalizado correspondente.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Sob a normalização

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1,$$

segue que

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta.$$

Além disso,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \eta.$$

Portanto, em um autovetor generalizado normalizado, o valor do quociente de Rayleigh generalizado coincide com o autovalor generalizado correspondente.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, a matriz $\mathbf{M}$ é invertível, e a equação generalizada também poderia ser escrita como

$$\mathbf{M}^{-1} \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Entretanto, mesmo que $\mathbf{A}$ e $\mathbf{M}$ sejam simétricas, a matriz $\mathbf{M}^{-1} \mathbf{A}$ não precisa ser simétrica. Para preservar a estrutura simétrica e poder aplicar diretamente o Teorema Espectral, é preferível transformar o problema utilizando a raiz quadrada de $\mathbf{M}$.

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2} \mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} = \lambda \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\widetilde{\mathbf{A}}^\top = \widetilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido no problema espectral ordinário

$$\widetilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u},$$

para uma matriz simétrica. Consequentemente, todos os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$ são reais e os resultados do Teorema Espectral podem ser aplicados à matriz $\widetilde{\mathbf{A}}$.

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \widetilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{a}$$

transforma a geometria induzida por $\mathbf{M}$ em geometria euclidiana, pois

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{u}^\top \mathbf{u}.$$

Equivalentemente,

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Geometricamente, $\mathbf{M}^{-1/2}$ transforma a esfera unitária euclidiana no elipsoide

$$\{\mathbf{a} \in \mathbb{R}^p : \mathbf{a}^\top \mathbf{M} \mathbf{a} = 1\}.$$

O problema generalizado pode, portanto, ser estudado como um problema de Rayleigh ordinário no sistema de coordenadas em que a métrica definida por $\mathbf{M}$ se torna euclidiana.

Quando $\mathbf{M}$ representar posteriormente uma matriz de covariâncias, essa mesma estrutura estará relacionada ao branqueamento. Aqui, porém, $\mathbf{M}$ representa genericamente a matriz que define a geometria do problema.

Teorema 5.8 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_p .

Comprovação. A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.5 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados. $\square$

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Proposição 5.8 (Ortogonalidade e base de autovetores generalizados). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$.*

Se $\mathbf{v}_i$ e $\mathbf{v}_j$ são autovetores generalizados associados a autovalores distintos λ_i e λ_j , então

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Além disso, existe uma base de $\mathbb{R}^p$ formada por autovetores generalizados

$$\mathcal{B}_g = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

que pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \delta_{ij}.$$

(Horn; Johnson, 2013)

Comprovação. Para autovalores distintos,

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{M} \mathbf{v}_i$$

e

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{M} \mathbf{v}_j.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \lambda_i \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= (\mathbf{A} \mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j. \end{aligned}$$

Portanto,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Para mostrar a existência de uma base completa, considere

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Como $\widetilde{\mathbf{A}}$ é simétrica, o Teorema Espectral garante uma base ortonormal de autovetores

$$\{\mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

Defina

$$\mathbf{v}_j = \mathbf{M}^{-1/2} \mathbf{u}_j.$$

Esses vetores são autovetores generalizados e

$$\begin{aligned} \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= \mathbf{u}_i^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}_j \\ &= \mathbf{u}_i^\top \mathbf{u}_j \\ &= \delta_{ij}. \end{aligned}$$

Assim, mesmo quando há autovalores generalizados repetidos, pode-se escolher uma base ortonormal segundo o produto interno induzido por $\mathbf{M}$. $\square$

5.7.4 Diagonalização simultânea por congruência

Considere a decomposição espectral

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \Lambda_g \mathbf{Q}_g^\top,$$

em que

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{B}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

Como $\mathbf{M}^{-1/2}$ é invertível e $\mathbf{Q}_g$ é ortogonal, $\mathbf{B}_g$ é invertível. Suas colunas formam uma base $\mathbf{M}$ -ortonormal de autovetores generalizados.

De fato,

$$\begin{aligned} \mathbf{A} \mathbf{B}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \Lambda_g \\ &= \mathbf{M} \mathbf{B}_g \Lambda_g. \end{aligned}$$

Além disso,

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p,\end{aligned}$$

e

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \Lambda_g.\end{aligned}$$

Portanto,

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

O par $(\mathbf{A}, \mathbf{M})$ é, assim, reduzido simultaneamente por uma transformação de congruência:

$$(\mathbf{A}, \mathbf{M}) \longrightarrow (\Lambda_g, \mathbf{I}_p).$$

Essa operação deve ser distinguida da semelhança

$$\mathbf{B}^{-1} \mathbf{A} \mathbf{B},$$

utilizada para representar um único operador em outra base. Na congruência, as matrizes aparecem multiplicadas pela transposta da matriz de base à esquerda e pela própria matriz à direita.

Como

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p,$$

segue que

$$\mathbf{B}_g^{-1} = \mathbf{B}_g^\top \mathbf{M}.$$

Assim, se

$$\mathbf{a} = \mathbf{B}_g \mathbf{z},$$

então as coordenadas de $\mathbf{a}$ nessa base são

$$\mathbf{z} = \mathbf{B}_g^{-1} \mathbf{a} = \mathbf{B}_g^\top \mathbf{M} \mathbf{a}.$$

Nessas coordenadas,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, portanto, a mesma forma do quociente de Rayleigh ordinário quando expresso na base $\mathbf{M}$ -ortonormal de autovetores generalizados.

Exemplo 5.10 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{b}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{b}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas da matriz da base

$$\mathbf{B}_g = [\mathbf{b}_{g,1} \quad \mathbf{b}_{g,2}],$$

obtêm-se

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_2$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Este capítulo desenvolveu a estrutura espectral das transformações lineares quadradas. O ponto de partida foi a identificação de direções invariantes, isto é, direções nas quais a ação de uma matriz reduz-se à multiplicação por um escalar.

Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

com $\mathbf{v} \neq \mathbf{0}$, o escalar λ é um autovalor e $\mathbf{v}$ é um autovetor correspondente. O conjunto formado pelo vetor nulo e por todos os autovetores associados a λ constitui o autoespaço

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovalores são determinados pela condição

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0.$$

A multiplicidade algébrica $m_a(\lambda)$ registra a multiplicidade de λ como raiz do polinômio característico, enquanto a multiplicidade geométrica

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda)$$

mede a dimensão do autoespaço correspondente.

Quando $\mathbf{A}$ possui p autovetores linearmente independentes, eles formam uma base

$$\mathcal{B}_\mathbf{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\},$$

cujas matrizes são

$$\mathbf{B}_\mathbf{A} = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_p].$$

Nessa base,

$$[T_\mathbf{A}]_{\mathcal{B}_\mathbf{A} \leftarrow \mathcal{B}_\mathbf{A}} = \mathbf{B}_\mathbf{A}^{-1} \mathbf{A} \mathbf{B}_\mathbf{A} = \Lambda_\mathbf{A},$$

e, portanto,

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}.$$

A diagonalização é, assim, uma mudança para coordenadas nas quais o operador atua separadamente sobre cada direção da base de autovetores.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores. Nesse caso, a matriz da base pode ser escolhida ortogonal,

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

com

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top,$$

e obtém-se a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Equivalentemente,

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Agrupando autovalores repetidos, essa representação pode ser escrita em termos dos projetores espectrais:

$$\mathbf{A} = \sum_h \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Essa forma mostra que uma matriz simétrica atua projetando o vetor sobre autoespaços ortogonais e aplicando a cada componente o autovalor correspondente.

A decomposição espectral também permite recuperar diretamente propriedades da matriz:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

e

$$\text{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\},$$

contando as multiplicidades.

Além disso,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \},$$

enquanto

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Para matrizes simétricas,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp.$$

A mesma decomposição simplifica as formas quadráticas. Se

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x},$$

então

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são, portanto, determinadas pelos sinais dos autovalores. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides cujos eixos estão alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

é uma média ponderada dos autovalores. Para

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

tem-se

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

O máximo e o mínimo são atingidos nos autoespaços associados aos autovalores extremos. A otimização de uma forma quadrática sob a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

conduz à condição

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}.$$

Autovalores e autovetores podem, portanto, ser interpretados também como valores e direções estacionárias de problemas de otimização quadrática.

A decomposição espectral permite ainda definir funções de matrizes simétricas. Se f está definida no espectro de $\mathbf{A}$,

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Equivalentemente,

$$f(\mathbf{A}) = \sum_h f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Assim, a função espectral preserva os autoespaços e transforma cada autovalor λ no escalar $f(\lambda)$. Potências, inversas, raízes quadradas, raízes quadradas inversas, pseudoinversas, exponenciais e logaritmos são casos particulares dessa construção, sob as condições necessárias à definição de cada função.

Quando a geometria do problema é determinada por uma matriz simétrica positiva definida $\mathbf{M}$, surge o problema de autovalores generalizados

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

com $\mathbf{A} = \mathbf{A}^\top$ e $\mathbf{M} \succ 0$.

O quociente correspondente é

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

converte esse problema em um problema de Rayleigh ordinário para a matriz simétrica

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Consequentemente, os autovalores generalizados são reais e pode-se escolher uma base de autovetores generalizados cuja matriz $\mathbf{B}_g$ satisfaz

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

A Tabela 5.2 reúne as expressões principais desenvolvidas no capítulo.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica direções invariantes
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Projeto espectral	$\Pi_\lambda = \mathbf{Q}_\lambda \mathbf{Q}_\lambda^\top$	Projeta sobre o autoespaço associado a λ
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}$	Caracteriza valores e direções espectrais por otimização
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda \mathbf{M} \mathbf{v}$	Compara duas formas quadráticas

Objeto	Expressão	Interpretação
Base generalizada	$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$	Define ortonormalidade na geometria induzida por $\mathbf{M}$
Diagonalização por congruência	$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g$	Reduz simultaneamente as duas formas quadráticas

Ao final deste capítulo, o estudante deverá ser capaz de:

- identificar autovalores, autovetores e autoespaços e interpretar seu significado geométrico;
- distinguir multiplicidades algébrica e geométrica;
- determinar quando uma matriz é diagonalizável;
- interpretar a diagonalização como mudança para uma base de autovetores;
- aplicar o Teorema Espectral a matrizes simétricas reais;
- interpretar projetores e subespaços espectrais;
- relacionar autovalores a traço, determinante, posto, núcleo, imagem e positividade;
- representar formas quadráticas em coordenadas espectrais;
- formular problemas de otimização por meio do quociente de Rayleigh;
- construir e interpretar funções espectrais de matrizes;
- compreender inversas, raízes e pseudoinversas pela ação sobre os autovalores;
- formular e transformar problemas de autovalores generalizados;
- distinguir ortogonalidade euclidiana de ortogonalidade segundo uma matriz positiva definida.

A decomposição espectral fornece uma descrição particularmente simples para matrizes simétricas quadradas. Entretanto, matrizes de dados e muitas transformações de interesse são retangulares ou não simétricas e, portanto, não admitem diretamente essa decomposição. O próximo capítulo amplia essas ideias por meio da **Decomposição em Valores Singulares**, relacionando matrizes retangulares aos espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ e conectando valores singulares, espaços fundamentais, posto e aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma matriz real e $T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ a transformação linear associada;
- $r = \text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$;
- $d_1 \geq \dots \geq d_r > 0$ representam os valores singulares positivos de $\mathbf{A}$;
- $\mathbf{v}_j \in \mathbb{R}^p$ representa um vetor singular à direita;
- $\mathbf{u}_j \in \mathbb{R}^q$ representa um vetor singular à esquerda;
- $\mathbf{U}$, $\mathbf{D}$ e $\mathbf{V}$ representam os fatores da SVD completa;
- $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ representam os fatores da SVD compacta;
- $\mathbf{U}_k$, $\mathbf{D}_k$ e $\mathbf{V}_k$ representam os fatores de uma SVD truncada;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\|\mathbf{A}\|_2$ e $\|\mathbf{A}\|_F$ representam, respectivamente, as normas espectral e de Frobenius.

As convenções estabelecidas nos capítulos anteriores para núcleo, imagem, espaço coluna, espaço linha e bases ortonormais permanecem válidas.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

*Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub; Van Loan, 2013)*

A demonstração será apresentada posteriormente, após a construção da SVD a partir das decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$.

Definição 6.1 (Matriz diagonal retangular). Seja

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

A matriz $\mathbf{D}$ é denominada **diagonal retangular** quando existem escalares

$$d_1, \dots, d_s$$

tais que

$$D_{ij} = \begin{cases} d_i, & i = j \leq s, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, apenas os elementos da diagonal principal podem ser diferentes de zero.

No bloco diagonal de ordem s , essa condição pode ser escrita de forma compacta utilizando a delta de Kronecker:

$$D_{ij} = d_i \delta_{ij}, \quad i, j = 1, \dots, s.$$

Se

$$q > p,$$

então $s = p$ e $\mathbf{D}$ possui $q - p$ linhas nulas abaixo de sua parte diagonal.

Se

$$p > q,$$

então $s = q$ e $\mathbf{D}$ possui $p - q$ colunas nulas à direita de sua parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_p \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Nesse caso, a parte diagonal possui $p = \min(q, p)$ elementos e as $q - p$ linhas restantes são nulas.

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Agora, a parte diagonal possui $q = \min(q, p)$ elementos e as $p - q$ colunas restantes são nulas.

Como

$$s = \min(q, p),$$

a matriz $\mathbf{D}$ possui s posições diagonais. Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos. Ordenando-os de forma decrescente,

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto, quando $r < s$,

$$d_{r+1} = \cdots = d_s = 0.$$

Assim, o número de valores singulares positivos é exatamente o posto de $\mathbf{A}$ e, consequentemente, a dimensão da imagem da transformação linear associada:

$$r = \text{posto}(\mathbf{A}) = \dim(\text{Im}(T_{\mathbf{A}})).$$

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.2 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A} \mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;
- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{z} = \mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base ortonormal dos vetores singulares à direita,

$$\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

Assim,

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_V}.$$

Na segunda etapa,

$$\mathbf{Dz}$$

multiplica separadamente as coordenadas pelas entradas diagonais de $\mathbf{D}$. Como $\mathbf{D} \in \mathbb{R}^{q \times p}$ pode ser retangular, essa etapa também realiza a passagem entre as dimensões do domínio e do contradomínio.

Na terceira etapa, $\mathbf{U}$ reconstrói o resultado nas coordenadas canônicas de $\mathbb{R}^q$ a partir da base ortonormal

$$\mathcal{B}_U = \{\mathbf{u}_1, \dots, \mathbf{u}_q\}.$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.3 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.4 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva todos os r valores singulares positivos e fornece a representação exata

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

A SVD truncada conserva apenas parte desses componentes singulares.

Para

$$1 \leq k < r,$$

defina

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k] \in \mathbb{R}^{q \times k},$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

Definição 6.5 (SVD truncada). Seja

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a matriz

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$$

é denominada **SVD truncada de posto k** de $\mathbf{A}$.

Como $k < r$, a SVD truncada descarta componentes associados a valores singulares positivos. Portanto, em geral,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ possui posto k e constitui uma aproximação de $\mathbf{A}$. As propriedades de otimalidade dessa aproximação e os erros decorrentes do truncamento serão estudados posteriormente.

A terminologia empregada para as diferentes formas da SVD não é uniforme na literatura. Dependendo da referência, aparecem expressões como **SVD reduzida**, **SVD fina** (*thin SVD*), **SVD econômica** (*economy-sized SVD*) e **SVD compacta**, nem sempre com exatamente o mesmo significado (Demmel, 2000; Driscoll; Braun, 2022; Sidi, 2017).

Para evitar ambiguidades, neste capítulo serão utilizadas as seguintes convenções:

- **SVD completa**, para a representação que utiliza bases ortonormais completas dos espaços de origem e de chegada;
- **SVD compacta**, para a representação exata que conserva somente os $r = \text{posto}(\mathbf{A})$ valores singulares positivos e os vetores singulares correspondentes;

- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

Exemplo 6.1 (SVD completa, compacta e truncada de uma matriz retangular). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \\ 2 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

A matriz possui posto

$$r = 3$$

e seus valores singulares, em ordem decrescente, são aproximadamente

$$d_1 = 4.1780, \quad d_2 = 2.1600, \quad d_3 = 1.3706.$$

Os valores apresentados a seguir estão arredondados a quatro casas decimais. Por esse motivo, as decomposições numéricas devem ser interpretadas a menos de arredondamento.

SVD completa

Uma SVD completa de $\mathbf{A}$ é

$$\mathbf{A} \approx \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que

$$\mathbf{U} \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 & -0.6014 & -0.2239 \\ 0.5461 & -0.2239 & 0.5466 & 0.5614 & -0.1943 \\ 0.3803 & -0.6954 & -0.3419 & -0.4142 & -0.2887 \\ 0.4348 & 0.4111 & -0.6965 & 0.3743 & -0.1295 \\ 0.4126 & -0.0779 & -0.0136 & -0.1073 & 0.9011 \end{bmatrix} \in \mathbb{R}^{5 \times 5},$$

$$\mathbf{D} \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

e

$$\mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

As colunas de $\mathbf{U}$ são os vetores singulares à esquerda,

$$\mathbf{u}_1, \dots, \mathbf{u}_5,$$

e as colunas de $\mathbf{V}$ são os vetores singulares à direita,

$$\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3.$$

Os três primeiros pares de vetores singulares estão associados aos três valores singulares positivos:

$$(\mathbf{u}_1, \mathbf{v}_1) \leftrightarrow d_1 = 4.1780,$$

$$(\mathbf{u}_2, \mathbf{v}_2) \leftrightarrow d_2 = 2.1600,$$

e

$$(\mathbf{u}_3, \mathbf{v}_3) \leftrightarrow d_3 = 1.3706.$$

As duas últimas colunas de $\mathbf{U}$ completam uma base ortonormal de $\mathbb{R}^5$. Elas correspondem às duas linhas nulas de $\mathbf{D}$.

SVD compacta

Como

$$r = \text{posto}(\mathbf{A}) = 3,$$

a SVD compacta conserva somente os três valores singulares positivos e os vetores singulares correspondentes:

$$\mathbf{A} \approx \mathbf{U}_3 \mathbf{D}_3 \mathbf{V}_3^\top,$$

com

$$\mathbf{U}_3 \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 \\ 0.5461 & -0.2239 & 0.5466 \\ 0.3803 & -0.6954 & -0.3419 \\ 0.4348 & 0.4111 & -0.6965 \\ 0.4126 & -0.0779 & -0.0136 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

$$\mathbf{D}_3 \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \end{bmatrix} \in \mathbb{R}^{3 \times 3},$$

e

$$\mathbf{V}_3 = \mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

A representação continua sendo exata antes do arredondamento numérico. A SVD compacta elimina apenas as duas colunas adicionais de $\mathbf{U}$ e as duas linhas nulas correspondentes de $\mathbf{D}$.

Como

$$r = p = 3,$$

todos os vetores singulares à direita participam da SVD compacta. Por isso,

$$\mathbf{V}_3 = \mathbf{V}.$$

SVD truncada de posto 2

Considere agora a conservação apenas dos dois maiores valores singulares,

$$d_1 = 4.1780 \quad \text{e} \quad d_2 = 2.1600.$$

A SVD truncada de posto 2 utiliza

$$\mathbf{U}_2 \approx \begin{bmatrix} 0.4449 & 0.5397 \\ 0.5461 & -0.2239 \\ 0.3803 & -0.6954 \\ 0.4348 & 0.4111 \\ 0.4126 & -0.0779 \end{bmatrix} \in \mathbb{R}^{5 \times 2},$$

$$\mathbf{D}_2 \approx \begin{bmatrix} 4.1780 & 0 \\ 0 & 2.1600 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

e

$$\mathbf{V}_2 \approx \begin{bmatrix} 0.6506 & 0.7406 \\ 0.5576 & -0.3155 \\ 0.5156 & -0.5933 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Assim,

$$\mathbf{A}_2 = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top$$

é uma aproximação de posto 2 da matriz original. Numericamente,

$$\mathbf{A}_2 \approx \begin{bmatrix} 2.0726 & 0.6688 & 0.2667 \\ 1.1260 & 1.4248 & 1.4631 \\ -0.0788 & 1.3598 & 1.7103 \\ 1.8394 & 0.7330 & 0.4098 \\ 0.9969 & 1.0143 & 0.9885 \end{bmatrix}.$$

Como o terceiro valor singular positivo foi descartado,

$$\mathbf{A}_2 \neq \mathbf{A}.$$

As três formas podem ser comparadas pelas dimensões de seus fatores:

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD completa	$\mathbf{U} : 5 \times 5$	$\mathbf{D} : 5 \times 3$	$\mathbf{V} : 3 \times 3$	d_1, d_2, d_3	Exato
SVD compacta	$\mathbf{U}_3 : 5 \times 3$	$\mathbf{D}_3 : 3 \times 3$	$\mathbf{V}_3 : 3 \times 3$	d_1, d_2, d_3	Exato
SVD truncada	$\mathbf{U}_2 : 5 \times 2$	$\mathbf{D}_2 : 2 \times 2$	$\mathbf{V}_2 : 3 \times 2$	d_1, d_2	Aproximado

A SVD completa apresenta bases ortonormais completas dos espaços de origem e de chegada. A SVD compacta mantém somente as direções associadas aos valores singulares positivos, sem perder informação necessária à reconstrução de $\mathbf{A}$. A SVD truncada conserva apenas parte dessas direções e, por isso, produz uma aproximação de posto menor.

6.1.6 Aprofundamento: não unicidade dos vetores singulares

Leitura de aprofundamento

Esta seção examina a não unicidade dos vetores singulares. Embora os valores singulares sejam determinados pela matriz, os vetores singulares associados podem admitir diferentes representações.

Serão considerados três casos: a mudança simultânea de sinal de pares de vetores singulares, a liberdade de escolha de bases ortonormais quando um valor singular positivo possui multiplicidade maior que um e a escolha das bases associadas ao valor singular zero.

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d\mathbf{U}_d \mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d(\mathbf{U}_d \mathbf{R})(\mathbf{V}_d \mathbf{R})^\top &= d\mathbf{U}_d \mathbf{R} \mathbf{R}^\top \mathbf{V}_d^\top \\ &= d\mathbf{U}_d \mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das duas matrizes de Gram associadas a $\mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Essas matrizes já apareceram no estudo dos espaços das variáveis e das observações. A SVD mostra agora que seus espectros estão diretamente relacionados e que essa relação permite construir bases ortonormais adaptadas à transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A} \mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Propriedades das matrizes de Gram associadas

As matrizes

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A}\mathbf{A}^\top$$

são matrizes de Gram associadas, respectivamente, às colunas e às linhas de $\mathbf{A}$.

Pela Proposição 3.9, ambas são simétricas e semidefinidas positivas. Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{A}\mathbf{A}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{A}\mathbf{A}^\top) = \text{posto}(\mathbf{A}).$$

Assim, se

$$r = \text{posto}(\mathbf{A}),$$

cada uma dessas matrizes possui exatamente r autovalores positivos, considerando suas multiplicidades.

Como ambas são simétricas, o Teorema 5.4 garante a existência de bases ortonormais de autovetores. Como também são semidefinidas positivas, todos os seus autovalores são não negativos.

Proposição 6.1 (Espectros das matrizes de Gram associadas). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *se esses autovalores são ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

podem-se definir

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r;$$

3. *os núcleos satisfazem*

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A} \mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então,

$$\mathbf{Ax} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}^\top \mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top \mathbf{A}),$$

então

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{x}^\top$,

$$\begin{aligned} 0 &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} \\ &= \|\mathbf{Ax}\|^2. \end{aligned}$$

Portanto,

$$\mathbf{Ax} = \mathbf{0},$$

e

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}).$$

Assim,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

O mesmo argumento, aplicado a $\mathbf{A}^\top$, fornece

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

Considere agora um autovalor positivo λ de

$$\mathbf{A}^\top \mathbf{A}$$

e um autovetor unitário $\mathbf{v}$ associado:

$$\mathbf{A}^\top \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Como $\lambda > 0$, defina

$$\mathbf{u} = \frac{\mathbf{A} \mathbf{v}}{\sqrt{\lambda}}.$$

Esse vetor possui norma unitária, pois

$$\begin{aligned} \mathbf{u}^\top \mathbf{u} &= \frac{\mathbf{v}^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\lambda} \\ &= \frac{\lambda \mathbf{v}^\top \mathbf{v}}{\lambda} \\ &= 1. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top \mathbf{u} &= \frac{\mathbf{A} \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\mathbf{A}^\top \mathbf{A} \mathbf{v})}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\lambda \mathbf{v})}{\sqrt{\lambda}} \\ &= \lambda \mathbf{u}. \end{aligned}$$

Portanto, todo autovalor positivo de

$$\mathbf{A}^\top \mathbf{A}$$

também é autovalor de

$$\mathbf{A}\mathbf{A}^\top.$$

O argumento inverso é obtido começando por um autovetor de

$$\mathbf{A}\mathbf{A}^\top$$

e definindo

$$\mathbf{v} = \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}.$$

Para $\lambda > 0$, as aplicações

$$\mathbf{v} \mapsto \frac{\mathbf{A}\mathbf{v}}{\sqrt{\lambda}}$$

e

$$\mathbf{u} \mapsto \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}$$

estabelecem aplicações lineares inversas entre o autoespaço de $\mathbf{A}^\top \mathbf{A}$ associado a λ e o autoespaço de $\mathbf{A}\mathbf{A}^\top$ associado ao mesmo autovalor. Portanto, esses autoespaços possuem a mesma dimensão e as multiplicidades dos autovalores positivos coincidem.

Como

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A}) = r,$$

existem exatamente r autovalores positivos. O mesmo ocorre para

$$\mathbf{A}\mathbf{A}^\top.$$

Definindo

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r,$$

obtêm-se r números positivos associados aos autovalores positivos comuns às duas matrizes de Gram. A construção a seguir mostrará que esses números são precisamente os valores singulares positivos de $\mathbf{A}$. $\square$

As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos pares singulares

Suponha inicialmente que

$$\mathbf{A} \neq \mathbf{0}.$$

Então,

$$r = \text{posto}(\mathbf{A}) \geq 1.$$

O caso

$$\mathbf{A} = \mathbf{0}$$

será tratado diretamente na demonstração do Teorema [6.1](#).

A construção começa pela matriz

$$\mathbf{A}^\top \mathbf{A},$$

que atua em

$$\mathbb{R}^p,$$

o domínio da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Seus autovetores associados aos autovalores positivos determinarão os **vetores singulares à direita**. A aplicação de $\mathbf{A}$ a essas direções, seguida de normalização, produzirá os **vetores singulares à esquerda** em $\mathbb{R}^q$.

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Particione a matriz de autovetores como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

contém os autovetores associados aos autovalores positivos e

$$\mathbf{V}_0 = [\mathbf{v}_{r+1} \quad \cdots \quad \mathbf{v}_p]$$

contém os autovetores associados ao autovalor zero.

Pela Proposição 6.1,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Portanto, as colunas de $\mathbf{V}_0$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{V}_r$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A})^\perp = \mathcal{C}(\mathbf{A}^\top).$$

Proposição 6.2 (Construção dos pares singulares positivos). *Para cada*

$$j = 1, \dots, r,$$

defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Então:

1. *os vetores*

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais;

2. *para cada $j = 1, \dots, r$,*

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j;$$

3. os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

Comprovação. Para $i, j \leq r$,

$$\begin{aligned}\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.\end{aligned}$$

Como os vetores

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Pela definição de $\mathbf{u}_j$,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Além disso,

$$\begin{aligned}\mathbf{A}^\top\mathbf{u}_j &= \frac{\mathbf{A}^\top\mathbf{A}\mathbf{v}_j}{d_j} \\ &= \frac{d_j^2\mathbf{v}_j}{d_j} \\ &= d_j\mathbf{v}_j.\end{aligned}$$

Cada $\mathbf{u}_j$ pertence a

$$\mathcal{C}(\mathbf{A}),$$

pois

$$\mathbf{u}_j = \frac{1}{d_j}\mathbf{A}\mathbf{v}_j.$$

Como existem

$$r = \text{posto}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A})$$

vetores ortonormais desse tipo, eles formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

□

A construção estabelece uma correspondência entre duas direções ortonormais:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p \quad \xrightarrow{\mathbf{A}} \quad d_j\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q \quad \xrightarrow{\mathbf{A}^\top} \quad d_j\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p.$$

Assim, $\mathbf{v}_j$ é uma direção singular à direita, $\mathbf{u}_j$ é a direção singular à esquerda correspondente e d_j é o fator de escalonamento que relaciona as duas.

6.2.3 Construção da SVD compacta

Reúna os vetores singulares à esquerda em

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r]$$

e defina

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r).$$

As relações

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j, \quad j = 1, \dots, r,$$

podem ser escritas simultaneamente como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r.$$

Proposição 6.3 (SVD compacta obtida dos pares singulares). *Com as matrizes $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ definidas anteriormente,*

$$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Portanto,

$$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$$

é a SVD compacta de $\mathbf{A}$, e

$$d_1, \dots, d_r$$

são seus valores singulares positivos.

Comprovação. Como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal,

$$\mathbf{I}_p = \mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top.$$

As colunas de $\mathbf{V}_0$ pertencem a

$$\mathcal{N}(\mathbf{A}),$$

de modo que

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$

Assim,

$$\begin{aligned} \mathbf{A} &= \mathbf{A} \mathbf{I}_p \\ &= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\ &= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

□

A SVD compacta utiliza exatamente as direções que participam da transformação:

- as colunas de $\mathbf{V}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A}^\top)$;
- $\mathbf{D}_r$ contém os fatores de escalonamento positivos;
- as colunas de $\mathbf{U}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A})$.

A construção anterior permite concluir a demonstração do Teorema [6.1](#).

Comprovação. Se

$$\mathbf{A} = \mathbf{0},$$

tome

$$\mathbf{U} = \mathbf{I}_q, \quad \mathbf{V} = \mathbf{I}_p$$

e

$$\mathbf{D} = \mathbf{0}_{q \times p}.$$

Então,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Suponha agora que

$$\mathbf{A} \neq \mathbf{0}.$$

Pela Proposição 6.3,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de $\mathbf{U}_r$ formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A}^\top)^\perp.$$

Complete esse conjunto com uma base ortonormal

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_q$$

de

$$\mathcal{N}(\mathbf{A}^\top).$$

Defina

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0] \in \mathbb{R}^{q \times q},$$

em que

$$\mathbf{U}_0 = [\mathbf{u}_{r+1} \quad \dots \quad \mathbf{u}_q].$$

A matriz $\mathbf{U}$ é ortogonal.

A matriz

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0] \in \mathbb{R}^{p \times p}$$

já foi obtida da decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

e também é ortogonal.

Defina

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

como a matriz diagonal retangular cujos primeiros r elementos diagonais são

$$d_1, \dots, d_r$$

e cujos demais elementos são nulos.

Como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$$

e

$$\mathbf{A}\mathbf{V}_0 = \mathbf{0},$$

tem-se

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{D}.$$

Multiplicando à direita por $\mathbf{V}^\top$,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Isso demonstra a existência da SVD completa. □

6.2.4 Decomposições espectrais associadas

Proposição 6.4 (Decomposições espectrais induzidas pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Comprovação. Utilizando a SVD compacta,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

Como as colunas de $\mathbf{U}_r$ são ortonormais,

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Analogamente,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

□

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A} \mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A} \mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

As duas decomposições também identificam os espaços aos quais pertencem os vetores singulares:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q.$$

Portanto, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio. Os valores singulares positivos realizam a ligação entre esses dois espaços.

6.2.5 Exemplo de construção da SVD

Exemplo 6.2 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned} \mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

O segundo é

$$\begin{aligned} \mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}. \end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A} \mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A} \mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, pode-se escolher uma SVD na qual, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

6.2.7 Aprofundamento: SVD de matrizes simétricas indefinidas

Leitura de aprofundamento

Esta seção examina a relação entre a decomposição espectral e a SVD quando uma matriz simétrica possui autovalores negativos. Nesse caso, os valores singulares correspondem aos módulos dos autovalores, enquanto seus sinais são incorporados a uma das matrizes ortogonais da SVD.

Esse desenvolvimento complementa o caso semidefinido positivo apresentado anteriormente, mas não é necessário para acompanhar as aplicações principais da SVD às matrizes de Gram, às matrizes de dados e às estruturas de covariância.

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j)|\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_{\mathbf{A}},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_{\mathbf{A}} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_{\mathbf{A}}\mathbf{\Lambda}_{\mathbf{A}}\mathbf{Q}_{\mathbf{A}}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como a transformação leva a bola unitária do domínio a um elipsoide contido na imagem de $\mathbf{A}$, cujos semieixos são determinados pelos valores e vetores singulares. O comportamento da esfera unitária dependerá da existência ou não de direções pertencentes ao núcleo.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \sum_{j=1}^p \alpha_j \mathbf{Av}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Proposição 6.5 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto $r \geq 1$. A imagem da bola unitária por $\mathbf{A}$ é o elipsoide sólido de dimensão r , contido em $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$

Em particular,

$$\mathbf{A}(\mathcal{B}_p) \subseteq \mathcal{C}(\mathbf{A}),$$

e a dimensão desse elipsoide é

$$\dim(\mathcal{C}(\mathbf{A})) = r.$$

No caso extremo $\mathbf{A} = \mathbf{0}$, a imagem da bola unitária reduz-se ao conjunto $\{\mathbf{0}\}$.

Comprovação. Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

$$\mathbf{x} = \sum_{j=1}^r \frac{\beta_j}{d_j} \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1,$$

de modo que $\mathbf{x} \in \mathcal{B}_p$. Além disso,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{u}_j = \mathbf{y}.$$

Logo, o conjunto apresentado coincide com a imagem da bola unitária. □

O comportamento da esfera unitária depende da existência de um núcleo não trivial.

Se $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso, a imagem da esfera unitária

$$\mathcal{S}_{p-1} = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| = 1\}$$

é a fronteira relativa do elipsoide

$$\mathbf{A}(\mathcal{B}_p)$$

no subespaço $\mathcal{C}(\mathbf{A})$.

Por outro lado, se

$$r < p,$$

então

$$\dim(\mathcal{N}(\mathbf{A})) = p - r > 0.$$

Nesse caso, a imagem da esfera unitária coincide com a imagem da bola unitária:

$$\mathbf{A}(\mathcal{S}_{p-1}) = \mathbf{A}(\mathcal{B}_p).$$

De fato, para qualquer ponto do elipsoide cuja componente nas direções $\mathbf{v}_1, \dots, \mathbf{v}_r$ tenha norma menor que 1, pode-se acrescentar uma componente pertencente ao núcleo até obter um vetor de norma 1, sem alterar sua imagem por $\mathbf{A}$.

Finalmente, se

$$r < q,$$

o elipsoide não ocupa todo o espaço de chegada. Ele está contido no subespaço de dimensão r

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a geometria da imagem da bola revela simultaneamente os fatores de escala da transformação e a dimensão de sua imagem.

6.3.2 Alteração dos comprimentos

Os valores singulares permitem determinar os fatores extremos de alteração dos comprimentos produzidos pela transformação.

Proposição 6.6 (Extremos da alteração dos comprimentos). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto $r \geq 1$, com valores singulares positivos ordenados como

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0.$$

Então, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

Consequentemente,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p,$$

então

$$d_p \|\mathbf{x}\| \leq \|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|$$

para todo $\mathbf{x} \in \mathbb{R}^p$, e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se

$$r < p,$$

então

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

Comprovação. Escreva $\mathbf{x}$ na base ortonormal dos vetores singulares à direita:

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j.$$

Como essa base é ortonormal,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2.$$

Por outro lado,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Como

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais,

$$\|\mathbf{Ax}\|^2 = \sum_{j=1}^r d_j^2 \alpha_j^2.$$

Como

$$d_j \leq d_1, \quad j = 1, \dots, r,$$

segue que

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^r d_j^2 \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^r \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_1^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, tomando

$$\mathbf{x} = \mathbf{v}_1,$$

pois

$$\|\mathbf{Av}_1\| = \|d_1 \mathbf{u}_1\| = d_1.$$

Logo,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Suponha agora que $\mathbf{A}$ possua posto coluna completo. Nesse caso,

$$r = p$$

e

$$d_p > 0.$$

Como

$$d_j \geq d_p, \quad j = 1, \dots, p,$$

tem-se

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^p d_j^2 \alpha_j^2 \\
&\geq d_p^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_p^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \geq d_p \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, para

$$\mathbf{x} = \mathbf{v}_p,$$

de modo que

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Finalmente, se

$$r < p,$$

então

$$\dim \mathcal{N}(\mathbf{A}) = p - r > 0.$$

Logo, existe um vetor unitário

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Para esse vetor,

$$\mathbf{Ax}_0 = \mathbf{0},$$

e, portanto,

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

□

O maior valor singular d_1 representa, portanto, o maior fator de ampliação produzido pela transformação. Quando $\mathbf{A}$ possui posto coluna completo, o menor valor singular d_p representa o menor fator de alteração de comprimento entre vetores unitários. Quando o posto coluna não é completo, existem direções unitárias eliminadas pela transformação, e o menor comprimento possível da imagem é zero.

Esses extremos serão retomados posteriormente na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.3 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;
- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal de $\mathbb{R}^2$ e identificam duas direções sobre a circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

Neste exemplo, as bases singulares do domínio e do contradomínio são distintas. A matriz $\mathbf{V}^\top$ expressa os pontos da circunferência nas coordenadas da base formada por $\mathbf{v}_1$ e $\mathbf{v}_2$. Como essa transformação é ortogonal, a circunferência permanece uma circunferência. Em seguida, $\mathbf{D}$ realiza a deformação, multiplicando os comprimentos nas duas direções por d_1 e d_2 . Finalmente, $\mathbf{U}$ orienta os semieixos da elipse nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$ no espaço de chegada.

6.3.4 Transformações com núcleo não trivial

Quando

$$r < p,$$

a transformação possui núcleo não trivial e elimina $p - r$ direções linearmente independentes do domínio. Geometricamente, a imagem da bola unitária passa a ter dimensão inferior à dimensão do domínio.

Exemplo 6.4 (Colapso de uma direção pela transformação). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A ação da transformação sobre um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

é

$$\mathbf{A}_0 \mathbf{x} = \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix}.$$

Portanto, toda a direção

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

é eliminada, pois

$$\mathbf{A}_0 \mathbf{e}_2 = \mathbf{0}.$$

De fato,

$$\mathcal{N}(\mathbf{A}_0) = \text{span} \{ \mathbf{e}_2 \}.$$

A bola unitária de $\mathbb{R}^2$ é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

Assim, a imagem possui dimensão 1, que coincide com

$$\text{posto}(\mathbf{A}_0) = 1.$$

O valor singular positivo $d_1 = 2$ determina o comprimento do único semieixo não nulo, enquanto o valor singular $d_2 = 0$ identifica a direção eliminada pela transformação.

De modo geral:

- cada valor singular positivo produz um semieixo não nulo da imagem;
- existem exatamente r semieixos não nulos;
- o núcleo possui dimensão $p - r$ e contém todas as direções que são transformadas no vetor nulo;
- a dimensão do elipsoide resultante é r ;
- o elipsoide está contido em $\mathcal{C}(\mathbf{A})$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores e normas diretamente a partir dos vetores e valores singulares. Aspectos relacionados ao condicionamento numérico serão apresentados posteriormente como leitura de aprofundamento.

6.4 Espaços fundamentais, posto e normas

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Proposição 6.7 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_q\} = \mathcal{C}(\mathbf{U}_0).$$

(Golub; Van Loan, 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{U}_r) \subseteq \mathcal{C}(\mathbf{A}).$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r).$$

Aplicando o mesmo argumento a

$$\mathbf{A}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top,$$

obtém-se

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r).$$

Considere agora a base ortonormal completa

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma decomposição única da forma

$$\mathbf{x} = \mathbf{V}_r \alpha + \mathbf{V}_0 \beta.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top (\mathbf{V}_r \alpha + \mathbf{V}_0 \beta) \\ &= \mathbf{U}_r \mathbf{D}_r \alpha, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_0 = \mathbf{0}.$$

Como $\mathbf{D}_r$ é invertível,

$$\mathbf{Ax} = \mathbf{0}$$

se, e somente se,

$$\alpha = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A})$$

se, e somente se,

$$\mathbf{x} = \mathbf{V}_0 \beta.$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

Aplicando o mesmo raciocínio a $\mathbf{A}^\top$,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Assim, a SVD completa fornece bases ortonormais simultaneamente para os quatro espaços fundamentais de $\mathbf{A}$. $\square$

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.4.

Tabela 6.4: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

A identificação das bases dos quatro espaços fundamentais permite construir diretamente seus projetores ortogonais.

Proposição 6.8 (Projetores dos espaços fundamentais pela SVD). *Considere a SVD completa escrita como*

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Então, os projetores ortogonais sobre os quatro espaços fundamentais são

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^{\top}$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

Comprovação. Pela Proposição 6.7,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r)$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Como as colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ são ortonormais, a Proposição 3.14 fornece

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top.$$

Além disso, como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U} \mathbf{U}^\top = \mathbf{I}_q.$$

Portanto,

$$\mathbf{U}_r \mathbf{U}_r^\top + \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q,$$

de onde

$$\mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

Aplicando o mesmo argumento a

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

obtêm-se

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

□

Como são projetores ortogonais, essas matrizes são simétricas e idempotentes, conforme as propriedades estudadas no Capítulo 3.

Exemplo 6.5 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{ \mathbf{0} \}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned} \mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}. \end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

Pela SVD, o posto de $\mathbf{A}$ é exatamente o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r = \# \{j : d_j > 0\}.$$

Como consequência do Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Essas dimensões também são visualizadas diretamente na SVD completa:

- as r colunas de $\mathbf{V}_r$ formam uma base do espaço linha;
- as $p - r$ colunas de $\mathbf{V}_0$ formam uma base do núcleo de $\mathbf{A}$;
- as r colunas de $\mathbf{U}_r$ formam uma base do espaço coluna;
- as $q - r$ colunas de $\mathbf{U}_0$ formam uma base do núcleo de $\mathbf{A}^\top$.

É importante distinguir essas dimensões do número de posições diagonais nulas de $\mathbf{D}$. Como

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui apenas

$$s = \min(q, p)$$

posições diagonais, existem

$$s - r$$

valores singulares nulos entre essas posições, enquanto as dimensões dos dois núcleos são, respectivamente,

$$p - r \quad \text{e} \quad q - r.$$

Assim, em matrizes retangulares, a estrutura completa dos núcleos não deve ser inferida apenas pela quantidade de elementos diagonais nulos de $\mathbf{D}$.

A Tabela 6.5 reúne as principais relações entre os valores e vetores singulares e a estrutura da transformação.

Tabela 6.5: Relação entre a SVD e a estrutura da matriz.

Estrutura ou propriedade	Caracterização pela SVD
Posto	Número de valores singulares positivos
Imagem $\mathcal{C}(\mathbf{A})$	Vetores singulares à esquerda associados a $d_j > 0$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	Vetores singulares à direita associados a $d_j > 0$
Núcleo $\mathcal{N}(\mathbf{A})$	Vetores singulares à direita associados à parte nula
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	Vetores singulares à esquerda associados à parte nula
Ampliação máxima	d_1
Menor fator positivo de escala	d_r

Se $r < p$, a menor norma de $\mathbf{A}\mathbf{x}$ entre todos os vetores unitários do domínio é zero, pois existem vetores unitários no núcleo. O valor d_r descreve o menor fator **positivo** de escala, isto é, a menor ação da transformação quando restrita ao espaço linha $\mathcal{C}(\mathbf{A}^\top)$.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.6 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \text{tr} (\mathbf{A}^\top \widetilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \tilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.7 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr} (\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.8 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Proposição 6.9 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub; Van Loan, 2013)

Comprovação. Pela Proposição 6.6,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Como, pela Definição 6.8,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|,$$

segue imediatamente que

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius, utilizando a Proposição 6.4,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Portanto,

$$\begin{aligned} \|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\ &= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\ &= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\ &= \text{tr}(\mathbf{D}_r^2) \\ &= \sum_{j=1}^r d_j^2. \end{aligned}$$

Logo,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

□

Se $\mathbf{A} = \mathbf{0}$, então não há valores singulares positivos e, diretamente pelas definições,

$$\|\mathbf{A}\|_2 = \|\mathbf{A}\|_F = 0.$$

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Proposição 6.10 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub; Van Loan, 2013)

Comprovação. Para a norma espectral, como $\mathbf{Q}_1$ preserva normas,

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2 \mathbf{x}\| = \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\|.$$

Como $\mathbf{Q}_2$ é ortogonal, a transformação

$$\mathbf{z} = \mathbf{Q}_2 \mathbf{x}$$

preserva a norma e percorre todos os vetores unitários quando $\mathbf{x}$ percorre a esfera unitária. Portanto,

$$\begin{aligned} \|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 &= \max_{\|\mathbf{x}\|=1} \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\| \\ &= \max_{\|\mathbf{z}\|=1} \|\mathbf{A} \mathbf{z}\| \\ &= \|\mathbf{A}\|_2. \end{aligned}$$

Para a norma de Frobenius,

$$\begin{aligned}
\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F^2 &= \text{tr} \left[(\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2) \right] \\
&= \text{tr} (\mathbf{Q}_2^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}_2) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A} \mathbf{Q}_2 \mathbf{Q}_2^\top) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A}) \\
&= \|\mathbf{A}\|_F^2.
\end{aligned}$$

Logo, ambas as normas são invariantes sob multiplicações ortogonais. $\square$

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p = q,$$

de modo que não existem direções singulares associadas ao valor zero. Assim, as formas compacta e completa possuem as mesmas dimensões e podem ser escritas com os mesmos fatores:

$$\mathbf{U}_r = \mathbf{U}, \quad \mathbf{D}_r = \mathbf{D}, \quad \mathbf{V}_r = \mathbf{V}.$$

6.4.8 Aprofundamento: condicionamento e posto numérico

Leitura de aprofundamento

Esta seção apresenta duas extensões de natureza numérica da interpretação dos valores singulares. A primeira utiliza a razão entre os valores singulares extremos para avaliar o condicionamento de uma transformação. A segunda distingue o posto algébrico do posto numérico obtido após a adoção de uma tolerância computacional.

Esses conceitos são importantes para estabilidade numérica, problemas inversos e algoritmos matriciais, mas não são necessários para acompanhar os resultados centrais sobre espaços fundamentais, aproximações de posto reduzido e aplicações estatísticas da SVD.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

Quando

$$\text{posto}(\mathbf{A}) = s,$$

a matriz possui o maior posto possível para suas dimensões e todos os seus s valores singulares são positivos:

$$d_1 \geq \dots \geq d_s > 0.$$

Definição 6.9 (Número de condição na norma espectral). Para uma matriz de posto máximo,

$$\text{posto}(\mathbf{A}) = s,$$

define-se o **número de condição na norma espectral** por

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Quando

$$\text{posto}(\mathbf{A}) < s,$$

adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

(Golub; Van Loan, 2013)

O número de condição compara o maior e o menor fatores positivos de escala associados à parte ativa da transformação.

Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

os valores singulares extremos possuem magnitudes semelhantes. Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são transformadas por fatores muito maiores que outras.

É importante distinguir **núcleo não trivial**, **deficiência de posto** e **mau condicionamento**.

A deficiência de posto ocorre quando

$$\text{posto}(\mathbf{A}) < \min(q, p).$$

Entretanto, uma matriz retangular pode possuir núcleo não trivial mesmo apresentando posto máximo.

Por exemplo, se

$$q < p$$

e

$$\text{posto}(\mathbf{A}) = q,$$

então $\mathbf{A}$ possui posto linha completo e, portanto, posto máximo. Mesmo assim,

$$\dim \mathcal{N}(\mathbf{A}) = p - q > 0.$$

Assim, existem direções do domínio que são transformadas no vetor nulo.

Nesse caso, a transformação não é injetiva em todo o domínio $\mathbb{R}^p$. Sua restrição ao espaço linha,

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp,$$

é, entretanto, injetiva.

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{A}\mathbf{x}\|.$$

Portanto, para matrizes largas de posto linha completo, o número de condição finito descreve a variação dos fatores de escala sobre o espaço linha, isto é, sobre a parte do domínio na qual a transformação atua de forma injetiva.

Se

$$q \geq p$$

e

$$\text{posto}(\mathbf{A}) = p,$$

então $\mathbf{A}$ possui posto coluna completo e

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso,

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Para uma matriz quadrada invertível,

$$q = p = r,$$

tem-se também

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Portanto,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p},$$

de modo que

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Uma matriz de posto máximo com número de condição elevado é denominada **mal condicionada**. Valores singulares positivos muito pequenos indicam direções nas quais a transformação produz forte contração. Ao inverter a ação da matriz nessas direções, pequenas perturbações podem ser amplificadas.

Esse fenômeno será retomado posteriormente na discussão da pseudoinversa.

Exemplo 6.6 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

Nesse caso, as duas direções singulares são transformadas pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por um fator igual a 2, enquanto a segunda é contraída por um fator igual a 0,02.

A inversão da segunda componente exige um fator

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem ser fortemente ampliadas quando se procura inverter a transformação.

6.4.8.1 Posto exato e posto numérico

Matematicamente, o posto é determinado exatamente pelos valores singulares positivos:

$$\text{posto}(\mathbf{A}) = \# \{j : d_j > 0\}.$$

Em cálculos computacionais, entretanto, valores que seriam exatamente nulos em aritmética exata podem aparecer como números positivos muito pequenos em razão de arredondamentos, aproximações ou ruído.

Por isso, pode-se adotar uma tolerância

$$\tau \geq 0$$

e tratar como numericamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

Definição 6.10 (Posto numérico). Fixada uma tolerância $\tau \geq 0$, o **posto numérico** de $\mathbf{A}$ é definido por

$$r_\tau(\mathbf{A}) = \# \{j : d_j > \tau\}.$$

Diferentemente do posto algébrico, o posto numérico depende da tolerância adotada.

A escolha de τ pode depender de fatores como:

- precisão numérica;
- escala da matriz;
- dimensões da matriz;
- finalidade da análise;
- nível de perturbação ou ruído considerado relevante.

Portanto, dois valores devem ser distinguidos:

$$\text{posto}(\mathbf{A}) = \#\{j : d_j > 0\}$$

e

$$r_\tau(\mathbf{A}) = \#\{j : d_j > \tau\}.$$

Essa distinção será particularmente útil quando forem estudadas aproximações de posto reduzido. Nessas aproximações, valores singulares matematicamente positivos podem ser descartados deliberadamente quando sua contribuição é considerada pequena.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, a SVD recupera a dupla representação da matriz de dados introduzida no Capítulo 1:

- as colunas de $\mathbf{V}_r$ pertencem a $\mathbb{R}^p$ e determinam direções no espaço em que as observações são representadas;
- as colunas de $\mathbf{U}_r$ pertencem a $\mathbb{R}^n$ e determinam direções no espaço em que as variáveis são representadas.

Os mesmos valores singulares conectam essas duas representações.

6.5.1 Dualidade entre observações e variáveis

A SVD relaciona diretamente as duas representações da matriz de dados: as observações como vetores em $\mathbb{R}^p$ e as variáveis como vetores em $\mathbb{R}^n$.

Proposição 6.11 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

então

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

Consequentemente, para

$$j = 1, \dots, r,$$

tem-se

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, o mesmo valor singular d_j relaciona uma direção $\mathbf{v}_j$ no espaço das observações $\mathbb{R}^p$ a uma direção $\mathbf{u}_j$ no espaço das variáveis $\mathbb{R}^n$.

Comprovação. Multiplicando a SVD compacta à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{V}_r^\top\mathbf{V}_r = \mathbf{I}_r.$$

Transpondo a SVD compacta,

$$\mathbf{X}^\top = \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top.$$

Multiplicando à direita por $\mathbf{U}_r$,

$$\begin{aligned}\mathbf{X}^\top\mathbf{U}_r &= \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top\mathbf{U}_r \\ &= \mathbf{V}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{U}_r^\top\mathbf{U}_r = \mathbf{I}_r.$$

As relações correspondentes a cada coluna seguem diretamente dessas duas identidades matriciais. $\square$

6.5.2 Coordenadas das observações nas direções singulares à direita

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Pela Proposição 6.11,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações na base ortonormal

$$\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$$

do espaço linha

$$\mathcal{C}(\mathbf{X}^\top) \subseteq \mathbb{R}^p.$$

Como cada observação pertence a esse subespaço, as r coordenadas são suficientes para representá-la exatamente.

Se a linha i de $\mathbf{X}$ corresponde ao vetor

$$\mathbf{x}_i \in \mathbb{R}^p,$$

então

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Portanto, z_{ij} é a coordenada da observação i na direção singular $\mathbf{v}_j$.

A j -ésima coluna de $\mathbf{Z}$ é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Assim, $\mathbf{v}_j$ determina a direção utilizada para representar as observações, enquanto $\mathbf{u}_j$ descreve como as coordenadas correspondentes se distribuem entre as n unidades observacionais.

6.5.3 Coordenadas das variáveis nas direções singulares à esquerda

A relação dual é

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top.$$

Defina

$$\mathbf{W} = \mathbf{U}_r^\top \mathbf{X} \in \mathbb{R}^{r \times p}.$$

Cada coluna de $\mathbf{X}$ representa uma variável como vetor em $\mathbb{R}^n$. Se

$$\mathbf{x}^{(j)} \in \mathbb{R}^n$$

denota a j -ésima variável, então a j -ésima coluna de $\mathbf{W}$ contém suas coordenadas na base ortonormal

$$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$$

do espaço coluna

$$\mathcal{C}(\mathbf{X}) \subseteq \mathbb{R}^n.$$

Para a direção singular ℓ ,

$$\mathbf{u}_\ell^\top \mathbf{x}^{(j)} = d_\ell v_{j\ell}.$$

Portanto, os elementos de $\mathbf{V}_r$, escalonados pelos valores singulares, também descrevem as coordenadas das variáveis na base singular à esquerda.

As relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam, assim, a dualidade entre o espaço das observações e o espaço das variáveis.

6.5.4 Matrizes de Gram da matriz de dados

As duas matrizes de Gram associadas a $\mathbf{X}$ descrevem relações entre objetos diferentes.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

reúne os produtos internos entre as colunas de $\mathbf{X}$, isto é, entre as variáveis representadas como vetores em $\mathbb{R}^n$.

A matriz

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

reúne os produtos internos entre as linhas de $\mathbf{X}$, isto é, entre as observações representadas como vetores em $\mathbb{R}^p$.

Pela Proposição 6.4,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto, as duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ determina uma direção no espaço das observações;
- $\mathbf{u}_j \in \mathbb{R}^n$ determina uma direção no espaço das variáveis.

Essa dualidade também pode ser útil quando as dimensões da matriz são muito diferentes. Se

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Se

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

possui ordem menor.

Em ambos os casos, os valores próprios positivos são os mesmos e correspondem aos quadrados dos valores singulares de $\mathbf{X}$.

6.5.5 Representação exata das observações

Proposição 6.12 (Preservação da geometria pelas coordenadas singulares). *Seja*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de dados e defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Então,

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top$$

e

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Consequentemente, para quaisquer observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell,$$

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

Comprovação. Como

$$\mathbf{Z} = \mathbf{U}_r \mathbf{D}_r,$$

segue da SVD compacta que

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{Z} \mathbf{V}_r^\top.$$

Além disso,

$$\begin{aligned} \mathbf{Z} \mathbf{Z}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned}$$

Pela Proposição 6.4,

$$\mathbf{X} \mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Os elementos dessas duas matrizes são os produtos internos entre pares de observações. Logo,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Tomando $i = \ell$, obtém-se

$$\|\mathbf{x}_i\|^2 = \|\mathbf{z}_i\|^2.$$

Finalmente,

$$\begin{aligned}
\|\mathbf{x}_i - \mathbf{x}_\ell\|^2 &= \|\mathbf{x}_i\|^2 + \|\mathbf{x}_\ell\|^2 - 2\mathbf{x}_i^\top \mathbf{x}_\ell \\
&= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_\ell\|^2 - 2\mathbf{z}_i^\top \mathbf{z}_\ell \\
&= \|\mathbf{z}_i - \mathbf{z}_\ell\|^2.
\end{aligned}$$

□

A reconstrução de cada observação pode ser escrita como

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto,

$$\mathbf{x}_i \in \mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

as observações podem ser representadas exatamente por apenas r coordenadas, sem alteração de seus produtos internos, normas ou distâncias euclidianas.

Essa situação pode ocorrer mesmo quando $\mathbf{X}$ possui o maior posto possível para suas dimensões. Por exemplo, se

$$n < p$$

e

$$r = n,$$

a matriz possui posto linha completo, mas ainda assim

$$r < p.$$

Nesse caso, as observações ocupam um subespaço de dimensão r dentro de $\mathbb{R}^p$ e sua representação por $\mathbf{Z}$ é exata.

6.5.6 Centralização da matriz de dados

A posição da nuvem depende de seu centro. Para estudar os afastamentos em relação ao vetor de médias, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Proposição 6.13 (Vetores singulares à esquerda de uma matriz centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados centralizada, então

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r,$$

e as colunas da matriz de coordenadas

$$\mathbf{Z} = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

também possuem média igual a zero.

Comprovação. Como as colunas de $\mathbf{X}_c$ estão centralizadas,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD compacta,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui colunas ortonormais, segue que

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{z}_j = 0.$$

□

6.5.7 Antecipação: relação com a matriz de covariâncias amostral

A definição estatística e as propriedades da matriz de covariâncias amostral serão desenvolvidas nos capítulos posteriores dedicados à covariância e às estatísticas amostrais. Neste ponto, interessa apenas sua relação algébrica com a SVD da matriz centralizada.

Para $n \geq 2$, adotando temporariamente a notação

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se o seguinte resultado.

Proposição 6.14 (Relação entre a SVD e a covariância amostral). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Consequentemente:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$ associados aos autovalores positivos;
- os autovalores positivos de $\mathbf{S}$ são

$$\lambda_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r;$$

- tem-se

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) = r.$$

Comprovação. Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \\ &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top, \end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

A expressão obtida é uma decomposição espectral de $\mathbf{S}$ em seu subespaço associado aos autovalores positivos. Portanto, os autovetores correspondentes são as colunas de $\mathbf{V}_r$ e os autovalores positivos são

$$\frac{d_j^2}{n-1}.$$

Como $\mathbf{D}_r$ possui exatamente r elementos diagonais positivos,

$$\text{posto}(\mathbf{S}) = r.$$

□

A centralização impõe ainda uma restrição ao posto. Como

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n - 1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n - 1, p).$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz de covariâncias amostral é necessariamente singular.

Essas relações serão retomadas posteriormente em sua formulação estatística. Aqui, elas mostram que a SVD da matriz centralizada determina diretamente a estrutura espectral da matriz de covariâncias amostral.

6.5.8 Magnitude quadrática da matriz centralizada

Proposição 6.15 (Magnitude quadrática da nuvem centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Além disso, se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

então

$$\|\mathbf{X}_c\|_F^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Consequentemente,

$$\sum_{j=1}^r d_j^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Comprovação. Pela Proposição 6.9,

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Por outro lado,

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1) \mathbf{S}.$$

Logo,

$$\begin{aligned} \|\mathbf{X}_c\|_F^2 &= \operatorname{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= (n-1) \operatorname{tr}(\mathbf{S}). \end{aligned}$$

□

Se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias das observações, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

Portanto,

$$\sum_{j=1}^r d_j^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

A soma dos quadrados dos valores singulares da matriz centralizada representa, assim, a soma quadrática total dos afastamentos das observações em relação ao centro da nuvem.

Como $\text{tr}(\mathbf{S})$ é a soma dos elementos diagonais de $\mathbf{S}$, ela corresponde à soma das variâncias amostrais das p variáveis.

A centralização é essencial para essa interpretação. Para uma matriz não centralizada,

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2$$

mede a soma dos quadrados das posições em relação à origem, e não a dispersão das observações em torno de seu vetor de médias.

Exemplo 6.7 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned}\mathbf{Z} &= \mathbf{X}\mathbf{V}_2 \\ &= \mathbf{U}_2\mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}.\end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das observações. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta fornece a representação exata

$$\mathbf{X} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Como todos os r componentes associados a valores singulares positivos são mantidos:

- a matriz é reconstruída exatamente;
- os produtos internos entre as observações são preservados;
- as normas das observações são preservadas;
- as distâncias euclidianas entre as observações são preservadas;

- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão menor pode ser construída conservando apenas os primeiros k pares singulares, com

$$k < r.$$

Nesse caso, componentes associados a valores singulares positivos são deliberadamente descartados e a reconstrução deixa de ser exata.

A distinção fundamental é, portanto:

- a **SVD compacta** omite dos fatores completos apenas direções associadas à parte nula da transformação e preserva exatamente a matriz;
- a **SVD truncada** descarta também componentes associados a valores singulares positivos e produz uma aproximação.

A forma expandida da SVD permitirá identificar separadamente a contribuição de cada componente singular e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta também pode ser expressa como uma soma de componentes matriciais associados aos pares singulares.

Proposição 6.16 (Forma expandida da SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

possui posto 1 e satisfaz

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

Comprovação. Escrevendo

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

tem-se

$$\begin{aligned} \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top. \end{aligned}$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Multiplicar por $d_j > 0$ não altera o posto, de modo que

$$\text{posto}(d_j \mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Para a norma espectral, se $\|\mathbf{x}\| = 1$,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top \mathbf{x}\| &= d_j |\mathbf{v}_j^\top \mathbf{x}| \|\mathbf{u}_j\| \\ &\leq d_j. \end{aligned}$$

A igualdade é atingida para

$$\mathbf{x} = \mathbf{v}_j.$$

Portanto,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = d_j.$$

Para a norma de Frobenius,

$$\begin{aligned}\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F^2 &= d_j^2 \operatorname{tr}(\mathbf{v}_j \mathbf{u}_j^\top \mathbf{u}_j \mathbf{v}_j^\top) \\ &= d_j^2 (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\ &= d_j^2.\end{aligned}$$

Logo,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

□

A expressão

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é denominada **forma expandida da SVD**.

Cada componente singular representa uma transformação de posto 1: a componente do vetor de entrada na direção $\mathbf{v}_j$ é multiplicada por d_j e enviada para a direção $\mathbf{u}_j$.

Como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0,$$

os componentes singulares estão ordenados de acordo com suas magnitudes nas normas espectral e de Frobenius.

6.6.1 Ortogonalidade dos componentes singulares

Proposição 6.17 (Ortogonalidade dos componentes singulares). *Para*

$$i \neq j,$$

os componentes singulares

$$d_i \mathbf{u}_i \mathbf{v}_i^\top$$

e

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius:

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

Comprovação. Pelo produto interno de Frobenius,

$$\begin{aligned} \left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F &= d_i d_j \operatorname{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\ &= d_i d_j (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i). \end{aligned}$$

Como os vetores singulares são ortonormais, para $i \neq j$,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Logo,

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

□

Como a forma expandida é uma soma de componentes ortogonais segundo o produto interno de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Essa igualdade fornece uma decomposição pitagórica da magnitude quadrática total da matriz entre seus componentes singulares.

6.6.2 SVD truncada na forma expandida

Retomando a Definição 6.5, a aproximação de posto k pode ser expressa diretamente a partir da forma expandida da SVD.

Se

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

então

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Assim, truncar a SVD corresponde a conservar as primeiras k parcelas singulares e descartar

$$\sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa representação permitirá quantificar o erro produzido pelo truncamento e estabelecer as propriedades de otimalidade de $\mathbf{A}_k$.

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.3 Erros produzidos pelo truncamento

Proposição 6.18 (Decomposição e erros da SVD truncada). *Se*

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r,$$

então

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Além disso,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0,$$

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2,$$

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Comprovação. Pela forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Subtraindo

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

obtém-se

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Pela Proposição 6.17, os componentes associados a índices diferentes são ortogonais segundo o produto interno de Frobenius. Como $\mathbf{A}_k$ utiliza os índices

$$1, \dots, k$$

e a diferença utiliza

$$k+1, \dots, r,$$

segue que

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Aplicando a decomposição pitagórica,

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Portanto,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Por outro lado, a matriz residual

$$\mathbf{A} - \mathbf{A}_k$$

possui valores singulares positivos

$$d_{k+1}, d_{k+2}, \dots, d_r.$$

Pela Proposição 6.9, sua norma espectral é igual ao maior desses valores:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

□

A proporção da magnitude quadrática de Frobenius preservada pela aproximação pode ser escrita como

$$\eta_k = \frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}.$$

A proporção descartada é

$$1 - \eta_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

Para uma matriz genérica, η_k mede exclusivamente a proporção de sua magnitude quadrática, segundo a norma de Frobenius, representada pelos primeiros k componentes singulares. Essa quantidade não deve ser interpretada automaticamente como proporção de variância ou de informação estatística.

Quando $\mathbf{A}$ é uma matriz de dados centralizada, entretanto,

$$\|\mathbf{A}\|_F^2$$

corresponde à soma quadrática total dos afastamentos das observações em relação ao centro da nuvem. Nesse contexto específico, η_k representa a proporção dessa dispersão quadrática preservada pelos primeiros k componentes singulares.

A norma espectral descreve outro aspecto do erro. Como

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1},$$

o primeiro valor singular descartado determina o maior erro produzido pelo truncamento sobre qualquer vetor unitário:

$$d_{k+1} = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

Esse máximo é atingido, por exemplo, na direção

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

Assim, a norma espectral mede um erro de pior caso, enquanto a norma de Frobenius agrega quadraticamente os erros associados a todos os componentes singulares descartados.

6.6.4 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.2 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub; Van Loan, 2013)

6.6.5 Aprofundamento: demonstração e unicidade da melhor aproximação

Leitura de aprofundamento

O Teorema de Eckart–Young–Mirsky estabelece a otimalidade da SVD truncada sem exigir que sua demonstração seja utilizada nas aplicações posteriores.

Nesta leitura de aprofundamento, demonstra-se a otimalidade separadamente nas normas espectral e de Frobenius e examina-se quando a melhor aproximação de posto reduzido é ou não única.

Comprovação. Considere inicialmente a norma espectral e uma matriz arbitrária

$$\tilde{\mathbf{A}}$$

com

$$\text{posto}(\tilde{\mathbf{A}}) \leq k.$$

Defina o subespaço

$$\mathcal{S}_{k+1} = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_{k+1} \}.$$

Como

$$\dim(\mathcal{S}_{k+1}) = k + 1$$

e a restrição de $\widetilde{\mathbf{A}}$ a esse subespaço possui imagem de dimensão no máximo k , existe um vetor unitário

$$\mathbf{x} \in \mathcal{S}_{k+1}$$

tal que

$$\widetilde{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Escreva

$$\mathbf{x} = \sum_{j=1}^{k+1} \alpha_j \mathbf{v}_j,$$

com

$$\sum_{j=1}^{k+1} \alpha_j^2 = 1.$$

Então,

$$\begin{aligned} \left\| (\mathbf{A} - \widetilde{\mathbf{A}}) \mathbf{x} \right\|^2 &= \|\mathbf{A}\mathbf{x}\|^2 \\ &= \sum_{j=1}^{k+1} d_j^2 \alpha_j^2 \\ &\geq d_{k+1}^2 \sum_{j=1}^{k+1} \alpha_j^2 \\ &= d_{k+1}^2. \end{aligned}$$

Logo,

$$\left\| \mathbf{A} - \widetilde{\mathbf{A}} \right\|_2 \geq d_{k+1}.$$

Para a SVD truncada,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Portanto, $\mathbf{A}_k$ atinge o limite inferior e é uma solução ótima na norma espectral.

Para a norma de Frobenius, considere o projetor ortogonal

$$\mathbf{P}$$

sobre o espaço coluna de $\tilde{\mathbf{A}}$. Como

$$\text{posto}(\tilde{\mathbf{A}}) \leq k,$$

tem-se

$$\text{posto}(\mathbf{P}) \leq k.$$

Além disso,

$$\mathbf{P}\tilde{\mathbf{A}} = \tilde{\mathbf{A}}.$$

A diferença pode ser decomposta como

$$\mathbf{A} - \tilde{\mathbf{A}} = (\mathbf{I}_q - \mathbf{P}) \mathbf{A} + (\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}).$$

As duas parcelas são ortogonais segundo o produto interno de Frobenius, pois a primeira possui colunas no complemento ortogonal de $\mathcal{C}(\mathbf{P})$, enquanto a segunda possui colunas em $\mathcal{C}(\mathbf{P})$.

Assim,

$$\begin{aligned} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 &= \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 \\ &\quad + \|\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 \\ &\geq \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2. \end{aligned}$$

A primeira parcela pode ser escrita como

$$\|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 = \|\mathbf{A}\|_F^2 - \|\mathbf{P}\mathbf{A}\|_F^2.$$

Considere uma base ortonormal

$$\mathbf{w}_1, \dots, \mathbf{w}_s, \quad s \leq k,$$

do espaço projetado por $\mathbf{P}$. Então,

$$\mathbf{P} = \sum_{i=1}^s \mathbf{w}_i \mathbf{w}_i^\top$$

e

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{i=1}^s \mathbf{w}_i^\top \mathbf{AA}^\top \mathbf{w}_i. \end{aligned}$$

Usando a decomposição espectral

$$\mathbf{AA}^\top = \sum_{j=1}^r d_j^2 \mathbf{u}_j \mathbf{u}_j^\top,$$

tem-se

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{j=1}^r d_j^2 \text{tr}(\mathbf{Pu}_j \mathbf{u}_j^\top) \\ &= \sum_{j=1}^r d_j^2 \mathbf{u}_j^\top \mathbf{Pu}_j. \end{aligned}$$

Defina

$$c_j = \mathbf{u}_j^\top \mathbf{Pu}_j = \|\mathbf{Pu}_j\|^2.$$

Como $\mathbf{P}$ é um projetor ortogonal,

$$0 \leq c_j \leq 1.$$

Além disso,

$$\begin{aligned}
\sum_{j=1}^r c_j &= \sum_{j=1}^r \mathbf{u}_j^\top \mathbf{P} \mathbf{u}_j \\
&\leq \text{tr}(\mathbf{P}) \\
&= \text{posto}(\mathbf{P}) \\
&\leq k.
\end{aligned}$$

Portanto,

$$\|\mathbf{P}\mathbf{A}\|_F^2 = \sum_{j=1}^r c_j d_j^2,$$

com

$$0 \leq c_j \leq 1$$

e

$$\sum_{j=1}^r c_j \leq k.$$

Como os valores singulares estão ordenados, sob as restrições,

$$0 \leq c_j \leq 1 \quad \text{e} \quad \sum_j c_j \leq k,$$

a soma ponderada é maximizada atribuindo peso 1 aos k maiores valores d_j^2 e peso 0 aos demais. Como

$$d_1^2 \geq \dots \geq d_r^2,$$

segue que

$$\|\mathbf{P}\mathbf{A}\|_F^2 \leq \sum_{j=1}^k d_j^2.$$

Portanto,

$$\begin{aligned}\|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &\geq \|\mathbf{A}\|_F^2 - \sum_{j=1}^k d_j^2 \\ &= \sum_{j=k+1}^r d_j^2.\end{aligned}$$

Para

$$\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^\top,$$

tem-se

$$\mathbf{P}\mathbf{A} = \mathbf{A}_k.$$

Além disso,

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Logo, $\mathbf{A}_k$ também atinge o limite inferior na norma de Frobenius. $\square$

O teorema mostra que nenhuma matriz de posto no máximo k pode apresentar erro menor que $\mathbf{A}_k$ nas duas normas consideradas.

Na norma espectral, o erro ótimo é determinado exclusivamente pelo primeiro valor singular descartado,

$$d_{k+1}.$$

Na norma de Frobenius, o erro ótimo depende de toda a parcela espectral descartada,

$$\sqrt{\sum_{j=k+1}^r d_j^2}.$$

6.6.5.1 Unicidade da aproximação

A otimalidade estabelecida pelo Teorema 6.2 não implica, em geral, que a matriz aproximante seja única. A situação depende também da norma considerada.

Na norma de Frobenius, a melhor aproximação de posto no máximo k é única quando há separação estrita entre os valores singulares que ficam em lados opostos do truncamento:

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o ponto de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de subespaços dentro desse bloco singular podem produzir aproximações ótimas distintas.

Na norma espectral, a matriz

$$\mathbf{A}_k$$

é sempre uma aproximação ótima, mas a aproximação ótima pode não ser única mesmo quando

$$d_k > d_{k+1}.$$

Isso ocorre porque outras matrizes de posto no máximo k podem produzir o mesmo erro máximo

$$d_{k+1}.$$

Portanto, a condição

$$d_k > d_{k+1}$$

garante unicidade da melhor aproximação na norma de Frobenius, mas não deve ser utilizada como critério geral de unicidade na norma espectral.

Quando

$$k \geq r,$$

não há truncamento de componentes singulares positivos e a representação exata é

$$\mathbf{A}_k = \mathbf{A},$$

com erro igual a zero.

6.6.6 Exemplo de aproximação de posto 1

Exemplo 6.8 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

Neste exemplo, as normas espectral e de Frobenius do erro coincidem porque a matriz residual possui apenas um valor singular positivo. Quando mais de um componente singular é descartado, os dois erros são, em geral, diferentes.

6.6.7 Aproximação de uma matriz de dados

A SVD truncada possui uma interpretação direta como projeção das observações em um subespaço de menor dimensão.

Proposição 6.19 (SVD truncada como projeção das observações). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados e

$$1 \leq k < r,$$

então sua aproximação truncada satisfaz

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X} \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{P}_k = \mathbf{V}_k \mathbf{V}_k^\top$$

é o projetor ortogonal sobre

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \},$$

cada linha de $\mathbf{X}_k$ é a projeção ortogonal da observação correspondente sobre $\mathcal{S}_k$.

Se

$$\mathbf{Z}_k = \mathbf{X}\mathbf{V}_k,$$

então

$$\mathbf{Z}_k = \mathbf{U}_k\mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k\mathbf{V}_k^\top.$$

Comprovação. Pela relação

$$\mathbf{X}\mathbf{V}_k = \mathbf{U}_k\mathbf{D}_k,$$

tem-se

$$\begin{aligned}\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top &= \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top \\ &= \mathbf{X}_k.\end{aligned}$$

Como as colunas de $\mathbf{V}_k$ são ortonormais,

$$\mathbf{P}_k = \mathbf{V}_k\mathbf{V}_k^\top$$

é o projetor ortogonal sobre $\mathcal{S}_k$.

Portanto, para cada observação $\mathbf{x}_i$,

$$\hat{\mathbf{x}}_{i,k} = \mathbf{P}_k\mathbf{x}_i$$

e, equivalentemente,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij}\mathbf{v}_j.$$

O resíduo correspondente é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij}\mathbf{v}_j.$$

□

A matriz

$$\mathbf{Z}_k \in \mathbb{R}^{n \times k}$$

fornece uma representação das observações em k coordenadas. A multiplicação por

$$\mathbf{V}_k^\top$$

reconstrói suas aproximações no espaço original $\mathbb{R}^p$.

Além disso,

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2 = \sum_{j=k+1}^r d_j^2.$$

Pelo Teorema 6.2, nenhuma matriz de posto no máximo k possui erro de reconstrução menor na norma de Frobenius. Em particular, entre as representações obtidas pela projeção das observações em subespaços lineares de dimensão no máximo k , o subespaço

$$\mathcal{S}_k = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

minimiza a soma dos erros quadráticos de reconstrução.

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a proporção da dispersão quadrática total da nuvem preservada pelas primeiras k direções singulares.

Essa relação será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, ela deve ser interpretada como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada e a pseudoinversa utilizam os mesmos componentes singulares com finalidades distintas.

Na aproximação de posto reduzido, componentes associados a valores singulares positivos são deliberadamente descartados:

$$\mathbf{A} \longrightarrow \mathbf{A}_k.$$

Na pseudoinversa, todos os componentes associados a valores singulares positivos são mantidos, mas os fatores de escala são invertidos:

$$d_j \longrightarrow \frac{1}{d_j}, \quad j = 1, \dots, r.$$

As direções associadas à parte nula da transformação não são invertidas.

Essa construção conduz à pseudoinversa de Moore–Penrose e, a partir dela, às soluções de sistemas lineares e problemas de mínimos quadrados.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Se $r \geq 1$, todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos. Portanto,

$$\mathbf{D}_r^{-1} = \text{diag} \left(\frac{1}{d_1}, \dots, \frac{1}{d_r} \right)$$

está bem definida.

Se $r = 0$, então $\mathbf{A} = \mathbf{0}$ e sua pseudoinversa será definida como a matriz nula de dimensão $p \times q$.

Definição 6.11 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

No caso $\mathbf{A} = \mathbf{0}$, define-se

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz os escalonamentos de $\mathbf{A}$ nas direções associadas aos valores singulares positivos e anula as componentes pertencentes a

$$\mathcal{N}(\mathbf{A}^\top).$$

Assim, ela atua como uma inversão entre os subespaços

$$\mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

nos quais a ação de $\mathbf{A}$ é não nula.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio de sua decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

então

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que cada autovalor não nulo é substituído por seu inverso e os autovalores nulos permanecem iguais a zero.

A definição baseada na SVD,

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

estende essa construção para qualquer matriz real, inclusive matrizes retangulares e não simétricas.

Quando $\mathbf{A}$ é quadrada e invertível,

$$r = p = q,$$

todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Portanto, a inversa usual constitui um caso particular da pseudoinversa.

6.7.2 Aprofundamento: caracterização de Moore–Penrose

Leitura de aprofundamento

A pseudoinversa foi definida anteriormente a partir da SVD. Existe também uma caracterização independente dessa decomposição: a pseudoinversa de Moore–Penrose é a única matriz que satisfaz simultaneamente quatro identidades algébricas.

Esta seção apresenta essas condições, verifica que a matriz construída pela SVD as satisfaz e demonstra sua unicidade. A caracterização é importante na teoria de inversas generalizadas, mas não é necessária para acompanhar as aplicações posteriores da pseudoinversa a projeções e mínimos quadrados.

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.3 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente o caso

$$\mathbf{A} = \mathbf{0}.$$

A matriz

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}$$

satisfaz imediatamente as quatro condições de Moore–Penrose.

Além disso, se uma matriz

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

satisfaz essas condições para $\mathbf{A} = \mathbf{0}$, a segunda condição fornece

$$\mathbf{GAG} = \mathbf{G}.$$

Como $\mathbf{A} = \mathbf{0}$,

$$\mathbf{GAG} = \mathbf{0},$$

e, portanto,

$$\mathbf{G} = \mathbf{0}.$$

Logo, a pseudoinversa também é única nesse caso.

Suponha agora

$$\mathbf{A} \neq \mathbf{0}.$$

Então

$$r = \text{posto}(\mathbf{A}) \geq 1,$$

e, pela SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Então,

$$\begin{aligned} \mathbf{A} \mathbf{A}^+ \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{A}. \end{aligned}$$

De modo semelhante,

$$\begin{aligned} \mathbf{A}^+ \mathbf{A} \mathbf{A}^+ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{A}^+. \end{aligned}$$

Além disso,

$$\mathbf{A} \mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top,$$

que são matrizes simétricas. Portanto, a matriz definida pela SVD satisfaz as quatro condições de Moore–Penrose.

Para demonstrar a unicidade, suponha que

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

também satisfaça as quatro condições.

A matriz $\mathbf{A} \mathbf{G}$ é simétrica e

$$\begin{aligned} (\mathbf{A} \mathbf{G})^2 &= \mathbf{A} \mathbf{G} \mathbf{A} \mathbf{G} \\ &= (\mathbf{A} \mathbf{G} \mathbf{A}) \mathbf{G} \\ &= \mathbf{A} \mathbf{G}. \end{aligned}$$

Logo, $\mathbf{A} \mathbf{G}$ é um projetor ortogonal.

Sua imagem está contida em $\mathcal{C}(\mathbf{A})$. Além disso, se

$$\mathbf{y} = \mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{G}\mathbf{y} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x} = \mathbf{y}.$$

Portanto,

$$\mathbf{A}\mathbf{G} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top.$$

De maneira análoga, $\mathbf{G}\mathbf{A}$ é simétrica e idempotente.

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Reciprocamente, se

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0},$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{G}\mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Como $\mathbf{G}\mathbf{A}$ é um projetor ortogonal,

$$\mathbf{G}\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})^\perp} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top.$$

Da condição

$$\mathbf{GAG} = \mathbf{G},$$

segue que

$$\mathcal{C}(\mathbf{G}) \subseteq \mathcal{C}(\mathbf{GA}) = \mathcal{C}(\mathbf{A}^\top).$$

Considere agora um vetor singular à esquerda $\mathbf{u}_j$, com $j \leq r$. Como

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

tem-se

$$\mathbf{AGu}_j = \mathbf{u}_j.$$

Como

$$\mathbf{Gu}_j \in \mathcal{C}(\mathbf{A}^\top),$$

esse vetor pode ser escrito como

$$\mathbf{Gu}_j = \sum_{\ell=1}^r c_\ell \mathbf{v}_\ell.$$

Aplicando $\mathbf{A}$,

$$\mathbf{u}_j = \sum_{\ell=1}^r c_\ell d_\ell \mathbf{u}_\ell.$$

Pela unicidade das coordenadas na base ortonormal,

$$c_\ell = \begin{cases} 1/d_j, & \ell = j, \\ 0, & \ell \neq j. \end{cases}$$

Portanto,

$$\mathbf{Gu}_j = \frac{1}{d_j} \mathbf{v}_j.$$

Considere, por fim,

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top).$$

Como $\mathbf{A}\mathbf{G}$ projeta sobre $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Além disso,

$$\mathbf{G}\mathbf{u} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \cap \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

segue que

$$\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Assim, $\mathbf{G}$ atua sobre a base ortonormal formada pelas colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ exatamente como

$$\mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Logo,

$$\mathbf{G} = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top = \mathbf{A}^+.$$

Portanto, a pseudoinversa de Moore–Penrose existe e é única. □

6.7.3 Pseudoinversa e projetores

Os produtos envolvendo $\mathbf{A}$ e sua pseudoinversa recuperam os projetores ortogonais dos quatro espaços fundamentais.

Proposição 6.20 (Projetores determinados pela pseudoinversa). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

então

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Consequentemente,

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

Comprovação. Pela definição da pseudoinversa,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Pela Proposição 6.8,

$$\mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Analogamente,

$$\begin{aligned}\mathbf{A}^+ \mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.\end{aligned}$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathcal{C}(\mathbf{A}^\top)^\perp = \mathcal{N}(\mathbf{A}),$$

os projetores sobre os complementos ortogonais são

$$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

□

A Tabela 6.6 resume essas relações.

Tabela 6.6: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A} \mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+ \mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A}$	$\mathcal{N}(\mathbf{A})$

Os dois produtos atuam em espaços diferentes. A matriz

$$\mathbf{A}\mathbf{A}^+ \in \mathbb{R}^{q \times q}$$

atua no contradomínio e seleciona a componente pertencente à imagem da transformação.

Por outro lado,

$$\mathbf{A}^+\mathbf{A} \in \mathbb{R}^{p \times p}$$

atua no domínio e seleciona a componente pertencente ao espaço linha, isto é, ao complemento ortogonal do núcleo de $\mathbf{A}$.

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

A pseudoinversa permite caracterizar a compatibilidade do sistema, descrever todas as suas soluções e identificar aquela de menor norma.

Proposição 6.21 (Sistemas compatíveis pela pseudoinversa). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

é compatível se, e somente se,

$$\mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Quando o sistema é compatível, o conjunto de todas as soluções é

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

em que

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Entre todas essas soluções,

$$\mathbf{x}^{\star} = \mathbf{A}^+\mathbf{b}$$

é a única de menor norma euclidiana.

Se

$$r = p,$$

o núcleo de $\mathbf{A}$ é trivial e a solução é única.

Comprovação. O sistema é compatível exatamente quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Pela Proposição 6.20,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Suponha que o sistema seja compatível. Então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se $\mathbf{x}$ é qualquer outra solução,

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x}_0.$$

Logo,

$$\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0},$$

e, portanto,

$$\mathbf{x} - \mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma}.$$

Além disso,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\boldsymbol{\gamma} \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\mathbf{x}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\boldsymbol{\gamma}\|^2.$$

A menor norma é obtida somente quando

$$\boldsymbol{\gamma} = \mathbf{0}.$$

Portanto,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de menor norma.

Finalmente, se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e nenhuma componente adicional pode ser acrescentada à solução. □

6.7.5 Mínimos quadrados

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

pode-se procurar um vetor $\mathbf{x}$ cuja imagem $\mathbf{Ax}$ esteja o mais próxima possível de $\mathbf{b}$.

O problema é

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o erro mínimo é zero e o problema coincide com a resolução de um sistema compatível.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe solução exata e busca-se a melhor aproximação possível dentro do espaço coluna de $\mathbf{A}$.

Definição 6.12 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma **solução de mínimos quadrados** de

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

A pseudoinversa fornece diretamente todas as soluções desse problema.

Proposição 6.22 (Mínimos quadrados pela pseudoinversa). *Para qualquer*

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor ajustado de mínimos quadrados é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b}.$$

O resíduo é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+)\mathbf{b}$$

e satisfaz

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top),$$

ou, equivalentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Consequentemente, uma solução de mínimos quadrados satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

O conjunto de todas as soluções de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todos os minimizadores,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é o único de menor norma euclidiana.

Comprovação. Pela Proposição 6.20,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{A}\mathbf{A}^+.$$

Defina

$$\hat{\mathbf{b}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

e

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}}.$$

Como $\hat{\mathbf{b}}$ é a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$,

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathbf{b} - \mathbf{A}\mathbf{x} = \mathbf{r} + (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}),$$

em que

$$\mathbf{r} \perp (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}).$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 = \|\mathbf{r}\|^2 + \|\hat{\mathbf{b}} - \mathbf{Ax}\|^2.$$

Assim,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 \geq \|\mathbf{r}\|^2,$$

com igualdade se, e somente se,

$$\mathbf{Ax} = \hat{\mathbf{b}}.$$

Como

$$\mathbf{A}(\mathbf{A}^+\mathbf{b}) = \mathbf{AA}^+\mathbf{b} = \hat{\mathbf{b}},$$

o vetor

$$\mathbf{A}^+\mathbf{b}$$

é uma solução de mínimos quadrados.

Além disso, um vetor $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados se, e somente se,

$$\mathbf{A}\hat{\mathbf{x}} = \hat{\mathbf{b}} = \mathbf{AA}^+\mathbf{b}.$$

Nesse caso, seu resíduo é

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} = \mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Portanto,

$$\mathbf{A}^\top(\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0},$$

o que equivale às equações normais

$$\mathbf{A}^\top\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^\top\mathbf{b}.$$

Reciprocamente, se $\hat{\mathbf{x}}$ satisfaz as equações normais, então

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathbf{A}\hat{\mathbf{x}} \in \mathcal{C}(\mathbf{A}),$$

a decomposição

$$\mathbf{b} = \mathbf{A}\hat{\mathbf{x}} + (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}})$$

é ortogonal. Pela unicidade da projeção ortogonal,

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \hat{\mathbf{b}}.$$

Logo, $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados.

Para caracterizar todos os minimizadores, observe que

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

se, e somente se,

$$\mathbf{A}(\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b}) = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b} \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

com

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Finalmente,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\gamma \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\hat{\mathbf{x}}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\gamma\|^2.$$

A menor norma é obtida unicamente quando

$$\gamma = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de mínimos quadrados de menor norma. □

A decomposição geométrica correspondente é

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Como essas parcelas são ortogonais,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.5.1 Caso de posto coluna completo

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível, e

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Portanto,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

6.7.5.2 Caso de posto linha completo

Se

$$r = q \leq p,$$

então

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Logo, para todo

$$\mathbf{b} \in \mathbb{R}^q,$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

é compatível.

Nesse caso,

$$\mathbf{AA}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{AA}^\top)^{-1}.$$

A solução

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a solução exata de menor norma.

6.7.6 Expressão da solução nas direções singulares

A forma expandida da pseudoinversa permite interpretar diretamente a solução de menor norma nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.7 Aprofundamento: instabilidade e pseudoinversa truncada

Leitura de aprofundamento

A pseudoinversa inverte os valores singulares positivos. Como consequência, valores singulares muito pequenos podem produzir grandes fatores de amplificação na solução. Esta seção examina a sensibilidade da pseudoinversa a perturbações e apresenta a pseudoinversa truncada como uma forma de evitar a inversão de algumas direções singulares. Essas ideias pertencem ao estudo de problemas inversos e regularização e não são necessárias para acompanhar os resultados centrais de mínimos quadrados desenvolvidos neste capítulo.

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned}\Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j.\end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Como os valores singulares positivos de $\mathbf{A}^+$ são

$$\frac{1}{d_r} \geq \dots \geq \frac{1}{d_1},$$

tem-se, para $r \geq 1$,

$$\|\mathbf{A}^+\|_2 = \frac{1}{d_r}.$$

Consequentemente,

$$\|\Delta \hat{\mathbf{x}}\| \leq \frac{1}{d_r} \|\varepsilon\|.$$

O menor valor singular positivo controla, portanto, a maior amplificação possível de uma perturbação pela pseudoinversa.

Esse comportamento relaciona:

- valores singulares positivos pequenos;
- forte amplificação nas direções correspondentes da pseudoinversa;
- sensibilidade a perturbações;
- instabilidade de problemas inversos.

Quando $\mathbf{A}$ possui posto máximo, um menor valor singular muito pequeno em relação a d_1 corresponde também a um número de condição elevado. Se a matriz não possui posto máximo, o número de condição definido anteriormente é infinito, enquanto a pseudoinversa continua invertendo somente os valores singulares positivos.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.7.1 Pseudoinversa truncada

Considere a aproximação truncada

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Sua pseudoinversa de Moore–Penrose é

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

Ela pode ser utilizada como uma inversão truncada de $\mathbf{A}$, conservando somente os k maiores valores singulares.

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.8 Exemplo com o sistema condutor

Exemplo 6.9 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuada os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned}
\hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\
&= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\
&= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}.
\end{aligned}$$

O vetor ajustado é

$$\begin{aligned}
\hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\
&= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\
&= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\begin{aligned}
\mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\
&= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}.
\end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão dos fatores de escala associados aos valores singulares positivos;
- anulação das componentes pertencentes a $\mathcal{N}(\mathbf{A}^\top)$;
- construção dos projetores sobre $\mathcal{C}(\mathbf{A})$ e $\mathcal{C}(\mathbf{A}^\top)$;
- solução de sistemas lineares compatíveis;
- seleção da solução exata de menor norma quando há não unicidade;
- solução de problemas de mínimos quadrados;
- seleção da solução de mínimos quadrados de menor norma quando há vários minimizadores.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares estende a ideia de decomposição espectral a qualquer matriz real. Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existe uma decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo d_j ,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

Se

$$r = \text{posto}(\mathbf{A}),$$

a SVD compacta é

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r), \quad d_1 \geq \dots \geq d_r > 0.$$

A SVD compacta é uma representação exata. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

descarta parcelas associadas a valores singulares positivos e produz uma aproximação de posto reduzido.

A construção da SVD decorre das decomposições espectrais das duas matrizes de Gram:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Seus autovalores positivos são

$$d_1^2, \dots, d_r^2.$$

Assim, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio.

Geometricamente, a imagem da bola unitária é um elipsoide de dimensão r contido em

$$\mathcal{C}(\mathbf{A}),$$

com semieixos

$$d_1 \mathbf{u}_1, \dots, d_r \mathbf{u}_r.$$

Os valores singulares medem, portanto, os fatores de escala nas direções singulares. Em particular,

$$\|\mathbf{A}\|_2 = d_1,$$

de modo que o maior valor singular é o maior fator de ampliação produzido pela transformação.

A SVD também fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \},$$

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \},$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_r \},$$

e

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{v}_{r+1}, \dots, \mathbf{v}_p \}.$$

Consequentemente,

$$\dim(\mathcal{N}(\mathbf{A})) = p - r$$

e

$$\dim(\mathcal{N}(\mathbf{A}^\top)) = q - r.$$

As normas espectral e de Frobenius possuem representações simples em termos dos valores singulares:

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a SVD compacta fornece

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Como

$$\mathbf{X} = \mathbf{Z} \mathbf{V}_r^\top,$$

essa representação é exata quando são mantidos todos os r componentes singulares positivos.

Além disso,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top,$$

de modo que a representação compacta preserva os produtos internos, as normas e as distâncias euclidianas entre as observações.

Analogamente,

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top$$

fornece as coordenadas das variáveis nas direções singulares à esquerda.

Quando a matriz de dados está centralizada,

$$\mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Adotando a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Assim, os vetores singulares à direita de $\mathbf{X}_c$ determinam as direções espectrais associadas aos autovalores positivos de $\mathbf{S}$, enquanto

$$\frac{d_j^2}{n-1}$$

são os autovalores positivos correspondentes.

Essa relação antecipa uma das principais conexões entre a SVD e as técnicas de redução de dimensionalidade que serão desenvolvidas posteriormente.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

representa a matriz como uma soma de componentes singulares de posto 1, ortogonais entre si segundo o produto interno de Frobenius.

Na norma de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

é uma decomposição pitagórica da magnitude quadrática total da matriz.

O Teorema de Eckart–Young–Mirsky estabelece que

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é uma solução do problema de melhor aproximação de $\mathbf{A}$ entre todas as matrizes de posto no máximo k , tanto na norma espectral quanto na norma de Frobenius. Os erros mínimos são

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A norma espectral mede o maior erro remanescente em uma direção unitária, enquanto a norma de Frobenius agrega quadraticamente todas as parcelas descartadas.

A pseudoinversa de Moore–Penrose é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

com $\mathbf{A}^+ = \mathbf{0}$ quando $\mathbf{A} = \mathbf{0}$.

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução de mínimos quadrados de menor norma.

Quando

$$r < p,$$

podem existir outros minimizadores, obtidos pela adição de componentes pertencentes a

$$\mathcal{N}(\mathbf{A}).$$

A pseudoinversa seleciona, entre todos eles, o único vetor de menor norma euclidiana.

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b},$$

isto é, a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$, enquanto o resíduo

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+) \mathbf{b}$$

pertence a

$$\mathcal{N}(\mathbf{A}^\top).$$

A Tabela 6.7 reúne as relações principais.

Tabela 6.7: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Utiliza bases ortonormais completas no domínio e no contradomínio
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata usando somente os componentes associados aos valores singulares positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Relaciona uma direção do domínio a uma direção do contradomínio

Objeto	Expressão	Interpretação
Matrizes de Gram	$\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$	Determinam os quadrados dos valores singulares e os vetores singulares correspondentes
Posto	$r = \#\{j : d_j > 0\}$	Dimensão da imagem da transformação
Norma espectral	$\ \mathbf{A}\ _2 = d_1$	Maior fator de ampliação da transformação
Norma de Frobenius	$\ \mathbf{A}\ _F^2 = \sum_{j=1}^r d_j^2$	Magnitude quadrática total da matriz
Coordenadas das observações	$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$	Representação das observações nas direções singulares à direita
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$	Aproximação ótima de posto no máximo k
Erro espectral	$\ \mathbf{A} - \mathbf{A}_k\ _2 = d_{k+1}$	Maior erro do truncamento sobre vetores unitários
Erro de Frobenius	$\ \mathbf{A} - \mathbf{A}_k\ _F^2 = \sum_{j=k+1}^r d_j^2$	Magnitude quadrática total dos componentes descartados
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$	Inverte os fatores de escala associados aos valores singulares positivos
Projeter no espaço coluna	$\mathbf{A} \mathbf{A}^+$	Projeta sobre $\mathcal{C}(\mathbf{A})$
Projeter no espaço linha	$\mathbf{A}^+ \mathbf{A}$	Projeta sobre $\mathcal{C}(\mathbf{A}^\top)$
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}$	Seleciona a solução de mínimos quadrados de menor norma

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir as formas completa, compacta e truncada da SVD;
- diferenciar uma representação compacta exata de uma aproximação truncada de posto reduzido;
- relacionar a SVD às decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$;
- interpretar geometricamente os valores e vetores singulares;
- identificar o posto e os quatro espaços fundamentais por meio da SVD;
- construir os projetores ortogonais associados aos espaços fundamentais;
- calcular e interpretar as normas espectral e de Frobenius a partir dos valores singulares;
- interpretar a dualidade entre observações e variáveis em uma matriz de dados;
- representar exatamente as observações em coordenadas singulares e compreender a preservação de produtos internos e distâncias;

- relacionar a SVD de uma matriz centralizada à estrutura espectral de sua matriz de covariâncias amostral;
- representar uma matriz como soma de componentes singulares ortogonais de posto 1;
- construir aproximações de posto reduzido e determinar seus erros nas normas espectral e de Frobenius;
- aplicar o Teorema de Eckart–Young–Mirsky;
- construir e interpretar a pseudoinversa de Moore–Penrose;
- distinguir solução exata, solução de mínimos quadrados e solução de mínimos quadrados de menor norma;
- interpretar mínimos quadrados como um problema de projeção ortogonal.

Ideia central do capítulo

A Decomposição em Valores Singulares descreve uma matriz por meio de pares de direções ortonormais no domínio e no contradomínio e dos fatores de escala que relacionam essas direções. Essa estrutura revela o posto e os espaços fundamentais, fornece representações exatas ou aproximadas de menor dimensão e permite construir projetores, pseudoinversas e soluções de mínimos quadrados.

A SVD encerra o percurso dedicado às principais estruturas de Álgebra Linear utilizadas neste módulo. Matrizes, espaços vetoriais, transformações lineares, decomposição espectral e SVD fornecem, em conjunto, a base geométrica e matricial para representar estruturas multivariadas.

O próximo capítulo desenvolve **Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada**. Gradientes, Hessianas, multiplicadores de Lagrange, diferenciais matriciais, traços, determinantes e integrais completarão os fundamentos matemáticos necessários para formular problemas de otimização, estimação e transformação de variáveis nos capítulos seguintes.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Neste capítulo, salvo indicação em contrário, $\|\cdot\|$ aplicada a vetores denota a norma euclidiana definida em Definição 1.10.

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2,$$

em que $\|\cdot\|_F$ denota a norma de Frobenius definida em Definição 6.7.

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{A}\mathbf{X}\mathbf{B}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Representação de primeira ordem
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a forma da transformação linear que representa localmente a variação da função e, conseqüentemente, a dimensão do gradiente, da Jacobiana ou do operador diferencial utilizado para representá-la.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa o incremento utilizado como argumento da transformação linear que define o diferencial. Assim,

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}$$

é linear em $d\mathbf{x}$.

A notação diferencial é frequentemente interpretada de maneira informal como uma variação infinitesimal. Formalmente, porém, o diferencial é a aplicação linear que fornece a parte de primeira ordem da variação da função.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana estão associados à mesma ideia de aproximação linear local, mas correspondem a contradomínios diferentes. Para uma função escalar, o gradiente fornece a representação vetorial da aplicação linear que define o diferencial. Para uma função vetorial, a Jacobiana fornece a representação matricial dessa aplicação linear.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Proposição 7.1 (Direções de maior crescimento e redução). *Se f é diferenciável em $\mathbf{x}$ e*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior taxa de redução de primeira ordem ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

Comprovação. Pelo Teorema 1.1,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. Aplicando o mesmo argumento à direção oposta, obtém-se o resultado para a maior taxa de redução de primeira ordem. $\square$

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação de primeira ordem não distingue direções de crescimento ou redução, e o comportamento local passa a depender de termos de ordem superior.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^\top \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

Suponha que as derivadas parciais das componentes de $\mathbf{g}$ existam no ponto $\mathbf{x}$. A matriz Jacobiana de $\mathbf{g}$ nesse ponto é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \cdots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} g_1 \\ g_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

Assim, a parte linear local de uma transformação afim é exatamente a matriz $\mathbf{A}$, enquanto o termo de translação desaparece na diferenciação.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.1 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x})) \mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem do produto reflete a composição das aplicações lineares: sobre uma perturbação $\mathbf{h}_{\mathbf{x}} \in \mathbb{R}^p$, atua primeiro $\mathbf{J}_{\mathbf{g}}(\mathbf{x})$ e, sobre o resultado, atua $\mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x}))$. Por isso, na representação matricial, a Jacobiana de $\mathbf{h}$ aparece à esquerda.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})^{\top} \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^{\top} \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função com derivadas parciais de segunda ordem no ponto considerado. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

O segundo diferencial é uma forma quadrática no incremento $d\mathbf{x}$ e descreve a contribuição local de segunda ordem da função.

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a segunda taxa de variação de f ao longo da reta que passa por $\mathbf{x}$ na direção $\mathbf{u}$ e fornece a medida de curvatura direcional utilizada neste capítulo.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned}\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2.\end{aligned}$$

Ela é positiva para todo vetor não nulo. Para vetores unitários, a segunda taxa de variação é maior nas direções com maior componente em módulo no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^{\top} (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2} \right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2 \left(x_2 - \frac{1}{2} \right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.2 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0). \end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a variação local de primeira ordem;
- a Hessiana determina a variação local de segunda ordem.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece. Se a forma quadrática associada à Hessiana é não degenerada, ela fornece o termo dominante da variação local. Quando essa forma se anula em alguma direção, termos de ordem superior podem ser necessários para determinar o comportamento da função.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Proposição 7.2 (Condição necessária de primeira ordem). *Se f é diferenciável em um ponto interior $\mathbf{x}^*$ de seu domínio e possui nesse ponto um máximo ou mínimo local, então*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Comprovação. Se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \neq \mathbf{0},$$

considere a direção unitária

$$\mathbf{u} = \frac{\nabla_{\mathbf{x}} f(\mathbf{x}^*)}{\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\|}.$$

Então,

$$D_{\mathbf{u}} f(\mathbf{x}^*) = \|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| > 0,$$

enquanto

$$D_{-\mathbf{u}} f(\mathbf{x}^*) = -\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| < 0.$$

Assim, existem direções locais de aumento e de redução, o que contradiz a existência de um extremo local interior. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

□

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

tem-se

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

A recíproca da proposição anterior não é verdadeira em geral: um ponto estacionário pode ser mínimo local, máximo local ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.3 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável em uma vizinhança de um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^$ é um mínimo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^$ é um máximo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*)$$

é indefinida, então $\mathbf{x}^$ é um ponto de sela.*

Se a Hessiana é apenas semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)

Comprovação. Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Considere inicialmente

$$\mathbf{H} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Como $\mathbf{H}$ é simétrica e positiva definida, seu menor autovalor satisfaz

$$\lambda_{\min}(\mathbf{H}) > 0.$$

Portanto,

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} \geq \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2.$$

Além disso,

$$o(\|\mathbf{h}\|^2) = \varepsilon(\mathbf{h}) \|\mathbf{h}\|^2,$$

com

$$\varepsilon(\mathbf{h}) \rightarrow 0$$

quando $\mathbf{h} \rightarrow \mathbf{0}$.

Logo, para $\mathbf{h}$ suficientemente pequeno,

$$|\varepsilon(\mathbf{h})| < \frac{1}{4} \lambda_{\min}(\mathbf{H}).$$

Assim,

$$\begin{aligned} f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) &\geq \frac{1}{2} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 - \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &= \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &> 0 \end{aligned}$$

para todo $\mathbf{h} \neq \mathbf{0}$ suficientemente pequeno. Portanto, $\mathbf{x}^*$ é um mínimo local estrito.

O caso de Hessiana negativa definida é obtido aplicando o mesmo argumento a $-f$, produzindo um máximo local estrito.

Se a Hessiana é indefinida, existem vetores unitários $\mathbf{u}_1$ e $\mathbf{u}_2$ tais que

$$\mathbf{u}_1^\top \mathbf{H} \mathbf{u}_1 > 0$$

e

$$\mathbf{u}_2^\top \mathbf{H} \mathbf{u}_2 < 0.$$

Considere perturbações da forma

$$\mathbf{h} = t\mathbf{u}_j.$$

Então,

$$f(\mathbf{x}^* + t\mathbf{u}_j) - f(\mathbf{x}^*) = \frac{1}{2}t^2\mathbf{u}_j^\top \mathbf{H}\mathbf{u}_j + o(t^2).$$

Para $|t|$ suficientemente pequeno, o sinal dessa diferença coincide com o sinal da forma quadrática. Assim, a função assume valores maiores que

$$f(\mathbf{x}^*)$$

em uma direção e menores em outra, arbitrariamente próximos de $\mathbf{x}^*$. Portanto, $\mathbf{x}^*$ é um ponto de sela. $\square$

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0, 0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1-t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, conjuntos afins como hiperplanos, bolas e regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.4 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.5 (Critério da Hessiana para convexidade). *Considere uma função*

$$f : \mathcal{C} \longrightarrow \mathbb{R}$$

duas vezes continuamente diferenciável em um conjunto convexo aberto

$$\mathcal{C} \subseteq \mathbb{R}^p.$$

Então, f é convexa em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Analogamente, f é côncava em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Além disso, se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa. Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente côncava.

(Boyd; Vandenberghe, 2004)

Comprovação. Considere dois pontos distintos

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e defina

$$g(t) = f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})), \quad 0 \leq t \leq 1.$$

Como $\mathcal{C}$ é convexo, todo o segmento entre $\mathbf{x}$ e $\mathbf{y}$ pertence a $\mathcal{C}$.

Pela regra da cadeia,

$$g''(t) = (\mathbf{y} - \mathbf{x})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) (\mathbf{y} - \mathbf{x}).$$

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{z}) \succeq \mathbf{0}$$

para todo $\mathbf{z} \in \mathcal{C}$, então

$$g''(t) \geq 0,$$

e, portanto, g é convexa em $[0, 1]$. Como isso vale para qualquer segmento contido em $\mathcal{C}$, f é convexa.

Reciprocamente, se f é convexa, então a restrição de f a qualquer reta é convexa. Para qualquer

$$\mathbf{x} \in \mathcal{C}$$

e qualquer direção

$$\mathbf{u} \in \mathbb{R}^p,$$

considere

$$h(t) = f(\mathbf{x} + t\mathbf{u})$$

para t suficientemente próximo de zero. A convexidade de h implica

$$h''(0) \geq 0.$$

Como

$$h''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u},$$

tem-se

$$\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u} \geq 0$$

para todo $\mathbf{u}$. Logo,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}.$$

O resultado para funções côncavas segue aplicando o argumento a $-f$.

Se a Hessiana é positiva definida em todo ponto, então, para $\mathbf{x} \neq \mathbf{y}$,

$$g''(t) > 0$$

ao longo do segmento. Logo, g é estritamente convexa, e portanto f é estritamente convexa. O caso de Hessiana negativa definida é análogo. $\square$

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

A condição

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

em todo o domínio é suficiente para convexidade estrita, mas não é necessária. Uma função estritamente convexa pode possuir Hessiana singular em pontos isolados. Por exemplo,

$$f(x) = x^4$$

é estritamente convexa em $\mathbb{R}$, embora

$$f''(0) = 0.$$

7.4.5 Consequências para otimização

Proposição 7.3 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa e existe um ponto estacionário $\mathbf{x}^$, então esse ponto é o único minimizador global. (Boyd; Vandenberghe, 2004)*

Comprovação. Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$. $\square$

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

De fato, como $\mathbf{A}$ é simétrica,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}).$$

Assim, existe

$$\mathbf{z} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{b}^\top \mathbf{z} \neq 0.$$

Ao longo da reta

$$\mathbf{x} = t\mathbf{z},$$

o termo quadrático é nulo e

$$f(t\mathbf{z}) = -t\mathbf{b}^\top \mathbf{z} + c,$$

que pode tender a $-\infty$ escolhendo o sinal apropriado de t .

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

A Proposição 7.2 estabelece a condição necessária de primeira ordem para extremos locais interiores, enquanto o Teorema 7.3 utiliza a Hessiana para classificar pontos estacionários quando o teste de segunda ordem é conclusivo.

No caso convexo, a Proposição 7.3 mostra que um ponto estacionário é minimizador global. Esses resultados fornecem as condições de otimalidade; a questão seguinte é construir um procedimento iterativo para localizar esses pontos.

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top (\mathbf{x} - \mathbf{x}^{(t)}) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}). \end{aligned}$$

Defina

$$\mathbf{g}^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$$

e

$$\mathbf{H}^{(t)} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}).$$

Escrevendo

$$\mathbf{d} = \mathbf{x} - \mathbf{x}^{(t)},$$

o modelo quadrático local pode ser representado por

$$m_t(\mathbf{d}) = f(\mathbf{x}^{(t)}) + (\mathbf{g}^{(t)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{H}^{(t)} \mathbf{d}.$$

Seu gradiente em relação a $\mathbf{d}$ é

$$\nabla_{\mathbf{d}} m_t(\mathbf{d}) = \mathbf{g}^{(t)} + \mathbf{H}^{(t)} \mathbf{d}.$$

Se

$$\mathbf{H}^{(t)} \succ \mathbf{0},$$

o modelo quadrático é estritamente convexo e possui um único minimizador. Esse minimizador, denominado **direção de Newton**, satisfaz

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}.$$

Quando $\mathbf{H}^{(t)}$ é invertível,

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

A atualização de Newton com passo completo é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)},$$

ou, equivalentemente,

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver o sistema linear

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

sem calcular explicitamente a inversa da Hessiana.

Se a Hessiana é apenas invertível, mas não positiva definida, a solução desse sistema é um ponto estacionário do modelo quadrático, mas pode não ser seu minimizador. Nesse caso, a direção de Newton também pode deixar de ser uma direção de descida para a função original.

Proposição 7.4 (Direção de Newton como direção de descida). *Suponha que*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) \neq \mathbf{0}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \succ \mathbf{0}.$$

Então a direção de Newton $\mathbf{d}^{(t)}$ é uma direção de descida para f em $\mathbf{x}^{(t)}$, isto é,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

Comprovação. Como

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)},$$

tem-se

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} = -(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

Como $\mathbf{H}^{(t)} \succ \mathbf{0}$, também

$$(\mathbf{H}^{(t)})^{-1} \succ \mathbf{0}.$$

Logo, para $\mathbf{g}^{(t)} \neq \mathbf{0}$,

$$(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)} > 0,$$

e, portanto,

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

□

O passo completo corresponde a

$$\alpha_t = 1.$$

Uma forma mais geral da atualização é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \alpha_t \mathbf{d}^{(t)}, \quad 0 < \alpha_t \leq 1.$$

A escolha de $\alpha_t < 1$ produz um passo de Newton amortecido. Esse recurso pode ser utilizado quando o modelo quadrático local ainda não representa adequadamente a função ao longo de um passo completo.

Assim, a construção da direção e a escolha do comprimento da etapa são operações distintas. Métodos numéricos de otimização costumam combinar a direção de Newton com procedimentos de controle da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana constante e positiva definida, uma etapa completa de Newton conduz exatamente ao único minimizador,

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b},$$

independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, as linhas da Jacobiana das restrições são linearmente independentes. O espaço tangente ao conjunto viável é então

$$\mathcal{T}_{\mathbf{x}} = \mathcal{N}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})).$$

Portanto, uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

O espaço normal correspondente é

$$\mathcal{T}_{\mathbf{x}}^{\perp} = \mathcal{C}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})^{\top}),$$

isto é, o espaço gerado pelos gradientes das restrições.

Em um ótimo local regular $\mathbf{x}^*$, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{T}_{\mathbf{x}^*}.$$

Consequentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{T}_{\mathbf{x}^*}^\perp = \mathcal{C} \left[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \right].$$

7.6.1 Multiplicadores de Lagrange

Teorema 7.6 (Condição de Lagrange). *Considere funções continuamente diferenciáveis*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

e

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m.$$

Seja $\mathbf{x}^*$ um ótimo local do problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)$$

sejam linearmente independentes.

Essa condição equivale a

$$\text{posto } [\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)] = m.$$

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

Comprovação. Como $\mathbf{x}^*$ é um ótimo local regular, a derivada direcional da função objetivo é nula em todas as direções tangentes ao conjunto viável. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)].$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)]^\perp.$$

Pelo Teorema 3.6,

$$\mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)]^\perp = \mathcal{C}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top].$$

Assim, existe um vetor

$$\mu^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \mu^*.$$

Definindo

$$\lambda^* = -\mu^*,$$

obtém-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

□

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

Sob a condição de regularidade do teorema, as condições necessárias de primeira ordem podem ser escritas como

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Essas condições identificam candidatos a ótimo restrito. No caso geral, elas não são suficientes para garantir mínimo ou máximo. A classificação exige condições adicionais sobre a função objetivo, as restrições e a variação de segunda ordem nas direções tangentes.

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere o problema

$$\max_{\mathbf{x}} \mathbf{a}^\top \mathbf{x},$$

em que

$$\mathbf{a} \neq \mathbf{0},$$

sujeito à restrição

$$\mathbf{x}^\top \mathbf{x} = 1.$$

A restrição exige que $\mathbf{x}$ tenha norma euclidiana unitária:

$$\|\mathbf{x}\| = 1.$$

Escrevendo-a na forma

$$c(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} - 1 = 0,$$

o problema pode ser tratado pelos multiplicadores de Lagrange.

Para manter a formulação como um problema de minimização, considere a função objetivo

$$f(\mathbf{x}) = -\mathbf{a}^\top \mathbf{x}.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^\top \mathbf{x} + \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

As condições de primeira ordem são obtidas diferenciando a lagrangiana em relação a $\mathbf{x}$ e ao multiplicador λ .

Em relação a $\mathbf{x}$,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a} + 2\lambda \mathbf{x}.$$

Portanto, em um ponto candidato à solução,

$$-\mathbf{a} + 2\lambda \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}.$$

Em relação a λ ,

$$\frac{\partial \mathcal{L}(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{x}^\top \mathbf{x} - 1.$$

Assim, a segunda condição de primeira ordem simplesmente recupera a restrição:

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Substituindo

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}$$

na restrição,

$$\left(\frac{1}{2\lambda} \mathbf{a} \right)^\top \left(\frac{1}{2\lambda} \mathbf{a} \right) = 1,$$

e, portanto,

$$\frac{\mathbf{a}^\top \mathbf{a}}{4\lambda^2} = 1.$$

Como

$$\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|^2,$$

segue que

$$4\lambda^2 = \|\mathbf{a}\|^2,$$

ou

$$\lambda = \pm \frac{\|\mathbf{a}\|}{2}.$$

Consequentemente, existem dois pontos candidatos:

$$\mathbf{x}_1 = \frac{\mathbf{a}}{\|\mathbf{a}\|}$$

e

$$\mathbf{x}_2 = -\frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

Para identificar qual deles maximiza a função objetivo original, avalie

$$\mathbf{a}^\top \mathbf{x}.$$

No primeiro ponto,

$$\mathbf{a}^\top \mathbf{x}_1 = \mathbf{a}^\top \frac{\mathbf{a}}{\|\mathbf{a}\|} = \frac{\|\mathbf{a}\|^2}{\|\mathbf{a}\|} = \|\mathbf{a}\|.$$

No segundo,

$$\mathbf{a}^\top \mathbf{x}_2 = -\|\mathbf{a}\|.$$

Logo, o máximo é atingido em

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|},$$

e o valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Geometricamente, a solução mostra que, entre todos os vetores unitários, o produto interno com $\mathbf{a}$ é máximo quando $\mathbf{x}$ possui a mesma direção e o mesmo sentido de $\mathbf{a}$.

O resultado também coincide com o caso de igualdade no Teorema 1.1, pois

$$\mathbf{a}^\top \mathbf{x} \leq \|\mathbf{a}\| \|\mathbf{x}\| = \|\mathbf{a}\|,$$

e a igualdade ocorre quando $\mathbf{x}$ é proporcional a $\mathbf{a}$.

Se $\mathbf{a} = \mathbf{0}$, a função objetivo é constante e todo vetor unitário satisfaz

$$\mathbf{a}^\top \mathbf{x} = 0.$$

Nesse caso, todo vetor que satisfaz a restrição é uma solução ótima.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Portanto, todo ponto regular estacionário do problema restrito é um autovetor de $\mathbf{A}$, e o valor da função objetivo nesse ponto é o autovalor correspondente.

Pelo Teorema 5.5, desenvolvido no capítulo de decomposição espectral,

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\max}(\mathbf{A}),$$

e

$$\min_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\min}(\mathbf{A}).$$

Assim, os multiplicadores de Lagrange produzem a equação de autovalores como condição de estacionariedade, enquanto o resultado espectral identifica quais desses pontos realizam os extremos globais.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica,

$$\mathbf{C} \in \mathbb{R}^{m \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^m.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

Esse sistema em blocos reúne as condições de primeira ordem do problema restrito.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e $\mathbf{C}$ possui posto linha completo, a função objetivo é estritamente convexa e o conjunto definido por

$$\mathbf{C}\mathbf{x} = \mathbf{d}$$

é afim. Quando esse conjunto é não vazio, as condições de primeira ordem identificam o único minimizador global.

Mais geralmente, para uma matriz $\mathbf{A}$ semidefinida positiva, a unicidade depende de a forma quadrática ser positiva nas direções viáveis não nulas, isto é,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} > 0$$

para todo

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{C}\mathbf{z} = \mathbf{0}.$$

Sem condições desse tipo, a resolução do sistema fornece apenas candidatos que satisfazem as condições de primeira ordem.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Derivadas de formas quadráticas

As formas quadráticas foram definidas em Definição 2.23, e a Proposição 2.10 mostrou que seu valor depende apenas da parte simétrica da matriz. O objetivo agora é obter suas derivadas.

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Proposição 7.5 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

Comprovação. Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana. □

Utilizando a classificação de positividade apresentada em Definição 2.24, se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, todos os vetores da forma

$$\mathbf{x} = \mu + \mathbf{z}, \quad \mathbf{z} \in \mathcal{N}(\mathbf{A}),$$

também minimizam a função. Portanto, a unicidade ocorre quando

$$\mathbf{A} \succ \mathbf{0}.$$

7.7.3 Derivadas da norma euclidiana

Retomando a norma euclidiana definida em Definição 1.10,

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Portanto,

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{Ax})^\top (\mathbf{b} - \mathbf{Ax}).$$

Pela regra da cadeia,

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{Ax}).\end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

A Hessiana é constante e não depende de $\mathbf{x}$. Além disso,

$$\mathbf{z}^\top \mathbf{A}^\top \mathbf{Az} = \|\mathbf{Az}\|^2 \geq 0,$$

para todo

$$\mathbf{z} \in \mathbb{R}^p.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

As equações normais já foram introduzidas geometricamente em Definição 3.21, a partir da projeção sobre o espaço coluna. No Capítulo 6, Proposição 6.22 apresentou a solução por meio da SVD e da pseudoinversa. Nesta seção, o mesmo resultado será obtido a partir da condição de primeira ordem do cálculo diferencial.

7.7.5 Equações normais

Proposição 7.6 (Caracterização dos mínimos quadrados pelas equações normais). *Considere*

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2,$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é minimizador global de f se, e somente se, satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}.$$

Se $\mathbf{A}$ possui posto coluna completo, o minimizador é único e dado por

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Comprovação. A derivação anterior fornece

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Logo, f é convexa. Pelo Proposição 7.3, um ponto é minimizador global se, e somente se, seu gradiente é nulo. Portanto,

$$\nabla_{\mathbf{x}} f(\hat{\mathbf{x}}) = \mathbf{0}$$

se, e somente se,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

de modo que f é estritamente convexa e possui, no máximo, um minimizador. Como

$$\mathbf{A}^\top \mathbf{A}$$

é invertível, esse minimizador é

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

□

A condição

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}$$

mostra que o resíduo de mínimos quadrados é ortogonal ao espaço coluna de $\mathbf{A}$.

O caso de posto deficiente, o conjunto de todos os minimizadores e a solução de menor norma foram estabelecidos em Proposição 6.22. Aqui, o objetivo é destacar que as equações normais surgem diretamente da condição de primeira ordem do problema de otimização.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos não negativos

$$\omega_1, \dots, \omega_q \geq 0$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Como Ω é diagonal e, portanto, simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, em qualquer minimizador, o resíduo satisfaz a condição de ortogonalidade ponderada

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Quando

$$\Omega \succ \mathbf{0},$$

retoma-se o produto interno induzido definido em Definição 3.16:

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^{\top} \Omega \mathbf{v}.$$

A condição anterior corresponde, portanto, à ortogonalidade do resíduo ao espaço coluna de $\mathbf{A}$ nessa geometria ponderada.

Se Ω é singular, a mesma condição algébrica permanece válida, mas a forma ponderada é apenas semidefinida positiva e não define um produto interno em todo o espaço.

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^{\top} \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^{\top} \Omega \mathbf{A})^{-1} \mathbf{A}^{\top} \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

Quando

$$\Omega \succ \mathbf{0},$$

o critério pode ser escrito utilizando a norma induzida de Definição 3.17:

$$f_{\omega}(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|_{\Omega}^2,$$

com

$$\|\mathbf{z}\|_{\Omega}^2 = \mathbf{z}^{\top} \Omega \mathbf{z}.$$

Assim, os mínimos quadrados ponderados correspondem a uma projeção segundo a geometria induzida por Ω .

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma classe ampla de funções de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual duas vezes diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Proposição 7.7 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Comprovação. Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}). \end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^\top + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana. □

A Hessiana possui, portanto, duas parcelas com papéis distintos:

$$\underbrace{2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x})}_{\text{parcela de primeira ordem dos resíduos}} + \underbrace{2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x})}_{\text{correção de não linearidade}} .$$

O primeiro termo da Hessiana,

$$2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}),$$

é semidefinido positivo. Isso não implica, porém, que a função de mínimos quadrados não linear seja convexa, pois a segunda parcela da Hessiana pode ser indefinida.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos ou quando as Hessianas das funções residuais têm contribuição reduzida na região considerada, a segunda parcela pode ser desprezada aproximadamente. Nesse caso,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}).$$

No caso linear,

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}}^2 r_i(\mathbf{x}) = \mathbf{0}$$

para todo i . Portanto, a segunda parcela desaparece exatamente e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Retomando a convenção estabelecida no início do capítulo, o gradiente matricial é

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius definido em Definição 6.6,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr} (\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

Assim como o gradiente de uma função escalar de vetor representa o diferencial segundo o produto interno euclidiano, o gradiente matricial representa o diferencial segundo o produto interno de Frobenius.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço foi definido em Definição 2.9, e suas propriedades algébricas foram estabelecidas em Proposição 2.5 e Proposição 2.8. Para o cálculo matricial, serão utilizadas especialmente as permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}}\phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Proposição 7.8 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

Comprovação. O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

□

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Derivadas da norma de Frobenius

Pela Definição 6.7,

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

De fato, essa função é estritamente convexa em $\mathbf{X}$, pois sua segunda variação em uma perturbação não nula $d\mathbf{X}$ é

$$d^2\phi = 2\|d\mathbf{X}\|_F^2 > 0.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}\mathbf{X}\Gamma + \mathbf{A}^{\top}\mathbf{X}\Gamma^{\top}.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

A dimensão do gradiente coincide com a dimensão do argumento:

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{m \times n}.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{\top}\mathbf{A}\mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_{\cdot 1}, \dots, \mathbf{x}_{\cdot n},$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_{\cdot j}^{\top} \mathbf{A} \mathbf{x}_{\cdot j}.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_{\cdot 1}, \dots, 2\mathbf{A}\mathbf{x}_{\cdot n}.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{X}\mathbf{B}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{XB} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Se $\mathbf{X}$ não possui posto coluna completo, os minimizadores não são únicos. A solução de mínimos quadrados de menor norma de Frobenius é

$$\widehat{\mathbf{B}}^\star = \mathbf{X}^+ \mathbf{Y}.$$

Mais geralmente, todos os minimizadores podem ser escritos como

$$\widehat{\mathbf{B}} = \mathbf{X}^+ \mathbf{Y} + (\mathbf{I}_k - \mathbf{X}^+ \mathbf{X}) \mathbf{C},$$

em que

$$\mathbf{C} \in \mathbb{R}^{k \times p}$$

é arbitrária.

A parcela adicional pertence ao núcleo da transformação

$$\mathbf{B} \mapsto \mathbf{XB}$$

e, portanto, não altera os valores ajustados.

Assim, quando o critério utilizado é simplesmente a norma de Frobenius dos resíduos, o problema matricial pode ser interpretado como p problemas de mínimos quadrados que compartilham a mesma matriz de delineamento.

Proposição 7.9 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{XB}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa se, e somente se, $\mathbf{X}$ possui posto coluna completo.

Comprovação. Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa.

Reciprocamente, se $\mathbf{X}$ não possui posto coluna completo, existe

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{X}\mathbf{z} = \mathbf{0}.$$

Escolha qualquer vetor não nulo

$$\mathbf{c} \in \mathbb{R}^p$$

e defina

$$d\mathbf{B} = \mathbf{z}\mathbf{c}^\top.$$

Então

$$d\mathbf{B} \neq \mathbf{0},$$

mas

$$\mathbf{X} d\mathbf{B} = \mathbf{0}.$$

Portanto,

$$d^2Q = 0$$

em uma direção não nula, e a função não é estritamente convexa. □

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

Como

$$\Omega \succeq \mathbf{0}$$

e

$$\Sigma \succ \mathbf{0},$$

o critério também pode ser escrito como

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \left\| \Omega^{1/2} \mathcal{E}(\mathbf{B}) \Sigma^{-1/2} \right\|_F^2.$$

Essa forma mostra que a ponderação atua simultaneamente nas duas dimensões da matriz residual.

A matriz Ω atua no espaço das observações e pondera as linhas da matriz de resíduos. A matriz Σ^{-1} atua no espaço das respostas e define a geometria utilizada para combinar as colunas da matriz de resíduos.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \operatorname{tr} \left[(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B} \right].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{X} \mathbf{B} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, ou equivalentemente, se as colunas de

$$\Omega^{1/2} \mathbf{X}$$

são linearmente independentes, então o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Para Σ fixa e positiva definida, a ponderação invertível no espaço das respostas altera o valor do critério e sua geometria, mas não altera o conjunto de minimizadores em relação a $\mathbf{B}$.

Isso ocorre porque

$$\Sigma^{-1}$$

é invertível e pode ser eliminada da condição de primeira ordem.

A ponderação das observações por Ω , por outro lado, permanece nas equações normais e pode modificar o estimador.

Os diferenciais matriciais e as identidades de traço permitem agora tratar funções em que a própria matriz variável aparece no interior de uma inversa ou de um determinante. Essas estruturas são particularmente importantes quando o parâmetro pertence ao conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

A matriz inversa e o determinante foram definidos em Definição 2.11 e Definição 2.13, enquanto a relação entre determinante e invertibilidade foi estabelecida em Teorema 2.4. A classificação das matrizes simétricas por positividade foi apresentada em Definição 2.24.

Nesta seção, esses objetos são retomados como funções de uma matriz variável. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Proposição 7.10 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019)

Comprovação. Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

□

Quando $\mathbf{X} \succ \mathbf{0}$ e a perturbação

$$d\mathbf{X} \succeq \mathbf{0},$$

tem-se

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \succeq \mathbf{0},$$

e, portanto,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \preceq \mathbf{0}.$$

Assim, a inversão reverte a ordem de Loewner: aumentos semidefinidos positivos da matriz produzem variações semidefinidas negativas de sua inversa.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Proposição 7.11 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019)

Comprovação. Considere uma perturbação $\mathbf{H}$ e a função

$$g(t) = \det(\mathbf{X} + t\mathbf{H}).$$

Como $\mathbf{X}$ é invertível,

$$g(t) = \det(\mathbf{X}) \det(\mathbf{I}_p + t\mathbf{X}^{-1}\mathbf{H}).$$

Pela multilinearidade do determinante,

$$\det(\mathbf{I}_p + t\mathbf{M}) = 1 + t \operatorname{tr}(\mathbf{M}) + o(t).$$

Aplicando essa expansão com

$$\mathbf{M} = \mathbf{X}^{-1}\mathbf{H},$$

obtém-se

$$g(t) = \det(\mathbf{X}) [1 + t \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}) + o(t)].$$

Logo,

$$g'(0) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}).$$

Como $\mathbf{H}$ representa uma perturbação arbitrária,

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}d\mathbf{X}).$$

□

Como

$$d \det(\mathbf{X}) = \operatorname{tr}[(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X}],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X})\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X})\mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

A restrição

$$\mathbf{X} \succ \mathbf{0}$$

garante simultaneamente que $\mathbf{X}$ é invertível e que

$$\det(\mathbf{X}) > 0,$$

de modo que o logaritmo real do determinante está bem definido.

Proposição 7.12 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

Comprovação. Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \text{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \text{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente. □

Para uma matriz real invertível, não necessariamente simétrica, pode-se considerar

$$\phi(\mathbf{X}) = \log |\det(\mathbf{X})|.$$

Como o determinante não se anula no conjunto das matrizes invertíveis, seu sinal permanece constante em uma vizinhança suficientemente pequena de cada matriz invertível. Nesse domínio,

$$d \log |\det(\mathbf{X})| = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}),$$

e, portanto,

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}.$$

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2\phi = -\text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Logo,

$$d^2\phi \leq 0.$$

Proposição 7.13 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas.

(Boyd; Vandenberghe, 2004)

Comprovação. O conjunto das matrizes simétricas positivas definidas é convexo. Para toda matriz

$$\mathbf{X} \succ \mathbf{0}$$

e toda direção simétrica não nula $\mathbf{H}$,

$$d^2\phi[\mathbf{H}, \mathbf{H}] = -\|\mathbf{X}^{-1/2}\mathbf{H}\mathbf{X}^{-1/2}\|_F^2 < 0.$$

Logo, a restrição de ϕ a qualquer segmento não degenerado do cone positivo definido possui segunda derivada negativa. Portanto,

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava nesse domínio. □

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}\mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\text{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Observe que o gradiente possui a mesma dimensão de $\mathbf{X}$,

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{p \times p}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^\top \mathbf{X}^{-1} \mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top \mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}} \phi = -(\mathbf{X}^{-1} \mathbf{a})(\mathbf{X}^{-1} \mathbf{a})^\top.$$

Essa matriz é semidefinida negativa.

Consequentemente, para uma perturbação

$$\mathbf{H} \succeq \mathbf{0},$$

tem-se

$$d\phi[\mathbf{H}] = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top \mathbf{H}] \leq 0.$$

Assim, aumentar $\mathbf{X}$ segundo a ordem de Loewner não aumenta a forma quadrática inversa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^\top \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}} \phi = 2\mathbf{X}^{-1} \mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{xx}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere $n > 0$ e o critério

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dQ &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma}Q = \frac{n}{2}\Sigma^{-1} - \frac{1}{2}\Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

A condição de primeira ordem é

$$n\Sigma^{-1} = \Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n\Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Proposição 7.14 (Minimização do critério de covariância). *Considere*

$$n > 0$$

e uma matriz

$$\mathbf{G} \succ \mathbf{0}.$$

Então, a função

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Comprovação. Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\mathrm{tr}(\Sigma^{-1}\mathbf{G}) = \mathrm{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$Q(\Sigma) = \frac{1}{2} [\mathrm{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$Q(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

$$z = n.$$

Como cada parcela

$$z_j - n \log z_j$$

possui mínimo único em $z_j = n$, o mínimo global exige

$$z_1 = \cdots = z_p = n.$$

Portanto,

$$\mathbf{Z} = n\mathbf{I}_p.$$

Essa igualdade equivale a

$$\Sigma = \frac{1}{n}\mathbf{G}.$$

□

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido.

Além disso, o critério é ilimitado inferiormente. De fato, escolhendo uma direção unitária

$$\mathbf{u} \in \mathcal{N}(\mathbf{G}),$$

pode-se fazer o autovalor de Σ associado a essa direção tender a zero. Nessa direção, o termo

$$\text{tr}(\Sigma^{-1}\mathbf{G})$$

não recebe contribuição, enquanto

$$\log \det(\Sigma) \longrightarrow -\infty.$$

Portanto,

$$Q(\Sigma) \longrightarrow -\infty,$$

e o problema não possui minimizador no cone positivo definido.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

Nesta seção, o núcleo necessário para os capítulos seguintes é formado por três ideias:

- o operador vec ;
- o produto de Kronecker;
- a identidade que relaciona vec e produtos matriciais.

As subseções posteriores sobre Hessianas vetorizadas, matriz de comutação, meia vetorização, matrizes de duplicação e eliminação e Jacobianas de transformações matriciais serão apresentadas como aprofundamento. Elas são úteis em desenvolvimentos mais avançados de cálculo matricial e inferência, mas não são necessárias para uma primeira leitura do restante do livro.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11} \mathbf{C} & \cdots & a_{1n} \mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1} \mathbf{C} & \cdots & a_{mn} \mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1)(\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Proposição 7.15 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{A}\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

A identidade mostra que uma transformação que atua simultaneamente à esquerda e à direita de uma matriz pode ser representada como uma transformação linear usual sobre o vetor formado por seus elementos.

Assim,

$$\mathbf{X} \mapsto \mathbf{A}\mathbf{X}\mathbf{\Gamma}$$

corresponde, após vetorização, a

$$\text{vec}(\mathbf{X}) \mapsto (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X}\mathbf{\Gamma}.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \mathbf{\Gamma}.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \mathbf{\Gamma}^\top \otimes \mathbf{A}.$$

7.10.4 Aprofundamento: derivadas vetorizadas e parâmetros matriciais

Leitura de aprofundamento

As subseções seguintes desenvolvem ferramentas úteis quando parâmetros matriciais precisam ser tratados explicitamente como vetores. Elas permitem representar Hessianas, transposições, parâmetros simétricos e Jacobianas matriciais por meio de vec , produto de Kronecker e matrizes especiais.

Esses resultados são importantes em desenvolvimentos avançados de inferência multivariada e cálculo matricial, mas podem ser omitidos em uma primeira leitura sem comprometer a continuidade dos capítulos seguintes.

7.10.4.1 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr} (\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec} (\nabla_{\mathbf{X}} \phi)^\top d \text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec} (\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.4.2 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec} (\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned}\text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}).\end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Proposição 7.16 (Convexidade da forma quadrática matricial). *Considere*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}\Gamma),$$

em que

$$\mathbf{A} = \mathbf{A}^\top \in \mathbb{R}^{m \times m}$$

e

$$\Gamma = \Gamma^\top \in \mathbb{R}^{n \times n}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então ϕ é convexa em $\mathbf{X}$.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então ϕ é estritamente convexa.

Comprovação. A Hessiana vetorizada é

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2 (\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então

$$\Gamma \otimes \mathbf{A} \succeq \mathbf{0}.$$

Logo, a Hessiana é semidefinida positiva e ϕ é convexa.

Se ambas as matrizes são positivas definidas, então

$$\Gamma \otimes \mathbf{A} \succ \mathbf{0}.$$

Nesse caso, a Hessiana é positiva definida e ϕ é estritamente convexa. □

7.10.4.3 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^\top.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^\top$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.4.4 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{A}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior de $\mathbf{A}$, incluindo a diagonal.

Quando

$$\mathbf{A} = \mathbf{S} = \mathbf{S}^\top,$$

o operador vech contém exatamente os elementos distintos de $\mathbf{S}$. Por isso, ele fornece uma parametrização sem redundância do espaço das matrizes simétricas.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos. A redução ocorre porque uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos. Assim, vech fornece uma parametrização sem redundância do espaço das matrizes simétricas.

7.10.4.5 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.4.6 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é a matriz de seleção que satisfaz

$$\text{vech}(\mathbf{A}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{A})$$

para toda matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \neq \mathbf{I}_{p^2}.$$

A matriz $\mathbf{L}_p^{\text{elim}}$ conserva apenas os elementos correspondentes à parte triangular inferior, enquanto $\mathbf{D}_p^{\text{dup}}$ reconstrói uma matriz impondo simetria. Portanto, esse produto não recupera arbitrariamente uma matriz não simétrica.

Para uma matriz simétrica $\mathbf{S}$, entretanto,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S}) = \text{vec}(\mathbf{S}).$$

7.10.4.7 Diferenciais de parâmetros simétricos

Proposição 7.17 (Gradiente em relação aos elementos distintos de uma matriz simétrica).
Considere um parâmetro matricial

$$\Sigma = \Sigma^\top \in \mathbb{R}^{p \times p}$$

e uma função escalar

$$\phi(\Sigma).$$

Suponha que seu diferencial possa ser escrito como

$$d\phi = \text{tr} [\mathbf{G}^\top d\Sigma],$$

em que

$$d\Sigma = d\Sigma^\top.$$

Então,

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

Em particular, quando

$$\mathbf{G} = \nabla_\Sigma \phi,$$

tem-se

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\nabla_\Sigma \phi).$$

Comprovação. Como

$$\text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} \text{vech}(\Sigma),$$

tem-se

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Além disso,

$$d\phi = \text{vec}(\mathbf{G})^\top d \text{vec}(\Sigma).$$

Substituindo,

$$d\phi = \text{vec}(\mathbf{G})^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Logo,

$$d\phi = \left[(\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}) \right]^\top d \text{vech}(\Sigma),$$

de onde segue

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

□

A parametrização por

$$\text{vech}(\Sigma)$$

remove a redundância existente em

$$\text{vec}(\Sigma),$$

pois uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos livres.

7.10.4.8 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^{\top} \mathbf{X} + \mathbf{X}^{\top} d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned} \text{vec}(d\mathbf{X}^{\top} \mathbf{X}) &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^{\top}) \\ &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}). \end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^{\top} d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^{\top}) \text{vec}(d\mathbf{X}).$$

Logo,

$$d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) = [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ \times d \operatorname{vec}(\mathbf{X}).$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica, a representação por

$$\operatorname{vec}(\mathbf{X}^\top \mathbf{X})$$

contém elementos repetidos. Uma representação sem redundância é obtida por

$$\operatorname{vech}(\mathbf{X}^\top \mathbf{X}).$$

Aplicando a matriz de eliminação,

$$d \operatorname{vech}(\mathbf{X}^\top \mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) \\ = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \operatorname{vec}(\mathbf{X}).$$

Assim, a Jacobiana relativa somente aos elementos distintos de $\mathbf{X}^\top \mathbf{X}$ é

$$\mathbf{J}_{\operatorname{vech} \circ \mathcal{G}}(\mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}).$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

O bloco de aprofundamento mostrou como vec e o produto de Kronecker podem ser estendidos para representar derivadas de ordem superior e parâmetros matriciais com restrições estruturais.

Para a continuidade do livro, as ideias essenciais a reter desta seção são

$$\text{vec}(\mathbf{A}\mathbf{X}\mathbf{\Gamma}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e o fato de que matrizes simétricas possuem apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças, momentos e distribuições marginais de vetores aleatórios contínuos. A mudança de variáveis permite, adicionalmente, transformar regiões de integração e determinar densidades após transformações do vetor aleatório.

Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$. Nesta seção, integrais múltiplas, marginalização, esperanças e mudança de variáveis constituem o núcleo necessário para os capítulos probabilísticos seguintes. A diferenciação sob o sinal de integração será apresentada posteriormente como aprofundamento.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

O produto cartesiano corresponde ao caso mais simples. Para regiões mais gerais, os limites de uma integral podem depender das demais variáveis. Em duas dimensões, por exemplo, uma região da forma

$$\mathcal{D} = \{(x_1, x_2) : a < x_1 < b, c(x_1) < x_2 < d(x_1)\}$$

conduz a

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2 = \int_a^b \int_{c(x_1)}^{d(x_1)} f(x_1, x_2) dx_2 dx_1,$$

quando as condições de integração correspondentes são satisfeitas.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.7 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.8 (Teorema de Fubini). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow \mathbb{R}$$

é mensurável e absolutamente integrável, isto é,

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então, para quase todo $x_1 \in \mathcal{D}_1$,

$$x_2 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_2$, e, para quase todo $x_2 \in \mathcal{D}_2$,

$$x_1 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_1$.

Além disso,

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) \, dx_1 \, dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) \, dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) \, dx_1 \right] dx_2. \end{aligned}$$

(Axler, 2020)

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Definição 7.15 (Densidade conjunta). O vetor aleatório $\mathbf{X}$ é absolutamente contínuo em relação à medida de Lebesgue em $\mathbb{R}^p$ quando existe uma função mensurável

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty]$$

tal que, para todo conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

tem-se

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A função $f_{\mathbf{X}}$ é denominada **densidade conjunta** de $\mathbf{X}$.

Tomando

$$\mathcal{A} = \mathbb{R}^p,$$

segue necessariamente que

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Proposição 7.18 (Densidades marginais). *Considere o vetor aleatório absolutamente contínuo particionado como*

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2).$$

Então, uma densidade marginal de $\mathbf{X}_1$ é

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2,$$

e uma densidade marginal de $\mathbf{X}_2$ é

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

Comprovação. Como a densidade conjunta é não negativa, o Teorema 7.7 permite integrar sucessivamente suas componentes.

Para qualquer conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^{p_1},$$

tem-se

$$\begin{aligned} P(\mathbf{X}_1 \in \mathcal{A}) &= \int_{\mathcal{A} \times \mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 d\mathbf{x}_2 \\ &= \int_{\mathcal{A}} \left[\int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \right] d\mathbf{x}_1. \end{aligned}$$

Portanto,

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2$$

é uma densidade marginal de $\mathbf{X}_1$. O argumento para $\mathbf{X}_2$ é análogo. $\square$

A marginalização elimina as componentes que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 \, dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções escalares, vetoriais e matriciais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.9 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol, 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

o elemento de volume transforma-se segundo

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Proposição 7.19 (Densidade de uma transformação invertível). *Considere um vetor aleatório absolutamente contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$, tal que*

$$P(\mathbf{X} \in \mathcal{D}) = 1,$$

e uma transformação

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

satisfazendo as condições do Teorema 7.9.

Defina

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}).$$

Então, para

$$\mathbf{y} \in \mathcal{G},$$

a densidade de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Para

$$\mathbf{y} \notin \mathcal{G},$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{y}) = 0.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é globalmente injetiva, a fórmula anterior não pode ser aplicada diretamente com uma única inversa. Sob condições de regularidade, pode-se particionar o domínio em regiões nas quais a transformação seja injetiva e somar as contribuições correspondentes às diferentes pré-imagens.

Esse caso não será desenvolvido em detalhe neste capítulo.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0,35x_1x_2 \\ x_2 + 0,20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0,35x_2 & 0,35x_1 \\ 0,40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0,35x_2 - 0,14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

A parametrização polar não é uma transformação globalmente bijetiva em todas as escolhas possíveis de domínio: a origem possui representação angular não única e o ângulo é periódico. Para a aplicação da fórmula de mudança de variáveis, trabalha-se em regiões adequadas de injetividade; as fronteiras envolvidas possuem medida nula e não alteram o valor das integrais usuais.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e sua raiz quadrada principal simétrica positiva definida

$$\Sigma^{1/2}.$$

Considere a transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned}\mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).\end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsoides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Aprofundamento: diferenciação sob o sinal de integração

Leitura de aprofundamento

A diferenciação sob o sinal de integração é utilizada para justificar formalmente identidades envolvendo funções de verossimilhança, vetor escore e informação de Fisher.

Esse conteúdo é importante para desenvolvimentos inferenciais mais formais, mas pode ser omitido em uma primeira leitura. Para a continuidade imediata dos capítulos probabilísticos, basta reter que a troca entre derivação e integração exige condições de regularidade e não pode ser realizada automaticamente.

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.10 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.11 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. *para todo $\theta \in \mathcal{V}$, a função*

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. *exista $\delta > 0$ tal que*

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. *para quase todo $\mathbf{x} \in \mathcal{D}$, a função*

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. *exista uma função integrável*

$$M_j : \mathcal{D} \rightarrow [0, \infty)$$

tal que, para quase todo

$$\mathbf{x} \in \mathcal{D},$$

a desigualdade

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

seja válida para todo t com $|t| < \delta$;

5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Comprovação. Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \mapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x})\mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

$$\begin{aligned} \lim_{m \rightarrow \infty} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \int_{\mathcal{D}} \lim_{m \rightarrow \infty} q_m(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}. \end{aligned}$$

Por outro lado,

$$\begin{aligned} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \frac{\int_{\mathcal{D}} h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) d\mathbf{x} - \int_{\mathcal{D}} h(\mathbf{x}, \theta_0) d\mathbf{x}}{t_m} \\ &= \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m}. \end{aligned}$$

Logo,

$$\lim_{m \rightarrow \infty} \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Como a sequência $t_m \rightarrow 0$ foi escolhida arbitrariamente, a derivada parcial existe e satisfaz a igualdade enunciada. $\square$

Quando as condições do Teorema 7.11 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.11 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned} \mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}. \end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

X

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A parte de aprofundamento mostrou, adicionalmente, como condições de dominação podem justificar a diferenciação de integrais parametrizadas e identidades utilizadas posteriormente em inferência.

Para a continuidade do livro, as ideias centrais a reter são:

- probabilidades são obtidas por integração da densidade conjunta;
- densidades marginais são obtidas integrando as componentes que se deseja eliminar;
- esperanças de vetores e matrizes são calculadas componente a componente;
- mudanças de variáveis exigem o determinante absoluto da Jacobiana;
- transformações afins produzem fatores de volume constantes;
- transformações elipsoidais convertem geometria esférica e elipsoidal.

7.12 Aprofundamento: aplicações à estimação e à inferência

Leitura de aprofundamento

As subseções seguintes mostram como as ferramentas de cálculo desenvolvidas neste capítulo aparecem em problemas de estimação e inferência.

O objetivo é apresentar apenas a estrutura matemática dessas aplicações. As propriedades probabilísticas dos estimadores, as condições de regularidade, as distribuições assintóticas e os procedimentos inferenciais serão desenvolvidos nos capítulos específicos do Módulo II. Este bloco pode ser omitido em uma primeira leitura sem comprometer a continuidade imediata do livro.

As aplicações seguintes envolvem gradientes, Hessianas, expansões de Taylor, diferenciação sob o sinal de integração e cálculo matricial. Elas antecipam, em nível matemático, conceitos que serão retomados posteriormente.

7.12.1 Log-verossimilhança e vetor escore

Considere observações independentes

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

provenientes de um mesmo modelo paramétrico com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros e Θ é o espaço paramétrico.

Nessas condições, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.16 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Se um estimador de máxima verossimilhança é um ponto interior do espaço paramétrico e a log-verossimilhança é diferenciável nesse ponto, então deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.17 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Se

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}$$

e

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

então

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \prec \mathbf{0},$$

e o teste da Hessiana fornece uma condição suficiente para que $\hat{\theta}$ seja um máximo local estrito da log-verossimilhança.

Em um ponto arbitrário do espaço paramétrico, a matriz

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta)$$

não precisa ser positiva semidefinida e pode, inclusive, ser indefinida.

Em um ponto estacionário interior que seja máximo local,

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \preceq \mathbf{0},$$

de modo que

$$\mathcal{J}_n(\hat{\theta}) \succeq \mathbf{0}.$$

A informação observada pode ser singular quando, por exemplo:

- há parâmetros localmente não identificados;
- existem redundâncias na parametrização;
- a log-verossimilhança apresenta direções localmente planas.

Máximos na fronteira exigem tratamento separado, pois as condições usuais de ponto estacionário e o teste irrestrito da Hessiana não os caracterizam adequadamente.

Definição 7.18 (Informação de Fisher). Suponha que o vetor escore possua segundo momento finito. A informação de Fisher da amostra é definida por

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathbf{s}_n(\theta) \mathbf{s}_n(\theta)^{\top}].$$

(Casella; Berger, 2002)

Sob condições de regularidade que permitem diferenciar a densidade sob o sinal de integração,

$$E_{\theta} [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais que justificam a relação entre a primeira e a segunda derivadas da log-verossimilhança,

$$\begin{aligned} \mathcal{J}_n(\theta) &= -E_{\theta} [\nabla_{\theta}^2 \ell_n(\theta)] \\ &= E_{\theta} [\mathcal{J}_n(\theta)]. \end{aligned}$$

Assim, em modelos regulares, a informação de Fisher coincide com a esperança da informação observada. Como o escore possui esperança nula nessas condições,

$$\mathcal{J}_n(\theta) = \text{Cov}_{\theta} [\mathbf{s}_n(\theta)].$$

Essas identidades não devem ser utilizadas automaticamente. Sua validade depende das condições de regularidade, incluindo a possibilidade de intercambiar derivação e integração e o comportamento do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_{\theta}^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_{\theta}^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = -\mathbf{s}_n(\theta^{(t)}),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

Essa é a aplicação do método de Newton à equação

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

Quando

$$\mathcal{J}_n(\theta^{(t)}) \succ \mathbf{0},$$

a direção

$$\mathbf{d}^{(t)} = \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)})$$

é uma direção local de aumento da log-verossimilhança, pois

$$\mathbf{s}_n(\theta^{(t)})^\top \mathbf{d}^{(t)} > 0$$

quando o escore é não nulo.

Ainda assim, um passo completo pode não aumentar a log-verossimilhança quando o ponto atual está distante da solução. Em aplicações numéricas, podem ser utilizados controles do comprimento da etapa.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada

$$\mathcal{J}_n(\theta)$$

pela informação de Fisher

$$\mathcal{J}_n(\theta).$$

Sob as condições de regularidade para as quais

$$\mathcal{J}_n(\theta) = E_\theta [\mathcal{J}_n(\theta)],$$

essa substituição pode ser interpretada como a troca da curvatura observada pela curvatura esperada da log-verossimilhança.

Quando

$$\mathcal{J}_n(\theta^{(t)})$$

é invertível, a direção $\mathbf{d}^{(t)}$ é obtida pela solução de

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = \mathbf{s}_n(\theta^{(t)}),$$

seguida da atualização

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Assim, Newton–Raphson utiliza

$$\mathcal{J}_n(\theta),$$

enquanto o método do escore de Fisher utiliza

$$\mathcal{J}_n(\theta).$$

Quando a identidade de informação é válida, a primeira representa a curvatura observada e a segunda sua correspondente curvatura esperada.

As atualizações coincidem quando as duas matrizes são iguais no ponto considerado ou, mais geralmente, quando produzem a mesma solução para a equação que determina a direção da etapa.

7.12.5 Expansão local de uma raiz do escore

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned}\mathbf{0} &= \mathbf{s}_n(\hat{\theta}) \\ &\approx \mathbf{s}_n(\theta_0) + \nabla_{\theta}^2 \ell_n(\theta_0) (\hat{\theta} - \theta_0).\end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n(\theta_0) = -\mathcal{J}_n(\theta_0),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa expressão é uma aproximação local de primeira ordem. A obtenção de uma representação assintótica rigorosa exige controlar o termo restante da expansão e substituir a informação observada por um limite apropriado.

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.12 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q$$

diferenciável no ponto

$$\theta.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A demonstração formal utiliza a aproximação de Taylor de primeira ordem juntamente com resultados probabilísticos sobre convergência em distribuição. Esses resultados serão desenvolvidos no módulo inferencial; neste capítulo interessa principalmente a origem diferencial da matriz

$$\mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta)(\hat{\theta} - \theta).$$

A matriz

$$\mathbf{V}_{\mathbf{g}} = \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}$$

é a matriz de covariâncias da distribuição limite de

$$\sqrt{n} \left[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \right].$$

Por isso, denomina-se

$$\frac{1}{n} \mathbf{V}_{\mathbf{g}}$$

matriz de covariâncias assintótica de

$$\mathbf{g}(\hat{\theta}).$$

Em aplicações, é comum utilizá-la como aproximação da matriz de covariâncias do estimador para amostras grandes. A convergência em distribuição, isoladamente, não garante convergência dos segundos momentos; essa interpretação requer condições adicionais de regularidade.

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância assintótica é

$$\frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_2}{\theta_1} \\ -\frac{1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n} \left(\hat{\theta} - \theta \right) \xrightarrow{d} N_2 \left(\mathbf{0}, \Xi \right),$$

então

$$\sqrt{n} \left(\frac{\hat{\theta}_1}{\hat{\theta}_2} - \frac{\theta_1}{\theta_2} \right)$$

converge em distribuição para uma normal com variância assintótica

$$\nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.25 (Estimação de um vetor de médias). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

Exemplo 7.26 (Critério do modelo linear multivariado). Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere o critério

$$\begin{aligned} Q(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} Q = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Observe que, para Σ fixa e positiva definida, o minimizador em relação a $\mathbf{B}$ não depende de Σ . Isso decorre do fato de que Σ^{-1} é invertível e desaparece da condição de primeira ordem.

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_\mathcal{E} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^\top (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_\mathcal{E}).$$

Se

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_\mathcal{E}.$$

A condição

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo.

Se $\mathbf{X}$ possui posto coluna completo k , a matriz residual pode ser escrita como

$$\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}} = (\mathbf{I}_n - \mathbf{P}_\mathbf{X}) \mathbf{Y},$$

em que

$$\text{posto}(\mathbf{I}_n - \mathbf{P}_\mathbf{X}) = n - k.$$

Consequentemente,

$$\text{posto}(\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}) \leq \min(p, n - k).$$

Assim, uma condição necessária para

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

é

$$n - k \geq p.$$

Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério é ilimitado inferiormente no cone das matrizes positivas definidas. Em particular, pode-se fazer um autovalor de Σ tender a zero em uma direção pertencente ao núcleo de $\mathbf{G}_{\mathcal{E}}$ sem produzir aumento compensatório no termo de traço.

Aqui o modelo foi utilizado apenas como uma aplicação conjunta de gradientes matriciais, log-determinante e diferenciação de funções envolvendo matrizes inversas.

A interpretação probabilística do critério, as propriedades dos estimadores, suas distribuições e a formulação de hipóteses serão desenvolvidas posteriormente nos capítulos de estimação, modelo linear multivariado e inferência.

O bloco de aprofundamento mostrou como as ferramentas de cálculo deste capítulo aparecem em problemas de estimação e inferência:

Tabela 7.2: Relações entre as ferramentas de cálculo e suas aplicações estatísticas.

Ferramenta matemática	Aplicação estatística
Gradiente	Vetor escore
Hessiana	Informação observada
Esperança da curvatura	Informação de Fisher
Expansão de Taylor	Aproximações locais e método delta
Cálculo matricial	Estimação de parâmetros vetoriais e matriciais

Essas relações devem ser entendidas neste capítulo como aplicações das ferramentas matemáticas. Sua interpretação estatística completa será retomada no Módulo II.

7.13 Síntese do capítulo

O capítulo reuniu as ferramentas de cálculo necessárias para estudar funções de vetores e matrizes e para formular problemas posteriores da Estatística Multivariada.

No cálculo diferencial, o gradiente representa a variação de primeira ordem de uma função escalar, a Jacobiana representa a transformação linear local de uma função vetorial e a Hessiana descreve sua curvatura. Essas estruturas sustentam aproximações de Taylor e condições de otimalidade.

A otimização utiliza essas derivadas de formas diferentes. Em problemas sem restrições, pontos estacionários e a definitude da Hessiana permitem caracterizar soluções locais, enquanto a convexidade fornece resultados globais. Em problemas com restrições de igualdade, os multiplicadores de Lagrange incorporam a geometria do conjunto viável. As funções de resíduos mostram como essas ferramentas conduzem às equações normais e aos problemas de mínimos quadrados.

No cálculo matricial, os diferenciais e as identidades de traço permitem trabalhar diretamente com parâmetros matriciais. Derivadas de inversas, determinantes e log-determinantes serão utilizadas em critérios que envolvem matrizes de covariâncias. A vetorização e o produto de Kronecker fornecem uma representação vetorial para transformações entre matrizes.

O cálculo integral completa essa estrutura ao permitir a obtenção de probabilidades, expectativas e densidades marginais. O Teorema da Mudança de Variáveis mostra como o determinante Jacobiano modifica elementos de volume e densidades sob transformações. Transformações afins e elipsoidais conectam essa ideia às formas quadráticas e às matrizes positivas definidas.

As principais relações estabelecidas no capítulo podem ser resumidas da seguinte forma:

Tabela 7.3: Relações entre as ferramentas do cálculo e seus usos posteriores.

Estrutura matemática	Papel nos capítulos seguintes
Derivadas	Aproximação local e otimização
Diferenciais matriciais	Manipulação e estimação de parâmetros matriciais
Integração e Jacobianos	Construção e transformação de distribuições multivariadas

A Tabela 7.4 reúne algumas das identidades de uso recorrente.

Tabela 7.4: Identidades selecionadas de cálculo vetorial e matricial.

Função ou transformação	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Os blocos de aprofundamento desenvolveram ferramentas que não são necessárias para uma primeira leitura do capítulo, entre elas derivadas vetorizadas e parametrização de matrizes simétricas, diferenciação sob o sinal de integração e aplicações do cálculo à estimação e à inferência. Esses resultados poderão ser retomados quando forem necessários nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- interpretar derivadas como aproximações locais;
- utilizar Taylor e a Hessiana em problemas de otimização;
- formular condições de primeira ordem com e sem restrições;
- derivar critérios quadráticos e equações normais;
- utilizar diferenciais e identidades de traço em funções matriciais;
- diferenciar expressões envolvendo inversas, determinantes e log-determinantes;
- utilizar vec, produto de Kronecker e sua identidade de vetorização;
- calcular probabilidades, expectativas e densidades marginais por integração;
- aplicar mudanças de variáveis e interpretar o determinante Jacobiano.

O Capítulo 7 encerra o **Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada**.

Antes do início do Módulo II, os **Exercícios de fixação do Módulo I** retomam de forma integrada os principais conceitos desenvolvidos ao longo dos sete capítulos. Os exercícios articulam representação matricial dos dados, projeções, transformações lineares, formas quadráticas, autovalores e autovetores, SVD, pseudoinversa e cálculo vetorial e matricial em problemas que serão utilizados posteriormente na Estatística Multivariada.

O capítulo seguinte inicia o **Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada** com o estudo das matrizes de covariâncias e correlações. Gradientes, formas quadráticas, transformações lineares, integrais, projeções e produtos matriciais fornecerão

as ferramentas matemáticas para descrever a variabilidade conjunta de vetores aleatórios e sustentar os desenvolvimentos probabilísticos e inferenciais posteriores.

Exercícios de fixação do Módulo I

Os exercícios deste módulo retomam os fundamentos matemáticos desenvolvidos nos capítulos anteriores e os utilizam em problemas que reaparecerão ao longo da Estatística Multivariada.

A lista está dividida em duas partes. Na primeira, os cálculos devem ser realizados sem auxílio computacional. As matrizes foram escolhidas para permitir resultados exatos e enfatizar as relações entre álgebra, geometria e cálculo.

Na segunda parte, o R ou Python será utilizado para estender essas mesmas ideias a conjuntos de dados de maior dimensão. O objetivo não é substituir os cálculos matriciais por funções prontas, mas utilizá-los para analisar matrizes de dados reais e verificar computacionalmente propriedades estudadas no Módulo I.

Parte I — Exercícios sem uso de computador

Exercício 7.1 (Transformação de variáveis em uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 2 & 2 \\ 3 & 0 & 1 \end{bmatrix},$$

em que as linhas representam quatro observações e as colunas representam três variáveis.

Considere também a transformação

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

1. Escreva, para uma observação genérica

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

as duas componentes de

$$\mathbf{y} = \mathbf{A}\mathbf{x}.$$

2. Interprete cada nova componente como uma combinação linear das variáveis originais.
3. Determine a matriz de dados transformada utilizando

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

4. Indique as dimensões de $\mathbf{X}$, $\mathbf{A}$ e $\mathbf{Y}$ e explique por que a transformação reduziu o número de variáveis de três para duas.
5. Determine o posto de $\mathbf{A}$.
6. Determine a dimensão de $\mathcal{N}(\mathbf{A})$ e explique o significado desse resultado em termos de perda de informação.
7. Sabendo apenas $\mathbf{y} = \mathbf{A}\mathbf{x}$, discuta se é possível recuperar unicamente o vetor original $\mathbf{x}$.

Exercício 7.2 (Centralização como projeção). Considere $n = 4$ e defina

$$\mathbf{H}_4 = \mathbf{I}_4 - \frac{1}{4}\mathbf{1}_4\mathbf{1}_4^\top.$$

1. Escreva explicitamente a matriz $\mathbf{H}_4$.
2. Verifique que

$$\mathbf{H}_4^\top = \mathbf{H}_4$$

e

$$\mathbf{H}_4^2 = \mathbf{H}_4.$$

3. Mostre que

$$\mathbf{H}_4\mathbf{1}_4 = \mathbf{0}.$$

4. Aplique $\mathbf{H}_4$ à matriz $\mathbf{X}$ do Exercício 7.1:

$$\mathbf{X}_c = \mathbf{H}_4\mathbf{X}.$$

- Verifique diretamente que

$$\mathbf{1}_4^\top \mathbf{X}_c = \mathbf{0}^\top.$$

- Interprete a igualdade anterior em termos das médias das variáveis.

Exercício 7.3 (Centralização e reescalonamento das variáveis). Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times 3}$$

e a matriz diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix}.$$

- Determine $\mathbf{D}^{-1}$.
- Considere inicialmente uma matriz já centralizada $\mathbf{X}_c$ e defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}^{-1}.$$

Explique o efeito dessa transformação sobre cada uma das três variáveis.

- Explique por que $\mathbf{D}^{-1}$ atua à direita da matriz de dados.
- Compare essa operação com a centralização

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

explicando por que $\mathbf{H}_n$ atua à esquerda enquanto $\mathbf{D}^{-1}$ atua à direita.

- Escreva, em uma única expressão, a transformação que primeiro centraliza $\mathbf{X}$ e depois reescala suas variáveis.
- A centralização e o reescalonamento atuam no mesmo espaço? Justifique utilizando as dimensões de $\mathbf{H}_n$ e $\mathbf{D}^{-1}$.

Exercício 7.4 (Duas matrizes de Gram para os mesmos dados). Considere a matriz centralizada

$$\mathbf{X}_c = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 2 \\ 0 & -2 \end{bmatrix}.$$

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Indique as dimensões das duas matrizes.
3. Qual das duas matrizes contém os produtos internos entre as colunas de $\mathbf{X}_c$?
4. Qual contém os produtos internos entre as linhas de $\mathbf{X}_c$?
5. Determine o posto das duas matrizes.
6. Determine os autovalores positivos de cada matriz.
7. Verifique que os autovalores positivos coincidem.
8. Relacione esse resultado à construção da SVD de uma matriz retangular.

Exercício 7.5 (Projeção, ajuste e resíduos). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

1. Verifique que as colunas de $\mathbf{X}$ são linearmente independentes.
2. Determine

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

3. Verifique que

$$\mathbf{P}_X^\top = \mathbf{P}_X$$

e

$$\mathbf{P}_X^2 = \mathbf{P}_X.$$

4. Calcule

$$\hat{\mathbf{y}} = \mathbf{P}_X \mathbf{y}.$$

5. Determine o vetor de resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

6. Verifique que

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

7. Identifique o subespaço ao qual pertence $\hat{\mathbf{y}}$.

8. Identifique o subespaço ao qual pertence $\mathbf{e}$.

9. Interprete geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

Exercício 7.6 (Um problema de mínimos quadrados por três perspectivas). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

O objetivo é determinar o vetor que minimiza

$$\|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2.$$

Resolva o problema das três formas seguintes.

1. Determine a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$ e obtenha, a partir dela, o vetor ajustado.
2. Resolva as equações normais

$$\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

3. Calcule

$$\mathbf{A}^\top \mathbf{A}$$

e determine os valores singulares de $\mathbf{A}$.

4. Construa uma SVD compacta de $\mathbf{A}$.
5. Construa a pseudoinversa

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$$

e obtenha

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}.$$

6. Compare as soluções obtidas pelas três abordagens.
7. Compare também os vetores ajustados e os resíduos.
8. Explique por que projeções, equações normais e pseudoinversa conduzem ao mesmo problema de aproximação.

Exercício 7.7 (Forma quadrática e direções privilegiadas). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. Calcule $q(\mathbf{x})$ para

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

2. Determine os autovalores de $\mathbf{A}$.
3. Determine uma base ortonormal de autovetores.
4. Calcule a forma quadrática em cada autovetor unitário.
5. Determine

$$\max_{\|\mathbf{x}\|=1} q(\mathbf{x})$$

e

$$\min_{\|\mathbf{x}\|=1} q(\mathbf{x}).$$

6. Relacione os valores encontrados aos autovalores de $\mathbf{A}$.

Exercício 7.8 (Norma euclidiana e norma induzida). Considere

$$\mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

responda:

1. Calcule as normas euclidianas de $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{z}$.
2. Calcule as normas induzidas por $\mathbf{M}$,

$$\|\mathbf{v}\|_{\mathbf{M}} = \sqrt{\mathbf{v}^{\top} \mathbf{M} \mathbf{v}}.$$

3. Calcule a distância euclidiana entre $\mathbf{x}$ e $\mathbf{y}$.
4. Calcule a distância induzida por $\mathbf{M}$ entre os mesmos vetores.
5. Qual coordenada recebe maior peso na geometria induzida por $\mathbf{M}$?
6. Explique por que duas geometrias diferentes podem produzir avaliações diferentes da proximidade entre observações.

Exercício 7.9 (Matrizes particionadas e complemento de Schur). Considere a matriz simétrica

$$\mathbf{M} = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

particionada como

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^\top & \mathbf{D} \end{bmatrix},$$

em que

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{D} = [2].$$

1. Verifique que $\mathbf{A}$ é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Calcule o complemento de Schur de $\mathbf{A}$ em $\mathbf{M}$,

$$\mathbf{S} = \mathbf{D} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B}.$$

4. Verifique que $\mathbf{S} > 0$.
5. Utilize a identidade por blocos

$$\det(\mathbf{M}) = \det(\mathbf{A}) \det(\mathbf{S})$$

para calcular $\det(\mathbf{M})$.

6. Confirme o resultado calculando diretamente o determinante de $\mathbf{M}$.

Exercício 7.10 (Direção que maximiza uma medida de dispersão). Considere

$$\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Para um vetor unitário $\mathbf{a}$, defina

$$D(\mathbf{a}) = \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

1. Determine os autovalores de $\mathbf{S}$.
2. Determine uma base ortonormal de autovetores.
3. Resolva

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

4. Determine a direção que minimiza $D(\mathbf{a})$ sob a mesma restrição.
5. Calcule o valor da forma quadrática nas duas direções.
6. Se $\mathbf{S}$ representasse uma matriz de dispersão de duas variáveis, interprete a direção associada ao maior autovalor.
7. Interprete também a direção associada ao menor autovalor.

Exercício 7.11 (Maximização de uma razão entre duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 12 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Resolva

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}}.$$

1. Mostre, por multiplicadores de Lagrange ou pelo quociente de Rayleigh generalizado, que as direções candidatas satisfazem

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{B}\mathbf{x}.$$

2. Determine os autovalores generalizados.
3. Determine um autovetor associado a cada autovalor generalizado.
4. Normalize os autovetores segundo a geometria de $\mathbf{B}$, impondo

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1.$$

5. Determine o valor máximo do quociente.
6. Determine também o valor mínimo.
7. Verifique que os dois autovetores podem ser escolhidos de modo que

$$\mathbf{x}_1^\top \mathbf{B} \mathbf{x}_2 = 0.$$

8. Compare essa ortogonalidade com a ortogonalidade euclidiana usual.

Exercício 7.12 (Transformação de um problema generalizado). Utilize as matrizes $\mathbf{A}$ e $\mathbf{B}$ do Exercício 7.11.

1. Determine a raiz quadrada principal

$$\mathbf{B}^{1/2}$$

e sua inversa

$$\mathbf{B}^{-1/2}.$$

2. Construa

$$\mathbf{C} = \mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2}.$$

3. Verifique que

$$\mathbf{C} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

- Determine os autovalores de $\mathbf{C}$.
- Compare-os com os autovalores generalizados obtidos no exercício anterior.
- Considere a transformação

$$\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}.$$

Mostre que

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = \mathbf{z}^\top \mathbf{z}.$$

- Mostre que

$$\frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}} = \frac{\mathbf{z}^\top \mathbf{C} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

- Explique por que a transformação converte um problema em geometria induzida por $\mathbf{B}$ em um problema espectral euclidiano.

Exercício 7.13 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

- Calcule

$$\mathbf{A}^\top \mathbf{A}.$$

- Determine os autovalores de $\mathbf{A}^\top \mathbf{A}$.
- Determine os valores singulares positivos de $\mathbf{A}$ em ordem decrescente.
- Determine os vetores singulares à direita correspondentes.
- Utilize

$$\mathbf{u}_j = \frac{\mathbf{A} \mathbf{v}_j}{d_j}$$

para construir os vetores singulares à esquerda.

- Verifique que os vetores obtidos são ortonormais.

7. Construa

$$\mathbf{U}_r, \quad \mathbf{D}_r, \quad \mathbf{V}_r.$$

8. Verifique diretamente que

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

9. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A})$.

10. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A}^\top)$.

Exercício 7.14 (Aproximação de posto reduzido). Utilize a matriz e a SVD do Exercício 7.13.

1. Escreva

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + d_2 \mathbf{u}_2 \mathbf{v}_2^\top.$$

2. Construa a aproximação de posto 1

$$\mathbf{A}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1^\top.$$

3. Determine explicitamente

$$\mathbf{A} - \mathbf{A}_1.$$

4. Calcule

$$\|\mathbf{A} - \mathbf{A}_1\|_F.$$

5. Verifique que, neste caso,

$$\|\mathbf{A} - \mathbf{A}_1\|_F = d_2.$$

6. Calcule

$$\|\mathbf{A}\|_F^2.$$

7. Verifique que

$$\|\mathbf{A}\|_F^2 = d_1^2 + d_2^2.$$

8. Calcule

$$\frac{d_1^2}{d_1^2 + d_2^2}.$$

9. Interprete essa razão como a parcela da magnitude quadrática da matriz preservada pela aproximação de posto 1.

Exercício 7.15 (Gradiente e Hessiana de um critério de mínimos quadrados). Considere

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

1. Desenvolva $Q(\beta)$ como uma expressão quadrática em β .
2. Obtenha

$$\nabla_{\beta} Q(\beta).$$

3. Obtenha

$$\nabla_{\beta}^2 Q(\beta).$$

4. Mostre que, se $\mathbf{X}$ possui posto completo de colunas,

$$\mathbf{X}^{\top} \mathbf{X} \succ \mathbf{0}.$$

5. Conclua que a Hessiana é positiva definida.
6. Mostre que o ponto estacionário é o único minimizador global.
7. Aplique o resultado a

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix},$$

determinando $\hat{\beta}$ exatamente.

8. Compare a solução com aquela obtida geometricamente no Exercício 7.5.

Exercício 7.16 (Multiplicadores de Lagrange e autovalores). Considere uma matriz real simétrica $\mathbf{A}$ e o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

1. Construa a função lagrangiana.
2. Diferencie-a em relação a $\mathbf{x}$.
3. Diferencie-a em relação ao multiplicador de Lagrange.
4. Mostre que as condições de primeira ordem conduzem a uma equação da forma

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}.$$

5. Explique por que o problema de otimização se transforma em um problema de autovalores.
6. Resolva completamente o problema para

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

7. Determine também o mínimo sob a mesma restrição.
8. Compare os resultados com os obtidos no Exercício 7.10.

Exercício 7.17 (Vetorização e produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Adote a convenção de que $\text{vec}(\mathbf{X})$ empilha as colunas de $\mathbf{X}$.

1. Calcule diretamente

$$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{B}.$$

2. Determine

$$\text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{Y}).$$

3. Construa

$$\mathbf{B}^\top \otimes \mathbf{A}.$$

4. Calcule

$$(\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

5. Verifique a identidade

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

6. Compare as dimensões da transformação matricial com as dimensões de sua representação vetorizada.

Exercício 7.18 (Diferenciação de um critério matricial). Considere, para

$$\Sigma \succ \mathbf{0},$$

a função

$$Q(\Sigma) = 2 \log \det(\Sigma) + \text{tr}(\mathbf{G}\Sigma^{-1}),$$

em que

$$\mathbf{G} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Utilize diferenciais para obter

$$dQ.$$

2. Mostre que um ponto estacionário deve satisfazer

$$2\Sigma^{-1} - \Sigma^{-1}\mathbf{G}\Sigma^{-1} = \mathbf{0}.$$

3. Resolva essa equação para Σ .
4. Verifique que a matriz obtida é positiva definida.

Exercício 7.19 (Transformação afim, Jacobiana e alteração de área). Considere

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

1. Calcule $\det(\mathbf{A})$ e mostre que a transformação é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Escreva a transformação inversa

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

4. Determine a matriz Jacobiana da transformação de $\mathbf{x}$ para $\mathbf{y}$.
5. Determine o determinante Jacobiano.
6. Considere a região

$$0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1.$$

Determine as imagens de seus quatro vértices.

7. Descreva geometricamente a região transformada.
8. Determine sua área.
9. Compare a razão entre a área transformada e a área original com

$$|\det(\mathbf{A})|.$$

Exercício 7.20 (Integração e obtenção de densidades marginais). Considere a função conjunta

$$f(x, y) = 2,$$

para

$$0 < x < y < 1,$$

e

$$f(x, y) = 0$$

fora dessa região.

1. Represente geometricamente a região em que $f(x, y) > 0$.
2. Verifique que

$$\int_0^1 \int_0^y 2 \, dx \, dy = 1.$$

3. Obtenha a função marginal de X integrando em relação a y .
4. Obtenha a função marginal de Y integrando em relação a x .
5. Verifique que cada função marginal integra 1 em seu respectivo domínio.
6. Calcule $E(X)$.
7. Calcule $E(Y)$.
8. Explique por que os limites de integração dependem da geometria da região de suporte.

Parte II — Exercícios com uso do R

Nesta parte, utilize preferencialmente operações matriciais do R. Quando uma função pronta reproduzir diretamente um resultado estudado no Módulo I, utilize-a apenas depois da construção matricial, como forma de conferência.

Em comparações envolvendo posto, autovalores teoricamente nulos ou valores singulares numericamente nulos, considere a possibilidade de pequenos erros de arredondamento computacional e utilize uma tolerância numérica adequada.

Exercício 7.21 (Centralização matricial dos dados `USArrests`). Considere as quatro variáveis quantitativas do conjunto de dados `USArrests`.

1. Armazene a matriz de dados em um objeto $\mathbf{X}$.
2. Determine n e p a partir da própria matriz.
3. Construa explicitamente

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

4. Obtenha

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

5. Verifique numericamente que as médias das colunas de $\mathbf{X}_c$ são zero, admitindo apenas diferenças de arredondamento.
6. Verifique numericamente que

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

7. Determine o posto numérico de $\mathbf{H}_n$.
8. Verifique que

$$\mathbf{H}_n \mathbf{1}_n \approx \mathbf{0}.$$

9. Somente ao final, compare $\mathbf{X}_c$ com o resultado produzido por

```
scale(X, center = TRUE, scale = FALSE)
```

10. Explique geometricamente o papel de $\mathbf{H}_n$.

Exercício 7.22 (Matrizes de Gram e seus espectros). Utilize a matriz centralizada $\mathbf{X}_c$ obtida no Exercício 7.21.

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Compare as dimensões das duas matrizes.
3. Determine seus postos numéricos.
4. Calcule os autovalores de ambas.
5. Para identificar os autovalores numericamente positivos, utilize uma tolerância relativa, por exemplo,

$$\lambda_j > 10^{-10} \lambda_{\max}.$$

6. Compare os autovalores positivos de $\mathbf{G}_V$ e $\mathbf{G}_O$.
7. Explique por que uma matriz 4×4 e uma matriz 50×50 contêm o mesmo espectro não nulo.
8. Relacione os resultados aos valores singulares de $\mathbf{X}_c$.

Exercício 7.23 (Construção de novas variáveis por transformação linear). Considere apenas as quatro variáveis quantitativas de `iris`, formando

$$\mathbf{X} \in \mathbb{R}^{150 \times 4}.$$

Defina

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & -1 & 0 & 0 \end{bmatrix}.$$

1. Obtenha

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

2. Escreva explicitamente cada uma das três novas variáveis como combinação das quatro variáveis originais.
3. Verifique as dimensões de $\mathbf{Y}$.
4. Determine o posto de $\mathbf{A}$.
5. Determine a dimensão de $\mathcal{N}(\mathbf{A})$.
6. Discuta se a transformação preserva toda a informação necessária para reconstruir as quatro variáveis originais.
7. Centralize $\mathbf{X}$.
8. Aplique a mesma transformação à matriz centralizada.
9. Verifique as médias das três variáveis transformadas após a centralização.
10. Explique por que uma transformação linear de dados centralizados continua produzindo variáveis com média amostral zero.

Exercício 7.24 (Busca da direção de maior dispersão). Utilize as variáveis quantitativas de `USArrests`.

1. Centralize a matriz de dados e denote o resultado por $\mathbf{X}_c$.
2. Construa

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

3. Obtenha os autovalores e autovetores de $\mathbf{S}$ utilizando `eigen()`.
4. Identifique a direção unitária $\mathbf{a}_1$ associada ao maior autovalor.
5. Calcule

$$\mathbf{a}_1^\top \mathbf{S} \mathbf{a}_1.$$

6. Compare o resultado com o maior autovalor de $\mathbf{S}$.
7. Gere um grande número de vetores aleatórios em $\mathbb{R}^4$ e normalize cada um para norma unitária.

8. Para cada vetor $\mathbf{a}$, calcule

$$\mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

9. Compare o maior valor encontrado entre as direções aleatórias com o maior autovalor de $\mathbf{S}$.
10. Explique o que esse experimento numérico mostra sobre o quociente de Rayleigh.
11. Repita a análise após padronizar as quatro variáveis para variância unitária.
12. Compare a nova direção de máxima dispersão com aquela obtida utilizando as variáveis apenas centralizadas e discuta o efeito da mudança de escala.

Não utilize `prcomp()` neste exercício.

Exercício 7.25 (Projeção e reconstrução a partir de uma direção). Utilize $\mathbf{X}_c$ e a direção $\mathbf{a}_1$ obtidas no Exercício 7.24.

1. Calcule as coordenadas das observações na direção $\mathbf{a}_1$:

$$\mathbf{z}_1 = \mathbf{X}_c \mathbf{a}_1.$$

2. Verifique as dimensões de $\mathbf{z}_1$.
3. Reconstrua a parcela da matriz de dados associada a essa direção:

$$\widehat{\mathbf{X}}_1 = \mathbf{z}_1 \mathbf{a}_1^\top.$$

4. Verifique que $\widehat{\mathbf{X}}_1$ possui posto 1.
5. Calcule

$$\mathbf{E}_1 = \mathbf{X}_c - \widehat{\mathbf{X}}_1.$$

6. Calcule

$$\|\mathbf{X}_c\|_F^2, \quad \|\widehat{\mathbf{X}}_1\|_F^2, \quad \|\mathbf{E}_1\|_F^2.$$

7. Verifique numericamente que

$$\|\mathbf{X}_c\|_F^2 \approx \|\widehat{\mathbf{X}}_1\|_F^2 + \|\mathbf{E}_1\|_F^2.$$

8. Verifique também que

$$\langle \widehat{\mathbf{X}}_1, \mathbf{E}_1 \rangle_F \approx 0.$$

9. Interprete o que foi preservado e o que foi descartado pela projeção.

Exercício 7.26 (SVD e decomposição espectral da matriz de dados). Utilize a matriz centralizada de `USArrests`.

1. Calcule sua SVD utilizando `svd()`.
2. Extraia $\mathbf{U}$, os valores singulares e $\mathbf{V}$.
3. Construa explicitamente a matriz diagonal $\mathbf{D}$.
4. Verifique numericamente que

$$\mathbf{X}_c \approx \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

5. Verifique que

$$\mathbf{X}_c^\top \mathbf{X}_c \approx \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

6. Calcule

```
eigen(t(Xc) %*% Xc)
```

e compare os autovetores obtidos com os vetores singulares à direita.

7. Compare os autovalores de $\mathbf{X}_c^\top \mathbf{X}_c$ com os quadrados dos valores singulares.
8. Explique por que vetores produzidos por `eigen()` e `svd()` podem diferir apenas pelo sinal.
9. Relacione as colunas de $\mathbf{V}$ a direções no espaço das variáveis.

Exercício 7.27 (Aproximações de posto reduzido em uma matriz de dados). Utilize a SVD obtida no Exercício 7.26.

Para

$$k = 1, 2, 3,$$

construa

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Para cada valor de k :

1. determine o posto numérico de $\mathbf{X}_{c,k}$;
2. calcule

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F;$$

3. verifique numericamente que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 \approx \sum_{j=k+1}^r d_j^2;$$

4. calcule

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2};$$

5. interprete essa quantidade em termos da magnitude quadrática preservada pela aproximação;
6. compare os erros para $k = 1$, $k = 2$ e $k = 3$;
7. explique por que o erro não pode aumentar quando k cresce.

Não utilize `prcomp()` para construir as aproximações.

Exercício 7.28 (Mínimos quadrados com duas variáveis respostas). Utilize o conjunto de dados `mtcars`.

Considere como respostas:

- `mpg`;
- `qsec`;

e como variáveis explicativas:

- `intercepto`;
- `wt`;
- `hp`.

Construa

$$\mathbf{Y} \in \mathbb{R}^{n \times 2}$$

e

$$\mathbf{X} \in \mathbb{R}^{n \times 3}.$$

1. Verifique as dimensões das duas matrizes.
2. Verifique que $\mathbf{X}$ possui posto completo de colunas.
3. Calcule

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

4. Determine as dimensões de $\widehat{\mathbf{B}}$.
5. Interprete suas duas colunas.
6. Calcule

$$\widehat{\mathbf{Y}} = \mathbf{X} \widehat{\mathbf{B}}$$

e

$$\mathbf{E} = \mathbf{Y} - \widehat{\mathbf{Y}}.$$

7. Verifique numericamente que

$$\mathbf{X}^\top \mathbf{E} \approx \mathbf{0}.$$

8. Ajuste separadamente, utilizando `lm()`, um modelo para `mpg` e outro para `qsec`.
9. Compare os coeficientes das duas regressões com as colunas de $\widehat{\mathbf{B}}$.

Exercício 7.29 (Posto deficiente e pseudoinversa). Utilize `mtcars` e considere `mpg` como vetor-resposta.

Construa uma matriz de delineamento cujas colunas sejam

$$\mathbf{1}, \quad \text{wt}, \quad 2 \text{ wt}.$$

1. Determine o posto da matriz de delineamento.
2. Compare o posto com o número de colunas.
3. Calcule seus valores singulares.
4. Identifique quais valores singulares devem ser considerados numericamente positivos utilizando uma tolerância adequada.
5. Tente utilizar diretamente

$$(\mathbf{X}^\top \mathbf{X})^{-1}$$

e explique o problema encontrado.

6. Construa manualmente a pseudoinversa de $\mathbf{X}$ a partir de sua SVD, invertendo apenas os valores singulares considerados positivos.
7. Obtenha

$$\hat{\beta}^+ = \mathbf{X}^+ \mathbf{y}.$$

8. Calcule

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}^+.$$

9. Determine um vetor não nulo

$$\mathbf{h} \in \mathcal{N}(\mathbf{X}).$$

10. Para diferentes valores de γ , construa

$$\hat{\beta}(\gamma) = \hat{\beta}^+ + \gamma \mathbf{h}.$$

11. Verifique que todos esses vetores produzem o mesmo vetor ajustado.
12. Compare numericamente

$$\|\hat{\beta}(\gamma)\|$$

para vários valores positivos e negativos de γ .

13. Verifique que a solução fornecida pela pseudoinversa possui a menor norma euclidiana.

14. Relacione a não unicidade dos coeficientes ao núcleo de $\mathbf{X}$.

Exercício 7.30 (Vetorização de um modelo com várias respostas). Retome as matrizes $\mathbf{X}$, $\mathbf{Y}$ e $\widehat{\mathbf{B}}$ do Exercício 7.28.

A relação matricial é

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\mathbf{B}}.$$

1. Construa em R

$$\text{vec}(\widehat{\mathbf{Y}})$$

empilhando as colunas.

2. Construa

$$\text{vec}(\widehat{\mathbf{B}}).$$

3. Construa

$$\mathbf{I}_2 \otimes \mathbf{X}.$$

4. Verifique suas dimensões.

5. Verifique numericamente que

$$\text{vec}(\widehat{\mathbf{Y}}) = (\mathbf{I}_2 \otimes \mathbf{X}) \text{vec}(\widehat{\mathbf{B}}).$$

6. Compare as dimensões dos dois lados da igualdade.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a variar no mesmo sentido, em sentidos opostos ou se apresentam relações lineares de redundância.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, caracterizar relações lineares entre as componentes e representar geometricamente a dispersão conjunta (Johnson; Wichern, 2007).

A matriz de correlações resulta da padronização das covariâncias pelos desvios-padrão das variáveis. Seus elementos são adimensionais e permitem comparar a intensidade e o sentido das associações lineares entre variáveis medidas em diferentes unidades.

O objetivo deste capítulo é desenvolver essas estruturas nos níveis populacional e descritivo dos dados observados. As propriedades inferenciais das estatísticas amostrais serão estudadas no Capítulo 10. A distribuição normal multivariada, apresentada no próximo capítulo, utilizará a matriz de covariâncias para construir um modelo probabilístico para a variabilidade conjunta.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathcal{R} \in \mathbb{R}^{p \times p}$ representa a matriz de correlações populacional;
- $\boldsymbol{\Sigma}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas entre os vetores aleatórios $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias populacionais;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa uma matriz de dados observada, com observações nas linhas e variáveis nas colunas;
- $\bar{\mathbf{x}} \in \mathbb{R}^p$ representa o vetor de médias calculado a partir dos dados observados;
- $\mathbf{H}_n = \mathbf{I}_n - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top$ representa a matriz de centralização;
- $\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$ representa a matriz de dados centralizada;
- $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$ representa a matriz total de somas de quadrados e produtos cruzados;
- $\mathbf{S} \in \mathbb{R}^{p \times p}$ e $\mathbf{R} \in \mathbb{R}^{p \times p}$ representam, respectivamente, as matrizes de covariâncias e

- de correlações calculadas a partir dos dados observados;
- $\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp})$ representa a matriz diagonal das variâncias observadas;
- $\mathbf{S}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas calculada entre dois blocos de variáveis observadas;
- $\mathbf{X}$, $\mathbf{T}$, $\mathbf{S}$ e $\mathbf{R}$ representam, respectivamente, a média amostral, a matriz de somas de quadrados e produtos cruzados centralizados, a matriz de covariâncias amostral e a matriz de correlações amostral consideradas como objetos aleatórios; suas propriedades serão desenvolvidas no Capítulo 10;
- $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ representam as parcelas intragrupos e entre grupos da matriz total de somas de quadrados e produtos cruzados;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam, respectivamente, as somas de quadrados total, intragrupos e entre grupos obtidas pelos traços de $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam essas somas de quadrados consideradas como objetos aleatórios;
- $QM_{\text{intra}} = SQ_{\text{intra}}/(n - G)$ e $QM_{\text{entre}} = SQ_{\text{entre}}/(G - 1)$ representam os quadrados médios intragrupos e entre grupos no caso escalar;
- Σ^+ representa a pseudoinversa de Moore–Penrose de Σ quando a matriz de covariâncias é singular.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, formas quadráticas, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais e pseudoinversa permanecem válidas.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Retomando Definição 1.2, considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com realização $\mathbf{x} \in \mathbb{R}^p$. Quando n realizações são observadas, sua organização em uma matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ segue a representação estabelecida na Definição 1.6.

Suponha inicialmente que $E(|X_j|) < \infty$ para $j = 1, \dots, p$. O **vetor de médias populacional** é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \in \mathbb{R}^p. \quad (8.1)$$

O vetor μ determina a localização média da distribuição no espaço das observações. Subtraindo esse vetor de $\mathbf{X}$, obtém-se o vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu. \quad (8.2)$$

Pela linearidade da esperança,

$$E(\mathbf{X}_c) = E(\mathbf{X}) - \mu = \mathbf{0}.$$

A centralização corresponde a uma translação da distribuição, levando seu vetor de médias à origem. Como estabelecido na Proposição 4.15, a subtração do mesmo vetor de todos os pontos preserva as distâncias entre pares de realizações. Portanto, a centralização altera a localização, mas não a geometria relativa da nuvem de pontos.

A centralização da matriz de dados observada será retomada posteriormente neste capítulo, quando forem construídas a matriz de produtos cruzados e a matriz de covariâncias observada.

8.1.2 Momentos de segunda ordem

O estudo das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante também a existência dos primeiros momentos. Além disso, para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz aplicada a variáveis aleatórias de segundo momento finito fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

Portanto, os produtos cruzados necessários à construção das covariâncias possuem esperança finita.

A matriz de segundos momentos em relação à origem é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top) \in \mathbb{R}^{p \times p}.$$

O produto $\mathbf{X}\mathbf{X}^\top$ é o produto externo definido na Definição 1.14. Seus elementos são

$$[\mathbf{X}\mathbf{X}^\top]_{jk} = X_j X_k,$$

de modo que

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1 X_2) & \cdots & E(X_1 X_p) \\ E(X_2 X_1) & E(X_2^2) & \cdots & E(X_2 X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_p X_1) & E(X_p X_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Seus elementos dependem, portanto, da localização da distribuição e de sua variabilidade conjunta.

Para descrever a dispersão em torno do vetor de médias, utiliza-se o segundo momento central:

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Expandindo o produto e utilizando $E(\mathbf{X}) = \mu$,

$$\begin{aligned} \Sigma &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top \\ &= \mathbf{M}_2 - \mu\mu^\top. \end{aligned} \tag{8.3}$$

A identidade Equação 8.3 é a versão matricial da relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está, portanto, no ponto de referência: $\mathbf{M}_2$ descreve segundos momentos em relação à origem, enquanto Σ descreve a variabilidade em torno da média.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com segundos momentos finitos e médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se $E(X^2) < \infty$ e $E(Y^2) < \infty$, a **covariância populacional** entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva indica predominância de desvios de mesmo sinal;
- uma covariância negativa indica predominância de desvios de sinais opostos;
- uma covariância nula indica ausência de associação linear registrada pela covariância.

A Figura 8.1 apresenta configurações com covariâncias positiva, aproximadamente nula e negativa.




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

Na primeira configuração, a nuvem de pontos tende a se alongar em uma direção crescente; na terceira, em uma direção decrescente. A configuração central não apresenta orientação linear predominante. O valor da covariância depende também das escalas das variáveis e, por isso, seu módulo não fornece isoladamente uma medida comparável de intensidade entre diferentes pares de variáveis.

Expandindo o produto dos desvios,

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.\end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.4)$$

A expressão Equação 8.4 relaciona a covariância ao momento conjunto $E(XY)$ e aos primeiros momentos das duas variáveis.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.5)$$

A identidade Equação 8.5 mostra que translações não alteram a covariância. Mudanças de escala multiplicam a covariância pelo produto dos fatores aplicados às duas variáveis. Quando somente um desses fatores é negativo, o sinal da covariância é invertido.

Essa dependência das unidades impede a comparação direta entre covariâncias associadas a pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, por exemplo, sua covariância com outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.6)$$

O limite Equação 8.6 será utilizado posteriormente para mostrar que a correlação pertence ao intervalo $[-1, 1]$.

Covariância nula e independência

Covariância nula não implica independência em uma distribuição geral. A covariância

registra associação linear de segunda ordem, e relações não lineares podem produzir covariância igual a zero.

Exemplo 8.1 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X , possui média zero e segundo momento finito.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Como ε é independente de X ,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Para calcular a covariância entre X e Y , utiliza-se

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Como $Y = X^2 + \varepsilon$,

$$\begin{aligned} E(XY) &= E[X(X^2 + \varepsilon)] \\ &= E(X^3) + E(X\varepsilon) \\ &= 0. \end{aligned}$$

Além disso,

$$E(X)E(Y) = 0,$$

pois $E(X) = 0$. Portanto,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0.$$

Apesar da covariância nula, X e Y não são independentes. Para verificar isso, considere a esperança condicional de Y dado $X = x$. Como

$$\begin{aligned} E(Y \mid X = x) &= E(X^2 + \varepsilon \mid X = x) \\ &= x^2 + E(\varepsilon \mid X = x). \end{aligned}$$

Como ε é independente de X ,

$$E(\varepsilon \mid X = x) = E(\varepsilon) = 0.$$

Portanto,

$$E(Y \mid X = x) = x^2.$$

Assim, a média condicional de Y depende do valor de X . Se X e Y fossem independentes, a distribuição condicional de Y dado $X = x$ seria a mesma distribuição marginal de Y e, conseqüentemente,

$$E(Y \mid X = x) = E(Y),$$

não dependendo de x . Logo, X e Y são dependentes, apesar de apresentarem covariância nula.

A Figura 8.2 ilustra essa relação.

A configuração parabólica evidencia uma dependência que não produz orientação linear global. O exemplo delimita a informação fornecida pela covariância e mostra por que o valor zero não deve ser interpretado, sem hipóteses adicionais, como independência.

As variâncias das componentes e as covariâncias entre todos os pares de componentes podem ser reunidas em uma única matriz.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

Definição 8.2 (Matriz de covariâncias populacional). Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com vetor de médias μ e segundos momentos finitos. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top] \in \mathbb{R}^{p \times p}. \quad (8.7)$$




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

O elemento situado na linha j e na coluna k de Σ é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.8)$$

Os elementos da diagonal principal são as variâncias,

$$\sigma_{jj} = \text{Var}(X_j),$$

e os elementos fora da diagonal são as covariâncias entre componentes distintos.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

tem-se

$$\sigma_{jk} = \sigma_{kj},$$

e Σ é simétrica. Para p componentes, existem p variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas, totalizando

$$\frac{p(p+1)}{2}$$

elementos distintos.

As unidades dos elementos dependem das variáveis envolvidas. Se X_j é medida em uma unidade u_j , então

$$\sigma_{jj}$$

é expressa em u_j^2 . Para $j \neq k$,

$$\sigma_{jk}$$

é expressa em $u_j u_k$. Essa dependência das unidades motiva a construção posterior da matriz de correlações.

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ possui a forma

$$Y = \mathbf{a}^\top \mathbf{X}, \quad \mathbf{a} \in \mathbb{R}^p.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação e define uma direção no espaço das variáveis. A combinação linear, já utilizada no Módulo 1, adquire aqui uma interpretação probabilística: sua média e sua variância são determinadas por μ e Σ .

Proposição 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \tag{8.9}$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}, \tag{8.10}$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \tag{8.11}$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \mu.$$

Além disso,

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \mu = \mathbf{a}^\top (\mathbf{X} - \mu).$$

Consequentemente,

$$\begin{aligned}\text{Var}(\mathbf{a}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top \mathbf{a}] \\ &= \mathbf{a}^\top \Sigma \mathbf{a}.\end{aligned}$$

De modo análogo,

$$\begin{aligned}\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top \mathbf{b}] \\ &= \mathbf{a}^\top \Sigma \mathbf{b}.\end{aligned}$$

□

A expressão Equação 8.10 mostra que a matriz de covariâncias determina a variabilidade de todas as combinações lineares das componentes. A quantidade

$$\mathbf{a}^\top \Sigma \mathbf{a}$$

é uma forma quadrática no sentido de Definição 2.23. Quando $\|\mathbf{a}\| = 1$, ela representa a variância da projeção de $\mathbf{X}$ sobre a direção unitária $\mathbf{a}$.

Essa relação constitui a ligação entre a matriz de covariâncias e a geometria desenvolvida no Módulo 1: diferentes direções podem apresentar diferentes níveis de dispersão.

Exemplo 8.2 (Matriz de covariâncias com três variáveis). Considere

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

As variâncias das três componentes são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9, \quad \text{Var}(X_3) = 1,$$

e as covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1,5,$$

$$\text{Cov}(X_1, X_3) = -0,8,$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere a combinação linear

$$Y = X_1 + 0,5X_2 - X_3,$$

com vetor de coeficientes

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação 8.10,

$$\begin{aligned} \text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\ &= \begin{bmatrix} 1 & 0,5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix} \\ &= 10,35. \end{aligned}$$

A variância da combinação depende das variâncias individuais, das covariâncias e dos coeficientes utilizados. A covariância negativa entre X_1 e X_3 , por exemplo, contribui positivamente para $\text{Var}(Y)$ porque os coeficientes dessas duas componentes possuem sinais opostos.

8.2.3 Propriedades estruturais e singularidade

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. A classificação de positividade de matrizes foi estabelecida na Definição 2.24; aqui ela adquire uma interpretação probabilística direta, pois a forma quadrática associada a Σ representa uma variância (Eaton, 2007).

Proposição 8.2 (Caracterização estrutural das matrizes de covariâncias). *Uma matriz $\mathbf{C} \in \mathbb{R}^{p \times p}$ é matriz de covariâncias de algum vetor aleatório com segundos momentos finitos se, e somente se,*

$$\mathbf{C} = \mathbf{C}^\top$$

e

$$\mathbf{C} \succeq \mathbf{0}.$$

Consequentemente, toda matriz de covariâncias possui elementos diagonais não negativos, autovalores não negativos e submatrizes principais positivas semidefinidas.

Comprovação. Se

$$\mathbf{C} = \text{Cov}(\mathbf{X}),$$

a simetria decorre de

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j).$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{C} \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Logo, $\mathbf{C}$ é positiva semidefinida.

Reciprocamente, suponha que $\mathbf{C}$ seja real, simétrica e positiva semidefinida. Pelo Teorema 5.4 e pela raiz quadrada principal definida na Definição 5.9, existe uma matriz simétrica positiva semidefinida $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}, \quad j = 1, \dots, p.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{X} = \mathbf{C}^{1/2} \mathbf{U}.$$

Como

$$E(\mathbf{U}) = \mathbf{0},$$

tem-se

$$E(\mathbf{X}) = \mathbf{C}^{1/2} E(\mathbf{U}) = \mathbf{0}.$$

Além disso,

$$E(\mathbf{U}\mathbf{U}^\top) = \mathbf{I}_p.$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= E(\mathbf{X}\mathbf{X}^\top) \\ &= E(\mathbf{C}^{1/2} \mathbf{U}\mathbf{U}^\top \mathbf{C}^{1/2}) \\ &= \mathbf{C}^{1/2} E(\mathbf{U}\mathbf{U}^\top) \mathbf{C}^{1/2} \\ &= \mathbf{C}^{1/2} \mathbf{I}_p \mathbf{C}^{1/2} \\ &= \mathbf{C}. \end{aligned}$$

Portanto, toda matriz real simétrica positiva semidefinida pode ocorrer como matriz de covariâncias. $\square$

Essa construção estabelece apenas a existência de um vetor aleatório com matriz de covariâncias $\mathbf{C}$ e não exige uma família de distribuições específica.

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

também deve ser positiva semidefinida. Logo,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

o que equivale a

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

Esse resultado recupera, no nível matricial, o limite apresentado na Equação 8.6.

A simetria, isoladamente, não é suficiente para caracterizar uma matriz de covariâncias.

Exemplo 8.3 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica. Entretanto, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2. \end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de uma combinação linear, o que é impossível. A matriz é, portanto, simétrica, mas não positiva semidefinida.

Quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$, a matriz Σ é positiva definida. Pela Equação 8.10, isso significa que toda combinação linear não trivial das componentes possui variância positiva.

A situação muda quando Σ é singular. Nesse caso, aparecerá a expressão **quase certamente**. Seja U uma variável aleatória definida em um espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e seja $c \in \mathbb{R}$. Escrever

$$U = c \quad \text{quase certamente}$$

significa que

$$P(\{\omega \in \Omega : U(\omega) = c\}) = P(U = c) = 1.$$

Equivalentemente, a igualdade pode falhar apenas em um conjunto de resultados de probabilidade zero.

Proposição 8.3 (Caracterização da singularidade da matriz de covariâncias). *Seja Σ a matriz de covariâncias de $\mathbf{X} \in \mathbb{R}^p$. As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

Comprovação. Como Σ é simétrica e positiva semidefinida, o Teorema 5.4 garante uma decomposição com autovalores não negativos. A matriz é singular se, e somente se, pelo menos um desses autovalores é zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ no núcleo de Σ e, portanto,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ .

Pela Equação 8.10,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}),$$

o que estabelece a equivalência entre as duas condições seguintes.

Uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser zero. Portanto,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

□

A última condição da Proposição 8.3 também pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade de Σ corresponde à existência de uma relação afim exata e não trivial entre as componentes do vetor aleatório.

Em termos geométricos, os vetores pertencentes a

$$\mathcal{N}(\Sigma)$$

determinam direções de variância nula. Como Σ é simétrica, a relação entre núcleo e espaço coluna desenvolvida no Módulo 1 permite escrever

$$\mathcal{N}(\Sigma)^\perp = \mathcal{C}(\Sigma).$$

Consequentemente,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma) \quad \text{quase certamente.}$$

Se

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade do vetor centralizado está restrita a um subespaço de dimensão r . O vetor original está, portanto, restrito quase certamente ao subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

A matriz de covariâncias também pode ser utilizada para descrever conjuntamente dois vetores aleatórios distintos. Essa extensão produz matrizes retangulares de covariâncias cruzadas e permite representar as relações lineares entre dois blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam segundos momentos finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}. \quad (8.12)$$

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para $j = 1, \dots, p$ e $k = 1, \dots, q$. Portanto,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A orientação da matriz depende da ordem dos vetores. Invertendo essa ordem,

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (8.13)$$

Assim,

$$\Sigma_{XY} \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} \in \mathbb{R}^{q \times p}.$$

Mesmo quando $p = q$, não se tem em geral

$$\Sigma_{XY} = \Sigma_{YX},$$

pois uma matriz de covariâncias cruzadas não precisa ser simétrica.

Proposição 8.4 (Covariância entre combinações de dois vetores). *Para quaisquer vetores fixos*

$$\mathbf{a} \in \mathbb{R}^p \quad e \quad \mathbf{b} \in \mathbb{R}^q,$$

tem-se

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (8.14)$$

Comprovação. As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} & \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\ &= E\left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b}\right] \\ &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \end{aligned}$$

□

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

se, e somente se,

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para todos os vetores $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$. Nesse caso, nenhuma combinação linear do primeiro bloco possui covariância não nula com uma combinação linear do segundo.

A condição

$$\Sigma_{XY} = \mathbf{0}$$

não implica, em uma distribuição geral, independência entre os vetores. Essa relação será retomada no Capítulo 9 sob a distribuição normal multivariada.

Os dois vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{V} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix},$$

e sua matriz de covariâncias pode ser representada por blocos, conforme a estrutura de matrizes particionadas definida na Definição 2.25:

$$\Sigma_V = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.15)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor, enquanto os blocos fora da diagonal descrevem as covariâncias entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa condição restringe conjuntamente seus blocos. Em particular, Σ_{XY} não pode ser especificada arbitrariamente depois de fixadas Σ_{XX} e Σ_{YY} .

8.3.1.1 Complemento de Schur e dispersão residual

O complemento de Schur já foi definido na Definição 2.26. Aplicado à matriz de covariâncias particionada, ele recebe uma interpretação estatística de segunda ordem.

Suponha que

$$\Sigma_{YY} \succ \mathbf{0}.$$

O complemento de Schur de Σ_{YY} em Σ_V é

$$\Sigma_{XX \cdot Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}. \quad (8.16)$$

Pelo resultado de positividade do complemento de Schur no Teorema 2.9,

$$\Sigma_{XX \cdot Y} \succeq \mathbf{0}.$$

A expressão também pode ser interpretada diretamente como uma covariância residual.

Proposição 8.5 (Complemento de Schur e covariância residual). *Defina os vetores centralizados*

$$\mathbf{X}_c = \mathbf{X} - \mu_X$$

e

$$\mathbf{Y}_c = \mathbf{Y} - \mu_Y.$$

Para qualquer matriz

$$\mathbf{L} \in \mathbb{R}^{p \times q},$$

considere o resíduo linear

$$\mathbf{R}_L = \mathbf{X}_c - \mathbf{L}\mathbf{Y}_c.$$

Se $\Sigma_{YY} \succ \mathbf{0}$, a escolha

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1}$$

satisfaz

$$\text{Cov}(\mathbf{R}_{L^*}) = \Sigma_{XX.Y}.$$

Além disso, para qualquer $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_L) - \Sigma_{XX.Y} \succeq \mathbf{0}.$$

Portanto, $\mathbf{L}^*$ minimiza a covariância residual segundo a ordem de Loewner.

Comprovação. Para uma matriz arbitrária $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_L) = \Sigma_{XX} - \mathbf{L}\Sigma_{YX} - \Sigma_{XY}\mathbf{L}^\top + \mathbf{L}\Sigma_{YY}\mathbf{L}^\top.$$

Substituindo

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1},$$

a expressão pode ser reorganizada como

$$\begin{aligned}\text{Cov}(\mathbf{R}_{\mathbf{L}}) &= \Sigma_{XX.Y} \\ &\quad + (\mathbf{L} - \mathbf{L}^*) \Sigma_{YY} (\mathbf{L} - \mathbf{L}^*)^\top.\end{aligned}$$

Como Σ_{YY} é positiva definida,

$$(\mathbf{L} - \mathbf{L}^*) \Sigma_{YY} (\mathbf{L} - \mathbf{L}^*)^\top \succeq \mathbf{0}.$$

A diferença entre a covariância residual correspondente a qualquer $\mathbf{L}$ e aquela obtida com $\mathbf{L}^*$ é, portanto, positiva semidefinida. $\square$

Essa interpretação depende apenas dos segundos momentos e não exige normalidade. Sob normalidade conjunta, o mesmo complemento de Schur aparecerá no Capítulo 9 como matriz de covariâncias da distribuição condicional de um bloco dado o outro.

Exemplo 8.4 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix}.$$

Para as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2,$$

os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação 8.14,

$$\begin{aligned} \text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\ &= [1 \quad -2] \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\ &= -7. \end{aligned}$$

A covariância entre U e V resulta conjuntamente das covariâncias entre todas as componentes que participam das duas combinações lineares.

8.3.2 Transformações afins da média e da covariância

As transformações afins foram definidas na Definição 4.7. No contexto probabilístico, interessa determinar como elas modificam a média e a matriz de covariâncias.

Considere

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r.$$

Proposição 8.6 (Média e covariância sob transformação afim). *Se $\mathbf{X}$ possui média μ_X e matriz de covariâncias Σ_{XX} , então*

$$E(\mathbf{U}) = \mathbf{A}\mu_X + \mathbf{c} \tag{8.17}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \quad (8.18)$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{A}\mathbf{X} + \mathbf{c}) = \mathbf{A}\mu_X + \mathbf{c}.$$

O vetor transformado centralizado é

$$\begin{aligned} \mathbf{U} - E(\mathbf{U}) &= \mathbf{A}\mathbf{X} + \mathbf{c} - \mathbf{A}\mu_X - \mathbf{c} \\ &= \mathbf{A}(\mathbf{X} - \mu_X). \end{aligned}$$

Portanto,

$$\begin{aligned} \text{Cov}(\mathbf{U}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \end{aligned}$$

□

A ausência do vetor $\mathbf{c}$ na Equação 8.18 confirma que translações alteram a localização, mas não a matriz de covariâncias.

Quando

$$r = 1 \quad \text{e} \quad \mathbf{A} = \mathbf{a}^\top,$$

a expressão reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a},$$

recuperando Equação 8.10.

Se $\mathbf{A}$ é diagonal,

$$\mathbf{A} = \text{diag}(a_1, \dots, a_p),$$

então

$$\text{Cov}(a_j X_j, a_k X_k) = a_j a_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(a_j X_j) = a_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal no sentido de Definição 2.18,

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Como $\mathbf{Q}^\top = \mathbf{Q}^{-1}$, essa transformação produz uma matriz semelhante a Σ_{XX} e preserva seus autovalores. A interpretação estatística dessa propriedade será retomada na geometria da covariância.

Exemplo 8.5 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e

$$\mathbf{U} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As componentes transformadas são

$$U_1 = X_1 + X_2$$

e

$$U_2 = X_1 - X_2.$$

Pela expressão Equação 8.18,

$$\begin{aligned}
\text{Cov}(\mathbf{U}) &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top \\
&= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\
&= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}.
\end{aligned}$$

Logo,

$$\text{Var}(U_1) = 17, \quad \text{Var}(U_2) = 9$$

e

$$\text{Cov}(U_1, U_2) = -5.$$

A transformação modifica simultaneamente as variâncias das componentes e a covariância entre elas.

As covariâncias cruzadas também se transformam de maneira compatível.

Proposição 8.7 (Covariância cruzada sob transformações afins). *Considere*

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{G}\mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{G} \in \mathbb{R}^{s \times q}.$$

Então,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}\Sigma_{XY}\mathbf{G}^\top. \quad (8.19)$$

Comprovação. Após a centralização,

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}(\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{G}(\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E \left[\mathbf{A}(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{G}^\top \right] \\ &= \mathbf{A} \Sigma_{XY} \mathbf{G}^\top. \end{aligned}$$

□

As expressões Equação 8.18 e Equação 8.19 mostram que a matriz de covariâncias responde de maneira sistemática às transformações lineares. A padronização das componentes constitui um caso particular dessa estrutura.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar as escalas marginais, suponha que

$$\sigma_{jj} = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias populacionais por

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}). \quad (8.20)$$

Como todas as variâncias são positivas,

$$\mathbf{D}_\Sigma \succ \mathbf{0}$$

e existem as matrizes diagonais

$$\mathbf{D}_{\Sigma}^{1/2} = \text{diag} \left(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}} \right)$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Definição 8.4 (Vetor aleatório padronizado). O vetor aleatório marginalmente padronizado correspondente a $\mathbf{X}$ é

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu). \quad (8.21)$$

Sua componente j é

$$Z_j = \frac{X_j - \mu_j}{\sqrt{\sigma_{jj}}}.$$

Assim,

$$E(Z_j) = 0$$

e

$$\text{Var}(Z_j) = 1.$$

Em forma vetorial,

$$E(\mathbf{Z}) = \mathbf{0}.$$

Aplicando Equação 8.18,

$$\text{Cov}(\mathbf{Z}) = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Definição 8.5 (Matriz de correlações populacional). Se todas as componentes de $\mathbf{X}$ possuem variâncias positivas, sua **matriz de correlações populacional** é

$$\mathcal{R} = \text{Cov}(\mathbf{Z}) = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}. \quad (8.22)$$

O símbolo $\mathcal{R}$ é reservado à matriz populacional. Posteriormente, $\mathbf{R}$ representará a matriz de correlações amostral, enquanto $\mathbf{R}$ representará seu valor calculado a partir de uma amostra observada.

A matriz $\mathcal{R}$ possui a forma

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sqrt{\sigma_{jj}\sigma_{kk}}}. \quad (8.23)$$

Equivalentemente,

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

A correlação é adimensional porque o numerador e o denominador de Equação 8.23 possuem as mesmas unidades.

A relação entre covariâncias e correlações pode ser invertida:

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}. \quad (8.24)$$

Portanto, Σ pode ser decomposta em dois elementos:

- $\mathbf{D}_\Sigma$ registra as variâncias e, conseqüentemente, as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear após a remoção dessas escalas.

A matriz de correlações isoladamente não permite recuperar as variâncias originais.

Exemplo 8.6 (Matriz de correlações obtida por uma transformação de padronização). Considere um vetor aleatório

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com vetor de médias μ e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix}.$$

Os desvios-padrão populacionais são

$$\sqrt{\sigma_{11}} = 4 \quad \text{e} \quad \sqrt{\sigma_{22}} = 5.$$

Portanto,

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 16 & 0 \\ 0 & 25 \end{bmatrix}$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix}.$$

Considere a transformação de padronização

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \boldsymbol{\mu}).$$

Ela pode ser escrita como a transformação afim

$$\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

com

$$\mathbf{A} = \mathbf{D}_{\Sigma}^{-1/2}$$

e

$$\mathbf{c} = -\mathbf{D}_{\Sigma}^{-1/2} \boldsymbol{\mu}.$$

Utilizando Proposição [8.6](#),

$$\text{Cov}(\mathbf{Z}) = \mathbf{A}\Sigma\mathbf{A}^{\top}.$$

Como $\mathbf{A}$ é diagonal e simétrica,

$$\begin{aligned}
\text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.
\end{aligned}$$

Essa é precisamente a matriz de correlações populacional,

$$\mathcal{R} = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.$$

De fato,

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \frac{12}{\sqrt{16 \cdot 25}} = \frac{12}{20} = 0,6.$$

O exemplo mostra duas formas equivalentes de chegar ao mesmo resultado. Pela transformação do vetor,

$$\text{padronizar } \mathbf{X} \implies \text{Cov}(\mathbf{Z}).$$

Equivalentemente, pode-se transformar diretamente a matriz de covariâncias:

$$\Sigma \implies \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Em ambas as perspectivas, as variâncias tornam-se unitárias e a covariância entre as componentes padronizadas passa a coincidir com sua correlação.

8.4.2 Propriedades, escala e independência

Proposição 8.8 (Caracterização das matrizes de correlações). *Uma matriz*

$$\mathbf{C} \in \mathbb{R}^{p \times p}$$

é matriz de correlações de algum vetor aleatório com variâncias marginais positivas se, e somente se,

$$\mathbf{C} = \mathbf{C}^{\top},$$

$$\mathbf{C} \succeq \mathbf{0}$$

e

$$c_{jj} = 1, \quad j = 1, \dots, p.$$

Consequentemente, toda matriz de correlações possui:

1. elementos no intervalo $[-1, 1]$;
2. autovalores reais e não negativos;
3. traço igual a p .

Comprovação. Se $\mathbf{C} = \mathcal{R}$ é uma matriz de correlações, então

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Como Σ é simétrica,

$$\mathcal{R}^{\top} = \mathcal{R}.$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^{\top} \mathcal{R} \mathbf{a} &= \left(\mathbf{D}_{\Sigma}^{-1/2} \mathbf{a} \right)^{\top} \Sigma \left(\mathbf{D}_{\Sigma}^{-1/2} \mathbf{a} \right) \\ &\geq 0, \end{aligned}$$

de modo que

$$\mathcal{R} \succeq \mathbf{0}.$$

A diagonal é unitária porque

$$\rho_{jj} = \frac{\sigma_{jj}}{\sqrt{\sigma_{jj}\sigma_{jj}}} = 1.$$

Reciprocamente, suponha que $\mathbf{C}$ seja simétrica, positiva semidefinida e possua diagonal unitária. Pela raiz quadrada principal definida na Definição 5.9, existe $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{Z} = \mathbf{C}^{1/2} \mathbf{U}.$$

Tem-se

$$\text{Cov}(\mathbf{Z}) = \mathbf{C}^{1/2} \mathbf{I}_p \mathbf{C}^{1/2} = \mathbf{C}.$$

Como a diagonal de $\mathbf{C}$ é unitária, todas as componentes de $\mathbf{Z}$ possuem variância igual a um. Logo, sua matriz de covariâncias coincide com sua matriz de correlações, e $\mathbf{C}$ é uma matriz de correlações válida.

Pela desigualdade de Cauchy–Schwarz,

$$|c_{jk}| \leq \sqrt{c_{jj}c_{kk}} = 1.$$

Como $\mathbf{C}$ é simétrica e positiva semidefinida, seus autovalores são reais e não negativos. Finalmente,

$$\text{tr}(\mathbf{C}) = \sum_{j=1}^p c_{jj} = p.$$

□

Se Σ possui variâncias marginais positivas, então $\mathbf{D}_\Sigma^{-1/2}$ é invertível e a padronização preserva a definição positiva. Assim,

$$\mathcal{R} \succ \mathbf{0} \iff \Sigma \succ \mathbf{0}.$$

Os valores extremos da correlação correspondem a relações lineares exatas entre as variáveis padronizadas. Para $j \neq k$,

$$\rho_{jk} = 1 \iff Z_k = Z_j \quad \text{quase certamente,}$$

enquanto

$$\rho_{jk} = -1 \iff Z_k = -Z_j \quad \text{quase certamente.}$$

Portanto, uma correlação de módulo igual a 1 implica uma relação linear exata entre as duas variáveis e, conseqüentemente, a singularidade da matriz de covariâncias do par correspondente.

Além disso, não basta que cada correlação, considerada isoladamente, pertença ao intervalo $[-1, 1]$ para que uma matriz seja uma matriz de correlações válida; a matriz completa também deve ser positiva semidefinida.

Exemplo 8.7 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0,9 & 0,9 \\ 0,9 & 1 & -0,9 \\ 0,9 & -0,9 & 1 \end{bmatrix}.$$

Todos os elementos pertencem ao intervalo $[-1, 1]$, a matriz é simétrica e sua diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2,888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Logo, $\mathbf{A}$ não é uma matriz de correlações.

O exemplo mostra que as correlações entre pares devem ser compatíveis com uma única estrutura conjunta positiva semidefinida.

Duas componentes X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como suas variâncias são positivas,

$$\rho_{jk} = 0 \iff \sigma_{jk} = 0.$$

Essa condição não implica independência em uma distribuição geral, conforme ilustrado no Exemplo 8.1.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

e, portanto,

$$\text{Cov}(X_j, X_k) = 0.$$

Assim,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca depende de hipóteses adicionais.

Uma matriz de correlações diagonal necessariamente é

$$\mathcal{R} = \mathbf{I}_p.$$

Nesse caso, todas as componentes são duas a duas não correlacionadas. Essa propriedade não garante, por si só, independência conjunta. A relação especial entre ausência de correlação e independência sob normalidade conjunta será estabelecida no Capítulo 9.

Considere agora uma mudança de localização e escala aplicada separadamente às componentes:

$$Y_j = c_j X_j + d_j, \quad c_j \neq 0.$$

Tem-se

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk},$$

enquanto

$$\text{Var}(Y_j) = c_j^2 \sigma_{jj}.$$

Consequentemente,

$$\text{Corr}(Y_j, Y_k) = \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \quad (8.25)$$

Se $c_j > 0$ e $c_k > 0$,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Portanto, translações e mudanças positivas de unidade não alteram a correlação. A multiplicação de uma variável por uma constante negativa inverte o sinal de suas correlações, sem alterar seus módulos.

Exemplo 8.8 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.2:

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

A matriz das variâncias marginais é

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de modo que

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.22,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2} \\ &= \begin{bmatrix} 1 & 0,25 & -0,4 \\ 0,25 & 1 & 0 \\ -0,4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1,5}{\sqrt{4 \cdot 9}} = 0,25,$$

enquanto

$$\rho_{13} = \frac{-0,8}{\sqrt{4 \cdot 1}} = -0,4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

tem-se

$$|\rho_{13}| > |\rho_{12}|.$$

A covariância entre X_1 e X_2 possui maior módulo nas unidades originais, mas a associação linear padronizada entre X_1 e X_3 é mais intensa. A comparação evidencia a diferença entre a informação fornecida por covariâncias e por correlações.

A matriz de covariâncias preserva as variâncias e as unidades originais das componentes. A matriz de correlações descreve a mesma estrutura de segunda ordem após a padronização marginal, atribuindo variância unitária a todas as componentes. Essa mudança de escala pode alterar a geometria da dispersão e será considerada na interpretação espectral das duas matrizes.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais e elipsoide de covariância

A expressão Equação 8.10 mostra que a matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa quantidade representa a dispersão ao longo da direção unitária $\mathbf{a}$. A interpretação espectral das formas quadráticas foi desenvolvida no Capítulo 5. Aplicando o Teorema 5.4 à matriz simétrica positiva semidefinida Σ ,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top, \quad (8.26)$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j \geq 0.$$

A transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.27)$$

expressa o vetor centralizado nas coordenadas da base de autovetores. Pela regra de transformação da covariância,

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \Lambda. \quad (8.28)$$

Portanto,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Cov}(Y_j, Y_k) = 0, \quad j \neq k.$$

Os autovetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. O autovalor λ_j quantifica a variância ao longo do eixo $\mathbf{q}_j$.

Se

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0,$$

o resultado sobre os extremos do quociente de Rayleigh no Teorema 5.5 fornece

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.29)$$

Os valores extremos são alcançados nos autovetores correspondentes. Assim, a decomposição espectral identifica direções ortogonais nas quais as covariâncias desaparecem e as variâncias são dadas diretamente pelos autovalores.

Neste capítulo, essa decomposição é utilizada somente para descrever a geometria da dispersão. A seleção de eixos espectrais para construir uma representação de dimensão reduzida pertence à formulação da Análise de Componentes Principais.

Exemplo 8.9 (Obtenção dos eixos de maior e menor variabilidade). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Queremos determinar a direção unitária

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

na qual a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

apresenta a maior variância possível.

Pela expressão Equação 8.10,

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto, o problema é

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Esse é precisamente o tipo de problema de otimização com restrição estudado no Módulo 1. Como maximizar uma função equivale a minimizar seu negativo, a condição necessária de Lagrange estabelecida no Teorema 7.6 aplica-se também a este problema. Considere

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \Sigma \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1).$$

Como Σ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \Sigma \mathbf{a}) = 2\Sigma \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é, portanto,

$$2\Sigma \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0},$$

ou

$$\Sigma \mathbf{a} = \eta \mathbf{a}. \quad (8.30)$$

Assim, as direções estacionárias do problema são autovetores de Σ , e os multiplicadores de Lagrange correspondentes são seus autovalores.

Para determiná-los,

$$\det(\Sigma - \eta \mathbf{I}_2) = 0.$$

Logo,

$$\begin{aligned} \det \begin{bmatrix} 4-\eta & 2 \\ 2 & 4-\eta \end{bmatrix} &= (4-\eta)^2 - 4 \\ &= \eta^2 - 8\eta + 12 \\ &= (\eta - 6)(\eta - 2). \end{aligned}$$

Os autovalores são, portanto,

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2.$$

Para $\lambda_1 = 6$,

$$(\Sigma - 6\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = a_2.$$

Impondo a restrição de norma unitária,

$$a_1^2 + a_2^2 = 1,$$

podemos escolher

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 2$,

$$(\Sigma - 2\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = -a_2,$$

e podemos escolher

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo resultado dos extremos do quociente de Rayleigh no Teorema 5.5,

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_1 = 6,$$

alcançado na direção $\mathbf{q}_1$, enquanto

$$\min_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_2 = 2,$$

alcançado na direção $\mathbf{q}_2$.

Consequentemente,

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 6$$

e

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 2.$$

Reunindo os autovetores em

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

a transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu)$$

produz

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

O cálculo mostra concretamente a conexão entre **variância de uma combinação linear, otimização restrita e decomposição espectral**: os autovetores da matriz de covariâncias surgem como as direções estacionárias da variância sob a restrição de norma unitária, e os autovalores fornecem as variâncias nessas direções.

Neste ponto, o objetivo é somente compreender a geometria da matriz de covariâncias. A utilização dessas direções para construir uma técnica de redução de dimensionalidade será desenvolvida posteriormente na Análise de Componentes Principais.

Quando Σ é diagonal, os eixos espectrais coincidem com os eixos coordenados. No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \tag{8.31}$$

tem-se, para qualquer vetor unitário $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2.$$

A condição Equação 8.31 descreve uma estrutura de segunda ordem isotrópica: a variância é a mesma em todas as direções. Essa condição, isoladamente, não implica que a distribuição de $\mathbf{X}$ seja esfericamente simétrica.

Suponha agora que

$$\Sigma \succ \mathbf{0}.$$

Para $c > 0$, considere

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.32)$$

A interpretação das superfícies de nível de formas quadráticas positivas definidas foi estabelecida no Capítulo 5. Neste caso, utilizando Equação 8.26 e definindo

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

a condição que define $\mathcal{E}_c$ torna-se

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.33)$$

Portanto:

- o centro é μ ;
- os eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo associado a $\mathbf{q}_j$ possui comprimento $c\sqrt{\lambda_j}$.

Assim, autovalores maiores correspondem a maior extensão da dispersão na direção associada.

A Figura 8.3 mostra essa geometria no caso bidimensional.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias determina, assim, uma geometria de segunda ordem para a dispersão conjunta.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido somente por μ e Σ . Sem uma hipótese adicional sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma probabilidade específica nem interpretá-lo como região de confiança. A interpretação probabilística dessas superfícies será desenvolvida no Capítulo 9 para a distribuição normal multivariada.

Quando Σ é singular, a variabilidade está restrita ao subespaço




Figura 8.3: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

$$\mathcal{C}(\Sigma).$$

A raiz quadrada principal definida na Definição 5.9 permite representar o elipsoide degenerado por

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}, \quad (8.34)$$

em que

$$r = \text{posto}(\Sigma) < p.$$

Esse conjunto está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

e possui r semieixos não nulos, com comprimentos $c\sqrt{\lambda_j}$ para os autovalores positivos. A pseudoinversa será utilizada mais adiante para expressar a mesma geometria no contexto da distância de Mahalanobis.

8.5.2 Variância total, variância generalizada e volume

Uma matriz de covariâncias contém toda a estrutura de segunda ordem do vetor aleatório. Algumas funções escalares de Σ resumem aspectos específicos dessa dispersão, mas nenhuma delas substitui a matriz completa.

Definição 8.6 (Variância total). A **variância total** de $\mathbf{X} \in \mathbb{R}^p$ é

$$\text{VT}(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.35)$$

Pela definição de traço na Definição 2.9,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.36)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.37)$$

A variância total também possui uma interpretação em termos de esperança matemática. Mais geralmente, seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$ um vetor fixo. Então,

$$E \left[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a}) \right] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}). \quad (8.38)$$

De fato,

$$\mathbf{X} - \mathbf{a} = (\mathbf{X} - \mu) + (\mu - \mathbf{a}),$$

e, ao expandir a forma quadrática, os termos cruzados possuem esperança nula porque

$$E(\mathbf{X} - \mu) = \mathbf{0}.$$

Além disso,

$$E \left[(\mathbf{X} - \mu)^\top \mathbf{A} (\mathbf{X} - \mu) \right] = \text{tr}(\mathbf{A}\Sigma).$$

Tomando

$$\mathbf{A} = \mathbf{I}_p \quad \text{e} \quad \mathbf{a} = \mu,$$

obtém-se

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \text{tr}(\Sigma). \quad (8.39)$$

Portanto, a variância total é o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu vetor de médias.

Mais geralmente, tomando $\mathbf{A} = \mathbf{I}_p$,

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] = \text{tr}(\Sigma) + \|\mu - \mathbf{a}\|^2. \quad (8.40)$$

Essa expressão mostra que μ minimiza o afastamento quadrático médio:

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] \geq E \left[\|\mathbf{X} - \mu\|^2 \right].$$

Como

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j,$$

segue também que

$$E[\|\mathbf{X} - \mu\|^2] = \sum_{j=1}^p \lambda_j.$$

Assim, a mesma quantidade pode ser interpretada como soma das variâncias marginais, soma das variâncias nos eixos espectrais ou afastamento euclidiano quadrático médio em relação ao centro.

Definição 8.7 (Variância média). A **variância média** é

$$\text{VM}(\mathbf{X}) = \frac{1}{p} \text{tr}(\Sigma) = \frac{1}{p} \sum_{j=1}^p \lambda_j.$$

A variância total e a variância média dependem das escalas das componentes. Quando as variáveis possuem unidades distintas, sua interpretação requer cautela.

Outra medida utiliza o determinante da matriz de covariâncias.

Definição 8.8 (Variância generalizada). A **variância generalizada** de $\mathbf{X}$ é

$$\text{VG}(\mathbf{X}) = \det(\Sigma). \quad (8.41)$$

Pelas propriedades do determinante e pela decomposição espectral,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.42)$$

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se pelo menos um autovalor é zero,

$$\det(\Sigma) = 0,$$

mesmo que exista variabilidade nas demais direções. Nesse caso, o valor zero indica que a dispersão ocupa um subespaço de dimensão inferior a p ; não indica ausência de variabilidade.

A variância generalizada não deve ser confundida com o volume do elipsoide de covariância. A relação entre as duas quantidades envolve a raiz quadrada do determinante (Johnson; Wichern, 2007).

Proposição 8.9 (Volume do elipsoide de covariância). *Se $\Sigma \succ \mathbf{0}$, o volume p -dimensional do elipsoide $\mathcal{E}_c$ definido na Equação 8.32 é*

$$\text{Vol}_p(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.43)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

Comprovação. O elipsoide é a imagem da bola

$$\mathcal{B}_c = \{\mathbf{u} \in \mathbb{R}^p : \|\mathbf{u}\| \leq c\}$$

pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{u}.$$

A translação não altera o volume. Pelo Proposição 4.9, a transformação linear multiplica volumes por

$$|\det(\Sigma^{1/2})| = \det(\Sigma)^{1/2}.$$

Como

$$\text{Vol}_p(\mathcal{B}_c) = \kappa_p c^p,$$

obtem-se Equação 8.43. □

Portanto,

$$\det(\Sigma)^{1/2}$$

é o fator associado à escala de volume da dispersão, enquanto

$$\det(\Sigma)$$

é a variância generalizada.

Exemplo 8.10 (Variância total e variância generalizada). Considere

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = \text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16$$

e

$$\det(\Sigma_2) = 7.$$

A primeira configuração distribui a variabilidade igualmente entre os dois eixos. A segunda concentra maior variabilidade em uma direção e menor variabilidade na outra. A igualdade das variâncias totais não implica, portanto, igualdade da geometria da dispersão.

As unidades também diferem entre essas medidas. Se as componentes possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 \cdots u_p^2,$$

enquanto

$$\det(\Sigma)^{1/2}$$

possui unidade

$$u_1 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

Considere agora uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela expressão Equação 8.18,

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.$$

Consequentemente,

$$\det(\Sigma_{YY}) = \det(\mathbf{A})^2 \det(\Sigma_{XX}). \quad (8.44)$$

Para a escala de volume,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.45)$$

Essa expressão é compatível com o fator de alteração de volume desenvolvido na Proposição 4.9.

Quando $\mathbf{A}$ é ortogonal, $|\det(\mathbf{A})| = 1$ e a transformação preserva os autovalores de Σ . Consequentemente, preserva a variância total, a variância generalizada e os comprimentos dos semieixos do elipsoide, alterando somente sua orientação no sistema de coordenadas.

A forma quadrática que define o elipsoide fornece também uma medida de afastamento adaptada à estrutura de covariâncias. Essa medida é a distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana utiliza a mesma geometria em todas as direções. Em dados multivariados, entretanto, um deslocamento pode representar um afastamento pequeno em uma direção de grande variabilidade e um afastamento expressivo em outra direção de pequena variabilidade.

A distância de Mahalanobis incorpora essa estrutura por meio da matriz de covariâncias. No caso univariado, ela reduz o afastamento $|x - \mu|$ à sua escala natural,

$$\frac{|x - \mu|}{\sigma}.$$

Considere

$$\Sigma \succ \mathbf{0}.$$

Definição 8.9 (Distância de Mahalanobis). A **distância de Mahalanobis** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação a Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.46)$$

Em particular, a distância de $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.47)$$

8.6.1 Interpretação geométrica e espectral

O quadrado da distância de Mahalanobis de $\mathbf{x}$ ao vetor de médias é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.48)$$

Como $\Sigma^{-1} \succ \mathbf{0}$, ela define o produto interno induzido apresentado na Definição 3.16 e a norma correspondente de Definição 3.17. Assim, Equação 8.46 é uma distância métrica, sem necessidade de repetir aqui a demonstração das propriedades métricas desenvolvidas no Módulo 1.

Quando

$$\Sigma = \mathbf{I}_p,$$

a distância de Mahalanobis coincide com a distância euclidiana. Quando $p = 1$,

$$d_M(x, \mu) = \frac{|x - \mu|}{\sigma}.$$

A medida é adimensional, pois a inversa da matriz de covariâncias compensa as unidades presentes no vetor de diferenças.

A interpretação espectral decorre diretamente de Equação 8.26. Se

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

então

$$d_M^2(\mathbf{x}, \mu) = \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \quad (8.49)$$

Essa expressão mostra como a distância de Mahalanobis incorpora a geometria da dispersão. Cada componente u_j representa o deslocamento de $\mathbf{x} - \mu$ na direção do autovetor correspondente, enquanto λ_j é a variância nessa direção.

Cada deslocamento é, portanto, ponderado pelo inverso da variância na direção correspondente. Um mesmo deslocamento geométrico recebe menor peso em uma direção de grande variabilidade e maior peso em uma direção de pequena variabilidade.

Exemplo 8.11 (Afastamentos em direções com variâncias distintas). Considere dois eixos espectrais com

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Um afastamento de magnitude 2 ao longo do primeiro eixo produz

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

O mesmo afastamento ao longo do segundo produz

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro, mas o segundo apresenta maior distância de Mahalanobis porque se encontra em uma direção com menor dispersão populacional.

As superfícies de igual distância,

$$d_M(\mathbf{x}, \mu) = c,$$

são exatamente as fronteiras dos elipsoides definidos na Equação 8.32. Isso reforça a interpretação geométrica da distância de Mahalanobis: pontos pertencentes à mesma superfície elipsoidal apresentam o mesmo afastamento em relação ao centro quando a estrutura de covariâncias é considerada.

A Figura 8.4 compara dois deslocamentos com a mesma distância euclidiana ao centro, mas orientados segundo eixos de dispersão distintos.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A medida compara o deslocamento com a quantidade de variabilidade disponível na direção em que ele ocorre.

8.6.2 Branqueamento e esferização

Uma forma alternativa de compreender a geometria associada à matriz de covariâncias consiste em transformar as coordenadas de modo que a variabilidade resultante seja a mesma em todas as direções.

Seja $\mathbf{X}$ um vetor aleatório com vetor de médias μ e matriz de covariâncias $\Sigma \succ \mathbf{0}$. Uma transformação linear da forma

$$\mathbf{Z} = \mathbf{W}(\mathbf{X} - \mu)$$

é denominada **branqueamento** (*whitening*) quando a matriz $\mathbf{W}$ é escolhida de modo que

$$\text{Cov}(\mathbf{Z}) = \mathbf{W}\Sigma\mathbf{W}^\top = \mathbf{I}_p.$$

Assim, as componentes do vetor branqueado possuem variância unitária e covariâncias nulas entre si. O termo **esferização** enfatiza a interpretação geométrica da mesma transformação: os elipsoides associados à estrutura de covariâncias são transformados em esferas.




Figura 8.4: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

Essa interpretação refere-se à estrutura de segunda ordem do vetor aleatório, representada pela matriz de covariâncias. Em geral, o branqueamento não implica que toda a distribuição do vetor transformado seja esfericamente simétrica.

A raiz quadrada inversa de uma matriz positiva definida foi construída no Capítulo 5 a partir da raiz quadrada principal dada na Definição 5.9. Uma escolha para a matriz de branqueamento é

$$\mathbf{W} = \Sigma^{-1/2},$$

pois

$$\Sigma^{-1/2} \Sigma \Sigma^{-1/2} = \mathbf{I}_p.$$

Essa escolha é denominada **branqueamento simétrico**. Ela remove simultaneamente as diferenças de variância e as covariâncias entre as componentes. Para um ponto $\mathbf{x}$, a transformação correspondente é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu). \quad (8.50)$$

Para o vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

tem-se

$$E(\mathbf{Z}) = \mathbf{0} \quad \text{e} \quad \text{Cov}(\mathbf{Z}) = \mathbf{I}_p. \quad (8.51)$$

A transformação de branqueamento também permite interpretar diretamente a distância de Mahalanobis. De Equação 8.50,

$$\begin{aligned} \|\mathbf{z}\|^2 &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Logo,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.52)$$

A distância de Mahalanobis é, portanto, a distância euclidiana após a centralização e o branqueamento.

A esperança da distância quadrática de Mahalanobis também depende apenas da matriz de covariâncias. Como

$$d_M^2(\mathbf{X}, \mu) = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu),$$

a expressão Equação 8.38, com

$$\mathbf{A} = \Sigma^{-1},$$

fornece

$$\begin{aligned} E[d_M^2(\mathbf{X}, \mu)] &= \text{tr}(\Sigma^{-1}\Sigma) \\ &= \text{tr}(\mathbf{I}_p) \\ &= p. \end{aligned} \tag{8.53}$$

Esse resultado utiliza apenas a existência de μ e $\Sigma \succ \mathbf{0}$; não requer normalidade. No Capítulo 9, a hipótese de normalidade multivariada permitirá caracterizar não apenas essa esperança, mas a distribuição completa da distância quadrática de Mahalanobis.

Exemplo 8.12 (Branqueamento a partir da decomposição espectral). Retome a matriz de covariâncias do Exemplo 8.9,

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Sua decomposição espectral é

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

Utilizando a raiz quadrada inversa desenvolvida no Módulo 1,

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top,$$

em que

$$\Lambda^{-1/2} = \begin{bmatrix} 1/\sqrt{6} & 0 \\ 0 & 1/\sqrt{2} \end{bmatrix}.$$

Defina

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu).$$

Então,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \mathbf{Q}\Lambda\mathbf{Q}^\top \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\mathbf{I}_2\mathbf{Q}^\top \\ &= \mathbf{I}_2. \end{aligned}$$

A transformação pode ser compreendida em três etapas:

$$\mathbf{X} - \mu \xrightarrow{\mathbf{Q}^\top} \text{coordenadas nos eixos espectrais}$$

$$\xrightarrow{\Lambda^{-1/2}} \text{reescalonamento para variância unitária}$$

$$\xrightarrow{\mathbf{Q}} \mathbf{Z}.$$

O primeiro passo expressa o vetor na base de autovetores de Σ , na qual a matriz de covariâncias é diagonal. O segundo divide cada coordenada por $\sqrt{\lambda_j}$, tornando todas as variâncias iguais a 1. O terceiro retorna ao sistema original de coordenadas por meio da transformação ortogonal $\mathbf{Q}$.

Considere agora um ponto cuja diferença em relação ao centro é

$$\mathbf{x} - \mu = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Suas coordenadas espectrais são

$$\mathbf{Q}^\top (\mathbf{x} - \mu) = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

Pela expressão Equação 8.49,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= \frac{(\sqrt{2})^2}{6} + \frac{(\sqrt{2})^2}{2} \\ &= \frac{2}{6} + \frac{2}{2} \\ &= \frac{4}{3}. \end{aligned}$$

Por outro lado,

$$\left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|^2 = \frac{4}{3}.$$

Assim, o exemplo verifica concretamente a identidade

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|.$$

A decomposição espectral, a raiz matricial, o branqueamento e a distância de Mahalanobis aparecem, portanto, como partes de uma mesma construção geométrica.

O branqueamento não é único. De fato, se $\mathbf{Q}_0$ é uma matriz ortogonal, então

$$\mathbf{W} = \mathbf{Q}_0 \Sigma^{-1/2}$$

também satisfaz

$$\mathbf{W} \Sigma \mathbf{W}^\top = \mathbf{I}_p.$$

Portanto, diferentes transformações podem produzir vetores com matriz de covariâncias igual à identidade. Essas versões diferem por uma transformação ortogonal e, conseqüentemente, preservam as distâncias euclidianas no espaço branqueado.

A padronização marginal e o branqueamento devem ser distinguidos. Pela expressão Equação 8.22, a padronização marginal produz

$$\text{Cov} \left(\mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu) \right) = \mathcal{R}.$$

Assim, a padronização marginal torna as variâncias iguais a 1, mas a matriz resultante pode apresentar correlações não nulas fora da diagonal. O branqueamento, por sua vez, utiliza a estrutura completa da matriz de covariâncias e produz

$$\text{Cov} (\mathbf{Z}) = \mathbf{I}_p.$$

Se

$$\mathbf{z}_D = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{x} - \mu),$$

a relação

$$\Sigma = \mathbf{D}_{\Sigma}^{1/2} \mathcal{R} \mathbf{D}_{\Sigma}^{1/2}$$

implica

$$d_M^2(\mathbf{x}, \mu) = \mathbf{z}_D^{\top} \mathcal{R}^{-1} \mathbf{z}_D. \quad (8.54)$$

Assim, a padronização marginal remove as escalas individuais, enquanto $\mathcal{R}^{-1}$ incorpora a associação linear remanescente. Somente quando

$$\mathcal{R} = \mathbf{I}_p$$

a distância de Mahalanobis coincide com a distância euclidiana entre as coordenadas marginalmente padronizadas.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são objetos populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão conjunta podem ser representadas por quantidades calculadas diretamente a partir das observações.

Nesta seção,

$$\bar{\mathbf{x}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}$$

representam valores obtidos de uma matriz de dados específica. Quando as linhas dessa matriz forem consideradas realizações de uma amostra aleatória, esses valores corresponderão a realizações das estatísticas

$$\bar{\mathbf{X}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}.$$

As propriedades dessas estatísticas como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Centralização, SQPC e matriz de covariâncias observada

Considere $n \geq 2$ observações de p variáveis organizadas, conforme Definição 1.6, em

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p$$

representa a i -ésima observação.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \in \mathbb{R}^p, \quad (8.55)$$

em que

$$\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n.$$

A matriz de dados centralizada é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.56)$$

Cada linha de $\mathbf{X}_c$ é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e suas colunas satisfazem

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.57)$$

Retomando a matriz de centralização utilizada no Capítulo 4,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

tem-se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.58)$$

A operação remove a localização das colunas sem alterar as diferenças entre as observações, conforme a propriedade estabelecida na Proposição 4.15.

Definição 8.10 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SQPC, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Equivalentemente,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.59)$$

A sigla **SQPC** significa **Somas de Quadrados e Produtos Cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*. O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k).$$

Quando $j = k$, t_{jj} é a soma dos quadrados dos desvios da variável j . Quando $j \neq k$, t_{jk} é a soma dos produtos cruzados entre as variáveis j e k .

Como

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram das colunas centralizadas no sentido de Definição 3.18. Assim, pelas propriedades estabelecidas na Proposição 3.9,

$$\mathbf{T} = \mathbf{T}^\top,$$

$$\mathbf{T} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

A centralização impõe

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top,$$

de modo que as colunas de $\mathbf{X}_c$ pertencem ao subespaço ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (8.60)$$

A matriz $\mathbf{T}$ registra a dispersão sem uma normalização pelo número de observações.

Definição 8.11 (Matriz de covariâncias observada). A **matriz de covariâncias observada** é

$$\mathbf{S} = \frac{1}{n - 1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n - 1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n - 1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.61)$$

Seu elemento (j, k) é

$$s_{jk} = \frac{1}{n - 1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k). \quad (8.62)$$

Os elementos diagonais são as variâncias calculadas para as colunas,

$$s_{jj} = \frac{1}{n - 1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

e os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas.

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$,

$$\mathbf{S} = \mathbf{S}^\top, \quad \mathbf{S} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

Portanto,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1). \quad (8.63)$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

Essa singularidade decorre da dimensão dos dados centralizados. Suas consequências para estimação e regularização serão tratadas no Capítulo 10.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{S} \mathbf{a} &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \end{aligned} \quad (8.64)$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas determinada por $\mathbf{a}$. Portanto, Equação 8.64 é a contraparte descritiva de Equação 8.10.

O divisor $n - 1$ é utilizado aqui como convenção para a matriz de covariâncias observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será estabelecida no Capítulo 10.

8.7.2 Matriz de correlações e covariâncias cruzadas observadas

Suponha que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias observadas por

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}). \quad (8.65)$$

Definição 8.12 (Matriz de correlações observada). A **matriz de correlações observada** é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \quad (8.66)$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.67)$$

A matriz $\mathbf{R}$ é simétrica, positiva semidefinida e possui diagonal unitária. Como $\mathbf{D}_S^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Em particular,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}.$$

A relação inversa é

$$\mathbf{S} = \mathbf{D}_S^{1/2} \mathbf{R} \mathbf{D}_S^{1/2}. \quad (8.68)$$

Defina agora a matriz das colunas centralizadas e padronizadas,

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2} \in \mathbb{R}^{n \times p}. \quad (8.69)$$

Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}} &= \frac{1}{n-1} \mathbf{D}_S^{-1/2} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_S^{-1/2} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}. \quad (8.70)$$

A expressão Equação 8.70 mostra que $\mathbf{R}$ é, a menos do fator $1/(n-1)$, uma matriz de Gram das colunas padronizadas.

Exemplo 8.13 (Da matriz de dados às matrizes de covariâncias e correlações). Considere quatro observações de duas variáveis organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}.$$

Aqui,

$$n = 4 \quad \text{e} \quad p = 2.$$

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{4} \mathbf{X}^\top \mathbf{1}_4 = \begin{bmatrix} 2,5 \\ 2,5 \end{bmatrix}.$$

Portanto, a matriz centralizada é

$$\begin{aligned} \mathbf{X}_c &= \mathbf{X} - \mathbf{1}_4 \bar{\mathbf{x}}^\top \\ &= \begin{bmatrix} -1,5 & -0,5 \\ -0,5 & -1,5 \\ 0,5 & 1,5 \\ 1,5 & 0,5 \end{bmatrix}. \end{aligned}$$

A matriz total de somas de quadrados e produtos cruzados é

$$\begin{aligned}\mathbf{T} &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}.\end{aligned}$$

Os elementos diagonais são as somas dos quadrados dos desvios de cada variável. O elemento fora da diagonal é a soma dos produtos cruzados.

Como

$$n - 1 = 3,$$

a matriz de covariâncias observada é

$$\begin{aligned}\mathbf{S} &= \frac{1}{3} \mathbf{T} \\ &= \begin{bmatrix} 5/3 & 1 \\ 1 & 5/3 \end{bmatrix}.\end{aligned}$$

Assim,

$$s_{11} = s_{22} = \frac{5}{3}$$

e

$$s_{12} = 1.$$

A matriz diagonal das variâncias observadas é

$$\mathbf{D}_S = \begin{bmatrix} 5/3 & 0 \\ 0 & 5/3 \end{bmatrix}.$$

Como as duas variâncias são iguais,

$$\mathbf{D}_S^{-1/2} = \sqrt{\frac{3}{5}} \mathbf{I}_2.$$

Logo,

$$\begin{aligned}
\mathbf{R} &= \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2} \\
&= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.
\end{aligned}$$

Também podemos obter diretamente a correlação entre as duas colunas:

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{1}{\sqrt{(5/3)(5/3)}} = \frac{3}{5} = 0,6.$$

O exemplo resume a cadeia de construção descritiva desenvolvida nesta seção:

$$\mathbf{X} \longrightarrow \bar{\mathbf{x}} \longrightarrow \mathbf{X}_c \longrightarrow \mathbf{T} \longrightarrow \mathbf{S} \longrightarrow \mathbf{R}.$$

Nesse ponto, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ são valores calculados a partir da matriz de dados observada. Sua interpretação como realizações de estatísticas amostrais e suas propriedades inferenciais serão desenvolvidas no Capítulo 10.

Se $\mathbf{x}_{\text{pad},j}$ representa a coluna j de $\mathbf{X}_{\text{pad}}$, então

$$\|\mathbf{x}_{\text{pad},j}\|^2 = n - 1.$$

Consequentemente,

$$r_{jk} = \frac{\mathbf{x}_{\text{pad},j}^\top \mathbf{x}_{\text{pad},k}}{\|\mathbf{x}_{\text{pad},j}\| \|\mathbf{x}_{\text{pad},k}\|}. \quad (8.71)$$

Assim, a correlação observada entre duas variáveis é o cosseno do ângulo entre suas colunas centralizadas e padronizadas no espaço das observações. Essa interpretação utiliza diretamente a geometria de produtos internos desenvolvida no Módulo 1.

A representação descritiva também se estende a dois blocos de variáveis. Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais. Se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y},$$

define-se:

Definição 8.13 (Matriz de covariâncias cruzadas observada). A **matriz de covariâncias cruzadas observada** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y} \in \mathbb{R}^{p \times q}. \quad (8.72)$$

Sua orientação satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.73)$$

Para

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância observada entre as combinações

$$\mathbf{u} = \mathbf{X}\mathbf{a}$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}$$

é

$$s_{uv} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (8.74)$$

A expressão Equação 8.74 é a contraparte descritiva de Equação 8.14.

Se as duas matrizes forem concatenadas,

$$\begin{bmatrix} \mathbf{X} & \mathbf{Y} \end{bmatrix},$$

a matriz de covariâncias observada correspondente possui a estrutura

$$\begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \quad (8.75)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto de variáveis, enquanto os blocos fora da diagonal registram as covariâncias entre os dois conjuntos.

A matriz $\mathbf{T}$ descreve a dispersão conjunta de todas as observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão admite uma decomposição adicional.

8.8 Decomposição da dispersão por grupos

Considere as n observações distribuídas em G grupos não vazios. O grupo g contém n_g observações, com

$$n_1 + \cdots + n_G = n.$$

Represente a observação i do grupo g por

$$\mathbf{x}_{ig} \in \mathbb{R}^p, \quad i = 1, \dots, n_g, \quad g = 1, \dots, G.$$

O vetor de médias do grupo g é

$$\bar{\mathbf{x}}_g = \frac{1}{n_g} \sum_{i=1}^{n_g} \mathbf{x}_{ig}. \quad (8.76)$$

A média total satisfaz

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{g=1}^G \sum_{i=1}^{n_g} \mathbf{x}_{ig} = \frac{1}{n} \sum_{g=1}^G n_g \bar{\mathbf{x}}_g. \quad (8.77)$$

A dispersão total das observações em torno da média geral pode ser separada em duas fontes:

- **dispersão intragrupos:** afastamentos das observações em relação à média do grupo ao qual pertencem;

- **dispersão entre grupos:** afastamentos das médias dos grupos em relação à média total.

Essa decomposição distingue, portanto, a variabilidade existente **dentro dos grupos** daquela associada às **diferenças entre seus centros**. Em várias técnicas multivariadas, essa distinção será fundamental para avaliar se os grupos apresentam centros suficientemente separados em relação à variabilidade existente internamente.

Geometricamente, para cada observação, o deslocamento em relação à média total pode ser percorrido em duas etapas: primeiro, da observação até a média de seu grupo e, depois, da média do grupo até a média total. Assim,

$$\mathbf{x}_{ig} - \bar{\mathbf{x}} = (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) + (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}). \quad (8.78)$$

A Figura 8.5 ilustra essas duas componentes. Os afastamentos das observações em relação aos respectivos centros representam a dispersão intragrupos, enquanto os afastamentos dos centros dos grupos em relação à média total representam a dispersão entre grupos.

8.8.1 Dispersão total, intragrupos e entre grupos

A matriz total é

$$\mathbf{T} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}) (\mathbf{x}_{ig} - \bar{\mathbf{x}})^\top. \quad (8.79)$$

Definição 8.14 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)^\top \in \mathbb{R}^{p \times p}. \quad (8.80)$$

Cada termo mede o afastamento de uma observação em relação ao centro de seu próprio grupo.

Definição 8.15 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top \in \mathbb{R}^{p \times p}. \quad (8.81)$$

A ponderação por n_g registra o número de observações representadas por cada média de grupo. Assim, um mesmo afastamento $\bar{\mathbf{x}}_g - \bar{\mathbf{x}}$ contribui mais para a dispersão entre grupos quando corresponde a um grupo com maior número de observações.




Figura 8.5: Decomposição geométrica da dispersão em componentes intragrupos e entre grupos.

Proposição 8.10 (Decomposição da dispersão total). *Para qualquer partição das n observações em G grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.82)$$

Comprovação. Pela decomposição vetorial apresentada na Equação 8.78,

$$\mathbf{x}_{ig} - \bar{\mathbf{x}} = (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) + (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}).$$

Ao formar o produto externo e somar sobre as observações, surgem duas parcelas quadráticas e dois termos cruzados. Para cada grupo,

$$\sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem. A soma das primeiras parcelas produz $\mathbf{T}_{\text{intra}}$, enquanto

$$\sum_{i=1}^{n_g} (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top = n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top.$$

Somando sobre os grupos, obtém-se

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

□

Exemplo 8.14 (Decomposição da dispersão em dois grupos). Considere quatro observações de duas variáveis, distribuídas em dois grupos:

Grupo	X_1	X_2
1	1	1
1	3	1
2	3	5
2	5	5

Assim,

$$n_1 = n_2 = 2, \quad n = 4, \quad G = 2.$$

As médias dos grupos são

$$\bar{\mathbf{x}}_1 = \frac{1}{2} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right] = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{2} \left[\begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

A média total é

$$\begin{aligned} \bar{\mathbf{x}} &= \frac{1}{4} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix}. \end{aligned}$$

Podemos agora calcular separadamente as três matrizes da decomposição.

Dispersão intragrupos.

No primeiro grupo,

$$\mathbf{x}_{11} - \bar{\mathbf{x}}_1 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{21} - \bar{\mathbf{x}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua contribuição para a dispersão intragrupos é

$$\begin{aligned} \mathbf{T}_{\text{intra},1} &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} -1 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

No segundo grupo,

$$\mathbf{x}_{12} - \bar{\mathbf{x}}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{22} - \bar{\mathbf{x}}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

de modo que

$$\mathbf{T}_{\text{intra},2} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{T}_{\text{intra}} &= \mathbf{T}_{\text{intra},1} + \mathbf{T}_{\text{intra},2} \\ &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned} \tag{8.83}$$

Toda a dispersão dentro dos grupos ocorre, neste exemplo, na primeira variável. A segunda variável é constante dentro de cada grupo.

Dispersão entre grupos.

Os afastamentos das médias dos grupos em relação à média total são

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 - \bar{\mathbf{x}} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Como ambos os grupos possuem duas observações,

$$\begin{aligned} \mathbf{T}_{\text{entre}} &= 2 \begin{bmatrix} -1 \\ -2 \end{bmatrix} \begin{bmatrix} -1 & -2 \end{bmatrix} + 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.84}$$

Nesse caso, a diferença entre os centros dos grupos envolve simultaneamente as duas variáveis.

Dispersão total.

Calculando diretamente os desvios das quatro observações em relação a

$$\bar{\mathbf{x}} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

obtém-se

$$\begin{aligned} \mathbf{T} &= \begin{bmatrix} -2 \\ -2 \end{bmatrix} \begin{bmatrix} -2 & -2 \end{bmatrix} + \begin{bmatrix} 0 \\ -2 \end{bmatrix} \begin{bmatrix} 0 & -2 \end{bmatrix} \\ &\quad + \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.85}$$

A identidade Equação 8.82 pode então ser verificada diretamente:

$$\begin{aligned} \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}} &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix} \\ &= \mathbf{T}. \end{aligned}$$

A decomposição também pode ser examinada em direções específicas. Para

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

que seleciona a primeira variável,

$$\mathbf{a}_1^\top \mathbf{T} \mathbf{a}_1 = 8,$$

com

$$\mathbf{a}_1^\top \mathbf{T}_{\text{intra}} \mathbf{a}_1 = 4$$

e

$$\mathbf{a}_1^\top \mathbf{T}_{\text{entre}} \mathbf{a}_1 = 4.$$

Assim,

$$8 = 4 + 4.$$

Metade da dispersão de X_1 decorre de diferenças dentro dos grupos e metade das diferenças entre seus centros.

Para

$$\mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

que seleciona a segunda variável,

$$\mathbf{a}_2^\top \mathbf{T} \mathbf{a}_2 = 16,$$

enquanto

$$\mathbf{a}_2^\top \mathbf{T}_{\text{intra}} \mathbf{a}_2 = 0$$

e

$$\mathbf{a}_2^\top \mathbf{T}_{\text{entre}} \mathbf{a}_2 = 16.$$

Portanto,

$$16 = 0 + 16.$$

A variável X_2 não apresenta dispersão dentro dos grupos neste conjunto de dados; toda a sua dispersão total está associada à diferença entre as médias dos dois grupos.

O exemplo mostra que a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

expressa simultaneamente a decomposição da dispersão em todas as direções. Para qualquer combinação linear das variáveis, a dispersão total dessa combinação também se decompõe nas parcelas intragrupos e entre grupos, conforme Equação [8.86](#).

A identidade Equação 8.82 é algébrica e depende somente da partição das observações e das definições das médias total e de grupo (Renchert; Christensen, 2012). Normalidade, independência e outros pressupostos probabilísticos não são necessários para estabelecê-la.

Para qualquer direção

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.86)$$

Se

$$y_{ig} = \mathbf{a}^\top \mathbf{x}_{ig},$$

então Equação 8.86 corresponde exatamente à decomposição univariada

$$\sum_{g=1}^G \sum_{i=1}^{n_g} (y_{ig} - \bar{y})^2 = \sum_{g=1}^G \sum_{i=1}^{n_g} (y_{ig} - \bar{y}_g)^2 + \sum_{g=1}^G n_g (\bar{y}_g - \bar{y})^2. \quad (8.87)$$

A decomposição matricial reúne simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.2 Somas de quadrados e traço das matrizes de dispersão

As matrizes $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes de somas de quadrados e produtos cruzados e descrevem simultaneamente a dispersão das diferentes variáveis e suas associações.

O traço dessas matrizes reúne apenas os termos quadráticos da diagonal e fornece uma medida escalar de dispersão. Defina

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Essas quantidades constituem as somas de quadrados total, intragrupos e entre grupos, respectivamente. No caso univariado, elas coincidem com as somas de quadrados usuais da análise de variância. No caso multivariado, correspondem à soma das somas de quadrados das p variáveis.

Como o traço soma as contribuições das diferentes variáveis, essas quantidades dependem das escalas em que as variáveis são expressas. Sua interpretação conjunta é mais direta quando as variáveis possuem unidades comparáveis ou quando uma padronização apropriada foi realizada.

Para a matriz de dispersão total,

$$\mathbf{T} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}) (\mathbf{x}_{ig} - \bar{\mathbf{x}})^\top,$$

tem-se

$$\begin{aligned} \text{tr}(\mathbf{T}) &= \sum_{g=1}^G \sum_{i=1}^{n_g} \text{tr} \left[(\mathbf{x}_{ig} - \bar{\mathbf{x}}) (\mathbf{x}_{ig} - \bar{\mathbf{x}})^\top \right] \\ &= \sum_{g=1}^G \sum_{i=1}^{n_g} \|\mathbf{x}_{ig} - \bar{\mathbf{x}}\|^2. \end{aligned} \quad (8.88)$$

Portanto,

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}) = \sum_{g=1}^G \sum_{i=1}^{n_g} \|\mathbf{x}_{ig} - \bar{\mathbf{x}}\|^2. \quad (8.89)$$

Assim, SQ_{total} é a soma dos quadrados das distâncias euclidianas das observações à média total.

Analogamente,

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}}) = \sum_{g=1}^G \sum_{i=1}^{n_g} \|\mathbf{x}_{ig} - \bar{\mathbf{x}}_g\|^2 \quad (8.90)$$

mede a soma dos quadrados dos afastamentos das observações em relação aos centros de seus respectivos grupos.

Por sua vez,

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{g=1}^G n_g \|\bar{\mathbf{x}}_g - \bar{\mathbf{x}}\|^2 \quad (8.91)$$

mede a soma ponderada dos quadrados das distâncias entre os centros dos grupos e a média total.

Como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade do traço fornece

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}. \quad (8.92)$$

Equivalentemente,

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (8.93)$$

Ao tomar o traço da decomposição matricial, recupera-se uma identidade escalar análoga à decomposição de somas de quadrados familiar da análise de variância:

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

A decomposição matricial

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é mais informativa, pois preserva também os produtos cruzados entre as variáveis. O traço resume essa estrutura matricial em uma única soma de quadrados.

Assim, a decomposição matricial da dispersão também produz uma decomposição da quantidade total de dispersão medida pelas distâncias euclidianas quadráticas.

Dividindo essas somas por n , obtêm-se medidas médias da dispersão quadrática. Por exemplo,

$$\frac{SQ_{\text{total}}}{n} = \frac{1}{n} \text{tr}(\mathbf{T}) = \frac{1}{n} \sum_{g=1}^G \sum_{i=1}^{n_g} \|\mathbf{x}_{ig} - \bar{\mathbf{x}}\|^2.$$

Essa quantidade representa o afastamento quadrático médio das observações em relação à média total. De modo correspondente,

$$\frac{SQ_{\text{intra}}}{n}$$

e

$$\frac{SQ_{\text{entre}}}{n}$$

representam, respectivamente, as contribuições médias da dispersão intragrupos e entre grupos.

8.8.3 Esperança das matrizes de dispersão por grupos

Até este ponto, a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

foi tratada como uma identidade algébrica para os dados observados. É possível também examinar essas matrizes como objetos aleatórios e calcular suas esperanças, desde que se especifique uma estrutura probabilística para as observações.

Suponha que, para cada grupo g ,

$$\mathbf{X}_{ig}, \quad i = 1, \dots, n_g,$$

sejam vetores aleatórios independentes, com

$$E(\mathbf{X}_{ig}) = \mu_g$$

e matriz de covariâncias comum

$$\text{Cov}(\mathbf{X}_{ig}) = \Sigma.$$

Não é necessário assumir normalidade.

Defina a média populacional ponderada dos grupos por

$$\mu = \frac{1}{n} \sum_{g=1}^G n_g \mu_g. \quad (8.94)$$

Considere ainda a matriz

$$\mathbf{B}_\mu = \sum_{g=1}^G n_g (\mu_g - \mu) (\mu_g - \mu)^\top, \quad (8.95)$$

que representa a dispersão entre os vetores de médias populacionais dos grupos.

Quando as matrizes de dispersão são consideradas objetos aleatórios, as somas de quadrados correspondentes também são objetos aleatórios. Defina

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Suas realizações observadas são, respectivamente,

$$SQ_{\text{total}}, \quad SQ_{\text{intra}} \quad \text{e} \quad SQ_{\text{entre}}.$$

Para a matriz de dispersão intragrupos,

$$\mathbf{T}_{\text{intra}} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)^\top,$$

tem-se

$$E(\mathbf{T}_{\text{intra}}) = (n - G)\Sigma. \quad (8.96)$$

Tomando o traço dos dois lados e utilizando a linearidade do traço e da esperança,

$$E(SQ_{\text{intra}}) = (n - G) \text{tr}(\Sigma).$$

Consequentemente,

$$E\left(\frac{SQ_{\text{intra}}}{n - G}\right) = \text{tr}(\Sigma).$$

Dentro de cada grupo, os vetores centralizados satisfazem

$$\sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) = \mathbf{0}.$$

Assim, a centralização pela média do grupo reduz em uma unidade a dimensão disponível, fazendo com que o grupo g contribua com $n_g - 1$ graus de liberdade. Portanto,

$$\sum_{g=1}^G (n_g - 1) = n - G.$$

A quantidade $n - G$ corresponde, assim, aos graus de liberdade intragrupos familiares da análise de variância. A divisão por $n - G$ antecipa a construção dos quadrados médios utilizada em ANOVA e planejamento de experimentos.

Para a dispersão entre grupos,

$$\mathbf{T}_{\text{entre}} = \sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top,$$

a esperança é

$$E(\mathbf{T}_{\text{entre}}) = (G - 1)\Sigma + \mathbf{B}_\mu. \quad (8.97)$$

Essa expressão contém duas parcelas com interpretações distintas. O termo

$$(G - 1)\Sigma$$

representa a variabilidade decorrente do fato de que as médias amostrais dos grupos variam de amostra para amostra, enquanto

$$\mathbf{B}_\mu$$

representa a separação efetiva entre os vetores de médias populacionais.

Em particular, se

$$\mu_1 = \cdots = \mu_G,$$

então

$$\mathbf{B}_\mu = \mathbf{0},$$

mas, ainda assim,

$$E(\mathbf{T}_{\text{entre}}) = (G - 1)\Sigma.$$

Tomando o traço na Equação 8.97,

$$E(\text{SQ}_{\text{entre}}) = (G - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Consequentemente,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{G - 1}\right) = \text{tr}(\Sigma) + \frac{\text{tr}(\mathbf{B}_\mu)}{G - 1}.$$

Quando os grupos possuem o mesmo vetor de médias populacional,

$$\mu_1 = \cdots = \mu_G,$$

tem-se

$$\mathbf{B}_\mu = \mathbf{0}.$$

Nesse caso,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{G - 1}\right) = E\left(\frac{\text{SQ}_{\text{intra}}}{n - G}\right) = \text{tr}(\Sigma).$$

Portanto, quando não existe separação entre os vetores de médias populacionais, as somas de quadrados intragrupos e entre grupos, após a divisão pelas respectivas quantidades $n - G$ e $G - 1$, possuem a mesma esperança.

Isso ocorre porque as médias amostrais dos grupos não coincidem exatamente, mesmo quando seus vetores de médias populacionais são iguais.

Por fim, como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade da esperança fornece

$$\begin{aligned} E(\mathbf{T}) &= E(\mathbf{T}_{\text{intra}}) + E(\mathbf{T}_{\text{entre}}) \\ &= (n-1)\Sigma + \mathbf{B}_{\mu}. \end{aligned} \quad (8.98)$$

Tomando o traço,

$$E(\text{SQ}_{\text{total}}) = (n-1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_{\mu}). \quad (8.99)$$

Além disso,

$$\text{SQ}_{\text{total}} = \text{SQ}_{\text{intra}} + \text{SQ}_{\text{entre}},$$

que é a versão aleatória da decomposição observada

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

Quando todos os grupos possuem o mesmo vetor de médias populacional,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Esses resultados dependem apenas de momentos de primeira e segunda ordem e da independência entre as observações; a normalidade não é necessária. Distribuições amostrais e resultados inferenciais associados a essas matrizes serão tratados posteriormente.

No caso univariado, as matrizes reduzem-se a escalares e a decomposição assume a forma familiar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

As divisões

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n - G}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{G - 1}$$

correspondem aos quadrados médios familiares da análise de variância e do planejamento de experimentos.

No contexto multivariado, contudo, as matrizes completas de somas de quadrados e produtos cruzados preservam informações adicionais sobre as associações entre as variáveis. Por essa razão, métodos multivariados posteriores utilizarão $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, e não apenas seus traços.

8.8.4 Propriedades e limites de posto

Independentemente das hipóteses probabilísticas utilizadas na subseção anterior, as propriedades estruturais a seguir decorrem diretamente das definições das matrizes de dispersão.

Proposição 8.11 (Estrutura das matrizes de dispersão por grupos). *As matrizes*

$$\mathbf{T}, \quad \mathbf{T}_{\text{intra}} \quad \text{e} \quad \mathbf{T}_{\text{entre}}$$

são simétricas e positivas semidefinidas. Além disso,

$$\mathbf{0} \preceq \mathbf{T}_{\text{intra}} \preceq \mathbf{T}$$

e

$$\mathbf{0} \preceq \mathbf{T}_{\text{entre}} \preceq \mathbf{T}.$$

Seus postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - G), \quad (8.100)$$

e

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, G - 1). \quad (8.101)$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{g=1}^G \sum_{i=1}^{n_g} [\mathbf{a}^\top (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{g=1}^G n_g \left[\mathbf{a}^\top (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) \right]^2 \geq 0.$$

Logo, as duas parcelas são positivas semidefinidas. Pela identidade Equação 8.82,

$$\mathbf{T} - \mathbf{T}_{\text{intra}} = \mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T} - \mathbf{T}_{\text{entre}} = \mathbf{T}_{\text{intra}} \succeq \mathbf{0},$$

o que estabelece as relações na ordem de Loewner.

O limite para $\mathbf{T}$ foi obtido na Equação 8.60.

Dentro do grupo g , os n_g vetores centralizados satisfazem

$$\sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) = \mathbf{0}.$$

Assim, os vetores centralizados desse grupo geram um subespaço de dimensão no máximo $n_g - 1$. Considerando todos os grupos,

$$\sum_{g=1}^G (n_g - 1) = n - G,$$

e, portanto,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - G).$$

Para a parcela entre grupos,

$$\sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) = \mathbf{0}.$$

Os G vetores

$$\sqrt{n_g} (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})$$

geram, portanto, um subespaço de dimensão no máximo $G - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, G - 1).$$

□

Os limites podem ser estritos quando existem relações lineares adicionais entre as variáveis ou entre os vetores de médias dos grupos.

As relações na ordem de Loewner implicam, para qualquer direção $\mathbf{a}$,

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}$$

e

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}.$$

Assim, a dispersão intragrupos ou entre grupos em uma direção não pode exceder a dispersão total na mesma direção.

Dois casos extremos auxiliam a interpretação. Se

$$\bar{\mathbf{x}}_1 = \dots = \bar{\mathbf{x}}_G = \bar{\mathbf{x}},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0}.$$

Se, por outro lado, todas as observações de cada grupo coincidem com a respectiva média,

$$\mathbf{x}_{ig} = \bar{\mathbf{x}}_g,$$

então

$$\mathbf{T}_{\text{intra}} = \mathbf{0}.$$

Neste capítulo, a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é inicialmente desenvolvida como uma decomposição algébrica da dispersão observada e, sob hipóteses explícitas de independência e covariância comum, recebe também uma interpretação por meio das esperanças das matrizes de dispersão. Distribuições amostrais, testes de hipóteses e sua formulação no modelo linear multivariado serão desenvolvidos posteriormente.

No Capítulo 11, uma estrutura correspondente será obtida a partir do modelo linear multivariado e de matrizes de projeção. Graus de liberdade, estimadores de covariâncias residuais e hipóteses lineares pertencem àquele contexto.

8.9 Síntese do capítulo

A matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X})$$

representa a estrutura de segunda ordem de um vetor aleatório. Sua diagonal contém as variâncias das componentes, e seus elementos fora da diagonal registram covariâncias. Para qualquer combinação linear,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a},$$

de modo que a matriz de covariâncias determina a dispersão em todas as direções.

A padronização marginal conduz à matriz de correlações

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2},$$

que preserva a estrutura de associação linear após a retirada das escalas marginais.

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto o traço e o determinante produzem resumos escalares distintos. A variância total é

$$\text{tr}(\Sigma) = \sum_{j=1}^p \sigma_{jj} = \sum_{j=1}^p \lambda_j,$$

e também pode ser interpretada como o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu centro:

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma).$$

Mais geralmente, para uma matriz simétrica $\mathbf{A}$ e um vetor fixo $\mathbf{a}$,

$$E \left[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a}) \right] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}).$$

A variância generalizada é

$$\det(\Sigma),$$

e, quando $\Sigma \succ \mathbf{0}$, a distância de Mahalanobis

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

mede afastamentos levando em conta simultaneamente escalas e covariâncias. Sua esperança populacional satisfaz

$$E[d_M^2(\mathbf{X}, \mu)] = p.$$

A transformação de **branqueamento** (*whitening*), também denominada **esferização**, transforma a estrutura de covariâncias em identidade. No branqueamento simétrico,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_p.$$

Nesse espaço transformado, a distância de Mahalanobis coincide com a distância euclidiana. A padronização marginal e o branqueamento diferem porque a primeira produz matriz de covariâncias igual a $\mathcal{R}$, enquanto o branqueamento produz $\mathbf{I}_p$.

No nível descritivo, as mesmas estruturas são representadas por

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c, \quad \mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A sigla **SQPC** significa **somas de quadrados e produtos cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*.

Quando as observações estão organizadas em grupos,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa a dispersão observada dentro dos grupos da dispersão associada às diferenças entre seus centros. As matrizes completas preservam tanto as somas de quadrados de cada variável quanto os produtos cruzados entre variáveis.

Tomando o traço, obtém-se a decomposição escalar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}},$$

em que

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}), \quad SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

No caso univariado, essa identidade coincide com a decomposição de somas de quadrados familiar da análise de variância. Os correspondentes quadrados médios são

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n - G}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{G - 1}.$$

No contexto multivariado, entretanto, as matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ contêm informação adicional sobre os produtos cruzados e, por isso, são mais informativas do que seus traços.

Sob independência entre as observações e matriz de covariâncias comum Σ nos grupos, as matrizes de dispersão também admitem interpretações probabilísticas. Se

$$\mu = \frac{1}{n} \sum_{g=1}^G n_g \mu_g$$

e

$$\mathbf{B}_\mu = \sum_{g=1}^G n_g \left(\mu_g - \mu \right) \left(\mu_g - \mu \right)^\top,$$

então

$$E(\mathbf{T}_{\text{intra}}) = (n - G)\Sigma,$$

$$E(\mathbf{T}_{\text{entre}}) = (G - 1)\Sigma + \mathbf{B}_\mu,$$

e

$$E(\mathbf{T}) = (n - 1)\Sigma + \mathbf{B}_\mu.$$

Tomando os traços,

$$E(\text{SQ}_{\text{intra}}) = (n - G) \text{tr}(\Sigma)$$

e

$$E(\text{SQ}_{\text{entre}}) = (G - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Definindo os quadrados médios como objetos aleatórios por

$$\text{QM}_{\text{intra}} = \frac{\text{SQ}_{\text{intra}}}{n - G}$$

e

$$\text{QM}_{\text{entre}} = \frac{\text{SQ}_{\text{entre}}}{G - 1},$$

quando

$$\mu_1 = \cdots = \mu_G,$$

tem-se

$$E(\text{QM}_{\text{intra}}) = E(\text{QM}_{\text{entre}}) = \text{tr}(\Sigma).$$

Essa igualdade antecipa a lógica dos quadrados médios da análise de variância, enquanto a formulação multivariada posterior utilizará as matrizes completas de somas de quadrados e produtos cruzados.

A Tabela 8.1 reúne os principais objetos do capítulo.

Tabela 8.1: Principais objetos desenvolvidos no capítulo.

Nível	Objeto	Símbolo	Função
Populacional	vetor de médias	μ	localização
Populacional	matriz de covariâncias	Σ	dispersão conjunta
Populacional	matriz de correlações	$\mathcal{R}$	associação linear padronizada
Populacional	covariância cruzada	Σ_{XY}	associação linear entre blocos
Geométrico	variância total	$\text{tr}(\Sigma)$	dispersão quadrática média
Geométrico	variância generalizada	$\det(\Sigma)$	dispersão multidimensional global
Geométrico	distância de Mahalanobis	d_M	afastamento ajustado à dispersão
Geométrico	branqueamento	$\Sigma^{-1/2}$	transformação para covariância identidade
Dados observados	média	$\bar{\mathbf{x}}$	centro das observações
Dados observados	SQPC	$\mathbf{T}$	dispersão não normalizada
Dados observados	covariância	$\mathbf{S}$	dispersão calculada dos dados
Dados observados	correlação	$\mathbf{R}$	associação linear padronizada nos dados
Dados agrupados	dispersão intragrupos	$\mathbf{T}_{\text{intra}}$	dispersão dentro dos grupos
Dados agrupados	dispersão entre grupos	$\mathbf{T}_{\text{entre}}$	dispersão entre os centros dos grupos
Dados agrupados	decomposição matricial	$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$	separação da dispersão por grupos

Nível	Objeto	Símbolo	Função
Dados agrupados	somas de quadrados	$SQ_{\text{total}}, SQ_{\text{intra}}, SQ_{\text{entre}}$	resumos escalares obtidos pelos traços das matrizes de dispersão
Dados agrupados	quadrados médios	$QM_{\text{intra}}, QM_{\text{entre}}$	somas de quadrados ajustadas pelos respectivos graus de liberdade

Ao final deste capítulo, o estudante deverá ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- calcular e interpretar variâncias e covariâncias de combinações lineares;
- reconhecer as condições estruturais, a singularidade e o posto de matrizes de covariâncias e correlações;
- interpretar a decomposição espectral, a variância total, a variância generalizada e a geometria dos elipsoides de dispersão;
- relacionar formas quadráticas e esperanças matemáticas à estrutura de covariâncias;
- interpretar a distância de Mahalanobis e sua relação com o branqueamento e a esferização;
- distinguir padronização marginal e branqueamento;
- distinguir parâmetros populacionais, estatísticas amostrais e valores calculados de dados observados;
- decompor a dispersão observada em parcelas total, intragrupos e entre grupos;
- relacionar os traços das matrizes de dispersão às somas de quadrados total, intragrupos e entre grupos;
- reconhecer a relação entre somas de quadrados, graus de liberdade e quadrados médios, estabelecendo a conexão com a análise de variância;
- interpretar, sob hipóteses probabilísticas apropriadas, as esperanças das matrizes de dispersão e das correspondentes somas de quadrados e quadrados médios.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas, em geral, não determina sua distribuição conjunta. O próximo capítulo introduz a **Distribuição Normal Multivariada**, na qual o vetor de médias e a matriz de covariâncias determinam completamente a distribuição. Serão desenvolvidas suas distribuições marginais e condicionais e, no caso não singular, sua função densidade. Nesse contexto, a distância quadrática de

Mahalanobis deixará de ser apenas uma construção geométrica baseada em momentos de segunda ordem e passará a possuir uma distribuição probabilística específica.

9 Distribuição Normal Multivariada

O Capítulo 8 desenvolveu o vetor de médias na Equação 8.1, a matriz de covariâncias na Definição 8.2 e a geometria da dispersão na Equação 8.32. Em uma distribuição geral, essas estruturas de primeira e segunda ordem não determinam completamente a distribuição conjunta. Diferentes distribuições podem possuir o mesmo vetor de médias e a mesma matriz de covariâncias.

Na família normal multivariada, o vetor de médias e a matriz de covariâncias determinam a distribuição. Além disso, transformações afins e distribuições marginais permanecem normais, e a estrutura de covariâncias assume consequências probabilísticas específicas, como a equivalência entre não correlação e independência para componentes conjuntamente normais.

O objetivo deste capítulo é construir a distribuição normal multivariada e relacionar suas propriedades probabilísticas à estrutura desenvolvida no capítulo anterior. Serão considerados os casos não singular e singular, a função densidade, as distribuições marginais e condicionais, a independência entre blocos, a padronização, o branqueamento e a distribuição da distância quadrática de Mahalanobis.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\mu \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathbf{X} \sim N_p(\mu, \Sigma)$ indica uma distribuição normal multivariada de dimensão p , parametrizada pelo vetor de médias e pela matriz de covariâncias;
- $\mathbf{Z}$ representa um vetor normal multivariado padrão, cuja dimensão será indicada pelo contexto; por exemplo, $\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r)$ em dimensão r ;
- $\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias marginais;
- $\sigma_j = \sqrt{\sigma_{jj}}$ representa o desvio-padrão marginal da componente X_j ;
- $\mathcal{R}$ representa a matriz de correlações populacional;
- $\mathbf{X}_1$ e $\mathbf{X}_2$ representam blocos de um vetor normal particionado, com matrizes de covariâncias Σ_{11} e Σ_{22} e covariâncias cruzadas Σ_{12} e Σ_{21} ;
- $\Sigma_{11.2}$ representa o complemento de Schur de Σ_{22} em Σ ;
- $d_M^2(\mathbf{x}, \mu)$ representa a distância quadrática de Mahalanobis de um ponto fixo $\mathbf{x}$ ao centro populacional;

- D_M^2 representa a distância quadrática de Mahalanobis considerada como variável aleatória;
- Σ^+ representa a pseudoinversa de Moore–Penrose no caso singular;
- χ_p^2 representa a distribuição qui-quadrado com p graus de liberdade, e $\chi_{p;1-\alpha}^2$ representa seu quantil de ordem $1 - \alpha$.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

Uma maneira de caracterizar a normalidade multivariada é examinar todas as projeções lineares do vetor. Essa caracterização inclui o caso em que alguma combinação linear possui variância zero (Eaton, 2007).

Na definição a seguir, admite-se também a normal univariada degenerada: quando a variância é zero, a distribuição fica concentrada em sua média.

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se o caso degenerado de variância zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pela Proposição 8.1 do Capítulo 8, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu$$

quase certamente.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Assim, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente considerada separadamente não garante normalidade multivariada. A definição exige que **todas as combinações lineares** das componentes possuam distribuição normal.

Portanto,

$$X_j \text{ normal para todo } j$$

não implica, isoladamente,

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ representa a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece que toda projeção unidimensional de um vetor normal multivariado possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A definição anterior também permite construir vetores normais multivariados a partir de variáveis normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ \vdots \\ Z_r \end{bmatrix},$$

com

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e componentes mutuamente independentes.

Para qualquer $\mathbf{c} \in \mathbb{R}^r$,

$$\mathbf{c}^\top \mathbf{Z} = \sum_{j=1}^r c_j Z_j$$

é uma variável normal. Além disso,

$$E(\mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_r.$$

Logo,

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A transformação afim definida na Definição 4.7 permite transportar essa distribuição para outros vetores de médias e outras estruturas de covariância.

Proposição 9.1 (Construção afim de um vetor normal). *Se*

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

$\mathbf{A} \in \mathbb{R}^{p \times r}$ e $\mu \in \mathbb{R}^p$, então o vetor

$$\mathbf{X} = \mu + \mathbf{AZ} \tag{9.3}$$

satisfaz

$$\mathbf{X} \sim N_p(\mu, \mathbf{AA}^\top). \tag{9.4}$$

Comprovação. Pelo resultado de transformação da covariância na Proposição 8.6,

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top = \mathbf{AA}^\top. \tag{9.5}$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{AZ} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

A última parcela é uma combinação linear das componentes de $\mathbf{Z}$ e, portanto, possui distribuição normal. Assim, $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$, o que caracteriza $\mathbf{X}$ como normal multivariado. $\square$

A matriz $\mathbf{A}$ determina como as componentes independentes de $\mathbf{Z}$ são combinadas. A transformação pode introduzir covariâncias entre as componentes de $\mathbf{X}$, mesmo que as componentes do vetor inicial sejam independentes.

Pela Proposição 8.2, uma matriz de covariâncias é simétrica e positiva semidefinida. Reciprocamente, toda matriz real simétrica e positiva semidefinida admite uma fatoração

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

De fato, pelo Teorema 5.4,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com autovalores não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\Lambda^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \Sigma.$$

Consequentemente, qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica positiva semidefinida Σ podem parametrizar uma distribuição normal multivariada.

No Capítulo 8, a Proposição 8.2 estabeleceu que simetria e semidefinição positiva caracterizam as matrizes que podem ocorrer como matrizes de covariâncias. Na família normal multivariada, qualquer matriz com essa estrutura pode ser utilizada na construção de uma distribuição por meio de uma fatoração $\Sigma = \mathbf{A}\mathbf{A}^\top$.

Quando

$$\Sigma \succ \mathbf{0},$$

a raiz quadrada principal definida na Definição 5.9 é invertível e pode ser utilizada como matriz da construção afim, pois

$$\Sigma^{1/2}\Sigma^{1/2} = \Sigma.$$

Assim, se

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

o vetor

$$\mathbf{Y} = \mu + \Sigma^{1/2} \mathbf{Z}$$

possui distribuição

$$\mathbf{Y} \sim N_p(\mu, \Sigma).$$

9.1.3 Determinação pelos parâmetros

O vetor de médias μ e a matriz de covariâncias Σ descrevem características de primeira e segunda ordem, mas, por si sós, não determinam uma distribuição conjunta. Na família normal multivariada, esses parâmetros determinam a distribuição, pois todas as projeções lineares são normais e seus parâmetros são determinados por μ e Σ .

Nesta seção será utilizada a notação de **igualdade em distribuição**. Para vetores aleatórios $\mathbf{X}$ e $\mathbf{Y}$ em $\mathbb{R}^p$, escrever

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

significa que os dois vetores possuem a mesma distribuição conjunta. Equivalentemente, para todo

$$\mathbf{x} = (x_1, \dots, x_p)^\top \in \mathbb{R}^p,$$

tem-se

$$P(X_1 \leq x_1, \dots, X_p \leq x_p) = P(Y_1 \leq x_1, \dots, Y_p \leq x_p).$$

A igualdade em distribuição não significa que

$$\mathbf{X} = \mathbf{Y}$$

quase certamente. Os vetores podem, inclusive, estar definidos em espaços de probabilidade distintos.

O resultado geral que permite passar das distribuições das projeções à distribuição conjunta é o Teorema de Cramér–Wold (Eaton, 2007).

Teorema 9.1 (Teorema de Cramér–Wold). *Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios em $\mathbb{R}^p$. Então,*

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a} \in \mathbb{R}^p$.

A implicação direta decorre da aplicação da mesma transformação linear a vetores com a mesma distribuição. A implicação inversa estabelece que a coleção das distribuições de todas as projeções lineares determina a distribuição conjunta.

Leitura de aprofundamento

O Teorema de Cramér–Wold é um resultado geral e não depende da hipótese de normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

Aqui, sua função é justificar que duas distribuições normais multivariadas com o mesmo vetor de médias e a mesma matriz de covariâncias são a mesma distribuição.

Proposição 9.2 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\mathbf{Y} \sim N_p(\mu, \Sigma),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a}$. Pelo Teorema 9.1,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

□

Essa propriedade explica por que a notação

$$N_p(\mu, \Sigma)$$

é suficiente para identificar uma distribuição normal multivariada.

Como consequência, quando

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a construção anterior permite escrever

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.1.4 Aprofundamento: caso singular e suporte efetivo

Leitura de aprofundamento

A normal multivariada também pode ser definida quando Σ é singular. Nesse caso, a distribuição permanece normal, mas sua variabilidade está restrita a um subespaço afim de dimensão inferior a p .

A sequência principal do capítulo utilizará predominantemente o caso não singular, $\Sigma \succ \mathbf{0}$. O caso singular esclarece a relação entre dependência linear, posto da matriz de

covariâncias e suporte probabilístico.

Definição 9.2 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\mu, \Sigma)$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\Sigma) = r < p.$$

Quando

$$\text{posto}(\Sigma) = p,$$

a distribuição é denominada **não singular**.

Se

$$\text{posto}(\Sigma) = r < p,$$

a decomposição espectral reduzida pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

possui colunas ortonormais associadas aos autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top.$$

Logo, uma representação da distribuição singular é

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.8)$$

No Capítulo 8, a partir da Proposição 8.3, vimos que a singularidade de Σ implica, para qualquer vetor aleatório com essa matriz de covariâncias,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente. Na família normal, a representação na Equação 9.8 permite uma conclusão mais forte: o subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

constitui o suporte da distribuição.

Proposição 9.3 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

então

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.9)$$

O suporte da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Comprovação. Pela representação Equação 9.8,

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}.$$

Como $\Lambda_r^{1/2}$ é invertível,

$$\mathcal{C}(\mathbf{A}_r) = \mathcal{C}(\mathbf{Q}_r) = \mathcal{C}(\Sigma).$$

Portanto,

$$\mathbf{A}_r \mathbf{Z} \in \mathcal{C}(\Sigma)$$

quase certamente, o que fornece Equação 9.9.

Além disso, $\mathbf{A}_r$ possui posto coluna r . A aplicação

$$\mathbf{z} \mapsto \mu + \mathbf{A}_r \mathbf{z}$$

é uma transformação afim bijetiva entre $\mathbb{R}^r$ e

$$\mu + \mathcal{C}(\Sigma).$$

Como a normal padrão em $\mathbb{R}^r$ possui densidade positiva em todo $\mathbb{R}^r$, todo conjunto relativamente aberto e não vazio desse subespaço afim possui probabilidade positiva. Assim, esse subespaço é o suporte da distribuição. $\square$

A mesma estrutura pode ser caracterizada pelo núcleo da matriz de covariâncias. Se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

e, conseqüentemente,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

quase certamente.

As direções do núcleo são, portanto, direções sem variabilidade probabilística.

A normal singular não possui densidade em relação à medida de Lebesgue de dimensão p em $\mathbb{R}^p$, pois concentra toda a probabilidade em um conjunto de dimensão $r < p$. No suporte afim de dimensão r , entretanto, a distribuição pode ser descrita por uma densidade relativamente à medida de volume r -dimensional desse subespaço.

Exemplo 9.1 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Equivalentemente,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1 e

$$X_2 = 2X_1$$

quase certamente. Portanto, toda a distribuição está concentrada na reta

$$x_2 = 2x_1.$$

Embora o vetor tenha duas componentes, sua dimensão probabilística efetiva é 1.

O caso singular mostra que a normal multivariada pode existir mesmo sem possuir densidade no espaço ambiente $\mathbb{R}^p$. Quando

$$\Sigma \succ \mathbf{0},$$

essa restrição desaparece: a matriz possui posto p , é invertível e a distribuição ocupa todo o espaço $\mathbb{R}^p$.

9.2 Densidade no caso não singular

A partir deste ponto, considere

$$\Sigma \succ \mathbf{0}.$$

Então,

$$\Sigma^{-1}$$

existe e

$$\det(\Sigma) > 0,$$

permitindo representar a distribuição normal multivariada por uma densidade em relação à medida de Lebesgue em $\mathbb{R}^p$.

9.2.1 Função densidade e log-densidade

Proposição 9.4 (Densidade da normal multivariada não singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0},$$

então $\mathbf{X}$ possui densidade

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.10)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Comprovação. Pela representação Equação 9.7,

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z},$$

com

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Como as componentes de $\mathbf{Z}$ são normais padrão independentes, sua densidade conjunta é

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{(2\pi)^{p/2}} \exp \left(-\frac{1}{2} \mathbf{z}^\top \mathbf{z} \right).$$

Considere a transformação afim

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

Como $\Sigma^{1/2}$ é invertível,

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu).$$

A Jacobiana da transformação inversa é a matriz constante $\Sigma^{-1/2}$, de modo que

$$\left| \det(\Sigma^{-1/2}) \right| = \det(\Sigma)^{-1/2}.$$

Aplicando a transformação de densidades estabelecida na Proposição 7.19,

$$\begin{aligned} f_{\mathbf{x}}(\mathbf{x}) &= f_{\mathbf{Z}}[\Sigma^{-1/2}(\mathbf{x} - \mu)] \det(\Sigma)^{-1/2} \\ &= \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}. \end{aligned}$$

□

A derivação mostra a função desempenhada pelos dois termos matriciais da densidade. O determinante surge da alteração de volume provocada pela transformação afim, enquanto a matriz inversa aparece ao expressar o afastamento de $\mathbf{x}$ nas coordenadas da normal padrão obtidas pelo branqueamento.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$. Probabilidades são atribuídas a regiões:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}, \quad (9.11)$$

para conjuntos mensuráveis $\mathcal{A} \subseteq \mathbb{R}^p$.

A forma quadrática no expoente é a distância quadrática de Mahalanobis definida na Definição 8.9:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Assim,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left[-\frac{1}{2} d_M^2(\mathbf{x}, \mu) \right]. \quad (9.12)$$

Para μ e Σ fixos, a posição de $\mathbf{x}$ afeta a densidade somente por meio de sua distância de Mahalanobis ao vetor de médias. Como

$$c \mapsto \exp \left(-\frac{c}{2} \right)$$

é estritamente decrescente para $c \geq 0$, pontos mais afastados do centro segundo essa métrica possuem menor densidade.

A log-densidade é

$$\begin{aligned} \log f_{\mathbf{X}}(\mathbf{x}) &= -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned} \quad (9.13)$$

A expressão reúne uma constante dependente da dimensão, um termo associado à escala volumétrica da dispersão e um termo associado ao afastamento do ponto em relação ao centro.

No Capítulo 10, essa mesma estrutura aparecerá na função de verossimilhança de uma amostra normal multivariada.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e Equação 9.10 reduz-se a

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right].$$

O vetor μ determina a localização da distribuição. Como

$$d_M^2(\mathbf{x}, \mu) \geq 0$$

e a igualdade ocorre em $\mathbf{x} = \mu$, a densidade atinge seu máximo no centro:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}. \quad (9.14)$$

A matriz Σ determina a escala, a orientação e a forma das superfícies de igual densidade. A geometria desses elipsoides foi desenvolvida no Capítulo 8 na Equação 8.32; a novidade probabilística é que, na distribuição normal, essa mesma geometria organiza os valores da densidade.

9.2.2 Superfícies de igual densidade

Para $c > 0$, considere

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) = c\}. \quad (9.15)$$

Para todo $\mathbf{x} \in \mathcal{S}_c$,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{c}{2}\right).$$

Portanto, $\mathcal{S}_c$ é uma superfície de igual densidade.

Pela representação espectral na Equação 8.33, desenvolvida no Capítulo 8, essas superfícies são elipsoidais. Seus eixos e extensões são determinados pela estrutura espectral de Σ .

Não é necessário reconstruir aqui essa geometria; no modelo normal, o novo resultado é a correspondência

$$\text{distância de Mahalanobis constante} \iff \text{densidade constante}.$$

A Figura 9.1 mostra essa correspondência para uma distribuição normal bivariada.




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

As curvas de nível são elipses centradas em μ . Todos os pontos sobre uma mesma curva apresentam a mesma distância de Mahalanobis ao centro e, conseqüentemente, a mesma densidade.

A região interna correspondente é

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.16)$$

Neste ponto, c é apenas uma constante positiva. Mais adiante, a distribuição de D_M^2 permitirá escolher valores de c associados a probabilidades populacionais específicas.

9.3 Transformações e distribuições marginais

A construção na Proposição 9.1 partiu de um vetor normal padrão. Uma propriedade mais geral da família normal é o fechamento sob transformações afins. Essa propriedade permite obter distribuições de combinações lineares, projeções, subvectores e transformações de padronização sem recalculas densidades por integração.

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

$\mathbf{A} \in \mathbb{R}^{m \times p}$ e $\mathbf{b} \in \mathbb{R}^m$.

Proposição 9.5 (Fechamento da família normal sob transformações afins). *Se*

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}, \tag{9.17}$$

então

$$\mathbf{Y} \sim N_m(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top). \tag{9.18}$$

Comprovação. Pela Proposição 8.6,

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^m$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}. \end{aligned}$$

Como $\mathbf{X}$ é normal multivariado,

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição de uma constante preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado. $\square$

As fórmulas para média e covariância são válidas para vetores aleatórios gerais com segundos momentos finitos. O resultado específico da família normal é o **fechamento distribucional**:

$$\mathbf{X} \text{ normal multivariado} \implies \mathbf{A}\mathbf{X} + \mathbf{b} \text{ normal multivariado.}$$

A matriz $\mathbf{A}$ não precisa possuir posto completo. Se

$$\text{posto}(\mathbf{A}\Sigma\mathbf{A}^\top) < m,$$

a distribuição transformada é uma normal singular em $\mathbb{R}^m$.

Exemplo 9.2 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

Logo,

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \end{aligned}$$

e a matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

O exemplo mostra que uma transformação afim modifica simultaneamente localização e covariância, mas preserva a família normal.

9.3.2 Combinações lineares

Uma combinação linear é o caso $m = 1$ de Proposição 9.5.

Para $\mathbf{a} \in \mathbb{R}^p$ e $b \in \mathbb{R}$,

$$Y = \mathbf{a}^\top \mathbf{X} + b$$

satisfaz

$$Y \sim N(\mathbf{a}^\top \mu + b, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.19)$$

A expressão fornece diretamente a distribuição de somas, diferenças, contrastes, médias ponderadas e projeções lineares.

Exemplo 9.3 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

Quando $\sigma_{12} > 0$, a covariância aumenta a variância da soma e reduz a variância da diferença. Para $\sigma_{12} < 0$, ocorre o efeito inverso.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

a distribuição é degenerada e

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

quase certamente.

9.3.3 Distribuições marginais

As distribuições marginais de subvetores também podem ser obtidas como transformações lineares.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.20)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Proposição 9.6 (Distribuições marginais da normal multivariada). *Sob o particionamento na Equação 9.20,*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.21)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.22)$$

Comprovação. O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

com

$$\mathbf{A}_1 = \begin{bmatrix} \mathbf{I}_{p_1} & \mathbf{0} \end{bmatrix}.$$

Pela Proposição 9.5,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1 \mu, \mathbf{A}_1 \Sigma \mathbf{A}_1^\top).$$

A estrutura particionada fornece

$$\mathbf{A}_1 \mu = \mu_1$$

e

$$\mathbf{A}_1 \Sigma \mathbf{A}_1^\top = \Sigma_{11}.$$

O segundo bloco é obtido de forma análoga. $\square$

A distribuição marginal de um bloco depende de seu vetor de médias e de sua própria matriz de covariâncias. A matriz Σ_{12} não aparece nos parâmetros marginais, mas participa da estrutura de dependência conjunta.

Exemplo 9.4 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0,5 \\ -1 & 0,5 & 2 \end{bmatrix} \right).$$

Selecionando X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas componentes correspondentes de μ , e a matriz de covariâncias marginal é a submatriz principal associada às variáveis selecionadas.

As distribuições marginais continuam normais quando a distribuição conjunta é singular. O subvetor selecionado pode possuir matriz de covariâncias não singular ou singular.

9.3.4 Padronização marginal e branqueamento

O Capítulo 8 definiu na Equação 8.20 a matriz

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Suponha

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

A padronização marginal é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.23)$$

Pela Proposição 9.5 e pela definição de $\mathcal{R}$ na Definição 8.5,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.24)$$

com

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Cada componente padronizada satisfaz

$$Z_{\text{pad},j} \sim N(0, 1),$$

mas as componentes não são necessariamente independentes.

Padronização não implica independência

A padronização marginal produz componentes com média zero e variância unitária, mas preserva as correlações existentes entre elas.

Assim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}).$$

As componentes serão independentes precisamente quando

$$\mathcal{R} = \mathbf{I}_p,$$

resultado que será formalizado na seção seguinte.

Quando

$$\Sigma \succ \mathbf{0},$$

o Capítulo 8 mostrou na Equação 8.51 que o branqueamento simétrico transforma a estrutura de segunda ordem em covariância identidade. Sob normalidade multivariada, é possível determinar também a distribuição completa do vetor transformado.

O branqueamento simétrico é dado por

$$\mathbf{Z} = \Sigma^{-1/2}(\mathbf{X} - \mu). \quad (9.25)$$

Pelo fechamento da família normal,

$$\begin{aligned}\mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p).\end{aligned}\tag{9.26}$$

A diferença entre as duas transformações é, portanto,

$$\mathbf{D}_\Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R})$$

e

$$\Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A padronização marginal transforma as variâncias em um e preserva as correlações. O branqueamento transforma toda a matriz de covariâncias em identidade.

A consequência adicional da normalidade conjunta é probabilística: como será formalizado na seção seguinte, uma matriz de covariâncias diagonal implica independência das componentes dentro de um vetor conjuntamente normal. Portanto, as componentes do vetor branqueado são independentes.

Como discutido no Capítulo 8, o branqueamento não é único. No caso normal, essa não unicidade preserva também a distribuição normal padrão. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

pois

$$\mathbf{Q}_0 \mathbf{I}_p \mathbf{Q}_0^\top = \mathbf{I}_p.$$

O branqueamento simétrico constitui uma escolha específica entre transformações que produzem covariância identidade.

Branqueamento no caso singular

Se

$$\text{posto}(\Sigma) = r < p,$$

a matriz $\Sigma^{-1/2}$ não existe em todo $\mathbb{R}^p$. Utilizando

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

pode-se definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.27)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.28)$$

Essa transformação expressa a distribuição em suas r direções de variância positiva e realiza o branqueamento no espaço efetivo da normal singular. Assim, embora o vetor original pertença a $\mathbb{R}^p$, sua parte aleatória pode ser representada por um vetor normal padrão de dimensão r .

A próxima seção utiliza uma propriedade específica da normalidade conjunta: para blocos pertencentes ao mesmo vetor normal multivariado, covariância cruzada nula é equivalente à independência.

9.4 Independência e distribuições condicionais

Quando os segundos momentos existem, a independência entre dois blocos implica covariância cruzada nula. A implicação inversa, entretanto, não é válida sem hipóteses adicionais. Na família normal multivariada, a normalidade conjunta estabelece a equivalência entre independência e covariância cruzada nula.

A normalidade conjunta também permite determinar a distribuição condicional de um bloco a partir da estrutura de covariâncias. Nesse desenvolvimento, o complemento de Schur, definido na Definição 2.26 e aplicado à matriz de covariâncias no Capítulo 8, passa a ter uma interpretação probabilística: ele corresponde à matriz de covariâncias condicional.

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.29)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Se os dois blocos são independentes, então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A normalidade conjunta permite estabelecer também a implicação inversa.

Nesta seção, quando o símbolo $\perp$ aparece entre vetores aleatórios, a notação

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

significa que $\mathbf{X}_1$ e $\mathbf{X}_2$ são **independentes**. Esse uso deve ser distinguido da ortogonalidade geométrica, também representada pelo símbolo $\perp$ nos capítulos de Álgebra Linear.

Proposição 9.7 (Independência de blocos conjuntamente normais). *Para os blocos do vetor normal multivariado na Equação 9.29,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}. \tag{9.30}$$

Comprovação. Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então a independência implica

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

Para a implicação inversa, suponha

$$\Sigma_{12} = \mathbf{0}.$$

Como

$$\Sigma_{21} = \Sigma_{12}^\top,$$

a matriz de covariâncias conjunta assume a forma

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Existem matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^\top$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^\top.$$

Considere vetores normais padrão independentes $\mathbf{Z}_1$ e $\mathbf{Z}_2$ e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Por construção,

$$\mathbf{Y}_1 \perp \mathbf{Y}_2.$$

Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Pela Proposição 9.2,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

$$\mathbf{X}_1 \perp \mathbf{X}_2.$$

□

O resultado permanece válido quando a matriz de covariâncias conjunta é singular. A demonstração utiliza a caracterização da distribuição normal por seu vetor de médias e sua matriz de covariâncias e não depende da existência de densidade em todo $\mathbb{R}^p$.

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então

$$X_1, \dots, X_p$$

são mutuamente independentes.

Esse resultado é uma consequência específica da normalidade conjunta. Sem essa hipótese, uma matriz de covariâncias diagonal garante covariância nula entre componentes, mas não implica independência.

A normalidade deve ser conjunta

A equivalência

$$\text{Cov}(X_i, X_j) = 0 \iff X_i \perp X_j$$

exige que X_i e X_j pertençam ao mesmo vetor normal multivariado.

A normalidade de cada variável considerada separadamente não é suficiente para essa conclusão.

9.4.2 Distribuição condicional

Considere novamente

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

e suponha

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0},$$

de modo que Σ_{22}^{-1} existe.

Nesta subseção, a distribuição condicional será desenvolvida no caso não singular. Normais singulares também admitem distribuições condicionais, mas sua formulação pode exigir restrições ao suporte efetivo ou o uso cuidadoso de inversas generalizadas. Essa extensão não será necessária para os desenvolvimentos posteriores deste livro.

Na notação condicional, a barra vertical $|$ deve ser lida como **dado**. Assim,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$$

representa o vetor $\mathbf{X}_1$ condicionado ao valor $\mathbf{X}_2 = \mathbf{x}_2$, e o subscrito $1 | 2$ será utilizado para identificar quantidades condicionais relativas ao primeiro bloco dado o segundo.

Defina

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2) \quad (9.31)$$

e

$$\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.32)$$

A segunda expressão é o complemento de Schur de Σ_{22} na matriz Σ , já introduzido na Equação 8.16.

Proposição 9.8 (Distribuição condicional da normal multivariada). *Sob as condições anteriores,*

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11.2}). \quad (9.33)$$

Comprovação. Considere

$$\mathbf{L}^* = \Sigma_{12}\Sigma_{22}^{-1}$$

e defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \mathbf{L}^*(\mathbf{X}_2 - \mu_2). \quad (9.34)$$

Os vetores $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são obtidos conjuntamente por uma transformação afim de $\mathbf{X}$. Pela Proposição 9.5,

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \mathbf{L}^* \Sigma_{22} \\ &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pela Proposição 9.7,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.35)$$

Além disso,

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Pela Proposição 8.5,

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Portanto,

$$\mathbf{E}_{1|2} \sim N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando Equação 9.34,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Condicionando em

$$\mathbf{X}_2 = \mathbf{x}_2,$$

a parcela que depende de $\mathbf{X}_2$ torna-se

$$\mu_{1|2}(\mathbf{x}_2).$$

Como $\mathbf{E}_{1|2}$ é independente de $\mathbf{X}_2$, sua distribuição permanece

$$N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2})$$

após o condicionamento. Portanto,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2}).$$

□

A demonstração fornece a decomposição

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.36)$$

com

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

Consequentemente,

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2). \quad (9.37)$$

No Capítulo 8, na Proposição 8.5, a expressão

$$\mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2)$$

surgiu como o melhor ajuste linear de $\mathbf{X}_1$ em função de $\mathbf{X}_2$, utilizando apenas informações de primeira e segunda ordem.

Sob normalidade conjunta, ocorre um resultado mais forte:

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2).$$

Assim, na família normal multivariada, o melhor ajuste linear coincide exatamente com a esperança condicional, e a matriz de covariâncias do resíduo linear coincide com a matriz de covariâncias condicional.

9.4.3 Média e covariância condicionais

A média condicional

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

depende do valor condicionado.

O vetor

$$\mathbf{x}_2 - \mu_2$$

representa o afastamento do bloco conhecido em relação à sua média. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média de $\mathbf{X}_1$.

Quando

$$\mathbf{x}_2 = \mu_2,$$

tem-se

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

A matriz de covariâncias condicional é

$$\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Ela não depende do valor específico de $\mathbf{x}_2$. Assim, diferentes valores do bloco condicionante deslocam o centro da distribuição condicional, mas não alteram sua matriz de covariâncias.

Como $\Sigma \succ \mathbf{0}$, a propriedade de positividade do complemento de Schur fornece

$$\Sigma_{11 \cdot 2} \succ \mathbf{0}. \quad (9.38)$$

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11 \cdot 2} = \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.39)$$

Como

$$\Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \succeq \mathbf{0},$$

segue que

$$\Sigma_{11 \cdot 2} \preceq \Sigma_{11}. \quad (9.40)$$

Portanto, para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} \text{Var} [\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{a}^\top \Sigma_{11 \cdot 2} \mathbf{a} \\ &\leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}. \end{aligned}$$

Condicionar no segundo bloco não aumenta a variância de nenhuma combinação linear do primeiro bloco.

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se simultaneamente

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1$$

e

$$\Sigma_{11 \cdot 2} = \Sigma_{11}.$$

Nesse caso, a distribuição condicional coincide com a distribuição marginal, como consequência da independência entre os blocos estabelecida na Proposição 9.7.

9.4.4 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.41)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad -1 < \rho < 1.$$

A média condicional de X_1 dado $X_2 = x_2$ é

$$\begin{aligned} E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2} (x_2 - \mu_2) \\ &= \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2). \end{aligned} \quad (9.42)$$

A variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2 \sigma_1^2 \sigma_2^2}{\sigma_2^2} \\ &= \sigma_1^2 (1 - \rho^2). \end{aligned} \quad (9.43)$$

Portanto,

$$X_1 | X_2 = x_2 \sim N \left[\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right]. \quad (9.44)$$

O sinal de ρ determina a direção do deslocamento da média condicional. Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média de X_1 para valores maiores; se $\rho < 0$, o deslocamento ocorre em sentido oposto.

A variância condicional depende de ρ^2 e não do valor observado x_2 . Quanto maior $|\rho|$, menor é a variabilidade remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

obtém-se

$$E(X_1 | X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 | X_2 = x_2) = \sigma_1^2.$$

A distribuição condicional coincide, então, com a marginal. Isso é consistente com Proposição 9.7, pois, sob normalidade conjunta, $\rho = 0$ implica independência entre X_1 e X_2 .

Exemplo 9.5 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0,8,$$

e a variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = 1) &= 1 - 0,8^2 \\ &= 0,36. \end{aligned}$$

Logo,

$$X_1 | X_2 = 1 \sim N(0,8, 0,36).$$

O desvio-padrão condicional é

$$\sqrt{0,36} = 0,6.$$




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.

No primeiro painel, a linha horizontal identifica o valor condicionado $X_2 = 1$. O ponto sobre essa linha indica a média da distribuição condicional de X_1 .

O segundo painel mostra

$$X_1 \mid X_2 = 1 \sim N(0,8, 0,36).$$

Em relação à distribuição marginal $N(0,1)$, a média passa de 0 para 0,8 e a variância passa de 1 para 0,36. O exemplo ilustra duas propriedades gerais: a média condicional depende do valor condicionado, enquanto a matriz de covariâncias condicional não depende desse valor.

O branqueamento desenvolvido anteriormente permite agora obter uma segunda consequência probabilística da normalidade: a distribuição exata da distância quadrática de Mahalanobis.

9.5 Distância de Mahalanobis e regiões de probabilidade

O Capítulo 8 definiu na Definição 8.9 a distância de Mahalanobis como uma medida geométrica adaptada à estrutura de covariâncias. Quando o vetor segue uma distribuição normal multivariada não singular, a distância quadrática ao vetor de médias possui uma distribuição probabilística conhecida.

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A variável aleatória

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \quad (9.45)$$

representa a distância quadrática de Mahalanobis entre uma realização aleatória e o centro populacional.

9.5.1 Distribuição qui-quadrado

Proposição 9.9 (Distribuição da distância quadrática de Mahalanobis). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0},$$

então

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2. \quad (9.46)$$

Comprovação. Pelo branqueamento na Equação 9.25,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

As componentes

$$Z_1, \dots, Z_p$$

são, portanto, normais padrão independentes.

Além disso,

$$\begin{aligned}
D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\
&= \left[\Sigma^{-1/2} (\mathbf{X} - \mu) \right]^\top \left[\Sigma^{-1/2} (\mathbf{X} - \mu) \right] \\
&= \mathbf{Z}^\top \mathbf{Z} \\
&= \sum_{j=1}^p Z_j^2.
\end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Logo,

$$D_M^2 \sim \chi_p^2.$$

□

Os graus de liberdade correspondem à dimensão efetiva da distribuição. No caso não singular, essa dimensão é p .

Consequentemente,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \quad (9.47)$$

A escala de D_M^2 depende, portanto, da dimensão. Sob o modelo normal, seu valor esperado é p , e não zero.

A igualdade

$$E(D_M^2) = p$$

não depende da normalidade multivariada. No Capítulo 8, Equação 8.53 obteve esse resultado a partir apenas da estrutura de segunda ordem, para qualquer vetor aleatório com vetor de médias μ e matriz de covariâncias positiva definida Σ .

A hipótese de normalidade fornece um resultado mais forte:

$$D_M^2 \sim \chi_p^2.$$

Assim, no presente capítulo, além do valor esperado, passa-se a conhecer a distribuição completa da distância quadrática de Mahalanobis, incluindo sua variância e seus quantis.

No espaço branqueado,

$$D_M^2 = \|\mathbf{Z}\|^2.$$

Assim, a distância quadrática de Mahalanobis no espaço original corresponde ao quadrado da distância euclidiana à origem no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado

$$D_M^2 \sim \chi_p^2$$

utiliza os parâmetros populacionais μ e Σ .

Se esses parâmetros forem substituídos por estimativas obtidas a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 .

A distinção entre parâmetros conhecidos e estimados será desenvolvida nos Capítulos 10 e 12.

9.5.2 Regiões elipsoidais de probabilidade

Seja

$$\chi_{p;1-\alpha}^2$$

o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com p graus de liberdade, isto é,

$$P(\chi_p^2 \leq \chi_{p;1-\alpha}^2) = 1 - \alpha.$$

Definição 9.3 (Região elipsoidal de probabilidade). Para

$$0 < \alpha < 1,$$

define-se

$$\mathcal{E}_{1-\alpha} = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p;1-\alpha}^2 \right\}. \quad (9.48)$$

Pela Proposição 9.9,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P[D_M^2 \leq \chi_{p;1-\alpha}^2] \\ &= P[\chi_p^2 \leq \chi_{p;1-\alpha}^2] \\ &= 1 - \alpha. \end{aligned} \tag{9.49}$$

Portanto, $\mathcal{E}_{1-\alpha}$ é uma região populacional que contém uma realização de $\mathbf{X}$ com probabilidade $1 - \alpha$.

Sua fronteira é

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p;1-\alpha}^2.$$

A geometria é a mesma dos elipsoides de Mahalanobis definidos na Equação 8.32 no Capítulo 8. A novidade do modelo normal é a calibração probabilística da constante. Como naquele capítulo o elipsoide foi definido por

$$d_M^2(\mathbf{x}, \mu) \leq c^2,$$

a região de probabilidade $1 - \alpha$ é obtida fazendo

$$c^2 = \chi_{p;1-\alpha}^2,$$

ou, equivalentemente,

$$c = \sqrt{\chi_{p;1-\alpha}^2}.$$

No espaço branqueado, a região corresponde à esfera

$$\{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p;1-\alpha}^2\},$$

de raio

$$\sqrt{\chi_{p;1-\alpha}^2}.$$

As superfícies de igual densidade e as fronteiras das regiões elipsoidais de probabilidade possuem a mesma forma geométrica porque ambas são determinadas por valores constantes de d_M^2 . A diferença está na escolha da constante: nas regiões de probabilidade, ela é determinada por um quantil da distribuição χ_p^2 .

Região de probabilidade e região de confiança

A região

$$\mathcal{E}_{1-\alpha}$$

refere-se à posição de uma **realização de $\mathbf{X}$** quando os parâmetros populacionais μ e Σ são conhecidos.

Ela não é uma região de confiança para μ .

Regiões de confiança para parâmetros populacionais serão construídas no Capítulo 12 a partir de distribuições amostrais.

9.5.3 Avaliação de uma observação fixa

Considere agora um ponto fixo

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.50)$$

O ponto está dentro de $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p;1-\alpha}^2. \quad (9.51)$$

Se

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p;1-\alpha}^2,$$

a observação está fora da região que contém probabilidade populacional $1 - \alpha$.

Essa comparação descreve a posição de um valor já observado em relação ao modelo. Depois que $\mathbf{x}_0$ foi fixado, não se atribui a ele probabilidade de pertencer à região: ele está dentro ou fora dela.

Também pode ser calculada a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)]. \quad (9.52)$$

A quantidade p_M mede, sob o modelo populacional completamente especificado, a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada.

Um valor pequeno indica que $\mathbf{x}_0$ se encontra em uma região de afastamentos pouco frequentes sob a distribuição especificada. Essa interpretação depende de μ e Σ serem parâmetros populacionais conhecidos e não constitui, neste ponto, um procedimento inferencial para detecção de observações atípicas com parâmetros estimados.

Exemplo 9.6 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix}.$$

Logo,

$$\begin{aligned} d_M^2(\mathbf{x}_0, \mu) &= \begin{bmatrix} 3 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\ &= \frac{7}{3} \\ &\approx 2,33. \end{aligned}$$

Para a região que contém probabilidade 0,95,

$$\chi_{2;0,95}^2 \approx 5,99.$$

Como

$$2,33 < 5,99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

A probabilidade de cauda associada à distância observada é

$$p_M = P(\chi_2^2 \geq 2,33) \\ \approx 0,31.$$

Assim, aproximadamente 31% dos vetores gerados pelo modelo apresentam distância quadrática de Mahalanobis ao centro pelo menos tão grande quanto a observada. O ponto, portanto, não apresenta um afastamento particularmente extremo em relação à distribuição especificada.

O exemplo utiliza parâmetros populacionais conhecidos. Se o vetor de médias e a matriz de covariâncias fossem substituídos por estimativas amostrais, seria necessário utilizar a teoria inferencial apropriada.

9.5.4 Aprofundamento: caso singular

Leitura de aprofundamento

Quando Σ é singular, a inversa ordinária não existe e a distribuição está concentrada em um subespaço afim. A pseudoinversa permite definir a forma de Mahalanobis no espaço efetivo da distribuição.

Os graus de liberdade deixam de ser p e passam a corresponder ao posto de Σ .

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\text{posto}(\Sigma) = r < p.$$

Define-se a forma generalizada de Mahalanobis por

$$D_{M,+}^2 = (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu). \quad (9.53)$$

Proposição 9.10 (Forma generalizada de Mahalanobis no caso normal singular). *Se*

$$1 \leq r = \text{posto}(\Sigma) < p,$$

então

$$D_{M,+}^2 \sim \chi_r^2. \quad (9.54)$$

Comprovação. Considere a decomposição espectral reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pelo branqueamento reduzido na Equação 9.27,

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu) \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A pseudoinversa de Σ é

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente,

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r \\ &= \sum_{j=1}^r Z_{rj}^2. \end{aligned}$$

As componentes de $\mathbf{Z}_r$ são normais padrão independentes. Portanto,

$$\mathbf{Z}_r^\top \mathbf{Z}_r \sim \chi_r^2.$$

□

Consequentemente,

$$E(D_{M,+}^2) = r$$

e

$$\text{Var}(D_{M,+}^2) = 2r.$$

Assim, no caso singular, a escala da forma generalizada de Mahalanobis é determinada pela dimensão efetiva r da distribuição, e não pela dimensão ambiente p .

Uma região de probabilidade $1 - \alpha$ no suporte efetivo pode ser definida por

$$\mathcal{E}_{1-\alpha}^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r;1-\alpha}^2 \right\}. \quad (9.55)$$

Pela Proposição 9.10,

$$P[\mathbf{X} \in \mathcal{E}_{1-\alpha}^{(r)}] = 1 - \alpha.$$

A calibração utiliza a dimensão efetiva r , e não a dimensão ambiente p .

Se

$$r = 0,$$

então

$$\Sigma = \mathbf{0}$$

e

$$\mathbf{X} = \mu$$

quase certamente. Nesse caso extremo, a distribuição está concentrada em um único ponto.

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição singular atribui probabilidade 1 ao seu suporte afim.

Os resultados desta seção mostram a passagem da geometria da distância de Mahalanobis e de seus elipsoides, desenvolvida na Definição 8.9 e Equação 8.32 no Capítulo 8, para uma interpretação probabilística. Na família normal, a forma quadrática de Mahalanobis possui uma distribuição conhecida, e os elipsoides podem ser calibrados por probabilidades populacionais.

A comparação entre duas distribuições normais permite observar, em seguida, como mudanças no vetor de médias e na matriz de covariâncias modificam suas posições, formas e densidades. Essa comparação será utilizada somente como motivação para técnicas de discriminação desenvolvidas posteriormente.

9.6 Comparação entre distribuições normais

Considere duas populações descritas por distribuições normais multivariadas:

$$\mathbf{X}_1 \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{X}_2 \sim N_p(\mu_2, \Sigma_2),$$

com

$$\Sigma_1 \succ \mathbf{0} \quad \text{e} \quad \Sigma_2 \succ \mathbf{0}.$$

Os vetores de médias determinam a localização das distribuições, enquanto as matrizes de covariâncias determinam sua dispersão, orientação e forma. A comparação entre duas distribuições normais permite observar como esses dois componentes da parametrização atuam conjuntamente.

9.6.1 Médias distintas e covariância comum

Suponha

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As duas distribuições possuem superfícies de igual densidade com a mesma forma, orientação e extensão, mas centradas em pontos diferentes.

Pela log-densidade na Equação 9.13, ambas contêm o termo quadrático

$$-\frac{1}{2}\mathbf{x}^\top \Sigma^{-1} \mathbf{x}.$$

Ao comparar as duas log-densidades, esse termo é comum e se cancela. De fato,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \end{aligned} \tag{9.56}$$

A log-razão entre as densidades é, portanto, uma função afim de $\mathbf{x}$.

Consequentemente, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : f_1(\mathbf{x}) = f_2(\mathbf{x})\}$$

é um hiperplano.

A matriz de covariâncias comum influencia a orientação desse hiperplano por meio do vetor

$$\Sigma^{-1} (\mu_1 - \mu_2),$$

que determina sua direção normal. Assim, a separação entre os centros é avaliada segundo a geometria induzida pela matriz de covariâncias comum.

9.6.2 Covariâncias distintas

Considere agora

$$\Sigma_1 \neq \Sigma_2.$$

As distribuições podem diferir não somente quanto à localização, mas também quanto à forma, orientação e extensão de suas superfícies de igual densidade.

Nesse caso, as log-densidades envolvem as formas quadráticas

$$-\frac{1}{2} (\mathbf{x} - \mu_1)^\top \Sigma_1^{-1} (\mathbf{x} - \mu_1)$$

e

$$-\frac{1}{2} (\mathbf{x} - \mu_2)^\top \Sigma_2^{-1} (\mathbf{x} - \mu_2).$$

Como as matrizes inversas são diferentes, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral. Expandindo a diferença entre as log-densidades,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2} \mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x} \\ &\quad + \mathbf{x}^\top (\Sigma_1^{-1} \mu_1 - \Sigma_2^{-1} \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma_1^{-1} \mu_1 - \mu_2^\top \Sigma_2^{-1} \mu_2) \\ &\quad - \frac{1}{2} \log \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right). \end{aligned} \tag{9.57}$$

A presença do termo

$$\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x}$$

faz com que a log-razão seja, em geral, uma função quadrática de $\mathbf{x}$.

Assim, o conjunto de pontos nos quais

$$f_1(\mathbf{x}) = f_2(\mathbf{x})$$

é determinado, em geral, por uma equação quadrática em $\mathbf{x}$. Sua geometria pode, portanto, diferir substancialmente do hiperplano obtido no caso de covariância comum.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

A Figura 9.3 ilustra as duas situações.

No primeiro painel, as duas distribuições apresentam superfícies de nível com a mesma forma e orientação, deslocadas para centros diferentes. No segundo, as diferenças entre as matrizes de covariâncias modificam também a extensão e a orientação dessas superfícies.

A comparação mostra duas estruturas algébricas que serão utilizadas posteriormente. Com uma matriz de covariâncias comum, a comparação das log-densidades elimina os termos quadráticos comuns e produz uma expressão afim. Com matrizes de covariâncias distintas, permanecem, em geral, termos quadráticos.

Esses resultados serão retomados na formulação da Análise Discriminante. A construção de regras de classificação, probabilidades a priori, custos de decisão e estimação dos parâmetros pertence aos módulos posteriores.

9.7 Alcance da hipótese de normalidade

A distribuição normal multivariada acrescenta uma estrutura probabilística específica aos objetos desenvolvidos nos capítulos anteriores. É importante distinguir quais resultados dependem dessa hipótese e quais permanecem válidos para vetores aleatórios mais gerais.

9.7.1 Resultados que não exigem normalidade

Diversos resultados utilizados neste capítulo dependem somente da existência dos momentos necessários.

Para um vetor aleatório com média μ e matriz de covariâncias Σ ,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}$$

não exigem normalidade.

Da mesma forma, para

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

as relações

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

são propriedades gerais dos primeiros e segundos momentos.

A matriz de covariâncias continua simétrica e positiva semidefinida, conforme Proposição 8.2; a distância de Mahalanobis continua definindo a geometria apresentada na Definição 8.9 quando a matriz de covariâncias é positiva definida; e o complemento de Schur continua representando a covariância do resíduo do melhor ajuste linear entre blocos, conforme Proposição 8.5. Esses resultados foram desenvolvidos no Capítulo 8 sem hipótese de normalidade.

Também não depende da normalidade a esperança de uma forma quadrática centrada. Para uma matriz simétrica $\mathbf{A}$,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A}(\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A}(\mu - \mathbf{a}),$$

desde que existam os momentos de segunda ordem necessários.

Em particular, quando $\Sigma \succ \mathbf{0}$,

$$E \left[(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \right] = p.$$

Portanto, o valor esperado da distância quadrática de Mahalanobis é uma propriedade de segunda ordem e não uma consequência específica da normalidade.

Esses resultados descrevem estruturas de primeira e segunda ordem. Eles não determinam, por si mesmos, a distribuição conjunta.

9.7.2 Resultados específicos da família normal

A hipótese de normalidade conjunta produz propriedades adicionais.

Entre os resultados desenvolvidos neste capítulo estão:

- o vetor de médias e a matriz de covariâncias determinam completamente a distribuição;
- no caso singular, o suporte da distribuição é o subespaço afim $\mu + \mathcal{C}(\Sigma)$;
- transformações afins preservam a família normal;
- distribuições marginais de subvectores permanecem normais;
- covariância cruzada nula entre blocos conjuntamente normais equivale à independência;
- distribuições condicionais permanecem normais;
- a esperança condicional entre blocos é uma função afim do bloco condicionante;
- a matriz de covariâncias condicional é o complemento de Schur correspondente;
- o branqueamento de uma normal não singular produz componentes normais padrão independentes;
- a distância quadrática de Mahalanobis populacional possui distribuição χ_p^2 no caso não singular;
- no caso singular, a forma construída com a pseudoinversa possui distribuição χ_r^2 , em que r é o posto da matriz de covariâncias.

A equivalência

$$\Sigma_{12} = \mathbf{0} \quad \Longleftrightarrow \quad \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo da diferença entre uma propriedade geral de covariância e uma propriedade específica da família normal.

A implicação

$$\mathbf{X}_1 \perp \mathbf{X}_2 \quad \Longrightarrow \quad \Sigma_{12} = \mathbf{0}$$

vale, quando os segundos momentos existem, sem normalidade. A implicação inversa requer a estrutura normal conjunta estabelecida na Proposição 9.7.

De maneira semelhante, a igualdade

$$E(D_M^2) = p$$

decorre apenas da estrutura de segunda ordem, mas a afirmação

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

é específica do modelo normal multivariado não singular.

Assim, conhecer apenas μ e Σ permite determinar a esperança dessa forma quadrática, mas não sua distribuição completa. A distribuição qui-quadrado estabelecida na Proposição 9.9 depende da normalidade multivariada.

Assim, a normalidade transforma relações entre médias, covariâncias e formas quadráticas em afirmações sobre distribuições completas.

9.7.3 Passagem do modelo populacional para a inferência

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais conhecidos. Essa escolha permitiu estudar diretamente as propriedades da distribuição

$$N_p(\mu, \Sigma).$$

Em uma aplicação estatística, esses parâmetros são geralmente desconhecidos. A observação de uma amostra introduz uma nova distinção entre:

- parâmetros populacionais;
- estatísticas aleatórias;
- estimadores;
- valores calculados a partir dos dados observados.

Essa distinção modifica alguns resultados. Por exemplo,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não autoriza substituir diretamente μ e Σ por estimativas e manter a mesma distribuição.

Da mesma forma, conhecer a forma da densidade normal não é suficiente para realizar inferência sobre parâmetros desconhecidos. É necessário especificar uma amostra aleatória, construir estatísticas e estudar suas propriedades e distribuições amostrais.

O Capítulo 10 inicia essa passagem. O modelo probabilístico permanece o ponto de partida, mas os parâmetros deixam de ser tratados como conhecidos e passam a ser inferidos a partir dos dados.

9.8 Síntese do capítulo

A distribuição normal multivariada estabelece um modelo probabilístico para um vetor aleatório em que a estrutura conjunta é completamente determinada pelo vetor de médias e pela matriz de covariâncias.

A Tabela 9.1 reúne os principais resultados.

Tabela 9.1: Principais estruturas e resultados da distribuição normal multivariada.

Estrutura	Resultado
Definição	$\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a} \in \mathbb{R}^p$
Parametrização	$\mathbf{X} \sim N_p(\mu, \Sigma)$ é determinada por μ e Σ
Construção	$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}$, com $\Sigma = \mathbf{A}\mathbf{A}^\top$
Caso singular	o suporte é $\mu + \mathcal{C}(\Sigma)$
Caso não singular	existe densidade em $\mathbb{R}^p$ quando $\Sigma \succ \mathbf{0}$
Transformação afim	$\mathbf{A}\mathbf{X} + \mathbf{b}$ permanece normal
Marginalização	subvectores de um vetor normal multivariado permanecem normais
Independência	$\Sigma_{12} = \mathbf{0}$ equivale à independência entre blocos conjuntamente normais
Condicionamento	a distribuição condicional é normal, com média afim e covariância dada por complemento de Schur
Branqueamento	no caso não singular, produz $N_p(\mathbf{0}, \mathbf{I}_p)$
Mahalanobis	$D_M^2 \sim \chi_p^2$ no caso não singular
Regiões de probabilidade	$D_M^2 \leq \chi_{p;1-\alpha}^2$ define uma região populacional de probabilidade $1 - \alpha$
Caso singular de Mahalanobis	$D_{M,+}^2 \sim \chi_r^2$, com $r = \text{posto}(\Sigma)$
Comparação de distribuições	covariância comum produz log-razão afim; covariâncias distintas produzem, em geral, log-razão quadrática

A definição por combinações lineares fornece a caracterização probabilística da família. Para cada $\mathbf{a} \in \mathbb{R}^p$, a projeção

$$\mathbf{a}^\top \mathbf{X}$$

é completamente determinada por

$$\mathbf{a}^\top \boldsymbol{\mu}$$

e

$$\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}.$$

Assim, o vetor de médias e a matriz de covariâncias determinam as distribuições de todas as projeções unidimensionais. Pelo Teorema de Cramér–Wold, essas projeções determinam a distribuição conjunta.

A representação

$$\mathbf{X} \stackrel{d}{=} \boldsymbol{\mu} + \mathbf{A}\mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

com

$$\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top,$$

conecta a distribuição normal multivariada às transformações afins e à decomposição da matriz de covariâncias.

Quando

$$\text{posto}(\boldsymbol{\Sigma}) < p,$$

a distribuição é singular e permanece concentrada em um subespaço afim. Quando

$$\boldsymbol{\Sigma} \succ \mathbf{0},$$

a distribuição possui densidade em todo $\mathbb{R}^p$, cujas superfícies de igual densidade são determinadas pela distância de Mahalanobis.

As propriedades de transformação e marginalização preservam a família normal. A normalidade conjunta também estabelece a equivalência entre independência e covariância cruzada nula

e fornece distribuições condicionais normais. Nesse contexto, o complemento de Schur deixa de representar somente uma covariância residual linear e passa a ser exatamente a matriz de covariâncias condicional.

No caso não singular, o branqueamento transforma o vetor em

$$N_p(\mathbf{0}, \mathbf{I}_p),$$

e a forma quadrática

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu)$$

possui distribuição χ_p^2 . Esse resultado atribui uma calibração probabilística aos elipsoides de Mahalanobis desenvolvidos geometricamente na Equação 8.32 no Capítulo 8.

O Capítulo 8 já havia mostrado na Equação 8.53, sem hipótese de normalidade, que a esperança dessa forma quadrática é p . A normalidade acrescenta a distribuição completa χ_p^2 , permitindo definir regiões de probabilidade por seus quantis.

Ao término deste capítulo, deve-se ser capaz de:

- caracterizar uma distribuição normal multivariada por combinações lineares;
- construir vetores normais por transformações afins de vetores normais padrão;
- distinguir distribuições normais singulares e não singulares;
- identificar o suporte efetivo de uma normal singular;
- interpretar a densidade normal multivariada e suas superfícies de nível;
- obter distribuições de transformações afins, combinações lineares e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância cruzada nula e independência sob normalidade conjunta;
- determinar média e matriz de covariâncias de uma distribuição condicional;
- interpretar o complemento de Schur como covariância condicional;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis populacional e interpretar regiões elipsoidais de probabilidade;
- comparar distribuições normais com covariância comum e com covariâncias distintas por meio de suas log-densidades;
- distinguir resultados gerais de segunda ordem daqueles que dependem da normalidade.

Neste capítulo, μ e Σ foram considerados parâmetros populacionais conhecidos. O Capítulo 10 introduz a amostra aleatória multivariada e distingue parâmetros, estatísticas, estimadores e estimativas. Essa passagem permite estudar como o vetor de médias e a matriz de covariâncias podem ser estimados a partir dos dados e quais propriedades podem ser atribuídas aos respectivos estimadores.

10 Estatísticas Amostrais e Estimação

O Capítulo 8 desenvolveu o vetor de médias populacional na Equação 8.1 e a matriz de covariâncias populacional na Definição 8.2. O Capítulo 9, por sua vez, formulou a distribuição normal multivariada na Definição 9.1. Até esse ponto, μ e Σ foram tratados como parâmetros populacionais. Em uma aplicação estatística, esses parâmetros geralmente são desconhecidos e precisam ser estimados a partir de uma amostra.

O objetivo deste capítulo é passar dos objetos populacionais às estatísticas definidas sobre uma amostra multivariada e estudar sua utilização como estimadores. Serão desenvolvidos o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados (SQPC), os estimadores da matriz de covariâncias, a matriz de correlações amostral e as covariâncias cruzadas entre blocos de variáveis.

Os métodos dos momentos e da máxima verossimilhança serão utilizados como princípios de construção de estimadores. As propriedades matemáticas e os resultados de cálculo matricial estabelecidos no Módulo 1 serão retomados somente quando necessários.

As distribuições amostrais exatas, a distribuição de Wishart, a independência entre o vetor de médias e a matriz de covariâncias amostrais sob normalidade e os procedimentos de inferência serão desenvolvidos no Capítulo 12. Neste capítulo, o objetivo é construir os principais estimadores de localização, dispersão e associação, estudar suas propriedades e examinar limitações associadas ao tamanho amostral e à dimensão.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório populacional;
- $\mathbf{X}_1, \dots, \mathbf{X}_n$ representam os vetores aleatórios que compõem a amostra;
- $\mathbf{x}_1, \dots, \mathbf{x}_n$ representam suas realizações;
- $\mathcal{X} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória da amostra;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa a matriz de dados observada;
- μ , Σ e $\mathcal{R}$ representam, respectivamente, o vetor de médias, a matriz de covariâncias e a matriz de correlações populacionais;
- $\bar{\mathbf{X}}$ representa o vetor de médias amostrais como estatística aleatória, enquanto $\bar{\mathbf{x}}$ representa seu valor observado;
- $\mathbf{T}$ representa a matriz total de somas de quadrados e produtos cruzados (SQPC) como estatística aleatória, e $\mathbf{T}$ sua realização observada, definida na Definição 8.10;

- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória, e $\mathbf{S}$ seu valor observado;
- $\mathbf{R}$ representa a matriz de correlações amostral como estatística aleatória, e $\mathbf{R}$ seu valor observado;
- $\mathbf{T}_{jk}$, $\mathbf{S}_{jk}$ e $\mathbf{R}_{jk}$ representam elementos das respectivas matrizes aleatórias, enquanto t_{jk} , s_{jk} e r_{jk} representam seus valores observados;
- $\mathbf{G} = G(\mathcal{X})$ será utilizada como notação genérica para uma estatística, evitando conflito com o símbolo $\mathbf{T}$ reservado à matriz SQPC;
- $\hat{\theta}$ representa um estimador de um parâmetro θ , e $\hat{\theta}_{\text{obs}}$ o valor assumido pelo estimador após a observação da amostra.

A convenção $\mathbf{T}$ para a matriz SQPC observada mantém a notação estabelecida na Definição 8.10.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordem, o vetor de médias e a matriz de covariâncias definidos na Equação 8.1 e Definição 8.2 satisfazem

$$E(\mathbf{X}) = \mu \in \mathbb{R}^p$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma \in \mathbb{R}^{p \times p}.$$

Os parâmetros são características fixas da distribuição populacional. A aleatoriedade introduzida pelo processo de amostragem está nos vetores que compõem a amostra e, consequentemente, nas estatísticas definidas a partir deles.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e identicamente distribuídos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A notação

$$\stackrel{\text{iid}}{\sim}$$

indica que os vetores aleatórios são independentes e identicamente distribuídos segundo a mesma distribuição.

A condição de distribuição idêntica estabelece que todas as unidades são regidas pela mesma distribuição populacional. A independência estabelece que a realização de uma unidade não altera a distribuição das demais unidades.

Quando a distribuição populacional possui densidade em relação a uma medida comum, a independência implica

$$f_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_\theta(\mathbf{x}_i). \quad (10.2)$$

A independência também implica a fatoração da função de distribuição conjunta da amostra:

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.3)$$

Essas fatorações dizem respeito à independência **entre unidades amostrais**. A dependência entre as componentes de um mesmo vetor continua representada pela distribuição multivariada F_θ .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j na unidade i .

A independência entre

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre

$$X_{i1}, \dots, X_{ip}.$$

As componentes de uma mesma unidade podem apresentar covariâncias e outras formas de dependência.

Quando os segundos momentos existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_\ell) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No modelo normal multivariado definido na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A definição do vetor de médias amostrais, da matriz SQPC, da matriz de covariâncias amostral e da matriz de correlações amostral não exige normalidade. Neste capítulo, a hipótese normal será utilizada especificamente na obtenção dos estimadores de máxima verossimilhança de μ e Σ . As distribuições amostrais exatas e os resultados inferenciais associados serão desenvolvidos no Capítulo 12.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra, uma realização de $\mathcal{X}$ é denotada por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.6)$$

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é a matriz aleatória da amostra;
- $\mathbf{X}$ é a matriz de dados observada;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;
- $\mathbf{x}_i$ é sua realização;
- X_{ij} é uma variável aleatória;
- x_{ij} é o valor observado correspondente.

Se o suporte de $\mathbf{X}$ é

$$\mathcal{S}_{\mathbf{X}} \subseteq \mathbb{R}^p,$$

o espaço das possíveis amostras é

$$\mathcal{S}_{\mathbf{X}}^n.$$

No caso em que

$$\mathcal{S}_{\mathbf{X}} = \mathbb{R}^p,$$

esse espaço pode ser identificado com

$$(\mathbb{R}^p)^n$$

ou, equivalentemente, com o conjunto das matrizes reais $n \times p$.

Uma estatística associa a cada possível realização da amostra uma quantidade escalar, vetorial ou matricial. Antes da observação da amostra, ela constitui um objeto aleatório; após a observação, obtém-se seu valor calculado a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

Neste capítulo, as principais quantidades populacionais de interesse são o vetor de médias μ , definido na Equação 8.1, a matriz de covariâncias Σ , definida na Definição 8.2, e a matriz de correlações $\mathcal{R}$, definida na Definição 8.5.

A matriz $\mathcal{R}$ é determinada por Σ e, portanto, não constitui um parâmetro adicional quando a matriz de covariâncias já integra a parametrização do modelo.

No modelo normal multivariado não singular definido na Definição 9.1, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Uma estatística é uma função da amostra aleatória que não contém parâmetros desconhecidos em sua expressão. De forma genérica, será representada por

$$\mathbf{G} = G(\mathcal{X}). \tag{10.7}$$

A estatística pode assumir valores escalares, vetoriais ou matriciais.

Embora a expressão da estatística não contenha parâmetros desconhecidos, sua distribuição amostral pode depender dos parâmetros da distribuição populacional.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i. \quad (10.8)$$

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de uma estatística é denominada **distribuição amostral**. Ela descreve como a estatística varia entre as possíveis realizações da amostra aleatória de tamanho n .

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_\theta$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{G} = G(\mathcal{X})$$

descreve a variabilidade da estatística entre as possíveis realizações da amostra.

A distribuição populacional e a distribuição amostral correspondem, portanto, a objetos probabilísticos distintos. O Capítulo 12 estudará distribuições amostrais específicas das estatísticas introduzidas neste capítulo.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Um estimador de um parâmetro θ é uma estatística

$$\hat{\theta} = G(\mathcal{X}) \quad (10.10)$$

utilizada para estimar θ .

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X}). \quad (10.11)$$

Todo estimador é uma estatística, mas nem toda estatística precisa ser utilizada para estimar um parâmetro. A função atribuída à estatística depende do objetivo da análise.

Assim,

$$\bar{\mathbf{X}}$$

é um estimador de μ , enquanto

$$\bar{\mathbf{x}}$$

é a estimativa obtida para uma amostra específica.

Mais adiante, a matriz de covariâncias amostral

$$\mathbf{S}$$

será definida como estimador de Σ , enquanto

$$\mathbf{s}$$

representará sua realização observada.

O erro de estimação é

$$\hat{\theta} - \theta. \quad (10.12)$$

Como o estimador é uma função da amostra aleatória, o erro de estimação também é aleatório. Sua distribuição permite avaliar propriedades do procedimento de estimação.

Um mesmo parâmetro pode possuir diferentes estimadores. Para Σ , por exemplo, serão estudados o estimador não viesado

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e, sob o modelo normal multivariado, o estimador de máxima verossimilhança

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T},$$

ambos construídos a partir da matriz SQPC $\mathbf{T}$ definida na Definição 8.10.

A estimação pontual utiliza uma estimativa única para representar o parâmetro. A estimação por regiões utiliza conjuntos construídos para quantificar a incerteza associada ao processo amostral. Neste capítulo será desenvolvida a estimação pontual. As regiões de confiança serão tratadas no Capítulo 12.

A comparação entre estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência e equivariância serão examinados a seguir. Questões de sensibilidade e robustez serão retomadas posteriormente como aprofundamento.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem estimar o mesmo parâmetro e apresentar comportamentos distintos ao longo das possíveis amostras.

Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = G(\mathcal{X}) \in \mathbb{R}^r.$$

A avaliação de $\hat{\theta}$ depende de sua distribuição amostral e do critério utilizado para comparar procedimentos. Viés, variabilidade, erro quadrático médio e comparações de eficiência podem ser considerados para um tamanho amostral fixo. A consistência e a eficiência assintótica tratam do comportamento de sequências de estimadores quando n aumenta. A suficiência examina a informação preservada pela redução da amostra, enquanto a equivariância descreve a coerência do procedimento sob transformações (Casella; Berger, 2002). Questões de sensibilidade e robustez serão tratadas posteriormente como aprofundamento.

10.2.1 Viés e variabilidade

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés (*Bias* em inglês) de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é

$$E(\hat{\theta}_j) - \theta_j.$$

A ausência de viés descreve o comportamento médio do procedimento sobre as possíveis amostras. Ela não garante que uma estimativa particular esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\hat{\Theta} \in \mathbb{R}^{a \times b},$$

define-se, elemento a elemento,

$$\text{Bias}(\hat{\Theta}) = E(\hat{\Theta}) - \Theta. \quad (10.14)$$

A variabilidade de um estimador vetorial é descrita por

$$\text{Cov}(\hat{\theta}) = E \left[\{ \hat{\theta} - E(\hat{\theta}) \} \{ \hat{\theta} - E(\hat{\theta}) \}^{\top} \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias de seus componentes e os elementos fora da diagonal são as covariâncias entre eles.

Para qualquer $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^{\top} \hat{\theta}) = \mathbf{a}^{\top} \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr} [\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

Essa medida-resumo depende da escala e da parametrização e não substitui a matriz de covariâncias quando a dependência entre os componentes do estimador é relevante.

Para um estimador matricial, uma representação da variabilidade é

$$\text{Cov} \left[\text{vec} \left(\widehat{\Theta} \right) \right].$$

O operador vec , definido na Definição 7.9, transforma a matriz estimada em um vetor e permite representar conjuntamente a variabilidade de todos os seus elementos.

Viés e variabilidade descrevem aspectos diferentes do desempenho de um estimador. Um procedimento pode apresentar pequeno viés e grande variabilidade, ou maior viés e menor variabilidade. Para comparar conjuntamente essas duas fontes de erro, é necessário especificar como os desvios entre estimador e parâmetro serão avaliados.

10.2.2 Erro quadrático médio e funções de perda

A comparação entre estimadores requer especificar como diferentes erros são avaliados. Essa escolha é formalizada por uma **função de perda**. Para uma perda L , o **risco** do estimador é seu valor esperado sob o parâmetro θ :

$$R(\theta, \hat{\theta}) = E_{\theta} \left[L(\hat{\theta}, \theta) \right].$$

Assim, diferentes funções de perda podem conduzir a diferentes critérios de comparação entre estimadores (Casella; Berger, 2002).

Para um estimador vetorial, considere a perda quadrática euclidiana

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.16)$$

Essa escolha atribui o mesmo peso às coordenadas na parametrização utilizada. Outros problemas podem exigir ponderações ou perdas diferentes.

Definição 10.6 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = E \left[\|\hat{\theta} - \theta\|^2 \right]. \quad (10.17)$$

Proposição 10.1 (Decomposição do erro quadrático médio). Se $\hat{\theta}$ possui segundos momentos finitos, então

$$\text{EQM}(\hat{\theta}) = \text{tr} \left[\text{Cov}(\hat{\theta}) \right] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.18)$$

Comprovação. Escreva

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + \text{Bias}(\hat{\theta}).$$

O primeiro termo possui média zero. Ao expandir o quadrado da norma e tomar esperança, o termo cruzado desaparece. Além disso,

$$E[\|\hat{\theta} - E(\hat{\theta})\|^2] = \text{tr}[\text{Cov}(\hat{\theta})].$$

Substituindo essas relações, obtém-se Equação 10.18. □

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr}[\text{Cov}(\hat{\theta})].$$

A decomposição na Equação 10.18 também pode ser vista como uma aplicação de Equação 8.38, tomando a matriz identidade e considerando $\hat{\theta}$ como vetor aleatório com média $E(\hat{\theta})$.

A ausência de viés não implica EQM mínimo. Um estimador viesado pode apresentar menor risco quadrático se a redução de variabilidade compensar o viés. Essa ideia será retomada na seção de regularização.

Para parâmetros matriciais, uma escolha correspondente é a perda baseada na norma de Frobenius definida na Definição 6.7:

$$L_F(\hat{\Theta}, \Theta) = \|\hat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\hat{\Theta}) = E[\|\hat{\Theta} - \Theta\|_F^2]. \quad (10.19)$$

Equivalentemente,

$$\begin{aligned} \text{EQM}_F(\hat{\Theta}) &= \text{tr}\{\text{Cov}[\text{vec}(\hat{\Theta})]\} \\ &\quad + \|\text{Bias}(\hat{\Theta})\|_F^2. \end{aligned} \quad (10.20)$$

A norma de Frobenius corresponde a uma escolha específica de perda. Em problemas de estimação de matrizes de covariâncias, outros critérios podem atribuir pesos diferentes a autovalores, direções ou erros de inversão.

10.2.3 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta (Vaart, 1998).

Definição 10.7 (Consistência). Uma sequência

$$\hat{\theta}_n$$

é consistente para θ quando

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (10.21)$$

quando $n \rightarrow \infty$.

A notação

$$\xrightarrow{P}$$

indica **convergência em probabilidade**. Isso significa que, para todo $\varepsilon > 0$,

$$P(\|\hat{\theta}_n - \theta\| > \varepsilon) \rightarrow 0. \quad (10.22)$$

Na formulação clássica deste capítulo, a dimensão do parâmetro é mantida fixa enquanto n aumenta. Quando a dimensão também varia com n , é necessário declarar o regime dimensional e a métrica utilizada para avaliar o erro. Essa distinção será retomada na seção de aprofundamento sobre alta dimensão.

Não viesamento e consistência descrevem propriedades diferentes. O não viesamento compara a esperança do estimador com o parâmetro para um tamanho amostral dado, enquanto a consistência descreve o que acontece com o erro de estimação quando n aumenta. Uma propriedade não deve ser interpretada como sinônimo da outra.

10.2.4 Eficiência

Para estimadores vetoriais não viesados, uma comparação natural considera suas matrizes de covariâncias. Considere dois estimadores

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2,$$

ambos não viesados para θ .

Diz-se que $\hat{\theta}_1$ é uniformemente pelo menos tão eficiente quanto $\hat{\theta}_2$, segundo a ordem de Löwner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.23)$$

Equivalentemente,

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0}.$$

Consequentemente, para todo $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2).$$

No caso vetorial, não existe necessariamente um estimador que seja mais preciso em todos os aspectos. Cada vetor $\mathbf{a} \in \mathbb{R}^r$ define uma combinação linear $\mathbf{a}^\top \hat{\theta}$ e, portanto, uma direção na qual a variabilidade dos estimadores pode ser comparada. Um estimador pode apresentar menor variabilidade em determinadas direções e maior variabilidade em outras.

A ordem de Löwner declara $\hat{\theta}_1$ pelo menos tão eficiente quanto $\hat{\theta}_2$ somente quando a desigualdade anterior vale para **todas** as direções $\mathbf{a}$. Por isso, trata-se de uma ordem parcial: podem existir duas matrizes de covariâncias para as quais nenhum dos estimadores apresenta menor variabilidade em todas as direções.

Quando duas matrizes de covariâncias não são comparáveis pela ordem de Löwner, pode-se adotar um critério escalar que resuma algum aspecto de sua variabilidade. Um exemplo é

$$\text{tr} [\text{Cov}(\hat{\theta})],$$

que soma as variâncias dos componentes do estimador. Essa escolha estabelece um critério particular de comparação; outra função de perda pode produzir uma ordenação diferente.

Para estimadores viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. É necessário considerar um risco que incorpore viés e variabilidade.

A eficiência assintótica compara as matrizes que aparecem nas distribuições-limite de sequências de estimadores. Sob condições de regularidade, estimadores de máxima verossimilhança podem atingir limites associados à informação de Fisher definida na Definição 7.18. Os resultados assintóticos correspondentes não serão desenvolvidos neste capítulo e serão retomados no contexto inferencial do Capítulo 12.

10.2.5 Suficiência

Uma estatística suficiente resume a amostra sem perder informação sobre o parâmetro no modelo considerado. Depois de conhecida essa estatística, a distribuição condicional dos dados restantes não depende do parâmetro (Casella; Berger, 2002).

Definição 10.8 (Estatística suficiente). Considere uma amostra aleatória $\mathcal{X}$ cuja distribuição depende de um parâmetro populacional θ , e uma estatística definida pela regra

$$\mathbf{G} = G(\mathcal{X}).$$

A estatística $\mathbf{G}$ é **suficiente para θ** quando a distribuição condicional da amostra $\mathcal{X}$, dado o valor de $\mathbf{G}$, não depende de θ .

Assim, G é a regra que reduz a amostra à estatística $\mathbf{G}$, enquanto θ é o parâmetro populacional sobre o qual se deseja preservar informação.

A suficiência pode ser entendida como uma redução dos dados sem perda de informação sobre θ no contexto do modelo considerado. Isso não significa que seja possível reconstruir a amostra original a partir de $\mathbf{G}$, mas que a parte da amostra não representada por $\mathbf{G}$ deixa de depender do parâmetro.

A definição de suficiência é formulada em termos de uma distribuição condicional, que nem sempre é a forma mais conveniente para verificar a propriedade diretamente. Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério equivalente baseado na forma da densidade ou da função de probabilidade conjunta.

Teorema 10.1 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família dominada por uma medida comum, com densidade ou função de probabilidade conjunta*

$$f_{\theta}(\mathbf{x}), \quad \theta \in \Theta.$$

A estatística

$$G(\mathbf{x})$$

é suficiente para θ se, e somente se, existem funções não negativas q_θ e r tais que

$$f_\theta(\mathbf{x}) = q_\theta[G(\mathbf{x})] r(\mathbf{x}), \quad (10.24)$$

em que q_θ contém a dependência em relação ao parâmetro por meio da estatística $G(\mathbf{x})$, enquanto $r(\mathbf{x})$ não depende de θ .

A fatoração separa a densidade conjunta em duas partes. A primeira,

$$q_\theta[G(\mathbf{x})],$$

contém toda a dependência em relação a θ e utiliza os dados somente por meio de $G(\mathbf{x})$. A segunda,

$$r(\mathbf{x}),$$

pode depender da amostra completa, mas não depende do parâmetro. Por isso, para estudar θ , a informação contida nos dados entra na verossimilhança por meio da estatística suficiente.

No modelo normal multivariado definido na Definição 9.1, o vetor de médias amostrais e a matriz SQPC formam conjuntamente uma estatística suficiente para μ e Σ (Anderson, 2003).

Proposição 10.2 (Suficiência no modelo normal multivariado). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

Defina o vetor de médias amostrais

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$$

e a matriz SQPC

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^\top. \quad (10.25)$$

Nesse caso, a regra

$$G(\mathcal{X}) = (\bar{\mathbf{X}}, \mathbf{T})$$

reduz a amostra completa ao vetor de médias amostrais e à matriz SQPC. A estatística

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para o parâmetro

$$(\mu, \Sigma).$$

Comprovação. Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}.$$

A identidade de decomposição em torno da média fornece

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top, \end{aligned}$$

em que $\mathbf{T}$ é a matriz SQPC observada definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, toda a dependência da densidade conjunta em relação a μ e Σ ocorre por meio de

$$(\bar{\mathbf{x}}, \mathbf{T}).$$

O resultado segue de Teorema 10.1. □

A suficiência não implica, por si só, ausência de viés, consistência ou eficiência. Ela descreve a quantidade de informação sobre o parâmetro preservada pela estatística, e não a qualidade de um estimador construído a partir dela. Sob o modelo considerado, reduzir a amostra a uma estatística suficiente não elimina informação sobre θ .

10.2.6 Equivariância

Uma transformação dos dados pode induzir uma transformação correspondente no parâmetro. Um procedimento equivariante respeita essa relação.

Definição 10.9 (Equivariância de um estimador). Considere um parâmetro populacional θ e um estimador definido pela regra

$$\hat{\theta} = G(\mathcal{X}).$$

Se h transforma a amostra e essa transformação induz uma transformação correspondente g no parâmetro populacional,

$$\theta \mapsto g(\theta),$$

o estimador é **equivariante** quando aplicar G aos dados transformados produz o mesmo resultado que transformar, por g , o estimador obtido com os dados originais:

$$G[h(\mathcal{X})] = g[G(\mathcal{X})]. \quad (10.26)$$

Assim, G representa a regra de estimação, h a transformação aplicada aos dados e g a transformação correspondente no parâmetro.

As funções h e g não precisam ser iguais, pois atuam sobre objetos diferentes. A função h especifica como os dados são transformados, enquanto g descreve como o parâmetro de interesse se transforma em consequência dessa transformação. Para uma mesma transformação h dos dados, a forma de g pode mudar conforme o parâmetro considerado.

Considere, por exemplo, a transformação afim dos dados

$$h : \mathbf{X}_i \mapsto \mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

Nesse caso, h é a transformação aplicada a cada vetor observado da amostra.

Para o vetor de médias, o parâmetro populacional é

$$\theta = \mu,$$

e a transformação correspondente no espaço paramétrico é

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Portanto,

$$\mu_Y = g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Para a matriz de covariâncias, o parâmetro populacional é

$$\theta = \Sigma,$$

e, por Proposição 8.6, a transformação correspondente é

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Portanto,

$$\Sigma_Y = g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Esse exemplo mostra que uma mesma transformação h aplicada aos dados pode induzir transformações diferentes no espaço paramétrico. Para a média,

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d},$$

enquanto, para a covariância,

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Assim, a forma de g depende do parâmetro considerado, mesmo quando a transformação h dos dados permanece a mesma.

Para estimar μ , a regra de estimação é

$$G_1(\mathcal{X}) = \bar{\mathbf{X}}.$$

Aplicando a mesma regra aos dados transformados,

$$G_1[h(\mathcal{X})] = \bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d} = g_1[G_1(\mathcal{X})].$$

Portanto, o vetor de médias amostrais é equivariante em relação a essa transformação afim. Para estimar Σ , a regra de estimação é

$$G_2(\mathcal{X}) = \mathbf{S}_X.$$

Para os dados transformados,

$$G_2[h(\mathcal{X})] = \mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top = g_2[G_2(\mathcal{X})].$$

Assim, a matriz de covariâncias amostral também é equivariante em relação à transformação considerada.

A equivariância descreve como um estimador responde a uma transformação dos **dados**: transformar os dados e depois estimar deve produzir o mesmo resultado que estimar primeiro e aplicar a transformação correspondente ao parâmetro.

Essa propriedade deve ser distinguida da invariância da máxima verossimilhança. Nesse segundo caso, parte-se de um estimador de máxima verossimilhança já obtido para θ e utiliza-se uma função desse estimador para estimar uma função do parâmetro.

As propriedades desta seção respondem a perguntas diferentes sobre um procedimento de estimação:

- **viés** compara o valor médio do estimador com o parâmetro;
- **variabilidade** descreve quanto o estimador muda entre amostras;
- **erro quadrático médio** combina viés e variabilidade segundo uma função de perda;
- **consistência** descreve o comportamento do estimador quando o tamanho amostral aumenta;
- **eficiência** compara a variabilidade de procedimentos concorrentes;
- **suficiência** examina quanta informação sobre o parâmetro é preservada por uma estatística;
- **equivariância** examina a coerência do estimador diante de transformações dos dados.

Essas propriedades não estabelecem uma ordenação universal entre estimadores. Um procedimento pode apresentar vantagens segundo um critério e desvantagens segundo outro. A escolha depende do parâmetro de interesse, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise.

Os métodos dos momentos e da máxima verossimilhança fornecem dois princípios gerais para construir os estimadores estudados a seguir.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos relaciona momentos populacionais a seus correspondentes amostrais. A máxima verossimilhança escolhe os valores dos parâmetros que tornam os dados observados mais compatíveis com o modelo especificado (Casella; Berger, 2002).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. Além disso, o princípio utilizado para construir um estimador deve ser distinguido das propriedades estudadas na seção anterior. Em particular, obter um estimador pelo método dos momentos ou pela máxima verossimilhança não garante, por si só, ausência de viés, consistência, eficiência, suficiência, equivariância ou robustez.

Algumas propriedades podem ser demonstradas sob condições adicionais sobre o modelo e o processo amostral. Outras decorrem da própria estrutura de um método. Essas distinções serão indicadas ao apresentar cada procedimento.

10.3.1 Método dos momentos

Definição 10.10 (Estimador pelo método dos momentos). Considere um parâmetro

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um vetor de funções

$$\mathbf{q}(\mathbf{X}) \in \mathbb{R}^r$$

cujas esperanças existem. Os momentos populacionais utilizados pelo método são reunidos em

$$\mathbf{m}(\theta) = E_{\theta}[\mathbf{q}(\mathbf{X})]. \quad (10.27)$$

A partir de uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

constroem-se os correspondentes momentos amostrais,

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.28)$$

O **estimador pelo método dos momentos** de θ é uma solução, pertencente ao espaço paramétrico Θ , do sistema

$$\mathbf{m}(\hat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.29)$$

Assim, o método substitui os momentos populacionais, que dependem do parâmetro desconhecido, pelos correspondentes momentos calculados a partir da amostra e resolve as equações resultantes em relação a θ .

A existência e a unicidade do estimador dependem dos momentos escolhidos e da forma da função $\mathbf{m}$. O sistema pode não possuir solução, possuir mais de uma solução ou produzir valores que não pertençam a Θ .

Propriedades dos estimadores de momentos

A propriedade que define o método é a correspondência entre os momentos populacionais e seus análogos amostrais expressa na Equação 10.29. Essa construção, isoladamente, não garante que o estimador obtido seja não viesado, eficiente, suficiente, equivariante ou robusto.

A consistência também não decorre apenas do método. Sob condições como existência dos momentos utilizados, convergência dos momentos amostrais para seus correspondentes populacionais, identificação do parâmetro por esses momentos e continuidade adequada da solução, estimadores de momentos podem ser consistentes.

Portanto, as propriedades apresentadas na seção anterior devem ser verificadas para o estimador e o modelo considerados.

Para o vetor de médias populacional,

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{x}},$$

de modo que

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{x}}. \quad (10.30)$$

Para a matriz de covariâncias, considere o segundo momento não central

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

Pela identidade Equação 8.3,

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top.$$

Substituindo os momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned}\widehat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.\end{aligned}\tag{10.31}$$

A matriz no numerador é a versão aleatória da matriz total de somas de quadrados e produtos cruzados (SQPC) definida, para dados observados, na Definição 8.10. Será denotada por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.\tag{10.32}$$

Portanto,

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.\tag{10.33}$$

Essa construção utiliza apenas momentos de primeira e segunda ordem e não exige a hipótese de normalidade multivariada. O divisor n surge aqui diretamente do princípio do método dos momentos; posteriormente, ele também será obtido pela máxima verossimilhança sob o modelo normal.

A matriz $\mathbf{T}$ será desenvolvida em detalhes na seção dedicada à SQPC. Para cada realização da amostra, ela produz a matriz $\mathbf{T}$ definida na Definição 8.10.

Restrições do espaço paramétrico

Resolver as equações de momentos não garante que a solução obtida satisfaça todas as restrições impostas ao parâmetro. Em modelos com condições de positividade, ordem, posto ou outras restrições estruturais, é necessário verificar se a solução pertence efetivamente ao espaço paramétrico Θ .

10.3.2 Verossimilhança e máxima verossimilhança

Definição 10.11 (Função de verossimilhança). Considere um modelo parametrizado por

$$\theta \in \Theta,$$

no qual cada observação possui densidade ou função de probabilidade

$$f(\mathbf{x}; \theta).$$

Para uma amostra aleatória independente e identicamente distribuída

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

e uma realização observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n,$$

a **função de verossimilhança** é

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.34)$$

Na verossimilhança, os dados observados são mantidos fixos e θ varia em Θ . Portanto, L é utilizada para comparar valores do parâmetro segundo sua compatibilidade com a amostra observada; ela não é, em geral, uma distribuição de probabilidade sobre θ .

A log-verossimilhança é

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \log L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n),$$

e, sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.35)$$

Como o logaritmo é estritamente crescente, a verossimilhança e a log-verossimilhança possuem os mesmos pontos de máximo.

Definição 10.12 (Estimador de máxima verossimilhança). Considere a função de verossimilhança definida na Definição 10.11. Um **estimador de máxima verossimilhança** de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

cujas regras seleciona um valor do espaço paramétrico que maximiza a verossimilhança:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.36)$$

Como o logaritmo é estritamente crescente, a mesma regra pode ser obtida maximizando a log-verossimilhança:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} \ell(\theta; \mathcal{X}).$$

Após a observação da amostra, a estimativa correspondente satisfaz

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A notação $\arg \max$ representa o conjunto dos valores do parâmetro em que o máximo é atingido. Assim, a definição admite a possibilidade de mais de um máximo. A existência e a unicidade do estimador precisam ser verificadas no modelo e no espaço paramétrico considerados.

Propriedades dos estimadores de máxima verossimilhança

A maximização da verossimilhança não garante, em amostras finitas, que o estimador seja não viesado ou apresente erro quadrático médio mínimo. Também não garante, por si só, suficiência, equivariância em relação a transformações dos dados ou robustez.

Sob condições de regularidade e identificabilidade, estimadores de máxima verossimilhança podem ser consistentes, assintoticamente normais e assintoticamente eficientes. Esses resultados dependem das condições do modelo e não são consequências incondicionais do procedimento de maximização.

Uma propriedade estrutural específica da máxima verossimilhança é a **invariância em relação a funções do parâmetro**: quando o estimador de máxima verossimilhança existe, uma função apropriada desse estimador fornece o estimador de máxima verossimilhança da função correspondente do parâmetro. Essa propriedade será formalizada adiante.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

Considere uma amostra do modelo normal multivariado definido na Definição 9.1:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Pela densidade normal multivariada na Equação 9.10 e pela independência das unidades amostrais, para uma amostra observada a verossimilhança é

$$\begin{aligned} L(\mu, \Sigma) &= (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \\ &\times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \end{aligned} \quad (10.37)$$

A log-verossimilhança é

$$\begin{aligned} \ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu). \end{aligned} \quad (10.38)$$

Considere a matriz SQPC observada $\mathbf{T}$, definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.39)$$

Separando o afastamento em relação a μ no desvio em relação à média amostral e no deslocamento da própria média, obtém-se

$$\begin{aligned} &\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top. \end{aligned} \quad (10.40)$$

A forma quadrática presente na log-verossimilhança pode ser reescrita utilizando o traço. Pela relação entre traço e produto externo na Proposição 2.7 e pela propriedade cíclica no (ex?),-propriedade-cíclica-traco, para um vetor $\mathbf{z}$ e uma matriz compatível $\mathbf{A}$,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} = \text{tr}(\mathbf{A} \mathbf{z} \mathbf{z}^\top).$$

Consequentemente,

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \\ &= \text{tr} \left[\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] \\ &= \text{tr}(\Sigma^{-1} \mathbf{T}) + n (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu), \end{aligned}$$

em que a última igualdade utiliza Equação 10.40. Assim, a log-verossimilhança pode ser escrita como

$$\begin{aligned} \ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}) \\ &\quad - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu). \end{aligned} \tag{10.41}$$

Para Σ fixa, o último termo é não positivo na log-verossimilhança e atinge seu maior valor quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, obtém-se a log-verossimilhança perfilada

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{T}}{n} \right) \right] \right\}, \tag{10.42}$$

em que C não depende de Σ .

Desconsiderando a constante C , maximizar Equação 10.42 equivale a minimizar

$$\frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Essa expressão possui exatamente a forma do critério estudado na Proposição 7.14, com

$$\mathbf{G} = \mathbf{T}.$$

Assim, quando $\mathbf{T} \succ \mathbf{0}$, aquele resultado pode ser aplicado diretamente para obter o minimizador.

Proposição 10.3 (Estimadores de máxima verossimilhança no modelo normal). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

Para uma amostra observada, se

$$\text{posto}(\mathbf{T}) = p,$$

a função de verossimilhança possui máximo único no espaço paramétrico e

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}},$$

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

No evento amostral em que a condição de posto se verifica, as regras correspondentes são

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}} \tag{10.43}$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}. \tag{10.44}$$

Comprovação. A maximização em relação a μ decorre de Equação 10.41. Como

$$\Sigma^{-1} \succ \mathbf{0},$$

tem-se

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente em

$$\mu = \bar{\mathbf{x}}.$$

Para a maximização em relação a Σ , a log-verossimilhança perfilada na Equação 10.42 mostra que é equivalente minimizar

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Sob a hipótese

$$\text{posto}(\mathbf{T}) = p,$$

tem-se

$$\mathbf{T} \succ \mathbf{0}.$$

Aplicando Proposição 7.14 com $\mathbf{G} = \mathbf{T}$, o minimizador único é

$$\Sigma = \frac{\mathbf{T}}{n}.$$

Logo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

□

Pelo limite de posto da matriz SQPC estabelecido na Equação 8.60,

$$\text{posto}(\mathbf{T}) \leq \min(p, n-1).$$

Consequentemente, uma condição necessária para posto completo é

$$n \geq p+1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois as colunas da matriz centralizada ainda podem ser linearmente dependentes. Sob uma distribuição normal multivariada não singular e

$$n \geq p + 1,$$

a condição

$$\text{posto}(\mathbf{T}) = p$$

ocorre quase certamente.

Se $\mathbf{T}$ é singular, a verossimilhança não possui máximo no espaço

$$\{\Sigma : \Sigma \succ \mathbf{0}\}.$$

De fato, pelo Teorema 5.4, escreva

$$\mathbf{T} = \mathbf{Q} \text{diag}(t_1, \dots, t_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$t_j > 0, \quad j = 1, \dots, r, \quad r < p.$$

Para $\varepsilon > 0$, considere

$$\Sigma_\varepsilon = \mathbf{Q} \text{diag}\left(\frac{t_1}{n}, \dots, \frac{t_r}{n}, \varepsilon, \dots, \varepsilon\right) \mathbf{Q}^\top.$$

Então,

$$\text{tr}(\Sigma_\varepsilon^{-1} \mathbf{T}) = nr,$$

enquanto

$$\log \det(\Sigma_\varepsilon) \longrightarrow -\infty$$

quando

$$\varepsilon \longrightarrow 0.$$

Consequentemente, a log-verossimilhança cresce sem limite ao longo dessa sequência, e o máximo não é atingido no espaço das matrizes positivas definidas.

A matriz

$$\frac{\mathbf{T}}{n}$$

continua sendo bem definida e positiva semidefinida e coincide com o estimador obtido pelo método dos momentos. Quando essa matriz é singular, ela não constitui o estimador de máxima verossimilhança no modelo cujo espaço paramétrico exige

$$\Sigma \succ \mathbf{0}.$$

Quando o máximo existe, o estimador de Σ utiliza o divisor n . Mais adiante será mostrado que esse estimador é viesado para Σ e que o divisor $n - 1$ produz o estimador não viesado usual.

O modelo normal mostrou um caso em que método dos momentos e máxima verossimilhança conduzem às mesmas expressões para μ e Σ . Essa coincidência, porém, é específica do modelo considerado. Retornando à comparação geral entre os dois princípios de construção, suas relações com as propriedades estudadas anteriormente podem ser resumidas da seguinte forma:

Tabela 10.1: Relação entre os métodos de estimação e as propriedades estudadas na seção anterior.

Propriedade	Método dos momentos	Máxima verossimilhança
Não viesamento em amostras finitas	Não é garantido pelo método	Não é garantido pelo método
Consistência	Pode ser obtida sob condições de convergência, identificação e continuidade	Pode ser obtida sob condições de regularidade e identificação
Eficiência em amostras finitas	Não é garantida	Não é garantida
Eficiência assintótica	Não é uma propriedade geral do método	Pode ocorrer sob condições de regularidade
Suficiência	Não é garantida pelo método	Não é garantida apenas pela maximização
Equivariância sob transformações dos dados	Depende do estimador e da transformação	Depende do estimador e da transformação
Invariância sob funções do parâmetro	Não é uma propriedade geral do método	É uma propriedade estrutural da máxima verossimilhança, quando o estimador existe
Robustez	Não é garantida	Não é garantida

A tabela distingue propriedades que decorrem da própria construção do método daquelas que exigem hipóteses adicionais sobre o modelo, a amostra ou o estimador específico.

10.3.3 Invariância da máxima verossimilhança

A máxima verossimilhança possui uma propriedade que permite estimar funções do parâmetro sem realizar uma nova maximização desde o início (Casella; Berger, 2002).

Considere

$$\psi = g(\theta).$$

Quando g não é injetiva, diferentes valores de θ podem produzir o mesmo valor de ψ . Defina a verossimilhança perfilada de ψ por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.45)$$

Proposição 10.4 (Invariância da máxima verossimilhança). *Se*

$$\hat{\theta}_{\text{MV}}$$

é um estimador de máxima verossimilhança de θ e

$$\psi = g(\theta),$$

então

$$g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de ψ em relação à verossimilhança perfilada na Equação 10.45.

Comprovação. Defina

$$\hat{\psi} = g(\hat{\theta}_{\text{MV}}).$$

Como a fibra

$$\{\theta \in \Theta : g(\theta) = \hat{\psi}\}$$

contém $\hat{\theta}_{\text{MV}}$, tem-se

$$L_g(\hat{\psi}) = L(\hat{\theta}_{\text{MV}}).$$

Nenhum outro valor de ψ pode apresentar verossimilhança perfilada superior, pois isso implicaria a existência de algum θ cuja verossimilhança superasse o máximo global. Portanto,

$$\hat{\psi} = g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de ψ . □

A invariância da máxima verossimilhança deve ser distinguida da equivariância.

- **Equivariância** relaciona uma transformação dos dados à transformação correspondente do estimador.
- **Invariância da máxima verossimilhança** aplica uma função do parâmetro ao estimador de máxima verossimilhança já obtido.

Considere a matriz de correlações populacional definida na Definição 8.5:

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Quando o estimador de máxima verossimilhança de Σ existe e possui diagonal positiva, a invariância fornece

$$\hat{\mathcal{R}}_{\text{MV}} = \hat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2} \hat{\Sigma}_{\text{MV}} \hat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2}. \quad (10.46)$$

Como correlações são preservadas por mudanças positivas de escala, conforme Equação 8.25, o fator comum que distingue as matrizes de covariâncias com divisores n e $n - 1$ se cancela na padronização. Assim, a matriz na Equação 10.46 coincide com a matriz de correlações calculada a partir da covariância amostral com divisor $n - 1$.

A propriedade pode ser aplicada também a funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma)$$

e, quando o estimador é positivo definido,

$$\Sigma^{-1}.$$

A invariância é uma propriedade de otimização. Ela não implica ausência de viés, consistência automática ou estabilidade numérica. Em particular, a inversão de uma matriz estimada mal condicionada pode amplificar pequenas perturbações.

Os dois métodos apresentados produzem, no modelo normal, o mesmo estimador para μ e a mesma matriz com divisor n para Σ . A seção seguinte examina primeiro o vetor de médias amostrais e suas propriedades.

10.4 Estimação do vetor de médias

O vetor de médias populacional μ , definido na Equação 8.1, descreve a localização da população em $\mathbb{R}^p$. A seção anterior mostrou que o método dos momentos e, sob o modelo normal multivariado, a máxima verossimilhança conduzem ao vetor de médias amostrais como estimador de μ . Nesta seção, esse estimador será estudado quanto às propriedades apresentadas anteriormente.

Considere a amostra aleatória multivariada definida na Equação 10.1 e suponha que

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n.$$

Os resultados sobre esperança, variabilidade, erro quadrático médio e consistência utilizam a independência entre as unidades amostrais e os momentos indicados acima. A normalidade multivariada será necessária apenas quando o vetor de médias amostrais for interpretado como estimador de máxima verossimilhança no modelo normal.

10.4.1 Vetor de médias amostrais

Retomando a Equação 10.8, o vetor de médias amostrais é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

com

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.47)$$

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n. \quad (10.48)$$

Após a observação dos dados,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.49)$$

Pelo método dos momentos, a Equação 10.30 fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}.$$

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança existe, a Equação 10.43 fornece

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}.$$

Portanto,

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}. \quad (10.50)$$

A mesma estatística é, portanto, obtida por dois princípios de construção diferentes. A partir deste ponto, o interesse recai sobre as propriedades de $\bar{\mathbf{X}}$ como estimador de μ . Essas propriedades não decorrem do fato de o estimador ter sido obtido pelo método dos momentos ou pela máxima verossimilhança; elas serão verificadas diretamente sob as hipóteses declaradas nesta seção.

Além de sua interpretação como estimativa de μ , o valor observado $\bar{\mathbf{x}}$ possui uma caracterização geométrica: ele é o centroide da nuvem de pontos e minimiza a soma dos quadrados das distâncias euclidianas das observações a um centro comum.

Proposição 10.5 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor $\bar{\mathbf{x}}$ é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.51)$$

Comprovação. Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Somando os quadrados das normas,

$$\begin{aligned} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\ &\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\ &\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \end{aligned}$$

Pela propriedade de centralização estabelecida na Equação 8.57,

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}.$$

Logo,

$$\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \quad (10.52)$$

A primeira parcela não depende de $\mathbf{m}$, e a segunda é não negativa e se anula somente em

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador. □

A identidade Equação 10.52 será reutilizada na construção da matriz SQPC e na decomposição da dispersão em torno de centros distintos.

10.4.2 Não viesamento, variabilidade e erro quadrático médio

Proposição 10.6 (Esperança e covariância do vetor de médias amostrais). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\bar{\mathbf{X}}) = \mu \tag{10.53}$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \tag{10.54}$$

Comprovação. Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right).$$

Como as unidades amostrais são independentes,

$$\text{Cov} \left(\sum_{i=1}^n \mathbf{x}_i \right) = \sum_{i=1}^n \text{Cov} (\mathbf{x}_i) = n\Sigma.$$

Portanto,

$$\text{Cov} (\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

□

Consequentemente,

$$\text{Bias} (\bar{\mathbf{X}}) = \mathbf{0}.$$

O vetor de médias amostrais é, portanto, não viesado para μ .

Elemento a elemento,

$$\text{Var} (\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov} (\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

A matriz de covariâncias do erro de estimação é obtida multiplicando Σ pelo fator $1/n$. Assim, o aumento do tamanho amostral reduz a magnitude das variâncias e covariâncias, preservando a estrutura relativa determinada por Σ .

Como $\bar{\mathbf{X}}$ é não viesado, a decomposição do erro quadrático médio na Equação 10.18 reduz-se ao termo de variabilidade. Sob a perda quadrática euclidiana,

$$\begin{aligned} \text{EQM} (\bar{\mathbf{X}}) &= \text{tr} [\text{Cov} (\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr} (\Sigma). \end{aligned} \tag{10.55}$$

Como a variância total populacional foi definida na Equação 8.35 por

$$\text{tr} (\Sigma),$$

Equação 10.55 mostra que o erro quadrático médio sob perda euclidiana corresponde à variância total dividida pelo tamanho amostral.

Esses resultados estabelecem o não viesamento, a matriz de covariâncias e o erro quadrático médio de $\bar{\mathbf{X}}$. Eles não estabelecem, por si só, eficiência, pois essa propriedade exige comparar o estimador com procedimentos concorrentes segundo um critério especificado.

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

O correspondente estimador é

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Aplicando Proposição 8.1 ao vetor aleatório $\bar{\mathbf{X}}$, cuja média e matriz de covariâncias são dadas na Proposição 10.6,

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \mu,$$

e

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned} \tag{10.56}$$

Cada vetor $\mathbf{a}$ define uma combinação linear dos componentes de $\bar{\mathbf{X}}$ e, geometricamente, especifica uma direção juntamente com uma escala. Sua variabilidade é determinada por

$$\frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Para comparar apenas direções, pode-se considerar vetores $\mathbf{a}$ de norma unitária. Nesse caso, direções com maior variância populacional também produzem maior variabilidade entre as estimativas das respectivas combinações lineares. Essa é a mesma interpretação utilizada anteriormente na comparação de matrizes de covariâncias pela ordem de Löwner.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Mais geralmente, para

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\mu$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n}\mathbf{C}\Sigma\mathbf{C}^\top. \tag{10.57}$$

Essas expressões serão retomadas no estudo de contrastes e hipóteses lineares.

10.4.4 Consistência e equivariância

Proposição 10.7 (Consistência do vetor de médias amostrais). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independentes, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

com segundos momentos finitos. Para dimensão p fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \tag{10.58}$$

quando $n \rightarrow \infty$.

Comprovação. Por Equação 10.55,

$$E\left[\|\bar{\mathbf{X}} - \mu\|^2\right] = \frac{\text{tr}(\Sigma)}{n}.$$

Para $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$\begin{aligned} P(\|\bar{\mathbf{X}} - \mu\| > \varepsilon) &\leq \frac{E\left[\|\bar{\mathbf{X}} - \mu\|^2\right]}{\varepsilon^2} \\ &= \frac{\text{tr}(\Sigma)}{n\varepsilon^2} \rightarrow 0. \end{aligned}$$

Logo,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

□

A prova utiliza segundos momentos finitos. Para dimensão fixa, a consistência também pode ser obtida por leis dos grandes números sob condições de integrabilidade mais gerais.

A equivariância do vetor de médias amostrais foi utilizada anteriormente como exemplo de Definição 10.9. O resultado é registrado a seguir para referência posterior.

Proposição 10.8 (Equivariância afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \tag{10.59}$$

Como, por Equação 8.17,

$$\mu_Y = \mathbf{C}\mu + \mathbf{d},$$

a transformação aplicada ao estimador acompanha exatamente a transformação correspondente do parâmetro populacional.

Até este ponto, foram estabelecidas propriedades distintas do vetor de médias amostrais: ele é não viesado, possui matriz de covariâncias Σ/n , tem erro quadrático médio $\text{tr}(\Sigma)/n$ sob perda euclidiana, é consistente sob as condições especificadas e é equivariante em relação a transformações afins. Essas propriedades foram demonstradas para o estimador concreto e não decorrem simplesmente do método utilizado para construí-lo.

10.4.5 Variabilidade entre amostras

O vetor $\bar{\mathbf{X}}$ é uma estatística aleatória, enquanto $\bar{\mathbf{x}}$ é sua realização para uma amostra observada. Se o processo de amostragem fosse repetido, diferentes amostras produziriam diferentes valores de $\bar{\mathbf{x}}$. A distribuição desses valores corresponde à distribuição amostral do estimador.

A Figura 10.1 apresenta 250 realizações de $\bar{\mathbf{X}}$ para amostras de tamanhos 5 e 50 geradas de uma mesma distribuição normal bivariada. A normalidade é utilizada apenas para gerar a ilustração; o resultado na Equação 10.54 depende apenas da independência das unidades amostrais e da existência dos segundos momentos.




Figura 10.1: Vetores de médias amostrais obtidos em 250 amostras de uma distribuição normal bivariada, para tamanhos amostrais 5 e 50.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Para $n = 50$, a nuvem é mais concentrada do que para $n = 5$, em concordância com a redução da matriz de covariâncias por $1/n$.

A figura **não representa ainda um resultado sobre a forma exata da distribuição amostral de $\bar{\mathbf{X}}$** . Essa distribuição será estudada no Capítulo 12.

O vetor de médias amostrais estima a localização da população. A estimação da dispersão exige considerar os desvios das observações em relação a esse centro. Esses desvios conduzem à matriz SQPC e aos estimadores da matriz de covariâncias.

10.5 SQPC e estimação da matriz de covariâncias

O vetor de médias amostrais descreve a localização da amostra. A estimação da matriz de covariâncias exige representar como as observações se dispersam conjuntamente em torno desse centro.

O Capítulo 8 definiu a matriz total de somas de quadrados e produtos cruzados (SQPC) na Definição 8.10 e a matriz de covariâncias observada na Definição 8.11. A seção sobre métodos de estimação mostrou ainda que o método dos momentos conduz à matriz SQPC dividida por n e que, sob o modelo normal multivariado e as condições de existência do máximo, a máxima verossimilhança conduz à mesma expressão.

Nesta seção, a SQPC e as matrizes de covariâncias correspondentes passam a ser tratadas como estatísticas aleatórias. O objetivo é comparar os estimadores de Σ resultantes de diferentes critérios e estudar suas propriedades.

Considere a amostra aleatória multivariada definida na Equação 10.1, com unidades independentes e

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

e suponha que os segundos momentos sejam finitos.

10.5.1 SQPC como estatística aleatória

A matriz aleatória da amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Retomando a matriz de centralização utilizada na Equação 8.58,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

define-se a matriz aleatória centralizada por

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}. \quad (10.60)$$

Suas linhas são

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Definição 10.13 (Matriz SQPC amostral). A **matriz de somas de quadrados e produtos cruzados (SQPC) amostral** é a estatística

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.61)$$

Equivalentemente,

$$\mathbf{T} = \mathcal{X}_c^\top \mathcal{X}_c = \mathcal{X}^\top \mathbf{H}_n \mathcal{X}. \quad (10.62)$$

Após a observação da amostra,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.63)$$

A matriz $\mathbf{T}$ é exatamente a matriz SQPC observada definida na Definição 8.10 e escrita matricialmente na Equação 8.59. A diferença de notação é probabilística: $\mathbf{T}$ representa a estatística aleatória, enquanto $\mathbf{T}$ representa sua realização observada.

O elemento (j, k) de $\mathbf{T}$ é

$$\mathsf{T}_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.64)$$

Na diagonal,

$$\mathsf{T}_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a soma de quadrados centralizada da variável j . Fora da diagonal, T_{jk} é o produto cruzado centralizado entre as variáveis j e k .

Após a observação da amostra, os elementos correspondentes de $\mathbf{T}$ são denotados por t_{jk} .

10.5.2 Decomposição em torno de um centro arbitrário

A caracterização do centroide na Equação 10.52 mostrou, em termos de distâncias quadráticas, como a dispersão em torno de um centro arbitrário pode ser decomposta em uma parcela em torno da média amostral e outra associada ao deslocamento do centro. Para a estimação da matriz de covariâncias, utiliza-se a versão matricial dessa decomposição.

Proposição 10.9 (Decomposição da SQPC em torno de um centro arbitrário). *Para qualquer vetor fixo*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \\ = \mathbf{T} + n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \quad (10.65)$$

Comprovação. Escreva

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo na soma dos produtos externos, surgem quatro parcelas. Os dois termos cruzados contêm

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

e, portanto, se anulam. Restam

$$\mathbf{T}$$

e

$$n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^\top,$$

o que fornece Equação 10.65. □

Para

$$\mathbf{c} = \mu,$$

obtém-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \\ = \mathbf{T} + n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top. \end{aligned} \tag{10.66}$$

Essa identidade separa a dispersão das observações em torno do centro populacional em duas parcelas: a dispersão em torno da média amostral e o afastamento entre a média amostral e a média populacional.

10.5.3 Esperança da SQPC

A identidade anterior permite obter a esperança de $\mathbf{T}$ sem assumir normalidade.

Proposição 10.10 (Esperança da SQPC). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{T}) = (n-1)\Sigma. \tag{10.67}$$

Comprovação. Tomando esperança no lado esquerdo de Equação 10.66,

$$E \left[\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] = \sum_{i=1}^n \Sigma = n\Sigma.$$

Para a segunda parcela do lado direito,

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] = n \text{Cov} (\bar{\mathbf{X}}).$$

Por Equação 10.54,

$$n \text{Cov} (\bar{\mathbf{X}}) = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{T}) + \Sigma,$$

e segue que

$$E(\mathbf{T}) = (n-1)\Sigma.$$

□

O fator $n-1$ surge porque a SQPC utiliza desvios em relação à média estimada a partir da própria amostra. A centralização impõe

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

de modo que os n vetores de desvios satisfazem uma restrição linear. Assim, a centralização reduz em uma unidade a dimensão associada às variações em torno da média amostral.

A relação

$$E(\mathbf{T}) = (n-1)\Sigma$$

depende apenas da independência entre as unidades amostrais e da existência dos segundos momentos necessários; a normalidade multivariada não é exigida. A distribuição completa de $\mathbf{T}$ sob normalidade será tratada no Capítulo 12.

10.5.4 Estimador não viesado da matriz de covariâncias

Definição 10.14 (Matriz de covariâncias amostral). Para $n \geq 2$, define-se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}, \quad (10.68)$$

em que $\mathbf{T}$ é definida na Definição 10.13.

Proposição 10.11 (Não viesamento da matriz de covariâncias amostral). *Sob as condições da Proposição 10.10,*

$$E(\mathbf{S}) = \Sigma. \quad (10.69)$$

Portanto, $\mathbf{S}$ é um estimador não viesado de Σ .

Comprovação. Por Equação 10.68 e Equação 10.67,

$$\begin{aligned} E(\mathbf{S}) &= \frac{1}{n-1} E(\mathbf{T}) \\ &= \frac{1}{n-1} (n-1) \Sigma \\ &= \Sigma. \end{aligned}$$

□

Após a observação, obtém-se a matriz de covariâncias observada definida na Definição 8.11:

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.70)$$

Componente a componente,

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.71)$$

Para $j = k$,

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Assim,

$$\mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}.$$

Após a observação da amostra, os elementos correspondentes de $\mathbf{S}$ são denotados por s_{jk} .

A divisão por $n - 1$ corrige o viés associado à centralização pela média amostral. Ela não é escolhida para garantir semidefinição positiva. Como a matriz SQPC observada satisfaz

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram, conforme Definição 3.18, e suas propriedades de simetria e semidefinição positiva decorrem da Proposição 3.9. A multiplicação por $1/(n - 1) > 0$ preserva essas propriedades em $\mathbf{S}$.

O não viesamento de $\mathbf{S}$ foi obtido utilizando apenas segundos momentos. Uma caracterização de sua variabilidade completa exigiria estudar

$$\text{Cov}[\text{vec}(\mathbf{S})],$$

utilizando o operador definido na Definição 7.9. De modo correspondente, o erro quadrático médio matricial sob a perda baseada na norma de Frobenius definida na Definição 6.7 envolveria

$$E \left[\|\mathbf{S} - \Sigma\|_F^2 \right].$$

Essas quantidades dependem, em geral, de momentos de quarta ordem. Por isso, diferentemente do que ocorreu com o vetor de médias amostrais, os segundos momentos assumidos nesta seção não são suficientes para determinar a variabilidade completa ou o EQM de $\mathbf{S}$. Sob normalidade, resultados mais específicos serão obtidos a partir da distribuição amostral da matriz de covariâncias no Capítulo 12.

10.5.5 Estimador com divisor n : momentos e máxima verossimilhança

Pelo método dos momentos, a Equação 10.33 fornece

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado não singular e quando o máximo existe, a Equação 10.44 fornece a mesma estatística:

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Portanto, no modelo normal e nas condições de existência do estimador de máxima verossimilhança,

$$\widehat{\Sigma}_{\text{MM}} = \widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

tem-se, sob o modelo normal,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (10.72)$$

Por Equação 10.67,

$$E\left(\frac{\mathbf{T}}{n}\right) = \frac{n-1}{n} \Sigma.$$

Portanto, como estimador de Σ ,

$$\text{Bias}\left(\frac{\mathbf{T}}{n}\right) = -\frac{1}{n} \Sigma.$$

Esse resultado vale para o estimador pelo método dos momentos sem exigir normalidade. Sob o modelo normal e nas condições de existência do máximo, a mesma estatística é também o estimador de máxima verossimilhança. Nesse caso,

$$E(\widehat{\Sigma}_{MV}) = \frac{n-1}{n}\Sigma \quad (10.73)$$

e

$$\text{Bias}(\widehat{\Sigma}_{MV}) = -\frac{1}{n}\Sigma. \quad (10.74)$$

Assim, o viés é uma propriedade da estatística $\mathbf{T}/n$ como estimador de Σ , e não uma consequência do método utilizado para obtê-la.

A comparação entre

$$\frac{\mathbf{T}}{n} \quad \text{e} \quad \frac{\mathbf{T}}{n-1}$$

mostra novamente que o princípio utilizado para construir um estimador e suas propriedades estatísticas são questões distintas. A primeira matriz resulta diretamente do método dos momentos e, sob normalidade, também da máxima verossimilhança; a segunda utiliza a correção necessária para obter não viesamento.

Quando n aumenta,

$$\frac{n-1}{n} \rightarrow 1,$$

de modo que a diferença relativa entre os dois estimadores desaparece.

Dois divisores, dois critérios

A matriz

$$\frac{\mathbf{T}}{n}$$

surge como estimador de momentos e, sob o modelo normal e as condições de existência do máximo, como estimador de máxima verossimilhança.

A matriz

$$\frac{\mathbf{T}}{n-1}$$

é construída para satisfazer

$$E(\mathbf{S}) = \Sigma.$$

Nenhum dos dois divisores é universalmente “correto” sem especificar o critério de estimação.

Sob o modelo normal multivariado, Proposição 10.2 estabeleceu que

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para

$$(\mu, \Sigma).$$

Como, para n fixado,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é uma transformação bijetiva de $\mathbf{T}$, o par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

preserva a mesma informação sobre os parâmetros. Essa afirmação é conjunta: ela não significa que $\mathbf{S}$ isoladamente seja suficiente para (μ, Σ) .

10.5.6 Consistência dos estimadores de covariância

O não viesamento é uma propriedade para tamanho amostral fixo. A consistência descreve o comportamento quando n aumenta.

Proposição 10.12 (Consistência da matriz de covariâncias amostral). *Considere uma amostra aleatória i.i.d.*

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

em que

$$\mathbf{X}_i \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu,$$

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

e

$$E(\|\mathbf{X}_i\|^2) < \infty.$$

Se o número p de variáveis permanece fixo quando $n \rightarrow \infty$, então

$$\mathbf{S} \xrightarrow{P} \Sigma. \quad (10.75)$$

Comprovação. Pela identidade

$$\frac{1}{n} \mathbf{T} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^\top - \bar{\mathbf{X}} \bar{\mathbf{X}}^\top, \quad (10.76)$$

a matriz com divisor n pode ser escrita como diferença entre o segundo momento amostral não central e o produto externo da média amostral.

Para cada par (j, k) , a condição de segundos momentos finitos implica

$$E(|X_j X_k|) < \infty.$$

Pela Lei dos Grandes Números,

$$\frac{1}{n} \sum_{i=1}^n X_{ij} X_{ik} \xrightarrow{P} E(X_j X_k),$$

e

$$\bar{X}_j \xrightarrow{P} \mu_j.$$

Logo, elemento a elemento,

$$\frac{1}{n} \mathbf{T} \xrightarrow{P} E(\mathbf{X} \mathbf{X}^\top) - \mu \mu^\top = \Sigma.$$

Como p é fixo,

$$\mathbf{S} = \frac{n}{n-1} \left(\frac{\mathbf{T}}{n} \right) \xrightarrow{P} \Sigma.$$

□

Pela mesma argumentação,

$$\widehat{\Sigma}_{MV} = \frac{\mathbf{T}}{n} \xrightarrow{P} \Sigma \quad (10.77)$$

sempre que a expressão é considerada como estatística. No modelo normal positivo definido, sua interpretação como estimador de máxima verossimilhança requer adicionalmente a existência do máximo discutida anteriormente.

A consistência apresentada aqui corresponde ao regime clássico de **dimensão fixa**. Quando p aumenta com n , a convergência deve ser analisada segundo o regime dimensional e a norma de interesse.

10.5.7 Transformações, posto e singularidade

As propriedades algébricas da matriz SQPC observada decorrem de sua representação de Gram na Equação 8.59 e do limite de posto estabelecido na Equação 8.60. Como essas propriedades valem para cada realização da amostra, elas também caracterizam as estatísticas $\mathbf{T}$ e $\mathbf{S}$ amostra a amostra.

Transformações afins. A equivariância da matriz de covariâncias amostral foi utilizada anteriormente como exemplo de Definição 10.9. Para referência, se

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

então

$$\mathbf{T}_Y = \mathbf{C}\mathbf{T}_X\mathbf{C}^\top \quad (10.78)$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \quad (10.79)$$

A translação $\mathbf{d}$ desaparece pela centralização. Como a matriz populacional satisfaz, pela Proposição 8.6,

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top,$$

a transformação da estatística acompanha exatamente a transformação correspondente do parâmetro.

Simetria e semidefinição positiva. Pela representação de Gram na Equação 8.59 e pelas propriedades de matrizes de Gram na Proposição 3.9, para qualquer realização da amostra,

$$\mathbf{T} = \mathbf{T}^\top \quad \text{e} \quad \mathbf{T} \succeq \mathbf{0}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

a matriz $\mathbf{S}$ também é simétrica e positiva semidefinida. Assim, em aritmética exata, o estimador não produz autovalores negativos.

Variância de combinações lineares. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{X}_i - \bar{\mathbf{X}})]^2. \quad (10.80)$$

A forma quadrática é a variância amostral da variável projetada

$$\mathbf{a}^\top \mathbf{X}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0$$

se, e somente se, os valores observados da combinação linear $\mathbf{a}^\top \mathbf{X}_i$ são constantes na amostra.

Posto. Pelo resultado estabelecido na Equação 8.60, para qualquer realização da amostra,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n-1). \quad (10.81)$$

Como $\mathbf{S}$ é obtida por multiplicação de $\mathbf{T}$ por uma constante positiva,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}). \quad (10.82)$$

Uma condição necessária para

$$\mathbf{S} \succ \mathbf{0}$$

é, portanto,

$$n \geq p + 1.$$

Mesmo quando essa desigualdade é satisfeita, a definição positiva depende de as colunas de $\mathbf{X}_c$ possuírem posto completo.

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

A singularidade significa que existe algum vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p$$

tal que

$$\mathbf{S}\mathbf{a} = \mathbf{0}.$$

Equivalentemente,

$$\mathbf{a}^\top \mathbf{S}\mathbf{a} = 0,$$

de modo que a combinação linear correspondente apresenta variância amostral nula.

Inversão. Quando

$$\mathbf{S} \succ \mathbf{0},$$

sua inversa existe e pode ser utilizada em formas quadráticas e métricas baseadas na covariância estimada.

Se $\mathbf{S}$ é singular, $\mathbf{S}^{-1}$ não existe. A utilização de pseudoinversas ou de estimadores regularizados corresponde a escolhas distintas e será discutida na seção de aprofundamento.

Forma quadrática com covariância estimada

A distância de Mahalanobis foi definida na Definição 8.9 utilizando os parâmetros populacionais. Sob normalidade, Proposição 9.9 estabelece a distribuição qui-quadrado da forma correspondente quando μ e Σ são conhecidos.

Substituir esses parâmetros por quantidades estimadas, como $\bar{\mathbf{x}}$ e $\mathbf{S}$, produz outra estatística. Portanto, a distribuição

$$D_M^2 \sim \chi_p^2$$

não pode ser transferida diretamente para uma forma quadrática construída com estimadores.

As distribuições apropriadas para estatísticas que envolvem parâmetros estimados serão estudadas no Capítulo 12.

Até este ponto, foram estabelecidas propriedades distintas dos estimadores de Σ . A matriz $\mathbf{S} = \mathbf{T}/(n-1)$ é não viesada, enquanto $\mathbf{T}/n$ é viesada em amostras finitas, embora seja obtida pelo método dos momentos e, sob normalidade e existência do máximo, também pela máxima verossimilhança. Ambos os estimadores são consistentes no regime de dimensão fixa sob as condições especificadas. Além disso, a matriz de covariâncias amostral é equivariante sob transformações afins, positiva semidefinida em cada realização e possui posto limitado por $\min(p, n-1)$.

Esses resultados não estabelecem eficiência em amostras finitas, e a avaliação completa da variabilidade ou do erro quadrático médio matricial exige hipóteses adicionais sobre momentos de ordem superior.

O posto e a estabilidade numérica da matriz de covariâncias amostral tornam-se especialmente relevantes quando p não é pequeno em relação a n . Antes de discutir esse regime, serão construídos os estimadores correspondentes para covariâncias entre blocos e para correlações.

10.6 Estimação de covariâncias cruzadas e correlações

Em diversos problemas multivariados, as variáveis são organizadas em blocos observados sobre as mesmas unidades amostrais. As covariâncias cruzadas descrevem associações lineares entre variáveis pertencentes a blocos distintos, enquanto as correlações removem as escalas marginais dessas associações.

O Capítulo 8 definiu a matriz de covariâncias cruzadas populacional na Definição 8.3, a matriz de covariâncias cruzadas observada na Definição 8.13 e a matriz de correlações observada na

Definição 8.12. Nesta seção, os objetos correspondentes são tratados como estatísticas aleatórias e utilizados na estimação de suas contrapartes populacionais.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q.$$

A matriz de covariâncias cruzadas populacional

$$\Sigma_{XY}$$

foi definida na Definição 8.3. Sua orientação satisfaz, conforme Equação 8.13,

$$\Sigma_{YX} = \Sigma_{XY}^{\top}.$$

Para o vetor conjunto

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

a estrutura em blocos da matriz de covariâncias segue Equação 8.15. Neste capítulo, será denotada por

$$\Sigma_{\text{conj}} = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.83)$$

Para estimar Σ_{XY} , é necessária uma amostra **pareada**:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ correspondem à mesma unidade amostral. Alterar a correspondência entre as linhas dos dois blocos modifica as covariâncias cruzadas.

Organize as observações nas matrizes aleatórias

$$\mathcal{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} \in \mathbb{R}^{n \times q}.$$

Após a centralização,

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.15 (Matriz de somas de produtos cruzados entre blocos). A **matriz de somas de produtos cruzados entre os dois blocos** é

$$\mathbf{T}_{XY} = \mathcal{X}_c^\top \mathcal{Y}_c. \quad (10.84)$$

Equivalentemente,

$$\mathbf{T}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{y}_i - \bar{\mathbf{Y}})^\top. \quad (10.85)$$

Após a observação,

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.86)$$

A inversão da ordem dos blocos produz

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top$$

e

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 10.16 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}. \quad (10.87)$$

Após a observação da amostra, obtém-se a matriz de covariâncias cruzadas observada definida na Definição 8.13:

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.88)$$

Seu elemento (j, k) é

$$S_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.89)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{S}_{XY}$ é denotado por $s_{X_j Y_k}$.

Proposição 10.13 (Não viesamento da covariância cruzada amostral). *Considere uma amostra pareada i.i.d. do vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

com segundos momentos finitos. Então,

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.90)$$

Comprovação. A matriz de covariâncias amostral do vetor conjunto é

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}.$$

Pelo não viesamento da matriz de covariâncias amostral estabelecido na Equação 10.69,

$$E(\mathbf{S}_{\text{conj}}) = \Sigma_{\text{conj}}.$$

A igualdade entre os blocos superiores direitos fornece

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}.$$

□

O método dos momentos aplicado à matriz de covariâncias do vetor conjunto conduz ao estimador

$$\widehat{\Sigma}_{\text{conj},\text{MM}} = \frac{1}{n} \mathbf{T}_{\text{conj}}.$$

Consequentemente, o bloco correspondente à covariância cruzada é

$$\widehat{\Sigma}_{XY,\text{MM}} = \frac{1}{n} \mathbf{T}_{XY}.$$

Sob normalidade conjunta não singular,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_{\text{conj}} \right),$$

o estimador de máxima verossimilhança da matriz conjunta de covariâncias, quando existe, utiliza também o divisor n . Portanto,

$$\widehat{\Sigma}_{XY,\text{MM}} = \widehat{\Sigma}_{XY,\text{MV}} = \frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY}. \quad (10.91)$$

Se

$$n \geq p + q + 1$$

e a distribuição normal conjunta é não singular, a matriz SQPC do vetor conjunto possui posto $p + q$ quase certamente. Nessas condições, o estimador positivo definido de máxima verossimilhança da matriz conjunta existe quase certamente.

Por Equação 10.90,

$$E \left(\frac{1}{n} \mathbf{T}_{XY} \right) = \frac{n-1}{n} \Sigma_{XY}.$$

Assim,

$$\text{Bias} \left(\frac{1}{n} \mathbf{T}_{XY} \right) = -\frac{1}{n} \Sigma_{XY}.$$

Esse viés pertence à estatística $\mathbf{T}_{XY}/n$ como estimador de Σ_{XY} e não depende da hipótese de normalidade. A normalidade é necessária apenas para interpretar essa mesma estatística como o bloco cruzado do estimador de máxima verossimilhança da matriz conjunta.

A consistência também pode ser obtida diretamente a partir da matriz de covariâncias do vetor conjunto. Sob as condições da Proposição 10.12, aplicadas ao vetor de dimensão $p + q$,

$$\mathbf{S}_{\text{conj}} \xrightarrow{P} \Sigma_{\text{conj}}.$$

Consequentemente, cada um de seus blocos converge para o bloco populacional correspondente e, em particular,

$$\mathbf{S}_{XY} \xrightarrow{P} \Sigma_{XY}. \quad (10.92)$$

Como

$$\frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY},$$

também se obtém

$$\frac{1}{n} \mathbf{T}_{XY} \xrightarrow{P} \Sigma_{XY}.$$

A transformação da covariância cruzada amostral acompanha a transformação do parâmetro populacional estabelecida na Equação 8.19. Se

$$\mathbf{U} = \mathbf{C}\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{D}\mathbf{Y} + \mathbf{d},$$

então

$$\mathbf{S}_{UV} = \mathbf{C}\mathbf{S}_{XY}\mathbf{D}^\top. \quad (10.93)$$

Portanto, $\mathbf{S}_{XY}$ é equivariante em relação a essas transformações afins dos dois blocos. Os vetores de localização $\mathbf{c}$ e $\mathbf{d}$ desaparecem após a centralização.

Para

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

segue que

$$S_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.94)$$

Diferentemente de uma matriz de covariâncias de um único vetor, $\mathbf{S}_{XY}$ é, em geral, retangular quando $p \neq q$. Mesmo quando $p = q$, ela não precisa ser simétrica. Os dois blocos satisfazem

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top.$$

Por isso, propriedades como simetria e semidefinição positiva não devem ser atribuídas isoladamente à matriz de covariâncias cruzadas. Essas propriedades pertencem à matriz de covariâncias do vetor conjunto, da qual $\mathbf{S}_{XY}$ é um bloco.

O posto satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.95)$$

Esse limite restringirá posteriormente técnicas que utilizam simultaneamente dois conjuntos de variáveis.

10.6.2 Matriz de correlações amostral

A matriz de correlações amostral é obtida pela padronização das covariâncias pelas variâncias marginais correspondentes.

Considere

$$\mathbf{S} = (S_{jk})$$

e defina a matriz diagonal das variâncias amostrais por

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Definição 10.17 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \quad (10.96)$$

Após a observação da amostra, obtém-se a matriz $\mathbf{R}$ definida na Definição 8.12:

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.97)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) da estatística aleatória $\mathbf{R}$ é

$$R_{jk} = \frac{S_{jk}}{\sqrt{S_{jj}S_{kk}}}. \quad (10.98)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{R}$ é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}.$$

Consequentemente,

$$R_{jj} = 1$$

e, para a realização observada,

$$r_{jj} = 1.$$

A interpretação geométrica da correlação observada foi estabelecida na Equação 8.71, que identifica r_{jk} com o cosseno do ângulo entre as colunas centralizadas e padronizadas. Aqui, a ênfase recai sobre $\mathbf{R}$ como estatística utilizada para estimar a matriz populacional $\mathcal{R}$.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Se

$$S_{jj} = 0$$

a correspondente padronização não existe.

10.6.3 Propriedades estruturais

Proposição 10.14 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, $\mathbf{R}$ é:*

1. *simétrica;*
2. *positiva semidefinida;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.99)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.100)$$

Comprovação. A simetria decorre da simetria de $\mathbf{S}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{R} \mathbf{a} &= (\mathbf{D}_S^{-1/2} \mathbf{a})^\top \mathbf{S} (\mathbf{D}_S^{-1/2} \mathbf{a}) \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{R}$ é positiva semidefinida.

A diagonal unitária decorre de

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1.$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definitude positiva. $\square$

Uma matriz simétrica com diagonal unitária e elementos em $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A positividade semidefinida também é necessária.

Como

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}),$$

uma condição necessária para definitude positiva é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois ainda podem existir dependências lineares entre as colunas centralizadas.

Quando

$$p \geq n,$$

a matriz de correlações, se definida, é necessariamente singular.

Para uma realização observada,

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.101)$$

A padronização remove as escalas marginais, mas não altera o posto.

A matriz de correlações populacional é uma função da matriz de covariâncias,

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Substituindo Σ pelo estimador de momentos

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T},$$

obtem-se um estimador por substituição de $\mathcal{R}$. Como o fator comum $1/n$ aparece tanto nas covariâncias quanto nas variâncias marginais, ele se cancela na padronização. A matriz resultante é

R.

Assim, $\mathbf{R}$ pode ser obtida pela padronização do estimador de momentos de Σ .

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança de Σ existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Novamente, o fator comum $(n-1)/n$ cancela-se na transformação de covariâncias em correlações. Pela Proposição 10.4,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}. \quad (10.102)$$

Assim, no modelo normal considerado e nas condições de existência do máximo, a mesma matriz de correlações amostral também é obtida pela máxima verossimilhança.

Essa coincidência não implica não viesamento. Em geral,

$$E(\mathbf{R}_{jk}) \neq \rho_{jk}.$$

A razão é que a correlação amostral é uma função não linear das variâncias e covariâncias amostrais.

Por outro lado, se

$$\mathbf{S} \xrightarrow{P} \Sigma$$

e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

Considere a transformação

$$g(\mathbf{A}) = \mathbf{D}_A^{-1/2} \mathbf{A} \mathbf{D}_A^{-1/2},$$

em que

$$\mathbf{D}_A = \text{diag}(a_{11}, \dots, a_{pp}).$$

Essa transformação converte uma matriz de covariâncias em sua matriz de correlações e é contínua quando os elementos de sua diagonal são positivos.

O **teorema do mapeamento contínuo** estabelece que, se uma sequência de estatísticas converge em probabilidade e uma função é contínua no limite, então a sequência obtida pela aplicação dessa função também converge em probabilidade (Vaart, 1998).

Como

$$\mathbf{S} \xrightarrow{P} \Sigma$$

no regime de dimensão fixa e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

a transformação g é contínua em Σ . Portanto,

$$g(\mathbf{S}) \xrightarrow{P} g(\Sigma).$$

Como

$$g(\mathbf{S}) = \mathbf{R}$$

e

$$g(\Sigma) = \mathcal{R},$$

segue que

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \tag{10.103}$$

Portanto, a matriz de correlações amostral é consistente para a matriz de correlações populacional, embora suas entradas possam ser viesadas em amostras finitas.

10.6.4 Transformações de localização e escala

O efeito populacional das mudanças de localização e escala sobre a correlação foi estabelecido na Equação 8.25. Para uma realização observada, considere

$$y_{ij} = a_j + b_j x_{ij}, \quad b_j \neq 0.$$

A localização a_j desaparece após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \operatorname{sgn}(b_j) \operatorname{sgn}(b_k) r_{X_j X_k}. \quad (10.104)$$

Fatores de escala positivos preservam a correlação. Quando apenas um dos fatores b_j e b_k é negativo, o sinal da correlação é invertido. Mudanças de localização não alteram a correlação.

Em forma matricial, para

$$\mathbf{Y} = \mathbf{X} \mathbf{D}_b + \mathbf{1}_n \mathbf{a}^\top,$$

com

$$\mathbf{D}_b = \operatorname{diag}(b_1, \dots, b_p),$$

defina

$$\mathbf{D}_{\operatorname{sgn}} = \operatorname{diag}[\operatorname{sgn}(b_1), \dots, \operatorname{sgn}(b_p)].$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\operatorname{sgn}} \mathbf{R}_X \mathbf{D}_{\operatorname{sgn}}. \quad (10.105)$$

Se todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X.$$

Para dois blocos, defina as matrizes diagonais aleatórias

$$\mathbf{D}_X = \operatorname{diag}(S_{X_1 X_1}, \dots, S_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} \left(S_{Y_1 Y_1}, \dots, S_{Y_q Y_q} \right).$$

Quando todas as variâncias amostrais envolvidas são positivas, define-se a matriz de correlações cruzadas amostral por

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2}. \quad (10.106)$$

Seu elemento (j, k) é

$$R_{X_j Y_k} = \frac{S_{X_j Y_k}}{\sqrt{S_{X_j X_j} S_{Y_k Y_k}}}.$$

Após a observação da amostra,

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2},$$

em que

$$\mathbf{D}_X = \text{diag} \left(s_{X_1 X_1}, \dots, s_{X_p X_p} \right)$$

e

$$\mathbf{D}_Y = \text{diag} \left(s_{Y_1 Y_1}, \dots, s_{Y_q Y_q} \right).$$

Seu elemento observado é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}}.$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top$$

e, após a observação,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top.$$

A matriz de correlações do vetor conjunto assume a forma

$$\mathbf{R}_{\text{conj}} = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix}. \quad (10.107)$$

Até este ponto, foram estabelecidas propriedades distintas das estatísticas utilizadas para representar associações entre variáveis. A matriz $\mathbf{S}_{XY}$ é não viesada e consistente para Σ_{XY} sob as condições especificadas, enquanto $\mathbf{T}_{XY}/n$ apresenta o mesmo fator de viés observado na estimação da matriz de covariâncias e, sob normalidade conjunta e existência do máximo, também corresponde ao estimador de máxima verossimilhança do bloco cruzado.

A matriz de correlações amostral $\mathbf{R}$ remove as escalas marginais, preserva a semidefinição positiva e o posto da matriz de covariâncias quando está definida, é consistente no regime de dimensão fixa, mas suas entradas não são, em geral, estimadores não viesados das correlações populacionais. Sob o modelo normal, a invariância da máxima verossimilhança conduz à mesma matriz $\mathbf{R}$.

As matrizes de covariâncias e correlações cruzadas serão utilizadas posteriormente em métodos que relacionam dois conjuntos de variáveis. O objetivo neste capítulo é estabelecer sua estimação e as propriedades necessárias para esses desenvolvimentos.

A próxima seção examina situações em que a dimensão, a redundância ou a sensibilidade das estatísticas clássicas dificultam a estimação da matriz de covariâncias.

10.7 Aprofundamento: dimensão, estabilidade e extensões da estimação

Esta seção examina situações em que a dimensão, o condicionamento ou a sensibilidade das estatísticas amostrais exigem cuidados adicionais. Os resultados anteriores trataram dos estimadores clássicos da média e da matriz de covariâncias. A regularização e a estimação robusta modificam esses procedimentos para tratar, respectivamente, problemas de instabilidade e de sensibilidade.

Uma matriz de covariâncias não estruturada de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. Assim, o número de parâmetros de dispersão a estimar cresce quadraticamente com p , enquanto o número de unidades amostrais permanece igual a n .

Regularização e robustez respondem a problemas diferentes. A regularização procura reduzir a instabilidade associada à dimensão, à redundância, ao tamanho amostral ou ao mau condicionamento. A estimação robusta procura reduzir a sensibilidade do procedimento a determinadas

formas de contaminação ou desvios do modelo. As duas abordagens podem ser combinadas, mas tratam de problemas distintos.

10.7.1 Relação entre p e n

O limite de posto estabelecido na Equação 10.81,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1),$$

permite distinguir diferentes regimes dimensionais.

Dimensão fixa. No regime clássico,

$$p$$

permanece fixo enquanto

$$n \longrightarrow \infty.$$

Sob as condições da Proposição 10.12,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Como p é fixo, a convergência dos elementos implica convergência em qualquer norma matricial sobre $\mathbb{R}^{p \times p}$, pois todas essas normas são equivalentes em dimensão finita.

Dimensão crescente. Quando

$$p = p_n$$

também aumenta com n , os resultados obtidos para dimensão fixa não podem ser transferidos automaticamente. Um regime de referência é

$$\frac{p_n}{n} \longrightarrow c, \quad 0 < c < 1.$$

Nesse regime, a matriz de covariâncias amostral pode possuir posto completo e, ainda assim, apresentar elevada variabilidade em seu espectro.

O controle dos erros de estimação elemento a elemento não garante, por si só, controle do erro matricial em norma espectral. Consequentemente, boa estimação das covariâncias individuais

não assegura automaticamente boa estimação dos autovalores, autovetores, determinante, inversa ou formas quadráticas que dependem da matriz inversa.

Além disso, o número de covariâncias fora da diagonal é

$$\frac{p(p-1)}{2},$$

e todas são estimadas a partir das mesmas n unidades.

Não existe um valor universal de p/n que separe matrizes estáveis e instáveis. O comportamento depende também da estrutura de Σ , da separação entre seus autovalores, da distribuição populacional e da função da matriz utilizada posteriormente.

Dimensão maior ou igual ao tamanho amostral. Se

$$p \geq n,$$

Equação 10.81 implica

$$\text{posto}(\mathbf{S}) \leq n - 1 < p.$$

Logo, a matriz de covariâncias amostral é necessariamente singular.

Essa singularidade não implica singularidade de Σ . Ela pode decorrer exclusivamente do número limitado de direções amostrais disponíveis após a centralização.

Posto amostral e posto populacional

Quando

$$p \geq n,$$

$\mathbf{S}$ é singular por construção, mesmo que a matriz populacional satisfaça

$$\Sigma \succ \mathbf{0}.$$

A singularidade da matriz amostral, portanto, não constitui evidência suficiente de singularidade da matriz de covariâncias populacional.

10.7.2 Condicionamento e inversão

Considere uma realização positiva definida,

$$\mathbf{S} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p),$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

A inversa é

$$\mathbf{S}^{-1} = \mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^\top.$$

Autovalores pequenos de $\mathbf{S}$ tornam-se pesos elevados em $\mathbf{S}^{-1}$.

O número de condição espectral foi definido na Definição 6.9. Para uma matriz simétrica positiva definida,

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.108)$$

Quanto maior essa razão, maior é a diferença entre as escalas espectrais extremas da matriz. Quando

$$\ell_{\min}(\mathbf{S}) \longrightarrow 0,$$

tem-se

$$\kappa_2(\mathbf{S}) \longrightarrow \infty.$$

Se $\mathbf{S}$ é singular, o número de condição associado à inversão é infinito. Portanto, invertibilidade e bom condicionamento são propriedades distintas.

O mau condicionamento torna a inversa sensível a erros de estimação: pequenas perturbações em $\mathbf{S}$ podem produzir alterações acentuadas em

$$\mathbf{S}^{-1}.$$

O determinante também depende de todo o espectro:

$$\det(\mathbf{S}) = \prod_{j=1}^p \ell_j.$$

Já a estabilidade dos autovetores depende não somente da magnitude dos autovalores, mas também de sua separação. Autovalores muito próximos podem produzir direções individuais sensíveis a pequenas perturbações.

Considere, por exemplo, a contraparte amostral da forma quadrática utilizada na distância de Mahalanobis definida na Definição 8.9:

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Nas coordenadas dos autovetores de $\mathbf{S}$,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Assim, erros na estimação de autovalores pequenos podem ser amplificados pela inversão, pois essas direções recebem pesos proporcionais a $1/\ell_j$.

Inversão computacional

A existência de $\mathbf{S}^{-1}$ não significa que seja necessário formá-la explicitamente. Quando o objetivo é calcular

$$\mathbf{S}^{-1} \mathbf{b},$$

é preferível, em geral, resolver o sistema

$$\mathbf{S} \mathbf{x} = \mathbf{b}.$$

Essa escolha não elimina o mau condicionamento, mas evita uma inversão explícita desnecessária.

10.7.3 Regularização

A regularização substitui a matriz de covariâncias amostral por um estimador que combina $\mathbf{S}$ com restrições ou valores de referência previamente especificados. O objetivo pode ser reduzir variabilidade, melhorar o condicionamento ou produzir uma matriz invertível.

Uma classe simples combina $\mathbf{S}$ com uma matriz-alvo (Ledoit; Wolf, 2004).

Definição 10.18 (Estimador de covariância por contração). Considere uma matriz-alvo fixada

$$\Gamma \in \mathbb{R}^{p \times p}, \quad \Gamma \succeq \mathbf{0},$$

e um peso

$$0 \leq \lambda \leq 1.$$

Define-se o estimador por contração

$$\widehat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \quad (10.109)$$

Para

$$\lambda = 0,$$

recupera-se $\mathbf{S}$. Para

$$\lambda = 1,$$

o estimador coincide com o alvo.

A contração geralmente introduz viés. Sua avaliação deve considerar conjuntamente viés e variabilidade por meio de uma função de perda e do risco correspondente.

A consistência também depende da forma como a regularização varia com o tamanho amostral. Se $\lambda \in (0, 1]$ e Γ são fixos e

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

então

$$\widehat{\Sigma}_\lambda \xrightarrow{P} (1 - \lambda)\Sigma + \lambda\Gamma.$$

Portanto, com $\lambda > 0$ fixo, o estimador não é, em geral, consistente para Σ . Se a matriz-alvo Γ é fixa e o peso passa a depender de n , com

$$\lambda_n \rightarrow 0,$$

então

$$\widehat{\Sigma}_{\lambda_n} = (1 - \lambda_n)\mathbf{S} + \lambda_n \Gamma \xrightarrow{P} \Sigma,$$

sempre que

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Assim, nesse caso, a intensidade da regularização desaparece assintoticamente e a consistência da matriz de covariâncias amostral é preservada.

Em aplicações, o alvo e o peso podem ser estimados a partir dos próprios dados. Nesse caso,

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\Gamma}. \quad (10.110)$$

A aleatoriedade de $\widehat{\lambda}$ e de $\widehat{\Gamma}$ passa, então, a fazer parte das propriedades do estimador.

A matriz-alvo precisa ser compatível com as unidades e escalas das variáveis. Um alvo diagonal preserva as escalas marginais e reduz as covariâncias. Um alvo esférico $\tau\mathbf{I}_p$ pressupõe que uma escala comum possua interpretação. Para matrizes de correlações, a identidade $\mathbf{I}_p$ constitui uma escolha natural de referência. O alvo também pode representar relações previamente especificadas entre as variáveis, como covariâncias nulas ou uma estrutura de correlação definida antes da estimação.

A identidade $\mathbf{I}_p$ não é um alvo neutro para uma matriz de covariâncias quando as variáveis são medidas em unidades ou escalas distintas.

Um alvo esférico adaptado à escala observada pode utilizar

$$\widehat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}), \quad (10.111)$$

levando a

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\tau}\mathbf{I}_p. \quad (10.112)$$

Essa escolha pressupõe que uma variância média comum tenha significado para as variáveis consideradas. Além disso, a definitude positiva produzida pelo componente esférico exige $\hat{\tau} > 0$. Como $\mathbf{S} \succeq \mathbf{0}$, essa condição equivale a haver variabilidade amostral positiva em pelo menos uma direção.

Outro alvo é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(\mathbf{S}_{11}, \dots, \mathbf{S}_{pp})$$

com

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.113)$$

Nesse caso, as variâncias amostrais permanecem inalteradas e as covariâncias são multiplicadas por $1 - \lambda$.

Proposição 10.15 (Definitude positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\hat{\Sigma}_{\lambda} \succ \mathbf{0}. \quad (10.114)$$

Comprovação. Para qualquer $\mathbf{a} \neq \mathbf{0}$,

$$\mathbf{a}^{\top} \hat{\Sigma}_{\lambda} \mathbf{a} = (1 - \lambda)\mathbf{a}^{\top} \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^{\top} \Gamma \mathbf{a}.$$

A primeira parcela é não negativa e a segunda é estritamente positiva. Logo,

$$\mathbf{a}^{\top} \hat{\Sigma}_{\lambda} \mathbf{a} > 0.$$

□

Com um alvo esférico,

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0,$$

e uma decomposição

$$\mathbf{S} = \mathbf{Q} \text{diag}(\mathbf{L}_1, \dots, \mathbf{L}_p) \mathbf{Q}^\top,$$

obtém-se

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \text{diag}[(1 - \lambda)\mathbf{L}_1 + \lambda\tau, \dots, (1 - \lambda)\mathbf{L}_p + \lambda\tau] \mathbf{Q}^\top. \quad (10.115)$$

Portanto,

$$\mathbf{L}_{j,\lambda} = (1 - \lambda)\mathbf{L}_j + \lambda\tau. \quad (10.116)$$

Se

$$\mathbf{L}_j = 0$$

e

$$\lambda > 0,$$

então

$$\mathbf{L}_{j,\lambda} = \lambda\tau > 0.$$

A contração esférica afasta os autovalores de zero e pode melhorar o condicionamento. Esse efeito algébrico não garante redução do erro de estimação. A escolha do alvo e de λ deve ser avaliada segundo a função de perda e o risco considerados.

A Figura 10.2 compara o espectro da covariância amostral com uma versão regularizada.

No regime $p < n$, a regularização desloca os autovalores na direção do alvo. No regime $p \geq n$, os autovalores nulos decorrentes do limite de posto são substituídos por valores positivos.

A figura mostra um efeito algébrico da regularização. A escolha de λ e do alvo é um problema estatístico distinto e não será desenvolvida algoritmicamente neste capítulo.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

10.7.4 Pseudoinversa e regularização

A pseudoinversa de Moore–Penrose foi definida na Definição 6.11. Para uma matriz de covariâncias amostral com decomposição espectral reduzida

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que Λ_r contém os r autovalores positivos, tem-se

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.117)$$

A pseudoinversa e a regularização resolvem problemas matemáticos diferentes.

Para visualizar essa diferença, considere

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\ell_1, \dots, \ell_p) \mathbf{Q}^\top,$$

com

$$\ell_j \geq 0.$$

A pseudoinversa atribui os pesos

$$\begin{cases} 1/\ell_j, & \ell_j > 0, \\ 0, & \ell_j = 0. \end{cases}$$

Considere agora

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

com

$$0 < \lambda \leq 1 \quad \text{e} \quad \tau > 0.$$

Sua inversa é

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1 - \lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.118)$$

Se

$$\ell_j = 0,$$

a pseudoinversa atribui peso zero, enquanto a inversa regularizada atribui

$$\frac{1}{\lambda\tau}.$$

A pseudoinversa não modifica $\mathbf{S}$; ela substitui a inversão usual por sua extensão de Moore–Penrose. Os autovalores positivos continuam recebendo pesos $1/\ell_j$, mesmo quando são muito pequenos, enquanto as direções associadas a autovalores nulos recebem peso zero.

A regularização modifica a própria matriz utilizada para estimar Σ e define outro procedimento estatístico. Na contração esférica, os autovalores são afastados de zero e a inversão passa a utilizar pesos finitos determinados pelos autovalores regularizados. Portanto, pseudoinversa e regularização tratam a singularidade por mecanismos diferentes.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ ou por uma inversa regularizada modifica a estatística utilizada. Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica não podem ser transferidas automaticamente para essas substituições.

10.7.5 Sensibilidade e robustez

O vetor de médias e a matriz de covariâncias amostrais podem sofrer alterações arbitrariamente grandes quando uma observação é substituída por outra suficientemente afastada da maior parte dos dados (Maronna et al., 2019).

Considere a substituição de uma observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.119)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

A alteração não possui limite uniforme quando $\mathbf{x}_k^*$ pode se afastar arbitrariamente dos demais dados. Assim, uma única observação pode produzir uma mudança arbitrariamente grande na média amostral.

Na matriz de covariâncias, os produtos externos

$$(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

fazem com que observações afastadas possam modificar simultaneamente dispersões, covariâncias e direções espectrais.

Uma observação extrema não deve ser identificada automaticamente como erro. Ela pode representar uma unidade válida situada em uma região pouco frequente da população, uma observação proveniente de outra população ou um erro de registro ou medição. O comportamento extremo também pode indicar que a distribuição possui caudas mais pesadas, assimetria ou heterogeneidade não representadas pelo modelo adotado.

A decisão de manter, corrigir ou excluir uma observação exige conhecimento do processo de coleta e do contexto.

Estimadores robustos de localização e dispersão procuram limitar determinados tipos de sensibilidade. Sua comparação depende de quanto as estimativas se alteram diante de observações contaminadas, da eficiência sob o modelo adotado como referência, da equivariância, das condições de existência em função de n e p , do custo computacional e do parâmetro de localização ou dispersão que o procedimento pretende estimar. Nenhum procedimento apresenta o melhor desempenho em todos esses critérios.

Observações extremas, alta dimensão e má especificação correspondem a problemas diferentes. Observações extremas podem alterar fortemente estimadores sensíveis. A alta dimensão afeta o número de parâmetros a estimar, o posto e a estabilidade da matriz. A má especificação ocorre quando a distribuição ou a estrutura assumida pelo modelo não representa adequadamente o processo que gerou os dados. Esses problemas podem ocorrer simultaneamente, mas exigem tratamentos diferentes.

A avaliação de uma matriz de covariâncias estimada depende da finalidade da análise. Tamanho amostral e dimensão determinam restrições de posto; o espectro informa sobre direções de variabilidade e condicionamento; as escalas das variáveis influenciam a interpretação e a escolha de alvos de regularização; e a sensibilidade das estimativas deve ser considerada quando observações extremas ou desvios do modelo podem alterar substancialmente os resultados.

O exemplo integrado a seguir reúne os principais objetos construídos no capítulo em uma única amostra.

10.8 Exemplo integrado

O exemplo reúne a estimação da localização, da dispersão e das relações entre dois blocos de variáveis. Como os cálculos são realizados para uma amostra observada, os resultados numéricos são estimativas, representadas pelos correspondentes objetos observados.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 2 \\ 3 & 5 & 3 \\ 3 & 6 & 3 \\ 5 & 7 & 4 \\ 5 & 6 & 6 \\ 6 & 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 9 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A correspondência entre as linhas de $\mathbf{X}$ e $\mathbf{Y}$ precisa ser preservada para a estimação das covariâncias cruzadas.

Os valores foram escolhidos para que as médias sejam inteiras e os produtos cruzados possam ser calculados sem arredondamento. Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 6 \\ 4 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

As matrizes centralizadas são, portanto,

$$\mathbf{X}_c = \begin{bmatrix} -2 & -2 & -2 \\ -1 & -1 & -1 \\ -1 & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 2 \\ 2 & 2 & 2 \end{bmatrix}$$

e

$$\mathbf{Y}_c = \begin{bmatrix} -3 & -2 \\ -1 & -3 \\ 0 & 0 \\ 1 & 2 \\ -1 & -1 \\ 4 & 4 \end{bmatrix}.$$

Em ambas as matrizes, cada coluna soma zero, como exige a centralização pela média amostral. Para o primeiro bloco, a matriz SQPC observada é

$$\mathbf{T}_X = \mathbf{X}_c^\top \mathbf{X}_c.$$

Os elementos da diagonal são somas de quadrados. Por exemplo,

$$t_{11} = (-2)^2 + (-1)^2 + (-1)^2 + 1^2 + 1^2 + 2^2 = 12.$$

Os elementos fora da diagonal são somas de produtos cruzados. Por exemplo,

$$\begin{aligned} t_{12} &= (-2)(-2) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(0) + (2)(2) \\ &= 10. \end{aligned}$$

Calculando os demais elementos da mesma forma,

$$\mathbf{T}_X = \begin{bmatrix} 12 & 10 & 12 \\ 10 & 10 & 9 \\ 12 & 9 & 14 \end{bmatrix}. \quad (10.120)$$

A simetria decorre de $t_{jk} = t_{kj}$, de modo que somente a diagonal e uma das partes triangulares precisam ser calculadas diretamente.

A matriz de covariâncias amostral utiliza o divisor

$$n - 1 = 5.$$

Logo,

$$\begin{aligned}\mathbf{S}_X &= \frac{1}{5}\mathbf{T}_X \\ &= \begin{bmatrix} 2,4 & 2,0 & 2,4 \\ 2,0 & 2,0 & 1,8 \\ 2,4 & 1,8 & 2,8 \end{bmatrix}.\end{aligned}\tag{10.121}$$

A matriz $\mathbf{S}_X$ é a realização observada do estimador não viesado $\mathbf{S}_X$ de Σ_{XX} , cujo não viesamento foi estabelecido na Equação 10.69.

Sob o modelo normal multivariado definido na Definição 9.1, nesta amostra

$$\text{posto}(\mathbf{T}_X) = 3.$$

Portanto, a condição de posto completo da Proposição 10.3 é satisfeita. Assim, a estimativa de máxima verossimilhança da matriz de covariâncias é

$$\begin{aligned}\widehat{\Sigma}_{XX, \text{MV, obs}} &= \frac{1}{6}\mathbf{T}_X \\ &= \begin{bmatrix} 2 & 5/3 & 2 \\ 5/3 & 5/3 & 3/2 \\ 2 & 3/2 & 7/3 \end{bmatrix}.\end{aligned}\tag{10.122}$$

As duas matrizes estão relacionadas por

$$\widehat{\Sigma}_{XX, \text{MV, obs}} = \frac{5}{6}\mathbf{S}_X.$$

Como diferem apenas pelo fator escalar positivo $5/6$, possuem os mesmos autovetores e o mesmo posto. Seus autovalores diferem pelo fator $5/6$, enquanto o número de condição espectral permanece inalterado.

Em cálculos manuais, os valores exatos devem ser mantidos enquanto possível. Por isso, a estimativa de máxima verossimilhança foi apresentada em forma fracionária. O arredondamento deve ser realizado apenas na apresentação dos resultados que não admitem uma representação exata simples. Utilizar valores já arredondados de médias, covariâncias, correlações ou autovetores em cálculos posteriores pode acumular erros e produzir resultados diferentes dos obtidos a partir dos valores exatos.

Neste exemplo, $\mathbf{T}_X$ é exata e $\mathbf{S}_X = \mathbf{T}_X/5$ possui representação decimal finita. Para calcular correlações, pode-se utilizar diretamente

$$r_{jk} = \frac{t_{jk}}{\sqrt{t_{jj}t_{kk}}},$$

pois o divisor comum de $\mathbf{S}_X$ se cancela. Autovalores e números de condição apresentados em forma decimal devem ser calculados com os valores não arredondados e arredondados apenas ao final.

A matriz de correlações observada é

$$\mathbf{R}_X \approx \begin{bmatrix} 1,000 & 0,913 & 0,926 \\ 0,913 & 1,000 & 0,761 \\ 0,926 & 0,761 & 1,000 \end{bmatrix}. \quad (10.123)$$

As três correlações são positivas. A maior ocorre entre X_1 e X_3 ,

$$r_{13} \approx 0,926,$$

e a menor entre X_2 e X_3 ,

$$r_{23} \approx 0,761.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 \approx 6,579, \quad \ell_2 \approx 0,560 \quad \text{e} \quad \ell_3 \approx 0,061.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e

$$\mathbf{S}_X \succ \mathbf{0}.$$

Seu número de condição espectral é aproximadamente

$$\kappa_2(\mathbf{S}_X) = \frac{\ell_1}{\ell_3} \approx 108,3.$$

O valor de $\kappa_2(\mathbf{S}_X)$ foi calculado com os autovalores antes do arredondamento. Dividir os valores exibidos, já arredondados, pode produzir uma aproximação ligeiramente diferente.

Portanto, $\mathbf{S}_X$ é invertível, mas seus autovalores apresentam magnitudes bastante distintas. O valor relativamente elevado de $\kappa_2(\mathbf{S}_X)$ mostra que invertibilidade e bom condicionamento são propriedades distintas.

Para estimar as relações entre os dois blocos, utiliza-se

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c.$$

Por exemplo, o elemento correspondente a X_1 e Y_1 é

$$\begin{aligned} t_{X_1 Y_1} &= (-2)(-3) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(-1) + (2)(4) \\ &= 15. \end{aligned}$$

Os demais produtos cruzados fornecem

$$\mathbf{T}_{XY} = \begin{bmatrix} 15 & 16 \\ 16 & 17 \\ 13 & 13 \end{bmatrix}. \quad (10.124)$$

Logo, pela definição de covariância cruzada observada na Definição 8.13,

$$\mathbf{S}_{XY} = \frac{1}{5} \mathbf{T}_{XY} = \begin{bmatrix} 3,0 & 3,2 \\ 3,2 & 3,4 \\ 2,6 & 2,6 \end{bmatrix}. \quad (10.125)$$

Por exemplo,

$$s_{X_3 Y_1} = 2,6$$

é a covariância amostral entre X_3 e Y_1 .

A inversão da ordem dos blocos segue Equação 8.73:

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 3,0 & 3,2 & 2,6 \\ 3,2 & 3,4 & 2,6 \end{bmatrix}.$$

Para o segundo bloco,

$$\mathbf{T}_Y = \mathbf{Y}_c^\top \mathbf{Y}_c = \begin{bmatrix} 28 & 28 \\ 28 & 34 \end{bmatrix},$$

de modo que

$$\mathbf{S}_Y = \frac{1}{5} \mathbf{T}_Y = \begin{bmatrix} 5,6 & 5,6 \\ 5,6 & 6,8 \end{bmatrix}.$$

Reunindo as cinco variáveis,

$$\mathbf{X}_{\text{conj}} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

a matriz SQPC conjunta possui a forma em blocos

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} \mathbf{T}_X & \mathbf{T}_{XY} \\ \mathbf{T}_{YX} & \mathbf{T}_Y \end{bmatrix}.$$

Numericamente,

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} 12 & 10 & 12 & 15 & 16 \\ 10 & 10 & 9 & 16 & 17 \\ 12 & 9 & 14 & 13 & 13 \\ 15 & 16 & 13 & 28 & 28 \\ 16 & 17 & 13 & 28 & 34 \end{bmatrix}.$$

Como $n - 1 = 5$,

$$\mathbf{S}_{\text{conj}} = \frac{1}{5} \mathbf{T}_{\text{conj}} = \begin{bmatrix} 2,4 & 2,0 & 2,4 & 3,0 & 3,2 \\ 2,0 & 2,0 & 1,8 & 3,2 & 3,4 \\ 2,4 & 1,8 & 2,8 & 2,6 & 2,6 \\ 3,0 & 3,2 & 2,6 & 5,6 & 5,6 \\ 3,2 & 3,4 & 2,6 & 5,6 & 6,8 \end{bmatrix}. \quad (10.126)$$

A organização em blocos permite identificar diretamente as covariâncias internas de $\mathbf{X}$, as covariâncias internas de $\mathbf{Y}$ e as covariâncias cruzadas entre os dois conjuntos.

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_{\text{conj}}) \leq 5.$$

A matriz conjunta centralizada é

$$\mathbf{X}_{\text{conj},c} = \begin{bmatrix} -2 & -2 & -2 & -3 & -2 \\ -1 & -1 & -1 & -1 & -3 \\ -1 & 0 & -1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 2 \\ 1 & 0 & 2 & -1 & -1 \\ 2 & 2 & 2 & 4 & 4 \end{bmatrix}.$$

Seu escalonamento fornece cinco pivôs, de modo que

$$\text{posto}(\mathbf{X}_{\text{conj},c}) = 5.$$

Como

$$\mathbf{T}_{\text{conj}} = \mathbf{X}_{\text{conj},c}^{\top} \mathbf{X}_{\text{conj},c},$$

segue de Equação 8.60 que

$$\text{posto}(\mathbf{S}_{\text{conj}}) = 5.$$

Portanto,

$$\mathbf{S}_{\text{conj}} \succ \mathbf{0}.$$

O caso $n = 6$ e $p = 5$ está exatamente no limite $n = p + 1$. Esse tamanho amostral permite posto completo, mas não o garante para uma amostra arbitrária.

O exemplo mostra como uma única amostra produz realizações dos principais objetos definidos no capítulo. Os vetores $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ estimam as médias populacionais, enquanto $\mathbf{T}_X$ é a realização da estatística SQPC. A divisão de $\mathbf{T}_X$ por $n - 1$ produz a estimativa não viesada $\mathbf{S}_X$; a divisão por n produz a estimativa pelo método dos momentos e, sob o modelo normal e as condições de existência do máximo, também a estimativa de máxima verossimilhança.

A matriz $\mathbf{R}_X$ utiliza a mesma informação de covariância após a remoção das escalas marginais. O posto completo de $\mathbf{S}_X$ garante sua invertibilidade, mas o número de condição mostra que essa propriedade não garante estabilidade da inversão.

O pareamento das linhas de $\mathbf{X}$ e $\mathbf{Y}$ determina os produtos cruzados em $\mathbf{T}_{XY}$ e, conseqüentemente, as covariâncias em $\mathbf{S}_{XY}$. A matriz conjunta reúne em um único objeto as covariâncias internas dos dois blocos e as covariâncias entre eles.

Todos os valores apresentados são realizações obtidas nesta amostra. Não viesamento, consistência, eficiência e outras propriedades dos estimadores descrevem seu comportamento ao considerar as possíveis amostras geradas pelo modelo.

10.9 Síntese do capítulo

Este capítulo estabeleceu a relação entre parâmetros populacionais, estatísticas amostrais, estimadores e suas realizações observadas.

A distinção central envolve quatro objetos. O parâmetro θ é uma característica fixa da distribuição populacional. Uma amostra aleatória $\mathcal{X}$ produz estatísticas por meio de funções dos dados,

$$\mathbf{G} = G(\mathcal{X}).$$

Quando uma estatística é utilizada para estimar θ , ela constitui um estimador,

$$\hat{\theta} = G(\mathcal{X}).$$

Após a observação da amostra, a realização

$$\hat{\theta}_{\text{obs}} = G(\mathbf{x})$$

é a estimativa do parâmetro. Portanto, todo estimador é uma estatística, mas nem toda estatística é utilizada como estimador.

Para uma amostra multivariada i.i.d., o vetor de médias amostrais estima μ , enquanto a matriz de covariâncias amostral estima Σ :

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

e

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

em que $\mathbf{T}$ é a matriz SQPC amostral definida na Definição 10.13.

O método dos momentos e a máxima verossimilhança são princípios de construção de estimadores. O método utilizado não determina, por si só, as propriedades do estimador obtido.

O método dos momentos fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{x}}$$

e

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado e quando o máximo existe, a máxima verossimilhança conduz às mesmas estatísticas.

A segunda estatística é viesada em amostras finitas, enquanto

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é não viesada. As duas são consistentes para Σ no regime de dimensão fixa sob as condições estabelecidas no capítulo.

Os resultados na Proposição 10.6 e Equação 10.69 fornecem

$$E(\bar{\mathbf{X}}) = \mu, \quad \text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}, \quad E(\mathbf{S}) = \Sigma.$$

No regime de dimensão fixa, Proposição 10.7 e Proposição 10.12 estabelecem

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad \text{e} \quad \mathbf{S} \xrightarrow{P} \Sigma.$$

Para variáveis organizadas em dois blocos pareados,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}$$

estima a matriz de covariâncias cruzadas. Quando as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}$$

fornece a matriz de correlações amostral.

Os principais objetos do capítulo podem ser resumidos por:

Tabela 10.2: Relação entre parâmetros, estatísticas, estimadores e valores observados utilizados no capítulo.

Parâmetro ou objeto	Estatística/estimador	Propriedade destacada	Valor observado
μ	$\bar{\mathbf{X}}$	Não viesado e consistente; MM; MV sob normalidade e existência do máximo	$\bar{\mathbf{x}}$
Σ	$\mathbf{S} = \mathbf{T}/(n-1)$	Não viesado e consistente	$\mathbf{S}$
Σ	$\mathbf{T}/n$	MM; MV sob normalidade e existência do máximo; viesado em amostras finitas e consistente	$\mathbf{T}/n$
SQPC amostral	$\mathbf{T}$	Estatística que reúne somas de quadrados e produtos cruzados	$\mathbf{T}$
Σ_{XY}	$\mathbf{S}_{XY}$	Não viesado e consistente	$\mathbf{S}_{XY}$
$\mathcal{R}$	$\mathbf{R}$	Em geral viesado, mas consistente; MV sob normalidade e existência do máximo	$\mathbf{R}$

As propriedades estudadas respondem a perguntas diferentes. O viés compara a esperança do estimador com o parâmetro; a variabilidade descreve quanto o estimador muda entre amostras; o erro quadrático médio combina erro sistemático e variabilidade segundo uma função de perda; a consistência descreve o comportamento quando n aumenta; e a eficiência compara estimadores concorrentes segundo sua variabilidade ou risco. A suficiência verifica se uma redução da amostra preserva a informação sobre o parâmetro, enquanto a equivariância descreve a resposta do estimador a transformações dos dados. A robustez examina quanto o procedimento pode ser alterado pelas formas de contaminação ou perturbação consideradas.

A estrutura de posto

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1)$$

mostra por que dimensão e tamanho amostral precisam ser considerados conjuntamente. Quando $p \geq n$, a covariância amostral é necessariamente singular. Mesmo quando existe uma inversa, seu uso pode ser instável quando alguns autovalores são pequenos.

Pseudoinversa e regularização tratam singularidade e condicionamento por mecanismos diferentes. A pseudoinversa mantém $\mathbf{S}$ e modifica a operação utilizada para trabalhar com suas direções de variância nula. A regularização substitui $\mathbf{S}$ por outro estimador, por exemplo combinando-a com uma matriz-alvo. Essa modificação pode afastar autovalores de zero e melhorar o condicionamento, mas também altera viés, risco e consistência. Com peso de contração fixo e alvo diferente de Σ , a consistência para Σ não é garantida.

Ao término deste capítulo, deve-se ser capaz de:

- distinguir parâmetro, estatística, estimador, estimativa e distribuição amostral;
- avaliar viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência, equivariância e robustez;
- distinguir os princípios do método dos momentos e da máxima verossimilhança;
- construir o vetor de médias amostrais, a matriz SQPC e os estimadores da matriz de covariâncias;
- explicar a origem e a função dos divisores n e $n - 1$;
- construir estimadores de covariâncias cruzadas e correlações;
- analisar posto, singularidade e condicionamento de matrizes estimadas;
- distinguir pseudoinversa, regularização e estimação robusta segundo o problema que cada procedimento procura tratar.

O Capítulo 11 utiliza a matriz de covariâncias populacional de Definição 8.2, o modelo normal multivariado de Definição 9.1 e os estimadores desenvolvidos neste capítulo para construir o **modelo linear multivariado**. Nesse modelo, várias variáveis-resposta são relacionadas simultaneamente a uma matriz de delineamento, produzindo uma matriz de parâmetros, valores ajustados, resíduos e matrizes SQPC associadas às fontes de variação.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

11 Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

11.1 Problemas e estruturas das técnicas multivariadas

11.2 Formulação da Análise de Componentes Principais

11.3 Formulação da Análise Fatorial

11.4 Formulação da Análise de Agrupamentos

11.5 Formulação do Escalonamento Multidimensional

11.6 Formulação da Análise de Correspondência

11.7 Formulação da MANOVA

11.8 Formulação da Análise Discriminante

11.9 Formulação da Correlação Canônica

11.10 Formulação da Análise Conjunta

Referências

ANDERSON, Theodore W. **An Introduction to Multivariate Statistical Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

APOSTOL, Tom M. **Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability**. 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. **Métodos multivariados de análise estatística**. 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. **Measure, Integration & Real Analysis**. Cham: Springer, 2020. v. 282

BOYD, Stephen; VANDENBERGHE, Lieven. **Convex Optimization**. Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury, 2002.

DEMME, James W. **Singular Value Decomposition**. In: BAI, Zhaojun *et al.* (Orgs.). **Templates for the Solution of Algebraic Eigenvalue Problems: A Practical Guide**. Philadelphia: Society for Industrial; Applied Mathematics, 2000. p. 135–147.

DRISCOLL, Tobin A.; BRAUN, Richard J. **Fundamentals of Numerical Computation: Julia Edition**. Philadelphia: Society for Industrial; Applied Mathematics, 2022. p. 614

EATON, Morris L. **Multivariate Statistics: A Vector Space Approach**. Beachwood, OH: Institute of Mathematical Statistics, 2007. v. 53 p. 512

GOLUB, Gene H.; VAN LOAN, Charles F. **Matrix Computations**. 4. ed. Baltimore: Johns Hopkins University Press, 2013.

HAIR, Jr., Joseph F. *et al.* **Multivariate Data Analysis**. 8. ed. Andover: Cengage Learning, 2018.

HARVILLE, David A. **Matrix Algebra From a Statistician's Perspective**. New York:

Springer, 1997. p. 634

HORN, Roger A.; JOHNSON, Charles R. **Topics in Matrix Analysis**. Cambridge: Cambridge University Press, 1991.

HORN, Roger A.; JOHNSON, Charles R. **Matrix Analysis**. 2. ed. Cambridge: Cambridge University Press, 2013.

JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.

LEDOIT, Olivier; WOLF, Michael. **A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices**. **Journal of Multivariate Analysis**, v. 88, n. 2, p. 365–411, 2004.

MAGNUS, Jan R.; NEUDECKER, Heinz. **Matrix Differential Calculus with Applications in Statistics and Econometrics**. 3. ed. Chichester: John Wiley & Sons, 2019. p. 504

MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. **Métodos Estatísticos Multivariados: Uma Introdução**. 4. ed. Porto Alegre: Bookman, 2019. p. 254

MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. **Multivariate Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2024. p. 592

MARONNA, Ricardo A. *et al.* **Robust Statistics: Theory and Methods (with R)**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464

MEYER, Carl D. **Matrix Analysis and Applied Linear Algebra**. 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991

MINGOTI, Sueli Aparecida. **Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada**. Belo Horizonte: Editora UFMG, 2005.

RENCER, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2012.

SIDI, Avram. **Vector Extrapolation Methods with Applications**. Philadelphia: Society for Industrial; Applied Mathematics, 2017. p. 381

VAART, A. W. van der. **Asymptotic Statistics**. Cambridge: Cambridge University Press, 1998. p. 462