

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	11
Direitos Autorais e Uso da Obra	11
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	11
 I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multi- variada	 12
 1 Vetores e representação dos dados multivariados	 13
1.1 Escalares, vetores e matrizes	13
1.2 O espaço $\mathbb{R}^p$	16
1.3 Representação matricial de um conjunto de dados	18
1.3.1 Linhas como observações	19
1.3.2 Colunas como variáveis	20
1.3.3 Espaço das observações e espaço das variáveis	21
1.3.4 Nuvem de pontos multivariada	22
1.4 Operações elementares com vetores	22
1.4.1 Soma e subtração	23
1.4.2 Multiplicação por escalar	24
1.4.3 Combinações lineares	25
1.5 Produto interno, norma, ângulo e distância euclidiana	27
1.6 Síntese do capítulo	32
 2 Álgebra matricial aplicada	 33
2.1 Operações matriciais fundamentais	33
2.1.1 Produto matriz-vetor	36
2.1.2 Produto entre matrizes	38
2.1.3 Propriedades do produto matricial	39
2.2 Transposição, simetria e traço	40
2.2.1 Transposição	41
2.2.2 Propriedades da transposição	42
2.2.3 Matrizes simétricas	44
2.2.4 Traço	47
2.3 Identidade, inversa, determinante, posto e sistemas lineares	50
2.3.1 Matriz identidade	50

2.3.2	Matriz inversa	52
2.3.3	Determinante	54
2.3.4	Interpretação geométrica do determinante	58
2.3.5	Posto	59
2.3.6	Sistemas lineares	61
2.3.7	Pseudoinversa	64
2.4	Matrizes ortogonais, diagonais e triangulares	65
2.4.1	Matrizes ortogonais	65
2.4.2	Matrizes diagonais	68
2.4.3	Matrizes triangulares	71
2.4.4	Sistemas triangulares	72
2.5	Formas bilineares, formas quadráticas e positividade	74
2.5.1	Formas bilineares	74
2.5.2	Formas quadráticas	75
2.5.3	Positividade	78
2.5.4	Superfícies de nível	80
2.6	Matrizes particionadas e complemento de Schur	81
2.6.1	Matrizes particionadas	81
2.6.2	Soma e multiplicação por escalar	82
2.6.3	Transposição por blocos	83
2.6.4	Multiplicação por blocos	83
2.6.5	Complemento de Schur	85
2.6.6	Determinante de uma matriz particionada	86
2.6.7	Inversão em blocos	87
2.6.8	Positividade e complemento de Schur	88
2.7	Síntese do capítulo	90
3	Espaços vetoriais, bases e projeções	92
3.1	Espaços, subespaços e geração	92
3.1.1	Subespaços vetoriais	94
3.1.2	Subespaço gerado	96
3.2	Independência linear, bases e dimensão	97
3.2.1	Independência linear	97
3.2.2	Independência linear e sistemas homogêneos	99
3.2.3	Bases	102
3.2.4	Coordenadas em uma base	103
3.2.5	Base canônica	105
3.2.6	Bases ortogonais e ortonormais	106
3.2.7	Dimensão	108
3.3	Espaços fundamentais de uma matriz	109
3.3.1	Espaço nulo	110
3.3.2	Espaço coluna e imagem	112
3.3.3	Espaço linha	115

3.3.4	Espaço nulo à esquerda	116
3.3.5	Teorema Posto–Nulidade	118
3.3.6	Os quatro espaços fundamentais	121
3.3.7	Complemento ortogonal	122
3.3.8	Relações de ortogonalidade	122
3.4	Produtos internos, bases ortonormais e matrizes de Gram	124
3.4.1	Produtos internos induzidos por matrizes	125
3.4.2	Norma e distância induzidas	127
3.4.3	Ortogonalidade induzida	128
3.4.4	Interpretação por transformação de coordenadas	128
3.4.5	Matrizes de Gram	130
3.4.6	Propriedades da matriz de Gram	131
3.4.7	Matrizes de Gram e bases ortonormais	133
3.4.8	Produtos cruzados em uma matriz de dados	134
3.5	Complementos ortogonais e projeções	135
3.5.1	Propriedades do Completo ortogonal	136
3.5.2	Dimensão do complemento ortogonal	137
3.5.3	Decomposição ortogonal	138
3.5.4	Projeção sobre uma direção	141
3.5.5	Projeção sobre um subespaço com base ortonormal	144
3.5.6	Projeção sobre o espaço coluna de uma matriz	146
3.5.7	Propriedades da matriz de projeção	150
3.5.8	Projeção sobre o complemento ortogonal	152
3.5.9	Projeção como melhor aproximação	157
3.5.10	Projeções e mínimos quadrados	159
3.6	Síntese do capítulo	162
4	Transformações lineares	166
4.1	Transformações lineares e representação matricial	166
4.1.1	Transformação determinada por uma base	168
4.1.2	Representação matricial nas bases canônicas	170
4.1.3	Imagem de um subespaço	172
4.2	Transformação de vetores e matrizes de dados	173
4.2.1	Novas variáveis como combinações lineares	175
4.2.2	Dimensão da configuração transformada	177
4.2.3	Efeito sobre diferenças e produtos internos	180
4.2.4	Transformação das matrizes de produtos internos	181
4.3	Composição, invertibilidade e perda de informação	182
4.3.1	Composição de transformações lineares	183
4.3.2	A ordem das transformações	184
4.3.3	Transformação inversa	186
4.3.4	Injetividade, sobrejetividade e bijetividade	188
4.3.5	Perda de informação	192

4.3.6	Redução de dimensionalidade	193
4.3.7	Transformações singulares	194
4.4	Transformações geométricas	195
4.4.1	Rotação	196
4.4.2	Reflexão	197
4.4.3	Escalonamento	199
4.4.4	Cisalhamento	200
4.4.5	Projeção	202
4.4.6	Comparação geométrica	202
4.4.7	Determinante, volume e orientação	204
4.5	Transformações ortogonais	205
4.5.1	Transformação de uma matriz de dados	207
4.5.2	Determinante e orientação	208
4.5.3	Matrizes ortogonais e bases ortonormais	209
4.5.4	Comparação com transformações não ortogonais	210
4.6	Mudanças de coordenadas e representação em bases	211
4.6.1	Conversão entre duas bases	213
4.6.2	Representação de uma transformação em bases gerais	214
4.6.3	Representação de um operador em uma nova base	217
4.6.4	Transformação ativa e mudança passiva	219
4.6.5	Mudança de coordenadas de uma matriz de dados	220
4.7	Transformações afins e pré-processamento	221
4.7.1	Translação	222
4.7.2	Transformação afim de uma matriz de dados	223
4.7.3	Centralização	224
4.7.4	Escalonamento das variáveis	226
4.7.5	Padronização	227
4.7.6	Ordem entre centralização e escalonamento	228
4.7.7	Composição e inversão de transformações afins	229
4.7.8	Comparação das operações de pré-processamento	230
4.8	Síntese do capítulo	231
5	Autovalores, autovetores e decomposição espectral	235
5.1	Direções invariantes, autovalores e autoespaços	235
5.2	Equação característica, multiplicidades e diagonalização	243
5.2.1	Determinação dos autovalores e autoespaços	245
5.2.2	Autovalores complexos de matrizes reais	247
5.2.3	Independência entre autovetores	248
5.2.4	Multiplicidades algébrica e geométrica	250
5.2.5	Diagonalização	252
5.2.6	Potências de uma matriz diagonalizável	255
5.3	Matrizes simétricas e decomposição espectral	256
5.3.1	Decomposição espectral do exemplo condutor	261

5.3.2	Forma aditiva da decomposição espectral	263
5.3.3	Projetores sobre autoespaços	264
5.3.4	Não unicidade da matriz de autovetores	266
5.4	Consequências da decomposição espectral	267
5.4.1	Traço, determinante, posto e invertibilidade	268
5.4.2	Formas quadráticas em coordenadas espectrais	271
5.4.3	Superfícies de nível em coordenadas espectrais	274
5.5	Quociente de Rayleigh e otimização espectral	277
5.5.1	Representação espectral	278
5.5.2	Exemplo bidimensional	281
5.5.3	Formulação com restrição de norma	284
5.5.4	Multiplicadores de Lagrange	284
5.5.5	Direções sucessivas	286
5.6	Funções espectrais de matrizes	288
5.6.1	Ação sobre os autoespaços	290
5.6.2	Potências inteiras	291
5.6.3	Inversa espectral	292
5.6.4	Raiz quadrada principal	293
5.6.5	Raiz quadrada inversa	294
5.6.6	Pseudoinversa espectral	295
5.6.7	Exponencial e logaritmo matriciais	297
5.7	Autovalores generalizados	298
5.7.1	Quociente de Rayleigh generalizado	300
5.7.2	Redução a um problema espectral ordinário	301
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	304
5.7.4	Diagonalização simultânea por congruência	305
5.7.5	Exemplo numérico	307
5.8	Síntese do capítulo	311
6	Decomposição em Valores Singulares	314
6.1	Definição e formas da Decomposição em Valores Singulares	315
6.1.1	Vetores singulares	317
6.1.2	Interpretação como composição de transformações	319
6.1.3	SVD completa	320
6.1.4	SVD compacta	321
6.1.5	SVD compacta e SVD truncada	322
6.1.6	Não unicidade dos vetores singulares	323
6.2	Construção da SVD e relação com a decomposição espectral	325
6.2.1	Simetria e semidefinição positiva	326
6.2.2	Construção dos vetores singulares	331
6.2.3	Demonstração da existência da SVD completa	334
6.2.4	Decomposições espectrais associadas	336
6.2.5	Exemplo de construção da SVD	337

6.2.6	Relação com a decomposição espectral de matrizes simétricas	341
6.3	Interpretação geométrica da SVD	343
6.3.1	Imagem da bola unitária	344
6.3.2	Alteração dos comprimentos	347
6.3.3	Exemplo geométrico no plano	349
6.3.4	Transformações de posto deficiente	350
6.4	Espaços fundamentais, posto, normas e condicionamento	351
6.4.1	Espaço coluna e espaço linha	352
6.4.2	Projetores ortogonais	356
6.4.3	Posto e nulidades	359
6.4.4	Produto interno de Frobenius	360
6.4.5	Normas e valores singulares	361
6.4.6	Invariância ortogonal	363
6.4.7	Determinante e invertibilidade	364
6.4.8	Menor valor singular	365
6.4.9	Número de condição	366
6.4.10	Posto exato e posto numérico	370
6.5	SVD de uma matriz de dados	371
6.5.1	Coordenadas no espaço das variáveis	372
6.5.2	Coordenadas no espaço das observações	373
6.5.3	Matrizes de Gram	374
6.5.4	Reconstrução das observações	376
6.5.5	Preservação de produtos internos	377
6.5.6	Centralização da matriz de dados	378
6.5.7	Relação com a matriz de covariâncias amostral	379
6.5.8	Magnitude quadrática da matriz centralizada	380
6.5.9	Representação exata e aproximação	382
6.6	Forma expandida e aproximações de posto reduzido	383
6.6.1	Parcelas de posto 1	384
6.6.2	Ortogonalidade das parcelas	384
6.6.3	SVD truncada	386
6.6.4	Ortogonalidade entre aproximação e diferença	387
6.6.5	Erro na norma espectral	388
6.6.6	Teorema de Eckart–Young–Mirsky	388
6.6.7	Unicidade da aproximação	393
6.6.8	Exemplo de aproximação de posto 1	394
6.6.9	Aproximação de uma matriz de dados	396
6.7	Pseudoinversa e soluções de mínimos quadrados	397
6.7.1	Relação com a pseudoinversa espectral	399
6.7.2	Condições de Moore–Penrose	400
6.7.3	Pseudoinversa e projetores	404
6.7.4	Sistemas lineares compatíveis	405
6.7.5	Solução de menor norma	407

6.7.6	Sistemas incompatíveis e mínimos quadrados	408
6.7.7	Resíduo de mínimos quadrados	410
6.7.8	Conjunto das soluções de mínimos quadrados	411
6.7.9	Expressão espectral da solução	414
6.7.10	Valores singulares pequenos e instabilidade	415
6.7.11	Pseudoinversa truncada	416
6.7.12	Exemplo com o sistema condutor	416
6.8	Síntese do capítulo	419
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	424
7.1	Funções, variações e diferenciais	424
7.1.1	Tipos de funções	424
7.1.2	Convenções de derivação	427
7.1.3	Variação de uma função	428
7.1.4	Diferencial	430
7.1.5	Aproximação ao longo de uma direção	431
7.1.6	Diferenciabilidade de funções vetoriais	433
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	434
7.2.1	Gradiente e derivada direcional	434
7.2.2	Gradiente e conjuntos de nível	436
7.2.3	Jacobiana	438
7.2.4	Regra da cadeia	441
7.2.5	Hessiana	443
7.3	Aproximações de Taylor e classificação local	445
7.3.1	Aproximação de Taylor de primeira ordem	445
7.3.2	Aproximação de Taylor de segunda ordem	447
7.3.3	Pontos estacionários	448
7.3.4	Classificação pela Hessiana	449
7.3.5	Caso inconclusivo	451
7.4	Convexidade e concavidade	452
7.4.1	Conjuntos convexos	452
7.4.2	Funções convexas	453
7.4.3	Caracterização de primeira ordem	453
7.4.4	Caracterização pela Hessiana	454
7.4.5	Consequências para otimização	455
7.4.6	Funções quadráticas	456
7.5	Otimização sem restrições	457
7.5.1	Método de Newton	458
7.6	Otimização com restrições de igualdade	459
7.6.1	Multiplicadores de Lagrange	460
7.6.2	Relação com problemas de autovalores	463
7.6.3	Restrições lineares	464

7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	465
7.7.1	Formas lineares e bilineares	465
7.7.2	Formas quadráticas	466
7.7.3	Norma euclidiana	468
7.7.4	Funções de resíduos lineares	469
7.7.5	Equações normais	470
7.7.6	Mínimos quadrados ponderados	472
7.7.7	Funções compostas de resíduos	473
7.7.8	Mínimos quadrados não lineares	474
7.8	Diferenciais matriciais e cálculo por traços	475
7.8.1	Regras básicas do diferencial matricial	476
7.8.2	Identidades de traço	477
7.8.3	Função linear de uma matriz	479
7.8.4	Norma de Frobenius	480
7.8.5	Funções quadráticas de uma matriz	481
7.8.6	Funções matriciais de resíduos	482
7.8.7	Ponderação de observações e respostas	485
7.9	Derivadas de inversas, determinantes e log-determinantes	486
7.9.1	Diferencial da matriz inversa	486
7.9.2	Diferencial do determinante	488
7.9.3	Diferencial do log-determinante	489
7.9.4	Segunda variação do log-determinante	490
7.9.5	Traço envolvendo uma matriz inversa	491
7.9.6	Forma quadrática com matriz inversa	492
7.9.7	Crítério com log-determinante e traço	493
7.9.8	Parâmetros matriciais simétricos	496
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	497
7.10.1	Operador de vetorização	497
7.10.2	Produto de Kronecker	499
7.10.3	Identidade de vetorização	500
7.10.4	Gradiente matricial e gradiente vetorizado	502
7.10.5	Hessiana de uma função matricial	502
7.10.6	Gradiente matricial e gradiente vetorizado	503
7.10.7	Hessiana de uma função matricial	504
7.10.8	Matriz de comutação	505
7.10.9	Meia vetorização de matrizes simétricas	506
7.10.10	Matriz de duplicação	507
7.10.11	Matriz de eliminação	508
7.10.12	Diferenciais de parâmetros simétricos	509
7.10.13	Jacobiana de transformações matriciais	510
7.11	Integração múltipla e mudança de variáveis	511
7.11.1	Integrais múltiplas	511
7.11.2	Teoremas de Tonelli e Fubini	512

7.11.3	Densidades multivariadas	513
7.11.4	Distribuições marginais	514
7.11.5	Esperanças de funções vetoriais	515
7.11.6	Mudança de variáveis	517
7.11.7	Transformação de densidades	518
7.11.8	Transformações afins	519
7.11.9	Interpretação geométrica do determinante Jacobiano	521
7.11.10	Coordenadas polares	522
7.11.11	Transformações elipsoidais	523
7.11.12	Diferenciação sob o sinal de integração	524
7.12	Aplicações à estimação e à inferência	530
7.12.1	Log-verossimilhança e vetor escore	530
7.12.2	Informação observada e informação de Fisher	531
7.12.3	Newton–Raphson	532
7.12.4	Método do escore de Fisher	533
7.12.5	Expansão local de um estimador	533
7.12.6	Método delta	534
7.12.7	Estimação de um vetor de médias	536
7.12.8	Critério do modelo linear multivariado	537
7.13	Síntese do capítulo	538

II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada 541

8 Módulo 3 – Formulação Matemática e Estatística das Técnicas Multivariadas 542

8.1	Capítulo 13 – Problemas e estruturas das técnicas multivariadas	542
8.2	Capítulo 14 – Formulação da Análise de Componentes Principais	542
8.3	Capítulo 15 – Formulação da Análise Fatorial	542
8.4	Capítulo 16 – Formulação da Análise de Agrupamentos	542
8.5	Capítulo 17 – Formulação do Escalonamento Multidimensional	542
8.6	Capítulo 18 – Formulação da Análise de Correspondência	542
8.7	Capítulo 19 – Formulação da MANOVA	542
8.8	Capítulo 20 – Formulação da Análise Discriminante	542
8.9	Capítulo 21 – Formulação da Correlação Canônica	542
8.10	Capítulo 22 – Formulação da Análise Conjunta	542

III Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas 543

9 Módulo 3 – Formulação Matemática e Estatística das Técnicas Multivariadas 544

9.1	Capítulo 13 – Problemas e estruturas das técnicas multivariadas	544
-----	---	-----

9.2	Capítulo 14 – Formulação da Análise de Componentes Principais	544
9.3	Capítulo 15 – Formulação da Análise Fatorial	544
9.4	Capítulo 16 – Formulação da Análise de Agrupamentos	544
9.5	Capítulo 17 – Formulação do Escalonamento Multidimensional	544
9.6	Capítulo 18 – Formulação da Análise de Correspondência	544
9.7	Capítulo 19 – Formulação da MANOVA	544
9.8	Capítulo 20 – Formulação da Análise Discriminante	544
9.9	Capítulo 21 – Formulação da Correlação Canônica	544
	Capítulo 22 – Formulação da Análise Conjunta	544

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

A análise multivariada estuda duas ou mais variáveis medidas em cada unidade observacional. Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor em $\mathbb{R}^p$.

Quando são observadas n unidades, os vetores correspondentes são organizados nas linhas de uma matriz de dados com dimensão $n \times p$. As linhas representam as observações, e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em $\mathbb{R}^p$ e estudar suas relações por meio de operações vetoriais e conceitos da geometria euclidiana.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações elementares com vetores, o produto interno, a norma, o ângulo e a distância euclidiana.

1.1 Escalares, vetores e matrizes

Uma observação univariada contém o valor de uma variável. Quando várias variáveis são medidas sobre a mesma unidade, seus valores podem ser reunidos em um vetor. Os vetores de diferentes unidades podem ser organizados em uma matriz.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

O vetor aleatório $\mathbf{X}$ possui uma distribuição conjunta de probabilidades. O vetor $\mathbf{x}$ contém os valores registrados para uma unidade observacional.

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : altura, em centímetros;
- X_3 : massa corporal, em quilogramas.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 22 anos, 168 centímetros de altura e 64 quilogramas, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 22 \\ 168 \\ 64 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$(22, 168, 64)^\top \neq (168, 22, 64)^\top.$$

No primeiro vetor, a idade ocupa a primeira posição. No segundo, essa posição é ocupada pela altura.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com m linhas e n colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{m \times n} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $m \times n$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Um vetor-coluna de dimensão p pode ser tratado como uma matriz $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

Sua transposta é um vetor-linha de dimensão $1 \times p$:

$$\mathbf{x}^\top = [x_1 \quad \cdots \quad x_p] \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real

Objeto	Notação	Descrição
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. A representação dos vetores em $\mathbb{R}^p$ será desenvolvida na próxima seção.

1.2 O espaço $\mathbb{R}^p$

Os valores observados de p variáveis quantitativas formam um vetor com p componentes. O conjunto de todos os vetores desse tipo é o espaço euclidiano $\mathbb{R}^p$.

Definição 1.4 (Espaço euclidiano $\mathbb{R}^p$). O espaço euclidiano de dimensão p é definido por

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ possui p coordenadas reais.

Uma observação descrita por p variáveis é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ que contém os vetores correspondentes às observações será denominado **espaço das observações**. Cada ponto representa uma unidade observacional, e cada eixo corresponde a uma variável.

A dimensão do espaço depende do número de variáveis:

- para $p = 1$, as observações são pontos em uma reta;
- para $p = 2$, as observações são pontos em um plano;
- para $p = 3$, as observações são pontos em um espaço tridimensional;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, sem visualização direta completa.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor corresponde ao ponto de coordenadas $(3, 5)$ no plano.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathbb{R}^p.$$

A dimensão ambiente é igual a p . A nuvem pode ocupar uma região de dimensão inferior quando existem relações lineares ou redundâncias entre as variáveis.

A posição relativa dos pontos depende das coordenadas utilizadas e das escalas das variáveis. Produto interno, norma, ângulo e distância serão introduzidos posteriormente para descrever essas relações.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.3 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Os vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.5 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1,2 \\ 2,0 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2,0 \\ 2,5 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 2,8 \\ 3,1 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 3,7 \\ 3,8 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1,2 & 2,0 \\ 2,0 & 2,5 \\ 2,8 & 3,1 \\ 3,7 & 3,8 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira linha corresponde à observação

$$\mathbf{x}_3^\top = [2,8 \quad 3,1],$$

e o elemento $x_{32} = 3,1$ é o valor da segunda variável na terceira unidade.

1.3.1 Linhas como observações

A matriz pode ser escrita como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix}.$$

Cada linha $\mathbf{x}_i^\top$ contém os valores das p variáveis para a observação i . O vetor-coluna correspondente é

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p.$$

As linhas da matriz formam uma coleção de n pontos no espaço das observações:

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p.$$

Quando $p = 2$, cada linha pode ser representada por um ponto no plano. A Figura 1.2 apresenta os dados do Exemplo 1.3.




Figura 1.2: Observações representadas como pontos no espaço bidimensional.

Cada ponto da figura corresponde a uma linha da matriz. Suas coordenadas são os valores das duas variáveis observadas na unidade.

1.3.2 Colunas como variáveis

A mesma matriz pode ser escrita por suas colunas:

$$\mathbf{X} = [\mathbf{x}^{(1)} \ \mathbf{x}^{(2)} \ \dots \ \mathbf{x}^{(p)}] ,$$

em que

$$\mathbf{x}^{(j)} = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix} \in \mathbb{R}^n$$

reúne os valores da variável j nas n unidades observacionais.

Cada coluna é um vetor no espaço das variáveis. Para o exemplo anterior,

$$\mathbf{x}^{(1)} = \begin{bmatrix} 1,2 \\ 2,0 \\ 2,8 \\ 3,7 \end{bmatrix}, \quad \mathbf{x}^{(2)} = \begin{bmatrix} 2,0 \\ 2,5 \\ 3,1 \\ 3,8 \end{bmatrix}.$$

A primeira coluna contém os valores de X_1 , e a segunda contém os valores de X_2 .

1.3.3 Espaço das observações e espaço das variáveis

A organização da matriz produz duas representações:

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

e

$$\mathbf{x}^{(j)} \in \mathbb{R}^n, \quad j = 1, \dots, p.$$

No **espaço das observações**, cada ponto representa uma unidade observacional e cada coordenada corresponde a uma variável.

No **espaço das variáveis**, cada vetor representa uma variável e suas componentes correspondem às unidades observacionais.

A Tabela [1.2](#) resume as duas representações da matriz de dados.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Objeto	Espaço	Quantidade
Linhas de $\mathbf{X}$	Observações	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	Variáveis	$\mathbb{R}^n$	p vetores

A interpretação adequada depende do objeto analisado. Relações entre unidades utilizam as linhas da matriz. Relações entre variáveis utilizam suas colunas.

1.3.4 Nuvem de pontos multivariada

As linhas de $\mathbf{X}$ formam uma nuvem de pontos em $\mathbb{R}^p$:

$$\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}.$$

A posição de cada ponto é determinada pelos valores das p variáveis. A forma da nuvem descreve a distribuição geométrica das observações no espaço.

A dimensão ambiente da nuvem é p . Relações lineares entre as variáveis podem fazer com que os pontos ocupem uma região de dimensão inferior.

A comparação entre as posições dos pontos requer uma medida de proximidade. Essa medida depende das variáveis consideradas, de suas escalas e da geometria adotada. A distância euclidiana será definida após a apresentação das operações elementares com vetores.

1.4 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.6 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

1.4.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.




Figura 1.3: Soma de vetores pela regra do paralelogramo.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.4.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

O comprimento de $\alpha \mathbf{x}$ é determinado por $|\alpha|$, e o sentido é invertido quando $\alpha < 0$:

- se $|\alpha| > 1$, o comprimento aumenta;
- se $0 < |\alpha| < 1$, o comprimento diminui;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido é invertido.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.4.3 Combinações lineares

Definição 1.7 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** desses vetores é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado pertence a $\mathbb{R}^p$ porque a soma e a multiplicação por escalar preservam o espaço:

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

Uma combinação linear também pode ser formada pelas componentes de um vetor aleatório. Para

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} \in \mathbb{R}^p,$$

define-se a variável aleatória escalar

$$Z = \mathbf{a}^\top \mathbf{X} = a_1 X_1 + a_2 X_2 + \cdots + a_p X_p.$$

Para uma realização $\mathbf{x}$ de $\mathbf{X}$, o valor observado correspondente é

$$z = \mathbf{a}^\top \mathbf{x} = a_1 x_1 + a_2 x_2 + \cdots + a_p x_p.$$

Exemplo 1.7 (Combinação linear das variáveis). Considere

$$\mathbf{a} = \begin{bmatrix} 2,0 \\ -0,5 \\ 3,0 \end{bmatrix}$$

e

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

A variável aleatória definida por esses coeficientes é

$$Z = \mathbf{a}^\top \mathbf{X} = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para a observação

$$\mathbf{x} = \begin{bmatrix} 4,0 \\ 2,0 \\ 1,5 \end{bmatrix},$$

o valor observado é

$$z = \mathbf{a}^\top \mathbf{x} = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação linear. A expressão $\mathbf{a}^\top \mathbf{X}$ define uma variável aleatória escalar, e $\mathbf{a}^\top \mathbf{x}$ fornece seu valor para uma observação.

As operações vetoriais permitem construir diferenças, deslocamentos e combinações das variáveis. O produto interno permite definir comprimento, ângulo, ortogonalidade e distância.

1.5 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

Definição 1.8 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** é definido por

$$\mathbf{x}^\top \mathbf{y} = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{x}^\top \mathbf{y} = 2(4) + 1(2) + 3(-1) = 7.$$

Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$, o produto interno satisfaz,

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x},$$

$$(\alpha \mathbf{x} + \beta \mathbf{z})^\top \mathbf{y} = \alpha \mathbf{x}^\top \mathbf{y} + \beta \mathbf{z}^\top \mathbf{y},$$

e

$$\mathbf{x}^\top \mathbf{x} \geq 0.$$

A igualdade

$$\mathbf{x}^\top \mathbf{x} = 0$$

ocorre somente quando $\mathbf{x} = \mathbf{0}$.

Definição 1.9 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\mathbf{x}^\top \mathbf{y}| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

(Meyer 2023)

A desigualdade de Cauchy–Schwarz garante que, para vetores não nulos,

$$-1 \leq \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Essa razão permite definir o ângulo entre dois vetores.

Definição 1.10 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o ângulo $\theta \in [0, \pi]$ entre eles é definido por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$


A relação entre o produto interno e o ângulo também pode ser escrita como

$$\mathbf{x}^\top \mathbf{y} = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$


O sinal do produto interno descreve a orientação relativa dos vetores:

- $\mathbf{x}^\top \mathbf{y} > 0$ quando o ângulo é agudo;
- $\mathbf{x}^\top \mathbf{y} = 0$ quando o ângulo é reto;
- $\mathbf{x}^\top \mathbf{y} < 0$ quando o ângulo é obtuso.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.4: Sinal do produto interno segundo o ângulo formado entre dois vetores.

A Figura 1.4 apresenta essas três situações.

Definição 1.11 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\mathbf{x}^T \mathbf{y} = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\mathbf{0}^T \mathbf{x} = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

Definição 1.12 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as observações. A padronização e outras geometrias serão estudadas nos capítulos posteriores.

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer 2023)

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.6 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas é representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto com n observações é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam observações em $\mathbb{R}^p$, e as colunas representam variáveis em $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem formar vetores e variáveis a partir de coeficientes definidos.

O produto interno euclidiano é

$$\mathbf{x}^\top \mathbf{y}.$$

A partir dele, definem-se a norma

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}},$$

o ângulo entre vetores não nulos,

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|},$$

e a distância euclidiana,

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Esses elementos permitem representar os dados multivariados como uma matriz e como uma nuvem de pontos. O próximo capítulo desenvolve as operações e as propriedades matriciais utilizadas para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, as observações foram representadas por vetores e organizadas nas linhas de uma matriz de dados. As linhas correspondem às unidades observacionais, e as colunas correspondem às variáveis.

Este capítulo apresenta as operações e as propriedades matriciais utilizadas na manipulação dessas representações. São estudadas as operações elemento a elemento, o produto matricial, a transposição, a simetria, o traço, a inversa, o determinante, o posto e os sistemas lineares.

O capítulo também introduz matrizes ortogonais, diagonais e triangulares, formas bilineares e quadráticas, positividade, matrizes particionadas e complemento de Schur.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam

$$\mathbf{A} = (a_{ij})_{m \times n} \quad \text{e} \quad \mathbf{B} = (b_{ij})_{r \times s}.$$

As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \quad \Longleftrightarrow \quad m = r, \quad n = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, m$ e $j = 1, \dots, n$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{m \times n}$ e $\mathbf{B} = (b_{ij})_{m \times n}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{m \times n}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{m \times n}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

A matriz nula de dimensão $m \times n$ é representada por

$$\mathbf{0}_{m \times n} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

Para matrizes $\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{m \times n}$,

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A},$$

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}),$$

$$\mathbf{A} + \mathbf{0}_{m \times n} = \mathbf{A}$$

e

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{m \times n}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{m \times n}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{m \times n}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Para $\alpha, \beta \in \mathbb{R}$ e matrizes $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$,

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B},$$

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A},$$

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}$$

e

$$1\mathbf{A} = \mathbf{A}.$$

Essas operações preservam as dimensões das matrizes. O produto matricial utiliza outra regra e pode produzir uma matriz com dimensões diferentes das matrizes multiplicadas.

2.1.1 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = (a_{ij})_{m \times n} \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^n a_{1j}x_j \\ \sum_{j=1}^n a_{2j}x_j \\ \vdots \\ \sum_{j=1}^n a_{mj}x_j \end{bmatrix} \in \mathbb{R}^m.$$

A componente i de $\mathbf{Ax}$ é

$$(\mathbf{Ax})_i = \sum_{j=1}^n a_{ij}x_j.$$

Cada componente do produto é o produto interno entre uma linha de $\mathbf{A}$ e o vetor $\mathbf{x}$.

Escrevendo as colunas de $\mathbf{A}$ como

$$\mathbf{A} = [\mathbf{a}^{(1)} \ \mathbf{a}^{(2)} \ \dots \ \mathbf{a}^{(n)}],$$

também se obtém

$$\mathbf{Ax} = x_1 \mathbf{a}^{(1)} + x_2 \mathbf{a}^{(2)} + \dots + x_n \mathbf{a}^{(n)}.$$

O produto $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

O produto é

$$\mathbf{Ax} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 1(2) + 2(-1) \\ -1(2) + 3(-1) \\ 2(2) + 0(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Pelas colunas de $\mathbf{A}$,

$$\mathbf{Ax} = 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

2.1.2 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Cada coluna da segunda matriz é multiplicada pela primeira matriz.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = (a_{ik})_{m \times n} \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{B} = (b_{kj})_{n \times r} \in \mathbb{R}^{n \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a matriz

$$\mathbf{C} = \mathbf{AB} = (c_{ij})_{m \times r} \in \mathbb{R}^{m \times r},$$

cujos elementos são definidos por

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj},$$

para $i = 1, \dots, m$ e $j = 1, \dots, r$.

O elemento c_{ij} é obtido pelo produto interno entre a linha i de $\mathbf{A}$ e a coluna j de $\mathbf{B}$.

Se

$$\mathbf{B} = [\mathbf{b}^{(1)} \ \mathbf{b}^{(2)} \ \dots \ \mathbf{b}^{(r)}],$$

então

$$\mathbf{AB} = [\mathbf{Ab}^{(1)} \ \mathbf{Ab}^{(2)} \ \dots \ \mathbf{Ab}^{(r)}].$$

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ é igual ao número de linhas de $\mathbf{B}$:

$$\begin{matrix} \mathbf{A} & \mathbf{B} & = & \mathbf{AB} \\ m \times n & n \times r & & m \times r \end{matrix}$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ é igual ao número de linhas de $\mathbf{B}$, o produto $\mathbf{AB}$ está definido e possui dimensão 2×2 :

$$\mathbf{AB} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix}.$$

Calculando os produtos entre linhas e colunas,

$$\mathbf{AB} = \begin{bmatrix} 1(2) + 2(0) + 0(4) & 1(1) + 2(-1) + 0(2) \\ -1(2) + 3(0) + 1(4) & -1(1) + 3(-1) + 1(2) \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

2.1.3 Propriedades do produto matricial

Para matrizes com dimensões compatíveis, o produto matricial é associativo:

$$(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC}).$$

O produto é distributivo em relação à soma:

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}$$

e

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{AB}) = (\alpha\mathbf{A})\mathbf{B} = \mathbf{A}(\alpha\mathbf{B}).$$

O produto matricial não é comutativo em geral:

$$\mathbf{AB} \neq \mathbf{BA}.$$

Mesmo quando os dois produtos estão definidos e possuem a mesma dimensão, seus resultados podem ser diferentes.

Exemplo 2.5 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

O produto matricial combina linhas e colunas e pode alterar as dimensões do objeto resultante. A transposição modifica a disposição dos elementos de uma matriz e será apresentada na próxima seção.

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja

$$\mathbf{A} = (a_{ij})_{m \times n} \in \mathbb{R}^{m \times n}.$$

A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{n \times m} \in \mathbb{R}^{n \times m}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.6 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

2.2.2 Propriedades da transposição

Para matrizes com dimensões compatíveis e $\alpha \in \mathbb{R}$,

$$(\mathbf{A}^\top)^\top = \mathbf{A},$$

$$(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top,$$

$$(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$$

e

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

A transposição de um produto inverte a ordem das matrizes.

Exemplo 2.7 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

Para vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno satisfaz

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}.$$

O produto $\mathbf{x}^\top \mathbf{y}$ é uma matriz 1×1 identificada com um escalar. O produto

$$\mathbf{xy}^\top$$

possui dimensão $p \times p$ e é denominado produto externo.

Definição 2.7 (Produto externo). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto externo** é a matriz

$$\mathbf{xy}^\top = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_p \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_p \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_p \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

Exemplo 2.8 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{x}^\top \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ -1 \end{bmatrix} = 1$$

e

$$\mathbf{xy}^\top = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 3 & -1 \end{bmatrix} = \begin{bmatrix} 3 & -1 \\ 6 & -2 \end{bmatrix}.$$

O produto interno produz um escalar, enquanto o produto externo produz uma matriz. Essa distinção será utilizada na construção de matrizes de somas de quadrados e produtos cruzados.

2.2.3 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.8 (Matriz simétrica). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.9 (Matriz antissimétrica). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada*

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

pode ser escrita de maneira única como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn e Johnson 2013)

Comprovação. A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas. □

Exemplo 2.10 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

A parte simétrica será utilizada no estudo das formas quadráticas. As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.4 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada.

Definição 2.10 (Traço de uma matriz). Seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Cálculo do traço). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix},$$

tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Para matrizes $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha \in \mathbb{R}$, o traço satisfaz

$$\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B}),$$

$$\text{tr}(\alpha \mathbf{A}) = \alpha \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

Teorema 2.2 (Propriedade cíclica do traço). *Se*

$$\mathbf{A} \in \mathbb{R}^{m \times n} \quad e \quad \mathbf{B} \in \mathbb{R}^{n \times m},$$

então

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}).$$

(Harville 1997)

Comprovação. Pela definição do produto matricial,

$$\text{tr}(\mathbf{AB}) = \sum_{i=1}^m (\mathbf{AB})_{ii} = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ji}.$$

Trocando a ordem das somas,

$$\text{tr}(\mathbf{AB}) = \sum_{j=1}^n \sum_{i=1}^m b_{ji} a_{ij} = \text{tr}(\mathbf{BA}).$$

□

Para três matrizes com dimensões compatíveis,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem dos fatores pode ser deslocada ciclicamente, mas não pode ser alterada arbitrariamente.

Exemplo 2.12 (Traço de produtos matriciais). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}.$$

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -3 & 12 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} 2 & 7 \\ -1 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

os traços são iguais:

$$\text{tr}(\mathbf{AB}) = 0 + 12 = 12$$

e

$$\text{tr}(\mathbf{BA}) = 2 + 10 = 12.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$\text{tr}(\mathbf{x}\mathbf{x}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Para uma matriz

$$\mathbf{A} = (a_{ij})_{m \times n},$$

tem-se

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij}^2.$$

O traço será utilizado na representação de somas de quadrados, variâncias totais e expressões envolvendo formas quadráticas. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.11 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos são definidos por

$$(\mathbf{I}_n)_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

tem-se

$$\mathbf{I}_m \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_n = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^n$,

$$\mathbf{I}_n \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.12 (Matriz inversa). Uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.3 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

Comprovação. Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única. □

Exemplo 2.14 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.4 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

Comprovação. Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1}\mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n\mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1}\mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1}\mathbf{A})\mathbf{B} = \mathbf{B}^{-1}\mathbf{I}_n\mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}.$$

□

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.13 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.14 (Determinante). Seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O **determinante** de $\mathbf{A}$ pode ser calculado pela expansão em cofatores de qualquer linha i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij}C_{ij}.$$

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Teorema 2.5 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.6 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere a transformação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{n \times n}.$$

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

é o fator pelo qual essa transformação multiplica comprimentos orientados em uma dimensão, áreas em duas dimensões, volumes em três dimensões e seus equivalentes em dimensões maiores.

O sinal de $\det(\mathbf{A})$ indica se a orientação é preservada ou invertida:

- $\det(\mathbf{A}) > 0$: a orientação é preservada;
- $\det(\mathbf{A}) < 0$: a orientação é invertida;
- $\det(\mathbf{A}) = 0$: a região é comprimida em uma dimensão inferior.

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.

Na primeira situação, a área é multiplicada por $|\det(\mathbf{A})|$. Na segunda, a região bidimensional é comprimida em uma reta. Na terceira, a área é preservada, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

2.3.5 Posto

O posto mede a quantidade de informação linearmente não redundante contida em uma matriz.

Definição 2.15 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{m \times n}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(m, n).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(m, n).$$

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.7 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer 2023)

Exemplo 2.18 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de m equações lineares com n incógnitas pode ser escrito na forma matricial.

Definição 2.16 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{m \times n}, \quad \mathbf{x} \in \mathbb{R}^n$$

e

$$\mathbf{b} \in \mathbb{R}^m.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2, \\ \vdots & \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m. \end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1n} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{m1} & \cdots & a_{mn} & b_m \end{bmatrix}.$$

Teorema 2.8 (Existência e quantidade de soluções). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- *a solução é única se*

$$\text{posto}(\mathbf{A}) = n;$$

- *existem infinitas soluções se*

$$\text{posto}(\mathbf{A}) < n.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = n$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < n$	Existem infinitas soluções

Exemplo 2.19 (Sistema com solução única). Considere

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3. \end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $m > n$, o sistema é sobredeterminado;
- se $m < n$, o sistema é subdeterminado;
- se $m = n$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

Matrizes retangulares e matrizes singulares não possuem inversa usual. A pseudoinversa fornece uma extensão para esses casos.

2.3.7 Pseudoinversa

Matrizes retangulares e matrizes quadradas singulares não possuem inversa usual. Para esses casos, utiliza-se a pseudoinversa de Moore–Penrose.

Para

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

sua pseudoinversa é representada por

$$\mathbf{A}^+ \in \mathbb{R}^{n \times m}.$$

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o sistema

$$\mathbf{Ax} = \mathbf{b}.$$

Se o sistema é consistente, o vetor

$$\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$$

é uma solução exata. Quando existem várias soluções, $\mathbf{x}^+$ é a solução com menor norma euclidiana.

Se o sistema é inconsistente, $\mathbf{x}^+$ minimiza

$$\|\mathbf{Ax} - \mathbf{b}\|.$$

Nesse caso, $\mathbf{x}^+$ é a solução de mínimos quadrados com menor norma entre todos os minimizadores.

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+ \mathbf{A} \neq \mathbf{I}_n$$

e

$$\mathbf{A} \mathbf{A}^+ \neq \mathbf{I}_m.$$

A pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção da pseudoinversa e sua relação com o posto, os sistemas lineares e os mínimos quadrados serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.17 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.20 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.9 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Comprovação. Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

□

Tomando $\mathbf{y} = \mathbf{x}$,

$$\|\mathbf{Q}\mathbf{x}\|^2 = \|\mathbf{x}\|^2,$$

de modo que

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| = \|\mathbf{x} - \mathbf{y}\|.$$

Matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

O determinante de uma matriz ortogonal satisfaz

$$\det(\mathbf{Q})^2 = 1.$$

De fato,

$$1 = \det(\mathbf{I}_n) = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{Q}^\top) \det(\mathbf{Q}) = \det(\mathbf{Q})^2.$$

Assim,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal. Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são ortogonais, então

$$(\mathbf{Q}_1 \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{Q}_2) = \mathbf{Q}_2^\top \mathbf{Q}_1^\top \mathbf{Q}_1 \mathbf{Q}_2 = \mathbf{I}_n.$$

As interpretações geométricas associadas às matrizes ortogonais serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.18 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag}(d_1, d_2, \dots, d_n).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1 x_1 \\ d_2 x_2 \\ \vdots \\ d_n x_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.21 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.19 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$\mathbf{U}^\top$ é triangular inferior.

Da mesma forma,

$\mathbf{L}^\top$ é triangular superior.

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.22 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Sistemas triangulares

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.23 (Sistema triangular superior). Considere o sistema

$$\begin{aligned}x_1 + 2x_2 - x_3 &= 4, \\2x_2 + 3x_3 &= 7, \\x_3 &= 1.\end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{L}\mathbf{x} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar. Quando os dois vetores são iguais, obtém-se uma forma quadrática.

2.5.1 Formas bilineares

Definição 2.20 (Forma bilinear). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A função

$$B(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p,$$

é uma **forma bilinear** associada à matriz $\mathbf{A}$.

Em termos das componentes,

$$\mathbf{x}^\top \mathbf{A} \mathbf{y} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i y_j.$$

A bilinearidade significa que a expressão é linear em cada vetor quando o outro permanece fixo. Para $\alpha, \beta \in \mathbb{R}$,

$$B(\alpha \mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) = \alpha B(\mathbf{x}_1, \mathbf{y}) + \beta B(\mathbf{x}_2, \mathbf{y})$$

e

$$B(\mathbf{x}, \alpha \mathbf{y}_1 + \beta \mathbf{y}_2) = \alpha B(\mathbf{x}, \mathbf{y}_1) + \beta B(\mathbf{x}, \mathbf{y}_2).$$

Exemplo 2.24 (Cálculo de uma forma bilinear). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

Tem-se

$$\mathbf{A}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} 5 \\ -6 \end{bmatrix}.$$

Logo,

$$\mathbf{x}^\top \mathbf{A}\mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 5 \\ -6 \end{bmatrix} = -7.$$

2.5.2 Formas quadráticas

Definição 2.21 (Forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A função

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p,$$

é uma **forma quadrática** associada à matriz $\mathbf{A}$.

Em termos das componentes,

$$q(\mathbf{x}) = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j.$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a forma quadrática é

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = ax_1^2 + (b+c)x_1x_2 + dx_2^2.$$

Teorema 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Comprovação. A matriz $\mathbf{A}$ pode ser escrita como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x} + \mathbf{x}^\top \mathbf{K} \mathbf{x}.$$

O escalar $\mathbf{x}^\top \mathbf{K} \mathbf{x}$ satisfaz

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = (\mathbf{x}^\top \mathbf{K} \mathbf{x})^\top = \mathbf{x}^\top \mathbf{K}^\top \mathbf{x} = -\mathbf{x}^\top \mathbf{K} \mathbf{x}.$$

Portanto,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0$$

e

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

□

Toda forma quadrática pode ser representada por uma matriz simétrica.

Exemplo 2.25 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuando os produtos,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtém-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 2(1)^2 + 2(1)(2) + 3(2)^2 = 18.$$

2.5.3 Positividade

A classificação de uma matriz simétrica depende dos valores assumidos por sua forma quadrática.

Definição 2.22 (Matriz positiva definida). Uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Definição 2.23 (Matriz semidefinida positiva). Uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

De modo análogo:

- **A é negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$;

- **A** é **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$;

- **A** é **indefinida** quando sua forma quadrática assume valores positivos e negativos.

Exemplo 2.26 (Classificação de formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

A expressão é positiva para todo $\mathbf{x} \neq \mathbf{0}$. Portanto, **A** é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

A forma quadrática é igual a zero para vetores não nulos com $x_1 = 0$. Portanto, **B** é semidefinida positiva.

Para

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

tem-se

$$\mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

A expressão assume valores positivos e negativos. Portanto, $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Quando $\mathbf{A}$ é indefinida, as curvas de nível podem assumir a forma de hipérboles.

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Matrizes particionadas e complemento de Schur

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.24 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.27 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ \hline 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.28 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ \hline 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

O complemento de Schur é definido para matrizes quadradas particionadas em blocos, quando um dos blocos diagonais é invertível.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Definição 2.25 (Complemento de Schur). Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$** é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$ em $\mathbf{A}$** é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, e $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

Exemplo 2.29 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \left[\begin{array}{cc|cc} 3 & 1 & 1 & 0 \\ 1 & 3 & 0 & 1 \\ \hline 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\begin{aligned} \mathbf{A}_{11} &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, & \mathbf{A}_{12} &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \\ \mathbf{A}_{21} &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} & \text{e} & \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}. \end{aligned}$$

Como

$$\mathbf{A}_{22}^{-1} = \mathbf{I}_2,$$

o complemento de Schur de $\mathbf{A}_{22}$ é

$$\begin{aligned} \mathbf{A}_{11.2} &= \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.6 Determinante de uma matriz particionada

Teorema 2.11 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd e Vandenberghe 2004)

Comprovação. Quando $\mathbf{A}_{22}$ é invertível, a matriz pode ser fatorada como

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

A primeira matriz possui determinante igual a 1. A segunda é triangular por blocos. Portanto,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

A segunda identidade é obtida por uma fatoração análoga utilizando $\mathbf{A}_{11}$. □

No Exemplo 2.29,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = \det \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = 3.$$

Logo,

$$\det(\mathbf{A}) = 3.$$

2.6.7 Inversão em blocos

O complemento de Schur também permite escrever a inversa de uma matriz particionada.

Teorema 2.12 (Inversa em blocos). *Considere*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1} \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{A}_{11.2}^{-1} & \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{A}_{11.2}^{-1} \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \end{bmatrix}.$$

(Boyd e Vandenberghe 2004)

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.8 Positividade e complemento de Schur

Para matrizes simétricas, o complemento de Schur permite verificar a definição positiva utilizando matrizes de menor dimensão.

Teorema 2.13 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então

$\mathbf{A}$ é positiva definida

se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Boyd e Vandenberghe 2004)

Comprovação. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{aligned} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} &= \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} \\ &\quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

Suponha inicialmente que $\mathbf{A}_{11.2}$ e $\mathbf{A}_{22}$ sejam positivas definidas. Para

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} \neq \mathbf{0},$$

se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Portanto, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela é igual a zero e

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0.$$

Logo, $\mathbf{A}_{11.2}$ é positiva definida. □

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22.1}$.

O termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a parcela de $\mathbf{A}_{11}$ associada à relação com o segundo bloco. O complemento

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a parcela remanescente após esse ajuste.

Essa estrutura será retomada no estudo de covariâncias condicionais e de relações entre blocos de variáveis.

2.7 Síntese do capítulo

As operações de soma, subtração e multiplicação por escalar são realizadas entre elementos correspondentes de matrizes com dimensões compatíveis. O produto

$$\mathbf{AB}$$

é definido quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$.

A transposição troca linhas por colunas e satisfaz

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

Uma matriz quadrada é simétrica quando

$$\mathbf{A}^\top = \mathbf{A},$$

e seu traço é a soma dos elementos da diagonal principal:

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

A matriz identidade é o elemento neutro do produto matricial. Uma matriz quadrada $\mathbf{A}$ é invertível quando existe $\mathbf{A}^{-1}$ tal que

$$\mathbf{AA}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n.$$

Para matrizes quadradas, as condições

$$\mathbf{A} \text{ é invertível,} \quad \det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{Ax} = \mathbf{b}.$$

A pseudoinversa estende a resolução para matrizes retangulares ou singulares e será desenvolvida no capítulo sobre decomposição em valores singulares.

As matrizes ortogonais satisfazem

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$$

e preservam produtos internos, normas e distâncias. Matrizes diagonais e triangulares possuem estruturas que simplificam determinantes, inversões e sistemas lineares.

Uma forma bilinear é representada por

$$\mathbf{x}^\top \mathbf{A} \mathbf{y},$$

e uma forma quadrática por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A classificação de uma matriz simétrica como definida, semidefinida ou indefinida depende dos valores assumidos por sua forma quadrática.

O particionamento organiza uma matriz em blocos compatíveis. O complemento de Schur permite representar determinantes, inversas e condições de positividade de matrizes particionadas.

Esses resultados fornecem a linguagem matricial utilizada no estudo de espaços vetoriais, transformações lineares e decomposições matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e, para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$ e $\alpha, \beta \in \mathbb{R}$, são satisfeitas as propriedades

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x},$$

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}),$$

$$\mathbf{x} + \mathbf{0} = \mathbf{x},$$

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0},$$

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y},$$

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x},$$

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}$$

e

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais, é um espaço vetorial. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e o inverso aditivo de

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix}$$

é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

O conjunto de todas as matrizes reais de dimensão $m \times n$,

$$\mathbb{R}^{m \times n},$$

também é um espaço vetorial com as operações usuais de soma e multiplicação por escalar.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Teorema 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

O conjunto S é uma translação do subespaço W e constitui um conjunto afim.

A Figura 3.1 compara uma reta que passa pela origem com uma reta afim paralela.




Figura 3.1: Comparação entre um subespaço de $\mathbb{R}^2$ e uma reta afim.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \cdots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \cdots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.5 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes.

Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.6 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.

3.2.2 Independência linear e sistemas homogêneos

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k].$$

A combinação linear

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

pode ser escrita como




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

$$\mathbf{A}\alpha = \mathbf{0},$$

em que

$$\alpha = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_k \end{bmatrix}.$$

Teorema 3.2 (Independência linear e sistema homogêneo). *As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se, o sistema*

$$\mathbf{A}\alpha = \mathbf{0}$$

possui apenas a solução trivial

$$\alpha = \mathbf{0}.$$

Se $\mathbf{A} \in \mathbb{R}^{p \times k}$, suas colunas são linearmente independentes quando

$$\text{posto}(\mathbf{A}) = k.$$

Consequentemente, não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Teorema 3.3 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*
2. *Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.*
3. *Todo subconjunto de um conjunto linearmente independente também é linearmente independente.*
4. *Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.*
5. *Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.*

A última propriedade fornece uma interpretação direta da redundância.

Teorema 3.4 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

Comprovação. Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente. $\square$

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.7 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.8 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.5 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Comprovação. Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única. □

Definição 3.6 (Coordenadas em uma base). Se

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.9 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker,

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Teorema 3.6 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de V , então, para qualquer $\mathbf{x} \in V$,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal,

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Comprovação. Escreva

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal, todos os termos com $i \neq j$ são nulos. Assim,

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j,$$

e

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Quando a base é ortonormal,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

□

A Figura 3.3 compara diferentes bases de $\mathbb{R}^2$.




Figura 3.3: Comparação entre a base canônica, uma base oblqua e uma base ortonormal rotacionada de $\mathbb{R}^2$.

A base canônica e a base rotacionada são ortonormais. Na base oblqua, os vetores são linearmente independentes, mas não são ortogonais.

3.2.7 Dimensão

Definição 3.10 (Dimensão). Se um espaço vetorial V possui uma base com k vetores, sua **dimensão** é

$$\dim(V) = k.$$

Todas as bases de um espaço vetorial de dimensão finita possuem o mesmo número de vetores.

Teorema 3.7 (Número de vetores de uma base). *Se V é um espaço vetorial de dimensão finita, todas as bases de V possuem a mesma quantidade de vetores.*

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.10 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Teorema 3.8 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz determina subespaços associados às suas colunas, linhas e soluções de sistemas homogêneos. Esses subespaços descrevem as direções que podem ser produzidas pela matriz e as direções que são anuladas por sua ação.

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}.$$

A matriz define a aplicação

$$T_{\mathbf{A}} : \mathbb{R}^n \longrightarrow \mathbb{R}^m, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

O estudo geral das transformações lineares será desenvolvido no capítulo seguinte. Nesta seção, essa aplicação será utilizada para definir o núcleo e a imagem de uma matriz.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** ou **núcleo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} = \mathbf{0}\}.$$

O espaço nulo reúne todos os vetores do domínio que são enviados ao vetor nulo.

Teorema 3.9 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^n$.

Comprovação. O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} \quad \text{e} \quad \mathbf{Ay} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{Ax} + \beta\mathbf{Ay} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço. □

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.11 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{Ax} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna e imagem

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{m \times n}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\} \subseteq \mathbb{R}^m.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + \cdots + x_n \mathbf{a}_n.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Definição 3.13 (Imagem de uma matriz). A **imagem** da aplicação definida por $\mathbf{A}$ é

$$\text{Im}(\mathbf{A}) = \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^n\}.$$

Como os vetores $\mathbf{Ax}$ são exatamente as combinações lineares das colunas de $\mathbf{A}$,

$$\text{Im}(\mathbf{A}) = \mathcal{C}(\mathbf{A}).$$

Teorema 3.10 (Consistência de um sistema linear). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Comprovação. Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{Ax},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_n$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_1 + \cdots + x_n \mathbf{a}_n.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix},$$

obtém-se

$$\mathbf{Ax} = \mathbf{b}.$$

□

Exemplo 3.12 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \quad \mathbf{a}_3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base do espaço coluna deve ser formada por colunas da matriz original. As posições das colunas pivô podem ser identificadas por escalonamento, mas os vetores da base são retirados de $\mathbf{A}$, e não da matriz escalonada.

3.3.3 Espaço linha

Definição 3.14 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

é o subespaço de $\mathbb{R}^n$ gerado por suas linhas.

Equivalentemente,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.13 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{r}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{r}_2^\top = [2 \quad 4 \quad -2].$$

Como

$$\mathbf{r}_2^\top = 2\mathbf{r}_1^\top,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.15 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^m : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_n^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, n.$$

Exemplo 3.14 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.11 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = n.$$

(Meyer 2023)

Comprovação. Uma base de um subespaço de dimensão finita pode ser completada para formar uma base do espaço que o contém.

Considere uma base do espaço nulo,

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Complete esse conjunto para obter uma base de $\mathbb{R}^n$:

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como essa base possui n vetores,

$$s + r = n.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^n$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A} \mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

$$\mathbf{A} \mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{A} \mathbf{w}_j.$$

Portanto,

$$\mathbf{A} \mathbf{w}_1, \dots, \mathbf{A} \mathbf{w}_r$$

geram $\mathcal{C}(\mathbf{A})$.

Para verificar a independência linear, suponha que

$$\sum_{j=1}^r \beta_j \mathbf{A} \mathbf{w}_j = \mathbf{0}.$$

Então,

$$\mathbf{A} \left(\sum_{j=1}^r \beta_j \mathbf{w}_j \right) = \mathbf{0},$$

de modo que

$$\sum_{j=1}^r \beta_j \mathbf{w}_j \in \mathcal{N}(\mathbf{A}).$$

Esse vetor também pertence a

$$\text{span}\{\mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^n$, a interseção entre esses dois subespaços contém somente o vetor nulo. Assim,

$$\beta_1 = \dots = \beta_r = 0.$$

Logo,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

formam uma base de $\mathcal{C}(\mathbf{A})$. Portanto,

$$r = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Logo,

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = n.$$

□

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = m.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = m.$$

Para o exemplo utilizado nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Portanto,

$$1 + 2 = 3$$

e

$$1 + 1 = 2,$$

de acordo com as dimensões do domínio e do contradomínio.

3.3.6 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^m$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^n$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^n$	$n - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^m$	$m - r$

A Tabela 3.1 mostra que os espaços coluna e nulo à esquerda pertencem ao contradomínio $\mathbb{R}^m$, enquanto os espaços linha e nulo pertencem ao domínio $\mathbb{R}^n$.

3.3.7 Complemento ortogonal

Definição 3.16 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

3.3.8 Relações de ortogonalidade

O espaço nulo é ortogonal ao espaço linha.

Teorema 3.12 (Ortogonalidade entre espaço nulo e espaço linha). *Para*

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Comprovação. Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Cada componente de $\mathbf{A}\mathbf{x}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, consequentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{Ax}$ é, portanto, igual a zero, de modo que

$$\mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

□

De forma análoga,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Essas relações produzem as decomposições ortogonais

$$\mathbb{R}^n = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^m = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

O símbolo $\oplus$ indica que a soma é direta: cada vetor possui uma representação única como soma de componentes pertencentes aos dois subespaços.

Teorema 3.13 (Decomposições pelos espaços fundamentais). *Se*

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

então todo vetor $\mathbf{x} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

em que

$$\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$$

e

$$\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}).$$

Da mesma forma, todo vetor $\mathbf{y} \in \mathbb{R}^m$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^{\top}},$$

em que

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}^{\top}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

(Strang 2023)

As decomposições ortogonais serão retomadas na construção de projeções sobre subespaços.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^{\top} \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Essas noções podem ser modificadas atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Produtos internos induzidos por matrizes

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.17 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^{\top} \mathbf{M} \mathbf{y} = (\mathbf{x}^{\top} \mathbf{M} \mathbf{y})^{\top} = \mathbf{y}^{\top} \mathbf{M}^{\top} \mathbf{x} = \mathbf{y}^{\top} \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Teorema 3.14 (Propriedades do produto interno induzido). *Para quaisquer*

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e $\alpha, \beta \in \mathbb{R}$,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn e Johnson 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.15 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M}\mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^\top \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.2 Norma e distância induzidas

Definição 3.18 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.16 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned} \|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{\begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}. \end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.3 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^{\top} \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.4 Interpretação por transformação de coordenadas

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^{\top} \mathbf{C}.$$

Assim,

$$\begin{aligned} \langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^{\top} \mathbf{C}^{\top} \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^{\top} (\mathbf{C} \mathbf{y}). \end{aligned}$$

O produto interno induzido por $\mathbf{M}$ equivale ao produto interno euclidiano aplicado aos vetores transformados

$$\mathbf{C} \mathbf{x} \quad \text{e} \quad \mathbf{C} \mathbf{y}.$$

Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C}\mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^{\top} \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.
Nesse caso, a expressão define uma **seminorma**, e não uma norma.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.5 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.19 (Matriz de Gram). Sejam

$$\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.17 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.6 Propriedades da matriz de Gram

Teorema 3.15 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;

4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$. (*Horn e Johnson 2013*)

Comprovação. A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0.\end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

A forma quadrática é igual a zero quando

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Assim, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.

Além disso,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}),$$

pois

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}$$

implica

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} = \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

As duas matrizes possuem, portanto, a mesma nulidade. Pelo Teorema Posto–Nulidade,

$$\text{posto}(\mathbf{V}^\top \mathbf{V}) = \text{posto}(\mathbf{V}).$$

Reciprocamente, se

$$\mathbf{V}\mathbf{c} = \mathbf{0},$$

então

$$\mathbf{V}^\top \mathbf{V}\mathbf{c} = \mathbf{V}^\top \mathbf{0} = \mathbf{0}.$$

Portanto,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}).$$

□

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.7 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.18 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.8 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}\mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela 3.2 resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij} x_{ik}$
$\mathbf{X}\mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.5 Complementos ortogonais e projeções

A ortogonalidade permite decompor um vetor em duas componentes: uma pertencente a um subespaço e outra perpendicular a todos os vetores desse subespaço.

3.5.1 Propriedades do Completo ortogonal

O complemento ortogonal reúne os vetores perpendiculares a todo o subespaço, e não somente a um conjunto particular de seus vetores.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k \right\}.$$

Teorema 3.16 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

Comprovação. O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$\begin{aligned} (\alpha \mathbf{x} + \beta \mathbf{y})^\top \mathbf{s} &= \alpha \mathbf{x}^\top \mathbf{s} + \beta \mathbf{y}^\top \mathbf{s} \\ &= 0. \end{aligned}$$

Portanto,

$$\alpha \mathbf{x} + \beta \mathbf{y} \in S^\perp.$$

□

Exemplo 3.19 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$

Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.5.2 Dimensão do complemento ortogonal

Teorema 3.17 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$

Se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se $\mathbf{x} \in S \cap S^\perp$, então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Em espaços vetoriais de dimensão finita,

$$(S^\perp)^\perp = S.$$

3.5.3 Decomposição ortogonal

Teorema 3.18 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

Comprovação. Pelo Teorema 3.21, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned} \mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição. □

A componente $\mathbf{x}_S$ é a projeção ortogonal de $\mathbf{x}$ sobre S . A componente

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é o resíduo ortogonal.

A unicidade decorre da condição

$$S \cap S^\perp = \{\mathbf{0}\}.$$

Suponha que existam duas decomposições:

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

e

$$\mathbf{r}_1, \mathbf{r}_2 \in S^\perp.$$

Então,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{r}_2 - \mathbf{r}_1.$$

O lado esquerdo pertence a S , enquanto o lado direito pertence a $S^\perp$. Portanto, ambos pertencem à interseção

$$S \cap S^\perp = \{\mathbf{0}\},$$

e

$$\mathbf{s}_1 = \mathbf{s}_2, \quad \mathbf{r}_1 = \mathbf{r}_2.$$

3.5.4 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que $\mathbf{u} \neq \mathbf{0}$.

A projeção de $\mathbf{x}$ sobre S possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u}.$$

O resíduo deve ser ortogonal a $\mathbf{u}$:

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Assim,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Definição 3.20 (Projeção sobre uma direção). A projeção ortogonal de $\mathbf{x}$ sobre

$$S = \text{span}\{\mathbf{u}\}$$

é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Se $\mathbf{u}$ possui norma igual a 1, então

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}.$$

Exemplo 3.20 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição.




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.

3.5.5 Projecção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projecção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é a soma das projecções sobre cada vetor da base:

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

A soma das projecções pode ser escrita como

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \mathbf{q}_1 \mathbf{q}_1^\top \mathbf{x} + \dots + \mathbf{q}_k \mathbf{q}_k^\top \mathbf{x} \\ &= \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x} \\ &= \mathbf{Q} \mathbf{Q}^\top \mathbf{x}. \end{aligned}$$

Teorema 3.19 (Projecção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q} \mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top.$$

(Meyer 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ reconstrói o vetor projetado no espaço original.

Exemplo 3.21 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.5.6 Projecção sobre o espaço coluna de uma matriz

Considere

$$\mathbf{A} = [\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k},$$

com colunas linearmente independentes.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}).$$

A projecção de $\mathbf{x}$ sobre S deve possuir a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

Como as colunas de $\mathbf{A}$ são linearmente independentes, a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em $\hat{\mathbf{x}} = \mathbf{A}\mathbf{c}$,

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Teorema 3.20 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre

$$\mathcal{C}(\mathbf{A})$$

é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A}(\mathbf{A}^{\top}\mathbf{A})^{-1}\mathbf{A}^{\top}.$$

A matriz $\mathbf{P}_{\mathbf{A}}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$. Matrizes diferentes que possuem o mesmo espaço coluna produzem a mesma projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^{\top}\mathbf{A} = \mathbf{I}_k,$$

e a fórmula reduz-se a

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A}\mathbf{A}^{\top}.$$

Teorema 3.21 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt.

Exemplo 3.22 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^{\top}\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned} \mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\ &= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\ &= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{aligned} \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A} \mathbf{c} \\ &= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\ &= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}. \end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

3.5.7 Propriedades da matriz de projeção

Teorema 3.22 (Propriedades da matriz de projeção). *Se $\mathbf{A}$ possui colunas linearmente independentes e*

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top},$$

então:

1. $\mathbf{P}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{P}_{\mathbf{A}}$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
4. $\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$;
5. $\text{posto}(\mathbf{P}_{\mathbf{A}}) = \text{posto}(\mathbf{A})$.

Comprovação. A simetria decorre de

$$\begin{aligned} \mathbf{P}_{\mathbf{A}}^{\top} &= \left[\mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \right]^{\top} \\ &= \mathbf{A} \left[(\mathbf{A}^{\top} \mathbf{A})^{-1} \right]^{\top} \mathbf{A}^{\top} \\ &= \mathbf{P}_{\mathbf{A}}, \end{aligned}$$

pois $\mathbf{A}^{\top} \mathbf{A}$ e sua inversa são simétricas.

Para a idempotência,

$$\begin{aligned} \mathbf{P}_{\mathbf{A}}^2 &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top} \\ &= \mathbf{P}_{\mathbf{A}}. \end{aligned}$$

Todo vetor projetado possui a forma

$$\mathbf{P}_{\mathbf{A}} \mathbf{x} = \mathbf{A} \mathbf{c},$$

e, portanto, pertence a $\mathcal{C}(\mathbf{A})$.

Reciprocamente, se

$$\mathbf{y} = \mathbf{A} \mathbf{c} \in \mathcal{C}(\mathbf{A}),$$

então

$$\begin{aligned}\mathbf{P_A y} &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{A} \mathbf{c} \\ &= \mathbf{A} \mathbf{c} \\ &= \mathbf{y}.\end{aligned}$$

Logo,

$$\mathcal{C}(\mathbf{P_A}) = \mathcal{C}(\mathbf{A}).$$

Se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{A}^\top \mathbf{x} = \mathbf{0},$$

e, consequentemente,

$$\mathbf{P_A x} = \mathbf{0}.$$

Assim,

$$\mathcal{N}(\mathbf{P_A}) = \mathcal{C}(\mathbf{A})^\perp.$$

Como o espaço coluna de $\mathbf{P_A}$ coincide com o espaço coluna de $\mathbf{A}$,

$$\text{posto}(\mathbf{P_A}) = \text{posto}(\mathbf{A}).$$

Reciprocamente, suponha que

$$\mathbf{P_A x} = \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{P_A} = \mathbf{A}^\top,$$

tem-se

$$\mathbf{A}^\top \mathbf{x} = \mathbf{A}^\top \mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{0}.$$

Portanto, $\mathbf{x}$ é ortogonal a todas as colunas de $\mathbf{A}$ e

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp.$$

Logo,

$$\mathcal{N}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp.$$

□

A idempotência significa que projetar um vetor já projetado não produz alteração:

$$\mathbf{P}_\mathbf{A} (\mathbf{P}_\mathbf{A} \mathbf{x}) = \mathbf{P}_\mathbf{A} \mathbf{x}.$$

3.5.8 Projecção sobre o complemento ortogonal

A componente residual de um vetor é obtida subtraindo sua projecção:

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_\mathbf{A} \mathbf{x}.$$

Defina

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_p - \mathbf{P}_\mathbf{A}.$$

Então,

$$\mathbf{r} = \mathbf{M}_\mathbf{A} \mathbf{x}.$$

Definição 3.21 (Matriz de projecção residual). A matriz

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_p - \mathbf{P}_\mathbf{A}$$

é a matriz de projecção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_A \mathbf{x} + \mathbf{M}_A \mathbf{x}.$$

As duas componentes satisfazem

$$\mathbf{P}_A \mathbf{x} \in \mathcal{C}(A)$$

e

$$\mathbf{M}_A \mathbf{x} \in \mathcal{C}(A)^\perp.$$

Além disso,

$$(\mathbf{P}_A \mathbf{x})^\top (\mathbf{M}_A \mathbf{x}) = 0.$$

Teorema 3.23 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_A = \mathbf{I}_p - \mathbf{P}_A,$$

então:

1. $\mathbf{M}_A$ é simétrica;
2. $\mathbf{M}_A$ é idempotente;
3. $\mathbf{P}_A \mathbf{M}_A = \mathbf{0}$;
4. $\mathbf{M}_A \mathbf{P}_A = \mathbf{0}$;
5. $\mathcal{C}(\mathbf{M}_A) = \mathcal{C}(A)^\perp$;
6. $\mathcal{N}(\mathbf{M}_A) = \mathcal{C}(A)$.

Comprovação. Como $\mathbf{P}_A$ é simétrica,

$$\begin{aligned} \mathbf{M}_A^\top &= (\mathbf{I}_p - \mathbf{P}_A)^\top \\ &= \mathbf{I}_p - \mathbf{P}_A^\top \\ &= \mathbf{I}_p - \mathbf{P}_A \\ &= \mathbf{M}_A. \end{aligned}$$

Portanto, $\mathbf{M}_A$ é simétrica.

Para verificar a idempotência,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^2 &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^2 \\ &= \mathbf{I}_p - 2\mathbf{P}_{\mathbf{A}} + \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}},\end{aligned}$$

pois

$$\mathbf{P}_{\mathbf{A}}^2 = \mathbf{P}_{\mathbf{A}}.$$

Além disso,

$$\begin{aligned}\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} &= \mathbf{P}_{\mathbf{A}}(\mathbf{I}_p - \mathbf{P}_{\mathbf{A}}) \\ &= \mathbf{P}_{\mathbf{A}} - \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{0}.\end{aligned}$$

De forma análoga,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})\mathbf{P}_{\mathbf{A}} \\ &= \mathbf{P}_{\mathbf{A}} - \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{0}.\end{aligned}$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{P}_{\mathbf{A}}).$$

Como

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp,$$

segue que

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) \subseteq \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, seja

$$\mathbf{y} \in \mathcal{C}(\mathbf{A})^\perp.$$

Então,

$$\mathbf{P}_\mathbf{A} \mathbf{y} = \mathbf{0},$$

e

$$\begin{aligned}\mathbf{M}_\mathbf{A} \mathbf{y} &= (\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{y} \\ &= \mathbf{y}.\end{aligned}$$

Portanto, $\mathbf{y}$ pertence à imagem de $\mathbf{M}_\mathbf{A}$, de modo que

$$\mathcal{C}(\mathbf{A})^\perp \subseteq \mathcal{C}(\mathbf{M}_\mathbf{A}).$$

Logo,

$$\mathcal{C}(\mathbf{M}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp.$$

Se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{x}.$$

Consequentemente,

$$\begin{aligned}\mathbf{M}_\mathbf{A} \mathbf{x} &= (\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{x} \\ &= \mathbf{x} - \mathbf{x} \\ &= \mathbf{0}.\end{aligned}$$

Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{M}_\mathbf{A}).$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{N}(\mathbf{M}_{\mathbf{A}}).$$

Então,

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} = \mathbf{0},$$

isto é,

$$(\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})\mathbf{x} = \mathbf{0}.$$

Portanto,

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x}.$$

Como

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

segue que

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Logo,

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) \subseteq \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

□

Quando $\mathbf{A} \in \mathbb{R}^{p \times k}$ possui posto k ,

$$\text{posto}(\mathbf{P}_{\mathbf{A}}) = k$$

e

$$\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

3.5.9 Projeção como melhor aproximação

A projeção ortogonal é o vetor do subespaço que possui a menor distância até o vetor original.

Teorema 3.24 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer 2023)

Comprovação. Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

O resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$. Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escreva

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}).$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre somente quando

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é, quando

$$\mathbf{y} = \hat{\mathbf{x}}.$$

□

A projeção é, portanto, a solução do problema

$$\min_{\mathbf{y} \in S} \|\mathbf{x} - \mathbf{y}\|^2.$$

Quando

$$S = \mathcal{C}(\mathbf{A}),$$

todo vetor de S possui a forma

$$\mathbf{y} = \mathbf{A}\mathbf{c}.$$

Assim, o problema pode ser escrito como

$$\min_{\mathbf{c} \in \mathbb{R}^k} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2.$$

3.5.10 Projeções e mínimos quadrados

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^m.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}$$

pode não possuir solução exata quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}).$$

Nesse caso, procura-se um vetor

$$\mathbf{A}\hat{\beta} \in \mathcal{C}(\mathbf{A})$$

que minimize

$$\|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.24,

$$\mathbf{A}\hat{\beta} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O resíduo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta}$$

deve ser ortogonal ao espaço coluna de $\mathbf{A}$. Portanto,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo o resíduo,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0}.$$

Logo,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.22 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\mathbf{A}^\top \mathbf{A}$$

é invertível e a solução é única:

$$\hat{\beta} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\boldsymbol{\beta}} = \mathbf{P}_{\mathbf{A}}\mathbf{b},$$

e o vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{M}_{\mathbf{A}}\mathbf{b}.$$

Teorema 3.25 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^{\perp}.$$

Consequentemente,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub e Van Loan 2013)

Se as colunas de $\mathbf{A}$ são linearmente dependentes, os coeficientes que resolvem as equações normais podem não ser únicos. A projeção

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece única, pois depende apenas do espaço coluna.

Nesse caso, a matriz de projeção pode ser escrita como

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A}\mathbf{A}^+,$$

em que $\mathbf{A}^+$ é a pseudoinversa de Moore–Penrose. Sua construção será desenvolvida no capítulo sobre Decomposição em Valores Singulares.

As projeções ponderadas podem ser definidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será utilizada posteriormente em problemas ponderados.

3.6 Síntese do capítulo

Um subespaço vetorial é um subconjunto fechado em relação às combinações lineares. O subespaço gerado por

$$\mathbf{v}_1, \dots, \mathbf{v}_k$$

é

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}.$$

Um conjunto de vetores é linearmente independente quando

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \dots = \alpha_k = 0.$$

Uma base é um conjunto linearmente independente que gera o espaço. Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ possui uma representação única:

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

O número de vetores de uma base determina a dimensão do espaço.

Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

os quatro espaços fundamentais são:

$$\mathcal{C}(\mathbf{A}), \quad \mathcal{L}(\mathbf{A}), \quad \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A}^\top).$$

Se

$$r = \text{posto}(\mathbf{A}),$$

então

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = n - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = m - r.$$

As relações de ortogonalidade são

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Um produto interno pode ser induzido por uma matriz simétrica positiva definida:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}.$$

A norma e a distância correspondentes são

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

e

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

A matriz de Gram

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

organiza os produtos internos entre as colunas de $\mathbf{V}$. Ela é simétrica e semidefinida positiva, sendo positiva definida quando essas colunas são linearmente independentes.

Para um subespaço $S \subseteq \mathbb{R}^p$,

$$\mathbb{R}^p = S \oplus S^\perp.$$

Assim, todo vetor pode ser decomposto de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{r},$$

em que

$$\text{proj}_S(\mathbf{x}) \in S$$

e

$$\mathbf{r} \in S^\perp.$$

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Se as colunas de $\mathbf{A}$ são linearmente independentes e

$$S = \mathcal{C}(\mathbf{A}),$$

a matriz de projeção é

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção é o vetor de S que minimiza a distância até $\mathbf{x}$. Essa propriedade fornece a interpretação geométrica das equações normais e dos problemas de mínimos quadrados.

Os conceitos de base, núcleo, imagem e projeção serão utilizados no estudo das transformações lineares e de suas representações matriciais.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada transformação linear.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha \mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.

Teorema 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer 2023)

Comprovação. Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned} T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\ &= T(\mathbf{u}) + T(-\mathbf{v}) \\ &= T(\mathbf{u}) - T(\mathbf{v}). \end{aligned}$$

□

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Teorema 4.2 (Determinação de uma transformação por uma base). *Seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_p).$$

(Meyer 2023)

Comprovação. Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_p \mathbf{v}_p.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_p T(\mathbf{v}_p).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio pode ser determinada. $\square$

Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned}
T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\
&= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\
&= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}.
\end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

As colunas da matriz são as imagens dos vetores da base canônica.

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned}
T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \cdots + x_p T(\mathbf{e}_p) \\
&= x_1 \mathbf{a}_1 + \cdots + x_p \mathbf{a}_p \\
&= \mathbf{A}\mathbf{x}.
\end{aligned}$$

Teorema 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned}
T_{\mathbf{A}}(\alpha \mathbf{u} + \beta \mathbf{v}) &= \mathbf{A}(\alpha \mathbf{u} + \beta \mathbf{v}) \\
&= \alpha \mathbf{A}\mathbf{u} + \beta \mathbf{A}\mathbf{v} \\
&= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}).
\end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Imagem de um subespaço

Considere um subespaço

$$S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \dots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Teorema 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Comprovação. A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A}\mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X}\mathbf{A}^\top.$$

□

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

Em R, essa operação pode ser realizada por:

```
Y <- X %*% t(A)
```

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q].$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q].$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}^{(j)} = \mathbf{X}\mathbf{w}_j.$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip}.$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.1 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix}.$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\ &= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\ &= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}. \end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}. \end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}^{(1)} = \mathbf{x}^{(1)} + \mathbf{x}^{(2)}.$$

A segunda é

$$\mathbf{y}^{(2)} = 2\mathbf{x}^{(1)} - \mathbf{x}^{(2)}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, a configuração transformada está contida em um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando

$$r < p,$$

a transformação elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, a geometria induzida pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em $\mathcal{N}(\mathbf{A})$ para os quais

$$\|\mathbf{x}\|_{\mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Teorema 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

Em geral,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

Exemplo 4.2 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.2 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Teorema 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Comprovação. Tem-se

$$\begin{aligned} (\mathbf{BA}) (\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B} (\mathbf{AA}^{-1}) \mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1}) (\mathbf{BA}) &= \mathbf{A}^{-1} (\mathbf{B}^{-1}\mathbf{B}) \mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

□

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.3 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Teorema 4.7 (Caracterizações por núcleo, imagem e posto). *Se*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

Comprovação. Suponha que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{Ax}_1 = \mathbf{Ax}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema 3.11,

$$\dim(\mathcal{N}(\mathbf{A})) + \text{posto}(\mathbf{A}) = p.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

A transformação é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à imagem de $T_{\mathbf{A}}$. Como essa imagem é $\mathcal{C}(\mathbf{A})$, a sobrejetividade equivale a

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim(\mathcal{C}(\mathbf{A})) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

□

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando o Teorema 4.7 com o Teorema 2.7, obtém-se o resultado seguinte.

Teorema 4.8 (Equivalências para uma transformação quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
5. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
6. $\text{posto}(\mathbf{A}) = p$;
7. $\det(\mathbf{A}) \neq 0$;
8. $\mathbf{A}^{-1}$ existe.

(Meyer 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \mathcal{N}(\mathbf{A}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \mathcal{N}(\mathbf{A})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo espaço nulo. Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

A transformação elimina $p - r$ direções independentes e produz uma imagem de dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar o posto como o número de direções independentes preservadas na imagem. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam apenas a orientação da configuração, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;
- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}(\theta)\mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}(\theta)^\top \mathbf{Q}(\theta) = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}(\theta)^{-1} = \mathbf{Q}(\theta)^\top = \mathbf{Q}(-\theta).$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}(\theta)) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada reflexão de Householder.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é ampliada ou comprimida por um fator diferente, de modo que comprimentos, ângulos e proporções podem ser alterados.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned} y_1 &= x_1 + kx_2, \\ y_2 &= x_2. \end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det\left(\mathbf{C}_{ij}(k)\right) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

Uma projeção mantém a componente de um vetor pertencente a um subespaço e elimina a componente ortogonal.

Para uma direção unitária $\mathbf{u} \in \mathbb{R}^p$, a matriz de projeção é

$$\mathbf{P}_{\mathbf{u}} = \mathbf{u}\mathbf{u}^{\top}.$$

A imagem de $\mathbf{x}$ é

$$\mathbf{P}_{\mathbf{u}}\mathbf{x} = (\mathbf{u}^{\top}\mathbf{x})\mathbf{u}.$$

Como estudado no Capítulo 3,

$$\mathbf{P}_{\mathbf{u}}^2 = \mathbf{P}_{\mathbf{u}}$$

e

$$\mathbf{P}_{\mathbf{u}}^{\top} = \mathbf{P}_{\mathbf{u}}.$$

Se $p > 1$, a projeção sobre uma única direção possui posto 1. Consequentemente,

$$\det(\mathbf{P}_{\mathbf{u}}) = 0.$$

A projeção é uma transformação linear não invertível. Vetores que possuem a mesma componente na direção de $\mathbf{u}$ são enviados ao mesmo ponto.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário.

A rotação gira o quadrado em relação aos eixos coordenados sem alterar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área. A projeção reduz a figura a um segmento de reta.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Teorema 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja $E \subseteq \mathbb{R}^p$ um conjunto mensurável. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se $\det(\mathbf{A}) = 0$, a imagem está contida em um subespaço de dimensão inferior a p e seu volume p -dimensional é igual a zero.

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

O sinal do determinante descreve a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, ocorre redução de dimensão.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}(\theta)$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Amplia ou comprime direções
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.17, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Pelo Teorema 2.9, para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Assim, a transformação preserva o produto interno entre todos os pares de vetores.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned} \|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2. \end{aligned}$$

Portanto,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned} \|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|. \end{aligned}$$

Logo, todas as distâncias euclidianas são preservadas.

Para vetores não nulos, o ângulo θ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como os produtos internos e as normas permanecem inalterados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados. Em particular,

$$\mathbf{x}^\top \mathbf{y} = 0$$

implica

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0.$$

Transformações ortogonais preservam, assim:

- produtos internos;
- normas;
- distâncias;
- ângulos;
- ortogonalidade;
- áreas e volumes.

Elas podem modificar a orientação da configuração, mas não alteram suas relações métricas internas.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Teorema 4.10 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Comprovação. Tem-se

$$\begin{aligned}\mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top.\end{aligned}$$

□

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Como

$$\mathbf{Q}^\top\mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned}1 &= \det(\mathbf{Q}^\top\mathbf{Q}) \\ &= \det(\mathbf{Q}^\top)\det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2.\end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Como

$$|\det(\mathbf{Q})| = 1,$$

áreas e volumes são preservados.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também são ortonormais.

A mesma matriz pode ser interpretada de duas formas:

- como uma transformação que preserva a geometria euclidiana;
- como uma base ortonormal organizada em suas colunas.

A relação entre essas interpretações será desenvolvida na seção sobre mudanças de coordenadas.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções ortogonais.




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções ortogonais.

A rotação e a reflexão mantêm a circunferência unitária e o ângulo reto entre as direções. O escalonamento transforma a circunferência em uma elipse. O cisalhamento também deforma a circunferência e altera o ângulo entre os vetores.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$. Organizando seus vetores nas colunas de uma matriz, define-se

$$\mathbf{P}_{\mathcal{B}} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes,

$$\mathbf{P}_{\mathcal{B}}$$

é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{P}_{\mathcal{B}}^{-1} \mathbf{x}.$$

A matriz $\mathbf{P}_{\mathcal{B}}$ converte coordenadas na base $\mathcal{B}$ em coordenadas canônicas. Sua inversa realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{P}_{\mathcal{B}}^{\top} \mathbf{P}_{\mathcal{B}} = \mathbf{I}_p.$$

Logo,

$$\mathbf{P}_{\mathcal{B}}^{-1} = \mathbf{P}_{\mathcal{B}}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{P}_{\mathcal{B}}^{\top} \mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top} \mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top} \mathbf{x} \end{bmatrix}.$$

Cada coordenada é o produto interno entre o vetor e uma direção da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$:

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\}.$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{P}_{\mathcal{C}} [\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{P}_{\mathcal{C}} [\mathbf{x}]_{\mathcal{C}} = \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando por $\mathbf{P}_{\mathcal{C}}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.4 (Matriz de mudança de base). A matriz que converte coordenadas da base $\mathcal{B}$ para a base $\mathcal{C}$ é

$$\mathbf{P}_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{P}_{\mathcal{B}}.$$

Assim,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{P}_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

A seta indica o sentido da conversão:

$$\mathcal{B} \longrightarrow \mathcal{C}.$$

A conversão no sentido contrário é dada por

$$\mathbf{P}_{\mathcal{B} \leftarrow \mathcal{C}} = \mathbf{P}_{\mathcal{B}}^{-1} \mathbf{P}_{\mathcal{C}}.$$

As duas matrizes são inversas:

$$\mathbf{P}_{\mathcal{B} \leftarrow \mathcal{C}} = (\mathbf{P}_{\mathcal{C} \leftarrow \mathcal{B}})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio e $\mathcal{C}$ uma base do contradomínio. As coordenadas canônicas do vetor de entrada são

$$\mathbf{x} = \mathbf{P}_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}},$$

enquanto as coordenadas da imagem na base $\mathcal{C}$ são

$$[T(\mathbf{x})]_{\mathcal{C}} = \mathbf{P}_{\mathcal{C}}^{-1}T(\mathbf{x}).$$

Substituindo a representação matricial de T ,

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{P}_{\mathcal{C}}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{P}_{\mathcal{C}}^{-1}\mathbf{A}\mathbf{P}_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Teorema 4.11 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{P}_{\mathcal{C}}^{-1}\mathbf{A}\mathbf{P}_{\mathcal{B}}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer 2023)

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.3 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{P}_{\mathcal{B}} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{P}_{\mathcal{C}} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{P}_{\mathcal{C}}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} [T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{A} \mathbf{P}_{\mathcal{B}} \\ &= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}. \end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio, a matriz do operador nessa base é

$$\mathbf{A}_{\mathcal{B}} = \mathbf{P}_{\mathcal{B}}^{-1} \mathbf{A} \mathbf{P}_{\mathcal{B}}.$$

Definição 4.5 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{B}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{B} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Teorema 4.12 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{B} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{B}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{B}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{B}) = \text{posto}(\mathbf{A}).$$

(Horn e Johnson 2013)

Comprovação. Para o determinante,

$$\begin{aligned}\det(\mathbf{B}) &= \det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}).\end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned}\text{tr}(\mathbf{B}) &= \text{tr}(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) \\ &= \text{tr}(\mathbf{A}\mathbf{P}\mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}).\end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) = \text{posto}(\mathbf{A}).$$

□

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}(\theta)$,

$$\mathbf{Q}(\theta)^{-1} = \mathbf{Q}(\theta)^{\top} = \mathbf{Q}(-\theta).$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

A Figura 4.7 compara as duas interpretações.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.6 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned} \mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\ &= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\ &= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. A aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Teorema 4.13 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Comprovação. Tem-se

$$\begin{aligned}\mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j.\end{aligned}$$

Logo, as duas diferenças possuem a mesma norma. □

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica distâncias e ângulos. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada por

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1}(\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1.

Para duas observações padronizadas,

$$\begin{aligned} \mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j). \end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x},$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m}.$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1}\mathbf{m}.$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim é invertível quando sua parte linear é invertível.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e modifica a geometria. A padronização combina as duas operações.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão	Linear	Mantém a origem fixa
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não

Operação	Expressão	Linear	Mantém a origem fixa
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalonamento	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares modificam direção, escala ou dimensão mantendo a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando são consideradas como operações sobre observações individuais.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Conforme a Definição 4.1,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica $T(\mathbf{0}) = \mathbf{0}$ e permite determinar a transformação a partir das imagens dos vetores de uma base.

Toda transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

possui uma representação matricial única:

$$T(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Nas bases canônicas, as colunas de $\mathbf{A}$ são as imagens dos vetores da base do domínio. Quando as observações ocupam as linhas de uma matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea de todas as observações é

$$\mathbf{Y} = \mathbf{XA}^\top.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada e cada coluna corresponde a uma combinação linear das variáveis originais.

O posto de $\mathbf{A}$ determina a dimensão da imagem, enquanto o espaço nulo reúne as direções eliminadas pela transformação:

$$\dim(\mathcal{N}(\mathbf{A})) + \text{posto}(\mathbf{A}) = p.$$

Quando $\mathcal{N}(\mathbf{A})$ contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem. Para uma matriz quadrada, posto completo, núcleo trivial, determinante não nulo, bijetividade e existência da inversa são condições equivalentes.

A composição de transformações é representada pelo produto de suas matrizes. Se T_1 é representada por $\mathbf{A}$ e T_2 por $\mathbf{B}$, então

$$[T_2 \circ T_1] = \mathbf{B}\mathbf{A}.$$

A matriz situada à direita atua primeiro. Como a multiplicação matricial não é comutativa, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas produzem efeitos distintos sobre uma configuração de pontos. Rotações e reflexões preservam distâncias e ângulos. Escalonamentos modificam o comprimento das direções, cisalhamentos alteram ângulos e projeções eliminam componentes fora de um subespaço. Para uma transformação quadrada, $|\det(\mathbf{A})|$ representa o fator de alteração do volume, enquanto o sinal do determinante informa se a orientação é preservada ou invertida.

Transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos, normas, distâncias, ângulos e volumes. Também satisfazem

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) = \pm 1.$$

Uma transformação também pode ser representada em bases diferentes. Se $\mathcal{B}$ é uma base do domínio, $\mathcal{C}$ é uma base do contradomínio e $\mathbf{A}$ representa a transformação nas bases canônicas, então

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{A} \mathbf{P}_{\mathcal{B}}.$$

Quando a mesma base é utilizada no domínio e no contradomínio, as matrizes resultantes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa modifica o vetor em relação a eixos fixos. A mudança passiva mantém o vetor geométrico e modifica apenas suas coordenadas. Para uma base ortonormal organizada nas colunas de $\mathbf{Q}$, essas operações são representadas, respectivamente, por

$$\mathbf{y} = \mathbf{Q}\mathbf{x}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x}.$$

As transformações afins acrescentam uma translação à parte linear:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização é uma translação, o escalonamento é uma transformação linear e a padronização combina as duas operações. Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

A Tabela 4.6 reúne as expressões principais desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$\mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{X}\mathbf{A}^{\top}$	Transforma simultaneamente todas as observações
Composição	$\mathbf{B}\mathbf{A}\mathbf{x}$	Aplica $\mathbf{A}$ antes de $\mathbf{B}$
Transformação inversa	$\mathbf{A}^{-1}\mathbf{y}$	Recupera o vetor original
Rotação	$\mathbf{Q}(\theta)\mathbf{x}$	Gira a configuração preservando sua geometria
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria e inverte a orientação
Escalaonamento	$\mathbf{L}\mathbf{x}$	Amplia ou comprime direções

Objeto ou operação	Expressão	Interpretação
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração
Projeção	$\mathbf{P}\mathbf{x}$	Elimina componentes fora de um subespaço
Mudança de base	$\mathbf{P}_{\mathcal{B}}^{-1}\mathbf{x}$	Altera as coordenadas do vetor
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização	$\mathbf{x} - \mathbf{m}$	Desloca o centro da configuração
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

O capítulo seguinte examina direções cuja orientação é preservada por uma transformação linear. Essas direções conduzem aos conceitos de autovalor, autovetor e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Em uma base arbitrária, a matriz pode combinar diferentes coordenadas, dificultando a interpretação de sua ação. Algumas direções, entretanto, possuem um comportamento mais simples: todos os vetores contidos nessas direções permanecem no mesmo subespaço após a transformação.

A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço. Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. Nessa representação, a transformação atua separadamente sobre cada coordenada.

Para matrizes simétricas, essa simplificação possui propriedades adicionais. Seus autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permite interpretar formas quadráticas, matrizes positivas definidas, elipsóides, funções de matrizes e problemas de otimização. Essas estruturas também serão utilizadas posteriormente no estudo de covariâncias e decomposições matriciais.

5.1 Direções invariantes, autovalores e autoespaços

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p$$

é **invariante** sob $\mathbf{A}$ quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo $\mathbf{w} \in \mathcal{W}$.

Uma reta que passa pela origem e é gerada por um vetor não nulo $\mathbf{v}$ possui a forma

$$\text{span}(\mathbf{v}) = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Essa reta é invariante sob $\mathbf{A}$ quando a imagem de $\mathbf{v}$ permanece na própria reta. Nesse caso, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Definição 5.1 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.1 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned} \mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$.




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

A equação de autovalor também mostra que um autovetor não possui um representante único.

Teorema 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned}\mathbf{A}(c\mathbf{v}) &= c\mathbf{A}\mathbf{v} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}).\end{aligned}$$

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ . □

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.2 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Teorema 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

Comprovação. Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda \mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$. □

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição permite verificar se um vetor conhecido é um autovetor. Para determinar os autovalores a partir da matriz, é necessário identificar os valores de λ para os quais o sistema

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais. Essa condição conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo. Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.3 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Comprovação. Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$. □

Definição 5.3 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn e Johnson 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ,

$$\mathbf{Q}\left(\frac{\pi}{2}\right) = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando o espaço é ampliado de $\mathbb{R}^2$ para $\mathbb{C}^2$, a matriz possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente para matrizes cujos autovalores e autovetores são reais. Em particular, as matrizes simétricas reais sempre satisfazem essa condição.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.4 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

Comprovação. A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \dots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes. $\square$

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.4 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Considere duas matrizes com o mesmo polinômio característico:

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Em ambos os casos,

$$p_{\mathbf{A}_j}(\lambda) = (2 - \lambda)^2.$$

Portanto,

$$m_a(2) = 2.$$

Para $\mathbf{A}_1$,

$$\mathbf{A}_1 - 2\mathbf{I}_2 = \mathbf{0},$$

de modo que

$$\mathcal{E}_2 = \mathbb{R}^2$$

e

$$m_g(2) = 2.$$

Todo vetor não nulo do plano é um autovetor de $\mathbf{A}_1$ associado a $\lambda = 2$.

Para $\mathbf{A}_2$,

$$\mathbf{A}_2 - 2\mathbf{I}_2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

O sistema correspondente impõe

$$v_2 = 0.$$

Assim,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e

$$m_g(2) = 1.$$

Nesse caso, existe somente uma direção invariante linearmente independente.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

A Figura 5.2 compara as estruturas dos dois autoespaços.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

Uma transformação assume uma representação particularmente simples quando existe uma base formada por autovetores.

Definição 5.5 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existem uma matriz invertível

$$\mathbf{P}_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{P}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{P}_{\mathbf{A}}^{-1}.$$

As colunas de $\mathbf{P}_{\mathbf{A}}$ são autovetores linearmente independentes:

$$\mathbf{P}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p],$$

e a matriz diagonal contém os autovalores correspondentes:

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A ordem das colunas de $\mathbf{P}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Como

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{v}_j,$$

tem-se

$$\mathbf{A} \mathbf{P}_{\mathbf{A}} = \mathbf{P}_{\mathbf{A}} \Lambda_{\mathbf{A}}.$$

Multiplicando à direita por $\mathbf{P}_{\mathbf{A}}^{-1}$,

$$\mathbf{A} = \mathbf{P}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{P}_{\mathbf{A}}^{-1}.$$

Essa expressão é uma mudança de representação do operador. Conforme a Definição 4.5,

$$\Lambda_{\mathbf{A}} = \mathbf{P}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{P}_{\mathbf{A}}$$

é a matriz do mesmo operador na base formada pelos autovetores.

Se

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}} \mathbf{z},$$

então

$$\begin{aligned}\mathbf{Ax} &= \mathbf{AP_Az} \\ &= \mathbf{P_A\Lambda_Az}.\end{aligned}$$

Nas coordenadas da base de autovetores, cada componente é transformada separadamente:

$$\Lambda_{\mathbf{A}}\mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix}.$$

Teorema 5.5 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;
2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;
3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;
4. a soma das dimensões dos autoespaços é igual a p ;
5. para cada autovalor λ ,

$$m_g(\lambda) = m_a(\lambda).$$

(Horn e Johnson 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.4 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1} \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1} \\ &= \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{P}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{P}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

A diagonalização reduz a aplicação repetida do operador à aplicação independente das potências dos autovalores em cada direção invariante.

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.8, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.6 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

1. *todos os autovalores de $\mathbf{A}$ são reais;*
2. *autoespaços associados a autovalores distintos são ortogonais;*
3. *existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
4. *existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

(Horn e Johnson 2013)

Comprovação. Para demonstrar que os autovalores são reais, considere um autovalor possivelmente complexo λ e um autovetor complexo não nulo $\mathbf{z}$, de modo que

$$\mathbf{A}\mathbf{z} = \lambda\mathbf{z}.$$

Como $\mathbf{A}$ é real e simétrica, ela também é hermitiana:

$$\mathbf{A}^* = \mathbf{A},$$

em que $*$ representa a transposta conjugada.

Multiplicando a equação de autovalor à esquerda por $\mathbf{z}^*$,

$$\mathbf{z}^* \mathbf{A} \mathbf{z} = \lambda \mathbf{z}^* \mathbf{z}.$$

A quantidade

$$\mathbf{z}^* \mathbf{A} \mathbf{z}$$

é real, pois

$$(\mathbf{z}^* \mathbf{A} \mathbf{z})^* = \mathbf{z}^* \mathbf{A}^* \mathbf{z} = \mathbf{z}^* \mathbf{A} \mathbf{z}.$$

Além disso,

$$\mathbf{z}^* \mathbf{z} > 0.$$

Portanto,

$$\lambda = \frac{\mathbf{z}^* \mathbf{A} \mathbf{z}}{\mathbf{z}^* \mathbf{z}}$$

é real.

Considere agora dois autovetores reais $\mathbf{v}_i$ e $\mathbf{v}_j$, associados a autovalores distintos λ_i e λ_j . Como

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j,$$

tem-se

$$\begin{aligned} \lambda_i \mathbf{v}_i^\top \mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{v}_j. \end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Portanto, os autoespaços associados a autovalores distintos são ortogonais.

A existência de uma base ortonormal de autovetores pode ser demonstrada por indução sobre a ordem p da matriz. Para $p = 1$, o resultado é imediato.

Suponha agora $p > 1$. Pelo Teorema Fundamental da Álgebra, o polinômio característico de $\mathbf{A}$ possui pelo menos uma raiz em $\mathbb{C}$. Pela primeira parte da demonstração, essa raiz é real. Denote-a por λ_1 .

Como

$$\det(\mathbf{A} - \lambda_1 \mathbf{I}_p) = 0,$$

a matriz real

$$\mathbf{A} - \lambda_1 \mathbf{I}_p$$

é singular e possui um vetor não nulo real em seu núcleo. Normalizando esse vetor, obtém-se um autovetor unitário $\mathbf{q}_1$.

Considere o complemento ortogonal

$$\mathcal{W} = \text{span}(\mathbf{q}_1)^\perp.$$

Para qualquer $\mathbf{x} \in \mathcal{W}$,

$$\mathbf{q}_1^\top \mathbf{x} = 0.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned}\mathbf{q}_1^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{q}_1)^\top \mathbf{x} \\ &= \lambda_1 \mathbf{q}_1^\top \mathbf{x} \\ &= 0.\end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{x} \in \mathcal{W},$$

e $\mathcal{W}$ é invariante sob $\mathbf{A}$.

A restrição de $\mathbf{A}$ a $\mathcal{W}$ permanece simétrica. Como

$$\dim(\mathcal{W}) = p - 1,$$

a hipótese de indução garante uma base ortonormal

$$\mathbf{q}_2, \dots, \mathbf{q}_p$$

de $\mathcal{W}$ formada por autovetores da restrição e, conseqüentemente, de $\mathbf{A}$.

Assim,

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$ composta por autovetores de $\mathbf{A}$.

Organizando esses vetores nas colunas de

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

tem-se

$$\mathbf{Q}_A^\top \mathbf{Q}_A = \mathbf{I}_p.$$

Portanto,

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Definindo

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a relação

$$\mathbf{A} \mathbf{Q}_A = \mathbf{Q}_A \Lambda_A$$

fornece

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

□

A representação

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela também pode ser interpretada como uma diagonalização ortogonal.

Nas coordenadas determinadas pela base de autovetores,

$$\mathbf{z} = \mathbf{Q}_A^\top \mathbf{x},$$

o vetor original é recuperado por

$$\mathbf{x} = \mathbf{Q}_A \mathbf{z}.$$

A transformação de $\mathbf{x}$ pode ser escrita como

$$\begin{aligned}\mathbf{Ax} &= \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top \mathbf{x} \\ &= \mathbf{Q}_A \Lambda_A \mathbf{z}.\end{aligned}$$

A operação ocorre em três etapas:

1. $\mathbf{Q}_A^\top$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. Λ_A multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_A$ converte o resultado para as coordenadas canônicas.

A matriz simétrica atua, portanto, como um escalonamento independente em direções ortogonais.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.2 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz ortogonal de autovetores é

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a esfera unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária são determinados por




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por escalonamentos independentes.

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Teorema 5.7 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn e Johnson 2013)

Comprovação. As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Teorema 3.22, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned}\Pi_{\lambda^{(h)}}\Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h\mathbf{Q}_h^\top\mathbf{Q}_\ell\mathbf{Q}_\ell^\top \\ &= \mathbf{0}.\end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

□

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_\lambda = \mathbf{q}\mathbf{q}^\top.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_A$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top},$$

em que

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Teorema 5.8 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

Comprovação. Pela propriedade cíclica do traço,

$$\begin{aligned} \text{tr}(\mathbf{A}) &= \text{tr}(\mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top) \\ &= \text{tr}(\Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top \mathbf{Q}_\mathbf{A}) \\ &= \text{tr}(\Lambda_\mathbf{A}) \\ &= \sum_{j=1}^p \lambda_j. \end{aligned}$$

Para o determinante,

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{Q}_\mathbf{A}) \det(\Lambda_\mathbf{A}) \det(\mathbf{Q}_\mathbf{A}^\top) \\ &= \det(\Lambda_\mathbf{A}), \end{aligned}$$

pois

$$\det(\mathbf{Q}_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_{\mathbf{A}}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ estão relacionadas por uma mudança de base invertível e possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned} \dim \mathcal{N}(\mathbf{A}) &= p - \text{posto}(\mathbf{A}) \\ &= \# \{j : \lambda_j = 0\}. \end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos. □

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Teorema 5.9 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}$$

é a decomposição espectral de uma matriz simétrica, então

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

Comprovação. Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores formam uma base ortonormal, os dois subespaços são complementos ortogonais. $\square$

Cada autovalor nulo identifica uma direção eliminada pela transformação. Cada autovalor não nulo identifica uma direção que permanece representada na imagem.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.21, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Defina as coordenadas espectrais de $\mathbf{x}$ por

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

O sinal da forma quadrática é determinado pelos sinais dos autovalores.

Teorema 5.10 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn e Johnson 2013)

Comprovação. Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos. $\square$

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{c/\lambda_j} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.3 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^{\top} \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^{\top} \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh e otimização espectral

A decomposição espectral mostra que uma matriz simétrica atua por escalonamentos independentes em direções ortogonais. Essa estrutura permite identificar as direções nas quais uma forma quadrática assume seus maiores e menores valores.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p.$$

Definição 5.6 (Quociente de Rayleigh). O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a} \neq \mathbf{0}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}.$$

O denominador normaliza a forma quadrática pelo comprimento ao quadrado do vetor. Por isso, o quociente depende da direção de $\mathbf{a}$, e não de sua magnitude.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned}\mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}).\end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

Escreva

$$\mathbf{a} = \mathbf{Q}_{\mathbf{A}} \mathbf{z}.$$

Como $\mathbf{Q}_{\mathbf{A}}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é uma média ponderada dos autovalores. Os pesos medem a participação da direção de $\mathbf{a}$ em cada autoespaço.

Teorema 5.11 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido pelos autovetores associados a λ_1 , e o mínimo é atingido pelos autovetores associados a λ_p . (Horn e Johnson 2013)

Comprovação. Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido. □

Se o maior autovalor é simples, as direções que maximizam o quociente são

$$\text{span}(\mathbf{q}_1).$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

5.5.2 Exemplo bidimensional

Exemplo 5.4 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da esfera unitária.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

5.5.3 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição impede que a função objetivo seja aumentada apenas pela multiplicação de $\mathbf{a}$ por uma constante.

Sem essa restrição, se existe um vetor para o qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

então

$$(\mathbf{c} \mathbf{a})^{\top} \mathbf{A} (\mathbf{c} \mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}$$

pode crescer indefinidamente à medida que $|c|$ aumenta.

5.5.4 Multiplicadores de Lagrange

Para obter as direções estacionárias do problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \lambda) = \mathbf{a}^{\top} \mathbf{A} \mathbf{a} - \lambda (\mathbf{a}^{\top} \mathbf{a} - 1).$$

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^{\top} \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A}\mathbf{a} - 2\lambda\mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}.$$

As direções estacionárias do problema são autovetores de $\mathbf{A}$. Multiplicando a equação à esquerda por $\mathbf{a}^\top$ e utilizando

$$\mathbf{a}^\top \mathbf{a} = 1,$$

obtém-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A}\mathbf{a} &= \lambda \mathbf{a}^\top \mathbf{a} \\ &= \lambda. \end{aligned}$$

O valor da função objetivo em um autovetor unitário é o autovalor correspondente. Assim:

- o maior autovalor fornece o máximo global;
- o menor autovalor fornece o mínimo global;
- os demais autovalores correspondem a valores estacionários intermediários.

Teorema 5.12 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica. Os pontos estacionários do problema*

$$\text{otimizar} \quad \mathbf{a}^\top \mathbf{A}\mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

são os autovetores unitários de $\mathbf{A}$. O valor da função objetivo em um autovetor associado a λ é igual a λ .

Esse resultado explica por que problemas de maximização de variância, separação ou associação conduzem frequentemente a equações de autovalores. Quando a função objetivo é uma forma quadrática e a restrição fixa o comprimento, as condições de primeira ordem produzem uma equação espectral.

5.5.5 Direções sucessivas

Depois de encontrar a direção associada ao maior autovalor, pode-se procurar a direção de maior valor entre aquelas ortogonais à primeira.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição de ortogonalidade elimina qualquer componente na direção de $\mathbf{q}_1$. O maior valor restante é λ_2 , atingido em $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.13 (Caracterização variacional de direções sucessivas). *Se $\mathbf{A}$ é simétrica e seus autovalores estão ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p,$$

então

$$\lambda_k = \max_{\substack{\mathbf{a}^\top \mathbf{a} = 1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j < k}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por qualquer autovetor unitário associado a λ_k que satisfaça as restrições. (Horn e Johnson 2013)

Comprovação. Se $\mathbf{a}$ é ortogonal a

$$\mathbf{q}_1, \dots, \mathbf{q}_{k-1},$$

sua expansão espectral possui a forma

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Logo,

$$\begin{aligned}
\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \sum_{j=k}^p \lambda_j z_j^2 \\
&\leq \lambda_k \sum_{j=k}^p z_j^2 \\
&= \lambda_k.
\end{aligned}$$

Tomando

$$\mathbf{a} = \mathbf{q}_k,$$

obtém-se

$$\mathbf{q}_k^\top \mathbf{A} \mathbf{q}_k = \lambda_k.$$

Portanto, o limite superior é atingido. □

Quando há autovalores repetidos, as direções sucessivas dentro do mesmo autoespaço não são individualmente determinadas. Qualquer base ortonormal desse autoespaço fornece o mesmo valor da função objetivo e descreve o mesmo subespaço ótimo.

A caracterização variacional relaciona três objetos:

forma quadrática $\longleftrightarrow$ problema de otimização $\longleftrightarrow$ equação de autovalores.

A decomposição espectral também permite aplicar funções escalares aos autovalores e, desse modo, definir potências, raízes, inversas e outras funções de matrizes simétricas.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.7 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Teorema 5.14 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn e Johnson 1991)

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_\lambda$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

□

Portanto, todo autovetor de $\mathbf{A}$ também é autovetor de $f(\mathbf{A})$, com autovalor transformado em $f(\lambda)$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{Q}_\mathbf{A}^\top,$$

com

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_\mathbf{A}$ fornece

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top.$$

Exemplo 5.5 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^{-1} \mathbf{Q}_{\mathbf{A}}^{\top},$$

em que

$$\Lambda_{\mathbf{A}}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top},$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.8 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a **raiz quadrada principal** de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Essa matriz satisfaz

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned} \mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \Lambda_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A} \mathbf{I}_p \mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p. \end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2} \mathbf{x}$$

remove os diferentes fatores de escala determinados por $\mathbf{A}$. Ela também converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned}
\mathbf{x}^\top \mathbf{A}^{-1} \mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2} \mathbf{A}^{-1/2} \mathbf{x} \\
&= \mathbf{z}^\top \mathbf{z} \\
&= \|\mathbf{z}\|^2.
\end{aligned}$$

Essa transformação será retomada posteriormente como uma operação de branqueamento quando $\mathbf{A}$ representar uma matriz de covariâncias.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.9 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa divide a componente associada a cada autovalor não nulo por esse autovalor e anula as componentes pertencentes ao núcleo.

Exemplo 5.6 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}. \end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz positiva definida, o logaritmo principal é

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição
$\mathbf{A}^k$	λ_j^k	k inteiro não negativo
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$

Função	Ação sobre λ_j	Condição
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	$\mathbf{A}$ simétrica
$\exp(\mathbf{A})$	e^{λ_j}	$\mathbf{A}$ simétrica
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais transformam separadamente cada autoespaço. As raízes quadradas e suas inversas também permitem converter problemas definidos por duas formas quadráticas em problemas espectrais ordinários. Essa construção conduz aos autovalores generalizados.

5.7 Autovalores generalizados

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.17, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.10 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda\mathbf{M})\mathbf{v} = \mathbf{0}.$$

Para que existam soluções não triviais, é necessário que

$$\det(\mathbf{A} - \lambda\mathbf{M}) = 0.$$

Essa equação determina os autovalores generalizados do par.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.11 (Quociente de Rayleigh generalizado). Para

$$\mathbf{a} \neq \mathbf{0},$$

o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

Como $\mathbf{M} \succ 0$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o quociente está definido em todas as direções não nulas.

Assim como no caso ordinário, ele é invariante à escala:

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a})$$

para todo $c \neq 0$.

O problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição fixa o comprimento de $\mathbf{a}$ segundo a geometria determinada por $\mathbf{M}$.

A função lagrangiana é

$$\mathcal{L}(\mathbf{a}, \lambda) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \lambda (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1).$$

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A}\mathbf{a} - 2\lambda\mathbf{M}\mathbf{a}.$$

A condição de primeira ordem produz

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{M}\mathbf{a}.$$

Portanto, os pontos estacionários do problema restrito são autovetores generalizados.

Multiplicando essa equação à esquerda por $\mathbf{a}^\top$,

$$\mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda \mathbf{a}^\top \mathbf{M}\mathbf{a}.$$

Se

$$\mathbf{a}^\top \mathbf{M}\mathbf{a} = 1,$$

então

$$\mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda.$$

O autovalor generalizado é o valor assumido pela função objetivo na direção generalizada normalizada.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}\mathbf{M}^{-1/2}\mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\tilde{\mathbf{A}}^\top = \tilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido em um problema ordinário para uma matriz simétrica:

$$\tilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u}.$$

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \tilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}$$

converte a norma induzida por $\mathbf{M}$ na norma euclidiana. A matriz $\mathbf{M}^{-1/2}$ realiza a transformação inversa, levando as coordenadas euclidianas de $\mathbf{u}$ novamente às coordenadas originais de $\mathbf{v}$. O problema generalizado pode, então, ser analisado pelos resultados do Teorema Espectral e do quociente de Rayleigh ordinário.

Teorema 5.15 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

Comprovação. A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.11 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados. $\square$

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Teorema 5.16 (Ortogonalidade de autovetores generalizados). *Sejam $\mathbf{v}_i$ e $\mathbf{v}_j$ autovetores generalizados associados a autovalores distintos λ_i e λ_j do par $(\mathbf{A}, \mathbf{M})$.*

Então,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

(Horn e Johnson 2013)

Comprovação. Como

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{M} \mathbf{v}_i$$

e

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{M} \mathbf{v}_j,$$

tem-se

$$\begin{aligned}
\lambda_i \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= (\mathbf{A} \mathbf{v}_i)^\top \mathbf{v}_j \\
&= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\
&= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\
&= \lambda_j \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j.
\end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

□

Os autovetores podem ser normalizados para satisfazer

$$\mathbf{v}_j^\top \mathbf{M} \mathbf{v}_j = 1.$$

Assim, uma base de autovetores generalizados pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Essa é a ortonormalidade na métrica induzida por $\mathbf{M}$.

5.7.4 Diagonalização simultânea por congruência

Seja

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \mathbf{A}_g \mathbf{Q}_g^\top$$

a decomposição espectral da matriz transformada

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{P}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

As colunas de $\mathbf{P}_g$ são autovetores generalizados. De fato,

$$\begin{aligned} \mathbf{A} \mathbf{P}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \Lambda_g \\ &= \mathbf{M} \mathbf{P}_g \Lambda_g. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{P}_g^\top \mathbf{M} \mathbf{P}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p, \end{aligned}$$

e

$$\begin{aligned} \mathbf{P}_g^\top \mathbf{A} \mathbf{P}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \Lambda_g. \end{aligned}$$

Portanto,

$$\mathbf{P}_g^\top \mathbf{M} \mathbf{P}_g = \mathbf{I}_p$$

e

$$\mathbf{P}_g^\top \mathbf{A} \mathbf{P}_g = \Lambda_g.$$

As matrizes $\mathbf{A}$ e $\mathbf{M}$ são diagonalizadas simultaneamente por uma transformação de congruência. Essa operação difere da semelhança

$$\mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

utilizada para representar um único operador em outra base.

Na nova base:

- a forma quadrática associada a $\mathbf{M}$ torna-se a norma euclidiana;
- a forma quadrática associada a $\mathbf{A}$ torna-se diagonal.

Se

$$\mathbf{a} = \mathbf{P}_g \mathbf{z},$$

então

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, nessa base, a mesma forma do quociente de Rayleigh ordinário.

5.7.5 Exemplo numérico

Exemplo 5.7 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{p}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{p}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas de

$$\mathbf{P}_g = [\mathbf{p}_{g,1} \quad \mathbf{p}_{g,2}],$$

obtêm-se

$$\mathbf{P}_g^\top \mathbf{M} \mathbf{P}_g = \mathbf{I}_2$$

e

$$\mathbf{P}_g^\top \mathbf{A} \mathbf{P}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Um autovetor identifica uma direção invariante de uma transformação linear. Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor não nulo $\mathbf{v}$ permanece no autoespaço associado, enquanto o autovalor λ determina o escalonamento nessa direção.

Os autovalores são obtidos pela equação característica

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0,$$

e o autoespaço correspondente é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

A multiplicidade algébrica registra a repetição de um autovalor no polinômio característico. A multiplicidade geométrica é a dimensão de seu autoespaço. Uma matriz é diagonalizável quando possui uma base formada por autovetores:

$$\mathbf{A} = \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1}.$$

Nessa base, a transformação atua separadamente sobre cada coordenada.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores e a decomposição

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

A decomposição espectral permite escrever

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top,$$

mostrando que a matriz atua por escalonamentos independentes em direções ortogonais.

Traço, determinante, posto, invertibilidade e positividade podem ser determinados pelos autovalores. Nas coordenadas espectrais,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2,$$

de modo que os sinais dos autovalores caracterizam o sinal da forma quadrática. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

assume valores entre o menor e o maior autovalor. Seus extremos são atingidos nos autoespaços correspondentes. A mesma estrutura surge ao otimizar uma forma quadrática sob uma restrição de norma, pois as condições de primeira ordem conduzem a

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}.$$

A decomposição espectral também permite definir funções de matrizes:

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Potências, inversas, raízes quadradas, pseudoinversas, exponenciais e logaritmos são obtidos aplicando a função correspondente a cada autovalor.

Quando a normalização é definida por uma matriz positiva definida $\mathbf{M}$, obtém-se o problema generalizado

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{M} \mathbf{v}.$$

A mudança de variáveis determinada por $\mathbf{M}^{1/2}$ converte esse problema em um problema espectral ordinário para

$$\mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Os autovetores generalizados podem ser escolhidos ortonormais segundo a métrica de $\mathbf{M}$.

A Tabela 5.2 reúne as expressões principais.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica uma direção invariante
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{P}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{P}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Forma quadrática	$\mathbf{x}^\top \mathbf{A}\mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a})$	Caracteriza os autovalores extremos
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A}f(\Lambda_\mathbf{A})\mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}$	Compara duas formas quadráticas

A diagonalização depende da existência de uma base de autovetores, e a decomposição espectral é formulada para matrizes simétricas. O próximo capítulo apresenta uma decomposição aplicável a qualquer matriz real, inclusive matrizes retangulares e não simétricas. A Decomposição em Valores Singulares relacionará os espaços das linhas e das colunas, o posto, as normas matriciais e as aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e cujas colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub e Van Loan 2013)

A matriz $\mathbf{D}$ é denominada diagonal retangular porque

$$D_{ij} = 0 \quad \text{quando } i \neq j.$$

Se

$$q > p,$$

a matriz $\mathbf{D}$ possui linhas nulas abaixo de sua parte diagonal. Se

$$p > q,$$

ela possui colunas nulas à direita da parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & d_p \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos:

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto os demais valores singulares são iguais a zero.

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.1 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j\mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A}\mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;

- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base dos vetores singulares à direita.

Na segunda etapa,

$$\mathbf{DV}^\top \mathbf{x}$$

multiplica separadamente as coordenadas pelos valores singulares. Como $\mathbf{D}$ pode ser retangular, essa etapa também pode alterar a dimensão do espaço.

Na terceira etapa, $\mathbf{U}$ expressa o resultado na base ortonormal dos vetores singulares à esquerda.

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.2 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.3 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva os r valores singulares positivos e satisfaz exatamente

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Uma SVD truncada conserva somente os k maiores valores singulares, com

$$1 \leq k < r.$$

Definindo

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k],$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k)$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_k],$$

obtem-se

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Quando $k < r$,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ é uma aproximação de posto k . Suas propriedades de otimalidade e os erros produzidos pelo truncamento serão desenvolvidos posteriormente.

Alguns textos utilizam as expressões **SVD reduzida** ou **SVD econômica** para formas que não incluem todas as colunas das matrizes ortogonais. Como essa terminologia não é uniforme, neste capítulo serão utilizadas as expressões:

- **SVD completa**, para a representação com bases ortonormais completas;
- **SVD compacta**, para a representação exata com os valores singulares positivos;
- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

6.1.6 Não unicidade dos vetores singulares

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d \mathbf{U}_d \mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d (\mathbf{U}_d \mathbf{R}) (\mathbf{V}_d \mathbf{R})^\top &= d \mathbf{U}_d \mathbf{R} \mathbf{R}^\top \mathbf{V}_d^\top \\ &= d \mathbf{U}_d \mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das matrizes

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A} \mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Simetria e semidefinição positiva

A simetria segue de

$$(\mathbf{A}^\top \mathbf{A})^\top = \mathbf{A}^\top \mathbf{A}$$

e

$$(\mathbf{A}\mathbf{A}^\top)^\top = \mathbf{A}\mathbf{A}^\top.$$

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned}\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{x})^\top (\mathbf{A} \mathbf{x}) \\ &= \|\mathbf{A} \mathbf{x}\|^2 \\ &\geq 0.\end{aligned}$$

Logo,

$$\mathbf{A}^\top \mathbf{A} \succeq 0.$$

De modo semelhante, para qualquer

$$\mathbf{y} \in \mathbb{R}^q,$$

$$\begin{aligned}\mathbf{y}^\top \mathbf{A} \mathbf{A}^\top \mathbf{y} &= (\mathbf{A}^\top \mathbf{y})^\top (\mathbf{A}^\top \mathbf{y}) \\ &= \|\mathbf{A}^\top \mathbf{y}\|^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{A} \mathbf{A}^\top \succeq 0.$$

Pelo Teorema 5.6, as duas matrizes possuem autovalores reais não negativos e bases ortonormais de autovetores.

Teorema 6.2 (Espectros associados à SVD). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *esses autovalores podem ser escritos como*

$$d_1^2, \dots, d_r^2,$$

em que

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$;

3. *os núcleos satisfazem*

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A} \mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub e Van Loan 2013)

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então,

$$\mathbf{Ax} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}^\top \mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top \mathbf{A}),$$

então

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{x}^\top$,

$$\begin{aligned} 0 &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} \\ &= \|\mathbf{Ax}\|^2. \end{aligned}$$

Portanto,

$$\mathbf{Ax} = \mathbf{0},$$

e

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}).$$

Assim,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

O mesmo argumento, aplicado a $\mathbf{A}^\top$, fornece

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

Considere agora um autovalor positivo λ de

$$\mathbf{A}^\top \mathbf{A}$$

e um autovetor unitário $\mathbf{v}$ associado:

$$\mathbf{A}^\top \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Como $\lambda > 0$, defina

$$\mathbf{u} = \frac{\mathbf{A} \mathbf{v}}{\sqrt{\lambda}}.$$

Esse vetor possui norma unitária, pois

$$\begin{aligned} \mathbf{u}^\top \mathbf{u} &= \frac{\mathbf{v}^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\lambda} \\ &= \frac{\lambda \mathbf{v}^\top \mathbf{v}}{\lambda} \\ &= 1. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top \mathbf{u} &= \frac{\mathbf{A} \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\mathbf{A}^\top \mathbf{A} \mathbf{v})}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\lambda \mathbf{v})}{\sqrt{\lambda}} \\ &= \lambda \mathbf{u}. \end{aligned}$$

Portanto, todo autovalor positivo de

$$\mathbf{A}^\top \mathbf{A}$$

também é autovalor de

$$\mathbf{A}\mathbf{A}^\top.$$

O argumento inverso é obtido começando por um autovetor de

$$\mathbf{A}\mathbf{A}^\top$$

e definindo

$$\mathbf{v} = \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}.$$

As transformações entre os autoespaços são inversíveis quando $\lambda > 0$. Por isso, as multiplicidades dos autovalores positivos também coincidem.

Como

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A}) = r,$$

existem exatamente r autovalores positivos. O mesmo ocorre para

$$\mathbf{A}\mathbf{A}^\top.$$

Definindo

$$d_j = \sqrt{\lambda_j},$$

obtêm-se os r valores singulares positivos de $\mathbf{A}$. □

As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos vetores singulares

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Para cada autovalor positivo, defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Os vetores assim construídos são ortonormais. Para $i, j \leq r$,

$$\begin{aligned}
\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\
&= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\
&= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.
\end{aligned}$$

Como os vetores $\mathbf{v}_j$ são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam um conjunto ortonormal.

Além disso,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\begin{aligned}
\mathbf{A}^\top \mathbf{u}_j &= \frac{\mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_j} \\
&= \frac{d_j^2 \mathbf{v}_j}{d_j} \\
&= d_j \mathbf{v}_j.
\end{aligned}$$

Assim, cada valor singular positivo associa um par de direções:

$$\mathbf{v}_j \in \mathbb{R}^p \quad \text{e} \quad \mathbf{u}_j \in \mathbb{R}^q.$$

Essas direções satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

Reunindo os pares associados aos valores singulares positivos,

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

obtém-se

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r.$$

Complete $\mathbf{V}_r$ com uma matriz $\mathbf{V}_0$ cujas colunas formam uma base ortonormal de $\mathcal{N}(\mathbf{A})$. Então,

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal e

$$\mathbf{I}_p = \mathbf{V}_r\mathbf{V}_r^\top + \mathbf{V}_0\mathbf{V}_0^\top.$$

Como

$$\mathbf{A}\mathbf{V}_0 = \mathbf{0},$$

tem-se

$$\begin{aligned}
\mathbf{A} &= \mathbf{A} \mathbf{I}_p \\
&= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\
&= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\
&= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.
\end{aligned}$$

Essa é a SVD compacta.

6.2.3 Demonstração da existência da SVD completa

A construção anterior também demonstra o Teorema 6.1.

Comprovação. Os vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

estão associados ao autovalor zero de

$$\mathbf{A}^\top \mathbf{A}.$$

Pelo Teorema 6.2,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Logo,

$$\mathbf{A} \mathbf{v}_j = \mathbf{0}, \quad j = r + 1, \dots, p.$$

Os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal do espaço coluna de $\mathbf{A}$. Complete esse conjunto com uma base ortonormal

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_q$$

de

$$\mathcal{N}(\mathbf{A}^\top).$$

Defina

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e mantenha

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

As duas matrizes são ortogonais.

Construa a matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

colocando

$$d_1, \dots, d_r$$

em suas primeiras posições diagonais e zeros nas demais posições.

Para $j \leq r$,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Para $j > r$,

$$\mathbf{A}\mathbf{v}_j = \mathbf{0}.$$

Essas relações podem ser reunidas em

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{D}.$$

Multiplicando à direita por $\mathbf{V}^\top$,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Portanto, toda matriz real possui uma SVD completa. □

6.2.4 Decomposições espectrais associadas

A SVD compacta fornece diretamente as decomposições espectrais das duas matrizes de Gram:

$$\begin{aligned}\mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.\end{aligned}$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Essa expressão possui dimensão $p \times p$, pois

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}, \quad \mathbf{D}_r^2 \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r^\top \in \mathbb{R}^{r \times p}.$$

De forma análoga,

$$\begin{aligned}\mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.\end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top,$$

com dimensão $q \times q$.

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A}\mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A}\mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

6.2.5 Exemplo de construção da SVD

Exemplo 6.1 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned} \mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

O segundo é

$$\begin{aligned}
\mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\
&= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.
\end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A}\mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A}\mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j) |\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_\mathbf{A},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_\mathbf{A} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_\mathbf{A}\mathbf{\Lambda}_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

i Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como essas direções transformam uma esfera unitária do domínio em uma elipse ou em um elipsoide no espaço de chegada.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{A}\mathbf{x} &= \sum_{j=1}^p \alpha_j \mathbf{A}\mathbf{v}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Teorema 6.3 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r . A imagem da bola unitária por $\mathbf{A}$ é o elipsoide

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$

Comprovação. Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

$$\mathbf{x} = \sum_{j=1}^r \frac{\beta_j}{d_j} \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1,$$

de modo que $\mathbf{x} \in \mathcal{B}_p$. Além disso,

$$\mathbf{Ax} = \sum_{j=1}^r \beta_j \mathbf{u}_j = \mathbf{y}.$$

Logo, o conjunto apresentado coincide com a imagem da bola unitária. □

Quando $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

a imagem da esfera unitária

$$\{\mathbf{x} : \|\mathbf{x}\| = 1\}$$

é a superfície do elipsoide.

Quando

$$r < p,$$

existem direções não nulas eliminadas por $\mathbf{A}$. Nesse caso, a imagem da esfera também contém pontos do interior do elipsoide, pois parte da norma de $\mathbf{x}$ pode estar concentrada no núcleo da transformação.

Se

$$r < q,$$

o elipsoide está contido no subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a SVD também revela a dimensão efetiva da imagem da transformação.

6.3.2 Alteração dos comprimentos

A expansão de $\mathbf{x}$ na base dos vetores singulares fornece

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2.$$

Por outro lado,

$$\begin{aligned}\|\mathbf{Ax}\|^2 &= \left\| \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j \right\|^2 \\ &= \sum_{j=1}^r d_j^2 \alpha_j^2,\end{aligned}$$

pois os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Como

$$d_1 \geq d_j$$

para todo j ,

$$\begin{aligned}\|\mathbf{Ax}\|^2 &= \sum_{j=1}^r d_j^2 \alpha_j^2 \\ &\leq d_1^2 \sum_{j=1}^p \alpha_j^2 \\ &= d_1^2 \|\mathbf{x}\|^2.\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

A igualdade é atingida quando $\mathbf{x}$ pertence ao subespaço singular à direita associado ao maior valor singular.

Em particular,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

O maior valor singular é o maior fator de ampliação produzido pela transformação.

Se $\mathbf{A}$ possui posto coluna completo, então

$$r = p$$

e

$$d_p > 0.$$

Nesse caso,

$$\begin{aligned} \|\mathbf{Ax}\|^2 &= \sum_{j=1}^p d_j^2 \alpha_j^2 \\ &\geq d_p^2 \sum_{j=1}^p \alpha_j^2 \\ &= d_p^2 \|\mathbf{x}\|^2. \end{aligned}$$

Logo,

$$\|\mathbf{Ax}\| \geq d_p \|\mathbf{x}\|$$

e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se $\mathbf{A}$ não possui posto coluna completo, existe um vetor unitário no núcleo. Nesse caso,

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

Esses extremos serão retomados na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.2 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;
- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal da circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.

A figura representa uma transformação não simétrica. Por isso, as direções singulares à direita e à esquerda não coincidem. A matriz $\mathbf{V}^\top$ alinha inicialmente a circunferência às direções $\mathbf{v}_1$ e $\mathbf{v}_2$. A matriz $\mathbf{D}$ altera os comprimentos segundo d_1 e d_2 . A matriz $\mathbf{U}$ orienta os semieixos resultantes nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$.

6.3.4 Transformações de posto deficiente

Quando algum valor singular é zero, a transformação colapsa uma direção do domínio.

Por exemplo, considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Seus valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A bola unitária é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

A direção correspondente ao valor singular nulo pertence ao núcleo. O elipsoide resultante é degenerado e possui dimensão inferior à dimensão do domínio.

De modo geral:

- cada valor singular positivo produz um semieixo da imagem;
- cada valor singular nulo elimina uma direção;
- o número de semieixos não nulos é o posto da matriz;
- o elipsoide está contido no espaço coluna de $\mathbf{A}$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores, normas e condicionamento diretamente a partir dos vetores e valores singulares.

6.4 Espaços fundamentais, posto, normas e condicionamento

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Teorema 6.4 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_q\} = \mathcal{C}(\mathbf{U}_0).$$

(Golub e Van Loan 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{U}_r) \subseteq \mathcal{C}(\mathbf{A}).$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r).$$

Aplicando o mesmo argumento a

$$\mathbf{A}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top,$$

obtém-se

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r).$$

Considere agora a base ortonormal completa

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma decomposição única da forma

$$\mathbf{x} = \mathbf{V}_r \alpha + \mathbf{V}_0 \beta.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top (\mathbf{V}_r \alpha + \mathbf{V}_0 \beta) \\ &= \mathbf{U}_r \mathbf{D}_r \alpha, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_0 = \mathbf{0}.$$

Como $\mathbf{D}_r$ é invertível,

$$\mathbf{Ax} = \mathbf{0}$$

se, e somente se,

$$\alpha = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A})$$

se, e somente se,

$$\mathbf{x} = \mathbf{V}_0 \beta.$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

Aplicando o mesmo raciocínio a $\mathbf{A}^\top$,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

□

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.3.

Tabela 6.3: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

Como as colunas de $\mathbf{U}_r$ são ortonormais, a matriz

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^{\top}$$

é o projetor ortogonal sobre o espaço coluna de $\mathbf{A}$.

O projetor sobre o núcleo à esquerda é

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^{\top})} = \mathbf{U}_0 \mathbf{U}_0^{\top}.$$

Como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U}_r \mathbf{U}_r^{\top} + \mathbf{U}_0 \mathbf{U}_0^{\top} = \mathbf{I}_q.$$

Portanto,

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^{\top})} = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^{\top}.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

é o projetor sobre o espaço linha, enquanto

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top$$

projeta sobre o núcleo.

As matrizes

$$\mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{V}_r \mathbf{V}_r^\top$$

são simétricas e idempotentes, conforme as propriedades dos projetores ortogonais estudadas anteriormente.

Exemplo 6.3 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{ \mathbf{0} \}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned} \mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}. \end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

A quantidade de valores singulares positivos é igual ao posto:

$$\text{posto}(\mathbf{A}) = r.$$

Essa igualdade também pode ser observada a partir da SVD compacta. As matrizes

$$\mathbf{U}_r \quad \text{e} \quad \mathbf{V}_r$$

possuem posto coluna r , e

$$\mathbf{D}_r$$

é diagonal e invertível. Portanto,

$$\text{posto}(\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) = r.$$

Pelo Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Os valores singulares nulos representam direções eliminadas pela transformação. A quantidade dessas direções depende do espaço considerado:

- no domínio, existem $p - r$ direções no núcleo de $\mathbf{A}$;
- no contradomínio, existem $q - r$ direções ortogonais à imagem.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.4 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = \text{tr}(\mathbf{A}^\top \tilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \tilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.5 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr}(\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.6 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Teorema 6.5 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub e Van Loan 2013)

Comprovação. Para a norma espectral, escreva

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2$$

e

$$\|\mathbf{Ax}\|^2 = \sum_{j=1}^r d_j^2 \alpha_j^2.$$

Como $d_j \leq d_1$,

$$\|\mathbf{Ax}\|^2 \leq d_1^2 \|\mathbf{x}\|^2.$$

Logo,

$$\frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} \leq d_1.$$

Tomando

$$\mathbf{x} = \mathbf{v}_1,$$

obtém-se

$$\|\mathbf{Av}_1\| = d_1.$$

Portanto,

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius,

$$\begin{aligned}
\|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\
&= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\
&= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\
&= \text{tr}(\mathbf{D}_r^2) \\
&= \sum_{j=1}^r d_j^2.
\end{aligned}$$

□

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Teorema 6.6 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub e Van Loan 2013)

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p$$

e a SVD compacta coincide, em dimensão, com a SVD completa.

6.4.8 Menor valor singular

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p \leq q,$$

seu menor valor singular é

$$d_p > 0.$$

Ele possui a caracterização

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

Portanto, d_p mede o menor fator de alteração do comprimento entre os vetores unitários do domínio.

Se

$$d_p$$

é pequeno, existe uma direção unitária cuja imagem possui comprimento pequeno. Nessa direção, a transformação aproxima-se de um colapso.

Se a matriz não possui posto coluna completo, existe um vetor unitário no núcleo e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

6.4.9 Número de condição

Defina

$$s = \min(q, p).$$

Definição 6.7 (Número de condição na norma espectral). Se

$$\text{posto}(\mathbf{A}) = s,$$

o número de condição espectral é

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Se

$$\text{posto}(\mathbf{A}) < s,$$

define-se

$$\kappa_2(\mathbf{A}) = \infty.$$

Quando $\mathbf{A}$ possui posto máximo, d_s é o menor valor singular positivo.

Se

$$q \geq p$$

e

$$r = p,$$

a matriz possui posto coluna completo. Nesse caso,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|.$$

O número de condição compara diretamente os fatores máximo e mínimo de alteração dos comprimentos no domínio inteiro.

Se

$$q < p$$

e

$$r = q,$$

a matriz possui posto linha completo, mas

$$\dim \mathcal{N}(\mathbf{A}) = p - q.$$

Existem, portanto, direções eliminadas pela transformação. Nesse caso, o número de condição descreve a ação de $\mathbf{A}$ restrita ao espaço linha

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp.$$

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{A}\mathbf{x}\|.$$

Para uma matriz quadrada invertível,

$$r = p = q$$

e

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Logo,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p}$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

A interpretação do número de condição deve considerar somente as direções associadas aos valores singulares positivos.

- Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

essas direções são transformadas por fatores semelhantes.

- Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são preservadas ou ampliadas, enquanto outras são fortemente contraídas.

- Quando

$$\kappa_2(\mathbf{A}) = \infty,$$

o posto é menor que o máximo possível e há valores singulares nulos adicionais além daqueles impostos pelas dimensões retangulares da matriz.

Valores singulares positivos muito pequenos amplificam erros quando se tenta inverter a transformação em seu subespaço ativo. Esse efeito será retomado na seção sobre pseudoinversa e mínimos quadrados.

Exemplo 6.4 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

A matriz amplia todas as direções pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por 2, enquanto a segunda é contraída por 0,02. A inversão exigiria multiplicar essa segunda componente por

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem produzir alterações acentuadas na solução invertida.

6.4.10 Posto exato e posto numérico

Matematicamente, o posto é o número de valores singulares estritamente positivos:

$$r = \# \{j : d_j > 0\}.$$

Em cálculos numéricos, resultados teoricamente nulos podem aparecer como números positivos muito pequenos devido a arredondamentos, ruído ou aproximações computacionais.

Por isso, programas numéricos utilizam uma tolerância τ e tratam como efetivamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

O número de valores singulares acima da tolerância é denominado **posto numérico**.

A tolerância não é uma propriedade puramente algébrica da matriz. Ela depende de:

- precisão numérica;
- escala dos dados;
- dimensões da matriz;
- finalidade da análise;
- nível de ruído considerado relevante.

Essa distinção será útil nas aproximações de posto reduzido. Nessas aproximações, valores singulares pequenos podem ser descartados deliberadamente, mesmo quando são matematicamente positivos.

A SVD fornece, assim, uma descrição integrada da estrutura da matriz:

$$\begin{aligned} \text{posto} &\longleftrightarrow \text{número de valores singulares positivos,} \\ \text{imagem} &\longleftrightarrow \text{vetores singulares à esquerda,} \\ \text{espaço linha} &\longleftrightarrow \text{vetores singulares à direita,} \\ \text{núcleos} &\longleftrightarrow \text{direções associadas a valores nulos,} \\ \text{ampliação máxima} &\longleftrightarrow d_1, \\ \text{contração mínima} &\longleftrightarrow d_r, \\ \text{condicionamento} &\longleftrightarrow d_1/d_r. \end{aligned}$$

Quando a matriz representa um conjunto de dados, as bases à esquerda e à direita descrevem, respectivamente, estruturas nos espaços das observações e das variáveis.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, os dois conjuntos de vetores singulares pertencem a espaços diferentes:

- as colunas de $\mathbf{U}_r$ pertencem ao espaço das observações $\mathbb{R}^n$;
- as colunas de $\mathbf{V}_r$ pertencem ao espaço das variáveis $\mathbb{R}^p$.

Os valores singulares conectam essas duas representações.

6.5.1 Coordenadas no espaço das variáveis

Multiplicando a SVD à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r.\end{aligned}$$

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Então,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações nas direções determinadas pelos vetores singulares à direita.

Sua j -ésima coluna é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Portanto, para cada direção $\mathbf{v}_j$ no espaço das variáveis, a multiplicação

$$\mathbf{X}\mathbf{v}_j$$

produz um vetor de n coordenadas, uma para cada observação.

Se a linha i de $\mathbf{X}$ é

$$\mathbf{x}_i^\top,$$

então o elemento z_{ij} é

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Assim, z_{ij} é a projeção da observação i sobre a direção $\mathbf{v}_j$.

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

o vetor singular à esquerda fornece a direção das coordenadas entre as observações, enquanto o valor singular determina sua magnitude.

6.5.2 Coordenadas no espaço das observações

A relação dual é obtida multiplicando a transposta da matriz de dados por $\mathbf{U}_r$:

$$\begin{aligned} \mathbf{X}^\top \mathbf{U}_r &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \\ &= \mathbf{V}_r \mathbf{D}_r. \end{aligned}$$

Logo,

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

A j -ésima coluna dessa matriz é

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Essa expressão representa as variáveis nas direções determinadas pelos vetores singulares à esquerda.

As duas relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam a dualidade entre os espaços das observações e das variáveis.

Teorema 6.7 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados, então, para cada $j = 1, \dots, r$,

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Portanto, o mesmo valor singular d_j relaciona uma direção no espaço das variáveis a uma direção no espaço das observações.

6.5.3 Matrizes de Gram

As matrizes

$$\mathbf{X}^\top \mathbf{X}$$

e

$$\mathbf{X} \mathbf{X}^\top$$

descrevem produtos internos em espaços distintos.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de produtos cruzados entre as variáveis. Pela SVD,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

A matriz

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram entre as observações:

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

As duas matrizes possuem os mesmos autovalores positivos:

$$d_1^2, \dots, d_r^2.$$

Entretanto, seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ descreve uma direção entre as variáveis;
- $\mathbf{u}_j \in \mathbb{R}^n$ descreve uma direção entre as observações.

Essa relação permite escolher a menor das duas matrizes para determinadas análises teóricas. Quando

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Quando

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

pode fornecer uma representação de menor dimensão.

Essa observação não altera a SVD: as duas matrizes compartilham os mesmos valores singulares positivos e representam lados complementares da mesma estrutura.

6.5.4 Reconstrução das observações

A SVD compacta pode ser escrita como

$$\mathbf{X} = (\mathbf{X}\mathbf{V}_r) \mathbf{V}_r^\top.$$

Como

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r,$$

tem-se

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top.$$

A matriz $\mathbf{Z}$ contém as coordenadas das observações na base formada pelas colunas de $\mathbf{V}_r$. A multiplicação por $\mathbf{V}_r^\top$ reconstrói as observações no espaço original das variáveis.

Para a observação i ,

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto, todas as observações pertencem ao subespaço

$$\mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

a nuvem de observações está contida em um subespaço próprio de $\mathbb{R}^p$. Nesse caso, existe redundância linear exata entre as variáveis.

6.5.5 Preservação de produtos internos

Como

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r,$$

tem-se

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{V}_r\mathbf{V}_r^\top\mathbf{X}^\top.$$

Como todas as linhas de $\mathbf{X}$ pertencem ao espaço linha

$$\mathcal{C}(\mathbf{V}_r),$$

vale

$$\mathbf{X}\mathbf{V}_r\mathbf{V}_r^\top = \mathbf{X}.$$

Logo,

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Portanto, a representação pelas r coordenadas singulares positivas preserva exatamente os produtos internos entre as observações.

Para duas observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Consequentemente,

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

A representação compacta reduz a dimensão de p para r quando a matriz possui posto deficiente, sem alterar a geometria euclidiana da nuvem de observações.

Essa redução é exata porque são mantidas todas as direções associadas a valores singulares positivos.

6.5.6 Centralização da matriz de dados

A posição da nuvem de observações depende do vetor de médias. Para estudar sua estrutura em torno do centro, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

é a matriz de centralização.

A SVD compacta de $\mathbf{X}_c$ é

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Como as colunas de $\mathbf{X}_c$ possuem média zero,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui posto coluna completo,

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto, cada vetor singular à esquerda associado a um valor singular positivo é ortogonal ao vetor de uns:

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Isso significa que as coordenadas

$$\mathbf{z}_j = d_j \mathbf{u}_j$$

também possuem média zero.

6.5.7 Relação com a matriz de covariâncias amostral

A matriz de covariâncias amostral pode ser escrita como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top. \end{aligned}$$

Logo,

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Essa expressão mostra que:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$;
- os autovalores positivos de $\mathbf{S}$ são

$$\frac{d_j^2}{n-1};$$

- o posto de $\mathbf{S}$ é igual ao posto de $\mathbf{X}_c$.

Como

$$\text{posto}(\mathbf{H}_n) = n-1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n-1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n-1, p).$$

Se

$$p \geq n,$$

a matriz de covariâncias amostral é necessariamente singular, pois

$$\text{posto}(\mathbf{S}) \leq n-1 < p.$$

Esse resultado será retomado no capítulo de covariâncias. Neste ponto, ele mostra que a SVD da matriz centralizada descreve diretamente a estrutura espectral da covariância amostral.

6.5.8 Magnitude quadrática da matriz centralizada

A norma de Frobenius da matriz centralizada é

$$\begin{aligned}\|\mathbf{X}_c\|_F^2 &= \text{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= \sum_{j=1}^r d_j^2.\end{aligned}$$

Como

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1)\mathbf{S},$$

tem-se

$$\|\mathbf{X}_c\|_F^2 = (n-1) \text{tr}(\mathbf{S}).$$

Portanto,

$$\sum_{j=1}^r d_j^2 = (n-1) \text{tr}(\mathbf{S}).$$

A soma dos quadrados dos valores singulares de $\mathbf{X}_c$ corresponde à dispersão quadrática total da nuvem em torno da média, multiplicada por $n-1$.

Essa interpretação depende da centralização. Para uma matriz de dados não centralizada,

$$\|\mathbf{X}\|_F^2$$

mede a soma dos quadrados em relação à origem, e não a dispersão em relação ao vetor de médias.

Exemplo 6.5 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned} \mathbf{Z} &= \mathbf{X} \mathbf{V}_2 \\ &= \mathbf{U}_2 \mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}. \end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das variáveis. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta produz a representação exata

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Quando todas as r direções associadas a valores singulares positivos são mantidas:

- a matriz é reconstruída exatamente;
- os produtos internos entre observações são preservados;
- as distâncias euclidianas entre observações são preservadas;
- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão ainda menor utiliza somente os primeiros k valores singulares, com

$$k < r.$$

Nesse caso, a reconstrução deixa de ser exata. A forma expandida da SVD permite identificar a contribuição de cada direção e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta pode ser desenvolvida como uma soma de matrizes de posto 1. Se

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

então

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r].$$

Efetuando o produto,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa expressão é denominada **forma expandida da SVD**.

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

representa a contribuição do j -ésimo par de direções singulares.

6.6.1 Parcelas de posto 1

Considere a matriz

$$\mathbf{u}_j \mathbf{v}_j^\top.$$

Suas colunas são múltiplos de $\mathbf{u}_j$:

$$\mathbf{u}_j \mathbf{v}_j^\top = [v_{1j} \mathbf{u}_j \quad \cdots \quad v_{pj} \mathbf{u}_j].$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

A matriz original é, portanto, construída pela soma de r estruturas de posto 1:

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + \cdots + d_r \mathbf{u}_r \mathbf{v}_r^\top.$$

Os valores singulares determinam a magnitude de cada parcela. Como

$$d_1 \geq \cdots \geq d_r > 0,$$

as parcelas são organizadas em ordem decrescente segundo sua contribuição para as normas espectral e de Frobenius.

6.6.2 Ortogonalidade das parcelas

As matrizes

$$\mathbf{u}_i \mathbf{v}_i^\top$$

e

$$\mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius quando $i \neq j$.

De fato,

$$\begin{aligned}
\left\langle \mathbf{u}_i \mathbf{v}_i^\top, \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F &= \text{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\
&= \text{tr} (\mathbf{v}_i \mathbf{u}_i^\top \mathbf{u}_j \mathbf{v}_j^\top) \\
&= (\mathbf{u}_i^\top \mathbf{u}_j) \text{tr} (\mathbf{v}_i \mathbf{v}_j^\top) \\
&= (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i).
\end{aligned}$$

Como os vetores singulares são ortonormais,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_j^\top \mathbf{v}_i = 0$$

quando $i \neq j$. Logo,

$$\left\langle \mathbf{u}_i \mathbf{v}_i^\top, \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

Além disso,

$$\begin{aligned}
\left\| \mathbf{u}_j \mathbf{v}_j^\top \right\|_F^2 &= \left\langle \mathbf{u}_j \mathbf{v}_j^\top, \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F \\
&= (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\
&= 1.
\end{aligned}$$

Portanto,

$$\left\| d_j \mathbf{u}_j \mathbf{v}_j^\top \right\|_F = d_j.$$

A identidade

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

pode ser interpretada como uma decomposição pitagórica da magnitude quadrática total da matriz.

6.6.3 SVD truncada

A forma expandida permite construir aproximações conservando somente as primeiras parcelas.

Definição 6.8 (SVD truncada). Seja

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

a SVD compacta expandida de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a **SVD truncada no posto k** é

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.4 Ortogonalidade entre aproximação e diferença

Como as parcelas singulares são ortogonais segundo o produto interno de Frobenius,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

As duas parcelas são

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A razão

$$\frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

mede a proporção da magnitude quadrática da matriz preservada pela aproximação.

A parcela descartada é

$$\frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

As duas proporções somam 1.

Para uma matriz genérica, essas quantidades devem ser interpretadas em termos da norma de Frobenius. Quando $\mathbf{A}$ é uma matriz de dados centralizada, elas também podem ser relacionadas à dispersão total da nuvem de observações.

6.6.5 Erro na norma espectral

O maior valor singular da diferença

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é

$$d_{k+1}.$$

Portanto,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Esse erro mede a maior diferença entre a ação de $\mathbf{A}$ e a ação de $\mathbf{A}_k$ sobre um vetor unitário:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

A direção em que o erro máximo é atingido é

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

6.6.6 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.8 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub e Van Loan 2013)

Comprovação. Considere inicialmente a norma espectral e uma matriz arbitrária

$$\widetilde{\mathbf{A}}$$

com

$$\text{posto}(\widetilde{\mathbf{A}}) \leq k.$$

Defina o subespaço

$$\mathcal{S}_{k+1} = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_{k+1} \}.$$

Como

$$\dim(\mathcal{S}_{k+1}) = k + 1$$

e a restrição de $\widetilde{\mathbf{A}}$ a esse subespaço possui imagem de dimensão no máximo k , existe um vetor unitário

$$\mathbf{x} \in \mathcal{S}_{k+1}$$

tal que

$$\widetilde{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Escreva

$$\mathbf{x} = \sum_{j=1}^{k+1} \alpha_j \mathbf{v}_j,$$

com

$$\sum_{j=1}^{k+1} \alpha_j^2 = 1.$$

Então,

$$\begin{aligned} \left\| (\mathbf{A} - \widetilde{\mathbf{A}}) \mathbf{x} \right\|^2 &= \|\mathbf{A}\mathbf{x}\|^2 \\ &= \sum_{j=1}^{k+1} d_j^2 \alpha_j^2 \\ &\geq d_{k+1}^2 \sum_{j=1}^{k+1} \alpha_j^2 \\ &= d_{k+1}^2. \end{aligned}$$

Logo,

$$\|\mathbf{A} - \widetilde{\mathbf{A}}\|_2 \geq d_{k+1}.$$

Para a SVD truncada,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Portanto, $\mathbf{A}_k$ atinge o limite inferior e é uma solução ótima na norma espectral.

Para a norma de Frobenius, considere o projetor ortogonal

$$\mathbf{P}$$

sobre o espaço coluna de $\widetilde{\mathbf{A}}$. Como

$$\text{posto}(\widetilde{\mathbf{A}}) \leq k,$$

tem-se

$$\text{posto}(\mathbf{P}) \leq k.$$

Além disso,

$$\mathbf{P}\widetilde{\mathbf{A}} = \widetilde{\mathbf{A}}.$$

A diferença pode ser decomposta como

$$\mathbf{A} - \widetilde{\mathbf{A}} = (\mathbf{I}_q - \mathbf{P}) \mathbf{A} + (\mathbf{P}\mathbf{A} - \widetilde{\mathbf{A}}).$$

As duas parcelas são ortogonais segundo o produto interno de Frobenius, pois a primeira possui colunas no complemento ortogonal de $\mathcal{C}(\mathbf{P})$, enquanto a segunda possui colunas em $\mathcal{C}(\mathbf{P})$.

Assim,

$$\begin{aligned} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &= \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 \\ &\quad + \|\mathbf{P}\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 \\ &\geq \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2. \end{aligned}$$

A primeira parcela pode ser escrita como

$$\|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 = \|\mathbf{A}\|_F^2 - \|\mathbf{P}\mathbf{A}\|_F^2.$$

Considere uma base ortonormal

$$\mathbf{w}_1, \dots, \mathbf{w}_s, \quad s \leq k,$$

do espaço projetado por $\mathbf{P}$. Então,

$$\mathbf{P} = \sum_{i=1}^s \mathbf{w}_i \mathbf{w}_i^\top$$

e

$$\begin{aligned} \|\mathbf{P}\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{P}\mathbf{A}\mathbf{A}^\top) \\ &= \sum_{i=1}^s \mathbf{w}_i^\top \mathbf{A}\mathbf{A}^\top \mathbf{w}_i. \end{aligned}$$

Expandindo os vetores $\mathbf{w}_i$ na base dos vetores singulares à esquerda, obtém-se

$$\|\mathbf{P}\mathbf{A}\|_F^2 = \sum_{j=1}^r c_j d_j^2,$$

em que

$$0 \leq c_j \leq 1$$

e

$$\sum_{j=1}^r c_j \leq k.$$

Como os valores singulares estão ordenados,

$$\|\mathbf{P}\mathbf{A}\|_F^2 \leq \sum_{j=1}^k d_j^2.$$

Portanto,

$$\begin{aligned}\|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &\geq \|\mathbf{A}\|_F^2 - \sum_{j=1}^k d_j^2 \\ &= \sum_{j=k+1}^r d_j^2.\end{aligned}$$

Para

$$\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^\top,$$

tem-se

$$\mathbf{P}\mathbf{A} = \mathbf{A}_k.$$

Além disso,

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Logo, $\mathbf{A}_k$ também atinge o limite inferior na norma de Frobenius. $\square$

O teorema mostra que nenhum outro procedimento pode produzir uma matriz de posto no máximo k com erro menor nas duas normas consideradas.

6.6.7 Unicidade da aproximação

A existência de uma aproximação ótima não implica sempre unicidade.

Na norma de Frobenius, a aproximação de posto k é única quando

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o limite de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de bases e subespaços dentro desse bloco podem produzir aproximações ótimas distintas.

Na norma espectral, $\mathbf{A}_k$ é uma aproximação ótima, mas outras matrizes de posto no máximo k também podem atingir o mesmo erro. A unicidade não deve ser presumida apenas pela existência de uma separação entre valores singulares.

Quando

$$k \geq r,$$

a aproximação exata é

$$\mathbf{A}_k = \mathbf{A},$$

e o erro é zero.

6.6.8 Exemplo de aproximação de posto 1

Exemplo 6.6 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

6.6.9 Aproximação de uma matriz de dados

Se

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é uma matriz de dados, sua aproximação de posto k é

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Definindo

$$\mathbf{Z}_k = \mathbf{X} \mathbf{V}_k,$$

tem-se

$$\mathbf{Z}_k = \mathbf{U}_k \mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k \mathbf{V}_k^\top.$$

A matriz $\mathbf{Z}_k$ fornece uma representação das observações em k coordenadas. A multiplicação por $\mathbf{V}_k^\top$ reconstrói uma aproximação das variáveis originais.

Para a observação i ,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij} \mathbf{v}_j.$$

O vetor residual é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij} \mathbf{v}_j.$$

A SVD truncada escolhe o subespaço de dimensão k que minimiza a soma dos erros quadráticos de reconstrução de todas as observações:

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2.$$

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a parcela da dispersão quadrática total preservada pelas primeiras k direções singulares.

Essa estrutura será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, o resultado deve ser interpretado como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada descarta direções associadas a valores singulares menores. A pseudoinversa realiza uma operação diferente: ela conserva as direções associadas a valores singulares positivos e inverte os respectivos fatores de escala.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Como todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos, a matriz

$$\mathbf{D}_r^{-1} = \text{diag}\left(\frac{1}{d_1}, \dots, \frac{1}{d_r}\right)$$

está bem definida.

Definição 6.9 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz a ação de $\mathbf{A}$ somente nas direções efetivamente representadas pela transformação.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio da decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

é simétrica, a definição espectral produz

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que cada autovalor não nulo é substituído por seu inverso.

A definição pela SVD coincide com essa construção, mas permanece válida quando $\mathbf{A}$ não é simétrica ou é retangular.

Se $\mathbf{A}$ é quadrada e invertível, todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Assim, a pseudoinversa generaliza a inversa usual.

6.7.2 Condições de Moore–Penrose

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.9 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub e Van Loan 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top}$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top}.$$

Então,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+\mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \\ &= \mathbf{A}. \end{aligned}$$

De modo semelhante,

$$\begin{aligned} \mathbf{A}^+\mathbf{A}\mathbf{A}^+ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \\ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \\ &= \mathbf{A}^+. \end{aligned}$$

Além disso,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top,$$

que são matrizes simétricas. Portanto, a matriz definida pela SVD satisfaz as quatro condições de Moore–Penrose.

Para demonstrar a unicidade, suponha que

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

também satisfaça as quatro condições.

A matriz $\mathbf{AG}$ é simétrica e

$$\begin{aligned} (\mathbf{AG})^2 &= \mathbf{AGAG} \\ &= (\mathbf{AGA})\mathbf{G} \\ &= \mathbf{AG}. \end{aligned}$$

Logo, $\mathbf{AG}$ é um projetor ortogonal.

Sua imagem está contida em $\mathcal{C}(\mathbf{A})$. Além disso, se

$$\mathbf{y} = \mathbf{Ax} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{AGy} = \mathbf{AGAx} = \mathbf{Ax} = \mathbf{y}.$$

Portanto,

$$\mathbf{AG} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top.$$

De maneira análoga, $\mathbf{GA}$ é simétrica e idempotente.

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{GAx} = \mathbf{0}.$$

Reciprocamente, se

$$\mathbf{GAx} = \mathbf{0},$$

então

$$\mathbf{Ax} = \mathbf{AGAx} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{GA}) = \mathcal{N}(\mathbf{A}).$$

Como $\mathbf{GA}$ é um projetor ortogonal,

$$\mathbf{GA} = \mathbf{P}_{\mathcal{N}(\mathbf{A})^\perp} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top.$$

Da condição

$$\mathbf{GAG} = \mathbf{G},$$

segue que

$$\mathcal{C}(\mathbf{G}) \subseteq \mathcal{C}(\mathbf{GA}) = \mathcal{C}(\mathbf{A}^\top).$$

Considere agora um vetor singular à esquerda $\mathbf{u}_j$, com $j \leq r$. Como

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

tem-se

$$\mathbf{AGu}_j = \mathbf{u}_j.$$

Como

$$\mathbf{G}\mathbf{u}_j \in \mathcal{C}(\mathbf{A}^\top),$$

esse vetor pode ser escrito como

$$\mathbf{G}\mathbf{u}_j = \sum_{\ell=1}^r c_\ell \mathbf{v}_\ell.$$

Aplicando $\mathbf{A}$,

$$\mathbf{u}_j = \sum_{\ell=1}^r c_\ell d_\ell \mathbf{u}_\ell.$$

Pela unicidade das coordenadas na base ortonormal,

$$c_\ell = \begin{cases} 1/d_j, & \ell = j, \\ 0, & \ell \neq j. \end{cases}$$

Portanto,

$$\mathbf{G}\mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j.$$

Considere, por fim,

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top).$$

Como $\mathbf{A}\mathbf{G}$ projeta sobre $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Além disso,

$$\mathbf{G}\mathbf{u} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \cap \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

segue que

$$\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Assim, $\mathbf{G}$ atua sobre a base ortonormal formada pelas colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ exatamente como

$$\mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Logo,

$$\mathbf{G} = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top = \mathbf{A}^+.$$

Portanto, a pseudoinversa de Moore–Penrose existe e é única. $\square$

6.7.3 Pseudoinversa e projetores

Os produtos

$$\mathbf{A}\mathbf{A}^+$$

e

$$\mathbf{A}^+ \mathbf{A}$$

possuem interpretações geométricas distintas.

Pela SVD,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})},$$

o projetor ortogonal sobre o espaço coluna de $\mathbf{A}$.

De modo semelhante,

$$\begin{aligned}\mathbf{A}^+\mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top.\end{aligned}$$

Logo,

$$\mathbf{A}^+\mathbf{A} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)},$$

o projetor ortogonal sobre o espaço linha de $\mathbf{A}$.

Os complementos são

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

A Tabela 6.4 resume essas relações.

Tabela 6.4: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A}\mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+\mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+\mathbf{A}$	$\mathcal{N}(\mathbf{A})$

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b},$$

em que

$$\mathbf{b} \in \mathbb{R}^q.$$

O sistema é compatível quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Como

$$\mathbf{A}\mathbf{A}^+$$

é o projetor sobre esse espaço,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se o sistema é compatível, então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

As demais soluções são obtidas acrescentando qualquer vetor do núcleo:

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{x}_{\mathcal{N}},$$

com

$$\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}).$$

Utilizando a base fornecida pela SVD,

$$\mathbf{x}_{\mathcal{N}} = \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Portanto, o conjunto de soluções pode ser escrito como

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma.$$

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução é única:

$$\mathbf{x} = \mathbf{A}^+ \mathbf{b}.$$

6.7.5 Solução de menor norma

Quando um sistema compatível possui várias soluções, a pseudoinversa seleciona a solução de menor norma euclidiana.

Teorema 6.10 (Solução compatível de menor norma). *Se*

$$\mathbf{Ax} = \mathbf{b}$$

é compatível, então

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a única solução de menor norma euclidiana. (Golub e Van Loan 2013)

Comprovação. Toda solução possui a forma

$$\mathbf{x} = \mathbf{A}^+ \mathbf{b} + \mathbf{x}_{\mathcal{N}},$$

com

$$\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}).$$

A pseudoinversa produz um vetor no espaço linha:

$$\mathbf{A}^+ \mathbf{b} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

tem-se

$$(\mathbf{A}^+\mathbf{b})^\top \mathbf{x}_{\mathcal{N}} = 0.$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{x}_{\mathcal{N}}\|^2.$$

Logo,

$$\|\mathbf{x}\| \geq \|\mathbf{A}^+\mathbf{b}\|,$$

com igualdade somente quando

$$\mathbf{x}_{\mathcal{N}} = \mathbf{0}.$$

Portanto,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de menor norma. □

6.7.6 Sistemas incompatíveis e mínimos quadrados

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

não possui solução exata.

Nesse caso, procura-se um vetor $\mathbf{x}$ que minimize a distância entre $\mathbf{Ax}$ e $\mathbf{b}$:

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Esse é o problema de **mínimos quadrados**.

Definição 6.10 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma solução de mínimos quadrados do sistema

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

O vetor ajustado é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna:

$$\hat{\mathbf{b}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} \mathbf{b}.$$

Pela pseudoinversa,

$$\hat{\mathbf{b}} = \mathbf{AA}^+ \mathbf{b}.$$

Uma solução de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b},$$

pois

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{AA}^+ \mathbf{b} = \hat{\mathbf{b}}.$$

6.7.7 Resíduo de mínimos quadrados

O vetor residual é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}}.$$

Substituindo a expressão do vetor ajustado,

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+) \mathbf{b}.$$

Como

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top),$$

tem-se

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Portanto,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Como

$$\mathbf{r} = \mathbf{b} - \mathbf{A}\hat{\mathbf{x}},$$

segue que

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}.$$

Reorganizando,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Essas são as **equações normais** do problema de mínimos quadrados.

A interpretação geométrica é:

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

As duas parcelas são ortogonais:

$$\hat{\mathbf{b}}^\top \mathbf{r} = 0.$$

Assim,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.8 Conjunto das soluções de mínimos quadrados

As equações normais podem possuir várias soluções quando $\mathbf{A}$ é deficiente em posto.

Teorema 6.11 (Soluções de mínimos quadrados pela SVD). *O conjunto de todas as soluções do problema*

$$\min_{\mathbf{x}} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2$$

é

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} + \mathbf{V}_0 \boldsymbol{\gamma},$$

em que

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Entre essas soluções,

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}$$

é a única de menor norma. (Golub e Van Loan 2013)

Comprovação. Todos os vetores da forma

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} + \mathbf{V}_0 \gamma$$

produzem o mesmo vetor ajustado, pois

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$

Assim,

$$\begin{aligned} \mathbf{A} \hat{\mathbf{x}} &= \mathbf{A} \mathbf{A}^+ \mathbf{b} + \mathbf{A} \mathbf{V}_0 \gamma \\ &= \mathbf{A} \mathbf{A}^+ \mathbf{b}. \end{aligned}$$

Logo, todos esses vetores minimizam o mesmo resíduo.

Reciprocamente, duas soluções de mínimos quadrados produzem o mesmo vetor ajustado, que é a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$. Portanto, a diferença entre elas pertence ao núcleo de $\mathbf{A}$ e pode ser escrita como

$$\mathbf{V}_0 \gamma.$$

A propriedade de menor norma segue da ortogonalidade entre

$$\mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathcal{N}(\mathbf{A}),$$

pelo mesmo argumento utilizado no caso compatível. □

Quando

$$r = p,$$

a matriz possui posto coluna completo e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. A pseudoinversa assume a forma

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Logo,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto linha completo,

$$r = q \leq p,$$

então

$$\mathbf{A} \mathbf{A}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{A} \mathbf{A}^\top)^{-1}.$$

Essa expressão fornece a solução de menor norma dos sistemas compatíveis subdeterminados.

6.7.9 Expressão espectral da solução

A pseudoinversa permite decompor a solução nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.10 Valores singulares pequenos e instabilidade

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned} \Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j. \end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Esse comportamento relaciona:

- valores singulares pequenos;
- número de condição elevado;
- sensibilidade a perturbações;
- instabilidade de soluções inversas.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.11 Pseudoinversa truncada

A SVD truncada sugere uma inversão aproximada que conserva somente os k maiores valores singulares:

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.12 Exemplo com o sistema condutor

Exemplo 6.7 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuando os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned} \hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\ &= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}. \end{aligned}$$

O vetor ajustado é

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\ &= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}. \end{aligned}$$

O resíduo é

$$\begin{aligned} \mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}. \end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão nas direções associadas a valores singulares positivos;
- projeção sobre os espaços fundamentais;
- solução de sistemas compatíveis;
- seleção da solução de menor norma;
- solução de mínimos quadrados para sistemas incompatíveis.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares representa qualquer matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

na forma

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

A SVD completa utiliza bases ortonormais de todo o domínio e de todo o contradomínio. A SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

conserva somente os r valores singulares positivos e reconstrói exatamente a matriz. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

produz uma aproximação de posto reduzido.

Os valores singulares são obtidos pelas decomposições espectrais

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

As duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes.

A interpretação geométrica mostra que a SVD transforma a bola unitária em um elipsoide. Suas direções principais são os vetores singulares à esquerda, e os comprimentos dos semieixos são os valores singulares. O maior valor singular satisfaz

$$\|\mathbf{A}\|_2 = d_1$$

e representa o maior fator de ampliação da transformação.

A SVD fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r), \quad \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0),$$

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r), \quad \mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

O posto é o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r.$$

A norma de Frobenius é

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Quando

$$r = \min(q, p),$$

o número de condição espectral é

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_{\min(q,p)}}.$$

Se o posto é menor que o máximo possível, adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

Para matrizes largas com posto linha completo, esse número descreve a ação da transformação no complemento ortogonal de seu núcleo.

Quando $\mathbf{X}$ é uma matriz de dados,

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

as coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Se $\mathbf{X}_c$ está centralizada,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto, os vetores singulares à direita são autovetores da matriz de covariâncias amostral, e seus autovalores positivos são $d_j^2/(n-1)$.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

decompõe a matriz em parcelas ortogonais de posto 1. Pelo Teorema de Eckart–Young–Mirsky, a SVD truncada fornece uma aproximação ótima:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r\mathbf{U}_r^\top$$

e

$$\mathbf{A}^+\mathbf{A} = \mathbf{V}_r\mathbf{V}_r^\top,$$

e fornece a solução de mínimos quadrados de menor norma:

$$\hat{\mathbf{x}}^* = \mathbf{A}^+\mathbf{b}.$$

A Tabela 6.5 reúne as relações principais.

Tabela 6.5: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Bases ortonormais completas
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata com valores positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Associação entre domínio e contradomínio
Matrizes de Gram	$\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$	Determinam d_j^2 e os vetores singulares
Posto	$r = \#\{j : d_j > 0\}$	Dimensão efetiva da transformação
Normas	$\ \mathbf{A}\ _2 = d_1$ e $\ \mathbf{A}\ _F^2 = \sum_j d_j^2$	Ampliação máxima e magnitude quadrática
Forma expandida	$\mathbf{A} = \sum_j d_j\mathbf{u}_j\mathbf{v}_j^\top$	Soma de parcelas de posto 1
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top$	Aproximação de posto reduzido
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r\mathbf{D}_r^{-1}\mathbf{U}_r^\top$	Inversão nas direções ativas
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+\mathbf{b}$	Solução de menor norma

Ao concluir o capítulo, o estudante deverá ser capaz de:

1. distinguir as formas completa, compacta e truncada da SVD;
2. obter valores e vetores singulares a partir das matrizes de Gram;
3. interpretar geometricamente os valores singulares;
4. identificar os quatro espaços fundamentais;

5. relacionar valores singulares a posto, normas e condicionamento;
6. construir aproximações de posto reduzido;
7. utilizar a pseudoinversa em sistemas lineares e mínimos quadrados.

O próximo capítulo desenvolve cálculo diferencial, integral e matricial aplicado à Estatística Multivariada. As normas, formas quadráticas, projeções e problemas de mínimos quadrados estudados até aqui serão retomados na formulação de gradientes, Hessianas, funções objetivo, condições de otimalidade e procedimentos de estimação.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2.$$

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{A}\mathbf{X}\mathbf{B}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Objeto diferencial
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

Função	Domínio	Contradomínio	Objeto diferencial
--------	---------	---------------	--------------------

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a dimensão do gradiente, da Jacobiana ou do operador diferencial.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{x}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em $\mathbf{x}$ quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \rightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \rightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa uma perturbação infinitesimal do argumento. O diferencial é linear em relação a essa perturbação.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em $\mathbf{x}$ quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana representam a mesma ideia em contradomínios diferentes. O gradiente representa a parte linear da variação de uma função escalar. A Jacobiana representa a parte linear da variação de uma função vetorial.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Teorema 7.1 (Direções de maior crescimento e redução). *Se*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior redução ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol 1969)

Comprovação. Pela desigualdade de Cauchy–Schwarz,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. A aplicação do mesmo argumento a $-\mathbf{u}$ fornece o resultado para a maior redução. $\square$

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação linear não indica crescimento ou redução local.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^{\top} \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

A matriz Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \cdots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

O vetor $\mathbf{b}$ altera a posição da imagem, mas não altera a transformação linear local.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.2 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_f(\mathbf{x}) = \mathbf{J}_h(\mathbf{g}(\mathbf{x})) \mathbf{J}_g(\mathbf{x}).$$

(Apostol 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem das matrizes acompanha a ordem inversa da aplicação das aproximações lineares: primeiro atua a Jacobiana de $\mathbf{g}$ e, depois, a Jacobiana de $\mathbf{h}$.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_g(\mathbf{x})^\top \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^\top \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_g(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função duas vezes diferenciável. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a curvatura da função na direção $\mathbf{u}$.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned} \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2. \end{aligned}$$

Ela é positiva para todo vetor não nulo. A curvatura é maior em direções com componente mais acentuada no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2}\right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned}
f(\mathbf{x}) &\approx \frac{3}{2} + \begin{bmatrix} 2 & 2 \end{bmatrix} \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\
&= \frac{3}{2} + 2(x_1 - 1) + 2\left(x_2 - \frac{1}{2}\right).
\end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.3 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned}
f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\
&\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2).
\end{aligned}$$

(Apostol 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned}
f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\
&\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0).
\end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a inclinação local;
- a Hessiana determina a curvatura local.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece e a forma quadrática associada à Hessiana passa a determinar o comportamento local dominante.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}}f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Todo ponto interior em que uma função diferenciável possui máximo ou mínimo local é estacionário. A recíproca não é necessariamente verdadeira: um ponto estacionário pode ser mínimo, máximo ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.4 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável e um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^$ é um mínimo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^$ é um máximo local estrito. Se a Hessiana é indefinida, então $\mathbf{x}^*$ é um ponto de sela. Se a Hessiana é semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol 1969)*

Comprovação. Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Se a Hessiana é positiva definida, a forma quadrática é positiva para todo $\mathbf{h} \neq \mathbf{0}$. Para perturbações suficientemente pequenas, o termo quadrático domina o restante, produzindo um mínimo local estrito.

O argumento é análogo para uma Hessiana negativa definida.

Se a Hessiana é indefinida, existem direções $\mathbf{u}_1$ e $\mathbf{u}_2$ tais que

$$\mathbf{u}_1^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{u}_1 > 0$$

e

$$\mathbf{u}_2^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{u}_2 < 0.$$

A função aumenta em algumas direções e diminui em outras. Portanto, o ponto é de sela. $\square$

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0,0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1 - t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, hiperplanos, bolas, regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.5 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd e Vandenberghe 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.6 (Critério da Hessiana para convexidade). *Considere uma função duas vezes continuamente diferenciável em um conjunto convexo aberto $\mathcal{C}$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é convexa.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0},$$

a função é côncava.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0},$$

a função é estritamente côncava. (Boyd e Vandenberghe 2004)

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

7.4.5 Consequências para otimização

Teorema 7.7 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa, esse mínimo global é único. (Boyd e Vandenberghe 2004)

Comprovação. Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$. □

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

Quando f é diferenciável, a condição de primeira ordem para um mínimo interior é

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Essa condição é necessária, mas não suficiente no caso geral.

Uma condição suficiente de segunda ordem é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Para funções convexas, a condição de gradiente nulo já é suficiente para um mínimo global (Boyd e Vandenberghe 2004).

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) \approx & f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^{\top} (\mathbf{x} - \mathbf{x}^{(t)}) \\ & + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^{\top} \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}) . \end{aligned}$$

O gradiente dessa aproximação em relação a $\mathbf{x}$ é

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}) .$$

Igualando a zero,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}) = -\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) .$$

Se a Hessiana é invertível, obtém-se a atualização

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) .$$

A direção de Newton é a solução do sistema linear

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \mathbf{d}^{(t)} = -\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) .$$

Na implementação computacional, é preferível resolver esse sistema sem calcular explicitamente a inversa da Hessiana.

O método depende de:

- existência das derivadas de segunda ordem;
- Hessiana invertível;
- escolha adequada do ponto inicial;
- comportamento local da função.

Longe da solução, uma etapa de Newton pode não reduzir a função. Métodos numéricos costumam combinar a direção de Newton com controle do comprimento da etapa (Boyd e Vandenberghe 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana positiva definida, Newton encontra o minimizador em uma única etapa, independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, os gradientes das restrições determinam as direções normais ao conjunto viável.

Uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_c(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

Em um ótimo restrito, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{d} = 0$$

para todo $\mathbf{d}$ tal que

$$\mathbf{J}_c(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

Isso implica que o gradiente da função objetivo pertence ao espaço gerado pelos gradientes das restrições.

7.6.1 Multiplicadores de Lagrange

Teorema 7.8 (Condição de Lagrange). *Considere um ponto $\mathbf{x}^*$ que é ótimo local do problema*

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_c(\mathbf{x}^*)$$

sejam linearmente independentes.

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol 1969)

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

As condições de primeira ordem são

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere

$$\max_{\mathbf{x}} \mathbf{a}^\top \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Escreva a restrição como

$$c(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} - 1 = 0.$$

A lagrangiana pode ser definida por

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^\top \mathbf{x} + \lambda (\mathbf{x}^\top \mathbf{x} - 1),$$

convertendo a maximização em minimização.

A condição em relação a $\mathbf{x}$ é

$$-\mathbf{a} + 2\lambda \mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}.$$

A restrição implica

$$\frac{\|\mathbf{a}\|^2}{4\lambda^2} = 1.$$

Para maximizar $\mathbf{a}^\top \mathbf{x}$, escolhe-se

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

O valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Esse resultado coincide com a igualdade na desigualdade de Cauchy–Schwarz.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

O problema de otimização conduz, portanto, a um problema de autovalores. O maior valor da função objetivo é o maior autovalor de $\mathbf{A}$.

Essa relação foi desenvolvida no capítulo de decomposição espectral. Aqui, ela mostra como os multiplicadores de Lagrange produzem a equação de autovalores a partir de uma restrição de norma.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que $\mathbf{A}$ é simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

A solução exige condições de posto e invertibilidade compatíveis com a matriz do sistema.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Formas quadráticas

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Teorema 7.9 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

Comprovação. Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana. □

Se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

7.7.3 Norma euclidiana

Como

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x},$$

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{A}\mathbf{x})^\top (\mathbf{b} - \mathbf{A}\mathbf{x}).$$

Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}). \end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

7.7.5 Equações normais

Uma solução de mínimos quadrados deve satisfazer

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{0}.$$

Logo,

$$\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}) = \mathbf{0},$$

ou

$$\mathbf{A}^\top \mathbf{A}\mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

Essas são as equações normais.

A condição também pode ser escrita como

$$\mathbf{A}^\top \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, no ponto de mínimo, o vetor residual é ortogonal ao espaço coluna de $\mathbf{A}$.

Quando $\mathbf{A}$ possui posto coluna completo, a solução é única:

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Quando $\mathbf{A}$ é deficiente em posto, as equações normais podem possuir várias soluções. A pseudoinversa fornece a solução de menor norma:

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}.$$

A geometria das soluções de mínimos quadrados e a construção pela SVD foram desenvolvidas no capítulo anterior.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos

$$\omega_1, \dots, \omega_q$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Quando Ω é simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^\top \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \Omega \mathbf{A})^{-1} \mathbf{A}^\top \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma função de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Teorema 7.10 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Comprovação. Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x}). \end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^{\top} + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana. □

O primeiro termo da Hessiana,

$$2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}),$$

é semidefinido positivo.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos, pode-se aproximar a Hessiana por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}).$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Defina o gradiente matricial por

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr} (\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço transforma expressões matriciais quadradas em escalares e permite realizar permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}} \phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Teorema 7.11 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}} \phi = \mathbf{A}.$$

(Magnus e Neudecker 2019)

Comprovação. O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}} \phi = \mathbf{A}.$$

□

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Norma de Frobenius

A norma de Frobenius satisfaz

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}\left[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}\right].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}\left[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}\right]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}} \phi = \mathbf{A} \mathbf{X} \Gamma + \mathbf{A}^\top \mathbf{X} \Gamma^\top.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A} \mathbf{X} \Gamma.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_1, \dots, \mathbf{x}_n,$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_j^\top \mathbf{A} \mathbf{x}_j.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_1, \dots, 2\mathbf{A}\mathbf{x}_n.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{XB}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{X} \mathbf{B} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Cada coluna de $\widehat{\mathbf{B}}$ corresponde ao ajuste de uma coluna de $\mathbf{Y}$ sobre a mesma matriz de delineamento $\mathbf{X}$.

Teorema 7.12 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{X}\mathbf{B}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa quando $\mathbf{X}$ possui posto coluna completo.

Comprovação. Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa. $\square$

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

A matriz Ω pondera as linhas da matriz de resíduos. A matriz Σ^{-1} pondera as combinações entre as colunas.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \text{tr} [(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B}].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{XB} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Nesse critério, a ponderação invertível entre as respostas altera o valor da função e sua geometria, mas não altera o ponto de mínimo em relação a $\mathbf{B}$. A ponderação das observações, por outro lado, modifica as equações normais e o estimador.

As próximas identidades tratam funções que envolvem inversas e determinantes. Esses objetos aparecem em critérios definidos sobre o conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

As matrizes inversas e os determinantes aparecem em transformações de coordenadas, funções de densidade e critérios de estimação. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Teorema 7.13 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus e Neudecker 2019)

Comprovação. Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

□

O sinal negativo indica que o aumento de uma matriz positiva definida em determinada direção produz redução de sua inversa na direção correspondente, segundo a ordem matricial apropriada.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Teorema 7.14 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus e Neudecker 2019)

Como

$$d \det(\mathbf{X}) = \operatorname{tr} \left[(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X} \right],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

Teorema 7.15 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

Comprovação. Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente. □

Para uma matriz invertível não necessariamente simétrica, a função

$$\log |\det(\mathbf{X})|$$

satisfaz

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}$$

em qualquer região em que o sinal do determinante permaneça constante.

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2 \phi = -\operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Como

$$\mathbf{X}^{-1/2} d\mathbf{X} \mathbf{X}^{-1/2}$$

é simétrica,

$$\begin{aligned} \text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}) &= \|\mathbf{X}^{-1/2} d\mathbf{X} \mathbf{X}^{-1/2}\|_F^2 \\ &\geq 0. \end{aligned}$$

Logo,

$$d^2\phi \leq 0.$$

Teorema 7.16 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas. (Boyd e Vandenberghe 2004)

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A} \mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A} \mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\operatorname{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \operatorname{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^{\top}\mathbf{X}^{-1}\mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \operatorname{tr}(\mathbf{X}^{-1}\mathbf{a}\mathbf{a}^{\top}).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{a}\mathbf{a}^{\top}\mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}}\phi = -(\mathbf{X}^{-1}\mathbf{a})(\mathbf{X}^{-1}\mathbf{a})^{\top}.$$

Essa matriz é semidefinida negativa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^{\top} \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}}\phi = 2\mathbf{X}^{-1}\mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{x}\mathbf{x}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere

$$L(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dL &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma} L = \frac{n}{2} \Sigma^{-1} - \frac{1}{2} \Sigma^{-1} \mathbf{G} \Sigma^{-1}.$$

A condição de primeira ordem é

$$n \Sigma^{-1} = \Sigma^{-1} \mathbf{G} \Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n \Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Teorema 7.17 (Minimização do critério de covariância). *Se*

$$\mathbf{G} \succ \mathbf{0},$$

a função

$$L(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Comprovação. Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\text{tr}(\Sigma^{-1} \mathbf{G}) = \text{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$L(\Sigma) = \frac{1}{2} [\text{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$L(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

$$z = n.$$

Portanto,

$$\mathbf{Z} = n\mathbf{I}_p.$$

Essa igualdade equivale a

$$\Sigma = \frac{1}{n}\mathbf{G}.$$

□

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido. Nesse caso, o critério não possui minimizador interior. É possível fazer alguns autovalores de Σ tenderem a zero em direções pertencentes ao núcleo de $\mathbf{G}$, fazendo o log-determinante tender a $-\infty$ sem aumento compensatório no termo de traço.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11}\mathbf{C} & \cdots & a_{1n}\mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{C} & \cdots & a_{mn}\mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus e Neudecker 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1) (\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Teorema 7.18 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus e Neudecker 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{AX}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{AX}\Gamma.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \Gamma.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\Gamma^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \Gamma^\top \otimes \mathbf{A}.$$

7.10.4 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr} (\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec} (\nabla_{\mathbf{X}} \phi)^\top d \text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec} (\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.5 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec} (\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned}\text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}).\end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

a Hessiana é semidefinida positiva e a função é convexa.

7.10.6 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{C}) = \text{vec}(\mathbf{A})^\top \text{vec}(\mathbf{C}),$$

tem-se

$$d\phi = \text{vec}(\nabla_{\mathbf{X}}\phi)^\top d\text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})}\phi = \text{vec}(\nabla_{\mathbf{X}}\phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.7 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = \frac{\partial \text{vec}(\nabla_{\mathbf{X}}\phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \mathbf{C}),$$

com $\mathbf{A}$ e $\mathbf{C}$ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\mathbf{C}.$$

Vetorizando,

$$\begin{aligned} \text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\mathbf{C}) \\ &= 2(\mathbf{C} \otimes \mathbf{A})\text{vec}(\mathbf{X}). \end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\mathbf{C} \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{C} \succeq \mathbf{0},$$

a Hessiana é semidefinida positiva e a função é convexa.

7.10.8 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^\top.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^\top$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.9 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz simétrica

$$\mathbf{S} = \mathbf{S}^\top \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{S}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior, incluindo a diagonal.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos.

7.10.10 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.11 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é definida por

$$\text{vech}(\mathbf{S}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S})$$

para toda matriz simétrica $\mathbf{S}$.

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}}$$

não é a identidade em $\mathbb{R}^{p^2}$, pois o produto atua sobre vetores que podem representar matrizes não simétricas.

7.10.12 Diferenciais de parâmetros simétricos

Se

$$\Sigma = \Sigma^\top$$

é um parâmetro matricial simétrico, então

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Considere uma função escalar

$$\phi(\Sigma)$$

com gradiente matricial

$$\nabla_\Sigma \phi.$$

Seu diferencial é

$$d\phi = \text{vec}(\nabla_\Sigma \phi)^\top d \text{vec}(\Sigma).$$

Substituindo a matriz de duplicação,

$$d\phi = \text{vec}(\nabla_\Sigma \phi)^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Portanto,

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^{\top} \text{vec}(\nabla_{\Sigma}\phi).$$

Essa expressão transforma o gradiente matricial em um gradiente relativo somente aos elementos distintos do parâmetro simétrico.

7.10.13 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^{\top} \mathbf{X} + \mathbf{X}^{\top} d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned}\text{vec}(d\mathbf{X}^\top \mathbf{X}) &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^\top) \\ &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}).\end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^\top d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^\top) \text{vec}(d\mathbf{X}).$$

Logo,

$$\begin{aligned}d \text{vec}(\mathbf{X}^\top \mathbf{X}) &= [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ &\quad \times d \text{vec}(\mathbf{X}).\end{aligned}$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças e distribuições marginais. Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.19 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.20 (Teorema de Fubini). *Se*

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então as integrais iteradas existem, são finitas e satisfazem

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) \, dx_1 \, dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) \, dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) \, dx_1 \right] dx_2. \end{aligned}$$

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório contínuo

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Uma função

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty)$$

é uma densidade conjunta quando

$$f_{\mathbf{X}}(\mathbf{x}) \geq 0$$

e

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x} = 1.$$

Para um conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

a probabilidade é

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

A densidade marginal de $\mathbf{X}_1$ é obtida integrando a densidade conjunta em relação às componentes de $\mathbf{X}_2$:

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2.$$

De modo semelhante,

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

A marginalização elimina as variáveis que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{X_1, X_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de X_1 é

$$\begin{aligned} f_{X_1}(x_1) &= \int_0^{x_1} 2 \, dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de X_2 é

$$\begin{aligned} f_{X_2}(x_2) &= \int_{x_2}^1 2 \, dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções vetoriais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.21 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

tem-se

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Teorema 7.22 (Densidade de uma transformação invertível). *Considere um vetor aleatório contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$ e a transformação*

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}),$$

satisfazendo as condições do Teorema da Mudança de Variáveis.

Então,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é injetiva em todo o domínio, o domínio deve ser particionado em regiões de injetividade. As contribuições das diferentes pré-imagens são somadas.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0.35x_1x_2 \\ x_2 + 0.20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0.35x_2 & 0.35x_1 \\ 0.40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0.35x_2 - 0.14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

O fator r representa o aumento da área dos setores à medida que a distância à origem cresce.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e uma transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned} \mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsóides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Diferenciação sob o sinal de integração

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.23 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.24 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. para todo $\theta \in \mathcal{V}$, a função

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. exista $\delta > 0$ tal que

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. para quase todo $\mathbf{x} \in \mathcal{D}$, a função

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. exista uma função integrável

$$M_j : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

para todo t com $|t| < \delta$ e quase todo $\mathbf{x} \in \mathcal{D}$;

5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Comprovação. Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \longmapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x}) \mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

$$\begin{aligned} \lim_{m \rightarrow \infty} \int_{\mathcal{D}} q_m(\mathbf{x}) \, d\mathbf{x} &= \int_{\mathcal{D}} \lim_{m \rightarrow \infty} q_m(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} \, d\mathbf{x}. \end{aligned}$$

Por outro lado,

$$\begin{aligned}\int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \frac{\int_{\mathcal{D}} h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) d\mathbf{x} - \int_{\mathcal{D}} h(\mathbf{x}, \theta_0) d\mathbf{x}}{t_m} \\ &= \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m}.\end{aligned}$$

Logo,

$$\lim_{m \rightarrow \infty} \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Como a sequência $t_m \rightarrow 0$ foi escolhida arbitrariamente, a derivada parcial existe e satisfaz a igualdade enunciada. $\square$

Quando as condições do Teorema 7.24 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.24 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned}\mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}.\end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

$$\mathbf{X}$$

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A diferenciação sob o sinal de integração conecta essas ferramentas às funções de verossimilhança, ao vetor escore e à informação de Fisher.

7.12 Aplicações à estimação e à inferência

As ferramentas de diferenciação permitem formular condições de estimação, construir aproximações locais e estudar transformações de estimadores. Nesta seção, essas aplicações serão apresentadas apenas em sua estrutura matemática.

7.12.1 Log-verossimilhança e vetor escore

Considere uma amostra

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

de uma distribuição com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros.

Sob independência, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.15 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Um estimador de máxima verossimilhança interior deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.16 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Quando

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

a Hessiana da log-verossimilhança é negativa definida no ponto estimado, fornecendo uma condição suficiente de máximo local estrito.

A informação observada pode ser singular ou apenas semidefinida quando:

- há parâmetros não identificados;
- existem redundâncias na parametrização;
- o máximo ocorre na fronteira;
- a log-verossimilhança apresenta pouca curvatura em determinadas direções.

Definição 7.17 (Informação de Fisher). A informação de Fisher é definida por

$$\mathcal{J}_n(\theta) = E_\theta [\mathcal{J}_n(\theta)],$$

quando essa esperança existe. (Casella e Berger 2002)

Sob condições que permitem diferenciar a densidade sob o sinal de integração,

$$E_\theta [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais de regularidade,

$$\mathcal{J}_n(\theta) = E_\theta [\mathbf{s}_n(\theta)\mathbf{s}_n(\theta)^\top].$$

Essa identidade não deve ser utilizada sem verificar as condições de regularidade e a independência do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_\theta^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_\theta^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = -\mathbf{s}_n(\theta^{(t)}),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada pela informação esperada:

$$\theta^{(t+1)} = \theta^{(t)} + \mathcal{J}_n \left(\theta^{(t)} \right)^{-1} \mathbf{s}_n \left(\theta^{(t)} \right).$$

Os dois métodos coincidem quando

$$\mathcal{J}_n(\theta) = \mathcal{J}_n(\theta)$$

ou quando essas matrizes produzem a mesma atualização.

7.12.5 Expansão local de um estimador

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n \left(\hat{\theta} \right) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned} \mathbf{0} &= \mathbf{s}_n \left(\hat{\theta} \right) \\ &\approx \mathbf{s}_n \left(\theta_0 \right) + \nabla_{\theta}^2 \ell_n \left(\theta_0 \right) \left(\hat{\theta} - \theta_0 \right). \end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n \left(\theta_0 \right) = -\mathcal{J}_n \left(\theta_0 \right),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.25 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função diferenciável

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart 1998)

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta) (\hat{\theta} - \theta).$$

A covariância aproximada é

$$\text{Cov} [\mathbf{g}(\hat{\theta})] \approx \frac{1}{n} \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}.$$

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância aproximada é

$$\text{Var} [g(\hat{\theta})] \approx \frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_1}{\theta_2^2} \\ -\frac{\theta_1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_2(\mathbf{0}, \Xi),$$

então

$$\sqrt{n} \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$$

converge em distribuição para uma normal com variância

$$\nabla_{\theta} g^{\top} \Xi \nabla_{\theta} g.$$

7.12.7 Estimação de um vetor de médias

Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

7.12.8 Critério do modelo linear multivariado

Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere

$$\begin{aligned} L(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} L = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{Y}.$$

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_{\mathcal{E}} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^{\top} (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$L(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_{\mathcal{E}}).$$

Se

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_{\mathcal{E}}.$$

A condição

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo. Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério não possui minimizador no interior do conjunto das matrizes positivas definidas.

A interpretação probabilística desse critério e as propriedades dos estimadores serão desenvolvidas nos capítulos de estimação e modelo linear multivariado.

7.13 Síntese do capítulo

O cálculo diferencial descreve a variação local de funções escalares, vetoriais e matriciais. Para uma função escalar de vetor, o gradiente determina a aproximação linear:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana representa a transformação linear local de uma função vetorial:

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|).$$

A Hessiana descreve a curvatura de uma função escalar. Em um ponto estacionário, sua definitude permite distinguir mínimos, máximos e pontos de sela. Para funções convexas, qualquer ponto estacionário é um mínimo global.

A diferenciação de funções de resíduos conduz às equações normais. Para

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{Ax}),$$

e a condição de primeira ordem é

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}.$$

O cálculo matricial organiza derivadas de funções cujos argumentos são matrizes. O gradiente matricial é definido por

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa representação permite diferenciar normas de Frobenius, funções de resíduos matriciais, produtos quadráticos, inversas, determinantes e log-determinantes.

A vetorização transforma uma matriz em um vetor e permite representar transformações matriciais por produtos de Kronecker:

$$\text{vec}(\mathbf{AX}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Para matrizes simétricas, o operador vech elimina elementos repetidos. As matrizes de duplicação e eliminação relacionam as parametrizações por vec e vech.

O cálculo integral fornece probabilidades, esperanças e distribuições marginais. A mudança de variáveis incorpora o fator

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|,$$

que representa a alteração local de volume produzida pela transformação.

Na estimação, o gradiente da log-verossimilhança define o vetor escore, enquanto sua Hessiana negativa define a informação observada. Expansões de Taylor sustentam métodos iterativos de estimação e aproximações como o método delta.

A Tabela 7.2 reúne algumas das identidades utilizadas ao longo do capítulo.

Tabela 7.2: Identidades selecionadas de cálculo vetorial e matricial.

Função	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \mathbf{\Gamma})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A} \mathbf{X} \mathbf{\Gamma} + \mathbf{A}^\top \mathbf{X} \mathbf{\Gamma}^\top$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} (d\mathbf{X}) \mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A} \mathbf{X}^{-1})$	$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-\top} \mathbf{A}^\top \mathbf{X}^{-\top}$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Ao final do capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- construir aproximações de Taylor de primeira e segunda ordens;
- classificar pontos estacionários por meio da Hessiana;
- reconhecer condições de convexidade e concavidade;
- formular condições de primeira ordem em problemas com e sem restrições;
- diferenciar formas quadráticas, critérios de resíduos e funções matriciais;
- utilizar diferenciais de inversas, determinantes e log-determinantes;
- aplicar vetorização, produto de Kronecker e meia vetorização;
- interpretar o determinante Jacobiano em mudanças de variáveis;
- reconhecer o papel do cálculo em problemas de estimação e inferência.

O próximo capítulo inicia o estudo probabilístico dos dados multivariados por meio das matrizes de covariâncias e correlações. Essas matrizes combinam expectativas, produtos cruzados, formas quadráticas e transformações lineares, reunindo os principais objetos desenvolvidos ao longo do Módulo 1.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Módulo 3 – Formulação Matemática e Estatística das Técnicas Multivariadas

8.1 Capítulo 13 – Problemas e estruturas das técnicas multivariadas

8.2 Capítulo 14 – Formulação da Análise de Componentes Principais

8.3 Capítulo 15 – Formulação da Análise Fatorial

8.4 Capítulo 16 – Formulação da Análise de Agrupamentos

8.5 Capítulo 17 – Formulação do Escalonamento Multidimensional

8.6 Capítulo 18 – Formulação da Análise de Correspondência

8.7 Capítulo 19 – Formulação da MANOVA

8.8 Capítulo 20 – Formulação da Análise Discriminante

8.9 Capítulo 21 – Formulação da Correlação Canônica

8.10 Capítulo 22 – Formulação da Análise Conjunta

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

9 Módulo 3 – Formulação Matemática e Estatística das Técnicas Multivariadas

9.1 Capítulo 13 – Problemas e estruturas das técnicas multivariadas

9.2 Capítulo 14 – Formulação da Análise de Componentes Principais

9.3 Capítulo 15 – Formulação da Análise Fatorial

9.4 Capítulo 16 – Formulação da Análise de Agrupamentos

9.5 Capítulo 17 – Formulação do Escalonamento Multidimensional

9.6 Capítulo 18 – Formulação da Análise de Correspondência

9.7 Capítulo 19 – Formulação da MANOVA

9.8 Capítulo 20 – Formulação da Análise Discriminante

9.9 Capítulo 21 – Formulação da Correlação Canônica

Capítulo 22 – Formulação da Análise Conjunta

Apostol, Tom M. 1969. *Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability*. 2^o ed. New York: John Wiley & Sons.

Axler, Sheldon. 2020. *Measure, Integration & Real Analysis*. Vol. 282. Graduate Texts em Mathematics. Cham: Springer. <https://doi.org/10.1007/978-3-030-33143-6>.

Boyd, Stephen, e Lieven Vandenberghe. 2004. *Convex Optimization*. Cambridge: Cambridge University Press. <https://web.stanford.edu/~boyd/cvxbook/>.

- Casella, George, e Roger L. Berger. 2002. *Statistical Inference*. 2^o ed. Pacific Grove, CA: Duxbury. https://books.google.com/books?id=0x_vAAAAMAAJ.
- Golub, Gene H., e Charles F. Van Loan. 2013. *Matrix Computations*. 4^o ed. Baltimore: Johns Hopkins University Press. <https://www.press.jhu.edu/books/title/10678/matrix-computations>.
- Harville, David A. 1997. *Matrix Algebra From a Statistician's Perspective*. New York: Springer. <https://doi.org/10.1007/b98818>.
- Horn, Roger A., e Charles R. Johnson. 1991. *Topics in Matrix Analysis*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/CBO9780511840371>.
- . 2013. *Matrix Analysis*. 2^o ed. Cambridge: Cambridge University Press. <https://doi.org/10.1017/CBO9781139020411>.
- Magnus, Jan R., e Heinz Neudecker. 2019. *Matrix Differential Calculus with Applications in Statistics and Econometrics*. 3^o ed. Chichester: John Wiley & Sons. <https://doi.org/10.1002/9781119541219>.
- Meyer, Carl D. 2023. *Matrix Analysis and Applied Linear Algebra*. 2^o ed. Philadelphia: Society for Industrial; Applied Mathematics. <https://doi.org/10.1137/1.9781611977448>.
- Strang, Gilbert. 2023. *Introduction to Linear Algebra*. 6^o ed. Wellesley, MA: Wellesley-Cambridge Press. <https://math.mit.edu/~gs/linearalgebra/ila6/indexila6.html>.
- Vaart, A. W. van der. 1998. *Asymptotic Statistics*. Cambridge: Cambridge University Press. <https://doi.org/10.1017/CBO9780511802256>.