

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	21
Direitos Autorais e Uso da Obra	21
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	21
Prefácio	22
Identificação da Disciplina	24
EMENTA	24
OBJETIVO GERAL	24
OBJETIVOS ESPECÍFICOS	24
CONTEÚDO PROGRAMÁTICO	25
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	25
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	25
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	25
METODOLOGIA	26
AVALIAÇÃO	26
CRITÉRIOS DE AVALIAÇÃO	26
BIBLIOGRAFIA BÁSICA	27
BIBLIOGRAFIA COMPLEMENTAR	27
 I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multi-	 28
variada	
 1 Vetores e representação dos dados multivariados	 29
1.1 Escalares, vetores e matrizes	30
1.1.1 Vetor-coluna, vetor-linha e transposição	33
1.2 Natureza das variáveis e representação	34
1.3 O espaço $\mathbb{R}^p$	35
1.4 Representação matricial de um conjunto de dados	38
1.4.1 Espaço das observações e espaço das variáveis	40
1.5 Operações elementares com vetores	41
1.5.1 Soma e subtração	41
1.5.2 Multiplicação por escalar	42
1.5.3 Combinações lineares	44

1.6	Produto interno, norma, ângulo e distância euclidiana	46
1.6.1	Produto interno euclidiano	46
1.6.2	Norma euclidiana	47
1.6.3	Desigualdade de Cauchy–Schwarz	48
1.6.4	Ângulo entre vetores	51
1.6.5	Distância euclidiana	53
1.6.6	Desigualdade triangular	55
1.6.7	Produto externo	56
1.7	Síntese do capítulo	58
2	Álgebra matricial aplicada	60
2.1	Operações matriciais fundamentais	61
2.1.1	Soma e subtração de matrizes	61
2.1.2	Produto matriz-vetor	64
2.1.3	Produto entre matrizes	67
2.1.4	Propriedades do produto matricial	72
2.2	Transposição, simetria e traço	73
2.2.1	Transposição	73
2.2.2	Matrizes simétricas	75
2.2.3	Traço	79
2.3	Identidade, inversa, determinante, posto e sistemas lineares	83
2.3.1	Matriz identidade	83
2.3.2	Matriz inversa	84
2.3.3	Determinante	87
2.3.4	Interpretação geométrica do determinante	91
2.3.5	Posto	92
2.3.6	Sistemas lineares	95
2.3.7	Aprofundamento: pseudoinversa	99
2.4	Matrizes ortogonais, diagonais e triangulares	101
2.4.1	Matrizes ortogonais	101
2.4.2	Matrizes diagonais	104
2.4.3	Matrizes triangulares	106
2.4.4	Aprofundamento: sistemas triangulares	108
2.5	Formas bilineares, formas quadráticas e positividade	110
2.5.1	Formas bilineares	110
2.5.2	Formas quadráticas	114
2.5.3	Positividade	121
2.5.4	Superfícies de nível	127
2.6	Aprofundamento: matrizes particionadas e complemento de Schur	128
2.6.1	Matrizes particionadas	128
2.6.2	Soma e multiplicação por escalar	130
2.6.3	Transposição por blocos	130
2.6.4	Multiplicação por blocos	131

2.6.5	Complemento de Schur	133
2.6.6	Eliminação por blocos	134
2.6.7	Determinante de uma matriz particionada	136
2.6.8	Inversão em blocos	137
2.6.9	Positividade e complemento de Schur	138
2.7	Síntese do capítulo	141
3	Espaços vetoriais, bases e projeções	144
3.1	Espaços, subespaços e geração	145
3.1.1	Subespaços vetoriais	147
3.1.2	Subespaço gerado	149
3.2	Independência linear, bases e dimensão	152
3.2.1	Independência linear	152
3.2.2	Independência linear e posto	154
3.2.3	Bases	156
3.2.4	Coordenadas em uma base	157
3.2.5	Base canônica	159
3.2.6	Bases ortogonais e ortonormais	160
3.2.7	Dimensão	163
3.3	Espaços fundamentais de uma matriz	165
3.3.1	Espaço nulo	165
3.3.2	Espaço coluna	168
3.3.3	Espaço linha	171
3.3.4	Espaço nulo à esquerda	172
3.3.5	Extensão de uma base	174
3.3.6	Teorema Posto–Nulidade	175
3.3.7	Os quatro espaços fundamentais	179
3.3.8	Complemento ortogonal	179
3.3.9	Relações de ortogonalidade	180
3.4	Produtos internos, bases ortonormais e matrizes de Gram	182
3.4.1	Aprofundamento: produtos internos e geometrias induzidas	182
3.4.2	Matrizes de Gram	187
3.4.3	Propriedades da matriz de Gram	189
3.4.4	Matrizes de Gram e bases ortonormais	191
3.4.5	Produtos cruzados em uma matriz de dados	192
3.4.6	Propriedades do complemento ortogonal	193
3.4.7	Dimensão do complemento ortogonal	195
3.4.8	Decomposição ortogonal	198
3.4.9	Decomposição dos espaços fundamentais	200
3.5	Projeções ortogonais	201
3.5.1	Projeção sobre uma direção	202
3.5.2	Projeção sobre um subespaço com base ortonormal	207
3.5.3	Projeção sobre o espaço coluna de uma matriz	210

3.5.4	Propriedades da matriz de projeção	214
3.5.5	Aprofundamento: projeção residual e complemento ortogonal	218
3.5.6	Projeção como melhor aproximação	223
3.5.7	Aprofundamento: projeções e mínimos quadrados	226
3.6	Síntese do capítulo	230
4	Transformações lineares	233
4.1	Transformações lineares e representação matricial	234
4.1.1	Transformação determinada por uma base	236
4.1.2	Representação matricial nas bases canônicas	238
4.1.3	Núcleo e imagem de uma transformação linear	240
4.1.4	Imagem de um subespaço	241
4.2	Transformação de vetores e matrizes de dados	242
4.2.1	Novas variáveis como combinações lineares	244
4.2.2	Dimensão da configuração transformada	246
4.2.3	Efeito sobre diferenças e produtos internos	250
4.2.4	Transformação das matrizes de produtos internos	251
4.3	Composição, invertibilidade e perda de informação	252
4.3.1	Composição de transformações lineares	253
4.3.2	A ordem das transformações	254
4.3.3	Transformação inversa	257
4.3.4	Injetividade, sobrejetividade e bijetividade	258
4.3.5	Perda de informação	263
4.3.6	Redução de dimensionalidade	264
4.3.7	Transformações singulares	265
4.4	Transformações geométricas	266
4.4.1	Rotação	267
4.4.2	Reflexão	268
4.4.3	Escalonamento	270
4.4.4	Cisalhamento	271
4.4.5	Projeção	273
4.4.6	Comparação geométrica	274
4.4.7	Determinante, volume e orientação	275
4.5	Transformações ortogonais	277
4.5.1	Transformação de uma matriz de dados	279
4.5.2	Determinante e orientação	280
4.5.3	Matrizes ortogonais e bases ortonormais	281
4.5.4	Comparação com transformações não ortogonais	282
4.6	Mudanças de coordenadas e representação em bases	284
4.6.1	Conversão entre duas bases	286
4.6.2	Representação de uma transformação em bases gerais	287
4.6.3	Representação de um operador em uma nova base	290
4.6.4	Transformação ativa e mudança passiva	292

4.6.5	Mudança de coordenadas de uma matriz de dados	293
4.7	Transformações afins e pré-processamento	294
4.7.1	Translação	296
4.7.2	Transformação afim de uma matriz de dados	296
4.7.3	Centralização	297
4.7.4	Escalonamento das variáveis	301
4.7.5	Padronização	302
4.7.6	Ordem entre centralização e escalonamento	303
4.7.7	Composição e inversão de transformações afins	304
4.7.8	Comparação das operações de pré-processamento	306
4.8	Síntese do capítulo	306
5	Autovalores, autovetores e decomposição espectral	314
5.1	Direções invariantes, autovalores e autoespaços	315
5.2	Equação característica, multiplicidades e diagonalização	324
5.2.1	Determinação dos autovalores e autoespaços	326
5.2.2	Autovalores complexos de matrizes reais	328
5.2.3	Independência entre autovetores	329
5.2.4	Multiplicidades algébrica e geométrica	331
5.2.5	Diagonalização	336
5.2.6	Potências de uma matriz diagonalizável	339
5.3	Matrizes simétricas e decomposição espectral	340
5.3.1	Decomposição espectral do exemplo condutor	346
5.3.2	Forma aditiva da decomposição espectral	348
5.3.3	Projetores sobre autoespaços	349
5.3.4	Não unicidade da matriz de autovetores	351
5.4	Consequências da decomposição espectral	352
5.4.1	Traço, determinante, posto e invertibilidade	352
5.4.2	Formas quadráticas em coordenadas espectrais	356
5.4.3	Superfícies de nível em coordenadas espectrais	361
5.5	Quociente de Rayleigh	364
5.5.1	Representação espectral	365
5.5.2	Formulação com restrição de norma	371
5.5.3	Multiplicadores de Lagrange	372
5.5.4	Direções sucessivas	377
5.6	Funções espectrais de matrizes	381
5.6.1	Ação sobre os autoespaços	382
5.6.2	Potências inteiras	383
5.6.3	Inversa espectral	384
5.6.4	Raiz quadrada principal	385
5.6.5	Raiz quadrada inversa	386
5.6.6	Pseudoinversa espectral	387
5.6.7	Exponencial e logaritmo matriciais	389

5.7	Aprofundamento: autovalores generalizados	390
5.7.1	Quociente de Rayleigh generalizado	393
5.7.2	Redução a um problema espectral ordinário	396
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	399
5.7.4	Diagonalização simultânea por congruência	401
5.8	Síntese do capítulo	407
6	Decomposição em Valores Singulares	413
6.1	Definição e formas da Decomposição em Valores Singulares	414
6.1.1	Vetores singulares	418
6.1.2	Interpretação como composição de transformações	420
6.1.3	SVD completa	421
6.1.4	SVD compacta	422
6.1.5	SVD compacta e SVD truncada	423
6.1.6	Aprofundamento: não unicidade dos vetores singulares	429
6.2	Construção da SVD e relação com a decomposição espectral	431
6.2.1	Propriedades das matrizes de Gram associadas	432
6.2.2	Construção dos pares singulares	437
6.2.3	Construção da SVD compacta	442
6.2.4	Decomposições espectrais associadas	446
6.2.5	Exemplo de construção da SVD	448
6.2.6	Relação com a decomposição espectral de matrizes simétricas	451
6.2.7	Aprofundamento: SVD de matrizes simétricas indefinidas	452
6.3	Interpretação geométrica da SVD	453
6.3.1	Imagem da bola unitária	455
6.3.2	Alteração dos comprimentos	458
6.3.3	Exemplo geométrico no plano	463
6.3.4	Transformações com núcleo não trivial	464
6.4	Espaços fundamentais, posto e normas	466
6.4.1	Espaço coluna e espaço linha	467
6.4.2	Projetores ortogonais	471
6.4.3	Posto e nulidades	475
6.4.4	Produto interno de Frobenius	476
6.4.5	Normas e valores singulares	478
6.4.6	Invariância ortogonal	480
6.4.7	Determinante e invertibilidade	481
6.4.8	Aprofundamento: condicionamento e posto numérico	482
6.5	SVD de uma matriz de dados	488
6.5.1	Dualidade entre observações e variáveis	489
6.5.2	Coordenadas das observações nas direções singulares à direita	490
6.5.3	Coordenadas das variáveis nas direções singulares à esquerda	492
6.5.4	Matrizes de Gram da matriz de dados	493
6.5.5	Representação exata das observações	494

6.5.6	Centralização da matriz de dados	497
6.5.7	Antecipação: relação com a matriz de covariâncias amostral	498
6.5.8	Magnitude quadrática da matriz centralizada	500
6.5.9	Representação exata e aproximação	503
6.6	Forma expandida e aproximações de posto reduzido	504
6.6.1	Ortogonalidade dos componentes singulares	506
6.6.2	SVD truncada na forma expandida	508
6.6.3	Erros produzidos pelo truncamento	509
6.6.4	Teorema de Eckart–Young–Mirsky	512
6.6.5	Aprofundamento: demonstração e unicidade da melhor aproximação . .	513
6.6.6	Exemplo de aproximação de posto 1	520
6.6.7	Aproximação de uma matriz de dados	522
6.7	Pseudoinversa e soluções de mínimos quadrados	525
6.7.1	Relação com a pseudoinversa espectral	527
6.7.2	Aprofundamento: caracterização de Moore–Penrose	528
6.7.3	Pseudoinversa e projetores	534
6.7.4	Sistemas lineares compatíveis	536
6.7.5	Mínimos quadrados	539
6.7.6	Expressão da solução nas direções singulares	546
6.7.7	Aprofundamento: instabilidade e pseudoinversa truncada	547
6.7.8	Exemplo com o sistema condutor	550
6.8	Síntese do capítulo	552
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	561
7.1	Funções, variações e diferenciais	561
7.1.1	Tipos de funções	561
7.1.2	Convenções de derivação	564
7.1.3	Variação de uma função	565
7.1.4	Diferencial	567
7.1.5	Aproximação ao longo de uma direção	569
7.1.6	Diferenciabilidade de funções vetoriais	569
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	572
7.2.1	Gradiente e derivada direcional	572
7.2.2	Gradiente e conjuntos de nível	575
7.2.3	Jacobiana	578
7.2.4	Regra da cadeia	580
7.2.5	Hessiana	582
7.3	Aproximações de Taylor e classificação local	584
7.3.1	Aproximação de Taylor de primeira ordem	584
7.3.2	Aproximação de Taylor de segunda ordem	586
7.3.3	Pontos estacionários	587
7.3.4	Classificação pela Hessiana	589
7.3.5	Caso inconclusivo	592

7.4	Convexidade e concavidade	593
7.4.1	Conjuntos convexos	593
7.4.2	Funções convexas	594
7.4.3	Caracterização de primeira ordem	595
7.4.4	Caracterização pela Hessiana	595
7.4.5	Consequências para otimização	598
7.4.6	Funções quadráticas	599
7.5	Otimização sem restrições	601
7.5.1	Método de Newton	601
7.6	Otimização com restrições de igualdade	605
7.6.1	Multiplicadores de Lagrange	606
7.6.2	Relação com problemas de autovalores	612
7.6.3	Restrições lineares	613
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	615
7.7.1	Formas lineares e bilineares	615
7.7.2	Derivadas de formas quadráticas	616
7.7.3	Derivadas da norma euclidiana	619
7.7.4	Funções de resíduos lineares	619
7.7.5	Equações normais	621
7.7.6	Mínimos quadrados ponderados	624
7.7.7	Funções compostas de resíduos	626
7.7.8	Mínimos quadrados não lineares	627
7.8	Diferenciais matriciais e cálculo por traços	629
7.8.1	Regras básicas do diferencial matricial	630
7.8.2	Identities de traço	631
7.8.3	Função linear de uma matriz	632
7.8.4	Derivadas da norma de Frobenius	633
7.8.5	Funções quadráticas de uma matriz	634
7.8.6	Funções matriciais de resíduos	636
7.8.7	Ponderação de observações e respostas	640
7.9	Derivadas de inversas, determinantes e log-determinantes	642
7.9.1	Diferencial da matriz inversa	642
7.9.2	Diferencial do determinante	644
7.9.3	Diferencial do log-determinante	646
7.9.4	Segunda variação do log-determinante	647
7.9.5	Traço envolvendo uma matriz inversa	649
7.9.6	Forma quadrática com matriz inversa	650
7.9.7	Crítério com log-determinante e traço	651
7.9.8	Parâmetros matriciais simétricos	655
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	655
7.10.1	Operador de vetorização	656
7.10.2	Produto de Kronecker	657
7.10.3	Identidade de vetorização	659

7.10.4	Aprofundamento: derivadas vetorizadas e parâmetros matriciais	660
7.11	Integração múltipla e mudança de variáveis	673
7.11.1	Integrais múltiplas	673
7.11.2	Teoremas de Tonelli e Fubini	674
7.11.3	Densidades multivariadas	676
7.11.4	Distribuições marginais	677
7.11.5	Esperanças de funções escalares, vetoriais e matriciais	679
7.11.6	Mudança de variáveis	680
7.11.7	Transformação de densidades	682
7.11.8	Transformações afins	683
7.11.9	Interpretação geométrica do determinante Jacobiano	685
7.11.10	Coordenadas polares	686
7.11.11	Transformações elipsoidais	687
7.11.12	Aprofundamento: diferenciação sob o sinal de integração	688
7.12	Aprofundamento: aplicações à estimação e à inferência	695
7.12.1	Log-verossimilhança e vetor escore	695
7.12.2	Informação observada e informação de Fisher	696
7.12.3	Newton–Raphson	698
7.12.4	Método do escore de Fisher	699
7.12.5	Expansão local de uma raiz do escore	701
7.12.6	Método delta	702
7.13	Síntese do capítulo	708
Exercícios de fixação do Módulo I		711
Parte I — Exercícios sem uso de computador		711
Parte II — Exercícios com uso do R		727
 II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Mul-		
tivariada		737
8	Matrizes de covariâncias e correlações	738
8.1	Momentos, centralização e covariância	739
8.1.1	Vetor de médias e centralização	739
8.1.2	Momentos de segunda ordem	740
8.1.3	Covariância entre duas variáveis	742
8.2	Matriz de covariâncias populacional	747
8.2.1	Definição e interpretação dos elementos	747
8.2.2	Variâncias e covariâncias de combinações lineares	748
8.2.3	Propriedades estruturais e singularidade	751
8.3	Covariâncias entre vetores e transformações	757
8.3.1	Covariâncias cruzadas e vetores particionados	757
8.3.2	Transformações afins da média e da covariância	763

8.4	Padronização e matriz de correlações	767
8.4.1	Matriz de correlações populacional	767
8.4.2	Propriedades, escala e independência	772
8.5	Geometria e medidas globais da dispersão	778
8.5.1	Eixos espectrais e elipsoide de covariância	778
8.5.2	Variância total, variância generalizada e volume	785
8.6	Distância de Mahalanobis	791
8.6.1	Interpretação geométrica e espectral	792
8.6.2	Branqueamento e esferização	795
8.7	Representação descritiva a partir dos dados	800
8.7.1	Centralização, SQPC e matriz de covariâncias observada	800
8.7.2	Matriz de correlações e covariâncias cruzadas observadas	804
8.8	Decomposição da dispersão por grupos	810
8.8.1	Dispersão total, intragrupos e entre grupos	812
8.8.2	Somas de quadrados e traço das matrizes de dispersão	818
8.8.3	Esperança das matrizes de dispersão por grupos	821
8.8.4	Propriedades e limites de posto	826
8.9	Síntese do capítulo	829
9	Distribuição Normal Multivariada	835
9.1	Definição e construção	836
9.1.1	Definição por combinações lineares	836
9.1.2	Construção afim a partir do vetor normal padrão	838
9.1.3	Determinação pelos parâmetros	841
9.2	Densidade da normal multivariada	844
9.2.1	Função densidade e log-densidade	844
9.2.2	Superfícies de igual densidade	847
9.3	Transformações e distribuições marginais	849
9.3.1	Fechamento sob transformações afins	849
9.3.2	Combinações lineares	851
9.3.3	Distribuições marginais	853
9.3.4	Padronização marginal e branqueamento	855
9.4	Independência e distribuições condicionais	857
9.4.1	Independência entre blocos conjuntamente normais	857
9.4.2	Distribuição condicional	860
9.4.3	Média e covariância condicionais	864
9.4.4	Caso bivariado	866
9.5	Distância de Mahalanobis e regiões de probabilidade	869
9.5.1	Distribuição qui-quadrado	869
9.5.2	Regiões elipsoidais de probabilidade	871
9.5.3	Avaliação de uma observação fixa	873
9.6	Comparação entre distribuições normais	875
9.6.1	Médias distintas e covariância comum	876

9.6.2	Covariâncias distintas	877
9.7	Alcance da hipótese de normalidade	879
9.7.1	Resultados que não exigem normalidade	879
9.7.2	Resultados específicos da família normal	880
9.7.3	Passagem do modelo populacional para a inferência	881
9.8	Aprofundamento: Normal Singular	882
9.9	Síntese do capítulo	891
10	Estatísticas Amostrais e Estimação	894
10.1	Da população à amostra	895
10.1.1	Amostra aleatória multivariada	896
10.1.2	Matriz aleatória da amostra e matriz observada	898
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	899
10.2	Propriedades dos estimadores multivariados	902
10.2.1	Viés e variabilidade	903
10.2.2	Erro quadrático médio e funções de perda	904
10.2.3	Consistência	906
10.2.4	Eficiência	907
10.2.5	Suficiência	908
10.2.6	Equivariância	912
10.3	Métodos de estimação	915
10.3.1	Método dos momentos	915
10.3.2	Verossimilhança e máxima verossimilhança	918
10.3.3	Invariância da máxima verossimilhança	926
10.4	Estimação do vetor de médias	929
10.4.1	Vetor de médias amostrais	930
10.4.2	Não viesamento, variabilidade e erro quadrático médio	932
10.4.3	Combinações lineares	934
10.4.4	Consistência e equivariância	936
10.4.5	Variabilidade entre amostras	938
10.5	SQPC e estimação da matriz de covariâncias	939
10.5.1	SQPC como estatística aleatória	939
10.5.2	Decomposição em torno de um centro arbitrário	941
10.5.3	Esperança da SQPC	942
10.5.4	Estimador não viesado da matriz de covariâncias	944
10.5.5	Estimador com divisor n : momentos e máxima verossimilhança	946
10.5.6	Consistência dos estimadores de covariância	948
10.5.7	Transformações, posto e singularidade	950
10.6	Estimação de covariâncias cruzadas e correlações	954
10.6.1	Covariâncias cruzadas entre blocos	954
10.6.2	Matriz de correlações amostral	960
10.6.3	Propriedades estruturais	961
10.6.4	Transformações de localização e escala	965

10.7	Aprofundamento: dimensão, estabilidade e extensões da estimação	967
10.7.1	Relação entre p e n	968
10.7.2	Condicionamento e inversão	970
10.7.3	Regularização	972
10.7.4	Pseudoinversa e regularização	977
10.7.5	Sensibilidade e robustez	978
10.8	Exemplo integrado	979
10.9	Síntese do capítulo	987
11	Modelo Linear Multivariado e Hipóteses Lineares	991
11.1	Formulação do modelo linear multivariado	992
11.1.1	Resposta vetorial e matriz de respostas	992
11.1.2	Estrutura matricial do modelo	995
11.1.3	Estrutura de médias e covariâncias residuais	996
11.1.4	Forma vetorizada	997
11.1.5	Distribuição normal matricial	998
11.1.6	Transformações da resposta	1001
11.2	Estimação da matriz de parâmetros	1002
11.2.1	Mínimos quadrados	1002
11.2.2	Estimador sob posto completo	1003
11.2.3	Esperança e matriz de covariâncias	1005
11.2.4	Relação com máxima verossimilhança	1007
11.2.5	Modelo contendo somente intercepto	1008
11.3	Valores ajustados, resíduos e projeções	1010
11.3.1	Valores ajustados e resíduos	1011
11.3.2	Ortogonalidade	1012
11.3.3	Esperança dos valores ajustados e dos resíduos	1013
11.3.4	Covariâncias dos valores ajustados e dos resíduos	1014
11.3.5	Representação dos ajustes e resíduos	1015
11.3.6	Conexão com o modelo contendo somente intercepto	1016
11.4	SQPC residual e estimação da covariância	1017
11.4.1	Construção da SQPC residual	1018
11.4.2	Esperança e graus de liberdade	1020
11.4.3	Estimação da covariância residual	1023
11.4.4	Estimador de máxima verossimilhança	1025
11.4.5	Posto e singularidade	1026
11.4.6	Modelo contendo somente intercepto	1028
11.5	Decomposição da variação multivariada	1030
11.5.1	SQPC total	1030
11.5.2	SQPC associada ao modelo	1031
11.5.3	Decomposição entre modelo e resíduo	1033
11.5.4	Combinações lineares das respostas	1035
11.5.5	Modelos sem intercepto	1036

11.5.6	Modelo de grupos como caso particular	1037
11.6	Posto, parametrização e estimabilidade	1040
11.6.1	Delineamento com posto deficiente	1040
11.6.2	Pseudoinversa e unicidade do ajuste	1041
11.6.3	Funções estimáveis	1042
11.6.4	Estimador de uma função estimável	1045
11.6.5	Parametrizações equivalentes	1045
11.7	Hipóteses lineares multivariadas	1046
11.7.1	Combinações dos termos do modelo	1046
11.7.2	Combinações das respostas	1048
11.7.3	Hipótese linear geral	1049
11.7.4	Estimabilidade da hipótese	1050
11.7.5	SQPC da hipótese	1051
11.7.6	Modelos encaixados	1054
11.7.7	Casos particulares	1056
11.8	Exemplo integrado	1058
11.9	Síntese do capítulo	1067
12	Inferência Multivariada	1072
12.1	Distribuições amostrais exatas e assintóticas	1073
12.1.1	Distribuição da média amostral sob normalidade	1073
12.1.2	Teorema Central do Limite multivariado	1076
12.2	Distribuição de Wishart	1078
12.2.1	Construção e parametrização	1079
12.2.2	Suporte, posto e definição positiva	1081
12.2.3	Momentos	1082
12.2.4	Formas quadráticas	1084
12.2.5	Aditividade	1085
12.2.6	Transformações lineares	1085
12.2.7	Aprofundamento: densidade da distribuição de Wishart	1087
12.2.8	Distribuição da SQPC e da covariância amostral	1088
12.2.9	Independência entre média e covariância	1093
12.3	Distribuições no modelo linear multivariado	1095
12.3.1	Distribuição do estimador da matriz de parâmetros	1096
12.3.2	Distribuição de funções estimáveis	1098
12.3.3	Distribuição da SQPC residual	1100
12.3.4	Independência entre estimação e SQPC residual	1102
12.3.5	Distribuição da SQPC da hipótese sob H_0	1104
12.4	Princípios da inferência multivariada	1108
12.4.1	Testes globais e hipóteses simultâneas	1109
12.4.2	Razão de verossimilhanças	1110
12.4.3	Resultado assintótico de Wilks	1112
12.4.4	Razão de verossimilhanças em modelos normais encaixados	1114

12.5	Inferência sobre um vetor de médias	1117
12.5.1	Covariância conhecida	1118
12.5.2	Estatística T^2 de Hotelling	1120
12.5.3	Relações com os casos assintótico e univariado	1123
12.5.4	Região de confiança elipsoidal	1124
12.5.5	Geometria da região	1125
12.5.6	Intervalos simultâneos	1126
12.5.7	Hipóteses lineares sobre o vetor de médias	1128
12.5.8	Relação com o modelo linear multivariado	1132
12.6	Comparação entre dois vetores de médias	1133
12.6.1	Duas amostras independentes	1134
12.6.2	Covariâncias populacionais distintas	1141
12.6.3	Observações pareadas	1142
12.7	Condições e limites da inferência clássica	1147
12.7.1	Independência, normalidade e covariância comum	1147
12.7.2	Posto, dimensão e tamanho amostral	1150
12.7.3	Aprofundamento: alta dimensão e robustez	1153
12.8	Síntese do Módulo 2	1156
12.8.1	Passagem para o Módulo 3	1158
Exercícios de fixação do Módulo II		1159
Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador		1160
Parte II — Exercícios com uso do R		1170
 III Módulo III — Formulação Matemática e Estatística das Técnicas Multi-variadas		 1175
13 Problemas e estruturas das técnicas multivariadas		1176
13.1	Do problema estatístico à técnica multivariada	1177
13.2	Classes de problemas multivariados	1179
13.2.1	Redução de dimensionalidade	1179
13.2.2	Representação de estruturas latentes	1179
13.2.3	Formação de grupos	1180
13.2.4	Representação de associações em tabelas de contingência	1180
13.2.5	Comparação de vetores de médias	1180
13.2.6	Discriminação e classificação	1181
13.3	Diferentes formas de classificar as técnicas	1181
13.3.1	Interdependência e dependência	1181
13.3.2	Exploratórias, descritivas, preditivas e inferenciais	1181
13.3.3	Supervisionadas e não supervisionadas	1182

13.4	Estruturas matemáticas recorrentes	1183
13.4.1	Combinações lineares e projeções	1183
13.4.2	Formas quadráticas e problemas espectrais	1183
13.4.3	Otimização sob restrições e critérios de ajuste	1184
13.4.4	SVD e representações de baixa dimensão	1185
13.4.5	Distâncias e métricas	1185
13.4.6	Modelos lineares e probabilísticos	1185
13.5	Mesmas estruturas, diferentes interpretações	1187
13.6	Relações entre as técnicas	1188
13.7	Síntese	1189
14	Formulação da Análise de Componentes Principais	1191
14.1	O problema de redução de dimensionalidade	1191
14.2	Componentes principais como combinações lineares	1194
14.3	Primeira componente principal	1195
14.4	Componentes principais sucessivas	1197
14.5	Formulação espectral	1199
14.6	Variância total e proporção de variância	1200
14.7	Subespaço principal, projeção e reconstrução	1204
14.8	Formulação amostral	1205
14.9	Formulação da ACP pela SVD	1208
14.10	ACP baseada na matriz de correlações	1210
14.11	Formulação descritiva, populacional e inferencial	1213
14.12	Limites da representação por componentes principais	1215
14.13	Aprofundamentos teóricos	1215
14.13.1	Formulação do subespaço principal e variabilidade máxima	1216
14.13.2	Reconstrução e erro quadrático	1222
14.13.3	Geometria da qualidade de representação	1226
14.13.4	Aproximação de posto reduzido	1230
14.13.5	Propriedades da solução	1233
14.13.6	Estimação e inferência das componentes sob normalidade	1237
14.14	Aprofundamentos metodológicos e aplicados	1239
14.14.1	Escolha do número de componentes	1239
14.14.2	Coeficientes e relação das variáveis com as componentes	1241
14.14.3	Representação das observações e das variáveis	1246
14.14.4	Elementos ativos e suplementares na ACP	1250
14.14.5	Correspondência com a implementação utilizada	1252
14.15	Síntese	1253
15	Formulação da Análise Fatorial	1255
15.1	O problema da estrutura latente	1255
15.2	Formulação do modelo de fatores comuns	1256
15.3	Hipóteses do modelo ortogonal	1260

15.4	Estrutura da matriz de covariâncias	1262
15.4.1	Covariâncias entre variáveis	1264
15.4.2	Variâncias das variáveis	1265
15.5	Comunalidades e especificidades	1265
15.6	Cargas fatoriais e associação com os fatores	1268
15.7	Geometria das cargas fatoriais	1269
15.8	Estrutura comum de covariâncias	1272
15.9	Identificação do modelo fatorial	1274
15.9.1	Escala dos fatores	1274
15.9.2	Indeterminação do sinal	1275
15.9.3	Indeterminação rotacional	1275
15.10	Rotação dos eixos fatoriais	1276
15.10.1	Rotações ortogonais	1277
15.10.2	Rotações oblíquas	1277
15.11	Formulação populacional e amostral	1279
15.11.1	O problema de estimação	1280
15.11.2	Escore fatoriais	1281
15.12	Pressupostos e limites do modelo	1282
15.12.1	Número de fatores	1283
15.12.2	Dependência do conjunto e da escala das variáveis	1284
15.12.3	Papel da normalidade	1284
15.13	Análise Fatorial e Análise de Componentes Principais	1284
15.14	Aprofundamentos teóricos	1286
15.14.1	Contagem de parâmetros e identificação	1286
15.14.2	Invariâncias da rotação ortogonal	1291
15.14.3	Critérios de rotação como problemas de otimização	1292
15.14.4	Fatores principais e mínimos resíduos	1294
15.14.5	Formulação probabilística normal	1300
15.14.6	Distribuições associadas à avaliação da matriz de correlações	1303
15.14.7	Distribuição condicional dos fatores e escore por regressão	1306
15.14.8	Critérios e propriedades dos métodos de escores fatoriais	1307
15.15	Aprofundamentos metodológicos e aplicados	1309
15.15.1	Adequação da matriz de correlações à Análise Fatorial	1310
15.15.2	Escolha do número de fatores	1315
15.15.3	Matriz reproduzida e resíduos	1317
15.15.4	Critérios específicos de rotação	1319
15.15.5	Diferentes métodos de escores fatoriais	1321
15.15.6	Correspondência com a implementação utilizada	1322
15.16	Síntese	1323
16	Formulação da Análise de Agrupamentos	1325
16.1	O problema de formação de grupos	1326
16.2	Representação dos objetos e proximidade	1326

16.3	Dissimilaridades entre objetos	1327
16.3.1	Efeito da escala	1329
16.4	Partições	1330
16.4.1	Outras formas de pertinência	1331
16.5	Homogeneidade interna e separação	1331
16.6	Agrupamento por centroides	1332
16.6.1	Dispersão dentro e entre grupos	1332
16.6.2	Formulação das K -médias	1334
16.6.3	Partição para centroides fixados	1336
16.6.4	Geometria das regiões de alocação	1337
16.7	Estrutura dos métodos hierárquicos	1340
16.7.1	Ligações simples, completa e média	1341
16.7.2	Método de Ward e dispersão intragrupos	1343
16.7.3	Dendrograma e níveis de fusão	1344
16.7.4	Uma partição e uma hierarquia representam objetos diferentes	1347
16.8	Diferentes definições matemáticas de grupo	1348
16.9	Dependência da solução e limites da formulação	1349
16.10	Limites da interpretação dos grupos	1350
16.11	Relações com outras técnicas multivariadas	1351
16.11.1	Agrupamentos e ACP	1351
16.11.2	Agrupamentos e Análise Discriminante	1351
16.11.3	Agrupamentos e MANOVA	1352
16.12	Aprofundamentos teóricos	1352
16.12.1	O centroide como minimizador	1352
16.12.2	Existência e não unicidade da solução	1353
16.12.3	Transformações que preservam o critério das K -médias	1354
16.12.4	Derivação do incremento de Ward	1355
16.12.5	Empates e não unicidade da hierarquia	1356
16.13	Aprofundamentos metodológicos e aplicados	1356
16.13.1	Dados mistos e dissimilaridade de Gower	1356
16.13.2	Escolha do número de grupos	1357
16.13.3	Solução global, algoritmo e inicialização	1359
16.13.4	Convenções computacionais para o método de Ward	1360
16.14	Síntese	1361
17	Formulação da Análise de Correspondência	1363
17.1	O problema de associação em uma tabela de contingência	1364
17.2	Frequências marginais, massas e perfis	1365
17.2.1	Distribuições condicionais observadas	1367
17.2.2	Independência como referência	1368
17.3	Geometria dos perfis	1370
17.4	Inércia e afastamento da independência	1372

17.5	Padronização dos desvios da independência	1373
17.5.1	Inércia como norma matricial	1374
17.6	Relação algébrica com a estatística qui-quadrado	1375
17.7	Formulação pela decomposição em valores singulares	1376
17.7.1	Decomposição da inércia	1378
17.7.2	Representação em dimensão reduzida	1380
17.8	Coordenadas da Análise de Correspondência	1381
17.8.1	Sistema de coordenadas padrão	1381
17.8.2	Sistema de coordenadas principais	1382
17.8.3	Distâncias entre perfis e coordenadas principais	1383
17.9	Representação conjunta de linhas e colunas	1384
17.9.1	O significado das proximidades	1385
17.10	Formulação descritiva e inferencial	1386
17.11	Relação com a Análise de Componentes Principais	1387
17.12	Condições e limites da representação	1388
17.12.1	Tabela ativa e massas	1388
17.12.2	Dimensão da representação	1389
17.12.3	Sinais, multiplicidades e orientação	1390
17.12.4	Proximidade entre linhas e colunas	1391
17.13	Aprofundamentos teóricos	1392
17.13.1	Limite do posto da matriz de desvios padronizados	1392
17.13.2	Relações baricêntricas	1394
17.13.3	Centralização ponderada das coordenadas padrão e principais	1395
17.13.4	Reconstrução dos desvios da independência	1397
17.13.5	Decomposição da estatística de Pearson pelas dimensões	1399
17.13.6	Formulação probabilística e teste de independência	1399
17.14	Aprofundamentos metodológicos e aplicados	1401
17.14.1	Contribuição e qualidade de representação	1401
17.14.2	Escolha do número de dimensões	1403
17.14.3	Leitura da representação reduzida	1405
17.14.4	Categorias suplementares	1406
17.14.5	Linhas suplementares	1406
17.14.6	Colunas suplementares	1407
17.14.7	Qualidade de representação	1407
17.15	Síntese	1409
18	Formulação da MANOVA	1411
18.1	O problema de comparação multivariada	1412
18.2	A hipótese no modelo linear multivariado	1413
18.2.1	Matrizes de hipótese e erro	1414
18.3	Hipótese e erro em uma combinação linear das respostas	1415
18.4	Problema espectral da MANOVA	1417
18.4.1	Padronização pela dispersão residual e interpretação geométrica	1419

18.5	Critérios multivariados	1422
18.6	Uma mesma estrutura, quatro formas de agregação	1425
18.7	Pressupostos e limites	1426
18.7.1	Estrutura da média e estimabilidade	1426
18.7.2	Independência entre unidades	1426
18.7.3	Covariância residual comum	1427
18.7.4	Não singularidade populacional e amostral	1427
18.7.5	Normalidade multivariada	1428
18.7.6	Associação residual, condicionamento e singularidade	1429
18.8	Relações com outras técnicas	1429
18.8.1	ANOVA	1429
18.8.2	T^2 de Hotelling	1430
18.8.3	Regressão multivariada	1431
18.8.4	Análise Discriminante	1431
18.9	Aprofundamentos teóricos	1432
18.9.1	Base probabilística dos critérios	1432
18.9.2	Calibração inferencial dos critérios	1435
18.9.3	Invariância a transformações lineares das respostas	1436
18.9.4	Posto, sinais e multiplicidades das direções	1438
18.10	Aprofundamentos metodológicos e aplicados	1439
18.10.1	Avaliação da homogeneidade das matrizes de covariâncias	1439
18.10.2	Avaliação das respostas após o teste global	1439
18.11	Síntese	1441
19	Formulação da Análise Discriminante	1443
19.1	O problema de discriminação e classificação	1444
19.2	Classificação como problema de decisão	1445
19.2.1	Probabilidades a priori e posteriores	1445
19.2.2	Regra de Bayes sob perda zero-um	1446
19.3	Discriminação linear sob normalidade	1447
19.3.1	Fronteiras e distância de Mahalanobis	1449
19.4	Discriminação quadrática	1450
19.4.1	Fronteiras e comparação com a LDA	1452
19.5	Da regra populacional à regra estimada	1453
19.5.1	Covariância comum na LDA	1455
19.5.2	Probabilidades <i>a priori</i>	1455
19.5.3	Regra estimada da LDA	1456
19.5.4	Regra estimada da QDA	1457
19.6	Formulação geométrica de Fisher	1458
19.6.1	Dispersões populacionais dentro e entre grupos	1459
19.6.2	Dispersões projetadas	1460
19.7	Formulação amostral de Fisher	1462

19.8	Direções discriminantes e autovalores generalizados	1465
19.8.1	Geometria pela dispersão intragrupos	1465
19.8.2	Número de direções discriminantes	1468
19.9	Representação no subespaço discriminante	1469
19.10	Relação espectral com a MANOVA	1471
19.11	Dois grupos e relação entre Fisher e LDA	1472
19.11.1	Formulação populacional para dois grupos	1473
19.11.2	Mais de dois grupos	1475
19.12	Pressupostos e limites	1475
19.12.1	Grupos previamente definidos	1476
19.12.2	Normalidade e estrutura das covariâncias	1477
19.12.3	Não singularidade e dimensão	1478
19.12.4	Independência das unidades de treinamento	1480
19.12.5	Probabilidades <i>a priori</i> e perdas	1480
19.12.6	Sobreposição entre as classes	1481
19.13	Relações com outras técnicas	1482
19.13.1	Análise de Componentes Principais	1482
19.13.2	Análise de Agrupamentos	1483
19.14	Aprofundamentos teóricos	1483
19.14.1	Perdas e risco de classificação	1483
19.14.2	Forma explícita da fronteira quadrática	1486
19.14.3	Decomposição da covariância por grupos	1487
19.14.4	Relação com a discriminação linear normal	1487
19.14.5	Relação amostral entre Fisher e LDA	1489
19.14.6	Identificação das direções discriminantes	1490
19.15	Aprofundamentos metodológicos e aplicados	1491
19.15.1	Coeficientes das funções discriminantes	1491
19.15.2	Erro aparente e erro em novas observações	1492
19.15.3	Matriz de classificação	1493
19.16	Síntese	1494
Exercícios de fixação do Módulo III		1497
Parte I — Núcleo		1498
Parte II — Aprofundamentos teóricos		1506
Parte III — Aprofundamentos metodológicos e aplicados		1514
Referências		1523

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos. Técnicas diferentes podem ainda ser aplicadas a um mesmo conjunto de dados e produzir representações distintas ou complementares, pois cada uma privilegia um aspecto específico da estrutura multivariada.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual e matemática orienta a interpretação dos resultados e o uso dos procedimentos computacionais. Essa organização permite compreender por que cada técnica assume determinada forma, que tipo de informação preserva ou modela e quais fundamentos sustentam sua utilização e interpretação.

O **jamovi** é utilizado nas aplicações das técnicas multivariadas, enquanto o ambiente **R** e o sistema **Quarto** apoiam a produção de exemplos, figuras e do próprio livro. A implementação computacional é relacionada explicitamente à formulação estatística apresentada, permitindo

interpretar as opções e as saídas do software sem substituir o desenvolvimento matemático e conceitual dos métodos.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;
- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;

- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar o problema estatístico e selecionar a técnica multivariada de acordo com o objetivo da análise e a natureza dos dados;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados

Álgebra matricial aplicada

Espaços vetoriais, bases e projeções

Transformações lineares

Autovalores, autovetores e decomposição espectral

Decomposição em valores singulares

Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações

Distribuição normal multivariada

Estatísticas amostrais e estimação

Modelo linear multivariado e hipóteses lineares

Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas

Análise de Componentes Principais

Análise Fatorial

Análise de Agrupamentos

Análise de Correspondência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a avaliação dos pressupostos e a interpretação dos resultados, mantendo explícita a relação entre a formulação estatística e a implementação utilizada.

AVALIAÇÃO

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2018)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações com vetores, o produto interno, a norma, o ângulo, a distância euclidiana e o produto externo.

Convenções gerais de notação

As convenções abaixo indicam apenas como os objetos serão representados. Seus significados e propriedades serão definidos ao longo do capítulo.

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{.j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_i^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;
- o símbolo $\top$ indica transposição;

- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$ representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{\cdot j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j .

Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Neste momento, o vetor é utilizado apenas para organizar as medidas. A comparação geométrica de variáveis com unidades diferentes exigirá atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i\cdot}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{\cdot j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i\cdot}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{\cdot j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i\cdot}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_i$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_{\cdot j}$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. Antes de utilizar essas representações geometricamente, é necessário distinguir a natureza das variáveis que fornecem suas componentes.

1.2 Natureza das variáveis e representação

A representação de uma observação como ponto em $\mathbb{R}^p$ pressupõe que suas coordenadas sejam valores numéricos para os quais as operações utilizadas na geometria tenham significado compatível com as variáveis analisadas.

Uma **variável quantitativa** assume valores numéricos que representam quantidades. Ela pode ser discreta, quando seus valores pertencem a um conjunto enumerável, ou contínua, quando pode assumir valores em um intervalo da reta real. Em ambos os casos, seus valores observados podem ser representados por números reais e utilizados como coordenadas quando essa representação for adequada ao problema.

Uma **variável categórica** registra a categoria à qual pertence uma unidade. Em uma variável **nominal**, as categorias não possuem uma ordenação intrínseca. Em uma variável **ordinal**, as categorias possuem uma ordenação, mas as diferenças entre posições sucessivas não representam necessariamente distâncias de mesma magnitude. Uma variável binária constitui um caso particular de variável categórica com duas categorias.

A atribuição de códigos numéricos a categorias não modifica a natureza da variável. Se três categorias nominais forem codificadas por 1, 2 e 3, por exemplo, as diferenças entre esses números não passam a representar automaticamente distâncias entre as categorias. Para uma

variável ordinal, uma codificação numérica pode preservar a ordenação, mas não implica que a diferença entre categorias consecutivas possua significado quantitativo.

Essa distinção também deve ser preservada na organização computacional dos dados. Uma coluna armazenada por números inteiros pode representar uma medida quantitativa, uma variável ordinal ou apenas códigos de categorias nominais. O significado estatístico da coluna é determinado pela variável e por sua escala de mensuração, e não pelo formato numérico utilizado para armazená-la.

Neste capítulo, as matrizes e os vetores representados em $\mathbb{R}^p$ serão construídos a partir de variáveis quantitativas, salvo indicação explícita em contrário. Nos capítulos posteriores, variáveis categóricas e conjuntos de dados mistos serão associados a representações próprias quando a técnica utilizada assim exigir.

1.3 O espaço $\mathbb{R}^p$

Considerando p variáveis quantitativas, os valores observados em uma unidade podem ser organizados em um vetor com p componentes reais. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço $\mathbb{R}^p$). O espaço $\mathbb{R}^p$ é o conjunto

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ no qual são representadas as unidades observacionais será denominado **espaço das observações**. Cada vetor representa uma unidade, e cada componente corresponde a uma variável.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;

- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.4 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{\cdot 1} \ \mathbf{x}_{\cdot 2} \ \cdots \ \mathbf{x}_{\cdot p}] .$$

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = [5 \quad 7] .$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.4.1 Espaço das observações e espaço das variáveis

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{.j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

No **espaço das observações**, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às variáveis.

No **espaço das variáveis**, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{.j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.5 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.5.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.5.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

A norma do vetor resultante satisfaz

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;




Figura 1.3: Soma de vetores pela regra do paralelogramo.

- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.5.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

As operações anteriores produzem novos vetores ou novas variáveis. A próxima operação tem natureza diferente: o produto interno associa dois vetores a um número real e permite construir as noções de comprimento, ângulo, ortogonalidade e distância.

1.6 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

1.6.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. *Linearidade no segundo argumento*

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. *Não negatividade*

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. *Positividade definida*

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0}.$$

1.6.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.

Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.6.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Meyer, 2023)

Comprovação. Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha \langle \mathbf{x}, \mathbf{y} \rangle - \alpha \langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2 \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha \langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2 \|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

Substituindo o valor escolhido para α ,

$$\begin{aligned}
0 &\leq \|\mathbf{x}\|^2 - 2 \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \langle \mathbf{x}, \mathbf{y} \rangle \\
&\quad + \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \right)^2 \|\mathbf{y}\|^2 \\
&= \|\mathbf{x}\|^2 - \frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2}.
\end{aligned}$$

Logo,

$$\frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2} \leq \|\mathbf{x}\|^2.$$

Como $\|\mathbf{y}\|^2 > 0$, podemos multiplicar os dois lados por esse valor e obter

$$\langle \mathbf{x}, \mathbf{y} \rangle^2 \leq \|\mathbf{x}\|^2 \|\mathbf{y}\|^2.$$

Tomando a raiz quadrada dos dois lados,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Resta examinar quando ocorre a igualdade. Na construção anterior, a igualdade é satisfeita se, e somente se,

$$\langle \mathbf{x} - \alpha \mathbf{y}, \mathbf{x} - \alpha \mathbf{y} \rangle = 0.$$

Pela positividade definida do produto interno, isso ocorre se, e somente se,

$$\mathbf{x} - \alpha \mathbf{y} = \mathbf{0},$$

ou seja,

$$\mathbf{x} = \alpha \mathbf{y}.$$

Portanto, quando $\mathbf{y} \neq \mathbf{0}$, a igualdade ocorre se, e somente se, $\mathbf{x}$ é múltiplo escalar de $\mathbf{y}$.

Reunindo os dois casos, concluímos que a igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. $\square$

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.6.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.6.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as observações.




Figura 1.6: Os vetores x e y são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

A padronização e outras geometrias serão estudadas nos capítulos posteriores.

1.6.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer, 2023)

Comprovação. Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2. \end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2. \end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

□

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.6.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do **produto externo**.

Definição 1.14 (Produto externo). Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, o **produto externo** de $\mathbf{x}$ e $\mathbf{y}$, denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

é definido como a matriz em $\mathbb{R}^{p \times q}$

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$[\text{ext}(\mathbf{x}, \mathbf{y})]_{ij} = x_i y_j.$$

O resultado do produto externo é uma matriz.

A estrutura do produto externo pode ser observada por suas colunas. Como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = [y_1 \mathbf{x} \quad y_2 \mathbf{x} \quad \cdots \quad y_q \mathbf{x}],$$

cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

O produto externo é

$$\begin{aligned} \text{ext}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} 1(3) & 1(-1) & 1(4) \\ 2(3) & 2(-1) & 2(4) \end{bmatrix} \\ &= \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}. \end{aligned}$$

O resultado possui dimensão 2×3 , correspondente às dimensões de $\mathbf{x}$ e $\mathbf{y}$, respectivamente.

O produto interno e o produto externo produzem objetos de naturezas diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz. No próximo capítulo, após a definição do produto matricial, o produto externo será relacionado às operações entre matrizes e vetores, e suas propriedades matriciais serão desenvolvidas.

1.7 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos. O próximo capítulo desenvolverá as operações e as propriedades matriciais necessárias para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo será retomado como um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas bilineares e quadráticas. As seções finais introduzem matrizes particionadas e complemento de Schur, preparando estruturas que serão utilizadas posteriormente na formulação de resultados multivariados.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{r \times s}$. As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \iff n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. *Comutatividade*

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. *Associatividade*

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. *Existência do elemento neutro*

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A},$$

em que $\mathbf{0}_{n \times p}$ é o elemento neutro de dimensão $n \times p$:

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

4. Existência do elemento oposto

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$ e $\alpha, \beta \in \mathbb{R}$. A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:*

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. Elemento neutro da multiplicação escalar

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial, apresentado a seguir, utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. A definição a seguir reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelas linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelas colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_1 - \mathbf{a}_2 \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a seguinte matriz em $\mathbb{R}^{n \times r}$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

i Produto interno e produto externo como produtos matriciais

As operações entre vetores apresentadas anteriormente também podem ser expressas por meio do produto matricial.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno** pode ser escrito como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Como

$$\mathbf{x}^\top \in \mathbb{R}^{1 \times p} \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^{p \times 1},$$

o produto possui dimensão 1×1 e corresponde a um escalar:

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

De forma semelhante, para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

o **produto externo**, anteriormente denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

pode ser escrito como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \mathbf{xy}^\top.$$

Nesse caso,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \text{e} \quad \mathbf{y}^\top \in \mathbb{R}^{1 \times q},$$

de modo que

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

Portanto, a ordem e a orientação dos vetores determinam objetos diferentes:

$$\mathbf{x}^\top \mathbf{y} \text{ é um escalar}$$

enquanto

$$\mathbf{xy}^\top \text{ é uma matriz.}$$

Exemplo 2.5 (Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

A matriz

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 3 & 6 & 4 \\ 1 & 5 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{bmatrix} \in \mathbb{R}^{3 \times 4}$$

é obtida escrevendo as colunas de $\mathbf{X}$ como linhas. A operação de transposição e suas propriedades serão formalizadas adiante.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{X}\mathbf{a} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

Considere agora o produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}.$$

Esse produto possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \langle \mathbf{x}_{\cdot 1}, \mathbf{x}_{\cdot 2} \rangle = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \langle \mathbf{x}_1, \mathbf{x}_2 \rangle = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos serão retomados no estudo de matrizes de Gram, produtos cruzados, covariâncias e decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. Associatividade

$$(\mathbf{A}\mathbf{B})\mathbf{C} = \mathbf{A}(\mathbf{B}\mathbf{C}).$$

2. Distributividade à esquerda

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbf{B} + \mathbf{A}\mathbf{C}.$$

3. Distributividade à direita

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{A}\mathbf{C} + \mathbf{B}\mathbf{C}.$$

4. Compatibilidade com a multiplicação por escalar

Para $\alpha \in \mathbb{R}$,

$$(\alpha\mathbf{A})\mathbf{B} = \alpha(\mathbf{A}\mathbf{B}) = \mathbf{A}(\alpha\mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{A}\mathbf{B}$ e $\mathbf{B}\mathbf{A}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{A}\mathbf{B} \neq \mathbf{B}\mathbf{A}.$$

Exemplo 2.6 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja $\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}$. A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

Proposição 2.4 (Propriedades da transposição). *Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes com dimensões compatíveis e seja $\alpha \in \mathbb{R}$. Então,*

1. $(\mathbf{A}^\top)^\top = \mathbf{A}$,
2. $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$,
3. $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ e
4. $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.
5. Em particular, para vetores $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, $(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top$.

A última propriedade mostra que a transposição de um produto inverte a ordem dos fatores. Em particular, ela será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

2.2.2 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x} \in \mathbb{R}^p$, tem-se

$$(\mathbf{x}\mathbf{x}^\top)^\top = \mathbf{x}\mathbf{x}^\top.$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.8 (Matriz antissimétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Aprofundamento

A decomposição seguinte mostra que toda matriz quadrada pode ser separada em uma parte simétrica e uma parte antissimétrica. A parte simétrica será particularmente importante no estudo das formas quadráticas.

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser escrita de maneira única como*

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn; Johnson, 2013)

Comprovação. A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas. □

Exemplo 2.10 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.3 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada. Apesar de sua definição simples, essa operação permite representar de forma compacta somas de quadrados, produtos internos, formas quadráticas e diversas expressões matriciais utilizadas em Estatística Multivariada.

Definição 2.9 (Traço de uma matriz). Seja $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$. O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Cálculo do traço). Para $\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix}$, tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Proposição 2.5 (Propriedades básicas do traço). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha, \beta \in \mathbb{R}$. Então,*

1. *Linearidade:*

$$\text{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{tr}(\mathbf{A}) + \beta \text{tr}(\mathbf{B}).$$

2. *Invariância à transposição:*

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

3. *Traço da matriz identidade:*

$$\text{tr}(\mathbf{I}_n) = n.$$

Consequentemente,

$$\text{tr}(\alpha \mathbf{I}_n) = \alpha n.$$

4. *Propriedade cíclica:* se $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$, então

$$\text{tr}(\mathbf{CD}) = \text{tr}(\mathbf{DC}).$$

(Harville, 1997)

A primeira propriedade mostra que o traço é uma operação linear. A segunda decorre do fato de que a transposição não modifica os elementos da diagonal principal. A quarta permite reorganizar produtos matriciais dentro do traço, desde que seja preservada a ordem cíclica dos fatores.

A propriedade cíclica pode ser demonstrada diretamente a partir da definição do produto matricial.

Comprovação. Como $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$,

$$\text{tr}(\mathbf{CD}) = \sum_{i=1}^n (\mathbf{CD})_{ii} = \sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji}.$$

Trocando a ordem das somas,

$$\sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji} = \sum_{j=1}^p \sum_{i=1}^n d_{ji} c_{ij} = \text{tr}(\mathbf{DC}).$$

□

Proposição 2.6 (Ciclicidade para vários fatores). *Para matrizes com dimensões compatíveis, os fatores de um produto podem ser deslocados ciclicamente dentro do traço. Por exemplo,*

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A propriedade é **cíclica**. Portanto, a ordem relativa dos fatores é preservada. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Proposição 2.7 (Traço, produto interno e produto externo). *Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\text{tr}(\mathbf{xy}^\top) = \mathbf{y}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Como $\mathbf{xy}^\top = \text{ext}(\mathbf{x}, \mathbf{y})$, também podemos escrever

$$\text{tr}[\text{ext}(\mathbf{x}, \mathbf{y})] = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Em particular,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Essa propriedade estabelece uma ligação direta entre o traço e as operações vetoriais introduzidas anteriormente.

Proposição 2.8 (Traço de produtos matriciais). *Para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$,*

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ij}.$$

Consequentemente,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

Pela propriedade cíclica,

$$\operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \operatorname{tr}(\mathbf{A} \mathbf{A}^\top).$$

Portanto, o traço permite representar a soma dos quadrados de todos os elementos de uma matriz. Essa expressão será retomada posteriormente no estudo da norma de Frobenius, de matrizes de produtos cruzados e de decomposições matriciais.

Exemplo 2.12 (Traço de produtos matriciais). Considere $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} 1 & 3 \\ -2 & 3 \end{bmatrix}$.

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -9 & 9 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} -1 & 13 \\ -7 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

seus traços são iguais:

$$\operatorname{tr}(\mathbf{AB}) = 0 + 9 = 9$$

e

$$\operatorname{tr}(\mathbf{BA}) = -1 + 10 = 9.$$

O traço será utilizado repetidamente na representação de somas de quadrados, produtos cruzados, variâncias totais, formas quadráticas e expressões de verossimilhança. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.10 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos podem ser representados pelo **delta de Kronecker**,

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

de modo que

$$(\mathbf{I}_n)_{ij} = \delta_{ij}.$$

O delta de Kronecker será utilizado posteriormente para representar de forma compacta relações de ortogonalidade e ortonormalidade.

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.11 (Matriz inversa). Uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.2 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

Comprovação. Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única. □

Exemplo 2.14 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.3 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

Comprovação. Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

□

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.12 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.13 (Determinante). Para uma matriz de ordem um,

$$\mathbf{A} = [a_{11}],$$

define-se

$$\det(\mathbf{A}) = a_{11}.$$

Para $n \geq 2$, seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O determinante de $\mathbf{A}$ pode ser calculado recursivamente pela expansão em cofatores de qualquer linha fixa i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna fixa j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Em cada termo, o cofator C_{ij} envolve o determinante de uma matriz de ordem $n - 1$. O caso de ordem um encerra a definição recursiva.

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e rea-

lizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais, que serão estudadas posteriormente.

Proposição 2.9 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.4 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere uma matriz quadrada

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{n \times n}.$$

As colunas de $\mathbf{A}$ podem ser interpretadas como vetores em $\mathbb{R}^n$. Esses vetores determinam uma região geométrica cuja medida depende de suas direções e comprimentos.

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

corresponde à medida do paralelepípedo determinado pelas colunas de $\mathbf{A}$:

- em uma dimensão, corresponde a um comprimento;
- em duas dimensões, corresponde à área do paralelogramo determinado pelas duas colunas;
- em três dimensões, corresponde ao volume do paralelepípedo determinado pelas três colunas;
- em $\mathbb{R}^n$, corresponde ao volume n -dimensional determinado pelas n colunas.

Como a matriz identidade $\mathbf{I}_n$ possui determinante igual a 1, suas colunas determinam uma região de volume unitário. Assim, $|\det(\mathbf{A})|$ também pode ser interpretado como o fator pelo qual esse volume unitário é ampliado ou reduzido quando os vetores canônicos são substituídos pelas colunas de $\mathbf{A}$.

O sinal do determinante acrescenta informação sobre a orientação dos vetores:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é nulo.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

No último caso, as colunas não determinam todas as direções necessárias para formar um volume n -dimensional. Em $\mathbb{R}^2$, por exemplo, duas colunas alinhadas formam uma região de área zero; em $\mathbb{R}^3$, três colunas contidas em um mesmo plano formam uma região de volume zero.

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.

2.3.5 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.14 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura será importante posteriormente nas decomposições matriciais, em que uma matriz poderá ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.5 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer, 2023)

Exemplo 2.18 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.15 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n. \end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.6 (Existência e quantidade de soluções). *Sejam*

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- a solução é única se

$$\text{posto}(\mathbf{A}) = p;$$

- existem infinitas soluções se

$$\text{posto}(\mathbf{A}) < p.$$

Definição 2.16 (Sistema linear homogêneo). Um **sistema linear homogêneo** é um sistema da forma

$$\mathbf{A}\mathbf{x} = \mathbf{0},$$

em que

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{0} \in \mathbb{R}^n.$$

Portanto, um sistema homogêneo é um caso particular de sistema linear no qual todos os termos independentes são iguais a zero.

Todo sistema homogêneo possui pelo menos a **solução trivial**

$$\mathbf{x} = \mathbf{0}.$$

Dependendo da matriz $\mathbf{A}$, também podem existir **soluções não triviais**, isto é, soluções para as quais

$$\mathbf{x} \neq \mathbf{0}.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.19 (Sistema com solução única). Considere

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3. \end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.20 (Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4. \end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5. \end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.3.7 Aprofundamento: pseudoinversa

Leitura de aprofundamento

A pseudoinversa permite estender a resolução de sistemas lineares para matrizes retangulares ou singulares. Sua construção será desenvolvida no capítulo sobre decomposição em valores singulares. Nesta seção, são apresentadas sua definição e suas principais consequências.

Definição 2.17 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Harville, 1997)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+\mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{AA}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção de $\mathbf{A}^+$, sua interpretação por projeções e sua relação com o posto serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.18 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.21 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.7 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Comprovação. Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

□

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.19 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag} \left(\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} \right).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1x_1 \\ d_2x_2 \\ \vdots \\ d_nx_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.22 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.20 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$$\mathbf{U}^\top \text{ é triangular inferior.}$$

Da mesma forma,

$$\mathbf{L}^\top \text{ é triangular superior.}$$

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.23 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Aprofundamento: sistemas triangulares

Leitura de aprofundamento

Os sistemas triangulares mostram como a estrutura de uma matriz pode simplificar a resolução de equações. Esses procedimentos também aparecem nas decomposições matriciais estudadas posteriormente.

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.24 (Sistema triangular superior). Considere o sistema

$$\begin{aligned} x_1 + 2x_2 - x_3 &= 4, \\ 2x_2 + 3x_3 &= 7, \\ x_3 &= 1. \end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{L}\mathbf{x} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar e são lineares em cada argumento separadamente. Quando uma forma bilinear é avaliada utilizando o mesmo vetor em seus dois argumentos, obtém-se uma função de um único vetor, denominada forma quadrática.

Essa relação permite conectar propriedades das matrizes, como simetria e positividade, a expressões escalares que aparecem frequentemente na análise multivariada, entre elas produtos internos, normas, variâncias e distâncias.

2.5.1 Formas bilineares

Definição 2.21 (Forma bilinear). Uma função

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **forma bilinear** quando é linear separadamente em cada argumento.

Isso significa que, para quaisquer

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e quaisquer

$$\beta \in \mathbb{R},$$

tem-se

$$g(\mathbf{x} + \beta \mathbf{z}, \mathbf{y}) = g(\mathbf{x}, \mathbf{y}) + \beta g(\mathbf{z}, \mathbf{y})$$

e

$$g(\mathbf{x}, \mathbf{z} + \beta \mathbf{y}) = g(\mathbf{x}, \mathbf{z}) + \beta g(\mathbf{x}, \mathbf{y}).$$

A bilinearidade significa, portanto, que, mantendo um dos argumentos fixo, a forma bilinear é uma função linear do outro argumento.

Fixado $\mathbf{y} \in \mathbb{R}^p$, a função

$$\mathbf{x} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{x}$. Analogamente, fixado $\mathbf{x} \in \mathbb{R}^p$, a função

$$\mathbf{y} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{y}$.

Um caso particularmente importante para a estatística são as formas bilineares simétricas.

Definição 2.22 (Forma bilinear simétrica). Uma forma bilinear

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **simétrica** quando

$$g(\mathbf{x}, \mathbf{y}) = g(\mathbf{y}, \mathbf{x})$$

para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

Exemplo 2.25 (Produto interno como forma bilinear simétrica). O produto interno usual em $\mathbb{R}^p$,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle,$$

é um exemplo de forma bilinear simétrica, pois,

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle,$$

ou, equivalentemente,

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}.$$

Nem toda forma bilinear é simétrica.

Exemplo 2.26 (Bilinearidade e ausência de simetria). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$$

e os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

A função

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é dada por

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2y_1 + y_2 \\ -y_1 + 3y_2 \end{bmatrix} \\ &= 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2. \end{aligned}$$

Para verificar a linearidade no primeiro argumento, sejam $\mathbf{x}_1, \mathbf{x}_2, \mathbf{y} \in \mathbb{R}^2$ e $\beta \in \mathbb{R}$. Então,

$$\begin{aligned} g(\mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) &= (\mathbf{x}_1 + \beta \mathbf{x}_2)^\top \mathbf{A} \mathbf{y} \\ &= \mathbf{x}_1^\top \mathbf{A} \mathbf{y} + \beta \mathbf{x}_2^\top \mathbf{A} \mathbf{y} \\ &= g(\mathbf{x}_1, \mathbf{y}) + \beta g(\mathbf{x}_2, \mathbf{y}). \end{aligned}$$

Analogamente, para $\mathbf{x}, \mathbf{y}_1, \mathbf{y}_2 \in \mathbb{R}^2$,

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}_1 + \beta \mathbf{y}_2) &= \mathbf{x}^\top \mathbf{A} (\mathbf{y}_1 + \beta \mathbf{y}_2) \\ &= \mathbf{x}^\top \mathbf{A} \mathbf{y}_1 + \beta \mathbf{x}^\top \mathbf{A} \mathbf{y}_2 \\ &= g(\mathbf{x}, \mathbf{y}_1) + \beta g(\mathbf{x}, \mathbf{y}_2). \end{aligned}$$

Portanto, g é linear em cada argumento separadamente e, assim, é uma forma bilinear.

Para verificar se a forma bilinear é simétrica, invertem-se os dois argumentos. Tem-se

$$g(\mathbf{y}, \mathbf{x}) = 2x_1y_1 - x_1y_2 + x_2y_1 + 3x_2y_2.$$

Por outro lado,

$$g(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2.$$

As duas expressões diferem nos termos cruzados. Portanto, em geral,

$$g(\mathbf{x}, \mathbf{y}) \neq g(\mathbf{y}, \mathbf{x}),$$

e a forma bilinear não é simétrica.

De modo geral, uma forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é simétrica se, e somente se, sua matriz representante é simétrica, isto é, $\mathbf{A} = \mathbf{A}^\top$.

Uma forma bilinear também pode ser avaliada utilizando o mesmo vetor em seus dois argumentos. Assim, em vez de considerar

$$g(\mathbf{x}, \mathbf{y}),$$

podemos considerar

$$g(\mathbf{x}, \mathbf{x}).$$

Essa avaliação produz uma função de um único vetor e conduz às formas quadráticas.

2.5.2 Formas quadráticas

Definição 2.23 (Forma quadrática). Seja

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma forma bilinear. A função

$$Q : \mathbb{R}^p \longrightarrow \mathbb{R}$$

definida por

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x})$$

é denominada **forma quadrática** associada a g .

Se a forma bilinear possui representação matricial

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p.$$

A forma bilinear depende de dois argumentos e é linear em cada um deles separadamente. A forma quadrática, por sua vez, depende de um único argumento e, em geral, não é uma função linear desse vetor.

De fato, para qualquer $\alpha \in \mathbb{R}$,

$$\begin{aligned} Q(\alpha \mathbf{x}) &= g(\alpha \mathbf{x}, \alpha \mathbf{x}) \\ &= \alpha^2 g(\mathbf{x}, \mathbf{x}) \\ &= \alpha^2 Q(\mathbf{x}). \end{aligned}$$

Assim,

$$Q(\alpha \mathbf{x}) = \alpha^2 Q(\mathbf{x}).$$

A expressão quadrática pode ser interpretada como a avaliação da forma bilinear sobre a diagonal do produto cartesiano,

$$\{(\mathbf{x}, \mathbf{x}) : \mathbf{x} \in \mathbb{R}^p\} \subset \mathbb{R}^p \times \mathbb{R}^p.$$

O produto interno fornece um exemplo imediato dessa construção.

Exemplo 2.27 (Produto interno e norma ao quadrado). Considere a forma bilinear dada pelo produto interno usual,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Ao utilizar o mesmo vetor nos dois argumentos,

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x}) = \langle \mathbf{x}, \mathbf{x} \rangle.$$

Pela definição da norma euclidiana,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2.$$

Portanto,

$$Q(\mathbf{x}) = \|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

A matriz representante dessa forma quadrática é

$$\mathbf{I}_p.$$

Em geral, se

$$\mathbf{A} = (a_{ij})_{p \times p},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j. \quad (2.1)$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= ax_1^2 + (b+c)x_1x_2 + dx_2^2. \end{aligned}$$

Esse desenvolvimento mostra uma diferença importante entre formas bilineares e formas quadráticas.

Na forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

os elementos a_{ij} e a_{ji} podem produzir contribuições distintas porque os dois vetores não precisam ser iguais.

Na forma quadrática

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

os termos fora da diagonal aparecem combinados. No caso bidimensional, por exemplo, b e c aparecem somente por meio da soma

$$b + c.$$

Consequentemente, a matriz que aparece em uma representação

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

não é necessariamente única quando matrizes não simétricas são admitidas. Matrizes que diferem apenas por uma parcela antissimétrica produzem a mesma forma quadrática.

Entretanto, toda forma quadrática possui uma única matriz simétrica que a representa. Essa propriedade é apresentada na proposição seguinte.

Proposição 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Então $\mathbf{S}$ é simétrica e, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Além disso, $\mathbf{S}$ é a única matriz simétrica que representa essa forma quadrática.

Comprovação. A matriz $\mathbf{A}$ pode ser escrita como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica.

De fato,

$$\mathbf{S}^\top = \mathbf{S}$$

e

$$\mathbf{K}^\top = -\mathbf{K}.$$

Assim,

$$\begin{aligned}\mathbf{x}^\top \mathbf{A} \mathbf{x} &= \mathbf{x}^\top (\mathbf{S} + \mathbf{K}) \mathbf{x} \\ &= \mathbf{x}^\top \mathbf{S} \mathbf{x} + \mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

O termo

$$\mathbf{x}^\top \mathbf{K} \mathbf{x}$$

é um escalar. Portanto,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = (\mathbf{x}^\top \mathbf{K} \mathbf{x})^\top.$$

Utilizando a transposição do produto,

$$\begin{aligned}\mathbf{x}^\top \mathbf{K} \mathbf{x} &= \mathbf{x}^\top \mathbf{K}^\top \mathbf{x} \\ &= -\mathbf{x}^\top \mathbf{K} \mathbf{x}.\end{aligned}$$

Logo,

$$2\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0$$

e, consequentemente,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0.$$

Portanto,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Resta mostrar a unicidade da representação simétrica.

Suponha que $\mathbf{S}_1$ e $\mathbf{S}_2$ sejam duas matrizes simétricas que representem a mesma forma quadrática. Então,

$$\mathbf{x}^\top \mathbf{S}_1 \mathbf{x} = \mathbf{x}^\top \mathbf{S}_2 \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Definindo

$$\mathbf{D} = \mathbf{S}_1 - \mathbf{S}_2,$$

a matriz $\mathbf{D}$ também é simétrica e satisfaz

$$\mathbf{x}^\top \mathbf{D} \mathbf{x} = 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\begin{aligned} 0 &= (\mathbf{x} + \mathbf{y})^\top \mathbf{D} (\mathbf{x} + \mathbf{y}) \\ &= \mathbf{x}^\top \mathbf{D} \mathbf{x} + \mathbf{x}^\top \mathbf{D} \mathbf{y} + \mathbf{y}^\top \mathbf{D} \mathbf{x} + \mathbf{y}^\top \mathbf{D} \mathbf{y}. \end{aligned}$$

Como $\mathbf{D}$ é simétrica,

$$\mathbf{y}^\top \mathbf{D} \mathbf{x} = \mathbf{x}^\top \mathbf{D} \mathbf{y},$$

e os termos quadráticos são nulos. Assim,

$$2\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Logo,

$$\mathbf{x}^\top \mathbf{D} \mathbf{y} = 0$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$.

Em particular, tomando os vetores da base canônica,

$$\mathbf{x} = \mathbf{e}_i \quad \text{e} \quad \mathbf{y} = \mathbf{e}_j,$$

obtem-se

$$\mathbf{e}_i^\top \mathbf{D} \mathbf{e}_j = d_{ij} = 0$$

para todos i e j .

Portanto,

$$\mathbf{D} = \mathbf{0},$$

o que implica

$$\mathbf{S}_1 = \mathbf{S}_2.$$

□

Assim, embora uma forma quadrática possa possuir diferentes representações por matrizes não simétricas, sua representação por uma matriz simétrica é única.

Por essa razão, no estudo de formas quadráticas, pode-se trabalhar sem perda de generalidade com matrizes simétricas.

Observe que essa propriedade é específica das formas quadráticas. Para uma forma bilinear geral,

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

a parte antissimétrica de $\mathbf{A}$ pode contribuir para o valor da expressão quando

$$\mathbf{x} \neq \mathbf{y}.$$

Quando os dois argumentos coincidem, essa contribuição desaparece.

Exemplo 2.28 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

A forma quadrática associada a $\mathbf{A}$ é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então,

$$Q(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuando os produtos,

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtém-se

$$\begin{aligned} Q(\mathbf{x}) &= 2(1)^2 + 2(1)(2) + 3(2)^2 \\ &= 2 + 4 + 12 \\ &= 18. \end{aligned}$$

2.5.3 Positividade

Como toda forma quadrática pode ser representada por uma única matriz simétrica, propriedades importantes da forma quadrática podem ser estudadas a partir dos valores assumidos por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com $\mathbf{A}$ simétrica.

A classificação em positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida depende do sinal assumido por essa expressão.

Definição 2.24 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica e considere a forma quadrática

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \succ \mathbf{0};$$

- **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \succeq \mathbf{0};$$

- **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \prec \mathbf{0};$$

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \preceq \mathbf{0};$$

- **indefinida** quando existem vetores não nulos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Para matrizes indefinidas, não se utiliza uma relação de ordem do tipo $\mathbf{A} \succeq \mathbf{0}$ ou $\mathbf{A} \preceq \mathbf{0}$.

As notações $\succ$, $\succeq$, $\prec$ e $\preceq$ expressam a ordem de Löwner para matrizes simétricas. Em particular,

$$\begin{aligned} \mathbf{A} \succ \mathbf{0} &\iff \mathbf{A} \text{ é positiva definida,} \\ \mathbf{A} \succeq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida positiva,} \\ \mathbf{A} \prec \mathbf{0} &\iff \mathbf{A} \text{ é negativa definida,} \\ \mathbf{A} \preceq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida negativa.} \end{aligned}$$

produto interno usual fornece um exemplo imediato de forma quadrática associada a uma matriz positiva definida.

Como

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \|\mathbf{x}\|^2,$$

tem-se

$$Q(\mathbf{x}) > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Portanto, a matriz identidade

$$\mathbf{I}_p$$

é positiva definida.

Outro exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo.

Para

$$\mathbf{x}, \mathbf{z} \in \mathbb{R}^p,$$

considere

$$\mathbf{xx}^\top.$$

Então,

$$\begin{aligned}\mathbf{z}^\top (\mathbf{xx}^\top) \mathbf{z} &= (\mathbf{z}^\top \mathbf{x}) (\mathbf{x}^\top \mathbf{z}) \\ &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{xx}^\top$$

é semidefinida positiva.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\text{rank}(\mathbf{xx}^\top) = 1.$$

Assim, quando $p > 1$, existem vetores não nulos $\mathbf{z}$ ortogonais a $\mathbf{x}$. Para esses vetores,

$$\mathbf{x}^\top \mathbf{z} = 0$$

e, portanto,

$$\mathbf{z}^\top (\mathbf{xx}^\top) \mathbf{z} = 0.$$

Logo, para $p > 1$ e $\mathbf{x} \neq \mathbf{0}$, a matriz

$$\mathbf{xx}^\top$$

é semidefinida positiva, mas não positiva definida.

Esse tipo de matriz terá importância particular na construção das matrizes de covariâncias, que envolvem somas de produtos externos de vetores de desvios.

Exemplo 2.29 (Classificação de formas quadráticas). Considere inicialmente

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

Como

$$2x_1^2 + 3x_2^2 > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0},$$

a matriz $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

Portanto, $\mathbf{B}$ é semidefinida positiva.

Entretanto, para vetores não nulos da forma

$$\mathbf{x} = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}, \quad x_2 \neq 0,$$

tem-se

$$Q(\mathbf{x}) = 0.$$

Assim, $\mathbf{B}$ não é positiva definida.

Finalmente, considere

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

A forma quadrática associada é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{x}) = 1 > 0.$$

Por outro lado, para

$$\mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{y}) = -1 < 0.$$

Portanto, a forma quadrática assume valores positivos e negativos, e a matriz $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérboles. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Aprofundamento: matrizes particionadas e complemento de Schur

Leitura de aprofundamento

Esta seção pode ser utilizada como referência nos capítulos posteriores. As operações por blocos e o complemento de Schur serão retomados no estudo de covariâncias particionadas, distribuições condicionais, regressão entre blocos e correlação canônica.

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.25 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.30 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.31 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

Matrizes particionadas permitem tratar uma matriz de grande dimensão a partir de blocos menores. Em vários problemas, é útil eliminar um desses blocos e estudar a estrutura que permanece no outro. O **complemento de Schur** é a matriz que surge naturalmente nesse processo de eliminação.

Definição 2.26 (Complemento de Schur). Considere a matriz quadrada particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Os blocos diagonais $\mathbf{A}_{11}$ e $\mathbf{A}_{22}$ são quadrados. Quando um deles é invertível, podemos utilizá-lo para eliminar os efeitos dos blocos fora da diagonal.

Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, enquanto $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

A expressão pode ser compreendida como uma correção do bloco diagonal original. Por exemplo,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

parte de $\mathbf{A}_{11}$ e retira a parcela associada às relações que passam pelo segundo bloco. Essa interpretação ficará mais clara ao observarmos a eliminação por blocos.

2.6.6 Eliminação por blocos

Suponha que $\mathbf{A}_{22}$ seja invertível. Queremos eliminar o bloco $\mathbf{A}_{12}$, isto é, produzir uma matriz equivalente cuja posição superior direita seja ocupada por uma matriz nula.

Para isso, considere

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Multiplicando $\mathbf{E}$ por $\mathbf{A}$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Efetuada o produto por blocos,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{A}_{12} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{22} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Como $\mathbf{A}_{22}^{-1}\mathbf{A}_{22} = \mathbf{I}_q$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Portanto, o complemento de Schur aparece exatamente como o bloco que permanece depois da eliminação de $\mathbf{A}_{12}$ utilizando $\mathbf{A}_{22}$.

Como

$$\mathbf{E}^{-1} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix},$$

também podemos escrever

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Essa fatoração é consequência direta da eliminação por blocos.

Um caso simples ajuda a reconhecer a estrutura. Para uma matriz 2×2 ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

com $d \neq 0$, o complemento de Schur de d é

$$a - bd^{-1}c.$$

Como veremos a seguir,

$$\det(\mathbf{A}) = d(a - bd^{-1}c) = ad - bc,$$

recuperando a expressão usual do determinante de uma matriz 2×2 .

Exemplo 2.32 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Como $\mathbf{A}_{22} = \mathbf{I}_2$, tem-se $\mathbf{A}_{22}^{-1} = \mathbf{I}_2$. Logo,

$$\begin{aligned} \mathbf{A}_{11.2} &= \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.7 Determinante de uma matriz particionada

A eliminação por blocos mostra uma das principais utilidades do complemento de Schur: calcular o determinante de uma matriz particionada utilizando determinantes de matrizes menores.

Teorema 2.8 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd; Vandenberghe, 2004)

Comprovação. Suponha que $\mathbf{A}_{22}$ seja invertível. Pela eliminação por blocos apresentada anteriormente,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Como $\mathbf{E}$ é triangular por blocos e possui matrizes identidade na diagonal,

$$\det(\mathbf{E}) = 1.$$

Portanto,

$$\det(\mathbf{EA}) = \det(\mathbf{A}).$$

A matriz $\mathbf{EA}$ também é triangular por blocos. Assim,

$$\det(\mathbf{EA}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

A segunda identidade é obtida de forma análoga, eliminando o bloco $\mathbf{A}_{21}$ a partir de $\mathbf{A}_{11}$. $\square$

No Exemplo 2.32,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = 3.$$

Consequentemente,

$$\det(\mathbf{A}) = 3.$$

2.6.8 Inversão em blocos

O complemento de Schur também permite obter a inversa de uma matriz particionada. A origem da expressão pode ser entendida a partir da mesma fatoração obtida pela eliminação por blocos.

Se $\mathbf{A}_{22}$ é invertível,

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{11.2}$ também é invertível, os dois fatores são invertíveis. Como a inversa de um produto inverte a ordem dos fatores, a inversa de $\mathbf{A}$ pode ser construída a partir das inversas dessas duas matrizes mais simples.

Proposição 2.11 (Inversa em blocos). *Considere a matriz particionada*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e o complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1} & \mathbf{B}_{22} \end{bmatrix},$$

com o bloco $(2, 2)$ dado por

$$\mathbf{B}_{22} = \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}.$$

(Boyd; Vandenberghe, 2004)

A expressão pode parecer extensa, mas sua estrutura é determinada pela eliminação anterior. O bloco $\mathbf{A}_{11.2}^{-1}$ representa a parte de $\mathbf{A}_{11}$ que permanece depois da eliminação do segundo bloco.

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.9 Positividade e complemento de Schur

Outra aplicação importante ocorre em matrizes simétricas. O complemento de Schur permite verificar a definição positiva de uma matriz particionada por meio de matrizes de menor dimensão.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^{\top} & \mathbf{A}_{22} \end{bmatrix}.$$

Para estudar se $\mathbf{A}$ é positiva definida, consideramos sua forma quadrática. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y}.$$

Quando $\mathbf{A}_{22}$ é invertível, os termos envolvendo $\mathbf{y}$ podem ser reorganizados completando a forma quadrática:

$$\begin{aligned} & \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top) \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

O primeiro termo contém exatamente o complemento de Schur de $\mathbf{A}_{22}$.

Teorema 2.9 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então $\mathbf{A}$ é positiva definida se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Boyd; Vandenberghe, 2004)

Comprovação. Pela decomposição da forma quadrática,

$$\begin{aligned} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} &= \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

Suponha inicialmente que $\mathbf{A}_{11.2}$ e $\mathbf{A}_{22}$ sejam positivas definidas.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Logo, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela da decomposição é igual a zero. Portanto,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0.$$

Assim, $\mathbf{A}_{11 \cdot 2}$ é positiva definida. □

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22 \cdot 1}$.

O complemento de Schur aparece sempre que uma matriz particionada é estudada após a eliminação de um dos blocos. Por isso, ele será útil em diferentes partes da Análise Multivariada.

Algebricamente, o termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a correção associada ao segundo bloco, enquanto

$$\mathbf{A}_{11 \cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa o primeiro bloco depois dessa correção.

Essa interpretação é puramente matricial e vale para matrizes particionadas gerais.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada,

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix},$$

o complemento

$$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

adquire uma interpretação estatística adicional. Ele representa a matriz de covariâncias da parcela do primeiro bloco que permanece após o ajuste linear pelo segundo bloco. Sob normalidade conjunta, essa mesma matriz corresponde à covariância condicional do primeiro bloco dado o segundo.

Essa estrutura será retomada no estudo de covariâncias condicionais, regressão entre blocos e distribuição normal multivariada.

2.7 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{A}\mathbf{x}$	Produce produtos internos pelas linhas e combinações lineares pelas colunas
Produto matricial	$\mathbf{A}_{n \times p} \mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma bilinear	$\mathbf{x}^\top \mathbf{A} \mathbf{y}$	Relaciona dois vetores por meio de uma matriz
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{A} \mathbf{x} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida.

As seções sobre pseudoinversa, sistemas triangulares, matrizes particionadas e complemento de Schur funcionam como aprofundamentos. Esses resultados serão retomados quando sua utilização estatística se tornar necessária.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas bilineares e quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

Convenções para espaços vetoriais e subespaços

As convenções vetoriais e matriciais apresentadas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- V e W representam espaços vetoriais ou subespaços vetoriais;
- S representa, em geral, um subespaço de $\mathbb{R}^p$;
- $\mathcal{B}$ representa uma base;
- $\mathcal{B}_W$ representa uma base associada ao subespaço W ;
- $\dim(V)$ representa a dimensão do espaço vetorial V ;
- $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ representa o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$;
- $[\mathbf{x}]_{\mathcal{B}}$ representa o vetor de coordenadas de $\mathbf{x}$ em relação à base $\mathcal{B}$;
- $S^\perp$ representa o complemento ortogonal de S ;
- $\mathcal{C}(\mathbf{A})$ representa o espaço coluna de $\mathbf{A}$;
- $\mathcal{L}(\mathbf{A})$ representa o espaço linha de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A})$ representa o espaço nulo de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A}^\top)$ representa o espaço nulo de $\mathbf{A}^\top$;
- $\oplus$ representa soma direta de subespaços;
- $\text{proj}_S(\mathbf{x})$ representa a projeção ortogonal de $\mathbf{x}$ sobre S ;
- $\mathbf{P}_S$ representa uma matriz de projeção ortogonal sobre S ;
- $\mathbf{G}$ representa, quando indicado, uma matriz de Gram.

Quando uma base for escrita como

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\},$$

a ordem dos vetores será considerada fixada sempre que forem utilizadas coordenadas em relação a essa base.

Os vetores continuarão sendo representados por letras minúsculas em negrito, como $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{v}$, enquanto matrizes serão representadas por letras maiúsculas em negrito, como $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{Q}$.

As definições e propriedades específicas de cada espaço, base, decomposição ou operador serão apresentadas nas seções correspondentes.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e são satisfeitas as seguintes propriedades:

1. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$,

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}.$$

2. Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$,

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}).$$

3. Existe um vetor $\mathbf{0} \in V$ tal que, para todo $\mathbf{x} \in V$,

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

4. Para todo $\mathbf{x} \in V$, existe um vetor $-\mathbf{x} \in V$ tal que

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0}.$$

5. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$ e $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y}.$$

6. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x}.$$

7. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}.$$

8. Para todo $\mathbf{x} \in V$,

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais de adição e multiplicação por escalar, é um espaço vetorial. Seus elementos são vetores com p componentes reais. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e, para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

seu inverso aditivo é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

Os elementos de um espaço vetorial não precisam ser necessariamente vetores numéricos. Por exemplo, o conjunto de todas as matrizes reais de dimensão $n \times p$,

$$\mathbb{R}^{n \times p},$$

também é um espaço vetorial com as operações usuais de adição de matrizes e multiplicação por escalar. Nesse caso, os elementos do espaço vetorial são matrizes.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Proposição 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer, 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

Geometricamente, S é uma reta paralela a W , mas deslocada e sem passar pela origem.

A Figura 3.1 compara uma reta que é subespaço de $\mathbb{R}^2$ com uma reta paralela que não é subespaço.




Figura 3.1: Comparação entre uma reta que é subespaço de $\mathbb{R}^2$ e uma reta que não é subespaço.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem e, por isso, não é um subespaço de $\mathbb{R}^2$.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é o conjunto de todas as suas combinações lineares,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

A notação

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$$

indica o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Exemplo 3.5 (Espaço e subespaço gerado). Considere o espaço vetorial

$$V = \mathbb{R}^3.$$

Primeiro, considere os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}.$$

Como qualquer vetor de $\mathbb{R}^3$ pode ser obtido escolhendo adequadamente α_1 , α_2 e α_3 ,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} = \mathbb{R}^3.$$

Nesse caso, o subespaço gerado coincide com o próprio espaço V .

Considere agora apenas os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

As combinações lineares desses vetores são da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ 0 \end{bmatrix}.$$

Portanto,

$$W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} : x_1, x_2 \in \mathbb{R} \right\}.$$

O conjunto W é o plano $x_3 = 0$ contido em $\mathbb{R}^3$. Assim,

$$W \subsetneq V,$$

Os dois casos mostram que um subespaço gerado pode coincidir com todo o espaço ou possuir dimensão menor. Em um espaço vetorial de dimensão finita, um subespaço não pode ter dimensão maior que a do espaço que o contém.

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.6 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes.

Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.7 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

3.2.2 Independência linear e posto

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k], \quad \mathbf{A} \in \mathbb{R}^{p \times k}.$$

As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se,

$$\text{posto}(\mathbf{A}) = k.$$

Assim, o número de vetores linearmente independentes entre as colunas de $\mathbf{A}$ é determinado pelo posto da matriz.

Como

$$\text{posto}(\mathbf{A}) \leq \min(p, k),$$

não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Proposição 3.2 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*

2. Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.
3. Todo subconjunto de um conjunto linearmente independente também é linearmente independente.
4. Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.
5. Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.

A última propriedade fornece uma interpretação direta da redundância.

Proposição 3.3 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

Comprovação. Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente. $\square$

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.8 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.9 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.1 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Comprovação. Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única. □

Definição 3.6 (Coordenadas em uma base). Se

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.10 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

As coordenadas de um vetor em uma base são os coeficientes que indicam quanto de cada vetor da base é necessário para reconstruir esse vetor por combinação linear. Assim, o vetor de coordenadas não é o próprio vetor, mas a representação desse vetor em relação à base escolhida.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

A partir deste ponto, considere um subespaço $S \subseteq \mathbb{R}^p$ com o produto interno euclidiano.

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

de S é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base $\mathcal{B}$ de S é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker, a condição de ortonormalidade pode ser escrita como

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Teorema 3.2 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt. (Meyer, 2023)

Esse resultado garante que a geometria de um subespaço de dimensão finita pode ser descrita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Proposição 3.4 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de um subespaço $S \subseteq \mathbb{R}^p$, então todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Cada coordenada de $\mathbf{x}$ na base $\mathcal{B}$ pode ser obtida separadamente por

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}, \quad j = 1, \dots, k.$$

Portanto,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal, então $\mathbf{b}_j^\top \mathbf{b}_j = 1$ para todo j , de modo que

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

e

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Assim, em uma base ortogonal, cada coordenada pode ser determinada por meio de um produto interno, sem a necessidade de resolver simultaneamente um sistema linear. (Meyer, 2023)

Comprovação. Como $\mathcal{B}$ é uma base de S , todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados à esquerda por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal,

$$\mathbf{b}_j^\top \mathbf{b}_i = 0 \quad \text{para} \quad i \neq j.$$

Assim, todos os termos da soma com $i \neq j$ são nulos, restando

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j.$$

Como $\mathbf{b}_j \neq \mathbf{0}$,

$$\mathbf{b}_j^\top \mathbf{b}_j = \|\mathbf{b}_j\|^2 > 0,$$

e, portanto,

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Se a base é ortonormal, então $\|\mathbf{b}_j\| = 1$ e, consequentemente,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

Logo,

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

o que fornece diretamente as coordenadas de $\mathbf{x}$ na base ortonormal. $\square$

A Figura 3.3 compara três bases de $\mathbb{R}^2$ e destaca a diferença entre independência linear e ortogonalidade.




Figura 3.3: Comparação entre uma base canônica, uma base oblôqua e uma base ortonormal rotacionada de $\mathbb{R}^2$. O símbolo de ângulo reto identifica os pares de vetores ortogonais.

Na primeira e na terceira bases, os vetores são ortogonais e possuem norma igual a 1, como indicado pelos marcadores de ângulo reto. Portanto, ambas são bases ortonormais. Na base oblôqua, os vetores continuam sendo linearmente independentes e, por isso, formam uma base de $\mathbb{R}^2$, mas não são ortogonais.

3.2.7 Dimensão

Um espaço vetorial é denominado **finito-dimensional** quando possui uma base formada por um número finito de vetores.

Para que a dimensão possa ser definida pelo número de vetores de uma base, é necessário estabelecer primeiro que esse número não depende da base escolhida.

Teorema 3.3 (Número de vetores de uma base). *Se um espaço vetorial V possui uma base finita, então todas as bases de V são finitas e possuem a mesma quantidade de vetores. (Meyer, 2023)*

Definição 3.10 (Dimensão). Se as bases de um espaço vetorial finito-dimensional V possuem k vetores, a **dimensão** de V é definida por

$$\dim(V) = k.$$

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.11 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Proposição 3.5 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz está associada a subespaços determinados por suas linhas, por suas colunas e pelas soluções de sistemas lineares homogêneos. Esses subespaços permitem relacionar o posto, a dependência linear e as soluções de sistemas lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Serão estudados quatro subespaços associados a $\mathbf{A}$:

- o espaço coluna;
- o espaço linha;
- o espaço nulo;
- o espaço nulo à esquerda.

Os dois primeiros são construídos a partir das colunas e das linhas da matriz. Os dois últimos são determinados pelas soluções dos sistemas homogêneos associados, respectivamente, a $\mathbf{A}$ e a $\mathbf{A}^\top$.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\}.$$

Quando $\mathbf{A}$ é interpretada como a matriz associada a uma transformação linear, esse espaço corresponde ao **núcleo** da transformação. Essa interpretação será formalizada no capítulo seguinte.

O espaço nulo reúne todos os vetores $\mathbf{x} \in \mathbb{R}^p$ que são anulados pela multiplicação por $\mathbf{A}$, isto é, aqueles para os quais $\mathbf{Ax} = \mathbf{0}$.

Proposição 3.6 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

Comprovação. O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned} \mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}. \end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço. □

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.12 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_{.1} \quad \mathbf{a}_{.2} \quad \cdots \quad \mathbf{a}_{.p}] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_{.1}, \dots, \mathbf{a}_{.p} \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p},$$

o conjunto de todos os vetores que podem ser escritos na forma $\mathbf{Ax}$ coincide com o espaço gerado pelas colunas de $\mathbf{A}$:

$$\mathcal{C}(\mathbf{A}) = \{ \mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p \}.$$

Essa caracterização permite relacionar diretamente o espaço coluna à existência de soluções de sistemas lineares.

Proposição 3.7 (Consistência de um sistema linear). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Comprovação. Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{Ax},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_{.1} + \dots + x_p \mathbf{a}_{.p}.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtém-se

$$\mathbf{Ax} = \mathbf{b}.$$

□

Exemplo 3.13 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \mathbf{a}_3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base de $\mathcal{C}(\mathbf{A})$ pode ser formada por quaisquer vetores linearmente independentes que gerem esse espaço. Quando se deseja obter uma base selecionando colunas da própria matriz $\mathbf{A}$, as posições das colunas pivô podem ser identificadas por escalonamento. Nesse procedimento, os vetores da base são as colunas correspondentes da matriz original, e não as colunas da matriz escalonada.

3.3.3 Espaço linha

Definição 3.13 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.14 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.14 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto, todo vetor de $\mathcal{N}(\mathbf{A}^\top)$ é ortogonal a cada coluna de $\mathbf{A}$ e, conseqüentemente, a toda combinação linear dessas colunas. A relação entre o espaço nulo à esquerda e o complemento ortogonal do espaço coluna será formalizada adiante.

Exemplo 3.15 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Extensão de uma base

Uma base de um subespaço pode ser completada acrescentando vetores até formar uma base de todo o espaço. Esse resultado será utilizado na demonstração do Teorema Posto–Nulidade.

Teorema 3.4 (Extensão de uma base). *Seja W um subespaço de um espaço vetorial V de dimensão finita. Se*

$$\mathcal{B}_W = \{\mathbf{u}_1, \dots, \mathbf{u}_s\}$$

é uma base de W , então existem vetores $\mathbf{z}_1, \dots, \mathbf{z}_r \in V$ tais que

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

é uma base de V . (Meyer, 2023)

Comprovação. Se $\mathcal{B}_W$ já gera V , então $\mathcal{B}_W$ é uma base de V e nada precisa ser acrescentado. Caso contrário, existe um vetor $\mathbf{z}_1 \in V$ que não pertence ao subespaço gerado por $\mathcal{B}_W$. Assim,

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1\}$$

é linearmente independente.

Se esse conjunto ainda não gera V , escolhe-se um vetor $\mathbf{z}_2 \in V$ que não pertence ao subespaço gerado pelos vetores já selecionados. O novo conjunto continua linearmente independente.

Repetindo esse procedimento, acrescentam-se vetores enquanto o conjunto obtido não gerar V . Como V possui dimensão finita, não é possível acrescentar indefinidamente vetores linearmente independentes. Portanto, após um número finito de etapas, obtém-se um conjunto

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

que é linearmente independente e gera V . Logo, esse conjunto é uma base de V . $\square$

3.3.6 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.5 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Meyer, 2023)

Comprovação. Considere uma base do espaço nulo,

$$\mathcal{B}_\mathcal{N} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Pelo Teorema 3.4, essa base de $\mathcal{N}(\mathbf{A})$ pode ser completada para formar uma base de $\mathbb{R}^p$. Assim, existem vetores $\mathbf{w}_1, \dots, \mathbf{w}_r \in \mathbb{R}^p$ tais que

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$.

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j.$$

Portanto,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

geram $\mathcal{C}(\mathbf{A})$.

Para verificar a independência linear, suponha que

$$\sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j = \mathbf{0}.$$

Então,

$$\mathbf{A} \left(\sum_{j=1}^r \beta_j \mathbf{w}_j \right) = \mathbf{0},$$

de modo que

$$\sum_{j=1}^r \beta_j \mathbf{w}_j \in \mathcal{N}(\mathbf{A}).$$

Esse vetor também pertence a

$$\text{span}\{\mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$, a interseção entre esses dois subespaços contém somente o vetor nulo. Assim,

$$\beta_1 = \dots = \beta_r = 0.$$

Logo,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

formam uma base de $\mathcal{C}(\mathbf{A})$. Portanto,

$$r = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Logo,

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = p.$$

□

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Exemplo 3.16 (Aplicação do Teorema Posto–Nulidade). Para a matriz utilizada nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Assim, para $\mathbf{A} \in \mathbb{R}^{2 \times 3}$,

$$1 + 2 = 3,$$

confirmando que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = 3.$$

Aplicando o resultado a $\mathbf{A}^\top$,

$$1 + 1 = 2,$$

de modo que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = 2.$$

Os resultados correspondem, respectivamente, às dimensões dos espaços ambientes $\mathbb{R}^3$ e $\mathbb{R}^2$.

3.3.7 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os quatro espaços se organizam em dois espaços ambientes. O espaço coluna e o espaço nulo à esquerda são subespaços de $\mathbb{R}^n$, enquanto o espaço linha e o espaço nulo são subespaços de $\mathbb{R}^p$.

3.3.8 Complemento ortogonal

Definição 3.15 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S . Essa definição permite descrever relações importantes entre os quatro espaços fundamentais de uma matriz.

3.3.9 Relações de ortogonalidade

Teorema 3.6 (Ortogonalidade entre os espaços fundamentais). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Cada componente de $\mathbf{A}\mathbf{x}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, conseqüentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{A}\mathbf{x}$ é, portanto, igual a zero, de modo que

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

□

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

em $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

em $\mathbb{R}^n$.

A decomposição dos espaços ambientes em somas diretas desses pares será obtida posteriormente a partir do resultado geral sobre complementos ortogonais.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Além da geometria euclidiana, é possível definir outras geometrias atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Aprofundamento: produtos internos e geometrias induzidas

Leitura de aprofundamento

Esta subseção generaliza o produto interno euclidiano por meio de matrizes positivas definidas e apresenta as normas, distâncias e relações de ortogonalidade associadas a essa generalização. Esses conceitos serão retomados no estudo da distância de Mahalanobis, de geometrias determinadas por matrizes de covariâncias e de problemas de mínimos quadrados ponderados.

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.16 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Proposição 3.8 (Propriedades do produto interno induzido). *Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$,*

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn; Johnson, 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.17 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.1.1 Norma e distância induzidas

Definição 3.17 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.18 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned}\|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{[2 \quad 1] \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}.\end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.1.2 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no capítulo anterior.

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^{\top} \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.1.3 Relação com a geometria euclidiana

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned}\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}).\end{aligned}$$

Assim, o produto interno induzido por $\mathbf{M}$ pode ser interpretado como o produto interno euclidiano entre os vetores $\mathbf{C} \mathbf{x}$ e $\mathbf{C} \mathbf{y}$. Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma. Analogamente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$$




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

pode ser igual a zero mesmo quando $\mathbf{x} \neq \mathbf{y}$. Portanto, essa expressão define, em geral, uma **pseudodistância**.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.2 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.18 (Matriz de Gram). Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$ e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.19 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.3 Propriedades da matriz de Gram

Proposição 3.9 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$.

(Horn; Johnson, 2013)

Comprovação. A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

Além disso,

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = 0$$

se, e somente se,

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Portanto, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.
Para demonstrar a igualdade dos núcleos, suponha inicialmente que

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{c}^\top$,

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} = \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

Logo,

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

e, portanto,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}).$$

Reciprocamente, se

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

então

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{V}^\top \mathbf{0} = \mathbf{0},$$

de modo que

$$\mathcal{N}(\mathbf{V}) \subseteq \mathcal{N}(\mathbf{V}^\top \mathbf{V}).$$

Assim,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}).$$

Como $\mathbf{V}^\top \mathbf{V}$ e $\mathbf{V}$ possuem o mesmo número de colunas, a igualdade das nulidades e o Teorema Posto–Nulidade implicam

$$\text{posto}(\mathbf{V}^\top \mathbf{V}) = \text{posto}(\mathbf{V}).$$

□

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são linearmente dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.4 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.20 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.5 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela [3.2](#) resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij}x_{ik}$
$\mathbf{X}\mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.4.6 Propriedades do complemento ortogonal

O complemento ortogonal, introduzido anteriormente na descrição dos espaços fundamentais de uma matriz, será agora estudado para um subespaço arbitrário de $\mathbb{R}^p$.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Proposição 3.10 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

Comprovação. O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$(\alpha\mathbf{x} + \beta\mathbf{y})^\top \mathbf{s} = \alpha\mathbf{x}^\top \mathbf{s} + \beta\mathbf{y}^\top \mathbf{s} = 0.$$

Portanto,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$. □

Exemplo 3.21 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$

Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.4.7 Dimensão do complemento ortogonal

Proposição 3.11 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$

Comprovação. Seja

$$\dim(S) = k.$$

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Pelo Teorema 3.4, essa base de S pode ser completada para formar uma base de $\mathbb{R}^p$. Aplicando o processo de Gram–Schmidt aos vetores acrescentados, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k+1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

e, portanto,

$$\alpha_i = 0, \quad i = 1, \dots, k.$$

Logo,

$$\mathbf{x} = \sum_{j=k+1}^p \alpha_j \mathbf{q}_j,$$

de modo que

$$\{\mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}$$

é uma base de $S^\perp$.

Assim,

$$\dim(S^\perp) = p - k,$$

e, como $\dim(S) = k$,

$$\dim(S) + \dim(S^\perp) = p.$$

□

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Outra consequência importante é

$$(S^\perp)^\perp = S.$$

De fato,

$$S \subseteq (S^\perp)^\perp,$$

pois todo vetor de S é ortogonal a todos os vetores de $S^\perp$. Além disso,

$$\begin{aligned} \dim \left((S^\perp)^\perp \right) &= p - \dim(S^\perp) \\ &= p - (p - k) \\ &= k \\ &= \dim(S). \end{aligned}$$

Como um subespaço está contido no outro e ambos possuem a mesma dimensão,

$$(S^\perp)^\perp = S.$$

3.4.8 Decomposição ortogonal

Teorema 3.7 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

O símbolo $\oplus$ representa uma **soma direta**: cada vetor de $\mathbb{R}^p$ possui uma única decomposição como soma de um vetor pertencente a S e um vetor pertencente a $S^\perp$.

Comprovação. Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned}\mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0.\end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

e

$$\mathbf{r}_1, \mathbf{r}_2 \in S^\perp.$$

Então,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{r}_2 - \mathbf{r}_1.$$

O lado esquerdo pertence a S , enquanto o lado direito pertence a $S^\perp$. Portanto, esse vetor pertence a

$$S \cap S^\perp = \{\mathbf{0}\}.$$

Assim,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{0}$$

e

$$\mathbf{r}_2 - \mathbf{r}_1 = \mathbf{0}.$$

Logo,

$$\mathbf{s}_1 = \mathbf{s}_2 \quad \text{e} \quad \mathbf{r}_1 = \mathbf{r}_2.$$

Portanto, a decomposição é única. □

A decomposição separa $\mathbf{x}$ em duas componentes únicas: $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$. Na seção seguinte, veremos que $\mathbf{x}_S$ é precisamente a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.4.9 Decomposição dos espaços fundamentais

A decomposição ortogonal pode ser aplicada diretamente aos quatro espaços fundamentais de uma matriz.

Proposição 3.12 (Decomposição dos espaços fundamentais). *Para uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$,*

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

De fato, pelo Teorema 3.6,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Aplicando o Teorema 3.7,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

com $\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$ e $\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A})$.

Analogamente,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

e, portanto,

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^\top},$$

com $\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$ e $\mathbf{y}_{\mathcal{N}^\top} \in \mathcal{N}(\mathbf{A}^\top)$.

Os quatro espaços fundamentais formam, portanto, dois pares de subespaços ortogonais complementares: um em $\mathbb{R}^p$ e outro em $\mathbb{R}^n$.

3.5 Projeções ortogonais

O Teorema 3.7 estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor $\mathbf{x} \in \mathbb{R}^p$ admite uma decomposição única em uma componente pertencente a S e outra pertencente a $S^\perp$. Essa decomposição permite definir a projeção ortogonal sobre um subespaço.

Definição 3.19 (Projeção ortogonal). Seja S um subespaço de $\mathbb{R}^p$. Pela decomposição ortogonal, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

com $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

A **projeção ortogonal de $\mathbf{x}$ sobre S** é definida por

$$\text{proj}_S(\mathbf{x}) = \mathbf{x}_S.$$

Consequentemente,

$$\mathbf{x} - \text{proj}_S(\mathbf{x}) \in S^\perp.$$

A forma da projeção depende de como o subespaço S é representado. Começaremos pelo caso mais simples, em que S possui dimensão 1.

3.5.1 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Proposição 3.13 (Projeção sobre uma direção). *Se*

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

então a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Como $\mathbf{u}^\top \mathbf{x}$ é um escalar, pode-se escrever

$$\frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}).$$

Pela associatividade da multiplicação matricial,

$$\mathbf{u} (\mathbf{u}^\top \mathbf{x}) = (\mathbf{u} \mathbf{u}^\top) \mathbf{x}.$$

Portanto,

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}) \\ &= \frac{1}{\mathbf{u}^\top \mathbf{u}} (\mathbf{u} \mathbf{u}^\top) \mathbf{x} = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.22 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned}\mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top\mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{P}_S\mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição e destaca a ortogonalidade entre a projeção e o resíduo.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

3.5.2 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Proposição 3.14 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Meyer, 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.23 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.5.3 Projeção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subseção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Proposição 3.15 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre $\mathcal{C}(\mathbf{A})$ é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_\mathbf{A} \mathbf{x},$$

em que

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz $\mathbf{P}_\mathbf{A}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$, e não da base particular escolhida para representá-lo.

De fato, suponha que outra base do mesmo subespaço seja organizada em uma matriz

$$\mathbf{B} = \mathbf{A} \mathbf{R},$$

em que $\mathbf{R} \in \mathbb{R}^{k \times k}$ é invertível. Então

$$\begin{aligned} \mathbf{P}_\mathbf{B} &= \mathbf{B} (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \\ &= \mathbf{A} \mathbf{R} (\mathbf{R}^\top \mathbf{A}^\top \mathbf{A} \mathbf{R})^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} \mathbf{R} \mathbf{R}^{-1} (\mathbf{A}^\top \mathbf{A})^{-1} (\mathbf{R}^\top)^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_\mathbf{A}. \end{aligned}$$

Portanto, bases diferentes do mesmo subespaço produzem a mesma matriz de projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_\mathbf{A} = \mathbf{A} \mathbf{A}^\top.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top.$$

Portanto,

$$\mathbf{Q}\mathbf{Q}^\top$$

é o caso ortonormal da expressão geral

$$\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Exemplo 3.24 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned}
\mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\
&= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\
&= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}.
\end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.5.4 Propriedades da matriz de projeção

Proposição 3.16 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top,$$

então:

1. $\mathbf{P}_A$ é simétrica;
2. $\mathbf{P}_A$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})$;
4. $\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\text{posto}(\mathbf{P}_A) = \text{posto}(\mathbf{A}) = k$.

Comprovação. A simetria decorre de

$$\begin{aligned} \mathbf{P}_A^\top &= \left[\mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \right]^\top \\ &= \mathbf{A} \left[(\mathbf{A}^\top \mathbf{A})^{-1} \right]^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_A, \end{aligned}$$

pois $\mathbf{A}^\top \mathbf{A}$ e sua inversa são simétricas.

Para verificar a idempotência,

$$\begin{aligned} \mathbf{P}_A^2 &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_A. \end{aligned}$$

Para determinar o espaço coluna, observe inicialmente que, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{x} = \mathbf{A} \left[(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \right].$$

Portanto,

$$\mathbf{P}_A \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

e, conseqüentemente,

$$\mathcal{C}(\mathbf{P}_A) \subseteq \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A}),$$

então existe $\mathbf{c} \in \mathbb{R}^k$ tal que

$$\mathbf{y} = \mathbf{A}\mathbf{c}.$$

Assim,

$$\begin{aligned}\mathbf{P}_\mathbf{A}\mathbf{y} &= \mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top\mathbf{A}\mathbf{c} \\ &= \mathbf{A}\mathbf{c} \\ &= \mathbf{y}.\end{aligned}$$

Logo,

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{P}_\mathbf{A}),$$

e, portanto,

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}).$$

Para determinar o espaço nulo, observe que

$$\begin{aligned}\mathbf{A}^\top\mathbf{P}_\mathbf{A} &= \mathbf{A}^\top\mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top \\ &= \mathbf{A}^\top.\end{aligned}$$

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{P}_\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top\mathbf{x} = \mathbf{A}^\top\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{A}^\top \mathbf{x} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{0}.$$

Assim,

$$\mathcal{N}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Finalmente, como

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}),$$

tem-se

$$\text{posto}(\mathbf{P}_\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Como as k colunas de $\mathbf{A}$ são linearmente independentes,

$$\text{posto}(\mathbf{A}) = k.$$

Portanto,

$$\text{posto}(\mathbf{P}_\mathbf{A}) = k.$$

□

A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.5.5 Aprofundamento: projeção residual e complemento ortogonal

Leitura de aprofundamento

Esta seção desenvolve a matriz que projeta um vetor sobre o complemento ortogonal de um subespaço. Essa representação será retomada no estudo de mínimos quadrados, da Decomposição em Valores Singulares e do modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

com colunas linearmente independentes e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}} \mathbf{x}.$$

Definição 3.20 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Proposição 3.17 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
3. $\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$ e $\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}$;
4. $\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
6. se $\mathbf{A}$ possui posto k , então $\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k$.

Comprovação. Como $\mathbf{P}_{\mathbf{A}}$ é simétrica,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^\top &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}}.\end{aligned}$$

Portanto, $\mathbf{M}_{\mathbf{A}}$ é simétrica.

Para verificar a idempotência,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^2 &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^2 \\ &= \mathbf{I}_p - 2\mathbf{P}_{\mathbf{A}} + \mathbf{P}_{\mathbf{A}}^2 \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}},\end{aligned}$$

pois

$$\mathbf{P}_{\mathbf{A}}^2 = \mathbf{P}_{\mathbf{A}}.$$

Além disso,

$$\begin{aligned}\mathbf{P}_A \mathbf{M}_A &= \mathbf{P}_A (\mathbf{I}_p - \mathbf{P}_A) \\ &= \mathbf{P}_A - \mathbf{P}_A^2 \\ &= \mathbf{0},\end{aligned}$$

e, de forma análoga,

$$\mathbf{M}_A \mathbf{P}_A = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{M}_A \mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{M}_A \mathbf{x} \in \mathcal{N}(\mathbf{P}_A).$$

Como

$$\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp,$$

tem-se

$$\mathcal{C}(\mathbf{M}_A) \subseteq \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{P}_A \mathbf{y} = \mathbf{0},$$

e, portanto,

$$\begin{aligned}\mathbf{M}_A \mathbf{y} &= (\mathbf{I}_p - \mathbf{P}_A) \mathbf{y} \\ &= \mathbf{y}.\end{aligned}$$

Assim,

$$\mathcal{C}(\mathbf{A})^\perp \subseteq \mathcal{C}(\mathbf{M}_\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{M}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Agora, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{x}.$$

Consequentemente,

$$\mathbf{M}_\mathbf{A} \mathbf{x} = \mathbf{0},$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{M}_\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{M}_\mathbf{A}),$$

então

$$(\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \mathbf{P}_\mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{P}_\mathbf{A} \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

segue que

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Finalmente,

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\dim \mathcal{C}(\mathbf{A}) = k,$$

o teorema da dimensão do complemento ortogonal fornece

$$\dim \mathcal{C}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

Logo,

$$\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

□

3.5.6 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.8 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer, 2023)

Comprovação. Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

□

Portanto, a projeção ortogonal pode ser caracterizada equivalentemente como

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Assim, projetar ortogonalmente $\mathbf{x}$ sobre S equivale a encontrar, entre todos os vetores pertencentes a S , aquele que está mais próximo de $\mathbf{x}$ segundo a distância euclidiana.

Quando $S = \mathcal{C}(\mathbf{A})$, com $\mathbf{A} \in \mathbb{R}^{p \times k}$, todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente, o problema de melhor aproximação pode ser escrito como

$$\hat{\mathbf{c}} \in \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor mais próximo de $\mathbf{x}$ em $\mathcal{C}(\mathbf{A})$ é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa formulação estabelece a ligação entre projeção ortogonal e mínimos quadrados. O desenvolvimento algébrico dessa relação é apresentado a seguir como aprofundamento.

3.5.7 Aprofundamento: projeções e mínimos quadrados

Leitura de aprofundamento

Esta seção desenvolve algebricamente a relação entre projeção ortogonal e mínimos quadrados. As equações normais, os resíduos, as matrizes de projeção e a pseudoinversa serão retomados na Decomposição em Valores Singulares e no modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^k} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.8, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.21 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A} \hat{\beta} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\beta} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\beta} \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\ &= \mathbf{P}_\mathbf{A} \mathbf{b}, \end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned} \hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\ &= \mathbf{M}_\mathbf{A} \mathbf{b}. \end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Proposição 3.18 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub; Van Loan, 2013)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, o problema de mínimos quadrados pode possuir diferentes vetores de coeficientes que produzem o mesmo ajuste. Portanto, $\hat{\beta}$ pode não ser único.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$.

Utilizando a pseudoinversa de Moore–Penrose (ver Definição 2.17),

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

de modo que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^+.$$

A pseudoinversa foi introduzida no capítulo anterior. Sua construção por meio da Decomposição em Valores Singulares será desenvolvida posteriormente.

As projeções ponderadas podem ser obtidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será retomada no estudo de problemas de mínimos quadrados ponderados.

3.6 Síntese do capítulo

Os espaços vetoriais permitem organizar conjuntos de vetores que preservam as operações de adição e multiplicação por escalar. Dentro desses espaços, os subespaços representam estruturas lineares de menor dimensão, enquanto bases fornecem conjuntos de vetores linearmente independentes capazes de gerar todo o espaço considerado. Fixada uma base, cada vetor pode ser representado de maneira única por suas coordenadas nessa base.

A dimensão quantifica o número de direções independentes necessárias para representar um espaço. Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

essa ideia conduz aos quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}), \mathcal{L}(\mathbf{A}), \mathcal{N}(\mathbf{A}) \text{ e } \mathcal{N}(\mathbf{A}^\top).$$

Se $r = \text{posto}(\mathbf{A})$, suas dimensões são

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

As matrizes de Gram organizam produtos internos entre conjuntos de vetores. Para uma matriz $\mathbf{V}$,

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

é simétrica e semidefinida positiva, e sua estrutura permite relacionar produtos internos, independência linear e posto.

A decomposição ortogonal estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor pode ser escrito de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com $\text{proj}_S(\mathbf{x}) \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , a matriz de projeção é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Se $S = \mathcal{C}(\mathbf{A})$ e as colunas de $\mathbf{A}$ são linearmente independentes, a mesma projeção pode ser escrita como

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção ortogonal possui ainda uma interpretação por otimização:

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Essa propriedade estabelece a ligação entre geometria, projeções e problemas de mínimos quadrados.

As partes de aprofundamento generalizam a geometria euclidiana por meio de produtos internos induzidos por matrizes positivas definidas e desenvolvem a matriz de projeção residual, as equações normais, o caso de posto deficiente e a pseudoinversa. Esses resultados serão retomados quando sua utilização se tornar necessária nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- interpretar geração, dependência e independência linear;
- identificar bases e determinar dimensões;
- representar vetores por coordenadas em uma base;
- distinguir bases gerais, ortogonais e ortonormais;
- determinar e interpretar os quatro espaços fundamentais de uma matriz;
- relacionar posto, nulidade e dimensão;
- interpretar as relações de ortogonalidade entre os espaços fundamentais;
- construir e interpretar matrizes de Gram;
- determinar complementos ortogonais e decomposições ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar a projeção ortogonal como problema de melhor aproximação;
- reconhecer a relação geométrica entre projeções e mínimos quadrados.

No próximo capítulo, as matrizes serão estudadas como representações de transformações lineares entre espaços vetoriais. Os conceitos de base, dimensão, posto, espaços fundamentais e projeções desenvolvidos aqui permitirão interpretar como essas transformações atuam sobre vetores e subespaços. O espaço nulo e o espaço coluna também serão relacionados, nesse novo contexto, ao núcleo e à imagem da transformação associada a uma matriz.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada **transformação linear**.

No capítulo anterior, o espaço nulo e o espaço coluna foram definidos diretamente a partir de uma matriz. Neste capítulo, essas estruturas serão também interpretadas, respectivamente, como o núcleo e a imagem da transformação linear associada à matriz.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

Convenções para transformações lineares

As convenções vetoriais e matriciais estabelecidas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $T : V \rightarrow W$ representa uma transformação entre os espaços vetoriais V e W ;
- V representa o domínio e W o contradomínio da transformação;
- $\mathbf{x} \in V$ representa um vetor do domínio e $T(\mathbf{x}) \in W$ sua imagem pela transformação;
- $T_{\mathbf{A}}$ representa a transformação linear associada à matriz $\mathbf{A}$;
- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ quando utilizada na forma $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$;
- $\ker(T)$ representa o núcleo de uma transformação linear;
- $\text{Im}(T)$ representa a imagem de uma transformação linear;
- $\mathcal{E}_p$ representa a base canônica de $\mathbb{R}^p$;
- $[T]_{\mathcal{C} \leftarrow \mathcal{B}}$ representa a matriz de uma transformação em relação a uma base $\mathcal{B}$ do domínio e a uma base $\mathcal{C}$ do contradomínio.

As relações entre essas notações e os espaços fundamentais das matrizes serão estabelecidas ao longo do capítulo.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha\mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

Proposição 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

Comprovação. Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned}
T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\
&= T(\mathbf{u}) + T(-\mathbf{v}) \\
&= T(\mathbf{u}) - T(\mathbf{v}).
\end{aligned}$$

□

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Proposição 4.2 (Determinação de uma transformação por uma base). *Seja V um espaço vetorial de dimensão finita e seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_k).$$

(Meyer, 2023)

Comprovação. Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_k T(\mathbf{v}_k).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio fica determinada de maneira única. □

Exemplo 4.1 (Transformação determinada pelas imagens de uma base). Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\ &= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}. \end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Portanto, a matriz que representa T na base canônica é

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix},$$

cujas colunas são precisamente

$$T(\mathbf{e}_1) \quad \text{e} \quad T(\mathbf{e}_2).$$

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \dots + x_p T(\mathbf{e}_p) \\ &= x_1 \mathbf{a}_1 + \dots + x_p \mathbf{a}_p \\ &= \mathbf{A}\mathbf{x}. \end{aligned}$$

Isso estabelece a existência de uma matriz que representa T nas bases canônicas.

Para verificar a unicidade, suponha que outra matriz

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

também satisfaça

$$T(\mathbf{x}) = \mathbf{C}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Aplicando essa igualdade aos vetores da base canônica,

$$\mathbf{C}\mathbf{e}_j = T(\mathbf{e}_j) = \mathbf{A}\mathbf{e}_j, \quad j = 1, \dots, p.$$

Como $\mathbf{A}\mathbf{e}_j$ e $\mathbf{C}\mathbf{e}_j$ correspondem, respectivamente, às j -ésimas colunas de $\mathbf{A}$ e $\mathbf{C}$, todas as colunas das duas matrizes são iguais. Portanto,

$$\mathbf{C} = \mathbf{A}.$$

A matriz representante de T nas bases canônicas é, assim, única.

Proposição 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

(Meyer, 2023)

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned} T_{\mathbf{A}}(\alpha\mathbf{u} + \beta\mathbf{v}) &= \mathbf{A}(\alpha\mathbf{u} + \beta\mathbf{v}) \\ &= \alpha\mathbf{A}\mathbf{u} + \beta\mathbf{A}\mathbf{v} \\ &= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}). \end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Núcleo e imagem de uma transformação linear

Dois subespaços descrevem aspectos fundamentais da ação de uma transformação linear: os vetores do domínio que são enviados ao vetor nulo e os vetores do contradomínio que podem ser obtidos pela transformação.

Definição 4.2 (Núcleo e imagem de uma transformação linear). Seja

$$T : V \longrightarrow W$$

uma transformação linear.

O **núcleo** de T é o conjunto

$$\ker(T) = \{\mathbf{x} \in V : T(\mathbf{x}) = \mathbf{0}\}.$$

A **imagem** de T é o conjunto

$$\text{Im}(T) = \{T(\mathbf{x}) : \mathbf{x} \in V\}.$$

O núcleo é um subespaço do domínio V , enquanto a imagem é um subespaço do contradomínio W .

Para a transformação matricial

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax},$$

o núcleo é

$$\begin{aligned}\ker(T_{\mathbf{A}}) &= \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\} \\ &= \mathcal{N}(\mathbf{A}),\end{aligned}$$

e a imagem é

$$\begin{aligned}\operatorname{Im}(T_{\mathbf{A}}) &= \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p\} \\ &= \mathcal{C}(\mathbf{A}).\end{aligned}$$

Relação com os subespaços associados a uma matriz

O **espaço nulo** e o **espaço coluna** estudados no capítulo anterior correspondem, respectivamente, ao **núcleo** e à **imagem** da transformação linear associada à matriz $\mathbf{A}$:

$$\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}}), \quad \mathcal{C}(\mathbf{A}) = \operatorname{Im}(T_{\mathbf{A}}).$$

Se

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

o **contradomínio** é $\mathbb{R}^q$, enquanto a imagem é o subespaço efetivamente alcançado pela transformação,

$$\operatorname{Im}(T_{\mathbf{A}}) \subseteq \mathbb{R}^q.$$

4.1.4 Imagem de um subespaço

Considere um subespaço

$$S = \operatorname{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \cdots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Proposição 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Comprovação. A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A} \mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X} \mathbf{A}^\top.$$

□

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q] .$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q] .$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}_{\cdot j} = \mathbf{X}\mathbf{w}_j .$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip} .$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.2 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} .$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} ,$$

tem-se

$$\begin{aligned}
\mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\
&= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\
&= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}.
\end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned}
\mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\
&= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\
&= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}.
\end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}_{.1} = \mathbf{x}_{.1} + \mathbf{x}_{.2}.$$

A segunda é

$$\mathbf{y}_{.2} = 2\mathbf{x}_{.1} - \mathbf{x}_{.2}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, todas as observações transformadas pertencem a um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Assim, a dimensão da configuração transformada não pode exceder $\text{posto}(\mathbf{A})$, embora possa ser menor, dependendo da configuração original dos dados.

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando $r < p$, a transformação possui núcleo não trivial e elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, como a transformação modifica produtos internos, comprimentos e distâncias. Quando $\mathbf{A}$ possui posto completo nas colunas, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e determina um produto interno no domínio. Quando $\mathbf{A}$ não possui posto completo nas colunas, essa matriz é apenas semidefinida positiva e algumas direções são eliminadas pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

para os quais

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}^\top \mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Proposição 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

A ordem de aplicação das transformações é importante. Quando duas transformações atuam sobre o mesmo espaço,

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e

$$T_2 : \mathbb{R}^p \longrightarrow \mathbb{R}^p,$$

representadas, respectivamente, por

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{p \times p},$$

as duas composições

$$T_2 \circ T_1$$

e

$$T_1 \circ T_2$$

estão definidas. Suas matrizes representantes são, respectivamente,

$$\mathbf{BA}$$

e

$$\mathbf{AB}.$$

Como a multiplicação de matrizes não é, em geral, comutativa,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente, em geral,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

A igualdade pode ocorrer para transformações particulares, mas não constitui uma propriedade geral da composição.

Exemplo 4.3 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.3 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{Ax},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Proposição 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Comprovação. Tem-se

$$\begin{aligned} (\mathbf{BA})(\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B}(\mathbf{AA}^{-1})\mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1})(\mathbf{BA}) &= \mathbf{A}^{-1}(\mathbf{B}^{-1}\mathbf{B})\mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

□

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.4 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Proposição 4.7 (Caracterizações por núcleo, imagem e posto). *Seja*

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

com $\mathbf{A} \in \mathbb{R}^{q \times p}$. Então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

(Meyer, 2023)

Comprovação. Suponha inicialmente que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{Ax}_1 = \mathbf{Ax}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema [3.5](#),

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

Como $\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}})$, tem-se

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

Por outro lado, $T_{\mathbf{A}}$ é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à sua imagem. Como

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}),$$

a sobrejetividade equivale a

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim \mathcal{C}(\mathbf{A}) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

□

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando o Proposição 4.7 com o Teorema 2.5, obtém-se o resultado seguinte.

Proposição 4.8 (Equivalências para uma transformação linear associada a uma matriz quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $T_{\mathbf{A}}$ é invertível;
5. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
6. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
7. $\text{posto}(\mathbf{A}) = p$;
8. $\det(\mathbf{A}) \neq 0$;
9. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$

Propriedade	Condição geométrica	Condição matricial
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \ker(T_{\mathbf{A}}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \ker(T_{\mathbf{A}})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo núcleo da transformação, que coincide com o espaço nulo da matriz associada.

Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

O espaço nulo possui dimensão $p - r$. Portanto, existem $p - r$ direções linearmente independentes no domínio que são anuladas pela transformação, enquanto a imagem possui dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar

$$\text{posto}(\mathbf{A})$$

como a dimensão da imagem da transformação, isto é, como o número máximo de direções linearmente independentes que podem compor o espaço transformado. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam a posição da configuração em relação aos eixos coordenados sem deformar sua geometria, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;

- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}_\theta \mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}_\theta^\top \mathbf{Q}_\theta = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}_\theta^{-1} = \mathbf{Q}_\theta^\top = \mathbf{Q}_{-\theta}.$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}_\theta) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada **reflexão de Householder**.

Observe que as duas construções preservam componentes diferentes. A matriz $2\mathbf{u}\mathbf{u}^\top - \mathbf{I}$ preserva a componente na direção de $\mathbf{u}$ e inverte as componentes ortogonais a ela, enquanto $\mathbf{I} - 2\mathbf{u}\mathbf{u}^\top$ preserva as componentes ortogonais a $\mathbf{u}$ e inverte a componente na direção de $\mathbf{u}$.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é reescalada por um fator próprio, de modo que comprimentos, ângulos e proporções podem ser alterados. Se algum fator s_j for negativo, além da alteração de escala ocorre a inversão do sentido da coordenada correspondente.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned} y_1 &= x_1 + kx_2, \\ y_2 &= x_2. \end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det\left(\mathbf{C}_{ij}(k)\right) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

As projeções ortogonais foram desenvolvidas no capítulo anterior a partir da decomposição de um vetor em componentes pertencentes a subespaços ortogonais. Aqui, interessa interpretá-las como transformações lineares.

Considere uma direção unitária

$$\mathbf{u} \in \mathbb{R}^p, \quad \|\mathbf{u}\| = 1,$$

e o subespaço

$$S = \text{span}\{\mathbf{u}\}.$$

A matriz da projeção ortogonal sobre S é

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top,$$

de modo que

$$T_{\mathbf{P}_S}(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

Como estudado no capítulo anterior,

$$\mathbf{P}_S^2 = \mathbf{P}_S$$

e

$$\mathbf{P}_S^\top = \mathbf{P}_S.$$

Do ponto de vista das transformações lineares,

$$\text{Im}(T_{\mathbf{P}_S}) = S$$

e

$$\ker(T_{\mathbf{P}_S}) = S^\perp.$$

Assim, a projeção preserva a componente pertencente a S e elimina toda a componente pertencente a $S^\perp$.

Para uma projeção sobre uma única direção,

$$\text{posto}(\mathbf{P}_S) = 1.$$

Consequentemente, quando $p > 1$,

$$\det(\mathbf{P}_S) = 0,$$

e a transformação não é invertível. Vetores que diferem apenas por uma componente pertencente a $S^\perp$ possuem a mesma imagem.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário. Como todos os painéis utilizam a mesma escala, alterações de forma, área e dimensão podem ser comparadas diretamente.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

A rotação altera a posição do quadrado em relação aos eixos coordenados sem modificar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme modifica os comprimentos nas direções coordenadas e transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área, mostrando que preservar área não implica preservar ângulos ou comprimentos. A projeção elimina uma direção e reduz a figura a um segmento de reta.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Proposição 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$E \subseteq \mathbb{R}^p$$

um conjunto mensurável com volume p -dimensional finito. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se

$$\det(\mathbf{A}) = 0,$$

então

$$\text{posto}(\mathbf{A}) < p,$$

de modo que a imagem $\mathbf{A}E$ está contida em um subespaço próprio de $\mathbb{R}^p$. Consequentemente,

$$\text{Vol}_p(\mathbf{A}E) = 0.$$

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

Quando a transformação é invertível, o sinal do determinante descreve o efeito sobre a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida.

Se $\det(\mathbf{A}) = 0$, a transformação não é invertível, sua imagem possui dimensão inferior a p e o volume p -dimensional é reduzido a zero.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}_\theta$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Reescala direções coordenadas
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.18, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Proposição 4.10 (Preservação da geometria euclidiana). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, a transformação*

$$T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x}$$

preserva:

1. o produto interno;
2. as normas;
3. as distâncias euclidianas;
4. os ângulos entre vetores não nulos;
5. a ortogonalidade.

Comprovação. Pelo Teorema 2.7,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Portanto, o produto interno entre quaisquer dois vetores é preservado.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2.\end{aligned}$$

Como as normas são não negativas,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|.\end{aligned}$$

Logo, todas as distâncias euclidianas entre pares de vetores são preservadas.

Para vetores não nulos, o ângulo θ entre $\mathbf{x}$ e $\mathbf{y}$ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como o produto interno e as normas são preservados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados.

Em particular, se

$$\mathbf{x}^\top \mathbf{y} = 0,$$

então

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0,$$

e a ortogonalidade é preservada. □

Assim, transformações ortogonais preservam integralmente as relações métricas determinadas pelo produto interno euclidiano. Elas podem alterar a orientação da configuração, mas não deformam sua geometria interna.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Proposição 4.11 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top. \end{aligned}$$

□

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados não nulos.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Proposição 4.12 (Determinante de uma matriz ortogonal). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então*

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

Consequentemente,

$$|\det(\mathbf{Q})| = 1,$$

e a transformação preserva volumes p -dimensionais.

Comprovação. Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned} 1 &= \det(\mathbf{Q}^\top \mathbf{Q}) \\ &= \det(\mathbf{Q}^\top) \det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2. \end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Logo,

$$|\det(\mathbf{Q})| = 1.$$

□

No plano, a preservação do volume p -dimensional corresponde à preservação de áreas; em $\mathbb{R}^3$, corresponde à preservação de volumes.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no Capítulo 2. Portanto, as colunas de $\mathbf{Q}$ possuem norma unitária e são ortogonais duas a duas.

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também formam um conjunto ortonormal.

Uma matriz ortogonal admite, portanto, duas interpretações que devem ser distinguidas:

- como matriz de uma transformação linear que preserva a geometria euclidiana;
- como matriz cujas colunas constituem uma base ortonormal de $\mathbb{R}^p$.

Na primeira interpretação, a matriz atua sobre o vetor e modifica sua posição no espaço. Na segunda, seus vetores-coluna definem um sistema de coordenadas. A relação entre essas duas interpretações será desenvolvida na seção seguinte.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções inicialmente ortogonais. O marcador de ângulo reto identifica os casos em que a ortogonalidade é preservada.

A rotação e a reflexão mantêm a circunferência unitária e preservam o ângulo reto entre as duas direções. O escalonamento não uniforme transforma a circunferência em uma elipse; embora as duas direções coordenadas permaneçam ortogonais neste exemplo particular, seus comprimentos são alterados e a transformação não é ortogonal. O cisalhamento deforma a circunferência e também altera o ângulo entre as direções.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções inicialmente ortogonais.

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$, com a ordem dos vetores fixada. Como definido no capítulo anterior, a matriz formada pelos vetores da base é

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes, $\mathbf{B}$ é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Assim, $\mathbf{B}$ converte as coordenadas de $\mathbf{x}$ na base $\mathcal{B}$ em suas coordenadas na base canônica, enquanto $\mathbf{B}^{-1}$ realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{B}^{\top}\mathbf{B} = \mathbf{I}_p.$$

Logo,

$$\mathbf{B}^{-1} = \mathbf{B}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{\top}\mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top}\mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top}\mathbf{x} \end{bmatrix},$$

de modo que cada coordenada é obtida pelo produto interno entre $\mathbf{x}$ e o vetor correspondente da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$,

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\},$$

e as respectivas matrizes

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p]$$

e

$$\mathbf{C} = [\mathbf{c}_1 \quad \dots \quad \mathbf{c}_p].$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{C}[\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{C}[\mathbf{x}]_{\mathcal{C}} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando à esquerda por $\mathbf{C}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.5 (Matriz de mudança de base). A **matriz de mudança de base de $\mathcal{B}$ para $\mathcal{C}$** é

$$\mathbf{C}^{-1}\mathbf{B}.$$

Ela transforma as coordenadas de um vetor na base $\mathcal{B}$ em suas coordenadas na base $\mathcal{C}$:

$$[\mathbf{x}]_{\mathcal{C}} = (\mathbf{C}^{-1}\mathbf{B}) [\mathbf{x}]_{\mathcal{B}}.$$

O sentido da conversão deve ser observado na ordem das matrizes:

$$\mathcal{B} \longrightarrow \mathcal{C} \quad \Longleftrightarrow \quad \mathbf{C}^{-1}\mathbf{B}.$$

No sentido contrário, a matriz de mudança de base é

$$\mathbf{B}^{-1}\mathbf{C}.$$

As duas matrizes são inversas entre si:

$$\mathbf{B}^{-1}\mathbf{C} = (\mathbf{C}^{-1}\mathbf{B})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio, com matriz

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p],$$

e seja $\mathcal{C}$ uma base do contradomínio, com matriz

$$\mathbf{C} = [\mathbf{c}_1 \quad \cdots \quad \mathbf{c}_q].$$

Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{C}^{-1}T(\mathbf{x}) \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Proposição 4.13 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

A fórmula pode ser interpretada pela sequência das operações, da direita para a esquerda:

$$[\mathbf{x}]_{\mathcal{B}} \xrightarrow{\mathbf{B}} \mathbf{x} \xrightarrow{\mathbf{A}} T(\mathbf{x}) \xrightarrow{\mathbf{C}^{-1}} [T(\mathbf{x})]_{\mathcal{C}}.$$

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.4 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{C}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}
[T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{C}^{-1} \mathbf{A} \mathbf{B} \\
&= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\
&= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}.
\end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio,

$$[T]_{\mathcal{B} \leftarrow \mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Quando conveniente, essa matriz será denotada abreviadamente por

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Definição 4.6 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{D}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Proposição 4.14 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{D}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{D}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{D}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{D}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

Comprovação. Para o determinante,

$$\begin{aligned} \det(\mathbf{D}) &= \det(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}). \end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{D}) &= \text{tr}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) \\ &= \text{tr}(\mathbf{A} \mathbf{P} \mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}). \end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1} \mathbf{A} \mathbf{P}) = \text{posto}(\mathbf{A}).$$

□

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}_{\theta}$,

$$\mathbf{Q}_{\theta}^{-1} = \mathbf{Q}_{\theta}^{\top} = \mathbf{Q}_{(-\theta)}.$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$

Portanto, embora uma mesma matriz ortogonal possa aparecer nas duas interpretações, o sentido da operação é distinto: na transformação ativa, $\mathbf{Q}$ atua sobre o vetor; na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$, a conversão das coordenadas é realizada por $\mathbf{Q}^{-1} = \mathbf{Q}^\top$.

A Figura 4.7 compara as duas interpretações.




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa por $\mathbf{Q}$	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base formada pelas colunas de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.7 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui dimensão $n \times q$ e contém n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

As dimensões da transformação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} + \underbrace{\mathbf{1}_n}_{n \times 1} \underbrace{\mathbf{b}^\top}_{1 \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned}
\mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\
&= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\
&= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.
\end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. Em contraste, a aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Além disso,

$$\mathbf{H}_n = \mathbf{H}_n^\top$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Portanto, $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

seu núcleo é

$$\mathcal{N}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\},$$

e sua imagem é o subespaço

$$\mathcal{C}(\mathbf{H}_n) = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\} = \text{span}\{\mathbf{1}_n\}^\perp.$$

Assim, multiplicar uma variável observada por $\mathbf{H}_n$ equivale a projetá-la ortogonalmente sobre o subespaço dos vetores cujas componentes somam zero.

Como $\mathbf{H}_n$ é simétrica e

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{1}_n^\top \mathbf{H}_n \mathbf{X} = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Proposição 4.15 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Comprovação. Tem-se

$$\begin{aligned}\mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j.\end{aligned}$$

Logo, as duas diferenças possuem a mesma norma. □

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica, em geral, distâncias e ângulos. Alguns pares particulares de vetores podem manter sua relação angular, mas a geometria euclidiana não é preservada para todos os vetores. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada pela matriz positiva definida

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas. Quando todas as escalas são iguais, isto é,

$$\mathbf{L} = \ell \mathbf{I}_p,$$

o escalonamento é uniforme: todas as distâncias são multiplicadas pelo mesmo fator $1/\ell$ e os ângulos são preservados.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1, desde que todas as variáveis apresentem desvio-padrão amostral positivo.

A interpretação da padronização como transformação afim considera $\mathbf{m}$ e $\mathbf{L}$ fixados. Quando o vetor de médias e os desvios-padrão são calculados a partir da própria matriz de dados $\mathbf{X}$, esses elementos passam a depender dos dados. Nesse caso, para os valores calculados de $\mathbf{m}$ e $\mathbf{L}$, cada observação é submetida à transformação afim

$$\mathbf{x} \mapsto \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}),$$

mas a operação completa que associa a matriz original $\mathbf{X}$ à matriz padronizada $\mathbf{Z}$ é dependente dos dados e não constitui, globalmente, uma transformação afim de $\mathbf{X}$.

Para duas observações padronizadas,

$$\begin{aligned}\mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j) .\end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j) .$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}) .$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x} ,$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m} .$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1} \mathbf{m} .$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim de $\mathbb{R}^p$ em $\mathbb{R}^p$ é invertível se, e somente se, sua parte linear $\mathbf{A}$ é invertível.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos. O mesmo vetor de escalas é utilizado no escalonamento e na padronização, permitindo separar visualmente o efeito da alteração de escala do efeito da centralização.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as diferenças nem as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e, em geral, modifica comprimentos, distâncias e ângulos. A padronização combina esses dois efeitos: centraliza a nuvem e reescala suas coordenadas.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão para um vetor	Linear como função de $\mathbf{x}$?	Mantém a origem fixa?
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalação	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares podem modificar direção, escala ou dimensão, mas mantêm necessariamente a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando consideradas como operações sobre uma observação individual e para parâmetros de localização e escala fixados. Quando a centralização de uma matriz de dados é escrita como $\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$, a operação é linear no espaço das matrizes.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Para uma transformação

$$T : V \longrightarrow W,$$

tem-se

$$T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica, entre outras consequências,

$$T(\mathbf{0}) = \mathbf{0},$$

e permite determinar uma transformação linear a partir de sua ação sobre uma base do domínio.

Fixadas as bases do domínio e do contradomínio, uma transformação linear possui uma representação matricial única. Em particular, nas bases canônicas, uma transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Quando as observações ocupam as linhas de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea das observações é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^{\top}.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada, enquanto cada coluna corresponde a uma combinação linear das variáveis originais.

A matriz associada à transformação permite relacionar os conceitos desenvolvidos neste capítulo aos espaços fundamentais estudados anteriormente:

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o núcleo reúne os vetores eliminados pela transformação, enquanto a imagem contém todos os vetores que podem ser produzidos por ela. Pelo teorema posto-nulidade,

$$\dim \ker(T_{\mathbf{A}}) + \dim \operatorname{Im}(T_{\mathbf{A}}) = p,$$

ou, equivalentemente,

$$\dim \mathcal{N}(\mathbf{A}) + \operatorname{posto}(\mathbf{A}) = p.$$

O posto é, portanto, a dimensão da imagem da transformação. Quando o núcleo contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem e ocorre perda de informação.

Para uma transformação quadrada, as condições

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\},$$

$$\operatorname{Im}(T_{\mathbf{A}}) = \mathbb{R}^p,$$

$$\operatorname{posto}(\mathbf{A}) = p,$$

$$\det(\mathbf{A}) \neq 0$$

e a existência de $\mathbf{A}^{-1}$ são equivalentes.

A composição de transformações corresponde ao produto de suas matrizes. Se T_1 é representada por $\mathbf{A}_1$ e T_2 por $\mathbf{A}_2$, então

$$[T_2 \circ T_1] = \mathbf{A}_2 \mathbf{A}_1.$$

A matriz situada à direita atua primeiro. Como o produto matricial não é comutativo, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas ilustram diferentes efeitos possíveis sobre uma configuração. Rotações e reflexões são transformações ortogonais e preservam a geometria euclidiana. Escalonamentos alteram as escalas das direções coordenadas; cisalhamentos modificam, em geral, ângulos e comprimentos; projeções eliminam componentes pertencentes ao complemento do subespaço sobre o qual se projeta.

Para uma transformação quadrada,

$$|\det(\mathbf{A})|$$

representa o fator de alteração do volume p -dimensional. Quando $\det(\mathbf{A}) \neq 0$, seu sinal informa também o efeito sobre a orientação: valores positivos preservam a orientação e valores negativos a invertem. Se

$$\det(\mathbf{A}) = 0,$$

a transformação reduz a dimensão e o volume p -dimensional da imagem é igual a zero.

As transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos e, consequentemente, normas, distâncias, ângulos e ortogonalidade. Além disso,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) \in \{-1, 1\},$$

de modo que também preservam volumes p -dimensionais.

As colunas de uma matriz ortogonal formam uma base ortonormal e satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij}.$$

Essa propriedade estabelece a ligação entre transformações ortogonais e sistemas de coordenadas ortonormais.

Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

é uma base de $\mathbb{R}^p$ e

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p],$$

então

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Para duas bases $\mathcal{B}$ e $\mathcal{C}$, com matrizes $\mathbf{B}$ e $\mathbf{C}$, respectivamente, a conversão das coordenadas de $\mathcal{B}$ para $\mathcal{C}$ é

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Se uma transformação é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Quando a mesma base é utilizada no domínio e no contradomínio,

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B},$$

de modo que as duas matrizes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa e a mudança passiva de coordenadas devem ser diferenciadas. Se $\mathbf{Q}$ é ortogonal, na transformação ativa,

$$\mathbf{y} = \mathbf{Q}\mathbf{x},$$

enquanto, na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top}\mathbf{x}.$$

Na primeira situação, o vetor é transformado em relação a eixos fixos. Na segunda, o vetor geométrico permanece o mesmo e apenas sua representação em coordenadas é alterada.

As transformações afins generalizam as transformações lineares por meio da inclusão de uma translação:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização de uma observação em torno de um vetor fixo é uma transformação afim, enquanto o escalonamento é uma transformação linear diagonal. A padronização combina essas duas operações.

Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Como

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

a matriz $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Sua imagem é

$$\mathcal{C}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\}^\perp,$$

o subespaço dos vetores cujas componentes somam zero.

A Tabela 4.6 reúne algumas das principais expressões desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$	Transforma simultaneamente as observações
Núcleo	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$	Reúne os vetores enviados ao vetor nulo
Imagem	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$	Reúne os vetores alcançados pela transformação
Composição	$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{A}_2 \mathbf{A}_1 \mathbf{x}$	Aplica T_1 antes de T_2
Transformação inversa	$\mathbf{x} = \mathbf{A}^{-1} \mathbf{y}$	Recupera o vetor original quando $\mathbf{A}$ é invertível
Rotação	$\mathbf{Q}_\theta \mathbf{x}$	Preserva a geometria e a orientação

Objeto ou operação	Expressão	Interpretação
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria; seu efeito sobre a orientação é determinado pelo determinante
Escalonamento	$\mathbf{L}\mathbf{x}$	Reescala direções coordenadas
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração preservando volume no caso elementar
Projeção ortogonal	$\mathbf{P}_S\mathbf{x}$	Mantém a componente em S e elimina a componente em $S^\perp$
Coordenadas em uma base	$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}$	Representa o mesmo vetor na base $\mathcal{B}$
Mudança de $\mathcal{B}$ para $\mathcal{C}$	$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}$	Converte coordenadas entre bases
Transformação em bases gerais	$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}$	Representa a transformação nas bases escolhidas
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização dos dados	$\mathbf{X}_c = \mathbf{H}_n\mathbf{X}$	Projeta cada variável no subespaço de média zero
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

Ao final deste capítulo, o estudante deverá ser capaz de:

- reconhecer e verificar a linearidade de uma transformação;
- construir a matriz de uma transformação a partir da imagem de uma base;
- relacionar núcleo e imagem de uma transformação ao espaço nulo e ao espaço coluna da matriz associada;
- interpretar posto, injetividade, sobrejetividade, bijetividade e perda de informação;
- representar a composição e a inversão de transformações por operações matriciais;
- interpretar geometricamente rotações, reflexões, escalonamentos, cisalhamentos e projeções;
- relacionar o determinante à alteração de volume, à orientação e à redução de dimensão;
- reconhecer transformações ortogonais e interpretar as propriedades geométricas que elas preservam;
- converter coordenadas entre bases;
- representar uma transformação linear em bases distintas do domínio e do contradomínio;
- distinguir transformação ativa e mudança passiva de coordenadas;
- interpretar transformações afins, centralização, escalonamento e padronização;

- reconhecer a matriz de centralização como uma matriz de projeção ortogonal.

No próximo capítulo, serão estudadas direções especiais para as quais a ação de uma transformação linear produz um múltiplo escalar do próprio vetor,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Essas direções conduzem aos conceitos de autovetores, autovalores, autoespaços e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Vimos também que a matriz de um operador depende da base utilizada para representá-lo. Uma mudança de base pode produzir uma matriz mais simples, embora o operador linear permaneça o mesmo. Neste capítulo, procuraremos bases especialmente adaptadas à ação do operador.

Algumas direções possuem um comportamento particularmente simples: quando um vetor pertence a uma dessas direções, sua imagem permanece na mesma reta que passa pela origem. A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço.

Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. A diagonalização pode, portanto, ser interpretada como uma mudança para um sistema de coordenadas em que a transformação atua separadamente sobre cada direção da base.

Para matrizes simétricas reais, essa simplificação possui propriedades adicionais: todos os autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permitirá interpretar formas quadráticas, matrizes positivas definidas, elipsoides, funções de matrizes e problemas de otimização. Essas estruturas serão retomadas nos capítulos de SVD, covariâncias e técnicas multivariadas.

Convenções de notação

Ao longo deste capítulo:

- λ representa um autovalor;

- $\mathbf{v}$ representa um autovetor;
- $\mathcal{E}_\lambda$ representa o autoespaço associado a λ ;
- $m_a(\lambda)$ e $m_g(\lambda)$ representam, respectivamente, as multiplicidades algébrica e geométrica;
- $\mathcal{B}_\mathbf{A}$ representa uma base de autovetores de $\mathbf{A}$, quando tal base existe;
- $\mathbf{B}_\mathbf{A}$ representa a matriz formada pelos vetores da base $\mathcal{B}_\mathbf{A}$;
- $\Lambda_\mathbf{A}$ representa a matriz diagonal dos autovalores correspondente à ordenação escolhida dos autovetores;
- $\mathbf{Q}_\mathbf{A}$ representa uma matriz ortogonal de autovetores quando $\mathbf{A}$ é simétrica;
- Π_λ representa o projetor espectral associado ao autoespaço de λ ;
- $\mathcal{R}_\mathbf{A}(\mathbf{x})$ representa o quociente de Rayleigh.

Salvo indicação contrária, as interpretações geométricas serão desenvolvidas em espaços vetoriais reais. Autovalores e autovetores complexos serão considerados explicitamente quando necessário.

5.1 Direções invariantes, autovalores e autoespaços

Definição 5.1 (Subespaço invariante). Considere

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p.$$

O subespaço $\mathcal{W}$ é **invariante sob $\mathbf{A}$** quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo

$$\mathbf{w} \in \mathcal{W}.$$

Isso significa que a multiplicação por $\mathbf{A}$ transforma vetores de $\mathcal{W}$ em vetores que permanecem no próprio subespaço $\mathcal{W}$.

Um caso particularmente importante ocorre quando o subespaço invariante possui dimensão 1.

Seja

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span}\{\mathbf{v}\} = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Como $\mathbf{v} \neq \mathbf{0}$, o conjunto $\{\mathbf{v}\}$ é uma base de $\mathcal{W}$ e, portanto,

$$\dim(\mathcal{W}) = 1.$$

Geometricamente, $\mathcal{W}$ corresponde a uma reta que passa pela origem e está contida em $\mathbb{R}^p$.

Se $\mathcal{W}$ é invariante sob $\mathbf{A}$, então

$$\mathbf{A}\mathbf{v} \in \mathcal{W}.$$

Como todos os vetores de $\mathcal{W}$ são múltiplos escalares de $\mathbf{v}$, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Assim, a ação de $\mathbf{A}$ sobre $\mathbf{v}$ mantém sua imagem na mesma reta gerada por $\mathbf{v}$. A magnitude pode ser alterada e, dependendo do sinal de λ , também pode ocorrer mudança de sentido.

Exemplo 5.1 (Uma reta invariante em $\mathbb{R}^2$). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

e o vetor

$$\mathbf{v} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\},$$

que corresponde à reta

$$x_2 = x_1$$

em $\mathbb{R}^2$.

Aplicando $\mathbf{A}$ ao vetor $\mathbf{v}$,

$$\begin{aligned} \mathbf{A}\mathbf{v} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= 3\mathbf{v}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v} \in \mathcal{W},$$

e a reta $\mathcal{W}$ é invariante sob $\mathbf{A}$. Nesse caso, a transformação multiplica os vetores dessa direção por um fator igual a 3, sem retirar suas imagens da reta.

A relação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

observada nesse caso conduz às definições de autovalor e autovetor.

Definição 5.2 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.2 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{Ax} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$. As retas tracejadas em cinza representam as duas direções invariantes.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

Um autovetor não é único. Se $\mathbf{v}$ é um autovetor associado ao autovalor λ , então qualquer múltiplo não nulo de $\mathbf{v}$ também é um autovetor associado ao mesmo autovalor.

Proposição 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

Comprovação. Como

$$\mathbf{Av} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned} \mathbf{A}(c\mathbf{v}) &= c\mathbf{Av} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}). \end{aligned}$$




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ . □

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.3 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Proposição 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

Comprovação. Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda\mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$. □

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição do autoespaço transforma a busca por autovetores em um problema de núcleo. Para um valor fixado de λ , existem autovetores associados precisamente quando

$$\mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p) \neq \{\mathbf{0}\}.$$

Resta, portanto, determinar quais valores de λ tornam esse núcleo não trivial. Essa condição equivale à singularidade de $\mathbf{A} - \lambda \mathbf{I}_p$ e conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo.

Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.1 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Comprovação. Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$. □

Definição 5.4 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn; Johnson, 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ($\theta = \frac{\pi}{2}$),

$$\mathbf{Q}_{\frac{\pi}{2}} = \begin{bmatrix} \cos\left(\frac{\pi}{2}\right) & -\sin\left(\frac{\pi}{2}\right) \\ \sin\left(\frac{\pi}{2}\right) & \cos\left(\frac{\pi}{2}\right) \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovalores reais e, conseqüentemente, não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando a mesma matriz é considerada como um operador em $\mathbb{C}^2$, ela possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente no contexto real. Em particular, toda matriz simétrica real possui autovalores reais e admite uma base ortonormal de autovetores reais.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.2 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

Comprovação. A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \dots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes. $\square$

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.5 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Exemplo 5.3 (Mesma multiplicidade algébrica e diferentes multiplicidades geométricas). Considere as matrizes

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Polinômio característico e multiplicidade algébrica

Para $\mathbf{A}_1$,

$$\begin{aligned} p_{\mathbf{A}_1}(\lambda) &= \det(\mathbf{A}_1 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Para $\mathbf{A}_2$,

$$\begin{aligned} p_{\mathbf{A}_2}(\lambda) &= \det(\mathbf{A}_2 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 1 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Portanto, as duas matrizes possuem o mesmo polinômio característico,

$$p(\lambda) = (2 - \lambda)^2,$$

e, conseqüentemente, o mesmo autovalor,

$$\lambda = 2.$$

Como o fator $(2 - \lambda)$ aparece duas vezes no polinômio característico, o autovalor $\lambda = 2$ possui multiplicidade algébrica

$$m_a(2) = 2$$

para ambas as matrizes.

Autoespaço de $\mathbf{A}_1$

Para determinar o autoespaço associado a $\lambda = 2$, procuramos todos os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$\mathbf{A}_1 \mathbf{v} = 2\mathbf{v}.$$

Essa equação pode ser escrita como

$$(\mathbf{A}_1 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando a matriz,

$$\begin{aligned}\mathbf{A}_1 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.\end{aligned}$$

Assim, o sistema a ser resolvido é

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

ou seja,

$$\begin{cases} 0 = 0, \\ 0 = 0. \end{cases}$$

O sistema não impõe nenhuma restrição sobre v_1 e v_2 . Portanto, ambos são livres e qualquer vetor de $\mathbb{R}^2$ pertence ao espaço nulo de $\mathbf{A}_1 - 2\mathbf{I}_2$.

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_1 - 2\mathbf{I}_2) = \mathbb{R}^2.$$

Como

$$\dim(\mathbb{R}^2) = 2,$$

temos

$$m_g(2) = \dim(E_2) = 2.$$

Assim, todo vetor não nulo de $\mathbb{R}^2$ é um autovetor de $\mathbf{A}_1$ associado ao autovalor $\lambda = 2$.

Autoespaço de $\mathbf{A}_2$

Para $\mathbf{A}_2$, procuramos novamente os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$(\mathbf{A}_2 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando,

$$\begin{aligned} \mathbf{A}_2 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Efetuando a multiplicação,

$$\begin{bmatrix} v_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

o que corresponde ao sistema

$$\begin{cases} v_2 = 0, \\ 0 = 0. \end{cases}$$

Nesse caso, v_2 deve ser igual a zero, enquanto v_1 permanece livre. Assim, todo vetor do autoespaço possui a forma

$$\mathbf{v} = \begin{bmatrix} v_1 \\ 0 \end{bmatrix} = v_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_2 - 2\mathbf{I}_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}.$$

Esse autoespaço possui uma única direção linearmente independente. Portanto,

$$m_g(2) = \dim(E_2) = 1.$$

As duas matrizes possuem, portanto, o mesmo autovalor $\lambda = 2$ e a mesma multiplicidade algébrica,

$$m_a(2) = 2,$$

mas apresentam multiplicidades geométricas diferentes:

$$m_g(2) = \begin{cases} 2, & \text{para } \mathbf{A}_1, \\ 1, & \text{para } \mathbf{A}_2. \end{cases}$$

A diferença decorre da dimensão dos respectivos autoespaços. Para $\mathbf{A}_1$, o autoespaço é todo o plano $\mathbb{R}^2$; para $\mathbf{A}_2$, o autoespaço é apenas a reta gerada por $(1, 0)^\top$.

A Figura 5.2 compara as estruturas dos dois autoespaços.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

No capítulo anterior, vimos que a matriz de um operador depende da base utilizada para representá-lo. A diagonalização corresponde à escolha de uma base particularmente conveniente: uma base formada por autovetores.

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e suponha que exista uma base de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

A matriz dessa base é

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Como os vetores da base são linearmente independentes, $\mathbf{B}_{\mathbf{A}}$ é invertível.

Se

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad j = 1, \dots, p,$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

então

$$\mathbf{A}\mathbf{B}_{\mathbf{A}} = \mathbf{B}_{\mathbf{A}}\Lambda_{\mathbf{A}}.$$

Multiplicando à esquerda por $\mathbf{B}_{\mathbf{A}}^{-1}$,

$$\mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Definição 5.6 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existe uma base $\mathcal{B}_{\mathbf{A}}$ de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Equivalentemente, existem uma matriz invertível $\mathbf{B}_{\mathbf{A}}$ e uma matriz diagonal $\Lambda_{\mathbf{A}}$ tais que

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A ordem das colunas de $\mathbf{B}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Pela notação de mudança de base desenvolvida no capítulo anterior,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Assim, $\Lambda_{\mathbf{A}}$ é a matriz do mesmo operador quando tanto o domínio quanto o contradomínio são representados na base de autovetores.

Para qualquer vetor $\mathbf{x} \in \mathbb{R}^p$, suas coordenadas nessa base são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{x},$$

de modo que

$$\mathbf{x} = \mathbf{B}_{\mathbf{A}} \mathbf{z}.$$

Nas coordenadas da base de autovetores,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}} [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Como

$$\Lambda_{\mathbf{A}} \mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix},$$

a transformação atua separadamente sobre cada coordenada: a componente correspondente ao autovetor $\mathbf{v}_j$ é multiplicada por λ_j .

A diagonalização é, portanto, uma mudança para um sistema de coordenadas no qual as direções da base são invariantes e a ação do operador deixa de misturar coordenadas.

Teorema 5.3 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

- 1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;*
- 2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;*
- 3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. a soma das dimensões dos autoespaços é igual a p ;*
- 5. para cada autovalor λ ,*

$$m_g(\lambda) = m_a(\lambda).$$

(Horn; Johnson, 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.2 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \\ &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{B}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{B}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Assim, a aplicação repetida do operador pode ser analisada coordenada a coordenada na base de autovetores: após k aplicações, a coordenada associada a $\mathbf{v}_j$ é multiplicada por λ_j^k .

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.4 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

- 1. todos os autovalores de $\mathbf{A}$ são reais;*
- 2. autoespaços associados a autovalores distintos são ortogonais;*
- 3. existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_\mathbf{A} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

(Horn; Johnson, 2013)

Comprovação. Para demonstrar que os autovalores são reais, considere um autovalor possivelmente complexo λ e um autovetor complexo não nulo $\mathbf{z}$, de modo que

$$\mathbf{A}\mathbf{z} = \lambda\mathbf{z}.$$

Como $\mathbf{A}$ é real e simétrica, ela também é hermitiana:

$$\mathbf{A}^* = \mathbf{A},$$

em que $*$ representa a transposta conjugada.

Multiplicando a equação de autovalor à esquerda por $\mathbf{z}^*$,

$$\mathbf{z}^* \mathbf{A} \mathbf{z} = \lambda \mathbf{z}^* \mathbf{z}.$$

A quantidade

$$\mathbf{z}^* \mathbf{A} \mathbf{z}$$

é real, pois

$$(\mathbf{z}^* \mathbf{A} \mathbf{z})^* = \mathbf{z}^* \mathbf{A}^* \mathbf{z} = \mathbf{z}^* \mathbf{A} \mathbf{z}.$$

Além disso,

$$\mathbf{z}^* \mathbf{z} > 0.$$

Portanto,

$$\lambda = \frac{\mathbf{z}^* \mathbf{A} \mathbf{z}}{\mathbf{z}^* \mathbf{z}}$$

é real.

Considere agora dois autovetores reais $\mathbf{v}_i$ e $\mathbf{v}_j$, associados a autovalores distintos λ_i e λ_j . Como

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j\mathbf{v}_j,$$

tem-se

$$\begin{aligned}\lambda_i\mathbf{v}_i^\top\mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}^\top\mathbf{v}_j \\ &= \mathbf{v}_i^\top\mathbf{A}\mathbf{v}_j \\ &= \lambda_j\mathbf{v}_i^\top\mathbf{v}_j.\end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j)\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top\mathbf{v}_j = 0.$$

Portanto, os autoespaços associados a autovalores distintos são ortogonais.

A existência de uma base ortonormal de autovetores pode ser demonstrada por indução sobre a ordem p da matriz. Para $p = 1$, o resultado é imediato.

Suponha agora $p > 1$. Pelo Teorema Fundamental da Álgebra, o polinômio característico de $\mathbf{A}$ possui pelo menos uma raiz em $\mathbb{C}$. Pela primeira parte da demonstração, essa raiz é real. Denote-a por λ_1 .

Como

$$\det(\mathbf{A} - \lambda_1\mathbf{I}_p) = 0,$$

a matriz real

$$\mathbf{A} - \lambda_1\mathbf{I}_p$$

é singular e possui um vetor não nulo real em seu núcleo. Normalizando esse vetor, obtém-se um autovetor unitário $\mathbf{q}_1$.

Considere o complemento ortogonal

$$\mathcal{W} = \text{span} \{ \mathbf{q}_1 \}^\perp.$$

Para qualquer $\mathbf{x} \in \mathcal{W}$,

$$\mathbf{q}_1^\top \mathbf{x} = 0.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \mathbf{q}_1^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{q}_1)^\top \mathbf{x} \\ &= \lambda_1 \mathbf{q}_1^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{x} \in \mathcal{W},$$

e $\mathcal{W}$ é invariante sob $\mathbf{A}$.

A restrição de $\mathbf{A}$ a $\mathcal{W}$ permanece simétrica. Como

$$\dim(\mathcal{W}) = p - 1,$$

a hipótese de indução garante uma base ortonormal

$$\mathbf{q}_2, \dots, \mathbf{q}_p$$

de $\mathcal{W}$ formada por autovetores da restrição e, consequentemente, de $\mathbf{A}$.

Assim,

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$ composta por autovetores de $\mathbf{A}$.

Organizando esses vetores nas colunas de

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

tem-se

$$\mathbf{Q}_A^\top \mathbf{Q}_A = \mathbf{I}_p.$$

Portanto,

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Definindo

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a relação

$$\mathbf{A} \mathbf{Q}_A = \mathbf{Q}_A \Lambda_A$$

fornece

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

□

A representação

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela é uma diagonalização ortogonal.

Considere a base ortonormal de autovetores

$$\mathcal{B}_A = \{\mathbf{q}_1, \dots, \mathbf{q}_p\}.$$

A matriz dessa base é

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p].$$

Assim, no caso simétrico, a matriz da base de autovetores introduzida na seção anterior pode ser escolhida ortogonal:

$$\mathbf{B}_A = \mathbf{Q}_A,$$

com

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Pela notação de coordenadas desenvolvida no capítulo anterior,

$$[\mathbf{x}]_{\mathcal{B}_A} = \mathbf{Q}_A^\top \mathbf{x}.$$

Denotando

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_A},$$

tem-se

$$\mathbf{x} = \mathbf{Q}_A \mathbf{z}.$$

A matriz do operador nessa base é

$$[T_A]_{\mathcal{B}_A \leftarrow \mathcal{B}_A} = \mathbf{Q}_A^\top \mathbf{A} \mathbf{Q}_A = \Lambda_A.$$

Consequentemente,

$$[T_A(\mathbf{x})]_{\mathcal{B}_A} = \Lambda_A [\mathbf{x}]_{\mathcal{B}_A}.$$

Em coordenadas canônicas,

$$\begin{aligned} \mathbf{A} \mathbf{x} &= \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top \mathbf{x} \\ &= \mathbf{Q}_A \Lambda_A \mathbf{z}. \end{aligned}$$

A ação da matriz pode ser interpretada em três etapas:

1. $\mathbf{Q}_A^\top$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. Λ_A multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_A$ reconstrói o vetor nas coordenadas canônicas.

Assim, uma matriz simétrica atua por fatores escalares independentes em direções ortogonais. Quando algum autovalor é negativo, o escalonamento na direção correspondente inclui também a inversão do sentido.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.4 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \mathbf{q}_2\}$$

é uma base ortonormal de autovetores de $\mathbb{R}^2$.

A matriz dessa base é a matriz ortogonal

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a circunferência unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária em $\mathbb{R}^p$ são determinados por

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por fatores escalares independentes.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{Ax} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Proposição 5.3 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn; Johnson, 2013)

Comprovação. As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Proposição 3.16, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned} \Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h \mathbf{Q}_h^\top \mathbf{Q}_\ell \mathbf{Q}_\ell^\top \\ &= \mathbf{0}. \end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

□

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_{\lambda} = \mathbf{q}\mathbf{q}^{\top}.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_{\mathbf{A}}$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Proposição 5.4 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

Comprovação. Pela propriedade cíclica do traço,

$$\begin{aligned} \text{tr}(\mathbf{A}) &= \text{tr}(\mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \text{tr}(\Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{Q}_{\mathbf{A}}) \\ &= \text{tr}(\Lambda_{\mathbf{A}}) \\ &= \sum_{j=1}^p \lambda_j. \end{aligned}$$

Para o determinante,

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{Q}_{\mathbf{A}}) \det(\Lambda_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) \\ &= \det(\Lambda_{\mathbf{A}}), \end{aligned}$$

pois

$$\det(\mathbf{Q}_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_{\mathbf{A}}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ são semelhantes, pois

$$\Lambda_{\mathbf{A}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{A} \mathbf{Q}_{\mathbf{A}}.$$

Como a multiplicação à esquerda e à direita por matrizes invertíveis preserva o posto, $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned} \dim \mathcal{N}(\mathbf{A}) &= p - \text{posto}(\mathbf{A}) \\ &= \# \{j : \lambda_j = 0\}. \end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos. □

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Proposição 5.5 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}$$

é a decomposição espectral de uma matriz simétrica, então

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^{\perp},$$

ou, equivalentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

Comprovação. Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores associados a autovalores nulos são ortogonais aos autovetores associados a autovalores não nulos, e juntos formam uma base ortonormal de $\mathbb{R}^p$, os dois subespaços são complementos ortogonais. $\square$

O autoespaço associado ao autovalor zero reúne exatamente as direções eliminadas pela transformação. Os autoespaços associados a autovalores não nulos constituem, em conjunto, a imagem da transformação.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.23, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são determinadas pelos sinais dos autovalores, enquanto o valor assumido para um vetor específico depende também de suas coordenadas espectrais $z_1, \dots, z_p$.

Exemplo 5.5 (Forma quadrática em coordenadas espectrais). Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 3 \quad \text{e} \quad \lambda_2 = 1,$$

com autovetores ortonormais associados

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{Q}_\mathbf{A} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda_\mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral de $\mathbf{A}$ é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Considere agora o vetor

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Nas coordenadas originais, a forma quadrática é

$$\begin{aligned}q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\&= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\&= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} \\&= 14.\end{aligned}$$

Equivalentemente, escrevendo a forma quadrática em função das coordenadas originais,

$$q_{\mathbf{A}}(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 2x_2^2.$$

Observe a presença do produto cruzado $2x_1x_2$.

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x}.$$

Como

$$\mathbf{Q}_{\mathbf{A}}^{\top} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{z} &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\&= \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}.\end{aligned}$$

Portanto,

$$z_1 = \frac{3}{\sqrt{2}} \quad \text{e} \quad z_2 = \frac{1}{\sqrt{2}}.$$

Nas coordenadas espectrais, a mesma forma quadrática é

$$\begin{aligned}
q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\
&= \lambda_1 z_1^2 + \lambda_2 z_2^2 \\
&= 3 \left(\frac{3}{\sqrt{2}} \right)^2 + 1 \left(\frac{1}{\sqrt{2}} \right)^2 \\
&= 3 \left(\frac{9}{2} \right) + \frac{1}{2} \\
&= 14.
\end{aligned}$$

Assim, nas coordenadas espectrais,

$$q_{\mathbf{A}}(\mathbf{x}) = 3z_1^2 + z_2^2,$$

sem produtos cruzados. A mudança de coordenadas não altera o valor da forma quadrática; ela apenas a expressa em uma base na qual a matriz é diagonal.

Proposição 5.6 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn; Johnson, 2013)

Comprovação. Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos. $\square$

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{(c/\lambda_j)} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.6 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^\top \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^\top \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

O termo cruzado $2x_1x_2$ presente nas coordenadas canônicas desaparece nas coordenadas espectrais porque os eixos coordenados passam a coincidir com as direções principais da forma quadrática.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh

Definição 5.7 (Quociente de Rayleigh). Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$. O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma euclidiana de $\mathbf{a}$.

Quando $\mathbf{A}$ é definida positiva, a forma quadrática também pode ser escrita como

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{A}},$$

em que $\langle \cdot, \cdot \rangle_{\mathbf{A}}$ é o produto interno induzido por $\mathbf{A}$, definido em Definição 3.16.

A divisão por $\|\mathbf{a}\|^2$ remove o efeito da magnitude do vetor. Consequentemente, o quociente de Rayleigh depende da direção determinada por $\mathbf{a}$, e não de seu comprimento.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}). \end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

As coordenadas de $\mathbf{a}$ na base espectral são

$$\mathbf{z} = [\mathbf{a}]_{\mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{a},$$

de modo que

$$\mathbf{a} = \mathbf{Q}_\mathbf{A} \mathbf{z}.$$

Como $\mathbf{Q}_\mathbf{A}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda_\mathbf{A} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

Portanto,

$$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é, portanto, uma média ponderada dos autovalores. Para uma base espectral fixada, ω_j mede a proporção do comprimento ao quadrado de $\mathbf{a}$ associada à direção $\mathbf{q}_j$.

Quando um autovalor λ possui multiplicidade maior que 1, a quantidade intrínseca ao autoespaço correspondente é a soma dos pesos associados aos vetores de uma base ortonormal desse autoespaço. Essa soma é igual à proporção do comprimento ao quadrado da projeção de $\mathbf{a}$ sobre $\mathcal{E}_\lambda$.

Teorema 5.5 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço associado a λ_p . (Horn; Johnson, 2013)

Comprovação. Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido. □

Se o maior autovalor é simples, a reta que maximiza o quociente é

$$\text{span}\{\mathbf{q}_1\}.$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

Exemplo 5.7 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da circunferência unitária.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.

5.5.2 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição de norma separa a escolha da **direção** da escolha da magnitude do vetor. De fato,

$$(c\mathbf{a})^{\top} \mathbf{A} (c\mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}.$$

Portanto, sem uma normalização, o valor da forma quadrática pode ser alterado simplesmente pelo escalonamento do vetor, mesmo quando sua direção permanece a mesma.

Se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

o problema de maximização sem restrição é ilimitado superiormente. Analogamente, se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} < 0,$$

o problema de minimização sem restrição é ilimitado inferiormente.

A condição

$$\mathbf{a}^{\top} \mathbf{a} = 1$$

elimina esse efeito de escala e restringe a otimização às direções representadas por vetores unitários.

5.5.3 Multiplicadores de Lagrange

Em diferentes problemas da Estatística Multivariada, procura-se uma **direção** no espaço das variáveis que torne máxima ou mínima alguma quantidade de interesse. Essa quantidade pode representar, por exemplo, variabilidade, separação entre grupos ou associação entre conjuntos de variáveis.

Uma direção pode ser representada por um vetor $\mathbf{a}$. Entretanto, os vetores $\mathbf{a}$ e $c\mathbf{a}$, para $c \neq 0$, representam a mesma direção, embora tenham comprimentos diferentes. Por isso, quando o interesse está apenas na direção, é conveniente impor a normalização

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Essa restrição faz com que a busca seja realizada sobre o conjunto dos vetores unitários. Geometricamente, em $\mathbb{R}^p$, esses vetores formam a esfera unitária.

Considere agora a forma quadrática

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica. O problema consiste em investigar como o valor de $f(\mathbf{a})$ varia quando a direção $\mathbf{a}$ percorre a esfera unitária.

5.5.3.1 O que é um ponto estacionário sob uma restrição?

Em um problema sem restrições, um ponto estacionário de uma função diferenciável é um ponto no qual seu gradiente é nulo. Em um problema com restrição, essa condição precisa ser modificada, pois nem todas as direções de deslocamento são permitidas.

Neste caso, $\mathbf{a}$ deve permanecer sobre a esfera

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um ponto é estacionário para o problema restrito quando pequenas alterações de $\mathbf{a}$ que respeitam essa restrição não produzem, em primeira ordem, aumento ou redução da função objetivo.

Geometricamente, isso ocorre quando o gradiente da função objetivo não possui componente na direção tangente à superfície da restrição. De forma equivalente, o gradiente da função objetivo deve ser proporcional ao gradiente da função que define a restrição.

Essa condição é obtida pelo método dos multiplicadores de Lagrange.

Considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem para um ponto estacionário é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A} \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que as direções estacionárias do problema são precisamente direções de autovetores de $\mathbf{A}$. O multiplicador de Lagrange η é o autovalor associado à direção encontrada.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \eta \mathbf{a}^\top \mathbf{a} \\ &= \eta,\end{aligned}$$

pois $\mathbf{a}^\top \mathbf{a} = 1$.

Assim, quando $\mathbf{a}$ é um autovetor unitário associado ao autovalor λ ,

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Portanto, há uma correspondência direta:

direção estacionária $\leftrightarrow$ autovetor

e

valor da forma quadrática nessa direção $\leftrightarrow$ autovalor.

Como $\mathbf{A}$ é simétrica, seus autovalores são reais. Além disso, pelos resultados do quociente de Rayleigh, para todo vetor unitário $\mathbf{a}$,

$$\lambda_{\min} \leq \mathbf{a}^\top \mathbf{A} \mathbf{a} \leq \lambda_{\max}.$$

Os extremos são atingidos nos autoespaços associados ao menor e ao maior autovalor. Consequentemente,

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\max},$$

e

$$\min_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\min}.$$

Assim:

- o maior autovalor fornece o máximo global da forma quadrática sobre a esfera unitária;
- o menor autovalor fornece o mínimo global;

- os demais autovalores correspondem a valores estacionários intermediários;
- os autovetores associados fornecem as respectivas direções.

Teorema 5.6 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e considere*

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}$$

restrita aos vetores que satisfazem

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um vetor unitário $\mathbf{a}$ é um ponto estacionário de f sobre a esfera unitária se, e somente se, $\mathbf{a}$ é um autovetor de $\mathbf{A}$.

Se

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a},$$

então

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Em particular, o maior autovalor corresponde ao máximo global da função sobre a esfera unitária, e o menor autovalor corresponde ao mínimo global.

Este resultado permite compreender por que autovalores e autovetores surgem repetidamente em técnicas multivariadas. Em muitos casos, a técnica procura uma direção $\mathbf{a}$ que torne máxima uma quantidade expressa por uma forma quadrática.

Na Análise de Componentes Principais, por exemplo, para um vetor aleatório $\mathbf{X}$ com matriz de covariâncias Σ , a variância da combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

é

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A primeira componente principal procura a direção unitária que maximiza essa variância:

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo resultado anterior, a solução é um autovetor associado ao maior autovalor de Σ . Portanto,

maior autovalor $\longrightarrow$ maior variância possível

e

autovetor correspondente $\longrightarrow$ direção de maior variabilidade.

As componentes seguintes são obtidas acrescentando restrições de ortogonalidade às direções já encontradas. Isso conduz sucessivamente aos demais autovetores e autovalores.

A mesma estrutura reaparece, com modificações, em outros problemas multivariados. Na análise discriminante, procura-se uma direção que produza grande separação entre grupos em relação à variabilidade dentro dos grupos. Na MANOVA, determinadas direções maximizam a variação associada à hipótese em relação à variação residual. Na correlação canônica, procuram-se combinações lineares de dois conjuntos de variáveis que apresentem associação máxima.

Nesses casos, a função a ser otimizada envolve frequentemente uma razão entre duas formas quadráticas,

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{B} \mathbf{a}},$$

e a condição de estacionariedade conduz ao problema de autovalores generalizados

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{B} \mathbf{a}.$$

Assim, autovalores e autovetores aparecem nessas técnicas porque representam soluções de problemas de otimização sobre direções: os autovetores fornecem as direções de interesse e os autovalores quantificam o valor atingido pelo critério nessas direções.

5.5.4 Direções sucessivas

O problema de otimização anterior identifica uma direção associada ao maior autovalor de $\mathbf{A}$. Em muitas aplicações, entretanto, interessa obter não apenas uma direção ótima, mas uma sequência de direções que representem aspectos distintos da estrutura da matriz.

Depois de encontrar a primeira direção, pode-se procurar uma segunda direção que maximize a mesma forma quadrática, mas que seja ortogonal à primeira. O procedimento pode ser repetido sucessivamente, impondo que cada nova direção seja ortogonal às anteriormente obtidas.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição

$$\mathbf{a}^\top \mathbf{q}_1 = 0$$

impede que $\mathbf{a}$ possua componente na direção de $\mathbf{q}_1$. Assim, se $\mathbf{a}$ for escrito na base espectral,

$$\mathbf{a} = z_1 \mathbf{q}_1 + z_2 \mathbf{q}_2 + \dots + z_p \mathbf{q}_p,$$

a condição de ortogonalidade implica

$$z_1 = 0.$$

Portanto, a otimização passa a ocorrer apenas no subespaço gerado por

$$\mathbf{q}_2, \dots, \mathbf{q}_p.$$

Nesse subespaço, o maior autovalor disponível é λ_2 . Assim, o maior valor da forma quadrática é λ_2 , atingido na direção de $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.7 (Caracterização variacional de direções sucessivas). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

e seja

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação. Então, para $k = 1, \dots, p$,

$$\lambda_k = \max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por $\mathbf{q}_k$ e, quando λ_k possui multiplicidade maior que 1, por qualquer autovetor unitário associado a λ_k que satisfaça as restrições de ortogonalidade. (Horn; Johnson, 2013)

Comprovação. Como

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$, qualquer vetor $\mathbf{a}$ pode ser escrito como

$$\mathbf{a} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{a}.$$

As restrições

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1,$$

implicam

$$z_1 = \dots = z_{k-1} = 0.$$

Portanto,

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como os autovetores são ortonormais e $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Nas coordenadas espectrais,

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \sum_{j=k}^p \lambda_j z_j^2.$$

Como os autovalores estão ordenados de forma decrescente,

$$\lambda_j \leq \lambda_k, \quad j \geq k.$$

Logo,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \sum_{j=k}^p \lambda_j z_j^2 \\ &\leq \lambda_k \sum_{j=k}^p z_j^2 \\ &= \lambda_k.\end{aligned}$$

O limite é atingido tomando

$$\mathbf{a} = \mathbf{q}_k,$$

pois $\mathbf{q}_k$ possui norma unitária, é ortogonal a $\mathbf{q}_1, \dots, \mathbf{q}_{k-1}$ e satisfaz

$$\mathbf{A} \mathbf{q}_k = \lambda_k \mathbf{q}_k.$$

Assim,

$$\mathbf{q}_k^\top \mathbf{A} \mathbf{q}_k = \lambda_k.$$

Portanto,

$$\max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j=0, j=1,\dots,k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_k.$$

□

Quando há autovalores repetidos, as direções individuais dentro do autoespaço correspondente não são unicamente determinadas. Diferentes bases ortonormais desse autoespaço produzem o mesmo valor da função objetivo e representam o mesmo subespaço espectral. Assim, o subespaço associado ao autovalor repetido é bem determinado, embora a escolha particular dos autovetores que formam uma base desse subespaço não seja única.

A caracterização variacional relaciona, portanto, três objetos fundamentais:

forma quadrática $\longleftrightarrow$ problema de otimização $\longleftrightarrow$ estrutura espectral.

Além de identificar os valores extremos, essa caracterização permite obter sucessivamente as direções ortogonais associadas aos autovalores ordenados da matriz.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar real definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.8 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função real definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Proposição 5.7 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn; Johnson, 1991)

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_{\lambda}$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

□

Portanto, todo autovetor de $\mathbf{A}$ associado a λ também é autovetor de $f(\mathbf{A})$, agora associado ao autovalor $f(\lambda)$. Mais geralmente, todo o autoespaço $\mathcal{E}_{\lambda}$ de $\mathbf{A}$ permanece invariante sob $f(\mathbf{A})$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^k \mathbf{Q}_{\mathbf{A}}^{\top},$$

com

$$\Lambda_{\mathbf{A}}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_{\mathbf{A}}$ fornece

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Exemplo 5.8 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_{\mathbf{A}} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.9 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a raiz quadrada principal de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{A} \succ 0$, a raiz quadrada principal é invertível e

$$\mathbf{A}^{-1/2} = (\mathbf{A}^{1/2})^{-1}.$$

Além disso,

$$\mathbf{A}^{-1} = \mathbf{A}^{-1/2} \mathbf{A}^{-1/2}$$

e

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned}\mathbf{A}^{-1/2}\mathbf{A}\mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\Lambda_\mathbf{A}\Lambda_\mathbf{A}^{-1/2}\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A}\mathbf{I}_p\mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p.\end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2}\mathbf{x}$$

reescala as componentes espectrais de $\mathbf{x}$ segundo os fatores $1/\sqrt{\lambda_j}$. Além disso, converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned}\mathbf{x}^\top \mathbf{A}^{-1}\mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2}\mathbf{A}^{-1/2}\mathbf{x} \\ &= \mathbf{z}^\top \mathbf{z} \\ &= \|\mathbf{z}\|^2.\end{aligned}$$

Quando $\mathbf{A}$ for uma matriz de covariâncias $\Sigma \succ 0$, essa construção será retomada no branqueamento. Para um vetor com média μ , a transformação correspondente será aplicada ao vetor centralizado,

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu).$$

Nesse caso, a distância de Mahalanobis será interpretada como uma distância euclidiana nas coordenadas branqueadas.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.10 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A pseudoinversa de Moore–Penrose de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}}^+ \mathbf{Q}_{\mathbf{A}}^\top,$$

em que

$$\Lambda_{\mathbf{A}}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa atua separadamente sobre os autoespaços: nas direções associadas a autovalores não nulos, aplica o fator $1/\lambda$; no autoespaço associado ao autovalor zero, sua ação é nula. Assim, ela inverte a transformação sobre sua imagem e mantém eliminadas as componentes pertencentes ao núcleo.

Exemplo 5.9 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned}\mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz simétrica positiva definida, define-se o **logaritmo principal** por

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^\top.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição adicional
$\mathbf{A}^k$	λ_j^k	$k \in \{0, 1, 2, \dots\}$
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	nenhuma além da simetria assumida na seção
$\exp(\mathbf{A})$	e^{λ_j}	nenhuma além da simetria assumida na seção
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais atuam separadamente sobre os autoespaços, transformando cada autovalor λ no valor escalar $f(\lambda)$. Essa construção permite obter diretamente potências, inversas, raízes e pseudoinversas e mostra como certas transformações matriciais podem ser compreendidas como reescalonamentos das direções espectrais.

Em particular, a raiz quadrada e a raiz quadrada inversa permitem converter problemas definidos por uma geometria induzida por uma matriz positiva definida em problemas euclidianos equivalentes. Essa ideia será utilizada imediatamente na formulação dos autovalores generalizados.

5.7 Aprofundamento: autovalores generalizados

Leitura de aprofundamento

Esta seção apresenta uma extensão do problema ordinário de autovalores para situações em que duas formas quadráticas são consideradas simultaneamente. Embora esse desenvolvimento não seja necessário para acompanhar os resultados centrais da decompo-

sição espectral, ele fornece uma base matemática importante para técnicas multivariadas que envolvem a comparação entre diferentes estruturas de variabilidade, separação ou associação.

Ao longo da seção, serão apresentados os autovalores generalizados, o quociente de Rayleigh generalizado, a ortogonalidade em uma métrica definida por uma matriz positiva definida e a redução do problema generalizado a um problema espectral ordinário.

Alguns problemas de Estatística Multivariada envolvem a comparação entre duas formas quadráticas, em vez da otimização de uma única forma quadrática relativamente à norma euclidiana. Nesses casos, surge naturalmente o problema de autovalores generalizados,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

em que $\mathbf{A}$ é simétrica e $\mathbf{M}$ é simétrica positiva definida.

Essa estrutura generaliza o problema ordinário de autovalores, recuperado quando

$$\mathbf{M} = \mathbf{I}_p.$$

Os autovalores generalizados serão úteis posteriormente em problemas que envolvem a comparação entre diferentes medidas de variabilidade, separação ou associação. A leitura a seguir desenvolve a formulação matemática desse problema e sua relação com o quociente de Rayleigh e a decomposição espectral.

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.16, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.11 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda \mathbf{M}) \mathbf{v} = \mathbf{0}.$$

Existem soluções não triviais se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Essa equação é a equação característica generalizada do par $(\mathbf{A}, \mathbf{M})$ e determina seus autovalores generalizados.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.12 (Quociente de Rayleigh generalizado). Sejam $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica e $\mathbf{M} \in \mathbb{R}^{p \times p}$ simétrica positiva definida. Para $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$, o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|_{\mathbf{M}}^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma induzida por $\mathbf{M}$,

$$\|\mathbf{a}\|_{\mathbf{M}}^2 = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{M}} = \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Como $\mathbf{M} \succ \mathbf{0}$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o denominador é sempre positivo e o quociente está definido para todo vetor não nulo.

No quociente de Rayleigh ordinário, a normalização é realizada pela norma euclidiana,

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

No caso generalizado, essa normalização é substituída pela norma induzida por $\mathbf{M}$. Assim, o comprimento do vetor passa a ser medido segundo a geometria determinada por essa matriz.

Assim como no caso ordinário, o quociente é invariante à escala. Para qualquer escalar $c \neq 0$,

$$\begin{aligned}
\mathcal{R}_{\mathbf{A},\mathbf{M}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top \mathbf{M}(c\mathbf{a})} \\
&= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{M} \mathbf{a}} \\
&= \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}).
\end{aligned}$$

Portanto, o valor do quociente depende da direção determinada por $\mathbf{a}$, e não de sua magnitude segundo a norma induzida por $\mathbf{M}$.

Essa invariância permite escolher, em cada direção, um representante com norma unitária na geometria determinada por $\mathbf{M}$. Consequentemente, o problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição equivale a

$$\|\mathbf{a}\|_{\mathbf{M}} = 1$$

e, portanto, fixa o comprimento de $\mathbf{a}$ segundo a geometria induzida por $\mathbf{M}$.

Para determinar os pontos estacionários desse problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{M} \mathbf{a}) = 2\mathbf{M} \mathbf{a}.$$

Assim,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A} \mathbf{a} - 2\eta \mathbf{M} \mathbf{a}.$$

A condição de primeira ordem

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0}$$

produz

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que todo ponto estacionário $\mathbf{a}$ é um autovetor generalizado do par $(\mathbf{A}, \mathbf{M})$ e que o multiplicador η é o autovalor generalizado correspondente.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Sob a normalização

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1,$$

segue que

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta.$$

Além disso,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \eta.$$

Portanto, em um autovetor generalizado normalizado, o valor do quociente de Rayleigh generalizado coincide com o autovalor generalizado correspondente.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, a matriz $\mathbf{M}$ é invertível, e a equação generalizada também poderia ser escrita como

$$\mathbf{M}^{-1} \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Entretanto, mesmo que $\mathbf{A}$ e $\mathbf{M}$ sejam simétricas, a matriz $\mathbf{M}^{-1} \mathbf{A}$ não precisa ser simétrica. Para preservar a estrutura simétrica e poder aplicar diretamente o Teorema Espectral, é preferível transformar o problema utilizando a raiz quadrada de $\mathbf{M}$.

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2} \mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} = \lambda \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\widetilde{\mathbf{A}}^\top = \widetilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido no problema espectral ordinário

$$\widetilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u},$$

para uma matriz simétrica. Consequentemente, todos os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$ são reais e os resultados do Teorema Espectral podem ser aplicados à matriz $\widetilde{\mathbf{A}}$.

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \widetilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{a}$$

transforma a geometria induzida por $\mathbf{M}$ em geometria euclidiana, pois

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{u}^\top \mathbf{u}.$$

Equivalentemente,

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Geometricamente, $\mathbf{M}^{-1/2}$ transforma a esfera unitária euclidiana no elipsoide

$$\{\mathbf{a} \in \mathbb{R}^p : \mathbf{a}^\top \mathbf{M} \mathbf{a} = 1\}.$$

O problema generalizado pode, portanto, ser estudado como um problema de Rayleigh ordinário no sistema de coordenadas em que a métrica definida por $\mathbf{M}$ se torna euclidiana.

Quando $\mathbf{M}$ representar posteriormente uma matriz de covariâncias, essa mesma estrutura estará relacionada ao branqueamento. Aqui, porém, $\mathbf{M}$ representa genericamente a matriz que define a geometria do problema.

Teorema 5.8 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_p .

Comprovação. A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.5 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados. $\square$

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Proposição 5.8 (Ortogonalidade e base de autovetores generalizados). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$.*

Se $\mathbf{v}_i$ e $\mathbf{v}_j$ são autovetores generalizados associados a autovalores distintos λ_i e λ_j , então

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Além disso, existe uma base de $\mathbb{R}^p$ formada por autovetores generalizados

$$\mathcal{B}_g = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

que pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \delta_{ij}.$$

(Horn; Johnson, 2013)

Comprovação. Para autovalores distintos,

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{M} \mathbf{v}_i$$

e

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{M} \mathbf{v}_j.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned} \lambda_i \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= (\mathbf{A} \mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j. \end{aligned}$$

Portanto,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Para mostrar a existência de uma base completa, considere

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Como $\widetilde{\mathbf{A}}$ é simétrica, o Teorema Espectral garante uma base ortonormal de autovetores

$$\{\mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

Defina

$$\mathbf{v}_j = \mathbf{M}^{-1/2} \mathbf{u}_j.$$

Esses vetores são autovetores generalizados e

$$\begin{aligned} \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= \mathbf{u}_i^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}_j \\ &= \mathbf{u}_i^\top \mathbf{u}_j \\ &= \delta_{ij}. \end{aligned}$$

Assim, mesmo quando há autovalores generalizados repetidos, pode-se escolher uma base ortonormal segundo o produto interno induzido por $\mathbf{M}$. $\square$

5.7.4 Diagonalização simultânea por congruência

Considere a decomposição espectral

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \Lambda_g \mathbf{Q}_g^\top,$$

em que

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{B}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

Como $\mathbf{M}^{-1/2}$ é invertível e $\mathbf{Q}_g$ é ortogonal, $\mathbf{B}_g$ é invertível. Suas colunas formam uma base $\mathbf{M}$ -ortonormal de autovetores generalizados.

De fato,

$$\begin{aligned} \mathbf{A} \mathbf{B}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \Lambda_g \\ &= \mathbf{M} \mathbf{B}_g \Lambda_g. \end{aligned}$$

Além disso,

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p,\end{aligned}$$

e

$$\begin{aligned}\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \Lambda_g.\end{aligned}$$

Portanto,

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

O par $(\mathbf{A}, \mathbf{M})$ é, assim, reduzido simultaneamente por uma transformação de congruência:

$$(\mathbf{A}, \mathbf{M}) \longrightarrow (\Lambda_g, \mathbf{I}_p).$$

Essa operação deve ser distinguida da semelhança

$$\mathbf{B}^{-1} \mathbf{A} \mathbf{B},$$

utilizada para representar um único operador em outra base. Na congruência, as matrizes aparecem multiplicadas pela transposta da matriz de base à esquerda e pela própria matriz à direita.

Como

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p,$$

segue que

$$\mathbf{B}_g^{-1} = \mathbf{B}_g^\top \mathbf{M}.$$

Assim, se

$$\mathbf{a} = \mathbf{B}_g \mathbf{z},$$

então as coordenadas de $\mathbf{a}$ nessa base são

$$\mathbf{z} = \mathbf{B}_g^{-1} \mathbf{a} = \mathbf{B}_g^\top \mathbf{M} \mathbf{a}.$$

Nessas coordenadas,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, portanto, a mesma forma do quociente de Rayleigh ordinário quando expresso na base $\mathbf{M}$ -ortonormal de autovetores generalizados.

Exemplo 5.10 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{b}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{b}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas da matriz da base

$$\mathbf{B}_g = [\mathbf{b}_{g,1} \quad \mathbf{b}_{g,2}],$$

obtêm-se

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_2$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Este capítulo desenvolveu a estrutura espectral das transformações lineares quadradas. O ponto de partida foi a identificação de direções invariantes, isto é, direções nas quais a ação de uma matriz reduz-se à multiplicação por um escalar.

Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

com $\mathbf{v} \neq \mathbf{0}$, o escalar λ é um autovalor e $\mathbf{v}$ é um autovetor correspondente. O conjunto formado pelo vetor nulo e por todos os autovetores associados a λ constitui o autoespaço

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovalores são determinados pela condição

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0.$$

A multiplicidade algébrica $m_a(\lambda)$ registra a multiplicidade de λ como raiz do polinômio característico, enquanto a multiplicidade geométrica

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda)$$

mede a dimensão do autoespaço correspondente.

Quando $\mathbf{A}$ possui p autovetores linearmente independentes, eles formam uma base

$$\mathcal{B}_\mathbf{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\},$$

cujas matrizes é

$$\mathbf{B}_\mathbf{A} = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_p].$$

Nessa base,

$$[T_\mathbf{A}]_{\mathcal{B}_\mathbf{A} \leftarrow \mathcal{B}_\mathbf{A}} = \mathbf{B}_\mathbf{A}^{-1} \mathbf{A} \mathbf{B}_\mathbf{A} = \Lambda_\mathbf{A},$$

e, portanto,

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}.$$

A diagonalização é, assim, uma mudança para coordenadas nas quais o operador atua separadamente sobre cada direção da base de autovetores.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores. Nesse caso, a matriz da base pode ser escolhida ortogonal,

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

com

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top,$$

e obtém-se a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Equivalentemente,

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Agrupando autovalores repetidos, essa representação pode ser escrita em termos dos projetores espectrais:

$$\mathbf{A} = \sum_h \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Essa forma mostra que uma matriz simétrica atua projetando o vetor sobre autoespaços ortogonais e aplicando a cada componente o autovalor correspondente.

A decomposição espectral também permite recuperar diretamente propriedades da matriz:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

e

$$\text{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\},$$

contando as multiplicidades.

Além disso,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \left\{ \mathbf{q}_j : \lambda_j = 0 \right\},$$

enquanto

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \left\{ \mathbf{q}_j : \lambda_j \neq 0 \right\}.$$

Para matrizes simétricas,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp.$$

A mesma decomposição simplifica as formas quadráticas. Se

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x},$$

então

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são, portanto, determinadas pelos sinais dos autovalores. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides cujos eixos estão alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

é uma média ponderada dos autovalores. Para

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

tem-se

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

O máximo e o mínimo são atingidos nos autoespaços associados aos autovalores extremos. A otimização de uma forma quadrática sob a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

conduz à condição

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}.$$

Autovalores e autovetores podem, portanto, ser interpretados também como valores e direções estacionárias de problemas de otimização quadrática.

A decomposição espectral permite ainda definir funções de matrizes simétricas. Se f está definida no espectro de $\mathbf{A}$,

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Equivalentemente,

$$f(\mathbf{A}) = \sum_h f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Assim, a função espectral preserva os autoespaços e transforma cada autovalor λ no escalar $f(\lambda)$. Potências, inversas, raízes quadradas, raízes quadradas inversas, pseudoinversas, exponenciais e logaritmos são casos particulares dessa construção, sob as condições necessárias à definição de cada função.

Quando a geometria do problema é determinada por uma matriz simétrica positiva definida $\mathbf{M}$, surge o problema de autovalores generalizados

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

com $\mathbf{A} = \mathbf{A}^\top$ e $\mathbf{M} \succ 0$.

O quociente correspondente é

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

converte esse problema em um problema de Rayleigh ordinário para a matriz simétrica

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Consequentemente, os autovalores generalizados são reais e pode-se escolher uma base de autovetores generalizados cuja matriz $\mathbf{B}_g$ satisfaz

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

A Tabela 5.2 reúne as expressões principais desenvolvidas no capítulo.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica direções invariantes
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Projeto espectral	$\Pi_\lambda = \mathbf{Q}_\lambda \mathbf{Q}_\lambda^\top$	Projeta sobre o autoespaço associado a λ
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}$	Caracteriza valores e direções espectrais por otimização
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda \mathbf{M} \mathbf{v}$	Compara duas formas quadráticas

Objeto	Expressão	Interpretação
Base generalizada	$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$	Define ortonormalidade na geometria induzida por $\mathbf{M}$
Diagonalização por congruência	$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g$	Reduz simultaneamente as duas formas quadráticas

Ao final deste capítulo, o estudante deverá ser capaz de:

- identificar autovalores, autovetores e autoespaços e interpretar seu significado geométrico;
- distinguir multiplicidades algébrica e geométrica;
- determinar quando uma matriz é diagonalizável;
- interpretar a diagonalização como mudança para uma base de autovetores;
- aplicar o Teorema Espectral a matrizes simétricas reais;
- interpretar projetores e subespaços espectrais;
- relacionar autovalores a traço, determinante, posto, núcleo, imagem e positividade;
- representar formas quadráticas em coordenadas espectrais;
- formular problemas de otimização por meio do quociente de Rayleigh;
- construir e interpretar funções espectrais de matrizes;
- compreender inversas, raízes e pseudoinversas pela ação sobre os autovalores;
- formular e transformar problemas de autovalores generalizados;
- distinguir ortogonalidade euclidiana de ortogonalidade segundo uma matriz positiva definida.

A decomposição espectral fornece uma descrição particularmente simples para matrizes simétricas quadradas. Entretanto, matrizes de dados e muitas transformações de interesse são retangulares ou não simétricas e, portanto, não admitem diretamente essa decomposição. O próximo capítulo amplia essas ideias por meio da **Decomposição em Valores Singulares**, relacionando matrizes retangulares aos espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ e conectando valores singulares, espaços fundamentais, posto e aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma matriz real e $T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ a transformação linear associada;
- $r = \text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$;
- $d_1 \geq \dots \geq d_r > 0$ representam os valores singulares positivos de $\mathbf{A}$;
- $\mathbf{v}_j \in \mathbb{R}^p$ representa um vetor singular à direita;
- $\mathbf{u}_j \in \mathbb{R}^q$ representa um vetor singular à esquerda;
- $\mathbf{U}$, $\mathbf{D}$ e $\mathbf{V}$ representam os fatores da SVD completa;
- $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ representam os fatores da SVD compacta;
- $\mathbf{U}_k$, $\mathbf{D}_k$ e $\mathbf{V}_k$ representam os fatores de uma SVD truncada;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\|\mathbf{A}\|_2$ e $\|\mathbf{A}\|_F$ representam, respectivamente, as normas espectral e de Frobenius.

As convenções estabelecidas nos capítulos anteriores para núcleo, imagem, espaço coluna, espaço linha e bases ortonormais permanecem válidas.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

*Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub; Van Loan, 2013)*

A demonstração será apresentada posteriormente, após a construção da SVD a partir das decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$.

Definição 6.1 (Matriz diagonal retangular). Seja

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

A matriz $\mathbf{D}$ é denominada **diagonal retangular** quando existem escalares

$$d_1, \dots, d_s$$

tais que

$$D_{ij} = \begin{cases} d_i, & i = j \leq s, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, apenas os elementos da diagonal principal podem ser diferentes de zero.

No bloco diagonal de ordem s , essa condição pode ser escrita de forma compacta utilizando a delta de Kronecker:

$$D_{ij} = d_i \delta_{ij}, \quad i, j = 1, \dots, s.$$

Se

$$q > p,$$

então $s = p$ e $\mathbf{D}$ possui $q - p$ linhas nulas abaixo de sua parte diagonal.

Se

$$p > q,$$

então $s = q$ e $\mathbf{D}$ possui $p - q$ colunas nulas à direita de sua parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_p \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Nesse caso, a parte diagonal possui $p = \min(q, p)$ elementos e as $q - p$ linhas restantes são nulas.

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Agora, a parte diagonal possui $q = \min(q, p)$ elementos e as $p - q$ colunas restantes são nulas.

Como

$$s = \min(q, p),$$

a matriz $\mathbf{D}$ possui s posições diagonais. Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos. Ordenando-os de forma decrescente,

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto, quando $r < s$,

$$d_{r+1} = \cdots = d_s = 0.$$

Assim, o número de valores singulares positivos é exatamente o posto de $\mathbf{A}$ e, consequentemente, a dimensão da imagem da transformação linear associada:

$$r = \text{posto}(\mathbf{A}) = \dim(\text{Im}(T_{\mathbf{A}})).$$

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.2 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A}\mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;
- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{z} = \mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base ortonormal dos vetores singulares à direita,

$$\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

Assim,

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_V}.$$

Na segunda etapa,

$$\mathbf{Dz}$$

multiplica separadamente as coordenadas pelas entradas diagonais de $\mathbf{D}$. Como $\mathbf{D} \in \mathbb{R}^{q \times p}$ pode ser retangular, essa etapa também realiza a passagem entre as dimensões do domínio e do contradomínio.

Na terceira etapa, $\mathbf{U}$ reconstrói o resultado nas coordenadas canônicas de $\mathbb{R}^q$ a partir da base ortonormal

$$\mathcal{B}_U = \{\mathbf{u}_1, \dots, \mathbf{u}_q\}.$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.3 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.4 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva todos os r valores singulares positivos e fornece a representação exata

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

A SVD truncada conserva apenas parte desses componentes singulares.

Para

$$1 \leq k < r,$$

defina

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k] \in \mathbb{R}^{q \times k},$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

Definição 6.5 (SVD truncada). Seja

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a matriz

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$$

é denominada **SVD truncada de posto k** de $\mathbf{A}$.

Como $k < r$, a SVD truncada descarta componentes associados a valores singulares positivos. Portanto, em geral,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ possui posto k e constitui uma aproximação de $\mathbf{A}$. As propriedades de otimalidade dessa aproximação e os erros decorrentes do truncamento serão estudados posteriormente.

A terminologia empregada para as diferentes formas da SVD não é uniforme na literatura. Dependendo da referência, aparecem expressões como **SVD reduzida**, **SVD fina** (*thin SVD*), **SVD econômica** (*economy-sized SVD*) e **SVD compacta**, nem sempre com exatamente o mesmo significado (Demmel, 2000; Driscoll; Braun, 2022; Sidi, 2017).

Para evitar ambiguidades, neste capítulo serão utilizadas as seguintes convenções:

- **SVD completa**, para a representação que utiliza bases ortonormais completas dos espaços de origem e de chegada;
- **SVD compacta**, para a representação exata que conserva somente os $r = \text{posto}(\mathbf{A})$ valores singulares positivos e os vetores singulares correspondentes;

- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

Exemplo 6.1 (SVD completa, compacta e truncada de uma matriz retangular). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \\ 2 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

A matriz possui posto

$$r = 3$$

e seus valores singulares, em ordem decrescente, são aproximadamente

$$d_1 = 4.1780, \quad d_2 = 2.1600, \quad d_3 = 1.3706.$$

Os valores apresentados a seguir estão arredondados a quatro casas decimais. Por esse motivo, as decomposições numéricas devem ser interpretadas a menos de arredondamento.

SVD completa

Uma SVD completa de $\mathbf{A}$ é

$$\mathbf{A} \approx \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que

$$\mathbf{U} \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 & -0.6014 & -0.2239 \\ 0.5461 & -0.2239 & 0.5466 & 0.5614 & -0.1943 \\ 0.3803 & -0.6954 & -0.3419 & -0.4142 & -0.2887 \\ 0.4348 & 0.4111 & -0.6965 & 0.3743 & -0.1295 \\ 0.4126 & -0.0779 & -0.0136 & -0.1073 & 0.9011 \end{bmatrix} \in \mathbb{R}^{5 \times 5},$$

$$\mathbf{D} \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

e

$$\mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

As colunas de $\mathbf{U}$ são os vetores singulares à esquerda,

$$\mathbf{u}_1, \dots, \mathbf{u}_5,$$

e as colunas de $\mathbf{V}$ são os vetores singulares à direita,

$$\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3.$$

Os três primeiros pares de vetores singulares estão associados aos três valores singulares positivos:

$$(\mathbf{u}_1, \mathbf{v}_1) \leftrightarrow d_1 = 4.1780,$$

$$(\mathbf{u}_2, \mathbf{v}_2) \leftrightarrow d_2 = 2.1600,$$

e

$$(\mathbf{u}_3, \mathbf{v}_3) \leftrightarrow d_3 = 1.3706.$$

As duas últimas colunas de $\mathbf{U}$ completam uma base ortonormal de $\mathbb{R}^5$. Elas correspondem às duas linhas nulas de $\mathbf{D}$.

SVD compacta

Como

$$r = \text{posto}(\mathbf{A}) = 3,$$

a SVD compacta conserva somente os três valores singulares positivos e os vetores singulares correspondentes:

$$\mathbf{A} \approx \mathbf{U}_3 \mathbf{D}_3 \mathbf{V}_3^\top,$$

com

$$\mathbf{U}_3 \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 \\ 0.5461 & -0.2239 & 0.5466 \\ 0.3803 & -0.6954 & -0.3419 \\ 0.4348 & 0.4111 & -0.6965 \\ 0.4126 & -0.0779 & -0.0136 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

$$\mathbf{D}_3 \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \end{bmatrix} \in \mathbb{R}^{3 \times 3},$$

e

$$\mathbf{V}_3 = \mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

A representação continua sendo exata antes do arredondamento numérico. A SVD compacta elimina apenas as duas colunas adicionais de $\mathbf{U}$ e as duas linhas nulas correspondentes de $\mathbf{D}$.

Como

$$r = p = 3,$$

todos os vetores singulares à direita participam da SVD compacta. Por isso,

$$\mathbf{V}_3 = \mathbf{V}.$$

SVD truncada de posto 2

Considere agora a conservação apenas dos dois maiores valores singulares,

$$d_1 = 4.1780 \quad \text{e} \quad d_2 = 2.1600.$$

A SVD truncada de posto 2 utiliza

$$\mathbf{U}_2 \approx \begin{bmatrix} 0.4449 & 0.5397 \\ 0.5461 & -0.2239 \\ 0.3803 & -0.6954 \\ 0.4348 & 0.4111 \\ 0.4126 & -0.0779 \end{bmatrix} \in \mathbb{R}^{5 \times 2},$$

$$\mathbf{D}_2 \approx \begin{bmatrix} 4.1780 & 0 \\ 0 & 2.1600 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

e

$$\mathbf{V}_2 \approx \begin{bmatrix} 0.6506 & 0.7406 \\ 0.5576 & -0.3155 \\ 0.5156 & -0.5933 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Assim,

$$\mathbf{A}_2 = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top$$

é uma aproximação de posto 2 da matriz original. Numericamente,

$$\mathbf{A}_2 \approx \begin{bmatrix} 2.0726 & 0.6688 & 0.2667 \\ 1.1260 & 1.4248 & 1.4631 \\ -0.0788 & 1.3598 & 1.7103 \\ 1.8394 & 0.7330 & 0.4098 \\ 0.9969 & 1.0143 & 0.9885 \end{bmatrix}.$$

Como o terceiro valor singular positivo foi descartado,

$$\mathbf{A}_2 \neq \mathbf{A}.$$

As três formas podem ser comparadas pelas dimensões de seus fatores:

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD completa	$\mathbf{U} : 5 \times 5$	$\mathbf{D} : 5 \times 3$	$\mathbf{V} : 3 \times 3$	d_1, d_2, d_3	Exato
SVD compacta	$\mathbf{U}_3 : 5 \times 3$	$\mathbf{D}_3 : 3 \times 3$	$\mathbf{V}_3 : 3 \times 3$	d_1, d_2, d_3	Exato
SVD truncada	$\mathbf{U}_2 : 5 \times 2$	$\mathbf{D}_2 : 2 \times 2$	$\mathbf{V}_2 : 3 \times 2$	d_1, d_2	Aproximado

A SVD completa apresenta bases ortonormais completas dos espaços de origem e de chegada. A SVD compacta mantém somente as direções associadas aos valores singulares positivos, sem perder informação necessária à reconstrução de $\mathbf{A}$. A SVD truncada conserva apenas parte dessas direções e, por isso, produz uma aproximação de posto menor.

6.1.6 Aprofundamento: não unicidade dos vetores singulares

Leitura de aprofundamento

Esta seção examina a não unicidade dos vetores singulares. Embora os valores singulares sejam determinados pela matriz, os vetores singulares associados podem admitir diferentes representações.

Serão considerados três casos: a mudança simultânea de sinal de pares de vetores singulares, a liberdade de escolha de bases ortonormais quando um valor singular positivo possui multiplicidade maior que um e a escolha das bases associadas ao valor singular zero.

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d\mathbf{U}_d \mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d(\mathbf{U}_d \mathbf{R})(\mathbf{V}_d \mathbf{R})^\top &= d\mathbf{U}_d \mathbf{R} \mathbf{R}^\top \mathbf{V}_d^\top \\ &= d\mathbf{U}_d \mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das duas matrizes de Gram associadas a $\mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Essas matrizes já apareceram no estudo dos espaços das variáveis e das observações. A SVD mostra agora que seus espectros estão diretamente relacionados e que essa relação permite construir bases ortonormais adaptadas à transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A} \mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Propriedades das matrizes de Gram associadas

As matrizes

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A}\mathbf{A}^\top$$

são matrizes de Gram associadas, respectivamente, às colunas e às linhas de $\mathbf{A}$.

Pela Proposição 3.9, ambas são simétricas e semidefinidas positivas. Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{A}\mathbf{A}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{A}\mathbf{A}^\top) = \text{posto}(\mathbf{A}).$$

Assim, se

$$r = \text{posto}(\mathbf{A}),$$

cada uma dessas matrizes possui exatamente r autovalores positivos, considerando suas multiplicidades.

Como ambas são simétricas, o Teorema 5.4 garante a existência de bases ortonormais de autovetores. Como também são semidefinidas positivas, todos os seus autovalores são não negativos.

Proposição 6.1 (Espectros das matrizes de Gram associadas). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *se esses autovalores são ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

podem-se definir

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r;$$

3. *os núcleos satisfazem*

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A} \mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então,

$$\mathbf{Ax} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}^\top \mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top \mathbf{A}),$$

então

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{x}^\top$,

$$\begin{aligned} 0 &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} \\ &= \|\mathbf{Ax}\|^2. \end{aligned}$$

Portanto,

$$\mathbf{Ax} = \mathbf{0},$$

e

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}).$$

Assim,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

O mesmo argumento, aplicado a $\mathbf{A}^\top$, fornece

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

Considere agora um autovalor positivo λ de

$$\mathbf{A}^\top \mathbf{A}$$

e um autovetor unitário $\mathbf{v}$ associado:

$$\mathbf{A}^\top \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Como $\lambda > 0$, defina

$$\mathbf{u} = \frac{\mathbf{A} \mathbf{v}}{\sqrt{\lambda}}.$$

Esse vetor possui norma unitária, pois

$$\begin{aligned} \mathbf{u}^\top \mathbf{u} &= \frac{\mathbf{v}^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\lambda} \\ &= \frac{\lambda \mathbf{v}^\top \mathbf{v}}{\lambda} \\ &= 1. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top \mathbf{u} &= \frac{\mathbf{A} \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\mathbf{A}^\top \mathbf{A} \mathbf{v})}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\lambda \mathbf{v})}{\sqrt{\lambda}} \\ &= \lambda \mathbf{u}. \end{aligned}$$

Portanto, todo autovalor positivo de

$$\mathbf{A}^\top \mathbf{A}$$

também é autovalor de

$$\mathbf{A}\mathbf{A}^\top.$$

O argumento inverso é obtido começando por um autovetor de

$$\mathbf{A}\mathbf{A}^\top$$

e definindo

$$\mathbf{v} = \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}.$$

Para $\lambda > 0$, as aplicações

$$\mathbf{v} \mapsto \frac{\mathbf{A}\mathbf{v}}{\sqrt{\lambda}}$$

e

$$\mathbf{u} \mapsto \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}$$

estabelecem aplicações lineares inversas entre o autoespaço de $\mathbf{A}^\top \mathbf{A}$ associado a λ e o autoespaço de $\mathbf{A}\mathbf{A}^\top$ associado ao mesmo autovalor. Portanto, esses autoespaços possuem a mesma dimensão e as multiplicidades dos autovalores positivos coincidem.

Como

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A}) = r,$$

existem exatamente r autovalores positivos. O mesmo ocorre para

$$\mathbf{A}\mathbf{A}^\top.$$

Definindo

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r,$$

obtêm-se r números positivos associados aos autovalores positivos comuns às duas matrizes de Gram. A construção a seguir mostrará que esses números são precisamente os valores singulares positivos de $\mathbf{A}$. $\square$

As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos pares singulares

Suponha inicialmente que

$$\mathbf{A} \neq \mathbf{0}.$$

Então,

$$r = \text{posto}(\mathbf{A}) \geq 1.$$

O caso

$$\mathbf{A} = \mathbf{0}$$

será tratado diretamente na demonstração do Teorema [6.1](#).

A construção começa pela matriz

$$\mathbf{A}^\top \mathbf{A},$$

que atua em

$$\mathbb{R}^p,$$

o domínio da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Seus autovetores associados aos autovalores positivos determinarão os **vetores singulares à direita**. A aplicação de $\mathbf{A}$ a essas direções, seguida de normalização, produzirá os **vetores singulares à esquerda** em $\mathbb{R}^q$.

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Particione a matriz de autovetores como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

contém os autovetores associados aos autovalores positivos e

$$\mathbf{V}_0 = [\mathbf{v}_{r+1} \quad \cdots \quad \mathbf{v}_p]$$

contém os autovetores associados ao autovalor zero.

Pela Proposição 6.1,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Portanto, as colunas de $\mathbf{V}_0$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{V}_r$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A})^\perp = \mathcal{C}(\mathbf{A}^\top).$$

Proposição 6.2 (Construção dos pares singulares positivos). *Para cada*

$$j = 1, \dots, r,$$

defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Então:

1. *os vetores*

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais;

2. *para cada $j = 1, \dots, r$,*

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j;$$

3. os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

Comprovação. Para $i, j \leq r$,

$$\begin{aligned}\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.\end{aligned}$$

Como os vetores

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Pela definição de $\mathbf{u}_j$,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Além disso,

$$\begin{aligned}\mathbf{A}^\top\mathbf{u}_j &= \frac{\mathbf{A}^\top\mathbf{A}\mathbf{v}_j}{d_j} \\ &= \frac{d_j^2\mathbf{v}_j}{d_j} \\ &= d_j\mathbf{v}_j.\end{aligned}$$

Cada $\mathbf{u}_j$ pertence a

$$\mathcal{C}(\mathbf{A}),$$

pois

$$\mathbf{u}_j = \frac{1}{d_j}\mathbf{A}\mathbf{v}_j.$$

Como existem

$$r = \text{posto}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A})$$

vetores ortonormais desse tipo, eles formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$

□

A construção estabelece uma correspondência entre duas direções ortonormais:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p \quad \xrightarrow{\mathbf{A}} \quad d_j\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q \quad \xrightarrow{\mathbf{A}^\top} \quad d_j\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p.$$

Assim, $\mathbf{v}_j$ é uma direção singular à direita, $\mathbf{u}_j$ é a direção singular à esquerda correspondente e d_j é o fator de escalonamento que relaciona as duas.

6.2.3 Construção da SVD compacta

Reúna os vetores singulares à esquerda em

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r]$$

e defina

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r).$$

As relações

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j, \quad j = 1, \dots, r,$$

podem ser escritas simultaneamente como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r.$$

Proposição 6.3 (SVD compacta obtida dos pares singulares). *Com as matrizes $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ definidas anteriormente,*

$$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Portanto,

$$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$$

é a SVD compacta de $\mathbf{A}$, e

$$d_1, \dots, d_r$$

são seus valores singulares positivos.

Comprovação. Como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal,

$$\mathbf{I}_p = \mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top.$$

As colunas de $\mathbf{V}_0$ pertencem a

$$\mathcal{N}(\mathbf{A}),$$

de modo que

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$

Assim,

$$\begin{aligned} \mathbf{A} &= \mathbf{A} \mathbf{I}_p \\ &= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\ &= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

□

A SVD compacta utiliza exatamente as direções que participam da transformação:

- as colunas de $\mathbf{V}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A}^\top)$;
- $\mathbf{D}_r$ contém os fatores de escalonamento positivos;
- as colunas de $\mathbf{U}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A})$.

A construção anterior permite concluir a demonstração do Teorema [6.1](#).

Comprovação. Se

$$\mathbf{A} = \mathbf{0},$$

tome

$$\mathbf{U} = \mathbf{I}_q, \quad \mathbf{V} = \mathbf{I}_p$$

e

$$\mathbf{D} = \mathbf{0}_{q \times p}.$$

Então,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Suponha agora que

$$\mathbf{A} \neq \mathbf{0}.$$

Pela Proposição 6.3,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de $\mathbf{U}_r$ formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A}^\top)^\perp.$$

Complete esse conjunto com uma base ortonormal

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_q$$

de

$$\mathcal{N}(\mathbf{A}^\top).$$

Defina

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0] \in \mathbb{R}^{q \times q},$$

em que

$$\mathbf{U}_0 = [\mathbf{u}_{r+1} \quad \dots \quad \mathbf{u}_q].$$

A matriz $\mathbf{U}$ é ortogonal.

A matriz

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0] \in \mathbb{R}^{p \times p}$$

já foi obtida da decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

e também é ortogonal.

Defina

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

como a matriz diagonal retangular cujos primeiros r elementos diagonais são

$$d_1, \dots, d_r$$

e cujos demais elementos são nulos.

Como

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$$

e

$$\mathbf{A}\mathbf{V}_0 = \mathbf{0},$$

tem-se

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{D}.$$

Multiplicando à direita por $\mathbf{V}^\top$,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Isso demonstra a existência da SVD completa. □

6.2.4 Decomposições espectrais associadas

Proposição 6.4 (Decomposições espectrais induzidas pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Comprovação. Utilizando a SVD compacta,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

Como as colunas de $\mathbf{U}_r$ são ortonormais,

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Analogamente,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

□

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A} \mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A} \mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

As duas decomposições também identificam os espaços aos quais pertencem os vetores singulares:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q.$$

Portanto, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio. Os valores singulares positivos realizam a ligação entre esses dois espaços.

6.2.5 Exemplo de construção da SVD

Exemplo 6.2 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned} \mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

O segundo é

$$\begin{aligned} \mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}. \end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A} \mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A} \mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, pode-se escolher uma SVD na qual, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

6.2.7 Aprofundamento: SVD de matrizes simétricas indefinidas

Leitura de aprofundamento

Esta seção examina a relação entre a decomposição espectral e a SVD quando uma matriz simétrica possui autovalores negativos. Nesse caso, os valores singulares correspondem aos módulos dos autovalores, enquanto seus sinais são incorporados a uma das matrizes ortogonais da SVD.

Esse desenvolvimento complementa o caso semidefinido positivo apresentado anteriormente, mas não é necessário para acompanhar as aplicações principais da SVD às matrizes de Gram, às matrizes de dados e às estruturas de covariância.

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j)|\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_{\mathbf{A}},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_{\mathbf{A}} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_{\mathbf{A}}\mathbf{\Lambda}_{\mathbf{A}}\mathbf{Q}_{\mathbf{A}}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como a transformação leva a bola unitária do domínio a um elipsoide contido na imagem de $\mathbf{A}$, cujos semieixos são determinados pelos valores e vetores singulares. O comportamento da esfera unitária dependerá da existência ou não de direções pertencentes ao núcleo.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \sum_{j=1}^p \alpha_j \mathbf{Av}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Proposição 6.5 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto $r \geq 1$. A imagem da bola unitária por $\mathbf{A}$ é o elipsoide sólido de dimensão r , contido em $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$

Em particular,

$$\mathbf{A}(\mathcal{B}_p) \subseteq \mathcal{C}(\mathbf{A}),$$

e a dimensão desse elipsoide é

$$\dim(\mathcal{C}(\mathbf{A})) = r.$$

No caso extremo $\mathbf{A} = \mathbf{0}$, a imagem da bola unitária reduz-se ao conjunto $\{\mathbf{0}\}$.

Comprovação. Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

$$\mathbf{x} = \sum_{j=1}^r \frac{\beta_j}{d_j} \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1,$$

de modo que $\mathbf{x} \in \mathcal{B}_p$. Além disso,

$$\mathbf{Ax} = \sum_{j=1}^r \beta_j \mathbf{u}_j = \mathbf{y}.$$

Logo, o conjunto apresentado coincide com a imagem da bola unitária. □

O comportamento da esfera unitária depende da existência de um núcleo não trivial.

Se $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso, a imagem da esfera unitária

$$\mathcal{S}_{p-1} = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| = 1\}$$

é a fronteira relativa do elipsoide

$$\mathbf{A}(\mathcal{B}_p)$$

no subespaço $\mathcal{C}(\mathbf{A})$.

Por outro lado, se

$$r < p,$$

então

$$\dim(\mathcal{N}(\mathbf{A})) = p - r > 0.$$

Nesse caso, a imagem da esfera unitária coincide com a imagem da bola unitária:

$$\mathbf{A}(\mathcal{S}_{p-1}) = \mathbf{A}(\mathcal{B}_p).$$

De fato, para qualquer ponto do elipsoide cuja componente nas direções $\mathbf{v}_1, \dots, \mathbf{v}_r$ tenha norma menor que 1, pode-se acrescentar uma componente pertencente ao núcleo até obter um vetor de norma 1, sem alterar sua imagem por $\mathbf{A}$.

Finalmente, se

$$r < q,$$

o elipsoide não ocupa todo o espaço de chegada. Ele está contido no subespaço de dimensão r

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a geometria da imagem da bola revela simultaneamente os fatores de escala da transformação e a dimensão de sua imagem.

6.3.2 Alteração dos comprimentos

Os valores singulares permitem determinar os fatores extremos de alteração dos comprimentos produzidos pela transformação.

Proposição 6.6 (Extremos da alteração dos comprimentos). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto $r \geq 1$, com valores singulares positivos ordenados como

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0.$$

Então, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

Consequentemente,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p,$$

então

$$d_p \|\mathbf{x}\| \leq \|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|$$

para todo $\mathbf{x} \in \mathbb{R}^p$, e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se

$$r < p,$$

então

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

Comprovação. Escreva $\mathbf{x}$ na base ortonormal dos vetores singulares à direita:

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j.$$

Como essa base é ortonormal,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2.$$

Por outro lado,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Como

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais,

$$\|\mathbf{Ax}\|^2 = \sum_{j=1}^r d_j^2 \alpha_j^2.$$

Como

$$d_j \leq d_1, \quad j = 1, \dots, r,$$

segue que

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^r d_j^2 \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^r \alpha_j^2 \\
&\leq d_1^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_1^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, tomando

$$\mathbf{x} = \mathbf{v}_1,$$

pois

$$\|\mathbf{Av}_1\| = \|d_1 \mathbf{u}_1\| = d_1.$$

Logo,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Suponha agora que $\mathbf{A}$ possua posto coluna completo. Nesse caso,

$$r = p$$

e

$$d_p > 0.$$

Como

$$d_j \geq d_p, \quad j = 1, \dots, p,$$

tem-se

$$\begin{aligned}
\|\mathbf{Ax}\|^2 &= \sum_{j=1}^p d_j^2 \alpha_j^2 \\
&\geq d_p^2 \sum_{j=1}^p \alpha_j^2 \\
&= d_p^2 \|\mathbf{x}\|^2.
\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \geq d_p \|\mathbf{x}\|.$$

A igualdade é atingida, por exemplo, para

$$\mathbf{x} = \mathbf{v}_p,$$

de modo que

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Finalmente, se

$$r < p,$$

então

$$\dim \mathcal{N}(\mathbf{A}) = p - r > 0.$$

Logo, existe um vetor unitário

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Para esse vetor,

$$\mathbf{Ax}_0 = \mathbf{0},$$

e, portanto,

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

□

O maior valor singular d_1 representa, portanto, o maior fator de ampliação produzido pela transformação. Quando $\mathbf{A}$ possui posto coluna completo, o menor valor singular d_p representa o menor fator de alteração de comprimento entre vetores unitários. Quando o posto coluna não é completo, existem direções unitárias eliminadas pela transformação, e o menor comprimento possível da imagem é zero.

Esses extremos serão retomados posteriormente na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.3 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;
- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal de $\mathbb{R}^2$ e identificam duas direções sobre a circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

Neste exemplo, as bases singulares do domínio e do contradomínio são distintas. A matriz $\mathbf{V}^\top$ expressa os pontos da circunferência nas coordenadas da base formada por $\mathbf{v}_1$ e $\mathbf{v}_2$. Como essa transformação é ortogonal, a circunferência permanece uma circunferência. Em seguida, $\mathbf{D}$ realiza a deformação, multiplicando os comprimentos nas duas direções por d_1 e d_2 . Finalmente, $\mathbf{U}$ orienta os semieixos da elipse nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$ no espaço de chegada.

6.3.4 Transformações com núcleo não trivial

Quando

$$r < p,$$

a transformação possui núcleo não trivial e elimina $p - r$ direções linearmente independentes do domínio. Geometricamente, a imagem da bola unitária passa a ter dimensão inferior à dimensão do domínio.

Exemplo 6.4 (Colapso de uma direção pela transformação). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A ação da transformação sobre um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

é

$$\mathbf{A}_0 \mathbf{x} = \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix}.$$

Portanto, toda a direção

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

é eliminada, pois

$$\mathbf{A}_0 \mathbf{e}_2 = \mathbf{0}.$$

De fato,

$$\mathcal{N}(\mathbf{A}_0) = \text{span} \{ \mathbf{e}_2 \}.$$

A bola unitária de $\mathbb{R}^2$ é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

Assim, a imagem possui dimensão 1, que coincide com

$$\text{posto}(\mathbf{A}_0) = 1.$$

O valor singular positivo $d_1 = 2$ determina o comprimento do único semieixo não nulo, enquanto o valor singular $d_2 = 0$ identifica a direção eliminada pela transformação.

De modo geral:

- cada valor singular positivo produz um semieixo não nulo da imagem;
- existem exatamente r semieixos não nulos;
- o núcleo possui dimensão $p - r$ e contém todas as direções que são transformadas no vetor nulo;
- a dimensão do elipsoide resultante é r ;
- o elipsoide está contido em $\mathcal{C}(\mathbf{A})$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores e normas diretamente a partir dos vetores e valores singulares. Aspectos relacionados ao condicionamento numérico serão apresentados posteriormente como leitura de aprofundamento.

6.4 Espaços fundamentais, posto e normas

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Proposição 6.7 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_q\} = \mathcal{C}(\mathbf{U}_0).$$

(Golub; Van Loan, 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{U}_r) \subseteq \mathcal{C}(\mathbf{A}).$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r).$$

Aplicando o mesmo argumento a

$$\mathbf{A}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top,$$

obtém-se

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r).$$

Considere agora a base ortonormal completa

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma decomposição única da forma

$$\mathbf{x} = \mathbf{V}_r \alpha + \mathbf{V}_0 \beta.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top (\mathbf{V}_r \alpha + \mathbf{V}_0 \beta) \\ &= \mathbf{U}_r \mathbf{D}_r \alpha, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_0 = \mathbf{0}.$$

Como $\mathbf{D}_r$ é invertível,

$$\mathbf{Ax} = \mathbf{0}$$

se, e somente se,

$$\alpha = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A})$$

se, e somente se,

$$\mathbf{x} = \mathbf{V}_0 \beta.$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

Aplicando o mesmo raciocínio a $\mathbf{A}^\top$,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Assim, a SVD completa fornece bases ortonormais simultaneamente para os quatro espaços fundamentais de $\mathbf{A}$. $\square$

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.4.

Tabela 6.4: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

A identificação das bases dos quatro espaços fundamentais permite construir diretamente seus projetores ortogonais.

Proposição 6.8 (Projetores dos espaços fundamentais pela SVD). *Considere a SVD completa escrita como*

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Então, os projetores ortogonais sobre os quatro espaços fundamentais são

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^{\top}$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

Comprovação. Pela Proposição 6.7,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r)$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Como as colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ são ortonormais, a Proposição 3.14 fornece

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top.$$

Além disso, como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U} \mathbf{U}^\top = \mathbf{I}_q.$$

Portanto,

$$\mathbf{U}_r \mathbf{U}_r^\top + \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q,$$

de onde

$$\mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

Aplicando o mesmo argumento a

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

obtêm-se

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

□

Como são projetores ortogonais, essas matrizes são simétricas e idempotentes, conforme as propriedades estudadas no Capítulo 3.

Exemplo 6.5 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{ \mathbf{0} \}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned} \mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}. \end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

Pela SVD, o posto de $\mathbf{A}$ é exatamente o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r = \# \{j : d_j > 0\}.$$

Como consequência do Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Essas dimensões também são visualizadas diretamente na SVD completa:

- as r colunas de $\mathbf{V}_r$ formam uma base do espaço linha;
- as $p - r$ colunas de $\mathbf{V}_0$ formam uma base do núcleo de $\mathbf{A}$;
- as r colunas de $\mathbf{U}_r$ formam uma base do espaço coluna;
- as $q - r$ colunas de $\mathbf{U}_0$ formam uma base do núcleo de $\mathbf{A}^\top$.

É importante distinguir essas dimensões do número de posições diagonais nulas de $\mathbf{D}$. Como

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui apenas

$$s = \min(q, p)$$

posições diagonais, existem

$$s - r$$

valores singulares nulos entre essas posições, enquanto as dimensões dos dois núcleos são, respectivamente,

$$p - r \quad \text{e} \quad q - r.$$

Assim, em matrizes retangulares, a estrutura completa dos núcleos não deve ser inferida apenas pela quantidade de elementos diagonais nulos de $\mathbf{D}$.

A Tabela 6.5 reúne as principais relações entre os valores e vetores singulares e a estrutura da transformação.

Tabela 6.5: Relação entre a SVD e a estrutura da matriz.

Estrutura ou propriedade	Caracterização pela SVD
Posto	Número de valores singulares positivos
Imagem $\mathcal{C}(\mathbf{A})$	Vetores singulares à esquerda associados a $d_j > 0$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	Vetores singulares à direita associados a $d_j > 0$
Núcleo $\mathcal{N}(\mathbf{A})$	Vetores singulares à direita associados à parte nula
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	Vetores singulares à esquerda associados à parte nula
Ampliação máxima	d_1
Menor fator positivo de escala	d_r

Se $r < p$, a menor norma de $\mathbf{A}\mathbf{x}$ entre todos os vetores unitários do domínio é zero, pois existem vetores unitários no núcleo. O valor d_r descreve o menor fator **positivo** de escala, isto é, a menor ação da transformação quando restrita ao espaço linha $\mathcal{C}(\mathbf{A}^\top)$.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.6 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \text{tr} (\mathbf{A}^\top \widetilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \tilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \widetilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.7 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr} (\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.8 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Proposição 6.9 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub; Van Loan, 2013)

Comprovação. Pela Proposição 6.6,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Como, pela Definição 6.8,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|,$$

segue imediatamente que

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius, utilizando a Proposição 6.4,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Portanto,

$$\begin{aligned} \|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\ &= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\ &= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\ &= \text{tr}(\mathbf{D}_r^2) \\ &= \sum_{j=1}^r d_j^2. \end{aligned}$$

Logo,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

□

Se $\mathbf{A} = \mathbf{0}$, então não há valores singulares positivos e, diretamente pelas definições,

$$\|\mathbf{A}\|_2 = \|\mathbf{A}\|_F = 0.$$

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Proposição 6.10 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub; Van Loan, 2013)

Comprovação. Para a norma espectral, como $\mathbf{Q}_1$ preserva normas,

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2 \mathbf{x}\| = \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\|.$$

Como $\mathbf{Q}_2$ é ortogonal, a transformação

$$\mathbf{z} = \mathbf{Q}_2 \mathbf{x}$$

preserva a norma e percorre todos os vetores unitários quando $\mathbf{x}$ percorre a esfera unitária. Portanto,

$$\begin{aligned} \|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 &= \max_{\|\mathbf{x}\|=1} \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\| \\ &= \max_{\|\mathbf{z}\|=1} \|\mathbf{A} \mathbf{z}\| \\ &= \|\mathbf{A}\|_2. \end{aligned}$$

Para a norma de Frobenius,

$$\begin{aligned}
\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F^2 &= \text{tr} \left[(\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2) \right] \\
&= \text{tr} (\mathbf{Q}_2^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}_2) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A} \mathbf{Q}_2 \mathbf{Q}_2^\top) \\
&= \text{tr} (\mathbf{A}^\top \mathbf{A}) \\
&= \|\mathbf{A}\|_F^2.
\end{aligned}$$

Logo, ambas as normas são invariantes sob multiplicações ortogonais. $\square$

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p = q,$$

de modo que não existem direções singulares associadas ao valor zero. Assim, as formas compacta e completa possuem as mesmas dimensões e podem ser escritas com os mesmos fatores:

$$\mathbf{U}_r = \mathbf{U}, \quad \mathbf{D}_r = \mathbf{D}, \quad \mathbf{V}_r = \mathbf{V}.$$

6.4.8 Aprofundamento: condicionamento e posto numérico

Leitura de aprofundamento

Esta seção apresenta duas extensões de natureza numérica da interpretação dos valores singulares. A primeira utiliza a razão entre os valores singulares extremos para avaliar o condicionamento de uma transformação. A segunda distingue o posto algébrico do posto numérico obtido após a adoção de uma tolerância computacional.

Esses conceitos são importantes para estabilidade numérica, problemas inversos e algoritmos matriciais, mas não são necessários para acompanhar os resultados centrais sobre espaços fundamentais, aproximações de posto reduzido e aplicações estatísticas da SVD.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

Quando

$$\text{posto}(\mathbf{A}) = s,$$

a matriz possui o maior posto possível para suas dimensões e todos os seus s valores singulares são positivos:

$$d_1 \geq \dots \geq d_s > 0.$$

Definição 6.9 (Número de condição na norma espectral). Para uma matriz de posto máximo,

$$\text{posto}(\mathbf{A}) = s,$$

define-se o **número de condição na norma espectral** por

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Quando

$$\text{posto}(\mathbf{A}) < s,$$

adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

(Golub; Van Loan, 2013)

O número de condição compara o maior e o menor fatores positivos de escala associados à parte ativa da transformação.

Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

os valores singulares extremos possuem magnitudes semelhantes. Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são transformadas por fatores muito maiores que outras.

É importante distinguir **núcleo não trivial**, **deficiência de posto** e **mau condicionamento**.

A deficiência de posto ocorre quando

$$\text{posto}(\mathbf{A}) < \min(q, p).$$

Entretanto, uma matriz retangular pode possuir núcleo não trivial mesmo apresentando posto máximo.

Por exemplo, se

$$q < p$$

e

$$\text{posto}(\mathbf{A}) = q,$$

então $\mathbf{A}$ possui posto linha completo e, portanto, posto máximo. Mesmo assim,

$$\dim \mathcal{N}(\mathbf{A}) = p - q > 0.$$

Assim, existem direções do domínio que são transformadas no vetor nulo.

Nesse caso, a transformação não é injetiva em todo o domínio $\mathbb{R}^p$. Sua restrição ao espaço linha,

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp,$$

é, entretanto, injetiva.

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{A}\mathbf{x}\|.$$

Portanto, para matrizes largas de posto linha completo, o número de condição finito descreve a variação dos fatores de escala sobre o espaço linha, isto é, sobre a parte do domínio na qual a transformação atua de forma injetiva.

Se

$$q \geq p$$

e

$$\text{posto}(\mathbf{A}) = p,$$

então $\mathbf{A}$ possui posto coluna completo e

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso,

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Para uma matriz quadrada invertível,

$$q = p = r,$$

tem-se também

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Portanto,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p},$$

de modo que

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Uma matriz de posto máximo com número de condição elevado é denominada **mal condicionada**. Valores singulares positivos muito pequenos indicam direções nas quais a transformação produz forte contração. Ao inverter a ação da matriz nessas direções, pequenas perturbações podem ser amplificadas.

Esse fenômeno será retomado posteriormente na discussão da pseudoinversa.

Exemplo 6.6 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

Nesse caso, as duas direções singulares são transformadas pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por um fator igual a 2, enquanto a segunda é contraída por um fator igual a 0,02.

A inversão da segunda componente exige um fator

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem ser fortemente ampliadas quando se procura inverter a transformação.

6.4.8.1 Posto exato e posto numérico

Matematicamente, o posto é determinado exatamente pelos valores singulares positivos:

$$\text{posto}(\mathbf{A}) = \# \{j : d_j > 0\}.$$

Em cálculos computacionais, entretanto, valores que seriam exatamente nulos em aritmética exata podem aparecer como números positivos muito pequenos em razão de arredondamentos, aproximações ou ruído.

Por isso, pode-se adotar uma tolerância

$$\tau \geq 0$$

e tratar como numericamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

Definição 6.10 (Posto numérico). Fixada uma tolerância $\tau \geq 0$, o **posto numérico** de $\mathbf{A}$ é definido por

$$r_\tau(\mathbf{A}) = \# \{j : d_j > \tau\}.$$

Diferentemente do posto algébrico, o posto numérico depende da tolerância adotada.

A escolha de τ pode depender de fatores como:

- precisão numérica;
- escala da matriz;
- dimensões da matriz;
- finalidade da análise;
- nível de perturbação ou ruído considerado relevante.

Portanto, dois valores devem ser distinguidos:

$$\text{posto}(\mathbf{A}) = \#\{j : d_j > 0\}$$

e

$$r_\tau(\mathbf{A}) = \#\{j : d_j > \tau\}.$$

Essa distinção será particularmente útil quando forem estudadas aproximações de posto reduzido. Nessas aproximações, valores singulares matematicamente positivos podem ser descartados deliberadamente quando sua contribuição é considerada pequena.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, a SVD recupera a dupla representação da matriz de dados introduzida no Capítulo 1:

- as colunas de $\mathbf{V}_r$ pertencem a $\mathbb{R}^p$ e determinam direções no espaço em que as observações são representadas;
- as colunas de $\mathbf{U}_r$ pertencem a $\mathbb{R}^n$ e determinam direções no espaço em que as variáveis são representadas.

Os mesmos valores singulares conectam essas duas representações.

6.5.1 Dualidade entre observações e variáveis

A SVD relaciona diretamente as duas representações da matriz de dados: as observações como vetores em $\mathbb{R}^p$ e as variáveis como vetores em $\mathbb{R}^n$.

Proposição 6.11 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

então

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

Consequentemente, para

$$j = 1, \dots, r,$$

tem-se

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, o mesmo valor singular d_j relaciona uma direção $\mathbf{v}_j$ no espaço das observações $\mathbb{R}^p$ a uma direção $\mathbf{u}_j$ no espaço das variáveis $\mathbb{R}^n$.

Comprovação. Multiplicando a SVD compacta à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{V}_r^\top\mathbf{V}_r = \mathbf{I}_r.$$

Transpondo a SVD compacta,

$$\mathbf{X}^\top = \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top.$$

Multiplicando à direita por $\mathbf{U}_r$,

$$\begin{aligned}\mathbf{X}^\top\mathbf{U}_r &= \mathbf{V}_r\mathbf{D}_r\mathbf{U}_r^\top\mathbf{U}_r \\ &= \mathbf{V}_r\mathbf{D}_r,\end{aligned}$$

pois

$$\mathbf{U}_r^\top\mathbf{U}_r = \mathbf{I}_r.$$

As relações correspondentes a cada coluna seguem diretamente dessas duas identidades matriciais. $\square$

6.5.2 Coordenadas das observações nas direções singulares à direita

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Pela Proposição 6.11,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações na base ortonormal

$$\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$$

do espaço linha

$$\mathcal{C}(\mathbf{X}^\top) \subseteq \mathbb{R}^p.$$

Como cada observação pertence a esse subespaço, as r coordenadas são suficientes para representá-la exatamente.

Se a linha i de $\mathbf{X}$ corresponde ao vetor

$$\mathbf{x}_i \in \mathbb{R}^p,$$

então

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Portanto, z_{ij} é a coordenada da observação i na direção singular $\mathbf{v}_j$.

A j -ésima coluna de $\mathbf{Z}$ é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Assim, $\mathbf{v}_j$ determina a direção utilizada para representar as observações, enquanto $\mathbf{u}_j$ descreve como as coordenadas correspondentes se distribuem entre as n unidades observacionais.

6.5.3 Coordenadas das variáveis nas direções singulares à esquerda

A relação dual é

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top.$$

Defina

$$\mathbf{W} = \mathbf{U}_r^\top \mathbf{X} \in \mathbb{R}^{r \times p}.$$

Cada coluna de $\mathbf{X}$ representa uma variável como vetor em $\mathbb{R}^n$. Se

$$\mathbf{x}^{(j)} \in \mathbb{R}^n$$

denota a j -ésima variável, então a j -ésima coluna de $\mathbf{W}$ contém suas coordenadas na base ortonormal

$$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$$

do espaço coluna

$$\mathcal{C}(\mathbf{X}) \subseteq \mathbb{R}^n.$$

Para a direção singular ℓ ,

$$\mathbf{u}_\ell^\top \mathbf{x}^{(j)} = d_\ell v_{j\ell}.$$

Portanto, os elementos de $\mathbf{V}_r$, escalonados pelos valores singulares, também descrevem as coordenadas das variáveis na base singular à esquerda.

As relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam, assim, a dualidade entre o espaço das observações e o espaço das variáveis.

6.5.4 Matrizes de Gram da matriz de dados

As duas matrizes de Gram associadas a $\mathbf{X}$ descrevem relações entre objetos diferentes.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

reúne os produtos internos entre as colunas de $\mathbf{X}$, isto é, entre as variáveis representadas como vetores em $\mathbb{R}^n$.

A matriz

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

reúne os produtos internos entre as linhas de $\mathbf{X}$, isto é, entre as observações representadas como vetores em $\mathbb{R}^p$.

Pela Proposição 6.4,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto, as duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ determina uma direção no espaço das observações;
- $\mathbf{u}_j \in \mathbb{R}^n$ determina uma direção no espaço das variáveis.

Essa dualidade também pode ser útil quando as dimensões da matriz são muito diferentes. Se

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Se

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

possui ordem menor.

Em ambos os casos, os valores próprios positivos são os mesmos e correspondem aos quadrados dos valores singulares de $\mathbf{X}$.

6.5.5 Representação exata das observações

Proposição 6.12 (Preservação da geometria pelas coordenadas singulares). *Seja*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de dados e defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Então,

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top$$

e

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Consequentemente, para quaisquer observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell,$$

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

Comprovação. Como

$$\mathbf{Z} = \mathbf{U}_r \mathbf{D}_r,$$

segue da SVD compacta que

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{Z} \mathbf{V}_r^\top.$$

Além disso,

$$\begin{aligned} \mathbf{Z} \mathbf{Z}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned}$$

Pela Proposição 6.4,

$$\mathbf{X} \mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Os elementos dessas duas matrizes são os produtos internos entre pares de observações. Logo,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Tomando $i = \ell$, obtém-se

$$\|\mathbf{x}_i\|^2 = \|\mathbf{z}_i\|^2.$$

Finalmente,

$$\begin{aligned}
\|\mathbf{x}_i - \mathbf{x}_\ell\|^2 &= \|\mathbf{x}_i\|^2 + \|\mathbf{x}_\ell\|^2 - 2\mathbf{x}_i^\top \mathbf{x}_\ell \\
&= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_\ell\|^2 - 2\mathbf{z}_i^\top \mathbf{z}_\ell \\
&= \|\mathbf{z}_i - \mathbf{z}_\ell\|^2.
\end{aligned}$$

□

A reconstrução de cada observação pode ser escrita como

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto,

$$\mathbf{x}_i \in \mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

as observações podem ser representadas exatamente por apenas r coordenadas, sem alteração de seus produtos internos, normas ou distâncias euclidianas.

Essa situação pode ocorrer mesmo quando $\mathbf{X}$ possui o maior posto possível para suas dimensões. Por exemplo, se

$$n < p$$

e

$$r = n,$$

a matriz possui posto linha completo, mas ainda assim

$$r < p.$$

Nesse caso, as observações ocupam um subespaço de dimensão r dentro de $\mathbb{R}^p$ e sua representação por $\mathbf{Z}$ é exata.

6.5.6 Centralização da matriz de dados

A posição da nuvem depende de seu centro. Para estudar os afastamentos em relação ao vetor de médias, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Proposição 6.13 (Vetores singulares à esquerda de uma matriz centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados centralizada, então

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r,$$

e as colunas da matriz de coordenadas

$$\mathbf{Z} = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

também possuem média igual a zero.

Comprovação. Como as colunas de $\mathbf{X}_c$ estão centralizadas,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD compacta,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui colunas ortonormais, segue que

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{z}_j = 0.$$

□

6.5.7 Antecipação: relação com a matriz de covariâncias amostral

A definição estatística e as propriedades da matriz de covariâncias amostral serão desenvolvidas nos capítulos posteriores dedicados à covariância e às estatísticas amostrais. Neste ponto, interessa apenas sua relação algébrica com a SVD da matriz centralizada.

Para $n \geq 2$, adotando temporariamente a notação

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se o seguinte resultado.

Proposição 6.14 (Relação entre a SVD e a covariância amostral). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Consequentemente:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$ associados aos autovalores positivos;
- os autovalores positivos de $\mathbf{S}$ são

$$\lambda_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r;$$

- tem-se

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) = r.$$

Comprovação. Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \\ &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top, \end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

A expressão obtida é uma decomposição espectral de $\mathbf{S}$ em seu subespaço associado aos autovalores positivos. Portanto, os autovetores correspondentes são as colunas de $\mathbf{V}_r$ e os autovalores positivos são

$$\frac{d_j^2}{n-1}.$$

Como $\mathbf{D}_r$ possui exatamente r elementos diagonais positivos,

$$\text{posto}(\mathbf{S}) = r.$$

□

A centralização impõe ainda uma restrição ao posto. Como

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n - 1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n - 1, p).$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz de covariâncias amostral é necessariamente singular.

Essas relações serão retomadas posteriormente em sua formulação estatística. Aqui, elas mostram que a SVD da matriz centralizada determina diretamente a estrutura espectral da matriz de covariâncias amostral.

6.5.8 Magnitude quadrática da matriz centralizada

Proposição 6.15 (Magnitude quadrática da nuvem centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Além disso, se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

então

$$\|\mathbf{X}_c\|_F^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Consequentemente,

$$\sum_{j=1}^r d_j^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Comprovação. Pela Proposição 6.9,

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Por outro lado,

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1) \mathbf{S}.$$

Logo,

$$\begin{aligned} \|\mathbf{X}_c\|_F^2 &= \operatorname{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= (n-1) \operatorname{tr}(\mathbf{S}). \end{aligned}$$

□

Se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias das observações, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

Portanto,

$$\sum_{j=1}^r d_j^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

A soma dos quadrados dos valores singulares da matriz centralizada representa, assim, a soma quadrática total dos afastamentos das observações em relação ao centro da nuvem.

Como $\text{tr}(\mathbf{S})$ é a soma dos elementos diagonais de $\mathbf{S}$, ela corresponde à soma das variâncias amostrais das p variáveis.

A centralização é essencial para essa interpretação. Para uma matriz não centralizada,

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2$$

mede a soma dos quadrados das posições em relação à origem, e não a dispersão das observações em torno de seu vetor de médias.

Exemplo 6.7 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned}\mathbf{Z} &= \mathbf{X}\mathbf{V}_2 \\ &= \mathbf{U}_2\mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}.\end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das observações. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta fornece a representação exata

$$\mathbf{X} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top.$$

Como todos os r componentes associados a valores singulares positivos são mantidos:

- a matriz é reconstruída exatamente;
- os produtos internos entre as observações são preservados;
- as normas das observações são preservadas;
- as distâncias euclidianas entre as observações são preservadas;

- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão menor pode ser construída conservando apenas os primeiros k pares singulares, com

$$k < r.$$

Nesse caso, componentes associados a valores singulares positivos são deliberadamente descartados e a reconstrução deixa de ser exata.

A distinção fundamental é, portanto:

- a **SVD compacta** omite dos fatores completos apenas direções associadas à parte nula da transformação e preserva exatamente a matriz;
- a **SVD truncada** descarta também componentes associados a valores singulares positivos e produz uma aproximação.

A forma expandida da SVD permitirá identificar separadamente a contribuição de cada componente singular e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta também pode ser expressa como uma soma de componentes matriciais associados aos pares singulares.

Proposição 6.16 (Forma expandida da SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

possui posto 1 e satisfaz

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

Comprovação. Escrevendo

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

tem-se

$$\begin{aligned} \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top. \end{aligned}$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Multiplicar por $d_j > 0$ não altera o posto, de modo que

$$\text{posto}(d_j \mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Para a norma espectral, se $\|\mathbf{x}\| = 1$,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top \mathbf{x}\| &= d_j |\mathbf{v}_j^\top \mathbf{x}| \|\mathbf{u}_j\| \\ &\leq d_j. \end{aligned}$$

A igualdade é atingida para

$$\mathbf{x} = \mathbf{v}_j.$$

Portanto,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = d_j.$$

Para a norma de Frobenius,

$$\begin{aligned}\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F^2 &= d_j^2 \operatorname{tr}(\mathbf{v}_j \mathbf{u}_j^\top \mathbf{u}_j \mathbf{v}_j^\top) \\ &= d_j^2 (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\ &= d_j^2.\end{aligned}$$

Logo,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

□

A expressão

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é denominada **forma expandida da SVD**.

Cada componente singular representa uma transformação de posto 1: a componente do vetor de entrada na direção $\mathbf{v}_j$ é multiplicada por d_j e enviada para a direção $\mathbf{u}_j$.

Como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0,$$

os componentes singulares estão ordenados de acordo com suas magnitudes nas normas espectral e de Frobenius.

6.6.1 Ortogonalidade dos componentes singulares

Proposição 6.17 (Ortogonalidade dos componentes singulares). *Para*

$$i \neq j,$$

os componentes singulares

$$d_i \mathbf{u}_i \mathbf{v}_i^\top$$

e

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius:

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

Comprovação. Pelo produto interno de Frobenius,

$$\begin{aligned} \left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F &= d_i d_j \operatorname{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\ &= d_i d_j (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i). \end{aligned}$$

Como os vetores singulares são ortonormais, para $i \neq j$,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Logo,

$$\left\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

□

Como a forma expandida é uma soma de componentes ortogonais segundo o produto interno de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Essa igualdade fornece uma decomposição pitagórica da magnitude quadrática total da matriz entre seus componentes singulares.

6.6.2 SVD truncada na forma expandida

Retomando a Definição 6.5, a aproximação de posto k pode ser expressa diretamente a partir da forma expandida da SVD.

Se

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

então

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Assim, truncar a SVD corresponde a conservar as primeiras k parcelas singulares e descartar

$$\sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa representação permitirá quantificar o erro produzido pelo truncamento e estabelecer as propriedades de otimalidade de $\mathbf{A}_k$.

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.3 Erros produzidos pelo truncamento

Proposição 6.18 (Decomposição e erros da SVD truncada). *Se*

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r,$$

então

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Além disso,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0,$$

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2,$$

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Comprovação. Pela forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Subtraindo

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

obtém-se

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Pela Proposição 6.17, os componentes associados a índices diferentes são ortogonais segundo o produto interno de Frobenius. Como $\mathbf{A}_k$ utiliza os índices

$$1, \dots, k$$

e a diferença utiliza

$$k+1, \dots, r,$$

segue que

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Aplicando a decomposição pitagórica,

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Portanto,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Por outro lado, a matriz residual

$$\mathbf{A} - \mathbf{A}_k$$

possui valores singulares positivos

$$d_{k+1}, d_{k+2}, \dots, d_r.$$

Pela Proposição 6.9, sua norma espectral é igual ao maior desses valores:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

□

A proporção da magnitude quadrática de Frobenius preservada pela aproximação pode ser escrita como

$$\eta_k = \frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}.$$

A proporção descartada é

$$1 - \eta_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

Para uma matriz genérica, η_k mede exclusivamente a proporção de sua magnitude quadrática, segundo a norma de Frobenius, representada pelos primeiros k componentes singulares. Essa quantidade não deve ser interpretada automaticamente como proporção de variância ou de informação estatística.

Quando $\mathbf{A}$ é uma matriz de dados centralizada, entretanto,

$$\|\mathbf{A}\|_F^2$$

corresponde à soma quadrática total dos afastamentos das observações em relação ao centro da nuvem. Nesse contexto específico, η_k representa a proporção dessa dispersão quadrática preservada pelos primeiros k componentes singulares.

A norma espectral descreve outro aspecto do erro. Como

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1},$$

o primeiro valor singular descartado determina o maior erro produzido pelo truncamento sobre qualquer vetor unitário:

$$d_{k+1} = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

Esse máximo é atingido, por exemplo, na direção

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

Assim, a norma espectral mede um erro de pior caso, enquanto a norma de Frobenius agrega quadraticamente os erros associados a todos os componentes singulares descartados.

6.6.4 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.2 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub; Van Loan, 2013)

6.6.5 Aprofundamento: demonstração e unicidade da melhor aproximação

Leitura de aprofundamento

O Teorema de Eckart–Young–Mirsky estabelece a otimalidade da SVD truncada sem exigir que sua demonstração seja utilizada nas aplicações posteriores.

Nesta leitura de aprofundamento, demonstra-se a otimalidade separadamente nas normas espectral e de Frobenius e examina-se quando a melhor aproximação de posto reduzido é ou não única.

Comprovação. Considere inicialmente a norma espectral e uma matriz arbitrária

$$\tilde{\mathbf{A}}$$

com

$$\text{posto}(\tilde{\mathbf{A}}) \leq k.$$

Defina o subespaço

$$\mathcal{S}_{k+1} = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_{k+1} \}.$$

Como

$$\dim(\mathcal{S}_{k+1}) = k + 1$$

e a restrição de $\widetilde{\mathbf{A}}$ a esse subespaço possui imagem de dimensão no máximo k , existe um vetor unitário

$$\mathbf{x} \in \mathcal{S}_{k+1}$$

tal que

$$\widetilde{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Escreva

$$\mathbf{x} = \sum_{j=1}^{k+1} \alpha_j \mathbf{v}_j,$$

com

$$\sum_{j=1}^{k+1} \alpha_j^2 = 1.$$

Então,

$$\begin{aligned} \left\| (\mathbf{A} - \widetilde{\mathbf{A}}) \mathbf{x} \right\|^2 &= \left\| \mathbf{A} \mathbf{x} \right\|^2 \\ &= \sum_{j=1}^{k+1} d_j^2 \alpha_j^2 \\ &\geq d_{k+1}^2 \sum_{j=1}^{k+1} \alpha_j^2 \\ &= d_{k+1}^2. \end{aligned}$$

Logo,

$$\left\| \mathbf{A} - \widetilde{\mathbf{A}} \right\|_2 \geq d_{k+1}.$$

Para a SVD truncada,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Portanto, $\mathbf{A}_k$ atinge o limite inferior e é uma solução ótima na norma espectral.

Para a norma de Frobenius, considere o projetor ortogonal

$$\mathbf{P}$$

sobre o espaço coluna de $\tilde{\mathbf{A}}$. Como

$$\text{posto}(\tilde{\mathbf{A}}) \leq k,$$

tem-se

$$\text{posto}(\mathbf{P}) \leq k.$$

Além disso,

$$\mathbf{P}\tilde{\mathbf{A}} = \tilde{\mathbf{A}}.$$

A diferença pode ser decomposta como

$$\mathbf{A} - \tilde{\mathbf{A}} = (\mathbf{I}_q - \mathbf{P}) \mathbf{A} + (\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}).$$

As duas parcelas são ortogonais segundo o produto interno de Frobenius, pois a primeira possui colunas no complemento ortogonal de $\mathcal{C}(\mathbf{P})$, enquanto a segunda possui colunas em $\mathcal{C}(\mathbf{P})$.

Assim,

$$\begin{aligned} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 &= \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 \\ &\quad + \|\mathbf{P}\mathbf{A} - \tilde{\mathbf{A}}\|_F^2 \\ &\geq \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2. \end{aligned}$$

A primeira parcela pode ser escrita como

$$\|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 = \|\mathbf{A}\|_F^2 - \|\mathbf{P}\mathbf{A}\|_F^2.$$

Considere uma base ortonormal

$$\mathbf{w}_1, \dots, \mathbf{w}_s, \quad s \leq k,$$

do espaço projetado por $\mathbf{P}$. Então,

$$\mathbf{P} = \sum_{i=1}^s \mathbf{w}_i \mathbf{w}_i^\top$$

e

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{i=1}^s \mathbf{w}_i^\top \mathbf{AA}^\top \mathbf{w}_i. \end{aligned}$$

Usando a decomposição espectral

$$\mathbf{AA}^\top = \sum_{j=1}^r d_j^2 \mathbf{u}_j \mathbf{u}_j^\top,$$

tem-se

$$\begin{aligned} \|\mathbf{PA}\|_F^2 &= \text{tr}(\mathbf{PAA}^\top) \\ &= \sum_{j=1}^r d_j^2 \text{tr}(\mathbf{Pu}_j \mathbf{u}_j^\top) \\ &= \sum_{j=1}^r d_j^2 \mathbf{u}_j^\top \mathbf{Pu}_j. \end{aligned}$$

Defina

$$c_j = \mathbf{u}_j^\top \mathbf{Pu}_j = \|\mathbf{Pu}_j\|^2.$$

Como $\mathbf{P}$ é um projetor ortogonal,

$$0 \leq c_j \leq 1.$$

Além disso,

$$\begin{aligned}
\sum_{j=1}^r c_j &= \sum_{j=1}^r \mathbf{u}_j^\top \mathbf{P} \mathbf{u}_j \\
&\leq \text{tr}(\mathbf{P}) \\
&= \text{posto}(\mathbf{P}) \\
&\leq k.
\end{aligned}$$

Portanto,

$$\|\mathbf{P}\mathbf{A}\|_F^2 = \sum_{j=1}^r c_j d_j^2,$$

com

$$0 \leq c_j \leq 1$$

e

$$\sum_{j=1}^r c_j \leq k.$$

Como os valores singulares estão ordenados, sob as restrições,

$$0 \leq c_j \leq 1 \quad \text{e} \quad \sum_j c_j \leq k,$$

a soma ponderada é maximizada atribuindo peso 1 aos k maiores valores d_j^2 e peso 0 aos demais. Como

$$d_1^2 \geq \dots \geq d_r^2,$$

segue que

$$\|\mathbf{P}\mathbf{A}\|_F^2 \leq \sum_{j=1}^k d_j^2.$$

Portanto,

$$\begin{aligned}\|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &\geq \|\mathbf{A}\|_F^2 - \sum_{j=1}^k d_j^2 \\ &= \sum_{j=k+1}^r d_j^2.\end{aligned}$$

Para

$$\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^\top,$$

tem-se

$$\mathbf{P}\mathbf{A} = \mathbf{A}_k.$$

Além disso,

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Logo, $\mathbf{A}_k$ também atinge o limite inferior na norma de Frobenius. $\square$

O teorema mostra que nenhuma matriz de posto no máximo k pode apresentar erro menor que $\mathbf{A}_k$ nas duas normas consideradas.

Na norma espectral, o erro ótimo é determinado exclusivamente pelo primeiro valor singular descartado,

$$d_{k+1}.$$

Na norma de Frobenius, o erro ótimo depende de toda a parcela espectral descartada,

$$\sqrt{\sum_{j=k+1}^r d_j^2}.$$

6.6.5.1 Unicidade da aproximação

A otimalidade estabelecida pelo Teorema 6.2 não implica, em geral, que a matriz aproximante seja única. A situação depende também da norma considerada.

Na norma de Frobenius, a melhor aproximação de posto no máximo k é única quando há separação estrita entre os valores singulares que ficam em lados opostos do truncamento:

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o ponto de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de subespaços dentro desse bloco singular podem produzir aproximações ótimas distintas.

Na norma espectral, a matriz

$$\mathbf{A}_k$$

é sempre uma aproximação ótima, mas a aproximação ótima pode não ser única mesmo quando

$$d_k > d_{k+1}.$$

Isso ocorre porque outras matrizes de posto no máximo k podem produzir o mesmo erro máximo

$$d_{k+1}.$$

Portanto, a condição

$$d_k > d_{k+1}$$

garante unicidade da melhor aproximação na norma de Frobenius, mas não deve ser utilizada como critério geral de unicidade na norma espectral.

Quando

$$k \geq r,$$

não há truncamento de componentes singulares positivos e a representação exata é

$$\mathbf{A}_k = \mathbf{A},$$

com erro igual a zero.

6.6.6 Exemplo de aproximação de posto 1

Exemplo 6.8 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

Neste exemplo, as normas espectral e de Frobenius do erro coincidem porque a matriz residual possui apenas um valor singular positivo. Quando mais de um componente singular é descartado, os dois erros são, em geral, diferentes.

6.6.7 Aproximação de uma matriz de dados

A SVD truncada possui uma interpretação direta como projeção das observações em um subespaço de menor dimensão.

Proposição 6.19 (SVD truncada como projeção das observações). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados e

$$1 \leq k < r,$$

então sua aproximação truncada satisfaz

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X} \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{P}_k = \mathbf{V}_k \mathbf{V}_k^\top$$

é o projetor ortogonal sobre

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \},$$

cada linha de $\mathbf{X}_k$ é a projeção ortogonal da observação correspondente sobre $\mathcal{S}_k$.

Se

$$\mathbf{Z}_k = \mathbf{X}\mathbf{V}_k,$$

então

$$\mathbf{Z}_k = \mathbf{U}_k\mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k\mathbf{V}_k^\top.$$

Comprovação. Pela relação

$$\mathbf{X}\mathbf{V}_k = \mathbf{U}_k\mathbf{D}_k,$$

tem-se

$$\begin{aligned}\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top &= \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top \\ &= \mathbf{X}_k.\end{aligned}$$

Como as colunas de $\mathbf{V}_k$ são ortonormais,

$$\mathbf{P}_k = \mathbf{V}_k\mathbf{V}_k^\top$$

é o projetor ortogonal sobre $\mathcal{S}_k$.

Portanto, para cada observação $\mathbf{x}_i$,

$$\hat{\mathbf{x}}_{i,k} = \mathbf{P}_k\mathbf{x}_i$$

e, equivalentemente,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij}\mathbf{v}_j.$$

O resíduo correspondente é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij}\mathbf{v}_j.$$

□

A matriz

$$\mathbf{Z}_k \in \mathbb{R}^{n \times k}$$

fornece uma representação das observações em k coordenadas. A multiplicação por

$$\mathbf{V}_k^\top$$

reconstrói suas aproximações no espaço original $\mathbb{R}^p$.

Além disso,

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2 = \sum_{j=k+1}^r d_j^2.$$

Pelo Teorema 6.2, nenhuma matriz de posto no máximo k possui erro de reconstrução menor na norma de Frobenius. Em particular, entre as representações obtidas pela projeção das observações em subespaços lineares de dimensão no máximo k , o subespaço

$$\mathcal{S}_k = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

minimiza a soma dos erros quadráticos de reconstrução.

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a proporção da dispersão quadrática total da nuvem preservada pelas primeiras k direções singulares.

Essa relação será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, ela deve ser interpretada como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada e a pseudoinversa utilizam os mesmos componentes singulares com finalidades distintas.

Na aproximação de posto reduzido, componentes associados a valores singulares positivos são deliberadamente descartados:

$$\mathbf{A} \longrightarrow \mathbf{A}_k.$$

Na pseudoinversa, todos os componentes associados a valores singulares positivos são mantidos, mas os fatores de escala são invertidos:

$$d_j \longrightarrow \frac{1}{d_j}, \quad j = 1, \dots, r.$$

As direções associadas à parte nula da transformação não são invertidas.

Essa construção conduz à pseudoinversa de Moore–Penrose e, a partir dela, às soluções de sistemas lineares e problemas de mínimos quadrados.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Se $r \geq 1$, todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos. Portanto,

$$\mathbf{D}_r^{-1} = \text{diag} \left(\frac{1}{d_1}, \dots, \frac{1}{d_r} \right)$$

está bem definida.

Se $r = 0$, então $\mathbf{A} = \mathbf{0}$ e sua pseudoinversa será definida como a matriz nula de dimensão $p \times q$.

Definição 6.11 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

No caso $\mathbf{A} = \mathbf{0}$, define-se

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz os escalonamentos de $\mathbf{A}$ nas direções associadas aos valores singulares positivos e anula as componentes pertencentes a

$$\mathcal{N}(\mathbf{A}^\top).$$

Assim, ela atua como uma inversão entre os subespaços

$$\mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

nos quais a ação de $\mathbf{A}$ é não nula.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio de sua decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

então

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que cada autovalor não nulo é substituído por seu inverso e os autovalores nulos permanecem iguais a zero.

A definição baseada na SVD,

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

estende essa construção para qualquer matriz real, inclusive matrizes retangulares e não simétricas.

Quando $\mathbf{A}$ é quadrada e invertível,

$$r = p = q,$$

todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Portanto, a inversa usual constitui um caso particular da pseudoinversa.

6.7.2 Aprofundamento: caracterização de Moore–Penrose

Leitura de aprofundamento

A pseudoinversa foi definida anteriormente a partir da SVD. Existe também uma caracterização independente dessa decomposição: a pseudoinversa de Moore–Penrose é a única matriz que satisfaz simultaneamente quatro identidades algébricas.

Esta seção apresenta essas condições, verifica que a matriz construída pela SVD as satisfaz e demonstra sua unicidade. A caracterização é importante na teoria de inversas generalizadas, mas não é necessária para acompanhar as aplicações posteriores da pseudoinversa a projeções e mínimos quadrados.

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.3 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente o caso

$$\mathbf{A} = \mathbf{0}.$$

A matriz

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}$$

satisfaz imediatamente as quatro condições de Moore–Penrose.

Além disso, se uma matriz

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

satisfaz essas condições para $\mathbf{A} = \mathbf{0}$, a segunda condição fornece

$$\mathbf{GAG} = \mathbf{G}.$$

Como $\mathbf{A} = \mathbf{0}$,

$$\mathbf{GAG} = \mathbf{0},$$

e, portanto,

$$\mathbf{G} = \mathbf{0}.$$

Logo, a pseudoinversa também é única nesse caso.

Suponha agora

$$\mathbf{A} \neq \mathbf{0}.$$

Então

$$r = \text{posto}(\mathbf{A}) \geq 1,$$

e, pela SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Então,

$$\begin{aligned} \mathbf{A} \mathbf{A}^+ \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{A}. \end{aligned}$$

De modo semelhante,

$$\begin{aligned} \mathbf{A}^+ \mathbf{A} \mathbf{A}^+ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{A}^+. \end{aligned}$$

Além disso,

$$\mathbf{A} \mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top,$$

que são matrizes simétricas. Portanto, a matriz definida pela SVD satisfaz as quatro condições de Moore–Penrose.

Para demonstrar a unicidade, suponha que

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

também satisfaça as quatro condições.

A matriz $\mathbf{A} \mathbf{G}$ é simétrica e

$$\begin{aligned} (\mathbf{A} \mathbf{G})^2 &= \mathbf{A} \mathbf{G} \mathbf{A} \mathbf{G} \\ &= (\mathbf{A} \mathbf{G} \mathbf{A}) \mathbf{G} \\ &= \mathbf{A} \mathbf{G}. \end{aligned}$$

Logo, $\mathbf{A} \mathbf{G}$ é um projetor ortogonal.

Sua imagem está contida em $\mathcal{C}(\mathbf{A})$. Além disso, se

$$\mathbf{y} = \mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{G}\mathbf{y} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x} = \mathbf{y}.$$

Portanto,

$$\mathbf{A}\mathbf{G} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top.$$

De maneira análoga, $\mathbf{G}\mathbf{A}$ é simétrica e idempotente.

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Reciprocamente, se

$$\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0},$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{G}\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{G}\mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Como $\mathbf{G}\mathbf{A}$ é um projetor ortogonal,

$$\mathbf{G}\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})^\perp} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top.$$

Da condição

$$\mathbf{GAG} = \mathbf{G},$$

segue que

$$\mathcal{C}(\mathbf{G}) \subseteq \mathcal{C}(\mathbf{GA}) = \mathcal{C}(\mathbf{A}^\top).$$

Considere agora um vetor singular à esquerda $\mathbf{u}_j$, com $j \leq r$. Como

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

tem-se

$$\mathbf{AGu}_j = \mathbf{u}_j.$$

Como

$$\mathbf{Gu}_j \in \mathcal{C}(\mathbf{A}^\top),$$

esse vetor pode ser escrito como

$$\mathbf{Gu}_j = \sum_{\ell=1}^r c_\ell \mathbf{v}_\ell.$$

Aplicando $\mathbf{A}$,

$$\mathbf{u}_j = \sum_{\ell=1}^r c_\ell d_\ell \mathbf{u}_\ell.$$

Pela unicidade das coordenadas na base ortonormal,

$$c_\ell = \begin{cases} 1/d_j, & \ell = j, \\ 0, & \ell \neq j. \end{cases}$$

Portanto,

$$\mathbf{Gu}_j = \frac{1}{d_j} \mathbf{v}_j.$$

Considere, por fim,

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top).$$

Como $\mathbf{A}\mathbf{G}$ projeta sobre $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Além disso,

$$\mathbf{G}\mathbf{u} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \cap \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

segue que

$$\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Assim, $\mathbf{G}$ atua sobre a base ortonormal formada pelas colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ exatamente como

$$\mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Logo,

$$\mathbf{G} = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top = \mathbf{A}^+.$$

Portanto, a pseudoinversa de Moore–Penrose existe e é única. □

6.7.3 Pseudoinversa e projetores

Os produtos envolvendo $\mathbf{A}$ e sua pseudoinversa recuperam os projetores ortogonais dos quatro espaços fundamentais.

Proposição 6.20 (Projetores determinados pela pseudoinversa). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

então

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Consequentemente,

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

Comprovação. Pela definição da pseudoinversa,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Pela Proposição 6.8,

$$\mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Analogamente,

$$\begin{aligned}\mathbf{A}^+ \mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.\end{aligned}$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathcal{C}(\mathbf{A}^\top)^\perp = \mathcal{N}(\mathbf{A}),$$

os projetores sobre os complementos ortogonais são

$$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

□

A Tabela 6.6 resume essas relações.

Tabela 6.6: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A} \mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A} \mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+ \mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A}$	$\mathcal{N}(\mathbf{A})$

Os dois produtos atuam em espaços diferentes. A matriz

$$\mathbf{A}\mathbf{A}^+ \in \mathbb{R}^{q \times q}$$

atua no contradomínio e seleciona a componente pertencente à imagem da transformação.

Por outro lado,

$$\mathbf{A}^+\mathbf{A} \in \mathbb{R}^{p \times p}$$

atua no domínio e seleciona a componente pertencente ao espaço linha, isto é, ao complemento ortogonal do núcleo de $\mathbf{A}$.

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

A pseudoinversa permite caracterizar a compatibilidade do sistema, descrever todas as suas soluções e identificar aquela de menor norma.

Proposição 6.21 (Sistemas compatíveis pela pseudoinversa). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

é compatível se, e somente se,

$$\mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Quando o sistema é compatível, o conjunto de todas as soluções é

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

em que

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Entre todas essas soluções,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única de menor norma euclidiana.

Se

$$r = p,$$

o núcleo de $\mathbf{A}$ é trivial e a solução é única.

Comprovação. O sistema é compatível exatamente quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Pela Proposição 6.20,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Suponha que o sistema seja compatível. Então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se $\mathbf{x}$ é qualquer outra solução,

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x}_0.$$

Logo,

$$\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0},$$

e, portanto,

$$\mathbf{x} - \mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma.$$

Além disso,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\gamma \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\mathbf{x}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\gamma\|^2.$$

A menor norma é obtida somente quando

$$\gamma = \mathbf{0}.$$

Portanto,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de menor norma.

Finalmente, se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e nenhuma componente adicional pode ser acrescentada à solução. □

6.7.5 Mínimos quadrados

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

pode-se procurar um vetor $\mathbf{x}$ cuja imagem $\mathbf{Ax}$ esteja o mais próxima possível de $\mathbf{b}$.

O problema é

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o erro mínimo é zero e o problema coincide com a resolução de um sistema compatível.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe solução exata e busca-se a melhor aproximação possível dentro do espaço coluna de $\mathbf{A}$.

Definição 6.12 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma **solução de mínimos quadrados** de

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

A pseudoinversa fornece diretamente todas as soluções desse problema.

Proposição 6.22 (Mínimos quadrados pela pseudoinversa). *Para qualquer*

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor ajustado de mínimos quadrados é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b}.$$

O resíduo é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+)\mathbf{b}$$

e satisfaz

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top),$$

ou, equivalentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Consequentemente, uma solução de mínimos quadrados satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

O conjunto de todas as soluções de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todos os minimizadores,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é o único de menor norma euclidiana.

Comprovação. Pela Proposição 6.20,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{A}\mathbf{A}^+.$$

Defina

$$\hat{\mathbf{b}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

e

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}}.$$

Como $\hat{\mathbf{b}}$ é a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$,

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{A}\mathbf{x} \in \mathcal{C}(\mathbf{A}).$$

Portanto,

$$\mathbf{b} - \mathbf{A}\mathbf{x} = \mathbf{r} + (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}),$$

em que

$$\mathbf{r} \perp (\hat{\mathbf{b}} - \mathbf{A}\mathbf{x}).$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 = \|\mathbf{r}\|^2 + \|\hat{\mathbf{b}} - \mathbf{Ax}\|^2.$$

Assim,

$$\|\mathbf{b} - \mathbf{Ax}\|^2 \geq \|\mathbf{r}\|^2,$$

com igualdade se, e somente se,

$$\mathbf{Ax} = \hat{\mathbf{b}}.$$

Como

$$\mathbf{A}(\mathbf{A}^+\mathbf{b}) = \mathbf{AA}^+\mathbf{b} = \hat{\mathbf{b}},$$

o vetor

$$\mathbf{A}^+\mathbf{b}$$

é uma solução de mínimos quadrados.

Além disso, um vetor $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados se, e somente se,

$$\mathbf{A}\hat{\mathbf{x}} = \hat{\mathbf{b}} = \mathbf{AA}^+\mathbf{b}.$$

Nesse caso, seu resíduo é

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} = \mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Portanto,

$$\mathbf{A}^\top(\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0},$$

o que equivale às equações normais

$$\mathbf{A}^\top\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^\top\mathbf{b}.$$

Reciprocamente, se $\hat{\mathbf{x}}$ satisfaz as equações normais, então

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathbf{A}\hat{\mathbf{x}} \in \mathcal{C}(\mathbf{A}),$$

a decomposição

$$\mathbf{b} = \mathbf{A}\hat{\mathbf{x}} + (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}})$$

é ortogonal. Pela unicidade da projeção ortogonal,

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b} = \hat{\mathbf{b}}.$$

Logo, $\hat{\mathbf{x}}$ é uma solução de mínimos quadrados.

Para caracterizar todos os minimizadores, observe que

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}\mathbf{A}^+\mathbf{b}$$

se, e somente se,

$$\mathbf{A}(\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b}) = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}} - \mathbf{A}^+\mathbf{b} \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma},$$

com

$$\boldsymbol{\gamma} \in \mathbb{R}^{p-r}.$$

Finalmente,

$$\mathbf{A}^+\mathbf{b} \in \mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathbf{V}_0\gamma \in \mathcal{N}(\mathbf{A}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

segue que

$$\|\hat{\mathbf{x}}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{V}_0\gamma\|^2.$$

A menor norma é obtida unicamente quando

$$\gamma = \mathbf{0}.$$

Portanto,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de mínimos quadrados de menor norma. □

A decomposição geométrica correspondente é

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Como essas parcelas são ortogonais,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.5.1 Caso de posto coluna completo

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível, e

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Portanto,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

6.7.5.2 Caso de posto linha completo

Se

$$r = q \leq p,$$

então

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Logo, para todo

$$\mathbf{b} \in \mathbb{R}^q,$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

é compatível.

Nesse caso,

$$\mathbf{AA}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{AA}^\top)^{-1}.$$

A solução

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a solução exata de menor norma.

6.7.6 Expressão da solução nas direções singulares

A forma expandida da pseudoinversa permite interpretar diretamente a solução de menor norma nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.7 Aprofundamento: instabilidade e pseudoinversa truncada

Leitura de aprofundamento

A pseudoinversa inverte os valores singulares positivos. Como consequência, valores singulares muito pequenos podem produzir grandes fatores de amplificação na solução. Esta seção examina a sensibilidade da pseudoinversa a perturbações e apresenta a pseudoinversa truncada como uma forma de evitar a inversão de algumas direções singulares. Essas ideias pertencem ao estudo de problemas inversos e regularização e não são necessárias para acompanhar os resultados centrais de mínimos quadrados desenvolvidos neste capítulo.

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned}\Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j.\end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Como os valores singulares positivos de $\mathbf{A}^+$ são

$$\frac{1}{d_r} \geq \dots \geq \frac{1}{d_1},$$

tem-se, para $r \geq 1$,

$$\|\mathbf{A}^+\|_2 = \frac{1}{d_r}.$$

Consequentemente,

$$\|\Delta \hat{\mathbf{x}}\| \leq \frac{1}{d_r} \|\varepsilon\|.$$

O menor valor singular positivo controla, portanto, a maior amplificação possível de uma perturbação pela pseudoinversa.

Esse comportamento relaciona:

- valores singulares positivos pequenos;
- forte amplificação nas direções correspondentes da pseudoinversa;
- sensibilidade a perturbações;
- instabilidade de problemas inversos.

Quando $\mathbf{A}$ possui posto máximo, um menor valor singular muito pequeno em relação a d_1 corresponde também a um número de condição elevado. Se a matriz não possui posto máximo, o número de condição definido anteriormente é infinito, enquanto a pseudoinversa continua invertendo somente os valores singulares positivos.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.7.1 Pseudoinversa truncada

Considere a aproximação truncada

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Sua pseudoinversa de Moore–Penrose é

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

Ela pode ser utilizada como uma inversão truncada de $\mathbf{A}$, conservando somente os k maiores valores singulares.

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.8 Exemplo com o sistema condutor

Exemplo 6.9 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuando os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned}
 \hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\
 &= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\
 &= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}.
 \end{aligned}$$

O vetor ajustado é

$$\begin{aligned}
 \hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\
 &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\
 &= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}.
 \end{aligned}$$

O resíduo é

$$\begin{aligned}
 \mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\
 &= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}.
 \end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão dos fatores de escala associados aos valores singulares positivos;
- anulação das componentes pertencentes a $\mathcal{N}(\mathbf{A}^\top)$;
- construção dos projetores sobre $\mathcal{C}(\mathbf{A})$ e $\mathcal{C}(\mathbf{A}^\top)$;
- solução de sistemas lineares compatíveis;
- seleção da solução exata de menor norma quando há não unicidade;
- solução de problemas de mínimos quadrados;
- seleção da solução de mínimos quadrados de menor norma quando há vários minimizadores.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares estende a ideia de decomposição espectral a qualquer matriz real. Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existe uma decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo d_j ,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

Se

$$r = \text{posto}(\mathbf{A}),$$

a SVD compacta é

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r), \quad d_1 \geq \dots \geq d_r > 0.$$

A SVD compacta é uma representação exata. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

descarta parcelas associadas a valores singulares positivos e produz uma aproximação de posto reduzido.

A construção da SVD decorre das decomposições espectrais das duas matrizes de Gram:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Seus autovalores positivos são

$$d_1^2, \dots, d_r^2.$$

Assim, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio.

Geometricamente, a imagem da bola unitária é um elipsoide de dimensão r contido em

$$\mathcal{C}(\mathbf{A}),$$

com semieixos

$$d_1 \mathbf{u}_1, \dots, d_r \mathbf{u}_r.$$

Os valores singulares medem, portanto, os fatores de escala nas direções singulares. Em particular,

$$\|\mathbf{A}\|_2 = d_1,$$

de modo que o maior valor singular é o maior fator de ampliação produzido pela transformação.

A SVD também fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \},$$

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \},$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_r \},$$

e

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{v}_{r+1}, \dots, \mathbf{v}_p \}.$$

Consequentemente,

$$\dim(\mathcal{N}(\mathbf{A})) = p - r$$

e

$$\dim(\mathcal{N}(\mathbf{A}^\top)) = q - r.$$

As normas espectral e de Frobenius possuem representações simples em termos dos valores singulares:

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a SVD compacta fornece

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Como

$$\mathbf{X} = \mathbf{Z} \mathbf{V}_r^\top,$$

essa representação é exata quando são mantidos todos os r componentes singulares positivos.

Além disso,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top,$$

de modo que a representação compacta preserva os produtos internos, as normas e as distâncias euclidianas entre as observações.

Analogamente,

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top$$

fornece as coordenadas das variáveis nas direções singulares à esquerda.

Quando a matriz de dados está centralizada,

$$\mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Adotando a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Assim, os vetores singulares à direita de $\mathbf{X}_c$ determinam as direções espectrais associadas aos autovalores positivos de $\mathbf{S}$, enquanto

$$\frac{d_j^2}{n-1}$$

são os autovalores positivos correspondentes.

Essa relação antecipa uma das principais conexões entre a SVD e as técnicas de redução de dimensionalidade que serão desenvolvidas posteriormente.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

representa a matriz como uma soma de componentes singulares de posto 1, ortogonais entre si segundo o produto interno de Frobenius.

Na norma de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

é uma decomposição pitagórica da magnitude quadrática total da matriz.

O Teorema de Eckart–Young–Mirsky estabelece que

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é uma solução do problema de melhor aproximação de $\mathbf{A}$ entre todas as matrizes de posto no máximo k , tanto na norma espectral quanto na norma de Frobenius. Os erros mínimos são

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A norma espectral mede o maior erro remanescente em uma direção unitária, enquanto a norma de Frobenius agrega quadraticamente todas as parcelas descartadas.

A pseudoinversa de Moore–Penrose é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

com $\mathbf{A}^+ = \mathbf{0}$ quando $\mathbf{A} = \mathbf{0}$.

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução de mínimos quadrados de menor norma.

Quando

$$r < p,$$

podem existir outros minimizadores, obtidos pela adição de componentes pertencentes a

$$\mathcal{N}(\mathbf{A}).$$

A pseudoinversa seleciona, entre todos eles, o único vetor de menor norma euclidiana.

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b},$$

isto é, a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$, enquanto o resíduo

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+) \mathbf{b}$$

pertence a

$$\mathcal{N}(\mathbf{A}^\top).$$

A Tabela 6.7 reúne as relações principais.

Tabela 6.7: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Utiliza bases ortonormais completas no domínio e no contradomínio
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata usando somente os componentes associados aos valores singulares positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Relaciona uma direção do domínio a uma direção do contradomínio

Objeto	Expressão	Interpretação
Matrizes de Gram	$\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$	Determinam os quadrados dos valores singulares e os vetores singulares correspondentes
Posto	$r = \#\{j : d_j > 0\}$	Dimensão da imagem da transformação
Norma espectral	$\ \mathbf{A}\ _2 = d_1$	Maior fator de ampliação da transformação
Norma de Frobenius	$\ \mathbf{A}\ _F^2 = \sum_{j=1}^r d_j^2$	Magnitude quadrática total da matriz
Coordenadas das observações	$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$	Representação das observações nas direções singulares à direita
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$	Aproximação ótima de posto no máximo k
Erro espectral	$\ \mathbf{A} - \mathbf{A}_k\ _2 = d_{k+1}$	Maior erro do truncamento sobre vetores unitários
Erro de Frobenius	$\ \mathbf{A} - \mathbf{A}_k\ _F^2 = \sum_{j=k+1}^r d_j^2$	Magnitude quadrática total dos componentes descartados
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$	Inverte os fatores de escala associados aos valores singulares positivos
Projeter no espaço coluna	$\mathbf{A} \mathbf{A}^+$	Projeta sobre $\mathcal{C}(\mathbf{A})$
Projeter no espaço linha	$\mathbf{A}^+ \mathbf{A}$	Projeta sobre $\mathcal{C}(\mathbf{A}^\top)$
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}$	Seleciona a solução de mínimos quadrados de menor norma

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir as formas completa, compacta e truncada da SVD;
- diferenciar uma representação compacta exata de uma aproximação truncada de posto reduzido;
- relacionar a SVD às decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$;
- interpretar geometricamente os valores e vetores singulares;
- identificar o posto e os quatro espaços fundamentais por meio da SVD;
- construir os projetores ortogonais associados aos espaços fundamentais;
- calcular e interpretar as normas espectral e de Frobenius a partir dos valores singulares;
- interpretar a dualidade entre observações e variáveis em uma matriz de dados;
- representar exatamente as observações em coordenadas singulares e compreender a preservação de produtos internos e distâncias;

- relacionar a SVD de uma matriz centralizada à estrutura espectral de sua matriz de covariâncias amostral;
- representar uma matriz como soma de componentes singulares ortogonais de posto 1;
- construir aproximações de posto reduzido e determinar seus erros nas normas espectral e de Frobenius;
- aplicar o Teorema de Eckart–Young–Mirsky;
- construir e interpretar a pseudoinversa de Moore–Penrose;
- distinguir solução exata, solução de mínimos quadrados e solução de mínimos quadrados de menor norma;
- interpretar mínimos quadrados como um problema de projeção ortogonal.

Ideia central do capítulo

A Decomposição em Valores Singulares descreve uma matriz por meio de pares de direções ortonormais no domínio e no contradomínio e dos fatores de escala que relacionam essas direções. Essa estrutura revela o posto e os espaços fundamentais, fornece representações exatas ou aproximadas de menor dimensão e permite construir projetores, pseudoinversas e soluções de mínimos quadrados.

A SVD encerra o percurso dedicado às principais estruturas de Álgebra Linear utilizadas neste módulo. Matrizes, espaços vetoriais, transformações lineares, decomposição espectral e SVD fornecem, em conjunto, a base geométrica e matricial para representar estruturas multivariadas.

O próximo capítulo desenvolve **Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada**. Gradientes, Hessianas, multiplicadores de Lagrange, diferenciais matriciais, traços, determinantes e integrais completarão os fundamentos matemáticos necessários para formular problemas de otimização, estimação e transformação de variáveis nos capítulos seguintes.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Neste capítulo, salvo indicação em contrário, $\|\cdot\|$ aplicada a vetores denota a norma euclidiana definida em Definição [1.10](#).

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2,$$

em que $\|\cdot\|_F$ denota a norma de Frobenius definida em Definição 6.7.

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{A}\mathbf{X}\mathbf{B}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Representação de primeira ordem
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a forma da transformação linear que representa localmente a variação da função e, conseqüentemente, a dimensão do gradiente, da Jacobiana ou do operador diferencial utilizado para representá-la.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa o incremento utilizado como argumento da transformação linear que define o diferencial. Assim,

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}$$

é linear em $d\mathbf{x}$.

A notação diferencial é frequentemente interpretada de maneira informal como uma variação infinitesimal. Formalmente, porém, o diferencial é a aplicação linear que fornece a parte de primeira ordem da variação da função.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana estão associados à mesma ideia de aproximação linear local, mas correspondem a contradomínios diferentes. Para uma função escalar, o gradiente fornece a representação vetorial da aplicação linear que define o diferencial. Para uma função vetorial, a Jacobiana fornece a representação matricial dessa aplicação linear.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Proposição 7.1 (Direções de maior crescimento e redução). *Se f é diferenciável em $\mathbf{x}$ e*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior taxa de redução de primeira ordem ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

Comprovação. Pelo Teorema 1.1,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. Aplicando o mesmo argumento à direção oposta, obtém-se o resultado para a maior taxa de redução de primeira ordem. $\square$

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação de primeira ordem não distingue direções de crescimento ou redução, e o comportamento local passa a depender de termos de ordem superior.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^\top \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

Suponha que as derivadas parciais das componentes de $\mathbf{g}$ existam no ponto $\mathbf{x}$. A matriz Jacobiana de $\mathbf{g}$ nesse ponto é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \cdots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} g_1 \\ g_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

Assim, a parte linear local de uma transformação afim é exatamente a matriz $\mathbf{A}$, enquanto o termo de translação desaparece na diferenciação.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.1 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x})) \mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem do produto reflete a composição das aplicações lineares: sobre uma perturbação $\mathbf{h}_{\mathbf{x}} \in \mathbb{R}^p$, atua primeiro $\mathbf{J}_{\mathbf{g}}(\mathbf{x})$ e, sobre o resultado, atua $\mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x}))$. Por isso, na representação matricial, a Jacobiana de $\mathbf{h}$ aparece à esquerda.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})^{\top} \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^{\top} \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função com derivadas parciais de segunda ordem no ponto considerado. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

O segundo diferencial é uma forma quadrática no incremento $d\mathbf{x}$ e descreve a contribuição local de segunda ordem da função.

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a segunda taxa de variação de f ao longo da reta que passa por $\mathbf{x}$ na direção $\mathbf{u}$ e fornece a medida de curvatura direcional utilizada neste capítulo.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned}\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2.\end{aligned}$$

Ela é positiva para todo vetor não nulo. Para vetores unitários, a segunda taxa de variação é maior nas direções com maior componente em módulo no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^{\top} (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2} \right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2 \left(x_2 - \frac{1}{2} \right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.2 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0). \end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a variação local de primeira ordem;
- a Hessiana determina a variação local de segunda ordem.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece. Se a forma quadrática associada à Hessiana é não degenerada, ela fornece o termo dominante da variação local. Quando essa forma se anula em alguma direção, termos de ordem superior podem ser necessários para determinar o comportamento da função.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Proposição 7.2 (Condição necessária de primeira ordem). *Se f é diferenciável em um ponto interior $\mathbf{x}^*$ de seu domínio e possui nesse ponto um máximo ou mínimo local, então*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Comprovação. Se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \neq \mathbf{0},$$

considere a direção unitária

$$\mathbf{u} = \frac{\nabla_{\mathbf{x}} f(\mathbf{x}^*)}{\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\|}.$$

Então,

$$D_{\mathbf{u}} f(\mathbf{x}^*) = \|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| > 0,$$

enquanto

$$D_{-\mathbf{u}} f(\mathbf{x}^*) = -\|\nabla_{\mathbf{x}} f(\mathbf{x}^*)\| < 0.$$

Assim, existem direções locais de aumento e de redução, o que contradiz a existência de um extremo local interior. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

□

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

tem-se

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

A recíproca da proposição anterior não é verdadeira em geral: um ponto estacionário pode ser mínimo local, máximo local ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.3 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável em uma vizinhança de um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^$ é um mínimo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^$ é um máximo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*)$$

é indefinida, então $\mathbf{x}^$ é um ponto de sela.*

Se a Hessiana é apenas semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)

Comprovação. Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Considere inicialmente

$$\mathbf{H} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Como $\mathbf{H}$ é simétrica e positiva definida, seu menor autovalor satisfaz

$$\lambda_{\min}(\mathbf{H}) > 0.$$

Portanto,

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} \geq \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2.$$

Além disso,

$$o(\|\mathbf{h}\|^2) = \varepsilon(\mathbf{h}) \|\mathbf{h}\|^2,$$

com

$$\varepsilon(\mathbf{h}) \rightarrow 0$$

quando $\mathbf{h} \rightarrow \mathbf{0}$.

Logo, para $\mathbf{h}$ suficientemente pequeno,

$$|\varepsilon(\mathbf{h})| < \frac{1}{4} \lambda_{\min}(\mathbf{H}).$$

Assim,

$$\begin{aligned} f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) &\geq \frac{1}{2} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 - \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &= \frac{1}{4} \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2 \\ &> 0 \end{aligned}$$

para todo $\mathbf{h} \neq \mathbf{0}$ suficientemente pequeno. Portanto, $\mathbf{x}^*$ é um mínimo local estrito.

O caso de Hessiana negativa definida é obtido aplicando o mesmo argumento a $-f$, produzindo um máximo local estrito.

Se a Hessiana é indefinida, existem vetores unitários $\mathbf{u}_1$ e $\mathbf{u}_2$ tais que

$$\mathbf{u}_1^\top \mathbf{H} \mathbf{u}_1 > 0$$

e

$$\mathbf{u}_2^\top \mathbf{H} \mathbf{u}_2 < 0.$$

Considere perturbações da forma

$$\mathbf{h} = t\mathbf{u}_j.$$

Então,

$$f(\mathbf{x}^* + t\mathbf{u}_j) - f(\mathbf{x}^*) = \frac{1}{2}t^2\mathbf{u}_j^\top \mathbf{H}\mathbf{u}_j + o(t^2).$$

Para $|t|$ suficientemente pequeno, o sinal dessa diferença coincide com o sinal da forma quadrática. Assim, a função assume valores maiores que

$$f(\mathbf{x}^*)$$

em uma direção e menores em outra, arbitrariamente próximos de $\mathbf{x}^*$. Portanto, $\mathbf{x}^*$ é um ponto de sela. $\square$

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0, 0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1-t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, conjuntos afins como hiperplanos, bolas e regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.4 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.5 (Critério da Hessiana para convexidade). *Considere uma função*

$$f : \mathcal{C} \longrightarrow \mathbb{R}$$

duas vezes continuamente diferenciável em um conjunto convexo aberto

$$\mathcal{C} \subseteq \mathbb{R}^p.$$

Então, f é convexa em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Analogamente, f é côncava em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Além disso, se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa. Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente côncava.

(Boyd; Vandenberghe, 2004)

Comprovação. Considere dois pontos distintos

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e defina

$$g(t) = f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})), \quad 0 \leq t \leq 1.$$

Como $\mathcal{C}$ é convexo, todo o segmento entre $\mathbf{x}$ e $\mathbf{y}$ pertence a $\mathcal{C}$.

Pela regra da cadeia,

$$g''(t) = (\mathbf{y} - \mathbf{x})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) (\mathbf{y} - \mathbf{x}).$$

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{z}) \succeq \mathbf{0}$$

para todo $\mathbf{z} \in \mathcal{C}$, então

$$g''(t) \geq 0,$$

e, portanto, g é convexa em $[0, 1]$. Como isso vale para qualquer segmento contido em $\mathcal{C}$, f é convexa.

Reciprocamente, se f é convexa, então a restrição de f a qualquer reta é convexa. Para qualquer

$$\mathbf{x} \in \mathcal{C}$$

e qualquer direção

$$\mathbf{u} \in \mathbb{R}^p,$$

considere

$$h(t) = f(\mathbf{x} + t\mathbf{u})$$

para t suficientemente próximo de zero. A convexidade de h implica

$$h''(0) \geq 0.$$

Como

$$h''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u},$$

tem-se

$$\mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u} \geq 0$$

para todo $\mathbf{u}$. Logo,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}.$$

O resultado para funções côncavas segue aplicando o argumento a $-f$.

Se a Hessiana é positiva definida em todo ponto, então, para $\mathbf{x} \neq \mathbf{y}$,

$$g''(t) > 0$$

ao longo do segmento. Logo, g é estritamente convexa, e portanto f é estritamente convexa. O caso de Hessiana negativa definida é análogo. $\square$

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

A condição

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

em todo o domínio é suficiente para convexidade estrita, mas não é necessária. Uma função estritamente convexa pode possuir Hessiana singular em pontos isolados. Por exemplo,

$$f(x) = x^4$$

é estritamente convexa em $\mathbb{R}$, embora

$$f''(0) = 0.$$

7.4.5 Consequências para otimização

Proposição 7.3 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa e existe um ponto estacionário $\mathbf{x}^$, então esse ponto é o único minimizador global. (Boyd; Vandenberghe, 2004)*

Comprovação. Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$. $\square$

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

De fato, como $\mathbf{A}$ é simétrica,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}).$$

Assim, existe

$$\mathbf{z} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{b}^\top \mathbf{z} \neq 0.$$

Ao longo da reta

$$\mathbf{x} = t\mathbf{z},$$

o termo quadrático é nulo e

$$f(t\mathbf{z}) = -t\mathbf{b}^\top \mathbf{z} + c,$$

que pode tender a $-\infty$ escolhendo o sinal apropriado de t .

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

A Proposição 7.2 estabelece a condição necessária de primeira ordem para extremos locais interiores, enquanto o Teorema 7.3 utiliza a Hessiana para classificar pontos estacionários quando o teste de segunda ordem é conclusivo.

No caso convexo, a Proposição 7.3 mostra que um ponto estacionário é minimizador global. Esses resultados fornecem as condições de otimalidade; a questão seguinte é construir um procedimento iterativo para localizar esses pontos.

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top (\mathbf{x} - \mathbf{x}^{(t)}) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}). \end{aligned}$$

Defina

$$\mathbf{g}^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$$

e

$$\mathbf{H}^{(t)} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}).$$

Escrevendo

$$\mathbf{d} = \mathbf{x} - \mathbf{x}^{(t)},$$

o modelo quadrático local pode ser representado por

$$m_t(\mathbf{d}) = f(\mathbf{x}^{(t)}) + (\mathbf{g}^{(t)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{H}^{(t)} \mathbf{d}.$$

Seu gradiente em relação a $\mathbf{d}$ é

$$\nabla_{\mathbf{d}} m_t(\mathbf{d}) = \mathbf{g}^{(t)} + \mathbf{H}^{(t)} \mathbf{d}.$$

Se

$$\mathbf{H}^{(t)} \succ \mathbf{0},$$

o modelo quadrático é estritamente convexo e possui um único minimizador. Esse minimizador, denominado **direção de Newton**, satisfaz

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}.$$

Quando $\mathbf{H}^{(t)}$ é invertível,

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

A atualização de Newton com passo completo é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)},$$

ou, equivalentemente,

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver o sistema linear

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

sem calcular explicitamente a inversa da Hessiana.

Se a Hessiana é apenas invertível, mas não positiva definida, a solução desse sistema é um ponto estacionário do modelo quadrático, mas pode não ser seu minimizador. Nesse caso, a direção de Newton também pode deixar de ser uma direção de descida para a função original.

Proposição 7.4 (Direção de Newton como direção de descida). *Suponha que*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) \neq \mathbf{0}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \succ \mathbf{0}.$$

Então a direção de Newton $\mathbf{d}^{(t)}$ é uma direção de descida para f em $\mathbf{x}^{(t)}$, isto é,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

Comprovação. Como

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)},$$

tem-se

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} = -(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

Como $\mathbf{H}^{(t)} \succ \mathbf{0}$, também

$$(\mathbf{H}^{(t)})^{-1} \succ \mathbf{0}.$$

Logo, para $\mathbf{g}^{(t)} \neq \mathbf{0}$,

$$(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)} > 0,$$

e, portanto,

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

□

O passo completo corresponde a

$$\alpha_t = 1.$$

Uma forma mais geral da atualização é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \alpha_t \mathbf{d}^{(t)}, \quad 0 < \alpha_t \leq 1.$$

A escolha de $\alpha_t < 1$ produz um passo de Newton amortecido. Esse recurso pode ser utilizado quando o modelo quadrático local ainda não representa adequadamente a função ao longo de um passo completo.

Assim, a construção da direção e a escolha do comprimento da etapa são operações distintas. Métodos numéricos de otimização costumam combinar a direção de Newton com procedimentos de controle da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana constante e positiva definida, uma etapa completa de Newton conduz exatamente ao único minimizador,

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b},$$

independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, as linhas da Jacobiana das restrições são linearmente independentes. O espaço tangente ao conjunto viável é então

$$\mathcal{T}_{\mathbf{x}} = \mathcal{N}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})).$$

Portanto, uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

O espaço normal correspondente é

$$\mathcal{T}_{\mathbf{x}}^{\perp} = \mathcal{C}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})^{\top}),$$

isto é, o espaço gerado pelos gradientes das restrições.

Em um ótimo local regular $\mathbf{x}^*$, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{T}_{\mathbf{x}^*}.$$

Consequentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{T}_{\mathbf{x}^*}^\perp = \mathcal{C} \left[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \right].$$

7.6.1 Multiplicadores de Lagrange

Teorema 7.6 (Condição de Lagrange). *Considere funções continuamente diferenciáveis*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

e

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m.$$

Seja $\mathbf{x}^*$ um ótimo local do problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)$$

sejam linearmente independentes.

Essa condição equivale a

$$\text{posto } [\mathbf{J}_c(\mathbf{x}^*)] = m.$$

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_c(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

Comprovação. Como $\mathbf{x}^*$ é um ótimo local regular, a derivada direcional da função objetivo é nula em todas as direções tangentes ao conjunto viável. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{N}[\mathbf{J}_c(\mathbf{x}^*)].$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{N}[\mathbf{J}_c(\mathbf{x}^*)]^\perp.$$

Pelo Teorema 3.6,

$$\mathcal{N}[\mathbf{J}_c(\mathbf{x}^*)]^\perp = \mathcal{C}[\mathbf{J}_c(\mathbf{x}^*)^\top].$$

Assim, existe um vetor

$$\mu^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{J}_c(\mathbf{x}^*)^\top \mu^*.$$

Definindo

$$\lambda^* = -\mu^*,$$

obtém-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

□

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

Sob a condição de regularidade do teorema, as condições necessárias de primeira ordem podem ser escritas como

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Essas condições identificam candidatos a ótimo restrito. No caso geral, elas não são suficientes para garantir mínimo ou máximo. A classificação exige condições adicionais sobre a função objetivo, as restrições e a variação de segunda ordem nas direções tangentes.

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere o problema

$$\max_{\mathbf{x}} \mathbf{a}^\top \mathbf{x},$$

em que

$$\mathbf{a} \neq \mathbf{0},$$

sujeito à restrição

$$\mathbf{x}^\top \mathbf{x} = 1.$$

A restrição exige que $\mathbf{x}$ tenha norma euclidiana unitária:

$$\|\mathbf{x}\| = 1.$$

Escrevendo-a na forma

$$c(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} - 1 = 0,$$

o problema pode ser tratado pelos multiplicadores de Lagrange.

Para manter a formulação como um problema de minimização, considere a função objetivo

$$f(\mathbf{x}) = -\mathbf{a}^\top \mathbf{x}.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^\top \mathbf{x} + \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

As condições de primeira ordem são obtidas diferenciando a lagrangiana em relação a $\mathbf{x}$ e ao multiplicador λ .

Em relação a $\mathbf{x}$,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a} + 2\lambda \mathbf{x}.$$

Portanto, em um ponto candidato à solução,

$$-\mathbf{a} + 2\lambda \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}.$$

Em relação a λ ,

$$\frac{\partial \mathcal{L}(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{x}^\top \mathbf{x} - 1.$$

Assim, a segunda condição de primeira ordem simplesmente recupera a restrição:

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Substituindo

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}$$

na restrição,

$$\left(\frac{1}{2\lambda} \mathbf{a} \right)^\top \left(\frac{1}{2\lambda} \mathbf{a} \right) = 1,$$

e, portanto,

$$\frac{\mathbf{a}^\top \mathbf{a}}{4\lambda^2} = 1.$$

Como

$$\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|^2,$$

segue que

$$4\lambda^2 = \|\mathbf{a}\|^2,$$

ou

$$\lambda = \pm \frac{\|\mathbf{a}\|}{2}.$$

Consequentemente, existem dois pontos candidatos:

$$\mathbf{x}_1 = \frac{\mathbf{a}}{\|\mathbf{a}\|}$$

e

$$\mathbf{x}_2 = -\frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

Para identificar qual deles maximiza a função objetivo original, avalie

$$\mathbf{a}^\top \mathbf{x}.$$

No primeiro ponto,

$$\mathbf{a}^\top \mathbf{x}_1 = \mathbf{a}^\top \frac{\mathbf{a}}{\|\mathbf{a}\|} = \frac{\|\mathbf{a}\|^2}{\|\mathbf{a}\|} = \|\mathbf{a}\|.$$

No segundo,

$$\mathbf{a}^\top \mathbf{x}_2 = -\|\mathbf{a}\|.$$

Logo, o máximo é atingido em

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|},$$

e o valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Geometricamente, a solução mostra que, entre todos os vetores unitários, o produto interno com $\mathbf{a}$ é máximo quando $\mathbf{x}$ possui a mesma direção e o mesmo sentido de $\mathbf{a}$.

O resultado também coincide com o caso de igualdade no Teorema 1.1, pois

$$\mathbf{a}^\top \mathbf{x} \leq \|\mathbf{a}\| \|\mathbf{x}\| = \|\mathbf{a}\|,$$

e a igualdade ocorre quando $\mathbf{x}$ é proporcional a $\mathbf{a}$.

Se $\mathbf{a} = \mathbf{0}$, a função objetivo é constante e todo vetor unitário satisfaz

$$\mathbf{a}^\top \mathbf{x} = 0.$$

Nesse caso, todo vetor que satisfaz a restrição é uma solução ótima.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Portanto, todo ponto regular estacionário do problema restrito é um autovetor de $\mathbf{A}$, e o valor da função objetivo nesse ponto é o autovalor correspondente.

Pelo Teorema 5.5, desenvolvido no capítulo de decomposição espectral,

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\max}(\mathbf{A}),$$

e

$$\min_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\min}(\mathbf{A}).$$

Assim, os multiplicadores de Lagrange produzem a equação de autovalores como condição de estacionariedade, enquanto o resultado espectral identifica quais desses pontos realizam os extremos globais.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica,

$$\mathbf{C} \in \mathbb{R}^{m \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^m.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

Esse sistema em blocos reúne as condições de primeira ordem do problema restrito.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e $\mathbf{C}$ possui posto linha completo, a função objetivo é estritamente convexa e o conjunto definido por

$$\mathbf{C}\mathbf{x} = \mathbf{d}$$

é afim. Quando esse conjunto é não vazio, as condições de primeira ordem identificam o único minimizador global.

Mais geralmente, para uma matriz $\mathbf{A}$ semidefinida positiva, a unicidade depende de a forma quadrática ser positiva nas direções viáveis não nulas, isto é,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} > 0$$

para todo

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{C}\mathbf{z} = \mathbf{0}.$$

Sem condições desse tipo, a resolução do sistema fornece apenas candidatos que satisfazem as condições de primeira ordem.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Derivadas de formas quadráticas

As formas quadráticas foram definidas em Definição 2.23, e a Proposição 2.10 mostrou que seu valor depende apenas da parte simétrica da matriz. O objetivo agora é obter suas derivadas.

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Proposição 7.5 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

Comprovação. Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana. □

Utilizando a classificação de positividade apresentada em Definição 2.24, se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, todos os vetores da forma

$$\mathbf{x} = \mu + \mathbf{z}, \quad \mathbf{z} \in \mathcal{N}(\mathbf{A}),$$

também minimizam a função. Portanto, a unicidade ocorre quando

$$\mathbf{A} \succ \mathbf{0}.$$

7.7.3 Derivadas da norma euclidiana

Retomando a norma euclidiana definida em Definição 1.10,

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Portanto,

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{Ax})^\top (\mathbf{b} - \mathbf{Ax}).$$

Pela regra da cadeia,

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{Ax}).\end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

A Hessiana é constante e não depende de $\mathbf{x}$. Além disso,

$$\mathbf{z}^\top \mathbf{A}^\top \mathbf{Az} = \|\mathbf{Az}\|^2 \geq 0,$$

para todo

$$\mathbf{z} \in \mathbb{R}^p.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

As equações normais já foram introduzidas geometricamente em Definição 3.21, a partir da projeção sobre o espaço coluna. No Capítulo 6, Proposição 6.22 apresentou a solução por meio da SVD e da pseudoinversa. Nesta seção, o mesmo resultado será obtido a partir da condição de primeira ordem do cálculo diferencial.

7.7.5 Equações normais

Proposição 7.6 (Caracterização dos mínimos quadrados pelas equações normais). *Considere*

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2,$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é minimizador global de f se, e somente se, satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}.$$

Se $\mathbf{A}$ possui posto coluna completo, o minimizador é único e dado por

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Comprovação. A derivação anterior fornece

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Logo, f é convexa. Pelo Proposição 7.3, um ponto é minimizador global se, e somente se, seu gradiente é nulo. Portanto,

$$\nabla_{\mathbf{x}} f(\hat{\mathbf{x}}) = \mathbf{0}$$

se, e somente se,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

de modo que f é estritamente convexa e possui, no máximo, um minimizador. Como

$$\mathbf{A}^\top \mathbf{A}$$

é invertível, esse minimizador é

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

□

A condição

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}$$

mostra que o resíduo de mínimos quadrados é ortogonal ao espaço coluna de $\mathbf{A}$.

O caso de posto deficiente, o conjunto de todos os minimizadores e a solução de menor norma foram estabelecidos em Proposição 6.22. Aqui, o objetivo é destacar que as equações normais surgem diretamente da condição de primeira ordem do problema de otimização.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos não negativos

$$\omega_1, \dots, \omega_q \geq 0$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Como Ω é diagonal e, portanto, simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, em qualquer minimizador, o resíduo satisfaz a condição de ortogonalidade ponderada

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Quando

$$\Omega \succ \mathbf{0},$$

retoma-se o produto interno induzido definido em Definição 3.16:

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^{\top} \Omega \mathbf{v}.$$

A condição anterior corresponde, portanto, à ortogonalidade do resíduo ao espaço coluna de $\mathbf{A}$ nessa geometria ponderada.

Se Ω é singular, a mesma condição algébrica permanece válida, mas a forma ponderada é apenas semidefinida positiva e não define um produto interno em todo o espaço.

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^{\top} \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^{\top} \Omega \mathbf{A})^{-1} \mathbf{A}^{\top} \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

Quando

$$\Omega \succ \mathbf{0},$$

o critério pode ser escrito utilizando a norma induzida de Definição 3.17:

$$f_{\omega}(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|_{\Omega}^2,$$

com

$$\|\mathbf{z}\|_{\Omega}^2 = \mathbf{z}^{\top} \Omega \mathbf{z}.$$

Assim, os mínimos quadrados ponderados correspondem a uma projeção segundo a geometria induzida por Ω .

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma classe ampla de funções de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual duas vezes diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Proposição 7.7 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Comprovação. Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}). \end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^\top + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana. □

A Hessiana possui, portanto, duas parcelas com papéis distintos:

$$\underbrace{2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x})}_{\text{parcela de primeira ordem dos resíduos}} + \underbrace{2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x})}_{\text{correção de não linearidade}} .$$

O primeiro termo da Hessiana,

$$2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}),$$

é semidefinido positivo. Isso não implica, porém, que a função de mínimos quadrados não linear seja convexa, pois a segunda parcela da Hessiana pode ser indefinida.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos ou quando as Hessianas das funções residuais têm contribuição reduzida na região considerada, a segunda parcela pode ser desprezada aproximadamente. Nesse caso,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}).$$

No caso linear,

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}}^2 r_i(\mathbf{x}) = \mathbf{0}$$

para todo i . Portanto, a segunda parcela desaparece exatamente e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Retomando a convenção estabelecida no início do capítulo, o gradiente matricial é

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius definido em Definição 6.6,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr}(\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

Assim como o gradiente de uma função escalar de vetor representa o diferencial segundo o produto interno euclidiano, o gradiente matricial representa o diferencial segundo o produto interno de Frobenius.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço foi definido em Definição 2.9, e suas propriedades algébricas foram estabelecidas em Proposição 2.5 e Proposição 2.8. Para o cálculo matricial, serão utilizadas especialmente as permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}}\phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Proposição 7.8 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

Comprovação. O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}.$$

□

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Derivadas da norma de Frobenius

Pela Definição 6.7,

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

De fato, essa função é estritamente convexa em $\mathbf{X}$, pois sua segunda variação em uma perturbação não nula $d\mathbf{X}$ é

$$d^2\phi = 2\|d\mathbf{X}\|_F^2 > 0.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}}\phi = \mathbf{A}\mathbf{X}\Gamma + \mathbf{A}^{\top}\mathbf{X}\Gamma^{\top}.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

A dimensão do gradiente coincide com a dimensão do argumento:

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{m \times n}.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{\top}\mathbf{A}\mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_{\cdot 1}, \dots, \mathbf{x}_{\cdot n},$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_{\cdot j}^{\top} \mathbf{A} \mathbf{x}_{\cdot j}.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_{\cdot 1}, \dots, 2\mathbf{A}\mathbf{x}_{\cdot n}.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{XB}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{XB} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Se $\mathbf{X}$ não possui posto coluna completo, os minimizadores não são únicos. A solução de mínimos quadrados de menor norma de Frobenius é

$$\widehat{\mathbf{B}}^\star = \mathbf{X}^+ \mathbf{Y}.$$

Mais geralmente, todos os minimizadores podem ser escritos como

$$\widehat{\mathbf{B}} = \mathbf{X}^+ \mathbf{Y} + (\mathbf{I}_k - \mathbf{X}^+ \mathbf{X}) \mathbf{C},$$

em que

$$\mathbf{C} \in \mathbb{R}^{k \times p}$$

é arbitrária.

A parcela adicional pertence ao núcleo da transformação

$$\mathbf{B} \mapsto \mathbf{XB}$$

e, portanto, não altera os valores ajustados.

Assim, quando o critério utilizado é simplesmente a norma de Frobenius dos resíduos, o problema matricial pode ser interpretado como p problemas de mínimos quadrados que compartilham a mesma matriz de delineamento.

Proposição 7.9 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{X}\mathbf{B}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa se, e somente se, $\mathbf{X}$ possui posto coluna completo.

Comprovação. Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa.

Reciprocamente, se $\mathbf{X}$ não possui posto coluna completo, existe

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{X}\mathbf{z} = \mathbf{0}.$$

Escolha qualquer vetor não nulo

$$\mathbf{c} \in \mathbb{R}^p$$

e defina

$$d\mathbf{B} = \mathbf{z}\mathbf{c}^\top.$$

Então

$$d\mathbf{B} \neq \mathbf{0},$$

mas

$$\mathbf{X} d\mathbf{B} = \mathbf{0}.$$

Portanto,

$$d^2Q = 0$$

em uma direção não nula, e a função não é estritamente convexa. □

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

Como

$$\Omega \succeq \mathbf{0}$$

e

$$\Sigma \succ \mathbf{0},$$

o critério também pode ser escrito como

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \left\| \Omega^{1/2} \mathcal{E}(\mathbf{B}) \Sigma^{-1/2} \right\|_F^2.$$

Essa forma mostra que a ponderação atua simultaneamente nas duas dimensões da matriz residual.

A matriz Ω atua no espaço das observações e pondera as linhas da matriz de resíduos. A matriz Σ^{-1} atua no espaço das respostas e define a geometria utilizada para combinar as colunas da matriz de resíduos.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \operatorname{tr} \left[(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B} \right].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{X} \mathbf{B} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, ou equivalentemente, se as colunas de

$$\Omega^{1/2} \mathbf{X}$$

são linearmente independentes, então o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Para Σ fixa e positiva definida, a ponderação invertível no espaço das respostas altera o valor do critério e sua geometria, mas não altera o conjunto de minimizadores em relação a $\mathbf{B}$.

Isso ocorre porque

$$\Sigma^{-1}$$

é invertível e pode ser eliminada da condição de primeira ordem.

A ponderação das observações por Ω , por outro lado, permanece nas equações normais e pode modificar o estimador.

Os diferenciais matriciais e as identidades de traço permitem agora tratar funções em que a própria matriz variável aparece no interior de uma inversa ou de um determinante. Essas estruturas são particularmente importantes quando o parâmetro pertence ao conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

A matriz inversa e o determinante foram definidos em Definição 2.11 e Definição 2.13, enquanto a relação entre determinante e invertibilidade foi estabelecida em Teorema 2.4. A classificação das matrizes simétricas por positividade foi apresentada em Definição 2.24.

Nesta seção, esses objetos são retomados como funções de uma matriz variável. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Proposição 7.10 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019)

Comprovação. Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

□

Quando $\mathbf{X} \succ \mathbf{0}$ e a perturbação

$$d\mathbf{X} \succeq \mathbf{0},$$

tem-se

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \succeq \mathbf{0},$$

e, portanto,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \preceq \mathbf{0}.$$

Assim, a inversão reverte a ordem de Loewner: aumentos semidefinidos positivos da matriz produzem variações semidefinidas negativas de sua inversa.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Proposição 7.11 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019)

Comprovação. Considere uma perturbação $\mathbf{H}$ e a função

$$g(t) = \det(\mathbf{X} + t\mathbf{H}).$$

Como $\mathbf{X}$ é invertível,

$$g(t) = \det(\mathbf{X}) \det(\mathbf{I}_p + t\mathbf{X}^{-1}\mathbf{H}).$$

Pela multilinearidade do determinante,

$$\det(\mathbf{I}_p + t\mathbf{M}) = 1 + t \operatorname{tr}(\mathbf{M}) + o(t).$$

Aplicando essa expansão com

$$\mathbf{M} = \mathbf{X}^{-1}\mathbf{H},$$

obtém-se

$$g(t) = \det(\mathbf{X}) [1 + t \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}) + o(t)].$$

Logo,

$$g'(0) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}).$$

Como $\mathbf{H}$ representa uma perturbação arbitrária,

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

□

Como

$$d \det(\mathbf{X}) = \operatorname{tr} [(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X}],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

A restrição

$$\mathbf{X} \succ \mathbf{0}$$

garante simultaneamente que $\mathbf{X}$ é invertível e que

$$\det(\mathbf{X}) > 0,$$

de modo que o logaritmo real do determinante está bem definido.

Proposição 7.12 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

Comprovação. Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \text{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \text{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente. □

Para uma matriz real invertível, não necessariamente simétrica, pode-se considerar

$$\phi(\mathbf{X}) = \log |\det(\mathbf{X})|.$$

Como o determinante não se anula no conjunto das matrizes invertíveis, seu sinal permanece constante em uma vizinhança suficientemente pequena de cada matriz invertível. Nesse domínio,

$$d \log |\det(\mathbf{X})| = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}),$$

e, portanto,

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}.$$

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2\phi = -\text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Logo,

$$d^2\phi \leq 0.$$

Proposição 7.13 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas.

(Boyd; Vandenberghe, 2004)

Comprovação. O conjunto das matrizes simétricas positivas definidas é convexo. Para toda matriz

$$\mathbf{X} \succ \mathbf{0}$$

e toda direção simétrica não nula $\mathbf{H}$,

$$d^2\phi[\mathbf{H}, \mathbf{H}] = -\|\mathbf{X}^{-1/2}\mathbf{H}\mathbf{X}^{-1/2}\|_F^2 < 0.$$

Logo, a restrição de ϕ a qualquer segmento não degenerado do cone positivo definido possui segunda derivada negativa. Portanto,

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava nesse domínio. □

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}\mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\text{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Observe que o gradiente possui a mesma dimensão de $\mathbf{X}$,

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{p \times p}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^\top \mathbf{X}^{-1} \mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top \mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}} \phi = -(\mathbf{X}^{-1} \mathbf{a})(\mathbf{X}^{-1} \mathbf{a})^\top.$$

Essa matriz é semidefinida negativa.

Consequentemente, para uma perturbação

$$\mathbf{H} \succeq \mathbf{0},$$

tem-se

$$d\phi[\mathbf{H}] = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top \mathbf{H}] \leq 0.$$

Assim, aumentar $\mathbf{X}$ segundo a ordem de Loewner não aumenta a forma quadrática inversa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^\top \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}} \phi = 2\mathbf{X}^{-1} \mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{x}\mathbf{x}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere $n > 0$ e o critério

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dQ &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma}Q = \frac{n}{2}\Sigma^{-1} - \frac{1}{2}\Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

A condição de primeira ordem é

$$n\Sigma^{-1} = \Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n\Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Proposição 7.14 (Minimização do critério de covariância). *Considere*

$$n > 0$$

e uma matriz

$$\mathbf{G} \succ \mathbf{0}.$$

Então, a função

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Comprovação. Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\mathrm{tr}(\Sigma^{-1}\mathbf{G}) = \mathrm{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$Q(\Sigma) = \frac{1}{2} [\mathrm{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$Q(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

$$z = n.$$

Como cada parcela

$$z_j - n \log z_j$$

possui mínimo único em $z_j = n$, o mínimo global exige

$$z_1 = \cdots = z_p = n.$$

Portanto,

$$\mathbf{Z} = n\mathbf{I}_p.$$

Essa igualdade equivale a

$$\Sigma = \frac{1}{n}\mathbf{G}.$$

□

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido.

Além disso, o critério é ilimitado inferiormente. De fato, escolhendo uma direção unitária

$$\mathbf{u} \in \mathcal{N}(\mathbf{G}),$$

pode-se fazer o autovalor de Σ associado a essa direção tender a zero. Nessa direção, o termo

$$\text{tr}(\Sigma^{-1}\mathbf{G})$$

não recebe contribuição, enquanto

$$\log \det(\Sigma) \longrightarrow -\infty.$$

Portanto,

$$Q(\Sigma) \longrightarrow -\infty,$$

e o problema não possui minimizador no cone positivo definido.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

Nesta seção, o núcleo necessário para os capítulos seguintes é formado por três ideias:

- o operador vec ;
- o produto de Kronecker;
- a identidade que relaciona vec e produtos matriciais.

As subseções posteriores sobre Hessianas vetorizadas, matriz de comutação, meia vetorização, matrizes de duplicação e eliminação e Jacobianas de transformações matriciais serão apresentadas como aprofundamento. Elas são úteis em desenvolvimentos mais avançados de cálculo matricial e inferência, mas não são necessárias para uma primeira leitura do restante do livro.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11} \mathbf{C} & \cdots & a_{1n} \mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1} \mathbf{C} & \cdots & a_{mn} \mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1)(\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Proposição 7.15 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{A}\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

A identidade mostra que uma transformação que atua simultaneamente à esquerda e à direita de uma matriz pode ser representada como uma transformação linear usual sobre o vetor formado por seus elementos.

Assim,

$$\mathbf{X} \mapsto \mathbf{A}\mathbf{X}\mathbf{\Gamma}$$

corresponde, após vetorização, a

$$\text{vec}(\mathbf{X}) \mapsto (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X}\mathbf{\Gamma}.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \mathbf{\Gamma}.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \mathbf{\Gamma}^\top \otimes \mathbf{A}.$$

7.10.4 Aprofundamento: derivadas vetorizadas e parâmetros matriciais

Leitura de aprofundamento

As subseções seguintes desenvolvem ferramentas úteis quando parâmetros matriciais precisam ser tratados explicitamente como vetores. Elas permitem representar Hessianas, transposições, parâmetros simétricos e Jacobianas matriciais por meio de vec , produto de Kronecker e matrizes especiais.

Esses resultados são importantes em desenvolvimentos avançados de inferência multivariada e cálculo matricial, mas podem ser omitidos em uma primeira leitura sem comprometer a continuidade dos capítulos seguintes.

7.10.4.1 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr} (\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec} (\nabla_{\mathbf{X}} \phi)^\top d \text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec} (\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.4.2 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec} (\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned}\text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}).\end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Proposição 7.16 (Convexidade da forma quadrática matricial). *Considere*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A}\mathbf{X}\Gamma),$$

em que

$$\mathbf{A} = \mathbf{A}^\top \in \mathbb{R}^{m \times m}$$

e

$$\Gamma = \Gamma^\top \in \mathbb{R}^{n \times n}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então ϕ é convexa em $\mathbf{X}$.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então ϕ é estritamente convexa.

Comprovação. A Hessiana vetorizada é

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2 (\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succ \mathbf{0},$$

então

$$\Gamma \otimes \mathbf{A} \succeq \mathbf{0}.$$

Logo, a Hessiana é semidefinida positiva e ϕ é convexa.

Se ambas as matrizes são positivas definidas, então

$$\Gamma \otimes \mathbf{A} \succ \mathbf{0}.$$

Nesse caso, a Hessiana é positiva definida e ϕ é estritamente convexa. □

7.10.4.3 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^\top.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^\top$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r}(\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.4.4 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{A}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior de $\mathbf{A}$, incluindo a diagonal.

Quando

$$\mathbf{A} = \mathbf{S} = \mathbf{S}^\top,$$

o operador vech contém exatamente os elementos distintos de $\mathbf{S}$. Por isso, ele fornece uma parametrização sem redundância do espaço das matrizes simétricas.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos. A redução ocorre porque uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos. Assim, vech fornece uma parametrização sem redundância do espaço das matrizes simétricas.

7.10.4.5 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.4.6 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é a matriz de seleção que satisfaz

$$\text{vech}(\mathbf{A}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{A})$$

para toda matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \neq \mathbf{I}_{p^2}.$$

A matriz $\mathbf{L}_p^{\text{elim}}$ conserva apenas os elementos correspondentes à parte triangular inferior, enquanto $\mathbf{D}_p^{\text{dup}}$ reconstrói uma matriz impondo simetria. Portanto, esse produto não recupera arbitrariamente uma matriz não simétrica.

Para uma matriz simétrica $\mathbf{S}$, entretanto,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S}) = \text{vec}(\mathbf{S}).$$

7.10.4.7 Diferenciais de parâmetros simétricos

Proposição 7.17 (Gradiente em relação aos elementos distintos de uma matriz simétrica).
Considere um parâmetro matricial

$$\Sigma = \Sigma^\top \in \mathbb{R}^{p \times p}$$

e uma função escalar

$$\phi(\Sigma).$$

Suponha que seu diferencial possa ser escrito como

$$d\phi = \text{tr} [\mathbf{G}^\top d\Sigma],$$

em que

$$d\Sigma = d\Sigma^\top.$$

Então,

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

Em particular, quando

$$\mathbf{G} = \nabla_\Sigma \phi,$$

tem-se

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\nabla_\Sigma \phi).$$

Comprovação. Como

$$\text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} \text{vech}(\Sigma),$$

tem-se

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Além disso,

$$d\phi = \text{vec}(\mathbf{G})^\top d \text{vec}(\Sigma).$$

Substituindo,

$$d\phi = \text{vec}(\mathbf{G})^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Logo,

$$d\phi = \left[(\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}) \right]^\top d \text{vech}(\Sigma),$$

de onde segue

$$\nabla_{\text{vech}(\Sigma)} \phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

□

A parametrização por

$$\text{vech}(\Sigma)$$

remove a redundância existente em

$$\text{vec}(\Sigma),$$

pois uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos livres.

7.10.4.8 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^{\top} \mathbf{X} + \mathbf{X}^{\top} d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned} \text{vec}(d\mathbf{X}^{\top} \mathbf{X}) &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^{\top}) \\ &= (\mathbf{X}^{\top} \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}). \end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^{\top} d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^{\top}) \text{vec}(d\mathbf{X}).$$

Logo,

$$d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) = [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ \times d \operatorname{vec}(\mathbf{X}).$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica, a representação por

$$\operatorname{vec}(\mathbf{X}^\top \mathbf{X})$$

contém elementos repetidos. Uma representação sem redundância é obtida por

$$\operatorname{vech}(\mathbf{X}^\top \mathbf{X}).$$

Aplicando a matriz de eliminação,

$$d \operatorname{vech}(\mathbf{X}^\top \mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} d \operatorname{vec}(\mathbf{X}^\top \mathbf{X}) \\ = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \operatorname{vec}(\mathbf{X}).$$

Assim, a Jacobiana relativa somente aos elementos distintos de $\mathbf{X}^\top \mathbf{X}$ é

$$\mathbf{J}_{\operatorname{vech} \circ \mathcal{G}}(\mathbf{X}) = \mathbf{L}_n^{\operatorname{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}).$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

O bloco de aprofundamento mostrou como vec e o produto de Kronecker podem ser estendidos para representar derivadas de ordem superior e parâmetros matriciais com restrições estruturais.

Para a continuidade do livro, as ideias essenciais a reter desta seção são

$$\text{vec}(\mathbf{A}\mathbf{X}\mathbf{\Gamma}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e o fato de que matrizes simétricas possuem apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças, momentos e distribuições marginais de vetores aleatórios contínuos. A mudança de variáveis permite, adicionalmente, transformar regiões de integração e determinar densidades após transformações do vetor aleatório.

Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$. Nesta seção, integrais múltiplas, marginalização, esperanças e mudança de variáveis constituem o núcleo necessário para os capítulos probabilísticos seguintes. A diferenciação sob o sinal de integração será apresentada posteriormente como aprofundamento.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

O produto cartesiano corresponde ao caso mais simples. Para regiões mais gerais, os limites de uma integral podem depender das demais variáveis. Em duas dimensões, por exemplo, uma região da forma

$$\mathcal{D} = \{(x_1, x_2) : a < x_1 < b, c(x_1) < x_2 < d(x_1)\}$$

conduz a

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2 = \int_a^b \int_{c(x_1)}^{d(x_1)} f(x_1, x_2) dx_2 dx_1,$$

quando as condições de integração correspondentes são satisfeitas.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.7 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.8 (Teorema de Fubini). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow \mathbb{R}$$

é mensurável e absolutamente integrável, isto é,

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então, para quase todo $x_1 \in \mathcal{D}_1$,

$$x_2 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_2$, e, para quase todo $x_2 \in \mathcal{D}_2$,

$$x_1 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_1$.

Além disso,

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) \, dx_1 \, dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) \, dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) \, dx_1 \right] dx_2. \end{aligned}$$

(Axler, 2020)

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Definição 7.15 (Densidade conjunta). O vetor aleatório $\mathbf{X}$ é absolutamente contínuo em relação à medida de Lebesgue em $\mathbb{R}^p$ quando existe uma função mensurável

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty]$$

tal que, para todo conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

tem-se

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A função $f_{\mathbf{X}}$ é denominada **densidade conjunta** de $\mathbf{X}$.

Tomando

$$\mathcal{A} = \mathbb{R}^p,$$

segue necessariamente que

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Proposição 7.18 (Densidades marginais). *Considere o vetor aleatório absolutamente contínuo particionado como*

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2).$$

Então, uma densidade marginal de $\mathbf{X}_1$ é

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2,$$

e uma densidade marginal de $\mathbf{X}_2$ é

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

Comprovação. Como a densidade conjunta é não negativa, o Teorema 7.7 permite integrar sucessivamente suas componentes.

Para qualquer conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^{p_1},$$

tem-se

$$\begin{aligned} P(\mathbf{X}_1 \in \mathcal{A}) &= \int_{\mathcal{A} \times \mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 d\mathbf{x}_2 \\ &= \int_{\mathcal{A}} \left[\int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \right] d\mathbf{x}_1. \end{aligned}$$

Portanto,

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2$$

é uma densidade marginal de $\mathbf{X}_1$. O argumento para $\mathbf{X}_2$ é análogo. $\square$

A marginalização elimina as componentes que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções escalares, vetoriais e matriciais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.9 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol, 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

o elemento de volume transforma-se segundo

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Proposição 7.19 (Densidade de uma transformação invertível). *Considere um vetor aleatório absolutamente contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$, tal que*

$$P(\mathbf{X} \in \mathcal{D}) = 1,$$

e uma transformação

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

satisfazendo as condições do Teorema 7.9.

Defina

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}).$$

Então, para

$$\mathbf{y} \in \mathcal{G},$$

a densidade de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Para

$$\mathbf{y} \notin \mathcal{G},$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{y}) = 0.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é globalmente injetiva, a fórmula anterior não pode ser aplicada diretamente com uma única inversa. Sob condições de regularidade, pode-se particionar o domínio em regiões nas quais a transformação seja injetiva e somar as contribuições correspondentes às diferentes pré-imagens.

Esse caso não será desenvolvido em detalhe neste capítulo.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0,35x_1x_2 \\ x_2 + 0,20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0,35x_2 & 0,35x_1 \\ 0,40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0,35x_2 - 0,14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

A parametrização polar não é uma transformação globalmente bijetiva em todas as escolhas possíveis de domínio: a origem possui representação angular não única e o ângulo é periódico. Para a aplicação da fórmula de mudança de variáveis, trabalha-se em regiões adequadas de injetividade; as fronteiras envolvidas possuem medida nula e não alteram o valor das integrais usuais.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e sua raiz quadrada principal simétrica positiva definida

$$\Sigma^{1/2}.$$

Considere a transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned}\mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).\end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsoides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Aprofundamento: diferenciação sob o sinal de integração

Leitura de aprofundamento

A diferenciação sob o sinal de integração é utilizada para justificar formalmente identidades envolvendo funções de verossimilhança, vetor escore e informação de Fisher.

Esse conteúdo é importante para desenvolvimentos inferenciais mais formais, mas pode ser omitido em uma primeira leitura. Para a continuidade imediata dos capítulos probabilísticos, basta reter que a troca entre derivação e integração exige condições de regularidade e não pode ser realizada automaticamente.

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.10 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.11 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. *para todo $\theta \in \mathcal{V}$, a função*

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. *exista $\delta > 0$ tal que*

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. *para quase todo $\mathbf{x} \in \mathcal{D}$, a função*

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. *exista uma função integrável*

$$M_j : \mathcal{D} \rightarrow [0, \infty)$$

tal que, para quase todo

$$\mathbf{x} \in \mathcal{D},$$

a desigualdade

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

seja válida para todo t com $|t| < \delta$;

5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Comprovação. Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \mapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x})\mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

$$\begin{aligned} \lim_{m \rightarrow \infty} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \int_{\mathcal{D}} \lim_{m \rightarrow \infty} q_m(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}. \end{aligned}$$

Por outro lado,

$$\begin{aligned} \int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \frac{\int_{\mathcal{D}} h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) d\mathbf{x} - \int_{\mathcal{D}} h(\mathbf{x}, \theta_0) d\mathbf{x}}{t_m} \\ &= \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m}. \end{aligned}$$

Logo,

$$\lim_{m \rightarrow \infty} \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Como a sequência $t_m \rightarrow 0$ foi escolhida arbitrariamente, a derivada parcial existe e satisfaz a igualdade enunciada. $\square$

Quando as condições do Teorema 7.11 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.11 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned} \mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}. \end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

X

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A parte de aprofundamento mostrou, adicionalmente, como condições de dominação podem justificar a diferenciação de integrais parametrizadas e identidades utilizadas posteriormente em inferência.

Para a continuidade do livro, as ideias centrais a reter são:

- probabilidades são obtidas por integração da densidade conjunta;
- densidades marginais são obtidas integrando as componentes que se deseja eliminar;
- esperanças de vetores e matrizes são calculadas componente a componente;
- mudanças de variáveis exigem o determinante absoluto da Jacobiana;
- transformações afins produzem fatores de volume constantes;
- transformações elipsoidais convertem geometria esférica e elipsoidal.

7.12 Aprofundamento: aplicações à estimação e à inferência

Leitura de aprofundamento

As subseções seguintes mostram como as ferramentas de cálculo desenvolvidas neste capítulo aparecem em problemas de estimação e inferência.

O objetivo é apresentar apenas a estrutura matemática dessas aplicações. As propriedades probabilísticas dos estimadores, as condições de regularidade, as distribuições assintóticas e os procedimentos inferenciais serão desenvolvidos nos capítulos específicos do Módulo II. Este bloco pode ser omitido em uma primeira leitura sem comprometer a continuidade imediata do livro.

As aplicações seguintes envolvem gradientes, Hessianas, expansões de Taylor, diferenciação sob o sinal de integração e cálculo matricial. Elas antecipam, em nível matemático, conceitos que serão retomados posteriormente.

7.12.1 Log-verossimilhança e vetor escore

Considere observações independentes

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

provenientes de um mesmo modelo paramétrico com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros e Θ é o espaço paramétrico.

Nessas condições, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.16 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Se um estimador de máxima verossimilhança é um ponto interior do espaço paramétrico e a log-verossimilhança é diferenciável nesse ponto, então deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.17 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Se

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}$$

e

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

então

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \prec \mathbf{0},$$

e o teste da Hessiana fornece uma condição suficiente para que $\hat{\theta}$ seja um máximo local estrito da log-verossimilhança.

Em um ponto arbitrário do espaço paramétrico, a matriz

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta)$$

não precisa ser positiva semidefinida e pode, inclusive, ser indefinida.

Em um ponto estacionário interior que seja máximo local,

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \preceq \mathbf{0},$$

de modo que

$$\mathcal{J}_n(\hat{\theta}) \succeq \mathbf{0}.$$

A informação observada pode ser singular quando, por exemplo:

- há parâmetros localmente não identificados;
- existem redundâncias na parametrização;
- a log-verossimilhança apresenta direções localmente planas.

Máximos na fronteira exigem tratamento separado, pois as condições usuais de ponto estacionário e o teste irrestrito da Hessiana não os caracterizam adequadamente.

Definição 7.18 (Informação de Fisher). Suponha que o vetor escore possua segundo momento finito. A informação de Fisher da amostra é definida por

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathbf{s}_n(\theta) \mathbf{s}_n(\theta)^{\top}].$$

(Casella; Berger, 2002)

Sob condições de regularidade que permitem diferenciar a densidade sob o sinal de integração,

$$E_{\theta} [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais que justificam a relação entre a primeira e a segunda derivadas da log-verossimilhança,

$$\begin{aligned} \mathcal{J}_n(\theta) &= -E_{\theta} [\nabla_{\theta}^2 \ell_n(\theta)] \\ &= E_{\theta} [\mathcal{J}_n(\theta)]. \end{aligned}$$

Assim, em modelos regulares, a informação de Fisher coincide com a esperança da informação observada. Como o escore possui esperança nula nessas condições,

$$\mathcal{J}_n(\theta) = \text{Cov}_{\theta} [\mathbf{s}_n(\theta)].$$

Essas identidades não devem ser utilizadas automaticamente. Sua validade depende das condições de regularidade, incluindo a possibilidade de intercambiar derivação e integração e o comportamento do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_{\theta}^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_{\theta}^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = -\mathbf{s}_n(\theta^{(t)}),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

Essa é a aplicação do método de Newton à equação

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

Quando

$$\mathcal{J}_n(\theta^{(t)}) \succ \mathbf{0},$$

a direção

$$\mathbf{d}^{(t)} = \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)})$$

é uma direção local de aumento da log-verossimilhança, pois

$$\mathbf{s}_n(\theta^{(t)})^\top \mathbf{d}^{(t)} > 0$$

quando o escore é não nulo.

Ainda assim, um passo completo pode não aumentar a log-verossimilhança quando o ponto atual está distante da solução. Em aplicações numéricas, podem ser utilizados controles do comprimento da etapa.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada

$$\mathcal{J}_n(\theta)$$

pela informação de Fisher

$$\mathcal{J}_n(\theta).$$

Sob as condições de regularidade para as quais

$$\mathcal{J}_n(\theta) = E_\theta [\mathcal{J}_n(\theta)],$$

essa substituição pode ser interpretada como a troca da curvatura observada pela curvatura esperada da log-verossimilhança.

Quando

$$\mathcal{J}_n(\theta^{(t)})$$

é invertível, a direção $\mathbf{d}^{(t)}$ é obtida pela solução de

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = \mathbf{s}_n(\theta^{(t)}),$$

seguida da atualização

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Assim, Newton–Raphson utiliza

$$\mathcal{J}_n(\theta),$$

enquanto o método do escore de Fisher utiliza

$$\mathcal{J}_n(\theta).$$

Quando a identidade de informação é válida, a primeira representa a curvatura observada e a segunda sua correspondente curvatura esperada.

As atualizações coincidem quando as duas matrizes são iguais no ponto considerado ou, mais geralmente, quando produzem a mesma solução para a equação que determina a direção da etapa.

7.12.5 Expansão local de uma raiz do escore

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned}\mathbf{0} &= \mathbf{s}_n(\hat{\theta}) \\ &\approx \mathbf{s}_n(\theta_0) + \nabla_{\theta}^2 \ell_n(\theta_0) (\hat{\theta} - \theta_0).\end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n(\theta_0) = -\mathcal{J}_n(\theta_0),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa expressão é uma aproximação local de primeira ordem. A obtenção de uma representação assintótica rigorosa exige controlar o termo restante da expansão e substituir a informação observada por um limite apropriado.

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.12 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q$$

diferenciável no ponto

$$\theta.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A demonstração formal utiliza a aproximação de Taylor de primeira ordem juntamente com resultados probabilísticos sobre convergência em distribuição. Esses resultados serão desenvolvidos no módulo inferencial; neste capítulo interessa principalmente a origem diferencial da matriz

$$\mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta)(\hat{\theta} - \theta).$$

A matriz

$$\mathbf{V}_{\mathbf{g}} = \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}$$

é a matriz de covariâncias da distribuição limite de

$$\sqrt{n} \left[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \right].$$

Por isso, denomina-se

$$\frac{1}{n} \mathbf{V}_{\mathbf{g}}$$

matriz de covariâncias assintótica de

$$\mathbf{g}(\hat{\theta}).$$

Em aplicações, é comum utilizá-la como aproximação da matriz de covariâncias do estimador para amostras grandes. A convergência em distribuição, isoladamente, não garante convergência dos segundos momentos; essa interpretação requer condições adicionais de regularidade.

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância assintótica é

$$\frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_2}{\theta_1} \\ -\frac{1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n} \left(\hat{\theta} - \theta \right) \xrightarrow{d} N_2 \left(\mathbf{0}, \Xi \right),$$

então

$$\sqrt{n} \left(\frac{\hat{\theta}_1}{\hat{\theta}_2} - \frac{\theta_1}{\theta_2} \right)$$

converge em distribuição para uma normal com variância assintótica

$$\nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.25 (Estimação de um vetor de médias). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

Exemplo 7.26 (Critério do modelo linear multivariado). Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere o critério

$$\begin{aligned} Q(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} Q = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Observe que, para Σ fixa e positiva definida, o minimizador em relação a $\mathbf{B}$ não depende de Σ . Isso decorre do fato de que Σ^{-1} é invertível e desaparece da condição de primeira ordem.

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_\mathcal{E} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^\top (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_\mathcal{E}).$$

Se

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_\mathcal{E}.$$

A condição

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo.

Se $\mathbf{X}$ possui posto coluna completo k , a matriz residual pode ser escrita como

$$\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}} = (\mathbf{I}_n - \mathbf{P}_\mathbf{X}) \mathbf{Y},$$

em que

$$\text{posto}(\mathbf{I}_n - \mathbf{P}_\mathbf{X}) = n - k.$$

Consequentemente,

$$\text{posto}(\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}) \leq \min(p, n - k).$$

Assim, uma condição necessária para

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

é

$$n - k \geq p.$$

Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério é ilimitado inferiormente no cone das matrizes positivas definidas. Em particular, pode-se fazer um autovalor de Σ tender a zero em uma direção pertencente ao núcleo de $\mathbf{G}_{\mathcal{E}}$ sem produzir aumento compensatório no termo de traço.

Aqui o modelo foi utilizado apenas como uma aplicação conjunta de gradientes matriciais, log-determinante e diferenciação de funções envolvendo matrizes inversas.

A interpretação probabilística do critério, as propriedades dos estimadores, suas distribuições e a formulação de hipóteses serão desenvolvidas posteriormente nos capítulos de estimação, modelo linear multivariado e inferência.

O bloco de aprofundamento mostrou como as ferramentas de cálculo deste capítulo aparecem em problemas de estimação e inferência:

Tabela 7.2: Relações entre as ferramentas de cálculo e suas aplicações estatísticas.

Ferramenta matemática	Aplicação estatística
Gradiente	Vetor escore
Hessiana	Informação observada
Esperança da curvatura	Informação de Fisher
Expansão de Taylor	Aproximações locais e método delta
Cálculo matricial	Estimação de parâmetros vetoriais e matriciais

Essas relações devem ser entendidas neste capítulo como aplicações das ferramentas matemáticas. Sua interpretação estatística completa será retomada no Módulo II.

7.13 Síntese do capítulo

O capítulo reuniu as ferramentas de cálculo necessárias para estudar funções de vetores e matrizes e para formular problemas posteriores da Estatística Multivariada.

No cálculo diferencial, o gradiente representa a variação de primeira ordem de uma função escalar, a Jacobiana representa a transformação linear local de uma função vetorial e a Hessiana descreve sua curvatura. Essas estruturas sustentam aproximações de Taylor e condições de otimalidade.

A otimização utiliza essas derivadas de formas diferentes. Em problemas sem restrições, pontos estacionários e a definitude da Hessiana permitem caracterizar soluções locais, enquanto a convexidade fornece resultados globais. Em problemas com restrições de igualdade, os multiplicadores de Lagrange incorporam a geometria do conjunto viável. As funções de resíduos mostram como essas ferramentas conduzem às equações normais e aos problemas de mínimos quadrados.

No cálculo matricial, os diferenciais e as identidades de traço permitem trabalhar diretamente com parâmetros matriciais. Derivadas de inversas, determinantes e log-determinantes serão utilizadas em critérios que envolvem matrizes de covariâncias. A vetorização e o produto de Kronecker fornecem uma representação vetorial para transformações entre matrizes.

O cálculo integral completa essa estrutura ao permitir a obtenção de probabilidades, expectativas e densidades marginais. O Teorema da Mudança de Variáveis mostra como o determinante Jacobiano modifica elementos de volume e densidades sob transformações. Transformações afins e elipsoidais conectam essa ideia às formas quadráticas e às matrizes positivas definidas.

As principais relações estabelecidas no capítulo podem ser resumidas da seguinte forma:

Tabela 7.3: Relações entre as ferramentas do cálculo e seus usos posteriores.

Estrutura matemática	Papel nos capítulos seguintes
Derivadas	Aproximação local e otimização
Diferenciais matriciais	Manipulação e estimação de parâmetros matriciais
Integração e Jacobianos	Construção e transformação de distribuições multivariadas

A Tabela 7.4 reúne algumas das identidades de uso recorrente.

Tabela 7.4: Identidades selecionadas de cálculo vetorial e matricial.

Função ou transformação	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Os blocos de aprofundamento desenvolveram ferramentas que não são necessárias para uma primeira leitura do capítulo, entre elas derivadas vetorizadas e parametrização de matrizes simétricas, diferenciação sob o sinal de integração e aplicações do cálculo à estimação e à inferência. Esses resultados poderão ser retomados quando forem necessários nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- interpretar derivadas como aproximações locais;
- utilizar Taylor e a Hessiana em problemas de otimização;
- formular condições de primeira ordem com e sem restrições;
- derivar critérios quadráticos e equações normais;
- utilizar diferenciais e identidades de traço em funções matriciais;
- diferenciar expressões envolvendo inversas, determinantes e log-determinantes;
- utilizar vec, produto de Kronecker e sua identidade de vetorização;
- calcular probabilidades, expectativas e densidades marginais por integração;
- aplicar mudanças de variáveis e interpretar o determinante Jacobiano.

O Capítulo 7 encerra o **Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada**.

Antes do início do Módulo II, os **Exercícios de fixação do Módulo I** retomam de forma integrada os principais conceitos desenvolvidos ao longo dos sete capítulos. Os exercícios articulam representação matricial dos dados, projeções, transformações lineares, formas quadráticas, autovalores e autovetores, SVD, pseudoinversa e cálculo vetorial e matricial em problemas que serão utilizados posteriormente na Estatística Multivariada.

O capítulo seguinte inicia o **Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada** com o estudo das matrizes de covariâncias e correlações. Gradientes, formas quadráticas, transformações lineares, integrais, projeções e produtos matriciais fornecerão

as ferramentas matemáticas para descrever a variabilidade conjunta de vetores aleatórios e sustentar os desenvolvimentos probabilísticos e inferenciais posteriores.

Exercícios de fixação do Módulo I

Os exercícios deste módulo retomam os fundamentos matemáticos desenvolvidos nos capítulos anteriores e os utilizam em problemas que reaparecerão ao longo da Estatística Multivariada.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades e operações com vetores e matrizes, bem como suas interpretações algébricas e geométricas. As matrizes foram escolhidas para permitir resultados exatos e favorecer a compreensão das relações entre Álgebra Linear, Geometria e Cálculo.

Na segunda parte, o **R** ou **Python** será utilizado para estender essas mesmas ideias a matrizes de maior dimensão e a conjuntos de dados. O objetivo não é substituir os cálculos matriciais por funções prontas, mas utilizar a computação para aplicar e verificar propriedades estudadas no Módulo I.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos no Módulo I (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de propriedades como simetria, ortogonalidade, independência linear, posto, invertibilidade, definição positiva ou outras condições específicas, essas condições devem ser verificadas ou justificadas.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Exercícios sem uso de computador

Exercício 7.1 (Transformação de variáveis em uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 2 & 2 \\ 3 & 0 & 1 \end{bmatrix},$$

em que as linhas representam quatro observações e as colunas representam três variáveis.

Considere também a transformação

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

1. Escreva, para uma observação genérica

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

as duas componentes de

$$\mathbf{y} = \mathbf{Ax}.$$

2. Interprete cada nova componente como uma combinação linear das variáveis originais.
3. Determine a matriz de dados transformada utilizando

$$\mathbf{Y} = \mathbf{XA}^\top.$$

4. Indique as dimensões de $\mathbf{X}$, $\mathbf{A}$ e $\mathbf{Y}$ e explique por que a transformação reduziu o número de variáveis de três para duas.
5. Determine o posto de $\mathbf{A}$.
6. Determine a dimensão de $\mathcal{N}(\mathbf{A})$ e explique o significado desse resultado em termos de perda de informação.
7. Sabendo apenas $\mathbf{y} = \mathbf{Ax}$, discuta se é possível recuperar unicamente o vetor original $\mathbf{x}$.

Exercício 7.2 (Centralização como projeção). Considere $n = 4$ e defina

$$\mathbf{H}_4 = \mathbf{I}_4 - \frac{1}{4} \mathbf{1}_4 \mathbf{1}_4^\top.$$

1. Escreva explicitamente a matriz $\mathbf{H}_4$.

2. Verifique que

$$\mathbf{H}_4^\top = \mathbf{H}_4$$

e

$$\mathbf{H}_4^2 = \mathbf{H}_4.$$

3. Mostre que

$$\mathbf{H}_4 \mathbf{1}_4 = \mathbf{0}.$$

4. Aplique $\mathbf{H}_4$ à matriz $\mathbf{X}$ do Exercício 7.1:

$$\mathbf{X}_c = \mathbf{H}_4 \mathbf{X}.$$

5. Verifique diretamente que

$$\mathbf{1}_4^\top \mathbf{X}_c = \mathbf{0}^\top.$$

6. Interprete a igualdade anterior em termos das médias das variáveis.

Exercício 7.3 (Centralização e reescalonamento das variáveis). Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times 3}$$

e a matriz diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix}.$$

1. Determine $\mathbf{D}^{-1}$.

2. Considere inicialmente uma matriz já centralizada $\mathbf{X}_c$ e defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}^{-1}.$$

Explique o efeito dessa transformação sobre cada uma das três variáveis.

3. Explique por que $\mathbf{D}^{-1}$ atua à direita da matriz de dados.
4. Compare essa operação com a centralização

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

explicando por que $\mathbf{H}_n$ atua à esquerda enquanto $\mathbf{D}^{-1}$ atua à direita.

5. Escreva, em uma única expressão, a transformação que primeiro centraliza $\mathbf{X}$ e depois reescala suas variáveis.
6. A centralização e o reescalonamento atuam no mesmo espaço? Justifique utilizando as dimensões de $\mathbf{H}_n$ e $\mathbf{D}^{-1}$.

Exercício 7.4 (Duas matrizes de Gram para os mesmos dados). Considere a matriz centralizada

$$\mathbf{X}_c = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 2 \\ 0 & -2 \end{bmatrix}.$$

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Indique as dimensões das duas matrizes.
3. Qual das duas matrizes contém os produtos internos entre as colunas de $\mathbf{X}_c$?
4. Qual contém os produtos internos entre as linhas de $\mathbf{X}_c$?
5. Determine o posto das duas matrizes.
6. Determine os autovalores positivos de cada matriz.
7. Verifique que os autovalores positivos coincidem.
8. Relacione esse resultado à construção da SVD de uma matriz retangular.

Exercício 7.5 (Projeção, ajuste e resíduos). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

1. Verifique que as colunas de $\mathbf{X}$ são linearmente independentes.
2. Determine

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

3. Verifique que

$$\mathbf{P}_X^\top = \mathbf{P}_X$$

e

$$\mathbf{P}_X^2 = \mathbf{P}_X.$$

4. Calcule

$$\hat{\mathbf{y}} = \mathbf{P}_X \mathbf{y}.$$

5. Determine o vetor de resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

6. Verifique que

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

7. Identifique o subespaço ao qual pertence $\hat{\mathbf{y}}$.
8. Identifique o subespaço ao qual pertence $\mathbf{e}$.
9. Interprete geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

Exercício 7.6 (Um problema de mínimos quadrados por três perspectivas). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

O objetivo é determinar o vetor que minimiza

$$\|\mathbf{b} - \mathbf{Ax}\|^2.$$

Resolva o problema das três formas seguintes.

1. Determine a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$ e obtenha, a partir dela, o vetor ajustado.
2. Resolva as equações normais

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}.$$

3. Calcule

$$\mathbf{A}^\top \mathbf{A}$$

e determine os valores singulares de $\mathbf{A}$.

4. Construa uma SVD compacta de $\mathbf{A}$.
5. Construa a pseudoinversa

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$$

e obtenha

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}.$$

6. Compare as soluções obtidas pelas três abordagens.
7. Compare também os vetores ajustados e os resíduos.
8. Explique por que projeções, equações normais e pseudoinversa conduzem ao mesmo problema de aproximação.

Exercício 7.7 (Forma quadrática e direções privilegiadas). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. Calcule $q(\mathbf{x})$ para

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

2. Determine os autovalores de $\mathbf{A}$.
3. Determine uma base ortonormal de autovetores.
4. Calcule a forma quadrática em cada autovetor unitário.
5. Determine

$$\max_{\|\mathbf{x}\|=1} q(\mathbf{x})$$

e

$$\min_{\|\mathbf{x}\|=1} q(\mathbf{x}).$$

6. Relacione os valores encontrados aos autovalores de $\mathbf{A}$.

Exercício 7.8 (Norma euclidiana e norma induzida). Considere

$$\mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

responda:

1. Calcule as normas euclidianas de $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{z}$.
2. Calcule as normas induzidas por $\mathbf{M}$,

$$\|\mathbf{v}\|_{\mathbf{M}} = \sqrt{\mathbf{v}^{\top} \mathbf{M} \mathbf{v}}.$$

3. Calcule a distância euclidiana entre $\mathbf{x}$ e $\mathbf{y}$.
4. Calcule a distância induzida por $\mathbf{M}$ entre os mesmos vetores.
5. Qual coordenada recebe maior peso na geometria induzida por $\mathbf{M}$?
6. Explique por que duas geometrias diferentes podem produzir avaliações diferentes da proximidade entre observações.

Exercício 7.9 (Matrizes particionadas e complemento de Schur). Considere a matriz simétrica

$$\mathbf{M} = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

particionada como

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^{\top} & \mathbf{D} \end{bmatrix},$$

em que

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{D} = [2].$$

1. Verifique que $\mathbf{A}$ é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Calcule o complemento de Schur de $\mathbf{A}$ em $\mathbf{M}$,

$$\mathbf{S} = \mathbf{D} - \mathbf{B}^{\top} \mathbf{A}^{-1} \mathbf{B}.$$

4. Verifique que $\mathbf{S} > 0$.
5. Utilize a identidade por blocos

$$\det(\mathbf{M}) = \det(\mathbf{A}) \det(\mathbf{S})$$

para calcular $\det(\mathbf{M})$.

6. Confirme o resultado calculando diretamente o determinante de $\mathbf{M}$.

Exercício 7.10 (Direção que maximiza uma medida de dispersão). Considere

$$\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Para um vetor unitário $\mathbf{a}$, defina

$$D(\mathbf{a}) = \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

1. Determine os autovalores de $\mathbf{S}$.
2. Determine uma base ortonormal de autovetores.
3. Resolva

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

4. Determine a direção que minimiza $D(\mathbf{a})$ sob a mesma restrição.
5. Calcule o valor da forma quadrática nas duas direções.
6. Se $\mathbf{S}$ representasse uma matriz de dispersão de duas variáveis, interprete a direção associada ao maior autovalor.
7. Interprete também a direção associada ao menor autovalor.

Exercício 7.11 (Maximização de uma razão entre duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 12 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Resolva

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}}.$$

1. Mostre, por multiplicadores de Lagrange ou pelo quociente de Rayleigh generalizado, que as direções candidatas satisfazem

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{B} \mathbf{x}.$$

2. Determine os autovalores generalizados.
3. Determine um autovetor associado a cada autovalor generalizado.
4. Normalize os autovetores segundo a geometria de $\mathbf{B}$, impondo

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1.$$

5. Determine o valor máximo do quociente.
6. Determine também o valor mínimo.
7. Verifique que os dois autovetores podem ser escolhidos de modo que

$$\mathbf{x}_1^\top \mathbf{B} \mathbf{x}_2 = 0.$$

8. Compare essa ortogonalidade com a ortogonalidade euclidiana usual.

Exercício 7.12 (Transformação de um problema generalizado). Utilize as matrizes $\mathbf{A}$ e $\mathbf{B}$ do Exercício 7.11.

1. Determine a raiz quadrada principal

$$\mathbf{B}^{1/2}$$

e sua inversa

$$\mathbf{B}^{-1/2}.$$

2. Construa

$$\mathbf{C} = \mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2}.$$

3. Determine os autovalores de $\mathbf{C}$.

4. Compare-os com os autovalores generalizados obtidos no exercício anterior.

5. Considere a transformação

$$\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}.$$

Mostre que

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = \mathbf{z}^\top \mathbf{z}.$$

6. Mostre que

$$\frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}} = \frac{\mathbf{z}^\top \mathbf{C} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

7. Explique por que a transformação converte um problema em geometria induzida por $\mathbf{B}$ em um problema espectral euclidiano.

Exercício 7.13 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

1. Calcule

$$\mathbf{A}^\top \mathbf{A}.$$

2. Determine os autovalores de $\mathbf{A}^\top \mathbf{A}$.

3. Determine os valores singulares positivos de $\mathbf{A}$ em ordem decrescente.

4. Determine os vetores singulares à direita correspondentes.

5. Utilize

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}$$

para construir os vetores singulares à esquerda.

6. Verifique que os vetores obtidos são ortonormais.

7. Construa

$$\mathbf{U}_r, \quad \mathbf{D}_r, \quad \mathbf{V}_r.$$

8. Verifique diretamente que

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

9. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A})$.

10. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A}^\top)$.

Exercício 7.14 (Aproximação de posto reduzido). Utilize a matriz e a SVD do Exercício 7.13.

1. Escreva

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + d_2 \mathbf{u}_2 \mathbf{v}_2^\top.$$

2. Construa a aproximação de posto 1

$$\mathbf{A}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1^\top.$$

3. Determine explicitamente

$$\mathbf{A} - \mathbf{A}_1.$$

4. Calcule

$$\|\mathbf{A} - \mathbf{A}_1\|_F.$$

5. Verifique que, neste caso,

$$\|\mathbf{A} - \mathbf{A}_1\|_F = d_2.$$

6. Calcule

$$\|\mathbf{A}\|_F^2.$$

7. Verifique que

$$\|\mathbf{A}\|_F^2 = d_1^2 + d_2^2.$$

8. Calcule

$$\frac{d_1^2}{d_1^2 + d_2^2}.$$

9. Interprete essa razão como a parcela da magnitude quadrática da matriz preservada pela aproximação de posto 1.

Exercício 7.15 (Gradiente e Hessiana de um critério de mínimos quadrados). Considere

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

1. Desenvolva $Q(\beta)$ como uma expressão quadrática em β .

2. Obtenha

$$\nabla_{\beta} Q(\beta).$$

3. Obtenha

$$\nabla_{\beta}^2 Q(\beta).$$

4. Mostre que, se $\mathbf{X}$ possui posto completo de colunas,

$$\mathbf{X}^{\top} \mathbf{X} \succ \mathbf{0}.$$

5. Conclua que a Hessiana é positiva definida.

6. Mostre que o ponto estacionário é o único minimizador global.
7. Aplique o resultado a

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix},$$

determinando $\hat{\beta}$ exatamente.

8. Compare a solução com aquela obtida geometricamente no Exercício 7.5.

Exercício 7.16 (Multiplicadores de Lagrange e autovalores). Considere uma matriz real simétrica $\mathbf{A}$ e o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

1. Construa a função lagrangiana.
2. Diferencie-a em relação a $\mathbf{x}$.
3. Diferencie-a em relação ao multiplicador de Lagrange.
4. Mostre que as condições de primeira ordem conduzem a uma equação da forma

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}.$$

5. Explique por que o problema de otimização se transforma em um problema de autovalores.
6. Resolva completamente o problema para

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

7. Determine também o mínimo sob a mesma restrição.
8. Compare os resultados com os obtidos no Exercício 7.10.

Exercício 7.17 (Vetorização e produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Adote a convenção de que $\text{vec}(\mathbf{X})$ empilha as colunas de $\mathbf{X}$.

1. Calcule diretamente

$$\mathbf{Y} = \mathbf{AXB}.$$

2. Determine

$$\text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{Y}).$$

3. Construa

$$\mathbf{B}^\top \otimes \mathbf{A}.$$

4. Calcule

$$(\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

5. Verifique a identidade

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

6. Compare as dimensões da transformação matricial com as dimensões de sua representação vetorizada.

Exercício 7.18 (Diferenciação de um critério matricial). Considere, para

$$\Sigma \succ \mathbf{0},$$

a função

$$Q(\Sigma) = 2 \log \det(\Sigma) + \text{tr}(\mathbf{G}\Sigma^{-1}),$$

em que

$$\mathbf{G} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Utilize diferenciais para obter

$$dQ.$$

2. Mostre que um ponto estacionário deve satisfazer

$$2\Sigma^{-1} - \Sigma^{-1}\mathbf{G}\Sigma^{-1} = \mathbf{0}.$$

3. Resolva essa equação para Σ .
4. Verifique que a matriz obtida é positiva definida.

Exercício 7.19 (Transformação afim, Jacobiana e alteração de área). Considere

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

1. Calcule $\det(\mathbf{A})$ e mostre que a transformação é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Escreva a transformação inversa

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

4. Determine a matriz Jacobiana da transformação de $\mathbf{x}$ para $\mathbf{y}$.
5. Determine o determinante Jacobiano.
6. Considere a região

$$0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1.$$

Determine as imagens de seus quatro vértices.

7. Descreva geometricamente a região transformada.
8. Determine sua área.
9. Compare a razão entre a área transformada e a área original com

$$|\det(\mathbf{A})|.$$

Parte II — Exercícios com uso do R

Nesta parte, utilize preferencialmente operações matriciais do R. Quando uma função pronta reproduzir diretamente um resultado estudado no Módulo I, utilize-a apenas depois da construção matricial, como forma de conferência.

Em comparações envolvendo posto, autovalores teoricamente nulos ou valores singulares numericamente nulos, considere a possibilidade de pequenos erros de arredondamento computacional e utilize uma tolerância numérica adequada.

Exercício 7.20 (Centralização matricial dos dados `USArrests`). Considere as quatro variáveis quantitativas do conjunto de dados `USArrests`.

1. Armazene a matriz de dados em um objeto $\mathbf{X}$.
2. Determine n e p a partir da própria matriz.
3. Construa explicitamente

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

4. Obtenha

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

- Verifique numericamente que as médias das colunas de $\mathbf{X}_c$ são zero, admitindo apenas diferenças de arredondamento.
- Verifique numericamente que

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

- Determine o posto numérico de $\mathbf{H}_n$.
- Verifique que

$$\mathbf{H}_n \mathbf{1}_n \approx \mathbf{0}.$$

- Somente ao final, compare $\mathbf{X}_c$ com o resultado produzido por

```
scale(X, center = TRUE, scale = FALSE)
```

- Explique geometricamente o papel de $\mathbf{H}_n$.

Exercício 7.21 (Matrizes de Gram e seus espectros). Utilize a matriz centralizada $\mathbf{X}_c$ obtida no Exercício 7.20.

- Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

- Compare as dimensões das duas matrizes.
- Determine seus postos numéricos.
- Calcule os autovalores de ambas.
- Para identificar os autovalores numericamente positivos, utilize uma tolerância relativa, por exemplo,

$$\lambda_j > 10^{-10} \lambda_{\max}.$$

6. Compare os autovalores positivos de $\mathbf{G}_V$ e $\mathbf{G}_O$.
7. Explique por que uma matriz 4×4 e uma matriz 50×50 contêm o mesmo espectro não nulo.
8. Relacione os resultados aos valores singulares de $\mathbf{X}_c$.

Exercício 7.22 (Construção de novas variáveis por transformação linear). Considere apenas as quatro variáveis quantitativas de `iris`, formando

$$\mathbf{X} \in \mathbb{R}^{150 \times 4}.$$

Defina

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & -1 & 0 & 0 \end{bmatrix}.$$

1. Obtenha

$$\mathbf{Y} = \mathbf{XA}^\top.$$

2. Escreva explicitamente cada uma das três novas variáveis como combinação das quatro variáveis originais.
3. Verifique as dimensões de $\mathbf{Y}$.
4. Determine o posto de $\mathbf{A}$.
5. Determine a dimensão de $\mathcal{N}(\mathbf{A})$.
6. Discuta se a transformação preserva toda a informação necessária para reconstruir as quatro variáveis originais.
7. Centralize $\mathbf{X}$.
8. Aplique a mesma transformação à matriz centralizada.
9. Verifique as médias das três variáveis transformadas após a centralização.
10. Explique por que uma transformação linear de dados centralizados continua produzindo variáveis com média amostral zero.

Exercício 7.23 (Busca da direção de maior dispersão). Utilize as variáveis quantitativas de `USArrests`.

1. Centralize a matriz de dados e denote o resultado por $\mathbf{X}_c$.

2. Construa

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

3. Obtenha os autovalores e autovetores de $\mathbf{S}$ utilizando `eigen()`.

4. Identifique a direção unitária $\mathbf{a}_1$ associada ao maior autovalor.

5. Calcule

$$\mathbf{a}_1^\top \mathbf{S} \mathbf{a}_1.$$

6. Compare o resultado com o maior autovalor de $\mathbf{S}$.

7. Gere um grande número de vetores aleatórios em $\mathbb{R}^4$ e normalize cada um para norma unitária.

8. Para cada vetor $\mathbf{a}$, calcule

$$\mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

9. Compare o maior valor encontrado entre as direções aleatórias com o maior autovalor de $\mathbf{S}$.

10. Explique o que esse experimento numérico mostra sobre o quociente de Rayleigh.

11. Repita a análise após padronizar as quatro variáveis para variância unitária.

12. Compare a nova direção de máxima dispersão com aquela obtida utilizando as variáveis apenas centralizadas e discuta o efeito da mudança de escala.

Não utilize `prcomp()` neste exercício.

Exercício 7.24 (Projeção e reconstrução a partir de uma direção). Utilize $\mathbf{X}_c$ e a direção $\mathbf{a}_1$ obtidas no Exercício 7.23.

1. Calcule as coordenadas das observações na direção $\mathbf{a}_1$:

$$\mathbf{z}_1 = \mathbf{X}_c \mathbf{a}_1.$$

2. Verifique as dimensões de $\mathbf{z}_1$.

3. Reconstrua a parcela da matriz de dados associada a essa direção:

$$\widehat{\mathbf{X}}_1 = \mathbf{z}_1 \mathbf{a}_1^\top.$$

4. Verifique que $\widehat{\mathbf{X}}_1$ possui posto 1.
5. Calcule

$$\mathbf{E}_1 = \mathbf{X}_c - \widehat{\mathbf{X}}_1.$$

6. Calcule

$$\|\mathbf{X}_c\|_F^2, \quad \|\widehat{\mathbf{X}}_1\|_F^2, \quad \|\mathbf{E}_1\|_F^2.$$

7. Verifique numericamente que

$$\|\mathbf{X}_c\|_F^2 \approx \|\widehat{\mathbf{X}}_1\|_F^2 + \|\mathbf{E}_1\|_F^2.$$

8. Verifique também que

$$\langle \widehat{\mathbf{X}}_1, \mathbf{E}_1 \rangle_F \approx 0.$$

9. Interprete o que foi preservado e o que foi descartado pela projeção.

Exercício 7.25 (SVD e decomposição espectral da matriz de dados). Utilize a matriz centralizada de `USArrests`.

1. Calcule sua SVD utilizando `svd()`.
2. Extraia $\mathbf{U}$, os valores singulares e $\mathbf{V}$.
3. Construa explicitamente a matriz diagonal $\mathbf{D}$.
4. Verifique numericamente que

$$\mathbf{X}_c \approx \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

5. Verifique que

$$\mathbf{X}_c^\top \mathbf{X}_c \approx \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

6. Calcule

```
eigen(t(Xc) %*% Xc)
```

e compare os autovetores obtidos com os vetores singulares à direita.

7. Compare os autovalores de $\mathbf{X}_c^\top \mathbf{X}_c$ com os quadrados dos valores singulares.
8. Explique por que vetores produzidos por `eigen()` e `svd()` podem diferir apenas pelo sinal.
9. Relacione as colunas de $\mathbf{V}$ a direções no espaço das variáveis.

Exercício 7.26 (Aproximações de posto reduzido em uma matriz de dados). Utilize a SVD obtida no Exercício 7.25.

Para

$$k = 1, 2, 3,$$

construa

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Para cada valor de k :

1. determine o posto numérico de $\mathbf{X}_{c,k}$;
2. calcule

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F;$$

3. verifique numericamente que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 \approx \sum_{j=k+1}^r d_j^2;$$

4. calcule

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2};$$

5. interprete essa quantidade em termos da magnitude quadrática preservada pela aproximação;
6. compare os erros para $k = 1$, $k = 2$ e $k = 3$;
7. explique por que o erro não pode aumentar quando k cresce.

Não utilize `prcomp()` para construir as aproximações.

Exercício 7.27 (Mínimos quadrados com duas variáveis respostas). Utilize o conjunto de dados `mtcars`.

Considere como respostas:

- `mpg`;
- `qsec`;

e como variáveis explicativas:

- `intercepto`;
- `wt`;
- `hp`.

Construa

$$\mathbf{Y} \in \mathbb{R}^{n \times 2}$$

e

$$\mathbf{X} \in \mathbb{R}^{n \times 3}.$$

1. Verifique as dimensões das duas matrizes.
2. Verifique que $\mathbf{X}$ possui posto completo de colunas.
3. Calcule

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

4. Determine as dimensões de $\widehat{\mathbf{B}}$.
5. Interprete suas duas colunas.
6. Calcule

$$\widehat{\mathbf{Y}} = \mathbf{X} \widehat{\mathbf{B}}$$

e

$$\mathbf{E} = \mathbf{Y} - \widehat{\mathbf{Y}}.$$

7. Verifique numericamente que

$$\mathbf{X}^\top \mathbf{E} \approx \mathbf{0}.$$

8. Ajuste separadamente, utilizando `lm()`, um modelo para `mpg` e outro para `qsec`.
 9. Compare os coeficientes das duas regressões com as colunas de $\widehat{\mathbf{B}}$.

Exercício 7.28 (Posto deficiente e pseudoinversa). Utilize `mtcars` e considere `mpg` como vetor-resposta.

Construa uma matriz de delineamento cujas colunas sejam

$$\mathbf{1}, \quad \text{wt}, \quad 2 \text{ wt}.$$

1. Determine o posto da matriz de delineamento.
2. Compare o posto com o número de colunas.
3. Calcule seus valores singulares.
4. Identifique quais valores singulares devem ser considerados numericamente positivos utilizando uma tolerância adequada.
5. Tente utilizar diretamente

$$(\mathbf{X}^\top \mathbf{X})^{-1}$$

e explique o problema encontrado.

6. Construa manualmente a pseudoinversa de $\mathbf{X}$ a partir de sua SVD, invertendo apenas os valores singulares considerados positivos.
7. Obtenha

$$\hat{\beta}^+ = \mathbf{X}^+ \mathbf{y}.$$

8. Calcule

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}^+.$$

9. Determine um vetor não nulo

$$\mathbf{h} \in \mathcal{N}(\mathbf{X}).$$

10. Para diferentes valores de γ , construa

$$\hat{\beta}(\gamma) = \hat{\beta}^+ + \gamma \mathbf{h}.$$

11. Verifique que todos esses vetores produzem o mesmo vetor ajustado.

12. Compare numericamente

$$\|\hat{\beta}(\gamma)\|$$

para vários valores positivos e negativos de γ .

13. Verifique que a solução fornecida pela pseudoinversa possui a menor norma euclidiana.

14. Relacione a não unicidade dos coeficientes ao núcleo de $\mathbf{X}$.

Exercício 7.29 (Vetorização de um modelo com várias respostas). Retome as matrizes $\mathbf{X}$, $\mathbf{Y}$ e $\widehat{\mathbf{B}}$ do Exercício 7.27.

A relação matricial é

$$\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\mathbf{B}}.$$

1. Construa em R

$$\text{vec}(\widehat{\mathbf{Y}})$$

empilhando as colunas.

2. Construa

$$\text{vec}(\widehat{\mathbf{B}}).$$

3. Construa

$$\mathbf{I}_2 \otimes \mathbf{X}.$$

4. Verifique suas dimensões.

5. Verifique numericamente que

$$\text{vec}(\widehat{\mathbf{Y}}) = (\mathbf{I}_2 \otimes \mathbf{X}) \text{vec}(\widehat{\mathbf{B}}).$$

6. Compare as dimensões dos dois lados da igualdade.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a variar no mesmo sentido, em sentidos opostos ou se apresentam relações lineares de redundância.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, caracterizar relações lineares entre as componentes e representar geometricamente a dispersão conjunta (Johnson; Wichern, 2007).

A matriz de correlações resulta da padronização das covariâncias pelos desvios-padrão das variáveis. Seus elementos são adimensionais e permitem comparar a intensidade e o sentido das associações lineares entre variáveis medidas em diferentes unidades.

O objetivo deste capítulo é desenvolver essas estruturas nos níveis populacional e descritivo dos dados observados. As propriedades inferenciais das estatísticas amostrais serão estudadas no Capítulo 10. A distribuição normal multivariada, apresentada no próximo capítulo, utilizará a matriz de covariâncias para construir um modelo probabilístico para a variabilidade conjunta.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathcal{R} \in \mathbb{R}^{p \times p}$ representa a matriz de correlações populacional;
- $\boldsymbol{\Sigma}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas entre os vetores aleatórios $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias populacionais;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa uma matriz de dados observada, com observações nas linhas e variáveis nas colunas;
- $\bar{\mathbf{x}} \in \mathbb{R}^p$ representa o vetor de médias calculado a partir dos dados observados;
- $\mathbf{H}_n = \mathbf{I}_n - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top$ representa a matriz de centralização;
- $\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$ representa a matriz de dados centralizada;
- $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$ representa a matriz total de somas de quadrados e produtos cruzados;
- $\mathbf{S} \in \mathbb{R}^{p \times p}$ e $\mathbf{R} \in \mathbb{R}^{p \times p}$ representam, respectivamente, as matrizes de covariâncias e

- de correlações calculadas a partir dos dados observados;
- $\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp})$ representa a matriz diagonal das variâncias observadas;
- $\mathbf{S}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas calculada entre dois blocos de variáveis observadas;
- $\mathbf{X}$, $\mathbf{T}$, $\mathbf{S}$ e $\mathbf{R}$ representam, respectivamente, a média amostral, a matriz de somas de quadrados e produtos cruzados centralizados, a matriz de covariâncias amostral e a matriz de correlações amostral consideradas como objetos aleatórios; suas propriedades serão desenvolvidas no Capítulo 10;
- $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ representam as parcelas intragrupos e entre grupos da matriz total de somas de quadrados e produtos cruzados;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam, respectivamente, as somas de quadrados total, intragrupos e entre grupos obtidas pelos traços de $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam essas somas de quadrados consideradas como objetos aleatórios;
- $QM_{\text{intra}} = SQ_{\text{intra}}/(n - K)$ e $QM_{\text{entre}} = SQ_{\text{entre}}/(K - 1)$ representam os quadrados médios intragrupos e entre grupos no caso escalar;
- Σ^+ representa a pseudoinversa de Moore–Penrose de Σ quando a matriz de covariâncias é singular.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, formas quadráticas, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais e pseudoinversa permanecem válidas.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Retomando Definição 1.2, considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com realização $\mathbf{x} \in \mathbb{R}^p$. Quando n realizações são observadas, sua organização em uma matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ segue a representação estabelecida na Definição 1.6.

Suponha inicialmente que $E(|X_j|) < \infty$ para $j = 1, \dots, p$. O **vetor de médias populacional** é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \in \mathbb{R}^p. \quad (8.1)$$

O vetor μ determina a localização média da distribuição no espaço das observações. Subtraindo esse vetor de $\mathbf{X}$, obtém-se o vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu. \quad (8.2)$$

Pela linearidade da esperança,

$$E(\mathbf{X}_c) = E(\mathbf{X}) - \mu = \mathbf{0}.$$

A centralização corresponde a uma translação da distribuição, levando seu vetor de médias à origem. Como estabelecido na Proposição 4.15, a subtração do mesmo vetor de todos os pontos preserva as distâncias entre pares de realizações. Portanto, a centralização altera a localização, mas não a geometria relativa da nuvem de pontos.

A centralização da matriz de dados observada será retomada posteriormente neste capítulo, quando forem construídas a matriz de produtos cruzados e a matriz de covariâncias observada.

8.1.2 Momentos de segunda ordem

O estudo das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante também a existência dos primeiros momentos. Além disso, para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz aplicada a variáveis aleatórias de segundo momento finito fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

Portanto, os produtos cruzados necessários à construção das covariâncias possuem esperança finita.

A matriz de segundos momentos em relação à origem é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top) \in \mathbb{R}^{p \times p}.$$

O produto $\mathbf{X}\mathbf{X}^\top$ é o produto externo definido na Definição 1.14. Seus elementos são

$$[\mathbf{X}\mathbf{X}^\top]_{jk} = X_j X_k,$$

de modo que

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1 X_2) & \cdots & E(X_1 X_p) \\ E(X_2 X_1) & E(X_2^2) & \cdots & E(X_2 X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_p X_1) & E(X_p X_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Seus elementos dependem, portanto, da localização da distribuição e de sua variabilidade conjunta.

Para descrever a dispersão em torno do vetor de médias, utiliza-se o segundo momento central:

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Expandindo o produto e utilizando $E(\mathbf{X}) = \mu$,

$$\begin{aligned} \Sigma &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top \\ &= \mathbf{M}_2 - \mu\mu^\top. \end{aligned} \tag{8.3}$$

A identidade Equação 8.3 é a versão matricial da relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está, portanto, no ponto de referência: $\mathbf{M}_2$ descreve segundos momentos em relação à origem, enquanto Σ descreve a variabilidade em torno da média.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com segundos momentos finitos e médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se X e Y são variáveis aleatórias com segundos momentos finitos e médias $\mu_X = E(X)$ e $\mu_Y = E(Y)$, a **covariância populacional** entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva indica predominância de desvios de mesmo sinal;
- uma covariância negativa indica predominância de desvios de sinais opostos;
- uma covariância nula indica ausência de associação linear registrada pela covariância.

A Figura 8.1 apresenta configurações com covariâncias positiva, aproximadamente nula e negativa.




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

Na primeira configuração, a nuvem de pontos tende a se alongar em uma direção crescente; na terceira, em uma direção decrescente. A configuração central não apresenta orientação linear predominante. O valor da covariância depende também das escalas das variáveis e, por isso,

seu módulo não fornece isoladamente uma medida comparável de intensidade entre diferentes pares de variáveis.

Expandindo o produto dos desvios,

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.\end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.4)$$

A expressão Equação 8.4 relaciona a covariância ao momento conjunto $E(XY)$ e aos primeiros momentos das duas variáveis.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.5)$$

A identidade Equação 8.5 mostra que translações não alteram a covariância. Mudanças de escala multiplicam a covariância pelo produto dos fatores aplicados às duas variáveis. Quando somente um desses fatores é negativo, o sinal da covariância é invertido.

Essa dependência das unidades impede a comparação direta entre covariâncias associadas a pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, por exemplo, sua covariância com outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.6)$$

O limite Equação 8.6 será utilizado posteriormente para mostrar que a correlação pertence ao intervalo $[-1, 1]$.

Covariância nula e independência

Covariância nula não implica independência em uma distribuição geral. A covariância registra associação linear de segunda ordem, e relações não lineares podem produzir covariância igual a zero.

Exemplo 8.1 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X , possui média zero e segundo momento finito.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Como ε é independente de X ,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Para calcular a covariância entre X e Y , utiliza-se

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Como $Y = X^2 + \varepsilon$,

$$\begin{aligned} E(XY) &= E[X(X^2 + \varepsilon)] \\ &= E(X^3) + E(X\varepsilon) \\ &= 0. \end{aligned}$$

Além disso,

$$E(X)E(Y) = 0,$$

pois $E(X) = 0$. Portanto,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0.$$

Apesar da covariância nula, X e Y não são independentes. Para verificar isso, considere a esperança condicional de Y dado $X = x$. Como

$$\begin{aligned} E(Y \mid X = x) &= E(X^2 + \varepsilon \mid X = x) \\ &= x^2 + E(\varepsilon \mid X = x). \end{aligned}$$

Como ε é independente de X ,

$$E(\varepsilon \mid X = x) = E(\varepsilon) = 0.$$

Portanto,

$$E(Y \mid X = x) = x^2.$$

Assim, a média condicional de Y depende do valor de X . Se X e Y fossem independentes, a distribuição condicional de Y dado $X = x$ seria a mesma distribuição marginal de Y e, consequentemente,

$$E(Y \mid X = x) = E(Y),$$

não dependendo de x . Logo, X e Y são dependentes, apesar de apresentarem covariância nula.

A Figura 8.2 ilustra essa relação.

A configuração parabólica evidencia uma dependência que não produz orientação linear global. O exemplo delimita a informação fornecida pela covariância e mostra por que o valor zero não deve ser interpretado, sem hipóteses adicionais, como independência.

As variâncias das componentes e as covariâncias entre todos os pares de componentes podem ser reunidas em uma única matriz.




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

Definição 8.2 (Matriz de covariâncias populacional). Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com vetor de médias μ e segundos momentos finitos. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top] \in \mathbb{R}^{p \times p}. \quad (8.7)$$

O elemento situado na linha j e na coluna k de Σ é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.8)$$

Os elementos da diagonal principal são as variâncias,

$$\sigma_{jj} = \text{Var}(X_j),$$

e os elementos fora da diagonal são as covariâncias entre componentes distintos.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

tem-se

$$\sigma_{jk} = \sigma_{kj},$$

e Σ é simétrica. Para p componentes, existem p variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas, totalizando

$$\frac{p(p+1)}{2}$$

elementos distintos.

As unidades dos elementos dependem das variáveis envolvidas. Se X_j é medida em uma unidade u_j , então

$$\sigma_{jj}$$

é expressa em u_j^2 . Para $j \neq k$,

$$\sigma_{jk}$$

é expressa em $u_j u_k$. Essa dependência das unidades motiva a construção posterior da matriz de correlações.

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ possui a forma

$$Y = \mathbf{a}^\top \mathbf{X}, \quad \mathbf{a} \in \mathbb{R}^p.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação e define uma direção no espaço das variáveis. A combinação linear, já utilizada no Módulo 1, adquire aqui uma interpretação probabilística: sua média e sua variância são determinadas por μ e Σ .

Proposição 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \tag{8.9}$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}, \tag{8.10}$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \tag{8.11}$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}.$$

Além disso,

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu} = \mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}).$$

Consequentemente,

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}] \\ &= \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned}$$

De modo análogo,

$$\begin{aligned} \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{b}] \\ &= \mathbf{a}^\top \Sigma \mathbf{b}. \end{aligned}$$

□

A expressão Equação 8.10 mostra que a matriz de covariâncias determina a variabilidade de todas as combinações lineares das componentes. A quantidade

$$\mathbf{a}^\top \Sigma \mathbf{a}$$

é uma forma quadrática no sentido de Definição 2.23. Quando $\|\mathbf{a}\| = 1$, ela representa a variância da projeção de $\mathbf{X}$ sobre a direção unitária $\mathbf{a}$.

Essa relação constitui a ligação entre a matriz de covariâncias e a geometria desenvolvida no Módulo 1: diferentes direções podem apresentar diferentes níveis de dispersão.

Exemplo 8.2 (Matriz de covariâncias com três variáveis). Considere

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

As variâncias das três componentes são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9, \quad \text{Var}(X_3) = 1,$$

e as covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1,5,$$

$$\text{Cov}(X_1, X_3) = -0,8,$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere a combinação linear

$$Y = X_1 + 0,5X_2 - X_3,$$

com vetor de coeficientes

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação 8.10,

$$\begin{aligned} \text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\ &= \begin{bmatrix} 1 & 0,5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix} \\ &= 10,35. \end{aligned}$$

A variância da combinação depende das variâncias individuais, das covariâncias e dos coeficientes utilizados. A covariância negativa entre X_1 e X_3 , por exemplo, contribui positivamente para $\text{Var}(Y)$ porque os coeficientes dessas duas componentes possuem sinais opostos.

8.2.3 Propriedades estruturais e singularidade

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. A classificação de positividade de matrizes foi estabelecida na Definição 2.24; aqui ela adquire uma interpretação probabilística direta, pois a forma quadrática associada a Σ representa uma variância (Eaton, 2007).

Proposição 8.2 (Caracterização estrutural das matrizes de covariâncias). *Uma matriz $\mathbf{C} \in \mathbb{R}^{p \times p}$ é matriz de covariâncias de algum vetor aleatório com segundos momentos finitos se, e somente se,*

$$\mathbf{C} = \mathbf{C}^\top$$

e

$$\mathbf{C} \succeq \mathbf{0}.$$

Consequentemente, toda matriz de covariâncias possui elementos diagonais não negativos, autovalores não negativos e submatrizes principais positivas semidefinidas.

Comprovação. Se

$$\mathbf{C} = \text{Cov}(\mathbf{X}),$$

a simetria decorre de

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j).$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{C} \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Logo, $\mathbf{C}$ é positiva semidefinida.

Reciprocamente, suponha que $\mathbf{C}$ seja real, simétrica e positiva semidefinida. Pelo Teorema 5.4 e pela raiz quadrada principal definida na Definição 5.9, existe uma matriz simétrica positiva semidefinida $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}, \quad j = 1, \dots, p.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{X} = \mathbf{C}^{1/2} \mathbf{U}.$$

Como

$$E(\mathbf{U}) = \mathbf{0},$$

tem-se

$$E(\mathbf{X}) = \mathbf{C}^{1/2} E(\mathbf{U}) = \mathbf{0}.$$

Além disso,

$$E(\mathbf{U}\mathbf{U}^\top) = \mathbf{I}_p.$$

Logo,

$$\begin{aligned}
\text{Cov}(\mathbf{X}) &= E(\mathbf{X}\mathbf{X}^\top) \\
&= E(\mathbf{C}^{1/2}\mathbf{U}\mathbf{U}^\top\mathbf{C}^{1/2}) \\
&= \mathbf{C}^{1/2}E(\mathbf{U}\mathbf{U}^\top)\mathbf{C}^{1/2} \\
&= \mathbf{C}^{1/2}\mathbf{I}_p\mathbf{C}^{1/2} \\
&= \mathbf{C}.
\end{aligned}$$

Portanto, toda matriz real simétrica positiva semidefinida pode ocorrer como matriz de covariâncias. $\square$

Essa construção estabelece apenas a existência de um vetor aleatório com matriz de covariâncias $\mathbf{C}$ e não exige uma família de distribuições específica.

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

também deve ser positiva semidefinida. Logo,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

o que equivale a

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

Esse resultado recupera, no nível matricial, o limite apresentado na Equação 8.6.

A simetria, isoladamente, não é suficiente para caracterizar uma matriz de covariâncias.

Exemplo 8.3 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica. Entretanto, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2.\end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de uma combinação linear, o que é impossível. A matriz é, portanto, simétrica, mas não positiva semidefinida.

Quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$, a matriz Σ é positiva definida. Pela Equação 8.10, isso significa que toda combinação linear não trivial das componentes possui variância positiva.

A situação muda quando Σ é singular. Nesse caso, aparecerá a expressão **quase certamente**. Seja U uma variável aleatória definida em um espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e seja $c \in \mathbb{R}$. Escrever

$$U = c \quad \text{quase certamente}$$

significa que

$$P(\{\omega \in \Omega : U(\omega) = c\}) = P(U = c) = 1.$$

Equivalentemente, a igualdade pode falhar apenas em um conjunto de resultados de probabilidade zero.

Proposição 8.3 (Caracterização da singularidade da matriz de covariâncias). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

Comprovação. Como Σ é simétrica e positiva semidefinida, o Teorema 5.4 garante uma decomposição com autovalores não negativos. A matriz é singular se, e somente se, pelo menos um desses autovalores é zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ no núcleo de Σ e, portanto,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ .

Pela Equação 8.10,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}),$$

o que estabelece a equivalência entre as duas condições seguintes.

Uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser zero. Portanto,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

□

A última condição da Proposição 8.3 também pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade de Σ corresponde à existência de uma relação afim exata e não trivial entre as componentes do vetor aleatório.

Em termos geométricos, os vetores pertencentes a

$$\mathcal{N}(\Sigma)$$

determinam direções de variância nula. Como Σ é simétrica, a relação entre núcleo e espaço coluna desenvolvida no Módulo 1 permite escrever

$$\mathcal{N}(\Sigma)^\perp = \mathcal{C}(\Sigma).$$

Consequentemente,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma) \quad \text{quase certamente.}$$

Se

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade do vetor centralizado está restrita a um subespaço de dimensão r . O vetor original está, portanto, restrito quase certamente ao subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

A matriz de covariâncias também pode ser utilizada para descrever conjuntamente dois vetores aleatórios distintos. Essa extensão produz matrizes retangulares de covariâncias cruzadas e permite representar as relações lineares entre dois blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam segundos momentos finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}, \quad (8.12)$$

em que $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ possuem segundos momentos finitos e médias μ_X e μ_Y , respectivamente.

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para $j = 1, \dots, p$ e $k = 1, \dots, q$. Portanto,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A orientação da matriz depende da ordem dos vetores. Invertendo essa ordem,

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (8.13)$$

Assim,

$$\Sigma_{XY} \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} \in \mathbb{R}^{q \times p}.$$

Mesmo quando $p = q$, não se tem em geral

$$\Sigma_{XY} = \Sigma_{YX},$$

pois uma matriz de covariâncias cruzadas não precisa ser simétrica.

Proposição 8.4 (Covariância entre combinações de dois vetores). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Para quaisquer vetores fixos*

$$\mathbf{a} \in \mathbb{R}^p \quad e \quad \mathbf{b} \in \mathbb{R}^q,$$

tem-se

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (8.14)$$

Comprovação. As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} & \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\ &= E \left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b} \right] \\ &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \end{aligned}$$

□

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

se, e somente se,

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para todos os vetores $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$. Nesse caso, nenhuma combinação linear do primeiro bloco possui covariância não nula com uma combinação linear do segundo.

A condição

$$\Sigma_{XY} = \mathbf{0}$$

não implica, em uma distribuição geral, independência entre os vetores. Essa relação será retomada no Capítulo 9 sob a distribuição normal multivariada.

Os dois vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{V} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix},$$

e sua matriz de covariâncias pode ser representada por blocos, conforme a estrutura de matrizes particionadas definida na Definição 2.25:

$$\Sigma_V = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.15)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor, enquanto os blocos fora da diagonal descrevem as covariâncias entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa condição restringe conjuntamente seus blocos. Em particular, Σ_{XY} não pode ser especificada arbitrariamente depois de fixadas Σ_{XX} e Σ_{YY} .

8.3.1.1 Complemento de Schur e dispersão residual

O complemento de Schur já foi definido na Definição 2.26. Aplicado à matriz de covariâncias particionada, ele recebe uma interpretação estatística de segunda ordem.

Suponha que

$$\Sigma_{YY} \succ \mathbf{0}.$$

O complemento de Schur de Σ_{YY} em Σ_V é

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}. \quad (8.16)$$

Pelo resultado de positividade do complemento de Schur no Teorema 2.9,

$$\Sigma_{XX.Y} \succeq \mathbf{0}.$$

A expressão também pode ser interpretada diretamente como uma covariância residual.

Proposição 8.5 (Complemento de Schur e covariância residual). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos, vetores de médias

$$\mu_X = E(\mathbf{X}) \quad e \quad \mu_Y = E(\mathbf{Y}),$$

e matriz de covariâncias conjunta

$$\text{Cov} \left(\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \right) = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}.$$

Se

$$\Sigma_{YY} \succ \mathbf{0},$$

o complemento de Schur

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$$

é a menor matriz de covariâncias residuais, segundo a ordem de Loewner, entre as matrizes obtidas ao aproximar linearmente $\mathbf{X}_c$ por $\mathbf{LY}_c$, com

$$\mathbf{L} \in \mathbb{R}^{p \times q}.$$

Para

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1},$$

tem-se

$$\text{Cov}(\mathbf{R}_{\mathbf{L}^*}) = \Sigma_{XX.Y},$$

e, para qualquer

$$\mathbf{L} \in \mathbb{R}^{p \times q},$$

tem-se

$$\text{Cov}(\mathbf{R}_{\mathbf{L}}) - \Sigma_{XX.Y} \succeq \mathbf{0},$$

em que

$$\mathbf{R}_{\mathbf{L}} = \mathbf{X}_c - \mathbf{LY}_c,$$

$$\mathbf{X}_c = \mathbf{X} - \mu_X \quad e \quad \mathbf{Y}_c = \mathbf{Y} - \mu_Y$$

Comprovação. Para uma matriz arbitrária $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_{\mathbf{L}}) = \Sigma_{XX} - \mathbf{L}\Sigma_{YX} - \Sigma_{XY}\mathbf{L}^{\top} + \mathbf{L}\Sigma_{YY}\mathbf{L}^{\top}.$$

Substituindo

$$\mathbf{L}^{\star} = \Sigma_{XY}\Sigma_{YY}^{-1},$$

a expressão pode ser reorganizada como

$$\begin{aligned} \text{Cov}(\mathbf{R}_{\mathbf{L}}) &= \Sigma_{XX.Y} \\ &\quad + (\mathbf{L} - \mathbf{L}^{\star})\Sigma_{YY}(\mathbf{L} - \mathbf{L}^{\star})^{\top}. \end{aligned}$$

Como Σ_{YY} é positiva definida,

$$(\mathbf{L} - \mathbf{L}^{\star})\Sigma_{YY}(\mathbf{L} - \mathbf{L}^{\star})^{\top} \succeq \mathbf{0}.$$

A diferença entre a covariância residual correspondente a qualquer $\mathbf{L}$ e aquela obtida com $\mathbf{L}^{\star}$ é, portanto, positiva semidefinida. $\square$

Essa interpretação depende apenas dos segundos momentos e não exige normalidade. Sob normalidade conjunta, o mesmo complemento de Schur aparecerá no Capítulo 9 como matriz de covariâncias da distribuição condicional de um bloco dado o outro.

Exemplo 8.4 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix}.$$

Para as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2,$$

os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação 8.14,

$$\begin{aligned} \text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\ &= [1 \quad -2] \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\ &= -7. \end{aligned}$$

A covariância entre U e V resulta conjuntamente das covariâncias entre todas as componentes que participam das duas combinações lineares.

8.3.2 Transformações afins da média e da covariância

As transformações afins foram definidas na Definição 4.7. No contexto probabilístico, interessa determinar como elas modificam a média e a matriz de covariâncias.

Considere

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r.$$

Proposição 8.6 (Média e covariância sob transformação afim). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ_X e matriz de covariâncias Σ_{XX} . Para*

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c}, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r,$$

tem-se

$$E(\mathbf{U}) = \mathbf{A}\mu_X + \mathbf{c} \quad (8.17)$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \quad (8.18)$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{A}\mathbf{X} + \mathbf{c}) = \mathbf{A}\mu_X + \mathbf{c}.$$

O vetor transformado centralizado é

$$\begin{aligned} \mathbf{U} - E(\mathbf{U}) &= \mathbf{A}\mathbf{X} + \mathbf{c} - \mathbf{A}\mu_X - \mathbf{c} \\ &= \mathbf{A}(\mathbf{X} - \mu_X). \end{aligned}$$

Portanto,

$$\begin{aligned} \text{Cov}(\mathbf{U}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \end{aligned}$$

□

A ausência do vetor $\mathbf{c}$ na Equação 8.18 confirma que translações alteram a localização, mas não a matriz de covariâncias.

Quando

$$r = 1 \quad \text{e} \quad \mathbf{A} = \mathbf{a}^\top,$$

a expressão reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a},$$

recuperando Equação 8.10.

Se $\mathbf{A}$ é diagonal,

$$\mathbf{A} = \text{diag}(a_1, \dots, a_p),$$

então

$$\text{Cov}(a_j X_j, a_k X_k) = a_j a_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(a_j X_j) = a_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal no sentido de Definição 2.18,

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Como $\mathbf{Q}^\top = \mathbf{Q}^{-1}$, essa transformação produz uma matriz semelhante a Σ_{XX} e preserva seus autovalores. A interpretação estatística dessa propriedade será retomada na geometria da covariância.

Exemplo 8.5 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e

$$\mathbf{U} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As componentes transformadas são

$$U_1 = X_1 + X_2$$

e

$$U_2 = X_1 - X_2.$$

Pela expressão Equação 8.18,

$$\begin{aligned}\text{Cov}(\mathbf{U}) &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}.\end{aligned}$$

Logo,

$$\text{Var}(U_1) = 17, \quad \text{Var}(U_2) = 9$$

e

$$\text{Cov}(U_1, U_2) = -5.$$

A transformação modifica simultaneamente as variâncias das componentes e a covariância entre elas.

As covariâncias cruzadas também se transformam de maneira compatível.

Proposição 8.7 (Covariância cruzada sob transformações afins). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Considere*

$$\mathbf{U} = \mathbf{A}_X\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{A}_Y\mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{A}_X \in \mathbb{R}^{r \times p}, \quad \mathbf{A}_Y \in \mathbb{R}^{s \times q}, \quad \mathbf{c} \in \mathbb{R}^r, \quad \mathbf{d} \in \mathbb{R}^s.$$

Então,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \quad (8.19)$$

Comprovação. Após a centralização,

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}_X (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{A}_Y (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E \left[\mathbf{A}_X (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{A}_Y^\top \right] \\ &= \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \end{aligned}$$

□

As expressões Equação 8.18 e Equação 8.19 mostram que a matriz de covariâncias responde de maneira sistemática às transformações lineares. A padronização das componentes constitui um caso particular dessa estrutura.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar as escalas marginais, suponha que

$$\sigma_{jj} = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias populacionais por

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}). \quad (8.20)$$

Como todas as variâncias são positivas,

$$\mathbf{D}_{\Sigma} \succ \mathbf{0}$$

e existem as matrizes diagonais

$$\mathbf{D}_{\Sigma}^{1/2} = \text{diag} \left(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}} \right)$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Definição 8.4 (Vetor aleatório padronizado). Se $\mathbf{X} \in \mathbb{R}^p$ possui média μ e variâncias marginais positivas, o vetor aleatório marginalmente padronizado correspondente é

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu), \quad (8.21)$$

em que $\mathbf{D}_{\Sigma} \succ \mathbf{0}$ é a matriz diagonal das variâncias populacionais e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Sua componente j é

$$Z_j = \frac{X_j - \mu_j}{\sqrt{\sigma_{jj}}}.$$

Assim,

$$E(Z_j) = 0$$

e

$$\text{Var}(Z_j) = 1.$$

Em forma vetorial,

$$E(\mathbf{Z}) = \mathbf{0}.$$

Aplicando Equação 8.18,

$$\text{Cov}(\mathbf{Z}) = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Definição 8.5 (Matriz de correlações populacional). A **matriz de correlações populacional** de $\mathbf{X} \in \mathbb{R}^p$ é

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}, \quad (8.22)$$

em que Σ é a matriz de covariâncias de $\mathbf{X}$ e

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}),$$

com

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

O símbolo $\mathcal{R}$ é reservado à matriz populacional. Posteriormente, $\mathbf{R}$ representará a matriz de correlações amostral, enquanto $\mathbf{R}$ representará seu valor calculado a partir de uma amostra observada.

A matriz $\mathcal{R}$ possui a forma

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sqrt{\sigma_{jj}\sigma_{kk}}}. \quad (8.23)$$

Equivalentemente,

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

A correlação é adimensional porque o numerador e o denominador de Equação 8.23 possuem as mesmas unidades.

A relação entre covariâncias e correlações pode ser invertida:

$$\Sigma = \mathbf{D}_{\Sigma}^{1/2} \mathcal{R} \mathbf{D}_{\Sigma}^{1/2}. \quad (8.24)$$

Portanto, Σ pode ser decomposta em dois elementos:

- $\mathbf{D}_{\Sigma}$ registra as variâncias e, consequentemente, as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear após a remoção dessas escalas.

A matriz de correlações isoladamente não permite recuperar as variâncias originais.

Exemplo 8.6 (Matriz de correlações obtida por uma transformação de padronização). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com vetor de médias μ e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix}.$$

Os desvios-padrão populacionais são

$$\sqrt{\sigma_{11}} = 4 \quad \text{e} \quad \sqrt{\sigma_{22}} = 5.$$

Portanto,

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 16 & 0 \\ 0 & 25 \end{bmatrix}$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix}.$$

Considere a transformação de padronização

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu).$$

Ela pode ser escrita como a transformação afim

$$\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

com

$$\mathbf{A} = \mathbf{D}_{\Sigma}^{-1/2}$$

e

$$\mathbf{c} = -\mathbf{D}_{\Sigma}^{-1/2}\boldsymbol{\mu}.$$

Utilizando Proposição 8.6,

$$\text{Cov}(\mathbf{Z}) = \mathbf{A}\Sigma\mathbf{A}^{\top}.$$

Como $\mathbf{A}$ é diagonal e simétrica,

$$\begin{aligned}\text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.\end{aligned}$$

Essa é precisamente a matriz de correlações populacional,

$$\mathcal{R} = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.$$

De fato,

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \frac{12}{\sqrt{16 \cdot 25}} = \frac{12}{20} = 0,6.$$

O exemplo mostra duas formas equivalentes de chegar ao mesmo resultado. Pela transformação do vetor,

$$\text{padronizar } \mathbf{X} \implies \text{Cov}(\mathbf{Z}).$$

Equivalentemente, pode-se transformar diretamente a matriz de covariâncias:

$$\Sigma \implies \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Em ambas as perspectivas, as variâncias tornam-se unitárias e a covariância entre as componentes padronizadas passa a coincidir com sua correlação.

8.4.2 Propriedades, escala e independência

Proposição 8.8 (Caracterização das matrizes de correlações). *Uma matriz*

$$\mathbf{C} \in \mathbb{R}^{p \times p}$$

é matriz de correlações de algum vetor aleatório com variâncias marginais positivas se, e somente se,

$$\mathbf{C} = \mathbf{C}^{\top},$$

$$\mathbf{C} \succeq \mathbf{0}$$

e

$$c_{jj} = 1, \quad j = 1, \dots, p.$$

Consequentemente, toda matriz de correlações possui:

1. elementos no intervalo $[-1, 1]$;
2. autovalores reais e não negativos;
3. traço igual a p .

Comprovação. Se $\mathbf{C} = \mathcal{R}$ é uma matriz de correlações, então

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Como Σ é simétrica,

$$\mathcal{R}^{\top} = \mathcal{R}.$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \mathcal{R} \mathbf{a} &= \left(\mathbf{D}_\Sigma^{-1/2} \mathbf{a} \right)^\top \Sigma \left(\mathbf{D}_\Sigma^{-1/2} \mathbf{a} \right) \\ &\geq 0,\end{aligned}$$

de modo que

$$\mathcal{R} \succeq \mathbf{0}.$$

A diagonal é unitária porque

$$\rho_{jj} = \frac{\sigma_{jj}}{\sqrt{\sigma_{jj}\sigma_{jj}}} = 1.$$

Reciprocamente, suponha que $\mathbf{C}$ seja simétrica, positiva semidefinida e possua diagonal unitária. Pela raiz quadrada principal definida na Definição 5.9, existe $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{Z} = \mathbf{C}^{1/2} \mathbf{U}.$$

Tem-se

$$\text{Cov}(\mathbf{Z}) = \mathbf{C}^{1/2} \mathbf{I}_p \mathbf{C}^{1/2} = \mathbf{C}.$$

Como a diagonal de $\mathbf{C}$ é unitária, todas as componentes de $\mathbf{Z}$ possuem variância igual a um. Logo, sua matriz de covariâncias coincide com sua matriz de correlações, e $\mathbf{C}$ é uma matriz de correlações válida.

Pela desigualdade de Cauchy–Schwarz,

$$|c_{jk}| \leq \sqrt{c_{jj}c_{kk}} = 1.$$

Como $\mathbf{C}$ é simétrica e positiva semidefinida, seus autovalores são reais e não negativos. Finalmente,

$$\text{tr}(\mathbf{C}) = \sum_{j=1}^p c_{jj} = p.$$

□

Se Σ possui variâncias marginais positivas, então $\mathbf{D}_\Sigma^{-1/2}$ é invertível e a padronização preserva a definição positiva. Assim,

$$\mathcal{R} \succ \mathbf{0} \quad \Longleftrightarrow \quad \Sigma \succ \mathbf{0}.$$

Os valores extremos da correlação correspondem a relações lineares exatas entre as variáveis padronizadas. Para $j \neq k$,

$$\rho_{jk} = 1 \quad \Longleftrightarrow \quad Z_k = Z_j \quad \text{quase certamente,}$$

enquanto

$$\rho_{jk} = -1 \quad \Longleftrightarrow \quad Z_k = -Z_j \quad \text{quase certamente.}$$

Portanto, uma correlação de módulo igual a 1 implica uma relação linear exata entre as duas variáveis e, conseqüentemente, a singularidade da matriz de covariâncias do par correspondente.

Além disso, não basta que cada correlação, considerada isoladamente, pertença ao intervalo $[-1, 1]$ para que uma matriz seja uma matriz de correlações válida; a matriz completa também deve ser positiva semidefinida.

Exemplo 8.7 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0,9 & 0,9 \\ 0,9 & 1 & -0,9 \\ 0,9 & -0,9 & 1 \end{bmatrix}.$$

Todos os elementos pertencem ao intervalo $[-1, 1]$, a matriz é simétrica e sua diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2,888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Logo, $\mathbf{A}$ não é uma matriz de correlações.

O exemplo mostra que as correlações entre pares devem ser compatíveis com uma única estrutura conjunta positiva semidefinida.

Duas componentes X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como suas variâncias são positivas,

$$\rho_{jk} = 0 \iff \sigma_{jk} = 0.$$

Essa condição não implica independência em uma distribuição geral, conforme ilustrado no Exemplo 8.1.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

e, portanto,

$$\text{Cov}(X_j, X_k) = 0.$$

Assim,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca depende de hipóteses adicionais.

Uma matriz de correlações diagonal necessariamente é

$$\mathcal{R} = \mathbf{I}_p.$$

Nesse caso, todas as componentes são duas a duas não correlacionadas. Essa propriedade não garante, por si só, independência conjunta. A relação especial entre ausência de correlação e independência sob normalidade conjunta será estabelecida no Capítulo 9.

Considere agora uma mudança de localização e escala aplicada separadamente às componentes:

$$Y_j = c_j X_j + d_j, \quad c_j \neq 0.$$

Tem-se

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk},$$

enquanto

$$\text{Var}(Y_j) = c_j^2 \sigma_{jj}.$$

Consequentemente,

$$\text{Corr}(Y_j, Y_k) = \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \quad (8.25)$$

Se $c_j > 0$ e $c_k > 0$,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Portanto, translações e mudanças positivas de unidade não alteram a correlação. A multiplicação de uma variável por uma constante negativa inverte o sinal de suas correlações, sem alterar seus módulos.

Exemplo 8.8 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.2:

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

A matriz das variâncias marginais é

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de modo que

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.22,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2} \\ &= \begin{bmatrix} 1 & 0,25 & -0,4 \\ 0,25 & 1 & 0 \\ -0,4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1,5}{\sqrt{4 \cdot 9}} = 0,25,$$

enquanto

$$\rho_{13} = \frac{-0,8}{\sqrt{4 \cdot 1}} = -0,4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

tem-se

$$|\rho_{13}| > |\rho_{12}|.$$

A covariância entre X_1 e X_2 possui maior módulo nas unidades originais, mas a associação linear padronizada entre X_1 e X_3 é mais intensa. A comparação evidencia a diferença entre a informação fornecida por covariâncias e por correlações.

A matriz de covariâncias preserva as variâncias e as unidades originais das componentes. A matriz de correlações descreve a mesma estrutura de segunda ordem após a padronização marginal, atribuindo variância unitária a todas as componentes. Essa mudança de escala pode alterar a geometria da dispersão e será considerada na interpretação espectral das duas matrizes.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais e elipsoide de covariância

A expressão Equação 8.10 mostra que a matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa quantidade representa a dispersão ao longo da direção unitária $\mathbf{a}$. A interpretação espectral das formas quadráticas foi desenvolvida no Capítulo 5. Aplicando o Teorema 5.4 à matriz simétrica positiva semidefinida Σ ,

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top, \quad (8.26)$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j \geq 0.$$

A transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.27)$$

expressa o vetor centralizado nas coordenadas da base de autovetores. Pela regra de transformação da covariância,

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \Lambda. \quad (8.28)$$

Portanto,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Cov}(Y_j, Y_k) = 0, \quad j \neq k.$$

Os autovetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. O autovalor λ_j quantifica a variância ao longo do eixo $\mathbf{q}_j$.

Se

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

o resultado sobre os extremos do quociente de Rayleigh no Teorema 5.5 fornece

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.29)$$

Os valores extremos são alcançados nos autovetores correspondentes. Assim, a decomposição espectral identifica direções ortogonais nas quais as covariâncias desaparecem e as variâncias são dadas diretamente pelos autovalores.

Neste capítulo, essa decomposição é utilizada somente para descrever a geometria da dispersão. A seleção de eixos espectrais para construir uma representação de dimensão reduzida pertence à formulação da Análise de Componentes Principais.

Exemplo 8.9 (Obtenção dos eixos de maior e menor variabilidade). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Queremos determinar a direção unitária

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

na qual a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

apresenta a maior variância possível.

Pela expressão Equação 8.10,

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto, o problema é

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Esse é precisamente o tipo de problema de otimização com restrição estudado no Módulo 1. Como maximizar uma função equivale a minimizar seu negativo, a condição necessária de Lagrange estabelecida no Teorema 7.6 aplica-se também a este problema. Considere

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \Sigma \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1).$$

Como Σ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \Sigma \mathbf{a}) = 2\Sigma \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é, portanto,

$$2\Sigma \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0},$$

ou

$$\Sigma \mathbf{a} = \eta \mathbf{a}. \quad (8.30)$$

Assim, as direções estacionárias do problema são autovetores de Σ , e os multiplicadores de Lagrange correspondentes são seus autovalores.

Para determiná-los,

$$\det(\Sigma - \eta \mathbf{I}_2) = 0.$$

Logo,

$$\begin{aligned} \det \begin{bmatrix} 4-\eta & 2 \\ 2 & 4-\eta \end{bmatrix} &= (4-\eta)^2 - 4 \\ &= \eta^2 - 8\eta + 12 \\ &= (\eta - 6)(\eta - 2). \end{aligned}$$

Os autovalores são, portanto,

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2.$$

Para $\lambda_1 = 6$,

$$(\Sigma - 6\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = a_2.$$

Impondo a restrição de norma unitária,

$$a_1^2 + a_2^2 = 1,$$

podemos escolher

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 2$,

$$(\Sigma - 2\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = -a_2,$$

e podemos escolher

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo resultado dos extremos do quociente de Rayleigh no Teorema 5.5,

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_1 = 6,$$

alcançado na direção $\mathbf{q}_1$, enquanto

$$\min_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_2 = 2,$$

alcançado na direção $\mathbf{q}_2$.

Consequentemente,

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 6$$

e

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 2.$$

Reunindo os autovetores em

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

a transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu)$$

produz

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

O cálculo mostra concretamente a conexão entre **variância de uma combinação linear, otimização restrita e decomposição espectral**: os autovetores da matriz de covariâncias surgem como as direções estacionárias da variância sob a restrição de norma unitária, e os autovalores fornecem as variâncias nessas direções.

Neste ponto, o objetivo é somente compreender a geometria da matriz de covariâncias. A utilização dessas direções para construir uma técnica de redução de dimensionalidade será desenvolvida posteriormente na Análise de Componentes Principais.

Quando Σ é diagonal, os eixos espectrais coincidem com os eixos coordenados. No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \quad (8.31)$$

tem-se, para qualquer vetor unitário $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2.$$

A condição Equação 8.31 descreve uma estrutura de segunda ordem isotrópica: a variância é a mesma em todas as direções. Essa condição, isoladamente, não implica que a distribuição de $\mathbf{X}$ seja esfericamente simétrica.

Suponha agora que

$$\Sigma \succ \mathbf{0}.$$

Para $c > 0$, considere

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.32)$$

A interpretação das superfícies de nível de formas quadráticas positivas definidas foi estabelecida no Capítulo 5. Neste caso, utilizando Equação 8.26 e definindo

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

a condição que define $\mathcal{E}_c$ torna-se

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.33)$$

Portanto:

- o centro é μ ;
- os eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo associado a $\mathbf{q}_j$ possui comprimento $c\sqrt{\lambda_j}$.

Assim, autovalores maiores correspondem a maior extensão da dispersão na direção associada.

A Figura 8.3 mostra essa geometria no caso bidimensional.




Figura 8.3: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias determina, assim, uma geometria de segunda ordem para a dispersão conjunta.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido somente por μ e Σ . Sem uma hipótese adicional sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma probabilidade específica nem interpretá-lo como região de confiança. A interpretação probabilística dessas superfícies será desenvolvida no Capítulo 9 para a distribuição normal multivariada.

Quando Σ é singular, a variabilidade está restrita ao subespaço

$$\mathcal{C}(\Sigma).$$

A raiz quadrada principal definida na Definição 5.9 permite representar o elipsoide degenerado por

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}, \quad (8.34)$$

em que

$$r = \text{posto}(\Sigma) < p.$$

Esse conjunto está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

e possui r semieixos não nulos, com comprimentos $c\sqrt{\lambda_j}$ para os autovalores positivos. A pseudoinversa será utilizada mais adiante para expressar a mesma geometria no contexto da distância de Mahalanobis.

8.5.2 Variância total, variância generalizada e volume

Uma matriz de covariâncias contém toda a estrutura de segunda ordem do vetor aleatório. Algumas funções escalares de Σ resumem aspectos específicos dessa dispersão, mas nenhuma delas substitui a matriz completa.

Definição 8.6 (Variância total). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância total** é

$$V_T(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.35)$$

Pela definição de traço na Definição 2.9,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.36)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.37)$$

A variância total também possui uma interpretação em termos de esperança matemática. Mais geralmente, seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$ um vetor fixo. Então,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}). \quad (8.38)$$

De fato,

$$\mathbf{X} - \mathbf{a} = (\mathbf{X} - \mu) + (\mu - \mathbf{a}),$$

e, ao expandir a forma quadrática, os termos cruzados possuem esperança nula porque

$$E(\mathbf{X} - \mu) = \mathbf{0}.$$

Além disso,

$$E[(\mathbf{X} - \mu)^\top \mathbf{A} (\mathbf{X} - \mu)] = \text{tr}(\mathbf{A}\Sigma).$$

Tomando

$$\mathbf{A} = \mathbf{I}_p \quad \text{e} \quad \mathbf{a} = \mu,$$

obtem-se

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \text{tr} (\Sigma) . \quad (8.39)$$

Portanto, a variância total é o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu vetor de médias.

Mais geralmente, tomando $\mathbf{A} = \mathbf{I}_p$,

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] = \text{tr} (\Sigma) + \|\mu - \mathbf{a}\|^2 . \quad (8.40)$$

Essa expressão mostra que μ minimiza o afastamento quadrático médio:

$$E \left[\|\mathbf{X} - \mathbf{a}\|^2 \right] \geq E \left[\|\mathbf{X} - \mu\|^2 \right] .$$

Como

$$\text{tr} (\Sigma) = \sum_{j=1}^p \lambda_j ,$$

segue também que

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \sum_{j=1}^p \lambda_j .$$

Assim, a mesma quantidade pode ser interpretada como soma das variâncias marginais, soma das variâncias nos eixos espectrais ou afastamento euclidiano quadrático médio em relação ao centro.

Definição 8.7 (Variância média). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , com autovalores $\lambda_1, \dots, \lambda_p$, sua **variância média** é

$$\text{VM} (\mathbf{X}) = \frac{1}{p} \text{tr} (\Sigma) = \frac{1}{p} \sum_{j=1}^p \lambda_j .$$

A variância total e a variância média dependem das escalas das componentes. Quando as variáveis possuem unidades distintas, sua interpretação requer cautela.

Outra medida utiliza o determinante da matriz de covariâncias.

Definição 8.8 (Variância generalizada). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância generalizada** é

$$V_G(\mathbf{X}) = \det(\Sigma). \quad (8.41)$$

Pelas propriedades do determinante e pela decomposição espectral,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.42)$$

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se pelo menos um autovalor é zero,

$$\det(\Sigma) = 0,$$

mesmo que exista variabilidade nas demais direções. Nesse caso, o valor zero indica que a dispersão ocupa um subespaço de dimensão inferior a p ; não indica ausência de variabilidade.

A variância generalizada não deve ser confundida com o volume do elipsoide de covariância. A relação entre as duas quantidades envolve a raiz quadrada do determinante (Johnson; Wichern, 2007).

Proposição 8.9 (Volume do elipsoide de covariância). *Se*

$$p \geq 1, \quad \mu \in \mathbb{R}^p, \quad \Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}$$

e

$$c > 0,$$

considere o elipsoide

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}.$$

Seu volume p -dimensional é

$$\text{Vol}_p(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.43)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

Comprovação. O elipsoide é a imagem da bola

$$\mathcal{B}_c = \{\mathbf{u} \in \mathbb{R}^p : \|\mathbf{u}\| \leq c\}$$

pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2}\mathbf{u}.$$

A translação não altera o volume. Pelo Proposição 4.9, a transformação linear multiplica volumes por

$$|\det(\Sigma^{1/2})| = \det(\Sigma)^{1/2}.$$

Como

$$\text{Vol}_p(\mathcal{B}_c) = \kappa_p c^p,$$

obtem-se Equação 8.43. □

Portanto,

$$\det(\Sigma)^{1/2}$$

é o fator associado à escala de volume da dispersão, enquanto

$$\det(\Sigma)$$

é a variância generalizada.

Exemplo 8.10 (Variância total e variância generalizada). Considere

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = \text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16$$

e

$$\det(\Sigma_2) = 7.$$

A primeira configuração distribui a variabilidade igualmente entre os dois eixos. A segunda concentra maior variabilidade em uma direção e menor variabilidade na outra. A igualdade das variâncias totais não implica, portanto, igualdade da geometria da dispersão.

As unidades também diferem entre essas medidas. Se as componentes possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 \cdots u_p^2,$$

enquanto

$$\det(\Sigma)^{1/2}$$

possui unidade

$$u_1 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

Considere agora uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela expressão Equação 8.18,

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.$$

Consequentemente,

$$\det(\Sigma_{YY}) = \det(\mathbf{A})^2 \det(\Sigma_{XX}). \quad (8.44)$$

Para a escala de volume,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.45)$$

Essa expressão é compatível com o fator de alteração de volume desenvolvido na Proposição 4.9.

Quando $\mathbf{A}$ é ortogonal, $|\det(\mathbf{A})| = 1$ e a transformação preserva os autovalores de Σ . Consequentemente, preserva a variância total, a variância generalizada e os comprimentos dos semieixos do elipsoide, alterando somente sua orientação no sistema de coordenadas.

A forma quadrática que define o elipsoide fornece também uma medida de afastamento adaptada à estrutura de covariâncias. Essa medida é a distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana utiliza a mesma geometria em todas as direções. Em dados multivariados, entretanto, um deslocamento pode representar um afastamento pequeno em uma direção de grande variabilidade e um afastamento expressivo em outra direção de pequena variabilidade.

A distância de Mahalanobis incorpora essa estrutura por meio da matriz de covariâncias. No caso univariado, ela reduz o afastamento $|x - \mu|$ à sua escala natural,

$$\frac{|x - \mu|}{\sigma}.$$

Definição 8.9 (Distância de Mahalanobis). Se $\Sigma \in \mathbb{R}^{p \times p}$ é positiva definida, a **distância de Mahalanobis** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação a Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.46)$$

Em particular, a distância de $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.47)$$

8.6.1 Interpretação geométrica e espectral

O quadrado da distância de Mahalanobis de $\mathbf{x}$ ao vetor de médias é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.48)$$

Como $\Sigma^{-1} \succ \mathbf{0}$, ela define o produto interno induzido apresentado na Definição 3.16 e a norma correspondente de Definição 3.17. Assim, Equação 8.46 é uma distância métrica, sem necessidade de repetir aqui a demonstração das propriedades métricas desenvolvidas no Módulo 1.

Quando

$$\Sigma = \mathbf{I}_p,$$

a distância de Mahalanobis coincide com a distância euclidiana. Quando $p = 1$,

$$d_M(x, \mu) = \frac{|x - \mu|}{\sigma}.$$

A medida é adimensional, pois a inversa da matriz de covariâncias compensa as unidades presentes no vetor de diferenças.

A interpretação espectral decorre diretamente de Equação 8.26. Se

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

então

$$d_M^2(\mathbf{x}, \mu) = \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \quad (8.49)$$

Essa expressão mostra como a distância de Mahalanobis incorpora a geometria da dispersão. Cada componente u_j representa o deslocamento de $\mathbf{x} - \mu$ na direção do autovetor correspondente, enquanto λ_j é a variância nessa direção.

Cada deslocamento é, portanto, ponderado pelo inverso da variância na direção correspondente. Um mesmo deslocamento geométrico recebe menor peso em uma direção de grande variabilidade e maior peso em uma direção de pequena variabilidade.

Exemplo 8.11 (Afastamentos em direções com variâncias distintas). Considere dois eixos espectrais com

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Um afastamento de magnitude 2 ao longo do primeiro eixo produz

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

O mesmo afastamento ao longo do segundo produz

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro, mas o segundo apresenta maior distância de Mahalanobis porque se encontra em uma direção com menor dispersão populacional.

As superfícies de igual distância,

$$d_M(\mathbf{x}, \mu) = c,$$

são exatamente as fronteiras dos elipsoides definidos na Equação 8.32. Isso reforça a interpretação geométrica da distância de Mahalanobis: pontos pertencentes à mesma superfície elipsoidal apresentam o mesmo afastamento em relação ao centro quando a estrutura de covariâncias é considerada.

A Figura 8.4 compara dois deslocamentos com a mesma distância euclidiana ao centro, mas orientados segundo eixos de dispersão distintos.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A medida compara o deslocamento com a quantidade de variabilidade disponível na direção em que ele ocorre.




Figura 8.4: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

8.6.2 Branqueamento e esferização

Uma forma alternativa de compreender a geometria associada à matriz de covariâncias consiste em transformar as coordenadas de modo que a variabilidade resultante seja a mesma em todas as direções.

Seja $\mathbf{X}$ um vetor aleatório com vetor de médias μ e matriz de covariâncias $\Sigma \succ \mathbf{0}$. Uma transformação linear da forma

$$\mathbf{Z} = \mathbf{W}(\mathbf{X} - \mu)$$

é denominada **branqueamento** (*whitening*) quando a matriz $\mathbf{W}$ é escolhida de modo que

$$\text{Cov}(\mathbf{Z}) = \mathbf{W}\Sigma\mathbf{W}^\top = \mathbf{I}_p.$$

Assim, as componentes do vetor branqueado possuem variância unitária e covariâncias nulas entre si. O termo **esferização** enfatiza a interpretação geométrica da mesma transformação: os elipsoides associados à estrutura de covariâncias são transformados em esferas.

Essa interpretação refere-se à estrutura de segunda ordem do vetor aleatório, representada pela matriz de covariâncias. Em geral, o branqueamento não implica que toda a distribuição do vetor transformado seja esfericamente simétrica.

A raiz quadrada inversa de uma matriz positiva definida foi construída no Capítulo 5 a partir da raiz quadrada principal dada na Definição 5.9. Uma escolha para a matriz de branqueamento é

$$\mathbf{W} = \Sigma^{-1/2},$$

pois

$$\Sigma^{-1/2}\Sigma\Sigma^{-1/2} = \mathbf{I}_p.$$

Essa escolha é denominada **branqueamento simétrico**. Ela remove simultaneamente as diferenças de variância e as covariâncias entre as componentes. Para um ponto $\mathbf{x}$, a transformação correspondente é

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu). \quad (8.50)$$

Para o vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2}(\mathbf{X} - \mu),$$

tem-se

$$E(\mathbf{Z}) = \mathbf{0} \quad \text{e} \quad \text{Cov}(\mathbf{Z}) = \mathbf{I}_p. \quad (8.51)$$

A transformação de branqueamento também permite interpretar diretamente a distância de Mahalanobis. De Equação 8.50,

$$\begin{aligned} \|\mathbf{z}\|^2 &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Logo,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.52)$$

A distância de Mahalanobis é, portanto, a distância euclidiana após a centralização e o branqueamento.

A esperança da distância quadrática de Mahalanobis também depende apenas da matriz de covariâncias. Como

$$d_M^2(\mathbf{X}, \mu) = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu),$$

a expressão Equação 8.38, com

$$\mathbf{A} = \Sigma^{-1},$$

fornece

$$\begin{aligned} E[d_M^2(\mathbf{X}, \mu)] &= \text{tr}(\Sigma^{-1} \Sigma) \\ &= \text{tr}(\mathbf{I}_p) \\ &= p. \end{aligned} \quad (8.53)$$

Esse resultado utiliza apenas a existência de μ e $\Sigma \succ \mathbf{0}$; não requer normalidade. No Capítulo 9, a hipótese de normalidade multivariada permitirá caracterizar não apenas essa esperança, mas a distribuição completa da distância quadrática de Mahalanobis.

Exemplo 8.12 (Branqueamento a partir da decomposição espectral). Retome a matriz de covariâncias do Exemplo 8.9,

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Sua decomposição espectral é

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

Utilizando a raiz quadrada inversa desenvolvida no Módulo 1,

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top,$$

em que

$$\Lambda^{-1/2} = \begin{bmatrix} 1/\sqrt{6} & 0 \\ 0 & 1/\sqrt{2} \end{bmatrix}.$$

Defina

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu).$$

Então,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \mathbf{Q}\Lambda\mathbf{Q}^\top \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\mathbf{I}_2\mathbf{Q}^\top \\ &= \mathbf{I}_2. \end{aligned}$$

A transformação pode ser compreendida em três etapas:

$$\begin{aligned} \mathbf{X} - \mu &\xrightarrow{\mathbf{Q}^\top} \text{coordenadas nos eixos espectrais} \\ &\xrightarrow{\Lambda^{-1/2}} \text{reescalonamento para variância unitária} \\ &\xrightarrow{\mathbf{Q}} \mathbf{Z}. \end{aligned}$$

O primeiro passo expressa o vetor na base de autovetores de Σ , na qual a matriz de covariâncias é diagonal. O segundo divide cada coordenada por $\sqrt{\lambda_j}$, tornando todas as variâncias iguais a 1. O terceiro retorna ao sistema original de coordenadas por meio da transformação ortogonal $\mathbf{Q}$.

Considere agora um ponto cuja diferença em relação ao centro é

$$\mathbf{x} - \mu = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Suas coordenadas espectrais são

$$\mathbf{Q}^\top (\mathbf{x} - \mu) = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

Pela expressão Equação 8.49,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= \frac{(\sqrt{2})^2}{6} + \frac{(\sqrt{2})^2}{2} \\ &= \frac{2}{6} + \frac{2}{2} \\ &= \frac{4}{3}. \end{aligned}$$

Por outro lado,

$$\left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|^2 = \frac{4}{3}.$$

Assim, o exemplo verifica concretamente a identidade

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|.$$

A decomposição espectral, a raiz matricial, o branqueamento e a distância de Mahalanobis aparecem, portanto, como partes de uma mesma construção geométrica.

O branqueamento não é único. De fato, se $\mathbf{Q}_0$ é uma matriz ortogonal, então

$$\mathbf{W} = \mathbf{Q}_0 \Sigma^{-1/2}$$

também satisfaz

$$\mathbf{W} \Sigma \mathbf{W}^\top = \mathbf{I}_p.$$

Portanto, diferentes transformações podem produzir vetores com matriz de covariâncias igual à identidade. Essas versões diferem por uma transformação ortogonal e, conseqüentemente, preservam as distâncias euclidianas no espaço branqueado.

A padronização marginal e o branqueamento devem ser distinguidos. Pela expressão Equação 8.22, a padronização marginal produz

$$\text{Cov} \left(\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \right) = \mathcal{R}.$$

Assim, a padronização marginal torna as variâncias iguais a 1, mas a matriz resultante pode apresentar correlações não nulas fora da diagonal. O branqueamento, por sua vez, utiliza a estrutura completa da matriz de covariâncias e produz

$$\text{Cov} (\mathbf{Z}) = \mathbf{I}_p.$$

Se

$$\mathbf{z}_D = \mathbf{D}_\Sigma^{-1/2} (\mathbf{x} - \mu),$$

a relação

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}$$

implica

$$d_M^2(\mathbf{x}, \mu) = \mathbf{z}_D^\top \mathcal{R}^{-1} \mathbf{z}_D. \quad (8.54)$$

Assim, a padronização marginal remove as escalas individuais, enquanto $\mathcal{R}^{-1}$ incorpora a associação linear remanescente. Somente quando

$$\mathcal{R} = \mathbf{I}_p$$

a distância de Mahalanobis coincide com a distância euclidiana entre as coordenadas marginalmente padronizadas.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são objetos populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão conjunta podem ser representadas por quantidades calculadas diretamente a partir das observações.

Nesta seção,

$$\bar{\mathbf{x}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}$$

representam valores obtidos de uma matriz de dados específica. Quando as linhas dessa matriz forem consideradas realizações de uma amostra aleatória, esses valores corresponderão a realizações das estatísticas

$$\bar{\mathbf{X}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}.$$

As propriedades dessas estatísticas como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Centralização, SQPC e matriz de covariâncias observada

Considere $n \geq 2$ observações de p variáveis organizadas, conforme Definição 1.6, em

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p$$

representa a i -ésima observação.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \in \mathbb{R}^p, \quad (8.55)$$

em que

$$\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n.$$

A matriz de dados centralizada é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.56)$$

Cada linha de $\mathbf{X}_c$ é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e suas colunas satisfazem

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.57)$$

Retomando a matriz de centralização utilizada no Capítulo 4,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

tem-se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.58)$$

A operação remove a localização das colunas sem alterar as diferenças entre as observações, conforme a propriedade estabelecida na Proposição 4.15.

Definição 8.10 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SQPC, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Equivalentemente,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.59)$$

A sigla **SQPC** significa **Somas de Quadrados e Produtos Cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*. O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

Quando $j = k$, t_{jj} é a soma dos quadrados dos desvios da variável j . Quando $j \neq k$, t_{jk} é a soma dos produtos cruzados entre as variáveis j e k .

Como

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram das colunas centralizadas no sentido de Definição 3.18. Assim, pelas propriedades estabelecidas na Proposição 3.9,

$$\mathbf{T} = \mathbf{T}^\top,$$

$$\mathbf{T} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

A centralização impõe

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top,$$

de modo que as colunas de $\mathbf{X}_c$ pertencem ao subespaço ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (8.60)$$

A matriz $\mathbf{T}$ registra a dispersão sem uma normalização pelo número de observações.

Definição 8.11 (Matriz de covariâncias observada). A **matriz de covariâncias observada** é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.61)$$

Seu elemento (j, k) é

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k). \quad (8.62)$$

Os elementos diagonais são as variâncias calculadas para as colunas,

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

e os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas.

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$,

$$\mathbf{S} = \mathbf{S}^\top, \quad \mathbf{S} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

Portanto,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1). \quad (8.63)$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

Essa singularidade decorre da dimensão dos dados centralizados. Suas consequências para estimação e regularização serão tratadas no Capítulo 10.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{S} \mathbf{a} &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \end{aligned} \quad (8.64)$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas determinada por $\mathbf{a}$. Portanto, Equação 8.64 é a contraparte descritiva de Equação 8.10.

O divisor $n-1$ é utilizado aqui como convenção para a matriz de covariâncias observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será estabelecida no Capítulo 10.

8.7.2 Matriz de correlações e covariâncias cruzadas observadas

Suponha que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias observadas por

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}). \quad (8.65)$$

Definição 8.12 (Matriz de correlações observada). A **matriz de correlações observada** é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \quad (8.66)$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.67)$$

A matriz $\mathbf{R}$ é simétrica, positiva semidefinida e possui diagonal unitária. Como $\mathbf{D}_S^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Em particular,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}.$$

A relação inversa é

$$\mathbf{S} = \mathbf{D}_S^{1/2} \mathbf{R} \mathbf{D}_S^{1/2}. \quad (8.68)$$

Defina agora a matriz das colunas centralizadas e padronizadas,

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2} \in \mathbb{R}^{n \times p}. \quad (8.69)$$

Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}} &= \frac{1}{n-1} \mathbf{D}_S^{-1/2} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_S^{-1/2} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}. \quad (8.70)$$

A expressão Equação 8.70 mostra que $\mathbf{R}$ é, a menos do fator $1/(n-1)$, uma matriz de Gram das colunas padronizadas.

Exemplo 8.13 (Da matriz de dados às matrizes de covariâncias e correlações). Considere quatro observações de duas variáveis organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}.$$

Aqui,

$$n = 4 \quad \text{e} \quad p = 2.$$

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{4} \mathbf{X}^\top \mathbf{1}_4 = \begin{bmatrix} 2,5 \\ 2,5 \end{bmatrix}.$$

Portanto, a matriz centralizada é

$$\begin{aligned} \mathbf{X}_c &= \mathbf{X} - \mathbf{1}_4 \bar{\mathbf{x}}^\top \\ &= \begin{bmatrix} -1,5 & -0,5 \\ -0,5 & -1,5 \\ 0,5 & 1,5 \\ 1,5 & 0,5 \end{bmatrix}. \end{aligned}$$

A matriz total de somas de quadrados e produtos cruzados é

$$\begin{aligned} \mathbf{T} &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são as somas dos quadrados dos desvios de cada variável. O elemento fora da diagonal é a soma dos produtos cruzados.

Como

$$n - 1 = 3,$$

a matriz de covariâncias observada é

$$\begin{aligned}\mathbf{S} &= \frac{1}{3}\mathbf{T} \\ &= \begin{bmatrix} 5/3 & 1 \\ 1 & 5/3 \end{bmatrix}.\end{aligned}$$

Assim,

$$s_{11} = s_{22} = \frac{5}{3}$$

e

$$s_{12} = 1.$$

A matriz diagonal das variâncias observadas é

$$\mathbf{D}_S = \begin{bmatrix} 5/3 & 0 \\ 0 & 5/3 \end{bmatrix}.$$

Como as duas variâncias são iguais,

$$\mathbf{D}_S^{-1/2} = \sqrt{\frac{3}{5}}\mathbf{I}_2.$$

Logo,

$$\begin{aligned}\mathbf{R} &= \mathbf{D}_S^{-1/2}\mathbf{S}\mathbf{D}_S^{-1/2} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.\end{aligned}$$

Também podemos obter diretamente a correlação entre as duas colunas:

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{1}{\sqrt{(5/3)(5/3)}} = \frac{3}{5} = 0,6.$$

O exemplo reúne as etapas da construção descritiva desenvolvida nesta seção. A partir da matriz de dados $\mathbf{X}$, calcula-se o vetor de médias $\bar{\mathbf{x}}$ e obtém-se a matriz centralizada $\mathbf{X}_c$. A matriz SQPC $\mathbf{T}$ registra a dispersão sem normalização, $\mathbf{S}$ introduz a normalização por $n - 1$ e $\mathbf{R}$ remove as escalas marginais por meio da padronização.

Nesse ponto, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ são valores calculados a partir da matriz de dados observada. Sua interpretação como realizações de estatísticas amostrais e suas propriedades inferenciais serão desenvolvidas no Capítulo 10.

Se $\mathbf{x}_{\text{pad},j}$ representa a coluna j de $\mathbf{X}_{\text{pad}}$, então

$$\|\mathbf{x}_{\text{pad},j}\|^2 = n - 1.$$

Consequentemente,

$$r_{jk} = \frac{\mathbf{x}_{\text{pad},j}^\top \mathbf{x}_{\text{pad},k}}{\|\mathbf{x}_{\text{pad},j}\| \|\mathbf{x}_{\text{pad},k}\|}. \quad (8.71)$$

Assim, a correlação observada entre duas variáveis é o cosseno do ângulo entre suas colunas centralizadas e padronizadas no espaço das observações. Essa interpretação utiliza diretamente a geometria de produtos internos desenvolvida no Módulo 1.

A representação descritiva também se estende a dois blocos de variáveis. Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais. Se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y},$$

define-se:

Definição 8.13 (Matriz de covariâncias cruzadas observada). A **matriz de covariâncias cruzadas observada** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y} \in \mathbb{R}^{p \times q}. \quad (8.72)$$

Sua orientação satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.73)$$

Para

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância observada entre as combinações

$$\mathbf{u} = \mathbf{X}\mathbf{a}$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}$$

é

$$s_{uv} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (8.74)$$

A expressão Equação 8.74 é a contraparte descritiva de Equação 8.14.

Se as duas matrizes forem concatenadas,

$$[\mathbf{X} \quad \mathbf{Y}],$$

a matriz de covariâncias observada correspondente possui a estrutura

$$\begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \quad (8.75)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto de variáveis, enquanto os blocos fora da diagonal registram as covariâncias entre os dois conjuntos.

A matriz $\mathbf{T}$ descreve a dispersão conjunta de todas as observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão admite uma decomposição adicional.

8.8 Decomposição da dispersão por grupos

Considere as n observações distribuídas em K grupos não vazios. O grupo k contém n_k observações, com

$$n_1 + \cdots + n_K = n.$$

Represente a observação i do grupo k por

$$\mathbf{x}_{ik} \in \mathbb{R}^p, \quad i = 1, \dots, n_k, \quad k = 1, \dots, K.$$

O vetor de médias do grupo k é

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathbf{x}_{ik}. \quad (8.76)$$

A média total satisfaz

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \mathbf{x}_{ik} = \frac{1}{n} \sum_{k=1}^K n_k \bar{\mathbf{x}}_k. \quad (8.77)$$

A dispersão total das observações em torno da média geral pode ser separada em duas fontes:

- **dispersão intragrupos:** afastamentos das observações em relação à média do grupo ao qual pertencem;
- **dispersão entre grupos:** afastamentos das médias dos grupos em relação à média total.

Essa decomposição distingue, portanto, a variabilidade existente **dentro dos grupos** daquela associada às **diferenças entre seus centros**. Em várias técnicas multivariadas, essa distinção será fundamental para avaliar se os grupos apresentam centros suficientemente separados em relação à variabilidade existente internamente.

Geometricamente, para cada observação, o deslocamento em relação à média total pode ser percorrido em duas etapas: primeiro, da observação até a média de seu grupo e, depois, da média do grupo até a média total. Assim,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (8.78)$$

A Figura 8.5 ilustra essas duas componentes. Os afastamentos das observações em relação aos respectivos centros representam a dispersão intragrupos, enquanto os afastamentos dos centros dos grupos em relação à média total representam a dispersão entre grupos.




Figura 8.5: Decomposição geométrica da dispersão em componentes intragrupos e entre grupos.

8.8.1 Dispersão total, intragrupos e entre grupos

A matriz total é

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top. \quad (8.79)$$

Definição 8.14 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top \in \mathbb{R}^{p \times p}. \quad (8.80)$$

Cada termo mede o afastamento de uma observação em relação ao centro de seu próprio grupo.

Definição 8.15 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \in \mathbb{R}^{p \times p}. \quad (8.81)$$

A ponderação por n_k registra o número de observações representadas por cada média de grupo. Assim, um mesmo afastamento $\bar{\mathbf{x}}_k - \bar{\mathbf{x}}$ contribui mais para a dispersão entre grupos quando corresponde a um grupo com maior número de observações.

Proposição 8.10 (Decomposição da dispersão total). *Para qualquer partição das n observações em K grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.82)$$

Comprovação. Pela decomposição vetorial apresentada na Equação 8.78,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}).$$

Ao formar o produto externo e somar sobre as observações, surgem duas parcelas quadráticas e dois termos cruzados. Para cada grupo,

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem. A soma das primeiras parcelas produz $\mathbf{T}_{\text{intra}}$, enquanto

$$\sum_{i=1}^{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top = n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top.$$

Somando sobre os grupos, obtém-se

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

□

Exemplo 8.14 (Decomposição da dispersão em dois grupos). Considere quatro observações de duas variáveis, distribuídas em dois grupos:

Grupo	X_1	X_2
1	1	1
1	3	1
2	3	5
2	5	5

Assim,

$$n_1 = n_2 = 2, \quad n = 4, \quad K = 2.$$

As médias dos grupos são

$$\bar{\mathbf{x}}_1 = \frac{1}{2} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right] = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{2} \left[\begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

A média total é

$$\begin{aligned} \bar{\mathbf{x}} &= \frac{1}{4} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix}. \end{aligned}$$

Podemos agora calcular separadamente as três matrizes da decomposição.

Dispersão intragrupos.

No primeiro grupo,

$$\mathbf{x}_{11} - \bar{\mathbf{x}}_1 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{21} - \bar{\mathbf{x}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua contribuição para a dispersão intragrupos é

$$\begin{aligned} \mathbf{T}_{\text{intra},1} &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} -1 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

No segundo grupo,

$$\mathbf{x}_{12} - \bar{\mathbf{x}}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{22} - \bar{\mathbf{x}}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

de modo que

$$\mathbf{T}_{\text{intra},2} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{T}_{\text{intra}} &= \mathbf{T}_{\text{intra},1} + \mathbf{T}_{\text{intra},2} \\ &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned} \tag{8.83}$$

Toda a dispersão dentro dos grupos ocorre, neste exemplo, na primeira variável. A segunda variável é constante dentro de cada grupo.

Dispersão entre grupos.

Os afastamentos das médias dos grupos em relação à média total são

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 - \bar{\mathbf{x}} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Como ambos os grupos possuem duas observações,

$$\begin{aligned} \mathbf{T}_{\text{entre}} &= 2 \begin{bmatrix} -1 \\ -2 \end{bmatrix} \begin{bmatrix} -1 & -2 \end{bmatrix} + 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.84}$$

Nesse caso, a diferença entre os centros dos grupos envolve simultaneamente as duas variáveis.

Dispersão total.

Calculando diretamente os desvios das quatro observações em relação a

$$\bar{\mathbf{x}} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

obtem-se

$$\begin{aligned} \mathbf{T} &= \begin{bmatrix} -2 \\ -2 \end{bmatrix} \begin{bmatrix} -2 & -2 \end{bmatrix} + \begin{bmatrix} 0 \\ -2 \end{bmatrix} \begin{bmatrix} 0 & -2 \end{bmatrix} \\ &\quad + \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.85}$$

A identidade Equação 8.82 pode então ser verificada diretamente:

$$\begin{aligned}
\mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}} &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \mathbf{T}.
\end{aligned}$$

A decomposição também pode ser examinada em direções específicas. Para

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

que seleciona a primeira variável,

$$\mathbf{a}_1^\top \mathbf{T} \mathbf{a}_1 = 8,$$

com

$$\mathbf{a}_1^\top \mathbf{T}_{\text{intra}} \mathbf{a}_1 = 4$$

e

$$\mathbf{a}_1^\top \mathbf{T}_{\text{entre}} \mathbf{a}_1 = 4.$$

Assim,

$$8 = 4 + 4.$$

Metade da dispersão de X_1 decorre de diferenças dentro dos grupos e metade das diferenças entre seus centros.

Para

$$\mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

que seleciona a segunda variável,

$$\mathbf{a}_2^\top \mathbf{T} \mathbf{a}_2 = 16,$$

enquanto

$$\mathbf{a}_2^\top \mathbf{T}_{\text{intra}} \mathbf{a}_2 = 0$$

e

$$\mathbf{a}_2^\top \mathbf{T}_{\text{entre}} \mathbf{a}_2 = 16.$$

Portanto,

$$16 = 0 + 16.$$

A variável X_2 não apresenta dispersão dentro dos grupos neste conjunto de dados; toda a sua dispersão total está associada à diferença entre as médias dos dois grupos.

O exemplo mostra que a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

expressa simultaneamente a decomposição da dispersão em todas as direções. Para qualquer combinação linear das variáveis, a dispersão total dessa combinação também se decompõe nas parcelas intragrupos e entre grupos, conforme Equação 8.86.

A identidade Equação 8.82 é algébrica e depende somente da partição das observações e das definições das médias total e de grupo (Renchert; Christensen, 2012). Normalidade, independência e outros pressupostos probabilísticos não são necessários para estabelecê-la.

Para qualquer direção

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.86)$$

Se

$$y_{ik} = \mathbf{a}^\top \mathbf{x}_{ik},$$

então Equação 8.86 corresponde exatamente à decomposição univariada

$$\sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y})^2 = \sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y}_k)^2 + \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2. \quad (8.87)$$

A decomposição matricial reúne simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.2 Somas de quadrados e traço das matrizes de dispersão

As matrizes $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes de somas de quadrados e produtos cruzados e descrevem simultaneamente a dispersão das diferentes variáveis e suas associações.

O traço dessas matrizes reúne apenas os termos quadráticos da diagonal e fornece uma medida escalar de dispersão. Defina

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Essas quantidades constituem as somas de quadrados total, intragrupos e entre grupos, respectivamente. No caso univariado, elas coincidem com as somas de quadrados usuais da análise de variância. No caso multivariado, correspondem à soma das somas de quadrados das p variáveis.

Como o traço soma as contribuições das diferentes variáveis, essas quantidades dependem das escalas em que as variáveis são expressas. Sua interpretação conjunta é mais direta quando as variáveis possuem unidades comparáveis ou quando uma padronização apropriada foi realizada.

Para a matriz de dispersão total,

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^{\top},$$

tem-se

$$\begin{aligned}
\text{tr}(\mathbf{T}) &= \sum_{k=1}^K \sum_{i=1}^{n_k} \text{tr} \left[(\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top \right] \\
&= \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2.
\end{aligned} \tag{8.88}$$

Portanto,

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2. \tag{8.89}$$

Assim, SQ_{total} é a soma dos quadrados das distâncias euclidianas das observações à média total.

Analogamente,

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}_k\|^2 \tag{8.90}$$

mede a soma dos quadrados dos afastamentos das observações em relação aos centros de seus respectivos grupos.

Por sua vez,

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2 \tag{8.91}$$

mede a soma ponderada dos quadrados das distâncias entre os centros dos grupos e a média total.

Como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade do traço fornece

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}. \tag{8.92}$$

Equivalentemente,

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \tag{8.93}$$

Ao tomar o traço da decomposição matricial, recupera-se uma identidade escalar análoga à decomposição de somas de quadrados familiar da análise de variância:

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

A decomposição matricial

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é mais informativa, pois preserva também os produtos cruzados entre as variáveis. O traço resume essa estrutura matricial em uma única soma de quadrados.

Assim, a decomposição matricial da dispersão também produz uma decomposição da quantidade total de dispersão medida pelas distâncias euclidianas quadráticas.

Dividindo essas somas por n , obtêm-se medidas médias da dispersão quadrática. Por exemplo,

$$\frac{SQ_{\text{total}}}{n} = \frac{1}{n} \text{tr}(\mathbf{T}) = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2.$$

Essa quantidade representa o afastamento quadrático médio das observações em relação à média total. De modo correspondente,

$$\frac{SQ_{\text{intra}}}{n}$$

e

$$\frac{SQ_{\text{entre}}}{n}$$

representam, respectivamente, as contribuições médias da dispersão intragrupos e entre grupos.

8.8.3 Esperança das matrizes de dispersão por grupos

Até este ponto, a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

foi tratada como uma identidade algébrica para os dados observados. É possível também examinar essas matrizes como objetos aleatórios e calcular suas esperanças, desde que se especifique uma estrutura probabilística para as observações.

Suponha que, para cada grupo $k = 1, \dots, K$,

$$\mathbf{X}_{ik}, \quad i = 1, \dots, n_k,$$

sejam vetores aleatórios independentes, com

$$E(\mathbf{X}_{ik}) = \mu_k$$

e matriz de covariâncias comum

$$\text{Cov}(\mathbf{X}_{ik}) = \Sigma.$$

Não é necessário assumir normalidade.

Defina a média populacional ponderada dos grupos por

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k. \quad (8.94)$$

Considere ainda a matriz

$$\mathbf{B}_\mu = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^\top, \quad (8.95)$$

que representa a dispersão entre os vetores de médias populacionais dos grupos.

Quando as matrizes de dispersão são consideradas objetos aleatórios, as somas de quadrados correspondentes também são objetos aleatórios. Defina

$$\text{SQ}_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Suas realizações observadas são, respectivamente,

$$SQ_{\text{total}}, \quad SQ_{\text{intra}} \quad \text{e} \quad SQ_{\text{entre}}.$$

Para a matriz de dispersão intragrupos,

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^{\top},$$

tem-se

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma. \quad (8.96)$$

Tomando o traço dos dois lados e utilizando a linearidade do traço e da esperança,

$$E(SQ_{\text{intra}}) = (n - K) \text{tr}(\Sigma).$$

Consequentemente,

$$E\left(\frac{SQ_{\text{intra}}}{n - K}\right) = \text{tr}(\Sigma).$$

Dentro de cada grupo, os vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, a centralização pela média do grupo reduz em uma unidade a dimensão disponível, fazendo com que o grupo k contribua com $n_k - 1$ graus de liberdade. Portanto,

$$\sum_{k=1}^K (n_k - 1) = n - K.$$

A quantidade $n - K$ corresponde, assim, aos graus de liberdade intragrupos familiares da análise de variância. A divisão por $n - K$ antecipa a construção dos quadrados médios utilizada em ANOVA e planejamento de experimentos.

Para a dispersão entre grupos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}) (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top,$$

a esperança é

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_\mu. \quad (8.97)$$

Essa expressão contém duas parcelas com interpretações distintas. O termo

$$(K - 1)\Sigma$$

representa a variabilidade decorrente do fato de que as médias amostrais dos grupos variam de amostra para amostra, enquanto

$$\mathbf{B}_\mu$$

representa a separação efetiva entre os vetores de médias populacionais.

Em particular, se

$$\mu_1 = \cdots = \mu_K,$$

então

$$\mathbf{B}_\mu = \mathbf{0},$$

mas, ainda assim,

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma.$$

Tomando o traço na Equação 8.97,

$$E(\text{SQ}_{\text{entre}}) = (K - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Consequentemente,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{K-1}\right) = \text{tr}(\Sigma) + \frac{\text{tr}(\mathbf{B}_{\mu})}{K-1}.$$

Quando os grupos possuem o mesmo vetor de médias populacional,

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$\mathbf{B}_{\mu} = \mathbf{0}.$$

Nesse caso,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{K-1}\right) = E\left(\frac{\text{SQ}_{\text{intra}}}{n-K}\right) = \text{tr}(\Sigma).$$

Portanto, quando não existe separação entre os vetores de médias populacionais, as somas de quadrados intragrupos e entre grupos, após a divisão pelas respectivas quantidades $n - K$ e $K - 1$, possuem a mesma esperança.

Isso ocorre porque as médias amostrais dos grupos não coincidem exatamente, mesmo quando seus vetores de médias populacionais são iguais.

Por fim, como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade da esperança fornece

$$\begin{aligned} E(\mathbf{T}) &= E(\mathbf{T}_{\text{intra}}) + E(\mathbf{T}_{\text{entre}}) \\ &= (n-1)\Sigma + \mathbf{B}_{\mu}. \end{aligned} \tag{8.98}$$

Tomando o traço,

$$E(\text{SQ}_{\text{total}}) = (n-1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_{\mu}). \tag{8.99}$$

Além disso,

$$\text{SQ}_{\text{total}} = \text{SQ}_{\text{intra}} + \text{SQ}_{\text{entre}},$$

que é a versão aleatória da decomposição observada

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

Quando todos os grupos possuem o mesmo vetor de médias populacional,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Esses resultados dependem apenas de momentos de primeira e segunda ordem e da independência entre as observações; a normalidade não é necessária. Distribuições amostrais e resultados inferenciais associados a essas matrizes serão tratados posteriormente.

No caso univariado, as matrizes reduzem-se a escalares e a decomposição assume a forma familiar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

As divisões

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n-K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K-1}$$

correspondem aos quadrados médios familiares da análise de variância e do planejamento de experimentos.

No contexto multivariado, contudo, as matrizes completas de somas de quadrados e produtos cruzados preservam informações adicionais sobre as associações entre as variáveis. Por essa razão, métodos multivariados posteriores utilizarão $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, e não apenas seus traços.

8.8.4 Propriedades e limites de posto

Independentemente das hipóteses probabilísticas utilizadas na subseção anterior, as propriedades estruturais a seguir decorrem diretamente das definições das matrizes de dispersão.

Proposição 8.11 (Estrutura das matrizes de dispersão por grupos). *As matrizes*

$$\mathbf{T}, \quad \mathbf{T}_{\text{intra}} \quad e \quad \mathbf{T}_{\text{entre}}$$

são simétricas e positivas semidefinidas. Além disso,

$$\mathbf{0} \preceq \mathbf{T}_{\text{intra}} \preceq \mathbf{T}$$

e

$$\mathbf{0} \preceq \mathbf{T}_{\text{entre}} \preceq \mathbf{T}.$$

Seus postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K), \quad (8.100)$$

e

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1). \quad (8.101)$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{k=1}^K \sum_{i=1}^{n_k} [\mathbf{a}^\top (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{k=1}^K n_k [\mathbf{a}^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})]^2 \geq 0.$$

Logo, as duas parcelas são positivas semidefnidas. Pela identidade Equação 8.82,

$$\mathbf{T} - \mathbf{T}_{\text{intra}} = \mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T} - \mathbf{T}_{\text{entre}} = \mathbf{T}_{\text{intra}} \succeq \mathbf{0},$$

o que estabelece as relações na ordem de Loewner.

O limite para $\mathbf{T}$ foi obtido na Equação 8.60.

Dentro do grupo k , os n_k vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, os vetores centralizados desse grupo geram um subespaço de dimensão no máximo $n_k - 1$. Considerando todos os grupos,

$$\sum_{k=1}^K (n_k - 1) = n - K,$$

e, portanto,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K).$$

Para a parcela entre grupos,

$$\sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) = \mathbf{0}.$$

Os K vetores

$$\sqrt{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})$$

geram, portanto, um subespaço de dimensão no máximo $K - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

□

Os limites podem ser estritos quando existem relações lineares adicionais entre as variáveis ou entre os vetores de médias dos grupos.

As relações na ordem de Loewner implicam, para qualquer direção $\mathbf{a}$,

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}$$

e

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}.$$

Assim, a dispersão intragrupos ou entre grupos em uma direção não pode exceder a dispersão total na mesma direção.

Dois casos extremos auxiliam a interpretação. Se

$$\bar{\mathbf{x}}_1 = \cdots = \bar{\mathbf{x}}_K = \bar{\mathbf{x}},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0}.$$

Se, por outro lado, todas as observações de cada grupo coincidem com a respectiva média,

$$\mathbf{x}_{ik} = \bar{\mathbf{x}}_k,$$

então

$$\mathbf{T}_{\text{intra}} = \mathbf{0}.$$

Neste capítulo, a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é inicialmente desenvolvida como uma decomposição algébrica da dispersão observada e, sob hipóteses explícitas de independência e covariância comum, recebe também uma interpretação por meio das esperanças das matrizes de dispersão. Distribuições amostrais, testes de hipóteses e sua formulação no modelo linear multivariado serão desenvolvidos posteriormente.

No Capítulo 11, uma estrutura correspondente será obtida a partir do modelo linear multivariado e de matrizes de projeção. Graus de liberdade, estimadores de covariâncias residuais e hipóteses lineares pertencem àquele contexto.

8.9 Síntese do capítulo

A matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X})$$

representa a estrutura de segunda ordem de um vetor aleatório. Sua diagonal contém as variâncias das componentes, e seus elementos fora da diagonal registram covariâncias. Para qualquer combinação linear,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a},$$

de modo que a matriz de covariâncias determina a dispersão em todas as direções.

A padronização marginal conduz à matriz de correlações

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2},$$

que preserva a estrutura de associação linear após a retirada das escalas marginais.

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto o traço e o determinante produzem resumos escalares distintos. A variância total é

$$\text{tr}(\Sigma) = \sum_{j=1}^p \sigma_{jj} = \sum_{j=1}^p \lambda_j,$$

e também pode ser interpretada como o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu centro:

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma).$$

Mais geralmente, para uma matriz simétrica $\mathbf{A}$ e um vetor fixo $\mathbf{a}$,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}).$$

A variância generalizada é

$$\det(\Sigma),$$

e, quando $\Sigma \succ \mathbf{0}$, a distância de Mahalanobis

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

mede afastamentos levando em conta simultaneamente escalas e covariâncias. Sua esperança populacional satisfaz

$$E[d_M^2(\mathbf{X}, \mu)] = p.$$

A transformação de **branqueamento** (*whitening*), também denominada **esferização**, transforma a estrutura de covariâncias em identidade. No branqueamento simétrico,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_p.$$

Nesse espaço transformado, a distância de Mahalanobis coincide com a distância euclidiana. A padronização marginal e o branqueamento diferem porque a primeira produz matriz de covariâncias igual a $\mathcal{R}$, enquanto o branqueamento produz $\mathbf{I}_p$.

No nível descritivo, as mesmas estruturas são representadas por

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c, \quad \mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A sigla **SQPC** significa **somas de quadrados e produtos cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*.

Quando as observações estão organizadas em grupos,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa a dispersão observada dentro dos grupos da dispersão associada às diferenças entre seus centros. As matrizes completas preservam tanto as somas de quadrados de cada variável quanto os produtos cruzados entre variáveis.

Tomando o traço, obtém-se a decomposição escalar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}},$$

em que

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}), \quad SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

No caso univariado, essa identidade coincide com a decomposição de somas de quadrados familiar da análise de variância. Os correspondentes quadrados médios são

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n - K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K - 1}.$$

No contexto multivariado, entretanto, as matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ contêm informação adicional sobre os produtos cruzados e, por isso, são mais informativas do que seus traços.

Sob independência entre as observações e matriz de covariâncias comum Σ nos grupos, as matrizes de dispersão também admitem interpretações probabilísticas. Se

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k$$

e

$$\mathbf{B}_{\mu} = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^{\top},$$

então

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma,$$

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_{\mu},$$

e

$$E(\mathbf{T}) = (n - 1)\Sigma + \mathbf{B}_\mu.$$

Tomando os traços,

$$E(\text{SQ}_{\text{intra}}) = (n - K) \text{tr}(\Sigma)$$

e

$$E(\text{SQ}_{\text{entre}}) = (K - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Definindo os quadrados médios como objetos aleatórios por

$$\text{QM}_{\text{intra}} = \frac{\text{SQ}_{\text{intra}}}{n - K}$$

e

$$\text{QM}_{\text{entre}} = \frac{\text{SQ}_{\text{entre}}}{K - 1},$$

quando

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$E(\text{QM}_{\text{intra}}) = E(\text{QM}_{\text{entre}}) = \text{tr}(\Sigma).$$

Essa igualdade antecipa a lógica dos quadrados médios da análise de variância, enquanto a formulação multivariada posterior utilizará as matrizes completas de somas de quadrados e produtos cruzados.

A Tabela 8.1 reúne os principais objetos do capítulo.

Tabela 8.1: Principais objetos desenvolvidos no capítulo.

Nível	Objeto	Símbolo	Função
Populacional	vetor de médias	μ	localização

Nível	Objeto	Símbolo	Função
Populacional	matriz de covariâncias	Σ	dispersão conjunta
Populacional	matriz de correlações	$\mathcal{R}$	associação linear padronizada
Populacional	covariância cruzada	Σ_{XY}	associação linear entre blocos
Geométrico	variância total	$\text{tr}(\Sigma)$	dispersão quadrática média
Geométrico	variância generalizada	$\det(\Sigma)$	dispersão multidimensional global
Geométrico	distância de Mahalanobis	d_M	afastamento ajustado à dispersão
Geométrico	branqueamento	$\Sigma^{-1/2}$	transformação para covariância identidade
Dados observados	média	$\bar{\mathbf{x}}$	centro das observações
Dados observados	SQPC	$\mathbf{T}$	dispersão não normalizada
Dados observados	covariância	$\mathbf{S}$	dispersão calculada dos dados
Dados observados	correlação	$\mathbf{R}$	associação linear padronizada nos dados
Dados agrupados	dispersão intragrupos	$\mathbf{T}_{\text{intra}}$	dispersão dentro dos grupos
Dados agrupados	dispersão entre grupos	$\mathbf{T}_{\text{entre}}$	dispersão entre os centros dos grupos
Dados agrupados	decomposição matricial	$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$	separação da dispersão por grupos
Dados agrupados	somas de quadrados	$SQ_{\text{total}}, SQ_{\text{intra}}, SQ_{\text{entre}}$	resumos escalares obtidos pelos traços das matrizes de dispersão
Dados agrupados	quadrados médios	$QM_{\text{intra}}, QM_{\text{entre}}$	somas de quadrados ajustadas pelos respectivos graus de liberdade

Ao final deste capítulo, o estudante deverá ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- calcular e interpretar variâncias e covariâncias de combinações lineares;
- reconhecer as condições estruturais, a singularidade e o posto de matrizes de covariâncias e correlações;
- interpretar a decomposição espectral, a variância total, a variância generalizada e a geometria dos elipsoides de dispersão;
- relacionar formas quadráticas e esperanças matemáticas à estrutura de covariâncias;
- interpretar a distância de Mahalanobis e sua relação com o branqueamento e a esferização;
- distinguir padronização marginal e branqueamento;
- distinguir parâmetros populacionais, estatísticas amostrais e valores calculados de dados observados;
- decompor a dispersão observada em parcelas total, intragrupos e entre grupos;
- relacionar os traços das matrizes de dispersão às somas de quadrados total, intragrupos e entre grupos;
- reconhecer a relação entre somas de quadrados, graus de liberdade e quadrados médios, estabelecendo a conexão com a análise de variância;
- interpretar, sob hipóteses probabilísticas apropriadas, as esperanças das matrizes de dispersão e das correspondentes somas de quadrados e quadrados médios.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas, em geral, não determina sua distribuição conjunta. O próximo capítulo introduz a **Distribuição Normal Multivariada**, na qual o vetor de médias e a matriz de covariâncias determinam completamente a distribuição. Serão desenvolvidas suas distribuições marginais e condicionais e, no caso não singular, sua função densidade. Nesse contexto, a distância quadrática de Mahalanobis deixará de ser apenas uma construção geométrica baseada em momentos de segunda ordem e passará a possuir uma distribuição probabilística específica.

9 Distribuição Normal Multivariada

O Capítulo 8 desenvolveu o vetor de médias na Equação 8.1, a matriz de covariâncias na Definição 8.2 e a geometria da dispersão na Equação 8.32. Em uma distribuição geral, essas estruturas de primeira e segunda ordem não determinam completamente a distribuição conjunta. Diferentes distribuições podem possuir o mesmo vetor de médias e a mesma matriz de covariâncias.

Na família normal multivariada, o vetor de médias e a matriz de covariâncias determinam a distribuição. Além disso, transformações afins e distribuições marginais permanecem normais, e a estrutura de covariâncias assume consequências probabilísticas específicas, como a equivalência entre não correlação e independência para componentes conjuntamente normais.

O objetivo deste capítulo é construir a distribuição normal multivariada e relacionar suas propriedades probabilísticas à estrutura desenvolvida no capítulo anterior. Serão estudadas a função densidade, as distribuições marginais e condicionais, a independência entre blocos, a padronização, o branqueamento e a distribuição da distância quadrática de Mahalanobis. A sequência principal considera $\Sigma \succ \mathbf{0}$; o caso em que a matriz de covariâncias é singular será reunido em Seção 9.8.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\mu \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathbf{X} \sim N_p(\mu, \Sigma)$ indica uma distribuição normal multivariada de dimensão p , parametrizada pelo vetor de médias e pela matriz de covariâncias;
- $\mathbf{Z}$ representa um vetor normal multivariado padrão, cuja dimensão será indicada pelo contexto; por exemplo, $\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r)$ em dimensão r ;
- $\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias marginais;
- $\sigma_j = \sqrt{\sigma_{jj}}$ representa o desvio-padrão marginal da componente X_j ;
- $\mathcal{R}$ representa a matriz de correlações populacional;
- $\mathbf{X}_1$ e $\mathbf{X}_2$ representam blocos de um vetor normal particionado, com matrizes de covariâncias Σ_{11} e Σ_{22} e covariâncias cruzadas Σ_{12} e Σ_{21} ;
- $\Sigma_{11.2}$ representa o complemento de Schur de Σ_{22} em Σ ;
- $d_M^2(\mathbf{x}, \mu)$ representa a distância quadrática de Mahalanobis de um ponto fixo $\mathbf{x}$ ao centro populacional;

- D_M^2 representa a distância quadrática de Mahalanobis considerada como variável aleatória;
- χ_p^2 representa a distribuição qui-quadrado com p graus de liberdade, e $\chi_{p;1-\alpha}^2$ representa seu quantil de ordem $1 - \alpha$.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

Uma maneira de caracterizar a normalidade multivariada é examinar todas as projeções lineares do vetor. Na definição a seguir, admite-se também uma normal univariada com variância zero (Eaton, 2007). A relação desse caso com matrizes de covariâncias singulares será desenvolvida em Seção 9.8.

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se também variância igual a zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pela Proposição 8.1 do Capítulo 8, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu$$

quase certamente.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Assim, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente considerada separadamente não garante normalidade

multivariada. A definição exige que **todas as combinações lineares** das componentes possuam distribuição normal.

Portanto,

$$X_j \text{ normal para todo } j$$

não implica, isoladamente,

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ representa a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece que toda projeção unidimensional de um vetor normal multivariado possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A definição anterior também permite construir vetores normais multivariados a partir de variáveis normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ \vdots \\ Z_r \end{bmatrix},$$

com

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e componentes mutuamente independentes.

Para qualquer $\mathbf{c} \in \mathbb{R}^r$,

$$\mathbf{c}^\top \mathbf{Z} = \sum_{j=1}^r c_j Z_j$$

é uma variável normal. Além disso,

$$E(\mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_r.$$

Logo,

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A transformação afim definida na Definição 4.7 permite transportar essa distribuição para outros vetores de médias e outras estruturas de covariância.

Proposição 9.1 (Construção afim de um vetor normal). *O vetor*

$$\mathbf{X} = \mu + \mathbf{AZ} \tag{9.3}$$

satisfaz

$$\mathbf{X} \sim N_p(\mu, \mathbf{AA}^\top), \tag{9.4}$$

em que

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

$\mathbf{A} \in \mathbb{R}^{p \times r}$ e $\mu \in \mathbb{R}^p$.

Comprovação. Pelo resultado de transformação da covariância na Proposição 8.6,

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top = \mathbf{AA}^\top. \tag{9.5}$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{AZ} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

A última parcela é uma combinação linear das componentes de $\mathbf{Z}$ e, portanto, possui distribuição normal. Assim, $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$, o que caracteriza $\mathbf{X}$ como normal multivariado. $\square$

A matriz $\mathbf{A}$ determina como as componentes independentes de $\mathbf{Z}$ são combinadas. A transformação pode introduzir covariâncias entre as componentes de $\mathbf{X}$, mesmo que as componentes do vetor inicial sejam independentes.

Pela Proposição 8.2, uma matriz de covariâncias é simétrica e positiva semidefinida. Reciprocamente, toda matriz real simétrica e positiva semidefinida admite uma fatoração

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

De fato, pelo Teorema 5.4,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com autovalores não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\Lambda^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \Sigma.$$

Consequentemente, qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica positiva semidefinida Σ podem parametrizar uma distribuição normal multivariada.

Se Σ é positiva semidefinida, mas não positiva definida, obtém-se o caso singular, que será definido e desenvolvido em Seção 9.8. Na sequência principal, considere

$$\Sigma \succ \mathbf{0}.$$

A raiz quadrada principal definida em Definição 5.9 é invertível e pode ser utilizada como matriz da construção afim, pois

$$\Sigma^{1/2}\Sigma^{1/2} = \Sigma.$$

Assim, se

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

o vetor

$$\mathbf{Y} = \mu + \Sigma^{1/2} \mathbf{Z}$$

possui distribuição

$$\mathbf{Y} \sim N_p(\mu, \Sigma).$$

9.1.3 Determinação pelos parâmetros

O vetor de médias μ e a matriz de covariâncias Σ descrevem características de primeira e segunda ordem, mas, por si sós, não determinam uma distribuição conjunta. Na família normal multivariada, esses parâmetros determinam a distribuição, pois todas as projeções lineares são normais e seus parâmetros são determinados por μ e Σ .

Nesta seção será utilizada a notação de **igualdade em distribuição**. Para vetores aleatórios $\mathbf{X}$ e $\mathbf{Y}$ em $\mathbb{R}^p$, escrever

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

significa que os dois vetores possuem a mesma distribuição conjunta. Equivalentemente, para todo

$$\mathbf{x} = (x_1, \dots, x_p)^\top \in \mathbb{R}^p,$$

tem-se

$$P(X_1 \leq x_1, \dots, X_p \leq x_p) = P(Y_1 \leq x_1, \dots, Y_p \leq x_p).$$

A igualdade em distribuição não significa que

$$\mathbf{X} = \mathbf{Y}$$

quase certamente. Os vetores podem, inclusive, estar definidos em espaços de probabilidade distintos.

O resultado geral que permite passar das distribuições das projeções à distribuição conjunta é o Teorema de Cramér–Wold (Eaton, 2007).

Teorema 9.1 (Teorema de Cramér–Wold). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^p$$

vetores aleatórios. Então,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo

$$\mathbf{a} \in \mathbb{R}^p.$$

(Eaton, 2007)

A implicação direta decorre da aplicação da mesma transformação linear a vetores com a mesma distribuição. A implicação inversa estabelece que a coleção das distribuições de todas as projeções lineares determina a distribuição conjunta.

Leitura de aprofundamento

O Teorema de Cramér–Wold é um resultado geral e não depende da hipótese de normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

Aqui, sua função é justificar que duas distribuições normais multivariadas com o mesmo vetor de médias e a mesma matriz de covariâncias são a mesma distribuição.

Proposição 9.2 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\mathbf{Y} \sim N_p(\mu, \Sigma),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Comprovação. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a}$. Pelo Teorema 9.1,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

□

Essa propriedade explica por que a notação

$$N_p(\mu, \Sigma)$$

é suficiente para identificar uma distribuição normal multivariada.

Como consequência, quando

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a construção anterior permite escrever

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.2 Densidade da normal multivariada

A partir deste ponto, considere

$$\Sigma \succ \mathbf{0}.$$

Então,

$$\Sigma^{-1}$$

existe e

$$\det(\Sigma) > 0,$$

permitindo representar a distribuição normal multivariada por uma densidade em relação à medida de Lebesgue em $\mathbb{R}^p$.

9.2.1 Função densidade e log-densidade

Proposição 9.3 (Densidade da normal multivariada). *A densidade de*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

é

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.8)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Comprovação. Pela representação Equação 9.7,

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z},$$

com

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Como as componentes de $\mathbf{Z}$ são normais padrão independentes, sua densidade conjunta é

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{(2\pi)^{p/2}} \exp\left(-\frac{1}{2}\mathbf{z}^\top \mathbf{z}\right).$$

Considere a transformação afim

$$\mathbf{x} = \mu + \Sigma^{1/2}\mathbf{z}.$$

Como $\Sigma^{1/2}$ é invertível,

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu).$$

A Jacobiana da transformação inversa é a matriz constante $\Sigma^{-1/2}$, de modo que

$$|\det(\Sigma^{-1/2})| = \det(\Sigma)^{-1/2}.$$

Aplicando a transformação de densidades estabelecida na Proposição 7.19,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= f_{\mathbf{Z}}[\Sigma^{-1/2}(\mathbf{x} - \mu)] \det(\Sigma)^{-1/2} \\ &= \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right\}. \end{aligned}$$

□

A derivação mostra a função desempenhada pelos dois termos matriciais da densidade. O determinante surge da alteração de volume provocada pela transformação afim, enquanto a matriz inversa aparece ao expressar o afastamento de $\mathbf{x}$ nas coordenadas da normal padrão obtidas pelo branqueamento.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$. Probabilidades são atribuídas a regiões:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}, \quad (9.9)$$

para conjuntos mensuráveis $\mathcal{A} \subseteq \mathbb{R}^p$.

A forma quadrática no expoente é a distância quadrática de Mahalanobis definida na Definição 8.9:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Assim,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left[-\frac{1}{2} d_M^2(\mathbf{x}, \mu) \right]. \quad (9.10)$$

Para μ e Σ fixos, a posição de $\mathbf{x}$ afeta a densidade somente por meio de sua distância de Mahalanobis ao vetor de médias. Como

$$c \mapsto \exp \left(-\frac{c}{2} \right)$$

é estritamente decrescente para $c \geq 0$, pontos mais afastados do centro segundo essa métrica possuem menor densidade.

A log-densidade é

$$\begin{aligned} \log f_{\mathbf{x}}(\mathbf{x}) &= -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned} \quad (9.11)$$

A expressão reúne uma constante dependente da dimensão, um termo associado à escala volumétrica da dispersão e um termo associado ao afastamento do ponto em relação ao centro. No Capítulo 10, essa mesma estrutura aparecerá na função de verossimilhança de uma amostra normal multivariada.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e Equação 9.8 reduz-se a

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

O vetor μ determina a localização da distribuição. Como

$$d_M^2(\mathbf{x}, \mu) \geq 0$$

e a igualdade ocorre em $\mathbf{x} = \mu$, a densidade atinge seu máximo no centro:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}. \quad (9.12)$$

A matriz Σ determina a escala, a orientação e a forma das superfícies de igual densidade. A geometria desses elipsoides foi desenvolvida no Capítulo 8 na Equação 8.32; a novidade probabilística é que, na distribuição normal, essa mesma geometria organiza os valores da densidade.

9.2.2 Superfícies de igual densidade

Para $c > 0$, considere

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) = c\}. \quad (9.13)$$

Para todo $\mathbf{x} \in \mathcal{S}_c$,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{c}{2}\right).$$

Portanto, $\mathcal{S}_c$ é uma superfície de igual densidade.

Pela representação espectral em Equação 8.33, essas superfícies são elipsoidais. Seus eixos e extensões são determinados pela estrutura espectral de Σ . No modelo normal, dois pontos possuem a mesma densidade se, e somente se, apresentam a mesma distância de Mahalanobis ao vetor de médias.

A Figura 9.1 mostra essa correspondência para uma distribuição normal bivariada.

As curvas de nível são elipses centradas em μ . Todos os pontos sobre uma mesma curva apresentam a mesma distância de Mahalanobis ao centro e, consequentemente, a mesma densidade.

A região interna correspondente é

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.14)$$

Neste ponto, c é apenas uma constante positiva. Mais adiante, a distribuição de D_M^2 permitirá escolher valores de c associados a probabilidades populacionais específicas.




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

9.3 Transformações e distribuições marginais

A construção na Proposição 9.1 partiu de um vetor normal padrão. Uma propriedade mais geral da família normal é o fechamento sob transformações afins. Essa propriedade permite obter distribuições de combinações lineares, projeções, subvectores e transformações de padronização sem recalculas densidades por integração.

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

$\mathbf{A} \in \mathbb{R}^{m \times p}$ e $\mathbf{b} \in \mathbb{R}^m$.

Proposição 9.4 (Fechamento da família normal sob transformações afins). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação afim

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \tag{9.15}$$

satisfaz

$$\mathbf{Y} \sim N_m(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top), \tag{9.16}$$

em que

$$\mathbf{A} \in \mathbb{R}^{m \times p} \quad e \quad \mathbf{b} \in \mathbb{R}^m.$$

Comprovação. Pela Proposição 8.6,

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^m$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}.\end{aligned}$$

Como $\mathbf{X}$ é normal multivariado,

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição de uma constante preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado. $\square$

As fórmulas para média e covariância são válidas para vetores aleatórios gerais com segundos momentos finitos. O resultado específico da família normal é o **fechamento distribucional**: se $\mathbf{X}$ possui distribuição normal multivariada, então $\mathbf{A}\mathbf{X} + \mathbf{b}$ também possui distribuição normal multivariada.

A matriz $\mathbf{A}$ não precisa possuir posto completo. Consequentemente, a matriz de covariâncias transformada

$$\mathbf{A}\Sigma\mathbf{A}^\top$$

pode não ser positiva definida. Esse caso será retomado em Seção 9.8.

Exemplo 9.1 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

Logo,

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \end{aligned}$$

e a matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

O exemplo mostra que uma transformação afim modifica simultaneamente localização e covariância, mas preserva a família normal.

9.3.2 Combinações lineares

Uma combinação linear é o caso $m = 1$ de Proposição 9.4.

Para $\mathbf{a} \in \mathbb{R}^p$ e $b \in \mathbb{R}$,

$$Y = \mathbf{a}^\top \mathbf{X} + b$$

satisfaz

$$Y \sim N(\mathbf{a}^\top \mu + b, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.17)$$

A expressão fornece diretamente a distribuição de somas, diferenças, contrastes, médias ponderadas e projeções lineares.

Exemplo 9.2 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

Quando $\sigma_{12} > 0$, a covariância aumenta a variância da soma e reduz a variância da diferença. Para $\sigma_{12} < 0$, ocorre o efeito inverso.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

quase certamente.

9.3.3 Distribuições marginais

As distribuições marginais de subvetores também podem ser obtidas como transformações lineares.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.18)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Proposição 9.5 (Distribuições marginais da normal multivariada). *Os blocos marginais de um vetor normal multivariado particionado satisfazem*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.19)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.20)$$

Esse resultado considera a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Comprovação. O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

com

$$\mathbf{A}_1 = \begin{bmatrix} \mathbf{I}_{p_1} & \mathbf{0} \end{bmatrix}.$$

Pela Proposição 9.4,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1\mu, \mathbf{A}_1\Sigma\mathbf{A}_1^\top).$$

A estrutura particionada fornece

$$\mathbf{A}_1\mu = \mu_1$$

e

$$\mathbf{A}_1\Sigma\mathbf{A}_1^\top = \Sigma_{11}.$$

O segundo bloco é obtido de forma análoga. □

A distribuição marginal de um bloco depende de seu vetor de médias e de sua própria matriz de covariâncias. A matriz Σ_{12} não aparece nos parâmetros marginais, mas participa da estrutura de dependência conjunta.

Exemplo 9.3 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0,5 \\ -1 & 0,5 & 2 \end{bmatrix} \right).$$

Selecioneando X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas componentes correspondentes de μ , e a matriz de covariâncias marginal é a submatriz principal associada às variáveis selecionadas.

9.3.4 Padronização marginal e branqueamento

O Capítulo 8 definiu na Equação 8.20 a matriz

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Suponha

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

A padronização marginal é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \boldsymbol{\mu}). \quad (9.21)$$

Pela Proposição 9.4 e pela definição de $\mathcal{R}$ na Definição 8.5,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.22)$$

com

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Cada componente padronizada satisfaz

$$Z_{\text{pad},j} \sim N(0, 1),$$

mas as componentes não são necessariamente independentes.

Padronização não implica independência

A padronização marginal produz componentes com média zero e variância unitária, mas preserva as correlações existentes entre elas.

Assim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}).$$

As componentes serão independentes precisamente quando

$$\mathcal{R} = \mathbf{I}_p,$$

resultado que será formalizado na seção seguinte.

Quando

$$\Sigma \succ \mathbf{0},$$

o Capítulo 8 mostrou na Equação 8.51 que o branqueamento simétrico transforma a estrutura de segunda ordem em covariância identidade. Sob normalidade multivariada, é possível determinar também a distribuição completa do vetor transformado.

O branqueamento simétrico é dado por

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.23)$$

Pelo fechamento da família normal,

$$\begin{aligned} \mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p). \end{aligned} \quad (9.24)$$

A diferença entre as duas transformações é, portanto,

$$\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R})$$

e

$$\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A padronização marginal transforma as variâncias em um e preserva as correlações. O branqueamento transforma toda a matriz de covariâncias em identidade.

A consequência adicional da normalidade conjunta é probabilística: como será formalizado na seção seguinte, uma matriz de covariâncias diagonal implica independência das componentes dentro de um vetor conjuntamente normal. Portanto, as componentes do vetor branqueado são independentes.

Como discutido no Capítulo 8, o branqueamento não é único. No caso normal, essa não unicidade preserva também a distribuição normal padrão. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

pois

$$\mathbf{Q}_0 \mathbf{I}_p \mathbf{Q}_0^\top = \mathbf{I}_p.$$

O branqueamento simétrico constitui uma escolha específica entre transformações que produzem covariância identidade.

A próxima seção utiliza uma propriedade específica da normalidade conjunta: para blocos pertencentes ao mesmo vetor normal multivariado, covariância cruzada nula é equivalente à independência.

9.4 Independência e distribuições condicionais

Quando os segundos momentos existem, a independência entre dois blocos implica covariância cruzada nula. A implicação inversa, entretanto, não é válida sem hipóteses adicionais. Na família normal multivariada, a normalidade conjunta estabelece a equivalência entre independência e covariância cruzada nula.

A normalidade conjunta também permite determinar a distribuição condicional de um bloco a partir da estrutura de covariâncias. Nesse desenvolvimento, o complemento de Schur, definido na Definição 2.26 e aplicado à matriz de covariâncias no Capítulo 8, passa a ter uma interpretação probabilística: ele corresponde à matriz de covariâncias condicional.

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.25)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Se os dois blocos são independentes, então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A normalidade conjunta permite estabelecer também a implicação inversa.

Nesta seção, quando o símbolo $\perp$ aparece entre vetores aleatórios, a notação

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

significa que $\mathbf{X}_1$ e $\mathbf{X}_2$ são **independentes**. Esse uso deve ser distinguido da ortogonalidade geométrica, também representada pelo símbolo $\perp$ nos capítulos de Álgebra Linear.

Proposição 9.6 (Independência de blocos conjuntamente normais). *Para dois blocos conjuntamente normais,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}, \quad (9.26)$$

considerando a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2).$$

Comprovação. Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então a independência implica

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

Para a implicação inversa, suponha

$$\Sigma_{12} = \mathbf{0}.$$

Como

$$\Sigma_{21} = \Sigma_{12}^{\top},$$

a matriz de covariâncias conjunta assume a forma

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Existem matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^{\top}$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^{\top}.$$

Considere vetores normais padrão independentes $\mathbf{Z}_1$ e $\mathbf{Z}_2$ e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Por construção,

$$\mathbf{Y}_1 \perp \mathbf{Y}_2.$$

Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Pela Proposição 9.2,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

$$\mathbf{X}_1 \perp \mathbf{X}_2.$$

□

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então

$$X_1, \dots, X_p$$

são mutuamente independentes.

Esse resultado é uma consequência específica da normalidade conjunta. Sem essa hipótese, uma matriz de covariâncias diagonal garante covariância nula entre componentes, mas não implica independência.

A normalidade deve ser conjunta

A equivalência

$$\text{Cov}(X_i, X_j) = 0 \iff X_i \perp X_j$$

exige que X_i e X_j pertençam ao mesmo vetor normal multivariado.

A normalidade de cada variável considerada separadamente não é suficiente para essa conclusão.

9.4.2 Distribuição condicional

Considere novamente

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

e suponha

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0},$$

de modo que Σ_{22}^{-1} existe.

Na notação condicional, a barra vertical $|$ deve ser lida como **dado**. Assim,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$$

representa o vetor $\mathbf{X}_1$ condicionado ao valor $\mathbf{X}_2 = \mathbf{x}_2$, e o subscrito $1 | 2$ será utilizado para identificar quantidades condicionais relativas ao primeiro bloco dado o segundo.

Proposição 9.7 (Distribuição condicional da normal multivariada). *A distribuição condicional de um bloco de um vetor normal multivariado particionado é normal multivariada:*

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1} \left(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2} \right). \quad (9.27)$$

Esse resultado considera a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad \mathbf{x}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{22} \succ \mathbf{0}.$$

A média condicional é

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) \quad (9.28)$$

e a matriz de covariâncias condicional é

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.29)$$

A matriz $\Sigma_{11 \cdot 2}$ é o complemento de Schur de Σ_{22} em Σ , definido em Equação 8.16.

Comprovação. Considere

$$\mathbf{L}^* = \Sigma_{12} \Sigma_{22}^{-1}$$

e defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \mathbf{L}^* (\mathbf{X}_2 - \mu_2). \quad (9.30)$$

Os vetores $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são obtidos conjuntamente por uma transformação afim de $\mathbf{X}$. Pela Proposição 9.4,

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \mathbf{L}^* \Sigma_{22} \\ &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pela Proposição 9.6,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.31)$$

Além disso,

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Pela Proposição 8.5,

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Portanto,

$$\mathbf{E}_{1|2} \sim N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando Equação 9.30,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Condicionando em

$$\mathbf{X}_2 = \mathbf{x}_2,$$

a parcela que depende de $\mathbf{X}_2$ torna-se

$$\mu_{1|2}(\mathbf{x}_2).$$

Como $\mathbf{E}_{1|2}$ é independente de $\mathbf{X}_2$, sua distribuição permanece

$$N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2})$$

após o condicionamento. Portanto,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2}).$$

□

A demonstração fornece a decomposição

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.32)$$

com

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

Consequentemente,

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2). \quad (9.33)$$

No Capítulo 8, na Proposição 8.5, a expressão

$$\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2)$$

surgiu como o melhor ajuste linear de $\mathbf{X}_1$ em função de $\mathbf{X}_2$, utilizando apenas informações de primeira e segunda ordem.

Sob normalidade conjunta, ocorre um resultado mais forte:

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2).$$

Assim, na família normal multivariada, o melhor ajuste linear coincide exatamente com a esperança condicional, e a matriz de covariâncias do resíduo linear coincide com a matriz de covariâncias condicional.

9.4.3 Média e covariância condicionais

A média condicional

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

depende do valor condicionado.

O vetor

$$\mathbf{x}_2 - \mu_2$$

representa o afastamento do bloco conhecido em relação à sua média. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média de $\mathbf{X}_1$.

Quando

$$\mathbf{x}_2 = \mu_2,$$

tem-se

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

A matriz de covariâncias condicional é

$$\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Ela não depende do valor específico de $\mathbf{x}_2$. Assim, diferentes valores do bloco condicionante deslocam o centro da distribuição condicional, mas não alteram sua matriz de covariâncias.

Como $\Sigma \succ \mathbf{0}$, a propriedade de positividade do complemento de Schur fornece

$$\Sigma_{11.2} \succ \mathbf{0}. \quad (9.34)$$

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11.2} = \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.35)$$

Como

$$\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \succeq \mathbf{0},$$

segue que

$$\Sigma_{11.2} \preceq \Sigma_{11}. \quad (9.36)$$

Portanto, para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} \text{Var}[\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{a}^\top \Sigma_{11.2} \mathbf{a} \\ &\leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}. \end{aligned}$$

Condicionar no segundo bloco não aumenta a variância de nenhuma combinação linear do primeiro bloco.

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se simultaneamente

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1$$

e

$$\Sigma_{11.2} = \Sigma_{11}.$$

Nesse caso, a distribuição condicional coincide com a distribuição marginal, como consequência da independência entre os blocos estabelecida na Proposição 9.6.

9.4.4 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.37)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad -1 < \rho < 1.$$

A média condicional de X_1 dado $X_2 = x_2$ é

$$\begin{aligned} E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2} (x_2 - \mu_2) \\ &= \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2). \end{aligned} \quad (9.38)$$

A variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2\sigma_1^2\sigma_2^2}{\sigma_2^2} \\ &= \sigma_1^2 (1 - \rho^2). \end{aligned} \quad (9.39)$$

Portanto,

$$X_1 | X_2 = x_2 \sim N \left[\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right]. \quad (9.40)$$

O sinal de ρ determina a direção do deslocamento da média condicional. Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média de X_1 para valores maiores; se $\rho < 0$, o deslocamento ocorre em sentido oposto.

A variância condicional depende de ρ^2 e não do valor observado x_2 . Quanto maior $|\rho|$, menor é a variabilidade remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

obtém-se

$$E(X_1 | X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 | X_2 = x_2) = \sigma_1^2.$$

A distribuição condicional coincide, então, com a marginal. Isso é consistente com Proposição 9.6, pois, sob normalidade conjunta, $\rho = 0$ implica independência entre X_1 e X_2 .

Exemplo 9.4 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0,8,$$

e a variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = 1) &= 1 - 0,8^2 \\ &= 0,36. \end{aligned}$$

Logo,

$$X_1 \mid X_2 = 1 \sim N(0,8,0,36).$$

O desvio-padrão condicional é

$$\sqrt{0,36} = 0,6.$$

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

No primeiro painel, a linha horizontal identifica o valor condicionado $X_2 = 1$. O ponto sobre essa linha indica a média da distribuição condicional de X_1 .

O segundo painel mostra

$$X_1 \mid X_2 = 1 \sim N(0,8,0,36).$$

Em relação à distribuição marginal $N(0,1)$, a média passa de 0 para 0,8 e a variância passa de 1 para 0,36. O exemplo ilustra duas propriedades gerais: a média condicional depende do valor condicionado, enquanto a matriz de covariâncias condicional não depende desse valor.

O branqueamento desenvolvido anteriormente permite agora obter uma segunda consequência probabilística da normalidade: a distribuição exata da distância quadrática de Mahalanobis.

9.5 Distância de Mahalanobis e regiões de probabilidade

O Capítulo 8 definiu em Definição 8.9 a distância de Mahalanobis como uma medida geométrica adaptada à estrutura de covariâncias. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a distância quadrática ao vetor de médias possui uma distribuição probabilística conhecida.

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A variável aleatória

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \quad (9.41)$$

representa a distância quadrática de Mahalanobis entre uma realização aleatória e o centro populacional.

9.5.1 Distribuição qui-quadrado

Proposição 9.8 (Distribuição da distância quadrática de Mahalanobis). *A distância quadrática de Mahalanobis*

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2, \quad (9.42)$$

para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Comprovação. Pelo branqueamento na Equação 9.23,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

As componentes

$$Z_1, \dots, Z_p$$

são, portanto, normais padrão independentes.

Além disso,

$$\begin{aligned} D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\ &= [\Sigma^{-1/2} (\mathbf{X} - \mu)]^\top [\Sigma^{-1/2} (\mathbf{X} - \mu)] \\ &= \mathbf{Z}^\top \mathbf{Z} \\ &= \sum_{j=1}^p Z_j^2. \end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Logo,

$$D_M^2 \sim \chi_p^2.$$

□

Como $\Sigma \succ \mathbf{0}$, a dimensão da distribuição é p , que determina os graus de liberdade da distribuição qui-quadrado.

Consequentemente,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \tag{9.43}$$

A escala de D_M^2 depende, portanto, da dimensão. Sob o modelo normal, seu valor esperado é p , e não zero.

A igualdade

$$E(D_M^2) = p$$

não depende da normalidade multivariada. No Capítulo 8, Equação 8.53 obteve esse resultado a partir apenas da estrutura de segunda ordem, para qualquer vetor aleatório com vetor de médias μ e matriz de covariâncias positiva definida Σ .

A hipótese de normalidade fornece um resultado mais forte:

$$D_M^2 \sim \chi_p^2.$$

Assim, no presente capítulo, além do valor esperado, passa-se a conhecer a distribuição completa da distância quadrática de Mahalanobis, incluindo sua variância e seus quantis.

No espaço branqueado,

$$D_M^2 = \|\mathbf{Z}\|^2.$$

Assim, a distância quadrática de Mahalanobis no espaço original corresponde ao quadrado da distância euclidiana à origem no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado

$$D_M^2 \sim \chi_p^2$$

utiliza os parâmetros populacionais μ e Σ .

Se esses parâmetros forem substituídos por estimativas obtidas a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 .

A distinção entre parâmetros populacionais e quantidades estimadas a partir da amostra será desenvolvida nos Capítulos 10 e 12.

9.5.2 Regiões elipsoidais de probabilidade

Definição 9.2 (Região elipsoidal de probabilidade). Para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a região elipsoidal de probabilidade $1 - \alpha$ é

$$\mathcal{E}_{1-\alpha} = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p;1-\alpha}^2 \right\}, \quad (9.44)$$

em que $0 < \alpha < 1$ e $\chi_{p;1-\alpha}^2$ é o quantil de ordem $1 - \alpha$ da distribuição χ_p^2 .

Consequentemente,

$$P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) = 1 - \alpha.$$

Pela Proposição 9.8,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P[D_M^2 \leq \chi_{p;1-\alpha}^2] \\ &= P[\chi_p^2 \leq \chi_{p;1-\alpha}^2] \\ &= 1 - \alpha. \end{aligned} \tag{9.45}$$

Portanto, $\mathcal{E}_{1-\alpha}$ é uma região populacional que contém uma realização de $\mathbf{X}$ com probabilidade $1 - \alpha$.

Sua fronteira é

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p;1-\alpha}^2.$$

A geometria é a mesma dos elipsoides de Mahalanobis definidos na Equação 8.32 no Capítulo 8. A novidade do modelo normal é a calibração probabilística da constante. Como naquele capítulo o elipsoide foi definido por

$$d_M^2(\mathbf{x}, \mu) \leq c^2,$$

a região de probabilidade $1 - \alpha$ é obtida fazendo

$$c^2 = \chi_{p;1-\alpha}^2,$$

ou, equivalentemente,

$$c = \sqrt{\chi_{p;1-\alpha}^2}.$$

No espaço branqueado, a região corresponde à esfera

$$\{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p;1-\alpha}^2\},$$

de raio

$$\sqrt{\chi_{p;1-\alpha}^2}.$$

As superfícies de igual densidade e as fronteiras das regiões elipsoidais de probabilidade possuem a mesma forma geométrica porque ambas são determinadas por valores constantes de d_M^2 . A diferença está na escolha da constante: nas regiões de probabilidade, ela é determinada por um quantil da distribuição χ_p^2 .

Região de probabilidade e região de confiança

A região

$$\mathcal{E}_{1-\alpha}$$

refere-se à posição de uma **realização de $\mathbf{X}$** quando os parâmetros populacionais μ e Σ são conhecidos.

Ela não é uma região de confiança para μ .

Regiões de confiança para parâmetros populacionais serão construídas no Capítulo 12 a partir de distribuições amostrais.

9.5.3 Avaliação de uma observação fixa

Considere agora um ponto fixo

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.46)$$

O ponto está dentro de $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p;1-\alpha}^2. \quad (9.47)$$

Se

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p;1-\alpha}^2,$$

a observação está fora da região que contém probabilidade populacional $1 - \alpha$.

Essa comparação descreve a posição de um valor já observado em relação ao modelo. Depois que $\mathbf{x}_0$ foi fixado, não se atribui a ele probabilidade de pertencer à região: ele está dentro ou fora dela.

Também pode ser calculada a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)] . \quad (9.48)$$

A quantidade p_M mede, sob o modelo populacional completamente especificado, a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada.

Um valor pequeno indica que $\mathbf{x}_0$ se encontra em uma região de afastamentos pouco frequentes sob a distribuição especificada. Essa interpretação depende de μ e Σ serem parâmetros populacionais conhecidos e não constitui, neste ponto, um procedimento inferencial para detecção de observações atípicas com parâmetros estimados.

Exemplo 9.5 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix} .$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} .$$

Logo,

$$\begin{aligned} d_M^2(\mathbf{x}_0, \mu) &= \begin{bmatrix} 3 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\ &= \frac{7}{3} \\ &\approx 2,33. \end{aligned}$$

Para a região que contém probabilidade 0,95,

$$\chi_{2;0,95}^2 \approx 5,99.$$

Como

$$2,33 < 5,99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

A probabilidade de cauda associada à distância observada é

$$\begin{aligned} p_M &= P(\chi_2^2 \geq 2,33) \\ &\approx 0,31. \end{aligned}$$

Assim, aproximadamente 31% dos vetores gerados pelo modelo apresentam distância quadrática de Mahalanobis ao centro pelo menos tão grande quanto a observada. O ponto, portanto, não apresenta um afastamento particularmente extremo em relação à distribuição especificada.

O exemplo utiliza parâmetros populacionais conhecidos. Se o vetor de médias e a matriz de covariâncias fossem substituídos por estimativas amostrais, seria necessário utilizar a teoria inferencial apropriada.

Os resultados desta seção mostram a passagem da geometria da distância de Mahalanobis e de seus elipsoides, desenvolvida em Definição 8.9 e Equação 8.32, para uma interpretação probabilística. Sob normalidade multivariada e $\Sigma \succ \mathbf{0}$, a forma quadrática de Mahalanobis possui distribuição χ_p^2 , permitindo calibrar os elipsoides por probabilidades populacionais.

A comparação entre duas distribuições normais permite observar, em seguida, como mudanças no vetor de médias e na matriz de covariâncias modificam suas posições, formas e densidades. Essa comparação será utilizada somente como motivação para técnicas de discriminação desenvolvidas posteriormente.

9.6 Comparação entre distribuições normais

Considere duas populações descritas por distribuições normais multivariadas:

$$\mathbf{X}_1 \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{X}_2 \sim N_p(\mu_2, \Sigma_2),$$

com

$$\Sigma_1 \succ \mathbf{0} \quad \text{e} \quad \Sigma_2 \succ \mathbf{0}.$$

Os vetores de médias determinam a localização das distribuições, enquanto as matrizes de covariâncias determinam sua dispersão, orientação e forma. A comparação entre duas distribuições normais permite observar como esses dois componentes da parametrização atuam conjuntamente.

9.6.1 Médias distintas e covariância comum

Suponha

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As duas distribuições possuem superfícies de igual densidade com a mesma forma, orientação e extensão, mas centradas em pontos diferentes.

Pela log-densidade na Equação 9.11, ambas contêm o termo quadrático

$$-\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x}.$$

Ao comparar as duas log-densidades, esse termo é comum e se cancela. De fato,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \end{aligned} \tag{9.49}$$

A log-razão entre as densidades é, portanto, uma função afim de $\mathbf{x}$.

Consequentemente, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : f_1(\mathbf{x}) = f_2(\mathbf{x})\}$$

é um hiperplano.

A matriz de covariâncias comum influencia a orientação desse hiperplano por meio do vetor

$$\Sigma^{-1}(\mu_1 - \mu_2),$$

que determina sua direção normal. Assim, a separação entre os centros é avaliada segundo a geometria induzida pela matriz de covariâncias comum.

9.6.2 Covariâncias distintas

Considere agora

$$\Sigma_1 \neq \Sigma_2.$$

As distribuições podem diferir não somente quanto à localização, mas também quanto à forma, orientação e extensão de suas superfícies de igual densidade.

Nesse caso, as log-densidades envolvem as formas quadráticas

$$-\frac{1}{2}(\mathbf{x} - \mu_1)^\top \Sigma_1^{-1}(\mathbf{x} - \mu_1)$$

e

$$-\frac{1}{2}(\mathbf{x} - \mu_2)^\top \Sigma_2^{-1}(\mathbf{x} - \mu_2).$$

Como as matrizes inversas são diferentes, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral. Expandindo a diferença entre as log-densidades,

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2} \mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x} \\ &\quad + \mathbf{x}^\top (\Sigma_1^{-1} \mu_1 - \Sigma_2^{-1} \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma_1^{-1} \mu_1 - \mu_2^\top \Sigma_2^{-1} \mu_2) \\ &\quad - \frac{1}{2} \log \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right). \end{aligned} \tag{9.50}$$

A presença do termo

$$\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x}$$

faz com que a log-razão seja, em geral, uma função quadrática de $\mathbf{x}$.

Assim, o conjunto de pontos nos quais

$$f_1(\mathbf{x}) = f_2(\mathbf{x})$$

é determinado, em geral, por uma equação quadrática em $\mathbf{x}$. Sua geometria pode, portanto, diferir substancialmente do hiperplano obtido no caso de covariância comum.

A Figura 9.3 ilustra as duas situações.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

No primeiro painel, as duas distribuições apresentam superfícies de nível com a mesma forma e orientação, deslocadas para centros diferentes. No segundo, as diferenças entre as matrizes de covariâncias modificam também a extensão e a orientação dessas superfícies.

A comparação mostra duas estruturas algébricas que serão utilizadas posteriormente. Com uma matriz de covariâncias comum, a comparação das log-densidades elimina os termos quadráticos comuns e produz uma expressão afim. Com matrizes de covariâncias distintas, permanecem, em geral, termos quadráticos.

Esses resultados serão retomados na formulação da Análise Discriminante. A construção de regras de classificação, probabilidades a priori, custos de decisão e estimação dos parâmetros pertence aos módulos posteriores.

9.7 Alcance da hipótese de normalidade

A distribuição normal multivariada acrescenta uma estrutura probabilística específica aos objetos desenvolvidos nos capítulos anteriores. É importante distinguir quais resultados dependem dessa hipótese e quais permanecem válidos para vetores aleatórios mais gerais.

9.7.1 Resultados que não exigem normalidade

Diversos resultados utilizados neste capítulo dependem somente da existência dos momentos necessários.

Para um vetor aleatório com média μ e matriz de covariâncias Σ ,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}$$

não exigem normalidade.

Da mesma forma, para

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

as relações

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

são propriedades gerais dos primeiros e segundos momentos.

A matriz de covariâncias continua simétrica e positiva semidefinida, conforme Proposição 8.2; a distância de Mahalanobis continua definindo a geometria apresentada na Definição 8.9 quando a matriz de covariâncias é positiva definida; e o complemento de Schur continua representando a covariância do resíduo do melhor ajuste linear entre blocos, conforme Proposição 8.5. Esses resultados foram desenvolvidos no Capítulo 8 sem hipótese de normalidade.

Também não depende da normalidade a esperança de uma forma quadrática centrada. Para uma matriz simétrica $\mathbf{A}$,

$$E \left[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a}) \right] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}),$$

desde que existam os momentos de segunda ordem necessários.

Em particular, quando $\Sigma \succ \mathbf{0}$,

$$E \left[(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \right] = p.$$

Portanto, o valor esperado da distância quadrática de Mahalanobis é uma propriedade de segunda ordem e não uma consequência específica da normalidade.

Esses resultados descrevem estruturas de primeira e segunda ordem. Eles não determinam, por si mesmos, a distribuição conjunta.

9.7.2 Resultados específicos da família normal

A hipótese de normalidade conjunta produz propriedades adicionais.

Entre os resultados desenvolvidos neste capítulo estão:

- o vetor de médias e a matriz de covariâncias determinam completamente a distribuição;
- transformações afins preservam a família normal;
- distribuições marginais de subvectores permanecem normais;
- covariância cruzada nula entre blocos conjuntamente normais equivale à independência;
- distribuições condicionais permanecem normais;
- a esperança condicional entre blocos é uma função afim do bloco condicionante;
- a matriz de covariâncias condicional é o complemento de Schur correspondente;
- quando $\Sigma \succ \mathbf{0}$, o branqueamento produz componentes normais padrão independentes;
- quando $\Sigma \succ \mathbf{0}$, a distância quadrática de Mahalanobis populacional possui distribuição χ_p^2 .

A equivalência

$$\Sigma_{12} = \mathbf{0} \iff \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo da diferença entre uma propriedade geral de covariância e uma propriedade específica da família normal.

A implicação

$$\mathbf{X}_1 \perp \mathbf{X}_2 \implies \Sigma_{12} = \mathbf{0}$$

vale, quando os segundos momentos existem, sem normalidade. A implicação inversa requer a estrutura normal conjunta estabelecida na Proposição 9.6.

De maneira semelhante, a igualdade

$$E(D_M^2) = p$$

decorre apenas da estrutura de segunda ordem, mas a afirmação

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

é específica do modelo normal multivariado sob $\Sigma \succ \mathbf{0}$.

Assim, conhecer apenas μ e Σ permite determinar a esperança dessa forma quadrática, mas não sua distribuição completa. A distribuição qui-quadrado estabelecida na Proposição 9.8 depende da normalidade multivariada.

Assim, a normalidade transforma relações entre médias, covariâncias e formas quadráticas em afirmações sobre distribuições completas.

9.7.3 Passagem do modelo populacional para a inferência

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais que caracterizam a distribuição, sem abordar sua estimação a partir de uma amostra. Essa escolha permitiu estudar diretamente as propriedades da distribuição

$$N_p(\mu, \Sigma).$$

Em uma aplicação estatística, esses parâmetros são geralmente desconhecidos. A observação de uma amostra introduz uma nova distinção entre:

- parâmetros populacionais;
- estatísticas aleatórias;
- estimadores;
- valores calculados a partir dos dados observados.

Essa distinção modifica alguns resultados. Por exemplo,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não autoriza substituir diretamente μ e Σ por estimativas e manter a mesma distribuição.

Da mesma forma, conhecer a forma da densidade normal não é suficiente para realizar inferência sobre parâmetros desconhecidos. É necessário especificar uma amostra aleatória, construir estatísticas e estudar suas propriedades e distribuições amostrais.

O Capítulo 10 inicia essa passagem. O modelo probabilístico permanece o ponto de partida, mas os parâmetros populacionais passam a ser relacionados a estatísticas e estimadores construídos a partir da amostra.

9.8 Aprofundamento: Normal Singular

Leitura de aprofundamento

A sequência principal do capítulo considerou

$$\Sigma \succ \mathbf{0},$$

de modo que a matriz de covariâncias é invertível e a distribuição possui densidade em todo $\mathbb{R}^p$.

Quando Σ é positiva semidefinida, mas não positiva definida, a distribuição normal multivariada é singular. Nesse caso, parte das direções apresenta variância zero e a variabilidade fica restrita a um subespaço de dimensão inferior a p .

Esta seção reúne a definição, a representação em dimensão reduzida, o suporte, a densidade no suporte, o branqueamento e a forma generalizada de Mahalanobis no caso singular.

Definição 9.3 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\mu, \Sigma)$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\Sigma) = r < p.$$

Como toda matriz de covariâncias é positiva semidefinida, esse caso equivale a

$$\Sigma \succeq \mathbf{0} \quad \text{e} \quad \Sigma \not\succ \mathbf{0}.$$

A distribuição é **não singular** quando

$$\text{posto}(\Sigma) = p,$$

equivalentemente,

$$\Sigma \succ \mathbf{0}.$$

A normal singular surge quando existem relações lineares exatas entre as componentes do vetor. Se, por exemplo,

$$X_3 = X_1 + X_2$$

quase certamente, uma das componentes não acrescenta uma nova direção de variabilidade e a matriz de covariâncias não possui posto completo.

O caso singular também pode resultar de uma transformação linear que reduz a dimensão. Se

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \in \mathbb{R}^m$$

e

$$\text{posto}(\mathbf{A}) < m,$$

então

$$\text{posto}(\mathbf{A}\Sigma\mathbf{A}^\top) \leq \text{posto}(\mathbf{A}) < m.$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

é singular.

A distribuição normal singular fornece, portanto, um modelo probabilístico para vetores normais sujeitos a restrições lineares exatas ou representados em um espaço ambiente de dimensão maior que sua dimensão probabilística efetiva.

A singularidade de uma matriz de covariâncias amostral, entretanto, não implica que a matriz de covariâncias populacional seja singular. Como será formalizado em Equação 10.81, quando

$p \geq n$, a matriz de covariâncias amostral possui posto no máximo $n - 1$ e é necessariamente singular, mesmo que a matriz populacional seja positiva definida.

Nos desenvolvimentos a seguir, considere

$$1 \leq r = \text{posto}(\Sigma) < p.$$

O caso extremo $r = 0$ será apresentado ao final da seção.

Como Σ é simétrica e positiva semidefinida, Teorema 5.4 e Proposição 5.6 garantem que sua decomposição espectral reduzida pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top. \quad (9.51)$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

possui colunas ortonormais associadas aos r autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Por Proposição 5.5,

$$\mathcal{C}(\Sigma) = \mathcal{C}(\mathbf{Q}_r).$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top.$$

Logo, uma representação da distribuição singular é

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.52)$$

Por Proposição 8.3, a singularidade de Σ implica, para qualquer vetor aleatório com essa matriz de covariâncias,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente. Na família normal, a representação na Equação 9.52 permite uma conclusão mais forte: o subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

constitui o suporte da distribuição.

Proposição 9.9 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

o suporte da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Consequentemente,

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.53)$$

Comprovação. Pela representação Equação 9.52,

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}.$$

Como $\Lambda_r^{1/2}$ é invertível,

$$\mathcal{C}(\mathbf{A}_r) = \mathcal{C}(\mathbf{Q}_r) = \mathcal{C}(\Sigma).$$

Portanto,

$$\mathbf{A}_r \mathbf{Z} \in \mathcal{C}(\Sigma)$$

quase certamente, o que fornece Equação 9.53.

Além disso, $\mathbf{A}_r$ possui posto coluna r . A aplicação

$$\mathbf{z} \mapsto \mu + \mathbf{A}_r \mathbf{z}$$

é uma transformação afim bijetiva entre $\mathbb{R}^r$ e

$$\mu + \mathcal{C}(\Sigma).$$

Como a normal padrão em $\mathbb{R}^r$ possui densidade positiva em todo $\mathbb{R}^r$, todo conjunto relativamente aberto e não vazio desse subespaço afim possui probabilidade positiva. Assim, esse subespaço é o suporte da distribuição. $\square$

A mesma estrutura pode ser caracterizada pelo núcleo da matriz de covariâncias. Se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

e, consequentemente,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

quase certamente.

As direções do núcleo são, portanto, direções sem variabilidade probabilística.

A normal singular não possui densidade em relação à medida de Lebesgue de dimensão p em $\mathbb{R}^p$, pois toda a probabilidade está concentrada no suporte

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão $r < p$. Nesse suporte, entretanto, a distribuição possui densidade relativamente à medida de volume r -dimensional, como será mostrado a seguir.

Exemplo 9.6 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Equivalentemente,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1 e

$$X_2 = 2X_1$$

quase certamente. Portanto, toda a distribuição está concentrada na reta

$$x_2 = 2x_1.$$

Embora o vetor tenha duas componentes, sua dimensão probabilística efetiva é 1.

Densidade no suporte da normal singular

Por Proposição 9.9, a distribuição está concentrada no subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão

$$r = \text{posto}(\Sigma).$$

Retomando Equação 9.51,

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top, \quad \Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r),$$

a Definição 5.10 fornece

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\det(\Lambda_r) = \prod_{j=1}^r \lambda_j > 0,$$

a densidade relativamente à medida de volume r -dimensional no suporte afim pode ser escrita como

$$f_{\text{sup}}(\mathbf{x}) = \frac{1}{(2\pi)^{r/2} \det(\Lambda_r)^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \right], \quad (9.54)$$

para

$$\mathbf{x} \in \mu + \mathcal{C}(\Sigma).$$

Essa expressão utiliza a mesma estrutura de Equação 9.8, mas somente nas r direções em que existe variabilidade (Anderson, 2003; Rao, 1973).

A conexão com uma normal não singular de dimensão r decorre diretamente de Equação 9.52. Defina

$$\mathbf{Y} = \Lambda_r^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

Por Proposição 9.1,

$$\mathbf{Y} \sim N_r(\mathbf{0}, \Lambda_r).$$

Assim, Equação 9.52 pode ser escrita como

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{Q}_r \mathbf{Y}. \quad (9.55)$$

Portanto, a normal singular em $\mathbb{R}^p$ corresponde à representação de uma normal não singular de dimensão r no subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

Branqueamento no caso singular

Se

$$\text{posto}(\Sigma) = r < p,$$

a matriz $\Sigma^{1/2}$ é singular e não possui inversa ordinária. Utilizando

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

pode-se definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.56)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.57)$$

Essa transformação expressa a distribuição em suas r direções de variância positiva e realiza o branqueamento no espaço efetivo da normal singular. Assim, embora o vetor original pertença a $\mathbb{R}^p$, sua parte aleatória pode ser representada por um vetor normal padrão de dimensão r .

Proposição 9.10 (Forma generalizada de Mahalanobis no caso normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad 1 \leq r = \text{posto}(\Sigma) < p,$$

a forma quadrática generalizada de Mahalanobis

$$D_{M,+}^2 = (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \quad (9.58)$$

satisfaz

$$D_{M,+}^2 \sim \chi_r^2, \quad (9.59)$$

em que Σ^+ é a pseudoinversa de Moore–Penrose de Σ .

Comprovação. Considere a decomposição espectral reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pelo branqueamento reduzido na Equação 9.56,

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu) \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A pseudoinversa de Σ é

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente,

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r \\ &= \sum_{j=1}^r Z_{rj}^2. \end{aligned}$$

As componentes de $\mathbf{Z}_r$ são normais padrão independentes. Portanto,

$$\mathbf{Z}_r^\top \mathbf{Z}_r \sim \chi_r^2.$$

□

Consequentemente,

$$E(D_{M,+}^2) = r$$

e

$$\text{Var}(D_{M,+}^2) = 2r.$$

Assim, no caso singular, a escala da forma generalizada de Mahalanobis é determinada pela dimensão efetiva r da distribuição, e não pela dimensão ambiente p .

Uma região de probabilidade $1 - \alpha$ no suporte efetivo pode ser definida por

$$\mathcal{E}_{1-\alpha}^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r;1-\alpha}^2 \right\}. \quad (9.60)$$

Pela Proposição 9.10,

$$P\left[\mathbf{X} \in \mathcal{E}_{1-\alpha}^{(r)}\right] = 1 - \alpha.$$

A calibração utiliza a dimensão efetiva r , e não a dimensão ambiente p .

Se

$$r = 0,$$

então

$$\Sigma = \mathbf{0}$$

e

$$\mathbf{X} = \mu$$

quase certamente. Nesse caso extremo, a distribuição está concentrada em um único ponto.

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição singular atribui probabilidade 1 ao seu suporte afim.

9.9 Síntese do capítulo

A distribuição normal multivariada estabelece um modelo probabilístico para um vetor aleatório em que a estrutura conjunta é completamente determinada pelo vetor de médias e pela matriz de covariâncias.

A Tabela 9.1 reúne os principais resultados.

Tabela 9.1: Principais estruturas e resultados da distribuição normal multivariada.

Estrutura	Resultado
Definição	$\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a} \in \mathbb{R}^p$
Parametrização	$\mathbf{X} \sim N_p(\mu, \Sigma)$ é determinada por μ e Σ
Construção	$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}$, com $\Sigma = \mathbf{A}\mathbf{A}^\top$

Estrutura	Resultado
Caso singular	se $\text{posto}(\Sigma) = r < p$, o suporte é $\mu + \mathcal{C}(\Sigma)$ e a densidade é definida relativamente ao volume r -dimensional nesse subespaço
Caso não singular	se $\Sigma \succ \mathbf{0}$, o suporte é $\mathbb{R}^p$ e existe densidade em relação à medida de Lebesgue em $\mathbb{R}^p$
Transformação afim	$\mathbf{A}\mathbf{X} + \mathbf{b}$ permanece normal
Marginalização	subvectores de um vetor normal multivariado permanecem normais
Independência	$\Sigma_{12} = \mathbf{0}$ equivale à independência entre blocos conjuntamente normais
Condicionamento	a distribuição condicional é normal, com média afim e covariância dada por complemento de Schur
Branqueamento	se $\Sigma \succ \mathbf{0}$, produz $N_p(\mathbf{0}, \mathbf{I}_p)$; no caso singular, o branqueamento reduzido produz $N_r(\mathbf{0}, \mathbf{I}_r)$
Mahalanobis	$D_M^2 \sim \chi_p^2$ no caso não singular
Regiões de probabilidade	$D_M^2 \leq \chi_{p;1-\alpha}^2$ define uma região populacional de probabilidade $1 - \alpha$
Caso singular de Mahalanobis	$D_{M,+}^2 \sim \chi_r^2$, com $r = \text{posto}(\Sigma)$
Comparação de distribuições	covariância comum produz log-razão afim; covariâncias distintas produzem, em geral, log-razão quadrática

A definição por combinações lineares e a representação afim mostram duas caracterizações complementares da família normal multivariada. A primeira descreve a distribuição por suas projeções unidimensionais; a segunda mostra como sua estrutura conjunta é determinada por μ e Σ .

Quando $\Sigma \succ \mathbf{0}$, a distribuição possui densidade em $\mathbb{R}^p$, o branqueamento produz uma normal padrão multivariada e a distância quadrática de Mahalanobis possui distribuição χ_p^2 . A normalidade fornece, assim, uma interpretação probabilística para a geometria da covariância e da distância de Mahalanobis desenvolvida no Capítulo 8.

Quando Σ é singular, a distribuição permanece normal, mas sua variabilidade fica restrita ao subespaço afim $\mu + \mathcal{C}(\Sigma)$. A dimensão probabilística efetiva passa a ser $r = \text{posto}(\Sigma)$, e a pseudoinversa permite estender ao suporte a densidade, o branqueamento e a forma quadrática de Mahalanobis.

Transformações afins e marginalizações preservam a família normal. Sob normalidade conjunta, covariância cruzada nula equivale à independência entre blocos, e o complemento de Schur fornece a matriz de covariâncias da distribuição condicional.

Ao término deste capítulo, deve-se ser capaz de:

- caracterizar uma distribuição normal multivariada por combinações lineares;
- construir vetores normais por transformações afins de vetores normais padrão;
- distinguir distribuições normais singulares e não singulares;
- identificar o suporte e a dimensão probabilística efetiva de uma normal singular;
- interpretar a densidade normal multivariada e suas superfícies de nível;
- obter distribuições de transformações afins, combinações lineares e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância cruzada nula e independência sob normalidade conjunta;
- determinar média e matriz de covariâncias de uma distribuição condicional;
- interpretar o complemento de Schur como covariância condicional;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis populacional e interpretar regiões elipsoidais de probabilidade;
- comparar distribuições normais com covariância comum e com covariâncias distintas por meio de suas log-densidades;
- distinguir resultados gerais de segunda ordem daqueles que dependem da normalidade.

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais que caracterizam a distribuição, sem abordar sua estimação a partir de uma amostra. O Capítulo 10 introduz a amostra aleatória multivariada e distingue parâmetros, estatísticas, estimadores e estimativas. Essa passagem permitirá estudar como o vetor de médias e a matriz de covariâncias podem ser estimados a partir dos dados e quais propriedades podem ser atribuídas aos respectivos estimadores.

10 Estatísticas Amostrais e Estimação

O Capítulo 8 desenvolveu o vetor de médias populacional na Equação 8.1 e a matriz de covariâncias populacional na Definição 8.2. O Capítulo 9, por sua vez, formulou a distribuição normal multivariada na Definição 9.1. Até esse ponto, μ e Σ foram tratados como parâmetros populacionais. Em uma aplicação estatística, esses parâmetros geralmente são desconhecidos e precisam ser estimados a partir de uma amostra.

O objetivo deste capítulo é passar dos objetos populacionais às estatísticas definidas sobre uma amostra multivariada e estudar sua utilização como estimadores. Serão desenvolvidos o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados (SQPC), os estimadores da matriz de covariâncias, a matriz de correlações amostral e as covariâncias cruzadas entre blocos de variáveis.

Os métodos dos momentos e da máxima verossimilhança serão utilizados como princípios de construção de estimadores. As propriedades matemáticas e os resultados de cálculo matricial estabelecidos no Módulo 1 serão retomados somente quando necessários.

As distribuições amostrais exatas, a distribuição de Wishart, a independência entre o vetor de médias e a matriz de covariâncias amostrais sob normalidade e os procedimentos de inferência serão desenvolvidos no Capítulo 12. Neste capítulo, o objetivo é construir os principais estimadores de localização, dispersão e associação, estudar suas propriedades e examinar limitações associadas ao tamanho amostral e à dimensão.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório populacional;
- $\mathbf{X}_1, \dots, \mathbf{X}_n$ representam os vetores aleatórios que compõem a amostra;
- $\mathbf{x}_1, \dots, \mathbf{x}_n$ representam suas realizações;
- $\mathcal{X} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória da amostra;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa a matriz de dados observada;
- μ , Σ e $\mathcal{R}$ representam, respectivamente, o vetor de médias, a matriz de covariâncias e a matriz de correlações populacionais;
- $\bar{\mathbf{X}}$ representa o vetor de médias amostrais como estatística aleatória, enquanto $\bar{\mathbf{x}}$ representa seu valor observado;
- $\mathbf{T}$ representa a matriz total de somas de quadrados e produtos cruzados (SQPC) como estatística aleatória, e $\mathbf{T}$ sua realização observada;

- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória, e $\mathbf{S}$ seu valor observado;
- $\mathbf{R}$ representa a matriz de correlações amostral como estatística aleatória, e $\mathbf{R}$ seu valor observado;
- T_{jk} , S_{jk} e R_{jk} representam elementos das respectivas matrizes aleatórias, enquanto t_{jk} , s_{jk} e r_{jk} representam seus valores observados;
- $\mathbf{G} = G(\mathcal{X})$ será utilizada como notação genérica para uma estatística, evitando conflito com o símbolo $\mathbf{T}$ reservado à matriz SQPC;
- $\hat{\theta}$ representa um estimador de um parâmetro θ , e $\hat{\theta}_{\text{obs}}$ o valor assumido pelo estimador após a observação da amostra.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordem, o vetor de médias e a matriz de covariâncias definidos na Equação 8.1 e Definição 8.2 satisfazem

$$E(\mathbf{X}) = \mu \in \mathbb{R}^p$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma \in \mathbb{R}^{p \times p}.$$

Os parâmetros são características fixas da distribuição populacional. A aleatoriedade introduzida pelo processo de amostragem está nos vetores que compõem a amostra e, conseqüentemente, nas estatísticas definidas a partir deles.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e identicamente distribuídos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A notação

$$\stackrel{\text{iid}}{\sim}$$

indica que os vetores aleatórios são independentes e identicamente distribuídos segundo a mesma distribuição.

A condição de distribuição idêntica estabelece que todas as unidades são regidas pela mesma distribuição populacional. A independência estabelece que a realização de uma unidade não altera a distribuição das demais unidades.

Quando a distribuição populacional possui densidade em relação a uma medida comum, a independência implica

$$f_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_\theta(\mathbf{x}_i). \quad (10.2)$$

A independência também implica a fatoração da função de distribuição conjunta da amostra:

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.3)$$

Essas fatorações dizem respeito à independência **entre unidades amostrais**. A dependência entre as componentes de um mesmo vetor continua representada pela distribuição multivariada F_θ .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j na unidade i .

A independência entre

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre

$$X_{i1}, \dots, X_{ip}.$$

As componentes de uma mesma unidade podem apresentar covariâncias e outras formas de dependência.

Quando os segundos momentos existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_\ell) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No modelo normal multivariado definido na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A definição do vetor de médias amostrais, da matriz SQPC, da matriz de covariâncias amostral e da matriz de correlações amostral não exige normalidade. Neste capítulo, a hipótese normal será utilizada especificamente na obtenção dos estimadores de máxima verossimilhança de μ e Σ . As distribuições amostrais exatas e os resultados inferenciais associados serão desenvolvidos no Capítulo 12.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra, uma realização de $\mathcal{X}$ é denotada por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.6)$$

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é a matriz aleatória da amostra;
- $\mathbf{X}$ é a matriz de dados observada;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;
- $\mathbf{x}_i$ é sua realização;
- X_{ij} é uma variável aleatória;
- x_{ij} é o valor observado correspondente.

Se o suporte de $\mathbf{X}$ é

$$\mathcal{S}_{\mathbf{X}} \subseteq \mathbb{R}^p,$$

o espaço das possíveis amostras é

$$\mathcal{S}_{\mathbf{X}}^n.$$

No caso em que

$$\mathcal{S}_{\mathbf{X}} = \mathbb{R}^p,$$

esse espaço pode ser identificado com

$$(\mathbb{R}^p)^n$$

ou, equivalentemente, com o conjunto das matrizes reais $n \times p$.

Uma estatística associa a cada possível realização da amostra uma quantidade escalar, vetorial ou matricial. Antes da observação da amostra, ela constitui um objeto aleatório; após a observação, obtém-se seu valor calculado a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

Neste capítulo, as principais quantidades populacionais de interesse são o vetor de médias μ , definido na Equação 8.1, a matriz de covariâncias Σ , definida na Definição 8.2, e a matriz de correlações $\mathcal{R}$, definida na Definição 8.5.

A matriz $\mathcal{R}$ é determinada por Σ e, portanto, não constitui um parâmetro adicional quando a matriz de covariâncias já integra a parametrização do modelo.

No modelo normal multivariado não singular definido na Definição 9.1, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Considere a matriz aleatória da amostra

$$\mathcal{X} \in \mathbb{R}^{n \times p}.$$

Uma estatística é uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{T},$$

cujas regras de cálculo não contêm parâmetros populacionais desconhecidos, em que $\mathcal{T}$ é o espaço em que o resultado assume valores.

A estatística correspondente é

$$\mathbf{G} = G(\mathcal{X}). \quad (10.7)$$

O espaço $\mathcal{T}$ pode ser escalar, vetorial ou matricial, de acordo com a estatística considerada.

Embora a expressão da estatística não contenha parâmetros desconhecidos, sua distribuição amostral pode depender dos parâmetros da distribuição populacional.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i. \quad (10.8)$$

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de uma estatística é denominada **distribuição amostral**. Ela descreve como a estatística varia entre as possíveis realizações da amostra aleatória de tamanho n .

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_\theta$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{G} = G(\mathcal{X})$$

descreve a variabilidade da estatística entre as possíveis realizações da amostra.

A distribuição populacional e a distribuição amostral correspondem, portanto, a objetos probabilísticos distintos. O Capítulo 12 estudará distribuições amostrais específicas das estatísticas introduzidas neste capítulo.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Considere um parâmetro

$$\theta \in \Theta \subseteq \mathcal{A},$$

em que $\mathcal{A}$ é o espaço em que o parâmetro é representado.

Um estimador de θ é uma estatística definida por uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{A},$$

de modo que

$$\hat{\theta} = G(\mathcal{X}). \quad (10.10)$$

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X}). \quad (10.11)$$

Todo estimador é uma estatística, mas nem toda estatística precisa ser utilizada para estimar um parâmetro. A função atribuída à estatística depende do objetivo da análise.

Assim,

$$\bar{\mathbf{X}}$$

é um estimador de μ , enquanto

$$\bar{\mathbf{x}}$$

é a estimativa obtida para uma amostra específica.

Mais adiante, a matriz de covariâncias amostral

$$\mathbf{S}$$

será definida como estimador de Σ , enquanto

$$\mathbf{s}$$

representará sua realização observada.

O erro de estimação é

$$\hat{\theta} - \theta. \quad (10.12)$$

Como o estimador é uma função da amostra aleatória, o erro de estimação também é aleatório. Sua distribuição permite avaliar propriedades do procedimento de estimação.

Um mesmo parâmetro pode possuir diferentes estimadores. Para Σ , por exemplo, serão estudados o estimador não viesado

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e, sob o modelo normal multivariado, o estimador de máxima verossimilhança

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T},$$

ambos construídos a partir da matriz SQPC $\mathbf{T}$ definida na Definição 8.10.

A estimação pontual utiliza uma estimativa única para representar o parâmetro. A estimação por regiões utiliza conjuntos construídos para quantificar a incerteza associada ao processo amostral. Neste capítulo será desenvolvida a estimação pontual. As regiões de confiança serão tratadas no Capítulo 12.

A comparação entre estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência e equivariância serão examinados a seguir. Questões de sensibilidade e robustez serão retomadas posteriormente como aprofundamento.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem estimar o mesmo parâmetro e apresentar comportamentos distintos ao longo das possíveis amostras.

Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = G(\mathcal{X}) \in \mathbb{R}^r.$$

A avaliação de $\hat{\theta}$ depende de sua distribuição amostral e do critério utilizado para comparar procedimentos. Viés, variabilidade, erro quadrático médio e comparações de eficiência podem ser considerados para um tamanho amostral fixo. A consistência e a eficiência assintótica tratam do comportamento de sequências de estimadores quando n aumenta. A suficiência examina a informação preservada pela redução da amostra, enquanto a equivariância descreve a coerência do procedimento sob transformações (Casella; Berger, 2002). Questões de sensibilidade e robustez serão tratadas posteriormente como aprofundamento.

10.2.1 Viés e variabilidade

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés (*Bias* em inglês) de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é

$$E(\hat{\theta}_j) - \theta_j.$$

A ausência de viés descreve o comportamento médio do procedimento sobre as possíveis amostras. Ela não garante que uma estimativa particular esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\hat{\Theta} \in \mathbb{R}^{a \times b},$$

define-se, elemento a elemento,

$$\text{Bias}(\hat{\Theta}) = E(\hat{\Theta}) - \Theta. \quad (10.14)$$

A variabilidade de um estimador vetorial é descrita por

$$\text{Cov}(\hat{\theta}) = E \left[\{ \hat{\theta} - E(\hat{\theta}) \} \{ \hat{\theta} - E(\hat{\theta}) \}^{\top} \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias de seus componentes e os elementos fora da diagonal são as covariâncias entre eles.

Para qualquer $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^{\top} \hat{\theta}) = \mathbf{a}^{\top} \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr} [\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

Essa medida-resumo depende da escala e da parametrização e não substitui a matriz de covariâncias quando a dependência entre os componentes do estimador é relevante.

Para um estimador matricial, uma representação da variabilidade é

$$\text{Cov} [\text{vec}(\hat{\Theta})].$$

O operador vec , definido na Definição 7.9, transforma a matriz estimada em um vetor e permite representar conjuntamente a variabilidade de todos os seus elementos.

Viés e variabilidade descrevem aspectos diferentes do desempenho de um estimador. Um procedimento pode apresentar pequeno viés e grande variabilidade, ou maior viés e menor variabilidade. Para comparar conjuntamente essas duas fontes de erro, é necessário especificar como os desvios entre estimador e parâmetro serão avaliados.

10.2.2 Erro quadrático médio e funções de perda

A comparação entre estimadores requer especificar como diferentes erros são avaliados. Essa escolha é formalizada por uma **função de perda**. Para uma perda L , o **risco** do estimador é seu valor esperado sob o parâmetro θ :

$$R(\theta, \hat{\theta}) = E_{\theta} [L(\hat{\theta}, \theta)].$$

Assim, diferentes funções de perda podem conduzir a diferentes critérios de comparação entre estimadores (Casella; Berger, 2002).

Para um estimador vetorial, considere a perda quadrática euclidiana

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.16)$$

Essa escolha atribui o mesmo peso às coordenadas na parametrização utilizada. Outros problemas podem exigir ponderações ou perdas diferentes.

Definição 10.6 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = E \left[\|\hat{\theta} - \theta\|^2 \right]. \quad (10.17)$$

Proposição 10.1 (Decomposição do erro quadrático médio). *Se $\hat{\theta}$ possui segundos momentos finitos, então*

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.18)$$

Comprovação. Escreva

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + \text{Bias}(\hat{\theta}).$$

O primeiro termo possui média zero. Ao expandir o quadrado da norma e tomar esperança, o termo cruzado desaparece. Além disso,

$$E \left[\|\hat{\theta} - E(\hat{\theta})\|^2 \right] = \text{tr} [\text{Cov}(\hat{\theta})].$$

Substituindo essas relações, obtém-se Equação 10.18. □

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})].$$

A decomposição na Equação 10.18 também pode ser vista como uma aplicação de Equação 8.38, tomando a matriz identidade e considerando $\hat{\theta}$ como vetor aleatório com média $E(\hat{\theta})$.

A ausência de viés não implica EQM mínimo. Um estimador viesado pode apresentar menor risco quadrático se a redução de variabilidade compensar o viés. Essa ideia será retomada na seção de regularização.

Para parâmetros matriciais, uma escolha correspondente é a perda baseada na norma de Frobenius definida na Definição 6.7:

$$L_F(\widehat{\Theta}, \Theta) = \|\widehat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\widehat{\Theta}) = E \left[\|\widehat{\Theta} - \Theta\|_F^2 \right]. \quad (10.19)$$

Equivalentemente,

$$\begin{aligned} \text{EQM}_F(\widehat{\Theta}) &= \text{tr} \left\{ \text{Cov} [\text{vec}(\widehat{\Theta})] \right\} \\ &\quad + \|\text{Bias}(\widehat{\Theta})\|_F^2. \end{aligned} \quad (10.20)$$

A norma de Frobenius corresponde a uma escolha específica de perda. Em problemas de estimação de matrizes de covariâncias, outros critérios podem atribuir pesos diferentes a autovalores, direções ou erros de inversão.

10.2.3 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta (Vaart, 1998).

Definição 10.7 (Consistência). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma sequência de estimadores

$$\widehat{\theta}_n \in \mathbb{R}^r,$$

com r fixo quando $n \rightarrow \infty$.

A sequência $\widehat{\theta}_n$ é consistente para θ quando

$$\widehat{\theta}_n \xrightarrow{P} \theta \quad (10.21)$$

quando

$$n \longrightarrow \infty.$$

A notação

$$\xrightarrow{P}$$

indica **convergência em probabilidade**. Isso significa que, para todo $\varepsilon > 0$,

$$P(\|\hat{\theta}_n - \theta\| > \varepsilon) \rightarrow 0. \quad (10.22)$$

Na formulação clássica deste capítulo, a dimensão do parâmetro é mantida fixa enquanto n aumenta. Quando a dimensão também varia com n , é necessário declarar o regime dimensional e a métrica utilizada para avaliar o erro. Essa distinção será retomada na seção de aprofundamento sobre alta dimensão.

Não viesamento e consistência descrevem propriedades diferentes. O não viesamento compara a esperança do estimador com o parâmetro para um tamanho amostral dado, enquanto a consistência descreve o que acontece com o erro de estimação quando n aumenta. Uma propriedade não deve ser interpretada como sinônimo da outra.

10.2.4 Eficiência

Para estimadores vetoriais não viesados, uma comparação natural considera suas matrizes de covariâncias. Considere dois estimadores

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2,$$

ambos não viesados para θ .

Diz-se que $\hat{\theta}_1$ é uniformemente pelo menos tão eficiente quanto $\hat{\theta}_2$, segundo a ordem de Löwner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.23)$$

Equivalentemente,

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0}.$$

Consequentemente, para todo $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2).$$

No caso vetorial, não existe necessariamente um estimador que seja mais preciso em todos os aspectos. Cada vetor $\mathbf{a} \in \mathbb{R}^r$ define uma combinação linear $\mathbf{a}^\top \hat{\theta}$ e, portanto, uma direção

na qual a variabilidade dos estimadores pode ser comparada. Um estimador pode apresentar menor variabilidade em determinadas direções e maior variabilidade em outras.

A ordem de Löwner declara $\hat{\theta}_1$ pelo menos tão eficiente quanto $\hat{\theta}_2$ somente quando a desigualdade anterior vale para **todas** as direções **a**. Por isso, trata-se de uma ordem parcial: podem existir duas matrizes de covariâncias para as quais nenhum dos estimadores apresenta menor variabilidade em todas as direções.

Quando duas matrizes de covariâncias não são comparáveis pela ordem de Löwner, pode-se adotar um critério escalar que resuma algum aspecto de sua variabilidade. Um exemplo é

$$\text{tr} [\text{Cov}(\hat{\theta})],$$

que soma as variâncias dos componentes do estimador. Essa escolha estabelece um critério particular de comparação; outra função de perda pode produzir uma ordenação diferente.

Para estimadores viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. É necessário considerar um risco que incorpore viés e variabilidade.

A eficiência assintótica compara as matrizes que aparecem nas distribuições-limite de sequências de estimadores. Sob condições de regularidade, estimadores de máxima verossimilhança podem atingir limites associados à informação de Fisher definida na Definição 7.18. Os resultados assintóticos correspondentes não serão desenvolvidos neste capítulo e serão retomados no contexto inferencial do Capítulo 12.

10.2.5 Suficiência

Uma estatística suficiente resume a amostra sem perder informação sobre o parâmetro no modelo considerado. Depois de conhecida essa estatística, a distribuição condicional dos dados restantes não depende do parâmetro (Casella; Berger, 2002).

Definição 10.8 (Estatística suficiente). Considere uma amostra aleatória

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

cuja distribuição pertence a uma família indexada por

$$\theta \in \Theta,$$

e uma estatística definida por

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{G},$$

de modo que

$$\mathbf{G} = G(\mathcal{X}).$$

A estatística $\mathbf{G}$ é **suficiente para** θ quando a distribuição condicional de $\mathcal{X}$ dado $\mathbf{G}$ é a mesma para todos os valores de $\theta \in \Theta$ para os quais essa distribuição condicional está definida.

A função G reduz a amostra à estatística $\mathbf{G}$. A suficiência estabelece que, após conhecida essa estatística, a parte restante da variabilidade da amostra não contém dependência adicional em relação a θ .

A suficiência pode ser entendida como uma redução dos dados sem perda de informação sobre θ no contexto do modelo considerado. Isso não significa que seja possível reconstruir a amostra original a partir de $\mathbf{G}$, mas que a parte da amostra não representada por $\mathbf{G}$ deixa de depender do parâmetro.

A definição de suficiência é formulada em termos de uma distribuição condicional, que nem sempre é a forma mais conveniente para verificar a propriedade diretamente. Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério equivalente baseado na forma da densidade ou da função de probabilidade conjunta.

Teorema 10.1 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família de distribuições indexada por*

$$\theta \in \Theta$$

e dominada por uma medida comum ν , com densidade conjunta

$$f_\theta : \mathcal{X} \longrightarrow [0, \infty)$$

em relação a ν .

Considere também uma estatística definida por

$$G : \mathcal{X} \longrightarrow \mathcal{G}.$$

A estatística $G(\mathcal{X})$ é suficiente para θ se, e somente se, existem funções não negativas

$$q_\theta : \mathcal{G} \longrightarrow [0, \infty), \quad \theta \in \Theta,$$

e

$$r : \mathcal{X} \longrightarrow [0, \infty),$$

com r independente de θ , tais que

$$f_{\theta}(\mathbf{x}) = q_{\theta}[G(\mathbf{x})] r(\mathbf{x}) \quad (10.24)$$

para ν -quase todo $\mathbf{x} \in \mathcal{X}$ e para todo $\theta \in \Theta$.

(Casella; Berger, 2002)

A fatoração separa a densidade conjunta em duas partes. A primeira,

$$q_{\theta}[G(\mathbf{x})],$$

contém toda a dependência em relação a θ e utiliza os dados somente por meio de $G(\mathbf{x})$. A segunda,

$$r(\mathbf{x}),$$

pode depender da amostra completa, mas não depende do parâmetro. Por isso, para estudar θ , a informação contida nos dados entra na verossimilhança por meio da estatística suficiente.

No modelo normal multivariado definido na Definição 9.1, o vetor de médias amostrais e a matriz SQPC formam conjuntamente uma estatística suficiente para μ e Σ (Anderson, 2003).

Proposição 10.2 (Suficiência no modelo normal multivariado). *No modelo normal multivariado, a estatística*

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para o parâmetro

$$(\mu, \Sigma),$$

quando

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Nesse resultado,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias amostrais e

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top \quad (10.25)$$

é a matriz SQPC.

Comprovação. Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}.$$

A identidade de decomposição em torno da média fornece

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top, \end{aligned}$$

em que $\mathbf{T}$ é a matriz SQPC observada definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, toda a dependência da densidade conjunta em relação a μ e Σ ocorre por meio de

$$(\bar{\mathbf{x}}, \mathbf{T}).$$

O resultado segue de Teorema 10.1. □

A suficiência não implica, por si só, ausência de viés, consistência ou eficiência. Ela descreve a quantidade de informação sobre o parâmetro preservada pela estatística, e não a qualidade de um estimador construído a partir dela. Sob o modelo considerado, reduzir a amostra a uma estatística suficiente não elimina informação sobre θ .

10.2.6 Equivariância

Uma transformação dos dados pode induzir uma transformação correspondente no parâmetro. Um procedimento equivariante respeita essa relação.

Definição 10.9 (Equivariância de um estimador). Considere um espaço amostral $\mathcal{X}$, um espaço amostral transformado $\mathcal{Y}$ e espaços paramétricos Θ e Ψ .

Sejam

$$h : \mathcal{X} \longrightarrow \mathcal{Y}$$

uma transformação dos dados e

$$g : \Theta \longrightarrow \Psi$$

a transformação correspondente do parâmetro.

Considere uma regra de estimação

$$G_{\Theta} : \mathcal{X} \longrightarrow \Theta$$

para $\theta \in \Theta$ e a regra correspondente

$$G_{\Psi} : \mathcal{Y} \longrightarrow \Psi$$

para

$$\psi = g(\theta).$$

As regras de estimação são **equivariantes** em relação a h e g quando

$$G_{\Psi} [h(\mathcal{X})] = g[G_{\Theta}(\mathcal{X})]. \quad (10.26)$$

A função h atua sobre os dados, enquanto g atua sobre o parâmetro. Por isso, as duas funções não precisam possuir a mesma forma.

Considere, por exemplo, a transformação afim dos dados

$$h : \mathbf{X}_i \mapsto \mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

Nesse caso, h é a transformação aplicada a cada vetor observado da amostra.

Para o vetor de médias, o parâmetro populacional é

$$\theta = \mu,$$

e a transformação correspondente no espaço paramétrico é

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Portanto,

$$\mu_Y = g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Para a matriz de covariâncias, o parâmetro populacional é

$$\theta = \Sigma,$$

e, por Proposição 8.6, a transformação correspondente é

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Portanto,

$$\Sigma_Y = g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Esse exemplo mostra que uma mesma transformação h aplicada aos dados pode induzir transformações diferentes no espaço paramétrico. Para a média,

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d},$$

enquanto, para a covariância,

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Assim, a forma de g depende do parâmetro considerado, mesmo quando a transformação h dos dados permanece a mesma.

Para estimar μ , a regra de estimação é

$$G_1(\mathcal{X}) = \bar{\mathbf{X}}.$$

Aplicando a mesma regra aos dados transformados,

$$G_1[h(\mathcal{X})] = \bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d} = g_1[G_1(\mathcal{X})].$$

Portanto, o vetor de médias amostrais é equivariante em relação a essa transformação afim.

Para estimar Σ , a regra de estimação é

$$G_2(\mathcal{X}) = \mathbf{S}_X.$$

Para os dados transformados,

$$G_2[h(\mathcal{X})] = \mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top = g_2[G_2(\mathcal{X})].$$

Assim, a matriz de covariâncias amostral também é equivariante em relação à transformação considerada.

A equivariância descreve como um estimador responde a uma transformação dos **dados**: transformar os dados e depois estimar deve produzir o mesmo resultado que estimar primeiro e aplicar a transformação correspondente ao parâmetro.

Essa propriedade deve ser distinguida da invariância da máxima verossimilhança. Nesse segundo caso, parte-se de um estimador de máxima verossimilhança já obtido para θ e utiliza-se uma função desse estimador para estimar uma função do parâmetro.

As propriedades desta seção respondem a perguntas diferentes sobre um procedimento de estimação:

- **viés** compara o valor médio do estimador com o parâmetro;

- **variabilidade** descreve quanto o estimador muda entre amostras;
- **erro quadrático médio** combina viés e variabilidade segundo uma função de perda;
- **consistência** descreve o comportamento do estimador quando o tamanho amostral aumenta;
- **eficiência** compara a variabilidade de procedimentos concorrentes;
- **suficiência** examina quanta informação sobre o parâmetro é preservada por uma estatística;
- **equivariância** examina a coerência do estimador diante de transformações dos dados.

Essas propriedades não estabelecem uma ordenação universal entre estimadores. Um procedimento pode apresentar vantagens segundo um critério e desvantagens segundo outro. A escolha depende do parâmetro de interesse, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise.

Os métodos dos momentos e da máxima verossimilhança fornecem dois princípios gerais para construir os estimadores estudados a seguir.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos relaciona momentos populacionais a seus correspondentes amostrais. A máxima verossimilhança escolhe os valores dos parâmetros que tornam os dados observados mais compatíveis com o modelo especificado (Casella; Berger, 2002).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. Além disso, o princípio utilizado para construir um estimador deve ser distinguido das propriedades estudadas na seção anterior. Em particular, obter um estimador pelo método dos momentos ou pela máxima verossimilhança não garante, por si só, ausência de viés, consistência, eficiência, suficiência, equivariância ou robustez.

Algumas propriedades podem ser demonstradas sob condições adicionais sobre o modelo e o processo amostral. Outras decorrem da própria estrutura de um método. Essas distinções serão indicadas ao apresentar cada procedimento.

10.3.1 Método dos momentos

Definição 10.10 (Estimador pelo método dos momentos). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma função

$$\mathbf{q} : \mathbb{R}^p \longrightarrow \mathbb{R}^r$$

tal que

$$E_{\theta} [\|\mathbf{q}(\mathbf{X})\|] < \infty$$

para os valores de θ considerados.

Defina

$$\mathbf{m} : \Theta \longrightarrow \mathbb{R}^r$$

por

$$\mathbf{m}(\theta) = E_{\theta} [\mathbf{q}(\mathbf{X})]. \quad (10.27)$$

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

defina

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.28)$$

Um **estimador pelo método dos momentos** de θ é qualquer solução

$$\hat{\theta}_{\text{MM}} \in \Theta$$

do sistema

$$\mathbf{m}(\hat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.29)$$

A existência e a unicidade do estimador dependem dos momentos escolhidos e da forma da função $\mathbf{m}$. Assim, o método substitui os momentos populacionais, que dependem do parâmetro desconhecido, pelos correspondentes momentos calculados a partir da amostra e resolve as equações resultantes em relação a θ .

O sistema pode não possuir solução, possuir mais de uma solução ou produzir valores que não pertençam a Θ .

Propriedades dos estimadores de momentos

A propriedade que define o método é a correspondência entre os momentos populacionais e seus análogos amostrais expressa na Equação 10.29. Essa construção, isoladamente, não garante que o estimador obtido seja não viesado, eficiente, suficiente, equivariante ou robusto.

A consistência também não decorre apenas do método. Sob condições como existência dos momentos utilizados, convergência dos momentos amostrais para seus correspondentes populacionais, identificação do parâmetro por esses momentos e continuidade adequada da solução, estimadores de momentos podem ser consistentes.

Portanto, as propriedades apresentadas na seção anterior devem ser verificadas para o estimador e o modelo considerados.

Para o vetor de médias populacional,

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{X}},$$

de modo que

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}. \quad (10.30)$$

Para a matriz de covariâncias, considere o segundo momento não central

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

Pela identidade Equação 8.3,

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top.$$

Substituindo os momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned} \hat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{X}} \bar{\mathbf{X}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^\top. \end{aligned} \quad (10.31)$$

A matriz no numerador é a versão aleatória da matriz total de somas de quadrados e produtos cruzados (SQPC) definida, para dados observados, na Definição 8.10. Será denotada por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.32)$$

Portanto,

$$\hat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}. \quad (10.33)$$

Essa construção utiliza apenas momentos de primeira e segunda ordem e não exige a hipótese de normalidade multivariada. O divisor n surge aqui diretamente do princípio do método dos momentos; posteriormente, ele também será obtido pela máxima verossimilhança sob o modelo normal.

A matriz $\mathbf{T}$ será desenvolvida em detalhes na seção dedicada à SQPC. Para cada realização da amostra, ela produz a matriz $\mathbf{T}$ definida na Definição 8.10.

Restrições do espaço paramétrico

Resolver as equações de momentos não garante que a solução obtida satisfaça todas as restrições impostas ao parâmetro. Em modelos com condições de positividade, ordem, posto ou outras restrições estruturais, é necessário verificar se a solução pertence efetivamente ao espaço paramétrico Θ .

10.3.2 Verossimilhança e máxima verossimilhança

Definição 10.11 (Função de verossimilhança). Considere um espaço paramétrico Θ e uma família de distribuições indexada por

$$\theta \in \Theta,$$

na qual cada observação possui densidade ou função de probabilidade

$$f(\mathbf{x}; \theta)$$

em um espaço amostral $\mathcal{X}$.

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

e uma realização observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X},$$

a função de verossimilhança, para os dados observados fixados, é a função

$$L(\cdot; \mathbf{x}_1, \dots, \mathbf{x}_n) : \Theta \longrightarrow [0, \infty)$$

definida por

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.34)$$

Na verossimilhança, os dados observados são mantidos fixos e θ varia em Θ . Portanto, L não é, em geral, uma distribuição de probabilidade sobre θ .

A log-verossimilhança é

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \log L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n),$$

e, sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.35)$$

Como o logaritmo é estritamente crescente, a verossimilhança e a log-verossimilhança possuem os mesmos pontos de máximo.

Definição 10.12 (Estimador de máxima verossimilhança). Considere a função de verossimilhança definida na Definição 10.11 e suponha que

$$\arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}) \neq \emptyset.$$

Um **estimador de máxima verossimilhança** de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

que seleciona um elemento desse conjunto:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.36)$$

Se o conjunto de máximos contiver mais de um elemento, qualquer elemento selecionado segundo a regra de estimação adotada é um estimador de máxima verossimilhança.

Como o logaritmo é estritamente crescente, a mesma regra pode ser obtida maximizando a log-verossimilhança:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} \ell(\theta; \mathcal{X}).$$

Após a observação da amostra, a estimativa correspondente satisfaz

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A notação $\arg \max$ representa o conjunto dos valores do parâmetro em que o máximo é atingido. Assim, a definição admite a possibilidade de mais de um máximo. A existência e a unicidade do estimador precisam ser verificadas no modelo e no espaço paramétrico considerados.

Propriedades dos estimadores de máxima verossimilhança

A maximização da verossimilhança não garante, em amostras finitas, que o estimador seja não viesado ou apresente erro quadrático médio mínimo. Também não garante, por si só, suficiência, equivariância em relação a transformações dos dados ou robustez.

Sob condições de regularidade e identificabilidade, estimadores de máxima verossimilhança podem ser consistentes, assintoticamente normais e assintoticamente eficientes. Esses resultados dependem das condições do modelo e não são consequências incondicionais do procedimento de maximização.

Uma propriedade estrutural específica da máxima verossimilhança é a **invariância em relação a funções do parâmetro**: quando o estimador de máxima verossimilhança existe, uma função apropriada desse estimador fornece o estimador de máxima verossimilhança da função correspondente do parâmetro. Essa propriedade será formalizada adiante.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

Considere uma amostra do modelo normal multivariado definido na Definição 9.1:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Pela densidade normal multivariada na Equação 9.8 e pela independência das unidades amostrais, para uma amostra observada a verossimilhança é

$$L(\mu, \Sigma) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \quad (10.37)$$

A log-verossimilhança é

$$\begin{aligned} \ell(\mu, \Sigma) = & -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ & - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu). \end{aligned} \quad (10.38)$$

Considere a matriz SQPC observada $\mathbf{T}$, definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.39)$$

Separando o afastamento em relação a μ no desvio em relação à média amostral e no deslocamento da própria média, obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top. \end{aligned} \quad (10.40)$$

A forma quadrática presente na log-verossimilhança pode ser reescrita utilizando o traço. Pela relação entre traço e produto externo em Proposição 2.7 e pela propriedade cíclica em Exemplo 2.12, para um vetor $\mathbf{z}$ e uma matriz compatível $\mathbf{A}$,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} = \text{tr}(\mathbf{A} \mathbf{z} \mathbf{z}^\top).$$

Consequentemente,

$$\begin{aligned}
& \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \\
&= \text{tr} \left[\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] \\
&= \text{tr} (\Sigma^{-1} \mathbf{T}) + n (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu),
\end{aligned}$$

em que a última igualdade utiliza Equação 10.40. Assim, a log-verossimilhança pode ser escrita como

$$\begin{aligned}
\ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\
&\quad - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}) \\
&\quad - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu).
\end{aligned} \tag{10.41}$$

Para Σ fixa, o último termo é não positivo na log-verossimilhança e atinge seu maior valor quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, obtém-se a log-verossimilhança perfilada

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{T}}{n} \right) \right] \right\}, \tag{10.42}$$

em que C não depende de Σ .

Desconsiderando a constante C , maximizar Equação 10.42 equivale a minimizar

$$\frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Essa expressão possui exatamente a forma do critério estudado na Proposição 7.14, com

$$\mathbf{G} = \mathbf{T}.$$

Assim, quando $\mathbf{T} \succ \mathbf{0}$, aquele resultado pode ser aplicado diretamente para obter o minimizador.

Proposição 10.3 (Estimadores de máxima verossimilhança no modelo normal). *No evento amostral em que o máximo da verossimilhança existe, os estimadores no modelo normal multivariado são*

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}} \quad (10.43)$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}. \quad (10.44)$$

O resultado considera

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, o máximo existe e é único quando

$$\text{posto}(\mathbf{T}) = p,$$

e, nesse caso,

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}}$$

e

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

Comprovação. A maximização em relação a μ decorre de Equação 10.41. Como

$$\Sigma^{-1} \succ \mathbf{0},$$

tem-se

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente em

$$\mu = \bar{\mathbf{x}}.$$

Para a maximização em relação a Σ , a log-verossimilhança perfilada na Equação 10.42 mostra que é equivalente minimizar

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Sob a hipótese

$$\text{posto}(\mathbf{T}) = p,$$

tem-se

$$\mathbf{T} \succ \mathbf{0}.$$

Aplicando Proposição 7.14 com $\mathbf{G} = \mathbf{T}$, o minimizador único é

$$\Sigma = \frac{\mathbf{T}}{n}.$$

Logo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

□

Pelo limite de posto da matriz SQPC estabelecido na Equação 8.60,

$$\text{posto}(\mathbf{T}) \leq \min(p, n-1).$$

Consequentemente, uma condição necessária para posto completo é

$$n \geq p+1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois as colunas da matriz centralizada ainda podem ser linearmente dependentes. Sob uma distribuição normal multivariada não singular e

$$n \geq p+1,$$

a condição

$$\text{posto}(\mathbf{T}) = p$$

ocorre quase certamente.

Se $\mathbf{T}$ é singular, a verossimilhança não possui máximo no espaço

$$\{\Sigma : \Sigma \succ \mathbf{0}\}.$$

De fato, pelo Teorema 5.4, escreva

$$\mathbf{T} = \mathbf{Q} \text{diag}(t_1, \dots, t_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$t_j > 0, \quad j = 1, \dots, r, \quad r < p.$$

Para $\varepsilon > 0$, considere

$$\Sigma_\varepsilon = \mathbf{Q} \text{diag}\left(\frac{t_1}{n}, \dots, \frac{t_r}{n}, \varepsilon, \dots, \varepsilon\right) \mathbf{Q}^\top.$$

Então,

$$\text{tr}(\Sigma_\varepsilon^{-1} \mathbf{T}) = nr,$$

enquanto

$$\log \det(\Sigma_\varepsilon) \longrightarrow -\infty$$

quando

$$\varepsilon \longrightarrow 0.$$

Consequentemente, a log-verossimilhança cresce sem limite ao longo dessa sequência, e o máximo não é atingido no espaço das matrizes positivas definidas.

A matriz

$$\frac{\mathbf{T}}{n}$$

continua sendo bem definida e positiva semidefinida e coincide com o estimador obtido pelo método dos momentos. Quando essa matriz é singular, ela não constitui o estimador de máxima verossimilhança no modelo cujo espaço paramétrico exige

$$\Sigma \succ \mathbf{0}.$$

Quando o máximo existe, o estimador de Σ utiliza o divisor n . Mais adiante será mostrado que esse estimador é viesado para Σ e que o divisor $n - 1$ produz o estimador não viesado usual.

O modelo normal mostrou um caso em que método dos momentos e máxima verossimilhança conduzem às mesmas expressões para μ e Σ . Essa coincidência, porém, é específica do modelo considerado. Retornando à comparação geral entre os dois princípios de construção, suas relações com as propriedades estudadas anteriormente podem ser resumidas da seguinte forma:

Tabela 10.1: Relação entre os métodos de estimação e as propriedades estudadas na seção anterior.

Propriedade	Método dos momentos	Máxima verossimilhança
Não viesamento em amostras finitas	Não é garantido pelo método	Não é garantido pelo método
Consistência	Pode ser obtida sob condições de convergência, identificação e continuidade	Pode ser obtida sob condições de regularidade e identificação
Eficiência em amostras finitas	Não é garantida	Não é garantida
Eficiência assintótica	Não é uma propriedade geral do método	Pode ocorrer sob condições de regularidade
Suficiência	Não é garantida pelo método	Não é garantida apenas pela maximização
Equivariância sob transformações dos dados	Depende do estimador e da transformação	Depende do estimador e da transformação
Invariância sob funções do parâmetro	Não é uma propriedade geral do método	É uma propriedade estrutural da máxima verossimilhança, quando o estimador existe
Robustez	Não é garantida	Não é garantida

A Tabela 10.1 distingue propriedades que decorrem da própria construção do método daquelas que exigem hipóteses adicionais sobre o modelo, a amostra ou o estimador específico.

10.3.3 Invariância da máxima verossimilhança

A máxima verossimilhança possui uma propriedade que permite estimar funções do parâmetro sem realizar uma nova maximização desde o início (Casella; Berger, 2002).

Considere uma função

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e defina

$$\psi = g(\theta).$$

Para cada

$$\psi \in \Psi,$$

defina a verossimilhança perfilada por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.45)$$

A função g não precisa ser injetiva, contínua ou monótona para a propriedade de invariância apresentada a seguir.

Proposição 10.4 (Invariância da máxima verossimilhança). *Considere*

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e suponha que

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta).$$

Então

$$g(\hat{\theta}_{\text{MV}}) \in \arg \max_{\psi \in \Psi} L_g(\psi).$$

Portanto,

$$\hat{\psi}_{\text{MV}} = g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de

$$\psi = g(\theta).$$

Comprovação. Defina

$$\widehat{\psi} = g\left(\widehat{\theta}_{\text{MV}}\right).$$

Como a fibra

$$\{\theta \in \Theta : g(\theta) = \widehat{\psi}\}$$

contém $\widehat{\theta}_{\text{MV}}$, tem-se

$$L_g\left(\widehat{\psi}\right) = L\left(\widehat{\theta}_{\text{MV}}\right).$$

Nenhum outro valor de ψ pode apresentar verossimilhança perfilada superior, pois isso implicaria a existência de algum θ cuja verossimilhança superasse o máximo global. Portanto,

$$\widehat{\psi} = g\left(\widehat{\theta}_{\text{MV}}\right)$$

é um estimador de máxima verossimilhança de ψ . □

A invariância da máxima verossimilhança deve ser distinguida da equivariância.

- **Equivariância** relaciona uma transformação dos dados à transformação correspondente do estimador.
- **Invariância da máxima verossimilhança** aplica uma função do parâmetro ao estimador de máxima verossimilhança já obtido.

Considere a matriz de correlações populacional definida na Definição 8.5:

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Quando o estimador de máxima verossimilhança de Σ existe e possui diagonal positiva, a invariância fornece

$$\widehat{\mathcal{R}}_{\text{MV}} = \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2} \widehat{\Sigma}_{\text{MV}} \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2}. \quad (10.46)$$

Como correlações são preservadas por mudanças positivas de escala, conforme Equação 8.25, o fator comum que distingue as matrizes de covariâncias com divisores n e $n - 1$ se cancela na padronização. Assim, a matriz na Equação 10.46 coincide com a matriz de correlações calculada a partir da covariância amostral com divisor $n - 1$.

A propriedade pode ser aplicada também a funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma)$$

e, quando o estimador é positivo definido,

$$\Sigma^{-1}.$$

A invariância é uma propriedade de otimização. Ela não implica ausência de viés, consistência automática ou estabilidade numérica. Em particular, a inversão de uma matriz estimada mal condicionada pode amplificar pequenas perturbações.

Os dois métodos apresentados produzem, no modelo normal, o mesmo estimador para μ e a mesma matriz com divisor n para Σ . A seção seguinte examina primeiro o vetor de médias amostrais e suas propriedades.

10.4 Estimação do vetor de médias

O vetor de médias populacional μ , definido na Equação 8.1, descreve a localização da população em $\mathbb{R}^p$. A seção anterior mostrou que o método dos momentos e, sob o modelo normal multivariado, a máxima verossimilhança conduzem ao vetor de médias amostrais como estimador de μ . Nesta seção, esse estimador será estudado quanto às propriedades apresentadas anteriormente.

Considere a amostra aleatória multivariada definida na Equação 10.1 e suponha que

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n.$$

Os resultados sobre esperança, variabilidade, erro quadrático médio e consistência utilizam a independência entre as unidades amostrais e os momentos indicados acima. A normalidade multivariada será necessária apenas quando o vetor de médias amostrais for interpretado como estimador de máxima verossimilhança no modelo normal.

10.4.1 Vetor de médias amostrais

Retomando a Equação 10.8, o vetor de médias amostrais é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

com

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.47)$$

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n. \quad (10.48)$$

Após a observação dos dados,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.49)$$

Pelo método dos momentos, a Equação 10.30 fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}.$$

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança existe, a Equação 10.43 fornece

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}.$$

Portanto,

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}. \quad (10.50)$$

A mesma estatística é, portanto, obtida por dois princípios de construção diferentes. A partir deste ponto, o interesse recai sobre as propriedades de $\bar{\mathbf{X}}$ como estimador de μ . Essas propriedades não decorrem do fato de o estimador ter sido obtido pelo método dos momentos ou pela máxima verossimilhança; elas serão verificadas diretamente sob as hipóteses declaradas nesta seção.

Além de sua interpretação como estimativa de μ , o valor observado $\bar{\mathbf{x}}$ possui uma caracterização geométrica: ele é o centroide da nuvem de pontos e minimiza a soma dos quadrados das distâncias euclidianas das observações a um centro comum.

Proposição 10.5 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor $\bar{\mathbf{x}}$ é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.51)$$

Comprovação. Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Somando os quadrados das normas,

$$\begin{aligned} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\ &\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\ &\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \end{aligned}$$

Pela propriedade de centralização estabelecida na Equação 8.57,

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}.$$

Logo,

$$\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \quad (10.52)$$

A primeira parcela não depende de $\mathbf{m}$, e a segunda é não negativa e se anula somente em

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador. □

A identidade Equação 10.52 será reutilizada na construção da matriz SQPC e na decomposição da dispersão em torno de centros distintos.

10.4.2 Não viesamento, variabilidade e erro quadrático médio

Proposição 10.6 (Esperança e covariância do vetor de médias amostrais). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\bar{\mathbf{X}}) = \mu \quad (10.53)$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \quad (10.54)$$

Comprovação. Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right).$$

Como as unidades amostrais são independentes,

$$\text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right) = \sum_{i=1}^n \text{Cov}(\mathbf{X}_i) = n\Sigma.$$

Portanto,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

□

Consequentemente,

$$\text{Bias}(\bar{\mathbf{X}}) = \mathbf{0}.$$

O vetor de médias amostrais é, portanto, não viesado para μ .

Elemento a elemento,

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov}(\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

A matriz de covariâncias do erro de estimação é obtida multiplicando Σ pelo fator $1/n$. Assim, o aumento do tamanho amostral reduz a magnitude das variâncias e covariâncias, preservando a estrutura relativa determinada por Σ .

Como $\bar{\mathbf{X}}$ é não viesado, a decomposição do erro quadrático médio na Equação 10.18 reduz-se ao termo de variabilidade. Sob a perda quadrática euclidiana,

$$\begin{aligned} \text{EQM}(\bar{\mathbf{X}}) &= \text{tr} [\text{Cov}(\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr}(\Sigma). \end{aligned} \quad (10.55)$$

Como a variância total populacional foi definida na Equação 8.35 por

$$\text{tr}(\Sigma),$$

Equação 10.55 mostra que o erro quadrático médio sob perda euclidiana corresponde à variância total dividida pelo tamanho amostral.

Esses resultados estabelecem o não viesamento, a matriz de covariâncias e o erro quadrático médio de $\bar{\mathbf{X}}$. Eles não estabelecem, por si só, eficiência, pois essa propriedade exige comparar o estimador com procedimentos concorrentes segundo um critério especificado.

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

O correspondente estimador é

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Aplicando Proposição 8.1 ao vetor aleatório $\bar{\mathbf{X}}$, cuja média e matriz de covariâncias são dadas na Proposição 10.6,

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \mu,$$

e

$$\begin{aligned}\text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.\end{aligned}\tag{10.56}$$

Cada vetor $\mathbf{a}$ define uma combinação linear dos componentes de $\bar{\mathbf{X}}$ e, geometricamente, especifica uma direção juntamente com uma escala. Sua variabilidade é determinada por

$$\frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Para comparar apenas direções, pode-se considerar vetores $\mathbf{a}$ de norma unitária. Nesse caso, direções com maior variância populacional também produzem maior variabilidade entre as estimativas das respectivas combinações lineares. Essa é a mesma interpretação utilizada anteriormente na comparação de matrizes de covariâncias pela ordem de Löwner.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Mais geralmente, para

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\mu$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n} \mathbf{C}\Sigma\mathbf{C}^\top. \quad (10.57)$$

Essas expressões serão retomadas no estudo de contrastes e hipóteses lineares.

10.4.4 Consistência e equivariância

Proposição 10.7 (Consistência do vetor de médias amostrais). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independentes, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

com segundos momentos finitos. Para dimensão p fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad (10.58)$$

quando $n \rightarrow \infty$.

Comprovação. Por Equação 10.55,

$$E\left[\|\bar{\mathbf{X}} - \mu\|^2\right] = \frac{\text{tr}(\Sigma)}{n}.$$

Para $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$\begin{aligned}
P(\|\bar{\mathbf{X}} - \mu\| > \varepsilon) &\leq \frac{E[\|\bar{\mathbf{X}} - \mu\|^2]}{\varepsilon^2} \\
&= \frac{\text{tr}(\Sigma)}{n\varepsilon^2} \rightarrow 0.
\end{aligned}$$

Logo,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

□

A prova utiliza segundos momentos finitos. Para dimensão fixa, a consistência também pode ser obtida por leis dos grandes números sob condições de integrabilidade mais gerais.

A equivariância do vetor de médias amostrais foi utilizada anteriormente como exemplo de Definição 10.9. O resultado é registrado a seguir para referência posterior.

Proposição 10.8 (Equivariância afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \tag{10.59}$$

Como, por Equação 8.17,

$$\mu_Y = \mathbf{C}\mu + \mathbf{d},$$

a transformação aplicada ao estimador acompanha exatamente a transformação correspondente do parâmetro populacional.

Até este ponto, foram estabelecidas propriedades distintas do vetor de médias amostrais: ele é não viesado, possui matriz de covariâncias Σ/n , tem erro quadrático médio $\text{tr}(\Sigma)/n$ sob perda euclidiana, é consistente sob as condições especificadas e é equivariante em relação a transformações afins. Essas propriedades foram demonstradas para o estimador concreto e não decorrem simplesmente do método utilizado para construí-lo.

10.4.5 Variabilidade entre amostras

O vetor $\bar{\mathbf{X}}$ é uma estatística aleatória, enquanto $\bar{\mathbf{x}}$ é sua realização para uma amostra observada. Se o processo de amostragem fosse repetido, diferentes amostras produziriam diferentes valores de $\bar{\mathbf{x}}$. A distribuição desses valores corresponde à distribuição amostral do estimador.

A Figura 10.1 apresenta 250 realizações de $\bar{\mathbf{X}}$ para amostras de tamanhos 5 e 50 geradas de uma mesma distribuição normal bivariada. A normalidade é utilizada apenas para gerar a ilustração; o resultado na Equação 10.54 depende apenas da independência das unidades amostrais e da existência dos segundos momentos.




Figura 10.1: Vetores de médias amostrais obtidos em 250 amostras de uma distribuição normal bivariada, para tamanhos amostrais 5 e 50.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Para $n = 50$, a nuvem é mais concentrada do que para $n = 5$, em concordância com a redução da matriz de covariâncias por $1/n$.

A figura **não representa ainda um resultado sobre a forma exata da distribuição amostral de $\bar{\mathbf{X}}$** . Essa distribuição será estudada no Capítulo 12.

O vetor de médias amostrais estima a localização da população. A estimação da dispersão exige considerar os desvios das observações em relação a esse centro. Esses desvios conduzem à matriz SQPC e aos estimadores da matriz de covariâncias.

10.5 SQPC e estimação da matriz de covariâncias

O vetor de médias amostrais descreve a localização da amostra. A estimação da matriz de covariâncias exige representar como as observações se dispersam conjuntamente em torno desse centro.

O Capítulo 8 definiu a matriz total de somas de quadrados e produtos cruzados (SQPC) na Definição 8.10 e a matriz de covariâncias observada na Definição 8.11. A seção sobre métodos de estimação mostrou ainda que o método dos momentos conduz à matriz SQPC dividida por n e que, sob o modelo normal multivariado e as condições de existência do máximo, a máxima verossimilhança conduz à mesma expressão.

Nesta seção, a SQPC e as matrizes de covariâncias correspondentes passam a ser tratadas como estatísticas aleatórias. O objetivo é comparar os estimadores de Σ resultantes de diferentes critérios e estudar suas propriedades.

Considere a amostra aleatória multivariada definida na Equação 10.1, com unidades independentes e

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

e suponha que os segundos momentos sejam finitos.

10.5.1 SQPC como estatística aleatória

A matriz aleatória da amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Retomando a matriz de centralização utilizada na Equação 8.58,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

define-se a matriz aleatória centralizada por

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}. \quad (10.60)$$

Suas linhas são

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Definição 10.13 (Matriz SQPC amostral). A **matriz de somas de quadrados e produtos cruzados (SQPC) amostral** é a estatística

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.61)$$

Equivalentemente,

$$\mathbf{T} = \mathcal{X}_c^\top \mathcal{X}_c = \mathcal{X}^\top \mathbf{H}_n \mathcal{X}. \quad (10.62)$$

Após a observação da amostra,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.63)$$

A matriz $\mathbf{T}$ é exatamente a matriz SQPC observada definida na Definição 8.10 e escrita matricialmente na Equação 8.59. A diferença de notação é probabilística: $\mathbf{T}$ representa a estatística aleatória, enquanto $\mathbf{T}$ representa sua realização observada.

O elemento (j, k) de $\mathbf{T}$ é

$$\mathsf{T}_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.64)$$

Na diagonal,

$$\mathbf{T}_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a soma de quadrados centralizada da variável j . Fora da diagonal, $\mathbf{T}_{jk}$ é o produto cruzado centralizado entre as variáveis j e k .

Após a observação da amostra, os elementos correspondentes de $\mathbf{T}$ são denotados por t_{jk} .

10.5.2 Decomposição em torno de um centro arbitrário

A caracterização do centroide na Equação 10.52 mostrou, em termos de distâncias quadráticas, como a dispersão em torno de um centro arbitrário pode ser decomposta em uma parcela em torno da média amostral e outra associada ao deslocamento do centro. Para a estimação da matriz de covariâncias, utiliza-se a versão matricial dessa decomposição.

Proposição 10.9 (Decomposição da SQPC em torno de um centro arbitrário). *Para qualquer vetor fixo*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \\ = \mathbf{T} + n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \tag{10.65}$$

Comprovação. Escreva

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo na soma dos produtos externos, surgem quatro parcelas. Os dois termos cruzados contêm

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

e, portanto, se anulam. Restam

$\mathbf{T}$

e

$$n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^{\top},$$

o que fornece Equação 10.65. □

Para

$$\mathbf{c} = \mu,$$

obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^{\top} \\ &= \mathbf{T} + n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^{\top}. \end{aligned} \tag{10.66}$$

Essa identidade separa a dispersão das observações em torno do centro populacional em duas parcelas: a dispersão em torno da média amostral e o afastamento entre a média amostral e a média populacional.

10.5.3 Esperança da SQPC

A identidade anterior permite obter a esperança de $\mathbf{T}$ sem assumir normalidade.

Proposição 10.10 (Esperança da SQPC). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{T}) = (n-1)\Sigma. \tag{10.67}$$

Comprovação. Tomando esperança no lado esquerdo de Equação 10.66,

$$E \left[\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] = \sum_{i=1}^n \Sigma = n\Sigma.$$

Para a segunda parcela do lado direito,

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] = n \text{Cov} (\bar{\mathbf{X}}).$$

Por Equação 10.54,

$$n \text{Cov} (\bar{\mathbf{X}}) = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{T}) + \Sigma,$$

e segue que

$$E(\mathbf{T}) = (n-1)\Sigma.$$

□

O fator $n-1$ surge porque a SQPC utiliza desvios em relação à média estimada a partir da própria amostra. A centralização impõe

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

de modo que os n vetores de desvios satisfazem uma restrição linear. Assim, a centralização reduz em uma unidade a dimensão associada às variações em torno da média amostral.

A relação

$$E(\mathbf{T}) = (n-1)\Sigma$$

depende apenas da independência entre as unidades amostrais e da existência dos segundos momentos necessários; a normalidade multivariada não é exigida. A distribuição completa de $\mathbf{T}$ sob normalidade será tratada no Capítulo 12.

10.5.4 Estimador não viesado da matriz de covariâncias

Definição 10.14 (Matriz de covariâncias amostral). Para $n \geq 2$, define-se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}, \quad (10.68)$$

em que $\mathbf{T}$ é definida na Definição 10.13.

Proposição 10.11 (Não viesamento da matriz de covariâncias amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes, possuem segundos momentos finitos e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{S}) = \Sigma. \quad (10.69)$$

Portanto, $\mathbf{S}$ é um estimador não viesado de Σ .

Comprovação. Por Equação 10.68 e Equação 10.67,

$$\begin{aligned} E(\mathbf{S}) &= \frac{1}{n-1} E(\mathbf{T}) \\ &= \frac{1}{n-1} (n-1) \Sigma \\ &= \Sigma. \end{aligned}$$

□

Após a observação, obtém-se a matriz de covariâncias observada definida na Definição 8.11:

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.70)$$

Componente a componente,

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.71)$$

Para $j = k$,

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Assim,

$$\mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}.$$

Após a observação da amostra, os elementos correspondentes de $\mathbf{S}$ são denotados por s_{jk} .

A divisão por $n-1$ corrige o viés associado à centralização pela média amostral. Ela não é escolhida para garantir semidefinição positiva. Como a matriz SQPC observada satisfaz

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram, conforme Definição 3.18, e suas propriedades de simetria e semidefinição positiva decorrem da Proposição 3.9. A multiplicação por $1/(n-1) > 0$ preserva essas propriedades em $\mathbf{S}$.

O não viesamento de $\mathbf{S}$ foi obtido utilizando apenas segundos momentos. Uma caracterização de sua variabilidade completa exigiria estudar

$$\text{Cov}[\text{vec}(\mathbf{S})],$$

utilizando o operador definido na Definição 7.9. De modo correspondente, o erro quadrático médio matricial sob a perda baseada na norma de Frobenius definida na Definição 6.7 envolveria

$$E \left[\|\mathbf{S} - \Sigma\|_F^2 \right].$$

Essas quantidades dependem, em geral, de momentos de quarta ordem. Por isso, diferentemente do que ocorreu com o vetor de médias amostrais, os segundos momentos assumidos nesta seção não são suficientes para determinar a variabilidade completa ou o EQM de $\mathbf{S}$. Sob normalidade, resultados mais específicos serão obtidos a partir da distribuição amostral da matriz de covariâncias no Capítulo 12.

10.5.5 Estimador com divisor n : momentos e máxima verossimilhança

Pelo método dos momentos, a Equação 10.33 fornece

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado não singular e quando o máximo existe, a Equação 10.44 fornece a mesma estatística:

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Portanto, no modelo normal e nas condições de existência do estimador de máxima verossimilhança,

$$\widehat{\Sigma}_{\text{MM}} = \widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

tem-se, sob o modelo normal,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (10.72)$$

Por Equação 10.67,

$$E \left(\frac{\mathbf{T}}{n} \right) = \frac{n-1}{n} \Sigma.$$

Portanto, como estimador de Σ ,

$$\text{Bias} \left(\frac{\mathbf{T}}{n} \right) = -\frac{1}{n} \Sigma.$$

Esse resultado vale para o estimador pelo método dos momentos sem exigir normalidade. Sob o modelo normal e nas condições de existência do máximo, a mesma estatística é também o estimador de máxima verossimilhança. Nesse caso,

$$E \left(\widehat{\Sigma}_{\text{MV}} \right) = \frac{n-1}{n} \Sigma \quad (10.73)$$

e

$$\text{Bias} \left(\widehat{\Sigma}_{\text{MV}} \right) = -\frac{1}{n} \Sigma. \quad (10.74)$$

Assim, o viés é uma propriedade da estatística $\mathbf{T}/n$ como estimador de Σ , e não uma consequência do método utilizado para obtê-la.

A comparação entre

$$\frac{\mathbf{T}}{n} \quad \text{e} \quad \frac{\mathbf{T}}{n-1}$$

mostra novamente que o princípio utilizado para construir um estimador e suas propriedades estatísticas são questões distintas. A primeira matriz resulta diretamente do método dos momentos e, sob normalidade, também da máxima verossimilhança; a segunda utiliza a correção necessária para obter não viesamento.

Quando n aumenta,

$$\frac{n-1}{n} \rightarrow 1,$$

de modo que a diferença relativa entre os dois estimadores desaparece.

Dois divisores, dois critérios

A matriz

$$\frac{\mathbf{T}}{n}$$

surge como estimador de momentos e, sob o modelo normal e as condições de existência do máximo, como estimador de máxima verossimilhança.

A matriz

$$\frac{\mathbf{T}}{n-1}$$

é construída para satisfazer

$$E(\mathbf{S}) = \Sigma.$$

Nenhum dos dois divisores é universalmente “correto” sem especificar o critério de estimação.

Sob o modelo normal multivariado, Proposição 10.2 estabeleceu que

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para

$$(\mu, \Sigma).$$

Como, para n fixado,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é uma transformação bijetiva de $\mathbf{T}$, o par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

preserva a mesma informação sobre os parâmetros. Essa afirmação é conjunta: ela não significa que $\mathbf{S}$ isoladamente seja suficiente para (μ, Σ) .

10.5.6 Consistência dos estimadores de covariância

O não viesamento é uma propriedade para tamanho amostral fixo. A consistência descreve o comportamento quando n aumenta.

Proposição 10.12 (Consistência da matriz de covariâncias amostral). *Considere uma amostra aleatória i.i.d.*

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

em que

$$\mathbf{X}_i \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu,$$

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

e

$$E(\|\mathbf{X}_i\|^2) < \infty.$$

Se o número p de variáveis permanece fixo quando $n \rightarrow \infty$, então

$$\mathbf{S} \xrightarrow{P} \Sigma. \quad (10.75)$$

Comprovação. Pela identidade

$$\frac{1}{n} \mathbf{T} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^\top - \bar{\mathbf{X}} \bar{\mathbf{X}}^\top, \quad (10.76)$$

a matriz com divisor n pode ser escrita como diferença entre o segundo momento amostral não central e o produto externo da média amostral.

Para cada par (j, k) , a condição de segundos momentos finitos implica

$$E(|X_j X_k|) < \infty.$$

Pela Lei dos Grandes Números,

$$\frac{1}{n} \sum_{i=1}^n X_{ij} X_{ik} \xrightarrow{P} E(X_j X_k),$$

e

$$\bar{X}_j \xrightarrow{P} \mu_j.$$

Logo, elemento a elemento,

$$\frac{1}{n} \mathbf{T} \xrightarrow{P} E(\mathbf{X}\mathbf{X}^\top) - \mu\mu^\top = \Sigma.$$

Como p é fixo,

$$\mathbf{S} = \frac{n}{n-1} \left(\frac{\mathbf{T}}{n} \right) \xrightarrow{P} \Sigma.$$

□

Pela mesma argumentação,

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n} \xrightarrow{P} \Sigma \quad (10.77)$$

sempre que a expressão é considerada como estatística. No modelo normal positivo definido, sua interpretação como estimador de máxima verossimilhança requer adicionalmente a existência do máximo discutida anteriormente.

A consistência apresentada aqui corresponde ao regime clássico de **dimensão fixa**. Quando p aumenta com n , a convergência deve ser analisada segundo o regime dimensional e a norma de interesse.

10.5.7 Transformações, posto e singularidade

As propriedades algébricas da matriz SQPC observada decorrem de sua representação de Gram na Equação 8.59 e do limite de posto estabelecido na Equação 8.60. Como essas propriedades valem para cada realização da amostra, elas também caracterizam as estatísticas $\mathbf{T}$ e $\mathbf{S}$ amostra a amostra.

Transformações afins. A equivariância da matriz de covariâncias amostral foi utilizada anteriormente como exemplo de Definição 10.9. Para referência, se

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

então

$$\mathbf{T}_Y = \mathbf{C}\mathbf{T}_X\mathbf{C}^\top \quad (10.78)$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \quad (10.79)$$

A translação $\mathbf{d}$ desaparece pela centralização. Como a matriz populacional satisfaz, pela Proposição 8.6,

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top,$$

a transformação da estatística acompanha exatamente a transformação correspondente do parâmetro.

Simetria e semidefinição positiva. Pela representação de Gram na Equação 8.59 e pelas propriedades de matrizes de Gram na Proposição 3.9, para qualquer realização da amostra,

$$\mathbf{T} = \mathbf{T}^\top \quad \text{e} \quad \mathbf{T} \succeq \mathbf{0}.$$

Como

$$\mathbf{S} = \frac{1}{n-1}\mathbf{T},$$

a matriz $\mathbf{S}$ também é simétrica e positiva semidefinida. Assim, em aritmética exata, o estimador não produz autovalores negativos.

Variância de combinações lineares. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{X}_i - \bar{\mathbf{X}})]^2. \quad (10.80)$$

A forma quadrática é a variância amostral da variável projetada

$$\mathbf{a}^\top \mathbf{X}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0$$

se, e somente se, os valores observados da combinação linear $\mathbf{a}^\top \mathbf{X}_i$ são constantes na amostra.

Posto. Pelo resultado estabelecido na Equação 8.60, para qualquer realização da amostra,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n-1). \quad (10.81)$$

Como $\mathbf{S}$ é obtida por multiplicação de $\mathbf{T}$ por uma constante positiva,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}). \quad (10.82)$$

Uma condição necessária para

$$\mathbf{S} \succ \mathbf{0}$$

é, portanto,

$$n \geq p+1.$$

Mesmo quando essa desigualdade é satisfeita, a definição positiva depende de as colunas de $\mathbf{X}_c$ possuírem posto completo.

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

A singularidade significa que existe algum vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p$$

tal que

$$\mathbf{S}\mathbf{a} = \mathbf{0}.$$

Equivalentemente,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0,$$

de modo que a combinação linear correspondente apresenta variância amostral nula.

Inversão. Quando

$$\mathbf{S} \succ \mathbf{0},$$

sua inversa existe e pode ser utilizada em formas quadráticas e métricas baseadas na covariância estimada.

Se $\mathbf{S}$ é singular, $\mathbf{S}^{-1}$ não existe. A utilização de pseudoinversas ou de estimadores regularizados corresponde a escolhas distintas e será discutida na seção de aprofundamento.

Forma quadrática com covariância estimada

A distância de Mahalanobis foi definida na Definição 8.9 utilizando os parâmetros populacionais. Sob normalidade, Proposição 9.8 estabelece a distribuição qui-quadrado da forma correspondente quando μ e Σ são conhecidos.

Substituir esses parâmetros por quantidades estimadas, como $\bar{\mathbf{x}}$ e $\mathbf{S}$, produz outra estatística. Portanto, a distribuição

$$D_M^2 \sim \chi_p^2$$

não pode ser transferida diretamente para uma forma quadrática construída com estimadores.

As distribuições apropriadas para estatísticas que envolvem parâmetros estimados serão estudadas no Capítulo 12.

Até este ponto, foram estabelecidas propriedades distintas dos estimadores de Σ . A matriz $\mathbf{S} = \mathbf{T}/(n-1)$ é não viesada, enquanto $\mathbf{T}/n$ é viesada em amostras finitas, embora seja obtida pelo método dos momentos e, sob normalidade e existência do máximo, também pela máxima verossimilhança. Ambos os estimadores são consistentes no regime de dimensão fixa sob as condições especificadas. Além disso, a matriz de covariâncias amostral é equivariante sob transformações afins, positiva semidefinida em cada realização e possui posto limitado por $\min(p, n-1)$.

Esses resultados não estabelecem eficiência em amostras finitas, e a avaliação completa da variabilidade ou do erro quadrático médio matricial exige hipóteses adicionais sobre momentos de ordem superior.

O posto e a estabilidade numérica da matriz de covariâncias amostral tornam-se especialmente relevantes quando p não é pequeno em relação a n . Antes de discutir esse regime, serão construídos os estimadores correspondentes para covariâncias entre blocos e para correlações.

10.6 Estimação de covariâncias cruzadas e correlações

Em diversos problemas multivariados, as variáveis são organizadas em blocos observados sobre as mesmas unidades amostrais. As covariâncias cruzadas descrevem associações lineares entre variáveis pertencentes a blocos distintos, enquanto as correlações removem as escalas marginais dessas associações.

O Capítulo 8 definiu a matriz de covariâncias cruzadas populacional na Definição 8.3, a matriz de covariâncias cruzadas observada na Definição 8.13 e a matriz de correlações observada na Definição 8.12. Nesta seção, os objetos correspondentes são tratados como estatísticas aleatórias e utilizados na estimação de suas contrapartes populacionais.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q.$$

A matriz de covariâncias cruzadas populacional

$$\Sigma_{XY}$$

foi definida na Definição 8.3. Sua orientação satisfaz, conforme Equação 8.13,

$$\Sigma_{YX} = \Sigma_{XY}^{\top}.$$

Para o vetor conjunto

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

a estrutura em blocos da matriz de covariâncias segue Equação 8.15. Neste capítulo, será denotada por

$$\Sigma_{\text{conj}} = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.83)$$

Para estimar Σ_{XY} , é necessária uma amostra **pareada**:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ correspondem à mesma unidade amostral. Alterar a correspondência entre as linhas dos dois blocos modifica as covariâncias cruzadas.

Organize as observações nas matrizes aleatórias

$$\mathcal{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} \in \mathbb{R}^{n \times q}.$$

Após a centralização,

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.15 (Matriz de somas de produtos cruzados entre blocos). A **matriz de somas de produtos cruzados entre os dois blocos** é

$$\mathbf{T}_{XY} = \mathcal{X}_c^\top \mathcal{Y}_c. \quad (10.84)$$

Equivalentemente,

$$\mathbf{T}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (10.85)$$

Após a observação,

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.86)$$

A inversão da ordem dos blocos produz

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top$$

e

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 10.16 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$, a matriz de covariâncias cruzadas amostral é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}, \quad (10.87)$$

em que $\mathbf{T}_{XY}$ é a matriz de somas de produtos cruzados entre os blocos definida na Definição 10.15.

Após a observação da amostra, obtém-se a matriz de covariâncias cruzadas observada definida na Definição 8.13:

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.88)$$

Seu elemento (j, k) é

$$S_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.89)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{S}_{XY}$ é denotado por $s_{X_j Y_k}$.

Proposição 10.13 (Não viesamento da covariância cruzada amostral). *Considere uma amostra pareada i.i.d. do vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

com segundos momentos finitos. Então,

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.90)$$

Comprovação. A matriz de covariâncias amostral do vetor conjunto é

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}.$$

Pelo não viesamento da matriz de covariâncias amostral estabelecido na Equação 10.69,

$$E(\mathbf{S}_{\text{conj}}) = \Sigma_{\text{conj}}.$$

A igualdade entre os blocos superiores direitos fornece

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}.$$

□

O método dos momentos aplicado à matriz de covariâncias do vetor conjunto conduz ao estimador

$$\widehat{\Sigma}_{\text{conj},\text{MM}} = \frac{1}{n} \mathbf{T}_{\text{conj}}.$$

Consequentemente, o bloco correspondente à covariância cruzada é

$$\widehat{\Sigma}_{XY,\text{MM}} = \frac{1}{n} \mathbf{T}_{XY}.$$

Sob normalidade conjunta não singular,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_{\text{conj}} \right),$$

o estimador de máxima verossimilhança da matriz conjunta de covariâncias, quando existe, utiliza também o divisor n . Portanto,

$$\widehat{\Sigma}_{XY,\text{MM}} = \widehat{\Sigma}_{XY,\text{MV}} = \frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY}. \quad (10.91)$$

Se

$$n \geq p + q + 1$$

e a distribuição normal conjunta é não singular, a matriz SQPC do vetor conjunto possui posto $p + q$ quase certamente. Nessas condições, o estimador positivo definido de máxima verossimilhança da matriz conjunta existe quase certamente.

Por Equação 10.90,

$$E\left(\frac{1}{n}\mathbf{T}_{XY}\right) = \frac{n-1}{n}\Sigma_{XY}.$$

Assim,

$$\text{Bias}\left(\frac{1}{n}\mathbf{T}_{XY}\right) = -\frac{1}{n}\Sigma_{XY}.$$

Esse viés pertence à estatística $\mathbf{T}_{XY}/n$ como estimador de Σ_{XY} e não depende da hipótese de normalidade. A normalidade é necessária apenas para interpretar essa mesma estatística como o bloco cruzado do estimador de máxima verossimilhança da matriz conjunta.

A consistência também pode ser obtida diretamente a partir da matriz de covariâncias do vetor conjunto. Sob as condições da Proposição 10.12, aplicadas ao vetor de dimensão $p + q$,

$$\mathbf{S}_{\text{conj}} \xrightarrow{P} \Sigma_{\text{conj}}.$$

Consequentemente, cada um de seus blocos converge para o bloco populacional correspondente e, em particular,

$$\mathbf{S}_{XY} \xrightarrow{P} \Sigma_{XY}. \quad (10.92)$$

Como

$$\frac{1}{n}\mathbf{T}_{XY} = \frac{n-1}{n}\mathbf{S}_{XY},$$

também se obtém

$$\frac{1}{n}\mathbf{T}_{XY} \xrightarrow{P} \Sigma_{XY}.$$

A transformação da covariância cruzada amostral acompanha a transformação do parâmetro populacional estabelecida na Equação 8.19. Se

$$\mathbf{U} = \mathbf{CX} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{D}\mathbf{Y} + \mathbf{d},$$

então

$$\mathbf{S}_{UV} = \mathbf{C}\mathbf{S}_{XY}\mathbf{D}^\top. \quad (10.93)$$

Portanto, $\mathbf{S}_{XY}$ é equivariante em relação a essas transformações afins dos dois blocos. Os vetores de localização $\mathbf{c}$ e $\mathbf{d}$ desaparecem após a centralização.

Para

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

segue que

$$\mathbf{S}_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.94)$$

Diferentemente de uma matriz de covariâncias de um único vetor, $\mathbf{S}_{XY}$ é, em geral, retangular quando $p \neq q$. Mesmo quando $p = q$, ela não precisa ser simétrica. Os dois blocos satisfazem

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top.$$

Por isso, propriedades como simetria e semidefinição positiva não devem ser atribuídas isoladamente à matriz de covariâncias cruzadas. Essas propriedades pertencem à matriz de covariâncias do vetor conjunto, da qual $\mathbf{S}_{XY}$ é um bloco.

O posto satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.95)$$

Esse limite restringirá posteriormente técnicas que utilizam simultaneamente dois conjuntos de variáveis.

10.6.2 Matriz de correlações amostral

A matriz de correlações amostral é obtida pela padronização das covariâncias pelas variâncias marginais correspondentes.

Considere

$$\mathbf{S} = (S_{jk})$$

e defina a matriz diagonal das variâncias amostrais por

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Definição 10.17 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas, a matriz de correlações amostral é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.96)$$

em que

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Após a observação da amostra, obtém-se a matriz $\mathbf{R}$ definida na Definição 8.12:

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.97)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) da estatística aleatória $\mathbf{R}$ é

$$R_{jk} = \frac{S_{jk}}{\sqrt{S_{jj}S_{kk}}}. \quad (10.98)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{R}$ é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}.$$

Consequentemente,

$$R_{jj} = 1$$

e, para a realização observada,

$$r_{jj} = 1.$$

A interpretação geométrica da correlação observada foi estabelecida na Equação 8.71, que identifica r_{jk} com o cosseno do ângulo entre as colunas centralizadas e padronizadas. Aqui, a ênfase recai sobre $\mathbf{R}$ como estatística utilizada para estimar a matriz populacional $\mathcal{R}$.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Se

$$S_{jj} = 0$$

a correspondente padronização não existe.

10.6.3 Propriedades estruturais

Proposição 10.14 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, $\mathbf{R}$ é:*

1. *simétrica;*
2. *positiva semidefinida;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.99)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.100)$$

Comprovação. A simetria decorre da simetria de $\mathbf{S}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \mathbf{R} \mathbf{a} &= \left(\mathbf{D}_S^{-1/2} \mathbf{a} \right)^\top \mathbf{S} \left(\mathbf{D}_S^{-1/2} \mathbf{a} \right) \\ &\geq 0.\end{aligned}$$

Logo, $\mathbf{R}$ é positiva semidefinida.

A diagonal unitária decorre de

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1.$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definitude positiva. $\square$

Uma matriz simétrica com diagonal unitária e elementos em $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A positividade semidefinida também é necessária.

Como

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}),$$

uma condição necessária para definitude positiva é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois ainda podem existir dependências lineares entre as colunas centralizadas.

Quando

$$p \geq n,$$

a matriz de correlações, se definida, é necessariamente singular.

Para uma realização observada,

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.101)$$

A padronização remove as escalas marginais, mas não altera o posto.

A matriz de correlações populacional é uma função da matriz de covariâncias,

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Substituindo Σ pelo estimador de momentos

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T},$$

obtém-se um estimador por substituição de $\mathcal{R}$. Como o fator comum $1/n$ aparece tanto nas covariâncias quanto nas variâncias marginais, ele se cancela na padronização. A matriz resultante é

$$\mathbf{R}.$$

Assim, $\mathbf{R}$ pode ser obtida pela padronização do estimador de momentos de Σ .

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança de Σ existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Novamente, o fator comum $(n-1)/n$ cancela-se na transformação de covariâncias em correlações. Pela Proposição 10.4,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}. \quad (10.102)$$

Assim, no modelo normal considerado e nas condições de existência do máximo, a mesma matriz de correlações amostral também é obtida pela máxima verossimilhança.

Essa coincidência não implica não viesamento. Em geral,

$$E(R_{jk}) \neq \rho_{jk}.$$

A razão é que a correlação amostral é uma função não linear das variâncias e covariâncias amostrais.

Por outro lado, se

$$\mathbf{S} \xrightarrow{P} \Sigma$$

e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

Considere a transformação

$$g(\mathbf{A}) = \mathbf{D}_A^{-1/2} \mathbf{A} \mathbf{D}_A^{-1/2},$$

em que

$$\mathbf{D}_A = \text{diag}(a_{11}, \dots, a_{pp}).$$

Essa transformação converte uma matriz de covariâncias em sua matriz de correlações e é contínua quando os elementos de sua diagonal são positivos.

O **teorema do mapeamento contínuo** estabelece que, se uma sequência de estatísticas converge em probabilidade e uma função é contínua no limite, então a sequência obtida pela aplicação dessa função também converge em probabilidade (Vaart, 1998).

Como

$$\mathbf{S} \xrightarrow{P} \Sigma$$

no regime de dimensão fixa e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

a transformação g é contínua em Σ . Portanto,

$$g(\mathbf{S}) \xrightarrow{P} g(\Sigma).$$

Como

$$g(\mathbf{S}) = \mathbf{R}$$

e

$$g(\Sigma) = \mathcal{R},$$

segue que

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \quad (10.103)$$

Portanto, a matriz de correlações amostral é consistente para a matriz de correlações populacional, embora suas entradas possam ser viesadas em amostras finitas.

10.6.4 Transformações de localização e escala

O efeito populacional das mudanças de localização e escala sobre a correlação foi estabelecido na Equação 8.25. Para uma realização observada, considere

$$y_{ij} = a_j + b_j x_{ij}, \quad b_j \neq 0.$$

A localização a_j desaparece após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \operatorname{sgn}(b_j) \operatorname{sgn}(b_k) r_{X_j X_k}. \quad (10.104)$$

Fatores de escala positivos preservam a correlação. Quando apenas um dos fatores b_j e b_k é negativo, o sinal da correlação é invertido. Mudanças de localização não alteram a correlação.

Em forma matricial, para

$$\mathbf{Y} = \mathbf{X} \mathbf{D}_b + \mathbf{1}_n \mathbf{a}^\top,$$

com

$$\mathbf{D}_b = \operatorname{diag}(b_1, \dots, b_p),$$

defina

$$\mathbf{D}_{\operatorname{sgn}} = \operatorname{diag}[\operatorname{sgn}(b_1), \dots, \operatorname{sgn}(b_p)].$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\operatorname{sgn}} \mathbf{R}_X \mathbf{D}_{\operatorname{sgn}}. \quad (10.105)$$

Se todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X.$$

Para dois blocos, defina as matrizes diagonais aleatórias

$$\mathbf{D}_X = \text{diag} (S_{X_1 X_1}, \dots, S_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (S_{Y_1 Y_1}, \dots, S_{Y_q Y_q}).$$

Quando todas as variâncias amostrais envolvidas são positivas, define-se a matriz de correlações cruzadas amostral por

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2}. \quad (10.106)$$

Seu elemento (j, k) é

$$R_{X_j Y_k} = \frac{S_{X_j Y_k}}{\sqrt{S_{X_j X_j} S_{Y_k Y_k}}}.$$

Após a observação da amostra,

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2},$$

em que

$$\mathbf{D}_X = \text{diag} (s_{X_1 X_1}, \dots, s_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (s_{Y_1 Y_1}, \dots, s_{Y_q Y_q}).$$

Seu elemento observado é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}}.$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top$$

e, após a observação,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top.$$

A matriz de correlações do vetor conjunto assume a forma

$$\mathbf{R}_{\text{conj}} = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix}. \quad (10.107)$$

Até este ponto, foram estabelecidas propriedades distintas das estatísticas utilizadas para representar associações entre variáveis. A matriz $\mathbf{S}_{XY}$ é não viesada e consistente para Σ_{XY} sob as condições especificadas, enquanto $\mathbf{T}_{XY}/n$ apresenta o mesmo fator de viés observado na estimação da matriz de covariâncias e, sob normalidade conjunta e existência do máximo, também corresponde ao estimador de máxima verossimilhança do bloco cruzado.

A matriz de correlações amostral $\mathbf{R}$ remove as escalas marginais, preserva a semidefinição positiva e o posto da matriz de covariâncias quando está definida, é consistente no regime de dimensão fixa, mas suas entradas não são, em geral, estimadores não viesados das correlações populacionais. Sob o modelo normal, a invariância da máxima verossimilhança conduz à mesma matriz $\mathbf{R}$.

As matrizes de covariâncias e correlações cruzadas serão utilizadas posteriormente em métodos que relacionam dois conjuntos de variáveis. O objetivo neste capítulo é estabelecer sua estimação e as propriedades necessárias para esses desenvolvimentos.

A próxima seção examina situações em que a dimensão, a redundância ou a sensibilidade das estatísticas clássicas dificultam a estimação da matriz de covariâncias.

10.7 Aprofundamento: dimensão, estabilidade e extensões da estimação

Esta seção examina situações em que a dimensão, o condicionamento ou a sensibilidade das estatísticas amostrais exigem cuidados adicionais. Os resultados anteriores trataram dos estimadores clássicos da média e da matriz de covariâncias. A regularização e a estimação robusta modificam esses procedimentos para tratar, respectivamente, problemas de instabilidade e de sensibilidade.

Uma matriz de covariâncias não estruturada de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. Assim, o número de parâmetros de dispersão a estimar cresce quadraticamente com p , enquanto o número de unidades amostrais permanece igual a n .

Regularização e robustez respondem a problemas diferentes. A regularização procura reduzir a instabilidade associada à dimensão, à redundância, ao tamanho amostral ou ao mau condicionamento. A estimação robusta procura reduzir a sensibilidade do procedimento a determinadas formas de contaminação ou desvios do modelo. As duas abordagens podem ser combinadas, mas tratam de problemas distintos.

10.7.1 Relação entre p e n

O limite de posto estabelecido na Equação 10.81,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1),$$

permite distinguir diferentes regimes dimensionais.

Dimensão fixa. No regime clássico,

$$p$$

permanece fixo enquanto

$$n \longrightarrow \infty.$$

Sob as condições da Proposição 10.12,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Como p é fixo, a convergência dos elementos implica convergência em qualquer norma matricial sobre $\mathbb{R}^{p \times p}$, pois todas essas normas são equivalentes em dimensão finita.

Dimensão crescente. Quando

$$p = p_n$$

também aumenta com n , os resultados obtidos para dimensão fixa não podem ser transferidos automaticamente. Um regime de referência é

$$\frac{p_n}{n} \longrightarrow c, \quad 0 < c < 1.$$

Nesse regime, a matriz de covariâncias amostral pode possuir posto completo e, ainda assim, apresentar elevada variabilidade em seu espectro.

O controle dos erros de estimação elemento a elemento não garante, por si só, controle do erro matricial em norma espectral. Consequentemente, boa estimação das covariâncias individuais não assegura automaticamente boa estimação dos autovalores, autovetores, determinante, inversa ou formas quadráticas que dependem da matriz inversa.

Além disso, o número de covariâncias fora da diagonal é

$$\frac{p(p-1)}{2},$$

e todas são estimadas a partir das mesmas n unidades.

Não existe um valor universal de p/n que separe matrizes estáveis e instáveis. O comportamento depende também da estrutura de Σ , da separação entre seus autovalores, da distribuição populacional e da função da matriz utilizada posteriormente.

Dimensão maior ou igual ao tamanho amostral. Se

$$p \geq n,$$

Equação 10.81 implica

$$\text{posto}(\mathbf{S}) \leq n - 1 < p.$$

Logo, a matriz de covariâncias amostral é necessariamente singular.

Essa singularidade não implica singularidade de Σ . Ela pode decorrer exclusivamente do número limitado de direções amostrais disponíveis após a centralização.

Posto amostral e posto populacional

Quando

$$p \geq n,$$

$\mathbf{S}$ é singular por construção, mesmo que a matriz populacional satisfaça

$$\Sigma \succ \mathbf{0}.$$

A singularidade da matriz amostral, portanto, não constitui evidência suficiente de singularidade da matriz de covariâncias populacional.

10.7.2 Condicionamento e inversão

Considere uma realização positiva definida,

$$\mathbf{S} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p),$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

A inversa é

$$\mathbf{S}^{-1} = \mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^\top.$$

Autovalores pequenos de $\mathbf{S}$ tornam-se pesos elevados em $\mathbf{S}^{-1}$.

O número de condição espectral foi definido na Definição 6.9. Para uma matriz simétrica positiva definida,

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.108)$$

Quanto maior essa razão, maior é a diferença entre as escalas espectrais extremas da matriz. Quando

$$\ell_{\min}(\mathbf{S}) \longrightarrow 0,$$

tem-se

$$\kappa_2(\mathbf{S}) \longrightarrow \infty.$$

Se $\mathbf{S}$ é singular, o número de condição associado à inversão é infinito. Portanto, invertibilidade e bom condicionamento são propriedades distintas.

O mau condicionamento torna a inversa sensível a erros de estimação: pequenas perturbações em $\mathbf{S}$ podem produzir alterações acentuadas em

$$\mathbf{S}^{-1}.$$

O determinante também depende de todo o espectro:

$$\det(\mathbf{S}) = \prod_{j=1}^p \ell_j.$$

Já a estabilidade dos autovetores depende não somente da magnitude dos autovalores, mas também de sua separação. Autovalores muito próximos podem produzir direções individuais sensíveis a pequenas perturbações.

Considere, por exemplo, a contraparte amostral da forma quadrática utilizada na distância de Mahalanobis definida na Definição 8.9:

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Nas coordenadas dos autovetores de $\mathbf{S}$,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Assim, erros na estimação de autovalores pequenos podem ser amplificados pela inversão, pois essas direções recebem pesos proporcionais a $1/\ell_j$.

Inversão computacional

A existência de $\mathbf{S}^{-1}$ não significa que seja necessário formá-la explicitamente. Quando o objetivo é calcular

$$\mathbf{S}^{-1} \mathbf{b},$$

é preferível, em geral, resolver o sistema

$$\mathbf{S} \mathbf{x} = \mathbf{b}.$$

Essa escolha não elimina o mau condicionamento, mas evita uma inversão explícita desnecessária.

10.7.3 Regularização

A regularização substitui a matriz de covariâncias amostral por um estimador que combina $\mathbf{S}$ com restrições ou valores de referência previamente especificados. O objetivo pode ser reduzir variabilidade, melhorar o condicionamento ou produzir uma matriz invertível.

Uma classe simples combina $\mathbf{S}$ com uma matriz-alvo (Ledoit; Wolf, 2004).

Definição 10.18 (Estimador de covariância por contração). Considere uma matriz-alvo fixada

$$\Gamma \in \mathbb{R}^{p \times p}, \quad \Gamma \succeq \mathbf{0},$$

e um peso

$$0 \leq \lambda \leq 1.$$

Define-se o estimador por contração

$$\widehat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \quad (10.109)$$

Para

$$\lambda = 0,$$

recupera-se $\mathbf{S}$. Para

$$\lambda = 1,$$

o estimador coincide com o alvo.

A contração geralmente introduz viés. Sua avaliação deve considerar conjuntamente viés e variabilidade por meio de uma função de perda e do risco correspondente.

A consistência também depende da forma como a regularização varia com o tamanho amostral. Se $\lambda \in (0, 1]$ e Γ são fixos e

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

então

$$\widehat{\Sigma}_\lambda \xrightarrow{P} (1 - \lambda)\Sigma + \lambda\Gamma.$$

Portanto, com $\lambda > 0$ fixo, o estimador não é, em geral, consistente para Σ . Se a matriz-alvo Γ é fixa e o peso passa a depender de n , com

$$\lambda_n \rightarrow 0,$$

então

$$\widehat{\Sigma}_{\lambda_n} = (1 - \lambda_n)\mathbf{S} + \lambda_n\Gamma \xrightarrow{P} \Sigma,$$

sempre que

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Assim, nesse caso, a intensidade da regularização desaparece assintoticamente e a consistência da matriz de covariâncias amostral é preservada.

Em aplicações, o alvo e o peso podem ser estimados a partir dos próprios dados. Nesse caso,

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\Gamma}. \quad (10.110)$$

A aleatoriedade de $\widehat{\lambda}$ e de $\widehat{\Gamma}$ passa, então, a fazer parte das propriedades do estimador.

A matriz-alvo precisa ser compatível com as unidades e escalas das variáveis. Um alvo diagonal preserva as escalas marginais e reduz as covariâncias. Um alvo esférico $\tau\mathbf{I}_p$ pressupõe que uma escala comum possua interpretação. Para matrizes de correlações, a identidade $\mathbf{I}_p$ constitui uma escolha natural de referência. O alvo também pode representar relações previamente especificadas entre as variáveis, como covariâncias nulas ou uma estrutura de correlação definida antes da estimação.

A identidade $\mathbf{I}_p$ não é um alvo neutro para uma matriz de covariâncias quando as variáveis são medidas em unidades ou escalas distintas.

Um alvo esférico adaptado à escala observada pode utilizar

$$\widehat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}), \quad (10.111)$$

levando a

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\tau}\mathbf{I}_p. \quad (10.112)$$

Essa escolha pressupõe que uma variância média comum tenha significado para as variáveis consideradas. Além disso, a definitude positiva produzida pelo componente esférico exige $\hat{\tau} > 0$. Como $\mathbf{S} \succeq \mathbf{0}$, essa condição equivale a haver variabilidade amostral positiva em pelo menos uma direção.

Outro alvo é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(\mathbf{S}_{11}, \dots, \mathbf{S}_{pp})$$

com

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.113)$$

Nesse caso, as variâncias amostrais permanecem inalteradas e as covariâncias são multiplicadas por $1 - \lambda$.

Proposição 10.15 (Definitude positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\hat{\Sigma}_{\lambda} \succ \mathbf{0}. \quad (10.114)$$

Comprovação. Para qualquer $\mathbf{a} \neq \mathbf{0}$,

$$\mathbf{a}^\top \hat{\Sigma}_{\lambda} \mathbf{a} = (1 - \lambda)\mathbf{a}^\top \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^\top \Gamma \mathbf{a}.$$

A primeira parcela é não negativa e a segunda é estritamente positiva. Logo,

$$\mathbf{a}^\top \hat{\Sigma}_{\lambda} \mathbf{a} > 0.$$

□

Com um alvo esférico,

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0,$$

e uma decomposição

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\mathbf{L}_1, \dots, \mathbf{L}_p) \mathbf{Q}^\top,$$

obtém-se

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \operatorname{diag}[(1 - \lambda)\mathbf{L}_1 + \lambda\tau, \dots, (1 - \lambda)\mathbf{L}_p + \lambda\tau] \mathbf{Q}^\top. \quad (10.115)$$

Portanto,

$$\mathbf{L}_{j,\lambda} = (1 - \lambda)\mathbf{L}_j + \lambda\tau. \quad (10.116)$$

Se

$$\mathbf{L}_j = 0$$

e

$$\lambda > 0,$$

então

$$\mathbf{L}_{j,\lambda} = \lambda\tau > 0.$$

A contração esférica afasta os autovalores de zero e pode melhorar o condicionamento. Esse efeito algébrico não garante redução do erro de estimação. A escolha do alvo e de λ deve ser avaliada segundo a função de perda e o risco considerados.

A Figura 10.2 compara o espectro da covariância amostral com uma versão regularizada.

No regime $p < n$, a regularização desloca os autovalores na direção do alvo. No regime $p \geq n$, os autovalores nulos decorrentes do limite de posto são substituídos por valores positivos.

A figura mostra um efeito algébrico da regularização. A escolha de λ e do alvo é um problema estatístico distinto e não será desenvolvida algoritmicamente neste capítulo.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

10.7.4 Pseudoinversa e regularização

A pseudoinversa de Moore–Penrose foi definida na Definição 6.11. Para uma matriz de covariâncias amostral com decomposição espectral reduzida

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que Λ_r contém os r autovalores positivos, tem-se

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.117)$$

A pseudoinversa e a regularização resolvem problemas matemáticos diferentes.

Para visualizar essa diferença, considere

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\ell_1, \dots, \ell_p) \mathbf{Q}^\top,$$

com

$$\ell_j \geq 0.$$

A pseudoinversa atribui os pesos

$$\begin{cases} 1/\ell_j, & \ell_j > 0, \\ 0, & \ell_j = 0. \end{cases}$$

Considere agora

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

com

$$0 < \lambda \leq 1 \quad \text{e} \quad \tau > 0.$$

Sua inversa é

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1 - \lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.118)$$

Se

$$\ell_j = 0,$$

a pseudoinversa atribui peso zero, enquanto a inversa regularizada atribui

$$\frac{1}{\lambda\tau}.$$

A pseudoinversa não modifica $\mathbf{S}$; ela substitui a inversão usual por sua extensão de Moore–Penrose. Os autovalores positivos continuam recebendo pesos $1/\ell_j$, mesmo quando são muito pequenos, enquanto as direções associadas a autovalores nulos recebem peso zero.

A regularização modifica a própria matriz utilizada para estimar Σ e define outro procedimento estatístico. Na contração esférica, os autovalores são afastados de zero e a inversão passa a utilizar pesos finitos determinados pelos autovalores regularizados. Portanto, pseudoinversa e regularização tratam a singularidade por mecanismos diferentes.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ ou por uma inversa regularizada modifica a estatística utilizada. Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica não podem ser transferidas automaticamente para essas substituições.

10.7.5 Sensibilidade e robustez

O vetor de médias e a matriz de covariâncias amostrais podem sofrer alterações arbitrariamente grandes quando uma observação é substituída por outra suficientemente afastada da maior parte dos dados (Maronna et al., 2019).

Considere a substituição de uma observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.119)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

A alteração não possui limite uniforme quando $\mathbf{x}_k^*$ pode se afastar arbitrariamente dos demais dados. Assim, uma única observação pode produzir uma mudança arbitrariamente grande na média amostral.

Na matriz de covariâncias, os produtos externos

$$(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

fazem com que observações afastadas possam modificar simultaneamente dispersões, covariâncias e direções espectrais.

Uma observação extrema não deve ser identificada automaticamente como erro. Ela pode representar uma unidade válida situada em uma região pouco frequente da população, uma observação proveniente de outra população ou um erro de registro ou medição. O comportamento extremo também pode indicar que a distribuição possui caudas mais pesadas, assimetria ou heterogeneidade não representadas pelo modelo adotado.

A decisão de manter, corrigir ou excluir uma observação exige conhecimento do processo de coleta e do contexto.

Estimadores robustos de localização e dispersão procuram limitar determinados tipos de sensibilidade. Sua comparação depende de quanto as estimativas se alteram diante de observações contaminadas, da eficiência sob o modelo adotado como referência, da equivariância, das condições de existência em função de n e p , do custo computacional e do parâmetro de localização ou dispersão que o procedimento pretende estimar. Nenhum procedimento apresenta o melhor desempenho em todos esses critérios.

Observações extremas, alta dimensão e má especificação correspondem a problemas diferentes. Observações extremas podem alterar fortemente estimadores sensíveis. A alta dimensão afeta o número de parâmetros a estimar, o posto e a estabilidade da matriz. A má especificação ocorre quando a distribuição ou a estrutura assumida pelo modelo não representa adequadamente o processo que gerou os dados. Esses problemas podem ocorrer simultaneamente, mas exigem tratamentos diferentes.

A avaliação de uma matriz de covariâncias estimada depende da finalidade da análise. Tamanho amostral e dimensão determinam restrições de posto; o espectro informa sobre direções de variabilidade e condicionamento; as escalas das variáveis influenciam a interpretação e a escolha de alvos de regularização; e a sensibilidade das estimativas deve ser considerada quando observações extremas ou desvios do modelo podem alterar substancialmente os resultados.

O exemplo integrado a seguir reúne os principais objetos construídos no capítulo em uma única amostra.

10.8 Exemplo integrado

O exemplo reúne a estimação da localização, da dispersão e das relações entre dois blocos de variáveis. Como os cálculos são realizados para uma amostra observada, os resultados numéricos são estimativas, representadas pelos correspondentes objetos observados.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 2 \\ 3 & 5 & 3 \\ 3 & 6 & 3 \\ 5 & 7 & 4 \\ 5 & 6 & 6 \\ 6 & 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 9 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A correspondência entre as linhas de $\mathbf{X}$ e $\mathbf{Y}$ precisa ser preservada para a estimação das covariâncias cruzadas.

Os valores foram escolhidos para que as médias sejam inteiras e os produtos cruzados possam ser calculados sem arredondamento. Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 6 \\ 4 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

As matrizes centralizadas são, portanto,

$$\mathbf{X}_c = \begin{bmatrix} -2 & -2 & -2 \\ -1 & -1 & -1 \\ -1 & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 2 \\ 2 & 2 & 2 \end{bmatrix}$$

e

$$\mathbf{Y}_c = \begin{bmatrix} -3 & -2 \\ -1 & -3 \\ 0 & 0 \\ 1 & 2 \\ -1 & -1 \\ 4 & 4 \end{bmatrix}.$$

Em ambas as matrizes, cada coluna soma zero, como exige a centralização pela média amostral.

Para o primeiro bloco, a matriz SQPC observada é

$$\mathbf{T}_X = \mathbf{X}_c^\top \mathbf{X}_c.$$

Os elementos da diagonal são somas de quadrados. Por exemplo,

$$t_{11} = (-2)^2 + (-1)^2 + (-1)^2 + 1^2 + 1^2 + 2^2 = 12.$$

Os elementos fora da diagonal são somas de produtos cruzados. Por exemplo,

$$\begin{aligned} t_{12} &= (-2)(-2) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(0) + (2)(2) \\ &= 10. \end{aligned}$$

Calculando os demais elementos da mesma forma,

$$\mathbf{T}_X = \begin{bmatrix} 12 & 10 & 12 \\ 10 & 10 & 9 \\ 12 & 9 & 14 \end{bmatrix}. \quad (10.120)$$

A simetria decorre de $t_{jk} = t_{kj}$, de modo que somente a diagonal e uma das partes triangulares precisam ser calculadas diretamente.

A matriz de covariâncias amostral utiliza o divisor

$$n - 1 = 5.$$

Logo,

$$\begin{aligned}\mathbf{S}_X &= \frac{1}{5}\mathbf{T}_X \\ &= \begin{bmatrix} 2,4 & 2,0 & 2,4 \\ 2,0 & 2,0 & 1,8 \\ 2,4 & 1,8 & 2,8 \end{bmatrix}.\end{aligned}\tag{10.121}$$

A matriz $\mathbf{S}_X$ é a realização observada do estimador não viesado $\mathbf{S}_X$ de Σ_{XX} , cujo não viesamento foi estabelecido na Equação 10.69.

Sob o modelo normal multivariado definido na Definição 9.1, nesta amostra

$$\text{posto}(\mathbf{T}_X) = 3.$$

Portanto, a condição de posto completo da Proposição 10.3 é satisfeita. Assim, a estimativa de máxima verossimilhança da matriz de covariâncias é

$$\begin{aligned}\widehat{\Sigma}_{XX, \text{MV, obs}} &= \frac{1}{6}\mathbf{T}_X \\ &= \begin{bmatrix} 2 & 5/3 & 2 \\ 5/3 & 5/3 & 3/2 \\ 2 & 3/2 & 7/3 \end{bmatrix}.\end{aligned}\tag{10.122}$$

As duas matrizes estão relacionadas por

$$\widehat{\Sigma}_{XX, \text{MV, obs}} = \frac{5}{6}\mathbf{S}_X.$$

Como diferem apenas pelo fator escalar positivo $5/6$, possuem os mesmos autovetores e o mesmo posto. Seus autovalores diferem pelo fator $5/6$, enquanto o número de condição espectral permanece inalterado.

Em cálculos manuais, os valores exatos devem ser mantidos enquanto possível. Por isso, a estimativa de máxima verossimilhança foi apresentada em forma fracionária. O arredondamento deve ser realizado apenas na apresentação dos resultados que não admitem uma representação exata simples. Utilizar valores já arredondados de médias, covariâncias, correlações ou autovetores em cálculos posteriores pode acumular erros e produzir resultados diferentes dos obtidos a partir dos valores exatos.

Neste exemplo, $\mathbf{T}_X$ é exata e $\mathbf{S}_X = \mathbf{T}_X/5$ possui representação decimal finita. Para calcular correlações, pode-se utilizar diretamente

$$r_{jk} = \frac{t_{jk}}{\sqrt{t_{jj}t_{kk}}},$$

pois o divisor comum de $\mathbf{S}_X$ se cancela. Autovalores e números de condição apresentados em forma decimal devem ser calculados com os valores não arredondados e arredondados apenas ao final.

A matriz de correlações observada é

$$\mathbf{R}_X \approx \begin{bmatrix} 1,000 & 0,913 & 0,926 \\ 0,913 & 1,000 & 0,761 \\ 0,926 & 0,761 & 1,000 \end{bmatrix}. \quad (10.123)$$

As três correlações são positivas. A maior ocorre entre X_1 e X_3 ,

$$r_{13} \approx 0,926,$$

e a menor entre X_2 e X_3 ,

$$r_{23} \approx 0,761.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 \approx 6,579, \quad \ell_2 \approx 0,560 \quad \text{e} \quad \ell_3 \approx 0,061.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e

$$\mathbf{S}_X \succ \mathbf{0}.$$

Seu número de condição espectral é aproximadamente

$$\kappa_2(\mathbf{S}_X) = \frac{\ell_1}{\ell_3} \approx 108,3.$$

O valor de $\kappa_2(\mathbf{S}_X)$ foi calculado com os autovalores antes do arredondamento. Dividir os valores exibidos, já arredondados, pode produzir uma aproximação ligeiramente diferente.

Portanto, $\mathbf{S}_X$ é invertível, mas seus autovalores apresentam magnitudes bastante distintas. O valor relativamente elevado de $\kappa_2(\mathbf{S}_X)$ mostra que invertibilidade e bom condicionamento são propriedades distintas.

Para estimar as relações entre os dois blocos, utiliza-se

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c.$$

Por exemplo, o elemento correspondente a X_1 e Y_1 é

$$\begin{aligned} t_{X_1 Y_1} &= (-2)(-3) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(-1) + (2)(4) \\ &= 15. \end{aligned}$$

Os demais produtos cruzados fornecem

$$\mathbf{T}_{XY} = \begin{bmatrix} 15 & 16 \\ 16 & 17 \\ 13 & 13 \end{bmatrix}. \quad (10.124)$$

Logo, pela definição de covariância cruzada observada na Definição 8.13,

$$\mathbf{S}_{XY} = \frac{1}{5} \mathbf{T}_{XY} = \begin{bmatrix} 3,0 & 3,2 \\ 3,2 & 3,4 \\ 2,6 & 2,6 \end{bmatrix}. \quad (10.125)$$

Por exemplo,

$$s_{X_3 Y_1} = 2,6$$

é a covariância amostral entre X_3 e Y_1 .

A inversão da ordem dos blocos segue Equação 8.73:

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 3,0 & 3,2 & 2,6 \\ 3,2 & 3,4 & 2,6 \end{bmatrix}.$$

Para o segundo bloco,

$$\mathbf{T}_Y = \mathbf{Y}_c^\top \mathbf{Y}_c = \begin{bmatrix} 28 & 28 \\ 28 & 34 \end{bmatrix},$$

de modo que

$$\mathbf{S}_Y = \frac{1}{5} \mathbf{T}_Y = \begin{bmatrix} 5,6 & 5,6 \\ 5,6 & 6,8 \end{bmatrix}.$$

Reunindo as cinco variáveis,

$$\mathbf{X}_{\text{conj}} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

a matriz SQPC conjunta possui a forma em blocos

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} \mathbf{T}_X & \mathbf{T}_{XY} \\ \mathbf{T}_{YX} & \mathbf{T}_Y \end{bmatrix}.$$

Numericamente,

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} 12 & 10 & 12 & 15 & 16 \\ 10 & 10 & 9 & 16 & 17 \\ 12 & 9 & 14 & 13 & 13 \\ 15 & 16 & 13 & 28 & 28 \\ 16 & 17 & 13 & 28 & 34 \end{bmatrix}.$$

Como $n - 1 = 5$,

$$\mathbf{S}_{\text{conj}} = \frac{1}{5} \mathbf{T}_{\text{conj}} = \begin{bmatrix} 2,4 & 2,0 & 2,4 & 3,0 & 3,2 \\ 2,0 & 2,0 & 1,8 & 3,2 & 3,4 \\ 2,4 & 1,8 & 2,8 & 2,6 & 2,6 \\ 3,0 & 3,2 & 2,6 & 5,6 & 5,6 \\ 3,2 & 3,4 & 2,6 & 5,6 & 6,8 \end{bmatrix}. \quad (10.126)$$

A organização em blocos permite identificar diretamente as covariâncias internas de $\mathbf{X}$, as covariâncias internas de $\mathbf{Y}$ e as covariâncias cruzadas entre os dois conjuntos.

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_{\text{conj}}) \leq 5.$$

A matriz conjunta centralizada é

$$\mathbf{X}_{\text{conj},c} = \begin{bmatrix} -2 & -2 & -2 & -3 & -2 \\ -1 & -1 & -1 & -1 & -3 \\ -1 & 0 & -1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 2 \\ 1 & 0 & 2 & -1 & -1 \\ 2 & 2 & 2 & 4 & 4 \end{bmatrix}.$$

Seu escalonamento fornece cinco pivôs, de modo que

$$\text{posto}(\mathbf{X}_{\text{conj},c}) = 5.$$

Como

$$\mathbf{T}_{\text{conj}} = \mathbf{X}_{\text{conj},c}^{\top} \mathbf{X}_{\text{conj},c},$$

segue de Equação 8.60 que

$$\text{posto}(\mathbf{S}_{\text{conj}}) = 5.$$

Portanto,

$$\mathbf{S}_{\text{conj}} \succ \mathbf{0}.$$

O caso $n = 6$ e $p = 5$ está exatamente no limite $n = p + 1$. Esse tamanho amostral permite posto completo, mas não o garante para uma amostra arbitrária.

O exemplo mostra como uma única amostra produz realizações dos principais objetos definidos no capítulo. Os vetores $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ estimam as médias populacionais, enquanto $\mathbf{T}_X$ é a realização da estatística SQPC. A divisão de $\mathbf{T}_X$ por $n - 1$ produz a estimativa não viesada $\mathbf{S}_X$; a divisão por n produz a estimativa pelo método dos momentos e, sob o modelo normal e as condições de existência do máximo, também a estimativa de máxima verossimilhança.

A matriz $\mathbf{R}_X$ utiliza a mesma informação de covariância após a remoção das escalas marginais. O posto completo de $\mathbf{S}_X$ garante sua invertibilidade, mas o número de condição mostra que essa propriedade não garante estabilidade da inversão.

O pareamento das linhas de $\mathbf{X}$ e $\mathbf{Y}$ determina os produtos cruzados em $\mathbf{T}_{XY}$ e, conseqüentemente, as covariâncias em $\mathbf{S}_{XY}$. A matriz conjunta reúne em um único objeto as covariâncias internas dos dois blocos e as covariâncias entre eles.

Todos os valores apresentados são realizações obtidas nesta amostra. Não viesamento, consistência, eficiência e outras propriedades dos estimadores descrevem seu comportamento ao considerar as possíveis amostras geradas pelo modelo.

10.9 Síntese do capítulo

Este capítulo estabeleceu a relação entre parâmetros populacionais, estatísticas amostrais, estimadores e suas realizações observadas.

A distinção central envolve quatro objetos. O parâmetro θ é uma característica fixa da distribuição populacional. Uma amostra aleatória $\mathcal{X}$ produz estatísticas por meio de funções dos dados,

$$\mathbf{G} = G(\mathcal{X}).$$

Quando uma estatística é utilizada para estimar θ , ela constitui um estimador,

$$\hat{\theta} = G(\mathcal{X}).$$

Após a observação da amostra, a realização

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X})$$

é a estimativa do parâmetro. Portanto, todo estimador é uma estatística, mas nem toda estatística é utilizada como estimador.

Para uma amostra multivariada i.i.d., o vetor de médias amostrais estima μ , enquanto a matriz de covariâncias amostral estima Σ :

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

e

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

em que $\mathbf{T}$ é a matriz SQPC amostral definida na Definição 10.13.

O método dos momentos e a máxima verossimilhança são princípios de construção de estimadores. O método utilizado não determina, por si só, as propriedades do estimador obtido.

O método dos momentos fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}$$

e

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado e quando o máximo existe, a máxima verossimilhança conduz às mesmas estatísticas.

A segunda estatística é viesada em amostras finitas, enquanto

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é não viesada. As duas são consistentes para Σ no regime de dimensão fixa sob as condições estabelecidas no capítulo.

Os resultados na Proposição 10.6 e Equação 10.69 fornecem

$$E(\bar{\mathbf{X}}) = \mu, \quad \text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}, \quad E(\mathbf{S}) = \Sigma.$$

No regime de dimensão fixa, Proposição 10.7 e Proposição 10.12 estabelecem

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad \text{e} \quad \mathbf{S} \xrightarrow{P} \Sigma.$$

Para variáveis organizadas em dois blocos pareados,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}$$

estima a matriz de covariâncias cruzadas. Quando as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}$$

fornece a matriz de correlações amostral.

A Tabela 10.2 reúne os principais objetos do capítulo.

Tabela 10.2: Relação entre parâmetros, estatísticas, estimadores e valores observados utilizados no capítulo.

Parâmetro ou objeto	Estatística/estimador	Propriedade destacada	Valor observado
μ	$\bar{\mathbf{X}}$	Não viesado e consistente; MM; MV sob normalidade e existência do máximo	$\bar{\mathbf{x}}$
Σ	$\mathbf{S} = \mathbf{T}/(n-1)$	Não viesado e consistente	$\mathbf{S}$
Σ	$\mathbf{T}/n$	MM; MV sob normalidade e existência do máximo; viesado em amostras finitas e consistente	$\mathbf{T}/n$
SQPC amostral	$\mathbf{T}$	Estatística que reúne somas de quadrados e produtos cruzados	$\mathbf{T}$
Σ_{XY}	$\mathbf{S}_{XY}$	Não viesado e consistente	$\mathbf{S}_{XY}$
$\mathcal{R}$	$\mathbf{R}$	Em geral viesado, mas consistente; MV sob normalidade e existência do máximo	$\mathbf{R}$

As propriedades estudadas respondem a perguntas diferentes. O viés compara a esperança do estimador com o parâmetro; a variabilidade descreve quanto o estimador muda entre amostras; o erro quadrático médio combina erro sistemático e variabilidade segundo uma função de perda; a consistência descreve o comportamento quando n aumenta; e a eficiência compara estimadores concorrentes segundo sua variabilidade ou risco. A suficiência verifica se uma redução da amostra preserva a informação sobre o parâmetro, enquanto a equivariância descreve a resposta do estimador a transformações dos dados. A robustez examina quanto o procedimento pode ser alterado pelas formas de contaminação ou perturbação consideradas.

A estrutura de posto

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1)$$

mostra por que dimensão e tamanho amostral precisam ser considerados conjuntamente. Quando $p \geq n$, a covariância amostral é necessariamente singular. Mesmo quando existe uma inversa, seu uso pode ser instável quando alguns autovalores são pequenos.

Pseudoinversa e regularização tratam singularidade e condicionamento por mecanismos diferentes. A pseudoinversa mantém $\mathbf{S}$ e modifica a operação utilizada para trabalhar com suas direções de variância nula. A regularização substitui $\mathbf{S}$ por outro estimador, por exemplo combinando-a com uma matriz-alvo. Essa modificação pode afastar autovalores de zero e melhorar o condicionamento, mas também altera viés, risco e consistência. Com peso de contração fixo e alvo diferente de Σ , a consistência para Σ não é garantida.

Ao término deste capítulo, deve-se ser capaz de:

- distinguir parâmetro, estatística, estimador, estimativa e distribuição amostral;
- avaliar viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência, equivariância e robustez;
- distinguir os princípios do método dos momentos e da máxima verossimilhança;
- construir o vetor de médias amostrais, a matriz SQPC e os estimadores da matriz de covariâncias;
- explicar a origem e a função dos divisores n e $n - 1$;
- construir estimadores de covariâncias cruzadas e correlações;
- analisar posto, singularidade e condicionamento de matrizes estimadas;
- distinguir pseudoinversa, regularização e estimação robusta segundo o problema que cada procedimento procura tratar.

O Capítulo 11 utiliza a matriz de covariâncias populacional de Definição 8.2, o modelo normal multivariado de Definição 9.1 e os estimadores desenvolvidos neste capítulo para construir o **modelo linear multivariado**. Nesse modelo, várias variáveis-resposta são relacionadas simultaneamente a uma matriz de delineamento, produzindo uma matriz de parâmetros, valores ajustados, resíduos e matrizes SQPC associadas às fontes de variação.

11 Modelo Linear Multivariado e Hipóteses Lineares

O Capítulo 10 desenvolveu a estimação do vetor de médias e da matriz de covariâncias a partir de uma amostra aleatória multivariada. O vetor de médias amostrais e suas propriedades foram estabelecidos em Proposição 10.6, enquanto a matriz de covariâncias amostral foi definida em Definição 10.14 e seu não viesamento foi estabelecido em Proposição 10.11. Nesse contexto, todas as unidades compartilhavam o mesmo vetor de médias populacional.

O modelo linear multivariado substitui essa média comum por uma estrutura de médias que pode variar entre as unidades segundo características conhecidas. Essa formulação permite representar, em um mesmo modelo, regressões com várias respostas, comparações entre grupos, efeitos de fatores e efeitos de covariáveis.

O modelo é escrito como

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

em que:

- $\mathbf{y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

Aqui, n é o número de unidades, p é o número de respostas observadas em cada unidade e q é o número de termos representados na matriz de delineamento. Esses termos podem incluir intercepto, indicadores de grupos ou tratamentos e covariáveis quantitativas.

O objetivo deste capítulo é formular o modelo, estimar $\mathbf{B}$, interpretar valores ajustados e resíduos por meio de projeções, construir a SQPC residual, estimar a matriz de covariâncias dos erros, decompor a dispersão observada e representar hipóteses lineares sobre parâmetros e combinações das respostas (Rencher; Christensen, 2012).

No caso de grupos, essa estrutura relacionará a variação residual e a variação associada ao modelo às matrizes de dispersão intragrupos e entre grupos definidas em Definição 8.14 e Definição 8.15.

As distribuições amostrais utilizadas na construção de testes e regiões de confiança serão desenvolvidas no Capítulo 12.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{Y}_i \in \mathbb{R}^p$ representa o vetor aleatório de respostas da unidade i ;
- $\mathbf{y}_i \in \mathbb{R}^p$ representa uma realização desse vetor;
- $\mathbf{y} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de respostas;
- $\mathbf{Y} \in \mathbb{R}^{n \times p}$ representa a matriz observada de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ representa a matriz de delineamento;
- $\mathbf{z}_i^\top$ representa a linha i de $\mathbf{Z}$;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ representa a matriz de parâmetros;
- $\varepsilon_i \in \mathbb{R}^p$ representa o vetor aleatório de erros da unidade i ;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de erros;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias entre as respostas de uma mesma unidade;
- $\widehat{\mathbf{B}}$ representa um estimador de $\mathbf{B}$;
- $\widehat{\mathbf{U}}$ representará a matriz aleatória de resíduos e $\widehat{\mathbf{U}}$ sua realização observada;
- $\mathbf{E}_{\text{res}}$ representará a SQPC residual como estatística aleatória e $\mathbf{E}$ sua realização observada;
- $\mathbf{T}$ continuará representando a SQPC total observada;
- $\mathbf{T}_{\text{mod}}$ representará a dispersão dos valores ajustados pelo modelo em torno da média geral;
- $\mathbf{H}$ ficará reservada à SQPC associada a uma hipótese linear.

A letra $\mathbf{Z}$ é utilizada para o delineamento para preservar $\mathbf{X}$ como símbolo da matriz de dados nos capítulos anteriores.

11.1 Formulação do modelo linear multivariado

11.1.1 Resposta vetorial e matriz de respostas

No modelo linear univariado, cada unidade fornece uma única resposta. No caso multivariado, a unidade i fornece simultaneamente

$$\mathbf{Y}_i = \begin{bmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{ip} \end{bmatrix} \in \mathbb{R}^p. \quad (11.1)$$

As componentes podem apresentar dependência. O modelo deve, portanto, representar simultaneamente:

1. a estrutura das médias das p respostas;
2. a variabilidade de cada resposta;
3. as covariâncias entre respostas observadas na mesma unidade.

Considere

$$\mathbf{z}_i = \begin{bmatrix} z_{i1} \\ \vdots \\ z_{iq} \end{bmatrix} \in \mathbb{R}^q,$$

contendo os valores dos q termos do modelo para a unidade i .

Um termo pode representar, por exemplo, o intercepto, o pertencimento a um grupo ou tratamento, o valor de uma covariável quantitativa ou outro efeito especificado no modelo. A matriz de delineamento reúne essas informações para todas as unidades.

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1p} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qp} \end{bmatrix} \in \mathbb{R}^{q \times p}. \quad (11.2)$$

A coluna j de $\mathbf{B}$ contém os coeficientes do modelo para a resposta j . A linha h reúne os coeficientes associados ao mesmo termo da matriz de delineamento para as p respostas.

Assim, uma covariável ou um efeito de grupo pode atuar de maneira diferente sobre cada resposta, embora todas utilizem a mesma matriz $\mathbf{Z}$.

A média condicional do vetor de respostas da unidade i é

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i. \quad (11.3)$$

Equivalentemente, em forma de vetor linha,

$$E(\mathbf{Y}_i^\top \mid \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{B}.$$

Definição 11.1 (Modelo linear multivariado para uma unidade). O vetor de respostas da unidade i é representado por

$$\mathbf{Y}_i = \mathbf{B}^\top \mathbf{z}_i + \varepsilon_i, \quad (11.4)$$

em que

$$\mathbf{Y}_i, \varepsilon_i \in \mathbb{R}^p, \quad \mathbf{z}_i \in \mathbb{R}^q, \quad \mathbf{B} \in \mathbb{R}^{q \times p}.$$

Componente a componente,

$$Y_{ij} = \mathbf{z}_i^\top \beta_j + \varepsilon_{ij}, \quad j = 1, \dots, p, \quad (11.5)$$

em que β_j é a coluna j de $\mathbf{B}$.

As equações das diferentes respostas compartilham a mesma matriz de delineamento. O carácter multivariado do modelo decorre da análise conjunta dessas respostas e da estrutura de covariâncias dos respectivos erros.

Para reunir as n unidades, defina a matriz aleatória

Definição 11.2 (Matriz aleatória de respostas).

$$\mathbf{y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \mathbf{Y}_2^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} = \begin{bmatrix} Y_{11} & \dots & Y_{1p} \\ Y_{21} & \dots & Y_{2p} \\ \vdots & \ddots & \vdots \\ Y_{n1} & \dots & Y_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.6)$$

Após a observação,

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.7)$$

A matriz de delineamento é

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times q}. \quad (11.8)$$

Neste capítulo, o modelo e os resultados de estimação são formulados condicionalmente a $\mathbf{Z}$. Assim, a matriz de delineamento é tratada como conhecida. Essa convenção abrange tanto delineamentos fixados previamente quanto análises condicionais aos valores observados das variáveis explicativas.

11.1.2 Estrutura matricial do modelo

Organize os vetores de erros nas linhas de

$$\mathcal{E} = \begin{bmatrix} \varepsilon_1^\top \\ \vdots \\ \varepsilon_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.9)$$

Definição 11.3 (Modelo linear multivariado). O modelo linear multivariado é

$$\mathcal{Y} = \mathbf{ZB} + \mathcal{E}. \quad (11.10)$$

em que:

- $\mathcal{Y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

A matriz de médias condicionais é

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}. \quad (11.11)$$

Portanto, a estrutura sistemática do modelo pertence ao espaço coluna de $\mathbf{Z}$. Cada coluna de

$$\mathbf{ZB}$$

é uma combinação linear das colunas do delineamento.

Se

$$r = \text{posto}(\mathbf{Z}), \quad (11.12)$$

então

$$r \leq \min(n, q).$$

O valor r é o número de colunas linearmente independentes de $\mathbf{Z}$ e, portanto, a dimensão do espaço de médias representado pelo delineamento.

Quando

$$r = q,$$

a matriz de delineamento possui posto coluna completo. O caso $r < q$ será examinado posteriormente, quando forem discutidas a unicidade dos coeficientes e as funções estimáveis.

11.1.3 Estrutura de médias e covariâncias residuais

A primeira condição do modelo é

Definição 11.4 (Média residual nula).

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}, \quad i = 1, \dots, n. \quad (11.13)$$

Consequentemente,

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i.$$

A segunda condição descreve a dependência entre as respostas de uma mesma unidade e entre unidades distintas.

Definição 11.5 (Estrutura de covariâncias dos erros). Para cada unidade,

$$\varepsilon_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

e assume-se que os segundos momentos condicionais existem.

A matriz de covariâncias condicional é comum às unidades:

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n, \quad (11.14)$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0}.$$

Além disso,

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}_{p \times p}, \quad i \neq \ell. \quad (11.15)$$

A matriz

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix}$$

é a matriz de covariâncias residuais entre as p respostas.

Assim,

$$\text{Var}(Y_{ij} | \mathbf{Z}) = \sigma_{jj},$$

e, para duas respostas da mesma unidade,

$$\text{Cov}(Y_{ij}, Y_{ik} | \mathbf{Z}) = \sigma_{jk}.$$

A expressão “covariância residual” indica a variabilidade que permanece após a estrutura de médias $\mathbf{ZB}$ ter sido especificada. Ela não deve ser confundida com a covariância marginal das respostas quando suas médias variam entre unidades.

As condições anteriores implicam que a dependência entre respostas é permitida **dentro de uma unidade**, enquanto erros de unidades distintas são não correlacionados. Sob normalidade conjunta, a covariância cruzada nula entre unidades implica independência por Proposição 9.6.

11.1.4 Forma vetorizada

A forma matricial

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$$

será a representação principal do modelo neste capítulo. Quando for necessário reunir todas as respostas em um único vetor, podem ser utilizados o operador vec e o produto de Kronecker definidos em Definição 7.9 e Definição 7.10.

Pela identidade de Proposição 7.15,

$$\text{vec}(\mathbf{ZB}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \quad (11.16)$$

de modo que

$$\text{vec}(\mathbf{y}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}) + \text{vec}(\mathcal{E}). \quad (11.17)$$

Proposição 11.1 (Covariância do erro vetorizado). *Se*

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

então

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.18)$$

Consequentemente,

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.19)$$

A forma vetorizada será utilizada como representação auxiliar em resultados de covariância e distribuição. Os cálculos de ajuste, resíduos e decomposição da variação serão desenvolvidos diretamente na forma matricial.

11.1.5 Distribuição normal matricial

A normalidade não é necessária para definir o modelo linear multivariado nem para obter os resultados de mínimos quadrados desenvolvidos neste capítulo. Ela será utilizada para obter distribuições amostrais exatas no Capítulo 12.

A distribuição normal matricial fornece uma notação compacta para representar conjuntamente a distribuição das linhas e das colunas de uma matriz aleatória (Gupta; Nagar, 1999).

Definição 11.6 (Distribuição normal matricial). *Se*

$$\mathcal{A} \in \mathbb{R}^{n \times p},$$

diz-se que

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V})$$

quando

$$\text{vec}(\mathcal{A}) \sim N_{np}[\text{vec}(\Xi), \mathbf{V} \otimes \mathbf{U}]. \quad (11.20)$$

Aqui,

$$\Xi \in \mathbb{R}^{n \times p}, \quad \mathbf{U} \in \mathbb{R}^{n \times n}, \quad \mathbf{V} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{U} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{V} \succeq \mathbf{0}.$$

A distribuição normal multivariada utilizada no lado direito de Equação 11.20 é a distribuição definida em Definição 9.1.

Neste capítulo será utilizado apenas o caso em que

$$\mathbf{U} = \mathbf{I}_n$$

e

$$\mathbf{V} = \Sigma.$$

A matriz $\mathbf{I}_n$ representa a ausência de dependência entre unidades, enquanto Σ representa as covariâncias entre as p respostas de uma mesma unidade.

Definição 11.7 (Modelo linear normal multivariado). Considere

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p},$$

e

$$\mathcal{E} \in \mathbb{R}^{n \times p}.$$

Se

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0},$$

o modelo linear normal multivariado é definido por

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}_{n \times p}, \mathbf{I}_n, \Sigma). \quad (11.21)$$

Equivalentemente,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma). \quad (11.22)$$

Pela definição da normal matricial,

$$\text{vec}(\mathbf{y}) \mid \mathbf{Z} \sim N_{np}[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n]. \quad (11.23)$$

A mesma estrutura pode ser lida por unidade:

$$\mathbf{Y}_i \mid \mathbf{Z} \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n, \quad (11.24)$$

com independência condicional entre as unidades.

A matriz Σ continua desempenhando o papel estabelecido nos Capítulos 8 e 9: suas diagonais são as variâncias residuais das respostas e seus elementos fora da diagonal descrevem a dependência linear residual entre elas.

Para uma resposta específica j , a coluna correspondente satisfaz

$$\mathbf{Y}_{\cdot j} \mid \mathbf{Z} \sim N_n(\mathbf{Z}\beta_j, \sigma_{jj}\mathbf{I}_n). \quad (11.25)$$

Para duas respostas j e k ,

$$\text{Cov}(\mathbf{Y}_{\cdot j}, \mathbf{Y}_{\cdot k} \mid \mathbf{Z}) = \sigma_{jk}\mathbf{I}_n. \quad (11.26)$$

Assim, ajustar separadamente as p equações produz os mesmos estimadores de mínimos quadrados para os coeficientes quando todas utilizam a mesma matriz $\mathbf{Z}$. A formulação conjunta mantém explícita a covariância entre as respostas e permite formular posteriormente hipóteses que envolvem várias respostas simultaneamente.

Sob normalidade, a mesma estrutura também permite relacionar mínimos quadrados e máxima verossimilhança. Essa relação será desenvolvida após a obtenção do estimador de $\mathbf{B}$.

11.1.6 Transformações da resposta

Uma transformação linear das respostas preserva a estrutura do modelo.

Considere

$$\mathbf{W}_i = \mathbf{A}^\top \mathbf{Y}_i,$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times s}.$$

Em forma matricial,

$$\mathcal{W} = \mathcal{Y} \mathbf{A}.$$

Logo,

$$\mathcal{W} = \mathbf{Z}(\mathbf{B}\mathbf{A}) + \mathcal{E}\mathbf{A}. \quad (11.27)$$

A matriz de parâmetros transformada é

$$\mathbf{B}_W = \mathbf{B}\mathbf{A},$$

e a matriz de covariâncias residuais é

$$\Sigma_W = \mathbf{A}^\top \Sigma \mathbf{A},$$

em concordância com Proposição 8.6.

Sob normalidade, Proposição 9.4 fornece

$$\mathcal{W} \mid \mathbf{Z} \sim N_{n \times s}(\mathbf{Z}\mathbf{B}\mathbf{A}, \mathbf{I}_n, \mathbf{A}^\top \Sigma \mathbf{A}). \quad (11.28)$$

Essa propriedade será utilizada posteriormente para formular hipóteses sobre combinações lineares das respostas.

O modelo está agora especificado em termos de sua estrutura de médias e de covariâncias. A próxima etapa é estimar a matriz de parâmetros $\mathbf{B}$ a partir da matriz observada de respostas.

11.2 Estimação da matriz de parâmetros

A estimação de $\mathbf{B}$ consiste em determinar a estrutura de médias

$$\mathbf{ZB}$$

que melhor aproxima a matriz observada de respostas $\mathbf{Y}$ segundo o critério adotado.

Como todas as respostas utilizam a mesma matriz de delineamento, cada coluna de $\mathbf{B}$ pode ser estimada pelo modelo linear correspondente àquela resposta. A formulação matricial reúne os p ajustes e mantém explícita a estrutura necessária para estudar conjuntamente os coeficientes e a covariância residual entre as respostas (Rencher; Christensen, 2012).

11.2.1 Mínimos quadrados

Considere uma matriz candidata

$$\mathbf{B}^* \in \mathbb{R}^{q \times p}.$$

A matriz de resíduos correspondente é

$$\mathbf{Y} - \mathbf{ZB}^*.$$

Definição 11.8 (Critério de mínimos quadrados multivariado). O critério de mínimos quadrados é

$$Q(\mathbf{B}^*) = \|\mathbf{Y} - \mathbf{ZB}^*\|_F^2. \quad (11.29)$$

Equivalentemente,

$$Q(\mathbf{B}^*) = \text{tr} \left[(\mathbf{Y} - \mathbf{ZB}^*)^\top (\mathbf{Y} - \mathbf{ZB}^*) \right]. \quad (11.30)$$

A norma de Frobenius foi definida em Definição 6.7. Neste problema,

$$Q(\mathbf{B}^*) = \sum_{j=1}^p \|\mathbf{y}_{\cdot j} - \mathbf{Zb}_j^*\|^2, \quad (11.31)$$

em que $\mathbf{y}_{\cdot j}$ é a coluna j de $\mathbf{Y}$ e $\mathbf{b}_j^*$ é a coluna correspondente de $\mathbf{B}^*$.

Portanto, minimizar $Q(\mathbf{B}^*)$ equivale a minimizar separadamente a soma de quadrados residual de cada uma das p respostas.

Por essa razão, as covariâncias fora da diagonal de Σ não participam da obtenção do estimador de mínimos quadrados de $\mathbf{B}$ quando todas as respostas utilizam a mesma matriz $\mathbf{Z}$. Elas determinam, porém, a covariância entre os estimadores de respostas distintas e serão utilizadas na estimação da covariância residual e nas hipóteses que envolvem várias respostas simultaneamente.

As equações normais e sua derivação por cálculo matricial foram estabelecidas em Definição 3.21 e Proposição 7.6. Aplicadas ao modelo atual, elas assumem a forma

$$\mathbf{Z}^\top \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.32)$$

Equivalentemente,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}}) = \mathbf{0}_{q \times p}. \quad (11.33)$$

Se

$$\widehat{\mathbf{U}} = \mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}},$$

então

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}. \quad (11.34)$$

Cada coluna da matriz de resíduos é, portanto, ortogonal ao espaço coluna de $\mathbf{Z}$. Essa propriedade é a versão multivariada da decomposição de mínimos quadrados estabelecida em Proposição 3.18.

11.2.2 Estimador sob posto completo

Suponha

$$\text{posto}(\mathbf{Z}) = q. \quad (11.35)$$

Nesse caso,

$$q \leq n$$

e

$$\mathbf{Z}^\top \mathbf{Z} \succ \mathbf{0}.$$

Proposição 11.2 (Estimador de mínimos quadrados sob posto completo). *Se*

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de mínimos quadrados de $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.36)$$

Após a observação das respostas,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (11.37)$$

A unicidade do minimizador decorre da definição positiva de

$$\mathbf{Z}^\top \mathbf{Z}.$$

A convexidade do critério e a caracterização do minimizador global por meio das equações normais foram desenvolvidas em Proposição 7.9 e não precisam ser novamente demonstradas aqui.

Para a resposta j , a coluna correspondente é

$$\hat{\beta}_j = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{\cdot j}, \quad (11.38)$$

em que

$$\mathbf{Y}_{\cdot j} = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{nj} \end{bmatrix}.$$

Assim, cada coluna de $\widehat{\mathbf{B}}$ coincide com o estimador de mínimos quadrados obtido para a resposta correspondente. A formulação matricial reúne esses estimadores em um único objeto.

11.2.3 Esperança e matriz de covariâncias

Substituindo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

em Equação 11.36,

$$\begin{aligned}\widehat{\mathbf{B}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.\end{aligned}\tag{11.39}$$

A segunda parcela representa o erro de estimação.

Proposição 11.3 (Esperança e covariância do estimador da matriz de parâmetros). *Considere*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

Se

$$\text{posto}(\mathbf{Z}) = q,$$

então

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}\tag{11.40}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.\tag{11.41}$$

Comprovação. De Equação 11.39 e da condição

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

segue imediatamente que

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}.$$

Para a covariância, defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então,

$$\widehat{\mathbf{B}} - \mathbf{B} = \mathbf{A}_Z \mathcal{E}.$$

Pela identidade de vetorização em Proposição 7.15,

$$\text{vec}(\widehat{\mathbf{B}} - \mathbf{B}) = (\mathbf{I}_p \otimes \mathbf{A}_Z) \text{vec}(\mathcal{E}).$$

Aplicando a estrutura de covariâncias dos erros,

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{A}_Z \mathbf{A}_Z^\top).$$

Como

$$\mathbf{A}_Z \mathbf{A}_Z^\top = (\mathbf{Z}^\top \mathbf{Z})^{-1},$$

obtém-se Equação 11.41. □

O resultado mostra duas fontes distintas de variabilidade:

$$\Sigma$$

descreve a variabilidade residual e a associação entre as respostas, enquanto

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a precisão dos coeficientes.

Para duas respostas j e k ,

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k | \mathbf{Z}) = \sigma_{jk} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.42)$$

Para $j = k$,

$$\text{Cov}(\hat{\beta}_j | \mathbf{Z}) = \sigma_{jj} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.43)$$

Assim, estimadores associados a respostas diferentes são correlacionados sempre que os erros dessas respostas apresentam covariância residual diferente de zero.

11.2.4 Relação com máxima verossimilhança

Sob o modelo linear normal multivariado, a log-verossimilhança para uma matriz observada de respostas $\mathbf{Y}$, a menos de termos que não dependem dos parâmetros, const é

$$\begin{aligned} \ell(\mathbf{B}, \Sigma; \mathbf{Y}) = \text{const} - \frac{n}{2} \log \det(\Sigma) \\ - \frac{1}{2} \text{tr} [\Sigma^{-1} (\mathbf{Y} - \mathbf{ZB})^\top (\mathbf{Y} - \mathbf{ZB})]. \end{aligned} \quad (11.44)$$

Para $\Sigma \succ \mathbf{0}$ fixada, o primeiro termo não depende de $\mathbf{B}$. Portanto, maximizar a log-verossimilhança em relação a $\mathbf{B}$ equivale a minimizar o termo quadrático residual.

Aplicando ao termo quadrático residual o procedimento de diferenciação matricial utilizado em Proposição 7.6, obtém-se

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ é invertível,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) = \mathbf{0},$$

que coincide com a equação normal de mínimos quadrados em Equação 11.33.

Proposição 11.4 (Mínimos quadrados e máxima verossimilhança). *Considere o modelo linear normal multivariado com*

$$\text{posto}(\mathbf{Z}) = q.$$

Para qualquer $\Sigma \succ \mathbf{0}$ fixada, o maximizador da verossimilhança em relação a $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Consequentemente, sempre que o estimador de máxima verossimilhança conjunto de

$$(\mathbf{B}, \Sigma)$$

existir no espaço paramétrico considerado,

$$\widehat{\mathbf{B}}_{\text{MV}} = \widehat{\mathbf{B}}. \quad (11.45)$$

A coincidência ocorre porque todas as respostas utilizam a mesma matriz de delineamento $\mathbf{Z}$ e porque Σ atua sobre a dependência entre as respostas, não sobre a estrutura entre as unidades.

Assim, Σ determina a covariância conjunta dos coeficientes estimados, mas não modifica a expressão de $\widehat{\mathbf{B}}$.

Esse resultado depende da estrutura do modelo e não se transfere automaticamente para situações em que as respostas utilizam delineamentos diferentes ou em que existe dependência residual entre unidades.

A existência do estimador conjunto de máxima verossimilhança da matriz de covariâncias será examinada na seção dedicada à SQPC residual.

11.2.5 Modelo contendo somente intercepto

O modelo mais simples ocorre quando todas as unidades possuem o mesmo vetor de médias:

$$\mathbf{Y}_i = \mu + \varepsilon_i, \quad i = 1, \dots, n. \quad (11.46)$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Como

$$\mathbf{Z}^\top \mathbf{Z} = n,$$

tem-se

$$\widehat{\mathbf{B}} = \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} = \bar{\mathbf{Y}}^\top. \quad (11.47)$$

Após a observação,

$$\widehat{\mathbf{B}}_{\text{obs}} = \bar{\mathbf{y}}^\top.$$

Portanto, Equação 11.47 recupera o estimador do vetor de médias estudado em Proposição 10.6.

Além disso,

$$\text{Cov}(\bar{\mathbf{Y}}) = \frac{\Sigma}{n},$$

recuperando diretamente Equação 10.54.

O modelo contendo somente intercepto é, assim, um caso particular do problema de estimação desenvolvido no Capítulo 10. No modelo linear multivariado geral, a única média comum é substituída por vetores de médias que variam entre as unidades segundo os termos representados em $\mathbf{Z}$.

11.3 Valores ajustados, resíduos e projeções

A estimação de $\mathbf{B}$ determina uma matriz de médias ajustadas pertencente ao espaço coluna da matriz de delineamento. A projeção ortogonal sobre um espaço coluna foi estabelecida em Proposição 3.15.

Seja

$$r = \text{posto}(\mathbf{Z}).$$

O projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z})$$

pode ser escrito como

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+, \quad (11.48)$$

em que $\mathbf{Z}^+$ é a pseudoinversa de Moore–Penrose definida em Definição 6.11.

Essa expressão depende apenas do espaço coluna de $\mathbf{Z}$ e permanece válida mesmo quando $\mathbf{Z}$ não possui posto coluna completo. A questão da unicidade dos coeficientes será tratada posteriormente na seção sobre estimabilidade.

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

essa expressão reduz-se a

$$\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top. \quad (11.49)$$

O projetor sobre o complemento ortogonal é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z. \quad (11.50)$$

As propriedades gerais dos projetores ortogonais foram desenvolvidas em Proposição 3.15 e Definição 3.20. Em particular,

$$\mathbf{P}_Z^\top = \mathbf{P}_Z, \quad \mathbf{P}_Z^2 = \mathbf{P}_Z,$$

$$\mathbf{M}_Z^\top = \mathbf{M}_Z, \quad \mathbf{M}_Z^2 = \mathbf{M}_Z,$$

e

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{M}_Z \mathbf{P}_Z = \mathbf{0}. \quad (11.51)$$

Além disso,

$$\text{posto}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r. \quad (11.52)$$

Essas dimensões terão interpretação direta nos graus de liberdade associados ao ajuste e ao resíduo.

11.3.1 Valores ajustados e resíduos

Definição 11.9 (Valores ajustados). A matriz aleatória de valores ajustados é

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.53)$$

Após a observação,

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y}. \quad (11.54)$$

Como

$$\mathbf{P}_Z \mathbf{Z} = \mathbf{Z},$$

tem-se

$$\begin{aligned} \hat{\mathbf{y}} &= \mathbf{P}_Z (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{Z}\mathbf{B} + \mathbf{P}_Z \mathcal{E}. \end{aligned} \quad (11.55)$$

Portanto, os valores ajustados preservam a estrutura sistemática do modelo e incorporam a projeção dos erros sobre o espaço do delineamento.

Definição 11.10 (Resíduos). A matriz aleatória de resíduos é

$$\widehat{\mathcal{U}} = \mathcal{Y} - \widehat{\mathcal{Y}} = \mathbf{M}_Z \mathcal{Y}. \quad (11.56)$$

Após a observação,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} = \mathbf{M}_Z \mathbf{Y}. \quad (11.57)$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

segue que

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}. \quad (11.58)$$

Os resíduos são, portanto, a parcela dos erros pertencente ao complemento ortogonal de

$$\mathcal{C}(\mathbf{Z}).$$

Para cada realização,

$$\mathbf{Y} = \widehat{\mathbf{Y}} + \widehat{\mathbf{U}}. \quad (11.59)$$

A decomposição ocorre coluna a coluna: cada vetor de respostas observadas é separado em sua projeção sobre o espaço do modelo e em um resíduo ortogonal a esse espaço.

11.3.2 Ortogonalidade

As equações normais já forneceram

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Além disso,

$$\begin{aligned} \widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} &= \mathbf{Y}^\top \mathbf{P}_Z \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{0}. \end{aligned} \quad (11.60)$$

Assim, para quaisquer respostas j e k ,

$$\hat{\mathbf{y}}_{\cdot j}^\top \hat{\mathbf{u}}_{\cdot k} = 0.$$

A ortogonalidade não ocorre somente entre o ajuste e o resíduo da mesma resposta. Como o mesmo par de projetores atua sobre todas as colunas de $\mathbf{Y}$, qualquer coluna ajustada é ortogonal a qualquer coluna residual.

Consequentemente,

$$\|\mathbf{Y}\|_F^2 = \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2. \quad (11.61)$$

Essa identidade refere-se aos produtos internos em relação à origem. Quando o modelo contém intercepto, a decomposição da dispersão em torno do vetor de médias amostrais será expressa posteriormente por SQPCs.

11.3.3 Esperança dos valores ajustados e dos resíduos

Proposição 11.5 (Esperança dos valores ajustados e dos resíduos). *Sob*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

tem-se

$$E(\hat{\mathbf{y}} \mid \mathbf{Z}) = \mathbf{ZB} \quad (11.62)$$

e

$$E(\widehat{\mathbf{U}} \mid \mathbf{Z}) = \mathbf{0}. \quad (11.63)$$

De fato,

$$\begin{aligned} E(\hat{\mathbf{y}} \mid \mathbf{Z}) &= \mathbf{P}_Z E(\mathbf{y} \mid \mathbf{Z}) \\ &= \mathbf{P}_Z \mathbf{ZB} \\ &= \mathbf{ZB}, \end{aligned}$$

enquanto

$$\begin{aligned} E(\widehat{\mathcal{U}} \mid \mathbf{Z}) &= \mathbf{M}_Z \mathbf{Z} \mathbf{B} \\ &= \mathbf{0}. \end{aligned}$$

Os valores ajustados são, portanto, não viesados para a matriz de médias representável pelo modelo, enquanto os resíduos possuem média condicional nula.

11.3.4 Covariâncias dos valores ajustados e dos resíduos

A forma vetorizada permite obter diretamente suas matrizes de covariâncias.

Como

$$\text{vec}(\mathbf{P}_Z \mathcal{E}) = (\mathbf{I}_p \otimes \mathbf{P}_Z) \text{vec}(\mathcal{E}),$$

tem-se

Proposição 11.6 (Covariâncias dos valores ajustados e dos resíduos). *Sob*

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

vale

$$\text{Cov}[\text{vec}(\widehat{\mathcal{Y}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{P}_Z \tag{11.64}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathcal{U}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z. \tag{11.65}$$

Além disso,

$$\text{Cov}[\text{vec}(\widehat{\mathcal{Y}}), \text{vec}(\widehat{\mathcal{U}}) \mid \mathbf{Z}] = \mathbf{0}. \tag{11.66}$$

A última igualdade decorre de

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{0}.$$

Os valores ajustados e os resíduos são, portanto, não correlacionados. Sob o modelo normal matricial, eles são conjuntamente normais e, conseqüentemente, independentes. A utilização dessa independência na construção das distribuições amostrais será retomada no Capítulo 12.

As matrizes

$$\Sigma \otimes \mathbf{P}_Z$$

e

$$\Sigma \otimes \mathbf{M}_Z$$

também mostram que o ajuste pode induzir dependência entre valores ajustados ou resíduos associados a unidades distintas. Embora os erros originais sejam não correlacionados entre unidades, os valores ajustados e os resíduos resultam de projeções que utilizam conjuntamente todas as observações.

A análise de medidas de influência e alavancagem pertence ao diagnóstico de modelos e não será desenvolvida neste capítulo.

11.3.5 Representação dos ajustes e resíduos

A Figura 11.1 apresenta um modelo com uma variável explicativa e duas respostas. As duas colunas da matriz de respostas utilizam o mesmo espaço de ajuste, mas possuem coeficientes e resíduos próprios.

Os segmentos verticais representam os resíduos de cada resposta. O mesmo projetor $\mathbf{P}_Z$ determina as posições ajustadas nas duas colunas, enquanto a associação residual entre as respostas não é representada diretamente nos painéis.

Essa associação será resumida pela SQPC residual.




Figura 11.1: Valores observados, retas ajustadas e resíduos para duas respostas modeladas pela mesma variável explicativa.

11.3.6 Conexão com o modelo contendo somente intercepto

Quando

$$\mathbf{Z} = \mathbf{1}_n,$$

tem-se

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top = \mathbf{H}_n. \quad (11.67)$$

Assim,

$$\widehat{\mathbf{Y}} = \mathbf{1}_n \bar{\mathbf{y}}^\top,$$

enquanto

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y}.$$

A matriz residual coincide, nesse caso, com a matriz de respostas centralizada. Portanto, a centralização utilizada nos Capítulos 8 e 10 aparece como um caso particular da projeção residual no modelo linear multivariado.

A próxima seção utilizará

$$\widehat{\mathbf{U}}$$

para construir a SQPC residual, determinar seus graus de liberdade e estimar a matriz de covariâncias Σ .

11.4 SQPC residual e estimação da covariância

A matriz de resíduos

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{y}$$

contém os desvios das respostas em relação aos valores ajustados pelo modelo. Os produtos cruzados entre esses resíduos formam uma matriz que descreve a dispersão conjunta que permanece após o ajuste e permite estimar

$$\Sigma,$$

a matriz de covariâncias dos erros.

No modelo contendo somente intercepto, essa construção recupera a SQPC amostral dos Capítulos 8 e 10. No modelo linear geral, o ajuste remove um espaço de médias de dimensão

$$r = \text{posto}(\mathbf{Z}),$$

restando um espaço residual de dimensão $n - r$.

11.4.1 Construção da SQPC residual

Definição 11.11 (SQPC residual). A SQPC residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}}. \quad (11.68)$$

Como

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{Y},$$

e $\mathbf{M}_Z$ é simétrica e idempotente,

$$\mathbf{E}_{\text{res}} = \mathcal{Y}^\top \mathbf{M}_Z \mathcal{Y}. \quad (11.69)$$

Após a observação,

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.70)$$

O elemento (j, k) de $\mathbf{E}$ é

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}. \quad (11.71)$$

Para $j = k$,

$$e_{jj} = \sum_{i=1}^n \hat{u}_{ij}^2$$

é a soma de quadrados residual da resposta j . Para $j \neq k$, e_{jk} é o produto cruzado residual entre as respostas j e k .

Como

$$\mathcal{Y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

e

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathcal{E}, \quad (11.72)$$

e, conseqüentemente,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}. \quad (11.73)$$

A SQPC residual depende do espaço de médias removido pelo ajuste por meio de $\mathbf{M}_Z$, mas não depende do valor específico de $\mathbf{B}$.

Como toda matriz de Gram, $\mathbf{E}$ é simétrica e positiva semidefinida. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

$$\begin{aligned} \mathbf{a}^\top \mathbf{E} \mathbf{a} &= \|\widehat{\mathbf{U}} \mathbf{a}\|^2 \\ &\geq 0. \end{aligned} \quad (11.74)$$

A forma quadrática corresponde à soma de quadrados residual da combinação linear das respostas

$$\mathbf{Y} \mathbf{a}.$$

De fato,

$$\widehat{\mathbf{u}}_{\mathbf{a}} = \mathbf{M}_Z \mathbf{Y} \mathbf{a} = \widehat{\mathbf{U}} \mathbf{a},$$

e

$$\widehat{\mathbf{u}}_{\mathbf{a}}^\top \widehat{\mathbf{u}}_{\mathbf{a}} = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.75)$$

Se as respostas forem transformadas por

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{p \times s},$$

então

$$\widehat{\mathbf{U}}^* = \widehat{\mathbf{U}} \mathbf{A}$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (11.76)$$

Essa transformação é coerente com a regra populacional

$$\Sigma^* = \mathbf{A}^\top \Sigma \mathbf{A}$$

e será utilizada posteriormente em hipóteses sobre combinações das respostas.

11.4.2 Esperança e graus de liberdade

A dimensão do espaço residual é determinada pelo posto da matriz de delineamento.

Como

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z,$$

tem-se

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r.$$

Definição 11.12 (Graus de liberdade residuais). Se

$$r = \text{posto}(\mathbf{Z}),$$

os graus de liberdade residuais são

$$\nu_E = n - r. \quad (11.77)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e, portanto,

$$\nu_E = n - q.$$

A expressão utiliza r , e não simplesmente o número de colunas de $\mathbf{Z}$, porque somente as r direções linearmente independentes do espaço do modelo consomem graus de liberdade. Colunas redundantes não aumentam a dimensão do espaço de médias ajustado.

Proposição 11.7 (Esperança da SQPC residual). *Sob a estrutura do modelo linear multivariado,*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

com

$$r = \text{posto}(\mathbf{Z}),$$

tem-se

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \quad (11.78)$$

Comprovação. Pela Equação 11.73,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

Considere o elemento (j, k) :

$$[\mathbf{E}_{\text{res}}]_{jk} = \varepsilon_{\cdot j}^\top \mathbf{M}_Z \varepsilon_{\cdot k}.$$

Escrevendo

$$\mathbf{M}_Z = (m_{i\ell}),$$

obtém-se

$$[\mathbf{E}_{\text{res}}]_{jk} = \sum_{i=1}^n \sum_{\ell=1}^n m_{i\ell} \varepsilon_{ij} \varepsilon_{\ell k}.$$

Para $i \neq \ell$,

$$E(\varepsilon_{ij}\varepsilon_{\ell k} \mid \mathbf{Z}) = 0,$$

enquanto, para $i = \ell$,

$$E(\varepsilon_{ij}\varepsilon_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

Logo,

$$\begin{aligned} E\left[\left[\mathbf{E}_{\text{res}}\right]_{jk} \mid \mathbf{Z}\right] &= \sum_{i=1}^n m_{ii} \sigma_{jk} \\ &= \text{tr}(\mathbf{M}_Z) \sigma_{jk} \\ &= (n - r) \sigma_{jk}. \end{aligned}$$

Como a igualdade vale para todos os elementos,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r) \Sigma.$$

□

A expressão generaliza Proposição 10.10, que estabelece

$$E(\mathbf{T}) = (n - 1) \Sigma.$$

No modelo contendo somente intercepto,

$$r = 1,$$

de modo que

$$n - r = n - 1.$$

No modelo linear geral, cada direção independente utilizada para representar a estrutura de médias reduz em uma unidade a dimensão do espaço residual.

11.4.3 Estimação da covariância residual

Definição 11.13 (Estimador residual da matriz de covariâncias). Se

$$r = \text{posto}(\mathbf{Z})$$

e

$$n - r > 0,$$

define-se

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}. \quad (11.79)$$

Após a observação,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}. \quad (11.80)$$

Proposição 11.8 (Não viesamento do estimador residual). Se

$$r = \text{posto}(\mathbf{Z}), \quad n - r > 0,$$

e

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

então

$$E(\widehat{\Sigma} \mid \mathbf{Z}) = \Sigma. \quad (11.81)$$

Portanto, $\widehat{\Sigma}$ é um estimador não viesado da matriz de covariâncias dos erros.

Comprovação. Por Equação 11.79 e Equação 11.78,

$$\begin{aligned} E(\widehat{\Sigma} \mid \mathbf{Z}) &= \frac{1}{n-r} E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) \\ &= \frac{1}{n-r} (n-r) \Sigma \\ &= \Sigma. \end{aligned}$$

□

Componente a componente,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{e_{jk}}{n-r}. \quad (11.82)$$

Assim,

$$\hat{\sigma}_{jj,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij}^2$$

estima a variância residual da resposta j , enquanto, para $j \neq k$,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

estima a covariância residual entre as respostas j e k .

A matriz de correlações residuais pode ser obtida pela mesma padronização utilizada nos Capítulos 8 e 10, desde que as variâncias residuais estimadas sejam positivas. Não é necessário introduzir uma nova construção: aplica-se

$$\mathbf{D}^{-1/2} \widehat{\Sigma}_{\text{obs}} \mathbf{D}^{-1/2}$$

com a matriz diagonal correspondente às variâncias residuais estimadas.

Covariância total e covariância residual

A matriz de covariâncias calculada diretamente das respostas descreve a variabilidade conjunta observada antes do ajuste.

A matriz

$$\widehat{\Sigma}_{\text{obs}}$$

descreve a variabilidade que permanece depois de removida a estrutura de médias pertencente a

$$\mathcal{C}(\mathbf{Z}).$$

Por isso, em geral, as duas matrizes não coincidem.

11.4.4 Estimador de máxima verossimilhança

Sob o modelo normal matricial, depois da maximização em relação à estrutura de médias, a parte da log-verossimilhança que depende de Σ é, a menos de constantes,

$$\ell_c(\Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{E}). \quad (11.83)$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

o máximo no espaço

$$\Sigma \succ \mathbf{0}$$

é alcançado em

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}. \quad (11.84)$$

Como

$$E(\mathbf{E}_{\text{res}} | \mathbf{Z}) = (n - r)\Sigma,$$

a estatística com divisor n satisfaz

$$E\left(\frac{\mathbf{E}_{\text{res}}}{n} | \mathbf{Z}\right) = \frac{n - r}{n} \Sigma.$$

Portanto, seu viés é

$$-\frac{r}{n} \Sigma.$$

Assim, o divisor $n - r$ produz o estimador não viesado, enquanto o divisor n é utilizado pela máxima verossimilhança sob normalidade e existência do máximo. Essa relação generaliza Equação 10.72, na qual os divisores correspondentes são $n - 1$ e n .

Existência do estimador de máxima verossimilhança

A expressão

$$\frac{\mathbf{E}}{n}$$

é a estimativa de máxima verossimilhança de Σ no modelo normal não singular somente quando

$$\mathbf{E} \succ \mathbf{0}.$$

Se $\mathbf{E}$ é singular, a verossimilhança não possui máximo no interior do espaço

$$\Sigma \succ \mathbf{0}.$$

A matriz $\mathbf{E}/n$ continua sendo calculável, mas perde essa interpretação de máxima verossimilhança no modelo positivo definido.

11.4.5 Posto e singularidade

A SQPC residual possui a forma de Gram

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}.$$

Portanto,

$$\text{posto}(\mathbf{E}) = \text{posto}(\widehat{\mathbf{U}}).$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r,$$

obtém-se:

Proposição 11.9 (Posto da SQPC residual). *Se*

$$r = \text{posto}(\mathbf{Z}),$$

a SQPC residual observada

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}$$

satisfaz

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.85)$$

Consequentemente, se

$$p > n - r,$$

então $\mathbf{E}$ é necessariamente singular.

Uma condição necessária para

$$\mathbf{E} \succ \mathbf{0}$$

é

$$n - r \geq p. \quad (11.86)$$

Para uma amostra arbitrária, essa desigualdade não é suficiente: também é necessário

$$\text{posto}(\widehat{\mathbf{U}}) = p.$$

Portanto, uma condição necessária para que a SQPC residual seja positiva definida é haver pelo menos p dimensões residuais,

$$n - r \geq p.$$

A desigualdade, isoladamente, não garante posto completo em uma amostra arbitrária; também é necessário que os resíduos observados gerem p direções linearmente independentes.

O limite de posto é a extensão de Equação 10.81, que no caso de uma única média fornece

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Questões de condicionamento, pseudoinversa e regularização continuam pertinentes às matrizes residuais, mas não serão novamente desenvolvidas aqui. O condicionamento foi discutido em Equação 10.108, a pseudoinversa em Equação 10.117 e a regularização por contração em Definição 10.18.

11.4.6 Modelo contendo somente intercepto

Considere

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$r = 1,$$

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{H}_n.$$

Logo,

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y},$$

e a SQPC residual observada é

$$\begin{aligned} \mathbf{E} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \end{aligned} \tag{11.87}$$

Essa matriz é exatamente a SQPC total observada

$$\mathbf{T}$$

definida em Definição 8.10 e correspondente à realização da estatística aleatória definida em Definição 10.13.

Como

$$n - r = n - 1,$$

obtém-se

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - 1} = \mathbf{S}, \quad (11.88)$$

recuperando Definição 10.14.

Sob normalidade e quando a SQPC possui posto completo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n},$$

em concordância com Equação 10.44.

Portanto, no modelo contendo somente intercepto,

$$\mathbf{E} = \mathbf{T}$$

e

$$\frac{\mathbf{E}}{n - 1} = \mathbf{S}.$$

Assim, a SQPC residual e o estimador não viesado da covariância residual recuperam exatamente os objetos estudados nos Capítulos 8 e 10. O modelo linear multivariado substitui a remoção de uma única média pela remoção de toda a estrutura de médias representada por

$$\mathcal{C}(\mathbf{Z}).$$

A próxima seção separa a SQPC total em uma parcela associada ao modelo e uma parcela residual.

11.5 Decomposição da variação multivariada

Quando o espaço coluna de $\mathbf{Z}$ contém o vetor $\mathbf{1}_n$, a dispersão das respostas em torno do vetor de médias amostrais pode ser decomposta em uma parcela associada ao modelo e uma parcela residual. Essa condição é satisfeita, por exemplo, quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

No caso univariado, essa separação produz as somas de quadrados utilizadas na análise de variância. No modelo multivariado, cada parcela é representada por uma matriz SQPC, preservando também os produtos cruzados entre as respostas.

A principal decomposição é

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

em que $\mathbf{T}$ representa a dispersão total em torno da média geral, $\mathbf{T}_{\text{mod}}$ representa a dispersão dos valores ajustados em torno da média geral e $\mathbf{E}$ representa a dispersão residual em torno dos valores ajustados.

11.5.1 SQPC total

A SQPC total observada foi definida em Definição 8.10. Aplicada à matriz de respostas,

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y}, \quad (11.89)$$

em que $\mathbf{H}_n$ é a matriz de centralização utilizada em Equação 8.58:

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Equivalentemente,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top, \quad (11.90)$$

com

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n.$$

A matriz $\mathbf{T}$ descreve a dispersão conjunta das respostas antes da remoção da estrutura explicada pelo delineamento.

11.5.2 SQPC associada ao modelo

Suponha que a direção constante pertença ao espaço do modelo, isto é,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}). \quad (11.91)$$

Essa condição é satisfeita quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

Defina o projetor sobre o espaço das constantes por

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (11.92)$$

Como

$$\mathcal{C}(\mathbf{1}_n) \subseteq \mathcal{C}(\mathbf{Z}),$$

tem-se

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1. \quad (11.93)$$

Consequentemente,

$$\mathbf{P}_Z - \mathbf{P}_1$$

é o projetor ortogonal sobre a parte de $\mathcal{C}(\mathbf{Z})$ ortogonal à direção constante. Essa parte representa as variações ajustadas pelo modelo em torno da média geral.

Seu posto é

$$\text{posto}(\mathbf{P}_Z - \mathbf{P}_1) = r - 1, \quad (11.94)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Definição 11.14 (SQPC associada ao modelo, corrigida pela média geral). Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

define-se

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \quad (11.95)$$

em que $\mathbf{P}_Z$ é o projetor sobre $\mathcal{C}(\mathbf{Z})$ e

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

é o projetor sobre a direção constante.

Se

$$\mathcal{C}(\mathbf{Z}) = \mathcal{C}(\mathbf{1}_n),$$

então

$$\mathbf{P}_Z = \mathbf{P}_1$$

e, conseqüentemente,

$$\mathbf{T}_{\text{mod}} = \mathbf{0}.$$

Assim, $\mathbf{T}_{\text{mod}}$ quantifica somente a variação ajustada que excede a representação da média geral.

A matriz

$$\mathbf{T}_{\text{mod}}$$

mede a dispersão dos valores ajustados pelo modelo em torno da média geral. No modelo de grupos, essa matriz coincide com a dispersão entre grupos. Em modelos com covariáveis, ela representa conjuntamente a variação dos valores ajustados em torno da média geral.

Se

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y},$$

então os valores ajustados centralizados são

$$\widehat{\mathbf{Y}}_c = \widehat{\mathbf{Y}} - \mathbf{1}_n \bar{\mathbf{y}}^\top = (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

Logo,

$$\mathbf{T}_{\text{mod}} = \widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c. \quad (11.96)$$

Para qualquer combinação linear das respostas,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} = \|(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} \mathbf{a}\|^2. \quad (11.97)$$

Portanto, $\mathbf{T}_{\text{mod}}$ reúne, para todas as combinações lineares das respostas, as somas de quadrados dos valores ajustados em torno da respectiva média geral.

11.5.3 Decomposição entre modelo e resíduo

Sob a condição

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

considere

$$\mathbf{H}_n = \mathbf{I}_n - \mathbf{P}_1$$

e

$$\mathbf{I}_n = \mathbf{P}_Z + \mathbf{M}_Z.$$

segue que

$$\mathbf{H}_n = (\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z. \quad (11.98)$$

Além disso,

$$(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{M}_Z = \mathbf{0}.$$

Assim, as duas parcelas correspondem a subespaços ortogonais.

Proposição 11.10 (Decomposição da SQPC total). *Se*

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

então

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}, \quad (11.99)$$

em que

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Comprovação. Substituindo Equação 11.98 na definição de $\mathbf{T}$,

$$\begin{aligned} \mathbf{T} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \mathbf{Y}^\top [(\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z] \mathbf{Y} \\ &= \mathbf{T}_{\text{mod}} + \mathbf{E}. \end{aligned}$$

□

A decomposição pode ser escrita também como

$$\begin{aligned} &\sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top \\ &= \sum_{i=1}^n (\hat{\mathbf{y}}_i - \bar{\mathbf{y}}) (\hat{\mathbf{y}}_i - \bar{\mathbf{y}})^\top \\ &\quad + \sum_{i=1}^n (\mathbf{y}_i - \hat{\mathbf{y}}_i) (\mathbf{y}_i - \hat{\mathbf{y}}_i)^\top. \end{aligned} \quad (11.100)$$

A primeira parcela à direita é $\mathbf{T}_{\text{mod}}$ e a segunda é $\mathbf{E}$.

As dimensões dos subespaços correspondentes fornecem

$$n - 1 = (r - 1) + (n - r). \quad (11.101)$$

A Tabela 11.1 resume as dimensões dos três subespaços envolvidos.

Tabela 11.1: Decomposição das dimensões associadas à SQPC total quando a direção constante pertence ao espaço do modelo.

Fonte	Projetor	Graus de liberdade
Total corrigido pela média geral	$\mathbf{H}_n$	$n - 1$
Modelo corrigido pela média geral	$\mathbf{P}_Z - \mathbf{P}_1$	$r - 1$
Residual	$\mathbf{M}_Z$	$n - r$

Os graus de liberdade correspondem aos postos dos projetores no espaço das unidades. Eles não devem ser confundidos com os postos das matrizes de SQPC, que também dependem de p .

Em particular,

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{mod}}) \leq \min(p, r - 1),$$

e

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.102)$$

11.5.4 Combinações lineares das respostas

A decomposição matricial contém, simultaneamente, as decomposições correspondentes a todas as combinações lineares das respostas.

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} + \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.103)$$

Cada termo possui interpretação univariada:

$$\mathbf{a}^\top \mathbf{T} \mathbf{a}$$

é a soma de quadrados total de $\mathbf{Y} \mathbf{a}$,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a}$$

é a soma de quadrados associada ao modelo, e

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

é a soma de quadrados residual.

Essa relação é suficiente, neste capítulo, para mostrar como a decomposição matricial preserva simultaneamente as decomposições das respostas originais e de suas combinações lineares. A utilização conjunta dessas matrizes em procedimentos inferenciais será desenvolvida no Capítulo 12 e, posteriormente, na formulação das técnicas multivariadas.

11.5.5 Modelos sem intercepto

Se

$$\mathbf{1}_n \notin \mathcal{C}(\mathbf{Z}),$$

a decomposição corrigida

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}$$

não se aplica na forma anterior, porque $\mathbf{P}_Z - \mathbf{P}_1$ não é, em geral, um projetor.

Permanece válida a decomposição em relação à origem,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.104)$$

Essa identidade não deve ser interpretada como uma decomposição da dispersão em torno da média amostral. No restante deste capítulo, a decomposição total–modelo–resíduo será utilizada principalmente quando a direção constante pertence ao espaço coluna de $\mathbf{Z}$.

11.5.6 Modelo de grupos como caso particular

Considere K grupos não vazios. Uma parametrização particularmente simples utiliza uma coluna indicadora para cada grupo. Para três grupos, por exemplo, a matriz de delineamento possui a forma

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ \vdots & \vdots & \vdots \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ \vdots & \vdots & \vdots \\ 0 & 0 & 1 \end{bmatrix},$$

em que cada linha identifica o grupo da respectiva unidade.

Na parametrização por médias de grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

em que $\mathcal{J}_k$ representa o conjunto dos índices das unidades pertencentes ao grupo k . Assim,

$$E(\mathbf{Y}_i \mid i \in \mathcal{J}_k) = \mu_k.$$

O estimador de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} \bar{\mathbf{y}}_1^\top \\ \vdots \\ \bar{\mathbf{y}}_K^\top \end{bmatrix}. \quad (11.105)$$

Portanto, o vetor ajustado para cada unidade é a média amostral do grupo ao qual ela pertence.

A SQPC residual é

$$\mathbf{E} = \sum_{k=1}^K \sum_{i \in \mathcal{J}_k} (\mathbf{y}_i - \bar{\mathbf{y}}_k) (\mathbf{y}_i - \bar{\mathbf{y}}_k)^\top. \quad (11.106)$$

Pela definição de dispersão intragrupos em Definição 8.14,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}. \quad (11.107)$$

Assim, a SQPC residual do modelo de grupos mede exatamente a dispersão das observações em torno das médias de seus respectivos grupos.

A parcela associada ao modelo é

$$\mathbf{T}_{\text{mod}} = \sum_{k=1}^K n_k (\bar{\mathbf{y}}_k - \bar{\mathbf{y}}) (\bar{\mathbf{y}}_k - \bar{\mathbf{y}})^\top. \quad (11.108)$$

Por Definição 8.15,

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}. \quad (11.109)$$

Portanto,

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}, \quad (11.110)$$

recuperando Proposição 8.10 como um caso particular do modelo linear multivariado.

Os graus de liberdade também se decompõem como

$$n - 1 = (K - 1) + (n - K). \quad (11.111)$$

A Figura 11.2 representa geometricamente as duas parcelas dessa decomposição. Os segmentos que ligam cada observação à média de seu grupo representam desvios intragrupos, enquanto os segmentos tracejados que ligam as médias dos grupos à média geral representam os deslocamentos responsáveis pela dispersão entre grupos.

As cruzeiras representam as médias dos grupos e o asterisco representa a média geral. Os segmentos internos aos grupos visualizam os termos associados a $\mathbf{T}_{\text{intra}}$, enquanto os deslocamentos das médias dos grupos em relação à média geral visualizam a estrutura associada a $\mathbf{T}_{\text{entre}}$.

A decomposição depende do espaço de médias representado por $\mathbf{Z}$, e não de uma parametrização específica desse espaço. Essa distinção motiva a discussão de posto, parametrização e estimabilidade da próxima seção.




Figura 11.2: Dispersão intragrupos e deslocamento das médias dos grupos em relação à média geral.

11.6 Posto, parametrização e estimabilidade

A expressão

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

exige

$$\text{posto}(\mathbf{Z}) = q.$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente independentes e os coeficientes de $\mathbf{B}$ são determinados pela parametrização adotada.

Alguns modelos, especialmente aqueles que representam grupos ou fatores, podem ser escritos com colunas redundantes em $\mathbf{Z}$. Diferentes valores dos coeficientes podem então representar exatamente a mesma estrutura de médias

$$\mathbf{Z}\mathbf{B}.$$

Por isso, é necessário distinguir a unicidade dos coeficientes da unicidade dos valores ajustados e das combinações de parâmetros que se deseja interpretar.

11.6.1 Delineamento com posto deficiente

Considere

$$\mathbf{Z} \in \mathbb{R}^{n \times q}$$

com

$$r = \text{posto}(\mathbf{Z}) < q. \quad (11.112)$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente dependentes. Portanto, existe pelo menos um vetor não nulo

$$\mathbf{d} \in \mathbb{R}^q$$

tal que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Consequentemente, alterações dos coeficientes em direções pertencentes ao núcleo de $\mathbf{Z}$ não modificam a estrutura de médias.

Definição 11.15 (Matrizes de parâmetros equivalentes). Duas matrizes

$$\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{q \times p}$$

são equivalentes em relação a $\mathbf{Z}$ quando

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2. \quad (11.113)$$

Assim, quando $r < q$, os coeficientes individuais de $\mathbf{B}$ podem não ser únicos, embora a matriz de médias

$$\mathbf{Z}\mathbf{B}$$

continue unicamente determinada pelo modelo.

11.6.2 Pseudoinversa e unicidade do ajuste

A pseudoinversa de Moore–Penrose e sua relação com mínimos quadrados foram desenvolvidas em Definição 6.11 e Proposição 6.22.

Quando

$$r < q,$$

a matriz

$$\mathbf{Z}^\top \mathbf{Z}$$

é singular, mas o problema de mínimos quadrados continua tendo solução. Uma delas é

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}. \quad (11.114)$$

Proposição 11.11 (Unicidade dos valores ajustados sob posto deficiente). *Mesmo quando os coeficientes de mínimos quadrados não são únicos, todas as soluções produzem a mesma matriz de valores ajustados,*

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.115)$$

Consequentemente, também são únicos

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

e

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Portanto, a deficiência de posto pode impedir a interpretação única de determinados coeficientes sem impedir o cálculo dos valores ajustados, dos resíduos e da SQPC residual.

Os graus de liberdade residuais continuam sendo determinados pelo posto efetivo,

$$\nu_E = n - r,$$

e o estimador não viesado da covariância residual permanece

$$\hat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}.$$

11.6.3 Funções estimáveis

Quando os coeficientes de $\mathbf{B}$ não são individualmente identificados, ainda podem existir combinações deles que sejam determinadas unicamente pela estrutura de médias. Essas combinações são particularmente importantes em modelos com fatores, nos quais comparações entre grupos podem ser estimáveis mesmo quando uma parametrização utiliza coeficientes redundantes.

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina os termos do modelo representados nas linhas de $\mathbf{B}$.

Definição 11.16 (Função linear estimável). Para

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

a função

$$\mathbf{CB}$$

é estimável quando existe uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times g}$$

tal que

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{CB}$$

para toda matriz de parâmetros $\mathbf{B}$.

Como

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB},$$

a condição anterior equivale a

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}. \tag{11.116}$$

Portanto, a estimabilidade depende do espaço linha de $\mathbf{Z}$.

Proposição 11.12 (Caracterização das funções estimáveis). *Para*

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

são equivalentes:

1. $\mathbf{CB}$ é estimável;
2. as linhas de $\mathbf{C}$ pertencem ao espaço linha de $\mathbf{Z}$,

$$\mathcal{C}(\mathbf{C}^\top) \subseteq \mathcal{C}(\mathbf{Z}^\top);$$

3. vale

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

Em particular,

$$\mathbf{CB} \text{ é estimável} \iff \mathbf{C} = \mathbf{CZ}^+\mathbf{Z}. \quad (11.117)$$

Comprovação. Pela definição de estimabilidade, deve existir uma matriz $\mathbf{A}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z}.$$

Isso ocorre exatamente quando cada linha de $\mathbf{C}$ pertence ao espaço linha de $\mathbf{Z}$.

Como

$$\mathbf{Z}^+\mathbf{Z}$$

é o projetor ortogonal sobre esse espaço, a mesma condição pode ser escrita como

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

□

A caracterização também pode ser expressa diretamente em termos das parametrizações equivalentes.

Se

$$\mathbf{ZB}_1 = \mathbf{ZB}_2,$$

então

$$\mathbf{CB}$$

é estimável se

$$\mathbf{CB}_1 = \mathbf{CB}_2$$

para todas as matrizes de parâmetros equivalentes.

Isso ocorre precisamente porque $\mathbf{C}$ elimina as componentes pertencentes ao núcleo de $\mathbf{Z}$.

11.6.4 Estimador de uma função estimável

Quando $\mathbf{CB}$ é estimável, pode-se utilizar

$$\widehat{\Theta}_C = \mathbf{CZ}^+ \mathbf{y}. \quad (11.118)$$

Como

$$\mathbf{C} = \mathbf{CZ}^+ \mathbf{Z},$$

tem-se

$$E(\widehat{\Theta}_C | \mathbf{Z}) = \mathbf{CB}. \quad (11.119)$$

Portanto, uma função estimável possui o mesmo valor independentemente da representação utilizada para os coeficientes redundantes. Essa propriedade permitirá formular contrastes e hipóteses sobre efeitos do modelo sem depender da parametrização escolhida.

11.6.5 Parametrizações equivalentes

Diferentes matrizes de delineamento podem representar o mesmo conjunto de estruturas de médias.

Se

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \quad (11.120)$$

então

$$\mathbf{P}_{\mathbf{Z}_1} = \mathbf{P}_{\mathbf{Z}_2},$$

e, para a mesma matriz de respostas, os dois modelos produzem os mesmos valores ajustados, resíduos e SQPC residual.

Essa situação ocorre, por exemplo, quando um fator é representado por diferentes sistemas de codificação. Os coeficientes individuais podem mudar de interpretação, mas as médias ajustadas e os contrastes estimáveis permanecem os mesmos.

O objeto que caracteriza a estrutura de médias é, portanto,

$$\mathcal{C}(\mathbf{Z}),$$

e não uma lista específica de coeficientes.

Deficiência de posto e mau condicionamento são problemas distintos. A deficiência de posto corresponde a dependências lineares exatas entre as colunas de $\mathbf{Z}$; o mau condicionamento pode ocorrer mesmo com posto completo e tornar os coeficientes sensíveis a pequenas perturbações. O número de condição definido em Definição 6.9 e a SVD definida em Definição 6.3 podem ser utilizados no diagnóstico desse problema.

A distinção entre coeficientes individuais e funções estimáveis permite formular comparações que não dependem da parametrização adotada. Na próxima seção, essas comparações serão expressas como hipóteses lineares sobre os termos do modelo e sobre as respostas.

11.7 Hipóteses lineares multivariadas

O modelo linear multivariado permite formular hipóteses sobre termos do modelo, diferenças entre grupos e combinações das respostas. A formulação será construída progressivamente, começando por combinações das linhas de $\mathbf{B}$ e, depois, incorporando combinações de suas colunas (Rao, 1973; Rencher; Christensen, 2012).

11.7.1 Combinações dos termos do modelo

Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}.$$

A matriz

$$\mathbf{C}_1 \mathbf{B} \in \mathbb{R}^{g \times p}$$

combina os termos representados nas linhas de $\mathbf{B}$.

Se

$$\mathbf{c}_1^\top \in \mathbb{R}^{1 \times q}$$

é uma linha de $\mathbf{C}_1$, então

$$\mathbf{c}_1^\top \mathbf{B} \in \mathbb{R}^{1 \times p}$$

contém a mesma combinação dos termos para todas as p respostas.

Por exemplo, se a linha h de $\mathbf{B}$ corresponde a um único termo do modelo,

$$\mathbf{c}_1^\top = \mathbf{e}_h^\top$$

seleciona os coeficientes desse termo nas p respostas.

No modelo parametrizado diretamente pelas médias de K grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

uma combinação

$$\mathbf{c}_1^\top \mathbf{B} = \sum_{k=1}^K c_{1k} \mu_k^\top$$

é um contraste entre os vetores de médias quando

$$\sum_{k=1}^K c_{1k} = 0.$$

Por exemplo,

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

produz

$$\mathbf{c}_1^\top \mathbf{B} = (\mu_1 - \mu_2)^\top.$$

Assim, uma única linha de $\mathbf{C}_1$ pode representar uma comparação entre grupos, enquanto várias linhas permitem representar simultaneamente diferentes contrastes.

11.7.2 Combinações das respostas

A multiplicação à direita de $\mathbf{B}$ atua sobre as respostas. Considere

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

Então,

$$\mathbf{BC}_2 \in \mathbb{R}^{q \times s}$$

contém os efeitos do modelo sobre as s combinações de respostas definidas por $\mathbf{C}_2$.

Para uma única combinação, considere

$$\mathbf{c}_2 \in \mathbb{R}^p$$

e defina

$$W_i = \mathbf{c}_2^\top \mathbf{Y}_i.$$

Sua média condicional é

$$E(W_i | \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{BC}_2, \quad (11.121)$$

e sua variância residual é

$$\text{Var}(W_i | \mathbf{Z}) = \mathbf{c}_2^\top \Sigma \mathbf{c}_2. \quad (11.122)$$

Para várias combinações simultâneas,

$$\mathbf{y}_{C_2} = \mathbf{y} \mathbf{C}_2,$$

e

$$\mathbf{y}_{C_2} = \mathbf{Z}(\mathbf{BC}_2) + \mathcal{E} \mathbf{C}_2. \quad (11.123)$$

A matriz de covariâncias residuais correspondente é

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2. \quad (11.124)$$

Portanto, $\mathbf{C}_1$ atua sobre os termos do modelo e $\mathbf{C}_2$ atua sobre as respostas.

11.7.3 Hipótese linear geral

Combinando as duas operações anteriores, define-se

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 \in \mathbb{R}^{g \times s}, \quad (11.125)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

As linhas de Θ correspondem às combinações dos termos definidas por $\mathbf{C}_1$, enquanto suas colunas correspondem às combinações das respostas definidas por $\mathbf{C}_2$.

Definição 11.17 (Hipótese linear geral multivariada). Para

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

a hipótese linear geral é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0, \quad (11.126)$$

em que

$$\Theta_0 \in \mathbb{R}^{g \times s}$$

contém os valores especificados pela hipótese.

Quando

$$\Theta_0 = \mathbf{0},$$

obtém-se

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mathbf{0}. \quad (11.127)$$

Se

$$\mathbf{C}_2 = \mathbf{I}_p,$$

a hipótese envolve os termos do modelo em todas as respostas:

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0.$$

Se

$$g = s = 1,$$

obtém-se a hipótese escalar

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = \theta_0. \quad (11.128)$$

11.7.4 Estimabilidade da hipótese

A hipótese deve envolver uma combinação dos parâmetros determinada pelo modelo. Pela caracterização da seção anterior,

$$\mathbf{C}_1 \mathbf{B}$$

é estimável quando

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (11.129)$$

Nessa situação,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2 \quad (11.130)$$

é um estimador de

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2,$$

e, após a observação,

$$\widehat{\Theta}_{\text{obs}} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2. \quad (11.131)$$

Sua esperança condicional satisfaz

$$E(\widehat{\Theta} | \mathbf{Z}) = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2. \quad (11.132)$$

Para construir a SQPC associada à hipótese, defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}. \quad (11.133)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}_1^{\top}. \quad (11.134)$$

No caso escalar, com uma combinação dos termos $\mathbf{c}_1$ e uma combinação das respostas $\mathbf{c}_2$,

$$\text{Var}(\mathbf{c}_1^{\top} \widehat{\mathbf{B}} \mathbf{c}_2 \mid \mathbf{Z}) = [\mathbf{c}_1^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{c}_1] (\mathbf{c}_2^{\top} \Sigma \mathbf{c}_2), \quad (11.135)$$

quando $\mathbf{Z}$ possui posto coluna completo.

A primeira parcela depende do delineamento e da combinação dos termos do modelo; a segunda depende da variabilidade residual da combinação das respostas.

Para as construções seguintes, $\mathbf{C}_1$ será considerada sem linhas redundantes. Assim,

$$\text{posto}(\mathbf{C}_1) = g,$$

e os graus de liberdade associados à hipótese são

$$\nu_H = g. \quad (11.136)$$

11.7.5 SQPC da hipótese

A SQPC da hipótese representa o afastamento observado em relação à hipótese, ponderado pela variabilidade decorrente do delineamento.

Definição 11.18 (SQPC da hipótese linear). Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times s}.$$

Suponha que as combinações dos termos especificadas por $\mathbf{C}_1$ sejam estimáveis, isto é,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}.$$

Para a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

o afastamento observado é

$$\widehat{\Delta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2 - \Theta_0 \in \mathbb{R}^{g \times s}. \quad (11.137)$$

Defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \in \mathbb{R}^{g \times g}.$$

Quando

$$\mathbf{V}_{C_1} \succ \mathbf{0},$$

a **SQPC da hipótese linear** é

$$\mathbf{H} = \widehat{\Delta}^{\top} \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \in \mathbb{R}^{s \times s}. \quad (11.138)$$

A matriz

$$\mathbf{H} \in \mathbb{R}^{s \times s}$$

é simétrica e positiva semidefinida,

$$\mathbf{H} \succeq \mathbf{0},$$

e satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(g, s). \quad (11.139)$$

Se

$$\widehat{\Delta} = \mathbf{0},$$

então

$$\mathbf{H} = \mathbf{0}.$$

Para as mesmas combinações de respostas, a SQPC residual é

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2. \quad (11.140)$$

Portanto, a hipótese produz o par

$$(\mathbf{H}, \mathbf{E}_{C_2}).$$

A matriz $\mathbf{H}$ representa a variação associada ao afastamento da hipótese, enquanto $\mathbf{E}_{C_2}$ representa a variação residual das mesmas combinações de respostas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se simplesmente o par

$$(\mathbf{H}, \mathbf{E}),$$

que será utilizado posteriormente na MANOVA.

As distribuições amostrais dessas matrizes serão estudadas no Capítulo 12. Os critérios específicos que comparam $\mathbf{H}$ e $\mathbf{E}$ pertencem ao Módulo 3.

11.7.6 Modelos encaixados

Uma hipótese sobre determinados termos do modelo também pode ser representada pela comparação entre um modelo completo e um modelo reduzido (Christensen, 2011).

Considere matrizes de delineamento $\mathbf{Z}_F$ e $\mathbf{Z}_R$ tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F). \quad (11.141)$$

O modelo reduzido representa um subconjunto das estruturas de médias disponíveis no modelo completo.

Defina

$$r_F = \text{posto}(\mathbf{Z}_F) \quad \text{e} \quad r_R = \text{posto}(\mathbf{Z}_R).$$

Seus projetores são

$$\mathbf{P}_F = \mathbf{Z}_F \mathbf{Z}_F^+$$

e

$$\mathbf{P}_R = \mathbf{Z}_R \mathbf{Z}_R^+.$$

Como os espaços são encaixados,

$$\mathbf{P}_F - \mathbf{P}_R$$

é o projetor sobre as direções acrescentadas pelo modelo completo e possui posto

$$\text{posto}(\mathbf{P}_F - \mathbf{P}_R) = r_F - r_R. \quad (11.142)$$

As SQPCs residuais são

$$\mathbf{E}_F = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_F) \mathbf{Y}$$

e

$$\mathbf{E}_R = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_R) \mathbf{Y}.$$

Proposição 11.13 (Decomposição das SQPCs de modelos encaixados). *Se*

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

e $\mathbf{P}_R$ e $\mathbf{P}_F$ são os projetores sobre os espaços dos modelos reduzido e completo, respectivamente, então

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \quad (11.143)$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}. \quad (11.144)$$

Equivalentemente,

$$\mathbf{H} = \mathbf{E}_R - \mathbf{E}_F. \quad (11.145)$$

Portanto, $\mathbf{H}$ mede a redução da SQPC residual obtida quando as direções presentes no modelo completo são acrescentadas ao modelo reduzido.

Os graus de liberdade correspondentes são

$$\nu_H = r_F - r_R \quad (11.146)$$

e

$$\nu_E = n - r_F. \quad (11.147)$$

Para combinações de respostas definidas por $\mathbf{C}_2$,

$$\mathbf{H}_{C_2} = \mathbf{C}_2^\top \mathbf{H} \mathbf{C}_2$$

e

$$\mathbf{E}_{F,C_2} = \mathbf{C}_2^\top \mathbf{E}_F \mathbf{C}_2. \quad (11.148)$$

A formulação por $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ identifica a função paramétrica examinada; a formulação por modelos encaixados mostra quanto a inclusão dos termos correspondentes reduz a variação residual.

11.7.7 Casos particulares

A forma geral inclui diferentes perguntas sem necessidade de construir uma notação específica para cada uma.

11.7.7.1 Comparação entre vetores de médias de grupos

Na parametrização por médias de grupos, considere

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} = \mathbf{0}^\top$$

equivale a

$$H_0 : \mu_1 = \mu_2. \tag{11.149}$$

Várias linhas em $\mathbf{C}_1$ permitem representar simultaneamente diferentes contrastes entre grupos. Essa é a estrutura que será utilizada posteriormente na MANOVA.

11.7.7.2 Efeito de um termo em todas as respostas

Se a linha h de $\mathbf{B}$ representa um termo específico do modelo, tome

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} = \mathbf{0}^\top \quad (11.150)$$

afirma que esse termo possui coeficiente nulo para todas as respostas.

11.7.7.3 Efeito sobre uma combinação das respostas

Para

$$\mathbf{c}_1 \in \mathbb{R}^q$$

e

$$\mathbf{c}_2 \in \mathbb{R}^p,$$

a hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = 0 \quad (11.151)$$

examina o efeito definido por $\mathbf{c}_1$ sobre a combinação de respostas definida por $\mathbf{c}_2$.

Por exemplo,

$$\mathbf{c}_2 = \mathbf{e}_j - \mathbf{e}_k$$

representa a diferença entre as respostas j e k .

11.7.7.4 Igualdade do efeito em duas respostas

Tomando

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$H_0 : \mathbf{e}_h^\top \mathbf{B} (\mathbf{e}_j - \mathbf{e}_k) = 0, \quad (11.152)$$

equivalente a

$$H_0 : \beta_{hj} = \beta_{hk}.$$

Esses casos mostram a função das duas matrizes. A matriz $\mathbf{C}_1$ combina termos do modelo, enquanto $\mathbf{C}_2$ combina respostas.

A estrutura que seguirá para o Capítulo 12 é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

acompanhada das matrizes SQPC associadas à hipótese e ao resíduo.

11.8 Exemplo integrado

Exemplo 11.1 (Regressão multivariada com uma covariável e duas respostas). Considere seis unidades. Para cada unidade, registra-se uma variável explicativa quantitativa x e duas respostas Y_1 e Y_2 .

Unidade	x	Y_1	Y_2
1	1	3	8
2	2	5	7
3	3	4	7
4	4	8	5
5	5	9	4
6	6	11	3

A matriz observada de respostas é

$$\mathbf{Y} = \begin{bmatrix} 3 & 8 \\ 5 & 7 \\ 4 & 7 \\ 8 & 5 \\ 9 & 4 \\ 11 & 3 \end{bmatrix},$$

e a matriz de delineamento, contendo intercepto e a covariável, é

$$\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{bmatrix}. \quad (11.153)$$

Nesse modelo,

$$\mathbf{B} = \begin{bmatrix} \beta_{01} & \beta_{02} \\ \beta_{11} & \beta_{12} \end{bmatrix},$$

em que a primeira linha contém os interceptos e a segunda contém os efeitos de x sobre as duas respostas.

Como

$$q = 2$$

e

$$\text{posto}(\mathbf{Z}) = 2,$$

a matriz de delineamento possui posto coluna completo. Portanto, $\mathbf{Z}^\top \mathbf{Z}$ é invertível e a estimativa de mínimos quadrados de $\mathbf{B}$ é única.

Tem-se

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 6 & 21 \\ 21 & 91 \end{bmatrix}$$

e

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{105} \begin{bmatrix} 91 & -21 \\ -21 & 6 \end{bmatrix}.$$

Estimação da matriz de parâmetros

A estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Numericamente,

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 16/15 & 139/15 \\ 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,067 & 9,267 \\ 1,600 & -1,029 \end{bmatrix}. \quad (11.154)$$

Portanto, as equações ajustadas são

$$\hat{Y}_1 = 1,067 + 1,600x$$

e

$$\hat{Y}_2 = 9,267 - 1,029x.$$

Para um aumento de uma unidade em x , a média ajustada de Y_1 aumenta em aproximadamente 1,600, enquanto a média ajustada de Y_2 diminui em aproximadamente 1,029.

A Figura 11.3 mostra simultaneamente as duas respostas, seus ajustes e os respectivos resíduos.




Figura 11.3: Respostas observadas, ajustes lineares e resíduos do exemplo integrado.

A figura evidencia as inclinações em sentidos opostos das duas respostas. Os segmentos tracejados ligam cada observação ao valor ajustado correspondente e representam graficamente os resíduos que serão reunidos na matriz $\widehat{\mathbf{U}}$.

A matriz de valores ajustados é

$$\widehat{\mathbf{Y}} = \mathbf{Z}\widehat{\mathbf{B}}_{\text{obs}} \approx \begin{bmatrix} 2,667 & 8,238 \\ 4,267 & 7,210 \\ 5,867 & 6,181 \\ 7,467 & 5,152 \\ 9,067 & 4,124 \\ 10,667 & 3,095 \end{bmatrix}. \quad (11.155)$$

Consequentemente,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} \approx \begin{bmatrix} 0,333 & -0,238 \\ 0,733 & -0,210 \\ -1,867 & 0,819 \\ 0,533 & -0,152 \\ -0,067 & -0,124 \\ 0,333 & -0,095 \end{bmatrix}. \quad (11.156)$$

As equações normais garantem

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Em particular, como o modelo contém intercepto, os resíduos somam zero em cada resposta.

SQPC residual e covariância residual

A SQPC residual é

$$\begin{aligned} \mathbf{E} &= \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \\ &= \begin{bmatrix} 68/15 & -28/15 \\ -28/15 & 86/105 \end{bmatrix} \\ &\approx \begin{bmatrix} 4,533 & -1,867 \\ -1,867 & 0,819 \end{bmatrix}. \end{aligned} \quad (11.157)$$

Como

$$n = 6$$

e

$$r = 2,$$

os graus de liberdade residuais são

$$\nu_E = n - r = 4.$$

A estimativa não viesada da matriz de covariâncias residual é

$$\begin{aligned}\widehat{\Sigma}_{\text{obs}} &= \frac{\mathbf{E}}{4} \\ &= \begin{bmatrix} 17/15 & -7/15 \\ -7/15 & 43/210 \end{bmatrix} \\ &\approx \begin{bmatrix} 1,133 & -0,467 \\ -0,467 & 0,205 \end{bmatrix}.\end{aligned}\tag{11.158}$$

A covariância residual estimada é negativa. Isso indica que, depois de removida a relação linear com x , desvios positivos de uma resposta tendem a ocorrer juntamente com desvios negativos da outra neste conjunto de dados.

Sob o modelo normal matricial, como $\mathbf{E} \succ \mathbf{0}$, a estimativa de máxima verossimilhança é

$$\begin{aligned}\widehat{\Sigma}_{\text{MV,obs}} &= \frac{\mathbf{E}}{6} \\ &\approx \begin{bmatrix} 0,756 & -0,311 \\ -0,311 & 0,137 \end{bmatrix}.\end{aligned}\tag{11.159}$$

A diferença entre as duas estimativas decorre dos divisores:

$$n - r = 4$$

para o estimador não viesado e

$$n = 6$$

para a máxima verossimilhança sob normalidade.

Decomposição da SQPC total

Como o modelo contém intercepto,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

A SQPC total é

$$\mathbf{T} = \begin{bmatrix} 148/3 & -92/3 \\ -92/3 & 58/3 \end{bmatrix} \approx \begin{bmatrix} 49,333 & -30,667 \\ -30,667 & 19,333 \end{bmatrix}. \quad (11.160)$$

A parcela associada à covariável, além do intercepto, é

$$\mathbf{T}_{\text{mod}} = \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \quad (11.161)$$

Utilizando os valores exatos das matrizes,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

Assim, a dispersão total em torno da média é decomposta na parcela associada à covariável e na parcela residual.

Os graus de liberdade apresentam a decomposição correspondente:

$$5 = 1 + 4,$$

isto é,

$$n - 1 = (r - 1) + (n - r).$$

Hipótese sobre o efeito da covariável

Considere a hipótese de que x não apresenta efeito linear sobre nenhuma das duas respostas.

Para seleccionar a segunda linha de $\mathbf{B}$, defina

$$\mathbf{C}_1 = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Como as duas respostas são mantidas,

$$\mathbf{C}_2 = \mathbf{I}_2.$$

A hipótese é

$$H_0 : \mathbf{C}_1 \mathbf{B} = \mathbf{0}^\top,$$

ou, equivalentemente,

$$H_0 : \beta_{11} = \beta_{12} = 0. \quad (11.162)$$

O afastamento observado em relação à hipótese nula é

$$\widehat{\Delta} = \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} = [8/5 \quad -36/35] \approx [1,600 \quad -1,029]. \quad (11.163)$$

Nesse caso, $\widehat{\Delta}$ é exatamente o vetor formado pelas duas inclinações estimadas, pois a hipótese especifica que ambas devem ser iguais a zero.

A matriz associada à variabilidade desse contraste é escalar:

$$\begin{aligned} \mathbf{V}_{C_1} &= \mathbf{C}_1 (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}_1^\top \\ &= \frac{2}{35} \\ &\approx 0,057. \end{aligned} \quad (11.164)$$

A SQPC da hipótese é

$$\begin{aligned} \mathbf{H} &= \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \\ &= \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \\ &\approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \end{aligned} \quad (11.165)$$

Nesse caso,

$$\mathbf{H} = \mathbf{T}_{\text{mod}}.$$

O modelo completo contém intercepto e covariável, enquanto o modelo sob H_0 contém apenas o intercepto. Portanto, $\mathbf{H}$ representa exatamente a redução da SQPC residual obtida pela inclusão da covariável.

Como o modelo reduzido contém somente a média geral,

$$\mathbf{E}_R = \mathbf{T},$$

e

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}.$$

Assim, a hipótese sobre a covariável produz o par

$$(\mathbf{H}, \mathbf{E}),$$

formado pela variação associada ao efeito examinado e pela variação residual.

A decisão inferencial sobre essa hipótese será construída no Capítulo 12.

Hipótese sobre uma combinação das respostas

A mesma estrutura permite avaliar o efeito da covariável sobre uma combinação específica das respostas.

Considere

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A resposta transformada é

$$Y_1 - Y_2.$$

A hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{c}_2 = 0 \quad (11.166)$$

afirma que a covariável não apresenta efeito sobre a diferença entre as duas respostas.

A estimativa é

$$\begin{aligned} \hat{\theta} &= \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} \mathbf{c}_2 \\ &= \frac{92}{35} \\ &\approx 2,629. \end{aligned}$$

Como

$$V_{C_1} = \frac{2}{35},$$

a SQPC da hipótese para essa combinação de respostas é o escalar

$$\begin{aligned} H_{c_2} &= \frac{\hat{\theta}^2}{V_{C_1}} \\ &= \frac{4232}{35} \\ &\approx 120,914. \end{aligned}$$

A SQPC residual dessa resposta transformada é

$$\begin{aligned} E_{c_2} &= \mathbf{c}_2^\top \mathbf{E} \mathbf{c}_2 \\ &= \frac{318}{35} \\ &\approx 9,086. \end{aligned} \tag{11.167}$$

A hipótese sobre a diferença $Y_1 - Y_2$ produz, portanto, o par escalar

$$(H_{c_2}, E_{c_2}) = \left(\frac{4232}{35}, \frac{318}{35} \right).$$

O exemplo mostra duas formas de utilizar o mesmo ajuste. Com $\mathbf{C}_2 = \mathbf{I}_2$, examina-se simultaneamente o efeito da covariável nas duas respostas. Com

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

examina-se o efeito da covariável sobre a diferença entre elas.

A construção das estatísticas de teste a partir desses pares pertence aos capítulos posteriores.

Neste exemplo, uma única matriz de delineamento produziu sucessivamente

$$\widehat{\mathbf{B}}_{\text{obs}}, \quad \widehat{\mathbf{Y}}, \quad \widehat{\mathbf{U}}, \quad \mathbf{E}, \quad \widehat{\Sigma}_{\text{obs}}$$

e as matrizes associadas às hipóteses examinadas. No modelo de grupos desenvolvido anteriormente, a mesma estrutura produz

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{H} = \mathbf{T}_{\text{entre}}$$

quando a hipótese compara os vetores de médias dos grupos. Essa correspondência será utilizada posteriormente na MANOVA e na Análise Discriminante.

11.9 Síntese do capítulo

O modelo linear multivariado representa conjuntamente p respostas observadas nas mesmas n unidades:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz $\mathbf{Z}$ contém os q termos do modelo, $\mathbf{B}$ determina seus efeitos sobre as p respostas e

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}$$

é a estrutura de médias condicionais. A matriz

$$\Sigma$$

descreve a covariância residual entre as respostas de uma mesma unidade.

Quando $\mathbf{Z}$ possui posto coluna completo, a matriz de parâmetros é estimada por

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

O ajuste depende do espaço coluna de $\mathbf{Z}$. Os valores ajustados e os resíduos são

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}$$

e

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y},$$

com

$$\mathbf{P}_Z + \mathbf{M}_Z = \mathbf{I}_n.$$

Assim, cada resposta é decomposta em uma parcela pertencente ao espaço do modelo e uma parcela residual.

A SQPC residual

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{U}}^{\top} \widehat{\mathbf{U}}$$

satisfaz

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Assim,

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

é um estimador não viesado da matriz de covariâncias residual.

Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

a dispersão em torno da média geral satisfaz

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

com graus de liberdade

$$n - 1 = (r - 1) + (n - r).$$

No modelo de grupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}},$$

de modo que

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}.$$

Assim, Proposição 8.10 passa a ser representada como um caso particular da decomposição de um modelo de médias. Essa correspondência fornece a estrutura matricial utilizada posteriormente na ANOVA/MANOVA e na Análise Discriminante.

Quando

$$\text{posto}(\mathbf{Z}) < q,$$

os coeficientes podem não ser únicos, embora os valores ajustados e os resíduos permaneçam determinados pelo espaço coluna de $\mathbf{Z}$. As comparações de interesse devem então ser formuladas por funções estimáveis, como

$$\mathbf{CB},$$

com

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A hipótese linear multivariada geral é

$$H_0 : \mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0.$$

A matriz $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas. A hipótese produz duas matrizes construídas sobre as mesmas combinações de respostas:

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta}$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2.$$

A primeira representa a variação associada ao afastamento da hipótese; a segunda representa a variação residual correspondente. Quando $\mathbf{C}_2 = \mathbf{I}_p$, obtém-se o par

$$(\mathbf{H}, \mathbf{E}),$$

que será utilizado posteriormente na MANOVA.

A Tabela 11.3 reúne os principais objetos utilizados no capítulo.

Tabela 11.3: Principais objetos do modelo linear multivariado.

Objeto	Expressão	Papel
estrutura de médias	$\mathbf{ZB}$	determina os vetores de médias permitidos pelo modelo
estimador dos parâmetros	$\widehat{\mathbf{B}}$	estima os coeficientes associados aos termos e às respostas
projektor do modelo	$\mathbf{P}_Z$	produz os valores ajustados
projektor residual	$\mathbf{M}_Z$	produz os resíduos
SQPC residual	$\mathbf{E}$	representa a variação que permanece após o ajuste
SQPC do modelo	$\mathbf{T}_{\text{mod}}$	representa a dispersão dos valores ajustados em torno da média geral
modelo de grupos	$\mathbf{E} = \mathbf{T}_{\text{intra}}, \mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}$	relaciona o modelo linear à decomposição intra e entre grupos
função estimável	$\mathbf{CB}$	representa comparações determinadas pelo modelo
hipótese geral	$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$	combina termos do modelo e respostas
SQPC da hipótese	$\mathbf{H}$	representa a variação associada ao afastamento da hipótese

Ao concluir este capítulo, o estudante deve ser capaz de:

- formular um modelo linear para várias respostas e interpretar $\mathbf{Z}$, $\mathbf{B}$ e Σ ;
- obter valores ajustados e resíduos por meio das projeções associadas a $\mathbf{Z}$;
- construir a SQPC residual e estimar a matriz de covariâncias dos erros;
- decompor a dispersão total em parcelas associada ao modelo e residual;
- relacionar, no modelo de grupos, as matrizes $\mathbf{H}$ e $\mathbf{E}$ às dispersões entre e dentro dos grupos;

- distinguir unicidade dos coeficientes de estimabilidade de combinações dos parâmetros;
- interpretar a função de $\mathbf{C}_1$ e de $\mathbf{C}_2$ em uma hipótese linear;
- formular hipóteses na forma $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$ e construir as SQPCs correspondentes.

Este capítulo construiu os estimadores, as projeções e as matrizes SQPC que representam a variação associada ao modelo, ao resíduo e às hipóteses lineares. O Capítulo 12 desenvolverá as distribuições amostrais desses objetos e mostrará como utilizá-los na construção de testes e regiões de confiança no contexto multivariado.

12 Inferência Multivariada

Os capítulos anteriores construíram os objetos sobre os quais será formulada a inferência multivariada. A matriz de covariâncias populacional foi definida em Definição 8.2, a distribuição normal multivariada em Definição 9.1, o vetor de médias amostral e suas propriedades em Proposição 10.6, e a matriz de covariâncias amostral em Definição 10.14. O modelo linear multivariado foi definido em Definição 11.3 e sua hipótese linear geral em Definição 11.17.

O objetivo deste capítulo é obter distribuições amostrais para esses objetos e utilizá-las na construção de testes de hipóteses e regiões de confiança. A distribuição de Wishart descreverá as matrizes SQPC sob normalidade, enquanto a estatística T^2 de Hotelling permitirá realizar inferência sobre vetores de médias quando a matriz de covariâncias populacional é desconhecida.

Os resultados exatos serão desenvolvidos principalmente sob normalidade multivariada. Resultados assintóticos serão utilizados quando a distribuição exata não estiver disponível ou quando o objetivo for descrever o comportamento limite das estatísticas. As duas situações serão distinguidas porque dependem de condições diferentes.

O capítulo também obterá as distribuições dos estimadores e das matrizes SQPC construídas no modelo linear multivariado. Esses resultados encerram a base probabilística e inferencial do Módulo 2 e serão utilizados na formulação das técnicas do Módulo 3.

Convenções de notação

Neste capítulo:

- $\bar{\mathbf{X}}$ representa o vetor de médias amostral como estatística aleatória e $\bar{\mathbf{x}}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória e $\mathbf{S}$ sua realização observada;
- $\mathbf{T}$ representa a SQPC amostral aleatória e $\mathbf{T}$ sua realização observada;
- $\mathbf{W}$ representa uma matriz aleatória com distribuição de Wishart;
- $\mathbf{E}_{\text{res}}$ e $\mathbf{E}$ representam, respectivamente, a SQPC residual aleatória e sua realização observada;
- $\mathbf{H}$ e $\mathbf{H}$ representam, respectivamente, a SQPC da hipótese aleatória e sua realização observada;
- $\mathbf{Z}$ continua representando a matriz de delineamento do modelo linear multivariado;
- $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas nas hipóteses lineares

definidas no Capítulo 11;

- $\mathbf{M}_Z$ permanece reservada ao projetor residual;
- $\mathbf{A}$ será utilizada posteriormente para formular hipóteses lineares diretamente sobre o vetor de médias.

As convenções preservam a distinção entre objetos populacionais, estatísticas aleatórias e realizações observadas estabelecida nos capítulos anteriores.

12.1 Distribuições amostrais exatas e assintóticas

A inferência estatística utiliza a distribuição amostral de uma estatística para quantificar sua variabilidade e calibrar procedimentos como testes e regiões de confiança. Essa distribuição pode ser conhecida exatamente sob um modelo probabilístico especificado ou aproximada por seu comportamento limite quando o tamanho amostral cresce.

Definição 12.1 (Resultados exatos e assintóticos). Um **resultado exato** é válido para o tamanho amostral considerado sem recorrer a um argumento limite. Quando o resultado é distribucional, ele fornece a distribuição da estatística sob as hipóteses probabilísticas especificadas.

Um **resultado assintótico** descreve o comportamento limite de uma estatística quando o tamanho amostral tende ao infinito. Sua utilização em amostras finitas constitui uma aproximação cuja qualidade depende das condições do problema.

Neste capítulo, os resultados exatos dependerão principalmente da normalidade multivariada. Os resultados assintóticos considerarão, salvo indicação em contrário, o regime

$$p \text{ fixo} \quad \text{e} \quad n \rightarrow \infty. \quad (12.1)$$

Essa distinção deve ser mantida também na interpretação: uma distribuição exata decorre do modelo probabilístico especificado, enquanto uma distribuição limite decorre de um argumento de convergência.

12.1.1 Distribuição da média amostral sob normalidade

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

independente e identicamente distribuída, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

O vetor de médias amostral é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Por Proposição 10.6,

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Esses resultados dependem dos momentos correspondentes, mas não da normalidade multivariada.

A normalidade acrescenta a distribuição exata da estatística.

Proposição 12.1 (Distribuição da média amostral sob normalidade). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

então

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.2)$$

O resultado é exato para qualquer $n \geq 1$.

Comprovação. A média amostral é uma combinação linear dos vetores normais independentes. Por Proposição 9.4, sua distribuição é normal multivariada.

Como Proposição 10.6 fornece

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

obtém-se Equação 12.2. □

A proposição mostra a diferença entre propriedades de um estimador e sua distribuição amostral. A igualdade

$$E(\bar{\mathbf{X}}) = \mu$$

expressa ausência de viés. Já

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

descreve toda a distribuição da estatística sob o modelo normal.

Se

$$\Sigma \succ \mathbf{0},$$

a média amostral pode ser branqueada:

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (12.3)$$

Aplicando o resultado qui-quadrado da distância de Mahalanobis estabelecido em Proposição 9.8,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \sim \chi_p^2. \quad (12.4)$$

O fator n aparece porque

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

de modo que

$$\left(\frac{\Sigma}{n}\right)^{-1} = n\Sigma^{-1}.$$

A expressão em Equação 12.4 fornece a base do procedimento inferencial para o vetor de médias quando Σ é conhecida. O caso em que Σ precisa ser estimada exigirá a distribuição da matriz de covariâncias amostral.

12.1.2 Teorema Central do Limite multivariado

Fora da família normal, a distribuição de

$$\bar{\mathbf{X}}$$

depende da distribuição conjunta da população. Em dimensão fixa, o Teorema Central do Limite multivariado fornece uma aproximação normal sob condições mais gerais (Vaart, 1998).

Teorema 12.1 (Teorema Central do Limite multivariado). *Considere, para dimensão fixa p , vetores aleatórios independentes e identicamente distribuídos*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu$$

e matriz de covariâncias finita

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma). \quad (12.5)$$

Comprovação. Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

considere

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \mu).$$

As variáveis

$$\mathbf{a}^\top \mathbf{X}_1, \dots, \mathbf{a}^\top \mathbf{X}_n$$

são independentes e identicamente distribuídas, com média

$$\mathbf{a}^\top \mu$$

e variância finita

$$\mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema Central do Limite univariado,

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Como a convergência vale para todo vetor fixo $\mathbf{a}$, o Teorema de Cramér–Wold em Teorema 9.1 implica Equação 12.5. $\square$

O resultado permite escrever, em sentido assintótico,

$$\bar{\mathbf{X}} \overset{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right). \quad (12.6)$$

A mesma expressão possui, portanto, dois significados distintos:

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma distribuição **exata** quando a população é normal multivariada, enquanto

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma aproximação **assintótica** sob as condições do Teorema 12.1.

Se

$$\Sigma \succ \mathbf{0},$$

então

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p (\mathbf{0}, \mathbf{I}_p), \quad (12.7)$$

e, pelo teorema da aplicação contínua,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} \chi_p^2. \quad (12.8)$$

Assim, a mesma forma quadrática possui distribuição qui-quadrado exata sob normalidade e distribuição limite qui-quadrado sob as condições do TCL multivariado.

Alcance da aproximação assintótica

O Teorema 12.1 considera dimensão p fixa e exige a existência dos momentos de segunda ordem.

O resultado não justifica automaticamente a inferência clássica quando há dependência entre unidades, inexistência de segundos momentos ou crescimento de p juntamente com n . Além disso, a substituição de Σ por uma matriz de covariâncias estimada introduz outra fonte de aleatoriedade que precisa ser considerada separadamente.

A distribuição da média amostral descreve a incerteza associada à localização. Quando Σ é desconhecida, a inferência depende também da distribuição da matriz que estima a dispersão. Sob normalidade multivariada, essa distribuição é obtida a partir da distribuição de Wishart.

12.2 Distribuição de Wishart

A inferência sobre uma matriz de covariâncias exige conhecer a distribuição das matrizes de produtos cruzados que a originam. No caso univariado, somas de quadrados de variáveis normais padronizadas conduzem à distribuição qui-quadrado. A distribuição de Wishart estende essa construção para somas de produtos externos de vetores normais e ocupa, na inferência normal multivariada, papel análogo ao da distribuição qui-quadrado na inferência univariada (Muirhead, 1982).

12.2.1 Construção e parametrização

Considere vetores aleatórios independentes

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \in \mathbb{R}^p$$

tais que

$$\mathbf{U}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 1, \dots, \nu,$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0}.$$

Cada produto externo

$$\mathbf{U}_j \mathbf{U}_j^\top$$

é uma matriz simétrica e positiva semidefinida.

Definição 12.2 (Distribuição de Wishart). Se

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma),$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0},$$

então a matriz aleatória

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{U}_j \mathbf{U}_j^{\top} \quad (12.9)$$

segue uma distribuição de Wishart com ν graus de liberdade e matriz de escala Σ .

Escreve-se

$$\mathbf{W} \sim W_p(\nu, \Sigma). \quad (12.10)$$

Nesta parametrização,

$$\Sigma$$

é denominada **matriz de escala** e ν é o número de graus de liberdade. A relação

$$E(\mathbf{W}) = \nu \Sigma$$

será estabelecida em Proposição [12.3](#).

A parametrização é indicada explicitamente porque diferentes convenções para a matriz de escala podem ser encontradas na literatura.

Quando

$$p = 1,$$

a matriz Wishart possui um único elemento. Se

$$\Sigma = [\sigma^2],$$

então

$$W = \sum_{j=1}^{\nu} U_j^2$$

e

$$\frac{W}{\sigma^2} \sim \chi_{\nu}^2. \quad (12.11)$$

Assim, a distribuição qui-quadrado é o caso univariado da distribuição de Wishart.

12.2.2 Suporte, posto e definição positiva

Organize os vetores geradores nas linhas da matriz

$$\mathcal{U} = \begin{bmatrix} \mathbf{U}_1^\top \\ \vdots \\ \mathbf{U}_\nu^\top \end{bmatrix} \in \mathbb{R}^{\nu \times p}.$$

Então,

$$\mathbf{W} = \mathcal{U}^\top \mathcal{U}. \quad (12.12)$$

Portanto, $\mathbf{W}$ é uma matriz de Gram no sentido de Definição 3.18. Por Proposição 3.9,

$$\mathbf{W} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{W}) = \text{posto}(\mathcal{U}) \leq \min(\nu, p).$$

Proposição 12.2 (Posto de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, com

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade 1,

$$\text{posto}(\mathbf{W}) = \min(\nu, p). \quad (12.13)$$

Consequentemente:

- se $\nu \geq p$, então $\mathbf{W} \succ \mathbf{0}$ com probabilidade 1;
- se $\nu < p$, então $\text{posto}(\mathbf{W}) = \nu$ com probabilidade 1 e a matriz é singular.

Como $\Sigma \succ \mathbf{0}$, cada vetor gerador possui distribuição normal não singular. A distribuição conjunta das entradas de $\mathcal{U}$ é contínua, e o conjunto das matrizes cujo posto é menor que $\min(\nu, p)$ possui probabilidade zero. Assim, a matriz de Gram atinge quase certamente o maior posto permitido por suas dimensões (Muirhead, 1982).

A condição

$$\nu \geq p$$

é, portanto, necessária e suficiente para a definição positiva quase certa na construção com graus de liberdade inteiros e

$$\Sigma \succ \mathbf{0}.$$

12.2.3 Momentos

A esperança da matriz Wishart é obtida diretamente da construção por produtos externos.

Proposição 12.3 (Momentos de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, então

$$E(\mathbf{W}) = \nu \Sigma. \quad (12.14)$$

Para os elementos da matriz,

$$\text{Cov}(W_{jk}, W_{\ell m}) = \nu (\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}). \quad (12.15)$$

Comprovação. Pela construção em Equação 12.9,

$$W_{jk} = \sum_{h=1}^{\nu} U_{hj} U_{hk}.$$

Como

$$E(U_{hj} U_{hk}) = \sigma_{jk},$$

segue que

$$E(W_{jk}) = \nu\sigma_{jk}.$$

Portanto,

$$E(\mathbf{W}) = \nu\Sigma.$$

A expressão para

$$\text{Cov}(W_{jk}, W_{\ell m})$$

decorre dos momentos de quarta ordem do vetor normal de média zero e da independência entre os ν vetores geradores (Muirhead, 1982). $\square$

Em particular,

$$\text{Var}(W_{jj}) = 2\nu\sigma_{jj}^2, \quad (12.16)$$

e, para $j \neq k$,

$$\text{Var}(W_{jk}) = \nu(\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2). \quad (12.17)$$

Dividindo pelos graus de liberdade,

$$E\left(\frac{\mathbf{W}}{\nu}\right) = \Sigma.$$

Além disso, Equação 12.15 implica

$$\text{Cov}\left(\frac{W_{jk}}{\nu}, \frac{W_{\ell m}}{\nu}\right) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{\nu}.$$

Portanto, para Σ fixa, a variabilidade dos elementos de $\mathbf{W}/\nu$ diminui à medida que ν aumenta.

12.2.4 Formas quadráticas

A analogia com a distribuição qui-quadrado também aparece em qualquer direção fixa do espaço das variáveis.

Proposição 12.4 (Forma quadrática de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2, então, para qualquer

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

vale

$$\frac{\mathbf{a}^\top \mathbf{W} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_\nu^2. \quad (12.18)$$

Comprovação. De Equação 12.9,

$$\mathbf{a}^\top \mathbf{W} \mathbf{a} = \sum_{j=1}^{\nu} (\mathbf{a}^\top \mathbf{U}_j)^2.$$

Por Proposição 9.4,

$$\mathbf{a}^\top \mathbf{U}_j \sim N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Assim, as variáveis

$$\frac{\mathbf{a}^\top \mathbf{U}_j}{\sqrt{\mathbf{a}^\top \Sigma \mathbf{a}}}$$

são normais padrão independentes. A soma de seus quadrados possui distribuição χ_ν^2 . $\square$

Assim, cada projeção univariada de uma matriz Wishart recupera a estrutura qui-quadrado correspondente à variância naquela direção.

12.2.5 Aditividade

Proposição 12.5 (Aditividade da distribuição de Wishart). *Se*

$$\mathbf{W}_1 \sim W_p(\nu_1, \Sigma)$$

e

$$\mathbf{W}_2 \sim W_p(\nu_2, \Sigma)$$

são independentes e possuem a mesma matriz de escala, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\nu_1 + \nu_2, \Sigma). \quad (12.19)$$

Comprovação. Pela construção da distribuição, as duas matrizes podem ser representadas por somas de, respectivamente, ν_1 e ν_2 produtos externos de vetores normais independentes com a mesma matriz de covariâncias Σ .

A soma das duas matrizes reúne

$$\nu_1 + \nu_2$$

produtos externos independentes e, portanto, possui a distribuição indicada. $\square$

A condição de escala comum é necessária para esse resultado. Matrizes Wishart independentes com matrizes de escala distintas não podem, em geral, ser somadas mantendo a mesma forma Wishart.

12.2.6 Transformações lineares

A transformação de uma matriz Wishart acompanha a transformação da matriz de covariâncias dos vetores normais que a geram.

Proposição 12.6 (Transformação linear de uma matriz Wishart). *Considere*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2.

Se

$$\mathbf{L} \in \mathbb{R}^{r \times p}$$

possui posto linha completo,

$$\text{posto}(\mathbf{L}) = r,$$

então

$$\mathbf{LWL}^\top \sim W_r(\nu, \mathbf{L}\Sigma\mathbf{L}^\top). \quad (12.20)$$

Comprovação. Pela construção,

$$\mathbf{LWL}^\top = \sum_{j=1}^{\nu} (\mathbf{LU}_j)(\mathbf{LU}_j)^\top.$$

Por Proposição 9.4,

$$\mathbf{LU}_j \sim N_r(\mathbf{0}, \mathbf{L}\Sigma\mathbf{L}^\top).$$

Como as transformações são aplicadas separadamente aos vetores independentes, os vetores transformados permanecem independentes.

Como $\mathbf{L}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{L}\Sigma\mathbf{L}^\top \succ \mathbf{0}.$$

Logo, a soma possui a distribuição apresentada. $\square$

Se $\mathbf{L}$ não possui posto linha completo,

$$\mathbf{L}\Sigma\mathbf{L}^\top$$

é singular e a distribuição fica restrita ao subespaço imagem de $\mathbf{L}$. Essa extensão singular não será necessária na sequência principal.

Tomando

$$\mathbf{L} = \Sigma^{-1/2},$$

com a raiz quadrada principal definida em Definição 5.9, obtém-se

$$\Sigma^{-1/2} \mathbf{W} \Sigma^{-1/2} \sim W_p(\nu, \mathbf{I}_p). \quad (12.21)$$

A transformação remove a matriz de escala da distribuição, de modo análogo ao branqueamento normal em Equação 9.23.

12.2.7 Aprofundamento: densidade da distribuição de Wishart

Leitura de aprofundamento

Os resultados inferenciais deste capítulo utilizam principalmente a construção por produtos externos, o posto, os momentos, a aditividade e as transformações da distribuição de Wishart.

A densidade é apresentada como aprofundamento porque será útil para relacionar a distribuição de Wishart a verossimilhanças envolvendo matrizes de covariâncias.

A construção em Definição 12.2 utiliza um número inteiro de vetores normais. A família Wishart não singular admite uma extensão para graus de liberdade reais

$$\nu > p - 1$$

por meio de sua densidade no cone das matrizes simétricas positivas definidas (Muirhead, 1982).

Proposição 12.7 (Densidade da distribuição de Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com

$$\nu > p - 1$$

e

$$\Sigma \succ \mathbf{0},$$

então sua densidade é

$$f_{\mathbf{W}}(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-p-1)/2} \exp \left[-\frac{1}{2} \text{tr} (\Sigma^{-1} \mathbf{W}) \right]}{2^{\nu p/2} |\Sigma|^{\nu/2} \Gamma_p(\nu/2)}, \quad (12.22)$$

para

$$\mathbf{W} \succ \mathbf{0}.$$

A função gama multivariada é

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad (12.23)$$

definida para

$$a > \frac{p-1}{2}.$$

Quando a Wishart é construída pela soma de ν produtos externos e

$$\nu < p,$$

a matriz é singular com probabilidade 1. Nesse caso, sua distribuição está concentrada em matrizes positivas semidefinidas de posto ν e não possui a densidade anterior no cone positivo definido.

A sequência inferencial deste capítulo utilizará graus de liberdade inteiros provenientes do tamanho amostral ou do posto de matrizes de projeção.

12.2.8 Distribuição da SQPC e da covariância amostral

Retomando Definição 10.13,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Por Definição 10.14,

$$\mathbf{S} = \frac{\mathbf{T}}{n-1}.$$

Por Proposição 10.10,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Sob normalidade multivariada, a distribuição completa dessa estatística pode ser estabelecida.

Teorema 12.2 (Distribuição da SQPC e da covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\mathbf{T} = (n-1)\mathbf{S} \sim W_p(n-1, \Sigma). \quad (12.24)$$

Comprovação. Organize a amostra na matriz aleatória

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix}.$$

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

cuja primeira linha seja

$$\frac{1}{\sqrt{n}}\mathbf{1}_n^\top,$$

e defina a matriz transformada

$$\mathcal{X}^* = \mathbf{Q}\mathcal{X}.$$

Sua primeira linha satisfaz

$$(\mathbf{X}_1^*)^\top = \sqrt{n} \bar{\mathbf{X}}^\top. \quad (12.25)$$

As demais linhas são combinações lineares cujos coeficientes somam zero. Portanto,

$$E(\mathbf{X}_j^*) = \mathbf{0}, \quad j = 2, \dots, n.$$

A covariância cruzada entre duas linhas transformadas é

$$\text{Cov}(\mathbf{X}_j^*, \mathbf{X}_k^*) = [\mathbf{Q}\mathbf{Q}^\top]_{jk} \Sigma = \delta_{jk} \Sigma.$$

As linhas transformadas são conjuntamente normais. Por Proposição 9.6, as covariâncias cruzadas nulas implicam independência. Assim,

$$\mathbf{X}_2^*, \dots, \mathbf{X}_n^* \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma).$$

A matriz de centralização pode ser escrita como

$$\mathbf{H}_n = \mathbf{Q}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{I}_{n-1} \end{bmatrix} \mathbf{Q}.$$

Utilizando a forma matricial da SQPC estabelecida em Equação 10.62,

$$\begin{aligned} \mathbf{T} &= \mathcal{X}^\top \mathbf{H}_n \mathcal{X} \\ &= \sum_{j=2}^n \mathbf{X}_j^* (\mathbf{X}_j^*)^\top. \end{aligned}$$

Essa é a soma de $n - 1$ produtos externos de vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Pela Definição 12.2,

$$\mathbf{T} \sim W_p(n - 1, \Sigma).$$

□

A esperança obtida pela distribuição de Wishart é consistente com Proposição 10.10 e Proposição 10.11.

A informação nova é a distribuição amostral completa:

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma).$$

Pela Proposição 12.4, para qualquer

$$\mathbf{a} \neq \mathbf{0},$$

tem-se

$$\frac{(n-1)\mathbf{a}^\top \mathbf{S} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_{n-1}^2. \quad (12.26)$$

Assim, a variância amostral de qualquer combinação linear fixa possui a mesma estrutura qui-quadrado conhecida do caso univariado.

Para os elementos de $\mathbf{S}$,

$$\text{Cov}(S_{jk}, S_{\ell m}) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{n-1}. \quad (12.27)$$

Em particular,

$$\text{Var}(S_{jj}) = \frac{2\sigma_{jj}^2}{n-1}$$

e, para $j \neq k$,

$$\text{Var}(S_{jk}) = \frac{\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2}{n-1}.$$

Esses resultados são exatos sob normalidade multivariada.

A matriz de covariâncias amostral possui, com probabilidade 1,

$$\text{posto}(\mathbf{S}) = \min(p, n-1). \quad (12.28)$$

Portanto, sob

$$\Sigma \succ \mathbf{0},$$

a condição

$$n > p \tag{12.29}$$

é necessária e suficiente para que

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1.

Quando

$$p \geq n,$$

a matriz $\mathbf{S}$ é necessariamente singular. Essa restrição dimensional terá consequência direta para a forma clássica da estatística T^2 de Hotelling.

Sob o modelo normal, Equação 10.44 fornece

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}.$$

Sempre que sua interpretação como estimador de máxima verossimilhança no espaço

$$\Sigma \succ \mathbf{0}$$

for válida,

$$n\widehat{\Sigma}_{\text{MV}} = \mathbf{T} \sim W_p(n-1, \Sigma). \tag{12.30}$$

A distribuição continua envolvendo $n-1$ graus de liberdade, pois a média populacional também foi estimada a partir da amostra.

12.2.9 Independência entre média e covariância

A transformação ortogonal utilizada na prova do Teorema 12.2 separa a informação amostral associada à localização da informação associada à dispersão.

A primeira linha transformada depende exclusivamente de

$$\bar{\mathbf{X}},$$

enquanto

$$\mathbf{T}$$

e, conseqüentemente,

$$\mathbf{S},$$

dependem apenas das demais linhas.

Teorema 12.3 (Independência entre média e covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

também vale

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.31)$$

Comprovação. Na prova de Teorema 12.2, a primeira linha de $\mathcal{X}^*$ depende apenas de

$$\bar{\mathbf{X}},$$

enquanto $\mathbf{T}$ depende apenas das demais linhas transformadas.

Esses dois blocos são independentes por Proposição 9.6. Portanto,

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

segue também

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

□

A independência é um resultado **exato da amostragem normal**. Ela não decorre somente da independência entre as observações.

O que depende da normalidade

As propriedades

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

não exigem normalidade multivariada.

Em contraste,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

são resultados exatos da amostragem normal.

Para uma população geral, a distribuição de $\mathbf{S}$ depende de características adicionais da distribuição, incluindo momentos de ordem superior, e a média e a covariância amostrais não são, em geral, independentes.

Temos, portanto, sob amostragem normal, o par

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

e

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

com

$$\bar{\mathbf{X}} \perp \mathbf{S}. \tag{12.32}$$

O par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

combina uma distribuição normal para a localização, uma distribuição Wishart para a dispersão e independência entre os dois objetos. Essa estrutura normal–Wishart será utilizada posteriormente na construção da estatística T^2 de Hotelling.

No modelo linear multivariado, a mesma organização reaparece. O vetor de médias amostral é substituído pelo estimador de $\mathbf{B}$, enquanto a SQPC amostral é substituída pela SQPC residual. Os $n-1$ graus de liberdade do problema de uma única média passam a ser os $n-r$ graus de liberdade residuais do modelo.

12.3 Distribuições no modelo linear multivariado

O modelo linear normal multivariado foi definido em Definição 11.7. Nesta seção, a normalidade será utilizada para obter as distribuições amostrais exatas dos estimadores e das matrizes SQPC construídas no Capítulo 11.

Retomando Equação 11.22,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma), \quad \Sigma \succ \mathbf{0}. \quad (12.33)$$

A matriz de delineamento é considerada fixa, ou a análise é condicionada em seus valores observados. Defina

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r,$$

em concordância com Equação 11.77.

A estrutura probabilística será desenvolvida em três etapas: distribuição do estimador dos parâmetros, distribuição da SQPC residual e distribuição da SQPC associada a uma hipótese linear.

12.3.1 Distribuição do estimador da matriz de parâmetros

Suponha inicialmente que

$$r = q.$$

Nesse caso, o estimador de mínimos quadrados definido em Equação 11.36 é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Por Equação 11.39,

$$\widehat{\mathbf{B}} = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.$$

Assim, $\widehat{\mathbf{B}}$ é uma transformação afim da matriz normal de erros.

Proposição 12.8 (Distribuição do estimador da matriz de parâmetros). *Sob o modelo linear normal multivariado e*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$\widehat{\mathbf{B}} \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{B}, (\mathbf{Z}^\top \mathbf{Z})^{-1}, \Sigma \right]. \quad (12.34)$$

Equivalentemente,

$$\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z} \sim N_{pq} \left[\text{vec}(\mathbf{B}), \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]. \quad (12.35)$$

Comprovação. Defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então

$$\widehat{\mathbf{B}} = \mathbf{B} + \mathbf{A}_Z \mathcal{E}.$$

Pela transformação da distribuição normal matricial,

$$\mathbf{A}_Z \mathcal{E} \mid \mathbf{Z} \sim N_{q \times p}(\mathbf{0}, \mathbf{A}_Z \mathbf{A}_Z^\top, \Sigma).$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

segue o resultado. □

A distribuição em Equação 12.34 contém como momentos os resultados de Proposição 11.3. A matriz

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a variabilidade dos coeficientes, enquanto

$$\Sigma$$

descreve a dependência residual entre as respostas.

Quando

$$r < q,$$

os coeficientes de $\mathbf{B}$ podem não ser únicos. Nesse caso, a inferência deve ser formulada sobre as funções estimáveis caracterizadas em Proposição 11.12.

12.3.2 Distribuição de funções estimáveis

O Capítulo 11 caracterizou as funções estimáveis do modelo linear multivariado. Sob normalidade, a distribuição exata de seu estimador decorre de uma transformação linear da matriz de erros.

Proposição 12.9 (Distribuição de uma função estimável). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2, \mathbf{V}_{C_1}, \Sigma_{C_2}). \quad (12.36)$$

Nesse resultado,

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2$$

e

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2.$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

satisfaz a condição de estimabilidade

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z},$$

enquanto

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

As matrizes de covariâncias são

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \quad (12.37)$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^{\top} \Sigma \mathbf{C}_2. \quad (12.38)$$

Sob essas condições,

$$\mathbf{V}_{C_1} \succ \mathbf{0} \quad e \quad \Sigma_{C_2} \succ \mathbf{0}.$$

Equivalentemente,

$$\text{vec}(\widehat{\Theta}) \mid \mathbf{Z} \sim N_{gs} \left[\text{vec}(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2), \Sigma_{C_2} \otimes \mathbf{V}_{C_1} \right]. \quad (12.39)$$

Comprovação. Pela estimabilidade,

$$\mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z} = \mathbf{C}_1.$$

Portanto,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 + \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2.$$

A segunda parcela é uma transformação bilateral da matriz normal de erros, com matriz de covariâncias entre linhas $\mathbf{V}_{C_1}$ e matriz de covariâncias entre colunas Σ_{C_2} . Isso fornece Equação 12.36. $\square$

A matriz $\mathbf{V}_{C_1}$ representa a variabilidade associada às combinações dos termos do modelo, enquanto Σ_{C_2} representa a covariância residual das combinações de respostas. A normalidade acrescenta a distribuição amostral exata à estrutura construída no Capítulo 11.

12.3.3 Distribuição da SQPC residual

Por Definição 11.11,

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

pode-se escrever

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

A matriz

$$\mathbf{M}_Z$$

é um projetor ortogonal de posto

$$\nu_E = n - r.$$

Proposição 12.10 (Distribuição da SQPC residual). *Sob o modelo linear normal multivariado, se*

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r \geq 1,$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.40)$$

Comprovação. Seja

$$\mathbf{Q}_E \in \mathbb{R}^{n \times (n-r)}$$

uma matriz cujas colunas formam uma base ortonormal de

$$\mathcal{C}(\mathbf{M}_Z).$$

Como $\mathbf{M}_Z$ é o projetor ortogonal sobre esse espaço,

$$\mathbf{M}_Z = \mathbf{Q}_E \mathbf{Q}_E^\top.$$

Defina

$$\mathcal{E}^* = \mathbf{Q}_E^\top \mathcal{E}.$$

Pela transformação da normal matricial,

$$\mathcal{E}^* \mid \mathbf{Z} \sim N_{(n-r) \times p}(\mathbf{0}, \mathbf{I}_{n-r}, \Sigma).$$

Portanto, suas $n - r$ linhas são vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\begin{aligned} \mathbf{E}_{\text{res}} &= \mathcal{E}^\top \mathbf{Q}_E \mathbf{Q}_E^\top \mathcal{E} \\ &= (\mathcal{E}^*)^\top \mathcal{E}^*. \end{aligned}$$

Pela construção da distribuição de Wishart,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma).$$

□

A esperança fornecida pela distribuição de Wishart coincide com Proposição 11.7.

Como o estimador residual foi definido em Equação 11.79 por

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r},$$

segue que

$$(n - r)\widehat{\Sigma} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.41)$$

O posto da SQPC residual é, com probabilidade 1,

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r). \quad (12.42)$$

Assim,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq p. \quad (12.43)$$

A condição é a contraparte probabilística do limite de posto discutido no Capítulo 11 e decorre diretamente de Proposição 12.2.

12.3.4 Independência entre estimação e SQPC residual

Para uma função estimável,

$$\widehat{\Theta} - \Theta = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2,$$

enquanto os resíduos satisfazem

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}.$$

Como

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

as duas parcelas correspondem a projeções ortogonais dos erros.

Proposição 12.11 (Independência entre estimação paramétrica e resíduos). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \perp \widehat{\mathcal{U}} \mid \mathbf{Z}.$$

Consequentemente,

$$\widehat{\Theta} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.44)$$

Comprovação. As duas matrizes são transformações lineares da mesma matriz normal de erros e, portanto, são conjuntamente normais.

Como

$$\mathbf{C}_1 \mathbf{Z} + \mathbf{M}_Z = \mathbf{0},$$

a covariância cruzada entre as duas transformações é nula. Por Proposição 9.6, segue a independência.

Como $\mathbf{E}_{\text{res}}$ é função dos resíduos, a segunda independência também é obtida. $\square$

Quando $\mathbf{Z}$ possui posto coluna completo, tomando

$$\mathbf{C}_1 = \mathbf{I}_q \quad \text{e} \quad \mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.45)$$

Esse resultado generaliza a independência entre média e covariância amostrais. No modelo contendo somente intercepto,

$$\widehat{\mathbf{B}} = \bar{\mathbf{X}}^\top$$

e

$$\mathbf{E}_{\text{res}} = (n - 1)\mathbf{S}.$$

Papel da normalidade

A ortogonalidade entre as projeções garante covariância cruzada nula entre as parcelas estimada e residual.

A conclusão de **independência** utiliza adicionalmente a normalidade conjunta. Fora do modelo normal, ortogonalidade das projeções não implica, por si só, independência entre as estatísticas correspondentes.

12.3.5 Distribuição da SQPC da hipótese sob H_0

Sob o modelo linear normal multivariado, a SQPC associada à hipótese e a SQPC residual correspondente possuem distribuições Wishart independentes. Esse resultado fornece a estrutura probabilística que será utilizada posteriormente na inferência multivariada do modelo linear.

Proposição 12.12 (Distribuições da SQPC da hipótese e da SQPC residual). *Sob o modelo linear normal multivariado, com*

$$\Sigma \succ \mathbf{0},$$

considere a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (12.46)$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}, \quad \text{posto}(\mathbf{C}_1) = g,$$

representa g funções estimáveis linearmente independentes.

Além disso,

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

Defina

$$r = \text{posto}(\mathbf{Z}), \quad n - r \geq 1,$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2.$$

O afastamento aleatório da hipótese é

$$\mathcal{D} = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{Y} \mathbf{C}_2 - \Theta_0. \quad (12.47)$$

Além disso,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}.$$

Sob H_0 ,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{V}_{C_1}, \Sigma_{C_2}). \quad (12.48)$$

Defina

$$\mathbf{H} = \mathcal{D}^{\top} \mathbf{V}_{C_1}^{-1} \mathcal{D} \quad (12.49)$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^{\top} \mathbf{E}_{\text{res}} \mathbf{C}_2. \quad (12.50)$$

Então,

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_{C_2}) \quad (12.51)$$

e

$$\mathbf{E}_{C_2} \mid \mathbf{Z} \sim W_s(n - r, \Sigma_{C_2}). \quad (12.52)$$

Além disso,

$$\mathbf{H} \perp \mathbf{E}_{C_2} \mid \mathbf{Z}. \quad (12.53)$$

Comprovação. Sob H_0 ,

$$\mathbf{V}_{C_1}^{-1/2} \mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{I}_g, \Sigma_{C_2}).$$

Portanto, suas g linhas são vetores independentes com distribuição

$$N_s(\mathbf{0}, \Sigma_{C_2}).$$

Como

$$\mathbf{H} = (\mathbf{V}_{C_1}^{-1/2} \mathcal{D})^\top (\mathbf{V}_{C_1}^{-1/2} \mathcal{D}),$$

Definição 12.2 fornece

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_{C_2}).$$

Por Proposição 12.6,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2 \mid \mathbf{Z} \sim W_s(n - r, \Sigma_{C_2}).$$

A independência decorre de Proposição 12.11. □

As duas matrizes possuem a mesma matriz de escala,

$$\Sigma_{C_2},$$

mas graus de liberdade diferentes:

- g corresponde ao número de combinações linearmente independentes dos termos do modelo definidas por $\mathbf{C}_1$;
- $n - r$ corresponde à dimensão do espaço residual.

Como

$$\text{posto}(\mathbf{C}_1) = g \quad \text{e} \quad \text{posto}(\mathbf{C}_2) = s,$$

a hipótese contém gs restrições escalares independentes.

O grau de liberdade da distribuição Wishart de $\mathbf{H}$ é, entretanto, g , porque a SQPC da hipótese é construída a partir de g vetores aleatórios no espaço das s combinações de respostas.

Por Proposição 12.2,

$$\text{posto}(\mathbf{H}) = \min(g, s)$$

e

$$\text{posto}(\mathbf{E}_{C_2}) = \min(n - r, s)$$

com probabilidade 1.

Em particular,

$$\mathbf{E}_{C_2} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq s. \quad (12.54)$$

Sob a hipótese alternativa

Defina

$$\Delta_0 = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 - \Theta_0. \quad (12.55)$$

Quando

$$\Delta_0 \neq \mathbf{0},$$

a SQPC $\mathbf{H}$ possui distribuição Wishart não central. A matriz

$$\mathbf{E}_{C_2}$$

mantém sua distribuição Wishart central e permanece independente de $\mathbf{H}$ (Muirhead, 1982).

A não centralidade incorpora o afastamento entre $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ e Θ_0 e será relevante para o estudo do poder. Sua parametrização detalhada não será necessária neste capítulo.

As distribuições obtidas nesta seção fornecem a estrutura probabilística geral para hipóteses lineares multivariadas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma)$$

e

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

com independência entre as duas matrizes. Esse par constitui a base probabilística das matrizes de hipótese e erro que serão utilizadas posteriormente na MANOVA.

O passo seguinte é estabelecer como uma hipótese conjunta é transformada em uma regra inferencial, distinguindo testes globais, razão de verossimilhanças e resultados exatos ou assintóticos.

12.4 Princípios da inferência multivariada

Uma hipótese multivariada pode impor simultaneamente várias restrições sobre um vetor, uma matriz ou uma função dos parâmetros. Um teste global avalia essas restrições como uma única afirmação estatística, considerando a dependência entre seus componentes.

No modelo linear multivariado, por exemplo,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$$

é a hipótese geral definida em Definição 11.17. De forma semelhante,

$$H_0 : \mu = \mu_0$$

é uma única hipótese sobre o vetor de médias, ainda que envolva p componentes.

O nível α controla a probabilidade de rejeitar H_0 quando ela é verdadeira. Para uma alternativa especificada, o poder é a probabilidade de rejeitar H_0 quando essa alternativa é verdadeira. Na inferência multivariada, essas probabilidades dependem da forma como as várias componentes são reunidas na estatística de teste.

12.4.1 Testes globais e hipóteses simultâneas

Considere uma hipótese vetorial

$$H_0 : \mu = \mu_0.$$

Ela implica as igualdades coordenadas

$$\mu_j = \mu_{0j}, \quad j = 1, \dots, p,$$

mas a realização de p testes marginais separados não é equivalente a um teste global do vetor.

Se cada teste marginal possui nível α e os testes são independentes, a probabilidade de pelo menos uma rejeição incorreta sob a hipótese global é

$$1 - (1 - \alpha)^p. \quad (12.56)$$

Por exemplo, para

$$p = 5$$

e

$$\alpha = 0,05,$$

essa probabilidade é

$$1 - 0,95^5 \approx 0,226.$$

Quando as estatísticas são dependentes, a expressão anterior não se aplica diretamente, mas a conclusão permanece: realizar vários testes marginais no mesmo nível não garante controle do nível global.

Teste global e análise posterior

Um teste global avalia uma hipótese conjunta e utiliza a estrutura de dependência entre seus componentes.

A rejeição da hipótese global não identifica, por si só, quais componentes ou combinações lineares são responsáveis pelo afastamento. Essa investigação exige procedimentos posteriores, como contrastes ou intervalos simultâneos, com controle adequado da multiplicidade.

A distribuição da estatística sob H_0 determina a calibração do teste. Quando sua distribuição amostral exata é conhecida, os valores críticos e o valor- p podem ser obtidos diretamente dessa distribuição. Quando apenas uma distribuição limite é conhecida, a calibração é assintótica.

Sob alternativas, algumas estatísticas passam a depender de parâmetros de não centralidade que incorporam o afastamento de H_0 em relação à variabilidade do problema. Esses parâmetros são utilizados no estudo do poder, mas suas distribuições detalhadas não serão desenvolvidas neste capítulo.

12.4.2 Razão de verossimilhanças

A razão de verossimilhanças fornece um princípio geral para comparar o melhor ajuste permitido por uma hipótese nula com o melhor ajuste disponível no modelo irrestrito (Casella; Berger, 2002).

A hipótese nula restringe o espaço paramétrico do modelo irrestrito a um subconjunto de valores admissíveis.

Definição 12.3 (Estatística da razão de verossimilhanças). Considere um parâmetro

$$\vartheta \in \mathcal{P}$$

e a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0, \quad \emptyset \neq \mathcal{P}_0 \subseteq \mathcal{P}.$$

Suponha que, para as realizações consideradas,

$$0 < \sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y}) < \infty.$$

A estatística da razão de verossimilhanças é

$$\Lambda_{\text{RV}}(\mathcal{Y}) = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathcal{Y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y})}. \quad (12.57)$$

Para uma realização observada $\mathbf{y}$, o valor observado da estatística é

$$\Lambda_{\text{RV,obs}} = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})}.$$

Como

$$\mathcal{P}_0 \subseteq \mathcal{P},$$

tem-se

$$0 \leq \Lambda_{\text{RV}} \leq 1.$$

Valores próximos de 1 indicam que a restrição imposta por H_0 produz pequena redução na verossimilhança máxima. Valores reduzidos indicam maior incompatibilidade entre a hipótese nula e os dados observados.

É conveniente utilizar a transformação

$$-2 \log \Lambda_{\text{RV}}.$$

Quando os máximos são atingidos e

$$\hat{\vartheta}$$

e

$$\tilde{\vartheta}$$

denotam, respectivamente, os estimadores de máxima verossimilhança irrestrito e restrito,

$$-2 \log \Lambda_{\text{RV}} = 2 \left[\ell(\hat{\vartheta}) - \ell(\tilde{\vartheta}) \right], \quad (12.58)$$

em que

$$\ell(\vartheta) = \log L(\vartheta; \mathbf{y}).$$

A estatística é não negativa e cresce à medida que as restrições impostas por H_0 reduzem o máximo da verossimilhança.

A distribuição de

$$-2 \log \Lambda_{\text{RV}}$$

depende do modelo. Em alguns problemas, existe uma distribuição exata ou uma transformação exata para uma distribuição conhecida. Quando essa distribuição não está disponível, modelos paramétricos regulares admitem uma aproximação assintótica fornecida pelo teorema de Wilks.

12.4.3 Resultado assintótico de Wilks

Teorema 12.4 (Resultado assintótico de Wilks). *Considere um espaço paramétrico*

$$\mathcal{P} \subseteq \mathbb{R}^k,$$

com k fixo quando $n \rightarrow \infty$, e um parâmetro verdadeiro

$$\vartheta_0 \in \text{int}(\mathcal{P}).$$

Considere a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0,$$

em que, em uma vizinhança de ϑ_0 ,

$$\mathcal{P}_0 = \{\vartheta \in \mathcal{P} : \mathbf{h}(\vartheta) = \mathbf{0}\},$$

com

$$\mathbf{h} : \mathcal{P} \longrightarrow \mathbb{R}^d$$

continuamente diferenciável e

$$\text{posto}[\mathbf{J}_{\mathbf{h}}(\vartheta_0)] = d,$$

com d fixo.

Seja

$$\ell_n(\vartheta) = \log L_n(\vartheta).$$

Suponha que:

1. *o modelo seja identificável;*

2. $\ell_n(\vartheta)$ seja duas vezes continuamente diferenciável em uma vizinhança de ϑ_0 ;
3. exista uma matriz

$$\mathbf{I}(\vartheta_0) \succ \mathbf{0}$$

tal que

$$\frac{1}{\sqrt{n}} \nabla \ell_n(\vartheta_0) \xrightarrow{d} N_k[\mathbf{0}, \mathbf{I}(\vartheta_0)];$$

4. para toda sequência

$$\vartheta_n \xrightarrow{P} \vartheta_0,$$

tem-se

$$-\frac{1}{n} \nabla^2 \ell_n(\vartheta_n) \xrightarrow{P} \mathbf{I}(\vartheta_0);$$

5. os estimadores de máxima verossimilhança irrestrito e restrito existem e satisfazem

$$\hat{\vartheta}_n \xrightarrow{P} \vartheta_0$$

e

$$\tilde{\vartheta}_n \xrightarrow{P} \vartheta_0$$

sob H_0 .

Então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2. \quad (12.59)$$

O número d corresponde ao número de restrições localmente independentes impostas por H_0 e satisfaz

$$d = \dim(\mathcal{P}) - \dim(\mathcal{P}_0)$$

na vizinhança de ϑ_0 .

(Vaart, 1998)

O resultado é assintótico (Vaart, 1998). Para uma amostra grande, uma região crítica aproximada de nível α é

$$-2 \log \Lambda_{\text{RV}} > \chi_{d;1-\alpha}^2. \quad (12.60)$$

O correspondente valor- p aproximado é

$$P[\chi_d^2 \geq -2 \log \Lambda_{\text{RV,obs}}]. \quad (12.61)$$

O número

$$d$$

não deve ser obtido simplesmente pela contagem de todas as expressões escritas na hipótese. Ele corresponde ao número de restrições **localmente independentes** ou, equivalentemente em situações regulares, à diferença entre as dimensões dos espaços paramétricos irrestrito e restrito.

Situações não regulares

A aproximação qui-quadrado do Teorema 12.4 não se aplica automaticamente quando:

- o parâmetro verdadeiro está na fronteira do espaço paramétrico;
- o modelo não é identificável;
- há restrições redundantes;
- a informação de Fisher é singular;
- a dimensão do parâmetro cresce com o tamanho amostral.

Nessas situações, a distribuição limite pode ser diferente de uma qui-quadrado convencional.

O **teorema de Wilks** em Teorema 12.4 é um resultado assintótico geral sobre razões de verossimilhanças. Ele deve ser distinguido da **lambda de Wilks**, que é uma estatística matricial específica utilizada posteriormente na MANOVA.

12.4.4 Razão de verossimilhanças em modelos normais encaixados

O princípio da razão de verossimilhanças pode ser aplicado aos modelos lineares multivariados encaixados de Proposição 11.13.

Considere a comparação entre um modelo completo e um modelo reduzido encaixado. A matriz **H** representa a redução da SQPC residual obtida pela inclusão, no modelo completo, dos termos ausentes no modelo reduzido.

Sob o modelo normal matricial com matriz de covariâncias residual comum, a verossimilhança maximizada é proporcional a $|\mathbf{E}|^{-n/2}$. A razão de verossimilhanças pode, portanto, ser expressa por meio dos determinantes das SQPCs residuais dos dois modelos.

Proposição 12.13 (Razão de verossimilhanças em modelos normais encaixados). *Considere modelos lineares normais multivariados completo e reduzido, definidos sobre as mesmas n unidades, com matriz de covariâncias residual comum*

$$\Sigma \succ \mathbf{0},$$

e tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F).$$

Se suas SQPCs residuais $\mathbf{E}_F$ e $\mathbf{E}_R$ são positivas definidas e

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H} \tag{12.62}$$

e

$$\mathbf{H} \succeq \mathbf{0},$$

então

$$\Lambda_{\text{RV}} = \left(\frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} \right)^{n/2}. \tag{12.63}$$

Equivalentemente,

$$\Lambda_{\text{RV}} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}. \tag{12.64}$$

A razão de determinantes

$$\Lambda_{\text{W}} = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \tag{12.65}$$

é denominada **lambda de Wilks**. Assim,

$$\Lambda_{RV} = \Lambda_W^{n/2}. \quad (12.66)$$

Portanto, Λ_{RV} e Λ_W são funções monotônicas uma da outra e conduzem à mesma ordenação das evidências contra H_0 .

Neste capítulo, a lambda de Wilks aparece como consequência da razão de verossimilhanças em modelos normais encaixados. Sua distribuição e sua utilização como critério específico da MANOVA serão desenvolvidas no Módulo 3.

Como

$$\mathbf{H} \succeq \mathbf{0},$$

a imposição das restrições do modelo reduzido não diminui a SQPC residual na ordem de Löwner:

$$\mathbf{E}_R \succeq \mathbf{E}_F.$$

Quando ambas são positivas definidas,

$$|\mathbf{E}_R| \geq |\mathbf{E}_F|,$$

e, portanto,

$$0 < \Lambda_{RV} \leq 1.$$

Valores de Λ_W próximos de 1 indicam pequena diferença entre os ajustes completo e reduzido. Valores menores indicam maior redução da dispersão residual quando os termos adicionais do modelo completo são incluídos.

A decomposição desse critério por raízes características e sua relação com os demais critérios multivariados pertencem à MANOVA.

Existência da forma por determinantes

A expressão em Equação 12.63 exige que as matrizes residuais relevantes sejam positivas definidas.

Sob o modelo normal, uma condição suficiente para

$$\mathbf{E}_F \succ \mathbf{0}$$

com probabilidade 1 é

$$n - r_F \geq p,$$

em que

$$r_F = \text{posto}(\mathbf{Z}_F).$$

Como

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H}$$

e

$$\mathbf{H} \succcurlyeq \mathbf{0},$$

a definição positiva de $\mathbf{E}_F$ implica a definição positiva de $\mathbf{E}_R$.

Quando a SQPC residual é singular, a razão de determinantes clássica deixa de estar disponível na forma anterior. Pseudoinversas, pseudodeterminantes ou regularização definem procedimentos diferentes e não preservam automaticamente a distribuição nula utilizada pela inferência clássica.

A razão de verossimilhanças fornece um princípio geral para comparar modelos restritos e irrestritos. Para a inferência sobre um único vetor de médias, entretanto, existem distribuições exatas mais específicas.

Quando Σ é conhecida, a forma quadrática da média amostral conduz diretamente a uma distribuição qui-quadrado. Quando Σ é desconhecida e precisa ser estimada por $\mathbf{S}$, a distribuição muda e conduz à estatística T^2 de Hotelling.

12.5 Inferência sobre um vetor de médias

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succcurlyeq \mathbf{0}.$$

O objetivo inicial é testar

$$H_0 : \mu = \mu_0$$

contra

$$H_1 : \mu \neq \mu_0,$$

em que

$$\mu_0 \in \mathbb{R}^p$$

é conhecido.

A distribuição da média amostral foi estabelecida em Proposição 12.1. A forma da estatística de teste depende de a matriz populacional Σ ser conhecida ou precisar ser substituída por sua estimativa amostral.

12.5.1 Covariância conhecida

Pela Proposição 12.1,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right).$$

Sob H_0 ,

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu_0) \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

Definição 12.4 (Estatística para a média com covariância conhecida). Quando $\Sigma \succ \mathbf{0}$ é conhecida, define-se

$$Q_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.67)$$

A forma quadrática utiliza a distância de Mahalanobis definida em Definição 8.9. Como

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

o fator n ajusta a distância à variabilidade da média amostral, e não à variabilidade de uma observação individual.

Proposição 12.14 (Distribuição com covariância conhecida). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$ conhecida, então, sob

$$H_0 : \mu = \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2. \quad (12.68)$$

O resultado decorre de Proposição 9.8 aplicado à distribuição da média amostral em Proposição 12.1. A matriz de covariâncias da média é Σ/n , o que produz a forma em Equação 12.67.

Assim, um teste de nível α rejeita H_0 quando

$$Q_{\mu, \text{obs}} > \chi_{p; 1-\alpha}^2, \quad (12.69)$$

em que

$$Q_{\mu, \text{obs}} = n \left(\bar{\mathbf{x}} - \mu_0 \right)^\top \Sigma^{-1} \left(\bar{\mathbf{x}} - \mu_0 \right). \quad (12.70)$$

O valor- p é

$$P(\chi_p^2 \geq Q_{\mu, \text{obs}}). \quad (12.71)$$

Sob uma alternativa fixa, a distribuição torna-se qui-quadrado não central, com parâmetro

$$\lambda_\mu = n \left(\mu - \mu_0 \right)^\top \Sigma^{-1} \left(\mu - \mu_0 \right). \quad (12.72)$$

Assim, a não centralidade cresce com o tamanho amostral e com o afastamento entre μ e μ_0 medido na geometria de Σ . Esse parâmetro será utilizado apenas como referência para a interpretação do poder.

Quando

$$p = 1,$$

obtém-se

$$Q_\mu = \frac{n(\bar{X} - \mu_0)^2}{\sigma^2},$$

que corresponde ao quadrado da estatística normal padronizada utilizada no teste de uma média com variância conhecida.

12.5.2 Estatística T^2 de Hotelling

Na maior parte das aplicações,

$$\Sigma$$

é desconhecida e precisa ser estimada. A substituição de Σ por $\mathbf{S}$ não preserva a distribuição qui-quadrado de Equação 12.68, porque a matriz utilizada na forma quadrática passa a ser aleatória.

Os resultados obtidos anteriormente fornecem

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

por Proposição 12.1,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

por Teorema 12.2, e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

por Teorema 12.3.

A estatística T^2 combina esses três resultados.

Definição 12.5 (Estatística T^2 de Hotelling para uma amostra). A estatística para testar

$$H_0 : \mu = \mu_0$$

quando Σ é desconhecida e $\mathbf{S} \succ \mathbf{0}$ é

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0). \quad (12.73)$$

A forma clássica de T^2 exige

$$\mathbf{S} \succ \mathbf{0},$$

pois utiliza $\mathbf{S}^{-1}$.

Como

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

Proposição 12.2 mostra que, sob $\Sigma \succ \mathbf{0}$,

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > p. \tag{12.74}$$

O fator n aparece porque a matriz de covariâncias da média é

$$\frac{\Sigma}{n}.$$

A expressão de T^2 tem a mesma forma quadrática utilizada na distância de Mahalanobis, mas emprega a matriz aleatória $\mathbf{S}$ no lugar de Σ . Portanto, trata-se de uma forma de Mahalanobis **estimada**, cuja distribuição precisa incorporar a variabilidade da estimação da covariância.

Proposição 12.15 (Distribuição exata de T^2). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \mu = \mu_0,$$

vale

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}. \quad (12.75)$$

Esse resultado utiliza conjuntamente a distribuição normal da média, a distribuição Wishart da covariância amostral e a independência entre esses dois objetos (Anderson, 2003; Rencher; Christensen, 2012).

Quando Σ é conhecida, somente a média amostral é aleatória na forma quadrática e obtém-se uma distribuição χ_p^2 . Quando Σ é substituída por $\mathbf{S}$, a incerteza da covariância estimada também participa da estatística. A transformação em Equação 12.75 incorpora essa fonte adicional de variabilidade e produz a distribuição F exata.

Após a observação,

$$\mathbf{T}_{\text{obs}}^2 = n (\bar{\mathbf{x}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0). \quad (12.76)$$

Defina

$$\mathbf{F}_{\text{obs}} = \frac{n-p}{p(n-1)} \mathbf{T}_{\text{obs}}^2. \quad (12.77)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}, \quad (12.78)$$

ou, equivalentemente, quando

$$\mathbf{F}_{\text{obs}} > F_{p, n-p; 1-\alpha}.$$

O valor- p é

$$P(F_{p, n-p} \geq \mathbf{F}_{\text{obs}}). \quad (12.79)$$

A rejeição informa que o vetor populacional não coincide com μ_0 . Ela não identifica, isoladamente, quais componentes ou combinações lineares são responsáveis pelo afastamento.

Sob uma alternativa fixa, a transformação de $\mathbf{T}^2$ possui distribuição F não central, com o mesmo parâmetro λ_μ definido em Equação 12.72. Essa distribuição é utilizada em estudos de poder e não será desenvolvida adicionalmente neste capítulo.

12.5.3 Relações com os casos assintótico e univariado

Quando p permanece fixo e

$$n \longrightarrow \infty,$$

a consistência de $\mathbf{S}$ estabelecida em Proposição 10.12 implica, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \quad (12.80)$$

Portanto, a distribuição qui-quadrado fornece uma aproximação assintótica. Sob normalidade e em amostras finitas, a distribuição F em Equação 12.75 é o resultado exato.

Quando

$$p = 1,$$

a matriz de covariâncias amostral reduz-se à variância amostral S . Assim,

$$\mathbf{T}^2 = \frac{n(\bar{X} - \mu_0)^2}{S} = \mathbf{t}^2, \quad (12.81)$$

em que

$$\mathbf{t} = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sqrt{S}} \sim t_{n-1}$$

sob H_0 .

Assim, o teste T^2 de uma amostra é a extensão multivariada do teste t de Student.

A estatística também é invariante a transformações afins com parte linear não singular. Se

$$\mathbf{Y}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b}, \quad \det(\mathbf{A}) \neq 0,$$

então Proposição 8.6 fornece

$$\mathbf{S}_Y = \mathbf{A} \mathbf{S} \mathbf{A}^\top.$$

Como

$$(\mathbf{A} \mathbf{S} \mathbf{A}^\top)^{-1} = \mathbf{A}^{-\top} \mathbf{S}^{-1} \mathbf{A}^{-1},$$

os fatores $\mathbf{A}$ se cancelam na forma quadrática e o valor de T^2 permanece inalterado.

12.5.4 Região de confiança elipsoidal

A região de confiança para μ é obtida reunindo todos os vetores que não seriam rejeitados pelo teste T^2 ao nível α . Essa inversão do teste produz uma região simultânea para todo o vetor de médias.

Proposição 12.16 (Região de confiança para o vetor de médias). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

defina

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.82)$$

Então,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{X}} - \theta)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \theta) \leq c_{\alpha,p,n} \right\} \quad (12.83)$$

possui cobertura

$$P(\mu \in \mathcal{C}_{1-\alpha}) = 1 - \alpha. \quad (12.84)$$

Após a observação,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : (\theta - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\theta - \bar{\mathbf{x}}) \leq \frac{c_{\alpha,p,n}}{n} \right\}. \quad (12.85)$$

A dualidade entre teste e região de confiança fornece

$$\mu_0 \in \mathcal{C}_{1-\alpha} \iff T_{\text{obs}}^2(\mu_0) \leq c_{\alpha,p,n}. \quad (12.86)$$

12.5.5 Geometria da região

A região observada é um elipsoide centrado em

$$\bar{\mathbf{x}}.$$

Considere a decomposição espectral

$$\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Em coordenadas espectrais, sua fronteira é

$$\sum_{j=1}^p \frac{z_j^2}{c_{\alpha,p,n} \lambda_j / n} = 1. \quad (12.87)$$

Consequentemente, os eixos do elipsoide são os autovetores de $\mathbf{S}$ e o comprimento do j -ésimo semieixo é

$$a_j = \sqrt{\frac{c_{\alpha,p,n} \lambda_j}{n}}. \quad (12.88)$$

A forma da região é a mesma estrutura elipsoidal de Equação 8.32, agora centrada em $\bar{\mathbf{x}}$ e escalada pela constante inferencial $c_{\alpha,p,n}/n$. A orientação e os comprimentos dos eixos decorrem da decomposição espectral utilizada em Equação 8.26.

A Figura 12.1 mostra, no caso bidimensional, como a covariância altera a orientação da região de confiança.




Figura 12.1: Efeito da matriz de covariâncias sobre a forma e a orientação da região de confiança para o vetor de médias.

Na primeira configuração da Figura 12.1, os eixos permanecem alinhados às coordenadas originais. Na segunda, a covariância positiva produz rotação do elipsoide. A região reflete, portanto, tanto as variâncias marginais quanto a dependência entre as componentes.

Interpretação da cobertura

Antes da observação dos dados,

$$\mathcal{C}_{1-\alpha}$$

é uma região aleatória que contém o verdadeiro vetor μ com probabilidade $1 - \alpha$.

Depois da observação, a região está fixada. Na interpretação frequentista, o parâmetro não passa a ser aleatório; a cobertura refere-se ao comportamento do procedimento em repetições amostrais.

12.5.6 Intervalos simultâneos

Cada vetor

$$\mathbf{a} \in \mathbb{R}^p$$

define uma combinação linear $\mathbf{a}^\top \mu$. Como todos esses funcionais são obtidos da mesma região elipsoidal, é possível construir intervalos com cobertura simultânea para todas as direções.

Proposição 12.17 (Intervalos simultâneos de Hotelling). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

e

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha},$$

os intervalos

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}, \quad \mathbf{a} \in \mathbb{R}^p, \quad (12.89)$$

possuem cobertura simultânea $1 - \alpha$ para todas as combinações lineares.

Comprovação. Se

$$\mu \in \mathcal{C}_{1-\alpha},$$

então

$$(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}}) \leq \frac{c_{\alpha,p,n}}{n}.$$

Pela desigualdade de Cauchy–Schwarz na geometria induzida por $\mathbf{S}$,

$$|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \sqrt{(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}})}.$$

Substituindo o limite da região, obtém-se Equação 12.89 simultaneamente para todas as direções $\mathbf{a}$. $\square$

Após a observação dos dados,

$$\mathbf{a}^\top \mu \in \mathbf{a}^\top \bar{\mathbf{x}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}. \quad (12.90)$$

Para

$$\mathbf{a} = \mathbf{e}_j,$$

obtém-se o intervalo simultâneo para uma componente:

$$\mu_j \in \bar{x}_j \pm \sqrt{\frac{c_{\alpha,p,n} S_{jj}}{n}}. \quad (12.91)$$

Para

$$\mathbf{a} = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$\mu_j - \mu_k \in \bar{x}_j - \bar{x}_k \pm \sqrt{\frac{c_{\alpha,p,n}}{n} (S_{jj} + S_{kk} - 2S_{jk})}. \quad (12.92)$$

Os intervalos de Hotelling fornecem cobertura simultânea para todas as combinações lineares $\mathbf{a}^\top \mu$. Quando o interesse está restrito a um conjunto finito e previamente especificado de combinações, procedimentos como Bonferroni utilizam uma família de inferências menor e podem produzir intervalos mais estreitos, dependendo da estrutura de covariâncias e do número de comparações.

12.5.7 Hipóteses lineares sobre o vetor de médias

A hipótese

$$H_0 : \mu = \mu_0$$

especifica todo o vetor de médias. Em outros problemas, o interesse está restrito a determinadas combinações lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{h \times p},$$

com

$$\text{posto}(\mathbf{A}) = h \leq p,$$

e

$$\mathbf{d} \in \mathbb{R}^h.$$

A hipótese é

$$H_0 : \mathbf{A}\mu = \mathbf{d}. \quad (12.93)$$

Cada linha de $\mathbf{A}$ define uma restrição linear. A condição de posto linha completo elimina restrições redundantes.

Defina

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

A distribuição decorre diretamente de Proposição 9.4.

Como $\mathbf{A}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

A média e a covariância amostrais transformadas são

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}}$$

e

$$\mathbf{S}_U = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Assim, o problema reduz-se exatamente à inferência sobre um vetor de médias de dimensão h .

12.5.7.1 Covariância conhecida

Quando Σ é conhecida, defina

$$Q_A = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.94)$$

Sob H_0 ,

$$Q_A \sim \chi_h^2. \quad (12.95)$$

Esse é Proposição 12.14 aplicado ao vetor transformado $\mathbf{U}_i$. Portanto, os graus de liberdade são determinados pelas h combinações linearmente independentes presentes na hipótese, e não pela dimensão original p .

12.5.7.2 Covariância desconhecida

Sob normalidade,

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > h. \quad (12.96)$$

Proposição 12.18 (Distribuição para hipóteses lineares sobre a média). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

e

$$\mathbf{A} \in \mathbb{R}^{h \times p}, \quad 1 \leq h \leq p, \quad \text{posto}(\mathbf{A}) = h, \quad \mathbf{d} \in \mathbb{R}^h, \quad n > h,$$

então, sob

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

a estatística

$$\mathbf{T}_A^2 = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}) \quad (12.97)$$

satisfaz

$$\frac{n-h}{h(n-1)} \mathbf{T}_A^2 \sim F_{h,n-h}. \quad (12.98)$$

O resultado é Proposição 12.15 aplicado aos vetores transformados

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i \in \mathbb{R}^h.$$

Por isso, a condição dimensional passa de $n > p$ para $n > h$.

Assim, um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{A,\text{obs}}^2 > \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha}, \quad (12.99)$$

em que

$$\mathbf{T}_{A,\text{obs}}^2 = n (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d}). \quad (12.100)$$

Uma consequência importante é que a condição dimensional depende de

$$h,$$

e não necessariamente de p .

Assim, mesmo quando

$$p \geq n$$

e a matriz completa

$$\mathbf{S}$$

é singular, uma hipótese de dimensão reduzida ainda pode admitir a inferência clássica se

$$n > h$$

e

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top$$

for não singular.

Quando

$$h = 1,$$

com

$$\mathbf{A} = \mathbf{a}^\top,$$

a hipótese

$$H_0 : \mathbf{a}^\top \mu = d$$

reduz-se ao teste t univariado aplicado à combinação linear

$$\mathbf{a}^\top \mathbf{X}.$$

Quando

$$h = p, \quad \mathbf{A} = \mathbf{I}_p, \quad \mathbf{d} = \mu_0,$$

recupera-se o teste T^2 para o vetor completo de médias.

12.5.8 Relação com o modelo linear multivariado

O modelo de uma única população pode ser escrito como

$$y = \mathbf{1}_n \mu^\top + \mathcal{E}.$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Na hipótese geral de Definição 11.17,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

tome

$$\mathbf{C}_1 = [1], \quad \mathbf{C}_2 = \mathbf{A}^\top$$

e

$$\Theta_0 = \mathbf{d}^\top.$$

Então,

$$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mu^\top \mathbf{A}^\top = (\mathbf{A} \mu)^\top.$$

Portanto,

$$H_0 : \mathbf{A} \mu = \mathbf{d}$$

é um caso particular da hipótese linear geral do Capítulo 11.

Essa correspondência mostra que o teste T^2 para uma média, as hipóteses sobre combinações lineares e a inferência no modelo linear multivariado utilizam a mesma estrutura. A próxima seção estende o problema à comparação entre dois vetores de médias.

12.6 Comparação entre dois vetores de médias

A comparação entre dois vetores de médias depende da relação entre as unidades que produziram as observações. Duas estruturas serão consideradas:

- **amostras independentes**, formadas por unidades distintas;
- **observações pareadas**, nas quais cada unidade ou par fornece duas medições relacionadas.

Nos dois casos, o parâmetro de interesse é uma diferença entre vetores de médias. O delineamento determina, porém, a matriz de covariâncias dessa diferença e, consequentemente, a estatística utilizada na inferência.

12.6.1 Duas amostras independentes

Considere duas amostras mutuamente independentes:

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A especificação de uma mesma matriz

$$\Sigma$$

para as duas populações é parte do modelo utilizado pelo procedimento clássico com covariância agrupada.

O parâmetro de interesse é

$$\delta = \mu_1 - \mu_2 \in \mathbb{R}^p. \quad (12.101)$$

Considere a hipótese

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (12.102)$$

contra

$$H_1 : \mu_1 - \mu_2 \neq \delta_0.$$

A igualdade dos vetores de médias corresponde ao caso

$$\delta_0 = \mathbf{0}.$$

12.6.1.1 Distribuição da diferença entre as médias

Aplicando Proposição 12.1 separadamente às duas amostras,

$$\bar{\mathbf{X}}_1 \sim N_p \left(\mu_1, \frac{\Sigma}{n_1} \right)$$

e

$$\bar{\mathbf{X}}_2 \sim N_p \left(\mu_2, \frac{\Sigma}{n_2} \right).$$

Como as amostras são independentes,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left[\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right]. \quad (12.103)$$

Para simplificar as expressões seguintes, defina o fator

$$n_{\text{ef}} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} = \frac{n_1 n_2}{n_1 + n_2}. \quad (12.104)$$

Então,

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma}{n_{\text{ef}}}.$$

A notação n_{ef} será utilizada apenas como fator de escala da covariância da diferença entre as médias. Ela não representa o número total de observações nem os graus de liberdade do procedimento.

12.6.1.2 Covariância agrupada

Como Σ é desconhecida, as duas amostras fornecem estimativas da mesma matriz de covariâncias populacional. Essas estimativas são combinadas ponderando cada SQPC pelos respectivos graus de liberdade:

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.105)$$

A matriz $\mathbf{S}_p$ é denominada **matriz de covariâncias agrupada**.

Após a observação,

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.106)$$

Por Teorema 12.2, sob o modelo de covariância comum,

$$(n_h - 1)\mathbf{S}_h \sim W_p(n_h - 1, \Sigma), \quad h = 1, 2.$$

Como as duas amostras são independentes, essas matrizes Wishart também são independentes. Portanto, Proposição 12.5 pode ser aplicada às duas SQPCs.

Proposição 12.19 (Distribuição da covariância agrupada). *Se as duas amostras são independentes, cada amostra é formada por observações i.i.d. normais multivariadas em $\mathbb{R}^p$ e ambas possuem matriz de covariâncias comum*

$$\Sigma \succ \mathbf{0},$$

com

$$n_1 \geq 2 \quad e \quad n_2 \geq 2,$$

então

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma). \quad (12.107)$$

Além disso,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \perp \mathbf{S}_p. \quad (12.108)$$

Comprovação. Pela aditividade da distribuição de Wishart,

$$\begin{aligned} & (n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2 \\ & \sim W_p(n_1 + n_2 - 2, \Sigma). \end{aligned}$$

A matriz no lado esquerdo é

$$(n_1 + n_2 - 2)\mathbf{S}_p.$$

Sob normalidade, em cada amostra a média é independente da respectiva matriz de covariâncias. A independência entre as duas amostras implica então a independência entre

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$$

e

$$\mathbf{S}_p.$$

□

A distribuição em Equação 12.107 fornece

$$E(\mathbf{S}_p) = \Sigma.$$

Além disso, por Proposição 12.2,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1. Portanto,

$$\mathbf{S}_p \succ \mathbf{0}$$

com probabilidade 1 quando

$$n_1 + n_2 - 2 \geq p. \quad (12.109)$$

12.6.1.3 Estatística T^2 para duas amostras

Definição 12.6 (Estatística T^2 para duas amostras independentes). Para testar

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

quando

$$\mathbf{S}_p \succ \mathbf{0},$$

define-se

$$T_{\text{ind}}^2 = n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right), \quad (12.110)$$

em que

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}$$

e

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}.$$

A estatística possui a mesma forma quadrática do T^2 de uma amostra. O vetor de afastamento é agora

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0,$$

e sua variabilidade é estimada pela matriz de covariâncias agrupada.

Proposição 12.20 (Distribuição exata de T^2 para duas amostras). *Se as duas amostras são independentes e*

$$\mathbf{X}_{1i} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma), \quad i = 1, \dots, n_1,$$

e

$$\mathbf{X}_{2i} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma), \quad i = 1, \dots, n_2,$$

com

$$\Sigma \succ \mathbf{0}, \quad n_1 \geq 2, \quad n_2 \geq 2,$$

e

$$n_1 + n_2 - 2 \geq p,$$

então, sob

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

tem-se

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} T_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}. \quad (12.111)$$

Comprovação. Sob H_0 , o vetor

$$\mathbf{V} = \sqrt{n_{\text{ef}}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)$$

satisfaz

$$\mathbf{V} \sim N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\mathbf{W} = (n_1 + n_2 - 2) \mathbf{S}_p$$

satisfaz, por Proposição [12.19](#),

$$\mathbf{W} \sim W_p(n_1 + n_2 - 2, \Sigma)$$

e

$$\mathbf{V} \perp \mathbf{W}.$$

A mesma estrutura normal–Wishart utilizada em Proposição [12.15](#) fornece

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} T_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}.$$

□

Para os dados observados,

$$\mathbf{T}_{\text{ind,obs}}^2 = n_{\text{ef}} \begin{pmatrix} \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \end{pmatrix}^\top \mathbf{S}_p^{-1} \begin{pmatrix} \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \end{pmatrix}. \quad (12.112)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{ind,obs}}^2 > \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.113)$$

Defina

$$c_{\alpha, p, n_1, n_2} = \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.114)$$

A inversão do teste fornece uma região de confiança de nível $1 - \alpha$ para

$$\delta = \mu_1 - \mu_2 :$$

$$\mathcal{C}_{\delta, 1 - \alpha} = \left\{ \theta \in \mathbb{R}^p : n_{\text{ef}} \begin{pmatrix} \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \end{pmatrix}^\top \mathbf{S}_p^{-1} \begin{pmatrix} \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \end{pmatrix} \leq c_{\alpha, p, n_1, n_2} \right\}. \quad (12.115)$$

A região é um elipsoide centrado em

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2,$$

com orientação determinada pela matriz de covariâncias agrupada.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

os intervalos derivados dessa região são

$$\mathbf{a}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) \pm \sqrt{\frac{c_{\alpha, p, n_1, n_2}}{n_{\text{ef}}} \mathbf{a}^\top \mathbf{S}_p \mathbf{a}}. \quad (12.116)$$

Esses intervalos fornecem cobertura simultânea para todas as combinações lineares de δ .

Quando

$$p = 1,$$

o procedimento reduz-se ao quadrado do teste t para duas amostras independentes com variâncias populacionais iguais:

$$T_{\text{ind}}^2 = t_{\text{pooled}}^2. \quad (12.117)$$

12.6.2 Covariâncias populacionais distintas

O procedimento anterior foi construído sob

$$\Sigma_1 = \Sigma_2.$$

Se

$$\Sigma_1 \neq \Sigma_2,$$

a diferença entre as médias continua tendo, sob normalidade,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left(\mu_1 - \mu_2, \frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2} \right). \quad (12.118)$$

Entretanto, a matriz agrupada satisfaz

$$E(\mathbf{S}_p) = \frac{(n_1 - 1)\Sigma_1 + (n_2 - 1)\Sigma_2}{n_1 + n_2 - 2},$$

e não estima diretamente

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}.$$

Consequentemente, a estrutura normal-Wishart utilizada em Proposição 12.20 deixa de ser válida com a matriz agrupada, e a transformação para a distribuição F não é mais exata.

Papel da homogeneidade das covariâncias

A igualdade

$$\Sigma_1 = \Sigma_2$$

não é necessária para o T^2 de uma amostra nem para o procedimento pareado.

Ela é uma hipótese específica do procedimento de duas amostras independentes que utiliza a covariância agrupada.

Quando as covariâncias populacionais são distintas, o problema inferencial é diferente e requer outro procedimento ou outra aproximação. A simples substituição de $\mathbf{S}_p$ por uma matriz alternativa não preserva automaticamente a distribuição F clássica.

12.6.3 Observações pareadas

No delineamento pareado, considere

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

em que os pares são independentes entre si, mas as duas medições dentro de cada par podem ser dependentes.

O número

$$n$$

representa o número de pares completos.

Defina

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i. \quad (12.119)$$

O vetor médio das diferenças é

$$\delta = E(\mathbf{D}_i) = \mu_X - \mu_Y. \quad (12.120)$$

Sua matriz de covariâncias é

$$\Sigma_D = \Sigma_X + \Sigma_Y - \Sigma_{XY} - \Sigma_{YX}. \quad (12.121)$$

A expressão mostra por que a associação dentro dos pares deve ser preservada: ela participa diretamente da variabilidade das diferenças.

A hipótese é

$$H_0 : \delta = \delta_0. \quad (12.122)$$

Para comparar diretamente as duas condições,

$$\delta_0 = \mathbf{0}.$$

Depois de formar as diferenças, cada par produz um único vetor

$$\mathbf{D}_i.$$

A comparação entre as duas condições passa, portanto, a ser uma inferência sobre o vetor médio de uma única população de diferenças:

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Suponha

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}.$$

A média amostral das diferenças é

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{i=1}^n \mathbf{D}_i = \bar{\mathbf{X}} - \bar{\mathbf{Y}}. \quad (12.123)$$

A matriz de covariâncias amostral é

$$\mathbf{S}_D = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{D}_i - \bar{\mathbf{D}}) (\mathbf{D}_i - \bar{\mathbf{D}})^\top. \quad (12.124)$$

Quando as matrizes são calculadas sobre os mesmos pares completos,

$$\mathbf{S}_D = \mathbf{S}_X + \mathbf{S}_Y - \mathbf{S}_{XY} - \mathbf{S}_{YX}. \quad (12.125)$$

A decomposição populacional em Equação 12.121 utiliza a covariância cruzada definida em Definição 8.3. Sua contraparte amostral em Equação 12.125 utiliza a matriz definida em Definição 10.16.

Definição 12.7 (Estatística T^2 para observações pareadas). Para os vetores de diferenças pareadas

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i, \quad i = 1, \dots, n,$$

com vetor de médias amostrais $\bar{\mathbf{D}}$ e matriz de covariâncias amostral $\mathbf{S}_D \succ \mathbf{0}$, define-se

$$\mathsf{T}_{\text{par}}^2 = n \left(\bar{\mathbf{D}} - \delta_0 \right)^\top \mathbf{S}_D^{-1} \left(\bar{\mathbf{D}} - \delta_0 \right). \quad (12.126)$$

Proposição 12.21 (Distribuição exata de T^2 para observações pareadas). Se

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \delta = \delta_0,$$

tem-se

$$\frac{n-p}{p(n-1)} \mathsf{T}_{\text{par}}^2 \sim F_{p, n-p}. \quad (12.127)$$

A proposição é Proposição 12.15 aplicada à amostra

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Por isso, o número de observações utilizado no teste é o número de pares completos.

Para os dados observados,

$$\mathbf{T}_{\text{par,obs}}^2 = n (\bar{\mathbf{d}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \delta_0). \quad (12.128)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{par,obs}}^2 > \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.129)$$

Quando

$$p = 1,$$

recupera-se o quadrado do teste t pareado:

$$\mathbf{T}_{\text{par}}^2 = \mathbf{t}_{\text{par}}^2. \quad (12.130)$$

Aplicando Proposição 12.16 à população de diferenças, obtém-se a região de confiança de nível $1 - \alpha$

$$\mathcal{C}_{D,1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{D}} - \theta)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \theta) \leq c_{\alpha,p,n} \right\}, \quad (12.131)$$

em que $c_{\alpha,p,n}$ foi definida em Equação 12.82.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

Proposição 12.17 fornece

$$\mathbf{a}^\top \bar{\mathbf{D}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S}_D \mathbf{a}}. \quad (12.132)$$

Assim, teste, região de confiança e intervalos simultâneos do caso pareado são os resultados de uma amostra aplicados aos vetores de diferenças.

Preservação do pareamento

O procedimento deve ser aplicado às diferenças construídas com a correspondência correta entre as unidades.

Tratar as duas condições como amostras independentes elimina da análise a covariância intrapar e utiliza uma estrutura de variabilidade diferente daquela determinada pelo delineamento.

A normalidade necessária ao resultado exato refere-se à distribuição dos vetores

$$\mathbf{D}_i,$$

e não exige, separadamente, que cada uma das duas condições possua distribuição marginal normal multivariada.

A Tabela 12.1 resume a diferença entre os dois delineamentos.

Tabela 12.1: Comparação entre o T^2 para amostras independentes e para observações pareadas.

Característica	Amostras independentes	Observações pareadas
unidade básica	observações distintas	par de medições relacionadas
parâmetro	$\mu_1 - \mu_2$	$E(\mathbf{D})$
matriz usada na forma quadrática	covariância comum estimada por $\mathbf{S}_p$	covariância das diferenças estimada por $\mathbf{S}_D$
dependência entre as duas medições	não há correspondência entre unidades das duas amostras	incorporada em Σ_{XY} e Σ_{YX} e, portanto, em Σ_D
graus de liberdade da matriz de covariâncias	$n_1 + n_2 - 2$	$n - 1$
condição clássica de inversão	$n_1 + n_2 - 2 \geq p$	$n > p$
redução univariada	teste t com variâncias iguais	teste t pareado

Os dois procedimentos utilizam a mesma lógica inferencial, mas estimam estruturas de variabilidade distintas. Essa diferença será retomada na seção seguinte ao organizar as condições necessárias à inferência multivariada clássica.

12.7 Condições e limites da inferência clássica

Os resultados desenvolvidos neste capítulo dependem da estrutura probabilística da amostra, das hipóteses específicas de cada procedimento e do posto das matrizes envolvidas. Essas condições não são intercambiáveis: uma hipótese necessária para um procedimento pode ser irrelevante para outro.

Quatro aspectos organizam a validade da inferência clássica:

1. independência entre as unidades amostrais na estrutura especificada pelo delineamento;
2. normalidade multivariada quando se utilizam distribuições exatas normal–Wishart;
3. covariância comum nos procedimentos que a pressupõem;
4. posto suficiente das matrizes utilizadas nas formas quadráticas, inversas e determinantes.

12.7.1 Independência, normalidade e covariância comum

12.7.1.1 Independência

Nos resultados para uma amostra,

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são consideradas independentes.

Para duas amostras independentes, exige-se também independência entre as duas amostras. No delineamento pareado, admite-se dependência entre as duas medições de um mesmo par, mas os pares devem ser independentes entre si.

No modelo linear multivariado clássico,

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n$$

expressa a ausência de covariância residual entre unidades distintas.

A independência é determinada principalmente pelo processo de amostragem e pelo delineamento do estudo. Se existe dependência entre unidades e ela não é incorporada ao modelo, expressões como

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}$$

podem deixar de representar a variabilidade efetiva da média amostral.

Consequentemente, estatísticas construídas com essa estrutura podem apresentar níveis de significância e coberturas diferentes dos valores nominais.

Independência e delineamento

A independência não é estabelecida por um teste aplicado aos valores observados. Ela deve ser avaliada a partir da forma como as unidades foram selecionadas, agrupadas e mensuradas.

Dependência espacial, temporal, hierárquica ou decorrente de medidas repetidas exige uma estrutura probabilística compatível com o delineamento.

12.7.1.2 Normalidade multivariada

A normalidade multivariada sustenta os principais resultados exatos deste capítulo. Sob esse modelo foram estabelecidas:

- a distribuição normal da média em Proposição 12.1;
- a distribuição Wishart da SQPC amostral em Teorema 12.2;
- a independência entre média e covariância amostrais em Teorema 12.3;
- a distribuição F exata do T^2 em Proposição 12.15;
- as distribuições Wishart e as independências associadas ao modelo linear multivariado em Proposição 12.12.

Esses resultados devem ser distinguidos das propriedades que dependem apenas de momentos. Por exemplo, Proposição 10.6 e Proposição 10.11 não exigem normalidade.

Fora do modelo normal, a distribuição Wishart e as independências utilizadas para construir as distribuições exatas deixam, em geral, de estar disponíveis. No regime de dimensão fixa de Equação 12.1, resultados assintóticos podem ainda ser obtidos.

Se as observações são i.i.d., possuem matriz de covariâncias finita e positiva definida, e as condições de Teorema 12.1 e Proposição 10.12 são satisfeitas, então, sob

$$H_0 : \mu = \mu_0,$$

o Teorema Central do Limite multivariado e o teorema de Slutsky fornecem

$$T^2 \xrightarrow{d} \chi_p^2. \quad (12.133)$$

Essa convergência não implica que

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}$$

seja uma distribuição exata em amostras finitas fora do modelo normal.

Exato e assintótico

A normalidade não é necessária para definir médias, covariâncias, matrizes SQPC ou formas quadráticas.

Neste capítulo, ela é utilizada para obter determinadas distribuições amostrais **exatas**. Fora desse modelo, uma aproximação assintótica depende das condições do resultado limite utilizado e do regime em que n e p variam.

12.7.1.3 Covariância comum

A hipótese

$$\Sigma_1 = \Sigma_2$$

não pertence a todos os procedimentos multivariados.

Ela foi utilizada especificamente no teste de duas amostras independentes com covariância agrupada, pois permite obter

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma).$$

Quando

$$\Sigma_1 \neq \Sigma_2,$$

a covariância da diferença entre as médias é a apresentada em Equação 12.118,

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2},$$

e a matriz agrupada não conduz à distribuição F exata da Proposição 12.20.

No procedimento pareado, essa hipótese não é necessária. A matriz relevante é

$$\Sigma_D = \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i).$$

No modelo linear multivariado clássico, a estrutura

$$\text{Cov}(\varepsilon_i | \mathbf{Z}) = \Sigma$$

supõe uma matriz residual comum às unidades representadas pelo modelo.

Assim, a homogeneidade deve ser entendida como uma hipótese do **procedimento que utiliza uma matriz de covariâncias comum**, e não como uma condição universal da inferência multivariada.

12.7.2 Posto, dimensão e tamanho amostral

As formas clássicas das estatísticas utilizam matrizes inversas. A condição necessária depende da dimensão efetivamente utilizada em cada problema.

12.7.2.1 Uma amostra

Sob normalidade não singular,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1)$$

com probabilidade 1.

Portanto,

$$\mathbf{S}^{-1}$$

existe com probabilidade 1 se, e somente se,

$$n > p.$$

Essa é também a condição que torna positivo o segundo grau de liberdade

$$n - p$$

da distribuição

$$F_{p, n-p}.$$

12.7.2.2 Hipóteses de dimensão reduzida

Para

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

com

$$\text{posto}(\mathbf{A}) = h,$$

a matriz relevante é

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

A condição clássica passa a ser

$$n > h.$$

Portanto, a singularidade da matriz completa $\mathbf{S}$ não impede necessariamente a inferência sobre combinações previamente especificadas de dimensão menor.

12.7.2.3 Duas amostras independentes

Sob normalidade e covariância comum,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1.

A inversão clássica requer

$$n_1 + n_2 - 2 \geq p.$$

Sob essa condição,

$$n_1 + n_2 - p - 1 > 0,$$

como necessário para a distribuição F da Proposição [12.20](#).

12.7.2.4 Modelo linear multivariado

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

e

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r)$$

com probabilidade 1.

Logo,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

Para combinações de respostas definidas por

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

com posto coluna completo,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2$$

é positiva definida com probabilidade 1 quando

$$n - r \geq s,$$

conforme Equação [12.54](#).

Portanto, a condição de posto depende da dimensão do objeto que efetivamente participa da inferência. Uma matriz de covariâncias completa pode ser singular e, ainda assim, determinadas

combinações previamente especificadas admitirem inferência clássica em um espaço de menor dimensão.

Existência e estabilidade

A existência de uma inversa é uma condição algébrica; sua estabilidade depende também da separação entre os autovalores da matriz.

O efeito do condicionamento sobre a inversão de matrizes de covariâncias foi discutido em Equação 10.108. Assim, uma matriz pode possuir posto completo e ainda produzir formas quadráticas sensíveis a pequenas perturbações dos dados.

A Tabela 12.2 resume as condições centrais dos procedimentos desenvolvidos neste capítulo.

Tabela 12.2: Condições centrais para os resultados exatos da inferência multivariada clássica.

Procedimento	Estrutura probabilística para o resultado exato	Condição principal de posto
média com Σ conhecida	normalidade da média amostral	$\Sigma \succ \mathbf{0}$
T^2 de uma amostra	amostra normal multivariada	$n > p$
T^2 para $\mathbf{A}\mu = \mathbf{d}$	amostra normal multivariada	$n > h$
duas amostras independentes	normalidade, independência e covariância comum	$n_1 + n_2 - 2 \geq p$
observações pareadas	normalidade dos vetores de diferenças	$n > p$
modelo linear multivariado	normalidade matricial dos erros	$n - r \geq p$ para $\mathbf{E} \succ \mathbf{0}$
combinações de s respostas	normalidade matricial dos erros	$n - r \geq s$ para $\mathbf{E}_{C_2} \succ \mathbf{0}$

12.7.3 Aprofundamento: alta dimensão e robustez

A teoria desenvolvida neste capítulo é predominantemente uma teoria de **dimensão fixa**, na qual a informação amostral cresce enquanto a dimensão permanece constante. Quando a dimensão é grande em relação ao tamanho amostral, singularidade e instabilidade tornam-se parte central do problema.

12.7.3.1 Alta dimensão

Os limites de posto estabelecidos neste capítulo mostram que a inferência clássica baseada em inversas deixa de estar disponível quando a dimensão ultrapassa os graus de liberdade

correspondentes. Para uma amostra, por exemplo, Equação 10.81 implica que

$$p \geq n$$

torna $\mathbf{S}$ necessariamente singular. Situações análogas ocorrem para a covariância agrupada quando

$$p > n_1 + n_2 - 2$$

e para a SQPC residual do modelo linear quando

$$p > n - r.$$

O Capítulo 10 distinguiu duas respostas algébricas a problemas dessa natureza: a pseudoinversa em Equação 10.117 e a regularização da matriz de covariâncias em Definição 10.18. Nenhuma dessas substituições preserva automaticamente as distribuições inferenciais derivadas neste capítulo para a inversa clássica.

Por exemplo, substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ modifica a estatística T^2 e não permite utilizar automaticamente

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}.$$

O mesmo ocorre quando $\mathbf{S}$ é substituída por um estimador regularizado.

Uma alternativa diferente consiste em formular previamente a hipótese em um espaço de menor dimensão. Isso ocorre em

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

e, no modelo linear, em

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Nesse caso, a condição de posto depende da dimensão das combinações efetivamente examinadas. Se essas combinações forem escolhidas a partir dos próprios dados, entretanto, o processo de seleção também integra o procedimento inferencial.

Testes específicos para alta dimensão, regularização inferencial, reamostragem e procedimentos baseados em projeções possuem distribuições e critérios próprios e não serão desenvolvidos neste capítulo.

12.7.3.2 Sensibilidade e robustez

O Capítulo 10 mostrou que a média e a matriz de covariâncias amostrais podem ser fortemente afetadas por observações suficientemente afastadas dos demais dados. Para a média, esse efeito foi explicitado em Equação 10.119; para a matriz de covariâncias, a sensibilidade decorre dos produtos externos utilizados em sua construção.

Essa propriedade afeta diretamente a inferência deste capítulo porque estatísticas como T^2 utilizam simultaneamente

$$\bar{\mathbf{X}}$$

e

$$\mathbf{S}^{-1}.$$

Uma observação influente pode, portanto, modificar tanto o vetor de afastamento quanto a matriz utilizada para ponderá-lo. Isso não significa que toda observação extrema seja um erro nem permite classificar universalmente um procedimento como robusto ou não robusto. O efeito depende da distribuição, da dimensão, do tamanho amostral e da configuração dos dados.

Sob independência entre as unidades, existência dos momentos requeridos e em dimensão fixa, resultados assintóticos podem continuar válidos fora da normalidade. Essa validade assintótica não transforma em exatas as distribuições finitas derivadas da estrutura normal–Wishart.

Substituir $\bar{\mathbf{X}}$ ou $\mathbf{S}$ por estimadores robustos define outro procedimento estatístico e exige uma distribuição nula ou um método de calibração apropriado.

Alcance desta seção

O objetivo é delimitar os procedimentos clássicos desenvolvidos neste capítulo. Diagnósticos detalhados, estimação robusta, regularização, testes de alta dimensão e métodos de reamostragem possuem desenvolvimentos próprios e não serão tratados neste módulo.

As condições desta seção delimitam quais resultados do capítulo são exatos, quais dependem de aproximações assintóticas e quando as formas clássicas deixam de estar definidas. Com essas fronteiras estabelecidas, o Módulo 2 reúne os objetos probabilísticos, amostrais, de estimação, modelagem e inferência que serão utilizados pelas técnicas multivariadas do Módulo 3.

12.8 Síntese do Módulo 2

O Módulo 2 desenvolveu a base probabilística e inferencial necessária para estudar conjuntamente várias variáveis. O percurso começou com a representação da variabilidade conjunta por meio das covariâncias, introduziu a distribuição normal multivariada como modelo probabilístico, passou à construção e avaliação de estimadores, ampliou a estrutura da média por meio do modelo linear multivariado e concluiu com distribuições amostrais e procedimentos de inferência.

O percurso do módulo começou com a matriz de covariâncias populacional definida em Definição 8.2 e com a representação da variabilidade conjunta construída no Capítulo 8. A distribuição normal multivariada de Definição 9.1 acrescentou um modelo probabilístico para esses objetos.

No Capítulo 10, o vetor de médias amostral em Equação 10.8 e a matriz de covariâncias amostral definida em Definição 10.14 estabeleceram a passagem dos parâmetros populacionais para estatísticas e estimadores.

O Capítulo 11 generalizou a estrutura da média por meio do modelo linear multivariado de Definição 11.3,

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

e organizou hipóteses estimáveis na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

definida em Definição 11.17.

Neste capítulo, a distribuição de Wishart transformou as matrizes SQPC em objetos inferenciais. Em particular, Teorema 12.2 estabelece a distribuição da covariância amostral sob normalidade, enquanto Teorema 12.3 fornece a independência entre média e covariância amostrais.

No modelo linear multivariado, a mesma estrutura aparece nas matrizes de hipótese e erro. Sob H_0 , Proposição 12.12 fornece distribuições Wishart para $\mathbf{H}$ e para a SQPC residual correspondente, com independência entre elas. Esse resultado constitui a base probabilística que será reutilizada na MANOVA.

A inferência sobre vetores de médias foi organizada pela estatística T^2 de Hotelling. Quando Σ é conhecida, a forma quadrática possui distribuição qui-quadrado; quando a covariância é estimada por $\mathbf{S}$, Proposição 12.15 fornece uma transformação exata para a distribuição F . A mesma estrutura foi estendida a hipóteses $H_0 : \mathbf{A}\mu = \mathbf{d}$, à comparação de duas amostras independentes e às diferenças pareadas.

A razão de verossimilhanças forneceu uma formulação geral para comparar modelos sob restrições. No modelo linear normal, essa comparação levou à lambda de Wilks,

$$\Lambda_W = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|},$$

relacionando diretamente a redução da dispersão residual às matrizes $\mathbf{H}$ e $\mathbf{E}$.

Os resultados exatos deste módulo dependem das hipóteses probabilísticas e das condições de posto declaradas em cada procedimento. Fora dessas condições, resultados assintóticos, pseudoinversas ou regularização definem problemas inferenciais diferentes e não preservam automaticamente as distribuições clássicas.

A Tabela Tabela 12.3 reúne os objetos centrais dos cinco capítulos.

Tabela 12.3: Objetos centrais dos capítulos do Módulo 2.

Capítulo	Objeto central	Papel no Módulo 2
8. Matrizes de covariâncias e correlações	Σ e matrizes de dispersão	representa variabilidade, dependência e geometria
9. Distribuição Normal Multivariada	$N_p(\mu, \Sigma)$	estabelece o principal modelo probabilístico do módulo
10. Estatísticas Amostrais e Estimação	$\bar{\mathbf{X}}, \mathbf{T}$ e $\mathbf{S}$	relaciona parâmetros populacionais, estatísticas e estimadores
11. Modelo Linear Multivariado e Hipóteses Lineares	$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$ e $\mathbf{C}_1\mathbf{B}\mathbf{C}_2$	organiza médias, resíduos, SQPCs e hipóteses estimáveis
12. Inferência Multivariada	Wishart, T^2 , $(\mathbf{H}, \mathbf{E})$ e Λ_W	fornece distribuições amostrais, testes e regiões de confiança

Ao concluir o Módulo 2, o estudante deve ser capaz de:

- distinguir parâmetros populacionais, estatísticas amostrais, estimadores, estimativas e distribuições amostrais;
- interpretar a matriz de covariâncias e a distribuição normal multivariada como bases da modelagem probabilística conjunta;
- reconhecer a distribuição de Wishart e sua relação com matrizes SQPC e estimadores de covariância;
- formular e interpretar o modelo linear multivariado e hipóteses da forma $\mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0$;
- utilizar o T^2 de Hotelling para formular inferência sobre vetores de médias e combinações lineares;

- interpretar as matrizes $\mathbf{H}$ e $\mathbf{E}$ como variação associada à hipótese e ao resíduo;
- distinguir resultados exatos de aproximações assintóticas e identificar as condições de normalidade, independência, posto e delineamento que sustentam cada procedimento.

12.8.1 Passagem para o Módulo 3

Os dois primeiros módulos construíram a linguagem que será utilizada na formulação das técnicas multivariadas.

O Módulo 1 forneceu a base matemática formada por vetores, matrizes, subespaços, transformações, decomposições e ferramentas de cálculo.

O Módulo 2 acrescentou a estrutura probabilística e inferencial, abrangendo covariâncias, distribuições multivariadas, estimação, modelos lineares e procedimentos de inferência.

O Módulo 3 combinará essas duas estruturas para formular problemas multivariados específicos.

Matrizes de covariâncias serão decompostas ou modeladas. Projeções serão utilizadas para construir representações de menor dimensão. Distâncias e produtos internos serão utilizados para representar proximidades e formar grupos. Tabelas de contingência serão transformadas em estruturas geométricas. Matrizes de hipótese e erro serão retomadas na comparação multivariada de grupos. Modelos probabilísticos serão utilizados na discriminação e classificação. Dois blocos de variáveis serão relacionados por combinações lineares.

A passagem para o Módulo 3 corresponde, portanto, à mudança de uma teoria geral dos objetos multivariados para a formulação de técnicas destinadas a problemas estatísticos específicos.

Exercícios de fixação do Módulo II

Os exercícios deste módulo retomam os fundamentos probabilísticos e inferenciais desenvolvidos nos Capítulos 8 a 12 e os articulam com os resultados matemáticos estudados no Módulo I.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades, operações com vetores e matrizes e procedimentos de inferência. Na segunda, o R será utilizado para aplicar essas estruturas a conjuntos de dados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos nos Módulos I e II (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de normalidade, independência, existência de momentos, definição positiva, invertibilidade, posto, tamanho amostral, graus de liberdade ou outra hipótese específica, essa condição deve ser indicada.

Em particular, ao longo desta lista deve-se distinguir três situações:

1. resultados que permanecem válidos sem a hipótese de normalidade multivariada, desde que sejam satisfeitas as condições específicas necessárias, como existência de momentos e independência das unidades;
2. resultados exatos para amostras finitas cuja validade depende da normalidade multivariada;
3. resultados assintóticos que podem ser obtidos, sob condições próprias, quando o tamanho amostral cresce e a dimensão permanece fixa.

O fato de uma estatística poder ser calculada não significa que uma distribuição de referência utilizada para realizar inferência seja válida. Da mesma forma, o aumento do tamanho amostral pode justificar determinados resultados assintóticos, mas não transforma uma distribuição de amostra finita em um resultado exato fora das condições em que ela foi derivada.

A robustez de um procedimento diante de desvios da normalidade também não deve ser tratada como uma propriedade universal. Sua avaliação depende, entre outros aspectos, da intensidade e do tipo de desvio da distribuição, da presença de observações extremas, da dimensão e do tamanho amostral.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador

Exercício 12.1 (Covariância, correlação e transformação de escala). Considere as matrizes

$$\Sigma_A = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\Sigma_B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

Um estudante afirma que ambas podem representar matrizes de covariâncias porque são simétricas e possuem elementos diagonais positivos.

1. Verifique, separadamente para Σ_A e Σ_B , se estão satisfeitas as condições necessárias para que uma matriz real seja uma matriz de covariâncias. Em particular, verifique utilizando um dos critérios estudados no Módulo I. Apresente os cálculos utilizados e conclua, para cada matriz, se ela pode ou não representar uma matriz de covariâncias.
2. Para a matriz identificada no item anterior como uma matriz de covariâncias válida, determine numericamente a matriz de correlações correspondente. Verifique, no resultado obtido, os valores da diagonal e do elemento fora da diagonal.
3. Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

cujas matrizes de covariâncias sejam a matriz válida identificada no item 1. Para a combinação linear

$$Y = X_1 - X_2,$$

escreva o vetor de coeficientes da combinação linear, determine numericamente $\text{Var}(Y)$ utilizando uma forma quadrática e explique como o termo de covariância entre X_1 e X_2 participa do valor obtido.

4. Para o mesmo vetor $\mathbf{X}$, considere a transformação

$$Z_1 = X_1 \quad \text{e} \quad Z_2 = 10X_2.$$

Utilize a propriedade de transformação da matriz de covariâncias, sem retornar às definições escalares de variância e covariância. Calcule numericamente:

- $\text{Var}(Z_2)$;
- $\text{Cov}(Z_1, Z_2)$;
- $\text{Corr}(Z_1, Z_2)$.

Compare cada resultado com a quantidade correspondente para X_1 e X_2 .

5. Classifique como verdadeira ou falsa a afirmação a seguir e justifique sua resposta utilizando os resultados obtidos nos itens anteriores e a diferença entre covariância e correlação:

Quanto maior a covariância entre duas variáveis, mais forte é necessariamente a associação linear entre elas.

6. Considere agora que nenhuma distribuição probabilística específica, em particular a normal multivariada, tenha sido assumida para $\mathbf{X}$. Indique quais resultados utilizados nos itens 1 a 5 continuam válidos desde que existam os momentos de primeira e segunda ordem necessários. Explique por que a definição e as propriedades algébricas da matriz de covariâncias não dependem da hipótese de normalidade multivariada.

Exercício 12.2 (Normalidade conjunta, independência e condicionamento). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \right).$$

1. Determine a distribuição marginal do vetor

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix}.$$

Apresente explicitamente o vetor de médias e a matriz de covariâncias dessa distribuição marginal. Em seguida, determine se X_1 e X_3 são independentes e indique o resultado da distribuição normal multivariada que permite estabelecer essa conclusão.

2. Considere agora os blocos

$$\mathbf{X}_A = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e X_3 . Extraia da matriz de covariâncias de $\mathbf{X}$ o bloco de covariâncias cruzadas entre $\mathbf{X}_A$ e X_3 . A partir desse bloco e das propriedades da distribuição normal multivariada, determine se $\mathbf{X}_A$ e X_3 são independentes. Justifique a conclusão.

3. Determine a distribuição condicional

$$\mathbf{X}_A \mid X_3 = 0.$$

Para isso, particione o vetor de médias e a matriz de covariâncias de acordo com os dois blocos considerados. Apresente numericamente o vetor de médias condicionais e a matriz de covariâncias condicionais e escreva a distribuição normal resultante.

4. Suponha agora que fossem conhecidos apenas o vetor de médias e a matriz de covariâncias apresentados no enunciado, sem assumir que $\mathbf{X}$ possui distribuição normal multivariada. Reavalie separadamente:

- a conclusão de independência entre X_1 e X_3 ;
- a conclusão sobre a independência entre $\mathbf{X}_A$ e X_3 ;
- a forma da distribuição condicional de $\mathbf{X}_A$ dado $X_3 = 0$.

Para cada caso, indique o que ainda pode ser concluído somente a partir das médias e covariâncias conhecidas e o que dependia especificamente da normalidade conjunta. Em particular, explique por que covariância nula não implica, em geral, independência e por que a distribuição condicional não é determinada, em uma população arbitrária, apenas pelos dois primeiros momentos.

Exercício 12.3 (Estatística, estimador e estimativa da matriz de covariâncias). Uma amostra aleatória de tamanho $n = 6$ de um vetor com $p = 3$ componentes produziu a matriz SQPC observada

$$\mathbf{T} = \begin{bmatrix} 10 & 2 & 0 \\ 2 & 5 & 1 \\ 0 & 1 & 4 \end{bmatrix}.$$

1. Explique a função de cada um dos objetos a seguir no problema de estimação da matriz de covariâncias:
- a estatística aleatória $\mathbf{T}$;
 - sua realização observada $\mathbf{T}$;

- o parâmetro populacional Σ ;
- um estimador de Σ ;
- a estimativa obtida após a observação da amostra.

Em sua resposta, deixe explícita a diferença entre um objeto aleatório, seu valor observado e o parâmetro populacional que se pretende estimar.

2. A partir de $\mathbf{T}$, calcule numericamente:

- a estimativa não viesada de Σ ;
- a estimativa de máxima verossimilhança de Σ sob o modelo normal multivariado, quando o máximo da verossimilhança existe.

Identifique o divisor utilizado em cada caso. Em seguida, explique por que os dois divisores são diferentes e qual propriedade de cada estimador está sendo considerada em sua construção.

3. Verifique se $\mathbf{T}$ é positiva definida utilizando um critério estudado no Módulo I e apresente a verificação realizada. A partir desse resultado, determine o posto de $\mathbf{T}$ e conclua se, para esta amostra, a estimativa de máxima verossimilhança calculada no item 2 pertence ao espaço das matrizes de covariâncias positivas definidas exigido pelo modelo normal não singular.
4. Os dois estimadores utilizados no item 2 são diferentes para uma amostra finita. Explique por que essa diferença não impede que ambos sejam consistentes para Σ quando p permanece fixo e $n \rightarrow \infty$. Em sua justificativa, relacione os dois estimadores por meio de seus divisores e indique o que ocorre com essa diferença relativa quando n aumenta.
5. Suponha agora que as observações sejam i.i.d. de uma população multivariada que **não** possui distribuição normal, mas possui vetor de médias e matriz de covariâncias finitos. Para cada afirmação a seguir, indique se ela permanece válida, deixa de ser válida em geral ou necessita de hipóteses adicionais:

- $E(\bar{\mathbf{X}}) = \mu$;
- $\text{Cov}(\bar{\mathbf{X}}) = \Sigma/n$;
- $E(\mathbf{S}) = \Sigma$;
- $\mathbf{S} \xrightarrow{P} \Sigma$ quando $n \rightarrow \infty$ e p permanece fixo;
- $(n-1)\mathbf{S}$ possui exatamente distribuição de Wishart;
- $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes.

Explique também por que a matriz $\mathbf{T}/n$ continua podendo ser calculada para uma amostra não normal, mas não deve ser chamada automaticamente de estimativa de máxima verossimilhança de Σ sem que seja especificado um modelo probabilístico cuja verossimilhança conduza a esse estimador.

Exercício 12.4 (Estrutura e hipótese em um modelo linear multivariado). Considere um modelo linear multivariado com $n = 4$ unidades e duas variáveis-resposta:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz de delineamento possui duas colunas: a primeira corresponde ao intercepto e a segunda a uma covariável. Suponha que

$$\text{posto}(\mathbf{Z}) = 2,$$

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{Z}^\top \mathbf{Y} = \begin{bmatrix} 8 & 12 \\ 2 & -2 \end{bmatrix}.$$

Após o ajuste, a SQPC residual observada é

$$\mathbf{E} = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix}.$$

1. Utilize o resultado de mínimos quadrados para o caso em que $\mathbf{Z}$ possui posto completo e calcule numericamente $\widehat{\mathbf{B}}_{\text{obs}}$. Apresente a matriz estimada completa e suas dimensões.
2. Utilizando a organização das linhas e colunas de $\widehat{\mathbf{B}}_{\text{obs}}$, identifique explicitamente:
 - quais elementos correspondem aos interceptos das duas variáveis-resposta;
 - quais elementos correspondem aos coeficientes da covariável nas duas variáveis-resposta;
 - qual coluna reúne os coeficientes do modelo para a primeira resposta;
 - qual coluna reúne os coeficientes do modelo para a segunda resposta.

A interpretação solicitada neste item refere-se à posição e à função dos coeficientes no modelo, pois não foi atribuído um significado específico à covariável.

3. Determine numericamente:
 - o posto r da matriz de delineamento;
 - os graus de liberdade residuais $n - r$;
 - a estimativa não viesada da matriz de covariâncias dos erros.

Apresente a matriz de covariâncias residual estimada.

4. Formule a hipótese de que a covariável não possui efeito linear sobre nenhuma das duas variáveis-resposta na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe as dimensões dessas matrizes e mostre que a hipótese resultante equivale a impor simultaneamente que os dois coeficientes associados à covariável sejam iguais a zero. Justifique também por que essa função de $\mathbf{B}$ é estimável no modelo considerado.

5. O estimador de mínimos quadrados de cada coluna de $\mathbf{B}$ coincide com o estimador obtido ao ajustar separadamente um modelo linear para cada variável-resposta utilizando a mesma matriz $\mathbf{Z}$. Explique por que essa equivalência na estimação dos coeficientes não torna desnecessária a matriz de covariâncias residual. Em sua resposta, indique qual informação sobre a relação entre as respostas é registrada pelos elementos fora da diagonal dessa matriz.

Exercício 12.5 (Resultados exatos, ausência de normalidade e resultados assintóticos). Considere as afirmações a seguir.

I. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

então o vetor de médias amostrais possui exatamente uma distribuição normal multivariada, a SQPC amostral possui distribuição de Wishart e o vetor de médias amostrais é independente da matriz de covariâncias amostral.

II. Para qualquer população com vetor de médias e matriz de covariâncias finitos,

$$(n-1)\mathbf{S}$$

possui exatamente uma distribuição de Wishart.

III. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são i.i.d., possuem vetor de médias μ e matriz de covariâncias finita Σ e a dimensão p permanece fixa, então

$$\sqrt{n}(\bar{\mathbf{X}} - \mu)$$

converge em distribuição para uma distribuição normal multivariada quando $n \rightarrow \infty$, mesmo que a população de origem não possua distribuição normal multivariada.

IV. Se o modelo é identificável, o parâmetro verdadeiro pertence ao interior do espaço paramétrico, log-verossimilhança duas vezes continuamente diferenciável em uma vizinhança do parâmetro verdadeiro, possibilidade de trocar diferenciação e integração ou esperança, a matriz de informação de Fisher é positiva definida, as restrições impostas por H_0 são regulares e a dimensão paramétrica permanece fixa quando $n \rightarrow \infty$, então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_{\nu}^2,$$

em que ν corresponde ao número de restrições independentes impostas por H_0 . Portanto, a distribuição qui-quadrado obtida pelo Teorema de Wilks é assintótica e, em geral, não corresponde à distribuição exata da estatística em amostras finitas.

V. Se a população não possui distribuição normal multivariada, então, mesmo sob amostragem i.i.d. e existência de segundos momentos finitos, o vetor de médias amostrais deixa de ser não viesado para μ e a matriz de covariâncias amostral deixa de ser não viesada e consistente para Σ .

VI. Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0} \quad \text{e} \quad n > p.$$

Para testar

$$H_0 : \mu = \mu_0,$$

considere a estatística

$$\mathsf{T}^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0).$$

Sob H_0 , a normalidade multivariada das observações, a independência entre as unidades amostrais, a definição positiva de Σ e a condição $n > p$ permitem obter o resultado exato

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}.$$

Se a população não possui distribuição normal multivariada, mas as observações são i.i.d., possuem vetor de médias μ , matriz de covariâncias finita e positiva definida Σ , a matriz de covariâncias amostral satisfaz

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

e p permanece fixo quando

$$n \rightarrow \infty,$$

então, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2.$$

Portanto, fora da normalidade multivariada, a distribuição qui-quadrado é um resultado assintótico. Esse resultado não implica que a transformação de $\mathbf{T}^2$ para a distribuição F permaneça exata em amostras finitas.

Para cada afirmação:

1. Classifique a afirmação como **correta** ou **incorreta** e apresente uma justificativa baseada em um resultado estudado nos capítulos.
2. Para cada afirmação classificada como incorreta, escreva uma versão corrigida, modificando apenas as hipóteses ou a conclusão necessárias para que ela se torne válida.
3. Para cada resultado utilizado, liste explicitamente as hipóteses necessárias à sua validade e indique quais delas já aparecem na respectiva afirmação. Considere, quando pertinente, amostragem i.i.d., independência das unidades, normalidade multivariada, existência de momentos, definição positiva de Σ , dimensão p fixa e condições de regularidade do modelo.

Ao final, explique por que as duas afirmações a seguir são inadequadas:

Se os dados não são normais, os métodos clássicos deixam de funcionar.

e

Se a amostra é grande, os pressupostos deixam de ser importantes.

Em sua resposta, distinga a perda de uma **distribuição exata em amostra finita** da possibilidade de utilizar um **resultado assintótico**, e explique por que independência, existência de momentos e o regime dimensional continuam sendo relevantes quando n cresce.

Exercício 12.6 (T^2 de Hotelling, normalidade e o papel do delineamento). Um estudo mede duas variáveis nos mesmos 10 indivíduos antes e depois de uma intervenção. Para cada indivíduo, define-se o vetor de diferenças

$$\mathbf{D}_i = \mathbf{X}_{i,\text{depois}} - \mathbf{X}_{i,\text{antes}}, \quad i = 1, \dots, 10.$$

Os vetores de diferenças produziram

$$\bar{\mathbf{d}} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\mathbf{S}_D = \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix}.$$

Deseja-se avaliar se houve alteração média conjunta nas duas variáveis após a intervenção.

Admita inicialmente que as condições necessárias para a distribuição exata de T^2 sejam satisfeitas e utilize

$$F_{2,8;0,95} = 4,46.$$

1. Defina o vetor populacional de médias das diferenças μ_D e formule as hipóteses nula e alternativa para avaliar a ausência de alteração média conjunta. Em seguida, explique por que, após a construção dos vetores $\mathbf{D}_i$, o problema pode ser tratado como um problema de uma amostra aplicado aos vetores de diferenças.
2. Identifique explicitamente as condições necessárias para utilizar a distribuição exata de T^2 neste problema. Sua resposta deve considerar:
 - a distribuição conjunta dos vetores $\mathbf{D}_i$;
 - a independência entre indivíduos;
 - a definição positiva da matriz de covariâncias populacional das diferenças;
 - a relação entre o tamanho amostral n e a dimensão p .

Verifique numericamente a condição que envolve n e p .

3. Calcule a estatística T^2 para o teste da hipótese formulada no item 1. Em seguida, utilize a transformação estudada no capítulo para obter a estatística com distribuição F , informe seus graus de liberdade, compare o valor calculado com o valor crítico fornecido e apresente:
 - a decisão estatística ao nível de significância de 5%;
 - a conclusão no contexto da alteração média conjunta das duas variáveis.
4. Escreva a matriz de covariâncias do vetor de diferenças $\mathbf{D}_i$ em função das matrizes de covariâncias das medidas “antes” e “depois” e das covariâncias cruzadas entre essas duas medidas. Utilize essa expressão para explicar precisamente qual informação sobre a dependência dentro de cada indivíduo seria ignorada se as observações “antes” e “depois” fossem tratadas como duas amostras independentes.
5. Suponha, em outro estudo, que as duas condições sejam aplicadas a dois grupos constituídos por indivíduos distintos. Sob independência entre os grupos, normalidade multivariada e uma matriz de covariâncias populacional comum, indique:
 - qual estimador da matriz de covariâncias comum deve ser utilizado;
 - qual versão da estatística T^2 deve ser utilizada para comparar os vetores de médias dos dois grupos;
 - qual característica do delineamento distingue esse problema do problema pareado apresentado no início da questão.
6. Retorne ao estudo pareado original e suponha agora que a normalidade multivariada dos vetores de diferenças $\mathbf{D}_i$ não seja uma hipótese razoável.
 - a. Explique quais quantidades calculadas nos itens anteriores continuam podendo ser obtidas normalmente a partir da amostra, como $\bar{\mathbf{d}}$, $\mathbf{S}_D$ e o valor numérico de T^2 .
 - b. Explique por que, com $n = 10$, a transformação de T^2 para a distribuição F deixa de possuir, em geral, a justificativa de uma distribuição exata.
 - c. Suponha que, em vez de 10 indivíduos, uma sequência de estudos forneça amostras i.i.d. cada vez maiores de vetores de diferenças, com $p = 2$ fixo, segundos momentos finitos e matriz $\Sigma_D \succ \mathbf{0}$. Indique qual distribuição assintótica de T^2 pode ser utilizada sob H_0 quando $n \rightarrow \infty$.
 - d. Explique por que o resultado do item anterior não permite afirmar que a calibração finita pela distribuição F se tornou exata fora da normalidade.

Parte II — Exercícios com uso do R

Nesta parte, os cálculos solicitados devem ser construídos preferencialmente por meio de operações matriciais no R. Quando existir uma função pronta que reproduza diretamente um resultado estudado nos Módulos I ou II, utilize-a somente depois de realizar a construção matricial correspondente e apenas como forma de conferência.

Os códigos devem ser reprodutíveis e os resultados numéricos devem ser acompanhados das interpretações solicitadas. Nos procedimentos inferenciais, identifique as condições que sustentam a distribuição utilizada. A obtenção de uma estatística de teste ou de um valor- p pelo software não constitui, por si só, evidência de que as hipóteses probabilísticas do procedimento sejam satisfeitas.

Exercício 12.7 (Modelo linear multivariado com os dados `swiss`). Utilize o conjunto de dados `swiss`.

Considere como variáveis-resposta:

- `Fertility`;
- `Infant.Mortality`.

Construa

$$\mathbf{Y} = [\text{Fertility} \quad \text{Infant.Mortality}]$$

e uma matriz de delineamento $\mathbf{Z}$ cujas colunas, nesta ordem, correspondam a:

1. intercepto;
2. `Agriculture`;
3. `Education`.
4. Determine n , p , q e o posto r de $\mathbf{Z}$. Calcule os graus de liberdade residuais $n - r$. Em seguida, obtenha $\widehat{\mathbf{B}}_{\text{obs}}$ diretamente por operações matriciais e apresente a matriz com as linhas identificadas por `Intercepto`, `Agriculture` e `Education` e as colunas por `Fertility` e `Infant.Mortality`.

Somente depois desse cálculo, ajuste separadamente com `lm()` os dois modelos univariados correspondentes e verifique se seus coeficientes coincidem, salvo diferenças de arredondamento, com as respectivas colunas de $\widehat{\mathbf{B}}_{\text{obs}}$.

5. Calcule a matriz de valores ajustados e a matriz de resíduos $\widehat{\mathbf{U}}$. Verifique numericamente a condição

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}$$

calculando $\mathbf{Z}^\top \widehat{\mathbf{U}}$ e examinando se seus elementos são numericamente próximos de zero.

Explique por que essa propriedade decorre do ajuste por mínimos quadrados e não constitui uma verificação de normalidade dos erros.

6. Construa a SQPC residual

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}$$

e calcule o estimador não viesado da matriz de covariâncias residual. Interprete:

- os elementos da diagonal como variâncias residuais das duas respostas;
- o elemento fora da diagonal como covariância residual entre **Fertility** e **Infant.Mortality** após considerados os efeitos lineares de **Agriculture** e **Education**.

Como a direção constante pertence ao espaço coluna de $\mathbf{Z}$, construa também $\mathbf{T}$ e $\mathbf{T}_{\text{mod}}$ e verifique numericamente

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

7. Formule, na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

a hipótese de que o coeficiente de **Education** é igual a zero simultaneamente nas duas variáveis-resposta. Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe suas dimensões e verifique a condição de estimabilidade.

Não realize um teste multivariado dessa hipótese. O objetivo é construir corretamente a restrição matricial correspondente aos coeficientes de **Education**.

8. Considere os resultados obtidos nos itens anteriores e classifique-os em três grupos:
- a. resultados que decorrem da álgebra de mínimos quadrados e podem ser calculados sem assumir normalidade multivariada dos erros;

b. propriedades de esperança e covariância dos estimadores que exigem condições sobre a média, a independência entre unidades e a estrutura de covariâncias dos erros, mas não necessariamente normalidade;

c. resultados inferenciais exatos, como distribuições normais matriciais, distribuições de Wishart e independência entre estimadores e SQPC residual, cuja derivação depende da normalidade multivariada dos erros.

Para cada grupo, identifique pelo menos um resultado utilizado nesta questão e indique as condições necessárias.

Exercício 12.8 (Comparação multivariada entre regiões dos Estados Unidos). Utilize o conjunto `USArrests` e associe cada estado à sua região por meio dos objetos `state.name` e `state.region`.

Uma possibilidade para construir o vetor de regiões é

```
regiao <- state.region[
  match(
    rownames(USArrests),
    state.name
  )
]
```

Considere apenas os estados classificados nas regiões **South** e **Northeast**. Em cada região, utilize conjuntamente as quatro variáveis quantitativas de `USArrests`.

1. Determine:

- os tamanhos amostrais n_1 e n_2 ;
- a dimensão p ;
- os vetores de médias amostrais;
- as matrizes de covariâncias amostrais.

Calcule também

$$\nu = n_1 + n_2 - 2$$

e verifique se a relação entre ν e p satisfaz a condição dimensional necessária à construção da estatística clássica T^2 para duas amostras.

2. Construa matricialmente a matriz de covariâncias agrupada $\mathbf{S}_p$ e verifique se ela é invertível. Em seguida, calcule a estatística T^2 de Hotelling para testar

$$H_0 : \mu_{\text{South}} = \mu_{\text{Northeast}}.$$

Transforme T^2 para a estatística com distribuição F correspondente e informe:

- o valor de T^2 ;
- o valor da estatística F ;
- os graus de liberdade;
- o valor- p ;
- a decisão ao nível de significância de 5%;
- a conclusão sobre a igualdade dos vetores de médias populacionais.

A conclusão deve se referir ao vetor de quatro médias analisado conjuntamente, e não a cada variável separadamente.

3. A distribuição F utilizada no item anterior é exata sob condições específicas. Identifique explicitamente:

- a independência entre as duas amostras;
- a independência das unidades dentro de cada amostra;
- a normalidade multivariada em cada população;
- a igualdade das matrizes de covariâncias populacionais;
- a definição positiva da matriz de covariâncias comum;
- a condição dimensional necessária à inversão da matriz utilizada em T^2 .

Indique quais dessas condições são características do delineamento e quais são hipóteses sobre as distribuições populacionais.

4. Examine graficamente as quatro variáveis em cada região utilizando gráficos adequados para identificar assimetria acentuada e observações extremas. Utilize também gráficos quantil-quantil normais para cada variável.

A partir desses gráficos, descreva os principais desvios observados em relação à normalidade marginal. Não conclua que a distribuição é normal multivariada apenas porque uma ou mais variáveis apresentam comportamento aproximadamente normal em análises marginais.

Explique por que essas análises podem fornecer informações sobre a plausibilidade da normalidade, mas não demonstram que a hipótese de normalidade multivariada seja satisfeita.

5. Suponha que a normalidade multivariada não seja considerada razoável para esses dados.
- a.** Indique quais das seguintes quantidades continuam perfeitamente definidas como estatísticas calculadas a partir da amostra:
- os vetores de médias amostrais;
 - as matrizes de covariâncias amostrais;
 - a matriz de covariâncias agrupada;
 - o valor numérico de T^2 .
- b.** Explique por que a ausência de normalidade não impede o cálculo dessas quantidades, mas elimina, em geral, a justificativa para afirmar que a transformação de T^2 possui exatamente a distribuição F utilizada no item 2.
- c.** Considere uma sequência de estudos em que $p = 4$ permanece fixo, $n_1 \rightarrow \infty$, $n_2 \rightarrow \infty$, $n_1/(n_1 + n_2) \rightarrow \lambda \in (0, 1)$, as unidades são independentes, as duas populações possuem segundos momentos finitos e compartilham uma matriz de covariâncias positiva definida Σ . Explique por que resultados assintóticos podem ser utilizados para a inferência sobre a diferença entre os vetores de médias mesmo sem normalidade multivariada.
- d.** Explique por que o crescimento dos tamanhos amostrais não transforma a distribuição F de amostra finita, derivada sob normalidade multivariada e matriz de covariâncias comum, em uma distribuição exata fora dessas condições.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13 Problemas e estruturas das técnicas multivariadas

Os Módulos 1 e 2 estabeleceram a base matemática, geométrica, probabilística e inferencial utilizada na Análise Multivariada. Vetores e matrizes fornecem a representação dos dados; distâncias, produtos internos e projeções descrevem sua geometria; autovetores e vetores singulares identificam direções relevantes, enquanto autovalores e valores singulares quantificam magnitudes associadas a essas direções; matrizes de covariâncias e correlações descrevem a estrutura de variabilidade conjunta e de associação linear; e os modelos probabilísticos e inferenciais permitem formular conclusões sobre populações multivariadas.

Neste módulo, esses conhecimentos serão combinados para formular as principais técnicas multivariadas. Cada técnica será tratada como uma construção que articula o problema estatístico aos objetos matemáticos, probabilísticos e inferenciais já desenvolvidos, tornando explícitas as ligações entre esses fundamentos e a solução obtida. O ponto de partida passa a ser o problema estatístico. Redução de dimensionalidade, representação de estruturas latentes, formação de grupos, análise de associações em tabelas de contingência, comparação de vetores de médias e discriminação de grupos exigem formulações distintas (Johnson; Wichern, 2007).

Uma mesma estrutura matemática pode aparecer em técnicas diferentes. A decomposição espectral pode identificar direções de maior variabilidade, fornecer uma solução inicial para cargas fatoriais no método de fatores principais ou participar da determinação de direções de separação entre grupos. O significado estatístico depende do objeto analisado e do critério utilizado.

A formulação das técnicas deste módulo será organizada pelos elementos apresentados na Tabela 13.1.

Tabela 13.1: Elementos utilizados na formulação das técnicas multivariadas.

Elemento	Função na formulação
Problema estatístico	Define o objetivo da análise
Estrutura dos dados	Estabelece a forma como a informação está organizada
Objeto matemático	Representa a informação relevante para a técnica

Elemento	Função na formulação
Critério ou modelo	Determina a propriedade otimizada, decomposta ou modelada
Solução	Produce direções, coordenadas, grupos, parâmetros ou funções
Interpretação	Atribui significado estatístico e geométrico à solução

O objetivo deste capítulo é organizar os principais problemas da Análise Multivariada, identificar as estruturas compartilhadas pelas técnicas que serão desenvolvidas nos capítulos seguintes e explicitar como os fundamentos dos Módulos 1 e 2 passam a compor sua formulação.

13.1 Do problema estatístico à técnica multivariada

A presença de várias variáveis em um conjunto de dados caracteriza o contexto multivariado, mas não determina a técnica a ser utilizada. A escolha depende da estrutura que será analisada e do objetivo estabelecido.

Considere a matriz de dados $\mathbf{X}$ definida na Definição 1.6. Quando suas colunas correspondem a variáveis quantitativas, cada observação pode ser representada geometricamente pelas respectivas coordenadas em $\mathbb{R}^p$, conforme discutido na Seção 1.2. Variáveis categóricas não devem ser incorporadas automaticamente a essa geometria apenas pela atribuição de códigos numéricos; técnicas que utilizam categorias ou dados mistos exigem representações compatíveis com a natureza das variáveis.

A mesma matriz de dados quantitativos pode ser utilizada para construir combinações lineares que concentrem variabilidade, identificar grupos de observações semelhantes ou, quando os grupos são conhecidos, determinar direções que os separem. O conjunto de dados permanece o mesmo, enquanto o objeto de interesse e o critério de solução se modificam.

A Tabela 13.2 reúne as principais correspondências que serão desenvolvidas neste módulo.

Tabela 13.2: Correspondência entre problemas, estruturas e técnicas multivariadas.

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar a variabilidade em menor dimensão	Σ , $\mathbf{S}$, $\mathcal{R}$, $\mathbf{R}$ ou matriz de dados centralizada	Maximização da variância e aproximação de posto reduzido	Análise de Componentes Principais

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Explicar associações por dimensões não observadas	Matriz de covariâncias ou correlações	Modelo de fatores comuns	Análise Fatorial
Formar grupos de objetos semelhantes	Matriz de dados ou de dissimilaridades	Critérios de proximidade, dispersão ou ligação; modelos probabilísticos de mistura	Análise de Agrupamentos
Representar associações entre categorias	Tabela de contingência, massas e perfis	Geometria qui-quadrado, SVD e decomposição da inércia	Análise de Correspondência
Comparar conjuntamente várias respostas	Matrizes de hipótese e erro	Raízes características e critérios multivariados de teste	Análise de Variância Multivariada
Separar grupos conhecidos e classificar observações	Médias, covariâncias, probabilidades de classe e dispersões de grupos	Regra de Bayes, LDA/QDA ou critério de Fisher	Análise Discriminante

Os objetos utilizados nessa tabela já começaram a ser construídos nos módulos anteriores. A matriz de dados definida na Definição 1.6 permite trabalhar diretamente com observações e variáveis. A matriz de covariâncias populacional Σ , definida na Definição 8.2, e sua correspondente observada $\mathbf{S}$, definida na Definição 8.11, descrevem a variabilidade conjunta. A matriz de correlações observada $\mathbf{R}$, definida na Definição 8.12, corresponde à estrutura obtida após a padronização marginal das variáveis.

A escolha entre covariâncias e correlações não altera o objetivo estatístico da técnica, mas modifica a representação da variabilidade utilizada na formulação e pode, consequentemente, modificar a solução. A matriz de covariâncias preserva as escalas originais, enquanto a matriz de correlações atribui variância unitária às variáveis. Essa diferença será retomada no Capítulo 14 ao formular a Análise de Componentes Principais (ACP) a partir de $\mathbf{S}$ ou $\mathbf{R}$. A influência da escala também será retomada no Capítulo 16, pois a padronização das variáveis pode modificar as distâncias entre os objetos e, consequentemente, a estrutura dos grupos obtidos.

Outras técnicas utilizam estruturas diferentes. A Capítulo 16 pode partir de dados multivariados ou de dissimilaridades entre objetos e admite diferentes definições matemáticas de grupo. A Capítulo 17 parte de frequências organizadas em uma tabela de contingência e constrói massas, perfis e uma geometria ponderada. A Capítulo 18 utiliza diretamente a estrutura do modelo

linear multivariado definido na Definição 11.3. A Capítulo 19 utiliza informações sobre grupos previamente conhecidos e articula formulações probabilísticas de classificação com a formulação geométrica de Fisher.

A estrutura de entrada delimita a informação disponível para a técnica. Uma matriz de covariâncias resume relações de segunda ordem entre variáveis. Uma matriz de dissimilaridades representa relações entre pares de objetos. Uma tabela de contingência registra frequências conjuntas entre categorias. A formulação deve preservar essa diferença.

13.2 Classes de problemas multivariados

As técnicas deste módulo podem ser organizadas de acordo com o problema estatístico que resolvem. Essa classificação estabelece a função de cada método antes de sua formulação matemática.

13.2.1 Redução de dimensionalidade

A redução de dimensionalidade substitui uma representação de dimensão elevada por outra de menor dimensão, preservando uma característica definida da informação original.

Na Capítulo 14, o critério é a variabilidade. As novas dimensões são combinações lineares escolhidas para concentrar sucessivamente a variância. A formulação utiliza as projeções de Definição 3.19, a decomposição espectral sintetizada na Tabela 5.2 e a decomposição em valores singulares sintetizada na Tabela 6.7.

Representações de menor dimensão também aparecem em outras técnicas, mas associadas a problemas estatísticos distintos. Na Capítulo 17, as dimensões representam associações entre perfis de linhas e colunas de uma tabela de contingência. A propriedade que se procura representar faz parte da definição do problema.

13.2.2 Representação de estruturas latentes

A Capítulo 15 procura representar as associações entre variáveis observadas por meio de um número menor de fatores não observados.

Nesse caso, a matriz de covariâncias passa a ser objeto de um modelo. A formulação separa a parcela de variabilidade associada aos fatores comuns da parcela específica de cada variável.

Essa estrutura distingue a Capítulo 15 da Capítulo 14. A ACP procura uma representação da variabilidade observada, enquanto a Análise Fatorial específica um modelo para explicar a covariação entre as variáveis.

13.2.3 Formação de grupos

A Análise de Agrupamentos organiza objetos em grupos sem utilizar classes conhecidas previamente. A solução depende da representação dos objetos, da medida de proximidade e do critério que define a organização procurada.

A distância euclidiana definida na Definição 1.13 fornece uma medida de proximidade já estabelecida no Módulo 1. Na Capítulo 16, uma dissimilaridade é formalizada na Definição 16.1. As K -médiãs produzem uma partição, objeto definido na Definição 16.2, enquanto os métodos hierárquicos produzem uma sequência de partições aninhadas, formalizada na Definição 16.4. Uma terceira formulação define grupos probabilisticamente por meio do modelo da Definição 16.6.

Essas estruturas não são equivalentes. Sem um modelo probabilístico explícito, os grupos obtidos representam a solução do critério adotado e não correspondem automaticamente a populações distintas.

13.2.4 Representação de associações em tabelas de contingência

A Análise de Correspondência parte de uma tabela de frequências e representa os desvios em relação à independência entre suas categorias.

Na Capítulo 17, as frequências marginais originam as massas definidas na Definição 17.1 e os perfis definidos na Definição 17.2. A comparação entre perfis utiliza a distância qui-quadrado da Definição 17.3, e os desvios padronizados da independência são organizados pela matriz definida na Definição 17.5.

A Seção 17.7 mostra como a SVD dessa matriz decompõe a inércia e produz as dimensões da representação. As coordenadas padrão e principais são formalizadas, respectivamente, na Definição 17.7 e na Definição 17.8.

13.2.5 Comparação de vetores de médias

Na MANOVA, a comparação de vetores de médias constitui um caso particular de um problema mais geral: testar hipóteses sobre funções estimáveis dos parâmetros de um modelo linear multivariado com várias respostas.

O modelo definido na Definição 11.3 e a hipótese linear geral da Definição 11.17 fornecem a estrutura necessária. A Capítulo 18 acrescenta as matrizes de hipótese e erro e conduz ao problema de autovalores generalizados apresentado em Equação 18.14. Suas raízes são formalizadas na Definição 18.1 e utilizadas na construção dos quatro critérios reunidos na Seção 18.5.

A análise conjunta das respostas distingue a MANOVA de uma coleção de análises univariadas separadas.

13.2.6 Discriminação e classificação

A Análise Discriminante utiliza grupos conhecidos durante a construção da solução. Seu objetivo pode ser representar direções de separação entre esses grupos ou construir regras de classificação para novas observações.

Na formulação probabilística, distribuições condicionais e probabilidades *a priori* conduzem à regra de Bayes apresentada em Equação 19.3. A distribuição normal multivariada definida na Definição 9.1 e a distância de Mahalanobis definida na Definição 8.9 fornecem a base para as formulações da Seção 19.3 e da Seção 19.4.

A formulação geométrica da Seção 19.6 compara a dispersão entre grupos à dispersão intra-grupos. O critério amostral é definido na Definição 19.8 e conduz ao problema de autovalores generalizados de Equação 19.30.

A Análise Discriminante e a MANOVA compartilham estruturas de dispersão e problemas espectrais relacionados, mas possuem objetivos diferentes (Huberty; Olejnik, 2006). Essa relação é explicitada posteriormente em Equação 19.40.

13.3 Diferentes formas de classificar as técnicas

A classificação pelo problema estatístico será a principal organização adotada neste módulo. Outras classificações permitem comparar diferentes características das técnicas.

13.3.1 Interdependência e dependência

Nas técnicas de interdependência, a análise não estabelece previamente uma variável resposta que será explicada pelas demais. ACP, Análise Fatorial, Análise de Agrupamentos e Análise de Correspondência são exemplos.

Nas técnicas de dependência, alguma estrutura previamente definida orienta a análise. Na MANOVA, as respostas e os efeitos são determinados pelo delineamento. Na Análise Discriminante, os grupos são conhecidos durante a construção da solução.

13.3.2 Exploratórias, descritivas, preditivas e inferenciais

Uma técnica exploratória identifica padrões ou estruturas nos dados. Uma técnica descritiva resume uma configuração observada. Uma técnica preditiva produz uma regra aplicável a novas observações. Uma técnica inferencial utiliza a variabilidade amostral para formular conclusões sobre parâmetros ou populações.

Essas finalidades podem coexistir. A ACP é predominantemente exploratória e descritiva em muitas aplicações, embora exista teoria inferencial para componentes populacionais. A Análise Discriminante descreve a separação entre grupos e também pode produzir regras de classificação. A MANOVA possui finalidade principalmente inferencial.

13.3.3 Supervisionadas e não supervisionadas

A distinção entre métodos supervisionados e não supervisionados constitui uma classificação complementar e não uma taxonomia igualmente natural para todas as técnicas multivariadas.

Métodos supervisionados utilizam uma informação externa que orienta a construção da solução. Os rótulos dos grupos desempenham esse papel diretamente na Análise Discriminante. Na MANOVA, há uma estrutura previamente especificada pelo delineamento, que determina os efeitos avaliados, embora a terminologia supervisionada seja menos usual para essa técnica.

Métodos não supervisionados constroem a estrutura diretamente a partir dos dados, sem utilizar classes ou respostas previamente especificadas. ACP e Análise de Agrupamentos são exemplos.

Análise Fatorial e Análise de Correspondência são caracterizadas de forma mais adequada pelo problema estatístico e pela estrutura que procuram representar do que pela oposição entre supervisão e não supervisão.

A Tabela 13.3 resume essas classificações.

Tabela 13.3: Classificações complementares das técnicas estudadas no Módulo 3.

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
ACP	Redução de dimensionalidade	Interdependência	Exploratória e descritiva	Não supervisionada
Análise Fatorial	Estrutura latente	Interdependência	Exploratória; inferencial sob formulações probabilísticas específicas	Sem resposta externa na formulação exploratória
Análise de Agrupamentos	Formação de grupos	Interdependência	Exploratória e descritiva	Não supervisionada
Análise de Correspondência	Associação em tabelas	Interdependência	Exploratória e descritiva	Não supervisionada
MANOVA	Comparação de vetores de médias	Dependência	Inferencial	Delineamento conhecido

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
Análise Discriminante	Discriminação e classificação	Dependência	Descritiva e preditiva	Grupos conhecidos

A classificação pelo problema estatístico permanece mais diretamente ligada à formulação das técnicas. Por essa razão, os capítulos seguintes serão organizados pelo problema, pelo objeto matemático e pelo critério ou modelo utilizado.

13.4 Estruturas matemáticas recorrentes

As técnicas deste módulo reutilizam um conjunto relativamente pequeno de estruturas desenvolvidas anteriormente. O objetivo desta seção é estabelecer as conexões necessárias, sem repetir definições e demonstrações dos Módulos 1 e 2.

13.4.1 Combinações lineares e projeções

As combinações lineares definidas na Definição 1.8 constroem novas variáveis e novas direções a partir das variáveis originais. Para um vetor aleatório $\mathbf{X}$, sua forma é

$$Y = \mathbf{a}^\top \mathbf{X}.$$

O significado de $\mathbf{a}$ depende do critério da técnica. Na Capítulo 14, seus coeficientes definem direções de variabilidade. Na Capítulo 18, combinações lineares das respostas são utilizadas para comparar hipótese e erro. Na Seção 19.6, os coeficientes definem direções de separação entre grupos.

As projeções ortogonais definidas na Definição 3.19 permitem representar observações em subespaços. Essa geometria é utilizada no Capítulo 14 para interpretar a projeção sobre o subespaço principal e na Seção 19.9 para representar as observações no subespaço discriminante.

13.4.2 Formas quadráticas e problemas espectrais

As formas quadráticas definidas na Definição 2.23 aparecem na variância de combinações lineares, em distâncias ponderadas e em diferentes medidas de dispersão. Quando o critério depende da direção escolhida, surgem problemas de otimização espectral.

O quociente de Rayleigh definido na Definição 5.7 relaciona a otimização de uma forma quadrática aos autovalores de uma matriz simétrica. O resultado do Teorema 5.5 é aplicado

no Capítulo 14 à matriz de covariâncias ou de correlações para formular as componentes principais.

Quando duas formas quadráticas são comparadas, o quociente de Rayleigh generalizado da Definição 5.12 conduz ao problema de autovalores generalizados descrito no Teorema 5.8. Essa estrutura aparece concretamente em Equação 18.14 e Equação 19.30.

Quando a matriz do denominador é positiva definida, a ideia de branqueamento já desenvolvida em Equação 8.50 permite transformar a métrica correspondente em uma geometria euclidiana. Essa construção reaparece no problema simétrico da MANOVA em Equação 18.18 e na matriz branqueada de Fisher em Equação 19.31.

A decomposição espectral, sintetizada na Tabela 5.2, fornece as direções e magnitudes associadas a uma matriz simétrica. A interpretação dessas direções depende da matriz que foi construída e do problema estatístico que a originou.

13.4.3 Otimização sob restrições e critérios de ajuste

Diversas técnicas multivariadas definem suas soluções por meio da maximização ou minimização de um critério. Em termos gerais, a solução pode ser caracterizada por um problema da forma

$$\max_{\theta} f(\theta)$$

ou

$$\min_{\theta} Q(\theta),$$

eventualmente sujeito a restrições que delimitam o conjunto de soluções admissíveis.

Quando a função objetivo envolve uma forma quadrática e a restrição fixa a norma do vetor, os multiplicadores de Lagrange estabelecem a relação entre o problema de otimização e a equação de autovalores. A condição geral foi apresentada no Teorema 7.6 e a otimização sob restrição de norma foi ilustrada no Exemplo 7.11.

Essa estrutura aparece de formas distintas nas técnicas deste módulo. Na ACP, procura-se uma direção que maximize a variância sob uma restrição de normalização. Na Análise Discriminante de Fisher, maximiza-se a separação entre grupos relativamente à dispersão intragrupos. Nas K -médiãs, procura-se uma partição que minimize a dispersão intragrupos. Na Análise Fatorial, determinados métodos de estimação definem a solução pela minimização de resíduos entre estruturas de covariâncias ou pela maximização de uma função de verossimilhança.

O critério de otimização faz parte da definição da solução estatística. A obtenção de autovetores, centroides ou estimativas de parâmetros deve ser interpretada em relação à função que está sendo maximizada ou minimizada e às restrições que caracterizam o problema.

13.4.4 SVD e representações de baixa dimensão

A decomposição em valores singulares relaciona os espaços de linhas e colunas de uma matriz e permite construir aproximações de posto reduzido. Suas propriedades foram sintetizadas na Tabela 6.7.

No Módulo 3, a SVD aparece em contextos distintos. No Capítulo 14, é aplicada à matriz de dados centralizada. Na Capítulo 17, é aplicada à matriz de desvios padronizados definida na Definição 17.5, e a decomposição correspondente é desenvolvida na Seção 17.7.

O mecanismo algébrico é compartilhado, mas a matriz decomposta e o significado estatístico dos vetores e valores singulares são diferentes.

13.4.5 Distâncias e métricas

Distâncias organizam relações de proximidade entre observações; quando uma técnica admite dissimilaridades mais gerais, elas serão especificadas no capítulo correspondente. A distância euclidiana definida na Definição 1.13 é central na formulação das K -médias e participa da construção de métodos de agrupamento. A Definição 16.1 amplia essa representação no Capítulo 16.

Na Capítulo 17, a Definição 17.3 estabelece uma geometria ponderada adequada aos perfis. A distância de Mahalanobis, definida na Definição 8.9, incorpora a estrutura de dispersão à geometria. A expressão em eixos espectrais apresentada em Equação 8.49 mostra que o afastamento é ponderado pela variabilidade existente em cada direção e fornece parte da base geométrica das regras normais desenvolvidas na Seção 19.3 e na Seção 19.4.

13.4.6 Modelos lineares e probabilísticos

O modelo linear multivariado definido na Definição 11.3 organiza conjuntamente várias respostas, um delineamento e uma matriz de parâmetros. A hipótese linear geral da Definição 11.17 fornece a estrutura para testar combinações desses parâmetros. A Capítulo 18 utiliza diretamente esses resultados e acrescenta as matrizes de hipótese e erro, as raízes características e os critérios da Seção 18.5.

Outras técnicas acrescentam estruturas probabilísticas específicas à sua formulação. Na Capítulo 15, o modelo definido na Definição 15.1 especifica uma estrutura para a matriz de covariâncias, e a estimação por máxima verossimilhança acrescenta uma formulação probabilística baseada na normalidade multivariada. Na Capítulo 19, distribuições condicionais

aos grupos e probabilidades *a priori* são utilizadas na construção de regras probabilísticas de classificação. Na Seção 16.8, a Definição 16.6 apresenta uma definição probabilística alternativa de grupo.

Quando a normalidade multivariada é utilizada, sua definição e suas propriedades são as estabelecidas na Definição 9.1. Essa hipótese deve ser distinguida das estruturas algébricas e geométricas utilizadas na formulação das técnicas: ela não constitui uma condição geral para construções baseadas em combinações lineares, formas quadráticas, projeções, SVD ou problemas espectrais.

Da mesma forma, quando uma técnica utilizar máxima verossimilhança ou comparação de modelos por verossimilhanças, serão retomadas a função de verossimilhança definida na Definição 10.11 e a razão de verossimilhanças definida na Definição 12.3. Os resultados inferenciais também preservarão a distinção entre resultados exatos e assintóticos estabelecida na Definição 12.1.

A Tabela 13.4 reúne essas conexões.

Tabela 13.4: Estruturas dos Módulos 1 e 2 reutilizadas na formulação das técnicas.

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Centralização e padronização	Definição da origem e da escala da representação dos dados	ACP, Agrupamentos
Combinações lineares	Construção de novas direções ou variáveis	ACP, MANOVA, Discriminante
Projeções	Representação em subespaços e direções	ACP, Discriminante
Formas quadráticas	Medida de variabilidade, distância, associação ou separação	ACP, Correspondência, MANOVA, Discriminante
Otimização sob restrições e critérios de ajuste	Definição de soluções por maximização ou minimização de um critério	ACP, Fatorial, Agrupamentos, Discriminante
Autovalores e autovetores	Decomposição espectral e determinação de direções; em métodos específicos, obtenção de soluções de extração	ACP; Fatorial em métodos específicos de extração
Autovalores e autovetores generalizados	Comparação entre formas quadráticas e determinação de direções extremas	MANOVA, Discriminante

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
SVD	Decomposição e representação de baixa dimensão	ACP, Correspondência
Massas, perfis e ponderações marginais	Construção da geometria de associações categóricas	Correspondência
Distâncias e métricas	Representação de proximidade, associação, dispersão ou classificação	Agrupamentos, Correspondência, MANOVA, Discriminante
Covariâncias e correlações	Representação da variabilidade conjunta e da associação linear	ACP, Fatorial, MANOVA, Discriminante
Dispersão dentro e entre grupos	Comparação da estrutura de grupos	Agrupamentos, MANOVA, Discriminante
Modelo linear multivariado	Representação conjunta de respostas e efeitos	MANOVA
Normal multivariada	Formulações probabilísticas e resultados inferenciais sob hipóteses específicas	Fatorial, Discriminante, MANOVA
Função e razão de verossimilhanças	Estimação e comparação sob formulações probabilísticas específicas	Fatorial por máxima verossimilhança; MANOVA na fundamentação probabilística de critérios específicos

13.5 Mesmas estruturas, diferentes interpretações

Uma operação matemática adquire significado estatístico a partir do objeto ao qual é aplicada.

No Capítulo 14, a decomposição espectral da matriz de covariâncias ou correlações determina direções principais e as variâncias associadas a essas direções. No Capítulo 15, o método de fatores principais aplica uma decomposição espectral a uma matriz reduzida, cuja diagonal contém communalidades estimadas, para obter uma solução inicial para as cargas fatoriais. Um problema de autovalores generalizados envolvendo duas matrizes de dispersão, por sua vez, produz direções que comparam diferentes fontes de variabilidade.

A SVD apresenta a mesma característica. Aplicada à matriz de dados centralizada, participa da formulação da ACP. Aplicada aos desvios padronizados em relação à independência de uma tabela de contingência, produz os eixos da Análise de Correspondência.

A Tabela 13.5 resume essas diferenças.

Tabela 13.5: Exemplos de estruturas matemáticas com diferentes significados estatísticos.

Operação matemática	Objeto analisado	Significado da solução
Decomposição espectral	Matriz de covariâncias ou correlações	Direções e variâncias principais
Decomposição espectral	Matriz reduzida da Análise Fatorial	Solução inicial para as cargas fatoriais
Autovalores generalizados	Dispersão entre e dentro dos grupos	Direções de separação
Autovalores generalizados	Matrizes de hipótese e erro	Dimensões associadas ao efeito multivariado
SVD	Matriz de dados centralizada	Direções, escores e representação de baixa dimensão
SVD	Desvios padronizados em relação à independência	Eixos de associação entre categorias

A interpretação de um autovalor, autovetor, valor singular, vetor singular ou coordenada exige a identificação da matriz de origem e do critério que definiu sua construção. A operação matemática utilizada, isoladamente, não identifica a técnica: procedimentos distintos podem empregar a mesma decomposição, otimização ou medida de distância e, ainda assim, resolver problemas estatísticos diferentes. A identificação do método exige considerar conjuntamente o objeto analisado, o critério ou modelo adotado e o significado atribuído à solução.

As fontes de não unicidade também devem ser distinguidas. Na ACP, a indeterminação de sinal e os efeitos da multiplicidade são desenvolvidos na Seção 14.13.5.4. Na Análise Fatorial, a Proposição 15.2 formaliza uma indeterminação adicional, associada à rotação dos fatores. Na Análise de Agrupamentos, a não unicidade pode decorrer da existência de diferentes soluções ótimas, como discutido na Seção 16.12.2, ou de empates durante a construção de uma hierarquia, tratados na Seção 16.12.5. Na MANOVA, sinais e multiplicidades das direções são discutidos na Seção 18.9.4. Essas situações possuem origens matemáticas distintas e não devem ser interpretadas como uma única forma de indeterminação.

13.6 Relações entre as técnicas

Algumas técnicas apresentam estruturas matemáticas próximas, mas resolvem problemas diferentes. A Tabela 13.6 reúne relações que serão retomadas nos capítulos correspondentes.

Tabela 13.6: Relações conceituais entre técnicas do Módulo 3.

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Análise Fatorial	Covariâncias, correlações e decomposições de baixa dimensão	ACP representa a variabilidade total; Fatorial separa estrutura comum e variabilidade específica
Agrupamentos e Discriminante	Estrutura de grupos e medidas de separação	A Análise de Agrupamentos constrói grupos; a Análise Discriminante utiliza grupos conhecidos
MANOVA e Discriminante	Dispersão entre e dentro dos grupos	MANOVA testa efeitos; Discriminante representa separação e classifica
ACP e Correspondência	Decomposições de baixa dimensão	ACP utiliza a geometria de covariâncias; Correspondência utiliza perfis e geometria qui-quadrado

A relação entre ACP e Análise Fatorial é desenvolvida no Capítulo 15 e sintetizada na Tabela 15.4. As relações da Análise de Agrupamentos com outras técnicas são organizadas na Tabela 16.6. A conexão espectral entre MANOVA e a formulação de Fisher é explicitada em Equação 19.40. A relação entre ACP e Análise de Correspondência é desenvolvida na Capítulo 17 e sintetizada na Tabela 17.3.

Essas conexões mostram que a identificação da técnica depende do problema estatístico, do objeto analisado e do critério de solução. A operação matricial utilizada, isoladamente, não determina o método.

13.7 Síntese

As técnicas multivariadas deste módulo utilizam os fundamentos construídos nos Módulos 1 e 2 para resolver problemas estatísticos distintos. A formulação de cada técnica combina uma estrutura de dados, um objeto matemático e um critério ou modelo.

A centralização e a padronização definem a origem e a escala da representação utilizada por determinadas técnicas. Combinações lineares e projeções produzem novas direções e representações. Formas quadráticas e problemas espectrais permitem estudar variabilidade e comparar diferentes fontes de dispersão. Na MANOVA e na formulação de Fisher, o branqueamento converte a métrica determinada pela matriz de referência em uma geometria euclidiana e conduz a problemas espectrais simétricos equivalentes.

Autovalores e autovetores definem diretamente a solução da ACP e aparecem na Análise Fatorial em métodos específicos de extração; o modelo fatorial, porém, é definido pela decomposição da covariância em uma parte comum e uma parte específica. A SVD fornece representações de baixa dimensão na ACP e, na Seção 17.7, decompõe a inércia da Análise de Correspondência. Na Seção 16.8, diferentes critérios geométricos e probabilísticos mostram que grupo não corresponde a um único objeto matemático. A Seção 18.5 constrói quatro critérios a partir das mesmas raízes características, enquanto a Capítulo 19 articula decisão probabilística, LDA/QDA e a geometria de Fisher.

As hipóteses probabilísticas devem ser distinguidas das estruturas algébricas e geométricas. Normalidade, máxima verossimilhança e resultados inferenciais serão utilizados somente quando fizerem parte da formulação específica da técnica.

Os capítulos seguintes utilizarão esses fundamentos sem reconstruí-los. O Capítulo 14 inicia esse percurso formulando a Análise de Componentes Principais a partir da variância de combinações lineares, do quociente de Rayleigh, da decomposição espectral, das projeções e da SVD.

14 Formulação da Análise de Componentes Principais

A Análise de Componentes Principais (ACP) representa a variabilidade de um conjunto de variáveis por meio de combinações lineares ordenadas segundo a variância que concentram (Johnson; Wichern, 2007; Jolliffe, 2002). Seu objetivo é construir uma representação de menor dimensão que preserve, segundo esse critério, a maior parcela possível da variabilidade original.

A formulação utiliza combinações lineares e aplica diretamente Definição 5.7, Teorema 5.4, Definição 3.19 e Definição 6.4. A primeira leitura concentra-se no problema de redução de dimensionalidade, na construção das componentes, na formulação espectral, na variância representada, nas formulações amostral e por SVD, na distinção entre ACP baseada em covariâncias e em correlações e nos limites da representação. Ao final, os aprofundamentos teóricos retomam a caracterização do subespaço principal, o erro de reconstrução, a aproximação de posto reduzido e as propriedades da solução, enquanto os aprofundamentos metodológicos e aplicados tratam da escolha do número de componentes, da interpretação das variáveis e observações e da utilização de elementos suplementares.

14.1 O problema de redução de dimensionalidade

Considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com vetor de médias μ e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Cada realização $\mathbf{x} \in \mathbb{R}^p$ representa uma unidade por meio de p coordenadas. Quando várias dessas coordenadas apresentam associação linear, a variabilidade conjunta pode estar concentrada em um número menor de direções.

Essa situação pode ser entendida geometricamente. Uma nuvem de pontos em $\mathbb{R}^2$ pode apresentar grande extensão em uma direção e pequena extensão na direção ortogonal, como será ilustrado na Figura 14.1. Duas coordenadas são necessárias para representar exatamente cada ponto, mas uma única direção pode concentrar a maior parte da dispersão da nuvem. Em

dimensão p , o mesmo princípio conduz à procura de um subespaço de dimensão $k < p$ que represente adequadamente a variabilidade dos dados.

A ACP não seleciona diretamente k variáveis dentre as p variáveis originais. Ela constrói novas variáveis como combinações lineares das componentes de $\mathbf{X}$. Cada nova variável corresponde a uma direção no espaço das variáveis.

O vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

tem média nula e preserva a matriz de covariâncias de $\mathbf{X}$. A centralização separa a localização da distribuição de sua estrutura de dispersão. Por isso, a formulação populacional da ACP pode ser construída diretamente a partir de $\mathbf{X}_c$ e de Σ .

Uma direção unitária

$$\alpha \in \mathbb{R}^p, \quad \alpha^\top \alpha = 1,$$

produz a combinação linear

$$Y = \alpha^\top \mathbf{X}_c.$$

Como α possui norma unitária, Y representa a coordenada de $\mathbf{X}_c$ na direção definida por α .

Pelo resultado sobre momentos de combinações lineares apresentado na Proposição 8.1,

$$E(Y) = 0$$

e

$$\text{Var}(Y) = \alpha^\top \Sigma \alpha.$$

A variância da combinação linear depende, portanto, da direção α . Algumas direções podem apresentar grande dispersão, enquanto outras apresentam pequena dispersão.

A ACP utiliza essa diferença para ordenar as direções. O primeiro objetivo consiste em encontrar a direção unitária de maior variabilidade. Depois são procuradas novas direções, ortogonais às anteriores, que preservem sucessivamente a maior variabilidade restante.

A Figura 14.1 representa uma nuvem bidimensional com variabilidade distinta segundo diferentes direções. A primeira direção principal acompanha a maior extensão da nuvem, enquanto a segunda é ortogonal à primeira e representa a variabilidade remanescente.




Figura 14.1: As direções principais acompanham os eixos de maior e menor variabilidade da nuvem de observações.

A maior dispersão ocorre na direção da primeira componente. A segunda componente representa a maior variabilidade possível entre as direções ortogonais à primeira. A figura transforma a ideia de maximização da variância em uma propriedade geométrica da nuvem.

A redução de dimensionalidade ocorre quando apenas as primeiras $k < p$ direções são mantidas. A qualidade dessa representação depende da concentração da variabilidade nessas direções. Quando grande parte da variância total se concentra nas primeiras componentes, poucas direções podem representar adequadamente os dados. Quando a variabilidade se distribui de forma mais uniforme entre as componentes, a redução de dimensão implica perda proporcionalmente maior de variabilidade segundo o critério da ACP.

14.2 Componentes principais como combinações lineares

A j -ésima componente principal populacional tem a forma

$$Y_j = \alpha_j^\top \mathbf{X}_c = \alpha_j^\top (\mathbf{X} - \mu),$$

em que

$$\alpha_j \in \mathbb{R}^p$$

é o vetor de coeficientes da componente.

A formulação distingue os seguintes objetos:

- α_j define uma direção no espaço das variáveis;
- Y_j é uma variável aleatória obtida pela projeção de $\mathbf{X}_c$ nessa direção;
- a variância de Y_j quantifica a dispersão populacional representada pela direção;
- na formulação amostral, a versão estimada de α_j determina os escores das observações definidos em Definição 14.1.

Para duas combinações lineares,

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

e

$$Y_\ell = \alpha_\ell^\top \mathbf{X}_c,$$

tem-se

$$\text{Cov}(Y_j, Y_\ell) = \alpha_j^\top \Sigma \alpha_\ell.$$

Assim, a matriz Σ determina simultaneamente a variabilidade de cada direção e a covariância entre diferentes combinações lineares.

A restrição de norma unitária é necessária porque a variância depende da escala do vetor de coeficientes. Para qualquer constante c ,

$$\text{Var}(c\alpha^\top \mathbf{X}_c) = c^2 \alpha^\top \Sigma \alpha.$$

Sem controlar a norma de α , a variância poderia ser aumentada apenas multiplicando os coeficientes por uma constante. A condição

$$\alpha^\top \alpha = 1$$

remove esse efeito de escala e transforma o problema em uma escolha de direção.

14.3 Primeira componente principal

A primeira componente principal é definida pela direção unitária que apresenta a maior variância.

O problema é

$$\max_{\alpha_1 \in \mathbb{R}^p} \alpha_1^\top \Sigma \alpha_1,$$

sujeito a

$$\alpha_1^\top \alpha_1 = 1.$$

O Teorema 5.5 caracteriza os extremos do quociente definido em Definição 5.7. Aplicando esse resultado à matriz simétrica e semidefinida positiva Σ , o máximo é igual ao maior autovalor da matriz de covariâncias.

A variação do quociente de Rayleigh segundo a direção foi ilustrada na Figura 5.4. Na ACP, a matriz utilizada naquele problema passa a ser Σ , e o máximo do quociente corresponde à maior variância possível de uma combinação linear com coeficientes de norma unitária.

Se os autovalores de Σ forem ordenados como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

e α_1 for um autovetor unitário associado a λ_1 , então

$$\Sigma \alpha_1 = \lambda_1 \alpha_1.$$

A primeira componente principal é

$$Y_1 = \alpha_1^\top \mathbf{X}_c,$$

e sua variância é

$$\begin{aligned} \text{Var}(Y_1) &= \alpha_1^\top \Sigma \alpha_1 \\ &= \alpha_1^\top \lambda_1 \alpha_1 \\ &= \lambda_1 \alpha_1^\top \alpha_1. \end{aligned}$$

Portanto, como $\alpha_1^\top \alpha_1 = 1$, temos

$$\text{Var}(Y_1) = \lambda_1.$$

O maior autovalor possui uma interpretação estatística direta: ele é a maior variância que pode ser obtida por uma combinação linear das variáveis com vetor de coeficientes de norma unitária.

O autovetor correspondente fornece a direção em que essa variância é alcançada. A primeira componente principal transforma esse resultado geométrico em uma nova variável.

A derivação por multiplicadores de Lagrange não precisa ser reconstruída aqui. A relação entre critérios de otimização e soluções espectrais foi retomada na Seção 13.4.3. O resultado específico que relaciona a otimização de uma forma quadrática sob restrição de norma aos autovetores foi demonstrado no Teorema 5.6, a partir da condição geral de Lagrange apresentada no Teorema 7.6.

14.4 Componentes principais sucessivas

A primeira direção concentra a maior variabilidade possível em uma única coordenada. As componentes seguintes devem acrescentar novas direções sem repetir a informação linear já representada.

A segunda componente principal é definida como a combinação linear de maior variância entre as direções unitárias ortogonais à primeira:

$$\max_{\alpha_2 \in \mathbb{R}^p} \alpha_2^\top \Sigma \alpha_2,$$

sujeito a

$$\alpha_2^\top \alpha_2 = 1$$

e

$$\alpha_2^\top \alpha_1 = 0.$$

O mesmo princípio é aplicado sucessivamente. Para $j = 1, \dots, p$, a j -ésima direção principal resolve

$$\max_{\alpha_j \in \mathbb{R}^p} \alpha_j^\top \Sigma \alpha_j,$$

sujeito a

$$\alpha_j^\top \alpha_j = 1$$

e

$$\alpha_j^\top \alpha_\ell = 0, \quad \ell = 1, \dots, j-1.$$

A caracterização variacional de direções sucessivas já foi estabelecida no Teorema 5.7. Aplicando esse resultado a Σ , obtém-se

$$\Sigma \alpha_j = \lambda_j \alpha_j, \quad j = 1, \dots, p.$$

Assim, pode-se escolher uma base ortonormal de autovetores da matriz de covariâncias, ordenada de acordo com os autovalores decrescentes, para definir as direções principais. Quando um

autovalor possui multiplicidade maior que um, os autovetores individuais dentro do autoespaço correspondente não são únicos; essa não unicidade é desenvolvida na Seção 14.13.5.4.

A j -ésima componente principal é

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

e possui variância

$$\text{Var}(Y_j) = \lambda_j.$$

Para $j \neq \ell$,

$$\begin{aligned} \text{Cov}(Y_j, Y_\ell) &= \alpha_j^\top \Sigma \alpha_\ell \\ &= \lambda_\ell \alpha_j^\top \alpha_\ell \\ &= 0. \end{aligned}$$

Logo, as componentes principais são não correlacionadas:

$$\text{Cov}(Y_j, Y_\ell) = 0, \quad j \neq \ell.$$

Duas propriedades diferentes aparecem nessa construção. Os vetores de coeficientes são ortogonais,

$$\alpha_j^\top \alpha_\ell = 0,$$

enquanto as componentes principais são não correlacionadas,

$$\text{Cov}(Y_j, Y_\ell) = 0.$$

A primeira propriedade pertence à geometria dos vetores de coeficientes. A segunda pertence à estrutura probabilística das variáveis construídas. Na ACP, a equação de autovetores

$$\Sigma \alpha_\ell = \lambda_\ell \alpha_\ell$$

faz a ligação entre essas duas propriedades.

A ausência de correlação não implica independência em uma distribuição geral. Se $\mathbf{X}$ possui distribuição normal multivariada, qualquer transformação linear também é normal, conforme Proposição 9.4. Nesse caso, o vetor das componentes principais é normal multivariado e possui

matriz de covariâncias diagonal. Pelo resultado de independência para blocos normais de Proposição 9.6, as componentes principais são independentes.

A normalidade, portanto, acrescenta uma propriedade probabilística às componentes, mas não participa da definição da ACP.

14.5 Formulação espectral

Reunindo os vetores de coeficientes em

$$\mathbf{A} = (\alpha_1 \quad \alpha_2 \quad \cdots \quad \alpha_p),$$

tem-se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

A matriz $\mathbf{A}$ é ortogonal. Pelo Teorema Espectral de Teorema 5.4,

$$\Sigma = \mathbf{A} \Lambda \mathbf{A}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p).$$

As componentes podem ser reunidas no vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_p \end{pmatrix} = \mathbf{A}^\top \mathbf{X}_c.$$

Como

$$E(\mathbf{X}_c) = \mathbf{0},$$

tem-se

$$E(\mathbf{Y}) = \mathbf{0}.$$

Pela regra de transformação da matriz de covariâncias estabelecida na Equação 8.18,

$$\text{Cov}(\mathbf{A}^\top \mathbf{X}_c) = \mathbf{A}^\top \Sigma \mathbf{A}.$$

Substituindo a decomposição espectral,

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \mathbf{A}^\top \mathbf{A} \Lambda \mathbf{A}^\top \mathbf{A} \\ &= \Lambda. \end{aligned}$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}.$$

A transformação para componentes principais diagonaliza a estrutura de covariâncias. As variáveis originais podem apresentar covariâncias diferentes de zero; no novo sistema de coordenadas, toda a variabilidade aparece distribuída ao longo de eixos não correlacionados.

A transformação completa

$$\mathbf{X}_c \mapsto \mathbf{Y} = \mathbf{A}^\top \mathbf{X}_c$$

não reduz a dimensão. Ela representa o mesmo vetor em uma base ortonormal diferente. Pela propriedade de preservação geométrica das transformações ortogonais estabelecida na Proposição 4.10, produtos internos, normas e distâncias são preservados quando todas as p componentes são mantidas.

A redução ocorre somente quando a transformação é seguida pela retenção das primeiras $k < p$ coordenadas.

14.6 Variância total e proporção de variância

A variância total foi definida na Definição 8.6 por

$$V_T = \text{tr}(\Sigma).$$

Pela relação entre traço e autovalores estabelecida na Proposição 5.4,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Por outro lado,

$$\text{Cov}(\mathbf{Y}) = \Lambda,$$

de modo que

$$\text{tr}[\text{Cov}(\mathbf{Y})] = \sum_{j=1}^p \lambda_j.$$

Assim,

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

A ACP completa redistribui, entre novas coordenadas, a mesma variabilidade total presente nas variáveis originais. A ordenação dos autovalores concentra as maiores parcelas nas primeiras componentes.

Se

$$\text{tr}(\Sigma) > 0,$$

a proporção da variância total associada à componente j é

$$\pi_j = \frac{\lambda_j}{\sum_{\ell=1}^p \lambda_{\ell}}.$$

Para as primeiras k componentes, a proporção acumulada é

$$\Pi_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{\ell=1}^p \lambda_{\ell}}.$$

A variabilidade representada pelas primeiras k direções é

$$\sum_{j=1}^k \lambda_j,$$

enquanto a variabilidade associada às direções descartadas é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição pode ser resumida pela Tabela 14.1.

Tabela 14.1: Relação entre componentes principais, direções, autovalores e variância representada, quando a variância total é positiva.

Componente	Direção	Variância	Proporção da variância total
Y_1	α_1	λ_1	$\lambda_1 / \sum_{\ell=1}^p \lambda_\ell$
Y_2	α_2	λ_2	$\lambda_2 / \sum_{\ell=1}^p \lambda_\ell$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Y_p	α_p	λ_p	$\lambda_p / \sum_{\ell=1}^p \lambda_\ell$

Exemplo 14.1 (Componentes principais de duas variáveis). Considere um vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}.$$

A decomposição espectral fornece os autovalores

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\alpha_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

e

$$\alpha_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

A primeira componente principal é

$$Y_1 = \frac{(X_1 - \mu_1) + (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_1) = 6.$$

A segunda componente é

$$Y_2 = \frac{(X_1 - \mu_1) - (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_2) = 2$$

e

$$\text{Cov}(Y_1, Y_2) = 0.$$

A variância total é

$$\text{tr}(\Sigma) = 4 + 4 = 8,$$

que coincide com

$$\lambda_1 + \lambda_2 = 6 + 2 = 8.$$

A primeira componente representa $\frac{6}{8} = 75\%$ da variabilidade total, enquanto a segunda representa $\frac{2}{8} = 25\%$.

Se a representação for reduzida de duas para uma dimensão, a direção α_1 preserva 75% da variabilidade e descarta 25%. Nesse exemplo, a redução de dimensão possui interpretação direta: a maior parte da dispersão ocorre na direção em que as duas variáveis se deslocam conjuntamente.




Figura 14.2: Os autovalores quantificam a variância de cada componente, e sua soma acumulada determina a proporção da variabilidade representada pelas primeiras dimensões.

A Figura 14.2 mostra, em um exemplo didático, duas leituras complementares dos autovalores. O primeiro painel apresenta a variância associada individualmente a cada componente. O segundo apresenta a proporção acumulada da variância representada pelas primeiras componentes.

A concentração dos primeiros autovalores determina a capacidade de redução linear de dimensão. Quando Π_k é elevada para um valor pequeno de k , o subespaço principal representa grande parcela da variabilidade total. A proporção acumulada descreve a decomposição da variância, mas não estabelece, por si só, quantas componentes devem ser mantidas. Outros critérios utilizados para auxiliar essa escolha são apresentados na Seção 14.14.1, incluindo uma regra heurística específica para a ACP baseada na matriz de correlações.

14.7 Subespaço principal, projeção e reconstrução

Até aqui, as componentes principais foram construídas como direções sucessivas de máxima variabilidade. Quando apenas $k < p$ componentes são mantidas, essas direções podem ser consideradas conjuntamente. As primeiras k componentes definem um **subespaço principal de dimensão k** , no qual os dados podem ser representados com menor dimensionalidade.

A redução dimensional pode ser interpretada geometricamente como a projeção de $\mathbf{X}_c$ sobre o subespaço principal. Para uma realização do vetor aleatório, essa projeção fornece uma representação utilizando apenas as primeiras k componentes principais.

Entre todos os subespaços lineares de dimensão k , o subespaço principal é aquele que preserva a maior variabilidade total. Essa variabilidade corresponde à soma dos k maiores autovalores de Σ , enquanto a parcela descartada corresponde à soma dos autovalores associados às direções que não foram mantidas.

As primeiras k componentes também permitem construir, no espaço original, uma aproximação de cada realização de $\mathbf{X}_c$. Quando $k < p$, a aproximação difere da realização original por um resíduo ortogonal ao subespaço principal.

A variabilidade preservada e o erro de reconstrução descrevem a mesma escolha de subespaço sob perspectivas diferentes. O subespaço de dimensão k que preserva a maior variabilidade total é também aquele que minimiza o erro quadrático médio de reconstrução.

Quando existe separação entre o k -ésimo e o $(k + 1)$ -ésimo autovalores, o subespaço principal de dimensão k é determinado de maneira única. Se houver empate nessa fronteira, diferentes subespaços podem preservar a mesma variabilidade máxima. A definição formal dessa estrutura e as condições de unicidade são apresentadas na Definição 14.2.

A formulação matricial da propriedade de máxima variabilidade é desenvolvida na Seção 14.13.1, enquanto a relação entre variabilidade preservada e erro quadrático de reconstrução é formalizada na Seção 14.13.2.

14.8 Formulação amostral

A formulação populacional define as componentes em termos de Σ , que geralmente é desconhecida. A aplicação da técnica utiliza uma amostra para estimar suas direções e variâncias.

Considere uma realização amostral com $n \geq 2$ observações, organizada na matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com média observada $\bar{\mathbf{x}}$ e matriz centralizada

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A matriz de covariâncias observada foi definida na Definição 8.11 como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

A versão amostral da ACP substitui a matriz populacional Σ por $\mathbf{S}$.

Considere a decomposição espectral

$$\mathbf{S} = \widehat{\mathbf{A}}\widehat{\mathbf{\Lambda}}\widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\mathbf{\Lambda}} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p),$$

com

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0,$$

e

$$\widehat{\mathbf{A}} = (\hat{\alpha}_1 \quad \dots \quad \hat{\alpha}_p).$$

A Tabela 14.2 sintetiza a distinção entre os principais objetos populacionais e amostrais da ACP.

Tabela 14.2: Correspondência entre objetos populacionais e amostrais na ACP.

Objeto	População	Amostra observada
Matriz de covariâncias	Σ	$\mathbf{S}$
Direção principal j	α_j	$\hat{\alpha}_j$
Variância da componente j	λ_j	$\hat{\lambda}_j$
Componente principal	$Y_j = \alpha_j^\top (\mathbf{X} - \mu)$	construída a partir da direção estimada $\hat{\alpha}_j$
Coordenada da observação i na componente j	$y_{ij} = \alpha_j^\top (\mathbf{x}_i - \mu)$	escore $\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}})$

A direção $\hat{\alpha}_j$ é obtida a partir da amostra. Quando o autovalor populacional correspondente é simples, o autoespaço associado é unidimensional e a direção principal é determinada até mudança de sinal; nesse sentido, a direção amostral pode ser utilizada para estimar a direção populacional. Quando há multiplicidade, os autovetores individuais não são determinados de forma única, e o objeto de interesse passa a ser o autoespaço correspondente (Anderson, 2003). A relação entre a solução amostral e a populacional será retomada na Seção 14.11.

Para a observação i , o escore amostral na componente j é

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Definição 14.1 (Escore de uma componente principal). Considere a observação

$$\mathbf{x}_i \in \mathbb{R}^p,$$

sua versão centralizada

$$\mathbf{x}_i - \bar{\mathbf{x}},$$

e uma direção principal amostral unitária

$$\hat{\alpha}_j \in \mathbb{R}^p.$$

O **escore amostral da observação i na componente principal j** é sua coordenada na direção principal estimada:

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Para as primeiras k componentes, considere

$$\widehat{\mathbf{A}}_k = (\hat{\alpha}_1 \quad \dots \quad \hat{\alpha}_k).$$

Os escores das n observações nas k primeiras componentes podem ser organizados na matriz

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k \in \mathbb{R}^{n \times k}.$$

O elemento $\hat{y}_{ij}$ de $\widehat{\mathbf{Y}}_k$ é o escore da observação i na componente j . Assim, $\widehat{\mathbf{Y}}_k$ fornece a representação das observações no espaço principal de dimensão k .

Para uma observação específica i , suas coordenadas nas primeiras k componentes podem ser reunidas no vetor

$$\hat{\mathbf{y}}_{i,k} = \widehat{\mathbf{A}}_k^\top (\mathbf{x}_i - \bar{\mathbf{x}}) = \begin{pmatrix} \hat{y}_{i1} \\ \vdots \\ \hat{y}_{ik} \end{pmatrix}.$$

Os elementos de $\hat{\alpha}_j$ são os **coeficientes da componente principal**, enquanto $\hat{y}_{ij}$ é o **escore amostral** da observação i nessa componente. Os coeficientes definem as direções principais e os escores fornecem as coordenadas das observações nessas direções.

A matriz centralizada reconstruída a partir das primeiras k componentes pode ser escrita como

$$\widetilde{\mathbf{X}}_{c,k} = \widehat{\mathbf{Y}}_k \widehat{\mathbf{A}}_k^\top.$$

Como

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k,$$

segue que

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \widehat{\mathbf{A}}_k \widehat{\mathbf{A}}_k^\top.$$

Assim, a reconstrução amostral também é uma projeção ortogonal sobre o subespaço principal estimado.

Para retornar às unidades e à localização originais, adiciona-se novamente o vetor de médias:

$$\widetilde{\mathbf{X}}_k = \widetilde{\mathbf{X}}_{c,k} + \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A centralização remove a localização antes da determinação das direções principais; a reconstrução final restitui essa localização.

14.9 Formulação da ACP pela SVD

A formulação amostral pode ser obtida diretamente da matriz centralizada sem formar previamente $\mathbf{S}$.

Se

$$r = \text{posto}(\mathbf{X}_c) > 0,$$

considere a SVD compacta definida na Definição 6.4:

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

em que

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}, \quad \mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Os valores singulares são ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

a relação entre a SVD da matriz centralizada e a decomposição espectral da covariância, estabelecida na Proposição 6.14, fornece

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto, para as componentes associadas a autovalores positivos, a direção principal amostral pode ser escolhida como um autovetor $\mathbf{v}_j$ associado a $\hat{\lambda}_j$:

$$\hat{\alpha}_j = \mathbf{v}_j.$$

Como todo autovetor, $\mathbf{v}_j$ pode ser substituído por $-\mathbf{v}_j$ sem alterar a componente principal como direção.

Assim,

$$\hat{\lambda}_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r.$$

Os vetores singulares à direita da matriz centralizada são as direções principais amostrais associadas à variabilidade positiva. O quadrado de cada valor singular, dividido por $n-1$, é a variância observada da componente correspondente.

Se

$$r < p,$$

as $p-r$ componentes restantes possuem autovalor zero. A SVD compacta não precisa fornecer uma base para esse complemento nulo, pois essas direções não acrescentam variabilidade à representação.

A interpretação geométrica da SVD foi apresentada na Figura 6.1. Na ACP amostral, a matriz decomposta passa a ser $\mathbf{X}_c$. Os vetores singulares à direita fornecem as direções no espaço das variáveis, enquanto os produtos dos vetores singulares à esquerda pelos valores singulares fornecem as coordenadas das observações nessas direções.

Essa relação mostra que a decomposição espectral de $\mathbf{S}$ e a SVD de $\mathbf{X}_c$ não constituem duas técnicas diferentes. Para as componentes de variância positiva, elas fornecem duas formas de obter a mesma solução amostral da ACP.

Os escores também são obtidos diretamente pela SVD:

$$\widehat{\mathbf{Y}}_r = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Assim, a SVD separa naturalmente os elementos da representação:

- $\mathbf{V}_r$ contém as direções principais associadas à variabilidade positiva no espaço das variáveis;
- $\widehat{\mathbf{Y}}_r = \mathbf{U}_r \mathbf{D}_r$ contém os escores amostrais das observações;
- $\mathbf{D}_r$ determina a magnitude da variabilidade em cada direção.

A centralização também limita o número de componentes com variância positiva. Pelo resultado de posto da matriz de covariâncias observada estabelecido na Equação 8.63,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1).$$

Portanto, existem no máximo

$$\min(p, n - 1)$$

componentes principais com variância amostral positiva.

Em particular, quando $p \geq n$, a matriz $\mathbf{S}$ é necessariamente singular. Essa singularidade amostral não implica que a matriz populacional Σ seja singular; ela pode decorrer apenas do número de direções disponíveis na amostra após a centralização.

14.10 ACP baseada na matriz de correlações

A formulação anterior utiliza a matriz de covariâncias. Quando as variáveis possuem escalas ou unidades de medida diferentes, pode ser definido outro problema: realizar a ACP após padronizar cada variável para variância unitária (Johnson; Wichern, 2007).

A matriz de correlações populacional $\mathcal{R}$ foi definida na Definição 8.5, sob a condição de que todas as variâncias marginais populacionais sejam positivas, e sua correspondente observada $\mathbf{R}$ foi definida na Definição 8.12, sob a condição de que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

No nível observado, defina

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

Como

$$s_{jj} > 0, \quad j = 1, \dots, p,$$

a matriz $\mathbf{D}_S$ é positiva definida e $\mathbf{D}_S^{-1/2}$ existe. Assim,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A Equação 8.70 relaciona a matriz de correlações às colunas centralizadas e padronizadas. Para manter essa notação distinta da matriz de delineamento $\mathbf{Z}$ utilizada na Definição 11.3, neste capítulo denotaremos a matriz padronizada por

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2}.$$

Assim,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}.$$

Realizar a ACP de $\mathbf{R}$ equivale, portanto, a realizar a ACP sobre as colunas centralizadas e padronizadas de $\mathbf{X}$.

Se

$$\mathbf{R} = \widehat{\mathbf{A}}_R \widehat{\Lambda}_R \widehat{\mathbf{A}}_R^\top,$$

as direções principais observadas são obtidas no espaço das variáveis padronizadas. Os autovaleores

$$\hat{\lambda}_{R1}, \dots, \hat{\lambda}_{Rp}$$

representam as variâncias observadas das componentes construídas a partir dessas variáveis.

Como a diagonal de $\mathbf{R}$ é formada por valores iguais a 1,

$$\text{tr}(\mathbf{R}) = p.$$

Logo,

$$\sum_{j=1}^p \hat{\lambda}_{Rj} = p.$$

A proporção da variância padronizada representada pela componente j é

$$\frac{\hat{\lambda}_{Rj}}{p},$$

e a proporção acumulada nas primeiras k componentes é

$$\frac{\sum_{j=1}^k \hat{\lambda}_{Rj}}{p}.$$

A utilização de **S** ou **R** corresponde a **duas formulações diferentes da ACP**.

Na ACP baseada em **S**, as variáveis preservam suas escalas e variâncias originais. Uma variável com maior variabilidade pode exercer maior influência sobre as primeiras componentes.

Na ACP baseada em **R**, todas as variáveis entram na análise com variância unitária. As diferenças de escala marginal são removidas antes da decomposição.

A Tabela 14.3 resume essa distinção.

Tabela 14.3: Diferenças entre a ACP baseada em covariâncias e em correlações.

Aspecto	ACP por covariâncias	ACP por correlações
Matriz de entrada	S	R
Dados equivalentes	Centralizados	Centralizados e padronizados
Variâncias marginais	Mantidas nas unidades originais	Iguais a 1
Variância total	$\text{tr}(\mathbf{S})$	p
Influência da escala	Preservada	Removida pela padronização
Problema resolvido	Representar a variabilidade nas escalas originais	Representar a variabilidade após igualar as escalas marginais

A Figura 14.3 ilustra o efeito da padronização. Os dois painéis representam as mesmas observações, antes e depois da padronização marginal. A mudança das escalas altera a geometria e, conseqüentemente, as direções principais.




Figura 14.3: A ACP baseada em covariâncias preserva as escalas originais, enquanto a ACP baseada em correlações utiliza a geometria das variáveis padronizadas.

A seta vermelha representa a primeira direção principal em cada geometria. A padronização remove as diferenças de escala marginal entre as variáveis e, nesse exemplo, modifica a direção que maximiza a variância.

A escolha entre as duas matrizes faz parte da definição do problema estatístico. Ela não deve ser tratada como uma decisão puramente computacional.

A padronização modifica a geometria da nuvem de dados por meio de um escalonamento diferente em cada eixo. Consequentemente, os autovetores, os autovalores, os escores e o subespaço principal podem mudar.

Na Capítulo 15, a Análise Fatorial também pode ser formulada sobre uma matriz de covariâncias ou de correlações, mas seu objetivo é diferente: em vez de decompor a variabilidade total em direções principais, especifica um modelo para a estrutura de covariação entre as variáveis.

14.11 Formulação descritiva, populacional e inferencial

A ACP pode ser formulada sem hipótese de normalidade. Na formulação populacional baseada em covariâncias, basta que $\mathbf{X}$ possua momentos de segunda ordem finitos para que a matriz de covariâncias Σ e suas componentes principais estejam definidas. Na formulação baseada em correlações, exige-se adicionalmente que as variâncias marginais sejam positivas, como em Definição 8.5.

Na formulação **descritiva**, a matriz de dados observada é o objeto de interesse, e autovalores, direções e escores descrevem sua estrutura de variabilidade.

Na formulação **populacional**, os autovalores

$$\lambda_j$$

e os autovetores unitários

$$\alpha_j$$

são características da matriz populacional Σ . Quando uma amostra é utilizada para estudar essa estrutura, a matriz observada $\mathbf{S}$ fornece os correspondentes

$$\hat{\lambda}_j \quad \text{e} \quad \hat{\alpha}_j.$$

Sob as condições de consistência da matriz de covariâncias amostral estabelecidas na Proposição 10.12, a solução amostral pode ser interpretada como estimativa da estrutura espectral populacional. Quando um autovalor populacional é simples, a direção principal correspondente é determinada até mudança de sinal; quando há multiplicidade, os autovetores individuais deixam de ser únicos e o objeto identificado é o autoespaço correspondente, como discutido na Seção 14.13.5.4.

A normalidade multivariada não é necessária para a formulação da ACP. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação ortogonal para as componentes produz

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \Lambda).$$

Nesse caso, as componentes são independentes. Sem normalidade conjunta, a ACP garante que componentes distintas sejam não correlacionadas, mas não necessariamente independentes.

A inferência sobre autovalores, autovetores e subespaços requer hipóteses adicionais e teoria distribucional ou assintótica específica. Esses resultados não são necessários para a formulação da ACP e são retomados na Seção 14.13.6.

14.12 Limites da representação por componentes principais

A ACP resolve um problema definido de forma precisa: encontrar combinações lineares e subespaços que preservem variabilidade segundo uma matriz de covariâncias ou correlações. Os limites da técnica decorrem diretamente dessa formulação e são sintetizados na Tabela 14.4.

Tabela 14.4: Limites decorrentes da formulação clássica da Análise de Componentes Principais.

Aspecto	Consequência para a ACP
Critério de importância	As componentes são ordenadas pela variância. Uma direção de pequena variabilidade pode ser relevante para outro objetivo estatístico.
Estrutura representada	As componentes são combinações lineares e utilizam covariâncias ou correlações. Estruturas essencialmente não lineares podem não ser concentradas em poucas componentes.
Conjunto de variáveis	Inclusão, exclusão, transformação ou mudança de escala altera a matriz analisada e pode modificar toda a solução.
Sensibilidade da matriz de entrada	Valores extremos podem alterar variâncias, covariâncias, correlações e, consequentemente, autovalores e autovetores.
Redução de dimensão	Quando são descartadas direções com autovalores positivos, parte da variabilidade original deixa de ser representada.

Quando são retidas menos dimensões do que o posto efetivo da matriz analisada, parte da variabilidade é necessariamente descartada. Pela Proposição 14.2, essa perda corresponde à soma dos autovalores associados às direções excluídas. Toda a variabilidade é preservada apenas quando as dimensões descartadas possuem autovalores nulos.

14.13 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte reúne desenvolvimentos sobre o subespaço principal, a reconstrução por projeção, a aproximação de posto reduzido, as propriedades da solução e a estimação das componentes sob normalidade. Esses resultados ampliam a formulação apresentada no núcleo do capítulo, mas não são necessários para uma primeira leitura da técnica.

14.13.1 Formulação do subespaço principal e variabilidade máxima

Considere uma base ortonormal de autovetores de Σ ,

$$\alpha_1, \dots, \alpha_p,$$

ordenada de modo que

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Defina

$$\mathbf{A}_k = (\alpha_1 \quad \dots \quad \alpha_k) \in \mathbb{R}^{p \times k}.$$

Como esses vetores são ortonormais,

$$\mathbf{A}_k^\top \mathbf{A}_k = \mathbf{I}_k.$$

Suas colunas geram um subespaço que maximiza a variabilidade projetada em dimensão k .

Definição 14.2 (Subespaço principal). Seja

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias, com autovalores ordenados como

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0,$$

e seja

$$\alpha_1, \dots, \alpha_p$$

uma base ortonormal de autovetores correspondente a essa ordenação.

Para $1 \leq k \leq p$, um **subespaço principal de dimensão k** é

$$\mathcal{S}_k = \text{span} \{ \alpha_1, \dots, \alpha_k \}.$$

Se $k < p$ e

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único.

Se $\lambda_k = \lambda_{k+1}$, podem existir diferentes subespaços principais de dimensão k que preservam a mesma variabilidade máxima.

A matriz de projeção ortogonal sobre um subespaço principal $\mathcal{S}_k$ é

$$\mathbf{P}_k = \mathbf{A}_k \mathbf{A}_k^\top.$$

Essa expressão é uma aplicação direta da projeção sobre um subespaço com base ortonormal desenvolvida na Proposição 3.14.

As coordenadas de $\mathbf{X}_c$ nesse subespaço são

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c = \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix}.$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}_k) &= \mathbf{A}_k^\top \Sigma \mathbf{A}_k \\ &= \text{diag}(\lambda_1, \dots, \lambda_k). \end{aligned}$$

Portanto, a variância total das coordenadas mantidas é

$$\text{tr}[\text{Cov}(\mathbf{Y}_k)] = \sum_{j=1}^k \lambda_j.$$

Esse resultado fornece uma interpretação conjunta das primeiras k componentes. Elas determinam um subespaço linear de dimensão k que concentra a maior variabilidade possível entre todos os subespaços de mesma dimensão.

Considere qualquer matriz

$$\mathbf{Q} = (\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k) \in \mathbb{R}^{p \times k},$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

A projeção de $\mathbf{X}_c$ sobre o subespaço gerado por $\mathbf{Q}$ possui coordenadas

$$\mathbf{Q}^\top \mathbf{X}_c$$

e variância total

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) = \sum_{j=1}^k \mathbf{q}_j^\top \Sigma \mathbf{q}_j.$$

O resultado para uma única direção se estende ao conjunto das primeiras k direções.

Proposição 14.1 (Variabilidade máxima do subespaço principal). *Seja*

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias com autovalores

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

Para $1 \leq k \leq p$ e qualquer matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$

Portanto, a maior variância total que pode ser preservada por uma projeção ortogonal em um subespaço de dimensão k é

$$\sum_{j=1}^k \lambda_j.$$

Esse máximo é atingido por qualquer subespaço principal $\mathcal{S}_k$ de Definição 14.2.

Se $k < p$ e $\lambda_k > \lambda_{k+1}$, o subespaço que maximiza a variância é único.

Se $\lambda_k = \lambda_{k+1}$, o subespaço maximizador pode não ser único.



i Demonstração

Pelo Teorema Espectral de Teorema 5.4,

$$\Sigma = \mathbf{A}\mathbf{A}^\top.$$

Defina

$$\mathbf{B} = \mathbf{A}^\top \mathbf{Q}.$$

Como $\mathbf{A}$ é ortogonal e

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\mathbf{B}^\top \mathbf{B} = \mathbf{I}_k.$$

Se $b_{i\ell}$ denota o elemento da linha i e da coluna ℓ de $\mathbf{B}$, defina

$$w_i = \sum_{\ell=1}^k b_{i\ell}^2.$$

Então,

$$\begin{aligned} \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) &= \text{tr}(\mathbf{B}^\top \Lambda \mathbf{B}) \\ &= \sum_{i=1}^p \lambda_i w_i. \end{aligned}$$

Como

$$\mathbf{B}\mathbf{B}^\top$$

é um projetor ortogonal, seus elementos diagonais satisfazem

$$0 \leq w_i \leq 1.$$

Além disso,

14.13.2 Reconstrução e erro quadrático

As primeiras k componentes fornecem as coordenadas de $\mathbf{X}_c$ no subespaço principal. A projeção no espaço original é obtida por

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{Y}_k.$$

Como

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c,$$

segue que

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{A}_k^\top \mathbf{X}_c = \mathbf{P}_k \mathbf{X}_c.$$

O vetor $\tilde{\mathbf{X}}_{c,k}$ é a representação de $\mathbf{X}_c$ obtida utilizando apenas as primeiras k direções principais.

A parcela não representada é

$$\mathbf{E}_k = \mathbf{X}_c - \tilde{\mathbf{X}}_{c,k} = (\mathbf{I}_p - \mathbf{P}_k) \mathbf{X}_c.$$

A matriz de projeção residual foi definida na Definição 3.20, e a ortogonalidade entre a projeção e o resíduo decorre de Proposição 3.17. Portanto,

$$\|\mathbf{X}_c\|^2 = \|\tilde{\mathbf{X}}_{c,k}\|^2 + \|\mathbf{E}_k\|^2.$$

Tomando esperanças, a variabilidade total também se decompõe em parcela representada e parcela não representada:

$$E(\|\mathbf{X}_c\|^2) = E(\|\tilde{\mathbf{X}}_{c,k}\|^2) + E(\|\mathbf{E}_k\|^2).$$

A primeira parcela é

$$E(\|\tilde{\mathbf{X}}_{c,k}\|^2) = \sum_{j=1}^k \lambda_j,$$

enquanto, pela definição de variância total na Definição 8.6,

$$E\left(\|\mathbf{X}_c\|^2\right) = \text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Consequentemente,

$$E\left(\|\mathbf{E}_k\|^2\right) = \sum_{j=k+1}^p \lambda_j.$$

A variabilidade descartada pela redução de dimensão corresponde exatamente à soma dos autovalores associados às direções excluídas.

Proposição 14.2 (Variância preservada e erro de reconstrução). *Seja*

$$\mathbf{X} \in \mathbb{R}^p$$

um vetor aleatório com segundos momentos finitos, vetor de médias μ e matriz de covariâncias Σ . Defina

$$\mathbf{X}_c = \mathbf{X} - \mu.$$

Para $1 \leq k \leq p$, considere uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

e a projeção ortogonal

$$\tilde{\mathbf{X}}_{c,\mathbf{Q}} = \mathbf{Q}\mathbf{Q}^\top \mathbf{X}_c.$$

O erro quadrático médio de reconstrução é

$$E\left[\left\|\mathbf{X}_c - \tilde{\mathbf{X}}_{c,\mathbf{Q}}\right\|^2\right] = \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}).$$

Consequentemente, maximizar a variância preservada,

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}),$$

equivale a minimizar o erro quadrático médio de reconstrução.

Para um subespaço principal de dimensão k ,

$$\text{variância preservada} = \sum_{j=1}^k \lambda_j$$

e o erro mínimo é

$$\min_{\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k} E[\|\mathbf{x}_c - \mathbf{Q}\mathbf{Q}^\top \mathbf{x}_c\|^2] = \sum_{j=k+1}^p \lambda_j.$$

i Demonstração

Como $\mathbf{Q}\mathbf{Q}^\top$ é um projetor ortogonal,

$$\begin{aligned} E[\|\mathbf{x}_c - \mathbf{Q}\mathbf{Q}^\top \mathbf{x}_c\|^2] &= \text{tr}[(\mathbf{I}_p - \mathbf{Q}\mathbf{Q}^\top) \Sigma] \\ &= \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}). \end{aligned}$$

O primeiro termo é constante em relação a $\mathbf{Q}$. Portanto, minimizar o erro equivale a maximizar a variância preservada. Pela Proposição 14.1, o máximo é $\sum_{j=1}^k \lambda_j$ e, como $\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j$, o erro mínimo é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição de um vetor em projeção e resíduo ortogonal foi apresentada na Figura 3.5. Na ACP, o mesmo princípio é aplicado simultaneamente à nuvem de observações, utilizando como subespaço uma direção ou um subespaço principal.

A Figura 14.4 representa a redução de duas para uma dimensão. Cada observação é projetada sobre a primeira direção principal. Os segmentos vermelhos representam os resíduos de reconstrução.

Os pontos azuis são as observações centralizadas, os pontos verdes são suas representações utilizando somente a primeira componente e os segmentos vermelhos representam os resíduos de reconstrução. Entre todas as retas utilizadas como subespaço de representação, a primeira direção principal minimiza a soma dos quadrados desses resíduos. A mesma direção é aquela que preserva a maior variabilidade da nuvem projetada.




Figura 14.4: A redução para uma componente substitui cada observação por sua projeção sobre a primeira direção principal; os segmentos ortogonais representam o erro de reconstrução.

14.13.3 Geometria da qualidade de representação

A qualidade de representação pelas componentes principais pode ser expressa pela relação entre a norma quadrática da projeção e a norma quadrática do vetor representado. Para as observações, essa projeção ocorre em $\mathbb{R}^p$, sobre as direções principais. Para as variáveis, ocorre em $\mathbb{R}^n$, sobre as direções definidas pelos vetores de escores. As duas construções utilizam as relações entre produto interno, ângulo, norma e projeção desenvolvidas no Módulo I.

14.13.3.1 Qualidade de representação das observações

Defina o vetor da observação centralizada por

$$\mathbf{z}_i = \mathbf{x}_i - \bar{\mathbf{x}}.$$

A direção da componente j é dada pelo autovetor unitário $\hat{\alpha}_j$, e o escore correspondente é

$$\hat{y}_{ij} = \hat{\alpha}_j^\top \mathbf{z}_i.$$

Proposição 14.3 (Qualidade de representação das observações). *Considere $\mathbf{z}_i \neq \mathbf{0}$ e as direções principais ortonormais $\hat{\alpha}_1, \dots, \hat{\alpha}_p$.*

Se θ_{ij} é o ângulo entre $\mathbf{z}_i$ e $\hat{\alpha}_j$, então

$$\cos^2_{ij}(\text{obs}) = \cos^2 \theta_{ij} = \frac{\hat{y}_{ij}^2}{\|\mathbf{z}_i\|^2}. \quad (14.1)$$

Para o subespaço

$$S_k = \text{span} \{ \hat{\alpha}_1, \dots, \hat{\alpha}_k \},$$

a qualidade de representação pelas primeiras k componentes satisfaz

$$\cos^2_{i,(1:k)}(\text{obs}) = \sum_{j=1}^k \cos^2_{ij}(\text{obs}) = \frac{\left\| \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2}{\|\mathbf{z}_i\|^2}. \quad (14.2)$$

Além disso,

$$\cos^2_{i,(1:k)}(\text{obs}) = 1 - \frac{\left\| \mathbf{z}_i - \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2}{\|\mathbf{z}_i\|^2}.$$

Demonstração

Pela definição de ângulo entre vetores em Definição 1.11,

$$\cos \theta_{ij} = \frac{\mathbf{z}_i^\top \hat{\alpha}_j}{\|\mathbf{z}_i\| \|\hat{\alpha}_j\|}.$$

Como

$$\|\hat{\alpha}_j\| = 1$$

e

$$\hat{y}_{ij} = \hat{\alpha}_j^\top \mathbf{z}_i,$$

segue que

$$\cos \theta_{ij} = \frac{\hat{y}_{ij}}{\|\mathbf{z}_i\|}.$$

Elevando ao quadrado,

$$\cos^2 \theta_{ij} = \frac{\hat{y}_{ij}^2}{\|\mathbf{z}_i\|^2}.$$

Pela Proposição 3.13,

$$\text{proj}_{\text{span}\{\hat{\alpha}_j\}}(\mathbf{z}_i) = \hat{y}_{ij} \hat{\alpha}_j.$$

Como as primeiras k direções formam um conjunto ortonormal, a Proposição 3.14 fornece

$$\text{proj}_{S_k}(\mathbf{z}_i) = \sum_{j=1}^k \hat{y}_{ij} \hat{\alpha}_j$$

e

$$\left\| \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2 = \sum_{j=1}^k \hat{y}_{ij}^2.$$

Dividindo por $\|\mathbf{z}_i\|^2$, obtém-se a expressão para $\cos_{i,(1:k)}^{2(\text{obs})}$.

Pela decomposição ortogonal em Teorema 3.7,

$$\|\mathbf{z}_i\|^2 = \left\| \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2 + \left\| \mathbf{z}_i - \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2.$$

A divisão por $\|\mathbf{z}_i\|^2$ fornece a última identidade.

Na ACP baseada em covariâncias,

$$\|\mathbf{z}_i\|^2 = \sum_{\ell=1}^p \hat{y}_{i\ell}^2,$$

pois a transformação completa para as coordenadas principais é ortogonal. Na ACP baseada em correlações, a mesma relação é aplicada ao vetor da observação no espaço das variáveis centralizadas e padronizadas.

O numerador de Equação 14.2 é a distância quadrática preservada pela projeção, enquanto o denominador é a distância quadrática da observação ao centro. Valores próximos de 1 correspondem a pequena distância residual no subespaço retido.

14.13.3.2 Qualidade de representação das variáveis

Considere o vetor centralizado da variável X_i e o vetor de escores da componente Y_j . A qualidade de representação pode ser formulada diretamente pela correlação entre esses dois vetores.

Proposição 14.4 (Qualidade de representação das variáveis). *Considere $s_{ii} > 0$ e uma componente com $\hat{\lambda}_j > 0$. Se ϑ_{ij} é o ângulo entre o vetor centralizado da variável X_i e o vetor de escores da componente Y_j , então*

$$r_{ij} = \widehat{\text{Corr}}(X_i, Y_j) = \cos \vartheta_{ij},$$

e

$$\cos_{ij}^{2(\text{var})} = r_{ij}^2 = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}^2}{s_{ii}}. \quad (14.3)$$

Se $\mathbf{S}$ possui posto r , então

$$\sum_{j: \hat{\lambda}_j > 0} r_{ij}^2 = 1.$$

Para $1 \leq k \leq r$,

$$\cos_{i,(1:k)}^{2(\text{var})} = \sum_{j=1}^k r_{ij}^2.$$

Essa quantidade é a norma quadrática da projeção do vetor centralizado e normalizado da variável sobre o subespaço gerado pelos primeiros k vetores de escores normalizados.

Demonstração

A interpretação da correlação como cosseno estabelecida em Equação 8.71 fornece

$$r_{ij} = \cos \vartheta_{ij}.$$

Elevando ao quadrado,

$$\cos^2(\vartheta_{ij}) = r_{ij}^2.$$

A covariância amostral entre a variável X_i e a componente Y_j satisfaz

$$\widehat{\text{Cov}}(X_i, Y_j) = \mathbf{e}_i^\top \mathbf{S} \hat{\alpha}_j = \hat{\lambda}_j \hat{\alpha}_{ij},$$

pois

$$\mathbf{S} \hat{\alpha}_j = \hat{\lambda}_j \hat{\alpha}_j.$$

Como

$$\widehat{\text{Var}}(Y_j) = \hat{\lambda}_j,$$

segue que

$$r_{ij} = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}}{\sqrt{s_{ii}} \sqrt{\hat{\lambda}_j}} = \frac{\sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}}{\sqrt{s_{ii}}}.$$

Portanto,

$$r_{ij}^2 = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}^2}{s_{ii}}.$$

Se $\mathbf{S}$ possui posto r , sua decomposição espectral fornece

$$s_{ii} = \sum_{j: \hat{\lambda}_j > 0} \hat{\lambda}_j \hat{\alpha}_{ij}^2.$$

Consequentemente,

$$\begin{aligned} \sum_{j: \hat{\lambda}_j > 0} r_{ij}^2 &= \frac{1}{s_{ii}} \sum_{j: \hat{\lambda}_j > 0} \hat{\lambda}_j \hat{\alpha}_{ij}^2 \\ &= 1. \end{aligned}$$

Para explicitar a interpretação como projeção, seja $\mathbf{x}_{c,i} \in \mathbb{R}^n$ o vetor centralizado das observações da variável X_i e defina

$$\mathbf{w}_i = \frac{\mathbf{x}_{c,i}}{\|\mathbf{x}_{c,i}\|}.$$

Para cada componente com $\hat{\lambda}_j > 0$, seja $\hat{\mathbf{y}}_j \in \mathbb{R}^n$ o vetor formado pelos escores da componente j e defina

$$\mathbf{u}_j = \frac{\hat{\mathbf{y}}_j}{\|\hat{\mathbf{y}}_j\|}.$$

Os vetores de escores de componentes distintas são ortogonais; portanto, os vetores $\mathbf{u}_j$ formam um conjunto ortonormal em $\mathbb{R}^n$. Além disso,

$$\mathbf{w}_i^\top \mathbf{u}_j = r_{ij}.$$

Pela Proposição 3.14,

$$\left\| \text{proj}_{\text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}}(\mathbf{w}_i) \right\|^2 = \sum_{j=1}^k r_{ij}^2 = \cos_{i,(1:k)}^2(\text{var}).$$

Isso estabelece a interpretação da soma dos cossenos quadrados como norma quadrática da projeção da variável normalizada sobre o subespaço gerado pelos vetores de escores considerados.

Assim, $\cos_{i,(1:k)}^2(\text{var})$ mede a parcela da variância da variável i representada pelo subespaço principal considerado.

As duas construções utilizam a mesma relação geométrica. Para as observações, o ângulo é definido em $\mathbb{R}^p$ entre o vetor centralizado e uma direção principal. Para as variáveis, o ângulo é definido em $\mathbb{R}^n$ entre o vetor centralizado da variável e o vetor de escores da componente. Em ambos os casos, o $\cos^2$ expressa uma proporção quadrática de representação.

14.13.4 Aproximação de posto reduzido

A SVD permite conectar diretamente a redução de dimensionalidade ao problema de aproximação matricial.

Para

$$1 \leq k < r,$$

mantendo apenas os k primeiros termos da SVD,

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Pelo Teorema de Eckart–Young–Mirsky de Teorema 6.2, $\mathbf{X}_{c,k}$ é uma melhor aproximação de $\mathbf{X}_c$ entre todas as matrizes de posto não superior a k , segundo a norma de Frobenius.

Se

$$d_k > d_{k+1},$$

essa melhor aproximação é única. Quando

$$d_k = d_{k+1},$$

podem existir diferentes aproximações de posto não superior a k que atingem o mesmo erro mínimo.

Além disso, pela relação entre projeção e SVD estabelecida na Proposição 6.19,

$$\mathbf{X}_{c,k} = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top.$$

Como os escores associados às primeiras k direções são

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \mathbf{V}_k,$$

também se obtém

$$\mathbf{X}_{c,k} = \widehat{\mathbf{Y}}_k \mathbf{V}_k^\top.$$

Essas três expressões representam o mesmo objeto:

$$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top = \widehat{\mathbf{Y}}_k \mathbf{V}_k^\top.$$

A primeira expressão mostra a aproximação de posto reduzido; a segunda mostra a projeção sobre o subespaço principal; a terceira mostra a reconstrução a partir dos escores amostrais e das direções principais.

O erro quadrático total da aproximação é

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Como

$$d_j^2 = (n-1)\hat{\lambda}_j,$$

segue que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 = (n-1) \sum_{j=k+1}^r \hat{\lambda}_j.$$

A parcela da soma de quadrados preservada pela aproximação é

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2} = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{j=1}^r \hat{\lambda}_j}.$$

Essa expressão coincide com a proporção de variância observada representada pelas primeiras k componentes.

A equivalência entre as formulações pode ser resumida pela Tabela 14.5.

Tabela 14.5: Formulações relacionadas da Análise de Componentes Principais.

Formulação	Objeto otimizado ou decomposto	Solução
Variância	$\alpha^\top \Sigma \alpha$ ou $\alpha^\top \mathbf{S} \alpha$	Autovetores associados aos maiores autovalores
Subespaço	Variância total da projeção em dimensão k	Subespaço gerado pelas primeiras k direções
Reconstrução	Erro quadrático da representação	Projeção sobre um subespaço principal
SVD	Matriz de dados centralizada $\mathbf{X}_c$	Vetores singulares à direita associados à variabilidade positiva
Aproximação matricial	$\ \mathbf{X}_c - \mathbf{B}\ _F$ com $\text{posto}(\mathbf{B}) \leq k$	$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$

A ACP admite três formulações relacionadas. Estatisticamente, procura direções que concentram variabilidade. Geometricamente, projeta os dados em um subespaço de menor dimensão. Matricialmente, a formulação amostral produz uma aproximação de posto reduzido da matriz centralizada (Eaton, 2007; Johnson; Wichern, 2007). As três formulações conduzem ao mesmo subespaço principal.

14.13.5 Propriedades da solução

14.13.5.1 Invariância a translações

Para qualquer vetor constante $\mathbf{c} \in \mathbb{R}^p$,

$$\mathbf{X}^* = \mathbf{X} + \mathbf{c}$$

possui a mesma matriz de covariâncias de $\mathbf{X}$:

$$\text{Cov}(\mathbf{X}^*) = \Sigma.$$

Consequentemente, os autovalores e as direções principais não se alteram. A ACP baseada em covariâncias é, portanto, invariante a translações. A centralização modifica a origem da representação, mas não sua estrutura de dispersão.

14.13.5.2 Dependência da escala

A ACP baseada em covariâncias não é, em geral, invariante a mudanças individuais de escala. Se

$$\mathbf{X}^* = \mathbf{D}\mathbf{X},$$

com $\mathbf{D}$ diagonal e positiva, então

$$\Sigma^* = \mathbf{D}\Sigma\mathbf{D}.$$

Os autovalores e autovetores de Σ^* podem diferir dos de Σ . Portanto, mudanças de unidade podem alterar a solução da ACP por covariâncias. Essa propriedade explica a distinção entre a ACP baseada em covariâncias e a ACP baseada em correlações desenvolvida na Seção [14.10](#).

14.13.5.3 Indeterminação do sinal

Se

$$\Sigma \alpha_j = \lambda_j \alpha_j,$$

então

$$\Sigma(-\alpha_j) = \lambda_j(-\alpha_j).$$

Portanto, α_j e $-\alpha_j$ representam a mesma direção principal.

Se o sinal do vetor de coeficientes for invertido,

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

passa a ser

$$Y_j^* = -Y_j.$$

Os escores também mudam de sinal, mas a variância, o subespaço gerado e a qualidade da representação permanecem inalterados.

A orientação positiva ou negativa de um eixo principal é, portanto, arbitrária.

Ao comparar resultados produzidos por diferentes programas ou decomposições numéricas, sinais opostos não caracterizam componentes diferentes. Duas soluções podem apresentar sinais opostos e ainda representar exatamente a mesma componente.

A mudança de sinal não é a única situação em que as direções podem deixar de ser únicas. Quando há autovalores repetidos, a ACP identifica o autoespaço correspondente, mas não uma base única dentro dele. Além disso, quando a matriz analisada é singular, a variabilidade está restrita a um subespaço de dimensão inferior a p . Essas duas situações são desenvolvidas a seguir.

14.13.5.4 Unicidade, multiplicidade e dimensão efetiva

Quando todos os autovalores são simples, cada direção principal é determinada até mudança de sinal. Autovalores repetidos e matrizes singulares exigem distinguir a unicidade das direções, a unicidade dos subespaços e a dimensão efetivamente ocupada pela variabilidade.

14.13.5.4.1 Multiplicidade de autovalores

Os conceitos de multiplicidade algébrica e geométrica foram definidos na Definição 5.5. Como Σ é simétrica, o Teorema 5.4 garante uma base ortonormal em cada autoespaço.

Considere

$$\lambda_j = \lambda_{j+1}.$$

Qualquer base ortonormal do autoespaço associado pode ser utilizada. Assim, os vetores

$$\alpha_j \quad \text{e} \quad \alpha_{j+1}$$

não são individualmente determinados de forma única. O objeto determinado é o autoespaço associado ao autovalor repetido.

Quando um autovalor é simples, sua direção principal é determinada até mudança de sinal. Quando há multiplicidade, diferentes rotações ortogonais dentro do autoespaço produzem conjuntos diferentes de autovetores igualmente válidos. A ACP identifica, nesse caso, o subespaço de variabilidade correspondente, e não eixos individuais únicos.

A não unicidade das bases de um autoespaço com multiplicidade foi ilustrada na Figura 5.2. Na ACP, a mesma propriedade explica a condição de unicidade apresentada na Definição 14.2 e na Proposição 14.1.

Se

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único. Se

$$\lambda_k = \lambda_{k+1},$$

o corte ocorre dentro de um autoespaço associado a um autovalor repetido. Nesse caso, diferentes subespaços de dimensão k podem preservar a mesma variabilidade máxima.

Mesmo sem igualdade exata, autovalores muito próximos podem tornar os autovetores individuais mais sensíveis a pequenas perturbações da matriz analisada. Nessa situação, a interpretação conjunta do subespaço pode ser mais estável do que a interpretação de cada direção isoladamente.

14.13.5.4.2 Singularidade e dimensão efetiva

A Proposição 8.3 relaciona a singularidade da matriz de covariâncias à existência de combinações lineares com variância zero.

Se

$$\text{posto}(\Sigma) = r < p,$$

então exatamente r autovalores são positivos:

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

enquanto

$$\lambda_{r+1} = \dots = \lambda_p = 0.$$

A variabilidade populacional está inteiramente contida em um subespaço de dimensão r . As componentes associadas aos autovalores nulos possuem variância zero e não acrescentam novas direções de variabilidade. Assim, a passagem de p para r dimensões pode ser realizada sem perda de variância.

No nível amostral, a centralização implica

$$\text{posto}(\mathbf{X}_c) \leq n - 1$$

e, conseqüentemente,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Quando

$$p \geq n,$$

a matriz de covariâncias amostral é necessariamente singular, ainda que a matriz populacional não seja. A SVD representa diretamente o subespaço de variabilidade observado e continua aplicável sem exigir a inversão de $\mathbf{S}$.

14.13.6 Estimação e inferência das componentes sob normalidade

A formulação da ACP não exige normalidade multivariada. Os resultados desta seção referem-se à ACP populacional baseada na matriz de covariâncias. A hipótese normal passa a ter função específica quando os autovalores e as direções principais são tratados como parâmetros de uma população e se deseja estudar sua estimação ou sua distribuição amostral.

Considere uma amostra aleatória da distribuição normal multivariada definida na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

A Proposição 10.3 fornece o estimador de máxima verossimilhança de Σ no evento amostral em que o máximo existe. Isso exige $\text{posto}(\mathbf{S}) = p$; sob o modelo normal não singular, essa condição ocorre quase certamente quando $n \geq p + 1$. Com a convenção amostral utilizada neste capítulo, a Equação 10.72 fornece

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Considere a decomposição espectral da matriz de covariâncias amostral,

$$\mathbf{S} = \widehat{\mathbf{A}} \widehat{\Lambda} \widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\Lambda} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p).$$

Como $\widehat{\Sigma}_{\text{MV}}$ é um múltiplo positivo de $\mathbf{S}$,

$$\widehat{\Sigma}_{\text{MV}} = \widehat{\mathbf{A}} \left(\frac{n-1}{n} \widehat{\Lambda} \right) \widehat{\mathbf{A}}^\top.$$

As duas matrizes possuem, portanto, os mesmos autovetores. Seus autovalores diferem pelo fator

$$\frac{n-1}{n}.$$

Com a notação adotada neste capítulo,

$$\hat{\lambda}_{j,\text{MV}} = \frac{n-1}{n} \hat{\lambda}_j.$$

Nessas condições de existência e quando os autovalores populacionais são distintos, $\hat{\alpha}_j$, com uma convenção de sinal, e $\hat{\lambda}_{j,\text{MV}}$ são os estimadores de máxima verossimilhança da direção principal e de sua variância, respectivamente (Anderson, 2003).

A diferença entre os divisores n e $n-1$ não altera os eixos da ACP. Ela também não altera a proporção de variância associada a cada componente, pois

$$\frac{\hat{\lambda}_{j,\text{MV}}}{\sum_{\ell=1}^p \hat{\lambda}_{\ell,\text{MV}}} = \frac{\hat{\lambda}_j}{\sum_{\ell=1}^p \hat{\lambda}_\ell}.$$

A escolha do divisor modifica a escala dos autovalores, mas preserva as direções, os escores definidos a partir dessas direções e as proporções de variância.

A variabilidade amostral dos autovalores e autovetores pode ser estudada assintoticamente. Sob normalidade multivariada e autovalores populacionais distintos e positivos, para dimensão p fixa,

$$\sqrt{n} (\hat{\lambda}_j - \lambda_j) \xrightarrow{d} N(0, 2\lambda_j^2).$$

Para estudar uma direção individual, fixe o sinal de $\hat{\alpha}_j$ de modo que

$$\hat{\alpha}_j^\top \alpha_j > 0.$$

Então,

$$\sqrt{n} (\hat{\alpha}_j - \alpha_j) \xrightarrow{d} N_p(\mathbf{0}, \Gamma_j),$$

com

$$\Gamma_j = \sum_{\ell \neq j} \frac{\lambda_j \lambda_\ell}{(\lambda_j - \lambda_\ell)^2} \alpha_\ell \alpha_\ell^\top$$

(Anderson, 2003; Johnson; Wichern, 2007).

A expressão de Γ_j mostra o efeito da separação entre autovalores. Quando λ_j e λ_ℓ se aproximam, o denominador diminui e a variabilidade da direção estimada aumenta. Esse resultado formaliza a sensibilidade das direções individuais discutida na Seção [14.13.5.4](#).

As distribuições acima pressupõem autovalores distintos. Quando há multiplicidade, os autovetores individuais não constituem parâmetros únicos, e a inferência deve ser formulada em termos do autoespaço correspondente.

14.14 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne critérios e objetos utilizados na condução e na interpretação da ACP, incluindo a escolha do número de componentes, a relação das variáveis com as componentes, a representação das observações e das variáveis e a utilização de elementos suplementares.

14.14.1 Escolha do número de componentes

Tanto na ACP baseada em covariâncias quanto na baseada em correlações, a decomposição espectral produz até p componentes. A redução de dimensionalidade exige decidir quantas delas serão mantidas. Não existe uma resposta única determinada pela solução matemática da ACP: a decisão deve considerar o objetivo da representação, a parcela de variabilidade preservada, os tamanhos relativos dos autovalores e a interpretação das componentes (Johnson; Wichern, 2007).

Na aplicação amostral, denote por

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0$$

os autovalores da matriz observada utilizada na ACP. A proporção acumulada observada é

$$\hat{\Pi}_k = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{\ell=1}^p \hat{\lambda}_\ell}.$$

Essa quantidade descreve a parcela da variabilidade observada representada pelas primeiras k componentes. Valores elevados de $\hat{\Pi}_k$ indicam que poucas dimensões concentram grande parte da variabilidade, mas não existe uma proporção mínima universal que determine, por si só, quantas componentes devem ser retidas.

Outra informação é fornecida pelo gráfico dos autovalores, usualmente denominado **gráfico de declive** (*scree plot*). Os autovalores são apresentados em ordem decrescente e procura-se identificar uma mudança no padrão de queda. Quando existe um declínio inicial acentuado seguido por uma sequência relativamente mais estável de valores pequenos, essa mudança

pode indicar uma dimensão a partir da qual componentes adicionais acrescentam parcelas progressivamente menores da variabilidade.

A Figura 14.5 ilustra esse comportamento. A linha horizontal também permite comparar, no mesmo exemplo, o gráfico de declive com a referência $\lambda = 1$ utilizada na ACP baseada em correlações.




Figura 14.5: Gráfico de declive dos autovalores. A linha tracejada indica a referência autovalor igual a 1 para uma ACP baseada em correlações.

No exemplo, os cinco autovalores somam 5, como ocorre para uma matriz de correlações de ordem 5. A queda é mais acentuada nas primeiras componentes e se torna progressivamente menor a partir das seguintes. A linha tracejada representa outro critério: apenas os dois primeiros autovalores excedem 1. A mudança de inclinação e a comparação com 1 fornecem, portanto, informações distintas.

Na ACP baseada na matriz de correlações, há ainda uma referência específica decorrente da padronização. Como

$$\text{tr}(\mathbf{R}) = p,$$

a média dos p autovalores é igual a 1. Nesse contexto, o critério de reter componentes com

$$\hat{\lambda}_{Rj} > 1$$

pode ser interpretado como a retenção de componentes cuja variância excede a variância de uma variável original padronizada. Esse critério é uma regra heurística e sua justificativa não se transfere diretamente para a ACP baseada em uma matriz de covariâncias, cujas variâncias dependem das escalas das variáveis.

Assim, a escolha de k deve considerar conjuntamente a concentração dos autovalores, a proporção acumulada de variância, o padrão observado no gráfico de declive e a interpretabilidade da representação obtida. Diferentes critérios podem sugerir dimensões distintas, e a decisão deve permanecer vinculada ao objetivo da análise (Jolliffe, 2002).

A proporção acumulada e o gráfico de declive podem ser utilizados tanto na ACP baseada em covariâncias quanto na baseada em correlações, enquanto o critério do autovalor maior que 1 possui justificativa específica para a matriz de correlações. Mesmo nesse caso, trata-se de uma regra heurística, e não de uma condição necessária para retenção: uma componente com autovalor inferior a 1 pode ainda ser relevante para a representação ou para a interpretação do problema (Johnson; Wichern, 2007).

Os autovalores pequenos também possuem informação diagnóstica. Valores muito próximos de zero, especialmente entre as últimas componentes, podem indicar dependências lineares ou quase lineares entre as variáveis. Por isso, componentes associadas a autovalores muito pequenos não devem ser descartadas automaticamente sem que a estrutura correspondente seja examinada (Johnson; Wichern, 2007).

14.14.2 Coeficientes e relação das variáveis com as componentes

Os elementos do vetor

$$\alpha_j = \begin{pmatrix} \alpha_{1j} \\ \vdots \\ \alpha_{pj} \end{pmatrix}$$

são os **coeficientes da j -ésima componente principal**. Eles definem a combinação linear

$$Y_j = \sum_{i=1}^p \alpha_{ij} (X_i - \mu_i).$$

Esses coeficientes determinam a direção da componente no espaço das variáveis. Eles não devem ser confundidos com as correlações entre as variáveis originais e a componente.

A relação entre esses dois objetos pode ser obtida diretamente a partir da matriz de covariâncias.

Para a variável X_i ,

$$\begin{aligned}\text{Cov}(X_i, Y_j) &= \text{Cov}[X_i, \alpha_j^\top (\mathbf{X} - \mu)] \\ &= \sum_{\ell=1}^p \alpha_{\ell j} \text{Cov}(X_i, X_\ell) \\ &= (\Sigma \alpha_j)_i.\end{aligned}$$

Como

$$\Sigma \alpha_j = \lambda_j \alpha_j,$$

segue que

$$\text{Cov}(X_i, Y_j) = \lambda_j \alpha_{ij}.$$

Além disso,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Var}(X_i) = \sigma_{ii}.$$

Se

$$\sigma_{ii} > 0$$

e

$$\lambda_j > 0,$$

então a correlação está definida e

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} \alpha_{ij}}{\sqrt{\sigma_{ii}}}.$$

Proposição 14.5 (Correlação entre uma variável e uma componente principal). *Considere a ACP populacional baseada na matriz de covariâncias Σ . Para uma variável X_i com*

$$\sigma_{ii} > 0$$

e uma componente principal

$$Y_j = \alpha_j^\top (\mathbf{X} - \mu)$$

associada a um autovalor

$$\lambda_j > 0,$$

tem-se

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} \alpha_{ij}}{\sqrt{\sigma_{ii}}}.$$

Na ACP populacional baseada na matriz de correlações $\mathcal{R}$, suponha que as variâncias marginais sejam positivas, como exigido na Definição 8.5. Considere a variável padronizada $X_{i,\text{pad}}$ e uma componente

$$Y_{Rj}$$

construída a partir do autovetor α_{Rj} associado a

$$\lambda_{Rj} > 0.$$

Como

$$\text{Var}(X_{i,\text{pad}}) = 1,$$

tem-se

$$\text{Corr}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\lambda_{Rj}} \alpha_{R,ij}.$$

A exigência de autovalor positivo decorre da própria definição de correlação. Se

$$\lambda_j = 0,$$

então

$$\text{Var}(Y_j) = 0,$$

e a correlação entre Y_j e qualquer variável não está definida.

A expressão mostra que o coeficiente α_{ij} e a correlação entre X_i e Y_j representam objetos diferentes.

A diferença entre os coeficientes da componente e as correlações com as variáveis pode ser visualizada na Figura 14.6. O exemplo utiliza uma matriz de covariâncias com variâncias marginais diferentes.




Figura 14.6: Os coeficientes definem a direção da componente, enquanto as correlações medem a associação de cada variável com a componente.

Os coeficientes pertencem ao vetor unitário que define a direção principal. As correlações dependem também da variância da componente e da variância de cada variável. Por isso, as duas medidas não são intercambiáveis.

Os coeficientes devem ser interpretados como elementos da combinação linear que define conjuntamente a direção principal, enquanto as correlações descrevem a associação linear de cada variável, considerada individualmente, com a componente construída. Na ACP baseada em covariâncias, essas correlações também incorporam as diferenças entre as variâncias marginais das variáveis. Por isso, coeficientes e correlações fornecem informações complementares e podem ser examinados conjuntamente na interpretação das componentes (Johnson; Wichern, 2007).

Na Capítulo 15, as cargas fatoriais pertencem ao próprio modelo de covariâncias e têm interpretação diferente dos coeficientes de uma componente principal.

Na formulação amostral baseada em $\mathbf{S}$, se

$$s_{ii} > 0$$

e

$$\hat{\lambda}_j > 0,$$

então

$$\widehat{\text{Corr}}(X_i, Y_j) = \frac{\sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}}{\sqrt{s_{ii}}}.$$

Quando a ACP é realizada sobre $\mathbf{R}$, cada variável padronizada possui variância observada igual a 1. Para uma componente com

$$\hat{\lambda}_{Rj} > 0,$$

denotando por $X_{i,\text{pad}}$ a variável padronizada e por Y_{Rj} a componente correspondente,

$$\widehat{\text{Corr}}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\hat{\lambda}_{Rj}} \hat{\alpha}_{R,ij}.$$

A interpretação das componentes pode utilizar conjuntamente os coeficientes e as associações das variáveis com as componentes. A formulação matemática deve preservar a distinção entre os dois objetos.

14.14.3 Representação das observações e das variáveis

A representação das observações utiliza os escores das componentes. Para as variáveis, é necessário distinguir as coordenadas associadas aos eixos principais das correlações com as componentes desenvolvidas na Seção 14.14.2.

14.14.3.1 Observações: coordenadas, qualidade de representação e contribuição

Para a observação i , a coordenada na componente j é o próprio escore

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Assim, em uma representação pelas duas primeiras componentes, a observação i é localizada pelo ponto

$$(\hat{y}_{i1}, \hat{y}_{i2}).$$

O escore fornece a coordenada da observação ao longo da direção principal. Seu sinal indica o lado do eixo e seu módulo indica o afastamento da origem nessa direção.

A Proposição 14.3 estabelece a interpretação geométrica dessa qualidade. Pela Equação 14.1, para a componente j ,

$$\cos_{ij}^{2(\text{obs})} = \frac{\hat{y}_{ij}^2}{\sum_{\ell=1}^p \hat{y}_{i\ell}^2}.$$

Para as primeiras k componentes,

$$\cos_{i,(1:k)}^{2(\text{obs})} = \sum_{j=1}^k \cos_{ij}^{2(\text{obs})}.$$

Valores próximos de 1 indicam que o subespaço retido representa bem a posição da observação em relação ao centro.

Para uma componente com $\hat{\lambda}_j > 0$ e pesos iguais para as observações, a **contribuição** da observação i para a componente j é

$$\text{ctr}_{ij}^{(\text{obs})} = \frac{\hat{y}_{ij}^2}{\sum_{h=1}^n \hat{y}_{hj}^2}. \quad (14.4)$$

Portanto,

$$\sum_{i=1}^n \text{ctr}_{ij}^{(\text{obs})} = 1.$$

Na convenção amostral utilizada neste capítulo,

$$\sum_{h=1}^n \hat{y}_{hj}^2 = (n-1)\hat{\lambda}_j,$$

e

$$\text{ctr}_{ij}^{(\text{obs})} = \frac{\hat{y}_{ij}^2}{(n-1)\hat{\lambda}_j}.$$

Uma contribuição elevada indica que a observação responde por uma parcela elevada da soma de quadrados associada à componente.

As duas medidas respondem a perguntas diferentes. O $\cos^2$ avalia quanto a componente representa a observação. A contribuição avalia quanto a observação participa da variabilidade associada à componente.

14.14.3.2 Variáveis: coordenadas, qualidade de representação e contribuição

A Seção 14.14.2 mostrou que os coeficientes que definem uma direção principal e as correlações das variáveis com as componentes são objetos distintos. A representação das variáveis também exige distinguir essas correlações das coordenadas associadas aos eixos principais.

Considere primeiro a ACP baseada em $\mathbf{S}$. Para a variável i e a componente j , a coordenada adotada neste capítulo é

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}.$$

Pela relação desenvolvida na Seção 14.14.2,

$$r_{ij} = \widehat{\text{Corr}}(X_i, Y_j) = \frac{c_{ij}}{\sqrt{s_{ii}}},$$

quando $s_{ii} > 0$.

A coordenada c_{ij} e a correlação r_{ij} coincidem apenas quando a variável considerada possui variância unitária. Esse é o caso da ACP aplicada às variáveis padronizadas.

Na ACP baseada em $\mathbf{R}$,

$$c_{R,ij} = \sqrt{\hat{\lambda}_{Rj}} \hat{\alpha}_{R,ij}$$

e, como cada variável padronizada possui variância igual a 1,

$$c_{R,ij} = r_{R,ij}.$$

A Proposição 14.4 estabelece a interpretação geométrica dessa qualidade. Pela Equação 14.3, para uma componente com $\hat{\lambda}_j > 0$,

$$\cos_{ij}^{2(\text{var})} = r_{ij}^2.$$

Para as primeiras k componentes,

$$\cos_{i,(1:k)}^{2(\text{var})} = \sum_{j=1}^k r_{ij}^2.$$

Valores próximos de 1 indicam que a variância da variável está bem representada pelo subespaço considerado.

Para uma componente com $\hat{\lambda}_j > 0$ e pesos iguais para as variáveis, a contribuição da variável i para a componente j pode ser escrita como

$$\text{ctr}_{ij}^{(\text{var})} = \frac{c_{ij}^2}{\hat{\lambda}_j}. \quad (14.5)$$

Como

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij},$$

segue que

$$\text{ctr}_{ij}^{(\text{var})} = \hat{\alpha}_{ij}^2.$$

Portanto,

$$\sum_{i=1}^p \text{ctr}_{ij}^{(\text{var})} = 1.$$

Na ACP baseada em correlações, para uma componente com $\hat{\lambda}_{Rj} > 0$,

$$c_{R,ij} = r_{R,ij},$$

e a contribuição também pode ser escrita como

$$\text{ctr}_{ij}^{(\text{var})} = \frac{r_{R,ij}^2}{\hat{\lambda}_{Rj}}.$$

A coordenada localiza a variável na geometria associada às componentes. O $\cos^2$ mede sua qualidade de representação. A contribuição mede sua participação na construção da componente.

14.14.3.3 Duas representações complementares

A ACP permite examinar dois espaços relacionados e distintos. A geometria dos respectivos cossenos quadrados foi desenvolvida na Seção 14.13.3. Nesta seção, essas medidas são utilizadas para avaliar a qualidade das representações produzidas pelos mapas.

No **mapa das observações**, os pontos são posicionados pelos escores. A distância entre os pontos descreve a proximidade no subespaço representado, segundo a geometria das variáveis originais na ACP baseada em covariâncias e das variáveis padronizadas na ACP baseada em correlações. A qualidade da representação de cada observação é avaliada pelos respectivos $\cos^2$.

No **mapa das variáveis**, duas representações devem ser distinguidas. As coordenadas c_{ij} descrevem a posição das variáveis na geometria associada às componentes. As correlações r_{ij} colocam todas as variáveis em uma escala comum.

Quando o mapa é construído pelas correlações, os pontos

$$(r_{i1}, r_{i2})$$

estão contidos no círculo unitário, pois

$$r_{i1}^2 + r_{i2}^2 \leq 1.$$

Na ACP baseada em correlações, as coordenadas $c_{R,ij}$ coincidem com as correlações $r_{R,ij}$. Nesse caso, o mapa das variáveis e o círculo de correlações utilizam as mesmas coordenadas.

O círculo de correlações permite identificar quais variáveis estão mais associadas a cada dimensão e quais são bem representadas pelo plano considerado.

Coordenada, qualidade de representação e contribuição devem permanecer conceitualmente separadas:

- a **coordenada** informa onde a observação ou variável se encontra na representação;
- o $\cos^2$ informa quão bem ela é representada pela dimensão ou pelo subespaço;
- a **contribuição** informa quanto ela participa da construção da variabilidade representada por uma dimensão.

Essas medidas complementam a interpretação dos autovalores. Os autovalores descrevem a importância global das componentes. Coordenadas, $\cos^2$ e contribuições permitem examinar quais observações e variáveis caracterizam a representação obtida.

14.14.4 Elementos ativos e suplementares na ACP

A formulação desenvolvida até aqui utilizou todas as variáveis selecionadas para construir a matriz de covariâncias ou de correlações e, a partir dela, determinar autovalores, autovetores e componentes principais. Esses elementos podem ser denominados **ativos**, pois participam diretamente da determinação da solução.

Uma vez construído o espaço principal, outros elementos podem ser relacionados a essa representação sem participar da determinação das direções principais. Esses elementos são denominados **suplementares**.

A distinção entre elementos ativos e suplementares está, portanto, no papel que desempenham na análise: os elementos ativos participam da construção da solução, enquanto os elementos suplementares são projetados ou relacionados à solução já construída.

14.14.4.1 Observações suplementares

Considere uma nova observação

$$\mathbf{x}_* \in \mathbb{R}^p$$

que não tenha participado do cálculo da matriz de covariâncias e das direções principais. Mantendo a solução obtida a partir das observações ativas, sua coordenada na componente j pode ser calculada por

$$\hat{y}_{*j} = \hat{\alpha}_j^\top (\mathbf{x}_* - \bar{\mathbf{x}}). \quad (14.6)$$

A observação é, portanto, projetada sobre direções já determinadas. Ela recebe coordenadas no espaço principal, mas não modifica

$$\hat{\lambda}_j \quad \text{nem} \quad \hat{\alpha}_j.$$

Quando a ACP é realizada sobre variáveis padronizadas, a observação suplementar deve ser centralizada e padronizada utilizando as médias e os desvios-padrão empregados na construção da solução, e não parâmetros recalculados a partir da nova observação.

Essa construção utiliza a projeção sobre um subespaço com base ortonormal desenvolvida na Proposição 3.14. Uma vez definida a base do espaço principal, outros vetores podem ser representados nessa base sem que ela precise ser novamente estimada.

14.14.4.2 Variáveis quantitativas suplementares

Uma variável quantitativa suplementar não participa da matriz utilizada para determinar as componentes principais. Depois que os escores das observações ativas são obtidos, sua relação com cada componente pode ser avaliada pela correlação

$$r_{*j} = \widehat{\text{Corr}}(X_*, Y_j),$$

desde que a variável suplementar apresente variância observada positiva.

O valor r_{*j} descreve a associação linear da variável suplementar com a componente j . Seu quadrado,

$$r_{*j}^2,$$

mede a qualidade de representação da variável suplementar nessa dimensão.

Uma associação elevada auxilia a interpretação da componente, mas não atribui à variável suplementar participação na construção do eixo. As direções principais permanecem determinadas exclusivamente pelas variáveis ativas.

14.14.4.3 Variáveis categóricas suplementares

Uma variável categórica não integra diretamente a matriz de covariâncias ou de correlações da ACP clássica desenvolvida neste capítulo. Depois que as componentes são obtidas, suas categorias podem ser relacionadas à posição das observações no espaço principal.

Considere uma categoria g formada pelo conjunto I_g de n_g observações ativas. Com pesos iguais, sua coordenada na componente j é o baricentro dos escores das observações pertencentes à categoria,

$$\bar{y}_{gj} = \frac{1}{n_g} \sum_{i \in I_g} \hat{y}_{ij}.$$

Em uma representação pelas duas primeiras componentes, a categoria é localizada pelo ponto

$$(\bar{y}_{g1}, \bar{y}_{g2}).$$

Essa posição descreve onde se encontra, em média, o conjunto de observações pertencentes à categoria. Categorias localizadas em regiões distintas podem auxiliar a interpretação da configuração observada.

As coordenadas das categorias são calculadas depois da construção dos eixos. Elas não alteram os autovalores, os autovetores ou os escores das observações ativas.

Os elementos suplementares preservam a separação entre a construção das componentes e a interpretação posterior da solução.

14.14.5 Correspondência com a implementação utilizada

Nas atividades computacionais, a ACP será realizada pelo módulo [MEDA](#) (Leblay et al., 2026) do [jamovi](#) (The jamovi project, 2026). O MEDA utiliza procedimentos do pacote [FactoMineR](#) (Lê; Josse; Husson, 2008) e permite definir variáveis quantitativas ativas, variáveis quantitativas suplementares e variáveis categóricas suplementares.

A opção *Scale to unit variance* controla a padronização das variáveis quantitativas ativas. Quando ela está ativada, a solução corresponde à ACP baseada na matriz de correlações desenvolvida na Seção 14.10. Quando está desativada, as diferenças de escala entre as variáveis permanecem na análise e a solução corresponde à formulação baseada em covariâncias.

Há uma diferença de convenção na ACP sem padronização. Neste capítulo,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Com pesos iguais para as observações, o [FactoMineR](#) utiliza a matriz

$$\mathbf{S}_{\text{FM}} = \frac{1}{n} \mathbf{X}_c^\top \mathbf{X}_c.$$

Assim,

$$\mathbf{S}_{\text{FM}} = \frac{n-1}{n} \mathbf{S}$$

e seus autovalores satisfazem

$$\hat{\lambda}_{j,\text{FM}} = \frac{n-1}{n} \hat{\lambda}_j.$$

Essa mudança de escala não altera os autovetores nem as proporções de variância. As coordenadas das variáveis que dependem de $\sqrt{\hat{\lambda}_j}$ mudam pelo fator correspondente, enquanto correlações, $\cos^2$ e contribuições permanecem invariantes. Na ACP padronizada, a normalização conduz à mesma matriz de correlações $\mathbf{R}$ definida neste capítulo.

Para as observações, as coordenadas correspondem aos escores das componentes. Os $\cos^2$ medem a qualidade de representação e as contribuições medem a participação de cada observação na componente. As fórmulas deste capítulo expressam as contribuições como proporções que somam 1; a implementação as apresenta em porcentagem, multiplicadas por 100.

Para as variáveis ativas, o **FactoMineR** distingue coordenadas, correlações com as componentes, $\cos^2$ e contribuições. Quando *Scale to unit variance* está ativada, as coordenadas das variáveis coincidem com suas correlações com as componentes. Sem padronização, esses dois objetos são distintos, conforme discutido na Seção 14.14.3.

As variáveis e observações suplementares são relacionadas à solução depois que os eixos principais são determinados. Elas recebem coordenadas e medidas de representação sem participar da estimação das direções principais.

A padronização para variância unitária é a configuração inicial do **MEDA**. Sua utilização deve ser definida a partir das escalas das variáveis e do objetivo da análise. A configuração padrão do programa não determina essa escolha.

14.15 Síntese

A Análise de Componentes Principais representa a variabilidade multivariada por meio de direções ortonormais ordenadas segundo a variância associada a cada uma delas. Para o vetor centralizado $\mathbf{X}_c$,

$$Y_j = \alpha_j^\top \mathbf{X}_c, \quad \text{Var}(Y_j) = \lambda_j,$$

em que α_j é um autovetor unitário de Σ associado ao autovalor λ_j . Como as direções principais podem ser escolhidas ortonormais, componentes principais distintas são não correlacionadas.

A redução de dimensionalidade mantém as primeiras k direções. O subespaço gerado por essas direções maximiza a variabilidade da projeção e minimiza o erro quadrático de reconstrução entre os subespaços de mesma dimensão. Na formulação amostral, a SVD da matriz de dados centralizada fornece a mesma estrutura de subespaços e permite construir diretamente os escores das observações.

A matriz utilizada define a geometria da análise. A ACP baseada em $\mathbf{S}$ preserva as escalas e variâncias originais. A ACP baseada em $\mathbf{R}$ utiliza variáveis padronizadas e atribui variância unitária a cada uma delas.

A escolha do número de componentes não é determinada por um único critério. Autovalores, proporção acumulada de variância, gráfico de declive e interpretação das componentes fornecem informações complementares para decidir a dimensão da representação.

Os escores fornecem as coordenadas das observações no espaço principal. Para as variáveis, coeficientes, coordenadas e correlações com as componentes possuem funções distintas. Os $\cos^2$ medem qualidade de representação e as contribuições indicam a participação de observações ou variáveis em cada dimensão. Elementos suplementares podem ser projetados ou relacionados à solução depois da determinação dos eixos, sem modificar as componentes principais.

A formulação descritiva parte da matriz de dados observada e não exige normalidade multivariada. A formulação populacional baseada em covariâncias requer momentos de segunda ordem finitos; a formulação baseada em correlações requer também variâncias marginais positivas. Sob hipóteses probabilísticas adicionais, a estrutura espectral populacional pode ser tratada como objeto de estimação e inferência.

Na Capítulo 15, o objeto de interesse muda. A Análise Fatorial procura representar a estrutura comum de covariâncias por meio de fatores latentes e separa essa parcela da variabilidade específica de cada variável.

15 Formulação da Análise Fatorial

A Análise Fatorial representa a estrutura de covariâncias entre variáveis observadas por meio de um número menor de variáveis latentes, denominadas **fatores comuns**. No modelo ortogonal, as covariâncias entre variáveis distintas são atribuídas aos fatores comuns, enquanto a variância de cada variável é decomposta em uma parcela comum e uma parcela específica (Johnson; Wichern, 2007).

Diferentemente da ACP formulada no Capítulo 14, que constrói combinações lineares para representar a variabilidade total, a Análise Fatorial especifica um modelo para a estrutura de covariâncias. No modelo ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi,$$

em que $\Phi\Phi^\top$ representa a parcela comum da covariância e Ψ representa a variabilidade específica.

A formulação utiliza a matriz de covariâncias populacional definida na Definição 8.2, a noção de posto na Definição 2.14 e, no aprofundamento probabilístico, a distribuição normal multivariada da Definição 9.1. O núcleo desenvolve o modelo de fatores comuns, as cargas, as comunicações, a identificação em visão conceitual, a rotação, as formulações populacional e amostral, os escores fatoriais, os pressupostos e a distinção em relação à ACP. Os aprofundamentos tratam da identificação formal, da formulação normal e das decisões metodológicas associadas à Análise Fatorial Exploratória.

Neste capítulo, a matriz de cargas fatoriais será denotada por $\Phi = (\phi_{ij})$, seguindo a notação adotada por Artes e Barroso (Artes; Barroso, 2023).

15.1 O problema da estrutura latente

Considere o vetor aleatório

$$\mathbf{x} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p,$$

com segundos momentos finitos, vetor de médias

$$\mu = E(\mathbf{X})$$

e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Os elementos fora da diagonal de Σ registram as covariâncias entre pares de variáveis e, portanto, sua associação linear. Na Análise Fatorial, essa estrutura é representada a partir de uma hipótese: parte das covariâncias entre as variáveis observadas é atribuída à influência conjunta de um número menor de fatores não diretamente observados.

Considere

$$\mathbf{F} = \begin{pmatrix} F_1 \\ \vdots \\ F_m \end{pmatrix} \in \mathbb{R}^m,$$

com

$$1 \leq m < p$$

na formulação de baixa dimensão adotada neste capítulo.

As componentes de $\mathbf{F}$ são variáveis aleatórias latentes. Elas não correspondem a colunas observadas da matriz de dados. Sua existência é postulada pelo modelo para representar a estrutura de covariâncias entre as variáveis observadas.

A Análise Fatorial utiliza uma representação de menor dimensão diferente daquela construída pela ACP. As variáveis observadas são modeladas por fatores latentes comuns e por parcelas específicas.

Os fatores comuns representam a parcela compartilhada da estrutura de covariâncias. Os fatores específicos representam a variabilidade de cada variável que não é atribuída aos fatores comuns. As condições que definem essa decomposição serão estabelecidas no modelo ortogonal.

15.2 Formulação do modelo de fatores comuns

O modelo básico representa o vetor observado como a soma de três parcelas:

1. localização média;
2. contribuição dos fatores comuns;
3. contribuição específica.

Definição 15.1 (Modelo de fatores comuns). Considere um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos e vetor de médias

$$\mu = E(\mathbf{X}).$$

Sejam

$$\mathbf{F} \in \mathbb{R}^m$$

um vetor aleatório de fatores comuns e

$$\varepsilon \in \mathbb{R}^p$$

um vetor aleatório de fatores específicos, ambos com segundos momentos finitos e satisfazendo

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo de fatores comuns é

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon, \tag{15.1}$$

em que

$$\Phi \in \mathbb{R}^{p \times m}$$

é a matriz de cargas fatoriais.

Os elementos do modelo são organizados na Tabela [15.1](#).

Tabela 15.1: Elementos do modelo de fatores comuns.

Objeto	Dimensão	Função no modelo
$\mathbf{X}$	$p \times 1$	Vetor de variáveis observadas
μ	$p \times 1$	Vetor de médias
$\mathbf{F}$	$m \times 1$	Vetor de fatores comuns latentes
Φ	$p \times m$	Matriz de cargas fatoriais
ε	$p \times 1$	Vetor de fatores específicos
Ψ	$p \times p$	Matriz de covariâncias dos fatores específicos no modelo ortogonal

A i -ésima variável pode ser escrita como

$$X_i = \mu_i + \phi_{i1}F_1 + \phi_{i2}F_2 + \cdots + \phi_{im}F_m + \varepsilon_i. \quad (15.2)$$

A linha i da matriz de cargas será denotada por

$$\phi_i^\top = (\phi_{i1} \quad \cdots \quad \phi_{im}).$$

A coluna j será denotada por

$$\phi_{\cdot j} = \begin{pmatrix} \phi_{1j} \\ \vdots \\ \phi_{pj} \end{pmatrix} \in \mathbb{R}^p.$$

Assim,

$$X_i - \mu_i = \phi_i^\top \mathbf{F} + \varepsilon_i.$$

A carga ϕ_{ij} representa o coeficiente associado ao fator F_j na expressão linear da variável X_i . Sua interpretação depende da escala dos fatores, da escala das variáveis e da parametrização utilizada.

A Figura 15.1 representa a estrutura de um modelo com dois fatores e três variáveis observadas. As setas azuis representam as contribuições dos fatores comuns e as setas vermelhas representam os fatores específicos.




Figura 15.1: Estrutura do modelo de fatores comuns: as variáveis observadas recebem contribuições dos fatores comuns e dos fatores específicos.

A figura mostra a estrutura linear postulada pelo modelo. Sob as hipóteses do modelo ortogonal estabelecidas a seguir, as covariâncias entre variáveis distintas são atribuídas à parcela comum, enquanto os fatores específicos não acrescentam covariâncias entre variáveis distintas.

15.3 Hipóteses do modelo ortogonal

A expressão na Equação 15.1 ainda não determina a estrutura de covariâncias. Para isso, são estabelecidas condições sobre os fatores comuns e os fatores específicos.

Na parametrização ortogonal adotada neste capítulo, os fatores comuns são centralizados, possuem variância unitária e são mutuamente não correlacionados:

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m.$$

Os fatores específicos satisfazem

$$E(\varepsilon) = \mathbf{0}$$

e

$$\text{Cov}(\varepsilon) = \Psi,$$

com

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0.$$

Além disso,

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Essas condições são reunidas na definição a seguir.

Definição 15.2 (Modelo fatorial ortogonal). Considere o modelo de fatores comuns da Definição 15.1, com

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo é denominado **fatorial ortogonal** quando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, atribui variância unitária a cada fator e estabelece covariâncias nulas entre fatores distintos. A ortogonalidade, nesse contexto, refere-se à estrutura de covariâncias dos fatores.

Essa padronização se refere aos **fatores latentes** e não implica que as variáveis observadas tenham variância unitária. A padronização das variáveis observadas ocorre quando o modelo é formulado a partir da matriz de correlações.

A diagonalidade de Ψ estabelece

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \forall i \neq j.$$

Consequentemente, a parcela específica do modelo não acrescenta covariância entre variáveis distintas.

A diagonalidade de Ψ estabelece **não correlação** entre fatores específicos distintos, mas não implica sua independência sem hipóteses probabilísticas adicionais. No modelo fatorial normal

da Definição 15.7, a normalidade conjunta de ε , combinada com a diagonalidade de Ψ , permite concluir pela independência de seus componentes utilizando a Proposição 9.6.

A condição

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}$$

separa, em termos de covariância, a parcela comum da parcela específica.

Essas hipóteses são suficientes para obter a estrutura de segunda ordem do modelo fatorial ortogonal. A normalidade multivariada não é necessária para essa formulação. Seu papel é retomado na seção sobre pressupostos e desenvolvido na Seção 15.14.5.

15.4 Estrutura da matriz de covariâncias

De Equação 15.1,

$$\mathbf{X} - \mu = \Phi \mathbf{F} + \varepsilon.$$

Pelas condições de média do modelo,

$$E(\mathbf{X}) = \mu.$$

Para a matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\Phi \mathbf{F} + \varepsilon) \\ &= \Phi \text{Cov}(\mathbf{F}) \Phi^\top + \text{Cov}(\varepsilon) \\ &\quad + \Phi \text{Cov}(\mathbf{F}, \varepsilon) + \text{Cov}(\varepsilon, \mathbf{F}) \Phi^\top. \end{aligned}$$

A regra de transformação da covariância utilizada nessa expressão foi estabelecida na Proposição 8.6.

Pelas hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Portanto,

$$\Sigma = \Phi\Phi^\top + \Psi. \quad (15.3)$$

Proposição 15.1 (Estrutura de covariâncias do modelo fatorial ortogonal). *Sob as hipóteses na Definição 15.2, a matriz de covariâncias de $\mathbf{X}$ é*

$$\Sigma = \Phi\Phi^\top + \Psi,$$

em que

$$\Phi\Phi^\top \succeq \mathbf{0}$$

e

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p) \succeq \mathbf{0}.$$

A expressão na Equação 15.3 é o núcleo matemático da Análise Fatorial.

A matriz

$$\Phi\Phi^\top$$

é a matriz de covariâncias da parcela comum do modelo. Como

$$\Phi \in \mathbb{R}^{p \times m},$$

tem-se

$$\text{posto}(\Phi\Phi^\top) \leq m.$$

Assim, a estrutura comum é representada por uma matriz semidefinida positiva cujo posto é limitado pelo número de fatores.

A matriz

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

contém as variâncias específicas.

A decomposição

$$\Sigma = \underbrace{\Phi\Phi^\top}_{\text{estrutura comum}} + \underbrace{\Psi}_{\text{estrutura específica}}$$

explicita a diferença em relação à ACP. A Análise Fatorial não procura uma decomposição espectral completa de Σ . Ela procura representar a matriz de covariâncias por uma estrutura comum de posto reduzido acrescida de uma matriz diagonal de variâncias específicas.

15.4.1 Covariâncias entre variáveis

Considere duas variáveis distintas X_i e X_j . Pelo modelo,

$$X_i - \mu_i = \phi_i^\top \mathbf{F} + \varepsilon_i$$

e

$$X_j - \mu_j = \phi_j^\top \mathbf{F} + \varepsilon_j.$$

Sob as hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(X_i, X_j) = \phi_i^\top \phi_j, \quad i \neq j.$$

Equivalentemente,

$$\sigma_{ij} = \sum_{h=1}^m \phi_{ih} \phi_{jh}, \quad i \neq j. \quad (15.4)$$

A covariância entre duas variáveis observadas é, portanto, reproduzida pelo produto interno entre seus vetores de cargas.

Esse resultado admite uma interpretação geométrica. As linhas de Φ podem ser vistas como vetores em $\mathbb{R}^m$. Variáveis cujos vetores de cargas apresentam grande produto interno positivo possuem covariância positiva segundo o modelo; vetores com produto interno negativo correspondem a covariância negativa; e vetores ortogonais correspondem a covariância nula entre as variáveis no modelo fatorial ortogonal.

Essa geometria é desenvolvida na Seção [15.7](#).

15.4.2 Variâncias das variáveis

Para uma variável X_i ,

$$\begin{aligned}\text{Var}(X_i) &= \text{Var}(\phi_i^\top \mathbf{F} + \varepsilon_i) \\ &= \phi_i^\top \phi_i + \psi_i.\end{aligned}$$

Portanto,

$$\sigma_{ii} = \sum_{h=1}^m \phi_{ih}^2 + \psi_i. \quad (15.5)$$

A variância de cada variável é decomposta em uma parcela comum e uma parcela específica.

15.5 Comunalidades e especificidades

A decomposição da Equação 15.5 permite definir duas quantidades próprias da Análise Fatorial.

Definição 15.3 (Comunalidade). No modelo fatorial ortogonal na Definição 15.2, a **comunalidade** da variável X_i é

$$h_i^2 = \phi_i^\top \phi_i = \sum_{h=1}^m \phi_{ih}^2. \quad (15.6)$$

A comunalidade é a quantidade da variância de X_i atribuída à parcela comum do modelo.

Definição 15.4 (Especificidade). No modelo fatorial ortogonal na Definição 15.2, a **especificidade** da variável X_i é

$$\psi_i = \text{Var}(\varepsilon_i), \quad \psi_i \geq 0.$$

Assim,

$$\text{Var}(X_i) = h_i^2 + \psi_i. \quad (15.7)$$

A comunalidade e a especificidade pertencem à decomposição da variância de **cada variável**. Elas não correspondem à decomposição da variância total em componentes sucessivamente ordenadas, como ocorre na ACP.

Quando as variáveis estão padronizadas,

$$\text{Var}(X_i) = 1,$$

e, portanto,

$$1 = h_i^2 + \psi_i. \quad (15.8)$$

Nesse caso,

$$0 \leq h_i^2 \leq 1$$

e

$$0 \leq \psi_i \leq 1.$$

Como a variância total da variável padronizada é igual a 1, a comunalidade h_i^2 também pode ser interpretada como a proporção de sua variância atribuída aos fatores comuns, enquanto ψ_i é a proporção atribuída ao fator específico.

A soma das comunalidades pode ser escrita como

$$\sum_{i=1}^p h_i^2 = \text{tr}(\Phi\Phi^\top).$$

Como

$$\text{tr}(\Sigma) = \text{tr}(\Phi\Phi^\top) + \text{tr}(\Psi),$$

a variância total também admite a decomposição

$$\text{tr}(\Sigma) = \sum_{i=1}^p h_i^2 + \sum_{i=1}^p \psi_i. \quad (15.9)$$

A interpretação dessa identidade difere daquela utilizada na ACP. Na ACP, os autovalores distribuem a variância total entre componentes principais. Na Análise Fatorial, a identidade separa a variabilidade atribuída à estrutura comum da variabilidade específica das variáveis.

Exemplo 15.1 (Modelo com um fator comum). Considere três variáveis padronizadas e centralizadas representadas por um único fator comum,

$$\mathbf{X} = \Phi F + \varepsilon,$$

com

$$\Phi = \begin{pmatrix} 0,80 \\ 0,70 \\ 0,60 \end{pmatrix}$$

e

$$\Psi = \begin{pmatrix} 0,36 & 0 & 0 \\ 0 & 0,51 & 0 \\ 0 & 0 & 0,64 \end{pmatrix}.$$

As communalidades são

$$h_1^2 = 0,80^2 = 0,64,$$

$$h_2^2 = 0,70^2 = 0,49$$

e

$$h_3^2 = 0,60^2 = 0,36.$$

Como as variáveis são padronizadas,

$$h_i^2 + \psi_i = 1$$

para cada variável.

A matriz de covariâncias comuns é

$$\Phi\Phi^\top = \begin{pmatrix} 0,64 & 0,56 & 0,48 \\ 0,56 & 0,49 & 0,42 \\ 0,48 & 0,42 & 0,36 \end{pmatrix}.$$

Somando as variâncias específicas,

$$\mathcal{R} = \Phi\Phi^\top + \Psi = \begin{pmatrix} 1 & 0,56 & 0,48 \\ 0,56 & 1 & 0,42 \\ 0,48 & 0,42 & 1 \end{pmatrix}.$$

As correlações entre variáveis distintas são reproduzidas pelo fator comum. Por exemplo,

$$\text{Corr}(X_1, X_2) = 0,80 \times 0,70 = 0,56.$$

A primeira variável apresenta comunalidade 0,64, de modo que 64% de sua variância padronizada é atribuída ao fator comum e 36% é atribuída ao fator específico. Para a terceira variável, essas parcelas são 36% e 64%, respectivamente.

O exemplo mostra que a Análise Fatorial procura representar simultaneamente as covariâncias entre as variáveis e a decomposição de suas variâncias em parcelas comum e específica.

15.6 Cargas fatoriais e associação com os fatores

A matriz Φ reúne as cargas fatoriais do modelo. Seus elementos aparecem tanto na representação das variáveis quanto na matriz de covariâncias reproduzida.

No modelo ortogonal,

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \text{Cov}(\Phi\mathbf{F} + \varepsilon, \mathbf{F}).$$

Como

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

e

$$\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0},$$

segue que

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Phi. \tag{15.10}$$

Portanto,

$$\text{Cov}(X_i, F_j) = \phi_{ij}.$$

Essa igualdade decorre da parametrização em que os fatores possuem variância unitária.

A carga fatorial coincide com a correlação entre X_i e F_j somente quando a variável observada também possui variância unitária. De forma geral, se $\sigma_{ii} > 0$,

$$\text{Corr}(X_i, F_j) = \frac{\phi_{ij}}{\sqrt{\sigma_{ii}}}. \quad (15.11)$$

Para variáveis padronizadas,

$$\sigma_{ii} = 1,$$

e então

$$\text{Corr}(X_i, F_j) = \phi_{ij}.$$

Essa distinção é semelhante àquela estabelecida na Seção 14.14.2 entre os coeficientes das componentes principais e as correlações das variáveis com as componentes. Na Análise Fatorial, as cargas são parâmetros do próprio modelo de covariâncias.

A formulação construída até este ponto mostra que o problema da estrutura latente pode ser expresso por

$$\Sigma = \Phi\Phi^\top + \Psi.$$

O passo seguinte consiste em analisar a geometria da matriz de cargas e uma propriedade que distingue a Análise Fatorial da ACP: diferentes matrizes de cargas podem produzir exatamente a mesma estrutura de covariâncias comuns. Essa indeterminação conduz ao problema de identificação e às rotações fatoriais.

15.7 Geometria das cargas fatoriais

No modelo ortogonal, cada linha da matriz de cargas

$$\phi_i^\top = (\phi_{i1} \quad \cdots \quad \phi_{im})$$

pode ser representada como um vetor em $\mathbb{R}^m$.

A interpretação geométrica reúne a expressão da comunalidade na Equação 15.6 e a expressão da covariância entre variáveis distintas na Equação 15.4:

$$h_i^2 = \phi_i^\top \phi_i = \|\phi_i\|^2$$

e, para $i \neq j$,

$$\sigma_{ij} = \phi_i^\top \phi_j.$$

Portanto, o comprimento do vetor de cargas da variável X_i determina sua comunalidade, enquanto o produto interno entre os vetores de cargas de duas variáveis determina a covariância comum reproduzida entre elas.

Aplicando a relação entre produto interno e ângulo definida em Definição 1.11, para $\phi_i \neq \mathbf{0}$ e $\phi_j \neq \mathbf{0}$,

$$\sigma_{ij} = \phi_i^\top \phi_j = \|\phi_i\| \|\phi_j\| \cos(\theta_{ij}),$$

em que $\theta_{ij} \in [0, \pi]$ é o ângulo entre os vetores de cargas ϕ_i e ϕ_j . Assim, a covariância comum depende simultaneamente dos comprimentos dos vetores e de sua orientação relativa.

Vetores próximos em direção produzem produto interno positivo. Vetores orientados em sentidos aproximadamente opostos produzem produto interno negativo. Vetores aproximadamente ortogonais produzem pequena covariância comum.

A Figura 15.2 representa quatro variáveis em um modelo com dois fatores. O comprimento de cada vetor está associado à comunalidade e sua orientação descreve a relação da variável com os fatores.

Os vetores de X_1 e X_2 apresentam orientações semelhantes e, portanto, produto interno positivo. A variável X_3 está mais associada à segunda direção fatorial. A posição de X_4 mostra que uma variável pode apresentar sinais diferentes de associação com os dois fatores.

O círculo unitário fornece uma referência geométrica para variáveis padronizadas. Nesse caso,

$$h_i^2 \leq 1,$$

de modo que os vetores de cargas permanecem no interior ou sobre a circunferência.

Essa representação não transforma os fatores em variáveis observadas. Ela representa os parâmetros que relacionam cada variável observada às dimensões latentes especificadas pelo modelo.




Figura 15.2: Geometria das cargas em um modelo com dois fatores. O comprimento de cada vetor determina a communalidade e o produto interno entre vetores determina a covariância comum entre as variáveis.

15.8 Estrutura comum de covariâncias

A estrutura fatorial comum pode ser isolada pela diferença entre a matriz total de covariâncias e a matriz de variâncias específicas.

Defina

$$\Sigma_{\text{com}} = \Sigma - \Psi.$$

Pela Equação 15.3,

$$\Sigma_{\text{com}} = \Phi\Phi^{\top}. \quad (15.12)$$

Essa matriz é a matriz de covariâncias da parcela comum do modelo. De fato, definindo

$$\mathbf{X}_{\text{com}} = \Phi\mathbf{F},$$

e utilizando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

obtém-se

$$\text{Cov}(\mathbf{X}_{\text{com}}) = \Phi \text{Cov}(\mathbf{F})\Phi^{\top} = \Phi\Phi^{\top} = \Sigma_{\text{com}}.$$

Definição 15.5 (Matriz de covariâncias comuns). No modelo fatorial ortogonal na Definição 15.2, a **matriz de covariâncias comuns** é

$$\Sigma_{\text{com}} = \Phi\Phi^{\top}.$$

Seus elementos diagonais são as communalidades e seus elementos fora da diagonal são as covariâncias reproduzidas pelos fatores comuns.

A diagonal de Σ_{com} é

$$\text{diag}(\Sigma_{\text{com}}) = \begin{pmatrix} h_1^2 \\ \vdots \\ h_p^2 \end{pmatrix},$$

enquanto, para $i \neq j$,

$$(\Sigma_{\text{com}})_{ij} = \sigma_{ij}.$$

Na formulação populacional exata do modelo básico, toda covariância entre variáveis distintas é atribuída aos fatores comuns. As variâncias possuem uma parcela adicional representada por Ψ .

Quando as variáveis são padronizadas,

$$\Sigma = \mathcal{R},$$

e a matriz comum possui diagonal formada pelas comunalidades:

$$\Sigma_{\text{com}} = \mathcal{R} - \Psi.$$

Como Ψ é diagonal, Σ_{com} e $\mathcal{R}$ possuem os mesmos elementos fora da diagonal. A diferença ocorre na diagonal: os valores unitários de $\mathcal{R}$ são substituídos pelas comunalidades h_i^2 na matriz comum.

A dimensão da estrutura comum é limitada pelo número de fatores. Como

$$\text{posto}(\Phi\Phi^\top) \leq m,$$

a Análise Fatorial procura representar uma matriz de covariâncias de dimensão p por uma estrutura comum cujo posto é, no máximo, $m < p$.

Essa redução de posto pertence apenas à parcela comum. A matriz total

$$\Sigma = \Sigma_{\text{com}} + \Psi$$

pode continuar apresentando posto completo porque as variâncias específicas acrescentam variabilidade nas direções das variáveis observadas.

Esse ponto distingue novamente a Análise Fatorial da aproximação de posto reduzido utilizada na ACP. Uma aproximação espectral truncada de Σ produz diretamente uma matriz de posto reduzido. O modelo fatorial acrescenta uma matriz diagonal e procura preservar a estrutura específica de cada variável.

A Figura 15.3 representa a decomposição de uma matriz de covariâncias em sua parcela comum e sua parcela específica.

A matriz comum reproduz as covariâncias entre variáveis distintas e contribui também para as variâncias da diagonal. A matriz específica acrescenta somente variabilidade própria a cada variável. A soma das duas parcelas produz a matriz total especificada pelo modelo.




Figura 15.3: Decomposição de uma matriz de covariâncias em estrutura comum, produzida pelas cargas fatoriais, e estrutura específica diagonal.

15.9 Identificação do modelo fatorial

A equação

$$\Sigma = \Phi\Phi^{\top} + \Psi$$

não determina automaticamente valores únicos para todos os parâmetros.

Na formulação de segunda ordem desenvolvida até aqui, a identificação diz respeito às características de Φ e Ψ que podem ser determinadas de forma única a partir de Σ . Na formulação normal da Seção 15.14.5, a distribuição observável é determinada por μ e Σ ; portanto, a identificação dos parâmetros de covariância continua vinculada à forma como Φ e Ψ determinam Σ .

Algumas indeterminações decorrem diretamente da parametrização dos fatores. Entre elas estão a escala, o sinal e a orientação dos eixos fatoriais.

15.9.1 Escala dos fatores

Considere, inicialmente, um único fator:

$$\mathbf{X} = \mu + \Phi F + \varepsilon.$$

Para qualquer constante não nula c ,

$$\Phi F = (c\Phi) \left(\frac{F}{c} \right).$$

Logo, sem uma restrição adicional, a escala da carga e a escala do fator podem ser modificadas simultaneamente sem alterar a parte comum do modelo.

No modelo ortogonal padronizado, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a variância de cada fator e remove essa indeterminação de escala.

15.9.2 Indeterminação do sinal

Se uma coluna de Φ e o fator correspondente tiverem seus sinais invertidos simultaneamente, o produto permanece inalterado.

Para o fator F_j ,

$$\phi_{.j} F_j = (-\phi_{.j}) (-F_j).$$

Portanto, o sinal de um fator não é determinado pelo modelo.

Essa propriedade é semelhante à indeterminação de sinal dos autovetores observada na ACP, mas sua origem pertence agora à representação do produto entre carga e fator latente.

15.9.3 Indeterminação rotacional

Quando

$$m \geq 2,$$

surge também a indeterminação rotacional.

Diferentes orientações ortogonais dos fatores podem representar a mesma estrutura comum de covariâncias. Portanto, a orientação dos eixos fatoriais não é determinada de forma única pelo modelo.

O desenvolvimento matricial dessa propriedade, incluindo a transformação simultânea das cargas e dos fatores e a demonstração da invariância da estrutura comum, é apresentado na Seção [15.14.1](#).

15.10 Rotação dos eixos fatoriais

A rotação modifica a representação das cargas em relação aos eixos fatoriais. No caso de uma rotação ortogonal, ela preserva exatamente a matriz de covariâncias comuns e, conseqüentemente, a matriz de covariâncias reproduzida quando Ψ é mantida.

A Figura 15.4 compara uma matriz de cargas com uma solução obtida por uma rotação ortogonal. Para fins ilustrativos, aplica-se uma transformação ortogonal correspondente a uma rotação de 35° . Esse valor não corresponde a um critério específico de rotação: em uma aplicação, a orientação é determinada pelo critério adotado. Os vetores mudam de coordenadas em relação aos eixos, mas seus comprimentos e produtos internos são preservados.




Figura 15.4: Uma rotação ortogonal modifica as coordenadas das cargas, mas preserva comprimentos, produtos internos, communalidades e a matriz de covariâncias comuns.

A rotação altera os coeficientes individuais da matriz de cargas, mas uma rotação ortogonal preserva as communalidades, as covariâncias comuns e a variância comum total. A distribuição dessa variância entre os fatores individuais, entretanto, pode mudar após a rotação.

As demonstrações dessas propriedades são apresentadas na Seção 15.14.2.

Por isso, fatores rotacionados não devem ser interpretados como uma sequência ordenada de parcelas invariantes da variância total, como ocorre com as componentes principais. A rotação preserva a estrutura comum global, mas redistribui sua representação entre os eixos fatoriais.

A rotação deve ser distinguida da estimação inicial. Primeiro é obtida uma solução que reproduz a estrutura de covariâncias segundo determinado critério. Depois, uma transformação pode ser aplicada às cargas para selecionar outra representação da estrutura fatorial.

O objetivo de uma rotação é favorecer uma **estrutura simples**, na qual cada variável apresente cargas concentradas em um número reduzido de fatores e cargas pequenas nos demais. A rotação deve ser interpretada como uma transformação de uma solução fatorial já obtida, e não como um método alternativo de extração ou estimação.

15.10.1 Rotações ortogonais

Nas rotações ortogonais, os fatores permanecem não correlacionados. Em uma solução com dois fatores, a transformação pode ser visualizada como uma rotação dos eixos por determinado ângulo θ . Esse ângulo não é fixado previamente: a orientação resulta do critério de rotação adotado. Os eixos permanecem perpendiculares entre si, formando 90° . Com mais de dois fatores, uma transformação ortogonal não é descrita, em geral, por um único ângulo.

Diferentes critérios podem ser utilizados para selecionar uma orientação ortogonal que favoreça uma estrutura simples. Para a formulação do modelo, interessa que essas rotações modifiquem a orientação dos eixos fatoriais sem alterar a estrutura comum reproduzida nem introduzir correlações entre os fatores. Alguns critérios específicos são apresentados na Seção [15.15.4](#).

15.10.2 Rotações oblíquas

A hipótese de fatores não correlacionados pode ser excessivamente restritiva. Quando não há razão para impor covariâncias nulas entre os fatores, podem ser utilizadas **rotações oblíquas**.

Um **modelo com fatores correlacionados** e uma **rotação oblíqua** são conceitos relacionados, mas distintos. O primeiro admite uma matriz de covariâncias fatoriais diferente da identidade. A rotação oblíqua é uma transformação não ortogonal aplicada a uma solução fatorial para selecionar outra representação da estrutura comum, na qual os fatores resultantes podem ser correlacionados. A formulação a seguir descreve o modelo com fatores correlacionados associado a essa representação.

Para distinguir essa formulação da notação já adotada para a matriz de cargas, denote por

$$\Omega = \text{Cov}(\mathbf{F})$$

a matriz de covariâncias dos fatores. Quando os fatores possuem variâncias unitárias,

$$\text{diag}(\Omega) = \mathbf{1},$$

e Ω é a matriz de correlações fatoriais.

No modelo ortogonal,

$$\Omega = \mathbf{I}_m,$$

enquanto, em uma solução oblíqua,

$$\Omega \neq \mathbf{I}_m$$

em geral.

A matriz de covariâncias das variáveis passa então a ser escrita como

$$\Sigma = \Phi\Omega\Phi^\top + \Psi. \quad (15.13)$$

A parcela comum é, portanto,

$$\Sigma_{\text{com}} = \Phi\Omega\Phi^\top.$$

Consequentemente, na solução oblíqua a comunalidade da variável i corresponde ao i -ésimo elemento diagonal dessa matriz:

$$h_i^2 = (\Phi\Omega\Phi^\top)_{ii}.$$

Quando $\Omega = \mathbf{I}_m$, recupera-se o resultado do modelo ortogonal,

$$h_i^2 = \sum_{j=1}^m \phi_{ij}^2.$$

A matriz Φ contém os coeficientes que relacionam diretamente os fatores às variáveis no modelo e, em uma solução oblíqua, é denominada **matriz de padrões**.

Por outro lado,

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Phi\Omega.$$

Denotando

$$\Phi_\Omega = \Phi\Omega, \quad (15.14)$$

obtém-se a denominada **matriz de estrutura**. Na formulação em que variáveis e fatores possuem variâncias unitárias, seus elementos correspondem às correlações entre as variáveis observadas e os fatores.

Assim, em uma solução oblíqua devem ser distinguidos três objetos:

- a **matriz de padrões** Φ , formada pelos coeficientes do modelo;
- a **matriz de correlações fatoriais** Ω ;
- a **matriz de estrutura** $\Phi_\Omega = \Phi\Omega$, que descreve as associações entre variáveis e fatores.

No caso ortogonal,

$$\Omega = \mathbf{I}_m,$$

de modo que

$$\Phi_\Omega = \Phi.$$

Por isso, a distinção entre matriz de padrões e matriz de estrutura desaparece quando os fatores são ortogonais.

Diferentes critérios também podem ser utilizados para selecionar uma orientação oblíqua. Alguns deles são apresentados na Seção [15.15.4](#).

A escolha entre rotação ortogonal e oblíqua define a estrutura permitida para as correlações entre os fatores. Na solução ortogonal, essas correlações são fixadas em zero. Na solução oblíqua, elas podem ser diferentes de zero.

A decisão deve considerar se a hipótese de fatores não correlacionados é adequada ao problema analisado. A aparência das cargas, isoladamente, não determina a forma de rotação.

Estabelecida a estrutura populacional do modelo e suas principais indeterminações, passa-se ao nível amostral. A matriz de covariâncias ou de correlações observada é o objeto a partir do qual a estrutura fatorial é estimada. A avaliação da adequação da matriz de correlações é tratada na Seção [15.15.1](#).

15.11 Formulação populacional e amostral

No nível populacional, o modelo fatorial especifica uma estrutura para a matriz de covariâncias. No modelo ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi.$$

Os parâmetros de interesse incluem as cargas fatoriais e as variâncias específicas.

15.11.1 O problema de estimação

No nível amostral, o modelo fatorial deve fornecer uma estrutura compatível com a matriz de covariâncias ou de correlações observada. Diferentes métodos utilizam critérios distintos para obter essa representação (Johnson; Wichern, 2007).

O método de fatores principais utiliza uma construção espectral baseada em uma matriz reduzida, cuja diagonal contém comunalidades estimadas. Outros métodos definem a estimação por meio de uma função de discrepância entre a matriz observada e a matriz reproduzida pelo modelo.

Para uma análise baseada em covariâncias, essa segunda classe pode ser representada genericamente por

$$\min_{\theta} d[\mathbf{S}, \Sigma(\theta)], \quad (15.15)$$

em que θ reúne os parâmetros livres do modelo e

$$\Sigma(\theta) = \Phi\Phi^{\top} + \Psi$$

é a matriz de covariâncias reproduzida para um determinado conjunto de valores desses parâmetros.

A função

$$d[\mathbf{S}, \Sigma(\theta)]$$

associa à matriz amostral $\mathbf{S}$ e à matriz reproduzida $\Sigma(\theta)$ um valor numérico de discrepância. A matriz $\mathbf{S}$ permanece fixa durante a estimação, enquanto θ varia e, conseqüentemente, modifica a matriz reproduzida. O problema de estimação consiste em procurar os valores de θ que produzem a menor discrepância segundo o critério adotado.

Quando a análise é baseada em correlações, a mesma ideia é aplicada à matriz amostral de correlações $\mathbf{R}$ e à matriz reproduzida para as variáveis padronizadas.

O critério de estimação procura aproximar a estrutura de segunda ordem observada daquela reproduzida pelo modelo. Ele não seleciona, por si só, uma orientação única para as cargas quando diferentes orientações representam a mesma estrutura comum. A rotação tratada na Seção 15.10 atua depois da obtenção da solução e seleciona uma representação dos fatores para interpretação.

Neste capítulo são consideradas três formulações. O método de **fatores principais** utiliza uma decomposição espectral de uma matriz cuja diagonal contém comunalidades estimadas. O

método de **mínimos resíduos** (MINRES) reduz uma discrepância entre associações observadas e reproduzidas. Sob normalidade multivariada, a **máxima verossimilhança** utiliza a distribuição probabilística especificada para as observações.

Os métodos de fatores principais e mínimos resíduos são desenvolvidos na Seção 15.14.4. A máxima verossimilhança é desenvolvida na Seção 15.14.5.

15.11.2 Escores fatoriais

Os fatores comuns aparecem no modelo como variáveis latentes,

F.

Eles não são observados diretamente. Essa situação difere da ACP, em que o escore definido na Definição 14.1 é obtido pela projeção da observação sobre uma direção principal determinada pela solução.

Na Análise Fatorial, é necessário acrescentar um critério para relacionar uma observação aos fatores latentes. Esse é o **problema dos escores fatoriais** (Johnson; Wichern, 2007).

Considere uma observação

$$\mathbf{x} \in \mathbb{R}^p.$$

Depois que o modelo é especificado ou ajustado, pode-se obter uma estimativa ou predição da realização dos fatores associada a essa unidade. Essa quantidade é denominada **escore fatorial**.

Definição 15.6 (Escore fatorial). Um **escore fatorial** é uma quantidade calculada a partir das variáveis observadas e de uma solução fatorial para representar a posição de uma unidade nas dimensões fatoriais. No modelo com fatores aleatórios adotado neste capítulo, pode ser interpretado como uma predição da realização dos fatores associada à unidade.

A Tabela 15.2 sintetiza as funções distintas desempenhadas pelos fatores, pelas cargas e pelos escores fatoriais.

Tabela 15.2: Distinção entre fatores, cargas e escores fatoriais.

Objeto	Natureza
F	Vetor aleatório latente especificado pelo modelo

Objeto	Natureza
Φ	Matriz de parâmetros que relaciona fatores e variáveis
$\mathbf{f}_i$	Realização latente dos fatores associada à unidade i , não diretamente observada
$\hat{\mathbf{f}}_i$	Escore utilizado para estimar ou prever $\mathbf{f}_i$

As cargas fatoriais são parâmetros da estrutura do modelo, enquanto os escores são quantidades associadas às unidades observacionais.

O modelo fatorial não fornece, por si só, um único valor de escore para cada observação. A obtenção dos escores exige um critério adicional de estimação ou predição, e critérios diferentes podem produzir valores distintos para a mesma unidade (Johnson; Wichern, 2007).

Os escores também são referidos à orientação dos fatores utilizada na solução. Quando os eixos fatoriais são transformados, as coordenadas fatoriais devem ser transformadas de forma compatível. Assim, um escore numérico deve ser interpretado em relação à matriz de cargas e à orientação dos fatores que definem a solução.

A interpretação probabilística do escore por regressão é desenvolvida na Seção 15.14.7. Outros métodos são apresentados na Seção 15.15.5.

15.12 Pressupostos e limites do modelo

Os aspectos que condicionam a Análise Fatorial possuem funções diferentes. Alguns definem o modelo de fatores comuns. Outros correspondem a restrições dos parâmetros, condições de identificação, escolhas de especificação ou hipóteses necessárias para procedimentos probabilísticos específicos.

A Tabela 15.3 organiza essas diferenças.

Tabela 15.3: Pressupostos, condições e limites da formulação fatorial.

Aspecto	Natureza	Papel na formulação
Linearidade	Hipótese definidora	As variáveis observadas são representadas linearmente pelos fatores comuns e pelos fatores específicos
Estrutura comum de baixa dimensão	Especificação estrutural	A parcela comum da matriz de covariâncias é representada por $m < p$ fatores

Aspecto	Natureza	Papel na formulação
Diagonalidade de Ψ	Hipótese definidora	Fatores específicos associados a variáveis distintas possuem covariância nula
Não correlação entre fatores comuns e específicos	Hipótese definidora	Separa, em termos de covariância, as parcelas comum e específica
Identificação	Condição do modelo	As características que constituem o objeto de interesse devem ser determinadas pela parametrização e pelas restrições adotadas
Admissibilidade	Restrição paramétrica	As variâncias específicas devem ser não negativas e a matriz reproduzida deve ser uma matriz de covariâncias válida
Normalidade	Hipótese probabilística adicional	Não é necessária para o modelo de segunda ordem; integra o modelo fatorial normal e sustenta a verossimilhança normal e resultados inferenciais correspondentes
Número de fatores	Escolha de especificação	Determina a dimensão da estrutura comum e a classe de matrizes de covariâncias representáveis
Conjunto e escala das variáveis	Dependência da análise	Alterações nas variáveis ou em suas escalas modificam a estrutura de covariâncias ou correlações modelada

15.12.1 Número de fatores

O número m determina a dimensão da estrutura comum e a classe de matrizes de covariâncias que o modelo pode representar. Valores pequenos impõem uma estrutura mais restritiva. O aumento de m amplia a flexibilidade da representação.

Um número insuficiente de fatores pode deixar associações sistemáticas sem representação.

Um número excessivo reduz a parcimônia e pode produzir dimensões com pouca utilidade interpretativa.

No núcleo, m integra a especificação do modelo. Os critérios utilizados para auxiliar sua escolha são apresentados na Seção [15.15.2](#).

15.12.2 Dependência do conjunto e da escala das variáveis

A estrutura fatorial é definida em relação às variáveis incluídas no modelo. Adicionar, retirar ou transformar variáveis modifica a matriz de covariâncias ou correlações e pode alterar a solução.

Uma análise baseada em covariâncias também depende das escalas marginais. A utilização da matriz de correlações remove essas diferenças de escala antes do ajuste, mas define outra estrutura de segunda ordem. A mesma distinção entre covariâncias e correlações foi desenvolvida para a ACP na Seção [14.10](#).

15.12.3 Papel da normalidade

A decomposição

$$\Sigma = \Phi\Phi^{\top} + \Psi$$

é uma estrutura de segunda ordem e não exige normalidade multivariada.

A normalidade é acrescentada quando se adota o modelo fatorial normal da Definição [15.7](#). Essa especificação permite desenvolver a máxima verossimilhança, a distribuição condicional dos fatores e os resultados inferenciais apresentados nos aprofundamentos teóricos.

15.13 Análise Fatorial e Análise de Componentes Principais

A Análise de Componentes Principais, formulada no Capítulo [14](#), e a Análise Fatorial resolvem problemas estatísticos distintos. A ACP constrói direções que representam a variabilidade da matriz analisada. A Análise Fatorial especifica uma estrutura latente para representar as covariâncias entre as variáveis observadas.

As duas técnicas podem utilizar matrizes de covariâncias ou de correlações, e decomposições espectrais aparecem em algumas de suas formulações. Essas semelhanças algébricas não tornam equivalentes os objetos estatísticos representados.

Na ACP,

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top,$$

em que as colunas de $\mathbf{A}$ são os autovetores unitários $\alpha_1, \dots, \alpha_p$ e os elementos diagonais de $\mathbf{\Lambda}$ são os autovalores.

No modelo fatorial ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A Tabela 15.4 reúne as diferenças principais.

Tabela 15.4: Diferenças matemáticas e estatísticas entre ACP e Análise Fatorial.

Aspecto	ACP	Análise Fatorial
Problema	Representar a variabilidade em poucas direções	Representar as covariâncias por fatores latentes
Objeto populacional	Σ ou $\mathcal{R}$	Σ ou $\mathcal{R}$
Estrutura definidora	Decomposição espectral da matriz analisada	Modelo de fatores comuns
Formulação ortogonal	$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top$	$\Sigma = \Phi\Phi^\top + \Psi$
Variabilidade considerada	Variância total	Variância comum separada da específica
Objetos de menor dimensão	Componentes definidas como combinações lineares das variáveis observadas	Fatores latentes especificados pelo modelo
Coeficientes	Autovetores α_j	Cargas fatoriais ϕ_{ij}
Escores	Coordenadas das observações no espaço das componentes	Quantidades utilizadas para estimar ou prever os fatores associados às observações
Não unicidade	Sinal e, sob multiplicidade, autoespaços	Após fixada a escala, sinal, rotação e possíveis indeterminações adicionais de identificação
Normalidade	Não necessária para definir a técnica	Não necessária para o modelo de segunda ordem; necessária para a formulação normal

A presença de autovalores e autovetores em alguns métodos de estimação fatorial não transforma esses procedimentos em ACP. Na ACP, a decomposição espectral atua sobre a matriz utilizada na análise e representa sua variabilidade. Na Análise Fatorial, procedimentos espectrais podem ser utilizados para estimar uma solução compatível com o modelo

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A parcela

$$\Phi\Phi^\top$$

representa a estrutura comum. A matriz diagonal Ψ mantém explicitamente a variabilidade específica de cada variável.

Neste capítulo, o modelo de fatores comuns é estudado no contexto da **Análise Fatorial Exploratória**, em que a estrutura das cargas não é completamente especificada antes do ajuste. Na Análise Fatorial Confirmatória, restrições sobre a estrutura fatorial são estabelecidas previamente a partir do modelo de mensuração. Essa extensão não será desenvolvida neste livro.

15.14 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte reúne desenvolvimentos sobre identificação, invariâncias e critérios de rotação, fatores principais e mínimos resíduos, formulação probabilística, máxima verossimilhança, distribuições associadas à avaliação da matriz de correlações e propriedades dos métodos de escores fatoriais. Esses resultados ampliam a formulação apresentada no núcleo do capítulo, mas não são necessários para uma primeira leitura da técnica.

15.14.1 Contagem de parâmetros e identificação

No modelo ortogonal adotado neste capítulo, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, mas permanece a indeterminação associada à orientação dos eixos fatoriais. Diferentes matrizes de cargas podem representar a mesma estrutura de covariâncias (Anderson, 2003).

A contagem de parâmetros apresentada nesta seção fornece uma condição necessária de compatibilidade dimensional entre a parametrização e os elementos distintos de Σ em pontos regulares. Ela não constitui, isoladamente, uma condição suficiente de identificação.

15.14.1.1 Desenvolvimento matricial da indeterminação rotacional

A não unicidade da orientação dos fatores pode ser estabelecida formalmente por transformações da matriz de cargas e do vetor de fatores (Anderson, 2003).

Quando

$$m \geq 2,$$

surge também a indeterminação rotacional.

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{m \times m},$$

definida na Definição 2.18, de modo que

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{Q} \mathbf{Q}^\top = \mathbf{I}_m.$$

Defina

$$\Phi^* = \Phi \mathbf{Q}$$

e

$$\mathbf{F}^* = \mathbf{Q}^\top \mathbf{F}.$$

Então,

$$\begin{aligned} \Phi^* \mathbf{F}^* &= \Phi \mathbf{Q} \mathbf{Q}^\top \mathbf{F} \\ &= \Phi \mathbf{F}. \end{aligned}$$

Além disso,

$$\begin{aligned} \text{Cov}(\mathbf{F}^*) &= \mathbf{Q}^\top \text{Cov}(\mathbf{F}) \mathbf{Q} \\ &= \mathbf{Q}^\top \mathbf{Q} \\ &= \mathbf{I}_m. \end{aligned}$$

A nova representação continua sendo ortogonal.

Para a matriz de covariâncias comuns,

$$\begin{aligned}\Phi^* \Phi^{*\top} &= \Phi \mathbf{Q} \mathbf{Q}^\top \Phi^\top \\ &= \Phi \Phi^\top.\end{aligned}$$

Portanto,

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top. \quad (15.16)$$

Proposição 15.2 (Indeterminação rotacional do modelo fatorial ortogonal). *Considere um modelo fatorial ortogonal com*

$$\Phi \in \mathbb{R}^{p \times m}$$

e seja

$$\mathbf{Q} \in \mathbb{R}^{m \times m}$$

qualquer matriz ortogonal. Então a matriz de cargas

$$\Phi^* = \Phi \mathbf{Q}$$

produz a mesma matriz de covariâncias comuns:

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top.$$

Além disso, com

$$\mathbf{F}^* = \mathbf{Q}^\top \mathbf{F},$$

a parcela comum do modelo é preservada e

$$\text{Cov}(\mathbf{F}^*) = \mathbf{I}_m.$$

Assim, a estrutura de covariâncias do modelo não determina uma orientação ortogonal única para os fatores.

A invariância em Equação 15.16 utiliza diretamente a preservação do produto interno estabelecida no Teorema 2.7.

A indeterminação rotacional mostra que diferentes matrizes de cargas relacionadas por transformações ortogonais podem representar a mesma matriz

$$\Phi\Phi^\top.$$

Esse resultado demonstra a não unicidade da orientação dos fatores. Ele não implica, por si só, que $\Phi\Phi^\top$ e Ψ sejam identificáveis de forma única a partir de Σ ; essa questão requer condições adicionais de identificação.

15.14.1.2 Contagem de parâmetros

A matriz simétrica Σ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

No modelo ortogonal com m fatores, a matriz de cargas possui

$$pm$$

elementos e a matriz diagonal Ψ possui

$$p$$

variâncias específicas.

Uma contagem direta produz

$$pm + p$$

parâmetros. Essa parametrização contém diferentes matrizes de cargas relacionadas por transformações ortogonais que representam a mesma matriz de covariâncias.

Em um ponto regular com

$$\text{posto}(\Phi) = m,$$

as transformações ortogonais possuem

$$\frac{m(m-1)}{2}$$

graus de liberdade contínuos. Inversões de sinal também produzem representações equivalentes, mas constituem uma indeterminação discreta e não alteram a dimensão local da parametrização.

A dimensão local do modelo fatorial ortogonal é, portanto,

$$pm + p - \frac{m(m-1)}{2}. \quad (15.17)$$

Uma condição necessária de contagem é, portanto,

$$pm + p - \frac{m(m-1)}{2} \leq \frac{p(p+1)}{2}. \quad (15.18)$$

Essa desigualdade compara o número de elementos distintos de Σ com a dimensão local do modelo. Ela é uma condição necessária de contagem em pontos regulares.

A diferença entre essas duas quantidades será retomada na Equação 15.35 como o número de restrições independentes do modelo utilizado no teste de ajuste por máxima verossimilhança.

A contagem de parâmetros não garante identificação

Satisfazer a condição de contagem da Equação 15.18 não garante identificação do modelo. A identificação depende também da estrutura das cargas, das restrições impostas e da posição do parâmetro no espaço paramétrico.

Uma parametrização identificada exige restrições que eliminem as representações equivalentes relevantes para o problema considerado. Essas restrições podem atuar sobre as cargas ou sobre a orientação dos fatores (Anderson, 2003).

Na Análise Fatorial Exploratória, a orientação das cargas é escolhida posteriormente para favorecer a interpretação da solução. Na Análise Fatorial Confirmatória, restrições sobre a estrutura das cargas são especificadas antes do ajuste e participam diretamente da identificação do modelo.

As condições algébricas completas de identificação variam conforme a estrutura imposta ao modelo e não serão desenvolvidas neste capítulo.

15.14.2 Invariâncias da rotação ortogonal

Considere a matriz de cargas rotacionada

$$\Phi^* = \Phi \mathbf{Q},$$

com $\mathbf{Q}$ ortogonal.

Para a variável i , a linha correspondente da matriz rotacionada é

$$\phi_i^{*\top} = \phi_i^\top \mathbf{Q}.$$

A comunalidade permanece inalterada porque

$$\begin{aligned}\|\phi_i^*\|^2 &= \phi_i^\top \mathbf{Q} \mathbf{Q}^\top \phi_i \\ &= \|\phi_i\|^2.\end{aligned}$$

Para duas variáveis i e j ,

$$\begin{aligned}\phi_i^{*\top} \phi_j^* &= \phi_i^\top \mathbf{Q} \mathbf{Q}^\top \phi_j \\ &= \phi_i^\top \phi_j.\end{aligned}$$

As covariâncias comuns permanecem, portanto, inalteradas. Esse resultado é a versão elemento a elemento da invariância matricial estabelecida na Equação 15.16.

A variância comum total também é preservada:

$$\begin{aligned}\text{tr}(\Phi^* \Phi^{*\top}) &= \text{tr}(\Phi \Phi^\top) \\ &= \sum_{j=1}^m \|\phi_{\cdot j}\|^2.\end{aligned}$$

A parcela associada a cada eixo fatorial pode mudar. Em geral,

$$\sum_{i=1}^p \phi_{ij}^{*2} \neq \sum_{i=1}^p \phi_{ij}^2.$$

A rotação ortogonal preserva a estrutura comum global e redistribui sua representação entre os fatores individuais.

15.14.3 Critérios de rotação como problemas de otimização

A indeterminação rotacional permite escolher, entre representações equivalentes da estrutura comum, uma orientação que favoreça determinado padrão das cargas. Um critério de rotação formaliza essa escolha por meio de uma função objetivo. Nas rotações ortogonais, a matriz de cargas rotacionada é

$$\Phi^* = \Phi \mathbf{Q},$$

com $\mathbf{Q}$ ortogonal. A estrutura comum permanece inalterada, conforme estabelecido na Seção 15.14.2, mas os elementos de Φ^* dependem da orientação escolhida.

15.14.3.1 Varimax

O critério Varimax procura aumentar a dispersão dos quadrados das cargas dentro de cada fator (Kaiser, 1958).

Na forma normalizada de Kaiser, para uma variável com comunalidade $h_i^2 > 0$, defina

$$\tilde{\phi}_{ij}^* = \frac{\phi_{ij}^*}{h_i}.$$

O critério pode ser escrito como

$$v_{\text{Varimax}} = \sum_{j=1}^m \left[\frac{1}{p} \sum_{i=1}^p (\tilde{\phi}_{ij}^*)^4 - \left(\frac{1}{p} \sum_{i=1}^p (\tilde{\phi}_{ij}^*)^2 \right)^2 \right]. \quad (15.19)$$

A orientação é escolhida para maximizar v_{Varimax} . Para cada fator, a expressão entre colchetes mede a dispersão dos quadrados das cargas normalizadas. A maximização favorece colunas nas quais algumas cargas apresentam magnitude elevada e outras se aproximam de zero.

A normalização reduz o efeito das diferenças de comunalidade entre as variáveis na determinação da orientação.

15.14.3.2 Quartimax

O Quartimax procura concentrar, para cada variável, sua comunalidade em um número reduzido de fatores (Lawley; Maxwell, 1971). Um critério equivalente, sob rotação ortogonal, consiste em maximizar

$$v_{\text{Quartimax}} = \sum_{i=1}^p \sum_{j=1}^m (\phi_{ij}^*)^4. \quad (15.20)$$

Como a rotação ortogonal preserva

$$h_i^2 = \sum_{j=1}^m (\phi_{ij}^*)^2,$$

a maximização das quartas potências favorece a concentração dessa magnitude em poucas cargas de cada linha.

Varimax e Quartimax utilizam, portanto, a mesma solução inicial e preservam a mesma estrutura comum, mas favorecem organizações diferentes da matriz de cargas.

15.14.3.3 Oblimin

Nas rotações oblíquas, a orientação é escolhida sem exigir que os fatores permaneçam ortogonais. Denote por

$$\mathbf{B} = (b_{ij})$$

uma matriz de padrões candidata na parametrização oblíqua apresentada na Seção 15.10.

A família *direct oblmin* utiliza uma função de simplicidade aplicada diretamente às cargas. Uma forma usual do critério pode ser escrita como (Jennrich, 1979; Jennrich; Sampson, 1966)

$$g_{\gamma}(\mathbf{B}) = \sum_{1 \leq j < k \leq m} \left[\sum_{i=1}^p b_{ij}^2 b_{ik}^2 - \frac{\gamma}{p} \left(\sum_{i=1}^p b_{ij}^2 \right) \left(\sum_{i=1}^p b_{ik}^2 \right) \right], \quad (15.21)$$

que é minimizado em relação à orientação oblíqua admissível.

O parâmetro γ modifica a forma do critério. Para $\gamma = 0$, obtém-se o critério Quartimin. A minimização procura reduzir a presença simultânea de cargas elevadas de uma mesma variável em vários fatores, sem impor correlações fatoriais nulas.

15.14.3.4 Promax

O Promax utiliza uma estratégia de aproximação a uma estrutura-alvo (Hendrickson; White, 1964). Parte-se de uma matriz de cargas previamente submetida a uma rotação ortogonal, denotada por

$$\Phi^{(0)}.$$

Para $\kappa > 1$, constrói-se uma matriz-alvo cujos elementos são

$$\phi_{ij}^{(\kappa)} = \text{sign}(\phi_{ij}^{(0)}) |\phi_{ij}^{(0)}|^\kappa. \quad (15.22)$$

A transformação por potência amplia o contraste entre cargas maiores e menores. Em seguida, procura-se uma transformação oblíqua não singular $\mathbf{G}$ que aproxime a matriz-alvo, por um problema do tipo

$$\min_{\mathbf{G}} \|\Phi^{(0)}\mathbf{G} - \Phi^{(\kappa)}\|_F^2. \quad (15.23)$$

A solução é posteriormente normalizada de acordo com a parametrização adotada para os fatores. Diferentemente de Varimax e Quartimax, a transformação final não precisa ser ortogonal.

Os critérios de rotação definem como uma orientação é selecionada entre representações admissíveis da estrutura comum. Suas consequências para a escolha e a interpretação da solução são tratadas na Seção 15.15.4.

15.14.4 Fatores principais e mínimos resíduos

Fatores principais e mínimos resíduos utilizam critérios distintos para obter uma solução fatorial. O método de fatores principais constrói sucessivamente uma matriz reduzida com comunalidades estimadas na diagonal e aplica a ela uma decomposição espectral. O MINRES determina as cargas pela minimização dos resíduos entre associações observadas e reproduzidas.

As duas formulações procuram representar a estrutura comum, mas não utilizam o mesmo critério de estimação (Johnson; Wichern, 2007).

15.14.4.1 Fatores principais

O método de **fatores principais**, também denominado **método dos eixos principais** (*principal axis factoring*, PAF), utiliza uma decomposição espectral de uma matriz construída para representar a parcela comum da estrutura de covariâncias ou correlações (Johnson; Wichern, 2007).

Fatores ou eixos principais não são componentes principais. As duas técnicas utilizam autovaleores e autovetores, mas os aplicam a objetos estatísticos diferentes.

Na ACP, a decomposição espectral atua sobre a matriz de covariâncias ou de correlações analisada e representa sua variabilidade. No método dos fatores principais, ela atua sobre uma matriz reduzida, cuja diagonal contém comunalidades estimadas.

No nível populacional, para o modelo ortogonal,

$$\Sigma_{\text{com}} = \Sigma - \Psi = \Phi\Phi^\top.$$

Como

$$\text{posto}(\Sigma_{\text{com}}) \leq m,$$

um modelo com m fatores representa a estrutura comum por uma matriz de posto não superior a m .

Na aplicação amostral baseada em correlações, as comunalidades são desconhecidas. O procedimento parte de estimativas iniciais

$$\hat{h}_1^2, \dots, \hat{h}_p^2$$

e substitui a diagonal unitária de $\mathbf{R}$ por esses valores, formando a denominada **matriz de correlações reduzida**

$$\mathbf{R}_{\text{red}} = \begin{pmatrix} \hat{h}_1^2 & r_{12} & \cdots & r_{1p} \\ r_{21} & \hat{h}_2^2 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & \hat{h}_p^2 \end{pmatrix}. \quad (15.24)$$

A denominação é tradicional: depois da substituição dos elementos diagonais, $\mathbf{R}_{\text{red}}$ não é, em geral, uma matriz de correlações no sentido estrito. Sua diagonal passa a representar a parcela estimada da variância de cada variável atribuída aos fatores comuns.

A matriz reduzida é um objeto intermediário do método. Ela orienta a estimação da estrutura comum e não deve ser confundida com a matriz de correlações reproduzida pelo modelo fatorial completo.

A utilização de autovalores e autovetores nos dois métodos não torna as técnicas equivalentes. Na ACP baseada em correlações, decompõe-se a própria matriz

$$\mathbf{R}.$$

No método de fatores principais, a decomposição espectral é aplicada à matriz reduzida

$$\mathbf{R}_{\text{red}},$$

cujas diagonais contêm comunalidades estimadas. A matriz decomposta e a parcela de variabilidade representada são, portanto, diferentes.

Como $\mathbf{R}_{\text{red}}$ é simétrica, considere seus autovalores

$$\hat{\lambda}_{\text{red},1} \geq \hat{\lambda}_{\text{red},2} \geq \dots \geq \hat{\lambda}_{\text{red},p}$$

e autovetores unitários associados

$$\hat{\alpha}_{\text{red},1}, \dots, \hat{\alpha}_{\text{red},p},$$

satisfazendo

$$\mathbf{R}_{\text{red}} \hat{\alpha}_{\text{red},j} = \hat{\lambda}_{\text{red},j} \hat{\alpha}_{\text{red},j}, \quad \hat{\alpha}_{\text{red},j}^{\top} \hat{\alpha}_{\text{red},j} = 1.$$

Reunindo os autovetores em

$$\widehat{\mathbf{A}}_{\text{red}} = (\hat{\alpha}_{\text{red},1} \quad \dots \quad \hat{\alpha}_{\text{red},p})$$

e definindo

$$\widehat{\Lambda}_{\text{red}} = \text{diag}(\hat{\lambda}_{\text{red},1}, \dots, \hat{\lambda}_{\text{red},p}),$$

tem-se

$$\mathbf{R}_{\text{red}} = \widehat{\mathbf{A}}_{\text{red}} \widehat{\Lambda}_{\text{red}} \widehat{\mathbf{A}}_{\text{red}}^{\top}. \quad (15.25)$$

A decomposição utiliza autovalores e autovetores, como na ACP. O significado estatístico é diferente porque esses objetos pertencem à matriz reduzida, construída a partir de comunalidades estimadas.

Suponha que a solução utilize m autovalores positivos da matriz reduzida,

$$\hat{\lambda}_{\text{red},1} \geq \dots \geq \hat{\lambda}_{\text{red},m} > 0.$$

Defina

$$\widehat{\mathbf{A}}_{\text{red},m} = (\hat{\alpha}_{\text{red},1} \quad \dots \quad \hat{\alpha}_{\text{red},m}) \in \mathbb{R}^{p \times m}$$

e

$$\widehat{\Lambda}_{\text{red},m} = \text{diag}(\hat{\lambda}_{\text{red},1}, \dots, \hat{\lambda}_{\text{red},m}).$$

A matriz de cargas não rotacionadas correspondente é

$$\widehat{\Phi}_0 = \widehat{\mathbf{A}}_{\text{red},m} \widehat{\Lambda}_{\text{red},m}^{1/2}. \quad (15.26)$$

Se $\hat{a}_{\text{red},ij}$ é o i -ésimo elemento de $\hat{\alpha}_{\text{red},j}$, então

$$\hat{\phi}_{ij}^{(0)} = \sqrt{\hat{\lambda}_{\text{red},j}} \hat{a}_{\text{red},ij}. \quad (15.27)$$

A matriz comum reproduzida pela solução retida é

$$\widehat{\Phi}_0 \widehat{\Phi}_0^\top = \widehat{\mathbf{A}}_{\text{red},m} \widehat{\Lambda}_{\text{red},m} \widehat{\mathbf{A}}_{\text{red},m}^\top.$$

As comunalidades associadas às cargas obtidas são os elementos diagonais da estrutura comum reproduzida. Para a variável X_i ,

$$\hat{h}_i^2 = \sum_{j=1}^m (\hat{\phi}_{ij}^{(0)})^2.$$

No procedimento iterativo de fatores principais, essas comunalidades são utilizadas para atualizar a diagonal da matriz reduzida. A nova matriz produz outra decomposição espectral e, conseqüentemente, novas cargas e comunalidades. As atualizações prosseguem segundo o critério de convergência adotado.

A escolha das comunalidades iniciais, a tolerância de convergência e outros detalhes numéricos dependem da implementação e não serão desenvolvidos neste capítulo.

A solução obtida por fatores principais é inicialmente não rotacionada. Uma transformação posterior pode selecionar outra orientação para as cargas, conforme desenvolvido na Seção 15.10. No caso ortogonal, a invariância da estrutura comum foi estabelecida na Equação 15.16.

Na ACP baseada em correlações, a decomposição espectral é aplicada a $\mathbf{R}$. No método de fatores principais, ela é aplicada a $\mathbf{R}_{\text{red}}$, cuja diagonal contém comunalidades estimadas. Essa diferença determina se a decomposição representa a variância total padronizada ou é utilizada para estimar a parcela comum.

Como $\mathbf{R}_{\text{red}}$ depende de comunalidades estimadas, ela não é necessariamente semidefinida positiva durante todo o procedimento. Autovalores negativos podem ocorrer nessa matriz intermediária.

Esses valores não representam variâncias negativas dos fatores. Eles apenas não podem ser utilizados na expressão da Equação 15.27, que exige a raiz quadrada de um autovalor positivo para construir as cargas dos fatores retidos.

15.14.4.2 Mínimos quadrados e mínimos resíduos

Outra classe de métodos estima a estrutura fatorial pela minimização de uma função dos resíduos entre a matriz observada e a matriz reproduzida.

Como referência geral, em uma análise baseada em covariâncias, um critério de mínimos quadrados não ponderados pode ser escrito como

$$F_{\text{MQ}}(\Phi, \Psi) = \|\mathbf{S} - \Phi\Phi^\top - \Psi\|_F^2. \quad (15.28)$$

A norma de Frobenius definida na Definição 6.7 reúne os resíduos dos elementos correspondentes das duas matrizes. Essa expressão apresenta a lógica geral de ajuste por mínimos quadrados; ela não constitui, por si só, a definição do MINRES.

No modelo ortogonal, Ψ é diagonal. As associações entre variáveis distintas são reproduzidas pela parcela comum $\Phi\Phi^\top$, enquanto a diagonal é completada pelas variâncias específicas.

O método de **mínimos resíduos** (*minimum residual*, MINRES) concentra o ajuste, em uma análise baseada em correlações, nos elementos fora da diagonal. Para o modelo ortogonal, o critério pode ser escrito como

$$F_{\text{MINRES}}(\Phi) = \sum_{i < j} \left[r_{ij} - (\Phi\Phi^\top)_{ij} \right]^2. \quad (15.29)$$

O método procura cargas que reduzam os resíduos das correlações entre variáveis distintas. Depois de obtidas as cargas, as comunalidades são determinadas por suas somas de quadrados, e as especificidades completam a diagonal da matriz de correlações reproduzida.

O MINRES pertence à família dos métodos de mínimos quadrados não ponderados, mas designa esse critério específico de mínimos resíduos. A denominação não deve ser utilizada como sinônimo de qualquer ajuste por mínimos quadrados.

Métodos de mínimos quadrados ponderados atribuem pesos diferentes aos resíduos e definem outros critérios de ajuste. Suas funções objetivo e algoritmos não serão desenvolvidos neste capítulo.

A utilização dos resíduos para avaliar a reprodução da estrutura observada é desenvolvida na Seção 15.15.3.

Uma solução fatorial estimada deve respeitar as restrições de admissibilidade do modelo. Em particular,

$$\widehat{\psi}_i \geq 0, \quad i = 1, \dots, p.$$

Estimativas com

$$\widehat{\psi}_i < 0$$

produzem soluções impróprias associadas aos chamados **casos de Heywood** (Johnson; Wichern, 2007).

Para variáveis padronizadas, a relação

$$1 = \widehat{h}_i^2 + \widehat{\psi}_i$$

mostra que

$$\widehat{\psi}_i < 0$$

equivale a

$$\widehat{h}_i^2 > 1.$$

O caso

$$\widehat{\psi}_i = 0$$

corresponde à fronteira do espaço paramétrico. Resultados inferenciais derivados sob a hipótese de uma solução interior podem exigir tratamento adicional nessa situação.

15.14.5 Formulação probabilística normal

A estrutura de segunda ordem desenvolvida até aqui não exige normalidade. O aprofundamento probabilístico utiliza a distribuição normal multivariada definida na Definição 9.1 e especifica distribuições para os fatores comuns e para os fatores específicos (Anderson, 2003).

Definição 15.7 (Modelo fatorial normal). Considere o modelo fatorial ortogonal na Definição 15.2.

O modelo é denominado **fatorial normal ortogonal** quando

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m),$$

$$\varepsilon \sim N_p(\mathbf{0}, \Psi),$$

e

$$\mathbf{F} \perp \varepsilon.$$

O vetor aleatório observado é

$$\mathbf{X} = \mu + \Phi\mathbf{F} + \varepsilon.$$

A Definição 9.1 admite matrizes de covariâncias singulares. Assim, a distribuição de ε permanece bem definida quando alguma especificidade ψ_i é nula.

Como $\mathbf{F}$ e ε são vetores normais independentes, sua distribuição conjunta é normal. Pela estabilidade da normal multivariada sob transformações afins, estabelecida na Proposição 9.4,

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma = \Phi\Phi^\top + \Psi. \tag{15.30}$$

A normalidade acrescenta uma especificação distributiva à estrutura de segunda ordem do modelo.

Além disso, como ε é conjuntamente normal e Ψ é diagonal, os fatores específicos são independentes. Essa conclusão utiliza a propriedade de independência entre blocos normais estabelecida na Proposição 9.6.

A hipótese

$$\mathbf{F} \perp \varepsilon$$

também é mais forte do que a condição de covariância cruzada nula utilizada no modelo de segunda ordem.

Essa formulação probabilística permite utilizar a função de verossimilhança definida na Definição 10.11 e o princípio de máxima verossimilhança formalizado na Definição 10.12.

Sob o modelo fatorial normal, a máxima verossimilhança estima os parâmetros escolhendo, entre as matrizes admissíveis da forma

$$\Sigma = \Phi\Phi^\top + \Psi,$$

aquela que maximiza a verossimilhança da amostra observada. Diferentemente dos fatores principais, esse procedimento decorre diretamente do modelo probabilístico e fornece também uma base para a avaliação inferencial do ajuste.

15.14.5.1 Estimação por máxima verossimilhança e ajuste global

Sob o modelo fatorial normal, a máxima verossimilhança estima a estrutura de covariâncias dentro da classe definida pelo modelo fatorial (Anderson, 2003). A mesma formulação permite comparar essa classe com o modelo normal de covariâncias sem restrições estruturais.

Seja Θ_{fat} o espaço paramétrico admissível de uma parametrização identificada do modelo fatorial, com

$$\Sigma(\theta) = \Phi\Phi^\top + \Psi.$$

A verossimilhança normal requer uma matriz de covariâncias positiva definida. Define-se, portanto,

$$\Theta_{\text{fat}}^+ = \{\theta \in \Theta_{\text{fat}} : \Sigma(\theta) \succ \mathbf{0}\}. \quad (15.31)$$

Considere uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p[\mu, \Sigma(\theta)].$$

A Proposição 10.3 fornece

$$\hat{\mu} = \bar{\mathbf{x}}.$$

Quando $\text{posto}(\mathbf{S}) = p$, a Proposição 10.3 garante que o máximo da verossimilhança do modelo normal irrestrito existe e que a estimativa da matriz de covariâncias é $\mathbf{S}_{\text{MV}}$. Pela Equação 10.72,

$$\mathbf{S}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (15.32)$$

A log-verossimilhança concentrada, desconsiderando termos constantes em relação a θ , é

$$\ell(\theta) = C - \frac{n}{2} \left\{ \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \right\}. \quad (15.33)$$

Assim, a estimação por máxima verossimilhança equivale a minimizar

$$\log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}]$$

sobre Θ_{fat}^+ .

Quando

$$\mathbf{S}_{\text{MV}} \succ \mathbf{0},$$

pode-se utilizar a função de discrepância normalizada

$$F_{\text{ML}}(\theta) = \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] - \log |\mathbf{S}_{\text{MV}}| - p. \quad (15.34)$$

Essa função satisfaz

$$F_{\text{ML}} = 0$$

quando a matriz reproduzida coincide com $\mathbf{S}_{\text{MV}}$. Se $\mathbf{S}_{\text{MV}}$ é singular, a matriz $\mathbf{S}_{\text{MV}} = (n-1)\mathbf{S}/n$ continua definida e a log-verossimilhança na Equação 15.33 pode ser avaliada para matrizes modeladas positivas definidas. Nesse caso, porém, o modelo normal irrestrito com matriz de covariâncias positiva definida não possui estimativa de máxima verossimilhança, e a forma normalizada em Equação 15.34 e a comparação por razão de verossimilhanças com o modelo irrestrito não estão disponíveis na forma apresentada.

A solução é obtida, em geral, por otimização numérica; os algoritmos correspondentes não serão desenvolvidos neste capítulo (Lawley; Maxwell, 1971).

15.14.5.2 Ajuste global e graus de liberdade

A formulação por máxima verossimilhança permite comparar o modelo fatorial com o modelo normal de covariâncias sem restrições estruturais.

Em um ponto regular de uma parametrização identificada do modelo fatorial ortogonal com m fatores, o número de restrições independentes é a diferença entre os

$$\frac{p(p+1)}{2}$$

parâmetros livres da matriz de covariâncias irrestrita e a dimensão do modelo dada na Equação 15.17. Assim,

$$\nu_{\text{fat}} = \frac{p(p+1)}{2} - pm - p + \frac{m(m-1)}{2}. \quad (15.35)$$

Quando $\mathbf{S}_{\text{MV}} \succ \mathbf{0}$, a estatística da razão de verossimilhanças pode ser escrita como

$$-2 \log \Lambda_{\text{RV}} = n F_{\text{ML}}(\hat{\theta}_{\text{MV}}). \quad (15.36)$$

Sob identificação, solução populacional interior e as demais condições regulares do resultado assintótico de Wilks em Teorema 12.4, mantendo p e m fixos e fazendo

$$n \rightarrow \infty,$$

tem-se, se o modelo está corretamente especificado,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi^2_{\nu_{\text{fat}}}. \quad (15.37)$$

A distribuição qui-quadrado é um resultado assintótico. O número de fatores altera simultaneamente a flexibilidade do modelo e seus graus de liberdade.

A escolha de m é discutida na Seção 15.15.2. Quando a máxima verossimilhança é utilizada, o ajuste do modelo fornece uma fonte adicional de informação para essa decisão.

15.14.6 Distribuições associadas à avaliação da matriz de correlações

As medidas utilizadas na avaliação prévia da matriz de correlações possuem naturezas distintas. As correlações simples e parciais admitem resultados distribucionais sob normalidade, enquanto MSA e KMO são índices descritivos construídos a partir dessas correlações. O teste de esfericidade de Bartlett utiliza uma aproximação qui-quadrado.

15.14.6.1 Correlação amostral

Considere duas variáveis com distribuição normal bivariada e correlação populacional ρ_{ij} . Sob

$$H_0 : \rho_{ij} = 0,$$

a correlação amostral r_{ij} satisfaz exatamente

$$T_{ij} = \frac{r_{ij}\sqrt{n-2}}{\sqrt{1-r_{ij}^2}} \sim t_{n-2}. \quad (15.38)$$

Para correlação populacional não necessariamente nula, a transformação de Fisher

$$Z_{ij} = \operatorname{arctanh}(r_{ij})$$

possui, para amostras suficientemente grandes, distribuição aproximadamente normal,

$$Z_{ij} \stackrel{\text{aprox}}{\sim} N\left[\operatorname{arctanh}(\rho_{ij}), \frac{1}{n-3}\right]. \quad (15.39)$$

Esses resultados descrevem uma correlação isolada e não constituem testes de adequação global da matriz à Análise Fatorial (Anderson, 2003).

15.14.6.2 Correlação parcial

Considere agora a correlação parcial entre X_i e X_j depois do controle linear das outras $p-2$ variáveis. Denote por $\rho_{ij \cdot -ij}$ a correlação parcial populacional correspondente. Suponha

$$\Sigma \succ \mathbf{0}$$

e

$$n > p.$$

Sob normalidade multivariada e

$$H_0 : \rho_{ij \cdot -ij} = 0,$$

a correlação parcial amostral p_{ij} satisfaz

$$T_{ij \cdot -ij} = \frac{p_{ij} \sqrt{n-p}}{\sqrt{1-p_{ij}^2}} \sim t_{n-p}, \quad (15.40)$$

quando os graus de liberdade são positivos.

Para $n > p + 1$ e amostras suficientemente grandes, a transformação de Fisher fornece a aproximação

$$\operatorname{arctanh}(p_{ij}) \stackrel{\text{aprox}}{\sim} N \left[\operatorname{arctanh}(\rho_{ij \cdot -ij}), \frac{1}{n-p-1} \right]. \quad (15.41)$$

As correlações parciais que aparecem na matriz anti-imagem são, portanto, estatísticas amostrais com comportamento distribucional próprio. MSA e KMO reúnem várias dessas correlações e correlações simples em razões de somas de quadrados. Na condução clássica da Análise Fatorial Exploratória, esses índices são utilizados de forma descritiva e não são associados a um teste com distribuição de referência e p -valor.

15.14.6.3 Aproximação de Bartlett

O teste de esfericidade utiliza conjuntamente os elementos da matriz de correlações. Sob normalidade multivariada e

$$H_0 : \mathcal{R} = \mathbf{I}_p,$$

a estatística apresentada na Equação 15.56 utiliza uma correção da transformação de

$$-\log |\mathbf{R}|.$$

A distribuição qui-quadrado utilizada no teste é aproximada:

$$\chi_B^2 \stackrel{\text{aprox}}{\sim} \chi_{p(p-1)/2}^2.$$

A correção melhora a aproximação qui-quadrado, mas não transforma a estatística em uma variável com distribuição qui-quadrado exata em amostras finitas (Bartlett, 1950; Johnson; Wichern, 2007).

A distinção entre resultados exatos, aproximados e índices descritivos é utilizada na interpretação metodológica da Seção 15.15.1.

15.14.7 Distribuição condicional dos fatores e escore por regressão

Sob o modelo fatorial normal, a distribuição condicional dos fatores dadas as variáveis observadas permite interpretar o escore por regressão como uma predição do vetor fatorial latente.

Considere o modelo fatorial normal ortogonal da Definição 15.7 e suponha

$$\Sigma \succ \mathbf{0}.$$

Como

$$\text{Cov}(\mathbf{F}, \mathbf{X}) = \Phi^\top,$$

a distribuição condicional normal da Proposição 9.7 fornece diretamente

$$\mathbf{F} \mid (\mathbf{X} = \mathbf{x}) \sim N_m \left[\Phi^\top \Sigma^{-1} (\mathbf{x} - \mu), \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi \right]. \quad (15.42)$$

Consequentemente,

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Phi^\top \Sigma^{-1} (\mathbf{x} - \mu), \quad (15.43)$$

e

$$\text{Cov}(\mathbf{F} \mid \mathbf{X}) = \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi. \quad (15.44)$$

A média condicional fornece o **escore fatorial por regressão** (Johnson; Wichern, 2007):

$$\hat{\mathbf{f}}_{\text{reg}} = \Phi^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (15.45)$$

Quando os parâmetros são desconhecidos, eles são substituídos por estimativas obtidas do modelo ajustado.

A covariância condicional mostra que, em geral, conhecer $\mathbf{X} = \mathbf{x}$ não determina exatamente a realização dos fatores. Os fatores permanecem latentes e diferentes critérios de obtenção dos escores podem produzir valores distintos para a mesma solução fatorial.

15.14.8 Critérios e propriedades dos métodos de escores fatoriais

O escore por regressão desenvolvido na Seção 15.14.7 utiliza a distribuição condicional dos fatores. Outros métodos partem de critérios diferentes e, por isso, não produzem necessariamente os mesmos valores.

Considere

$$\mathbf{z} = \mathbf{x} - \mu = \Phi \mathbf{f} + \varepsilon.$$

15.14.8.1 Escore de Bartlett

O método de Bartlett trata $\mathbf{f}$ como o vetor de valores fatoriais a ser estimado e utiliza as variâncias específicas para ponderar os resíduos (Bartlett, 1937; Johnson; Wichern, 2007).

Supondo

$$\Psi \succ \mathbf{0},$$

considera-se

$$d_B(\mathbf{f}) = (\mathbf{z} - \Phi \mathbf{f})^\top \Psi^{-1} (\mathbf{z} - \Phi \mathbf{f}). \quad (15.46)$$

Quando

$$\Phi^\top \Psi^{-1} \Phi$$

é invertível, a minimização produz

$$\hat{\mathbf{f}}_B = (\Phi^\top \Psi^{-1} \Phi)^{-1} \Phi^\top \Psi^{-1} \mathbf{z}. \quad (15.47)$$

Condicionalmente a um valor fixado $\mathbf{f}$,

$$E(\hat{\mathbf{f}}_B | \mathbf{f}) = \mathbf{f},$$

e

$$\text{Cov}(\hat{\mathbf{f}}_B - \mathbf{f} | \mathbf{f}) = (\Phi^\top \Psi^{-1} \Phi)^{-1}.$$

O método atribui maior peso relativo às variáveis com menor variância específica.

15.14.8.2 Escore de Anderson–Rubin

O método de Anderson–Rubin procura construir escores mutuamente não correlacionados para uma solução ortogonal (Anderson; Rubin, 1956).

Suponha $\Psi \succ \mathbf{0}$ e defina

$$\mathbf{G}_{\text{AR}} = \Phi^\top \Psi^{-1} \Sigma \Psi^{-1} \Phi.$$

Quando $\mathbf{G}_{\text{AR}} \succ \mathbf{0}$, os escores podem ser escritos como

$$\hat{\mathbf{f}}_{\text{AR}} = \mathbf{G}_{\text{AR}}^{-1/2} \Phi^\top \Psi^{-1} \mathbf{z}. \quad (15.48)$$

Sua matriz de covariâncias é

$$\text{Cov}(\hat{\mathbf{f}}_{\text{AR}}) = \mathbf{I}_m. \quad (15.49)$$

Essa propriedade explica por que o método é compatível com soluções em que os fatores são especificados como ortogonais.

15.14.8.3 Escores de ten Berge

Em uma solução oblíqua, a matriz de correlações dos fatores é

$$\Omega.$$

O método de ten Berge pertence à classe dos métodos de predição que procuram preservar nos escores a estrutura de correlações dos fatores (Berge et al., 1999). Sua propriedade característica é

$$\text{Corr}(\hat{\mathbf{f}}_{\text{TB}}) = \Omega. \quad (15.50)$$

A construção utiliza raízes matriciais e uma transformação dos coeficientes de predição para satisfazer essa restrição. A propriedade em Equação 15.50 permite representar uma solução oblíqua por escores cujas correlações reproduzem a estrutura especificada para os fatores.

15.14.8.4 Método de Harman

O método de Harman utiliza uma construção baseada em variáveis idealizadas associadas à parcela comum da solução (Grice, 2001).

Suponha

$$\text{posto}(\Phi) = m.$$

A matriz de pesos pode ser escrita como

$$\mathbf{W}_H = \Phi (\Phi^\top \Phi)^{-1},$$

e o escore correspondente é

$$\hat{\mathbf{f}}_H = \mathbf{W}_H^\top \mathbf{z} = (\Phi^\top \Phi)^{-1} \Phi^\top \mathbf{z}. \quad (15.51)$$

Essa expressão corresponde à solução de mínimos quadrados não ponderados de

$$\min_{\mathbf{f}} \|\mathbf{z} - \Phi \mathbf{f}\|^2.$$

A construção difere do método de Bartlett porque não pondera os resíduos pelas variâncias específicas. Também não impõe, por construção, escores mutuamente não correlacionados nem a preservação da matriz de correlações fatoriais.

Os métodos de escores utilizam, portanto, critérios distintos. O escore por regressão privilegia a predição condicional dos fatores; Bartlett minimiza resíduos ponderados pelas variâncias específicas; Anderson–Rubin impõe escores não correlacionados; ten Berge preserva a estrutura de correlações fatoriais; Harman utiliza uma representação idealizada da parcela comum. Nenhum desses critérios é uniformemente superior para todas as finalidades (Johnson; Wichern, 2007).

15.15 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne critérios e procedimentos utilizados na condução da Análise Fatorial Exploratória, incluindo avaliação da matriz de correlações, escolha da dimensão, avaliação da reprodução da estrutura observada, rotação e obtenção de escores.

15.15.1 Adequação da matriz de correlações à Análise Fatorial

Na Análise Fatorial Exploratória, a matriz de correlações pode ser examinada antes da estimação para verificar como as associações entre as variáveis se modificam depois do controle linear das demais variáveis. Esses procedimentos pertencem à condução da análise e não à definição do modelo fatorial.

Uma situação compatível com a representação por fatores comuns ocorre quando vários pares de variáveis apresentam correlações simples diferentes de zero e as correlações parciais tendem a ser menores em módulo depois do controle das demais variáveis. Correlações parciais elevadas indicam associações entre pares que permanecem depois desse controle e podem não ser explicadas por poucos fatores comuns (Hair et al., 2018).

A matriz anti-imagem, a MSA e o KMO utilizam $\mathbf{R}^{-1}$ e, portanto, exigem uma matriz de correlações não singular. Pela Definição 8.12, quando as variâncias amostrais são positivas,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Combinando essa relação com a Equação 8.63,

$$\text{posto}(\mathbf{R}) \leq \min(p, n - 1).$$

Assim, $n > p$ é necessário para que $\mathbf{R}$ possa ter posto completo, mas não garante sua invertibilidade. Dependências lineares exatas entre as variáveis padronizadas também tornam $\mathbf{R}$ singular.

Apesar da expressão *sampling adequacy*, MSA e KMO não medem diretamente o tamanho da amostra. Seus valores são construídos a partir da comparação entre correlações simples e parciais.

Matriz anti-imagem, MSA, KMO e teste de Bartlett fornecem informações complementares sobre a estrutura das associações. Eles não demonstram que um modelo fatorial com determinado número de fatores apresenta bom ajuste.

As distribuições associadas às correlações simples e parciais e o caráter aproximado da distribuição utilizada no teste de Bartlett são desenvolvidos na Seção 15.14.6. MSA e KMO permanecem medidas descritivas e não possuem, na utilização adotada neste capítulo, um p -valor associado.

15.15.1.1 Matriz anti-imagem

A matriz anti-imagem é construída a partir das associações que permanecem entre pares de variáveis depois do controle linear das demais. Por isso, sua interpretação está diretamente ligada às correlações parciais.

Considere a matriz de correlações observada

$$\mathbf{R} = (r_{ij}),$$

positiva definida, e sua inversa

$$\mathbf{C} = \mathbf{R}^{-1} = (c_{ij}).$$

Para $i \neq j$, a correlação parcial entre X_i e X_j , controlando-se as demais variáveis, é

$$p_{ij} = -\frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}}.$$

Defina

$$\mathbf{D} = \text{diag} \left(\frac{1}{c_{11}}, \dots, \frac{1}{c_{pp}} \right).$$

A matriz de covariâncias anti-imagem é

$$\mathbf{S}_{\text{AI}} = \mathbf{D}\mathbf{C}\mathbf{D}. \quad (15.52)$$

Seus elementos diagonais são

$$s_{ii}^{(\text{AI})} = \frac{1}{c_{ii}},$$

enquanto, para $i \neq j$,

$$s_{ij}^{(\text{AI})} = \frac{c_{ij}}{c_{ii}c_{jj}}.$$

A padronização dessa matriz produz a matriz de correlações anti-imagem. Definindo

$$\mathbf{D}_C = \text{diag} (c_{11}, \dots, c_{pp}),$$

tem-se

$$\mathbf{R}_{\text{AI}} = \mathbf{D}_C^{-1/2} \mathbf{C} \mathbf{D}_C^{-1/2}. \quad (15.53)$$

Sua diagonal é unitária e, para $i \neq j$,

$$r_{ij}^{(\text{AI})} = \frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}} = -p_{ij}.$$

Portanto, os elementos fora da diagonal da matriz de correlações anti-imagem correspondem aos negativos das correlações parciais entre pares de variáveis, controlando-se as demais. Valores pequenos em módulo indicam pouca associação residual entre os pares depois desse controle.

A matriz de correlações anti-imagem definida na Equação 15.53 possui diagonal unitária. Em algumas saídas computacionais, essa diagonal é substituída pelas medidas individuais de adequação apresentadas a seguir. Essa convenção de apresentação não altera a definição matemática da matriz anti-imagem.

15.15.1.2 Medida de adequação amostral — MSA

A **Measure of Sampling Adequacy (MSA)** avalia cada variável separadamente pela relação entre suas correlações simples e suas correlações parciais com as demais variáveis.

Para a variável X_i , quando o denominador é positivo,

$$\text{MSA}_i = \frac{\sum_{j \neq i} r_{ij}^2}{\sum_{j \neq i} r_{ij}^2 + \sum_{j \neq i} p_{ij}^2}. \quad (15.54)$$

Nesse caso,

$$0 \leq \text{MSA}_i \leq 1.$$

A MSA se aproxima de 1 quando as correlações parciais são pequenas em relação às correlações simples. Valores baixos indicam que parte importante das associações da variável com as demais permanece mesmo depois do controle linear das outras variáveis. Esse padrão reduz a evidência de que suas correlações possam ser representadas pela mesma estrutura comum.

Hair et al. utilizam 0,50 como referência operacional mínima para examinar a adequação de uma variável (Hair et al., 2018). Esse valor é uma **regra prática**. Ele não constitui condição matemática de existência ou identificação do modelo fatorial.

15.15.1.3 Kaiser-Meyer-Olkin — KMO

O índice de **Kaiser-Meyer-Olkin (KMO)** aplica ao conjunto de variáveis o mesmo princípio utilizado pela MSA individual:

$$\text{KMO} = \frac{\sum_{i < j} r_{ij}^2}{\sum_{i < j} r_{ij}^2 + \sum_{i < j} p_{ij}^2}. \quad (15.55)$$

Quando o denominador é positivo,

$$0 \leq \text{KMO} \leq 1.$$

Valores próximos de 1 correspondem a correlações parciais pequenas em relação às correlações simples. Nesse caso, grande parte das associações entre pares diminui depois do controle das demais variáveis, padrão compatível com a presença de uma estrutura compartilhada.

Valores baixos indicam que parte importante das associações entre pares permanece depois do controle das demais variáveis. Hair et al. utilizam 0,50 como referência operacional mínima para a medida global (Hair et al., 2018).

MSA e KMO diferem pela abrangência. A MSA_i avalia uma variável em relação às demais. O KMO resume o mesmo tipo de comparação para o conjunto de variáveis. Nenhuma das duas medidas testa a hipótese de que um modelo fatorial específico seja verdadeiro.

15.15.1.4 Teste de esfericidade de Bartlett

O teste de esfericidade de Bartlett avalia a hipótese de que a matriz de correlações populacional $\mathcal{R}$, definida na Definição 8.5, seja a matriz identidade (Johnson; Wichern, 2007).

Considere uma amostra aleatória da distribuição normal multivariada definida na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com variâncias marginais positivas. Seja $\mathbf{R}$ a matriz de correlações observada calculada a partir das n observações completas. A hipótese nula é

$$H_0 : \mathcal{R} = \mathbf{I}_p,$$

contra

$$H_1 : \mathcal{R} \neq \mathbf{I}_p.$$

Sob H_0 , todas as correlações populacionais fora da diagonal são nulas.

Supondo $\mathbf{R}$ positiva definida, utiliza-se a estatística

$$\chi_B^2 = - \left[n - 1 - \frac{2p + 5}{6} \right] \log |\mathbf{R}|. \quad (15.56)$$

Para amostras suficientemente grandes,

$$\chi_B^2 \stackrel{\text{aprox}}{\sim} \chi_{p(p-1)/2}^2$$

sob H_0 (Johnson; Wichern, 2007).

A rejeição de H_0 fornece evidência de que a matriz de correlações populacional não é a identidade. Existe, portanto, associação linear entre pelo menos algumas das variáveis.

Esse resultado não estabelece a existência de uma estrutura fatorial de baixa dimensão nem o bom ajuste de um modelo com determinado número de fatores. Ele apenas afasta o caso em que todas as correlações populacionais entre variáveis distintas são nulas.

A não rejeição de H_0 indica que os dados não fornecem evidência suficiente para distinguir a matriz de correlações populacional da identidade, situação pouco favorável à busca de fatores comuns.

Hair et al. recomendam interpretar Bartlett em conjunto com as correlações parciais e as medidas de adequação (Hair et al., 2018). Em amostras grandes, associações pequenas podem produzir rejeição de H_0 . A significância do teste não deve ser utilizada isoladamente como evidência de adequação fatorial.

Tabela 15.5: Síntese dos procedimentos utilizados na avaliação da matriz de correlações antes da estimação fatorial.

Procedimento	Referência para interpretação	Conclusão permitida
Elementos fora da diagonal da anti-imagem	valores próximos de 0 são favoráveis	pequena associação parcial residual
MSA_i	0,50 como referência operacional mínima	valores menores indicam que a variável deve ser examinada antes de mantê-la na solução

Procedimento	Referência para interpretação	Conclusão permitida
KMO	0,50 como referência operacional mínima	valores maiores indicam menor importância relativa das correlações parciais
Bartlett	rejeitar H_0 quando o p -valor é menor que o nível α definido	a matriz de correlações populacional difere da identidade

15.15.2 Escolha do número de fatores

A dimensão m da estrutura fatorial é parte da especificação do modelo. Um número muito pequeno de fatores pode ser insuficiente para reproduzir a estrutura comum das variáveis, enquanto um número excessivo pode produzir uma representação desnecessariamente complexa e de interpretação instável (Hair et al., 2018).

A formulação do modelo estabelece que $m < p$, mas não determina, por si só, o valor de m . A escolha do número de fatores constitui uma decisão de modelagem e pode ser auxiliada por diferentes critérios.

Os critérios de retenção auxiliam a escolher a dimensão de uma solução fatorial exploratória. Eles fornecem evidências complementares e não substituem a interpretação da estrutura obtida.

A escolha de m não deve ser confundida com a avaliação da adequação da matriz de correlações. A matriz anti-imagem, as medidas MSA e KMO e o teste de esfericidade de Bartlett fornecem informações sobre a existência e a natureza das associações entre as variáveis, mas não determinam, por si só, quantos fatores devem ser retidos.

Alguns critérios utilizam uma sequência de raízes associadas à estrutura analisada. Antes de interpretá-las, é necessário identificar **qual matriz ou qual procedimento de extração as produziu**. Na ACP, os autovalores pertencem diretamente à matriz de covariâncias ou de correlações. Na Análise Fatorial, métodos distintos podem utilizar estruturas diferentes para representar a parcela comum.

No método de fatores principais desenvolvido na Seção 15.14.4, por exemplo, a decomposição espectral é aplicada à matriz reduzida $\mathbf{R}_{\text{red}}$, cuja diagonal contém comunalidades estimadas. Suas raízes não devem ser confundidas com os autovalores da matriz de correlações original $\mathbf{R}$.

O **gráfico de declive** (*scree plot*) apresenta uma sequência de raízes em ordem decrescente. Uma mudança acentuada no padrão de queda pode indicar uma região a partir da qual as raízes restantes se tornam relativamente pequenas. Sua interpretação depende das raízes utilizadas na construção do gráfico (Hair et al., 2018).

O critério baseado em autovalores maiores que 1 exige cuidado adicional. Quando aplicado aos autovalores da matriz de correlações $\mathbf{R}$, o valor 1 possui a interpretação de variância de uma variável padronizada. Essa justificativa é a mesma discutida para a ACP na Seção 14.14.1. Quando as raízes são obtidas de outra matriz ou de outro procedimento de extração, esse limiar não conserva automaticamente a mesma interpretação.

Assim, critérios baseados na magnitude das raízes devem ser tratados como auxiliares e sempre associados à matriz ou ao método que as produziu.

Outro procedimento é a **análise paralela**. Seu princípio é comparar as raízes obtidas dos dados observados com valores de referência produzidos sob uma estrutura sem associação sistemática entre as variáveis.

Para que a comparação tenha significado, as raízes observadas e as de referência devem ser obtidas segundo critérios comparáveis. Na Análise Fatorial, isso exige atenção à matriz analisada e ao método utilizado para representar a estrutura comum. A análise paralela não deve ser identificada automaticamente com a comparação dos autovalores da matriz $\mathbf{R}$ quando o procedimento fatorial utiliza outra definição de raiz.

A construção da referência pode variar quanto ao mecanismo de geração dos dados, ao número de replicações, à medida de referência adotada e ao procedimento utilizado para obter as raízes. Por isso, o capítulo utiliza a análise paralela como um **princípio de comparação com uma estrutura de ruído**, sem vinculá-la a um algoritmo computacional específico.

A escolha de m pode considerar conjuntamente:

- a possibilidade de interpretar cada fator a partir das variáveis associadas a ele;
- o comportamento das raízes e do gráfico de declive;
- critérios auxiliares de retenção;
- a análise paralela, quando utilizada;
- a reprodução da estrutura observada;
- os resíduos do modelo, quando disponíveis;
- a interpretação da solução depois da rotação.

Essas informações podem indicar soluções diferentes. Nesse caso, é útil examinar modelos com dimensões próximas e verificar como a estrutura muda quando um fator é acrescentado ou retirado (Hair et al., 2018).

O número de fatores não é determinado por um critério isolado. A decisão final deve equilibrar representação da estrutura comum, parcimônia, ajuste e interpretação (Johnson; Wichern, 2007).

15.15.3 Matriz reproduzida e resíduos

Depois da estimação, é possível examinar quanto da estrutura observada é reproduzida pela solução fatorial. Esse diagnóstico utiliza a matriz reproduzida e a diferença entre seus elementos e os da matriz utilizada no ajuste.

No modelo ortogonal, sejam

$$\widehat{\Phi}$$

e

$$\widehat{\Psi}$$

as estimativas correspondentes a uma solução com m fatores.

A matriz de cargas depende da parametrização e da orientação escolhida. A estrutura de segunda ordem reproduzida pelo modelo é o objeto utilizado para avaliar o ajuste.

No modelo ortogonal, a matriz de covariâncias reproduzida é

$$\widehat{\Sigma}_{\text{fat}} = \widehat{\Phi}\widehat{\Phi}^{\top} + \widehat{\Psi}. \quad (15.57)$$

Quando a análise é baseada em correlações, a expressão correspondente é

$$\widehat{\mathcal{R}}_{\text{fat}} = \widehat{\Phi}\widehat{\Phi}^{\top} + \widehat{\Psi},$$

com a parametrização definida para as variáveis padronizadas.

Em uma solução com fatores correlacionados, a parcela comum é

$$\widehat{\Phi}\widehat{\Omega}\widehat{\Phi}^{\top},$$

e a matriz reproduzida é obtida acrescentando $\widehat{\Psi}$, conforme a formulação oblíqua desenvolvida na Seção 15.10.

A reprodução da estrutura observada pode ser examinada pela diferença entre a matriz utilizada no ajuste e a matriz estimada pelo modelo.

Para uma análise baseada em covariâncias, a matriz de resíduos é

$$\mathbf{E}_S = \mathbf{S} - \widehat{\Sigma}_{\text{fat}}. \quad (15.58)$$

Para uma análise baseada em correlações,

$$\mathbf{E}_R = \mathbf{R} - \widehat{\mathcal{R}}_{\text{fat}}. \quad (15.59)$$

No modelo ortogonal, para $i \neq j$, o resíduo de uma covariância é

$$e_{S,ij} = s_{ij} - \sum_{h=1}^m \hat{\phi}_{ih} \hat{\phi}_{jh}.$$

Na análise baseada em correlações,

$$e_{R,ij} = r_{ij} - \sum_{h=1}^m \hat{\phi}_{ih} \hat{\phi}_{jh}.$$

Esses elementos mostram diretamente quais associações entre variáveis distintas não foram reproduzidas pela estrutura comum estimada.

Os elementos da diagonal avaliam a reprodução das variâncias. Seu comportamento depende do método de estimação e da forma como as especificidades são determinadas. Em procedimentos que completam a diagonal por

$$\hat{\psi}_i = s_{ii} - \hat{h}_i^2$$

ou, no caso padronizado,

$$\hat{\psi}_i = 1 - \hat{h}_i^2,$$

os resíduos diagonais são nulos por construção.

A matriz de resíduos também permite separar o papel da estimação do papel da rotação. Em uma rotação ortogonal,

$$\widehat{\Phi}^* = \widehat{\Phi} \mathbf{Q}$$

e, pela Equação 15.16,

$$\widehat{\Phi}^* \widehat{\Phi}^{*\top} = \widehat{\Phi} \widehat{\Phi}^\top.$$

A matriz reproduzida e a matriz de resíduos permanecem inalteradas. A rotação modifica a orientação das cargas, não o ajuste da estrutura reproduzida.

Na formulação oblíqua, a mesma conclusão vale quando cargas e correlações fatoriais são transformadas de forma compatível, preservando a parcela comum reproduzida.

Se o modelo populacional ortogonal com m fatores representa exatamente a estrutura de covariâncias,

$$\Sigma = \Phi\Phi^\top + \Psi,$$

a matriz residual populacional correspondente é nula.

Na amostra, resíduos diferentes de zero são esperados mesmo quando o modelo populacional está corretamente especificado, pois $\mathbf{S}$ e $\mathbf{R}$ variam entre amostras.

Resíduos amostrais também podem refletir limitações da estrutura especificada. Um número insuficiente de fatores, uma forma inadequada do modelo ou associações que não são representadas pela estrutura comum podem produzir padrões sistemáticos nos resíduos.

Por isso, a matriz residual deve ser interpretada como um diagnóstico da reprodução da estrutura observada. Um resíduo isolado não identifica, por si só, a causa de uma discrepância.

15.15.4 Critérios específicos de rotação

Depois que uma solução fatorial é obtida, diferentes critérios podem selecionar orientações que favoreçam uma estrutura mais simples. Esses critérios atuam sobre a representação das cargas e não constituem novos métodos de estimação.

As funções objetivo que definem Varimax, Quartimax, Oblimin e Promax são apresentadas na Seção 15.14.3. Nesta seção, o interesse é distinguir as consequências metodológicas desses critérios para a interpretação da solução.

A escolha da rotação deve ser distinguida da avaliação do ajuste. Uma transformação que preserva a estrutura comum reproduzida também preserva a matriz de resíduos, conforme mostrado na Seção 15.15.3. A rotação procura facilitar a interpretação da solução.

15.15.4.1 Critérios de rotação ortogonal

Nas rotações ortogonais, os fatores permanecem não correlacionados. Dois critérios clássicos diferem pelo aspecto da matriz de cargas que procuram simplificar.

O **Varimax** procura aumentar o contraste entre os quadrados das cargas dentro de cada fator. A solução tende a apresentar, em cada coluna da matriz de cargas, algumas cargas relativamente elevadas e outras pequenas. O critério favorece, assim, a identificação das variáveis mais associadas a cada fator (Johnson; Wichern, 2007; Kaiser, 1958).

O **Quartimax** enfatiza a simplificação das variáveis. A orientação favorece situações em que cada variável apresente carga relevante em um número reduzido de fatores (Lawley; Maxwell, 1971).

Varimax e Quartimax procuram uma estrutura simples por critérios diferentes. O Varimax enfatiza a separação das cargas dentro dos fatores; o Quartimax enfatiza a concentração das cargas de cada variável em poucas dimensões. Por isso, as duas rotações podem produzir interpretações diferentes para a mesma solução não rotacionada.

15.15.4.2 Critérios de rotação oblíqua

As rotações oblíquas permitem que os fatores resultantes sejam correlacionados. Entre os critérios usuais estão **Oblimin** e **Promax** (Hair et al., 2018).

O **Oblimin** procura uma estrutura simples sem impor ortogonalidade entre os fatores. Como os eixos podem deixar de ser perpendiculares, a interpretação da solução deve considerar conjuntamente a matriz de padrões, a matriz de estrutura e a matriz de correlações fatoriais apresentadas na Seção 15.10.

O **Promax** utiliza uma construção em etapas. Parte de uma solução inicialmente rotacionada, constrói uma estrutura-alvo com maior contraste entre cargas elevadas e pequenas e procura uma transformação oblíqua que se aproxime desse padrão (Hendrickson; White, 1964).

Oblimin e Promax pertencem à mesma classe geral de rotações oblíquas, mas utilizam critérios distintos para escolher a orientação final. Não são denominações diferentes para o mesmo procedimento.

15.15.4.3 Escolha da rotação

Não existe um critério de rotação que seja superior em todas as aplicações (Hair et al., 2018). A escolha entre rotação ortogonal e oblíqua depende da estrutura que se pretende admitir para os fatores. A rotação ortogonal fixa suas correlações em zero; a rotação oblíqua permite correlações fatoriais diferentes de zero, representadas por Ω na Seção 15.10.

A rotação oblíqua é apropriada quando o modelo admite correlações entre os fatores. Depois do ajuste, a matriz de correlações fatoriais mostra a magnitude dessas associações. Se essas correlações forem próximas de zero e a organização das cargas permanecer semelhante à obtida por uma rotação ortogonal, a solução ortogonal pode fornecer uma representação mais simples.

Também pode ser útil comparar mais de uma rotação. Se diferentes critérios conduzem a uma organização semelhante das cargas e à mesma interpretação dos fatores, a estrutura interpretada apresenta menor dependência de uma escolha rotacional específica (Johnson; Wichern, 2007).

A rotação não determina se a solução fatorial está correta. Ela seleciona uma representação entre soluções compatíveis com a estrutura estimada e deve ser interpretada em conjunto com a adequação do modelo, os resíduos e o significado das dimensões obtidas.

15.15.5 Diferentes métodos de escores fatoriais

O escore por regressão não é a única forma de atribuir coordenadas fatoriais às unidades observacionais. Como os fatores são latentes, métodos diferentes podem produzir valores distintos para uma mesma observação mesmo quando a solução fatorial permanece fixada (Johnson; Wichern, 2007).

As propriedades matemáticas dos principais critérios são desenvolvidas na Seção 15.14.8. Para a condução da análise, a escolha deve considerar a propriedade que se deseja preservar nos escores.

Tabela 15.6: Propriedades privilegiadas pelos métodos de escores fatoriais considerados no capítulo.

Método	Propriedade privilegiada	Consequência para o uso
Thurstone ou regressão	predição dos fatores a partir das variáveis observadas	no modelo normal ortogonal, corresponde à média condicional desenvolvida na Seção 15.14.7
Bartlett	minimização dos resíduos ponderados pelas variâncias específicas	variáveis com menor variância específica recebem maior peso relativo
ten Berge	preservação da estrutura de correlações fatoriais	permite que as correlações entre os escores reproduzam Ω em soluções oblíquas
Anderson–Rubin	obtenção de escores não correlacionados	é compatível com soluções em que os fatores são ortogonais
Harman	representação baseada em variáveis idealizadas da parcela comum	fornece uma construção alternativa sem impor as propriedades anteriores

O método por regressão é apropriado quando o objetivo principal é prever os fatores a partir das variáveis observadas. Bartlett utiliza explicitamente a estrutura das variâncias específicas e é sensível à diferença de precisão com que as variáveis representam a parcela comum.

O método de Anderson–Rubin produz escores não correlacionados. Essa propriedade é coerente com uma solução ortogonal, mas não reproduz a estrutura de uma solução oblíqua quando Ω possui elementos fora da diagonal diferentes de zero.

O método de ten Berge possui finalidade distinta: preservar nos escores a estrutura de correlações especificada para os fatores. Essa propriedade torna sua interpretação particularmente compatível com soluções oblíquas.

Os valores dos escores dependem do método utilizado. A escolha do método não modifica a matriz de cargas, as communalidades, as variâncias específicas ou a matriz de covariâncias reproduzida, pois os escores são construídos depois da obtenção da solução fatorial.

A interpretação dos fatores deve permanecer baseada principalmente na estrutura das cargas e em sua relação com as variáveis observadas. Os escores são utilizados para representar as unidades observacionais nas dimensões fatoriais e sua utilização posterior deve registrar o método empregado.

15.15.6 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise Fatorial Exploratória será realizada pela análise EFA do núcleo do [jamovi](#) (The jamovi project, 2026). As opções apresentadas pela implementação correspondem a etapas estatísticas distintas da análise.

Tabela 15.7: Correspondência entre opções da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Minimum residuals	estimação pelo critério MINRES	Seção 15.14.4
Principal axis	método de fatores ou eixos principais	Seção 15.14.4
Maximum likelihood	estimação sob o modelo fatorial normal	Seção 15.14.5
Based on parallel analysis, Based on eigenvalue e Fixed number	procedimentos para determinar ou fixar o número de fatores	Seção 15.15.2
KMO measure of sampling adequacy	KMO global e medidas individuais MSA_i	Seção 15.15.1
Bartlett's test of sphericity	estatística χ_B^2 , graus de liberdade e p -valor	Seção 15.15.1
Varimax, Quartimax, Oblimin e Promax	critérios de rotação desenvolvidos no capítulo	Seção 15.14.3 e Seção 15.15.4
Factor correlations	estimativa da matriz de correlações fatoriais $\hat{\Omega}$ em soluções oblíquas	Seção 15.10

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Thurstone, Bartlett, ten Berge, Anderson–Rubin e Harman	diferentes critérios para obtenção dos escores fatoriais	Seção 15.14.8 e Seção 15.15.5

A opção *Principal axis* não corresponde à Análise de Componentes Principais. Na ACP, a decomposição espectral atua sobre a matriz de covariâncias ou de correlações analisada. No método de fatores principais, a decomposição atua sobre uma matriz reduzida cuja diagonal contém comunalidades estimadas.

A implementação também oferece a rotação **Simplimax**. Esse critério não é desenvolvido neste capítulo. Sua presença na interface não modifica a distinção entre rotações ortogonais e oblíquas nem exige que todos os critérios disponíveis no software sejam incorporados à formulação da técnica.

Na saída de KMO, o valor global corresponde ao índice definido na Equação 15.55, enquanto os valores apresentados para cada variável correspondem às medidas MSA_i da Equação 15.54. O teste de Bartlett apresenta a estatística da Equação 15.56, seus graus de liberdade e o p -valor correspondente.

A opção *Factor correlations* é pertinente às rotações oblíquas e corresponde à estimativa de Ω . Nas rotações ortogonais, as correlações entre fatores são fixadas em zero pela própria parametrização.

A implementação também pode apresentar medidas de ajuste, incluindo estatística qui-quadrado, graus de liberdade, p -valor, RMSEA, TLI e BIC. A razão de verossimilhanças desenvolvida na Seção 15.14.5 corresponde especificamente à formulação por máxima verossimilhança. Medidas fornecidas pela implementação sob outros métodos de extração não devem ser identificadas automaticamente com essa mesma estatística inferencial.

Para os escores fatoriais, Thurstone corresponde ao escore por regressão desenvolvido na Seção 15.14.7. Bartlett, ten Berge, Anderson–Rubin e Harman correspondem aos critérios desenvolvidos na Seção 15.14.8. A escolha entre eles é discutida metodologicamente na Seção 15.15.5.

15.16 Síntese

A Análise Fatorial representa as covariâncias entre variáveis observadas por meio de um número menor de fatores latentes. No modelo ortogonal,

$$\mathbf{X} = \mu + \Phi\mathbf{F} + \varepsilon,$$

e

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A matriz $\Phi\Phi^\top$ contém a parcela comum das variâncias e covariâncias. A matriz diagonal Ψ contém as variâncias específicas. Para uma variável padronizada,

$$h_i^2 = \sum_{j=1}^m \phi_{ij}^2, \quad \psi_i = 1 - h_i^2.$$

As cargas determinam como cada variável se relaciona com os fatores. No modelo ortogonal com variáveis padronizadas, a carga ϕ_{ij} também é a correlação entre X_i e F_j .

A orientação dos fatores não é única. Rotações ortogonais preservam fatores não correlacionados e mantêm a parcela comum reproduzida. Rotações oblíquas permitem correlações entre os fatores. A rotação altera a representação das cargas, mas não substitui a estimação do modelo.

Na análise amostral, as cargas e as variâncias específicas são obtidas a partir da matriz de covariâncias ou de correlações observada. Fatores principais, MINRES e máxima verossimilhança utilizam critérios diferentes para obter a solução. A normalidade é uma hipótese adicional da formulação fatorial normal e não pertence à definição do modelo de segunda ordem.

Depois da estimação, a matriz reproduzida e os resíduos mostram quais covariâncias ou correlações foram representadas pelo modelo. O número de fatores altera a dimensão e a flexibilidade da estrutura comum estimada; a rotação seleciona uma orientação das cargas para interpretação sem substituir o critério de estimação.

Os fatores são variáveis latentes. Os escores fatoriais são valores calculados para representar as observações nas dimensões fatoriais. Como sua obtenção exige um critério adicional, métodos diferentes podem produzir escores diferentes para a mesma observação.

A ACP constrói combinações lineares para representar a variabilidade da matriz analisada, enquanto a Análise Fatorial especifica um modelo que separa variabilidade comum e específica.

Na Capítulo 16, o problema muda para a formação de grupos de observações. A Análise de Agrupamentos será formulada a partir de medidas de proximidade e de critérios que definem a semelhança entre observações e grupos.

16 Formulação da Análise de Agrupamentos

A Análise de Agrupamentos organiza objetos em grupos a partir de uma representação dos dados, de uma medida de proximidade e de um critério que define a organização procurada (Everitt et al., 2011).

Sua formulação reutiliza a matriz de dados de Definição 1.6, a distância euclidiana de Definição 1.13, as geometrias induzidas de Definição 3.17 e a decomposição da dispersão entre e dentro de grupos estabelecida em Proposição 8.10.

O núcleo desenvolve a representação dos objetos, as medidas de proximidade, as partições, a formulação das K -médias, os métodos hierárquicos, Ward, o dendrograma, diferentes definições matemáticas de grupo e os limites da análise. Os aprofundamentos teóricos desenvolvem propriedades das soluções e das funções objetivo, enquanto os aprofundamentos metodológicos e aplicados tratam de dados mistos, escolha do número de grupos e aspectos computacionais da obtenção das soluções.

Os elementos que definem o problema são organizados na Tabela 16.1.

Tabela 16.1: Elementos que definem um problema de Análise de Agrupamentos.

Elemento	Objeto	Papel na análise
Representação dos objetos	matriz de dados $\mathbf{X}$ ou matriz de dissimilaridades Δ	determina a informação disponível para comparar os objetos
Proximidade	distância, dissimilaridade ou similaridade	estabelece o significado de objetos próximos
Organização	partição $\mathcal{P}$ ou estrutura hierárquica	representa os grupos construídos
Critério	função de perda, dispersão ou ligação	permite comparar diferentes organizações
Solução	grupos de objetos	resulta da otimização ou da regra de construção adotada

A mesma coleção de observações pode produzir agrupamentos diferentes quando um desses elementos é alterado. Por isso, a Análise de Agrupamentos não possui uma definição universal de grupo independente da representação, da proximidade e do critério utilizado.

16.1 O problema de formação de grupos

Considere n objetos representados pelas linhas da matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

conforme Definição 1.6.

Os grupos não são conhecidos previamente. O objetivo é construir uma organização dos índices das observações segundo a representação dos objetos, a medida de proximidade e o critério adotado.

O significado de pertencer ao mesmo grupo depende desse critério. Nas K -médias, os grupos são definidos pela concentração das observações em torno de centroides; nos métodos hierárquicos, pela regra utilizada para comparar e reunir conjuntos de objetos.

Essa formulação distingue a Análise de Agrupamentos da Capítulo 19. Na Análise de Agrupamentos, a própria organização dos objetos faz parte da solução; na Análise Discriminante, os grupos são conhecidos previamente e integram a informação utilizada pela técnica.

A Figura 16.1 mostra uma mesma configuração bidimensional organizada de duas formas. A figura ilustra que os pontos observados, isoladamente, não determinam qual partição deve ser escolhida.

As duas organizações mantêm os mesmos pontos e alteram somente a regra utilizada para reuni-los. A figura representa uma característica da técnica: a estrutura de grupos deve ser interpretada em relação ao critério que a produziu.

16.2 Representação dos objetos e proximidade

A matriz de dados não é a única forma de entrada da Análise de Agrupamentos. Quando as coordenadas dos objetos estão disponíveis, a proximidade pode ser calculada a partir das linhas de $\mathbf{X}$. Quando as relações entre os objetos já são fornecidas diretamente, a análise pode partir de uma matriz de dissimilaridades.

A distância euclidiana já foi definida em Definição 1.13. Para duas observações $\mathbf{x}_i$ e $\mathbf{x}_j$, utilizaremos diretamente

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|.$$




Figura 16.1: Diferentes partições de uma mesma configuração de observações.

Não é necessário reconstruir suas propriedades métricas neste capítulo. O resultado será aplicado para definir a geometria de métodos como as K -médias e o método de Ward.

Pela Definição 3.17, uma matriz positiva definida determina uma geometria ponderada para comprimentos e distâncias. Diferentes escolhas dessa geometria podem atribuir proximidades diferentes ao mesmo conjunto de observações. A distância de Mahalanobis, definida em Definição 8.9, é uma aplicação estatística dessa construção.

A Análise de Agrupamentos também pode receber como entrada uma matriz

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

na qual δ_{ij} representa a dissimilaridade entre os objetos i e j .

16.3 Dissimilaridades entre objetos

Definição 16.1 (Dissimilaridade). Seja

$$\mathcal{J} = \{1, \dots, n\}$$

um conjunto de objetos. Uma **dissimilaridade** é uma função

$$\delta : \mathcal{I} \times \mathcal{I} \longrightarrow [0, \infty),$$

na qual valores maiores representam menor proximidade entre os objetos.

Neste capítulo, serão consideradas dissimilaridades que satisfazem

$$\delta(i, i) = 0, \quad i \in \mathcal{I},$$

e

$$\delta(i, j) = \delta(j, i), \quad i, j \in \mathcal{I}.$$

Não será exigido que

$$\delta(i, j) > 0 \quad \text{para} \quad i \neq j,$$

nem que seja satisfeita a desigualdade triangular.

A matriz associada a δ é

$$\Delta = (\delta_{ij}), \quad \delta_{ij} = \delta(i, j).$$

Assim, uma distância métrica pode ser utilizada como dissimilaridade, mas uma dissimilaridade não precisa satisfazer todas as propriedades exigidas de uma distância métrica (Everitt et al., 2011).

De forma correspondente, uma similaridade atribui valores maiores a objetos considerados mais semelhantes. A transformação entre similaridade e dissimilaridade depende da medida adotada e não constitui uma operação universal.

A distinção entre matriz de atributos e matriz de dissimilaridades é sintetizada na Tabela 16.2.

Tabela 16.2: Formas de representação utilizadas na Análise de Agrupamentos.

Representação	Informação disponível	Consequência para a formulação
$\mathbf{X} \in \mathbb{R}^{n \times p}$	valores das p variáveis para cada objeto	a proximidade é construída a partir das coordenadas
$\Delta \in \mathbb{R}^{n \times n}$	dissimilaridades entre pares de objetos	o agrupamento pode ser formulado diretamente sobre as relações entre objetos

A escolha entre essas representações também delimita os métodos disponíveis. O critério das K -médias utiliza explicitamente centroides no espaço das variáveis e requer as coordenadas das observações. Métodos hierárquicos podem ser formulados diretamente a partir de uma matriz de dissimilaridades, desde que a regra de ligação seja compatível com a informação disponível.

A presença de uma medida de dissimilaridade não significa que ela possa substituir livremente a distância euclidiana quadrática na formulação das K -médias. O centroide é o representante ótimo de um grupo porque a média minimiza a soma das distâncias euclidianas quadráticas às observações. Ao modificar essa função de perda, podem mudar o representante ótimo do grupo, a função objetivo e a própria definição do método. Por isso, procedimentos construídos a partir de outras dissimilaridades devem ser identificados pela formulação que efetivamente utilizam.

16.3.1 Efeito da escala

Pela Definição 1.13, a contribuição de cada coordenada para a distância depende de sua escala. A padronização observada é dada em Equação 8.69. Na Análise de Agrupamentos, padronizar as variáveis modifica as proximidades e pode alterar os grupos obtidos.

A Figura 16.2 mostra essa consequência para uma configuração bidimensional. A figura não redefine a padronização; ela mostra seu efeito sobre o problema de agrupamento.




Figura 16.2: Mudanças de escala alteram a geometria utilizada para comparar as observações.

A ampliação da segunda coordenada aumenta sua contribuição para as distâncias. Um método baseado nessas distâncias passa a comparar os mesmos objetos segundo outra geometria.

A padronização deve ser entendida da mesma forma. Ela não constitui uma exigência geral da Análise de Agrupamentos. Sua utilização altera a contribuição relativa das variáveis e, portanto, altera o problema geométrico resolvido pelo método.

16.4 Partições

Uma das formas mais comuns de representar um agrupamento é por meio de uma partição rígida do conjunto de objetos.

Seja

$$\mathcal{I} = \{1, \dots, n\}$$

o conjunto dos índices das observações.

Definição 16.2 (Partição em grupos). Uma **partição em K grupos** é uma coleção

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

de subconjuntos não vazios de $\mathcal{I}$ que satisfaz

$$C_k \cap C_\ell = \emptyset, \quad k \neq \ell,$$

e

$$\bigcup_{k=1}^K C_k = \mathcal{I}.$$

As duas condições estabelecem que:

- um objeto não pertence simultaneamente a dois grupos distintos;
- todos os objetos são atribuídos a algum grupo.

O número de elementos do grupo C_k será denotado por

$$n_k = |C_k|,$$

com

$$\sum_{k=1}^K n_k = n.$$

A partição é um objeto combinatório. Ela informa quais observações pertencem ao mesmo grupo, mas não determina sozinha o critério utilizado para obtê-la.

Uma representação equivalente pode ser construída por indicadores de pertinência,

$$u_{ik} = \begin{cases} 1, & i \in C_k, \\ 0, & i \notin C_k. \end{cases}$$

Para uma partição rígida,

$$\sum_{k=1}^K u_{ik} = 1, \quad i = 1, \dots, n. \quad (16.1)$$

16.4.1 Outras formas de pertinência

A partição rígida não é a única forma de representar a associação entre objetos e grupos. Métodos difusos podem atribuir graus de pertencimento a diferentes grupos, enquanto formulações probabilísticas podem associar probabilidades de pertinência às observações.

Essas representações correspondem a definições distintas de grupo. O desenvolvimento principal deste capítulo utilizará partições rígidas, pois elas fornecem a estrutura empregada nas K -médias e nos métodos hierárquicos. Uma definição probabilística de grupo é apresentada na Seção 16.8.

16.5 Homogeneidade interna e separação

Uma partição só pode ser comparada com outras partições depois que se estabelece um critério de agrupamento.

Considere

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Alguns critérios avaliam diretamente a dispersão dentro dos grupos; outros utilizam relações de proximidade entre observações ou entre conjuntos de observações. A separação entre grupos pode resultar dessas construções sem constituir uma parcela explícita da função objetivo.

Nas K -médias, o critério é a dispersão quadrática intragrupos. A relação com a dispersão entre grupos é dada por Proposição 8.10.

A caracterização da média como centroide e como minimizadora da soma das distâncias euclidianas quadráticas já foi estabelecida em Proposição 10.5. Essa propriedade será aplicada a cada grupo da partição.

16.6 Agrupamento por centroides

Uma partição pode ser representada geometricamente por um ponto que resume cada grupo. Para

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

com

$$n_k = |C_k|,$$

o **centroide** do grupo C_k será denotado por

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i. \quad (16.2)$$

A notação $\mathbf{c}_k$ distingue o centro calculado a partir das observações de um vetor de médias populacional μ_k .

No agrupamento por centroides, a proximidade entre uma observação e um grupo é determinada por sua distância ao centro correspondente. Essa representação permite definir critérios baseados na dispersão das observações em torno dos centroides.

16.6.1 Dispersão dentro e entre grupos

A Definição 8.14 e a Definição 8.15 definem as matrizes de dispersão dentro e entre grupos, e a Proposição 8.10 estabelece

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Nesses resultados, os grupos são dados. Na Análise de Agrupamentos, a mesma decomposição assume outra função: a partição é desconhecida e passa a integrar o problema de otimização.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

a matriz intragrupos pode ser escrita, utilizando os centroides de Equação 16.2, como

$$\mathbf{T}_{\text{intra}}(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} (\mathbf{x}_i - \mathbf{c}_k)(\mathbf{x}_i - \mathbf{c}_k)^\top. \quad (16.3)$$

Tomando o traço,

$$\begin{aligned} \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})] &= \sum_{k=1}^K \sum_{i \in C_k} \text{tr}[(\mathbf{x}_i - \mathbf{c}_k)(\mathbf{x}_i - \mathbf{c}_k)^\top] \\ &= \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \end{aligned} \quad (16.4)$$

A expressão em Equação 16.4 transforma a matriz intragrupos definida em Definição 8.14 em um critério escalar para comparar partições.

Quanto menores forem as distâncias quadráticas das observações aos centroides de seus grupos, menor será

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Como a matriz total $\mathbf{T}$ não depende da partição e

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue também que

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (16.5)$$

Para K fixado, reduzir a dispersão intragrupos aumenta a parcela da dispersão atribuída aos centroides dos grupos em relação ao centroide global. Essa relação fornece a formulação utilizada pelas K -médias.

16.6.2 Formulação das K -médias

O método das K -médias define os grupos pela minimização da soma das distâncias euclidianas quadráticas das observações aos centroides correspondentes (MacQueen, 1967).

Definição 16.3 (Critério das K -médias). Para um número fixado de grupos K , com

$$1 \leq K \leq n,$$

considere os indicadores de pertinência u_{ik} e os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p.$$

O critério conjunto das K -médias é

$$Q_K(\{u_{ik}\}, \mathbf{c}_1, \dots, \mathbf{c}_K) = \sum_{i=1}^n \sum_{k=1}^K u_{ik} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.6)$$

sujeito a

$$u_{ik} \in \{0, 1\},$$

$$\sum_{k=1}^K u_{ik} = 1, \quad i = 1, \dots, n,$$

e

$$\sum_{i=1}^n u_{ik} \geq 1, \quad k = 1, \dots, K.$$

As duas primeiras restrições estabelecem uma atribuição rígida: u_{ik} é binário e cada observação pertence a exatamente um dos K grupos. A terceira restrição garante que todos os K grupos sejam não vazios.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

o critério após a minimização em relação aos centros é

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.7)$$

em que

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i.$$

A propriedade de que esses centroides minimizam o critério para uma partição fixada decorre diretamente de Proposição 10.5.

Uma **solução global** das K -médias é qualquer partição

$$\mathcal{P}^* \in \arg \min_{\mathcal{P} \in \mathcal{A}_K} J_K(\mathcal{P}), \quad (16.8)$$

em que $\mathcal{A}_K$ é o conjunto das partições de $\{1, \dots, n\}$ em exatamente K grupos não vazios.

A existência e a possível não unicidade dessa solução são desenvolvidas na Seção 16.12.2.

Pela relação em Equação 16.4,

$$J_K(\mathcal{P}) = \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})]. \quad (16.9)$$

Nas K -médias, a estrutura de Definição 8.14 e Proposição 8.10 é aplicada a uma partição desconhecida, que passa a integrar o problema de otimização.

A partir de Equação 16.5,

$$J_K(\mathcal{P}) = \text{tr}(\mathbf{T}) - \text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})].$$

Como

$$\text{tr}(\mathbf{T})$$

é constante para a mesma matriz de dados, minimizar o critério das K -médias equivale a maximizar

$$\text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})]. \quad (16.10)$$

Como a dispersão entre grupos pode ser escrita em função dos centroides e de seus tamanhos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\mathbf{c}_k - \bar{\mathbf{x}}) (\mathbf{c}_k - \bar{\mathbf{x}})^\top,$$

tem-se

$$\text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\mathbf{c}_k - \bar{\mathbf{x}}\|^2. \quad (16.11)$$

Para a mesma matriz de dados e um valor fixado de K ,

$$\text{tr}(\mathbf{T})$$

é constante entre as partições admissíveis. Assim, uma partição minimiza

$$\text{tr}(\mathbf{T}_{\text{intra}})$$

se, e somente se, maximiza

$$\text{tr}(\mathbf{T}_{\text{entre}}).$$

As duas formulações caracterizam, portanto, o mesmo problema de otimização das K -médias para K fixado.

16.6.3 Partição para centroides fixados

Considere os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K$$

como fixados. Desconsiderando momentaneamente a restrição de não vacuidade dos grupos, a contribuição de uma observação $\mathbf{x}_i$ ao critério é minimizada atribuindo-a a um centro pertencente a

$$\arg \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.12)$$

Assim, cada observação é associada a um centroide de menor distância. Em caso de empate, mais de uma atribuição pode produzir a mesma contribuição mínima.

Quando essa regra produz K grupos não vazios, ela também minimiza o critério entre as atribuições admissíveis para os centroides fixados. Se algum centro não receber observações, a restrição de não vacuidade impede que o subproblema restrito seja resolvido apenas pela minimização ponto a ponto. O tratamento computacional desses casos pertence à etapa de implementação e não será desenvolvido neste capítulo.

Essa propriedade, combinada ao fato de que o centróide minimiza a soma de quadrados para uma partição fixada, caracteriza a estrutura de otimização associada ao critério das K -médias.

16.6.4 Geometria das regiões de alocação

Para centroides fixados, a regra em Equação 16.12 divide o espaço em regiões formadas pelos pontos mais próximos de cada centróide.

Para dois centroides $\mathbf{c}_k$ e $\mathbf{c}_\ell$, a fronteira entre suas regiões satisfaz

$$\|\mathbf{x} - \mathbf{c}_k\|^2 = \|\mathbf{x} - \mathbf{c}_\ell\|^2.$$

Expandindo os produtos internos e cancelando os termos comuns, obtém-se

$$2(\mathbf{c}_\ell - \mathbf{c}_k)^\top \mathbf{x} = \mathbf{c}_\ell^\top \mathbf{c}_\ell - \mathbf{c}_k^\top \mathbf{c}_k. \quad (16.13)$$

A fronteira é, portanto, um hiperplano.

As regiões definidas simultaneamente por todos os centroides formam uma partição de Voronoi do espaço. Uma região de Voronoi pode não conter nenhuma das observações disponíveis para uma determinada configuração de centros; isso não altera sua definição geométrica.

Essa geometria explica por que as K -médias favorecem grupos associados a regiões convexas em torno de centros.

A Figura 16.3 representa uma solução com três centroides. As regiões de fundo indicam qual centróide é o mais próximo em cada posição do plano, enquanto os símbolos maiores identificam os centroides da solução.

A figura mostra duas propriedades da formulação. Cada grupo é representado por um centróide, e a alocação é determinada pela geometria euclidiana relativa a esses centros. A forma dos grupos obtidos pelo critério está vinculada a essa representação.

Exemplo 16.1 (Comparação de duas partições). Considere quatro observações unidimensionais,

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 8, \quad x_4 = 9,$$

e duas partições candidatas com




Figura 16.3: Centroides e regiões de alocação definidas pela distância euclidiana.

$$K = 2.$$

Na primeira,

$$\mathcal{P}_1 = \{\{1, 2\}, \{3, 4\}\}.$$

Os centroides são

$$c_1 = 1,5$$

e

$$c_2 = 8,5.$$

Logo,

$$\begin{aligned} J_2(\mathcal{P}_1) &= (1 - 1,5)^2 + (2 - 1,5)^2 \\ &\quad + (8 - 8,5)^2 + (9 - 8,5)^2 \\ &= 1. \end{aligned}$$

Considere agora

$$\mathcal{P}_2 = \{\{1, 3\}, \{2, 4\}\}.$$

Os centroides são

$$c_1 = 4,5$$

e

$$c_2 = 5,5.$$

Nesse caso,

$$\begin{aligned} J_2(\mathcal{P}_2) &= (1 - 4,5)^2 + (8 - 4,5)^2 \\ &\quad + (2 - 5,5)^2 + (9 - 5,5)^2 \\ &= 49. \end{aligned}$$

O critério atribui valor menor à primeira partição porque as observações estão mais concentradas em torno dos respectivos centroides.

A comparação entre as partições é determinada pela soma das dispersões quadráticas dentro dos grupos. Distâncias elevadas entre alguns pares de observações, isoladamente, não definem a solução.

A formulação por centroides caracteriza grupos pela concentração quadrática em torno de centros. Os métodos hierárquicos utilizam outra estrutura: constroem uma sequência de agrupamentos aninhados a partir de regras de proximidade entre conjuntos.

16.7 Estrutura dos métodos hierárquicos

As K -médias procuram diretamente uma partição para um número K previamente fixado de grupos. Os métodos hierárquicos produzem outro objeto: uma sequência de partições aninhadas, na qual a organização dos grupos é construída progressivamente (Everitt et al., 2011).

Os métodos hierárquicos podem ser aglomerativos ou divisivos. Nos procedimentos **aglomerativos**, grupos menores são sucessivamente reunidos; nos **divisivos**, grupos maiores são progressivamente subdivididos. O desenvolvimento deste capítulo será concentrado nos métodos aglomerativos.

A construção depende de dois elementos distintos: uma medida de dissimilaridade entre os objetos e uma **regra de ligação** que estende essa dissimilaridade para pares de grupos. É a regra de ligação que define matematicamente quais grupos são considerados mais próximos em cada etapa. O dendrograma registra a hierarquia produzida por essas fusões.

Em um procedimento aglomerativo, parte-se da partição formada por n grupos unitários,

$$\mathcal{P}_n = \{\{1\}, \dots, \{n\}\},$$

e, a cada etapa, dois grupos são fundidos. Após uma fusão, obtém-se uma nova partição com um grupo a menos, até chegar a

$$\mathcal{P}_1 = \{\{1, \dots, n\}\}.$$

As partições sucessivas são aninhadas: um grupo formado em determinada etapa permanece contido em algum grupo das etapas posteriores.

Definição 16.4 (Hierarquia de agrupamentos). Uma **hierarquia aglomerativa** é uma sequência de partições

$$\mathcal{P}_n, \mathcal{P}_{n-1}, \dots, \mathcal{P}_1,$$

na qual $\mathcal{P}_{r-1}$ é obtida de $\mathcal{P}_r$ pela fusão de exatamente dois grupos.

A construção da hierarquia exige uma regra para comparar grupos. A Definição 1.13 e a geometria de Definição 3.17 definem proximidades entre observações; no agrupamento hierárquico, a regra de ligação estende essa informação a pares de grupos.

Considere dois grupos não vazios

$$A \subseteq \{1, \dots, n\}$$

e

$$B \subseteq \{1, \dots, n\}.$$

Uma **regra de ligação** define uma dissimilaridade

$$D(A, B)$$

entre esses grupos. Não existe uma única extensão obrigatória da dissimilaridade entre objetos para a comparação entre conjuntos. Diferentes regras utilizam informações distintas sobre os elementos de A e B e, por isso, podem produzir hierarquias diferentes mesmo quando partem da mesma matriz Δ .

A regra de ligação integra a definição matemática do método hierárquico. Alterá-la pode produzir outra hierarquia mesmo quando a matriz de dissimilaridades permanece a mesma.

16.7.1 Ligações simples, completa e média

Três regras podem ser construídas diretamente a partir das dissimilaridades entre pares de objetos.

Na **ligação simples**,

$$D_{\text{simples}}(A, B) = \min_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.14)$$

A proximidade entre os grupos é determinada pelo par mais próximo. A fusão pode, portanto, ocorrer quando existe uma conexão curta entre dois conjuntos, mesmo que outros elementos estejam relativamente afastados.

Na **ligação completa**,

$$D_{\text{completa}}(A, B) = \max_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.15)$$

A comparação é determinada pelo par mais distante. Essa definição favorece fusões nas quais todos os elementos dos dois grupos permanecem relativamente próximos.

Na **ligação média**,

$$D_{\text{media}}(A, B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} \delta_{ij}. \quad (16.16)$$

A dissimilaridade entre os grupos corresponde à média das dissimilaridades entre todos os pares formados por um elemento de A e um elemento de B .

As três regras utilizam a mesma matriz de dissimilaridades, mas representam noções distintas de proximidade entre conjuntos.

A Tabela 16.3 compara as três definições de proximidade entre grupos.

Tabela 16.3: Critérios de ligação construídos a partir das dissimilaridades entre objetos.

Regra de ligação	Dissimilaridade entre A e B	Estrutura privilegiada
simples	menor dissimilaridade entre pares	conexão entre elementos próximos
completa	maior dissimilaridade entre pares	controle da maior dissimilaridade entre os grupos candidatos à fusão
média	média das dissimilaridades entre pares	proximidade média entre os conjuntos

A diferença entre os critérios pode ser observada mesmo com poucos objetos. Considere dois grupos

$$A = \{1, 2\}$$

e

$$B = \{3, 4\},$$

com dissimilaridades entre seus elementos dadas por

$$\delta_{13} = 2, \quad \delta_{14} = 8, \quad \delta_{23} = 3, \quad \delta_{24} = 7.$$

Então,

$$D_{\text{simples}}(A, B) = 2,$$

$$D_{\text{completa}}(A, B) = 8$$

e

$$D_{\text{media}}(A, B) = \frac{2 + 8 + 3 + 7}{4} = 5.$$

Não há contradição entre os três resultados. Cada valor responde a uma definição diferente da proximidade entre grupos.

16.7.2 Método de Ward e dispersão intragrupos

O método de Ward utiliza um critério de fusão baseado na dispersão quadrática intragrupos. Na formulação desenvolvida neste capítulo, os objetos possuem coordenadas em um espaço euclidiano e, em cada etapa da hierarquia, são comparados os aumentos de dispersão produzidos pelas fusões possíveis (Johnson; Wichern, 2007; Ward, 1963).

Essa interpretação utiliza a matriz $\mathbf{T}_{\text{intra}}$ definida em Definição 8.14 e a decomposição estabelecida em Proposição 8.10.

Proposição 16.1 (Incremento de dispersão no método de Ward). *Para dois grupos não vazios A e B , com tamanhos n_A e n_B e centroides $\mathbf{c}_A$ e $\mathbf{c}_B$, a fusão aumenta a soma de quadrados intragrupos em*

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2. \quad (16.17)$$

O método de Ward seleciona, em cada etapa, uma fusão que produz o menor aumento em

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

A expressão em Equação 16.17 combina a separação entre os centroides com os tamanhos dos grupos.

Ward e K -médias utilizam a dispersão quadrática intragrupos, mas resolvem problemas diferentes.

Nas K -médias, para K fixado, a solução global é definida por

$$\arg \min_{\mathcal{P} \in \mathcal{A}_K} \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})].$$

No método de Ward, a hierarquia é construída sequencialmente. Em cada etapa, entre as fusões disponíveis, são reunidos os dois grupos que produzem o menor aumento da dispersão intragrupos (Johnson; Wichern, 2007; Ward, 1963).

Uma fusão realizada em uma etapa não é desfeita posteriormente. Por isso, cortar o dendrograma de Ward em K grupos não equivale, em geral, a resolver o problema global das K -médias para esse mesmo valor de K .

A Figura 16.4 representa a diferença conceitual entre ligação simples, ligação completa e Ward para dois grupos.

Na ligação simples, apenas o par mais próximo determina a comparação. Na ligação completa, utiliza-se o par mais afastado. Em Ward, a distância entre centroides participa de uma expressão ponderada pelos tamanhos dos grupos e determina o aumento produzido na dispersão intragrupos.

A ligação média não aparece na figura porque utiliza simultaneamente todos os pares entre os dois grupos e não pode ser representada por um único segmento.

16.7.3 Dendrograma e níveis de fusão

A sequência produzida por um método hierárquico pode ser representada por um dendrograma.

Definição 16.5 (Dendrograma). Um **dendrograma** é uma representação gráfica de uma hierarquia de agrupamentos na qual as folhas representam os objetos e as alturas das junções registram os níveis associados às fusões entre grupos.




Figura 16.4: Diferentes critérios utilizam diferentes características para medir a proximidade entre dois grupos.

O dendrograma representa a sequência de partições aninhadas produzida pelo método. Uma partição com determinado número de grupos pode ser associada a uma etapa da hierarquia e, quando os níveis de fusão permitem essa separação, representada por um corte horizontal.

Um corte horizontal do dendrograma seleciona uma das partições contidas na hierarquia, mas não estabelece, por si só, que essa partição seja preferível às demais. O dendrograma representa a estrutura das fusões produzidas pelo método; a escolha de uma partição específica constitui uma decisão adicional.

A escolha do número de grupos e os critérios auxiliares utilizados nessa decisão são tratados na Seção 16.13.2.

A Figura 16.5 apresenta uma hierarquia simples construída a partir de seis objetos.

O significado do eixo vertical do dendrograma depende da regra de ligação. Na ligação simples, a altura registra a dissimilaridade associada à fusão. No método de Ward, ela está associada ao aumento da dispersão intragrupos, e sua escala pode depender da convenção utilizada na implementação.

Alturas de dendrogramas produzidos por critérios diferentes não precisam representar a mesma quantidade.




Figura 16.5: Representação hierárquica das fusões entre seis objetos. A altura registra o nível da fusão.

16.7.4 Uma partição e uma hierarquia representam objetos diferentes

As K -médias produzem diretamente uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um método hierárquico produz uma coleção ordenada de partições aninhadas.

Essa diferença modifica o tipo de informação fornecida pela técnica e é sintetizada na Tabela 16.4.

Tabela 16.4: Estruturas produzidas por diferentes formulações de agrupamento.

Estrutura	Resultado principal	Critério
K -médias	uma partição para K fixado	minimização da dispersão quadrática intragrupos
ligação simples	uma hierarquia	menor dissimilaridade entre grupos
ligação completa	uma hierarquia	maior dissimilaridade entre grupos
ligação média	uma hierarquia	média das dissimilaridades entre grupos
Ward	uma hierarquia	menor aumento da dispersão intragrupos

A existência de diferentes critérios mostra que “grupo” não corresponde a um único objeto matemático.

Nas K -médias, um grupo é representado por proximidade a um centroide. Na ligação simples, a formação de grupos depende da conectividade produzida por pares próximos. Na ligação completa, controla-se a maior dissimilaridade entre elementos de grupos candidatos à fusão. Na ligação média, considera-se conjuntamente o conjunto de dissimilaridades entre os dois grupos. Em Ward, a fusão é avaliada por seu efeito sobre a dispersão quadrática intragrupos.

Além disso, uma partição selecionada de uma hierarquia não precisa coincidir com a solução obtida pela otimização direta de um critério para o mesmo número de grupos. A hierarquia conserva as fusões realizadas anteriormente e, portanto, restringe as partições que podem aparecer nas etapas posteriores.

Além dessas formulações geométricas, grupos também podem ser definidos probabilisticamente como componentes de uma distribuição. Essa definição probabilística é apresentada na Seção 16.8.

16.8 Diferentes definições matemáticas de grupo

As formulações anteriores mostram que a expressão **grupo** não identifica um único objeto matemático. Nas K -médias, um grupo é organizado em torno de um centroide; nos métodos hierárquicos, sua formação depende de uma regra de ligação e da sequência de fusões.

Uma formulação diferente pode ser construída por meio de um modelo probabilístico (Everitt et al., 2011). Considere uma variável categórica latente

$$C \in \{1, \dots, K\},$$

com

$$P(C = k) = \pi_k, \quad \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Se, condicionalmente a $C = k$, o vetor aleatório $\mathbf{X}$ possui densidade

$$f_k(\mathbf{x}; \theta_k),$$

então, pela lei da probabilidade total,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k). \quad (16.18)$$

Definição 16.6 (Modelo de mistura para agrupamento). Um **modelo de mistura para agrupamento** representa a distribuição das observações como uma combinação de K componentes probabilísticas,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k).$$

Nessa formulação, o grupo é representado pela componente associada à variável latente categórica C . O conceito de grupo é, portanto, diferente daquele definido por proximidade a centroides ou por regras de ligação.

Para um valor $\mathbf{x}$ tal que

$$f(\mathbf{x}) > 0,$$

a associação às componentes pode ser descrita pelas probabilidades posteriores

$$P(C = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x}; \theta_k)}{\sum_{\ell=1}^K \pi_\ell f_\ell(\mathbf{x}; \theta_\ell)}. \quad (16.19)$$

Diferentemente de uma partição rígida, na qual cada objeto pertence a um único grupo, o modelo de mistura pode associar a mesma observação a diferentes componentes com probabilidades distintas. Uma partição rígida pode ser obtida posteriormente, por exemplo, atribuindo cada observação à componente de maior probabilidade posterior.

A normalidade multivariada não é necessária para definir um modelo de mistura em geral. Ela aparece apenas quando as densidades componentes são escolhidas como normais multivariadas.

Outras classes de métodos podem definir grupos por conectividade ou por regiões de elevada concentração. Essas formulações serão apenas mencionadas neste livro; seu desenvolvimento metodológico e computacional pertence à etapa aplicada.

16.9 Dependência da solução e limites da formulação

A Análise de Agrupamentos não possui um conjunto único de pressupostos probabilísticos. As K -médias e os métodos hierárquicos desenvolvidos neste capítulo podem ser formulados geometricamente, sem hipótese de normalidade multivariada ou de um modelo probabilístico gerador. Quando um modelo de mistura é utilizado, as hipóteses das distribuições componentes passam a integrar a formulação.

A solução depende das escolhas que definem o problema. A Tabela 16.5 resume essas dependências.

Tabela 16.5: Elementos dos quais depende uma solução de agrupamento.

Elemento modificado	Estrutura alterada	Consequência possível
conjunto de variáveis	representação dos objetos	proximidades e grupos podem mudar
escala das variáveis	geometria do espaço	variáveis recebem pesos relativos diferentes
métrica ou dissimilaridade	relação de proximidade	pares considerados próximos podem mudar
número K	conjunto de soluções consideradas	muda o problema formulado
função objetivo	definição de homogeneidade	muda a estrutura procurada
regra de ligação	proximidade entre grupos	muda a hierarquia

Adicionar, retirar ou transformar variáveis modifica a representação dos objetos e pode alterar as relações de proximidade. Mudanças de escala e de métrica modificam a geometria utilizada para compará-los.

Observações muito afastadas das demais também podem alterar a solução. Nas K -médias, elas podem deslocar centroides e aumentar fortemente a dispersão quadrática; nos métodos hierárquicos, podem modificar as proximidades e a sequência de fusões. Como as fusões realizadas por um procedimento aglomerativo não são desfeitas, seus efeitos podem permanecer nas etapas posteriores da hierarquia (Hair et al., 2018; Johnson; Wichern, 2007).

A forma de grupo procurada também depende do critério. As K -médias representam grupos por centroides e minimizam dispersão quadrática intragrupos. As ligações simples, completa e média utilizam diferentes definições de proximidade entre conjuntos. O método de Ward seleciona fusões segundo o aumento da dispersão intragrupos. Em modelos de mistura, os grupos correspondem a componentes de uma distribuição especificada.

A solução pode não ser única. Nas K -médias, diferentes partições podem atingir o mesmo mínimo; nos métodos hierárquicos, empates podem produzir diferentes sequências de fusões. Além disso, os rótulos atribuídos aos grupos são arbitrários.

Os pressupostos e os limites devem, portanto, ser interpretados relativamente à formulação utilizada. A representação dos objetos, a proximidade e o critério de agrupamento fazem parte da própria definição do problema.

16.10 Limites da interpretação dos grupos

A Análise de Agrupamentos é uma técnica não supervisionada: os rótulos dos grupos não são conhecidos previamente.

Uma solução obtida por K -médias, por um método hierárquico ou por um modelo de mistura descreve uma organização dos objetos segundo a formulação adotada. A existência dessa solução não demonstra que os dados tenham sido gerados por populações distintas.

Solução de agrupamento e categorias externas

Uma solução de agrupamento organiza os objetos segundo as variáveis, a medida de proximidade e o critério utilizados. Essa solução não estabelece, por si só, correspondência com categorias definidas por informações externas ao procedimento de agrupamento. Essa correspondência deve ser examinada utilizando variáveis que não participaram da formação dos grupos ou outras informações externas ao procedimento.

16.11 Relações com outras técnicas multivariadas

A Análise de Agrupamentos compartilha alguns objetos matemáticos com outras técnicas do módulo, mas atribui a eles funções diferentes. A Tabela 16.6 resume essas relações.

Tabela 16.6: Relações entre a Análise de Agrupamentos e outras técnicas multivariadas.

Técnica relacionada	Estrutura compartilhada	Diferença principal
ACP	representação geométrica das observações	ACP constrói direções de variabilidade; Agrupamentos constrói grupos
Análise Discriminante	grupos, médias e dispersões	Agrupamentos constrói grupos; Discriminante utiliza grupos conhecidos
MANOVA	dispersão dentro e entre grupos	Agrupamentos utiliza a dispersão para construir grupos; MANOVA utiliza grupos definidos pelo delineamento para testar efeitos

16.11.1 Agrupamentos e ACP

No Capítulo 14, a ACP produz novas coordenadas para as observações. Quando todas as componentes de uma transformação ortogonal são mantidas, as distâncias euclidianas são preservadas por Proposição 4.10.

Quando apenas $k < p$ componentes são mantidas, as observações são projetadas sobre o subespaço principal de Definição 14.2. As distâncias passam, então, a ser calculadas na representação reduzida e podem diferir das distâncias no espaço original.

Assim, utilizar ACP antes de uma Análise de Agrupamentos modifica o problema sempre que ocorre redução efetiva de dimensão ou mudança prévia da representação dos dados.

16.11.2 Agrupamentos e Análise Discriminante

Na Análise de Agrupamentos, os grupos fazem parte da solução. No Capítulo 19, os grupos são conhecidos previamente e fazem parte da informação utilizada para construir direções de separação ou regras de classificação.

As duas técnicas podem utilizar médias, dispersões e distâncias, mas esses objetos possuem funções estatísticas distintas conforme o problema considerado.

16.11.3 Agrupamentos e MANOVA

A conexão com o Capítulo 18 aparece na decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

estabelecida em Proposição 8.10.

Nas K -médias, a partição é desconhecida e procura-se reduzir

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Na MANOVA, os grupos ou tratamentos são definidos pelo delineamento, e estruturas de dispersão participam da formulação inferencial sobre diferenças entre vetores de médias.

O mesmo objeto matricial pode, portanto, participar de técnicas diferentes sem desempenhar a mesma função estatística.

16.12 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte desenvolve propriedades matemáticas das soluções de agrupamento. São examinados o centroide como minimizador do critério quadrático, a existência e a não unicidade das soluções, as transformações que preservam o critério das K -médias, a derivação do incremento de Ward e a não unicidade associada a empates nos métodos hierárquicos. Esses resultados justificam propriedades apresentadas no núcleo, mas não são necessários para uma primeira leitura da técnica.

16.12.1 O centroide como minimizador

A propriedade que justifica a média como representante de cada grupo já foi estabelecida em Proposição 10.5. Aplicando Equação 10.52 às observações de um grupo não vazio C_k , seu centroide

$$\mathbf{c}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i$$

é o único ponto que minimiza

$$\sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}\|^2$$

em relação a $\mathbf{c} \in \mathbb{R}^p$.

O uso da média como representante do grupo decorre, portanto, da distância euclidiana quadrática utilizada pelo critério das K -médias. Outras funções de perda podem produzir representantes diferentes.

16.12.2 Existência e não unicidade da solução

Para uma matriz de dados com n observações e um valor fixado de

$$1 \leq K \leq n,$$

existe um número finito de partições das observações em exatamente K grupos não vazios. Como

$$J_K(\mathcal{P}) \geq 0,$$

o conjunto dos valores de $J_K(\mathcal{P})$ possui um mínimo. Portanto, existe pelo menos uma solução global para o problema definido na Equação 16.8.

A existência do mínimo não implica unicidade. Duas ou mais partições distintas podem atingir o mesmo valor mínimo.

Além disso, permutar os rótulos dos grupos não produz uma nova organização das observações. Se

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

qualquer permutação desses mesmos conjuntos representa a mesma partição, embora utilize outra numeração para os grupos.

16.12.3 Transformações que preservam o critério das K -médias

Considere a transformação

$$\mathbf{x}_i^* = \mathbf{a} + c\mathbf{Q}\mathbf{x}_i,$$

em que

$$\mathbf{a} \in \mathbb{R}^p, \quad c \neq 0, \quad \mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Para uma partição fixada, o centroide transformado do grupo C_k é

$$\mathbf{c}_k^* = \mathbf{a} + c\mathbf{Q}\mathbf{c}_k.$$

Logo,

$$\begin{aligned} \|\mathbf{x}_i^* - \mathbf{c}_k^*\|^2 &= \|c\mathbf{Q}(\mathbf{x}_i - \mathbf{c}_k)\|^2 \\ &= c^2 \|\mathbf{x}_i - \mathbf{c}_k\|^2, \end{aligned}$$

pela preservação da norma por transformações ortogonais estabelecida em Proposição 4.10.

Assim, para qualquer partição admissível,

$$J_K^*(\mathcal{P}) = c^2 J_K(\mathcal{P}). \quad (16.20)$$

Como $c^2 > 0$, a transformação preserva a ordenação das partições segundo o critério. Portanto,

$$\arg \min_{\mathcal{P} \in \mathcal{A}_K} J_K^*(\mathcal{P}) = \arg \min_{\mathcal{P} \in \mathcal{A}_K} J_K(\mathcal{P}).$$

Esse resultado reúne translações, rotações, reflexões e mudanças comuns de escala. Mudanças distintas de escala entre variáveis não pertencem a essa classe e podem alterar a solução, como mostra a Figura 16.2.

16.12.4 Derivação do incremento de Ward

Considere dois grupos não vazios A e B , com tamanhos

$$n_A = |A|, \quad n_B = |B|,$$

e centroides $\mathbf{c}_A$ e $\mathbf{c}_B$. Após a fusão,

$$C = A \cup B,$$

o centroide do grupo resultante é

$$\mathbf{c}_C = \frac{n_A \mathbf{c}_A + n_B \mathbf{c}_B}{n_A + n_B}. \quad (16.21)$$

Defina

$$J(A) = \sum_{i \in A} \|\mathbf{x}_i - \mathbf{c}_A\|^2.$$

O aumento da dispersão intragrupos produzido pela fusão é

$$\Delta_{\text{Ward}}(A, B) = J(A \cup B) - J(A) - J(B). \quad (16.22)$$

Aplicando Equação 10.52 separadamente aos grupos A e B , em torno do novo centroide $\mathbf{c}_C$, obtém-se

$$\Delta_{\text{Ward}}(A, B) = n_A \|\mathbf{c}_A - \mathbf{c}_C\|^2 + n_B \|\mathbf{c}_B - \mathbf{c}_C\|^2.$$

Substituindo Equação 16.21,

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2,$$

que é a expressão apresentada na Equação 16.17.

16.12.5 Empates e não unicidade da hierarquia

Em uma etapa do procedimento aglomerativo, mais de um par de grupos pode apresentar o mesmo menor valor do critério de ligação. Nesse caso, o critério não determina sozinho qual fusão deve ocorrer primeiro, e diferentes regras de desempate podem produzir sequências posteriores distintas.

Essa não unicidade deve ser distinguida da liberdade de reordenar graficamente as folhas de um dendrograma sem modificar a hierarquia representada. A primeira pertence à construção da solução; a segunda é apenas uma propriedade de sua representação gráfica.

16.13 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne decisões e procedimentos utilizados na condução da Análise de Agrupamentos. São examinados o tratamento de dados mistos, a escolha do número de grupos, a busca computacional da solução das K -médias e as convenções computacionais do método de Ward.

16.13.1 Dados mistos e dissimilaridade de Gower

A formulação das K -médias desenvolvida neste capítulo utiliza variáveis quantitativas representadas em um espaço euclidiano. Quando os objetos são descritos simultaneamente por variáveis quantitativas, ordinais e nominais, conforme a distinção apresentada na Seção 1.2, a comparação entre observações exige uma representação que respeite a natureza de cada atributo.

Uma possibilidade é a dissimilaridade derivada do coeficiente geral de similaridade proposto por Gower (Gower, 1971). Para dois objetos i e h , sua forma geral pode ser escrita como

$$d_G(i, h) = \frac{\sum_{j=1}^p w_{ijh} d_{ijh}}{\sum_{j=1}^p w_{ijh}}, \quad (16.23)$$

em que d_{ijh} representa a dissimilaridade parcial entre os objetos na variável j e w_{ijh} indica se essa comparação participa do cálculo. A expressão é definida quando

$$\sum_{j=1}^p w_{ijh} > 0,$$

isto é, quando existe pelo menos uma variável disponível para comparar os dois objetos.

A construção de d_{ijh} depende do tipo de variável. Para uma variável quantitativa, uma forma usual é dividir a diferença absoluta pela amplitude observada,

$$d_{ijh} = \frac{|x_{ij} - x_{hj}|}{R_j},$$

quando $R_j > 0$. Para uma variável nominal, a dissimilaridade parcial pode assumir valor 0 para categorias iguais e 1 para categorias diferentes. O tratamento específico de variáveis ordinais exige uma regra para incorporar a ordenação das categorias ao cálculo da dissimilaridade e não será desenvolvido nesta formulação.

A combinação dessas contribuições produz uma medida comum para atributos de naturezas distintas. Essa possibilidade não transforma a formulação clássica das K -médias em um método baseado em distância de Gower. O critério das K -médias continua definido pela minimização de distâncias euclidianas quadráticas em torno de centroides.

Procedimentos destinados a dados mistos podem utilizar outros representantes e outras funções objetivo. O método de K -prototypes combina critérios para as partes quantitativa e categórica da representação (Huang, 1998). O representante de um grupo deixa de ser descrito exclusivamente pelo vetor de médias utilizado nas K -médias.

Na interpretação computacional, uma opção denominada “Gower” pode corresponder à mudança do procedimento de agrupamento, e não à simples substituição da distância dentro das K -médias. A função objetivo efetivamente utilizada deve ser identificada antes de interpretar o resultado como uma extensão de um método conhecido.

16.13.2 Escolha do número de grupos

Para comparar soluções com diferentes valores de K , defina

$$W_K = \min_{\mathcal{P} \in \mathcal{A}_K} J_K(\mathcal{P}), \quad (16.24)$$

em que $\mathcal{A}_K$ é o conjunto definido na Equação 16.8.

Para $1 \leq K < n$,

$$W_{K+1} \leq W_K.$$

De fato, em qualquer partição em $K < n$ grupos, pelo menos um grupo contém duas ou mais observações. Esse grupo pode ser dividido em dois grupos não vazios e, após o recálculo de seus centroides, a soma das dispersões quadráticas desses dois grupos não pode exceder a dispersão do grupo original. Portanto, existe uma partição admissível em $K + 1$ grupos cujo critério não

é maior que o da partição considerada. Em particular, essa propriedade vale para a partição que atinge W_K .

No caso extremo $K = n$, cada observação pode formar um grupo unitário e

$$W_n = 0.$$

A redução de W_K à medida que K aumenta mostra que o menor valor da função objetivo não pode, isoladamente, determinar o número de grupos. A escolha exige avaliar se o ganho obtido ao aumentar K justifica a maior complexidade da partição.

O **gráfico do cotovelo** (*elbow plot*) examina a sequência de valores de dispersão intragrupos para diferentes valores de K . A interpretação procura uma região em que reduções adicionais de W_K passam a ser relativamente pequenas. Essa mudança de comportamento pode fornecer uma indicação para a escolha de K , mas não constitui uma regra que determine um número verdadeiro de grupos.

Outro critério utiliza a **silhueta**, que compara a coesão de uma observação com seu próprio grupo e sua separação em relação aos demais (Kaufman; Rousseeuw, 1990). Considere uma partição com pelo menos dois grupos e uma observação i pertencente a um grupo com pelo menos duas observações. Seja $a(i)$ a dissimilaridade média entre i e as demais observações de seu grupo e seja $b(i)$ a menor dissimilaridade média entre i e as observações de qualquer outro grupo. Quando

$$\max\{a(i), b(i)\} > 0,$$

o coeficiente de silhueta é

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}. \quad (16.25)$$

O coeficiente satisfaz

$$-1 \leq s(i) \leq 1.$$

Para uma observação que forma sozinha um grupo, adota-se usualmente $s(i) = 0$. Para uma partição com apenas um grupo, a silhueta não está definida.

Valores elevados indicam que a observação está relativamente próxima das observações de seu grupo e afastada dos grupos concorrentes. Valores próximos de zero indicam posições intermediárias, enquanto valores negativos indicam maior proximidade média com outro grupo. A média dos coeficientes fornece uma medida descritiva da coesão e da separação da partição.

A **estatística gap** compara a dispersão intragrupos da solução observada com aquela obtida sob uma distribuição de referência utilizada como modelo nulo para a estrutura de agrupamento (Tibshirani; Walther; Hastie, 2001).

Para distinguir essa quantidade do mínimo global W_K definido em Equação 16.24, denote por

$$\widetilde{W}_K$$

a dispersão intragrupos da solução efetivamente obtida pelo procedimento de agrupamento para K grupos. Então,

$$\text{Gap}(K) = E^* [\log \widetilde{W}_K^*] - \log \widetilde{W}_K, \quad (16.26)$$

em que $\widetilde{W}_K^*$ é a dispersão obtida aplicando o mesmo procedimento a dados gerados pela distribuição de referência, e E^* representa a média sob esse mecanismo de geração.

Quando o procedimento utilizado não garante o mínimo global das K -médias,

$$\widetilde{W}_K \geq W_K.$$

A aplicação da estatística gap depende, portanto, da distribuição de referência e do procedimento utilizado para obter as soluções observadas e de referência.

O cotovelo, a silhueta e a estatística gap fornecem informações diferentes sobre as soluções obtidas para cada valor de K . Nenhum desses critérios estabelece, isoladamente, a existência de um número verdadeiro de grupos na população.

A escolha de K deve considerar conjuntamente o comportamento desses critérios, a estabilidade da partição quando essa propriedade for avaliada e a possibilidade de caracterizar os grupos a partir das variáveis utilizadas e do objetivo da análise (Hair et al., 2018). Procedimentos de validação por reamostragem e análises mais extensas de estabilidade não são desenvolvidos neste capítulo.

16.13.3 Solução global, algoritmo e inicialização

O critério das K -médias define a solução global pela minimização de

$$J_K(\mathcal{P}).$$

Essa definição deve ser distinguida do procedimento computacional utilizado para procurar uma partição.

Algoritmos de K -médias normalmente alternam duas operações: atribuir observações aos centroides e recalculá-los a partir dos grupos formados. Essas operações utilizam as propriedades apresentadas na Seção 16.6.2, mas sua execução não garante que a solução global da Equação 16.8 seja encontrada.

O resultado pode depender dos centroides ou da partição utilizados na inicialização. Diferentes valores iniciais podem conduzir a soluções finais diferentes, inclusive com valores distintos da função objetivo (Johnson; Wichern, 2007).

Por isso, a análise pode ser repetida a partir de diferentes inicializações. Entre as soluções obtidas para o mesmo valor de K , pode-se comparar

$$J_K(\mathcal{P})$$

e examinar se a composição dos grupos permanece semelhante entre os ajustes.

A repetição das inicializações amplia a busca por soluções com menor valor da função objetivo, mas não altera o critério matemático que define as K -médias.

16.13.4 Convenções computacionais para o método de Ward

A formulação de Ward utilizada neste capítulo é definida pelo aumento da dispersão quadrática intragrupos. Algumas implementações utilizam convenções diferentes para representar computacionalmente esse critério.

Algumas implementações distinguem as opções `Ward.D` e `Ward.D2`. Esses nomes não representam duas denominações equivalentes para o mesmo cálculo.

A formulação desenvolvida neste capítulo utiliza diretamente o aumento da soma de quadrados intragrupos,

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2.$$

Em implementações baseadas na convenção do `hclust` do R, `Ward.D2` é a opção diretamente associada a essa formulação de mínima variância quando a análise parte das distâncias euclidianas. `Ward.D` corresponde a uma convenção histórica distinta. A interpretação do resultado deve considerar qual dessas formulações foi utilizada.

Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise de Agrupamentos será realizada pelo módulo `snowCluster` (Seol, 2026) do `jamovi` (The jamovi project, 2026).

Para variáveis quantitativas, a análise por K -médias corresponde ao critério desenvolvido na Seção 16.6.2. A padronização modifica previamente a geometria das observações e deve

ser interpretada conforme a Seção 16.3.1. Diferentes algoritmos computacionais podem ser utilizados para procurar uma solução desse mesmo critério sem alterar sua função objetivo.

As opções de agrupamento hierárquico correspondem às medidas de proximidade e às regras de ligação apresentadas na Seção 16.7. As convenções computacionais específicas do método de Ward são discutidas na Seção 16.13.4.

Para dados mistos, a utilização de Gower não corresponde à simples substituição da distância euclidiana dentro das K -médias. Esse caso envolve uma formulação própria para dados de diferentes tipos, conforme discutido na Seção 16.13.1.

Os critérios auxiliares para escolha do número de grupos são apresentados na Seção 16.13.2.

16.14 Síntese

A Análise de Agrupamentos procura organizar objetos sem utilizar classes previamente conhecidas. A estrutura obtida depende da representação dos objetos, da medida de proximidade e do critério adotado para definir os grupos.

Quando as observações são representadas por vetores

$$\mathbf{x}_i \in \mathbb{R}^p,$$

suas proximidades podem ser construídas a partir das coordenadas. Alguns métodos também podem partir diretamente de uma matriz de dissimilaridades

$$\Delta \in \mathbb{R}^{n \times n}.$$

Nas K -médias, procura-se uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

que minimize a dispersão quadrática intragrupos,

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2 = \text{tr}(\mathbf{T}_{\text{intra}}).$$

Os centroides aparecem nessa formulação porque a média de cada grupo minimiza a soma das distâncias euclidianas quadráticas às observações que o compõem. Para K fixado,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

de modo que a redução da dispersão intragrupos corresponde ao aumento da dispersão entre grupos em relação à dispersão total observada.

Os métodos hierárquicos produzem outro tipo de objeto: uma sequência de partições aninhadas. As ligações simples, completa e média utilizam definições diferentes de proximidade entre grupos. O método de Ward seleciona, em cada etapa, a fusão que produz o menor aumento da dispersão intragrupos,

$$\Delta_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mathbf{c}_A - \mathbf{c}_B\|^2.$$

O dendrograma representa a hierarquia das fusões resultantes.

Uma terceira formulação define grupos como componentes de um modelo probabilístico,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k).$$

Nesse caso, a associação de uma observação aos grupos pode ser descrita por probabilidades posteriores de pertinência, em vez de ser necessariamente estabelecida por uma partição rígida.

As K -médias, os métodos hierárquicos e os modelos de mistura atribuem significados diferentes ao conceito de grupo. A solução também depende das variáveis utilizadas, de suas escalas, da medida de proximidade, do número de grupos e do critério adotado. Uma solução matematicamente definida não demonstra, por si só, a existência de populações distintas nem sua correspondência com categorias externas ao procedimento de agrupamento.

No Capítulo 17, o objeto de análise passa a ser uma tabela de contingência. Perfis, massas, distância qui-quadrado, inércia e decomposição em valores singulares são utilizados para representar associações entre categorias.

17 Formulação da Análise de Correspondência

A Análise de Correspondência simples representa geometricamente a estrutura de associação entre as categorias de duas variáveis qualitativas a partir de uma tabela de contingência. A técnica compara os perfis observados com a estrutura correspondente à independência em uma geometria ponderada pelas frequências marginais (Greenacre, 2017).

Os desvios da independência são padronizados pelas massas e reunidos em uma matriz cuja SVD fornece as dimensões da associação, suas inércias e as coordenadas das categorias de linhas e colunas. Essa construção é geométrica e descritiva. Sua relação com a estatística de Pearson exige distinguir a identidade algébrica válida para a tabela observada da inferência sobre independência em uma população.

O núcleo do capítulo desenvolve a técnica a partir da tabela de contingência, das massas, dos perfis, da geometria qui-quadrado e da SVD. Também apresenta os sistemas de coordenadas, a representação conjunta das duas margens, a distinção entre formulação descritiva e inferencial, a relação com a ACP e os limites de interpretação. Os aprofundamentos teóricos tratam do limite do posto, das relações baricêtricas, da centralização das coordenadas, da reconstrução dos desvios e da relação com a estatística de Pearson. Os aprofundamentos metodológicos e aplicados apresentam as contribuições, a qualidade de representação, a escolha das dimensões, a leitura do mapa reduzido e as categorias suplementares.

Os elementos da formulação são organizados na Tabela 17.1.

Tabela 17.1: Elementos da formulação da Análise de Correspondência.

Elemento	Objeto	Papel na análise
dados observados	tabela de contingência N	registra as frequências conjuntas
distribuição observada	matriz P	expressa frequências relativas
pesos marginais	massas r e c	determinam a importância relativa das categorias
representação interna	perfis de linhas e de colunas	descreve distribuições condicionais observadas
referência	independência	fornece a estrutura sem associação
geometria	distância qui-quadrado	compara perfis com ponderação pelas massas

Elemento	Objeto	Papel na análise
estrutura matricial	desvios padronizados $\mathbf{Q}_{CA}$	reúne os desvios da independência
solução	SVD de $\mathbf{Q}_{CA}$	produz inércias e coordenadas

17.1 O problema de associação em uma tabela de contingência

As duas variáveis analisadas são categóricas, conforme a distinção apresentada na Seção 1.2. Suas categorias não são tratadas como coordenadas quantitativas em $\mathbb{R}^p$. A informação utilizada pela Análise de Correspondência é organizada pelas frequências conjuntas das categorias em uma tabela de contingência.

Considere duas variáveis qualitativas, uma com I categorias e outra com J categorias. As frequências observadas são organizadas na tabela

$$\mathbf{N} = (n_{ij}) \in \mathbb{N}_0^{I \times J},$$

em que

$$n_{ij} \in \mathbb{N}_0$$

representa a frequência conjunta observada da categoria i da variável das linhas com a categoria j da variável das colunas.

O total observado é

$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}, \quad n > 0. \quad (17.1)$$

A condição $n > 0$ permite definir a matriz de frequências relativas observadas

$$\mathbf{P} = \frac{1}{n} \mathbf{N} = (p_{ij}) \in \mathbb{R}^{I \times J}. \quad (17.2)$$

Assim,

$$p_{ij} = \frac{n_{ij}}{n} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

A matriz $\mathbf{P}$ descreve a **distribuição relativa observada** na tabela. Neste desenvolvimento geométrico, $\mathbf{P}$ é construída diretamente a partir das frequências observadas. A distribuição conjunta populacional será introduzida na Seção 17.13.6.

A análise procura determinar como $\mathbf{P}$ se afasta da estrutura correspondente à independência e representar esse afastamento em poucas dimensões.

A tabela possui duas leituras complementares. Comparando as linhas, investigam-se diferenças entre as distribuições das categorias das colunas condicionadas a cada linha. Comparando as colunas, investigam-se diferenças entre as distribuições das categorias das linhas condicionadas a cada coluna.

17.2 Frequências marginais, massas e perfis

As frequências marginais relativas determinam os pesos utilizados na geometria da Análise de Correspondência.

Definição 17.1 (Massas de linhas e colunas). Considere uma matriz de frequências relativas

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J},$$

com

$$p_{ij} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

As **massas das linhas** são as frequências relativas marginais

$$r_i = \sum_{j=1}^J p_{ij}, \quad i = 1, \dots, I,$$

e as **massas das colunas** são

$$c_j = \sum_{i=1}^I p_{ij}, \quad j = 1, \dots, J.$$

Em forma vetorial,

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \in \mathbb{R}^I$$

e

$$\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I \in \mathbb{R}^J.$$

Como a soma dos elementos de $\mathbf{P}$ é igual a 1,

$$\mathbf{1}_I^\top \mathbf{r} = \mathbf{1}_J^\top \mathbf{c} = 1.$$

As matrizes diagonais das massas são

$$\mathbf{D}_r = \text{diag}(r_1, \dots, r_I) \in \mathbb{R}^{I \times I}$$

e

$$\mathbf{D}_c = \text{diag}(c_1, \dots, c_J) \in \mathbb{R}^{J \times J}.$$

A definição admite massas nulas. A geometria ativa da Análise de Correspondência utiliza inversas e raízes inversas das matrizes de massas. Por isso, o desenvolvimento considera categorias ativas com

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J. \quad (17.3)$$

Categorias de massa nula não possuem perfis definidos e não participam da geometria ativa. Essa situação será retomada nos limites da representação.

17.2.1 Distribuições condicionais observadas

A Análise de Correspondência compara distribuições condicionais observadas, denominadas perfis.

Definição 17.2 (Perfis de linhas e de colunas). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas com massas de linhas e colunas dadas por Definição 17.1.

Para uma linha i com

$$r_i > 0,$$

o **perfil da linha i** é

$$\mathbf{p}_{i\cdot} = \begin{pmatrix} \frac{p_{i1}}{r_i} \\ \vdots \\ \frac{p_{iJ}}{r_i} \end{pmatrix} \in \mathbb{R}^J. \quad (17.4)$$

Para uma coluna j com

$$c_j > 0,$$

o **perfil da coluna j** é

$$\mathbf{p}_{\cdot j} = \begin{pmatrix} \frac{p_{1j}}{c_j} \\ \vdots \\ \frac{p_{Ij}}{c_j} \end{pmatrix} \in \mathbb{R}^I. \quad (17.5)$$

Cada perfil possui soma unitária:

$$\mathbf{1}_J^\top \mathbf{p}_{i\cdot} = 1$$

e

$$\mathbf{1}_I^\top \mathbf{p}_{\cdot|j} = 1.$$

Sob Equação 17.3, os perfis de linhas podem ser reunidos na matriz

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}, \quad (17.6)$$

enquanto os perfis de colunas são organizados em

$$\mathbf{P}^{(c)} = \mathbf{D}_c^{-1} \mathbf{P}^\top \in \mathbb{R}^{J \times I}. \quad (17.7)$$

O perfil médio das linhas, ponderado pelas massas r_i , é

$$\sum_{i=1}^I r_i \mathbf{p}_{i\cdot} = \mathbf{c}, \quad (17.8)$$

pois, para cada componente j ,

$$\sum_{i=1}^I r_i \frac{p_{ij}}{r_i} = \sum_{i=1}^I p_{ij} = c_j.$$

De forma dual,

$$\sum_{j=1}^J c_j \mathbf{p}_{\cdot|j} = \mathbf{r}. \quad (17.9)$$

Assim, $\mathbf{c}$ é o centro ponderado da nuvem dos perfis de linhas e $\mathbf{r}$ é o centro ponderado da nuvem dos perfis de colunas.

17.2.2 Independência como referência

Para a distribuição relativa observada, a estrutura de independência associada às marginais $\mathbf{r}$ e $\mathbf{c}$ é

$$p_{ij} = r_i c_j, \quad (17.10)$$

ou, em forma matricial,

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top. \quad (17.11)$$

Nesse caso, como as massas ativas são positivas,

$$\frac{p_{ij}}{r_i} = c_j,$$

de modo que

$$\mathbf{p}_{i| \cdot} = \mathbf{c}$$

para todas as linhas.

Analogamente,

$$\frac{p_{ij}}{c_j} = r_i,$$

e todos os perfis de colunas coincidem com

$$\mathbf{r}.$$

A independência corresponde, portanto, ao colapso de cada nuvem de perfis em seu respectivo centro.

Quando

$$\mathbf{P} \neq \mathbf{r}\mathbf{c}^\top,$$

as diferenças

$$p_{ij} - r_i c_j$$

representam os desvios observados em relação à estrutura de independência.

Esses desvios ainda não levam em conta a importância relativa das marginais. A geometria da Análise de Correspondência surge ao ponderá-los pelas massas das categorias.

17.3 Geometria dos perfis

A Análise de Correspondência compara os perfis utilizando uma geometria ponderada pelas massas marginais.

Pelas definições de Definição 3.16 e Definição 3.17, sob Equação 17.3,

$$\mathbf{D}_c^{-1}$$

e

$$\mathbf{D}_r^{-1}$$

são matrizes diagonais positivas definidas e, portanto, definem produtos internos nos espaços de perfis de linhas e de colunas.

Essa estrutura conduz à distância qui-quadrado.

Definição 17.3 (Distância qui-quadrado entre perfis). Considere uma matriz

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

de frequências relativas cujas massas satisfazem

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J.$$

Se

$$\mathbf{p}_{i|\cdot}, \mathbf{p}_{i'|\cdot} \in \mathbb{R}^J$$

são dois perfis de linhas, sua **distância qui-quadrado** é definida por

$$d_{\chi^2}^2(i, i') = (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i|\cdot} - \mathbf{p}_{i'|\cdot}). \quad (17.12)$$

Equivalentemente,

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^J \frac{1}{c_j} \left(\frac{p_{ij}}{r_i} - \frac{p_{i'j}}{r_{i'}} \right)^2.$$

Se

$$\mathbf{p}_{\cdot|j}, \mathbf{p}_{\cdot|j'} \in \mathbb{R}^I$$

são dois perfis de colunas, sua distância qui-quadrado é

$$d_{\chi^2}^2(j, j') = (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'})^\top \mathbf{D}_r^{-1} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'}). \quad (17.13)$$

Equivalentemente,

$$d_{\chi^2}^2(j, j') = \sum_{i=1}^I \frac{1}{r_i} \left(\frac{p_{ij}}{c_j} - \frac{p_{ij'}}{c_{j'}} \right)^2.$$

A distância qui-quadrado é, portanto, uma distância euclidiana em coordenadas reescaladas pelas massas. Para as linhas,

$$d_{\chi^2}(i, i') = \|\mathbf{D}_c^{-1/2} (\mathbf{p}_{i\cdot} - \mathbf{p}_{i'\cdot})\|,$$

e, para as colunas,

$$d_{\chi^2}(j, j') = \|\mathbf{D}_r^{-1/2} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'})\|.$$

As ponderações

$$\frac{1}{c_j}$$

e

$$\frac{1}{r_i}$$

fazem com que uma mesma diferença absoluta entre perfis tenha peso maior quando ocorre em uma categoria de menor massa.

A distância de uma linha ao centro da nuvem é

$$d_{\chi^2}^2(i, \mathbf{c}) = \left(\mathbf{p}_{i\cdot} - \mathbf{c} \right)^\top \mathbf{D}_c^{-1} \left(\mathbf{p}_{i\cdot} - \mathbf{c} \right), \quad (17.14)$$

ou, utilizando

$$\frac{p_{ij}}{r_i} - c_j = \frac{p_{ij} - r_i c_j}{r_i},$$

tem-se

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i^2 c_j}. \quad (17.15)$$

De forma dual,

$$d_{\chi^2}^2(j, \mathbf{r}) = \sum_{i=1}^I \frac{(p_{ij} - r_i c_j)^2}{c_j^2 r_i}. \quad (17.16)$$

17.4 Inércia e afastamento da independência

Definição 17.4 (Inércia total). Considere uma matriz de frequências relativas

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

com massas de linhas e colunas estritamente positivas.

A **inércia total** da tabela é a dispersão qui-quadrado ponderada dos perfis de linhas em torno de seu centro $\mathbf{c}$:

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}). \quad (17.17)$$

Utilizando Equação 17.15,

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \quad (17.18)$$

De forma dual,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}). \quad (17.19)$$

Como todos os termos em Equação 17.18 são não negativos,

$$\mathcal{J} = 0$$

se, e somente se,

$$p_{ij} = r_i c_j$$

para todas as células, ou equivalentemente,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top.$$

A inércia quantifica, portanto, o afastamento global da distribuição relativa observada em relação à estrutura de independência na geometria qui-quadrado.

17.5 Padronização dos desvios da independência

A expressão de Equação 17.18 sugere reunir os desvios

$$p_{ij} - r_i c_j$$

em uma única matriz, padronizando-os pelas massas correspondentes.

Definição 17.5 (Matriz de desvios padronizados). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas cujas massas

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

são estritamente positivas.

A matriz de desvios padronizados da Análise de Correspondência é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2} \in \mathbb{R}^{I \times J}. \quad (17.20)$$

Seu elemento (i, j) é

$$q_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}. \quad (17.21)$$

A matriz $\mathbf{Q}_{\text{CA}}$ representa, em coordenadas ponderadas, os desvios da distribuição observada em relação à independência.

As restrições impostas pelas marginais reduzem em pelo menos uma unidade o posto disponível em cada lado. Assim,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1). \quad (17.22)$$

A demonstração algébrica desse limite é apresentada na Seção 17.13.1. A restrição explica por que a Análise de Correspondência possui, no máximo,

$$\min(I - 1, J - 1)$$

dimensões não nulas.

17.5.1 Inércia como norma matricial

Pela definição de $\mathbf{Q}_{\text{CA}}$ e pela norma de Frobenius de Definição 6.7,

$$\begin{aligned} \|\mathbf{Q}_{\text{CA}}\|_F^2 &= \sum_{i=1}^I \sum_{j=1}^J q_{ij}^2 \\ &= \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \end{aligned}$$

Por Equação 17.18,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2. \quad (17.23)$$

Proposição 17.1 (Formas equivalentes da inércia). *Sob massas de linhas e colunas estritamente positivas,*

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r})$$

e

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

A mesma quantidade possui, assim, três interpretações compatíveis: dispersão da nuvem de linhas, dispersão da nuvem de colunas e magnitude matricial dos desvios padronizados da independência.

17.6 Relação algébrica com a estatística qui-quadrado

Para a tabela observada, a estatística de Pearson calculada a partir das frequências marginais é

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - nr_i c_j)^2}{nr_i c_j}. \quad (17.24)$$

Como

$$n_{ij} = np_{ij},$$

tem-se

$$\begin{aligned} \chi^2 &= \sum_{i=1}^I \sum_{j=1}^J \frac{n^2 (p_{ij} - r_i c_j)^2}{nr_i c_j} \\ &= n \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \end{aligned}$$

Por Equação 17.18,

$$\chi^2 = n\mathcal{J}. \quad (17.25)$$

A identidade

$$\chi^2 = n\mathcal{J}$$

é **algébrica e exata para a tabela observada**. Ela não exige um modelo probabilístico para a geração da tabela nem uma aproximação assintótica.

Sua interpretação como estatística de teste exige um modelo probabilístico para a geração da tabela, desenvolvido na Seção 17.13.6. A inércia e a identidade acima pertencem à estrutura descritiva e geométrica da Análise de Correspondência, enquanto a distribuição de referência de χ^2 pertence à inferência.

17.7 Formulação pela decomposição em valores singulares

A matriz de desvios padronizados

$$\mathbf{Q}_{CA} \in \mathbb{R}^{I \times J}$$

é, em geral, retangular. Sua decomposição utiliza diretamente a SVD compacta definida em Definição 6.4.

Defina

$$L = \text{posto}(\mathbf{Q}_{CA}).$$

Por Equação 17.22,

$$0 \leq L \leq \min(I - 1, J - 1).$$

Se

$$L = 0,$$

então

$$\mathbf{Q}_{CA} = \mathbf{0},$$

e, por Proposição 17.1,

$$\mathcal{J} = 0.$$

Nesse caso, a distribuição relativa observada coincide com a estrutura de independência,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top,$$

e não existem dimensões não nulas de associação a decompor.

Considere, portanto, no restante desta seção,

$$L \geq 1.$$

Pela SVD compacta de Definição 6.4,

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top, \tag{17.26}$$

com

$$\mathbf{U} \in \mathbb{R}^{I \times L}, \quad \mathbf{D} \in \mathbb{R}^{L \times L}, \quad \mathbf{V} \in \mathbb{R}^{J \times L},$$

satisfazendo

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_L,$$

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_L$$

e

$$\mathbf{D} = \text{diag}(d_1, \dots, d_L),$$

em que

$$d_1 \geq d_2 \geq \dots \geq d_L > 0.$$

Os vetores singulares à esquerda e à direita definem as direções da matriz de desvios padronizados. O reescalonamento por $\mathbf{D}_r^{-1/2}$ e $\mathbf{D}_c^{-1/2}$ transforma essas direções nas coordenadas das linhas e das colunas em suas respectivas geometrias ponderadas.

A SVD acopla as duas representações por meio dos mesmos valores singulares.

17.7.1 Decomposição da inércia

Definição 17.6 (Inércia principal). Considere a SVD compacta

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$$

de uma matriz de desvios padronizados com posto

$$L \geq 1,$$

em que

$$\mathbf{D} = \text{diag}(d_1, \dots, d_L)$$

e

$$d_\ell > 0, \quad \ell = 1, \dots, L.$$

A inércia principal da dimensão ℓ é

$$\lambda_\ell = d_\ell^2, \quad \ell = 1, \dots, L. \quad (17.27)$$

Pela relação entre a norma de Frobenius e os valores singulares estabelecida em Proposição 6.9,

$$\|\mathbf{Q}_{\text{CA}}\|_F^2 = \sum_{\ell=1}^L d_\ell^2.$$

Como

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2$$

por Equação 17.23, segue que

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell. \quad (17.28)$$

A SVD decompõe, portanto, a inércia total em parcelas não negativas associadas às diferentes dimensões da associação.

Utilizando a identidade exata

$$\chi^2 = n\mathcal{J}$$

de Equação 17.25,

$$\chi^2 = n \sum_{\ell=1}^L \lambda_{\ell}. \quad (17.29)$$

Essa igualdade é uma decomposição algébrica da estatística observada e não depende de uma distribuição amostral. A formulação probabilística da estatística de Pearson é desenvolvida na Seção 17.13.6.

Como

$$\lambda_{\ell} > 0,$$

a proporção da inércia associada à dimensão ℓ é

$$\frac{\lambda_{\ell}}{\sum_{h=1}^L \lambda_h}. \quad (17.30)$$

Para

$$1 \leq k \leq L,$$

a proporção acumulada da inércia representada pelas primeiras k dimensões é

$$\frac{\sum_{\ell=1}^k \lambda_{\ell}}{\sum_{\ell=1}^L \lambda_{\ell}}. \quad (17.31)$$

Essas proporções descrevem a decomposição da **inércia qui-quadrado**. Embora a expressão seja formalmente semelhante à proporção de variância explicada da ACP, o objeto decomposto é diferente: na Análise de Correspondência, decompõem-se os desvios padronizados da independência.

17.7.2 Representação em dimensão reduzida

Considere

$$1 \leq k < L.$$

Defina

$$\mathbf{U}_k = (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k) \in \mathbb{R}^{I \times k},$$

$$\mathbf{V}_k = (\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_k) \in \mathbb{R}^{J \times k}$$

e

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}.$$

A SVD truncada é

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top. \quad (17.32)$$

Pelo Teorema de Eckart–Young–Mirsky em Teorema 6.2,

$$\mathbf{Q}_{\text{CA},k}$$

é uma melhor aproximação de posto no máximo k de

$$\mathbf{Q}_{\text{CA}}$$

em norma de Frobenius.

O erro quadrático de aproximação é

$$\begin{aligned} \|\mathbf{Q}_{\text{CA}} - \mathbf{Q}_{\text{CA},k}\|_F^2 &= \sum_{\ell=k+1}^L d_\ell^2 \\ &= \sum_{\ell=k+1}^L \lambda_\ell. \end{aligned} \quad (17.33)$$

A quantidade

$$\mathcal{J}_k = \sum_{\ell=1}^k \lambda_{\ell} \quad (17.34)$$

é a parcela da inércia total representada pelas primeiras k dimensões.

Consequentemente,

$$\mathcal{J} = \mathcal{J}_k + \sum_{\ell=k+1}^L \lambda_{\ell}.$$

O resultado de posto reduzido deve ser interpretado em relação ao objeto efetivamente decomposto. Na Análise de Correspondência, a SVD truncada fornece uma aproximação ótima, em norma de Frobenius, da **matriz ponderada de desvios da independência**.

Ela não corresponde à aproximação da tabela de frequências brutas segundo uma distância euclidiana ordinária.

17.8 Coordenadas da Análise de Correspondência

A SVD é realizada sobre uma matriz em que os desvios da independência já foram ponderados pelas massas das categorias. As coordenadas da Análise de Correspondência transformam os vetores singulares novamente para os espaços dos perfis de linhas e de colunas.

A representação utilizará duas escalas: coordenadas padrão e coordenadas principais.

17.8.1 Sistema de coordenadas padrão

Definição 17.7 (Coordenadas padrão). Considere uma tabela de frequências relativas

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

com massas de linhas e colunas estritamente positivas e a SVD compacta

$$\mathbf{Q}_{CA} = \mathbf{U} \mathbf{D} \mathbf{V}^{\top},$$

com

$$L = \text{posto}(\mathbf{Q}_{CA}) \geq 1.$$

As **coordenadas padrão das linhas** são as linhas de

$$\mathbf{A}_r = \mathbf{D}_r^{-1/2} \mathbf{U} \in \mathbb{R}^{I \times L}, \quad (17.35)$$

e as **coordenadas padrão das colunas** são as linhas de

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V} \in \mathbb{R}^{J \times L}. \quad (17.36)$$

Como as colunas de $\mathbf{U}$ e $\mathbf{V}$ são ortonormais,

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_L$$

e

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_L.$$

As coordenadas padrão são, portanto, ortonormais nas geometrias ponderadas pelas respectivas massas.

17.8.2 Sistema de coordenadas principais

Definição 17.8 (Coordenadas principais). Sob as condições de Definição 17.7, as **coordenadas principais das linhas** são

$$\mathbf{F}_r = \mathbf{A}_r \mathbf{D} = \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D} \in \mathbb{R}^{I \times L}, \quad (17.37)$$

e as **coordenadas principais das colunas** são

$$\mathbf{F}_c = \mathbf{A}_c \mathbf{D} = \mathbf{D}_c^{-1/2} \mathbf{V} \mathbf{D} \in \mathbb{R}^{J \times L}. \quad (17.38)$$

As coordenadas principais incorporam os valores singulares e, portanto, a magnitude da associação representada em cada dimensão. Como

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_L$$

e

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_L,$$

segue que

$$\mathbf{F}_r^\top \mathbf{D}_r \mathbf{F}_r = \mathbf{D}^2$$

e

$$\mathbf{F}_c^\top \mathbf{D}_c \mathbf{F}_c = \mathbf{D}^2.$$

Se $f_{i\ell}^{(r)}$ e $f_{j\ell}^{(c)}$ denotam as coordenadas principais da linha i e da coluna j na dimensão ℓ , respectivamente, então

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2, \quad \ell = 1, \dots, L. \quad (17.39)$$

Cada inércia principal possui, assim, uma representação simultânea pela dispersão ponderada das coordenadas das linhas e das colunas.

Essa dualidade não significa que as duas nuvens pertençam originalmente ao mesmo espaço de perfis. As linhas são perfis em $\mathbb{R}^J$ e as colunas são perfis em $\mathbb{R}^I$; a SVD fornece dimensões acopladas para representar a mesma estrutura de associação.

17.8.3 Distâncias entre perfis e coordenadas principais

As coordenadas principais completas reproduzem a geometria qui-quadrado dos perfis.

Para as linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P}.$$

A partir de Equação 17.20,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{D}_r^{-1/2} \mathbf{Q}_{CA}.$$

Substituindo a SVD e utilizando Equação 17.37,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{F}_r \mathbf{V}^\top. \quad (17.40)$$

Como

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_L,$$

a multiplicação por $\mathbf{V}^\top$ preserva a norma das diferenças entre as linhas de $\mathbf{F}_r$.

Proposição 17.2 (Preservação das distâncias qui-quadrado). *Mantidas todas as L dimensões associadas aos valores singulares positivos, para quaisquer linhas i e i' ,*

$$d_{\chi^2}^2(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|^2,$$

e, de forma dual, para quaisquer colunas j e j' ,

$$d_{\chi^2}^2(j, j') = \|\mathbf{f}_j^{(c)} - \mathbf{f}_{j'}^{(c)}\|^2.$$

Portanto, a ponderação pelas massas é incorporada antes da SVD, enquanto as coordenadas principais permitem representar a geometria resultante por distâncias euclidianas usuais.

Se apenas as primeiras

$$k < L$$

dimensões forem mantidas, a distância representada entre dois perfis não pode exceder a distância completa, pois as parcelas quadráticas associadas às dimensões descartadas são não negativas. A representação reduzida preserva apenas a parcela da geometria qui-quadrado contida no subespaço retido.

17.9 Representação conjunta de linhas e colunas

A Análise de Correspondência fornece coordenadas para as duas margens da tabela. Para representar linhas e colunas simultaneamente, é necessário especificar quais sistemas de coordenadas serão utilizados para cada nuvem.

A Tabela 17.2 reúne três representações particularmente úteis para compreender essa geometria.

Tabela 17.2: Sistemas de coordenadas para representar linhas e colunas na Análise de Correspondência.

Representação	Linhas	Colunas	Propriedade principal
métrica das linhas	principais $\mathbf{F}_r$	padrão $\mathbf{A}_c$	preserva a geometria das linhas e utiliza escalas compatíveis com a dualidade entre linhas e colunas
métrica das colunas	padrão $\mathbf{A}_r$	principais $\mathbf{F}_c$	preserva a geometria das colunas e utiliza escalas compatíveis com a dualidade entre linhas e colunas
simétrica	principais $\mathbf{F}_r$	principais $\mathbf{F}_c$	representa ambas as nuvens em escalas associadas às inércias principais

Na representação métrica das linhas, as distâncias euclidianas entre os pontos de linhas reproduzem exatamente suas distâncias qui-quadrado quando todas as dimensões não nulas são mantidas. As colunas aparecem em coordenadas padrão e participam diretamente das relações baricêntricas das linhas.

Na representação métrica das colunas ocorre a relação dual.

Na representação simétrica, linhas e colunas são expressas por coordenadas principais. Essa representação é útil para examinar simultaneamente as duas margens, mas não cria uma métrica qui-quadrado comum entre pontos pertencentes a margens diferentes.

17.9.1 O significado das proximidades

Dentro da nuvem das linhas, proximidades representam semelhança entre perfis segundo a distância qui-quadrado; a interpretação dual vale para as colunas.

A distância entre um ponto de linha e um ponto de coluna não corresponde, em geral, a uma distância qui-quadrado definida pela técnica. Por isso, proximidade gráfica entre categorias pertencentes a margens diferentes não constitui uma medida métrica direta de associação.

A interpretação conjunta deve considerar os perfis, as relações baricêntricas e o sistema de coordenadas utilizado. Nas representações simétricas, a proximidade entre uma categoria de linha e uma categoria de coluna não deve ser interpretada, isoladamente, como uma medida direta de associação.

17.10 Formulação descritiva e inferencial

A identidade

$$\chi^2 = n\mathcal{J}$$

estabelecida em Equação 17.25 relaciona a estatística de Pearson calculada para a tabela observada com a inércia total da Análise de Correspondência. Essa igualdade é algébrica e não exige, por si só, um modelo probabilístico.

Na formulação descritiva,

$$p_{ij}, \quad r_i \quad \text{e} \quad c_j$$

são quantidades calculadas a partir da tabela observada. A inércia

$$\mathcal{J}$$

mede e decompõe geometricamente o afastamento de

$$\mathbf{P} = \mathbf{rc}^\top.$$

Quando a estatística de Pearson é utilizada em um teste de independência, ela avalia globalmente a compatibilidade entre os dados e uma estrutura populacional de independência. As dimensões obtidas pela SVD, por sua vez, decompõem descritivamente o afastamento observado:

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell.$$

Uma dimensão da Correspondência não corresponde automaticamente a uma hipótese inferencial populacional separada. O teste global e a decomposição geométrica respondem, portanto, a problemas distintos.

A identidade

$$\chi^2 = n\mathcal{J}$$

também separa magnitude geométrica e tamanho amostral. Se todas as contagens forem multiplicadas por um mesmo inteiro positivo a , a matriz de frequências relativas $\mathbf{P}$, as massas, a matriz $\mathbf{Q}_{CA}$, a inércia e as coordenadas permanecem inalteradas, enquanto

$$\chi^{2*} = a\chi^2.$$

Assim, significância estatística e magnitude geométrica da associação não são a mesma quantidade. A Correspondência pode ser utilizada descritivamente mesmo quando não se pretende realizar um teste formal de independência (Greenacre, 2017).

17.11 Relação com a Análise de Componentes Principais

A Análise de Correspondência e a ACP compartilham estruturas de decomposição e representação em baixa dimensão, mas partem de objetos estatísticos e geometrias diferentes.

No Capítulo 14, a ACP representa a variabilidade de dados quantitativos por meio de direções principais. Na Análise de Correspondência, a estrutura de entrada é uma tabela de contingência e a representação é construída a partir de perfis e da geometria qui-quadrado.

Considere a matriz dos perfis de linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P}.$$

Pela definição de $\mathbf{P}^{(r)}$ e por Equação 17.20,

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{1/2} (\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2}. \quad (17.41)$$

Antes da SVD, portanto, os perfis de linhas são:

1. centralizados em torno de $\mathbf{c}$;
2. ponderados pelas massas das linhas;
3. reescalados pelas massas das colunas.

Essa expressão permite interpretar a Análise de Correspondência como uma decomposição ponderada dos perfis centralizados. A semelhança com a ACP está no uso de uma estrutura centralizada, da SVD e de aproximações de posto reduzido. A diferença está no objeto analisado, nos pesos e na geometria: na Correspondência, as massas participam da construção e a métrica entre perfis é a métrica qui-quadrado.

A Tabela 17.3 resume essas diferenças.

Tabela 17.3: Relação entre a ACP e a Análise de Correspondência.

Aspecto	ACP	Análise de Correspondência
objeto inicial	matriz de dados quantitativos ou matriz de covariâncias/correlações	tabela de contingência
unidades representadas	observações e/ou variáveis	categorias de linhas e colunas
centro	vetor de médias	perfis marginais $\mathbf{c}$ e $\mathbf{r}$
pesos	usualmente iguais na formulação básica	massas r_i e c_j
geometria	euclidiana ou padronizada	qui-quadrado
quantidade decomposta	variância	inércia
ferramenta espectral	autovalores ou SVD	SVD dos desvios padronizados

A presença de SVD e de aproximações de posto reduzido nas duas técnicas não as torna equivalentes. A ACP representa variabilidade de variáveis quantitativas; a Correspondência representa associações entre categorias por meio de perfis ponderados. Ela não deve, portanto, ser interpretada simplesmente como uma ACP aplicada a variáveis qualitativas (Greenacre, 2017).

17.12 Condições e limites da representação

A formulação da Análise de Correspondência é predominantemente geométrica e descritiva. As condições necessárias para definir essa geometria devem ser distinguidas das hipóteses adicionais utilizadas na inferência sobre independência.

17.12.1 Tabela ativa e massas

A tabela de frequências observadas satisfaz

$$\mathbf{N} \in \mathbb{N}_0^{I \times J}$$

e

$$n > 0.$$

A geometria ativa requer

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

para que os perfis e as inversas de $\mathbf{D}_r$ e $\mathbf{D}_c$ utilizados na técnica estejam definidos.

Linhas ou colunas com massa nula não possuem perfis ativos e devem ser retiradas da geometria formulada neste capítulo.

Massas positivas muito pequenas não impedem matematicamente a análise, mas podem exercer influência elevada porque a distância qui-quadrado utiliza os inversos das massas.

Uma frequência celular nula,

$$n_{ij} = 0,$$

também não impede a análise quando as massas marginais correspondentes permanecem positivas. Um zero estrutural corresponde a uma combinação que não pode ocorrer segundo o mecanismo que gerou a tabela e, portanto, não deve ser tratado como uma frequência amostral nula comum. Na formulação inferencial, o conjunto de células admissíveis deve ser estabelecido antes de aplicar o modelo de independência e a distribuição de referência de Pearson.

Na formulação inferencial, frequências esperadas pequenas podem comprometer a qualidade da aproximação assintótica de Pearson. Essa questão pertence à avaliação aplicada do teste e não à definição geométrica da Correspondência.

17.12.2 Dimensão da representação

Por Equação 17.22,

$$L = \text{posto}(\mathbf{Q}_{CA}) \leq \min(I - 1, J - 1).$$

Quando apenas

$$1 \leq k < L$$

dimensões são mantidas, a parcela da inércia representada é aquela definida na Equação 17.31.

O mapa é, nesse caso, uma representação de posto reduzido. Uma representação bidimensional não implica que a associação observada seja intrinsecamente bidimensional.

17.12.3 Sinais, multiplicidades e orientação

Para um valor singular simples, a troca simultânea

$$\mathbf{u}_\ell \mapsto -\mathbf{u}_\ell, \quad \mathbf{v}_\ell \mapsto -\mathbf{v}_\ell$$

não altera

$$d_\ell \mathbf{u}_\ell \mathbf{v}_\ell^\top.$$

Consequentemente, todas as coordenadas de linhas e colunas na dimensão ℓ podem ter seus sinais invertidos simultaneamente sem modificar a solução. A designação dos lados do eixo como positivo e negativo é, portanto, arbitrária. Permanecem invariantes, contudo, as posições relativas: categorias situadas no mesmo lado continuam no mesmo lado, e categorias situadas em lados opostos continuam em lados opostos. Por esse motivo, resultados produzidos por programas ou execuções diferentes podem apresentar um eixo refletido sem representar soluções distintas.

Quando um valor singular d possui multiplicidade $m > 1$, a indeterminação é mais ampla. Se $\mathbf{U}_B$ e $\mathbf{V}_B$ reúnem os vetores singulares do bloco correspondente, então, para qualquer matriz ortogonal $\mathbf{R} \in \mathbb{R}^{m \times m}$,

$$\mathbf{U}_B \mapsto \mathbf{U}_B \mathbf{R}, \quad \mathbf{V}_B \mapsto \mathbf{V}_B \mathbf{R}$$

preserva a reconstrução, pois

$$\mathbf{U}_B \mathbf{R} (d\mathbf{I}_m) (\mathbf{V}_B \mathbf{R})^\top = \mathbf{U}_B (d\mathbf{I}_m) \mathbf{V}_B^\top.$$

Nesse caso, os eixos individuais do bloco não são únicos; o subespaço por eles gerado é o objeto geometricamente determinado. Se todas as dimensões de uma multiplicidade forem mantidas, o subespaço, as distâncias e a parcela de inércia correspondente permanecem invariantes. Se o truncamento ocorrer dentro desse bloco, o subespaço retido não será único. Sempre que possível, um bloco de valores singulares repetidos deve ser mantido ou descartado integralmente; caso isso não seja feito, a não unicidade precisa ser informada.

Valores singulares muito próximos, embora não produzam multiplicidade exata, também podem tornar instável a orientação dos eixos individuais. Nessas situações, a interpretação deve privilegiar inércias, distâncias dentro de cada nuvem, relações entre perfis e o subespaço conjunto, em vez do sinal ou da orientação isolada de cada eixo.

17.12.4 Proximidade entre linhas e colunas

As distâncias entre linhas em coordenadas principais completas reproduzem as distâncias qui-quadrado entre seus perfis; a interpretação dual vale para as colunas.

A distância gráfica entre uma linha e uma coluna não possui, em geral, essa interpretação. A Figura 17.1 ilustra a diferença entre distâncias definidas dentro de cada nuvem e a posição simultânea das duas margens.




Figura 17.1: Representação conjunta das categorias de linhas e colunas. Distâncias dentro da mesma nuvem possuem interpretação geométrica própria; a distância entre uma linha e uma coluna não corresponde, em geral, a uma distância qui-quadrado.

O mapa permite examinar simultaneamente as duas margens, mas sua leitura deve respeitar a geometria de cada nuvem.

As duas nuvens estão relacionadas pelos perfis: a posição de uma categoria de uma margem depende da distribuição relativa das categorias da outra margem. Essa dualidade será formalizada

pelas relações baricênticas na Seção 17.13.2.

A distância gráfica direta entre uma categoria de linha e uma categoria de coluna não constitui, em geral, uma distância qui-quadrado definida pela técnica.

A Análise de Correspondência descreve associações entre categorias. Uma inércia positiva,

$$\mathcal{J} > 0,$$

indica que a tabela observada se afasta da estrutura

$$\mathbf{P} = \mathbf{rc}^\top.$$

Mesmo quando o teste global fornece evidência de associação populacional, esse resultado não estabelece causalidade.

Uma dimensão da Correspondência é uma direção singular que organiza parte dos desvios padronizados da independência. Ela não corresponde, por definição, a uma variável latente.

A interpretação de uma dimensão deve considerar os perfis, as coordenadas das categorias e o padrão dos desvios em relação à independência. Um nome atribuído ao eixo deve decorrer dessas informações e do problema analisado.

17.13 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte desenvolve propriedades algébricas e probabilísticas da Análise de Correspondência. São examinados o limite do posto decorrente das restrições marginais, as relações baricênticas entre as duas nuvens, as propriedades das coordenadas padrão e principais, a reconstrução dos desvios da independência, a decomposição da estatística de Pearson pelas dimensões e a formulação probabilística do teste global de independência.

17.13.1 Limite do posto da matriz de desvios padronizados

O limite apresentado em Equação 17.22 decorre de restrições lineares produzidas pelas próprias marginais da tabela. Como

$$\mathbf{P}\mathbf{1}_J = \mathbf{r}$$

e

$$\mathbf{c}^\top \mathbf{1}_J = 1,$$

segue que

$$\begin{aligned} \mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J &= \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{1}_J \\ &= \mathbf{D}_r^{-1/2} (\mathbf{r} - \mathbf{r}) \\ &= \mathbf{0}. \end{aligned} \tag{17.42}$$

Analogamente,

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}. \tag{17.43}$$

Como

$$\mathbf{D}_c^{1/2} \mathbf{1}_J \neq \mathbf{0}$$

e

$$\mathbf{D}_r^{1/2} \mathbf{1}_I \neq \mathbf{0}$$

sob massas positivas, $\mathbf{Q}_{\text{CA}}$ possui um vetor não nulo em seu núcleo à direita e um vetor não nulo no núcleo de sua transposta. Portanto,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq J - 1$$

e

$$\text{posto}(\mathbf{Q}_{\text{CA}}^\top) \leq I - 1.$$

Consequentemente,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1),$$

o que demonstra o limite enunciado em Equação [17.22](#).

17.13.2 Relações baricêntricas

As duas nuvens de categorias são construídas a partir da mesma tabela e da mesma SVD. Essa estrutura produz relações diretas entre suas coordenadas.

Das restrições marginais de $\mathbf{Q}_{CA}$ e da SVD compacta decorre

$$\mathbf{r}^\top \mathbf{A}_r = \mathbf{0}^\top, \quad \mathbf{c}^\top \mathbf{A}_c = \mathbf{0}^\top.$$

Partindo de

$$\mathbf{Q}_{CA} \mathbf{V} = \mathbf{U} \mathbf{D}$$

e utilizando

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V},$$

obtém-se

$$\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{A}_c = \mathbf{U} \mathbf{D}.$$

Como

$$\mathbf{c}^\top \mathbf{A}_c = \mathbf{0}^\top,$$

segue que

$$\mathbf{F}_r = \mathbf{D}_r^{-1} \mathbf{P} \mathbf{A}_c. \quad (17.44)$$

De forma dual,

$$\mathbf{F}_c = \mathbf{D}_c^{-1} \mathbf{P}^\top \mathbf{A}_r. \quad (17.45)$$

Essas igualdades são as **relações baricêntricas** ou **relações de transição**.

Para a linha i ,

$$\mathbf{f}_i^{(r)} = \sum_{j=1}^J \frac{p_{ij}}{r_i} \mathbf{a}_j^{(c)}. \quad (17.46)$$

Como os pesos p_{ij}/r_i formam o perfil da linha i , sua coordenada principal é o centro ponderado das coordenadas padrão das colunas.

De forma dual,

$$\mathbf{f}_j^{(c)} = \sum_{i=1}^I \frac{p_{ij}}{c_j} \mathbf{a}_i^{(r)}. \quad (17.47)$$

Assim, a posição de uma categoria é determinada pela distribuição condicional observada das categorias da outra margem.

As relações são exatas nas L dimensões não nulas. Quando apenas as primeiras $k < L$ dimensões são apresentadas, elas continuam válidas coordenada a coordenada nas dimensões retidas, embora o mapa represente apenas parte da associação.

A Figura 17.2 ilustra essa propriedade para uma tabela simples. As coordenadas principais de uma linha são apresentadas no mesmo sistema das coordenadas padrão das colunas que participam de seu baricentro.

A figura representa uma relação de média ponderada entre as duas margens. A relação baricêntrica não define uma distância qui-quadrado entre uma categoria de linha e uma categoria de coluna.

17.13.3 Centralização ponderada das coordenadas padrão e principais

A ortonormalidade das coordenadas padrão e a dispersão das coordenadas principais já foram estabelecidas na Seção 17.8. Uma propriedade adicional decorre das restrições marginais demonstradas em Seção 17.13.1.

A partir de Equação 17.42 e Equação 17.43, utilizando a SVD compacta de $\mathbf{Q}_{CA}$, obtêm-se

$$\mathbf{V}^\top \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}$$

e

$$\mathbf{U}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}.$$

De fato, a matriz $\mathbf{D}$ da SVD compacta reúne apenas os valores singulares positivos e, portanto, é invertível. Pelas definições de Equação 17.35 e Equação 17.36, segue que

$$\begin{aligned} \mathbf{r}^\top \mathbf{A}_r &= (\mathbf{D}_r^{1/2} \mathbf{1}_I)^\top \mathbf{U} = \mathbf{0}^\top, \\ \mathbf{c}^\top \mathbf{A}_c &= (\mathbf{D}_c^{1/2} \mathbf{1}_J)^\top \mathbf{V} = \mathbf{0}^\top. \end{aligned}$$




Figura 17.2: Relação baricêntrica entre uma linha e as coordenadas padrão das colunas. A posição da linha é a média ponderada das posições das colunas, com pesos dados pelo perfil da própria linha.

As coordenadas principais herdam a mesma centralização:

$$\mathbf{r}^\top \mathbf{F}_r = \mathbf{0}^\top, \quad \mathbf{c}^\top \mathbf{F}_c = \mathbf{0}^\top.$$

Portanto, o centro ponderado das categorias de linhas e o centro ponderado das categorias de colunas coincidem com a origem, tanto nas coordenadas padrão quanto nas coordenadas principais. Essa centralização utiliza as massas das categorias e não, em geral, pesos iguais. A propriedade permanece válida coordenada a coordenada quando apenas parte das dimensões é mantida.

17.13.4 Reconstrução dos desvios da independência

A SVD também permite reconstruir a matriz de frequências relativas observadas a partir da estrutura de independência e das dimensões da associação.

De Equação 17.20,

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r^{1/2} \mathbf{Q}_{CA} \mathbf{D}_c^{1/2}.$$

Substituindo a SVD e utilizando

$$\mathbf{U} = \mathbf{D}_r^{1/2} \mathbf{A}_r, \quad \mathbf{V} = \mathbf{D}_c^{1/2} \mathbf{A}_c,$$

obtem-se

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r \mathbf{A}_r \mathbf{D} \mathbf{A}_c^\top \mathbf{D}_c. \quad (17.48)$$

Consequentemente, para a célula (i, j) ,

$$p_{ij} - r_i c_j = r_i c_j \sum_{\ell=1}^L d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}, \quad (17.49)$$

e

$$p_{ij} = r_i c_j \left[1 + \sum_{\ell=1}^L d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (17.50)$$

A primeira parcela,

$$r_i c_j,$$

é a frequência relativa determinada pelas marginais sob independência. A soma acrescenta os desvios observados representados pelas dimensões da Correspondência.

Cada dimensão contribui por meio de

$$r_i c_j d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}.$$

O sinal do produto $a_{i\ell}^{(r)} a_{j\ell}^{(c)}$ indica se a contribuição daquela dimensão acrescenta ou subtrai valor em relação à frequência relativa determinada pelas marginais. Embora o sinal individual das coordenadas seja arbitrário, sua inversão simultânea nas duas margens preserva esse produto e, portanto, preserva a contribuição da dimensão para o desvio reconstruído.

Com apenas as primeiras $k < L$ dimensões,

$$\tilde{p}_{ij}^{(k)} = r_i c_j \left[1 + \sum_{\ell=1}^k d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (17.51)$$

Essa expressão corresponde à aproximação de posto reduzido de $\mathbf{Q}_{CA}$. A reconstrução truncada é uma aproximação algébrica da associação observada e não garante, isoladamente,

$$\tilde{p}_{ij}^{(k)} \geq 0$$

para todas as células. A reconstrução completa da tabela relativa foi estabelecida na Equação 17.50. Para uma representação truncada, as dimensões descartadas determinam o erro de aproximação da matriz de desvios padronizados.

Como os vetores singulares retidos satisfazem as restrições marginais de Equação 17.42 e Equação 17.43, a reconstrução truncada preserva as marginais $\mathbf{r}$ e $\mathbf{c}$ e, portanto, mantém soma total igual a 1. O que não é garantido é a não negatividade de todas as células; por isso, a reconstrução truncada pode deixar de constituir uma tabela de probabilidades válida.

Para a aproximação com as primeiras k dimensões,

$$\mathbf{Q}_{CA,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top,$$

o erro de reconstrução é

$$\|\mathbf{Q}_{CA} - \mathbf{Q}_{CA,k}\|_F^2 = \sum_{\ell=k+1}^L d_\ell^2 = \sum_{\ell=k+1}^L \lambda_\ell.$$

A soma das inércias principais descartadas é, portanto, simultaneamente a **inércia não representada** e o **erro quadrático de reconstrução** da matriz de desvios padronizados.

17.13.5 Decomposição da estatística de Pearson pelas dimensões

Pela Equação 17.29,

$$\chi^2 = n \sum_{\ell=1}^L \lambda_{\ell} = \sum_{\ell=1}^L n \lambda_{\ell}. \quad (17.52)$$

Cada quantidade

$$n \lambda_{\ell}$$

é a parcela algébrica da estatística de Pearson associada à dimensão ℓ da tabela observada.

Essa decomposição não transforma

$$n \lambda_{\ell}$$

em uma estatística qui-quadrado independente nem fornece, por si só, um teste separado para cada dimensão. A distribuição inferencial da estatística global é tratada na Seção 17.13.6.

17.13.6 Formulação probabilística e teste de independência

Para uma interpretação inferencial, considere duas variáveis categóricas com probabilidades populacionais

$$\pi_{ij} = P(A = i, B = j),$$

com

$$\pi_{ij} \geq 0, \quad \sum_{i=1}^I \sum_{j=1}^J \pi_{ij} = 1.$$

As probabilidades marginais são

$$\pi_{i\cdot} = \sum_{j=1}^J \pi_{ij}$$

e

$$\pi_{.j} = \sum_{i=1}^I \pi_{ij}.$$

A hipótese populacional de independência é

$$H_0 : \pi_{ij} = \pi_{i.}\pi_{.j}, \quad i = 1, \dots, I, \quad j = 1, \dots, J. \quad (17.53)$$

Considere uma amostra de tamanho n formada por observações independentes dessa distribuição conjunta. O vetor das frequências celulares possui distribuição multinomial com parâmetros n e probabilidades π_{ij} .

Proposição 17.3 (Distribuição assintótica da estatística de Pearson sob independência). *Considere uma tabela de contingência $I \times J$, com I e J fixos, obtida de uma amostra multinomial de tamanho n .*

Sob

$$H_0 : \pi_{ij} = \pi_{i.}\pi_{.j},$$

suponha

$$\pi_{i.} > 0, \quad i = 1, \dots, I,$$

e

$$\pi_{.j} > 0, \quad j = 1, \dots, J.$$

Então, quando

$$n \longrightarrow \infty,$$

a estatística de Pearson satisfaz

$$\chi^2 \xrightarrow{d} \chi^2_{(I-1)(J-1)}. \quad (17.54)$$

Esse resultado é **assintótico**, no sentido de Definição 12.1, e deve ser distinguido da identidade exata

$$\chi^2 = n\mathcal{J}.$$

A distribuição qui-quadrado fornece a referência inferencial sob a hipótese populacional de independência, enquanto a identidade $\chi^2 = n\mathcal{J}$ permanece uma propriedade algébrica da tabela observada.

17.14 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne decisões e medidas utilizadas para examinar a representação obtida pela Análise de Correspondência. São tratadas a escolha do número de dimensões, a contribuição das categorias, a qualidade de representação por $\cos^2$, a leitura do mapa reduzido e a projeção de categorias suplementares.

17.14.1 Contribuição e qualidade de representação

A identidade de Equação 17.39,

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2,$$

permite decompor a inércia de cada dimensão entre as categorias.

Definição 17.9 (Contribuição para uma dimensão). A **contribuição da linha i para a dimensão ℓ** é

$$\text{ctr}_{i\ell}^{(r)} = \frac{r_i \left(f_{i\ell}^{(r)} \right)^2}{\lambda_\ell}, \quad (17.55)$$

e a **contribuição da coluna j** é

$$\text{ctr}_{j\ell}^{(c)} = \frac{c_j \left(f_{j\ell}^{(c)} \right)^2}{\lambda_\ell}. \quad (17.56)$$

Para cada dimensão,

$$\sum_{i=1}^I \text{ctr}_{i\ell}^{(r)} = 1, \quad \sum_{j=1}^J \text{ctr}_{j\ell}^{(c)} = 1.$$

A contribuição mede a parcela da inércia de uma dimensão associada a determinada categoria. Ela depende conjuntamente da massa e da posição da categoria.

Uma decomposição diferente avalia quanto da posição de uma categoria é representado por determinada dimensão. Como as coordenadas principais completas preservam a geometria qui-quadrado,

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{\ell=1}^L \left(f_{i\ell}^{(r)} \right)^2,$$

e, de forma dual,

$$d_{\chi^2}^2(j, \mathbf{r}) = \sum_{\ell=1}^L \left(f_{j\ell}^{(c)} \right)^2.$$

Definição 17.10 (Qualidade de representação por dimensão). Para uma linha i com distância positiva ao centro,

$$\cos_{i\ell}^2 = \frac{\left(f_{i\ell}^{(r)} \right)^2}{d_{\chi^2}^2(i, \mathbf{c})}. \quad (17.57)$$

Para uma coluna j com distância positiva ao centro,

$$\cos_{j\ell}^2 = \frac{\left(f_{j\ell}^{(c)} \right)^2}{d_{\chi^2}^2(j, \mathbf{r})}. \quad (17.58)$$

Para uma categoria com distância positiva ao centro, a soma dos $\cos^2$ sobre todas as dimensões é igual a 1. Se a categoria coincide com o centro de sua nuvem, todos os escores principais são nulos e o $\cos^2$ não é definido.

Para as primeiras $k \leq L$ dimensões,

$$\sum_{\ell=1}^k \cos_{i\ell}^2$$

representa a parcela da distância quadrática da linha i ao centro contida na representação reduzida; a definição dual vale para as colunas.

A Tabela 17.4 distingue as duas decomposições.

Tabela 17.4: Diferença entre contribuição e qualidade de representação na Análise de Correspondência.

Medida	Quantidade de referência	Interpretação
contribuição	inércia da dimensão λ_ℓ	participação da categoria na construção da dimensão
$\cos^2$	distância quadrática da categoria ao centro	parcela da posição da categoria representada pela dimensão

A contribuição distribui a **inércia de uma dimensão entre as categorias**, enquanto o $\cos^2$ distribui a **distância de uma categoria entre as dimensões**. Uma categoria pode contribuir fortemente para um eixo sem ser bem representada apenas por ele, e pode ser bem representada por um eixo mesmo contribuindo pouco para sua inércia.

Contribuição e $\cos^2$ respondem a perguntas diferentes e devem ser examinados depois de definida a dimensão da representação. A contribuição identifica quanto cada categoria participa da construção de um eixo, enquanto o $\cos^2$ informa quanto da posição de uma categoria é representado pelas dimensões consideradas.

Quando um valor singular possui multiplicidade maior que um, conforme a Seção 17.12.3, as contribuições e os $\cos^2$ atribuídos separadamente aos eixos desse bloco dependem da base ortonormal escolhida. As somas dessas medidas sobre todas as dimensões do bloco permanecem invariantes.

A escolha do número de dimensões é discutida na Seção 17.14.2.

17.14.2 Escolha do número de dimensões

O número de dimensões com inércia positiva é

$$L = \text{posto}(\mathbf{Q}_{\text{CA}}),$$

conforme definido na formulação da SVD.

Se

$$\mathcal{J} = 0,$$

então

$$\mathbf{Q}_{\text{CA}} = \mathbf{0}$$

e

$$L = 0.$$

Nesse caso, a tabela observada coincide com a estrutura de independência e não existem dimensões com inércia positiva.

Quando

$$L \geq 1,$$

as inércias principais são ordenadas como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_L > 0,$$

e satisfazem

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_{\ell}.$$

Uma representação de dimensão reduzida mantém

$$1 \leq k < L$$

dimensões.

A proporção de inércia associada a cada dimensão foi definida na Equação 17.30, e a proporção acumulada das primeiras k dimensões foi definida na Equação 17.31.

Na escolha da dimensão da representação, a Equação 17.31 informa a parcela da inércia total preservada pelas primeiras k dimensões. A parcela não representada é

$$1 - \Pi_k^{(\text{CA})} = \frac{\sum_{\ell=k+1}^L \lambda_{\ell}}{\sum_{\ell=1}^L \lambda_{\ell}}.$$

A sequência das inércias principais também pode ser examinada em ordem decrescente. Uma mudança acentuada no padrão de queda indica que as dimensões seguintes acrescentam parcelas progressivamente menores da associação observada.

A formulação matemática não determina um ponto de corte universal para a inércia acumulada. Critérios práticos podem ser utilizados como apoio, mas a escolha deve considerar a parcela de inércia representada, o comportamento das inércias principais e se as dimensões retidas podem ser descritas a partir dos perfis e das categorias que mais contribuem para sua construção (Hair et al., 2018; Johnson; Wichern, 2007).

O critério do autovalor maior que 1, utilizado como referência em algumas aplicações da ACP baseada em correlações, não possui justificativa análoga na Análise de Correspondência. As inércias principais dependem da tabela e da geometria qui-quadrado, e sua soma é a inércia total da associação, não o número de variáveis.

Uma representação bidimensional é especialmente conveniente para visualização, mas sua escolha não implica que a associação observada possua apenas duas dimensões.

17.14.3 Leitura da representação reduzida

A leitura de um mapa reduzido deve considerar simultaneamente a inércia representada, a qualidade de representação das categorias e a geometria definida pela técnica.

Para categorias de linhas, distâncias pequenas indicam perfis de linhas semelhantes segundo a métrica qui-quadrado. A mesma interpretação vale entre categorias de colunas. Quando apenas $k < L$ dimensões são representadas, essas distâncias são aproximações das distâncias completas.

O $\cos^2$ informa se a posição de uma categoria é bem representada pelo subespaço escolhido. Uma categoria com $\cos^2$ baixo nas dimensões apresentadas possui parte importante de sua distância ao centro fora do mapa. Sua posição no plano deve, portanto, ser interpretada com cautela.

A contribuição mede quanto uma categoria participa da construção da dimensão. Contribuição elevada e $\cos^2$ elevado não são condições equivalentes, conforme mostrado na Seção 17.14.1.

As massas também devem ser examinadas. Como a distância qui-quadrado pondera diferenças pelos inversos das massas marginais, categorias de pequena massa podem apresentar coordenadas afastadas do centro. Uma coordenada extrema deve ser examinada em conjunto com a massa, a contribuição e o perfil correspondente.

A distância gráfica entre uma categoria de linha e uma categoria de coluna não constitui, em geral, uma distância qui-quadrado definida pela técnica. Relações entre as duas margens devem ser examinadas por meio dos perfis, dos desvios em relação à independência e das relações baricêtricas desenvolvidas na Seção 17.13.2.

17.14.4 Categorias suplementares

A formulação desenvolvida até aqui utiliza categorias **ativas**, que participam da construção da tabela de frequências relativas, das massas, dos perfis e da matriz de desvios padronizados. Consequentemente, essas categorias participam da SVD que determina as dimensões da associação.

Uma categoria **suplementar** é projetada depois que a solução das categorias ativas foi construída. Sua inclusão não modifica os valores singulares, as inércias principais nem as coordenadas das categorias ativas. A projeção utiliza a geometria já determinada para posicionar categorias que não participaram da construção dos eixos (Greenacre, 2017).

17.14.5 Linhas suplementares

Considere uma categoria de linha suplementar cujo perfil em relação às J colunas ativas seja

$$\mathbf{q}_* = [q_{*1} \quad \cdots \quad q_{*J}]^\top \in \mathbb{R}^J,$$

com

$$q_{*j} \geq 0, \quad \sum_{j=1}^J q_{*j} = 1.$$

A relação baricêntrica desenvolvida em Equação 17.46 permite projetar essa categoria no espaço já construído. Se

$$\mathbf{a}_j^{(c)} \in \mathbb{R}^L$$

denota o vetor de coordenadas padrão da coluna ativa j , então as coordenadas principais da linha suplementar são

$$\mathbf{f}_*^{(r)} = \sum_{j=1}^J q_{*j} \mathbf{a}_j^{(c)}. \quad (17.59)$$

A expressão mostra que a linha suplementar é posicionada pelo mesmo princípio baricêntrico utilizado para as linhas ativas. Seu perfil fornece os pesos utilizados para combinar as coordenadas padrão das colunas.

A projeção utiliza uma solução já determinada. Por isso, a linha suplementar recebe coordenadas no espaço principal, mas não participa da determinação de

$$\mathbf{U}, \quad \mathbf{D} \quad \text{ou} \quad \mathbf{V}.$$

17.14.6 Colunas suplementares

A construção é dual para uma coluna suplementar. Considere seu perfil em relação às I linhas ativas,

$$\mathbf{q}_* = [q_{1*} \quad \cdots \quad q_{I*}]^\top \in \mathbb{R}^I,$$

com

$$q_{i*} \geq 0, \quad \sum_{i=1}^I q_{i*} = 1.$$

Se

$$\mathbf{a}_i^{(r)} \in \mathbb{R}^L$$

denota o vetor de coordenadas padrão da linha ativa i , então as coordenadas principais da coluna suplementar são

$$\mathbf{f}_*^{(c)} = \sum_{i=1}^I q_{i*} \mathbf{a}_i^{(r)}. \quad (17.60)$$

A linha suplementar é, portanto, projetada a partir das coordenadas padrão das colunas ativas, enquanto a coluna suplementar é projetada a partir das coordenadas padrão das linhas ativas. Essa dualidade é a mesma que produz as relações baricêntricas das categorias ativas.

17.14.7 Qualidade de representação

A qualidade de representação de uma categoria suplementar pode ser avaliada pela mesma relação geométrica utilizada para as categorias ativas.

Para uma linha suplementar, sua distância qui-quadrado ao perfil médio das colunas ativas é

$$d_{\chi^2}^2(\mathbf{q}_*, \mathbf{c}) = \sum_{j=1}^J \frac{(q_{*j} - c_j)^2}{c_j}.$$

Quando essa distância é positiva, o cosseno quadrado da linha suplementar na dimensão ℓ é

$$\cos_{*\ell}^2 = \frac{\left(f_{*\ell}^{(r)}\right)^2}{d_{\chi^2}^2(\mathbf{q}_*, \mathbf{c})}. \quad (17.61)$$

O valor mede a parcela da posição da categoria suplementar em relação ao perfil médio representada pela dimensão ℓ . A soma dos $\cos^2$ nas dimensões mantidas informa a qualidade de sua representação no subespaço exibido.

A interpretação da contribuição exige outra distinção. As contribuições das categorias ativas decompõem a inércia de uma dimensão porque essas categorias participaram de sua construção. Uma categoria suplementar é projetada depois da determinação dos eixos e, portanto, não participa da decomposição

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)}\right)^2 = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)}\right)^2.$$

Assim, para uma categoria suplementar podem ser examinadas sua posição e sua qualidade de representação, mas ela não possui contribuição ativa para a inércia que determinou a dimensão.

A distinção entre categorias ativas e suplementares separa duas etapas da análise. As categorias ativas determinam a geometria da associação; as categorias suplementares utilizam essa geometria para acrescentar informação interpretativa sem alterar a solução obtida.

Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise de Correspondência será realizada pelo módulo [MEDA](#) (Leblay et al., 2026) do [jamovi](#) (The jamovi project, 2026). O MEDA utiliza procedimentos implementados no pacote [FactoMineR](#) (Lê; Josse; Husson, 2008).

A entrada da análise é uma tabela de contingência, correspondente ao objeto desenvolvido na Seção [17.1](#). Códigos eventualmente utilizados para representar categorias não constituem valores quantitativos; a análise utiliza as frequências conjuntas da tabela.

As dimensões, inércias principais e coordenadas apresentadas pela implementação correspondem à decomposição por SVD e aos sistemas de coordenadas desenvolvidos nas Seção [17.7](#) e Seção [17.8](#). A proporção de inércia representada pelas dimensões pode ser utilizada na escolha da dimensão do mapa, conforme a Seção [17.14.2](#).

As contribuições indicam quais categorias participam da construção de cada dimensão, enquanto os $\cos^2$ descrevem sua qualidade de representação. Esses objetos são definidos na Seção [17.14.1](#) e sua utilização conjunta é discutida na Seção [17.14.3](#).

Categorias suplementares são projetadas depois da construção da solução ativa e não alteram os valores singulares, as inércias principais ou as coordenadas das categorias ativas, conforme a Seção [17.14.4](#).

17.15 Síntese

A Análise de Correspondência representa associações entre as categorias de duas variáveis a partir de uma tabela de contingência

$$\mathbf{N} = (n_{ij}) \in \mathbb{N}_0^{I \times J}.$$

A matriz de frequências relativas

$$\mathbf{P} = \frac{1}{n} \mathbf{N}$$

determina as massas

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \quad \text{e} \quad \mathbf{c} = \mathbf{P}^\top \mathbf{1}_I$$

e os perfis condicionais das linhas e das colunas.

Sob independência, a estrutura de referência é

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top.$$

A Correspondência analisa o afastamento dessa estrutura na geometria qui-quadrado. Os desvios padronizados da independência são reunidos na matriz

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

Sua norma de Frobenius determina a inércia total,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

A decomposição em valores singulares

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

decompõe essa inércia em

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell, \quad \lambda_\ell = d_\ell^2.$$

As inércias principais quantificam a parcela da associação representada em cada dimensão. Uma aproximação de posto reduzido preserva as dimensões que concentram maior parcela dessa estrutura.

As coordenadas principais fornecem representações euclidianas da geometria qui-quadrado de cada margem. Quando todas as dimensões não nulas são mantidas, as distâncias euclidianas entre pontos de linhas reproduzem as distâncias qui-quadrado entre seus perfis, e a relação dual vale para as colunas. As relações baricêtricas conectam as duas nuvens, mas não estabelecem uma distância qui-quadrado direta entre uma categoria de linha e uma categoria de coluna.

Para a tabela observada,

$$\chi^2 = n\mathcal{J}.$$

Essa identidade relaciona a geometria da Correspondência à estatística de Pearson. A inércia descreve o afastamento observado da independência, enquanto a utilização de χ^2 em um teste populacional requer um modelo probabilístico e condições inferenciais adicionais.

A Correspondência e a ACP compartilham decomposições de baixa dimensão, mas operam sobre objetos e geometrias diferentes. A ACP representa variabilidade em dados quantitativos; a Correspondência representa associações entre perfis de uma tabela de contingência.

Na Capítulo 18, o problema estatístico passa da representação de associações entre categorias para a comparação conjunta de várias respostas quantitativas entre grupos ou condições previamente definidos. A formulação utiliza o modelo linear multivariado, as matrizes de hipótese e erro e critérios baseados em sua estrutura espectral.

18 Formulação da MANOVA

A Análise de Variância Multivariada, MANOVA, testa hipóteses sobre vetores de médias ou, de forma mais geral, sobre funções estimáveis dos parâmetros de um modelo linear com várias respostas. A formulação considera p respostas quantitativas observadas nas mesmas unidades. Grupos, tratamentos, fatores e covariáveis são representados na matriz de delineamento.

O modelo linear multivariado definido em Definição 11.3 é

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

A MANOVA compara a variação multivariada atribuída à hipótese com a variação residual, representadas pelas matrizes $\mathbf{H}$ e $\mathbf{E}$. Essa comparação conduz a um problema de autovalores generalizados cujas raízes são agregadas pelos critérios de Wilks, Pillai, Hotelling–Lawley e Roy (Anderson, 2003; Johnson; Wichern, 2007).

O capítulo desenvolve a construção das matrizes $\mathbf{H}$ e $\mathbf{E}$, a formulação espectral, os quatro critérios e seus pressupostos. Os aprofundamentos apresentam a base probabilística da inferência, as propriedades da solução e os procedimentos necessários para sua aplicação, sem reconstruir os resultados já estabelecidos em Definição 11.3, Definição 11.17, Definição 11.18 e Definição 11.11.

Os elementos da formulação são resumidos na Tabela 18.1.

Tabela 18.1: Elementos da formulação da MANOVA.

Elemento	Objeto	Papel na MANOVA
respostas	$\mathbf{y}$	reúne as p respostas observadas nas mesmas unidades
delineamento	$\mathbf{Z}$	representa grupos, tratamentos, covariáveis e demais termos
parâmetros	$\mathbf{B}$	determina os vetores de médias condicionais
hipótese	$\mathbf{C}_1\mathbf{B} = \Theta_0$	especifica uma função estimável sobre todas as respostas

Elemento	Objeto	Papel na MANOVA
variação atribuída à hipótese	$\mathbf{H}$	mede o afastamento observado em relação a H_0
variação residual	$\mathbf{E}$	mede a variabilidade conjunta não explicada pelo modelo
comparação direcional	$\mathbf{a}^\top \mathbf{H} \mathbf{a} / \mathbf{a}^\top \mathbf{E} \mathbf{a}$	compara hipótese e erro para uma combinação das respostas
solução espectral	raízes e direções características	identifica direções extremas e quantifica o efeito relativo
critérios de teste	Wilks, Pillai, Hotelling–Lawley e Roy	agregam as mesmas raízes de formas distintas

18.1 O problema de comparação multivariada

Considere inicialmente $K \geq 2$ grupos e um vetor de p respostas para cada unidade,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

Se o vetor de médias do grupo k é

$$\mu_k = \begin{pmatrix} \mu_{k1} \\ \vdots \\ \mu_{kp} \end{pmatrix} \in \mathbb{R}^p, \quad k = 1, \dots, K,$$

a hipótese de igualdade entre os grupos é

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_K. \quad (18.1)$$

A alternativa afirma que pelo menos dois desses vetores de médias diferem.

Quando

$$p = 1,$$

a hipótese em Equação 18.1 é univariada e a comparação pode ser expressa pela razão entre uma soma de quadrados associada ao efeito e uma soma de quadrados residual.

Quando

$$p > 1,$$

o afastamento entre os grupos possui direção no espaço das respostas. Uma diferença pequena em cada resposta considerada isoladamente pode formar uma combinação linear com separação relevante, enquanto diferenças marginais aparentemente grandes podem refletir informação redundante entre respostas associadas.

A MANOVA considera simultaneamente a magnitude das diferenças entre os vetores de médias, a variabilidade residual de cada resposta e as covariâncias residuais entre as respostas.

Por isso, o problema não é equivalente a realizar p análises de variância independentes. A estrutura conjunta é representada por matrizes de somas de quadrados e produtos cruzados.

18.2 A hipótese no modelo linear multivariado

O problema de comparação entre grupos é uma aplicação do modelo linear multivariado. Indicadores de grupos, tratamentos, fatores e covariáveis são incorporados à matriz de delineamento $\mathbf{Z}$.

A hipótese linear geral foi definida em Definição 11.17 como

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (18.2)$$

Na MANOVA formulada para as p respostas originais,

$$\mathbf{C}_2 = \mathbf{I}_p,$$

e a hipótese torna-se

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0, \quad (18.3)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times p}.$$

A matriz $\mathbf{C}_1$ reúne os contrastes ou combinações dos parâmetros que definem o efeito testado. Consideraremos suas linhas linearmente independentes,

$$\text{posto}(\mathbf{C}_1) = g, \quad (18.4)$$

e a função $\mathbf{C}_1\mathbf{B}$ estimável. Pela condição de Equação 11.117,

$$\mathbf{C}_1 = \mathbf{C}_1\mathbf{Z}^+\mathbf{Z}. \quad (18.5)$$

Nessas condições, os graus de liberdade da hipótese são

$$\nu_H = g. \quad (18.6)$$

Para o efeito completo de K grupos,

$$g = K - 1. \quad (18.7)$$

Assim, a hipótese de igualdade dos vetores de médias em Equação 18.1 é um caso particular da hipótese linear geral definida em Definição 11.17.

18.2.1 Matrizes de hipótese e erro

A SQPC associada à hipótese foi definida em Definição 11.18. Para a hipótese em Equação 18.3, denote-a por

$$\mathbf{H} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{H} = \mathbf{H}^\top \succeq \mathbf{0}.$$

A matriz $\mathbf{H}$ representa a variação multivariada associada ao afastamento observado da hipótese. Seus elementos diagonais correspondem às parcelas das respostas individuais, enquanto os elementos fora da diagonal registram produtos cruzados entre esses afastamentos.

A SQPC residual definida em Definição 11.11 é

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{E} = \mathbf{E}^\top \succeq \mathbf{0}.$$

Ela representa a variação residual conjunta utilizada como referência para avaliar o efeito.

A Tabela 18.2 resume essas funções.

Tabela 18.2: Funções das matrizes de hipótese e erro na MANOVA.

Matriz	Origem	Interpretação
H	hipótese testada	variação multivariada associada ao afastamento observado de H_0
E	resíduos do modelo	variação multivariada residual utilizada como referência

Se

$$\mathbf{H} = \mathbf{0},$$

não há afastamento observado da hipótese nas funções paramétricas consideradas. Quando $\mathbf{H} \neq \mathbf{0}$, sua magnitude deve ser interpretada relativamente à estrutura residual representada por $\mathbf{E}$.

A formulação da MANOVA consiste, portanto, em comparar essas duas estruturas matriciais.

18.3 Hipótese e erro em uma combinação linear das respostas

Considere uma combinação linear das p respostas definida por

$$\mathbf{W} = \mathbf{a}^\top \mathbf{Y}, \quad \mathbf{a} \in \mathbb{R}^p. \quad (18.8)$$

Aplicando a mesma combinação linear às matrizes observadas de hipótese e erro, obtêm-se os escalares

$$h(\mathbf{a}) = \mathbf{a}^\top \mathbf{H} \mathbf{a} \quad (18.9)$$

e

$$e(\mathbf{a}) = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (18.10)$$

As duas expressões têm a forma definida em Definição 2.23.

A quantidade

$$h(\mathbf{a})$$

mede a variação atribuída à hipótese na combinação das respostas definida por $\mathbf{a}$, enquanto

$$e(\mathbf{a})$$

mede a variação residual dessa mesma combinação.

Para a formulação espectral clássica desenvolvida a seguir, suponha

$$\mathbf{E} \succ \mathbf{0}. \quad (18.11)$$

Então,

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0},$$

e pode-se definir

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (18.12)$$

A expressão em Equação 18.12 é o quociente de Rayleigh generalizado definido em Definição 5.12, aplicado ao par

$$(\mathbf{H}, \mathbf{E}).$$

As matrizes $\mathbf{H}$ e $\mathbf{E}$ fornecem, respectivamente, as formas quadráticas associadas à hipótese e ao erro.

A razão é invariante à escala de $\mathbf{a}$. Para qualquer

$$c \neq 0,$$

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}).$$

Portanto, interessa a direção determinada por $\mathbf{a}$, e não seu comprimento.

Uma direção apresenta grande razão hipótese/erro quando a combinação correspondente das respostas exibe variação associada à hipótese elevada relativamente à variabilidade residual nessa mesma combinação.

18.4 Problema espectral da MANOVA

O problema consiste em identificar as direções nas quais a razão em Equação 18.12 assume seus valores extremos. Pelo resultado de Teorema 5.8, aplicado ao par simétrico

$$(\mathbf{H}, \mathbf{E}),$$

com

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

os extremos de

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}} \tag{18.13}$$

são determinados pelo problema

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}. \tag{18.14}$$

Essa é a estrutura de autovalor generalizado definida em Definição 5.11.

Definição 18.1 (Raízes características da MANOVA). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

simétricas, com

$$\mathbf{H} \succeq \mathbf{0}$$

e

$$\mathbf{E} \succ \mathbf{0}.$$

As **raízes características da MANOVA** são os autovalores generalizados

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

do par $(\mathbf{H}, \mathbf{E})$. Como $\mathbf{E} \succ \mathbf{0}$, os autovetores generalizados associados podem ser escolhidos com a normalização

$$\alpha_j^\top \mathbf{E} \alpha_j = 1.$$

Com essa convenção,

$$\mathbf{H} \alpha_j = \lambda_j \mathbf{E} \alpha_j.$$

Se

$$r_H = \text{posto}(\mathbf{H}),$$

então exatamente r_H raízes são positivas.

Como a matriz de hipótese associada a uma função de posto g satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(p, g),$$

tem-se

$$r_H \leq \min(p, g). \tag{18.15}$$

No efeito completo de K grupos,

$$g = K - 1,$$

logo

$$r_H \leq \min(p, K - 1). \quad (18.16)$$

Assim, o número de direções nas quais um efeito pode aparecer é limitado simultaneamente pelo número de respostas e pelo número de contrastes independentes da hipótese.

Pelo produto interno induzido definido em Definição 3.16, os autovetores generalizados podem ser escolhidos ortonormais na geometria determinada por $\mathbf{E}$:

$$\alpha_j^\top \mathbf{E} \alpha_\ell = \delta_{j\ell}. \quad (18.17)$$

As direções características não precisam, portanto, ser ortogonais na geometria euclidiana original das respostas.

18.4.1 Padronização pela dispersão residual e interpretação geométrica

Como

$$\mathbf{E} \succ \mathbf{0},$$

a raiz quadrada principal de $\mathbf{E}$ e sua inversa existem por Definição 5.9.

Defina

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

e o problema generalizado transforma-se em

$$\mathbf{M}_{\text{HE}} \mathbf{z} = \lambda \mathbf{z}, \quad (18.18)$$

em que

$$\mathbf{M}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (18.19)$$

Como $\mathbf{H} \succeq \mathbf{0}$,

$$\mathbf{M}_{\text{HE}} = \mathbf{M}_{\text{HE}}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{M}_{\text{HE}}) = \text{posto}(\mathbf{H}) = r_H,$$

de modo que seus r_H autovalores positivos são exatamente as raízes positivas da MANOVA.

A transformação também produz

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = \mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}.$$

Portanto,

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}. \quad (18.20)$$

A transformação pela matriz de erro converte a geometria residual em uma geometria euclidiana. Nesse sistema, $\mathbf{M}_{\text{HE}}$ representa a magnitude da hipótese relativamente à dispersão residual.

A Figura 18.1 ilustra essa transformação no espaço das combinações lineares. Antes da padronização, o conjunto de direções que satisfaz

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

forma uma elipse determinada pela geometria residual. Sob a transformação

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a},$$

esse mesmo conjunto passa a satisfazer

$$\mathbf{z}^\top \mathbf{z} = 1,$$

tornando-se o círculo unitário. Nesse sistema padronizado, as direções características são os autovetores de $\mathbf{M}_{\text{HE}}$.




Figura 18.1: Branqueamento da geometria residual. À esquerda, o contorno representa as combinações lineares normalizadas por $\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$. Após a transformação $\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}$, a métrica residual torna-se euclidiana e o contorno transforma-se no círculo unitário. As linhas indicam as duas direções características do problema.

A Figura 18.1 não representa observações, médias de grupos ou regiões de probabilidade. O contorno representa o conjunto de combinações lineares normalizadas pela forma quadrática residual. O branqueamento também não elimina a variabilidade residual dos dados; ele reexpressa sua métrica de modo que

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

se torne a norma euclidiana

$$\mathbf{z}^\top \mathbf{z}.$$

Nesse sistema, as direções características podem ser interpretadas diretamente como os eixos espectrais de $\mathbf{M}_{\text{HE}}$.

Se uma direção característica for normalizada por

$$\alpha_j^\top \mathbf{E} \alpha_j = 1,$$

então

$$\alpha_j^\top \mathbf{H} \alpha_j = \lambda_j. \quad (18.21)$$

Cada raiz λ_j representa, assim, a razão hipótese/erro na respectiva direção característica normalizada. As raízes ordenam as direções segundo a intensidade do efeito relativamente à estrutura residual.

A hipótese matricial é, desse modo, convertida em uma coleção ordenada de razões hipótese/erro. Os quatro critérios clássicos da MANOVA agregam essa mesma coleção de formas distintas.

18.5 Critérios multivariados

Considere as raízes características

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

do par $(\mathbf{H}, \mathbf{E})$ definido em Definição 18.1, sob

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0}.$$

Se

$$r_H = \text{posto}(\mathbf{H}),$$

apenas

$$\lambda_1, \dots, \lambda_{r_H}$$

são positivas, quando $r_H > 0$.

Os quatro critérios clássicos da MANOVA agregam essa mesma coleção de raízes em uma estatística global. Para algumas representações, é útil definir

$$\theta_j = \frac{\lambda_j}{1 + \lambda_j}, \quad j = 1, \dots, p. \quad (18.22)$$

Como $\lambda_j \geq 0$,

$$0 \leq \theta_j < 1,$$

e a transformação preserva a ordenação das raízes.

Definição 18.2 (Lambda de Wilks). A **lambda de Wilks** é

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} = \prod_{j=1}^p \frac{1}{1 + \lambda_j}. \quad (18.23)$$

De fato,

$$\begin{aligned} |\mathbf{E} + \mathbf{H}| &= |\mathbf{E}| |\mathbf{I}_p + \mathbf{E}^{-1}\mathbf{H}| \\ &= |\mathbf{E}| \prod_{j=1}^p (1 + \lambda_j), \end{aligned}$$

o que produz a representação pelas raízes.

Em termos de Equação 18.22,

$$\Lambda_W = \prod_{j=1}^p (1 - \theta_j). \quad (18.24)$$

A lambda de Wilks satisfaz

$$0 < \Lambda_W \leq 1,$$

com

$$\Lambda_W = 1$$

se, e somente se,

$$\mathbf{H} = \mathbf{0}.$$

Valores menores correspondem a maior afastamento relativo entre hipótese e erro. Sua ligação com a razão de verossimilhanças é desenvolvida na Seção 18.9.1.1.

Definição 18.3 (Traço de Pillai). O **traço de Pillai** é

$$V = \text{tr} [\mathbf{H} (\mathbf{H} + \mathbf{E})^{-1}] = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}. \quad (18.25)$$

Portanto,

$$V = \sum_{j=1}^p \theta_j.$$

Cada raiz contribui por uma quantidade limitada ao intervalo $[0, 1)$, de modo que raízes muito elevadas não produzem contribuições ilimitadas ao critério (Pillai, 1955).

Definição 18.4 (Traço de Hotelling–Lawley). O **traço de Hotelling–Lawley** é

$$U = \text{tr} (\mathbf{E}^{-1} \mathbf{H}) = \sum_{j=1}^p \lambda_j. \quad (18.26)$$

O critério utiliza diretamente a soma das razões hipótese/erro. Como

$$\lambda_j \geq 0,$$

tem-se

$$U \geq 0,$$

com igualdade se, e somente se, $\mathbf{H} = \mathbf{0}$.

Definição 18.5 (Maior raiz de Roy). A **maior raiz de Roy** é

$$\Theta_R = \lambda_1. \quad (18.27)$$

Pela caracterização do quociente de Rayleigh generalizado,

$$\Theta_R = \max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (18.28)$$

Esse critério utiliza apenas a direção característica de maior razão hipótese/erro. Neste capítulo, a maior raiz de Roy é expressa na escala não limitada λ_1 . Algumas apresentações utilizam

a escala limitada $\theta_1 = \lambda_1/(1 + \lambda_1)$, correspondente à maior raiz de $\mathbf{H}(\mathbf{H} + \mathbf{E})^{-1}$. Como essa transformação é estritamente crescente, as duas parametrizações produzem a mesma ordenação do teste quando a calibração é realizada na escala correspondente (Anderson, 2003; Johnson; Wichern, 2007).

18.6 Uma mesma estrutura, quatro formas de agregação

Os quatro critérios são funções da mesma coleção de raízes características

$$\lambda_1, \dots, \lambda_p$$

obtida do problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}.$$

As raízes nulas não alteram os critérios. A Tabela 18.3 resume as diferentes formas de agregação.

Tabela 18.3: Critérios clássicos da MANOVA como funções das mesmas raízes características.

Critério	Expressão em função das raízes	Forma de agregação	Evidência crescente contra H_0
Wilks	$\prod_{j=1}^p (1 + \lambda_j)^{-1}$	produto	valores menores
Pillai	$\sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}$	soma limitada	valores maiores
Hotelling–Lawley	$\sum_{j=1}^p \lambda_j$	soma direta	valores maiores
Roy	λ_1	maior raiz	valores maiores

Roy concentra a comparação na direção dominante; Hotelling–Lawley soma diretamente as magnitudes das raízes; Pillai limita a contribuição individual de cada raiz; e Wilks combina multiplicativamente toda a coleção.

Os critérios podem, portanto, responder de forma diferente à distribuição do efeito entre as direções características, embora todos sejam construídos a partir da mesma relação espectral entre $\mathbf{H}$ e $\mathbf{E}$.

O cálculo dos quatro critérios depende apenas das matrizes observadas $\mathbf{H}$ e $\mathbf{E}$. A obtenção de valores críticos e valores p acrescenta uma etapa inferencial, cuja calibração depende do

número de respostas, dos graus de liberdade da hipótese e do erro e do modelo probabilístico adotado. Essa distinção será desenvolvida na Seção 18.9.2.

18.7 Pressupostos e limites

A MANOVA combina uma estrutura para as médias, uma comparação algébrica entre hipótese e erro e, na inferência clássica, um modelo probabilístico. As condições abaixo possuem funções diferentes dentro dessa construção.

18.7.1 Estrutura da média e estimabilidade

O modelo pressupõe

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

Grupos, tratamentos, covariáveis e demais efeitos relevantes devem estar representados adequadamente em $\mathbf{Z}$, pois a especificação da média determina tanto os resíduos quanto a hipótese avaliada.

Para

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

a função paramétrica deve ser estimável. Conforme Equação 18.5,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}.$$

Essa é uma condição de identificação da hipótese e não depende da normalidade multivariada.

18.7.2 Independência entre unidades

Na formulação probabilística clássica, os vetores de erros associados a unidades distintas são independentes:

$$\mathbf{e}_1, \dots, \mathbf{e}_n.$$

A dependência entre as componentes de um mesmo vetor resposta é permitida e representada por Σ . Dependência não modelada entre unidades, como em medidas repetidas, séries temporais ou estruturas espaciais, exige uma formulação de covariância apropriada.

18.7.3 Covariância residual comum

O modelo clássico utiliza

$$\text{Cov}(\mathbf{e}_i | \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n.$$

No problema de comparação entre grupos, isso corresponde à utilização de uma matriz de covariâncias residual populacional comum.

Na formulação probabilística clássica, essa condição permite representar a dispersão residual por uma única matriz populacional Σ . A matriz $\mathbf{E}$ continua sendo a SQPC residual observada do modelo. Se as matrizes de covariâncias diferem entre grupos ou unidades, os critérios ainda podem ser calculados quando as operações matriciais necessárias existem, mas a calibração inferencial clássica normal–Wishart deixa de corresponder exatamente ao mecanismo gerador dos dados.

18.7.4 Não singularidade populacional e amostral

A formulação clássica considera

$$\Sigma \succ \mathbf{0}.$$

Pela Proposição 8.3, essa condição populacional exclui a existência de uma combinação linear não trivial das respostas residuais com variância igual a zero.

A condição observada necessária ao problema espectral desenvolvido neste capítulo é

$$\mathbf{E} \succ \mathbf{0}.$$

Algebricamente, uma condição necessária para essa definição positiva é

$$\nu_E \geq p.$$

Essa desigualdade não é suficiente para uma matriz de dados arbitrária, pois relações lineares exatas entre as respostas residuais podem tornar $\mathbf{E}$ singular mesmo quando existem graus de liberdade residuais suficientes.

Sob o modelo normal clássico, com $\Sigma \succ \mathbf{0}$, o resultado estabelecido na Equação 12.43 mostra que

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se, $\nu_E \geq p$. A matriz observada $\mathbf{E}$ é uma realização dessa SQPC residual aleatória.

Quando $\mathbf{E}$ é singular, não existem diretamente

$$\mathbf{E}^{-1} \quad \text{e} \quad \mathbf{E}^{-1/2},$$

e a formulação espectral clássica adotada neste capítulo deixa de se aplicar. Formulações baseadas em pseudoinversas, regularização ou métodos próprios para situações de alta dimensão não são desenvolvidas neste capítulo.

18.7.5 Normalidade multivariada

A normalidade não é uma condição para a definição algébrica da MANOVA. As matrizes

$$\mathbf{H}, \quad \mathbf{E},$$

suas raízes características e os quatro critérios podem ser construídos sempre que as operações matriciais necessárias estejam definidas.

Sob a formulação normal clássica adotada neste capítulo, a normalidade dos erros acrescenta a estrutura probabilística que conduz às distribuições Wishart de $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$, à sua independência sob H_0 e à calibração inferencial clássica dos critérios.

A hipótese de normalidade refere-se aos erros condicionais à estrutura de médias representada por $\mathbf{Z}$. Ela não equivale à exigência de que a distribuição marginal obtida ao reunir todas as respostas observadas seja uma única normal multivariada.

No caso de comparação entre grupos, por exemplo, pode-se ter

$$\mathbf{Y}_i \mid G_i = k \sim N_p(\mu_k, \Sigma),$$

com vetores de médias distintos entre os grupos. A distribuição marginal resultante da mistura desses grupos não precisa pertencer à família normal multivariada, mesmo quando o modelo normal condicional está corretamente especificado.

Consequentemente, um diagnóstico aplicado diretamente às respostas sem considerar a estrutura sistemática das médias avalia uma propriedade diferente da normalidade dos erros assumida pelo modelo. A avaliação desse pressuposto deve ser compatível com a formulação condicional utilizada na MANOVA.

Devem ser distinguidos:

- a formulação algébrica baseada em $\mathbf{H}$ e $\mathbf{E}$;

- o modelo probabilístico normal com covariância residual comum;
- a calibração inferencial clássica dos critérios.

Procedimentos robustos, heterocedásticos, de permutação ou reamostragem constituem extensões metodológicas da formulação clássica e serão tratados nas etapas posteriores de aplicação.

18.7.6 Associação residual, condicionamento e singularidade

Associação residual elevada entre as respostas não invalida, por si só, a MANOVA. A dependência entre as componentes de um mesmo vetor de erros é representada por Σ e, nos dados observados, pelos produtos cruzados reunidos em $\mathbf{E}$. Considerar essa dependência é precisamente uma das razões para realizar uma análise conjunta das respostas.

Entretanto, relações lineares aproximadamente exatas entre as respostas residuais podem produzir uma matriz $\mathbf{E}$ mal condicionada. Nesse caso, $\mathbf{E}$ ainda é invertível, mas pequenas perturbações nos dados podem provocar alterações relativamente grandes em sua inversa, nas raízes e nas direções características. Portanto, invertibilidade não implica necessariamente estabilidade numérica.

A singularidade, tratada na Seção 18.7.4, constitui o caso limite: uma relação linear residual exata reduz o posto de $\mathbf{E}$ e impede a aplicação direta da formulação espectral clássica adotada no capítulo.

Devem ser distinguidas, portanto, três situações: associação residual entre as respostas, que é admitida pela MANOVA; quase dependência linear residual, que pode gerar mau condicionamento; e dependência linear residual exata, que pode tornar $\mathbf{E}$ singular.

18.8 Relações com outras técnicas

A MANOVA compartilha estruturas com outros procedimentos inferenciais e multivariados. As relações abaixo mostram como a comparação entre hipótese e erro se especializa ou recebe outra interpretação conforme o problema estatístico.

18.8.1 ANOVA

Quando existe uma única resposta,

$$p = 1,$$

as matrizes de hipótese e erro reduzem-se a escalares,

$$\mathbf{H} = (H), \quad \mathbf{E} = (E),$$

e existe no máximo uma raiz característica,

$$\lambda = \frac{H}{E}.$$

Se ν_H e ν_E são os graus de liberdade da hipótese e do erro, respectivamente, então

$$F = \frac{H/\nu_H}{E/\nu_E} = \frac{\nu_E}{\nu_H} \lambda. \quad (18.29)$$

Os quatro critérios multivariados tornam-se, nesse caso, funções monotônicas da mesma razão utilizada pela ANOVA. A MANOVA preserva, portanto, a comparação entre hipótese e erro, substituindo somas de quadrados escalares por matrizes de somas de quadrados e produtos cruzados.

18.8.2 T^2 de Hotelling

Na comparação clássica de duas populações,

$$K = 2,$$

há apenas um contraste independente e, portanto,

$$g = 1.$$

Existe no máximo uma raiz característica positiva.

Para duas amostras independentes de tamanhos n_1 e n_2 , com matriz de covariâncias comum, a relação com a estatística definida em Definição 12.6 é

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}. \quad (18.30)$$

Assim, o teste T^2 para duas populações e a MANOVA de dois grupos utilizam a mesma razão multivariada entre diferença de médias e dispersão residual.

Com hipóteses de posto superior a 1, várias raízes podem ser positivas e os critérios de Wilks, Pillai, Hotelling–Lawley e Roy passam a agregá-las de formas distintas.

18.8.3 Regressão multivariada

MANOVA e regressão multivariada utilizam o mesmo modelo

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

A diferença está na estrutura representada em $\mathbf{Z}$ e nas hipóteses formuladas sobre $\mathbf{B}$. Indicadores e contrastes podem representar grupos ou fatores, enquanto variáveis quantitativas podem representar covariáveis ou preditores contínuos.

Em ambos os casos, hipóteses estimáveis sobre

$$\mathbf{C}_1\mathbf{B}$$

podem ser avaliadas pelas mesmas matrizes de hipótese e erro.

18.8.4 Análise Discriminante

MANOVA e Análise Discriminante compartilham estruturas de dispersão associadas às diferenças entre grupos e à variabilidade dentro dos grupos.

Na MANOVA, o problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

procura direções em que a magnitude da hipótese seja elevada relativamente à dispersão residual. As raízes resultantes sustentam os critérios utilizados para testar a hipótese multivariada.

Na Seção 19.6, uma estrutura espectral relacionada será utilizada com outro objetivo: construir combinações das variáveis que evidenciem a separação entre grupos previamente conhecidos e possam sustentar procedimentos de discriminação ou classificação.

A proximidade algébrica não implica equivalência estatística. Na MANOVA, os grupos ou efeitos fazem parte da estrutura explicativa e o objetivo principal é testar diferenças no vetor resposta. Na Análise Discriminante, a pertença aos grupos é conhecida na amostra de referência e o interesse passa à representação da separação e, em determinadas formulações, à classificação de novas observações.

18.9 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte desenvolve propriedades algébricas e probabilísticas da MANOVA. São examinadas a estrutura normal–Wishart das matrizes de hipótese e erro, a relação entre a lambda de Wilks e a razão de verossimilhanças, a calibração inferencial dos critérios, a invariância sob transformações lineares não singulares das respostas e as condições de identificação das direções características.

18.9.1 Base probabilística dos critérios

Considere

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

com erros independentes

$$\mathbf{e}_i \sim N_p(\mathbf{0}, \Sigma), \quad i = 1, \dots, n, \quad (18.31)$$

em que

$$\Sigma \succ \mathbf{0}$$

é comum às unidades consideradas pelo modelo.

Para uma hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

com

$$\text{posto}(\mathbf{C}_1) = g,$$

os graus de liberdade residuais são

$$\nu_E = n - \text{posto}(\mathbf{Z}),$$

conforme Definição 11.12 e Equação 11.77.

Denote por

$$\mathbf{H}$$

a SQPC aleatória da hipótese e por

$$\mathbf{E}_{\text{res}}$$

a SQPC residual aleatória. Especializando Proposição 12.12 para as respostas originais, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma), \quad (18.32)$$

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(\nu_E, \Sigma), \quad (18.33)$$

e

$$\mathbf{H} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (18.34)$$

A distribuição da SQPC residual também foi estabelecida em Proposição 12.10. Esses resultados não precisam ser novamente demonstrados.

A estrutura normal–Wishart fornece a base probabilística dos testes clássicos da MANOVA. A mesma matriz populacional

$$\Sigma$$

descreve a dispersão residual das respostas e sustenta a utilização de uma única matriz de erro como referência para a comparação com $\mathbf{H}$.

Quando diferentes grupos possuem matrizes de covariâncias populacionais distintas, essa interpretação comum deixa de ser exata. As consequências dessa violação são discutidas na Seção 18.7.3.

18.9.1.1 Lambda de Wilks e razão de verossimilhanças

A lambda de Wilks possui uma ligação direta com a razão de verossimilhanças do modelo linear normal multivariado. Essa ligação conecta a formulação por modelos encaixados à representação espectral da MANOVA.

Para modelos encaixados, Proposição 11.13 fornece

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H},$$

em que $\mathbf{E}_F$ e $\mathbf{E}_R$ são as SQPCs residuais dos modelos completo e reduzido.

A Equação 12.64 estabelece

$$\Lambda_{RV} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}.$$

Na notação deste capítulo,

$$\mathbf{E}_F = \mathbf{E}, \quad \mathbf{E}_R = \mathbf{E} + \mathbf{H}.$$

Como Equação 12.65 define a razão de determinantes como lambda de Wilks,

$$\Lambda_{RV} = \Lambda_W^{n/2}. \quad (18.35)$$

A representação

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}$$

evidencia sua origem na comparação entre modelos encaixados, enquanto

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}$$

evidencia sua representação espectral (Wilks, 1932).

Os critérios de Pillai, Hotelling–Lawley e Roy são construídos a partir da mesma estrutura aleatória $(\mathbf{H}, \mathbf{E}_{\text{res}})$, embora não correspondam diretamente à razão de verossimilhanças do modelo normal.

A formulação distingue, portanto, três níveis:

1. as matrizes observadas $\mathbf{H}$ e $\mathbf{E}$ e suas raízes características;
2. os quatro critérios globais calculados a partir dessas raízes;
3. a calibração inferencial clássica, que acrescenta a estrutura probabilística normal–Wishart.

A definição dos critérios pertence aos dois primeiros níveis. A estrutura normal–Wishart fornece sua fundamentação probabilística clássica, mas não é necessária para definir algebricamente $\mathbf{H}$, $\mathbf{E}$ ou suas raízes características.

As condições do modelo e os limites da inferência são apresentados na Seção 18.7.

18.9.2 Calibração inferencial dos critérios

Os valores observados de Wilks, Pillai, Hotelling–Lawley e Roy são funções algébricas de $\mathbf{H}$ e $\mathbf{E}$. Um valor p exige, adicionalmente, uma distribuição de referência para o critério sob H_0 .

No modelo normal multivariado, essa distribuição decorre da estrutura normal–Wishart estabelecida em Equação 18.32, Equação 18.33 e Equação 18.34. Sua forma depende de

$$p, \quad g \quad \text{e} \quad \nu_E,$$

isto é, do número de respostas, do posto da hipótese e dos graus de liberdade residuais.

Em configurações particulares, a distribuição de referência pode ser expressa exatamente por meio de uma distribuição F . Em problemas gerais com várias raízes, são utilizadas transformações ou aproximações cujos graus de liberdade dependem do critério e das dimensões do problema. Portanto, expressões aproximadas para Wilks, Pillai e Hotelling–Lawley não devem ser tratadas como se fossem a mesma transformação aplicada a estatísticas intercambiáveis (Anderson, 2003).

Quando $r_H \leq 1$, existe no máximo uma raiz não nula, e os critérios satisfazem

$$\Lambda_W = \frac{1}{1 + \lambda_1}, \quad V = \frac{\lambda_1}{1 + \lambda_1}, \quad U = \lambda_1, \quad \Theta_R = \lambda_1.$$

Pela Equação 18.15, essa configuração ocorre necessariamente quando $p = 1$ ou $g = 1$. Os quatro critérios são, então, funções monótonas da mesma raiz e, sob uma calibração consistente, conduzem ao mesmo teste.

Quando existem duas ou mais raízes positivas, os critérios agregam o efeito de formas diferentes. A lambda de Wilks utiliza o produto de todas as contribuições; Pillai soma contribuições limitadas; Hotelling–Lawley soma diretamente as raízes; e Roy utiliza somente a maior delas. Suas estatísticas transformadas, seus graus de liberdade aproximados e seus valores p podem, por isso, diferir.

A calibração clássica pressupõe que a matriz residual seja não singular e que a estrutura normal–Wishart seja adequada. Se $\mathbf{E}$ é singular ou se as condições probabilísticas são substituídas por hipóteses mais fracas, as distribuições clássicas e suas aproximações não são automaticamente válidas.

Um resultado inferencial deve informar o critério utilizado, seu valor observado, a transformação adotada pelo procedimento computacional, os graus de liberdade correspondentes e o valor p . A interpretação deve identificar se a calibração é exata, aproximada ou assintótica.

18.9.3 Invariância a transformações lineares das respostas

Considere uma transformação linear não singular das respostas,

$$\mathbf{y}^* = \mathbf{y}\mathbf{A}, \quad (18.36)$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}, \quad \det(\mathbf{A}) \neq 0.$$

No sistema transformado,

$$\mathbf{B}^* = \mathbf{B}\mathbf{A}, \quad \mathcal{E}^* = \mathcal{E}\mathbf{A}.$$

Para representar a mesma hipótese, utiliza-se

$$\Theta_0^* = \Theta_0\mathbf{A}.$$

As matrizes de hipótese e erro transformam-se por congruência:

$$\mathbf{H}^* = \mathbf{A}^\top \mathbf{H} \mathbf{A} \quad (18.37)$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (18.38)$$

Se $\mathbf{A}$ é não singular, os pares

$$(\mathbf{H}, \mathbf{E})$$

e

$$(\mathbf{H}^*, \mathbf{E}^*)$$

possuem as mesmas raízes características, incluindo suas multiplicidades. A demonstração formal desse resultado é apresentada na Proposição 18.1.

Como Wilks, Pillai, Hotelling–Lawley e Roy dependem somente das raízes características, os quatro critérios são invariantes a transformações lineares não singulares das respostas, desde que a hipótese seja expressa no sistema transformado correspondente (Eaton, 2007).

As direções características mudam de coordenadas. Se α_j é uma direção característica normalizada no sistema original, pode-se tomar

$$\alpha_j^* = \mathbf{A}^{-1}\alpha_j,$$

de modo que

$$\mathcal{Y}^*\alpha_j^* = \mathcal{Y}\alpha_j.$$

Assim, os coeficientes numéricos das combinações lineares dependem da representação das respostas, enquanto as raízes e os quatro critérios permanecem invariantes sob mudanças invertíveis de coordenadas.

A invariância dos critérios decorre da preservação das raízes características do par $(\mathbf{H}, \mathbf{E})$ sob transformações lineares não singulares das respostas.

Proposição 18.1 (Invariância das raízes características). *Se $\mathbf{A}$ é não singular, os pares*

$$(\mathbf{H}, \mathbf{E})$$

e

$$(\mathbf{H}^*, \mathbf{E}^*)$$

possuem as mesmas raízes características, incluindo suas multiplicidades.

Comprovação. Tem-se

$$\begin{aligned}\det(\mathbf{H}^* - \lambda \mathbf{E}^*) &= \det[\mathbf{A}^\top (\mathbf{H} - \lambda \mathbf{E}) \mathbf{A}] \\ &= \det(\mathbf{A})^2 \det(\mathbf{H} - \lambda \mathbf{E}).\end{aligned}$$

Como

$$\det(\mathbf{A}) \neq 0,$$

as duas equações características possuem os mesmos zeros, com as mesmas multiplicidades. $\square$

18.9.4 Posto, sinais e multiplicidades das direções

O número de raízes positivas é

$$r_H = \text{posto}(\mathbf{H}) \leq \min(p, g),$$

conforme Equação 18.15.

Assim, o número de respostas não determina sozinho a quantidade de direções associadas ao efeito. Uma hipótese de baixo posto pode produzir poucas raízes positivas mesmo quando p é elevado.

Para uma raiz simples, a direção característica é determinada apenas até multiplicação por um escalar não nulo. Adotando a normalização

$$\alpha_j^\top \mathbf{E} \alpha_j = 1,$$

permanece a indeterminação de sinal:

$$\alpha_j \quad \text{e} \quad -\alpha_j$$

representam a mesma direção.

Quando uma raiz possui multiplicidade maior que 1, os autovetores individuais não são únicos; o subespaço característico correspondente é o objeto identificado.

18.10 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne procedimentos utilizados para avaliar as condições da MANOVA e examinar os resultados posteriores ao teste multivariado global. São tratados o teste M de Box, a avaliação das respostas individuais e a correspondência entre os objetos estatísticos desenvolvidos no capítulo e a implementação utilizada nas atividades computacionais.

18.10.1 Avaliação da homogeneidade das matrizes de covariâncias

A igualdade das matrizes de covariâncias constitui uma condição da formulação clássica de comparação entre grupos. O teste M de Box fornece uma avaliação inferencial dessa hipótese, mas seu resultado não substitui a análise da estrutura residual nem constitui, isoladamente, uma decisão sobre a validade da MANOVA.

No problema de comparação entre K grupos, a hipótese de covariância residual comum pode ser expressa como

$$H_0 : \Sigma_1 = \Sigma_2 = \dots = \Sigma_K.$$

O teste M de Box compara as matrizes de covariâncias estimadas nos grupos para avaliar sua compatibilidade com essa hipótese (Hair et al., 2018). Em sua forma clássica, o cálculo utiliza determinantes das matrizes de covariâncias amostrais dos grupos e requer que essas matrizes sejam não singulares. A rejeição de H_0 fornece evidência de heterogeneidade entre as matrizes de covariâncias.

A não rejeição de H_0 não demonstra que as matrizes populacionais sejam iguais. O resultado deve ser interpretado em conjunto com a estrutura dos dados e com as hipóteses utilizadas para obter a distribuição de referência do teste. Em particular, desvios da normalidade multivariada podem afetar seu comportamento.

O teste constitui, portanto, uma avaliação inferencial da hipótese de covariância comum e não uma condição que, isoladamente, determine a validade da MANOVA.

18.10.2 Avaliação das respostas após o teste global

Quando $p > 1$, a avaliação multivariada pode ser complementada pelo exame separado das respostas. Para a resposta j , os elementos diagonais

$$H_{jj} \quad \text{e} \quad E_{jj}$$

correspondem às somas de quadrados da hipótese e do erro associadas a essa variável, conduzindo à estatística

$$F_j = \frac{H_{jj}/\nu_H}{E_{jj}/\nu_E}. \quad (18.39)$$

Sob o modelo normal clássico, condicionalmente a $\mathbf{Z}$, e sob a hipótese nula marginal correspondente,

$$F_j \sim F_{\nu_H, \nu_E}.$$

Esses testes respondem a perguntas marginais sobre cada componente do vetor resposta e não reproduzem a MANOVA. Cada F_j utiliza apenas elementos diagonais de $\mathbf{H}$ e $\mathbf{E}$, enquanto os critérios multivariados utilizam as matrizes completas e incorporam também os produtos cruzados entre as respostas.

Por isso, uma conclusão global da MANOVA não deve ser substituída por uma coleção de testes univariados. Procedimentos de acompanhamento, controle de multiplicidade e comparações posteriores pertencem à etapa aplicada.

Correspondência com a implementação utilizada

Nas atividades computacionais, a MANOVA será realizada pela análise MANCOVA do núcleo do [jamovi](#) (The jamovi project, 2026). A análise admite várias respostas quantitativas e uma ou mais variáveis explicativas categóricas ou quantitativas. Sem covariáveis, ela fornece a formulação MANOVA considerada neste capítulo; com covariáveis, utiliza a mesma estrutura do modelo linear multivariado na forma de uma MANCOVA.

As respostas quantitativas correspondem às colunas de $\mathcal{Y}$, os fatores representam variáveis explicativas categóricas e as covariáveis representam variáveis explicativas quantitativas. Esses elementos determinam os termos da matriz de delineamento $\mathbf{Z}$.

Na tabela de testes multivariados, o programa disponibiliza os critérios de Pillai, Wilks, Hotelling e Roy. A denominação **Hotelling's Trace** utilizada na saída corresponde ao traço de Hotelling–Lawley definido neste capítulo. Os quatro resultados são funções das raízes características apresentadas na Seção 18.5.

O teste M de Box avalia a hipótese de covariância residual comum discutida na Seção 18.7.3, e os limites de sua utilização são apresentados na Seção 18.10.1. Os testes univariados fornecidos para cada resposta correspondem às comparações marginais discutidas na Seção 18.10.2 e não substituem o teste multivariado global.

Entre as verificações disponibilizadas pelo programa estão o teste de Shapiro–Wilk e o gráfico Q–Q. Esses resultados devem ser interpretados em relação aos erros do modelo e à estrutura condicional apresentada na Seção 18.7.5, e não automaticamente como propriedades da distribuição marginal de todas as respostas reunidas. A disponibilidade de um diagnóstico no programa não transforma seu resultado isolado em uma decisão

18.11 Síntese

A MANOVA formula a comparação conjunta de várias respostas no modelo linear multivariado. Para uma hipótese estimável, a informação necessária à comparação é reunida nas matrizes de somas de quadrados e produtos cruzados

$$\mathbf{H} \quad \text{e} \quad \mathbf{E},$$

associadas, respectivamente, à hipótese e ao erro residual.

Quando $\mathbf{E} \succ \mathbf{0}$, a comparação entre essas duas estruturas conduz ao problema de autovalores generalizados

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}.$$

As raízes características quantificam a magnitude da hipótese relativamente ao erro nas direções determinadas pelo problema espectral. Os critérios de Wilks, Pillai, Hotelling–Lawley e Roy utilizam a mesma coleção de raízes e diferem pela forma como agregam essa informação.

A construção de $\mathbf{H}$, $\mathbf{E}$, das raízes e dos critérios é algébrica. A inferência clássica acrescenta hipóteses probabilísticas sobre os erros, incluindo independência entre unidades, covariância residual comum e normalidade multivariada. Sob essa formulação, a estrutura normal–Wishart fornece a base para a distribuição de referência dos critérios. A avaliação dessas condições e o acompanhamento das respostas individuais pertencem à condução da análise e não alteram a definição do teste multivariado.

As relações com ANOVA, T^2 de Hotelling e regressão multivariada mostram que a MANOVA integra diferentes problemas de inferência no modelo linear. Sua relação com a Análise Discriminante decorre da utilização de estruturas de dispersão e problemas espectrais semelhantes, embora os objetivos estatísticos sejam distintos.

Ao final deste capítulo, o estudante deverá ser capaz de:

- formular uma hipótese estimável no modelo linear multivariado e identificar as matrizes $\mathbf{H}$ e $\mathbf{E}$;
- interpretar a MANOVA como uma comparação entre hipótese e erro por meio de um problema de autovalores generalizados;
- relacionar as raízes características aos critérios de Wilks, Pillai, Hotelling–Lawley e Roy;
- distinguir a construção algébrica dos critérios de sua calibração inferencial;

- identificar os principais pressupostos, limitações e relações da MANOVA com outras técnicas multivariadas.

Na Capítulo 19, a atenção passa do teste de diferenças multivariadas para a separação entre grupos previamente conhecidos. A Análise Discriminante utiliza estruturas de dispersão entre e dentro dos grupos para construir direções discriminantes e, sob modelos probabilísticos específicos, regras de classificação.

19 Formulação da Análise Discriminante

A Análise Discriminante utiliza grupos previamente conhecidos para resolver dois problemas relacionados: representar a separação entre os grupos e construir regras para classificar novas observações (Johnson; Wichern, 2007).

O capítulo desenvolve duas formulações. Na formulação probabilística, as classes são descritas por distribuições condicionais e a classificação é tratada como um problema de decisão envolvendo probabilidades *a priori*, perdas e probabilidades posteriores. Na formulação geométrica de Fisher, procuram-se combinações lineares que maximizem a separação entre grupos relativamente à dispersão intragrupos.

As duas formulações possuem objetivos distintos. A primeira produz regras de classificação; a segunda constrói direções que representam a separação entre grupos conhecidos. Sob condições específicas, suas soluções podem estar relacionadas.

O capítulo distingue parâmetros populacionais, estatísticas amostrais e regras estimadas. Os aprofundamentos teóricos retomam a formulação decisória e propriedades algébricas da solução, enquanto os aprofundamentos metodológicos e aplicados tratam da avaliação da classificação e da interpretação das funções discriminantes. Algoritmos, regularização e seleção de variáveis pertencem a etapas metodológicas posteriores.

A Tabela 19.1 resume as formulações utilizadas.

Tabela 19.1: Formulações complementares da Análise Discriminante.

Formulação	Objeto de partida	Problema	Resultado
decisão estatística	densidades condicionais, probabilidades <i>a priori</i> e perdas	escolher uma ação para uma nova observação	regra de Bayes
normal com covariância comum	μ_k, Σ e π_k	minimizar risco sob perda zero-um	regra discriminante linear
normal com covariâncias distintas	μ_k, Σ_k e π_k	minimizar risco sob perda zero-um	regra discriminante quadrática
geométrica de Fisher	dispersões intragrupos e entre grupos	maximizar separação relativa	direções e coordenadas discriminantes

19.1 O problema de discriminação e classificação

Considere uma variável aleatória de classe

$$C \in \{1, \dots, K\}, \quad K \geq 2.$$

A variável C é categórica, conforme a distinção apresentada na Seção 1.2. Os valores $1, \dots, K$ funcionam como rótulos das classes e não como medidas quantitativas. Sua ordem ou suas diferenças numéricas não participam da definição da Análise Discriminante.

Considere também um vetor aleatório de características quantitativas

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p.$$

Para cada classe

$$k \in \{1, \dots, K\},$$

existe uma distribuição condicional de

$$\mathbf{x} \mid C = k.$$

Uma realização

$$\mathbf{x} \in \mathbb{R}^p$$

representa os valores observados das características de uma unidade.

Durante a construção da técnica, os rótulos das unidades utilizadas para caracterizar os grupos são conhecidos. A Análise Discriminante é, portanto, uma técnica supervisionada.

Na **discriminação**, procura-se construir funções ou direções que representem a separação entre os grupos. Na **classificação**, procura-se uma regra

$$\psi : \mathbb{R}^p \longrightarrow \{1, \dots, K\}$$

que associe uma nova observação $\mathbf{x}$ a uma das classes.

A qualidade preditiva de uma regra estimada constitui um problema adicional. Taxas de erro, matrizes de classificação, validação cruzada e outros procedimentos de avaliação são tratados na Seção 19.15 e não participam da definição da regra.

19.2 Classificação como problema de decisão

A classificação pode ser formulada como um problema de decisão. Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

deve-se escolher uma ação

$$a \in \mathcal{A}, \quad \mathcal{A} = \{1, \dots, K\}.$$

A ação a significa atribuir a observação à classe a . A decisão depende das probabilidades *a priori*, das distribuições condicionais das características e das perdas associadas às possíveis classificações.

19.2.1 Probabilidades a priori e posteriores

Definição 19.1 (Probabilidades a priori das classes). Seja

$$\mathbf{C} \in \{1, \dots, K\}$$

uma variável aleatória de classe.

As **probabilidades a priori** são

$$\pi_k = P(\mathbf{C} = k), \quad k = 1, \dots, K,$$

com

$$\pi_k > 0$$

e

$$\sum_{k=1}^K \pi_k = 1.$$

As probabilidades *a priori* descrevem a distribuição das classes antes da observação das características da nova unidade. Elas são parâmetros do problema de decisão e não devem ser identificadas automaticamente com as proporções das classes em uma amostra de treinamento.

Suponha que, para cada classe k ,

$$\mathbf{X} \mid C = k$$

possua densidade condicional

$$f_k(\mathbf{x}) = f(\mathbf{x} \mid C = k).$$

Para uma observação $\mathbf{x}$ tal que

$$\sum_{\ell=1}^K \pi_{\ell} f_{\ell}(\mathbf{x}) > 0,$$

o teorema de Bayes fornece

$$P(C = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{\ell=1}^K \pi_{\ell} f_{\ell}(\mathbf{x})}. \quad (19.1)$$

A probabilidade posterior combina a probabilidade inicial da classe, representada por π_k , com a compatibilidade da observação com sua distribuição condicional, representada por $f_k(\mathbf{x})$.

19.2.2 Regra de Bayes sob perda zero-um

No caso mais simples, atribui-se perda zero a uma classificação correta e a mesma perda unitária a qualquer classificação incorreta:

$$L(a, k) = \begin{cases} 0, & a = k, \\ 1, & a \neq k. \end{cases} \quad (19.2)$$

Se a observação $\mathbf{x}$ for atribuída à classe a , a perda esperada posterior é

$$1 - P(C = a \mid \mathbf{X} = \mathbf{x}).$$

Minimizá-la equivale a maximizar a probabilidade posterior. Assim, a regra de Bayes sob perda zero-um atribui $\mathbf{x}$ a uma classe que satisfaça

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} P(C = k \mid \mathbf{X} = \mathbf{x}).$$

Por Equação 19.1, o denominador é comum a todas as classes. Portanto,

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \pi_k f_k(\mathbf{x}). \quad (19.3)$$

Quando

$$f_k(\mathbf{x}) > 0$$

para todas as classes, a mesma comparação pode ser realizada pelo escore

$$\log \pi_k + \log f_k(\mathbf{x}). \quad (19.4)$$

A Seção 19.3 e a Seção 19.4 especializam essa regra para populações normais multivariadas. As funções resultantes combinam a probabilidade *a priori* de cada classe com sua densidade condicional (Anderson, 2003).

Quando diferentes erros de classificação possuem consequências distintas, a maior probabilidade posterior deixa de determinar, isoladamente, a decisão ótima. A formulação geral incorpora essas consequências por meio de uma função de perda.

A formulação probabilística será agora especializada para populações normais multivariadas. A estrutura da matriz de covariâncias determinará se as fronteiras de classificação são lineares ou quadráticas.

19.3 Discriminação linear sob normalidade

Considere a especialização probabilística

$$\mathbf{X} \mid C = k \sim N_p(\mu_k, \Sigma), \quad k = 1, \dots, K, \quad (19.5)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e todas as classes compartilham a matriz de covariâncias

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}.$$

Considere também probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

A normalidade não é necessária para definir a regra de Bayes. Ela é utilizada aqui para especificar as distribuições condicionais das características.

Sob perda zero-um, Equação 19.3 mostra que a classificação pode ser obtida comparando

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A comparação entre log-densidades normais com matriz de covariâncias comum foi estabelecida em Equação 9.49. Os termos quadráticos em $\mathbf{x}$ e os termos que não dependem da classe cancelam-se, restando uma função afim das características.

Definição 19.2 (Função discriminante linear). Sob o modelo em Equação 19.5 e perda zero-um, a **função discriminante linear** da classe k é

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k. \quad (19.6)$$

A regra discriminante linear é

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k(\mathbf{x}). \quad (19.7)$$

A função $\delta_k(\mathbf{x})$ é afim em $\mathbf{x}$. A denominação *Linear Discriminant Analysis* refere-se à forma das fronteiras de decisão entre as classes.

19.3.1 Fronteiras e distância de Mahalanobis

Considere duas classes distintas,

$$k \neq h.$$

A fronteira entre elas é determinada por

$$\delta_k(\mathbf{x}) = \delta_h(\mathbf{x}),$$

ou, equivalentemente,

$$\begin{aligned} 0 = \mathbf{x}^\top \Sigma^{-1} (\mu_k - \mu_h) \\ - \frac{1}{2} (\mu_k^\top \Sigma^{-1} \mu_k - \mu_h^\top \Sigma^{-1} \mu_h) + \log \frac{\pi_k}{\pi_h}. \end{aligned} \quad (19.8)$$

Quando

$$\mu_k \neq \mu_h,$$

essa equação define um hiperplano cujo vetor normal é

$$\Sigma^{-1} (\mu_k - \mu_h). \quad (19.9)$$

A orientação da fronteira depende, portanto, da diferença entre os vetores de médias e da estrutura de covariâncias. Mantidos esses objetos, alterar as probabilidades *a priori* modifica o termo constante e desloca a fronteira, mas não altera seu vetor normal.

Se

$$\mu_k = \mu_h,$$

as duas classes possuem a mesma densidade condicional sob o modelo de covariância comum. A comparação entre elas depende apenas das probabilidades *a priori*. Se também

$$\pi_k = \pi_h,$$

os escores das duas classes coincidem para todo $\mathbf{x}$, e a regra não permite distingui-las.

A distância de Mahalanobis definida em Definição 8.9 permite escrever a mesma regra em forma geométrica. Para a classe k ,

$$d_M^2(\mathbf{x}, \mu_k; \Sigma) = (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k).$$

Sob perda zero-um,

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} \left\{ d_M^2(\mathbf{x}, \mu_k; \Sigma) - 2 \log \pi_k \right\}. \quad (19.10)$$

Se as probabilidades *a priori* são iguais,

$$\pi_1 = \dots = \pi_K = \frac{1}{K},$$

o termo associado às probabilidades é comum a todas as classes e

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} d_M^2(\mathbf{x}, \mu_k; \Sigma). \quad (19.11)$$

Assim, sob normalidade, covariância comum, probabilidades *a priori* iguais e perda zero-um, a regra de Bayes classifica pela menor distância de Mahalanobis ao centro populacional da classe.

A formulação mostra como uma estrutura geométrica já estabelecida adquire função decisória: a matriz Σ determina simultaneamente a dispersão das populações normais e a geometria utilizada para comparar uma nova observação com seus centros.

A LDA desenvolvida nesta seção é populacional, pois utiliza

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_K.$$

A passagem desses parâmetros para uma regra estimada é desenvolvida na Seção 19.5.

19.4 Discriminação quadrática

A linearidade da LDA decorre da utilização de uma matriz de covariâncias comum. Considere agora

$$\mathbf{X} \mid C = k \sim N_p(\mu_k, \Sigma_k), \quad k = 1, \dots, K, \quad (19.12)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e

$$\Sigma_k \in \mathbb{R}^{p \times p}, \quad \Sigma_k \succ \mathbf{0}.$$

Considere também

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Sob perda zero-um, a regra de Bayes continua comparando

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A diferença está na estrutura das distribuições condicionais. Como as matrizes de covariâncias dependem da classe, os termos quadráticos não se cancelam entre as comparações. Essa propriedade foi estabelecida em Equação 9.50.

Definição 19.3 (Função discriminante quadrática). Sob o modelo em Equação 19.12 e perda zero-um, a **função discriminante quadrática** da classe k é

$$\delta_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k) + \log \pi_k. \quad (19.13)$$

A regra discriminante quadrática é

$$\psi_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k^Q(\mathbf{x}). \quad (19.14)$$

A função possui dois componentes dependentes da dispersão da classe. A forma quadrática

$$(\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k)$$

é a distância quadrática de Mahalanobis à média da classe segundo sua própria matriz de covariâncias. O termo

$$\log |\Sigma_k|$$

participa da normalização da densidade e incorpora a dispersão multivariada da população.

Diferentemente da LDA, não existe uma única geometria de Mahalanobis compartilhada pelas classes.

19.4.1 Fronteiras e comparação com a LDA

Considere duas classes distintas,

$$k \neq h.$$

A fronteira é determinada por

$$\delta_k^Q(\mathbf{x}) = \delta_h^Q(\mathbf{x}).$$

Após reunir os termos quadráticos, lineares e constantes, obtém-se

$$\mathbf{x}^\top \mathbf{A}_{kh} \mathbf{x} + \mathbf{b}_{kh}^\top \mathbf{x} + c_{kh} = 0, \quad (19.15)$$

em que $\mathbf{A}_{kh}$, $\mathbf{b}_{kh}$ e c_{kh} dependem das médias, das matrizes de covariâncias e das probabilidades *a priori* das duas classes.

Quando

$$\Sigma_k \neq \Sigma_h,$$

tem-se

$$\mathbf{A}_{kh} \neq \mathbf{0},$$

e permanecem termos quadráticos em $\mathbf{x}$. A fronteira entre as classes não precisa, portanto, ser um hiperplano.

Quando todas as classes compartilham

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

o termo quadrático em $\mathbf{x}$ e o log-determinante tornam-se comuns a todas as classes. Esses termos podem ser retirados da comparação entre os escores, e a parte dependente da classe coincide com Equação 19.6. A regra de classificação da QDA torna-se, portanto, equivalente à LDA.

A diferença entre LDA e QDA decorre, portanto, da estrutura probabilística atribuída às covariâncias condicionais. A LDA utiliza uma única geometria residual e produz fronteiras lineares; a QDA utiliza uma geometria específica para cada classe e pode produzir fronteiras quadráticas.

A Figura 19.1 ilustra essa diferença para duas populações normais.




Figura 19.1: Fronteiras de decisão para duas populações normais. As elipses delimitam regiões de concentração de 75%. Com covariância comum, a LDA produz uma fronteira linear; com covariâncias distintas, a QDA pode produzir uma fronteira quadrática.

A diferença visual entre as fronteiras é uma consequência das hipóteses probabilísticas. Na LDA, os termos quadráticos comuns cancelam-se. Na QDA, esse cancelamento não ocorre quando as matrizes de covariâncias diferem.

19.5 Da regra populacional à regra estimada

As regras formuladas nas seções anteriores dependem de parâmetros populacionais.

Na LDA, são necessários

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_K.$$

Na QDA, são necessários

$$\mu_1, \dots, \mu_K, \quad \Sigma_1, \dots, \Sigma_K, \quad \pi_1, \dots, \pi_K.$$

Em uma aplicação, as médias e as matrizes de covariâncias populacionais são geralmente desconhecidas e são estimadas a partir de uma amostra de treinamento com classes conhecidas. As probabilidades *a priori* podem ser conhecidas, especificadas ou estimadas, conforme a informação disponível e o mecanismo de amostragem. A distinção entre estimador e estimativa estabelecida em Definição 10.4 será mantida: antes da observação da amostra, as estatísticas utilizadas são aleatórias; depois da observação, seus valores são estimativas.

Considere

$$n = \sum_{k=1}^K n_k,$$

em que n_k é o número de unidades observadas da classe k .

Para cada classe, a média amostral aleatória é obtida aplicando Equação 10.8 às observações do grupo, e sua realização observada será denotada por

$$\bar{\mathbf{x}}_k \in \mathbb{R}^p.$$

Quando

$$n_k \geq 2,$$

a matriz de covariâncias amostral definida em Definição 10.14 fornece o estimador da covariância da classe, cuja realização será denotada por

$$\mathbf{S}_k \in \mathbb{R}^{p \times p}.$$

Essas estatísticas não exigem normalidade para serem definidas. Nas formulações LDA e QDA, elas são utilizadas como estimadores dos parâmetros dos respectivos modelos normais.

19.5.1 Covariância comum na LDA

Sob a hipótese populacional

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

a dispersão das classes é reunida em uma única estimativa.

Pela correspondência entre a SQPC residual e a dispersão intragrupos estabelecida em Equação 11.107, para

$$n > K,$$

a matriz de covariâncias agrupada observada é

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}. \quad (19.16)$$

Equivalentemente, quando todas as matrizes $\mathbf{S}_k$ estão definidas,

$$\mathbf{S}_p = \frac{\sum_{k=1}^K (n_k - 1) \mathbf{S}_k}{n - K}.$$

A estrutura de dispersão intragrupos utilizada na Seção 19.6 fornece também a estimativa da covariância comum da LDA em Equação 19.16.

19.5.2 Probabilidades *a priori*

Na regra amostral, os valores das probabilidades *a priori* podem ser conhecidos a partir de informação populacional, especificados de acordo com o problema de classificação ou estimados a partir da amostra de treinamento.

Quando a amostra de treinamento representa a mistura populacional das classes, pode-se utilizar a estimativa

$$\hat{\pi}_k = \frac{n_k}{n}. \quad (19.17)$$

Essa escolha não é automática. Se os tamanhos das classes foram fixados pelo delineamento ou se o mecanismo amostral altera suas proporções, n_k/n não representa necessariamente

$$P(\mathbf{C} = k).$$

Nessas situações, as probabilidades *a priori* devem ser especificadas a partir do problema ou de informação populacional externa.

Para distinguir a estimativa amostral do valor efetivamente utilizado na regra, denote por

$$\tilde{\pi}_k$$

a probabilidade *a priori* adotada para a classificação. Quando ela é estimada pelas proporções da amostra,

$$\tilde{\pi}_k = \hat{\pi}_k;$$

quando é especificada externamente, $\tilde{\pi}_k$ representa diretamente o valor adotado.

19.5.3 Regra estimada da LDA

Substituindo as médias e a matriz de covariâncias populacionais por estimativas e utilizando os valores das probabilidades *a priori* adotados para a classificação, obtém-se uma regra *plug-in*.

Definição 19.4 (Função discriminante linear estimada). Considere médias observadas

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K,$$

uma matriz

$$\mathbf{S}_p \succ \mathbf{0}$$

e probabilidades *a priori* utilizadas na regra

$$\tilde{\pi}_k > 0, \quad \sum_{k=1}^K \tilde{\pi}_k = 1.$$

A **função discriminante linear estimada** da classe k é

$$\hat{\delta}_k(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k - \frac{1}{2} \bar{\mathbf{x}}_k^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k + \log \tilde{\pi}_k. \quad (19.18)$$

A regra estimada é

$$\widehat{\psi}_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \widehat{\delta}_k(\mathbf{x}). \quad (19.19)$$

A forma algébrica coincide com a regra populacional, mas os objetos possuem naturezas estatísticas diferentes:

$$\mu_k \longrightarrow \bar{\mathbf{x}}_k, \quad \Sigma \longrightarrow \mathbf{S}_p, \quad \pi_k \longrightarrow \tilde{\pi}_k.$$

A regra estimada depende da amostra de treinamento e, portanto, varia entre amostras.

19.5.4 Regra estimada da QDA

Na QDA, cada classe possui sua própria matriz de covariâncias.

Definição 19.5 (Função discriminante quadrática estimada). Considere

$$\mathbf{S}_k \succ \mathbf{0}, \quad k = 1, \dots, K.$$

A **função discriminante quadrática estimada** da classe k é

$$\widehat{\delta}_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\mathbf{S}_k| - \frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_k)^\top \mathbf{S}_k^{-1} (\mathbf{x} - \bar{\mathbf{x}}_k) + \log \tilde{\pi}_k. \quad (19.20)$$

A regra correspondente é

$$\widehat{\psi}_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \widehat{\delta}_k^Q(\mathbf{x}). \quad (19.21)$$

A LDA utiliza uma única estimativa de covariância, $\mathbf{S}_p$, enquanto a QDA utiliza

$$\mathbf{S}_1, \dots, \mathbf{S}_K.$$

A QDA exige, portanto, amostras de classe que permitam estimar matrizes de covariâncias não singulares. As condições de posto correspondentes são reunidas na Seção 19.12.

A Tabela 19.2 sintetiza a diferença entre as duas formulações.

Tabela 19.2: Comparação entre LDA e QDA.

Aspecto	LDA	QDA
modelo condicional	$N_p(\mu_k, \Sigma)$	$N_p(\mu_k, \Sigma_k)$
covariância populacional	comum	específica por classe
estimativa de covariância	$\mathbf{S}_p$	$\mathbf{S}_k$
função discriminante	afim em $\mathbf{x}$	quadrática em $\mathbf{x}$
fronteira entre duas classes	hiperplano	superfície quadrática em geral
geometria	uma métrica de Mahalanobis comum	uma métrica de Mahalanobis por classe
probabilidades <i>a priori</i>	entram por $\log \pi_k$ na regra populacional e por $\log \tilde{\pi}_k$ na regra estimada	entram por $\log \pi_k$ na regra populacional e por $\log \tilde{\pi}_k$ na regra estimada

A substituição das médias e covariâncias populacionais por estimativas transforma a regra populacional em uma regra construída a partir da amostra de treinamento. Quando as probabilidades *a priori* também são estimadas a partir da amostra, sua variabilidade amostral integra a regra; quando são especificadas externamente, seus valores permanecem fixos.

As formulações LDA e QDA resolvem um problema de decisão no espaço original das características. A formulação de Fisher parte de outro objetivo: utilizar os rótulos conhecidos para construir combinações lineares que representem a separação entre os grupos relativamente à dispersão intragrupos.

19.6 Formulação geométrica de Fisher

A formulação probabilística anterior produz regras para classificar novas observações. A formulação de Fisher utiliza os grupos conhecidos com outro objetivo: construir combinações lineares das características que representem sua separação relativamente à dispersão existente dentro dos grupos.

O problema admite uma formulação populacional e uma formulação amostral. A primeira identifica as estruturas de dispersão que definem o critério; a segunda utiliza as matrizes calculadas a partir das observações com rótulos conhecidos.

Na forma geométrica adotada neste capítulo, o critério de Fisher não exige normalidade multivariada nem igualdade das matrizes de covariâncias condicionais para ser definido. A hipótese de covariância comum torna-se necessária para estabelecer a correspondência direta com a LDA normal; apresentações clássicas de Fisher frequentemente incorporam essa condição ao desenvolvimento da técnica (Johnson; Wichern, 2007).

19.6.1 Dispersões populacionais dentro e entre grupos

Considere

$$\mathbf{C} \in \{1, \dots, K\},$$

com

$$P(\mathbf{C} = k) = \pi_k, \quad \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1,$$

e um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos.

Para cada classe, sejam

$$\mu_k = E(\mathbf{X} \mid \mathbf{C} = k)$$

e

$$\Sigma_k = \text{Cov}(\mathbf{X} \mid \mathbf{C} = k).$$

A média marginal é

$$\mu = E(\mathbf{X}) = \sum_{k=1}^K \pi_k \mu_k. \quad (19.22)$$

Definição 19.6 (Dispersões populacionais de Fisher). A **dispersão populacional intragrupos** é

$$\Sigma_W = \sum_{k=1}^K \pi_k \Sigma_k \in \mathbb{R}^{p \times p}, \quad (19.23)$$

e a **dispersão populacional entre grupos** é

$$\Sigma_B = \sum_{k=1}^K \pi_k (\mu_k - \mu) (\mu_k - \mu)^\top \in \mathbb{R}^{p \times p}. \quad (19.24)$$

As duas matrizes são simétricas e semidefinidas positivas. A matriz Σ_W representa a dispersão média existente dentro das classes, enquanto Σ_B representa a dispersão dos vetores de médias das classes em torno da média marginal.

Proposição 19.1 (Decomposição populacional da covariância por grupos). *Sob as condições de Definição 19.6,*

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B. \quad (19.25)$$

A demonstração dessa decomposição, obtida pela aplicação da decomposição da covariância à variável de classe C , é apresentada na Seção 19.14.3.

Essa decomposição é a contraparte populacional de

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

estabelecida em Proposição 8.10. Os objetos possuem naturezas distintas: Σ_W e Σ_B são parâmetros populacionais, enquanto $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes calculadas a partir das observações.

19.6.2 Dispersões projetadas

Considere uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

e a combinação linear

$$Z = \mathbf{a}^\top \mathbf{X}.$$

A dispersão média de Z dentro das classes é

$$\sum_{k=1}^K \pi_k \text{Var}(Z \mid C = k) = \mathbf{a}^\top \Sigma_W \mathbf{a}, \quad (19.26)$$

enquanto a dispersão das médias condicionais projetadas é

$$\sum_{k=1}^K \pi_k \left[\mathbf{a}^\top (\mu_k - \mu) \right]^2 = \mathbf{a}^\top \Sigma_B \mathbf{a}. \quad (19.27)$$

Definição 19.7 (Critério populacional de Fisher). Se

$$\Sigma_B \succeq \mathbf{0}$$

e

$$\Sigma_W \succ \mathbf{0},$$

o critério populacional de Fisher é

$$J_F^{(P)}(\mathbf{a}) = \frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}, \quad \mathbf{a} \neq \mathbf{0}. \quad (19.28)$$

O numerador mede a separação entre os vetores de médias das classes depois da projeção. O denominador mede a dispersão média que permanece dentro das classes na mesma direção. O critério procura, portanto, separação elevada relativamente à variabilidade intragrupos.

Essa formulação exige segundos momentos finitos e, na forma baseada em inversas desenvolvida aqui,

$$\Sigma_W \succ \mathbf{0}.$$

A normalidade multivariada e a igualdade

$$\Sigma_1 = \cdots = \Sigma_K$$

não são necessárias para definir o critério.

Quando as covariâncias condicionais são comuns,

$$\Sigma_k = \Sigma, \quad k = 1, \dots, K,$$

tem-se

$$\Sigma_W = \Sigma.$$

Sob essa condição, a relação entre a direção de Fisher e a discriminação linear normal é desenvolvida na Seção [19.14.4](#).

19.7 Formulação amostral de Fisher

Considere uma amostra com grupos conhecidos, com n_k observações no grupo k e

$$n = \sum_{k=1}^K n_k$$

observações no total.

As matrizes de dispersão intragrupos e entre grupos já foram definidas em Definição 8.14 e Definição 8.15. Elas serão denotadas, respectivamente, por

$$\mathbf{T}_{\text{intra}} \quad \text{e} \quad \mathbf{T}_{\text{entre}}.$$

Pela decomposição estabelecida em Proposição 8.10,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Na formulação amostral de Fisher, essas matrizes desempenham funções distintas: $\mathbf{T}_{\text{intra}}$ representa a dispersão das observações em torno dos centroides de seus grupos, enquanto $\mathbf{T}_{\text{entre}}$ representa a dispersão dos centroides em torno da média global.

As matrizes

$$\frac{1}{n} \mathbf{T}_{\text{intra}} \quad \text{e} \quad \frac{1}{n} \mathbf{T}_{\text{entre}}$$

correspondem às versões empíricas das dispersões populacionais quando as classes recebem pesos n_k/n . Como a multiplicação do numerador e do denominador por um mesmo escalar positivo não altera o quociente de Fisher, o critério pode ser formulado diretamente com as SQPCs.

Os pesos n_k presentes em $\mathbf{T}_{\text{entre}}$ pertencem à decomposição da amostra observada. Eles não devem ser identificados automaticamente com as probabilidades *a priori* π_k utilizadas na classificação probabilística.

Considere agora uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0}.$$

Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

sua coordenada projetada é

$$z = \mathbf{a}^\top \mathbf{x}.$$

Depois da projeção, a dispersão intragrupos é

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a},$$

enquanto a dispersão entre os centroides é

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}.$$

Definição 19.8 (Critério amostral de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Para

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

o critério amostral de Fisher é

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}. \quad (19.29)$$

O numerador mede a separação dos centroides depois da projeção, enquanto o denominador mede a dispersão que permanece dentro dos grupos na mesma direção.

Como

$$J_F(c\mathbf{a}) = J_F(\mathbf{a}), \quad c \neq 0,$$

o critério identifica direções, e não vetores com comprimento determinado.

Maximizar $J_F(\mathbf{a})$ corresponde a procurar uma combinação das características na qual a separação entre grupos seja elevada relativamente à dispersão intragrupos. A construção é supervisionada porque os rótulos dos grupos determinam diretamente $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$.

A Figura 19.2 compara duas projeções das mesmas observações. A primeira utiliza a direção que une os centroides; a segunda utiliza a direção determinada pelo critério de Fisher. Os escores são padronizados pelo desvio padrão intragrupos para tornar comparáveis as duas projeções.




Figura 19.2: Projeção das mesmas duas classes na direção que une os centroides e na direção de Fisher. A direção discriminante aumenta a separação entre os grupos relativamente à dispersão intragrupos.

A figura ilustra o papel do denominador de Equação 19.29: para a mesma dispersão entre grupos projetada, o critério de Fisher é maior em direções com menor dispersão intragrupos.

19.8 Direções discriminantes e autovalores generalizados

O critério em Equação 19.29 é o quociente de Rayleigh generalizado definido em Definição 5.12, aplicado ao par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}}).$$

Pelo resultado de Teorema 5.8, os extremos de

$$J_F(\mathbf{a})$$

são determinados pelo problema

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}. \quad (19.30)$$

Nessa expressão, $\mathbf{a}$ representa uma direção genérica. As soluções normalizadas serão denotadas por α_j .

19.8.1 Geometria pela dispersão intragrupos

Como

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

sua raiz quadrada principal e sua inversa existem por Definição 5.9.

Defina

$$\mathbf{u} = \mathbf{T}_{\text{intra}}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u},$$

e Equação 19.30 torna-se

$$\mathbf{M}_F \mathbf{u} = \lambda \mathbf{u},$$

em que

$$\mathbf{M}_F = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (19.31)$$

A matriz $\mathbf{M}_F$ é simétrica e semidefinida positiva. Como $\mathbf{T}_{\text{intra}}^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{M}_F) = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

A matriz $\mathbf{M}_F$ possui exatamente r_F autovalores positivos, que coincidem com as raízes positivas do problema generalizado de Fisher.

Definição 19.9 (Direções discriminantes de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Se $r_F \geq 1$, as **direções discriminantes de Fisher** são autovetores generalizados

$$\alpha_1, \dots, \alpha_{r_F} \in \mathbb{R}^p$$

associados às raízes positivas

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{r_F} > 0$$

e escolhidos com a normalização

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_\ell = \delta_{j\ell}. \quad (19.32)$$

Com essa convenção,

$$\mathbf{T}_{\text{entre}}\alpha_j = \lambda_j \mathbf{T}_{\text{intra}}\alpha_j.$$

Se

$$r_F = 0,$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva entre os centroides.

Para a primeira direção,

$$J_F(\alpha_1) = \lambda_1 = \max_{\mathbf{a} \neq \mathbf{0}} J_F(\mathbf{a}).$$

A normalização em Equação 19.32 implica, para cada j ,

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1. \quad (19.33)$$

Consequentemente,

$$\alpha_j^\top \mathbf{T}_{\text{entre}} \alpha_j = \lambda_j. \quad (19.34)$$

Cada raiz λ_j mede, portanto, a separação entre os grupos na direção α_j depois que a dispersão intragrupos nessa direção foi normalizada para 1.

Quando $r_F \geq 1$, a participação relativa de cada raiz na soma das raízes discriminantes positivas pode ser expressa por

$$\rho_j = \frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell}, \quad j = 1, \dots, r_F. \quad (19.35)$$

Consequentemente,

$$\sum_{j=1}^{r_F} \rho_j = 1.$$

A quantidade ρ_j descreve a participação relativa da direção j na soma das raízes discriminantes positivas. Ela não representa uma proporção da variância total das características, como ocorre na ACP. As raízes de Fisher quantificam separação entre grupos relativamente à dispersão intragrupos, de modo que sua interpretação permanece vinculada ao critério discriminante.

A ortogonalidade em Equação 19.32 é definida pela geometria induzida por $\mathbf{T}_{\text{intra}}$. Em geral,

$$\alpha_j^\top \alpha_\ell$$

não precisa ser zero para

$$j \neq \ell.$$

19.8.2 Número de direções discriminantes

Pelo limite de posto estabelecido em Equação 8.101,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

Como

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}),$$

segue que

$$r_F \leq \min(p, K - 1). \quad (19.36)$$

O limite decorre de duas restrições. A separação ocorre em um espaço de dimensão p , e os K centroides centralizados em torno da média global podem gerar no máximo $K - 1$ direções linearmente independentes.

Assim, dois grupos produzem no máximo uma direção discriminante, e K grupos produzem no máximo $K - 1$, sem ultrapassar a dimensão original p .

O subespaço gerado por

$$\alpha_1, \dots, \alpha_{r_F}$$

é o subespaço discriminante de Fisher. A Seção 19.9 utiliza essas direções para construir coordenadas supervisionadas das observações e dos centroides.

19.9 Representação no subespaço discriminante

As direções

$$\alpha_1, \dots, \alpha_{r_F}$$

definidas em Definição 19.9 determinam um subespaço supervisionado de dimensão

$$r_F \leq \min(p, K - 1).$$

As combinações lineares associadas a essas direções produzem coordenadas construídas especificamente para representar a separação entre os grupos relativamente à dispersão intragrupos.

Definição 19.10 (Coordenadas discriminantes). Considere as direções discriminantes normalizadas

$$\alpha_1, \dots, \alpha_{r_F} \in \mathbb{R}^p$$

e a média global amostral

$$\bar{\mathbf{x}} \in \mathbb{R}^p.$$

A **coordenada discriminante** j de uma observação

$$\mathbf{x} \in \mathbb{R}^p$$

é

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}}), \quad j = 1, \dots, r_F. \quad (19.37)$$

O vetor de coordenadas discriminantes é

$$\mathbf{z}(\mathbf{x}) = \begin{pmatrix} z_1(\mathbf{x}) \\ \vdots \\ z_{r_F}(\mathbf{x}) \end{pmatrix} \in \mathbb{R}^{r_F}. \quad (19.38)$$

A centralização coloca a média global na origem da representação. Utilizar

$$\alpha_j^\top \mathbf{x}$$

sem centralização preservaria as diferenças entre observações e centroides, modificando apenas a origem das coordenadas.

O centroide do grupo k na dimensão discriminante j é

$$\bar{z}_{kj} = \alpha_j^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (19.39)$$

A representação é supervisionada porque

$$\alpha_1, \dots, \alpha_{r_F}$$

dependem de $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, que são construídas a partir dos grupos conhecidos. Alterações nos rótulos ou na composição dos grupos podem modificar o subespaço discriminante.

A Figura 19.3 compara a representação das mesmas observações em duas características originais com a representação obtida pelas duas direções discriminantes disponíveis para três grupos. No segundo caso, as coordenadas incorporam conjuntamente as três características para representar a separação supervisionada.

No segundo painel, as direções são determinadas pelo problema espectral de Fisher. A transformação por

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

padroniza a dispersão intragrupos, e os autovetores de

$$\mathbf{M}_F$$

identificam as direções de maior separação entre os centroides nesse espaço transformado.

A construção difere da ACP. No Capítulo 14, as direções são escolhidas pela variabilidade total; em Fisher, são escolhidas pela separação entre grupos relativamente à dispersão intragrupos.




Figura 19.3: Representação de três grupos em duas características originais e nas duas coordenadas discriminantes de Fisher. As coordenadas são construídas especificamente para representar a separação entre os grupos.

19.10 Relação espectral com a MANOVA

A formulação de Fisher coincide com o problema espectral da MANOVA quando as duas técnicas são aplicadas à mesma partição em grupos e a hipótese da MANOVA compara os respectivos vetores de médias.

Nesse caso,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{H} = \mathbf{T}_{\text{entre}}. \quad (19.40)$$

Assim, para essa hipótese de comparação entre os grupos, o problema de Fisher

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j$$

coincide com o problema de autovalores generalizados desenvolvido no Capítulo 18.

As raízes positivas e os subespaços característicos são, portanto, os mesmos quando as matrizes de hipótese e erro da MANOVA correspondem, respectivamente, às dispersões entre e dentro dos grupos.

O significado estatístico da solução depende da técnica. Na MANOVA, as raízes são agregadas pelos critérios de Wilks, Pillai, Hotelling–Lawley e Roy para avaliar uma hipótese sobre os grupos. Na formulação de Fisher, os autovetores generalizados associados às raízes positivas definem direções utilizadas para representar sua separação.

A coincidência algébrica não implica coincidência de objetivos: a MANOVA utiliza a estrutura espectral para inferência sobre efeitos, enquanto Fisher a utiliza para construir uma representação discriminante.

19.11 Dois grupos e relação entre Fisher e LDA

Quando

$$K = 2,$$

a matriz de dispersão entre grupos possui posto no máximo 1. Existe, portanto, no máximo uma direção discriminante associada a uma raiz positiva.

Defina

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2. \quad (19.41)$$

Para dois grupos,

$$\mathbf{T}_{\text{entre}} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top. \quad (19.42)$$

Se

$$\mathbf{d} = \mathbf{0},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva.

Suponha agora

$$\mathbf{d} \neq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Como Equação 19.42 possui posto 1, a única direção discriminante possível satisfaz

$$\alpha_1 \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (19.43)$$

A diferença

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$$

representa a separação bruta entre os centroides. A multiplicação por

$$\mathbf{T}_{\text{intra}}^{-1}$$

repondera essa separação segundo a dispersão e as associações existentes dentro dos grupos.

A direção de Fisher não é, portanto, determinada apenas pela distância entre os centroides. Diferenças que ocorrem em direções de elevada dispersão intragrupos recebem menor peso relativo do que diferenças de mesma magnitude em direções de menor dispersão.

19.11.1 Formulação populacional para dois grupos

A mesma estrutura aparece na formulação populacional.

Considere

$$P(C = 1) = \pi_1, \quad P(C = 2) = \pi_2,$$

com

$$\pi_1 + \pi_2 = 1,$$

e defina

$$\mathbf{d}_\mu = \mu_1 - \mu_2.$$

A dispersão entre grupos é

$$\Sigma_B = \pi_1 \pi_2 \mathbf{d}_\mu \mathbf{d}_\mu^\top.$$

Se

$$\Sigma_W \succ \mathbf{0}$$

e

$$\mu_1 \neq \mu_2,$$

uma direção que maximiza o critério populacional de Fisher satisfaz

$$\mathbf{a}_F \propto \Sigma_W^{-1} (\mu_1 - \mu_2). \quad (19.44)$$

Esse resultado depende das estruturas de primeiro e segundo momentos e não exige normalidade multivariada.

Se, adicionalmente, as duas classes seguem distribuições normais com matriz de covariâncias comum

$$\Sigma,$$

então

$$\Sigma_W = \Sigma,$$

e Equação 19.44 torna-se

$$\mathbf{a}_F \propto \Sigma^{-1} (\mu_1 - \mu_2).$$

Essa direção é paralela ao vetor normal da fronteira da LDA em Equação 19.9. A correspondência refere-se à orientação da solução: a regra da LDA depende também das probabilidades *a priori* e da função de perda. A derivação completa dessa relação é apresentada na Seção 19.14.4.

19.11.2 Mais de dois grupos

Quando

$$K > 2,$$

a matriz

$$\mathbf{T}_{\text{entre}}$$

pode possuir posto superior a 1, e Fisher pode produzir

$$r_F \leq \min(p, K - 1)$$

direções discriminantes.

A LDA, por sua vez, não precisa construir previamente essas coordenadas discriminantes. Sua regra compara diretamente

$$\delta_1(\mathbf{x}), \dots, \delta_K(\mathbf{x})$$

no espaço original das características.

As direções de Fisher fornecem uma representação supervisionada da separação entre os grupos; a LDA fornece uma regra probabilística de decisão. As duas formulações compartilham médias e estruturas de dispersão, mas resolvem problemas distintos.

19.12 Pressupostos e limites

As formulações desenvolvidas neste capítulo possuem requisitos diferentes. O critério geométrico de Fisher adotado depende de estruturas de primeiro e segundo momentos e, na forma baseada em inversas desenvolvida aqui, de condições de não singularidade. LDA e QDA acrescentam hipóteses probabilísticas específicas para obter as funções discriminantes normais. As regras estimadas introduzem ainda condições amostrais de posto.

A Tabela [19.3](#) reúne essas diferenças.

Tabela 19.3: Condições associadas ao critério geométrico de Fisher adotado no capítulo e às formulações normais da LDA e da QDA.

Condição	Fisher geométrico adotado	LDA normal	QDA normal
grupos previamente definidos	necessária	necessária	necessária
segundos momentos finitos	necessários na formulação populacional	satisfeitos sob normalidade	satisfeitos sob normalidade
normalidade multivariada	não necessária para definir o critério de Fisher	assumida na formulação normal apresentada	assumida na formulação normal apresentada
covariância comum entre classes	não necessária para o critério geométrico adotado	assumida	não assumida
não singularidade populacional	$\Sigma_W \succ \mathbf{0}$ na forma baseada em inversas	$\Sigma \succ \mathbf{0}$	$\Sigma_k \succ \mathbf{0}$ para cada classe
não singularidade amostral	$\mathbf{T}_{\text{intra}} \succ \mathbf{0}$ na forma baseada em inversas	$\mathbf{S}_p \succ \mathbf{0}$	$\mathbf{S}_k \succ \mathbf{0}$ para cada classe
probabilidades <i>a priori</i>	entram como pesos na formulação populacional; não entram como termo de decisão no critério amostral	entram na regra de decisão	entram na regra de decisão
função de perda	não entra no critério	as funções apresentadas correspondem à perda zero–um	as funções apresentadas correspondem à perda zero–um

19.12.1 Grupos previamente definidos

A Análise Discriminante utiliza rótulos conhecidos durante a construção da solução.

Na formulação de Fisher, esses rótulos determinam

$$\mathbf{T}_{\text{intra}} \quad \text{e} \quad \mathbf{T}_{\text{entre}}.$$

Na formulação probabilística, eles determinam quais observações caracterizam cada distribuição condicional

$$\mathbf{X} \mid \mathbf{C} = k.$$

A técnica não constrói os grupos a partir dos dados. Se os rótulos utilizados não corresponderem às classes relevantes para o problema, a solução continuará descrevendo separação ou classificação relativamente aos grupos fornecidos.

19.12.2 Normalidade e estrutura das covariâncias

A normalidade multivariada não é necessária para definir o critério populacional de Fisher,

$$J_F^{(P)}(\mathbf{a}),$$

nem sua versão amostral,

$$J_F(\mathbf{a}).$$

Na formulação probabilística geral, a regra de Bayes também não exige normalidade. Essa hipótese foi introduzida especificamente para obter as formas LDA e QDA apresentadas neste capítulo.

Na LDA,

$$\Sigma_1 = \cdots = \Sigma_K = \Sigma,$$

com

$$\Sigma \succ \mathbf{0}.$$

A matriz comum faz com que os termos quadráticos em $\mathbf{x}$ sejam iguais nas comparações entre classes e se cancelem, produzindo fronteiras lineares.

Na QDA,

$$\Sigma_k \succ \mathbf{0}, \quad k = 1, \dots, K,$$

mas as matrizes podem diferir entre classes. Os termos quadráticos permanecem e as fronteiras podem ser quadráticas.

A condição de covariância comum pertence, portanto, à formulação normal da LDA e não é necessária para definir o critério geométrico de Fisher utilizado neste capítulo.

Algumas apresentações clássicas de Fisher para várias populações adotam adicionalmente uma matriz de covariâncias comum e de posto completo (Johnson; Wichern, 2007). Essa hipótese permite relacionar diretamente a separação de Fisher à estrutura probabilística da discriminação linear normal. Aqui, porém, o critério de Fisher é apresentado em sua forma geométrica mais geral, construída a partir da dispersão média intragrupos Σ_W .

19.12.3 Não singularidade e dimensão

A forma baseada em inversas do critério populacional de Fisher pressupõe

$$\Sigma_W \succ \mathbf{0}.$$

Essa condição garante

$$\mathbf{a}^\top \Sigma_W \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0}$$

e permite utilizar

$$\Sigma_W^{-1} \quad \text{e} \quad \Sigma_W^{-1/2}.$$

A positividade definida de Σ_W é uma condição sobre a estrutura de segundo momento dentro das classes e não depende de normalidade.

Na formulação amostral,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K). \quad (19.45)$$

Consequentemente,

$$n - K \geq p \quad (19.46)$$

é uma condição necessária para que

$$\mathbf{T}_{\text{intra}}$$

possa possuir posto completo.

Ela não é suficiente para um conjunto de dados arbitrário. Dependências lineares exatas entre as características dentro dos grupos podem tornar $\mathbf{T}_{\text{intra}}$ singular mesmo quando

$$n - K \geq p.$$

Quando

$$p > n - K,$$

a singularidade é inevitável.

Na LDA estimada,

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}},$$

de modo que

$$\text{posto}(\mathbf{S}_p) = \text{posto}(\mathbf{T}_{\text{intra}}).$$

A regra clássica estimada da LDA e a formulação amostral clássica de Fisher compartilham, portanto, a mesma condição de invertibilidade da dispersão intragrupos.

Na QDA, cada classe possui sua própria matriz de covariâncias amostral. Para a classe k ,

$$\text{posto}(\mathbf{S}_k) \leq \min(p, n_k - 1).$$

Assim,

$$n_k - 1 \geq p \tag{19.47}$$

é condição necessária para que $\mathbf{S}_k$ possa possuir posto completo. Essa condição deve ser satisfeita separadamente em cada classe.

A QDA estimada impõe, portanto, uma condição de posto separada em cada classe e se torna particularmente exigente em tamanho amostral quando p é elevado.

A não singularidade, entretanto, não garante estabilidade. Quando algumas características são aproximadamente combinações lineares de outras, $\mathbf{T}_{\text{intra}}$, $\mathbf{S}_p$ ou alguma $\mathbf{S}_k$ podem permanecer invertíveis, mas apresentar autovalores muito pequenos. Nesse caso, suas inversas podem

amplificar pequenas perturbações dos dados e tornar coeficientes e direções discriminantes sensíveis à amostra.

Esse problema deve ser distinguido da singularidade exata. Associação entre características é esperada em dados multivariados; quase dependência linear pode produzir mau condicionamento; dependência linear exata pode reduzir o posto das matrizes necessárias.

Quando as matrizes são singulares, as formulações clássicas baseadas em inversas e raízes quadradas inversas não estão definidas diretamente. Pseudoinversas, regularização e redução preliminar de dimensão correspondem a formulações adicionais e pertencem à etapa metodológica posterior.

19.12.4 Independência das unidades de treinamento

As estatísticas

$$\bar{\mathbf{x}}_k, \quad \mathbf{S}_k \quad \text{e} \quad \mathbf{S}_p$$

podem ser calculadas a partir das observações sem exigir independência.

As propriedades amostrais usuais dessas estatísticas, sob o esquema clássico considerado, são obtidas tratando as unidades de treinamento como independentes e utilizando, dentro de cada classe, a distribuição condicional especificada para aquela população.

Dependência temporal, espacial, longitudinal ou decorrente de agrupamentos altera a estrutura amostral e pode exigir modelos específicos. Essa questão pertence ao mecanismo probabilístico de geração dos dados e não ao problema algébrico de Fisher.

19.12.5 Probabilidades *a priori* e perdas

As probabilidades

$$\pi_k = P(C = k)$$

desempenham funções diferentes nas duas formulações do capítulo.

Na classificação probabilística, elas representam as probabilidades *a priori* das classes e entram nas funções LDA e QDA pelo termo

$$\log \pi_k.$$

Na formulação populacional de Fisher adotada neste capítulo, as mesmas probabilidades aparecem como pesos na construção de

$$\Sigma_W \quad \text{e} \quad \Sigma_B.$$

Sua função, nesse caso, é ponderar as dispersões populacionais das classes, e não determinar diretamente uma ação de classificação.

Na formulação amostral de Fisher, o critério utiliza $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, cujos pesos decorrem dos tamanhos observados n_k . A razão n_k/n coincide com a estimativa empírica de π_k em Equação 19.17 somente quando a amostra de treinamento representa a mistura populacional das classes.

A função de perda pertence ao problema de decisão e não ao critério geométrico de Fisher. Sob perda zero-um, a regra de Bayes reduz-se à escolha da maior probabilidade posterior; quando diferentes erros possuem consequências distintas, a decisão ótima pode mudar mesmo que as densidades condicionais e as probabilidades *a priori* permaneçam inalteradas.

19.12.6 Sobreposição entre as classes

Mesmo quando os parâmetros populacionais são conhecidos e o modelo probabilístico está corretamente especificado, a classificação pode apresentar erro.

Se duas classes atribuem densidade positiva à mesma região do espaço das características, uma observação nessa região não determina unicamente sua classe de origem.

A regra de Bayes escolhe a ação de menor risco condicional, mas esse risco mínimo pode ser positivo. Sob perda zero-um, a probabilidade global de classificação incorreta alcançada pela regra de Bayes é denominada **erro de Bayes**.

Quando as distribuições das classes se sobrepõem, esse erro pode ser positivo mesmo que os parâmetros populacionais sejam conhecidos exatamente. Existe, portanto, uma parcela do erro de classificação associada à própria dificuldade de separar as populações no espaço das características.

Esse erro populacional deve ser distinguido do erro adicional introduzido pela estimação das médias, covariâncias e demais parâmetros a partir de uma amostra de treinamento.

A avaliação empírica de uma regra estimada, por procedimentos como amostras de teste, validação cruzada, matrizes de classificação e medidas de desempenho, é tratada na Seção 19.15.

19.13 Relações com outras técnicas

A relação entre Análise Discriminante e MANOVA foi estabelecida a partir da correspondência

$$\mathbf{H} = \mathbf{T}_{\text{entre}} \quad \text{e} \quad \mathbf{E} = \mathbf{T}_{\text{intra}},$$

quando a MANOVA compara os vetores de médias correspondentes à mesma partição em grupos utilizada por Fisher. Nesse caso, as duas formulações conduzem ao mesmo problema de autovalores generalizados. A diferença está no objetivo estatístico: o Capítulo 18 utiliza as raízes para construir critérios de teste, enquanto Fisher utiliza os autovetores associados para representar a separação entre grupos.

A comparação com Capítulo 14 e Capítulo 16 distingue a Análise Discriminante pela utilização de grupos previamente conhecidos e pelo critério empregado para construir a representação.

19.13.1 Análise de Componentes Principais

O Capítulo 14 e a formulação de Fisher constroem combinações lineares, mas utilizam critérios diferentes.

Na ACP, as direções são determinadas pela variabilidade total. Em Fisher, a direção genérica $\mathbf{a}$ é avaliada por

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}},$$

de modo que a separação entre os grupos é comparada com a dispersão existente dentro deles.

A Tabela 19.4 sintetiza essa distinção.

Tabela 19.4: Comparação entre ACP e a formulação de Fisher.

Aspecto	ACP	Fisher
informação sobre grupos	não utilizada	utilizada
objeto matricial principal	covariância ou correlação total	dispersões entre e dentro dos grupos
critério	variabilidade total	separação entre grupos relativa à dispersão intragrupos
representação	não supervisionada em relação aos grupos	supervisionada

Aspecto	ACP	Fisher
dimensão máxima não nula	limitada pelo posto da matriz analisada	$\min(p, K - 1)$
interpretação das direções	variabilidade	separação relativa

Uma direção de elevada variabilidade total não precisa apresentar elevada capacidade de separação entre grupos. A diferença decorre da informação utilizada para construir cada representação.

19.13.2 Análise de Agrupamentos

A Análise Discriminante e o Capítulo 16 utilizam objetos como centroides, distâncias e dispersões, mas partem de problemas distintos.

Na Análise Discriminante, os grupos são conhecidos e seus rótulos participam da construção das regras de classificação ou das direções de Fisher. Na Análise de Agrupamentos, os grupos não são fornecidos previamente e devem ser construídos a partir de critérios de proximidade, dispersão ou modelagem probabilística.

Assim, a presença ou ausência de rótulos conhecidos distingue uma representação supervisionada da separação entre grupos de um problema de formação de grupos.

19.14 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte aprofunda a base decisória, algébrica e espectral da Análise Discriminante. São examinadas a formulação por perdas e risco, a forma explícita da fronteira quadrática, a decomposição populacional da covariância por grupos, as relações populacional e amostral entre Fisher e LDA e as condições de identificação das direções discriminantes.

19.14.1 Perdas e risco de classificação

A regra de máxima probabilidade posterior obtida no núcleo corresponde à perda zero-um, na qual todas as classificações incorretas recebem a mesma perda. Quando diferentes erros possuem consequências distintas, a decisão é formulada pela minimização da perda esperada posterior. Essa formulação é mais geral, mas não é necessária para desenvolver a LDA e a QDA sob perda zero-um.

Definição 19.11 (Perda de classificação). Considere o conjunto de ações

$$\mathcal{A} = \{1, \dots, K\}.$$

Uma **função de perda de classificação** é uma função

$$L : \mathcal{A} \times \{1, \dots, K\} \longrightarrow [0, \infty)$$

tal que

$$L(a, k)$$

quantifica a consequência de escolher a ação a quando a classe verdadeira é k .

Os valores

$$L(k, k)$$

correspondem às classificações corretas, enquanto

$$L(a, k), \quad a \neq k,$$

correspondem aos diferentes tipos de erro. A formulação permite atribuir consequências distintas a diferentes classificações incorretas.

Definição 19.12 (Risco condicional de classificação). Para uma observação $\mathbf{x}$ na qual as probabilidades posteriores estão definidas, o **risco condicional** de escolher a ação

$$a \in \mathcal{A}$$

é

$$R(a \mid \mathbf{x}) = \sum_{k=1}^K L(a, k) P(\mathbf{C} = k \mid \mathbf{X} = \mathbf{x}). \quad (19.48)$$

O risco condicional é a perda esperada associada a uma ação depois de observadas as características $\mathbf{x}$. Cada consequência possível é ponderada pela probabilidade posterior da respectiva classe verdadeira.

Para uma regra de classificação

$$\psi : \mathbb{R}^p \longrightarrow \mathcal{A},$$

seu risco global é

$$R(\psi) = E[L(\psi(\mathbf{X}), \mathbf{C})]. \quad (19.49)$$

Pela lei da esperança total,

$$R(\psi) = E[R(\psi(\mathbf{X}) \mid \mathbf{X})].$$

Assim, escolher em cada observação uma ação que minimize o risco condicional também minimiza o risco global. O menor risco alcançável é o **risco de Bayes**,

$$R_B = E\left[\min_{a \in \mathcal{A}} R(a \mid \mathbf{X})\right]. \quad (19.50)$$

Sob perda zero-um, R_B coincide com a probabilidade global de classificação incorreta da regra de Bayes.

Definição 19.13 (Regra de Bayes para classificação). Para cada observação $\mathbf{x}$, defina o conjunto de ações que minimizam o risco condicional por

$$\mathcal{A}_B(\mathbf{x}) = \arg \min_{a \in \mathcal{A}} R(a \mid \mathbf{x}). \quad (19.51)$$

Uma **regra de Bayes** é qualquer função

$$\psi_B : \mathbb{R}^p \longrightarrow \mathcal{A}$$

tal que

$$\psi_B(\mathbf{x}) \in \mathcal{A}_B(\mathbf{x})$$

sempre que os riscos condicionais estejam definidos.

Quando mais de uma ação minimiza o risco, uma regra de desempate pode ser especificada para produzir uma classificação única.

A regra de Bayes depende conjuntamente das distribuições condicionais, das probabilidades *a priori* e da função de perda. Sob a perda zero-um, essa formulação geral reduz-se à regra de máxima probabilidade posterior em Equação 19.3. Com perdas assimétricas, a classe de maior probabilidade posterior não precisa ser a ação que minimiza o risco (Anderson, 2003).

19.14.2 Forma explícita da fronteira quadrática

A forma quadrática da fronteira é suficiente para distinguir conceitualmente QDA e LDA. A expansão a seguir explicita como médias, covariâncias e probabilidades *a priori* determinam seus termos quadráticos, lineares e constantes.

Na Equação 19.15,

$$\mathbf{A}_{kh} = \frac{1}{2} (\Sigma_h^{-1} - \Sigma_k^{-1}),$$

$$\mathbf{b}_{kh} = \Sigma_k^{-1} \mu_k - \Sigma_h^{-1} \mu_h$$

e

$$\begin{aligned} c_{kh} = & -\frac{1}{2} \mu_k^\top \Sigma_k^{-1} \mu_k + \frac{1}{2} \mu_h^\top \Sigma_h^{-1} \mu_h \\ & - \frac{1}{2} \log |\Sigma_k| + \frac{1}{2} \log |\Sigma_h| + \log \frac{\pi_k}{\pi_h}. \end{aligned}$$

Assim, diferenças entre as inversas das matrizes de covariâncias determinam o termo quadrático, diferenças entre as médias ponderadas pelas respectivas precisões determinam o termo linear, e médias, determinantes e probabilidades *a priori* participam do termo constante.

Se

$$\Sigma_k = \Sigma_h,$$

então

$$\mathbf{A}_{kh} = \mathbf{0},$$

recuperando-se uma fronteira linear.

19.14.3 Decomposição da covariância por grupos

A identidade $\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B$ é uma aplicação da decomposição da covariância condicionada à variável de classe. Sua demonstração explícita por que a variabilidade marginal pode ser separada em uma parcela média dentro das classes e outra associada às diferenças entre seus vetores de médias.

Escreva

$$\mathbf{X} - \mu = (\mathbf{X} - \mu_C) + (\mu_C - \mu),$$

em que

$$\mu_C = E(\mathbf{X} \mid C).$$

Como

$$E[\mathbf{X} - \mu_C \mid C] = \mathbf{0},$$

os termos cruzados possuem esperança nula. Assim,

$$\text{Cov}(\mathbf{X}) = E[\text{Cov}(\mathbf{X} \mid C)] + \text{Cov}[E(\mathbf{X} \mid C)],$$

o que fornece

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B.$$

19.14.4 Relação com a discriminação linear normal

Considere agora duas populações normais com matriz de covariâncias comum,

$$\mathbf{X} \mid C = k \sim N_p(\mu_k, \Sigma), \quad k = 1, 2,$$

com

$$\Sigma \succ \mathbf{0}.$$

Na LDA, o vetor normal à fronteira entre as duas classes é

$$\Sigma^{-1}(\mu_1 - \mu_2), \quad (19.52)$$

conforme Equação 19.9.

Sob covariância condicional comum,

$$\Sigma_W = \pi_1 \Sigma + \pi_2 \Sigma = \Sigma.$$

Substituindo em Equação 19.44,

$$\mathbf{a}_F \propto \Sigma^{-1}(\mu_1 - \mu_2).$$

Assim, para duas populações com covariância comum, a direção populacional de Fisher é paralela ao vetor normal da fronteira da LDA.

Essa equivalência refere-se à **orientação**. Os problemas estatísticos continuam distintos.

Fisher procura uma direção que maximize

$$\frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}.$$

A LDA utiliza as distribuições condicionais, as probabilidades *a priori* e a função de perda para construir uma regra de classificação.

A posição da fronteira da LDA depende também dos termos

$$-\frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k.$$

Consequentemente, mudanças nas probabilidades *a priori* podem deslocar a fronteira sem modificar sua orientação. Com funções de perda diferentes da perda zero-um, a regra ótima também pode mudar sem alterar o critério geométrico de Fisher.

19.14.5 Relação amostral entre Fisher e LDA

A equivalência de orientação entre Fisher e LDA para dois grupos também aparece na solução estimada. Quando as duas formulações são construídas a partir da mesma amostra e da mesma dispersão intragrupos, a matriz de covariâncias agrupada da LDA é proporcional à SQPC intragrupos utilizada por Fisher. Seus vetores discriminantes diferem, portanto, apenas por um fator de escala.

Na amostra, Equação 19.16 fornece

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}.$$

Consequentemente,

$$\mathbf{S}_p^{-1} = (n - K) \mathbf{T}_{\text{intra}}^{-1},$$

quando as duas matrizes são não singulares.

Para

$$K = 2,$$

segue que

$$\mathbf{S}_p^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (19.53)$$

Assim, quando a mesma estimativa agrupada de covariâncias é utilizada, a orientação estimada da fronteira da LDA coincide, até escala, com a direção amostral de Fisher.

A regra estimada da LDA ainda contém os termos associados às probabilidades *a priori* e às médias das classes, necessários para determinar a posição da fronteira e classificar novas observações.

19.14.6 Identificação das direções discriminantes

As direções de Fisher apresentam as indeterminações próprias do problema de autovalores generalizados.

Para uma raiz positiva simples,

$$\lambda_j,$$

a direção normalizada

$$\alpha_j$$

satisfaz

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j$$

e

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1.$$

A normalização fixa a escala, mas permanece a indeterminação de sinal:

$$\alpha_j \quad \text{e} \quad -\alpha_j$$

representam o mesmo eixo discriminante.

A mudança de sinal transforma

$$z_j(\mathbf{x})$$

em

$$-z_j(\mathbf{x}),$$

sem modificar o subespaço, a separação dos centroides ou as distâncias ao longo do eixo.

Quando uma raiz positiva possui multiplicidade maior que 1, os autovetores individuais associados não são únicos. Diferentes bases ortonormais na métrica induzida por

$$\mathbf{T}_{\text{intra}}$$

podem representar o mesmo autoespaço.

Nesse caso, o objeto identificado é o subespaço discriminante associado à raiz repetida, e não uma base particular de direções.

19.15 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne procedimentos utilizados para avaliar o desempenho da regra de classificação e interpretar as funções discriminantes. São examinados os diferentes coeficientes associados às funções discriminantes, o erro aparente, o erro em novas observações, a matriz de classificação e a correspondência entre os objetos desenvolvidos no capítulo e a implementação utilizada.

19.15.1 Coeficientes das funções discriminantes

As direções discriminantes determinam as coordenadas utilizadas para representar a separação entre os grupos. Na interpretação das funções, podem aparecer diferentes versões de seus coeficientes e correlações entre as características originais e as coordenadas discriminantes. Esses objetos possuem significados distintos e não devem ser utilizados de forma intercambiável.

Os elementos de α_j são os coeficientes utilizados para construir a coordenada discriminante

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}}).$$

Esses coeficientes dependem da escala das características, de sua estrutura de dispersão e da normalização adotada para a direção. Sua magnitude isolada não fornece, em geral, uma medida direta da importância de cada variável.

Uma mesma direção discriminante pode ser representada por vetores que diferem por um escalar não nulo. Uma forma adicional de normalização consiste em definir

$$\tilde{\alpha}_j = \frac{\alpha_j}{\|\alpha_j\|_2}. \quad (19.54)$$

Esse reescalonamento não preserva necessariamente a normalização em Equação 19.32, mas preserva a direção geométrica, pois

$$\text{span}(\tilde{\alpha}_j) = \text{span}(\alpha_j).$$

Os **coeficientes normalizados** são, portanto, os coeficientes da mesma direção expressos em outra escala. Eles não constituem uma nova medida de associação entre as características e a função discriminante.

Outro objeto é fornecido pelas **cargas discriminantes**, também denominadas **correlações de estrutura**. Na solução amostral, a carga associada à característica h e à função discriminante j é a correlação amostral entre os valores observados dessa característica e as coordenadas discriminantes correspondentes. Denote essa correlação por

$$r_{hj}^{(\text{estrutura})}.$$

Esse objeto descreve a associação linear entre a característica observada e a função discriminante construída.

O coeficiente da direção e o coeficiente de estrutura possuem interpretações distintas. O primeiro participa diretamente da construção da combinação linear; o segundo descreve a associação linear entre uma característica e a coordenada resultante. Como as características originais podem estar correlacionadas, uma variável pode apresentar coeficiente relativamente pequeno na combinação linear e, ainda assim, correlação elevada com a função discriminante.

Assim, a interpretação deve distinguir os coeficientes que definem a direção, seus reescalamentos e as correlações das características com as coordenadas discriminantes. Esses objetos fornecem informações distintas sobre a construção e a interpretação das funções discriminantes.

19.15.2 Erro aparente e erro em novas observações

A formulação da LDA e da QDA determina como construir uma regra de classificação. Avaliar o desempenho dessa regra constitui um problema adicional. Em particular, o erro observado nas mesmas unidades utilizadas para estimar a regra deve ser distinguido do erro obtido em observações que não participaram da estimação.

Considere uma amostra de treinamento formada por pares

$$(\mathbf{x}_i, c_i), \quad i = 1, \dots, n,$$

utilizados para construir uma regra $\hat{\psi}$. A proporção de classificações incorretas calculada nas próprias observações utilizadas no ajuste é o **erro aparente**,

$$\hat{R}_{\text{aparente}} = \frac{1}{n} \sum_{i=1}^n \mathbb{1} \{ \hat{\psi}(\mathbf{x}_i) \neq c_i \}, \quad (19.55)$$

em que $\mathbb{1}\{\cdot\}$ é a função indicadora.

Esse erro descreve o desempenho da regra nas unidades que também contribuíram para estimar seus parâmetros e tende a ser otimista como estimativa do erro em novas observações, porque os mesmos dados participam do ajuste e da avaliação (Johnson; Wichern, 2007).

Considere agora uma amostra de teste independente da amostra de treinamento, formada por m pares

$$(\mathbf{x}_i^*, c_i^*), \quad i = 1, \dots, m,$$

que não participaram da estimação da regra. A proporção de classificações incorretas nesse conjunto é

$$\widehat{R}_{\text{teste}} = \frac{1}{m} \sum_{i=1}^m \mathbb{1} \{ \widehat{\psi}(\mathbf{x}_i^*) \neq c_i^* \}. \quad (19.56)$$

O erro aparente descreve o comportamento da regra nas observações utilizadas em sua construção, enquanto o erro de teste descreve seu comportamento em observações que não participaram da estimação. Quando a amostra de teste representa o mecanismo populacional no qual a regra será aplicada, esse erro fornece uma avaliação externa de seu desempenho preditivo. Validação cruzada e outros procedimentos procuram obter avaliações análogas sem reutilizar uma observação simultaneamente para ajustar e avaliar a mesma regra (Hair et al., 2018; Johnson; Wichern, 2007).

19.15.3 Matriz de classificação

A **matriz de classificação** cruza a classe observada com a classe atribuída pela regra. As entradas da diagonal correspondem às classificações corretas, enquanto as entradas fora da diagonal identificam os tipos de erro cometidos.

A proporção global de classificações incorretas resume o desempenho da regra, mas pode ocultar diferenças importantes entre as classes. As proporções calculadas dentro de cada classe permitem identificar classes com maior ou menor frequência de classificação correta e quais erros de classificação ocorrem com maior frequência (Hair et al., 2018; Johnson; Wichern, 2007).

No caso de duas classes, medidas como sensibilidade e especificidade podem ser obtidas depois de definida qual classe representa o evento de interesse. Para mais de duas classes, essas medidas exigem uma definição específica por classe ou uma estratégia de comparação de uma classe contra as demais.

Correspondência com a implementação utilizada

A implementação utilizada nas aulas, por meio do módulo `snowCluster`, disponibiliza a

Análise Discriminante Linear (LDA). A QDA permanece neste capítulo porque a distinção entre covariância comum e covariâncias específicas por classe pertence à formulação estatística da técnica, mesmo quando a implementação adotada não disponibiliza diretamente a regra quadrática.

A rotina computacional subjacente utiliza `MASS::lda()`, do pacote MASS (Ripley; Venables, 2002). Na configuração utilizada pelo módulo, o argumento `prior` não é especificado no ajuste; consequentemente, as probabilidades *a priori* utilizadas pela rotina são determinadas pelas proporções das classes no conjunto de treinamento. O item apresentado como *Prior probability* é uma saída do procedimento e não uma escolha das probabilidades pelo usuário.

A implementação apresenta separadamente coeficientes das funções discriminantes, *normalized loadings* e *structure coefficients*. Os *normalized loadings* correspondem ao reescalonamento euclidiano dos vetores discriminantes, enquanto os *structure coefficients* são correlações entre as características observadas e as coordenadas discriminantes. Esses objetos não devem ser interpretados como medidas equivalentes.

Medidas resumidas associadas às diferentes funções discriminantes devem ser interpretadas de acordo com a transformação utilizada pela implementação. Em particular, valores apresentados como *eigenvalue* ou *variance explained* não devem ser identificados automaticamente com λ_j ou com ρ_j definidos neste capítulo sem verificar a escala utilizada no cálculo.

19.16 Síntese

A Análise Discriminante utiliza grupos previamente conhecidos para construir regras de classificação e representar a separação entre as classes.

Na formulação probabilística, cada classe é caracterizada por uma probabilidade *a priori* π_k e por uma distribuição condicional das características. Sob perda zero-um, a regra de Bayes atribui uma observação a uma classe que maximize

$$\pi_k f_k(\mathbf{x}),$$

ou, equivalentemente, sua probabilidade posterior.

Quando as distribuições condicionais são normais e compartilham uma matriz de covariâncias comum, obtém-se a LDA, cujas fronteiras de classificação são lineares. Quando cada classe possui sua própria matriz de covariâncias, obtém-se a QDA, cujas fronteiras podem conter termos quadráticos. Na passagem para as regras amostrais, médias e matrizes de covariâncias desconhecidas são substituídas por estimativas. As probabilidades *a priori* utilizadas na classificação podem ser estimadas a partir da amostra ou especificadas com base em informação externa e no problema de decisão.

Na formulação geométrica de Fisher, a direção $\mathbf{a}$ é avaliada pela separação entre os grupos relativamente à dispersão intragrupos:

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

Quando

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

as direções discriminantes são obtidas pelo problema de autovalores generalizados

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j.$$

O número de direções associadas a raízes positivas satisfaz

$$r_F \leq \min(p, K - 1).$$

As combinações lineares definidas por essas direções produzem coordenadas discriminantes que representam a separação entre os grupos relativamente à dispersão intragrupos.

Para duas classes, existe no máximo uma direção discriminante associada a uma raiz positiva. Sob normalidade e covariância comum, a direção populacional de Fisher é paralela ao vetor normal da fronteira da LDA,

$$\Sigma^{-1} (\mu_1 - \mu_2).$$

Essa correspondência não torna as duas formulações equivalentes em objetivo: Fisher constrói uma direção de separação, enquanto a LDA estabelece uma regra probabilística de classificação cuja posição também depende das probabilidades *a priori* e da função de perda.

A normalidade das distribuições condicionais não é necessária para definir o critério geométrico de Fisher. Ela pertence às formulações normais da LDA e da QDA. A LDA assume covariância comum entre as classes, enquanto a QDA permite matrizes de covariâncias específicas. As formulações baseadas em inversas exigem ainda condições de não singularidade, e quase dependências lineares podem produzir mau condicionamento antes da perda efetiva de posto.

Mesmo com os parâmetros populacionais conhecidos, a sobreposição entre as distribuições condicionais pode produzir classificações incorretas. Sob perda zero-um, a probabilidade global mínima de classificação incorreta alcançada pela regra de Bayes é o erro de Bayes. Em regras estimadas, esse limite deve ser distinguido do erro adicional associado à estimação dos parâmetros.

Quando a MANOVA compara os vetores de médias correspondentes à mesma partição em grupos utilizada por Fisher,

$$\mathbf{H} = \mathbf{T}_{\text{entre}} \quad \text{e} \quad \mathbf{E} = \mathbf{T}_{\text{intra}},$$

e as duas técnicas conduzem ao mesmo problema espectral, embora utilizem sua solução para finalidades distintas. A ACP procura direções de elevada variabilidade total sem utilizar os rótulos das classes. A Análise de Agrupamentos também parte de um problema diferente, pois procura construir grupos que não são conhecidos previamente.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir os problemas de discriminação, classificação e formação de grupos;
- formular a regra de Bayes e identificar o papel das probabilidades *a priori*, das distribuições condicionais e da função de perda;
- distinguir LDA e QDA a partir da estrutura das matrizes de covariâncias e da geometria de suas fronteiras;
- formular o critério de Fisher e obter as direções discriminantes por meio de um problema de autovalores generalizados;
- distinguir parâmetros populacionais, estatísticas amostrais e objetos utilizados nas regras estimadas;
- identificar os principais pressupostos, limites e relações da Análise Discriminante com MANOVA, ACP e Análise de Agrupamentos.

Com a Análise Discriminante, encerra-se a formulação das técnicas multivariadas deste módulo. Os capítulos mostraram como combinações lineares, distâncias, estruturas de covariância, decomposições matriciais, modelos probabilísticos e problemas espectrais assumem funções diferentes conforme o problema estatístico. As etapas posteriores poderão utilizar essas formulações para desenvolver implementação, diagnóstico, interpretação, validação e aplicação.

Exercícios de fixação do Módulo III

Os exercícios deste módulo retomam a formulação matemática e estatística das técnicas multivariadas desenvolvidas no Módulo III.

A lista está dividida em três partes, de acordo com a função do conteúdo no módulo.

Na **Parte I — Núcleo**, os exercícios verificam a compreensão do problema estatístico de cada técnica, seus objetos de entrada, a formulação matemática, as principais quantidades calculadas e a interpretação dos resultados.

Na **Parte II — Aprofundamentos teóricos**, os exercícios exploram propriedades, demonstrações, condições de existência, invariâncias, identificação, relações espectrais e resultados probabilísticos que explicam por que as formulações do núcleo funcionam.

Na **Parte III — Aprofundamentos metodológicos e aplicados**, os exercícios utilizam o R para examinar decisões de análise, adequação dos dados, escolha de dimensionalidade ou número de grupos, interpretação, diagnóstico e avaliação dos resultados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Definições, teoremas, proposições, propriedades, identidades e decomposições já estabelecidos nos Módulos I, II e III podem e devem ser utilizados diretamente, salvo quando uma demonstração ou derivação for solicitada explicitamente.

Sempre que um resultado dos módulos anteriores for utilizado, identifique o resultado empregado e verifique suas condições de validade. Não basta reproduzir uma fórmula ou uma saída de software. Quando forem necessárias condições de existência de momentos, definição positiva, invertibilidade, posto, independência, normalidade, tamanho amostral, graus de liberdade ou identificabilidade, essas condições devem ser indicadas.

Os exercícios do Módulo III devem combinar os fundamentos anteriores com o problema específico de cada técnica. Assim, projeções, quocientes de Rayleigh, SVD, autovalores generalizados, branqueamento, matrizes de covariâncias, distribuição Normal Multivariada, estimação, modelo linear multivariado, Wishart e resultados de inferência já desenvolvidos devem ser reutilizados.

Quando houver inferência, diferencie a construção algébrica ou geométrica da estatística. Quando houver escolha metodológica, explicita como a decisão adotada pode modificar a solução.

Parte I — Núcleo

Exercício 19.1 (Problemas estatísticos e estruturas das técnicas multivariadas). Considere as situações a seguir.

Situação A. Uma equipe possui seis medidas quantitativas de qualidade ambiental obtidas em 120 locais e deseja construir duas combinações lineares que representem a maior parte possível da variabilidade observada.

Situação B. Um questionário possui doze itens quantitativos destinados a medir dimensões não observadas de satisfação. O objetivo é representar as covariâncias entre os itens por um número menor de fatores comuns.

Situação C. Cem municípios são descritos por indicadores socioeconômicos e não existe uma classificação prévia. Deseja-se formar grupos de municípios internamente semelhantes.

Situação D. Uma tabela cruza quatro categorias de ocupação com cinco níveis de escolaridade. O objetivo é representar as associações entre as categorias das duas variáveis.

Situação E. Três tratamentos foram aplicados a grupos previamente definidos e quatro respostas quantitativas foram medidas em cada unidade. O objetivo é testar se os vetores de médias diferem entre os tratamentos.

Situação F. Três espécies previamente conhecidas são descritas por medidas morfométricas. Deseja-se representar sua separação e construir uma regra para classificar novos indivíduos.

1. Para cada situação, identifique a técnica do Módulo III mais diretamente associada ao problema.
2. Para cada técnica identificada, indique:
 - o objeto de entrada;
 - qual estrutura é fornecida previamente (rótulos de grupos, tratamentos, categorias observadas ou nenhuma dessas estruturas) e qual papel ela desempenha na análise;
 - o objeto matemático;
 - o principal critério de construção da solução;
 - se o objetivo principal é redução, estrutura latente, agrupamento, associação, comparação ou classificação.
3. Compare as Situações A e B. Explique por que ambas podem produzir poucas dimensões a partir de muitas variáveis, mas não resolvem o mesmo problema estatístico.

4. Compare as Situações C e F. Explique o papel dos grupos em cada técnica e por que a existência de rótulos conhecidos modifica a formulação do problema.
5. Compare as Situações D e A. Explique por que a Análise de Correspondência utiliza uma geometria de perfis e massas, enquanto a ACP parte de uma matriz de covariâncias ou correlações entre variáveis quantitativas.
6. Compare as Situações E e F. Explique por que MANOVA e Análise Discriminante podem compartilhar estruturas de dispersão entre e dentro dos grupos, embora possuam objetivos estatísticos diferentes.

Exercício 19.2 (ACP: variância, direções principais e representação). Considere um vetor aleatório bidimensional com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

1. Verifique que Σ é simétrica e positiva definida.
2. Determine seus autovalores e escolha uma base ortonormal de autovetores associados, ordenando os autovalores de forma decrescente.
3. Escreva as duas componentes principais populacionais

$$Y_j = \alpha_j^\top \mathbf{X}, \quad j = 1, 2.$$

4. Determine a variância de cada componente principal e verifique que a soma dessas variâncias é igual a

$$\text{tr}(\Sigma).$$

5. Calcule a proporção da variância total explicada pela primeira componente e a proporção acumulada pelas duas componentes.
6. Explique por que a primeira componente maximiza a variância entre todas as combinações lineares com vetor de coeficientes de norma igual a um. Relacione a argumentação ao problema de variância direcional praticado em Exercício 7.10 e à caracterização variacional das direções sucessivas estabelecida em Teorema 5.7.
7. Considere a observação centralizada

$$\mathbf{x} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Calcule seus escores nas duas componentes.

8. Reconstrua $\mathbf{x}$:

- utilizando as duas componentes;
- utilizando apenas a primeira componente.

Calcule o erro quadrático da reconstrução de uma componente e interprete o que foi descartado pela redução de dimensão. Relacione a reconstrução à projeção ortogonal praticada em Exercício 7.24.

9. Explique o que mudaria na interpretação se a ACP fosse construída a partir da matriz de correlações em vez da matriz de covariâncias.

Exercício 19.3 (Análise Fatorial: estrutura comum de covariâncias). Considere um modelo fatorial ortogonal para quatro variáveis padronizadas e dois fatores comuns, com matriz de cargas

$$\Phi = \begin{bmatrix} 0,8 & 0 \\ 0,6 & 0,2 \\ 0,1 & 0,7 \\ 0 & 0,8 \end{bmatrix}$$

e matriz de especificidades

$$\Psi = \text{diag}(0,36, 0,60, 0,50, 0,36).$$

1. Calcule a comunalidade de cada variável e verifique que, para todas elas,

$$h_i^2 + \psi_i = 1.$$

2. Construa a matriz de covariâncias comuns

$$\Phi\Phi^\top.$$

3. Obtenha a matriz reproduzida

$$\Sigma = \Phi\Phi^\top + \Psi.$$

4. Interprete:

- os elementos diagonais de $\Phi\Phi^\top$;
- os elementos fora da diagonal;
- os elementos diagonais de Ψ .

- Compare as covariâncias reproduzidas entre os pares (X_1, X_2) , (X_1, X_4) e (X_3, X_4) . Explique como as cargas compartilhadas pelos pares de variáveis determinam essas covariâncias.
- Considere uma matriz ortogonal

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e a matriz de cargas rotacionadas

$$\Phi^* = \Phi \mathbf{Q}.$$

Mostre que

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top.$$

- Explique por que a rotação altera as cargas individuais, mas não altera a matriz de covariâncias comuns reproduzida no modelo ortogonal.
- Explique, com base neste exemplo, por que uma carga fatorial não deve ser interpretada da mesma maneira que um coeficiente de uma componente principal.

Exercício 19.4 (Agrupamentos: partições, centroides e métodos hierárquicos). Considere seis observações bidimensionais:

$$\mathbf{x}_1 = (0, 0), \quad \mathbf{x}_2 = (0, 2), \quad \mathbf{x}_3 = (2, 0),$$

$$\mathbf{x}_4 = (8, 8), \quad \mathbf{x}_5 = (8, 10), \quad \mathbf{x}_6 = (10, 8).$$

- Calcule as distâncias euclidianas entre todos os pares de observações e organize os resultados em uma matriz de distâncias.
- Considere a partição

$$\mathcal{P}_A = \{\{1, 2, 3\}, \{4, 5, 6\}\}.$$

Determine os dois centroides e calcule o critério das K -médias

$$J_2(\mathcal{P}_A).$$

3. Considere agora

$$\mathcal{P}_B = \{\{1, 2, 4\}, \{3, 5, 6\}\}.$$

Calcule os centroides e $J_2(\mathcal{P}_B)$. Compare as duas partições.

4. Explique por que a partição com menor dispersão intragrupos também possui maior dispersão entre grupos quando $K = 2$ permanece fixado.
5. Começando com seis grupos unitários, determine qual ou quais fusões podem ocorrer primeiro segundo:
 - ligação simples;
 - ligação completa;
 - ligação média;
 - método de Ward.

Em caso de empate, indique todas as fusões possíveis.

Em seguida, suponha que a primeira fusão escolhida tenha sido entre as observações 1 e 2, formando o grupo $G = \{1, 2\}$. Calcule o critério utilizado para comparar G com o grupo unitário $\{3\}$ segundo ligação simples, ligação completa, ligação média e Ward. Explique por que as quatro regras deixam de ser equivalentes depois que aparecem grupos com mais de uma observação.

6. Para dois grupos unitários contendo $\mathbf{x}_i$ e $\mathbf{x}_j$, mostre que o incremento de Ward é

$$\Delta_{ij} = \frac{1}{2} \|\mathbf{x}_i - \mathbf{x}_j\|^2.$$

7. Explique por que o corte de um dendrograma de Ward em dois grupos não precisa coincidir, em geral, com o mínimo global do critério das K -médias para $K = 2$.

Exercício 19.5 (Análise de Correspondência: perfis, inércia e dimensão). Considere a tabela de contingência

$$\mathbf{N} = \begin{bmatrix} 30 & 10 & 10 \\ 10 & 20 & 20 \end{bmatrix},$$

em que as linhas representam duas categorias de uma variável e as colunas três categorias de outra.

1. Calcule:

- o total n ;

- a matriz de frequências relativas $\mathbf{P}$;
 - as massas das linhas;
 - as massas das colunas.
2. Determine os perfis das duas linhas e os perfis das três colunas.
 3. Sob independência, obtenha a matriz esperada de frequências relativas

$$\mathbf{r}\mathbf{c}^\top.$$

4. Calcule a distância qui-quadrado entre os dois perfis de linhas.
5. Calcule a estatística qui-quadrado de Pearson da tabela e obtenha a inércia total pela identidade

$$\mathcal{J} = \frac{\chi^2}{n}.$$

6. Construa a matriz de desvios padronizados

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

Nos itens seguintes, quando utilizar a decomposição dessa matriz, recupere a interpretação da SVD praticada em Exercício 7.13.

7. Determine o posto máximo possível de $\mathbf{Q}_{\text{CA}}$ neste problema e explique por que a representação possui, no máximo, uma dimensão não trivial.
8. Verifique que a soma dos quadrados dos elementos de $\mathbf{Q}_{\text{CA}}$ é igual à inércia total.
9. Explique por que a identidade $\chi^2 = n\mathcal{J}$ é exata para a tabela observada, enquanto a utilização de uma distribuição qui-quadrado para realizar um teste de independência exige uma formulação probabilística adicional.

Exercício 19.6 (MANOVA: matrizes de hipótese e erro e critérios multivariados). Considere uma hipótese multivariada para duas respostas cuja matriz de hipótese e matriz de erro sejam

$$\mathbf{H} = \begin{bmatrix} 8 & 0 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{E} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Verifique que $\mathbf{E}$ é positiva definida.
2. Resolva o problema de autovalores generalizados

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e determine as duas raízes características em ordem decrescente. Utilize, quando necessário, a estrutura praticada em Exercício 7.11.

3. Identifique as direções generalizadas correspondentes e normalize-as na métrica de $\mathbf{E}$.
4. Para uma combinação linear $\mathbf{a}^\top \mathbf{Y}$, interprete

$$\frac{\mathbf{a}^\top \mathbf{H}\mathbf{a}}{\mathbf{a}^\top \mathbf{E}\mathbf{a}}.$$

5. Calcule:

- a lambda de Wilks;
- o traço de Pillai;
- o traço de Hotelling–Lawley;
- a maior raiz de Roy.

6. Explique como cada critério agrega as mesmas raízes características de forma diferente.
7. Repita conceitualmente o problema após a transformação de branqueamento pela matriz $\mathbf{E}$. Explique o que acontece com a métrica residual e relacione a transformação a Exercício 7.12.
8. Indique quais resultados dos itens anteriores são puramente algébricos e quais etapas adicionais seriam necessárias para transformar os critérios em testes inferenciais.

Exercício 19.7 (Análise Discriminante: LDA, Fisher e classificação). Considere duas populações com vetores de médias

$$\mu_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mu_2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e matriz de covariâncias comum

$$\Sigma = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 1 \end{bmatrix}.$$

Admita probabilidades *a priori* iguais e perda zero–um.

1. Verifique que Σ é positiva definida e calcule Σ^{-1} . Relacione a geometria induzida por Σ^{-1} ao que foi praticado em Exercício 7.8.
2. Escreva as duas funções discriminantes lineares populacionais da LDA, desprezando constantes comuns às classes.
3. Determine a fronteira de classificação entre as duas classes e mostre que ela pode ser escrita como

$$x_1 + x_2 = 2.$$

4. Classifique as observações

$$\mathbf{x}_A = \begin{bmatrix} 0,5 \\ 0,5 \end{bmatrix}$$

e

$$\mathbf{x}_B = \begin{bmatrix} 1,5 \\ 1,2 \end{bmatrix}.$$

5. Determine a direção populacional de Fisher para duas classes e mostre que ela é proporcional a

$$\Sigma^{-1} (\mu_2 - \mu_1).$$

Relacione essa direção ao tipo de problema espectral generalizado estudado em Exercício 7.11.

6. Explique por que, sob as condições deste exercício, a direção de Fisher e a direção que aparece na fronteira da LDA estão diretamente relacionadas.
7. Suponha agora que as probabilidades *a priori* deixem de ser iguais. Explique qual termo das funções discriminantes é alterado e por que a fronteira se desloca.
8. Explique por que a formulação geométrica de Fisher pode ser construída sem normalidade, enquanto a interpretação probabilística da LDA utilizada neste exercício depende do modelo normal com covariância comum.

Parte II — Aprofundamentos teóricos

Exercício 19.8 (ACP: propriedades espectrais, reconstrução e multiplicidade). Considere uma matriz de covariâncias populacional

$$\Sigma = \mathbf{A}\Lambda\mathbf{A}^\top,$$

em que $\mathbf{A}$ é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

1. Demonstre que as componentes principais

$$Y_j = \alpha_j^\top \mathbf{X}$$

são não correlacionadas.

2. Mostre que

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

3. Para uma observação centralizada $\mathbf{x}$, escreva sua reconstrução utilizando as primeiras k direções principais e mostre que o vetor reconstruído é a projeção ortogonal de $\mathbf{x}$ sobre

$$\text{span}(\alpha_1, \dots, \alpha_k).$$

4. Mostre que o erro de reconstrução pode ser escrito como a soma dos quadrados dos escores descartados.
5. Considere uma matriz de dados centralizada $\mathbf{X}_c \in \mathbb{R}^{n \times p}$ e a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Utilize os resultados de SVD e aproximação de posto reduzido já estudados no Módulo I, em particular Exercício 7.14 e Exercício 7.26, para relacionar a reconstrução pelas primeiras k componentes principais à melhor aproximação de posto k de $\mathbf{X}_c$.

6. Suponha agora que $\lambda_2 = \lambda_3$ seja um autovalor de multiplicidade exatamente dois, distinto dos demais autovalores.

Explique: - quais objetos continuam unicamente determinados; - por que os autovetores individuais associados a $\lambda_2 = \lambda_3$ não são únicos; - por que o autoespaço bidimensional correspondente permanece unicamente determinado.

7. Explique por que uma mudança de sinal de um autovetor altera o sinal dos escores correspondentes, mas não altera a variância explicada nem a reconstrução quando o mesmo sinal é utilizado de forma consistente.

Exercício 19.9 (Análise Fatorial: identificação, rotação e formulação normal). Considere o modelo fatorial ortogonal

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon,$$

com

$$E(\mathbf{F}) = \mathbf{0}, \quad \text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$E(\varepsilon) = \mathbf{0}, \quad \text{Cov}(\varepsilon) = \Psi,$$

em que $\Psi \succ \mathbf{0}$ é diagonal e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

1. Obtenha

$$\Sigma = \Phi \Phi^\top + \Psi.$$

2. Seja $\mathbf{Q}$ uma matriz ortogonal de ordem m . Mostre que

$$\Phi^* = \Phi \mathbf{Q}$$

gera a mesma matriz de covariâncias observável.

3. Explique por que o resultado anterior implica indeterminação rotacional e por que a rotação não corrige falta de ajuste da matriz reproduzida.
4. Inicialmente, conte os elementos livres de Φ e Ψ antes de considerar a indeterminação rotacional. Em seguida, utilize o fato de que o grupo de matrizes ortogonais de ordem m possui $m(m-1)/2$ graus de liberdade para determinar a dimensão efetiva da parametrização após descontar essa indeterminação.

Compare o resultado com os

$$\frac{p(p+1)}{2}$$

elementos distintos de Σ e obtenha a condição de contagem correspondente. Explique por que essa condição é necessária, mas não suficiente, para identificação do modelo fatorial.

5. Sob o modelo fatorial normal,

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m), \quad \varepsilon \sim N_p(\mathbf{0}, \Psi),$$

com independência entre os dois vetores, determine a distribuição marginal de $\mathbf{X}$.

6. Utilizando os resultados sobre a distribuição Normal Multivariada particionada estudados no Módulo II, em particular Exercício 12.2, obtenha

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}).$$

7. Explique por que a expressão obtida no item anterior fundamenta o escore fatorial por regressão, mas não transforma o fator latente em uma variável observada.

Exercício 19.10 (Agrupamentos: minimização, existência, invariâncias e Ward). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p.$$

1. Para um grupo não vazio G , demonstre que o ponto

$$\bar{\mathbf{x}}_G = \frac{1}{|G|} \sum_{i \in G} \mathbf{x}_i$$

minimiza

$$\sum_{i \in G} \|\mathbf{x}_i - \mathbf{c}\|^2$$

em relação a $\mathbf{c} \in \mathbb{R}^p$.

2. Utilize o resultado anterior para justificar por que, fixada uma partição, o centroide é a escolha ótima no critério das K -médias.
3. Para $1 \leq K \leq n$, explique por que o conjunto de partições admissíveis das n observações em K grupos não vazios é finito. Conclua que o mínimo global W_K é atingido por pelo menos uma partição.
4. Mostre que, para $1 \leq K < n$,

$$W_{K+1} \leq W_K,$$

em que W_K é o mínimo global da dispersão intragrupos entre todas as partições em K grupos não vazios.

5. Explique por que a monotonicidade de W_K não fornece, sozinha, um número ótimo de grupos.
6. Mostre que translações comuns de todas as observações preservam o critério das K -médias.
7. Determine o efeito de multiplicar todas as coordenadas por uma constante $c \neq 0$ sobre:
 - as distâncias euclidianas;
 - o critério J_K ;
 - a partição que minimiza o critério.

Relacione a discussão de mudança de escala à geometria induzida já praticada em Exercício 7.8.

8. Considere dois grupos A e B , com tamanhos n_A e n_B e centroides $\bar{\mathbf{x}}_A$ e $\bar{\mathbf{x}}_B$. Obtenha o incremento de Ward

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$

9. Explique por que empates no critério de fusão podem produzir mais de uma hierarquia admissível.

Exercício 19.11 (Análise de Correspondência: posto, relações baricêntricas e reconstrução). Considere uma tabela ativa com I linhas, J colunas, massas estritamente positivas e matriz de desvios padronizados

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

1. Mostre que

$$\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}$$

e

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}.$$

2. Utilize essas relações para justificar

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1).$$

3. A partir da SVD

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

obtenha a decomposição da inércia total como soma das inércias principais. Utilize diretamente a estrutura de SVD praticada em Exercício 7.13.

4. Obtenha as relações baricêntricas entre coordenadas principais de uma margem e coordenadas padrão da outra.
5. Mostre que as coordenadas padrão e principais são centralizadas em relação às respectivas massas.
6. A partir da reconstrução completa dos desvios da independência, obtenha uma expressão para p_{ij} em função de r_i , c_j , dos valores singulares e das coordenadas padrão.
7. Considere uma reconstrução truncada nas primeiras k dimensões. Mostre que as marginais $\mathbf{r}$ e $\mathbf{c}$ são preservadas. Relacione a truncagem à aproximação de posto reduzido praticada em Exercício 7.14.
8. Explique por que a reconstrução truncada pode, apesar disso, produzir alguma célula negativa.

9. Mostre como a estatística de Pearson pode ser decomposta pelas dimensões e explique por que isso não implica automaticamente que cada termo dimensional possua, isoladamente, uma distribuição qui-quadrado de referência.

Exercício 19.12 (MANOVA: base probabilística, verossimilhança e invariância). Considere o modelo linear multivariado normal com matriz de covariâncias residual $\Sigma \succ \mathbf{0}$ e uma hipótese linear estimável que produz as matrizes aleatórias de hipótese e erro

$$\mathbf{H} \text{ e } \mathbf{E}.$$

Admita que os graus de liberdade residuais sejam suficientes para que $\mathbf{E} \succ \mathbf{0}$ quase certamente. Relacione essa condição aos resultados sobre posto e distribuição Wishart estudados no Módulo II e, ao distinguir resultados exatos e assintóticos, recupere Exercício 12.5.

1. Sob H_0 , identifique as distribuições de Wishart associadas a $\mathbf{H}$ e $\mathbf{E}$ e indique os respectivos graus de liberdade.
2. Explique por que a independência entre $\mathbf{H}$ e $\mathbf{E}$ é importante para a construção das distribuições dos critérios MANOVA.
3. Mostre que as raízes características podem ser obtidas a partir do problema simétrico

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \mathbf{z} = \lambda \mathbf{z}.$$

Relacione a passagem ao problema simétrico com Exercício 7.11 e Exercício 7.12.

4. Obtenha

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{H} + \mathbf{E}|} = \prod_{j=1}^s \frac{1}{1 + \lambda_j}.$$

5. Relacione a lambda de Wilks à razão de verossimilhanças entre o modelo restrito e o modelo irrestrito.
6. Suponha uma transformação não singular das respostas,

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}.$$

Mostre como $\mathbf{H}$ e $\mathbf{E}$ se transformam e prove que as raízes características permanecem inalteradas.

7. Conclua, a partir do item anterior, que Wilks, Pillai, Hotelling–Lawley e Roy são invariantes a transformações lineares não singulares das respostas quando a hipótese é transformada de forma compatível.

8. Considere o caso em que existe no máximo uma raiz não nula. Mostre que Pillai, Hotelling–Lawley e Roy são funções crescentes dessa raiz, enquanto a lambda de Wilks é decrescente, e explique por que os quatro critérios conduzem ao mesmo teste quando a calibração é realizada de forma consistente.

Exercício 19.13 (Análise Discriminante: risco, fronteiras e relações com Fisher). Considere K classes com densidades condicionais $f_k(\mathbf{x})$, probabilidades *a priori* π_k e perdas $L(j | k)$ associadas à decisão pela classe j quando a classe verdadeira é k .

1. Escreva o risco condicional de decidir pela classe j dado $\mathbf{x}$.
2. Mostre que, sob perda zero–um, a regra de Bayes escolhe a classe que maximiza

$$\pi_k f_k(\mathbf{x}).$$

3. Suponha populações normais multivariadas com matrizes de covariâncias específicas Σ_k . Obtenha a função discriminante quadrática, desprezando termos comuns às classes. Ao organizar a derivação, recupere a estrutura da distribuição Normal Multivariada praticada em Exercício 12.2.
4. Mostre que, quando

$$\Sigma_1 = \cdots = \Sigma_K = \Sigma,$$

os termos quadráticos em $\mathbf{x}$ comuns às classes se cancelam e a fronteira entre duas classes torna-se linear.

5. Para duas classes com covariância comum, obtenha a direção da fronteira da LDA e relacione-a a

$$\Sigma^{-1} (\mu_1 - \mu_2).$$

6. No caso de duas classes, mostre que a direção populacional de Fisher é proporcional à mesma quantidade quando a dispersão intragrupos é dada pela covariância comum.
7. Para K grupos, obtenha a decomposição

$$\Sigma = \Sigma_W + \Sigma_B$$

a partir da lei da covariância total.

8. Explique por que o problema espectral de Fisher compartilha a estrutura de dispersões dentro e entre grupos com a MANOVA, embora os objetivos de classificação/discriminação e teste de hipótese sejam diferentes. Relacione a construção espectral a Exercício 7.11 e, quando pertinente, ao branqueamento estudado em Exercício 7.12.
-

Parte III — Aprofundamentos metodológicos e aplicados

Nesta parte, utilize o R. Quando um objeto central da técnica puder ser construído diretamente por operações matriciais, faça primeiro essa construção e utilize funções prontas depois, como conferência ou para ampliar a análise.

As decisões metodológicas devem ser justificadas. Não escolha padronização, número de dimensões, número de fatores, número de grupos, rotação, regra de classificação ou procedimento inferencial apenas porque uma função produziu determinada saída.

Exercício 19.14 (ACP com os dados `USArrests`). Utilize o conjunto de dados `USArrests`.

1. Examine as quatro variáveis e compare suas escalas por meio de médias, desvios padrão, amplitudes e gráficos adequados. Explique por que a decisão entre utilizar a matriz de covariâncias ou a matriz de correlações pode alterar a ACP.
2. Realize duas análises:
 - ACP das variáveis centralizadas sem padronização;
 - ACP das variáveis centralizadas e padronizadas.

Utilize `prcomp()` apenas depois de identificar quais matrizes estão sendo decompostas em cada caso.

3. Para cada análise, obtenha:
 - autovalores;
 - proporções de variância;
 - proporções acumuladas;
 - coeficientes das componentes;
 - escores das observações.
4. Compare as duas soluções e identifique quais variáveis dominam as primeiras componentes quando os dados não são padronizados.
5. Para a ACP padronizada, examine o gráfico de declive e a proporção acumulada de variância. Proponha um número de componentes a manter e justifique a escolha.

6. Construa a reconstrução das observações utilizando apenas as componentes retidas. Para a ACP baseada nas variáveis padronizadas, calcule inicialmente o erro quadrático de reconstrução na própria escala padronizada utilizada para construir a solução. Identifique os estados com maior perda de representação e explique por que esses erros não devem ser interpretados diretamente nas unidades originais das quatro variáveis. Relacione a reconstrução à projeção ortogonal praticada em Exercício 7.24.
7. Interprete as duas primeiras componentes a partir dos coeficientes e das correlações variável-componente. Não trate automaticamente coeficientes elevados como equivalentes a correlações elevadas.
8. Faça um gráfico dos escores das duas primeiras componentes e descreva padrões de posição entre os estados sem transformar proximidade gráfica em evidência de agrupamentos populacionais.

Exercício 19.15 (Análise Fatorial com os dados `USJudgeRatings`). Utilize como variáveis ativas as onze avaliações de `INTG` a `RTEG` do conjunto `USJudgeRatings`. A variável `CONT`, que registra o número de contatos do advogado com o juiz, não deve participar da construção da estrutura fatorial.

1. Construa a matriz de correlações e examine:

- magnitude das correlações;
- determinante da matriz;
- autovalores.

Ao interpretar a matriz, retome a estrutura de covariâncias e correlações praticada em Exercício 12.1.

2. Calcule o teste de esfericidade de Bartlett a partir da matriz de correlações, do número de variáveis e do tamanho amostral. Informe a hipótese testada, a estatística, os graus de liberdade e o valor- p .
3. Calcule o KMO global por operações matriciais:
 - obtenha a inversa da matriz de correlações;
 - construa as correlações parciais;
 - utilize as somas dos quadrados das correlações e correlações parciais.

Interprete o resultado como medida de adequação à estrutura fatorial, sem tratá-lo como teste de existência de um modelo fatorial verdadeiro.

4. Examine o gráfico de declive dos autovalores da matriz de correlações como informação exploratória inicial. Em seguida, compare os ajustes por máxima verossimilhança com um, dois e três fatores. Não trate os autovalores da matriz de correlações original como se fossem automaticamente as raízes produzidas por todos os métodos de extração.

5. Ajuste modelos fatoriais por máxima verossimilhança com `factanal()` para os números de fatores admissíveis considerados, utilizando inicialmente `rotation = "none"`. Para cada solução:

- examine as unicidades;
- examine as cargas não rotacionadas;
- examine o teste de ajuste global quando disponível;
- construa a matriz reproduzida

$$\widehat{\mathbf{R}} = \widehat{\Phi}\widehat{\Phi}^\top + \widehat{\Psi}$$

e a matriz de resíduos

$$\mathbf{R} - \widehat{\mathbf{R}}.$$

Identifique os maiores resíduos em valor absoluto.

6. Escolha uma solução e aplique rotação Varimax. Compare as cargas antes e depois da rotação e verifique que a rotação ortogonal não altera as comunalidades nem a matriz de covariâncias comuns reproduzida.
7. Identifique as variáveis que mais caracterizam cada fator e proponha uma interpretação apenas quando o conjunto de cargas sustentar uma dimensão coerente.
8. Discuta se outra rotação, inclusive oblíqua, poderia ser plausível. Explique o que mudaria na interpretação se os fatores fossem autorizados a se correlacionar.

Exercício 19.16 (Agrupamentos com os dados `USArrests`). Utilize o conjunto `USArrests`.

1. Compare as escalas das quatro variáveis e execute a análise com os dados padronizados. Explique por que essa decisão é particularmente relevante em métodos baseados em distância euclidiana e relacione a discussão de métrica à geometria induzida praticada em Exercício 7.8.
2. Aplique K -médias para

$$K = 2, \dots, 6,$$

utilizando várias inicializações por meio do argumento `nstart`. Registre a dispersão intragrupos total de cada solução.

3. Construa o gráfico da dispersão intragrupos em função de K e identifique valores candidatos de K . Não faça ainda uma escolha definitiva apenas a partir desse gráfico.

4. Para pelo menos dois valores de K , repita o algoritmo com diferentes sementes e com `nstart = 1`. Investigue se diferentes inicializações produzem soluções distintas. Caso as soluções obtidas coincidam, explique por que essa coincidência não demonstra que o mínimo global foi encontrado.

5. Utilize `hclust()` com:

- ligação simples;
- ligação completa;
- ligação média;
- `ward.D2`.

Compare os dendrogramas e explique por que métodos diferentes podem produzir hierarquias diferentes sobre os mesmos dados.

6. Para os valores candidatos de K identificados no item 3, corte o dendrograma de Ward e compare as partições com as soluções das K -médias por meio de tabelas cruzadas de pertencas.
7. Utilize a silhueta, por meio do pacote `cluster`, para avaliar as soluções consideradas. Compare a silhueta média para diferentes números de grupos e, combinando esse resultado com o comportamento da dispersão intragrupos e a interpretação dos grupos, proponha um valor de K para a solução final.
8. Identifique observações cuja presença parece influenciar fortemente as soluções. Refaça, apenas como análise de sensibilidade, a solução após retirar uma dessas observações e descreva as alterações. Não utilize essa comparação como justificativa automática para excluir a observação da análise final.
9. Realize uma ACP das quatro variáveis padronizadas. Verifique que, quando todas as componentes são mantidas, as distâncias euclidianas entre as observações são preservadas pela transformação ortogonal. Em seguida, repita o agrupamento utilizando apenas as duas primeiras componentes e compare a solução com aquela obtida no espaço padronizado completo. Explique por que a redução de dimensão, ao contrário de uma transformação ortogonal completa, pode modificar o problema de agrupamento. Utilize, quando necessário, Exercício 7.24 e Exercício 7.26.

Exercício 19.17 (Análise de Correspondência com `HairEyeColor`). Utilize

```
tab <- apply(
  HairEyeColor,
  c(1, 2),
  sum
)
```

para obter uma tabela entre cor do cabelo e cor dos olhos, agregada sobre sexo.

1. Construa diretamente:
 - a matriz de frequências relativas $\mathbf{P}$;
 - as massas das linhas e colunas;
 - os perfis de linhas e colunas;
 - a matriz de desvios padronizados $\mathbf{Q}_{CA}$.
2. Calcule a estatística qui-quadrado de Pearson e a inércia total. Verifique numericamente

$$\chi^2 = n\mathcal{I}.$$

3. Aplique `svd()` a $\mathbf{Q}_{CA}$ e obtenha:

- valores singulares;
- inércias principais;
- proporções de inércia;
- proporções acumuladas.

Relacione a decomposição obtida à SVD e à aproximação truncada praticadas em Exercício 7.13 e Exercício 7.26.

4. Determine o número máximo de dimensões não triviais e proponha quantas dimensões utilizar na representação reduzida.
5. Construa as coordenadas padrão e principais das linhas e das colunas.
6. Verifique numericamente que as distâncias euclidianas entre coordenadas principais completas de uma mesma margem reproduzem as distâncias qui-quadrado entre os respectivos perfis.
7. Para as duas primeiras dimensões, calcule:
 - contribuições das categorias;
 - $\cos^2$;
 - qualidade de representação acumulada.

Identifique categorias importantes para construir cada dimensão e categorias bem representadas no plano.

8. Construa um mapa com as categorias de cabelo e olhos. Interprete:
 - posições dentro da nuvem de linhas;
 - posições dentro da nuvem de colunas;
 - associações sugeridas pela geometria conjunta.

Não interprete a distância euclidiana entre uma categoria de linha e uma categoria de coluna como uma distância qui-quadrado definida pela técnica.

Exercício 19.18 (MANOVA com os dados `iris`). Utilize `Species` como fator de grupos e as quatro medidas quantitativas de `iris` como vetor de respostas.

1. Determine:

- número de grupos;
- tamanho de cada grupo;
- dimensão do vetor resposta;
- vetores de médias amostrais;
- matrizes de covariâncias por grupo.

2. Ajuste o modelo multivariado

```
ajuste <- manova(  
  cbind(  
    Sepal.Length,  
    Sepal.Width,  
    Petal.Length,  
    Petal.Width  
  ) ~ Species,  
  data = iris  
)
```

3. Retome a construção das matrizes SQPC estudada no modelo linear multivariado do Módulo II, em particular Exercício 12.4. A partir do ajuste:

- obtenha a matriz residual e construa

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}};$$

- construa a SQPC total das respostas centralizadas;
- utilize a decomposição entre variação total, entre grupos e residual para obter $\mathbf{H}$;
- verifique numericamente que $\mathbf{E}$ é não singular.

Compare a função de $\mathbf{H}$ e $\mathbf{E}$ neste exercício com a SQPC de hipótese e a SQPC residual já estudadas no Módulo II.

4. Calcule as raízes características do problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e, a partir delas, obtenha manualmente: - lambda de Wilks; - traço de Pillai; - traço de Hotelling–Lawley; - maior raiz de Roy.

5. Compare os valores do item anterior com as saídas de `summary()` para os quatro testes.
6. Examine separadamente:
 - quais informações seriam necessárias no delineamento ou no processo de amostragem para justificar a independência entre unidades;
 - a plausibilidade de covariância residual comum;
 - a não singularidade da matriz residual;
 - a plausibilidade da normalidade multivariada dos erros por meio dos diagnósticos disponíveis.

Explique quais dessas condições podem ser investigadas a partir dos dados observados e quais dependem do modo como os dados foram obtidos. Não trate ausência de evidência gráfica contra uma hipótese como demonstração de que ela é verdadeira.

7. Depois do teste multivariado global, examine os testes univariados para cada resposta. Explique por que esses testes não reproduzem a MANOVA e por que uma estratégia de acompanhamento deve considerar multiplicidade e finalidade da análise.
8. Compare os quatro critérios quanto à conclusão global. Explique por que valores numéricos diferentes não significam que estejam testando hipóteses multivariadas distintas.

Exercício 19.19 (Análise Discriminante com os dados `iris`). Utilize as quatro variáveis quantitativas de `iris` para classificar `Species`.

1. Fixe uma semente e divida os dados de cada espécie em uma amostra de treinamento com aproximadamente 70% das observações e uma amostra de teste com as restantes. Preserve todas as espécies nos dois conjuntos.
2. Na amostra de treinamento, calcule:
 - vetores de médias por classe;
 - matrizes de covariâncias por classe;
 - matriz de covariâncias agrupada;
 - probabilidades *a priori* empíricas.

Relacione a estimação das matrizes de covariâncias ao que foi praticado em Exercício 12.3.

3. Ajuste uma LDA com `MASS::lda()` utilizando primeiro probabilidades *a priori* iguais. Examine:
 - coeficientes discriminantes;
 - número de direções;
 - proporções associadas às raízes discriminantes;
 - coordenadas discriminantes das observações de treinamento.

4. Utilize a regra para classificar as observações da amostra de teste. Construa a matriz de classificação e calcule:

- erro global;
- proporção de acertos por classe;
- tipos de erro mais frequentes.

5. Considere agora uma população-alvo hipotética na qual as proporções das três espécies sejam

$$\pi = \begin{bmatrix} 0,60 \\ 0,20 \\ 0,20 \end{bmatrix}.$$

Refaça a LDA utilizando essas probabilidades *a priori* e compare as funções discriminantes e as classificações com aquelas obtidas sob probabilidades iguais. Explique por que a alteração das probabilidades *a priori* modifica a regra de decisão mesmo quando as médias e a matriz de covariâncias permanecem inalteradas.

6. Ajuste também uma QDA com `MASS::qda()`. Compare sua matriz de classificação com a da LDA e relacione as diferenças à hipótese de covariância comum.

7. Calcule o erro aparente da LDA na amostra de treinamento e compare com o erro na amostra de teste. Explique por que o erro aparente pode ser otimista.

8. Na amostra de treinamento, utilize `MASS::lda(..., CV = TRUE)` para obter a classificação por validação cruzada *leave-one-out*. Calcule a taxa de erro correspondente e compare:

- erro aparente;
- erro por validação cruzada;
- erro na amostra de teste.

Explique por que essas três quantidades utilizam os dados de maneiras diferentes e não precisam coincidir.

9. Identifique observações mal classificadas e examine suas posições nas duas primeiras coordenadas discriminantes. Discuta se os erros ocorrem em regiões de sobreposição entre as classes.

10. Conclua indicando:

- qual regra apresentou melhor desempenho sob a divisão treinamento–teste e as probabilidades *a priori* adotadas;
- quais hipóteses, probabilidades *a priori*, critérios de avaliação e decisões metodológicas sustentam essa comparação;

- se as diferentes formas de estimar o erro conduzem à mesma conclusão;
- por que o desempenho observado neste exercício não deve ser tratado como propriedade populacional definitiva da regra.

Referências

ANDERSON, Theodore W. **An Introduction to Multivariate Statistical Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

ANDERSON, Theodore W.; RUBIN, Herman. Statistical Inference in Factor Analysis. *In*: Berkeley: University of California Press, 1956. Disponível em: <https://digitalassets.lib.berkeley.edu/math/ucb/text/math_s3_v5_article-10.pdf>. Acesso em: 3 ago. 2026

APOSTOL, Tom M. **Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability**. 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. **Métodos multivariados de análise estatística**. 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. **Measure, Integration & Real Analysis**. Cham: Springer, 2020. v. 282

BARTLETT, M. S. The Statistical Conception of Mental Factors. **British Journal of Psychology**, v. 28, p. 97–104, 1937.

BARTLETT, M. S. Tests of Significance in Factor Analysis. **British Journal of Psychology (Statistical Section)**, v. 3, p. 77–85, 1950.

BERGE}, {Jos M. F. }. {ten *et al.* [Some new results on correlation-preserving factor scores prediction methods](#). **Linear Algebra and Its Applications**, v. 289, n. 1-3, p. 311–318, 1 mar. 1999.

BOYD, Stephen; VANDENBERGHE, Lieven. **Convex Optimization**. Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury, 2002.

CHRISTENSEN, Ronald. **Plane Answers to Complex Questions: The Theory of Linear Models**. 4. ed. New York: Springer, 2011. p. 494

DEMME, James W. [Singular Value Decomposition](#). In: BAI, Zhaojun *et al.* (Orgs.). **Templates for the Solution of Algebraic Eigenvalue Problems: A Practical Guide**. Philadelphia: Society for Industrial; Applied Mathematics, 2000. p. 135–147.

DRISCOLL, Tobin A.; BRAUN, Richard J. [Fundamentals of Numerical Computation: Julia Edition](#). Philadelphia: Society for Industrial; Applied Mathematics, 2022. p. 614

EATON, Morris L. [Multivariate Statistics: A Vector Space Approach](#). Beachwood, OH: Institute of Mathematical Statistics, 2007. v. 53 p. 512

EVERITT, Brian S. *et al.* [Cluster Analysis](#). 5. ed. Chichester: John Wiley & Sons, 2011. p. 352

GOLUB, Gene H.; VAN LOAN, Charles F. [Matrix Computations](#). 4. ed. Baltimore: Johns Hopkins University Press, 2013.

GOWER, John C. [A General Coefficient of Similarity and Some of Its Properties](#). **Biometrics**, v. 27, n. 4, p. 857–871, 1971.

GREENACRE, Michael. [Correspondence Analysis in Practice](#). 3. ed. Boca Raton: CRC Press, 2017.

GRICE, James W. [Computing and Evaluating Factor Scores](#). **Psychological Methods**, v. 6, n. 4, p. 430–450, 2001.

GUPTA, Arjun K.; NAGAR, Daya K. [Matrix Variate Distributions](#). Boca Raton: Chapman & Hall/CRC, 1999.

HAIR, Jr., Joseph F. *et al.* [Multivariate Data Analysis](#). 8. ed. Andover: Cengage Learning, 2018.

HARVILLE, David A. [Matrix Algebra From a Statistician's Perspective](#). New York: Springer, 1997. p. 634

HENDRICKSON, Alan E.; WHITE, Paul Owen. [Promax: A Quick Method for Rotation to Oblique Simple Structure](#). **British Journal of Statistical Psychology**, v. 17, n. 1, p. 65–70, 1964.

HORN, Roger A.; JOHNSON, Charles R. [Topics in Matrix Analysis](#). Cambridge: Cambridge University Press, 1991.

HORN, Roger A.; JOHNSON, Charles R. [Matrix Analysis](#). 2. ed. Cambridge: Cambridge University Press, 2013.

- HUANG, Zhexue. [Extensions to the \$k\$ -Means Algorithm for Clustering Large Data Sets with Categorical Values](#). **Data Mining and Knowledge Discovery**, v. 2, n. 3, p. 283–304, 1998.
- HUBERTY, Carl J.; OLEJNIK, Stephen. [Applied MANOVA and Discriminant Analysis](#). 2. ed. Hoboken, NJ: John Wiley & Sons, 2006.
- JENNRICH, Robert I. [Admissible Values of Gamma in Direct Oblimin Rotation](#). **Psychometrika**, v. 44, n. 2, p. 173–177, 1979.
- JENNRICH, Robert I.; SAMPSON, P. F. [Rotation for Simple Loadings](#). **Psychometrika**, v. 31, p. 313–323, 1966.
- JOHNSON, Richard A.; WICHERN, Dean W. [Applied Multivariate Statistical Analysis](#). 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.
- JOLLIFFE, Ian T. [Principal Component Analysis](#). 2. ed. New York: Springer, 2002. p. 488
- KAISER, Henry F. [The Varimax Criterion for Analytic Rotation in Factor Analysis](#). **Psychometrika**, v. 23, n. 3, p. 187–200, 1958.
- KAUFMAN, Leonard; ROUSSEEUW, Peter J. [Finding Groups in Data: An Introduction to Cluster Analysis](#). New York: John Wiley & Sons, 1990.
- LAWLEY, D. N.; MAXWELL, A. E. [Factor Analysis as a Statistical Method](#). 2. ed. London: Butterworths, 1971.
- LÊ, Sébastien; JOSSE, Julie; HUSSON, François. [FactoMineR: A Package for Multivariate Analysis](#). **Journal of Statistical Software**, v. 25, n. 1, p. 1–18, 2008.
- LEBLAY, Thomas *et al.* **MEDA: Multivariate Exploratory Data Analysis with jamovi and FactoMineR**. Disponível em: <<https://sebastien-le.github.io/medasite/>>. Acesso em: 1 set. 2026.
- LEDOIT, Olivier; WOLF, Michael. [A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices](#). **Journal of Multivariate Analysis**, v. 88, n. 2, p. 365–411, 2004.
- MACQUEEN, James. Some Methods for Classification and Analysis of Multivariate Observations. *In*: Berkeley: University of California Press, 1967. Disponível em: <<https://projecteuclid.org/euclid.bsm/1200512992>>. Acesso em: 3 ago. 2026
- MAGNUS, Jan R.; NEUDECKER, Heinz. [Matrix Differential Calculus with Applications in Statistics and Econometrics](#). 3. ed. Chichester: John Wiley & Sons, 2019. p. 504

- MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. **Métodos Estatísticos Multivariados: Uma Introdução**. 4. ed. Porto Alegre: Bookman, 2019. p. 254
- MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. **Multivariate Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2024. p. 592
- MARONNA, Ricardo A. *et al.* **Robust Statistics: Theory and Methods (with R)**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464
- MEYER, Carl D. **Matrix Analysis and Applied Linear Algebra**. 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991
- MINGOTI, Sueli Aparecida. **Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada**. Belo Horizonte: Editora UFMG, 2005.
- MUIRHEAD, Robb J. **Aspects of Multivariate Statistical Theory**. New York: John Wiley & Sons, 1982.
- PILLAI, K. C. S. **Some New Test Criteria in Multivariate Analysis**. **The Annals of Mathematical Statistics**, v. 26, n. 1, p. 117–121, 1955.
- RAO, C. Radhakrishna. **Linear Statistical Inference and Its Applications**. 2. ed. New York: John Wiley & Sons, 1973.
- RENCER, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2012.
- RIPLEY, Brian D.; VENABLES, William N. **Modern Applied Statistics with S**. Fourth ed. New York: Springer, 2002.
- SEOL, Hyunsoo. **snowCluster: Multivariate Analysis**. Disponível em: <<https://github.com/hyunsooseol/snowCluster>>. Acesso em: 1 set. 2026.
- SIDI, Avram. **Vector Extrapolation Methods with Applications**. Philadelphia: Society for Industrial; Applied Mathematics, 2017. p. 381
- THE JAMOVİ PROJECT. **jamovi (Version 2.7) [Computer Software]**., 2026. Disponível em: <<https://www.jamovi.org>>. Acesso em: 1 set. 2026
- TIBSHIRANI, Robert; WALTHER, Guenther; HASTIE, Trevor. **Estimating the Number of Clusters in a Data Set via the Gap Statistic**. **Journal of the Royal Statistical Society: Series B (Statistical Methodology)**, v. 63, n. 2, p. 411–423, 2001.

VAART, A. W. van der. [Asymptotic Statistics](#). Cambridge: Cambridge University Press, 1998. p. 462

WARD, Jr., Joe H. [Hierarchical Grouping to Optimize an Objective Function](#). **Journal of the American Statistical Association**, v. 58, n. 301, p. 236–244, 1963.

WILKS, Samuel S. [Certain Generalizations in the Analysis of Variance](#). **Biometrika**, v. 24, n. 3–4, p. 471–494, 1932.