

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	22
Direitos Autorais e Uso da Obra	22
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	22
Prefácio	23
Identificação da Disciplina	25
EMENTA	25
OBJETIVO GERAL	25
OBJETIVOS ESPECÍFICOS	25
CONTEÚDO PROGRAMÁTICO	26
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	26
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	26
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	26
METODOLOGIA	27
AVALIAÇÃO	27
CRITÉRIOS DE AVALIAÇÃO	27
BIBLIOGRAFIA BÁSICA	28
BIBLIOGRAFIA COMPLEMENTAR	28
I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multi- variada	29
1 Vetores e representação dos dados multivariados	30
1.1 Escalares, vetores e matrizes	31
1.1.1 Vetor-coluna, vetor-linha e transposição	34
1.2 Natureza das variáveis e representação	35
1.3 O espaço $\mathbb{R}^p$	36
1.4 Representação matricial de um conjunto de dados	39
1.4.1 Espaço das observações e espaço das variáveis	41
1.5 Operações elementares com vetores	42
1.5.1 Soma e subtração	42
1.5.2 Multiplicação por escalar	43
1.5.3 Combinações lineares	45

1.6	Produto interno, norma, ângulo e distância euclidiana	47
1.6.1	Produto interno euclidiano	47
1.6.2	Norma euclidiana	48
1.6.3	Desigualdade de Cauchy–Schwarz	49
1.6.4	Ângulo entre vetores	52
1.6.5	Distância euclidiana	54
1.6.6	Desigualdade triangular	56
1.6.7	Produto externo	58
1.7	Síntese do capítulo	60
2	Álgebra matricial aplicada	62
2.1	Operações matriciais fundamentais	63
2.1.1	Soma e subtração de matrizes	63
2.1.2	Produto matriz-vetor	66
2.1.3	Produto entre matrizes	69
2.1.4	Propriedades do produto matricial	74
2.2	Transposição, simetria e traço	75
2.2.1	Transposição	75
2.2.2	Matrizes simétricas	77
2.2.3	Traço	81
2.3	Identidade, inversa, determinante, posto e sistemas lineares	84
2.3.1	Matriz identidade	85
2.3.2	Matriz inversa	86
2.3.3	Determinante	88
2.3.4	Interpretação geométrica do determinante	93
2.3.5	Posto	94
2.3.6	Sistemas lineares	97
2.3.7	Aprofundamento: pseudoinversa	101
2.4	Matrizes ortogonais, diagonais e triangulares	103
2.4.1	Matrizes ortogonais	103
2.4.2	Matrizes diagonais	106
2.4.3	Matrizes triangulares	108
2.4.4	Aprofundamento: sistemas triangulares	110
2.5	Formas bilineares, formas quadráticas e positividade	112
2.5.1	Formas bilineares	112
2.5.2	Formas quadráticas	116
2.5.3	Positividade	123
2.5.4	Superfícies de nível	128
2.6	Aprofundamento: matrizes particionadas e complemento de Schur	129
2.6.1	Matrizes particionadas	130
2.6.2	Soma e multiplicação por escalar	131
2.6.3	Transposição por blocos	132
2.6.4	Multiplicação por blocos	132

2.6.5	Complemento de Schur	134
2.6.6	Eliminação por blocos	135
2.6.7	Determinante de uma matriz particionada	137
2.6.8	Inversão em blocos	139
2.6.9	Positividade e complemento de Schur	140
2.7	Síntese do capítulo	142
3	Espaços vetoriais, bases e projeções	145
3.1	Espaços, subespaços e geração	146
3.1.1	Subespaços vetoriais	148
3.1.2	Subespaço gerado	150
3.2	Independência linear, bases e dimensão	153
3.2.1	Independência linear	153
3.2.2	Independência linear e posto	155
3.2.3	Bases	157
3.2.4	Coordenadas em uma base	158
3.2.5	Base canônica	160
3.2.6	Bases ortogonais e ortonormais	161
3.2.7	Dimensão	164
3.3	Espaços fundamentais de uma matriz	165
3.3.1	Espaço nulo	166
3.3.2	Espaço coluna	169
3.3.3	Espaço linha	171
3.3.4	Espaço nulo à esquerda	173
3.3.5	Extensão de uma base	175
3.3.6	Teorema Posto–Nulidade	176
3.3.7	Os quatro espaços fundamentais	180
3.3.8	Complemento ortogonal	180
3.3.9	Relações de ortogonalidade	181
3.4	Produtos internos, bases ortonormais e matrizes de Gram	184
3.4.1	Aprofundamento: produtos internos e geometrias induzidas	184
3.4.2	Matrizes de Gram	189
3.4.3	Propriedades da matriz de Gram	191
3.4.4	Matrizes de Gram e bases ortonormais	194
3.4.5	Produtos cruzados em uma matriz de dados	195
3.4.6	Propriedades do complemento ortogonal	196
3.4.7	Dimensão do complemento ortogonal	198
3.4.8	Decomposição ortogonal	202
3.4.9	Decomposição dos espaços fundamentais	205
3.5	Projeções ortogonais	206
3.5.1	Projeção sobre uma direção	207
3.5.2	Projeção sobre um subespaço com base ortonormal	210
3.5.3	Projeção sobre o espaço coluna de uma matriz	215

3.5.4	Propriedades da matriz de projeção	219
3.5.5	Aprofundamento: projeção residual e complemento ortogonal	223
3.5.6	Projeção como melhor aproximação	228
3.5.7	Aprofundamento: projeções e mínimos quadrados	231
3.6	Síntese do capítulo	236
4	Transformações lineares	239
4.1	Transformações lineares e representação matricial	240
4.1.1	Transformação determinada por uma base	242
4.1.2	Representação matricial nas bases canônicas	244
4.1.3	Núcleo e imagem de uma transformação linear	246
4.1.4	Imagem de um subespaço	248
4.2	Transformação de vetores e matrizes de dados	249
4.2.1	Novas variáveis como combinações lineares	251
4.2.2	Dimensão da configuração transformada	253
4.2.3	Efeito sobre diferenças e produtos internos	256
4.2.4	Transformação das matrizes de produtos internos	258
4.3	Composição, invertibilidade e perda de informação	259
4.3.1	Composição de transformações lineares	259
4.3.2	A ordem das transformações	261
4.3.3	Transformação inversa	263
4.3.4	Injetividade, sobrejetividade e bijetividade	265
4.3.5	Perda de informação	270
4.3.6	Redução de dimensionalidade	271
4.3.7	Transformações singulares	272
4.4	Transformações geométricas	273
4.4.1	Rotação	274
4.4.2	Reflexão	275
4.4.3	Escalonamento	277
4.4.4	Cisalhamento	278
4.4.5	Projeção	280
4.4.6	Comparação geométrica	281
4.4.7	Determinante, volume e orientação	282
4.5	Transformações ortogonais	284
4.5.1	Transformação de uma matriz de dados	286
4.5.2	Determinante e orientação	287
4.5.3	Matrizes ortogonais e bases ortonormais	288
4.5.4	Comparação com transformações não ortogonais	289
4.6	Mudanças de coordenadas e representação em bases	290
4.6.1	Conversão entre duas bases	292
4.6.2	Representação de uma transformação em bases gerais	293
4.6.3	Representação de um operador em uma nova base	296
4.6.4	Transformação ativa e mudança passiva	298

4.6.5	Mudança de coordenadas de uma matriz de dados	300
4.7	Transformações afins e pré-processamento	301
4.7.1	Translação	302
4.7.2	Transformação afim de uma matriz de dados	303
4.7.3	Centralização	304
4.7.4	Escalonamento das variáveis	307
4.7.5	Padronização	308
4.7.6	Ordem entre centralização e escalonamento	309
4.7.7	Composição e inversão de transformações afins	310
4.7.8	Comparação das operações de pré-processamento	311
4.8	Síntese do capítulo	312
5	Autovalores, autovetores e decomposição espectral	320
5.1	Direções invariantes, autovalores e autoespaços	321
5.2	Equação característica, multiplicidades e diagonalização	330
5.2.1	Determinação dos autovalores e autoespaços	332
5.2.2	Autovalores complexos de matrizes reais	334
5.2.3	Independência entre autovetores	335
5.2.4	Multiplicidades algébrica e geométrica	336
5.2.5	Diagonalização	342
5.2.6	Potências de uma matriz diagonalizável	345
5.3	Matrizes simétricas e decomposição espectral	346
5.3.1	Decomposição espectral do exemplo condutor	351
5.3.2	Forma aditiva da decomposição espectral	353
5.3.3	Projetores sobre autoespaços	354
5.3.4	Não unicidade da matriz de autovetores	356
5.4	Consequências da decomposição espectral	357
5.4.1	Traço, determinante, posto e invertibilidade	358
5.4.2	Formas quadráticas em coordenadas espectrais	362
5.4.3	Superfícies de nível em coordenadas espectrais	367
5.5	Quociente de Rayleigh	370
5.5.1	Representação espectral	371
5.5.2	Formulação com restrição de norma	377
5.5.3	Multiplicadores de Lagrange	378
5.5.4	Direções sucessivas	383
5.6	Funções espectrais de matrizes	387
5.6.1	Ação sobre os autoespaços	388
5.6.2	Potências inteiras	389
5.6.3	Inversa espectral	391
5.6.4	Raiz quadrada principal	392
5.6.5	Raiz quadrada inversa	393
5.6.6	Pseudoinversa espectral	394
5.6.7	Exponencial e logaritmo matriciais	396

5.7	Aprofundamento: autovalores generalizados	397
5.7.1	Quociente de Rayleigh generalizado	400
5.7.2	Redução a um problema espectral ordinário	403
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	406
5.7.4	Diagonalização simultânea por congruência	409
5.8	Síntese do capítulo	414
6	Decomposição em Valores Singulares	421
6.1	Definição e formas da Decomposição em Valores Singulares	422
6.1.1	Vetores singulares	426
6.1.2	Interpretação como composição de transformações	428
6.1.3	SVD completa	429
6.1.4	SVD compacta	430
6.1.5	SVD compacta e SVD truncada	431
6.1.6	Aprofundamento: não unicidade dos vetores singulares	437
6.2	Construção da SVD e relação com a decomposição espectral	439
6.2.1	Propriedades das matrizes de Gram associadas	440
6.2.2	Construção dos pares singulares	444
6.2.3	Construção da SVD compacta	450
6.2.4	Decomposições espectrais associadas	454
6.2.5	Exemplo de construção da SVD	456
6.2.6	Relação com a decomposição espectral de matrizes simétricas	459
6.2.7	Aprofundamento: SVD de matrizes simétricas indefinidas	459
6.3	Interpretação geométrica da SVD	461
6.3.1	Imagem da bola unitária	462
6.3.2	Alteração dos comprimentos	467
6.3.3	Exemplo geométrico no plano	471
6.3.4	Transformações com núcleo não trivial	472
6.4	Espaços fundamentais, posto e normas	474
6.4.1	Espaço coluna e espaço linha	475
6.4.2	Projetores ortogonais	480
6.4.3	Posto e nulidades	483
6.4.4	Produto interno de Frobenius	485
6.4.5	Normas e valores singulares	486
6.4.6	Invariância ortogonal	489
6.4.7	Determinante e invertibilidade	490
6.4.8	Aprofundamento: condicionamento e posto numérico	491
6.5	SVD de uma matriz de dados	497
6.5.1	Dualidade entre observações e variáveis	498
6.5.2	Coordenadas das observações nas direções singulares à direita	500
6.5.3	Coordenadas das variáveis nas direções singulares à esquerda	501
6.5.4	Matrizes de Gram da matriz de dados	502
6.5.5	Representação exata das observações	503

6.5.6	Centralização da matriz de dados	506
6.5.7	Antecipação: relação com a matriz de covariâncias amostral	507
6.5.8	Magnitude quadrática da matriz centralizada	509
6.5.9	Representação exata e aproximação	512
6.6	Forma expandida e aproximações de posto reduzido	513
6.6.1	Ortogonalidade dos componentes singulares	516
6.6.2	SVD truncada na forma expandida	517
6.6.3	Erros produzidos pelo truncamento	518
6.6.4	Teorema de Eckart–Young–Mirsky	523
6.6.5	Aprofundamento: demonstração e unicidade da melhor aproximação . .	524
6.6.6	Exemplo de aproximação de posto 1	528
6.6.7	Aproximação de uma matriz de dados	530
6.7	Pseudoinversa e soluções de mínimos quadrados	534
6.7.1	Relação com a pseudoinversa espectral	536
6.7.2	Aprofundamento: caracterização de Moore–Penrose	537
6.7.3	Pseudoinversa e projetores	540
6.7.4	Sistemas lineares compatíveis	542
6.7.5	Mínimos quadrados	546
6.7.6	Expressão da solução nas direções singulares	552
6.7.7	Aprofundamento: instabilidade e pseudoinversa truncada	553
6.7.8	Exemplo com o sistema condutor	555
6.8	Síntese do capítulo	558
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	566
7.1	Funções, variações e diferenciais	566
7.1.1	Tipos de funções	566
7.1.2	Convenções de derivação	569
7.1.3	Variação de uma função	570
7.1.4	Diferencial	572
7.1.5	Aproximação ao longo de uma direção	574
7.1.6	Diferenciabilidade de funções vetoriais	574
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	577
7.2.1	Gradiente e derivada direcional	577
7.2.2	Gradiente e conjuntos de nível	579
7.2.3	Jacobiana	581
7.2.4	Regra da cadeia	584
7.2.5	Hessiana	586
7.3	Aproximações de Taylor e classificação local	589
7.3.1	Aproximação de Taylor de primeira ordem	589
7.3.2	Aproximação de Taylor de segunda ordem	590
7.3.3	Pontos estacionários	592
7.3.4	Classificação pela Hessiana	593
7.3.5	Caso inconclusivo	598

7.4	Convexidade e concavidade	599
7.4.1	Conjuntos convexos	599
7.4.2	Funções convexas	600
7.4.3	Caracterização de primeira ordem	600
7.4.4	Caracterização pela Hessiana	601
7.4.5	Consequências para otimização	604
7.4.6	Funções quadráticas	605
7.5	Otimização sem restrições	607
7.5.1	Método de Newton	607
7.6	Otimização com restrições de igualdade	611
7.6.1	Multiplicadores de Lagrange	613
7.6.2	Relação com problemas de autovalores	618
7.6.3	Restrições lineares	619
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	621
7.7.1	Formas lineares e bilineares	621
7.7.2	Derivadas de formas quadráticas	622
7.7.3	Derivadas da norma euclidiana	625
7.7.4	Funções de resíduos lineares	626
7.7.5	Equações normais	627
7.7.6	Mínimos quadrados ponderados	630
7.7.7	Funções compostas de resíduos	632
7.7.8	Mínimos quadrados não lineares	633
7.8	Diferenciais matriciais e cálculo por traços	635
7.8.1	Regras básicas do diferencial matricial	636
7.8.2	Identicidades de traço	637
7.8.3	Função linear de uma matriz	638
7.8.4	Derivadas da norma de Frobenius	639
7.8.5	Funções quadráticas de uma matriz	640
7.8.6	Funções matriciais de resíduos	642
7.8.7	Ponderação de observações e respostas	647
7.9	Derivadas de inversas, determinantes e log-determinantes	649
7.9.1	Diferencial da matriz inversa	649
7.9.2	Diferencial do determinante	651
7.9.3	Diferencial do log-determinante	653
7.9.4	Segunda variação do log-determinante	654
7.9.5	Traço envolvendo uma matriz inversa	656
7.9.6	Forma quadrática com matriz inversa	657
7.9.7	Crítério com log-determinante e traço	658
7.9.8	Parâmetros matriciais simétricos	662
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	663
7.10.1	Operador de vetorização	663
7.10.2	Produto de Kronecker	665
7.10.3	Identidade de vetorização	666

7.10.4	Aprofundamento: derivadas vetorizadas e parâmetros matriciais	668
7.11	Integração múltipla e mudança de variáveis	680
7.11.1	Integrais múltiplas	680
7.11.2	Teoremas de Tonelli e Fubini	682
7.11.3	Densidades multivariadas	683
7.11.4	Distribuições marginais	684
7.11.5	Esperanças de funções escalares, vetoriais e matriciais	686
7.11.6	Mudança de variáveis	687
7.11.7	Transformação de densidades	689
7.11.8	Transformações afins	690
7.11.9	Interpretação geométrica do determinante Jacobiano	692
7.11.10	Coordenadas polares	693
7.11.11	Transformações elipsoidais	694
7.11.12	Aprofundamento: diferenciação sob o sinal de integração	695
7.12	Aprofundamento: aplicações à estimação e à inferência	703
7.12.1	Log-verossimilhança e vetor escore	703
7.12.2	Informação observada e informação de Fisher	704
7.12.3	Newton–Raphson	706
7.12.4	Método do escore de Fisher	707
7.12.5	Expansão local de uma raiz do escore	709
7.12.6	Método delta	710
7.13	Síntese do capítulo	716
Exercícios de fixação do Módulo I		719
Parte I — Exercícios sem uso de computador		719
Parte II — Exercícios com uso do R		735
 II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Mul-		
tivariada		745
8	Matrizes de covariâncias e correlações	746
8.1	Momentos, centralização e covariância	747
8.1.1	Vetor de médias e centralização	747
8.1.2	Momentos de segunda ordem	748
8.1.3	Covariância entre duas variáveis	750
8.2	Matriz de covariâncias populacional	755
8.2.1	Definição e interpretação dos elementos	755
8.2.2	Variâncias e covariâncias de combinações lineares	756
8.2.3	Propriedades estruturais e singularidade	759
8.3	Covariâncias entre vetores e transformações	765
8.3.1	Covariâncias cruzadas e vetores particionados	765
8.3.2	Transformações afins da média e da covariância	772

8.4	Padronização e matriz de correlações	776
8.4.1	Matriz de correlações populacional	776
8.4.2	Propriedades, escala e independência	781
8.5	Geometria e medidas globais da dispersão	787
8.5.1	Eixos espectrais e elipsoide de covariância	787
8.5.2	Variância total, variância generalizada e volume	795
8.6	Distância de Mahalanobis	801
8.6.1	Interpretação geométrica e espectral	802
8.6.2	Branqueamento e esferização	805
8.7	Representação descritiva a partir dos dados	810
8.7.1	Centralização, SQPC e matriz de covariâncias observada	810
8.7.2	Matriz de correlações e covariâncias cruzadas observadas	814
8.8	Decomposição da dispersão por grupos	820
8.8.1	Dispersão total, intragrupos e entre grupos	822
8.8.2	Somas de quadrados e traço das matrizes de dispersão	828
8.8.3	Esperança das matrizes de dispersão por grupos	831
8.8.4	Propriedades e limites de posto	836
8.9	Síntese do capítulo	840
9	Distribuição Normal Multivariada	846
9.1	Definição e construção	847
9.1.1	Definição por combinações lineares	847
9.1.2	Construção afim a partir do vetor normal padrão	849
9.1.3	Determinação pelos parâmetros	852
9.2	Densidade da normal multivariada	855
9.2.1	Função densidade e log-densidade	855
9.2.2	Superfícies de igual densidade	858
9.3	Transformações e distribuições marginais	860
9.3.1	Fechamento sob transformações afins	860
9.3.2	Combinações lineares	862
9.3.3	Distribuições marginais	864
9.3.4	Padronização marginal e branqueamento	866
9.4	Independência e distribuições condicionais	868
9.4.1	Independência entre blocos conjuntamente normais	868
9.4.2	Distribuição condicional	872
9.4.3	Média e covariância condicionais	876
9.4.4	Caso bivariado	878
9.5	Distância de Mahalanobis e regiões de probabilidade	881
9.5.1	Distribuição qui-quadrado	882
9.5.2	Regiões elipsoidais de probabilidade	884
9.5.3	Avaliação de uma observação fixa	885
9.6	Comparação entre distribuições normais	888
9.6.1	Médias distintas e covariância comum	888

9.6.2	Covariâncias distintas	889
9.7	Alcance da hipótese de normalidade	890
9.7.1	Resultados que não exigem normalidade	891
9.7.2	Resultados específicos da família normal	892
9.7.3	Passagem do modelo populacional para a inferência	894
9.8	Aprofundamento: Normal Singular	894
9.9	Síntese do capítulo	904
10	Estatísticas Amostrais e Estimação	906
10.1	Da população à amostra	907
10.1.1	Amostra aleatória multivariada	908
10.1.2	Matriz aleatória da amostra e matriz observada	910
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	911
10.2	Propriedades dos estimadores multivariados	914
10.2.1	Viés e variabilidade	915
10.2.2	Erro quadrático médio e funções de perda	916
10.2.3	Consistência	918
10.2.4	Eficiência	919
10.2.5	Suficiência	920
10.2.6	Equivariância	924
10.3	Métodos de estimação	927
10.3.1	Método dos momentos	927
10.3.2	Verossimilhança e máxima verossimilhança	930
10.3.3	Invariância da máxima verossimilhança	939
10.4	Estimação do vetor de médias	941
10.4.1	Vetor de médias amostrais	942
10.4.2	Não viesamento, variabilidade e erro quadrático médio	944
10.4.3	Combinações lineares	946
10.4.4	Consistência e equivariância	948
10.4.5	Variabilidade entre amostras	950
10.5	SQPC e estimação da matriz de covariâncias	950
10.5.1	SQPC como estatística aleatória	952
10.5.2	Decomposição em torno de um centro arbitrário	953
10.5.3	Esperança da SQPC	954
10.5.4	Estimador não viesado da matriz de covariâncias	956
10.5.5	Estimador com divisor n : momentos e máxima verossimilhança	958
10.5.6	Consistência dos estimadores de covariância	961
10.5.7	Transformações, posto e singularidade	963
10.6	Estimação de covariâncias cruzadas e correlações	966
10.6.1	Covariâncias cruzadas entre blocos	966
10.6.2	Matriz de correlações amostral	972
10.6.3	Propriedades estruturais	973
10.6.4	Transformações de localização e escala	977

10.7	Aprofundamento: dimensão, estabilidade e extensões da estimação	980
10.7.1	Relação entre p e n	980
10.7.2	Condicionamento e inversão	982
10.7.3	Regularização	984
10.7.4	Pseudoinversa e regularização	988
10.7.5	Sensibilidade e robustez	990
10.8	Exemplo integrado	991
10.9	Síntese do capítulo	999
11	Modelo Linear Multivariado e Hipóteses Lineares	1003
11.1	Formulação do modelo linear multivariado	1004
11.1.1	Resposta vetorial e matriz de respostas	1004
11.1.2	Estrutura matricial do modelo	1007
11.1.3	Estrutura de médias e covariâncias residuais	1008
11.1.4	Forma vetorizada	1009
11.1.5	Distribuição normal matricial	1010
11.1.6	Transformações da resposta	1013
11.2	Estimação da matriz de parâmetros	1014
11.2.1	Mínimos quadrados	1014
11.2.2	Estimador sob posto completo	1015
11.2.3	Esperança e matriz de covariâncias	1017
11.2.4	Relação com máxima verossimilhança	1019
11.2.5	Modelo contendo somente intercepto	1020
11.3	Valores ajustados, resíduos e projeções	1021
11.3.1	Valores ajustados e resíduos	1023
11.3.2	Ortogonalidade	1024
11.3.3	Esperança dos valores ajustados e dos resíduos	1025
11.3.4	Covariâncias dos valores ajustados e dos resíduos	1025
11.3.5	Representação dos ajustes e resíduos	1027
11.3.6	Conexão com o modelo contendo somente intercepto	1027
11.4	SQPC residual e estimação da covariância	1028
11.4.1	Construção da SQPC residual	1029
11.4.2	Esperança e graus de liberdade	1031
11.4.3	Estimação da covariância residual	1034
11.4.4	Estimador de máxima verossimilhança	1036
11.4.5	Posto e singularidade	1037
11.4.6	Modelo contendo somente intercepto	1039
11.5	Decomposição da variação multivariada	1041
11.5.1	SQPC total	1041
11.5.2	SQPC associada ao modelo	1042
11.5.3	Decomposição entre modelo e resíduo	1044
11.5.4	Combinações lineares das respostas	1046
11.5.5	Modelos sem intercepto	1047

11.5.6	Modelo de grupos como caso particular	1048
11.6	Posto, parametrização e estimabilidade	1051
11.6.1	Delineamento com posto deficiente	1051
11.6.2	Pseudoinversa e unicidade do ajuste	1052
11.6.3	Funções estimáveis	1053
11.6.4	Estimador de uma função estimável	1056
11.6.5	Parametrizações equivalentes	1056
11.7	Hipóteses lineares multivariadas	1057
11.7.1	Combinações dos termos do modelo	1057
11.7.2	Combinações das respostas	1059
11.7.3	Hipótese linear geral	1060
11.7.4	Estimabilidade da hipótese	1061
11.7.5	SQPC da hipótese	1062
11.7.6	Modelos encaixados	1065
11.7.7	Casos particulares	1067
11.8	Exemplo integrado	1069
11.9	Síntese do capítulo	1078
12	Inferência Multivariada	1083
12.1	Distribuições amostrais exatas e assintóticas	1084
12.1.1	Distribuição da média amostral sob normalidade	1084
12.1.2	Teorema Central do Limite multivariado	1087
12.2	Distribuição de Wishart	1089
12.2.1	Construção e parametrização	1090
12.2.2	Suporte, posto e definição positiva	1092
12.2.3	Momentos	1093
12.2.4	Formas quadráticas	1095
12.2.5	Aditividade	1096
12.2.6	Transformações lineares	1096
12.2.7	Aprofundamento: densidade da distribuição de Wishart	1098
12.2.8	Distribuição da SQPC e da covariância amostral	1099
12.2.9	Independência entre média e covariância	1105
12.3	Distribuições no modelo linear multivariado	1107
12.3.1	Distribuição do estimador da matriz de parâmetros	1108
12.3.2	Distribuição de funções estimáveis	1110
12.3.3	Distribuição da SQPC residual	1111
12.3.4	Independência entre estimação e SQPC residual	1114
12.3.5	Distribuição da SQPC da hipótese sob H_0	1116
12.4	Princípios da inferência multivariada	1120
12.4.1	Testes globais e hipóteses simultâneas	1121
12.4.2	Razão de verossimilhanças	1122
12.4.3	Resultado assintótico de Wilks	1124
12.4.4	Razão de verossimilhanças em modelos normais encaixados	1126

12.5	Inferência sobre um vetor de médias	1129
12.5.1	Covariância conhecida	1130
12.5.2	Estatística T^2 de Hotelling	1132
12.5.3	Relações com os casos assintótico e univariado	1135
12.5.4	Região de confiança elipsoidal	1136
12.5.5	Geometria da região	1137
12.5.6	Intervalos simultâneos	1138
12.5.7	Hipóteses lineares sobre o vetor de médias	1140
12.5.8	Relação com o modelo linear multivariado	1144
12.6	Comparação entre dois vetores de médias	1145
12.6.1	Duas amostras independentes	1146
12.6.2	Covariâncias populacionais distintas	1154
12.6.3	Observações pareadas	1155
12.7	Condições e limites da inferência clássica	1159
12.7.1	Independência, normalidade e covariância comum	1159
12.7.2	Posto, dimensão e tamanho amostral	1162
12.7.3	Aprofundamento: alta dimensão e robustez	1166
12.8	Síntese do Módulo 2	1168
12.8.1	Passagem para o Módulo 3	1170
Exercícios de fixação do Módulo II		1172
Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador		1173
Parte II — Exercícios com uso do R		1183
 III Módulo III — Formulação Matemática e Estatística das Técnicas Multi-variadas		 1188
13 Problemas e estruturas das técnicas multivariadas		1189
13.1	Do problema estatístico à técnica multivariada	1190
13.2	Classes de problemas multivariados	1192
13.2.1	Redução de dimensionalidade	1192
13.2.2	Representação de estruturas latentes	1192
13.2.3	Formação de grupos	1193
13.2.4	Representação de associações em tabelas de contingência	1193
13.2.5	Teste conjunto de hipóteses sobre várias respostas	1193
13.2.6	Discriminação e classificação	1194
13.3	Diferentes formas de classificar as técnicas	1194
13.3.1	Interdependência e dependência	1194
13.3.2	Exploratórias, descritivas, preditivas e inferenciais	1194
13.3.3	Supervisionadas e não supervisionadas	1195

13.4	Estruturas matemáticas recorrentes	1196
13.4.1	Combinações lineares e projeções	1196
13.4.2	Formas quadráticas e problemas espectrais	1197
13.4.3	Otimização sob restrições e critérios de ajuste	1197
13.4.4	SVD e representações de baixa dimensão	1198
13.4.5	Distâncias e métricas	1198
13.4.6	Modelos lineares e probabilísticos	1199
13.5	Mesmas estruturas, diferentes interpretações	1200
13.6	Relações entre as técnicas	1202
13.7	Síntese	1203
14	Formulação da Análise de Componentes Principais	1204
14.1	O problema de redução de dimensionalidade	1204
14.2	Componentes principais como combinações lineares	1207
14.3	Primeira componente principal	1208
14.4	Componentes principais sucessivas	1209
14.5	Formulação espectral	1212
14.6	Variância total e proporção de variância	1213
14.7	Subespaço principal, projeção e reconstrução	1217
14.8	Formulação amostral	1218
14.9	Formulação da ACP pela SVD	1221
14.10	ACP baseada na matriz de correlações	1223
14.11	Formulação descritiva, populacional e inferencial	1226
14.12	Limites da representação por componentes principais	1228
14.13	Aprofundamentos teóricos	1229
14.13.1	Formulação do subespaço principal e variabilidade máxima	1229
14.13.2	Reconstrução e erro quadrático	1235
14.13.3	Geometria da qualidade de representação	1239
14.13.4	Aproximação de posto reduzido	1243
14.13.5	Propriedades da solução	1246
14.13.6	Estimação e inferência das componentes sob normalidade	1250
14.14	Aprofundamentos metodológicos e aplicados	1252
14.14.1	Escolha do número de componentes	1252
14.14.2	Coeficientes e relação das variáveis com as componentes	1254
14.14.3	Representação das observações e das variáveis	1258
14.14.4	Elementos ativos e suplementares na ACP	1263
14.14.5	Correspondência com a implementação utilizada	1265
14.15	Síntese	1267
15	Formulação da Análise Fatorial	1269
15.1	O problema da estrutura latente	1269
15.2	Formulação do modelo de fatores comuns	1270
15.3	Hipóteses do modelo ortogonal	1274

15.4	Estrutura da matriz de covariâncias	1275
15.4.1	Covariâncias entre variáveis	1277
15.4.2	Variâncias das variáveis	1278
15.5	Comunalidades e especificidades	1278
15.6	Cargas fatoriais e associação com os fatores	1281
15.7	Geometria das cargas fatoriais	1283
15.8	Estrutura comum de covariâncias	1285
15.9	Identificação do modelo fatorial	1287
15.9.1	Escala dos fatores	1288
15.9.2	Indeterminação do sinal	1288
15.9.3	Indeterminação rotacional	1289
15.10	Rotação dos eixos fatoriais	1289
15.10.1	Rotações ortogonais	1290
15.10.2	Rotações oblíquas	1290
15.11	Formulação populacional e amostral	1293
15.11.1	O problema de estimação	1293
15.11.2	Escores fatoriais	1294
15.12	Pressupostos e limites do modelo	1295
15.12.1	Número de fatores	1297
15.12.2	Dependência do conjunto e da escala das variáveis	1297
15.12.3	Papel da normalidade	1297
15.13	Análise Fatorial e Análise de Componentes Principais	1298
15.14	Aprofundamentos teóricos	1300
15.14.1	Contagem de parâmetros e identificação	1300
15.14.2	Invariâncias da rotação ortogonal	1304
15.14.3	Critérios de rotação como problemas de otimização	1305
15.14.4	Fatores principais e mínimos resíduos	1308
15.14.5	Formulação probabilística normal	1313
15.14.6	Distribuições associadas à avaliação da matriz de correlações	1317
15.14.7	Distribuição condicional dos fatores e escore por regressão	1319
15.14.8	Critérios e propriedades dos métodos de escores fatoriais	1321
15.15	Aprofundamentos metodológicos e aplicados	1323
15.15.1	Adequação da matriz de correlações à Análise Fatorial	1324
15.15.2	Escolha do número de fatores	1329
15.15.3	Matriz reproduzida e resíduos	1330
15.15.4	Critérios específicos de rotação	1333
15.15.5	Diferentes métodos de escores fatoriais	1335
15.15.6	Correspondência com a implementação utilizada	1336
15.16	Síntese	1338
16	Formulação da Análise de Agrupamentos	1340
16.1	O problema de formação de grupos	1341
16.2	Representação dos objetos e proximidade	1341

16.3	Dissimilaridades entre objetos	1342
16.3.1	Efeito da escala	1344
16.4	Partições	1345
16.4.1	Outras formas de pertinência	1346
16.5	Homogeneidade interna e separação	1347
16.6	Agrupamento por centroides	1347
16.6.1	Dispersão dentro e entre grupos	1348
16.6.2	Formulação das K -médias	1349
16.6.3	Partição para centros fixados	1352
16.6.4	Geometria das regiões de alocação	1352
16.7	Estrutura dos métodos hierárquicos	1355
16.7.1	Ligações simples, completa e média	1357
16.7.2	Método de Ward e dispersão intragrupos	1359
16.7.3	Dendrograma e níveis de fusão	1361
16.7.4	Uma partição e uma hierarquia representam objetos diferentes	1361
16.8	Diferentes definições matemáticas de grupo	1362
16.9	Dependência da solução e limites da formulação	1365
16.10	Limites da interpretação dos grupos	1366
16.11	Relações com outras técnicas multivariadas	1366
16.11.1	Agrupamentos e ACP	1367
16.11.2	Agrupamentos e Análise Discriminante	1367
16.11.3	Agrupamentos e MANOVA	1368
16.12	Aprofundamentos teóricos	1368
16.12.1	O centroide como minimizador	1368
16.12.2	Existência e não unicidade da solução	1369
16.12.3	Algoritmo alternante das K -médias e redução do critério	1370
16.12.4	Transformações que preservam a solução das K -médias	1371
16.12.5	Derivação do incremento de Ward	1372
16.12.6	Empates e não unicidade da hierarquia	1375
16.12.7	Modelos de mistura como definição probabilística de grupos	1375
16.13	Aprofundamentos metodológicos e aplicados	1377
16.13.1	Preparação da representação para o agrupamento	1377
16.13.2	Dados mistos e dissimilaridade de Gower	1379
16.13.3	Escolha da medida de proximidade e do procedimento	1380
16.13.4	Escolha do número de grupos	1382
16.13.5	Inicialização e comparação entre execuções	1385
16.13.6	Estabilidade, validação e perfil dos grupos	1386
16.13.7	Correspondência com a implementação utilizada	1389
16.14	Síntese	1391
17	Formulação da Análise de Correspondência	1393
17.1	O problema de associação em uma tabela de contingência	1394

17.2	Massas e perfis	1395
17.2.1	Distribuições condicionais observadas	1397
17.2.2	Independência como referência	1399
17.3	Geometria dos perfis	1400
17.4	Inércia e afastamento da independência	1402
17.5	Padronização dos desvios da independência	1404
17.5.1	Inércia como norma matricial	1405
17.6	Relação algébrica com a estatística de Pearson	1406
17.7	Formulação pela decomposição em valores singulares	1407
17.7.1	Decomposição da inércia	1408
17.7.2	Representação em dimensão reduzida	1410
17.8	Coordenadas da Análise de Correspondência	1412
17.8.1	Sistema de coordenadas padrão	1412
17.8.2	Sistema de coordenadas principais	1413
17.8.3	Distâncias entre perfis e coordenadas principais	1415
17.9	Representação conjunta de linhas e colunas	1416
17.9.1	O significado das proximidades	1416
17.10	Formulação descritiva e relação com a inferência	1417
17.11	Relação com a Análise de Componentes Principais	1423
17.12	Condições e limites da representação	1424
17.12.1	Massas positivas e frequências nulas	1424
17.12.2	Composição da tabela e generalização	1425
17.12.3	Dimensão da representação	1425
17.12.4	Sinais e orientação	1425
17.12.5	Limites da interpretação	1426
17.13	Aprofundamentos teóricos	1426
17.13.1	Limite do posto da matriz de desvios padronizados	1426
17.13.2	Não unicidade dos eixos e dos subespaços representados	1428
17.13.3	Centralização ponderada das coordenadas padrão e principais	1429
17.13.4	Reconstrução dos desvios da independência	1429
17.13.5	Decomposição da estatística de Pearson pelas dimensões	1431
17.13.6	Formulação probabilística e teste de independência	1431
17.14	Aprofundamentos metodológicos e aplicados	1433
17.14.1	Definição da tabela e exame das categorias	1434
17.14.2	Relação com o teste global de independência	1434
17.14.3	Escolha do número de dimensões	1434
17.14.4	Leitura da representação reduzida	1435
17.14.5	Sensibilidade e validação da interpretação	1437
17.14.6	Análise de Correspondência Múltipla	1437
17.14.7	Correspondência com a implementação utilizada	1437
17.15	Síntese	1438

18	Formulação da MANOVA	1441
18.1	O problema de comparação multivariada	1442
18.2	A hipótese no modelo linear multivariado	1443
18.2.1	SQPC da hipótese e SQPC residual	1444
18.3	Hipótese e erro em uma combinação linear das respostas	1446
18.4	Problema espectral da MANOVA	1447
18.4.1	Padronização pela SQPC residual e interpretação geométrica	1449
18.5	Critérios multivariados	1453
18.6	Quatro critérios como funções das raízes características	1457
18.6.1	Uso inferencial dos critérios	1458
18.7	Pressupostos e limites	1459
18.7.1	Estrutura da média e estimabilidade	1459
18.7.2	Independência entre unidades	1460
18.7.3	Covariância residual comum	1460
18.7.4	Não singularidade populacional e amostral	1460
18.7.5	Normalidade multivariada	1462
18.7.6	Associação residual, condicionamento e singularidade	1463
18.8	Relações com outras técnicas	1463
18.8.1	ANOVA	1463
18.8.2	T^2 de Hotelling	1464
18.8.3	Regressão multivariada	1465
18.8.4	Análise Discriminante	1465
18.9	Aprofundamentos teóricos	1466
18.9.1	Distribuições Wishart de hipótese e erro sob H_0	1466
18.9.2	Calibração inferencial dos critérios	1469
18.9.3	Invariância a transformações lineares não singulares das respostas	1470
18.9.4	Posto, sinais e multiplicidades das direções	1473
18.10	Aprofundamentos metodológicos e aplicados	1474
18.10.1	Tamanho das células e balanceamento	1474
18.10.2	Avaliação da homogeneidade das matrizes de covariâncias	1475
18.10.3	Observações atípicas e influência	1475
18.10.4	Escolha e interpretação do critério multivariado	1476
18.10.5	Avaliação das respostas após o teste global	1476
18.10.6	Contrastes e comparações posteriores	1477
18.10.7	MANOVA fatorial e MANCOVA	1478
18.10.8	Validação dos resultados	1480
18.10.9	Correspondência com a implementação utilizada	1480
18.11	Síntese	1483
19	Formulação da Análise Discriminante	1485
19.1	O problema de discriminação e classificação	1486
19.2	Classificação como problema de decisão	1487
19.2.1	Probabilidades <i>a priori</i> e <i>a posteriori</i>	1487

19.2.2	Regra de Bayes sob perda zero-um	1488
19.3	Discriminação linear sob normalidade (LDA)	1491
19.3.1	Fronteiras e distância de Mahalanobis	1492
19.4	Discriminação quadrática (QDA)	1494
19.4.1	Fronteiras e comparação com a LDA	1495
19.5	Da regra populacional à regra estimada	1496
19.5.1	Covariância comum na LDA	1498
19.5.2	Probabilidades <i>a priori</i>	1499
19.5.3	Regra estimada da LDA	1499
19.5.4	Regra estimada da QDA	1500
19.6	Formulação geométrica de Fisher	1501
19.6.1	Dispersões populacionais dentro e entre grupos	1502
19.6.2	Dispersões projetadas	1503
19.7	Formulação amostral de Fisher	1505
19.8	Direções discriminantes e autovalores generalizados	1507
19.8.1	Geometria pela dispersão intragrupos	1508
19.8.2	Número de direções discriminantes	1512
19.9	Representação no subespaço discriminante	1512
19.10	Relação espectral com a MANOVA	1515
19.11	Dois grupos e relação entre Fisher e LDA	1516
19.11.1	Formulação populacional para dois grupos	1517
19.11.2	Mais de dois grupos	1519
19.12	Pressupostos e limites	1519
19.12.1	Grupos previamente definidos	1520
19.12.2	Normalidade e estrutura das covariâncias	1521
19.12.3	Não singularidade e dimensão	1522
19.12.4	Independência das unidades de treinamento	1524
19.12.5	Probabilidades <i>a priori</i> e perdas	1524
19.12.6	Sobreposição entre as classes	1525
19.13	Relações com outras técnicas	1525
19.13.1	Análise de Componentes Principais	1526
19.13.2	Análise de Agrupamentos	1527
19.14	Aprofundamentos teóricos	1527
19.14.1	Perdas e risco de classificação	1527
19.14.2	Erro de classificação e separação de Mahalanobis	1530
19.14.3	Forma explícita da fronteira quadrática	1532
19.14.4	Decomposição da covariância por grupos	1533
19.14.5	Relação com a discriminação linear normal	1534
19.14.6	Relação amostral entre Fisher e LDA	1535
19.14.7	Identificação das direções discriminantes	1536
19.15	Aprofundamentos metodológicos e aplicados	1537
19.15.1	Definição das probabilidades <i>a priori</i> e consequências dos erros	1537
19.15.2	Avaliação das condições da análise	1538

19.15.3 Escolha entre LDA e QDA	1538
19.15.4 Importância e avaliação das funções discriminantes de Fisher	1539
19.15.5 Coeficientes das funções discriminantes de Fisher	1541
19.15.6 Centroides e interpretação dos grupos	1542
19.15.7 Erro aparente e erro em novas observações	1543
19.15.8 Matriz de classificação e desempenho por classe	1544
19.15.9 Casos classificados incorretamente	1545
19.15.10 Correspondência com a implementação utilizada	1546
19.16 Síntese	1549
Exercícios de fixação do Módulo III	1551
Parte I — Núcleo	1552
Parte II — Aprofundamentos teóricos	1560
Parte III — Aprofundamentos metodológicos e aplicados	1568
Referências	1577

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos. Técnicas diferentes podem ainda ser aplicadas a um mesmo conjunto de dados e produzir representações distintas ou complementares, pois cada uma privilegia um aspecto específico da estrutura multivariada.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual e matemática orienta a interpretação dos resultados e o uso dos procedimentos computacionais. Essa organização permite compreender por que cada técnica assume determinada forma, que tipo de informação preserva ou modela e quais fundamentos sustentam sua utilização e interpretação.

O **jamovi** é utilizado nas aplicações das técnicas multivariadas, enquanto o ambiente **R** e o sistema **Quarto** apoiam a produção de exemplos, figuras e do próprio livro. A implementação computacional é relacionada explicitamente à formulação estatística apresentada, permitindo

interpretar as opções e as saídas do software sem substituir o desenvolvimento matemático e conceitual dos métodos.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;
- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;

- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar o problema estatístico e selecionar a técnica multivariada de acordo com o objetivo da análise e a natureza dos dados;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados

Álgebra matricial aplicada

Espaços vetoriais, bases e projeções

Transformações lineares

Autovalores, autovetores e decomposição espectral

Decomposição em valores singulares

Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações

Distribuição normal multivariada

Estatísticas amostrais e estimação

Modelo linear multivariado e hipóteses lineares

Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas

Análise de Componentes Principais

Análise Fatorial

Análise de Agrupamentos

Análise de Correspondência

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a avaliação dos pressupostos e a interpretação dos resultados, mantendo explícita a relação entre a formulação estatística e a implementação utilizada.

AVALIAÇÃO

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2018)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações com vetores, o produto interno, a norma, o ângulo, a distância euclidiana e o produto externo.

Convenções gerais de notação

As convenções abaixo indicam apenas como os objetos serão representados. Seus significados e propriedades serão definidos ao longo do capítulo.

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{.j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_i^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;
- o símbolo $\top$ indica transposição;

- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$ representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{\cdot j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j .

Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

Exemplo 1.1 (Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Neste momento, o vetor é utilizado apenas para organizar as medidas. A comparação geométrica de variáveis com unidades diferentes exigirá atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i\cdot}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{\cdot j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i\cdot}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{\cdot j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i\cdot}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_i$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_{\cdot j}$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. Antes de utilizar essas representações geometricamente, é necessário distinguir a natureza das variáveis que fornecem suas componentes.

1.2 Natureza das variáveis e representação

A representação de uma observação como ponto em $\mathbb{R}^p$ pressupõe que suas coordenadas sejam valores numéricos para os quais as operações utilizadas na geometria tenham significado compatível com as variáveis analisadas.

Uma **variável quantitativa** assume valores numéricos que representam quantidades. Ela pode ser discreta, quando seus valores pertencem a um conjunto enumerável, ou contínua, quando pode assumir valores em um intervalo da reta real. Em ambos os casos, seus valores observados podem ser representados por números reais e utilizados como coordenadas quando essa representação for adequada ao problema.

Uma **variável categórica** registra a categoria à qual pertence uma unidade. Em uma variável **nominal**, as categorias não possuem uma ordenação intrínseca. Em uma variável **ordinal**, as categorias possuem uma ordenação, mas as diferenças entre posições sucessivas não representam necessariamente distâncias de mesma magnitude. Uma variável binária constitui um caso particular de variável categórica com duas categorias.

A atribuição de códigos numéricos a categorias não modifica a natureza da variável. Se três categorias nominais forem codificadas por 1, 2 e 3, por exemplo, as diferenças entre esses números não passam a representar automaticamente distâncias entre as categorias. Para uma

variável ordinal, uma codificação numérica pode preservar a ordenação, mas não implica que a diferença entre categorias consecutivas possua significado quantitativo.

Essa distinção também deve ser preservada na organização computacional dos dados. Uma coluna armazenada por números inteiros pode representar uma medida quantitativa, uma variável ordinal ou apenas códigos de categorias nominais. O significado estatístico da coluna é determinado pela variável e por sua escala de mensuração, e não pelo formato numérico utilizado para armazená-la.

Neste capítulo, as matrizes e os vetores representados em $\mathbb{R}^p$ serão construídos a partir de variáveis quantitativas, salvo indicação explícita em contrário. Nos capítulos posteriores, variáveis categóricas e conjuntos de dados mistos serão associados a representações próprias quando a técnica utilizada assim exigir.

1.3 O espaço $\mathbb{R}^p$

Considerando p variáveis quantitativas, os valores observados em uma unidade podem ser organizados em um vetor com p componentes reais. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço $\mathbb{R}^p$). O espaço $\mathbb{R}^p$ é o conjunto

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ no qual são representadas as unidades observacionais será denominado **espaço das observações**. Cada vetor representa uma unidade, e cada componente corresponde a uma variável.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;

- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.4 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{\cdot 1} \ \mathbf{x}_{\cdot 2} \ \cdots \ \mathbf{x}_{\cdot p}] .$$

Exemplo 1.3 (Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = [5 \quad 7] .$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.4.1 Espaço das observações e espaço das variáveis

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{.j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

No **espaço das observações**, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às variáveis.

No **espaço das variáveis**, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{.j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.5 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.5.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.5.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

A norma do vetor resultante satisfaz

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;




Figura 1.3: Soma de vetores pela regra do paralelogramo.

- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.

Exemplo 1.5 (Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.5.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

As operações anteriores produzem novos vetores ou novas variáveis. A próxima operação tem natureza diferente: o produto interno associa dois vetores a um número real e permite construir as noções de comprimento, ângulo, ortogonalidade e distância.

1.6 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

1.6.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. *Linearidade no segundo argumento*

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. *Não negatividade*

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. *Positividade definida*

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0}.$$

1.6.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.


Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.6.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Meyer, 2023)



i Demonstração

Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

51

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha\langle \mathbf{x}, \mathbf{y} \rangle - \alpha\langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2\langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha\langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2\|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$$

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.6.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.6.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as observações.




Figura 1.6: Os vetores x e y são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

A padronização e outras geometrias serão estudadas nos capítulos posteriores.

1.6.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer, 2023)

i Demonstração

Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2.\end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2.\end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.6.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do **produto externo**.

Definição 1.14 (Produto externo). Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, o **produto externo** de $\mathbf{x}$ e $\mathbf{y}$, denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

é definido como a matriz em $\mathbb{R}^{p \times q}$

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$[\text{ext}(\mathbf{x}, \mathbf{y})]_{ij} = x_i y_j.$$

O resultado do produto externo é uma matriz.

A estrutura do produto externo pode ser observada por suas colunas. Como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = [y_1 \mathbf{x} \quad y_2 \mathbf{x} \quad \cdots \quad y_q \mathbf{x}],$$

cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

O produto externo é

$$\begin{aligned} \text{ext}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} 1(3) & 1(-1) & 1(4) \\ 2(3) & 2(-1) & 2(4) \end{bmatrix} \\ &= \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}. \end{aligned}$$

O resultado possui dimensão 2×3 , correspondente às dimensões de $\mathbf{x}$ e $\mathbf{y}$, respectivamente.

O produto interno e o produto externo produzem objetos de naturezas diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz. No próximo capítulo, após a definição do produto matricial, o produto externo será relacionado às operações entre matrizes e vetores, e suas propriedades matriciais serão desenvolvidas.

1.7 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\text{ext}(\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos. O próximo capítulo desenvolverá as operações e as propriedades matriciais necessárias para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo será retomado como um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas bilineares e quadráticas. As seções finais introduzem matrizes particionadas e complemento de Schur, preparando estruturas que serão utilizadas posteriormente na formulação de resultados multivariados.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{r \times s}$. As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \iff n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. Comutatividade

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. Associatividade

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. Existência do elemento neutro

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A},$$

em que $\mathbf{0}_{n \times p}$ é o elemento neutro de dimensão $n \times p$:

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

4. Existência do elemento oposto

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$ e $\alpha, \beta \in \mathbb{R}$. A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:*

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. Elemento neutro da multiplicação escalar

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial, apresentado a seguir, utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. A definição a seguir reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelas linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelas colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_1 - \mathbf{a}_2 \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a seguinte matriz em $\mathbb{R}^{n \times r}$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

i Produto interno e produto externo como produtos matriciais

As operações entre vetores apresentadas anteriormente também podem ser expressas por meio do produto matricial.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno** pode ser escrito como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Como

$$\mathbf{x}^\top \in \mathbb{R}^{1 \times p} \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^{p \times 1},$$

o produto possui dimensão 1×1 e corresponde a um escalar:

$$\mathbf{x}^\top \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

De forma semelhante, para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

o **produto externo**, anteriormente denotado por

$$\text{ext}(\mathbf{x}, \mathbf{y}),$$

pode ser escrito como

$$\text{ext}(\mathbf{x}, \mathbf{y}) = \mathbf{xy}^\top.$$

Nesse caso,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \text{e} \quad \mathbf{y}^\top \in \mathbb{R}^{1 \times q},$$

de modo que

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

Portanto, a ordem e a orientação dos vetores determinam objetos diferentes:

$$\mathbf{x}^\top \mathbf{y} \text{ é um escalar}$$

enquanto

$$\mathbf{xy}^\top \text{ é uma matriz.}$$

Exemplo 2.5 (Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

A matriz

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 3 & 6 & 4 \\ 1 & 5 & 2 & 3 \\ 4 & 2 & 1 & 5 \end{bmatrix} \in \mathbb{R}^{3 \times 4}$$

é obtida escrevendo as colunas de $\mathbf{X}$ como linhas. A operação de transposição e suas propriedades serão formalizadas adiante.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{X}\mathbf{a} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

Considere agora o produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}.$$

Esse produto possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \langle \mathbf{x}_{\cdot 1}, \mathbf{x}_{\cdot 2} \rangle = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \langle \mathbf{x}_1, \mathbf{x}_2 \rangle = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos serão retomados no estudo de matrizes de Gram, produtos cruzados, covariâncias e decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. Associatividade

$$(\mathbf{A}\mathbf{B})\mathbf{C} = \mathbf{A}(\mathbf{B}\mathbf{C}).$$

2. Distributividade à esquerda

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{A}\mathbf{B} + \mathbf{A}\mathbf{C}.$$

3. Distributividade à direita

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{A}\mathbf{C} + \mathbf{B}\mathbf{C}.$$

4. Compatibilidade com a multiplicação por escalar

Para $\alpha \in \mathbb{R}$,

$$(\alpha \mathbf{A})\mathbf{B} = \alpha(\mathbf{A}\mathbf{B}) = \mathbf{A}(\alpha \mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{A}\mathbf{B}$ e $\mathbf{B}\mathbf{A}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{A}\mathbf{B} \neq \mathbf{B}\mathbf{A}.$$

Exemplo 2.6 (Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja $\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}$. A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

Proposição 2.4 (Propriedades da transposição). *Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes com dimensões compatíveis e seja $\alpha \in \mathbb{R}$. Então,*

1. $(\mathbf{A}^\top)^\top = \mathbf{A}$,
2. $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$,
3. $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ e
4. $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$.
5. Em particular, para vetores $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$, $(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top$.

A última propriedade mostra que a transposição de um produto inverte a ordem dos fatores. Em particular, ela será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

2.2.2 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x} \in \mathbb{R}^p$, tem-se

$$(\mathbf{x}\mathbf{x}^\top)^\top = \mathbf{x}\mathbf{x}^\top.$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.8 (Matriz antissimétrica). Uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Aprofundamento

A decomposição seguinte mostra que toda matriz quadrada pode ser separada em uma parte simétrica e uma parte antissimétrica. A parte simétrica será particularmente importante no estudo das formas quadráticas.

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser escrita de maneira única como*

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn; Johnson, 2013)

i Demonstração

A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas.

Exemplo 2.10 (Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.3 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada. Apesar de sua definição simples, essa operação permite representar de forma compacta somas de quadrados, produtos internos, formas quadráticas e diversas expressões matriciais utilizadas em Estatística Multivariada.

Definição 2.9 (Traço de uma matriz). Seja $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$. O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Cálculo do traço). Para $\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix}$, tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Proposição 2.5 (Propriedades básicas do traço). *Sejam $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha, \beta \in \mathbb{R}$. Então,*

1. *Linearidade:*

$$\text{tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{tr}(\mathbf{A}) + \beta \text{tr}(\mathbf{B}).$$

2. *Invariância à transposição:*

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

3. *Traço da matriz identidade:*

$$\text{tr}(\mathbf{I}_n) = n.$$

Consequentemente,

$$\text{tr}(\alpha \mathbf{I}_n) = \alpha n.$$

4. *Propriedade cíclica:* se $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$, então

$$\text{tr}(\mathbf{CD}) = \text{tr}(\mathbf{DC}).$$

(Harville, 1997)

A primeira propriedade mostra que o traço é uma operação linear. A segunda decorre do fato de que a transposição não modifica os elementos da diagonal principal. A quarta permite reorganizar produtos matriciais dentro do traço, desde que seja preservada a ordem cíclica dos fatores.

A propriedade cíclica pode ser demonstrada diretamente a partir da definição do produto matricial.

i Demonstração

Como $\mathbf{C} \in \mathbb{R}^{n \times p}$ e $\mathbf{D} \in \mathbb{R}^{p \times n}$,

$$\text{tr}(\mathbf{CD}) = \sum_{i=1}^n (\mathbf{CD})_{ii} = \sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji}.$$

Trocando a ordem das somas,

$$\sum_{i=1}^n \sum_{j=1}^p c_{ij} d_{ji} = \sum_{j=1}^p \sum_{i=1}^n d_{ji} c_{ij} = \text{tr}(\mathbf{DC}).$$

Proposição 2.6 (Ciclicidade para vários fatores). *Para matrizes com dimensões compatíveis, os fatores de um produto podem ser deslocados ciclicamente dentro do traço. Por exemplo,*

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A propriedade é **cíclica**. Portanto, a ordem relativa dos fatores é preservada. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Proposição 2.7 (Traço, produto interno e produto externo). *Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\text{tr}(\mathbf{xy}^\top) = \mathbf{y}^\top \mathbf{x} = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Como $\mathbf{xy}^\top = \text{ext}(\mathbf{x}, \mathbf{y})$, também podemos escrever

$$\text{tr}[\text{ext}(\mathbf{x}, \mathbf{y})] = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Em particular,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Essa propriedade estabelece uma ligação direta entre o traço e as operações vetoriais introduzidas anteriormente.

Proposição 2.8 (Traço de produtos matriciais). *Para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$,*

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ij}.$$

Consequentemente,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

Pela propriedade cíclica,

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \text{tr}(\mathbf{AA}^\top).$$

Portanto, o traço permite representar a soma dos quadrados de todos os elementos de uma matriz. Essa expressão será retomada posteriormente no estudo da norma de Frobenius, de matrizes de produtos cruzados e de decomposições matriciais.

Exemplo 2.12 (Traço de produtos matriciais). Considere $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} 1 & 3 \\ -2 & 3 \end{bmatrix}$.

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -9 & 9 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} -1 & 13 \\ -7 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

seus traços são iguais:

$$\text{tr}(\mathbf{AB}) = 0 + 9 = 9$$

e

$$\text{tr}(\mathbf{BA}) = -1 + 10 = 9.$$

O traço será utilizado repetidamente na representação de somas de quadrados, produtos cruzados, variâncias totais, formas quadráticas e expressões de verossimilhança. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.10 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos podem ser representados pelo **delta de Kronecker**,

$$\delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

de modo que

$$(\mathbf{I}_n)_{ij} = \delta_{ij}.$$

O delta de Kronecker será utilizado posteriormente para representar de forma compacta relações de ortogonalidade e ortonormalidade.

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.11 (Matriz inversa). Uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.2 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

i Demonstração

Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única.

Exemplo 2.14 (Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.3 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

i Demonstração

Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.12 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.13 (Determinante). Para uma matriz de ordem um,

$$\mathbf{A} = [a_{11}],$$

define-se

$$\det(\mathbf{A}) = a_{11}.$$

Para $n \geq 2$, seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O determinante de $\mathbf{A}$ pode ser calculado recursivamente pela expansão em cofatores de qualquer linha fixa i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna fixa j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Em cada termo, o cofator C_{ij} envolve o determinante de uma matriz de ordem $n - 1$. O caso de ordem um encerra a definição recursiva.

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e realizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais, que serão estudadas posteriormente.

Proposição 2.9 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.4 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A})\det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere uma matriz quadrada

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_n] \in \mathbb{R}^{n \times n}.$$

As colunas de $\mathbf{A}$ podem ser interpretadas como vetores em $\mathbb{R}^n$. Esses vetores determinam uma região geométrica cuja medida depende de suas direções e comprimentos.

O valor absoluto do determinante,

$$|\det(\mathbf{A})|,$$

corresponde à medida do paralelepípedo determinado pelas colunas de $\mathbf{A}$:

- em uma dimensão, corresponde a um comprimento;
- em duas dimensões, corresponde à área do paralelogramo determinado pelas duas colunas;
- em três dimensões, corresponde ao volume do paralelepípedo determinado pelas três colunas;
- em $\mathbb{R}^n$, corresponde ao volume n -dimensional determinado pelas n colunas.

Como a matriz identidade $\mathbf{I}_n$ possui determinante igual a 1, suas colunas determinam uma região de volume unitário. Assim, $|\det(\mathbf{A})|$ também pode ser interpretado como o fator pelo qual esse volume unitário é ampliado ou reduzido quando os vetores canônicos são substituídos pelas colunas de $\mathbf{A}$.

O sinal do determinante acrescenta informação sobre a orientação dos vetores:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é nulo.

No último caso, as colunas não determinam todas as direções necessárias para formar um volume n -dimensional. Em $\mathbb{R}^2$, por exemplo, duas colunas alinhadas formam uma região de área zero; em $\mathbb{R}^3$, três colunas contidas em um mesmo plano formam uma região de volume zero.

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

2.3.5 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.14 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura será importante posteriormente nas decomposições matriciais, em que uma matriz poderá ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.5 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ *é invertível,*

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer, 2023)

Exemplo 2.18 (Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.15 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\&\vdots \\a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n.\end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.6 (Existência e quantidade de soluções). *Sejam*

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- *a solução é única se*

$$\text{posto}(\mathbf{A}) = p;$$

- *existem infinitas soluções se*

$$\text{posto}(\mathbf{A}) < p.$$

Definição 2.16 (Sistema linear homogêneo). Um **sistema linear homogêneo** é um sistema da forma

$$\mathbf{Ax} = \mathbf{0},$$

em que

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{0} \in \mathbb{R}^n.$$

Portanto, um sistema homogêneo é um caso particular de sistema linear no qual todos os termos independentes são iguais a zero.

Todo sistema homogêneo possui pelo menos a **solução trivial**

$$\mathbf{x} = \mathbf{0}.$$

Dependendo da matriz $\mathbf{A}$, também podem existir **soluções não triviais**, isto é, soluções para as quais

$$\mathbf{x} \neq \mathbf{0}.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.19 (Sistema com solução única). Considere

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3. \end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.20 (Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4. \end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned} x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5. \end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.3.7 Aprofundamento: pseudoinversa

Leitura de aprofundamento

A pseudoinversa permite estender a resolução de sistemas lineares para matrizes retangulares ou singulares. Sua construção será desenvolvida no capítulo sobre decomposição em valores singulares. Nesta seção, são apresentadas sua definição e suas principais consequências.

Definição 2.17 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Harville, 1997)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+\mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+\mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{AA}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção de $\mathbf{A}^+$, sua interpretação por projeções e sua relação com o posto serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.18 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.21 (Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.7 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

i Demonstração

Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q}\mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.19 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag} \left(\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} \right).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1x_1 \\ d_2x_2 \\ \vdots \\ d_nx_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.22 (Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.20 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$$\mathbf{U}^\top \text{ é triangular inferior.}$$

Da mesma forma,

$$\mathbf{L}^\top \text{ é triangular superior.}$$

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.23 (Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Aprofundamento: sistemas triangulares

Leitura de aprofundamento

Os sistemas triangulares mostram como a estrutura de uma matriz pode simplificar a resolução de equações. Esses procedimentos também aparecem nas decomposições matriciais estudadas posteriormente.

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.24 (Sistema triangular superior). Considere o sistema

$$\begin{aligned} x_1 + 2x_2 - x_3 &= 4, \\ 2x_2 + 3x_3 &= 7, \\ x_3 &= 1. \end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{Lx} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar e são lineares em cada argumento separadamente. Quando uma forma bilinear é avaliada utilizando o mesmo vetor em seus dois argumentos, obtém-se uma função de um único vetor, denominada forma quadrática.

Essa relação permite conectar propriedades das matrizes, como simetria e positividade, a expressões escalares que aparecem frequentemente na análise multivariada, entre elas produtos internos, normas, variâncias e distâncias.

2.5.1 Formas bilineares

Definição 2.21 (Forma bilinear). Uma função

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **forma bilinear** quando é linear separadamente em cada argumento.

Isso significa que, para quaisquer

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e quaisquer

$$\beta \in \mathbb{R},$$

tem-se

$$g(\mathbf{x} + \beta \mathbf{z}, \mathbf{y}) = g(\mathbf{x}, \mathbf{y}) + \beta g(\mathbf{z}, \mathbf{y})$$

e

$$g(\mathbf{x}, \mathbf{z} + \beta \mathbf{y}) = g(\mathbf{x}, \mathbf{z}) + \beta g(\mathbf{x}, \mathbf{y}).$$

A bilinearidade significa, portanto, que, mantendo um dos argumentos fixo, a forma bilinear é uma função linear do outro argumento.

Fixado $\mathbf{y} \in \mathbb{R}^p$, a função

$$\mathbf{x} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{x}$. Analogamente, fixado $\mathbf{x} \in \mathbb{R}^p$, a função

$$\mathbf{y} \mapsto g(\mathbf{x}, \mathbf{y})$$

é linear em $\mathbf{y}$.

Um caso particularmente importante para a estatística são as formas bilineares simétricas.

Definição 2.22 (Forma bilinear simétrica). Uma forma bilinear

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

é denominada **simétrica** quando

$$g(\mathbf{x}, \mathbf{y}) = g(\mathbf{y}, \mathbf{x})$$

para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

Exemplo 2.25 (Produto interno como forma bilinear simétrica). O produto interno usual em $\mathbb{R}^p$,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle,$$

é um exemplo de forma bilinear simétrica, pois,

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle,$$

ou, equivalentemente,

$$\mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}.$$

Nem toda forma bilinear é simétrica.

Exemplo 2.26 (Bilinearidade e ausência de simetria). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$$

e os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

A função

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é dada por

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2y_1 + y_2 \\ -y_1 + 3y_2 \end{bmatrix} \\ &= 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2. \end{aligned}$$

Para verificar a linearidade no primeiro argumento, sejam $\mathbf{x}_1, \mathbf{x}_2, \mathbf{y} \in \mathbb{R}^2$ e $\beta \in \mathbb{R}$. Então,

$$\begin{aligned} g(\mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) &= (\mathbf{x}_1 + \beta \mathbf{x}_2)^\top \mathbf{A} \mathbf{y} \\ &= \mathbf{x}_1^\top \mathbf{A} \mathbf{y} + \beta \mathbf{x}_2^\top \mathbf{A} \mathbf{y} \\ &= g(\mathbf{x}_1, \mathbf{y}) + \beta g(\mathbf{x}_2, \mathbf{y}). \end{aligned}$$

Analogamente, para $\mathbf{x}, \mathbf{y}_1, \mathbf{y}_2 \in \mathbb{R}^2$,

$$\begin{aligned} g(\mathbf{x}, \mathbf{y}_1 + \beta \mathbf{y}_2) &= \mathbf{x}^\top \mathbf{A} (\mathbf{y}_1 + \beta \mathbf{y}_2) \\ &= \mathbf{x}^\top \mathbf{A} \mathbf{y}_1 + \beta \mathbf{x}^\top \mathbf{A} \mathbf{y}_2 \\ &= g(\mathbf{x}, \mathbf{y}_1) + \beta g(\mathbf{x}, \mathbf{y}_2). \end{aligned}$$

Portanto, g é linear em cada argumento separadamente e, assim, é uma forma bilinear.

Para verificar se a forma bilinear é simétrica, invertem-se os dois argumentos. Tem-se

$$g(\mathbf{y}, \mathbf{x}) = 2x_1y_1 - x_1y_2 + x_2y_1 + 3x_2y_2.$$

Por outro lado,

$$g(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + x_1y_2 - x_2y_1 + 3x_2y_2.$$

As duas expressões diferem nos termos cruzados. Portanto, em geral,

$$g(\mathbf{x}, \mathbf{y}) \neq g(\mathbf{y}, \mathbf{x}),$$

e a forma bilinear não é simétrica.

De modo geral, uma forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}$$

é simétrica se, e somente se, sua matriz representante é simétrica, isto é, $\mathbf{A} = \mathbf{A}^\top$.

Uma forma bilinear também pode ser avaliada utilizando o mesmo vetor em seus dois argumentos. Assim, em vez de considerar

$$g(\mathbf{x}, \mathbf{y}),$$

podemos considerar

$$g(\mathbf{x}, \mathbf{x}).$$

Essa avaliação produz uma função de um único vetor e conduz às formas quadráticas.

2.5.2 Formas quadráticas

Definição 2.23 (Forma quadrática). Seja

$$g : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma forma bilinear. A função

$$Q : \mathbb{R}^p \longrightarrow \mathbb{R}$$

definida por

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x})$$

é denominada **forma quadrática** associada a g .

Se a forma bilinear possui representação matricial

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p.$$

A forma bilinear depende de dois argumentos e é linear em cada um deles separadamente. A forma quadrática, por sua vez, depende de um único argumento e, em geral, não é uma função linear desse vetor.

De fato, para qualquer $\alpha \in \mathbb{R}$,

$$\begin{aligned} Q(\alpha \mathbf{x}) &= g(\alpha \mathbf{x}, \alpha \mathbf{x}) \\ &= \alpha^2 g(\mathbf{x}, \mathbf{x}) \\ &= \alpha^2 Q(\mathbf{x}). \end{aligned}$$

Assim,

$$Q(\alpha \mathbf{x}) = \alpha^2 Q(\mathbf{x}).$$

A expressão quadrática pode ser interpretada como a avaliação da forma bilinear sobre a diagonal do produto cartesiano,

$$\{(\mathbf{x}, \mathbf{x}) : \mathbf{x} \in \mathbb{R}^p\} \subset \mathbb{R}^p \times \mathbb{R}^p.$$

O produto interno fornece um exemplo imediato dessa construção.

Exemplo 2.27 (Produto interno e norma ao quadrado). Considere a forma bilinear dada pelo produto interno usual,

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle.$$

Ao utilizar o mesmo vetor nos dois argumentos,

$$Q(\mathbf{x}) = g(\mathbf{x}, \mathbf{x}) = \langle \mathbf{x}, \mathbf{x} \rangle.$$

Pela definição da norma euclidiana,

$$\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2.$$

Portanto,

$$Q(\mathbf{x}) = \|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

A matriz representante dessa forma quadrática é

$$\mathbf{I}_p.$$

Em geral, se

$$\mathbf{A} = (a_{ij})_{p \times p},$$

então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j. \quad (2.1)$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= ax_1^2 + (b+c)x_1x_2 + dx_2^2. \end{aligned}$$

Esse desenvolvimento mostra uma diferença importante entre formas bilineares e formas quadráticas.

Na forma bilinear

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

os elementos a_{ij} e a_{ji} podem produzir contribuições distintas porque os dois vetores não precisam ser iguais.

Na forma quadrática

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

os termos fora da diagonal aparecem combinados. No caso bidimensional, por exemplo, b e c aparecem somente por meio da soma

$$b + c.$$

Consequentemente, a matriz que aparece em uma representação

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

não é necessariamente única quando matrizes não simétricas são admitidas. Matrizes que diferem apenas por uma parcela antissimétrica produzem a mesma forma quadrática.

Entretanto, toda forma quadrática possui uma única matriz simétrica que a representa. Essa propriedade é apresentada na proposição seguinte.

Proposição 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e defina

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$


Então $\mathbf{S}$ é simétrica e, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Além disso, $\mathbf{S}$ é a única matriz simétrica que representa essa forma quadrática.



Assim, embora uma forma quadrática possa possuir diferentes representações por matrizes não simétricas, sua representação por uma matriz simétrica é única.

Por essa razão, no estudo de formas quadráticas, pode-se trabalhar sem perda de generalidade com matrizes simétricas.

Observe que essa propriedade é específica das formas quadráticas. Para uma forma bilinear geral,

$$g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

a parte antissimétrica de $\mathbf{A}$ pode contribuir para o valor da expressão quando

$$\mathbf{x} \neq \mathbf{y}.$$

Quando os dois argumentos coincidem, essa contribuição desaparece.

Exemplo 2.28 (Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

A forma quadrática associada a $\mathbf{A}$ é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então,

$$Q(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuando os produtos,

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtém-se

$$\begin{aligned} Q(\mathbf{x}) &= 2(1)^2 + 2(1)(2) + 3(2)^2 \\ &= 2 + 4 + 12 \\ &= 18. \end{aligned}$$

2.5.3 Positividade

Como toda forma quadrática pode ser representada por uma única matriz simétrica, propriedades importantes da forma quadrática podem ser estudadas a partir dos valores assumidos por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com $\mathbf{A}$ simétrica.

A classificação em positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida depende do sinal assumido por essa expressão.

Definição 2.24 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica e considere a forma quadrática

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \succ \mathbf{0};$$

- **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \succeq \mathbf{0};$$

- **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso, escreve-se

$$\mathbf{A} \prec \mathbf{0};$$

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Nesse caso, escreve-se

$$\mathbf{A} \preceq \mathbf{0};$$

- **indefinida** quando existem vetores não nulos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Para matrizes indefinidas, não se utiliza uma relação de ordem do tipo $\mathbf{A} \succeq \mathbf{0}$ ou $\mathbf{A} \preceq \mathbf{0}$.

As notações $\succ$, $\succeq$, $\prec$ e $\preceq$ expressam a ordem de Löwner para matrizes simétricas. Em particular,

$$\begin{aligned}\mathbf{A} \succ \mathbf{0} &\iff \mathbf{A} \text{ é positiva definida,} \\ \mathbf{A} \succeq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida positiva,} \\ \mathbf{A} \prec \mathbf{0} &\iff \mathbf{A} \text{ é negativa definida,} \\ \mathbf{A} \preceq \mathbf{0} &\iff \mathbf{A} \text{ é semidefinida negativa.}\end{aligned}$$

produto interno usual fornece um exemplo imediato de forma quadrática associada a uma matriz positiva definida.

Como

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{I}_p \mathbf{x} = \|\mathbf{x}\|^2,$$

tem-se

$$Q(\mathbf{x}) > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0}.$$

Portanto, a matriz identidade

$$\mathbf{I}_p$$

é positiva definida.

Outro exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo.

Para

$$\mathbf{x}, \mathbf{z} \in \mathbb{R}^p,$$

considere

$$\mathbf{x}\mathbf{x}^\top.$$

Então,

$$\begin{aligned}\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} &= (\mathbf{z}^\top \mathbf{x}) (\mathbf{x}^\top \mathbf{z}) \\ &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\text{rank}(\mathbf{x}\mathbf{x}^\top) = 1.$$

Assim, quando $p > 1$, existem vetores não nulos $\mathbf{z}$ ortogonais a $\mathbf{x}$. Para esses vetores,

$$\mathbf{x}^\top \mathbf{z} = 0$$

e, portanto,

$$\mathbf{z}^\top (\mathbf{x}\mathbf{x}^\top) \mathbf{z} = 0.$$

Logo, para $p > 1$ e $\mathbf{x} \neq \mathbf{0}$, a matriz

$$\mathbf{x}\mathbf{x}^\top$$

é semidefinida positiva, mas não positiva definida.

Esse tipo de matriz terá importância particular na construção das matrizes de covariâncias, que envolvem somas de produtos externos de vetores de desvios.

Exemplo 2.29 (Classificação de formas quadráticas). Considere inicialmente

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

Como

$$2x_1^2 + 3x_2^2 > 0$$

para todo

$$\mathbf{x} \neq \mathbf{0},$$

a matriz $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

Portanto, $\mathbf{B}$ é semidefinida positiva.

Entretanto, para vetores não nulos da forma

$$\mathbf{x} = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}, \quad x_2 \neq 0,$$

tem-se

$$Q(\mathbf{x}) = 0.$$

Assim, $\mathbf{B}$ não é positiva definida.

Finalmente, considere

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

A forma quadrática associada é

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{x}) = 1 > 0.$$

Por outro lado, para

$$\mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

obtém-se

$$Q(\mathbf{y}) = -1 < 0.$$

Portanto, a forma quadrática assume valores positivos e negativos, e a matriz $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérbolas. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Aprofundamento: matrizes particionadas e complemento de Schur

Leitura de aprofundamento

Esta seção pode ser utilizada como referência nos capítulos posteriores. As operações por blocos e o complemento de Schur serão retomados no estudo de covariâncias particionadas, distribuições condicionais, regressão entre blocos e correlação canônica.

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.25 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.30 (Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ \hline 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.31 (Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ \hline 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

Matrizes particionadas permitem tratar uma matriz de grande dimensão a partir de blocos menores. Em vários problemas, é útil eliminar um desses blocos e estudar a estrutura que permanece no outro. O **complemento de Schur** é a matriz que surge naturalmente nesse processo de eliminação.

Definição 2.26 (Complemento de Schur). Considere a matriz quadrada particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Os blocos diagonais $\mathbf{A}_{11}$ e $\mathbf{A}_{22}$ são quadrados. Quando um deles é invertível, podemos utilizá-lo para eliminar os efeitos dos blocos fora da diagonal.

Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21} \mathbf{A}_{11}^{-1} \mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, enquanto $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

A expressão pode ser compreendida como uma correção do bloco diagonal original. Por exemplo,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

parte de $\mathbf{A}_{11}$ e retira a parcela associada às relações que passam pelo segundo bloco. Essa interpretação ficará mais clara ao observarmos a eliminação por blocos.

2.6.6 Eliminação por blocos

Suponha que $\mathbf{A}_{22}$ seja invertível. Queremos eliminar o bloco $\mathbf{A}_{12}$, isto é, produzir uma matriz equivalente cuja posição superior direita seja ocupada por uma matriz nula.

Para isso, considere

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Multiplicando $\mathbf{E}$ por $\mathbf{A}$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Efetuando o produto por blocos,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{A}_{12} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{22} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Como $\mathbf{A}_{22}^{-1}\mathbf{A}_{22} = \mathbf{I}_q$,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Portanto, o complemento de Schur aparece exatamente como o bloco que permanece depois da eliminação de $\mathbf{A}_{12}$ utilizando $\mathbf{A}_{22}$.

Como

$$\mathbf{E}^{-1} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix},$$

também podemos escrever

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11 \cdot 2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Essa fatoração é consequência direta da eliminação por blocos.

Um caso simples ajuda a reconhecer a estrutura. Para uma matriz 2×2 ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

com $d \neq 0$, o complemento de Schur de d é

$$a - bd^{-1}c.$$

Como veremos a seguir,

$$\det(\mathbf{A}) = d(a - bd^{-1}c) = ad - bc,$$

recuperando a expressão usual do determinante de uma matriz 2×2 .

Exemplo 2.32 (Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Como $\mathbf{A}_{22} = \mathbf{I}_2$, tem-se $\mathbf{A}_{22}^{-1} = \mathbf{I}_2$. Logo,

$$\begin{aligned} \mathbf{A}_{11 \cdot 2} &= \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.7 Determinante de uma matriz particionada

A eliminação por blocos mostra uma das principais utilidades do complemento de Schur: calcular o determinante de uma matriz particionada utilizando determinantes de matrizes menores.

Teorema 2.8 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd; Vandenberghe, 2004)

i Demonstração

Suponha que $\mathbf{A}_{22}$ seja invertível. Pela eliminação por blocos apresentada anteriormente,

$$\mathbf{EA} = \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{E} = \begin{bmatrix} \mathbf{I}_p & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix}.$$

Como $\mathbf{E}$ é triangular por blocos e possui matrizes identidade na diagonal,

$$\det(\mathbf{E}) = 1.$$

Portanto,

$$\det(\mathbf{EA}) = \det(\mathbf{A}).$$

A matriz $\mathbf{EA}$ também é triangular por blocos. Assim,

$$\det(\mathbf{EA}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

A segunda identidade é obtida de forma análoga, eliminando o bloco $\mathbf{A}_{21}$ a partir de $\mathbf{A}_{11}$.

No Exemplo 2.32,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = 3.$$

Consequentemente,

$$\det(\mathbf{A}) = 3.$$

2.6.8 Inversão em blocos

O complemento de Schur também permite obter a inversa de uma matriz particionada. A origem da expressão pode ser entendida a partir da mesma fatoração obtida pela eliminação por blocos.

Se $\mathbf{A}_{22}$ é invertível,

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{11.2}$ também é invertível, os dois fatores são invertíveis. Como a inversa de um produto inverte a ordem dos fatores, a inversa de $\mathbf{A}$ pode ser construída a partir das inversas dessas duas matrizes mais simples.

Proposição 2.11 (Inversa em blocos). *Considere a matriz particionada*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e o complemento de Schur de $\mathbf{A}_{22}$ em $\mathbf{A}$,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1} & \mathbf{B}_{22} \end{bmatrix},$$

com o bloco $(2,2)$ dado por

$$\mathbf{B}_{22} = \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11.2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}.$$

(Boyd; Vandenberghe, 2004)

A expressão pode parecer extensa, mas sua estrutura é determinada pela eliminação anterior. O bloco $\mathbf{A}_{11.2}^{-1}$ representa a parte de $\mathbf{A}_{11}$ que permanece depois da eliminação do segundo bloco.

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.9 Positividade e complemento de Schur

Outra aplicação importante ocorre em matrizes simétricas. O complemento de Schur permite verificar a definição positiva de uma matriz particionada por meio de matrizes de menor dimensão.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Para estudar se $\mathbf{A}$ é positiva definida, consideramos sua forma quadrática. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y}.$$

Quando $\mathbf{A}_{22}$ é invertível, os termos envolvendo $\mathbf{y}$ podem ser reorganizados completando a forma quadrática:

$$\begin{aligned} & \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top (\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top) \mathbf{x} \\ & \quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

O primeiro termo contém exatamente o complemento de Schur de $\mathbf{A}_{22}$.

Teorema 2.9 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então $\mathbf{A}$ é positiva definida se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top$$

é positiva definida. (Boyd; Vandenberghe, 2004)

i Demonstração

Pela decomposição da forma quadrática,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} \\ + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}).$$

Suponha inicialmente que $\mathbf{A}_{11 \cdot 2}$ e $\mathbf{A}_{22}$ sejam positivas definidas.

Se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Logo, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela da decomposição é igual a zero. Portanto,

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11 \cdot 2} \mathbf{x} > 0.$$

Assim, $\mathbf{A}_{11 \cdot 2}$ é positiva definida.

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22 \cdot 1}$.

O complemento de Schur aparece sempre que uma matriz particionada é estudada após a eliminação de um dos blocos. Por isso, ele será útil em diferentes partes da Análise Multivariada.

Algebricamente, o termo

$$\mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa a correção associada ao segundo bloco, enquanto

$$\mathbf{A}_{11 \cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$$

representa o primeiro bloco depois dessa correção.

Essa interpretação é puramente matricial e vale para matrizes particionadas gerais.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada,

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix},$$

o complemento

$$\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{12}^\top$$

adquire uma interpretação estatística adicional. Ele representa a matriz de covariâncias da parcela do primeiro bloco que permanece após o ajuste linear pelo segundo bloco. Sob normalidade conjunta, essa mesma matriz corresponde à covariância condicional do primeiro bloco dado o segundo.

Essa estrutura será retomada no estudo de covariâncias condicionais, regressão entre blocos e distribuição normal multivariada.

2.7 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{A}\mathbf{x}$	Produz produtos internos pelas linhas e combinações lineares pelas colunas
Produto matricial	$\mathbf{A}_{n \times p}\mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{A}\mathbf{B})^\top = \mathbf{B}^\top\mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma bilinear	$\mathbf{x}^\top \mathbf{A} \mathbf{y}$	Relaciona dois vetores por meio de uma matriz
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$$\mathbf{A} \text{ é invertível,}$$

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{Ax} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{Ax}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida.

As seções sobre pseudoinversa, sistemas triangulares, matrizes particionadas e complemento de Schur funcionam como aprofundamentos. Esses resultados serão retomados quando sua utilização estatística se tornar necessária.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas bilineares e quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

Convenções para espaços vetoriais e subespaços

As convenções vetoriais e matriciais apresentadas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- V e W representam espaços vetoriais ou subespaços vetoriais;
- S representa, em geral, um subespaço de $\mathbb{R}^p$;
- $\mathcal{B}$ representa uma base;
- $\mathcal{B}_W$ representa uma base associada ao subespaço W ;
- $\dim(V)$ representa a dimensão do espaço vetorial V ;
- $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ representa o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$;
- $[\mathbf{x}]_{\mathcal{B}}$ representa o vetor de coordenadas de $\mathbf{x}$ em relação à base $\mathcal{B}$;
- $S^\perp$ representa o complemento ortogonal de S ;
- $\mathcal{C}(\mathbf{A})$ representa o espaço coluna de $\mathbf{A}$;
- $\mathcal{L}(\mathbf{A})$ representa o espaço linha de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A})$ representa o espaço nulo de $\mathbf{A}$;
- $\mathcal{N}(\mathbf{A}^\top)$ representa o espaço nulo de $\mathbf{A}^\top$;
- $\oplus$ representa soma direta de subespaços;
- $\text{proj}_S(\mathbf{x})$ representa a projeção ortogonal de $\mathbf{x}$ sobre S ;
- $\mathbf{P}_S$ representa uma matriz de projeção ortogonal sobre S ;
- $\mathbf{G}$ representa, quando indicado, uma matriz de Gram.

Quando uma base for escrita como

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\},$$

a ordem dos vetores será considerada fixada sempre que forem utilizadas coordenadas em relação a essa base.

Os vetores continuarão sendo representados por letras minúsculas em negrito, como $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{v}$, enquanto matrizes serão representadas por letras maiúsculas em negrito, como $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{Q}$.

As definições e propriedades específicas de cada espaço, base, decomposição ou operador serão apresentadas nas seções correspondentes.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e são satisfeitas as seguintes propriedades:

1. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$,

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x}.$$

2. Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$,

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}).$$

3. Existe um vetor $\mathbf{0} \in V$ tal que, para todo $\mathbf{x} \in V$,

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

4. Para todo $\mathbf{x} \in V$, existe um vetor $-\mathbf{x} \in V$ tal que

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0}.$$

5. Para quaisquer $\mathbf{x}, \mathbf{y} \in V$ e $\alpha \in \mathbb{R}$,

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y}.$$

6. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x}.$$

7. Para quaisquer $\mathbf{x} \in V$ e $\alpha, \beta \in \mathbb{R}$,

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}.$$

8. Para todo $\mathbf{x} \in V$,

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais de adição e multiplicação por escalar, é um espaço vetorial. Seus elementos são vetores com p componentes reais. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e, para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

seu inverso aditivo é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

Os elementos de um espaço vetorial não precisam ser necessariamente vetores numéricos. Por exemplo, o conjunto de todas as matrizes reais de dimensão $n \times p$,

$$\mathbb{R}^{n \times p},$$

também é um espaço vetorial com as operações usuais de adição de matrizes e multiplicação por escalar. Nesse caso, os elementos do espaço vetorial são matrizes.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Proposição 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer, 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

Geometricamente, S é uma reta paralela a W , mas deslocada e sem passar pela origem.

A Figura 3.1 compara uma reta que é subespaço de $\mathbb{R}^2$ com uma reta paralela que não é subespaço.




Figura 3.1: Comparação entre uma reta que é subespaço de $\mathbb{R}^2$ e uma reta que não é subespaço.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem e, por isso, não é um subespaço de $\mathbb{R}^2$.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é o conjunto de todas as suas combinações lineares,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

A notação

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$$

indica o subespaço gerado pelos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Exemplo 3.5 (Espaço e subespaço gerado). Considere o espaço vetorial

$$V = \mathbb{R}^3.$$

Primeiro, considere os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}.$$

Como qualquer vetor de $\mathbb{R}^3$ pode ser obtido escolhendo adequadamente α_1 , α_2 e α_3 ,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} = \mathbb{R}^3.$$

Nesse caso, o subespaço gerado coincide com o próprio espaço V .

Considere agora apenas os vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

As combinações lineares desses vetores são da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ 0 \end{bmatrix}.$$

Portanto,

$$W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} : x_1, x_2 \in \mathbb{R} \right\}.$$

O conjunto W é o plano $x_3 = 0$ contido em $\mathbb{R}^3$. Assim,

$$W \subsetneq V,$$

Os dois casos mostram que um subespaço gerado pode coincidir com todo o espaço ou possuir dimensão menor. Em um espaço vetorial de dimensão finita, um subespaço não pode ter dimensão maior que a do espaço que o contém.

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.6 (Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes.

Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.7 (Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

3.2.2 Independência linear e posto

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k], \quad \mathbf{A} \in \mathbb{R}^{p \times k}.$$

As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se,

$$\text{posto}(\mathbf{A}) = k.$$

Assim, o número de vetores linearmente independentes entre as colunas de $\mathbf{A}$ é determinado pelo posto da matriz.

Como

$$\text{posto}(\mathbf{A}) \leq \min(p, k),$$

não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Proposição 3.2 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*

2. Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.
3. Todo subconjunto de um conjunto linearmente independente também é linearmente independente.
4. Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.
5. Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.

A última propriedade fornece uma interpretação direta da redundância.

Proposição 3.3 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

i Demonstração

Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente.

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.8 (Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.9 (Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.1 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

i Demonstração

Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única.

Definição 3.6 (Coordenadas em uma base). *Se*

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.10 (Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_B = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

As coordenadas de um vetor em uma base são os coeficientes que indicam quanto de cada vetor da base é necessário para reconstruir esse vetor por combinação linear. Assim, o vetor de coordenadas não é o próprio vetor, mas a representação desse vetor em relação à base escolhida.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

A partir deste ponto, considere um subespaço $S \subseteq \mathbb{R}^p$ com o produto interno euclidiano.

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

de S é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base $\mathcal{B}$ de S é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker, a condição de ortonormalidade pode ser escrita como

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Teorema 3.2 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt. (Meyer, 2023)

Esse resultado garante que a geometria de um subespaço de dimensão finita pode ser descrita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Proposição 3.4 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de um subespaço $S \subseteq \mathbb{R}^p$, então todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Cada coordenada de $\mathbf{x}$ na base $\mathcal{B}$ pode ser obtida separadamente por

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}, \quad j = 1, \dots, k.$$

Portanto,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal, então $\mathbf{b}_j^\top \mathbf{b}_j = 1$ para todo j , de modo que

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

e

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Assim, em uma base ortogonal, cada coordenada pode ser determinada por meio de um produto interno, sem a necessidade de resolver simultaneamente um sistema linear. (Meyer, 2023)

i Demonstração

Como $\mathcal{B}$ é uma base de S , todo vetor $\mathbf{x} \in S$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados à esquerda por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal,

$$\mathbf{b}_j^\top \mathbf{b}_i = 0 \quad \text{para} \quad i \neq j.$$

Assim, todos os termos da soma com $i \neq j$ são nulos, restando

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j.$$

Como $\mathbf{b}_j \neq \mathbf{0}$,

$$\mathbf{b}_j^\top \mathbf{b}_j = \|\mathbf{b}_j\|^2 > 0,$$

e, portanto,

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Se a base é ortonormal, então $\|\mathbf{b}_j\| = 1$ e, conseqüentemente,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

Logo,

$$c_j = \mathbf{b}_j^\top \mathbf{x},$$

o que fornece diretamente as coordenadas de $\mathbf{x}$ na base ortonormal.

A Figura 3.3 compara três bases de $\mathbb{R}^2$ e destaca a diferença entre independência linear e ortogonalidade.




Figura 3.3: Comparação entre uma base canônica, uma base oblôqua e uma base ortonormal rotacionada de $\mathbb{R}^2$. O símbolo de ângulo reto identifica os pares de vetores ortogonais.

Na primeira e na terceira bases, os vetores são ortogonais e possuem norma igual a 1, como indicado pelos marcadores de ângulo reto. Portanto, ambas são bases ortonormais. Na base oblôqua, os vetores continuam sendo linearmente independentes e, por isso, formam uma base de $\mathbb{R}^2$, mas não são ortogonais.

3.2.7 Dimensão

Um espaço vetorial é denominado **finito-dimensional** quando possui uma base formada por um número finito de vetores.

Para que a dimensão possa ser definida pelo número de vetores de uma base, é necessário estabelecer primeiro que esse número não depende da base escolhida.

Teorema 3.3 (Número de vetores de uma base). *Se um espaço vetorial V possui uma base finita, então todas as bases de V são finitas e possuem a mesma quantidade de vetores. (Meyer, 2023)*

Definição 3.10 (Dimensão). Se as bases de um espaço vetorial finito-dimensional V possuem k vetores, a **dimensão** de V é definida por

$$\dim(V) = k.$$

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.11 (Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Proposição 3.5 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz está associada a subespaços determinados por suas linhas, por suas colunas e pelas soluções de sistemas lineares homogêneos. Esses subespaços permitem relacionar o posto, a dependência linear e as soluções de sistemas lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Serão estudados quatro subespaços associados a $\mathbf{A}$:

- o espaço coluna;
- o espaço linha;
- o espaço nulo;
- o espaço nulo à esquerda.

Os dois primeiros são construídos a partir das colunas e das linhas da matriz. Os dois últimos são determinados pelas soluções dos sistemas homogêneos associados, respectivamente, a $\mathbf{A}$ e a $\mathbf{A}^\top$.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{A}\mathbf{x} = \mathbf{0}\}.$$

Quando $\mathbf{A}$ é interpretada como a matriz associada a uma transformação linear, esse espaço corresponde ao **núcleo** da transformação. Essa interpretação será formalizada no capítulo seguinte.

O espaço nulo reúne todos os vetores $\mathbf{x} \in \mathbb{R}^p$ que são anulados pela multiplicação por $\mathbf{A}$, isto é, aqueles para os quais $\mathbf{A}\mathbf{x} = \mathbf{0}$.

Proposição 3.6 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

i Demonstração

O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço.

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.12 (Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_{.1} \quad \mathbf{a}_{.2} \quad \cdots \quad \mathbf{a}_{.p}] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_{.1}, \dots, \mathbf{a}_{.p} \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Como

$$\mathbf{Ax} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p},$$

o conjunto de todos os vetores que podem ser escritos na forma $\mathbf{Ax}$ coincide com o espaço gerado pelas colunas de $\mathbf{A}$:

$$\mathcal{C}(\mathbf{A}) = \{ \mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p \}.$$

Essa caracterização permite relacionar diretamente o espaço coluna à existência de soluções de sistemas lineares.

Proposição 3.7 (Consistência de um sistema linear). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

i Demonstração

Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{A}\mathbf{x},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_{.1} + \dots + x_p \mathbf{a}_{.p}.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtém-se

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

Exemplo 3.13 (Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_{.1} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \mathbf{a}_{.2} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \mathbf{a}_{.3} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_{.2} = 2\mathbf{a}_{.1}$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base de $\mathcal{C}(\mathbf{A})$ pode ser formada por quaisquer vetores linearmente independentes que gerem esse espaço. Quando se deseja obter uma base selecionando colunas da própria matriz $\mathbf{A}$, as posições das colunas pivô podem ser identificadas por escalonamento. Nesse procedimento, os vetores da base são as colunas correspondentes da matriz original, e não as colunas da matriz escalonada.

3.3.3 Espaço linha

Definição 3.13 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.14 (Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

Definição 3.14 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto, todo vetor de $\mathcal{N}(\mathbf{A}^\top)$ é ortogonal a cada coluna de $\mathbf{A}$ e, conseqüentemente, a toda combinação linear dessas colunas. A relação entre o espaço nulo à esquerda e o complemento ortogonal do espaço coluna será formalizada adiante.

Exemplo 3.15 (Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.5 Extensão de uma base

Uma base de um subespaço pode ser completada acrescentando vetores até formar uma base de todo o espaço. Esse resultado será utilizado na demonstração do Teorema Posto–Nulidade.

Teorema 3.4 (Extensão de uma base). *Seja W um subespaço de um espaço vetorial V de dimensão finita. Se*

$$\mathcal{B}_W = \{\mathbf{u}_1, \dots, \mathbf{u}_s\}$$

é uma base de W , então existem vetores $\mathbf{z}_1, \dots, \mathbf{z}_r \in V$ tais que

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

é uma base de V . (Meyer, 2023)

i Demonstração

Se $\mathcal{B}_W$ já gera V , então $\mathcal{B}_W$ é uma base de V e nada precisa ser acrescentado. Caso contrário, existe um vetor $\mathbf{z}_1 \in V$ que não pertence ao subespaço gerado por $\mathcal{B}_W$. Assim,

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1\}$$

é linearmente independente.

Se esse conjunto ainda não gera V , escolhe-se um vetor $\mathbf{z}_2 \in V$ que não pertence ao subespaço gerado pelos vetores já selecionados. O novo conjunto continua linearmente independente.

Repetindo esse procedimento, acrescentam-se vetores enquanto o conjunto obtido não gerar V . Como V possui dimensão finita, não é possível acrescentar indefinidamente vetores linearmente independentes. Portanto, após um número finito de etapas, obtém-se um conjunto

$$\{\mathbf{u}_1, \dots, \mathbf{u}_s, \mathbf{z}_1, \dots, \mathbf{z}_r\}$$

que é linearmente independente e gera V . Logo, esse conjunto é uma base de V .

3.3.6 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.5 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Meyer, 2023)



i Demonstração

Considere uma base do espaço nulo,

$$\mathcal{B}_{\mathcal{N}} = \{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Pelo Teorema 3.4, essa base de $\mathcal{N}(\mathbf{A})$ pode ser completada para formar uma base de $\mathbb{R}^p$. Assim, existem vetores $\mathbf{w}_1, \dots, \mathbf{w}_r \in \mathbb{R}^p$ tais que

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$.

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Exemplo 3.16 (Aplicação do Teorema Posto–Nulidade). Para a matriz utilizada nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Assim, para $\mathbf{A} \in \mathbb{R}^{2 \times 3}$,

$$1 + 2 = 3,$$

confirmando que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = 3.$$

Aplicando o resultado a $\mathbf{A}^\top$,

$$1 + 1 = 2,$$

de modo que

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = 2.$$

Os resultados correspondem, respectivamente, às dimensões dos espaços ambientes $\mathbb{R}^3$ e $\mathbb{R}^2$.

3.3.7 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimensão
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os quatro espaços se organizam em dois espaços ambientes. O espaço coluna e o espaço nulo à esquerda são subespaços de $\mathbb{R}^n$, enquanto o espaço linha e o espaço nulo são subespaços de $\mathbb{R}^p$.

3.3.8 Complemento ortogonal

Definição 3.15 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S . Essa definição permite descrever relações importantes entre os quatro espaços fundamentais de uma matriz.

3.3.9 Relações de ortogonalidade

Teorema 3.6 (Ortogonalidade entre os espaços fundamentais). *Para*


$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$



i Demonstração

Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{Ax} = \mathbf{0}.$$

Cada componente de $\mathbf{Ax}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, consequentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{Ax}$ é, portanto, igual a zero, de modo que

$$\mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

em $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

em $\mathbb{R}^n$.

A decomposição dos espaços ambientes em somas diretas desses pares será obtida posteriormente a partir do resultado geral sobre complementos ortogonais.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Além da geometria euclidiana, é possível definir outras geometrias atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Aprofundamento: produtos internos e geometrias induzidas

Leitura de aprofundamento

Esta subseção generaliza o produto interno euclidiano por meio de matrizes positivas definidas e apresenta as normas, distâncias e relações de ortogonalidade associadas a essa generalização. Esses conceitos serão retomados no estudo da distância de Mahalanobis, de geometrias determinadas por matrizes de covariâncias e de problemas de mínimos quadrados ponderados.

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.16 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Proposição 3.8 (Propriedades do produto interno induzido). *Para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$,*

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn; Johnson, 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.17 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.1.1 Norma e distância induzidas

Definição 3.17 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.18 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned} \|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{\begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}. \end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.1.2 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no capítulo anterior.

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^\top \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.1.3 Relação com a geometria euclidiana

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned} \langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}). \end{aligned}$$

Assim, o produto interno induzido por $\mathbf{M}$ pode ser interpretado como o produto interno euclidiano entre os vetores $\mathbf{C} \mathbf{x}$ e $\mathbf{C} \mathbf{y}$. Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma. Analogamente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}}$$

pode ser igual a zero mesmo quando $\mathbf{x} \neq \mathbf{y}$. Portanto, essa expressão define, em geral, uma **pseudodistância**.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.2 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.18 (Matriz de Gram). Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$ e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.19 (Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.3 Propriedades da matriz de Gram


Proposição 3.9 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$.

(Horn; Johnson, 2013)



i Demonstração

A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0.\end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.
Além disso,

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = 0$$

se, e somente se,

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Portanto, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V} \mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$.

Para demonstrar a igualdade dos núcleos, suponha inicialmente que

$$\mathbf{V}^\top \mathbf{V} \mathbf{c} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{c}^\top$,

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \stackrel{193}{=} \|\mathbf{V} \mathbf{c}\|^2 = 0.$$

Logo,

$$\mathbf{V} \mathbf{c} = \mathbf{0},$$

e, portanto,

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são linearmente dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.4 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.20 (Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.5 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela [3.2](#) resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij} x_{ik}$
$\mathbf{X} \mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.4.6 Propriedades do complemento ortogonal

O complemento ortogonal, introduzido anteriormente na descrição dos espaços fundamentais de uma matriz, será agora estudado para um subespaço arbitrário de $\mathbb{R}^p$.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k \right\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Proposição 3.10 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

i Demonstração

O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$(\alpha \mathbf{x} + \beta \mathbf{y})^\top \mathbf{s} = \alpha \mathbf{x}^\top \mathbf{s} + \beta \mathbf{y}^\top \mathbf{s} = 0.$$

Portanto,

$$\alpha \mathbf{x} + \beta \mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$.

Exemplo 3.21 (Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$


Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.4.7 Dimensão do complemento ortogonal

Proposição 3.11 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$



i Demonstração

Seja

$$\dim(S) = k.$$

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Pelo Teorema 3.4, essa base de S pode ser completada para formar uma base de $\mathbb{R}^p$. Aplicando o processo de Gram–Schmidt aos vetores acrescentados, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k + 1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

e, portanto,

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Outra consequência importante é

$$(S^\perp)^\perp = S.$$

De fato,

$$S \subseteq (S^\perp)^\perp,$$

pois todo vetor de S é ortogonal a todos os vetores de $S^\perp$. Além disso,

$$\begin{aligned} \dim\left((S^\perp)^\perp\right) &= p - \dim(S^\perp) \\ &= p - (p - k) \\ &= k \\ &= \dim(S). \end{aligned}$$

Como um subespaço está contido no outro e ambos possuem a mesma dimensão,

$$(S^\perp)^\perp = S.$$

3.4.8 Decomposição ortogonal

Teorema 3.7 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

O símbolo $\oplus$ representa uma **soma direta**: cada vetor de $\mathbb{R}^p$ possui uma única decomposição como soma de um vetor pertencente a S e um vetor pertencente a $S^\perp$.



i Demonstração

Pelo Teorema 3.2, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned} \mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\ &= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\ &= 0. \end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

A decomposição separa $\mathbf{x}$ em duas componentes únicas: $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$. Na seção seguinte, veremos que $\mathbf{x}_S$ é precisamente a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.4.9 Decomposição dos espaços fundamentais

A decomposição ortogonal pode ser aplicada diretamente aos quatro espaços fundamentais de uma matriz.

Proposição 3.12 (Decomposição dos espaços fundamentais). *Para uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$,*

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

De fato, pelo Teorema 3.6,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

Aplicando o Teorema 3.7,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

com $\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$ e $\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A})$.

Analogamente,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

e, portanto,

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}^\top},$$

com $\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$ e $\mathbf{y}_{\mathcal{N}^\top} \in \mathcal{N}(\mathbf{A}^\top)$.

Os quatro espaços fundamentais formam, portanto, dois pares de subespaços ortogonais complementares: um em $\mathbb{R}^p$ e outro em $\mathbb{R}^n$.

3.5 Projeções ortogonais

O Teorema 3.7 estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor $\mathbf{x} \in \mathbb{R}^p$ admite uma decomposição única em uma componente pertencente a S e outra pertencente a $S^\perp$. Essa decomposição permite definir a projeção ortogonal sobre um subespaço.

Definição 3.19 (Projeção ortogonal). Seja S um subespaço de $\mathbb{R}^p$. Pela decomposição ortogonal, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

com $\mathbf{x}_S \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

A **projeção ortogonal de $\mathbf{x}$ sobre S** é definida por

$$\text{proj}_S(\mathbf{x}) = \mathbf{x}_S.$$

Consequentemente,

$$\mathbf{x} - \text{proj}_S(\mathbf{x}) \in S^\perp.$$

A forma da projeção depende de como o subespaço S é representado. Começaremos pelo caso mais simples, em que S possui dimensão 1.

3.5.1 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Proposição 3.13 (Projeção sobre uma direção). *Se*

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

então a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Como $\mathbf{u}^\top \mathbf{x}$ é um escalar, pode-se escrever

$$\frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}).$$

Pela associatividade da multiplicação matricial,

$$\mathbf{u} (\mathbf{u}^\top \mathbf{x}) = (\mathbf{u} \mathbf{u}^\top) \mathbf{x}.$$

Portanto,

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} = \frac{1}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} (\mathbf{u}^\top \mathbf{x}) \\ &= \frac{1}{\mathbf{u}^\top \mathbf{u}} (\mathbf{u} \mathbf{u}^\top) \mathbf{x} = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.22 (Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}. \end{aligned}$$

Assim,

$$\mathbf{P}_S \mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição e destaca a ortogonalidade entre a projeção e o resíduo.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.

3.5.2 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q} \mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q} \mathbf{Q}^\top \mathbf{x}.$$

Proposição 3.14 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Meyer, 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.23 (Projeção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projeção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.5.3 Projeção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subseção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A} \mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A} \mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Proposição 3.15 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre $\mathcal{C}(\mathbf{A})$ é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_\mathbf{A} \mathbf{x},$$

em que

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz $\mathbf{P}_\mathbf{A}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$, e não da base particular escolhida para representá-lo.

De fato, suponha que outra base do mesmo subespaço seja organizada em uma matriz

$$\mathbf{B} = \mathbf{A}\mathbf{R},$$

em que $\mathbf{R} \in \mathbb{R}^{k \times k}$ é invertível. Então

$$\begin{aligned} \mathbf{P}_\mathbf{B} &= \mathbf{B}(\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \\ &= \mathbf{A}\mathbf{R}(\mathbf{R}^\top \mathbf{A}^\top \mathbf{A}\mathbf{R})^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A}\mathbf{R}\mathbf{R}^{-1}(\mathbf{A}^\top \mathbf{A})^{-1}(\mathbf{R}^\top)^{-1} \mathbf{R}^\top \mathbf{A}^\top \\ &= \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_\mathbf{A}. \end{aligned}$$

Portanto, bases diferentes do mesmo subespaço produzem a mesma matriz de projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_\mathbf{A} = \mathbf{A}\mathbf{A}^\top.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_\mathbf{S} = \mathbf{Q}\mathbf{Q}^\top.$$

Portanto,

$$\mathbf{Q}\mathbf{Q}^\top$$

é o caso ortonormal da expressão geral

$$\mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Exemplo 3.24 (Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned} \mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\ &= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\ &= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.5.4 Propriedades da matriz de projeção

Proposição 3.16 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e


$$\mathbf{P}_\mathbf{A} = \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top,$$

então:

1. $\mathbf{P}_\mathbf{A}$ é simétrica;
2. $\mathbf{P}_\mathbf{A}$ é idempotente;
3. $\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})$;

$$4. \mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp} = \mathcal{N}(\mathbf{A}^{\top});$$

$$5. \text{posto}(\mathbf{P}_{\mathbf{A}}) = \text{posto}(\mathbf{A}) = k.$$



A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.5.5 Aprofundamento: projeção residual e complemento ortogonal

Leitura de aprofundamento

Esta seção desenvolve a matriz que projeta um vetor sobre o complemento ortogonal de um subespaço. Essa representação será retomada no estudo de mínimos quadrados, da Decomposição em Valores Singulares e do modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

com colunas linearmente independentes e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}} \mathbf{x}.$$

Definição 3.20 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,


$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Proposição 3.17 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
3. $\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$ e $\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}$;
4. $\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$;
5. $\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$;
6. se $\mathbf{A}$ possui posto k , então $\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k$.



3.5.6 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.8 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer, 2023)



i Demonstração

Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

$$\mathbf{y} = \hat{\mathbf{x}}.$$

Portanto, a projeção ortogonal pode ser caracterizada equivalentemente como

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Assim, projetar ortogonalmente $\mathbf{x}$ sobre S equivale a encontrar, entre todos os vetores pertencentes a S , aquele que está mais próximo de $\mathbf{x}$ segundo a distância euclidiana.

Quando $S = \mathcal{C}(\mathbf{A})$, com $\mathbf{A} \in \mathbb{R}^{p \times k}$, todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente, o problema de melhor aproximação pode ser escrito como

$$\hat{\mathbf{c}} \in \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor mais próximo de $\mathbf{x}$ em $\mathcal{C}(\mathbf{A})$ é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa formulação estabelece a ligação entre projeção ortogonal e mínimos quadrados. O desenvolvimento algébrico dessa relação é apresentado a seguir como aprofundamento.

3.5.7 Aprofundamento: projeções e mínimos quadrados

Leitura de aprofundamento

Esta seção desenvolve algebricamente a relação entre projeção ortogonal e mínimos quadrados. As equações normais, os resíduos, as matrizes de projeção e a pseudoinversa serão retomados na Decomposição em Valores Singulares e no modelo linear multivariado.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^k} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.8, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \operatorname{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.21 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\beta} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned}
\hat{\mathbf{b}} &= \mathbf{A}\hat{\beta} \\
&= \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\
&= \mathbf{P}_\mathbf{A} \mathbf{b},
\end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned}
\hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\
&= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\
&= \mathbf{M}_\mathbf{A} \mathbf{b}.
\end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Proposição 3.18 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub; Van Loan, 2013)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, o problema de mínimos quadrados pode possuir diferentes vetores de coeficientes que produzem o mesmo ajuste. Portanto, $\hat{\beta}$ pode não ser único.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$.

Utilizando a pseudoinversa de Moore–Penrose (ver Definição 2.17),

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

de modo que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^+.$$

A pseudoinversa foi introduzida no capítulo anterior. Sua construção por meio da Decomposição em Valores Singulares será desenvolvida posteriormente.

As projeções ponderadas podem ser obtidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será retomada no estudo de problemas de mínimos quadrados ponderados.

3.6 Síntese do capítulo

Os espaços vetoriais permitem organizar conjuntos de vetores que preservam as operações de adição e multiplicação por escalar. Dentro desses espaços, os subespaços representam estruturas lineares de menor dimensão, enquanto bases fornecem conjuntos de vetores linearmente independentes capazes de gerar todo o espaço considerado. Fixada uma base, cada vetor pode ser representado de maneira única por suas coordenadas nessa base.

A dimensão quantifica o número de direções independentes necessárias para representar um espaço. Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

essa ideia conduz aos quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}), \mathcal{L}(\mathbf{A}), \mathcal{N}(\mathbf{A}) \text{ e } \mathcal{N}(\mathbf{A}^\top).$$

Se $r = \text{posto}(\mathbf{A})$, suas dimensões são

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

As matrizes de Gram organizam produtos internos entre conjuntos de vetores. Para uma matriz $\mathbf{V}$,

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

é simétrica e semidefinida positiva, e sua estrutura permite relacionar produtos internos, independência linear e posto.

A decomposição ortogonal estabelece que, para qualquer subespaço $S \subseteq \mathbb{R}^p$, todo vetor pode ser escrito de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com $\text{proj}_S(\mathbf{x}) \in S$ e $\mathbf{x}_{S^\perp} \in S^\perp$.

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , a matriz de projeção é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Se $S = \mathcal{C}(\mathbf{A})$ e as colunas de $\mathbf{A}$ são linearmente independentes, a mesma projeção pode ser escrita como

$$\mathbf{P}_A = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção ortogonal possui ainda uma interpretação por otimização:

$$\text{proj}_S(\mathbf{x}) = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Essa propriedade estabelece a ligação entre geometria, projeções e problemas de mínimos quadrados.

As partes de aprofundamento generalizam a geometria euclidiana por meio de produtos internos induzidos por matrizes positivas definidas e desenvolvem a matriz de projeção residual, as equações normais, o caso de posto deficiente e a pseudoinversa. Esses resultados serão retomados quando sua utilização se tornar necessária nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- interpretar geração, dependência e independência linear;
- identificar bases e determinar dimensões;
- representar vetores por coordenadas em uma base;
- distinguir bases gerais, ortogonais e ortonormais;
- determinar e interpretar os quatro espaços fundamentais de uma matriz;
- relacionar posto, nulidade e dimensão;
- interpretar as relações de ortogonalidade entre os espaços fundamentais;
- construir e interpretar matrizes de Gram;
- determinar complementos ortogonais e decomposições ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar a projeção ortogonal como problema de melhor aproximação;
- reconhecer a relação geométrica entre projeções e mínimos quadrados.

No próximo capítulo, as matrizes serão estudadas como representações de transformações lineares entre espaços vetoriais. Os conceitos de base, dimensão, posto, espaços fundamentais e projeções desenvolvidos aqui permitirão interpretar como essas transformações atuam sobre vetores e subespaços. O espaço nulo e o espaço coluna também serão relacionados, nesse novo contexto, ao núcleo e à imagem da transformação associada a uma matriz.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada **transformação linear**.

No capítulo anterior, o espaço nulo e o espaço coluna foram definidos diretamente a partir de uma matriz. Neste capítulo, essas estruturas serão também interpretadas, respectivamente, como o núcleo e a imagem da transformação linear associada à matriz.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

Convenções para transformações lineares

As convenções vetoriais e matriciais estabelecidas nos capítulos anteriores permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $T : V \rightarrow W$ representa uma transformação entre os espaços vetoriais V e W ;
- V representa o domínio e W o contradomínio da transformação;
- $\mathbf{x} \in V$ representa um vetor do domínio e $T(\mathbf{x}) \in W$ sua imagem pela transformação;
- $T_{\mathbf{A}}$ representa a transformação linear associada à matriz $\mathbf{A}$;
- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ quando utilizada na forma $T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}$;
- $\ker(T)$ representa o núcleo de uma transformação linear;
- $\text{Im}(T)$ representa a imagem de uma transformação linear;
- $\mathcal{E}_p$ representa a base canônica de $\mathbb{R}^p$;
- $[T]_{\mathcal{C} \leftarrow \mathcal{B}}$ representa a matriz de uma transformação em relação a uma base $\mathcal{B}$ do domínio e a uma base $\mathcal{C}$ do contradomínio.

As relações entre essas notações e os espaços fundamentais das matrizes serão estabelecidas ao longo do capítulo.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha\mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

Proposição 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

i Demonstração

Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned} T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\ &= T(\mathbf{u}) + T(-\mathbf{v}) \\ &= T(\mathbf{u}) - T(\mathbf{v}). \end{aligned}$$

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Proposição 4.2 (Determinação de uma transformação por uma base). *Seja V um espaço vetorial de dimensão finita e seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_k).$$

(Meyer, 2023)

i Demonstração

Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \cdots + c_k \mathbf{v}_k.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \cdots + c_k T(\mathbf{v}_k).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio fica determinada de maneira única.

Exemplo 4.1 (Transformação determinada pelas imagens de uma base). Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned} T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\ &= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}. \end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Portanto, a matriz que representa T na base canônica é

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix},$$

cujas colunas são precisamente

$$T(\mathbf{e}_1) \quad \text{e} \quad T(\mathbf{e}_2).$$

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \cdots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned}
T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \cdots + x_p T(\mathbf{e}_p) \\
&= x_1 \mathbf{a}_1 + \cdots + x_p \mathbf{a}_p \\
&= \mathbf{A}\mathbf{x}.
\end{aligned}$$

Isso estabelece a existência de uma matriz que representa T nas bases canônicas.

Para verificar a unicidade, suponha que outra matriz

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

também satisfaça

$$T(\mathbf{x}) = \mathbf{C}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Aplicando essa igualdade aos vetores da base canônica,

$$\mathbf{C}\mathbf{e}_j = T(\mathbf{e}_j) = \mathbf{A}\mathbf{e}_j, \quad j = 1, \dots, p.$$

Como $\mathbf{A}\mathbf{e}_j$ e $\mathbf{C}\mathbf{e}_j$ correspondem, respectivamente, às j -ésimas colunas de $\mathbf{A}$ e $\mathbf{C}$, todas as colunas das duas matrizes são iguais. Portanto,

$$\mathbf{C} = \mathbf{A}.$$

A matriz representante de T nas bases canônicas é, assim, única.

Proposição 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

(Meyer, 2023)

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned} T_{\mathbf{A}}(\alpha \mathbf{u} + \beta \mathbf{v}) &= \mathbf{A}(\alpha \mathbf{u} + \beta \mathbf{v}) \\ &= \alpha \mathbf{A}\mathbf{u} + \beta \mathbf{A}\mathbf{v} \\ &= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}). \end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Núcleo e imagem de uma transformação linear

Dois subespaços descrevem aspectos fundamentais da ação de uma transformação linear: os vetores do domínio que são enviados ao vetor nulo e os vetores do contradomínio que podem ser obtidos pela transformação.

Definição 4.2 (Núcleo e imagem de uma transformação linear). Seja

$$T : V \longrightarrow W$$

uma transformação linear.

O **núcleo** de T é o conjunto

$$\ker(T) = \{\mathbf{x} \in V : T(\mathbf{x}) = \mathbf{0}\}.$$

A **imagem** de T é o conjunto

$$\text{Im}(T) = \{T(\mathbf{x}) : \mathbf{x} \in V\}.$$

O núcleo é um subespaço do domínio V , enquanto a imagem é um subespaço do contradomínio W .

Para a transformação matricial

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax},$$

o núcleo é

$$\begin{aligned}\ker(T_{\mathbf{A}}) &= \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\} \\ &= \mathcal{N}(\mathbf{A}),\end{aligned}$$

e a imagem é

$$\begin{aligned}\text{Im}(T_{\mathbf{A}}) &= \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^p\} \\ &= \mathcal{C}(\mathbf{A}).\end{aligned}$$

Relação com os subespaços associados a uma matriz

O **espaço nulo** e o **espaço coluna** estudados no capítulo anterior correspondem, respectivamente, ao **núcleo** e à **imagem** da transformação linear associada à matriz $\mathbf{A}$:

$$\mathcal{N}(\mathbf{A}) = \ker(T_{\mathbf{A}}), \quad \mathcal{C}(\mathbf{A}) = \text{Im}(T_{\mathbf{A}}).$$

Se

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

o **contradomínio** é $\mathbb{R}^q$, enquanto a imagem é o subespaço efetivamente alcançado pela transformação,

$$\text{Im}(T_{\mathbf{A}}) \subseteq \mathbb{R}^q.$$

4.1.4 Imagem de um subespaço

Considere um subespaço

$$S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \dots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Proposição 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

i Demonstração

A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A}\mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X}\mathbf{A}^\top.$$

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q].$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q].$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}_{\cdot j} = \mathbf{X}\mathbf{w}_j.$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip}.$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.2 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix}.$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\ &= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\ &= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}. \end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}. \end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}_{.1} = \mathbf{x}_{.1} + \mathbf{x}_{.2}.$$

A segunda é

$$\mathbf{y}_{.2} = 2\mathbf{x}_{.1} - \mathbf{x}_{.2}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, todas as observações transformadas pertencem a um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Assim, a dimensão da configuração transformada não pode exceder $\text{posto}(\mathbf{A})$, embora possa ser menor, dependendo da configuração original dos dados.

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando $r < p$, a transformação possui núcleo não trivial e elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, como a transformação modifica produtos internos, comprimentos e distâncias. Quando $\mathbf{A}$ possui posto completo nas colunas, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e determina um produto interno no domínio. Quando $\mathbf{A}$ não possui posto completo nas colunas, essa matriz é apenas semidefinida positiva e algumas direções são eliminadas pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A}\mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A}\mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A} \mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

para os quais

$$\|\mathbf{x}\|_{\mathbf{A}^\top \mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}^\top \mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_X = \mathbf{X}\mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top,$$

tem-se

$$\begin{aligned}\mathbf{G}_Y &= \mathbf{Y}\mathbf{Y}^\top \\ &= \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.\end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Proposição 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{BA}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{XA}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{YB}^\top \\ &= \mathbf{XA}^\top \mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

A ordem de aplicação das transformações é importante. Quando duas transformações atuam sobre o mesmo espaço,

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e

$$T_2 : \mathbb{R}^p \longrightarrow \mathbb{R}^p,$$

representadas, respectivamente, por

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{p \times p},$$

as duas composições

$$T_2 \circ T_1$$

e

$$T_1 \circ T_2$$

estão definidas. Suas matrizes representantes são, respectivamente,

$$\mathbf{BA}$$

e

$$\mathbf{AB}.$$

Como a multiplicação de matrizes não é, em geral, comutativa,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente, em geral,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

A igualdade pode ocorrer para transformações particulares, mas não constitui uma propriedade geral da composição.

Exemplo 4.3 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.3 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Proposição 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

i Demonstração

Tem-se

$$\begin{aligned} (\mathbf{BA})(\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B}(\mathbf{AA}^{-1})\mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1})(\mathbf{BA}) &= \mathbf{A}^{-1}(\mathbf{B}^{-1}\mathbf{B})\mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.4 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Proposição 4.7 (Caracterizações por núcleo, imagem e posto). *Seja*

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

com $\mathbf{A} \in \mathbb{R}^{q \times p}$. Então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$


3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

(Meyer, 2023)



i Demonstração

Suponha inicialmente que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{Ax}_1 = \mathbf{Ax}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema 3.5,

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando a Proposição 4.7 com o Teorema 2.5, obtém-se o resultado seguinte.

Proposição 4.8 (Equivalências para uma transformação linear associada a uma matriz quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $T_{\mathbf{A}}$ é invertível;
5. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
6. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
7. $\text{posto}(\mathbf{A}) = p$;
8. $\det(\mathbf{A}) \neq 0$;
9. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \ker(T_{\mathbf{A}}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \ker(T_{\mathbf{A}})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo núcleo da transformação, que coincide com o espaço nulo da matriz associada.

Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

O espaço nulo possui dimensão $p - r$. Portanto, existem $p - r$ direções linearmente independentes no domínio que são anuladas pela transformação, enquanto a imagem possui dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar

$$\text{posto}(\mathbf{A})$$

como a dimensão da imagem da transformação, isto é, como o número máximo de direções linearmente independentes que podem compor o espaço transformado. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam a posição da configuração em relação aos eixos coordenados sem deformar sua geometria, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;
- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}_\theta \mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}_\theta^\top \mathbf{Q}_\theta = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}_\theta^{-1} = \mathbf{Q}_\theta^\top = \mathbf{Q}_{-\theta}.$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto. Além disso,

$$\det(\mathbf{Q}_\theta) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada **reflexão de Householder**.

Observe que as duas construções preservam componentes diferentes. A matriz $2\mathbf{u}\mathbf{u}^\top - \mathbf{I}$ preserva a componente na direção de $\mathbf{u}$ e inverte as componentes ortogonais a ela, enquanto $\mathbf{I} - 2\mathbf{u}\mathbf{u}^\top$ preserva as componentes ortogonais a $\mathbf{u}$ e inverte a componente na direção de $\mathbf{u}$.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é reescalada por um fator próprio, de modo que comprimentos, ângulos e proporções podem ser alterados. Se algum fator

s_j for negativo, além da alteração de escala ocorre a inversão do sentido da coordenada correspondente.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned}y_1 &= x_1 + kx_2, \\y_2 &= x_2.\end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det(\mathbf{C}_{ij}(k)) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

As projeções ortogonais foram desenvolvidas no capítulo anterior a partir da decomposição de um vetor em componentes pertencentes a subespaços ortogonais. Aqui, interessa interpretá-las como transformações lineares.

Considere uma direção unitária

$$\mathbf{u} \in \mathbb{R}^p, \quad \|\mathbf{u}\| = 1,$$

e o subespaço

$$S = \text{span}\{\mathbf{u}\}.$$

A matriz da projeção ortogonal sobre S é

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top,$$

de modo que

$$T_{\mathbf{P}_S}(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

Como estudado no capítulo anterior,

$$\mathbf{P}_S^2 = \mathbf{P}_S$$

e

$$\mathbf{P}_S^\top = \mathbf{P}_S.$$

Do ponto de vista das transformações lineares,

$$\text{Im}(T_{\mathbf{P}_S}) = S$$

e

$$\ker(T_{\mathbf{P}_S}) = S^\perp.$$

Assim, a projeção preserva a componente pertencente a S e elimina toda a componente pertencente a $S^\perp$.

Para uma projeção sobre uma única direção,

$$\text{posto}(\mathbf{P}_S) = 1.$$

Consequentemente, quando $p > 1$,

$$\det(\mathbf{P}_S) = 0,$$

e a transformação não é invertível. Vetores que diferem apenas por uma componente pertencente a $S^\perp$ possuem a mesma imagem.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário. Como todos os painéis utilizam a mesma escala, alterações de forma, área e dimensão podem ser comparadas diretamente.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

A rotação altera a posição do quadrado em relação aos eixos coordenados sem modificar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme modifica os comprimentos nas direções coordenadas e transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área, mostrando que preservar área não implica preservar ângulos ou comprimentos. A projeção elimina uma direção e reduz a figura a um segmento de reta.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Proposição 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$E \subseteq \mathbb{R}^p$$

um conjunto mensurável com volume p -dimensional finito. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se

$$\det(\mathbf{A}) = 0,$$

então

$$\text{posto}(\mathbf{A}) < p,$$

de modo que a imagem $\mathbf{A}E$ está contida em um subespaço próprio de $\mathbb{R}^p$. Consequentemente,

$$\text{Vol}_p(\mathbf{A}E) = 0.$$

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

Quando a transformação é invertível, o sinal do determinante descreve o efeito sobre a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida.

Se $\det(\mathbf{A}) = 0$, a transformação não é invertível, sua imagem possui dimensão inferior a p e o volume p -dimensional é reduzido a zero.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}_\theta$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Reescala direções coordenadas
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.18, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Proposição 4.10 (Preservação da geometria euclidiana). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, a transformação*

$$T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x}$$

preserva:

1. o produto interno;
2. as normas;
3. as distâncias euclidianas;
4. os ângulos entre vetores não nulos;
5. a ortogonalidade.

i Demonstração

Pelo Teorema 2.7,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Portanto, o produto interno entre quaisquer dois vetores é preservado. Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2.\end{aligned}$$

Como as normas são não negativas,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned}\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|.\end{aligned}$$

Logo, todas as distâncias euclidianas entre pares de vetores são preservadas. Para vetores não nulos, o ângulo θ entre $\mathbf{x}$ e $\mathbf{y}$ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como o produto interno e as normas são preservados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados.

Em particular, se

$$\mathbf{x}^\top \mathbf{y} = 0,$$

então

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0,$$

e a ortogonalidade é preservada.

Assim, transformações ortogonais preservam integralmente as relações métricas determinadas pelo produto interno euclidiano. Elas podem alterar a orientação da configuração, mas não deformam sua geometria interna.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{XQ}^\top.$$

Proposição 4.11 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{XQ}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{YY}^\top = \mathbf{XX}^\top.$$

i Demonstração

Tem-se

$$\begin{aligned}\mathbf{YY}^\top &= (\mathbf{XQ}^\top)(\mathbf{XQ}^\top)^\top \\ &= \mathbf{XQ}^\top \mathbf{QX}^\top \\ &= \mathbf{XI}_p \mathbf{X}^\top \\ &= \mathbf{XX}^\top.\end{aligned}$$

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados não nulos.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Proposição 4.12 (Determinante de uma matriz ortogonal). *Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então*

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

Consequentemente,

$$|\det(\mathbf{Q})| = 1,$$

e a transformação preserva volumes p -dimensionais.

i Demonstração

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned} 1 &= \det(\mathbf{Q}^\top \mathbf{Q}) \\ &= \det(\mathbf{Q}^\top) \det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2. \end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Logo,

$$|\det(\mathbf{Q})| = 1.$$

No plano, a preservação do volume p -dimensional corresponde à preservação de áreas; em $\mathbb{R}^3$, corresponde à preservação de volumes.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij},$$

em que δ_{ij} é o delta de Kronecker definido no Capítulo 2. Portanto, as colunas de $\mathbf{Q}$ possuem norma unitária e são ortogonais duas a duas.

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também formam um conjunto ortonormal.

Uma matriz ortogonal admite, portanto, duas interpretações que devem ser distinguidas:

- como matriz de uma transformação linear que preserva a geometria euclidiana;
- como matriz cujas colunas constituem uma base ortonormal de $\mathbb{R}^p$.

Na primeira interpretação, a matriz atua sobre o vetor e modifica sua posição no espaço. Na segunda, seus vetores-coluna definem um sistema de coordenadas. A relação entre essas duas interpretações será desenvolvida na seção seguinte.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções inicialmente ortogonais. O marcador de ângulo reto identifica os casos em que a ortogonalidade é preservada.




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções inicialmente ortogonais.

A rotação e a reflexão mantêm a circunferência unitária e preservam o ângulo reto entre as duas direções. O escalonamento não uniforme transforma a circunferência em uma elipse; embora as duas direções coordenadas permaneçam ortogonais neste exemplo particular, seus comprimentos são alterados e a transformação não é ortogonal. O cisalhamento deforma a circunferência e também altera o ângulo entre as direções.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$, com a ordem dos vetores fixada. Como definido no capítulo anterior, a matriz formada pelos vetores da base é

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes, $\mathbf{B}$ é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Assim, $\mathbf{B}$ converte as coordenadas de $\mathbf{x}$ na base $\mathcal{B}$ em suas coordenadas na base canônica, enquanto $\mathbf{B}^{-1}$ realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{B}^{\top} \mathbf{B} = \mathbf{I}_p.$$

Logo,

$$\mathbf{B}^{-1} = \mathbf{B}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{\top} \mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{b}_p^\top \mathbf{x} \end{bmatrix},$$

de modo que cada coordenada é obtida pelo produto interno entre $\mathbf{x}$ e o vetor correspondente da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$,

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\},$$

e as respectivas matrizes

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p]$$

e

$$\mathbf{C} = [\mathbf{c}_1 \quad \dots \quad \mathbf{c}_p].$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{C}[\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{C}[\mathbf{x}]_{\mathcal{C}} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando à esquerda por $\mathbf{C}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.5 (Matriz de mudança de base). A **matriz de mudança de base de $\mathcal{B}$ para $\mathcal{C}$** é

$$\mathbf{C}^{-1}\mathbf{B}.$$

Ela transforma as coordenadas de um vetor na base $\mathcal{B}$ em suas coordenadas na base $\mathcal{C}$:

$$[\mathbf{x}]_{\mathcal{C}} = (\mathbf{C}^{-1}\mathbf{B}) [\mathbf{x}]_{\mathcal{B}}.$$

O sentido da conversão deve ser observado na ordem das matrizes:

$$\mathcal{B} \longrightarrow \mathcal{C} \quad \Longleftrightarrow \quad \mathbf{C}^{-1}\mathbf{B}.$$

No sentido contrário, a matriz de mudança de base é

$$\mathbf{B}^{-1}\mathbf{C}.$$

As duas matrizes são inversas entre si:

$$\mathbf{B}^{-1}\mathbf{C} = (\mathbf{C}^{-1}\mathbf{B})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio, com matriz

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p],$$

e seja $\mathcal{C}$ uma base do contradomínio, com matriz

$$\mathbf{C} = [\mathbf{c}_1 \quad \cdots \quad \mathbf{c}_q].$$

Como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}},$$

tem-se

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{C}^{-1}T(\mathbf{x}) \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{C}^{-1}\mathbf{A}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Proposição 4.13 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

A fórmula pode ser interpretada pela sequência das operações, da direita para a esquerda:

$$[\mathbf{x}]_{\mathcal{B}} \xrightarrow{\mathbf{B}} \mathbf{x} \xrightarrow{\mathbf{A}} T(\mathbf{x}) \xrightarrow{\mathbf{C}^{-1}} [T(\mathbf{x})]_{\mathcal{C}}.$$

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.4 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{C}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} [T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{C}^{-1} \mathbf{A} \mathbf{B} \\ &= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}. \end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio,

$$[T]_{\mathcal{B} \leftarrow \mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Quando conveniente, essa matriz será denotada abreviadamente por

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1} \mathbf{A} \mathbf{B}.$$

Definição 4.6 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{D}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Proposição 4.14 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{D}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{D} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{D}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{D}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{D}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

i Demonstração

Para o determinante,

$$\begin{aligned}\det(\mathbf{D}) &= \det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A}) \det(\mathbf{P}) \\ &= \det(\mathbf{A}).\end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned}\mathrm{tr}(\mathbf{D}) &= \mathrm{tr}(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) \\ &= \mathrm{tr}(\mathbf{A}\mathbf{P}\mathbf{P}^{-1}) \\ &= \mathrm{tr}(\mathbf{A}).\end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\mathrm{posto}(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) = \mathrm{posto}(\mathbf{A}).$$

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}_{\theta}$,

$$\mathbf{Q}_{\theta}^{-1} = \mathbf{Q}_{\theta}^{\top} = \mathbf{Q}(-\theta).$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$

Portanto, embora uma mesma matriz ortogonal possa aparecer nas duas interpretações, o sentido da operação é distinto: na transformação ativa, $\mathbf{Q}$ atua sobre o vetor; na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$, a conversão das coordenadas é realizada por $\mathbf{Q}^{-1} = \mathbf{Q}^{\top}$.

A Figura 4.7 compara as duas interpretações.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa por $\mathbf{Q}$	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base formada pelas colunas de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.7 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui dimensão $n \times q$ e contém n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

As dimensões da transformação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} + \underbrace{\mathbf{1}_n}_{n \times 1} \underbrace{\mathbf{b}^\top}_{1 \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned} \mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\ &= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\ &= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. Em contraste, a aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Além disso,

$$\mathbf{H}_n = \mathbf{H}_n^\top$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Portanto, $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

seu núcleo é

$$\mathcal{N}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\},$$

e sua imagem é o subespaço

$$\mathcal{C}(\mathbf{H}_n) = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{1}_n^\top \mathbf{z} = 0\} = \text{span}\{\mathbf{1}_n\}^\perp.$$

Assim, multiplicar uma variável observada por $\mathbf{H}_n$ equivale a projetá-la ortogonalmente sobre o subespaço dos vetores cujas componentes somam zero.

Como $\mathbf{H}_n$ é simétrica e

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{H}_n = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{1}_n^\top \mathbf{H}_n \mathbf{X} = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Proposição 4.15 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

i Demonstração

Tem-se

$$\begin{aligned}\mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j.\end{aligned}$$

Logo, as duas diferenças possuem a mesma norma.

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica, em geral, distâncias e ângulos. Alguns pares particulares de vetores podem manter sua relação angular, mas a geometria euclidiana não é preservada para todos os vetores. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada pela matriz positiva definida

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas. Quando todas as escalas são iguais, isto é,

$$\mathbf{L} = \ell \mathbf{I}_p,$$

o escalonamento é uniforme: todas as distâncias são multiplicadas pelo mesmo fator $1/\ell$ e os ângulos são preservados.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afim com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1, desde que todas as variáveis apresentem desvio-padrão amostral positivo.

A interpretação da padronização como transformação afim considera $\mathbf{m}$ e $\mathbf{L}$ fixados. Quando o vetor de médias e os desvios-padrão são calculados a partir da própria matriz de dados $\mathbf{X}$, esses elementos passam a depender dos dados. Nesse caso, para os valores calculados de $\mathbf{m}$ e $\mathbf{L}$, cada observação é submetida à transformação afim

$$\mathbf{x} \mapsto \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}),$$

mas a operação completa que associa a matriz original $\mathbf{X}$ à matriz padronizada $\mathbf{Z}$ é dependente dos dados e não constitui, globalmente, uma transformação afim de $\mathbf{X}$.

Para duas observações padronizadas,

$$\begin{aligned} \mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j). \end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x},$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1}\mathbf{m}.$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1}\mathbf{m}.$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim de $\mathbb{R}^p$ em $\mathbb{R}^p$ é invertível se, e somente se, sua parte linear $\mathbf{A}$ é invertível.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos. O mesmo vetor de escalas é utilizado no escalonamento e na padronização, permitindo separar visualmente o efeito da alteração de escala do efeito da centralização.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as diferenças nem as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e, em geral, modifica comprimentos, distâncias e ângulos. A padronização combina esses dois efeitos: centraliza a nuvem e reescala suas coordenadas.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão para um vetor	Linear como função de $\mathbf{x}$?	Mantém a origem fixa?
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalonamento	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares podem modificar direção, escala ou dimensão, mas mantêm necessariamente a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando consideradas como operações sobre uma observação individual e para parâmetros de localização e escala fixados. Quando a centralização de uma matriz de dados é escrita como $\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$, a operação é linear no espaço das matrizes.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Para uma transformação

$$T : V \longrightarrow W,$$

tem-se

$$T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica, entre outras consequências,

$$T(\mathbf{0}) = \mathbf{0},$$

e permite determinar uma transformação linear a partir de sua ação sobre uma base do domínio.

Fixadas as bases do domínio e do contradomínio, uma transformação linear possui uma representação matricial única. Em particular, nas bases canônicas, uma transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Quando as observações ocupam as linhas de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea das observações é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^{\top}.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada, enquanto cada coluna corresponde a uma combinação linear das variáveis originais.

A matriz associada à transformação permite relacionar os conceitos desenvolvidos neste capítulo aos espaços fundamentais estudados anteriormente:

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o núcleo reúne os vetores eliminados pela transformação, enquanto a imagem contém todos os vetores que podem ser produzidos por ela. Pelo teorema posto-nulidade,

$$\dim \ker(T_{\mathbf{A}}) + \dim \text{Im}(T_{\mathbf{A}}) = p,$$

ou, equivalentemente,

$$\dim \mathcal{N}(\mathbf{A}) + \text{posto}(\mathbf{A}) = p.$$

O posto é, portanto, a dimensão da imagem da transformação. Quando o núcleo contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem e ocorre perda de informação.

Para uma transformação quadrada, as condições

$$\ker(T_{\mathbf{A}}) = \{\mathbf{0}\},$$

$$\text{Im}(T_{\mathbf{A}}) = \mathbb{R}^p,$$

$$\text{posto}(\mathbf{A}) = p,$$

$$\det(\mathbf{A}) \neq 0$$

e a existência de $\mathbf{A}^{-1}$ são equivalentes.

A composição de transformações corresponde ao produto de suas matrizes. Se T_1 é representada por $\mathbf{A}_1$ e T_2 por $\mathbf{A}_2$, então

$$[T_2 \circ T_1] = \mathbf{A}_2 \mathbf{A}_1.$$

A matriz situada à direita atua primeiro. Como o produto matricial não é comutativo, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas ilustram diferentes efeitos possíveis sobre uma configuração. Rotações e reflexões são transformações ortogonais e preservam a geometria euclidiana. Escalonamentos alteram as escalas das direções coordenadas; cisalhamentos modificam, em geral, ângulos e comprimentos; projeções eliminam componentes pertencentes ao complemento do subespaço sobre o qual se projeta.

Para uma transformação quadrada,

$$|\det(\mathbf{A})|$$

representa o fator de alteração do volume p -dimensional. Quando $\det(\mathbf{A}) \neq 0$, seu sinal informa também o efeito sobre a orientação: valores positivos preservam a orientação e valores negativos a invertem. Se

$$\det(\mathbf{A}) = 0,$$

a transformação reduz a dimensão e o volume p -dimensional da imagem é igual a zero.

As transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos e, consequentemente, normas, distâncias, ângulos e ortogonalidade. Além disso,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) \in \{-1, 1\},$$

de modo que também preservam volumes p -dimensionais.

As colunas de uma matriz ortogonal formam uma base ortonormal e satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \delta_{ij}.$$

Essa propriedade estabelece a ligação entre transformações ortogonais e sistemas de coordenadas ortonormais.

Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

é uma base de $\mathbb{R}^p$ e

$$\mathbf{B} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_p],$$

então

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}.$$

Para duas bases $\mathcal{B}$ e $\mathcal{C}$, com matrizes $\mathbf{B}$ e $\mathbf{C}$, respectivamente, a conversão das coordenadas de $\mathcal{B}$ para $\mathcal{C}$ é

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Se uma transformação é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}.$$

Quando a mesma base é utilizada no domínio e no contradomínio,

$$\mathbf{A}_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{A}\mathbf{B},$$

de modo que as duas matrizes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa e a mudança passiva de coordenadas devem ser diferenciadas. Se $\mathbf{Q}$ é ortogonal, na transformação ativa,

$$\mathbf{y} = \mathbf{Q}\mathbf{x},$$

enquanto, na mudança passiva para a base formada pelas colunas de $\mathbf{Q}$,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top}\mathbf{x}.$$

Na primeira situação, o vetor é transformado em relação a eixos fixos. Na segunda, o vetor geométrico permanece o mesmo e apenas sua representação em coordenadas é alterada.

As transformações afins generalizam as transformações lineares por meio da inclusão de uma translação:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização de uma observação em torno de um vetor fixo é uma transformação afim, enquanto o escalonamento é uma transformação linear diagonal. A padronização combina essas duas operações.

Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n\mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Como

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

a matriz $\mathbf{H}_n$ é uma matriz de projeção ortogonal. Sua imagem é

$$\mathcal{C}(\mathbf{H}_n) = \text{span}\{\mathbf{1}_n\}^\perp,$$

o subespaço dos vetores cujas componentes somam zero.

A Tabela 4.6 reúne algumas das principais expressões desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top$	Transforma simultaneamente as observações
Núcleo	$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A})$	Reúne os vetores enviados ao vetor nulo
Imagem	$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})$	Reúne os vetores alcançados pela transformação
Composição	$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{A}_2 \mathbf{A}_1 \mathbf{x}$	Aplica T_1 antes de T_2
Transformação inversa	$\mathbf{x} = \mathbf{A}^{-1} \mathbf{y}$	Recupera o vetor original quando $\mathbf{A}$ é invertível
Rotação	$\mathbf{Q}_\theta \mathbf{x}$	Preserva a geometria e a orientação
Reflexão	$\mathbf{F} \mathbf{x}$	Preserva a geometria; seu efeito sobre a orientação é determinado pelo determinante
Escalonamento	$\mathbf{L} \mathbf{x}$	Reescala direções coordenadas

Objeto ou operação	Expressão	Interpretação
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração preservando volume no caso elementar
Projeção ortogonal	$\mathbf{P}_S\mathbf{x}$	Mantém a componente em S e elimina a componente em $S^\perp$
Coordenadas em uma base	$[\mathbf{x}]_{\mathcal{B}} = \mathbf{B}^{-1}\mathbf{x}$	Representa o mesmo vetor na base $\mathcal{B}$
Mudança de $\mathcal{B}$ para $\mathcal{C}$	$[\mathbf{x}]_{\mathcal{C}} = \mathbf{C}^{-1}\mathbf{B}[\mathbf{x}]_{\mathcal{B}}$	Converte coordenadas entre bases
Transformação em bases gerais	$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{C}^{-1}\mathbf{A}\mathbf{B}$	Representa a transformação nas bases escolhidas
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização dos dados	$\mathbf{X}_c = \mathbf{H}_n\mathbf{X}$	Projeta cada variável no subespaço de média zero
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

Ao final deste capítulo, o estudante deverá ser capaz de:

- reconhecer e verificar a linearidade de uma transformação;
- construir a matriz de uma transformação a partir da imagem de uma base;
- relacionar núcleo e imagem de uma transformação ao espaço nulo e ao espaço coluna da matriz associada;
- interpretar posto, injetividade, sobrejetividade, bijetividade e perda de informação;
- representar a composição e a inversão de transformações por operações matriciais;
- interpretar geometricamente rotações, reflexões, escalonamentos, cisalhamentos e projeções;
- relacionar o determinante à alteração de volume, à orientação e à redução de dimensão;
- reconhecer transformações ortogonais e interpretar as propriedades geométricas que elas preservam;
- converter coordenadas entre bases;
- representar uma transformação linear em bases distintas do domínio e do contradomínio;
- distinguir transformação ativa e mudança passiva de coordenadas;
- interpretar transformações afins, centralização, escalonamento e padronização;
- reconhecer a matriz de centralização como uma matriz de projeção ortogonal.

No próximo capítulo, serão estudadas direções especiais para as quais a ação de uma transformação linear produz um múltiplo escalar do próprio vetor,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Essas direções conduzem aos conceitos de autovetores, autovalores, autoespaços e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Vimos também que a matriz de um operador depende da base utilizada para representá-lo. Uma mudança de base pode produzir uma matriz mais simples, embora o operador linear permaneça o mesmo. Neste capítulo, procuraremos bases especialmente adaptadas à ação do operador.

Algumas direções possuem um comportamento particularmente simples: quando um vetor pertence a uma dessas direções, sua imagem permanece na mesma reta que passa pela origem. A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço.

Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. A diagonalização pode, portanto, ser interpretada como uma mudança para um sistema de coordenadas em que a transformação atua separadamente sobre cada direção da base.

Para matrizes simétricas reais, essa simplificação possui propriedades adicionais: todos os autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permitirá interpretar formas quadráticas, matrizes positivas definidas, elipsoides, funções de matrizes e problemas de otimização. Essas estruturas serão retomadas nos capítulos de SVD, covariâncias e técnicas multivariadas.

Convenções de notação

Ao longo deste capítulo:

- λ representa um autovalor;

- $\mathbf{v}$ representa um autovetor;
- $\mathcal{E}_\lambda$ representa o autoespaço associado a λ ;
- $m_a(\lambda)$ e $m_g(\lambda)$ representam, respectivamente, as multiplicidades algébrica e geométrica;
- $\mathcal{B}_\mathbf{A}$ representa uma base de autovetores de $\mathbf{A}$, quando tal base existe;
- $\mathbf{B}_\mathbf{A}$ representa a matriz formada pelos vetores da base $\mathcal{B}_\mathbf{A}$;
- $\Lambda_\mathbf{A}$ representa a matriz diagonal dos autovalores correspondente à ordenação escolhida dos autovetores;
- $\mathbf{Q}_\mathbf{A}$ representa uma matriz ortogonal de autovetores quando $\mathbf{A}$ é simétrica;
- Π_λ representa o projetor espectral associado ao autoespaço de λ ;
- $\mathcal{R}_\mathbf{A}(\mathbf{x})$ representa o quociente de Rayleigh.

Salvo indicação contrária, as interpretações geométricas serão desenvolvidas em espaços vetoriais reais. Autovalores e autovetores complexos serão considerados explicitamente quando necessário.

5.1 Direções invariantes, autovalores e autoespaços

Definição 5.1 (Subespaço invariante). Considere

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p.$$

O subespaço $\mathcal{W}$ é **invariante sob $\mathbf{A}$** quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo

$$\mathbf{w} \in \mathcal{W}.$$

Isso significa que a multiplicação por $\mathbf{A}$ transforma vetores de $\mathcal{W}$ em vetores que permanecem no próprio subespaço $\mathcal{W}$.

Um caso particularmente importante ocorre quando o subespaço invariante possui dimensão 1.

Seja

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span}\{\mathbf{v}\} = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Como $\mathbf{v} \neq \mathbf{0}$, o conjunto $\{\mathbf{v}\}$ é uma base de $\mathcal{W}$ e, portanto,

$$\dim(\mathcal{W}) = 1.$$

Geometricamente, $\mathcal{W}$ corresponde a uma reta que passa pela origem e está contida em $\mathbb{R}^p$.

Se $\mathcal{W}$ é invariante sob $\mathbf{A}$, então

$$\mathbf{A}\mathbf{v} \in \mathcal{W}.$$

Como todos os vetores de $\mathcal{W}$ são múltiplos escalares de $\mathbf{v}$, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Assim, a ação de $\mathbf{A}$ sobre $\mathbf{v}$ mantém sua imagem na mesma reta gerada por $\mathbf{v}$. A magnitude pode ser alterada e, dependendo do sinal de λ , também pode ocorrer mudança de sentido.

Exemplo 5.1 (Uma reta invariante em $\mathbb{R}^2$). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

e o vetor

$$\mathbf{v} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O subespaço gerado por $\mathbf{v}$ é

$$\mathcal{W} = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\},$$

que corresponde à reta

$$x_2 = x_1$$

em $\mathbb{R}^2$.

Aplicando $\mathbf{A}$ ao vetor $\mathbf{v}$,

$$\begin{aligned} \mathbf{A}\mathbf{v} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= 3\mathbf{v}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v} \in \mathcal{W},$$

e a reta $\mathcal{W}$ é invariante sob $\mathbf{A}$. Nesse caso, a transformação multiplica os vetores dessa direção por um fator igual a 3, sem retirar suas imagens da reta.

A relação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

observada nesse caso conduz às definições de autovalor e autovetor.

Definição 5.2 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.2 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned}\mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{Ax} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$. As retas tracejadas em cinza representam as duas direções invariantes.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

Um autovetor não é único. Se $\mathbf{v}$ é um autovetor associado ao autovalor λ , então qualquer múltiplo não nulo de $\mathbf{v}$ também é um autovetor associado ao mesmo autovalor.

Proposição 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

i Demonstração

Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned}\mathbf{A}(c\mathbf{v}) &= c\mathbf{A}\mathbf{v} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}).\end{aligned}$$

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ .

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.3 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Proposição 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

i Demonstração

Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda\mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$.

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição do autoespaço transforma a busca por autovetores em um problema de núcleo. Para um valor fixado de λ , existem autovetores associados precisamente quando

$$\mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p) \neq \{\mathbf{0}\}.$$

Resta, portanto, determinar quais valores de λ tornam esse núcleo não trivial. Essa condição equivale à singularidade de $\mathbf{A} - \lambda \mathbf{I}_p$ e conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo.

Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.1 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

i Demonstração

Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$.

Definição 5.4 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn; Johnson, 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ($\theta = \frac{\pi}{2}$),

$$\mathbf{Q}_{\frac{\pi}{2}} = \begin{bmatrix} \cos(\frac{\pi}{2}) & -\sin(\frac{\pi}{2}) \\ \sin(\frac{\pi}{2}) & \cos(\frac{\pi}{2}) \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovalores reais e, conseqüentemente, não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando a mesma matriz é considerada como um operador em $\mathbb{C}^2$, ela possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente no contexto real. Em particular, toda matriz simétrica real possui autovalores reais e admite uma base ortonormal de autovetores reais.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.2 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

i Demonstração

A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \cdots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes.

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.5 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Exemplo 5.3 (Mesma multiplicidade algébrica e diferentes multiplicidades geométricas). Considere as matrizes

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Polinômio característico e multiplicidade algébrica

Para $\mathbf{A}_1$,

$$\begin{aligned} p_{\mathbf{A}_1}(\lambda) &= \det(\mathbf{A}_1 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Para $\mathbf{A}_2$,

$$\begin{aligned} p_{\mathbf{A}_2}(\lambda) &= \det(\mathbf{A}_2 - \lambda \mathbf{I}_2) \\ &= \det \begin{bmatrix} 2 - \lambda & 1 \\ 0 & 2 - \lambda \end{bmatrix} \\ &= (2 - \lambda)^2. \end{aligned}$$

Portanto, as duas matrizes possuem o mesmo polinômio característico,

$$p(\lambda) = (2 - \lambda)^2,$$

e, conseqüentemente, o mesmo autovalor,

$$\lambda = 2.$$

Como o fator $(2 - \lambda)$ aparece duas vezes no polinômio característico, o autovalor $\lambda = 2$ possui multiplicidade algébrica

$$m_a(2) = 2$$

para ambas as matrizes.

Autoespaço de $\mathbf{A}_1$

Para determinar o autoespaço associado a $\lambda = 2$, procuramos todos os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$\mathbf{A}_1 \mathbf{v} = 2\mathbf{v}.$$

Essa equação pode ser escrita como

$$(\mathbf{A}_1 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando a matriz,

$$\begin{aligned}\mathbf{A}_1 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.\end{aligned}$$

Assim, o sistema a ser resolvido é

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

ou seja,

$$\begin{cases} 0 = 0, \\ 0 = 0. \end{cases}$$

O sistema não impõe nenhuma restrição sobre v_1 e v_2 . Portanto, ambos são livres e qualquer vetor de $\mathbb{R}^2$ pertence ao espaço nulo de $\mathbf{A}_1 - 2\mathbf{I}_2$.

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_1 - 2\mathbf{I}_2) = \mathbb{R}^2.$$

Como

$$\dim(\mathbb{R}^2) = 2,$$

temos

$$m_g(2) = \dim(E_2) = 2.$$

Assim, todo vetor não nulo de $\mathbb{R}^2$ é um autovetor de $\mathbf{A}_1$ associado ao autovalor $\lambda = 2$.

Autoespaço de $\mathbf{A}_2$

Para $\mathbf{A}_2$, procuramos novamente os vetores

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

que satisfazem

$$(\mathbf{A}_2 - 2\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Calculando,

$$\begin{aligned} \mathbf{A}_2 - 2\mathbf{I}_2 &= \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Efetuada a multiplicação,

$$\begin{bmatrix} v_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

o que corresponde ao sistema

$$\begin{cases} v_2 = 0, \\ 0 = 0. \end{cases}$$

Nesse caso, v_2 deve ser igual a zero, enquanto v_1 permanece livre. Assim, todo vetor do autoespaço possui a forma

$$\mathbf{v} = \begin{bmatrix} v_1 \\ 0 \end{bmatrix} = v_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo,

$$E_2 = \mathcal{N}(\mathbf{A}_2 - 2\mathbf{I}_2) = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}.$$

Esse autoespaço possui uma única direção linearmente independente. Portanto,

$$m_g(2) = \dim(E_2) = 1.$$

As duas matrizes possuem, portanto, o mesmo autovalor $\lambda = 2$ e a mesma multiplicidade algébrica,

$$m_a(2) = 2,$$

mas apresentam multiplicidades geométricas diferentes:

$$m_g(2) = \begin{cases} 2, & \text{para } \mathbf{A}_1, \\ 1, & \text{para } \mathbf{A}_2. \end{cases}$$

A diferença decorre da dimensão dos respectivos autoespaços. Para $\mathbf{A}_1$, o autoespaço é todo o plano $\mathbb{R}^2$; para $\mathbf{A}_2$, o autoespaço é apenas a reta gerada por $(1, 0)^\top$.

A Figura 5.2 compara as estruturas dos dois autoespaços.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

No capítulo anterior, vimos que a matriz de um operador depende da base utilizada para representá-lo. A diagonalização corresponde à escolha de uma base particularmente conveniente: uma base formada por autovetores.

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e suponha que exista uma base de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

A matriz dessa base é

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Como os vetores da base são linearmente independentes, $\mathbf{B}_{\mathbf{A}}$ é invertível.

Se

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j, \quad j = 1, \dots, p,$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

então

$$\mathbf{A}\mathbf{B}_{\mathbf{A}} = \mathbf{B}_{\mathbf{A}}\Lambda_{\mathbf{A}}.$$

Multiplicando à esquerda por $\mathbf{B}_{\mathbf{A}}^{-1}$,

$$\mathbf{B}_{\mathbf{A}}^{-1}\mathbf{A}\mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Definição 5.6 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existe uma base $\mathcal{B}_{\mathbf{A}}$ de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Equivalentemente, existem uma matriz invertível $\mathbf{B}_{\mathbf{A}}$ e uma matriz diagonal $\Lambda_{\mathbf{A}}$ tais que

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A ordem das colunas de $\mathbf{B}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Pela notação de mudança de base desenvolvida no capítulo anterior,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}}.$$

Assim, $\Lambda_{\mathbf{A}}$ é a matriz do mesmo operador quando tanto o domínio quanto o contradomínio são representados na base de autovetores.

Para qualquer vetor $\mathbf{x} \in \mathbb{R}^p$, suas coordenadas nessa base são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{x},$$

de modo que

$$\mathbf{x} = \mathbf{B}_{\mathbf{A}} \mathbf{z}.$$

Nas coordenadas da base de autovetores,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}} [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Como

$$\Lambda_{\mathbf{A}} \mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix},$$

a transformação atua separadamente sobre cada coordenada: a componente correspondente ao autovetor $\mathbf{v}_j$ é multiplicada por λ_j .

A diagonalização é, portanto, uma mudança para um sistema de coordenadas no qual as direções da base são invariantes e a ação do operador deixa de misturar coordenadas.

Teorema 5.3 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

- 1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;*
- 2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;*
- 3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. a soma das dimensões dos autoespaços é igual a p ;*
- 5. para cada autovalor λ ,*

$$m_g(\lambda) = m_a(\lambda).$$

(Horn; Johnson, 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.2 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{B}_\mathbf{A}^{-1} \\ &= \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{B}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{B}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{B}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Assim, a aplicação repetida do operador pode ser analisada coordenada a coordenada na base de autovetores: após k aplicações, a coordenada associada a $\mathbf{v}_j$ é multiplicada por λ_j^k .

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.4 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

- 1. todos os autovalores de $\mathbf{A}$ são reais;*
- 2. autoespaços associados a autovalores distintos são ortogonais;*
- 3. existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
- 4. existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_\mathbf{A} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

(Horn; Johnson, 2013)



A representação

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela é uma diagonalização ortogonal.

Considere a base ortonormal de autovetores

$$\mathcal{B}_\mathbf{A} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\}.$$

A matriz dessa base é

$$\mathbf{Q}_\mathbf{A} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p].$$

Assim, no caso simétrico, a matriz da base de autovetores introduzida na seção anterior pode ser escolhida ortogonal:

$$\mathbf{B}_\mathbf{A} = \mathbf{Q}_\mathbf{A},$$

com

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top.$$

Pela notação de coordenadas desenvolvida no capítulo anterior,

$$[\mathbf{x}]_{\mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{x}.$$

Denotando

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_\mathbf{A}},$$

tem-se

$$\mathbf{x} = \mathbf{Q}_\mathbf{A} \mathbf{z}.$$

A matriz do operador nessa base é

$$[T_\mathbf{A}]_{\mathcal{B}_\mathbf{A} \leftarrow \mathcal{B}_\mathbf{A}} = \mathbf{Q}_\mathbf{A}^\top \mathbf{A} \mathbf{Q}_\mathbf{A} = \Lambda_\mathbf{A}.$$

Consequentemente,

$$[T_{\mathbf{A}}(\mathbf{x})]_{\mathcal{B}_{\mathbf{A}}} = \Lambda_{\mathbf{A}}[\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}}.$$

Em coordenadas canônicas,

$$\begin{aligned}\mathbf{Ax} &= \mathbf{Q}_{\mathbf{A}}\Lambda_{\mathbf{A}}\mathbf{Q}_{\mathbf{A}}^{\top}\mathbf{x} \\ &= \mathbf{Q}_{\mathbf{A}}\Lambda_{\mathbf{A}}\mathbf{z}.\end{aligned}$$

A ação da matriz pode ser interpretada em três etapas:

1. $\mathbf{Q}_{\mathbf{A}}^{\top}$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. $\Lambda_{\mathbf{A}}$ multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_{\mathbf{A}}$ reconstrói o vetor nas coordenadas canônicas.

Assim, uma matriz simétrica atua por fatores escalares independentes em direções ortogonais. Quando algum autovalor é negativo, o escalonamento na direção correspondente inclui também a inversão do sentido.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.4 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{q}_1, \mathbf{q}_2\}$$

é uma base ortonormal de autovetores de $\mathbb{R}^2$.

A matriz dessa base é a matriz ortogonal

$$\mathbf{Q}_{\mathbf{A}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_{\mathbf{A}} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a circunferência unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por fatores escalares independentes.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária em $\mathbb{R}^p$ são determinados por

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Proposição 5.3 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovaleores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn; Johnson, 2013)

i Demonstração

As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Proposição 3.16, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned} \Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h \mathbf{Q}_h^\top \mathbf{Q}_\ell \mathbf{Q}_\ell^\top \\ &= \mathbf{0}. \end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_\lambda = \mathbf{q} \mathbf{q}^\top.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_A$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \mapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top},$$

em que

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Proposição 5.4 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

i Demonstração

Pela propriedade cíclica do traço,

$$\begin{aligned}\operatorname{tr}(\mathbf{A}) &= \operatorname{tr}(\mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top) \\ &= \operatorname{tr}(\Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top \mathbf{Q}_\mathbf{A}) \\ &= \operatorname{tr}(\Lambda_\mathbf{A}) \\ &= \sum_{j=1}^p \lambda_j.\end{aligned}$$

Para o determinante,

$$\begin{aligned}\det(\mathbf{A}) &= \det(\mathbf{Q}_\mathbf{A}) \det(\Lambda_\mathbf{A}) \det(\mathbf{Q}_\mathbf{A}^\top) \\ &= \det(\Lambda_\mathbf{A}),\end{aligned}$$

pois

$$\det(\mathbf{Q}_\mathbf{A}) \det(\mathbf{Q}_\mathbf{A}^\top) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_\mathbf{A}$ são semelhantes, pois

$$\Lambda_\mathbf{A} = \mathbf{Q}_\mathbf{A}^\top \mathbf{A} \mathbf{Q}_\mathbf{A}.$$

Como a multiplicação à esquerda e à direita por matrizes invertíveis preserva o posto, $\mathbf{A}$ e $\Lambda_\mathbf{A}$ possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\operatorname{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned}\dim \mathcal{N}(\mathbf{A}) &= p - \operatorname{posto}(\mathbf{A}) \\ &= \#\{j : \lambda_j = 0\}.\end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos.

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Proposição 5.5 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top$$

é a decomposição espectral de uma matriz simétrica, então

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp,$$

ou, equivalentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

i Demonstração

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores associados a autovalores nulos são ortogonais aos autovetores associados a autovalores não nulos, e juntos formam uma base ortonormal de $\mathbb{R}^p$, os dois subespaços são complementos ortogonais.

O autoespaço associado ao autovalor zero reúne exatamente as direções eliminadas pela

transformação. Os autoespaços associados a autovalores não nulos constituem, em conjunto, a imagem da transformação.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.23, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são determinadas pelos sinais dos autovalores, enquanto o valor assumido para um vetor específico depende também de suas coordenadas espectrais $z_1, \dots, z_p$.

Exemplo 5.5 (Forma quadrática em coordenadas espectrais). Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 3 \quad \text{e} \quad \lambda_2 = 1,$$

com autovetores ortonormais associados

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{Q}_\mathbf{A} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda_\mathbf{A} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral de $\mathbf{A}$ é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Considere agora o vetor

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Nas coordenadas originais, a forma quadrática é

$$\begin{aligned} q_\mathbf{A}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 5 \\ 4 \end{bmatrix} \\ &= 14. \end{aligned}$$

Equivalentemente, escrevendo a forma quadrática em função das coordenadas originais,

$$q_{\mathbf{A}}(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 2x_2^2.$$

Observe a presença do produto cruzado $2x_1x_2$.

As coordenadas de $\mathbf{x}$ na base espectral são

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x}.$$

Como

$$\mathbf{Q}_{\mathbf{A}}^{\top} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{z} &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$z_1 = \frac{3}{\sqrt{2}} \quad \text{e} \quad z_2 = \frac{1}{\sqrt{2}}.$$

Nas coordenadas espectrais, a mesma forma quadrática é

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{z}^{\top} \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \lambda_1 z_1^2 + \lambda_2 z_2^2 \\ &= 3 \left(\frac{3}{\sqrt{2}} \right)^2 + 1 \left(\frac{1}{\sqrt{2}} \right)^2 \\ &= 3 \left(\frac{9}{2} \right) + \frac{1}{2} \\ &= 14. \end{aligned}$$

Assim, nas coordenadas espectrais,

$$q_{\mathbf{A}}(\mathbf{x}) = 3z_1^2 + z_2^2,$$

sem produtos cruzados. A mudança de coordenadas não altera o valor da forma quadrática; ela apenas a expressa em uma base na qual a matriz é diagonal.

Proposição 5.6 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn; Johnson, 2013)

i Demonstração

Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos.

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{(c/\lambda_j)} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.6 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^{\top} \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^{\top} \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^{\top} \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

O termo cruzado $2x_1x_2$ presente nas coordenadas canônicas desaparece nas coordenadas espectrais porque os eixos coordenados passam a coincidir com as direções principais da forma quadrática.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh

Definição 5.7 (Quociente de Rayleigh). Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$. O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma euclidiana de $\mathbf{a}$.

Quando $\mathbf{A}$ é definida positiva, a forma quadrática também pode ser escrita como

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{A}},$$

em que $\langle \cdot, \cdot \rangle_{\mathbf{A}}$ é o produto interno induzido por $\mathbf{A}$, definido em Definição 3.16.

A divisão por $\|\mathbf{a}\|^2$ remove o efeito da magnitude do vetor. Consequentemente, o quociente de Rayleigh depende da direção determinada por $\mathbf{a}$, e não de seu comprimento.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A} (c\mathbf{a})}{(c\mathbf{a})^\top (c\mathbf{a})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}). \end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

As coordenadas de $\mathbf{a}$ na base espectral são

$$\mathbf{z} = [\mathbf{a}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{a},$$

de modo que

$$\mathbf{a} = \mathbf{Q}_{\mathbf{A}} \mathbf{z}.$$

Como $\mathbf{Q}_{\mathbf{A}}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é, portanto, uma média ponderada dos autovalores. Para uma base espectral fixada, ω_j mede a proporção do comprimento ao quadrado de $\mathbf{a}$ associada à direção $\mathbf{q}_j$.

Quando um autovalor λ possui multiplicidade maior que 1, a quantidade intrínseca ao autoespaço correspondente é a soma dos pesos associados aos vetores de uma base ortonormal desse autoespaço. Essa soma é igual à proporção do comprimento ao quadrado da projeção de $\mathbf{a}$ sobre $\mathcal{E}_\lambda$.

Teorema 5.5 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço associado a λ_p . (Horn; Johnson, 2013)

i Demonstração

Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido.

Se o maior autovalor é simples, a reta que maximiza o quociente é

$$\text{span}\{\mathbf{q}_1\}.$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

Exemplo 5.7 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da circunferência unitária.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.

5.5.2 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição de norma separa a escolha da **direção** da escolha da magnitude do vetor. De fato,

$$(c\mathbf{a})^{\top} \mathbf{A} (c\mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}.$$

Portanto, sem uma normalização, o valor da forma quadrática pode ser alterado simplesmente pelo escalonamento do vetor, mesmo quando sua direção permanece a mesma.

Se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

o problema de maximização sem restrição é ilimitado superiormente. Analogamente, se existe uma direção para a qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} < 0,$$

o problema de minimização sem restrição é ilimitado inferiormente.

A condição

$$\mathbf{a}^{\top} \mathbf{a} = 1$$

elimina esse efeito de escala e restringe a otimização às direções representadas por vetores unitários.

5.5.3 Multiplicadores de Lagrange

Em diferentes problemas da Estatística Multivariada, procura-se uma **direção** no espaço das variáveis que torne máxima ou mínima alguma quantidade de interesse. Essa quantidade pode representar, por exemplo, variabilidade, separação entre grupos ou associação entre conjuntos de variáveis.

Uma direção pode ser representada por um vetor $\mathbf{a}$. Entretanto, os vetores $\mathbf{a}$ e $c\mathbf{a}$, para $c \neq 0$, representam a mesma direção, embora tenham comprimentos diferentes. Por isso, quando o interesse está apenas na direção, é conveniente impor a normalização

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Essa restrição faz com que a busca seja realizada sobre o conjunto dos vetores unitários. Geometricamente, em $\mathbb{R}^p$, esses vetores formam a esfera unitária.

Considere agora a forma quadrática

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica. O problema consiste em investigar como o valor de $f(\mathbf{a})$ varia quando a direção $\mathbf{a}$ percorre a esfera unitária.

5.5.3.1 O que é um ponto estacionário sob uma restrição?

Em um problema sem restrições, um ponto estacionário de uma função diferenciável é um ponto no qual seu gradiente é nulo. Em um problema com restrição, essa condição precisa ser modificada, pois nem todas as direções de deslocamento são permitidas.

Neste caso, $\mathbf{a}$ deve permanecer sobre a esfera

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um ponto é estacionário para o problema restrito quando pequenas alterações de $\mathbf{a}$ que respeitam essa restrição não produzem, em primeira ordem, aumento ou redução da função objetivo.

Geometricamente, isso ocorre quando o gradiente da função objetivo não possui componente na direção tangente à superfície da restrição. De forma equivalente, o gradiente da função objetivo deve ser proporcional ao gradiente da função que define a restrição.

Essa condição é obtida pelo método dos multiplicadores de Lagrange.

Considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem para um ponto estacionário é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A} \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que as direções estacionárias do problema são precisamente direções de autovetores de $\mathbf{A}$. O multiplicador de Lagrange η é o autovalor associado à direção encontrada.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \eta \mathbf{a}^\top \mathbf{a} \\ &= \eta,\end{aligned}$$

pois $\mathbf{a}^\top \mathbf{a} = 1$.

Assim, quando $\mathbf{a}$ é um autovetor unitário associado ao autovalor λ ,

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Portanto, há uma correspondência direta:

direção estacionária $\leftrightarrow$ autovetor

e

valor da forma quadrática nessa direção $\leftrightarrow$ autovalor.

Como $\mathbf{A}$ é simétrica, seus autovalores são reais. Além disso, pelos resultados do quociente de Rayleigh, para todo vetor unitário $\mathbf{a}$,

$$\lambda_{\min} \leq \mathbf{a}^\top \mathbf{A} \mathbf{a} \leq \lambda_{\max}.$$

Os extremos são atingidos nos autoespaços associados ao menor e ao maior autovalor. Consequentemente,

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\max},$$

e

$$\min_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda_{\min}.$$

Assim:

- o maior autovalor fornece o máximo global da forma quadrática sobre a esfera unitária;
- o menor autovalor fornece o mínimo global;

- os demais autovalores correspondem a valores estacionários intermediários;
- os autovetores associados fornecem as respectivas direções.

Teorema 5.6 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e considere*

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}$$

restrita aos vetores que satisfazem

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Um vetor unitário $\mathbf{a}$ é um ponto estacionário de f sobre a esfera unitária se, e somente se, $\mathbf{a}$ é um autovetor de $\mathbf{A}$.

Se

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a},$$

então

$$f(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a} = \lambda.$$

Em particular, o maior autovalor corresponde ao máximo global da função sobre a esfera unitária, e o menor autovalor corresponde ao mínimo global.

Este resultado permite compreender por que autovalores e autovetores surgem repetidamente em técnicas multivariadas. Em muitos casos, a técnica procura uma direção $\mathbf{a}$ que torne máxima uma quantidade expressa por uma forma quadrática.

Na Análise de Componentes Principais, por exemplo, para um vetor aleatório $\mathbf{X}$ com matriz de covariâncias Σ , a variância da combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

é

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A primeira componente principal procura a direção unitária que maximiza essa variância:

$$\max_{\mathbf{a}^\top \mathbf{a}=1} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo resultado anterior, a solução é um autovetor associado ao maior autovalor de Σ . Portanto,

maior autovalor $\longrightarrow$ maior variância possível

e

autovetor correspondente $\longrightarrow$ direção de maior variabilidade.

As componentes seguintes são obtidas acrescentando restrições de ortogonalidade às direções já encontradas. Isso conduz sucessivamente aos demais autovetores e autovalores.

A mesma estrutura reaparece, com modificações, em outros problemas multivariados. Na análise discriminante, procura-se uma direção que produza grande separação entre grupos em relação à variabilidade dentro dos grupos. Na MANOVA, determinadas direções maximizam a variação associada à hipótese em relação à variação residual. Na correlação canônica, procuram-se combinações lineares de dois conjuntos de variáveis que apresentem associação máxima.

Nesses casos, a função a ser otimizada envolve frequentemente uma razão entre duas formas quadráticas,

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{B} \mathbf{a}},$$

e a condição de estacionariedade conduz ao problema de autovalores generalizados

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{B} \mathbf{a}.$$

Assim, autovalores e autovetores aparecem nessas técnicas porque representam soluções de problemas de otimização sobre direções: os autovetores fornecem as direções de interesse e os autovalores quantificam o valor atingido pelo critério nessas direções.

5.5.4 Direções sucessivas

O problema de otimização anterior identifica uma direção associada ao maior autovalor de $\mathbf{A}$. Em muitas aplicações, entretanto, interessa obter não apenas uma direção ótima, mas uma sequência de direções que representem aspectos distintos da estrutura da matriz.

Depois de encontrar a primeira direção, pode-se procurar uma segunda direção que maximize a mesma forma quadrática, mas que seja ortogonal à primeira. O procedimento pode ser repetido sucessivamente, impondo que cada nova direção seja ortogonal às anteriormente obtidas.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição

$$\mathbf{a}^\top \mathbf{q}_1 = 0$$

impede que $\mathbf{a}$ possua componente na direção de $\mathbf{q}_1$. Assim, se $\mathbf{a}$ for escrito na base espectral,

$$\mathbf{a} = z_1 \mathbf{q}_1 + z_2 \mathbf{q}_2 + \dots + z_p \mathbf{q}_p,$$

a condição de ortogonalidade implica

$$z_1 = 0.$$

Portanto, a otimização passa a ocorrer apenas no subespaço gerado por

$$\mathbf{q}_2, \dots, \mathbf{q}_p.$$

Nesse subespaço, o maior autovalor disponível é λ_2 . Assim, o maior valor da forma quadrática é λ_2 , atingido na direção de $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.7 (Caracterização variacional de direções sucessivas). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

e seja

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

uma base ortonormal de autovetores correspondente a essa ordenação. Então, para $k = 1, \dots, p$,

$$\lambda_k = \max_{\substack{\|\mathbf{a}\|=1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j=1, \dots, k-1}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por $\mathbf{q}_k$ e, quando λ_k possui multiplicidade maior que 1, por qualquer autovetor unitário associado a λ_k que satisfaça as restrições de ortogonalidade. (Horn; Johnson, 2013)



i Demonstração

Como

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$, qualquer vetor $\mathbf{a}$ pode ser escrito como

$$\mathbf{a} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{a}.$$

As restrições

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1,$$

implicam

$$z_1 = \dots = z_{k-1} = 0.$$

Portanto,

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como os autovetores são ortonormais e $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Nas coordenadas espectrais,

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \sum_{j=k}^p \lambda_j z_j^2.$$

Como os autovalores estão ordenados de forma decrescente,

Quando há autovalores repetidos, as direções individuais dentro do autoespaço correspondente não são unicamente determinadas. Diferentes bases ortonormais desse autoespaço produzem o mesmo valor da função objetivo e representam o mesmo subespaço espectral. Assim, o subespaço associado ao autovalor repetido é bem determinado, embora a escolha particular dos autovetores que formam uma base desse subespaço não seja única.

A caracterização variacional relaciona, portanto, três objetos fundamentais:

$$\text{forma quadrática} \longleftrightarrow \text{problema de otimização} \longleftrightarrow \text{estrutura espectral}.$$

Além de identificar os valores extremos, essa caracterização permite obter sucessivamente as direções ortogonais associadas aos autovalores ordenados da matriz.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar real definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.8 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função real definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Proposição 5.7 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn; Johnson, 1991)

i Demonstração

Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_\lambda$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

Portanto, todo autovetor de $\mathbf{A}$ associado a λ também é autovetor de $f(\mathbf{A})$, agora associado ao autovalor $f(\lambda)$. Mais geralmente, todo o autoespaço $\mathcal{E}_\lambda$ de $\mathbf{A}$ permanece invariante sob $f(\mathbf{A})$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{Q}_\mathbf{A}^\top,$$

com

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_A$ fornece

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Exemplo 5.8 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_A \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_A^\top.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_A \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_A^\top.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.9 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a raiz quadrada principal de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{A} \succ 0$, a raiz quadrada principal é invertível e

$$\mathbf{A}^{-1/2} = (\mathbf{A}^{1/2})^{-1}.$$

Além disso,

$$\mathbf{A}^{-1} = \mathbf{A}^{-1/2} \mathbf{A}^{-1/2}$$

e

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned} \mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \Lambda_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A} \mathbf{I}_p \mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p. \end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2} \mathbf{x}$$

reescala as componentes espectrais de $\mathbf{x}$ segundo os fatores $1/\sqrt{\lambda_j}$. Além disso, converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned} \mathbf{x}^\top \mathbf{A}^{-1} \mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2} \mathbf{A}^{-1/2} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{z} \\ &= \|\mathbf{z}\|^2. \end{aligned}$$

Quando $\mathbf{A}$ for uma matriz de covariâncias $\Sigma \succ 0$, essa construção será retomada no branqueamento. Para um vetor com média μ , a transformação correspondente será aplicada ao vetor centralizado,

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu).$$

Nesse caso, a distância de Mahalanobis será interpretada como uma distância euclidiana nas coordenadas branqueadas.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.10 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A pseudoinversa de Moore–Penrose de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa atua separadamente sobre os autoespaços: nas direções associadas a autovalores não nulos, aplica o fator $1/\lambda$; no autoespaço associado ao autovalor zero, sua ação é nula. Assim, ela inverte a transformação sobre sua imagem e mantém eliminadas as componentes pertencentes ao núcleo.

Exemplo 5.9 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned}\mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz simétrica positiva definida, define-se o **logaritmo principal** por

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^\top.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição adicional
$\mathbf{A}^k$	λ_j^k	$k \in \{0, 1, 2, \dots\}$
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	nenhuma além da simetria assumida na seção
$\exp(\mathbf{A})$	e^{λ_j}	nenhuma além da simetria assumida na seção
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais atuam separadamente sobre os autoespaços, transformando cada autovalor λ no valor escalar $f(\lambda)$. Essa construção permite obter diretamente potências, inversas, raízes e pseudoinversas e mostra como certas transformações matriciais podem ser compreendidas como reescalonamentos das direções espectrais.

Em particular, a raiz quadrada e a raiz quadrada inversa permitem converter problemas definidos por uma geometria induzida por uma matriz positiva definida em problemas euclidianos equivalentes. Essa ideia será utilizada imediatamente na formulação dos autovalores generalizados.

5.7 Aprofundamento: autovalores generalizados

Leitura de aprofundamento

Esta seção apresenta uma extensão do problema ordinário de autovalores para situações em que duas formas quadráticas são consideradas simultaneamente. Embora esse desenvolvimento não seja necessário para acompanhar os resultados centrais da decomposição espectral, ele fornece uma base matemática importante para técnicas multivariadas que envolvem a comparação entre diferentes estruturas de variabilidade, separação ou associação.

Ao longo da seção, serão apresentados os autovalores generalizados, o quociente de Rayleigh generalizado, a ortogonalidade em uma métrica definida por uma matriz positiva definida e a redução do problema generalizado a um problema espectral ordinário.

Alguns problemas de Estatística Multivariada envolvem a comparação entre duas formas quadráticas, em vez da otimização de uma única forma quadrática relativamente à norma euclidiana. Nesses casos, surge naturalmente o problema de autovalores generalizados,

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

em que $\mathbf{A}$ é simétrica e $\mathbf{M}$ é simétrica positiva definida.

Essa estrutura generaliza o problema ordinário de autovalores, recuperado quando

$$\mathbf{M} = \mathbf{I}_p.$$

Os autovalores generalizados serão úteis posteriormente em problemas que envolvem a comparação entre diferentes medidas de variabilidade, separação ou associação. A leitura a seguir desenvolve a formulação matemática desse problema e sua relação com o quociente de Rayleigh e a decomposição espectral.

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.16, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.11 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda\mathbf{M})\mathbf{v} = \mathbf{0}.$$

Existem soluções não triviais se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Essa equação é a equação característica generalizada do par $(\mathbf{A}, \mathbf{M})$ e determina seus autovalores generalizados.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.12 (Quociente de Rayleigh generalizado). Sejam $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica e $\mathbf{M} \in \mathbb{R}^{p \times p}$ simétrica positiva definida. Para $\mathbf{a} \in \mathbb{R}^p$, com $\mathbf{a} \neq \mathbf{0}$, o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \frac{q_{\mathbf{A}}(\mathbf{a})}{\|\mathbf{a}\|_{\mathbf{M}}^2}.$$

O numerador é a forma quadrática associada a $\mathbf{A}$, enquanto o denominador é o quadrado da norma induzida por $\mathbf{M}$,

$$\|\mathbf{a}\|_{\mathbf{M}}^2 = \langle \mathbf{a}, \mathbf{a} \rangle_{\mathbf{M}} = \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Como $\mathbf{M} \succ \mathbf{0}$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o denominador é sempre positivo e o quociente está definido para todo vetor não nulo.

No quociente de Rayleigh ordinário, a normalização é realizada pela norma euclidiana,

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a}.$$

No caso generalizado, essa normalização é substituída pela norma induzida por $\mathbf{M}$. Assim, o comprimento do vetor passa a ser medido segundo a geometria determinada por essa matriz.

Assim como no caso ordinário, o quociente é invariante à escala. Para qualquer escalar $c \neq 0$,

$$\begin{aligned}
\mathcal{R}_{\mathbf{A},\mathbf{M}}(c\mathbf{a}) &= \frac{(c\mathbf{a})^\top \mathbf{A}(c\mathbf{a})}{(c\mathbf{a})^\top \mathbf{M}(c\mathbf{a})} \\
&= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{M} \mathbf{a}} \\
&= \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}).
\end{aligned}$$

Portanto, o valor do quociente depende da direção determinada por $\mathbf{a}$, e não de sua magnitude segundo a norma induzida por $\mathbf{M}$.

Essa invariância permite escolher, em cada direção, um representante com norma unitária na geometria determinada por $\mathbf{M}$. Consequentemente, o problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição equivale a

$$\|\mathbf{a}\|_{\mathbf{M}} = 1$$

e, portanto, fixa o comprimento de $\mathbf{a}$ segundo a geometria induzida por $\mathbf{M}$.

Para determinar os pontos estacionários desse problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1),$$

em que η é o multiplicador de Lagrange.

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{M} \mathbf{a}) = 2\mathbf{M} \mathbf{a}.$$

Assim,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A} \mathbf{a} - 2\eta \mathbf{M} \mathbf{a}.$$

A condição de primeira ordem

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0}$$

produz

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}.$$

Como a restrição

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1$$

garante que $\mathbf{a} \neq \mathbf{0}$, essa equação mostra que todo ponto estacionário $\mathbf{a}$ é um autovetor generalizado do par $(\mathbf{A}, \mathbf{M})$ e que o multiplicador η é o autovalor generalizado correspondente.

Multiplicando a equação

$$\mathbf{A} \mathbf{a} = \eta \mathbf{M} \mathbf{a}$$

à esquerda por $\mathbf{a}^\top$, obtém-se

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta \mathbf{a}^\top \mathbf{M} \mathbf{a}.$$

Sob a normalização

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1,$$

segue que

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \eta.$$

Além disso,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}} = \eta.$$

Portanto, em um autovetor generalizado normalizado, o valor do quociente de Rayleigh generalizado coincide com o autovalor generalizado correspondente.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, a matriz $\mathbf{M}$ é invertível, e a equação generalizada também poderia ser escrita como

$$\mathbf{M}^{-1} \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Entretanto, mesmo que $\mathbf{A}$ e $\mathbf{M}$ sejam simétricas, a matriz $\mathbf{M}^{-1} \mathbf{A}$ não precisa ser simétrica. Para preservar a estrutura simétrica e poder aplicar diretamente o Teorema Espectral, é preferível transformar o problema utilizando a raiz quadrada de $\mathbf{M}$.

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2} \mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} = \lambda \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\widetilde{\mathbf{A}}^\top = \widetilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido no problema espectral ordinário

$$\widetilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u},$$

para uma matriz simétrica. Consequentemente, todos os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$ são reais e os resultados do Teorema Espectral podem ser aplicados à matriz $\widetilde{\mathbf{A}}$.

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \widetilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{a}$$

transforma a geometria induzida por $\mathbf{M}$ em geometria euclidiana, pois

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{u}^\top \mathbf{u}.$$

Equivalentemente,

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Geometricamente, $\mathbf{M}^{-1/2}$ transforma a esfera unitária euclidiana no elipsoide

$$\{\mathbf{a} \in \mathbb{R}^p : \mathbf{a}^\top \mathbf{M} \mathbf{a} = 1\}.$$

O problema generalizado pode, portanto, ser estudado como um problema de Rayleigh ordinário no sistema de coordenadas em que a métrica definida por $\mathbf{M}$ se torna euclidiana.

Quando $\mathbf{M}$ representar posteriormente uma matriz de covariâncias, essa mesma estrutura estará relacionada ao branqueamento. Aqui, porém, $\mathbf{M}$ representa genericamente a matriz que define a geometria do problema.

Teorema 5.8 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_1 , e o mínimo é atingido por todo vetor não nulo do autoespaço generalizado associado a λ_p .

i Demonstração

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.5 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados.

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Proposição 5.8 (Ortogonalidade e base de autovetores generalizados). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M} \succ 0$.*

Se $\mathbf{v}_i$ e $\mathbf{v}_j$ são autovetores generalizados associados a autovalores distintos λ_i e λ_j , então

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Além disso, existe uma base de $\mathbb{R}^p$ formada por autovetores generalizados

$$\mathcal{B}_g = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

que pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \delta_{ij}.$$

(Horn; Johnson, 2013)

i Demonstração

Para autovalores distintos,

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{M}\mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{M}\mathbf{v}_j.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned}\lambda_i \mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}\mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j.\end{aligned}$$

Portanto,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j = 0.$$

Para mostrar a existência de uma base completa, considere

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Como $\tilde{\mathbf{A}}$ é simétrica, o Teorema Espectral garante uma base ortonormal de autovetores

$$\{\mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

Defina

$$\mathbf{v}_j = \mathbf{M}^{-1/2} \mathbf{u}_j.$$

Esses vetores são autovetores generalizados e

$$\begin{aligned}\mathbf{v}_i^\top \mathbf{M}\mathbf{v}_j &= \mathbf{u}_i^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u}_j \\ &= \mathbf{u}_i^\top \mathbf{u}_j \\ &= \delta_{ij}.\end{aligned}$$

Assim, mesmo quando há autovalores generalizados repetidos, pode-se escolher uma base ortonormal segundo o produto interno induzido por $\mathbf{M}$.

5.7.4 Diagonalização simultânea por congruência

Considere a decomposição espectral

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \mathbf{\Lambda}_g \mathbf{Q}_g^\top,$$

em que

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{B}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

Como $\mathbf{M}^{-1/2}$ é invertível e $\mathbf{Q}_g$ é ortogonal, $\mathbf{B}_g$ é invertível. Suas colunas formam uma base $\mathbf{M}$ -ortonormal de autovetores generalizados.

De fato,

$$\begin{aligned} \mathbf{A} \mathbf{B}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \mathbf{\Lambda}_g \\ &= \mathbf{M} \mathbf{B}_g \mathbf{\Lambda}_g. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p, \end{aligned}$$

e

$$\begin{aligned} \mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \widetilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{\Lambda}_g. \end{aligned}$$

Portanto,

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

O par $(\mathbf{A}, \mathbf{M})$ é, assim, reduzido simultaneamente por uma transformação de congruência:

$$(\mathbf{A}, \mathbf{M}) \longrightarrow (\Lambda_g, \mathbf{I}_p).$$

Essa operação deve ser distinguida da semelhança

$$\mathbf{B}^{-1} \mathbf{A} \mathbf{B},$$

utilizada para representar um único operador em outra base. Na congruência, as matrizes aparecem multiplicadas pela transposta da matriz de base à esquerda e pela própria matriz à direita.

Como

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p,$$

segue que

$$\mathbf{B}_g^{-1} = \mathbf{B}_g^\top \mathbf{M}.$$

Assim, se

$$\mathbf{a} = \mathbf{B}_g \mathbf{z},$$

então as coordenadas de $\mathbf{a}$ nessa base são

$$\mathbf{z} = \mathbf{B}_g^{-1} \mathbf{a} = \mathbf{B}_g^\top \mathbf{M} \mathbf{a}.$$

Nessas coordenadas,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, portanto, a mesma forma do quociente de Rayleigh ordinário quando expresso na base $\mathbf{M}$ -ortonormal de autovetores generalizados.

Exemplo 5.10 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{b}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{b}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas da matriz da base

$$\mathbf{B}_g = \begin{bmatrix} \mathbf{b}_{g,1} & \mathbf{b}_{g,2} \end{bmatrix},$$

obtêm-se

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_2$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Este capítulo desenvolveu a estrutura espectral das transformações lineares quadradas. O ponto de partida foi a identificação de direções invariantes, isto é, direções nas quais a ação de uma matriz reduz-se à multiplicação por um escalar.

Para

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

com $\mathbf{v} \neq \mathbf{0}$, o escalar λ é um autovalor e $\mathbf{v}$ é um autovetor correspondente. O conjunto formado pelo vetor nulo e por todos os autovetores associados a λ constitui o autoespaço

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Os autovalores são determinados pela condição

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

A multiplicidade algébrica $m_a(\lambda)$ registra a multiplicidade de λ como raiz do polinômio característico, enquanto a multiplicidade geométrica

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda)$$

mede a dimensão do autoespaço correspondente.

Quando $\mathbf{A}$ possui p autovetores linearmente independentes, eles formam uma base

$$\mathcal{B}_{\mathbf{A}} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\},$$

cujas matrizes são

$$\mathbf{B}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Nessa base,

$$[T_{\mathbf{A}}]_{\mathcal{B}_{\mathbf{A}} \leftarrow \mathcal{B}_{\mathbf{A}}} = \mathbf{B}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{B}_{\mathbf{A}} = \Lambda_{\mathbf{A}},$$

e, portanto,

$$\mathbf{A} = \mathbf{B}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{B}_{\mathbf{A}}^{-1}.$$

A diagonalização é, assim, uma mudança para coordenadas nas quais o operador atua separadamente sobre cada direção da base de autovetores.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores. Nesse caso, a matriz da base pode ser escolhida ortogonal,

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

com

$$\mathbf{Q}_{\mathbf{A}}^{-1} = \mathbf{Q}_{\mathbf{A}}^{\top},$$

e obtém-se a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Equivalentemente,

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top.$$

Agrupando autovalores repetidos, essa representação pode ser escrita em termos dos projetores espectrais:

$$\mathbf{A} = \sum_h \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Essa forma mostra que uma matriz simétrica atua projetando o vetor sobre autoespaços ortogonais e aplicando a cada componente o autovalor correspondente.

A decomposição espectral também permite recuperar diretamente propriedades da matriz:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

e

$$\text{posto}(\mathbf{A}) = \#\{j : \lambda_j \neq 0\},$$

contando as multiplicidades.

Além disso,

$$\ker(T_{\mathbf{A}}) = \mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \},$$

enquanto

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Para matrizes simétricas,

$$\text{Im}(T_{\mathbf{A}}) = \ker(T_{\mathbf{A}})^\perp.$$

A mesma decomposição simplifica as formas quadráticas. Se

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_{\mathbf{A}}} = \mathbf{Q}_{\mathbf{A}}^{\top} \mathbf{x},$$

então

$$\mathbf{x}^{\top} \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

As possibilidades de sinal da forma quadrática são, portanto, determinadas pelos sinais dos autovalores. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides cujos eixos estão alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^{\top} \mathbf{A} \mathbf{a}}{\mathbf{a}^{\top} \mathbf{a}},$$

é uma média ponderada dos autovalores. Para

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

tem-se

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

O máximo e o mínimo são atingidos nos autoespaços associados aos autovalores extremos. A otimização de uma forma quadrática sob a restrição

$$\mathbf{a}^{\top} \mathbf{a} = 1$$

conduz à condição

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}.$$

Autovalores e autovetores podem, portanto, ser interpretados também como valores e direções estacionárias de problemas de otimização quadrática.

A decomposição espectral permite ainda definir funções de matrizes simétricas. Se f está definida no espectro de $\mathbf{A}$,

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Equivalentemente,

$$f(\mathbf{A}) = \sum_h f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Assim, a função espectral preserva os autoespaços e transforma cada autovalor λ no escalar $f(\lambda)$. Potências, inversas, raízes quadradas, raízes quadradas inversas, pseudoinversas, exponenciais e logaritmos são casos particulares dessa construção, sob as condições necessárias à definição de cada função.

Quando a geometria do problema é determinada por uma matriz simétrica positiva definida $\mathbf{M}$, surge o problema de autovalores generalizados

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v},$$

com $\mathbf{A} = \mathbf{A}^\top$ e $\mathbf{M} \succ 0$.

O quociente correspondente é

$$\mathcal{R}_{\mathbf{A},\mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

converte esse problema em um problema de Rayleigh ordinário para a matriz simétrica

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Consequentemente, os autovalores generalizados são reais e pode-se escolher uma base de autovetores generalizados cuja matriz $\mathbf{B}_g$ satisfaz

$$\mathbf{B}_g^\top \mathbf{M} \mathbf{B}_g = \mathbf{I}_p$$

e

$$\mathbf{B}_g^\top \mathbf{A} \mathbf{B}_g = \Lambda_g.$$

A Tabela 5.2 reúne as expressões principais desenvolvidas no capítulo.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica direções invariantes
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{B}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{B}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Projeto espectral	$\Pi_\lambda = \mathbf{Q}_\lambda\mathbf{Q}_\lambda^\top$	Projeta sobre o autoespaço associado a λ
Forma quadrática	$\mathbf{x}^\top\mathbf{A}\mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a}) = \frac{\mathbf{a}^\top\mathbf{A}\mathbf{a}}{\mathbf{a}^\top\mathbf{a}}$	Caracteriza valores e direções espectrais por otimização
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A}f(\Lambda_\mathbf{A})\mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}$	Compara duas formas quadráticas
Base generalizada	$\mathbf{B}_g^\top\mathbf{M}\mathbf{B}_g = \mathbf{I}_p$	Define ortonormalidade na geometria induzida por $\mathbf{M}$
Diagonalização por congruência	$\mathbf{B}_g^\top\mathbf{A}\mathbf{B}_g = \Lambda_g$	Reduz simultaneamente as duas formas quadráticas

Ao final deste capítulo, o estudante deverá ser capaz de:

- identificar autovalores, autovetores e autoespaços e interpretar seu significado geométrico;
- distinguir multiplicidades algébrica e geométrica;
- determinar quando uma matriz é diagonalizável;
- interpretar a diagonalização como mudança para uma base de autovetores;
- aplicar o Teorema Espectral a matrizes simétricas reais;
- interpretar projetores e subespaços espectrais;
- relacionar autovalores a traço, determinante, posto, núcleo, imagem e positividade;
- representar formas quadráticas em coordenadas espectrais;
- formular problemas de otimização por meio do quociente de Rayleigh;
- construir e interpretar funções espectrais de matrizes;
- compreender inversas, raízes e pseudoinversas pela ação sobre os autovalores;
- formular e transformar problemas de autovalores generalizados;
- distinguir ortogonalidade euclidiana de ortogonalidade segundo uma matriz positiva definida.

A decomposição espectral fornece uma descrição particularmente simples para matrizes simétricas quadradas. Entretanto, matrizes de dados e muitas transformações de interesse são retangulares ou não simétricas e, portanto, não admitem diretamente essa decomposição. O próximo capítulo amplia essas ideias por meio da **Decomposição em Valores Singulares**, relacionando matrizes retangulares aos espectros de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ e conectando valores singulares, espaços fundamentais, posto e aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{A} \in \mathbb{R}^{q \times p}$ representa uma matriz real e $T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q$ a transformação linear associada;
- $r = \text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$;
- $d_1 \geq \dots \geq d_r > 0$ representam os valores singulares positivos de $\mathbf{A}$;
- $\mathbf{v}_j \in \mathbb{R}^p$ representa um vetor singular à direita;
- $\mathbf{u}_j \in \mathbb{R}^q$ representa um vetor singular à esquerda;
- $\mathbf{U}$, $\mathbf{D}$ e $\mathbf{V}$ representam os fatores da SVD completa;
- $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ representam os fatores da SVD compacta;
- $\mathbf{U}_k$, $\mathbf{D}_k$ e $\mathbf{V}_k$ representam os fatores de uma SVD truncada;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\|\mathbf{A}\|_2$ e $\|\mathbf{A}\|_F$ representam, respectivamente, as normas espectral e de Frobenius.

As convenções estabelecidas nos capítulos anteriores para núcleo, imagem, espaço coluna, espaço linha e bases ortonormais permanecem válidas.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

*Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub; Van Loan, 2013)*

A demonstração será apresentada posteriormente, após a construção da SVD a partir das decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$.

Definição 6.1 (Matriz diagonal retangular). Seja

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

A matriz $\mathbf{D}$ é denominada **diagonal retangular** quando existem escalares

$$d_1, \dots, d_s$$

tais que

$$D_{ij} = \begin{cases} d_i, & i = j \leq s, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, apenas os elementos da diagonal principal podem ser diferentes de zero.

No bloco diagonal de ordem s , essa condição pode ser escrita de forma compacta utilizando a delta de Kronecker:

$$D_{ij} = d_i \delta_{ij}, \quad i, j = 1, \dots, s.$$

Se

$$q > p,$$

então $s = p$ e $\mathbf{D}$ possui $q - p$ linhas nulas abaixo de sua parte diagonal.

Se

$$p > q,$$

então $s = q$ e $\mathbf{D}$ possui $p - q$ colunas nulas à direita de sua parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_p \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Nesse caso, a parte diagonal possui $p = \min(q, p)$ elementos e as $q - p$ linhas restantes são nulas.

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Agora, a parte diagonal possui $q = \min(q, p)$ elementos e as $p - q$ colunas restantes são nulas.

Como

$$s = \min(q, p),$$

a matriz $\mathbf{D}$ possui s posições diagonais. Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos. Ordenando-os de forma decrescente,

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto, quando $r < s$,

$$d_{r+1} = \cdots = d_s = 0.$$

Assim, o número de valores singulares positivos é exatamente o posto de $\mathbf{A}$ e, consequentemente, a dimensão da imagem da transformação linear associada:

$$r = \text{posto}(\mathbf{A}) = \dim(\text{Im}(T_{\mathbf{A}})).$$

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.2 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A}\mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;
- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{z} = \mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base ortonormal dos vetores singulares à direita,

$$\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}.$$

Assim,

$$\mathbf{z} = [\mathbf{x}]_{\mathcal{B}_V}.$$

Na segunda etapa,

$$\mathbf{Dz}$$

multiplica separadamente as coordenadas pelas entradas diagonais de $\mathbf{D}$. Como $\mathbf{D} \in \mathbb{R}^{q \times p}$ pode ser retangular, essa etapa também realiza a passagem entre as dimensões do domínio e do contradomínio.

Na terceira etapa, $\mathbf{U}$ reconstrói o resultado nas coordenadas canônicas de $\mathbb{R}^q$ a partir da base ortonormal

$$\mathcal{B}_U = \{\mathbf{u}_1, \dots, \mathbf{u}_q\}.$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.3 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.4 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva todos os r valores singulares positivos e fornece a representação exata

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

A SVD truncada conserva apenas parte desses componentes singulares.

Para

$$1 \leq k < r,$$

defina

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k] \in \mathbb{R}^{q \times k},$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

Definição 6.5 (SVD truncada). Seja

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a matriz

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$$

é denominada **SVD truncada de posto k** de $\mathbf{A}$.

Como $k < r$, a SVD truncada descarta componentes associados a valores singulares positivos. Portanto, em geral,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ possui posto k e constitui uma aproximação de $\mathbf{A}$. As propriedades de otimalidade dessa aproximação e os erros decorrentes do truncamento serão estudados posteriormente.

A terminologia empregada para as diferentes formas da SVD não é uniforme na literatura. Dependendo da referência, aparecem expressões como **SVD reduzida**, **SVD fina** (*thin SVD*), **SVD econômica** (*economy-sized SVD*) e **SVD compacta**, nem sempre com exatamente o mesmo significado (Demmel, 2000; Driscoll; Braun, 2022; Sidi, 2017).

Para evitar ambiguidades, neste capítulo serão utilizadas as seguintes convenções:

- **SVD completa**, para a representação que utiliza bases ortonormais completas dos espaços de origem e de chegada;
- **SVD compacta**, para a representação exata que conserva somente os $r = \text{posto}(\mathbf{A})$ valores singulares positivos e os vetores singulares correspondentes;

- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

Exemplo 6.1 (SVD completa, compacta e truncada de uma matriz retangular). Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \\ 2 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

A matriz possui posto

$$r = 3$$

e seus valores singulares, em ordem decrescente, são aproximadamente

$$d_1 = 4.1780, \quad d_2 = 2.1600, \quad d_3 = 1.3706.$$

Os valores apresentados a seguir estão arredondados a quatro casas decimais. Por esse motivo, as decomposições numéricas devem ser interpretadas a menos de arredondamento.

SVD completa

Uma SVD completa de $\mathbf{A}$ é

$$\mathbf{A} \approx \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que

$$\mathbf{U} \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 & -0.6014 & -0.2239 \\ 0.5461 & -0.2239 & 0.5466 & 0.5614 & -0.1943 \\ 0.3803 & -0.6954 & -0.3419 & -0.4142 & -0.2887 \\ 0.4348 & 0.4111 & -0.6965 & 0.3743 & -0.1295 \\ 0.4126 & -0.0779 & -0.0136 & -0.1073 & 0.9011 \end{bmatrix} \in \mathbb{R}^{5 \times 5},$$

$$\mathbf{D} \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

e

$$\mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

As colunas de $\mathbf{U}$ são os vetores singulares à esquerda,

$$\mathbf{u}_1, \dots, \mathbf{u}_5,$$

e as colunas de $\mathbf{V}$ são os vetores singulares à direita,

$$\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3.$$

Os três primeiros pares de vetores singulares estão associados aos três valores singulares positivos:

$$(\mathbf{u}_1, \mathbf{v}_1) \leftrightarrow d_1 = 4.1780,$$

$$(\mathbf{u}_2, \mathbf{v}_2) \leftrightarrow d_2 = 2.1600,$$

e

$$(\mathbf{u}_3, \mathbf{v}_3) \leftrightarrow d_3 = 1.3706.$$

As duas últimas colunas de $\mathbf{U}$ completam uma base ortonormal de $\mathbb{R}^5$. Elas correspondem às duas linhas nulas de $\mathbf{D}$.

SVD compacta

Como

$$r = \text{posto}(\mathbf{A}) = 3,$$

a SVD compacta conserva somente os três valores singulares positivos e os vetores singulares correspondentes:

$$\mathbf{A} \approx \mathbf{U}_3 \mathbf{D}_3 \mathbf{V}_3^\top,$$

com

$$\mathbf{U}_3 \approx \begin{bmatrix} 0.4449 & 0.5397 & 0.3147 \\ 0.5461 & -0.2239 & 0.5466 \\ 0.3803 & -0.6954 & -0.3419 \\ 0.4348 & 0.4111 & -0.6965 \\ 0.4126 & -0.0779 & -0.0136 \end{bmatrix} \in \mathbb{R}^{5 \times 3},$$

$$\mathbf{D}_3 \approx \begin{bmatrix} 4.1780 & 0 & 0 \\ 0 & 2.1600 & 0 \\ 0 & 0 & 1.3706 \end{bmatrix} \in \mathbb{R}^{3 \times 3},$$

e

$$\mathbf{V}_3 = \mathbf{V} \approx \begin{bmatrix} 0.6506 & 0.7406 & -0.1682 \\ 0.5576 & -0.3155 & 0.7678 \\ 0.5156 & -0.5933 & -0.6182 \end{bmatrix} \in \mathbb{R}^{3 \times 3}.$$

A representação continua sendo exata antes do arredondamento numérico. A SVD compacta elimina apenas as duas colunas adicionais de $\mathbf{U}$ e as duas linhas nulas correspondentes de $\mathbf{D}$.

Como

$$r = p = 3,$$

todos os vetores singulares à direita participam da SVD compacta. Por isso,

$$\mathbf{V}_3 = \mathbf{V}.$$

SVD truncada de posto 2

Considere agora a conservação apenas dos dois maiores valores singulares,

$$d_1 = 4.1780 \quad \text{e} \quad d_2 = 2.1600.$$

A SVD truncada de posto 2 utiliza

$$\mathbf{U}_2 \approx \begin{bmatrix} 0.4449 & 0.5397 \\ 0.5461 & -0.2239 \\ 0.3803 & -0.6954 \\ 0.4348 & 0.4111 \\ 0.4126 & -0.0779 \end{bmatrix} \in \mathbb{R}^{5 \times 2},$$

$$\mathbf{D}_2 \approx \begin{bmatrix} 4.1780 & 0 \\ 0 & 2.1600 \end{bmatrix} \in \mathbb{R}^{2 \times 2},$$

e

$$\mathbf{V}_2 \approx \begin{bmatrix} 0.6506 & 0.7406 \\ 0.5576 & -0.3155 \\ 0.5156 & -0.5933 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Assim,

$$\mathbf{A}_2 = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top$$

é uma aproximação de posto 2 da matriz original. Numericamente,

$$\mathbf{A}_2 \approx \begin{bmatrix} 2.0726 & 0.6688 & 0.2667 \\ 1.1260 & 1.4248 & 1.4631 \\ -0.0788 & 1.3598 & 1.7103 \\ 1.8394 & 0.7330 & 0.4098 \\ 0.9969 & 1.0143 & 0.9885 \end{bmatrix}.$$

Como o terceiro valor singular positivo foi descartado,

$$\mathbf{A}_2 \neq \mathbf{A}.$$

As três formas podem ser comparadas pelas dimensões de seus fatores:

Forma	Matriz à esquerda	Matriz diagonal	Matriz à direita	Valores singulares mantidos	Resultado
SVD completa	$\mathbf{U} : 5 \times 5$	$\mathbf{D} : 5 \times 3$	$\mathbf{V} : 3 \times 3$	d_1, d_2, d_3	Exato
SVD compacta	$\mathbf{U}_3 : 5 \times 3$	$\mathbf{D}_3 : 3 \times 3$	$\mathbf{V}_3 : 3 \times 3$	d_1, d_2, d_3	Exato
SVD truncada	$\mathbf{U}_2 : 5 \times 2$	$\mathbf{D}_2 : 2 \times 2$	$\mathbf{V}_2 : 3 \times 2$	d_1, d_2	Aproximado

A SVD completa apresenta bases ortonormais completas dos espaços de origem e de chegada. A SVD compacta mantém somente as direções associadas aos valores singulares positivos, sem perder informação necessária à reconstrução de $\mathbf{A}$. A SVD truncada conserva apenas parte dessas direções e, por isso, produz uma aproximação de posto menor.

6.1.6 Aprofundamento: não unicidade dos vetores singulares

Leitura de aprofundamento

Esta seção examina a não unicidade dos vetores singulares. Embora os valores singulares sejam determinados pela matriz, os vetores singulares associados podem admitir diferentes representações.

Serão considerados três casos: a mudança simultânea de sinal de pares de vetores singulares, a liberdade de escolha de bases ortonormais quando um valor singular positivo possui multiplicidade maior que um e a escolha das bases associadas ao valor singular zero.

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j (-\mathbf{u}_j) (-\mathbf{v}_j)^\top = d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d\mathbf{U}_d \mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d(\mathbf{U}_d \mathbf{R})(\mathbf{V}_d \mathbf{R})^\top &= d\mathbf{U}_d \mathbf{R} \mathbf{R}^\top \mathbf{V}_d^\top \\ &= d\mathbf{U}_d \mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das duas matrizes de Gram associadas a $\mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Essas matrizes já apareceram no estudo dos espaços das variáveis e das observações. A SVD mostra agora que seus espectros estão diretamente relacionados e que essa relação permite construir bases ortonormais adaptadas à transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^q.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A} \mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Propriedades das matrizes de Gram associadas

As matrizes

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A}\mathbf{A}^\top$$

são matrizes de Gram associadas, respectivamente, às colunas e às linhas de $\mathbf{A}$.

Pela Proposição 3.9, ambas são simétricas e semidefinidas positivas. Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{A}\mathbf{A}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{A}\mathbf{A}^\top) = \text{posto}(\mathbf{A}).$$

Assim, se

$$r = \text{posto}(\mathbf{A}),$$

cada uma dessas matrizes possui exatamente r autovalores positivos, considerando suas multiplicidades.

Como ambas são simétricas, o Teorema 5.4 garante a existência de bases ortonormais de autovetores. Como também são semidefinidas positivas, todos os seus autovalores são não negativos.

Proposição 6.1 (Espectros das matrizes de Gram associadas). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *se esses autovalores são ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

podem-se definir

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r;$$


3. *os núcleos satisfazem*

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A} \mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub; Van Loan, 2013)



As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos pares singulares

Suponha inicialmente que

$$\mathbf{A} \neq \mathbf{0}.$$

Então,

$$r = \text{posto}(\mathbf{A}) \geq 1.$$

O caso

$$\mathbf{A} = \mathbf{0}$$

será tratado diretamente na demonstração do Teorema [6.1](#).

A construção começa pela matriz

$$\mathbf{A}^\top \mathbf{A},$$

que atua em

$$\mathbb{R}^p,$$

o domínio da transformação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Seus autovetores associados aos autovalores positivos determinarão os **vetores singulares à direita**. A aplicação de $\mathbf{A}$ a essas direções, seguida de normalização, produzirá os **vetores singulares à esquerda** em $\mathbb{R}^q$.

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Particione a matriz de autovetores como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

contém os autovetores associados aos autovalores positivos e

$$\mathbf{V}_0 = [\mathbf{v}_{r+1} \quad \cdots \quad \mathbf{v}_p]$$

contém os autovetores associados ao autovalor zero.

Pela Proposição 6.1,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Portanto, as colunas de $\mathbf{V}_0$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{V}_r$ formam uma base ortonormal de

$$\mathcal{N}(\mathbf{A})^\perp = \mathcal{C}(\mathbf{A}^\top).$$

Proposição 6.2 (Construção dos pares singulares positivos). *Para cada*

$$j = 1, \dots, r,$$

defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Então:

1. *os vetores*

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais;

2. *para cada $j = 1, \dots, r$,*

$$\mathbf{A}\mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j;$$

3. os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal de

$$\mathcal{C}(\mathbf{A}).$$



i Demonstração

Para $i, j \leq r$,

$$\begin{aligned}\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\ &= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.\end{aligned}$$

Como os vetores

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Pela definição de $\mathbf{u}_j$,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j.$$

Além disso,

$$\begin{aligned}\mathbf{A}^\top \mathbf{u}_j &= \frac{\mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_j} \\ &= \frac{d_j^2 \mathbf{v}_j}{d_j} \\ &= d_j \mathbf{v}_j.\end{aligned}$$

Cada $\mathbf{u}_j$ pertence a

A construção estabelece uma correspondência entre duas direções ortonormais:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p \xrightarrow{\mathbf{A}} d_j \mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q \xrightarrow{\mathbf{A}^\top} d_j \mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p.$$

Assim, $\mathbf{v}_j$ é uma direção singular à direita, $\mathbf{u}_j$ é a direção singular à esquerda correspondente e d_j é o fator de escalonamento que relaciona as duas.

6.2.3 Construção da SVD compacta

Reúna os vetores singulares à esquerda em

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r]$$

e defina

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r).$$

As relações

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j, \quad j = 1, \dots, r,$$

podem ser escritas simultaneamente como

$$\mathbf{A} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Proposição 6.3 (SVD compacta obtida dos pares singulares). *Com as matrizes $\mathbf{U}_r$, $\mathbf{D}_r$ e $\mathbf{V}_r$ definidas anteriormente,*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Portanto,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de $\mathbf{A}$, e

$$d_1, \dots, d_r$$

são seus valores singulares positivos.

i Demonstração

Como

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal,

$$\mathbf{I}_p = \mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top.$$

As colunas de $\mathbf{V}_0$ pertencem a

$$\mathcal{N}(\mathbf{A}),$$

de modo que

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$


Assim,

$$\begin{aligned} \mathbf{A} &= \mathbf{A} \mathbf{I}_p \\ &= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\ &= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

A SVD compacta utiliza exatamente as direções que participam da transformação:

- as colunas de $\mathbf{V}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A}^\top)$;
- $\mathbf{D}_r$ contém os fatores de escalonamento positivos;
- as colunas de $\mathbf{U}_r$ formam uma base ortonormal de $\mathcal{C}(\mathbf{A})$.

A construção anterior permite concluir a demonstração do Teorema 6.1.



i Demonstração

Se

$$\mathbf{A} = \mathbf{0},$$

tome

$$\mathbf{U} = \mathbf{I}_q, \quad \mathbf{V} = \mathbf{I}_p$$

e

$$\mathbf{D} = \mathbf{0}_{q \times p}.$$

Então,

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Suponha agora que

$$\text{453}$$

$$\mathbf{A} \neq \mathbf{0}.$$

Pela Proposição 6.3,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de $\mathbf{U}_r$ formam uma base ortonormal de

6.2.4 Decomposições espectrais associadas

Proposição 6.4 (Decomposições espectrais induzidas pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

i Demonstração

Utilizando a SVD compacta,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top. \end{aligned}$$

Como as colunas de $\mathbf{U}_r$ são ortonormais,

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Analogamente,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A} \mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A} \mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

As duas decomposições também identificam os espaços aos quais pertencem os vetores singulares:

$$\mathbf{v}_j \in \mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q.$$

Portanto, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio. Os valores singulares positivos realizam a ligação entre esses dois espaços.

6.2.5 Exemplo de construção da SVD

Exemplo 6.2 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned}
\mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\
&= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\
&= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.
\end{aligned}$$

O segundo é

$$\begin{aligned}
\mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\
&= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.
\end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A}\mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A}\mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, pode-se escolher uma SVD na qual, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

6.2.7 Aprofundamento: SVD de matrizes simétricas indefinidas

Leitura de aprofundamento

Esta seção examina a relação entre a decomposição espectral e a SVD quando uma matriz simétrica possui autovalores negativos. Nesse caso, os valores singulares correspondem aos módulos dos autovalores, enquanto seus sinais são incorporados a uma das matrizes ortogonais da SVD.

Esse desenvolvimento complementa o caso semidefinido positivo apresentado anteriormente,

mas não é necessário para acompanhar as aplicações principais da SVD às matrizes de Gram, às matrizes de dados e às estruturas de covariância.

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j)|\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_\mathbf{A},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_\mathbf{A} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_\mathbf{A}\mathbf{\Lambda}_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como a transformação leva a bola unitária do domínio a um elipsoide contido na imagem de $\mathbf{A}$, cujos semieixos são determinados pelos valores e vetores singulares. O comportamento da esfera unitária dependerá da existência ou não de direções pertencentes ao núcleo.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \sum_{j=1}^p \alpha_j \mathbf{Av}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Proposição 6.5 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto $r \geq 1$. A imagem da bola unitária por $\mathbf{A}$ é o elipsoide sólido de dimensão r , contido em $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$


Em particular,

$$\mathbf{A}(\mathcal{B}_p) \subseteq \mathcal{C}(\mathbf{A}),$$

e a dimensão desse elipsoide é

$$\dim(\mathcal{C}(\mathbf{A})) = r.$$

No caso extremo $\mathbf{A} = \mathbf{0}$, a imagem da bola unitária reduz-se ao conjunto $\{\mathbf{0}\}$.



i Demonstração

Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado. Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

O comportamento da esfera unitária depende da existência de um núcleo não trivial.

Se $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso, a imagem da esfera unitária

$$\mathcal{S}_{p-1} = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| = 1\}$$

é a fronteira relativa do elipsoide

$$\mathbf{A}(\mathcal{B}_p)$$

no subespaço $\mathcal{C}(\mathbf{A})$.

Por outro lado, se

$$r < p,$$

então

$$\dim(\mathcal{N}(\mathbf{A})) = p - r > 0.$$

Nesse caso, a imagem da esfera unitária coincide com a imagem da bola unitária:

$$\mathbf{A}(\mathcal{S}_{p-1}) = \mathbf{A}(\mathcal{B}_p).$$

De fato, para qualquer ponto do elipsoide cuja componente nas direções $\mathbf{v}_1, \dots, \mathbf{v}_r$ tenha norma menor que 1, pode-se acrescentar uma componente pertencente ao núcleo até obter um vetor de norma 1, sem alterar sua imagem por $\mathbf{A}$.

Finalmente, se

$$r < q,$$

o elipsoide não ocupa todo o espaço de chegada. Ele está contido no subespaço de dimensão r

$$\mathcal{C}(\mathbf{A}) = \text{span} \{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a geometria da imagem da bola revela simultaneamente os fatores de escala da transformação e a dimensão de sua imagem.

6.3.2 Alteração dos comprimentos

Os valores singulares permitem determinar os fatores extremos de alteração dos comprimentos produzidos pela transformação.

Proposição 6.6 (Extremos da alteração dos comprimentos). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto $r \geq 1$, com valores singulares positivos ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Então, para todo

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

Consequentemente,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p,$$

então

$$d_p \|\mathbf{x}\| \leq \|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|$$

para todo $\mathbf{x} \in \mathbb{R}^p$, e


$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se

$$r < p,$$

então

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$



O maior valor singular d_1 representa, portanto, o maior fator de ampliação produzido pela transformação. Quando $\mathbf{A}$ possui posto coluna completo, o menor valor singular d_p representa o menor fator de alteração de comprimento entre vetores unitários. Quando o posto coluna não é completo, existem direções unitárias eliminadas pela transformação, e o menor comprimento possível da imagem é zero.

Esses extremos serão retomados posteriormente na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.3 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;

- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal de $\mathbb{R}^2$ e identificam duas direções sobre a circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

Neste exemplo, as bases singulares do domínio e do contradomínio são distintas. A matriz $\mathbf{V}^T$ expressa os pontos da circunferência nas coordenadas da base formada por $\mathbf{v}_1$ e $\mathbf{v}_2$. Como essa transformação é ortogonal, a circunferência permanece uma circunferência. Em seguida, $\mathbf{D}$ realiza a deformação, multiplicando os comprimentos nas duas direções por d_1 e d_2 . Finalmente, $\mathbf{U}$ orienta os semieixos da elipse nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$ no espaço de chegada.

6.3.4 Transformações com núcleo não trivial

Quando

$$r < p,$$

a transformação possui núcleo não trivial e elimina $p - r$ direções linearmente independentes do domínio. Geometricamente, a imagem da bola unitária passa a ter dimensão inferior à dimensão do domínio.

Exemplo 6.4 (Colapso de uma direção pela transformação). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A ação da transformação sobre um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

é

$$\mathbf{A}_0 \mathbf{x} = \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix}.$$

Portanto, toda a direção

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

é eliminada, pois

$$\mathbf{A}_0 \mathbf{e}_2 = \mathbf{0}.$$

De fato,

$$\mathcal{N}(\mathbf{A}_0) = \text{span} \{ \mathbf{e}_2 \}.$$

A bola unitária de $\mathbb{R}^2$ é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

Assim, a imagem possui dimensão 1, que coincide com

$$\text{posto}(\mathbf{A}_0) = 1.$$

O valor singular positivo $d_1 = 2$ determina o comprimento do único semieixo não nulo, enquanto o valor singular $d_2 = 0$ identifica a direção eliminada pela transformação.

De modo geral:

- cada valor singular positivo produz um semieixo não nulo da imagem;
- existem exatamente r semieixos não nulos;
- o núcleo possui dimensão $p - r$ e contém todas as direções que são transformadas no vetor nulo;
- a dimensão do elipsoide resultante é r ;
- o elipsoide está contido em $\mathcal{C}(\mathbf{A})$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores e normas diretamente a partir dos vetores e valores singulares. Aspectos relacionados ao condicionamento numérico serão apresentados posteriormente como leitura de aprofundamento.

6.4 Espaços fundamentais, posto e normas

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Proposição 6.7 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_q\} = \mathcal{C}(\mathbf{U}_0).$$

(*Golub; Van Loan, 2013*)



i Demonstração

Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.4.

Tabela 6.4: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^\top).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

A identificação das bases dos quatro espaços fundamentais permite construir diretamente seus projetores ortogonais.

Proposição 6.8 (Projetores dos espaços fundamentais pela SVD). *Considere a SVD completa escrita como*

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Então, os projetores ortogonais sobre os quatro espaços fundamentais são

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

i Demonstração

Pela Proposição 6.7,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r)$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

Como as colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ são ortonormais, a Proposição 3.14 fornece

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)} = \mathbf{U}_0 \mathbf{U}_0^\top.$$

Além disso, como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U} \mathbf{U}^\top = \mathbf{I}_q.$$

Portanto,

$$\mathbf{U}_r \mathbf{U}_r^\top + \mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q,$$

de onde

$$\mathbf{U}_0 \mathbf{U}_0^\top = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^\top.$$

Aplicando o mesmo argumento a

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

obtêm-se

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

e

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top.$$

Como são projetores ortogonais, essas matrizes são simétricas e idempotentes, conforme as

propriedades estudadas no Capítulo 3.

Exemplo 6.5 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned}\mathbf{U}_2\mathbf{U}_2^\top &= \mathbf{u}_1\mathbf{u}_1^\top + \mathbf{u}_2\mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}.\end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3\mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2\mathbf{U}_2^\top + \mathbf{u}_3\mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

Pela SVD, o posto de $\mathbf{A}$ é exatamente o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r = \#\{j : d_j > 0\}.$$

Como consequência do Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Essas dimensões também são visualizadas diretamente na SVD completa:

- as r colunas de $\mathbf{V}_r$ formam uma base do espaço linha;
- as $p - r$ colunas de $\mathbf{V}_0$ formam uma base do núcleo de $\mathbf{A}$;
- as r colunas de $\mathbf{U}_r$ formam uma base do espaço coluna;
- as $q - r$ colunas de $\mathbf{U}_0$ formam uma base do núcleo de $\mathbf{A}^\top$.

É importante distinguir essas dimensões do número de posições diagonais nulas de $\mathbf{D}$. Como

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

possui apenas

$$s = \min(q, p)$$

posições diagonais, existem

$$s - r$$

valores singulares nulos entre essas posições, enquanto as dimensões dos dois núcleos são, respectivamente,

$$p - r \quad \text{e} \quad q - r.$$

Assim, em matrizes retangulares, a estrutura completa dos núcleos não deve ser inferida apenas pela quantidade de elementos diagonais nulos de $\mathbf{D}$.

A Tabela 6.5 reúne as principais relações entre os valores e vetores singulares e a estrutura da transformação.

Tabela 6.5: Relação entre a SVD e a estrutura da matriz.

Estrutura ou propriedade	Caracterização pela SVD
Posto	Número de valores singulares positivos
Imagem $\mathcal{C}(\mathbf{A})$	Vetores singulares à esquerda associados a $d_j > 0$

Estrutura ou propriedade	Caracterização pela SVD
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	Vetores singulares à direita associados a $d_j > 0$
Núcleo $\mathcal{N}(\mathbf{A})$	Vetores singulares à direita associados à parte nula
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	Vetores singulares à esquerda associados à parte nula
Ampliação máxima	d_1
Menor fator positivo de escala	d_r

Se $r < p$, a menor norma de $\mathbf{A}\mathbf{x}$ entre todos os vetores unitários do domínio é zero, pois existem vetores unitários no núcleo. O valor d_r descreve o menor fator **positivo** de escala, isto é, a menor ação da transformação quando restrita ao espaço linha $\mathcal{C}(\mathbf{A}^\top)$.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.6 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o **produto interno de Frobenius** é

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = \text{tr}(\mathbf{A}^\top \tilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \tilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.7 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr}(\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.8 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Proposição 6.9 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \cdots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub; Van Loan, 2013)

i Demonstração

Pela Proposição 6.6,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\| = d_1.$$

Como, pela Definição 6.8,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|,$$

segue imediatamente que

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius, utilizando a Proposição 6.4,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Portanto,

$$\begin{aligned} \|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\ &= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\ &= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\ &= \text{tr}(\mathbf{D}_r^2) \\ &= \sum_{j=1}^r d_j^2. \end{aligned}$$

Logo,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Se $\mathbf{A} = \mathbf{0}$, então não há valores singulares positivos e, diretamente pelas definições,

$$\|\mathbf{A}\|_2 = \|\mathbf{A}\|_F = 0.$$

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r}\|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Proposição 6.10 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub; Van Loan, 2013)

i Demonstração

Para a norma espectral, como $\mathbf{Q}_1$ preserva normas,

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2 \mathbf{x}\| = \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\|.$$

Como $\mathbf{Q}_2$ é ortogonal, a transformação

$$\mathbf{z} = \mathbf{Q}_2 \mathbf{x}$$

preserva a norma e percorre todos os vetores unitários quando $\mathbf{x}$ percorre a esfera unitária. Portanto,

$$\begin{aligned}\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 &= \max_{\|\mathbf{x}\|=1} \|\mathbf{A} \mathbf{Q}_2 \mathbf{x}\| \\ &= \max_{\|\mathbf{z}\|=1} \|\mathbf{A} \mathbf{z}\| \\ &= \|\mathbf{A}\|_2.\end{aligned}$$

Para a norma de Frobenius,

$$\begin{aligned}\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F^2 &= \text{tr} \left[(\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2)^\top (\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2) \right] \\ &= \text{tr} (\mathbf{Q}_2^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}_2) \\ &= \text{tr} (\mathbf{A}^\top \mathbf{A} \mathbf{Q}_2 \mathbf{Q}_2^\top) \\ &= \text{tr} (\mathbf{A}^\top \mathbf{A}) \\ &= \|\mathbf{A}\|_F^2.\end{aligned}$$

Logo, ambas as normas são invariantes sob multiplicações ortogonais.

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p = q,$$

de modo que não existem direções singulares associadas ao valor zero. Assim, as formas compacta e completa possuem as mesmas dimensões e podem ser escritas com os mesmos fatores:

$$\mathbf{U}_r = \mathbf{U}, \quad \mathbf{D}_r = \mathbf{D}, \quad \mathbf{V}_r = \mathbf{V}.$$

6.4.8 Aprofundamento: condicionamento e posto numérico

Leitura de aprofundamento

Esta seção apresenta duas extensões de natureza numérica da interpretação dos valores singulares. A primeira utiliza a razão entre os valores singulares extremos para avaliar o condicionamento de uma transformação. A segunda distingue o posto algébrico do posto numérico obtido após a adoção de uma tolerância computacional.

Esses conceitos são importantes para estabilidade numérica, problemas inversos e algoritmos matriciais, mas não são necessários para acompanhar os resultados centrais sobre espaços fundamentais, aproximações de posto reduzido e aplicações estatísticas da SVD.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e defina

$$s = \min(q, p).$$

Quando

$$\text{posto}(\mathbf{A}) = s,$$

a matriz possui o maior posto possível para suas dimensões e todos os seus s valores singulares são positivos:

$$d_1 \geq \dots \geq d_s > 0.$$

Definição 6.9 (Número de condição na norma espectral). Para uma matriz de posto máximo,

$$\text{posto}(\mathbf{A}) = s,$$

define-se o **número de condição na norma espectral** por

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Quando

$$\text{posto}(\mathbf{A}) < s,$$

adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

(Golub; Van Loan, 2013)

O número de condição compara o maior e o menor fatores positivos de escala associados à parte ativa da transformação.

Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

os valores singulares extremos possuem magnitudes semelhantes. Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são transformadas por fatores muito maiores que outras.

É importante distinguir **núcleo não trivial**, **deficiência de posto** e **mau condicionamento**.

A deficiência de posto ocorre quando

$$\text{posto}(\mathbf{A}) < \min(q, p).$$

Entretanto, uma matriz retangular pode possuir núcleo não trivial mesmo apresentando posto máximo.

Por exemplo, se

$$q < p$$

e

$$\text{posto}(\mathbf{A}) = q,$$

então $\mathbf{A}$ possui posto linha completo e, portanto, posto máximo. Mesmo assim,

$$\dim \mathcal{N}(\mathbf{A}) = p - q > 0.$$

Assim, existem direções do domínio que são transformadas no vetor nulo.

Nesse caso, a transformação não é injetiva em todo o domínio $\mathbb{R}^p$. Sua restrição ao espaço linha,

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp,$$

é, entretanto, injetiva.

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{Ax}\|.$$

Portanto, para matrizes largas de posto linha completo, o número de condição finito descreve a variação dos fatores de escala sobre o espaço linha, isto é, sobre a parte do domínio na qual a transformação atua de forma injetiva.

Se

$$q \geq p$$

e

$$\text{posto}(\mathbf{A}) = p,$$

então $\mathbf{A}$ possui posto coluna completo e

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Nesse caso,

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Para uma matriz quadrada invertível,

$$q = p = r,$$

tem-se também

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Portanto,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p},$$

de modo que

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

Uma matriz de posto máximo com número de condição elevado é denominada **mal condicionada**. Valores singulares positivos muito pequenos indicam direções nas quais a transformação produz forte contração. Ao inverter a ação da matriz nessas direções, pequenas perturbações podem ser amplificadas.

Esse fenômeno será retomado posteriormente na discussão da pseudoinversa.

Exemplo 6.6 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

Nesse caso, as duas direções singulares são transformadas pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por um fator igual a 2, enquanto a segunda é contraída por um fator igual a 0,02.

A inversão da segunda componente exige um fator

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem ser fortemente ampliadas quando se procura inverter a transformação.

6.4.8.1 Posto exato e posto numérico

Matematicamente, o posto é determinado exatamente pelos valores singulares positivos:

$$\text{posto}(\mathbf{A}) = \# \{j : d_j > 0\}.$$

Em cálculos computacionais, entretanto, valores que seriam exatamente nulos em aritmética exata podem aparecer como números positivos muito pequenos em razão de arredondamentos, aproximações ou ruído.

Por isso, pode-se adotar uma tolerância

$$\tau \geq 0$$

e tratar como numericamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

Definição 6.10 (Posto numérico). Fixada uma tolerância $\tau \geq 0$, o **posto numérico** de $\mathbf{A}$ é definido por

$$r_\tau(\mathbf{A}) = \#\{j : d_j > \tau\}.$$

Diferentemente do posto algébrico, o posto numérico depende da tolerância adotada.

A escolha de τ pode depender de fatores como:

- precisão numérica;
- escala da matriz;
- dimensões da matriz;
- finalidade da análise;
- nível de perturbação ou ruído considerado relevante.

Portanto, dois valores devem ser distinguidos:

$$\text{posto}(\mathbf{A}) = \#\{j : d_j > 0\}$$

e

$$r_\tau(\mathbf{A}) = \#\{j : d_j > \tau\}.$$

Essa distinção será particularmente útil quando forem estudadas aproximações de posto reduzido. Nessas aproximações, valores singulares matematicamente positivos podem ser descartados deliberadamente quando sua contribuição é considerada pequena.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, a SVD recupera a dupla representação da matriz de dados introduzida no Capítulo 1:

- as colunas de $\mathbf{V}_r$ pertencem a $\mathbb{R}^p$ e determinam direções no espaço em que as observações são representadas;
- as colunas de $\mathbf{U}_r$ pertencem a $\mathbb{R}^n$ e determinam direções no espaço em que as variáveis são representadas.

Os mesmos valores singulares conectam essas duas representações.

6.5.1 Dualidade entre observações e variáveis

A SVD relaciona diretamente as duas representações da matriz de dados: as observações como vetores em $\mathbb{R}^p$ e as variáveis como vetores em $\mathbb{R}^n$.

Proposição 6.11 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

então

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

Consequentemente, para

$$j = 1, \dots, r,$$

tem-se

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, o mesmo valor singular d_j relaciona uma direção $\mathbf{v}_j$ no espaço das observações $\mathbb{R}^p$ a uma direção $\mathbf{u}_j$ no espaço das variáveis $\mathbb{R}^n$.

i Demonstração

Multiplicando a SVD compacta à direita por $\mathbf{V}_r$,

$$\begin{aligned} \mathbf{X} \mathbf{V}_r &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \\ &= \mathbf{U}_r \mathbf{D}_r, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Transpondo a SVD compacta,

$$\mathbf{X}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top.$$

Multiplicando à direita por $\mathbf{U}_r$,

$$\begin{aligned} \mathbf{X}^\top \mathbf{U}_r &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \\ &= \mathbf{V}_r \mathbf{D}_r, \end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

As relações correspondentes a cada coluna seguem diretamente dessas duas identidades matriciais.

6.5.2 Coordenadas das observações nas direções singulares à direita

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Pela Proposição 6.11,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações na base ortonormal

$$\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$$

do espaço linha

$$\mathcal{C}(\mathbf{X}^\top) \subseteq \mathbb{R}^p.$$

Como cada observação pertence a esse subespaço, as r coordenadas são suficientes para representá-la exatamente.

Se a linha i de $\mathbf{X}$ corresponde ao vetor

$$\mathbf{x}_i \in \mathbb{R}^p,$$

então

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Portanto, z_{ij} é a coordenada da observação i na direção singular $\mathbf{v}_j$.

A j -ésima coluna de $\mathbf{Z}$ é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Assim, $\mathbf{v}_j$ determina a direção utilizada para representar as observações, enquanto $\mathbf{u}_j$ descreve como as coordenadas correspondentes se distribuem entre as n unidades observacionais.

6.5.3 Coordenadas das variáveis nas direções singulares à esquerda

A relação dual é

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top.$$

Defina

$$\mathbf{W} = \mathbf{U}_r^\top \mathbf{X} \in \mathbb{R}^{r \times p}.$$

Cada coluna de $\mathbf{X}$ representa uma variável como vetor em $\mathbb{R}^n$. Se

$$\mathbf{x}^{(j)} \in \mathbb{R}^n$$

denota a j -ésima variável, então a j -ésima coluna de $\mathbf{W}$ contém suas coordenadas na base ortonormal

$$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$$

do espaço coluna

$$\mathcal{C}(\mathbf{X}) \subseteq \mathbb{R}^n.$$

Para a direção singular ℓ ,

$$\mathbf{u}_\ell^\top \mathbf{x}^{(j)} = d_\ell v_{j\ell}.$$

Portanto, os elementos de $\mathbf{V}_r$, escalonados pelos valores singulares, também descrevem as coordenadas das variáveis na base singular à esquerda.

As relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam, assim, a dualidade entre o espaço das observações e o espaço das variáveis.

6.5.4 Matrizes de Gram da matriz de dados

As duas matrizes de Gram associadas a $\mathbf{X}$ descrevem relações entre objetos diferentes.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

reúne os produtos internos entre as colunas de $\mathbf{X}$, isto é, entre as variáveis representadas como vetores em $\mathbb{R}^n$.

A matriz

$$\mathbf{X}\mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

reúne os produtos internos entre as linhas de $\mathbf{X}$, isto é, entre as observações representadas como vetores em $\mathbb{R}^p$.

Pela Proposição 6.4,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto, as duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ determina uma direção no espaço das observações;
- $\mathbf{u}_j \in \mathbb{R}^n$ determina uma direção no espaço das variáveis.

Essa dualidade também pode ser útil quando as dimensões da matriz são muito diferentes. Se

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Se

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

possui ordem menor.

Em ambos os casos, os valores próprios positivos são os mesmos e correspondem aos quadrados dos valores singulares de $\mathbf{X}$.

6.5.5 Representação exata das observações

Proposição 6.12 (Preservação da geometria pelas coordenadas singulares). *Seja*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de dados e defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Então,

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top$$

e

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Consequentemente, para quaisquer observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell,$$

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

i Demonstração

Como

$$\mathbf{Z} = \mathbf{U}_r \mathbf{D}_r,$$

segue da SVD compacta que

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{Z} \mathbf{V}_r^\top.$$

Além disso,

$$\begin{aligned} \mathbf{Z} \mathbf{Z}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top. \end{aligned}$$

Pela Proposição 6.4,

$$\mathbf{X} \mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Portanto,

$$\mathbf{Z} \mathbf{Z}^\top = \mathbf{X} \mathbf{X}^\top.$$

Os elementos dessas duas matrizes são os produtos internos entre pares de observações. Logo,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Tomando $i = \ell$, obtém-se

$$\|\mathbf{x}_i\|^2 = \|\mathbf{z}_i\|^2.$$

Finalmente,

$$\begin{aligned} \|\mathbf{x}_i - \mathbf{x}_\ell\|^2 &= \|\mathbf{x}_i\|^2 + \|\mathbf{x}_\ell\|^2 - 2\mathbf{x}_i^\top \mathbf{x}_\ell \\ &= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_\ell\|^2 - 2\mathbf{z}_i^\top \mathbf{z}_\ell \\ &= \|\mathbf{z}_i - \mathbf{z}_\ell\|^2. \end{aligned}$$

A reconstrução de cada observação pode ser escrita como

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto,

$$\mathbf{x}_i \in \mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

as observações podem ser representadas exatamente por apenas r coordenadas, sem alteração de seus produtos internos, normas ou distâncias euclidianas.

Essa situação pode ocorrer mesmo quando $\mathbf{X}$ possui o maior posto possível para suas dimensões. Por exemplo, se

$$n < p$$

e

$$r = n,$$

a matriz possui posto linha completo, mas ainda assim

$$r < p.$$

Nesse caso, as observações ocupam um subespaço de dimensão r dentro de $\mathbb{R}^p$ e sua representação por $\mathbf{Z}$ é exata.

6.5.6 Centralização da matriz de dados

A posição da nuvem depende de seu centro. Para estudar os afastamentos em relação ao vetor de médias, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Proposição 6.13 (Vetores singulares à esquerda de uma matriz centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados centralizada, então

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Consequentemente,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r,$$

e as colunas da matriz de coordenadas

$$\mathbf{Z} = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

também possuem média igual a zero.

i Demonstração

Como as colunas de $\mathbf{X}_c$ estão centralizadas,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD compacta,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui colunas ortonormais, segue que

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto,

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

tem-se também

$$\mathbf{1}_n^\top \mathbf{z}_j = 0.$$

6.5.7 Antecipação: relação com a matriz de covariâncias amostral

A definição estatística e as propriedades da matriz de covariâncias amostral serão desenvolvidas nos capítulos posteriores dedicados à covariância e às estatísticas amostrais. Neste ponto, interessa apenas sua relação algébrica com a SVD da matriz centralizada.

Para $n \geq 2$, adotando temporariamente a notação

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se o seguinte resultado.

Proposição 6.14 (Relação entre a SVD e a covariância amostral). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Consequentemente:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$ associados aos autovalores positivos;
- os autovalores positivos de $\mathbf{S}$ são

$$\lambda_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r;$$

- tem-se

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) = r.$$

i Demonstração

Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c \\ &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top, \end{aligned}$$

pois

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r.$$

A expressão obtida é uma decomposição espectral de $\mathbf{S}$ em seu subespaço associado aos autovalores positivos. Portanto, os autovetores correspondentes são as colunas de $\mathbf{V}_r$ e os autovalores positivos são

$$\frac{d_j^2}{n-1}.$$

Como $\mathbf{D}_r$ possui exatamente r elementos diagonais positivos,

$$\text{posto}(\mathbf{S}) = r.$$

A centralização impõe ainda uma restrição ao posto. Como

$$\text{posto}(\mathbf{H}_n) = n - 1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n - 1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n - 1, p).$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz de covariâncias amostral é necessariamente singular.

Essas relações serão retomadas posteriormente em sua formulação estatística. Aqui, elas mostram que a SVD da matriz centralizada determina diretamente a estrutura espectral da matriz de covariâncias amostral.

6.5.8 Magnitude quadrática da matriz centralizada

Proposição 6.15 (Magnitude quadrática da nuvem centralizada). *Se*

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta da matriz de dados centralizada, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Além disso, se

$$\mathbf{S} = \frac{1}{n - 1} \mathbf{X}_c^\top \mathbf{X}_c,$$

então

$$\|\mathbf{X}_c\|_F^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

Consequentemente,

$$\sum_{j=1}^r d_j^2 = (n-1) \operatorname{tr}(\mathbf{S}).$$

i Demonstração

Pela Proposição 6.9,

$$\|\mathbf{X}_c\|_F^2 = \sum_{j=1}^r d_j^2.$$

Por outro lado,

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1) \mathbf{S}.$$

Logo,

$$\begin{aligned} \|\mathbf{X}_c\|_F^2 &= \operatorname{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= (n-1) \operatorname{tr}(\mathbf{S}). \end{aligned}$$

Se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias das observações, então

$$\|\mathbf{X}_c\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

Portanto,

$$\sum_{j=1}^r d_j^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2.$$

A soma dos quadrados dos valores singulares da matriz centralizada representa, assim, a soma quadrática total dos afastamentos das observações em relação ao centro da nuvem.

Como $\text{tr}(\mathbf{S})$ é a soma dos elementos diagonais de $\mathbf{S}$, ela corresponde à soma das variâncias amostrais das p variáveis.

A centralização é essencial para essa interpretação. Para uma matriz não centralizada,

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2$$

mede a soma dos quadrados das posições em relação à origem, e não a dispersão das observações em torno de seu vetor de médias.

Exemplo 6.7 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cujas SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned} \mathbf{Z} &= \mathbf{X} \mathbf{V}_2 \\ &= \mathbf{U}_2 \mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}. \end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das observações. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta fornece a representação exata

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Como todos os r componentes associados a valores singulares positivos são mantidos:

- a matriz é reconstruída exatamente;
- os produtos internos entre as observações são preservados;
- as normas das observações são preservadas;
- as distâncias euclidianas entre as observações são preservadas;
- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão menor pode ser construída conservando apenas os primeiros k pares singulares, com

$$k < r.$$

Nesse caso, componentes associados a valores singulares positivos são deliberadamente descartados e a reconstrução deixa de ser exata.

A distinção fundamental é, portanto:

- a **SVD compacta** omite dos fatores completos apenas direções associadas à parte nula da transformação e preserva exatamente a matriz;
- a **SVD truncada** descarta também componentes associados a valores singulares positivos e produz uma aproximação.

A forma expandida da SVD permitirá identificar separadamente a contribuição de cada componente singular e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta também pode ser expressa como uma soma de componentes matriciais associados aos pares singulares.

Proposição 6.16 (Forma expandida da SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

possui posto 1 e satisfaz

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$



i Demonstração

Escrevendo

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

tem-se

$$\begin{aligned} \mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top. \end{aligned}$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Multiplicar por $d_j > 0$ não altera o posto, de modo que

$$\text{posto}(d_j \mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

Para a norma espectral, se $\|\mathbf{x}\| = 1$,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top \mathbf{x}\| &= d_j |\mathbf{v}_j^\top \mathbf{x}| \|\mathbf{u}_j\| \\ &\leq d_j. \end{aligned}$$

A igualdade é atingida para

$$\mathbf{x} = \mathbf{v}_j.$$

Portanto,

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_2 = d_j.$$

Para a norma de Frobenius,

$$\begin{aligned} \|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F^2 &= d_j^2 \text{tr}(\mathbf{v}_j \mathbf{u}_j^\top \mathbf{u}_j \mathbf{v}_j^\top) \\ &= d_j^2 (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\ &= d_j^2. \end{aligned}$$

Logo,

515

$$\|d_j \mathbf{u}_j \mathbf{v}_j^\top\|_F = d_j.$$

A expressão

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é denominada **forma expandida da SVD**.

Cada componente singular representa uma transformação de posto 1: a componente do vetor de entrada na direção $\mathbf{v}_j$ é multiplicada por d_j e enviada para a direção $\mathbf{u}_j$.

Como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0,$$

os componentes singulares estão ordenados de acordo com suas magnitudes nas normas espectral e de Frobenius.

6.6.1 Ortogonalidade dos componentes singulares

Proposição 6.17 (Ortogonalidade dos componentes singulares). *Para*

$$i \neq j,$$

os componentes singulares

$$d_i \mathbf{u}_i \mathbf{v}_i^\top$$

e

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius:

$$\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \rangle_F = 0.$$

i Demonstração

Pelo produto interno de Frobenius,

$$\begin{aligned}\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \rangle_F \\&= d_i d_j \operatorname{tr} [(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top)] \\&= d_i d_j (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i).\end{aligned}$$

Como os vetores singulares são ortonormais, para $i \neq j$,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Logo,

$$\langle d_i \mathbf{u}_i \mathbf{v}_i^\top, d_j \mathbf{u}_j \mathbf{v}_j^\top \rangle_F = 0.$$

Como a forma expandida é uma soma de componentes ortogonais segundo o produto interno de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Essa igualdade fornece uma decomposição pitagórica da magnitude quadrática total da matriz entre seus componentes singulares.

6.6.2 SVD truncada na forma expandida

Retomando a Definição 6.5, a aproximação de posto k pode ser expressa diretamente a partir da forma expandida da SVD.

Se

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

então

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Assim, truncar a SVD corresponde a conservar as primeiras k parcelas singulares e descartar

$$\sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa representação permitirá quantificar o erro produzido pelo truncamento e estabelecer as propriedades de otimalidade de $\mathbf{A}_k$.

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.3 Erros produzidos pelo truncamento

Proposição 6.18 (Decomposição e erros da SVD truncada). *Se*

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top, \quad 1 \leq k < r,$$

então

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Além disso,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0,$$

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2,$$


$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$



i Demonstração

Pela forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Subtraindo

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

obtém-se

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Pela Proposição 6.17, os componentes associados a índices diferentes são ortogonais segundo o produto interno de Frobenius. Como $\mathbf{A}_k$ utiliza os índices

$$1, \dots, k$$

e a diferença utiliza

$$k+1, \dots, r,$$

segue que

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Aplicando a decomposição pitagórica,

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Portanto,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

Por outro lado, a matriz residual

$$\mathbf{A} - \mathbf{A}_k$$

possui valores singulares positivos

$$d_{k+1}, d_{k+2}, \dots, d_r.$$

Pela Proposição 6.9, sua norma espectral é igual ao maior desses valores:

A proporção da magnitude quadrática de Frobenius preservada pela aproximação pode ser escrita como

$$\eta_k = \frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}.$$

A proporção descartada é

$$1 - \eta_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

Para uma matriz genérica, η_k mede exclusivamente a proporção de sua magnitude quadrática, segundo a norma de Frobenius, representada pelos primeiros k componentes singulares. Essa quantidade não deve ser interpretada automaticamente como proporção de variância ou de informação estatística.

Quando $\mathbf{A}$ é uma matriz de dados centralizada, entretanto,

$$\|\mathbf{A}\|_F^2$$

corresponde à soma quadrática total dos afastamentos das observações em relação ao centro da nuvem. Nesse contexto específico, η_k representa a proporção dessa dispersão quadrática preservada pelos primeiros k componentes singulares.

A norma espectral descreve outro aspecto do erro. Como

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1},$$

o primeiro valor singular descartado determina o maior erro produzido pelo truncamento sobre qualquer vetor unitário:

$$d_{k+1} = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

Esse máximo é atingido, por exemplo, na direção

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

Assim, a norma espectral mede um erro de pior caso, enquanto a norma de Frobenius agrega quadraticamente os erros associados a todos os componentes singulares descartados.

6.6.4 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.2 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\tilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \tilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub; Van Loan, 2013)

6.6.5 Aprofundamento: demonstração e unicidade da melhor aproximação

Leitura de aprofundamento

O Teorema de Eckart–Young–Mirsky estabelece a otimalidade da SVD truncada sem exigir que sua demonstração seja utilizada nas aplicações posteriores.

Nesta leitura de aprofundamento, demonstra-se a otimalidade separadamente nas normas espectral e de Frobenius e examina-se quando a melhor aproximação de posto reduzido é ou não única.



O teorema mostra que nenhuma matriz de posto no máximo k pode apresentar erro menor que $\mathbf{A}_k$ nas duas normas consideradas.

Na norma espectral, o erro ótimo é determinado exclusivamente pelo primeiro valor singular descartado,

$$d_{k+1}.$$

Na norma de Frobenius, o erro ótimo depende de toda a parcela espectral descartada,

$$\sqrt{\sum_{j=k+1}^r d_j^2}.$$

6.6.5.1 Unicidade da aproximação

A otimalidade estabelecida pelo Teorema 6.2 não implica, em geral, que a matriz aproximante seja única. A situação depende também da norma considerada.

Na norma de Frobenius, a melhor aproximação de posto no máximo k é única quando há separação estrita entre os valores singulares que ficam em lados opostos do truncamento:

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o ponto de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de subespaços dentro desse bloco singular podem produzir aproximações ótimas distintas.

Na norma espectral, a matriz

$$\mathbf{A}_k$$

é sempre uma aproximação ótima, mas a aproximação ótima pode não ser única mesmo quando

$$d_k > d_{k+1}.$$

Isso ocorre porque outras matrizes de posto no máximo k podem produzir o mesmo erro máximo

$$d_{k+1}.$$

Portanto, a condição

$$d_k > d_{k+1}$$

garante unicidade da melhor aproximação na norma de Frobenius, mas não deve ser utilizada como critério geral de unicidade na norma espectral.

Quando

$$k \geq r,$$

não há truncamento de componentes singulares positivos e a representação exata é

$$\mathbf{A}_k = \mathbf{A},$$

com erro igual a zero.

6.6.6 Exemplo de aproximação de posto 1

Exemplo 6.8 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned} \mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\ &= 2 \left(\frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right) \left(\frac{1}{\sqrt{2}} [1 \quad 1] \right) \\ &= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}. \end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

Neste exemplo, as normas espectral e de Frobenius do erro coincidem porque a matriz residual possui apenas um valor singular positivo. Quando mais de um componente singular é descartado, os dois erros são, em geral, diferentes.

6.6.7 Aproximação de uma matriz de dados

A SVD truncada possui uma interpretação direta como projeção das observações em um subespaço de menor dimensão.

Proposição 6.19 (SVD truncada como projeção das observações). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados e

$$1 \leq k < r,$$

então sua aproximação truncada satisfaz

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X} \mathbf{V}_k \mathbf{V}_k^\top.$$

Como

$$\mathbf{P}_k = \mathbf{V}_k \mathbf{V}_k^\top$$

é o projetor ortogonal sobre

$$\mathcal{S}_k = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \},$$

cada linha de $\mathbf{X}_k$ é a projeção ortogonal da observação correspondente sobre $\mathcal{S}_k$.

Se

$$\mathbf{Z}_k = \mathbf{X} \mathbf{V}_k,$$

então

$$\mathbf{Z}_k = \mathbf{U}_k \mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k \mathbf{V}_k^\top.$$

i Demonstração

Pela relação

$$\mathbf{X}\mathbf{V}_k = \mathbf{U}_k\mathbf{D}_k,$$

tem-se

$$\begin{aligned}\mathbf{X}\mathbf{V}_k\mathbf{V}_k^\top &= \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top \\ &= \mathbf{X}_k.\end{aligned}$$

Como as colunas de $\mathbf{V}_k$ são ortonormais,

$$\mathbf{P}_k = \mathbf{V}_k\mathbf{V}_k^\top$$

é o projetor ortogonal sobre $\mathcal{S}_k$.

Portanto, para cada observação $\mathbf{x}_i$,

$$\hat{\mathbf{x}}_{i,k} = \mathbf{P}_k\mathbf{x}_i$$

e, equivalentemente,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij}\mathbf{v}_j.$$

O resíduo correspondente é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij}\mathbf{v}_j.$$

A matriz

$$\mathbf{Z}_k \in \mathbb{R}^{n \times k}$$

fornece uma representação das observações em k coordenadas. A multiplicação por

$$\mathbf{V}_k^\top$$

reconstrói suas aproximações no espaço original $\mathbb{R}^p$.

Além disso,

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2 = \sum_{j=k+1}^r d_j^2.$$

Pelo Teorema 6.2, nenhuma matriz de posto no máximo k possui erro de reconstrução menor na norma de Frobenius. Em particular, entre as representações obtidas pela projeção das observações em subespaços lineares de dimensão no máximo k , o subespaço

$$\mathcal{S}_k = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

minimiza a soma dos erros quadráticos de reconstrução.

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a proporção da dispersão quadrática total da nuvem preservada pelas primeiras k direções singulares.

Essa relação será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, ela deve ser interpretada como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada e a pseudoinversa utilizam os mesmos componentes singulares com finalidades distintas.

Na aproximação de posto reduzido, componentes associados a valores singulares positivos são deliberadamente descartados:

$$\mathbf{A} \longrightarrow \mathbf{A}_k.$$

Na pseudoinversa, todos os componentes associados a valores singulares positivos são mantidos, mas os fatores de escala são invertidos:

$$d_j \longrightarrow \frac{1}{d_j}, \quad j = 1, \dots, r.$$

As direções associadas à parte nula da transformação não são invertidas.

Essa construção conduz à pseudoinversa de Moore–Penrose e, a partir dela, às soluções de sistemas lineares e problemas de mínimos quadrados.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Se $r \geq 1$, todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos. Portanto,

$$\mathbf{D}_r^{-1} = \text{diag}\left(\frac{1}{d_1}, \dots, \frac{1}{d_r}\right)$$

está bem definida.

Se $r = 0$, então $\mathbf{A} = \mathbf{0}$ e sua pseudoinversa será definida como a matriz nula de dimensão $p \times q$.

Definição 6.11 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

No caso $\mathbf{A} = \mathbf{0}$, define-se

$$\mathbf{A}^+ = \mathbf{0}_{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz os escalonamentos de $\mathbf{A}$ nas direções associadas aos valores singulares positivos e anula as componentes pertencentes a

$$\mathcal{N}(\mathbf{A}^\top).$$

Assim, ela atua como uma inversão entre os subespaços

$$\mathcal{C}(\mathbf{A}^\top) \subseteq \mathbb{R}^p$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q,$$

nos quais a ação de $\mathbf{A}$ é não nula.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio de sua decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

então

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que cada autovalor não nulo é substituído por seu inverso e os autovalores nulos permanecem iguais a zero.

A definição baseada na SVD,

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

estende essa construção para qualquer matriz real, inclusive matrizes retangulares e não simétricas.

Quando $\mathbf{A}$ é quadrada e invertível,

$$r = p = q,$$

todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Portanto, a inversa usual constitui um caso particular da pseudoinversa.

6.7.2 Aprofundamento: caracterização de Moore–Penrose

Leitura de aprofundamento

A pseudoinversa foi definida anteriormente a partir da SVD. Existe também uma caracterização independente dessa decomposição: a pseudoinversa de Moore–Penrose é a única matriz que satisfaz simultaneamente quatro identidades algébricas.

Esta seção apresenta essas condições, verifica que a matriz construída pela SVD as satisfaz e demonstra sua unicidade. A caracterização é importante na teoria de inversas generalizadas, mas não é necessária para acompanhar as aplicações posteriores da pseudoinversa a projeções e mínimos quadrados.

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.3 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub; Van Loan, 2013)



6.7.3 Pseudoinversa e projetores

Os produtos envolvendo $\mathbf{A}$ e sua pseudoinversa recuperam os projetores ortogonais dos quatro espaços fundamentais.

Proposição 6.20 (Projetores determinados pela pseudoinversa). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

então

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+\mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Consequentemente,

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

i Demonstração

Pela definição da pseudoinversa,

$$\begin{aligned}\mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top,\end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Pela Proposição 6.8,

$$\mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Analogamente,

$$\begin{aligned}\mathbf{A}^+ \mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top \\ &= \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.\end{aligned}$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathcal{C}(\mathbf{A}^\top)^\perp = \mathcal{N}(\mathbf{A}),$$

os projetores sobre os complementos ortogonais são

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

A Tabela 6.6 resume essas relações.

Tabela 6.6: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A}\mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+ \mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+ \mathbf{A}$	$\mathcal{N}(\mathbf{A})$

Matriz	Espaço projetado
--------	------------------

Os dois produtos atuam em espaços diferentes. A matriz

$$\mathbf{A}\mathbf{A}^+ \in \mathbb{R}^{q \times q}$$

atua no contradomínio e seleciona a componente pertencente à imagem da transformação.

Por outro lado,

$$\mathbf{A}^+\mathbf{A} \in \mathbb{R}^{p \times p}$$

atua no domínio e seleciona a componente pertencente ao espaço linha, isto é, ao complemento ortogonal do núcleo de $\mathbf{A}$.

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

A pseudoinversa permite caracterizar a compatibilidade do sistema, descrever todas as suas soluções e identificar aquela de menor norma.

Proposição 6.21 (Sistemas compatíveis pela pseudoinversa). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

é compatível se, e somente se,

$$\mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Quando o sistema é compatível, o conjunto de todas as soluções é

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todas essas soluções,


$$\mathbf{x}^{\star} = \mathbf{A}^{+}\mathbf{b}$$

é a única de menor norma euclidiana.

Se

$$r = p,$$

o núcleo de $\mathbf{A}$ é trivial e a solução é única.



i Demonstração

O sistema é compatível exatamente quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Pela Proposição 6.20,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})}.$$

Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Suponha que o sistema seja compatível. Então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se $\mathbf{x}$ é qualquer outra solução,

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{x}_0.$$

Logo,

$$\mathbf{A}(\mathbf{x} - \mathbf{x}_0) = \mathbf{0},$$

e, portanto,

$$\mathbf{x} - \mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como as colunas de $\mathbf{V}_0$ formam uma base ortonormal desse núcleo,

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\boldsymbol{\gamma}.$$

6.7.5 Mínimos quadrados

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

pode-se procurar um vetor $\mathbf{x}$ cuja imagem $\mathbf{Ax}$ esteja o mais próxima possível de $\mathbf{b}$.

O problema é

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o erro mínimo é zero e o problema coincide com a resolução de um sistema compatível.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe solução exata e busca-se a melhor aproximação possível dentro do espaço coluna de $\mathbf{A}$.

Definição 6.12 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma **solução de mínimos quadrados** de

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

A pseudoinversa fornece diretamente todas as soluções desse problema.

Proposição 6.22 (Mínimos quadrados pela pseudoinversa). *Para qualquer*

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor ajustado de mínimos quadrados é

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{P}_{\mathcal{C}(\mathbf{A})}\mathbf{b}.$$

O resíduo é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+)\mathbf{b}$$

e satisfaz

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top),$$

ou, equivalentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Consequentemente, uma solução de mínimos quadrados satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

O conjunto de todas as soluções de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre todos os minimizadores,

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+\mathbf{b}$$

é o único de menor norma euclidiana.



A decomposição geométrica correspondente é

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Como essas parcelas são ortogonais,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.5.1 Caso de posto coluna completo

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível, e

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Portanto,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

6.7.5.2 Caso de posto linha completo

Se

$$r = q \leq p,$$

então

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Logo, para todo

$$\mathbf{b} \in \mathbb{R}^q,$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

é compatível.

Nesse caso,

$$\mathbf{AA}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{AA}^\top)^{-1}.$$

A solução

$$\mathbf{x}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução exata de menor norma.

6.7.6 Expressão da solução nas direções singulares

A forma expandida da pseudoinversa permite interpretar diretamente a solução de menor norma nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{A}\mathbf{x}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.7 Aprofundamento: instabilidade e pseudoinversa truncada

Leitura de aprofundamento

A pseudoinversa inverte os valores singulares positivos. Como consequência, valores singulares muito pequenos podem produzir grandes fatores de amplificação na solução. Esta seção examina a sensibilidade da pseudoinversa a perturbações e apresenta a pseudoinversa truncada como uma forma de evitar a inversão de algumas direções singulares. Essas ideias pertencem ao estudo de problemas inversos e regularização e não são necessárias para acompanhar os resultados centrais de mínimos quadrados desenvolvidos neste capítulo.

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned} \Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j. \end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Como os valores singulares positivos de $\mathbf{A}^+$ são

$$\frac{1}{d_r} \geq \dots \geq \frac{1}{d_1},$$

tem-se, para $r \geq 1$,

$$\|\mathbf{A}^+\|_2 = \frac{1}{d_r}.$$

Consequentemente,

$$\|\Delta\hat{\mathbf{x}}\| \leq \frac{1}{d_r}\|\varepsilon\|.$$

O menor valor singular positivo controla, portanto, a maior amplificação possível de uma perturbação pela pseudoinversa.

Esse comportamento relaciona:

- valores singulares positivos pequenos;
- forte amplificação nas direções correspondentes da pseudoinversa;
- sensibilidade a perturbações;
- instabilidade de problemas inversos.

Quando $\mathbf{A}$ possui posto máximo, um menor valor singular muito pequeno em relação a d_1 corresponde também a um número de condição elevado. Se a matriz não possui posto máximo, o número de condição definido anteriormente é infinito, enquanto a pseudoinversa continua invertendo somente os valores singulares positivos.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.7.1 Pseudoinversa truncada

Considere a aproximação truncada

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Sua pseudoinversa de Moore–Penrose é

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

Ela pode ser utilizada como uma inversão truncada de $\mathbf{A}$, conservando somente os k maiores valores singulares.

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.8 Exemplo com o sistema condutor

Exemplo 6.9 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuada os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned} \hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\ &= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}. \end{aligned}$$

O vetor ajustado é

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\ &= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}. \end{aligned}$$

O resíduo é

$$\begin{aligned} \mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}. \end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}}\mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão dos fatores de escala associados aos valores singulares positivos;
- anulação das componentes pertencentes a $\mathcal{N}(\mathbf{A}^\top)$;
- construção dos projetores sobre $\mathcal{C}(\mathbf{A})$ e $\mathcal{C}(\mathbf{A}^\top)$;
- solução de sistemas lineares compatíveis;
- seleção da solução exata de menor norma quando há não unicidade;
- solução de problemas de mínimos quadrados;
- seleção da solução de mínimos quadrados de menor norma quando há vários minimizadores.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares estende a ideia de decomposição espectral a qualquer matriz real. Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existe uma decomposição

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo d_j ,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

Se

$$r = \text{posto}(\mathbf{A}),$$

a SVD compacta é

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r), \quad d_1 \geq \dots \geq d_r > 0.$$

A SVD compacta é uma representação exata. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

descarta parcelas associadas a valores singulares positivos e produz uma aproximação de posto reduzido.

A construção da SVD decorre das decomposições espectrais das duas matrizes de Gram:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

Seus autovalores positivos são

$$d_1^2, \dots, d_r^2.$$

Assim, $\mathbf{A}^\top \mathbf{A}$ descreve a estrutura espectral relevante no domínio, enquanto $\mathbf{A} \mathbf{A}^\top$ descreve a estrutura correspondente no contradomínio.

Geometricamente, a imagem da bola unitária é um elipsoide de dimensão r contido em

$$\mathcal{C}(\mathbf{A}),$$

com semieixos

$$d_1 \mathbf{u}_1, \dots, d_r \mathbf{u}_r.$$

Os valores singulares medem, portanto, os fatores de escala nas direções singulares. Em particular,

$$\|\mathbf{A}\|_2 = d_1,$$

de modo que o maior valor singular é o maior fator de ampliação produzido pela transformação.

A SVD também fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \dots, \mathbf{u}_r \},$$

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_{r+1}, \dots, \mathbf{u}_q \},$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\},$$

e

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\}.$$

Consequentemente,

$$\dim(\mathcal{N}(\mathbf{A})) = p - r$$

e

$$\dim(\mathcal{N}(\mathbf{A}^\top)) = q - r.$$

As normas espectral e de Frobenius possuem representações simples em termos dos valores singulares:

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a SVD compacta fornece

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Como

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top,$$

essa representação é exata quando são mantidos todos os r componentes singulares positivos.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top,$$

de modo que a representação compacta preserva os produtos internos, as normas e as distâncias euclidianas entre as observações.

Analogamente,

$$\mathbf{U}_r^\top \mathbf{X} = \mathbf{D}_r \mathbf{V}_r^\top$$

fornece as coordenadas das variáveis nas direções singulares à esquerda.

Quando a matriz de dados está centralizada,

$$\mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Adotando a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

obtém-se

$$\mathbf{S} = \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top.$$

Assim, os vetores singulares à direita de $\mathbf{X}_c$ determinam as direções espectrais associadas aos autovalores positivos de $\mathbf{S}$, enquanto

$$\frac{d_j^2}{n-1}$$

são os autovalores positivos correspondentes.

Essa relação antecipa uma das principais conexões entre a SVD e as técnicas de redução de dimensionalidade que serão desenvolvidas posteriormente.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

representa a matriz como uma soma de componentes singulares de posto 1, ortogonais entre si segundo o produto interno de Frobenius.

Na norma de Frobenius,

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

é uma decomposição pitagórica da magnitude quadrática total da matriz.

O Teorema de Eckart–Young–Mirsky estabelece que

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é uma solução do problema de melhor aproximação de $\mathbf{A}$ entre todas as matrizes de posto no máximo k , tanto na norma espectral quanto na norma de Frobenius. Os erros mínimos são

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A norma espectral mede o maior erro remanescente em uma direção unitária, enquanto a norma de Frobenius agrega quadraticamente todas as parcelas descartadas.

A pseudoinversa de Moore–Penrose é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top,$$

com $\mathbf{A}^+ = \mathbf{0}$ quando $\mathbf{A} = \mathbf{0}$.

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A})}$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)}.$$

Para qualquer

$$\mathbf{b} \in \mathbb{R}^q,$$

o vetor

$$\hat{\mathbf{x}}^\star = \mathbf{A}^+ \mathbf{b}$$

é a solução de mínimos quadrados de menor norma.

Quando

$$r < p,$$

podem existir outros minimizadores, obtidos pela adição de componentes pertencentes a

$$\mathcal{N}(\mathbf{A}).$$

A pseudoinversa seleciona, entre todos eles, o único vetor de menor norma euclidiana.

O vetor ajustado é

$$\hat{\mathbf{b}} = \mathbf{A} \mathbf{A}^+ \mathbf{b},$$

isto é, a projeção ortogonal de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$, enquanto o resíduo

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A} \mathbf{A}^+) \mathbf{b}$$

pertence a

$$\mathcal{N}(\mathbf{A}^\top).$$

A Tabela 6.7 reúne as relações principais.

Tabela 6.7: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Utiliza bases ortonormais completas no domínio e no contradomínio
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata usando somente os componentes associados aos valores singulares positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Relaciona uma direção do domínio a uma direção do contradomínio
Matrizes de Gram	$\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$	Determinam os quadrados dos valores singulares e os vetores singulares correspondentes
Posto	$r = \#\{j : d_j > 0\}$	Dimensão da imagem da transformação
Norma espectral	$\ \mathbf{A}\ _2 = d_1$	Maior fator de ampliação da transformação
Norma de Frobenius	$\ \mathbf{A}\ _F^2 = \sum_{j=1}^r d_j^2$	Magnitude quadrática total da matriz
Coordenadas das observações	$\mathbf{Z} = \mathbf{X}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r$	Representação das observações nas direções singulares à direita
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top$	Aproximação ótima de posto no máximo k
Erro espectral	$\ \mathbf{A} - \mathbf{A}_k\ _2 = d_{k+1}$	Maior erro do truncamento sobre vetores unitários
Erro de Frobenius	$\ \mathbf{A} - \mathbf{A}_k\ _F^2 = \sum_{j=k+1}^r d_j^2$	Magnitude quadrática total dos componentes descartados
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r\mathbf{D}_r^{-1}\mathbf{U}_r^\top$	Inverte os fatores de escala associados aos valores singulares positivos
Projeto no espaço coluna	$\mathbf{A}\mathbf{A}^+$	Projeta sobre $\mathcal{C}(\mathbf{A})$
Projeto no espaço linha	$\mathbf{A}^+\mathbf{A}$	Projeta sobre $\mathcal{C}(\mathbf{A}^\top)$
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+\mathbf{b}$	Seleciona a solução de mínimos quadrados de menor norma

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir as formas completa, compacta e truncada da SVD;
- diferenciar uma representação compacta exata de uma aproximação truncada de posto reduzido;
- relacionar a SVD às decomposições espectrais de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$;
- interpretar geometricamente os valores e vetores singulares;
- identificar o posto e os quatro espaços fundamentais por meio da SVD;
- construir os projetores ortogonais associados aos espaços fundamentais;
- calcular e interpretar as normas espectral e de Frobenius a partir dos valores singulares;
- interpretar a dualidade entre observações e variáveis em uma matriz de dados;
- representar exatamente as observações em coordenadas singulares e compreender a preservação de produtos internos e distâncias;
- relacionar a SVD de uma matriz centralizada à estrutura espectral de sua matriz de covariâncias amostral;
- representar uma matriz como soma de componentes singulares ortogonais de posto 1;
- construir aproximações de posto reduzido e determinar seus erros nas normas espectral e de Frobenius;
- aplicar o Teorema de Eckart–Young–Mirsky;
- construir e interpretar a pseudoinversa de Moore–Penrose;
- distinguir solução exata, solução de mínimos quadrados e solução de mínimos quadrados de menor norma;
- interpretar mínimos quadrados como um problema de projeção ortogonal.

Ideia central do capítulo

A Decomposição em Valores Singulares descreve uma matriz por meio de pares de direções ortonormais no domínio e no contradomínio e dos fatores de escala que relacionam essas direções. Essa estrutura revela o posto e os espaços fundamentais, fornece representações exatas ou aproximadas de menor dimensão e permite construir projetores, pseudoinversas e soluções de mínimos quadrados.

A SVD encerra o percurso dedicado às principais estruturas de Álgebra Linear utilizadas neste módulo. Matrizes, espaços vetoriais, transformações lineares, decomposição espectral e SVD fornecem, em conjunto, a base geométrica e matricial para representar estruturas multivariadas.

O próximo capítulo desenvolve **Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada**. Gradientes, Hessianas, multiplicadores de Lagrange, diferenciais matriciais, traços, determinantes e integrais completarão os fundamentos matemáticos necessários para formular problemas de otimização, estimação e transformação de variáveis nos capítulos seguintes.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Neste capítulo, salvo indicação em contrário, $\|\cdot\|$ aplicada a vetores denota a norma euclidiana definida em Definição [1.10](#).

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2,$$

em que $\|\cdot\|_F$ denota a norma de Frobenius definida em Definição 6.7.

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{A}\mathbf{X}\mathbf{B}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Representação de primeira ordem
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a forma da transformação linear que representa localmente a variação da função e, conseqüentemente, a dimensão do gradiente, da Jacobiana ou do operador diferencial utilizado para representá-la.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa o incremento utilizado como argumento da transformação linear que define o diferencial. Assim,

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}$$

é linear em $d\mathbf{x}$.

A notação diferencial é frequentemente interpretada de maneira informal como uma variação infinitesimal. Formalmente, porém, o diferencial é a aplicação linear que fornece a parte de primeira ordem da variação da função.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana estão associados à mesma ideia de aproximação linear local, mas correspondem a contradomínios diferentes. Para uma função escalar, o gradiente fornece a representação vetorial da aplicação linear que define o diferencial. Para uma função vetorial, a Jacobiana fornece a representação matricial dessa aplicação linear.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Proposição 7.1 (Direções de maior crescimento e redução). *Se f é diferenciável em $\mathbf{x}$ e*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior taxa de redução de primeira ordem ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

i Demonstração

Pelo Teorema 1.1,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. Aplicando o mesmo argumento à direção oposta, obtém-se o resultado para a maior taxa de redução de primeira ordem.

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação de primeira ordem não distingue direções de crescimento ou redução, e o comportamento local passa a depender de termos de ordem superior.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^{\top} \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

Suponha que as derivadas parciais das componentes de $\mathbf{g}$ existam no ponto $\mathbf{x}$. A matriz Jacobiana de $\mathbf{g}$ nesse ponto é




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} g_1 \\ g_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

Assim, a parte linear local de uma transformação afim é exatamente a matriz $\mathbf{A}$, enquanto o termo de translação desaparece na diferenciação.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.1 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_{\mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x})) \mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem do produto reflete a composição das aplicações lineares: sobre uma perturbação $\mathbf{h}_{\mathbf{x}} \in \mathbb{R}^p$, atua primeiro $\mathbf{J}_{\mathbf{g}}(\mathbf{x})$ e, sobre o resultado, atua $\mathbf{J}_{\mathbf{h}}(\mathbf{g}(\mathbf{x}))$. Por isso, na representação matricial, a Jacobiana de $\mathbf{h}$ aparece à esquerda.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h : \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})^{\top} \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^\top \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_g(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função com derivadas parciais de segunda ordem no ponto considerado. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

O segundo diferencial é uma forma quadrática no incremento $d\mathbf{x}$ e descreve a contribuição local de segunda ordem da função.

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a segunda taxa de variação de f ao longo da reta que passa por $\mathbf{x}$ na direção $\mathbf{u}$ e fornece a medida de curvatura direcional utilizada neste capítulo.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned} \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2. \end{aligned}$$

Ela é positiva para todo vetor não nulo. Para vetores unitários, a segunda taxa de variação é maior nas direções com maior componente em módulo no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2} \right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2 \left(x_2 - \frac{1}{2} \right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.2 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0).$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a variação local de primeira ordem;
- a Hessiana determina a variação local de segunda ordem.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece. Se a forma quadrática associada à Hessiana é não degenerada, ela fornece o termo dominante da variação local. Quando essa forma se anula em alguma direção, termos de ordem superior podem ser necessários para determinar o comportamento da função.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}.$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}} f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Proposição 7.2 (Condição necessária de primeira ordem). *Se f é diferenciável em um ponto interior $\mathbf{x}^*$ de seu domínio e possui nesse ponto um máximo ou mínimo local, então*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

i Demonstração

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}^*) \neq \mathbf{0},$$

considere a direção unitária

$$\mathbf{u} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x}^*)}{\|\nabla_{\mathbf{x}}f(\mathbf{x}^*)\|}.$$

Então,

$$D_{\mathbf{u}}f(\mathbf{x}^*) = \|\nabla_{\mathbf{x}}f(\mathbf{x}^*)\| > 0,$$

enquanto

$$D_{-\mathbf{u}}f(\mathbf{x}^*) = -\|\nabla_{\mathbf{x}}f(\mathbf{x}^*)\| < 0.$$

Assim, existem direções locais de aumento e de redução, o que contradiz a existência de um extremo local interior. Portanto,

$$\nabla_{\mathbf{x}}f(\mathbf{x}^*) = \mathbf{0}.$$

Como

$$\nabla_{\mathbf{x}}f(\mathbf{x}^*) = \mathbf{0},$$

tem-se

$$D_{\mathbf{u}}f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

A recíproca da proposição anterior não é verdadeira em geral: um ponto estacionário pode ser mínimo local, máximo local ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.3 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável em uma vizinhança de um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^*$ é um mínimo local estrito.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$


então $\mathbf{x}^*$ é um máximo local estrito.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*)$$

é indefinida, então $\mathbf{x}^*$ é um ponto de sela.

Se a Hessiana é apenas semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)



i Demonstração

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Considere inicialmente

$$\mathbf{H} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Como $\mathbf{H}$ é simétrica e positiva definida, seu menor autovalor satisfaz

$$\lambda_{\min}(\mathbf{H}) > 0.$$

Portanto,

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} \geq \lambda_{\min}(\mathbf{H}) \|\mathbf{h}\|^2.$$

Além disso,

$$o(\|\mathbf{h}\|^2) = \varepsilon(\mathbf{h}) \|\mathbf{h}\|^2,$$

com

$$\varepsilon(\mathbf{h}) \xrightarrow{596} 0$$

quando $\mathbf{h} \rightarrow \mathbf{0}$.

Logo, para $\mathbf{h}$ suficientemente pequeno,

$$|\varepsilon(\mathbf{h})| < \frac{1}{4} \lambda_{\min}(\mathbf{H}).$$

Assim,

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0, 0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1 - t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, conjuntos afins como hiperplanos, bolas e regiões elipsoidais da forma

$$\left\{ \mathbf{x} : (\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{A} (\mathbf{x} - \boldsymbol{\mu}) \leq c \right\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.4 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.5 (Critério da Hessiana para convexidade). *Considere uma função*

$$f : \mathcal{C} \longrightarrow \mathbb{R}$$

duas vezes continuamente diferenciável em um conjunto convexo aberto

$$\mathcal{C} \subseteq \mathbb{R}^p.$$

Então, f é convexa em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Analogamente, f é côncava em $\mathcal{C}$ se, e somente se,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0}$$

para todo

$$\mathbf{x} \in \mathcal{C}.$$

Além disso, se


$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa. Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente côncava.

(Boyd; Vandenberghe, 2004)



i Demonstração

Considere dois pontos distintos

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e defina

$$g(t) = f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})), \quad 0 \leq t \leq 1.$$

Como $\mathcal{C}$ é convexo, todo o segmento entre $\mathbf{x}$ e $\mathbf{y}$ pertence a $\mathcal{C}$.
Pela regra da cadeia,

$$g''(t) = (\mathbf{y} - \mathbf{x})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) (\mathbf{y} - \mathbf{x}).$$

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{z}) \succeq \mathbf{0}$$

para todo $\mathbf{z} \in \mathcal{C}$, então

$$g''(t) \geq 0,$$

e, portanto, g é convexa em $[0, 1]$. Como isso vale para qualquer segmento contido em $\mathcal{C}$, f é convexa.

Reciprocamente, se f é convexa, então a restrição de f a qualquer reta é convexa. Para qualquer

$$\mathbf{x} \in \mathcal{C}$$

e qualquer direção

$$\mathbf{u} \in \mathbb{R}^p,$$

considere

$$h(t) = f(\mathbf{x} + t\mathbf{u})$$

para t suficientemente próximo de zero. A convexidade de h implica

$$h''(0) \geq 0.$$

Como

$$h''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u},$$

tem-se

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

A condição

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

em todo o domínio é suficiente para convexidade estrita, mas não é necessária. Uma função estritamente convexa pode possuir Hessiana singular em pontos isolados. Por exemplo,

$$f(x) = x^4$$

é estritamente convexa em $\mathbb{R}$, embora

$$f''(0) = 0.$$

7.4.5 Consequências para otimização

Proposição 7.3 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa e existe um ponto estacionário $\mathbf{x}^$, então esse ponto é o único minimizador global. (Boyd; Vandenberghe, 2004)*

i Demonstração

Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$.

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

De fato, como $\mathbf{A}$ é simétrica,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}).$$

Assim, existe

$$\mathbf{z} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{b}^\top \mathbf{z} \neq 0.$$

Ao longo da reta

$$\mathbf{x} = t\mathbf{z},$$

o termo quadrático é nulo e

$$f(t\mathbf{z}) = -t\mathbf{b}^\top \mathbf{z} + c,$$

que pode tender a $-\infty$ escolhendo o sinal apropriado de t .

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

A Proposição 7.2 estabelece a condição necessária de primeira ordem para extremos locais interiores, enquanto o Teorema 7.3 utiliza a Hessiana para classificar pontos estacionários quando o teste de segunda ordem é conclusivo.

No caso convexo, a Proposição 7.3 mostra que um ponto estacionário é minimizador global. Esses resultados fornecem as condições de otimalidade; a questão seguinte é construir um procedimento iterativo para localizar esses pontos.

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top (\mathbf{x} - \mathbf{x}^{(t)}) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}). \end{aligned}$$

Defina

$$\mathbf{g}^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$$

e

$$\mathbf{H}^{(t)} = \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}).$$

Escrevendo

$$\mathbf{d} = \mathbf{x} - \mathbf{x}^{(t)},$$

o modelo quadrático local pode ser representado por

$$m_t(\mathbf{d}) = f(\mathbf{x}^{(t)}) + (\mathbf{g}^{(t)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{H}^{(t)} \mathbf{d}.$$

Seu gradiente em relação a $\mathbf{d}$ é

$$\nabla_{\mathbf{d}} m_t(\mathbf{d}) = \mathbf{g}^{(t)} + \mathbf{H}^{(t)} \mathbf{d}.$$

Se

$$\mathbf{H}^{(t)} \succ \mathbf{0},$$

o modelo quadrático é estritamente convexo e possui um único minimizador. Esse minimizador, denominado **direção de Newton**, satisfaz

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}.$$

Quando $\mathbf{H}^{(t)}$ é invertível,

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

A atualização de Newton com passo completo é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)},$$

ou, equivalentemente,

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver o sistema linear

$$\mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

sem calcular explicitamente a inversa da Hessiana.

Se a Hessiana é apenas invertível, mas não positiva definida, a solução desse sistema é um ponto estacionário do modelo quadrático, mas pode não ser seu minimizador. Nesse caso, a direção de Newton também pode deixar de ser uma direção de descida para a função original.

Proposição 7.4 (Direção de Newton como direção de descida). *Suponha que*

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) \neq \mathbf{0}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \succ \mathbf{0}.$$

Então a direção de Newton $\mathbf{d}^{(t)}$ é uma direção de descida para f em $\mathbf{x}^{(t)}$, isto é,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

i Demonstração

Como

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)},$$

tem-se

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} = -(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}.$$

Como $\mathbf{H}^{(t)} \succ \mathbf{0}$, também

$$(\mathbf{H}^{(t)})^{-1} \succ \mathbf{0}.$$

Logo, para $\mathbf{g}^{(t)} \neq \mathbf{0}$,

$$(\mathbf{g}^{(t)})^\top (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)} > 0,$$

e, portanto,

$$(\mathbf{g}^{(t)})^\top \mathbf{d}^{(t)} < 0.$$

O passo completo corresponde a

$$\alpha_t = 1.$$

Uma forma mais geral da atualização é

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \alpha_t \mathbf{d}^{(t)}, \quad 0 < \alpha_t \leq 1.$$

A escolha de $\alpha_t < 1$ produz um passo de Newton amortecido. Esse recurso pode ser utilizado quando o modelo quadrático local ainda não representa adequadamente a função ao longo de um passo completo.

Assim, a construção da direção e a escolha do comprimento da etapa são operações distintas. Métodos numéricos de otimização costumam combinar a direção de Newton com procedimentos de controle da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned}\mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A}\mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1}\mathbf{b}.\end{aligned}$$

Assim, para uma função quadrática com Hessiana constante e positiva definida, uma etapa completa de Newton conduz exatamente ao único minimizador,

$$\mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b},$$

independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, as linhas da Jacobiana das restrições são linearmente independentes. O espaço tangente ao conjunto viável é então

$$\mathcal{T}_{\mathbf{x}} = \mathcal{N}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})).$$

Portanto, uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

O espaço normal correspondente é

$$\mathcal{T}_{\mathbf{x}}^{\perp} = \mathcal{C}(\mathbf{J}_{\mathbf{c}}(\mathbf{x})^{\top}),$$

isto é, o espaço gerado pelos gradientes das restrições.

Em um ótimo local regular $\mathbf{x}^*$, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^{\top} \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{T}_{\mathbf{x}^*}.$$

Consequentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{T}_{\mathbf{x}^*}^{\perp} = \mathcal{C}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^{\top}].$$

7.6.1 Multiplicadores de Lagrange

Teorema 7.6 (Condição de Lagrange). *Considere funções continuamente diferenciáveis*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

e

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m.$$

Seja $\mathbf{x}^*$ um ótimo local do problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)$$

sejam linearmente independentes.

Essa condição equivale a

$$\text{posto}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)] = m.$$

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

i Demonstração

Como $\mathbf{x}^*$ é um ótimo local regular, a derivada direcional da função objetivo é nula em todas as direções tangentes ao conjunto viável. Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top \mathbf{d} = 0$$

para todo

$$\mathbf{d} \in \mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)].$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) \in \mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)]^\perp.$$

Pelo Teorema 3.6,

$$\mathcal{N}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)]^\perp = \mathcal{C}[\mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top].$$

Assim, existe um vetor

$$\mu^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \mu^*.$$

Definindo

$$\lambda^* = -\mu^*,$$

obtém-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

Sob a condição de regularidade do teorema, as condições necessárias de primeira ordem podem ser escritas como

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Essas condições identificam candidatos a ótimo restrito. No caso geral, elas não são suficientes para garantir mínimo ou máximo. A classificação exige condições adicionais sobre a função objetivo, as restrições e a variação de segunda ordem nas direções tangentes.

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere o problema

$$\max_{\mathbf{x}} \mathbf{a}^{\top} \mathbf{x},$$

em que

$$\mathbf{a} \neq \mathbf{0},$$

sujeito à restrição

$$\mathbf{x}^{\top} \mathbf{x} = 1.$$

A restrição exige que $\mathbf{x}$ tenha norma euclidiana unitária:

$$\|\mathbf{x}\| = 1.$$

Escrevendo-a na forma

$$c(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{x} - 1 = 0,$$

o problema pode ser tratado pelos multiplicadores de Lagrange.

Para manter a formulação como um problema de minimização, considere a função objetivo

$$f(\mathbf{x}) = -\mathbf{a}^{\top} \mathbf{x}.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^{\top} \mathbf{x} + \lambda (\mathbf{x}^{\top} \mathbf{x} - 1).$$

As condições de primeira ordem são obtidas diferenciando a lagrangiana em relação a $\mathbf{x}$ e ao multiplicador λ .

Em relação a $\mathbf{x}$,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a} + 2\lambda\mathbf{x}.$$

Portanto, em um ponto candidato à solução,

$$-\mathbf{a} + 2\lambda\mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \frac{1}{2\lambda}\mathbf{a}.$$

Em relação a λ ,

$$\frac{\partial \mathcal{L}(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{x}^\top \mathbf{x} - 1.$$

Assim, a segunda condição de primeira ordem simplesmente recupera a restrição:

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Substituindo

$$\mathbf{x} = \frac{1}{2\lambda}\mathbf{a}$$

na restrição,

$$\left(\frac{1}{2\lambda}\mathbf{a}\right)^\top \left(\frac{1}{2\lambda}\mathbf{a}\right) = 1,$$

e, portanto,

$$\frac{\mathbf{a}^\top \mathbf{a}}{4\lambda^2} = 1.$$

Como

$$\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|^2,$$

segue que

$$4\lambda^2 = \|\mathbf{a}\|^2,$$

ou

$$\lambda = \pm \frac{\|\mathbf{a}\|}{2}.$$

Consequentemente, existem dois pontos candidatos:

$$\mathbf{x}_1 = \frac{\mathbf{a}}{\|\mathbf{a}\|}$$

e

$$\mathbf{x}_2 = -\frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

Para identificar qual deles maximiza a função objetivo original, avalie

$$\mathbf{a}^\top \mathbf{x}.$$

No primeiro ponto,

$$\mathbf{a}^\top \mathbf{x}_1 = \mathbf{a}^\top \frac{\mathbf{a}}{\|\mathbf{a}\|} = \frac{\|\mathbf{a}\|^2}{\|\mathbf{a}\|} = \|\mathbf{a}\|.$$

No segundo,

$$\mathbf{a}^\top \mathbf{x}_2 = -\|\mathbf{a}\|.$$

Logo, o máximo é atingido em

$$\mathbf{x}^\star = \frac{\mathbf{a}}{\|\mathbf{a}\|},$$

e o valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Geometricamente, a solução mostra que, entre todos os vetores unitários, o produto interno com $\mathbf{a}$ é máximo quando $\mathbf{x}$ possui a mesma direção e o mesmo sentido de $\mathbf{a}$.

O resultado também coincide com o caso de igualdade no Teorema 1.1, pois

$$\mathbf{a}^\top \mathbf{x} \leq \|\mathbf{a}\| \|\mathbf{x}\| = \|\mathbf{a}\|,$$

e a igualdade ocorre quando $\mathbf{x}$ é proporcional a $\mathbf{a}$.

Se $\mathbf{a} = \mathbf{0}$, a função objetivo é constante e todo vetor unitário satisfaz

$$\mathbf{a}^\top \mathbf{x} = 0.$$

Nesse caso, todo vetor que satisfaz a restrição é uma solução ótima.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Portanto, todo ponto regular estacionário do problema restrito é um autovetor de $\mathbf{A}$, e o valor da função objetivo nesse ponto é o autovalor correspondente.

Pelo Teorema 5.5, desenvolvido no capítulo de decomposição espectral,

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\max}(\mathbf{A}),$$

e

$$\min_{\|\mathbf{x}\|=1} \mathbf{x}^\top \mathbf{A} \mathbf{x} = \lambda_{\min}(\mathbf{A}).$$

Assim, os multiplicadores de Lagrange produzem a equação de autovalores como condição de estacionariedade, enquanto o resultado espectral identifica quais desses pontos realizam os extremos globais.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C}\mathbf{x} = \mathbf{d},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica,

$$\mathbf{C} \in \mathbb{R}^{m \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^m.$$

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

Esse sistema em blocos reúne as condições de primeira ordem do problema restrito.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e $\mathbf{C}$ possui posto linha completo, a função objetivo é estritamente convexa e o conjunto definido por

$$\mathbf{C} \mathbf{x} = \mathbf{d}$$

é afim. Quando esse conjunto é não vazio, as condições de primeira ordem identificam o único minimizador global.

Mais geralmente, para uma matriz $\mathbf{A}$ semidefinida positiva, a unicidade depende de a forma quadrática ser positiva nas direções viáveis não nulas, isto é,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} > 0$$

para todo

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{C}\mathbf{z} = \mathbf{0}.$$

Sem condições desse tipo, a resolução do sistema fornece apenas candidatos que satisfazem as condições de primeira ordem.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Derivadas de formas quadráticas

As formas quadráticas foram definidas em Definição 2.23, e a Proposição 2.10 mostrou que seu valor depende apenas da parte simétrica da matriz. O objetivo agora é obter suas derivadas.

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Proposição 7.5 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

i Demonstração

Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana.

Utilizando a classificação de positividade apresentada em Definição 2.24, se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, todos os vetores da forma

$$\mathbf{x} = \mu + \mathbf{z}, \quad \mathbf{z} \in \mathcal{N}(\mathbf{A}),$$

também minimizam a função. Portanto, a unicidade ocorre quando

$$\mathbf{A} \succ \mathbf{0}.$$

7.7.3 Derivadas da norma euclidiana

Retomando a norma euclidiana definida em Definição 1.10,

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Portanto,

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{A}\mathbf{x})^\top (\mathbf{b} - \mathbf{A}\mathbf{x}).$$

Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}). \end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

A Hessiana é constante e não depende de $\mathbf{x}$. Além disso,

$$\mathbf{z}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z} = \|\mathbf{A}\mathbf{z}\|^2 \geq 0,$$

para todo

$$\mathbf{z} \in \mathbb{R}^p.$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

As equações normais já foram introduzidas geometricamente em Definição 3.21, a partir da projeção sobre o espaço coluna. No Capítulo 6, Proposição 6.22 apresentou a solução por meio da SVD e da pseudoinversa. Nesta seção, o mesmo resultado será obtido a partir da condição de primeira ordem do cálculo diferencial.

7.7.5 Equações normais

Proposição 7.6 (Caracterização dos mínimos quadrados pelas equações normais). *Considere*

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|^2,$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é minimizador global de f se, e somente se, satisfaz as equações normais

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}.$$

Se $\mathbf{A}$ possui posto coluna completo, o minimizador é único e dado por

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

i Demonstração

A derivação anterior fornece

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0}.$$

Logo, f é convexa. Pelo Proposição 7.3, um ponto é minimizador global se, e somente se, seu gradiente é nulo. Portanto,

$$\nabla_{\mathbf{x}} f(\hat{\mathbf{x}}) = \mathbf{0}$$

se, e somente se,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

de modo que f é estritamente convexa e possui, no máximo, um minimizador. Como

$$\mathbf{A}^\top \mathbf{A}$$

é invertível, esse minimizador é

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

A condição

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}$$

mostra que o resíduo de mínimos quadrados é ortogonal ao espaço coluna de $\mathbf{A}$.

O caso de posto deficiente, o conjunto de todos os minimizadores e a solução de menor norma foram estabelecidos em Proposição 6.22. Aqui, o objetivo é destacar que as equações normais surgem diretamente da condição de primeira ordem do problema de otimização.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos não negativos

$$\omega_1, \dots, \omega_q \geq 0$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Como Ω é diagonal e, portanto, simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Equivalentemente,

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, em qualquer minimizador, o resíduo satisfaz a condição de ortogonalidade ponderada

$$\mathbf{A}^\top \Omega \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Quando

$$\Omega \succ \mathbf{0},$$

retoma-se o produto interno induzido definido em Definição 3.16:

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\Omega} = \mathbf{u}^{\top} \Omega \mathbf{v}.$$

A condição anterior corresponde, portanto, à ortogonalidade do resíduo ao espaço coluna de $\mathbf{A}$ nessa geometria ponderada.

Se Ω é singular, a mesma condição algébrica permanece válida, mas a forma ponderada é apenas semidefinida positiva e não define um produto interno em todo o espaço.

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^{\top} \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^{\top} \Omega \mathbf{A})^{-1} \mathbf{A}^{\top} \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

Quando

$$\Omega \succ \mathbf{0},$$

o critério pode ser escrito utilizando a norma induzida de Definição 3.17:

$$f_{\omega}(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|_{\Omega}^2,$$

com

$$\|\mathbf{z}\|_{\Omega}^2 = \mathbf{z}^{\top} \Omega \mathbf{z}.$$

Assim, os mínimos quadrados ponderados correspondem a uma projeção segundo a geometria induzida por Ω .

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma classe ampla de funções de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual duas vezes diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Proposição 7.7 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

i Demonstração

Pela regra da cadeia,

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x}).\end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^{\top} + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana.

A Hessiana possui, portanto, duas parcelas com papéis distintos:

$$\underbrace{2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x})}_{\text{parcela de primeira ordem dos resíduos}} + \underbrace{2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x})}_{\text{correção de não linearidade}}.$$

O primeiro termo da Hessiana,

$$2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}),$$

é semidefinido positivo. Isso não implica, porém, que a função de mínimos quadrados não linear seja convexa, pois a segunda parcela da Hessiana pode ser indefinida.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos ou quando as Hessianas das funções residuais têm contribuição reduzida na região considerada, a segunda parcela pode ser desprezada aproximadamente. Nesse caso,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}).$$

No caso linear,

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}}^2 r_i(\mathbf{x}) = \mathbf{0}$$

para todo i . Portanto, a segunda parcela desaparece exatamente e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujos argumentos são

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Retomando a convenção estabelecida no início do capítulo, o gradiente matricial é

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius definido em Definição 6.6,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr}(\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

Assim como o gradiente de uma função escalar de vetor representa o diferencial segundo o produto interno euclidiano, o gradiente matricial representa o diferencial segundo o produto interno de Frobenius.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{X}\mathbf{Y}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{YZ} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{XY} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço foi definido em Definição 2.9, e suas propriedades algébricas foram estabelecidas em Proposição 2.5 e Proposição 2.8. Para o cálculo matricial, serão utilizadas especialmente as permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}} \phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Proposição 7.8 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}} \phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

i Demonstração

O diferencial é

$$\begin{aligned} d\phi &= d \operatorname{tr} (\mathbf{A}^\top \mathbf{X}) \\ &= \operatorname{tr} (\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \operatorname{tr} [(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}} \phi = \mathbf{A}.$$

Como

$$\operatorname{tr} (\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Derivadas da norma de Frobenius

Pela Definição 6.7,

$$\|\mathbf{X}\|_F^2 = \operatorname{tr} (\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \operatorname{tr} (\mathbf{X}^\top \mathbf{X}) \\ &= \operatorname{tr} (d\mathbf{X}^\top \mathbf{X}) + \operatorname{tr} (\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\operatorname{tr} (d\mathbf{X}^\top \mathbf{X}) = \operatorname{tr} (\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \operatorname{tr} (\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

De fato, essa função é estritamente convexa em $\mathbf{X}$, pois sua segunda variação em uma perturbação não nula $d\mathbf{X}$ é

$$d^2\phi = 2\|d\mathbf{X}\|_F^2 > 0.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$d\phi = \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma).$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}\left[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}\right].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}\left[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}\right]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}} \phi = \mathbf{A} \mathbf{X} \Gamma + \mathbf{A}^\top \mathbf{X} \Gamma^\top.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A} \mathbf{X} \Gamma.$$

A dimensão do gradiente coincide com a dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi \in \mathbb{R}^{m \times n}.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A} \mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_{\cdot 1}, \dots, \mathbf{x}_{\cdot n},$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_{\cdot j}^{\top} \mathbf{A} \mathbf{x}_{\cdot j}.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_{\cdot 1}, \dots, 2\mathbf{A}\mathbf{x}_{\cdot n}.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{X}\mathbf{B}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^{\top} \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \operatorname{tr} \left(\mathcal{E}^\top d\mathcal{E} \right) \\ &= -2 \operatorname{tr} \left(\mathcal{E}^\top \mathbf{X} d\mathbf{B} \right) \\ &= -2 \operatorname{tr} \left[(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B} \right]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{X}\mathbf{B} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{X}\mathbf{B} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Se $\mathbf{X}$ não possui posto coluna completo, os minimizadores não são únicos. A solução de mínimos quadrados de menor norma de Frobenius é

$$\widehat{\mathbf{B}}^\star = \mathbf{X}^+ \mathbf{Y}.$$

Mais geralmente, todos os minimizadores podem ser escritos como

$$\widehat{\mathbf{B}} = \mathbf{X}^+ \mathbf{Y} + (\mathbf{I}_k - \mathbf{X}^+ \mathbf{X}) \mathbf{C},$$

em que

$$\mathbf{C} \in \mathbb{R}^{k \times p}$$

é arbitrária.

A parcela adicional pertence ao núcleo da transformação

$$\mathbf{B} \mapsto \mathbf{X}\mathbf{B}$$

e, portanto, não altera os valores ajustados.


Assim, quando o critério utilizado é simplesmente a norma de Frobenius dos resíduos, o problema matricial pode ser interpretado como p problemas de mínimos quadrados que compartilham a mesma matriz de delineamento.

Proposição 7.9 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{X}\mathbf{B}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa se, e somente se, $\mathbf{X}$ possui posto coluna completo.



i Demonstração

Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa.

Reciprocamente, se $\mathbf{X}$ não possui posto coluna completo, existe

$$\mathbf{z} \neq \mathbf{0}$$

tal que

$$\mathbf{X}\mathbf{z} = \mathbf{0}.$$

Escolha qualquer vetor não nulo

$$\mathbf{c} \in \mathbb{R}^p$$

e defina

$$d\mathbf{B} = \mathbf{z}\mathbf{c}^\top.$$

Então

$$d\mathbf{B} \neq \mathbf{0},$$

mas

$$d^2Q = 0$$

$$\mathbf{X} d\mathbf{B} = \mathbf{0}.$$

Portanto,

$$d^2Q = 0$$

em uma direção não nula, e a função não é estritamente convexa.

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

Como

$$\Omega \succeq \mathbf{0}$$

e

$$\Sigma \succ \mathbf{0},$$

o critério também pode ser escrito como

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \left\| \Omega^{1/2} \mathcal{E}(\mathbf{B}) \Sigma^{-1/2} \right\|_F^2.$$

Essa forma mostra que a ponderação atua simultaneamente nas duas dimensões da matriz residual.

A matriz Ω atua no espaço das observações e pondera as linhas da matriz de resíduos. A matriz Σ^{-1} atua no espaço das respostas e define a geometria utilizada para combinar as colunas da matriz de resíduos.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \operatorname{tr} \left[(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B} \right].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{X} \mathbf{B} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, ou equivalentemente, se as colunas de

$$\Omega^{1/2} \mathbf{X}$$

são linearmente independentes, então o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Para Σ fixa e positiva definida, a ponderação invertível no espaço das respostas altera o valor do critério e sua geometria, mas não altera o conjunto de minimizadores em relação a $\mathbf{B}$.

Isso ocorre porque

$$\Sigma^{-1}$$

é invertível e pode ser eliminada da condição de primeira ordem.

A ponderação das observações por Ω , por outro lado, permanece nas equações normais e pode modificar o estimador.

Os diferenciais matriciais e as identidades de traço permitem agora tratar funções em que a própria matriz variável aparece no interior de uma inversa ou de um determinante. Essas estruturas são particularmente importantes quando o parâmetro pertence ao conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

A matriz inversa e o determinante foram definidos em Definição 2.11 e Definição 2.13, enquanto a relação entre determinante e invertibilidade foi estabelecida em Teorema 2.4. A classificação das matrizes simétricas por positividade foi apresentada em Definição 2.24.

Nesta seção, esses objetos são retomados como funções de uma matriz variável. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Proposição 7.10 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019)

i Demonstração

Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

Quando $\mathbf{X} \succ \mathbf{0}$ e a perturbação

$$d\mathbf{X} \succeq \mathbf{0},$$

tem-se

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \succeq \mathbf{0},$$

e, portanto,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} \preceq \mathbf{0}.$$

Assim, a inversão reverte a ordem de Loewner: aumentos semidefinidos positivos da matriz produzem variações semidefinidas negativas de sua inversa.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Proposição 7.11 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019)

i Demonstração

Considere uma perturbação $\mathbf{H}$ e a função

$$g(t) = \det(\mathbf{X} + t\mathbf{H}).$$

Como $\mathbf{X}$ é invertível,

$$g(t) = \det(\mathbf{X}) \det(\mathbf{I}_p + t\mathbf{X}^{-1}\mathbf{H}).$$

Pela multilinearidade do determinante,

$$\det(\mathbf{I}_p + t\mathbf{M}) = 1 + t \operatorname{tr}(\mathbf{M}) + o(t).$$

Aplicando essa expansão com

$$\mathbf{M} = \mathbf{X}^{-1}\mathbf{H},$$

obtem-se

$$g(t) = \det(\mathbf{X}) [1 + t \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}) + o(t)].$$

Logo,

$$g'(0) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1}\mathbf{H}).$$

Como $\mathbf{H}$ representa uma perturbação arbitrária,

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Como

$$d \det(\mathbf{X}) = \operatorname{tr} [(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X}],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

A restrição

$$\mathbf{X} \succ \mathbf{0}$$

garante simultaneamente que $\mathbf{X}$ é invertível e que

$$\det(\mathbf{X}) > 0,$$

de modo que o logaritmo real do determinante está bem definido.

Proposição 7.12 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

i Demonstração

Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente.

Para uma matriz real invertível, não necessariamente simétrica, pode-se considerar

$$\phi(\mathbf{X}) = \log |\det(\mathbf{X})|.$$

Como o determinante não se anula no conjunto das matrizes invertíveis, seu sinal permanece constante em uma vizinhança suficientemente pequena de cada matriz invertível. Nesse domínio,

$$d \log |\det(\mathbf{X})| = \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}),$$

e, portanto,

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}.$$

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2\phi = -\text{tr}(\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}d\mathbf{X}).$$

Logo,

$$d^2\phi \leq 0.$$

Proposição 7.13 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas.

(Boyd; Vandenberghe, 2004)

i Demonstração

O conjunto das matrizes simétricas positivas definidas é convexo. Para toda matriz

$$\mathbf{X} \succ \mathbf{0}$$

e toda direção simétrica não nula $\mathbf{H}$,

$$d^2\phi[\mathbf{H}, \mathbf{H}] = -\|\mathbf{X}^{-1/2}\mathbf{H}\mathbf{X}^{-1/2}\|_F^2 < 0.$$

Logo, a restrição de ϕ a qualquer segmento não degenerado do cone positivo definido possui segunda derivada negativa. Portanto,

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava nesse domínio.

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}\mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\text{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Observe que o gradiente possui a mesma dimensão de $\mathbf{X}$,

$$\nabla_{\mathbf{X}}\phi \in \mathbb{R}^{p \times p}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^\top \mathbf{X}^{-1} \mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-1} \mathbf{a} \mathbf{a}^\top \mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}} \phi = -(\mathbf{X}^{-1} \mathbf{a})(\mathbf{X}^{-1} \mathbf{a})^\top.$$

Essa matriz é semidefinida negativa.

Consequentemente, para uma perturbação

$$\mathbf{H} \succeq \mathbf{0},$$

tem-se

$$d\phi[\mathbf{H}] = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top \mathbf{H}] \leq 0.$$

Assim, aumentar $\mathbf{X}$ segundo a ordem de Loewner não aumenta a forma quadrática inversa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^\top \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}} \phi = 2\mathbf{X}^{-1} \mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{x}\mathbf{x}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere $n > 0$ e o critério

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dQ &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma}Q = \frac{n}{2}\Sigma^{-1} - \frac{1}{2}\Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

A condição de primeira ordem é

$$n\Sigma^{-1} = \Sigma^{-1}\mathbf{G}\Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n\Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Proposição 7.14 (Minimização do critério de covariância). *Considere*

$$n > 0$$

e uma matriz


$$\mathbf{G} \succ \mathbf{0}.$$

Então, a função

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \operatorname{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$



i Demonstração

Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\text{tr}(\Sigma^{-1} \mathbf{G}) = \text{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$Q(\Sigma) = \frac{1}{2} [\text{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$Q(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido.

Além disso, o critério é ilimitado inferiormente. De fato, escolhendo uma direção unitária

$$\mathbf{u} \in \mathcal{N}(\mathbf{G}),$$

pode-se fazer o autovalor de Σ associado a essa direção tender a zero. Nessa direção, o termo

$$\text{tr}(\Sigma^{-1}\mathbf{G})$$

não recebe contribuição, enquanto

$$\log \det(\Sigma) \longrightarrow -\infty.$$

Portanto,

$$Q(\Sigma) \longrightarrow -\infty,$$

e o problema não possui minimizador no cone positivo definido.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

Nesta seção, o núcleo necessário para os capítulos seguintes é formado por três ideias:

- o operador vec ;
- o produto de Kronecker;
- a identidade que relaciona vec e produtos matriciais.

As subseções posteriores sobre Hessianas vetorizadas, matriz de comutação, meia vetorização, matrizes de duplicação e eliminação e Jacobianas de transformações matriciais serão apresentadas como aprofundamento. Elas são úteis em desenvolvimentos mais avançados de cálculo matricial e inferência, mas não são necessárias para uma primeira leitura do restante do livro.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11}\mathbf{C} & \cdots & a_{1n}\mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{C} & \cdots & a_{mn}\mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1)(\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Proposição 7.15 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{AX}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

A identidade mostra que uma transformação que atua simultaneamente à esquerda e à direita de uma matriz pode ser representada como uma transformação linear usual sobre o vetor formado por seus elementos.

Assim,

$$\mathbf{X} \mapsto \mathbf{AX}\Gamma$$

corresponde, após vetorização, a

$$\text{vec}(\mathbf{X}) \mapsto (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{AX}\Gamma.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \Gamma.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\Gamma^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \mathbf{\Gamma}^\top \otimes \mathbf{A}.$$

7.10.4 Aprofundamento: derivadas vetorizadas e parâmetros matriciais

Leitura de aprofundamento

As subseções seguintes desenvolvem ferramentas úteis quando parâmetros matriciais precisam ser tratados explicitamente como vetores. Elas permitem representar Hessianas, transposições, parâmetros simétricos e Jacobianas matriciais por meio de vec , produto de Kronecker e matrizes especiais.

Esses resultados são importantes em desenvolvimentos avançados de inferência multivariada e cálculo matricial, mas podem ser omitidos em uma primeira leitura sem comprometer a continuidade dos capítulos seguintes.

7.10.4.1 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{\Gamma}) = \text{vec}(\mathbf{A})^\top \text{vec}(\mathbf{\Gamma}),$$

tem-se

$$d\phi = \text{vec}(\nabla_{\mathbf{X}} \phi)^\top d\text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec}(\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.4.2 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec}(\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A} \mathbf{X} \Gamma.$$

Vetorizando,

$$\begin{aligned} \text{vec}(\nabla_{\mathbf{X}} \phi) &= 2 \text{vec}(\mathbf{A} \mathbf{X} \Gamma) \\ &= 2(\Gamma \otimes \mathbf{A}) \text{vec}(\mathbf{X}). \end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2(\Gamma \otimes \mathbf{A}).$$

Proposição 7.16 (Convexidade da forma quadrática matricial). *Considere*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

em que

$$\mathbf{A} = \mathbf{A}^\top \in \mathbb{R}^{m \times m}$$

e

$$\boldsymbol{\Gamma} = \boldsymbol{\Gamma}^\top \in \mathbb{R}^{n \times n}.$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\boldsymbol{\Gamma} \succeq \mathbf{0},$$

então ϕ é convexa em $\mathbf{X}$.

Se

$$\mathbf{A} \succ \mathbf{0}$$

e

$$\boldsymbol{\Gamma} \succ \mathbf{0},$$

então ϕ é estritamente convexa.

i Demonstração

A Hessiana vetorizada é

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = 2 (\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

então

$$\Gamma \otimes \mathbf{A} \succeq \mathbf{0}.$$

Logo, a Hessiana é semidefinida positiva e ϕ é convexa.

Se ambas as matrizes são positivas definidas, então

$$\Gamma \otimes \mathbf{A} \succ \mathbf{0}.$$

Nesse caso, a Hessiana é positiva definida e ϕ é estritamente convexa.

7.10.4.3 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^{\top}.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^{\top}$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.4.4 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{A}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior de $\mathbf{A}$, incluindo a diagonal.

Quando

$$\mathbf{A} = \mathbf{S} = \mathbf{S}^\top,$$

o operador vech contém exatamente os elementos distintos de $\mathbf{S}$. Por isso, ele fornece uma parametrização sem redundância do espaço das matrizes simétricas.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;

- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos. A redução ocorre porque uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos. Assim, vech fornece uma parametrização sem redundância do espaço das matrizes simétricas.

7.10.4.5 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.4.6 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é a matriz de seleção que satisfaz

$$\text{vech}(\mathbf{A}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{A})$$

para toda matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \neq \mathbf{I}_{p^2}.$$

A matriz $\mathbf{L}_p^{\text{elim}}$ conserva apenas os elementos correspondentes à parte triangular inferior, enquanto $\mathbf{D}_p^{\text{dup}}$ reconstrói uma matriz impondo simetria. Portanto, esse produto não recupera arbitrariamente uma matriz não simétrica.

Para uma matriz simétrica $\mathbf{S}$, entretanto,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S}) = \text{vec}(\mathbf{S}).$$

7.10.4.7 Diferenciais de parâmetros simétricos

Proposição 7.17 (Gradiente em relação aos elementos distintos de uma matriz simétrica).
Considere um parâmetro matricial

$$\Sigma = \Sigma^\top \in \mathbb{R}^{p \times p}$$

e uma função escalar

$$\phi(\Sigma).$$

Suponha que seu diferencial possa ser escrito como

$$d\phi = \text{tr} [\mathbf{G}^\top d\Sigma],$$

em que

$$d\Sigma = d\Sigma^\top.$$

Então,

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

Em particular, quando

$$\mathbf{G} = \nabla_\Sigma \phi,$$

tem-se

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\nabla_\Sigma \phi).$$

i Demonstração

Como

$$\text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} \text{vech}(\Sigma),$$

tem-se

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Além disso,

$$d\phi = \text{vec}(\mathbf{G})^\top d \text{vec}(\Sigma).$$

Substituindo,

$$d\phi = \text{vec}(\mathbf{G})^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Logo,

$$d\phi = \left[(\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}) \right]^\top d \text{vech}(\Sigma),$$

de onde segue

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^\top \text{vec}(\mathbf{G}).$$

A parametrização por

$$\text{vech}(\Sigma)$$

remove a redundância existente em

$$\text{vec}(\Sigma),$$

pois uma matriz simétrica possui apenas

$$\frac{p(p+1)}{2}$$

elementos livres.

7.10.4.8 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned} \text{vec}(d\mathbf{X}^\top \mathbf{X}) &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^\top) \\ &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}). \end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^\top d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^\top) \text{vec}(d\mathbf{X}).$$

Logo,

$$\begin{aligned} d \text{vec}(\mathbf{X}^\top \mathbf{X}) &= [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ &\quad \times d \text{vec}(\mathbf{X}). \end{aligned}$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica, a representação por

$$\text{vec}(\mathbf{X}^\top \mathbf{X})$$

contém elementos repetidos. Uma representação sem redundância é obtida por

$$\text{vech}(\mathbf{X}^\top \mathbf{X}).$$

Aplicando a matriz de eliminação,

$$\begin{aligned} d \text{vech}(\mathbf{X}^\top \mathbf{X}) &= \mathbf{L}_n^{\text{elim}} d \text{vec}(\mathbf{X}^\top \mathbf{X}) \\ &= \mathbf{L}_n^{\text{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}). \end{aligned}$$

Assim, a Jacobiana relativa somente aos elementos distintos de $\mathbf{X}^\top \mathbf{X}$ é

$$\mathbf{J}_{\text{vech} \circ \mathcal{G}}(\mathbf{X}) = \mathbf{L}_n^{\text{elim}} \mathbf{J}_{\mathcal{G}}(\mathbf{X}).$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

O bloco de aprofundamento mostrou como vec e o produto de Kronecker podem ser estendidos para representar derivadas de ordem superior e parâmetros matriciais com restrições estruturais.

Para a continuidade do livro, as ideias essenciais a reter desta seção são

$$\text{vec}(\mathbf{A}\mathbf{X}\mathbf{\Gamma}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e o fato de que matrizes simétricas possuem apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças, momentos e distribuições marginais de vetores aleatórios contínuos. A mudança de variáveis permite, adicionalmente, transformar regiões de integração e determinar densidades após transformações do vetor aleatório.

Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$. Nesta seção, integrais múltiplas, marginalização, esperanças e mudança de variáveis constituem o núcleo necessário para os capítulos probabilísticos seguintes. A diferenciação sob o sinal de integração será apresentada posteriormente como aprofundamento.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

O produto cartesiano corresponde ao caso mais simples. Para regiões mais gerais, os limites de uma integral podem depender das demais variáveis. Em duas dimensões, por exemplo, uma região da forma

$$\mathcal{D} = \{(x_1, x_2) : a < x_1 < b, c(x_1) < x_2 < d(x_1)\}$$

conduz a

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2 = \int_a^b \int_{c(x_1)}^{d(x_1)} f(x_1, x_2) dx_2 dx_1,$$

quando as condições de integração correspondentes são satisfeitas.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.7 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.8 (Teorema de Fubini). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow \mathbb{R}$$

é mensurável e absolutamente integrável, isto é,

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| dx_1 dx_2 < \infty,$$

então, para quase todo $x_1 \in \mathcal{D}_1$,

$$x_2 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_2$, e, para quase todo $x_2 \in \mathcal{D}_2$,

$$x_1 \mapsto f(x_1, x_2)$$

é integrável em $\mathcal{D}_1$.

Além disso,

$$\begin{aligned}\int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2.\end{aligned}$$

(Axler, 2020)

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Definição 7.15 (Densidade conjunta). O vetor aleatório $\mathbf{X}$ é absolutamente contínuo em relação à medida de Lebesgue em $\mathbb{R}^p$ quando existe uma função mensurável

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty]$$

tal que, para todo conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

tem-se

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A função $f_{\mathbf{X}}$ é denominada **densidade conjunta** de $\mathbf{X}$.

Tomando

$$\mathcal{A} = \mathbb{R}^p,$$

segue necessariamente que

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Proposição 7.18 (Densidades marginais). *Considere o vetor aleatório absolutamente contínuo particionado como*

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2).$$

Então, uma densidade marginal de $\mathbf{X}_1$ é

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2,$$

e uma densidade marginal de $\mathbf{X}_2$ é

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

i Demonstração

Como a densidade conjunta é não negativa, o Teorema 7.7 permite integrar sucessivamente suas componentes.

Para qualquer conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^{p_1},$$

tem-se

$$\begin{aligned} P(\mathbf{X}_1 \in \mathcal{A}) &= \int_{\mathcal{A} \times \mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1 d\mathbf{x}_2 \\ &= \int_{\mathcal{A}} \left[\int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2 \right] d\mathbf{x}_1. \end{aligned}$$

Portanto,

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2$$

é uma densidade marginal de $\mathbf{X}_1$. O argumento para $\mathbf{X}_2$ é análogo.

A marginalização elimina as componentes que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 \, dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 \, dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções escalares, vetoriais e matriciais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.9 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol, 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

o elemento de volume transforma-se segundo

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Proposição 7.19 (Densidade de uma transformação invertível). *Considere um vetor aleatório absolutamente contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$, tal que*

$$P(\mathbf{X} \in \mathcal{D}) = 1,$$

e uma transformação

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

satisfazendo as condições do Teorema 7.9.

Defina

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}).$$

Então, para

$$\mathbf{y} \in \mathcal{G},$$

a densidade de $\mathbf{Y}$ é

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Para

$$\mathbf{y} \notin \mathcal{G},$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{y}) = 0.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é globalmente injetiva, a fórmula anterior não pode ser aplicada diretamente com uma única inversa. Sob condições de regularidade, pode-se particionar o domínio em regiões nas quais a transformação seja injetiva e somar as contribuições correspondentes às diferentes pré-imagens.

Esse caso não será desenvolvido em detalhe neste capítulo.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0,35x_1x_2 \\ x_2 + 0,20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0,35x_2 & 0,35x_1 \\ 0,40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0,35x_2 - 0,14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

A parametrização polar não é uma transformação globalmente bijetiva em todas as escolhas possíveis de domínio: a origem possui representação angular não única e o ângulo é periódico. Para a aplicação da fórmula de mudança de variáveis, trabalha-se em regiões adequadas de injetividade; as fronteiras envolvidas possuem medida nula e não alteram o valor das integrais usuais.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e sua raiz quadrada principal simétrica positiva definida

$$\Sigma^{1/2}.$$

Considere a transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned}\mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).\end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsoides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Aprofundamento: diferenciação sob o sinal de integração

Leitura de aprofundamento

A diferenciação sob o sinal de integração é utilizada para justificar formalmente identidades envolvendo funções de verossimilhança, vetor escore e informação de Fisher.

Esse conteúdo é importante para desenvolvimentos inferenciais mais formais, mas pode ser omitido em uma primeira leitura. Para a continuidade imediata dos capítulos probabilísticos, basta reter que a troca entre derivação e integração exige condições de regularidade e não pode ser realizada automaticamente.

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.10 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.11 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. *para todo $\theta \in \mathcal{V}$, a função*

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. *exista $\delta > 0$ tal que*

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. *para quase todo $\mathbf{x} \in \mathcal{D}$, a função*

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. *exista uma função integrável*

$$M_j : \mathcal{D} \rightarrow [0, \infty)$$

tal que, para quase todo

$$\mathbf{x} \in \mathcal{D},$$

a desigualdade

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

seja válida para todo t com $|t| < \delta$;


5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$



i Demonstração

Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \rightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \rightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \mapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x}) \mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

Quando as condições do Teorema 7.11 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.11 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned} \mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}. \end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

X

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A parte de aprofundamento mostrou, adicionalmente, como condições de dominação podem justificar a diferenciação de integrais parametrizadas e identidades utilizadas posteriormente em inferência.

Para a continuidade do livro, as ideias centrais a reter são:

- probabilidades são obtidas por integração da densidade conjunta;
- densidades marginais são obtidas integrando as componentes que se deseja eliminar;
- esperanças de vetores e matrizes são calculadas componente a componente;
- mudanças de variáveis exigem o determinante absoluto da Jacobiana;
- transformações afins produzem fatores de volume constantes;
- transformações elipsoidais convertem geometria esférica e elipsoidal.

7.12 Aprofundamento: aplicações à estimação e à inferência

Leitura de aprofundamento

As subseções seguintes mostram como as ferramentas de cálculo desenvolvidas neste capítulo aparecem em problemas de estimação e inferência.

O objetivo é apresentar apenas a estrutura matemática dessas aplicações. As propriedades probabilísticas dos estimadores, as condições de regularidade, as distribuições assintóticas e os procedimentos inferenciais serão desenvolvidos nos capítulos específicos do Módulo II. Este bloco pode ser omitido em uma primeira leitura sem comprometer a continuidade imediata do livro.

As aplicações seguintes envolvem gradientes, Hessianas, expansões de Taylor, diferenciação sob o sinal de integração e cálculo matricial. Elas antecipam, em nível matemático, conceitos que serão retomados posteriormente.

7.12.1 Log-verossimilhança e vetor escore

Considere observações independentes

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

provenientes de um mesmo modelo paramétrico com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros e Θ é o espaço paramétrico.

Nessas condições, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.16 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Se um estimador de máxima verossimilhança é um ponto interior do espaço paramétrico e a log-verossimilhança é diferenciável nesse ponto, então deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.17 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Se

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}$$

e

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

então

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \prec \mathbf{0},$$

e o teste da Hessiana fornece uma condição suficiente para que $\hat{\theta}$ seja um máximo local estrito da log-verossimilhança.

Em um ponto arbitrário do espaço paramétrico, a matriz

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta)$$

não precisa ser positiva semidefinida e pode, inclusive, ser indefinida.

Em um ponto estacionário interior que seja máximo local,

$$\nabla_{\theta}^2 \ell_n(\hat{\theta}) \preceq \mathbf{0},$$

de modo que

$$\mathcal{J}_n(\hat{\theta}) \succeq \mathbf{0}.$$

A informação observada pode ser singular quando, por exemplo:

- há parâmetros localmente não identificados;
- existem redundâncias na parametrização;
- a log-verossimilhança apresenta direções localmente planas.

Máximos na fronteira exigem tratamento separado, pois as condições usuais de ponto estacionário e o teste irrestrito da Hessiana não os caracterizam adequadamente.

Definição 7.18 (Informação de Fisher). Suponha que o vetor escore possua segundo momento finito. A informação de Fisher da amostra é definida por

$$\mathcal{J}_n(\theta) = E_{\theta} [\mathbf{s}_n(\theta) \mathbf{s}_n(\theta)^{\top}].$$

(Casella; Berger, 2002)

Sob condições de regularidade que permitem diferenciar a densidade sob o sinal de integração,

$$E_{\theta} [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais que justificam a relação entre a primeira e a segunda derivadas da log-verossimilhança,

$$\begin{aligned} \mathcal{J}_n(\theta) &= -E_{\theta} [\nabla_{\theta}^2 \ell_n(\theta)] \\ &= E_{\theta} [\mathcal{J}_n(\theta)]. \end{aligned}$$

Assim, em modelos regulares, a informação de Fisher coincide com a esperança da informação observada. Como o escore possui esperança nula nessas condições,

$$\mathcal{J}_n(\theta) = \text{Cov}_{\theta} [\mathbf{s}_n(\theta)].$$

Essas identidades não devem ser utilizadas automaticamente. Sua validade depende das condições de regularidade, incluindo a possibilidade de intercambiar derivação e integração e o comportamento do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_{\theta}^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_{\theta}^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = -\mathbf{s}_n(\theta^{(t)}),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

Essa é a aplicação do método de Newton à equação

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

Quando

$$\mathcal{J}_n(\theta^{(t)}) \succ \mathbf{0},$$

a direção

$$\mathbf{d}^{(t)} = \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)})$$

é uma direção local de aumento da log-verossimilhança, pois

$$\mathbf{s}_n(\theta^{(t)})^\top \mathbf{d}^{(t)} > 0$$

quando o escore é não nulo.

Ainda assim, um passo completo pode não aumentar a log-verossimilhança quando o ponto atual está distante da solução. Em aplicações numéricas, podem ser utilizados controles do comprimento da etapa.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada

$$\mathcal{J}_n(\theta)$$

pela informação de Fisher

$$\mathcal{J}_n(\theta).$$

Sob as condições de regularidade para as quais

$$\mathcal{J}_n(\theta) = E_\theta [\mathcal{J}_n(\theta)],$$

essa substituição pode ser interpretada como a troca da curvatura observada pela curvatura esperada da log-verossimilhança.

Quando

$$\mathcal{J}_n(\theta^{(t)})$$

é invertível, a direção $\mathbf{d}^{(t)}$ é obtida pela solução de

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = \mathbf{s}_n(\theta^{(t)}),$$

seguida da atualização

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Assim, Newton–Raphson utiliza

$$\mathcal{J}_n(\theta),$$

enquanto o método do escore de Fisher utiliza

$$\mathcal{J}_n(\theta).$$

Quando a identidade de informação é válida, a primeira representa a curvatura observada e a segunda sua correspondente curvatura esperada.

As atualizações coincidem quando as duas matrizes são iguais no ponto considerado ou, mais geralmente, quando produzem a mesma solução para a equação que determina a direção da etapa.

7.12.5 Expansão local de uma raiz do escore

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned}\mathbf{0} &= \mathbf{s}_n(\hat{\theta}) \\ &\approx \mathbf{s}_n(\theta_0) + \nabla_{\theta}^2 \ell_n(\theta_0) (\hat{\theta} - \theta_0).\end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n(\theta_0) = -\mathcal{J}_n(\theta_0),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa expressão é uma aproximação local de primeira ordem. A obtenção de uma representação assintótica rigorosa exige controlar o termo restante da expansão e substituir a informação observada por um limite apropriado.

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.12 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q$$

diferenciável no ponto

$$\theta.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A demonstração formal utiliza a aproximação de Taylor de primeira ordem juntamente com resultados probabilísticos sobre convergência em distribuição. Esses resultados serão desenvolvidos no módulo inferencial; neste capítulo interessa principalmente a origem diferencial da matriz

$$\mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta)(\hat{\theta} - \theta).$$

A matriz

$$\mathbf{V}_{\mathbf{g}} = \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}$$

é a matriz de covariâncias da distribuição limite de

$$\sqrt{n} \left[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \right].$$

Por isso, denomina-se

$$\frac{1}{n} \mathbf{V}_{\mathbf{g}}$$

matriz de covariâncias assintótica de

$$\mathbf{g}(\hat{\theta}).$$

Em aplicações, é comum utilizá-la como aproximação da matriz de covariâncias do estimador para amostras grandes. A convergência em distribuição, isoladamente, não garante convergência dos segundos momentos; essa interpretação requer condições adicionais de regularidade.

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância assintótica é

$$\frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_2}{\theta_1} \\ -\frac{1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n} \left(\hat{\theta} - \theta \right) \xrightarrow{d} N_2 \left(\mathbf{0}, \Xi \right),$$

então

$$\sqrt{n} \left(\frac{\hat{\theta}_1}{\hat{\theta}_2} - \frac{\theta_1}{\theta_2} \right)$$

converge em distribuição para uma normal com variância assintótica

$$\nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.25 (Estimação de um vetor de médias). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

Exemplo 7.26 (Critério do modelo linear multivariado). Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere o critério

$$\begin{aligned} Q(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} Q = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Observe que, para Σ fixa e positiva definida, o minimizador em relação a $\mathbf{B}$ não depende de Σ . Isso decorre do fato de que Σ^{-1} é invertível e desaparece da condição de primeira ordem.

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_\mathcal{E} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^\top (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_\mathcal{E}).$$

Se

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_\mathcal{E}.$$

A condição

$$\mathbf{G}_\mathcal{E} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo.

Se $\mathbf{X}$ possui posto coluna completo k , a matriz residual pode ser escrita como

$$\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}} = (\mathbf{I}_n - \mathbf{P}_\mathbf{X}) \mathbf{Y},$$

em que

$$\text{posto}(\mathbf{I}_n - \mathbf{P}_\mathbf{X}) = n - k.$$

Consequentemente,

$$\text{posto}(\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}) \leq \min(p, n - k).$$

Assim, uma condição necessária para

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

é

$$n - k \geq p.$$

Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério é ilimitado inferiormente no cone das matrizes positivas definidas. Em particular, pode-se fazer um autovalor de Σ tender a zero em uma direção pertencente ao núcleo de $\mathbf{G}_{\mathcal{E}}$ sem produzir aumento compensatório no termo de traço.

Aqui o modelo foi utilizado apenas como uma aplicação conjunta de gradientes matriciais, log-determinante e diferenciação de funções envolvendo matrizes inversas.

A interpretação probabilística do critério, as propriedades dos estimadores, suas distribuições e a formulação de hipóteses serão desenvolvidas posteriormente nos capítulos de estimação, modelo linear multivariado e inferência.

O bloco de aprofundamento mostrou como as ferramentas de cálculo deste capítulo aparecem em problemas de estimação e inferência:

Tabela 7.2: Relações entre as ferramentas de cálculo e suas aplicações estatísticas.

Ferramenta matemática	Aplicação estatística
Gradiente	Vetor escore
Hessiana	Informação observada
Esperança da curvatura	Informação de Fisher
Expansão de Taylor	Aproximações locais e método delta
Cálculo matricial	Estimação de parâmetros vetoriais e matriciais

Essas relações devem ser entendidas neste capítulo como aplicações das ferramentas matemáticas. Sua interpretação estatística completa será retomada no Módulo II.

7.13 Síntese do capítulo

O capítulo reuniu as ferramentas de cálculo necessárias para estudar funções de vetores e matrizes e para formular problemas posteriores da Estatística Multivariada.

No cálculo diferencial, o gradiente representa a variação de primeira ordem de uma função escalar, a Jacobiana representa a transformação linear local de uma função vetorial e a Hessiana descreve sua curvatura. Essas estruturas sustentam aproximações de Taylor e condições de otimalidade.

A otimização utiliza essas derivadas de formas diferentes. Em problemas sem restrições, pontos estacionários e a definitude da Hessiana permitem caracterizar soluções locais, enquanto a convexidade fornece resultados globais. Em problemas com restrições de igualdade, os multiplicadores de Lagrange incorporam a geometria do conjunto viável. As funções de resíduos mostram como essas ferramentas conduzem às equações normais e aos problemas de mínimos quadrados.

No cálculo matricial, os diferenciais e as identidades de traço permitem trabalhar diretamente com parâmetros matriciais. Derivadas de inversas, determinantes e log-determinantes serão utilizadas em critérios que envolvem matrizes de covariâncias. A vetorização e o produto de Kronecker fornecem uma representação vetorial para transformações entre matrizes.

O cálculo integral completa essa estrutura ao permitir a obtenção de probabilidades, expectativas e densidades marginais. O Teorema da Mudança de Variáveis mostra como o determinante Jacobiano modifica elementos de volume e densidades sob transformações. Transformações afins e elipsoidais conectam essa ideia às formas quadráticas e às matrizes positivas definidas.

As principais relações estabelecidas no capítulo podem ser resumidas da seguinte forma:

Tabela 7.3: Relações entre as ferramentas do cálculo e seus usos posteriores.

Estrutura matemática	Papel nos capítulos seguintes
Derivadas	Aproximação local e otimização
Diferenciais matriciais	Manipulação e estimação de parâmetros matriciais
Integração e Jacobianos	Construção e transformação de distribuições multivariadas

A Tabela 7.4 reúne algumas das identidades de uso recorrente.

Tabela 7.4: Identidades selecionadas de cálculo vetorial e matricial.

Função ou transformação	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Os blocos de aprofundamento desenvolveram ferramentas que não são necessárias para uma primeira leitura do capítulo, entre elas derivadas vetorizadas e parametrização de matrizes simétricas, diferenciação sob o sinal de integração e aplicações do cálculo à estimação e à inferência. Esses resultados poderão ser retomados quando forem necessários nos capítulos posteriores.

Ao final deste capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- interpretar derivadas como aproximações locais;
- utilizar Taylor e a Hessiana em problemas de otimização;
- formular condições de primeira ordem com e sem restrições;
- derivar critérios quadráticos e equações normais;
- utilizar diferenciais e identidades de traço em funções matriciais;
- diferenciar expressões envolvendo inversas, determinantes e log-determinantes;
- utilizar vec, produto de Kronecker e sua identidade de vetorização;
- calcular probabilidades, expectativas e densidades marginais por integração;
- aplicar mudanças de variáveis e interpretar o determinante Jacobiano.

O Capítulo 7 encerra o **Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada**.

Antes do início do Módulo II, os **Exercícios de fixação do Módulo I** retomam de forma integrada os principais conceitos desenvolvidos ao longo dos sete capítulos. Os exercícios articulam representação matricial dos dados, projeções, transformações lineares, formas quadráticas, autovalores e autovetores, SVD, pseudoinversa e cálculo vetorial e matricial em problemas que serão utilizados posteriormente na Estatística Multivariada.

O capítulo seguinte inicia o **Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada** com o estudo das matrizes de covariâncias e correlações. Gradientes, formas quadráticas, transformações lineares, integrais, projeções e produtos matriciais fornecerão

as ferramentas matemáticas para descrever a variabilidade conjunta de vetores aleatórios e sustentar os desenvolvimentos probabilísticos e inferenciais posteriores.

Exercícios de fixação do Módulo I

Os exercícios deste módulo retomam os fundamentos matemáticos desenvolvidos nos capítulos anteriores e os utilizam em problemas que reaparecerão ao longo da Estatística Multivariada.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades e operações com vetores e matrizes, bem como suas interpretações algébricas e geométricas. As matrizes foram escolhidas para permitir resultados exatos e favorecer a compreensão das relações entre Álgebra Linear, Geometria e Cálculo.

Na segunda parte, o **R** ou **Python** será utilizado para estender essas mesmas ideias a matrizes de maior dimensão e a conjuntos de dados. O objetivo não é substituir os cálculos matriciais por funções prontas, mas utilizar a computação para aplicar e verificar propriedades estudadas no Módulo I.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos no Módulo I (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de propriedades como simetria, ortogonalidade, independência linear, posto, invertibilidade, definição positiva ou outras condições específicas, essas condições devem ser verificadas ou justificadas.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Exercícios sem uso de computador

Exercício 7.1 (Transformação de variáveis em uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 2 & 2 \\ 3 & 0 & 1 \end{bmatrix},$$

em que as linhas representam quatro observações e as colunas representam três variáveis.

Considere também a transformação

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

1. Escreva, para uma observação genérica

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

as duas componentes de

$$\mathbf{y} = \mathbf{Ax}.$$

2. Interprete cada nova componente como uma combinação linear das variáveis originais.
3. Determine a matriz de dados transformada utilizando

$$\mathbf{Y} = \mathbf{XA}^\top.$$

4. Indique as dimensões de $\mathbf{X}$, $\mathbf{A}$ e $\mathbf{Y}$ e explique por que a transformação reduziu o número de variáveis de três para duas.
5. Determine o posto de $\mathbf{A}$.
6. Determine a dimensão de $\mathcal{N}(\mathbf{A})$ e explique o significado desse resultado em termos de perda de informação.
7. Sabendo apenas $\mathbf{y} = \mathbf{Ax}$, discuta se é possível recuperar unicamente o vetor original $\mathbf{x}$.

Exercício 7.2 (Centralização como projeção). Considere $n = 4$ e defina

$$\mathbf{H}_4 = \mathbf{I}_4 - \frac{1}{4}\mathbf{1}_4\mathbf{1}_4^\top.$$

1. Escreva explicitamente a matriz $\mathbf{H}_4$.

2. Verifique que

$$\mathbf{H}_4^\top = \mathbf{H}_4$$

e

$$\mathbf{H}_4^2 = \mathbf{H}_4.$$

3. Mostre que

$$\mathbf{H}_4 \mathbf{1}_4 = \mathbf{0}.$$

4. Aplique $\mathbf{H}_4$ à matriz $\mathbf{X}$ do Exercício 7.1:

$$\mathbf{X}_c = \mathbf{H}_4 \mathbf{X}.$$

5. Verifique diretamente que

$$\mathbf{1}_4^\top \mathbf{X}_c = \mathbf{0}^\top.$$

6. Interprete a igualdade anterior em termos das médias das variáveis.

Exercício 7.3 (Centralização e reescalonamento das variáveis). Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times 3}$$

e a matriz diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 4 \end{bmatrix}.$$

1. Determine $\mathbf{D}^{-1}$.

2. Considere inicialmente uma matriz já centralizada $\mathbf{X}_c$ e defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}^{-1}.$$

Explique o efeito dessa transformação sobre cada uma das três variáveis.

3. Explique por que $\mathbf{D}^{-1}$ atua à direita da matriz de dados.
4. Compare essa operação com a centralização

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

explicando por que $\mathbf{H}_n$ atua à esquerda enquanto $\mathbf{D}^{-1}$ atua à direita.

5. Escreva, em uma única expressão, a transformação que primeiro centraliza $\mathbf{X}$ e depois reescala suas variáveis.
6. A centralização e o reescalonamento atuam no mesmo espaço? Justifique utilizando as dimensões de $\mathbf{H}_n$ e $\mathbf{D}^{-1}$.

Exercício 7.4 (Duas matrizes de Gram para os mesmos dados). Considere a matriz centralizada

$$\mathbf{X}_c = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 2 \\ 0 & -2 \end{bmatrix}.$$

1. Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

2. Indique as dimensões das duas matrizes.
3. Qual das duas matrizes contém os produtos internos entre as colunas de $\mathbf{X}_c$?
4. Qual contém os produtos internos entre as linhas de $\mathbf{X}_c$?
5. Determine o posto das duas matrizes.
6. Determine os autovalores positivos de cada matriz.
7. Verifique que os autovalores positivos coincidem.
8. Relacione esse resultado à construção da SVD de uma matriz retangular.

Exercício 7.5 (Projeção, ajuste e resíduos). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

1. Verifique que as colunas de $\mathbf{X}$ são linearmente independentes.
2. Determine

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

3. Verifique que

$$\mathbf{P}_X^\top = \mathbf{P}_X$$

e

$$\mathbf{P}_X^2 = \mathbf{P}_X.$$

4. Calcule

$$\hat{\mathbf{y}} = \mathbf{P}_X \mathbf{y}.$$

5. Determine o vetor de resíduos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

6. Verifique que

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

7. Identifique o subespaço ao qual pertence $\hat{\mathbf{y}}$.
8. Identifique o subespaço ao qual pertence $\mathbf{e}$.
9. Interprete geometricamente a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}.$$

Exercício 7.6 (Um problema de mínimos quadrados por três perspectivas). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

O objetivo é determinar o vetor que minimiza

$$\|\mathbf{b} - \mathbf{Ax}\|^2.$$

Resolva o problema das três formas seguintes.

1. Determine a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$ e obtenha, a partir dela, o vetor ajustado.
2. Resolva as equações normais

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}.$$

3. Calcule

$$\mathbf{A}^\top \mathbf{A}$$

e determine os valores singulares de $\mathbf{A}$.

4. Construa uma SVD compacta de $\mathbf{A}$.
5. Construa a pseudoinversa

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top$$

e obtenha

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}.$$

6. Compare as soluções obtidas pelas três abordagens.
7. Compare também os vetores ajustados e os resíduos.
8. Explique por que projeções, equações normais e pseudoinversa conduzem ao mesmo problema de aproximação.

Exercício 7.7 (Forma quadrática e direções privilegiadas). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. Calcule $q(\mathbf{x})$ para

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

2. Determine os autovalores de $\mathbf{A}$.
3. Determine uma base ortonormal de autovetores.
4. Calcule a forma quadrática em cada autovetor unitário.
5. Determine

$$\max_{\|\mathbf{x}\|=1} q(\mathbf{x})$$

e

$$\min_{\|\mathbf{x}\|=1} q(\mathbf{x}).$$

6. Relacione os valores encontrados aos autovalores de $\mathbf{A}$.

Exercício 7.8 (Norma euclidiana e norma induzida). Considere

$$\mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

responda:

1. Calcule as normas euclidianas de $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{z}$.
2. Calcule as normas induzidas por $\mathbf{M}$,

$$\|\mathbf{v}\|_{\mathbf{M}} = \sqrt{\mathbf{v}^{\top} \mathbf{M} \mathbf{v}}.$$

3. Calcule a distância euclidiana entre $\mathbf{x}$ e $\mathbf{y}$.
4. Calcule a distância induzida por $\mathbf{M}$ entre os mesmos vetores.
5. Qual coordenada recebe maior peso na geometria induzida por $\mathbf{M}$?
6. Explique por que duas geometrias diferentes podem produzir avaliações diferentes da proximidade entre observações.

Exercício 7.9 (Matrizes particionadas e complemento de Schur). Considere a matriz simétrica

$$\mathbf{M} = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

particionada como

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^{\top} & \mathbf{D} \end{bmatrix},$$

em que

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{D} = [2].$$

1. Verifique que $\mathbf{A}$ é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Calcule o complemento de Schur de $\mathbf{A}$ em $\mathbf{M}$,

$$\mathbf{S} = \mathbf{D} - \mathbf{B}^{\top} \mathbf{A}^{-1} \mathbf{B}.$$

4. Verifique que $\mathbf{S} > 0$.
5. Utilize a identidade por blocos

$$\det(\mathbf{M}) = \det(\mathbf{A}) \det(\mathbf{S})$$

para calcular $\det(\mathbf{M})$.

6. Confirme o resultado calculando diretamente o determinante de $\mathbf{M}$.

Exercício 7.10 (Direção que maximiza uma medida de dispersão). Considere

$$\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Para um vetor unitário $\mathbf{a}$, defina

$$D(\mathbf{a}) = \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

1. Determine os autovalores de $\mathbf{S}$.
2. Determine uma base ortonormal de autovetores.
3. Resolva

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

4. Determine a direção que minimiza $D(\mathbf{a})$ sob a mesma restrição.
5. Calcule o valor da forma quadrática nas duas direções.
6. Se $\mathbf{S}$ representasse uma matriz de dispersão de duas variáveis, interprete a direção associada ao maior autovalor.
7. Interprete também a direção associada ao menor autovalor.

Exercício 7.11 (Maximização de uma razão entre duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 12 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Resolva

$$\max_{\mathbf{x} \neq \mathbf{0}} \frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}}.$$

1. Mostre, por multiplicadores de Lagrange ou pelo quociente de Rayleigh generalizado, que as direções candidatas satisfazem

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{B} \mathbf{x}.$$

2. Determine os autovalores generalizados.
3. Determine um autovetor associado a cada autovalor generalizado.
4. Normalize os autovetores segundo a geometria de $\mathbf{B}$, impondo

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = 1.$$

5. Determine o valor máximo do quociente.
6. Determine também o valor mínimo.
7. Verifique que os dois autovetores podem ser escolhidos de modo que

$$\mathbf{x}_1^\top \mathbf{B} \mathbf{x}_2 = 0.$$

8. Compare essa ortogonalidade com a ortogonalidade euclidiana usual.

Exercício 7.12 (Transformação de um problema generalizado). Utilize as matrizes $\mathbf{A}$ e $\mathbf{B}$ do Exercício 7.11.

1. Determine a raiz quadrada principal

$$\mathbf{B}^{1/2}$$

e sua inversa

$$\mathbf{B}^{-1/2}.$$

2. Construa

$$\mathbf{C} = \mathbf{B}^{-1/2} \mathbf{A} \mathbf{B}^{-1/2}.$$

3. Determine os autovalores de $\mathbf{C}$.

4. Compare-os com os autovalores generalizados obtidos no exercício anterior.

5. Considere a transformação

$$\mathbf{z} = \mathbf{B}^{1/2} \mathbf{x}.$$

Mostre que

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = \mathbf{z}^\top \mathbf{z}.$$

6. Mostre que

$$\frac{\mathbf{x}^\top \mathbf{A} \mathbf{x}}{\mathbf{x}^\top \mathbf{B} \mathbf{x}} = \frac{\mathbf{z}^\top \mathbf{C} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}.$$

7. Explique por que a transformação converte um problema em geometria induzida por $\mathbf{B}$ em um problema espectral euclidiano.

Exercício 7.13 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

1. Calcule

$$\mathbf{A}^\top \mathbf{A}.$$

2. Determine os autovalores de $\mathbf{A}^\top \mathbf{A}$.

3. Determine os valores singulares positivos de $\mathbf{A}$ em ordem decrescente.

4. Determine os vetores singulares à direita correspondentes.

5. Utilize

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}$$

para construir os vetores singulares à esquerda.

6. Verifique que os vetores obtidos são ortonormais.

7. Construa

$$\mathbf{U}_r, \quad \mathbf{D}_r, \quad \mathbf{V}_r.$$

8. Verifique diretamente que

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

9. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A})$.

10. Identifique uma base ortonormal para $\mathcal{C}(\mathbf{A}^\top)$.

Exercício 7.14 (Aproximação de posto reduzido). Utilize a matriz e a SVD do Exercício 7.13.

1. Escreva

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + d_2 \mathbf{u}_2 \mathbf{v}_2^\top.$$

2. Construa a aproximação de posto 1

$$\mathbf{A}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1^\top.$$

3. Determine explicitamente

$$\mathbf{A} - \mathbf{A}_1.$$

4. Calcule

$$\|\mathbf{A} - \mathbf{A}_1\|_F.$$

5. Verifique que, neste caso,

$$\|\mathbf{A} - \mathbf{A}_1\|_F = d_2.$$

6. Calcule

$$\|\mathbf{A}\|_F^2.$$

7. Verifique que

$$\|\mathbf{A}\|_F^2 = d_1^2 + d_2^2.$$

8. Calcule

$$\frac{d_1^2}{d_1^2 + d_2^2}.$$

9. Interprete essa razão como a parcela da magnitude quadrática da matriz preservada pela aproximação de posto 1.

Exercício 7.15 (Gradiente e Hessiana de um critério de mínimos quadrados). Considere

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2.$$

1. Desenvolva $Q(\beta)$ como uma expressão quadrática em β .

2. Obtenha

$$\nabla_{\beta} Q(\beta).$$

3. Obtenha

$$\nabla_{\beta}^2 Q(\beta).$$

4. Mostre que, se $\mathbf{X}$ possui posto completo de colunas,

$$\mathbf{X}^{\top} \mathbf{X} \succ \mathbf{0}.$$

5. Conclua que a Hessiana é positiva definida.

6. Mostre que o ponto estacionário é o único minimizador global.
7. Aplique o resultado a

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix},$$

determinando $\hat{\beta}$ exatamente.

8. Compare a solução com aquela obtida geometricamente no Exercício 7.5.

Exercício 7.16 (Multiplicadores de Lagrange e autovalores). Considere uma matriz real simétrica $\mathbf{A}$ e o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

1. Construa a função lagrangiana.
2. Diferencie-a em relação a $\mathbf{x}$.
3. Diferencie-a em relação ao multiplicador de Lagrange.
4. Mostre que as condições de primeira ordem conduzem a uma equação da forma

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}.$$

5. Explique por que o problema de otimização se transforma em um problema de autovalores.
6. Resolva completamente o problema para

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

7. Determine também o mínimo sob a mesma restrição.
8. Compare os resultados com os obtidos no Exercício 7.10.

Exercício 7.17 (Vetorização e produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Adote a convenção de que $\text{vec}(\mathbf{X})$ empilha as colunas de $\mathbf{X}$.

1. Calcule diretamente

$$\mathbf{Y} = \mathbf{AXB}.$$

2. Determine

$$\text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{Y}).$$

3. Construa

$$\mathbf{B}^\top \otimes \mathbf{A}.$$

4. Calcule

$$(\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

5. Verifique a identidade

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

6. Compare as dimensões da transformação matricial com as dimensões de sua representação vetorizada.

Exercício 7.18 (Diferenciação de um critério matricial). Considere, para

$$\Sigma \succ \mathbf{0},$$

a função

$$Q(\Sigma) = 2 \log \det(\Sigma) + \text{tr}(\mathbf{G}\Sigma^{-1}),$$

em que

$$\mathbf{G} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Utilize diferenciais para obter

$$dQ.$$

2. Mostre que um ponto estacionário deve satisfazer

$$2\Sigma^{-1} - \Sigma^{-1}\mathbf{G}\Sigma^{-1} = \mathbf{0}.$$

3. Resolva essa equação para Σ .
4. Verifique que a matriz obtida é positiva definida.

Exercício 7.19 (Transformação afim, Jacobiana e alteração de área). Considere

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

com

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

1. Calcule $\det(\mathbf{A})$ e mostre que a transformação é invertível.
2. Determine $\mathbf{A}^{-1}$.
3. Escreva a transformação inversa

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

4. Determine a matriz Jacobiana da transformação de $\mathbf{x}$ para $\mathbf{y}$.
5. Determine o determinante Jacobiano.
6. Considere a região

$$0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1.$$

Determine as imagens de seus quatro vértices.

7. Descreva geometricamente a região transformada.
8. Determine sua área.
9. Compare a razão entre a área transformada e a área original com

$$|\det(\mathbf{A})|.$$

Parte II — Exercícios com uso do R

Nesta parte, utilize preferencialmente operações matriciais do R. Quando uma função pronta reproduzir diretamente um resultado estudado no Módulo I, utilize-a apenas depois da construção matricial, como forma de conferência.

Em comparações envolvendo posto, autovalores teoricamente nulos ou valores singulares numericamente nulos, considere a possibilidade de pequenos erros de arredondamento computacional e utilize uma tolerância numérica adequada.

Exercício 7.20 (Centralização matricial dos dados `USArrests`). Considere as quatro variáveis quantitativas do conjunto de dados `USArrests`.

1. Armazene a matriz de dados em um objeto $\mathbf{X}$.
2. Determine n e p a partir da própria matriz.
3. Construa explicitamente

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

4. Obtenha

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

- Verifique numericamente que as médias das colunas de $\mathbf{X}_c$ são zero, admitindo apenas diferenças de arredondamento.
- Verifique numericamente que

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

- Determine o posto numérico de $\mathbf{H}_n$.
- Verifique que

$$\mathbf{H}_n \mathbf{1}_n \approx \mathbf{0}.$$

- Somente ao final, compare $\mathbf{X}_c$ com o resultado produzido por

```
scale(X, center = TRUE, scale = FALSE)
```

- Explique geometricamente o papel de $\mathbf{H}_n$.

Exercício 7.21 (Matrizes de Gram e seus espectros). Utilize a matriz centralizada $\mathbf{X}_c$ obtida no Exercício 7.20.

- Calcule

$$\mathbf{G}_V = \mathbf{X}_c^\top \mathbf{X}_c$$

e

$$\mathbf{G}_O = \mathbf{X}_c \mathbf{X}_c^\top.$$

- Compare as dimensões das duas matrizes.
- Determine seus postos numéricos.
- Calcule os autovalores de ambas.
- Para identificar os autovalores numericamente positivos, utilize uma tolerância relativa, por exemplo,

$$\lambda_j > 10^{-10} \lambda_{\max}.$$

6. Compare os autovalores positivos de $\mathbf{G}_V$ e $\mathbf{G}_O$.
7. Explique por que uma matriz 4×4 e uma matriz 50×50 contêm o mesmo espectro não nulo.
8. Relacione os resultados aos valores singulares de $\mathbf{X}_c$.

Exercício 7.22 (Construção de novas variáveis por transformação linear). Considere apenas as quatro variáveis quantitativas de `iris`, formando

$$\mathbf{X} \in \mathbb{R}^{150 \times 4}.$$

Defina

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & -1 & 0 & 0 \end{bmatrix}.$$

1. Obtenha

$$\mathbf{Y} = \mathbf{XA}^\top.$$

2. Escreva explicitamente cada uma das três novas variáveis como combinação das quatro variáveis originais.
3. Verifique as dimensões de $\mathbf{Y}$.
4. Determine o posto de $\mathbf{A}$.
5. Determine a dimensão de $\mathcal{N}(\mathbf{A})$.
6. Discuta se a transformação preserva toda a informação necessária para reconstruir as quatro variáveis originais.
7. Centralize $\mathbf{X}$.
8. Aplique a mesma transformação à matriz centralizada.
9. Verifique as médias das três variáveis transformadas após a centralização.
10. Explique por que uma transformação linear de dados centralizados continua produzindo variáveis com média amostral zero.

Exercício 7.23 (Busca da direção de maior dispersão). Utilize as variáveis quantitativas de `USArrests`.

1. Centralize a matriz de dados e denote o resultado por $\mathbf{X}_c$.

2. Construa

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

3. Obtenha os autovalores e autovetores de $\mathbf{S}$ utilizando `eigen()`.

4. Identifique a direção unitária $\mathbf{a}_1$ associada ao maior autovalor.

5. Calcule

$$\mathbf{a}_1^\top \mathbf{S} \mathbf{a}_1.$$

6. Compare o resultado com o maior autovalor de $\mathbf{S}$.

7. Gere um grande número de vetores aleatórios em $\mathbb{R}^4$ e normalize cada um para norma unitária.

8. Para cada vetor $\mathbf{a}$, calcule

$$\mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

9. Compare o maior valor encontrado entre as direções aleatórias com o maior autovalor de $\mathbf{S}$.

10. Explique o que esse experimento numérico mostra sobre o quociente de Rayleigh.

11. Repita a análise após padronizar as quatro variáveis para variância unitária.

12. Compare a nova direção de máxima dispersão com aquela obtida utilizando as variáveis apenas centralizadas e discuta o efeito da mudança de escala.

Não utilize `prcomp()` neste exercício.

Exercício 7.24 (Projeção e reconstrução a partir de uma direção). Utilize $\mathbf{X}_c$ e a direção $\mathbf{a}_1$ obtidas no Exercício 7.23.

1. Calcule as coordenadas das observações na direção $\mathbf{a}_1$:

$$\mathbf{z}_1 = \mathbf{X}_c \mathbf{a}_1.$$

2. Verifique as dimensões de $\mathbf{z}_1$.

3. Reconstrua a parcela da matriz de dados associada a essa direção:

$$\widehat{\mathbf{X}}_1 = \mathbf{z}_1 \mathbf{a}_1^\top.$$

4. Verifique que $\widehat{\mathbf{X}}_1$ possui posto 1.
5. Calcule

$$\mathbf{E}_1 = \mathbf{X}_c - \widehat{\mathbf{X}}_1.$$

6. Calcule

$$\|\mathbf{X}_c\|_F^2, \quad \|\widehat{\mathbf{X}}_1\|_F^2, \quad \|\mathbf{E}_1\|_F^2.$$

7. Verifique numericamente que

$$\|\mathbf{X}_c\|_F^2 \approx \|\widehat{\mathbf{X}}_1\|_F^2 + \|\mathbf{E}_1\|_F^2.$$

8. Verifique também que

$$\langle \widehat{\mathbf{X}}_1, \mathbf{E}_1 \rangle_F \approx 0.$$

9. Interprete o que foi preservado e o que foi descartado pela projeção.

Exercício 7.25 (SVD e decomposição espectral da matriz de dados). Utilize a matriz centralizada de `USArrests`.

1. Calcule sua SVD utilizando `svd()`.
2. Extraia $\mathbf{U}$, os valores singulares e $\mathbf{V}$.
3. Construa explicitamente a matriz diagonal $\mathbf{D}$.
4. Verifique numericamente que

$$\mathbf{X}_c \approx \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

5. Verifique que

$$\mathbf{X}_c^\top \mathbf{X}_c \approx \mathbf{V}\mathbf{D}^2\mathbf{V}^\top.$$

6. Calcule

```
eigen(t(Xc) %*% Xc)
```

e compare os autovetores obtidos com os vetores singulares à direita.

7. Compare os autovalores de $\mathbf{X}_c^\top \mathbf{X}_c$ com os quadrados dos valores singulares.
8. Explique por que vetores produzidos por `eigen()` e `svd()` podem diferir apenas pelo sinal.
9. Relacione as colunas de $\mathbf{V}$ a direções no espaço das variáveis.

Exercício 7.26 (Aproximações de posto reduzido em uma matriz de dados). Utilize a SVD obtida no Exercício 7.25.

Para

$$k = 1, 2, 3,$$

construa

$$\mathbf{X}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Para cada valor de k :

1. determine o posto numérico de $\mathbf{X}_{c,k}$;
2. calcule

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F;$$

3. verifique numericamente que

$$\|\mathbf{X}_c - \mathbf{X}_{c,k}\|_F^2 \approx \sum_{j=k+1}^r d_j^2;$$

4. calcule

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2};$$

5. interprete essa quantidade em termos da magnitude quadrática preservada pela aproximação;
6. compare os erros para $k = 1$, $k = 2$ e $k = 3$;
7. explique por que o erro não pode aumentar quando k cresce.

Não utilize `prcomp()` para construir as aproximações.

Exercício 7.27 (Mínimos quadrados com duas variáveis respostas). Utilize o conjunto de dados `mtcars`.

Considere como respostas:

- `mpg`;
- `qsec`;

e como variáveis explicativas:

- `intercepto`;
- `wt`;
- `hp`.

Construa

$$\mathbf{Y} \in \mathbb{R}^{n \times 2}$$

e

$$\mathbf{X} \in \mathbb{R}^{n \times 3}.$$

1. Verifique as dimensões das duas matrizes.
2. Verifique que $\mathbf{X}$ possui posto completo de colunas.
3. Calcule

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

4. Determine as dimensões de $\widehat{\mathbf{B}}$.
5. Interprete suas duas colunas.
6. Calcule

$$\widehat{\mathbf{Y}} = \mathbf{X} \widehat{\mathbf{B}}$$

e

$$\mathbf{E} = \mathbf{Y} - \widehat{\mathbf{Y}}.$$

7. Verifique numericamente que

$$\mathbf{X}^\top \mathbf{E} \approx \mathbf{0}.$$

8. Ajuste separadamente, utilizando `lm()`, um modelo para `mpg` e outro para `qsec`.
 9. Compare os coeficientes das duas regressões com as colunas de $\widehat{\mathbf{B}}$.

Exercício 7.28 (Posto deficiente e pseudoinversa). Utilize `mtcars` e considere `mpg` como vetor-resposta.

Construa uma matriz de delineamento cujas colunas sejam

$$\mathbf{1}, \quad \text{wt}, \quad 2 \text{ wt}.$$

1. Determine o posto da matriz de delineamento.
2. Compare o posto com o número de colunas.
3. Calcule seus valores singulares.
4. Identifique quais valores singulares devem ser considerados numericamente positivos utilizando uma tolerância adequada.
5. Tente utilizar diretamente

$$(\mathbf{X}^\top \mathbf{X})^{-1}$$

e explique o problema encontrado.

6. Construa manualmente a pseudoinversa de $\mathbf{X}$ a partir de sua SVD, invertendo apenas os valores singulares considerados positivos.
7. Obtenha

$$\hat{\beta}^+ = \mathbf{X}^+ \mathbf{y}.$$

8. Calcule

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}^+.$$

9. Determine um vetor não nulo

$$\mathbf{h} \in \mathcal{N}(\mathbf{X}).$$

10. Para diferentes valores de γ , construa

$$\hat{\beta}(\gamma) = \hat{\beta}^+ + \gamma \mathbf{h}.$$

11. Verifique que todos esses vetores produzem o mesmo vetor ajustado.

12. Compare numericamente

$$\|\hat{\beta}(\gamma)\|$$

para vários valores positivos e negativos de γ .

13. Verifique que a solução fornecida pela pseudoinversa possui a menor norma euclidiana.

14. Relacione a não unicidade dos coeficientes ao núcleo de $\mathbf{X}$.

Exercício 7.29 (Vetorização de um modelo com várias respostas). Retome as matrizes $\mathbf{X}$, $\mathbf{Y}$ e $\hat{\mathbf{B}}$ do Exercício 7.27.

A relação matricial é

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\mathbf{B}}.$$

1. Construa em R

$$\text{vec}(\hat{\mathbf{Y}})$$

empilhando as colunas.

2. Construa

$$\text{vec}(\hat{\mathbf{B}}).$$

3. Construa

$$\mathbf{I}_2 \otimes \mathbf{X}.$$

4. Verifique suas dimensões.

5. Verifique numericamente que

$$\text{vec}(\hat{\mathbf{Y}}) = (\mathbf{I}_2 \otimes \mathbf{X}) \text{vec}(\hat{\mathbf{B}}).$$

6. Compare as dimensões dos dois lados da igualdade.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a variar no mesmo sentido, em sentidos opostos ou se apresentam relações lineares de redundância.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, caracterizar relações lineares entre as componentes e representar geometricamente a dispersão conjunta (Johnson; Wichern, 2007).

A matriz de correlações resulta da padronização das covariâncias pelos desvios-padrão das variáveis. Seus elementos são adimensionais e permitem comparar a intensidade e o sentido das associações lineares entre variáveis medidas em diferentes unidades.

O objetivo deste capítulo é desenvolver essas estruturas nos níveis populacional e descritivo dos dados observados. As propriedades inferenciais das estatísticas amostrais serão estudadas no Capítulo 10. A distribuição normal multivariada, apresentada no próximo capítulo, utilizará a matriz de covariâncias para construir um modelo probabilístico para a variabilidade conjunta.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\boldsymbol{\mu} \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathcal{R} \in \mathbb{R}^{p \times p}$ representa a matriz de correlações populacional;
- $\boldsymbol{\Sigma}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas entre os vetores aleatórios $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$;
- $\mathbf{D}_{\boldsymbol{\Sigma}} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias populacionais;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa uma matriz de dados observada, com observações nas linhas e variáveis nas colunas;
- $\bar{\mathbf{x}} \in \mathbb{R}^p$ representa o vetor de médias calculado a partir dos dados observados;
- $\mathbf{H}_n = \mathbf{I}_n - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top$ representa a matriz de centralização;
- $\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$ representa a matriz de dados centralizada;
- $\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c$ representa a matriz total de somas de quadrados e produtos cruzados;
- $\mathbf{S} \in \mathbb{R}^{p \times p}$ e $\mathbf{R} \in \mathbb{R}^{p \times p}$ representam, respectivamente, as matrizes de covariâncias e

- de correlações calculadas a partir dos dados observados;
- $\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp})$ representa a matriz diagonal das variâncias observadas;
- $\mathbf{S}_{XY} \in \mathbb{R}^{p \times q}$ representa a matriz de covariâncias cruzadas calculada entre dois blocos de variáveis observadas;
- $\mathbf{X}$, $\mathbf{T}$, $\mathbf{S}$ e $\mathbf{R}$ representam, respectivamente, a média amostral, a matriz de somas de quadrados e produtos cruzados centralizados, a matriz de covariâncias amostral e a matriz de correlações amostral consideradas como objetos aleatórios; suas propriedades serão desenvolvidas no Capítulo 10;
- $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ representam as parcelas intragrupos e entre grupos da matriz total de somas de quadrados e produtos cruzados;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam, respectivamente, as somas de quadrados total, intragrupos e entre grupos obtidas pelos traços de $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$;
- SQ_{total} , SQ_{intra} e SQ_{entre} representam essas somas de quadrados consideradas como objetos aleatórios;
- $QM_{\text{intra}} = SQ_{\text{intra}}/(n - K)$ e $QM_{\text{entre}} = SQ_{\text{entre}}/(K - 1)$ representam os quadrados médios intragrupos e entre grupos no caso escalar;
- Σ^+ representa a pseudoinversa de Moore–Penrose de Σ quando a matriz de covariâncias é singular.

As convenções estabelecidas nos capítulos anteriores para posto, núcleo, espaço coluna, formas quadráticas, matrizes positivas semidefinidas, decomposição espectral, raízes matriciais e pseudoinversa permanecem válidas.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Retomando Definição 1.2, considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com realização $\mathbf{x} \in \mathbb{R}^p$. Quando n realizações são observadas, sua organização em uma matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ segue a representação estabelecida na Definição 1.6.

Suponha inicialmente que $E(|X_j|) < \infty$ para $j = 1, \dots, p$. O **vetor de médias populacional** é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \in \mathbb{R}^p. \quad (8.1)$$

O vetor μ determina a localização média da distribuição no espaço das observações. Subtraindo esse vetor de $\mathbf{X}$, obtém-se o vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu. \quad (8.2)$$

Pela linearidade da esperança,

$$E(\mathbf{X}_c) = E(\mathbf{X}) - \mu = \mathbf{0}.$$

A centralização corresponde a uma translação da distribuição, levando seu vetor de médias à origem. Como estabelecido na Proposição 4.15, a subtração do mesmo vetor de todos os pontos preserva as distâncias entre pares de realizações. Portanto, a centralização altera a localização, mas não a geometria relativa da nuvem de pontos.

A centralização da matriz de dados observada será retomada posteriormente neste capítulo, quando forem construídas a matriz de produtos cruzados e a matriz de covariâncias observada.

8.1.2 Momentos de segunda ordem

O estudo das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante também a existência dos primeiros momentos. Além disso, para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz aplicada a variáveis aleatórias de segundo momento finito fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

Portanto, os produtos cruzados necessários à construção das covariâncias possuem esperança finita.

A matriz de segundos momentos em relação à origem é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top) \in \mathbb{R}^{p \times p}.$$

O produto $\mathbf{X}\mathbf{X}^\top$ é o produto externo definido na Definição 1.14. Seus elementos são

$$[\mathbf{X}\mathbf{X}^\top]_{jk} = X_j X_k,$$

de modo que

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1 X_2) & \cdots & E(X_1 X_p) \\ E(X_2 X_1) & E(X_2^2) & \cdots & E(X_2 X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_p X_1) & E(X_p X_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Seus elementos dependem, portanto, da localização da distribuição e de sua variabilidade conjunta.

Para descrever a dispersão em torno do vetor de médias, utiliza-se o segundo momento central:

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Expandindo o produto e utilizando $E(\mathbf{X}) = \mu$,

$$\begin{aligned} \Sigma &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top \\ &= \mathbf{M}_2 - \mu\mu^\top. \end{aligned} \tag{8.3}$$

A identidade Equação 8.3 é a versão matricial da relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está, portanto, no ponto de referência: $\mathbf{M}_2$ descreve segundos momentos em relação à origem, enquanto Σ descreve a variabilidade em torno da média.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com segundos momentos finitos e médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se X e Y são variáveis aleatórias com segundos momentos finitos e médias $\mu_X = E(X)$ e $\mu_Y = E(Y)$, a **covariância populacional** entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva indica predominância de desvios de mesmo sinal;
- uma covariância negativa indica predominância de desvios de sinais opostos;
- uma covariância nula indica ausência de associação linear registrada pela covariância.

A Figura 8.1 apresenta configurações com covariâncias positiva, aproximadamente nula e negativa.




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

Na primeira configuração, a nuvem de pontos tende a se alongar em uma direção crescente; na terceira, em uma direção decrescente. A configuração central não apresenta orientação linear predominante. O valor da covariância depende também das escalas das variáveis e, por isso,

seu módulo não fornece isoladamente uma medida comparável de intensidade entre diferentes pares de variáveis.

Expandindo o produto dos desvios,

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.\end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.4)$$

A expressão Equação 8.4 relaciona a covariância ao momento conjunto $E(XY)$ e aos primeiros momentos das duas variáveis.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.5)$$

A identidade Equação 8.5 mostra que translações não alteram a covariância. Mudanças de escala multiplicam a covariância pelo produto dos fatores aplicados às duas variáveis. Quando somente um desses fatores é negativo, o sinal da covariância é invertido.

Essa dependência das unidades impede a comparação direta entre covariâncias associadas a pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, por exemplo, sua covariância com outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.6)$$

O limite Equação 8.6 será utilizado posteriormente para mostrar que a correlação pertence ao intervalo $[-1, 1]$.

Covariância nula e independência

Covariância nula não implica independência em uma distribuição geral. A covariância registra associação linear de segunda ordem, e relações não lineares podem produzir covariância igual a zero.

Exemplo 8.1 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X , possui média zero e segundo momento finito.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Como ε é independente de X ,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Para calcular a covariância entre X e Y , utiliza-se

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Como $Y = X^2 + \varepsilon$,

$$\begin{aligned} E(XY) &= E[X(X^2 + \varepsilon)] \\ &= E(X^3) + E(X\varepsilon) \\ &= 0. \end{aligned}$$

Além disso,

$$E(X)E(Y) = 0,$$

pois $E(X) = 0$. Portanto,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0.$$

Apesar da covariância nula, X e Y não são independentes. Para verificar isso, considere a esperança condicional de Y dado $X = x$. Como

$$\begin{aligned} E(Y \mid X = x) &= E(X^2 + \varepsilon \mid X = x) \\ &= x^2 + E(\varepsilon \mid X = x). \end{aligned}$$

Como ε é independente de X ,

$$E(\varepsilon \mid X = x) = E(\varepsilon) = 0.$$

Portanto,

$$E(Y \mid X = x) = x^2.$$

Assim, a média condicional de Y depende do valor de X . Se X e Y fossem independentes, a distribuição condicional de Y dado $X = x$ seria a mesma distribuição marginal de Y e, conseqüentemente,

$$E(Y \mid X = x) = E(Y),$$

não dependendo de x . Logo, X e Y são dependentes, apesar de apresentarem covariância nula.

A Figura 8.2 ilustra essa relação.

A configuração parabólica evidencia uma dependência que não produz orientação linear global. O exemplo delimita a informação fornecida pela covariância e mostra por que o valor zero não deve ser interpretado, sem hipóteses adicionais, como independência.

As variâncias das componentes e as covariâncias entre todos os pares de componentes podem ser reunidas em uma única matriz.




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

Definição 8.2 (Matriz de covariâncias populacional). Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com vetor de médias μ e segundos momentos finitos. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top] \in \mathbb{R}^{p \times p}. \quad (8.7)$$

O elemento situado na linha j e na coluna k de Σ é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.8)$$

Os elementos da diagonal principal são as variâncias,

$$\sigma_{jj} = \text{Var}(X_j),$$

e os elementos fora da diagonal são as covariâncias entre componentes distintos.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

tem-se

$$\sigma_{jk} = \sigma_{kj},$$

e Σ é simétrica. Para p componentes, existem p variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas, totalizando

$$\frac{p(p+1)}{2}$$

elementos distintos.

As unidades dos elementos dependem das variáveis envolvidas. Se X_j é medida em uma unidade u_j , então

$$\sigma_{jj}$$

é expressa em u_j^2 . Para $j \neq k$,

$$\sigma_{jk}$$

é expressa em $u_j u_k$. Essa dependência das unidades motiva a construção posterior da matriz de correlações.

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ possui a forma

$$Y = \mathbf{a}^\top \mathbf{X}, \quad \mathbf{a} \in \mathbb{R}^p.$$

O vetor $\mathbf{a}$ contém os coeficientes da combinação e define uma direção no espaço das variáveis. A combinação linear, já utilizada no Módulo 1, adquire aqui uma interpretação probabilística: sua média e sua variância são determinadas por μ e Σ .

Proposição 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \tag{8.9}$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}, \tag{8.10}$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \tag{8.11}$$

i Demonstração

Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}.$$

Além disso,

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu} = \mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}).$$

Consequentemente,

$$\begin{aligned}\text{Var}(\mathbf{a}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}] \\ &= \mathbf{a}^\top \Sigma \mathbf{a}.\end{aligned}$$

De modo análogo,

$$\begin{aligned}\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{b}] \\ &= \mathbf{a}^\top \Sigma \mathbf{b}.\end{aligned}$$

A expressão Equação 8.10 mostra que a matriz de covariâncias determina a variabilidade de todas as combinações lineares das componentes. A quantidade

$$\mathbf{a}^\top \Sigma \mathbf{a}$$

é uma forma quadrática no sentido de Definição 2.23. Quando $\|\mathbf{a}\| = 1$, ela representa a variância da projeção de $\mathbf{X}$ sobre a direção unitária $\mathbf{a}$.

Essa relação constitui a ligação entre a matriz de covariâncias e a geometria desenvolvida no Módulo 1: diferentes direções podem apresentar diferentes níveis de dispersão.

Exemplo 8.2 (Matriz de covariâncias com três variáveis). Considere

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

As variâncias das três componentes são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9, \quad \text{Var}(X_3) = 1,$$

e as covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1,5,$$

$$\text{Cov}(X_1, X_3) = -0,8,$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere a combinação linear

$$Y = X_1 + 0,5X_2 - X_3,$$

com vetor de coeficientes

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação 8.10,

$$\begin{aligned} \text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\ &= \begin{bmatrix} 1 & 0,5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0,5 \\ -1 \end{bmatrix} \\ &= 10,35. \end{aligned}$$

A variância da combinação depende das variâncias individuais, das covariâncias e dos coeficientes utilizados. A covariância negativa entre X_1 e X_3 , por exemplo, contribui positivamente para $\text{Var}(Y)$ porque os coeficientes dessas duas componentes possuem sinais opostos.

8.2.3 Propriedades estruturais e singularidade

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. A classificação de positividade de matrizes foi estabelecida na Definição 2.24; aqui ela adquire uma interpretação probabilística direta, pois a forma quadrática associada a Σ representa uma variância (Eaton, 2007).


Proposição 8.2 (Caracterização estrutural das matrizes de covariâncias). *Uma matriz $\mathbf{C} \in \mathbb{R}^{p \times p}$ é matriz de covariâncias de algum vetor aleatório com segundos momentos finitos se, e somente se,*

$$\mathbf{C} = \mathbf{C}^\top$$

e

$$\mathbf{C} \succeq \mathbf{0}.$$

Consequentemente, toda matriz de covariâncias possui elementos diagonais não negativos, autovalores não negativos e submatrizes principais positivas semidefinidas.



i Demonstração

Se

$$\mathbf{C} = \text{Cov}(\mathbf{X}),$$

a simetria decorre de

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j).$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{C} \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Logo, $\mathbf{C}$ é positiva semidefinida.

Reciprocamente, suponha que $\mathbf{C}$ seja real, simétrica e positiva semidefinida. Pelo Teorema 5.4 e pela raiz quadrada principal definida na Definição 5.9, existe uma matriz simétrica positiva semidefinida $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^\top,$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}, \quad j = 1, \dots, p.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{I}_p.$$

Defina

$$\mathbf{X} = \mathbf{C}^{1/2} \mathbf{U}.$$

Como

Essa construção estabelece apenas a existência de um vetor aleatório com matriz de covariâncias $\mathbf{C}$ e não exige uma família de distribuições específica.

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

também deve ser positiva semidefinida. Logo,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

o que equivale a

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

Esse resultado recupera, no nível matricial, o limite apresentado na Equação 8.6.

A simetria, isoladamente, não é suficiente para caracterizar uma matriz de covariâncias.

Exemplo 8.3 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica. Entretanto, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2. \end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de uma combinação linear, o que é impossível. A matriz é, portanto, simétrica, mas não positiva semidefinida.

Quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$, a matriz Σ é positiva definida. Pela Equação 8.10, isso significa que toda combinação linear não trivial das componentes possui variância positiva.

A situação muda quando Σ é singular. Nesse caso, aparecerá a expressão **quase certamente**. Seja U uma variável aleatória definida em um espaço de probabilidade $(\Omega, \mathcal{F}, P)$ e seja $c \in \mathbb{R}$. Escrever

$$U = c \quad \text{quase certamente}$$

significa que

$$P(\{\omega \in \Omega : U(\omega) = c\}) = P(U = c) = 1.$$

Equivalentemente, a igualdade pode falhar apenas em um conjunto de resultados de probabilidade zero.

Proposição 8.3 (Caracterização da singularidade da matriz de covariâncias). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

i Demonstração

Como Σ é simétrica e positiva semidefinida, o Teorema 5.4 garante uma decomposição com autovalores não negativos. A matriz é singular se, e somente se, pelo menos um desses autovalores é zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ no núcleo de Σ e, portanto,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ .

Pela Equação 8.10,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}),$$

o que estabelece a equivalência entre as duas condições seguintes.

Uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser zero. Portanto,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

A última condição da Proposição 8.3 também pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade de Σ corresponde à existência de uma relação afim exata e não trivial entre as componentes do vetor aleatório.

Em termos geométricos, os vetores pertencentes a

$$\mathcal{N}(\Sigma)$$

determinam direções de variância nula. Como Σ é simétrica, a relação entre núcleo e espaço coluna desenvolvida no Módulo 1 permite escrever

$$\mathcal{N}(\Sigma)^\perp = \mathcal{C}(\Sigma).$$

Consequentemente,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma) \quad \text{quase certamente.}$$

Se

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade do vetor centralizado está restrita a um subespaço de dimensão r . O vetor original está, portanto, restrito quase certamente ao subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

A matriz de covariâncias também pode ser utilizada para descrever conjuntamente dois vetores aleatórios distintos. Essa extensão produz matrizes retangulares de covariâncias cruzadas e permite representar as relações lineares entre dois blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam segundos momentos finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}, \quad (8.12)$$

em que $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ possuem segundos momentos finitos e médias μ_X e μ_Y , respectivamente.

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para $j = 1, \dots, p$ e $k = 1, \dots, q$. Portanto,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A orientação da matriz depende da ordem dos vetores. Invertendo essa ordem,

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (8.13)$$

Assim,

$$\Sigma_{XY} \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} \in \mathbb{R}^{q \times p}.$$

Mesmo quando $p = q$, não se tem em geral

$$\Sigma_{XY} = \Sigma_{YX},$$

pois uma matriz de covariâncias cruzadas não precisa ser simétrica.

Proposição 8.4 (Covariância entre combinações de dois vetores). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Para quaisquer vetores fixos*

$$\mathbf{a} \in \mathbb{R}^p \quad e \quad \mathbf{b} \in \mathbb{R}^q,$$

tem-se

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \quad (8.14)$$

i Demonstração

As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\ &= E \left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b} \right] \\ &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}. \end{aligned}$$

Em particular,

$$\Sigma_{XY} = \mathbf{0}$$

se, e somente se,

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = 0$$

para todos os vetores $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$. Nesse caso, nenhuma combinação linear do primeiro bloco possui covariância não nula com uma combinação linear do segundo.

A condição

$$\Sigma_{XY} = \mathbf{0}$$

não implica, em uma distribuição geral, independência entre os vetores. Essa relação será retomada no Capítulo 9 sob a distribuição normal multivariada.

Os dois vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{V} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix},$$

e sua matriz de covariâncias pode ser representada por blocos, conforme a estrutura de matrizes particionadas definida na Definição 2.25:

$$\Sigma_V = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.15)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor, enquanto os blocos fora da diagonal descrevem as covariâncias entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa condição restringe conjuntamente seus blocos. Em particular, Σ_{XY} não pode ser especificada arbitrariamente depois de fixadas Σ_{XX} e Σ_{YY} .

8.3.1.1 Complemento de Schur e dispersão residual

O complemento de Schur já foi definido na Definição 2.26. Aplicado à matriz de covariâncias particionada, ele recebe uma interpretação estatística de segunda ordem.

Suponha que

$$\Sigma_{YY} \succ \mathbf{0}.$$

O complemento de Schur de Σ_{YY} em Σ_V é

$$\Sigma_{XX \cdot Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}. \quad (8.16)$$

Pelo resultado de positividade do complemento de Schur no Teorema 2.9,

$$\Sigma_{XX \cdot Y} \succeq \mathbf{0}.$$

A expressão também pode ser interpretada diretamente como uma covariância residual.

Proposição 8.5 (Complemento de Schur e covariância residual). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^q$$

vetores aleatórios com segundos momentos finitos, vetores de médias

$$\mu_X = E(\mathbf{X}) \quad e \quad \mu_Y = E(\mathbf{Y}),$$

e matriz de covariâncias conjunta

$$\text{Cov} \left(\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \right) = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}.$$

Se

$$\Sigma_{YY} \succ \mathbf{0},$$

o complemento de Schur

$$\Sigma_{XX.Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$$

é a menor matriz de covariâncias residuais, segundo a ordem de Loewner, entre as matrizes obtidas ao aproximar linearmente $\mathbf{X}_c$ por $\mathbf{L}\mathbf{Y}_c$, com

$$\mathbf{L} \in \mathbb{R}^{p \times q}.$$

Para

$$\mathbf{L}^* = \Sigma_{XY} \Sigma_{YY}^{-1},$$

tem-se

$$\text{Cov}(\mathbf{R}_{\mathbf{L}^*}) = \Sigma_{XX.Y},$$

e, para qualquer

$$\mathbf{L} \in \mathbb{R}^{p \times q},$$

tem-se

$$\text{Cov}(\mathbf{R}_L) - \Sigma_{XX \cdot Y} \succeq \mathbf{0},$$

em que

$$\mathbf{R}_L = \mathbf{X}_c - \mathbf{L}\mathbf{Y}_c,$$

$$\mathbf{X}_c = \mathbf{X} - \mu_X \quad e \quad \mathbf{Y}_c = \mathbf{Y} - \mu_Y.$$

i Demonstração

Para uma matriz arbitrária $\mathbf{L}$,

$$\text{Cov}(\mathbf{R}_L) = \Sigma_{XX} - \mathbf{L}\Sigma_{YX} - \Sigma_{XY}\mathbf{L}^\top + \mathbf{L}\Sigma_{YY}\mathbf{L}^\top.$$

Substituindo

$$\mathbf{L}^* = \Sigma_{XY}\Sigma_{YY}^{-1},$$

a expressão pode ser reorganizada como

$$\begin{aligned} \text{Cov}(\mathbf{R}_L) &= \Sigma_{XX \cdot Y} \\ &\quad + (\mathbf{L} - \mathbf{L}^*)\Sigma_{YY}(\mathbf{L} - \mathbf{L}^*)^\top. \end{aligned}$$

Como Σ_{YY} é positiva definida,

$$(\mathbf{L} - \mathbf{L}^*)\Sigma_{YY}(\mathbf{L} - \mathbf{L}^*)^\top \succeq \mathbf{0}.$$

A diferença entre a covariância residual correspondente a qualquer $\mathbf{L}$ e aquela obtida com $\mathbf{L}^*$ é, portanto, positiva semidefinida.

Essa interpretação depende apenas dos segundos momentos e não exige normalidade. Sob normalidade conjunta, o mesmo complemento de Schur aparecerá no Capítulo 9 como matriz de covariâncias da distribuição condicional de um bloco dado o outro.

Exemplo 8.4 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix}.$$

Para as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2,$$

os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação [8.14](#),

$$\begin{aligned} \text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\ &= \begin{bmatrix} 1 & -2 \end{bmatrix} \begin{bmatrix} 2 & -1 & 0,5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\ &= -7. \end{aligned}$$

A covariância entre U e V resulta conjuntamente das covariâncias entre todas as componentes que participam das duas combinações lineares.

8.3.2 Transformações afins da média e da covariância

As transformações afins foram definidas na Definição 4.7. No contexto probabilístico, interessa determinar como elas modificam a média e a matriz de covariâncias.

Considere

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r.$$

Proposição 8.6 (Média e covariância sob transformação afim). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ_X e matriz de covariâncias Σ_{XX} . Para*

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{c}, \quad \mathbf{A} \in \mathbb{R}^{r \times p}, \quad \mathbf{c} \in \mathbb{R}^r,$$

tem-se

$$E(\mathbf{U}) = \mathbf{A}\mu_X + \mathbf{c} \tag{8.17}$$

e

$$\text{Cov}(\mathbf{U}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \tag{8.18}$$

i Demonstração

Pela linearidade da esperança,

$$E(\mathbf{A}\mathbf{X} + \mathbf{c}) = \mathbf{A}\mu_X + \mathbf{c}.$$

O vetor transformado centralizado é

$$\begin{aligned}\mathbf{U} - E(\mathbf{U}) &= \mathbf{A}\mathbf{X} + \mathbf{c} - \mathbf{A}\mu_X - \mathbf{c} \\ &= \mathbf{A}(\mathbf{X} - \mu_X).\end{aligned}$$

Portanto,

$$\begin{aligned}\text{Cov}(\mathbf{U}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.\end{aligned}$$

A ausência do vetor $\mathbf{c}$ na Equação 8.18 confirma que translações alteram a localização, mas não a matriz de covariâncias.

Quando

$$r = 1 \quad \text{e} \quad \mathbf{A} = \mathbf{a}^\top,$$

a expressão reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a},$$

recuperando Equação 8.10.

Se $\mathbf{A}$ é diagonal,

$$\mathbf{A} = \text{diag}(a_1, \dots, a_p),$$

então

$$\text{Cov}(a_j X_j, a_k X_k) = a_j a_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(a_j X_j) = a_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal no sentido de Definição 2.18,

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Como $\mathbf{Q}^\top = \mathbf{Q}^{-1}$, essa transformação produz uma matriz semelhante a Σ_{XX} e preserva seus autovalores. A interpretação estatística dessa propriedade será retomada na geometria da covariância.

Exemplo 8.5 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e

$$\mathbf{U} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As componentes transformadas são

$$U_1 = X_1 + X_2$$

e

$$U_2 = X_1 - X_2.$$

Pela expressão Equação 8.18,

$$\begin{aligned} \text{Cov}(\mathbf{U}) &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}. \end{aligned}$$

Logo,

$$\text{Var}(U_1) = 17, \quad \text{Var}(U_2) = 9$$

e

$$\text{Cov}(U_1, U_2) = -5.$$

A transformação modifica simultaneamente as variâncias das componentes e a covariância entre elas.

As covariâncias cruzadas também se transformam de maneira compatível.

Proposição 8.7 (Covariância cruzada sob transformações afins). *Sejam $\mathbf{X} \in \mathbb{R}^p$ e $\mathbf{Y} \in \mathbb{R}^q$ vetores aleatórios com matriz de covariâncias cruzadas Σ_{XY} . Considere*

$$\mathbf{U} = \mathbf{A}_X \mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{A}_Y \mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{A}_X \in \mathbb{R}^{r \times p}, \quad \mathbf{A}_Y \in \mathbb{R}^{s \times q}, \quad \mathbf{c} \in \mathbb{R}^r, \quad \mathbf{d} \in \mathbb{R}^s.$$

Então,

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \quad (8.19)$$

i Demonstração

Após a centralização,

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}_X (\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{A}_Y (\mathbf{Y} - \mu_Y).$$

Logo,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E \left[\mathbf{A}_X (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{A}_Y^\top \right] \\ &= \mathbf{A}_X \Sigma_{XY} \mathbf{A}_Y^\top. \end{aligned}$$

As expressões Equação 8.18 e Equação 8.19 mostram que a matriz de covariâncias responde de maneira sistemática às transformações lineares. A padronização das componentes constitui um caso particular dessa estrutura.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar as escalas marginais, suponha que

$$\sigma_{jj} = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias populacionais por

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}). \quad (8.20)$$

Como todas as variâncias são positivas,

$$\mathbf{D}_\Sigma \succ \mathbf{0}$$

e existem as matrizes diagonais

$$\mathbf{D}_\Sigma^{1/2} = \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}})$$

e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Definição 8.4 (Vetor aleatório padronizado). Se $\mathbf{X} \in \mathbb{R}^p$ possui média μ e variâncias marginais positivas, o vetor aleatório marginalmente padronizado correspondente é

$$\mathbf{Z} = \mathbf{D}_{\Sigma}^{-1/2} (\mathbf{X} - \mu), \quad (8.21)$$

em que $\mathbf{D}_{\Sigma} \succ \mathbf{0}$ é a matriz diagonal das variâncias populacionais e

$$\mathbf{D}_{\Sigma}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\sigma_{11}}}, \dots, \frac{1}{\sqrt{\sigma_{pp}}} \right).$$

Sua componente j é

$$Z_j = \frac{X_j - \mu_j}{\sqrt{\sigma_{jj}}}.$$

Assim,

$$E(Z_j) = 0$$

e

$$\text{Var}(Z_j) = 1.$$

Em forma vetorial,

$$E(\mathbf{Z}) = \mathbf{0}.$$

Aplicando Equação 8.18,

$$\text{Cov}(\mathbf{Z}) = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Definição 8.5 (Matriz de correlações populacional). A **matriz de correlações populacional** de $\mathbf{X} \in \mathbb{R}^p$ é

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}, \quad (8.22)$$

em que Σ é a matriz de covariâncias de $\mathbf{X}$ e

$$\mathbf{D}_{\Sigma} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}),$$

com

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

O símbolo $\mathcal{R}$ é reservado à matriz populacional. Posteriormente, $\mathbf{R}$ representará a matriz de correlações amostral, enquanto $\mathbf{R}$ representará seu valor calculado a partir de uma amostra observada.

A matriz $\mathcal{R}$ possui a forma

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sqrt{\sigma_{jj}\sigma_{kk}}}. \quad (8.23)$$

Equivalentemente,

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

A correlação é adimensional porque o numerador e o denominador de Equação 8.23 possuem as mesmas unidades.

A relação entre covariâncias e correlações pode ser invertida:

$$\Sigma = \mathbf{D}_{\Sigma}^{1/2} \mathcal{R} \mathbf{D}_{\Sigma}^{1/2}. \quad (8.24)$$

Portanto, Σ pode ser decomposta em dois elementos:

- $\mathbf{D}_\Sigma$ registra as variâncias e, consequentemente, as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear após a remoção dessas escalas.

A matriz de correlações isoladamente não permite recuperar as variâncias originais.

Exemplo 8.6 (Matriz de correlações obtida por uma transformação de padronização). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com vetor de médias μ e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix}.$$

Os desvios-padrão populacionais são

$$\sqrt{\sigma_{11}} = 4 \quad \text{e} \quad \sqrt{\sigma_{22}} = 5.$$

Portanto,

$$\mathbf{D}_\Sigma = \begin{bmatrix} 16 & 0 \\ 0 & 25 \end{bmatrix}$$

e

$$\mathbf{D}_\Sigma^{-1/2} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix}.$$

Considere a transformação de padronização

$$\mathbf{Z} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu).$$

Ela pode ser escrita como a transformação afim

$$\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{c},$$

com

$$\mathbf{A} = \mathbf{D}_\Sigma^{-1/2}$$

e

$$\mathbf{c} = -\mathbf{D}_{\Sigma}^{-1/2} \mu.$$

Utilizando Proposição 8.6,

$$\text{Cov}(\mathbf{Z}) = \mathbf{A}\Sigma\mathbf{A}^{\top}.$$

Como $\mathbf{A}$ é diagonal e simétrica,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \begin{bmatrix} 16 & 12 \\ 12 & 25 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}. \end{aligned}$$

Essa é precisamente a matriz de correlações populacional,

$$\mathcal{R} = \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.$$

De fato,

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \frac{12}{\sqrt{16 \cdot 25}} = \frac{12}{20} = 0,6.$$

O exemplo mostra duas formas equivalentes de chegar ao mesmo resultado. Pela transformação do vetor,

$$\text{padronizar } \mathbf{X} \implies \text{Cov}(\mathbf{Z}).$$

Equivalentemente, pode-se transformar diretamente a matriz de covariâncias:

$$\Sigma \implies \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Em ambas as perspectivas, as variâncias tornam-se unitárias e a covariância entre as componentes padronizadas passa a coincidir com sua correlação.

8.4.2 Propriedades, escala e independência

Proposição 8.8 (Caracterização das matrizes de correlações). *Uma matriz*

$$\mathbf{C} \in \mathbb{R}^{p \times p}$$

é matriz de correlações de algum vetor aleatório com variâncias marginais positivas se, e somente se,

$$\mathbf{C} = \mathbf{C}^\top,$$

$$\mathbf{C} \succeq \mathbf{0}$$

e

$$c_{jj} = 1, \quad j = 1, \dots, p.$$

Consequentemente, toda matriz de correlações possui:

- 1. elementos no intervalo $[-1, 1]$;*
- 2. autovalores reais e não negativos;*
- 3. traço igual a p .*



i Demonstração

Se $\mathbf{C} = \mathcal{R}$ é uma matriz de correlações, então

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Como Σ é simétrica,

$$\mathcal{R}^{\top} = \mathcal{R}.$$

Além disso, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^{\top} \mathcal{R} \mathbf{a} &= \left(\mathbf{D}_{\Sigma}^{-1/2} \mathbf{a} \right)^{\top} \Sigma \left(\mathbf{D}_{\Sigma}^{-1/2} \mathbf{a} \right) \\ &\geq 0, \end{aligned}$$

de modo que

$$\mathcal{R} \succeq \mathbf{0}.$$

A diagonal é unitária porque

$$\rho_{jj} = \frac{\sigma_{jj}}{\sqrt{\sigma_{jj}\sigma_{jj}}} = 1.$$

Reciprocamente, suponha que $\mathbf{C}$ seja simétrica, positiva semidefinida e possua diagonal unitária. Pela raiz quadrada principal definida na Definição 5.9, existe $\mathbf{C}^{1/2}$ tal que

$$\mathbf{C} = \mathbf{C}^{1/2} \mathbf{C}^{1/2}.$$

Considere um vetor aleatório

$$\mathbf{U} = (U_1, \dots, U_p)^{\top},$$

cujas componentes são independentes e satisfazem

$$P(U_j = 1) = P(U_j = -1) = \frac{1}{2}.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

Se Σ possui variâncias marginais positivas, então $\mathbf{D}_\Sigma^{-1/2}$ é invertível e a padronização preserva a definição positiva. Assim,

$$\mathcal{R} \succ \mathbf{0} \iff \Sigma \succ \mathbf{0}.$$

Os valores extremos da correlação correspondem a relações lineares exatas entre as variáveis padronizadas. Para $j \neq k$,

$$\rho_{jk} = 1 \iff Z_k = Z_j \quad \text{quase certamente,}$$

enquanto

$$\rho_{jk} = -1 \iff Z_k = -Z_j \quad \text{quase certamente.}$$

Portanto, uma correlação de módulo igual a 1 implica uma relação linear exata entre as duas variáveis e, conseqüentemente, a singularidade da matriz de covariâncias do par correspondente.

Além disso, não basta que cada correlação, considerada isoladamente, pertença ao intervalo $[-1, 1]$ para que uma matriz seja uma matriz de correlações válida; a matriz completa também deve ser positiva semidefinida.

Exemplo 8.7 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0,9 & 0,9 \\ 0,9 & 1 & -0,9 \\ 0,9 & -0,9 & 1 \end{bmatrix}.$$

Todos os elementos pertencem ao intervalo $[-1, 1]$, a matriz é simétrica e sua diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2,888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Logo, $\mathbf{A}$ não é uma matriz de correlações.

O exemplo mostra que as correlações entre pares devem ser compatíveis com uma única estrutura conjunta positiva semidefinida.

Duas componentes X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como suas variâncias são positivas,

$$\rho_{jk} = 0 \iff \sigma_{jk} = 0.$$

Essa condição não implica independência em uma distribuição geral, conforme ilustrado no Exemplo 8.1.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

e, portanto,

$$\text{Cov}(X_j, X_k) = 0.$$

Assim,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca depende de hipóteses adicionais.

Uma matriz de correlações diagonal necessariamente é

$$\mathcal{R} = \mathbf{I}_p.$$

Nesse caso, todas as componentes são duas a duas não correlacionadas. Essa propriedade não garante, por si só, independência conjunta. A relação especial entre ausência de correlação e independência sob normalidade conjunta será estabelecida no Capítulo 9.

Considere agora uma mudança de localização e escala aplicada separadamente às componentes:

$$Y_j = c_j X_j + d_j, \quad c_j \neq 0.$$

Tem-se

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk},$$

enquanto

$$\text{Var}(Y_j) = c_j^2 \sigma_{jj}.$$

Consequentemente,

$$\text{Corr}(Y_j, Y_k) = \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \quad (8.25)$$

Se $c_j > 0$ e $c_k > 0$,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Portanto, translações e mudanças positivas de unidade não alteram a correlação. A multiplicação de uma variável por uma constante negativa inverte o sinal de suas correlações, sem alterar seus módulos.

Exemplo 8.8 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.2:

$$\Sigma = \begin{bmatrix} 4 & 1,5 & -0,8 \\ 1,5 & 9 & 0 \\ -0,8 & 0 & 1 \end{bmatrix}.$$

A matriz das variâncias marginais é

$$\mathbf{D}_{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

de modo que

$$\mathbf{D}_{\Sigma}^{-1/2} = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.22,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2} \\ &= \begin{bmatrix} 1 & 0,25 & -0,4 \\ 0,25 & 1 & 0 \\ -0,4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1,5}{\sqrt{4 \cdot 9}} = 0,25,$$

enquanto

$$\rho_{13} = \frac{-0,8}{\sqrt{4 \cdot 1}} = -0,4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

tem-se

$$|\rho_{13}| > |\rho_{12}|.$$

A covariância entre X_1 e X_2 possui maior módulo nas unidades originais, mas a associação linear padronizada entre X_1 e X_3 é mais intensa. A comparação evidencia a diferença entre a informação fornecida por covariâncias e por correlações.

A matriz de covariâncias preserva as variâncias e as unidades originais das componentes. A matriz de correlações descreve a mesma estrutura de segunda ordem após a padronização marginal, atribuindo variância unitária a todas as componentes. Essa mudança de escala pode alterar a geometria da dispersão e será considerada na interpretação espectral das duas matrizes.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais e elipsoide de covariância

A expressão Equação 8.10 mostra que a matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa quantidade representa a dispersão ao longo da direção unitária $\mathbf{a}$. A interpretação espectral das formas quadráticas foi desenvolvida no Capítulo 5. Aplicando o Teorema 5.4 à matriz simétrica positiva semidefinida Σ ,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top, \quad (8.26)$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j \geq 0.$$

A transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.27)$$

expressa o vetor centralizado nas coordenadas da base de autovetores. Pela regra de transformação da covariância,

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \Lambda. \quad (8.28)$$

Portanto,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Cov}(Y_j, Y_k) = 0, \quad j \neq k.$$

Os autovetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. O autovalor λ_j quantifica a variância ao longo do eixo $\mathbf{q}_j$.

Se

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0,$$

o resultado sobre os extremos do quociente de Rayleigh no Teorema 5.5 fornece

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.29)$$

Os valores extremos são alcançados nos autovetores correspondentes. Assim, a decomposição espectral identifica direções ortogonais nas quais as covariâncias desaparecem e as variâncias são dadas diretamente pelos autovalores.

Neste capítulo, essa decomposição é utilizada somente para descrever a geometria da dispersão. A seleção de eixos espectrais para construir uma representação de dimensão reduzida pertence à formulação da Análise de Componentes Principais.

Exemplo 8.9 (Obtenção dos eixos de maior e menor variabilidade). Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Queremos determinar a direção unitária

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad \mathbf{a}^\top \mathbf{a} = 1,$$

na qual a combinação linear

$$Y = \mathbf{a}^\top \mathbf{X}$$

apresenta a maior variância possível.

Pela expressão Equação 8.10,

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto, o problema é

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

Esse é precisamente o tipo de problema de otimização com restrição estudado no Módulo 1. Como maximizar uma função equivale a minimizar seu negativo, a condição necessária de Lagrange estabelecida no Teorema 7.6 aplica-se também a este problema. Considere

$$\mathcal{L}(\mathbf{a}, \eta) = \mathbf{a}^\top \Sigma \mathbf{a} - \eta (\mathbf{a}^\top \mathbf{a} - 1).$$

Como Σ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \Sigma \mathbf{a}) = 2\Sigma \mathbf{a}$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é, portanto,

$$2\Sigma \mathbf{a} - 2\eta \mathbf{a} = \mathbf{0},$$

ou

$$\Sigma \mathbf{a} = \eta \mathbf{a}. \quad (8.30)$$

Assim, as direções estacionárias do problema são autovetores de Σ , e os multiplicadores de Lagrange correspondentes são seus autovalores.

Para determiná-los,

$$\det(\Sigma - \eta \mathbf{I}_2) = 0.$$

Logo,

$$\begin{aligned} \det \begin{bmatrix} 4-\eta & 2 \\ 2 & 4-\eta \end{bmatrix} &= (4-\eta)^2 - 4 \\ &= \eta^2 - 8\eta + 12 \\ &= (\eta - 6)(\eta - 2). \end{aligned}$$

Os autovalores são, portanto,

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2.$$

Para $\lambda_1 = 6$,

$$(\Sigma - 6\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = a_2.$$

Impondo a restrição de norma unitária,

$$a_1^2 + a_2^2 = 1,$$

podemos escolher

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 2$,

$$(\Sigma - 2\mathbf{I}_2) \mathbf{a} = \mathbf{0}$$

produz

$$a_1 = -a_2,$$

e podemos escolher

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo resultado dos extremos do quociente de Rayleigh no Teorema [5.5](#),

$$\max_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_1 = 6,$$

alcançado na direção $\mathbf{q}_1$, enquanto

$$\min_{\|\mathbf{a}\|=1} \mathbf{a}^\top \Sigma \mathbf{a} = \lambda_2 = 2,$$

alcançado na direção $\mathbf{q}_2$.

Consequentemente,

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 6$$

e

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 2.$$

Reunindo os autovetores em

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

a transformação

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu)$$

produz

$$\text{Cov}(\mathbf{Y}) = \mathbf{Q}^\top \Sigma \mathbf{Q} = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

O cálculo mostra concretamente a conexão entre **variância de uma combinação linear, otimização restrita e decomposição espectral**: os autovetores da matriz de covariâncias surgem como as direções estacionárias da variância sob a restrição de norma unitária, e os autovalores fornecem as variâncias nessas direções.

Neste ponto, o objetivo é somente compreender a geometria da matriz de covariâncias. A utilização dessas direções para construir uma técnica de redução de dimensionalidade será desenvolvida posteriormente na Análise de Componentes Principais.

Quando Σ é diagonal, os eixos espectrais coincidem com os eixos coordenados. No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \tag{8.31}$$

tem-se, para qualquer vetor unitário $\mathbf{a}$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2.$$

A condição Equação 8.31 descreve uma estrutura de segunda ordem isotrópica: a variância é a mesma em todas as direções. Essa condição, isoladamente, não implica que a distribuição de $\mathbf{X}$ seja esfericamente simétrica.

Suponha agora que

$$\Sigma \succ \mathbf{0}.$$

Para $c > 0$, considere

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.32)$$

A interpretação das superfícies de nível de formas quadráticas positivas definidas foi estabelecida no Capítulo 5. Neste caso, utilizando Equação 8.26 e definindo

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

a condição que define $\mathcal{E}_c$ torna-se

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.33)$$

Portanto:

- o centro é μ ;
- os eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo associado a $\mathbf{q}_j$ possui comprimento $c\sqrt{\lambda_j}$.

Assim, autovalores maiores correspondem a maior extensão da dispersão na direção associada.

A Figura 8.3 mostra essa geometria no caso bidimensional.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias determina, assim, uma geometria de segunda ordem para a dispersão conjunta.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido somente por μ e Σ . Sem uma hipótese adicional sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma probabilidade específica nem interpretá-lo como região de confiança. A interpretação probabilística dessas superfícies será desenvolvida no Capítulo 9 para a distribuição normal multivariada.

Quando Σ é singular, a variabilidade está restrita ao subespaço




Figura 8.3: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

$$\mathcal{C}(\Sigma).$$

A raiz quadrada principal definida na Definição 5.9 permite representar o elipsoide degenerado por

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}, \quad (8.34)$$

em que

$$r = \text{posto}(\Sigma) < p.$$

Esse conjunto está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

e possui r semieixos não nulos, com comprimentos $c\sqrt{\lambda_j}$ para os autovalores positivos. A pseudoinversa será utilizada mais adiante para expressar a mesma geometria no contexto da distância de Mahalanobis.

8.5.2 Variância total, variância generalizada e volume

Uma matriz de covariâncias contém toda a estrutura de segunda ordem do vetor aleatório. Algumas funções escalares de Σ resumem aspectos específicos dessa dispersão, mas nenhuma delas substitui a matriz completa.

Definição 8.6 (Variância total). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância total** é

$$V_T(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.35)$$

Pela definição de traço na Definição 2.9,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.36)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.37)$$

A variância total também possui uma interpretação em termos de esperança matemática. Mais geralmente, seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica e seja $\mathbf{a} \in \mathbb{R}^p$ um vetor fixo. Então,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}). \quad (8.38)$$

De fato,

$$\mathbf{X} - \mathbf{a} = (\mathbf{X} - \mu) + (\mu - \mathbf{a}),$$

e, ao expandir a forma quadrática, os termos cruzados possuem esperança nula porque

$$E(\mathbf{X} - \mu) = \mathbf{0}.$$

Além disso,

$$E[(\mathbf{X} - \mu)^\top \mathbf{A} (\mathbf{X} - \mu)] = \text{tr}(\mathbf{A}\Sigma).$$

Tomando

$$\mathbf{A} = \mathbf{I}_p \quad \text{e} \quad \mathbf{a} = \mu,$$

obtém-se

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma). \quad (8.39)$$

Portanto, a variância total é o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu vetor de médias.

Mais geralmente, tomando $\mathbf{A} = \mathbf{I}_p$,

$$E[\|\mathbf{X} - \mathbf{a}\|^2] = \text{tr}(\Sigma) + \|\mu - \mathbf{a}\|^2. \quad (8.40)$$

Essa expressão mostra que μ minimiza o afastamento quadrático médio:

$$E[\|\mathbf{X} - \mathbf{a}\|^2] \geq E[\|\mathbf{X} - \mu\|^2].$$

Como

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j,$$

segue também que

$$E \left[\|\mathbf{X} - \mu\|^2 \right] = \sum_{j=1}^p \lambda_j.$$

Assim, a mesma quantidade pode ser interpretada como soma das variâncias marginais, soma das variâncias nos eixos espectrais ou afastamento euclidiano quadrático médio em relação ao centro.

Definição 8.7 (Variância média). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , com autovalores $\lambda_1, \dots, \lambda_p$, sua **variância média** é

$$\text{VM}(\mathbf{X}) = \frac{1}{p} \text{tr}(\Sigma) = \frac{1}{p} \sum_{j=1}^p \lambda_j.$$

A variância total e a variância média dependem das escalas das componentes. Quando as variáveis possuem unidades distintas, sua interpretação requer cautela.

Outra medida utiliza o determinante da matriz de covariâncias.

Definição 8.8 (Variância generalizada). Se $\mathbf{X} \in \mathbb{R}^p$ possui matriz de covariâncias Σ , sua **variância generalizada** é

$$V_G(\mathbf{X}) = \det(\Sigma). \quad (8.41)$$

Pelas propriedades do determinante e pela decomposição espectral,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.42)$$

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se pelo menos um autovalor é zero,

$$\det(\Sigma) = 0,$$

mesmo que exista variabilidade nas demais direções. Nesse caso, o valor zero indica que a dispersão ocupa um subespaço de dimensão inferior a p ; não indica ausência de variabilidade.

A variância generalizada não deve ser confundida com o volume do elipsoide de covariância. A relação entre as duas quantidades envolve a raiz quadrada do determinante (Johnson; Wichern, 2007).

Proposição 8.9 (Volume do elipsoide de covariância). *Se*

$$p \geq 1, \quad \mu \in \mathbb{R}^p, \quad \Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}$$

e

$$c > 0,$$

considere o elipsoide

$$\mathcal{E}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2 \right\}.$$

Seu volume p -dimensional é

$$\text{Vol}_p(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.43)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

i Demonstração

O elipsoide é a imagem da bola

$$\mathcal{B}_c = \{\mathbf{u} \in \mathbb{R}^p : \|\mathbf{u}\| \leq c\}$$

pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2}\mathbf{u}.$$

A translação não altera o volume. Pelo Proposição 4.9, a transformação linear multiplica volumes por

$$|\det(\Sigma^{1/2})| = \det(\Sigma)^{1/2}.$$

Como

$$\text{Vol}_p(\mathcal{B}_c) = \kappa_p c^p,$$

obtem-se Equação 8.43.

Portanto,

$$\det(\Sigma)^{1/2}$$

é o fator associado à escala de volume da dispersão, enquanto

$$\det(\Sigma)$$

é a variância generalizada.

Exemplo 8.10 (Variância total e variância generalizada). Considere

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = \text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16$$

e

$$\det(\Sigma_2) = 7.$$

A primeira configuração distribui a variabilidade igualmente entre os dois eixos. A segunda concentra maior variabilidade em uma direção e menor variabilidade na outra. A igualdade das variâncias totais não implica, portanto, igualdade da geometria da dispersão.

As unidades também diferem entre essas medidas. Se as componentes possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 \cdots u_p^2,$$

enquanto

$$\det(\Sigma)^{1/2}$$

possui unidade

$$u_1 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

Considere agora uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \mathbf{A} \in \mathbb{R}^{p \times p}.$$

Pela expressão Equação [8.18](#),

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top.$$

Consequentemente,

$$\det(\Sigma_{YY}) = \det(\mathbf{A})^2 \det(\Sigma_{XX}). \quad (8.44)$$

Para a escala de volume,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.45)$$

Essa expressão é compatível com o fator de alteração de volume desenvolvido na Proposição 4.9.

Quando $\mathbf{A}$ é ortogonal, $|\det(\mathbf{A})| = 1$ e a transformação preserva os autovalores de Σ . Consequentemente, preserva a variância total, a variância generalizada e os comprimentos dos semieixos do elipsoide, alterando somente sua orientação no sistema de coordenadas.

A forma quadrática que define o elipsoide fornece também uma medida de afastamento adaptada à estrutura de covariâncias. Essa medida é a distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana utiliza a mesma geometria em todas as direções. Em dados multivariados, entretanto, um deslocamento pode representar um afastamento pequeno em uma direção de grande variabilidade e um afastamento expressivo em outra direção de pequena variabilidade.

A distância de Mahalanobis incorpora essa estrutura por meio da matriz de covariâncias. No caso univariado, ela reduz o afastamento $|x - \mu|$ à sua escala natural,

$$\frac{|x - \mu|}{\sigma}.$$

Definição 8.9 (Distância de Mahalanobis). Se $\Sigma \in \mathbb{R}^{p \times p}$ é positiva definida, a **distância de Mahalanobis** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação a Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.46)$$

Em particular, a distância de $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.47)$$

8.6.1 Interpretação geométrica e espectral

O quadrado da distância de Mahalanobis de $\mathbf{x}$ ao vetor de médias é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.48)$$

Como $\Sigma^{-1} \succ \mathbf{0}$, ela define o produto interno induzido apresentado na Definição 3.16 e a norma correspondente de Definição 3.17. Assim, Equação 8.46 é uma distância métrica, sem necessidade de repetir aqui a demonstração das propriedades métricas desenvolvidas no Módulo 1.

Quando

$$\Sigma = \mathbf{I}_p,$$

a distância de Mahalanobis coincide com a distância euclidiana. Quando $p = 1$,

$$d_M(x, \mu) = \frac{|x - \mu|}{\sigma}.$$

A medida é adimensional, pois a inversa da matriz de covariâncias compensa as unidades presentes no vetor de diferenças.

A interpretação espectral decorre diretamente de Equação 8.26. Se

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu),$$

então

$$d_M^2(\mathbf{x}, \mu) = \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \quad (8.49)$$

Essa expressão mostra como a distância de Mahalanobis incorpora a geometria da dispersão. Cada componente u_j representa o deslocamento de $\mathbf{x} - \mu$ na direção do autovetor correspondente, enquanto λ_j é a variância nessa direção.

Cada deslocamento é, portanto, ponderado pelo inverso da variância na direção correspondente. Um mesmo deslocamento geométrico recebe menor peso em uma direção de grande variabilidade e maior peso em uma direção de pequena variabilidade.

Exemplo 8.11 (Afastamentos em direções com variâncias distintas). Considere dois eixos espectrais com

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Um afastamento de magnitude 2 ao longo do primeiro eixo produz

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

O mesmo afastamento ao longo do segundo produz

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro, mas o segundo apresenta maior distância de Mahalanobis porque se encontra em uma direção com menor dispersão populacional.

As superfícies de igual distância,

$$d_M(\mathbf{x}, \mu) = c,$$

são exatamente as fronteiras dos elipsoides definidos na Equação 8.32. Isso reforça a interpretação geométrica da distância de Mahalanobis: pontos pertencentes à mesma superfície elipsoidal apresentam o mesmo afastamento em relação ao centro quando a estrutura de covariâncias é considerada.

A Figura 8.4 compara dois deslocamentos com a mesma distância euclidiana ao centro, mas orientados segundo eixos de dispersão distintos.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A medida compara o deslocamento com a quantidade de variabilidade disponível na direção em que ele ocorre.




Figura 8.4: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

8.6.2 Branqueamento e esferização

Uma forma alternativa de compreender a geometria associada à matriz de covariâncias consiste em transformar as coordenadas de modo que a variabilidade resultante seja a mesma em todas as direções.

Seja $\mathbf{X}$ um vetor aleatório com vetor de médias μ e matriz de covariâncias $\Sigma \succ \mathbf{0}$. Uma transformação linear da forma

$$\mathbf{Z} = \mathbf{W}(\mathbf{X} - \mu)$$

é denominada **branqueamento** (*whitening*) quando a matriz $\mathbf{W}$ é escolhida de modo que

$$\text{Cov}(\mathbf{Z}) = \mathbf{W}\Sigma\mathbf{W}^\top = \mathbf{I}_p.$$

Assim, as componentes do vetor branqueado possuem variância unitária e covariâncias nulas entre si. O termo **esferização** enfatiza a interpretação geométrica da mesma transformação: os elipsoides associados à estrutura de covariâncias são transformados em esferas.

Essa interpretação refere-se à estrutura de segunda ordem do vetor aleatório, representada pela matriz de covariâncias. Em geral, o branqueamento não implica que toda a distribuição do vetor transformado seja esfericamente simétrica.

A raiz quadrada inversa de uma matriz positiva definida foi construída no Capítulo 5 a partir da raiz quadrada principal dada na Definição 5.9. Uma escolha para a matriz de branqueamento é

$$\mathbf{W} = \Sigma^{-1/2},$$

pois

$$\Sigma^{-1/2}\Sigma\Sigma^{-1/2} = \mathbf{I}_p.$$

Essa escolha é denominada **branqueamento simétrico**. Ela remove simultaneamente as diferenças de variância e as covariâncias entre as componentes. Para um ponto $\mathbf{x}$, a transformação correspondente é

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mu). \quad (8.50)$$

Para o vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2}(\mathbf{X} - \mu),$$

tem-se

$$E(\mathbf{Z}) = \mathbf{0} \quad \text{e} \quad \text{Cov}(\mathbf{Z}) = \mathbf{I}_p. \quad (8.51)$$

A transformação de branqueamento também permite interpretar diretamente a distância de Mahalanobis. De Equação 8.50,

$$\begin{aligned} \|\mathbf{z}\|^2 &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Logo,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.52)$$

A distância de Mahalanobis é, portanto, a distância euclidiana após a centralização e o branqueamento.

A esperança da distância quadrática de Mahalanobis também depende apenas da matriz de covariâncias. Como

$$d_M^2(\mathbf{X}, \mu) = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu),$$

a expressão Equação 8.38, com

$$\mathbf{A} = \Sigma^{-1},$$

fornece

$$\begin{aligned} E[d_M^2(\mathbf{X}, \mu)] &= \text{tr}(\Sigma^{-1} \Sigma) \\ &= \text{tr}(\mathbf{I}_p) \\ &= p. \end{aligned} \quad (8.53)$$

Esse resultado utiliza apenas a existência de μ e $\Sigma \succ \mathbf{0}$; não requer normalidade. No Capítulo 9, a hipótese de normalidade multivariada permitirá caracterizar não apenas essa esperança, mas a distribuição completa da distância quadrática de Mahalanobis.

Exemplo 8.12 (Branqueamento a partir da decomposição espectral). Retome a matriz de covariâncias do Exemplo 8.9,

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

Sua decomposição espectral é

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

e

$$\Lambda = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}.$$

Utilizando a raiz quadrada inversa desenvolvida no Módulo 1,

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top,$$

em que

$$\Lambda^{-1/2} = \begin{bmatrix} 1/\sqrt{6} & 0 \\ 0 & 1/\sqrt{2} \end{bmatrix}.$$

Defina

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu).$$

Então,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \mathbf{Q}\Lambda\mathbf{Q}^\top \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\mathbf{Q}^\top \\ &= \mathbf{Q}\mathbf{I}_2\mathbf{Q}^\top \\ &= \mathbf{I}_2. \end{aligned}$$

A transformação pode ser compreendida em três etapas:

$$\begin{aligned} \mathbf{X} - \mu &\xrightarrow{\mathbf{Q}^\top} \text{coordenadas nos eixos espectrais} \\ &\xrightarrow{\Lambda^{-1/2}} \text{reescalonamento para variância unitária} \\ &\xrightarrow{\mathbf{Q}} \mathbf{Z}. \end{aligned}$$

O primeiro passo expressa o vetor na base de autovetores de Σ , na qual a matriz de covariâncias é diagonal. O segundo divide cada coordenada por $\sqrt{\lambda_j}$, tornando todas as variâncias iguais a 1. O terceiro retorna ao sistema original de coordenadas por meio da transformação ortogonal $\mathbf{Q}$.

Considere agora um ponto cuja diferença em relação ao centro é

$$\mathbf{x} - \mu = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Suas coordenadas espectrais são

$$\mathbf{Q}^\top (\mathbf{x} - \mu) = \begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix}.$$

Pela expressão Equação 8.49,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= \frac{(\sqrt{2})^2}{6} + \frac{(\sqrt{2})^2}{2} \\ &= \frac{2}{6} + \frac{2}{2} \\ &= \frac{4}{3}. \end{aligned}$$

Por outro lado,

$$\left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|^2 = \frac{4}{3}.$$

Assim, o exemplo verifica concretamente a identidade

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|.$$

A decomposição espectral, a raiz matricial, o branqueamento e a distância de Mahalanobis aparecem, portanto, como partes de uma mesma construção geométrica.

O branqueamento não é único. De fato, se $\mathbf{Q}_0$ é uma matriz ortogonal, então

$$\mathbf{W} = \mathbf{Q}_0 \Sigma^{-1/2}$$

também satisfaz

$$\mathbf{W} \Sigma \mathbf{W}^\top = \mathbf{I}_p.$$

Portanto, diferentes transformações podem produzir vetores com matriz de covariâncias igual à identidade. Essas versões diferem por uma transformação ortogonal e, conseqüentemente, preservam as distâncias euclidianas no espaço branqueado.

A padronização marginal e o branqueamento devem ser distinguidos. Pela expressão Equação 8.22, a padronização marginal produz

$$\text{Cov} \left(\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \right) = \mathcal{R}.$$

Assim, a padronização marginal torna as variâncias iguais a 1, mas a matriz resultante pode apresentar correlações não nulas fora da diagonal. O branqueamento, por sua vez, utiliza a estrutura completa da matriz de covariâncias e produz

$$\text{Cov} (\mathbf{Z}) = \mathbf{I}_p.$$

Se

$$\mathbf{z}_D = \mathbf{D}_\Sigma^{-1/2} (\mathbf{x} - \mu),$$

a relação

$$\Sigma = \mathbf{D}_\Sigma^{1/2} \mathcal{R} \mathbf{D}_\Sigma^{1/2}$$

implica

$$d_M^2(\mathbf{x}, \mu) = \mathbf{z}_D^\top \mathcal{R}^{-1} \mathbf{z}_D. \quad (8.54)$$

Assim, a padronização marginal remove as escalas individuais, enquanto $\mathcal{R}^{-1}$ incorpora a associação linear remanescente. Somente quando

$$\mathcal{R} = \mathbf{I}_p$$

a distância de Mahalanobis coincide com a distância euclidiana entre as coordenadas marginalmente padronizadas.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são objetos populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão conjunta podem ser representadas por quantidades calculadas diretamente a partir das observações.

Nesta seção,

$$\bar{\mathbf{x}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}$$

representam valores obtidos de uma matriz de dados específica. Quando as linhas dessa matriz forem consideradas realizações de uma amostra aleatória, esses valores corresponderão a realizações das estatísticas

$$\bar{\mathbf{X}}, \quad \mathbf{S} \quad \text{e} \quad \mathbf{R}.$$

As propriedades dessas estatísticas como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Centralização, SQPC e matriz de covariâncias observada

Considere $n \geq 2$ observações de p variáveis organizadas, conforme Definição 1.6, em

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p$$

representa a i -ésima observação.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \in \mathbb{R}^p, \quad (8.55)$$

em que

$$\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n.$$

A matriz de dados centralizada é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.56)$$

Cada linha de $\mathbf{X}_c$ é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e suas colunas satisfazem

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.57)$$

Retomando a matriz de centralização utilizada no Capítulo 4,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

tem-se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.58)$$

A operação remove a localização das colunas sem alterar as diferenças entre as observações, conforme a propriedade estabelecida na Proposição 4.15.

Definição 8.10 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SQPC, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Equivalentemente,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.59)$$

A sigla **SQPC** significa **Somas de Quadrados e Produtos Cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*. O elemento (j, k) de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

Quando $j = k$, t_{jj} é a soma dos quadrados dos desvios da variável j . Quando $j \neq k$, t_{jk} é a soma dos produtos cruzados entre as variáveis j e k .

Como

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram das colunas centralizadas no sentido de Definição 3.18. Assim, pelas propriedades estabelecidas na Proposição 3.9,

$$\mathbf{T} = \mathbf{T}^\top,$$

$$\mathbf{T} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

A centralização impõe

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top,$$

de modo que as colunas de $\mathbf{X}_c$ pertencem ao subespaço ortogonal a $\mathbf{1}_n$, cuja dimensão é $n - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1). \quad (8.60)$$

A matriz $\mathbf{T}$ registra a dispersão sem uma normalização pelo número de observações.

Definição 8.11 (Matriz de covariâncias observada). A **matriz de covariâncias observada** é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.61)$$

Seu elemento (j, k) é

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k). \quad (8.62)$$

Os elementos diagonais são as variâncias calculadas para as colunas,

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

e os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas.

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$,

$$\mathbf{S} = \mathbf{S}^\top, \quad \mathbf{S} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c).$$

Portanto,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1). \quad (8.63)$$

Em particular, se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n-1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

Essa singularidade decorre da dimensão dos dados centralizados. Suas consequências para estimação e regularização serão tratadas no Capítulo 10.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{S} \mathbf{a} &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \end{aligned} \tag{8.64}$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas determinada por $\mathbf{a}$. Portanto, Equação 8.64 é a contraparte descritiva de Equação 8.10.

O divisor $n-1$ é utilizado aqui como convenção para a matriz de covariâncias observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será estabelecida no Capítulo 10.

8.7.2 Matriz de correlações e covariâncias cruzadas observadas

Suponha que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal das variâncias observadas por

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}). \tag{8.65}$$

Definição 8.12 (Matriz de correlações observada). A **matriz de correlações observada** é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \tag{8.66}$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.67)$$

A matriz $\mathbf{R}$ é simétrica, positiva semidefinida e possui diagonal unitária. Como $\mathbf{D}_S^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Em particular,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}.$$

A relação inversa é

$$\mathbf{S} = \mathbf{D}_S^{1/2} \mathbf{R} \mathbf{D}_S^{1/2}. \quad (8.68)$$

Defina agora a matriz das colunas centralizadas e padronizadas,

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2} \in \mathbb{R}^{n \times p}. \quad (8.69)$$

Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}} &= \frac{1}{n-1} \mathbf{D}_S^{-1/2} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_S^{-1/2} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}. \quad (8.70)$$

A expressão Equação 8.70 mostra que $\mathbf{R}$ é, a menos do fator $1/(n-1)$, uma matriz de Gram das colunas padronizadas.

Exemplo 8.13 (Da matriz de dados às matrizes de covariâncias e correlações). Considere quatro observações de duas variáveis organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}.$$

Aqui,

$$n = 4 \quad \text{e} \quad p = 2.$$

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \frac{1}{4} \mathbf{X}^\top \mathbf{1}_4 = \begin{bmatrix} 2,5 \\ 2,5 \end{bmatrix}.$$

Portanto, a matriz centralizada é

$$\begin{aligned} \mathbf{X}_c &= \mathbf{X} - \mathbf{1}_4 \bar{\mathbf{x}}^\top \\ &= \begin{bmatrix} -1,5 & -0,5 \\ -0,5 & -1,5 \\ 0,5 & 1,5 \\ 1,5 & 0,5 \end{bmatrix}. \end{aligned}$$

A matriz total de somas de quadrados e produtos cruzados é

$$\begin{aligned} \mathbf{T} &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são as somas dos quadrados dos desvios de cada variável. O elemento fora da diagonal é a soma dos produtos cruzados.

Como

$$n - 1 = 3,$$

a matriz de covariâncias observada é

$$\begin{aligned}\mathbf{S} &= \frac{1}{3}\mathbf{T} \\ &= \begin{bmatrix} 5/3 & 1 \\ 1 & 5/3 \end{bmatrix}.\end{aligned}$$

Assim,

$$s_{11} = s_{22} = \frac{5}{3}$$

e

$$s_{12} = 1.$$

A matriz diagonal das variâncias observadas é

$$\mathbf{D}_S = \begin{bmatrix} 5/3 & 0 \\ 0 & 5/3 \end{bmatrix}.$$

Como as duas variâncias são iguais,

$$\mathbf{D}_S^{-1/2} = \sqrt{\frac{3}{5}}\mathbf{I}_2.$$

Logo,

$$\begin{aligned}\mathbf{R} &= \mathbf{D}_S^{-1/2}\mathbf{S}\mathbf{D}_S^{-1/2} \\ &= \begin{bmatrix} 1 & 3/5 \\ 3/5 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix}.\end{aligned}$$

Também podemos obter diretamente a correlação entre as duas colunas:

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{1}{\sqrt{(5/3)(5/3)}} = \frac{3}{5} = 0,6.$$

O exemplo reúne as etapas da construção descritiva desenvolvida nesta seção. A partir da matriz de dados $\mathbf{X}$, calcula-se o vetor de médias $\bar{\mathbf{x}}$ e obtém-se a matriz centralizada $\mathbf{X}_c$. A matriz SQPC $\mathbf{T}$ registra a dispersão sem normalização, $\mathbf{S}$ introduz a normalização por $n - 1$ e $\mathbf{R}$ remove as escalas marginais por meio da padronização.

Nesse ponto, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ são valores calculados a partir da matriz de dados observada. Sua interpretação como realizações de estatísticas amostrais e suas propriedades inferenciais serão desenvolvidas no Capítulo 10.

Se $\mathbf{x}_{\text{pad},j}$ representa a coluna j de $\mathbf{X}_{\text{pad}}$, então

$$\|\mathbf{x}_{\text{pad},j}\|^2 = n - 1.$$

Consequentemente,

$$r_{jk} = \frac{\mathbf{x}_{\text{pad},j}^\top \mathbf{x}_{\text{pad},k}}{\|\mathbf{x}_{\text{pad},j}\| \|\mathbf{x}_{\text{pad},k}\|}. \quad (8.71)$$

Assim, a correlação observada entre duas variáveis é o cosseno do ângulo entre suas colunas centralizadas e padronizadas no espaço das observações. Essa interpretação utiliza diretamente a geometria de produtos internos desenvolvida no Módulo 1.

A representação descritiva também se estende a dois blocos de variáveis. Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais. Se

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y},$$

define-se:

Definição 8.13 (Matriz de covariâncias cruzadas observada). A **matriz de covariâncias cruzadas observada** entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y} \in \mathbb{R}^{p \times q}. \quad (8.72)$$

Sua orientação satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.73)$$

Para

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância observada entre as combinações

$$\mathbf{u} = \mathbf{X}\mathbf{a}$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}$$

é

$$s_{uv} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (8.74)$$

A expressão Equação 8.74 é a contraparte descritiva de Equação 8.14.

Se as duas matrizes forem concatenadas,

$$[\mathbf{X} \quad \mathbf{Y}],$$

a matriz de covariâncias observada correspondente possui a estrutura

$$\begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \quad (8.75)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto de variáveis, enquanto os blocos fora da diagonal registram as covariâncias entre os dois conjuntos.

A matriz $\mathbf{T}$ descreve a dispersão conjunta de todas as observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão admite uma decomposição adicional.

8.8 Decomposição da dispersão por grupos

Considere as n observações distribuídas em K grupos não vazios. O grupo k contém n_k observações, com

$$n_1 + \cdots + n_K = n.$$

Represente a observação i do grupo k por

$$\mathbf{x}_{ik} \in \mathbb{R}^p, \quad i = 1, \dots, n_k, \quad k = 1, \dots, K.$$

O vetor de médias do grupo k é

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathbf{x}_{ik}. \quad (8.76)$$

A média total satisfaz

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \mathbf{x}_{ik} = \frac{1}{n} \sum_{k=1}^K n_k \bar{\mathbf{x}}_k. \quad (8.77)$$

A dispersão total das observações em torno da média geral pode ser separada em duas fontes:

- **dispersão intragrupos:** afastamentos das observações em relação à média do grupo ao qual pertencem;
- **dispersão entre grupos:** afastamentos das médias dos grupos em relação à média total.

Essa decomposição distingue, portanto, a variabilidade existente **dentro dos grupos** daquela associada às **diferenças entre seus centros**. Em várias técnicas multivariadas, essa distinção será fundamental para avaliar se os grupos apresentam centros suficientemente separados em relação à variabilidade existente internamente.

Geometricamente, para cada observação, o deslocamento em relação à média total pode ser percorrido em duas etapas: primeiro, da observação até a média de seu grupo e, depois, da média do grupo até a média total. Assim,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (8.78)$$

A Figura 8.5 ilustra essas duas componentes. Os afastamentos das observações em relação aos respectivos centros representam a dispersão intragrupos, enquanto os afastamentos dos centros dos grupos em relação à média total representam a dispersão entre grupos.




Figura 8.5: Decomposição geométrica da dispersão em componentes intragrupos e entre grupos.

8.8.1 Dispersão total, intragrupos e entre grupos

A matriz total é

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top. \quad (8.79)$$

Definição 8.14 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^\top \in \mathbb{R}^{p \times p}. \quad (8.80)$$

Cada termo mede o afastamento de uma observação em relação ao centro de seu próprio grupo.

Definição 8.15 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \in \mathbb{R}^{p \times p}. \quad (8.81)$$

A ponderação por n_k registra o número de observações representadas por cada média de grupo. Assim, um mesmo afastamento $\bar{\mathbf{x}}_k - \bar{\mathbf{x}}$ contribui mais para a dispersão entre grupos quando corresponde a um grupo com maior número de observações.

Proposição 8.10 (Decomposição da dispersão total). *Para qualquer partição das n observações em K grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.82)$$

i Demonstração

Pela decomposição vetorial apresentada na Equação 8.78,

$$\mathbf{x}_{ik} - \bar{\mathbf{x}} = (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) + (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}).$$

Ao formar o produto externo e somar sobre as observações, surgem duas parcelas quadráticas e dois termos cruzados. Para cada grupo,

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem. A soma das primeiras parcelas produz $\mathbf{T}_{\text{intra}}$, enquanto

$$\sum_{i=1}^{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top = n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top.$$

Somando sobre os grupos, obtém-se

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Exemplo 8.14 (Decomposição da dispersão em dois grupos). Considere quatro observações de duas variáveis, distribuídas em dois grupos:

Grupo	X_1	X_2
1	1	1
1	3	1
2	3	5
2	5	5

Assim,

$$n_1 = n_2 = 2, \quad n = 4, \quad K = 2.$$

As médias dos grupos são

$$\bar{\mathbf{x}}_1 = \frac{1}{2} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right] = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{2} \left[\begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

A média total é

$$\begin{aligned} \bar{\mathbf{x}} &= \frac{1}{4} \left[\begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 5 \end{bmatrix} \right] \\ &= \begin{bmatrix} 3 \\ 3 \end{bmatrix}. \end{aligned}$$

Podemos agora calcular separadamente as três matrizes da decomposição.

Dispersão intragrupos.

No primeiro grupo,

$$\mathbf{x}_{11} - \bar{\mathbf{x}}_1 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{21} - \bar{\mathbf{x}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua contribuição para a dispersão intragrupos é

$$\begin{aligned} \mathbf{T}_{\text{intra},1} &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \begin{bmatrix} -1 & 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned}$$

No segundo grupo,

$$\mathbf{x}_{12} - \bar{\mathbf{x}}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{x}_{22} - \bar{\mathbf{x}}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

de modo que

$$\mathbf{T}_{\text{intra},2} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{T}_{\text{intra}} &= \mathbf{T}_{\text{intra},1} + \mathbf{T}_{\text{intra},2} \\ &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix}. \end{aligned} \tag{8.83}$$

Toda a dispersão dentro dos grupos ocorre, neste exemplo, na primeira variável. A segunda variável é constante dentro de cada grupo.

Dispersão entre grupos.

Os afastamentos das médias dos grupos em relação à média total são

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

e

$$\bar{\mathbf{x}}_2 - \bar{\mathbf{x}} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Como ambos os grupos possuem duas observações,

$$\begin{aligned} \mathbf{T}_{\text{entre}} &= 2 \begin{bmatrix} -1 \\ -2 \end{bmatrix} \begin{bmatrix} -1 & -2 \end{bmatrix} + 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + 2 \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix}. \end{aligned} \tag{8.84}$$

Nesse caso, a diferença entre os centros dos grupos envolve simultaneamente as duas variáveis.

Dispersão total.

Calculando diretamente os desvios das quatro observações em relação a

$$\bar{\mathbf{x}} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

obtém-se

$$\begin{aligned}
\mathbf{T} &= \begin{bmatrix} -2 \\ -2 \end{bmatrix} \begin{bmatrix} -2 & -2 \end{bmatrix} + \begin{bmatrix} 0 \\ -2 \end{bmatrix} \begin{bmatrix} 0 & -2 \end{bmatrix} \\
&+ \begin{bmatrix} 0 \\ 2 \end{bmatrix} \begin{bmatrix} 0 & 2 \end{bmatrix} + \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \end{bmatrix} \\
&= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix}.
\end{aligned} \tag{8.85}$$

A identidade Equação 8.82 pode então ser verificada diretamente:

$$\begin{aligned}
\mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}} &= \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \begin{bmatrix} 8 & 8 \\ 8 & 16 \end{bmatrix} \\
&= \mathbf{T}.
\end{aligned}$$

A decomposição também pode ser examinada em direções específicas. Para

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$

que selecciona a primeira variável,

$$\mathbf{a}_1^\top \mathbf{T} \mathbf{a}_1 = 8,$$

com

$$\mathbf{a}_1^\top \mathbf{T}_{\text{intra}} \mathbf{a}_1 = 4$$

e

$$\mathbf{a}_1^\top \mathbf{T}_{\text{entre}} \mathbf{a}_1 = 4.$$

Assim,

$$8 = 4 + 4.$$

Metade da dispersão de X_1 decorre de diferenças dentro dos grupos e metade das diferenças entre seus centros.

Para

$$\mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

que seleciona a segunda variável,

$$\mathbf{a}_2^\top \mathbf{T} \mathbf{a}_2 = 16,$$

enquanto

$$\mathbf{a}_2^\top \mathbf{T}_{\text{intra}} \mathbf{a}_2 = 0$$

e

$$\mathbf{a}_2^\top \mathbf{T}_{\text{entre}} \mathbf{a}_2 = 16.$$

Portanto,

$$16 = 0 + 16.$$

A variável X_2 não apresenta dispersão dentro dos grupos neste conjunto de dados; toda a sua dispersão total está associada à diferença entre as médias dos dois grupos.

O exemplo mostra que a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

expressa simultaneamente a decomposição da dispersão em todas as direções. Para qualquer combinação linear das variáveis, a dispersão total dessa combinação também se decompõe nas parcelas intragrupos e entre grupos, conforme Equação 8.86.

A identidade Equação 8.82 é algébrica e depende somente da partição das observações e das definições das médias total e de grupo (Rencher; Christensen, 2012). Normalidade, independência e outros pressupostos probabilísticos não são necessários para estabelecê-la.

Para qualquer direção

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.86)$$

Se

$$y_{ik} = \mathbf{a}^\top \mathbf{x}_{ik},$$

então Equação 8.86 corresponde exatamente à decomposição univariada

$$\sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y})^2 = \sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y}_k)^2 + \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2. \quad (8.87)$$

A decomposição matricial reúne simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.2 Somas de quadrados e traço das matrizes de dispersão

As matrizes $\mathbf{T}$, $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes de somas de quadrados e produtos cruzados e descrevem simultaneamente a dispersão das diferentes variáveis e suas associações.

O traço dessas matrizes reúne apenas os termos quadráticos da diagonal e fornece uma medida escalar de dispersão. Defina

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Essas quantidades constituem as somas de quadrados total, intragrupos e entre grupos, respectivamente. No caso univariado, elas coincidem com as somas de quadrados usuais da análise de variância. No caso multivariado, correspondem à soma das somas de quadrados das p variáveis.

Como o traço soma as contribuições das diferentes variáveis, essas quantidades dependem das escalas em que as variáveis são expressas. Sua interpretação conjunta é mais direta quando as variáveis possuem unidades comparáveis ou quando uma padronização apropriada foi realizada.

Para a matriz de dispersão total,

$$\mathbf{T} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top,$$

tem-se

$$\begin{aligned} \text{tr}(\mathbf{T}) &= \sum_{k=1}^K \sum_{i=1}^{n_k} \text{tr} \left[(\mathbf{x}_{ik} - \bar{\mathbf{x}}) (\mathbf{x}_{ik} - \bar{\mathbf{x}})^\top \right] \\ &= \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2. \end{aligned} \quad (8.88)$$

Portanto,

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2. \quad (8.89)$$

Assim, SQ_{total} é a soma dos quadrados das distâncias euclidianas das observações à média total.

Analogamente,

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}}) = \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}_k\|^2 \quad (8.90)$$

mede a soma dos quadrados dos afastamentos das observações em relação aos centros de seus respectivos grupos.

Por sua vez,

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2 \quad (8.91)$$

mede a soma ponderada dos quadrados das distâncias entre os centros dos grupos e a média total.

Como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade do traço fornece

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}. \quad (8.92)$$

Equivalentemente,

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (8.93)$$

Ao tomar o traço da decomposição matricial, recupera-se uma identidade escalar análoga à decomposição de somas de quadrados familiar da análise de variância:

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

A decomposição matricial

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é mais informativa, pois preserva também os produtos cruzados entre as variáveis. O traço resume essa estrutura matricial em uma única soma de quadrados.

Assim, a decomposição matricial da dispersão também produz uma decomposição da quantidade total de dispersão medida pelas distâncias euclidianas quadráticas.

Dividindo essas somas por n , obtêm-se medidas médias da dispersão quadrática. Por exemplo,

$$\frac{SQ_{\text{total}}}{n} = \frac{1}{n} \text{tr}(\mathbf{T}) = \frac{1}{n} \sum_{k=1}^K \sum_{i=1}^{n_k} \|\mathbf{x}_{ik} - \bar{\mathbf{x}}\|^2.$$

Essa quantidade representa o afastamento quadrático médio das observações em relação à média total. De modo correspondente,

$$\frac{SQ_{\text{intra}}}{n}$$

e

$$\frac{SQ_{\text{entre}}}{n}$$

representam, respectivamente, as contribuições médias da dispersão intragrupos e entre grupos.

8.8.3 Esperança das matrizes de dispersão por grupos

Até este ponto, a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

foi tratada como uma identidade algébrica para os dados observados. É possível também examinar essas matrizes como objetos aleatórios e calcular suas esperanças, desde que se especifique uma estrutura probabilística para as observações.

Suponha que, para cada grupo $k = 1, \dots, K$,

$$\mathbf{X}_{ik}, \quad i = 1, \dots, n_k,$$

sejam vetores aleatórios independentes, com

$$E(\mathbf{X}_{ik}) = \mu_k$$

e matriz de covariâncias comum

$$\text{Cov}(\mathbf{X}_{ik}) = \Sigma.$$

Não é necessário assumir normalidade.

Defina a média populacional ponderada dos grupos por

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k. \quad (8.94)$$

Considere ainda a matriz

$$\mathbf{B}_\mu = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^\top, \quad (8.95)$$

que representa a dispersão entre os vetores de médias populacionais dos grupos.

Quando as matrizes de dispersão são consideradas objetos aleatórios, as somas de quadrados correspondentes também são objetos aleatórios. Defina

$$\text{SQ}_{\text{total}} = \text{tr}(\mathbf{T}),$$

$$SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

Suas realizações observadas são, respectivamente,

$$SQ_{\text{total}}, \quad SQ_{\text{intra}} \quad \text{e} \quad SQ_{\text{entre}}.$$

Para a matriz de dispersão intragrupos,

$$\mathbf{T}_{\text{intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)^{\top},$$

tem-se

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma. \quad (8.96)$$

Tomando o traço dos dois lados e utilizando a linearidade do traço e da esperança,

$$E(SQ_{\text{intra}}) = (n - K) \text{tr}(\Sigma).$$

Consequentemente,

$$E\left(\frac{SQ_{\text{intra}}}{n - K}\right) = \text{tr}(\Sigma).$$

Dentro de cada grupo, os vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, a centralização pela média do grupo reduz em uma unidade a dimensão disponível, fazendo com que o grupo k contribua com $n_k - 1$ graus de liberdade. Portanto,

$$\sum_{k=1}^K (n_k - 1) = n - K.$$

A quantidade $n - K$ corresponde, assim, aos graus de liberdade intragrupos familiares da análise de variância. A divisão por $n - K$ antecipa a construção dos quadrados médios utilizada em ANOVA e planejamento de experimentos.

Para a dispersão entre grupos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}}) (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top,$$

a esperança é

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_\mu. \quad (8.97)$$

Essa expressão contém duas parcelas com interpretações distintas. O termo

$$(K - 1)\Sigma$$

representa a variabilidade decorrente do fato de que as médias amostrais dos grupos variam de amostra para amostra, enquanto

$$\mathbf{B}_\mu$$

representa a separação efetiva entre os vetores de médias populacionais.

Em particular, se

$$\mu_1 = \cdots = \mu_K,$$

então

$$\mathbf{B}_\mu = \mathbf{0},$$

mas, ainda assim,

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma.$$

Tomando o traço na Equação 8.97,

$$E(\text{SQ}_{\text{entre}}) = (K - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Consequentemente,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{K-1}\right) = \text{tr}(\Sigma) + \frac{\text{tr}(\mathbf{B}_{\mu})}{K-1}.$$

Quando os grupos possuem o mesmo vetor de médias populacional,

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$\mathbf{B}_{\mu} = \mathbf{0}.$$

Nesse caso,

$$E\left(\frac{\text{SQ}_{\text{entre}}}{K-1}\right) = E\left(\frac{\text{SQ}_{\text{intra}}}{n-K}\right) = \text{tr}(\Sigma).$$

Portanto, quando não existe separação entre os vetores de médias populacionais, as somas de quadrados intragrupos e entre grupos, após a divisão pelas respectivas quantidades $n - K$ e $K - 1$, possuem a mesma esperança.

Isso ocorre porque as médias amostrais dos grupos não coincidem exatamente, mesmo quando seus vetores de médias populacionais são iguais.

Por fim, como

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

a linearidade da esperança fornece

$$\begin{aligned} E(\mathbf{T}) &= E(\mathbf{T}_{\text{intra}}) + E(\mathbf{T}_{\text{entre}}) \\ &= (n-1)\Sigma + \mathbf{B}_{\mu}. \end{aligned} \tag{8.98}$$

Tomando o traço,

$$E(\text{SQ}_{\text{total}}) = (n-1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_{\mu}). \tag{8.99}$$

Além disso,

$$\text{SQ}_{\text{total}} = \text{SQ}_{\text{intra}} + \text{SQ}_{\text{entre}},$$

que é a versão aleatória da decomposição observada

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

Quando todos os grupos possuem o mesmo vetor de médias populacional,

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Esses resultados dependem apenas de momentos de primeira e segunda ordem e da independência entre as observações; a normalidade não é necessária. Distribuições amostrais e resultados inferenciais associados a essas matrizes serão tratados posteriormente.

No caso univariado, as matrizes reduzem-se a escalares e a decomposição assume a forma familiar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}}.$$

As divisões

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n-K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K-1}$$

correspondem aos quadrados médios familiares da análise de variância e do planejamento de experimentos.

No contexto multivariado, contudo, as matrizes completas de somas de quadrados e produtos cruzados preservam informações adicionais sobre as associações entre as variáveis. Por essa razão, métodos multivariados posteriores utilizarão $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, e não apenas seus traços.

8.8.4 Propriedades e limites de posto

Independentemente das hipóteses probabilísticas utilizadas na subseção anterior, as propriedades estruturais a seguir decorrem diretamente das definições das matrizes de dispersão.

Proposição 8.11 (Estrutura das matrizes de dispersão por grupos). *As matrizes*

$$\mathbf{T}, \quad \mathbf{T}_{\text{intra}} \quad e \quad \mathbf{T}_{\text{entre}}$$

são simétricas e positivas semidefinidas. Além disso,

$$\mathbf{0} \preceq \mathbf{T}_{\text{intra}} \preceq \mathbf{T}$$

e

$$\mathbf{0} \preceq \mathbf{T}_{\text{entre}} \preceq \mathbf{T}.$$


Seus postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K), \tag{8.100}$$

e

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1). \tag{8.101}$$



i Demonstração

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{k=1}^K \sum_{i=1}^{n_k} [\mathbf{a}^\top (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{k=1}^K n_k [\mathbf{a}^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})]^2 \geq 0.$$

Logo, as duas parcelas são positivas semidefinidas. Pela identidade Equação 8.82,

$$\mathbf{T} - \mathbf{T}_{\text{intra}} = \mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T} - \mathbf{T}_{\text{entre}} = \mathbf{T}_{\text{intra}} \succeq \mathbf{0},$$

o que estabelece as relações na ordem de Loewner.

O limite para $\mathbf{T}$ foi obtido na Equação 8.60.

Dentro do grupo k , os n_k vetores centralizados satisfazem

$$\sum_{i=1}^{n_k} (\mathbf{x}_{ik} - \bar{\mathbf{x}}_k) = \mathbf{0}.$$

Assim, os vetores centralizados desse grupo geram um subespaço de dimensão no máximo $n_k - 1$. Considerando todos os grupos,

$$\sum_{k=1}^K (n_k - 1) = n - K,$$

e, portanto,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K).$$

Para a parcela entre grupos,

$$\sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}) = \mathbf{0}.$$

Os K vetores

$$\sqrt{n_k} (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})$$

geram, portanto, um subespaço de dimensão no máximo $K - 1$. Consequentemente,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

Os limites podem ser estritos quando existem relações lineares adicionais entre as variáveis ou entre os vetores de médias dos grupos.

As relações na ordem de Loewner implicam, para qualquer direção $\mathbf{a}$,

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}$$

e

$$0 \leq \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} \leq \mathbf{a}^\top \mathbf{T} \mathbf{a}.$$

Assim, a dispersão intragrupos ou entre grupos em uma direção não pode exceder a dispersão total na mesma direção.

Dois casos extremos auxiliam a interpretação. Se

$$\bar{\mathbf{x}}_1 = \cdots = \bar{\mathbf{x}}_K = \bar{\mathbf{x}},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0}.$$

Se, por outro lado, todas as observações de cada grupo coincidem com a respectiva média,

$$\mathbf{x}_{ik} = \bar{\mathbf{x}}_k,$$

então

$$\mathbf{T}_{\text{intra}} = \mathbf{0}.$$

Neste capítulo, a identidade

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

é inicialmente desenvolvida como uma decomposição algébrica da dispersão observada e, sob hipóteses explícitas de independência e covariância comum, recebe também uma interpretação por meio das esperanças das matrizes de dispersão. Distribuições amostrais, testes de hipóteses e sua formulação no modelo linear multivariado serão desenvolvidos posteriormente.

No Capítulo 11, uma estrutura correspondente será obtida a partir do modelo linear multivariado e de matrizes de projeção. Graus de liberdade, estimadores de covariâncias residuais e hipóteses lineares pertencem àquele contexto.

8.9 Síntese do capítulo

A matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X})$$

representa a estrutura de segunda ordem de um vetor aleatório. Sua diagonal contém as variâncias das componentes, e seus elementos fora da diagonal registram covariâncias. Para qualquer combinação linear,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a},$$

de modo que a matriz de covariâncias determina a dispersão em todas as direções.

A padronização marginal conduz à matriz de correlações

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2},$$

que preserva a estrutura de associação linear após a retirada das escalas marginais.

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto o traço e o determinante produzem resumos escalares distintos. A variância total é

$$\text{tr}(\Sigma) = \sum_{j=1}^p \sigma_{jj} = \sum_{j=1}^p \lambda_j,$$

e também pode ser interpretada como o afastamento euclidiano quadrático médio do vetor aleatório em relação ao seu centro:

$$E[\|\mathbf{X} - \mu\|^2] = \text{tr}(\Sigma).$$

Mais geralmente, para uma matriz simétrica $\mathbf{A}$ e um vetor fixo $\mathbf{a}$,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A} (\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A} \Sigma) + (\mu - \mathbf{a})^\top \mathbf{A} (\mu - \mathbf{a}).$$

A variância generalizada é

$$\det(\Sigma),$$

e, quando $\Sigma \succ \mathbf{0}$, a distância de Mahalanobis

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

mede afastamentos levando em conta simultaneamente escalas e covariâncias. Sua esperança populacional satisfaz

$$E[d_M^2(\mathbf{X}, \mu)] = p.$$

A transformação de **branqueamento** (*whitening*), também denominada **esferização**, transforma a estrutura de covariâncias em identidade. No branqueamento simétrico,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu),$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_p.$$

Nesse espaço transformado, a distância de Mahalanobis coincide com a distância euclidiana. A padronização marginal e o branqueamento diferem porque a primeira produz matriz de covariâncias igual a $\mathcal{R}$, enquanto o branqueamento produz $\mathbf{I}_p$.

No nível descritivo, as mesmas estruturas são representadas por

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c, \quad \mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A sigla **SQPC** significa **somas de quadrados e produtos cruzados** e será utilizada como equivalente, em português, à sigla inglesa **SSCP**, de *sum of squares and cross-products*.

Quando as observações estão organizadas em grupos,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

separa a dispersão observada dentro dos grupos da dispersão associada às diferenças entre seus centros. As matrizes completas preservam tanto as somas de quadrados de cada variável quanto os produtos cruzados entre variáveis.

Tomando o traço, obtém-se a decomposição escalar

$$SQ_{\text{total}} = SQ_{\text{intra}} + SQ_{\text{entre}},$$

em que

$$SQ_{\text{total}} = \text{tr}(\mathbf{T}), \quad SQ_{\text{intra}} = \text{tr}(\mathbf{T}_{\text{intra}})$$

e

$$SQ_{\text{entre}} = \text{tr}(\mathbf{T}_{\text{entre}}).$$

No caso univariado, essa identidade coincide com a decomposição de somas de quadrados familiar da análise de variância. Os correspondentes quadrados médios são

$$QM_{\text{intra}} = \frac{SQ_{\text{intra}}}{n - K}$$

e

$$QM_{\text{entre}} = \frac{SQ_{\text{entre}}}{K - 1}.$$

No contexto multivariado, entretanto, as matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ contêm informação adicional sobre os produtos cruzados e, por isso, são mais informativas do que seus traços.

Sob independência entre as observações e matriz de covariâncias comum Σ nos grupos, as matrizes de dispersão também admitem interpretações probabilísticas. Se

$$\mu = \frac{1}{n} \sum_{k=1}^K n_k \mu_k$$

e

$$\mathbf{B}_{\mu} = \sum_{k=1}^K n_k (\mu_k - \mu) (\mu_k - \mu)^{\top},$$

então

$$E(\mathbf{T}_{\text{intra}}) = (n - K)\Sigma,$$

$$E(\mathbf{T}_{\text{entre}}) = (K - 1)\Sigma + \mathbf{B}_{\mu},$$

e

$$E(\mathbf{T}) = (n - 1)\Sigma + \mathbf{B}_\mu.$$

Tomando os traços,

$$E(\text{SQ}_{\text{intra}}) = (n - K) \text{tr}(\Sigma)$$

e

$$E(\text{SQ}_{\text{entre}}) = (K - 1) \text{tr}(\Sigma) + \text{tr}(\mathbf{B}_\mu).$$

Definindo os quadrados médios como objetos aleatórios por

$$\text{QM}_{\text{intra}} = \frac{\text{SQ}_{\text{intra}}}{n - K}$$

e

$$\text{QM}_{\text{entre}} = \frac{\text{SQ}_{\text{entre}}}{K - 1},$$

quando

$$\mu_1 = \cdots = \mu_K,$$

tem-se

$$E(\text{QM}_{\text{intra}}) = E(\text{QM}_{\text{entre}}) = \text{tr}(\Sigma).$$

Essa igualdade antecipa a lógica dos quadrados médios da análise de variância, enquanto a formulação multivariada posterior utilizará as matrizes completas de somas de quadrados e produtos cruzados.

A Tabela 8.1 reúne os principais objetos do capítulo.

Tabela 8.1: Principais objetos desenvolvidos no capítulo.

Nível	Objeto	Símbolo	Função
Populacional	vetor de médias	μ	localização

Nível	Objeto	Símbolo	Função
Populacional	matriz de covariâncias	Σ	dispersão conjunta
Populacional	matriz de correlações	$\mathcal{R}$	associação linear padronizada
Populacional	covariância cruzada	Σ_{XY}	associação linear entre blocos
Geométrico	variância total	$\text{tr}(\Sigma)$	dispersão quadrática média
Geométrico	variância generalizada	$\det(\Sigma)$	dispersão multidimensional global
Geométrico	distância de Mahalanobis	d_M	afastamento ajustado à dispersão
Geométrico	branqueamento	$\Sigma^{-1/2}$	transformação para covariância identidade
Dados observados	média	$\bar{\mathbf{x}}$	centro das observações
Dados observados	SQPC	$\mathbf{T}$	dispersão não normalizada
Dados observados	covariância	$\mathbf{S}$	dispersão calculada dos dados
Dados observados	correlação	$\mathbf{R}$	associação linear padronizada nos dados
Dados agrupados	dispersão intragrupos	$\mathbf{T}_{\text{intra}}$	dispersão dentro dos grupos
Dados agrupados	dispersão entre grupos	$\mathbf{T}_{\text{entre}}$	dispersão entre os centros dos grupos
Dados agrupados	decomposição matricial	$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$	separação da dispersão por grupos
Dados agrupados	somas de quadrados	$SQ_{\text{total}}, SQ_{\text{intra}}, SQ_{\text{entre}}$	resumos escalares obtidos pelos traços das matrizes de dispersão
Dados agrupados	quadrados médios	$QM_{\text{intra}}, QM_{\text{entre}}$	somas de quadrados ajustadas pelos respectivos graus de liberdade

Ao final deste capítulo, o estudante deverá ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- calcular e interpretar variâncias e covariâncias de combinações lineares;
- reconhecer as condições estruturais, a singularidade e o posto de matrizes de covariâncias e correlações;
- interpretar a decomposição espectral, a variância total, a variância generalizada e a geometria dos elipsoides de dispersão;
- relacionar formas quadráticas e esperanças matemáticas à estrutura de covariâncias;
- interpretar a distância de Mahalanobis e sua relação com o branqueamento e a esferização;
- distinguir padronização marginal e branqueamento;
- distinguir parâmetros populacionais, estatísticas amostrais e valores calculados de dados observados;
- decompor a dispersão observada em parcelas total, intragrupos e entre grupos;
- relacionar os traços das matrizes de dispersão às somas de quadrados total, intragrupos e entre grupos;
- reconhecer a relação entre somas de quadrados, graus de liberdade e quadrados médios, estabelecendo a conexão com a análise de variância;
- interpretar, sob hipóteses probabilísticas apropriadas, as esperanças das matrizes de dispersão e das correspondentes somas de quadrados e quadrados médios.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas, em geral, não determina sua distribuição conjunta. O próximo capítulo introduz a **Distribuição Normal Multivariada**, na qual o vetor de médias e a matriz de covariâncias determinam completamente a distribuição. Serão desenvolvidas suas distribuições marginais e condicionais e, no caso não singular, sua função densidade. Nesse contexto, a distância quadrática de Mahalanobis deixará de ser apenas uma construção geométrica baseada em momentos de segunda ordem e passará a possuir uma distribuição probabilística específica.

9 Distribuição Normal Multivariada

O Capítulo 8 desenvolveu o vetor de médias na Equação 8.1, a matriz de covariâncias na Definição 8.2 e a geometria da dispersão na Equação 8.32. Em uma distribuição geral, essas estruturas de primeira e segunda ordem não determinam completamente a distribuição conjunta. Diferentes distribuições podem possuir o mesmo vetor de médias e a mesma matriz de covariâncias.

Na família normal multivariada, o vetor de médias e a matriz de covariâncias determinam a distribuição. Além disso, transformações afins e distribuições marginais permanecem normais, e a estrutura de covariâncias assume consequências probabilísticas específicas, como a equivalência entre não correlação e independência para componentes conjuntamente normais.

O objetivo deste capítulo é construir a distribuição normal multivariada e relacionar suas propriedades probabilísticas à estrutura desenvolvida no capítulo anterior. Serão estudadas a função densidade, as distribuições marginais e condicionais, a independência entre blocos, a padronização, o branqueamento e a distribuição da distância quadrática de Mahalanobis. A sequência principal considera $\Sigma \succ \mathbf{0}$; o caso em que a matriz de covariâncias é singular será reunido em Seção 9.8.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório e $\mathbf{x} \in \mathbb{R}^p$ uma de suas realizações;
- $\mu \in \mathbb{R}^p$ representa o vetor de médias populacional;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias populacional;
- $\mathbf{X} \sim N_p(\mu, \Sigma)$ indica uma distribuição normal multivariada de dimensão p , parametrizada pelo vetor de médias e pela matriz de covariâncias;
- $\mathbf{Z}$ representa um vetor normal multivariado padrão, cuja dimensão será indicada pelo contexto; por exemplo, $\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r)$ em dimensão r ;
- $\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ representa a matriz diagonal das variâncias marginais;
- $\sigma_j = \sqrt{\sigma_{jj}}$ representa o desvio-padrão marginal da componente X_j ;
- $\mathcal{R}$ representa a matriz de correlações populacional;
- $\mathbf{X}_1$ e $\mathbf{X}_2$ representam blocos de um vetor normal particionado, com matrizes de covariâncias Σ_{11} e Σ_{22} e covariâncias cruzadas Σ_{12} e Σ_{21} ;
- $\Sigma_{11.2}$ representa o complemento de Schur de Σ_{22} em Σ ;
- $d_M^2(\mathbf{x}, \mu)$ representa a distância quadrática de Mahalanobis de um ponto fixo $\mathbf{x}$ ao centro populacional;

- D_M^2 representa a distância quadrática de Mahalanobis considerada como variável aleatória;
- χ_p^2 representa a distribuição qui-quadrado com p graus de liberdade, e $\chi_{p;1-\alpha}^2$ representa seu quantil de ordem $1 - \alpha$.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

Uma maneira de caracterizar a normalidade multivariada é examinar todas as projeções lineares do vetor. Na definição a seguir, admite-se também uma normal univariada com variância zero (Eaton, 2007). A relação desse caso com matrizes de covariâncias singulares será desenvolvida em Seção 9.8.

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se também variância igual a zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pela Proposição 8.1 do Capítulo 8, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu$$

quase certamente.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Assim, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente considerada separadamente não garante normalidade

multivariada. A definição exige que **todas as combinações lineares** das componentes possuam distribuição normal.

Portanto,

$$X_j \text{ normal para todo } j$$

não implica, isoladamente,

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ representa a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece que toda projeção unidimensional de um vetor normal multivariado possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A definição anterior também permite construir vetores normais multivariados a partir de variáveis normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ \vdots \\ Z_r \end{bmatrix},$$

com

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e componentes mutuamente independentes.

Para qualquer $\mathbf{c} \in \mathbb{R}^r$,

$$\mathbf{c}^\top \mathbf{Z} = \sum_{j=1}^r c_j Z_j$$

é uma variável normal. Além disso,

$$E(\mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}_r.$$

Logo,

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A transformação afim definida na Definição 4.7 permite transportar essa distribuição para outros vetores de médias e outras estruturas de covariância.

Proposição 9.1 (Construção afim de um vetor normal). *O vetor*

$$\mathbf{X} = \mu + \mathbf{AZ} \tag{9.3}$$

satisfaz

$$\mathbf{X} \sim N_p(\mu, \mathbf{AA}^\top), \tag{9.4}$$

em que

$$\mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

$\mathbf{A} \in \mathbb{R}^{p \times r}$ e $\mu \in \mathbb{R}^p$.

i Demonstração

Pelo resultado de transformação da covariância na Proposição 8.6,

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top = \mathbf{AA}^\top. \tag{9.5}$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{AZ} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

A última parcela é uma combinação linear das componentes de $\mathbf{Z}$ e, portanto, possui distribuição normal. Assim, $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$, o que caracteriza $\mathbf{X}$ como normal multivariado.

A matriz $\mathbf{A}$ determina como as componentes independentes de $\mathbf{Z}$ são combinadas. A transformação pode introduzir covariâncias entre as componentes de $\mathbf{X}$, mesmo que as componentes do vetor inicial sejam independentes.

Pela Proposição 8.2, uma matriz de covariâncias é simétrica e positiva semidefinida. Reciprocamente, toda matriz real simétrica e positiva semidefinida admite uma fatoração

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

De fato, pelo Teorema 5.4,

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

com autovalores não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\Lambda^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \Sigma.$$

Consequentemente, qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica positiva semidefinida Σ podem parametrizar uma distribuição normal multivariada.

Se Σ é positiva semidefinida, mas não positiva definida, obtém-se o caso singular, que será definido e desenvolvido em Seção 9.8. Na sequência principal, considere

$$\Sigma \succ \mathbf{0}.$$

A raiz quadrada principal definida em Definição 5.9 é invertível e pode ser utilizada como matriz da construção afim, pois

$$\Sigma^{1/2}\Sigma^{1/2} = \Sigma.$$

Assim, se

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

o vetor

$$\mathbf{Y} = \mu + \Sigma^{1/2} \mathbf{Z}$$

possui distribuição

$$\mathbf{Y} \sim N_p(\mu, \Sigma).$$

9.1.3 Determinação pelos parâmetros

O vetor de médias μ e a matriz de covariâncias Σ descrevem características de primeira e segunda ordem, mas, por si sós, não determinam uma distribuição conjunta. Na família normal multivariada, esses parâmetros determinam a distribuição, pois todas as projeções lineares são normais e seus parâmetros são determinados por μ e Σ .

Nesta seção será utilizada a notação de **igualdade em distribuição**. Para vetores aleatórios $\mathbf{X}$ e $\mathbf{Y}$ em $\mathbb{R}^p$, escrever

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

significa que os dois vetores possuem a mesma distribuição conjunta. Equivalentemente, para todo

$$\mathbf{x} = (x_1, \dots, x_p)^\top \in \mathbb{R}^p,$$

tem-se

$$P(X_1 \leq x_1, \dots, X_p \leq x_p) = P(Y_1 \leq x_1, \dots, Y_p \leq x_p).$$

A igualdade em distribuição não significa que

$$\mathbf{X} = \mathbf{Y}$$

quase certamente. Os vetores podem, inclusive, estar definidos em espaços de probabilidade distintos.

O resultado geral que permite passar das distribuições das projeções à distribuição conjunta é o Teorema de Cramér–Wold (Eaton, 2007).

Teorema 9.1 (Teorema de Cramér–Wold). *Sejam*

$$\mathbf{X} \in \mathbb{R}^p \quad e \quad \mathbf{Y} \in \mathbb{R}^p$$

vetores aleatórios. Então,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo

$$\mathbf{a} \in \mathbb{R}^p.$$

(Eaton, 2007)

A implicação direta decorre da aplicação da mesma transformação linear a vetores com a mesma distribuição. A implicação inversa estabelece que a coleção das distribuições de todas as projeções lineares determina a distribuição conjunta.

Leitura de aprofundamento

O Teorema de Cramér–Wold é um resultado geral e não depende da hipótese de normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

Aqui, sua função é justificar que duas distribuições normais multivariadas com o mesmo vetor de médias e a mesma matriz de covariâncias são a mesma distribuição.

Proposição 9.2 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\mathbf{Y} \sim N_p(\mu, \Sigma),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

i Demonstração

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a}$. Pelo Teorema 9.1,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Essa propriedade explica por que a notação

$$N_p(\mu, \Sigma)$$

é suficiente para identificar uma distribuição normal multivariada.

Como consequência, quando

$$\Sigma \succ \mathbf{0}$$

e

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a construção anterior permite escrever

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.2 Densidade da normal multivariada

A partir deste ponto, considere

$$\Sigma \succ \mathbf{0}.$$

Então,

$$\Sigma^{-1}$$

existe e

$$\det(\Sigma) > 0,$$

permitindo representar a distribuição normal multivariada por uma densidade em relação à medida de Lebesgue em $\mathbb{R}^p$.

9.2.1 Função densidade e log-densidade

Proposição 9.3 (Densidade da normal multivariada). *A densidade de*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

é

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.8)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

i Demonstração

Pela representação Equação 9.7,

$$\mathbf{X} \stackrel{d}{=} \mu + \Sigma^{1/2} \mathbf{Z},$$

com

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Como as componentes de $\mathbf{Z}$ são normais padrão independentes, sua densidade conjunta é

$$f_{\mathbf{Z}}(\mathbf{z}) = \frac{1}{(2\pi)^{p/2}} \exp\left(-\frac{1}{2} \mathbf{z}^\top \mathbf{z}\right).$$

Considere a transformação afim

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

Como $\Sigma^{1/2}$ é invertível,

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu).$$

A Jacobiana da transformação inversa é a matriz constante $\Sigma^{-1/2}$, de modo que

$$|\det(\Sigma^{-1/2})| = \det(\Sigma)^{-1/2}.$$

Aplicando a transformação de densidades estabelecida na Proposição 7.19,

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= f_{\mathbf{Z}}[\Sigma^{-1/2}(\mathbf{x} - \mu)] \det(\Sigma)^{-1/2} \\ &= \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp\left\{-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)\right\}. \end{aligned}$$

A derivação mostra a função desempenhada pelos dois termos matriciais da densidade. O determinante surge da alteração de volume provocada pela transformação afim, enquanto a matriz inversa aparece ao expressar o afastamento de $\mathbf{x}$ nas coordenadas da normal padrão obtidas pelo branqueamento.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$. Probabilidades são atribuídas a regiões:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}, \quad (9.9)$$

para conjuntos mensuráveis $\mathcal{A} \subseteq \mathbb{R}^p$.

A forma quadrática no expoente é a distância quadrática de Mahalanobis definida na Definição 8.9:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Assim,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left[-\frac{1}{2} d_M^2(\mathbf{x}, \mu) \right]. \quad (9.10)$$

Para μ e Σ fixos, a posição de $\mathbf{x}$ afeta a densidade somente por meio de sua distância de Mahalanobis ao vetor de médias. Como

$$c \mapsto \exp \left(-\frac{c}{2} \right)$$

é estritamente decrescente para $c \geq 0$, pontos mais afastados do centro segundo essa métrica possuem menor densidade.

A log-densidade é

$$\begin{aligned} \log f_{\mathbf{X}}(\mathbf{x}) &= -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned} \quad (9.11)$$

A expressão reúne uma constante dependente da dimensão, um termo associado à escala volumétrica da dispersão e um termo associado ao afastamento do ponto em relação ao centro. No Capítulo 10, essa mesma estrutura aparecerá na função de verossimilhança de uma amostra normal multivariada.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e Equação 9.8 reduz-se a

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

O vetor μ determina a localização da distribuição. Como

$$d_M^2(\mathbf{x}, \mu) \geq 0$$

e a igualdade ocorre em $\mathbf{x} = \mu$, a densidade atinge seu máximo no centro:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}. \quad (9.12)$$

A matriz Σ determina a escala, a orientação e a forma das superfícies de igual densidade. A geometria desses elipsoides foi desenvolvida no Capítulo 8 na Equação 8.32; a novidade probabilística é que, na distribuição normal, essa mesma geometria organiza os valores da densidade.

9.2.2 Superfícies de igual densidade

Para $c > 0$, considere

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) = c\}. \quad (9.13)$$

Para todo $\mathbf{x} \in \mathcal{S}_c$,

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left(-\frac{c}{2} \right).$$

Portanto, $\mathcal{S}_c$ é uma superfície de igual densidade.

Pela representação espectral em Equação 8.33, essas superfícies são elipsoidais. Seus eixos e extensões são determinados pela estrutura espectral de Σ . No modelo normal, dois pontos possuem a mesma densidade se, e somente se, apresentam a mesma distância de Mahalanobis ao vetor de médias.

A Figura 9.1 mostra essa correspondência para uma distribuição normal bivariada.

As curvas de nível são elipses centradas em μ . Todos os pontos sobre uma mesma curva apresentam a mesma distância de Mahalanobis ao centro e, consequentemente, a mesma densidade.

A região interna correspondente é




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.14)$$

Neste ponto, c é apenas uma constante positiva. Mais adiante, a distribuição de D_M^2 permitirá escolher valores de c associados a probabilidades populacionais específicas.

9.3 Transformações e distribuições marginais

A construção na Proposição 9.1 partiu de um vetor normal padrão. Uma propriedade mais geral da família normal é o fechamento sob transformações afins. Essa propriedade permite obter distribuições de combinações lineares, projeções, subvectores e transformações de padronização sem recalculas densidades por integração.

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

$$\mathbf{A} \in \mathbb{R}^{m \times p} \text{ e } \mathbf{b} \in \mathbb{R}^m.$$

Proposição 9.4 (Fechamento da família normal sob transformações afins). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação afim

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \quad (9.15)$$

satisfaz

$$\mathbf{Y} \sim N_m(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top), \quad (9.16)$$

em que

$$\mathbf{A} \in \mathbb{R}^{m \times p} \quad e \quad \mathbf{b} \in \mathbb{R}^m.$$

i Demonstração

Pela Proposição 8.6,

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^m$,

$$\begin{aligned}\mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}.\end{aligned}$$

Como $\mathbf{X}$ é normal multivariado,

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição de uma constante preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado.

As fórmulas para média e covariância são válidas para vetores aleatórios gerais com segundos momentos finitos. O resultado específico da família normal é o **fechamento distribucional**: se $\mathbf{X}$ possui distribuição normal multivariada, então $\mathbf{A}\mathbf{X} + \mathbf{b}$ também possui distribuição normal multivariada.

A matriz $\mathbf{A}$ não precisa possuir posto completo. Consequentemente, a matriz de covariâncias transformada

$$\mathbf{A}\Sigma\mathbf{A}^\top$$

pode não ser positiva definida. Esse caso será retomado em Seção 9.8.

Exemplo 9.1 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

Logo,

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \end{aligned}$$

e a matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

O exemplo mostra que uma transformação afim modifica simultaneamente localização e covariância, mas preserva a família normal.

9.3.2 Combinações lineares

Uma combinação linear é o caso $m = 1$ de Proposição 9.4.

Para $\mathbf{a} \in \mathbb{R}^p$ e $b \in \mathbb{R}$,

$$Y = \mathbf{a}^\top \mathbf{X} + b$$

satisfaz

$$Y \sim N(\mathbf{a}^\top \mu + b, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.17)$$

A expressão fornece diretamente a distribuição de somas, diferenças, contrastes, médias ponderadas e projeções lineares.

Exemplo 9.2 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

Quando $\sigma_{12} > 0$, a covariância aumenta a variância da soma e reduz a variância da diferença. Para $\sigma_{12} < 0$, ocorre o efeito inverso.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

então

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

quase certamente.

9.3.3 Distribuições marginais

As distribuições marginais de subvetores também podem ser obtidas como transformações lineares.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.18)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Proposição 9.5 (Distribuições marginais da normal multivariada). *Os blocos marginais de um vetor normal multivariado particionado satisfazem*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.19)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.20)$$

Esse resultado considera a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

i Demonstração

O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

com

$$\mathbf{A}_1 = [\mathbf{I}_{p_1} \quad \mathbf{0}].$$

Pela Proposição 9.4,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1 \mu, \mathbf{A}_1 \Sigma \mathbf{A}_1^\top).$$

A estrutura particionada fornece

$$\mathbf{A}_1 \mu = \mu_1$$

e

$$\mathbf{A}_1 \Sigma \mathbf{A}_1^\top = \Sigma_{11}.$$

O segundo bloco é obtido de forma análoga.

A distribuição marginal de um bloco depende de seu vetor de médias e de sua própria matriz de covariâncias. A matriz Σ_{12} não aparece nos parâmetros marginais, mas participa da estrutura de dependência conjunta.

Exemplo 9.3 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0,5 \\ -1 & 0,5 & 2 \end{bmatrix} \right).$$

Selecionando X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas componentes correspondentes de μ , e a matriz de covariâncias marginal é a submatriz principal associada às variáveis selecionadas.

9.3.4 Padronização marginal e branqueamento

O Capítulo 8 definiu na Equação 8.20 a matriz

$$\mathbf{D}_\Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}).$$

Suponha

$$\sigma_{jj} > 0, \quad j = 1, \dots, p.$$

A padronização marginal é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \boldsymbol{\mu}). \quad (9.21)$$

Pela Proposição 9.4 e pela definição de $\mathcal{R}$ na Definição 8.5,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.22)$$

com

$$\mathcal{R} = \mathbf{D}_\Sigma^{-1/2} \Sigma \mathbf{D}_\Sigma^{-1/2}.$$

Cada componente padronizada satisfaz

$$Z_{\text{pad},j} \sim N(0, 1),$$

mas as componentes não são necessariamente independentes.

Padronização não implica independência

A padronização marginal produz componentes com média zero e variância unitária, mas preserva as correlações existentes entre elas.

Assim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}).$$

As componentes serão independentes precisamente quando

$$\mathcal{R} = \mathbf{I}_p,$$

resultado que será formalizado na seção seguinte.

Quando

$$\Sigma \succ \mathbf{0},$$

o Capítulo 8 mostrou na Equação 8.51 que o branqueamento simétrico transforma a estrutura de segunda ordem em covariância identidade. Sob normalidade multivariada, é possível determinar também a distribuição completa do vetor transformado.

O branqueamento simétrico é dado por

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.23)$$

Pelo fechamento da família normal,

$$\begin{aligned} \mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p). \end{aligned} \quad (9.24)$$

A diferença entre as duas transformações é, portanto,

$$\mathbf{D}_\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R})$$

e

$$\Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A padronização marginal transforma as variâncias em um e preserva as correlações. O branqueamento transforma toda a matriz de covariâncias em identidade.

A consequência adicional da normalidade conjunta é probabilística: como será formalizado na seção seguinte, uma matriz de covariâncias diagonal implica independência das componentes dentro de um vetor conjuntamente normal. Portanto, as componentes do vetor branqueado são independentes.

Como discutido no Capítulo 8, o branqueamento não é único. No caso normal, essa não unicidade preserva também a distribuição normal padrão. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p),$$

pois

$$\mathbf{Q}_0 \mathbf{I}_p \mathbf{Q}_0^\top = \mathbf{I}_p.$$

O branqueamento simétrico constitui uma escolha específica entre transformações que produzem covariância identidade.

A próxima seção utiliza uma propriedade específica da normalidade conjunta: para blocos pertencentes ao mesmo vetor normal multivariado, covariância cruzada nula é equivalente à independência.

9.4 Independência e distribuições condicionais

Quando os segundos momentos existem, a independência entre dois blocos implica covariância cruzada nula. A implicação inversa, entretanto, não é válida sem hipóteses adicionais. Na família normal multivariada, a normalidade conjunta estabelece a equivalência entre independência e covariância cruzada nula.

A normalidade conjunta também permite determinar a distribuição condicional de um bloco a partir da estrutura de covariâncias. Nesse desenvolvimento, o complemento de Schur, definido na Definição 2.26 e aplicado à matriz de covariâncias no Capítulo 8, passa a ter uma interpretação probabilística: ele corresponde à matriz de covariâncias condicional.

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.25)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p.$$

Se os dois blocos são independentes, então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A normalidade conjunta permite estabelecer também a implicação inversa.

Nesta seção, quando o símbolo $\perp$ aparece entre vetores aleatórios, a notação

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

significa que $\mathbf{X}_1$ e $\mathbf{X}_2$ são **independentes**. Esse uso deve ser distinguido da ortogonalidade geométrica, também representada pelo símbolo $\perp$ nos capítulos de Álgebra Linear.

Proposição 9.6 (Independência de blocos conjuntamente normais). *Para dois blocos conjuntamente normais,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}, \quad (9.26)$$

considerando a estrutura conjunta


$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2).$$



i Demonstração

Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então a independência implica

$$\Sigma_{12} = \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

Para a implicação inversa, suponha

$$\Sigma_{12} = \mathbf{0}.$$

Como

$$\Sigma_{21} = \Sigma_{12}^\top,$$

a matriz de covariâncias conjunta assume a forma

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Existem matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^\top$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^\top.$$

Considere vetores normais padrão independentes $\mathbf{Z}_1$ e $\mathbf{Z}_2$ e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Por construção,

$$\mathbf{Y}_1 \perp \mathbf{Y}_2.$$

Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Pela Proposição 9.2,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então

$$X_1, \dots, X_p$$

são mutuamente independentes.

Esse resultado é uma consequência específica da normalidade conjunta. Sem essa hipótese, uma matriz de covariâncias diagonal garante covariância nula entre componentes, mas não implica independência.

A normalidade deve ser conjunta

A equivalência

$$\text{Cov}(X_i, X_j) = 0 \iff X_i \perp X_j$$

exige que X_i e X_j pertençam ao mesmo vetor normal multivariado.

A normalidade de cada variável considerada separadamente não é suficiente para essa conclusão.

9.4.2 Distribuição condicional

Considere novamente

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

e suponha

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0},$$

de modo que Σ_{22}^{-1} existe.

Na notação condicional, a barra vertical $|$ deve ser lida como **dado**. Assim,

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2$$

representa o vetor $\mathbf{X}_1$ condicionado ao valor $\mathbf{X}_2 = \mathbf{x}_2$, e o subscrito $1 \mid 2$ será utilizado para identificar quantidades condicionais relativas ao primeiro bloco dado o segundo.

Proposição 9.7 (Distribuição condicional da normal multivariada). *A distribuição condicional de um bloco de um vetor normal multivariado particionado é normal multivariada:*

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1} \left(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2} \right). \quad (9.27)$$

Esse resultado considera a estrutura conjunta

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}, \quad \mathbf{x}_2 \in \mathbb{R}^{p_2}, \quad p_1 + p_2 = p,$$

e

$$\Sigma_{22} \succ \mathbf{0}.$$

A média condicional é

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2) \quad (9.28)$$

e a matriz de covariâncias condicional é

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.29)$$

A matriz $\Sigma_{11 \cdot 2}$ é o complemento de Schur de Σ_{22} em Σ , definido em Equação 8.16.



i Demonstração

Considere

$$\mathbf{L}^* = \Sigma_{12} \Sigma_{22}^{-1}$$

e defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \mathbf{L}^* (\mathbf{X}_2 - \mu_2). \quad (9.30)$$

Os vetores $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são obtidos conjuntamente por uma transformação afim de $\mathbf{X}$. Pela Proposição 9.4,

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \mathbf{L}^* \Sigma_{22} \\ &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pela Proposição 9.6,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.31)$$

Além disso,

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Pela Proposição 8.5,

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Portanto,

$$\mathbf{E}_{1|2} \sim \mathcal{N}_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando Equação 9.30,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Condicionando em

$$\mathbf{X}_2 = \mathbf{x}_2$$

A demonstração fornece a decomposição

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.32)$$

com

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

Consequentemente,

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2). \quad (9.33)$$

No Capítulo 8, na Proposição 8.5, a expressão

$$\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2)$$

surgiu como o melhor ajuste linear de $\mathbf{X}_1$ em função de $\mathbf{X}_2$, utilizando apenas informações de primeira e segunda ordem.

Sob normalidade conjunta, ocorre um resultado mais forte:

$$E(\mathbf{X}_1 | \mathbf{X}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2).$$

Assim, na família normal multivariada, o melhor ajuste linear coincide exatamente com a esperança condicional, e a matriz de covariâncias do resíduo linear coincide com a matriz de covariâncias condicional.

9.4.3 Média e covariância condicionais

A média condicional

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

depende do valor condicionado.

O vetor

$$\mathbf{x}_2 - \mu_2$$

representa o afastamento do bloco conhecido em relação à sua média. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média de $\mathbf{X}_1$.

Quando

$$\mathbf{x}_2 = \mu_2,$$

tem-se

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

A matriz de covariâncias condicional é

$$\Sigma_{11\cdot 2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Ela não depende do valor específico de $\mathbf{x}_2$. Assim, diferentes valores do bloco condicionante deslocam o centro da distribuição condicional, mas não alteram sua matriz de covariâncias.

Como $\Sigma \succ \mathbf{0}$, a propriedade de positividade do complemento de Schur fornece

$$\Sigma_{11\cdot 2} \succ \mathbf{0}. \quad (9.34)$$

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11\cdot 2} = \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.35)$$

Como

$$\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \succeq \mathbf{0},$$

segue que

$$\Sigma_{11 \cdot 2} \preceq \Sigma_{11}. \quad (9.36)$$

Portanto, para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} \text{Var} [\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] &= \mathbf{a}^\top \Sigma_{11 \cdot 2} \mathbf{a} \\ &\leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}. \end{aligned}$$

Condicionar no segundo bloco não aumenta a variância de nenhuma combinação linear do primeiro bloco.

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se simultaneamente

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1$$

e

$$\Sigma_{11 \cdot 2} = \Sigma_{11}.$$

Nesse caso, a distribuição condicional coincide com a distribuição marginal, como consequência da independência entre os blocos estabelecida na Proposição 9.6.

9.4.4 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.37)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad -1 < \rho < 1.$$

A média condicional de X_1 dado $X_2 = x_2$ é

$$\begin{aligned}
E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2} (x_2 - \mu_2) \\
&= \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2).
\end{aligned} \tag{9.38}$$

A variância condicional é

$$\begin{aligned}
\text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2 \sigma_1^2 \sigma_2^2}{\sigma_2^2} \\
&= \sigma_1^2 (1 - \rho^2).
\end{aligned} \tag{9.39}$$

Portanto,

$$X_1 | X_2 = x_2 \sim N \left[\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right]. \tag{9.40}$$

O sinal de ρ determina a direção do deslocamento da média condicional. Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média de X_1 para valores maiores; se $\rho < 0$, o deslocamento ocorre em sentido oposto.

A variância condicional depende de ρ^2 e não do valor observado x_2 . Quanto maior $|\rho|$, menor é a variabilidade remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

obtém-se

$$E(X_1 | X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 | X_2 = x_2) = \sigma_1^2.$$

A distribuição condicional coincide, então, com a marginal. Isso é consistente com Proposição 9.6, pois, sob normalidade conjunta, $\rho = 0$ implica independência entre X_1 e X_2 .

Exemplo 9.4 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0,8,$$

e a variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = 1) &= 1 - 0,8^2 \\ &= 0,36. \end{aligned}$$

Logo,

$$X_1 | X_2 = 1 \sim N(0,8, 0,36).$$

O desvio-padrão condicional é

$$\sqrt{0,36} = 0,6.$$

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.

No primeiro painel, a linha horizontal identifica o valor condicionado $X_2 = 1$. O ponto sobre essa linha indica a média da distribuição condicional de X_1 .

O segundo painel mostra

$$X_1 | X_2 = 1 \sim N(0,8, 0,36).$$

Em relação à distribuição marginal $N(0,1)$, a média passa de 0 para 0,8 e a variância passa de 1 para 0,36. O exemplo ilustra duas propriedades gerais: a média condicional depende do valor condicionado, enquanto a matriz de covariâncias condicional não depende desse valor.

O branqueamento desenvolvido anteriormente permite agora obter uma segunda consequência probabilística da normalidade: a distribuição exata da distância quadrática de Mahalanobis.




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

9.5 Distância de Mahalanobis e regiões de probabilidade

O Capítulo 8 definiu em Definição 8.9 a distância de Mahalanobis como uma medida geométrica adaptada à estrutura de covariâncias. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a distância quadrática ao vetor de médias possui uma distribuição probabilística conhecida.

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A variável aleatória

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \quad (9.41)$$

representa a distância quadrática de Mahalanobis entre uma realização aleatória e o centro populacional.

9.5.1 Distribuição qui-quadrado

Proposição 9.8 (Distribuição da distância quadrática de Mahalanobis). *A distância quadrática de Mahalanobis*

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2, \quad (9.42)$$

para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

i Demonstração

Pelo branqueamento na Equação 9.23,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

As componentes

$$Z_1, \dots, Z_p$$

são, portanto, normais padrão independentes.

Além disso,

$$\begin{aligned} D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\ &= [\Sigma^{-1/2} (\mathbf{X} - \mu)]^\top [\Sigma^{-1/2} (\mathbf{X} - \mu)] \\ &= \mathbf{Z}^\top \mathbf{Z} \\ &= \sum_{j=1}^p Z_j^2. \end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Logo,

$$D_M^2 \sim \chi_p^2.$$

Como $\Sigma \succ \mathbf{0}$, a dimensão da distribuição é p , que determina os graus de liberdade da distribuição qui-quadrado.

Consequentemente,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \quad (9.43)$$

A escala de D_M^2 depende, portanto, da dimensão. Sob o modelo normal, seu valor esperado é p , e não zero.

A igualdade

$$E(D_M^2) = p$$

não depende da normalidade multivariada. No Capítulo 8, Equação 8.53 obteve esse resultado a partir apenas da estrutura de segunda ordem, para qualquer vetor aleatório com vetor de médias μ e matriz de covariâncias positiva definida Σ .

A hipótese de normalidade fornece um resultado mais forte:

$$D_M^2 \sim \chi_p^2.$$

Assim, no presente capítulo, além do valor esperado, passa-se a conhecer a distribuição completa da distância quadrática de Mahalanobis, incluindo sua variância e seus quantis.

No espaço branqueado,

$$D_M^2 = \|\mathbf{Z}\|^2.$$

Assim, a distância quadrática de Mahalanobis no espaço original corresponde ao quadrado da distância euclidiana à origem no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado

$$D_M^2 \sim \chi_p^2$$

utiliza os parâmetros populacionais μ e Σ .

Se esses parâmetros forem substituídos por estimativas obtidas a partir de uma amostra, a distribuição da forma quadrática resultante não será, em geral, χ_p^2 .

A distinção entre parâmetros populacionais e quantidades estimadas a partir da amostra será desenvolvida nos Capítulos 10 e 12.

9.5.2 Regiões elipsoidais de probabilidade

Definição 9.2 (Região elipsoidal de probabilidade). Para

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

a região elipsoidal de probabilidade $1 - \alpha$ é

$$\mathcal{E}_{1-\alpha} = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p;1-\alpha}^2 \right\}, \quad (9.44)$$

em que $0 < \alpha < 1$ e $\chi_{p;1-\alpha}^2$ é o quantil de ordem $1 - \alpha$ da distribuição χ_p^2 .

Consequentemente,

$$P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) = 1 - \alpha.$$

Pela Proposição 9.8,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P[D_M^2 \leq \chi_{p;1-\alpha}^2] \\ &= P[\chi_p^2 \leq \chi_{p;1-\alpha}^2] \\ &= 1 - \alpha. \end{aligned} \quad (9.45)$$

Portanto, $\mathcal{E}_{1-\alpha}$ é uma região populacional que contém uma realização de $\mathbf{X}$ com probabilidade $1 - \alpha$.

Sua fronteira é

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p;1-\alpha}^2.$$

A geometria é a mesma dos elipsoides de Mahalanobis definidos na Equação 8.32 no Capítulo 8. A novidade do modelo normal é a calibração probabilística da constante. Como naquele capítulo o elipsoide foi definido por

$$d_M^2(\mathbf{x}, \mu) \leq c^2,$$

a região de probabilidade $1 - \alpha$ é obtida fazendo

$$c^2 = \chi_{p;1-\alpha}^2,$$

ou, equivalentemente,

$$c = \sqrt{\chi_{p;1-\alpha}^2}.$$

No espaço branqueado, a região corresponde à esfera

$$\{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p;1-\alpha}^2\},$$

de raio

$$\sqrt{\chi_{p;1-\alpha}^2}.$$

As superfícies de igual densidade e as fronteiras das regiões elipsoidais de probabilidade possuem a mesma forma geométrica porque ambas são determinadas por valores constantes de d_M^2 . A diferença está na escolha da constante: nas regiões de probabilidade, ela é determinada por um quantil da distribuição χ_p^2 .

Região de probabilidade e região de confiança

A região

$$\mathcal{E}_{1-\alpha}$$

refere-se à posição de uma **realização de $\mathbf{X}$** quando os parâmetros populacionais μ e Σ são conhecidos.

Ela não é uma região de confiança para μ .

Regiões de confiança para parâmetros populacionais serão construídas no Capítulo 12 a partir de distribuições amostrais.

9.5.3 Avaliação de uma observação fixa

Considere agora um ponto fixo

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.46)$$

O ponto está dentro de $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p;1-\alpha}^2. \quad (9.47)$$

Se

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p;1-\alpha}^2,$$

a observação está fora da região que contém probabilidade populacional $1 - \alpha$.

Essa comparação descreve a posição de um valor já observado em relação ao modelo. Depois que $\mathbf{x}_0$ foi fixado, não se atribui a ele probabilidade de pertencer à região: ele está dentro ou fora dela.

Também pode ser calculada a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)]. \quad (9.48)$$

A quantidade p_M mede, sob o modelo populacional completamente especificado, a probabilidade de obter uma distância quadrática de Mahalanobis pelo menos tão grande quanto a observada.

Um valor pequeno indica que $\mathbf{x}_0$ se encontra em uma região de afastamentos pouco frequentes sob a distribuição especificada. Essa interpretação depende de μ e Σ serem parâmetros populacionais conhecidos e não constitui, neste ponto, um procedimento inferencial para detecção de observações atípicas com parâmetros estimados.

Exemplo 9.5 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix}.$$

Logo,

$$\begin{aligned}
d_M^2(\mathbf{x}_0, \mu) &= \begin{bmatrix} 3 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\
&= \frac{7}{3} \\
&\approx 2,33.
\end{aligned}$$

Para a região que contém probabilidade 0,95,

$$\chi_{2;0,95}^2 \approx 5,99.$$

Como

$$2,33 < 5,99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

A probabilidade de cauda associada à distância observada é

$$\begin{aligned}
p_M &= P(\chi_2^2 \geq 2,33) \\
&\approx 0,31.
\end{aligned}$$

Assim, aproximadamente 31% dos vetores gerados pelo modelo apresentam distância quadrática de Mahalanobis ao centro pelo menos tão grande quanto a observada. O ponto, portanto, não apresenta um afastamento particularmente extremo em relação à distribuição especificada.

O exemplo utiliza parâmetros populacionais conhecidos. Se o vetor de médias e a matriz de covariâncias fossem substituídos por estimativas amostrais, seria necessário utilizar a teoria inferencial apropriada.

Os resultados desta seção mostram a passagem da geometria da distância de Mahalanobis e de seus elipsoides, desenvolvida em Definição 8.9 e Equação 8.32, para uma interpretação probabilística. Sob normalidade multivariada e $\Sigma \succ \mathbf{0}$, a forma quadrática de Mahalanobis possui distribuição χ_p^2 , permitindo calibrar os elipsoides por probabilidades populacionais.

A comparação entre duas distribuições normais permite observar, em seguida, como mudanças no vetor de médias e na matriz de covariâncias modificam suas posições, formas e densidades. Essa comparação será utilizada somente como motivação para técnicas de discriminação desenvolvidas posteriormente.

9.6 Comparação entre distribuições normais

Considere duas populações descritas por distribuições normais multivariadas:

$$\mathbf{X}_1 \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{X}_2 \sim N_p(\mu_2, \Sigma_2),$$

com

$$\Sigma_1 \succ \mathbf{0} \quad \text{e} \quad \Sigma_2 \succ \mathbf{0}.$$

Os vetores de médias determinam a localização das distribuições, enquanto as matrizes de covariâncias determinam sua dispersão, orientação e forma. A comparação entre duas distribuições normais permite observar como esses dois componentes da parametrização atuam conjuntamente.

9.6.1 Médias distintas e covariância comum

Suponha

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As duas distribuições possuem superfícies de igual densidade com a mesma forma, orientação e extensão, mas centradas em pontos diferentes.

Pela log-densidade na Equação 9.11, ambas contêm o termo quadrático

$$-\frac{1}{2}\mathbf{x}^\top \Sigma^{-1}\mathbf{x}.$$

Ao comparar as duas log-densidades, esse termo é comum e se cancela. De fato,

$$\log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} = \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \quad (9.49)$$

A log-razão entre as densidades é, portanto, uma função afim de $\mathbf{x}$.

Consequentemente, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : f_1(\mathbf{x}) = f_2(\mathbf{x})\}$$

é um hiperplano.

A matriz de covariâncias comum influencia a orientação desse hiperplano por meio do vetor

$$\Sigma^{-1} (\mu_1 - \mu_2),$$

que determina sua direção normal. Assim, a separação entre os centros é avaliada segundo a geometria induzida pela matriz de covariâncias comum.

9.6.2 Covariâncias distintas

Considere agora

$$\Sigma_1 \neq \Sigma_2.$$

As distribuições podem diferir não somente quanto à localização, mas também quanto à forma, orientação e extensão de suas superfícies de igual densidade.

Nesse caso, as log-densidades envolvem as formas quadráticas

$$-\frac{1}{2} (\mathbf{x} - \mu_1)^\top \Sigma_1^{-1} (\mathbf{x} - \mu_1)$$

e

$$-\frac{1}{2} (\mathbf{x} - \mu_2)^\top \Sigma_2^{-1} (\mathbf{x} - \mu_2).$$

Como as matrizes inversas são diferentes, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral. Expandindo a diferença entre as log-densidades,

$$\begin{aligned}
\log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2} \mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x} \\
&\quad + \mathbf{x}^\top (\Sigma_1^{-1} \mu_1 - \Sigma_2^{-1} \mu_2) \\
&\quad - \frac{1}{2} (\mu_1^\top \Sigma_1^{-1} \mu_1 - \mu_2^\top \Sigma_2^{-1} \mu_2) \\
&\quad - \frac{1}{2} \log \left(\frac{|\Sigma_1|}{|\Sigma_2|} \right).
\end{aligned} \tag{9.50}$$

A presença do termo

$$\mathbf{x}^\top (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x}$$

faz com que a log-razão seja, em geral, uma função quadrática de $\mathbf{x}$.

Assim, o conjunto de pontos nos quais

$$f_1(\mathbf{x}) = f_2(\mathbf{x})$$

é determinado, em geral, por uma equação quadrática em $\mathbf{x}$. Sua geometria pode, portanto, diferir substancialmente do hiperplano obtido no caso de covariância comum.

A Figura 9.3 ilustra as duas situações.

No primeiro painel, as duas distribuições apresentam superfícies de nível com a mesma forma e orientação, deslocadas para centros diferentes. No segundo, as diferenças entre as matrizes de covariâncias modificam também a extensão e a orientação dessas superfícies.

A comparação mostra duas estruturas algébricas que serão utilizadas posteriormente. Com uma matriz de covariâncias comum, a comparação das log-densidades elimina os termos quadráticos comuns e produz uma expressão afim. Com matrizes de covariâncias distintas, permanecem, em geral, termos quadráticos.

Esses resultados serão retomados na formulação da Análise Discriminante. A construção de regras de classificação, probabilidades a priori, custos de decisão e estimação dos parâmetros pertence aos módulos posteriores.

9.7 Alcance da hipótese de normalidade

A distribuição normal multivariada acrescenta uma estrutura probabilística específica aos objetos desenvolvidos nos capítulos anteriores. É importante distinguir quais resultados dependem dessa hipótese e quais permanecem válidos para vetores aleatórios mais gerais.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

9.7.1 Resultados que não exigem normalidade

Diversos resultados utilizados neste capítulo dependem somente da existência dos momentos necessários.

Para um vetor aleatório com média μ e matriz de covariâncias Σ ,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}$$

não exigem normalidade.

Da mesma forma, para

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

as relações

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

são propriedades gerais dos primeiros e segundos momentos.

A matriz de covariâncias continua simétrica e positiva semidefinida, conforme Proposição 8.2; a distância de Mahalanobis continua definindo a geometria apresentada na Definição 8.9 quando a matriz de covariâncias é positiva definida; e o complemento de Schur continua representando a covariância do resíduo do melhor ajuste linear entre blocos, conforme Proposição 8.5. Esses resultados foram desenvolvidos no Capítulo 8 sem hipótese de normalidade.

Também não depende da normalidade a esperança de uma forma quadrática centrada. Para uma matriz simétrica $\mathbf{A}$,

$$E[(\mathbf{X} - \mathbf{a})^\top \mathbf{A}(\mathbf{X} - \mathbf{a})] = \text{tr}(\mathbf{A}\Sigma) + (\mu - \mathbf{a})^\top \mathbf{A}(\mu - \mathbf{a}),$$

desde que existam os momentos de segunda ordem necessários.

Em particular, quando $\Sigma \succ \mathbf{0}$,

$$E[(\mathbf{X} - \mu)^\top \Sigma^{-1}(\mathbf{X} - \mu)] = p.$$

Portanto, o valor esperado da distância quadrática de Mahalanobis é uma propriedade de segunda ordem e não uma consequência específica da normalidade.

Esses resultados descrevem estruturas de primeira e segunda ordem. Eles não determinam, por si mesmos, a distribuição conjunta.

9.7.2 Resultados específicos da família normal

A hipótese de normalidade conjunta produz propriedades adicionais.

Entre os resultados desenvolvidos neste capítulo estão:

- o vetor de médias e a matriz de covariâncias determinam completamente a distribuição;
- transformações afins preservam a família normal;
- distribuições marginais de subvectores permanecem normais;
- covariância cruzada nula entre blocos conjuntamente normais equivale à independência;
- distribuições condicionais permanecem normais;

- a esperança condicional entre blocos é uma função afim do bloco condicionante;
- a matriz de covariâncias condicional é o complemento de Schur correspondente;
- quando $\Sigma \succ \mathbf{0}$, o branqueamento produz componentes normais padrão independentes;
- quando $\Sigma \succ \mathbf{0}$, a distância quadrática de Mahalanobis populacional possui distribuição χ_p^2 .

A equivalência

$$\Sigma_{12} = \mathbf{0} \iff \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo da diferença entre uma propriedade geral de covariância e uma propriedade específica da família normal.

A implicação

$$\mathbf{X}_1 \perp \mathbf{X}_2 \implies \Sigma_{12} = \mathbf{0}$$

vale, quando os segundos momentos existem, sem normalidade. A implicação inversa requer a estrutura normal conjunta estabelecida na Proposição 9.6.

De maneira semelhante, a igualdade

$$E(D_M^2) = p$$

decorre apenas da estrutura de segunda ordem, mas a afirmação

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

é específica do modelo normal multivariado sob $\Sigma \succ \mathbf{0}$.

Assim, conhecer apenas μ e Σ permite determinar a esperança dessa forma quadrática, mas não sua distribuição completa. A distribuição qui-quadrado estabelecida na Proposição 9.8 depende da normalidade multivariada.

Assim, a normalidade transforma relações entre médias, covariâncias e formas quadráticas em afirmações sobre distribuições completas.

9.7.3 Passagem do modelo populacional para a inferência

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais que caracterizam a distribuição, sem abordar sua estimação a partir de uma amostra. Essa escolha permitiu estudar diretamente as propriedades da distribuição

$$N_p(\mu, \Sigma).$$

Em uma aplicação estatística, esses parâmetros são geralmente desconhecidos. A observação de uma amostra introduz uma nova distinção entre:

- parâmetros populacionais;
- estatísticas aleatórias;
- estimadores;
- valores calculados a partir dos dados observados.

Essa distinção modifica alguns resultados. Por exemplo,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não autoriza substituir diretamente μ e Σ por estimativas e manter a mesma distribuição.

Da mesma forma, conhecer a forma da densidade normal não é suficiente para realizar inferência sobre parâmetros desconhecidos. É necessário especificar uma amostra aleatória, construir estatísticas e estudar suas propriedades e distribuições amostrais.

O Capítulo 10 inicia essa passagem. O modelo probabilístico permanece o ponto de partida, mas os parâmetros populacionais passam a ser relacionados a estatísticas e estimadores construídos a partir da amostra.

9.8 Aprofundamento: Normal Singular

Leitura de aprofundamento

A sequência principal do capítulo considerou

$$\Sigma \succ \mathbf{0},$$

de modo que a matriz de covariâncias é invertível e a distribuição possui densidade em todo $\mathbb{R}^p$.

Quando Σ é positiva semidefinida, mas não positiva definida, a distribuição normal multivariada é singular. Nesse caso, parte das direções apresenta variância zero e a variabilidade fica restrita a um subespaço de dimensão inferior a p .

Esta seção reúne a definição, a representação em dimensão reduzida, o suporte, a densidade no suporte, o branqueamento e a forma generalizada de Mahalanobis no caso singular.

Definição 9.3 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\mu, \Sigma)$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\Sigma) = r < p.$$

Como toda matriz de covariâncias é positiva semidefinida, esse caso equivale a

$$\Sigma \succeq \mathbf{0} \quad \text{e} \quad \Sigma \neq \mathbf{0}.$$

A distribuição é **não singular** quando

$$\text{posto}(\Sigma) = p,$$

equivalentemente,

$$\Sigma \succ \mathbf{0}.$$

A normal singular surge quando existem relações lineares exatas entre as componentes do vetor. Se, por exemplo,

$$X_3 = X_1 + X_2$$

quase certamente, uma das componentes não acrescenta uma nova direção de variabilidade e a matriz de covariâncias não possui posto completo.

O caso singular também pode resultar de uma transformação linear que reduz a dimensão. Se

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \in \mathbb{R}^m$$

e

$$\text{posto}(\mathbf{A}) < m,$$

então

$$\text{posto}(\mathbf{A}\Sigma\mathbf{A}^\top) \leq \text{posto}(\mathbf{A}) < m.$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

é singular.

A distribuição normal singular fornece, portanto, um modelo probabilístico para vetores normais sujeitos a restrições lineares exatas ou representados em um espaço ambiente de dimensão maior que sua dimensão probabilística efetiva.

A singularidade de uma matriz de covariâncias amostral, entretanto, não implica que a matriz de covariâncias populacional seja singular. Como será formalizado em Equação 10.81, quando $p \geq n$, a matriz de covariâncias amostral possui posto no máximo $n - 1$ e é necessariamente singular, mesmo que a matriz populacional seja positiva definida.

Nos desenvolvimentos a seguir, considere

$$1 \leq r = \text{posto}(\Sigma) < p.$$

O caso extremo $r = 0$ será apresentado ao final da seção.

Como Σ é simétrica e positiva semidefinida, Teorema 5.4 e Proposição 5.6 garantem que sua decomposição espectral reduzida pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top. \quad (9.51)$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

possui colunas ortonormais associadas aos r autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Por Proposição 5.5,

$$\mathcal{C}(\Sigma) = \mathcal{C}(\mathbf{Q}_r).$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top.$$

Logo, uma representação da distribuição singular é

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.52)$$

Por Proposição 8.3, a singularidade de Σ implica, para qualquer vetor aleatório com essa matriz de covariâncias,

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente. Na família normal, a representação na Equação 9.52 permite uma conclusão mais forte: o subespaço afim

$$\mu + \mathcal{C}(\Sigma)$$

constitui o suporte da distribuição.

Proposição 9.9 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

o suporte da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Consequentemente,

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.53)$$

i Demonstração

Pela representação Equação 9.52,

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}.$$

Como $\Lambda_r^{1/2}$ é invertível,

$$\mathcal{C}(\mathbf{A}_r) = \mathcal{C}(\mathbf{Q}_r) = \mathcal{C}(\Sigma).$$

Portanto,

$$\mathbf{A}_r \mathbf{Z} \in \mathcal{C}(\Sigma)$$

quase certamente, o que fornece Equação 9.53.

Além disso, $\mathbf{A}_r$ possui posto coluna r . A aplicação

$$\mathbf{z} \mapsto \mu + \mathbf{A}_r \mathbf{z}$$

é uma transformação afim bijetiva entre $\mathbb{R}^r$ e

$$\mu + \mathcal{C}(\Sigma).$$

Como a normal padrão em $\mathbb{R}^r$ possui densidade positiva em todo $\mathbb{R}^r$, todo conjunto relativamente aberto e não vazio desse subespaço afim possui probabilidade positiva. Assim, esse subespaço é o suporte da distribuição.

A mesma estrutura pode ser caracterizada pelo núcleo da matriz de covariâncias. Se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

e, consequentemente,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

quase certamente.

As direções do núcleo são, portanto, direções sem variabilidade probabilística.

A normal singular não possui densidade em relação à medida de Lebesgue de dimensão p em $\mathbb{R}^p$, pois toda a probabilidade está concentrada no suporte

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão $r < p$. Nesse suporte, entretanto, a distribuição possui densidade relativamente à medida de volume r -dimensional, como será mostrado a seguir.

Exemplo 9.6 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Equivalentemente,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{x} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1 e

$$X_2 = 2X_1$$

quase certamente. Portanto, toda a distribuição está concentrada na reta

$$x_2 = 2x_1.$$

Embora o vetor tenha duas componentes, sua dimensão probabilística efetiva é 1.

Densidade no suporte da normal singular

Por Proposição 9.9, a distribuição está concentrada no subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão

$$r = \text{posto}(\Sigma).$$

Retomando Equação 9.51,

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top, \quad \Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r),$$

a Definição 5.10 fornece

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\det(\Lambda_r) = \prod_{j=1}^r \lambda_j > 0,$$

a densidade relativamente à medida de volume r -dimensional no suporte afim pode ser escrita como

$$f_{\text{sup}}(\mathbf{x}) = \frac{1}{(2\pi)^{r/2} \det(\Lambda_r)^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \right], \quad (9.54)$$

para

$$\mathbf{x} \in \mu + \mathcal{C}(\Sigma).$$

Essa expressão utiliza a mesma estrutura de Equação 9.8, mas somente nas r direções em que existe variabilidade (Anderson, 2003; Rao, 1973).

A conexão com uma normal não singular de dimensão r decorre diretamente de Equação 9.52. Defina

$$\mathbf{Y} = \Lambda_r^{1/2} \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

Por Proposição 9.1,

$$\mathbf{Y} \sim N_r(\mathbf{0}, \Lambda_r).$$

Assim, Equação 9.52 pode ser escrita como

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{Q}_r \mathbf{Y}. \quad (9.55)$$

Portanto, a normal singular em $\mathbb{R}^p$ corresponde à representação de uma normal não singular de dimensão r no subespaço afim

$$\mu + \mathcal{C}(\Sigma).$$

Branqueamento no caso singular

Se

$$\text{posto}(\Sigma) = r < p,$$

a matriz $\Sigma^{1/2}$ é singular e não possui inversa ordinária. Utilizando

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

pode-se definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.56)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.57)$$

Essa transformação expressa a distribuição em suas r direções de variância positiva e realiza o branqueamento no espaço efetivo da normal singular. Assim, embora o vetor original pertença a $\mathbb{R}^p$, sua parte aleatória pode ser representada por um vetor normal padrão de dimensão r .

Proposição 9.10 (Forma generalizada de Mahalanobis no caso normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma), \quad 1 \leq r = \text{posto}(\Sigma) < p,$$

a forma quadrática generalizada de Mahalanobis

$$D_{M,+}^2 = (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \quad (9.58)$$

satisfaz

$$D_{M,+}^2 \sim \chi_r^2, \quad (9.59)$$

em que Σ^+ é a pseudoinversa de Moore–Penrose de Σ .

i Demonstração

Considere a decomposição espectral reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Pelo branqueamento reduzido na Equação 9.56,

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu) \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A pseudoinversa de Σ é

$$\Sigma^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top.$$

Como

$$\mathbf{X} - \mu \in \mathcal{C}(\Sigma)$$

quase certamente,

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r \\ &= \sum_{j=1}^r Z_{rj}^2. \end{aligned}$$

As componentes de $\mathbf{Z}_r$ são normais padrão independentes. Portanto,

$$\mathbf{Z}_r^\top \mathbf{Z}_r \sim \chi_r^2.$$

Consequentemente,

$$E(D_{M,+}^2) = r$$

e

$$\text{Var}(D_{M,+}^2) = 2r.$$

Assim, no caso singular, a escala da forma generalizada de Mahalanobis é determinada pela dimensão efetiva r da distribuição, e não pela dimensão ambiente p .

Uma região de probabilidade $1 - \alpha$ no suporte efetivo pode ser definida por

$$\mathcal{E}_{1-\alpha}^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r;1-\alpha}^2 \right\}. \quad (9.60)$$

Pela Proposição 9.10,

$$P[\mathbf{X} \in \mathcal{E}_{1-\alpha}^{(r)}] = 1 - \alpha.$$

A calibração utiliza a dimensão efetiva r , e não a dimensão ambiente p .

Se

$$r = 0,$$

então

$$\Sigma = \mathbf{0}$$

e

$$\mathbf{X} = \mu$$

quase certamente. Nesse caso extremo, a distribuição está concentrada em um único ponto.

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição singular atribui probabilidade 1 ao seu suporte afim.

9.9 Síntese do capítulo

A distribuição normal multivariada estabelece um modelo probabilístico para um vetor aleatório em que a estrutura conjunta é completamente determinada pelo vetor de médias e pela matriz de covariâncias.

A Tabela 9.1 reúne os principais resultados.

Tabela 9.1: Principais estruturas e resultados da distribuição normal multivariada.

Estrutura	Resultado
Definição	$\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a} \in \mathbb{R}^p$
Parametrização	$\mathbf{X} \sim N_p(\mu, \Sigma)$ é determinada por μ e Σ
Construção	$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}\mathbf{Z}$, com $\Sigma = \mathbf{A}\mathbf{A}^\top$
Caso singular	se $\text{posto}(\Sigma) = r < p$, o suporte é $\mu + \mathcal{C}(\Sigma)$ e a densidade é definida relativamente ao volume r -dimensional nesse subespaço
Caso não singular	se $\Sigma \succ \mathbf{0}$, o suporte é $\mathbb{R}^p$ e existe densidade em relação à medida de Lebesgue em $\mathbb{R}^p$
Transformação afim	$\mathbf{A}\mathbf{X} + \mathbf{b}$ permanece normal
Marginalização	subvectores de um vetor normal multivariado permanecem normais
Independência	$\Sigma_{12} = \mathbf{0}$ equivale à independência entre blocos conjuntamente normais
Condicionamento	a distribuição condicional é normal, com média afim e covariância dada por complemento de Schur
Branqueamento	se $\Sigma \succ \mathbf{0}$, produz $N_p(\mathbf{0}, \mathbf{I}_p)$; no caso singular, o branqueamento reduzido produz $N_r(\mathbf{0}, \mathbf{I}_r)$
Mahalanobis	$D_M^2 \sim \chi_p^2$ no caso não singular
Regiões de probabilidade	$D_M^2 \leq \chi_{p;1-\alpha}^2$ define uma região populacional de probabilidade $1 - \alpha$
Caso singular de Mahalanobis	$D_{M,+}^2 \sim \chi_r^2$, com $r = \text{posto}(\Sigma)$
Comparação de distribuições	covariância comum produz log-razão afim; covariâncias distintas produzem, em geral, log-razão quadrática

A definição por combinações lineares e a representação afim mostram duas caracterizações complementares da família normal multivariada. A primeira descreve a distribuição por suas projeções unidimensionais; a segunda mostra como sua estrutura conjunta é determinada por μ e Σ .

Quando $\Sigma \succ \mathbf{0}$, a distribuição possui densidade em $\mathbb{R}^p$, o branqueamento produz uma normal padrão multivariada e a distância quadrática de Mahalanobis possui distribuição χ_p^2 . A normalidade fornece, assim, uma interpretação probabilística para a geometria da covariância e da distância de Mahalanobis desenvolvida no Capítulo 8.

Quando Σ é singular, a distribuição permanece normal, mas sua variabilidade fica restrita ao subespaço afim $\mu + \mathcal{C}(\Sigma)$. A dimensão probabilística efetiva passa a ser $r = \text{posto}(\Sigma)$, e a pseudoinversa permite estender ao suporte a densidade, o branqueamento e a forma quadrática de Mahalanobis.

Transformações afins e marginalizações preservam a família normal. Sob normalidade conjunta, covariância cruzada nula equivale à independência entre blocos, e o complemento de Schur fornece a matriz de covariâncias da distribuição condicional.

Ao término deste capítulo, deve-se ser capaz de:

- caracterizar uma distribuição normal multivariada por combinações lineares;
- construir vetores normais por transformações afins de vetores normais padrão;
- distinguir distribuições normais singulares e não singulares;
- identificar o suporte e a dimensão probabilística efetiva de uma normal singular;
- interpretar a densidade normal multivariada e suas superfícies de nível;
- obter distribuições de transformações afins, combinações lineares e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância cruzada nula e independência sob normalidade conjunta;
- determinar média e matriz de covariâncias de uma distribuição condicional;
- interpretar o complemento de Schur como covariância condicional;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis populacional e interpretar regiões elipsoidais de probabilidade;
- comparar distribuições normais com covariância comum e com covariâncias distintas por meio de suas log-densidades;
- distinguir resultados gerais de segunda ordem daqueles que dependem da normalidade.

Neste capítulo, μ e Σ foram tratados como parâmetros populacionais que caracterizam a distribuição, sem abordar sua estimação a partir de uma amostra. O Capítulo 10 introduz a amostra aleatória multivariada e distingue parâmetros, estatísticas, estimadores e estimativas. Essa passagem permitirá estudar como o vetor de médias e a matriz de covariâncias podem ser estimados a partir dos dados e quais propriedades podem ser atribuídas aos respectivos estimadores.

10 Estatísticas Amostrais e Estimação

O Capítulo 8 desenvolveu o vetor de médias populacional na Equação 8.1 e a matriz de covariâncias populacional na Definição 8.2. O Capítulo 9, por sua vez, formulou a distribuição normal multivariada na Definição 9.1. Até esse ponto, μ e Σ foram tratados como parâmetros populacionais. Em uma aplicação estatística, esses parâmetros geralmente são desconhecidos e precisam ser estimados a partir de uma amostra.

O objetivo deste capítulo é passar dos objetos populacionais às estatísticas definidas sobre uma amostra multivariada e estudar sua utilização como estimadores. Serão desenvolvidos o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados (SQPC), os estimadores da matriz de covariâncias, a matriz de correlações amostral e as covariâncias cruzadas entre blocos de variáveis.

Os métodos dos momentos e da máxima verossimilhança serão utilizados como princípios de construção de estimadores. As propriedades matemáticas e os resultados de cálculo matricial estabelecidos no Módulo 1 serão retomados somente quando necessários.

As distribuições amostrais exatas, a distribuição de Wishart, a independência entre o vetor de médias e a matriz de covariâncias amostrais sob normalidade e os procedimentos de inferência serão desenvolvidos no Capítulo 12. Neste capítulo, o objetivo é construir os principais estimadores de localização, dispersão e associação, estudar suas propriedades e examinar limitações associadas ao tamanho amostral e à dimensão.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{X} \in \mathbb{R}^p$ representa um vetor aleatório populacional;
- $\mathbf{X}_1, \dots, \mathbf{X}_n$ representam os vetores aleatórios que compõem a amostra;
- $\mathbf{x}_1, \dots, \mathbf{x}_n$ representam suas realizações;
- $\mathcal{X} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória da amostra;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa a matriz de dados observada;
- μ , Σ e $\mathcal{R}$ representam, respectivamente, o vetor de médias, a matriz de covariâncias e a matriz de correlações populacionais;
- $\bar{\mathbf{X}}$ representa o vetor de médias amostrais como estatística aleatória, enquanto $\bar{\mathbf{x}}$ representa seu valor observado;
- $\mathbf{T}$ representa a matriz total de somas de quadrados e produtos cruzados (SQPC) como estatística aleatória, e $\mathbf{T}$ sua realização observada;

- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória, e $\mathbf{S}$ seu valor observado;
- $\mathbf{R}$ representa a matriz de correlações amostral como estatística aleatória, e $\mathbf{R}$ seu valor observado;
- T_{jk} , S_{jk} e R_{jk} representam elementos das respectivas matrizes aleatórias, enquanto t_{jk} , s_{jk} e r_{jk} representam seus valores observados;
- $\mathbf{G} = G(\mathcal{X})$ será utilizada como notação genérica para uma estatística, evitando conflito com o símbolo $\mathbf{T}$ reservado à matriz SQPC;
- $\hat{\theta}$ representa um estimador de um parâmetro θ , e $\hat{\theta}_{\text{obs}}$ o valor assumido pelo estimador após a observação da amostra.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordem, o vetor de médias e a matriz de covariâncias definidos na Equação 8.1 e Definição 8.2 satisfazem

$$E(\mathbf{X}) = \mu \in \mathbb{R}^p$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma \in \mathbb{R}^{p \times p}.$$

Os parâmetros são características fixas da distribuição populacional. A aleatoriedade introduzida pelo processo de amostragem está nos vetores que compõem a amostra e, consequentemente, nas estatísticas definidas a partir deles.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e identicamente distribuídos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A notação

$$\stackrel{\text{iid}}{\sim}$$

indica que os vetores aleatórios são independentes e identicamente distribuídos segundo a mesma distribuição.

A condição de distribuição idêntica estabelece que todas as unidades são regidas pela mesma distribuição populacional. A independência estabelece que a realização de uma unidade não altera a distribuição das demais unidades.

Quando a distribuição populacional possui densidade em relação a uma medida comum, a independência implica

$$f_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_\theta(\mathbf{x}_i). \quad (10.2)$$

A independência também implica a fatoração da função de distribuição conjunta da amostra:

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.3)$$

Essas fatorações dizem respeito à independência **entre unidades amostrais**. A dependência entre as componentes de um mesmo vetor continua representada pela distribuição multivariada F_θ .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j na unidade i .

A independência entre

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre

$$X_{i1}, \dots, X_{ip}.$$

As componentes de uma mesma unidade podem apresentar covariâncias e outras formas de dependência.

Quando os segundos momentos existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_\ell) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No modelo normal multivariado definido na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A definição do vetor de médias amostrais, da matriz SQPC, da matriz de covariâncias amostral e da matriz de correlações amostral não exige normalidade. Neste capítulo, a hipótese normal será utilizada especificamente na obtenção dos estimadores de máxima verossimilhança de μ e Σ . As distribuições amostrais exatas e os resultados inferenciais associados serão desenvolvidos no Capítulo 12.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra, uma realização de $\mathcal{X}$ é denotada por

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.6)$$

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é a matriz aleatória da amostra;
- $\mathbf{X}$ é a matriz de dados observada;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;
- $\mathbf{x}_i$ é sua realização;
- X_{ij} é uma variável aleatória;
- x_{ij} é o valor observado correspondente.

Se o suporte de $\mathbf{X}$ é

$$\mathcal{S}_{\mathbf{X}} \subseteq \mathbb{R}^p,$$

o espaço das possíveis amostras é

$$\mathcal{S}_{\mathbf{X}}^n.$$

No caso em que

$$\mathcal{S}_{\mathbf{X}} = \mathbb{R}^p,$$

esse espaço pode ser identificado com

$$(\mathbb{R}^p)^n$$

ou, equivalentemente, com o conjunto das matrizes reais $n \times p$.

Uma estatística associa a cada possível realização da amostra uma quantidade escalar, vetorial ou matricial. Antes da observação da amostra, ela constitui um objeto aleatório; após a observação, obtém-se seu valor calculado a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

Neste capítulo, as principais quantidades populacionais de interesse são o vetor de médias μ , definido na Equação 8.1, a matriz de covariâncias Σ , definida na Definição 8.2, e a matriz de correlações $\mathcal{R}$, definida na Definição 8.5.

A matriz $\mathcal{R}$ é determinada por Σ e, portanto, não constitui um parâmetro adicional quando a matriz de covariâncias já integra a parametrização do modelo.

No modelo normal multivariado não singular definido na Definição 9.1, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Considere a matriz aleatória da amostra

$$\mathcal{X} \in \mathbb{R}^{n \times p}.$$

Uma estatística é uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{T},$$

cujas regras de cálculo não contêm parâmetros populacionais desconhecidos, em que $\mathcal{T}$ é o espaço em que o resultado assume valores.

A estatística correspondente é

$$\mathbf{G} = G(\mathcal{X}). \quad (10.7)$$

O espaço $\mathcal{T}$ pode ser escalar, vetorial ou matricial, de acordo com a estatística considerada.

Embora a expressão da estatística não contenha parâmetros desconhecidos, sua distribuição amostral pode depender dos parâmetros da distribuição populacional.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i. \quad (10.8)$$

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de uma estatística é denominada **distribuição amostral**. Ela descreve como a estatística varia entre as possíveis realizações da amostra aleatória de tamanho n .

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_\theta$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{G} = G(\mathcal{X})$$

descreve a variabilidade da estatística entre as possíveis realizações da amostra.

A distribuição populacional e a distribuição amostral correspondem, portanto, a objetos probabilísticos distintos. O Capítulo 12 estudará distribuições amostrais específicas das estatísticas introduzidas neste capítulo.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Considere um parâmetro

$$\theta \in \Theta \subseteq \mathcal{A},$$

em que $\mathcal{A}$ é o espaço em que o parâmetro é representado.

Um estimador de θ é uma estatística definida por uma função

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{A},$$

de modo que

$$\hat{\theta} = G(\mathcal{X}). \quad (10.10)$$

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X}). \quad (10.11)$$

Todo estimador é uma estatística, mas nem toda estatística precisa ser utilizada para estimar um parâmetro. A função atribuída à estatística depende do objetivo da análise.

Assim,

$$\bar{\mathbf{X}}$$

é um estimador de μ , enquanto

$$\bar{\mathbf{x}}$$

é a estimativa obtida para uma amostra específica.

Mais adiante, a matriz de covariâncias amostral

$$\mathbf{S}$$

será definida como estimador de Σ , enquanto

$$\mathbf{s}$$

representará sua realização observada.

O erro de estimação é

$$\hat{\theta} - \theta. \quad (10.12)$$

Como o estimador é uma função da amostra aleatória, o erro de estimação também é aleatório. Sua distribuição permite avaliar propriedades do procedimento de estimação.

Um mesmo parâmetro pode possuir diferentes estimadores. Para Σ , por exemplo, serão estudados o estimador não viesado

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

e, sob o modelo normal multivariado, o estimador de máxima verossimilhança

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T},$$

ambos construídos a partir da matriz SQPC $\mathbf{T}$ definida na Definição 8.10.

A estimação pontual utiliza uma estimativa única para representar o parâmetro. A estimação por regiões utiliza conjuntos construídos para quantificar a incerteza associada ao processo amostral. Neste capítulo será desenvolvida a estimação pontual. As regiões de confiança serão tratadas no Capítulo 12.

A comparação entre estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência e equivariância serão examinados a seguir. Questões de sensibilidade e robustez serão retomadas posteriormente como aprofundamento.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem estimar o mesmo parâmetro e apresentar comportamentos distintos ao longo das possíveis amostras.

Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = G(\mathcal{X}) \in \mathbb{R}^r.$$

A avaliação de $\hat{\theta}$ depende de sua distribuição amostral e do critério utilizado para comparar procedimentos. Viés, variabilidade, erro quadrático médio e comparações de eficiência podem ser considerados para um tamanho amostral fixo. A consistência e a eficiência assintótica tratam do comportamento de sequências de estimadores quando n aumenta. A suficiência examina a informação preservada pela redução da amostra, enquanto a equivariância descreve a coerência do procedimento sob transformações (Casella; Berger, 2002). Questões de sensibilidade e robustez serão tratadas posteriormente como aprofundamento.

10.2.1 Viés e variabilidade

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés (*Bias* em inglês) de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é

$$E(\hat{\theta}_j) - \theta_j.$$

A ausência de viés descreve o comportamento médio do procedimento sobre as possíveis amostras. Ela não garante que uma estimativa particular esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\hat{\Theta} \in \mathbb{R}^{a \times b},$$

define-se, elemento a elemento,

$$\text{Bias}(\hat{\Theta}) = E(\hat{\Theta}) - \Theta. \quad (10.14)$$

A variabilidade de um estimador vetorial é descrita por

$$\text{Cov}(\hat{\theta}) = E \left[\{ \hat{\theta} - E(\hat{\theta}) \} \{ \hat{\theta} - E(\hat{\theta}) \}^{\top} \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias de seus componentes e os elementos fora da diagonal são as covariâncias entre eles.

Para qualquer $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^{\top} \hat{\theta}) = \mathbf{a}^{\top} \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr} [\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

Essa medida-resumo depende da escala e da parametrização e não substitui a matriz de covariâncias quando a dependência entre os componentes do estimador é relevante.

Para um estimador matricial, uma representação da variabilidade é

$$\text{Cov} [\text{vec}(\hat{\Theta})].$$

O operador vec , definido na Definição 7.9, transforma a matriz estimada em um vetor e permite representar conjuntamente a variabilidade de todos os seus elementos.

Viés e variabilidade descrevem aspectos diferentes do desempenho de um estimador. Um procedimento pode apresentar pequeno viés e grande variabilidade, ou maior viés e menor variabilidade. Para comparar conjuntamente essas duas fontes de erro, é necessário especificar como os desvios entre estimador e parâmetro serão avaliados.

10.2.2 Erro quadrático médio e funções de perda

A comparação entre estimadores requer especificar como diferentes erros são avaliados. Essa escolha é formalizada por uma **função de perda**. Para uma perda L , o **risco** do estimador é seu valor esperado sob o parâmetro θ :

$$R(\theta, \hat{\theta}) = E_{\theta} [L(\hat{\theta}, \theta)].$$

Assim, diferentes funções de perda podem conduzir a diferentes critérios de comparação entre estimadores (Casella; Berger, 2002).

Para um estimador vetorial, considere a perda quadrática euclidiana

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.16)$$

Essa escolha atribui o mesmo peso às coordenadas na parametrização utilizada. Outros problemas podem exigir ponderações ou perdas diferentes.

Definição 10.6 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = E \left[\|\hat{\theta} - \theta\|^2 \right]. \quad (10.17)$$

Proposição 10.1 (Decomposição do erro quadrático médio). *Se $\hat{\theta}$ possui segundos momentos finitos, então*

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.18)$$

i Demonstração

Escreva

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + \text{Bias}(\hat{\theta}).$$

O primeiro termo possui média zero. Ao expandir o quadrado da norma e tomar esperança, o termo cruzado desaparece. Além disso,

$$E \left[\|\hat{\theta} - E(\hat{\theta})\|^2 \right] = \text{tr} [\text{Cov}(\hat{\theta})].$$

Substituindo essas relações, obtém-se Equação 10.18.

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})].$$

A decomposição na Equação 10.18 também pode ser vista como uma aplicação de Equação 8.38, tomando a matriz identidade e considerando $\hat{\theta}$ como vetor aleatório com média $E(\hat{\theta})$.

A ausência de viés não implica EQM mínimo. Um estimador viesado pode apresentar menor risco quadrático se a redução de variabilidade compensar o viés. Essa ideia será retomada na seção de regularização.

Para parâmetros matriciais, uma escolha correspondente é a perda baseada na norma de Frobenius definida na Definição 6.7:

$$L_F(\widehat{\Theta}, \Theta) = \|\widehat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\widehat{\Theta}) = E \left[\|\widehat{\Theta} - \Theta\|_F^2 \right]. \quad (10.19)$$

Equivalentemente,

$$\begin{aligned} \text{EQM}_F(\widehat{\Theta}) &= \text{tr} \left\{ \text{Cov} [\text{vec}(\widehat{\Theta})] \right\} \\ &\quad + \|\text{Bias}(\widehat{\Theta})\|_F^2. \end{aligned} \quad (10.20)$$

A norma de Frobenius corresponde a uma escolha específica de perda. Em problemas de estimação de matrizes de covariâncias, outros critérios podem atribuir pesos diferentes a autovalores, direções ou erros de inversão.

10.2.3 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta (Vaart, 1998).

Definição 10.7 (Consistência). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma sequência de estimadores

$$\widehat{\theta}_n \in \mathbb{R}^r,$$

com r fixo quando $n \rightarrow \infty$.

A sequência $\widehat{\theta}_n$ é consistente para θ quando

$$\widehat{\theta}_n \xrightarrow{P} \theta \quad (10.21)$$

quando

$$n \longrightarrow \infty.$$

A notação

$$\xrightarrow{P}$$

indica **convergência em probabilidade**. Isso significa que, para todo $\varepsilon > 0$,

$$P(\|\hat{\theta}_n - \theta\| > \varepsilon) \rightarrow 0. \quad (10.22)$$

Na formulação clássica deste capítulo, a dimensão do parâmetro é mantida fixa enquanto n aumenta. Quando a dimensão também varia com n , é necessário declarar o regime dimensional e a métrica utilizada para avaliar o erro. Essa distinção será retomada na seção de aprofundamento sobre alta dimensão.

Não viesamento e consistência descrevem propriedades diferentes. O não viesamento compara a esperança do estimador com o parâmetro para um tamanho amostral dado, enquanto a consistência descreve o que acontece com o erro de estimação quando n aumenta. Uma propriedade não deve ser interpretada como sinônimo da outra.

10.2.4 Eficiência

Para estimadores vetoriais não viesados, uma comparação natural considera suas matrizes de covariâncias. Considere dois estimadores

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2,$$

ambos não viesados para θ .

Diz-se que $\hat{\theta}_1$ é uniformemente pelo menos tão eficiente quanto $\hat{\theta}_2$, segundo a ordem de Löwner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.23)$$

Equivalentemente,

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0}.$$

Consequentemente, para todo $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2).$$

No caso vetorial, não existe necessariamente um estimador que seja mais preciso em todos os aspectos. Cada vetor $\mathbf{a} \in \mathbb{R}^r$ define uma combinação linear $\mathbf{a}^\top \hat{\theta}$ e, portanto, uma direção

na qual a variabilidade dos estimadores pode ser comparada. Um estimador pode apresentar menor variabilidade em determinadas direções e maior variabilidade em outras.

A ordem de Löwner declara $\hat{\theta}_1$ pelo menos tão eficiente quanto $\hat{\theta}_2$ somente quando a desigualdade anterior vale para **todas** as direções **a**. Por isso, trata-se de uma ordem parcial: podem existir duas matrizes de covariâncias para as quais nenhum dos estimadores apresenta menor variabilidade em todas as direções.

Quando duas matrizes de covariâncias não são comparáveis pela ordem de Löwner, pode-se adotar um critério escalar que resuma algum aspecto de sua variabilidade. Um exemplo é

$$\text{tr} [\text{Cov}(\hat{\theta})],$$

que soma as variâncias dos componentes do estimador. Essa escolha estabelece um critério particular de comparação; outra função de perda pode produzir uma ordenação diferente.

Para estimadores viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. É necessário considerar um risco que incorpore viés e variabilidade.

A eficiência assintótica compara as matrizes que aparecem nas distribuições-limite de sequências de estimadores. Sob condições de regularidade, estimadores de máxima verossimilhança podem atingir limites associados à informação de Fisher definida na Definição 7.18. Os resultados assintóticos correspondentes não serão desenvolvidos neste capítulo e serão retomados no contexto inferencial do Capítulo 12.

10.2.5 Suficiência

Uma estatística suficiente resume a amostra sem perder informação sobre o parâmetro no modelo considerado. Depois de conhecida essa estatística, a distribuição condicional dos dados restantes não depende do parâmetro (Casella; Berger, 2002).

Definição 10.8 (Estatística suficiente). Considere uma amostra aleatória

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

cuja distribuição pertence a uma família indexada por

$$\theta \in \Theta,$$

e uma estatística definida por

$$G : \mathbb{R}^{n \times p} \longrightarrow \mathcal{G},$$

de modo que

$$\mathbf{G} = G(\mathcal{X}).$$

A estatística $\mathbf{G}$ é **suficiente para** θ quando a distribuição condicional de $\mathcal{X}$ dado $\mathbf{G}$ é a mesma para todos os valores de $\theta \in \Theta$ para os quais essa distribuição condicional está definida.

A função G reduz a amostra à estatística $\mathbf{G}$. A suficiência estabelece que, após conhecida essa estatística, a parte restante da variabilidade da amostra não contém dependência adicional em relação a θ .

A suficiência pode ser entendida como uma redução dos dados sem perda de informação sobre θ no contexto do modelo considerado. Isso não significa que seja possível reconstruir a amostra original a partir de $\mathbf{G}$, mas que a parte da amostra não representada por $\mathbf{G}$ deixa de depender do parâmetro.

A definição de suficiência é formulada em termos de uma distribuição condicional, que nem sempre é a forma mais conveniente para verificar a propriedade diretamente. Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério equivalente baseado na forma da densidade ou da função de probabilidade conjunta.

Teorema 10.1 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família de distribuições indexada por*

$$\theta \in \Theta$$

e dominada por uma medida comum ν , com densidade conjunta

$$f_\theta : \mathcal{X} \longrightarrow [0, \infty)$$

em relação a ν .

Considere também uma estatística definida por

$$G : \mathcal{X} \longrightarrow \mathcal{G}.$$

A estatística $G(\mathcal{X})$ é suficiente para θ se, e somente se, existem funções não negativas

$$q_\theta : \mathcal{G} \longrightarrow [0, \infty), \quad \theta \in \Theta,$$

e

$$r : \mathcal{X} \longrightarrow [0, \infty),$$

com r independente de θ , tais que

$$f_{\theta}(\mathbf{x}) = q_{\theta}[G(\mathbf{x})] r(\mathbf{x}) \quad (10.24)$$

para ν -quase todo $\mathbf{x} \in \mathcal{X}$ e para todo $\theta \in \Theta$.

(Casella; Berger, 2002)

A fatoração separa a densidade conjunta em duas partes. A primeira,

$$q_{\theta}[G(\mathbf{x})],$$

contém toda a dependência em relação a θ e utiliza os dados somente por meio de $G(\mathbf{x})$. A segunda,

$$r(\mathbf{x}),$$

pode depender da amostra completa, mas não depende do parâmetro. Por isso, para estudar θ , a informação contida nos dados entra na verossimilhança por meio da estatística suficiente.

No modelo normal multivariado definido na Definição 9.1, o vetor de médias amostrais e a matriz SQPC formam conjuntamente uma estatística suficiente para μ e Σ (Anderson, 2003).

Proposição 10.2 (Suficiência no modelo normal multivariado). *No modelo normal multivariado, a estatística*

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para o parâmetro

$$(\mu, \Sigma),$$

quando

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Nesse resultado,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é o vetor de médias amostrais e

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top \quad (10.25)$$

é a matriz SQPC.

i Demonstração

Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}.$$

A identidade de decomposição em torno da média fornece

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top, \end{aligned}$$

em que $\mathbf{T}$ é a matriz SQPC observada definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, toda a dependência da densidade conjunta em relação a μ e Σ ocorre por meio de

$$(\bar{\mathbf{x}}, \mathbf{T}).$$

O resultado segue de Teorema 10.1.

A suficiência não implica, por si só, ausência de viés, consistência ou eficiência. Ela descreve a quantidade de informação sobre o parâmetro preservada pela estatística, e não a qualidade de um estimador construído a partir dela. Sob o modelo considerado, reduzir a amostra a uma estatística suficiente não elimina informação sobre θ .

10.2.6 Equivariância

Uma transformação dos dados pode induzir uma transformação correspondente no parâmetro. Um procedimento equivariante respeita essa relação.

Definição 10.9 (Equivariância de um estimador). Considere um espaço amostral $\mathcal{X}$, um espaço amostral transformado $\mathcal{Y}$ e espaços paramétricos Θ e Ψ .

Sejam

$$h : \mathcal{X} \longrightarrow \mathcal{Y}$$

uma transformação dos dados e

$$g : \Theta \longrightarrow \Psi$$

a transformação correspondente do parâmetro.

Considere uma regra de estimação

$$G_{\Theta} : \mathcal{X} \longrightarrow \Theta$$

para $\theta \in \Theta$ e a regra correspondente

$$G_{\Psi} : \mathcal{Y} \longrightarrow \Psi$$

para

$$\psi = g(\theta).$$

As regras de estimação são **equivariantes** em relação a h e g quando

$$G_{\Psi} [h(\mathcal{X})] = g[G_{\Theta}(\mathcal{X})]. \quad (10.26)$$

A função h atua sobre os dados, enquanto g atua sobre o parâmetro. Por isso, as duas funções não precisam possuir a mesma forma.

Considere, por exemplo, a transformação afim dos dados

$$h : \mathbf{X}_i \mapsto \mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

Nesse caso, h é a transformação aplicada a cada vetor observado da amostra.

Para o vetor de médias, o parâmetro populacional é

$$\theta = \mu,$$

e a transformação correspondente no espaço paramétrico é

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Portanto,

$$\mu_Y = g_1(\mu) = \mathbf{C}\mu + \mathbf{d}.$$

Para a matriz de covariâncias, o parâmetro populacional é

$$\theta = \Sigma,$$

e, por Proposição 8.6, a transformação correspondente é

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Portanto,

$$\Sigma_Y = g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Esse exemplo mostra que uma mesma transformação h aplicada aos dados pode induzir transformações diferentes no espaço paramétrico. Para a média,

$$g_1(\mu) = \mathbf{C}\mu + \mathbf{d},$$

enquanto, para a covariância,

$$g_2(\Sigma) = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Assim, a forma de g depende do parâmetro considerado, mesmo quando a transformação h dos dados permanece a mesma.

Para estimar μ , a regra de estimação é

$$G_1(\mathcal{X}) = \bar{\mathbf{X}}.$$

Aplicando a mesma regra aos dados transformados,

$$G_1[h(\mathcal{X})] = \bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d} = g_1[G_1(\mathcal{X})].$$

Portanto, o vetor de médias amostrais é equivariante em relação a essa transformação afim.

Para estimar Σ , a regra de estimação é

$$G_2(\mathcal{X}) = \mathbf{S}_X.$$

Para os dados transformados,

$$G_2[h(\mathcal{X})] = \mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top = g_2[G_2(\mathcal{X})].$$

Assim, a matriz de covariâncias amostral também é equivariante em relação à transformação considerada.

A equivariância descreve como um estimador responde a uma transformação dos **dados**: transformar os dados e depois estimar deve produzir o mesmo resultado que estimar primeiro e aplicar a transformação correspondente ao parâmetro.

Essa propriedade deve ser distinguida da invariância da máxima verossimilhança. Nesse segundo caso, parte-se de um estimador de máxima verossimilhança já obtido para θ e utiliza-se uma função desse estimador para estimar uma função do parâmetro.

As propriedades desta seção respondem a perguntas diferentes sobre um procedimento de estimação:

- **viés** compara o valor médio do estimador com o parâmetro;

- **variabilidade** descreve quanto o estimador muda entre amostras;
- **erro quadrático médio** combina viés e variabilidade segundo uma função de perda;
- **consistência** descreve o comportamento do estimador quando o tamanho amostral aumenta;
- **eficiência** compara a variabilidade de procedimentos concorrentes;
- **suficiência** examina quanta informação sobre o parâmetro é preservada por uma estatística;
- **equivariância** examina a coerência do estimador diante de transformações dos dados.

Essas propriedades não estabelecem uma ordenação universal entre estimadores. Um procedimento pode apresentar vantagens segundo um critério e desvantagens segundo outro. A escolha depende do parâmetro de interesse, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise.

Os métodos dos momentos e da máxima verossimilhança fornecem dois princípios gerais para construir os estimadores estudados a seguir.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos relaciona momentos populacionais a seus correspondentes amostrais. A máxima verossimilhança escolhe os valores dos parâmetros que tornam os dados observados mais compatíveis com o modelo especificado (Casella; Berger, 2002).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. Além disso, o princípio utilizado para construir um estimador deve ser distinguido das propriedades estudadas na seção anterior. Em particular, obter um estimador pelo método dos momentos ou pela máxima verossimilhança não garante, por si só, ausência de viés, consistência, eficiência, suficiência, equivariância ou robustez.

Algumas propriedades podem ser demonstradas sob condições adicionais sobre o modelo e o processo amostral. Outras decorrem da própria estrutura de um método. Essas distinções serão indicadas ao apresentar cada procedimento.

10.3.1 Método dos momentos

Definição 10.10 (Estimador pelo método dos momentos). Considere

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma função

$$\mathbf{q} : \mathbb{R}^p \longrightarrow \mathbb{R}^r$$

tal que

$$E_{\theta} [\|\mathbf{q}(\mathbf{X})\|] < \infty$$

para os valores de θ considerados.

Defina

$$\mathbf{m} : \Theta \longrightarrow \mathbb{R}^r$$

por

$$\mathbf{m}(\theta) = E_{\theta} [\mathbf{q}(\mathbf{X})]. \quad (10.27)$$

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

defina

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.28)$$

Um **estimador pelo método dos momentos** de θ é qualquer solução

$$\hat{\theta}_{\text{MM}} \in \Theta$$

do sistema

$$\mathbf{m}(\hat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.29)$$

A existência e a unicidade do estimador dependem dos momentos escolhidos e da forma da função $\mathbf{m}$. Assim, o método substitui os momentos populacionais, que dependem do parâmetro desconhecido, pelos correspondentes momentos calculados a partir da amostra e resolve as equações resultantes em relação a θ .

O sistema pode não possuir solução, possuir mais de uma solução ou produzir valores que não pertençam a Θ .

Propriedades dos estimadores de momentos

A propriedade que define o método é a correspondência entre os momentos populacionais e seus análogos amostrais expressa na Equação 10.29. Essa construção, isoladamente, não garante que o estimador obtido seja não viesado, eficiente, suficiente, equivariante ou robusto.

A consistência também não decorre apenas do método. Sob condições como existência dos momentos utilizados, convergência dos momentos amostrais para seus correspondentes populacionais, identificação do parâmetro por esses momentos e continuidade adequada da solução, estimadores de momentos podem ser consistentes.

Portanto, as propriedades apresentadas na seção anterior devem ser verificadas para o estimador e o modelo considerados.

Para o vetor de médias populacional,

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{X}},$$

de modo que

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}. \quad (10.30)$$

Para a matriz de covariâncias, considere o segundo momento não central

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

Pela identidade Equação 8.3,

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top.$$

Substituindo os momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned} \hat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{X}} \bar{\mathbf{X}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^\top. \end{aligned} \quad (10.31)$$

A matriz no numerador é a versão aleatória da matriz total de somas de quadrados e produtos cruzados (SQPC) definida, para dados observados, na Definição 8.10. Será denotada por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.32)$$

Portanto,

$$\hat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}. \quad (10.33)$$

Essa construção utiliza apenas momentos de primeira e segunda ordem e não exige a hipótese de normalidade multivariada. O divisor n surge aqui diretamente do princípio do método dos momentos; posteriormente, ele também será obtido pela máxima verossimilhança sob o modelo normal.

A matriz $\mathbf{T}$ será desenvolvida em detalhes na seção dedicada à SQPC. Para cada realização da amostra, ela produz a matriz $\mathbf{T}$ definida na Definição 8.10.

Restrições do espaço paramétrico

Resolver as equações de momentos não garante que a solução obtida satisfaça todas as restrições impostas ao parâmetro. Em modelos com condições de positividade, ordem, posto ou outras restrições estruturais, é necessário verificar se a solução pertence efetivamente ao espaço paramétrico Θ .

10.3.2 Verossimilhança e máxima verossimilhança

Definição 10.11 (Função de verossimilhança). Considere um espaço paramétrico Θ e uma família de distribuições indexada por

$$\theta \in \Theta,$$

na qual cada observação possui densidade ou função de probabilidade

$$f(\mathbf{x}; \theta)$$

em um espaço amostral $\mathcal{X}$.

Para uma amostra i.i.d.

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

e uma realização observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X},$$

a função de verossimilhança, para os dados observados fixados, é a função

$$L(\cdot; \mathbf{x}_1, \dots, \mathbf{x}_n) : \Theta \longrightarrow [0, \infty)$$

definida por

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.34)$$

Na verossimilhança, os dados observados são mantidos fixos e θ varia em Θ . Portanto, L não é, em geral, uma distribuição de probabilidade sobre θ .

A log-verossimilhança é

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \log L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n),$$

e, sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.35)$$

Como o logaritmo é estritamente crescente, a verossimilhança e a log-verossimilhança possuem os mesmos pontos de máximo.

Definição 10.12 (Estimador de máxima verossimilhança). Considere a função de verossimilhança definida na Definição 10.11 e suponha que

$$\arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}) \neq \emptyset.$$

Um **estimador de máxima verossimilhança** de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

que seleciona um elemento desse conjunto:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.36)$$

Se o conjunto de máximos contiver mais de um elemento, qualquer elemento selecionado segundo a regra de estimação adotada é um estimador de máxima verossimilhança.

Como o logaritmo é estritamente crescente, a mesma regra pode ser obtida maximizando a log-verossimilhança:

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} \ell(\theta; \mathcal{X}).$$

Após a observação da amostra, a estimativa correspondente satisfaz

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A notação $\arg \max$ representa o conjunto dos valores do parâmetro em que o máximo é atingido. Assim, a definição admite a possibilidade de mais de um máximo. A existência e a unicidade do estimador precisam ser verificadas no modelo e no espaço paramétrico considerados.

Propriedades dos estimadores de máxima verossimilhança

A maximização da verossimilhança não garante, em amostras finitas, que o estimador seja não viesado ou apresente erro quadrático médio mínimo. Também não garante, por si só, suficiência, equivariância em relação a transformações dos dados ou robustez.

Sob condições de regularidade e identificabilidade, estimadores de máxima verossimilhança podem ser consistentes, assintoticamente normais e assintoticamente eficientes. Esses resultados dependem das condições do modelo e não são consequências incondicionais do procedimento de maximização.

Uma propriedade estrutural específica da máxima verossimilhança é a **invariância em relação a funções do parâmetro**: quando o estimador de máxima verossimilhança existe, uma função apropriada desse estimador fornece o estimador de máxima verossimilhança da função correspondente do parâmetro. Essa propriedade será formalizada adiante.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

Considere uma amostra do modelo normal multivariado definido na Definição 9.1:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Pela densidade normal multivariada na Equação 9.8 e pela independência das unidades amostrais, para uma amostra observada a verossimilhança é

$$L(\mu, \Sigma) = (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \quad (10.37)$$

A log-verossimilhança é

$$\begin{aligned} \ell(\mu, \Sigma) = & -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ & - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu). \end{aligned} \quad (10.38)$$

Considere a matriz SQPC observada $\mathbf{T}$, definida na Definição 8.10:

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.39)$$

Separando o afastamento em relação a μ no desvio em relação à média amostral e no deslocamento da própria média, obtém-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{T} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top. \end{aligned} \quad (10.40)$$

A forma quadrática presente na log-verossimilhança pode ser reescrita utilizando o traço. Pela relação entre traço e produto externo em Proposição 2.7 e pela propriedade cíclica em Exemplo 2.12, para um vetor $\mathbf{z}$ e uma matriz compatível $\mathbf{A}$,

$$\mathbf{z}^\top \mathbf{A} \mathbf{z} = \text{tr}(\mathbf{A} \mathbf{z} \mathbf{z}^\top).$$

Consequentemente,

$$\begin{aligned}
& \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \\
&= \text{tr} \left[\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] \\
&= \text{tr} (\Sigma^{-1} \mathbf{T}) + n (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu),
\end{aligned}$$

em que a última igualdade utiliza Equação 10.40. Assim, a log-verossimilhança pode ser escrita como

$$\begin{aligned}
\ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\
&\quad - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}) \\
&\quad - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu).
\end{aligned} \tag{10.41}$$

Para Σ fixa, o último termo é não positivo na log-verossimilhança e atinge seu maior valor quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, obtém-se a log-verossimilhança perfilada

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{T}}{n} \right) \right] \right\}, \tag{10.42}$$

em que C não depende de Σ .

Desconsiderando a constante C , maximizar Equação 10.42 equivale a minimizar

$$\frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Essa expressão possui exatamente a forma do critério estudado na Proposição 7.14, com

$$\mathbf{G} = \mathbf{T}.$$

Assim, quando $\mathbf{T} \succ \mathbf{0}$, aquele resultado pode ser aplicado diretamente para obter o minimizador.

Proposição 10.3 (Estimadores de máxima verossimilhança no modelo normal). *No evento amostral em que o máximo da verossimilhança existe, os estimadores no modelo normal multivariado são*

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}} \quad (10.43)$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}. \quad (10.44)$$

O resultado considera

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, o máximo existe e é único quando

$$\text{posto}(\mathbf{T}) = p,$$

e, nesse caso,

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}}$$

e

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

i Demonstração

A maximização em relação a μ decorre de Equação 10.41. Como

$$\Sigma^{-1} \succ \mathbf{0},$$

tem-se

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente em

$$\mu = \bar{\mathbf{x}}.$$

Para a maximização em relação a Σ , a log-verossimilhança perfilada na Equação 10.42 mostra que é equivalente minimizar

$$Q(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{T}).$$

Sob a hipótese

$$\text{posto}(\mathbf{T}) = p,$$

tem-se

$$\mathbf{T} \succ \mathbf{0}.$$

Aplicando Proposição 7.14 com $\mathbf{G} = \mathbf{T}$, o minimizador único é

$$\Sigma = \frac{\mathbf{T}}{n}.$$

Logo,

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{T}}{n}.$$

Pelo limite de posto da matriz SQPC estabelecido na Equação 8.60,

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1).$$

Consequentemente, uma condição necessária para posto completo é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois as colunas da matriz centralizada ainda podem ser linearmente dependentes. Sob uma distribuição normal multivariada não singular e

$$n \geq p + 1,$$

a condição

$$\text{posto}(\mathbf{T}) = p$$

ocorre quase certamente.

Se $\mathbf{T}$ é singular, a verossimilhança não possui máximo no espaço

$$\{\Sigma : \Sigma \succ \mathbf{0}\}.$$

De fato, pelo Teorema 5.4, escreva

$$\mathbf{T} = \mathbf{Q} \text{diag}(t_1, \dots, t_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$t_j > 0, \quad j = 1, \dots, r, \quad r < p.$$

Para $\varepsilon > 0$, considere

$$\Sigma_\varepsilon = \mathbf{Q} \text{diag}\left(\frac{t_1}{n}, \dots, \frac{t_r}{n}, \varepsilon, \dots, \varepsilon\right) \mathbf{Q}^\top.$$

Então,

$$\text{tr}(\Sigma_\varepsilon^{-1} \mathbf{T}) = nr,$$

enquanto

$$\log \det(\Sigma_\varepsilon) \rightarrow -\infty$$

quando

$$\varepsilon \rightarrow 0.$$

Consequentemente, a log-verossimilhança cresce sem limite ao longo dessa sequência, e o máximo não é atingido no espaço das matrizes positivas definidas.

A matriz

$$\frac{\mathbf{T}}{n}$$

continua sendo bem definida e positiva semidefinida e coincide com o estimador obtido pelo método dos momentos. Quando essa matriz é singular, ela não constitui o estimador de máxima verossimilhança no modelo cujo espaço paramétrico exige

$$\Sigma \succ \mathbf{0}.$$

Quando o máximo existe, o estimador de Σ utiliza o divisor n . Mais adiante será mostrado que esse estimador é viesado para Σ e que o divisor $n - 1$ produz o estimador não viesado usual.

O modelo normal mostrou um caso em que método dos momentos e máxima verossimilhança conduzem às mesmas expressões para μ e Σ . Essa coincidência, porém, é específica do modelo considerado. Retornando à comparação geral entre os dois princípios de construção, suas relações com as propriedades estudadas anteriormente podem ser resumidas da seguinte forma:

Tabela 10.1: Relação entre os métodos de estimação e as propriedades estudadas na seção anterior.

Propriedade	Método dos momentos	Máxima verossimilhança
Não viesamento em amostras finitas	Não é garantido pelo método	Não é garantido pelo método
Consistência	Pode ser obtida sob condições de convergência, identificação e continuidade	Pode ser obtida sob condições de regularidade e identificação
Eficiência em amostras finitas	Não é garantida	Não é garantida
Eficiência assintótica	Não é uma propriedade geral do método	Pode ocorrer sob condições de regularidade
Suficiência	Não é garantida pelo método	Não é garantida apenas pela maximização
Equivariância sob transformações dos dados	Depende do estimador e da transformação	Depende do estimador e da transformação
Invariância sob funções do parâmetro	Não é uma propriedade geral do método	É uma propriedade estrutural da máxima verossimilhança, quando o estimador existe
Robustez	Não é garantida	Não é garantida

A Tabela 10.1 distingue propriedades que decorrem da própria construção do método daquelas que exigem hipóteses adicionais sobre o modelo, a amostra ou o estimador específico.

10.3.3 Invariância da máxima verossimilhança

A máxima verossimilhança possui uma propriedade que permite estimar funções do parâmetro sem realizar uma nova maximização desde o início (Casella; Berger, 2002).

Considere uma função

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e defina

$$\psi = g(\theta).$$

Para cada

$$\psi \in \Psi,$$

defina a verossimilhança perfilada por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.45)$$

A função g não precisa ser injetiva, contínua ou monótona para a propriedade de invariância apresentada a seguir.

Proposição 10.4 (Invariância da máxima verossimilhança). *Considere*

$$g : \Theta \longrightarrow \Psi, \quad \Psi = g(\Theta),$$

e suponha que

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta).$$

Então

$$g(\hat{\theta}_{\text{MV}}) \in \arg \max_{\psi \in \Psi} L_g(\psi).$$

Portanto,

$$\widehat{\psi}_{\text{MV}} = g(\widehat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de

$$\psi = g(\theta).$$

i Demonstração

Defina

$$\widehat{\psi} = g(\widehat{\theta}_{\text{MV}}).$$

Como a fibra

$$\{\theta \in \Theta : g(\theta) = \widehat{\psi}\}$$

contém $\widehat{\theta}_{\text{MV}}$, tem-se

$$L_g(\widehat{\psi}) = L(\widehat{\theta}_{\text{MV}}).$$

Nenhum outro valor de ψ pode apresentar verossimilhança perfilada superior, pois isso implicaria a existência de algum θ cuja verossimilhança superasse o máximo global. Portanto,

$$\widehat{\psi} = g(\widehat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de ψ .

A invariância da máxima verossimilhança deve ser distinguida da equivariância.

- **Equivariância** relaciona uma transformação dos dados à transformação correspondente do estimador.
- **Invariância da máxima verossimilhança** aplica uma função do parâmetro ao estimador de máxima verossimilhança já obtido.

Considere a matriz de correlações populacional definida na Definição 8.5:

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Quando o estimador de máxima verossimilhança de Σ existe e possui diagonal positiva, a invariância fornece

$$\widehat{\mathcal{R}}_{\text{MV}} = \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2} \widehat{\Sigma}_{\text{MV}} \widehat{\mathbf{D}}_{\Sigma, \text{MV}}^{-1/2}. \quad (10.46)$$

Como correlações são preservadas por mudanças positivas de escala, conforme Equação 8.25, o fator comum que distingue as matrizes de covariâncias com divisores n e $n - 1$ se cancela na padronização. Assim, a matriz na Equação 10.46 coincide com a matriz de correlações calculada a partir da covariância amostral com divisor $n - 1$.

A propriedade pode ser aplicada também a funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma)$$

e, quando o estimador é positivo definido,

$$\Sigma^{-1}.$$

A invariância é uma propriedade de otimização. Ela não implica ausência de viés, consistência automática ou estabilidade numérica. Em particular, a inversão de uma matriz estimada mal condicionada pode amplificar pequenas perturbações.

Os dois métodos apresentados produzem, no modelo normal, o mesmo estimador para μ e a mesma matriz com divisor n para Σ . A seção seguinte examina primeiro o vetor de médias amostrais e suas propriedades.

10.4 Estimação do vetor de médias

O vetor de médias populacional μ , definido na Equação 8.1, descreve a localização da população em $\mathbb{R}^p$. A seção anterior mostrou que o método dos momentos e, sob o modelo normal multivariado, a máxima verossimilhança conduzem ao vetor de médias amostrais como estimador de μ . Nesta seção, esse estimador será estudado quanto às propriedades apresentadas anteriormente.

Considere a amostra aleatória multivariada definida na Equação 10.1 e suponha que

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n.$$

Os resultados sobre esperança, variabilidade, erro quadrático médio e consistência utilizam a independência entre as unidades amostrais e os momentos indicados acima. A normalidade

multivariada será necessária apenas quando o vetor de médias amostrais for interpretado como estimador de máxima verossimilhança no modelo normal.

10.4.1 Vetor de médias amostrais

Retomando a Equação 10.8, o vetor de médias amostrais é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

com

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.47)$$

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n. \quad (10.48)$$

Após a observação dos dados,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.49)$$

Pelo método dos momentos, a Equação 10.30 fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}.$$

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança existe, a Equação 10.43 fornece

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}.$$

Portanto,

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}. \quad (10.50)$$

A mesma estatística é, portanto, obtida por dois princípios de construção diferentes. A partir deste ponto, o interesse recai sobre as propriedades de $\bar{\mathbf{X}}$ como estimador de μ . Essas propriedades não decorrem do fato de o estimador ter sido obtido pelo método dos momentos ou pela máxima verossimilhança; elas serão verificadas diretamente sob as hipóteses declaradas nesta seção.

Além de sua interpretação como estimativa de μ , o valor observado $\bar{\mathbf{x}}$ possui uma caracterização geométrica: ele é o centroide da nuvem de pontos e minimiza a soma dos quadrados das distâncias euclidianas das observações a um centro comum.

Proposição 10.5 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor $\bar{\mathbf{x}}$ é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.51)$$

i Demonstração

Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Somando os quadrados das normas,

$$\begin{aligned} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\ &\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\ &\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \end{aligned}$$

Pela propriedade de centralização estabelecida na Equação 8.57,

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}.$$

Logo,

$$\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2. \quad (10.52)$$

A primeira parcela não depende de $\mathbf{m}$, e a segunda é não negativa e se anula somente em

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador.

A identidade Equação 10.52 será reutilizada na construção da matriz SQPC e na decomposição da dispersão em torno de centros distintos.

10.4.2 Não viesamento, variabilidade e erro quadrático médio

Proposição 10.6 (Esperança e covariância do vetor de médias amostrais). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\bar{\mathbf{X}}) = \mu \quad (10.53)$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \quad (10.54)$$

i Demonstração

Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right).$$

Como as unidades amostrais são independentes,

$$\text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right) = \sum_{i=1}^n \text{Cov}(\mathbf{X}_i) = n\Sigma.$$

Portanto,

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Consequentemente,

$$\text{Bias}(\bar{\mathbf{X}}) = \mathbf{0}.$$

O vetor de médias amostrais é, portanto, não viesado para μ .

Elemento a elemento,

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov}(\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

A matriz de covariâncias do erro de estimação é obtida multiplicando Σ pelo fator $1/n$. Assim, o aumento do tamanho amostral reduz a magnitude das variâncias e covariâncias, preservando a estrutura relativa determinada por Σ .

Como $\bar{\mathbf{X}}$ é não viesado, a decomposição do erro quadrático médio na Equação 10.18 reduz-se ao termo de variabilidade. Sob a perda quadrática euclidiana,

$$\begin{aligned} \text{EQM}(\bar{\mathbf{X}}) &= \text{tr}[\text{Cov}(\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr}(\Sigma). \end{aligned} \tag{10.55}$$

Como a variância total populacional foi definida na Equação 8.35 por

$$\text{tr}(\Sigma),$$

Equação 10.55 mostra que o erro quadrático médio sob perda euclidiana corresponde à variância total dividida pelo tamanho amostral.

Esses resultados estabelecem o não viesamento, a matriz de covariâncias e o erro quadrático médio de $\bar{\mathbf{X}}$. Eles não estabelecem, por si só, eficiência, pois essa propriedade exige comparar o estimador com procedimentos concorrentes segundo um critério especificado.

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

O correspondente estimador é

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Aplicando Proposição 8.1 ao vetor aleatório $\bar{\mathbf{X}}$, cuja média e matriz de covariâncias são dadas na Proposição 10.6,

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \boldsymbol{\mu},$$

e

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned} \tag{10.56}$$

Cada vetor $\mathbf{a}$ define uma combinação linear dos componentes de $\bar{\mathbf{X}}$ e, geometricamente, especifica uma direção juntamente com uma escala. Sua variabilidade é determinada por

$$\frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}.$$

Para comparar apenas direções, pode-se considerar vetores $\mathbf{a}$ de norma unitária. Nesse caso, direções com maior variância populacional também produzem maior variabilidade entre as estimativas das respectivas combinações lineares. Essa é a mesma interpretação utilizada anteriormente na comparação de matrizes de covariâncias pela ordem de Löwner.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Mais geralmente, para

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\boldsymbol{\mu}$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n}\mathbf{C}\Sigma\mathbf{C}^\top. \quad (10.57)$$

Essas expressões serão retomadas no estudo de contrastes e hipóteses lineares.

10.4.4 Consistência e equivariância

Proposição 10.7 (Consistência do vetor de médias amostrais). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

independentes, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

com segundos momentos finitos. Para dimensão p fixa,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad (10.58)$$

quando $n \rightarrow \infty$.

i Demonstração

Por Equação 10.55,

$$E \left[\|\bar{\mathbf{X}} - \mu\|^2 \right] = \frac{\text{tr}(\Sigma)}{n}.$$

Para $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$\begin{aligned} P(\|\bar{\mathbf{X}} - \mu\| > \varepsilon) &\leq \frac{E \left[\|\bar{\mathbf{X}} - \mu\|^2 \right]}{\varepsilon^2} \\ &= \frac{\text{tr}(\Sigma)}{n\varepsilon^2} \rightarrow 0. \end{aligned}$$

Logo,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

A prova utiliza segundos momentos finitos. Para dimensão fixa, a consistência também pode ser obtida por leis dos grandes números sob condições de integrabilidade mais gerais.

A equivariância do vetor de médias amostrais foi utilizada anteriormente como exemplo de Definição 10.9. O resultado é registrado a seguir para referência posterior.

Proposição 10.8 (Equivariância afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \tag{10.59}$$

Como, por Equação 8.17,

$$\mu_Y = C\mu + d,$$

a transformação aplicada ao estimador acompanha exatamente a transformação correspondente do parâmetro populacional.

Até este ponto, foram estabelecidas propriedades distintas do vetor de médias amostrais: ele é não viesado, possui matriz de covariâncias Σ/n , tem erro quadrático médio $\text{tr}(\Sigma)/n$ sob perda euclidiana, é consistente sob as condições especificadas e é equivariante em relação a transformações afins. Essas propriedades foram demonstradas para o estimador concreto e não decorrem simplesmente do método utilizado para construí-lo.

10.4.5 Variabilidade entre amostras

O vetor $\bar{\mathbf{X}}$ é uma estatística aleatória, enquanto $\bar{\mathbf{x}}$ é sua realização para uma amostra observada. Se o processo de amostragem fosse repetido, diferentes amostras produziriam diferentes valores de $\bar{\mathbf{x}}$. A distribuição desses valores corresponde à distribuição amostral do estimador.

A Figura 10.1 apresenta 250 realizações de $\bar{\mathbf{X}}$ para amostras de tamanhos 5 e 50 geradas de uma mesma distribuição normal bivariada. A normalidade é utilizada apenas para gerar a ilustração; o resultado na Equação 10.54 depende apenas da independência das unidades amostrais e da existência dos segundos momentos.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Para $n = 50$, a nuvem é mais concentrada do que para $n = 5$, em concordância com a redução da matriz de covariâncias por $1/n$.

A figura **não representa ainda um resultado sobre a forma exata da distribuição amostral de $\mathbf{X}$** . Essa distribuição será estudada no Capítulo 12.

O vetor de médias amostrais estima a localização da população. A estimação da dispersão exige considerar os desvios das observações em relação a esse centro. Esses desvios conduzem à matriz SQPC e aos estimadores da matriz de covariâncias.

10.5 SQPC e estimação da matriz de covariâncias

O vetor de médias amostrais descreve a localização da amostra. A estimação da matriz de covariâncias exige representar como as observações se dispersam conjuntamente em torno desse centro.

O Capítulo 8 definiu a matriz total de somas de quadrados e produtos cruzados (SQPC) na Definição 8.10 e a matriz de covariâncias observada na Definição 8.11. A seção sobre métodos




Figura 10.1: Vetores de médias amostrais obtidos em 250 amostras de uma distribuição normal bivariada, para tamanhos amostrais 5 e 50.

de estimação mostrou ainda que o método dos momentos conduz à matriz SQPC dividida por n e que, sob o modelo normal multivariado e as condições de existência do máximo, a máxima verossimilhança conduz à mesma expressão.

Nesta seção, a SQPC e as matrizes de covariâncias correspondentes passam a ser tratadas como estatísticas aleatórias. O objetivo é comparar os estimadores de Σ resultantes de diferentes critérios e estudar suas propriedades.

Considere a amostra aleatória multivariada definida na Equação 10.1, com unidades independentes e

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

e suponha que os segundos momentos sejam finitos.

10.5.1 SQPC como estatística aleatória

A matriz aleatória da amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Retomando a matriz de centralização utilizada na Equação 8.58,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

define-se a matriz aleatória centralizada por

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}. \quad (10.60)$$

Suas linhas são

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Definição 10.13 (Matriz SQPC amostral). A **matriz de somas de quadrados e produtos cruzados (SQPC) amostral** é a estatística

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.61)$$

Equivalentemente,

$$\mathbf{T} = \mathcal{X}_c^\top \mathcal{X}_c = \mathcal{X}^\top \mathbf{H}_n \mathcal{X}. \quad (10.62)$$

Após a observação da amostra,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.63)$$

A matriz $\mathbf{T}$ é exatamente a matriz SQPC observada definida na Definição 8.10 e escrita matricialmente na Equação 8.59. A diferença de notação é probabilística: $\mathbf{T}$ representa a estatística aleatória, enquanto $\mathbf{T}$ representa sua realização observada.

O elemento (j, k) de $\mathbf{T}$ é

$$\mathsf{T}_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.64)$$

Na diagonal,

$$\mathsf{T}_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a soma de quadrados centralizada da variável j . Fora da diagonal, T_{jk} é o produto cruzado centralizado entre as variáveis j e k .

Após a observação da amostra, os elementos correspondentes de $\mathbf{T}$ são denotados por t_{jk} .

10.5.2 Decomposição em torno de um centro arbitrário

A caracterização do centroide na Equação 10.52 mostrou, em termos de distâncias quadráticas, como a dispersão em torno de um centro arbitrário pode ser decomposta em uma parcela em torno da média amostral e outra associada ao deslocamento do centro. Para a estimação da matriz de covariâncias, utiliza-se a versão matricial dessa decomposição.

Proposição 10.9 (Decomposição da SQPC em torno de um centro arbitrário). *Para qualquer vetor fixo*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} & \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c}) (\mathbf{X}_i - \mathbf{c})^\top \\ &= \mathbf{T} + n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \quad (10.65)$$

i Demonstração

Escreva

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo na soma dos produtos externos, surgem quatro parcelas. Os dois termos cruzados contêm

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

e, portanto, se anulam. Restam

$$\mathbf{T}$$

e

$$n (\bar{\mathbf{X}} - \mathbf{c}) (\bar{\mathbf{X}} - \mathbf{c})^\top,$$

o que fornece Equação 10.65.

Para

$$\mathbf{c} = \mu,$$

obtém-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \\ = \mathbf{T} + n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top. \end{aligned} \tag{10.66}$$

Essa identidade separa a dispersão das observações em torno do centro populacional em duas parcelas: a dispersão em torno da média amostral e o afastamento entre a média amostral e a média populacional.

10.5.3 Esperança da SQPC

A identidade anterior permite obter a esperança de $\mathbf{T}$ sem assumir normalidade.

Proposição 10.10 (Esperança da SQPC). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{T}) = (n-1)\Sigma. \quad (10.67)$$

i Demonstração

Tomando esperança no lado esquerdo de Equação 10.66,

$$\begin{aligned} E \left[\sum_{i=1}^n (\mathbf{X}_i - \mu) (\mathbf{X}_i - \mu)^\top \right] &= \sum_{i=1}^n \Sigma \\ &= n\Sigma. \end{aligned}$$

Para a segunda parcela do lado direito,

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] = n \text{Cov}(\bar{\mathbf{X}}).$$

Por Equação 10.54,

$$n \text{Cov}(\bar{\mathbf{X}}) = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{T}) + \Sigma,$$

e segue que

$$E(\mathbf{T}) = (n-1)\Sigma.$$

O fator $n-1$ surge porque a SQPC utiliza desvios em relação à média estimada a partir da própria amostra. A centralização impõe

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0},$$

de modo que os n vetores de desvios satisfazem uma restrição linear. Assim, a centralização reduz em uma unidade a dimensão associada às variações em torno da média amostral.

A relação

$$E(\mathbf{T}) = (n-1)\Sigma$$

depende apenas da independência entre as unidades amostrais e da existência dos segundos momentos necessários; a normalidade multivariada não é exigida. A distribuição completa de $\mathbf{T}$ sob normalidade será tratada no Capítulo 12.

10.5.4 Estimador não viesado da matriz de covariâncias

Definição 10.14 (Matriz de covariâncias amostral). Para $n \geq 2$, define-se

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}, \quad (10.68)$$

em que $\mathbf{T}$ é definida na Definição 10.13.

Proposição 10.11 (Não viesamento da matriz de covariâncias amostral). Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são independentes, possuem segundos momentos finitos e satisfazem

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n,$$

então

$$E(\mathbf{S}) = \Sigma. \quad (10.69)$$

Portanto, $\mathbf{S}$ é um estimador não viesado de Σ .

i Demonstração

Por Equação 10.68 e Equação 10.67,

$$\begin{aligned} E(\mathbf{S}) &= \frac{1}{n-1} E(\mathbf{T}) \\ &= \frac{1}{n-1} (n-1)\Sigma \\ &= \Sigma. \end{aligned}$$

Após a observação, obtém-se a matriz de covariâncias observada definida na Definição 8.11:

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}. \quad (10.70)$$

Componente a componente,

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.71)$$

Para $j = k$,

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Assim,

$$\mathbf{S} = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}.$$

Após a observação da amostra, os elementos correspondentes de $\mathbf{S}$ são denotados por s_{jk} .

A divisão por $n-1$ corrige o viés associado à centralização pela média amostral. Ela não é escolhida para garantir semidefinição positiva. Como a matriz SQPC observada satisfaz

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c,$$

ela é uma matriz de Gram, conforme Definição 3.18, e suas propriedades de simetria e semidefinição positiva decorrem da Proposição 3.9. A multiplicação por $1/(n-1) > 0$ preserva essas propriedades em $\mathbf{S}$.

O não viesamento de $\mathbf{S}$ foi obtido utilizando apenas segundos momentos. Uma caracterização de sua variabilidade completa exigiria estudar

$$\text{Cov}[\text{vec}(\mathbf{S})],$$

utilizando o operador definido na Definição 7.9. De modo correspondente, o erro quadrático médio matricial sob a perda baseada na norma de Frobenius definida na Definição 6.7 envolveria

$$E[\|\mathbf{S} - \Sigma\|_F^2].$$

Essas quantidades dependem, em geral, de momentos de quarta ordem. Por isso, diferentemente do que ocorreu com o vetor de médias amostrais, os segundos momentos assumidos nesta seção não são suficientes para determinar a variabilidade completa ou o EQM de $\mathbf{S}$. Sob normalidade, resultados mais específicos serão obtidos a partir da distribuição amostral da matriz de covariâncias no Capítulo 12.

10.5.5 Estimador com divisor n : momentos e máxima verossimilhança

Pelo método dos momentos, a Equação 10.33 fornece

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado não singular e quando o máximo existe, a Equação 10.44 fornece a mesma estatística:

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Portanto, no modelo normal e nas condições de existência do estimador de máxima verossimilhança,

$$\widehat{\Sigma}_{\text{MM}} = \widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

tem-se, sob o modelo normal,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (10.72)$$

Por Equação 10.67,

$$E\left(\frac{\mathbf{T}}{n}\right) = \frac{n-1}{n} \Sigma.$$

Portanto, como estimador de Σ ,

$$\text{Bias}\left(\frac{\mathbf{T}}{n}\right) = -\frac{1}{n} \Sigma.$$

Esse resultado vale para o estimador pelo método dos momentos sem exigir normalidade. Sob o modelo normal e nas condições de existência do máximo, a mesma estatística é também o estimador de máxima verossimilhança. Nesse caso,

$$E\left(\widehat{\Sigma}_{\text{MV}}\right) = \frac{n-1}{n} \Sigma \quad (10.73)$$

e

$$\text{Bias}\left(\widehat{\Sigma}_{\text{MV}}\right) = -\frac{1}{n} \Sigma. \quad (10.74)$$

Assim, o viés é uma propriedade da estatística $\mathbf{T}/n$ como estimador de Σ , e não uma consequência do método utilizado para obtê-la.

A comparação entre

$$\frac{\mathbf{T}}{n} \quad \text{e} \quad \frac{\mathbf{T}}{n-1}$$

mostra novamente que o princípio utilizado para construir um estimador e suas propriedades estatísticas são questões distintas. A primeira matriz resulta diretamente do método dos momentos e, sob normalidade, também da máxima verossimilhança; a segunda utiliza a correção necessária para obter não viesamento.

Quando n aumenta,

$$\frac{n-1}{n} \rightarrow 1,$$

de modo que a diferença relativa entre os dois estimadores desaparece.

Dois divisores, dois critérios

A matriz

$$\frac{\mathbf{T}}{n}$$

surge como estimador de momentos e, sob o modelo normal e as condições de existência do máximo, como estimador de máxima verossimilhança.

A matriz

$$\frac{\mathbf{T}}{n-1}$$

é construída para satisfazer

$$E(\mathbf{S}) = \Sigma.$$

Nenhum dos dois divisores é universalmente “correto” sem especificar o critério de estimação.

Sob o modelo normal multivariado, Proposição 10.2 estabeleceu que

$$(\bar{\mathbf{X}}, \mathbf{T})$$

é suficiente para

$$(\mu, \Sigma).$$

Como, para n fixado,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é uma transformação bijetiva de $\mathbf{T}$, o par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

preserva a mesma informação sobre os parâmetros. Essa afirmação é conjunta: ela não significa que $\mathbf{S}$ isoladamente seja suficiente para (μ, Σ) .

10.5.6 Consistência dos estimadores de covariância

O não viesamento é uma propriedade para tamanho amostral fixo. A consistência descreve o comportamento quando n aumenta.

Proposição 10.12 (Consistência da matriz de covariâncias amostral). *Considere uma amostra aleatória i.i.d.*

$$\mathbf{X}_1, \dots, \mathbf{X}_n,$$

em que

$$\mathbf{X}_i \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu,$$

$$\text{Cov}(\mathbf{X}_i) = \Sigma,$$

e

$$E(\|\mathbf{X}_i\|^2) < \infty.$$

Se o número p de variáveis permanece fixo quando $n \rightarrow \infty$, então

$$\mathbf{S} \xrightarrow{P} \Sigma. \tag{10.75}$$

i Demonstração

Pela identidade

$$\frac{1}{n} \mathbf{T} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top, \quad (10.76)$$

a matriz com divisor n pode ser escrita como diferença entre o segundo momento amostral não central e o produto externo da média amostral.

Para cada par (j, k) , a condição de segundos momentos finitos implica

$$E(|X_j X_k|) < \infty.$$

Pela Lei dos Grandes Números,

$$\frac{1}{n} \sum_{i=1}^n X_{ij} X_{ik} \xrightarrow{P} E(X_j X_k),$$

e

$$\bar{X}_j \xrightarrow{P} \mu_j.$$

Logo, elemento a elemento,

$$\frac{1}{n} \mathbf{T} \xrightarrow{P} E(\mathbf{x} \mathbf{x}^\top) - \mu \mu^\top = \Sigma.$$

Como p é fixo,

$$\mathbf{S} = \frac{n}{n-1} \left(\frac{\mathbf{T}}{n} \right) \xrightarrow{P} \Sigma.$$

Pela mesma argumentação,

$$\hat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n} \xrightarrow{P} \Sigma \quad (10.77)$$

sempre que a expressão é considerada como estatística. No modelo normal positivo definido, sua interpretação como estimador de máxima verossimilhança requer adicionalmente a existência do máximo discutida anteriormente.

A consistência apresentada aqui corresponde ao regime clássico de **dimensão fixa**. Quando p aumenta com n , a convergência deve ser analisada segundo o regime dimensional e a norma de interesse.

10.5.7 Transformações, posto e singularidade

As propriedades algébricas da matriz SQPC observada decorrem de sua representação de Gram na Equação 8.59 e do limite de posto estabelecido na Equação 8.60. Como essas propriedades valem para cada realização da amostra, elas também caracterizam as estatísticas $\mathbf{T}$ e $\mathbf{S}$ amostra a amostra.

Transformações afins. A equivariância da matriz de covariâncias amostral foi utilizada anteriormente como exemplo de Definição 10.9. Para referência, se

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

então

$$\mathbf{T}_Y = \mathbf{C}\mathbf{T}_X\mathbf{C}^\top \quad (10.78)$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \quad (10.79)$$

A translação $\mathbf{d}$ desaparece pela centralização. Como a matriz populacional satisfaz, pela Proposição 8.6,

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top,$$

a transformação da estatística acompanha exatamente a transformação correspondente do parâmetro.

Simetria e semidefinição positiva. Pela representação de Gram na Equação 8.59 e pelas propriedades de matrizes de Gram na Proposição 3.9, para qualquer realização da amostra,

$$\mathbf{T} = \mathbf{T}^\top \quad \text{e} \quad \mathbf{T} \succeq \mathbf{0}.$$

Como

$$\mathbf{S} = \frac{1}{n-1}\mathbf{T},$$

a matriz $\mathbf{S}$ também é simétrica e positiva semidefinida. Assim, em aritmética exata, o estimador não produz autovalores negativos.

Variância de combinações lineares. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{X}_i - \bar{\mathbf{X}})]^2. \quad (10.80)$$

A forma quadrática é a variância amostral da variável projetada

$$\mathbf{a}^\top \mathbf{X}.$$

Portanto,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0$$

se, e somente se, os valores observados da combinação linear $\mathbf{a}^\top \mathbf{X}_i$ são constantes na amostra.

Posto. Pelo resultado estabelecido na Equação 8.60, para qualquer realização da amostra,

$$\text{posto}(\mathbf{T}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n-1). \quad (10.81)$$

Como $\mathbf{S}$ é obtida por multiplicação de $\mathbf{T}$ por uma constante positiva,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{T}). \quad (10.82)$$

Uma condição necessária para

$$\mathbf{S} \succ \mathbf{0}$$

é, portanto,

$$n \geq p+1.$$

Mesmo quando essa desigualdade é satisfeita, a definição positiva depende de as colunas de $\mathbf{X}_c$ possuírem posto completo.

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e $\mathbf{S}$ é necessariamente singular.

A singularidade significa que existe algum vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p$$

tal que

$$\mathbf{S}\mathbf{a} = \mathbf{0}.$$

Equivalentemente,

$$\mathbf{a}^\top \mathbf{S}\mathbf{a} = 0,$$

de modo que a combinação linear correspondente apresenta variância amostral nula.

Inversão. Quando

$$\mathbf{S} \succ \mathbf{0},$$

sua inversa existe e pode ser utilizada em formas quadráticas e métricas baseadas na covariância estimada.

Se $\mathbf{S}$ é singular, $\mathbf{S}^{-1}$ não existe. A utilização de pseudoinversas ou de estimadores regularizados corresponde a escolhas distintas e será discutida na seção de aprofundamento.

Forma quadrática com covariância estimada

A distância de Mahalanobis foi definida na Definição 8.9 utilizando os parâmetros populacionais. Sob normalidade, Proposição 9.8 estabelece a distribuição qui-quadrado da forma correspondente quando μ e Σ são conhecidos.

Substituir esses parâmetros por quantidades estimadas, como $\bar{\mathbf{x}}$ e $\mathbf{S}$, produz outra estatística. Portanto, a distribuição

$$D_M^2 \sim \chi_p^2$$

não pode ser transferida diretamente para uma forma quadrática construída com estimadores.

As distribuições apropriadas para estatísticas que envolvem parâmetros estimados serão estudadas no Capítulo 12.

Até este ponto, foram estabelecidas propriedades distintas dos estimadores de Σ . A matriz $\mathbf{S} = \mathbf{T}/(n - 1)$ é não viesada, enquanto $\mathbf{T}/n$ é viesada em amostras finitas, embora seja obtida pelo método dos momentos e, sob normalidade e existência do máximo, também pela máxima verossimilhança. Ambos os estimadores são consistentes no regime de dimensão fixa sob as condições especificadas. Além disso, a matriz de covariâncias amostral é equivariante sob transformações afins, positiva semidefinida em cada realização e possui posto limitado por $\min(p, n - 1)$.

Esses resultados não estabelecem eficiência em amostras finitas, e a avaliação completa da variabilidade ou do erro quadrático médio matricial exige hipóteses adicionais sobre momentos de ordem superior.

O posto e a estabilidade numérica da matriz de covariâncias amostral tornam-se especialmente relevantes quando p não é pequeno em relação a n . Antes de discutir esse regime, serão construídos os estimadores correspondentes para covariâncias entre blocos e para correlações.

10.6 Estimação de covariâncias cruzadas e correlações

Em diversos problemas multivariados, as variáveis são organizadas em blocos observados sobre as mesmas unidades amostrais. As covariâncias cruzadas descrevem associações lineares entre variáveis pertencentes a blocos distintos, enquanto as correlações removem as escalas marginais dessas associações.

O Capítulo 8 definiu a matriz de covariâncias cruzadas populacional na Definição 8.3, a matriz de covariâncias cruzadas observada na Definição 8.13 e a matriz de correlações observada na Definição 8.12. Nesta seção, os objetos correspondentes são tratados como estatísticas aleatórias e utilizados na estimação de suas contrapartes populacionais.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q.$$

A matriz de covariâncias cruzadas populacional

$$\Sigma_{XY}$$

foi definida na Definição 8.3. Sua orientação satisfaz, conforme Equação 8.13,

$$\Sigma_{YX} = \Sigma_{XY}^\top.$$

Para o vetor conjunto

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

a estrutura em blocos da matriz de covariâncias segue Equação 8.15. Neste capítulo, será denotada por

$$\Sigma_{\text{conj}} = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.83)$$

Para estimar Σ_{XY} , é necessária uma amostra **pareada**:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ correspondem à mesma unidade amostral. Alterar a correspondência entre as linhas dos dois blocos modifica as covariâncias cruzadas.

Organize as observações nas matrizes aleatórias

$$\mathcal{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} \in \mathbb{R}^{n \times q}.$$

Após a centralização,

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.15 (Matriz de somas de produtos cruzados entre blocos). A **matriz de somas de produtos cruzados entre os dois blocos** é

$$\mathbf{T}_{XY} = \mathbf{x}_c^\top \mathbf{y}_c. \quad (10.84)$$

Equivalentemente,

$$\mathbf{T}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (10.85)$$

Após a observação,

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.86)$$

A inversão da ordem dos blocos produz

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top$$

e

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 10.16 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$, a matriz de covariâncias cruzadas amostral é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}, \quad (10.87)$$

em que $\mathbf{T}_{XY}$ é a matriz de somas de produtos cruzados entre os blocos definida na Definição 10.15.

Após a observação da amostra, obtém-se a matriz de covariâncias cruzadas observada definida na Definição 8.13:

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.88)$$

Seu elemento (j, k) é

$$s_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.89)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{S}_{XY}$ é denotado por $s_{X_j Y_k}$.

Proposição 10.13 (Não viesamento da covariância cruzada amostral). *Considere uma amostra pareada i.i.d. do vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix},$$

com segundos momentos finitos. Então,

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.90)$$

i Demonstração

A matriz de covariâncias amostral do vetor conjunto é

$$\mathbf{S}_{\text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}.$$

Pelo não viesamento da matriz de covariâncias amostral estabelecido na Equação 10.69,

$$E(\mathbf{S}_{\text{conj}}) = \Sigma_{\text{conj}}.$$

A igualdade entre os blocos superiores direitos fornece

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}.$$

O método dos momentos aplicado à matriz de covariâncias do vetor conjunto conduz ao estimador

$$\widehat{\Sigma}_{\text{conj}, \text{MM}} = \frac{1}{n} \mathbf{T}_{\text{conj}}.$$

Consequentemente, o bloco correspondente à covariância cruzada é

$$\widehat{\Sigma}_{XY, \text{MM}} = \frac{1}{n} \mathbf{T}_{XY}.$$

Sob normalidade conjunta não singular,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_{\text{conj}} \right),$$

o estimador de máxima verossimilhança da matriz conjunta de covariâncias, quando existe, utiliza também o divisor n . Portanto,

$$\widehat{\Sigma}_{XY,MM} = \widehat{\Sigma}_{XY,MV} = \frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY}. \quad (10.91)$$

Se

$$n \geq p + q + 1$$

e a distribuição normal conjunta é não singular, a matriz SQPC do vetor conjunto possui posto $p + q$ quase certamente. Nessas condições, o estimador positivo definido de máxima verossimilhança da matriz conjunta existe quase certamente.

Por Equação 10.90,

$$E \left(\frac{1}{n} \mathbf{T}_{XY} \right) = \frac{n-1}{n} \Sigma_{XY}.$$

Assim,

$$\text{Bias} \left(\frac{1}{n} \mathbf{T}_{XY} \right) = -\frac{1}{n} \Sigma_{XY}.$$

Esse viés pertence à estatística $\mathbf{T}_{XY}/n$ como estimador de Σ_{XY} e não depende da hipótese de normalidade. A normalidade é necessária apenas para interpretar essa mesma estatística como o bloco cruzado do estimador de máxima verossimilhança da matriz conjunta.

A consistência também pode ser obtida diretamente a partir da matriz de covariâncias do vetor conjunto. Sob as condições da Proposição 10.12, aplicadas ao vetor de dimensão $p + q$,

$$\mathbf{S}_{\text{conj}} \xrightarrow{P} \Sigma_{\text{conj}}.$$

Consequentemente, cada um de seus blocos converge para o bloco populacional correspondente e, em particular,

$$\mathbf{S}_{XY} \xrightarrow{P} \Sigma_{XY}. \quad (10.92)$$

Como

$$\frac{1}{n} \mathbf{T}_{XY} = \frac{n-1}{n} \mathbf{S}_{XY},$$

também se obtém

$$\frac{1}{n} \mathbf{T}_{XY} \xrightarrow{P} \Sigma_{XY}.$$

A transformação da covariância cruzada amostral acompanha a transformação do parâmetro populacional estabelecida na Equação 8.19. Se

$$\mathbf{U} = \mathbf{C}\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{D}\mathbf{Y} + \mathbf{d},$$

então

$$\mathbf{S}_{UV} = \mathbf{C}\mathbf{S}_{XY}\mathbf{D}^\top. \quad (10.93)$$

Portanto, $\mathbf{S}_{XY}$ é equivariante em relação a essas transformações afins dos dois blocos. Os vetores de localização $\mathbf{c}$ e $\mathbf{d}$ desaparecem após a centralização.

Para

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

segue que

$$\mathbf{S}_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.94)$$

Diferentemente de uma matriz de covariâncias de um único vetor, $\mathbf{S}_{XY}$ é, em geral, retangular quando $p \neq q$. Mesmo quando $p = q$, ela não precisa ser simétrica. Os dois blocos satisfazem

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top.$$

Por isso, propriedades como simetria e semidefinição positiva não devem ser atribuídas isoladamente à matriz de covariâncias cruzadas. Essas propriedades pertencem à matriz de covariâncias do vetor conjunto, da qual $\mathbf{S}_{XY}$ é um bloco.

O posto satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.95)$$

Esse limite restringirá posteriormente técnicas que utilizam simultaneamente dois conjuntos de variáveis.

10.6.2 Matriz de correlações amostral

A matriz de correlações amostral é obtida pela padronização das covariâncias pelas variâncias marginais correspondentes.

Considere

$$\mathbf{S} = (S_{jk})$$

e defina a matriz diagonal das variâncias amostrais por

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Definição 10.17 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas, a matriz de correlações amostral é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.96)$$

em que

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

Após a observação da amostra, obtém-se a matriz $\mathbf{R}$ definida na Definição 8.12:

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.97)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) da estatística aleatória $\mathbf{R}$ é

$$R_{jk} = \frac{S_{jk}}{\sqrt{S_{jj}S_{kk}}}. \quad (10.98)$$

Após a observação da amostra, o elemento correspondente de $\mathbf{R}$ é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}.$$

Consequentemente,

$$R_{jj} = 1$$

e, para a realização observada,

$$r_{jj} = 1.$$

A interpretação geométrica da correlação observada foi estabelecida na Equação 8.71, que identifica r_{jk} com o cosseno do ângulo entre as colunas centralizadas e padronizadas. Aqui, a ênfase recai sobre $\mathbf{R}$ como estatística utilizada para estimar a matriz populacional $\mathcal{R}$.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Se

$$S_{jj} = 0$$

a correspondente padronização não existe.

10.6.3 Propriedades estruturais

Proposição 10.14 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, $\mathbf{R}$ é:*

1. *simétrica;*
2. *positiva semidefinida;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.99)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.100)$$

i Demonstração

A simetria decorre da simetria de $\mathbf{S}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{R} \mathbf{a} &= (\mathbf{D}_S^{-1/2} \mathbf{a})^\top \mathbf{S} (\mathbf{D}_S^{-1/2} \mathbf{a}) \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{R}$ é positiva semidefinida.

A diagonal unitária decorre de

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1.$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definitude positiva.

Uma matriz simétrica com diagonal unitária e elementos em $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A positividade semidefinida também é necessária.

Como

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}),$$

uma condição necessária para definitude positiva é

$$n \geq p + 1.$$

Essa condição não é suficiente para uma amostra arbitrária, pois ainda podem existir dependências lineares entre as colunas centralizadas.

Quando

$$p \geq n,$$

a matriz de correlações, se definida, é necessariamente singular.

Para uma realização observada,

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.101)$$

A padronização remove as escalas marginais, mas não altera o posto.

A matriz de correlações populacional é uma função da matriz de covariâncias,

$$\mathcal{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}.$$

Substituindo Σ pelo estimador de momentos

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T},$$

obtem-se um estimador por substituição de $\mathcal{R}$. Como o fator comum $1/n$ aparece tanto nas covariâncias quanto nas variâncias marginais, ele se cancela na padronização. A matriz resultante é

$$\mathbf{R}.$$

Assim, $\mathbf{R}$ pode ser obtida pela padronização do estimador de momentos de Σ .

Sob o modelo normal multivariado, quando o estimador de máxima verossimilhança de Σ existe,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

Novamente, o fator comum $(n-1)/n$ cancela-se na transformação de covariâncias em correlações. Pela Proposição 10.4,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}. \quad (10.102)$$

Assim, no modelo normal considerado e nas condições de existência do máximo, a mesma matriz de correlações amostral também é obtida pela máxima verossimilhança.

Essa coincidência não implica não viesamento. Em geral,

$$E(\mathbf{R}_{jk}) \neq \rho_{jk}.$$

A razão é que a correlação amostral é uma função não linear das variâncias e covariâncias amostrais.

Por outro lado, se

$$\mathbf{S} \xrightarrow{P} \Sigma$$

e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

Considere a transformação

$$g(\mathbf{A}) = \mathbf{D}_A^{-1/2} \mathbf{A} \mathbf{D}_A^{-1/2},$$

em que

$$\mathbf{D}_A = \text{diag}(a_{11}, \dots, a_{pp}).$$

Essa transformação converte uma matriz de covariâncias em sua matriz de correlações e é contínua quando os elementos de sua diagonal são positivos.

O **teorema do mapeamento contínuo** estabelece que, se uma sequência de estatísticas converge em probabilidade e uma função é contínua no limite, então a sequência obtida pela aplicação dessa função também converge em probabilidade (Vaart, 1998).

Como

$$\mathbf{S} \xrightarrow{P} \Sigma$$

no regime de dimensão fixa e

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

a transformação g é contínua em Σ . Portanto,

$$g(\mathbf{S}) \xrightarrow{P} g(\Sigma).$$

Como

$$g(\mathbf{S}) = \mathbf{R}$$

e

$$g(\Sigma) = \mathcal{R},$$

segue que

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \quad (10.103)$$

Portanto, a matriz de correlações amostral é consistente para a matriz de correlações populacional, embora suas entradas possam ser viesadas em amostras finitas.

10.6.4 Transformações de localização e escala

O efeito populacional das mudanças de localização e escala sobre a correlação foi estabelecido na Equação 8.25. Para uma realização observada, considere

$$y_{ij} = a_j + b_j x_{ij}, \quad b_j \neq 0.$$

A localização a_j desaparece após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \operatorname{sgn}(b_j) \operatorname{sgn}(b_k) r_{X_j X_k}. \quad (10.104)$$

Fatores de escala positivos preservam a correlação. Quando apenas um dos fatores b_j e b_k é negativo, o sinal da correlação é invertido. Mudanças de localização não alteram a correlação.

Em forma matricial, para

$$\mathbf{Y} = \mathbf{X} \mathbf{D}_b + \mathbf{1}_n \mathbf{a}^\top,$$

com

$$\mathbf{D}_b = \operatorname{diag}(b_1, \dots, b_p),$$

defina

$$\mathbf{D}_{\operatorname{sgn}} = \operatorname{diag}[\operatorname{sgn}(b_1), \dots, \operatorname{sgn}(b_p)].$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\text{sgn}} \mathbf{R}_X \mathbf{D}_{\text{sgn}}. \quad (10.105)$$

Se todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X.$$

Para dois blocos, defina as matrizes diagonais aleatórias

$$\mathbf{D}_X = \text{diag} (S_{X_1 X_1}, \dots, S_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (S_{Y_1 Y_1}, \dots, S_{Y_q Y_q}).$$

Quando todas as variâncias amostrais envolvidas são positivas, define-se a matriz de correlações cruzadas amostral por

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2}. \quad (10.106)$$

Seu elemento (j, k) é

$$R_{X_j Y_k} = \frac{S_{X_j Y_k}}{\sqrt{S_{X_j X_j} S_{Y_k Y_k}}}.$$

Após a observação da amostra,

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2},$$

em que

$$\mathbf{D}_X = \text{diag} (s_{X_1 X_1}, \dots, s_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (s_{Y_1 Y_1}, \dots, s_{Y_q Y_q}).$$

Seu elemento observado é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}}.$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top$$

e, após a observação,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top.$$

A matriz de correlações do vetor conjunto assume a forma

$$\mathbf{R}_{\text{conj}} = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix}. \quad (10.107)$$

Até este ponto, foram estabelecidas propriedades distintas das estatísticas utilizadas para representar associações entre variáveis. A matriz $\mathbf{S}_{XY}$ é não viesada e consistente para Σ_{XY} sob as condições especificadas, enquanto $\mathbf{T}_{XY}/n$ apresenta o mesmo fator de viés observado na estimação da matriz de covariâncias e, sob normalidade conjunta e existência do máximo, também corresponde ao estimador de máxima verossimilhança do bloco cruzado.

A matriz de correlações amostral $\mathbf{R}$ remove as escalas marginais, preserva a semidefinição positiva e o posto da matriz de covariâncias quando está definida, é consistente no regime de dimensão fixa, mas suas entradas não são, em geral, estimadores não viesados das correlações populacionais. Sob o modelo normal, a invariância da máxima verossimilhança conduz à mesma matriz $\mathbf{R}$.

As matrizes de covariâncias e correlações cruzadas serão utilizadas posteriormente em métodos que relacionam dois conjuntos de variáveis. O objetivo neste capítulo é estabelecer sua estimação e as propriedades necessárias para esses desenvolvimentos.

A próxima seção examina situações em que a dimensão, a redundância ou a sensibilidade das estatísticas clássicas dificultam a estimação da matriz de covariâncias.

10.7 Aprofundamento: dimensão, estabilidade e extensões da estimação

Esta seção examina situações em que a dimensão, o condicionamento ou a sensibilidade das estatísticas amostrais exigem cuidados adicionais. Os resultados anteriores trataram dos estimadores clássicos da média e da matriz de covariâncias. A regularização e a estimação robusta modificam esses procedimentos para tratar, respectivamente, problemas de instabilidade e de sensibilidade.

Uma matriz de covariâncias não estruturada de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. Assim, o número de parâmetros de dispersão a estimar cresce quadraticamente com p , enquanto o número de unidades amostrais permanece igual a n .

Regularização e robustez respondem a problemas diferentes. A regularização procura reduzir a instabilidade associada à dimensão, à redundância, ao tamanho amostral ou ao mau condicionamento. A estimação robusta procura reduzir a sensibilidade do procedimento a determinadas formas de contaminação ou desvios do modelo. As duas abordagens podem ser combinadas, mas tratam de problemas distintos.

10.7.1 Relação entre p e n

O limite de posto estabelecido na Equação 10.81,

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1),$$

permite distinguir diferentes regimes dimensionais.

Dimensão fixa. No regime clássico,

$$p$$

permanece fixo enquanto

$$n \rightarrow \infty.$$

Sob as condições da Proposição 10.12,

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Como p é fixo, a convergência dos elementos implica convergência em qualquer norma matricial sobre $\mathbb{R}^{p \times p}$, pois todas essas normas são equivalentes em dimensão finita.

Dimensão crescente. Quando

$$p = p_n$$

também aumenta com n , os resultados obtidos para dimensão fixa não podem ser transferidos automaticamente. Um regime de referência é

$$\frac{p_n}{n} \rightarrow c, \quad 0 < c < 1.$$

Nesse regime, a matriz de covariâncias amostral pode possuir posto completo e, ainda assim, apresentar elevada variabilidade em seu espectro.

O controle dos erros de estimação elemento a elemento não garante, por si só, controle do erro matricial em norma espectral. Consequentemente, boa estimação das covariâncias individuais não assegura automaticamente boa estimação dos autovalores, autovetores, determinante, inversa ou formas quadráticas que dependem da matriz inversa.

Além disso, o número de covariâncias fora da diagonal é

$$\frac{p(p-1)}{2},$$

e todas são estimadas a partir das mesmas n unidades.

Não existe um valor universal de p/n que separe matrizes estáveis e instáveis. O comportamento depende também da estrutura de Σ , da separação entre seus autovalores, da distribuição populacional e da função da matriz utilizada posteriormente.

Dimensão maior ou igual ao tamanho amostral. Se

$$p \geq n,$$

Equação 10.81 implica

$$\text{posto}(\mathbf{S}) \leq n - 1 < p.$$

Logo, a matriz de covariâncias amostral é necessariamente singular.

Essa singularidade não implica singularidade de Σ . Ela pode decorrer exclusivamente do número limitado de direções amostrais disponíveis após a centralização.

Posto amostral e posto populacional

Quando

$$p \geq n,$$

$\mathbf{S}$ é singular por construção, mesmo que a matriz populacional satisfaça

$$\Sigma \succ \mathbf{0}.$$

A singularidade da matriz amostral, portanto, não constitui evidência suficiente de singularidade da matriz de covariâncias populacional.

10.7.2 Condicionamento e inversão

Considere uma realização positiva definida,

$$\mathbf{S} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p),$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

A inversa é

$$\mathbf{S}^{-1} = \mathbf{Q}\mathbf{\Lambda}^{-1}\mathbf{Q}^\top.$$

Autovalores pequenos de $\mathbf{S}$ tornam-se pesos elevados em $\mathbf{S}^{-1}$.

O número de condição espectral foi definido na Definição 6.9. Para uma matriz simétrica positiva definida,

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.108)$$

Quanto maior essa razão, maior é a diferença entre as escalas espectrais extremas da matriz. Quando

$$\ell_{\min}(\mathbf{S}) \longrightarrow 0,$$

tem-se

$$\kappa_2(\mathbf{S}) \longrightarrow \infty.$$

Se $\mathbf{S}$ é singular, o número de condição associado à inversão é infinito. Portanto, invertibilidade e bom condicionamento são propriedades distintas.

O mau condicionamento torna a inversa sensível a erros de estimação: pequenas perturbações em $\mathbf{S}$ podem produzir alterações acentuadas em

$$\mathbf{S}^{-1}.$$

O determinante também depende de todo o espectro:

$$\det(\mathbf{S}) = \prod_{j=1}^p \ell_j.$$

Já a estabilidade dos autovetores depende não somente da magnitude dos autovalores, mas também de sua separação. Autovalores muito próximos podem produzir direções individuais sensíveis a pequenas perturbações.

Considere, por exemplo, a contraparte amostral da forma quadrática utilizada na distância de Mahalanobis definida na Definição 8.9:

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Nas coordenadas dos autovetores de $\mathbf{S}$,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Assim, erros na estimação de autovalores pequenos podem ser amplificados pela inversão, pois essas direções recebem pesos proporcionais a $1/\ell_j$.

Inversão computacional

A existência de $\mathbf{S}^{-1}$ não significa que seja necessário formá-la explicitamente.

Quando o objetivo é calcular

$$\mathbf{S}^{-1}\mathbf{b},$$

é preferível, em geral, resolver o sistema

$$\mathbf{S}\mathbf{x} = \mathbf{b}.$$

Essa escolha não elimina o mau condicionamento, mas evita uma inversão explícita desnecessária.

10.7.3 Regularização

A regularização substitui a matriz de covariâncias amostral por um estimador que combina $\mathbf{S}$ com restrições ou valores de referência previamente especificados. O objetivo pode ser reduzir variabilidade, melhorar o condicionamento ou produzir uma matriz invertível.

Uma classe simples combina $\mathbf{S}$ com uma matriz-alvo (Ledoit; Wolf, 2004).

Definição 10.18 (Estimador de covariância por contração). Considere uma matriz-alvo fixada

$$\Gamma \in \mathbb{R}^{p \times p}, \quad \Gamma \succeq \mathbf{0},$$

e um peso

$$0 \leq \lambda \leq 1.$$

Define-se o estimador por contração

$$\widehat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \tag{10.109}$$

Para

$$\lambda = 0,$$

recupera-se $\mathbf{S}$. Para

$$\lambda = 1,$$

o estimador coincide com o alvo.

A contração geralmente introduz viés. Sua avaliação deve considerar conjuntamente viés e variabilidade por meio de uma função de perda e do risco correspondente.

A consistência também depende da forma como a regularização varia com o tamanho amostral. Se $\lambda \in (0, 1]$ e Γ são fixos e

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

então

$$\widehat{\Sigma}_\lambda \xrightarrow{P} (1 - \lambda)\Sigma + \lambda\Gamma.$$

Portanto, com $\lambda > 0$ fixo, o estimador não é, em geral, consistente para Σ . Se a matriz-alvo Γ é fixa e o peso passa a depender de n , com

$$\lambda_n \rightarrow 0,$$

então

$$\widehat{\Sigma}_{\lambda_n} = (1 - \lambda_n)\mathbf{S} + \lambda_n\Gamma \xrightarrow{P} \Sigma,$$

sempre que

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

Assim, nesse caso, a intensidade da regularização desaparece assintoticamente e a consistência da matriz de covariâncias amostral é preservada.

Em aplicações, o alvo e o peso podem ser estimados a partir dos próprios dados. Nesse caso,

$$\widehat{\Sigma}_{\widehat{\lambda}} = (1 - \widehat{\lambda})\mathbf{S} + \widehat{\lambda}\widehat{\Gamma}. \quad (10.110)$$

A aleatoriedade de $\widehat{\lambda}$ e de $\widehat{\Gamma}$ passa, então, a fazer parte das propriedades do estimador.

A matriz-alvo precisa ser compatível com as unidades e escalas das variáveis. Um alvo diagonal preserva as escalas marginais e reduz as covariâncias. Um alvo esférico $\tau\mathbf{I}_p$ pressupõe que uma escala comum possua interpretação. Para matrizes de correlações, a identidade $\mathbf{I}_p$ constitui uma escolha natural de referência. O alvo também pode representar relações previamente especificadas entre as variáveis, como covariâncias nulas ou uma estrutura de correlação definida antes da estimação.

A identidade $\mathbf{I}_p$ não é um alvo neutro para uma matriz de covariâncias quando as variáveis são medidas em unidades ou escalas distintas.

Um alvo esférico adaptado à escala observada pode utilizar

$$\hat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}), \quad (10.111)$$

levando a

$$\hat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\hat{\tau}\mathbf{I}_p. \quad (10.112)$$

Essa escolha pressupõe que uma variância média comum tenha significado para as variáveis consideradas. Além disso, a definitude positiva produzida pelo componente esférico exige $\hat{\tau} > 0$. Como $\mathbf{S} \succeq \mathbf{0}$, essa condição equivale a haver variabilidade amostral positiva em pelo menos uma direção.

Outro alvo é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(S_{11}, \dots, S_{pp})$$

com

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.113)$$

Nesse caso, as variâncias amostrais permanecem inalteradas e as covariâncias são multiplicadas por $1 - \lambda$.

Proposição 10.15 (Definitude positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\hat{\Sigma}_\lambda \succ \mathbf{0}. \quad (10.114)$$

i Demonstração

Para qualquer $\mathbf{a} \neq \mathbf{0}$,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} = (1 - \lambda) \mathbf{a}^\top \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^\top \Gamma \mathbf{a}.$$

A primeira parcela é não negativa e a segunda é estritamente positiva. Logo,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} > 0.$$

Com um alvo esférico,

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0,$$

e uma decomposição

$$\mathbf{S} = \mathbf{Q} \operatorname{diag} (\mathbf{L}_1, \dots, \mathbf{L}_p) \mathbf{Q}^\top,$$

obtém-se

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \operatorname{diag} [(1 - \lambda) \mathbf{L}_1 + \lambda \tau, \dots, (1 - \lambda) \mathbf{L}_p + \lambda \tau] \mathbf{Q}^\top. \quad (10.115)$$

Portanto,

$$\mathbf{L}_{j,\lambda} = (1 - \lambda) \mathbf{L}_j + \lambda \tau. \quad (10.116)$$

Se

$$\mathbf{L}_j = \mathbf{0}$$

e

$$\lambda > 0,$$

então

$$\mathbf{L}_{j,\lambda} = \lambda \tau > \mathbf{0}.$$

A contração esférica afasta os autovalores de zero e pode melhorar o condicionamento. Esse efeito algébrico não garante redução do erro de estimação. A escolha do alvo e de λ deve ser avaliada segundo a função de perda e o risco considerados.

A Figura 10.2 compara o espectro da covariância amostral com uma versão regularizada.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

No regime $p < n$, a regularização desloca os autovalores na direção do alvo. No regime $p \geq n$, os autovalores nulos decorrentes do limite de posto são substituídos por valores positivos.

A figura mostra um efeito algébrico da regularização. A escolha de λ e do alvo é um problema estatístico distinto e não será desenvolvida algoritmicamente neste capítulo.

10.7.4 Pseudoinversa e regularização

A pseudoinversa de Moore–Penrose foi definida na Definição 6.11. Para uma matriz de covariâncias amostral com decomposição espectral reduzida

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que Λ_r contém os r autovalores positivos, tem-se

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.117)$$

A pseudoinversa e a regularização resolvem problemas matemáticos diferentes.

Para visualizar essa diferença, considere

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(\ell_1, \dots, \ell_p) \mathbf{Q}^\top,$$

com

$$\ell_j \geq 0.$$

A pseudoinversa atribui os pesos

$$\begin{cases} 1/\ell_j, & \ell_j > 0, \\ 0, & \ell_j = 0. \end{cases}$$

Considere agora

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

com

$$0 < \lambda \leq 1 \quad \text{e} \quad \tau > 0.$$

Sua inversa é

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1 - \lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.118)$$

Se

$$\ell_j = 0,$$

a pseudoinversa atribui peso zero, enquanto a inversa regularizada atribui

$$\frac{1}{\lambda\tau}.$$

A pseudoinversa não modifica $\mathbf{S}$; ela substitui a inversão usual por sua extensão de Moore–Penrose. Os autovalores positivos continuam recebendo pesos $1/\ell_j$, mesmo quando são muito pequenos, enquanto as direções associadas a autovalores nulos recebem peso zero.

A regularização modifica a própria matriz utilizada para estimar Σ e define outro procedimento estatístico. Na contração esférica, os autovalores são afastados de zero e a inversão passa a utilizar pesos finitos determinados pelos autovalores regularizados. Portanto, pseudoinversa e regularização tratam a singularidade por mecanismos diferentes.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ ou por uma inversa regularizada modifica a estatística utilizada. Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica não podem ser transferidas automaticamente para essas substituições.

10.7.5 Sensibilidade e robustez

O vetor de médias e a matriz de covariâncias amostrais podem sofrer alterações arbitrariamente grandes quando uma observação é substituída por outra suficientemente afastada da maior parte dos dados (Maronna et al., 2019).

Considere a substituição de uma observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.119)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

A alteração não possui limite uniforme quando $\mathbf{x}_k^*$ pode se afastar arbitrariamente dos demais dados. Assim, uma única observação pode produzir uma mudança arbitrariamente grande na média amostral.

Na matriz de covariâncias, os produtos externos

$$(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

fazem com que observações afastadas possam modificar simultaneamente dispersões, covariâncias e direções espectrais.

Uma observação extrema não deve ser identificada automaticamente como erro. Ela pode representar uma unidade válida situada em uma região pouco frequente da população, uma observação proveniente de outra população ou um erro de registro ou medição. O comportamento extremo também pode indicar que a distribuição possui caudas mais pesadas, assimetria ou heterogeneidade não representadas pelo modelo adotado.

A decisão de manter, corrigir ou excluir uma observação exige conhecimento do processo de coleta e do contexto.

Estimadores robustos de localização e dispersão procuram limitar determinados tipos de sensibilidade. Sua comparação depende de quanto as estimativas se alteram diante de observações contaminadas, da eficiência sob o modelo adotado como referência, da equivariância, das condições de existência em função de n e p , do custo computacional e do parâmetro de localização ou dispersão que o procedimento pretende estimar. Nenhum procedimento apresenta o melhor desempenho em todos esses critérios.

Observações extremas, alta dimensão e má especificação correspondem a problemas diferentes. Observações extremas podem alterar fortemente estimadores sensíveis. A alta dimensão afeta o número de parâmetros a estimar, o posto e a estabilidade da matriz. A má especificação ocorre quando a distribuição ou a estrutura assumida pelo modelo não representa adequadamente o processo que gerou os dados. Esses problemas podem ocorrer simultaneamente, mas exigem tratamentos diferentes.

A avaliação de uma matriz de covariâncias estimada depende da finalidade da análise. Tamanho amostral e dimensão determinam restrições de posto; o espectro informa sobre direções de variabilidade e condicionamento; as escalas das variáveis influenciam a interpretação e a escolha de alvos de regularização; e a sensibilidade das estimativas deve ser considerada quando observações extremas ou desvios do modelo podem alterar substancialmente os resultados.

O exemplo integrado a seguir reúne os principais objetos construídos no capítulo em uma única amostra.

10.8 Exemplo integrado

O exemplo reúne a estimação da localização, da dispersão e das relações entre dois blocos de variáveis. Como os cálculos são realizados para uma amostra observada, os resultados numéricos são estimativas, representadas pelos correspondentes objetos observados.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 2 \\ 3 & 5 & 3 \\ 3 & 6 & 3 \\ 5 & 7 & 4 \\ 5 & 6 & 6 \\ 6 & 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 9 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A correspondência entre as linhas de $\mathbf{X}$ e $\mathbf{Y}$ precisa ser preservada para a estimação das covariâncias cruzadas.

Os valores foram escolhidos para que as médias sejam inteiras e os produtos cruzados possam ser calculados sem arredondamento. Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 6 \\ 4 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

As matrizes centralizadas são, portanto,

$$\mathbf{X}_c = \begin{bmatrix} -2 & -2 & -2 \\ -1 & -1 & -1 \\ -1 & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 2 \\ 2 & 2 & 2 \end{bmatrix}$$

e

$$\mathbf{Y}_c = \begin{bmatrix} -3 & -2 \\ -1 & -3 \\ 0 & 0 \\ 1 & 2 \\ -1 & -1 \\ 4 & 4 \end{bmatrix}.$$

Em ambas as matrizes, cada coluna soma zero, como exige a centralização pela média amostral. Para o primeiro bloco, a matriz SQPC observada é

$$\mathbf{T}_X = \mathbf{X}_c^\top \mathbf{X}_c.$$

Os elementos da diagonal são somas de quadrados. Por exemplo,

$$t_{11} = (-2)^2 + (-1)^2 + (-1)^2 + 1^2 + 1^2 + 2^2 = 12.$$

Os elementos fora da diagonal são somas de produtos cruzados. Por exemplo,

$$\begin{aligned} t_{12} &= (-2)(-2) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(0) + (2)(2) \\ &= 10. \end{aligned}$$

Calculando os demais elementos da mesma forma,

$$\mathbf{T}_X = \begin{bmatrix} 12 & 10 & 12 \\ 10 & 10 & 9 \\ 12 & 9 & 14 \end{bmatrix}. \quad (10.120)$$

A simetria decorre de $t_{jk} = t_{kj}$, de modo que somente a diagonal e uma das partes triangulares precisam ser calculadas diretamente.

A matriz de covariâncias amostral utiliza o divisor

$$n - 1 = 5.$$

Logo,

$$\begin{aligned}\mathbf{S}_X &= \frac{1}{5}\mathbf{T}_X \\ &= \begin{bmatrix} 2,4 & 2,0 & 2,4 \\ 2,0 & 2,0 & 1,8 \\ 2,4 & 1,8 & 2,8 \end{bmatrix}.\end{aligned}\tag{10.121}$$

A matriz $\mathbf{S}_X$ é a realização observada do estimador não viesado $\mathbf{S}_X$ de Σ_{XX} , cujo não viesamento foi estabelecido na Equação 10.69.

Sob o modelo normal multivariado definido na Definição 9.1, nesta amostra

$$\text{posto}(\mathbf{T}_X) = 3.$$

Portanto, a condição de posto completo da Proposição 10.3 é satisfeita. Assim, a estimativa de máxima verossimilhança da matriz de covariâncias é

$$\begin{aligned}\widehat{\Sigma}_{XX, \text{MV, obs}} &= \frac{1}{6}\mathbf{T}_X \\ &= \begin{bmatrix} 2 & 5/3 & 2 \\ 5/3 & 5/3 & 3/2 \\ 2 & 3/2 & 7/3 \end{bmatrix}.\end{aligned}\tag{10.122}$$

As duas matrizes estão relacionadas por

$$\widehat{\Sigma}_{XX, \text{MV, obs}} = \frac{5}{6}\mathbf{S}_X.$$

Como diferem apenas pelo fator escalar positivo $5/6$, possuem os mesmos autovetores e o mesmo posto. Seus autovalores diferem pelo fator $5/6$, enquanto o número de condição espectral permanece inalterado.

Em cálculos manuais, os valores exatos devem ser mantidos enquanto possível. Por isso, a estimativa de máxima verossimilhança foi apresentada em forma fracionária. O arredondamento deve ser realizado apenas na apresentação dos resultados que não admitem uma representação exata simples. Utilizar valores já arredondados de médias, covariâncias, correlações ou autovetores em cálculos posteriores pode acumular erros e produzir resultados diferentes dos obtidos a partir dos valores exatos.

Neste exemplo, $\mathbf{T}_X$ é exata e $\mathbf{S}_X = \mathbf{T}_X/5$ possui representação decimal finita. Para calcular correlações, pode-se utilizar diretamente

$$r_{jk} = \frac{t_{jk}}{\sqrt{t_{jj}t_{kk}}},$$

pois o divisor comum de $\mathbf{S}_X$ se cancela. Autovalores e números de condição apresentados em forma decimal devem ser calculados com os valores não arredondados e arredondados apenas ao final.

A matriz de correlações observada é

$$\mathbf{R}_X \approx \begin{bmatrix} 1,000 & 0,913 & 0,926 \\ 0,913 & 1,000 & 0,761 \\ 0,926 & 0,761 & 1,000 \end{bmatrix}. \quad (10.123)$$

As três correlações são positivas. A maior ocorre entre X_1 e X_3 ,

$$r_{13} \approx 0,926,$$

e a menor entre X_2 e X_3 ,

$$r_{23} \approx 0,761.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 \approx 6,579, \quad \ell_2 \approx 0,560 \quad \text{e} \quad \ell_3 \approx 0,061.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e

$$\mathbf{S}_X \succ \mathbf{0}.$$

Seu número de condição espectral é aproximadamente

$$\kappa_2(\mathbf{S}_X) = \frac{\ell_1}{\ell_3} \approx 108,3.$$

O valor de $\kappa_2(\mathbf{S}_X)$ foi calculado com os autovalores antes do arredondamento. Dividir os valores exibidos, já arredondados, pode produzir uma aproximação ligeiramente diferente.

Portanto, $\mathbf{S}_X$ é invertível, mas seus autovalores apresentam magnitudes bastante distintas. O valor relativamente elevado de $\kappa_2(\mathbf{S}_X)$ mostra que invertibilidade e bom condicionamento são propriedades distintas.

Para estimar as relações entre os dois blocos, utiliza-se

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c.$$

Por exemplo, o elemento correspondente a X_1 e Y_1 é

$$\begin{aligned} t_{X_1 Y_1} &= (-2)(-3) + (-1)(-1) + (-1)(0) + (1)(1) + (1)(-1) + (2)(4) \\ &= 15. \end{aligned}$$

Os demais produtos cruzados fornecem

$$\mathbf{T}_{XY} = \begin{bmatrix} 15 & 16 \\ 16 & 17 \\ 13 & 13 \end{bmatrix}. \quad (10.124)$$

Logo, pela definição de covariância cruzada observada na Definição 8.13,

$$\mathbf{S}_{XY} = \frac{1}{5} \mathbf{T}_{XY} = \begin{bmatrix} 3,0 & 3,2 \\ 3,2 & 3,4 \\ 2,6 & 2,6 \end{bmatrix}. \quad (10.125)$$

Por exemplo,

$$s_{X_3 Y_1} = 2,6$$

é a covariância amostral entre X_3 e Y_1 .

A inversão da ordem dos blocos segue Equação 8.73:

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 3,0 & 3,2 & 2,6 \\ 3,2 & 3,4 & 2,6 \end{bmatrix}.$$

Para o segundo bloco,

$$\mathbf{T}_Y = \mathbf{Y}_c^\top \mathbf{Y}_c = \begin{bmatrix} 28 & 28 \\ 28 & 34 \end{bmatrix},$$

de modo que

$$\mathbf{S}_Y = \frac{1}{5} \mathbf{T}_Y = \begin{bmatrix} 5,6 & 5,6 \\ 5,6 & 6,8 \end{bmatrix}.$$

Reunindo as cinco variáveis,

$$\mathbf{X}_{\text{conj}} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

a matriz SQPC conjunta possui a forma em blocos

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} \mathbf{T}_X & \mathbf{T}_{XY} \\ \mathbf{T}_{YX} & \mathbf{T}_Y \end{bmatrix}.$$

Numericamente,

$$\mathbf{T}_{\text{conj}} = \begin{bmatrix} 12 & 10 & 12 & 15 & 16 \\ 10 & 10 & 9 & 16 & 17 \\ 12 & 9 & 14 & 13 & 13 \\ 15 & 16 & 13 & 28 & 28 \\ 16 & 17 & 13 & 28 & 34 \end{bmatrix}.$$

Como $n - 1 = 5$,

$$\mathbf{S}_{\text{conj}} = \frac{1}{5} \mathbf{T}_{\text{conj}} = \begin{bmatrix} 2,4 & 2,0 & 2,4 & 3,0 & 3,2 \\ 2,0 & 2,0 & 1,8 & 3,2 & 3,4 \\ 2,4 & 1,8 & 2,8 & 2,6 & 2,6 \\ 3,0 & 3,2 & 2,6 & 5,6 & 5,6 \\ 3,2 & 3,4 & 2,6 & 5,6 & 6,8 \end{bmatrix}. \quad (10.126)$$

A organização em blocos permite identificar diretamente as covariâncias internas de $\mathbf{X}$, as covariâncias internas de $\mathbf{Y}$ e as covariâncias cruzadas entre os dois conjuntos.

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_{\text{conj}}) \leq 5.$$

A matriz conjunta centralizada é

$$\mathbf{X}_{\text{conj},c} = \begin{bmatrix} -2 & -2 & -2 & -3 & -2 \\ -1 & -1 & -1 & -1 & -3 \\ -1 & 0 & -1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 2 \\ 1 & 0 & 2 & -1 & -1 \\ 2 & 2 & 2 & 4 & 4 \end{bmatrix}.$$

Seu escalonamento fornece cinco pivôs, de modo que

$$\text{posto}(\mathbf{X}_{\text{conj},c}) = 5.$$

Como

$$\mathbf{T}_{\text{conj}} = \mathbf{X}_{\text{conj},c}^{\top} \mathbf{X}_{\text{conj},c},$$

segue de Equação 8.60 que

$$\text{posto}(\mathbf{S}_{\text{conj}}) = 5.$$

Portanto,

$$\mathbf{S}_{\text{conj}} \succ \mathbf{0}.$$

O caso $n = 6$ e $p = 5$ está exatamente no limite $n = p + 1$. Esse tamanho amostral permite posto completo, mas não o garante para uma amostra arbitrária.

O exemplo mostra como uma única amostra produz realizações dos principais objetos definidos no capítulo. Os vetores $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ estimam as médias populacionais, enquanto $\mathbf{T}_X$ é a realização da estatística SQPC. A divisão de $\mathbf{T}_X$ por $n - 1$ produz a estimativa não viesada $\mathbf{S}_X$; a divisão por n produz a estimativa pelo método dos momentos e, sob o modelo normal e as condições de existência do máximo, também a estimativa de máxima verossimilhança.

A matriz $\mathbf{R}_X$ utiliza a mesma informação de covariância após a remoção das escalas marginais. O posto completo de $\mathbf{S}_X$ garante sua invertibilidade, mas o número de condição mostra que essa propriedade não garante estabilidade da inversão.

O pareamento das linhas de $\mathbf{X}$ e $\mathbf{Y}$ determina os produtos cruzados em $\mathbf{T}_{XY}$ e, conseqüentemente, as covariâncias em $\mathbf{S}_{XY}$. A matriz conjunta reúne em um único objeto as covariâncias internas dos dois blocos e as covariâncias entre eles.

Todos os valores apresentados são realizações obtidas nesta amostra. Não viesamento, consistência, eficiência e outras propriedades dos estimadores descrevem seu comportamento ao considerar as possíveis amostras geradas pelo modelo.

10.9 Síntese do capítulo

Este capítulo estabeleceu a relação entre parâmetros populacionais, estatísticas amostrais, estimadores e suas realizações observadas.

A distinção central envolve quatro objetos. O parâmetro θ é uma característica fixa da distribuição populacional. Uma amostra aleatória $\mathcal{X}$ produz estatísticas por meio de funções dos dados,

$$\mathbf{G} = G(\mathcal{X}).$$

Quando uma estatística é utilizada para estimar θ , ela constitui um estimador,

$$\hat{\theta} = G(\mathcal{X}).$$

Após a observação da amostra, a realização

$$\hat{\theta}_{\text{obs}} = G(\mathbf{X})$$

é a estimativa do parâmetro. Portanto, todo estimador é uma estatística, mas nem toda estatística é utilizada como estimador.

Para uma amostra multivariada i.i.d., o vetor de médias amostrais estima μ , enquanto a matriz de covariâncias amostral estima Σ :

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

e

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T},$$

em que $\mathbf{T}$ é a matriz SQPC amostral definida na Definição 10.13.

O método dos momentos e a máxima verossimilhança são princípios de construção de estimadores. O método utilizado não determina, por si só, as propriedades do estimador obtido.

O método dos momentos fornece

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}$$

e

$$\widehat{\Sigma}_{\text{MM}} = \frac{1}{n} \mathbf{T}.$$

Sob o modelo normal multivariado e quando o máximo existe, a máxima verossimilhança conduz às mesmas estatísticas.

A segunda estatística é viesada em amostras finitas, enquanto

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}$$

é não viesada. As duas são consistentes para Σ no regime de dimensão fixa sob as condições estabelecidas no capítulo.

Os resultados na Proposição 10.6 e Equação 10.69 fornecem

$$E(\bar{\mathbf{X}}) = \mu, \quad \text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}, \quad E(\mathbf{S}) = \Sigma.$$

No regime de dimensão fixa, Proposição 10.7 e Proposição 10.12 estabelecem

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad \text{e} \quad \mathbf{S} \xrightarrow{P} \Sigma.$$

Para variáveis organizadas em dois blocos pareados,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{T}_{XY}$$

estima a matriz de covariâncias cruzadas. Quando as variâncias amostrais são positivas,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}$$

fornece a matriz de correlações amostral.

A Tabela 10.2 reúne os principais objetos do capítulo.

Tabela 10.2: Relação entre parâmetros, estatísticas, estimadores e valores observados utilizados no capítulo.

Parâmetro ou objeto	Estatística/estimador	Propriedade destacada	Valor observado
μ	$\bar{\mathbf{X}}$	Não viesado e consistente; MM; MV sob normalidade e existência do máximo	$\bar{\mathbf{x}}$
Σ	$\mathbf{S} = \mathbf{T}/(n-1)$	Não viesado e consistente	$\mathbf{S}$
Σ	$\mathbf{T}/n$	MM; MV sob normalidade e existência do máximo; viesado em amostras finitas e consistente	$\mathbf{T}/n$
SQPC amostral	$\mathbf{T}$	Estatística que reúne somas de quadrados e produtos cruzados	$\mathbf{T}$
Σ_{XY}	$\mathbf{S}_{XY}$	Não viesado e consistente	$\mathbf{S}_{XY}$
$\mathcal{R}$	$\mathbf{R}$	Em geral viesado, mas consistente; MV sob normalidade e existência do máximo	$\mathbf{R}$

As propriedades estudadas respondem a perguntas diferentes. O viés compara a esperança do estimador com o parâmetro; a variabilidade descreve quanto o estimador muda entre amostras; o erro quadrático médio combina erro sistemático e variabilidade segundo uma função de perda; a consistência descreve o comportamento quando n aumenta; e a eficiência compara estimadores concorrentes segundo sua variabilidade ou risco. A suficiência verifica se uma redução da amostra preserva a informação sobre o parâmetro, enquanto a equivariância descreve a resposta do estimador a transformações dos dados. A robustez examina quanto o procedimento pode ser alterado pelas formas de contaminação ou perturbação consideradas.

A estrutura de posto

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1)$$

mostra por que dimensão e tamanho amostral precisam ser considerados conjuntamente. Quando $p \geq n$, a covariância amostral é necessariamente singular. Mesmo quando existe uma inversa, seu uso pode ser instável quando alguns autovalores são pequenos.

Pseudoinversa e regularização tratam singularidade e condicionamento por mecanismos diferentes. A pseudoinversa mantém $\mathbf{S}$ e modifica a operação utilizada para trabalhar com suas direções de variância nula. A regularização substitui $\mathbf{S}$ por outro estimador, por exemplo combinando-a com uma matriz-alvo. Essa modificação pode afastar autovalores de zero e melhorar o condicionamento, mas também altera viés, risco e consistência. Com peso de contração fixo e alvo diferente de Σ , a consistência para Σ não é garantida.

Ao término deste capítulo, deve-se ser capaz de:

- distinguir parâmetro, estatística, estimador, estimativa e distribuição amostral;
- avaliar viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência, equivariância e robustez;
- distinguir os princípios do método dos momentos e da máxima verossimilhança;
- construir o vetor de médias amostrais, a matriz SQPC e os estimadores da matriz de covariâncias;
- explicar a origem e a função dos divisores n e $n - 1$;
- construir estimadores de covariâncias cruzadas e correlações;
- analisar posto, singularidade e condicionamento de matrizes estimadas;
- distinguir pseudoinversa, regularização e estimação robusta segundo o problema que cada procedimento procura tratar.

O Capítulo 11 utiliza a matriz de covariâncias populacional de Definição 8.2, o modelo normal multivariado de Definição 9.1 e os estimadores desenvolvidos neste capítulo para construir o **modelo linear multivariado**. Nesse modelo, várias variáveis-resposta são relacionadas simultaneamente a uma matriz de delineamento, produzindo uma matriz de parâmetros, valores ajustados, resíduos e matrizes SQPC associadas às fontes de variação.

11 Modelo Linear Multivariado e Hipóteses Lineares

O Capítulo 10 desenvolveu a estimação do vetor de médias e da matriz de covariâncias a partir de uma amostra aleatória multivariada. O vetor de médias amostrais e suas propriedades foram estabelecidos em Proposição 10.6, enquanto a matriz de covariâncias amostral foi definida em Definição 10.14 e seu não viesamento foi estabelecido em Proposição 10.11. Nesse contexto, todas as unidades compartilhavam o mesmo vetor de médias populacional.

O modelo linear multivariado substitui essa média comum por uma estrutura de médias que pode variar entre as unidades segundo características conhecidas. Essa formulação permite representar, em um mesmo modelo, regressões com várias respostas, comparações entre grupos, efeitos de fatores e efeitos de covariáveis.

O modelo é escrito como

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

em que:

- $\mathbf{y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

Aqui, n é o número de unidades, p é o número de respostas observadas em cada unidade e q é o número de termos representados na matriz de delineamento. Esses termos podem incluir intercepto, indicadores de grupos ou tratamentos e covariáveis quantitativas.

O objetivo deste capítulo é formular o modelo, estimar $\mathbf{B}$, interpretar valores ajustados e resíduos por meio de projeções, construir a SQPC residual, estimar a matriz de covariâncias dos erros, decompor a dispersão observada e representar hipóteses lineares sobre parâmetros e combinações das respostas (Rencher; Christensen, 2012).

No caso de grupos, essa estrutura relacionará a variação residual e a variação associada ao modelo às matrizes de dispersão intragrupos e entre grupos definidas em Definição 8.14 e Definição 8.15.

As distribuições amostrais utilizadas na construção de testes e regiões de confiança serão desenvolvidas no Capítulo 12.

Convenções de notação

Ao longo deste capítulo:

- $\mathbf{Y}_i \in \mathbb{R}^p$ representa o vetor aleatório de respostas da unidade i ;
- $\mathbf{y}_i \in \mathbb{R}^p$ representa uma realização desse vetor;
- $\mathbf{y} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de respostas;
- $\mathbf{Y} \in \mathbb{R}^{n \times p}$ representa a matriz observada de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ representa a matriz de delineamento;
- $\mathbf{z}_i^\top$ representa a linha i de $\mathbf{Z}$;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ representa a matriz de parâmetros;
- $\varepsilon_i \in \mathbb{R}^p$ representa o vetor aleatório de erros da unidade i ;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ representa a matriz aleatória de erros;
- $\Sigma \in \mathbb{R}^{p \times p}$ representa a matriz de covariâncias entre as respostas de uma mesma unidade;
- $\widehat{\mathbf{B}}$ representa um estimador de $\mathbf{B}$;
- $\widehat{\mathbf{U}}$ representará a matriz aleatória de resíduos e $\widehat{\mathbf{U}}$ sua realização observada;
- $\mathbf{E}_{\text{res}}$ representará a SQPC residual como estatística aleatória e $\mathbf{E}$ sua realização observada;
- $\mathbf{T}$ continuará representando a SQPC total observada;
- $\mathbf{T}_{\text{mod}}$ representará a dispersão dos valores ajustados pelo modelo em torno da média geral;
- $\mathbf{H}$ ficará reservada à SQPC associada a uma hipótese linear.

A letra $\mathbf{Z}$ é utilizada para o delineamento para preservar $\mathbf{X}$ como símbolo da matriz de dados nos capítulos anteriores.

11.1 Formulação do modelo linear multivariado

11.1.1 Resposta vetorial e matriz de respostas

No modelo linear univariado, cada unidade fornece uma única resposta. No caso multivariado, a unidade i fornece simultaneamente

$$\mathbf{Y}_i = \begin{bmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{ip} \end{bmatrix} \in \mathbb{R}^p. \quad (11.1)$$

As componentes podem apresentar dependência. O modelo deve, portanto, representar simultaneamente:

1. a estrutura das médias das p respostas;
2. a variabilidade de cada resposta;
3. as covariâncias entre respostas observadas na mesma unidade.

Considere

$$\mathbf{z}_i = \begin{bmatrix} z_{i1} \\ \vdots \\ z_{iq} \end{bmatrix} \in \mathbb{R}^q,$$

contendo os valores dos q termos do modelo para a unidade i .

Um termo pode representar, por exemplo, o intercepto, o pertencimento a um grupo ou tratamento, o valor de uma covariável quantitativa ou outro efeito especificado no modelo. A matriz de delineamento reúne essas informações para todas as unidades.

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1p} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qp} \end{bmatrix} \in \mathbb{R}^{q \times p}. \quad (11.2)$$

A coluna j de $\mathbf{B}$ contém os coeficientes do modelo para a resposta j . A linha h reúne os coeficientes associados ao mesmo termo da matriz de delineamento para as p respostas.

Assim, uma covariável ou um efeito de grupo pode atuar de maneira diferente sobre cada resposta, embora todas utilizem a mesma matriz $\mathbf{Z}$.

A média condicional do vetor de respostas da unidade i é

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i. \quad (11.3)$$

Equivalentemente, em forma de vetor linha,

$$E(\mathbf{Y}_i^\top \mid \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{B}.$$

Definição 11.1 (Modelo linear multivariado para uma unidade). O vetor de respostas da unidade i é representado por

$$\mathbf{Y}_i = \mathbf{B}^\top \mathbf{z}_i + \varepsilon_i, \quad (11.4)$$

em que

$$\mathbf{Y}_i, \varepsilon_i \in \mathbb{R}^p, \quad \mathbf{z}_i \in \mathbb{R}^q, \quad \mathbf{B} \in \mathbb{R}^{q \times p}.$$

Componente a componente,

$$Y_{ij} = \mathbf{z}_i^\top \beta_j + \varepsilon_{ij}, \quad j = 1, \dots, p, \quad (11.5)$$

em que β_j é a coluna j de $\mathbf{B}$.

As equações das diferentes respostas compartilham a mesma matriz de delineamento. O carácter multivariado do modelo decorre da análise conjunta dessas respostas e da estrutura de covariâncias dos respectivos erros.

Para reunir as n unidades, defina a matriz aleatória

Definição 11.2 (Matriz aleatória de respostas).

$$\mathbf{y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \mathbf{Y}_2^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} = \begin{bmatrix} Y_{11} & \dots & Y_{1p} \\ Y_{21} & \dots & Y_{2p} \\ \vdots & \ddots & \vdots \\ Y_{n1} & \dots & Y_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.6)$$

Após a observação,

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.7)$$

A matriz de delineamento é

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times q}. \quad (11.8)$$

Neste capítulo, o modelo e os resultados de estimação são formulados condicionalmente a $\mathbf{Z}$. Assim, a matriz de delineamento é tratada como conhecida. Essa convenção abrange tanto delineamentos fixados previamente quanto análises condicionais aos valores observados das variáveis explicativas.

11.1.2 Estrutura matricial do modelo

Organize os vetores de erros nas linhas de

$$\mathcal{E} = \begin{bmatrix} \varepsilon_1^\top \\ \vdots \\ \varepsilon_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.9)$$

Definição 11.3 (Modelo linear multivariado). O modelo linear multivariado é

$$\mathcal{Y} = \mathbf{ZB} + \mathcal{E}. \quad (11.10)$$

em que:

- $\mathcal{Y} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de respostas;
- $\mathbf{Z} \in \mathbb{R}^{n \times q}$ é a matriz de delineamento;
- $\mathbf{B} \in \mathbb{R}^{q \times p}$ é a matriz de parâmetros;
- $\mathcal{E} \in \mathbb{R}^{n \times p}$ é a matriz aleatória de erros.

A matriz de médias condicionais é

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}. \quad (11.11)$$

Portanto, a estrutura sistemática do modelo pertence ao espaço coluna de $\mathbf{Z}$. Cada coluna de

$$\mathbf{ZB}$$

é uma combinação linear das colunas do delineamento.

Se

$$r = \text{posto}(\mathbf{Z}), \quad (11.12)$$

então

$$r \leq \min(n, q).$$

O valor r é o número de colunas linearmente independentes de $\mathbf{Z}$ e, portanto, a dimensão do espaço de médias representado pelo delineamento.

Quando

$$r = q,$$

a matriz de delineamento possui posto coluna completo. O caso $r < q$ será examinado posteriormente, quando forem discutidas a unicidade dos coeficientes e as funções estimáveis.

11.1.3 Estrutura de médias e covariâncias residuais

A primeira condição do modelo é

Definição 11.4 (Média residual nula).

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}, \quad i = 1, \dots, n. \quad (11.13)$$

Consequentemente,

$$E(\mathbf{Y}_i \mid \mathbf{Z}) = \mathbf{B}^\top \mathbf{z}_i.$$

A segunda condição descreve a dependência entre as respostas de uma mesma unidade e entre unidades distintas.

Definição 11.5 (Estrutura de covariâncias dos erros). Para cada unidade,

$$\varepsilon_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

e assume-se que os segundos momentos condicionais existem.

A matriz de covariâncias condicional é comum às unidades:

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n, \quad (11.14)$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0}.$$

Além disso,

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}_{p \times p}, \quad i \neq \ell. \quad (11.15)$$

A matriz

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix}$$

é a matriz de covariâncias residuais entre as p respostas.

Assim,

$$\text{Var}(Y_{ij} \mid \mathbf{Z}) = \sigma_{jj},$$

e, para duas respostas da mesma unidade,

$$\text{Cov}(Y_{ij}, Y_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

A expressão “covariância residual” indica a variabilidade que permanece após a estrutura de médias $\mathbf{ZB}$ ter sido especificada. Ela não deve ser confundida com a covariância marginal das respostas quando suas médias variam entre unidades.

As condições anteriores implicam que a dependência entre respostas é permitida **dentro de uma unidade**, enquanto erros de unidades distintas são não correlacionados. Sob normalidade conjunta, a covariância cruzada nula entre unidades implica independência por Proposição 9.6.

11.1.4 Forma vetorizada

A forma matricial

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$$

será a representação principal do modelo neste capítulo. Quando for necessário reunir todas as respostas em um único vetor, podem ser utilizados o operador vec e o produto de Kronecker definidos em Definição 7.9 e Definição 7.10.

Pela identidade de Proposição 7.15,

$$\text{vec}(\mathbf{ZB}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \quad (11.16)$$

de modo que

$$\text{vec}(\mathbf{y}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}) + \text{vec}(\mathcal{E}). \quad (11.17)$$

Proposição 11.1 (Covariância do erro vetorizado). *Se*

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

então

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.18)$$

Consequentemente,

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.19)$$

A forma vetorizada será utilizada como representação auxiliar em resultados de covariância e distribuição. Os cálculos de ajuste, resíduos e decomposição da variação serão desenvolvidos diretamente na forma matricial.

11.1.5 Distribuição normal matricial

A normalidade não é necessária para definir o modelo linear multivariado nem para obter os resultados de mínimos quadrados desenvolvidos neste capítulo. Ela será utilizada para obter distribuições amostrais exatas no Capítulo 12.

A distribuição normal matricial fornece uma notação compacta para representar conjuntamente a distribuição das linhas e das colunas de uma matriz aleatória (Gupta; Nagar, 1999).

Definição 11.6 (Distribuição normal matricial). *Se*

$$\mathcal{A} \in \mathbb{R}^{n \times p},$$

diz-se que

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V})$$

quando

$$\text{vec}(\mathcal{A}) \sim N_{np}[\text{vec}(\Xi), \mathbf{V} \otimes \mathbf{U}]. \quad (11.20)$$

Aqui,

$$\Xi \in \mathbb{R}^{n \times p}, \quad \mathbf{U} \in \mathbb{R}^{n \times n}, \quad \mathbf{V} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{U} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{V} \succeq \mathbf{0}.$$

A distribuição normal multivariada utilizada no lado direito de Equação 11.20 é a distribuição definida em Definição 9.1.

Neste capítulo será utilizado apenas o caso em que

$$\mathbf{U} = \mathbf{I}_n$$

e

$$\mathbf{V} = \Sigma.$$

A matriz $\mathbf{I}_n$ representa a ausência de dependência entre unidades, enquanto Σ representa as covariâncias entre as p respostas de uma mesma unidade.

Definição 11.7 (Modelo linear normal multivariado). Considere

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p},$$

e

$$\mathcal{E} \in \mathbb{R}^{n \times p}.$$

Se

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma = \Sigma^\top, \quad \Sigma \succeq \mathbf{0},$$

o modelo linear normal multivariado é definido por

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}_{n \times p}, \mathbf{I}_n, \Sigma). \quad (11.21)$$

Equivalentemente,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma). \quad (11.22)$$

Pela definição da normal matricial,

$$\text{vec}(\mathbf{y}) \mid \mathbf{Z} \sim N_{np}[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n]. \quad (11.23)$$

A mesma estrutura pode ser lida por unidade:

$$\mathbf{Y}_i \mid \mathbf{Z} \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n, \quad (11.24)$$

com independência condicional entre as unidades.

A matriz Σ continua desempenhando o papel estabelecido nos Capítulos 8 e 9: suas diagonais são as variâncias residuais das respostas e seus elementos fora da diagonal descrevem a dependência linear residual entre elas.

Para uma resposta específica j , a coluna correspondente satisfaz

$$\mathbf{Y}_{\cdot j} \mid \mathbf{Z} \sim N_n(\mathbf{Z}\beta_j, \sigma_{jj}\mathbf{I}_n). \quad (11.25)$$

Para duas respostas j e k ,

$$\text{Cov}(\mathbf{Y}_{\cdot j}, \mathbf{Y}_{\cdot k} \mid \mathbf{Z}) = \sigma_{jk}\mathbf{I}_n. \quad (11.26)$$

Assim, ajustar separadamente as p equações produz os mesmos estimadores de mínimos quadrados para os coeficientes quando todas utilizam a mesma matriz $\mathbf{Z}$. A formulação conjunta mantém explícita a covariância entre as respostas e permite formular posteriormente hipóteses que envolvem várias respostas simultaneamente.

Sob normalidade, a mesma estrutura também permite relacionar mínimos quadrados e máxima verossimilhança. Essa relação será desenvolvida após a obtenção do estimador de $\mathbf{B}$.

11.1.6 Transformações da resposta

Uma transformação linear das respostas preserva a estrutura do modelo.

Considere

$$\mathbf{W}_i = \mathbf{A}^\top \mathbf{Y}_i,$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times s}.$$

Em forma matricial,

$$\mathcal{W} = \mathcal{Y} \mathbf{A}.$$

Logo,

$$\mathcal{W} = \mathbf{Z}(\mathbf{B}\mathbf{A}) + \mathcal{E}\mathbf{A}. \quad (11.27)$$

A matriz de parâmetros transformada é

$$\mathbf{B}_W = \mathbf{B}\mathbf{A},$$

e a matriz de covariâncias residuais é

$$\Sigma_W = \mathbf{A}^\top \Sigma \mathbf{A},$$

em concordância com Proposição 8.6.

Sob normalidade, Proposição 9.4 fornece

$$\mathcal{W} \mid \mathbf{Z} \sim N_{n \times s}(\mathbf{Z}\mathbf{B}\mathbf{A}, \mathbf{I}_n, \mathbf{A}^\top \Sigma \mathbf{A}). \quad (11.28)$$

Essa propriedade será utilizada posteriormente para formular hipóteses sobre combinações lineares das respostas.

O modelo está agora especificado em termos de sua estrutura de médias e de covariâncias. A próxima etapa é estimar a matriz de parâmetros $\mathbf{B}$ a partir da matriz observada de respostas.

11.2 Estimação da matriz de parâmetros

A estimação de $\mathbf{B}$ consiste em determinar a estrutura de médias

$$\mathbf{ZB}$$

que melhor aproxima a matriz observada de respostas $\mathbf{Y}$ segundo o critério adotado.

Como todas as respostas utilizam a mesma matriz de delineamento, cada coluna de $\mathbf{B}$ pode ser estimada pelo modelo linear correspondente àquela resposta. A formulação matricial reúne os p ajustes e mantém explícita a estrutura necessária para estudar conjuntamente os coeficientes e a covariância residual entre as respostas (Rencher; Christensen, 2012).

11.2.1 Mínimos quadrados

Considere uma matriz candidata

$$\mathbf{B}^* \in \mathbb{R}^{q \times p}.$$

A matriz de resíduos correspondente é

$$\mathbf{Y} - \mathbf{ZB}^*.$$

Definição 11.8 (Critério de mínimos quadrados multivariado). O critério de mínimos quadrados é

$$Q(\mathbf{B}^*) = \|\mathbf{Y} - \mathbf{ZB}^*\|_F^2. \quad (11.29)$$

Equivalentemente,

$$Q(\mathbf{B}^*) = \text{tr} \left[(\mathbf{Y} - \mathbf{ZB}^*)^\top (\mathbf{Y} - \mathbf{ZB}^*) \right]. \quad (11.30)$$

A norma de Frobenius foi definida em Definição 6.7. Neste problema,

$$Q(\mathbf{B}^*) = \sum_{j=1}^p \|\mathbf{y}_{\cdot j} - \mathbf{Zb}_j^*\|^2, \quad (11.31)$$

em que $\mathbf{y}_{\cdot j}$ é a coluna j de $\mathbf{Y}$ e $\mathbf{b}_j^*$ é a coluna correspondente de $\mathbf{B}^*$.

Portanto, minimizar $Q(\mathbf{B}^*)$ equivale a minimizar separadamente a soma de quadrados residual de cada uma das p respostas.

Por essa razão, as covariâncias fora da diagonal de Σ não participam da obtenção do estimador de mínimos quadrados de $\mathbf{B}$ quando todas as respostas utilizam a mesma matriz $\mathbf{Z}$. Elas determinam, porém, a covariância entre os estimadores de respostas distintas e serão utilizadas na estimação da covariância residual e nas hipóteses que envolvem várias respostas simultaneamente.

As equações normais e sua derivação por cálculo matricial foram estabelecidas em Definição 3.21 e Proposição 7.6. Aplicadas ao modelo atual, elas assumem a forma

$$\mathbf{Z}^\top \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.32)$$

Equivalentemente,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}}) = \mathbf{0}_{q \times p}. \quad (11.33)$$

Se

$$\widehat{\mathbf{U}} = \mathbf{Y} - \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}},$$

então

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}. \quad (11.34)$$

Cada coluna da matriz de resíduos é, portanto, ortogonal ao espaço coluna de $\mathbf{Z}$. Essa propriedade é a versão multivariada da decomposição de mínimos quadrados estabelecida em Proposição 3.18.

11.2.2 Estimador sob posto completo

Suponha

$$\text{posto}(\mathbf{Z}) = q. \quad (11.35)$$

Nesse caso,

$$q \leq n$$

e

$$\mathbf{Z}^\top \mathbf{Z} \succ \mathbf{0}.$$

Proposição 11.2 (Estimador de mínimos quadrados sob posto completo). *Se*

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de mínimos quadrados de $\mathbf{B}$ é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.36)$$

Após a observação das respostas,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (11.37)$$

A unicidade do minimizador decorre da definição positiva de

$$\mathbf{Z}^\top \mathbf{Z}.$$

A convexidade do critério e a caracterização do minimizador global por meio das equações normais foram desenvolvidas em Proposição 7.9 e não precisam ser novamente demonstradas aqui.

Para a resposta j , a coluna correspondente é

$$\hat{\beta}_j = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{\cdot j}, \quad (11.38)$$

em que

$$\mathbf{Y}_{\cdot j} = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{nj} \end{bmatrix}.$$

Assim, cada coluna de $\widehat{\mathbf{B}}$ coincide com o estimador de mínimos quadrados obtido para a resposta correspondente. A formulação matricial reúne esses estimadores em um único objeto.

11.2.3 Esperança e matriz de covariâncias

Substituindo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

em Equação 11.36,

$$\begin{aligned}\widehat{\mathbf{B}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.\end{aligned}\tag{11.39}$$

A segunda parcela representa o erro de estimação.

Proposição 11.3 (Esperança e covariância do estimador da matriz de parâmetros). *Considere*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}$$

e

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

Se

$$\text{posto}(\mathbf{Z}) = q,$$

então

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}\tag{11.40}$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.\tag{11.41}$$

i Demonstração

De Equação 11.39 e da condição

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

segue imediatamente que

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}.$$

Para a covariância, defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então,

$$\widehat{\mathbf{B}} - \mathbf{B} = \mathbf{A}_Z \mathcal{E}.$$

Pela identidade de vetorização em Proposição 7.15,

$$\text{vec}(\widehat{\mathbf{B}} - \mathbf{B}) = (\mathbf{I}_p \otimes \mathbf{A}_Z) \text{vec}(\mathcal{E}).$$

Aplicando a estrutura de covariâncias dos erros,

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{A}_Z \mathbf{A}_Z^\top).$$

Como

$$\mathbf{A}_Z \mathbf{A}_Z^\top = (\mathbf{Z}^\top \mathbf{Z})^{-1},$$

obtem-se Equação 11.41.

O resultado mostra duas fontes distintas de variabilidade:

$$\Sigma$$

descreve a variabilidade residual e a associação entre as respostas, enquanto

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a precisão dos coeficientes.

Para duas respostas j e k ,

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k \mid \mathbf{Z}) = \sigma_{jk} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.42)$$

Para $j = k$,

$$\text{Cov}(\hat{\beta}_j | \mathbf{Z}) = \sigma_{jj} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.43)$$

Assim, estimadores associados a respostas diferentes são correlacionados sempre que os erros dessas respostas apresentam covariância residual diferente de zero.

11.2.4 Relação com máxima verossimilhança

Sob o modelo linear normal multivariado, a log-verossimilhança para uma matriz observada de respostas $\mathbf{Y}$, a menos de termos que não dependem dos parâmetros, const é

$$\begin{aligned} \ell(\mathbf{B}, \Sigma; \mathbf{Y}) = \text{const} - \frac{n}{2} \log \det(\Sigma) \\ - \frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{ZB})^\top (\mathbf{Y} - \mathbf{ZB}) \right]. \end{aligned} \quad (11.44)$$

Para $\Sigma \succ \mathbf{0}$ fixada, o primeiro termo não depende de $\mathbf{B}$. Portanto, maximizar a log-verossimilhança em relação a $\mathbf{B}$ equivale a minimizar o termo quadrático residual.

Aplicando ao termo quadrático residual o procedimento de diferenciação matricial utilizado em Proposição 7.6, obtém-se

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ é invertível,

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZB}) = \mathbf{0},$$

que coincide com a equação normal de mínimos quadrados em Equação 11.33.

Proposição 11.4 (Mínimos quadrados e máxima verossimilhança). *Considere o modelo linear normal multivariado com*

$$\text{posto}(\mathbf{Z}) = q.$$

Para qualquer $\Sigma \succ \mathbf{0}$ fixada, o maximizador da verossimilhança em relação a $\mathbf{B}$ é

$$\hat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Consequentemente, sempre que o estimador de máxima verossimilhança conjunto de

$$(\mathbf{B}, \Sigma)$$

existir no espaço paramétrico considerado,

$$\widehat{\mathbf{B}}_{\text{MV}} = \widehat{\mathbf{B}}. \quad (11.45)$$

A coincidência ocorre porque todas as respostas utilizam a mesma matriz de delineamento $\mathbf{Z}$ e porque Σ atua sobre a dependência entre as respostas, não sobre a estrutura entre as unidades.

Assim, Σ determina a covariância conjunta dos coeficientes estimados, mas não modifica a expressão de $\widehat{\mathbf{B}}$.

Esse resultado depende da estrutura do modelo e não se transfere automaticamente para situações em que as respostas utilizam delineamentos diferentes ou em que existe dependência residual entre unidades.

A existência do estimador conjunto de máxima verossimilhança da matriz de covariâncias será examinada na seção dedicada à SQPC residual.

11.2.5 Modelo contendo somente intercepto

O modelo mais simples ocorre quando todas as unidades possuem o mesmo vetor de médias:

$$\mathbf{Y}_i = \mu + \varepsilon_i, \quad i = 1, \dots, n. \quad (11.46)$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Como

$$\mathbf{Z}^\top \mathbf{Z} = n,$$

tem-se

$$\widehat{\mathbf{B}} = \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} = \bar{\mathbf{Y}}^\top. \quad (11.47)$$

Após a observação,

$$\widehat{\mathbf{B}}_{\text{obs}} = \bar{\mathbf{y}}^\top.$$

Portanto, Equação 11.47 recupera o estimador do vetor de médias estudado em Proposição 10.6.

Além disso,

$$\text{Cov}(\bar{\mathbf{Y}}) = \frac{\Sigma}{n},$$

recuperando diretamente Equação 10.54.

O modelo contendo somente intercepto é, assim, um caso particular do problema de estimação desenvolvido no Capítulo 10. No modelo linear multivariado geral, a única média comum é substituída por vetores de médias que variam entre as unidades segundo os termos representados em $\mathbf{Z}$.

11.3 Valores ajustados, resíduos e projeções

A estimação de $\mathbf{B}$ determina uma matriz de médias ajustadas pertencente ao espaço coluna da matriz de delineamento. A projeção ortogonal sobre um espaço coluna foi estabelecida em Proposição 3.15.

Seja

$$r = \text{posto}(\mathbf{Z}).$$

O projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z})$$

pode ser escrito como

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+, \quad (11.48)$$

em que $\mathbf{Z}^+$ é a pseudoinversa de Moore–Penrose definida em Definição 6.11.

Essa expressão depende apenas do espaço coluna de $\mathbf{Z}$ e permanece válida mesmo quando $\mathbf{Z}$ não possui posto coluna completo. A questão da unicidade dos coeficientes será tratada posteriormente na seção sobre estimabilidade.

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

essa expressão reduz-se a

$$\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top. \quad (11.49)$$

O projetor sobre o complemento ortogonal é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z. \quad (11.50)$$

As propriedades gerais dos projetores ortogonais foram desenvolvidas em Proposição 3.15 e Definição 3.20. Em particular,

$$\mathbf{P}_Z^\top = \mathbf{P}_Z, \quad \mathbf{P}_Z^2 = \mathbf{P}_Z,$$

$$\mathbf{M}_Z^\top = \mathbf{M}_Z, \quad \mathbf{M}_Z^2 = \mathbf{M}_Z,$$

e

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{M}_Z \mathbf{P}_Z = \mathbf{0}. \quad (11.51)$$

Além disso,

$$\text{posto}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r. \quad (11.52)$$

Essas dimensões terão interpretação direta nos graus de liberdade associados ao ajuste e ao resíduo.

11.3.1 Valores ajustados e resíduos

Definição 11.9 (Valores ajustados). A matriz aleatória de valores ajustados é

$$\hat{y} = \mathbf{P}_Z y. \quad (11.53)$$

Após a observação,

$$\hat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y}. \quad (11.54)$$

Como

$$\mathbf{P}_Z \mathbf{Z} = \mathbf{Z},$$

tem-se

$$\begin{aligned} \hat{y} &= \mathbf{P}_Z (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{Z}\mathbf{B} + \mathbf{P}_Z \mathcal{E}. \end{aligned} \quad (11.55)$$

Portanto, os valores ajustados preservam a estrutura sistemática do modelo e incorporam a projeção dos erros sobre o espaço do delineamento.

Definição 11.10 (Resíduos). A matriz aleatória de resíduos é

$$\hat{u} = y - \hat{y} = \mathbf{M}_Z y. \quad (11.56)$$

Após a observação,

$$\hat{\mathbf{U}} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{M}_Z \mathbf{Y}. \quad (11.57)$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

segue que

$$\hat{u} = \mathbf{M}_Z \mathcal{E}. \quad (11.58)$$

Os resíduos são, portanto, a parcela dos erros pertencente ao complemento ortogonal de

$$\mathcal{C}(\mathbf{Z}).$$

Para cada realização,

$$\mathbf{Y} = \widehat{\mathbf{Y}} + \widehat{\mathbf{U}}. \quad (11.59)$$

A decomposição ocorre coluna a coluna: cada vetor de respostas observadas é separado em sua projeção sobre o espaço do modelo e em um resíduo ortogonal a esse espaço.

11.3.2 Ortogonalidade

As equações normais já forneceram

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Além disso,

$$\begin{aligned} \widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} &= \mathbf{Y}^\top \mathbf{P}_Z \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{0}. \end{aligned} \quad (11.60)$$

Assim, para quaisquer respostas j e k ,

$$\widehat{\mathbf{y}}_{.j}^\top \widehat{\mathbf{u}}_{.k} = 0.$$

A ortogonalidade não ocorre somente entre o ajuste e o resíduo da mesma resposta. Como o mesmo par de projetores atua sobre todas as colunas de $\mathbf{Y}$, qualquer coluna ajustada é ortogonal a qualquer coluna residual.

Consequentemente,

$$\|\mathbf{Y}\|_F^2 = \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2. \quad (11.61)$$

Essa identidade refere-se aos produtos internos em relação à origem. Quando o modelo contém intercepto, a decomposição da dispersão em torno do vetor de médias amostrais será expressa posteriormente por SQPCs.

11.3.3 Esperança dos valores ajustados e dos resíduos

Proposição 11.5 (Esperança dos valores ajustados e dos resíduos). *Sob*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

tem-se

$$E(\hat{\mathcal{Y}} \mid \mathbf{Z}) = \mathbf{ZB} \quad (11.62)$$

e

$$E(\hat{\mathcal{U}} \mid \mathbf{Z}) = \mathbf{0}. \quad (11.63)$$

De fato,

$$\begin{aligned} E(\hat{\mathcal{Y}} \mid \mathbf{Z}) &= \mathbf{P}_Z E(\mathcal{Y} \mid \mathbf{Z}) \\ &= \mathbf{P}_Z \mathbf{ZB} \\ &= \mathbf{ZB}, \end{aligned}$$

enquanto

$$\begin{aligned} E(\hat{\mathcal{U}} \mid \mathbf{Z}) &= \mathbf{M}_Z \mathbf{ZB} \\ &= \mathbf{0}. \end{aligned}$$

Os valores ajustados são, portanto, não viesados para a matriz de médias representável pelo modelo, enquanto os resíduos possuem média condicional nula.

11.3.4 Covariâncias dos valores ajustados e dos resíduos

A forma vetorizada permite obter diretamente suas matrizes de covariâncias.

Como

$$\text{vec}(\mathbf{P}_Z \mathcal{E}) = (\mathbf{I}_p \otimes \mathbf{P}_Z) \text{vec}(\mathcal{E}),$$

tem-se

Proposição 11.6 (Covariâncias dos valores ajustados e dos resíduos). *Sob*

$$\text{Cov} [\text{vec} (\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

vale

$$\text{Cov} [\text{vec} (\hat{\mathbf{y}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{P}_Z \quad (11.64)$$

e

$$\text{Cov} [\text{vec} (\hat{\mathbf{u}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z. \quad (11.65)$$

Além disso,

$$\text{Cov} [\text{vec} (\hat{\mathbf{y}}), \text{vec} (\hat{\mathbf{u}}) \mid \mathbf{Z}] = \mathbf{0}. \quad (11.66)$$

A última igualdade decorre de

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{0}.$$

Os valores ajustados e os resíduos são, portanto, não correlacionados. Sob o modelo normal matricial, eles são conjuntamente normais e, conseqüentemente, independentes. A utilização dessa independência na construção das distribuições amostrais será retomada no Capítulo 12.

As matrizes

$$\Sigma \otimes \mathbf{P}_Z$$

e

$$\Sigma \otimes \mathbf{M}_Z$$

também mostram que o ajuste pode induzir dependência entre valores ajustados ou resíduos associados a unidades distintas. Embora os erros originais sejam não correlacionados entre unidades, os valores ajustados e os resíduos resultam de projeções que utilizam conjuntamente todas as observações.

A análise de medidas de influência e alavancagem pertence ao diagnóstico de modelos e não será desenvolvida neste capítulo.

11.3.5 Representação dos ajustes e resíduos

A Figura 11.1 apresenta um modelo com uma variável explicativa e duas respostas. As duas colunas da matriz de respostas utilizam o mesmo espaço de ajuste, mas possuem coeficientes e resíduos próprios.




Figura 11.1: Valores observados, retas ajustadas e resíduos para duas respostas modeladas pela mesma variável explicativa.

Os segmentos verticais representam os resíduos de cada resposta. O mesmo projetor $\mathbf{P}_Z$ determina as posições ajustadas nas duas colunas, enquanto a associação residual entre as respostas não é representada diretamente nos painéis.

Essa associação será resumida pela SQPC residual.

11.3.6 Conexão com o modelo contendo somente intercepto

Quando

$$\mathbf{Z} = \mathbf{1}_n,$$

tem-se

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top = \mathbf{H}_n. \quad (11.67)$$

Assim,

$$\widehat{\mathbf{Y}} = \mathbf{1}_n \bar{\mathbf{y}}^\top,$$

enquanto

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y}.$$

A matriz residual coincide, nesse caso, com a matriz de respostas centralizada. Portanto, a centralização utilizada nos Capítulos 8 e 10 aparece como um caso particular da projeção residual no modelo linear multivariado.

A próxima seção utilizará

$$\widehat{\mathbf{U}}$$

para construir a SQPC residual, determinar seus graus de liberdade e estimar a matriz de covariâncias Σ .

11.4 SQPC residual e estimação da covariância

A matriz de resíduos

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

contém os desvios das respostas em relação aos valores ajustados pelo modelo. Os produtos cruzados entre esses resíduos formam uma matriz que descreve a dispersão conjunta que permanece após o ajuste e permite estimar

$$\Sigma,$$

a matriz de covariâncias dos erros.

No modelo contendo somente intercepto, essa construção recupera a SQPC amostral dos Capítulos 8 e 10. No modelo linear geral, o ajuste remove um espaço de médias de dimensão

$$r = \text{posto}(\mathbf{Z}),$$

restando um espaço residual de dimensão $n - r$.

11.4.1 Construção da SQPC residual

Definição 11.11 (SQPC residual). A SQPC residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}. \quad (11.68)$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{y},$$

e $\mathbf{M}_Z$ é simétrica e idempotente,

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}. \quad (11.69)$$

Após a observação,

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.70)$$

O elemento (j, k) de $\mathbf{E}$ é

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}. \quad (11.71)$$

Para $j = k$,

$$e_{jj} = \sum_{i=1}^n \hat{u}_{ij}^2$$

é a soma de quadrados residual da resposta j . Para $j \neq k$, e_{jk} é o produto cruzado residual entre as respostas j e k .

Como

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

e

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}, \quad (11.72)$$

e, conseqüentemente,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}. \quad (11.73)$$

A SQPC residual depende do espaço de médias removido pelo ajuste por meio de $\mathbf{M}_Z$, mas não depende do valor específico de $\mathbf{B}$.

Como toda matriz de Gram, $\mathbf{E}$ é simétrica e positiva semidefinida. Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

$$\begin{aligned} \mathbf{a}^\top \mathbf{E} \mathbf{a} &= \|\widehat{\mathbf{U}} \mathbf{a}\|^2 \\ &\geq 0. \end{aligned} \quad (11.74)$$

A forma quadrática corresponde à soma de quadrados residual da combinação linear das respostas

$$\mathbf{Y} \mathbf{a}.$$

De fato,

$$\widehat{\mathbf{u}}_{\mathbf{a}} = \mathbf{M}_Z \mathbf{Y} \mathbf{a} = \widehat{\mathbf{U}} \mathbf{a},$$

e

$$\widehat{\mathbf{u}}_{\mathbf{a}}^\top \widehat{\mathbf{u}}_{\mathbf{a}} = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.75)$$

Se as respostas forem transformadas por

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{p \times s},$$

então

$$\widehat{\mathbf{U}}^* = \widehat{\mathbf{U}}\mathbf{A}$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (11.76)$$

Essa transformação é coerente com a regra populacional

$$\Sigma^* = \mathbf{A}^\top \Sigma \mathbf{A}$$

e será utilizada posteriormente em hipóteses sobre combinações das respostas.

11.4.2 Esperança e graus de liberdade

A dimensão do espaço residual é determinada pelo posto da matriz de delineamento.

Como

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z,$$

tem-se

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r.$$

Definição 11.12 (Graus de liberdade residuais). Se

$$r = \text{posto}(\mathbf{Z}),$$

os graus de liberdade residuais são

$$\nu_E = n - r. \quad (11.77)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e, portanto,

$$\nu_E = n - q.$$

A expressão utiliza r , e não simplesmente o número de colunas de $\mathbf{Z}$, porque somente as r direções linearmente independentes do espaço do modelo consomem graus de liberdade. Colunas redundantes não aumentam a dimensão do espaço de médias ajustado.

Proposição 11.7 (Esperança da SQPC residual). *Sob a estrutura do modelo linear multivariado,*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma,$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_\ell \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq \ell,$$

com

$$r = \text{posto}(\mathbf{Z}),$$

tem-se

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \tag{11.78}$$

i Demonstração

Pela Equação 11.73,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

Considere o elemento (j, k) :

$$[\mathbf{E}_{\text{res}}]_{jk} = \varepsilon_{\cdot j}^\top \mathbf{M}_Z \varepsilon_{\cdot k}.$$

Escrevendo

$$\mathbf{M}_Z = (m_{i\ell}),$$

obtem-se

$$[\mathbf{E}_{\text{res}}]_{jk} = \sum_{i=1}^n \sum_{\ell=1}^n m_{i\ell} \varepsilon_{ij} \varepsilon_{\ell k}.$$

Para $i \neq \ell$,

$$E(\varepsilon_{ij} \varepsilon_{\ell k} \mid \mathbf{Z}) = 0,$$

enquanto, para $i = \ell$,

$$E(\varepsilon_{ij} \varepsilon_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

Logo,

$$\begin{aligned} E\left([\mathbf{E}_{\text{res}}]_{jk} \mid \mathbf{Z}\right) &= \sum_{i=1}^n m_{ii} \sigma_{jk} \\ &= \text{tr}(\mathbf{M}_Z) \sigma_{jk} \\ &= (n - r) \sigma_{jk}. \end{aligned}$$

Como a igualdade vale para todos os elementos,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r) \Sigma.$$

A expressão generaliza Proposição 10.10, que estabelece

$$E(\mathbf{T}) = (n - 1) \Sigma.$$

No modelo contendo somente intercepto,

$$r = 1,$$

de modo que

$$n - r = n - 1.$$

No modelo linear geral, cada direção independente utilizada para representar a estrutura de médias reduz em uma unidade a dimensão do espaço residual.

11.4.3 Estimação da covariância residual

Definição 11.13 (Estimador residual da matriz de covariâncias). Se

$$r = \text{posto}(\mathbf{Z})$$

e

$$n - r > 0,$$

define-se

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}. \quad (11.79)$$

Após a observação,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}. \quad (11.80)$$

Proposição 11.8 (Não viesamento do estimador residual). Se

$$r = \text{posto}(\mathbf{Z}), \quad n - r > 0,$$

e

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

então

$$E(\widehat{\Sigma} \mid \mathbf{Z}) = \Sigma. \quad (11.81)$$

Portanto, $\widehat{\Sigma}$ é um estimador não viesado da matriz de covariâncias dos erros.

i Demonstração

Por Equação 11.79 e Equação 11.78,

$$\begin{aligned} E(\widehat{\Sigma} \mid \mathbf{Z}) &= \frac{1}{n-r} E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) \\ &= \frac{1}{n-r} (n-r)\Sigma \\ &= \Sigma. \end{aligned}$$

Componente a componente,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{e_{jk}}{n-r}. \quad (11.82)$$

Assim,

$$\hat{\sigma}_{jj,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij}^2$$

estima a variância residual da resposta j , enquanto, para $j \neq k$,

$$\hat{\sigma}_{jk,\text{obs}} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

estima a covariância residual entre as respostas j e k .

A matriz de correlações residuais pode ser obtida pela mesma padronização utilizada nos Capítulos 8 e 10, desde que as variâncias residuais estimadas sejam positivas. Não é necessário introduzir uma nova construção: aplica-se

$$\mathbf{D}^{-1/2} \widehat{\Sigma}_{\text{obs}} \mathbf{D}^{-1/2}$$

com a matriz diagonal correspondente às variâncias residuais estimadas.

Covariância total e covariância residual

A matriz de covariâncias calculada diretamente das respostas descreve a variabilidade conjunta observada antes do ajuste.

A matriz

$$\widehat{\Sigma}_{\text{obs}}$$

descreve a variabilidade que permanece depois de removida a estrutura de médias pertencen-

cente a

$$\mathcal{C}(\mathbf{Z}).$$

Por isso, em geral, as duas matrizes não coincidem.

11.4.4 Estimador de máxima verossimilhança

Sob o modelo normal matricial, depois da maximização em relação à estrutura de médias, a parte da log-verossimilhança que depende de Σ é, a menos de constantes,

$$\ell_c(\Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{E}). \quad (11.83)$$

Quando

$$\mathbf{E} \succ \mathbf{0},$$

o máximo no espaço

$$\Sigma \succ \mathbf{0}$$

é alcançado em

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}. \quad (11.84)$$

Como

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

a estatística com divisor n satisfaz

$$E\left(\frac{\mathbf{E}_{\text{res}}}{n} \mid \mathbf{Z}\right) = \frac{n - r}{n} \Sigma.$$

Portanto, seu viés é

$$-\frac{r}{n} \Sigma.$$

Assim, o divisor $n - r$ produz o estimador não viesado, enquanto o divisor n é utilizado pela máxima verossimilhança sob normalidade e existência do máximo. Essa relação generaliza Equação 10.72, na qual os divisores correspondentes são $n - 1$ e n .

Existência do estimador de máxima verossimilhança

A expressão

$$\frac{\mathbf{E}}{n}$$

é a estimativa de máxima verossimilhança de Σ no modelo normal não singular somente quando

$$\mathbf{E} \succ \mathbf{0}.$$

Se $\mathbf{E}$ é singular, a verossimilhança não possui máximo no interior do espaço

$$\Sigma \succ \mathbf{0}.$$

A matriz $\mathbf{E}/n$ continua sendo calculável, mas perde essa interpretação de máxima verossimilhança no modelo positivo definido.

11.4.5 Posto e singularidade

A SQPC residual possui a forma de Gram

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}.$$

Portanto,

$$\text{posto}(\mathbf{E}) = \text{posto}(\widehat{\mathbf{U}}).$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r,$$

obtém-se:

Proposição 11.9 (Posto da SQPC residual). *Se*

$$r = \text{posto}(\mathbf{Z}),$$

a SQPC residual observada

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}$$

satisfaz

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.85)$$

Consequentemente, se

$$p > n - r,$$

então $\mathbf{E}$ é necessariamente singular.

Uma condição necessária para

$$\mathbf{E} \succ \mathbf{0}$$

é

$$n - r \geq p. \quad (11.86)$$

Para uma amostra arbitrária, essa desigualdade não é suficiente: também é necessário

$$\text{posto}(\widehat{\mathbf{U}}) = p.$$

Portanto, uma condição necessária para que a SQPC residual seja positiva definida é haver pelo menos p dimensões residuais,

$$n - r \geq p.$$

A desigualdade, isoladamente, não garante posto completo em uma amostra arbitrária; também é necessário que os resíduos observados gerem p direções linearmente independentes.

O limite de posto é a extensão de Equação 10.81, que no caso de uma única média fornece

$$\text{posto}(\mathbf{S}) \leq \min(p, n-1).$$

Questões de condicionamento, pseudoinversa e regularização continuam pertinentes às matrizes residuais, mas não serão novamente desenvolvidas aqui. O condicionamento foi discutido em Equação 10.108, a pseudoinversa em Equação 10.117 e a regularização por contração em Definição 10.18.

11.4.6 Modelo contendo somente intercepto

Considere

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$r = 1,$$

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{H}_n.$$

Logo,

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y},$$

e a SQPC residual observada é

$$\begin{aligned} \mathbf{E} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \end{aligned} \tag{11.87}$$

Essa matriz é exatamente a SQPC total observada

$$\mathbf{T}$$

definida em Definição 8.10 e correspondente à realização da estatística aleatória definida em Definição 10.13.

Como

$$n - r = n - 1,$$

obtém-se

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - 1} = \mathbf{S}, \quad (11.88)$$

recuperando Definição 10.14.

Sob normalidade e quando a SQPC possui posto completo,

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n},$$

em concordância com Equação 10.44.

Portanto, no modelo contendo somente intercepto,

$$\mathbf{E} = \mathbf{T}$$

e

$$\frac{\mathbf{E}}{n - 1} = \mathbf{S}.$$

Assim, a SQPC residual e o estimador não viesado da covariância residual recuperam exatamente os objetos estudados nos Capítulos 8 e 10. O modelo linear multivariado substitui a remoção de uma única média pela remoção de toda a estrutura de médias representada por

$$\mathcal{C}(\mathbf{Z}).$$

A próxima seção separa a SQPC total em uma parcela associada ao modelo e uma parcela residual.

11.5 Decomposição da variação multivariada

Quando o espaço coluna de $\mathbf{Z}$ contém o vetor $\mathbf{1}_n$, a dispersão das respostas em torno do vetor de médias amostrais pode ser decomposta em uma parcela associada ao modelo e uma parcela residual. Essa condição é satisfeita, por exemplo, quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

No caso univariado, essa separação produz as somas de quadrados utilizadas na análise de variância. No modelo multivariado, cada parcela é representada por uma matriz SQPC, preservando também os produtos cruzados entre as respostas.

A principal decomposição é

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

em que $\mathbf{T}$ representa a dispersão total em torno da média geral, $\mathbf{T}_{\text{mod}}$ representa a dispersão dos valores ajustados em torno da média geral e $\mathbf{E}$ representa a dispersão residual em torno dos valores ajustados.

11.5.1 SQPC total

A SQPC total observada foi definida em Definição 8.10. Aplicada à matriz de respostas,

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y}, \quad (11.89)$$

em que $\mathbf{H}_n$ é a matriz de centralização utilizada em Equação 8.58:

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

Equivalentemente,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top, \quad (11.90)$$

com

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n.$$

A matriz $\mathbf{T}$ descreve a dispersão conjunta das respostas antes da remoção da estrutura explicada pelo delineamento.

11.5.2 SQPC associada ao modelo

Suponha que a direção constante pertença ao espaço do modelo, isto é,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}). \quad (11.91)$$

Essa condição é satisfeita quando o modelo possui um intercepto explícito e também em parametrizações nas quais a média geral pertence ao espaço do modelo sem corresponder a uma coluna específica de $\mathbf{Z}$.

Defina o projetor sobre o espaço das constantes por

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (11.92)$$

Como

$$\mathcal{C}(\mathbf{1}_n) \subseteq \mathcal{C}(\mathbf{Z}),$$

tem-se

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1. \quad (11.93)$$

Consequentemente,

$$\mathbf{P}_Z - \mathbf{P}_1$$

é o projetor ortogonal sobre a parte de $\mathcal{C}(\mathbf{Z})$ ortogonal à direção constante. Essa parte representa as variações ajustadas pelo modelo em torno da média geral.

Seu posto é

$$\text{posto}(\mathbf{P}_Z - \mathbf{P}_1) = r - 1, \quad (11.94)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Definição 11.14 (SQPC associada ao modelo, corrigida pela média geral). Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

define-se

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \quad (11.95)$$

em que $\mathbf{P}_Z$ é o projetor sobre $\mathcal{C}(\mathbf{Z})$ e

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

é o projetor sobre a direção constante.

Se

$$\mathcal{C}(\mathbf{Z}) = \mathcal{C}(\mathbf{1}_n),$$

então

$$\mathbf{P}_Z = \mathbf{P}_1$$

e, conseqüentemente,

$$\mathbf{T}_{\text{mod}} = \mathbf{0}.$$

Assim, $\mathbf{T}_{\text{mod}}$ quantifica somente a variação ajustada que excede a representação da média geral.

A matriz

$$\mathbf{T}_{\text{mod}}$$

mede a dispersão dos valores ajustados pelo modelo em torno da média geral. No modelo de grupos, essa matriz coincide com a dispersão entre grupos. Em modelos com covariáveis, ela representa conjuntamente a variação dos valores ajustados em torno da média geral.

Se

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y},$$

então os valores ajustados centralizados são

$$\widehat{\mathbf{Y}}_c = \widehat{\mathbf{Y}} - \mathbf{1}_n \bar{\mathbf{y}}^\top = (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

Logo,

$$\mathbf{T}_{\text{mod}} = \widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c. \quad (11.96)$$

Para qualquer combinação linear das respostas,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} = \|(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} \mathbf{a}\|^2. \quad (11.97)$$

Portanto, $\mathbf{T}_{\text{mod}}$ reúne, para todas as combinações lineares das respostas, as somas de quadrados dos valores ajustados em torno da respectiva média geral.

11.5.3 Decomposição entre modelo e resíduo

Sob a condição

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

considere

$$\mathbf{H}_n = \mathbf{I}_n - \mathbf{P}_1$$

e

$$\mathbf{I}_n = \mathbf{P}_Z + \mathbf{M}_Z.$$

segue que

$$\mathbf{H}_n = (\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z. \quad (11.98)$$

Além disso,

$$(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{M}_Z = \mathbf{0}.$$

Assim, as duas parcelas correspondem a subespaços ortogonais.

Proposição 11.10 (Decomposição da SQPC total). *Se*

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

então

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}, \quad (11.99)$$

em que

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

$$\mathbf{T}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

i Demonstração

Substituindo Equação 11.98 na definição de $\mathbf{T}$,

$$\begin{aligned} \mathbf{T} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \mathbf{Y}^\top [(\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z] \mathbf{Y} \\ &= \mathbf{T}_{\text{mod}} + \mathbf{E}. \end{aligned}$$

A decomposição pode ser escrita também como

$$\begin{aligned} &\sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top \\ &= \sum_{i=1}^n (\hat{\mathbf{y}}_i - \bar{\mathbf{y}}) (\hat{\mathbf{y}}_i - \bar{\mathbf{y}})^\top \\ &\quad + \sum_{i=1}^n (\mathbf{y}_i - \hat{\mathbf{y}}_i) (\mathbf{y}_i - \hat{\mathbf{y}}_i)^\top. \end{aligned} \quad (11.100)$$

A primeira parcela à direita é $\mathbf{T}_{\text{mod}}$ e a segunda é $\mathbf{E}$.

As dimensões dos subespaços correspondentes fornecem

$$n - 1 = (r - 1) + (n - r). \quad (11.101)$$

A Tabela 11.1 resume as dimensões dos três subespaços envolvidos.

Tabela 11.1: Decomposição das dimensões associadas à SQPC total quando a direção constante pertence ao espaço do modelo.

Fonte	Projetor	Graus de liberdade
Total corrigido pela média geral	$\mathbf{H}_n$	$n - 1$
Modelo corrigido pela média geral	$\mathbf{P}_Z - \mathbf{P}_1$	$r - 1$
Residual	$\mathbf{M}_Z$	$n - r$

Os graus de liberdade correspondem aos postos dos projetores no espaço das unidades. Eles não devem ser confundidos com os postos das matrizes de SQPC, que também dependem de p .

Em particular,

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{T}_{\text{mod}}) \leq \min(p, r - 1),$$

e

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.102)$$

11.5.4 Combinações lineares das respostas

A decomposição matricial contém, simultaneamente, as decomposições correspondentes a todas as combinações lineares das respostas.

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a} + \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.103)$$

Cada termo possui interpretação univariada:

$$\mathbf{a}^\top \mathbf{T} \mathbf{a}$$

é a soma de quadrados total de $\mathbf{Y}\mathbf{a}$,

$$\mathbf{a}^\top \mathbf{T}_{\text{mod}} \mathbf{a}$$

é a soma de quadrados associada ao modelo, e

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

é a soma de quadrados residual.

Essa relação é suficiente, neste capítulo, para mostrar como a decomposição matricial preserva simultaneamente as decomposições das respostas originais e de suas combinações lineares. A utilização conjunta dessas matrizes em procedimentos inferenciais será desenvolvida no Capítulo 12 e, posteriormente, na formulação das técnicas multivariadas.

11.5.5 Modelos sem intercepto

Se

$$\mathbf{1}_n \notin \mathcal{C}(\mathbf{Z}),$$

a decomposição corrigida

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}$$

não se aplica na forma anterior, porque $\mathbf{P}_Z - \mathbf{P}_1$ não é, em geral, um projetor.

Permanece válida a decomposição em relação à origem,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.104)$$

Essa identidade não deve ser interpretada como uma decomposição da dispersão em torno da média amostral. No restante deste capítulo, a decomposição total–modelo–resíduo será utilizada principalmente quando a direção constante pertence ao espaço coluna de $\mathbf{Z}$.

11.5.6 Modelo de grupos como caso particular

Considere K grupos não vazios. Uma parametrização particularmente simples utiliza uma coluna indicadora para cada grupo. Para três grupos, por exemplo, a matriz de delineamento possui a forma

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ \vdots & \vdots & \vdots \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ \vdots & \vdots & \vdots \\ 0 & 0 & 1 \end{bmatrix},$$

em que cada linha identifica o grupo da respectiva unidade.

Na parametrização por médias de grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

em que $\mathcal{J}_k$ representa o conjunto dos índices das unidades pertencentes ao grupo k . Assim,

$$E(\mathbf{Y}_i \mid i \in \mathcal{J}_k) = \mu_k.$$

O estimador de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} \bar{\mathbf{y}}_1^\top \\ \vdots \\ \bar{\mathbf{y}}_K^\top \end{bmatrix}. \quad (11.105)$$

Portanto, o vetor ajustado para cada unidade é a média amostral do grupo ao qual ela pertence.

A SQPC residual é

$$\mathbf{E} = \sum_{k=1}^K \sum_{i \in \mathcal{J}_k} (\mathbf{y}_i - \bar{\mathbf{y}}_k) (\mathbf{y}_i - \bar{\mathbf{y}}_k)^\top. \quad (11.106)$$

Pela definição de dispersão intragrupos em Definição 8.14,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}. \quad (11.107)$$

Assim, a SQPC residual do modelo de grupos mede exatamente a dispersão das observações em torno das médias de seus respectivos grupos.

A parcela associada ao modelo é

$$\mathbf{T}_{\text{mod}} = \sum_{k=1}^K n_k (\bar{\mathbf{y}}_k - \bar{\mathbf{y}}) (\bar{\mathbf{y}}_k - \bar{\mathbf{y}})^\top. \quad (11.108)$$

Por Definição 8.15,

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}. \quad (11.109)$$

Portanto,

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}, \quad (11.110)$$

recuperando Proposição 8.10 como um caso particular do modelo linear multivariado.

Os graus de liberdade também se decompõem como

$$n - 1 = (K - 1) + (n - K). \quad (11.111)$$

A Figura 11.2 representa geometricamente as duas parcelas dessa decomposição. Os segmentos que ligam cada observação à média de seu grupo representam desvios intragrupos, enquanto os segmentos tracejados que ligam as médias dos grupos à média geral representam os deslocamentos responsáveis pela dispersão entre grupos.

As cruzes representam as médias dos grupos e o asterisco representa a média geral. Os segmentos internos aos grupos visualizam os termos associados a $\mathbf{T}_{\text{intra}}$, enquanto os deslocamentos das médias dos grupos em relação à média geral visualizam a estrutura associada a $\mathbf{T}_{\text{entre}}$.

A decomposição depende do espaço de médias representado por $\mathbf{Z}$, e não de uma parametrização específica desse espaço. Essa distinção motiva a discussão de posto, parametrização e estimabilidade da próxima seção.




Figura 11.2: Dispersão intragrupos e deslocamento das médias dos grupos em relação à média geral.

11.6 Posto, parametrização e estimabilidade

A expressão

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

exige

$$\text{posto}(\mathbf{Z}) = q.$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente independentes e os coeficientes de $\mathbf{B}$ são determinados pela parametrização adotada.

Alguns modelos, especialmente aqueles que representam grupos ou fatores, podem ser escritos com colunas redundantes em $\mathbf{Z}$. Diferentes valores dos coeficientes podem então representar exatamente a mesma estrutura de médias

$$\mathbf{Z}\mathbf{B}.$$

Por isso, é necessário distinguir a unicidade dos coeficientes da unicidade dos valores ajustados e das combinações de parâmetros que se deseja interpretar.

11.6.1 Delineamento com posto deficiente

Considere

$$\mathbf{Z} \in \mathbb{R}^{n \times q}$$

com

$$r = \text{posto}(\mathbf{Z}) < q. \quad (11.112)$$

Nesse caso, as colunas de $\mathbf{Z}$ são linearmente dependentes. Portanto, existe pelo menos um vetor não nulo

$$\mathbf{d} \in \mathbb{R}^q$$

tal que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Consequentemente, alterações dos coeficientes em direções pertencentes ao núcleo de $\mathbf{Z}$ não modificam a estrutura de médias.

Definição 11.15 (Matrizes de parâmetros equivalentes). Duas matrizes

$$\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{q \times p}$$

são equivalentes em relação a $\mathbf{Z}$ quando

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2. \quad (11.113)$$

Assim, quando $r < q$, os coeficientes individuais de $\mathbf{B}$ podem não ser únicos, embora a matriz de médias

$$\mathbf{Z}\mathbf{B}$$

continue unicamente determinada pelo modelo.

11.6.2 Pseudoinversa e unicidade do ajuste

A pseudoinversa de Moore–Penrose e sua relação com mínimos quadrados foram desenvolvidas em Definição 6.11 e Proposição 6.22.

Quando

$$r < q,$$

a matriz

$$\mathbf{Z}^\top \mathbf{Z}$$

é singular, mas o problema de mínimos quadrados continua tendo solução. Uma delas é

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}. \quad (11.114)$$

Proposição 11.11 (Unicidade dos valores ajustados sob posto deficiente). *Mesmo quando os coeficientes de mínimos quadrados não são únicos, todas as soluções produzem a mesma matriz de valores ajustados,*

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.115)$$

Consequentemente, também são únicos

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}$$

e

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Portanto, a deficiência de posto pode impedir a interpretação única de determinados coeficientes sem impedir o cálculo dos valores ajustados, dos resíduos e da SQPC residual.

Os graus de liberdade residuais continuam sendo determinados pelo posto efetivo,

$$\nu_E = n - r,$$

e o estimador não viesado da covariância residual permanece

$$\hat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}.$$

11.6.3 Funções estimáveis

Quando os coeficientes de $\mathbf{B}$ não são individualmente identificados, ainda podem existir combinações deles que sejam determinadas unicamente pela estrutura de médias. Essas combinações são particularmente importantes em modelos com fatores, nos quais comparações entre grupos podem ser estimáveis mesmo quando uma parametrização utiliza coeficientes redundantes.

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina os termos do modelo representados nas linhas de $\mathbf{B}$.

Definição 11.16 (Função linear estimável). Para

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

a função

$$\mathbf{CB}$$

é estimável quando existe uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times g}$$

tal que

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{CB}$$

para toda matriz de parâmetros $\mathbf{B}$.

Como

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB},$$

a condição anterior equivale a

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}. \tag{11.116}$$

Portanto, a estimabilidade depende do espaço linha de $\mathbf{Z}$.

Proposição 11.12 (Caracterização das funções estimáveis). *Para*

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

são equivalentes:

1. $\mathbf{CB}$ é estimável;
2. as linhas de $\mathbf{C}$ pertencem ao espaço linha de $\mathbf{Z}$,

$$\mathcal{C}(\mathbf{C}^\top) \subseteq \mathcal{C}(\mathbf{Z}^\top);$$

3. vale

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

Em particular,

$$\mathbf{CB} \text{ é estimável} \iff \mathbf{C} = \mathbf{CZ}^+\mathbf{Z}. \quad (11.117)$$

i Demonstração

Pela definição de estimabilidade, deve existir uma matriz $\mathbf{A}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z}.$$

Isso ocorre exatamente quando cada linha de $\mathbf{C}$ pertence ao espaço linha de $\mathbf{Z}$.

Como

$$\mathbf{Z}^+\mathbf{Z}$$

é o projetor ortogonal sobre esse espaço, a mesma condição pode ser escrita como

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A caracterização também pode ser expressa diretamente em termos das parametrizações equivalentes.

Se

$$\mathbf{ZB}_1 = \mathbf{ZB}_2,$$

então

$$\mathbf{CB}$$

é estimável se

$$\mathbf{CB}_1 = \mathbf{CB}_2$$

para todas as matrizes de parâmetros equivalentes.

Isso ocorre precisamente porque $\mathbf{C}$ elimina as componentes pertencentes ao núcleo de $\mathbf{Z}$.

11.6.4 Estimador de uma função estimável

Quando $\mathbf{CB}$ é estimável, pode-se utilizar

$$\widehat{\Theta}_C = \mathbf{CZ}^+ \mathbf{y}. \quad (11.118)$$

Como

$$\mathbf{C} = \mathbf{CZ}^+ \mathbf{Z},$$

tem-se

$$E(\widehat{\Theta}_C | \mathbf{Z}) = \mathbf{CB}. \quad (11.119)$$

Portanto, uma função estimável possui o mesmo valor independentemente da representação utilizada para os coeficientes redundantes. Essa propriedade permitirá formular contrastes e hipóteses sobre efeitos do modelo sem depender da parametrização escolhida.

11.6.5 Parametrizações equivalentes

Diferentes matrizes de delineamento podem representar o mesmo conjunto de estruturas de médias.

Se

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2), \quad (11.120)$$

então

$$\mathbf{P}_{\mathbf{Z}_1} = \mathbf{P}_{\mathbf{Z}_2},$$

e, para a mesma matriz de respostas, os dois modelos produzem os mesmos valores ajustados, resíduos e SQPC residual.

Essa situação ocorre, por exemplo, quando um fator é representado por diferentes sistemas de codificação. Os coeficientes individuais podem mudar de interpretação, mas as médias ajustadas e os contrastes estimáveis permanecem os mesmos.

O objeto que caracteriza a estrutura de médias é, portanto,

$$\mathcal{C}(\mathbf{Z}),$$

e não uma lista específica de coeficientes.

Deficiência de posto e mau condicionamento são problemas distintos. A deficiência de posto corresponde a dependências lineares exatas entre as colunas de $\mathbf{Z}$; o mau condicionamento pode ocorrer mesmo com posto completo e tornar os coeficientes sensíveis a pequenas perturbações. O número de condição definido em Definição 6.9 e a SVD definida em Definição 6.3 podem ser utilizados no diagnóstico desse problema.

A distinção entre coeficientes individuais e funções estimáveis permite formular comparações que não dependem da parametrização adotada. Na próxima seção, essas comparações serão expressas como hipóteses lineares sobre os termos do modelo e sobre as respostas.

11.7 Hipóteses lineares multivariadas

O modelo linear multivariado permite formular hipóteses sobre termos do modelo, diferenças entre grupos e combinações das respostas. A formulação será construída progressivamente, começando por combinações das linhas de $\mathbf{B}$ e, depois, incorporando combinações de suas colunas (Rao, 1973; Rencher; Christensen, 2012).

11.7.1 Combinações dos termos do modelo

Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}.$$

A matriz

$$\mathbf{C}_1 \mathbf{B} \in \mathbb{R}^{g \times p}$$

combina os termos representados nas linhas de $\mathbf{B}$.

Se

$$\mathbf{c}_1^\top \in \mathbb{R}^{1 \times q}$$

é uma linha de $\mathbf{C}_1$, então

$$\mathbf{c}_1^\top \mathbf{B} \in \mathbb{R}^{1 \times p}$$

contém a mesma combinação dos termos para todas as p respostas.

Por exemplo, se a linha h de $\mathbf{B}$ corresponde a um único termo do modelo,

$$\mathbf{c}_1^\top = \mathbf{e}_h^\top$$

seleciona os coeficientes desse termo nas p respostas.

No modelo parametrizado diretamente pelas médias de K grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_K^\top \end{bmatrix},$$

uma combinação

$$\mathbf{c}_1^\top \mathbf{B} = \sum_{k=1}^K c_{1k} \mu_k^\top$$

é um contraste entre os vetores de médias quando

$$\sum_{k=1}^K c_{1k} = 0.$$

Por exemplo,

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

produz

$$\mathbf{c}_1^\top \mathbf{B} = (\mu_1 - \mu_2)^\top.$$

Assim, uma única linha de $\mathbf{C}_1$ pode representar uma comparação entre grupos, enquanto várias linhas permitem representar simultaneamente diferentes contrastes.

11.7.2 Combinações das respostas

A multiplicação à direita de $\mathbf{B}$ atua sobre as respostas. Considere

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

Então,

$$\mathbf{BC}_2 \in \mathbb{R}^{q \times s}$$

contém os efeitos do modelo sobre as s combinações de respostas definidas por $\mathbf{C}_2$.

Para uma única combinação, considere

$$\mathbf{c}_2 \in \mathbb{R}^p$$

e defina

$$W_i = \mathbf{c}_2^\top \mathbf{Y}_i.$$

Sua média condicional é

$$E(W_i | \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{BC}_2, \quad (11.121)$$

e sua variância residual é

$$\text{Var}(W_i | \mathbf{Z}) = \mathbf{c}_2^\top \Sigma \mathbf{c}_2. \quad (11.122)$$

Para várias combinações simultâneas,

$$\mathbf{y}_{C_2} = \mathbf{y} \mathbf{C}_2,$$

e

$$\mathbf{y}_{C_2} = \mathbf{Z}(\mathbf{BC}_2) + \mathcal{E} \mathbf{C}_2. \quad (11.123)$$

A matriz de covariâncias residuais correspondente é

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2. \quad (11.124)$$

Portanto, $\mathbf{C}_1$ atua sobre os termos do modelo e $\mathbf{C}_2$ atua sobre as respostas.

11.7.3 Hipótese linear geral

Combinando as duas operações anteriores, define-se

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 \in \mathbb{R}^{g \times s}, \quad (11.125)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s}.$$

As linhas de Θ correspondem às combinações dos termos definidas por $\mathbf{C}_1$, enquanto suas colunas correspondem às combinações das respostas definidas por $\mathbf{C}_2$.

Definição 11.17 (Hipótese linear geral multivariada). Para

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q} \quad \text{e} \quad \mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

a hipótese linear geral é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0, \quad (11.126)$$

em que

$$\Theta_0 \in \mathbb{R}^{g \times s}$$

contém os valores especificados pela hipótese.

Quando

$$\Theta_0 = \mathbf{0},$$

obtém-se

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mathbf{0}. \quad (11.127)$$

Se

$$\mathbf{C}_2 = \mathbf{I}_p,$$

a hipótese envolve os termos do modelo em todas as respostas:

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0.$$

Se

$$g = s = 1,$$

obtém-se a hipótese escalar

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = \theta_0. \quad (11.128)$$

11.7.4 Estimabilidade da hipótese

A hipótese deve envolver uma combinação dos parâmetros determinada pelo modelo. Pela caracterização da seção anterior,

$$\mathbf{C}_1 \mathbf{B}$$

é estimável quando

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (11.129)$$

Nessa situação,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2 \quad (11.130)$$

é um estimador de

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2,$$

e, após a observação,

$$\widehat{\Theta}_{\text{obs}} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2. \quad (11.131)$$

Sua esperança condicional satisfaz

$$E(\widehat{\Theta} | \mathbf{Z}) = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2. \quad (11.132)$$

Para construir a SQPC associada à hipótese, defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}. \quad (11.133)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}_1^{\top}. \quad (11.134)$$

No caso escalar, com uma combinação dos termos $\mathbf{c}_1$ e uma combinação das respostas $\mathbf{c}_2$,

$$\text{Var}(\mathbf{c}_1^{\top} \widehat{\mathbf{B}} \mathbf{c}_2 \mid \mathbf{Z}) = [\mathbf{c}_1^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{c}_1] (\mathbf{c}_2^{\top} \Sigma \mathbf{c}_2), \quad (11.135)$$

quando $\mathbf{Z}$ possui posto coluna completo.

A primeira parcela depende do delineamento e da combinação dos termos do modelo; a segunda depende da variabilidade residual da combinação das respostas.

Para as construções seguintes, $\mathbf{C}_1$ será considerada sem linhas redundantes. Assim,

$$\text{posto}(\mathbf{C}_1) = g,$$

e os graus de liberdade associados à hipótese são

$$\nu_H = g. \quad (11.136)$$

11.7.5 SQPC da hipótese

A SQPC da hipótese representa o afastamento observado em relação à hipótese, ponderado pela variabilidade decorrente do delineamento.

Definição 11.18 (SQPC da hipótese linear). Considere

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times s}.$$

Suponha que as combinações dos termos especificadas por $\mathbf{C}_1$ sejam estimáveis, isto é,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}.$$

Para a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

o afastamento observado é

$$\widehat{\Delta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Y} \mathbf{C}_2 - \Theta_0 \in \mathbb{R}^{g \times s}. \quad (11.137)$$

Defina

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \in \mathbb{R}^{g \times g}.$$

Quando

$$\mathbf{V}_{C_1} \succ \mathbf{0},$$

a **SQPC da hipótese linear** é

$$\mathbf{H} = \widehat{\Delta}^{\top} \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \in \mathbb{R}^{s \times s}. \quad (11.138)$$

A matriz

$$\mathbf{H} \in \mathbb{R}^{s \times s}$$

é simétrica e positiva semidefinida,

$$\mathbf{H} \succeq \mathbf{0},$$

e satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(g, s). \quad (11.139)$$

Se

$$\widehat{\Delta} = \mathbf{0},$$

então

$$\mathbf{H} = \mathbf{0}.$$

Para as mesmas combinações de respostas, a SQPC residual é

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2. \quad (11.140)$$

Portanto, a hipótese produz o par

$$(\mathbf{H}, \mathbf{E}_{C_2}).$$

A matriz $\mathbf{H}$ representa a variação associada ao afastamento da hipótese, enquanto $\mathbf{E}_{C_2}$ representa a variação residual das mesmas combinações de respostas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtém-se simplesmente o par

$$(\mathbf{H}, \mathbf{E}),$$

que será utilizado posteriormente na MANOVA.

As distribuições amostrais dessas matrizes serão estudadas no Capítulo 12. Os critérios específicos que comparam $\mathbf{H}$ e $\mathbf{E}$ pertencem ao Módulo 3.

11.7.6 Modelos encaixados

Uma hipótese sobre determinados termos do modelo também pode ser representada pela comparação entre um modelo completo e um modelo reduzido (Christensen, 2011).

Considere matrizes de delineamento $\mathbf{Z}_F$ e $\mathbf{Z}_R$ tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F). \quad (11.141)$$

O modelo reduzido representa um subconjunto das estruturas de médias disponíveis no modelo completo.

Defina

$$r_F = \text{posto}(\mathbf{Z}_F) \quad \text{e} \quad r_R = \text{posto}(\mathbf{Z}_R).$$

Seus projetores são

$$\mathbf{P}_F = \mathbf{Z}_F \mathbf{Z}_F^+$$

e

$$\mathbf{P}_R = \mathbf{Z}_R \mathbf{Z}_R^+.$$

Como os espaços são encaixados,

$$\mathbf{P}_F - \mathbf{P}_R$$

é o projetor sobre as direções acrescentadas pelo modelo completo e possui posto

$$\text{posto}(\mathbf{P}_F - \mathbf{P}_R) = r_F - r_R. \quad (11.142)$$

As SQPCs residuais são

$$\mathbf{E}_F = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_F) \mathbf{Y}$$

e

$$\mathbf{E}_R = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_R) \mathbf{Y}.$$

Proposição 11.13 (Decomposição das SQPCs de modelos encaixados). *Se*

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

e $\mathbf{P}_R$ e $\mathbf{P}_F$ são os projetores sobre os espaços dos modelos reduzido e completo, respectivamente, então

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \quad (11.143)$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}. \quad (11.144)$$

Equivalentemente,

$$\mathbf{H} = \mathbf{E}_R - \mathbf{E}_F. \quad (11.145)$$

Portanto, $\mathbf{H}$ mede a redução da SQPC residual obtida quando as direções presentes no modelo completo são acrescentadas ao modelo reduzido.

Os graus de liberdade correspondentes são

$$\nu_H = r_F - r_R \quad (11.146)$$

e

$$\nu_E = n - r_F. \quad (11.147)$$

Para combinações de respostas definidas por $\mathbf{C}_2$,

$$\mathbf{H}_{C_2} = \mathbf{C}_2^\top \mathbf{H} \mathbf{C}_2$$

e

$$\mathbf{E}_{F,C_2} = \mathbf{C}_2^\top \mathbf{E}_F \mathbf{C}_2. \quad (11.148)$$

A formulação por $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ identifica a função paramétrica examinada; a formulação por modelos encaixados mostra quanto a inclusão dos termos correspondentes reduz a variação residual.

11.7.7 Casos particulares

A forma geral inclui diferentes perguntas sem necessidade de construir uma notação específica para cada uma.

11.7.7.1 Comparação entre vetores de médias de grupos

Na parametrização por médias de grupos, considere

$$\mathbf{c}_1^\top = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} = \mathbf{0}^\top$$

equivale a

$$H_0 : \mu_1 = \mu_2. \quad (11.149)$$

Várias linhas em $\mathbf{C}_1$ permitem representar simultaneamente diferentes contrastes entre grupos. Essa é a estrutura que será utilizada posteriormente na MANOVA.

11.7.7.2 Efeito de um termo em todas as respostas

Se a linha h de $\mathbf{B}$ representa um termo específico do modelo, tome

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{I}_p.$$

A hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} = \mathbf{0}^\top \quad (11.150)$$

afirma que esse termo possui coeficiente nulo para todas as respostas.

11.7.7.3 Efeito sobre uma combinação das respostas

Para

$$\mathbf{c}_1 \in \mathbb{R}^q$$

e

$$\mathbf{c}_2 \in \mathbb{R}^p,$$

a hipótese

$$H_0 : \mathbf{c}_1^\top \mathbf{B} \mathbf{c}_2 = 0 \quad (11.151)$$

examina o efeito definido por $\mathbf{c}_1$ sobre a combinação de respostas definida por $\mathbf{c}_2$.

Por exemplo,

$$\mathbf{c}_2 = \mathbf{e}_j - \mathbf{e}_k$$

representa a diferença entre as respostas j e k .

11.7.7.4 Igualdade do efeito em duas respostas

Tomando

$$\mathbf{C}_1 = \mathbf{e}_h^\top$$

e

$$\mathbf{C}_2 = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$H_0 : \mathbf{e}_h^\top \mathbf{B} (\mathbf{e}_j - \mathbf{e}_k) = 0, \quad (11.152)$$

equivalente a

$$H_0 : \beta_{hj} = \beta_{hk}.$$

Esses casos mostram a função das duas matrizes. A matriz $\mathbf{C}_1$ combina termos do modelo, enquanto $\mathbf{C}_2$ combina respostas.

A estrutura que seguirá para o Capítulo 12 é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

acompanhada das matrizes SQPC associadas à hipótese e ao resíduo.

11.8 Exemplo integrado

Exemplo 11.1 (Regressão multivariada com uma covariável e duas respostas). Considere seis unidades. Para cada unidade, registra-se uma variável explicativa quantitativa x e duas respostas Y_1 e Y_2 .

Unidade	x	Y_1	Y_2
1	1	3	8
2	2	5	7
3	3	4	7
4	4	8	5
5	5	9	4
6	6	11	3

A matriz observada de respostas é

$$\mathbf{Y} = \begin{bmatrix} 3 & 8 \\ 5 & 7 \\ 4 & 7 \\ 8 & 5 \\ 9 & 4 \\ 11 & 3 \end{bmatrix},$$

e a matriz de delineamento, contendo intercepto e a covariável, é

$$\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 6 \end{bmatrix}. \quad (11.153)$$

Nesse modelo,

$$\mathbf{B} = \begin{bmatrix} \beta_{01} & \beta_{02} \\ \beta_{11} & \beta_{12} \end{bmatrix},$$

em que a primeira linha contém os interceptos e a segunda contém os efeitos de x sobre as duas respostas.

Como

$$q = 2$$

e

$$\text{posto}(\mathbf{Z}) = 2,$$

a matriz de delineamento possui posto coluna completo. Portanto, $\mathbf{Z}^\top \mathbf{Z}$ é invertível e a estimativa de mínimos quadrados de $\mathbf{B}$ é única.

Tem-se

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 6 & 21 \\ 21 & 91 \end{bmatrix}$$

e

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{105} \begin{bmatrix} 91 & -21 \\ -21 & 6 \end{bmatrix}.$$

Estimação da matriz de parâmetros

A estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Numericamente,

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 16/15 & 139/15 \\ 8/5 & -36/35 \end{bmatrix} \approx \begin{bmatrix} 1,067 & 9,267 \\ 1,600 & -1,029 \end{bmatrix}. \quad (11.154)$$

Portanto, as equações ajustadas são

$$\hat{Y}_1 = 1,067 + 1,600x$$

e

$$\hat{Y}_2 = 9,267 - 1,029x.$$

Para um aumento de uma unidade em x , a média ajustada de Y_1 aumenta em aproximadamente 1,600, enquanto a média ajustada de Y_2 diminui em aproximadamente 1,029.

A Figura 11.3 mostra simultaneamente as duas respostas, seus ajustes e os respectivos resíduos.




Figura 11.3: Respostas observadas, ajustes lineares e resíduos do exemplo integrado.

A figura evidencia as inclinações em sentidos opostos das duas respostas. Os segmentos tracejados ligam cada observação ao valor ajustado correspondente e representam graficamente os resíduos que serão reunidos na matriz $\widehat{\mathbf{U}}$.

A matriz de valores ajustados é

$$\widehat{\mathbf{Y}} = \mathbf{Z}\widehat{\mathbf{B}}_{\text{obs}} \approx \begin{bmatrix} 2,667 & 8,238 \\ 4,267 & 7,210 \\ 5,867 & 6,181 \\ 7,467 & 5,152 \\ 9,067 & 4,124 \\ 10,667 & 3,095 \end{bmatrix}. \quad (11.155)$$

Consequentemente,

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{Y}} \approx \begin{bmatrix} 0,333 & -0,238 \\ 0,733 & -0,210 \\ -1,867 & 0,819 \\ 0,533 & -0,152 \\ -0,067 & -0,124 \\ 0,333 & -0,095 \end{bmatrix}. \quad (11.156)$$

As equações normais garantem

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Em particular, como o modelo contém intercepto, os resíduos somam zero em cada resposta.

SQPC residual e covariância residual

A SQPC residual é

$$\begin{aligned} \mathbf{E} &= \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \\ &= \begin{bmatrix} 68/15 & -28/15 \\ -28/15 & 86/105 \end{bmatrix} \\ &\approx \begin{bmatrix} 4,533 & -1,867 \\ -1,867 & 0,819 \end{bmatrix}. \end{aligned} \quad (11.157)$$

Como

$$n = 6$$

e

$$r = 2,$$

os graus de liberdade residuais são

$$\nu_E = n - r = 4.$$

A estimativa não viesada da matriz de covariâncias residual é

$$\begin{aligned}\widehat{\Sigma}_{\text{obs}} &= \frac{\mathbf{E}}{4} \\ &= \begin{bmatrix} 17/15 & -7/15 \\ -7/15 & 43/210 \end{bmatrix} \\ &\approx \begin{bmatrix} 1,133 & -0,467 \\ -0,467 & 0,205 \end{bmatrix}.\end{aligned}\tag{11.158}$$

A covariância residual estimada é negativa. Isso indica que, depois de removida a relação linear com x , desvios positivos de uma resposta tendem a ocorrer juntamente com desvios negativos da outra neste conjunto de dados.

Sob o modelo normal matricial, como $\mathbf{E} \succ \mathbf{0}$, a estimativa de máxima verossimilhança é

$$\begin{aligned}\widehat{\Sigma}_{\text{MV,obs}} &= \frac{\mathbf{E}}{6} \\ &\approx \begin{bmatrix} 0,756 & -0,311 \\ -0,311 & 0,137 \end{bmatrix}.\end{aligned}\tag{11.159}$$

A diferença entre as duas estimativas decorre dos divisores:

$$n - r = 4$$

para o estimador não viesado e

$$n = 6$$

para a máxima verossimilhança sob normalidade.

Decomposição da SQPC total

Como o modelo contém intercepto,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

A SQPC total é

$$\mathbf{T} = \begin{bmatrix} 148/3 & -92/3 \\ -92/3 & 58/3 \end{bmatrix} \approx \begin{bmatrix} 49,333 & -30,667 \\ -30,667 & 19,333 \end{bmatrix}. \quad (11.160)$$

A parcela associada à covariável, além do intercepto, é

$$\mathbf{T}_{\text{mod}} = \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \quad (11.161)$$

Utilizando os valores exatos das matrizes,

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

Assim, a dispersão total em torno da média é decomposta na parcela associada à covariável e na parcela residual.

Os graus de liberdade apresentam a decomposição correspondente:

$$5 = 1 + 4,$$

isto é,

$$n - 1 = (r - 1) + (n - r).$$

Hipótese sobre o efeito da covariável

Considere a hipótese de que x não apresenta efeito linear sobre nenhuma das duas respostas.

Para seleccionar a segunda linha de $\mathbf{B}$, defina

$$\mathbf{C}_1 = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Como as duas respostas são mantidas,

$$\mathbf{C}_2 = \mathbf{I}_2.$$

A hipótese é

$$H_0 : \mathbf{C}_1 \mathbf{B} = \mathbf{0}^\top,$$

ou, equivalentemente,

$$H_0 : \beta_{11} = \beta_{12} = 0. \quad (11.162)$$

O afastamento observado em relação à hipótese nula é

$$\widehat{\Delta} = \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} = [8/5 \quad -36/35] \approx [1,600 \quad -1,029]. \quad (11.163)$$

Nesse caso, $\widehat{\Delta}$ é exatamente o vetor formado pelas duas inclinações estimadas, pois a hipótese especifica que ambas devem ser iguais a zero.

A matriz associada à variabilidade desse contraste é escalar:

$$\begin{aligned} \mathbf{V}_{C_1} &= \mathbf{C}_1 (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}_1^\top \\ &= \frac{2}{35} \\ &\approx 0,057. \end{aligned} \quad (11.164)$$

A SQPC da hipótese é

$$\begin{aligned} \mathbf{H} &= \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta} \\ &= \begin{bmatrix} 224/5 & -144/5 \\ -144/5 & 648/35 \end{bmatrix} \\ &\approx \begin{bmatrix} 44,800 & -28,800 \\ -28,800 & 18,514 \end{bmatrix}. \end{aligned} \quad (11.165)$$

Nesse caso,

$$\mathbf{H} = \mathbf{T}_{\text{mod}}.$$

O modelo completo contém intercepto e covariável, enquanto o modelo sob H_0 contém apenas o intercepto. Portanto, $\mathbf{H}$ representa exatamente a redução da SQPC residual obtida pela inclusão da covariável.

Como o modelo reduzido contém somente a média geral,

$$\mathbf{E}_R = \mathbf{T},$$

e

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}.$$

Assim, a hipótese sobre a covariável produz o par

$$(\mathbf{H}, \mathbf{E}),$$

formado pela variação associada ao efeito examinado e pela variação residual.

A decisão inferencial sobre essa hipótese será construída no Capítulo 12.

Hipótese sobre uma combinação das respostas

A mesma estrutura permite avaliar o efeito da covariável sobre uma combinação específica das respostas.

Considere

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A resposta transformada é

$$Y_1 - Y_2.$$

A hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{c}_2 = 0 \tag{11.166}$$

afirma que a covariável não apresenta efeito sobre a diferença entre as duas respostas.

A estimativa é

$$\begin{aligned} \hat{\theta} &= \mathbf{C}_1 \widehat{\mathbf{B}}_{\text{obs}} \mathbf{c}_2 \\ &= \frac{92}{35} \\ &\approx 2,629. \end{aligned}$$

Como

$$V_{C_1} = \frac{2}{35},$$

a SQPC da hipótese para essa combinação de respostas é o escalar

$$\begin{aligned} H_{c_2} &= \frac{\hat{\theta}^2}{V_{C_1}} \\ &= \frac{4232}{35} \\ &\approx 120,914. \end{aligned}$$

A SQPC residual dessa resposta transformada é

$$\begin{aligned} E_{c_2} &= \mathbf{c}_2^\top \mathbf{E} \mathbf{c}_2 \\ &= \frac{318}{35} \\ &\approx 9,086. \end{aligned} \tag{11.167}$$

A hipótese sobre a diferença $Y_1 - Y_2$ produz, portanto, o par escalar

$$(H_{c_2}, E_{c_2}) = \left(\frac{4232}{35}, \frac{318}{35} \right).$$

O exemplo mostra duas formas de utilizar o mesmo ajuste. Com $\mathbf{C}_2 = \mathbf{I}_2$, examina-se simultaneamente o efeito da covariável nas duas respostas. Com

$$\mathbf{c}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

examina-se o efeito da covariável sobre a diferença entre elas.

A construção das estatísticas de teste a partir desses pares pertence aos capítulos posteriores.

Neste exemplo, uma única matriz de delineamento produziu sucessivamente

$$\widehat{\mathbf{B}}_{\text{obs}}, \quad \widehat{\mathbf{Y}}, \quad \widehat{\mathbf{U}}, \quad \mathbf{E}, \quad \widehat{\Sigma}_{\text{obs}}$$

e as matrizes associadas às hipóteses examinadas. No modelo de grupos desenvolvido anteriormente, a mesma estrutura produz

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{H} = \mathbf{T}_{\text{entre}}$$

quando a hipótese compara os vetores de médias dos grupos. Essa correspondência será utilizada posteriormente na MANOVA e na Análise Discriminante.

11.9 Síntese do capítulo

O modelo linear multivariado representa conjuntamente p respostas observadas nas mesmas n unidades:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz $\mathbf{Z}$ contém os q termos do modelo, $\mathbf{B}$ determina seus efeitos sobre as p respostas e

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}$$

é a estrutura de médias condicionais. A matriz

$$\Sigma$$

descreve a covariância residual entre as respostas de uma mesma unidade.

Quando $\mathbf{Z}$ possui posto coluna completo, a matriz de parâmetros é estimada por

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

O ajuste depende do espaço coluna de $\mathbf{Z}$. Os valores ajustados e os resíduos são

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}$$

e

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y},$$

com

$$\mathbf{P}_Z + \mathbf{M}_Z = \mathbf{I}_n.$$

Assim, cada resposta é decomposta em uma parcela pertencente ao espaço do modelo e uma parcela residual.

A SQPC residual

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{U}}^{\top} \widehat{\mathbf{U}}$$

satisfaz

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma,$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Assim,

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

é um estimador não viesado da matriz de covariâncias residual.

Quando

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

a dispersão em torno da média geral satisfaz

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E},$$

com graus de liberdade

$$n - 1 = (r - 1) + (n - r).$$

No modelo de grupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}}$$

e

$$\mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}},$$

de modo que

$$\mathbf{T} = \mathbf{T}_{\text{entre}} + \mathbf{T}_{\text{intra}}.$$

Assim, Proposição 8.10 passa a ser representada como um caso particular da decomposição de um modelo de médias. Essa correspondência fornece a estrutura matricial utilizada posteriormente na ANOVA/MANOVA e na Análise Discriminante.

Quando

$$\text{posto}(\mathbf{Z}) < q,$$

os coeficientes podem não ser únicos, embora os valores ajustados e os resíduos permaneçam determinados pelo espaço coluna de $\mathbf{Z}$. As comparações de interesse devem então ser formuladas por funções estimáveis, como

$$\mathbf{CB},$$

com

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A hipótese linear multivariada geral é

$$H_0 : \mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0.$$

A matriz $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas. A hipótese produz duas matrizes construídas sobre as mesmas combinações de respostas:

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{V}_{C_1}^{-1} \widehat{\Delta}$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E} \mathbf{C}_2.$$

A primeira representa a variação associada ao afastamento da hipótese; a segunda representa a variação residual correspondente. Quando $\mathbf{C}_2 = \mathbf{I}_p$, obtém-se o par

$$(\mathbf{H}, \mathbf{E}),$$

que será utilizado posteriormente na MANOVA.

A Tabela 11.3 reúne os principais objetos utilizados no capítulo.

Tabela 11.3: Principais objetos do modelo linear multivariado.

Objeto	Expressão	Papel
estrutura de médias	$\mathbf{ZB}$	determina os vetores de médias permitidos pelo modelo
estimador dos parâmetros	$\widehat{\mathbf{B}}$	estima os coeficientes associados aos termos e às respostas
projektor do modelo	$\mathbf{P}_Z$	produz os valores ajustados
projektor residual	$\mathbf{M}_Z$	produz os resíduos
SQPC residual	$\mathbf{E}$	representa a variação que permanece após o ajuste
SQPC do modelo	$\mathbf{T}_{\text{mod}}$	representa a dispersão dos valores ajustados em torno da média geral
modelo de grupos	$\mathbf{E} = \mathbf{T}_{\text{intra}}, \mathbf{T}_{\text{mod}} = \mathbf{T}_{\text{entre}}$	relaciona o modelo linear à decomposição intra e entre grupos
função estimável	$\mathbf{CB}$	representa comparações determinadas pelo modelo
hipótese geral	$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$	combina termos do modelo e respostas
SQPC da hipótese	$\mathbf{H}$	representa a variação associada ao afastamento da hipótese

Ao concluir este capítulo, o estudante deve ser capaz de:

- formular um modelo linear para várias respostas e interpretar $\mathbf{Z}$, $\mathbf{B}$ e Σ ;
- obter valores ajustados e resíduos por meio das projeções associadas a $\mathbf{Z}$;
- construir a SQPC residual e estimar a matriz de covariâncias dos erros;
- decompor a dispersão total em parcelas associada ao modelo e residual;
- relacionar, no modelo de grupos, as matrizes $\mathbf{H}$ e $\mathbf{E}$ às dispersões entre e dentro dos grupos;

- distinguir unicidade dos coeficientes de estimabilidade de combinações dos parâmetros;
- interpretar a função de $\mathbf{C}_1$ e de $\mathbf{C}_2$ em uma hipótese linear;
- formular hipóteses na forma $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$ e construir as SQPCs correspondentes.

Este capítulo construiu os estimadores, as projeções e as matrizes SQPC que representam a variação associada ao modelo, ao resíduo e às hipóteses lineares. O Capítulo 12 desenvolverá as distribuições amostrais desses objetos e mostrará como utilizá-los na construção de testes e regiões de confiança no contexto multivariado.

12 Inferência Multivariada

Os capítulos anteriores construíram os objetos sobre os quais será formulada a inferência multivariada. A matriz de covariâncias populacional foi definida em Definição 8.2, a distribuição normal multivariada em Definição 9.1, o vetor de médias amostral e suas propriedades em Proposição 10.6, e a matriz de covariâncias amostral em Definição 10.14. O modelo linear multivariado foi definido em Definição 11.3 e sua hipótese linear geral em Definição 11.17.

O objetivo deste capítulo é obter distribuições amostrais para esses objetos e utilizá-las na construção de testes de hipóteses e regiões de confiança. A distribuição de Wishart descreverá as matrizes SQPC sob normalidade, enquanto a estatística T^2 de Hotelling permitirá realizar inferência sobre vetores de médias quando a matriz de covariâncias populacional é desconhecida.

Os resultados exatos serão desenvolvidos principalmente sob normalidade multivariada. Resultados assintóticos serão utilizados quando a distribuição exata não estiver disponível ou quando o objetivo for descrever o comportamento limite das estatísticas. As duas situações serão distinguidas porque dependem de condições diferentes.

O capítulo também obterá as distribuições dos estimadores e das matrizes SQPC construídas no modelo linear multivariado. Esses resultados encerram a base probabilística e inferencial do Módulo 2 e serão utilizados na formulação das técnicas do Módulo 3.

Convenções de notação

Neste capítulo:

- $\bar{\mathbf{X}}$ representa o vetor de médias amostral como estatística aleatória e $\bar{\mathbf{x}}$ sua realização observada;
- $\mathbf{S}$ representa a matriz de covariâncias amostral como estatística aleatória e $\mathbf{S}$ sua realização observada;
- $\mathbf{T}$ representa a SQPC amostral aleatória e $\mathbf{T}$ sua realização observada;
- $\mathbf{W}$ representa uma matriz aleatória com distribuição de Wishart;
- $\mathbf{E}_{\text{res}}$ e $\mathbf{E}$ representam, respectivamente, a SQPC residual aleatória e sua realização observada;
- $\mathbf{H}$ e $\mathbf{H}$ representam, respectivamente, a SQPC da hipótese aleatória e sua realização observada;
- $\mathbf{Z}$ continua representando a matriz de delineamento do modelo linear multivariado;
- $\mathbf{C}_1$ combina termos do modelo e $\mathbf{C}_2$ combina respostas nas hipóteses lineares

definidas no Capítulo 11;

- $\mathbf{M}_Z$ permanece reservada ao projetor residual;
- $\mathbf{A}$ será utilizada posteriormente para formular hipóteses lineares diretamente sobre o vetor de médias.

As convenções preservam a distinção entre objetos populacionais, estatísticas aleatórias e realizações observadas estabelecida nos capítulos anteriores.

12.1 Distribuições amostrais exatas e assintóticas

A inferência estatística utiliza a distribuição amostral de uma estatística para quantificar sua variabilidade e calibrar procedimentos como testes e regiões de confiança. Essa distribuição pode ser conhecida exatamente sob um modelo probabilístico especificado ou aproximada por seu comportamento limite quando o tamanho amostral cresce.

Definição 12.1 (Resultados exatos e assintóticos). Um **resultado exato** é válido para o tamanho amostral considerado sem recorrer a um argumento limite. Quando o resultado é distribucional, ele fornece a distribuição da estatística sob as hipóteses probabilísticas especificadas.

Um **resultado assintótico** descreve o comportamento limite de uma estatística quando o tamanho amostral tende ao infinito. Sua utilização em amostras finitas constitui uma aproximação cuja qualidade depende das condições do problema.

Neste capítulo, os resultados exatos dependerão principalmente da normalidade multivariada. Os resultados assintóticos considerarão, salvo indicação em contrário, o regime

$$p \text{ fixo} \quad \text{e} \quad n \rightarrow \infty. \quad (12.1)$$

Essa distinção deve ser mantida também na interpretação: uma distribuição exata decorre do modelo probabilístico especificado, enquanto uma distribuição limite decorre de um argumento de convergência.

12.1.1 Distribuição da média amostral sob normalidade

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

independente e identicamente distribuída, com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

O vetor de médias amostral é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Por Proposição 10.6,

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Esses resultados dependem dos momentos correspondentes, mas não da normalidade multivariada.

A normalidade acrescenta a distribuição exata da estatística.

Proposição 12.1 (Distribuição da média amostral sob normalidade). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

então

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.2)$$

O resultado é exato para qualquer $n \geq 1$.

i Demonstração

A média amostral é uma combinação linear dos vetores normais independentes. Por Proposição 9.4, sua distribuição é normal multivariada. Como Proposição 10.6 fornece

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

obtém-se Equação 12.2.

A proposição mostra a diferença entre propriedades de um estimador e sua distribuição amostral. A igualdade

$$E(\bar{\mathbf{X}}) = \mu$$

expressa ausência de viés. Já

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

descreve toda a distribuição da estatística sob o modelo normal.

Se

$$\Sigma \succ \mathbf{0},$$

a média amostral pode ser branqueada:

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (12.3)$$

Aplicando o resultado qui-quadrado da distância de Mahalanobis estabelecido em Proposição 9.8,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \sim \chi_p^2. \quad (12.4)$$

O fator n aparece porque

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

de modo que

$$\left(\frac{\Sigma}{n}\right)^{-1} = n\Sigma^{-1}.$$

A expressão em Equação 12.4 fornece a base do procedimento inferencial para o vetor de médias quando Σ é conhecida. O caso em que Σ precisa ser estimada exigirá a distribuição da matriz de covariâncias amostral.

12.1.2 Teorema Central do Limite multivariado

Fora da família normal, a distribuição de

$$\bar{\mathbf{X}}$$

depende da distribuição conjunta da população. Em dimensão fixa, o Teorema Central do Limite multivariado fornece uma aproximação normal sob condições mais gerais (Vaart, 1998).

Teorema 12.1 (Teorema Central do Limite multivariado). *Considere, para dimensão fixa p , vetores aleatórios independentes e identicamente distribuídos*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu$$

e matriz de covariâncias finita

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma). \quad (12.5)$$

i Demonstração

Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

considere

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \mu).$$

As variáveis

$$\mathbf{a}^\top \mathbf{X}_1, \dots, \mathbf{a}^\top \mathbf{X}_n$$

são independentes e identicamente distribuídas, com média

$$\mathbf{a}^\top \mu$$

e variância finita

$$\mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema Central do Limite univariado,

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Como a convergência vale para todo vetor fixo $\mathbf{a}$, o Teorema de Cramér–Wold em Teorema 9.1 implica Equação 12.5.

O resultado permite escrever, em sentido assintótico,

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right). \quad (12.6)$$

A mesma expressão possui, portanto, dois significados distintos:

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma distribuição **exata** quando a população é normal multivariada, enquanto

$$\bar{\mathbf{X}} \stackrel{a}{\sim} N_p \left(\mu, \frac{\Sigma}{n} \right)$$

é uma aproximação **assintótica** sob as condições do Teorema 12.1.

Se

$$\Sigma \succ \mathbf{0},$$

então

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \mathbf{I}_p), \quad (12.7)$$

e, pelo teorema da aplicação contínua,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} \chi_p^2. \quad (12.8)$$

Assim, a mesma forma quadrática possui distribuição qui-quadrado exata sob normalidade e distribuição limite qui-quadrado sob as condições do TCL multivariado.

Alcance da aproximação assintótica

O Teorema 12.1 considera dimensão p fixa e exige a existência dos momentos de segunda ordem.

O resultado não justifica automaticamente a inferência clássica quando há dependência entre unidades, inexistência de segundos momentos ou crescimento de p juntamente com n . Além disso, a substituição de Σ por uma matriz de covariâncias estimada introduz outra fonte de aleatoriedade que precisa ser considerada separadamente.

A distribuição da média amostral descreve a incerteza associada à localização. Quando Σ é desconhecida, a inferência depende também da distribuição da matriz que estima a dispersão. Sob normalidade multivariada, essa distribuição é obtida a partir da distribuição de Wishart.

12.2 Distribuição de Wishart

A inferência sobre uma matriz de covariâncias exige conhecer a distribuição das matrizes de produtos cruzados que a originam. No caso univariado, somas de quadrados de variáveis normais padronizadas conduzem à distribuição qui-quadrado. A distribuição de Wishart estende essa construção para somas de produtos externos de vetores normais e ocupa, na inferência normal multivariada, papel análogo ao da distribuição qui-quadrado na inferência univariada (Muirhead, 1982).

12.2.1 Construção e parametrização

Considere vetores aleatórios independentes

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \in \mathbb{R}^p$$

tais que

$$\mathbf{U}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 1, \dots, \nu,$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0}.$$

Cada produto externo

$$\mathbf{U}_j \mathbf{U}_j^\top$$

é uma matriz simétrica e positiva semidefinida.

Definição 12.2 (Distribuição de Wishart). Se

$$\mathbf{U}_1, \dots, \mathbf{U}_\nu \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma),$$

com

$$\nu \in \{1, 2, \dots\}$$

e

$$\Sigma \succ \mathbf{0},$$

então a matriz aleatória

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{U}_j \mathbf{U}_j^{\top} \quad (12.9)$$

segue uma distribuição de Wishart com ν graus de liberdade e matriz de escala Σ .

Escreve-se

$$\mathbf{W} \sim W_p(\nu, \Sigma). \quad (12.10)$$

Nesta parametrização,

$$\Sigma$$

é denominada **matriz de escala** e ν é o número de graus de liberdade. A relação

$$E(\mathbf{W}) = \nu \Sigma$$

será estabelecida em Proposição [12.3](#).

A parametrização é indicada explicitamente porque diferentes convenções para a matriz de escala podem ser encontradas na literatura.

Quando

$$p = 1,$$

a matriz Wishart possui um único elemento. Se

$$\Sigma = [\sigma^2],$$

então

$$W = \sum_{j=1}^{\nu} U_j^2$$

e

$$\frac{W}{\sigma^2} \sim \chi_{\nu}^2. \quad (12.11)$$

Assim, a distribuição qui-quadrado é o caso univariado da distribuição de Wishart.

12.2.2 Suporte, posto e definição positiva

Organize os vetores geradores nas linhas da matriz

$$\mathcal{U} = \begin{bmatrix} \mathbf{U}_1^\top \\ \vdots \\ \mathbf{U}_\nu^\top \end{bmatrix} \in \mathbb{R}^{\nu \times p}.$$

Então,

$$\mathbf{W} = \mathcal{U}^\top \mathcal{U}. \quad (12.12)$$

Portanto, $\mathbf{W}$ é uma matriz de Gram no sentido de Definição 3.18. Por Proposição 3.9,

$$\mathbf{W} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{W}) = \text{posto}(\mathcal{U}) \leq \min(\nu, p).$$

Proposição 12.2 (Posto de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, com

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade 1,

$$\text{posto}(\mathbf{W}) = \min(\nu, p). \quad (12.13)$$

Consequentemente:

- se $\nu \geq p$, então $\mathbf{W} \succ \mathbf{0}$ com probabilidade 1;
- se $\nu < p$, então $\text{posto}(\mathbf{W}) = \nu$ com probabilidade 1 e a matriz é singular.

Como $\Sigma \succ \mathbf{0}$, cada vetor gerador possui distribuição normal não singular. A distribuição conjunta das entradas de $\mathcal{U}$ é contínua, e o conjunto das matrizes cujo posto é menor que $\min(\nu, p)$ possui probabilidade zero. Assim, a matriz de Gram atinge quase certamente o maior posto permitido por suas dimensões (Muirhead, 1982).

A condição

$$\nu \geq p$$

é, portanto, necessária e suficiente para a definição positiva quase certa na construção com graus de liberdade inteiros e

$$\Sigma \succ \mathbf{0}.$$

12.2.3 Momentos

A esperança da matriz Wishart é obtida diretamente da construção por produtos externos.

Proposição 12.3 (Momentos de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

pela construção em Definição 12.2, então

$$E(\mathbf{W}) = \nu \Sigma. \tag{12.14}$$

Para os elementos da matriz,

$$\text{Cov}(W_{jk}, W_{\ell m}) = \nu (\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}). \tag{12.15}$$

i Demonstração

Pela construção em Equação 12.9,

$$W_{jk} = \sum_{h=1}^{\nu} U_{hj} U_{hk}.$$

Como

$$E(U_{hj} U_{hk}) = \sigma_{jk},$$

segue que

$$E(W_{jk}) = \nu \sigma_{jk}.$$

Portanto,

$$E(\mathbf{W}) = \nu \Sigma.$$

A expressão para

$$\text{Cov}(W_{jk}, W_{\ell m})$$

decorre dos momentos de quarta ordem do vetor normal de média zero e da independência entre os ν vetores geradores (Muirhead, 1982).

Em particular,

$$\text{Var}(W_{jj}) = 2\nu \sigma_{jj}^2, \quad (12.16)$$

e, para $j \neq k$,

$$\text{Var}(W_{jk}) = \nu (\sigma_{jj} \sigma_{kk} + \sigma_{jk}^2). \quad (12.17)$$

Dividindo pelos graus de liberdade,

$$E\left(\frac{\mathbf{W}}{\nu}\right) = \Sigma.$$

Além disso, Equação 12.15 implica

$$\text{Cov}\left(\frac{W_{jk}}{\nu}, \frac{W_{\ell m}}{\nu}\right) = \frac{\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}}{\nu}.$$

Portanto, para Σ fixa, a variabilidade dos elementos de $\mathbf{W}/\nu$ diminui à medida que ν aumenta.

12.2.4 Formas quadráticas

A analogia com a distribuição qui-quadrado também aparece em qualquer direção fixa do espaço das variáveis.

Proposição 12.4 (Forma quadrática de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2, então, para qualquer

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

vale

$$\frac{\mathbf{a}^\top \mathbf{W} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_\nu^2. \quad (12.18)$$

i Demonstração

De Equação 12.9,

$$\mathbf{a}^\top \mathbf{W} \mathbf{a} = \sum_{j=1}^{\nu} (\mathbf{a}^\top \mathbf{U}_j)^2.$$

Por Proposição 9.4,

$$\mathbf{a}^\top \mathbf{U}_j \sim N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Assim, as variáveis

$$\frac{\mathbf{a}^\top \mathbf{U}_j}{\sqrt{\mathbf{a}^\top \Sigma \mathbf{a}}}$$

são normais padrão independentes. A soma de seus quadrados possui distribuição χ_ν^2 .

Assim, cada projeção univariada de uma matriz Wishart recupera a estrutura qui-quadrado correspondente à variância naquela direção.

12.2.5 Aditividade

Proposição 12.5 (Aditividade da distribuição de Wishart). *Se*

$$\mathbf{W}_1 \sim W_p(\nu_1, \Sigma)$$

e

$$\mathbf{W}_2 \sim W_p(\nu_2, \Sigma)$$

são independentes e possuem a mesma matriz de escala, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\nu_1 + \nu_2, \Sigma). \quad (12.19)$$

i Demonstração

Pela construção da distribuição, as duas matrizes podem ser representadas por somas de, respectivamente, ν_1 e ν_2 produtos externos de vetores normais independentes com a mesma matriz de covariâncias Σ .

A soma das duas matrizes reúne

$$\nu_1 + \nu_2$$

produtos externos independentes e, portanto, possui a distribuição indicada.

A condição de escala comum é necessária para esse resultado. Matrizes Wishart independentes com matrizes de escala distintas não podem, em geral, ser somadas mantendo a mesma forma Wishart.

12.2.6 Transformações lineares

A transformação de uma matriz Wishart acompanha a transformação da matriz de covariâncias dos vetores normais que a geram.

Proposição 12.6 (Transformação linear de uma matriz Wishart). *Considere*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

pela construção em Definição 12.2.

Se

$$\mathbf{L} \in \mathbb{R}^{r \times p}$$

possui posto linha completo,

$$\text{posto}(\mathbf{L}) = r,$$

então

$$\mathbf{LWL}^\top \sim W_r(\nu, \mathbf{L}\Sigma\mathbf{L}^\top). \quad (12.20)$$

i Demonstração

Pela construção,

$$\mathbf{LWL}^\top = \sum_{j=1}^{\nu} (\mathbf{LU}_j)(\mathbf{LU}_j)^\top.$$

Por Proposição 9.4,

$$\mathbf{LU}_j \sim N_r(\mathbf{0}, \mathbf{L}\Sigma\mathbf{L}^\top).$$

Como as transformações são aplicadas separadamente aos vetores independentes, os vetores transformados permanecem independentes.

Como $\mathbf{L}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{L}\Sigma\mathbf{L}^\top \succ \mathbf{0}.$$

Logo, a soma possui a distribuição apresentada.

Se $\mathbf{L}$ não possui posto linha completo,

$$\mathbf{L}\Sigma\mathbf{L}^\top$$

é singular e a distribuição fica restrita ao subespaço imagem de $\mathbf{L}$. Essa extensão singular não será necessária na sequência principal.

Tomando

$$\mathbf{L} = \Sigma^{-1/2},$$

com a raiz quadrada principal definida em Definição 5.9, obtém-se

$$\Sigma^{-1/2} \mathbf{W} \Sigma^{-1/2} \sim W_p(\nu, \mathbf{I}_p). \quad (12.21)$$

A transformação remove a matriz de escala da distribuição, de modo análogo ao branqueamento normal em Equação 9.23.

12.2.7 Aprofundamento: densidade da distribuição de Wishart

Leitura de aprofundamento

Os resultados inferenciais deste capítulo utilizam principalmente a construção por produtos externos, o posto, os momentos, a aditividade e as transformações da distribuição de Wishart.

A densidade é apresentada como aprofundamento porque será útil para relacionar a distribuição de Wishart a verossimilhanças envolvendo matrizes de covariâncias.

A construção em Definição 12.2 utiliza um número inteiro de vetores normais. A família Wishart não singular admite uma extensão para graus de liberdade reais

$$\nu > p - 1$$

por meio de sua densidade no cone das matrizes simétricas positivas definidas (Muirhead, 1982).

Proposição 12.7 (Densidade da distribuição de Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com

$$\nu > p - 1$$

e

$$\Sigma \succ \mathbf{0},$$

então sua densidade é

$$f_{\mathbf{W}}(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-p-1)/2} \exp \left[-\frac{1}{2} \text{tr} (\Sigma^{-1} \mathbf{W}) \right]}{2^{\nu p/2} |\Sigma|^{\nu/2} \Gamma_p(\nu/2)}, \quad (12.22)$$

para

$$\mathbf{W} \succ \mathbf{0}.$$

A função gama multivariada é

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad (12.23)$$

definida para

$$a > \frac{p-1}{2}.$$

Quando a Wishart é construída pela soma de ν produtos externos e

$$\nu < p,$$

a matriz é singular com probabilidade 1. Nesse caso, sua distribuição está concentrada em matrizes positivas semidefinidas de posto ν e não possui a densidade anterior no cone positivo definido.

A sequência inferencial deste capítulo utilizará graus de liberdade inteiros provenientes do tamanho amostral ou do posto de matrizes de projeção.

12.2.8 Distribuição da SQPC e da covariância amostral

Retomando Definição 10.13,

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Por Definição 10.14,

$$\mathbf{S} = \frac{\mathbf{T}}{n-1}.$$

Por Proposição [10.10](#),

$$E(\mathbf{T}) = (n-1)\Sigma.$$

Sob normalidade multivariada, a distribuição completa dessa estatística pode ser estabelecida.

Teorema 12.2 (Distribuição da SQPC e da covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com


$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\mathbf{T} = (n-1)\mathbf{S} \sim W_p(n-1, \Sigma). \quad (12.24)$$



i Demonstração

Organize a amostra na matriz aleatória

$$\mathcal{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix}.$$

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

cujas primeira linha seja

$$\frac{1}{\sqrt{n}} \mathbf{1}_n^\top,$$

e defina a matriz transformada

$$\mathcal{X}^* = \mathbf{Q}\mathcal{X}.$$

Sua primeira linha satisfaz

$$(\mathbf{x}_1^*)^\top = \sqrt{n} \bar{\mathbf{x}}^\top. \quad (12.25)$$

As demais linhas são combinações lineares cujos coeficientes somam zero. Portanto,

$$E(\mathbf{x}_j^*) = \mathbf{0}, \quad j = 2, \dots, n.$$

A covariância cruzada entre duas linhas transformadas é

$$\text{Cov}(\mathbf{x}_j^*, \mathbf{x}_k^*) = [\mathbf{Q}\mathbf{Q}^\top]_{jk} \Sigma = \delta_{jk} \Sigma.$$

As linhas transformadas são conjuntamente normais. Por Proposição 9.6, as covariâncias cruzadas nulas implicam independência. Assim,

$$\mathbf{x}_2^*, \dots, \mathbf{x}_n^* \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma).$$

A matriz de centralização pode ser escrita como

$$\mathbf{H}_n = \mathbf{Q}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{I}_{n-1} \end{bmatrix} \mathbf{Q}.$$

Utilizando a forma matricial da SQPC estabelecida em Equação 10.62,

$$\begin{aligned} \mathbf{T} &= \mathcal{X}^\top \mathbf{H}_n \mathcal{X} \\ &= \sum_{j=2}^n \mathbf{x}_j^* (\mathbf{x}_j^*)^\top. \end{aligned}$$

Essa é a soma de $n - 1$ produtos externos de vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

A esperança obtida pela distribuição de Wishart é consistente com Proposição 10.10 e Proposição 10.11.

A informação nova é a distribuição amostral completa:

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma).$$

Pela Proposição 12.4, para qualquer

$$\mathbf{a} \neq \mathbf{0},$$

tem-se

$$\frac{(n-1)\mathbf{a}^\top \mathbf{S} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_{n-1}^2. \quad (12.26)$$

Assim, a variância amostral de qualquer combinação linear fixa possui a mesma estrutura qui-quadrado conhecida do caso univariado.

Para os elementos de $\mathbf{S}$,

$$\text{Cov}(S_{jk}, S_{\ell m}) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{n-1}. \quad (12.27)$$

Em particular,

$$\text{Var}(S_{jj}) = \frac{2\sigma_{jj}^2}{n-1}$$

e, para $j \neq k$,

$$\text{Var}(S_{jk}) = \frac{\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2}{n-1}.$$

Esses resultados são exatos sob normalidade multivariada.

A matriz de covariâncias amostral possui, com probabilidade 1,

$$\text{posto}(\mathbf{S}) = \min(p, n-1). \quad (12.28)$$

Portanto, sob

$$\Sigma \succ \mathbf{0},$$

a condição

$$n > p \tag{12.29}$$

é necessária e suficiente para que

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1.

Quando

$$p \geq n,$$

a matriz $\mathbf{S}$ é necessariamente singular. Essa restrição dimensional terá consequência direta para a forma clássica da estatística T^2 de Hotelling.

Sob o modelo normal, Equação 10.44 fornece

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{T}}{n}.$$

Sempre que sua interpretação como estimador de máxima verossimilhança no espaço

$$\Sigma \succ \mathbf{0}$$

for válida,

$$n\widehat{\Sigma}_{\text{MV}} = \mathbf{T} \sim W_p(n-1, \Sigma). \tag{12.30}$$

A distribuição continua envolvendo $n-1$ graus de liberdade, pois a média populacional também foi estimada a partir da amostra.

12.2.9 Independência entre média e covariância

A transformação ortogonal utilizada na prova do Teorema 12.2 separa a informação amostral associada à localização da informação associada à dispersão.

A primeira linha transformada depende exclusivamente de

$$\bar{\mathbf{X}},$$

enquanto

$$\mathbf{T}$$

e, conseqüentemente,

$$\mathbf{S},$$

dependem apenas das demais linhas.

Teorema 12.3 (Independência entre média e covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2$$

e

$$\Sigma \succ \mathbf{0},$$

então

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

também vale

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.31)$$

i Demonstração

Na prova de Teorema 12.2, a primeira linha de $\mathcal{X}^*$ depende apenas de

$$\bar{\mathbf{X}},$$

enquanto $\mathbf{T}$ depende apenas das demais linhas transformadas.

Esses dois blocos são independentes por Proposição 9.6. Portanto,

$$\bar{\mathbf{X}} \perp \mathbf{T}.$$

Como

$$\mathbf{S} = \frac{\mathbf{T}}{n-1},$$

segue também

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

A independência é um resultado **exato da amostragem normal**. Ela não decorre somente da independência entre as observações.

O que depende da normalidade

As propriedades

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

não exigem normalidade multivariada.

Em contraste,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

são resultados exatos da amostragem normal.

Para uma população geral, a distribuição de $\mathbf{S}$ depende de características adicionais da distribuição, incluindo momentos de ordem superior, e a média e a covariância amostrais não são, em geral, independentes.

Temos, portanto, sob amostragem normal, o par

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right)$$

e

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

com

$$\bar{\mathbf{X}} \perp \mathbf{S}. \quad (12.32)$$

O par

$$(\bar{\mathbf{X}}, \mathbf{S})$$

combina uma distribuição normal para a localização, uma distribuição Wishart para a dispersão e independência entre os dois objetos. Essa estrutura normal–Wishart será utilizada posteriormente na construção da estatística T^2 de Hotelling.

No modelo linear multivariado, a mesma organização reaparece. O vetor de médias amostral é substituído pelo estimador de $\mathbf{B}$, enquanto a SQPC amostral é substituída pela SQPC residual. Os $n-1$ graus de liberdade do problema de uma única média passam a ser os $n-r$ graus de liberdade residuais do modelo.

12.3 Distribuições no modelo linear multivariado

O modelo linear normal multivariado foi definido em Definição 11.7. Nesta seção, a normalidade será utilizada para obter as distribuições amostrais exatas dos estimadores e das matrizes SQPC construídas no Capítulo 11.

Retomando Equação 11.22,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{ZB}, \mathbf{I}_n, \Sigma), \quad \Sigma \succ \mathbf{0}. \quad (12.33)$$

A matriz de delineamento é considerada fixa, ou a análise é condicionada em seus valores observados. Defina

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r,$$

em concordância com Equação 11.77.

A estrutura probabilística será desenvolvida em três etapas: distribuição do estimador dos parâmetros, distribuição da SQPC residual e distribuição da SQPC associada a uma hipótese linear.

12.3.1 Distribuição do estimador da matriz de parâmetros

Suponha inicialmente que

$$r = q.$$

Nesse caso, o estimador de mínimos quadrados definido em Equação 11.36 é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}.$$

Por Equação 11.39,

$$\widehat{\mathbf{B}} = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.$$

Assim, $\widehat{\mathbf{B}}$ é uma transformação afim da matriz normal de erros.

Proposição 12.8 (Distribuição do estimador da matriz de parâmetros). *Sob o modelo linear normal multivariado e*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$\widehat{\mathbf{B}} \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{B}, (\mathbf{Z}^\top \mathbf{Z})^{-1}, \Sigma \right]. \quad (12.34)$$

Equivalentemente,

$$\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z} \sim N_{pq} \left[\text{vec}(\mathbf{B}), \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]. \quad (12.35)$$

i Demonstração

Defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então

$$\widehat{\mathbf{B}} = \mathbf{B} + \mathbf{A}_Z \mathcal{E}.$$

Pela transformação da distribuição normal matricial,

$$\mathbf{A}_Z \mathcal{E} \mid \mathbf{Z} \sim N_{q \times p}(\mathbf{0}, \mathbf{A}_Z \mathbf{A}_Z^\top, \Sigma).$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

segue o resultado.

A distribuição em Equação 12.34 contém como momentos os resultados de Proposição 11.3. A matriz

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a variabilidade dos coeficientes, enquanto

$$\Sigma$$

descreve a dependência residual entre as respostas.

Quando

$$r < q,$$

os coeficientes de $\mathbf{B}$ podem não ser únicos. Nesse caso, a inferência deve ser formulada sobre as funções estimáveis caracterizadas em Proposição 11.12.

12.3.2 Distribuição de funções estimáveis

O Capítulo 11 caracterizou as funções estimáveis do modelo linear multivariado. Sob normalidade, a distribuição exata de seu estimador decorre de uma transformação linear da matriz de erros.

Proposição 12.9 (Distribuição de uma função estimável). *Sob o modelo linear normal multivariado,*

$$\widehat{\Theta} \mid \mathbf{Z} \sim N_{g \times s} \left(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2, \mathbf{V}_{C_1}, \Sigma_{C_2} \right). \quad (12.36)$$

Nesse resultado,

$$\Theta = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2$$

e

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{y} \mathbf{C}_2.$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \text{posto}(\mathbf{C}_1) = g,$$

satisfaz a condição de estimabilidade

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z},$$

enquanto

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

As matrizes de covariâncias são

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top} \quad (12.37)$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^{\top} \Sigma \mathbf{C}_2. \quad (12.38)$$

Sob essas condições,

$$\mathbf{V}_{C_1} \succ \mathbf{0} \quad e \quad \Sigma_{C_2} \succ \mathbf{0}.$$

Equivalentemente,

$$\text{vec}(\widehat{\Theta}) \mid \mathbf{Z} \sim N_{gs} \left[\text{vec}(\mathbf{C}_1 \mathbf{B} \mathbf{C}_2), \Sigma_{C_2} \otimes \mathbf{V}_{C_1} \right]. \quad (12.39)$$

i Demonstração

Pela estimabilidade,

$$\mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z} = \mathbf{C}_1.$$

Portanto,

$$\widehat{\Theta} = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 + \mathbf{C}_1 \mathbf{Z}^+ \mathcal{E} \mathbf{C}_2.$$

A segunda parcela é uma transformação bilateral da matriz normal de erros, com matriz de covariâncias entre linhas $\mathbf{V}_{C_1}$ e matriz de covariâncias entre colunas Σ_{C_2} . Isso fornece Equação 12.36.

A matriz $\mathbf{V}_{C_1}$ representa a variabilidade associada às combinações dos termos do modelo, enquanto Σ_{C_2} representa a covariância residual das combinações de respostas. A normalidade acrescenta a distribuição amostral exata à estrutura construída no Capítulo 11.

12.3.3 Distribuição da SQPC residual

Por Definição 11.11,

$$\mathbf{E}_{\text{res}} = \widehat{\mathcal{U}}^\top \widehat{\mathcal{U}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}.$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

pode-se escrever

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}.$$

A matriz

$$\mathbf{M}_Z$$

é um projetor ortogonal de posto

$$\nu_E = n - r.$$

Proposição 12.10 (Distribuição da SQPC residual). *Sob o modelo linear normal multivariado, se*

$$r = \text{posto}(\mathbf{Z})$$

e

$$\nu_E = n - r \geq 1,$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.40)$$

i Demonstração

Seja

$$\mathbf{Q}_E \in \mathbb{R}^{n \times (n-r)}$$

uma matriz cujas colunas formam uma base ortonormal de

$$\mathcal{C}(\mathbf{M}_Z).$$

Como $\mathbf{M}_Z$ é o projetor ortogonal sobre esse espaço,

$$\mathbf{M}_Z = \mathbf{Q}_E \mathbf{Q}_E^\top.$$

Defina

$$\mathcal{E}^* = \mathbf{Q}_E^\top \mathcal{E}.$$

Pela transformação da normal matricial,

$$\mathcal{E}^* \mid \mathbf{Z} \sim N_{(n-r) \times p}(\mathbf{0}, \mathbf{I}_{n-r}, \Sigma).$$

Portanto, suas $n - r$ linhas são vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\begin{aligned} \mathbf{E}_{\text{res}} &= \mathcal{E}^\top \mathbf{Q}_E \mathbf{Q}_E^\top \mathcal{E} \\ &= (\mathcal{E}^*)^\top \mathcal{E}^*. \end{aligned}$$

Pela construção da distribuição de Wishart,

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma).$$

A esperança fornecida pela distribuição de Wishart coincide com Proposição 11.7.

Como o estimador residual foi definido em Equação 11.79 por

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r},$$

segue que

$$(n - r)\widehat{\Sigma} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.41)$$

O posto da SQPC residual é, com probabilidade 1,

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r). \quad (12.42)$$

Assim,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq p. \quad (12.43)$$

A condição é a contraparte probabilística do limite de posto discutido no Capítulo 11 e decorre diretamente de Proposição 12.2.

12.3.4 Independência entre estimação e SQPC residual

Para uma função estimável,

$$\widehat{\boldsymbol{\theta}} - \boldsymbol{\theta} = \mathbf{C}_1 \mathbf{Z}^+ \boldsymbol{\varepsilon} \mathbf{C}_2,$$

enquanto os resíduos satisfazem

$$\widehat{\boldsymbol{u}} = \mathbf{M}_Z \boldsymbol{\varepsilon}.$$

Como

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

as duas parcelas correspondem a projeções ortogonais dos erros.

Proposição 12.11 (Independência entre estimação paramétrica e resíduos). *Sob o modelo linear normal multivariado,*

$$\widehat{\boldsymbol{\theta}} \perp \widehat{\boldsymbol{u}} \mid \mathbf{Z}.$$

Consequentemente,

$$\widehat{\boldsymbol{\theta}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.44)$$

i Demonstração

As duas matrizes são transformações lineares da mesma matriz normal de erros e, portanto, são conjuntamente normais.

Como

$$\mathbf{C}_1 \mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0},$$

a covariância cruzada entre as duas transformações é nula. Por Proposição 9.6, segue a independência.

Como $\mathbf{E}_{\text{res}}$ é função dos resíduos, a segunda independência também é obtida.

Quando $\mathbf{Z}$ possui posto coluna completo, tomando

$$\mathbf{C}_1 = \mathbf{I}_q \quad \text{e} \quad \mathbf{C}_2 = \mathbf{I}_p,$$

obtem-se

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.45)$$

Esse resultado generaliza a independência entre média e covariância amostrais. No modelo contendo somente intercepto,

$$\widehat{\mathbf{B}} = \bar{\mathbf{X}}^\top$$

e

$$\mathbf{E}_{\text{res}} = (n - 1)\mathbf{S}.$$

Papel da normalidade

A ortogonalidade entre as projeções garante covariância cruzada nula entre as parcelas estimada e residual.

A conclusão de **independência** utiliza adicionalmente a normalidade conjunta. Fora do modelo normal, ortogonalidade das projeções não implica, por si só, independência entre as estatísticas correspondentes.

12.3.5 Distribuição da SQPC da hipótese sob H_0

Sob o modelo linear normal multivariado, a SQPC associada à hipótese e a SQPC residual correspondente possuem distribuições Wishart independentes. Esse resultado fornece a estrutura probabilística que será utilizada posteriormente na inferência multivariada do modelo linear.

Proposição 12.12 (Distribuições da SQPC da hipótese e da SQPC residual). *Sob o modelo linear normal multivariado, com*

$$\Sigma \succ \mathbf{0},$$

considere a hipótese

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (12.46)$$

A matriz

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}, \quad \mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}, \quad \text{posto}(\mathbf{C}_1) = g,$$

representa g funções estimáveis linearmente independentes.

Além disso,

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s}, \quad \text{posto}(\mathbf{C}_2) = s.$$

Defina

$$r = \text{posto}(\mathbf{Z}), \quad n - r \geq 1,$$

e

$$\Sigma_{C_2} = \mathbf{C}_2^\top \Sigma \mathbf{C}_2.$$

O afastamento aleatório da hipótese é

$$\mathcal{D} = \mathbf{C}_1 \mathbf{Z}^+ \mathcal{Y} \mathbf{C}_2 - \Theta_0. \quad (12.47)$$

Além disso,

$$\mathbf{V}_{C_1} = \mathbf{C}_1 \mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}_1^{\top}.$$

Sob H_0 ,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s} \left(\mathbf{0}, \mathbf{V}_{C_1}, \Sigma_{C_2} \right). \tag{12.48}$$

Defina

$$\mathbf{H} = \mathcal{D}^{\top} \mathbf{V}_{C_1}^{-1} \mathcal{D} \tag{12.49}$$

e

$$\mathbf{E}_{C_2} = \mathbf{C}_2^{\top} \mathbf{E}_{\text{res}} \mathbf{C}_2. \tag{12.50}$$

Então,

$$\mathbf{H} \mid \mathbf{Z} \sim W_s \left(g, \Sigma_{C_2} \right) \tag{12.51}$$

e

$$\mathbf{E}_{C_2} \mid \mathbf{Z} \sim W_s \left(n - r, \Sigma_{C_2} \right). \tag{12.52}$$

Além disso,

$$\mathbf{H} \perp \mathbf{E}_{C_2} \mid \mathbf{Z}. \tag{12.53}$$

i Demonstração

Sob H_0 ,

$$\mathbf{V}_{C_1}^{-1/2} \mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{I}_g, \Sigma_{C_2}).$$

Portanto, suas g linhas são vetores independentes com distribuição

$$N_s(\mathbf{0}, \Sigma_{C_2}).$$

Como

$$\mathbf{H} = (\mathbf{V}_{C_1}^{-1/2} \mathcal{D})^\top (\mathbf{V}_{C_1}^{-1/2} \mathcal{D}),$$

Definição 12.2 fornece

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_{C_2}).$$

Por Proposição 12.6,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2 \mid \mathbf{Z} \sim W_s(n - r, \Sigma_{C_2}).$$

A independência decorre de Proposição 12.11.

As duas matrizes possuem a mesma matriz de escala,

$$\Sigma_{C_2},$$

mas graus de liberdade diferentes:

- g corresponde ao número de combinações linearmente independentes dos termos do modelo definidas por $\mathbf{C}_1$;
- $n - r$ corresponde à dimensão do espaço residual.

Como

$$\text{posto}(\mathbf{C}_1) = g \quad \text{e} \quad \text{posto}(\mathbf{C}_2) = s,$$

a hipótese contém gs restrições escalares independentes.

O grau de liberdade da distribuição Wishart de $\mathbf{H}$ é, entretanto, g , porque a SQPC da hipótese é construída a partir de g vetores aleatórios no espaço das s combinações de respostas.

Por Proposição 12.2,

$$\text{posto}(\mathbf{H}) = \min(g, s)$$

e

$$\text{posto}(\mathbf{E}_{C_2}) = \min(n - r, s)$$

com probabilidade 1.

Em particular,

$$\mathbf{E}_{C_2} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se,

$$n - r \geq s. \quad (12.54)$$

Sob a hipótese alternativa

Defina

$$\Delta_0 = \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 - \Theta_0. \quad (12.55)$$

Quando

$$\Delta_0 \neq \mathbf{0},$$

a SQPC $\mathbf{H}$ possui distribuição Wishart não central. A matriz

$$\mathbf{E}_{C_2}$$

mantém sua distribuição Wishart central e permanece independente de $\mathbf{H}$ (Muirhead, 1982).

A não centralidade incorpora o afastamento entre $\mathbf{C}_1 \mathbf{B} \mathbf{C}_2$ e Θ_0 e será relevante para o estudo do poder. Sua parametrização detalhada não será necessária neste capítulo.

As distribuições obtidas nesta seção fornecem a estrutura probabilística geral para hipóteses lineares multivariadas.

Quando

$$\mathbf{C}_2 = \mathbf{I}_p,$$

obtem-se, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma)$$

e

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

com independência entre as duas matrizes. Esse par constitui a base probabilística das matrizes de hipótese e erro que serão utilizadas posteriormente na MANOVA.

O passo seguinte é estabelecer como uma hipótese conjunta é transformada em uma regra inferencial, distinguindo testes globais, razão de verossimilhanças e resultados exatos ou assintóticos.

12.4 Princípios da inferência multivariada

Uma hipótese multivariada pode impor simultaneamente várias restrições sobre um vetor, uma matriz ou uma função dos parâmetros. Um teste global avalia essas restrições como uma única afirmação estatística, considerando a dependência entre seus componentes.

No modelo linear multivariado, por exemplo,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0$$

é a hipótese geral definida em Definição 11.17. De forma semelhante,

$$H_0 : \mu = \mu_0$$

é uma única hipótese sobre o vetor de médias, ainda que envolva p componentes.

O nível α controla a probabilidade de rejeitar H_0 quando ela é verdadeira. Para uma alternativa especificada, o poder é a probabilidade de rejeitar H_0 quando essa alternativa é verdadeira. Na inferência multivariada, essas probabilidades dependem da forma como as várias componentes são reunidas na estatística de teste.

12.4.1 Testes globais e hipóteses simultâneas

Considere uma hipótese vetorial

$$H_0 : \mu = \mu_0.$$

Ela implica as igualdades coordenadas

$$\mu_j = \mu_{0j}, \quad j = 1, \dots, p,$$

mas a realização de p testes marginais separados não é equivalente a um teste global do vetor.

Se cada teste marginal possui nível α e os testes são independentes, a probabilidade de pelo menos uma rejeição incorreta sob a hipótese global é

$$1 - (1 - \alpha)^p. \quad (12.56)$$

Por exemplo, para

$$p = 5$$

e

$$\alpha = 0,05,$$

essa probabilidade é

$$1 - 0,95^5 \approx 0,226.$$

Quando as estatísticas são dependentes, a expressão anterior não se aplica diretamente, mas a conclusão permanece: realizar vários testes marginais no mesmo nível não garante controle do nível global.

Teste global e análise posterior

Um teste global avalia uma hipótese conjunta e utiliza a estrutura de dependência entre seus componentes.

A rejeição da hipótese global não identifica, por si só, quais componentes ou combinações lineares são responsáveis pelo afastamento. Essa investigação exige procedimentos posteriores, como contrastes ou intervalos simultâneos, com controle adequado da multiplicidade.

A distribuição da estatística sob H_0 determina a calibração do teste. Quando sua distribuição amostral exata é conhecida, os valores críticos e o valor- p podem ser obtidos diretamente dessa distribuição. Quando apenas uma distribuição limite é conhecida, a calibração é assintótica.

Sob alternativas, algumas estatísticas passam a depender de parâmetros de não centralidade que incorporam o afastamento de H_0 em relação à variabilidade do problema. Esses parâmetros são utilizados no estudo do poder, mas suas distribuições detalhadas não serão desenvolvidas neste capítulo.

12.4.2 Razão de verossimilhanças

A razão de verossimilhanças fornece um princípio geral para comparar o melhor ajuste permitido por uma hipótese nula com o melhor ajuste disponível no modelo irrestrito (Casella; Berger, 2002).

A hipótese nula restringe o espaço paramétrico do modelo irrestrito a um subconjunto de valores admissíveis.

Definição 12.3 (Estatística da razão de verossimilhanças). Considere um parâmetro

$$\vartheta \in \mathcal{P}$$

e a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0, \quad \emptyset \neq \mathcal{P}_0 \subseteq \mathcal{P}.$$

Suponha que, para as realizações consideradas,

$$0 < \sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y}) < \infty.$$

A estatística da razão de verossimilhanças é

$$\Lambda_{\text{RV}}(\mathcal{Y}) = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathcal{Y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathcal{Y})}. \quad (12.57)$$

Para uma realização observada $\mathbf{y}$, o valor observado da estatística é

$$\Lambda_{\text{RV,obs}} = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})}.$$

Como

$$\mathcal{P}_0 \subseteq \mathcal{P},$$

tem-se

$$0 \leq \Lambda_{\text{RV}} \leq 1.$$

Valores próximos de 1 indicam que a restrição imposta por H_0 produz pequena redução na verossimilhança máxima. Valores reduzidos indicam maior incompatibilidade entre a hipótese nula e os dados observados.

É conveniente utilizar a transformação

$$-2 \log \Lambda_{\text{RV}}.$$

Quando os máximos são atingidos e

$$\hat{\vartheta}$$

e

$$\tilde{\vartheta}$$

denotam, respectivamente, os estimadores de máxima verossimilhança irrestrito e restrito,

$$-2 \log \Lambda_{\text{RV}} = 2 \left[\ell(\hat{\vartheta}) - \ell(\tilde{\vartheta}) \right], \quad (12.58)$$

em que

$$\ell(\vartheta) = \log L(\vartheta; \mathbf{y}).$$

A estatística é não negativa e cresce à medida que as restrições impostas por H_0 reduzem o máximo da verossimilhança.

A distribuição de

$$-2 \log \Lambda_{\text{RV}}$$

depende do modelo. Em alguns problemas, existe uma distribuição exata ou uma transformação exata para uma distribuição conhecida. Quando essa distribuição não está disponível, modelos paramétricos regulares admitem uma aproximação assintótica fornecida pelo teorema de Wilks.

12.4.3 Resultado assintótico de Wilks

Teorema 12.4 (Resultado assintótico de Wilks). *Considere um espaço paramétrico*

$$\mathcal{P} \subseteq \mathbb{R}^k,$$

com k fixo quando $n \rightarrow \infty$, e um parâmetro verdadeiro

$$\vartheta_0 \in \text{int}(\mathcal{P}).$$

Considere a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0,$$

em que, em uma vizinhança de ϑ_0 ,

$$\mathcal{P}_0 = \{\vartheta \in \mathcal{P} : \mathbf{h}(\vartheta) = \mathbf{0}\},$$

com

$$\mathbf{h} : \mathcal{P} \longrightarrow \mathbb{R}^d$$

continuamente diferenciável e

$$\text{posto}[\mathbf{J}_{\mathbf{h}}(\vartheta_0)] = d,$$

com d fixo.

Seja

$$\ell_n(\vartheta) = \log L_n(\vartheta).$$

Suponha que:

1. *o modelo seja identificável;*

2. $\ell_n(\vartheta)$ seja duas vezes continuamente diferenciável em uma vizinhança de ϑ_0 ;
3. exista uma matriz

$$\mathbf{I}(\vartheta_0) \succ \mathbf{0}$$

tal que

$$\frac{1}{\sqrt{n}} \nabla \ell_n(\vartheta_0) \xrightarrow{d} N_k[\mathbf{0}, \mathbf{I}(\vartheta_0)];$$

4. para toda sequência

$$\vartheta_n \xrightarrow{P} \vartheta_0,$$

tem-se

$$-\frac{1}{n} \nabla^2 \ell_n(\vartheta_n) \xrightarrow{P} \mathbf{I}(\vartheta_0);$$

5. os estimadores de máxima verossimilhança irrestrito e restrito existem e satisfazem

$$\hat{\vartheta}_n \xrightarrow{P} \vartheta_0$$

e

$$\tilde{\vartheta}_n \xrightarrow{P} \vartheta_0$$

sob H_0 .

Então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2. \quad (12.59)$$

O número d corresponde ao número de restrições localmente independentes impostas por H_0 e satisfaz

$$d = \dim(\mathcal{P}) - \dim(\mathcal{P}_0)$$

na vizinhança de ϑ_0 .

(Vaart, 1998)

O resultado é assintótico (Vaart, 1998). Para uma amostra grande, uma região crítica aproximada de nível α é

$$-2 \log \Lambda_{\text{RV}} > \chi_{d;1-\alpha}^2. \quad (12.60)$$

O correspondente valor- p aproximado é

$$P[\chi_d^2 \geq -2 \log \Lambda_{\text{RV,obs}}]. \quad (12.61)$$

O número

$$d$$

não deve ser obtido simplesmente pela contagem de todas as expressões escritas na hipótese. Ele corresponde ao número de restrições **localmente independentes** ou, equivalentemente em situações regulares, à diferença entre as dimensões dos espaços paramétricos irrestrito e restrito.

Situações não regulares

A aproximação qui-quadrado do Teorema 12.4 não se aplica automaticamente quando:

- o parâmetro verdadeiro está na fronteira do espaço paramétrico;
- o modelo não é identificável;
- há restrições redundantes;
- a informação de Fisher é singular;
- a dimensão do parâmetro cresce com o tamanho amostral.

Nessas situações, a distribuição limite pode ser diferente de uma qui-quadrado convencional.

O **teorema de Wilks** em Teorema 12.4 é um resultado assintótico geral sobre razões de verossimilhanças. Ele deve ser distinguido da **lambda de Wilks**, que é uma estatística matricial específica utilizada posteriormente na MANOVA.

12.4.4 Razão de verossimilhanças em modelos normais encaixados

O princípio da razão de verossimilhanças pode ser aplicado aos modelos lineares multivariados encaixados de Proposição 11.13.

Considere a comparação entre um modelo completo e um modelo reduzido encaixado. A matriz **H** representa a redução da SQPC residual obtida pela inclusão, no modelo completo, dos termos ausentes no modelo reduzido.

Sob o modelo normal matricial com matriz de covariâncias residual comum, a verossimilhança maximizada é proporcional a $|\mathbf{E}|^{-n/2}$. A razão de verossimilhanças pode, portanto, ser expressa por meio dos determinantes das SQPCs residuais dos dois modelos.

Proposição 12.13 (Razão de verossimilhanças em modelos normais encaixados). *Considere modelos lineares normais multivariados completo e reduzido, definidos sobre as mesmas n unidades, com matriz de covariâncias residual comum*

$$\Sigma \succ \mathbf{0},$$

e tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F).$$

Se suas SQPCs residuais $\mathbf{E}_F$ e $\mathbf{E}_R$ são positivas definidas e

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H} \tag{12.62}$$

e

$$\mathbf{H} \succeq \mathbf{0},$$

então

$$\Lambda_{\text{RV}} = \left(\frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} \right)^{n/2}. \tag{12.63}$$

Equivalentemente,

$$\Lambda_{\text{RV}} = \left[\frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \right]^{n/2}. \tag{12.64}$$

A razão de determinantes

$$\Lambda_{\text{W}} = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \tag{12.65}$$

é denominada **lambda de Wilks**. Assim,

$$\Lambda_{RV} = \Lambda_W^{n/2}. \quad (12.66)$$

Portanto, Λ_{RV} e Λ_W são funções monotônicas uma da outra e conduzem à mesma ordenação das evidências contra H_0 .

Neste capítulo, a lambda de Wilks aparece como consequência da razão de verossimilhanças em modelos normais encaixados. Sua distribuição e sua utilização como critério específico da MANOVA serão desenvolvidas no Módulo 3.

Como

$$\mathbf{H} \succeq \mathbf{0},$$

a imposição das restrições do modelo reduzido não diminui a SQPC residual na ordem de Löwner:

$$\mathbf{E}_R \succeq \mathbf{E}_F.$$

Quando ambas são positivas definidas,

$$|\mathbf{E}_R| \geq |\mathbf{E}_F|,$$

e, portanto,

$$0 < \Lambda_{RV} \leq 1.$$

Valores de Λ_W próximos de 1 indicam pequena diferença entre os ajustes completo e reduzido. Valores menores indicam maior redução da dispersão residual quando os termos adicionais do modelo completo são incluídos.

A decomposição desse critério por raízes características e sua relação com os demais critérios multivariados pertencem à MANOVA.

Existência da forma por determinantes

A expressão em Equação 12.63 exige que as matrizes residuais relevantes sejam positivas definidas.

Sob o modelo normal, uma condição suficiente para

$$\mathbf{E}_F \succ \mathbf{0}$$

com probabilidade 1 é

$$n - r_F \geq p,$$

em que

$$r_F = \text{posto}(\mathbf{Z}_F).$$

Como

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H}$$

e

$$\mathbf{H} \succcurlyeq \mathbf{0},$$

a definição positiva de $\mathbf{E}_F$ implica a definição positiva de $\mathbf{E}_R$.

Quando a SQPC residual é singular, a razão de determinantes clássica deixa de estar disponível na forma anterior. Pseudoinversas, pseudodeterminantes ou regularização definem procedimentos diferentes e não preservam automaticamente a distribuição nula utilizada pela inferência clássica.

A razão de verossimilhanças fornece um princípio geral para comparar modelos restritos e irrestritos. Para a inferência sobre um único vetor de médias, entretanto, existem distribuições exatas mais específicas.

Quando Σ é conhecida, a forma quadrática da média amostral conduz diretamente a uma distribuição qui-quadrado. Quando Σ é desconhecida e precisa ser estimada por $\mathbf{S}$, a distribuição muda e conduz à estatística T^2 de Hotelling.

12.5 Inferência sobre um vetor de médias

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succcurlyeq \mathbf{0}.$$

O objetivo inicial é testar

$$H_0 : \mu = \mu_0$$

contra

$$H_1 : \mu \neq \mu_0,$$

em que

$$\mu_0 \in \mathbb{R}^p$$

é conhecido.

A distribuição da média amostral foi estabelecida em Proposição 12.1. A forma da estatística de teste depende de a matriz populacional Σ ser conhecida ou precisar ser substituída por sua estimativa amostral.

12.5.1 Covariância conhecida

Pela Proposição 12.1,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right).$$

Sob H_0 ,

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu_0) \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

Definição 12.4 (Estatística para a média com covariância conhecida). Quando $\Sigma \succ \mathbf{0}$ é conhecida, define-se

$$Q_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.67)$$

A forma quadrática utiliza a distância de Mahalanobis definida em Definição 8.9. Como

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n},$$

o fator n ajusta a distância à variabilidade da média amostral, e não à variabilidade de uma observação individual.

Proposição 12.14 (Distribuição com covariância conhecida). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$ conhecida, então, sob

$$H_0 : \mu = \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2. \quad (12.68)$$

O resultado decorre de Proposição 9.8 aplicado à distribuição da média amostral em Proposição 12.1. A matriz de covariâncias da média é Σ/n , o que produz a forma em Equação 12.67.

Assim, um teste de nível α rejeita H_0 quando

$$Q_{\mu, \text{obs}} > \chi_{p; 1-\alpha}^2, \quad (12.69)$$

em que

$$Q_{\mu, \text{obs}} = n \left(\bar{\mathbf{x}} - \mu_0 \right)^\top \Sigma^{-1} \left(\bar{\mathbf{x}} - \mu_0 \right). \quad (12.70)$$

O valor- p é

$$P(\chi_p^2 \geq Q_{\mu, \text{obs}}). \quad (12.71)$$

Sob uma alternativa fixa, a distribuição torna-se qui-quadrado não central, com parâmetro

$$\lambda_\mu = n \left(\mu - \mu_0 \right)^\top \Sigma^{-1} \left(\mu - \mu_0 \right). \quad (12.72)$$

Assim, a não centralidade cresce com o tamanho amostral e com o afastamento entre μ e μ_0 medido na geometria de Σ . Esse parâmetro será utilizado apenas como referência para a interpretação do poder.

Quando

$$p = 1,$$

obtém-se

$$Q_\mu = \frac{n(\bar{X} - \mu_0)^2}{\sigma^2},$$

que corresponde ao quadrado da estatística normal padronizada utilizada no teste de uma média com variância conhecida.

12.5.2 Estatística T^2 de Hotelling

Na maior parte das aplicações,

$$\Sigma$$

é desconhecida e precisa ser estimada. A substituição de Σ por $\mathbf{S}$ não preserva a distribuição qui-quadrado de Equação 12.68, porque a matriz utilizada na forma quadrática passa a ser aleatória.

Os resultados obtidos anteriormente fornecem

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

por Proposição 12.1,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

por Teorema 12.2, e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

por Teorema 12.3.

A estatística T^2 combina esses três resultados.

Definição 12.5 (Estatística T^2 de Hotelling para uma amostra). A estatística para testar

$$H_0 : \mu = \mu_0$$

quando Σ é desconhecida e $\mathbf{S} \succ \mathbf{0}$ é

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0). \quad (12.73)$$

A forma clássica de T^2 exige

$$\mathbf{S} \succ \mathbf{0},$$

pois utiliza $\mathbf{S}^{-1}$.

Como

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

Proposição 12.2 mostra que, sob $\Sigma \succ \mathbf{0}$,

$$\mathbf{S} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > p. \quad (12.74)$$

O fator n aparece porque a matriz de covariâncias da média é

$$\frac{\Sigma}{n}.$$

A expressão de T^2 tem a mesma forma quadrática utilizada na distância de Mahalanobis, mas emprega a matriz aleatória $\mathbf{S}$ no lugar de Σ . Portanto, trata-se de uma forma de Mahalanobis **estimada**, cuja distribuição precisa incorporar a variabilidade da estimação da covariância.

Proposição 12.15 (Distribuição exata de T^2). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \mu = \mu_0,$$

vale

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}. \quad (12.75)$$

Esse resultado utiliza conjuntamente a distribuição normal da média, a distribuição Wishart da covariância amostral e a independência entre esses dois objetos (Anderson, 2003; Rencher; Christensen, 2012).

Quando Σ é conhecida, somente a média amostral é aleatória na forma quadrática e obtém-se uma distribuição χ_p^2 . Quando Σ é substituída por $\mathbf{S}$, a incerteza da covariância estimada também participa da estatística. A transformação em Equação 12.75 incorpora essa fonte adicional de variabilidade e produz a distribuição F exata.

Após a observação,

$$\mathbf{T}_{\text{obs}}^2 = n (\bar{\mathbf{x}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0). \quad (12.76)$$

Defina

$$\mathbf{F}_{\text{obs}} = \frac{n-p}{p(n-1)} \mathbf{T}_{\text{obs}}^2. \quad (12.77)$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}, \quad (12.78)$$

ou, equivalentemente, quando

$$\mathbf{F}_{\text{obs}} > F_{p, n-p; 1-\alpha}.$$

O valor- p é

$$P(F_{p, n-p} \geq \mathbf{F}_{\text{obs}}). \quad (12.79)$$

A rejeição informa que o vetor populacional não coincide com μ_0 . Ela não identifica, isoladamente, quais componentes ou combinações lineares são responsáveis pelo afastamento.

Sob uma alternativa fixa, a transformação de $\mathbf{T}^2$ possui distribuição F não central, com o mesmo parâmetro λ_μ definido em Equação 12.72. Essa distribuição é utilizada em estudos de poder e não será desenvolvida adicionalmente neste capítulo.

12.5.3 Relações com os casos assintótico e univariado

Quando p permanece fixo e

$$n \longrightarrow \infty,$$

a consistência de $\mathbf{S}$ estabelecida em Proposição 10.12 implica, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \quad (12.80)$$

Portanto, a distribuição qui-quadrado fornece uma aproximação assintótica. Sob normalidade e em amostras finitas, a distribuição F em Equação 12.75 é o resultado exato.

Quando

$$p = 1,$$

a matriz de covariâncias amostral reduz-se à variância amostral S . Assim,

$$\mathbf{T}^2 = \frac{n(\bar{X} - \mu_0)^2}{S} = \mathbf{t}^2, \quad (12.81)$$

em que

$$\mathbf{t} = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sqrt{S}} \sim t_{n-1}$$

sob H_0 .

Assim, o teste T^2 de uma amostra é a extensão multivariada do teste t de Student.

A estatística também é invariante a transformações afins com parte linear não singular. Se

$$\mathbf{Y}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b}, \quad \det(\mathbf{A}) \neq 0,$$

então Proposição 8.6 fornece

$$\mathbf{S}_Y = \mathbf{A} \mathbf{S} \mathbf{A}^\top.$$

Como

$$(\mathbf{A} \mathbf{S} \mathbf{A}^\top)^{-1} = \mathbf{A}^{-\top} \mathbf{S}^{-1} \mathbf{A}^{-1},$$

os fatores $\mathbf{A}$ se cancelam na forma quadrática e o valor de T^2 permanece inalterado.

12.5.4 Região de confiança elipsoidal

A região de confiança para μ é obtida reunindo todos os vetores que não seriam rejeitados pelo teste T^2 ao nível α . Essa inversão do teste produz uma região simultânea para todo o vetor de médias.

Proposição 12.16 (Região de confiança para o vetor de médias). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

defina

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.82)$$

Então,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{X}} - \theta)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \theta) \leq c_{\alpha,p,n} \right\} \quad (12.83)$$

possui cobertura

$$P(\mu \in \mathcal{C}_{1-\alpha}) = 1 - \alpha. \quad (12.84)$$

Após a observação,

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : (\theta - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\theta - \bar{\mathbf{x}}) \leq \frac{c_{\alpha,p,n}}{n} \right\}. \quad (12.85)$$

A dualidade entre teste e região de confiança fornece

$$\mu_0 \in \mathcal{C}_{1-\alpha} \iff T_{\text{obs}}^2(\mu_0) \leq c_{\alpha,p,n}. \quad (12.86)$$

12.5.5 Geometria da região

A região observada é um elipsoide centrado em

$$\bar{\mathbf{x}}.$$

Considere a decomposição espectral

$$\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top,$$

com

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Em coordenadas espectrais, sua fronteira é

$$\sum_{j=1}^p \frac{z_j^2}{c_{\alpha,p,n} \lambda_j / n} = 1. \quad (12.87)$$

Consequentemente, os eixos do elipsoide são os autovetores de $\mathbf{S}$ e o comprimento do j -ésimo semieixo é

$$a_j = \sqrt{\frac{c_{\alpha,p,n} \lambda_j}{n}}. \quad (12.88)$$

A forma da região é a mesma estrutura elipsoidal de Equação 8.32, agora centrada em $\bar{\mathbf{x}}$ e escalada pela constante inferencial $c_{\alpha,p,n}/n$. A orientação e os comprimentos dos eixos decorrem da decomposição espectral utilizada em Equação 8.26.

A Figura 12.1 mostra, no caso bidimensional, como a covariância altera a orientação da região de confiança.




Figura 12.1: Efeito da matriz de covariâncias sobre a forma e a orientação da região de confiança para o vetor de médias.

Na primeira configuração da Figura 12.1, os eixos permanecem alinhados às coordenadas originais. Na segunda, a covariância positiva produz rotação do elipsoide. A região reflete, portanto, tanto as variâncias marginais quanto a dependência entre as componentes.

Interpretação da cobertura

Antes da observação dos dados,

$$\mathcal{C}_{1-\alpha}$$

é uma região aleatória que contém o verdadeiro vetor μ com probabilidade $1 - \alpha$.

Depois da observação, a região está fixada. Na interpretação frequentista, o parâmetro não passa a ser aleatório; a cobertura refere-se ao comportamento do procedimento em repetições amostrais.

12.5.6 Intervalos simultâneos

Cada vetor

$$\mathbf{a} \in \mathbb{R}^p$$

define uma combinação linear $\mathbf{a}^\top \mu$. Como todos esses funcionais são obtidos da mesma região elipsoidal, é possível construir intervalos com cobertura simultânea para todas as direções.

Proposição 12.17 (Intervalos simultâneos de Hotelling). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

com

$$n > p \quad e \quad 0 < \alpha < 1,$$

e

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha},$$

os intervalos

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}, \quad \mathbf{a} \in \mathbb{R}^p, \quad (12.89)$$

possuem cobertura simultânea $1 - \alpha$ para todas as combinações lineares.

i Demonstração

Se

$$\mu \in \mathcal{C}_{1-\alpha},$$

então

$$(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}}) \leq \frac{c_{\alpha,p,n}}{n}.$$

Pela desigualdade de Cauchy–Schwarz na geometria induzida por $\mathbf{S}$,

$$|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \sqrt{(\mu - \bar{\mathbf{X}})^\top \mathbf{S}^{-1} (\mu - \bar{\mathbf{X}})}.$$

Substituindo o limite da região, obtém-se Equação 12.89 simultaneamente para todas as direções $\mathbf{a}$.

Após a observação dos dados,

$$\mathbf{a}^\top \mu \in \mathbf{a}^\top \bar{\mathbf{x}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S} \mathbf{a}}. \quad (12.90)$$

Para

$$\mathbf{a} = \mathbf{e}_j,$$

obtém-se o intervalo simultâneo para uma componente:

$$\mu_j \in \bar{x}_j \pm \sqrt{\frac{c_{\alpha,p,n} S_{jj}}{n}}. \quad (12.91)$$

Para

$$\mathbf{a} = \mathbf{e}_j - \mathbf{e}_k,$$

obtém-se

$$\mu_j - \mu_k \in \bar{x}_j - \bar{x}_k \pm \sqrt{\frac{c_{\alpha,p,n}}{n} (S_{jj} + S_{kk} - 2S_{jk})}. \quad (12.92)$$

Os intervalos de Hotelling fornecem cobertura simultânea para todas as combinações lineares $\mathbf{a}^\top \mu$. Quando o interesse está restrito a um conjunto finito e previamente especificado de combinações, procedimentos como Bonferroni utilizam uma família de inferências menor e podem produzir intervalos mais estreitos, dependendo da estrutura de covariâncias e do número de comparações.

12.5.7 Hipóteses lineares sobre o vetor de médias

A hipótese

$$H_0 : \mu = \mu_0$$

especifica todo o vetor de médias. Em outros problemas, o interesse está restrito a determinadas combinações lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{h \times p},$$

com

$$\text{posto}(\mathbf{A}) = h \leq p,$$

e

$$\mathbf{d} \in \mathbb{R}^h.$$

A hipótese é

$$H_0 : \mathbf{A}\mu = \mathbf{d}. \quad (12.93)$$

Cada linha de $\mathbf{A}$ define uma restrição linear. A condição de posto linha completo elimina restrições redundantes.

Defina

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

A distribuição decorre diretamente de Proposição 9.4.

Como $\mathbf{A}$ possui posto linha completo e

$$\Sigma \succ \mathbf{0},$$

tem-se

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

A média e a covariância amostrais transformadas são

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}}$$

e

$$\mathbf{S}_U = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Assim, o problema reduz-se exatamente à inferência sobre um vetor de médias de dimensão h .

12.5.7.1 Covariância conhecida

Quando Σ é conhecida, defina

$$Q_A = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.94)$$

Sob H_0 ,

$$Q_A \sim \chi_h^2. \quad (12.95)$$

Esse é Proposição 12.14 aplicado ao vetor transformado $\mathbf{U}_i$. Portanto, os graus de liberdade são determinados pelas h combinações linearmente independentes presentes na hipótese, e não pela dimensão original p .

12.5.7.2 Covariância desconhecida

Sob normalidade,

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top \succ \mathbf{0}$$

com probabilidade 1 quando

$$n > h. \quad (12.96)$$

Proposição 12.18 (Distribuição para hipóteses lineares sobre a média). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

e

$$\mathbf{A} \in \mathbb{R}^{h \times p}, \quad 1 \leq h \leq p, \quad \text{posto}(\mathbf{A}) = h, \quad \mathbf{d} \in \mathbb{R}^h, \quad n > h,$$

então, sob

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

a estatística

$$\mathbf{T}_A^2 = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}) \quad (12.97)$$

satisfaz

$$\frac{n-h}{h(n-1)} \mathbf{T}_A^2 \sim F_{h,n-h}. \quad (12.98)$$

O resultado é Proposição 12.15 aplicado aos vetores transformados

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i \in \mathbb{R}^h.$$

Por isso, a condição dimensional passa de $n > p$ para $n > h$.

Assim, um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{A,\text{obs}}^2 > \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha}, \quad (12.99)$$

em que

$$\mathbf{T}_{A,\text{obs}}^2 = n (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d}). \quad (12.100)$$

Uma consequência importante é que a condição dimensional depende de

$$h,$$

e não necessariamente de p .

Assim, mesmo quando

$$p \geq n$$

e a matriz completa

$$\mathbf{S}$$

é singular, uma hipótese de dimensão reduzida ainda pode admitir a inferência clássica se

$$n > h$$

e

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top$$

for não singular.

Quando

$$h = 1,$$

com

$$\mathbf{A} = \mathbf{a}^\top,$$

a hipótese

$$H_0 : \mathbf{a}^\top \mu = d$$

reduz-se ao teste t univariado aplicado à combinação linear

$$\mathbf{a}^\top \mathbf{X}.$$

Quando

$$h = p, \quad \mathbf{A} = \mathbf{I}_p, \quad \mathbf{d} = \mu_0,$$

recupera-se o teste T^2 para o vetor completo de médias.

12.5.8 Relação com o modelo linear multivariado

O modelo de uma única população pode ser escrito como

$$y = \mathbf{1}_n \mu^\top + \mathcal{E}.$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Na hipótese geral de Definição 11.17,

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

tome

$$\mathbf{C}_1 = [1], \quad \mathbf{C}_2 = \mathbf{A}^\top$$

e

$$\Theta_0 = \mathbf{d}^\top.$$

Então,

$$\mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \mu^\top \mathbf{A}^\top = (\mathbf{A} \mu)^\top.$$

Portanto,

$$H_0 : \mathbf{A} \mu = \mathbf{d}$$

é um caso particular da hipótese linear geral do Capítulo 11.

Essa correspondência mostra que o teste T^2 para uma média, as hipóteses sobre combinações lineares e a inferência no modelo linear multivariado utilizam a mesma estrutura. A próxima seção estende o problema à comparação entre dois vetores de médias.

12.6 Comparação entre dois vetores de médias

A comparação entre dois vetores de médias depende da relação entre as unidades que produziram as observações. Duas estruturas serão consideradas:

- **amostras independentes**, formadas por unidades distintas;
- **observações pareadas**, nas quais cada unidade ou par fornece duas medições relacionadas.

Nos dois casos, o parâmetro de interesse é uma diferença entre vetores de médias. O delineamento determina, porém, a matriz de covariâncias dessa diferença e, consequentemente, a estatística utilizada na inferência.

12.6.1 Duas amostras independentes

Considere duas amostras mutuamente independentes:

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A especificação de uma mesma matriz

$$\Sigma$$

para as duas populações é parte do modelo utilizado pelo procedimento clássico com covariância agrupada.

O parâmetro de interesse é

$$\delta = \mu_1 - \mu_2 \in \mathbb{R}^p. \quad (12.101)$$

Considere a hipótese

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (12.102)$$

contra

$$H_1 : \mu_1 - \mu_2 \neq \delta_0.$$

A igualdade dos vetores de médias corresponde ao caso

$$\delta_0 = \mathbf{0}.$$

12.6.1.1 Distribuição da diferença entre as médias

Aplicando Proposição 12.1 separadamente às duas amostras,

$$\bar{\mathbf{X}}_1 \sim N_p \left(\mu_1, \frac{\Sigma}{n_1} \right)$$

e

$$\bar{\mathbf{X}}_2 \sim N_p \left(\mu_2, \frac{\Sigma}{n_2} \right).$$

Como as amostras são independentes,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left[\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right]. \quad (12.103)$$

Para simplificar as expressões seguintes, defina o fator

$$n_{\text{ef}} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} = \frac{n_1 n_2}{n_1 + n_2}. \quad (12.104)$$

Então,

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma}{n_{\text{ef}}}.$$

A notação n_{ef} será utilizada apenas como fator de escala da covariância da diferença entre as médias. Ela não representa o número total de observações nem os graus de liberdade do procedimento.

12.6.1.2 Covariância agrupada

Como Σ é desconhecida, as duas amostras fornecem estimativas da mesma matriz de covariâncias populacional. Essas estimativas são combinadas ponderando cada SQPC pelos respectivos graus de liberdade:

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.105)$$

A matriz $\mathbf{S}_p$ é denominada **matriz de covariâncias agrupada**.

Após a observação,

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.106)$$

Por Teorema 12.2, sob o modelo de covariância comum,

$$(n_h - 1)\mathbf{S}_h \sim W_p(n_h - 1, \Sigma), \quad h = 1, 2.$$

Como as duas amostras são independentes, essas matrizes Wishart também são independentes. Portanto, Proposição 12.5 pode ser aplicada às duas SQPCs.

Proposição 12.19 (Distribuição da covariância agrupada). *Se as duas amostras são independentes, cada amostra é formada por observações i.i.d. normais multivariadas em $\mathbb{R}^p$ e ambas possuem matriz de covariâncias comum*

$$\Sigma \succ \mathbf{0},$$

com

$$n_1 \geq 2 \quad e \quad n_2 \geq 2,$$

então

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma). \quad (12.107)$$

Além disso,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \perp \mathbf{S}_p. \quad (12.108)$$

i Demonstração

Pela aditividade da distribuição de Wishart,

$$(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2 \\ \sim W_p(n_1 + n_2 - 2, \Sigma).$$

A matriz no lado esquerdo é

$$(n_1 + n_2 - 2)\mathbf{S}_p.$$

Sob normalidade, em cada amostra a média é independente da respectiva matriz de covariâncias. A independência entre as duas amostras implica então a independência entre

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$$

e

$$\mathbf{S}_p.$$

A distribuição em Equação 12.107 fornece

$$E(\mathbf{S}_p) = \Sigma.$$

Além disso, por Proposição 12.2,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1. Portanto,

$$\mathbf{S}_p \succ \mathbf{0}$$

com probabilidade 1 quando

$$n_1 + n_2 - 2 \geq p. \tag{12.109}$$

12.6.1.3 Estatística T^2 para duas amostras

Definição 12.6 (Estatística T^2 para duas amostras independentes). Para testar

$$H_0 : \mu_1 - \mu_2 = \delta_0,$$

quando

$$\mathbf{S}_p \succ \mathbf{0},$$

define-se

$$T_{\text{ind}}^2 = n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \right), \quad (12.110)$$

em que

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}$$

e

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}.$$

A estatística possui a mesma forma quadrática do T^2 de uma amostra. O vetor de afastamento é agora

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0,$$

e sua variabilidade é estimada pela matriz de covariâncias agrupada.

Proposição 12.20 (Distribuição exata de T^2 para duas amostras). *Se as duas amostras são independentes e*

$$\mathbf{X}_{1i} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma), \quad i = 1, \dots, n_1,$$

e

$$\mathbf{X}_{2i} \overset{\text{iid}}{\sim} N_p\left(\mu_2, \Sigma\right), \qquad i=1, \ldots, n_2,$$

com

$$\Sigma \succ \mathbf{0}, \qquad n_1 \geq 2, \qquad n_2 \geq 2,$$

e

$$n_1+n_2-2\geq p,$$

então, sob

$$H_0:\mu_1-\mu_2=\delta_0,$$

tem-se

$$\frac{n_1+n_2-p-1}{p(n_1+n_2-2)}\mathsf{T}^2_{\text{ind}}\sim F_{p,\,n_1+n_2-p-1}.\tag{12.111}$$

i Demonstração

Sob H_0 , o vetor

$$\mathbf{V} = \sqrt{n_{\text{ef}}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)$$

satisfaz

$$\mathbf{V} \sim N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\mathbf{W} = (n_1 + n_2 - 2)\mathbf{S}_p$$

satisfaz, por Proposição 12.19,

$$\mathbf{W} \sim W_p(n_1 + n_2 - 2, \Sigma)$$

e

$$\mathbf{V} \perp \mathbf{W}.$$

A mesma estrutura normal–Wishart utilizada em Proposição 12.15 fornece

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} \mathbf{T}_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}.$$

Para os dados observados,

$$\begin{aligned} \mathbf{T}_{\text{ind,obs}}^2 &= n_{\text{ef}} \left(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \right)^\top \mathbf{S}_p^{-1} \\ &\quad \left(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0 \right). \end{aligned} \tag{12.112}$$

Um teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{ind,obs}}^2 > \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \tag{12.113}$$

Defina

$$c_{\alpha, p, n_1, n_2} = \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \tag{12.114}$$

A inversão do teste fornece uma região de confiança de nível $1 - \alpha$ para

$$\delta = \mu_1 - \mu_2 :$$

$$\mathcal{C}_{\delta, 1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n_{\text{ef}} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \right)^\top \mathbf{S}_p^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta \right) \leq c_{\alpha, p, n_1, n_2} \right\}. \quad (12.115)$$

A região é um elipsoide centrado em

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2,$$

com orientação determinada pela matriz de covariâncias agrupada.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

os intervalos derivados dessa região são

$$\mathbf{a}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) \pm \sqrt{\frac{c_{\alpha, p, n_1, n_2}}{n_{\text{ef}}} \mathbf{a}^\top \mathbf{S}_p \mathbf{a}}. \quad (12.116)$$

Esses intervalos fornecem cobertura simultânea para todas as combinações lineares de δ .

Quando

$$p = 1,$$

o procedimento reduz-se ao quadrado do teste t para duas amostras independentes com variâncias populacionais iguais:

$$T_{\text{ind}}^2 = t_{\text{pooled}}^2. \quad (12.117)$$

12.6.2 Covariâncias populacionais distintas

O procedimento anterior foi construído sob

$$\Sigma_1 = \Sigma_2.$$

Se

$$\Sigma_1 \neq \Sigma_2,$$

a diferença entre as médias continua tendo, sob normalidade,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left(\mu_1 - \mu_2, \frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2} \right). \quad (12.118)$$

Entretanto, a matriz agrupada satisfaz

$$E(\mathbf{S}_p) = \frac{(n_1 - 1)\Sigma_1 + (n_2 - 1)\Sigma_2}{n_1 + n_2 - 2},$$

e não estima diretamente

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}.$$

Consequentemente, a estrutura normal–Wishart utilizada em Proposição 12.20 deixa de ser válida com a matriz agrupada, e a transformação para a distribuição F não é mais exata.

Papel da homogeneidade das covariâncias

A igualdade

$$\Sigma_1 = \Sigma_2$$

não é necessária para o T^2 de uma amostra nem para o procedimento pareado.

Ela é uma hipótese específica do procedimento de duas amostras independentes que utiliza a covariância agrupada.

Quando as covariâncias populacionais são distintas, o problema inferencial é diferente e requer outro procedimento ou outra aproximação. A simples substituição de $\mathbf{S}_p$ por uma matriz alternativa não preserva automaticamente a distribuição F clássica.

12.6.3 Observações pareadas

No delineamento pareado, considere

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

em que os pares são independentes entre si, mas as duas medições dentro de cada par podem ser dependentes.

O número

$$n$$

representa o número de pares completos.

Defina

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i. \quad (12.119)$$

O vetor médio das diferenças é

$$\delta = E(\mathbf{D}_i) = \mu_X - \mu_Y. \quad (12.120)$$

Sua matriz de covariâncias é

$$\Sigma_D = \Sigma_X + \Sigma_Y - \Sigma_{XY} - \Sigma_{YX}. \quad (12.121)$$

A expressão mostra por que a associação dentro dos pares deve ser preservada: ela participa diretamente da variabilidade das diferenças.

A hipótese é

$$H_0 : \delta = \delta_0. \quad (12.122)$$

Para comparar diretamente as duas condições,

$$\delta_0 = \mathbf{0}.$$

Depois de formar as diferenças, cada par produz um único vetor

$$\mathbf{D}_i.$$

A comparação entre as duas condições passa, portanto, a ser uma inferência sobre o vetor médio de uma única população de diferenças:

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Suponha

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}.$$

A média amostral das diferenças é

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{i=1}^n \mathbf{D}_i = \bar{\mathbf{X}} - \bar{\mathbf{Y}}. \quad (12.123)$$

A matriz de covariâncias amostral é

$$\mathbf{S}_D = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{D}_i - \bar{\mathbf{D}}) (\mathbf{D}_i - \bar{\mathbf{D}})^\top. \quad (12.124)$$

Quando as matrizes são calculadas sobre os mesmos pares completos,

$$\mathbf{S}_D = \mathbf{S}_X + \mathbf{S}_Y - \mathbf{S}_{XY} - \mathbf{S}_{YX}. \quad (12.125)$$

A decomposição populacional em Equação 12.121 utiliza a covariância cruzada definida em Definição 8.3. Sua contraparte amostral em Equação 12.125 utiliza a matriz definida em Definição 10.16.

Definição 12.7 (Estatística T^2 para observações pareadas). Para os vetores de diferenças pareadas

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i, \quad i = 1, \dots, n,$$

com vetor de médias amostrais $\bar{\mathbf{D}}$ e matriz de covariâncias amostral $\mathbf{S}_D \succ \mathbf{0}$, define-se

$$\mathsf{T}_{\text{par}}^2 = n (\bar{\mathbf{D}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \delta_0). \quad (12.126)$$

Proposição 12.21 (Distribuição exata de T^2 para observações pareadas). *Se*

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}$$

e

$$n > p,$$

então, sob

$$H_0 : \delta = \delta_0,$$

tem-se

$$\frac{n-p}{p(n-1)} T_{\text{par}}^2 \sim F_{p, n-p}. \quad (12.127)$$

A proposição é Proposição 12.15 aplicada à amostra

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Por isso, o número de observações utilizado no teste é o número de pares completos.

Para os dados observados,

$$T_{\text{par,obs}}^2 = n (\bar{\mathbf{d}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \delta_0). \quad (12.128)$$

Um teste de nível α rejeita H_0 quando

$$T_{\text{par,obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}. \quad (12.129)$$

Quando

$$p = 1,$$

recupera-se o quadrado do teste t pareado:

$$T_{\text{par}}^2 = t_{\text{par}}^2. \quad (12.130)$$

Aplicando Proposição 12.16 à população de diferenças, obtém-se a região de confiança de nível $1 - \alpha$

$$\mathcal{C}_{D,1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{D}} - \theta)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \theta) \leq c_{\alpha,p,n} \right\}, \quad (12.131)$$

em que $c_{\alpha,p,n}$ foi definida em Equação 12.82.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

Proposição 12.17 fornece

$$\mathbf{a}^\top \bar{\mathbf{D}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S}_D \mathbf{a}}. \quad (12.132)$$

Assim, teste, região de confiança e intervalos simultâneos do caso pareado são os resultados de uma amostra aplicados aos vetores de diferenças.

Preservação do pareamento

O procedimento deve ser aplicado às diferenças construídas com a correspondência correta entre as unidades.

Tratar as duas condições como amostras independentes elimina da análise a covariância intrapar e utiliza uma estrutura de variabilidade diferente daquela determinada pelo delineamento.

A normalidade necessária ao resultado exato refere-se à distribuição dos vetores

$$\mathbf{D}_i,$$

e não exige, separadamente, que cada uma das duas condições possua distribuição marginal normal multivariada.

A Tabela 12.1 resume a diferença entre os dois delineamentos.

Tabela 12.1: Comparação entre o T^2 para amostras independentes e para observações pareadas.

Característica	Amostras independentes	Observações pareadas
unidade básica	observações distintas	par de medições relacionadas
parâmetro	$\mu_1 - \mu_2$	$E(\mathbf{D})$
matriz usada na forma quadrática	covariância comum estimada por $\mathbf{S}_p$	covariância das diferenças estimada por $\mathbf{S}_D$
dependência entre as duas medições	não há correspondência entre unidades das duas amostras	incorporada em Σ_{XY} e Σ_{YX} e, portanto, em Σ_D
graus de liberdade da matriz de covariâncias	$n_1 + n_2 - 2$	$n - 1$
condição clássica de inversão	$n_1 + n_2 - 2 \geq p$	$n > p$
redução univariada	teste t com variâncias iguais	teste t pareado

Os dois procedimentos utilizam a mesma lógica inferencial, mas estimam estruturas de variabilidade distintas. Essa diferença será retomada na seção seguinte ao organizar as condições necessárias à inferência multivariada clássica.

12.7 Condições e limites da inferência clássica

Os resultados desenvolvidos neste capítulo dependem da estrutura probabilística da amostra, das hipóteses específicas de cada procedimento e do posto das matrizes envolvidas. Essas condições não são intercambiáveis: uma hipótese necessária para um procedimento pode ser irrelevante para outro.

Quatro aspectos organizam a validade da inferência clássica:

1. independência entre as unidades amostrais na estrutura especificada pelo delineamento;
2. normalidade multivariada quando se utilizam distribuições exatas normal–Wishart;
3. covariância comum nos procedimentos que a pressupõem;
4. posto suficiente das matrizes utilizadas nas formas quadráticas, inversas e determinantes.

12.7.1 Independência, normalidade e covariância comum

12.7.1.1 Independência

Nos resultados para uma amostra,

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são consideradas independentes.

Para duas amostras independentes, exige-se também independência entre as duas amostras. No delineamento pareado, admite-se dependência entre as duas medições de um mesmo par, mas os pares devem ser independentes entre si.

No modelo linear multivariado clássico,

$$\text{Cov} [\text{vec} (\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n$$

expressa a ausência de covariância residual entre unidades distintas.

A independência é determinada principalmente pelo processo de amostragem e pelo delineamento do estudo. Se existe dependência entre unidades e ela não é incorporada ao modelo, expressões como

$$\text{Cov} (\bar{\mathbf{X}}) = \frac{\Sigma}{n}$$

podem deixar de representar a variabilidade efetiva da média amostral.

Consequentemente, estatísticas construídas com essa estrutura podem apresentar níveis de significância e coberturas diferentes dos valores nominais.

Independência e delineamento

A independência não é estabelecida por um teste aplicado aos valores observados. Ela deve ser avaliada a partir da forma como as unidades foram selecionadas, agrupadas e mensuradas.

Dependência espacial, temporal, hierárquica ou decorrente de medidas repetidas exige uma estrutura probabilística compatível com o delineamento.

12.7.1.2 Normalidade multivariada

A normalidade multivariada sustenta os principais resultados exatos deste capítulo. Sob esse modelo foram estabelecidas:

- a distribuição normal da média em Proposição 12.1;
- a distribuição Wishart da SQPC amostral em Teorema 12.2;
- a independência entre média e covariância amostrais em Teorema 12.3;
- a distribuição F exata do T^2 em Proposição 12.15;
- as distribuições Wishart e as independências associadas ao modelo linear multivariado em Proposição 12.12.

Esses resultados devem ser distinguidos das propriedades que dependem apenas de momentos. Por exemplo, Proposição 10.6 e Proposição 10.11 não exigem normalidade.

Fora do modelo normal, a distribuição Wishart e as independências utilizadas para construir as distribuições exatas deixam, em geral, de estar disponíveis. No regime de dimensão fixa de Equação 12.1, resultados assintóticos podem ainda ser obtidos.

Se as observações são i.i.d., possuem matriz de covariâncias finita e positiva definida, e as condições de Teorema 12.1 e Proposição 10.12 são satisfeitas, então, sob

$$H_0 : \mu = \mu_0,$$

o Teorema Central do Limite multivariado e o teorema de Slutsky fornecem

$$\mathbb{T}^2 \xrightarrow{d} \chi_p^2. \quad (12.133)$$

Essa convergência não implica que

$$\frac{n-p}{p(n-1)} \mathbb{T}^2 \sim F_{p, n-p}$$

seja uma distribuição exata em amostras finitas fora do modelo normal.

Exato e assintótico

A normalidade não é necessária para definir médias, covariâncias, matrizes SQPC ou formas quadráticas.

Neste capítulo, ela é utilizada para obter determinadas distribuições amostrais **exatas**. Fora desse modelo, uma aproximação assintótica depende das condições do resultado limite utilizado e do regime em que n e p variam.

12.7.1.3 Covariância comum

A hipótese

$$\Sigma_1 = \Sigma_2$$

não pertence a todos os procedimentos multivariados.

Ela foi utilizada especificamente no teste de duas amostras independentes com covariância agrupada, pois permite obter

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma).$$

Quando

$$\Sigma_1 \neq \Sigma_2,$$

a covariância da diferença entre as médias é a apresentada em Equação 12.118,

$$\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2},$$

e a matriz agrupada não conduz à distribuição F exata da Proposição 12.20.

No procedimento pareado, essa hipótese não é necessária. A matriz relevante é

$$\Sigma_D = \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i).$$

No modelo linear multivariado clássico, a estrutura

$$\text{Cov}(\varepsilon_i | \mathbf{Z}) = \Sigma$$

supõe uma matriz residual comum às unidades representadas pelo modelo.

Assim, a homogeneidade deve ser entendida como uma hipótese do **procedimento que utiliza uma matriz de covariâncias comum**, e não como uma condição universal da inferência multivariada.

12.7.2 Posto, dimensão e tamanho amostral

As formas clássicas das estatísticas utilizam matrizes inversas. A condição necessária depende da dimensão efetivamente utilizada em cada problema.

12.7.2.1 Uma amostra

Sob normalidade não singular,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1)$$

com probabilidade 1.

Portanto,

$$\mathbf{S}^{-1}$$

existe com probabilidade 1 se, e somente se,

$$n > p.$$

Essa é também a condição que torna positivo o segundo grau de liberdade

$$n - p$$

da distribuição

$$F_{p, n-p}.$$

12.7.2.2 Hipóteses de dimensão reduzida

Para

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

com

$$\text{posto}(\mathbf{A}) = h,$$

a matriz relevante é

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

A condição clássica passa a ser

$$n > h.$$

Portanto, a singularidade da matriz completa $\mathbf{S}$ não impede necessariamente a inferência sobre combinações previamente especificadas de dimensão menor.

12.7.2.3 Duas amostras independentes

Sob normalidade e covariância comum,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1.

A inversão clássica requer

$$n_1 + n_2 - 2 \geq p.$$

Sob essa condição,

$$n_1 + n_2 - p - 1 > 0,$$

como necessário para a distribuição F da Proposição [12.20](#).

12.7.2.4 Modelo linear multivariado

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma),$$

e

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r)$$

com probabilidade 1.

Logo,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

Para combinações de respostas definidas por

$$\mathbf{C}_2 \in \mathbb{R}^{p \times s},$$

com posto coluna completo,

$$\mathbf{E}_{C_2} = \mathbf{C}_2^\top \mathbf{E}_{\text{res}} \mathbf{C}_2$$

é positiva definida com probabilidade 1 quando

$$n - r \geq s,$$

conforme Equação 12.54.

Portanto, a condição de posto depende da dimensão do objeto que efetivamente participa da inferência. Uma matriz de covariâncias completa pode ser singular e, ainda assim, determinadas combinações previamente especificadas admitirem inferência clássica em um espaço de menor dimensão.

Existência e estabilidade

A existência de uma inversa é uma condição algébrica; sua estabilidade depende também da separação entre os autovalores da matriz.

O efeito do condicionamento sobre a inversão de matrizes de covariâncias foi discutido em Equação 10.108. Assim, uma matriz pode possuir posto completo e ainda produzir formas quadráticas sensíveis a pequenas perturbações dos dados.

A Tabela Tabela 12.2 resume as condições centrais dos procedimentos desenvolvidos neste capítulo.

Tabela 12.2: Condições centrais para os resultados exatos da inferência multivariada clássica.

Procedimento	Estrutura probabilística para o resultado exato	Condição principal de posto
média com Σ conhecida	normalidade da média amostral	$\Sigma \succ \mathbf{0}$
T^2 de uma amostra	amostra normal multivariada	$n > p$
T^2 para $\mathbf{A}\mu = \mathbf{d}$	amostra normal multivariada	$n > h$
duas amostras independentes	normalidade, independência e covariância comum	$n_1 + n_2 - 2 \geq p$
observações pareadas	normalidade dos vetores de diferenças	$n > p$
modelo linear multivariado	normalidade matricial dos erros	$n - r \geq p$ para $\mathbf{E} \succ \mathbf{0}$
combinações de s respostas	normalidade matricial dos erros	$n - r \geq s$ para $\mathbf{E}_{C_2} \succ \mathbf{0}$

12.7.3 Aprofundamento: alta dimensão e robustez

A teoria desenvolvida neste capítulo é predominantemente uma teoria de **dimensão fixa**, na qual a informação amostral cresce enquanto a dimensão permanece constante. Quando a dimensão é grande em relação ao tamanho amostral, singularidade e instabilidade tornam-se parte central do problema.

12.7.3.1 Alta dimensão

Os limites de posto estabelecidos neste capítulo mostram que a inferência clássica baseada em inversas deixa de estar disponível quando a dimensão ultrapassa os graus de liberdade correspondentes. Para uma amostra, por exemplo, Equação 10.81 implica que

$$p \geq n$$

torna $\mathbf{S}$ necessariamente singular. Situações análogas ocorrem para a covariância agrupada quando

$$p > n_1 + n_2 - 2$$

e para a SQPC residual do modelo linear quando

$$p > n - r.$$

O Capítulo 10 distinguiu duas respostas algébricas a problemas dessa natureza: a pseudoinversa em Equação 10.117 e a regularização da matriz de covariâncias em Definição 10.18. Nenhuma dessas substituições preserva automaticamente as distribuições inferenciais derivadas neste capítulo para a inversa clássica.

Por exemplo, substituir $\mathbf{S}^{-1}$ por $\mathbf{S}^+$ modifica a estatística T^2 e não permite utilizar automaticamente

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}.$$

O mesmo ocorre quando $\mathbf{S}$ é substituída por um estimador regularizado.

Uma alternativa diferente consiste em formular previamente a hipótese em um espaço de menor dimensão. Isso ocorre em

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

e, no modelo linear, em

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Nesse caso, a condição de posto depende da dimensão das combinações efetivamente examinadas. Se essas combinações forem escolhidas a partir dos próprios dados, entretanto, o processo de seleção também integra o procedimento inferencial.

Testes específicos para alta dimensão, regularização inferencial, reamostragem e procedimentos baseados em projeções possuem distribuições e critérios próprios e não serão desenvolvidos neste capítulo.

12.7.3.2 Sensibilidade e robustez

O Capítulo 10 mostrou que a média e a matriz de covariâncias amostrais podem ser fortemente afetadas por observações suficientemente afastadas dos demais dados. Para a média, esse efeito foi explicitado em Equação 10.119; para a matriz de covariâncias, a sensibilidade decorre dos produtos externos utilizados em sua construção.

Essa propriedade afeta diretamente a inferência deste capítulo porque estatísticas como T^2 utilizam simultaneamente

$$\bar{\mathbf{X}}$$

e

$$\mathbf{S}^{-1}.$$

Uma observação influente pode, portanto, modificar tanto o vetor de afastamento quanto a matriz utilizada para ponderá-lo. Isso não significa que toda observação extrema seja um erro nem permite classificar universalmente um procedimento como robusto ou não robusto. O efeito depende da distribuição, da dimensão, do tamanho amostral e da configuração dos dados.

Sob independência entre as unidades, existência dos momentos requeridos e em dimensão fixa, resultados assintóticos podem continuar válidos fora da normalidade. Essa validade assintótica não transforma em exatas as distribuições finitas derivadas da estrutura normal–Wishart.

Substituir $\bar{\mathbf{X}}$ ou $\mathbf{S}$ por estimadores robustos define outro procedimento estatístico e exige uma distribuição nula ou um método de calibração apropriado.

Alcance desta seção

O objetivo é delimitar os procedimentos clássicos desenvolvidos neste capítulo. Diagnósticos detalhados, estimação robusta, regularização, testes de alta dimensão e métodos de reamostragem possuem desenvolvimentos próprios e não serão tratados neste módulo.

As condições desta seção delimitam quais resultados do capítulo são exatos, quais dependem de aproximações assintóticas e quando as formas clássicas deixam de estar definidas. Com essas fronteiras estabelecidas, o Módulo 2 reúne os objetos probabilísticos, amostrais, de estimação, modelagem e inferência que serão utilizados pelas técnicas multivariadas do Módulo 3.

12.8 Síntese do Módulo 2

O Módulo 2 desenvolveu a base probabilística e inferencial necessária para estudar conjuntamente várias variáveis. O percurso começou com a representação da variabilidade conjunta por meio das covariâncias, introduziu a distribuição normal multivariada como modelo probabilístico, passou à construção e avaliação de estimadores, ampliou a estrutura da média por meio do modelo linear multivariado e concluiu com distribuições amostrais e procedimentos de inferência.

O percurso do módulo começou com a matriz de covariâncias populacional definida em Definição 8.2 e com a representação da variabilidade conjunta construída no Capítulo 8. A

distribuição normal multivariada de Definição 9.1 acrescentou um modelo probabilístico para esses objetos.

No Capítulo 10, o vetor de médias amostral em Equação 10.8 e a matriz de covariâncias amostral definida em Definição 10.14 estabeleceram a passagem dos parâmetros populacionais para estatísticas e estimadores.

O Capítulo 11 generalizou a estrutura da média por meio do modelo linear multivariado de Definição 11.3,

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

e organizou hipóteses estimáveis na forma

$$H_0 : \mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0,$$

definida em Definição 11.17.

Neste capítulo, a distribuição de Wishart transformou as matrizes SQPC em objetos inferenciais. Em particular, Teorema 12.2 estabelece a distribuição da covariância amostral sob normalidade, enquanto Teorema 12.3 fornece a independência entre média e covariância amostrais.

No modelo linear multivariado, a mesma estrutura aparece nas matrizes de hipótese e erro. Sob H_0 , Proposição 12.12 fornece distribuições Wishart para $\mathbf{H}$ e para a SQPC residual correspondente, com independência entre elas. Esse resultado constitui a base probabilística que será reutilizada na MANOVA.

A inferência sobre vetores de médias foi organizada pela estatística T^2 de Hotelling. Quando Σ é conhecida, a forma quadrática possui distribuição qui-quadrado; quando a covariância é estimada por $\mathbf{S}$, Proposição 12.15 fornece uma transformação exata para a distribuição F . A mesma estrutura foi estendida a hipóteses $H_0 : \mathbf{A}\mu = \mathbf{d}$, à comparação de duas amostras independentes e às diferenças pareadas.

A razão de verossimilhanças forneceu uma formulação geral para comparar modelos sob restrições. No modelo linear normal, essa comparação levou à lambda de Wilks,

$$\Lambda_W = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|},$$

relacionando diretamente a redução da dispersão residual às matrizes $\mathbf{H}$ e $\mathbf{E}$.

Os resultados exatos deste módulo dependem das hipóteses probabilísticas e das condições de posto declaradas em cada procedimento. Fora dessas condições, resultados assintóticos, pseudoinversas ou regularização definem problemas inferenciais diferentes e não preservam automaticamente as distribuições clássicas.

A Tabela 12.3 reúne os objetos centrais dos cinco capítulos.

Tabela 12.3: Objetos centrais dos capítulos do Módulo 2.

Capítulo	Objeto central	Papel no Módulo 2
8. Matrizes de covariâncias e correlações	Σ e matrizes de dispersão	representa variabilidade, dependência e geometria
9. Distribuição Normal Multivariada	$N_p(\mu, \Sigma)$	estabelece o principal modelo probabilístico do módulo
10. Estatísticas Amostrais e Estimação	$\bar{\mathbf{X}}, \mathbf{T}$ e $\mathbf{S}$	relaciona parâmetros populacionais, estatísticas e estimadores
11. Modelo Linear Multivariado e Hipóteses Lineares	$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$ e $\mathbf{C}_1\mathbf{B}\mathbf{C}_2$	organiza médias, resíduos, SQPCs e hipóteses estimáveis
12. Inferência Multivariada	Wishart, T^2 , $(\mathbf{H}, \mathbf{E})$ e Λ_W	fornece distribuições amostrais, testes e regiões de confiança

Ao concluir o Módulo 2, o estudante deve ser capaz de:

- distinguir parâmetros populacionais, estatísticas amostrais, estimadores, estimativas e distribuições amostrais;
- interpretar a matriz de covariâncias e a distribuição normal multivariada como bases da modelagem probabilística conjunta;
- reconhecer a distribuição de Wishart e sua relação com matrizes SQPC e estimadores de covariância;
- formular e interpretar o modelo linear multivariado e hipóteses da forma $\mathbf{C}_1\mathbf{B}\mathbf{C}_2 = \Theta_0$;
- utilizar o T^2 de Hotelling para formular inferência sobre vetores de médias e combinações lineares;
- interpretar as matrizes $\mathbf{H}$ e $\mathbf{E}$ como variação associada à hipótese e ao resíduo;
- distinguir resultados exatos de aproximações assintóticas e identificar as condições de normalidade, independência, posto e delineamento que sustentam cada procedimento.

12.8.1 Passagem para o Módulo 3

Os dois primeiros módulos construíram a linguagem que será utilizada na formulação das técnicas multivariadas.

O Módulo 1 forneceu a base matemática formada por vetores, matrizes, subespaços, transformações, decomposições e ferramentas de cálculo.

O Módulo 2 acrescentou a estrutura probabilística e inferencial, abrangendo covariâncias, distribuições multivariadas, estimação, modelos lineares e procedimentos de inferência.

O Módulo 3 combinará essas duas estruturas para formular problemas multivariados específicos.

Matrizes de covariâncias serão decompostas ou modeladas. Projeções serão utilizadas para construir representações de menor dimensão. Distâncias e produtos internos serão utilizados para representar proximidades e formar grupos. Tabelas de contingência serão transformadas em estruturas geométricas. Matrizes de hipótese e erro serão retomadas na comparação multivariada de grupos. Modelos probabilísticos serão utilizados na discriminação e classificação. Dois blocos de variáveis serão relacionados por combinações lineares.

A passagem para o Módulo 3 corresponde, portanto, à mudança de uma teoria geral dos objetos multivariados para a formulação de técnicas destinadas a problemas estatísticos específicos.

Exercícios de fixação do Módulo II

Os exercícios deste módulo retomam os fundamentos probabilísticos e inferenciais desenvolvidos nos Capítulos 8 a 12 e os articulam com os resultados matemáticos estudados no Módulo I.

A lista está dividida em duas partes. Na primeira, os problemas devem ser resolvidos sem auxílio computacional e enfatizam conceitos, propriedades, operações com vetores e matrizes e procedimentos de inferência. Na segunda, o R será utilizado para aplicar essas estruturas a conjuntos de dados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Os resultados já estabelecidos nos Módulos I e II (definições, teoremas, proposições, propriedades, identidades e decomposições) podem e devem ser utilizados diretamente, sem necessidade de nova demonstração, salvo quando isso for solicitado explicitamente.

Ao utilizar um resultado, identifique o resultado empregado e verifique se suas condições são satisfeitas no problema considerado. Não basta reproduzir uma fórmula. Quando uma conclusão depender de normalidade, independência, existência de momentos, definição positiva, invertibilidade, posto, tamanho amostral, graus de liberdade ou outra hipótese específica, essa condição deve ser indicada.

Em particular, ao longo desta lista deve-se distinguir três situações:

1. resultados que permanecem válidos sem a hipótese de normalidade multivariada, desde que sejam satisfeitas as condições específicas necessárias, como existência de momentos e independência das unidades;
2. resultados exatos para amostras finitas cuja validade depende da normalidade multivariada;
3. resultados assintóticos que podem ser obtidos, sob condições próprias, quando o tamanho amostral cresce e a dimensão permanece fixa.

O fato de uma estatística poder ser calculada não significa que uma distribuição de referência utilizada para realizar inferência seja válida. Da mesma forma, o aumento do tamanho amostral pode justificar determinados resultados assintóticos, mas não transforma uma distribuição de amostra finita em um resultado exato fora das condições em que ela foi derivada.

A robustez de um procedimento diante de desvios da normalidade também não deve ser tratada como uma propriedade universal. Sua avaliação depende, entre outros aspectos, da intensidade e do tipo de desvio da distribuição, da presença de observações extremas, da dimensão e do tamanho amostral.

As questões foram elaboradas para exigir a escolha e a articulação dos resultados adequados. Por isso, algumas fórmulas não são fornecidas no enunciado e devem ser localizadas nos capítulos.

Parte I — Conceitos, fundamentos, operações matriciais e inferência sem uso de computador

Exercício 12.1 (Covariância, correlação e transformação de escala). Considere as matrizes

$$\Sigma_A = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$$

e

$$\Sigma_B = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

Um estudante afirma que ambas podem representar matrizes de covariâncias porque são simétricas e possuem elementos diagonais positivos.

1. Verifique, separadamente para Σ_A e Σ_B , se estão satisfeitas as condições necessárias para que uma matriz real seja uma matriz de covariâncias. Em particular, verifique utilizando um dos critérios estudados no Módulo I. Apresente os cálculos utilizados e conclua, para cada matriz, se ela pode ou não representar uma matriz de covariâncias.
2. Para a matriz identificada no item anterior como uma matriz de covariâncias válida, determine numericamente a matriz de correlações correspondente. Verifique, no resultado obtido, os valores da diagonal e do elemento fora da diagonal.
3. Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

cujas matrizes de covariâncias sejam a matriz válida identificada no item 1. Para a combinação linear

$$Y = X_1 - X_2,$$

escreva o vetor de coeficientes da combinação linear, determine numericamente $\text{Var}(Y)$ utilizando uma forma quadrática e explique como o termo de covariância entre X_1 e X_2 participa do valor obtido.

4. Para o mesmo vetor $\mathbf{X}$, considere a transformação

$$Z_1 = X_1 \quad \text{e} \quad Z_2 = 10X_2.$$

Utilize a propriedade de transformação da matriz de covariâncias, sem retornar às definições escalares de variância e covariância. Calcule numericamente:

- $\text{Var}(Z_2)$;
- $\text{Cov}(Z_1, Z_2)$;
- $\text{Corr}(Z_1, Z_2)$.

Compare cada resultado com a quantidade correspondente para X_1 e X_2 .

5. Classifique como verdadeira ou falsa a afirmação a seguir e justifique sua resposta utilizando os resultados obtidos nos itens anteriores e a diferença entre covariância e correlação:

Quanto maior a covariância entre duas variáveis, mais forte é necessariamente a associação linear entre elas.

6. Considere agora que nenhuma distribuição probabilística específica, em particular a normal multivariada, tenha sido assumida para $\mathbf{X}$. Indique quais resultados utilizados nos itens 1 a 5 continuam válidos desde que existam os momentos de primeira e segunda ordem necessários. Explique por que a definição e as propriedades algébricas da matriz de covariâncias não dependem da hipótese de normalidade multivariada.

Exercício 12.2 (Normalidade conjunta, independência e condicionamento). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \right).$$

1. Determine a distribuição marginal do vetor

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix}.$$

Apresente explicitamente o vetor de médias e a matriz de covariâncias dessa distribuição marginal. Em seguida, determine se X_1 e X_3 são independentes e indique o resultado da distribuição normal multivariada que permite estabelecer essa conclusão.

2. Considere agora os blocos

$$\mathbf{X}_A = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e X_3 . Extraia da matriz de covariâncias de $\mathbf{X}$ o bloco de covariâncias cruzadas entre $\mathbf{X}_A$ e X_3 . A partir desse bloco e das propriedades da distribuição normal multivariada, determine se $\mathbf{X}_A$ e X_3 são independentes. Justifique a conclusão.

3. Determine a distribuição condicional

$$\mathbf{X}_A \mid X_3 = 0.$$

Para isso, particione o vetor de médias e a matriz de covariâncias de acordo com os dois blocos considerados. Apresente numericamente o vetor de médias condicionais e a matriz de covariâncias condicionais e escreva a distribuição normal resultante.

4. Suponha agora que fossem conhecidos apenas o vetor de médias e a matriz de covariâncias apresentados no enunciado, sem assumir que $\mathbf{X}$ possui distribuição normal multivariada. Reavalie separadamente:

- a conclusão de independência entre X_1 e X_3 ;
- a conclusão sobre a independência entre $\mathbf{X}_A$ e X_3 ;
- a forma da distribuição condicional de $\mathbf{X}_A$ dado $X_3 = 0$.

Para cada caso, indique o que ainda pode ser concluído somente a partir das médias e covariâncias conhecidas e o que dependia especificamente da normalidade conjunta. Em particular, explique por que covariância nula não implica, em geral, independência e por que a distribuição condicional não é determinada, em uma população arbitrária, apenas pelos dois primeiros momentos.

Exercício 12.3 (Estatística, estimador e estimativa da matriz de covariâncias). Uma amostra aleatória de tamanho $n = 6$ de um vetor com $p = 3$ componentes produziu a matriz SQPC observada

$$\mathbf{T} = \begin{bmatrix} 10 & 2 & 0 \\ 2 & 5 & 1 \\ 0 & 1 & 4 \end{bmatrix}.$$

1. Explique a função de cada um dos objetos a seguir no problema de estimação da matriz de covariâncias:
- a estatística aleatória $\mathbf{T}$;
 - sua realização observada $\mathbf{T}$;

- o parâmetro populacional Σ ;
- um estimador de Σ ;
- a estimativa obtida após a observação da amostra.

Em sua resposta, deixe explícita a diferença entre um objeto aleatório, seu valor observado e o parâmetro populacional que se pretende estimar.

2. A partir de $\mathbf{T}$, calcule numericamente:

- a estimativa não viesada de Σ ;
- a estimativa de máxima verossimilhança de Σ sob o modelo normal multivariado, quando o máximo da verossimilhança existe.

Identifique o divisor utilizado em cada caso. Em seguida, explique por que os dois divisores são diferentes e qual propriedade de cada estimador está sendo considerada em sua construção.

3. Verifique se $\mathbf{T}$ é positiva definida utilizando um critério estudado no Módulo I e apresente a verificação realizada. A partir desse resultado, determine o posto de $\mathbf{T}$ e conclua se, para esta amostra, a estimativa de máxima verossimilhança calculada no item 2 pertence ao espaço das matrizes de covariâncias positivas definidas exigido pelo modelo normal não singular.
4. Os dois estimadores utilizados no item 2 são diferentes para uma amostra finita. Explique por que essa diferença não impede que ambos sejam consistentes para Σ quando p permanece fixo e $n \rightarrow \infty$. Em sua justificativa, relacione os dois estimadores por meio de seus divisores e indique o que ocorre com essa diferença relativa quando n aumenta.
5. Suponha agora que as observações sejam i.i.d. de uma população multivariada que **não** possui distribuição normal, mas possui vetor de médias e matriz de covariâncias finitos. Para cada afirmação a seguir, indique se ela permanece válida, deixa de ser válida em geral ou necessita de hipóteses adicionais:

- $E(\bar{\mathbf{X}}) = \mu$;
- $\text{Cov}(\bar{\mathbf{X}}) = \Sigma/n$;
- $E(\mathbf{S}) = \Sigma$;
- $\mathbf{S} \xrightarrow{P} \Sigma$ quando $n \rightarrow \infty$ e p permanece fixo;
- $(n-1)\mathbf{S}$ possui exatamente distribuição de Wishart;
- $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes.

Explique também por que a matriz $\mathbf{T}/n$ continua podendo ser calculada para uma amostra não normal, mas não deve ser chamada automaticamente de estimativa de máxima verossimilhança de Σ sem que seja especificado um modelo probabilístico cuja verossimilhança conduza a esse estimador.

Exercício 12.4 (Estrutura e hipótese em um modelo linear multivariado). Considere um modelo linear multivariado com $n = 4$ unidades e duas variáveis-resposta:

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

A matriz de delineamento possui duas colunas: a primeira corresponde ao intercepto e a segunda a uma covariável. Suponha que

$$\text{posto}(\mathbf{Z}) = 2,$$

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{Z}^\top \mathbf{Y} = \begin{bmatrix} 8 & 12 \\ 2 & -2 \end{bmatrix}.$$

Após o ajuste, a SQPC residual observada é

$$\mathbf{E} = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix}.$$

1. Utilize o resultado de mínimos quadrados para o caso em que $\mathbf{Z}$ possui posto completo e calcule numericamente $\widehat{\mathbf{B}}_{\text{obs}}$. Apresente a matriz estimada completa e suas dimensões.
2. Utilizando a organização das linhas e colunas de $\widehat{\mathbf{B}}_{\text{obs}}$, identifique explicitamente:
 - quais elementos correspondem aos interceptos das duas variáveis-resposta;
 - quais elementos correspondem aos coeficientes da covariável nas duas variáveis-resposta;
 - qual coluna reúne os coeficientes do modelo para a primeira resposta;
 - qual coluna reúne os coeficientes do modelo para a segunda resposta.

A interpretação solicitada neste item refere-se à posição e à função dos coeficientes no modelo, pois não foi atribuído um significado específico à covariável.

3. Determine numericamente:
 - o posto r da matriz de delineamento;
 - os graus de liberdade residuais $n - r$;
 - a estimativa não viesada da matriz de covariâncias dos erros.

Apresente a matriz de covariâncias residual estimada.

4. Formule a hipótese de que a covariável não possui efeito linear sobre nenhuma das duas variáveis-resposta na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0.$$

Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe as dimensões dessas matrizes e mostre que a hipótese resultante equivale a impor simultaneamente que os dois coeficientes associados à covariável sejam iguais a zero. Justifique também por que essa função de $\mathbf{B}$ é estimável no modelo considerado.

5. O estimador de mínimos quadrados de cada coluna de $\mathbf{B}$ coincide com o estimador obtido ao ajustar separadamente um modelo linear para cada variável-resposta utilizando a mesma matriz $\mathbf{Z}$. Explique por que essa equivalência na estimação dos coeficientes não torna desnecessária a matriz de covariâncias residual. Em sua resposta, indique qual informação sobre a relação entre as respostas é registrada pelos elementos fora da diagonal dessa matriz.

Exercício 12.5 (Resultados exatos, ausência de normalidade e resultados assintóticos). Considere as afirmações a seguir.

I. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0},$$

então o vetor de médias amostrais possui exatamente uma distribuição normal multivariada, a SQPC amostral possui distribuição de Wishart e o vetor de médias amostrais é independente da matriz de covariâncias amostral.

II. Para qualquer população com vetor de médias e matriz de covariâncias finitos,

$$(n-1)\mathbf{S}$$

possui exatamente uma distribuição de Wishart.

III. Se

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

são i.i.d., possuem vetor de médias μ e matriz de covariâncias finita Σ e a dimensão p permanece fixa, então

$$\sqrt{n}(\bar{\mathbf{X}} - \mu)$$

converge em distribuição para uma distribuição normal multivariada quando $n \rightarrow \infty$, mesmo que a população de origem não possua distribuição normal multivariada.

IV. Se o modelo é identificável, o parâmetro verdadeiro pertence ao interior do espaço paramétrico, log-verossimilhança duas vezes continuamente diferenciável em uma vizinhança do parâmetro verdadeiro, possibilidade de trocar diferenciação e integração ou esperança, a matriz de informação de Fisher é positiva definida, as restrições impostas por H_0 são regulares e a dimensão paramétrica permanece fixa quando $n \rightarrow \infty$, então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_{\nu}^2,$$

em que ν corresponde ao número de restrições independentes impostas por H_0 . Portanto, a distribuição qui-quadrado obtida pelo Teorema de Wilks é assintótica e, em geral, não corresponde à distribuição exata da estatística em amostras finitas.

V. Se a população não possui distribuição normal multivariada, então, mesmo sob amostragem i.i.d. e existência de segundos momentos finitos, o vetor de médias amostrais deixa de ser não viesado para μ e a matriz de covariâncias amostral deixa de ser não viesada e consistente para Σ .

VI. Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0} \quad \text{e} \quad n > p.$$

Para testar

$$H_0 : \mu = \mu_0,$$

considere a estatística

$$\mathsf{T}^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0).$$

Sob H_0 , a normalidade multivariada das observações, a independência entre as unidades amostrais, a definição positiva de Σ e a condição $n > p$ permitem obter o resultado exato

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}.$$

Se a população não possui distribuição normal multivariada, mas as observações são i.i.d., possuem vetor de médias μ , matriz de covariâncias finita e positiva definida Σ , a matriz de covariâncias amostral satisfaz

$$\mathbf{S} \xrightarrow{P} \Sigma,$$

e p permanece fixo quando

$$n \rightarrow \infty,$$

então, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2.$$

Portanto, fora da normalidade multivariada, a distribuição qui-quadrado é um resultado assintótico. Esse resultado não implica que a transformação de $\mathbf{T}^2$ para a distribuição F permaneça exata em amostras finitas.

Para cada afirmação:

1. Classifique a afirmação como **correta** ou **incorreta** e apresente uma justificativa baseada em um resultado estudado nos capítulos.
2. Para cada afirmação classificada como incorreta, escreva uma versão corrigida, modificando apenas as hipóteses ou a conclusão necessárias para que ela se torne válida.
3. Para cada resultado utilizado, liste explicitamente as hipóteses necessárias à sua validade e indique quais delas já aparecem na respectiva afirmação. Considere, quando pertinente, amostragem i.i.d., independência das unidades, normalidade multivariada, existência de momentos, definição positiva de Σ , dimensão p fixa e condições de regularidade do modelo.

Ao final, explique por que as duas afirmações a seguir são inadequadas:

Se os dados não são normais, os métodos clássicos deixam de funcionar.

e

Se a amostra é grande, os pressupostos deixam de ser importantes.

Em sua resposta, distinga a perda de uma **distribuição exata em amostra finita** da possibilidade de utilizar um **resultado assintótico**, e explique por que independência, existência de momentos e o regime dimensional continuam sendo relevantes quando n cresce.

Exercício 12.6 (T^2 de Hotelling, normalidade e o papel do delineamento). Um estudo mede duas variáveis nos mesmos 10 indivíduos antes e depois de uma intervenção. Para cada indivíduo, define-se o vetor de diferenças

$$\mathbf{D}_i = \mathbf{X}_{i,\text{depois}} - \mathbf{X}_{i,\text{antes}}, \quad i = 1, \dots, 10.$$

Os vetores de diferenças produziram

$$\bar{\mathbf{d}} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\mathbf{S}_D = \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix}.$$

Deseja-se avaliar se houve alteração média conjunta nas duas variáveis após a intervenção.

Admita inicialmente que as condições necessárias para a distribuição exata de T^2 sejam satisfeitas e utilize

$$F_{2,8;0,95} = 4,46.$$

1. Defina o vetor populacional de médias das diferenças μ_D e formule as hipóteses nula e alternativa para avaliar a ausência de alteração média conjunta. Em seguida, explique por que, após a construção dos vetores $\mathbf{D}_i$, o problema pode ser tratado como um problema de uma amostra aplicado aos vetores de diferenças.
2. Identifique explicitamente as condições necessárias para utilizar a distribuição exata de T^2 neste problema. Sua resposta deve considerar:
 - a distribuição conjunta dos vetores $\mathbf{D}_i$;
 - a independência entre indivíduos;
 - a definição positiva da matriz de covariâncias populacional das diferenças;
 - a relação entre o tamanho amostral n e a dimensão p .

Verifique numericamente a condição que envolve n e p .

3. Calcule a estatística T^2 para o teste da hipótese formulada no item 1. Em seguida, utilize a transformação estudada no capítulo para obter a estatística com distribuição F , informe seus graus de liberdade, compare o valor calculado com o valor crítico fornecido e apresente:
 - a decisão estatística ao nível de significância de 5%;
 - a conclusão no contexto da alteração média conjunta das duas variáveis.
4. Escreva a matriz de covariâncias do vetor de diferenças $\mathbf{D}_i$ em função das matrizes de covariâncias das medidas “antes” e “depois” e das covariâncias cruzadas entre essas duas medidas. Utilize essa expressão para explicar precisamente qual informação sobre a dependência dentro de cada indivíduo seria ignorada se as observações “antes” e “depois” fossem tratadas como duas amostras independentes.
5. Suponha, em outro estudo, que as duas condições sejam aplicadas a dois grupos constituídos por indivíduos distintos. Sob independência entre os grupos, normalidade multivariada e uma matriz de covariâncias populacional comum, indique:
 - qual estimador da matriz de covariâncias comum deve ser utilizado;
 - qual versão da estatística T^2 deve ser utilizada para comparar os vetores de médias dos dois grupos;
 - qual característica do delineamento distingue esse problema do problema pareado apresentado no início da questão.
6. Retorne ao estudo pareado original e suponha agora que a normalidade multivariada dos vetores de diferenças $\mathbf{D}_i$ não seja uma hipótese razoável.
 - a. Explique quais quantidades calculadas nos itens anteriores continuam podendo ser obtidas normalmente a partir da amostra, como $\bar{\mathbf{d}}$, $\mathbf{S}_D$ e o valor numérico de T^2 .
 - b. Explique por que, com $n = 10$, a transformação de T^2 para a distribuição F deixa de possuir, em geral, a justificativa de uma distribuição exata.
 - c. Suponha que, em vez de 10 indivíduos, uma sequência de estudos forneça amostras i.i.d. cada vez maiores de vetores de diferenças, com $p = 2$ fixo, segundos momentos finitos e matriz $\Sigma_D \succ \mathbf{0}$. Indique qual distribuição assintótica de T^2 pode ser utilizada sob H_0 quando $n \rightarrow \infty$.
 - d. Explique por que o resultado do item anterior não permite afirmar que a calibração finita pela distribuição F se tornou exata fora da normalidade.

Parte II — Exercícios com uso do R

Nesta parte, os cálculos solicitados devem ser construídos preferencialmente por meio de operações matriciais no R. Quando existir uma função pronta que reproduza diretamente um resultado estudado nos Módulos I ou II, utilize-a somente depois de realizar a construção matricial correspondente e apenas como forma de conferência.

Os códigos devem ser reprodutíveis e os resultados numéricos devem ser acompanhados das interpretações solicitadas. Nos procedimentos inferenciais, identifique as condições que sustentam a distribuição utilizada. A obtenção de uma estatística de teste ou de um valor- p pelo software não constitui, por si só, evidência de que as hipóteses probabilísticas do procedimento sejam satisfeitas.

Exercício 12.7 (Modelo linear multivariado com os dados `swiss`). Utilize o conjunto de dados `swiss`.

Considere como variáveis-resposta:

- `Fertility`;
- `Infant.Mortality`.

Construa

$$\mathbf{Y} = [\text{Fertility} \quad \text{Infant.Mortality}]$$

e uma matriz de delineamento $\mathbf{Z}$ cujas colunas, nesta ordem, correspondam a:

1. `intercepto`;
2. `Agriculture`;
3. `Education`.
4. Determine n , p , q e o posto r de $\mathbf{Z}$. Calcule os graus de liberdade residuais $n - r$. Em seguida, obtenha $\widehat{\mathbf{B}}_{\text{obs}}$ diretamente por operações matriciais e apresente a matriz com as linhas identificadas por `Intercepto`, `Agriculture` e `Education` e as colunas por `Fertility` e `Infant.Mortality`.

Somente depois desse cálculo, ajuste separadamente com `lm()` os dois modelos univariados correspondentes e verifique se seus coeficientes coincidem, salvo diferenças de arredondamento, com as respectivas colunas de $\widehat{\mathbf{B}}_{\text{obs}}$.

5. Calcule a matriz de valores ajustados e a matriz de resíduos $\widehat{\mathbf{U}}$. Verifique numericamente a condição

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}$$

calculando $\mathbf{Z}^\top \widehat{\mathbf{U}}$ e examinando se seus elementos são numericamente próximos de zero.

Explique por que essa propriedade decorre do ajuste por mínimos quadrados e não constitui uma verificação de normalidade dos erros.

6. Construa a SQPC residual

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}$$

e calcule o estimador não viesado da matriz de covariâncias residual. Interprete:

- os elementos da diagonal como variâncias residuais das duas respostas;
- o elemento fora da diagonal como covariância residual entre **Fertility** e **Infant.Mortality** após considerados os efeitos lineares de **Agriculture** e **Education**.

Como a direção constante pertence ao espaço coluna de $\mathbf{Z}$, construa também $\mathbf{T}$ e $\mathbf{T}_{\text{mod}}$ e verifique numericamente

$$\mathbf{T} = \mathbf{T}_{\text{mod}} + \mathbf{E}.$$

7. Formule, na forma

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0,$$

a hipótese de que o coeficiente de **Education** é igual a zero simultaneamente nas duas variáveis-resposta. Especifique numericamente $\mathbf{C}_1$, $\mathbf{C}_2$ e Θ_0 , informe suas dimensões e verifique a condição de estimabilidade.

Não realize um teste multivariado dessa hipótese. O objetivo é construir corretamente a restrição matricial correspondente aos coeficientes de **Education**.

8. Considere os resultados obtidos nos itens anteriores e classifique-os em três grupos:
- a. resultados que decorrem da álgebra de mínimos quadrados e podem ser calculados sem assumir normalidade multivariada dos erros;

b. propriedades de esperança e covariância dos estimadores que exigem condições sobre a média, a independência entre unidades e a estrutura de covariâncias dos erros, mas não necessariamente normalidade;

c. resultados inferenciais exatos, como distribuições normais matriciais, distribuições de Wishart e independência entre estimadores e SQPC residual, cuja derivação depende da normalidade multivariada dos erros.

Para cada grupo, identifique pelo menos um resultado utilizado nesta questão e indique as condições necessárias.

Exercício 12.8 (Comparação multivariada entre regiões dos Estados Unidos). Utilize o conjunto `USArrests` e associe cada estado à sua região por meio dos objetos `state.name` e `state.region`.

Uma possibilidade para construir o vetor de regiões é

```
regiao <- state.region[
  match(
    rownames(USArrests),
    state.name
  )
]
```

Considere apenas os estados classificados nas regiões **South** e **Northeast**. Em cada região, utilize conjuntamente as quatro variáveis quantitativas de `USArrests`.

1. Determine:

- os tamanhos amostrais n_1 e n_2 ;
- a dimensão p ;
- os vetores de médias amostrais;
- as matrizes de covariâncias amostrais.

Calcule também

$$\nu = n_1 + n_2 - 2$$

e verifique se a relação entre ν e p satisfaz a condição dimensional necessária à construção da estatística clássica T^2 para duas amostras.

2. Construa matricialmente a matriz de covariâncias agrupada $\mathbf{S}_p$ e verifique se ela é invertível. Em seguida, calcule a estatística T^2 de Hotelling para testar

$$H_0 : \mu_{\text{South}} = \mu_{\text{Northeast}}.$$

Transforme T^2 para a estatística com distribuição F correspondente e informe:

- o valor de T^2 ;
- o valor da estatística F ;
- os graus de liberdade;
- o valor- p ;
- a decisão ao nível de significância de 5%;
- a conclusão sobre a igualdade dos vetores de médias populacionais.

A conclusão deve se referir ao vetor de quatro médias analisado conjuntamente, e não a cada variável separadamente.

3. A distribuição F utilizada no item anterior é exata sob condições específicas. Identifique explicitamente:

- a independência entre as duas amostras;
- a independência das unidades dentro de cada amostra;
- a normalidade multivariada em cada população;
- a igualdade das matrizes de covariâncias populacionais;
- a definição positiva da matriz de covariâncias comum;
- a condição dimensional necessária à inversão da matriz utilizada em T^2 .

Indique quais dessas condições são características do delineamento e quais são hipóteses sobre as distribuições populacionais.

4. Examine graficamente as quatro variáveis em cada região utilizando gráficos adequados para identificar assimetria acentuada e observações extremas. Utilize também gráficos quantil-quantil normais para cada variável.

A partir desses gráficos, descreva os principais desvios observados em relação à normalidade marginal. Não conclua que a distribuição é normal multivariada apenas porque uma ou mais variáveis apresentam comportamento aproximadamente normal em análises marginais.

Explique por que essas análises podem fornecer informações sobre a plausibilidade da normalidade, mas não demonstram que a hipótese de normalidade multivariada seja satisfeita.

5. Suponha que a normalidade multivariada não seja considerada razoável para esses dados.
- a.** Indique quais das seguintes quantidades continuam perfeitamente definidas como estatísticas calculadas a partir da amostra:
- os vetores de médias amostrais;
 - as matrizes de covariâncias amostrais;
 - a matriz de covariâncias agrupada;
 - o valor numérico de T^2 .
- b.** Explique por que a ausência de normalidade não impede o cálculo dessas quantidades, mas elimina, em geral, a justificativa para afirmar que a transformação de T^2 possui exatamente a distribuição F utilizada no item 2.
- c.** Considere uma sequência de estudos em que $p = 4$ permanece fixo, $n_1 \rightarrow \infty$, $n_2 \rightarrow \infty$, $n_1/(n_1 + n_2) \rightarrow \lambda \in (0, 1)$, as unidades são independentes, as duas populações possuem segundos momentos finitos e compartilham uma matriz de covariâncias positiva definida Σ . Explique por que resultados assintóticos podem ser utilizados para a inferência sobre a diferença entre os vetores de médias mesmo sem normalidade multivariada.
- d.** Explique por que o crescimento dos tamanhos amostrais não transforma a distribuição F de amostra finita, derivada sob normalidade multivariada e matriz de covariâncias comum, em uma distribuição exata fora dessas condições.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13 Problemas e estruturas das técnicas multivariadas

Os Módulos 1 e 2 estabeleceram a base matemática, geométrica, probabilística e inferencial utilizada na Análise Multivariada. Vetores e matrizes fornecem a representação dos dados; distâncias, produtos internos e projeções descrevem sua geometria; autovetores e vetores singulares fornecem direções determinadas pelas decomposições correspondentes, enquanto autovalores e valores singulares quantificam suas magnitudes; matrizes de covariâncias e correlações descrevem a variabilidade conjunta e a associação linear; e os modelos probabilísticos e inferenciais permitem formular conclusões sobre populações multivariadas.

Neste módulo, os fundamentos anteriores são utilizados para formular técnicas multivariadas específicas. Cada técnica parte de um problema estatístico e utiliza os objetos matemáticos, probabilísticos ou inferenciais necessários à sua solução. Redução de dimensionalidade, representação de estruturas latentes, formação de grupos, análise de associações em tabelas de contingência, análise conjunta de várias respostas e discriminação de grupos exigem formulações distintas (Johnson; Wichern, 2002).

Uma mesma estrutura matemática pode aparecer em técnicas diferentes. A decomposição espectral pode identificar direções de maior variabilidade, fornecer uma solução inicial para cargas fatoriais no método de fatores principais ou participar da determinação de direções de separação entre grupos. O significado estatístico depende do objeto analisado e do critério utilizado.

A Tabela 13.1 reúne os elementos que estruturam a formulação das técnicas deste módulo.

Tabela 13.1: Elementos utilizados na formulação das técnicas multivariadas.

Elemento	Função na formulação
Problema estatístico	Define o objetivo da análise
Estrutura dos dados	Define como observações, variáveis, categorias ou grupos são representados
Objeto matemático	Organiza a informação utilizada pelo critério ou modelo
Critério ou modelo	Determina a propriedade otimizada, decomposta ou modelada

Elemento	Função na formulação
Solução	Produz direções, coordenadas, grupos, parâmetros ou funções
Interpretação	Atribui significado estatístico e geométrico à solução

O objetivo deste capítulo é organizar os problemas multivariados tratados neste módulo, identificar as estruturas compartilhadas pelas técnicas desenvolvidas nos capítulos seguintes e explicitar como os fundamentos dos Módulos 1 e 2 passam a compor sua formulação.

13.1 Do problema estatístico à técnica multivariada

A presença de várias variáveis em um conjunto de dados caracteriza o contexto multivariado, mas não determina a técnica. A escolha depende do problema estatístico, do objeto analisado e do critério ou modelo adotado.

Considere a matriz de dados $\mathbf{X}$ definida na Definição 1.6. Quando suas colunas correspondem a variáveis quantitativas, cada observação pode ser representada geometricamente pelas respectivas coordenadas em $\mathbb{R}^p$, conforme discutido na Seção 1.2. Variáveis categóricas não devem ser incorporadas automaticamente a essa geometria apenas pela atribuição de códigos numéricos; técnicas que utilizam categorias ou dados mistos exigem representações compatíveis com a natureza das variáveis.

A mesma matriz de dados quantitativos pode ser utilizada para construir combinações lineares que concentrem variabilidade, identificar grupos de observações semelhantes ou, quando os grupos são conhecidos, determinar direções que os separem. O conjunto de dados permanece o mesmo, enquanto o objeto de interesse e o critério de solução se modificam.

A Tabela 13.2 reúne as principais correspondências que serão desenvolvidas neste módulo.

Tabela 13.2: Correspondência entre problemas, estruturas e técnicas multivariadas.

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Representar a variabilidade em menor dimensão	Σ , $\mathbf{S}$, $\mathcal{R}$, $\mathbf{R}$ ou matriz de dados centralizada	Maximização da variância e aproximação de posto reduzido	Análise de Componentes Principais
Representar as covariâncias por fatores comuns	Matriz de covariâncias ou correlações	Modelo de fatores comuns	Análise Fatorial

Problema estatístico	Estrutura ou objeto central	Critério ou modelo	Técnica
Formar grupos de objetos semelhantes	Matriz de dados ou de dissimilaridades	Critérios de proximidade, dispersão ou ligação; modelos probabilísticos de mistura	Análise de Agrupamentos
Representar associações entre categorias	Tabela de contingência, massas e perfis	Geometria qui-quadrado, SVD e decomposição da inércia	Análise de Correspondência
Testar conjuntamente hipóteses sobre várias respostas	Modelo linear multivariado e matrizes de hipótese e erro	Raízes características e critérios multivariados de teste	MANOVA
Separar grupos conhecidos e classificar observações	Médias, covariâncias, probabilidades de classe e dispersões de grupos	Regra de Bayes, LDA/QDA ou critério de Fisher	Análise Discriminante

Parte dos objetos utilizados nessa tabela foi definida nos módulos anteriores. A matriz de dados da Definição 1.6 representa observações e variáveis. A matriz de covariâncias populacional Σ , definida na Definição 8.2, e sua correspondente observada $\mathbf{S}$, definida na Definição 8.11, descrevem a variabilidade conjunta. A matriz de correlações observada $\mathbf{R}$, definida na Definição 8.12, descreve a estrutura linear depois da padronização marginal das variáveis.

A escolha entre covariâncias e correlações não altera o objetivo estatístico da técnica, mas modifica a representação da variabilidade utilizada na formulação e pode, consequentemente, modificar a solução. A matriz de covariâncias preserva as escalas originais, enquanto a matriz de correlações atribui variância unitária às variáveis. Essa diferença será retomada no Capítulo 14 ao formular a Análise de Componentes Principais (ACP) a partir de $\mathbf{S}$ ou $\mathbf{R}$. A influência da escala também será retomada no Capítulo 16, pois a padronização das variáveis pode modificar as distâncias entre os objetos e, consequentemente, a estrutura dos grupos obtidos.

Outras técnicas utilizam estruturas diferentes. O Capítulo 16 pode partir de dados multivariados ou de dissimilaridades entre objetos e admite diferentes definições matemáticas de grupo. O Capítulo 17 parte de frequências organizadas em uma tabela de contingência e constrói massas, perfis e uma geometria ponderada. O Capítulo 18 utiliza diretamente a estrutura do modelo linear multivariado definido na Definição 11.3. O Capítulo 19 utiliza informações sobre grupos

previamente conhecidos e articula formulações probabilísticas de classificação com a formulação geométrica de Fisher.

A estrutura de entrada delimita a informação disponível para a técnica. Uma matriz de covariâncias resume relações de segunda ordem entre variáveis. Uma matriz de dissimilaridades representa relações entre pares de objetos. Uma tabela de contingência registra frequências conjuntas entre categorias. A formulação deve preservar essa diferença.

13.2 Classes de problemas multivariados

As técnicas deste módulo podem ser organizadas de acordo com o problema estatístico que resolvem. Essa classificação estabelece a função de cada método antes de sua formulação matemática.

13.2.1 Redução de dimensionalidade

A redução de dimensionalidade substitui uma representação de dimensão elevada por outra de menor dimensão, preservando uma característica definida da informação original.

No Capítulo 14, o critério é a variabilidade. As novas dimensões são combinações lineares escolhidas para concentrar sucessivamente a variância. A formulação utiliza as projeções de Definição 3.19, a decomposição espectral sintetizada na Tabela 5.2 e a decomposição em valores singulares sintetizada na Tabela 6.7.

Representações de menor dimensão também aparecem em outras técnicas, mas associadas a problemas estatísticos distintos. No Capítulo 17, as dimensões representam associações entre perfis de linhas e colunas de uma tabela de contingência. A propriedade que se procura representar faz parte da definição do problema.

13.2.2 Representação de estruturas latentes

O Capítulo 15 procura representar as associações entre variáveis observadas por meio de um número menor de fatores não observados.

Nesse caso, a matriz de covariâncias passa a ser objeto de um modelo. A formulação separa a parcela de variabilidade associada aos fatores comuns da parcela específica de cada variável.

Essa estrutura distingue o Capítulo 15 do Capítulo 14. A ACP procura uma representação da variabilidade observada, enquanto a Análise Fatorial especifica um modelo para explicar a covariação entre as variáveis.

13.2.3 Formação de grupos

A Análise de Agrupamentos organiza objetos em grupos sem utilizar classes conhecidas previamente. A solução depende da representação dos objetos, da medida de proximidade e do critério que define a organização procurada.

A distância euclidiana definida na Definição 1.13 fornece uma medida de proximidade já estabelecida no Módulo 1. No Capítulo 16, uma dissimilaridade é formalizada na Definição 16.1. As K -médiãs produzem uma partição, objeto definido na Definição 16.2, enquanto os métodos hierárquicos produzem uma sequência de partições aninhadas, formalizada na Definição 16.4. Uma terceira formulação define grupos probabilisticamente por meio do modelo da Definição 16.6.

Essas estruturas não são equivalentes. Sem um modelo probabilístico explícito, os grupos obtidos representam a solução do critério adotado e não correspondem automaticamente a populações distintas.

13.2.4 Representação de associações em tabelas de contingência

A Análise de Correspondência parte de uma tabela de frequências e representa os desvios em relação à independência entre suas categorias.

No Capítulo 17, as frequências marginais originam as massas definidas na Definição 17.1 e os perfis definidos na Definição 17.2. A comparação entre perfis utiliza a distância qui-quadrado da Definição 17.3, e os desvios padronizados da independência são organizados pela matriz definida na Definição 17.5.

A Seção 17.7 mostra como a SVD dessa matriz decompõe a inércia e produz as dimensões da representação. As coordenadas padrão e principais são formalizadas, respectivamente, na Definição 17.7 e na Definição 17.8.

13.2.5 Teste conjunto de hipóteses sobre várias respostas

Na MANOVA, a comparação de vetores de médias constitui um caso particular de um problema mais geral: testar hipóteses sobre funções estimáveis dos parâmetros de um modelo linear multivariado com várias respostas.

A MANOVA utiliza o modelo definido na Definição 11.3 e a hipótese linear geral da Definição 11.17 para representar conjuntamente as respostas e o efeito avaliado. No Capítulo 18, as matrizes de hipótese e erro conduzem ao problema de autovalores generalizados apresentado na Equação 18.14. As raízes características são definidas na Definição 18.1 e utilizadas na construção dos quatro critérios reunidos na Seção 18.5.

A análise conjunta das respostas distingue a MANOVA de uma coleção de análises univariadas separadas.

13.2.6 Discriminação e classificação

A Análise Discriminante utiliza grupos conhecidos durante a construção da solução. Seu objetivo pode ser representar direções de separação entre esses grupos ou construir regras de classificação para novas observações.

Na formulação probabilística, distribuições condicionais e probabilidades *a priori* conduzem à regra de Bayes apresentada na Equação 19.3. A distribuição normal multivariada da Definição 9.1 e a distância de Mahalanobis da Definição 8.9 entram diretamente nas regras normal-linear e normal-quadrática desenvolvidas na Seção 19.3 e na Seção 19.4.

A formulação geométrica da Seção 19.6 compara a dispersão entre grupos à dispersão intra-grupos. O critério amostral é definido na Definição 19.8 e conduz ao problema de autovalores generalizados da Equação 19.30.

A Análise Discriminante e a MANOVA compartilham estruturas de dispersão e problemas espectrais relacionados, mas possuem objetivos diferentes (Huberty; Olejnik, 2006). Essa relação é explicitada na Equação 19.40.

13.3 Diferentes formas de classificar as técnicas

A classificação pelo problema estatístico será a principal organização adotada neste módulo. Outras classificações permitem comparar diferentes características das técnicas.

13.3.1 Interdependência e dependência

Nas técnicas de interdependência, as variáveis ou os objetos são analisados sem uma divisão prévia entre respostas e variáveis explicativas. ACP, Análise Fatorial, Análise de Agrupamentos e Análise de Correspondência são exemplos.

Nas técnicas de dependência, o problema estabelece previamente qual variável ou conjunto de variáveis ocupa a posição de resposta e qual informação explica, compara ou prediz essa resposta. Na MANOVA, o vetor de respostas e os efeitos avaliados são definidos pelo delineamento. Na Análise Discriminante, a classe conhecida ocupa a posição de resposta categórica e as características observadas são utilizadas para discriminar ou classificar.

13.3.2 Exploratórias, descritivas, preditivas e inferenciais

Uma técnica exploratória identifica padrões ou estruturas nos dados. Uma técnica descritiva resume uma configuração observada. Uma técnica preditiva produz uma regra aplicável a novas observações. Uma técnica inferencial utiliza a variabilidade amostral para formular conclusões sobre parâmetros ou populações.

Essas finalidades podem coexistir. A ACP é predominantemente exploratória e descritiva em muitas aplicações, embora exista teoria inferencial para componentes populacionais. A Análise Discriminante descreve a separação entre grupos e também pode produzir regras de classificação. A MANOVA possui finalidade principalmente inferencial.

13.3.3 Supervisionadas e não supervisionadas

A distinção entre métodos supervisionados e não supervisionados constitui uma classificação complementar e não uma taxonomia igualmente natural para todas as técnicas multivariadas.

Métodos supervisionados utilizam uma informação externa que orienta a construção da solução. Os rótulos dos grupos desempenham esse papel diretamente na Análise Discriminante. Na MANOVA, há uma estrutura previamente especificada pelo delineamento, que determina os efeitos avaliados, embora a terminologia supervisionada seja menos usual para essa técnica.

Métodos não supervisionados constroem a estrutura diretamente a partir dos dados, sem utilizar classes ou respostas previamente especificadas. ACP e Análise de Agrupamentos são exemplos.

Para Análise Fatorial e Análise de Correspondência, a classificação pelo problema estatístico e pela estrutura representada é mais informativa que a oposição entre supervisão e não supervisão.

A Tabela 13.3 resume essas classificações.

Tabela 13.3: Classificações complementares das técnicas estudadas no Módulo 3.

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
ACP	Redução de dimensionalidade	Interdependência	Exploratória e descritiva	Não supervisionada
Análise Fatorial	Estrutura latente	Interdependência	Exploratória; inferencial sob formulações probabilísticas específicas	Sem resposta externa na formulação exploratória
Análise de Agrupamentos	Formação de grupos	Interdependência	Exploratória e descritiva	Não supervisionada
Análise de Correspondência	Associação em tabelas de contingência	Interdependência	Exploratória e descritiva	Sem resposta externa na formulação

Técnica	Problema predominante	Relação entre variáveis	Finalidade frequente	Estrutura de supervisão
MANOVA	Hipóteses sobre várias respostas	Dependência	Inferencial	Respostas e efeitos definidos pelo delineamento
Análise Discriminante	Discriminação e classificação	Dependência	Descritiva e preditiva	Grupos conhecidos

A classificação pelo problema estatístico é a mais diretamente relacionada à formulação das técnicas. Por isso, problema, objeto matemático e critério ou modelo constituem os eixos de organização adotados neste módulo.

13.4 Estruturas matemáticas recorrentes

As técnicas deste módulo reutilizam estruturas desenvolvidas nos Módulos 1 e 2. Combinações lineares, formas quadráticas, problemas espectrais, decomposições matriciais, métricas e modelos probabilísticos assumem funções diferentes conforme o problema estatístico.

13.4.1 Combinações lineares e projeções

As combinações lineares definidas na Definição 1.8 constroem novas variáveis e novas direções a partir das variáveis originais. Para um vetor aleatório $\mathbf{X}$, sua forma é

$$Y = \mathbf{a}^\top \mathbf{X}.$$

O significado de $\mathbf{a}$ depende do critério da técnica. No Capítulo 14, seus coeficientes definem direções de variabilidade. No Capítulo 18, combinações lineares das respostas são utilizadas para comparar hipótese e erro. Na Seção 19.6, os coeficientes definem direções de separação entre grupos.

A projeção ortogonal definida na Definição 3.19 associa cada observação ao seu representante em um subespaço. No Capítulo 14, essa operação produz a representação no subespaço principal; na Seção 19.9, produz a representação no subespaço discriminante.

13.4.2 Formas quadráticas e problemas espectrais

As formas quadráticas definidas na Definição 2.23 aparecem na variância de combinações lineares, em distâncias ponderadas e em diferentes medidas de dispersão. Quando o critério depende da direção escolhida, surgem problemas de otimização espectral.

O quociente de Rayleigh definido na Definição 5.7 relaciona a otimização de uma forma quadrática aos autovalores de uma matriz simétrica. O resultado do Teorema 5.5 é aplicado no Capítulo 14 à matriz de covariâncias ou de correlações para formular as componentes principais.

Quando duas formas quadráticas são comparadas, o quociente de Rayleigh generalizado da Definição 5.12 conduz ao problema de autovalores generalizados descrito no Teorema 5.8. Na Equação 18.14 e na Equação 19.30, essa estrutura compara duas fontes de dispersão segundo o problema estatístico de cada técnica.

Quando a matriz do denominador é positiva definida, a transformação de branqueamento da Equação 8.50 converte a métrica correspondente em uma geometria euclidiana. Essa transformação é aplicada ao problema simétrico da MANOVA na Equação 18.18 e à formulação de Fisher na Equação 19.31.

A decomposição espectral, sintetizada na Tabela 5.2, fornece as direções e magnitudes associadas a uma matriz simétrica. A interpretação dessas direções depende da matriz que foi construída e do problema estatístico que a originou.

13.4.3 Otimização sob restrições e critérios de ajuste

Diversas técnicas multivariadas definem suas soluções por meio da maximização ou minimização de um critério. Em termos gerais, a solução pode ser caracterizada por um problema da forma

$$\max_{\theta} f(\theta)$$

ou

$$\min_{\theta} Q(\theta),$$

eventualmente sujeito a restrições que delimitam o conjunto de soluções admissíveis.

Quando a função objetivo envolve uma forma quadrática e a restrição fixa a norma do vetor, os multiplicadores de Lagrange estabelecem a relação entre o problema de otimização e a equação de autovalores. A condição geral foi apresentada no Teorema 7.6 e a otimização sob restrição de norma foi ilustrada no Exemplo 7.11.

Essa estrutura aparece de formas distintas nas técnicas deste módulo. Na ACP, procura-se uma direção que maximize a variância sob uma restrição de normalização. Na Análise Discriminante de Fisher, maximiza-se a separação entre grupos relativamente à dispersão intragrupos. Nas K -médias, procura-se uma partição que minimize a dispersão intragrupos. Na Análise Fatorial, determinados métodos de estimação definem a solução pela minimização de resíduos entre estruturas de covariâncias ou pela maximização de uma função de verossimilhança.

Autovetores, centroides e estimativas de parâmetros são definidos pelo critério que otimizam e pelas restrições impostas ao problema. Na ACP, o critério é a variância; nas K -médias, a dispersão intragrupos; em métodos fatoriais específicos, os resíduos ou a verossimilhança.

13.4.4 SVD e representações de baixa dimensão

A decomposição em valores singulares relaciona os espaços de linhas e colunas de uma matriz e permite construir aproximações de posto reduzido. Suas propriedades foram sintetizadas na Tabela 6.7.

No Módulo 3, a SVD aparece em contextos distintos. No Capítulo 14, é aplicada à matriz de dados centralizada. No Capítulo 17, é aplicada à matriz de desvios padronizados definida na Definição 17.5, e a decomposição correspondente é desenvolvida na Seção 17.7.

O mecanismo algébrico é compartilhado, mas a matriz decomposta e o significado estatístico dos vetores e valores singulares são diferentes.

13.4.5 Distâncias e métricas

Distâncias quantificam proximidade entre observações. Quando uma técnica admite dissimilaridades que não satisfazem todas as propriedades de uma distância, essa distinção deve permanecer explícita. A distância euclidiana da Definição 1.13 é central nas K -médias e constitui uma das medidas disponíveis nos métodos hierárquicos. No Capítulo 16, a Definição 16.1 formaliza a classe mais geral de dissimilaridades.

No Capítulo 17, a Definição 17.3 estabelece a geometria dos perfis, ponderando suas diferenças pelas massas da margem oposta. A distância de Mahalanobis da Definição 8.9 pondera os deslocamentos pela estrutura de covariâncias. Na Equação 8.49, direções de maior variabilidade recebem menor peso no afastamento padronizado. Essa distância entra diretamente nas regras normais desenvolvidas na Seção 19.3 e na Seção 19.4.

13.4.6 Modelos lineares e probabilísticos

O modelo linear multivariado da Definição 11.3 representa conjuntamente várias respostas, o delineamento e a matriz de parâmetros. A hipótese linear geral da Definição 11.17 seleciona as combinações dos parâmetros que serão testadas. No Capítulo 18, essas hipóteses originam as matrizes de hipótese e erro, cujas raízes características são utilizadas nos critérios da Seção 18.5.

Outras técnicas acrescentam estruturas probabilísticas específicas à sua formulação. No Capítulo 15, o modelo definido na Definição 15.1 especifica uma estrutura para a matriz de covariâncias, e a estimação por máxima verossimilhança acrescenta uma formulação probabilística baseada na normalidade multivariada. No Capítulo 19, distribuições condicionais aos grupos e probabilidades *a priori* são utilizadas na construção de regras probabilísticas de classificação. Na Seção 16.8, a Definição 16.6 apresenta uma definição probabilística alternativa de grupo.

Quando a normalidade multivariada é utilizada, sua definição e suas propriedades são as estabelecidas na Definição 9.1. Essa hipótese deve ser distinguida das estruturas algébricas e geométricas utilizadas na formulação das técnicas: ela não constitui uma condição geral para construções baseadas em combinações lineares, formas quadráticas, projeções, SVD ou problemas espectrais.

Nas formulações por máxima verossimilhança, a função da Definição 10.11 e a razão da Definição 12.3 são utilizadas sem nova definição. A interpretação inferencial preserva a distinção entre resultados exatos e assintóticos estabelecida na Definição 12.1.

A Tabela 13.4 reúne essas conexões.

Tabela 13.4: Estruturas dos Módulos 1 e 2 reutilizadas na formulação das técnicas.

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Centralização e padronização	Definição da origem e da escala da representação dos dados	ACP, Agrupamentos
Combinações lineares	Construção de novas direções ou variáveis	ACP, MANOVA, Discriminante
Projeções	Representação em subespaços e direções	ACP, Discriminante
Formas quadráticas	Medida de variabilidade, distância, associação ou separação	ACP, Correspondência, MANOVA, Discriminante
Otimização sob restrições e critérios de ajuste	Definição de soluções por maximização ou minimização de um critério	ACP, Fatorial, Agrupamentos, MANOVA, Discriminante

Estrutura desenvolvida anteriormente	Utilização no Módulo 3	Técnicas diretamente relacionadas
Autovalores e autovetores	Decomposição espectral e determinação de direções; em métodos específicos, obtenção de soluções de extração	ACP; Fatorial em métodos específicos de extração
Autovalores e autovetores generalizados	Comparação entre formas quadráticas e determinação de direções extremas	MANOVA, Discriminante
SVD	Decomposição e representação de baixa dimensão	ACP, Correspondência
Produtos internos e métricas induzidas	Construção de geometrias ponderadas ou adaptadas à estrutura de dispersão	Correspondência, MANOVA, Discriminante
Distâncias e métricas	Representação de proximidade, associação ou classificação	Agrupamentos, Correspondência, Discriminante
Covariâncias e correlações	Representação da variabilidade conjunta e da associação linear	ACP, Fatorial, MANOVA, Discriminante
Dispersão dentro e entre grupos	Comparação da estrutura de grupos	Agrupamentos, MANOVA, Discriminante
Modelo linear multivariado	Representação conjunta de respostas e efeitos	MANOVA
Normal multivariada	Formulações probabilísticas e resultados inferenciais sob hipóteses específicas	Fatorial, Discriminante, MANOVA
Função e razão de verossimilhanças	Estimação e comparação sob formulações probabilísticas específicas	Fatorial por máxima verossimilhança; MANOVA na fundamentação da lambda de Wilks

13.5 Mesmas estruturas, diferentes interpretações

Uma operação matemática adquire significado estatístico a partir do objeto ao qual é aplicada.

No Capítulo 14, a decomposição espectral da matriz de covariâncias ou correlações determina as direções principais e suas variâncias. No Capítulo 15, o método de fatores principais aplica a decomposição espectral a uma matriz reduzida, cuja diagonal contém comunalidades estimadas,

para obter uma solução inicial de cargas. No Capítulo 18, os autovalores generalizados comparam hipótese e erro; na Seção 19.6, comparam dispersão entre grupos e dispersão intragrupos.

A SVD apresenta a mesma característica. Aplicada à matriz de dados centralizada, participa da formulação da ACP. Aplicada aos desvios padronizados em relação à independência de uma tabela de contingência, produz os eixos da Análise de Correspondência.

A Tabela 13.5 resume essas diferenças.

Tabela 13.5: Exemplos de estruturas matemáticas com diferentes significados estatísticos.

Operação matemática	Objeto analisado	Significado da solução
Decomposição espectral	Matriz de covariâncias ou correlações	Direções e variâncias principais
Decomposição espectral	Matriz reduzida da Análise Fatorial	Solução inicial para as cargas fatoriais
Autovalores generalizados	Dispersão entre e dentro dos grupos	Direções de separação
Autovalores generalizados	Matrizes de hipótese e erro	Direções características e magnitudes relativas de hipótese e erro
SVD	Matriz de dados centralizada	Direções, escores e representação de baixa dimensão
SVD	Desvios padronizados em relação à independência	Eixos de associação entre categorias

A interpretação de um autovalor, autovetor, valor singular, vetor singular ou coordenada exige identificar a matriz de origem e o critério que definiu sua construção. Uma mesma operação pode resolver problemas estatísticos diferentes quando é aplicada a objetos distintos ou associada a critérios diferentes.

As fontes de não unicidade também devem ser distinguidas. Na ACP, a indeterminação de sinal e os efeitos da multiplicidade são desenvolvidos na Seção 14.13.5.4. Na Análise Fatorial, a Proposição 15.2 formaliza uma indeterminação adicional, associada à rotação dos fatores. Na Análise de Agrupamentos, a não unicidade pode decorrer da existência de diferentes soluções ótimas, como discutido na Seção 16.12.2, ou de empates durante a construção de uma hierarquia, tratados na Seção 16.12.6. Na MANOVA, sinais e multiplicidades das direções são discutidos na Seção 18.9.4. A mesma estrutura espectral aparece nas direções de Fisher, cuja identificação é discutida na Seção 19.14.7. Essas situações possuem origens matemáticas distintas e não devem ser interpretadas como uma única forma de indeterminação.

As propriedades de invariância dependem da técnica e da transformação considerada. A ACP baseada em covariâncias é invariante a translações, mas pode mudar sob reescalamentos

individuais, conforme a Seção 14.13.5. Na Análise Fatorial, rotações ortogonais preservam a parte comum da matriz de covariâncias e modificam as cargas, conforme a Seção 15.14.2. Nas K -médias, translações, transformações ortogonais e mudanças comuns de escala preservam a solução nas condições estabelecidas na Seção 16.12.4. Na MANOVA, transformações lineares não singulares das respostas preservam as raízes características e os critérios quando a hipótese é transformada de modo correspondente, conforme a Seção 18.9.3.

13.6 Relações entre as técnicas

Algumas técnicas apresentam estruturas matemáticas próximas, mas resolvem problemas diferentes. A Tabela 13.6 reúne relações que serão retomadas nos capítulos correspondentes.

Tabela 13.6: Relações conceituais entre técnicas do Módulo 3.

Técnicas relacionadas	Estrutura compartilhada	Diferença principal
ACP e Análise Fatorial	Matrizes de covariâncias ou correlações e representações de menor dimensão	ACP representa a variabilidade total; Fatorial modela as covariâncias por fatores comuns e variâncias específicas
Agrupamentos e Discriminante	Grupos, médias, dispersões e medidas de proximidade ou separação	A Análise de Agrupamentos constrói grupos; a Análise Discriminante utiliza grupos conhecidos para representar separação ou classificar
MANOVA e Discriminante	Em problemas com grupos, dispersões entre e dentro e problemas de autovalores generalizados	MANOVA testa efeitos sobre o vetor de respostas; Discriminante representa separação entre grupos e pode classificar observações
ACP e Correspondência	Centralização e decomposições de baixa dimensão	ACP representa a variabilidade de dados quantitativos em geometria euclidiana ou padronizada; Correspondência representa associações entre perfis em geometria qui-quadrado

A Tabela 15.4 sintetiza a relação entre ACP e Análise Fatorial. A Tabela 16.6 organiza as relações da Análise de Agrupamentos com outras técnicas. A Equação 19.40 estabelece a

conexão espectral entre MANOVA e a formulação de Fisher. A [?@tbl-relacao-acp-ca](#) sintetiza a relação entre ACP e Análise de Correspondência.

A técnica é identificada pelo problema estatístico, pelo objeto analisado e pelo critério de solução; a operação matricial, isoladamente, não determina o método.

13.7 Síntese

As técnicas multivariadas deste módulo utilizam os fundamentos construídos nos Módulos 1 e 2 para resolver problemas estatísticos distintos. A formulação de cada técnica combina uma estrutura de dados, um objeto matemático e um critério ou modelo. O compartilhamento de uma decomposição, uma forma quadrática, uma métrica ou um problema espectral não torna duas técnicas estatisticamente equivalentes; o significado da solução depende do problema e do objeto ao qual a estrutura matemática é aplicada.

A centralização e a padronização definem a origem e a escala da representação utilizada por determinadas técnicas. Combinações lineares e projeções produzem novas direções e representações. Formas quadráticas e problemas espectrais permitem estudar variabilidade e comparar diferentes fontes de dispersão. Na MANOVA e na formulação de Fisher, o branqueamento converte a métrica determinada pela matriz de referência em uma geometria euclidiana e conduz a problemas espectrais simétricos equivalentes.

Autovalores e autovetores definem diretamente a solução da ACP e aparecem na Análise Fatorial em métodos específicos de extração; o modelo fatorial, porém, é definido pela decomposição da covariância em uma parte comum e uma parte específica. A SVD fornece representações de baixa dimensão na ACP e, na [Seção 17.7](#), decompõe a inércia da Análise de Correspondência. Na [Seção 16.8](#), diferentes critérios geométricos e probabilísticos mostram que grupo não corresponde a um único objeto matemático. A [Seção 18.5](#) constrói quatro critérios a partir das mesmas raízes características, enquanto o [Capítulo 19](#) articula decisão probabilística, LDA/QDA e a geometria de Fisher.

Propriedades de invariância e fontes de não unicidade também dependem da técnica. Mudanças de sinal, multiplicidade de raízes, rotações fatoriais e diferentes soluções de agrupamento possuem origens distintas e devem ser interpretadas em relação ao objeto estatístico que permanece identificado.

As hipóteses probabilísticas devem ser distinguidas das estruturas algébricas e geométricas. A normalidade e a máxima verossimilhança entram apenas nas formulações que as requerem, e os resultados inferenciais dependem das hipóteses probabilísticas correspondentes.

O [Capítulo 14](#) inicia a aplicação desses fundamentos ao formular a Análise de Componentes Principais a partir da variância de combinações lineares, do quociente de Rayleigh, da decomposição espectral, das projeções e da SVD.

14 Formulação da Análise de Componentes Principais

A Análise de Componentes Principais (ACP) representa a variabilidade de um conjunto de variáveis por meio de combinações lineares ordenadas segundo a variância que concentram (Johnson; Wichern, 2002; Jolliffe, 2002). Seu objetivo é construir uma representação de menor dimensão que preserve, segundo esse critério, a maior parcela possível da variabilidade original.

A formulação utiliza o quociente de Rayleigh da Definição 5.7, o Teorema 5.4, a projeção ortogonal da Definição 3.19 e a SVD compacta da Definição 6.4. A construção é desenvolvida nas formulações populacional, amostral e por SVD e distingue a ACP baseada na matriz de covariâncias daquela baseada na matriz de correlações.

14.1 O problema de redução de dimensionalidade

Considere o vetor aleatório

$$\mathbf{X} = (X_1, \dots, X_p)^\top \in \mathbb{R}^p,$$

com vetor de médias μ e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Cada realização $\mathbf{x} \in \mathbb{R}^p$ representa uma unidade por meio de p coordenadas. Quando várias dessas coordenadas apresentam associação linear, a variabilidade conjunta pode estar concentrada em um número menor de direções.

A Figura 14.1 ilustra essa interpretação geométrica. Uma nuvem de pontos em $\mathbb{R}^2$ pode apresentar grande extensão em uma direção e pequena extensão na direção ortogonal. Duas coordenadas são necessárias para representar exatamente cada ponto, mas uma única direção pode concentrar a maior parte da dispersão da nuvem. Em dimensão p , o mesmo princípio conduz à procura de um subespaço de dimensão $k < p$ que preserve a maior variabilidade possível segundo o critério da ACP.

A ACP não seleciona diretamente k variáveis dentre as p variáveis originais. Ela constrói novas variáveis como combinações lineares das componentes de $\mathbf{X}$. Cada combinação é determinada por um vetor de coeficientes em $\mathbb{R}^p$, que define uma direção no espaço das observações.

O vetor aleatório centralizado,

$$\mathbf{X}_c = \mathbf{X} - \mu,$$

tem média nula e preserva a matriz de covariâncias de $\mathbf{X}$. A centralização separa a localização da distribuição de sua estrutura de dispersão. Por isso, a formulação populacional da ACP pode ser construída diretamente a partir de $\mathbf{X}_c$ e de Σ .

Uma direção unitária

$$\alpha \in \mathbb{R}^p, \quad \alpha^\top \alpha = 1,$$

produz a combinação linear

$$Y = \alpha^\top \mathbf{X}_c.$$

Como α possui norma unitária, Y representa a coordenada de $\mathbf{X}_c$ na direção definida por α . Pelo resultado sobre momentos de combinações lineares apresentado na Proposição 8.1,

$$E(Y) = 0$$

e

$$\text{Var}(Y) = \alpha^\top \Sigma \alpha.$$

A variância da combinação linear depende, portanto, da direção α . Algumas direções podem apresentar grande dispersão, enquanto outras apresentam pequena dispersão.

A ACP ordena as direções pela variância das combinações lineares associadas. A primeira direção principal é a direção unitária que maximiza essa variância. Cada direção seguinte maximiza a variância entre as direções unitárias ortogonais às já selecionadas.

A Figura 14.1 representa uma nuvem bidimensional com variabilidade distinta segundo diferentes direções. A primeira direção principal acompanha a maior extensão da nuvem, enquanto a segunda é ortogonal à primeira e representa a variabilidade remanescente.

A maior dispersão ocorre na direção da primeira componente. A segunda componente representa a maior variabilidade possível entre as direções ortogonais à primeira. As duas direções mostram geometricamente a ordenação das componentes segundo a variância.

A redução de dimensionalidade ocorre quando apenas as primeiras $k < p$ direções são mantidas. A parcela de variabilidade preservada depende da concentração da variância total nessas




Figura 14.1: As direções principais acompanham os eixos de maior e menor variabilidade da nuvem de observações.

direções. Quando as primeiras componentes concentram grande parte da variância total, poucas componentes retêm uma parcela elevada da variabilidade. Quando a variância se distribui de modo mais uniforme entre as componentes, reduzir a dimensão descarta uma parcela maior da variabilidade total.

14.2 Componentes principais como combinações lineares

A j -ésima componente principal populacional tem a forma

$$Y_j = \alpha_j^\top \mathbf{X}_c = \alpha_j^\top (\mathbf{X} - \mu),$$

em que

$$\alpha_j \in \mathbb{R}^p$$

é o vetor de coeficientes da componente.

A formulação distingue os seguintes objetos:

- α_j define uma direção no espaço das variáveis;
- Y_j é uma variável aleatória obtida pela projeção de $\mathbf{X}_c$ nessa direção;
- a variância de Y_j quantifica a dispersão populacional representada pela direção;
- na formulação amostral, a versão estimada de α_j determina os escores das observações definidos na Definição 14.1.

Para duas combinações lineares,

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

e

$$Y_\ell = \alpha_\ell^\top \mathbf{X}_c,$$

tem-se

$$\text{Cov}(Y_j, Y_\ell) = \alpha_j^\top \Sigma \alpha_\ell.$$

Assim, a matriz Σ determina simultaneamente a variância de cada combinação linear e a covariância entre diferentes combinações lineares.

A restrição de norma unitária é necessária porque a variância depende da escala do vetor de coeficientes. Para qualquer constante c ,

$$\text{Var}(c\alpha^\top \mathbf{X}_c) = c^2 \alpha^\top \Sigma \alpha.$$

Sem controlar a norma de α , a variância poderia ser aumentada apenas multiplicando os coeficientes por uma constante. A condição

$$\alpha^\top \alpha = 1$$

remove esse efeito de escala e transforma o problema em uma escolha de direção.

14.3 Primeira componente principal

A primeira componente principal é a combinação linear cujo vetor de coeficientes unitário maximiza a variância.

O problema é

$$\max_{\alpha_1 \in \mathbb{R}^p} \alpha_1^\top \Sigma \alpha_1,$$

sujeito a

$$\alpha_1^\top \alpha_1 = 1.$$

O Teorema 5.5 caracteriza os extremos do quociente definido na Definição 5.7. Aplicando esse resultado à matriz simétrica e semidefinida positiva Σ , o máximo é igual ao maior autovalor da matriz de covariâncias.

A variação do quociente de Rayleigh segundo a direção foi ilustrada na Figura 5.4. Na ACP, a matriz utilizada naquele problema passa a ser Σ , e o máximo do quociente corresponde à maior variância possível de uma combinação linear com coeficientes de norma unitária.

Se os autovalores de Σ forem ordenados como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

e α_1 for um autovetor unitário associado a λ_1 , então

$$\Sigma \alpha_1 = \lambda_1 \alpha_1.$$

A primeira componente principal é

$$Y_1 = \alpha_1^\top \mathbf{X}_c,$$

e sua variância é

$$\begin{aligned}\text{Var}(Y_1) &= \alpha_1^\top \Sigma \alpha_1 \\ &= \alpha_1^\top \lambda_1 \alpha_1 \\ &= \lambda_1 \alpha_1^\top \alpha_1.\end{aligned}$$

Portanto, como $\alpha_1^\top \alpha_1 = 1$, temos

$$\text{Var}(Y_1) = \lambda_1.$$

O maior autovalor possui uma interpretação estatística direta: ele é a maior variância que pode ser obtida por uma combinação linear das variáveis com vetor de coeficientes de norma unitária.

O autovetor correspondente define a direção em que essa variância é alcançada. A projeção de $\mathbf{X}_c$ nessa direção define a primeira componente principal.

A Seção 13.4.3 relaciona critérios de otimização e soluções espectrais. O Teorema 5.6 estabelece a relação entre a otimização de uma forma quadrática sob restrição de norma e os autovetores, a partir da condição geral do Teorema 7.6.

14.4 Componentes principais sucessivas

A primeira componente utiliza a direção unitária que maximiza a variância. As componentes seguintes são construídas sucessivamente, impondo ortogonalidade entre seus vetores de coeficientes.

A segunda componente principal é a combinação linear cujo vetor de coeficientes unitário é ortogonal a α_1 e maximiza a variância sob essa restrição:

$$\max_{\alpha_2 \in \mathbb{R}^p} \alpha_2^\top \Sigma \alpha_2,$$

sujeito a

$$\alpha_2^\top \alpha_2 = 1$$

e

$$\alpha_2^\top \alpha_1 = 0.$$

O mesmo princípio é aplicado sucessivamente. Para $j = 1, \dots, p$, a j -ésima direção principal resolve

$$\max_{\alpha_j \in \mathbb{R}^p} \alpha_j^\top \Sigma \alpha_j,$$

sujeito a

$$\alpha_j^\top \alpha_j = 1$$

e

$$\alpha_j^\top \alpha_\ell = 0, \quad \ell = 1, \dots, j-1.$$

A caracterização variacional de direções sucessivas já foi estabelecida no Teorema 5.7. Aplicando esse resultado a Σ , obtém-se

$$\Sigma \alpha_j = \lambda_j \alpha_j, \quad j = 1, \dots, p.$$

Assim, pode-se escolher uma base ortonormal de autovetores da matriz de covariâncias, ordenada de acordo com os autovalores decrescentes, para definir as direções principais. Quando um autovalor possui multiplicidade maior que um, os autovetores individuais dentro do autoespaço correspondente não são únicos; essa não unicidade é desenvolvida na Seção 14.13.5.4.

A j -ésima componente principal é

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

e possui variância

$$\text{Var}(Y_j) = \lambda_j.$$

Para $j \neq \ell$,

$$\begin{aligned}
\text{Cov}(Y_j, Y_\ell) &= \alpha_j^\top \Sigma \alpha_\ell \\
&= \lambda_\ell \alpha_j^\top \alpha_\ell \\
&= 0.
\end{aligned}$$

Logo, as componentes principais são não correlacionadas:

$$\text{Cov}(Y_j, Y_\ell) = 0, \quad j \neq \ell.$$

Duas propriedades diferentes aparecem nessa construção. Os vetores de coeficientes são ortogonais,

$$\alpha_j^\top \alpha_\ell = 0,$$

enquanto as componentes principais são não correlacionadas,

$$\text{Cov}(Y_j, Y_\ell) = 0.$$

A primeira propriedade pertence à geometria dos vetores de coeficientes. A segunda pertence à estrutura probabilística das variáveis construídas. Na ACP, a equação de autovetores

$$\Sigma \alpha_\ell = \lambda_\ell \alpha_\ell$$

faz a ligação entre essas duas propriedades.

A ausência de correlação não implica independência em uma distribuição geral. Se $\mathbf{X}$ possui distribuição normal multivariada, qualquer transformação linear também é normal, conforme a Proposição 9.4. Nesse caso, o vetor das componentes principais é normal multivariado e possui matriz de covariâncias diagonal. Pela Proposição 9.6, as componentes principais são independentes.

A normalidade, portanto, acrescenta uma propriedade probabilística às componentes, mas não participa da definição da ACP.

14.5 Formulação espectral

Reunindo os vetores de coeficientes em

$$\mathbf{A} = \begin{pmatrix} \alpha_1 & \alpha_2 & \cdots & \alpha_p \end{pmatrix},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

A matriz $\mathbf{A}$ é ortogonal. Pelo Teorema 5.4,

$$\Sigma = \mathbf{A} \Lambda \mathbf{A}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p).$$

As componentes podem ser reunidas no vetor aleatório

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_p \end{pmatrix} = \mathbf{A}^\top \mathbf{X}_c.$$

Como

$$E(\mathbf{X}_c) = \mathbf{0},$$

tem-se

$$E(\mathbf{Y}) = \mathbf{0}.$$

Pela regra de transformação da matriz de covariâncias estabelecida na Equação 8.18,

$$\text{Cov}(\mathbf{A}^\top \mathbf{X}_c) = \mathbf{A}^\top \Sigma \mathbf{A}.$$

Substituindo a decomposição espectral,

$$\begin{aligned}\text{Cov}(\mathbf{Y}) &= \mathbf{A}^\top \mathbf{A} \mathbf{\Lambda} \mathbf{A}^\top \mathbf{A} \\ &= \mathbf{\Lambda}.\end{aligned}$$

Portanto,

$$\text{Cov}(\mathbf{Y}) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}.$$

A transformação para componentes principais diagonaliza a estrutura de covariâncias. As variáveis originais podem apresentar covariâncias diferentes de zero; no novo sistema de coordenadas, as componentes são não correlacionadas e suas variâncias aparecem na diagonal de $\mathbf{\Lambda}$.

A transformação completa

$$\mathbf{X}_c \mapsto \mathbf{Y} = \mathbf{A}^\top \mathbf{X}_c$$

não reduz a dimensão. Ela representa o mesmo vetor em uma base ortonormal diferente. Pela propriedade de preservação geométrica das transformações ortogonais estabelecida na Proposição 4.10, produtos internos, normas e distâncias são preservados quando todas as p componentes são mantidas.

A redução ocorre somente quando a transformação é seguida pela retenção das primeiras $k < p$ coordenadas.

14.6 Variância total e proporção de variância

A variância total foi definida na Definição 8.6 por

$$V_T = \text{tr}(\Sigma).$$

Pela relação entre traço e autovalores estabelecida na Proposição 5.4,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Além disso,

$$\text{Cov}(\mathbf{Y}) = \Lambda,$$

de modo que

$$\text{tr} [\text{Cov}(\mathbf{Y})] = \sum_{j=1}^p \lambda_j.$$

Assim,

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

A transformação completa para componentes principais preserva a variância total das variáveis originais. Como as componentes são ordenadas por autovalores decrescentes, as maiores parcelas dessa variância correspondem às primeiras componentes.

Se

$$\text{tr}(\Sigma) > 0,$$

a proporção da variância total associada à componente j é

$$\pi_j = \frac{\lambda_j}{\sum_{\ell=1}^p \lambda_\ell}.$$

Para as primeiras k componentes, a proporção acumulada é

$$\Pi_k = \frac{\sum_{j=1}^k \lambda_j}{\sum_{\ell=1}^p \lambda_\ell}.$$

A variabilidade representada pelas primeiras k direções é

$$\sum_{j=1}^k \lambda_j,$$

enquanto a variabilidade associada às direções descartadas é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição pode ser resumida pela Tabela 14.1.

Tabela 14.1: Relação entre componentes principais, direções, autovalores e variância representada, quando a variância total é positiva.

Componente	Direção	Variância	Proporção da variância total
Y_1	α_1	λ_1	$\lambda_1 / \sum_{\ell=1}^p \lambda_\ell$
Y_2	α_2	λ_2	$\lambda_2 / \sum_{\ell=1}^p \lambda_\ell$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Y_p	α_p	λ_p	$\lambda_p / \sum_{\ell=1}^p \lambda_\ell$

Exemplo 14.1 (Componentes principais de duas variáveis). Considere um vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}.$$

A decomposição espectral fornece os autovalores

$$\lambda_1 = 6 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\alpha_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

e

$$\alpha_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

A primeira componente principal é

$$Y_1 = \frac{(X_1 - \mu_1) + (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_1) = 6.$$

A segunda componente é

$$Y_2 = \frac{(X_1 - \mu_1) - (X_2 - \mu_2)}{\sqrt{2}},$$

com

$$\text{Var}(Y_2) = 2$$

e

$$\text{Cov}(Y_1, Y_2) = 0.$$

A variância total é

$$\text{tr}(\Sigma) = 4 + 4 = 8,$$

que coincide com

$$\lambda_1 + \lambda_2 = 6 + 2 = 8.$$

A primeira componente representa $\frac{6}{8} = 75\%$ da variabilidade total, enquanto a segunda representa $\frac{2}{8} = 25\%$.

Se a representação for reduzida de duas para uma dimensão, a direção α_1 preserva 75% da variabilidade e descarta 25%. Nesse exemplo, a redução de dimensão possui interpretação direta: a maior parte da dispersão ocorre na direção em que as duas variáveis se deslocam conjuntamente.

A Figura 14.2 mostra, em um exemplo didático, duas leituras complementares dos autovalores. O primeiro painel apresenta a variância associada individualmente a cada componente. O segundo apresenta a proporção acumulada da variância representada pelas primeiras componentes.

A concentração da variância nos primeiros autovalores determina quanto da variabilidade total pode ser preservado com poucas componentes. Quando Π_k está próximo de 1 para um valor pequeno de k , as primeiras k componentes preservam grande parcela da variância total. A proporção acumulada, entretanto, não determina sozinha quantas componentes devem ser mantidas. Outros critérios utilizados nessa decisão são apresentados na Seção 14.14.1, incluindo uma regra heurística específica para a ACP baseada na matriz de correlações.




Figura 14.2: Os autovalores quantificam a variância de cada componente, e sua soma acumulada determina a proporção da variabilidade representada pelas primeiras dimensões.

14.7 Subespaço principal, projeção e reconstrução

Até aqui, cada componente principal foi associada a uma direção que maximiza a variância sob as restrições correspondentes. Quando apenas $k < p$ componentes são mantidas, as direções associadas podem ser consideradas conjuntamente. Os vetores $\alpha_1, \dots, \alpha_k$ geram um **subespaço principal de dimensão k** , no qual as realizações podem ser representadas por suas primeiras k coordenadas principais.

A redução dimensional pode ser interpretada geometricamente como a projeção de $\mathbf{X}_c$ sobre o subespaço principal. Para uma realização do vetor aleatório, essa projeção fornece uma representação utilizando apenas as primeiras k componentes principais.

Entre todos os subespaços lineares de dimensão k , o subespaço principal maximiza a variância total da projeção de $\mathbf{X}_c$. Essa variância corresponde à soma dos k maiores autovalores de Σ , enquanto a parcela não representada corresponde à soma dos autovalores associados às direções descartadas.

As primeiras k componentes também permitem construir, no espaço original, uma aproximação de cada realização de $\mathbf{X}_c$. Quando $k < p$, a aproximação difere da realização original por um resíduo ortogonal ao subespaço principal.

A variabilidade preservada e o erro de reconstrução descrevem a mesma escolha de subespaço sob perspectivas diferentes. O subespaço de dimensão k que preserva a maior variabilidade

total é também aquele que minimiza o erro quadrático médio de reconstrução.

Quando existe separação entre o k -ésimo e o $(k + 1)$ -ésimo autovalores, o subespaço principal de dimensão k é determinado de maneira única. Se houver empate nessa fronteira, diferentes subespaços podem preservar a mesma variabilidade máxima. A definição formal dessa estrutura e as condições de unicidade são apresentadas na Definição 14.2.

A formulação matricial da propriedade de máxima variabilidade é desenvolvida na Seção 14.13.1, enquanto a relação entre variabilidade preservada e erro quadrático de reconstrução é formalizada na Seção 14.13.2.

14.8 Formulação amostral

A formulação populacional define as componentes em termos de Σ , que geralmente é desconhecida. A aplicação da técnica utiliza uma amostra para estimar suas direções e variâncias.

Considere uma realização amostral com $n \geq 2$ observações, organizada na matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com média observada $\bar{\mathbf{x}}$ e matriz centralizada

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A matriz de covariâncias observada foi definida na Definição 8.11 como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

A versão amostral da ACP substitui a matriz populacional Σ por $\mathbf{S}$.

Considere a decomposição espectral

$$\mathbf{S} = \widehat{\mathbf{A}} \widehat{\mathbf{\Lambda}} \widehat{\mathbf{A}}^\top,$$

em que

$$\widehat{\mathbf{\Lambda}} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p),$$

com

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0,$$

e

$$\widehat{\mathbf{A}} = (\hat{\alpha}_1 \quad \dots \quad \hat{\alpha}_p).$$

A Tabela 14.2 sintetiza a distinção entre os principais objetos populacionais e amostrais da ACP.

Tabela 14.2: Correspondência entre objetos populacionais e amostrais na ACP.

Objeto	População	Amostra observada
Matriz de covariâncias	Σ	$\mathbf{S}$
Direção principal j	α_j	$\hat{\alpha}_j$
Variância da componente j	λ_j	$\hat{\lambda}_j$
Componente principal	$Y_j = \alpha_j^\top (\mathbf{X} - \mu)$	construída a partir da direção estimada $\hat{\alpha}_j$
Coordenada da observação i na componente j	$y_{ij} = \alpha_j^\top (\mathbf{x}_i - \mu)$	escore $\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}})$

A direção $\hat{\alpha}_j$ é obtida a partir da amostra. Quando o autovalor populacional correspondente é simples, o autoespaço associado é unidimensional e a direção principal é determinada até mudança de sinal; nesse sentido, a direção amostral pode ser utilizada para estimar a direção populacional. Quando há multiplicidade, os autovetores individuais não são determinados de forma única, e o objeto de interesse passa a ser o autoespaço correspondente (Anderson, 2003). A distinção entre as formulações amostral e populacional é discutida na Seção 14.11.

Os escores amostrais das observações são definidos a partir das direções principais estimadas.

Definição 14.1 (Escore de uma componente principal). Considere a observação

$$\mathbf{x}_i \in \mathbb{R}^p,$$

sua versão centralizada

$$\mathbf{x}_i - \bar{\mathbf{x}},$$

e uma direção principal amostral unitária

$$\hat{\alpha}_j \in \mathbb{R}^p.$$

O **escore amostral da observação i na componente principal j** é sua coordenada na direção principal estimada:

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Para as primeiras k componentes, considere

$$\widehat{\mathbf{A}}_k = (\hat{\alpha}_1 \quad \cdots \quad \hat{\alpha}_k).$$

Os escores das n observações nas k primeiras componentes podem ser organizados na matriz

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k \in \mathbb{R}^{n \times k}.$$

O elemento $\hat{y}_{ij}$ de $\widehat{\mathbf{Y}}_k$ é o escore da observação i na componente j . Assim, $\widehat{\mathbf{Y}}_k$ reúne as coordenadas das observações nas primeiras k direções principais.

Para uma observação específica i , suas coordenadas nas primeiras k componentes podem ser reunidas no vetor

$$\hat{\mathbf{y}}_{i,k} = \widehat{\mathbf{A}}_k^\top (\mathbf{x}_i - \bar{\mathbf{x}}) = \begin{pmatrix} \hat{y}_{i1} \\ \vdots \\ \hat{y}_{ik} \end{pmatrix}.$$

Os elementos de $\hat{\alpha}_j$ são os **coeficientes da componente principal**, enquanto $\hat{y}_{ij}$ é o **escore amostral** da observação i nessa componente. Os coeficientes definem as direções principais e os escores fornecem as coordenadas das observações nessas direções.

A matriz centralizada reconstruída a partir das primeiras k componentes pode ser escrita como

$$\widetilde{\mathbf{X}}_{c,k} = \widehat{\mathbf{Y}}_k \widehat{\mathbf{A}}_k^\top.$$

Como

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \widehat{\mathbf{A}}_k,$$

segue que

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \widehat{\mathbf{A}}_k \widehat{\mathbf{A}}_k^\top.$$

Assim, a reconstrução amostral também é uma projeção ortogonal sobre o subespaço principal estimado.

Para retornar às unidades e à localização originais, adiciona-se novamente o vetor de médias:

$$\widetilde{\mathbf{X}}_k = \widetilde{\mathbf{X}}_{c,k} + \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

A centralização remove a localização antes da determinação das direções principais; a reconstrução final restitui essa localização.

14.9 Formulação da ACP pela SVD

A formulação amostral pode ser obtida diretamente da matriz centralizada sem formar previamente $\mathbf{S}$.

Se

$$r = \text{posto}(\mathbf{X}_c) > 0,$$

considere a SVD compacta definida na Definição 6.4:

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

em que

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}, \quad \mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Os valores singulares são ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_r > 0.$$

Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

a Proposição 6.14 relaciona a SVD da matriz centralizada à decomposição espectral da matriz de covariâncias:

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto, denotando por $\mathbf{v}_j$ a j -ésima coluna de $\mathbf{V}_r$, para $j = 1, \dots, r$, cada $\mathbf{v}_j$ é um autovetor de $\mathbf{S}$ associado a $\hat{\lambda}_j$ e pode ser escolhido como a direção principal amostral correspondente:

$$\hat{\alpha}_j = \mathbf{v}_j.$$

Como $\mathbf{v}_j$ e $-\mathbf{v}_j$ determinam a mesma direção, a mudança de sinal não altera o eixo principal; ela apenas inverte o sinal dos escores da componente correspondente.

Assim,

$$\hat{\lambda}_j = \frac{d_j^2}{n-1}, \quad j = 1, \dots, r.$$

Os vetores singulares à direita da matriz centralizada são as direções principais amostrais associadas à variabilidade positiva. O quadrado de cada valor singular, dividido por $n-1$, é a variância observada da componente correspondente.

Se

$$r < p,$$

as $p-r$ componentes restantes possuem autovalor zero e, portanto, variância amostral nula. A SVD compacta não inclui uma base para esse complemento nulo, pois retém apenas os vetores singulares associados a valores singulares positivos.

A interpretação geométrica da SVD foi apresentada na Figura 6.1. Na ACP amostral, a matriz decomposta é $\mathbf{X}_c$. Os vetores singulares à direita, em $\mathbb{R}^p$, fornecem as direções principais no espaço em que as observações são representadas, enquanto $\mathbf{U}_r \mathbf{D}_r$ reúne os escores das observações nessas direções.

Essa relação mostra que a decomposição espectral de $\mathbf{S}$ e a SVD de $\mathbf{X}_c$ não constituem duas técnicas diferentes. Para as componentes de variância positiva, elas fornecem duas formas de obter a mesma solução amostral da ACP.

Os escores também são obtidos diretamente pela SVD:

$$\hat{\mathbf{Y}}_r = \mathbf{X}_c \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Assim, a SVD reúne os elementos da solução amostral:

- $\mathbf{V}_r$ contém as r direções principais em $\mathbb{R}^p$ associadas a variância amostral positiva;
- $\widehat{\mathbf{Y}}_r = \mathbf{U}_r \mathbf{D}_r$ contém os escores amostrais das observações;
- $\mathbf{D}_r$ contém os valores singulares d_j , relacionados às variâncias das componentes por $\hat{\lambda}_j = d_j^2 / (n - 1)$.

A centralização também limita o número de componentes com variância positiva. Pela Equação 8.63,

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathbf{X}_c) \leq \min(p, n - 1).$$

Portanto, existem no máximo

$$\min(p, n - 1)$$

componentes principais com variância amostral positiva.

Em particular, quando $p \geq n$, a matriz $\mathbf{S}$ é necessariamente singular. Essa singularidade amostral não implica que a matriz populacional Σ seja singular, pois a centralização impõe $\text{posto}(\mathbf{X}_c) \leq n - 1 < p$.

14.10 ACP baseada na matriz de correlações

A formulação anterior utiliza a matriz de covariâncias. Quando as variáveis possuem escalas ou unidades de medida diferentes, pode ser definido outro problema: realizar a ACP após padronizar cada variável para variância unitária (Johnson; Wichern, 2002).

A matriz de correlações populacional $\mathcal{R}$ foi definida na Definição 8.5, sob a condição de que todas as variâncias marginais populacionais sejam positivas, e sua correspondente observada $\mathbf{R}$ foi definida na Definição 8.12, sob a condição de que

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

No nível observado, defina

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

Como

$$s_{jj} > 0, \quad j = 1, \dots, p,$$

a matriz $\mathbf{D}_S$ é positiva definida e $\mathbf{D}_S^{-1/2}$ existe. Assim,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

A Equação 8.70 relaciona a matriz de correlações às colunas centralizadas e padronizadas. Para manter essa notação distinta da matriz de delineamento $\mathbf{Z}$ utilizada na Definição 11.3, neste capítulo denotaremos a matriz padronizada por

$$\mathbf{X}_{\text{pad}} = \mathbf{X}_c \mathbf{D}_S^{-1/2}.$$

Assim,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X}_{\text{pad}}^\top \mathbf{X}_{\text{pad}}.$$

Realizar a ACP de $\mathbf{R}$ equivale, portanto, a realizar a ACP sobre as colunas centralizadas e padronizadas de $\mathbf{X}$.

Se

$$\mathbf{R} = \widehat{\mathbf{A}}_R \widehat{\Lambda}_R \widehat{\mathbf{A}}_R^\top,$$

as direções principais observadas são os autovetores de $\mathbf{R}$, definidos nas coordenadas padronizadas. Os autovalores

$$\hat{\lambda}_{R1}, \dots, \hat{\lambda}_{Rp}$$

representam as variâncias observadas das componentes construídas a partir dessas variáveis.

Como a diagonal de $\mathbf{R}$ é formada por valores iguais a 1,

$$\text{tr}(\mathbf{R}) = p.$$

Logo,

$$\sum_{j=1}^p \hat{\lambda}_{Rj} = p.$$

A proporção da variância padronizada representada pela componente j é

$$\frac{\hat{\lambda}_{Rj}}{p},$$

e a proporção acumulada nas primeiras k componentes é

$$\frac{\sum_{j=1}^k \hat{\lambda}_{Rj}}{p}.$$

A utilização de **S** ou **R** corresponde a **duas formulações diferentes da ACP**.

Na ACP baseada em **S**, o critério de máxima variância é avaliado nas escalas originais. As variâncias marginais s_{jj} entram no problema espectral com suas magnitudes observadas.

Na ACP baseada em **R**, cada variável é previamente padronizada para variância unitária. O problema espectral passa, portanto, a representar a variabilidade das variáveis padronizadas.

A Tabela 14.3 resume essa distinção.

Tabela 14.3: Diferenças entre a ACP baseada em covariâncias e em correlações.

Aspecto	ACP por covariâncias	ACP por correlações
Matriz de entrada	S	R
Dados equivalentes	Centralizados	Centralizados e padronizados
Variâncias marginais	Mantidas nas unidades originais	Iguais a 1
Variância total	$\text{tr}(\mathbf{S})$	p
Influência da escala	Preservada	Removida pela padronização
Problema resolvido	Representar a variabilidade nas escalas originais	Representar a variabilidade após igualar as escalas marginais

A Figura 14.3 ilustra o efeito da padronização. Os dois painéis representam as mesmas observações, antes e depois da padronização marginal. A mudança das escalas altera a geometria e, conseqüentemente, as direções principais.

A seta vermelha representa a primeira direção principal em cada geometria. A padronização remove as diferenças de escala marginal entre as variáveis e, nesse exemplo, modifica a direção que maximiza a variância.

A escolha entre **S** e **R** determina se o critério de máxima variância é aplicado às variáveis em suas escalas originais ou após a padronização e, portanto, qual estrutura de variabilidade será representada pela ACP.




Figura 14.3: A ACP baseada em covariâncias preserva as escalas originais, enquanto a ACP baseada em correlações utiliza a geometria das variáveis padronizadas.

A padronização modifica a geometria da nuvem de dados por meio de um escalonamento diferente em cada eixo. Consequentemente, os autovetores, os autovalores, os escores e o subespaço principal podem mudar.

No Capítulo 15, a Análise Fatorial também pode ser formulada sobre uma matriz de covariâncias ou de correlações, mas seu objetivo é diferente: em vez de decompor a variabilidade total em direções principais, especifica um modelo para a estrutura de covariação entre as variáveis.

14.11 Formulação descritiva, populacional e inferencial

A ACP pode ser formulada sem hipótese de normalidade. Na formulação populacional baseada em covariâncias, basta que $\mathbf{X}$ possua momentos de segunda ordem finitos para que a matriz de covariâncias Σ e suas componentes principais estejam definidas. Na formulação baseada em correlações, exige-se adicionalmente que as variâncias marginais sejam positivas, conforme a Definição 8.5.

Na formulação **descritiva**, a matriz de dados observada é o objeto de interesse, e autovalores, direções e escores descrevem sua estrutura de variabilidade.

Na formulação **populacional**, os autovalores

$$\lambda_j$$

e os autovetores unitários

$$\alpha_j$$

são características da matriz populacional Σ . Na formulação amostral, os autovalores e autovetores de $\mathbf{S}$ são denotados por

$$\hat{\lambda}_j \quad \text{e} \quad \hat{\alpha}_j.$$

Na ACP baseada em correlações, a distinção é análoga: os objetos populacionais são determinados pela matriz $\mathcal{R}$, enquanto os correspondentes observados são obtidos de $\mathbf{R}$.

Sob as condições de consistência da matriz de covariâncias amostral estabelecidas na Proposição 10.12, os autovalores, direções e subespaços amostrais podem estimar seus correspondentes populacionais, respeitadas as condições de identificação. Quando um autovalor populacional é simples, a direção principal correspondente é determinada até mudança de sinal; quando há multiplicidade, os autovetores individuais deixam de ser únicos e o objeto identificado é o autoespaço correspondente, como discutido na Seção 14.13.5.4.

A normalidade multivariada não é necessária para a formulação da ACP. Quando

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

a transformação ortogonal para as componentes produz

$$\mathbf{Y} = \mathbf{A}^\top (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \Lambda).$$

Nesse caso, as componentes são independentes. Sem normalidade conjunta, a ACP garante que componentes distintas sejam não correlacionadas, mas não necessariamente independentes.

A inferência sobre autovalores, autovetores e subespaços requer hipóteses adicionais e teoria distribucional ou assintótica específica. Esses resultados não são necessários para a formulação da ACP e são retomados na Seção 14.13.6.

14.12 Limites da representação por componentes principais

A ACP resolve um problema definido de forma precisa: encontrar combinações lineares e subespaços que preservem variabilidade segundo uma matriz de covariâncias ou correlações. Os limites da técnica decorrem diretamente dessa formulação e são sintetizados na Tabela 14.4.

Tabela 14.4: Limites decorrentes da formulação clássica da Análise de Componentes Principais.

Aspecto	Consequência para a ACP
Critério de importância	As componentes são ordenadas pela variância. Uma componente de pequena variância pode ser relevante para outro objetivo estatístico.
Estrutura representada	A redução é realizada por projeção em subespaços lineares determinados pela matriz de covariâncias ou de correlações. Quando a variabilidade não se concentra próxima de um subespaço linear de baixa dimensão, muitas componentes podem ser necessárias para representá-la.
Conjunto de variáveis	Inclusão, exclusão, transformação ou mudança de escala altera a matriz analisada e pode modificar toda a solução.
Sensibilidade da matriz de entrada	Valores extremos podem alterar variâncias, covariâncias, correlações e, conseqüentemente, autovalores e autovetores.
Redução de dimensão	Quando são descartadas direções com autovalores positivos, parte da variabilidade original deixa de ser representada.

Quando são retidas menos dimensões do que o posto da matriz analisada, pelo menos uma direção associada a um autovalor positivo é descartada. Pela Proposição 14.2, a variabilidade não representada corresponde à soma dos autovalores associados às direções excluídas. Toda a variabilidade é preservada apenas quando os autovalores das direções descartadas são nulos.

14.13 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte reúne desenvolvimentos sobre o subespaço principal, a reconstrução por projeção, a aproximação de posto reduzido, as propriedades da solução e a estimação das componentes sob normalidade.

14.13.1 Formulação do subespaço principal e variabilidade máxima

Considere uma base ortonormal de autovetores de Σ ,

$$\alpha_1, \dots, \alpha_p,$$

ordenada de modo que

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Defina

$$\mathbf{A}_k = (\alpha_1 \ \dots \ \alpha_k) \in \mathbb{R}^{p \times k}.$$

Como esses vetores são ortonormais,

$$\mathbf{A}_k^\top \mathbf{A}_k = \mathbf{I}_k.$$

Suas colunas geram o subespaço associado às primeiras k direções dessa base.

Definição 14.2 (Subespaço principal). Seja

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias, com autovalores ordenados como

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0,$$

e seja

$$\alpha_1, \dots, \alpha_p$$

uma base ortonormal de autovetores correspondente a essa ordenação.

Para $1 \leq k \leq p$, um **subespaço principal de dimensão k** é

$$\mathcal{S}_k = \text{span} \{ \alpha_1, \dots, \alpha_k \}.$$

Se $k < p$ e

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único.

Se $\lambda_k = \lambda_{k+1}$, existem diferentes subespaços principais de dimensão k que atingem a mesma variância total máxima da projeção.

A matriz de projeção ortogonal sobre um subespaço principal $\mathcal{S}_k$ é

$$\mathbf{P}_k = \mathbf{A}_k \mathbf{A}_k^\top.$$

Essa expressão é uma aplicação direta da projeção sobre um subespaço com base ortonormal desenvolvida na Proposição [3.14](#).

As coordenadas de $\mathbf{X}_c$ nesse subespaço são

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c = \begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix}.$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}_k) &= \mathbf{A}_k^\top \Sigma \mathbf{A}_k \\ &= \text{diag}(\lambda_1, \dots, \lambda_k). \end{aligned}$$

Portanto, a variância total das coordenadas mantidas é

$$\text{tr}[\text{Cov}(\mathbf{Y}_k)] = \sum_{j=1}^k \lambda_j.$$

A soma $\sum_{j=1}^k \lambda_j$ é a variância total das primeiras k componentes. As direções $\alpha_1, \dots, \alpha_k$ geram o subespaço principal associado a essas componentes.

Considere qualquer matriz

$$\mathbf{Q} = (\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_k) \in \mathbb{R}^{p \times k},$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

A projeção de $\mathbf{X}_c$ sobre o subespaço gerado por $\mathbf{Q}$ possui coordenadas

$$\mathbf{Q}^\top \mathbf{X}_c$$

e variância total

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) = \sum_{j=1}^k \mathbf{q}_j^\top \Sigma \mathbf{q}_j.$$

A expressão $\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q})$ permite comparar a variância total das projeções em diferentes subespaços de dimensão k .

Proposição 14.1 (Variabilidade máxima do subespaço principal). *Seja*

$$\Sigma \in \mathbb{R}^{p \times p}$$

uma matriz de covariâncias com autovalores

$$\lambda_1 \geq \cdots \geq \lambda_p \geq 0.$$

Para $1 \leq k \leq p$ e qualquer matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\mathrm{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) \leq \sum_{j=1}^k \lambda_j.$$

Portanto, a maior variância total que pode ser preservada por uma projeção ortogonal em um subespaço de dimensão k é

$$\sum_{j=1}^k \lambda_j.$$

Esse máximo é atingido por qualquer subespaço principal $\mathcal{S}_k$ definido na Definição [14.2](#).

Se $k < p$ e $\lambda_k > \lambda_{k+1}$, o subespaço que maximiza a variância é único.

Se $\lambda_k = \lambda_{k+1}$, o subespaço maximizador pode não ser único.



i Demonstração

Pelo Teorema 5.4,

$$\Sigma = \mathbf{A}\mathbf{A}\mathbf{A}^\top.$$

Defina

$$\mathbf{B} = \mathbf{A}^\top \mathbf{Q}.$$

Como $\mathbf{A}$ é ortogonal e

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

tem-se

$$\mathbf{B}^\top \mathbf{B} = \mathbf{I}_k.$$

Se $b_{i\ell}$ denota o elemento da linha i e da coluna ℓ de $\mathbf{B}$, defina

$$w_i = \sum_{\ell=1}^k b_{i\ell}^2.$$

Então,

$$\begin{aligned} \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}) &= \text{tr}(\mathbf{B}^\top \Lambda \mathbf{B}) \\ &= \sum_{i=1}^p \lambda_i w_i. \end{aligned}$$

Como

$$\mathbf{B}\mathbf{B}^\top$$

é um projetor ortogonal, seus elementos diagonais satisfazem

$$0 \leq w_i \leq 1.$$

Além disso,

14.13.2 Reconstrução e erro quadrático

As primeiras k componentes fornecem as coordenadas de $\mathbf{X}_c$ no subespaço principal. A projeção no espaço original é obtida por

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{Y}_k.$$

Como

$$\mathbf{Y}_k = \mathbf{A}_k^\top \mathbf{X}_c,$$

segue que

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{A}_k \mathbf{A}_k^\top \mathbf{X}_c = \mathbf{P}_k \mathbf{X}_c.$$

O vetor $\tilde{\mathbf{X}}_{c,k}$ é a representação de $\mathbf{X}_c$ obtida utilizando apenas as primeiras k direções principais.

A parcela não representada é

$$\mathbf{E}_k = \mathbf{X}_c - \tilde{\mathbf{X}}_{c,k} = (\mathbf{I}_p - \mathbf{P}_k) \mathbf{X}_c.$$

A matriz de projeção residual foi definida na Definição 3.20, e a ortogonalidade entre a projeção e o resíduo decorre da Proposição 3.17. Portanto,

$$\|\mathbf{X}_c\|^2 = \|\tilde{\mathbf{X}}_{c,k}\|^2 + \|\mathbf{E}_k\|^2.$$

Tomando esperanças, a variabilidade total também se decompõe em parcela representada e parcela não representada:

$$E(\|\mathbf{X}_c\|^2) = E(\|\tilde{\mathbf{X}}_{c,k}\|^2) + E(\|\mathbf{E}_k\|^2).$$

A primeira parcela é

$$E(\|\tilde{\mathbf{X}}_{c,k}\|^2) = \sum_{j=1}^k \lambda_j,$$

enquanto, pela definição de variância total na Definição 8.6,

$$E\left(\|\mathbf{X}_c\|^2\right) = \text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j.$$

Consequentemente,

$$E\left(\|\mathbf{E}_k\|^2\right) = \sum_{j=k+1}^p \lambda_j.$$

A variabilidade descartada pela redução de dimensão corresponde exatamente à soma dos autovalores associados às direções excluídas.

Proposição 14.2 (Variância preservada e erro de reconstrução). *Seja*

$$\mathbf{X} \in \mathbb{R}^p$$

um vetor aleatório com segundos momentos finitos, vetor de médias μ e matriz de covariâncias Σ . Defina

$$\mathbf{X}_c = \mathbf{X} - \mu.$$

Para $1 \leq k \leq p$, considere uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

com colunas ortonormais,

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k,$$

e a projeção ortogonal

$$\tilde{\mathbf{X}}_{c,\mathbf{Q}} = \mathbf{Q}\mathbf{Q}^\top \mathbf{X}_c.$$

O erro quadrático médio de reconstrução é

$$E\left[\left\|\mathbf{X}_c - \tilde{\mathbf{X}}_{c,\mathbf{Q}}\right\|^2\right] = \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}).$$

Consequentemente, maximizar a variância preservada,

$$\text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}),$$

equivale a minimizar o erro quadrático médio de reconstrução.

Para um subespaço principal de dimensão k ,

$$\text{variância preservada} = \sum_{j=1}^k \lambda_j$$

e o erro mínimo é

$$\min_{\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k} E \left[\|\mathbf{x}_c - \mathbf{Q} \mathbf{Q}^\top \mathbf{x}_c\|^2 \right] = \sum_{j=k+1}^p \lambda_j.$$

i Demonstração

Como $\mathbf{Q} \mathbf{Q}^\top$ é um projetor ortogonal,

$$\begin{aligned} E \left[\|\mathbf{x}_c - \mathbf{Q} \mathbf{Q}^\top \mathbf{x}_c\|^2 \right] &= \text{tr} \left[(\mathbf{I}_p - \mathbf{Q} \mathbf{Q}^\top) \Sigma \right] \\ &= \text{tr}(\Sigma) - \text{tr}(\mathbf{Q}^\top \Sigma \mathbf{Q}). \end{aligned}$$

O primeiro termo é constante em relação a $\mathbf{Q}$. Portanto, minimizar o erro equivale a maximizar a variância preservada. Pela Proposição 14.1, o máximo é $\sum_{j=1}^k \lambda_j$ e, como $\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j$, o erro mínimo é

$$\sum_{j=k+1}^p \lambda_j.$$

A decomposição de um vetor em projeção e resíduo ortogonal foi apresentada na Figura 3.5. Na ACP, cada realização centralizada pode ser decomposta em sua projeção sobre um subespaço principal e em um resíduo ortogonal. Para $k = 1$, esse subespaço é a reta gerada pela primeira direção principal.

A Figura 14.4 representa a redução de duas para uma dimensão. Cada observação é projetada sobre a primeira direção principal. Os segmentos vermelhos representam os resíduos de reconstrução.

Os pontos azuis são as observações centralizadas, os pontos verdes são suas projeções sobre a primeira direção principal e os segmentos vermelhos representam os resíduos de reconstrução. Entre todas as retas que passam pela origem no espaço dos dados centralizados, a reta gerada pela primeira direção principal minimiza a soma dos quadrados das normas dos resíduos ortogonais. Essa mesma reta maximiza a variância dos pontos projetados.




Figura 14.4: A redução para uma componente substitui cada observação por sua projeção sobre a primeira direção principal; os segmentos ortogonais representam o erro de reconstrução.

14.13.3 Geometria da qualidade de representação

A qualidade de representação pelas componentes principais pode ser expressa pela relação entre a norma quadrática da projeção e a norma quadrática do vetor representado. Para as observações, essa projeção ocorre em $\mathbb{R}^p$, sobre as direções principais. Para as variáveis, ocorre em $\mathbb{R}^n$, sobre as direções definidas pelos vetores de escores. As duas construções utilizam as relações entre produto interno, ângulo, norma e projeção desenvolvidas no Módulo I.

14.13.3.1 Qualidade de representação das observações

Defina o vetor da observação centralizada por

$$\mathbf{z}_i = \mathbf{x}_i - \bar{\mathbf{x}}.$$

A direção principal associada à componente j é dada pelo autovetor unitário $\hat{\alpha}_j$, e o escore da observação i nessa componente é

$$\hat{y}_{ij} = \hat{\alpha}_j^\top \mathbf{z}_i.$$

Proposição 14.3 (Qualidade de representação das observações). *Considere $\mathbf{z}_i \neq \mathbf{0}$ e as direções principais ortonormais $\hat{\alpha}_1, \dots, \hat{\alpha}_p$.*

Se θ_{ij} é o ângulo entre $\mathbf{z}_i$ e $\hat{\alpha}_j$, então

$$\cos_{ij}^{2(\text{obs})} = \cos^2 \theta_{ij} = \frac{\hat{y}_{ij}^2}{\|\mathbf{z}_i\|^2}. \quad (14.1)$$

Para o subespaço principal amostral

$$\hat{\mathcal{S}}_k = \text{span} \{ \hat{\alpha}_1, \dots, \hat{\alpha}_k \},$$

a qualidade de representação pelas primeiras k componentes satisfaz

$$\cos_{i,(1:k)}^{2(\text{obs})} = \sum_{j=1}^k \cos_{ij}^{2(\text{obs})} = \frac{\|\text{proj}_{\hat{\mathcal{S}}_k}(\mathbf{z}_i)\|^2}{\|\mathbf{z}_i\|^2}. \quad (14.2)$$

Além disso,

$$\cos_{i,(1:k)}^{2(\text{obs})} = 1 - \frac{\|\mathbf{z}_i - \text{proj}_{\hat{\mathcal{S}}_k}(\mathbf{z}_i)\|^2}{\|\mathbf{z}_i\|^2}.$$

Demonstração

Pela definição de ângulo entre vetores na Definição 1.11,

$$\cos \theta_{ij} = \frac{\mathbf{z}_i^\top \hat{\alpha}_j}{\|\mathbf{z}_i\| \|\hat{\alpha}_j\|}.$$

Como

$$\|\hat{\alpha}_j\| = 1$$

e

$$\hat{y}_{ij} = \hat{\alpha}_j^\top \mathbf{z}_i,$$

segue que

$$\cos \theta_{ij} = \frac{\hat{y}_{ij}}{\|\mathbf{z}_i\|}.$$

Elevando ao quadrado,

$$\cos^2 \theta_{ij} = \frac{\hat{y}_{ij}^2}{\|\mathbf{z}_i\|^2}.$$

Pela Proposição 3.13,

$$\text{proj}_{\text{span}\{\hat{\alpha}_j\}}(\mathbf{z}_i) = \hat{y}_{ij} \hat{\alpha}_j.$$

Como as primeiras k direções formam um conjunto ortonormal, a Proposição 3.14 fornece

$$\text{proj}_{S_k}(\mathbf{z}_i) = \sum_{j=1}^k \hat{y}_{ij} \hat{\alpha}_j$$

e

$$\left\| \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2 = \sum_{j=1}^k \hat{y}_{ij}^2.$$

Dividindo por $\|\mathbf{z}_i\|^2$, obtém-se a expressão para $\cos_{i,(1:k)}^{2(\text{obs})}$.

Pelo Teorema 3.7,

$$\|\mathbf{z}_i\|^2 = \left\| \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2 + \left\| \mathbf{z}_i - \text{proj}_{S_k}(\mathbf{z}_i) \right\|^2.$$

A divisão por $\|\mathbf{z}_i\|^2$ fornece a última identidade.

Na ACP baseada em covariâncias,

$$\|\mathbf{z}_i\|^2 = \sum_{\ell=1}^p \hat{y}_{i\ell}^2,$$

pois a transformação completa para as coordenadas principais é ortogonal. Na ACP baseada em correlações, a mesma relação é aplicada ao vetor da observação no espaço das variáveis centralizadas e padronizadas.

O numerador da Equação 14.2 é a norma quadrática da projeção da observação centralizada sobre o subespaço retido, enquanto o denominador é sua distância quadrática ao centro. Valores próximos de 1 correspondem a uma pequena distância quadrática entre a observação centralizada e sua projeção.

14.13.3.2 Qualidade de representação das variáveis

Considere o vetor centralizado da variável X_i e o vetor de escores da componente Y_j . A qualidade de representação pode ser formulada diretamente pela correlação entre esses dois vetores.

Proposição 14.4 (Qualidade de representação das variáveis). *Considere $s_{ii} > 0$ e uma componente com $\hat{\lambda}_j > 0$. Se ϑ_{ij} é o ângulo entre o vetor centralizado da variável X_i e o vetor de escores da componente Y_j , então*

$$r_{ij} = \widehat{\text{Corr}}(X_i, Y_j) = \cos \vartheta_{ij},$$

e

$$\cos^2_{ij}(\text{var}) = r_{ij}^2 = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}^2}{s_{ii}}. \quad (14.3)$$

Se $\mathbf{S}$ possui posto r , então

$$\sum_{j: \hat{\lambda}_j > 0} r_{ij}^2 = 1.$$

Para $1 \leq k \leq r$,

$$\cos^2_{i,(1:k)}(\text{var}) = \sum_{j=1}^k r_{ij}^2.$$

Essa quantidade é a norma quadrática da projeção do vetor centralizado e normalizado da variável sobre o subespaço gerado pelos primeiros k vetores de escores normalizados.

Demonstração

A interpretação da correlação como cosseno estabelecida em Equação 8.71 fornece

$$r_{ij} = \cos \vartheta_{ij}.$$

Elevando ao quadrado,

$$\cos^2(\vartheta_{ij}) = r_{ij}^2.$$

A covariância amostral entre a variável X_i e a componente Y_j satisfaz

$$\widehat{\text{Cov}}(X_i, Y_j) = \mathbf{e}_i^\top \mathbf{S} \hat{\alpha}_j = \hat{\lambda}_j \hat{\alpha}_{ij},$$

pois

$$\mathbf{S} \hat{\alpha}_j = \hat{\lambda}_j \hat{\alpha}_j.$$

Como

$$\widehat{\text{Var}}(Y_j) = \hat{\lambda}_j,$$

segue que

$$r_{ij} = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}}{\sqrt{s_{ii}} \sqrt{\hat{\lambda}_j}} = \frac{\sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}}{\sqrt{s_{ii}}}.$$

Portanto,

$$r_{ij}^2 = \frac{\hat{\lambda}_j \hat{\alpha}_{ij}^2}{s_{ii}}.$$

Se $\mathbf{S}$ possui posto r , sua decomposição espectral fornece

$$s_{ii} = \sum_{j: \hat{\lambda}_j > 0} \hat{\lambda}_j \hat{\alpha}_{ij}^2.$$

Consequentemente,

$$\begin{aligned} \sum_{j: \hat{\lambda}_j > 0} r_{ij}^2 &= \frac{1}{s_{ii}} \sum_{j: \hat{\lambda}_j > 0} \hat{\lambda}_j \hat{\alpha}_{ij}^2 \\ &= 1. \end{aligned}$$

Para explicitar a interpretação como projeção, seja $\mathbf{x}_{c,i} \in \mathbb{R}^n$ o vetor centralizado das observações da variável X_i e defina

$$\mathbf{w}_i = \frac{\mathbf{x}_{c,i}}{\|\mathbf{x}_{c,i}\|}.$$

Para cada componente com $\hat{\lambda}_j > 0$, seja $\hat{\mathbf{y}}_j \in \mathbb{R}^n$ o vetor formado pelos escores da componente j e defina

$$\mathbf{u}_j = \frac{\hat{\mathbf{y}}_j}{\|\hat{\mathbf{y}}_j\|}.$$

Os vetores de escores de componentes distintas são ortogonais; portanto, os vetores $\mathbf{u}_j$ formam um conjunto ortonormal em $\mathbb{R}^n$. Além disso,

$$\mathbf{w}_i^\top \mathbf{u}_j = r_{ij}.$$

Pela Proposição 3.14,

$$\left\| \text{proj}_{\text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}}(\mathbf{w}_i) \right\|^2 = \sum_{j=1}^k r_{ij}^2 = \cos_{i,(1:k)}^2(\text{var}).$$

Isso estabelece a interpretação da soma dos cossenos quadrados como norma quadrática da projeção da variável normalizada sobre o subespaço gerado pelos vetores de escores considerados.

Assim, $\cos_{i,(1:k)}^2(\text{var})$ mede a parcela da variância da variável i representada pelo subespaço gerado pelos primeiros k vetores de escores.

As duas construções utilizam a mesma relação geométrica. Para as observações, o ângulo é definido em $\mathbb{R}^p$ entre o vetor centralizado e uma direção principal. Para as variáveis, o ângulo é definido em $\mathbb{R}^n$ entre o vetor centralizado da variável e o vetor de escores da componente. Em ambos os casos, o $\cos^2$ expressa uma proporção quadrática de representação.

14.13.4 Aproximação de posto reduzido

A SVD relaciona diretamente a redução de dimensionalidade ao problema de aproximação matricial.

Para

$$1 \leq k < r,$$

mantendo apenas os k primeiros termos da SVD,

$$\tilde{\mathbf{X}}_{c,k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Pelo Teorema 6.2, $\widetilde{\mathbf{X}}_{c,k}$ é uma melhor aproximação de $\mathbf{X}_c$ entre todas as matrizes de posto não superior a k , segundo a norma de Frobenius.

Se

$$d_k > d_{k+1},$$

essa melhor aproximação é única. Quando

$$d_k = d_{k+1},$$

existem diferentes aproximações de posto não superior a k que atingem o mesmo erro mínimo.

Além disso, pela relação entre projeção e SVD estabelecida na Proposição 6.19,

$$\widetilde{\mathbf{X}}_{c,k} = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top.$$

Como os escores associados às primeiras k direções são

$$\widehat{\mathbf{Y}}_k = \mathbf{X}_c \mathbf{V}_k,$$

também se obtém

$$\widetilde{\mathbf{X}}_{c,k} = \widehat{\mathbf{Y}}_k \mathbf{V}_k^\top.$$

Essas três expressões representam o mesmo objeto:

$$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top = \mathbf{X}_c \mathbf{V}_k \mathbf{V}_k^\top = \widehat{\mathbf{Y}}_k \mathbf{V}_k^\top.$$

A primeira expressão mostra a aproximação de posto reduzido; a segunda mostra a projeção sobre o subespaço principal; a terceira mostra a reconstrução a partir dos escores amostrais e das direções principais.

O erro quadrático total da aproximação é

$$\|\mathbf{X}_c - \widetilde{\mathbf{X}}_{c,k}\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Como

$$d_j^2 = (n-1)\hat{\lambda}_j,$$

segue que

$$\|\mathbf{X}_c - \widetilde{\mathbf{X}}_{c,k}\|_F^2 = (n-1) \sum_{j=k+1}^r \hat{\lambda}_j.$$

A parcela da soma de quadrados preservada pela aproximação é

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2} = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{j=1}^r \hat{\lambda}_j}.$$

Essa expressão coincide com a proporção de variância observada representada pelas primeiras k componentes.

A equivalência entre as formulações pode ser resumida pela Tabela 14.5.

Tabela 14.5: Formulações relacionadas da Análise de Componentes Principais.

Formulação	Objeto otimizado ou decomposto	Solução
Variância	$\alpha^\top \Sigma \alpha$ ou $\alpha^\top \mathbf{S} \alpha$	Autovetores associados aos maiores autovalores
Subespaço	Variância total da projeção em dimensão k	Subespaço gerado pelas primeiras k direções
Reconstrução	Erro quadrático da representação	Projeção sobre um subespaço principal
SVD	Matriz de dados centralizada $\mathbf{X}_c$	Vetores singulares à direita associados aos valores singulares positivos
Aproximação matricial	$\ \mathbf{X}_c - \mathbf{B}\ _F$ com $\text{posto}(\mathbf{B}) \leq k$	$\mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top$

As formulações da Tabela 14.5 descrevem a mesma solução sob três perspectivas relacionadas. Estatisticamente, a ACP maximiza a variância das combinações lineares sujeitas às restrições de normalização e ortogonalidade. Geometricamente, o subespaço principal maximiza a variância total da projeção e minimiza o erro quadrático de reconstrução. Matricialmente, a SVD truncada fornece uma aproximação de posto reduzido da matriz de dados centralizada (Eaton, 2007; Johnson; Wichern, 2002). Na formulação amostral, essas perspectivas conduzem ao mesmo subespaço principal estimado.

14.13.5 Propriedades da solução

14.13.5.1 Invariância a translações

Para qualquer vetor constante $\mathbf{c} \in \mathbb{R}^p$,

$$\mathbf{X}^* = \mathbf{X} + \mathbf{c}$$

possui a mesma matriz de covariâncias de $\mathbf{X}$:

$$\text{Cov}(\mathbf{X}^*) = \Sigma.$$

Consequentemente, os autovalores e as direções principais não se alteram. A ACP baseada em covariâncias é, portanto, invariante a translações. A centralização modifica a origem da representação, mas não sua estrutura de dispersão.

14.13.5.2 Dependência da escala

A ACP baseada em covariâncias não é, em geral, invariante a mudanças individuais de escala. Se

$$\mathbf{X}^* = \mathbf{D}\mathbf{X},$$

com $\mathbf{D}$ diagonal e positiva, então

$$\Sigma^* = \mathbf{D}\Sigma\mathbf{D}.$$

Os autovalores e autovetores de Σ^* podem diferir dos de Σ . Portanto, mudanças de unidade podem alterar a solução da ACP por covariâncias. Essa propriedade explica a distinção entre a ACP baseada em covariâncias e a ACP baseada em correlações desenvolvida na Seção [14.10](#).

14.13.5.3 Indeterminação do sinal

Se

$$\Sigma \alpha_j = \lambda_j \alpha_j,$$

então

$$\Sigma(-\alpha_j) = \lambda_j(-\alpha_j).$$

Portanto, α_j e $-\alpha_j$ representam a mesma direção principal.

Se o sinal do vetor de coeficientes for invertido,

$$Y_j = \alpha_j^\top \mathbf{X}_c$$

passa a ser

$$Y_j^* = -Y_j.$$

Os escores também mudam de sinal, mas a variância, o subespaço gerado e a qualidade da representação permanecem inalterados.

A orientação positiva ou negativa de um eixo principal é, portanto, arbitrária.

Ao comparar resultados produzidos por diferentes programas ou decomposições numéricas, sinais opostos não caracterizam soluções distintas. A inversão do sinal da direção principal inverte também os escores correspondentes, mas preserva o mesmo eixo, a mesma variância e a mesma qualidade de representação.

A mudança de sinal não é a única situação em que as direções podem deixar de ser únicas. Quando há autovalores repetidos, a ACP identifica o autoespaço correspondente, mas não uma base única dentro dele. Além disso, quando a matriz analisada é singular, a variabilidade está restrita a um subespaço de dimensão inferior a p . Essas duas situações são desenvolvidas a seguir.

14.13.5.4 Unicidade, multiplicidade e dimensão efetiva

Quando todos os autovalores são simples, cada direção principal é determinada até mudança de sinal. Autovalores repetidos e matrizes singulares exigem distinguir a unicidade das direções, a unicidade dos subespaços e a dimensão efetivamente ocupada pela variabilidade.

14.13.5.4.1 Multiplicidade de autovalores

Os conceitos de multiplicidade algébrica e geométrica foram definidos na Definição 5.5. Como Σ é simétrica, o Teorema 5.4 garante uma base ortonormal em cada autoespaço.

Considere

$$\lambda_j = \lambda_{j+1}.$$

Qualquer base ortonormal do autoespaço associado pode ser utilizada. Assim, os vetores

$$\alpha_j \quad \text{e} \quad \alpha_{j+1}$$

não são individualmente determinados de forma única. O objeto determinado é o autoespaço associado ao autovalor repetido.

Quando um autovalor é simples, sua direção principal é determinada até mudança de sinal. Quando há multiplicidade, diferentes bases ortonormais do autoespaço produzem conjuntos diferentes de autovetores igualmente válidos. A ACP identifica, nesse caso, o autoespaço associado ao autovalor repetido, e não uma base ortonormal única dentro dele.

A não unicidade das bases de um autoespaço com multiplicidade foi ilustrada na Figura 5.2. Na ACP, a mesma propriedade explica a condição de unicidade apresentada na Definição 14.2 e na Proposição 14.1.

Se

$$\lambda_k > \lambda_{k+1},$$

o subespaço principal de dimensão k é único. Se

$$\lambda_k = \lambda_{k+1},$$

o corte ocorre dentro de um autoespaço associado a um autovalor repetido. Nesse caso, existem diferentes subespaços de dimensão k que atingem a mesma variância total máxima da projeção.

Mesmo sem igualdade exata, uma pequena separação entre autovalores adjacentes pode tornar os autovetores individuais sensíveis a pequenas perturbações da matriz analisada. Nessa situação, o subespaço gerado conjuntamente pelos autovetores associados aos autovalores próximos pode ser mais estável do que cada direção considerada isoladamente.

14.13.5.4.2 Singularidade e dimensão efetiva

A Proposição 8.3 relaciona a singularidade da matriz de covariâncias à existência de combinações lineares com variância zero.

Se

$$\text{posto}(\Sigma) = r < p,$$

então exatamente r autovalores são positivos:

$$\lambda_1 \geq \dots \geq \lambda_r > 0,$$

enquanto

$$\lambda_{r+1} = \dots = \lambda_p = 0.$$

O vetor centralizado $\mathbf{X}_c$ pertence, com probabilidade 1, ao subespaço gerado pelos autovetores associados aos r autovalores positivos. Para $j > r$, a componente Y_j possui média zero e variância zero e, portanto, $Y_j = 0$ quase certamente. Assim, a representação pelas r componentes de variância positiva preserva toda a variância populacional.

No nível amostral, a centralização implica

$$\text{posto}(\mathbf{X}_c) \leq n - 1$$

e, consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Quando

$$p \geq n,$$

a matriz de covariâncias amostral é necessariamente singular, ainda que a matriz populacional não seja. Na SVD compacta de $\mathbf{X}_c$, os vetores singulares à direita associados aos valores singulares positivos formam uma base ortonormal do subespaço das direções com variância amostral positiva. A formulação da ACP por SVD permanece, portanto, bem definida mesmo quando $\mathbf{S}$ é singular.

14.13.6 Estimação e inferência das componentes sob normalidade

A formulação da ACP não exige normalidade multivariada. Os resultados desta seção referem-se à ACP populacional baseada na matriz de covariâncias. A hipótese normal passa a ter função específica quando os autovalores e as direções principais são tratados como parâmetros de uma população e se deseja estudar sua estimação ou sua distribuição amostral.

Considere uma amostra aleatória da distribuição normal multivariada definida na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma), \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, a Proposição 10.3 fornece a estimativa de máxima verossimilhança de Σ quando o máximo da verossimilhança existe. Esse máximo existe e é único quando $\text{posto}(\mathbf{S}) = p$; sob o modelo normal não singular, essa condição ocorre quase certamente para $n \geq p + 1$. Com a convenção amostral utilizada neste capítulo, a Equação 10.72 fornece

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{n-1}{n} \mathbf{S}.$$

Considere a decomposição espectral da matriz de covariâncias amostral,

$$\mathbf{S} = \hat{\mathbf{A}} \hat{\Lambda} \hat{\mathbf{A}}^\top,$$

em que

$$\hat{\Lambda} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p).$$

Como $\hat{\Sigma}_{\text{MV,obs}}$ é um múltiplo positivo de $\mathbf{S}$,

$$\hat{\Sigma}_{\text{MV,obs}} = \hat{\mathbf{A}} \left(\frac{n-1}{n} \hat{\Lambda} \right) \hat{\mathbf{A}}^\top.$$

As duas matrizes possuem, portanto, os mesmos autovetores. Seus autovalores diferem pelo fator

$$\frac{n-1}{n}.$$

Com a notação adotada neste capítulo, a estimativa de máxima verossimilhança do j -ésimo autovalor é

$$\hat{\lambda}_{j,\text{MV,obs}} = \frac{n-1}{n} \hat{\lambda}_j.$$

Nessas condições de existência e quando os autovalores populacionais são distintos, a direção $\hat{\alpha}_j$, com uma convenção de sinal, e $\hat{\lambda}_{j,\text{MV,obs}}$ são as estimativas de máxima verossimilhança da direção principal populacional e de sua variância, respectivamente (Anderson, 2003).

A diferença entre os divisores n e $n-1$ não altera os eixos da ACP. Ela também não altera a proporção de variância associada a cada componente, pois

$$\frac{\hat{\lambda}_{j,\text{MV,obs}}}{\sum_{\ell=1}^p \hat{\lambda}_{\ell,\text{MV,obs}}} = \frac{\hat{\lambda}_j}{\sum_{\ell=1}^p \hat{\lambda}_\ell}.$$

A escolha do divisor modifica a escala dos autovalores, mas preserva as direções, os escores definidos a partir dessas direções e as proporções de variância.

Para estudar as distribuições amostrais, $\hat{\lambda}_j$ e $\hat{\alpha}_j$ passam a ser considerados como estatísticas da amostra aleatória, isto é, como estimadores dos objetos espectrais populacionais. Sob normalidade multivariada, autovalores populacionais distintos e dimensão p fixa,

$$\sqrt{n} (\hat{\lambda}_j - \lambda_j) \xrightarrow{d} N(0, 2\lambda_j^2).$$

Para estudar uma direção individual, fixe o sinal de $\hat{\alpha}_j$ de modo que

$$\hat{\alpha}_j^\top \alpha_j > 0.$$

Então,

$$\sqrt{n} (\hat{\alpha}_j - \alpha_j) \xrightarrow{d} N_p(\mathbf{0}, \Gamma_j),$$

com

$$\Gamma_j = \sum_{\ell \neq j} \frac{\lambda_j \lambda_\ell}{(\lambda_j - \lambda_\ell)^2} \alpha_\ell \alpha_\ell^\top$$

(Anderson, 2003; Johnson; Wichern, 2002).

A expressão de Γ_j mostra o efeito da separação entre autovalores. Quando λ_j se aproxima de outro autovalor λ_ℓ , o termo $(\lambda_j - \lambda_\ell)^{-2}$ aumenta e amplia a variância assintótica do estimador da direção principal. Esse resultado formaliza a sensibilidade das direções individuais discutida na Seção 14.13.5.4.

Os resultados assintóticos acima pressupõem autovalores populacionais distintos. Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais não são parâmetros identificados de forma única; o objeto inferencial passa a ser o autoespaço associado ao autovalor repetido, e as fórmulas anteriores para direções individuais deixam de se aplicar.

14.14 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne critérios e objetos utilizados na condução e na interpretação da ACP, incluindo a escolha do número de componentes, a relação das variáveis com as componentes, a representação das observações e das variáveis e a utilização de elementos suplementares.

14.14.1 Escolha do número de componentes

Tanto na ACP baseada em covariâncias quanto na baseada em correlações, a decomposição espectral produz p componentes, embora aquelas associadas a autovalores nulos tenham variância zero. A redução de dimensionalidade exige decidir quantas das primeiras componentes serão mantidas. Essa decisão não é determinada pela solução matemática da ACP e deve considerar o objetivo da representação, a parcela de variabilidade preservada, os tamanhos relativos dos autovalores e a interpretação das componentes (Johnson; Wichern, 2002).

Na aplicação amostral, denote por

$$\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0$$

os autovalores da matriz observada utilizada na ACP. A proporção acumulada observada é

$$\hat{\Pi}_k = \frac{\sum_{j=1}^k \hat{\lambda}_j}{\sum_{\ell=1}^p \hat{\lambda}_\ell}.$$

Essa quantidade descreve a parcela da variabilidade observada representada pelas primeiras k componentes. Quanto mais próximo de 1 estiver $\hat{\Pi}_k$ para um valor pequeno de k , maior será a parcela da variabilidade representada por poucas componentes. Não existe, entretanto, uma proporção mínima universal que determine, por si só, quantas componentes devem ser retidas.

Outra informação é fornecida pelo gráfico dos autovalores, usualmente denominado **gráfico de declive** (*scree plot*). Os autovalores são apresentados em ordem decrescente e procura-se identificar uma mudança de inclinação que separe o trecho de quedas mais acentuadas daquele

em que os autovalores se tornam relativamente pequenos e semelhantes. As componentes anteriores a essa estabilização constituem candidatas à retenção.

A Figura 14.5 ilustra esse comportamento. A linha horizontal também permite comparar, no mesmo exemplo, o gráfico de declive com a referência $\lambda = 1$ utilizada na ACP baseada em correlações.




Figura 14.5: Gráfico de declive dos autovalores. A linha tracejada indica a referência autovalor igual a 1 para uma ACP baseada em correlações.

No exemplo, os cinco autovalores somam 5, como ocorre para uma matriz de correlações de ordem 5. Após a segunda componente, os autovalores são menores e as quedas entre valores sucessivos tornam-se menos acentuadas. A linha tracejada representa outro critério: apenas os dois primeiros autovalores excedem 1. O gráfico de declive e a comparação com 1 utilizam, portanto, critérios distintos, embora neste exemplo ambos destaquem as primeiras componentes.

Na ACP baseada na matriz de correlações, há ainda uma referência específica decorrente da padronização. Como

$$\text{tr}(\mathbf{R}) = p,$$

a média dos p autovalores é igual a 1. Nesse contexto, o critério de reter componentes com

$$\hat{\lambda}_{Rj} > 1$$

pode ser interpretado como a retenção de componentes cuja variância excede a variância de uma variável original padronizada. Esse critério é uma regra heurística e sua justificativa não se transfere diretamente para a ACP baseada em uma matriz de covariâncias, cujas variâncias dependem das escalas das variáveis.

A escolha de k deve considerar conjuntamente a proporção acumulada de variância, o padrão dos autovalores no gráfico de declive e a interpretação da representação obtida. Esses critérios podem ser utilizados tanto na ACP baseada em covariâncias quanto na baseada em correlações. O critério do autovalor maior que 1, por sua vez, possui justificativa específica para a matriz de correlações e não constitui uma condição necessária para retenção. Diferentes critérios podem sugerir dimensões distintas, e a decisão deve permanecer vinculada ao objetivo da análise (Johnson; Wichern, 2002; Jolliffe, 2002).

Os autovalores pequenos também possuem informação diagnóstica. Valores muito próximos de zero, especialmente entre as últimas componentes, podem indicar dependências lineares ou quase lineares entre as variáveis. Assim, mesmo quando essas componentes não são mantidas na representação reduzida, os autovalores correspondentes devem ser examinados quanto à possível presença dessas dependências (Johnson; Wichern, 2002).

14.14.2 Coeficientes e relação das variáveis com as componentes

Os elementos do vetor

$$\alpha_j = \begin{pmatrix} \alpha_{1j} \\ \vdots \\ \alpha_{pj} \end{pmatrix}$$

são os **coeficientes da j -ésima componente principal**. Eles definem a combinação linear

$$Y_j = \sum_{i=1}^p \alpha_{ij} (X_i - \mu_i).$$

Esses coeficientes são as coordenadas do vetor unitário α_j que define a direção principal em $\mathbb{R}^p$ associada à componente. Eles não devem ser confundidos com as correlações entre cada variável e a componente.

A relação entre esses dois objetos pode ser obtida diretamente a partir da matriz de covariâncias.

Para a variável X_i ,

$$\begin{aligned}\text{Cov}(X_i, Y_j) &= \text{Cov}[X_i, \alpha_j^\top (\mathbf{X} - \mu)] \\ &= \sum_{\ell=1}^p \alpha_{\ell j} \text{Cov}(X_i, X_\ell) \\ &= (\Sigma \alpha_j)_i.\end{aligned}$$

Como

$$\Sigma \alpha_j = \lambda_j \alpha_j,$$

segue que

$$\text{Cov}(X_i, Y_j) = \lambda_j \alpha_{ij}.$$

Além disso,

$$\text{Var}(Y_j) = \lambda_j$$

e

$$\text{Var}(X_i) = \sigma_{ii}.$$

Se

$$\sigma_{ii} > 0$$

e

$$\lambda_j > 0,$$

então a correlação está definida e

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} \alpha_{ij}}{\sqrt{\sigma_{ii}}}.$$

Proposição 14.5 (Correlação entre uma variável e uma componente principal). *Considere a ACP populacional baseada na matriz de covariâncias Σ . Para uma variável X_i com*

$$\sigma_{ii} > 0$$

e uma componente principal

$$Y_j = \alpha_j^\top (\mathbf{X} - \mu)$$

associada a um autovalor

$$\lambda_j > 0,$$

tem-se

$$\text{Corr}(X_i, Y_j) = \frac{\sqrt{\lambda_j} \alpha_{ij}}{\sqrt{\sigma_{ii}}}.$$

Na ACP populacional baseada na matriz de correlações $\mathcal{R}$, suponha que as variâncias marginais sejam positivas, como exigido na Definição 8.5. Considere a variável padronizada $X_{i,\text{pad}}$ e uma componente

$$Y_{Rj}$$

construída a partir do autovetor α_{Rj} associado a

$$\lambda_{Rj} > 0.$$

Como

$$\text{Var}(X_{i,\text{pad}}) = 1,$$

tem-se

$$\text{Corr}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\lambda_{Rj}} \alpha_{R,ij}.$$

A condição $\lambda_j > 0$ é necessária porque a correlação exige variância positiva para a componente. Se

$$\lambda_j = 0,$$

então

$$\text{Var}(Y_j) = 0,$$

e a correlação entre Y_j e qualquer variável não está definida.

A expressão mostra que o coeficiente α_{ij} e a correlação entre X_i e Y_j representam objetos diferentes.

A diferença entre os coeficientes da componente e as correlações com as variáveis pode ser visualizada na Figura 14.6. O exemplo utiliza uma matriz de covariâncias com variâncias marginais diferentes.




Figura 14.6: Os coeficientes definem a direção principal associada à componente, enquanto as correlações medem a associação linear de cada variável com essa componente.

Os coeficientes pertencem ao vetor unitário que define a direção principal. As correlações dependem também da variância da componente e da variância de cada variável. Por isso, as duas medidas não são intercambiáveis.

Os coeficientes são as coordenadas do vetor unitário que define a direção principal e determinam a combinação linear da componente. As correlações descrevem a associação linear bivariada de cada variável com a componente. Na ACP baseada em covariâncias, seus valores dependem também das variâncias marginais das variáveis. Assim, coeficientes e correlações possuem interpretações distintas (Johnson; Wichern, 2002).

No Capítulo 15, as cargas fatoriais pertencem ao próprio modelo de covariâncias e têm interpretação diferente dos coeficientes de uma componente principal.

Na formulação amostral baseada em $\mathbf{S}$, se

$$s_{ii} > 0$$

e

$$\hat{\lambda}_j > 0,$$

então

$$\widehat{\text{Corr}}(X_i, Y_j) = \frac{\sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}}{\sqrt{s_{ii}}}.$$

Quando a ACP é realizada sobre $\mathbf{R}$, cada variável padronizada possui variância observada igual a 1. Para uma componente com

$$\hat{\lambda}_{Rj} > 0,$$

denotando por $X_{i,\text{pad}}$ a variável padronizada e por Y_{Rj} a componente correspondente,

$$\widehat{\text{Corr}}(X_{i,\text{pad}}, Y_{Rj}) = \sqrt{\hat{\lambda}_{Rj}} \hat{\alpha}_{R,ij}.$$

14.14.3 Representação das observações e das variáveis

A representação das observações utiliza os escores das componentes. Para as variáveis, é necessário distinguir dois objetos: as coordenadas utilizadas no mapa das variáveis e as correlações entre as variáveis e as componentes, desenvolvidas na Seção 14.14.2.

14.14.3.1 Observações: coordenadas, qualidade de representação e contribuição

Para a observação i , a coordenada na componente j é o próprio score

$$\hat{y}_{ij} = \hat{\alpha}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

Assim, em uma representação pelas duas primeiras componentes, a observação i é localizada pelo ponto

$$(\hat{y}_{i1}, \hat{y}_{i2}).$$

O score é a coordenada da observação na direção principal. Fixada a orientação de $\hat{\alpha}_j$, seu sinal indica de que lado da origem está a projeção, e seu módulo fornece a distância dessa projeção à origem ao longo do eixo.

A Proposição 14.3 estabelece a interpretação geométrica do $\cos^2$ das observações. Pela Equação 14.1, para a componente j ,

$$\cos_{ij}^{2(\text{obs})} = \frac{\hat{y}_{ij}^2}{\sum_{\ell=1}^p \hat{y}_{i\ell}^2}.$$

Para as primeiras k componentes,

$$\cos_{i,(1:k)}^{2(\text{obs})} = \sum_{j=1}^k \cos_{ij}^{2(\text{obs})}.$$

Valores próximos de 1 indicam que grande parcela da distância quadrática da observação ao centro é preservada pela projeção no subespaço retido.

Na formulação clássica adotada neste capítulo, para uma componente com $\hat{\lambda}_j > 0$, a **contribuição** da observação i para a componente j é

$$\text{ctr}_{ij}^{(\text{obs})} = \frac{\hat{y}_{ij}^2}{\sum_{h=1}^n \hat{y}_{hj}^2}. \quad (14.4)$$

Portanto,

$$\sum_{i=1}^n \text{ctr}_{ij}^{(\text{obs})} = 1.$$

Na convenção amostral utilizada neste capítulo,

$$\sum_{h=1}^n \hat{y}_{hj}^2 = (n-1)\hat{\lambda}_j,$$

e

$$\text{ctr}_{ij}^{(\text{obs})} = \frac{\hat{y}_{ij}^2}{(n-1)\hat{\lambda}_j}.$$

Quanto maior $\text{ctr}_{ij}^{(\text{obs})}$, maior a parcela da soma de quadrados dos escores da componente j correspondente à observação i .

O $\cos^2$ e a contribuição utilizam o mesmo escore quadrático, mas normalizações diferentes. O $\cos^2$ o divide pela distância quadrática total da observação ao centro; a contribuição o divide pela soma de quadrados dos escores de todas as observações na componente.

14.14.3.2 Variáveis: coordenadas, qualidade de representação e contribuição

A Seção 14.14.2 mostrou que os coeficientes que definem uma direção principal e as correlações das variáveis com as componentes são objetos distintos. A representação das variáveis também exige distinguir essas correlações das coordenadas associadas aos eixos principais.

Considere primeiro a ACP baseada em $\mathbf{S}$. Para a variável i e a componente j , a coordenada adotada neste capítulo é

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij}.$$

Pela relação desenvolvida na Seção 14.14.2,

$$r_{ij} = \widehat{\text{Corr}}(X_i, Y_j) = \frac{c_{ij}}{\sqrt{s_{ii}}},$$

quando $s_{ii} > 0$.

A coordenada c_{ij} e a correlação r_{ij} coincidem apenas quando a variável considerada possui variância unitária. Esse é o caso da ACP aplicada às variáveis padronizadas.

Na ACP baseada em $\mathbf{R}$,

$$c_{R,ij} = \sqrt{\hat{\lambda}_{Rj}} \hat{\alpha}_{R,ij}$$

e, como cada variável padronizada possui variância igual a 1,

$$c_{R,ij} = r_{R,ij}.$$

A Proposição 14.4 estabelece a interpretação geométrica do $\cos^2$ das variáveis. Pela Equação 14.3, para uma componente com $\hat{\lambda}_j > 0$,

$$\cos_{ij}^{2(\text{var})} = r_{ij}^2.$$

Para as primeiras k componentes,

$$\cos_{i,(1:k)}^{2(\text{var})} = \sum_{j=1}^k r_{ij}^2.$$

Valores próximos de 1 indicam que grande parcela da variância da variável é representada pelo subespaço gerado pelos primeiros k vetores de escores.

Para uma componente com $\hat{\lambda}_j > 0$, a contribuição da variável i para a componente j pode ser escrita como

$$\text{ctr}_{ij}^{(\text{var})} = \frac{c_{ij}^2}{\hat{\lambda}_j}. \quad (14.5)$$

Como

$$c_{ij} = \sqrt{\hat{\lambda}_j} \hat{\alpha}_{ij},$$

segue que

$$\text{ctr}_{ij}^{(\text{var})} = \hat{\alpha}_{ij}^2.$$

Portanto,

$$\sum_{i=1}^p \text{ctr}_{ij}^{(\text{var})} = 1.$$

Na ACP baseada em correlações, para uma componente com $\hat{\lambda}_{Rj} > 0$,

$$c_{R,ij} = r_{R,ij},$$

e a contribuição também pode ser escrita como

$$\text{ctr}_{ij}^{(\text{var})} = \frac{r_{R,ij}^2}{\hat{\lambda}_{Rj}}.$$

A coordenada localiza a variável na geometria associada às componentes. O $\cos^2$ mede sua qualidade de representação. A contribuição mede sua participação na construção da componente.

14.14.3.3 Duas representações complementares

A interpretação gráfica da ACP distingue o mapa das observações do mapa das variáveis. Os $\cos^2$ desenvolvidos na Seção 14.13.3 quantificam a qualidade de representação desses elementos nas dimensões retidas.

No **mapa das observações**, os pontos são posicionados pelos escores nas componentes retidas. A distância euclidiana entre dois pontos é a distância entre as projeções das observações no subespaço representado. Na ACP baseada em covariâncias, essa geometria é determinada pelos dados centralizados em suas escalas originais; na ACP baseada em correlações, pelos dados centralizados e padronizados. Quando nem todas as componentes são mantidas, as distâncias no mapa não reproduzem necessariamente as distâncias euclidianas no espaço completo. A qualidade da representação de cada observação é avaliada pelos respectivos $\cos^2$.

No **mapa das variáveis**, duas representações devem ser distinguidas. As coordenadas c_{ij} descrevem a posição das variáveis na geometria associada às componentes. As correlações r_{ij} expressam a associação linear entre cada variável e cada componente na escala comum $[-1, 1]$.

Quando o mapa é construído pelas correlações, os pontos

$$(r_{i1}, r_{i2})$$

estão contidos no círculo unitário, pois

$$r_{i1}^2 + r_{i2}^2 \leq 1.$$

Na ACP baseada em correlações, as coordenadas $c_{R,ij}$ coincidem com as correlações $r_{R,ij}$. Nesse caso, o mapa das variáveis e o círculo de correlações utilizam as mesmas coordenadas.

No círculo de correlações, o módulo de r_{ij} quantifica a intensidade da associação linear da variável i com a componente j , enquanto $r_{i1}^2 + r_{i2}^2$ quantifica a parcela de sua variância representada pelo plano das duas primeiras componentes. Pontos próximos da circunferência possuem $\cos^2$ acumulado próximo de 1 nesse plano.

Coordenada, $\cos^2$ e contribuição descrevem aspectos distintos da representação:

- a **coordenada** determina a posição da observação ou da variável na representação;
- o $\cos^2$ quantifica a parcela de sua norma quadrática ou de sua variância representada pela dimensão ou pelo subespaço;
- a **contribuição** quantifica a participação relativa na componente: para observações, pela parcela da soma de quadrados dos escores; para variáveis, pela parcela associada ao coeficiente quadrático $\hat{\alpha}_{ij}^2$.

Os autovalores quantificam a variância das componentes, enquanto coordenadas, $\cos^2$ e contribuições descrevem, respectivamente, a posição, a qualidade de representação e a participação relativa das observações e das variáveis.

14.14.4 Elementos ativos e suplementares na ACP

Na formulação amostral, as observações e as variáveis utilizadas na construção da solução são denominadas **ativas**. As observações ativas participam do cálculo das médias, dos desvios-padrão quando há padronização e da matriz de covariâncias ou de correlações; as variáveis ativas determinam quais coordenadas são consideradas nessa matriz. A partir desses elementos são obtidos os autovalores, as direções principais e os escores das observações ativas.

Elementos que não participam dessa construção são denominados **suplementares**. Depois que a solução é determinada, observações suplementares podem ser projetadas nas direções principais, variáveis quantitativas suplementares podem ser relacionadas às componentes por correlações e categorias suplementares podem ser posicionadas pelos baricentros dos escores.

Assim, os elementos suplementares são descritos em relação a uma solução já construída e não participam da determinação dos autovalores nem das direções principais.

14.14.4.1 Observações suplementares

Considere uma nova observação

$$\mathbf{x}_* \in \mathbb{R}^p$$

que não tenha participado da construção da solução. Mantendo a média e as direções principais estimadas a partir dos elementos ativos, seu escore na componente j é

$$\hat{y}_{*j} = \hat{\alpha}_j^\top (\mathbf{x}_* - \bar{\mathbf{x}}). \quad (14.6)$$

A observação é, portanto, projetada sobre direções já determinadas. Ela recebe escores nas componentes da solução, mas não modifica

$$\hat{\lambda}_j \quad \text{nem} \quad \hat{\alpha}_j.$$

Quando a ACP é realizada sobre variáveis padronizadas, a observação suplementar deve ser centralizada e padronizada utilizando as médias e os desvios-padrão empregados na construção da solução, sem recalculá-los após sua inclusão.

Essa construção utiliza a projeção sobre um subespaço com base ortonormal desenvolvida na Proposição 3.14. Uma vez definida a base do espaço principal, outros vetores podem ser representados nessa base sem que ela precise ser novamente estimada.

14.14.4.2 Variáveis quantitativas suplementares

Uma variável quantitativa suplementar não participa da matriz utilizada para determinar as componentes principais. Depois que os escores das observações ativas são obtidos, sua relação com cada componente pode ser avaliada pela correlação

$$r_{*j} = \widehat{\text{Corr}}(X_*, Y_j),$$

desde que a variável suplementar apresente variância observada positiva.

O valor r_{*j} descreve a associação linear da variável suplementar com a componente j . Seu quadrado,

$$r_{*j}^2,$$

mede a qualidade de representação da variável suplementar nessa dimensão.

Quanto maior $|r_{*j}|$, maior a intensidade da associação linear da variável suplementar com a componente j . Essa correlação possui função descritiva e não atribui à variável suplementar participação na determinação da direção principal, que permanece definida pela matriz construída a partir das observações e variáveis ativas.

14.14.4.3 Variáveis categóricas suplementares

Uma variável categórica não integra diretamente a matriz de covariâncias ou de correlações da ACP clássica desenvolvida neste capítulo. Depois que as componentes são obtidas, suas categorias podem ser relacionadas à posição das observações no espaço principal.

Considere uma categoria g formada pelo conjunto I_g de n_g observações ativas. Com pesos iguais, sua coordenada na componente j é o baricentro dos escores das observações pertencentes à categoria,

$$\bar{y}_{gj} = \frac{1}{n_g} \sum_{i \in I_g} \hat{y}_{ij}.$$

Em uma representação pelas duas primeiras componentes, a categoria é localizada pelo ponto

$$(\bar{y}_{g1}, \bar{y}_{g2}).$$

Essa posição é determinada pelos escores médios das observações pertencentes à categoria nas dimensões representadas. Diferenças entre os baricentros descrevem diferenças entre esses escores médios; constituem um resumo descritivo e não, por si sós, um teste de diferenças entre categorias.

As coordenadas das categorias são calculadas depois da construção dos eixos. Elas não alteram os autovalores, os autovetores ou os escores das observações ativas.

Em todos os casos, os elementos suplementares são relacionados à solução após sua construção e não participam da determinação dos eixos principais.

14.14.5 Correspondência com a implementação utilizada

Nas atividades computacionais, a ACP será realizada pelo módulo [MEDA](#) (Leblay et al., 2026) do [jamovi](#) (The jamovi project, 2026). O MEDA utiliza procedimentos do pacote [FactoMineR](#) (Lê; Josse; Husson, 2008). As opções e os resultados apresentados pela implementação correspondem a objetos estatísticos distintos desenvolvidos no capítulo.

Tabela 14.6: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Scale to unit variance	escolha entre a ACP sobre variáveis padronizadas e a ACP que preserva as escalas observadas	Seção 14.10
Variáveis quantitativas ativas	variáveis que participam da determinação dos eixos principais	Seção 14.14.4
Variáveis quantitativas suplementares	variáveis relacionadas às componentes depois da construção dos eixos	Seção 14.14.4

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Variáveis categóricas suplementares	categorias representadas pelos baricentros dos escores das observações correspondentes	Seção 14.14.4
Coordenadas das observações	escores $\hat{y}_{ij}$ das componentes principais	Seção 14.14.3
Coordenadas das variáveis	coordenadas c_{ij} associadas aos eixos principais	Seção 14.14.3
$\cos^2$	qualidade de representação das observações ou das variáveis	Seção 14.13.3 e Seção 14.14.3
Contribuições	participação relativa das observações na soma de quadrados da componente e das variáveis na direção principal	Seção 14.14.3

A opção *Scale to unit variance* controla a padronização das variáveis quantitativas ativas. Quando ela está ativada, a solução corresponde à ACP baseada na matriz de correlações desenvolvida na Seção 14.10. Quando está desativada, as diferenças de escala entre as variáveis permanecem na análise e as direções principais coincidem com as obtidas pela ACP baseada em covariâncias; a diferença de convenção na escala dos autovalores é descrita a seguir.

Há uma diferença de convenção na ACP sem padronização. Neste capítulo,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Com pesos iguais para as observações, o FactoMineR utiliza a matriz

$$\mathbf{S}_{\text{FM}} = \frac{1}{n} \mathbf{X}_c^\top \mathbf{X}_c.$$

Assim,

$$\mathbf{S}_{\text{FM}} = \frac{n-1}{n} \mathbf{S}$$

e seus autovalores satisfazem

$$\hat{\lambda}_{j,\text{FM}} = \frac{n-1}{n} \hat{\lambda}_j.$$

Essa mudança de escala não altera os autovetores, os escores das observações nem as proporções de variância. As coordenadas das variáveis que dependem de $\sqrt{\hat{\lambda}_j}$ são multiplicadas por $\sqrt{(n-1)/n}$, enquanto correlações, $\cos^2$ e contribuições permanecem invariantes. Na ACP padronizada, a normalização conduz à mesma matriz de correlações $\mathbf{R}$ definida neste capítulo.

As contribuições são expressas neste capítulo como proporções que somam 1 em cada componente; a implementação apresenta as mesmas quantidades em porcentagem, multiplicadas por 100.

Para as variáveis ativas, as coordenadas c_{ij} e as correlações r_{ij} com as componentes são objetos distintos na ACP sem padronização. Quando *Scale to unit variance* está ativada, esses dois objetos coincidem, conforme discutido na Seção 14.14.3.

A padronização para variância unitária é a configuração inicial do MEDA, mas essa configuração não constitui um critério estatístico para escolher entre a ACP baseada em correlações e a ACP baseada em covariâncias. A escolha depende das escalas das variáveis e do objetivo da análise.

14.15 Síntese

A Análise de Componentes Principais constrói componentes como combinações lineares de $\mathbf{X}_c$, ordenadas segundo suas variâncias. Os vetores de coeficientes dessas combinações definem as direções principais, que podem ser escolhidas ortonormais. Para o vetor centralizado $\mathbf{X}_c$,

$$Y_j = \alpha_j^\top \mathbf{X}_c, \quad \text{Var}(Y_j) = \lambda_j,$$

em que α_j é um autovetor unitário de Σ associado ao autovalor λ_j . Como as direções principais são definidas por autovetores de Σ escolhidos ortonormais, a matriz de covariâncias das componentes é diagonal e componentes principais distintas são não correlacionadas.

A redução de dimensionalidade retém as primeiras k componentes e representa as realizações no subespaço gerado pelas direções principais correspondentes. Entre todos os subespaços de dimensão k , esse subespaço maximiza a variância total da projeção e minimiza o erro quadrático de reconstrução. Na formulação amostral, para as componentes de variância positiva, os vetores singulares à direita de $\mathbf{X}_c$ geram os mesmos subespaços que os autovetores correspondentes de $\mathbf{S}$, e os escores são obtidos por $\mathbf{U}_k \mathbf{D}_k$.

A matriz utilizada define a geometria da análise. A ACP baseada em $\mathbf{S}$ preserva as escalas e variâncias originais. A ACP baseada em $\mathbf{R}$ utiliza variáveis padronizadas e atribui variância unitária a cada uma delas.

A escolha do número de componentes não é determinada por um único critério. Autovalores, proporção acumulada de variância, gráfico de declive e interpretação das componentes fornecem informações complementares para decidir a dimensão da representação.

Os escores fornecem as coordenadas das observações nas componentes principais. Para as variáveis, os coeficientes definem as direções, as coordenadas determinam sua posição na representação e as correlações quantificam sua associação linear com as componentes. Os $\cos^2$ quantificam a qualidade de representação. As contribuições das observações correspondem à participação relativa na soma de quadrados dos escores de uma componente, enquanto as contribuições das variáveis correspondem, na convenção adotada, aos coeficientes quadráticos $\hat{\alpha}_{ij}^2$. Os elementos suplementares são relacionados à solução depois da determinação dos eixos e não participam dessa determinação.

A formulação descritiva parte da matriz de dados observada e não exige normalidade multivariada. A formulação populacional baseada em covariâncias requer momentos de segunda ordem finitos; a formulação baseada em correlações requer também variâncias marginais positivas. Sob normalidade multivariada, autovalores e direções principais podem ser tratados por métodos de estimação e inferência; resultados para direções individuais requerem condições adicionais, como autovalores populacionais distintos.

Em contraste, no Capítulo 15, a Análise Fatorial procura representar a estrutura comum de covariâncias por meio de fatores latentes e separa essa parcela da variabilidade específica de cada variável.

15 Formulação da Análise Fatorial

A Análise Fatorial representa a estrutura de covariâncias entre variáveis observadas por meio de um número menor de variáveis latentes, denominadas **fatores comuns**. No modelo ortogonal, as covariâncias entre variáveis distintas são atribuídas aos fatores comuns, enquanto a variância de cada variável é decomposta em uma parcela comum e uma parcela específica (Johnson; Wichern, 2002).

Diferentemente da ACP formulada no Capítulo 14, que constrói componentes como combinações lineares das variáveis observadas, ordenadas segundo suas variâncias, a Análise Fatorial especifica um modelo para a estrutura de covariâncias. No modelo ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi,$$

em que $\Phi\Phi^\top$ é a matriz de covariâncias comuns e Ψ é a matriz diagonal das variâncias específicas.

A formulação utiliza a matriz de covariâncias populacional definida na Definição 8.2 e a noção de posto da Definição 2.14. A normalidade multivariada não é necessária para definir a estrutura de segunda ordem do modelo; ela é requerida apenas nas formulações probabilísticas e inferenciais que dependem dessa hipótese.

Neste capítulo, a matriz de cargas fatoriais será denotada por $\Phi = (\phi_{ij})$, seguindo a notação adotada por Artes e Barroso (Artes; Barroso, 2023).

15.1 O problema da estrutura latente

Considere o vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \in \mathbb{R}^p,$$

com segundos momentos finitos, vetor de médias

$$\mu = E(\mathbf{X})$$

e matriz de covariâncias populacional Σ , definida na Definição 8.2.

Os elementos fora da diagonal de Σ registram as covariâncias entre pares de variáveis e, portanto, sua associação linear. No modelo fatorial ortogonal adotado neste capítulo, essas covariâncias são atribuídas à influência conjunta de um número menor de fatores não diretamente observados.

Considere

$$\mathbf{F} = \begin{pmatrix} F_1 \\ \vdots \\ F_m \end{pmatrix} \in \mathbb{R}^m,$$

com

$$1 \leq m < p$$

na formulação de baixa dimensão adotada neste capítulo.

As componentes de $\mathbf{F}$ são variáveis aleatórias latentes. Elas não correspondem a colunas observadas da matriz de dados. Sua existência é postulada pelo modelo para representar a estrutura de covariâncias entre as variáveis observadas.

A Análise Fatorial introduz uma estrutura latente de dimensão $m < p$ para modelar as covariâncias entre as variáveis observadas. Cada variável é representada por uma parcela associada aos fatores comuns e por uma parcela específica.

Os fatores comuns representam a parcela compartilhada da estrutura de covariâncias. Os fatores específicos representam a variabilidade de cada variável que não é atribuída aos fatores comuns. As condições que definem essa decomposição serão estabelecidas no modelo ortogonal.

15.2 Formulação do modelo de fatores comuns

O modelo básico representa o vetor observado como a soma de três parcelas:

1. localização média;
2. contribuição dos fatores comuns;
3. contribuição específica.

Definição 15.1 (Modelo de fatores comuns). Considere um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos e vetor de médias

$$\boldsymbol{\mu} = E(\mathbf{X}) .$$

Sejam

$$\mathbf{F} \in \mathbb{R}^m$$

um vetor aleatório de fatores comuns e

$$\boldsymbol{\varepsilon} \in \mathbb{R}^p$$

um vetor aleatório de fatores específicos, ambos com segundos momentos finitos e satisfazendo

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\boldsymbol{\varepsilon}) = \mathbf{0}.$$

O modelo de fatores comuns é

$$\mathbf{X} = \boldsymbol{\mu} + \boldsymbol{\Phi}\mathbf{F} + \boldsymbol{\varepsilon}, \tag{15.1}$$

em que

$$\boldsymbol{\Phi} \in \mathbb{R}^{p \times m}$$

é a matriz de cargas fatoriais.

Os elementos do modelo são organizados na Tabela [15.1](#).

Tabela 15.1: Elementos do modelo de fatores comuns.

Objeto	Dimensão	Função no modelo
$\mathbf{X}$	$p \times 1$	Vetor de variáveis observadas
$\boldsymbol{\mu}$	$p \times 1$	Vetor de médias
$\mathbf{F}$	$m \times 1$	Vetor de fatores comuns latentes

Objeto	Dimensão	Função no modelo
Φ	$p \times m$	Matriz de cargas fatoriais
ε	$p \times 1$	Vetor de fatores específicos
Ψ	$p \times p$	Matriz de covariâncias dos fatores específicos no modelo ortogonal

A i -ésima variável pode ser escrita como

$$X_i = \mu_i + \phi_{i1}F_1 + \phi_{i2}F_2 + \cdots + \phi_{im}F_m + \varepsilon_i. \quad (15.2)$$

A linha i da matriz de cargas será denotada por

$$\phi_i^\top = (\phi_{i1} \quad \cdots \quad \phi_{im}).$$

A coluna j será denotada por

$$\phi_{\cdot j} = \begin{pmatrix} \phi_{1j} \\ \vdots \\ \phi_{pj} \end{pmatrix} \in \mathbb{R}^p.$$

Assim,

$$X_i - \mu_i = \phi_i^\top \mathbf{F} + \varepsilon_i.$$

A carga ϕ_{ij} representa o coeficiente associado ao fator F_j na expressão linear da variável X_i . Sua interpretação depende da escala dos fatores, da escala das variáveis e da parametrização utilizada.

A Figura 15.1 representa a estrutura de um modelo com dois fatores e três variáveis observadas. As setas azuis representam as contribuições dos fatores comuns e as setas vermelhas representam os fatores específicos.

A figura mostra a estrutura linear postulada pelo modelo. Sob as hipóteses do modelo ortogonal estabelecidas a seguir, as covariâncias entre variáveis distintas são atribuídas à parcela comum, enquanto os fatores específicos não acrescentam covariâncias entre variáveis distintas.




Figura 15.1: Estrutura do modelo de fatores comuns: as variáveis observadas recebem contribuições dos fatores comuns e dos fatores específicos.

15.3 Hipóteses do modelo ortogonal

A expressão na Equação 15.1 ainda não determina a estrutura de covariâncias. Na parametrização ortogonal adotada neste capítulo, são impostas condições de centralização e padronização dos fatores comuns, diagonalidade da matriz de covariâncias dos fatores específicos e ausência de covariância entre as parcelas comum e específica. Essas condições são reunidas na definição a seguir.

Definição 15.2 (Modelo fatorial ortogonal). Considere o modelo de fatores comuns da Definição 15.1, com

$$E(\mathbf{F}) = \mathbf{0}$$

e

$$E(\varepsilon) = \mathbf{0}.$$

O modelo é denominado **fatorial ortogonal** quando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0,$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

A condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, atribui variância unitária a cada fator e estabelece covariâncias nulas entre fatores distintos. A ortogonalidade, nesse contexto, refere-se à estrutura de covariâncias dos fatores.

Essa padronização se refere aos **fatores latentes** e não implica que as variáveis observadas tenham variância unitária. A padronização das variáveis observadas ocorre quando o modelo é formulado a partir da matriz de correlações.

A diagonalidade de Ψ estabelece

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \forall i \neq j.$$

Consequentemente, a parcela específica do modelo não acrescenta covariância entre variáveis distintas.

A diagonalidade de Ψ estabelece **não correlação** entre fatores específicos distintos, mas não implica sua independência sem hipóteses probabilísticas adicionais. Se ε possui distribuição normal multivariada, a diagonalidade de Ψ implica independência entre seus componentes pela Proposição 9.6.

A condição

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}$$

separa, em termos de covariância, a parcela comum da parcela específica.

Essas hipóteses são suficientes para obter a estrutura de segunda ordem do modelo fatorial ortogonal. A normalidade multivariada não é necessária para essa formulação. Seu papel é retomado na seção sobre pressupostos e desenvolvido na Seção 15.14.5.

15.4 Estrutura da matriz de covariâncias

Da Equação 15.1,

$$\mathbf{X} - \mu = \Phi \mathbf{F} + \varepsilon.$$

Pelas condições de média do modelo,

$$E(\mathbf{X}) = \mu.$$

Para a matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\Phi \mathbf{F} + \varepsilon) \\ &= \Phi \text{Cov}(\mathbf{F}) \Phi^\top + \text{Cov}(\varepsilon) \\ &\quad + \Phi \text{Cov}(\mathbf{F}, \varepsilon) + \text{Cov}(\varepsilon, \mathbf{F}) \Phi^\top. \end{aligned}$$

A regra de transformação da covariância utilizada nessa expressão foi estabelecida na Proposição 8.6.

Pelas hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$\text{Cov}(\varepsilon) = \Psi$$

e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

Portanto,

$$\Sigma = \Phi\Phi^\top + \Psi. \quad (15.3)$$

Proposição 15.1 (Estrutura de covariâncias do modelo fatorial ortogonal). *Sob as hipóteses da Definição 15.2, a matriz de covariâncias de $\mathbf{X}$ é*

$$\Sigma = \Phi\Phi^\top + \Psi,$$

em que

$$\Phi\Phi^\top \succeq \mathbf{0}$$

e

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p) \succeq \mathbf{0}.$$

A matriz

$$\Phi\Phi^\top$$

é a matriz de covariâncias da parcela comum do modelo. Como

$$\Phi \in \mathbb{R}^{p \times m},$$

tem-se

$$\text{posto}(\Phi\Phi^\top) \leq m.$$

Assim, a estrutura comum é representada por uma matriz semidefinida positiva cujo posto é limitado pelo número de fatores.

A matriz

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p)$$

contém as variâncias específicas.

A decomposição

$$\Sigma = \underbrace{\Phi\Phi^\top}_{\text{estrutura comum}} + \underbrace{\Psi}_{\text{estrutura específica}}$$

explicita a diferença em relação à ACP. A Análise Fatorial não procura uma decomposição espectral completa de Σ . Ela procura representar a matriz de covariâncias por uma estrutura comum de posto reduzido acrescida de uma matriz diagonal de variâncias específicas.

15.4.1 Covariâncias entre variáveis

Considere duas variáveis distintas X_i e X_j . Pelo modelo,

$$X_i - \mu_i = \phi_i^\top \mathbf{F} + \varepsilon_i$$

e

$$X_j - \mu_j = \phi_j^\top \mathbf{F} + \varepsilon_j.$$

Sob as hipóteses do modelo fatorial ortogonal,

$$\text{Cov}(X_i, X_j) = \phi_i^\top \phi_j, \quad i \neq j.$$

Equivalentemente,

$$\sigma_{ij} = \sum_{h=1}^m \phi_{ih} \phi_{jh}, \quad i \neq j. \quad (15.4)$$

A covariância entre duas variáveis observadas é, portanto, igual ao produto interno entre seus vetores de cargas.

Esse resultado admite uma interpretação geométrica. As linhas de Φ podem ser vistas como vetores em $\mathbb{R}^m$. O sinal do produto interno entre dois vetores de cargas determina o sinal da covariância correspondente no modelo: produto interno positivo corresponde a covariância positiva, produto interno negativo corresponde a covariância negativa e ortogonalidade corresponde a covariância nula.

Essa geometria é desenvolvida na Seção 15.7.

15.4.2 Variâncias das variáveis

Para uma variável X_i ,

$$\begin{aligned}\text{Var}(X_i) &= \text{Var}(\phi_i^\top \mathbf{F} + \varepsilon_i) \\ &= \phi_i^\top \phi_i + \psi_i.\end{aligned}$$

Portanto,

$$\sigma_{ii} = \sum_{h=1}^m \phi_{ih}^2 + \psi_i. \quad (15.5)$$

A variância de cada variável é decomposta em uma parcela comum e uma parcela específica.

15.5 Comunalidades e especificidades

A decomposição da Equação 15.5 permite definir duas quantidades próprias da Análise Fatorial.

Definição 15.3 (Comunalidade). No modelo fatorial ortogonal definido na Definição 15.2, a **comunalidade** da variável X_i é

$$h_i^2 = \phi_i^\top \phi_i = \sum_{h=1}^m \phi_{ih}^2. \quad (15.6)$$

A comunalidade é a parcela da variância de X_i atribuída aos fatores comuns.

Definição 15.4 (Especificidade). No modelo fatorial ortogonal definido na Definição 15.2, a **especificidade** da variável X_i é

$$\psi_i = \text{Var}(\varepsilon_i), \quad \psi_i \geq 0.$$

Assim,

$$\text{Var}(X_i) = h_i^2 + \psi_i. \quad (15.7)$$

A comunalidade e a especificidade pertencem à decomposição da variância de **cada variável**. Elas não correspondem à decomposição da variância total em componentes sucessivamente ordenadas, como ocorre na ACP.

Quando as variáveis estão padronizadas,

$$\text{Var}(X_i) = 1,$$

e, portanto,

$$1 = h_i^2 + \psi_i. \quad (15.8)$$

Nesse caso,

$$0 \leq h_i^2 \leq 1$$

e

$$0 \leq \psi_i \leq 1.$$

Como a variância total da variável padronizada é igual a 1, a comunalidade h_i^2 também pode ser interpretada como a proporção de sua variância atribuída aos fatores comuns, enquanto ψ_i é a proporção atribuída ao fator específico.

A soma das comunalidades pode ser escrita como

$$\sum_{i=1}^p h_i^2 = \text{tr}(\Phi\Phi^\top).$$

Como

$$\text{tr}(\Sigma) = \text{tr}(\Phi\Phi^\top) + \text{tr}(\Psi),$$

a variância total também admite a decomposição

$$\text{tr}(\Sigma) = \sum_{i=1}^p h_i^2 + \sum_{i=1}^p \psi_i. \quad (15.9)$$

A interpretação dessa identidade difere daquela utilizada na ACP. Na ACP, os autovalores distribuem a variância total entre componentes principais. Na Análise Fatorial, a identidade separa a variabilidade atribuída à estrutura comum da variabilidade específica das variáveis.

Exemplo 15.1 (Modelo com um fator comum). Considere três variáveis padronizadas e centralizadas representadas por um único fator comum,

$$\mathbf{X} = \Phi F + \varepsilon,$$

com

$$\Phi = \begin{pmatrix} 0,80 \\ 0,70 \\ 0,60 \end{pmatrix}$$

e

$$\Psi = \begin{pmatrix} 0,36 & 0 & 0 \\ 0 & 0,51 & 0 \\ 0 & 0 & 0,64 \end{pmatrix}.$$

As communalidades são

$$h_1^2 = 0,80^2 = 0,64,$$

$$h_2^2 = 0,70^2 = 0,49$$

e

$$h_3^2 = 0,60^2 = 0,36.$$

Como as variáveis são padronizadas,

$$h_i^2 + \psi_i = 1$$

para cada variável.

A matriz de covariâncias comuns é

$$\Phi\Phi^{\top} = \begin{pmatrix} 0,64 & 0,56 & 0,48 \\ 0,56 & 0,49 & 0,42 \\ 0,48 & 0,42 & 0,36 \end{pmatrix}.$$

Somando as variâncias específicas,

$$\mathcal{R} = \Phi\Phi^{\top} + \Psi = \begin{pmatrix} 1 & 0,56 & 0,48 \\ 0,56 & 1 & 0,42 \\ 0,48 & 0,42 & 1 \end{pmatrix}.$$

No modelo com um fator, as correlações entre variáveis distintas são iguais ao produto das cargas correspondentes. Por exemplo,

$$\text{Corr}(X_1, X_2) = 0,80 \times 0,70 = 0,56.$$

A primeira variável apresenta comunalidade 0,64, de modo que 64% de sua variância padronizada é atribuída ao fator comum e 36% é atribuída ao fator específico. Para a terceira variável, essas parcelas são 36% e 64%, respectivamente.

O exemplo mostra que a Análise Fatorial procura representar simultaneamente as covariâncias entre as variáveis e a decomposição de suas variâncias em parcelas comum e específica.

15.6 Cargas fatoriais e associação com os fatores

A matriz Φ reúne as cargas fatoriais do modelo. Seus elementos são os coeficientes de $\mathbf{F}$ na representação de $\mathbf{X} - \mu$ e determinam a matriz de covariâncias comuns $\Phi\Phi^{\top}$.

No modelo ortogonal,

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \text{Cov}(\Phi\mathbf{F} + \varepsilon, \mathbf{F}).$$

Como

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

e

$$\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0},$$

segue que

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Phi. \quad (15.10)$$

Portanto,

$$\text{Cov}(X_i, F_j) = \phi_{ij}.$$

Essa igualdade decorre conjuntamente de $\text{Cov}(\mathbf{F}) = \mathbf{I}_m$ e $\text{Cov}(\varepsilon, \mathbf{F}) = \mathbf{0}$.

A carga fatorial coincide com a correlação entre X_i e F_j somente quando a variável observada também possui variância unitária. Se $\sigma_{ii} > 0$,

$$\text{Corr}(X_i, F_j) = \frac{\phi_{ij}}{\sqrt{\sigma_{ii}}}. \quad (15.11)$$

Para variáveis padronizadas,

$$\sigma_{ii} = 1,$$

e então

$$\text{Corr}(X_i, F_j) = \phi_{ij}.$$

Essa distinção é semelhante àquela estabelecida na Seção 14.14.2 entre os coeficientes das componentes principais e as correlações das variáveis com as componentes. Na Análise Fatorial, as cargas são parâmetros do próprio modelo de covariâncias.

A formulação construída até este ponto mostra que o problema da estrutura latente pode ser expresso por

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A fatoração $\Phi\Phi^\top$ não é única: diferentes matrizes de cargas podem gerar a mesma matriz de covariâncias comuns. Assim, as cargas individuais dependem da parametrização adotada, enquanto a estrutura comum pode permanecer inalterada.

15.7 Geometria das cargas fatoriais

No modelo ortogonal, cada linha da matriz de cargas

$$\phi_i^\top = (\phi_{i1} \quad \cdots \quad \phi_{im})$$

pode ser representada como um vetor em $\mathbb{R}^m$.

A interpretação geométrica reúne a expressão da comunalidade na Equação 15.6 e a expressão da covariância entre variáveis distintas na Equação 15.4:

$$h_i^2 = \phi_i^\top \phi_i = \|\phi_i\|^2$$

e, para $i \neq j$,

$$\sigma_{ij} = \phi_i^\top \phi_j.$$

Portanto, o quadrado da norma do vetor de cargas da variável X_i é sua comunalidade, enquanto o produto interno entre os vetores de cargas de duas variáveis é a covariância entre elas no modelo fatorial ortogonal.

Aplicando a relação entre produto interno e ângulo definida na Definição 1.11, para $\phi_i \neq \mathbf{0}$ e $\phi_j \neq \mathbf{0}$,

$$\sigma_{ij} = \phi_i^\top \phi_j = \|\phi_i\| \|\phi_j\| \cos(\theta_{ij}),$$

em que $\theta_{ij} \in [0, \pi]$ é o ângulo entre os vetores de cargas ϕ_i e ϕ_j . Assim, a covariância comum depende simultaneamente dos comprimentos dos vetores e de sua orientação relativa.

Para vetores de cargas não nulos, se $0 \leq \theta_{ij} < \pi/2$, então $\sigma_{ij} > 0$; se $\theta_{ij} = \pi/2$, então $\sigma_{ij} = 0$; e, se $\pi/2 < \theta_{ij} \leq \pi$, então $\sigma_{ij} < 0$.

A Figura 15.2 representa quatro variáveis padronizadas em um modelo com dois fatores. O quadrado do comprimento de cada vetor é a comunalidade da variável, enquanto suas coordenadas são as cargas nos dois fatores.

Os vetores de X_1 e X_2 formam um ângulo agudo e, portanto, possuem produto interno positivo. A variável X_3 apresenta carga de maior magnitude em F_2 do que em F_1 . Para X_4 , as cargas possuem sinais opostos nos dois fatores.

O círculo unitário fornece uma referência geométrica para variáveis padronizadas. Nesse caso,

$$h_i^2 \leq 1,$$




Figura 15.2: Geometria das cargas de variáveis padronizadas em um modelo com dois fatores. O quadrado do comprimento de cada vetor é a communalidade, e o produto interno entre dois vetores é a covariância correspondente.

de modo que os vetores de cargas permanecem no interior ou sobre a circunferência.

A figura representa geometricamente os vetores de cargas das variáveis. Esses vetores contêm os coeficientes que relacionam cada variável observada aos fatores latentes.

15.8 Estrutura comum de covariâncias

A estrutura fatorial comum pode ser isolada pela diferença entre a matriz total de covariâncias e a matriz de variâncias específicas.

Defina

$$\Sigma_{\text{com}} = \Sigma - \Psi.$$

Pela Equação 15.3,

$$\Sigma_{\text{com}} = \Phi\Phi^{\top}. \quad (15.12)$$

Essa matriz é a matriz de covariâncias da parcela comum do modelo. De fato, definindo

$$\mathbf{X}_{\text{com}} = \Phi\mathbf{F},$$

e utilizando

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

obtém-se

$$\text{Cov}(\mathbf{X}_{\text{com}}) = \Phi \text{Cov}(\mathbf{F})\Phi^{\top} = \Phi\Phi^{\top} = \Sigma_{\text{com}}.$$

Definição 15.5 (Matriz de covariâncias comuns). No modelo fatorial ortogonal definido na Definição 15.2, a **matriz de covariâncias comuns** é

$$\Sigma_{\text{com}} = \Phi\Phi^{\top}.$$

Seus elementos diagonais são as comunalidades e, fora da diagonal, seus elementos são as covariâncias entre as variáveis observadas especificadas pelo modelo.

A diagonal de Σ_{com} é

$$\text{diag}(\Sigma_{\text{com}}) = \begin{pmatrix} h_1^2 \\ \vdots \\ h_p^2 \end{pmatrix},$$

enquanto, para $i \neq j$,

$$(\Sigma_{\text{com}})_{ij} = \sigma_{ij}.$$

Na formulação populacional exata do modelo básico, toda covariância entre variáveis distintas é atribuída aos fatores comuns. As variâncias possuem uma parcela adicional representada por Ψ .

Quando as variáveis são padronizadas,

$$\Sigma = \mathcal{R},$$

e a matriz comum possui diagonal formada pelas comunalidades:

$$\Sigma_{\text{com}} = \mathcal{R} - \Psi.$$

Como Ψ é diagonal, Σ_{com} e $\mathcal{R}$ possuem os mesmos elementos fora da diagonal. A diferença ocorre na diagonal: os valores unitários de $\mathcal{R}$ são substituídos pelas comunalidades h_i^2 na matriz comum.

O posto da estrutura comum é limitado pelo número de fatores. Como

$$\text{posto}(\Phi\Phi^\top) \leq m,$$

a Análise Fatorial representa uma matriz de covariâncias de ordem $p \times p$ por uma parcela comum cujo posto é, no máximo, $m < p$.

Essa restrição de posto aplica-se apenas à parcela comum. A matriz total

$$\Sigma = \Sigma_{\text{com}} + \Psi$$

pode apresentar posto completo, pois a adição da matriz diagonal Ψ não preserva, em geral, o posto reduzido de Σ_{com} .

Esse ponto distingue novamente a Análise Fatorial da aproximação de posto reduzido utilizada na ACP. Uma aproximação espectral truncada de Σ produz diretamente uma matriz de posto

reduzido. No modelo fatorial, a parcela comum possui posto reduzido, enquanto Ψ mantém separadamente a variância específica de cada variável.

A Figura 15.3 representa a decomposição de uma matriz de covariâncias em sua parcela comum e sua parcela específica.




Figura 15.3: Decomposição de uma matriz de covariâncias em estrutura comum, produzida pelas cargas fatoriais, e estrutura específica diagonal.

A matriz comum contém as covariâncias entre variáveis distintas e, em sua diagonal, as communalidades. A matriz específica é diagonal e contém as variâncias específicas ψ_i . A soma dessas duas parcelas é a matriz de covariâncias Σ especificada pelo modelo.

15.9 Identificação do modelo fatorial

A equação

$$\Sigma = \Phi\Phi^{\top} + \Psi$$

não implica uma parametrização única em termos de Φ e Ψ .

Na formulação de segunda ordem desenvolvida até aqui, a identificação diz respeito aos parâmetros ou estruturas associados a Φ e Ψ que são determinados de forma única por Σ . Se o vetor observado for modelado por uma distribuição normal multivariada, sua distribuição será determinada por μ e Σ , de modo que a identificação dos parâmetros de covariância continuará dependente da decomposição de Σ . Essa formulação probabilística é desenvolvida na Seção 15.14.5.

Antes da imposição de restrições de parametrização, escala, sinal e orientação dos eixos fatoriais não são determinados pela representação latente. No modelo ortogonal adotado neste capítulo, a condição $\text{Cov}(\mathbf{F}) = \mathbf{I}_m$ fixa a escala dos fatores, enquanto permanecem as indeterminações de sinal e de orientação.

15.9.1 Escala dos fatores

Considere, inicialmente, um único fator:

$$\mathbf{X} = \mu + \Phi F + \varepsilon.$$

Para qualquer constante não nula c ,

$$\Phi F = (c\Phi) \left(\frac{F}{c} \right).$$

Logo, sem uma restrição adicional, a escala do vetor de cargas e a escala do fator podem ser modificadas inversamente sem alterar a parcela comum do modelo.

No modelo ortogonal padronizado, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a variância de cada fator e remove essa indeterminação de escala.

15.9.2 Indeterminação do sinal

Se uma coluna de Φ e o fator correspondente tiverem seus sinais invertidos simultaneamente, o produto permanece inalterado.

Para o fator F_j ,

$$\phi_{.j} F_j = (-\phi_{.j}) (-F_j).$$

Portanto, o sinal de um fator não é determinado pelo modelo.

Essa propriedade é análoga à indeterminação de sinal dos autovetores na ACP. No modelo fatorial, a inversão simultânea do sinal de uma coluna de Φ e do fator correspondente preserva o produto $\Phi\mathbf{F}$ e, portanto, a distribuição observável especificada pelo modelo.

15.9.3 Indeterminação rotacional

Quando

$$m \geq 2,$$

existem transformações ortogonais que modificam conjuntamente a orientação dos eixos fatoriais sem alterar a estrutura comum de covariâncias.

Assim, a matriz de covariâncias não determina uma orientação única para os eixos fatoriais.

A invariância da estrutura comum sob essas transformações é demonstrada na Seção 15.14.1.

15.10 Rotação dos eixos fatoriais

A rotação modifica as coordenadas das cargas em relação aos eixos fatoriais. Uma rotação ortogonal preserva a matriz de covariâncias comuns e, mantendo Ψ , preserva também a matriz de covariâncias especificada pelo modelo.

A Figura 15.4 compara uma matriz de cargas com uma solução obtida por uma rotação ortogonal. Para fins ilustrativos, aplica-se uma transformação ortogonal correspondente a uma rotação de 35° . Esse valor não corresponde a um critério específico de rotação: em uma aplicação, a orientação é determinada pelo critério adotado. Os vetores mudam de coordenadas em relação aos eixos, mas seus comprimentos e produtos internos são preservados.

A rotação ortogonal altera as cargas individuais, mas preserva as comunalidades e a matriz de covariâncias comuns. Em consequência, preserva também a soma das comunalidades, enquanto as somas de quadrados das cargas associadas a cada fator podem mudar.

As demonstrações dessas propriedades são apresentadas na Seção 15.14.2.

Assim, os fatores rotacionados não possuem uma ordenação intrínseca por variância comparável à ordenação das componentes principais.

A estimação e a rotação cumprem funções distintas. A estimação obtém uma solução fatorial segundo determinado critério; a rotação transforma as cargas dessa solução sem constituir um novo método de extração ou estimação. Seu objetivo é favorecer uma **estrutura simples**, na qual cada variável apresente cargas concentradas em poucos fatores e cargas pequenas nos demais.




Figura 15.4: Uma rotação ortogonal modifica as coordenadas das cargas, mas preserva comprimentos, produtos internos, communalidades e a matriz de covariâncias comuns.

15.10.1 Rotações ortogonais

Nas rotações ortogonais, os fatores permanecem não correlacionados. Em uma solução com dois fatores, a transformação pode ser visualizada como uma rotação dos eixos por determinado ângulo θ . Esse ângulo não é fixado previamente: a orientação resulta do critério de rotação adotado. Os eixos permanecem perpendiculares entre si, formando 90° . Com mais de dois fatores, uma transformação ortogonal não é descrita, em geral, por um único ângulo.

Diferentes critérios podem selecionar orientações ortogonais distintas que favoreçam uma estrutura simples. Em todas elas, os fatores permanecem não correlacionados e a matriz de covariâncias comuns permanece inalterada. Alguns critérios específicos são apresentados na Seção 15.15.4.

15.10.2 Rotações oblíquas

A hipótese de fatores não correlacionados pode ser excessivamente restritiva. Quando não há razão para impor covariâncias nulas entre os fatores, podem ser utilizadas **rotações oblíquas**.

Um **modelo com fatores correlacionados** e uma **rotação oblíqua** são conceitos relacionados, mas distintos. O primeiro admite uma matriz de covariâncias fatoriais diferente da identidade. A rotação oblíqua é uma transformação não ortogonal aplicada a uma solução fatorial; na

representação resultante, os fatores podem ser correlacionados e sua matriz de covariâncias passa a integrar explicitamente a estrutura comum.

Denote por

$$\Omega = \text{Cov}(\mathbf{F})$$

a matriz de covariâncias dos fatores. Quando os fatores possuem variâncias unitárias,

$$\text{diag}(\Omega) = \mathbf{1},$$

e Ω é a matriz de correlações fatoriais.

No modelo ortogonal,

$$\Omega = \mathbf{I}_m,$$

enquanto, em uma solução oblíqua,

$$\Omega \neq \mathbf{I}_m$$

em geral.

A matriz de covariâncias das variáveis passa então a ser escrita como

$$\Sigma = \Phi\Omega\Phi^\top + \Psi. \quad (15.13)$$

A parcela comum é, portanto,

$$\Sigma_{\text{com}} = \Phi\Omega\Phi^\top.$$

Consequentemente, na solução oblíqua a comunalidade da variável i corresponde ao i -ésimo elemento diagonal dessa matriz:

$$h_i^2 = (\Phi\Omega\Phi^\top)_{ii}.$$

Quando $\Omega = \mathbf{I}_m$, recupera-se o resultado do modelo ortogonal,

$$h_i^2 = \sum_{j=1}^m \phi_{ij}^2.$$

A matriz Φ contém os coeficientes que relacionam diretamente os fatores às variáveis no modelo e, em uma solução oblíqua, é denominada **matriz de padrões**.

A covariância entre as variáveis observadas e os fatores é

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = \Phi\Omega.$$

Denotando

$$\Phi_\Omega = \Phi\Omega, \quad (15.14)$$

obtém-se a denominada **matriz de estrutura**. Na formulação em que variáveis e fatores possuem variâncias unitárias, seus elementos correspondem às correlações entre as variáveis observadas e os fatores.

Assim, em uma solução oblíqua devem ser distinguidos três objetos:

- a **matriz de padrões** Φ , formada pelos coeficientes do modelo;
- a **matriz de correlações fatoriais** Ω ;
- a **matriz de estrutura** $\Phi_\Omega = \Phi\Omega$, que descreve as associações entre variáveis e fatores.

No caso ortogonal,

$$\Omega = \mathbf{I}_m,$$

de modo que

$$\Phi_\Omega = \Phi.$$

Por isso, a distinção entre matriz de padrões e matriz de estrutura desaparece quando os fatores são ortogonais.

Diferentes critérios também podem ser utilizados para selecionar uma orientação oblíqua. Alguns deles são apresentados na Seção [15.15.4](#).

A escolha entre rotação ortogonal e oblíqua define a estrutura permitida para as correlações entre os fatores. Na solução ortogonal, essas correlações são fixadas em zero. Na solução oblíqua, elas podem ser diferentes de zero.

A decisão deve considerar se a hipótese de fatores não correlacionados é adequada ao problema analisado. A aparência das cargas, isoladamente, não determina a forma de rotação.

A avaliação da adequação da matriz de correlações à estrutura fatorial é tratada na Seção [15.15.1](#).

15.11 Formulação populacional e amostral

No nível populacional, o modelo fatorial especifica uma estrutura para a matriz de covariâncias. No modelo ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi.$$

Os elementos de Φ e as variâncias específicas de Ψ compõem a parametrização populacional da estrutura de covariâncias.

15.11.1 O problema de estimação

No nível amostral, a matriz de covariâncias ou de correlações observada fornece a informação utilizada para estimar a estrutura fatorial. Diferentes métodos utilizam critérios distintos para obter estimativas dessa estrutura (Johnson; Wichern, 2002).

O método de fatores principais utiliza uma construção espectral baseada em uma matriz reduzida, cuja diagonal contém comunalidades estimadas. Outros métodos definem a estimação por meio de uma função de discrepância entre a matriz observada e a matriz reproduzida pelo modelo.

Para uma análise baseada em covariâncias, essa segunda classe pode ser representada genericamente por

$$\min_{\theta} d[\mathbf{S}, \Sigma(\theta)], \quad (15.15)$$

em que θ reúne os parâmetros livres do modelo e

$$\Sigma(\theta) = \Phi\Phi^\top + \Psi$$

é a matriz de covariâncias implicada pelo modelo para um determinado valor de θ .

A função

$$d[\mathbf{S}, \Sigma(\theta)]$$

associa à matriz amostral $\mathbf{S}$ e à matriz implicada pelo modelo $\Sigma(\theta)$ um valor numérico de discrepância. Para a amostra observada, a estimação é realizada sobre os valores admissíveis de θ . Um valor minimizante $\hat{\theta}$ constitui uma estimativa dos parâmetros livres na parametrização adotada, e $\Sigma(\hat{\theta})$ é a matriz de covariâncias implicada pela solução ajustada. A distinção entre estimador e estimativa segue a Definição 10.4.

Quando a análise é baseada em correlações, o critério compara a matriz amostral $\mathbf{R}$ com a matriz de correlações implicada pelo modelo para as variáveis padronizadas.

O critério de estimação compara a estrutura de segunda ordem observada com aquela implicada pelo modelo. No caso ortogonal, transformações das cargas que preservam $\Phi\Phi^\top$ produzem o mesmo ajuste da estrutura de covariâncias e, portanto, o critério não distingue essas orientações. A rotação tratada na Seção 15.10 seleciona uma representação das cargas para interpretação.

Neste capítulo são considerados três métodos para obter uma solução fatorial. O método de **fatores principais** utiliza a decomposição espectral de uma matriz reduzida cuja diagonal contém comunalidades estimadas. O método de **mínimos resíduos** (MINRES) estima a estrutura fatorial pela minimização de um critério de discrepância entre associações observadas e implicadas pelo modelo. Sob normalidade multivariada, a **máxima verossimilhança** estima os parâmetros a partir da função de verossimilhança do modelo probabilístico.

Os métodos de fatores principais e mínimos resíduos são desenvolvidos na Seção 15.14.4. A máxima verossimilhança é desenvolvida na Seção 15.14.5.

15.11.2 Escores fatoriais

Os fatores comuns aparecem no modelo como variáveis latentes,

F.

Eles não são observados diretamente. Essa situação difere da ACP, em que o escore definido na Definição 14.1 é obtido pela projeção da observação sobre uma direção principal determinada pela solução.

Na Análise Fatorial, é necessário acrescentar um critério para relacionar uma observação aos fatores latentes. Esse é o **problema dos escores fatoriais** (Johnson; Wichern, 2002).

Considere uma observação

$$\mathbf{x} \in \mathbb{R}^p.$$

Depois que uma solução fatorial é especificada ou ajustada, pode-se calcular, a partir de $\mathbf{x}$, um valor associado a cada fator. Dependendo do tratamento dos fatores e do critério adotado, esse valor é interpretado como estimativa ou predição da realização latente dos fatores e é denominado **escore fatorial**.

Definição 15.6 (Escore fatorial). Um **escore fatorial** é um vetor calculado a partir das variáveis observadas e de uma solução fatorial para estimar ou prever a realização dos fatores associada a uma unidade. No modelo com fatores aleatórios adotado neste capítulo, sua interpretação probabilística é a de uma predição dessa realização.

A Tabela 15.2 sintetiza as funções distintas desempenhadas pelos fatores, pelas cargas e pelos escores fatoriais.

Tabela 15.2: Distinção entre fatores, cargas e escores fatoriais.

Objeto	Natureza
$\mathbf{F}$	Vetor aleatório latente especificado pelo modelo
Φ	Matriz de parâmetros que relaciona fatores e variáveis
$\mathbf{f}_i$	Realização latente dos fatores associada à unidade i , não diretamente observada
$\hat{\mathbf{f}}_i$	Escore utilizado para estimar ou prever $\mathbf{f}_i$

As cargas fatoriais são parâmetros da estrutura do modelo, enquanto os escores são quantidades associadas às unidades observacionais.

Mesmo com uma solução fatorial fixada, em geral a observação não determina univocamente a realização latente dos fatores, pois o modelo inclui também a parcela específica. A obtenção de $\hat{\mathbf{f}}_i$ exige, portanto, um critério adicional de estimação ou predição, e critérios distintos podem produzir escores diferentes para a mesma unidade (Johnson; Wichern, 2002).

Os escores dependem da orientação adotada para os fatores. Quando a solução fatorial é transformada, os escores correspondentes devem ser expressos na mesma parametrização. Em uma rotação ortogonal $\Phi^* = \Phi\mathbf{Q}$, por exemplo, as coordenadas fatoriais transformam-se por $\mathbf{f}_i^* = \mathbf{Q}^\top \mathbf{f}_i$. Assim, os valores dos escores são interpretados em relação à orientação da solução correspondente.

A interpretação probabilística do escore por regressão é desenvolvida na Seção 15.14.7. Outros métodos são apresentados na Seção 15.15.5.

15.12 Pressupostos e limites do modelo

Os aspectos que condicionam a Análise Fatorial possuem funções diferentes. Alguns definem o modelo de fatores comuns. Outros correspondem a restrições dos parâmetros, condições de identificação, escolhas de especificação ou hipóteses necessárias para procedimentos probabilísticos específicos.

A Tabela 15.3 organiza essas diferenças.

Tabela 15.3: Pressupostos, condições e limites da formulação fatorial.

Aspecto	Natureza	Papel na formulação
Linearidade	Hipótese definidora	As variáveis observadas são representadas linearmente pelos fatores comuns e pelos fatores específicos
Estrutura comum de baixa dimensão	Especificação estrutural	A parcela comum da matriz de covariâncias é representada por $m < p$ fatores
Diagonalidade de Ψ	Hipótese definidora	Fatores específicos associados a variáveis distintas possuem covariância nula
Não correlação entre fatores comuns e específicos	Hipótese definidora	Separa, em termos de covariância, as parcelas comum e específica
Identificação	Condição do modelo	Determina quais aspectos de Φ e Ψ são definidos univocamente por Σ sob a parametrização e as restrições adotadas
Admissibilidade	Restrição paramétrica	As variâncias específicas devem satisfazer $\psi_i \geq 0$; soluções que violem essa restrição não são admissíveis no modelo fatorial básico
Normalidade	Hipótese probabilística adicional	Não é necessária para o modelo de segunda ordem; integra o modelo fatorial normal e sustenta a verossimilhança normal e resultados inferenciais correspondentes
Número de fatores	Escolha de especificação	Determina a dimensão da estrutura comum e a classe de matrizes de covariâncias representáveis
Conjunto e escala das variáveis	Dependência da análise	Alterações nas variáveis ou em suas escalas modificam a estrutura de covariâncias ou correlações modelada

15.12.1 Número de fatores

O número m determina a dimensão máxima da estrutura comum e a classe de matrizes de covariâncias que o modelo pode representar. Diminuir m restringe o posto de $\Phi\Phi^\top$ e a classe de estruturas comuns representáveis; aumentar m amplia essa classe.

Um número insuficiente de fatores pode deixar padrões sistemáticos de covariância sem representação pela parcela comum. Um número excessivo reduz a parcimônia e pode produzir fatores com pouca utilidade interpretativa.

O número m integra a especificação do modelo. Os critérios utilizados para sua escolha são apresentados na Seção [15.15.2](#).

15.12.2 Dependência do conjunto e da escala das variáveis

A estrutura fatorial é definida em relação às variáveis incluídas no modelo. Adicionar, retirar ou transformar variáveis modifica a matriz de covariâncias ou correlações e pode alterar a solução.

Uma análise baseada em covariâncias também depende das escalas marginais. A utilização da matriz de correlações remove essas diferenças de escala antes do ajuste, mas define outra estrutura de segunda ordem. A mesma distinção entre covariâncias e correlações foi desenvolvida para a ACP na Seção [14.10](#).

15.12.3 Papel da normalidade

A decomposição

$$\Sigma = \Phi\Phi^\top + \Psi$$

é uma estrutura de segunda ordem e não exige normalidade multivariada.

A normalidade é uma hipótese probabilística adicional ao modelo de segunda ordem. Quando se especifica uma distribuição normal conjunta para os fatores comuns e específicos, podem ser desenvolvidos a máxima verossimilhança, a distribuição condicional dos fatores e resultados inferenciais baseados nessa hipótese. Essa formulação é apresentada na Seção [15.14.5](#).

15.13 Análise Fatorial e Análise de Componentes Principais

A Análise de Componentes Principais, formulada no Capítulo 14, e a Análise Fatorial resolvem problemas estatísticos distintos. A ACP constrói componentes como combinações lineares das variáveis observadas, ordenadas segundo suas variâncias. A Análise Fatorial especifica um modelo latente para a estrutura de covariâncias entre as variáveis observadas.

As duas técnicas podem utilizar matrizes de covariâncias ou de correlações, e decomposições espectrais aparecem em algumas de suas formulações. Essas semelhanças algébricas não tornam equivalentes os objetos estatísticos representados.

Na ACP,

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top,$$

em que as colunas de $\mathbf{A}$ são os autovetores unitários $\alpha_1, \dots, \alpha_p$ e os elementos diagonais de $\mathbf{\Lambda}$ são os autovalores.

No modelo fatorial ortogonal,

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A Tabela 15.4 reúne as diferenças principais.

Tabela 15.4: Diferenças matemáticas e estatísticas entre ACP e Análise Fatorial.

Aspecto	ACP	Análise Fatorial
Problema	Reduzir a dimensão preservando a maior variância possível nas componentes retidas	Modelar as covariâncias por fatores latentes e variâncias específicas
Objeto populacional	Σ ou $\mathcal{R}$	Σ ou $\mathcal{R}$
Estrutura definidora	Decomposição espectral da matriz analisada	Modelo de fatores comuns
Formulação ortogonal	$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top$	$\Sigma = \Phi\Phi^\top + \Psi$
Variabilidade considerada	Variância total	Variância comum separada da específica
Objetos de menor dimensão	Componentes definidas como combinações lineares das variáveis observadas	Fatores latentes especificados pelo modelo
Coefficientes	Autovetores α_j	Cargas fatoriais ϕ_{ij}

Aspecto	ACP	Análise Fatorial
Escores	Coordenadas das observações nas componentes principais	Valores calculados para estimar ou prever as realizações dos fatores associadas às observações
Não unicidade	Sinal; com autovalores repetidos, bases dos autoespaços e, quando o corte atravessa um autovalor múltiplo, o subespaço truncado	Após fixada a escala, sinal e orientação rotacional; a identificação pode exigir restrições adicionais
Normalidade	Não necessária para definir a técnica	Não necessária para o modelo de segunda ordem; adicionada na formulação probabilística normal e nos procedimentos que dependem dessa hipótese

A presença de autovalores e autovetores em alguns métodos de estimação fatorial não torna esses procedimentos equivalentes à ACP. Na ACP, os autovetores da matriz analisada definem as direções principais e os autovalores são as variâncias das componentes correspondentes. Na Análise Fatorial, decomposições espectrais podem ser utilizadas em métodos de estimação da estrutura comum, que permanece inserida no modelo

$$\Sigma = \Phi\Phi^{\top} + \Psi.$$

A parcela

$$\Phi\Phi^{\top}$$

é a matriz de covariâncias comuns, enquanto a matriz diagonal Ψ contém as variâncias específicas das variáveis.

Neste capítulo, o modelo de fatores comuns é estudado no contexto da **Análise Fatorial Exploratória**, em que a estrutura das cargas não é completamente especificada antes do ajuste. A Análise Fatorial Confirmatória, em que restrições sobre a estrutura fatorial são especificadas previamente a partir de um modelo de mensuração, não integra o escopo deste capítulo.

15.14 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte reúne desenvolvimentos sobre identificação, invariâncias e critérios de rotação, fatores principais e mínimos resíduos, formulação probabilística, máxima verossimilhança, distribuições associadas à avaliação da matriz de correlações e propriedades dos métodos de escores fatoriais.

15.14.1 Contagem de parâmetros e identificação

No modelo ortogonal adotado neste capítulo, a condição

$$\text{Cov}(\mathbf{F}) = \mathbf{I}_m$$

fixa a escala dos fatores, mas permanece a indeterminação associada à orientação dos eixos fatoriais. Diferentes matrizes de cargas podem representar a mesma estrutura de covariâncias (Anderson, 2003).

A contagem de parâmetros apresentada nesta seção fornece uma condição necessária de compatibilidade dimensional entre a parametrização e os elementos distintos de Σ em pontos regulares. Ela não constitui, isoladamente, uma condição suficiente de identificação.

15.14.1.1 Desenvolvimento matricial da indeterminação rotacional

A não unicidade da orientação dos fatores pode ser estabelecida formalmente por transformações da matriz de cargas e do vetor de fatores (Anderson, 2003).

Quando

$$m \geq 2,$$

a indeterminação da orientação inclui uma família contínua de transformações ortogonais.

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{m \times m},$$

definida na Definição 2.18, de modo que

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{Q} \mathbf{Q}^\top = \mathbf{I}_m.$$

Defina

$$\Phi^* = \Phi \mathbf{Q}$$

e

$$\mathbf{F}^* = \mathbf{Q}^\top \mathbf{F}.$$

Então,

$$\begin{aligned}\Phi^* \mathbf{F}^* &= \Phi \mathbf{Q} \mathbf{Q}^\top \mathbf{F} \\ &= \Phi \mathbf{F}.\end{aligned}$$

Além disso,

$$\begin{aligned}\text{Cov}(\mathbf{F}^*) &= \mathbf{Q}^\top \text{Cov}(\mathbf{F}) \mathbf{Q} \\ &= \mathbf{Q}^\top \mathbf{Q} \\ &= \mathbf{I}_m.\end{aligned}$$

Os fatores transformados permanecem padronizados e mutuamente não correlacionados.

Para a matriz de covariâncias comuns,

$$\begin{aligned}\Phi^* \Phi^{*\top} &= \Phi \mathbf{Q} \mathbf{Q}^\top \Phi^\top \\ &= \Phi \Phi^\top.\end{aligned}$$

Portanto,

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top. \quad (15.16)$$

Proposição 15.2 (Indeterminação rotacional do modelo fatorial ortogonal). *Considere um modelo fatorial ortogonal com*

$$\Phi \in \mathbb{R}^{p \times m}$$

e seja

$$\mathbf{Q} \in \mathbb{R}^{m \times m}$$

qualquer matriz ortogonal. Então a matriz de cargas

$$\Phi^* = \Phi Q$$

produz a mesma matriz de covariâncias comuns:

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top.$$

Além disso, com

$$\mathbf{F}^* = Q^\top \mathbf{F},$$

a parcela comum do modelo é preservada e

$$\text{Cov}(\mathbf{F}^*) = \mathbf{I}_m.$$

Assim, a estrutura de covariâncias do modelo não determina uma orientação ortogonal única para os fatores.

A invariância na Equação 15.16 utiliza diretamente a preservação do produto interno estabelecida no Teorema 2.7.

A Proposição 15.2 demonstra a não unicidade da orientação dos fatores: transformações ortogonais de Φ preservam $\Phi \Phi^\top$. Essa invariância não implica, entretanto, que $\Phi \Phi^\top$ e Ψ sejam identificáveis de forma única a partir de Σ ; essa questão depende de condições adicionais de identificação.

15.14.1.2 Contagem de parâmetros

A matriz simétrica Σ possui

$$\frac{p(p+1)}{2}$$

elementos distintos.

No modelo ortogonal com m fatores, a matriz de cargas possui

$$pm$$

elementos e a matriz diagonal Ψ possui

$$p$$

variâncias específicas.

Uma contagem direta produz

$$pm + p$$

parâmetros. Essa parametrização contém diferentes matrizes de cargas relacionadas por transformações ortogonais que representam a mesma matriz de covariâncias.

Em um ponto regular com

$$\text{posto}(\Phi) = m,$$

as transformações ortogonais possuem

$$\frac{m(m-1)}{2}$$

graus de liberdade contínuos. Inversões de sinal também produzem representações equivalentes, mas constituem uma indeterminação discreta e não alteram a dimensão local da parametrização.

Descontando os graus de liberdade contínuos associados à indeterminação rotacional, obtém-se a contagem dimensional

$$pm + p - \frac{m(m-1)}{2}. \quad (15.17)$$

Uma condição necessária de contagem é, portanto,

$$pm + p - \frac{m(m-1)}{2} \leq \frac{p(p+1)}{2}. \quad (15.18)$$

Essa desigualdade compara o número de elementos distintos de Σ com a contagem dimensional da parametrização após descontar a indeterminação rotacional. Ela é uma condição necessária de contagem em pontos regulares.

Sob regularidade e identificação local, a diferença entre o número de elementos distintos de Σ e essa contagem dimensional corresponde ao número de restrições independentes utilizado nos graus de liberdade do teste de ajuste por máxima verossimilhança, definidos na Equação 15.35.

A contagem de parâmetros não garante identificação

Satisfazer a condição de contagem da Equação 15.18 não garante identificação do modelo. A identificação depende também da estrutura das cargas, das restrições impostas e da posição do parâmetro no espaço paramétrico.

Uma parametrização identificada exige restrições que eliminem as representações equivalentes relevantes para o problema considerado. Essas restrições podem atuar sobre as cargas ou sobre a orientação dos fatores (Anderson, 2003).

Na Análise Fatorial Exploratória, restrições de identificação permitem obter uma parametrização inicial; posteriormente, uma rotação pode selecionar uma orientação equivalente das cargas para interpretação. Na Análise Fatorial Confirmatória, restrições sobre a estrutura das cargas são especificadas antes do ajuste e participam diretamente da identificação do modelo.

As condições algébricas de identificação dependem da estrutura imposta ao modelo e das restrições adotadas na parametrização.

15.14.2 Invariâncias da rotação ortogonal

Considere a matriz de cargas rotacionada

$$\Phi^* = \Phi \mathbf{Q},$$

com $\mathbf{Q}$ ortogonal.

Para a variável i , a linha correspondente da matriz rotacionada é

$$\phi_i^{*\top} = \phi_i^\top \mathbf{Q}.$$

A comunalidade permanece inalterada porque

$$\begin{aligned} \|\phi_i^*\|^2 &= \phi_i^\top \mathbf{Q} \mathbf{Q}^\top \phi_i \\ &= \|\phi_i\|^2. \end{aligned}$$

Para duas variáveis i e j ,

$$\begin{aligned} \phi_i^{*\top} \phi_j^* &= \phi_i^\top \mathbf{Q} \mathbf{Q}^\top \phi_j \\ &= \phi_i^\top \phi_j. \end{aligned}$$

As covariâncias comuns permanecem, portanto, inalteradas. Esse resultado é a versão elemento a elemento da invariância matricial estabelecida na Equação 15.16.

A variância comum total também é preservada:

$$\begin{aligned}\text{tr}(\Phi^* \Phi^{*\top}) &= \text{tr}(\Phi \Phi^\top) \\ &= \sum_{j=1}^m \|\phi_{\cdot j}\|^2.\end{aligned}$$

A soma dos quadrados das cargas associadas a um fator pode mudar após a rotação. Em geral,

$$\sum_{i=1}^p \phi_{ij}^{*2} \neq \sum_{i=1}^p \phi_{ij}^2.$$

Assim, a rotação preserva $\Phi \Phi^\top$ e a soma das comunalidades, mas pode alterar as somas de quadrados das cargas atribuídas a cada fator.

15.14.3 Critérios de rotação como problemas de otimização

A indeterminação rotacional permite escolher, entre representações equivalentes da estrutura comum, uma orientação que favoreça determinado padrão das cargas. Um critério de rotação formaliza essa escolha por meio de uma função objetivo. Nas rotações ortogonais, a matriz de cargas rotacionada é

$$\Phi^* = \Phi \mathbf{Q},$$

com $\mathbf{Q}$ ortogonal. A estrutura comum permanece inalterada, conforme estabelecido na Seção 15.14.2, mas os elementos de Φ^* dependem da orientação escolhida.

15.14.3.1 Varimax

O critério Varimax procura aumentar a dispersão dos quadrados das cargas dentro de cada fator (Kaiser, 1958).

Na forma normalizada de Kaiser, para uma variável com comunalidade $h_i^2 > 0$, defina

$$\tilde{\phi}_{ij}^* = \frac{\phi_{ij}^*}{\sqrt{h_i^2}}.$$

O critério pode ser escrito como

$$v_{\text{Varimax}} = \sum_{j=1}^m \left[\frac{1}{p} \sum_{i=1}^p (\tilde{\phi}_{ij}^*)^4 - \left(\frac{1}{p} \sum_{i=1}^p (\tilde{\phi}_{ij}^*)^2 \right)^2 \right]. \quad (15.19)$$

A orientação é escolhida para maximizar v_{Varimax} . Para cada fator, a expressão entre colchetes mede a dispersão dos quadrados das cargas normalizadas. A maximização favorece colunas nas quais algumas cargas apresentam magnitude elevada e outras se aproximam de zero.

Como a rotação ortogonal preserva h_i^2 , a normalização produz

$$\sum_{j=1}^m (\tilde{\phi}_{ij}^*)^2 = 1.$$

Assim, cada vetor de cargas normalizadas possui norma unitária, e o critério depende da distribuição relativa das cargas da variável entre os fatores, e não da magnitude de sua comunalidade.

15.14.3.2 Quartimax

O Quartimax procura uma orientação em que, para cada variável, poucos termos $(\phi_{ij}^*)^2$ concentrem a comunalidade h_i^2 (Lawley; Maxwell, 1971). Um critério equivalente, sob rotação ortogonal, consiste em maximizar

$$v_{\text{Quartimax}} = \sum_{i=1}^p \sum_{j=1}^m (\phi_{ij}^*)^4. \quad (15.20)$$

Como a rotação ortogonal preserva

$$h_i^2 = \sum_{j=1}^m (\phi_{ij}^*)^2,$$

a maximização das quartas potências favorece a concentração dessa magnitude em poucas cargas de cada linha.

Aplicados à mesma solução inicial, Varimax e Quartimax preservam a mesma estrutura comum, mas selecionam orientações diferentes segundo suas respectivas funções objetivo.

15.14.3.3 Oblimin

Nas rotações oblíquas, a orientação é escolhida sem exigir que os fatores permaneçam ortogonais. Denote por

$$\mathbf{B} = (b_{ij})$$

uma matriz de padrões candidata na parametrização oblíqua apresentada na Seção 15.10.

A família *direct oblimin* utiliza uma função de simplicidade aplicada diretamente aos elementos da matriz de padrões $\mathbf{B}$. Uma forma usual do critério pode ser escrita como (Jennrich, 1979; Jennrich; Sampson, 1966)

$$g_{\gamma}(\mathbf{B}) = \sum_{1 \leq j < k \leq m} \left[\sum_{i=1}^p b_{ij}^2 b_{ik}^2 - \frac{\gamma}{p} \left(\sum_{i=1}^p b_{ij}^2 \right) \left(\sum_{i=1}^p b_{ik}^2 \right) \right], \quad (15.21)$$

que é minimizado em relação à orientação oblíqua admissível.

O parâmetro γ modifica a forma do critério. Para $\gamma = 0$, obtém-se o critério Quartimin. A minimização procura reduzir a presença simultânea de coeficientes de padrão de grande magnitude para uma mesma variável em vários fatores, sem impor correlações fatoriais nulas.

15.14.3.4 Promax

O Promax utiliza uma estratégia de aproximação a uma matriz-alvo (Hendrickson; White, 1964). Considere uma matriz de cargas obtida após uma rotação ortogonal, denotada por

$$\Phi^{(0)}.$$

Para $\kappa > 1$, constrói-se uma matriz-alvo cujos elementos são

$$\phi_{ij}^{(\kappa)} = \text{sign}(\phi_{ij}^{(0)}) \left| \phi_{ij}^{(0)} \right|^{\kappa}. \quad (15.22)$$

A transformação por potência amplia o contraste entre cargas maiores e menores. Em seguida, procura-se uma transformação oblíqua não singular $\mathbf{G}$ que aproxime a matriz-alvo, por um problema do tipo

$$\min_{\mathbf{G}} \left\| \Phi^{(0)} \mathbf{G} - \Phi^{(\kappa)} \right\|_F^2. \quad (15.23)$$

A solução resultante é normalizada de acordo com a parametrização adotada para os fatores. Diferentemente de Varimax e Quartimax, a transformação do Promax não é restrita à classe das transformações ortogonais.

Os critérios de rotação definem como uma orientação é selecionada entre representações admissíveis da estrutura comum. Suas consequências para a escolha e a interpretação da solução são tratadas na Seção 15.15.4.

15.14.4 Fatores principais e mínimos resíduos

Fatores principais e mínimos resíduos utilizam critérios distintos para obter uma solução fatorial. O método de fatores principais constrói sucessivamente uma matriz reduzida com communalidades estimadas na diagonal e aplica a ela uma decomposição espectral. O MINRES determina as cargas pela minimização dos resíduos entre associações observadas e reproduzidas.

Os dois métodos procuram estimar a estrutura comum, mas utilizam critérios distintos (Johnson; Wichern, 2002).

15.14.4.1 Fatores principais

O método de **fatores principais**, também denominado **método dos eixos principais** (*principal axis factoring*, PAF), utiliza uma decomposição espectral de uma matriz construída para representar a parcela comum da estrutura de covariâncias ou correlações (Johnson; Wichern, 2002).

Fatores ou eixos principais não são componentes principais. As duas técnicas utilizam autovaleores e autovetores, mas os aplicam a objetos estatísticos diferentes.

Na ACP, os autovetores da matriz de covariâncias ou de correlações definem as direções principais, e os autovalores são as variâncias das componentes correspondentes. No método dos fatores principais, a decomposição espectral é aplicada a uma matriz reduzida, cuja diagonal contém communalidades estimadas.

No nível populacional, para o modelo ortogonal,

$$\Sigma_{\text{com}} = \Sigma - \Psi = \Phi\Phi^{\top}.$$

Como

$$\text{posto}(\Sigma_{\text{com}}) \leq m,$$

um modelo com m fatores representa a estrutura comum por uma matriz de posto não superior a m .

Na aplicação amostral baseada em correlações, as comunalidades são desconhecidas. O procedimento parte de estimativas iniciais

$$\hat{h}_1^2, \dots, \hat{h}_p^2$$

e substitui a diagonal unitária de $\mathbf{R}$ por esses valores, formando a denominada **matriz de correlações reduzida**

$$\mathbf{R}_{\text{red}} = \begin{pmatrix} \hat{h}_1^2 & r_{12} & \cdots & r_{1p} \\ r_{21} & \hat{h}_2^2 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & \hat{h}_p^2 \end{pmatrix}. \quad (15.24)$$

A denominação é tradicional: depois da substituição dos elementos diagonais, $\mathbf{R}_{\text{red}}$ não é, em geral, uma matriz de correlações no sentido estrito. Sua diagonal passa a representar a parcela estimada da variância de cada variável atribuída aos fatores comuns.

A matriz reduzida é um objeto intermediário do método e constitui a matriz à qual se aplica a decomposição espectral. Ela não deve ser confundida com a matriz de correlações implicada pela solução fatorial ajustada.

A decomposição espectral é, portanto, aplicada a $\mathbf{R}_{\text{red}}$, e não à matriz $\mathbf{R}$ utilizada na ACP baseada em correlações.

Como $\mathbf{R}_{\text{red}}$ é simétrica, considere seus autovalores

$$\hat{\lambda}_{\text{red},1} \geq \hat{\lambda}_{\text{red},2} \geq \cdots \geq \hat{\lambda}_{\text{red},p}$$

e autovetores unitários associados

$$\hat{\alpha}_{\text{red},1}, \dots, \hat{\alpha}_{\text{red},p},$$

satisfazendo

$$\mathbf{R}_{\text{red}} \hat{\alpha}_{\text{red},j} = \hat{\lambda}_{\text{red},j} \hat{\alpha}_{\text{red},j}, \quad \hat{\alpha}_{\text{red},j}^\top \hat{\alpha}_{\text{red},j} = 1.$$

Reunindo os autovetores em

$$\hat{\mathbf{A}}_{\text{red}} = (\hat{\alpha}_{\text{red},1} \quad \cdots \quad \hat{\alpha}_{\text{red},p})$$

e definindo

$$\widehat{\Lambda}_{\text{red}} = \text{diag} \left(\widehat{\lambda}_{\text{red},1}, \dots, \widehat{\lambda}_{\text{red},p} \right),$$

tem-se

$$\mathbf{R}_{\text{red}} = \widehat{\mathbf{A}}_{\text{red}} \widehat{\Lambda}_{\text{red}} \widehat{\mathbf{A}}_{\text{red}}^{\top}. \quad (15.25)$$

Os autovalores positivos selecionados nessa decomposição determinam, juntamente com os autovetores correspondentes, as cargas fatoriais não rotacionadas.

Suponha que a solução utilize m autovalores positivos da matriz reduzida,

$$\widehat{\lambda}_{\text{red},1} \geq \dots \geq \widehat{\lambda}_{\text{red},m} > 0.$$

Defina

$$\widehat{\mathbf{A}}_{\text{red},m} = \begin{pmatrix} \widehat{\alpha}_{\text{red},1} & \dots & \widehat{\alpha}_{\text{red},m} \end{pmatrix} \in \mathbb{R}^{p \times m}$$

e

$$\widehat{\Lambda}_{\text{red},m} = \text{diag} \left(\widehat{\lambda}_{\text{red},1}, \dots, \widehat{\lambda}_{\text{red},m} \right).$$

A matriz de cargas não rotacionadas correspondente é

$$\widehat{\Phi}_0 = \widehat{\mathbf{A}}_{\text{red},m} \widehat{\Lambda}_{\text{red},m}^{1/2}. \quad (15.26)$$

Se $\widehat{a}_{\text{red},ij}$ é o i -ésimo elemento de $\widehat{\alpha}_{\text{red},j}$, então

$$\widehat{\phi}_{ij}^{(0)} = \sqrt{\widehat{\lambda}_{\text{red},j}} \widehat{a}_{\text{red},ij}. \quad (15.27)$$

A estrutura comum estimada pela solução de m fatores é

$$\widehat{\Phi}_0 \widehat{\Phi}_0^{\top} = \widehat{\mathbf{A}}_{\text{red},m} \widehat{\Lambda}_{\text{red},m} \widehat{\mathbf{A}}_{\text{red},m}^{\top}.$$

As communalidades associadas às cargas obtidas são os elementos diagonais dessa matriz. Para a variável X_i ,

$$\widehat{h}_i^2 = \sum_{j=1}^m \left(\widehat{\phi}_{ij}^{(0)} \right)^2.$$

No procedimento iterativo de fatores principais, essas comunalidades são utilizadas para atualizar a diagonal da matriz reduzida. A nova matriz produz outra decomposição espectral e, conseqüentemente, novas cargas e comunalidades. As atualizações prosseguem segundo o critério de convergência adotado.

As comunalidades iniciais, a tolerância de convergência e os demais critérios numéricos são escolhas algorítmicas e podem variar entre implementações.

A solução obtida por fatores principais é inicialmente não rotacionada. Uma transformação posterior pode selecionar outra orientação para as cargas, conforme desenvolvido na Seção 15.10. No caso ortogonal, a invariância da estrutura comum foi estabelecida na Equação 15.16.

Como $\mathbf{R}_{\text{red}}$ depende de comunalidades estimadas, ela não é necessariamente semidefinida positiva durante todo o procedimento. Autovalores negativos podem ocorrer nessa matriz intermediária.

Esses autovalores negativos pertencem à matriz reduzida intermediária e não correspondem a variâncias fatoriais. Na construção da Equação 15.27, apenas autovalores positivos podem ser retidos, pois as cargas envolvem suas raízes quadradas.

15.14.4.2 Mínimos quadrados e mínimos resíduos

Outra classe de métodos estima a estrutura fatorial pela minimização de uma função dos resíduos entre os elementos da matriz observada e os elementos correspondentes da matriz implicada pelo modelo.

Em uma análise baseada em covariâncias, um critério geral de mínimos quadrados não ponderados para o modelo ortogonal pode ser escrito como

$$F_{\text{MQ}}(\Phi, \Psi) = \|\mathbf{S} - \Phi\Phi^\top - \Psi\|_F^2. \quad (15.28)$$

Pela Definição 6.7, esse critério é a soma dos quadrados dos resíduos de todos os elementos correspondentes de $\mathbf{S}$ e $\Phi\Phi^\top + \Psi$. Ele descreve a forma geral de um ajuste por mínimos quadrados não ponderados, mas não define o MINRES, cujo critério é apresentado a seguir.

No modelo ortogonal, Ψ é diagonal. Portanto, para $i \neq j$, a covariância implicada pelo modelo é

$$\sigma_{ij} = (\Phi\Phi^\top)_{ij},$$

enquanto, na diagonal,

$$\sigma_{ii} = h_i^2 + \psi_i.$$

O método de **mínimos resíduos** (*minimum residual*, MINRES) concentra o ajuste, em uma análise baseada em correlações, nos elementos fora da diagonal. Para o modelo ortogonal, o critério pode ser escrito como

$$F_{\text{MINRES}}(\Phi) = \sum_{i < j} \left[r_{ij} - (\Phi\Phi^\top)_{ij} \right]^2. \quad (15.29)$$

O método estima as cargas pela minimização dos resíduos das correlações fora da diagonal. Depois de obtidas as cargas, as communalidades são estimadas por

$$\hat{h}_i^2 = \sum_{j=1}^m \hat{\phi}_{ij}^2,$$

e, para variáveis padronizadas, as variâncias específicas são obtidas por

$$\hat{\psi}_i = 1 - \hat{h}_i^2.$$

O MINRES é um critério de mínimos quadrados não ponderados baseado nos resíduos fora da diagonal. Assim, o critério geral da Equação 15.28 e o MINRES pertencem à mesma família, mas não correspondem à mesma função objetivo.

Nos métodos de mínimos quadrados ponderados, pesos distintos são atribuídos aos resíduos, produzindo funções objetivo e estimadores diferentes daqueles definidos pelo MINRES.

A avaliação do ajuste por meio dos resíduos entre a matriz observada e a matriz implicada pela solução ajustada é tratada na Seção 15.15.3.

Uma solução fatorial estimada deve respeitar as restrições de admissibilidade do modelo. Em particular,

$$\hat{\psi}_i \geq 0, \quad i = 1, \dots, p.$$

Uma estimativa com

$$\hat{\psi}_i < 0$$

caracteriza uma solução imprópria denominada **caso de Heywood** (Johnson; Wichern, 2002).

Para variáveis padronizadas, a relação

$$1 = \hat{h}_i^2 + \hat{\psi}_i$$

mostra que

$$\widehat{\psi}_i < 0$$

equivale a

$$\widehat{h}_i^2 > 1.$$

O caso

$$\widehat{\psi}_i = 0$$

pertence à fronteira do espaço paramétrico admissível definido por $\psi_i \geq 0$. Nessa situação, resultados inferenciais derivados sob condições de regularidade que exigem uma solução interior não se aplicam diretamente.

15.14.5 Formulação probabilística normal

A estrutura de segunda ordem desenvolvida até aqui não exige normalidade. O aprofundamento probabilístico utiliza a distribuição normal multivariada definida na Definição 9.1 e especifica distribuições para os fatores comuns e para os fatores específicos (Anderson, 2003).

Definição 15.7 (Modelo fatorial normal). Considere o modelo fatorial ortogonal definido na Definição 15.2.

O modelo é denominado **fatorial normal ortogonal** quando

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m),$$

$$\varepsilon \sim N_p(\mathbf{0}, \Psi),$$

e

$$\mathbf{F} \perp \varepsilon.$$

O vetor aleatório observado é

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon.$$

A Definição 9.1 admite matrizes de covariâncias singulares. Assim, a distribuição de ε permanece bem definida quando alguma especificidade ψ_i é nula.

Como $\mathbf{F}$ e ε são vetores normais independentes, sua distribuição conjunta é normal. Pela estabilidade da normal multivariada sob transformações afins, estabelecida na Proposição 9.4,

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma = \Phi\Phi^\top + \Psi. \quad (15.30)$$

Além disso, como ε é conjuntamente normal e Ψ é diagonal, os fatores específicos são independentes. Essa conclusão utiliza a propriedade de independência entre blocos normais estabelecida na Proposição 9.6.

A hipótese

$$\mathbf{F} \perp \varepsilon$$

também é mais forte do que a condição de covariância cruzada nula utilizada no modelo de segunda ordem.

Sob essa especificação probabilística, a função de verossimilhança da amostra depende de μ e da matriz de covariâncias

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A estimação por máxima verossimilhança segue a Definição 10.12.

Sob o modelo fatorial normal, a máxima verossimilhança estima os parâmetros de uma parametrização identificada de modo que a matriz

$$\Sigma = \Phi\Phi^\top + \Psi$$

maximize a verossimilhança da amostra observada dentro da classe admitida pelo modelo. Diferentemente do método de fatores principais, o critério de estimação deriva da distribuição probabilística especificada e também conduz à comparação, por razão de verossimilhanças, entre o modelo fatorial e o modelo normal de covariâncias sem restrições estruturais.

15.14.5.1 Estimação por máxima verossimilhança e ajuste global

Considere uma parametrização identificada do modelo fatorial normal e denote por Θ_{fat} seu espaço paramétrico admissível, com

Seja Θ_{fat} o espaço paramétrico admissível de uma parametrização identificada do modelo fatorial, com

$$\Sigma(\theta) = \Phi\Phi^\top + \Psi.$$

A verossimilhança normal requer uma matriz de covariâncias positiva definida. Define-se, portanto,

$$\Theta_{\text{fat}}^+ = \{\theta \in \Theta_{\text{fat}} : \Sigma(\theta) \succ \mathbf{0}\}. \quad (15.31)$$

Considere uma amostra

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p[\mu, \Sigma(\theta)].$$

A Proposição 10.3 fornece

$$\hat{\mu} = \bar{\mathbf{x}}.$$

Quando $\text{posto}(\mathbf{S}) = p$, a Proposição 10.3 garante que o máximo da verossimilhança do modelo normal irrestrito existe e que a estimativa da matriz de covariâncias é $\mathbf{S}_{\text{MV}}$. Pela Equação 10.72,

$$\mathbf{S}_{\text{MV}} = \frac{n-1}{n}\mathbf{S}. \quad (15.32)$$

A log-verossimilhança concentrada, desconsiderando termos constantes em relação a θ , é

$$\ell(\theta) = C - \frac{n}{2} \left\{ \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] \right\}. \quad (15.33)$$

Assim, a estimação por máxima verossimilhança equivale a minimizar

$$\log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}]$$

sobre Θ_{fat}^+ .

Quando

$$\mathbf{S}_{\text{MV}} \succ \mathbf{0},$$

pode-se utilizar a função de discrepância normalizada

$$F_{\text{ML}}(\theta) = \log |\Sigma(\theta)| + \text{tr} [\mathbf{S}_{\text{MV}} \Sigma(\theta)^{-1}] - \log |\mathbf{S}_{\text{MV}}| - p. \quad (15.34)$$

Essa função satisfaz

$$F_{\text{ML}} = 0$$

quando

$$\Sigma(\theta) = \mathbf{S}_{\text{MV}}.$$

Se $\mathbf{S}_{\text{MV}}$ é singular, a matriz $\mathbf{S}_{\text{MV}} = (n-1)\mathbf{S}/n$ continua definida e a log-verossimilhança na Equação 15.33 pode ser avaliada para matrizes modeladas positivas definidas. Nesse caso, porém, o modelo normal irrestrito com matriz de covariâncias positiva definida não possui estimativa de máxima verossimilhança, e a forma normalizada em Equação 15.34 e a comparação por razão de verossimilhanças com o modelo irrestrito não estão disponíveis na forma apresentada.

A maximização da verossimilhança fatorial não possui, em geral, solução explícita e requer otimização numérica (Lawley; Maxwell, 1971).

15.14.5.2 Ajuste global e graus de liberdade

A formulação por máxima verossimilhança permite comparar o modelo fatorial com o modelo normal de covariâncias sem restrições estruturais.

Em um ponto regular de uma parametrização identificada do modelo fatorial ortogonal com m fatores, o número de restrições independentes é a diferença entre os

$$\frac{p(p+1)}{2}$$

parâmetros livres da matriz de covariâncias irrestrita e a contagem dimensional da parametrização após descontar a indeterminação rotacional, dada na Equação 15.17. Assim,

$$\nu_{\text{fat}} = \frac{p(p+1)}{2} - pm - p + \frac{m(m-1)}{2}. \quad (15.35)$$

Quando $\mathbf{S}_{\text{MV}} \succ \mathbf{0}$, a estatística da razão de verossimilhanças pode ser escrita como

$$-2 \log \Lambda_{\text{RV}} = n F_{\text{ML}}(\hat{\theta}_{\text{MV}}). \quad (15.36)$$

Sob identificação, solução populacional interior e as demais condições regulares do resultado assintótico de Wilks em Teorema 12.4, mantendo p e m fixos e fazendo

$$n \rightarrow \infty,$$

tem-se, se o modelo está corretamente especificado,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi^2_{\nu_{\text{fat}}}. \quad (15.37)$$

A convergência para a distribuição qui-quadrado na Equação 15.37 é assintótica. O aumento de m amplia a classe de estruturas fatoriais representáveis e reduz, em geral, os graus de liberdade do teste.

A escolha de m é discutida na Seção 15.15.2. Quando a máxima verossimilhança é utilizada, o teste de ajuste global também pode ser considerado na avaliação de soluções com diferentes números de fatores.

15.14.6 Distribuições associadas à avaliação da matriz de correlações

Os procedimentos utilizados na avaliação da matriz de correlações não possuem o mesmo status inferencial. Sob normalidade, correlações simples e parciais possuem resultados distribucionais exatos sob hipóteses nulas específicas e aproximações de grande amostra baseadas na transformação de Fisher. MSA e KMO são índices descritivos construídos a partir de correlações simples e parciais, enquanto o teste de esfericidade de Bartlett utiliza uma aproximação qui-quadrado.

15.14.6.1 Correlação amostral

Considere uma amostra aleatória de tamanho $n > 2$ de uma distribuição normal bivariada com correlação populacional ρ_{ij} . Sob

$$H_0 : \rho_{ij} = 0,$$

a correlação amostral r_{ij} satisfaz exatamente

$$T_{ij} = \frac{r_{ij} \sqrt{n-2}}{\sqrt{1-r_{ij}^2}} \sim t_{n-2}. \quad (15.38)$$

Para correlação populacional não necessariamente nula, a transformação de Fisher

$$Z_{ij} = \operatorname{arctanh}(r_{ij})$$

admite a aproximação de grande amostra

$$Z_{ij} \stackrel{\text{aprox}}{\sim} N\left[\operatorname{arctanh}(\rho_{ij}), \frac{1}{n-3}\right]. \quad (15.39)$$

Esses resultados descrevem uma correlação isolada e não constituem testes de adequação global da matriz à Análise Fatorial (Anderson, 2003).

15.14.6.2 Correlação parcial

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$n > p.$$

Considere a correlação parcial entre X_i e X_j depois do controle linear das outras $p-2$ variáveis e denote por $\rho_{ij \cdot -ij}$ a correlação parcial populacional correspondente.

Sob normalidade multivariada e

$$H_0 : \rho_{ij \cdot -ij} = 0,$$

a correlação parcial amostral p_{ij} satisfaz

$$T_{ij \cdot -ij} = \frac{p_{ij} \sqrt{n-p}}{\sqrt{1-p_{ij}^2}} \sim t_{n-p}, \quad (15.40)$$

Para $n > p+1$, a transformação de Fisher fornece a aproximação de grande amostra

$$\operatorname{arctanh}(p_{ij}) \stackrel{\text{aprox}}{\sim} N \left[\operatorname{arctanh}(\rho_{ij \cdot - ij}), \frac{1}{n-p-1} \right]. \quad (15.41)$$

As correlações parciais que aparecem na matriz anti-imagem são estatísticas amostrais. MSA e KMO são funções de várias correlações simples e parciais, construídas como razões de somas de quadrados. Os resultados distribucionais das correlações individuais não fornecem, por si só, uma distribuição de referência para MSA ou KMO. Na utilização adotada neste capítulo, esses índices são interpretados descritivamente e não possuem p -valor associado.

15.14.6.3 Aproximação de Bartlett

O teste de esfericidade considera conjuntamente a matriz de correlações. Sob normalidade multivariada e

$$H_0 : \mathcal{R} = \mathbf{I}_p,$$

a estatística definida na Equação 15.56 aplica a correção de Bartlett a uma quantidade baseada em

$$-\log |\mathbf{R}|.$$

A distribuição qui-quadrado utilizada no teste é aproximada:

$$\chi_B^2 \stackrel{\text{aprox}}{\sim} \chi_{p(p-1)/2}^2.$$

A correção melhora a aproximação qui-quadrado, mas não transforma a estatística em uma variável com distribuição qui-quadrado exata em amostras finitas (Bartlett, 1950; Johnson; Wichern, 2002).

A aplicação desses resultados à avaliação da matriz de correlações é discutida na Seção 15.15.1.

15.14.7 Distribuição condicional dos fatores e escore por regressão

Sob o modelo fatorial normal, o escore por regressão corresponde à média da distribuição condicional do vetor fatorial latente dado o vetor observado.

Considere o modelo fatorial normal ortogonal da Definição 15.7 e suponha

$$\Sigma \succ \mathbf{0}.$$

Como

$$\text{Cov}(\mathbf{F}, \mathbf{X}) = \Phi^\top,$$

a distribuição condicional normal da Proposição 9.7 fornece diretamente

$$\mathbf{F} \mid (\mathbf{X} = \mathbf{x}) \sim N_m \left[\Phi^\top \Sigma^{-1} (\mathbf{x} - \mu), \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi \right]. \quad (15.42)$$

Consequentemente,

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \Phi^\top \Sigma^{-1} (\mathbf{x} - \mu), \quad (15.43)$$

e

$$\text{Cov}(\mathbf{F} \mid \mathbf{X} = \mathbf{x}) = \mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi. \quad (15.44)$$

A média condicional fornece o **escore fatorial por regressão** (Johnson; Wichern, 2002):

$$\hat{\mathbf{f}}_{\text{reg}} = \Phi^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (15.45)$$

Quando os parâmetros são desconhecidos, utiliza-se a versão por substituição

$$\hat{\mathbf{f}}_{\text{reg}} = \hat{\Phi}^\top \hat{\Sigma}^{-1} (\mathbf{x} - \hat{\mu}),$$

com os parâmetros substituídos pelas estimativas da solução fatorial ajustada.

Em geral,

$$\mathbf{I}_m - \Phi^\top \Sigma^{-1} \Phi \neq \mathbf{0},$$

de modo que a distribuição condicional dos fatores não é degenerada e a observação $\mathbf{x}$ não determina univocamente sua realização latente. Diferentes critérios de obtenção dos escores podem, portanto, atribuir valores distintos à mesma observação sob uma solução fatorial fixada.

15.14.8 Critérios e propriedades dos métodos de escores fatoriais

Para comparar os diferentes critérios de obtenção dos escores, considere uma solução fatorial fixada e

$$\mathbf{z} = \mathbf{x} - \mu = \Phi \mathbf{f} + \varepsilon.$$

15.14.8.1 Escore de Bartlett

O método de Bartlett trata $\mathbf{f}$ como o vetor de valores fatoriais a ser estimado e utiliza as variâncias específicas para ponderar os resíduos (Bartlett, 1937; Johnson; Wichern, 2002).

Supondo

$$\Psi \succ \mathbf{0},$$

considera-se

$$d_B(\mathbf{f}) = (\mathbf{z} - \Phi \mathbf{f})^\top \Psi^{-1} (\mathbf{z} - \Phi \mathbf{f}). \quad (15.46)$$

Quando

$$\Phi^\top \Psi^{-1} \Phi$$

é invertível, a minimização produz

$$\hat{\mathbf{f}}_B = (\Phi^\top \Psi^{-1} \Phi)^{-1} \Phi^\top \Psi^{-1} \mathbf{z}. \quad (15.47)$$

Condicionalmente a

$$\mathbf{F} = \mathbf{f},$$

tem-se

$$E(\hat{\mathbf{f}}_B \mid \mathbf{F} = \mathbf{f}) = \mathbf{f},$$

e

$$\text{Cov}(\hat{\mathbf{f}}_B - \mathbf{f} \mid \mathbf{F} = \mathbf{f}) = (\Phi^\top \Psi^{-1} \Phi)^{-1}.$$

O método atribui maior peso relativo às variáveis com menor variância específica.

15.14.8.2 Escore de Anderson–Rubin

O método de Anderson–Rubin procura construir escores mutuamente não correlacionados para uma solução ortogonal (Anderson; Rubin, 1956).

Suponha $\Psi \succ \mathbf{0}$ e defina

$$\mathbf{G}_{\text{AR}} = \Phi^\top \Psi^{-1} \Sigma \Psi^{-1} \Phi.$$

Quando $\mathbf{G}_{\text{AR}} \succ \mathbf{0}$, os escores podem ser escritos como

$$\hat{\mathbf{f}}_{\text{AR}} = \mathbf{G}_{\text{AR}}^{-1/2} \Phi^\top \Psi^{-1} \mathbf{z}. \quad (15.48)$$

Sua matriz de covariâncias é

$$\text{Cov}(\hat{\mathbf{f}}_{\text{AR}}) = \mathbf{I}_m. \quad (15.49)$$

Assim, a construção produz escores com variâncias unitárias e covariâncias cruzadas nulas, reproduzindo em sua estrutura de segunda ordem a padronização e a ortogonalidade impostas aos fatores.

15.14.8.3 Escores de ten Berge

Em uma solução oblíqua, a matriz de correlações dos fatores é

$$\Omega.$$

O método de ten Berge pertence à classe dos métodos de predição que procuram preservar nos escores a estrutura de correlações dos fatores (Berge et al., 1999). Sua propriedade característica é

$$\text{Corr}(\hat{\mathbf{f}}_{\text{TB}}) = \Omega. \quad (15.50)$$

A construção utiliza raízes matriciais e uma transformação dos coeficientes de predição para satisfazer essa restrição. A propriedade na Equação 15.50 estabelece que os escores preservam a matriz de correlações fatoriais Ω especificada para a solução oblíqua.

15.14.8.4 Método de Harman

O método de Harman obtém os escores pela aproximação não ponderada de $\mathbf{z}$ pela parcela $\Phi\mathbf{f}$ (Grice, 2001).

Suponha

$$\text{posto}(\Phi) = m.$$

A matriz de pesos pode ser escrita como

$$\mathbf{W}_H = \Phi (\Phi^\top \Phi)^{-1},$$

e o escore correspondente é

$$\hat{\mathbf{f}}_H = \mathbf{W}_H^\top \mathbf{z} = (\Phi^\top \Phi)^{-1} \Phi^\top \mathbf{z}. \quad (15.51)$$

De fato, essa expressão é a solução do problema de mínimos quadrados não ponderados

$$\min_{\mathbf{f}} \|\mathbf{z} - \Phi\mathbf{f}\|^2.$$

A construção difere do método de Bartlett porque não pondera os resíduos pelas variâncias específicas. Também não impõe, por construção, escores mutuamente não correlacionados nem a preservação da matriz de correlações fatoriais.

15.15 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne critérios e procedimentos utilizados na condução da Análise Fatorial Exploratória, incluindo avaliação da matriz de correlações, escolha do número de fatores, avaliação do ajuste por meio dos resíduos, rotação e obtenção de escores.

15.15.1 Adequação da matriz de correlações à Análise Fatorial

Na Análise Fatorial Exploratória, a matriz de correlações pode ser examinada antes da estimação comparando-se as correlações simples com as correlações parciais entre pares de variáveis, controlando-se linearmente as demais.

Como diagnóstico exploratório, correlações simples acompanhadas por correlações parciais menores em módulo são compatíveis com uma estrutura em que parte das associações entre as variáveis é compartilhada. Correlações parciais elevadas indicam que parte da associação entre determinados pares permanece após o controle linear das demais variáveis, o que é menos compatível com uma estrutura comum de baixa dimensão (Hair et al., 2009).

A matriz anti-imagem, a MSA e o KMO utilizam $\mathbf{R}^{-1}$ e, portanto, exigem uma matriz de correlações não singular. Pela Definição 8.12, quando as variâncias amostrais são positivas,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}).$$

Combinando essa relação com a Equação 8.63,

$$\text{posto}(\mathbf{R}) \leq \min(p, n - 1).$$

Assim, $n > p$ é necessário para que $\mathbf{R}$ possa ter posto completo, mas não garante sua invertibilidade. Dependências lineares exatas entre as variáveis padronizadas também tornam $\mathbf{R}$ singular.

Apesar da expressão *sampling adequacy*, MSA e KMO não medem diretamente o tamanho da amostra. Seus valores são construídos a partir da comparação entre correlações simples e parciais.

Matriz anti-imagem, MSA e KMO descrevem a importância relativa das correlações parciais, enquanto o teste de Bartlett avalia a hipótese de matriz de correlações populacional identidade. Nenhum desses procedimentos avalia o ajuste de um modelo fatorial com número de fatores previamente especificado.

As distribuições associadas às correlações simples e parciais e o caráter aproximado da distribuição utilizada no teste de Bartlett são desenvolvidos na Seção 15.14.6. MSA e KMO permanecem medidas descritivas e não possuem, na utilização adotada neste capítulo, um p -valor associado.

15.15.1.1 Matriz anti-imagem

A matriz anti-imagem é construída a partir das correlações parciais entre pares de variáveis, controlando-se linearmente as demais.

Considere a matriz de correlações observada

$$\mathbf{R} = (r_{ij}),$$

positiva definida, e sua inversa

$$\mathbf{C} = \mathbf{R}^{-1} = (c_{ij}).$$

Para $i \neq j$, a correlação parcial entre X_i e X_j , controlando-se as demais variáveis, é

$$p_{ij} = -\frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}}.$$

Defina

$$\mathbf{D} = \text{diag} \left(\frac{1}{c_{11}}, \dots, \frac{1}{c_{pp}} \right).$$

A matriz de covariâncias anti-imagem é

$$\mathbf{S}_{\text{AI}} = \mathbf{D}\mathbf{C}\mathbf{D}. \quad (15.52)$$

Seus elementos diagonais são

$$s_{ii}^{(\text{AI})} = \frac{1}{c_{ii}},$$

enquanto, para $i \neq j$,

$$s_{ij}^{(\text{AI})} = \frac{c_{ij}}{c_{ii}c_{jj}}.$$

A padronização dessa matriz produz a matriz de correlações anti-imagem. Definindo

$$\mathbf{D}_C = \text{diag} (c_{11}, \dots, c_{pp}),$$

tem-se

$$\mathbf{R}_{\text{AI}} = \mathbf{D}_C^{-1/2} \mathbf{C} \mathbf{D}_C^{-1/2}. \quad (15.53)$$

Sua diagonal é unitária e, para $i \neq j$,

$$r_{ij}^{(\text{AI})} = \frac{c_{ij}}{\sqrt{c_{ii}c_{jj}}} = -p_{ij}.$$

Portanto, os elementos fora da diagonal da matriz de correlações anti-imagem correspondem aos negativos das correlações parciais entre pares de variáveis, controlando-se as demais. Valores pequenos em módulo indicam pouca associação residual entre os pares depois desse controle.

A matriz de correlações anti-imagem definida na Equação 15.53 possui diagonal unitária. Em algumas saídas computacionais, essa diagonal é substituída pelas medidas individuais de adequação apresentadas a seguir. Essa convenção de apresentação não altera a definição matemática da matriz anti-imagem.

15.15.1.2 Medida de adequação amostral — MSA

A **Measure of Sampling Adequacy (MSA)** avalia cada variável separadamente pela relação entre suas correlações simples e suas correlações parciais com as demais variáveis.

Para a variável X_i , quando o denominador é positivo,

$$\text{MSA}_i = \frac{\sum_{j \neq i} r_{ij}^2}{\sum_{j \neq i} r_{ij}^2 + \sum_{j \neq i} p_{ij}^2}. \quad (15.54)$$

Nesse caso,

$$0 \leq \text{MSA}_i \leq 1.$$

A MSA se aproxima de 1 quando as correlações parciais são pequenas em relação às correlações simples. Valores baixos indicam que parte importante das associações da variável com as demais permanece mesmo depois do controle linear das outras variáveis. Esse padrão é menos compatível com uma representação em que essas associações sejam predominantemente atribuídas a fatores comuns.

Hair et al. utilizam 0,50 como referência operacional mínima para examinar a adequação de uma variável (Hair et al., 2009). Esse valor é uma **regra prática**. Ele não constitui condição matemática de existência ou identificação do modelo fatorial.

15.15.1.3 Kaiser-Meyer-Olkin — KMO

O índice de **Kaiser-Meyer-Olkin (KMO)** aplica ao conjunto de variáveis o mesmo princípio utilizado pela MSA individual:

$$\text{KMO} = \frac{\sum_{i < j} r_{ij}^2}{\sum_{i < j} r_{ij}^2 + \sum_{i < j} p_{ij}^2}. \quad (15.55)$$

Quando o denominador é positivo,

$$0 \leq \text{KMO} \leq 1.$$

Valores próximos de 1 correspondem a correlações parciais pequenas em relação às correlações simples. Esse padrão indica que, depois do controle linear das demais variáveis, resta relativamente pouca associação entre os pares e é compatível com uma estrutura comum compartilhada pelo conjunto de variáveis.

Valores baixos indicam que parte importante das associações entre pares permanece depois do controle das demais variáveis. Hair et al. utilizam 0,50 como referência operacional mínima para a medida global (Hair et al., 2009).

MSA e KMO diferem pela abrangência. A MSA_i avalia uma variável em relação às demais. O KMO resume o mesmo tipo de comparação para o conjunto de variáveis. Nenhuma das duas medidas testa a hipótese de que um modelo fatorial específico seja verdadeiro.

15.15.1.4 Teste de esfericidade de Bartlett

O teste de esfericidade de Bartlett avalia a hipótese de que a matriz de correlações populacional $\mathcal{R}$, definida na Definição 8.5, seja a matriz identidade (Johnson; Wichern, 2002).

Considere uma amostra aleatória da distribuição normal multivariada definida na Definição 9.1,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com variâncias marginais positivas. Seja $\mathbf{R}$ a matriz de correlações observada calculada a partir das n observações completas. A hipótese nula é

$$H_0 : \mathcal{R} = \mathbf{I}_p,$$

contra

$$H_1 : \mathcal{R} \neq \mathbf{I}_p.$$

Sob H_0 , todas as correlações populacionais fora da diagonal são nulas.

Supondo $\mathbf{R}$ positiva definida, utiliza-se a estatística

$$\chi_B^2 = - \left[n - 1 - \frac{2p + 5}{6} \right] \log |\mathbf{R}|. \quad (15.56)$$

Para amostras suficientemente grandes,

$$\chi_B^2 \stackrel{\text{aprox}}{\sim} \chi_{p(p-1)/2}^2$$

sob H_0 (Johnson; Wichern, 2002).

A rejeição de H_0 fornece evidência de que a matriz de correlações populacional não é a identidade. Existe, portanto, associação linear entre pelo menos algumas das variáveis.

Esse resultado não estabelece a existência de uma estrutura fatorial de baixa dimensão nem o bom ajuste de um modelo com determinado número de fatores. Ele apenas afasta o caso em que todas as correlações populacionais entre variáveis distintas são nulas.

A não rejeição de H_0 indica que os dados não fornecem evidência suficiente para distinguir a matriz de correlações populacional da identidade, situação pouco favorável à busca de fatores comuns.

Hair et al. recomendam interpretar Bartlett em conjunto com as correlações parciais e as medidas de adequação (Hair et al., 2009). Em amostras grandes, associações pequenas podem produzir rejeição de H_0 . A significância do teste não deve ser utilizada isoladamente como evidência de adequação fatorial.

Tabela 15.5: Síntese dos procedimentos utilizados na avaliação da matriz de correlações antes da estimação fatorial.

Procedimento	Referência para interpretação	Conclusão permitida
Elementos fora da diagonal da anti-imagem	valores próximos de 0	correlações parciais pequenas em módulo
MSA_i	0,50 como referência operacional mínima	valores menores indicam maior importância relativa das correlações parciais da variável

Procedimento	Referência para interpretação	Conclusão permitida
KMO	0,50 como referência operacional mínima	valores maiores indicam menor importância relativa das correlações parciais
Bartlett	rejeitar H_0 quando o p -valor é menor que o nível α definido	a matriz de correlações populacional difere da identidade

15.15.2 Escolha do número de fatores

A dimensão m da estrutura fatorial é parte da especificação do modelo. Um número muito pequeno de fatores pode ser insuficiente para reproduzir a estrutura comum das variáveis, enquanto um número excessivo pode produzir uma representação desnecessariamente complexa e de interpretação instável (Hair et al., 2009).

A formulação do modelo estabelece que $m < p$, mas não determina, por si só, o valor de m . A escolha do número de fatores constitui uma decisão de modelagem e pode ser auxiliada por diferentes critérios.

Os critérios de retenção fornecem informações auxiliares para a escolha do número de fatores e devem ser considerados em conjunto com a interpretação da solução obtida.

A escolha de m não deve ser confundida com a avaliação da adequação da matriz de correlações. A matriz anti-imagem, MSA, KMO e o teste de esfericidade de Bartlett avaliam aspectos da estrutura de correlações antes da estimação fatorial, mas não determinam quantos fatores devem ser retidos.

Alguns critérios utilizam uma sequência de raízes associadas à estrutura analisada. Antes de interpretá-las, é necessário identificar **qual matriz ou qual procedimento de extração as produziu**. Na ACP, os autovalores pertencem diretamente à matriz de covariâncias ou de correlações. Na Análise Fatorial, métodos distintos podem utilizar estruturas diferentes para representar a parcela comum.

O **gráfico de declive** (*scree plot*) representa em ordem decrescente a sequência de autovalores ou raízes definida pelo procedimento utilizado. Procura-se um **cotovelo**, a partir do qual a queda se torna menos acentuada e os valores restantes são relativamente pequenos. A interpretação depende da matriz e do procedimento que produziram essa sequência (Hair et al., 2009).

O **gráfico de declive** (*scree plot*) apresenta uma sequência de raízes em ordem decrescente. Uma mudança acentuada no padrão de queda pode indicar uma região a partir da qual as raízes restantes se tornam relativamente pequenas. Sua interpretação depende das raízes utilizadas na construção do gráfico (Hair et al., 2009).

O critério baseado em autovalores maiores que 1 exige cuidado adicional. Quando aplicado aos autovalores da matriz de correlações $\mathbf{R}$, o valor 1 possui a interpretação de variância de uma variável padronizada. Essa justificativa é a mesma discutida para a ACP na Seção 14.14.1. Quando as raízes são obtidas de outra matriz ou de outro procedimento de extração, esse limiar não conserva automaticamente a mesma interpretação.

Assim, critérios baseados na magnitude das raízes devem ser tratados como auxiliares e sempre associados à matriz ou ao método que as produziu.

Outro procedimento é a **análise paralela**. Seu princípio é comparar as raízes obtidas dos dados observados com valores de referência gerados sob uma estrutura nula em que não há associação sistemática entre as variáveis.

Para que a comparação tenha significado, as raízes observadas e as de referência devem ser obtidas segundo critérios comparáveis. Na Análise Fatorial, isso exige atenção à matriz analisada e ao método utilizado para representar a estrutura comum. A análise paralela não deve ser identificada automaticamente com a comparação dos autovalores da matriz $\mathbf{R}$ quando o procedimento fatorial utiliza outra definição de raiz.

A construção da referência pode variar quanto ao mecanismo de geração dos dados, ao número de replicações, à medida de referência adotada e ao procedimento utilizado para obter as raízes. Portanto, o resultado da análise paralela depende da implementação adotada, e sua interpretação deve considerar como foram obtidas tanto as raízes observadas quanto os valores de referência.

A escolha de m pode considerar conjuntamente:

- a possibilidade de interpretar cada fator a partir das variáveis associadas a ele;
- o comportamento das raízes e do gráfico de declive;
- a análise paralela, quando utilizada;
- os resíduos da solução ajustada;
- o ajuste global, quando o método utilizado fornece esse procedimento;
- a interpretação da solução após a rotação.

Essas informações podem indicar soluções diferentes. Nesse caso, modelos com dimensões próximas devem ser comparados quanto às mudanças nas cargas, nas comunalidades, nos resíduos e na interpretação dos fatores (Hair et al., 2009).

Entre soluções com ajuste e interpretação satisfatórios, a escolha do menor número de fatores preserva a parcimônia do modelo (Johnson; Wichern, 2002).

15.15.3 Matriz reproduzida e resíduos

Depois da estimação, o ajuste pode ser examinado comparando a matriz utilizada na análise com a matriz implicada pela solução fatorial estimada. Nesta seção, essa matriz implicada pela solução ajustada será denominada **matriz reproduzida**.

No modelo ortogonal, sejam

$$\widehat{\Phi}$$

e

$$\widehat{\Psi},$$

as estimativas correspondentes a uma solução com m fatores.

A matriz de cargas depende da parametrização e da orientação escolhida. Para avaliar o ajuste, interessa a matriz de covariâncias implicada pela solução ajustada, e não uma orientação específica das cargas.

No modelo ortogonal, a matriz de covariâncias reproduzida é

$$\widehat{\Sigma}_{\text{fat}} = \widehat{\Phi}\widehat{\Phi}^{\top} + \widehat{\Psi}. \quad (15.57)$$

Quando a análise é baseada em correlações, a expressão correspondente é

$$\widehat{\mathcal{R}}_{\text{fat}} = \widehat{\Phi}\widehat{\Phi}^{\top} + \widehat{\Psi},$$

com a parametrização definida para as variáveis padronizadas.

Em uma solução com fatores correlacionados, a parcela comum é

$$\widehat{\Phi}\widehat{\Omega}\widehat{\Phi}^{\top},$$

e a matriz reproduzida é obtida acrescentando $\widehat{\Psi}$, conforme a formulação oblíqua desenvolvida na Seção 15.10.

A matriz de resíduos é definida como a diferença entre a matriz utilizada no ajuste e a matriz reproduzida pela solução fatorial.

Para uma análise baseada em covariâncias, a matriz de resíduos é

$$\mathbf{E}_S = \mathbf{S} - \widehat{\Sigma}_{\text{fat}}. \quad (15.58)$$

Para uma análise baseada em correlações,

$$\mathbf{E}_R = \mathbf{R} - \widehat{\mathcal{R}}_{\text{fat}}. \quad (15.59)$$

No modelo ortogonal, para $i \neq j$, o resíduo de uma covariância é

$$e_{S,ij} = s_{ij} - \sum_{h=1}^m \hat{\phi}_{ih} \hat{\phi}_{jh}.$$

Na análise baseada em correlações,

$$e_{R,ij} = r_{ij} - \sum_{h=1}^m \hat{\phi}_{ih} \hat{\phi}_{jh}.$$

Para $i \neq j$, cada resíduo quantifica a discrepância entre a covariância ou correlação observada e o valor correspondente implicado pela estrutura comum estimada. Quanto menor sua magnitude, menor é essa discrepância.

Os resíduos diagonais correspondem às diferenças entre as variâncias observadas e aquelas implicadas pela solução ajustada. Seu comportamento depende do método de estimação e da forma como as variâncias específicas são determinadas. Em procedimentos que definem

$$\hat{\psi}_i = s_{ii} - \hat{h}_i^2$$

ou, no caso padronizado,

$$\hat{\psi}_i = 1 - \hat{h}_i^2,$$

os resíduos diagonais são nulos por construção e, portanto, não fornecem um diagnóstico independente de ajuste.

A matriz de resíduos também permite separar o papel da estimação do papel da rotação. Em uma rotação ortogonal,

$$\hat{\Phi}^* = \hat{\Phi} \mathbf{Q}$$

e, pela Equação 15.16,

$$\hat{\Phi}^* \hat{\Phi}^{*\top} = \hat{\Phi} \hat{\Phi}^\top.$$

A matriz reproduzida e a matriz de resíduos permanecem inalteradas. A rotação modifica a orientação das cargas, não o ajuste da estrutura reproduzida.

Na formulação oblíqua, a mesma conclusão vale para transformações conjuntas das cargas e das correlações fatoriais que preservem

$$\widehat{\Phi}\widehat{\Omega}\widehat{\Phi}^{\top}.$$

Se o modelo populacional ortogonal com m fatores representa exatamente a estrutura de covariâncias,

$$\Sigma = \Phi\Phi^{\top} + \Psi,$$

a matriz residual populacional correspondente é nula.

Na amostra, resíduos diferentes de zero podem ocorrer mesmo quando a matriz populacional satisfaz exatamente o modelo fatorial, pois $\mathbf{S}$ ou $\mathbf{R}$ diferem de suas correspondentes populacionais em razão da variabilidade amostral e os parâmetros da solução são estimados a paResíduos amostrais também podem refletir inadequação da estrutura fatorial especificada. Um número insuficiente de fatores ou relações entre variáveis que não são captadas pelos fatores comuns e pela estrutura diagonal de Ψ podem produzir padrões sistemáticos nos resíduos.rtir da própria amostra.

A matriz residual deve ser examinada quanto à magnitude e ao padrão das discrepâncias entre a matriz observada e a matriz reproduzida. Padrões sistemáticos podem indicar inadequação local da estrutura especificada, mas um resíduo isolado não identifica, por si só, a causa da discrepância.

15.15.4 Critérios específicos de rotação

Depois que uma solução fatorial é obtida, diferentes critérios podem selecionar orientações que favoreçam uma estrutura mais simples. Esses critérios atuam sobre a representação das cargas e não constituem novos métodos de estimação.

As funções objetivo que definem Varimax, Quartimax, Oblimin e Promax são apresentadas na Seção 15.14.3. Metodologicamente, esses critérios diferem pelo tipo de estrutura simples que favorecem e por manterem ou não a ortogonalidade dos fatores.

A escolha da rotação deve ser distinguida da avaliação do ajuste. Transformações que preservam a matriz de covariâncias implicada pela solução ajustada também preservam a matriz de resíduos, conforme mostrado na Seção 15.15.3. A rotação modifica a representação dos fatores para favorecer a interpretação, sem constituir um novo ajuste do modelo.

15.15.4.1 Critérios de rotação ortogonal

Nas rotações ortogonais, os fatores permanecem não correlacionados. Dois critérios clássicos diferem pelo aspecto da matriz de cargas que procuram simplificar.

O **Varimax** procura aumentar o contraste entre os quadrados das cargas dentro de cada fator. Em cada coluna da matriz de cargas, o critério favorece uma distribuição mais desigual dos quadrados das cargas, com alguns valores maiores e outros próximos de zero. Isso tende a tornar mais nítidas as variáveis que apresentam as maiores cargas em módulo em cada fator (Johnson; Wichern, 2002; Kaiser, 1958).

O **Quartimax** enfatiza a simplificação das variáveis. Como a comunalidade h_i^2 é preservada pela rotação ortogonal, o critério favorece orientações em que poucos termos $(\phi_{ij}^*)^2$ concentrem a comunalidade de cada variável (Lawley; Maxwell, 1971).

O Varimax enfatiza o contraste entre os quadrados das cargas dentro das colunas da matriz de cargas, enquanto o Quartimax enfatiza sua concentração dentro das linhas. Os dois critérios podem, portanto, selecionar orientações distintas da mesma solução não rotacionada.

15.15.4.2 Critérios de rotação oblíqua

As rotações oblíquas permitem que os fatores resultantes sejam correlacionados. Entre os critérios usuais estão **Oblimin** e **Promax** (Hair et al., 2009).

O **Oblimin** procura uma estrutura simples sem impor $\Omega = \mathbf{I}_m$. Em uma solução oblíqua, a matriz de padrões e a matriz de estrutura podem ser diferentes, enquanto Ω registra as correlações entre os fatores. Esses três objetos são definidos na Seção 15.10.

O **Promax** parte de uma solução previamente submetida a uma rotação ortogonal, constrói uma matriz-alvo que acentua as diferenças de magnitude entre as cargas e procura uma transformação oblíqua que aproxime a solução dessa matriz-alvo (Hendrickson; White, 1964).

Oblimin e Promax pertencem à mesma classe geral de rotações oblíquas, mas utilizam critérios distintos para escolher a orientação final. Não são denominações diferentes para o mesmo procedimento.

15.15.4.3 Escolha da rotação

Não existe um critério de rotação que seja superior em todas as aplicações (Hair et al., 2009). A escolha entre rotação ortogonal e oblíqua depende da relação admitida entre os fatores. A rotação ortogonal impõe

$$\Omega = \mathbf{I}_m,$$

enquanto a rotação oblíqua estima também as correlações entre os fatores, representadas pelos elementos fora da diagonal de Ω , conforme a Seção 15.10.

Quando o problema analisado admite fatores correlacionados, a rotação oblíqua preserva essa possibilidade no modelo rotacionado. A matriz estimada $\hat{\Omega}$ mostra as correlações obtidas entre os fatores. Correlações de pequena magnitude indicam que a restrição de ortogonalidade pode produzir uma representação próxima daquela obtida pela solução oblíqua; correlações maiores indicam que uma solução ortogonal elimina uma associação entre fatores presente na solução rotacionada.

O critério de rotação também pode afetar o padrão das cargas fatoriais. A comparação entre soluções obtidas por critérios admissíveis deve considerar quais variáveis apresentam as maiores cargas em cada fator, a ocorrência de cargas cruzadas e a correspondência entre os conjuntos de variáveis associados aos fatores. Quando essas características permanecem semelhantes entre soluções, a interpretação depende menos do critério de rotação escolhido (Johnson; Wichern, 2002).

A rotação de uma solução fatorial não modifica o ajuste global correspondente à matriz de covariâncias reproduzida; ela modifica a representação dos fatores e das cargas. Por isso, a escolha da rotação deve ser separada da avaliação do ajuste do modelo. Os resíduos avaliam a reprodução das associações observadas, enquanto as cargas rotacionadas e, no caso oblíquo, as correlações entre fatores orientam a interpretação da solução.

15.15.5 Diferentes métodos de escores fatoriais

O escore por regressão não é a única forma de obter valores associados às realizações dos fatores latentes para as unidades observacionais. Como os fatores não são observados diretamente, métodos diferentes podem produzir escores distintos para uma mesma observação mesmo quando a solução fatorial permanece fixada (Johnson; Wichern, 2002).

As propriedades matemáticas dos principais critérios são desenvolvidas na Seção 15.14.8. Para a condução da análise, a escolha deve considerar a propriedade que se deseja preservar nos escores.

Tabela 15.6: Propriedades privilegiadas pelos métodos de escores fatoriais considerados no capítulo.

Método	Propriedade privilegiada	Consequência para o uso
Thurstone ou regressão	predição dos fatores a partir das variáveis observadas	no modelo normal ortogonal, corresponde à média condicional desenvolvida na Seção 15.14.7

Método	Propriedade privilegiada	Consequência para o uso
Bartlett	minimização dos resíduos ponderados pelas variâncias específicas	variáveis com menor variância específica recebem maior peso relativo
ten Berge	preservação da estrutura de correlações fatoriais	produz escores cuja matriz de correlações é Ω
Anderson–Rubin	obtenção de escores padronizados e não correlacionados	produz escores com matriz de covariâncias $\mathbf{I}_m$
Harman	minimização não ponderada de $\ \mathbf{z} - \Phi\mathbf{f}\ ^2$	não pondera os resíduos pelas variâncias específicas e não impõe a estrutura de correlações dos escores

O método por regressão é apropriado quando o objetivo principal é prever os fatores a partir das variáveis observadas. Bartlett pondera os resíduos pelo inverso das variâncias específicas, atribuindo maior peso relativo às variáveis com menor ψ_i .

O método de Anderson–Rubin produz escores não correlacionados. Essa propriedade é coerente com uma solução ortogonal, mas não reproduz a estrutura de uma solução oblíqua quando Ω possui elementos fora da diagonal diferentes de zero.

Em uma solução oblíqua, ten Berge preserva nos escores a matriz de correlações fatoriais Ω , ao contrário de um critério que imponha escores mutuamente não correlacionados.

Os valores dos escores dependem do método utilizado. A escolha do método não modifica a matriz de cargas, as communalidades, as variâncias específicas ou a matriz de covariâncias reproduzida, pois os escores são construídos depois da obtenção da solução fatorial.

A interpretação dos fatores deve basear-se nas relações entre os fatores e as variáveis observadas; em soluções oblíquas, devem ser consideradas também as distinções entre matriz de padrões, matriz de estrutura e correlações fatoriais. Os escores fornecem valores associados às realizações fatoriais das unidades observacionais, e seu uso em análises posteriores deve registrar o método empregado para calculá-los.

15.15.6 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise Fatorial Exploratória será realizada pela análise EFA do núcleo do [jamovi](#) (The jamovi project, 2026). As opções apresentadas pela implementação correspondem a etapas estatísticas distintas da análise.

Tabela 15.7: Correspondência entre opções da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Minimum residuals	estimação pelo critério MINRES	Seção 15.14.4
Principal axis	método de fatores ou eixos principais	Seção 15.14.4
Maximum likelihood	estimação sob o modelo fatorial normal	Seção 15.14.5
Based on parallel analysis, Based on eigenvalue e Fixed number	procedimentos para determinar ou fixar o número de fatores	Seção 15.15.2
KMO measure of sampling adequacy	KMO global e medidas individuais MSA_i	Seção 15.15.1
Bartlett's test of sphericity	estatística χ_B^2 , graus de liberdade e p -valor	Seção 15.15.1
Varimax, Quartimax, Oblimin e Promax	critérios de rotação desenvolvidos no capítulo	Seção 15.14.3 e Seção 15.15.4
Factor correlations	estimativa da matriz de correlações fatoriais $\hat{\Omega}$ em soluções oblíquas	Seção 15.10
Thurstone, Bartlett, ten Berge, Anderson–Rubin e Harman	diferentes critérios para obtenção dos escores fatoriais	Seção 15.14.8 e Seção 15.15.5

Na EFA da implementação utilizada, os valores empregados por **Based on eigenvalue** e **Based on parallel analysis** dependem do método de extração selecionado. Portanto, eles não devem ser identificados automaticamente com os autovalores da matriz de correlações **R**. Essa distinção é discutida na Seção [15.15.2](#).

A opção *Principal axis* não corresponde à Análise de Componentes Principais. Na ACP, os autovetores da matriz de covariâncias ou de correlações definem as direções principais e os autovalores são as variâncias das componentes correspondentes. No método de fatores principais, decomposições espectrais sucessivas são aplicadas a uma matriz reduzida cuja diagonal contém comunalidades estimadas.

A implementação também oferece **Simplimax**, uma rotação oblíqua não desenvolvida neste capítulo.

A opção *Factor correlations* é pertinente às rotações oblíquas e corresponde à estimativa de Ω . Nas rotações ortogonais, as correlações entre fatores são fixadas em zero pela própria parametrização.

A implementação também pode apresentar estatística qui-quadrado, graus de liberdade, p -valor, RMSEA, TLI e BIC. Essas medidas são obtidas a partir do ajuste produzido pelo método de extração selecionado. A razão de verossimilhanças desenvolvida na Seção 15.14.5 corresponde especificamente à estimação por máxima verossimilhança; sob **Minimum residuals** ou **Principal axis**, a estatística qui-quadrado apresentada pela implementação não deve ser interpretada como essa mesma razão de verossimilhanças.

Na implementação utilizada, **Thurstone** corresponde ao método de escores por regressão desenvolvido na Seção 15.14.7.

15.16 Síntese

A Análise Fatorial representa as covariâncias entre variáveis observadas por meio de um número menor de fatores latentes. No modelo ortogonal,

$$\mathbf{X} = \mu + \Phi\mathbf{F} + \varepsilon,$$

e

$$\Sigma = \Phi\Phi^\top + \Psi.$$

A matriz $\Phi\Phi^\top$ é a matriz de covariâncias comuns: sua diagonal contém as comunalidades e seus elementos fora da diagonal são as covariâncias entre as variáveis especificadas pelo modelo. A matriz diagonal Ψ contém as variâncias específicas. Para uma variável padronizada,

$$h_i^2 = \sum_{j=1}^m \phi_{ij}^2, \quad \psi_i = 1 - h_i^2.$$

As cargas são os coeficientes dos fatores na representação das variáveis. No modelo ortogonal com variáveis padronizadas,

$$\text{Corr}(X_i, F_j) = \phi_{ij}.$$

A orientação dos fatores não é única. Rotações ortogonais preservam $\Phi\Phi^\top$ e mantêm os fatores não correlacionados, enquanto rotações oblíquas admitem correlações entre os fatores. A rotação modifica a representação das cargas, mas não constitui um novo método de estimação.

Na análise amostral, a matriz de covariâncias ou de correlações observada é utilizada para estimar a estrutura fatorial. Fatores principais, MINRES e máxima verossimilhança empregam

critérios distintos. A normalidade é uma hipótese adicional da formulação probabilística normal e não é necessária para definir a estrutura de segunda ordem do modelo.

Depois da estimação, os resíduos quantificam as discrepâncias entre a matriz observada e a matriz reproduzida pela solução ajustada. O número de fatores restringe a dimensão máxima da estrutura comum, enquanto a rotação seleciona uma representação das cargas para interpretação sem alterar o critério de estimação.

Os fatores são variáveis latentes. Os escores fatoriais são valores calculados para estimar ou prever suas realizações associadas às unidades observacionais. Como sua obtenção exige um critério adicional, métodos diferentes podem produzir escores distintos para a mesma observação.

A ACP constrói componentes como combinações lineares das variáveis observadas, ordenadas segundo suas variâncias, enquanto a Análise Fatorial especifica um modelo latente que decompõe a matriz de covariâncias em parcelas comum e específica.

No Capítulo 16, o problema muda para a formação de grupos de observações. A Análise de Agrupamentos será formulada a partir de medidas de proximidade e de critérios que definem a semelhança entre observações e grupos.

16 Formulação da Análise de Agrupamentos

A Análise de Agrupamentos organiza objetos em grupos a partir de uma representação dos dados, de uma medida de proximidade e de um critério que define a organização procurada (Everitt et al., 2011).

Sua formulação reutiliza a matriz de dados da Definição 1.6, a distância euclidiana da Definição 1.13, as geometrias induzidas da Definição 3.17 e a decomposição da dispersão entre e dentro de grupos estabelecida na Proposição 8.10.

A formulação distingue partições, hierarquias e modelos probabilísticos de grupos. As K -médias definem uma partição pela minimização da dispersão intragrupos, enquanto os métodos hierárquicos constroem uma sequência de fusões segundo uma medida de proximidade e uma regra de ligação. Modelos de mistura fornecem uma definição probabilística alternativa de grupo. O capítulo também examina as decisões sobre representação dos objetos, número de grupos, inicialização, estabilidade e interpretação da solução.

Os elementos que definem o problema são organizados na Tabela 16.1.

Tabela 16.1: Elementos que definem um problema de Análise de Agrupamentos.

Elemento	Objeto	Papel na análise
Representação dos objetos	matriz de dados $\mathbf{X}$ ou matriz de dissimilaridades Δ	determina a informação disponível para comparar os objetos
Proximidade	distância, dissimilaridade ou similaridade	define como diferenças ou semelhanças entre objetos são quantificadas
Organização	partição $\mathcal{P}$ ou estrutura hierárquica	representa os grupos construídos
Critério	função de perda, medida de dispersão ou regra de ligação	define como organizações candidatas são avaliadas ou construídas
Solução	organização resultante	partição ou hierarquia obtida segundo o critério adotado

A mesma coleção de observações pode produzir agrupamentos diferentes quando um desses elementos é alterado. Por isso, a Análise de Agrupamentos não possui uma definição universal de grupo independente da representação, da proximidade e do critério utilizado.

16.1 O problema de formação de grupos

Considere n objetos representados pelas linhas da matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

conforme a Definição 1.6.

Os grupos não são conhecidos previamente. O objetivo é construir uma organização dos índices das observações segundo a representação dos objetos, a medida de proximidade e o critério adotado.

O significado de pertencer ao mesmo grupo depende desse critério. Nas K -médiãs, os grupos são definidos pela concentração das observações em torno de centroides; nos métodos hierárquicos, pela regra utilizada para comparar e reunir conjuntos de objetos.

Essa formulação distingue a Análise de Agrupamentos da Análise Discriminante (apresentada no Capítulo 19). Na Análise de Agrupamentos, a própria organização dos objetos faz parte da solução; na Análise Discriminante, os grupos são conhecidos previamente e integram a informação utilizada pela técnica.

A Figura 16.1 mostra uma mesma configuração bidimensional organizada de duas formas. A figura ilustra que os pontos observados, isoladamente, não determinam qual partição deve ser escolhida.

As duas organizações mantêm os mesmos pontos e alteram somente a regra utilizada para reuni-los. A figura representa uma característica da técnica: a estrutura de grupos deve ser interpretada em relação ao critério que a produziu.

16.2 Representação dos objetos e proximidade

A matriz de dados não é a única forma de entrada da Análise de Agrupamentos. Quando as coordenadas dos objetos estão disponíveis, a proximidade pode ser calculada a partir das linhas de $\mathbf{X}$. Quando as relações entre os objetos já são fornecidas diretamente, a análise pode partir de uma matriz de dissimilaridades.

A distância euclidiana definida na Definição 1.13, para duas observações $\mathbf{x}_i$ e $\mathbf{x}_j$, é




Figura 16.1: Diferentes partições de uma mesma configuração de observações.

$$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A distância euclidiana define a geometria das K -médias e participa, por meio das somas de quadrados intragrupos, da formulação do método de Ward.

Pela Definição 3.17, uma matriz positiva definida determina uma geometria ponderada para comprimentos e distâncias. Diferentes escolhas dessa geometria podem atribuir proximidades diferentes ao mesmo conjunto de observações. A distância de Mahalanobis, definida na Definição 8.9, é uma aplicação estatística dessa construção.

A Análise de Agrupamentos também pode receber como entrada uma matriz

$$\Delta = (\delta_{ij}) \in \mathbb{R}^{n \times n},$$

na qual δ_{ij} representa a dissimilaridade entre os objetos i e j .

16.3 Dissimilaridades entre objetos

Definição 16.1 (Dissimilaridade). Seja

$$\mathcal{I} = \{1, \dots, n\}$$

um conjunto de objetos. Uma **dissimilaridade** é uma função

$$\delta : \mathcal{I} \times \mathcal{I} \longrightarrow [0, \infty),$$

na qual valores maiores representam menor proximidade entre os objetos.

Neste capítulo, serão consideradas dissimilaridades que satisfazem

$$\delta(i, i) = 0, \quad i \in \mathcal{I},$$

e

$$\delta(i, j) = \delta(j, i), \quad i, j \in \mathcal{I}.$$

Não será exigido que

$$\delta(i, j) > 0 \quad \text{para} \quad i \neq j,$$

nem que seja satisfeita a desigualdade triangular.

A matriz associada a δ é

$$\Delta = (\delta_{ij}), \quad \delta_{ij} = \delta(i, j).$$

Assim, uma distância métrica pode ser utilizada como dissimilaridade, mas uma dissimilaridade não precisa satisfazer todas as propriedades exigidas de uma distância métrica (Everitt et al., 2011).

De forma correspondente, uma similaridade atribui valores maiores a objetos considerados mais semelhantes. A transformação entre similaridade e dissimilaridade depende da medida adotada e não constitui uma operação universal.

A distinção entre matriz de atributos e matriz de dissimilaridades é sintetizada na Tabela [16.2](#).

Tabela 16.2: Formas de representação utilizadas na Análise de Agrupamentos.

Representação	Informação disponível	Consequência para a formulação
$\mathbf{X} \in \mathbb{R}^{n \times p}$	valores das p variáveis para cada objeto	a proximidade é construída a partir das coordenadas
$\Delta \in \mathbb{R}^{n \times n}$	dissimilaridades entre pares de objetos	o agrupamento pode ser formulado diretamente sobre as relações entre objetos

A escolha entre essas representações também delimita os métodos disponíveis. O critério das K -médias utiliza explicitamente centroides no espaço das variáveis e requer as coordenadas das observações. Ligações simples, completa e média podem ser formuladas diretamente a partir das dissimilaridades entre objetos; procedimentos que dependem de centroides ou de somas de quadrados exigem estrutura adicional sobre a representação.

A presença de uma medida de dissimilaridade não significa que ela possa substituir livremente a distância euclidiana quadrática na formulação das K -médias. O centroide é o representante ótimo de um grupo porque a média minimiza a soma das distâncias euclidianas quadráticas às observações. Ao modificar essa função de perda, podem mudar o representante ótimo do grupo, a função objetivo e a própria definição do método. Por isso, procedimentos construídos a partir de outras dissimilaridades devem ser identificados pela formulação que efetivamente utilizam.

16.3.1 Efeito da escala

Pela Definição 1.13, a contribuição de cada coordenada para a distância depende de sua escala. A padronização observada é dada pela Equação 8.69. Na Análise de Agrupamentos, padronizar as variáveis modifica as proximidades e pode alterar os grupos obtidos.

A Figura 16.2 ilustra, em uma configuração bidimensional, como a mudança de escala modifica a geometria utilizada para comparar os mesmos objetos.

A ampliação da segunda coordenada aumenta sua contribuição para as distâncias. Um método baseado nessas distâncias passa a comparar os mesmos objetos segundo outra geometria.

A padronização não constitui uma exigência geral da Análise de Agrupamentos. Ao alterar a contribuição relativa das variáveis para as proximidades, ela modifica o problema geométrico resolvido pelo método.




Figura 16.2: Mudanças de escala alteram a geometria utilizada para comparar as observações.

16.4 Partições

Uma das formas mais comuns de representar um agrupamento é por meio de uma partição rígida do conjunto de objetos. Nesse tipo de partição, cada objeto é atribuído a um único grupo.

Seja

$$\mathcal{I} = \{1, \dots, n\}$$

o conjunto dos índices das observações.

Definição 16.2 (Partição em grupos). Uma **partição em K grupos** é uma coleção

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

de subconjuntos não vazios de $\mathcal{I}$ que satisfaz

$$C_k \cap C_\ell = \emptyset, \quad k \neq \ell,$$

e

$$\bigcup_{k=1}^K C_k = \mathcal{I}.$$

As duas condições estabelecem que:

- um objeto não pertence simultaneamente a dois grupos distintos;
- todos os objetos são atribuídos a algum grupo.

O número de elementos do grupo C_k será denotado por

$$n_k = |C_k|,$$

com

$$\sum_{k=1}^K n_k = n.$$

A partição é um objeto combinatório: ela descreve como as observações estão distribuídas entre os grupos. Essa representação informa a composição dos grupos, mas não especifica a medida de proximidade, o critério de agrupamento ou o procedimento utilizado para produzir essa divisão.

A atribuição de uma observação a um grupo pode ser representada por meio de indicadores de pertinência,

$$u_{ik} = \begin{cases} 1, & i \in C_k, \\ 0, & i \notin C_k. \end{cases}$$

Assim, $u_{ik} = 1$ indica que a observação i pertence ao grupo C_k , enquanto $u_{ik} = 0$ indica que ela não pertence a esse grupo.

Para uma partição rígida,

$$\sum_{k=1}^K u_{ik} = 1, \quad i = 1, \dots, n. \quad (16.1)$$

Como $u_{ik} \in \{0, 1\}$, essa restrição estabelece que, para cada observação i , exatamente um dos K indicadores de pertinência é igual a 1. Portanto, cada observação pertence a um único grupo.

16.4.1 Outras formas de pertinência

A partição rígida não é a única forma de representar a associação entre objetos e grupos. Métodos difusos podem atribuir graus de pertencimento a diferentes grupos, enquanto formulações probabilísticas podem associar probabilidades de pertinência às observações.

Essas representações correspondem a diferentes formas de expressar a pertinência dos objetos aos grupos. As K -médias produzem diretamente uma partição rígida; nos métodos hierárquicos, cada nível da hierarquia corresponde a uma partição dos objetos. Uma definição probabilística de grupo é apresentada na Seção 16.8.

16.5 Homogeneidade interna e separação

Uma partição só pode ser comparada com outras partições depois que se estabelece um critério de agrupamento.

Considere

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Alguns critérios avaliam diretamente a dispersão dentro dos grupos; outros utilizam relações de proximidade entre observações ou entre conjuntos de observações. A separação entre grupos pode resultar dessas construções sem constituir uma parcela explícita da função objetivo.

Nas K -médias, o critério é a dispersão quadrática intragrupos. A relação entre as dispersões intra e entre grupos é estabelecida pela Proposição 8.10.

A Proposição 10.5 estabelece que a média minimiza a soma das distâncias euclidianas quadráticas. Aplicada a cada grupo da partição, essa propriedade identifica seu centroide como o ponto que minimiza a dispersão quadrática intragrupo.

16.6 Agrupamento por centroides

Cada grupo de uma partição pode ser resumido geometricamente por seu centroide. Para

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

com

$$n_k = |C_k|,$$

o **centroide** do grupo C_k será denotado por

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i. \quad (16.2)$$

A notação $\bar{\mathbf{x}}_k$ explicita que o centroide é a média vetorial das observações pertencentes ao grupo C_k e o distingue do vetor de médias populacional μ_k .

No agrupamento por centroides, a proximidade entre uma observação e um grupo é determinada por sua distância ao centro correspondente. Essa representação permite definir critérios baseados na dispersão das observações em torno dos centroides.

16.6.1 Dispersão dentro e entre grupos

A Definição 8.14 e a Definição 8.15 definem as matrizes de dispersão dentro e entre grupos, e a Proposição 8.10 estabelece

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Nesses resultados, os grupos são dados. Na Análise de Agrupamentos, a mesma decomposição assume outra função: a partição é desconhecida e passa a integrar o problema de otimização.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

a matriz intragrupos pode ser escrita, utilizando os centroides definidos na Equação 16.2, como

$$\mathbf{T}_{\text{intra}}(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} (\mathbf{x}_i - \bar{\mathbf{x}}_k) (\mathbf{x}_i - \bar{\mathbf{x}}_k)^\top. \quad (16.3)$$

Tomando o traço,

$$\begin{aligned} \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})] &= \sum_{k=1}^K \sum_{i \in C_k} \text{tr}[(\mathbf{x}_i - \bar{\mathbf{x}}_k) (\mathbf{x}_i - \bar{\mathbf{x}}_k)^\top] \\ &= \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2. \end{aligned} \quad (16.4)$$

A Equação 16.4 expressa o traço da matriz intragrupos definida na Definição 8.14 como um critério escalar para comparar partições.

Quanto menores forem as distâncias quadráticas das observações aos centroides de seus grupos, menor será

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Como a matriz total $\mathbf{T}$ não depende da partição e

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue também que

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}). \quad (16.5)$$

Para K fixado, $\text{tr}(\mathbf{T})$ é constante em relação à partição. Portanto, minimizar $\text{tr}(\mathbf{T}_{\text{intra}})$ equivale a maximizar $\text{tr}(\mathbf{T}_{\text{entre}})$. As K -médias adotam o primeiro desses critérios.

16.6.2 Formulação das K -médias

O método das K -médias define os grupos pela minimização da soma das distâncias euclidianas quadráticas das observações aos centroides correspondentes (MacQueen, 1967). Na formulação conjunta, os centros são inicialmente tratados como variáveis do problema de otimização. Para uma partição fixada, os centros que minimizam o critério são os centroides dos grupos.

Definição 16.3 (Critério das K -médias). Para um número fixado de grupos K , com

$$1 \leq K \leq n,$$

considere os indicadores de pertinência u_{ik} e os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K \in \mathbb{R}^p.$$

O critério conjunto das K -médias é

$$Q_K(\{u_{ik}\}, \mathbf{c}_1, \dots, \mathbf{c}_K) = \sum_{i=1}^n \sum_{k=1}^K u_{ik} \|\mathbf{x}_i - \mathbf{c}_k\|^2, \quad (16.6)$$

sujeito a

$$u_{ik} \in \{0, 1\},$$

$$\sum_{k=1}^K u_{ik} = 1, \quad i = 1, \dots, n,$$

e

$$\sum_{i=1}^n u_{ik} \geq 1, \quad k = 1, \dots, K.$$

As duas primeiras restrições estabelecem uma atribuição rígida: u_{ik} é binário e cada observação pertence a exatamente um dos K grupos. A terceira restrição garante que todos os K grupos sejam não vazios.

Para uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

o critério após a minimização em relação aos centros é

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2, \quad (16.7)$$

em que

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i.$$

A propriedade de que esses centroides minimizam o critério para uma partição fixada decorre diretamente da Proposição 10.5.

Uma **solução global** das K -médias é qualquer partição

$$\mathcal{P}^* \in \arg \min_{\mathcal{P} \in \mathcal{A}_K} J_K(\mathcal{P}), \quad (16.8)$$

em que $\mathcal{A}_K$ é o conjunto das partições de $\{1, \dots, n\}$ em exatamente K grupos não vazios.

A existência e a possível não unicidade dessa solução são desenvolvidas na Seção 16.12.2.

Pela relação na Equação 16.4,

$$J_K(\mathcal{P}) = \text{tr}[\mathbf{T}_{\text{intra}}(\mathcal{P})]. \quad (16.9)$$

Nas K -médias, a estrutura da Definição 8.14 e da Proposição 8.10 é aplicada a uma partição desconhecida, que passa a integrar o problema de otimização.

A partir da Equação 16.5,

$$J_K(\mathcal{P}) = \text{tr}(\mathbf{T}) - \text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})].$$

Como

$$\text{tr}(\mathbf{T})$$

é constante para a mesma matriz de dados, minimizar o critério das K -médias equivale a maximizar

$$\text{tr}[\mathbf{T}_{\text{entre}}(\mathcal{P})]. \quad (16.10)$$

Como a dispersão entre grupos pode ser escrita em função dos centroides e de seus tamanhos,

$$\mathbf{T}_{\text{entre}} = \sum_{k=1}^K n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})(\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top,$$

tem-se

$$\text{tr}(\mathbf{T}_{\text{entre}}) = \sum_{k=1}^K n_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2. \quad (16.11)$$

Para a mesma matriz de dados e um valor fixado de K ,

$$\text{tr}(\mathbf{T})$$

é constante entre as partições admissíveis. Assim, uma partição minimiza

$$\text{tr}(\mathbf{T}_{\text{intra}})$$

se, e somente se, maximiza

$$\text{tr}(\mathbf{T}_{\text{entre}}).$$

As duas formulações caracterizam, portanto, o mesmo problema de otimização das K -médias para K fixado.

16.6.3 Partição para centros fixados

Considere os centros

$$\mathbf{c}_1, \dots, \mathbf{c}_K$$

como fixados. Desconsiderando momentaneamente a restrição de não vacuidade dos grupos, a contribuição de uma observação $\mathbf{x}_i$ ao critério é minimizada atribuindo-a a um centro pertencente a

$$\arg \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{c}_k\|^2. \quad (16.12)$$

Assim, cada observação é associada a um centro de menor distância. Em caso de empate, mais de uma atribuição pode produzir a mesma contribuição mínima.

Quando essa regra produz K grupos não vazios, ela também minimiza o critério entre as atribuições admissíveis para os centros fixados. Se algum centro não receber observações, a restrição de não vacuidade impede que o subproblema restrito seja resolvido apenas pela minimização ponto a ponto.

Essa propriedade, combinada ao fato de que o centroide minimiza a soma de quadrados para uma partição fixada, caracteriza a estrutura de otimização associada ao critério das K -médias.

16.6.4 Geometria das regiões de alocação

Para centros fixados, a regra na Equação 16.12 divide o espaço em regiões formadas pelos pontos mais próximos de cada centro.

Para dois centros $\mathbf{c}_k$ e $\mathbf{c}_\ell$, a fronteira entre suas regiões satisfaz

$$\|\mathbf{x} - \mathbf{c}_k\|^2 = \|\mathbf{x} - \mathbf{c}_\ell\|^2.$$

Expandindo os produtos internos e cancelando os termos comuns, obtém-se

$$2(\mathbf{c}_\ell - \mathbf{c}_k)^\top \mathbf{x} = \mathbf{c}_\ell^\top \mathbf{c}_\ell - \mathbf{c}_k^\top \mathbf{c}_k. \quad (16.13)$$

A fronteira é, portanto, um hiperplano.

Os centros determinam um diagrama de Voronoi: o espaço é coberto pelas regiões dos pontos para os quais cada centro é um dos mais próximos. Essas regiões podem compartilhar fronteiras quando há empate; para obter uma partição rígida do espaço, é necessário adotar uma regra de desempate nessas fronteiras. Uma região de Voronoi pode não conter nenhuma das observações

disponíveis para uma determinada configuração de centros; isso não altera sua definição geométrica.

Para centros fixados, cada região de Voronoi é determinada pela interseção das desigualdades que expressam que um centro é pelo menos tão próximo quanto os demais; essas regiões são convexas. Assim, a regra de alocação das K -médias divide o espaço em regiões convexas, exceto pela arbitrariedade de atribuição nas fronteiras de empate.

A Figura 16.3 representa uma solução com três centroides. As regiões de fundo indicam qual centroide é o mais próximo em cada posição do plano, enquanto os símbolos maiores identificam os centroides da solução.




Figura 16.3: Centroides e regiões de alocação definidas pela distância euclidiana.

Exemplo 16.1 (Comparação de duas partições). Considere quatro observações unidimensionais,

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 8, \quad x_4 = 9,$$

e duas partições candidatas com

$$K = 2.$$

Na primeira,

$$\mathcal{P}_1 = \{\{1, 2\}, \{3, 4\}\}.$$

Os centroides são

$$c_1 = 1,5$$

e

$$c_2 = 8,5.$$

Logo,

$$\begin{aligned} J_2(\mathcal{P}_1) &= (1 - 1,5)^2 + (2 - 1,5)^2 \\ &\quad + (8 - 8,5)^2 + (9 - 8,5)^2 \\ &= 1. \end{aligned}$$

Considere agora

$$\mathcal{P}_2 = \{\{1, 3\}, \{2, 4\}\}.$$

Os centroides são

$$c_1 = 4,5$$

e

$$c_2 = 5,5.$$

Nesse caso,

$$\begin{aligned}
J_2(\mathcal{P}_2) &= (1 - 4,5)^2 + (8 - 4,5)^2 \\
&\quad + (2 - 5,5)^2 + (9 - 5,5)^2 \\
&= 49.
\end{aligned}$$

Como

$$J_2(\mathcal{P}_1) = 1 < 49 = J_2(\mathcal{P}_2),$$

o critério atribui menor dispersão intragrupos a $\mathcal{P}_1$. A comparação utiliza a soma das distâncias quadráticas de cada observação ao centroide de seu grupo; distâncias entre pares de observações não entram isoladamente no critério das K -médias.

A comparação entre as partições é determinada pela soma das dispersões quadráticas dentro dos grupos. Distâncias elevadas entre alguns pares de observações, isoladamente, não definem a solução.

A formulação por centroides caracteriza grupos pela concentração quadrática em torno de centros. Os métodos hierárquicos utilizam outra estrutura: constroem uma sequência de agrupamentos aninhados a partir de regras de proximidade entre conjuntos.

16.7 Estrutura dos métodos hierárquicos

As K -médias procuram diretamente uma partição para um número K previamente fixado de grupos. Os métodos hierárquicos produzem outro objeto: uma sequência de partições aninhadas, na qual a organização dos grupos é construída progressivamente (Everitt et al., 2011).

Os métodos hierárquicos podem ser aglomerativos ou divisivos. Nos procedimentos **aglomerativos**, grupos menores são sucessivamente reunidos; nos **divisivos**, grupos maiores são progressivamente subdivididos. As formulações de ligação e do método de Ward desenvolvidas neste capítulo referem-se aos procedimentos aglomerativos.

A construção aglomerativa exige um critério para comparar os grupos disponíveis em cada etapa. Nas ligações simples, completa e média, esse critério é obtido a partir das dissimilaridades entre os objetos. No método de Ward, o critério é o aumento da dispersão quadrática intragrupos produzido por cada fusão. O dendrograma registra a hierarquia resultante.

Em um procedimento aglomerativo, parte-se da partição formada por n grupos unitários,

$$\mathcal{P}_n = \{\{1\}, \dots, \{n\}\},$$

e, a cada etapa, dois grupos são fundidos. Após uma fusão, obtém-se uma nova partição com um grupo a menos, até chegar a

$$\mathcal{P}_1 = \{\{1, \dots, n\}\}.$$

As partições sucessivas são aninhadas: um grupo formado em determinada etapa permanece contido em algum grupo das etapas posteriores.

Definição 16.4 (Hierarquia de agrupamentos). Uma **hierarquia aglomerativa** é uma sequência de partições

$$\mathcal{P}_n, \mathcal{P}_{n-1}, \dots, \mathcal{P}_1,$$

na qual $\mathcal{P}_{r-1}$ é obtida de $\mathcal{P}_r$ pela fusão de exatamente dois grupos.

Considere dois grupos não vazios

$$A \subseteq \{1, \dots, n\}$$

e

$$B \subseteq \{1, \dots, n\}.$$

Uma **regra de ligação** define uma dissimilaridade

$$D(A, B)$$

entre esses grupos. Não existe uma única extensão obrigatória da dissimilaridade entre objetos para a comparação entre conjuntos. Diferentes regras utilizam informações distintas sobre os elementos de A e B e, por isso, podem produzir hierarquias diferentes mesmo quando partem da mesma matriz Δ .

16.7.1 Ligações simples, completa e média

Três regras podem ser construídas diretamente a partir das dissimilaridades entre pares de objetos.

Na **ligação simples**,

$$D_{\text{simples}}(A, B) = \min_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.14)$$

A proximidade entre os grupos é determinada pelo par mais próximo. A fusão pode, portanto, ocorrer quando existe uma conexão curta entre dois conjuntos, mesmo que outros elementos estejam relativamente afastados.

Na **ligação completa**,

$$D_{\text{completa}}(A, B) = \max_{\substack{i \in A \\ j \in B}} \delta_{ij}. \quad (16.15)$$

A comparação é determinada pelo par mais distante. Essa definição favorece fusões nas quais todos os elementos dos dois grupos permanecem relativamente próximos.

Na **ligação média**,

$$D_{\text{media}}(A, B) = \frac{1}{n_A n_B} \sum_{i \in A} \sum_{j \in B} \delta_{ij}. \quad (16.16)$$

A dissimilaridade entre os grupos corresponde à média das dissimilaridades entre todos os pares formados por um elemento de A e um elemento de B .

As três regras utilizam a mesma matriz de dissimilaridades, mas representam noções distintas de proximidade entre conjuntos.

A Tabela 16.3 compara as três definições de proximidade entre grupos.

Tabela 16.3: Critérios de ligação construídos a partir das dissimilaridades entre objetos.

Regra de ligação	Dissimilaridade entre A e B	Estrutura privilegiada
simples	menor dissimilaridade entre pares	conexão entre elementos próximos
completa	maior dissimilaridade entre pares	controle da maior dissimilaridade entre os grupos candidatos à fusão

Regra de ligação	Dissimilaridade entre A e B	Estrutura privilegiada
média	média das dissimilaridades entre pares	proximidade média entre os conjuntos

A diferença entre os critérios pode ser observada mesmo com poucos objetos. Considere dois grupos

$$A = \{1, 2\}$$

e

$$B = \{3, 4\},$$

com dissimilaridades entre seus elementos dadas por

$$\delta_{13} = 2, \quad \delta_{14} = 8, \quad \delta_{23} = 3, \quad \delta_{24} = 7.$$

Então,

$$D_{\text{simples}}(A, B) = 2,$$

$$D_{\text{completa}}(A, B) = 8$$

e

$$D_{\text{média}}(A, B) = \frac{2 + 8 + 3 + 7}{2 \times 2} = 5.$$

Os três valores diferem porque cada regra define a dissimilaridade entre grupos por uma característica distinta dos pares formados entre A e B .

16.7.2 Método de Ward e dispersão intragrupos

O método de Ward utiliza um critério de fusão baseado na dispersão quadrática intragrupos. Para objetos representados por coordenadas em um espaço euclidiano, cada etapa compara os aumentos de dispersão produzidos pelas fusões admissíveis (Johnson; Wichern, 2002; Ward, 1963).

Essa interpretação utiliza a matriz $\mathbf{T}_{\text{intra}}$ definida na Definição 8.14 e a decomposição estabelecida na Proposição 8.10.

Proposição 16.1 (Incremento de dispersão no método de Ward). *Para dois grupos não vazios A e B , com tamanhos n_A e n_B e centroides $\bar{\mathbf{x}}_A$ e $\bar{\mathbf{x}}_B$, a fusão aumenta a soma de quadrados intragrupos em*

$$D_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2. \quad (16.17)$$

O método de Ward seleciona, em cada etapa, entre todas as fusões possíveis, aquela que produz o menor valor de D_{Ward} . Pela Equação 16.17, esse incremento depende dos tamanhos dos dois grupos e da distância euclidiana quadrática entre seus centroides.

Ward e K -médias utilizam a mesma medida de dispersão quadrática intragrupos, mas resolvem problemas diferentes.

Nas K -médias, para K fixado, procura-se uma partição que minimize globalmente

$$J_K(\mathcal{P}).$$

No método de Ward, a hierarquia é construída sequencialmente. Em cada etapa, são reunidos os dois grupos para os quais D_{Ward} é mínimo entre as fusões disponíveis (Johnson; Wichern, 2002; Ward, 1963).

Uma fusão realizada em uma etapa não é desfeita posteriormente. Por isso, cortar o dendrograma de Ward em K grupos não equivale, em geral, a resolver o problema global das K -médias para esse mesmo valor de K .

A Figura 16.4 representa a diferença conceitual entre ligação simples, ligação completa e Ward para dois grupos.

Na ligação simples, apenas o par mais próximo determina a comparação. Na ligação completa, utiliza-se o par mais afastado. Em Ward, a distância entre centroides participa de uma expressão ponderada pelos tamanhos dos grupos e determina o aumento produzido na dispersão intragrupos.

A ligação média não aparece na figura porque utiliza simultaneamente todos os pares entre os dois grupos e não pode ser representada por um único segmento.




Figura 16.4: Diferentes critérios utilizam diferentes características para medir a proximidade entre dois grupos.

16.7.3 Dendrograma e níveis de fusão

A sequência produzida por um método hierárquico pode ser representada por um dendrograma.

Definição 16.5 (Dendrograma). Um **dendrograma** é uma representação gráfica de uma hierarquia de agrupamentos na qual as folhas representam os objetos e as alturas das junções registram os níveis associados às fusões entre grupos.

O dendrograma representa a sequência de partições aninhadas produzida pelo método. Quando os níveis de fusão permitem essa separação, um corte horizontal seleciona uma das partições contidas na hierarquia. Esse corte identifica uma partição da sequência, mas não estabelece que ela seja preferível às demais.

A escolha do número de grupos e os critérios auxiliares utilizados nessa decisão são tratados na Seção 16.13.4.

A Figura 16.5 apresenta uma hierarquia simples construída a partir de seis objetos.

O significado do eixo vertical do dendrograma depende do critério utilizado. Na ligação simples, a altura registra a dissimilaridade associada à fusão. No método de Ward, ela está associada ao aumento da dispersão intragrupos, embora a escala exibida possa depender da convenção utilizada na implementação. Assim, alturas de dendrogramas produzidos por critérios diferentes não precisam representar a mesma quantidade.

16.7.4 Uma partição e uma hierarquia representam objetos diferentes

As K -médias produzem diretamente uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}.$$

Um método hierárquico produz uma coleção ordenada de partições aninhadas.

Essa diferença modifica o tipo de informação fornecida pela técnica e é sintetizada na Tabela 16.4.

Tabela 16.4: Estruturas produzidas por diferentes formulações de agrupamento.

Estrutura	Resultado principal	Critério
K -médias	uma partição para K fixado	minimização da dispersão quadrática intragrupos
ligação simples	uma hierarquia	menor dissimilaridade entre grupos

Estrutura	Resultado principal	Critério
ligação completa	uma hierarquia	maior dissimilaridade entre grupos
ligação média	uma hierarquia	média das dissimilaridades entre grupos
Ward	uma hierarquia	menor aumento da dispersão intragrupos

Nas K -médias, um grupo é representado por proximidade a um centroide. Na ligação simples, a formação de grupos depende da conectividade produzida por pares próximos. Na ligação completa, controla-se a maior dissimilaridade entre elementos de grupos candidatos à fusão. Na ligação média, considera-se conjuntamente o conjunto de dissimilaridades entre os dois grupos. Em Ward, a fusão é avaliada por seu efeito sobre a dispersão quadrática intragrupos.

Além disso, uma partição selecionada de uma hierarquia não precisa coincidir com a solução obtida pela otimização direta de um critério para o mesmo número de grupos. A hierarquia conserva as fusões realizadas anteriormente e, portanto, restringe as partições que podem aparecer nas etapas posteriores.

Além dessas formulações geométricas, grupos também podem ser definidos probabilisticamente por meio de modelos de mistura. Essa definição probabilística é apresentada na Seção 16.8.

16.8 Diferentes definições matemáticas de grupo

Uma forma diferente de definir grupos é por meio de um modelo probabilístico (Everitt et al., 2011). Em vez de procurar diretamente uma partição das observações, supõe-se que a distribuição do vetor aleatório $\mathbf{X}$ seja formada por uma mistura de K distribuições,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}),$$

em que

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

A componente k é representada por uma distribuição com densidade $f_k(\mathbf{x})$ e descreve uma subpopulação no modelo probabilístico. Portanto, uma componente não corresponde a uma observação $\mathbf{x}_i$ nem a um conjunto de índices C_k .




Figura 16.5: Representação hierárquica das fusões entre seis objetos. A altura registra o nível da fusão.

O peso π_k representa a probabilidade de uma observação da população provir da componente k antes de seu valor ser observado. Os pesos também determinam as proporções das componentes na população modelada.

Seja C uma variável que indica a componente associada a uma observação. Então,

$$P(C = k) = \pi_k,$$

e

$$f(\mathbf{x} \mid C = k) = f_k(\mathbf{x}).$$

Depois de observar $\mathbf{x}_i$, o Teorema de Bayes permite atualizar a probabilidade associada a cada componente. A probabilidade *a posteriori* de associação da observação i à componente k é

$$P(C = k \mid \mathbf{X} = \mathbf{x}_i) = \frac{\pi_k f_k(\mathbf{x}_i)}{\sum_{\ell=1}^K \pi_\ell f_\ell(\mathbf{x}_i)}.$$

Essa probabilidade combina o peso π_k da componente com o valor de sua densidade em $\mathbf{x}_i$, dado por $f_k(\mathbf{x}_i)$. Assim, uma observação pode apresentar probabilidades diferentes de associação às K componentes. Essas probabilidades expressam a incerteza sobre qual componente está associada à observação e não significam que ela pertença simultaneamente a vários grupos.

Componente e grupo são objetos distintos. A componente k pertence ao modelo probabilístico. Se posteriormente for construída uma classificação rígida, o grupo C_k será formado pelos índices das observações classificadas como associadas à componente k .

Essa formulação difere de uma partição rígida. Nas K -médias e nas partições obtidas pelo corte de uma hierarquia, cada observação é atribuída diretamente a um único grupo na solução considerada. Em um modelo de mistura, a associação é inicialmente expressa por probabilidades relativas às componentes. Uma classificação rígida pode ser construída posteriormente, atribuindo cada observação a uma única componente e formando, então, os grupos $C_1, \dots, C_K$.

Os modelos de mistura não são, em sua formulação usual, métodos hierárquicos. Para um número K previamente fixado de componentes, o modelo considera essas K componentes conjuntamente. Nesse aspecto, sua construção é mais próxima das K -médias do que dos métodos hierárquicos: em ambos os casos, parte-se de um valor de K e procura-se uma solução com K grupos. A diferença é que as K -médias utilizam um critério baseado em distâncias aos centroides, enquanto os modelos de mistura utilizam uma formulação probabilística.

A distribuição associada a cada componente deve ser especificada no modelo. Quando essa distribuição é escolhida como normal multivariada, a componente k é caracterizada por um

vetor de médias μ_k e uma matriz de covariâncias Σ_k . O modelo resultante é denominado **mistura de normais multivariadas**.

A normalidade multivariada, portanto, não é necessária para definir modelos de mistura em geral. Ela corresponde a uma escolha específica para as distribuições que compõem a mistura.

A formulação probabilística dos modelos de mistura é desenvolvida na Seção 16.12.7. Outras abordagens podem definir grupos por conectividade ou por regiões de elevada concentração de observações.

16.9 Dependência da solução e limites da formulação

A Análise de Agrupamentos não possui um conjunto único de pressupostos probabilísticos. As K -médias e os métodos hierárquicos podem ser formulados geometricamente, sem hipótese de normalidade multivariada ou de um modelo probabilístico gerador. Quando um modelo de mistura é utilizado, as hipóteses adotadas para as distribuições que compõem a mistura passam a integrar a formulação.

A solução depende das escolhas que definem o problema. A Tabela 16.5 resume essas dependências.

Tabela 16.5: Elementos dos quais depende uma solução de agrupamento.

Elemento modificado	Estrutura alterada	Consequência possível
conjunto de variáveis	representação dos objetos	proximidades e grupos podem mudar
escala das variáveis	geometria do espaço	variáveis recebem pesos relativos diferentes
métrica ou dissimilaridade	relação de proximidade	pares considerados próximos podem mudar
número K	conjunto de partições admissíveis	altera o conjunto sobre o qual o critério é otimizado
função objetivo	critério de qualidade da partição	partições diferentes podem se tornar ótimas
regra de ligação	critério de comparação entre grupos	pode alterar a sequência de fusões e a hierarquia
modelo probabilístico	definição das componentes	muda a interpretação dos grupos

Adicionar, retirar ou transformar variáveis modifica a representação dos objetos e pode alterar as relações de proximidade. Mudanças de escala e de métrica modificam a geometria utilizada para compará-los.

Observações muito afastadas das demais também podem alterar a solução. Nas K -médias, elas podem deslocar centroides e aumentar fortemente a dispersão quadrática; nos métodos hierárquicos, podem modificar as proximidades e a sequência de fusões. Como as fusões realizadas por um procedimento aglomerativo não são desfeitas, seus efeitos podem permanecer nas etapas posteriores da hierarquia (Hair et al., 2009; Johnson; Wichern, 2002).

A forma de grupo procurada também depende do critério. As K -médias representam grupos por centroides e minimizam dispersão quadrática intragrupos. As ligações simples, completa e média utilizam diferentes definições de proximidade entre conjuntos. O método de Ward seleciona fusões segundo o aumento da dispersão intragrupos. Em modelos de mistura, os grupos são representados pelas componentes da distribuição de mistura especificada.

A solução pode não ser única. Nas K -médias, diferentes partições podem atingir o mesmo mínimo; nos métodos hierárquicos, empates podem produzir diferentes sequências de fusões. Além disso, os rótulos atribuídos aos grupos são arbitrários.

Os pressupostos e os limites devem, portanto, ser interpretados relativamente à formulação utilizada. A representação dos objetos, a proximidade e o critério de agrupamento fazem parte da própria definição do problema.

16.10 Limites da interpretação dos grupos

A Análise de Agrupamentos é uma técnica não supervisionada: os rótulos dos grupos não são conhecidos previamente.

Uma solução obtida por K -médias, por um método hierárquico ou por um modelo de mistura descreve uma organização dos objetos segundo a formulação adotada. A existência dessa solução não demonstra que os dados tenham sido gerados por populações distintas.

Solução de agrupamento e categorias externas

Uma solução de agrupamento organiza os objetos segundo as variáveis, a medida de proximidade e o critério utilizados. Essa solução não estabelece, por si só, correspondência com categorias definidas por informações externas ao procedimento de agrupamento. Essa correspondência deve ser examinada utilizando variáveis que não participaram da formação dos grupos ou outras informações externas ao procedimento.

16.11 Relações com outras técnicas multivariadas

A Análise de Agrupamentos compartilha alguns objetos matemáticos com outras técnicas do módulo, mas atribui a eles funções diferentes. A Tabela 16.6 resume essas relações.

Tabela 16.6: Relações entre a Análise de Agrupamentos e outras técnicas multivariadas.

Técnica relacionada	Estrutura compartilhada	Diferença principal
ACP	representação geométrica das observações	ACP constrói componentes como combinações lineares das variáveis; Agrupamentos constrói grupos
Análise Discriminante	grupos, médias e dispersões	Agrupamentos constrói grupos; Discriminante utiliza grupos conhecidos
MANOVA	dispersão dentro e entre grupos	Agrupamentos utiliza a dispersão para construir grupos; MANOVA utiliza grupos definidos pelo delineamento para testar efeitos

16.11.1 Agrupamentos e ACP

No Capítulo 14, os escores das componentes principais fornecem uma nova representação das observações. Quando todas as componentes de uma transformação ortogonal são mantidas, as distâncias euclidianas são preservadas pela Proposição 4.10.

Quando apenas $k < p$ componentes são mantidas, as observações são projetadas sobre o subespaço principal da Definição 14.2. As distâncias passam, então, a ser calculadas na representação reduzida e podem diferir das distâncias no espaço original.

Assim, utilizar ACP antes de uma Análise de Agrupamentos modifica o problema sempre que ocorre redução efetiva de dimensão ou mudança prévia da representação dos dados.

16.11.2 Agrupamentos e Análise Discriminante

Na Análise de Agrupamentos, os grupos fazem parte da solução. Na Análise Discriminante formulada no Capítulo 19, os grupos são conhecidos previamente e integram a informação utilizada para construir funções discriminantes ou regras de classificação.

As duas técnicas podem utilizar médias, dispersões e distâncias, mas esses objetos possuem funções estatísticas distintas conforme o problema considerado.

16.11.3 Agrupamentos e MANOVA

A conexão com a MANOVA formulada no Capítulo 18 aparece na decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

estabelecida na Proposição 8.10.

Nas K -médias, a partição é desconhecida e procura-se reduzir

$$\text{tr}(\mathbf{T}_{\text{intra}}).$$

Na MANOVA, os grupos ou tratamentos são definidos pelo delineamento, e estruturas de dispersão participam da formulação inferencial sobre diferenças entre vetores de médias.

O mesmo objeto matricial pode, portanto, participar de técnicas diferentes sem desempenhar a mesma função estatística.

16.12 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte desenvolve propriedades matemáticas das soluções de agrupamento. São examinados o centroide como minimizador do critério quadrático, a existência e a não unicidade das soluções, a redução do critério pelas etapas alternadas das K -médias, as transformações que preservam a ordenação das partições e a solução do critério, a derivação do incremento de Ward, a não unicidade associada a empates nos métodos hierárquicos e a formulação probabilística de grupos por modelos de mistura.

16.12.1 O centroide como minimizador

Aplicando a Equação 10.52 e a Proposição 10.5 às observações de um grupo não vazio C_k , seu centroide

$$\bar{\mathbf{x}}_k = \frac{1}{n_k} \sum_{i \in C_k} \mathbf{x}_i$$

é o único ponto que minimiza

$$\sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{c}\|^2$$

em relação a $\mathbf{c} \in \mathbb{R}^p$.

O uso da média como representante do grupo decorre, portanto, da distância euclidiana quadrática utilizada pelo critério das K -médias. Outras funções de perda podem produzir representantes diferentes.

16.12.2 Existência e não unicidade da solução

Para uma matriz de dados com n observações e um valor fixado de

$$1 \leq K \leq n,$$

existe um número finito de partições das observações em exatamente K grupos não vazios. Como

$$J_K(\mathcal{P}) \geq 0,$$

o conjunto dos valores de $J_K(\mathcal{P})$ possui um mínimo. Portanto, existe pelo menos uma solução global para o problema definido na Equação 16.8.

A existência do mínimo não implica unicidade. Duas ou mais partições distintas podem atingir o mesmo valor mínimo.

Além disso, permutar os rótulos dos grupos não produz uma nova organização das observações. Se

$$\mathcal{P} = \{C_1, \dots, C_K\},$$

qualquer permutação desses mesmos conjuntos representa a mesma partição, embora utilize outra numeração para os grupos.

16.12.3 Algoritmo alternante das K -médias e redução do critério

O problema que define uma solução global na Equação 16.8 consiste em minimizar $J_K(\mathcal{P})$ sobre todas as partições admissíveis. Os algoritmos usuais de K -médias procuram reduzir esse critério alternando dois subproblemas já estabelecidos no núcleo: atribuição aos centroides mais próximos e atualização dos centroides pelas médias dos grupos (Johnson; Wichern, 2002).

Proposição 16.2 (Redução do critério nas etapas alternadas das K -médias). *Considere uma partição*

$$\mathcal{P}^{(t)} = \{C_1^{(t)}, \dots, C_K^{(t)}\}$$

em grupos não vazios e seus centroides

$$\bar{\mathbf{x}}_1^{(t)}, \dots, \bar{\mathbf{x}}_K^{(t)}.$$

Suponha que a etapa de atribuição associe cada observação a um centroide de menor distância, conforme a Equação 16.12, e produza novamente K grupos não vazios. Denote a nova partição por

$$\mathcal{P}^{(t+1)} = \{C_1^{(t+1)}, \dots, C_K^{(t+1)}\}.$$

Após recalcular os centroides dos novos grupos,

$$\bar{\mathbf{x}}_k^{(t+1)} = \frac{1}{|C_k^{(t+1)}|} \sum_{i \in C_k^{(t+1)}} \mathbf{x}_i,$$

o critério satisfaz

$$J_K(\mathcal{P}^{(t+1)}) \leq J_K(\mathcal{P}^{(t)}).$$

i Demonstração

Sejam $u_{ik}^{(t)}$ os indicadores associados à partição $\mathcal{P}^{(t)}$. Como cada observação é atribuída a um centroide de menor distância, a Equação 16.12 implica

$$Q_K(\{u_{ik}^{(t+1)}\}, \bar{\mathbf{x}}_1^{(t)}, \dots, \bar{\mathbf{x}}_K^{(t)}) \leq Q_K(\{u_{ik}^{(t)}\}, \bar{\mathbf{x}}_1^{(t)}, \dots, \bar{\mathbf{x}}_K^{(t)}).$$

Como os centros atuais são os centroides da partição $\mathcal{P}^{(t)}$,

$$Q_K(\{u_{ik}^{(t)}\}, \bar{\mathbf{x}}_1^{(t)}, \dots, \bar{\mathbf{x}}_K^{(t)}) = J_K(\mathcal{P}^{(t)}).$$

Fixada agora a nova partição $\mathcal{P}^{(t+1)}$, seus centroides minimizam a soma de quadrados dentro dos grupos, conforme a Proposição 10.5. Portanto,

$$J_K(\mathcal{P}^{(t+1)}) \leq Q_K(\{u_{ik}^{(t+1)}\}, \bar{\mathbf{x}}_1^{(t)}, \dots, \bar{\mathbf{x}}_K^{(t)}).$$

Combinando as duas desigualdades,

$$J_K(\mathcal{P}^{(t+1)}) \leq J_K(\mathcal{P}^{(t)}).$$

A proposição estabelece uma propriedade de descida do critério. Se uma etapa não modifica mais as atribuições, a partição é estável em relação às duas operações alternadas.

Essa estabilidade não implica que a solução obtida seja um minimizador global do problema definido na Equação 16.8. Diferentes inicializações podem conduzir a partições estáveis distintas e a valores diferentes de J_K (Johnson; Wichern, 2002).

Quando cada mudança efetiva de partição produz redução estrita do critério, o número finito de partições admissíveis impede uma sequência infinita de mudanças. Na presença de empates, o critério pode não determinar univocamente a atribuição, sendo necessária uma regra de desempate para definir a sequência produzida pelo algoritmo.

16.12.4 Transformações que preservam a solução das K -médias

Considere a transformação

$$\mathbf{x}_i^* = \mathbf{a} + c\mathbf{Q}\mathbf{x}_i,$$

em que

$$\mathbf{a} \in \mathbb{R}^p, \quad c \neq 0, \quad \mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Para uma partição fixada, o centroide transformado do grupo C_k é

$$\bar{\mathbf{x}}_k^* = \mathbf{a} + c\mathbf{Q}\bar{\mathbf{x}}_k.$$

Logo,

$$\begin{aligned}\|\mathbf{x}_i^* - \bar{\mathbf{x}}_k^*\|^2 &= \|c\mathbf{Q}(\mathbf{x}_i - \bar{\mathbf{x}}_k)\|^2 \\ &= c^2 \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2,\end{aligned}$$

pela preservação da norma por transformações ortogonais estabelecida na Proposição 4.10.

Assim, para qualquer partição admissível,

$$J_K^*(\mathcal{P}) = c^2 J_K(\mathcal{P}). \quad (16.18)$$

Como $c^2 > 0$, a transformação preserva a ordenação das partições segundo o critério. Portanto,

$$\arg \min_{\mathcal{P} \in \mathcal{A}_K} J_K^*(\mathcal{P}) = \arg \min_{\mathcal{P} \in \mathcal{A}_K} J_K(\mathcal{P}).$$

Esse resultado reúne translações, rotações, reflexões e mudanças comuns de escala. Mudanças distintas de escala entre variáveis não pertencem a essa classe e podem alterar a solução, como mostra a Figura 16.2.

16.12.5 Derivação do incremento de Ward

A Proposição 16.1 define o incremento de Ward como a diferença entre a dispersão intragrupos depois e antes da fusão. A seguir, deriva-se sua expressão em função dos tamanhos e dos centroides dos dois grupos.



i Demonstração

Considere a partição

$$\mathcal{P}_K = \{C_1, C_2, \dots, C_K\},$$

e suponha que C_1 e C_2 sejam fundidos, formando

$$C_{12} = C_1 \cup C_2.$$

A partição resultante é

$$\mathcal{P}_{K-1} = \{C_{12}, C_3, \dots, C_K\}.$$

Se

$$n_1 = |C_1|, \quad n_2 = |C_2|,$$

o centroide do grupo resultante é

$$\bar{\mathbf{x}}_{12} = \frac{n_1 \bar{\mathbf{x}}_1 + n_2 \bar{\mathbf{x}}_2}{n_1 + n_2}. \quad (16.19)$$

Antes da fusão, a dispersão quadrática intragrupos é

$$J_K(\mathcal{P}_K) = \sum \|\mathbf{x}_i - \bar{\mathbf{x}}_1\|^2 + \sum \|\mathbf{x}_i - \bar{\mathbf{x}}_2\|^2$$

16.12.6 Empates e não unicidade da hierarquia

Em uma etapa do procedimento aglomerativo, mais de um par de grupos pode apresentar o mesmo menor valor do critério de ligação. Nesse caso, o critério não determina sozinho qual fusão deve ocorrer primeiro, e diferentes regras de desempate podem produzir sequências posteriores distintas.

Essa não unicidade deve ser distinguida da liberdade de reordenar graficamente as folhas de um dendrograma sem modificar a hierarquia representada. A primeira pertence à construção da solução; a segunda é apenas uma propriedade de sua representação gráfica.

16.12.7 Modelos de mistura como definição probabilística de grupos

A definição probabilística de grupo apresentada na Seção 16.8 pode ser formalizada por meio de uma variável categórica latente.

Considere

$$C \in \{1, \dots, K\},$$

com

$$P(C = k) = \pi_k, \quad \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Se, condicionalmente a $C = k$, o vetor aleatório $\mathbf{X}$ possui densidade

$$f_k(\mathbf{x}; \theta_k),$$

então, pela lei da probabilidade total, sua densidade marginal possui a forma definida a seguir.

Definição 16.6 (Modelo de mistura para agrupamento). Um **modelo de mistura para agrupamento** representa a distribuição das observações como uma combinação de K componentes probabilísticas,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k). \quad (16.20)$$

Nessa formulação, o grupo é representado pela componente associada à variável latente categórica C . O conceito de grupo é, portanto, diferente daquele definido por proximidade a centroides ou por regras de ligação.

Para um valor $\mathbf{x}$ tal que

$$f(\mathbf{x}) > 0,$$

a associação às componentes pode ser descrita pelas probabilidades posteriores

$$P(C = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x}; \theta_k)}{\sum_{\ell=1}^K \pi_\ell f_\ell(\mathbf{x}; \theta_\ell)}. \quad (16.21)$$

Em contraste com uma partição rígida, uma observação pode apresentar probabilidades posteriores positivas de associação a várias componentes. Uma classificação rígida associada ao modelo pode ser obtida escolhendo

$$\hat{C}(\mathbf{x}) \in \arg \max_{1 \leq k \leq K} P(C = k \mid \mathbf{X} = \mathbf{x}).$$

Quando o máximo é único, a observação recebe diretamente o rótulo da componente com maior probabilidade posterior. Em caso de empate, é necessária uma regra de desempate para produzir uma classificação rígida.

Essa classificação posterior não elimina a informação probabilística da solução: além do rótulo atribuído, permanecem disponíveis as probabilidades de associação às diferentes componentes.

A normalidade multivariada não é necessária para a definição do modelo. Quando

$$f_k(\mathbf{x}; \theta_k)$$

é escolhida como uma densidade normal multivariada, cada componente é caracterizada por seu vetor de médias e sua matriz de covariâncias. Outras escolhas para as distribuições que compõem a mistura produzem modelos de mistura diferentes.

O modelo de mistura introduz, portanto, uma definição probabilística de grupo. Ele não constitui uma hipótese necessária para as K -médias ou para os métodos hierárquicos desenvolvidos no núcleo.

16.13 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte reúne decisões e procedimentos utilizados na condução da Análise de Agrupamentos. São examinados a preparação da representação dos objetos, o tratamento de dados mistos, a escolha do número de grupos, a inicialização das K -médias, as convenções computacionais do método de Ward e a avaliação da estabilidade, validação e interpretação dos grupos.

16.13.1 Preparação da representação para o agrupamento

Na Análise de Agrupamentos, as variáveis utilizadas para representar os objetos participam diretamente da definição de proximidade. Sua escolha, escala e redundância podem modificar a solução antes mesmo da aplicação do algoritmo (Hair et al., 2009).

16.13.1.1 Variáveis utilizadas na formação dos grupos

O conjunto de variáveis deve ser definido de acordo com o objetivo da análise. Incluir uma variável significa permitir que suas diferenças participem da construção dos grupos.

Variáveis destinadas apenas à caracterização ou à validação externa dos grupos podem ser mantidas fora da formação da partição e examinadas posteriormente. Essa separação evita utilizar a mesma informação simultaneamente para construir e para avaliar os grupos.

16.13.1.2 Escala e ponderação

O efeito da escala foi desenvolvido na Seção 16.3.1. Na condução da análise, deve-se decidir se diferenças nas unidades e amplitudes das variáveis devem produzir contribuições diferentes para as proximidades entre os objetos.

Quando essa ponderação não é desejada, a padronização pode colocar as variáveis em escalas comparáveis. Quando as diferenças de escala devem participar da definição de proximidade, a padronização modifica essa relação e não deve ser adotada automaticamente.

16.13.1.3 Redundância entre variáveis

Variáveis fortemente relacionadas podem produzir uma forma de ponderação implícita. Se várias variáveis representam praticamente a mesma característica, essa característica participa repetidamente do cálculo das proximidades.

Assim, mesmo quando todas as variáveis recebem o mesmo peso explícito, um conjunto numeroso de variáveis redundantes pode dominar a geometria da análise.

Esse problema difere da multicolinearidade em modelos de regressão. Na Análise de Agrupamentos, variáveis redundantes atribuem maior peso implícito às características que representam repetidamente no cálculo das proximidades (Hair et al., 2009).

16.13.1.4 Observações atípicas e representatividade

Observações afastadas das demais podem exercer forte influência sobre distâncias, centroides e fusões hierárquicas. Sua identificação não implica exclusão automática.

Uma observação atípica pode representar:

- erro de mensuração ou de registro;
- uma unidade que não pertence à população definida para a análise;
- uma unidade incomum, mas pertencente à população;
- uma observação de um grupo pequeno que está sub-representado na amostra.

A decisão deve considerar a origem da observação e o objetivo da análise. A retirada de unidades pertencentes a grupos pequenos pode eliminar justamente uma estrutura que deveria ser identificada.

A generalização dos grupos também depende da relação entre a amostra e a população de interesse. O procedimento de agrupamento não corrige a ausência ou a sub-representação, na amostra, de partes da população que deveriam participar da análise (Hair et al., 2009).

16.13.1.5 Tamanho da amostra e grupos pequenos

Na Análise de Agrupamentos, não há um tamanho amostral mínimo geral determinado por poder estatístico ou por uma distribuição de referência. A adequação do tamanho da amostra depende de sua capacidade de representar a heterogeneidade da população e, em particular, grupos de baixa frequência que sejam importantes para o objetivo da análise (Hair et al., 2009).

Uma amostra pode não conter observações de um grupo raro existente na população. Nessa situação, especificar um número maior de grupos não recupera uma estrutura que não está representada nos dados (Hair et al., 2009).

Também deve ser examinada a quantidade de observações disponível em cada grupo candidato. Grupos muito pequenos podem representar unidades atípicas, grupos raros ou instabilidade da solução. O tamanho do grupo, isoladamente, não determina sua exclusão; sua interpretação depende do objetivo da análise, da origem das observações e da possibilidade de caracterizar adequadamente o grupo.

Tabela 16.7: Aspectos da preparação da representação que afetam a Análise de Agrupamentos.

Aspecto	Efeito sobre a solução	Questão metodológica
seleção das variáveis	define quais características participam da proximidade	as variáveis representam o conceito segundo o qual os objetos devem ser agrupados?
escala	altera a contribuição relativa das variáveis	diferenças de escala devem funcionar como ponderação?
redundância	repete implicitamente algumas dimensões	várias variáveis estão representando a mesma característica?
observações atípicas	podem deslocar centroides ou formar grupos isolados	são erros, unidades relevantes ou grupos sub-representados?
tamanho da amostra	pode impedir que grupos de baixa frequência estejam representados nos dados	há observações suficientes para representar e caracterizar os grupos relevantes?

16.13.2 Dados mistos e dissimilaridade de Gower

A formulação euclidiana das K -médias utiliza variáveis quantitativas representadas em um espaço euclidiano. Quando os objetos são descritos simultaneamente por variáveis quantitativas, ordinais e nominais, conforme a distinção apresentada na Seção 1.2, a comparação entre observações exige uma representação que respeite a natureza de cada atributo.

Uma possibilidade é a dissimilaridade derivada do coeficiente geral de similaridade proposto por Gower (Gower, 1971). Para dois objetos i e h , sua forma geral pode ser escrita como

$$d_G(i, h) = \frac{\sum_{j=1}^p w_{ijh} d_{ijh}}{\sum_{j=1}^p w_{ijh}}, \quad (16.22)$$

em que d_{ijh} representa a dissimilaridade parcial entre os objetos na variável j e w_{ijh} indica se essa comparação participa do cálculo. A expressão é definida quando

$$\sum_{j=1}^p w_{ijh} > 0,$$

isto é, quando existe pelo menos uma variável disponível para comparar os dois objetos.

A construção de d_{ijh} depende do tipo de variável. Para uma variável quantitativa, uma forma usual é dividir a diferença absoluta pela amplitude observada,

$$d_{ijh} = \frac{|x_{ij} - x_{hj}|}{R_j},$$

quando $R_j > 0$. Para uma variável nominal, a dissimilaridade parcial pode assumir valor 0 para categorias iguais e 1 para categorias diferentes. Para variáveis ordinais, é necessário definir uma codificação que preserve a ordenação das categorias antes de construir a contribuição parcial para a dissimilaridade. A regra adotada deve ser explicitada, pois modifica os valores de d_{ijh} .

A combinação dessas contribuições produz uma medida comum para atributos de naturezas distintas. Essa possibilidade não transforma a formulação clássica das K -médias em um método baseado em distância de Gower. O critério das K -médias continua definido pela minimização de distâncias euclidianas quadráticas em torno de centroides.

Procedimentos destinados a dados mistos podem utilizar outros representantes e outras funções objetivo. O método de K -prototypes combina critérios para as partes quantitativa e categórica da representação (Huang, 1998). O representante de um grupo deixa de ser descrito exclusivamente pelo vetor de médias utilizado nas K -médias.

16.13.3 Escolha da medida de proximidade e do procedimento

A medida de proximidade e o procedimento de agrupamento devem ser escolhidos de forma compatível. A mesma matriz de dados pode produzir soluções diferentes quando muda a geometria utilizada para comparar os objetos ou o critério que define a formação dos grupos.

A primeira decisão é determinar qual informação deve representar a proximidade entre os objetos. Para variáveis quantitativas, a distância euclidiana utiliza diretamente as diferenças entre suas coordenadas e é compatível com métodos baseados em centroides e dispersão quadrática. A distância de Mahalanobis incorpora a estrutura de covariâncias e modifica a geometria segundo a variabilidade e a associação entre as variáveis, conforme a Definição 8.9.

A medida de proximidade também depende do aspecto dos objetos que deve definir a semelhança. Medidas de distância comparam suas posições no espaço das variáveis. Medidas baseadas em correlação podem, quando pertinente ao objetivo da análise, comparar o padrão relativo das características (Hair et al., 2009). Nesse caso, objetos com níveis distintos podem apresentar

padrões semelhantes. O procedimento de agrupamento deve ser compatível com a medida adotada.

Para dados de tipos diferentes, uma matriz de dissimilaridades construída pela medida de Gower pode fornecer uma representação comum, conforme a Seção 16.13.2. Nesse caso, o procedimento subsequente deve aceitar uma matriz de dissimilaridades ou utilizar uma função objetivo própria para dados mistos.

A segunda decisão é definir qual noção de grupo é compatível com o objetivo da análise. Os principais procedimentos desenvolvidos neste capítulo privilegiam estruturas diferentes.

Tabela 16.8: Relação entre procedimentos de agrupamento e a estrutura privilegiada por seus critérios.

Procedimento	Informação utilizada na formação dos grupos	Estrutura favorecida	Aspecto a examinar
<i>K</i>-médias	distâncias euclidianas quadráticas aos centroides	grupos concentrados em torno de médias	depende de <i>K</i> e da inicialização
ligação simples	menor dissimilaridade entre dois grupos	conectividade entre observações próximas	pode produzir encadeamento
ligação completa	maior dissimilaridade entre dois grupos	grupos mais compactos em relação ao diâmetro	depende de pares extremos
ligação média	média das dissimilaridades entre todos os pares dos dois grupos	compromisso entre proximidade local e dispersão global	utiliza toda a comparação entre os grupos
Ward	aumento da dispersão quadrática intragrupos	grupos compactos segundo a dispersão quadrática intragrupos	requer compatibilidade com a geometria euclidiana adotada

A ligação simples pode reunir objetos por cadeias sucessivas de proximidade. Essa propriedade permite representar estruturas conectadas que não precisam ser compactas, mas também torna o método sensível à presença de pontes formadas por observações intermediárias.

A ligação completa utiliza a maior dissimilaridade entre os grupos candidatos à fusão. Ela evita o mecanismo de encadeamento da ligação simples e tende a produzir grupos mais compactos, embora a comparação dependa dos elementos mais afastados de cada par de grupos.

A ligação média utiliza todas as dissimilaridades entre os dois grupos e não depende exclusivamente do par mais próximo ou mais afastado. Por isso, representa uma alternativa intermediária entre as ligações simples e completa (Hair et al., 2009).

O método de Ward procura limitar o aumento da dispersão intragrupos a cada fusão. Sua interpretação está diretamente vinculada à formulação quadrática desenvolvida na Seção 16.7.2. Observações atípicas podem alterar fortemente essa dispersão e, conseqüentemente, a sequência de fusões.

As K -médias utilizam uma partição com número de grupos previamente especificado e permitem a realocação das observações durante a busca computacional. Métodos hierárquicos produzem simultaneamente uma sequência de partições aninhadas e não desfazem fusões realizadas em etapas anteriores (Johnson; Wichern, 2002).

Quando o objetivo e os dados permitem mais de um procedimento, a comparação entre soluções permite examinar a sensibilidade da estrutura às escolhas metodológicas. Se procedimentos e medidas de proximidade plausíveis conduzem a organizações semelhantes, a interpretação apresenta menor dependência de uma escolha específica (Johnson; Wichern, 2002).

Uma estratégia possível consiste em utilizar inicialmente um método hierárquico para examinar diferentes números de grupos e obter centroides candidatos, seguidos por K -médias com esses centroides como valores iniciais (Hair et al., 2009). Essa combinação é uma estratégia computacional e não estabelece equivalência entre os dois critérios.

16.13.4 Escolha do número de grupos

Para comparar soluções com diferentes valores de K , defina

$$W_K = \min_{\mathcal{P} \in \mathcal{A}_K} J_K(\mathcal{P}), \quad (16.23)$$

em que $\mathcal{A}_K$ é o conjunto das partições de $\{1, \dots, n\}$ em exatamente K grupos não vazios, utilizado na Equação 16.8.

Para $1 \leq K < n$,

$$W_{K+1} \leq W_K.$$

De fato, em qualquer partição em $K < n$ grupos, pelo menos um grupo contém duas ou mais observações. Esse grupo pode ser dividido em dois grupos não vazios e, após o recálculo de seus centroides, a soma das dispersões quadráticas desses dois grupos não pode exceder a dispersão do grupo original. Portanto, existe uma partição admissível em $K + 1$ grupos cujo critério não é maior que o da partição considerada. Em particular, essa propriedade vale para a partição que atinge W_K .

No caso extremo $K = n$, cada observação pode formar um grupo unitário e

$$W_n = 0.$$

Como

$$W_{K+1} \leq W_K$$

e

$$W_n = 0,$$

minimizar W_K também em relação a K levaria à solução trivial $K = n$. A escolha do número de grupos exige, portanto, informação adicional à dispersão intragrupos mínima.

Na aplicação, a dispersão disponível para cada valor de K corresponde à solução efetivamente obtida pelo procedimento de agrupamento. Denote essa quantidade por

$$\widetilde{W}_K.$$

Como W_K é o mínimo global definido na Equação 16.23,

$$\widetilde{W}_K \geq W_K.$$

A igualdade ocorre quando a solução obtida atinge o mínimo global. Diferentemente de W_K , a sequência de valores $\widetilde{W}_K$ não precisa ser monotônica quando o procedimento de busca produz soluções locais diferentes para cada valor de K .

O **gráfico do cotovelo** (*elbow plot*) examina os valores de $\widetilde{W}_K$ obtidos para diferentes números de grupos. Procura-se uma região a partir da qual reduções adicionais da dispersão intragrupos se tornam relativamente pequenas. Essa mudança de comportamento pode auxiliar a escolha de K , mas não determina um número verdadeiro de grupos.

Outro critério utiliza a **silhueta**, que compara a coesão de uma observação com seu próprio grupo e sua separação em relação aos demais (Kaufman; Rousseeuw, 1990). Considere uma partição com pelo menos dois grupos e uma observação i pertencente a um grupo com pelo menos duas observações. Seja $a(i)$ a dissimilaridade média entre i e as demais observações de seu grupo e seja $b(i)$ a menor dissimilaridade média entre i e as observações de qualquer outro grupo. Quando

$$\max\{a(i), b(i)\} > 0,$$

o coeficiente de silhueta é

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}. \quad (16.24)$$

O coeficiente satisfaz

$$-1 \leq s(i) \leq 1.$$

Para uma observação que forma sozinha um grupo, adota-se usualmente $s(i) = 0$. Para uma partição com apenas um grupo, a silhueta não está definida.

Valores elevados indicam que a observação apresenta menor dissimilaridade média em relação ao próprio grupo do que aos grupos concorrentes. Valores próximos de zero indicam valores semelhantes de $a(i)$ e $b(i)$, enquanto valores negativos indicam menor dissimilaridade média em relação a outro grupo. A média dos coeficientes fornece uma medida descritiva da coesão e da separação da partição em relação à dissimilaridade adotada. Alterar essa dissimilaridade pode modificar $a(i)$, $b(i)$ e, conseqüentemente, os coeficientes de silhueta mesmo quando a partição permanece fixa.

A média deve ser examinada juntamente com os valores individuais. Uma partição com média elevada pode conter observações com $s(i)$ próximo de zero ou negativo. Esses valores mostram que uma avaliação global favorável pode coexistir com observações cuja alocação apresenta baixa separação em relação aos grupos concorrentes segundo a dissimilaridade adotada.

A **estatística gap** compara a dispersão intragrupos da solução observada com aquela obtida sob uma distribuição de referência escolhida para representar a ausência da estrutura de agrupamento procurada (Tibshirani; Walther; Hastie, 2001).

Utilizando $\widetilde{W}_K$ definido anteriormente,

$$\text{Gap}(K) = E^* [\log \widetilde{W}_K^*] - \log \widetilde{W}_K, \quad (16.25)$$

em que $\widetilde{W}_K^*$ é a dispersão obtida em dados gerados pela distribuição de referência, e E^* representa a média sob esse mecanismo de geração.

Para que a comparação mantenha o mesmo significado nos dados observados e de referência, $\widetilde{W}_K$ e $\widetilde{W}_K^*$ devem ser obtidos segundo o mesmo critério de agrupamento e procedimentos de busca comparáveis. A estatística gap depende, portanto, tanto da distribuição de referência quanto do procedimento utilizado para obter as soluções.

O cotovelo, a silhueta e a estatística gap fornecem informações diferentes sobre as soluções obtidas para cada valor de K . Nenhum desses critérios estabelece, isoladamente, a existência de um número verdadeiro de grupos na população.

A escolha de K deve considerar conjuntamente as informações fornecidas pelos critérios examinados, a estabilidade da solução e a interpretabilidade dos perfis formados pelas variáveis de agrupamento (Hair et al., 2009). Quando existirem variáveis externas pertinentes que não participaram da formação dos grupos, sua relação com a solução pode fornecer informação adicional na etapa de validação. A estabilidade e a validação são desenvolvidas na Seção 16.13.6.

16.13.4.1 Escolha de uma partição na hierarquia

Um método hierárquico fornece uma sequência aninhada de partições, representada pelo dendrograma. Escolher K significa selecionar, nessa sequência, uma partição com K grupos. Quando os níveis de fusão permitem essa representação, a mesma partição pode ser identificada por um corte horizontal no dendrograma.

Um aumento acentuado entre valores sucessivos de fusão indica que a etapa seguinte exige reunir grupos mais dissimilares segundo o critério adotado. Esse comportamento pode ser examinado no dendrograma ou diretamente na sequência dos valores de fusão.

O tamanho desse aumento não constitui um teste estatístico da existência de grupos e depende da medida de proximidade e do critério de ligação utilizados.

Uma partição candidata obtida por corte do dendrograma deve ser examinada quanto a:

- tamanho dos grupos;
- perfis das variáveis;
- observações que se unem somente em níveis elevados;
- estabilidade diante de mudanças razoáveis na representação ou no método;
- interpretação dos grupos em relação ao objetivo da análise.

Quando diferentes cortes do dendrograma são plausíveis, a decisão deve considerar as diferenças entre os perfis produzidos por essas partições e não apenas a aparência gráfica da árvore.

O corte de uma hierarquia de Ward em K grupos não resolve, em geral, o problema global das K -médias para o mesmo valor de K , conforme discutido na Seção 16.7.2. Os dois procedimentos podem ser comparados, mas suas soluções não devem ser tratadas como equivalentes.

16.13.5 Inicialização e comparação entre execuções

A Proposição 16.2 mostra que as etapas alternadas das K -médias não aumentam o critério, mas essa propriedade não garante que uma execução encontre a solução global.

O procedimento pode começar por uma partição inicial das observações ou por K centroides iniciais. A escolha desses valores influencia a trajetória seguida pelo algoritmo e pode produzir soluções finais distintas (Johnson; Wichern, 2002).

Para um mesmo valor de K , a mesma representação dos dados e o mesmo critério, é recomendável executar o procedimento a partir de diferentes inicializações. Entre as soluções obtidas, valores menores de

$$J_K(\mathcal{P})$$

indicam melhor atendimento ao critério das K -médias.

A comparação não deve se limitar ao valor da função objetivo. Duas execuções podem produzir valores próximos de J_K e ainda assim gerar partições diferentes. Por isso, também devem ser examinados os tamanhos dos grupos, seus centroides e a concordância das alocações depois de estabelecida a correspondência entre os rótulos dos grupos.

Uma estratégia de inicialização pode utilizar centroides obtidos previamente por um método hierárquico. Outra possibilidade é utilizar diferentes conjuntos de pontos iniciais. Hair et al. destacam que métodos não hierárquicos podem produzir soluções finais distintas para diferentes conjuntos de pontos-semente e que essas alternativas devem ser examinadas e validadas (Hair et al., 2009).

A estabilidade em relação à inicialização informa se a solução é sensível ao procedimento de busca. Ela não demonstra, por si só, que os grupos correspondam a uma estrutura populacional.

16.13.6 Estabilidade, validação e perfil dos grupos

Uma solução de agrupamento deve ser examinada além do valor do critério que a produziu. Como os grupos são construídos a partir dos próprios dados, sua avaliação pode considerar a estabilidade da partição, a interpretação dos perfis e, quando disponíveis e pertinentes ao objetivo da análise, variáveis externas que não participaram da formação dos grupos (Hair et al., 2009).

16.13.6.1 Estabilidade da solução

A estabilidade examina se uma estrutura semelhante reaparece quando aspectos razoáveis do procedimento são modificados.

Nas K -médias, uma primeira avaliação consiste em repetir a análise com diferentes inicializações, conforme a Seção 16.13.5.

Também podem ser comparadas soluções obtidas em subamostras, após pequenas perturbações dos dados ou por procedimentos de agrupamento compatíveis com o mesmo objetivo. Se a interpretação proposta for estável, pequenas alterações nos dados ou na representação não devem produzir mudanças substanciais na organização dos grupos. Como seus rótulos são

arbitrários, a comparação entre partições exige estabelecer previamente a correspondência entre grupos com perfis semelhantes.

A estabilidade não exige identidade exata entre partições. A comparação deve examinar quanto variam o número de grupos, seus perfis e as alocações das observações diante das perturbações consideradas. A conclusão sobre estabilidade depende da magnitude dessas mudanças e do objetivo da análise.

16.13.6.2 Caracterização pelas variáveis de agrupamento

Depois de escolhida uma solução, os grupos devem ser caracterizados pelas variáveis que participaram de sua formação.

Para métodos baseados em centroides, os vetores

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K$$

forneem perfis médios diretamente relacionados à construção da solução. A comparação entre esses perfis descreve como as variáveis utilizadas no agrupamento diferem entre os grupos e quais apresentam pouca variação entre eles.

A caracterização não deve ser reduzida aos centroides. Tamanho dos grupos, dispersão interna e presença de observações afastadas também descrevem a estrutura obtida. Como essas informações derivam dos dados utilizados na construção dos grupos, elas caracterizam a solução, mas não constituem validação externa.

16.13.6.3 Validade de critério com variáveis externas

Variáveis que não participaram da formação dos grupos podem ser reservadas para avaliar a relação da solução com critérios externos.

Quando existe, com base no problema de pesquisa, uma relação esperada entre uma variável externa e a estrutura procurada, diferenças entre os grupos compatíveis com essa relação fornecem informação favorável à validade de critério da solução. Hair et al. tratam essa etapa como avaliação de validade de critério (Hair et al., 2009).

Essa avaliação deve ser distinguida da própria formação dos grupos. A variável utilizada como critério externo não participa das proximidades ou da função objetivo empregada para construir a partição, e sua relação esperada com os grupos deve decorrer do problema de pesquisa, não da inspeção posterior da própria solução.

16.13.6.4 Perfil dos grupos com variáveis externas

Variáveis que não participaram da formação dos grupos também podem ser utilizadas para descrever os grupos depois que a partição foi escolhida. Quando não existe uma relação externa previamente especificada a ser examinada, sua função é construir o perfil dos grupos, e não avaliar validade de critério (Hair et al., 2009).

Essas variáveis podem representar características demográficas, ambientais, comportamentais ou outras informações pertinentes ao problema estudado. A distribuição dessas características em cada grupo compõe seu perfil externo, mas diferenças observadas entre os grupos não demonstram, isoladamente, que a partição corresponda a grupos distintos na população.

Tanto a validade de critério quanto o perfil externo devem ser interpretados considerando o delineamento amostral, a estabilidade da solução e a magnitude e o padrão das diferenças encontradas. Quando testes estatísticos forem utilizados para comparar grupos, seus p -valores não substituem a avaliação da magnitude das diferenças nem demonstram, por si só, a validade da solução.

Tabela 16.9: Dimensões utilizadas para avaliar e interpretar uma solução de agrupamento.

Dimensão avaliada	Procedimento	Informação obtida
sensibilidade à inicialização	repetir K -médias com diferentes pontos iniciais	dependência do procedimento de busca
estabilidade amostral	repetir a análise em subamostras ou reamostragens	sensibilidade da solução a mudanças na composição dos dados
estabilidade metodológica	comparar procedimentos razoáveis para o mesmo objetivo	dependência da solução em relação ao método
caracterização pelas variáveis de agrupamento	examinar centroides, dispersões e tamanhos dos grupos	características utilizadas para interpretar a própria solução
validade de critério	comparar os grupos em variáveis externas para as quais exista uma relação esperada	relação da solução com critérios externos
perfil externo	descrever os grupos com variáveis adicionais não utilizadas na formação	características que auxiliam a interpretação e a descrição dos grupos

Estabilidade, interpretabilidade e relação com informações externas são propriedades distintas de uma solução de agrupamento. Uma solução pode ser estável sem responder adequadamente

ao objetivo da análise, ou ser facilmente interpretável e ainda apresentar elevada sensibilidade aos dados ou à inicialização. Essas dimensões devem ser avaliadas separadamente.

16.13.7 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise de Agrupamentos será realizada pelo módulo `snowCluster` (Seol, 2026) do `jamovi` (The jamovi project, 2026). A implementação reúne procedimentos que correspondem a formulações distintas desenvolvidas no capítulo.

Tabela 16.10: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
K-means Clustering	busca de uma partição segundo o critério de soma de quadrados intragrupos	Seção 16.6.2
Number of clusters	número K de grupos	Seção 16.13.4
Standardize variables	padronização das variáveis antes do cálculo das distâncias	Seção 16.3.1 e Seção 16.13.1
Algorithm	algoritmo utilizado para procurar uma solução do critério das K -médias	Seção 16.12.3
Number of random starting values	número de inicializações utilizadas na busca	Seção 16.13.5
Centroids	médias vetoriais dos grupos obtidos	Seção 16.6.2
Within-cluster, between-cluster e total sum of squares	dispersões intragrupos, entre grupos e total	Seção 16.6.1
Elbow plot	comportamento de $\widetilde{W}_K$ para diferentes valores de K	Seção 16.13.4
Gap statistic plot	comparação de $\widetilde{W}_K$ com a dispersão obtida sob uma distribuição de referência	Seção 16.13.4
Gower distance	agrupamento de dados mistos por procedimento baseado em dissimilaridade de Gower	Seção 16.13.2
Silhouette index	medida de avaliação da separação e coesão dos grupos	Seção 16.13.4

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Silhouette plot	na versão auditada, não corresponde ao gráfico de silhueta definido no capítulo	Seção 16.13.4
Distance measure	medida utilizada para construir as dissimilaridades no agrupamento hierárquico	Seção 16.13.3
Clustering method	critério utilizado para selecionar as fusões na construção hierárquica	Seção 16.7 e Seção 16.13.3
Ward.D e Ward.D2	convenções computacionais distintas associadas ao método de Ward	Seção 16.7.2
Dendrogram	representação da sequência hierárquica de fusões	Definição 16.5
Variable clustering (PCA)	agrupamento de variáveis em uma representação obtida por ACP	não corresponde ao agrupamento das observações desenvolvido no núcleo
With p-values	agrupamento hierárquico de variáveis com avaliação por reamostragem	não corresponde à validação da partição das observações

Na análise de K -médias, a opção **Standardize variables** altera a representação utilizada no cálculo das distâncias e pode modificar a partição. Os centroides e as somas de quadrados apresentados na saída referem-se à escala efetivamente utilizada no ajuste. A configuração padrão da interface não substitui a decisão sobre a escala discutida na Seção 16.13.1.

As opções **Algorithm** e **Number of random starting values** modificam a busca computacional por uma solução, mas não o critério J_K que define as K -médias. O **Elbow plot** utiliza as dispersões $\tilde{W}_K$ das soluções efetivamente obtidas para diferentes valores de K , que não devem ser identificadas automaticamente com os mínimos globais W_K . Na versão auditada, o cálculo da estatística gap não reproduz necessariamente todas as opções de algoritmo e inicialização selecionadas para a solução principal; essa diferença deve ser considerada na comparação dos resultados.

A opção **Gower distance** segue uma formulação distinta das K -médias euclidianas e deve ser interpretada segundo a dissimilaridade para dados mistos desenvolvida na Seção 16.13.2. O **Silhouette index** pode ser utilizado para avaliar a coesão e a separação da solução segundo a dissimilaridade empregada. Na versão auditada, porém, o **Silhouette plot** não utiliza a matriz de dissimilaridades entre observações exigida pela definição apresentada na Seção 16.13.4 e, portanto, não corresponde ao gráfico de silhueta definido neste capítulo.

No agrupamento hierárquico, a medida de distância e o critério de fusão são escolhas distintas. Na convenção do `hclust` do R utilizada por implementações que oferecem essas duas opções, **Ward.D2** é a opção diretamente associada ao critério de mínima variância desenvolvido na Seção 16.7.2 quando a análise parte de distâncias euclidianas. **Ward.D** utiliza uma convenção histórica distinta e não deve ser tratado como uma denominação equivalente para o mesmo cálculo.

As opções **Variable clustering (PCA)** e **With p-values** agrupam variáveis, e não as observações utilizadas na formulação principal do capítulo. A primeira utiliza uma representação por ACP; a segunda utiliza `pvcust` e associa aos grupos da hierarquia de variáveis os valores AU (*approximately unbiased*) e BP (*bootstrap probability*) obtidos por reamostragem (Suzuki; Shimodaira, 2006). Esses resultados não constituem validação da partição de observações discutida na Seção 16.13.6.

16.14 Síntese

A Análise de Agrupamentos procura organizar objetos sem utilizar classes previamente conhecidas. A estrutura obtida depende da representação dos objetos, da medida de proximidade e do critério adotado para definir os grupos.

Quando as observações são representadas por vetores

$$\mathbf{x}_i \in \mathbb{R}^p,$$

suas proximidades podem ser construídas a partir das coordenadas. Alguns métodos também podem partir diretamente de uma matriz de dissimilaridades

$$\Delta \in \mathbb{R}^{n \times n}.$$

Nas K -médias, procura-se uma partição

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

que minimize a dispersão quadrática intragrupos,

$$J_K(\mathcal{P}) = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2 = \text{tr}(\mathbf{T}_{\text{intra}}).$$

Os centroides aparecem nessa formulação porque a média de cada grupo minimiza a soma das distâncias euclidianas quadráticas às observações que o compõem. Pela decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

tem-se

$$\text{tr}(\mathbf{T}) = \text{tr}(\mathbf{T}_{\text{intra}}) + \text{tr}(\mathbf{T}_{\text{entre}}).$$

Como $\mathbf{T}$ é fixada pelos dados, minimizar a dispersão quadrática intragrupos equivale a maximizar a dispersão quadrática entre grupos.

Os métodos hierárquicos produzem uma hierarquia, representada por uma sequência de partições aninhadas. As ligações simples, completa e média utilizam critérios diferentes para comparar grupos. No método de Ward, a fusão de dois grupos C_1 e C_2 produz um incremento

$$D_{\text{Ward}}(C_1, C_2) = \frac{n_1 n_2}{n_1 + n_2} \|\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2\|^2,$$

e, em cada etapa, é escolhida a fusão que produz o menor incremento.

O dendrograma representa a hierarquia das fusões resultantes.

Uma terceira formulação define grupos como componentes de um modelo de mistura probabilístico,

$$f(\mathbf{x}) = \sum_{k=1}^K \pi_k f_k(\mathbf{x}; \theta_k).$$

Nesse caso, a associação de uma observação aos grupos pode ser descrita por probabilidades posteriores de associação às componentes, em vez de ser necessariamente estabelecida por uma partição rígida.

As K -médias, os métodos hierárquicos e os modelos de mistura definem grupos por estruturas matemáticas diferentes. A solução depende das variáveis utilizadas, de suas escalas, da medida de proximidade, do número de grupos e do critério adotado. Uma solução matematicamente definida não demonstra, por si só, a existência de populações distintas nem sua correspondência com categorias externas ao procedimento de agrupamento.

No Capítulo 17, o objeto de análise passa a ser uma tabela de contingência. Perfis, massas, distância qui-quadrado, inércia e decomposição em valores singulares são utilizados para representar associações entre categorias.

17 Formulação da Análise de Correspondência

A Análise de Correspondência simples representa geometricamente a estrutura de associação entre as categorias de duas variáveis categóricas a partir de uma tabela de contingência. A técnica compara os perfis observados com a estrutura correspondente à independência segundo a geometria qui-quadrado (Johnson; Wichern, 2002).

Os desvios da independência são padronizados pelas massas e reunidos em uma matriz submetida à SVD. A decomposição determina as dimensões não nulas, as inércias principais e as coordenadas das categorias de linhas e colunas. A formulação é geométrica e descritiva. A relação com a estatística de Pearson exige distinguir a identidade algébrica válida para a tabela observada da inferência sobre independência em uma população.

Os elementos da formulação são organizados na Tabela 17.1.

Tabela 17.1: Elementos da formulação da Análise de Correspondência.

Elemento	Objeto	Papel na análise
dados observados	tabela de contingência $\mathbf{N}$	registra as frequências conjuntas
distribuição observada	matriz $\mathbf{P}$	expressa frequências relativas
referência	independência	fornece a estrutura sem associação
representação interna	perfis de linhas e de colunas	descreve distribuições condicionais observadas
referência	independência	fornece a estrutura sem associação
geometria	distância qui-quadrado	compara perfis com ponderação pelos inversos das massas da margem oposta
estrutura matricial	matriz de desvios padronizados da independência $\mathbf{Q}_{CA}$	reúne os desvios da independência após a padronização pelas massas
solução	SVD de $\mathbf{Q}_{CA}$	determina valores singulares, inércias principais e coordenadas

17.1 O problema de associação em uma tabela de contingência

A Análise de Correspondência simples considera duas variáveis categóricas, conforme a distinção apresentada na Seção 1.2. Para n observações, os dados categóricos podem ser organizados como

$$\mathbf{X}_{\text{cat}} = \begin{pmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{pmatrix},$$

em que cada linha representa uma observação e cada coluna representa uma das duas variáveis categóricas.

A primeira variável possui I categorias e a segunda possui J categorias. Os índices $1, \dots, I$ e $1, \dots, J$ identificam essas categorias, de modo que

$$x_{h1} \in \{1, \dots, I\}, \quad x_{h2} \in \{1, \dots, J\}, \quad h = 1, \dots, n.$$

A matriz $\mathbf{X}_{\text{cat}}$ contém duas variáveis. As quantidades I e J indicam os números de categorias da primeira e da segunda variável, respectivamente. Os índices atribuídos às categorias funcionam apenas como identificadores e não definem coordenadas quantitativas em $\mathbb{R}^2$.

A Análise de Correspondência utiliza as frequências conjuntas das categorias. Para $i = 1, \dots, I$ e $j = 1, \dots, J$, defina

$$n_{ij} = |\{h \in \{1, \dots, n\} : x_{h1} = i, x_{h2} = j\}|.$$

A quantidade n_{ij} corresponde ao número de observações que pertencem simultaneamente à categoria i da primeira variável e à categoria j da segunda. Essas frequências formam a tabela de contingência

$$\mathbf{N} = (n_{ij}) \in \mathbb{N}_0^{I \times J}.$$

A matriz $\mathbf{N}$ possui I linhas, correspondentes às categorias da primeira variável, e J colunas, correspondentes às categorias da segunda. Suas dimensões $I \times J$ referem-se às categorias das duas variáveis categóricas.

O total observado é

$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}, \quad n > 0. \quad (17.1)$$

Como $n > 0$, a matriz de frequências relativas observadas é definida por

$$\mathbf{P} = \frac{1}{n} \mathbf{N} = (p_{ij}) \in \mathbb{R}^{I \times J}. \quad (17.2)$$

Assim,

$$p_{ij} = \frac{n_{ij}}{n} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

A matriz $\mathbf{P}$ reúne as **frequências relativas observadas** da tabela e é construída diretamente a partir das frequências observadas. Ela deve ser distinguida da distribuição conjunta populacional considerada na Seção 17.13.6.

A análise procura determinar como $\mathbf{P}$ se afasta da estrutura correspondente à independência e representar esse afastamento em poucas dimensões.

A tabela possui duas leituras complementares. Comparando as linhas, investigam-se diferenças entre as distribuições das categorias das colunas condicionadas a cada linha. Comparando as colunas, investigam-se diferenças entre as distribuições das categorias das linhas condicionadas a cada coluna.

17.2 Massas e perfis

As frequências relativas marginais são denominadas **massas** e determinam a ponderação utilizada na geometria da Análise de Correspondência.

Definição 17.1 (Massas de linha e de coluna). Considere uma matriz de frequências relativas

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J},$$

com

$$p_{ij} \geq 0$$

e

$$\sum_{i=1}^I \sum_{j=1}^J p_{ij} = 1.$$

e as **massas das colunas** são

$$r_i = \sum_{j=1}^J p_{ij}, \quad i = 1, \dots, I,$$

e as **massas das colunas** são

$$c_j = \sum_{i=1}^I p_{ij}, \quad j = 1, \dots, J.$$

Em forma vetorial,

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \in \mathbb{R}^I$$

e

$$\mathbf{c} = \mathbf{P}^\top \mathbf{1}_I \in \mathbb{R}^J.$$

Como a soma dos elementos de $\mathbf{P}$ é igual a 1,

$$\mathbf{1}_I^\top \mathbf{r} = \mathbf{1}_J^\top \mathbf{c} = 1.$$

As matrizes diagonais das massas são

$$\mathbf{D}_r = \text{diag}(r_1, \dots, r_I) \in \mathbb{R}^{I \times I}$$

e

$$\mathbf{D}_c = \text{diag}(c_1, \dots, c_J) \in \mathbb{R}^{J \times J}.$$

A definição admite massas nulas. Como a geometria da Análise de Correspondência utiliza inversas e raízes inversas das matrizes de massas, o desenvolvimento considera apenas categorias com

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J. \quad (17.3)$$

Categorias de massa nula não possuem perfis definidos e ficam fora da geometria construída sob a condição da Equação 17.3.

17.2.1 Distribuições condicionais observadas

A Análise de Correspondência compara distribuições condicionais observadas, denominadas perfis.

Definição 17.2 (Perfis de linhas e de colunas). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas com massas de linhas e colunas definidas na Definição 17.1.

Para uma linha i com

$$r_i > 0,$$

o perfil da linha i é

$$\mathbf{p}_{i| \cdot} = \begin{pmatrix} \frac{p_{i1}}{r_i} \\ \vdots \\ \frac{p_{iJ}}{r_i} \end{pmatrix} \in \mathbb{R}^J. \quad (17.4)$$

Para uma coluna j com

$$c_j > 0,$$

o perfil da coluna j é

$$\mathbf{p}_{\cdot|j} = \begin{pmatrix} \frac{p_{1j}}{c_j} \\ c_j \\ \vdots \\ \frac{p_{Ij}}{c_j} \\ c_j \end{pmatrix} \in \mathbb{R}^I. \quad (17.5)$$

Cada perfil possui soma unitária:

$$\mathbf{1}_J^\top \mathbf{p}_{i\cdot} = 1$$

e

$$\mathbf{1}_I^\top \mathbf{p}_{\cdot|j} = 1.$$

Sob a condição da Equação 17.3, os perfis de linhas podem ser reunidos na matriz

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P} \in \mathbb{R}^{I \times J}, \quad (17.6)$$

enquanto os perfis de colunas são organizados em

$$\mathbf{P}^{(c)} = \mathbf{D}_c^{-1} \mathbf{P}^\top \in \mathbb{R}^{J \times I}. \quad (17.7)$$

O perfil médio das linhas, ponderado pelas massas r_i , é

$$\sum_{i=1}^I r_i \mathbf{p}_{i\cdot} = \mathbf{c}, \quad (17.8)$$

pois, para cada componente j ,

$$\sum_{i=1}^I r_i \frac{p_{ij}}{r_i} = \sum_{i=1}^I p_{ij} = c_j.$$

De forma dual,

$$\sum_{j=1}^J c_j \mathbf{p}_{\cdot|j} = \mathbf{r}. \quad (17.9)$$

Assim, $\mathbf{c}$ é o centro ponderado da nuvem dos perfis de linhas e $\mathbf{r}$ é o centro ponderado da nuvem dos perfis de colunas.

17.2.2 Independência como referência

Para a matriz $\mathbf{P}$, a estrutura de independência associada às massas $\mathbf{r}$ e $\mathbf{c}$ é

$$p_{ij} = r_i c_j, \quad (17.10)$$

ou, em forma matricial,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top. \quad (17.11)$$

Sob a condição da Equação 17.3,

$$\frac{p_{ij}}{r_i} = c_j,$$

de modo que

$$\mathbf{p}_{i|\cdot} = \mathbf{c}$$

para todas as linhas.

Analogamente,

$$\frac{p_{ij}}{c_j} = r_i,$$

e todos os perfis de colunas coincidem com

$$\mathbf{r}.$$

A independência corresponde, portanto, ao colapso de cada nuvem de perfis em seu respectivo centro.

Quando

$$\mathbf{P} \neq \mathbf{r}\mathbf{c}^\top,$$

as diferenças

$$p_{ij} - r_i c_j$$

representam os desvios observados em relação à estrutura de independência.

Esses desvios ainda não incorporam a ponderação marginal da geometria qui-quadrado. Na Análise de Correspondência, eles são padronizados pelos produtos das massas marginais.

17.3 Geometria dos perfis

A Análise de Correspondência compara os perfis por meio de produtos internos ponderados pelos inversos das massas da margem oposta.

Pela Definição 3.16 e pela Definição 3.17, sob a condição da Equação 17.3,

$$\mathbf{D}_c^{-1}$$

e

$$\mathbf{D}_r^{-1}$$

são matrizes diagonais positivas definidas e, portanto, definem produtos internos nos espaços de perfis de linhas e de colunas.

Esses produtos internos determinam a geometria dos perfis. As distâncias associadas são as distâncias qui-quadrado.

Definição 17.3 (Distância qui-quadrado entre perfis). Considere uma matriz

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

de frequências relativas cujas massas satisfazem

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J.$$

Se

$$\mathbf{p}_{i|\cdot}, \mathbf{p}_{i'|\cdot} \in \mathbb{R}^J$$

são dois perfis de linhas, o **quadrado de sua distância qui-quadrado** é definido por

$$d_{\chi^2}^2(i, i') = (\mathbf{p}_{i\cdot} - \mathbf{p}_{i'\cdot})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i\cdot} - \mathbf{p}_{i'\cdot}). \quad (17.12)$$

Equivalentemente,

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^J \frac{1}{c_j} \left(\frac{p_{ij}}{r_i} - \frac{p_{i'j}}{r_{i'}} \right)^2.$$

Se

$$\mathbf{p}_{\cdot|j}, \mathbf{p}_{\cdot|j'} \in \mathbb{R}^I$$

são dois perfis de colunas, o quadrado de sua distância qui-quadrado é

$$d_{\chi^2}^2(j, j') = (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'})^\top \mathbf{D}_r^{-1} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'}). \quad (17.13)$$

Equivalentemente,

$$d_{\chi^2}^2(j, j') = \sum_{i=1}^I \frac{1}{r_i} \left(\frac{p_{ij}}{c_j} - \frac{p_{ij'}}{c_{j'}} \right)^2.$$

A distância qui-quadrado é, portanto, uma distância euclidiana em coordenadas reescaladas pelas massas. Para as linhas,

$$d_{\chi^2}(i, i') = \|\mathbf{D}_c^{-1/2} (\mathbf{p}_{i\cdot} - \mathbf{p}_{i'\cdot})\|,$$

e, para as colunas,

$$d_{\chi^2}(j, j') = \|\mathbf{D}_r^{-1/2} (\mathbf{p}_{\cdot|j} - \mathbf{p}_{\cdot|j'})\|.$$

Na comparação entre perfis de linhas, a diferença na categoria de coluna j é ponderada por

$$\frac{1}{c_j}.$$

Na comparação entre perfis de colunas, a diferença na categoria de linha i é ponderada por

$$\frac{1}{r_i}.$$

Assim, para diferenças absolutas de mesma magnitude, a componente associada a uma categoria de menor massa tem maior peso na distância qui-quadrado.

A distância de uma linha ao centro da nuvem é

$$d_{\chi^2}^2(i, \mathbf{c}) = (\mathbf{p}_{i\cdot} - \mathbf{c})^\top \mathbf{D}_c^{-1} (\mathbf{p}_{i\cdot} - \mathbf{c}), \quad (17.14)$$

ou, utilizando

$$\frac{p_{ij}}{r_i} - c_j = \frac{p_{ij} - r_i c_j}{r_i},$$

tem-se

$$d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i^2 c_j}. \quad (17.15)$$

De forma dual,

$$d_{\chi^2}^2(j, \mathbf{r}) = \sum_{i=1}^I \frac{(p_{ij} - r_i c_j)^2}{c_j^2 r_i}. \quad (17.16)$$

17.4 Inércia e afastamento da independência

Definição 17.4 (Inércia total). A **inércia total** mede o afastamento global dos perfis em relação à estrutura de independência por meio das distâncias qui-quadrado entre os perfis e o centro da nuvem.

Para a nuvem de perfis de linhas, com massas $r_1, \dots, r_I$ e centro $\mathbf{c}$, a inércia total é

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}). \quad (17.17)$$

Como

$$\sum_{i=1}^I r_i = 1,$$

$\mathcal{J}$ é a média ponderada das distâncias qui-quadrado ao quadrado entre os perfis de linhas e o centro da nuvem. O termo

$$r_i d_{\chi^2}^2(i, \mathbf{c})$$

é a parcela da inércia total associada à categoria de linha i .

Substituindo a distância qui-quadrado da Equação 17.15 na Equação 17.17,

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \quad (17.18)$$

De forma dual,

$$\mathcal{J} = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r}), \quad (17.19)$$

de modo que a mesma inércia total pode ser obtida pela dispersão da nuvem de linhas em torno de $\mathbf{c}$ ou pela dispersão da nuvem de colunas em torno de $\mathbf{r}$.

Como todos os termos na Equação 17.18 são não negativos,

$$\mathcal{J} = 0$$

se, e somente se,

$$p_{ij} = r_i c_j$$

para todas as células, ou equivalentemente,

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top.$$

A inércia total é nula quando a distribuição observada coincide com a estrutura de independência. Valores positivos indicam afastamento dessa estrutura, e valores maiores correspondem a maior dispersão global dos perfis em relação aos respectivos centros.

17.5 Padronização dos desvios da independência

Na Equação 17.18, os desvios

$$p_{ij} - r_i c_j$$

aparecem padronizados pelas massas correspondentes. Esses termos podem ser reunidos em uma única matriz.

Definição 17.5 (Matriz de desvios padronizados da independência). Considere

$$\mathbf{P} = (p_{ij}) \in \mathbb{R}^{I \times J}$$

uma matriz de frequências relativas cujas massas

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

são estritamente positivas.

A matriz de desvios padronizados da independência é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2} \in \mathbb{R}^{I \times J}. \quad (17.20)$$

Seu elemento (i, j) é

$$q_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}. \quad (17.21)$$

A matriz $\mathbf{Q}_{\text{CA}}$ reúne os desvios da independência padronizados pelos produtos das massas marginais.

As restrições impostas pelas marginais implicam que o posto de $\mathbf{Q}_{\text{CA}}$, definido na Definição 2.14, satisfaz

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1). \quad (17.22)$$

As dependências lineares impostas pelas marginais, cuja derivação é apresentada na Seção 17.13.1, implicam que a Análise de Correspondência possui, no máximo,

$$\min(I - 1, J - 1)$$

dimensões não nulas.

17.5.1 Inércia como norma matricial

Pela Definição 17.5 e pela Definição 6.7,

$$\begin{aligned}\|\mathbf{Q}_{\text{CA}}\|_F^2 &= \sum_{i=1}^I \sum_{j=1}^J q_{ij}^2 \\ &= \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}.\end{aligned}$$

Comparando essa expressão com a Equação 17.18,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2. \quad (17.23)$$

Proposição 17.1 (Formas equivalentes da inércia). *Sob massas de linhas e colunas estritamente positivas,*

$$\mathcal{J} = \sum_{i=1}^I r_i d_{\chi^2}^2(i, \mathbf{c}) = \sum_{j=1}^J c_j d_{\chi^2}^2(j, \mathbf{r})$$

e

$$\mathcal{J} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

A inércia possui três interpretações compatíveis: dispersão da nuvem de linhas, dispersão da nuvem de colunas e magnitude matricial dos desvios padronizados da independência.

17.6 Relação algébrica com a estatística de Pearson

Sob a estrutura de independência ajustada às marginais observadas, a frequência esperada da célula (i, j) é

$$\hat{e}_{ij} = nr_i c_j.$$

A estatística de Pearson calculada a partir da tabela observada é

$$\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - \hat{e}_{ij})^2}{\hat{e}_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - nr_i c_j)^2}{nr_i c_j}. \quad (17.24)$$

Como

$$n_{ij} = np_{ij},$$

tem-se

$$\begin{aligned} \chi^2 &= \sum_{i=1}^I \sum_{j=1}^J \frac{n^2(p_{ij} - r_i c_j)^2}{nr_i c_j} \\ &= n \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}. \end{aligned}$$

Comparando a expressão anterior com a Equação 17.18,

$$\chi^2 = n\mathcal{J}. \quad (17.25)$$

A identidade

$$\chi^2 = n\mathcal{J}$$

é **algébrica e exata para a tabela observada**. Ela não exige um modelo probabilístico para a geração da tabela nem uma aproximação assintótica.

Sua interpretação como estatística de teste exige um modelo probabilístico para a geração da tabela, desenvolvido na Seção 17.13.6. A inércia e a identidade acima pertencem à estrutura descritiva e geométrica da Análise de Correspondência, enquanto a distribuição de referência de χ^2 pertence à inferência.

A estatística de Pearson resume o afastamento global da independência em uma única quantidade. A Análise de Correspondência decompõe a inércia correspondente entre dimensões e representa geometricamente os perfis de linhas e colunas (Johnson; Wichern, 2002).

17.7 Formulação pela decomposição em valores singulares

A matriz de desvios padronizados

$$\mathbf{Q}_{CA} \in \mathbb{R}^{I \times J}$$

é, em geral, retangular. A decomposição de $\mathbf{Q}_{CA}$ utiliza a SVD compacta definida na Definição 6.4.

Defina

$$L = \text{posto}(\mathbf{Q}_{CA}).$$

Pela Equação 17.22,

$$0 \leq L \leq \min(I - 1, J - 1).$$

Se

$$L = 0,$$

então

$$\mathbf{Q}_{CA} = \mathbf{0}$$

e, pela Proposição 17.1,

$$J = 0.$$

Nesse caso,

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top,$$

e não existem dimensões não nulas a decompor.

Quando $L \geq 1$, pela SVD compacta definida na Definição 6.4,

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top, \quad (17.26)$$

com

$$\mathbf{U} \in \mathbb{R}^{I \times L}, \quad \mathbf{D} \in \mathbb{R}^{L \times L}, \quad \mathbf{V} \in \mathbb{R}^{J \times L},$$

satisfazendo

$$\mathbf{U}^\top \mathbf{U} = \mathbf{I}_L,$$

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_L$$

e

$$\mathbf{D} = \text{diag}(d_1, \dots, d_L),$$

em que

$$d_1 \geq d_2 \geq \dots \geq d_L > 0.$$

Os vetores singulares à esquerda e à direita formam as bases ortonormais associadas à SVD. O reescalonamento por $\mathbf{D}_r^{-1/2}$ e $\mathbf{D}_c^{-1/2}$ produz as coordenadas padrão das linhas e das colunas em suas respectivas geometrias ponderadas.

A SVD acopla as duas representações por meio dos mesmos valores singulares.

17.7.1 Decomposição da inércia

Definição 17.6 (Inércia principal). A SVD de $\mathbf{Q}_{\text{CA}}$ decompõe a inércia total entre as dimensões não nulas da solução.

Para

$$\mathbf{Q}_{\text{CA}} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{D} = \text{diag}(d_1, \dots, d_L),$$

a **inércia principal da dimensão ℓ** é

$$\lambda_\ell = d_\ell^2, \quad \ell = 1, \dots, L. \quad (17.27)$$

A quantidade λ_ℓ representa a parcela da inércia total associada à dimensão ℓ .

Pela relação entre a norma de Frobenius e os valores singulares estabelecida na Proposição 6.9,

$$\|\mathbf{Q}_{\text{CA}}\|_F^2 = \sum_{\ell=1}^L d_\ell^2.$$

Pela Equação 17.23,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2,$$

e, portanto,

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell. \quad (17.28)$$

A SVD decompõe a inércia total em parcelas não negativas associadas às diferentes dimensões da solução.

Pela identidade exata da Equação 17.25,

$$\chi^2 = n\mathcal{J},$$

$$\chi^2 = n \sum_{\ell=1}^L \lambda_\ell. \quad (17.29)$$

A igualdade $\chi^2 = n \sum_{\ell=1}^L \lambda_\ell$ é uma decomposição algébrica da estatística observada e não depende de uma distribuição amostral. Sua interpretação inferencial depende da formulação probabilística especificada na Seção 17.13.6.

Quando $\mathcal{J} > 0$, a **proporção da inércia total associada à dimensão ℓ** é

$$\frac{\lambda_\ell}{\mathcal{J}} = \frac{\lambda_\ell}{\sum_{h=1}^L \lambda_h}, \quad \ell = 1, \dots, L. \quad (17.30)$$

Essa proporção representa a parcela da inércia total associada à dimensão ℓ .

Para $1 \leq k \leq L$, a **proporção acumulada da inércia nas primeiras k dimensões** é

$$\Pi_k^{(\text{CA})} = \frac{\sum_{\ell=1}^k \lambda_\ell}{\mathcal{J}} = \frac{\sum_{\ell=1}^k \lambda_\ell}{\sum_{\ell=1}^L \lambda_\ell}. \quad (17.31)$$

A quantidade $\Pi_k^{(\text{CA})}$ representa a parcela da inércia total associada conjuntamente às primeiras k dimensões.

Essas proporções descrevem a decomposição da inércia total entre as dimensões da Análise de Correspondência. Embora sejam formalmente semelhantes às proporções de variância da ACP, o objeto decomposto é diferente: na Análise de Correspondência, a inércia quantifica os desvios padronizados em relação à independência.

17.7.2 Representação em dimensão reduzida

Para

$$1 \leq k < L,$$

defina

$$\mathbf{U}_k = (\mathbf{u}_1 \quad \dots \quad \mathbf{u}_k) \in \mathbb{R}^{I \times k},$$

$$\mathbf{V}_k = (\mathbf{v}_1 \quad \dots \quad \mathbf{v}_k) \in \mathbb{R}^{J \times k}$$

e

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k) \in \mathbb{R}^{k \times k}.$$

A SVD truncada é

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top. \quad (17.32)$$

Pelo Teorema 6.2,

$$\mathbf{Q}_{\text{CA},k}$$

é uma melhor aproximação de posto no máximo k de

$$\mathbf{Q}_{\text{CA}}$$

em norma de Frobenius.

O erro quadrático de aproximação é

$$\begin{aligned} \|\mathbf{Q}_{\text{CA}} - \mathbf{Q}_{\text{CA},k}\|_F^2 &= \sum_{\ell=k+1}^L d_\ell^2 \\ &= \sum_{\ell=k+1}^L \lambda_\ell. \end{aligned} \quad (17.33)$$

A quantidade

$$\mathcal{J}_k = \sum_{\ell=1}^k \lambda_\ell \quad (17.34)$$

é a parcela da inércia total representada pelas primeiras k dimensões.

Consequentemente,

$$\mathcal{J} = \mathcal{J}_k + \sum_{\ell=k+1}^L \lambda_\ell.$$

Na Análise de Correspondência, a SVD truncada fornece uma aproximação ótima, em norma de Frobenius, da **matriz de desvios padronizados da independência**, e não da tabela de contingência $\mathbf{N}$ segundo uma distância euclidiana ordinária.

17.8 Coordenadas da Análise de Correspondência

A SVD é realizada sobre uma matriz em que os desvios da independência já foram ponderados pelas massas das categorias. As coordenadas da Análise de Correspondência transformam os vetores singulares novamente para os espaços dos perfis de linhas e de colunas.

A Análise de Correspondência utiliza duas escalas: coordenadas padrão e coordenadas principais.

17.8.1 Sistema de coordenadas padrão

Definição 17.7 (Coordenadas padrão). Considere uma matriz de frequências relativas

$$\mathbf{P} \in \mathbb{R}^{I \times J}$$

com massas de linhas e colunas estritamente positivas e a SVD compacta

$$\mathbf{Q}_{CA} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

com

$$L = \text{posto}(\mathbf{Q}_{CA}) \geq 1.$$

As **coordenadas padrão das linhas** são as linhas de

$$\mathbf{A}_r = \mathbf{D}_r^{-1/2} \mathbf{U} = (a_{i\ell}^{(r)}) \in \mathbb{R}^{I \times L}. \quad (17.35)$$

em que $a_{i\ell}^{(r)}$ é a coordenada padrão da linha i na dimensão ℓ . O vetor de coordenadas padrão da linha i é

$$\mathbf{a}_i^{(r)} = \begin{pmatrix} a_{i1}^{(r)} \\ \vdots \\ a_{iL}^{(r)} \end{pmatrix} \in \mathbb{R}^L.$$

As **coordenadas padrão das colunas** são as linhas de

$$\mathbf{A}_c = \mathbf{D}_c^{-1/2} \mathbf{V} = (a_{j\ell}^{(c)}) \in \mathbb{R}^{J \times L}. \quad (17.36)$$

em que $a_{j\ell}^{(c)}$ é a coordenada padrão da coluna j na dimensão ℓ . O vetor de coordenadas padrão da coluna j é

$$\mathbf{a}_j^{(c)} = \begin{pmatrix} a_{j1}^{(c)} \\ \vdots \\ a_{jL}^{(c)} \end{pmatrix} \in \mathbb{R}^L.$$

Como as colunas de $\mathbf{U}$ e $\mathbf{V}$ são ortonormais,

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_L$$

e

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_L.$$

As coordenadas padrão são, portanto, ortonormais nas geometrias ponderadas pelas respectivas massas.

17.8.2 Sistema de coordenadas principais

Definição 17.8 (Coordenadas principais). Mantidas as condições da Definição 17.7, as **coordenadas principais das linhas** são as linhas da matriz

$$\mathbf{F}_r = \mathbf{A}_r \mathbf{D} = \mathbf{D}_r^{-1/2} \mathbf{U} \mathbf{D} = (f_{i\ell}^{(r)}) \in \mathbb{R}^{I \times L}, \quad (17.37)$$

em que $f_{i\ell}^{(r)}$ é a coordenada principal da linha i na dimensão ℓ . O vetor de coordenadas principais da linha i é

$$\mathbf{f}_i^{(r)} = \begin{pmatrix} f_{i1}^{(r)} \\ \vdots \\ f_{iL}^{(r)} \end{pmatrix} \in \mathbb{R}^L.$$

As **coordenadas principais das colunas** são as linhas da matriz

$$\mathbf{F}_c = \mathbf{A}_c \mathbf{D} = \mathbf{D}_c^{-1/2} \mathbf{V} \mathbf{D} = (f_{j\ell}^{(c)}) \in \mathbb{R}^{J \times L}, \quad (17.38)$$

em que $f_{j\ell}^{(c)}$ é a coordenada principal da coluna j na dimensão ℓ . O vetor de coordenadas principais da coluna j é

$$\mathbf{f}_j^{(c)} = \begin{pmatrix} f_{j1}^{(c)} \\ \vdots \\ f_{jL}^{(c)} \end{pmatrix} \in \mathbb{R}^L.$$

As coordenadas principais incorporam os valores singulares, de modo que sua dispersão ponderada em cada dimensão corresponde à respectiva inércia principal. Como

$$\mathbf{A}_r^\top \mathbf{D}_r \mathbf{A}_r = \mathbf{I}_L$$

e

$$\mathbf{A}_c^\top \mathbf{D}_c \mathbf{A}_c = \mathbf{I}_L,$$

segue que

$$\mathbf{F}_r^\top \mathbf{D}_r \mathbf{F}_r = \mathbf{D}^2$$

e

$$\mathbf{F}_c^\top \mathbf{D}_c \mathbf{F}_c = \mathbf{D}^2.$$

Consequentemente, para cada dimensão ℓ ,

$$\lambda_\ell = \sum_{i=1}^I r_i \left(f_{i\ell}^{(r)} \right)^2 = \sum_{j=1}^J c_j \left(f_{j\ell}^{(c)} \right)^2, \quad \ell = 1, \dots, L. \quad (17.39)$$

A identidade mostra que a inércia principal λ_ℓ também corresponde à dispersão ponderada das coordenadas principais das linhas na dimensão ℓ e, de forma dual, à dispersão ponderada das coordenadas principais das colunas nessa mesma dimensão.

Em cada nuvem, a origem corresponde ao centro ponderado dos perfis. Para as linhas, esse centro é o perfil marginal $\mathbf{c}$ das colunas; para as colunas, é o perfil marginal $\mathbf{r}$ das linhas. Assim, uma categoria localizada próxima da origem possui perfil próximo do perfil marginal na representação considerada. A origem não representa uma categoria nem uma frequência pequena.

A igualdade das inércias principais nas duas nuvens não implica que os perfis de linhas e de colunas pertençam ao mesmo espaço. As linhas são perfis em $\mathbb{R}^J$ e as colunas são perfis em $\mathbb{R}^I$. Para cada dimensão ℓ , a SVD associa um eixo da nuvem de linhas a um eixo da nuvem de colunas pelo mesmo valor singular d_ℓ . Esses eixos determinam o termo

$$d_\ell \mathbf{u}_\ell \mathbf{v}_\ell^\top$$

da decomposição de $\mathbf{Q}_{\text{CA}}$.

17.8.3 Distâncias entre perfis e coordenadas principais

As coordenadas principais completas preservam as distâncias qui-quadrado entre os perfis.

Para as linhas,

$$\mathbf{P}^{(r)} = \mathbf{D}_r^{-1} \mathbf{P}.$$

Pela Equação 17.20,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{D}_r^{-1/2} \mathbf{Q}_{\text{CA}}.$$

Substituindo a decomposição da Equação 17.26 e utilizando a Equação 17.37,

$$(\mathbf{P}^{(r)} - \mathbf{1}_I \mathbf{c}^\top) \mathbf{D}_c^{-1/2} = \mathbf{F}_r \mathbf{V}^\top. \quad (17.40)$$

Como

$$\mathbf{V}^\top \mathbf{V} = \mathbf{I}_L,$$

a multiplicação por $\mathbf{V}^\top$ preserva a norma das diferenças entre as linhas de $\mathbf{F}_r$.

Proposição 17.2 (Preservação das distâncias qui-quadrado). *Mantidas todas as L dimensões associadas aos valores singulares positivos, para quaisquer linhas i e i' ,*

$$d_{\chi^2}^2(i, i') = \|\mathbf{f}_i^{(r)} - \mathbf{f}_{i'}^{(r)}\|^2,$$

e, de forma dual, para quaisquer colunas j e j' ,

$$d_{\chi^2}^2(j, j') = \|\mathbf{f}_j^{(c)} - \mathbf{f}_{j'}^{(c)}\|^2.$$

Se apenas as primeiras

$$k < L$$

dimensões forem mantidas, a distância representada entre dois perfis não pode exceder a distância completa, pois as parcelas quadráticas associadas às dimensões descartadas são não negativas. A representação reduzida preserva apenas as componentes das distâncias qui-quadrado associadas às dimensões retidas.

17.9 Representação conjunta de linhas e colunas

A Análise de Correspondência produz duas nuvens de pontos: uma para as categorias de linha e outra para as categorias de coluna. A representação pode ser construída a partir dos perfis de linhas ou, de forma dual, dos perfis de colunas (Johnson; Wichern, 2002).

Quando as linhas são representadas por suas coordenadas principais, as distâncias euclidianas entre os pontos de linhas reproduzem suas distâncias qui-quadrado se todas as dimensões não nulas forem mantidas. A propriedade dual vale para as colunas representadas por suas coordenadas principais.

Linhas e colunas também podem ser exibidas conjuntamente em um mesmo plano. Nesse mapa, a distância euclidiana entre uma categoria de linha e uma categoria de coluna não é uma distância qui-quadrado. A interpretação métrica permanece definida separadamente dentro de cada nuvem.

17.9.1 O significado das proximidades

Dentro da nuvem das linhas, pontos próximos correspondem a categorias com perfis de linha semelhantes segundo a distância qui-quadrado; a interpretação dual vale para as categorias de coluna.

Proximidades entre uma categoria de linha e uma categoria de coluna podem indicar associação entre as duas margens (Hair et al., 2009; Johnson; Wichern, 2002). Essa proximidade não possui a interpretação métrica da distância qui-quadrado, definida entre perfis pertencentes à mesma margem.

17.10 Formulação descritiva e relação com a inferência

A Análise de Correspondência descreve geometricamente o afastamento da independência na tabela observada. O teste de Pearson utiliza a mesma tabela para avaliar, sob um modelo probabilístico, a hipótese populacional de independência.

Para a tabela observada,

$$\chi^2 = n\mathcal{J},$$

conforme a Equação 17.25. Essa identidade é algébrica e exata: a estatística de Pearson χ^2 é igual ao tamanho total n multiplicado pela inércia total da tabela (Johnson; Wichern, 2002).

A interpretação inferencial exige um modelo probabilístico adicional para a geração da tabela. A formulação multinomial, as condições do resultado assintótico de Pearson e a origem dos graus de liberdade são desenvolvidas na Seção 17.13.6.

A distância qui-quadrado entre perfis, a estatística de Pearson χ^2 e a distribuição qui-quadrado utilizada como referência inferencial são objetos distintos. A distância qui-quadrado compar perfis; a estatística de Pearson quantifica o afastamento observado da independência; a distribuição de referência pertence à formulação inferencial.

Na formulação descritiva,

$$p_{ij}, \quad r_i \quad \text{e} \quad c_j$$

são quantidades calculadas a partir da tabela observada. A inércia

$$\mathcal{J}$$

mede o afastamento de

$$\mathbf{P} = \mathbf{r}\mathbf{c}^\top.$$

A SVD decompõe esse afastamento observado entre as dimensões,

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell.$$

Uma dimensão da Análise de Correspondência não corresponde a uma hipótese inferencial populacional separada. O teste de Pearson avalia globalmente a independência entre as duas variáveis, enquanto as dimensões decompõem descritivamente o afastamento observado.

A construção geométrica da Análise de Correspondência não depende da realização do teste formal de independência. A identidade

$$\chi^2 = n\mathcal{J}$$

relaciona algebricamente a estatística de Pearson à inércia da tabela observada, enquanto a interpretação inferencial de χ^2 requer a formulação probabilística apresentada em Seção 17.13.6.

Exemplo 17.1 (Análise de Correspondência de uma tabela 3×4). Considere a classificação de 120 atendimentos de uma lanchonete segundo o turno e o tipo de item escolhido. Os turnos são **manhã**, **tarde** e **noite**, e os itens são **café**, **suco**, **salgado** e **doce**. As frequências conjuntas observadas são

$$\mathbf{N} = \begin{pmatrix} 16 & 8 & 12 & 4 \\ 8 & 16 & 4 & 12 \\ 6 & 6 & 14 & 14 \end{pmatrix},$$

em que as linhas correspondem aos turnos manhã, tarde e noite, e as colunas correspondem a quatro categorias de itens.

O total observado é

$$n = 120.$$

A matriz de frequências relativas é

$$\mathbf{P} = \frac{1}{120}\mathbf{N} \approx \begin{pmatrix} 0,1333 & 0,0667 & 0,1000 & 0,0333 \\ 0,0667 & 0,1333 & 0,0333 & 0,1000 \\ 0,0500 & 0,0500 & 0,1167 & 0,1167 \end{pmatrix}.$$

As massas das linhas são

$$\mathbf{r} = \begin{pmatrix} 1/3 \\ 1/3 \\ 1/3 \end{pmatrix},$$

e as massas das colunas são

$$\mathbf{c} = \begin{pmatrix} 1/4 \\ 1/4 \\ 1/4 \\ 1/4 \end{pmatrix}.$$

Os perfis das linhas são

$$\mathbf{p}_{1\cdot} = \begin{pmatrix} 0,40 \\ 0,20 \\ 0,30 \\ 0,10 \end{pmatrix}, \quad \mathbf{p}_{2\cdot} = \begin{pmatrix} 0,20 \\ 0,40 \\ 0,10 \\ 0,30 \end{pmatrix},$$

e

$$\mathbf{p}_{3\cdot} = \begin{pmatrix} 0,15 \\ 0,15 \\ 0,35 \\ 0,35 \end{pmatrix}.$$

O centro da nuvem dos perfis de linhas é

$$\mathbf{c} = \begin{pmatrix} 0,25 \\ 0,25 \\ 0,25 \\ 0,25 \end{pmatrix}.$$

A distância qui-quadrado entre os dois primeiros perfis é

$$\begin{aligned} d_{\chi^2}^2(1, 2) &= \sum_{j=1}^4 \frac{1}{c_j} \left(\frac{p_{1j}}{r_1} - \frac{p_{2j}}{r_2} \right)^2 \\ &= \frac{(0,40 - 0,20)^2}{0,25} + \frac{(0,20 - 0,40)^2}{0,25} \\ &\quad + \frac{(0,30 - 0,10)^2}{0,25} + \frac{(0,10 - 0,30)^2}{0,25} \\ &= 0,64. \end{aligned}$$

Logo,

$$d_{\chi^2}(1, 2) = 0,80.$$

A matriz correspondente à independência é

$$\mathbf{rc}^{\top} = \begin{pmatrix} 1/12 & 1/12 & 1/12 & 1/12 \\ 1/12 & 1/12 & 1/12 & 1/12 \\ 1/12 & 1/12 & 1/12 & 1/12 \end{pmatrix}.$$

A matriz de desvios padronizados é

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2},$$

o que fornece

$$\mathbf{Q}_{\text{CA}} \approx \begin{pmatrix} 0,1732 & -0,0577 & 0,0577 & -0,1732 \\ -0,0577 & 0,1732 & -0,1732 & 0,0577 \\ -0,1155 & -0,1155 & 0,1155 & 0,1155 \end{pmatrix}.$$

Como

$$L = \text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I-1, J-1) = \min(2, 3) = 2,$$

há no máximo duas dimensões não nulas. A SVD de $\mathbf{Q}_{\text{CA}}$ fornece dois valores singulares positivos,

$$d_1 \approx 0,3266, \quad d_2 \approx 0,2828.$$

Portanto,

$$L = 2.$$

As inércias principais são

$$\lambda_1 = d_1^2 \approx 0,1067$$

e

$$\lambda_2 = d_2^2 = 0,0800.$$

A inércia total é

$$\mathcal{J} = \lambda_1 + \lambda_2 \approx 0,1867.$$

As proporções da inércia total associadas às duas dimensões são

$$\frac{\lambda_1}{\mathcal{J}} \approx 0,5714$$

e

$$\frac{\lambda_2}{J} \approx 0,4286.$$

Assim, a primeira dimensão representa aproximadamente 57,14% da inércia total e a segunda representa aproximadamente 42,86%.

Uma orientação possível para as coordenadas principais das linhas é

$$\mathbf{F}_r = \begin{pmatrix} 0,40 & -0,20 \\ -0,40 & -0,20 \\ 0 & 0,40 \end{pmatrix}.$$

As coordenadas principais das colunas podem ser escritas como

$$\mathbf{F}_c \approx \begin{pmatrix} 0,3266 & -0,2828 \\ -0,3266 & -0,2828 \\ 0,3266 & 0,2828 \\ -0,3266 & 0,2828 \end{pmatrix}.$$

A Figura 17.1 representa simultaneamente as coordenadas principais das três categorias de linha e das quatro categorias de coluna. As distâncias dentro de cada margem possuem a interpretação estabelecida pelas coordenadas principais; a distância entre um ponto de linha e um ponto de coluna não constitui uma distância qui-quadrado.

Na nuvem das linhas, manhã e tarde apresentam a maior separação na primeira dimensão, enquanto noite se distingue das duas primeiras principalmente pela segunda dimensão. Na nuvem das colunas, café e suco diferem na primeira dimensão, assim como salgado e doce, enquanto a segunda dimensão separa café e suco de salgado e doce.

As duas nuvens são apresentadas no mesmo sistema de eixos porque as dimensões de linhas e colunas são acopladas pela mesma decomposição singular. As distâncias entre categorias pertencentes à mesma margem podem ser interpretadas em termos das distâncias qui-quadrado entre seus perfis. A distância entre uma categoria de linha e uma categoria de coluna, entretanto, não corresponde diretamente a uma distância qui-quadrado.

A distância euclidiana entre as duas primeiras linhas na representação completa é

$$\begin{aligned} \|\mathbf{f}_1^{(r)} - \mathbf{f}_2^{(r)}\| &= \sqrt{(0,40 + 0,40)^2 + (-0,20 + 0,20)^2} \\ &= 0,80, \end{aligned}$$

igual à distância qui-quadrado entre seus perfis.




Figura 17.1: Representação conjunta das categorias de linha e de coluna em coordenadas principais nas duas dimensões da Análise de Correspondência.

A tabela possui duas dimensões não nulas. A primeira concentra aproximadamente 57,14% da inércia total e separa principalmente os perfis associados às duas primeiras categorias de linha. A segunda concentra aproximadamente 42,86% da inércia e distingue a terceira categoria de linha das demais. Como as duas dimensões são mantidas, a representação das linhas preserva exatamente suas distâncias qui-quadrado, e o mesmo ocorre para as colunas.

A estatística de Pearson é

$$\chi^2 = nJ = 120(0,1867) \approx 22,4.$$

Sob a hipótese populacional de independência e nas condições assintóticas apresentadas na Proposição 17.3, a distribuição de referência é

$$\chi^2_{(I-1)(J-1)} = \chi^2_6.$$

O exemplo distingue três quantidades relacionadas: as distâncias qui-quadrado comparam perfis dentro de cada margem, a inércia total quantifica o afastamento global da independência e a estatística de Pearson relaciona esse afastamento ao total de observações.

17.11 Relação com a Análise de Componentes Principais

A Análise de Componentes Principais e a Análise de Correspondência produzem representações de baixa dimensão a partir de decomposições matriciais, mas são formuladas para estruturas estatísticas diferentes (Johnson; Wichern, 2002).

Na ACP, as direções principais descrevem a variabilidade de dados quantitativos a partir de uma matriz de covariâncias ou correlações, conforme desenvolvido no Capítulo 14. Na Análise de Correspondência, a decomposição é aplicada à matriz de desvios da independência padronizados pelas massas,

$$\mathbf{Q}_{CA} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2},$$

e a representação descreve a associação entre categorias por meio dos perfis e da geometria qui-quadrado.

A semelhança entre as duas técnicas está na redução dimensional por decomposição matricial. A ACP organiza a variabilidade de dados quantitativos, enquanto a Análise de Correspondência organiza os desvios da independência em uma tabela de frequências. A Análise de Correspondência não corresponde à aplicação direta da ACP a variáveis categóricas.

17.12 Condições e limites da representação

A formulação da Análise de Correspondência é geométrica e descritiva e possui relativa liberdade de pressupostos estatísticos (Hair et al., 2009). A comparabilidade das categorias e a composição da tabela continuam fazendo parte da avaliação da análise. As condições necessárias à construção da geometria são distintas das hipóteses adicionais utilizadas na inferência sobre independência.

17.12.1 Massas positivas e frequências nulas

A tabela de contingência observada satisfaz

$$\mathbf{N} \in \mathbb{N}_0^{I \times J}$$

e

$$n > 0.$$

A definição dos perfis e da matriz $\mathbf{Q}_{CA}$ requer

$$r_i > 0, \quad i = 1, \dots, I,$$

e

$$c_j > 0, \quad j = 1, \dots, J,$$

para que os perfis e as inversas de $\mathbf{D}_r$ e $\mathbf{D}_c$ utilizados na técnica estejam definidos.

Linhas ou colunas com massa nula não possuem perfis definidos e não integram a geometria construída pelas matrizes $\mathbf{D}_r^{-1/2}$ e $\mathbf{D}_c^{-1/2}$.

Massas positivas muito pequenas não impedem matematicamente a análise. Na distância entre perfis de linhas, diferenças nas categorias de coluna são ponderadas pelos inversos das massas c_j ; na distância entre perfis de colunas, diferenças nas categorias de linha são ponderadas pelos inversos das massas r_i . Assim, uma categoria de pequena massa aumenta o peso de desvios que a envolvem na geometria da margem oposta. Sua própria distância ao centro depende de seu perfil, e não apenas de sua massa.

Uma frequência celular nula,

$$n_{ij} = 0,$$

não impede a construção dos perfis e da geometria quando a massa da linha i e a massa da coluna j permanecem positivas.

17.12.2 Composição da tabela e generalização

A solução depende das categorias que compõem a tabela. Linhas ou colunas atípicas podem alterar a configuração obtida, e a omissão de categorias pertencentes ao conjunto de interesse limita a generalização da representação (Hair et al., 2009).

17.12.3 Dimensão da representação

Pela Equação 17.22,

$$L = \text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1).$$

Quando apenas

$$1 \leq k < L$$

dimensões são mantidas, $\Pi_k^{(\text{CA})}$ é a proporção da inércia total representada pelas primeiras k dimensões.

O mapa é, nesse caso, uma representação de posto reduzido. Uma representação bidimensional não implica que a associação observada seja intrinsecamente bidimensional.

17.12.4 Sinais e orientação

A troca simultânea do sinal de $\mathbf{u}_\ell$ e $\mathbf{v}_\ell$ reflete as coordenadas de linhas e colunas na dimensão ℓ , mas não altera a reconstrução nem a inércia. A designação dos lados positivo e negativo de um eixo é arbitrária, enquanto as posições relativas das categorias permanecem inalteradas.

A não unicidade associada a valores singulares repetidos é desenvolvida em Seção 17.13.2.

17.12.5 Limites da interpretação

A Análise de Correspondência descreve associações entre categorias e é utilizada principalmente de forma exploratória (Hair et al., 2009). Uma inércia positiva,

$$\mathcal{J} > 0,$$

indica que a tabela observada se afasta da estrutura

$$\mathbf{P} = \mathbf{rc}^\top.$$

Sob a formulação multinomial da Seção 17.13.6, a rejeição do teste global fornece evidência contra a hipótese populacional de independência. A rejeição indica associação populacional entre as variáveis; não estabelece precedência temporal nem exclui explicações alternativas e, portanto, não sustenta interpretação causal (Hair et al., 2009).

17.13 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte trata do limite do posto decorrente das restrições marginais, da não unicidade dos eixos em blocos singulares, da centralização ponderada das coordenadas, da reconstrução dos desvios da independência, da decomposição da estatística de Pearson pelas dimensões e da formulação probabilística do teste global de independência.

17.13.1 Limite do posto da matriz de desvios padronizados

O limite da Equação 17.22 decorre de restrições lineares produzidas pelas próprias marginais da tabela. Como

$$\mathbf{P}\mathbf{1}_J = \mathbf{r}$$

e

$$\mathbf{c}^\top \mathbf{1}_J = 1,$$

segue que

$$\begin{aligned}
\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J &= \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{1}_J \\
&= \mathbf{D}_r^{-1/2} (\mathbf{r} - \mathbf{r}) \\
&= \mathbf{0}.
\end{aligned} \tag{17.41}$$

Analogamente,

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}. \tag{17.42}$$

Como

$$\mathbf{D}_c^{1/2} \mathbf{1}_J \neq \mathbf{0}$$

e

$$\mathbf{D}_r^{1/2} \mathbf{1}_I \neq \mathbf{0}$$

sob massas positivas, $\mathbf{Q}_{\text{CA}}$ possui um vetor não nulo em seu núcleo à direita e um vetor não nulo no núcleo de sua transposta. Portanto,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq J - 1$$

e

$$\text{posto}(\mathbf{Q}_{\text{CA}}^\top) \leq I - 1.$$

Consequentemente,

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1),$$

o que demonstra o limite enunciado em Equação [17.22](#).

17.13.2 Não unicidade dos eixos e dos subespaços representados

A não unicidade geral dos vetores singulares descrita na Seção 6.1.6 determina, na Análise de Correspondência, quais aspectos de um mapa permanecem invariantes quando a base singular não é única.

Para um valor singular simples, a troca simultânea

$$\mathbf{u}_\ell \mapsto -\mathbf{u}_\ell, \quad \mathbf{v}_\ell \mapsto -\mathbf{v}_\ell$$

não altera

$$d_\ell \mathbf{u}_\ell \mathbf{v}_\ell^\top.$$

Consequentemente, as coordenadas de linhas e colunas podem ser refletidas simultaneamente em uma dimensão sem modificar a reconstrução.

Quando um valor singular d possui multiplicidade $m > 1$, considere as matrizes $\mathbf{U}_B$ e $\mathbf{V}_B$ formadas pelos vetores singulares do bloco correspondente. Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\mathbf{U}_B \mapsto \mathbf{U}_B \mathbf{R}, \quad \mathbf{V}_B \mapsto \mathbf{V}_B \mathbf{R},$$

e

$$\mathbf{U}_B \mathbf{R} (d \mathbf{I}_m) (\mathbf{V}_B \mathbf{R})^\top = \mathbf{U}_B (d \mathbf{I}_m) \mathbf{V}_B^\top.$$

Assim, os eixos individuais do bloco não são determinados de maneira única, mas o subespaço por eles gerado permanece o mesmo.

Se todas as dimensões associadas ao valor singular repetido forem mantidas, o subespaço, a parcela de inércia e as distâncias euclidianas entre os pontos de cada nuvem permanecem invariantes. Se o truncamento ocorrer dentro desse bloco, diferentes subespaços de mesma dimensão podem produzir aproximações igualmente ótimas. Nesse caso, a orientação dos eixos retidos não deve ser tratada como uma característica única da solução.

17.13.3 Centralização ponderada das coordenadas padrão e principais

As restrições marginais demonstradas na Seção 17.13.1 determinam também a centralização ponderada das coordenadas padrão e principais.

A partir da Equação 17.41, da Equação 17.42 e da decomposição da Equação 17.26, obtêm-se

$$\mathbf{V}^\top \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}$$

e

$$\mathbf{U}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}.$$

De fato, a matriz $\mathbf{D}$ da SVD compacta reúne apenas os valores singulares positivos e, portanto, é invertível. Substituindo as definições das coordenadas padrão dadas na Equação 17.35 e na Equação 17.36, segue que

$$\begin{aligned} \mathbf{r}^\top \mathbf{A}_r &= \left(\mathbf{D}_r^{1/2} \mathbf{1}_I \right)^\top \mathbf{U} = \mathbf{0}^\top, \\ \mathbf{c}^\top \mathbf{A}_c &= \left(\mathbf{D}_c^{1/2} \mathbf{1}_J \right)^\top \mathbf{V} = \mathbf{0}^\top. \end{aligned}$$

As coordenadas principais herdam a mesma centralização:

$$\mathbf{r}^\top \mathbf{F}_r = \mathbf{0}^\top, \quad \mathbf{c}^\top \mathbf{F}_c = \mathbf{0}^\top.$$

Portanto, os centros ponderados das categorias de linha e de coluna coincidem com a origem, tanto em coordenadas padrão quanto em coordenadas principais. Os pesos são as massas das categorias, e não, em geral, pesos iguais. A centralização permanece válida coordenada a coordenada quando apenas parte das dimensões é mantida.

17.13.4 Reconstrução dos desvios da independência

A SVD decompõe os desvios da independência e produz representações de posto reduzido dos perfis (Johnson; Wichern, 2002).

Pela Equação 17.20,

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r^{1/2} \mathbf{Q}_{CA} \mathbf{D}_c^{1/2}.$$

Substituindo a decomposição da Equação 17.26 e usando as definições das coordenadas padrão da Equação 17.35 e da Equação 17.36, obtêm-se

$$\mathbf{P} - \mathbf{r}\mathbf{c}^\top = \mathbf{D}_r \mathbf{A}_r \mathbf{D}_c \mathbf{A}_c^\top \mathbf{D}_c. \quad (17.43)$$

Consequentemente, para a célula (i, j) ,

$$p_{ij} - r_i c_j = r_i c_j \sum_{\ell=1}^L d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)}, \quad (17.44)$$

e

$$p_{ij} = r_i c_j \left[1 + \sum_{\ell=1}^L d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (17.45)$$

Quando apenas as primeiras $k < L$ dimensões são mantidas, a reconstrução correspondente é

$$\tilde{p}_{ij}^{(k)} = r_i c_j \left[1 + \sum_{\ell=1}^k d_\ell a_{i\ell}^{(r)} a_{j\ell}^{(c)} \right]. \quad (17.46)$$

Essa reconstrução é induzida pela aproximação

$$\mathbf{Q}_{\text{CA},k} = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top,$$

que retém os primeiros k termos da SVD e produz uma aproximação de posto reduzido dos perfis (Johnson; Wichern, 2002).

O erro da aproximação na matriz de desvios padronizados é

$$\|\mathbf{Q}_{\text{CA}} - \mathbf{Q}_{\text{CA},k}\|_F^2 = \sum_{\ell=k+1}^L d_\ell^2 = \sum_{\ell=k+1}^L \lambda_\ell.$$

A soma das inércias principais descartadas corresponde, portanto, à inércia não representada pela solução de dimensão k .

17.13.5 Decomposição da estatística de Pearson pelas dimensões

Pela Equação 17.29,

$$\chi^2 = \sum_{\ell=1}^L n\lambda_{\ell}. \quad (17.47)$$

Cada termo $n\lambda_{\ell}$ é o componente da decomposição algébrica da estatística de Pearson associado à dimensão ℓ da tabela observada.

A Equação 17.47 é uma identidade algébrica. Ela não implica que os termos $n\lambda_{\ell}$ sejam estatísticas qui-quadrado independentes nem define testes separados por dimensão. Conforme a Seção 12.4.1, o teste de Pearson avalia a hipótese global de independência. Sob a formulação multinomial da Seção 17.13.6, a distribuição de referência é associada à estatística global χ^2 .

17.13.6 Formulação probabilística e teste de independência

Na formulação multinomial, sejam A e B duas variáveis categóricas com probabilidades conjuntas populacionais

$$\pi_{ij} = P(A = i, B = j),$$

com

$$\pi_{ij} \geq 0, \quad \sum_{i=1}^I \sum_{j=1}^J \pi_{ij} = 1.$$

As probabilidades marginais são

$$\pi_{i\cdot} = \sum_{j=1}^J \pi_{ij}$$

e

$$\pi_{\cdot j} = \sum_{i=1}^I \pi_{ij}.$$

A hipótese populacional de independência é

$$H_0 : \pi_{ij} = \pi_{i\cdot} \pi_{\cdot j}, \quad i = 1, \dots, I, \quad j = 1, \dots, J. \quad (17.48)$$

As quantidades p_{ij} , r_i e c_j são calculadas a partir da tabela observada, enquanto π_{ij} , $\pi_{i\cdot}$ e $\pi_{\cdot j}$ são parâmetros da distribuição populacional.

Em uma amostra aleatória de tamanho n formada por observações independentes dessa distribuição conjunta, o vetor das frequências celulares é aleatório e possui distribuição multinomial de tamanho n e probabilidades celulares π_{ij} . As frequências n_{ij} utilizadas na tabela são a realização observada desse vetor.

Proposição 17.3 (Distribuição assintótica da estatística de Pearson sob independência). *Considere uma tabela de contingência $I \times J$, com*

$$I \geq 2, \quad J \geq 2,$$

obtida de uma amostra multinomial de tamanho n , mantendo I e J fixos.

Sob

$$H_0 : \pi_{ij} = \pi_{i\cdot} \pi_{\cdot j},$$

suponha

$$\pi_{i\cdot} > 0, \quad i = 1, \dots, I,$$

e

$$\pi_{\cdot j} > 0, \quad j = 1, \dots, J.$$

Então, quando

$$n \longrightarrow \infty,$$

a estatística de Pearson satisfaz

$$\chi^2 \xrightarrow{d} \chi^2_{(I-1)(J-1)}. \quad (17.49)$$

Os $(I-1)(J-1)$ graus de liberdade resultam da diferença entre a dimensão do modelo conjunto irrestrito e a dimensão do modelo de independência. Uma distribuição conjunta sobre uma tabela $I \times J$ possui

$$IJ - 1$$

probabilidades livres, pois sua soma é igual a 1. Sob independência, a distribuição é determinada pelas probabilidades marginais das linhas e das colunas, que possuem, respectivamente,

$$I - 1 \quad \text{e} \quad J - 1$$

parâmetros livres. A diferença entre essas dimensões é

$$(IJ - 1) - [(I - 1) + (J - 1)] = (I - 1)(J - 1),$$

que corresponde aos graus de liberdade da estatística de Pearson sob a hipótese de independência.

A convergência em distribuição da Equação 17.49 é um resultado assintótico no sentido da Definição 12.1 e deve ser distinguida da identidade algébrica exata

$$\chi^2 = n\mathcal{I}.$$

Sob H_0 , a distribuição $\chi^2_{(I-1)(J-1)}$ é a referência inferencial assintótica; a identidade $\chi^2 = n\mathcal{I}$ é válida para a tabela observada.

17.14 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata da definição da tabela e do exame das categorias, da escolha do número de dimensões, da leitura da representação reduzida e da avaliação da sensibilidade e da validação da solução.

17.14.1 Definição da tabela e exame das categorias

A solução depende das categorias incluídas na tabela de contingência. Alterar esse conjunto modifica as massas, os perfis, a matriz de desvios padronizados da independência e, portanto, as dimensões obtidas.

A interpretação do mapa deve considerar as frequências marginais e os perfis. Pela geometria qui-quadrado, diferenças associadas a categorias de pequena massa recebem maior peso na comparação dos perfis da margem oposta. A solução também é sensível a linhas ou colunas atípicas e ao conjunto de categorias incluídas na análise (Hair et al., 2009).

A exclusão, a agregação ou a recodificação de categorias modifica a tabela e pode modificar a solução. Essas decisões devem decorrer da definição das categorias, da origem dos dados e do objetivo da análise.

17.14.2 Relação com o teste global de independência

A Análise de Correspondência é utilizada principalmente como técnica exploratória e gráfica (Hair et al., 2009; Johnson; Wichern, 2002). Sua construção geométrica não depende da realização de um teste de independência.

Quando a estatística de Pearson é considerada no modelo probabilístico desenvolvido em Seção 17.13.6, sua referência inferencial corresponde à hipótese global de independência. Esse resultado não define testes separados para dimensões, categorias ou células da representação.

17.14.3 Escolha do número de dimensões

A solução completa possui as L dimensões não nulas da decomposição da Equação 17.26, com o limite dimensional dado pela Equação 17.22. Para $L > 1$, uma representação reduzida exige escolher $k < L$ dimensões.

A escolha de k não modifica a solução completa; ela determina quantas dimensões serão utilizadas na representação. A proporção acumulada

$$\Pi_k^{(CA)} = \frac{\sum_{\ell=1}^k \lambda_{\ell}}{\mathcal{J}}$$

quantifica a parcela da inércia total representada pelas primeiras k dimensões. A parcela não representada é

$$1 - \Pi_k^{(CA)} = \frac{\sum_{\ell=k+1}^L \lambda_\ell}{J}. \quad (17.50)$$

A proporção de inércia representada é utilizada para avaliar soluções de baixa dimensão (Johnson; Wichern, 2002). Valores elevados indicam que o subespaço retido preserva grande parte da inércia total.

A Análise de Correspondência não possui um procedimento conclusivo para determinar o número apropriado de dimensões. Hair et al. (Hair et al., 2009) recomendam equilibrar parcimônia e interpretabilidade e apresentam, como regras práticas, a retenção de dimensões com inércia superior a 0,2 e de dimensões suficientes para atender aos objetivos da análise, geralmente duas ou três.

Essas orientações são heurísticas e não alteram a definição matemática da solução. Uma representação bidimensional, por exemplo, pode facilitar a visualização sem representar toda a inércia da tabela.

17.14.4 Leitura da representação reduzida

A leitura de uma representação reduzida deve considerar a proporção de inércia preservada e a geometria definida pela técnica.

Entre categorias de linhas, distâncias pequenas correspondem a perfis de linhas semelhantes segundo a distância qui-quadrado. A interpretação dual vale entre categorias de colunas. Quando apenas $k < L$ dimensões são representadas, as distâncias exibidas correspondem às parcelas das distâncias completas associadas às dimensões retidas.

A posição de uma categoria também deve ser examinada em relação à origem. Em cada nuvem, a origem representa o perfil marginal correspondente; categorias mais afastadas apresentam perfis mais distintos desse centro na representação considerada.

Na comparação entre perfis de linhas, diferenças associadas a colunas de pequena massa recebem maior peso; na comparação entre perfis de colunas, a propriedade dual vale para as massas das linhas. Massas e perfis devem, portanto, acompanhar a leitura das posições no mapa.

A distância qui-quadrado compara perfis pertencentes à mesma margem (Hair et al., 2009). Distâncias entre duas linhas ou entre duas colunas possuem essa interpretação métrica. A distância euclidiana entre uma categoria de linha e uma categoria de coluna não possui a mesma interpretação. A posição relativa entre as duas margens integra a representação da associação, mas não define uma distância entre perfis.

Na Figura 17.2, as distâncias dentro de cada nuvem são representadas nas duas dimensões exibidas e podem diferir das distâncias qui-quadrado completas quando existem dimensões omitidas.




Figura 17.2: Representação conjunta das categorias de linhas e colunas nas duas primeiras dimensões. As distâncias dentro de cada nuvem são representadas no subespaço exibido; a distância entre uma linha e uma coluna não corresponde, em geral, a uma distância qui-quadrado.

17.14.5 Sensibilidade e validação da interpretação

A reprodução da solução pode ser examinada em relação à amostra e ao conjunto de categorias (Hair et al., 2009).

Em subamostras ou múltiplas amostras, a comparação deve considerar a estrutura dimensional e as posições relativas das categorias.

A sensibilidade ao conjunto de categorias pode ser examinada comparando soluções obtidas após a inclusão ou a exclusão de categorias (Hair et al., 2009). Mudanças nas dimensões retidas ou nas posições relativas das categorias indicam dependência da configuração em relação à composição da tabela.

Uma representação com $k < L$ dimensões omite parte da inércia total. A interpretação do mapa deve, portanto, considerar a proporção de inércia preservada.

A inversão simultânea do sinal de um eixo não caracteriza mudança da solução. Quando valores singulares iguais ou próximos tornam a orientação dos eixos individualmente instável, a comparação deve privilegiar as configurações e os subespaços representados, conforme a Seção 17.13.2.

17.14.6 Análise de Correspondência Múltipla

Quando três ou mais variáveis categóricas são analisadas conjuntamente, a extensão é denominada **Análise de Correspondência Múltipla (ACM)** (Hair et al., 2009).

A ACM representa as categorias das variáveis em um espaço multidimensional comum. O objetivo é obter uma configuração de baixa dimensão que sintetize as associações entre categorias das diferentes variáveis (Hair et al., 2009).

A formulação matricial baseada em uma tabela bidimensional corresponde à Análise de Correspondência simples. A ACM requer uma extensão dessa formulação para acomodar simultaneamente mais de duas variáveis categóricas.

17.14.7 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise de Correspondência será realizada pelo módulo **MEDA** (Leblay et al., 2026) do **jamovi** (The jamovi project, 2026). Na versão auditada, o **MEDA** utiliza procedimentos do pacote **FactoMineR** (Lê; Josse; Husson, 2008).

A Tabela 17.2 relaciona as principais saídas utilizadas nas atividades aos objetos estatísticos desenvolvidos no capítulo.

Tabela 17.2: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Coluna de identificação das linhas	rótulos das categorias de linha	Seção 17.1
Colunas quantitativas ativas	frequências das categorias de coluna utilizadas na análise	Seção 17.1 e Seção 17.14.1
Percentage	proporção $\lambda_\ell/\mathcal{J}$ da inércia total associada à dimensão ℓ	Equação 17.30 e Seção 17.14.3
Row coordinates	coordenadas principais das linhas $\mathbf{F}_r$	Equação 17.37
Column coordinates	coordenadas principais das colunas $\mathbf{F}_c$	Equação 17.38
Chi-square test	estatística e teste global de independência de Pearson	Seção 17.13.6 e Seção 17.14.2

As coordenadas principais de linhas e colunas determinam a representação das duas margens. Distâncias entre categorias pertencentes à mesma margem devem ser interpretadas segundo a geometria discutida em Seção 17.14.4; a distância entre uma categoria de linha e uma categoria de coluna não constitui uma distância qui-quadrado.

A porcentagem associada a cada dimensão corresponde a

$$100 \frac{\lambda_\ell}{\mathcal{J}}.$$

A soma das porcentagens das primeiras k dimensões corresponde a

$$100 \Pi_k^{(CA)}.$$

O teste qui-quadrado corresponde ao teste global de independência discutido em Seção 17.13.6 e Seção 17.14.2. Sua presença entre as saídas computacionais não altera o caráter exploratório da representação de Correspondência.

17.15 Síntese

A Análise de Correspondência simples representa associações entre as categorias de duas variáveis categóricas a partir de uma tabela de contingência

$$\mathbf{N} = (n_{ij}) \in \mathbb{N}_0^{I \times J}.$$

A matriz de frequências relativas

$$\mathbf{P} = \frac{1}{n} \mathbf{N}$$

determina as massas

$$\mathbf{r} = \mathbf{P} \mathbf{1}_J \quad \text{e} \quad \mathbf{c} = \mathbf{P}^\top \mathbf{1}_I$$

e os perfis condicionais das linhas e das colunas.

Sob independência, a estrutura de referência é

$$\mathbf{P} = \mathbf{r} \mathbf{c}^\top.$$

A Correspondência analisa o afastamento dessa estrutura por meio dos perfis ponderados e das distâncias qui-quadrado. Os desvios padronizados da independência são reunidos na matriz

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

A norma de Frobenius de $\mathbf{Q}_{\text{CA}}$ determina a inércia total,

$$\mathcal{J} = \|\mathbf{Q}_{\text{CA}}\|_F^2.$$

A decomposição em valores singulares

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

decompõe essa inércia em

$$\mathcal{J} = \sum_{\ell=1}^L \lambda_\ell, \quad \lambda_\ell = d_\ell^2.$$

As inércias principais λ_ℓ quantificam a inércia associada a cada dimensão. As razões $\lambda_\ell/\mathcal{J}$ indicam as proporções da inércia total associadas às dimensões individuais, enquanto $\Pi_k^{(\text{CA})}$ indica a proporção acumulada nas primeiras k dimensões. Uma representação com $k < L$ dimensões preserva a proporção $\Pi_k^{(\text{CA})}$ da inércia total e descarta a proporção $1 - \Pi_k^{(\text{CA})}$.

As coordenadas principais fornecem representações euclidianas das distâncias qui-quadrado dentro de cada margem. Quando todas as dimensões não nulas são mantidas, as distâncias euclidianas entre pontos de linhas reproduzem as distâncias qui-quadrado entre seus perfis, e a relação dual vale para as colunas. A dualidade da construção conecta as duas nuvens, mas não estabelece uma distância qui-quadrado direta entre uma categoria de linha e uma categoria de coluna.

Para a tabela observada,

$$\chi^2 = nJ.$$

Essa identidade relaciona a geometria da Correspondência à estatística de Pearson. A inércia descreve o afastamento observado da independência, enquanto a interpretação inferencial de χ^2 em relação à hipótese populacional de independência requer um modelo probabilístico e as condições do resultado assintótico.

A ACP e a Análise de Correspondência produzem representações de baixa dimensão por decomposição matricial, mas partem de objetos diferentes. A ACP organiza a variabilidade de dados quantitativos, enquanto a Análise de Correspondência organiza os desvios da independência em uma tabela de contingência segundo a geometria qui-quadrado.

No Capítulo 18, o problema estatístico passa da representação de associações entre categorias para a comparação conjunta de várias respostas quantitativas entre grupos ou condições previamente definidos. A formulação utiliza o modelo linear multivariado, as matrizes de hipótese e erro e critérios baseados em sua estrutura espectral.

18 Formulação da MANOVA

A Análise Multivariada de Variância (MANOVA) testa hipóteses sobre vetores de médias ou, de forma mais geral, sobre funções estimáveis dos parâmetros de um modelo linear com várias respostas. A formulação considera p respostas quantitativas observadas nas mesmas unidades. Grupos, tratamentos, fatores e covariáveis são representados na matriz de delineamento.

O modelo linear multivariado definido na Definição 11.3 é

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

A MANOVA compara a matriz de somas de quadrados e produtos cruzados (SQPC) da hipótese, $\mathbf{H}$, com a SQPC residual, $\mathbf{E}$. O problema de autovalores generalizados associado a essas matrizes produz as raízes utilizadas pela lambda de Wilks, pelo critério de Pillai, pelo traço de Hotelling e pela maior raiz característica de Roy (Hair et al., 2009; Johnson; Wichern, 2002).

A hipótese linear geral da Definição 11.17, a SQPC da hipótese da Definição 11.18 e a SQPC residual da Definição 11.11 são utilizadas diretamente na formulação da MANOVA.

Os elementos da formulação são resumidos na Tabela 18.1.

Tabela 18.1: Elementos da formulação da MANOVA.

Elemento	Objeto	Papel na MANOVA
respostas	$\mathbf{y}$	reúne as p respostas observadas nas mesmas unidades
delineamento	$\mathbf{Z}$	representa grupos, tratamentos, covariáveis e demais termos
parâmetros	$\mathbf{B}$	reúne os coeficientes que determinam a matriz de médias $\mathbf{ZB}$
hipótese	$\mathbf{C}_1\mathbf{B} = \boldsymbol{\Theta}_0$	especifica uma função estimável sobre todas as respostas

Elemento	Objeto	Papel na MANOVA
SQPC da hipótese	$\mathbf{H}$	reúne somas de quadrados e produtos cruzados associados ao afastamento observado de H_0
SQPC residual	$\mathbf{E}$	reúne somas de quadrados e produtos cruzados residuais
comparação direcional	$\mathbf{a}^\top \mathbf{H} \mathbf{a} / \mathbf{a}^\top \mathbf{E} \mathbf{a}$	compara hipótese e erro para uma combinação das respostas
solução espectral	raízes e direções características	identifica as direções extremas da razão entre hipótese e erro e seus valores associados
critérios de teste	lambda de Wilks, critério de Pillai, traço de Hotelling e maior raiz característica de Roy	combinam as mesmas raízes características por funções diferentes

18.1 O problema de comparação multivariada

Considere inicialmente $K \geq 2$ grupos e um vetor de p respostas para cada unidade,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ \vdots \\ Y_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

Se o vetor de médias do grupo k é

$$\mu_k = \begin{pmatrix} \mu_{k1} \\ \vdots \\ \mu_{kp} \end{pmatrix} \in \mathbb{R}^p, \quad k = 1, \dots, K,$$

a hipótese de igualdade dos vetores de médias é

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_K. \quad (18.1)$$

A hipótese alternativa afirma que pelo menos dois desses vetores de médias diferem.

Quando

$$p = 1,$$

a hipótese da Equação 18.1 é univariada e a comparação pode ser expressa pela razão entre a soma de quadrados da hipótese e a soma de quadrados residual.

Quando

$$p > 1,$$

as diferenças entre os vetores de médias pertencem a $\mathbb{R}^p$ e podem ser examinadas por combinações lineares das respostas. Uma combinação linear pode evidenciar diferenças entre grupos que são pequenas em cada resposta considerada isoladamente. Diferenças marginais observadas em várias respostas também devem ser interpretadas considerando as covariâncias residuais entre elas.

A MANOVA avalia as diferenças entre os vetores de médias em relação à variabilidade residual de cada resposta e às covariâncias residuais entre as respostas.

A comparação multivariada não é equivalente a realizar separadamente p análises de variância, pois essas análises marginais não incorporam as covariâncias residuais entre as respostas. Na MANOVA, somas de quadrados e produtos cruzados da hipótese e do erro são organizados em matrizes que preservam essa informação conjunta.

18.2 A hipótese no modelo linear multivariado

O problema de comparação entre grupos é uma aplicação do modelo linear multivariado. Indicadores de grupos, tratamentos, fatores e covariáveis são incorporados à matriz de delineamento $\mathbf{Z}$.

Pela Definição 11.17, a hipótese linear geral é

$$H_0 : \mathbf{C}_1 \mathbf{B} \mathbf{C}_2 = \Theta_0. \quad (18.2)$$

Na MANOVA formulada para as p respostas originais,

$$\mathbf{C}_2 = \mathbf{I}_p,$$

e a hipótese torna-se

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0, \quad (18.3)$$

com

$$\mathbf{C}_1 \in \mathbb{R}^{g \times q}$$

e

$$\Theta_0 \in \mathbb{R}^{g \times p}.$$

A matriz $\mathbf{C}_1$ reúne as combinações lineares dos parâmetros que definem o efeito testado. A formulação utiliza $\mathbf{C}_1$ com linhas linearmente independentes,

$$\text{posto}(\mathbf{C}_1) = g, \quad (18.4)$$

e exige que $\mathbf{C}_1 \mathbf{B}$ seja estimável. Pela condição da Equação 11.117,

$$\mathbf{C}_1 = \mathbf{C}_1 \mathbf{Z}^+ \mathbf{Z}. \quad (18.5)$$

Como $\mathbf{C}_1$ possui g linhas linearmente independentes, os graus de liberdade da hipótese são

$$\nu_H = g. \quad (18.6)$$

Para a hipótese de igualdade dos vetores de médias de K grupos,

$$g = K - 1. \quad (18.7)$$

A hipótese de igualdade dos vetores de médias da Equação 18.1 é um caso particular da hipótese linear geral da Definição 11.17.

18.2.1 SQPC da hipótese e SQPC residual

Para a hipótese da Equação 18.3, a SQPC da hipótese definida na Definição 11.18 é denotada por

$$\mathbf{H} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{H} = \mathbf{H}^\top \succeq \mathbf{0}.$$

A matriz $\mathbf{H}$ reúne as somas de quadrados e os produtos cruzados associados ao afastamento observado de H_0 . Seus elementos diagonais são as somas de quadrados da hipótese para cada resposta, enquanto os elementos fora da diagonal são os produtos cruzados entre os afastamentos correspondentes.

Pela Definição 11.11, a SQPC residual é

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{E} = \mathbf{E}^\top \succeq \mathbf{0}.$$

Os elementos diagonais de $\mathbf{E}$ são as somas de quadrados residuais de cada resposta, enquanto os elementos fora da diagonal são os produtos cruzados residuais entre as respostas.

A Tabela 18.2 compara a origem e a interpretação das SQPCs $\mathbf{H}$ e $\mathbf{E}$.

Tabela 18.2: Funções das matrizes de hipótese e erro na MANOVA.

Matriz	Origem	Interpretação
$\mathbf{H}$	hipótese testada	somas de quadrados e produtos cruzados associados ao afastamento observado de H_0
$\mathbf{E}$	resíduos do modelo	somas de quadrados e produtos cruzados residuais

Se

$$\mathbf{H} = \mathbf{0},$$

não há afastamento observado da hipótese nas funções paramétricas consideradas. Quando $\mathbf{H} \neq \mathbf{0}$, o afastamento deve ser avaliado em relação à variação residual representada por $\mathbf{E}$.

A comparação entre $\mathbf{H}$ e $\mathbf{E}$ é feita para as mesmas combinações lineares das respostas.

18.3 Hipótese e erro em uma combinação linear das respostas

Para a unidade i , considere a combinação linear das p respostas

$$W_i = \mathbf{a}^\top \mathbf{Y}_i, \quad \mathbf{a} \in \mathbb{R}^p. \quad (18.8)$$

Para a combinação linear da Equação 18.8, as somas de quadrados associadas à hipótese e ao erro são

$$h(\mathbf{a}) = \mathbf{a}^\top \mathbf{H} \mathbf{a} \quad (18.9)$$

e

$$e(\mathbf{a}) = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (18.10)$$

Pela Definição 2.23, $h(\mathbf{a})$ e $e(\mathbf{a})$ são formas quadráticas em $\mathbf{a}$. A primeira é a soma de quadrados associada à hipótese para a resposta combinada W_i , enquanto a segunda é sua soma de quadrados residual.

A formulação espectral adotada pressupõe

$$\mathbf{E} \succ \mathbf{0}. \quad (18.11)$$

Então,

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0},$$

e a razão entre hipótese e erro é definida por

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (18.12)$$

A razão da Equação 18.12 é o quociente de Rayleigh generalizado definido na Definição 5.12, aplicado ao par

$$(\mathbf{H}, \mathbf{E}).$$

A razão é invariante à escala de $\mathbf{a}$. Para qualquer

$$c \neq 0,$$

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}).$$

A razão depende apenas da direção definida por $\mathbf{a}$ e não de sua norma.

Uma direção apresenta grande razão hipótese/erro quando a soma de quadrados associada à hipótese é grande em relação à soma de quadrados residual da mesma combinação de respostas.

18.4 Problema espectral da MANOVA

Pelo Teorema 5.8, aplicado ao par $(\mathbf{H}, \mathbf{E})$ com

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0},$$

o maior valor da razão hipótese/erro é

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}} = \lambda_1. \quad (18.13)$$

As direções características são obtidas do problema de autovalor generalizado

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}. \quad (18.14)$$

Esse é o problema de autovalor generalizado definido na Definição 5.11.

Definição 18.1 (Raízes características da MANOVA). Sejam

$$\mathbf{H}, \mathbf{E} \in \mathbb{R}^{p \times p}$$

simétricas, com

$$\mathbf{H} \succeq \mathbf{0}$$

e

$$\mathbf{E} \succ \mathbf{0}.$$

As **raízes características da MANOVA** são os autovalores generalizados

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$$

do par $(\mathbf{H}, \mathbf{E})$. Como $\mathbf{E} \succ \mathbf{0}$, os autovetores generalizados associados podem ser escolhidos com a normalização

$$\alpha_j^\top \mathbf{E} \alpha_j = 1.$$

Os pares

$$(\lambda_j, \alpha_j)$$

satisfazem

$$\mathbf{H} \alpha_j = \lambda_j \mathbf{E} \alpha_j.$$

Cada λ_j é uma raiz característica, isto é, um autovalor generalizado do par $(\mathbf{H}, \mathbf{E})$. O vetor α_j é um autovetor generalizado normalizado, e a reta

$$\text{span}(\alpha_j)$$

define a direção característica correspondente.

Se

$$r_H = \text{posto}(\mathbf{H}),$$

então exatamente r_H raízes são positivas. Quando $r_H > 0$,

$$\lambda_1 \geq \cdots \geq \lambda_{r_H} > 0.$$

Se $r_H < p$,

$$\lambda_{r_H+1} = \cdots = \lambda_p = 0.$$

Como $\mathbf{C}_1$ possui posto g , a SQPC da hipótese satisfaz

$$\text{posto}(\mathbf{H}) \leq \min(p, g),$$

tem-se

$$r_H \leq \min(p, g). \quad (18.15)$$

Na hipótese de igualdade dos vetores de médias de K grupos,

$$g = K - 1,$$

logo

$$r_H \leq \min(p, K - 1). \quad (18.16)$$

Portanto, o número de raízes características positivas é limitado simultaneamente pelo número de respostas e pelo número de restrições lineares independentes da hipótese.

Como $\mathbf{E} \succ \mathbf{0}$, o produto interno induzido definido na Definição 3.16 pode ser aplicado com matriz $\mathbf{E}$. Os autovetores generalizados podem ser escolhidos ortonormais nesse produto interno:

$$\alpha_j^\top \mathbf{E} \alpha_\ell = \delta_{j\ell}. \quad (18.17)$$

As direções características não precisam, portanto, ser ortogonais na geometria euclidiana original das respostas.

18.4.1 Padronização pela SQPC residual e interpretação geométrica

Como

$$\mathbf{E} \succ \mathbf{0},$$

a raiz quadrada principal $\mathbf{E}^{1/2}$ é definida pela Definição 5.9 e também é positiva definida. Portanto, $\mathbf{E}^{1/2}$ é invertível.

Defina

$$\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

e o problema generalizado transforma-se em

$$\mathbf{M}_{\text{HE}} \mathbf{z} = \lambda \mathbf{z}, \quad (18.18)$$

em que

$$\mathbf{M}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (18.19)$$

Como $\mathbf{H} \succeq \mathbf{0}$,

$$\mathbf{M}_{\text{HE}} = \mathbf{M}_{\text{HE}}^\top \succeq \mathbf{0}.$$

Além disso,

$$\text{posto}(\mathbf{M}_{\text{HE}}) = \text{posto}(\mathbf{H}) = r_H,$$

Portanto, $\mathbf{M}_{\text{HE}}$ possui exatamente r_H autovalores positivos, que coincidem com as raízes positivas da MANOVA.

Substituindo

$$\mathbf{a} = \mathbf{E}^{-1/2} \mathbf{z},$$

obtêm-se

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{H} \mathbf{a} = \mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}.$$

Portanto,

$$\mathcal{R}_{\mathbf{H}, \mathbf{E}}(\mathbf{a}) = \frac{\mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}}{\mathbf{z}^\top \mathbf{z}}. \quad (18.20)$$

A transformação $\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a}$ converte a forma quadrática residual em uma norma euclidiana. Nesse sistema, $\mathbf{z}^\top \mathbf{M}_{\text{HE}} \mathbf{z}$ é a forma quadrática da hipótese correspondente à direção $\mathbf{z}$.

A Figura 18.1 representa a mudança de coordenadas $\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a}$ no espaço dos coeficientes das combinações lineares. Antes da padronização, o conjunto de vetores de coeficientes que satisfaz

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

forma uma elipse determinada pela forma quadrática residual. Sob a transformação

$$\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a},$$

a condição

$$\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$$

torna-se

$$\mathbf{z}^\top \mathbf{z} = 1,$$

que define o círculo unitário. Nesse sistema padronizado, as direções características são os autovetores de $\mathbf{M}_{\text{HE}}$.

A Figura 18.1 não representa observações, médias de grupos ou regiões de probabilidade. O contorno corresponde ao conjunto de combinações lineares normalizadas pela forma quadrática residual. A transformação

$$\mathbf{z} = \mathbf{E}^{1/2}\mathbf{a}$$

converte

$$\mathbf{a}^\top \mathbf{E} \mathbf{a}$$

em

$$\mathbf{z}^\top \mathbf{z}.$$

Se uma direção característica for normalizada por




Figura 18.1: Branqueamento da geometria residual. À esquerda, o contorno representa as combinações lineares normalizadas por $\mathbf{a}^\top \mathbf{E} \mathbf{a} = 1$. Após a transformação $\mathbf{z} = \mathbf{E}^{1/2} \mathbf{a}$, a métrica residual torna-se euclidiana e o contorno transforma-se no círculo unitário. As linhas indicam as duas direções características do problema.

$$\alpha_j^\top \mathbf{E} \alpha_j = 1,$$

então

$$\alpha_j^\top \mathbf{H} \alpha_j = \lambda_j. \quad (18.21)$$

Cada raiz λ_j é a razão hipótese/erro na respectiva direção característica normalizada. A ordenação $\lambda_1 \geq \dots \geq \lambda_p$ ordena essas direções pela razão entre a soma de quadrados da hipótese e a soma de quadrados residual.

A solução do problema espectral produz as raízes características ordenadas

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

Os quatro critérios clássicos da MANOVA são funções dessas raízes.

18.5 Critérios multivariados

Considere as raízes características

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

definidas na Definição 18.1 para o par $(\mathbf{H}, \mathbf{E})$, sob

$$\mathbf{H} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{E} \succ \mathbf{0}.$$

Os quatro critérios clássicos da MANOVA são funções das raízes

$$\lambda_1, \dots, \lambda_p.$$

As formas espectrais dos critérios decorrem da matriz padronizada

$$\mathbf{M}_{\mathbf{H}\mathbf{E}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2},$$

definida na Equação 18.19. Essa matriz é simétrica positiva semidefinida e possui autovalores

$$\lambda_1, \dots, \lambda_p.$$

Pela Proposição 5.4, o traço de uma matriz simétrica é a soma de seus autovalores e seu determinante é o produto desses autovalores. A Proposição 2.5 e a Proposição 2.9 permitem relacionar essas propriedades às expressões originais em $\mathbf{H}$ e $\mathbf{E}$. Além disso, pela Definição 5.8 e pela Proposição 5.7, uma função espectral de $\mathbf{M}_{\text{HE}}$ transforma cada autovalor λ_j no valor correspondente da função escalar.

Definição 18.2 (Lambda de Wilks). A **lambda de Wilks** é

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} = \prod_{j=1}^p \frac{1}{1 + \lambda_j}. \quad (18.22)$$

De fato, pela definição de $\mathbf{M}_{\text{HE}}$,

$$\mathbf{E} + \mathbf{H} = \mathbf{E}^{1/2} (\mathbf{I}_p + \mathbf{M}_{\text{HE}}) \mathbf{E}^{1/2}.$$

Pela propriedade multiplicativa do determinante em Proposição 2.9,

$$\begin{aligned} |\mathbf{E} + \mathbf{H}| &= |\mathbf{E}^{1/2}|^2 |\mathbf{I}_p + \mathbf{M}_{\text{HE}}| \\ &= |\mathbf{E}| |\mathbf{I}_p + \mathbf{M}_{\text{HE}}|. \end{aligned}$$

Os autovalores de $\mathbf{I}_p + \mathbf{M}_{\text{HE}}$ são

$$1 + \lambda_1, \dots, 1 + \lambda_p.$$

Pela Proposição 5.4,

$$|\mathbf{I}_p + \mathbf{M}_{\text{HE}}| = \prod_{j=1}^p (1 + \lambda_j).$$

Portanto,

$$|\mathbf{E} + \mathbf{H}| = |\mathbf{E}| \prod_{j=1}^p (1 + \lambda_j),$$

o que fornece

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}.$$

A lambda de Wilks satisfaz

$$0 < \Lambda_W \leq 1,$$

com

$$\Lambda_W = 1$$

se, e somente se,

$$\mathbf{H} = \mathbf{0}.$$

Como cada fator $(1 + \lambda_j)^{-1}$ decresce com λ_j , valores menores de Λ_W correspondem a raízes características maiores. Na Seção 18.9.1.1, esse critério é relacionado à razão de verossimilhanças sob o modelo normal (Wilks, 1932).

Definição 18.3 (Critério de Pillai). O **critério de Pillai** é (Pillai, 1955)

$$V = \text{tr} [\mathbf{H} (\mathbf{H} + \mathbf{E})^{-1}] = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}. \quad (18.23)$$

Cada raiz contribui pelo termo

$$\frac{\lambda_j}{1 + \lambda_j},$$

que pertence a $[0, 1)$ e cresce monotonicamente com λ_j .

Como

$$\mathbf{H} = \mathbf{E}^{1/2} \mathbf{M}_{\text{HE}} \mathbf{E}^{1/2}$$

e

$$\mathbf{H} + \mathbf{E} = \mathbf{E}^{1/2} (\mathbf{I}_p + \mathbf{M}_{\text{HE}}) \mathbf{E}^{1/2},$$

tem-se

$$\mathbf{H} (\mathbf{H} + \mathbf{E})^{-1} = \mathbf{E}^{1/2} \mathbf{M}_{\text{HE}} (\mathbf{I}_p + \mathbf{M}_{\text{HE}})^{-1} \mathbf{E}^{-1/2}.$$

Pela propriedade cíclica do traço em Proposição 2.5,

$$V = \text{tr} \left[\mathbf{M}_{\text{HE}} (\mathbf{I}_p + \mathbf{M}_{\text{HE}})^{-1} \right].$$

A matriz

$$\mathbf{M}_{\text{HE}} (\mathbf{I}_p + \mathbf{M}_{\text{HE}})^{-1}$$

é a função espectral de $\mathbf{M}_{\text{HE}}$ correspondente a

$$f(\lambda) = \frac{\lambda}{1 + \lambda}.$$

Pela Proposição 5.7, seus autovalores são

$$\frac{\lambda_1}{1 + \lambda_1}, \dots, \frac{\lambda_p}{1 + \lambda_p}.$$

Aplicando a Proposição 5.4 ao traço,

$$V = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}.$$

Definição 18.4 (Traço de Hotelling). O **traço de Hotelling** é

$$U = \text{tr} (\mathbf{E}^{-1} \mathbf{H}) = \sum_{j=1}^p \lambda_j. \quad (18.24)$$

Pela propriedade cíclica do traço em Proposição 2.5,

$$\begin{aligned} \text{tr} (\mathbf{E}^{-1} \mathbf{H}) &= \text{tr} (\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}) \\ &= \text{tr} (\mathbf{M}_{\text{HE}}). \end{aligned}$$

Como os autovalores de $\mathbf{M}_{\text{HE}}$ são $\lambda_1, \dots, \lambda_p$, a Proposição 5.4 fornece

$$U = \sum_{j=1}^p \lambda_j.$$

O critério utiliza diretamente a soma das razões hipótese/erro. Como

$$\lambda_j \geq 0,$$

tem-se

$$U \geq 0,$$

com igualdade se, e somente se, $\mathbf{H} = \mathbf{0}$.

Definição 18.5 (Maior raiz característica de Roy). A **maior raiz característica de Roy** é

$$\lambda_1. \quad (18.25)$$

Pela Equação 18.13,

$$\lambda_1 = \max_{\mathbf{a} \neq \mathbf{0}} \frac{\mathbf{a}^\top \mathbf{H} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}}. \quad (18.26)$$

A maior raiz característica de Roy depende exclusivamente da direção que maximiza a razão entre a SQPC da hipótese e a SQPC residual. Valores maiores de λ_1 correspondem a maior separação entre hipótese e erro nessa direção (Hair et al., 2009).

18.6 Quatro critérios como funções das raízes características

Os quatro critérios dependem das raízes características

$$\lambda_1, \dots, \lambda_p$$

do problema

$$\mathbf{H} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}.$$

Uma raiz nula contribui com o fator 1 para a lambda de Wilks e com o termo 0 para o critério de Pillai e para o traço de Hotelling. Portanto, as raízes

$$\lambda_{r_H+1}, \dots, \lambda_p$$

não alteram os valores desses critérios. A maior raiz característica de Roy depende apenas de λ_1 .

A Tabela 18.3 compara as operações aplicadas às raízes.

Tabela 18.3: Critérios clássicos da MANOVA como funções das mesmas raízes características.

Critério	Expressão em função das raízes	Operação sobre as raízes	Evidência crescente contra H_0
Lambda de Wilks	$\prod_{j=1}^p (1 + \lambda_j)^{-1}$	produto	valores menores
Critério de Pillai	$\sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}$	soma dos termos transformados	valores maiores
Traço de Hotelling	$\sum_{j=1}^p \lambda_j$	soma das raízes	valores maiores
Maior raiz característica de Roy	λ_1	maior raiz	valores maiores

A maior raiz característica de Roy utiliza apenas λ_1 . O traço de Hotelling soma as raízes, o critério de Pillai soma os termos $\lambda_j/(1 + \lambda_j)$ e a lambda de Wilks multiplica os fatores $(1 + \lambda_j)^{-1}$.

Quando existe apenas uma raiz positiva, os quatro critérios são funções monotônicas dessa raiz. Com duas ou mais raízes positivas, as funções que definem os quatro critérios não são, em geral, transformações monotônicas entre si.

18.6.1 Uso inferencial dos critérios

Os valores observados da lambda de Wilks, do critério de Pillai, do traço de Hotelling e da maior raiz característica de Roy são funções de $\mathbf{H}$ e $\mathbf{E}$. Sua utilização como estatísticas de teste requer a distribuição de referência sob

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0.$$

Sob o modelo normal multivariado clássico, essa distribuição depende do número de respostas p , dos graus de liberdade da hipótese

$$\nu_H = g,$$

e dos graus de liberdade residuais ν_E .

Em configurações particulares, transformações dos critérios possuem distribuição F exata. Quando existem várias raízes positivas, são utilizadas distribuições, transformações ou aproximações específicas para cada critério, determinadas por p , g e ν_E (Anderson, 2003; Johnson; Wichern, 2002).

Fixado um nível de significância α , rejeita-se H_0 quando o valor p obtido pela distribuição de referência é menor ou igual a α . Valores menores de Λ_W e valores maiores de V , U e λ_1 correspondem a maior evidência contra H_0 .

Sob normalidade, a calibração decorre da distribuição conjunta de $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ estabelecida na Seção 18.9.1. Os casos exatos e as aproximações utilizadas para os critérios são especificados na Seção 18.9.2.

18.7 Pressupostos e limites

A formulação da MANOVA especifica a média das respostas, a comparação entre hipótese e erro e, para a inferência clássica, a distribuição dos erros. A estimabilidade determina quais hipóteses podem ser formuladas, enquanto independência entre unidades, covariância residual comum, não singularidade e normalidade multivariada sustentam a calibração inferencial clássica.

18.7.1 Estrutura da média e estimabilidade

O modelo pressupõe

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{Z}\mathbf{B}.$$

Grupos, tratamentos, covariáveis e demais efeitos incluídos no modelo são representados por colunas de $\mathbf{Z}$. Essa especificação determina o espaço de médias e os resíduos do modelo; a hipótese é definida por funções estimáveis de $\mathbf{B}$.

Para

$$H_0 : \mathbf{C}_1\mathbf{B} = \Theta_0,$$

a função $\mathbf{C}_1\mathbf{B}$ deve ser estimável. Pela Equação 18.5,

$$\mathbf{C}_1 = \mathbf{C}_1\mathbf{Z}^+\mathbf{Z}.$$

Essa condição garante que $\mathbf{C}_1\mathbf{B}$ seja determinada pela média $\mathbf{Z}\mathbf{B}$, mesmo quando diferentes parametrizações de $\mathbf{B}$ produzem a mesma média. A estimabilidade não depende da normalidade multivariada.

18.7.2 Independência entre unidades

Na formulação probabilística clássica, os vetores de erros associados a unidades observacionais distintas são independentes:

$$\mathbf{e}_1, \dots, \mathbf{e}_n.$$

A dependência entre as respostas de uma mesma unidade é descrita por Σ . Quando várias medidas da mesma unidade compõem um único vetor resposta, suas covariâncias integram essa matriz. Se unidades distintas também apresentam dependência temporal, espacial ou decorrente de agrupamentos, a hipótese de independência entre os vetores de erros deixa de valer. Nesse caso, o modelo deve especificar também as covariâncias entre erros de unidades distintas.

18.7.3 Covariância residual comum

O modelo clássico utiliza

$$\text{Cov}(\mathbf{e}_i | \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n.$$

Na comparação entre grupos, a mesma matriz Σ descreve a covariância residual populacional em todos os grupos. A matriz $\mathbf{E}$ é a SQPC residual observada do modelo.

Se as matrizes de covariâncias residuais diferem entre grupos, os quatro critérios ainda podem ser calculados quando as operações matriciais necessárias estão definidas, mas suas distribuições de referência clássicas não decorrem do modelo normal com covariância comum.

18.7.4 Não singularidade populacional e amostral

A formulação clássica considera

$$\Sigma \succ \mathbf{0}.$$

Pela Proposição 8.3, $\Sigma \succ \mathbf{0}$ implica que nenhuma combinação linear não nula das respostas residuais possui variância igual a zero.

A forma simétrica

$$\mathbf{M}_{\text{HE}} = \mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}$$

exige

$$\mathbf{E} \succ \mathbf{0}.$$

Com ν_E denotando os graus de liberdade residuais definidos na Definição 11.12,

$$\text{posto}(\mathbf{E}) \leq \min(p, \nu_E).$$

a condição

$$\mathbf{E} \succ \mathbf{0}$$

exige

$$\nu_E \geq p.$$

Essa condição é necessária, mas não suficiente para dados arbitrários: relações lineares exatas entre as respostas residuais podem reduzir o posto de $\mathbf{E}$ mesmo quando $\nu_E \geq p$.

Sob o modelo normal clássico, com $\Sigma \succ \mathbf{0}$, pela Equação 12.43,

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

com probabilidade 1 se, e somente se, $\nu_E \geq p$. A matriz observada $\mathbf{E}$ é uma realização de $\mathbf{E}_{\text{res}}$.

Quando $\mathbf{E}$ é singular, sua raiz quadrada $\mathbf{E}^{1/2}$ existe, mas também é singular. Portanto,

$$\mathbf{E}^{-1} \quad \text{e} \quad \mathbf{E}^{-1/2}$$

não existem como inversas ordinárias. A formulação espectral baseada em $\mathbf{E}^{-1/2}$ não está definida nesse caso.

18.7.5 Normalidade multivariada

A normalidade não é necessária para construir as SQPCs $\mathbf{H}$ e $\mathbf{E}$. Sob

$$\mathbf{E} \succ \mathbf{0},$$

as raízes características e os quatro critérios são definidos algebricamente sem exigir uma distribuição normal para os erros.

Sob o modelo linear normal multivariado definido na Definição 11.7, os erros são normais multivariados, independentes entre unidades e possuem matriz de covariâncias comum. Sob H_0 , essas condições implicam distribuições Wishart centrais para $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ e independência entre essas matrizes.

A hipótese de normalidade refere-se aos vetores de erros do modelo, condicionada à matriz de delineamento $\mathbf{Z}$. Ela não exige que a distribuição marginal obtida ao reunir respostas de unidades com diferentes médias condicionais seja uma única normal multivariada.

Na comparação entre grupos, uma formulação condicional com médias específicas por grupo é

$$\mathbf{Y}_i \mid G_i = k \sim N_p(\mu_k, \Sigma),$$

com vetores de médias distintos entre os grupos. A distribuição marginal resultante da mistura desses grupos não precisa pertencer à família normal multivariada, mesmo quando o modelo normal condicional está corretamente especificado.

Um diagnóstico aplicado às respostas agrupadas sem ajustar suas médias condicionais pode refletir diferenças entre grupos ou outros efeitos incluídos no modelo, e não falta de normalidade dos erros. O pressuposto de normalidade deve ser examinado nos resíduos obtidos após o ajuste da média

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

Para $p = 1$, os quatro critérios são funções monotônicas da única raiz

$$\lambda = \frac{H}{E}.$$

Como

$$F = \frac{\nu_E}{\nu_H} \lambda,$$

os quatro critérios produzem a mesma ordenação das amostras em relação à evidência contra H_0 e, quando calibrados em suas respectivas escalas, conduzem ao mesmo teste. Para $p > 1$, H e E são substituídos pelas SQPCs $\mathbf{H}$ e $\mathbf{E}$.

18.7.6 Associação residual, condicionamento e singularidade

Associação residual entre as respostas não invalida, por si só, a MANOVA. A dependência entre as componentes de um mesmo vetor de erros é representada por Σ e, nos dados observados, pelos produtos cruzados reunidos em $\mathbf{E}$. A MANOVA incorpora essa associação na comparação conjunta das respostas.

Relações lineares entre as respostas residuais muito próximas de uma dependência exata podem produzir uma matriz $\mathbf{E}$ mal condicionada, conforme a noção de condicionamento da Definição 6.9. Nesse caso, $\mathbf{E}$ permanece invertível, mas pequenas perturbações nos dados podem produzir alterações relativamente grandes em sua inversa, nas raízes e nas direções características. Invertibilidade, portanto, não garante estabilidade numérica.

Uma relação linear residual exata reduz o posto de $\mathbf{E}$ e pode torná-la singular, conforme a Seção 18.7.4. Se $\mathbf{E}$ é singular, $\mathbf{E}^{-1/2}$ não existe como inversa ordinária e a matriz $\mathbf{M}_{\mathbf{H}\mathbf{E}}$ não está definida pela Equação 18.19.

18.8 Relações com outras técnicas

A ANOVA e o T^2 de Hotelling surgem como casos particulares da formulação da MANOVA. A regressão multivariada utiliza o mesmo modelo linear multivariado e, na comparação entre grupos, o problema espectral relaciona-se à formulação de Fisher da Análise Discriminante.

18.8.1 ANOVA

Quando existe uma única resposta,

$$p = 1,$$

as matrizes de hipótese e erro reduzem-se a escalares,

$$\mathbf{H} = (H), \quad \mathbf{E} = (E),$$

e existe no máximo uma raiz característica,

$$\lambda = \frac{H}{E}.$$

Se ν_H e ν_E são os graus de liberdade da hipótese e do erro, respectivamente, então

$$F = \frac{H/\nu_H}{E/\nu_E} = \frac{\nu_E}{\nu_H} \lambda. \quad (18.27)$$

Para $p = 1$, os quatro critérios são transformações monotônicas da única raiz $\lambda = H/E$. Como

$$F = \frac{\nu_E}{\nu_H} \lambda,$$

esses critérios não acrescentam informação além da razão entre as somas de quadrados da hipótese e do erro. Para $p > 1$, os escalares H e E são substituídos pelas SQPCs $\mathbf{H}$ e $\mathbf{E}$.

18.8.2 T^2 de Hotelling

Na comparação clássica de duas populações,

$$K = 2,$$

há apenas um contraste independente e, portanto,

$$g = 1.$$

Existe no máximo uma raiz característica positiva.

Para duas amostras independentes de tamanhos n_1 e n_2 , com matriz de covariâncias comum e hipótese de igualdade dos vetores de médias, a relação com a estatística definida na Definição 12.6 é

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}. \quad (18.28)$$

Pela Equação 18.28,

$$T^2 = (n_1 + n_2 - 2) \lambda_1.$$

Com dois grupos,

$$g = 1$$

e

$$\text{posto}(\mathbf{H}) \leq 1.$$

Existe, portanto, no máximo uma raiz característica positiva. Quando $\lambda_1 > 0$, os quatro critérios dependem exclusivamente dessa raiz.

18.8.3 Regressão multivariada

MANOVA e regressão multivariada utilizam o mesmo modelo

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}.$$

Na MANOVA de grupos ou fatores, colunas de $\mathbf{Z}$ representam indicadores, contrastes e outros termos do delineamento. Na regressão multivariada, $\mathbf{Z}$ pode incluir preditores quantitativos contínuos. Em ambas as formulações, hipóteses estimáveis sobre

$$\mathbf{C}_1\mathbf{B}$$

são avaliadas pelas mesmas SQPCs de hipótese e erro.

18.8.4 Análise Discriminante

Na MANOVA de um fator que compara os vetores de médias dos mesmos K grupos utilizados na formulação de Fisher,

$$\mathbf{H} = \mathbf{T}_{\text{entre}} \quad \text{e} \quad \mathbf{E} = \mathbf{T}_{\text{intra}}.$$

Consequentemente, o problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

coincide com

$$\mathbf{T}_{\text{entre}}\alpha = \lambda\mathbf{T}_{\text{intra}}\alpha,$$

definido na Seção 19.6.

Na MANOVA, as raízes características são utilizadas pela lambda de Wilks, pelo critério de Pillai, pelo traço de Hotelling e pela maior raiz característica de Roy. Na formulação de Fisher, os autovetores associados às raízes positivas definem direções que maximizam a razão entre dispersão entre grupos e dispersão intragrupos.

A coincidência do problema de autovalores generalizados não torna as técnicas equivalentes. Na MANOVA, os grupos são termos do modelo e o objetivo é testar hipóteses sobre os vetores de médias ou sobre funções estimáveis dos parâmetros. Na formulação de Fisher, os rótulos dos grupos são conhecidos e utilizados para construir as matrizes de dispersão entre e dentro dos grupos. A construção de uma regra de classificação requer uma formulação adicional.

18.9 Aprofundamentos teóricos

Leitura de aprofundamento

Sob normalidade e H_0 , as SQPCs de hipótese e erro possuem distribuições Wishart independentes. Essa formulação probabilística fundamenta as distribuições de referência dos critérios. A razão de verossimilhanças conduz à lambda de Wilks, enquanto a invariância e a forma canônica caracterizam o papel das raízes e das direções características.

18.9.1 Distribuições Wishart de hipótese e erro sob H_0

Sob o modelo linear normal multivariado definido na Definição 11.7,

$$\Sigma \succ \mathbf{0},$$

os vetores de erros de unidades distintas são independentes e possuem a mesma matriz de covariâncias Σ .

Para uma hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

com

$$\text{posto}(\mathbf{C}_1) = g,$$

os graus de liberdade residuais, definidos na Definição 11.12, são

$$\nu_E = n - \text{posto}(\mathbf{Z}) .$$

Denote por

$$\mathbf{H}$$

a SQPC aleatória da hipótese e por

$$\mathbf{E}_{\text{res}}$$

a SQPC residual aleatória. Pela Proposição 12.12, aplicada às respostas originais, sob H_0 ,

$$\mathbf{H} \mid \mathbf{Z} \sim W_p(g, \Sigma) , \quad (18.29)$$

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(\nu_E, \Sigma) , \quad (18.30)$$

e

$$\mathbf{H} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z} . \quad (18.31)$$

A distribuição residual da Equação 18.30 corresponde à Proposição 12.10; a Equação 18.29 especializa a distribuição da SQPC da hipótese para as respostas originais.

Sob H_0 , $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ são matrizes Wishart independentes com a mesma matriz de escala Σ e graus de liberdade g e ν_E , respectivamente. As distribuições sob H_0 dos critérios clássicos decorrem dessa distribuição conjunta.

Se as matrizes de covariâncias populacionais diferem entre os grupos, $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ não possuem, em geral, a representação da Equação 18.29, da Equação 18.30 e da Equação 18.31 com uma matriz de escala comum Σ . A calibração clássica dos critérios baseada nessa representação deixa, portanto, de decorrer do modelo normal com covariância comum.

18.9.1.1 Lambda de Wilks e razão de verossimilhanças

Para a hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

denote por $\mathbf{E}_R$ a SQPC residual do ajuste sujeito a H_0 e por $\mathbf{E}$ a SQPC residual do ajuste irrestrito. A SQPC da hipótese corresponde ao aumento da SQPC residual imposto pela restrição, de modo que

$$\mathbf{E}_R = \mathbf{E} + \mathbf{H}.$$

Quando H_0 é obtida pela comparação entre modelos lineares encaixados, essa decomposição coincide com a Proposição 11.13.

No modelo normal multivariado, a maximização da verossimilhança sob o modelo irrestrito e sob H_0 produz

$$\Lambda_{RV} = \left[\frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} \right]^{n/2} = \Lambda_W^{n/2}. \quad (18.32)$$

Assim, rejeitar H_0 para valores pequenos da razão de verossimilhanças equivale a rejeitá-la para valores pequenos da lambda de Wilks (Anderson, 2003; Johnson; Wichern, 2002).

A Equação 18.22 reúne as duas formas da mesma estatística. A razão $|\mathbf{E}|/|\mathbf{E} + \mathbf{H}|$ compara as SQPCs residuais dos modelos completo e reduzido, enquanto o produto $\prod_{j=1}^p (1 + \lambda_j)^{-1}$ expressa a lambda de Wilks em função das raízes características (Wilks, 1932).

Sob o modelo normal, o critério de Pillai, o traço de Hotelling e a maior raiz característica de Roy também são funções do par aleatório $(\mathbf{H}, \mathbf{E}_{\text{res}})$. Esses três critérios não correspondem, em geral, ao critério da razão de verossimilhanças para a hipótese linear.

As matrizes observadas $\mathbf{H}$ e $\mathbf{E}$, suas raízes características e os quatro critérios são definidos algebricamente. Sob o modelo normal, a distribuição conjunta de $\mathbf{H}$ e $\mathbf{E}_{\text{res}}$ determina as distribuições de referência dos critérios sob H_0 .

18.9.2 Calibração inferencial dos critérios

Pela Equação 18.29, pela Equação 18.30 e pela Equação 18.31, as distribuições de referência dos critérios sob H_0 são determinadas por

$$p, \quad g \quad \text{e} \quad \nu_E,$$

em que p é o número de respostas, $g = \text{posto}(\mathbf{C}_1)$ e ν_E é o número de graus de liberdade residuais.

Algumas configurações admitem distribuições F exatas. Se existe uma única resposta,

$$p = 1,$$

então há no máximo uma raiz positiva e, sob H_0 ,

$$\frac{\nu_E}{g} \lambda_1 \sim F_{g, \nu_E}. \quad (18.33)$$

Se a hipótese possui um grau de liberdade,

$$g = 1,$$

e $\nu_E \geq p$, então

$$\frac{\nu_E - p + 1}{p} \lambda_1 \sim F_{p, \nu_E - p + 1}. \quad (18.34)$$

Nessas duas situações, os quatro critérios são funções monotônicas da única raiz e conduzem ao mesmo teste global.

Para $p > 1$ e $g > 1$, a distribuição da lambda de Wilks não se reduz, em geral, às distribuições F exatas anteriores. Mantendo p e g fixos, uma aproximação assintótica de Bartlett, quando ν_E cresce, é

$$-\left(\nu_E - \frac{p - g + 1}{2}\right) \log \Lambda_W \sim \chi_{pg}^2. \quad (18.35)$$

A aproximação é utilizada sob H_0 (Anderson, 2003; Johnson; Wichern, 2002). O critério de Pillai, o traço de Hotelling e a maior raiz característica de Roy possuem calibrações próprias, determinadas pelas respectivas distribuições de referência.

Quando uma amostra apresenta $r_H \leq 1$, os valores observados dos quatro critérios dependem de, no máximo, uma raiz positiva. Se $\lambda_1 > 0$,

$$\Lambda_W = \frac{1}{1 + \lambda_1}, \quad V = \frac{\lambda_1}{1 + \lambda_1}, \quad U = \lambda_1,$$

e a maior raiz característica de Roy é λ_1 .

Se $p = 1$ ou $g = 1$, a Equação 18.15 garante $r_H \leq 1$ para qualquer amostra. Nessas duas configurações, os quatro critérios são funções estritamente monotônicas da mesma raiz e conduzem a regiões de rejeição equivalentes quando cada critério é calibrado em sua escala correspondente.

Uma redução adicional de posto que produza $r_H \leq 1$ apenas na amostra observada estabelece as identidades algébricas acima para essa amostra, mas não implica, por si só, equivalência entre as distribuições de referência dos quatro critérios.

Quando existem duas ou mais raízes positivas, as distribuições de referência dos quatro critérios não são obtidas pela mesma transformação. As estatísticas transformadas e seus graus de liberdade dependem do critério, de p , de g e de ν_E (Anderson, 2003).

As distribuições de referência anteriores pressupõem normalidade multivariada dos erros, independência entre unidades, matriz de covariâncias residual comum e $\mathbf{E} \succ \mathbf{0}$. A violação dessas condições retira a justificativa, pelo modelo clássico, dos valores críticos e valores p obtidos com essas distribuições ou aproximações. Se $\mathbf{E}$ é singular, também deixam de estar definidas as formulações dos critérios que exigem sua inversa ou seu determinante não nulo.

18.9.3 Invariância a transformações lineares não singulares das respostas

Considere uma transformação linear não singular das respostas,

$$\mathbf{y}^* = \mathbf{y}\mathbf{A}, \tag{18.36}$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}, \quad \det(\mathbf{A}) \neq 0.$$

No sistema transformado,

$$\mathbf{B}^* = \mathbf{B}\mathbf{A}, \quad \mathcal{E}^* = \mathcal{E}\mathbf{A}.$$

Para representar a mesma hipótese, utiliza-se

$$\Theta_0^* = \Theta_0 \mathbf{A}.$$

As matrizes de hipótese e erro transformam-se por congruência:

$$\mathbf{H}^* = \mathbf{A}^\top \mathbf{H} \mathbf{A} \quad (18.37)$$

e

$$\mathbf{E}^* = \mathbf{A}^\top \mathbf{E} \mathbf{A}. \quad (18.38)$$

Proposição 18.1 (Invariância das raízes características). *Se $\mathbf{A}$ é não singular, os pares*

$$(\mathbf{H}, \mathbf{E})$$

e

$$(\mathbf{H}^*, \mathbf{E}^*)$$

possuem as mesmas raízes características, incluindo suas multiplicidades.

Comprovação. Tem-se

$$\begin{aligned} \det(\mathbf{H}^* - \lambda \mathbf{E}^*) &= \det[\mathbf{A}^\top (\mathbf{H} - \lambda \mathbf{E}) \mathbf{A}] \\ &= \det(\mathbf{A})^2 \det(\mathbf{H} - \lambda \mathbf{E}). \end{aligned}$$

Como

$$\det(\mathbf{A}) \neq 0,$$

as duas equações características possuem os mesmos zeros, com as mesmas multiplicidades. $\square$

Para o par observado $(\mathbf{H}, \mathbf{E})$, a decomposição espectral da matriz padronizada $\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2}$ determina uma forma canônica. Se

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} = \mathbf{Q} \operatorname{diag}(\lambda_1, \dots, \lambda_p) \mathbf{Q}^\top,$$

com $\mathbf{Q}$ ortogonal, então a transformação das respostas definida por

$$\mathbf{A} = \mathbf{E}^{-1/2} \mathbf{Q}$$

produz

$$\mathbf{E}^* = \mathbf{I}_p$$

e

$$\mathbf{H}^* = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Assim, para o par observado $(\mathbf{H}, \mathbf{E})$, a transformação definida por $\mathbf{A} = \mathbf{E}^{-1/2} \mathbf{Q}$ reduz a SQPC residual à identidade e a SQPC da hipótese à matriz diagonal das raízes características (Anderson, 2003; Eaton, 2007).

Consequentemente, a lambda de Wilks, o critério de Pillai, o traço de Hotelling e a maior raiz característica de Roy são invariantes a transformações lineares não singulares das respostas.

Se α_j é uma direção característica normalizada no sistema original, a direção correspondente no sistema transformado é

$$\alpha_j^* = \mathbf{A}^{-1} \alpha_j.$$

Essa transformação preserva a normalização,

$$(\alpha_j^*)^\top \mathbf{E}^* \alpha_j^* = \alpha_j^\top \mathbf{E} \alpha_j,$$

e a combinação linear das respostas,

$$\mathcal{Y}^* \alpha_j^* = \mathcal{Y} \alpha_j.$$

As raízes e os quatro critérios não dependem da escolha de um sistema invertível de coordenadas para as respostas. Os coeficientes das direções características, entretanto, são expressos nas coordenadas do sistema utilizado.

18.9.4 Posto, sinais e multiplicidades das direções

O número de raízes positivas é

$$r_H = \text{posto}(\mathbf{H}) \leq \min(p, g),$$

pela Equação 18.15.

O número de raízes positivas não é determinado apenas pelo número p de respostas. Como $r_H \leq g$, uma hipótese com poucas restrições lineares independentes pode produzir poucas raízes positivas mesmo quando p é elevado.

Como $\mathbf{H}$ é simétrica e $\mathbf{E} \succ \mathbf{0}$, aplica-se ao par $(\mathbf{H}, \mathbf{E})$ a ortogonalidade dos autovetores generalizados estabelecida na Proposição 5.8. As direções características podem ser escolhidas ortonormais no produto interno induzido por $\mathbf{E}$.

Para uma raiz simples, qualquer múltiplo escalar não nulo de um autovetor generalizado representa a mesma direção característica. Com a normalização

$$\alpha_j^\top \mathbf{E} \alpha_j = 1,$$

restam duas representações normalizadas da mesma direção:

$$\alpha_j \quad \text{e} \quad -\alpha_j.$$

Quando uma raiz λ possui multiplicidade $m > 1$, seja

$$\mathbf{A}_\lambda = [\alpha_1 \quad \cdots \quad \alpha_m]$$

uma matriz cujas colunas formam uma base $\mathbf{E}$ -ortonormal do subespaço característico correspondente, de modo que

$$\mathbf{A}_\lambda^\top \mathbf{E} \mathbf{A}_\lambda = \mathbf{I}_m.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

a matriz

$$\mathbf{A}_\lambda^* = \mathbf{A}_\lambda \mathbf{R}$$

fornece outra base **E**-ortonormal do mesmo subespaço. Portanto, uma raiz de multiplicidade $m > 1$ determina o subespaço característico, mas não uma base **E**-ortonormal única dentro dele.

A escolha de outra base **E**-ortonormal para esse subespaço não altera a λ de Wilks, o critério de Pillai, o traço de Hotelling ou a maior raiz característica de Roy, pois os quatro critérios dependem apenas das raízes características.

18.10 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata das decisões de condução, interpretação e avaliação da MANOVA: tamanho das células, homogeneidade das matrizes de covariâncias, escolha do critério multivariado, análise posterior ao teste global, MANOVA fatorial, MANCOVA e validação dos resultados.

18.10.1 Tamanho das células e balanceamento

Na MANOVA com fatores categóricos, o tamanho amostral deve ser examinado em cada célula do delineamento. Células menores produzem estimativas menos precisas das médias e das covariâncias e reduzem o poder para detectar diferenças entre os vetores de médias (Hair et al., 2009).

Uma matriz de covariâncias amostral calculada separadamente na célula k pode ter posto completo somente se

$$n_k - 1 \geq p,$$

além da ausência de dependências lineares exatas entre as respostas. Essa condição é necessária para procedimentos que utilizam as matrizes de covariâncias de cada grupo separadamente, como o teste M de Box. A MANOVA baseada na SQPC residual conjunta exige $\mathbf{E} \succ \mathbf{0}$, conforme a Seção 18.7.4, mas não exige posto completo de cada matriz de covariâncias amostral de grupo.

Tamanhos desiguais entre células são admitidos pelo modelo linear. Quando as matrizes de covariâncias populacionais diferem entre os grupos, células com tamanhos muito distintos aumentam a sensibilidade dos testes multivariados à violação da hipótese de covariância comum (Hair et al., 2009).

Células com tamanhos semelhantes reduzem a sensibilidade dos testes à heterogeneidade das matrizes de covariâncias.

18.10.2 Avaliação da homogeneidade das matrizes de covariâncias

Na comparação entre K grupos, a MANOVA clássica assume

$$\Sigma_1 = \Sigma_2 = \dots = \Sigma_K.$$

O teste M de Box avalia

$$H_0 : \Sigma_1 = \dots = \Sigma_K.$$

Sua estatística utiliza os determinantes das matrizes de covariâncias amostrais dos grupos e da matriz de covariâncias combinada. O cálculo exige matrizes amostrais não singulares. A rejeição de H_0 fornece evidência contra a hipótese de covariância comum; a não rejeição não demonstra igualdade das matrizes populacionais.

O teste M de Box é sensível a desvios da normalidade multivariada. Hair recomenda, por essa razão, níveis de significância como 0,01 ou menores (Hair et al., 2009). A rejeição do teste deve ser interpretada juntamente com a avaliação da normalidade, pois desvios da normalidade podem aumentar a frequência de rejeição da hipótese de covariância comum.

Em modelos com covariáveis, a hipótese de homogeneidade refere-se às matrizes de covariâncias dos erros condicionais ao modelo ajustado. O teste calculado com as respostas brutas agrupadas pelos fatores compara matrizes não ajustadas e não testa diretamente a igualdade das covariâncias residuais da MANCOVA.

18.10.3 Observações atípicas e influência

Uma observação atípica apresenta valores incomuns em uma ou mais respostas ou em uma combinação dessas respostas. Como as médias podem variar entre os níveis do delineamento, a avaliação deve considerar os resíduos do modelo,

$$\hat{e}_i = y_i - \hat{\mu}_i,$$

em que $\hat{\mu}_i$ é o vetor de médias ajustadas para a unidade i . Valores residuais extremos em uma resposta ou combinações residuais incomuns entre várias respostas identificam unidades que devem ser examinadas (Hair et al., 2009; Johnson; Wichern, 2002).

Uma observação é influente quando sua presença altera de forma apreciável os vetores de médias ajustadas, $\mathbf{H}$, $\mathbf{E}$, as raízes características ou os critérios multivariados. A comparação da análise com e sem a observação quantifica essa influência, mas não justifica sua exclusão.

A exclusão requer evidência independente de erro de registro, erro de mensuração ou inadequação da unidade à população definida para o estudo. Uma observação extrema e válida deve ser mantida quando pertence à população analisada (Hair et al., 2009).

18.10.4 Escolha e interpretação do critério multivariado

Os quatro critérios são funções das mesmas raízes características. A escolha do critério deve considerar os tamanhos das células, a plausibilidade dos pressupostos e o número de raízes que caracterizam o efeito, e não o menor valor p observado.

Quando os tamanhos das células são semelhantes e os pressupostos de normalidade e covariância comum são plausíveis, Hair recomenda o critério de Pillai ou a lambda de Wilks (Hair et al., 2009). Quando há células com tamanhos distintos ou evidência contra a hipótese de covariância comum, Hair recomenda o critério de Pillai por sua maior robustez nessas condições (Hair et al., 2009). Johnson e Wichern também relatam maior robustez de Pillai diante de desvios da normalidade (Johnson; Wichern, 2002).

A maior raiz característica de Roy utiliza apenas λ_1 e é indicada por Hair quando uma única dimensão domina o efeito e os pressupostos do modelo são plausíveis (Hair et al., 2009). O traço de Hotelling, o critério de Pillai e a lambda de Wilks incorporam todas as raízes positivas.

Resultados diferentes entre os quatro critérios decorrem das funções distintas aplicadas às mesmas raízes e não constituem evidências independentes. O relatório deve identificar o critério utilizado, seu valor observado, a estatística F quando houver transformação correspondente, os graus de liberdade e o valor p .

18.10.5 Avaliação das respostas após o teste global

A rejeição da hipótese multivariada fornece evidência de que a hipótese testada não se sustenta para o vetor de respostas. Essa rejeição não identifica quais respostas apresentam efeitos marginais. Os testes univariados podem ser utilizados para examinar separadamente cada componente do vetor resposta (Hair et al., 2009).

Para a resposta j , os elementos diagonais

$$H_{jj} \quad \text{e} \quad E_{jj}$$

são as somas de quadrados da hipótese e do erro correspondentes a essa resposta. A estatística univariada é

$$F_j = \frac{H_{jj}/\nu_H}{E_{jj}/\nu_E}. \quad (18.39)$$

Sob o modelo normal clássico e sob a hipótese nula marginal,

$$F_j \sim F_{\nu_H, \nu_E}.$$

O teste baseado em F_j utiliza somente H_{jj} e E_{jj} . Os critérios multivariados utilizam as matrizes completas $\mathbf{H}$ e $\mathbf{E}$ e, portanto, incorporam também os produtos cruzados entre as respostas. Um teste univariado não constitui uma decomposição do teste MANOVA.

Quando as p respostas são examinadas separadamente, as hipóteses marginais formam uma família de testes. A rejeição prévia da hipótese multivariada não controla a probabilidade de pelo menos uma rejeição incorreta nessa família. O ajuste de Bonferroni controla o erro familiar em nível α utilizando

$$\frac{\alpha}{p}$$

como nível de significância para cada uma das p hipóteses marginais. Outros procedimentos de multiplicidade podem ser utilizados de acordo com a família de hipóteses que será interpretada.

A rejeição da hipótese multivariada não exige que todas as hipóteses marginais sejam rejeitadas. A diferença entre grupos pode estar concentrada em algumas respostas ou em uma combinação linear das respostas (Hair et al., 2009; Johnson; Wichern, 2002).

Intervalos de confiança simultâneos podem ser construídos para componentes ou contrastes previamente especificados dos vetores de médias. Esses intervalos quantificam as diferenças estimadas e controlam conjuntamente o nível de confiança da família de afirmações considerada (Johnson; Wichern, 2002).

18.10.6 Contrastes e comparações posteriores

A rejeição da hipótese multivariada não identifica quais níveis do fator diferem. Quando o fator possui três ou mais níveis, contrastes e comparações posteriores podem localizar essas diferenças.

Um contraste planejado entre K médias de grupos pode ser escrito como

$$L = c_1\mu_1 + \cdots + c_K\mu_K,$$

com

$$\sum_{k=1}^K c_k = 0.$$

Os coeficientes $c_1, \dots, c_K$ definem a comparação entre os grupos. No modelo linear multivariado, contrastes estimáveis são incorporados à matriz $\mathbf{C}_1$ da hipótese linear definida na Definição 11.17.

Contrastes planejados devem ser especificados a partir da pergunta de pesquisa antes da inspeção das diferenças amostrais. Como o número de comparações planejadas costuma ser menor, eles podem apresentar maior poder para as comparações previamente definidas (Hair et al., 2009).

Quando as comparações são escolhidas depois do exame das médias, elas pertencem a uma análise *post hoc*. O procedimento de multiplicidade deve considerar o conjunto de comparações efetivamente realizado. A realização de várias comparações sem ajuste aumenta a probabilidade de pelo menos uma rejeição incorreta (Hair et al., 2009).

Testes por resposta e contrastes entre níveis avaliam hipóteses diferentes. O teste baseado em F_j examina o efeito sobre uma resposta específica, enquanto um contraste compara níveis ou combinações de níveis do fator.

Em uma análise *stepdown*, cada resposta é testada condicionalmente às respostas que a precedem. A ordem das respostas altera as hipóteses condicionais avaliadas e deve ser definida antes da análise com base no problema de pesquisa (Hair et al., 2009).

Na MANOVA de um fator, as direções associadas às raízes características definem combinações lineares das respostas ordenadas pela razão entre a dispersão entre grupos e a dispersão intragrupos. A relação entre essas direções e as funções discriminantes de Fisher é estabelecida na Seção 18.8.4.

18.10.7 MANOVA fatorial e MANCOVA

No modelo linear multivariado, fatores, interações e covariáveis determinam os termos da matriz de delineamento $\mathbf{Z}$. Cada hipótese linear estimável determina sua SQPC $\mathbf{H}$, enquanto a SQPC residual $\mathbf{E}$ é obtida do modelo ajustado.

18.10.7.1 MANOVA fatorial

Em um delineamento com dois ou mais fatores, cada efeito principal e cada interação correspondem a uma hipótese linear distinta. Para cada hipótese constrói-se uma SQPC $\mathbf{H}$, enquanto a SQPC residual $\mathbf{E}$ é obtida do mesmo modelo ajustado.

A interação deve ser examinada antes da interpretação dos efeitos principais. Quando existe interação, a diferença associada a um fator depende do nível do outro fator. O efeito principal resume diferenças marginais e pode ocultar o padrão observado nas combinações específicas de níveis (Hair et al., 2009; Johnson; Wichern, 2002).

Na inspeção de uma resposta específica, Hair distingue interações ordinais e desordinais. Em uma interação ordinal, a ordenação das médias entre os níveis de um fator permanece a mesma nos níveis do outro fator, embora as diferenças possam mudar de magnitude. Em uma interação desordinal, essa ordenação se inverte em pelo menos parte dos níveis examinados (Hair et al., 2009). Essa classificação descreve o perfil da resposta considerada e não substitui o teste multivariado da interação.

A rejeição da hipótese de ausência de interação não identifica quais combinações de níveis diferem. As médias das células, os efeitos simples e os contrastes entre combinações de níveis podem ser utilizados para localizar essas diferenças.

18.10.7.2 MANCOVA

Na MANCOVA, covariáveis quantitativas são incluídas na matriz de delineamento $\mathbf{Z}$. As hipóteses sobre os fatores comparam vetores de médias das respostas condicionais aos valores das covariáveis.

Para uma covariável escalar c e um fator com K níveis, o modelo aditivo pode ser escrito como

$$E(\mathbf{Y} \mid \mathbf{G} = k, c) = \mu_k + \gamma c, \quad k = 1, \dots, K,$$

em que $\gamma \in \mathbb{R}^p$ contém os coeficientes associados à covariável. A mesma inclinação γ em todos os grupos expressa a **homogeneidade dos coeficientes de regressão** exigida pelo modelo aditivo de MANCOVA (Hair et al., 2009).

Se os coeficientes associados à covariável diferem entre os grupos, o modelo pode ser escrito com coeficientes específicos,

$$E(\mathbf{Y} \mid \mathbf{G} = k, c) = \mu_k + \gamma_k c.$$

A diferença entre os grupos k e ℓ nesse caso é

$$(\mu_k - \mu_\ell) + (\gamma_k - \gamma_\ell) c.$$

Portanto, quando

$$\gamma_k \neq \gamma_\ell,$$

a diferença entre os vetores de médias depende do valor da covariável. No modelo linear, essa situação corresponde a uma interação fator-covariável.

Uma covariável associada às respostas pode reduzir a SQPC residual depois do ajuste e aumentar a precisão das comparações entre os níveis dos fatores. Hair recomenda selecionar covariáveis relacionadas às respostas e evitar covariáveis fortemente associadas aos fatores quando o objetivo é aumentar a precisão dos testes dos efeitos de grupo (Hair et al., 2009).

A associação entre a covariável e o fator não viola, por si só, o modelo linear. A MANOVA sem covariáveis compara os vetores de médias definidos pelo modelo sem ajuste para a covariável, enquanto a MANCOVA compara vetores de médias condicionais aos valores da covariável. Diferenças entre esses dois resultados decorrem das hipóteses distintas formuladas pelos dois modelos.

18.10.8 Validação dos resultados

A repetição do estudo sob o mesmo delineamento constitui a principal forma de avaliar a reprodução dos resultados de uma MANOVA (Hair et al., 2009). Em uma nova amostra da mesma população-alvo, devem ser comparadas as estimativas das diferenças entre os vetores de médias e as decisões obtidas para as mesmas hipóteses multivariadas.

Diferenças entre as duas análises devem ser examinadas considerando os tamanhos amostrais, os tamanhos das células, as matrizes de covariâncias e as estimativas dos efeitos.

Em estudos observacionais, a reprodução de uma associação em diferentes amostras não substitui a designação aleatória dos tratamentos. Quando os grupos são definidos por características observadas, a MANOVA compara os vetores de médias condicionais a esses grupos. Sem um delineamento ou uma estratégia de identificação causal que sustente essa interpretação, diferenças entre os vetores de médias não devem ser interpretadas como efeitos causais (Hair et al., 2009).

A repetição da análise em outra amostra da mesma população-alvo avalia a reprodução dos resultados nessa população. A generalização para outras populações exige suporte do delineamento amostral e das condições sob as quais as amostras foram obtidas.

18.10.9 Correspondência com a implementação utilizada

A implementação utilizada é a análise MANCOVA do núcleo do [jamovi](#) (The jamovi project, 2026). A Tabela 18.4 relaciona as opções e saídas da interface aos objetos estatísticos da MANOVA.

Tabela 18.4: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Dependent Variables	colunas da matriz de respostas $\mathbf{y}$	Definição 11.3

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Factors	fatores categóricos que determinam termos da matriz de delineamento Z	Definição 11.3 e Seção 18.10.7
Covariates	covariáveis quantitativas incluídas como termos de Z	Seção 18.10.7
Pillai's Trace	critério de Pillai	Seção 18.5
Wilks' Lambda	lambda de Wilks	Seção 18.5
Hotelling's Trace	traço de Hotelling	Seção 18.5
Roy's Largest Root	maior raiz característica de Roy	Seção 18.5
Univariate Tests	testes univariados de cada resposta para cada termo do modelo; a multiplicidade entre respostas deve ser tratada separadamente	Equação 18.39 e Seção 18.10.5
Box's M	teste de igualdade das matrizes de covariâncias dos grupos formados pelos fatores	Seção 18.10.2
Multivariate Shapiro–Wilk	teste de normalidade multivariada calculado pela implementação com os vetores de respostas observados; não utiliza os resíduos do modelo	Seção 18.7.5
Q–Q plot	comparação das distâncias de Mahalanobis calculadas com os vetores de respostas observados com quantis qui-quadrado; não utiliza os resíduos do modelo	Seção 18.7.5
Missing values	exclusão das unidades com valor ausente em alguma variável utilizada no modelo	convenção da implementação; tratamento estatístico de dados ausentes não desenvolvido no capítulo

Quando há dois ou mais fatores, a implementação inclui seus efeitos principais e as interações entre fatores. As covariáveis entram como termos aditivos e não geram automaticamente interações fator–covariável. O modelo ajustado pela interface impõe, portanto, coeficientes comuns para cada covariável nos diferentes níveis dos fatores, conforme a condição descrita na Seção 18.10.7.

A denominação **Hotelling's Trace** corresponde ao traço de Hotelling. Para cada termo do modelo, os quatro critérios utilizam a mesma SQPC da hipótese e a mesma SQPC residual. As diferenças entre os critérios decorrem das funções aplicadas às raízes características. A implementação apresenta também a estatística F , os graus de liberdade e o valor p associados a cada critério.

Os testes univariados correspondem aos testes da Seção 18.10.5. Para cada termo do modelo, cada resposta é examinada separadamente por uma estatística baseada em H_{jj} e E_{jj} . Esses testes não utilizam os produtos cruzados entre respostas e não reproduzem o teste multivariado.

Quando várias respostas são examinadas, os valores p univariados devem ser interpretados como uma família de testes. A rejeição prévia da hipótese multivariada não controla automaticamente o erro Tipo I dessa família; o procedimento de multiplicidade deve ser definido de acordo com as hipóteses marginais que serão interpretadas.

O teste M de Box utiliza as combinações dos níveis dos fatores para formar os grupos e compara as matrizes de covariâncias das respostas observadas. Em uma MANCOVA, as covariáveis não entram nesse cálculo; portanto, o teste não avalia diretamente a igualdade das matrizes de covariâncias residuais após o ajuste das covariáveis exigida pelo modelo.

A hipótese de normalidade da MANOVA refere-se aos vetores de erros condicionais à matriz de delineamento,

$$\varepsilon_i = y_i - E(\mathbf{Y}_i \mid \mathbf{Z}).$$

O teste multivariado de Shapiro–Wilk e o gráfico Q–Q da implementação auditada são calculados com os vetores de respostas observados y_i , e não com os resíduos do modelo ajustado.

Quando os vetores de médias diferem entre os níveis dos fatores, as respostas reunidas não precisam seguir uma única distribuição normal multivariada, mesmo que os erros condicionais sejam normais. Na MANCOVA, a média condicional também varia com os valores das covariáveis. Portanto, a distribuição das respostas não ajustadas não coincide, em geral, com a distribuição dos erros do modelo.

O teste multivariado de Shapiro–Wilk e o gráfico Q–Q da interface não testam diretamente a hipótese de normalidade formulada na Seção 18.7.5. A avaliação dessa hipótese deve utilizar os resíduos do modelo ajustado.

Na MANOVA de um fator, os resíduos são os desvios das observações em relação ao vetor de médias do respectivo grupo. Em modelos fatoriais ou com covariáveis, os resíduos são obtidos após o ajuste de todos os termos incluídos no modelo.

A exclusão das unidades com valores ausentes reduz a amostra analisada e pode alterar os tamanhos das células e os graus de liberdade residuais. A análise das observações completas não modela o mecanismo de ausência. Quando a ocorrência de valores ausentes depende das respostas ou de outras características das unidades, as estimativas obtidas com os casos

completos podem diferir das estimativas que seriam obtidas com os dados completos (Johnson; Wichern, 2002).

A interface não fornece os contrastes planejados e as comparações posteriores discutidos na Seção 18.10.6. Quando essas análises são necessárias, elas devem ser realizadas por procedimentos adicionais após o teste multivariado global.

18.11 Síntese

A MANOVA formula hipóteses sobre um vetor de respostas no modelo linear multivariado

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}.$$

Para uma hipótese estimável

$$H_0 : \mathbf{C}_1 \mathbf{B} = \Theta_0,$$

a SQPC da hipótese $\mathbf{H}$ quantifica a variação associada à hipótese testada, enquanto a SQPC residual $\mathbf{E}$ quantifica a variação não explicada pelo modelo.

Quando

$$\mathbf{E} \succ \mathbf{0},$$

a comparação entre hipótese e erro conduz ao problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}.$$

As raízes características

$$\lambda_1 \geq \dots \geq \lambda_p \geq 0$$

são os autovalores generalizados do par $(\mathbf{H}, \mathbf{E})$. O número de raízes positivas é

$$r_H = \text{posto}(\mathbf{H}) \leq \min(p, g),$$

em que $g = \text{posto}(\mathbf{C}_1)$.

Os quatro critérios clássicos são funções dessas raízes:

$$\Lambda_W = \prod_{j=1}^p \frac{1}{1 + \lambda_j}, \quad V = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j},$$

$$U = \sum_{j=1}^p \lambda_j, \quad \text{maior raiz característica de Roy} = \lambda_1.$$

A lambda de Wilks diminui à medida que aumenta a evidência contra H_0 ; o critério de Pillai, o traço de Hotelling e a maior raiz característica de Roy aumentam. A calibração inferencial clássica pressupõe independência entre unidades, normalidade multivariada dos erros, matriz de covariâncias residual comum e as condições de posto necessárias às operações matriciais utilizadas.

Para $p = 1$, o problema reduz-se à ANOVA. Com dois grupos, há no máximo uma raiz positiva e

$$\lambda_1 = \frac{T^2}{n_1 + n_2 - 2}.$$

A regressão multivariada utiliza o mesmo modelo linear multivariado, com hipóteses distintas sobre $\mathbf{B}$. Na MANOVA de um fator, $\mathbf{H}$ e $\mathbf{E}$ coincidem, respectivamente, com as matrizes de dispersão entre e dentro dos grupos utilizadas na formulação de Fisher.

A Análise Discriminante parte de grupos conhecidos e muda o objetivo da análise: em vez de testar hipóteses sobre vetores de médias, utiliza a separação entre e dentro dos grupos para construir direções discriminantes e, sob modelos probabilísticos específicos, regras de classificação.

19 Formulação da Análise Discriminante

A Análise Discriminante utiliza grupos previamente conhecidos para resolver dois problemas relacionados: representar a separação entre os grupos e construir regras para classificar novas observações (Johnson; Wichern, 2002).

O capítulo desenvolve duas formulações. Na formulação probabilística, as classes são descritas por distribuições condicionais e a classificação é tratada como um problema de decisão envolvendo probabilidades *a priori*, perdas e probabilidades *a posteriori*. Na formulação geométrica de Fisher, procuram-se combinações lineares que maximizem a separação entre grupos relativamente à dispersão intragrupos.

As duas formulações possuem objetivos distintos. A primeira produz regras de classificação; a segunda constrói direções que representam a separação entre grupos conhecidos. Sob condições específicas, suas soluções podem estar relacionadas.

Parâmetros populacionais, estatísticas amostrais e regras estimadas são objetos distintos. As formulações consideradas são as versões clássicas, sem regularização ou seleção automática de variáveis.

A Tabela 19.1 resume as formulações utilizadas.

Tabela 19.1: Formulações complementares da Análise Discriminante.

Formulação	Objeto de partida	Problema	Resultado
decisão estatística	densidades condicionais, probabilidades <i>a priori</i> e perdas	escolher uma ação para uma nova observação	regra de Bayes
normal com covariância comum	μ_k, Σ e π_k	minimizar risco sob perda zero-um	regra de classificação linear (LDA)
normal com covariâncias específicas por classe	μ_k, Σ_k e π_k	minimizar risco sob perda zero-um	regra de classificação quadrática (QDA)
geométrica de Fisher	dispersões intragrupos e entre grupos	maximizar separação relativa	direções e coordenadas discriminantes

19.1 O problema de discriminação e classificação

Considere uma variável aleatória de classe

$$C \in \{1, \dots, K\}, \quad K \geq 2.$$

A variável C é categórica, conforme a distinção apresentada na Seção 1.2. Os valores $1, \dots, K$ funcionam como rótulos das classes e não como medidas quantitativas. Sua ordem ou suas diferenças numéricas não participam da definição da Análise Discriminante.

Considere também um vetor aleatório de características quantitativas

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p.$$

Para cada classe

$$k \in \{1, \dots, K\},$$

existe uma distribuição condicional de

$$\mathbf{x} \mid C = k.$$

Uma realização

$$\mathbf{x} \in \mathbb{R}^p$$

representa os valores observados das características de uma unidade.

Durante a construção da técnica, os rótulos das unidades utilizadas para caracterizar os grupos são conhecidos. A Análise Discriminante é, portanto, uma técnica supervisionada.

Na **discriminação**, procura-se construir funções ou direções que representem a separação entre os grupos. Na **classificação**, procura-se uma regra

$$\psi : \mathbb{R}^p \longrightarrow \{1, \dots, K\}$$

que associe uma nova observação $\mathbf{x}$ a uma das classes.

Taxas de erro, matrizes de classificação e validação cruzada avaliam a qualidade preditiva de uma regra estimada. Esses procedimentos pertencem à avaliação da regra, e não à sua definição, conforme detalhado na Seção 19.15.

19.2 Classificação como problema de decisão

A classificação pode ser formulada como um problema de decisão. Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

deve-se escolher uma ação

$$a \in \mathcal{A}, \quad \mathcal{A} = \{1, \dots, K\}.$$

A ação a significa atribuir a observação à classe a . A decisão depende das probabilidades *a priori*, das distribuições condicionais das características e das perdas associadas às possíveis classificações.

19.2.1 Probabilidades *a priori* e *a posteriori*

Definição 19.1 (Probabilidades *a priori* das classes). Seja

$$C \in \{1, \dots, K\}$$

uma variável aleatória de classe.

As probabilidades *a priori* são

$$\pi_k = P(C = k), \quad k = 1, \dots, K,$$

com

$$\pi_k > 0$$

e

$$\sum_{k=1}^K \pi_k = 1.$$

As probabilidades *a priori* descrevem a distribuição das classes antes da observação das características da nova unidade. Elas são parâmetros do problema de decisão e não devem ser identificadas automaticamente com as proporções das classes em uma amostra de treinamento.

Suponha que, para cada classe k ,

$$\mathbf{X} \mid \mathbf{C} = k$$

possua densidade condicional

$$f_k(\mathbf{x}) = f(\mathbf{x} \mid \mathbf{C} = k).$$

Para uma observação $\mathbf{x}$ tal que

$$\sum_{\ell=1}^K \pi_{\ell} f_{\ell}(\mathbf{x}) > 0,$$

o teorema de Bayes fornece

$$P(\mathbf{C} = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{\ell=1}^K \pi_{\ell} f_{\ell}(\mathbf{x})}. \quad (19.1)$$

A probabilidade *a posteriori* é determinada pelo produto entre a probabilidade *a priori* π_k e o valor $f_k(\mathbf{x})$ da densidade condicional na observação $\mathbf{x}$, normalizado pela soma desses produtos entre as classes.

19.2.2 Regra de Bayes sob perda zero-um

No caso mais simples, atribui-se perda zero a uma classificação correta e a mesma perda unitária a qualquer classificação incorreta:

$$L(a, k) = \begin{cases} 0, & a = k, \\ 1, & a \neq k. \end{cases} \quad (19.2)$$

Se a observação $\mathbf{x}$ for atribuída à classe a , a perda depende da verdadeira classe, que permanece desconhecida. Depois de observar $\mathbf{x}$, cada classe k possui probabilidade *a posteriori*

$$P(\mathbf{C} = k \mid \mathbf{X} = \mathbf{x}).$$

A perda esperada associada à decisão a é obtida ponderando a perda correspondente a cada possível classe verdadeira por sua probabilidade *a posteriori*:

$$\sum_{k=1}^K L(a, k) P(C = k \mid \mathbf{X} = \mathbf{x}).$$

Sob a perda zero-um da Equação 19.2, o termo correspondente a $k = a$ é nulo e todos os termos com $k \neq a$ recebem perda unitária. Assim,

$$\begin{aligned} \sum_{k=1}^K L(a, k) P(C = k \mid \mathbf{X} = \mathbf{x}) &= \sum_{k \neq a} P(C = k \mid \mathbf{X} = \mathbf{x}) \\ &= 1 - P(C = a \mid \mathbf{X} = \mathbf{x}). \end{aligned}$$

Portanto, a perda esperada de atribuir $\mathbf{x}$ à classe a é a probabilidade *a posteriori* de que sua verdadeira classe seja diferente de a . Como

$$1 - u$$

decrece quando u aumenta, a menor perda esperada corresponde à maior probabilidade *a posteriori*. A regra de Bayes sob perda zero-um é, então,

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} P(C = k \mid \mathbf{X} = \mathbf{x}).$$

Pela Equação 19.1,

$$P(C = k \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{h=1}^K \pi_h f_h(\mathbf{x})}.$$

Para uma observação fixa $\mathbf{x}$, o denominador

$$\sum_{h=1}^K \pi_h f_h(\mathbf{x})$$

é o mesmo na probabilidade *a posteriori* de todas as classes. A comparação entre as classes depende, portanto, apenas dos valores

$$\pi_1 f_1(\mathbf{x}), \dots, \pi_K f_K(\mathbf{x}).$$

A regra de classificação pode ser escrita como

$$\psi_B(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \pi_k f_k(\mathbf{x}). \quad (19.3)$$

Se

$$\pi_k > 0 \quad \text{e} \quad f_k(\mathbf{x}) > 0$$

para todas as classes, a aplicação do logaritmo preserva a ordenação desses valores, pois o logaritmo é uma função estritamente crescente. Além disso,

$$\log [\pi_k f_k(\mathbf{x})] = \log \pi_k + \log f_k(\mathbf{x}).$$

Assim, para uma mesma observação $\mathbf{x}$, comparar

$$\pi_1 f_1(\mathbf{x}), \dots, \pi_K f_K(\mathbf{x})$$

é equivalente a comparar

$$\log \pi_1 + \log f_1(\mathbf{x}), \dots, \log \pi_K + \log f_K(\mathbf{x}).$$

A classe atribuída a $\mathbf{x}$ é aquela que apresenta o maior valor de

$$\log \pi_k + \log f_k(\mathbf{x}). \quad (19.4)$$

Sob normalidade multivariada, a forma de $f_k(\mathbf{x})$ determina duas especializações dessa regra. Quando todas as classes compartilham a mesma matriz de covariâncias, obtém-se a **Análise Discriminante Linear** (*Linear Discriminant Analysis*, LDA). Quando cada classe possui sua própria matriz de covariâncias, obtém-se a **Análise Discriminante Quadrática** (*Quadratic Discriminant Analysis*, QDA) (Anderson, 2003).

Quando as perdas dos diferentes erros de classificação não são iguais, a decisão ótima depende conjuntamente das probabilidades *a posteriori* e dos valores $L(a, k)$. Nesse caso, a classe de maior probabilidade *a posteriori* não precisa ser a decisão de menor perda esperada.

19.3 Discriminação linear sob normalidade (LDA)

Utilizando a distribuição Normal Multivariada definida na Definição 9.1, considere a especialização probabilística

$$\mathbf{x} \mid C = k \sim N_p(\mu_k, \Sigma), \quad k = 1, \dots, K, \quad (19.5)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e todas as classes compartilham a matriz de covariâncias

$$\Sigma \in \mathbb{R}^{p \times p}, \quad \Sigma \succ \mathbf{0}.$$

Considere também probabilidades *a priori*

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

A normalidade não é necessária para definir a regra de Bayes. Na LDA normal, ela especifica as distribuições condicionais das características.

Sob perda zero-um, a Equação 19.3 mostra que a classificação pode ser obtida comparando

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A comparação entre log-densidades normais com matriz de covariâncias comum foi estabelecida na Equação 9.49. Os termos quadráticos em $\mathbf{x}$ e os termos que não dependem da classe cancelam-se, restando uma função afim das características.

Definição 19.2 (Função discriminante linear de classe). Sob o modelo normal especificado na Equação 19.5 e perda zero-um, a **função discriminante linear da classe k** é

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k. \quad (19.6)$$

A regra discriminante linear é

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k(\mathbf{x}). \quad (19.7)$$

A função $\delta_k(\mathbf{x})$ é afim em $\mathbf{x}$. A denominação *Linear Discriminant Analysis* refere-se à forma das fronteiras de decisão entre as classes.

19.3.1 Fronteiras e distância de Mahalanobis

Considere duas classes distintas,

$$k \neq h.$$

A fronteira entre elas é determinada por

$$\delta_k(\mathbf{x}) = \delta_h(\mathbf{x}),$$

ou, equivalentemente,

$$\begin{aligned} 0 &= \mathbf{x}^\top \Sigma^{-1} (\mu_k - \mu_h) \\ &\quad - \frac{1}{2} (\mu_k^\top \Sigma^{-1} \mu_k - \mu_h^\top \Sigma^{-1} \mu_h) + \log \frac{\pi_k}{\pi_h}. \end{aligned} \quad (19.8)$$

Quando

$$\mu_k \neq \mu_h,$$

essa equação define um hiperplano cujo vetor normal é

$$\Sigma^{-1} (\mu_k - \mu_h). \quad (19.9)$$

A orientação da fronteira é determinada por $\Sigma^{-1}(\mu_k - \mu_h)$. Mantidos μ_k , μ_h e Σ , alterar as probabilidades *a priori* modifica o termo constante e desloca a fronteira, mas não altera seu vetor normal.

Se

$$\mu_k = \mu_h,$$

as duas classes possuem a mesma densidade condicional sob o modelo de covariância comum. A comparação entre elas depende apenas das probabilidades *a priori*. Se também

$$\pi_k = \pi_h,$$

os valores das funções discriminantes das duas classes coincidem para todo $\mathbf{x}$, e a regra não permite distingui-las.

A distância de Mahalanobis definida na Definição 8.9 permite escrever a mesma regra em forma geométrica. Para a classe k ,

$$d_M^2(\mathbf{x}, \mu_k; \Sigma) = (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k).$$

Sob perda zero-um,

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} \left\{ d_M^2(\mathbf{x}, \mu_k; \Sigma) - 2 \log \pi_k \right\}. \quad (19.10)$$

Se as probabilidades *a priori* são iguais,

$$\pi_1 = \dots = \pi_K = \frac{1}{K},$$

o termo associado às probabilidades é comum a todas as classes e

$$\psi_{\text{LDA}}(\mathbf{x}) \in \arg \min_{k \in \{1, \dots, K\}} d_M^2(\mathbf{x}, \mu_k; \Sigma). \quad (19.11)$$

Assim, sob normalidade, covariância comum, probabilidades *a priori* iguais e perda zero-um, a regra de Bayes classifica pela menor distância de Mahalanobis ao vetor de médias populacional μ_k de cada classe.

Na LDA, a matriz Σ desempenha dois papéis: é a matriz de covariâncias comum das distribuições condicionais e define a métrica de Mahalanobis utilizada para comparar uma nova observação com os vetores de médias das classes.

A LDA desenvolvida nesta seção é populacional, pois utiliza

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_K.$$

Na regra definida na Seção 19.5, esses parâmetros populacionais são substituídos pelas quantidades correspondentes obtidas ou adotadas a partir da amostra de treinamento.

19.4 Discriminação quadrática (QDA)

A linearidade da LDA decorre da utilização de uma matriz de covariâncias comum. Considere agora

$$\mathbf{x} \mid C = k \sim N_p(\mu_k, \Sigma_k), \quad k = 1, \dots, K, \quad (19.12)$$

em que

$$\mu_k \in \mathbb{R}^p$$

e

$$\Sigma_k \in \mathbb{R}^{p \times p}, \quad \Sigma_k \succ \mathbf{0}.$$

Considere também

$$\pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1.$$

Sob perda zero-um, a regra de Bayes continua comparando

$$\log \pi_k + \log f_k(\mathbf{x}).$$

A diferença está nas matrizes de covariâncias das distribuições condicionais. Como mostra a Equação 9.50, para duas classes com matrizes de covariâncias distintas, os termos quadráticos em $\mathbf{x}$ não se cancelam na comparação.

Definição 19.3 (Função discriminante quadrática de classe). Sob o modelo normal especificado na Equação 19.12 e perda zero-um, a **função discriminante quadrática da classe k** é

$$\delta_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k) + \log \pi_k. \quad (19.13)$$

A regra discriminante quadrática é

$$\psi_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \delta_k^Q(\mathbf{x}). \quad (19.14)$$

A função possui dois componentes dependentes da dispersão da classe. A forma quadrática, no sentido da Definição 2.23,

$$(\mathbf{x} - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x} - \mu_k)$$

é a distância quadrática de Mahalanobis à média da classe segundo sua própria matriz de covariâncias. O termo

$$\log |\Sigma_k|$$

é o logaritmo da variância generalizada da distribuição condicional da classe k , conforme a Definição 8.8, e participa do termo de normalização da densidade normal.

Na QDA, cada classe é comparada com sua média segundo a matriz de covariâncias Σ_k . Quando essas matrizes diferem entre as classes, não existe uma única métrica de Mahalanobis compartilhada por todas elas.

19.4.1 Fronteiras e comparação com a LDA

Considere duas classes distintas,

$$k \neq h.$$

A fronteira é determinada por

$$\delta_k^Q(\mathbf{x}) = \delta_h^Q(\mathbf{x}).$$

Após reunir os termos quadráticos, lineares e constantes, obtém-se

$$\mathbf{x}^\top \mathbf{A}_{kh} \mathbf{x} + \mathbf{b}_{kh}^\top \mathbf{x} + c_{kh} = 0, \quad (19.15)$$

em que $\mathbf{A}_{kh}$, $\mathbf{b}_{kh}$ e c_{kh} dependem das médias, das matrizes de covariâncias e das probabilidades *a priori* das duas classes.

Quando

$$\Sigma_k \neq \Sigma_h,$$

tem-se

$$\mathbf{A}_{kh} \neq \mathbf{0},$$

e permanecem termos quadráticos em $\mathbf{x}$. A fronteira entre as classes não precisa, portanto, ser um hiperplano.

Quando todas as classes compartilham

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

o termo quadrático em $\mathbf{x}$ e o log-determinante tornam-se comuns a todas as classes. Esses termos podem ser retirados da comparação entre as funções discriminantes de classe, e a parte dependente da classe coincide com a Equação 19.6. A regra de classificação da QDA torna-se, portanto, equivalente à LDA.

A diferença entre LDA e QDA decorre das matrizes de covariâncias assumidas para as distribuições condicionais. Na LDA, uma única matriz Σ define a métrica de Mahalanobis comum às classes e conduz a fronteiras lineares; na QDA, cada classe pode possuir sua própria matriz Σ_k , de modo que a comparação utiliza métricas de Mahalanobis específicas por classe e pode produzir fronteiras quadráticas.

A Figura 19.1 ilustra essa diferença para duas populações normais.

Na LDA, a matriz de covariâncias comum faz com que os termos quadráticos em $\mathbf{x}$ se cancelem na comparação entre as classes, produzindo a fronteira linear representada no primeiro painel. Na QDA, quando as matrizes de covariâncias das classes diferem, esse cancelamento não ocorre e a fronteira pode ser quadrática, como no segundo painel.

19.5 Da regra populacional à regra estimada

As regras populacionais da LDA e da QDA dependem de parâmetros populacionais.

Na LDA, são necessários

$$\mu_1, \dots, \mu_K, \quad \Sigma, \quad \pi_1, \dots, \pi_K.$$

Na QDA, são necessários




Figura 19.1: Fronteiras de decisão para duas populações normais. As elipses delimitam regiões de concentração de 75%. Com covariância comum, a LDA produz uma fronteira linear; com covariâncias distintas, a QDA pode produzir uma fronteira quadrática.

$$\mu_1, \dots, \mu_K, \quad \Sigma_1, \dots, \Sigma_K, \quad \pi_1, \dots, \pi_K.$$

Em uma aplicação, as médias e as matrizes de covariâncias populacionais são geralmente desconhecidas e são estimadas a partir de uma amostra de treinamento com classes conhecidas. As probabilidades *a priori* podem ser conhecidas, especificadas ou estimadas, conforme a informação disponível e o mecanismo de amostragem. Conforme a Definição 10.4, os estimadores são estatísticas aleatórias; após a observação da amostra, seus valores constituem estimativas.

Considere

$$n = \sum_{k=1}^K n_k,$$

em que n_k é o número de unidades observadas da classe k .

Para cada classe, a média amostral aleatória é obtida aplicando a Equação 10.8 às observações do grupo, e sua realização observada será denotada por

$$\bar{\mathbf{x}}_k \in \mathbb{R}^p.$$

Quando

$$n_k \geq 2,$$

a matriz de covariâncias amostral definida em Definição 10.14 fornece o estimador da covariância da classe, cuja realização será denotada por

$$\mathbf{S}_k \in \mathbb{R}^{p \times p}.$$

Essas estatísticas não exigem normalidade para serem definidas. Nas formulações LDA e QDA, elas são utilizadas como estimadores dos parâmetros dos respectivos modelos normais.

19.5.1 Covariância comum na LDA

Sob a hipótese populacional

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

a dispersão das classes é reunida em uma única estimativa.

Utilizando a matriz de dispersão intragrupos $\mathbf{T}_{\text{intra}}$ definida na Definição 8.14 e sua correspondência com a SQPC residual da MANOVA expressa pela Equação 11.107, para

$$n > K,$$

a matriz de covariâncias agrupada observada é

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}. \quad (19.16)$$

Equivalentemente, quando todas as matrizes $\mathbf{S}_k$ estão definidas,

$$\mathbf{S}_p = \frac{\sum_{k=1}^K (n_k - 1) \mathbf{S}_k}{n - K}.$$

A matriz $\mathbf{T}_{\text{intra}}$ utilizada na estimativa da covariância comum da LDA pela Equação 19.16 também compõe o critério amostral de Fisher desenvolvido na Seção 19.6.

19.5.2 Probabilidades *a priori*

Na regra estimada, as probabilidades *a priori* utilizadas na classificação podem ser conhecidas a partir de informação populacional, especificadas externamente ou estimadas a partir da amostra de treinamento.

Quando a amostra de treinamento representa a mistura populacional das classes, pode-se utilizar a estimativa

$$\hat{\pi}_k = \frac{n_k}{n}. \quad (19.17)$$

Essa escolha não é automática. Se os tamanhos das classes foram fixados pelo delineamento ou se o mecanismo amostral altera suas proporções, n_k/n não representa necessariamente

$$P(C = k).$$

Nessas situações, as probabilidades *a priori* devem ser especificadas a partir do problema ou de informação populacional externa.

Para distinguir a estimativa amostral do valor efetivamente utilizado na regra, denote por

$$\tilde{\pi}_k$$

a probabilidade *a priori* adotada para a classificação. Quando ela é estimada pelas proporções da amostra,

$$\tilde{\pi}_k = \hat{\pi}_k;$$

quando é especificada externamente, $\tilde{\pi}_k$ representa diretamente o valor adotado.

19.5.3 Regra estimada da LDA

Substituindo as médias e a matriz de covariâncias populacionais por estimativas e utilizando os valores das probabilidades *a priori* adotados para a classificação, obtém-se uma regra *plug-in*.

Definição 19.4 (Função discriminante linear de classe estimada). Considere médias observadas

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K,$$

a matriz de covariâncias agrupada

$$\mathbf{S}_p \succ \mathbf{0}$$

definida na Equação 19.16 e probabilidades *a priori* utilizadas na regra

$$\tilde{\pi}_k > 0, \quad \sum_{k=1}^K \tilde{\pi}_k = 1.$$

A função discriminante linear estimada da classe k é

$$\hat{\delta}_k(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k - \frac{1}{2} \bar{\mathbf{x}}_k^\top \mathbf{S}_p^{-1} \bar{\mathbf{x}}_k + \log \tilde{\pi}_k. \quad (19.18)$$

A regra estimada é

$$\hat{\psi}_{\text{LDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \hat{\delta}_k(\mathbf{x}). \quad (19.19)$$

A forma algébrica coincide com a regra populacional, mas os objetos possuem naturezas estatísticas diferentes:

$$\mu_k \longrightarrow \bar{\mathbf{x}}_k, \quad \Sigma \longrightarrow \mathbf{S}_p, \quad \pi_k \longrightarrow \tilde{\pi}_k.$$

A regra estimada depende da amostra de treinamento e, portanto, varia entre amostras.

19.5.4 Regra estimada da QDA

Na QDA estimada, a matriz de covariâncias de cada classe é estimada separadamente.

Definição 19.5 (Função discriminante quadrática de classe estimada). Considere

$$\mathbf{S}_k \succ \mathbf{0}, \quad k = 1, \dots, K.$$

A função discriminante quadrática estimada da classe k é

$$\hat{\delta}_k^Q(\mathbf{x}) = -\frac{1}{2} \log |\mathbf{S}_k| - \frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_k)^\top \mathbf{S}_k^{-1} (\mathbf{x} - \bar{\mathbf{x}}_k) + \log \tilde{\pi}_k. \quad (19.20)$$

A regra correspondente é

$$\hat{\psi}_{\text{QDA}}(\mathbf{x}) \in \arg \max_{k \in \{1, \dots, K\}} \hat{\delta}_k^Q(\mathbf{x}). \quad (19.21)$$

A LDA utiliza uma única estimativa de covariância, $\mathbf{S}_p$, enquanto a QDA utiliza

$$\mathbf{S}_1, \dots, \mathbf{S}_K.$$

A QDA exige, portanto, amostras de classe que permitam estimar matrizes de covariâncias não singulares. As condições de posto correspondentes são reunidas na Seção 19.12.

A Tabela 19.2 sintetiza a diferença entre as duas formulações.

Tabela 19.2: Comparação entre LDA e QDA.

Aspecto	LDA	QDA
modelo condicional	$N_p(\mu_k, \Sigma)$	$N_p(\mu_k, \Sigma_k)$
covariância populacional	comum	específica por classe
estimativa de covariância	$\mathbf{S}_p$	$\mathbf{S}_k$
função discriminante de classe	afim em $\mathbf{x}$	quadrática em $\mathbf{x}$
fronteira entre duas classes	hiperplano	superfície quadrática em geral
geometria	uma métrica de Mahalanobis comum	uma métrica de Mahalanobis por classe
probabilidades <i>a priori</i>	entram por $\log \pi_k$ na regra populacional e por $\log \tilde{\pi}_k$ na regra estimada	entram por $\log \pi_k$ na regra populacional e por $\log \tilde{\pi}_k$ na regra estimada

A substituição das médias e covariâncias populacionais por estimativas transforma a regra populacional em uma regra construída a partir da amostra de treinamento. Quando as probabilidades *a priori* também são estimadas a partir da amostra, sua variabilidade amostral integra a regra; quando são especificadas externamente, seus valores permanecem fixos.

19.6 Formulação geométrica de Fisher

A classificação probabilística produz regras para classificar novas observações. A formulação de Fisher utiliza os grupos conhecidos para construir combinações lineares das características que representem sua separação relativamente à dispersão existente dentro dos grupos.

O problema admite uma formulação populacional e uma formulação amostral. A formulação populacional constrói as dispersões dentro e entre classes a partir dos momentos condicionais

de $\mathbf{X} \mid C = k$; a formulação amostral utiliza as matrizes de dispersão calculadas a partir das observações com rótulos conhecidos.

O critério geométrico de Fisher não exige normalidade multivariada nem igualdade das matrizes de covariâncias condicionais para ser definido. A hipótese de covariância comum é necessária para estabelecer sua correspondência direta com a LDA normal; apresentações clássicas de Fisher frequentemente incorporam essa condição à formulação (Johnson; Wichern, 2002).

19.6.1 Dispersões populacionais dentro e entre grupos

Considere

$$C \in \{1, \dots, K\},$$

com

$$P(C = k) = \pi_k, \quad \pi_k > 0, \quad \sum_{k=1}^K \pi_k = 1,$$

e um vetor aleatório

$$\mathbf{X} \in \mathbb{R}^p$$

com segundos momentos finitos.

Para cada classe, sejam

$$\mu_k = E(\mathbf{X} \mid C = k)$$

e

$$\Sigma_k = \text{Cov}(\mathbf{X} \mid C = k).$$

A média marginal é

$$\mu = E(\mathbf{X}) = \sum_{k=1}^K \pi_k \mu_k. \quad (19.22)$$

Definição 19.6 (Dispersões populacionais de Fisher). A **dispersão populacional intragrupos** é

$$\Sigma_W = \sum_{k=1}^K \pi_k \Sigma_k \in \mathbb{R}^{p \times p}, \quad (19.23)$$

e a **dispersão populacional entre grupos** é

$$\Sigma_B = \sum_{k=1}^K \pi_k (\mu_k - \mu) (\mu_k - \mu)^\top \in \mathbb{R}^{p \times p}. \quad (19.24)$$

As duas matrizes são simétricas e semidefinidas positivas. A matriz Σ_W é a média, ponderada pelas probabilidades π_k , das matrizes de covariâncias condicionais, enquanto Σ_B é a dispersão dos vetores de médias condicionais em torno da média marginal, também ponderada pelas probabilidades π_k .

Proposição 19.1 (Decomposição populacional da covariância por grupos). *Sob as condições da Definição 19.6,*

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B. \quad (19.25)$$

A Equação 19.25 decorre da lei da covariância total condicionada à variável de classe $\mathbf{C}$; sua derivação está na Seção 19.14.4.

A Equação 19.25 é a contraparte populacional da decomposição amostral

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

estabelecida na Proposição 8.10. Os objetos possuem naturezas distintas: Σ_W e Σ_B são parâmetros populacionais, enquanto $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ são matrizes calculadas a partir das observações.

19.6.2 Dispersões projetadas

Considere uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

e a combinação linear

$$Z = \mathbf{a}^\top \mathbf{X}.$$

A dispersão média de Z dentro das classes é

$$\sum_{k=1}^K \pi_k \text{Var}(Z | C = k) = \mathbf{a}^\top \Sigma_W \mathbf{a}, \quad (19.26)$$

enquanto a dispersão das médias condicionais projetadas é

$$\sum_{k=1}^K \pi_k \left[\mathbf{a}^\top (\mu_k - \mu) \right]^2 = \mathbf{a}^\top \Sigma_B \mathbf{a}. \quad (19.27)$$

Definição 19.7 (Critério populacional de Fisher). Se

$$\Sigma_B \succeq \mathbf{0}$$

e

$$\Sigma_W \succ \mathbf{0},$$

o critério populacional de Fisher é

$$J_F^{(P)}(\mathbf{a}) = \frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}, \quad \mathbf{a} \neq \mathbf{0}. \quad (19.28)$$

O numerador é a dispersão, ponderada pelas probabilidades π_k , das médias condicionais projetadas em torno da média marginal projetada. O denominador é a média, também ponderada por π_k , das variâncias condicionais da projeção dentro das classes. O critério procura, portanto, direções em que a dispersão entre classes seja elevada relativamente à dispersão intragrupos.

O critério populacional de Fisher exige segundos momentos finitos. A solução baseada em Σ_W^{-1} exige adicionalmente

$$\Sigma_W \succ \mathbf{0}.$$

A normalidade multivariada e a igualdade

$$\Sigma_1 = \dots = \Sigma_K$$

não são necessárias para definir o critério.

Quando as covariâncias condicionais são comuns,

$$\Sigma_k = \Sigma, \quad k = 1, \dots, K,$$

tem-se

$$\Sigma_W = \Sigma.$$

Para duas classes com covariância comum, a direção de Fisher é paralela ao vetor normal da fronteira da LDA, conforme demonstrado na Seção 19.14.5.

19.7 Formulação amostral de Fisher

Considere uma amostra com grupos conhecidos, com n_k observações no grupo k e

$$n = \sum_{k=1}^K n_k$$

observações no total.

As matrizes de dispersão intragrupos $\mathbf{T}_{\text{intra}}$ e entre grupos $\mathbf{T}_{\text{entre}}$ são as definidas, respectivamente, na Definição 8.14 e na Definição 8.15.

Pela Proposição 8.10,

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Na formulação amostral de Fisher, essas matrizes desempenham funções distintas: $\mathbf{T}_{\text{intra}}$ representa a dispersão das observações em torno dos centroides de seus grupos, enquanto $\mathbf{T}_{\text{entre}}$ representa a dispersão dos centroides em torno da média global, ponderada pelos tamanhos dos grupos.

As matrizes

$$\frac{1}{n} \mathbf{T}_{\text{intra}} \quad \text{e} \quad \frac{1}{n} \mathbf{T}_{\text{entre}}$$

correspondem às versões empíricas das dispersões populacionais quando as classes recebem pesos n_k/n . Como a multiplicação do numerador e do denominador por um mesmo escalar positivo não altera o quociente de Fisher, o critério pode ser formulado diretamente com as SQPCs.

Os pesos n_k presentes em $\mathbf{T}_{\text{entre}}$ pertencem à decomposição da amostra observada. Eles não devem ser identificados automaticamente com as probabilidades *a priori* π_k utilizadas na classificação probabilística.

Considere agora uma direção

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0}.$$

Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

sua coordenada projetada é

$$z = \mathbf{a}^\top \mathbf{x}.$$

Depois da projeção, a dispersão intragrupos é

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a},$$

enquanto a dispersão entre os centroides, ponderada pelos tamanhos dos grupos, é

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}.$$

Definição 19.8 (Critério amostral de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p}$$

matrizes simétricas tais que

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Para

$$\mathbf{a} \in \mathbb{R}^p, \quad \mathbf{a} \neq \mathbf{0},$$

o critério amostral de Fisher é

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}. \quad (19.29)$$

O numerador mede a dispersão dos centroides projetados em torno da média global projetada, ponderada pelos tamanhos dos grupos, enquanto o denominador mede a dispersão das observações em torno dos centroides de seus grupos na mesma direção.

Como

$$J_F(c\mathbf{a}) = J_F(\mathbf{a}), \quad c \neq 0,$$

o critério identifica direções, e não vetores com comprimento determinado.

Maximizar $J_F(\mathbf{a})$ corresponde a procurar uma combinação das características na qual a separação entre grupos seja elevada relativamente à dispersão intragrupos. A construção é supervisionada porque os rótulos dos grupos determinam diretamente $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$.

A Figura 19.2 compara duas projeções das mesmas observações. A primeira utiliza a direção que une os centroides; a segunda utiliza a direção determinada pelo critério de Fisher. Os escores são padronizados pelo desvio padrão intragrupos para tornar comparáveis as duas projeções.

A figura ilustra o critério da Equação 19.29 em uma escala padronizada pela dispersão intragrupos. A direção de Fisher é escolhida para maximizar a dispersão entre grupos relativamente à dispersão intragrupos, enquanto a direção que une os centroides considera apenas sua separação no espaço original.

19.8 Direções discriminantes e autovalores generalizados

O critério definido na Equação 19.29 é o quociente de Rayleigh generalizado definido na Definição 5.12, aplicado ao par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}}).$$

Pelo Teorema 5.8, os extremos de

$$J_F(\mathbf{a})$$

são determinados pelo problema




Figura 19.2: Projeção das mesmas duas classes na direção que une os centroides e na direção de Fisher. A direção discriminante aumenta a separação entre os grupos relativamente à dispersão intragrupos.

$$\mathbf{T}_{\text{entre}} \mathbf{a} = \lambda \mathbf{T}_{\text{intra}} \mathbf{a}. \quad (19.30)$$

A Equação 19.30 é um problema de autovalores generalizados no sentido da Definição 5.11. Nessa expressão, $\mathbf{a}$ representa uma direção genérica. As soluções normalizadas serão denotadas por α_j .

19.8.1 Geometria pela dispersão intragrupos

Como

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

sua raiz quadrada principal, definida na Definição 5.9, também é positiva definida e, portanto, invertível.

A mudança de métrica está relacionada ao branqueamento dos pontos pela Equação 8.50. Como os pontos são transformados por $\mathbf{T}_{\text{intra}}^{-1/2}$, a direção correspondente no espaço transformado é definida por

$$\mathbf{u} = \mathbf{T}_{\text{intra}}^{1/2} \mathbf{a}.$$

Então,

$$\mathbf{a} = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{u},$$

e a Equação 19.30 torna-se

$$\mathbf{M}_F \mathbf{u} = \lambda \mathbf{u},$$

em que

$$\mathbf{M}_F = \mathbf{T}_{\text{intra}}^{-1/2} \mathbf{T}_{\text{entre}} \mathbf{T}_{\text{intra}}^{-1/2} \in \mathbb{R}^{p \times p}. \quad (19.31)$$

A matriz $\mathbf{M}_F$ é simétrica e semidefinida positiva. Como $\mathbf{T}_{\text{intra}}^{-1/2}$ é invertível,

$$\text{posto}(\mathbf{M}_F) = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

A matriz $\mathbf{M}_F$ possui exatamente r_F autovalores positivos. Esses autovalores coincidem com os autovalores generalizados do par

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}})$$

e, na Análise Discriminante, são denominados **raízes discriminantes de Fisher**.

Definição 19.9 (Direções discriminantes de Fisher). Sejam

$$\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{T}_{\text{entre}} \succeq \mathbf{0} \quad \text{e} \quad \mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Defina

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}).$$

Se $r_F \geq 1$, as **direções discriminantes de Fisher** são autovetores generalizados

$$\alpha_1, \dots, \alpha_{r_F} \in \mathbb{R}^p$$

associados às raízes positivas

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{r_F} > 0$$

e escolhidos com a normalização

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_\ell = \begin{cases} 1, & j = \ell, \\ 0, & j \neq \ell. \end{cases} \quad (19.32)$$

Sob essa condição,

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j.$$

Se

$$r_F = 0,$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva entre os centroides.

Para a primeira direção,

$$J_F(\alpha_1) = \lambda_1 = \max_{\mathbf{a} \neq \mathbf{0}} J_F(\mathbf{a}).$$

A condição de normalização da Equação 19.32 implica, para cada j ,

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1. \quad (19.33)$$

Consequentemente,

$$\alpha_j^\top \mathbf{T}_{\text{entre}} \alpha_j = \lambda_j. \quad (19.34)$$

Cada raiz λ_j é, portanto, a dispersão entre grupos na direção α_j quando a dispersão intragrupos nessa direção é normalizada para 1.

Quando $r_F \geq 1$, a participação relativa de cada raiz na soma das raízes discriminantes positivas é

$$\frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell}, \quad j = 1, \dots, r_F. \quad (19.35)$$

Essas participações somam 1:

$$\sum_{j=1}^{r_F} \frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell} = 1.$$

A razão

$$\frac{\lambda_j}{\sum_{\ell=1}^{r_F} \lambda_\ell}$$

descreve a participação relativa da direção j na soma das raízes discriminantes positivas. Ela não representa uma proporção da variância total das características, como ocorre na ACP. As raízes de Fisher quantificam separação entre grupos relativamente à dispersão intragrupos, de modo que sua interpretação permanece vinculada ao critério discriminante.

Como $\mathbf{T}_{\text{intra}} \succ \mathbf{0}$, ela induz o produto interno definido na Definição 3.16. A ortogonalidade expressa pela Equação 19.32 é, portanto, a ortogonalidade nessa geometria. Pela Proposição 5.8, direções associadas a raízes distintas podem ser escolhidas ortogonais nessa métrica. Em geral,

$$\alpha_j^\top \alpha_\ell$$

não precisa ser zero para

$$j \neq \ell.$$

19.8.2 Número de direções discriminantes

Pelo limite de posto estabelecido na Equação 8.101,

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, K - 1).$$

Como

$$r_F = \text{posto}(\mathbf{T}_{\text{entre}}),$$

segue que

$$r_F \leq \min(p, K - 1). \quad (19.36)$$

O limite decorre de duas restrições. A separação ocorre em um espaço de dimensão p , e os K centroides centralizados em torno da média global podem gerar no máximo $K - 1$ direções linearmente independentes.

Assim, dois grupos produzem no máximo uma direção discriminante, e K grupos produzem no máximo $K - 1$, sem ultrapassar a dimensão original p .

O subespaço gerado por

$$\alpha_1, \dots, \alpha_{r_F}$$

é o subespaço discriminante de Fisher. As coordenadas das observações e dos centroides nesse subespaço são definidas na Seção 19.9.

19.9 Representação no subespaço discriminante

As direções

$$\alpha_1, \dots, \alpha_{r_F}$$

definidas na Definição 19.9 determinam um subespaço supervisionado de dimensão

$$r_F \leq \min(p, K - 1).$$

As combinações lineares associadas a essas direções produzem coordenadas construídas especificamente para representar a separação entre os grupos relativamente à dispersão intragrupos.

Definição 19.10 (Coordenadas discriminantes). Considere as direções discriminantes normalizadas

$$\alpha_1, \dots, \alpha_{r_F} \in \mathbb{R}^p$$

e a média global amostral

$$\bar{\mathbf{x}} \in \mathbb{R}^p.$$

A **função discriminante de Fisher** j é a aplicação

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}}), \quad j = 1, \dots, r_F. \quad (19.37)$$

Para uma observação

$$\mathbf{x} \in \mathbb{R}^p,$$

o valor $z_j(\mathbf{x})$ é sua **coordenada discriminante** j , também denominada **escore discriminante** j .

O vetor de coordenadas discriminantes é

$$\mathbf{z}(\mathbf{x}) = \begin{pmatrix} z_1(\mathbf{x}) \\ \vdots \\ z_{r_F}(\mathbf{x}) \end{pmatrix} \in \mathbb{R}^{r_F}. \quad (19.38)$$

A denominação **coordenada discriminante** destaca a posição da observação no subespaço de Fisher; **escore discriminante** designa o mesmo valor numérico quando calculado para uma observação.

A centralização coloca a média global na origem da representação. Utilizar

$$\alpha_j^\top \mathbf{x}$$

sem centralização preservaria as diferenças entre observações e centroides, modificando apenas a origem das coordenadas.

O centroide do grupo k na dimensão discriminante j é

$$\bar{z}_{kj} = \alpha_j^\top (\bar{\mathbf{x}}_k - \bar{\mathbf{x}}). \quad (19.39)$$

A representação é supervisionada porque

$$\alpha_1, \dots, \alpha_{r_F}$$

dependem de $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, que são construídas a partir dos grupos conhecidos. Alterações nos rótulos ou na composição dos grupos podem modificar o subespaço discriminante.

No segundo painel, as direções são determinadas pelo problema espectral de Fisher. A transformação por

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

transforma a matriz de dispersão intragrupos em uma matriz identidade, e os autovetores de

$$\mathbf{M}_F$$

identificam as direções de maior dispersão entre grupos nesse espaço transformado.




Figura 19.3: Representação de três grupos em duas características originais e nas duas coordenadas discriminantes de Fisher. As coordenadas são construídas especificamente para representar a separação entre os grupos.

No segundo painel, as direções são determinadas pelo problema espectral de Fisher. A transformação por

$$\mathbf{T}_{\text{intra}}^{-1/2}$$

padroniza a dispersão intragrupos, e os autovetores de

$$\mathbf{M}_F$$

identificam as direções de maior separação entre os centroides nesse espaço transformado.

A construção difere da ACP. No Capítulo 14, as direções são escolhidas pela variabilidade total; em Fisher, são escolhidas pela separação entre grupos relativamente à dispersão intragrupos.

19.10 Relação espectral com a MANOVA

Considere a MANOVA de um fator em que os K níveis do fator correspondem aos mesmos K grupos utilizados na formulação de Fisher e a hipótese nula é a igualdade dos vetores de médias desses grupos. Nessa configuração, a matriz de erro da MANOVA coincide com a dispersão intragrupos,

$$\mathbf{E} = \mathbf{T}_{\text{intra}},$$

e a matriz de hipótese coincide com a dispersão entre grupos,

$$\mathbf{H} = \mathbf{T}_{\text{entre}}. \quad (19.40)$$

Assim, para essa hipótese de comparação entre os grupos, o problema de Fisher

$$\mathbf{T}_{\text{entre}}\alpha_j = \lambda_j \mathbf{T}_{\text{intra}}\alpha_j$$

coincide com o problema de autovalores generalizados desenvolvido no Capítulo 18.

As raízes positivas e os autoespaços generalizados associados são, portanto, os mesmos quando as matrizes de hipótese e erro da MANOVA correspondem, respectivamente, às dispersões entre e dentro dos grupos.

O significado estatístico da solução depende da técnica. Na MANOVA, Wilks, Pillai e Hotelling–Lawley combinam a coleção de raízes de formas distintas, enquanto Roy utiliza a maior raiz para avaliar a hipótese multivariada. Na formulação de Fisher, os autovetores generalizados associados às raízes positivas definem direções utilizadas para representar a separação entre os grupos.

A coincidência algébrica não implica coincidência de objetivos: a MANOVA utiliza as raízes para construir critérios de teste de hipóteses sobre os vetores de médias, enquanto Fisher utiliza os autovetores generalizados para construir direções discriminantes.

19.11 Dois grupos e relação entre Fisher e LDA

Quando

$$K = 2,$$

a matriz de dispersão entre grupos possui posto no máximo 1. Existe, portanto, no máximo uma direção discriminante associada a uma raiz positiva.

Defina

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2. \quad (19.41)$$

Para dois grupos,

$$\mathbf{T}_{\text{entre}} = \frac{n_1 n_2}{n_1 + n_2} \mathbf{d} \mathbf{d}^\top. \quad (19.42)$$

Se

$$\mathbf{d} = \mathbf{0},$$

então

$$\mathbf{T}_{\text{entre}} = \mathbf{0},$$

e não existe direção com separação amostral positiva.

Suponha agora

$$\mathbf{d} \neq \mathbf{0}$$

e

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0}.$$

Como $\mathbf{T}_{\text{entre}}$ na Equação 19.42 possui posto 1, a única direção discriminante associada a uma raiz positiva satisfaz

$$\alpha_1 \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (19.43)$$

A diferença

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$$

representa a separação bruta entre os centroides. A multiplicação por

$$\mathbf{T}_{\text{intra}}^{-1}$$

repondera essa separação segundo a dispersão e as associações existentes dentro dos grupos.

A direção de Fisher não é, portanto, determinada apenas pela distância entre os centroides. Diferenças que ocorrem em direções de elevada dispersão intragrupos recebem menor peso relativo do que diferenças de mesma magnitude em direções de menor dispersão.

19.11.1 Formulação populacional para dois grupos

Para dois grupos, a formulação populacional também conduz a uma única direção discriminante determinada pela diferença entre os vetores de médias condicionais e pela dispersão populacional intragrupos.

Considere

$$P(C = 1) = \pi_1, \quad P(C = 2) = \pi_2,$$

com

$$\pi_1 + \pi_2 = 1,$$

e defina

$$\mathbf{d}_\mu = \mu_1 - \mu_2.$$

A dispersão entre grupos é

$$\Sigma_B = \pi_1 \pi_2 \mathbf{d}_\mu \mathbf{d}_\mu^\top.$$

Se

$$\Sigma_W \succ \mathbf{0}$$

e

$$\mu_1 \neq \mu_2,$$

uma direção que maximiza o critério populacional de Fisher satisfaz

$$\mathbf{a}_F \propto \Sigma_W^{-1} (\mu_1 - \mu_2). \quad (19.44)$$

Esse resultado depende dos vetores de médias condicionais e da matriz Σ_W , construída a partir das covariâncias condicionais, e não exige normalidade multivariada.

Se, adicionalmente, as duas classes seguem distribuições normais com matriz de covariâncias comum

$$\Sigma,$$

então

$$\Sigma_W = \Sigma,$$

e a direção definida pela Equação 19.44 torna-se

$$\mathbf{a}_F \propto \Sigma^{-1} (\mu_1 - \mu_2).$$

A direção de Fisher é paralela ao vetor normal da fronteira da LDA dado pela Equação 19.9. Essa correspondência envolve a orientação da fronteira, e não a regra completa de classificação: sob perda zero-um, as probabilidades *a priori* também determinam sua posição; com perdas gerais, a decisão ótima depende ainda da função de perda. A Seção 19.14.5 demonstra essa correspondência.

19.11.2 Mais de dois grupos

Quando

$$K > 2,$$

a matriz

$$\mathbf{T}_{\text{entre}}$$

pode possuir posto superior a 1, e Fisher pode produzir

$$r_F \leq \min(p, K - 1)$$

direções discriminantes.

A LDA, por sua vez, não precisa construir previamente as direções nem as coordenadas discriminantes de Fisher. Sua regra compara diretamente

$$\delta_1(\mathbf{x}), \dots, \delta_K(\mathbf{x})$$

no espaço original das características.

As direções de Fisher fornecem uma representação supervisionada da separação entre os grupos; a LDA fornece uma regra probabilística de decisão. Sob a formulação normal com covariância comum da LDA, ambas utilizam os vetores de médias das classes e a dispersão intragrupos, mas esses objetos entram em critérios com objetivos distintos.

19.12 Pressupostos e limites

Fisher, LDA e QDA exigem condições diferentes. O critério populacional de Fisher depende dos vetores de médias e das matrizes de covariâncias condicionais, enquanto sua versão amostral utiliza as dispersões calculadas a partir dos grupos observados. As formulações baseadas em inversas exigem não singularidade das matrizes correspondentes. LDA e QDA acrescentam hipóteses probabilísticas para especificar as distribuições condicionais normais, e suas regras estimadas exigem condições amostrais de posto.

A Tabela [19.3](#) reúne essas condições.

Tabela 19.3: Condições das formulações de Fisher, LDA e QDA.

Condição	Fisher geométrico	LDA normal	QDA normal
grupos previamente definidos	necessária	necessária	necessária
segundos momentos finitos	necessários na formulação populacional	satisfeitos sob normalidade	satisfeitos sob normalidade
normalidade multivariada	não necessária para definir o critério	assumida	assumida
covariância comum entre classes	não necessária	assumida	não assumida
não singularidade populacional	$\Sigma_W \succ \mathbf{0}$ na forma baseada em inversas	$\Sigma \succ \mathbf{0}$	$\Sigma_k \succ \mathbf{0}$ para cada classe
não singularidade amostral	$\mathbf{T}_{\text{intra}} \succ \mathbf{0}$ na forma baseada em inversas	$\mathbf{S}_p \succ \mathbf{0}$	$\mathbf{S}_k \succ \mathbf{0}$ para cada classe
probabilidades <i>a priori</i>	ponderam as dispersões populacionais	entram na regra de decisão	entram na regra de decisão
função de perda	não entra no critério	perda zero-um na regra básica	perda zero-um na regra básica

19.12.1 Grupos previamente definidos

A Análise Discriminante utiliza rótulos conhecidos durante a construção da solução.

Na formulação de Fisher, esses rótulos determinam

$$\mathbf{T}_{\text{intra}} \quad \text{e} \quad \mathbf{T}_{\text{entre}}.$$

Na formulação probabilística, eles determinam quais observações caracterizam cada distribuição condicional

$$\mathbf{X} \mid \mathbf{C} = k.$$

A técnica não constrói os grupos a partir dos dados. Se os rótulos utilizados não representarem as classes que se deseja discriminar ou classificar, a solução continuará descrevendo apenas os grupos fornecidos.

19.12.2 Normalidade e estrutura das covariâncias

A normalidade multivariada não é necessária para definir o critério populacional de Fisher,

$$J_F^{(P)}(\mathbf{a}),$$

nem sua versão amostral,

$$J_F(\mathbf{a}).$$

Na formulação probabilística geral, a regra de Bayes também não exige normalidade. A normalidade multivariada é introduzida na especialização da regra de Bayes que conduz à LDA e à QDA.

Na LDA,

$$\Sigma_1 = \dots = \Sigma_K = \Sigma,$$

com

$$\Sigma \succ \mathbf{0}.$$

A matriz comum faz com que os termos quadráticos em $\mathbf{x}$ sejam iguais nas comparações entre classes e se cancelem, produzindo fronteiras lineares.

Na QDA,

$$\Sigma_k \succ \mathbf{0}, \quad k = 1, \dots, K,$$

e as matrizes podem diferir entre classes. Quando as matrizes das classes comparadas são distintas, os termos quadráticos em $\mathbf{x}$ não se cancelam em geral, e a fronteira pode ser quadrática.

A condição de covariância comum pertence, portanto, à formulação normal da LDA e não é necessária para definir o critério geométrico de Fisher.

Algumas apresentações clássicas de Fisher para várias populações adotam adicionalmente uma matriz de covariâncias comum e de posto completo (Johnson; Wichern, 2002). Sob essa condição, a separação de Fisher relaciona-se diretamente ao modelo normal com covariância comum da LDA. O critério geométrico definido pela Equação 19.28 utiliza, de forma mais geral, a dispersão média intragrupos Σ_W .

19.12.3 Não singularidade e dimensão

A forma baseada em inversas do critério populacional de Fisher pressupõe

$$\Sigma_W \succ \mathbf{0}.$$

Essa condição garante

$$\mathbf{a}^\top \Sigma_W \mathbf{a} > 0$$

para todo

$$\mathbf{a} \neq \mathbf{0}$$

e permite utilizar

$$\Sigma_W^{-1} \quad \text{e} \quad \Sigma_W^{-1/2}.$$

A positividade definida de Σ_W é uma condição sobre a média ponderada das matrizes de covariâncias condicionais e não depende de normalidade.

Na formulação amostral,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - K). \quad (19.45)$$

Consequentemente,

$$n - K \geq p \quad (19.46)$$

é uma condição necessária para que

$$\mathbf{T}_{\text{intra}}$$

possa possuir posto completo.

Ela não é suficiente para um conjunto de dados arbitrário. Dependências lineares exatas entre as características dentro dos grupos podem tornar $\mathbf{T}_{\text{intra}}$ singular mesmo quando

$$n - K \geq p.$$

Quando

$$p > n - K,$$

a singularidade é inevitável.

Na LDA estimada,

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}},$$

de modo que

$$\text{posto}(\mathbf{S}_p) = \text{posto}(\mathbf{T}_{\text{intra}}).$$

A regra clássica estimada da LDA e a formulação amostral clássica de Fisher compartilham, portanto, a mesma condição de invertibilidade da dispersão intragrupo.

Na QDA, cada classe possui sua própria matriz de covariâncias amostral. Para a classe k ,

$$\text{posto}(\mathbf{S}_k) \leq \min(p, n_k - 1).$$

Assim,

$$n_k - 1 \geq p \tag{19.47}$$

é condição necessária para que $\mathbf{S}_k$ possa possuir posto completo. Essa condição deve ser satisfeita separadamente em cada classe.

A QDA estimada impõe, portanto, uma condição de posto separada em cada classe e se torna particularmente exigente em tamanho amostral quando p é elevado.

A não singularidade, entretanto, não garante estabilidade. O problema está relacionado ao número de condição definido na Definição 6.9. Quando algumas características são aproximadamente combinações lineares de outras, $\mathbf{T}_{\text{intra}}$, $\mathbf{S}_p$ ou alguma $\mathbf{S}_k$ podem permanecer invertíveis, mas apresentar autovalores muito pequenos. Nesse caso, suas inversas podem amplificar pequenas perturbações dos dados e tornar coeficientes e direções discriminantes sensíveis à amostra.

Esse problema deve ser distinguido da singularidade exata. Associação entre características é esperada em dados multivariados; quase dependência linear pode produzir mau condicionamento; dependência linear exata pode reduzir o posto das matrizes necessárias.

Quando as matrizes são singulares, as formulações clássicas baseadas em inversas e raízes quadradas inversas não estão definidas diretamente. Pseudoinversas, regularização e redução preliminar de dimensão correspondem a extensões que modificam essas formulações.

19.12.4 Independência das unidades de treinamento

As estatísticas

$$\bar{\mathbf{x}}_k, \quad \mathbf{S}_k \quad \text{e} \quad \mathbf{S}_p$$

podem ser calculadas a partir das observações sem exigir independência.

Para interpretar probabilisticamente essas estatísticas sob o esquema amostral clássico, as unidades de treinamento são tratadas como independentes e, dentro de cada classe, como observações da distribuição condicional especificada para essa classe.

Dependência temporal, espacial, longitudinal ou decorrente de agrupamentos viola a independência das unidades pressuposta pelo esquema amostral clássico e requer uma formulação probabilística que represente essa dependência. O critério algébrico de Fisher, isoladamente, não modela a dependência entre unidades.

19.12.5 Probabilidades *a priori* e perdas

As probabilidades

$$\pi_k = P(\mathbf{C} = k)$$

desempenham funções diferentes nas duas formulações do capítulo.

Na classificação probabilística, elas representam as probabilidades *a priori* das classes e entram nas funções LDA e QDA pelo termo

$$\log \pi_k.$$

Na formulação populacional de Fisher, as probabilidades π_k aparecem como pesos na construção de

$$\Sigma_W \quad \text{e} \quad \Sigma_B.$$

Nesse critério, elas ponderam as dispersões populacionais das classes e não determinam uma ação de classificação.

Na formulação amostral de Fisher, o critério utiliza $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, cujos pesos decorrem dos tamanhos observados n_k . A razão n_k/n coincide com a estimativa empírica de π_k definida pela Equação 19.17 somente quando a amostra de treinamento representa a mistura populacional das classes.

A função de perda pertence ao problema de decisão e não ao critério geométrico de Fisher. Sob perda zero-um, a regra de Bayes reduz-se à escolha da maior probabilidade posterior; quando diferentes erros possuem consequências distintas, a decisão ótima pode mudar mesmo que as densidades condicionais e as probabilidades *a priori* permaneçam inalteradas.

19.12.6 Sobreposição entre as classes

Mesmo quando os parâmetros populacionais são conhecidos e o modelo probabilístico está corretamente especificado, a classificação pode apresentar erro.

Se duas classes atribuem densidade positiva à mesma região do espaço das características, uma observação nessa região não determina unicamente sua classe de origem.

A regra de Bayes escolhe a ação de menor risco condicional, mas esse risco mínimo pode ser positivo. Sob perda zero-um, a probabilidade global de classificação incorreta alcançada pela regra de Bayes é denominada **erro de Bayes**.

Quando as distribuições das classes se sobrepõem, esse erro pode ser positivo mesmo que os parâmetros populacionais sejam conhecidos exatamente. Existe, portanto, uma parcela do erro de classificação associada à própria dificuldade de separar as populações no espaço das características.

O erro de Bayes deve ser distinguido do erro populacional da regra estimada, isto é, da probabilidade de classificação incorreta que a regra obtida da amostra de treinamento apresenta em novas unidades da população de aplicação. Sob perda zero-um, para uma regra estimada fixada, esse erro não pode ser inferior ao erro de Bayes; a diferença entre ambos é o excesso de erro em relação à regra de Bayes.

Validação cruzada, conjunto de teste *holdout* e amostra independente estimam o desempenho da regra em regimes que evitam, em graus diferentes, avaliar exclusivamente as observações utilizadas no ajuste. Matrizes de classificação e medidas de desempenho resumem os erros produzidos nesses regimes; ver Seção 19.15.

19.13 Relações com outras técnicas

Quando a MANOVA compara os vetores de médias correspondentes à mesma partição em grupos utilizada por Fisher, a correspondência formalizada na Equação 19.40 faz com que as duas formulações conduzam ao mesmo problema de autovalores generalizados. A diferença

está no objetivo estatístico: o Capítulo 18 utiliza as raízes para construir critérios de teste, enquanto Fisher utiliza os autovetores associados para representar a separação entre grupos.

A Análise Discriminante também se distingue da Capítulo 14 e do Capítulo 16 pelo papel dos grupos na formulação. Em Fisher, os grupos são conhecidos previamente e seus rótulos participam da construção das direções discriminantes.

19.13.1 Análise de Componentes Principais

O Capítulo 14 e a formulação de Fisher constroem combinações lineares, mas utilizam critérios diferentes.

Na ACP, as direções são determinadas pela variabilidade total. Em Fisher, a direção genérica $\mathbf{a}$ é avaliada por

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}},$$

de modo que a separação entre os grupos é comparada com a dispersão existente dentro deles.

A Tabela 19.4 sintetiza essa distinção.

Tabela 19.4: Comparação entre ACP e a formulação de Fisher.

Aspecto	ACP	Fisher
informação sobre grupos	não utilizada	utilizada
objeto matricial principal	covariância ou correlação total	dispersões entre e dentro dos grupos
critério	variabilidade total	separação entre grupos relativa à dispersão intragrupos
representação	não supervisionada em relação aos grupos	supervisionada
dimensão máxima não nula	limitada pelo posto da matriz analisada	$\min(p, K - 1)$
interpretação das direções	variabilidade	separação relativa

Uma direção de elevada variabilidade total não precisa apresentar elevada capacidade de separação entre grupos. Fisher utiliza os rótulos dos grupos para construir $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$, enquanto a ACP não utiliza esses rótulos na determinação das componentes.

19.13.2 Análise de Agrupamentos

A Análise Discriminante e o Capítulo 16 utilizam objetos como centroides, distâncias e dispersões, mas partem de problemas distintos.

Na Análise Discriminante, os grupos são conhecidos e seus rótulos participam da construção das regras de classificação ou das direções de Fisher. Na Análise de Agrupamentos, os grupos não são fornecidos previamente e devem ser construídos a partir de critérios de proximidade, dispersão ou modelagem probabilística.

Na Análise Discriminante, os rótulos dos grupos fazem parte dos dados de entrada. Na Análise de Agrupamentos, os grupos são construídos pela própria análise.

19.14 Aprofundamentos teóricos

Leitura de aprofundamento

Esta parte aprofunda a base decisória, probabilística, algébrica e espectral da Análise Discriminante. São examinadas a formulação por perdas e risco, a relação entre separação de Mahalanobis e erro de classificação sob normalidade, a forma explícita da fronteira quadrática, a decomposição populacional da covariância por grupos, as relações populacional e amostral entre Fisher e LDA e as condições de identificação das direções discriminantes.

19.14.1 Perdas e risco de classificação

A regra de máxima probabilidade posterior obtida no núcleo é a regra de Bayes sob perda zero-um, na qual uma classificação correta recebe perda 0 e uma classificação incorreta recebe perda 1. Com uma função de perda geral, a decisão ótima escolhe a ação que minimiza a perda esperada posterior, denominada risco condicional.

Definição 19.11 (Perda de classificação). Considere o conjunto de ações

$$\mathcal{A} = \{1, \dots, K\}.$$

Uma **função de perda de classificação** é uma função

$$L : \mathcal{A} \times \{1, \dots, K\} \longrightarrow [0, \infty)$$

tal que

$$L(a, k)$$

quantifica a consequência de escolher a ação a quando a classe verdadeira é k .

Os valores

$$L(k, k)$$

correspondem às classificações corretas, enquanto

$$L(a, k), \quad a \neq k,$$

correspondem aos diferentes tipos de erro. A função L pode atribuir perdas distintas a diferentes classificações incorretas.

Definição 19.12 (Risco condicional de classificação). Para uma observação $\mathbf{x}$ na qual as probabilidades posteriores estão definidas, o **risco condicional** de escolher a ação

$$a \in \mathcal{A}$$

é

$$R(a | \mathbf{x}) = \sum_{k=1}^K L(a, k) P(C = k | \mathbf{X} = \mathbf{x}). \quad (19.48)$$

O risco condicional é a perda esperada associada a uma ação depois de observadas as características $\mathbf{x}$. Cada perda $L(a, k)$ é ponderada pela probabilidade posterior de que k seja a classe verdadeira.

Para uma regra de classificação

$$\psi : \mathbb{R}^p \longrightarrow \mathcal{A},$$

seu risco global é

$$R(\psi) = E[L(\psi(\mathbf{X}), C)]. \quad (19.49)$$

Pela lei da esperança total,

$$R(\psi) = E[R(\psi(\mathbf{X}) \mid \mathbf{X})].$$

Assim, escolher em cada observação uma ação que minimize o risco condicional também minimiza o risco global. O menor risco alcançável é o **risco de Bayes**,

$$R_B = E \left[\min_{a \in \mathcal{A}} R(a \mid \mathbf{X}) \right]. \quad (19.50)$$

Sob perda zero-um, R_B coincide com a probabilidade global de classificação incorreta da regra de Bayes.

Definição 19.13 (Regra de Bayes para classificação). Para cada observação $\mathbf{x}$, defina o conjunto de ações que minimizam o risco condicional por

$$\mathcal{A}_B(\mathbf{x}) = \arg \min_{a \in \mathcal{A}} R(a \mid \mathbf{x}). \quad (19.51)$$

Uma **regra de Bayes** é qualquer função

$$\psi_B : \mathbb{R}^p \longrightarrow \mathcal{A}$$

tal que

$$\psi_B(\mathbf{x}) \in \mathcal{A}_B(\mathbf{x})$$

sempre que os riscos condicionais estejam definidos.

Quando mais de uma ação minimiza o risco, uma regra de desempate pode ser especificada para produzir uma classificação única.

A regra de Bayes depende conjuntamente das distribuições condicionais, das probabilidades *a priori* e da função de perda. Sob perda zero-um, minimizar o risco condicional equivale a maximizar a probabilidade posterior, conforme a Equação 19.3. Com perdas assimétricas, a classe de maior probabilidade posterior não precisa ser a ação que minimiza o risco (Anderson, 2003).

19.14.2 Erro de classificação e separação de Mahalanobis

Considere duas classes sob o modelo normal da LDA,

$$\mathbf{X} \mid (\mathbf{C} = k) \sim N_p(\mu_k, \Sigma), \quad k = 1, 2,$$

com

$$\Sigma \succ \mathbf{0}$$

e

$$\mu_1 \neq \mu_2.$$

A separação entre os vetores de médias na métrica definida pela matriz de covariâncias comum pode ser expressa por

$$\Delta^2 = (\mu_1 - \mu_2)^\top \Sigma^{-1} (\mu_1 - \mu_2). \quad (19.52)$$

Assim,

$$\Delta = d_M(\mu_1, \mu_2; \Sigma)$$

é a distância de Mahalanobis entre os vetores de médias das duas classes.

Sob perda zero-um, a comparação entre as duas classes pode ser realizada pela diferença entre suas funções discriminantes lineares de classe,

$$D(\mathbf{x}) = \delta_1(\mathbf{x}) - \delta_2(\mathbf{x}).$$

Pelas funções discriminantes lineares de classe definidas na Equação 19.6, essa diferença pode ser escrita como

$$D(\mathbf{x}) = (\mu_1 - \mu_2)^\top \Sigma^{-1} \left[\mathbf{x} - \frac{\mu_1 + \mu_2}{2} \right] + \log \frac{\pi_1}{\pi_2}. \quad (19.53)$$

A observação é atribuída à classe 1 quando

$$D(\mathbf{x}) > 0$$

e à classe 2 quando

$$D(\mathbf{x}) < 0.$$

Como $D(\mathbf{X})$ é uma combinação linear de um vetor normal, sua distribuição condicional também é normal. Se a observação pertence à classe 1,

$$D(\mathbf{X}) \mid (\mathbf{C} = 1) \sim N\left(\frac{\Delta^2}{2} + \log \frac{\pi_1}{\pi_2}, \Delta^2\right),$$

enquanto, para a classe 2,

$$D(\mathbf{X}) \mid (\mathbf{C} = 2) \sim N\left(-\frac{\Delta^2}{2} + \log \frac{\pi_1}{\pi_2}, \Delta^2\right). \quad (19.54)$$

Se Φ denota a função de distribuição acumulada da normal padrão, a probabilidade condicional de classificar incorretamente uma observação da classe 1 é

$$P[\psi_B(\mathbf{X}) = 2 \mid \mathbf{C} = 1] = \Phi\left(-\frac{\Delta}{2} - \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right), \quad (19.55)$$

e, para uma observação da classe 2,

$$P[\psi_B(\mathbf{X}) = 1 \mid \mathbf{C} = 2] = \Phi\left(-\frac{\Delta}{2} + \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right). \quad (19.56)$$

Sob perda zero-um, o erro global da regra de Bayes é, portanto,

$$\begin{aligned} R_B &= \pi_1 \Phi\left(-\frac{\Delta}{2} - \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right) \\ &\quad + \pi_2 \Phi\left(-\frac{\Delta}{2} + \frac{1}{\Delta} \log \frac{\pi_1}{\pi_2}\right). \end{aligned} \quad (19.57)$$

Quando as probabilidades *a priori* são iguais,

$$\pi_1 = \pi_2 = \frac{1}{2},$$

os dois tipos de erro possuem a mesma probabilidade,

$$P[\psi_B(\mathbf{X}) = 2 \mid \mathbf{C} = 1] = P[\psi_B(\mathbf{X}) = 1 \mid \mathbf{C} = 2] = \Phi\left(-\frac{\Delta}{2}\right),$$

e o erro de Bayes reduz-se a

$$R_B = \Phi\left(-\frac{\Delta}{2}\right). \quad (19.58)$$

Para probabilidades *a priori* iguais, a Equação 19.58 mostra que R_B é uma função estritamente decrescente de Δ . Em particular,

$$\Delta \rightarrow 0 \quad \Rightarrow \quad R_B \rightarrow \frac{1}{2},$$

enquanto

$$\Delta \rightarrow \infty \quad \Rightarrow \quad R_B \rightarrow 0.$$

Sob normalidade, covariância comum, perda zero-um e parâmetros populacionais conhecidos, maior distância de Mahalanobis entre os vetores de médias implica menor erro de Bayes. Com probabilidades *a priori* desiguais, as probabilidades condicionais de erro dependem também de $\log(\pi_1/\pi_2)$, que desloca a fronteira de classificação e pode produzir erros diferentes nas duas classes (Anderson, 2003; Johnson; Wichern, 2002).

O valor R_B é o menor erro populacional possível sob o modelo e a perda considerados. Quando μ_1, μ_2 e Σ são substituídos por estimativas, obtém-se uma regra amostral cujo erro populacional é, em geral, maior que R_B .

19.14.3 Forma explícita da fronteira quadrática

Na QDA, a fronteira entre as classes k e h contém termos quadrático, linear e constante. Na Equação 19.15, esses termos são determinados por

$$\mathbf{A}_{kh} = \frac{1}{2} (\Sigma_h^{-1} - \Sigma_k^{-1}),$$

$$\mathbf{b}_{kh} = \Sigma_k^{-1} \mu_k - \Sigma_h^{-1} \mu_h$$

e

$$\begin{aligned} c_{kh} = & -\frac{1}{2} \mu_k^\top \Sigma_k^{-1} \mu_k + \frac{1}{2} \mu_h^\top \Sigma_h^{-1} \mu_h \\ & - \frac{1}{2} \log |\Sigma_k| + \frac{1}{2} \log |\Sigma_h| + \log \frac{\pi_k}{\pi_h}. \end{aligned}$$

Assim, a diferença entre as inversas das matrizes de covariâncias determina o termo quadrático, a diferença $\Sigma_k^{-1}\mu_k - \Sigma_h^{-1}\mu_h$ determina o termo linear, e os vetores de médias, os determinantes das matrizes de covariâncias e as probabilidades *a priori* determinam o termo constante.

Se

$$\Sigma_k = \Sigma_h,$$

então

$$\mathbf{A}_{kh} = \mathbf{0},$$

recuperando-se uma fronteira linear.

19.14.4 Decomposição da covariância por grupos

A identidade $\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B$ decorre da lei da covariância total aplicada ao condicionamento pela variável de classe $\mathbf{C}$. A primeira parcela é a média das covariâncias condicionais, e a segunda é a covariância dos vetores de médias condicionais.

Escreva

$$\mathbf{X} - \mu = (\mathbf{X} - \mu_c) + (\mu_c - \mu),$$

em que

$$\mu_c = E(\mathbf{X} \mid \mathbf{C}).$$

Como

$$E[\mathbf{X} - \mu_c \mid \mathbf{C}] = \mathbf{0},$$

os termos cruzados possuem esperança nula. Assim,

$$\text{Cov}(\mathbf{X}) = E[\text{Cov}(\mathbf{X} \mid \mathbf{C})] + \text{Cov}[E(\mathbf{X} \mid \mathbf{C})],$$

o que fornece

$$\text{Cov}(\mathbf{X}) = \Sigma_W + \Sigma_B.$$

19.14.5 Relação com a discriminação linear normal

Considere a formulação normal da LDA especificada na Equação 19.5 para duas classes,

$$K = 2,$$

com matriz de covariâncias comum

$$\Sigma \succ \mathbf{0}.$$

Na LDA, o vetor normal à fronteira entre as duas classes é

$$\Sigma^{-1}(\mu_1 - \mu_2), \quad (19.59)$$

conforme a Equação 19.9.

Sob covariância condicional comum,

$$\Sigma_W = \pi_1 \Sigma + \pi_2 \Sigma = \Sigma.$$

Substituindo na Equação 19.44,

$$\mathbf{a}_F \propto \Sigma^{-1}(\mu_1 - \mu_2).$$

Assim, para duas populações com covariância comum, a direção populacional de Fisher é paralela ao vetor normal da fronteira da LDA.

Essa coincidência refere-se apenas à **orientação** da direção de Fisher e do vetor normal da fronteira da LDA; ela não torna equivalentes os dois problemas estatísticos.

Fisher procura uma direção que maximize

$$\frac{\mathbf{a}^\top \Sigma_B \mathbf{a}}{\mathbf{a}^\top \Sigma_W \mathbf{a}}.$$

A LDA utiliza as distribuições condicionais, as probabilidades *a priori* e a função de perda para construir uma regra de classificação.

Além do vetor normal que determina sua orientação, a fronteira da LDA depende dos termos constantes das funções discriminantes lineares de classe,

$$-\frac{1}{2}\mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k.$$

Consequentemente, mudanças nas probabilidades *a priori* podem deslocar a fronteira sem modificar sua orientação. Com funções de perda diferentes da perda zero-um, a regra ótima também pode mudar sem alterar o critério geométrico de Fisher.

19.14.6 Relação amostral entre Fisher e LDA

Para dois grupos, a mesma coincidência de orientação aparece na versão estimada. Quando as duas formulações são construídas a partir da mesma amostra de treinamento, a matriz de covariâncias agrupada da LDA é proporcional à matriz de dispersão intragrupos utilizada por Fisher. O vetor normal estimado da fronteira da LDA e a direção amostral de Fisher são, portanto, proporcionais.

Na amostra, a Equação 19.16 fornece

$$\mathbf{S}_p = \frac{1}{n - K} \mathbf{T}_{\text{intra}}.$$

Consequentemente,

$$\mathbf{S}_p^{-1} = (n - K) \mathbf{T}_{\text{intra}}^{-1},$$

quando as duas matrizes são não singulares.

Para

$$K = 2,$$

segue que

$$\mathbf{S}_p^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \propto \mathbf{T}_{\text{intra}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2). \quad (19.60)$$

Assim, quando a mesma estimativa agrupada de covariâncias é utilizada, a orientação estimada da fronteira da LDA coincide, até escala, com a direção amostral de Fisher.

A regra estimada da LDA não se reduz a essa direção. Para duas classes, a diferença $\hat{\delta}_1(\mathbf{x}) - \hat{\delta}_2(\mathbf{x})$ contém, além do vetor normal proporcional à direção de Fisher, termos constantes formados pelas médias estimadas e pelas probabilidades *a priori* adotadas; esses termos determinam a posição da fronteira.

19.14.7 Identificação das direções discriminantes

As direções de Fisher apresentam as indeterminações de sinal e multiplicidade do problema de autovalores generalizados descritas na Seção 18.9.4. Na Análise Discriminante, essas indeterminações referem-se aos autovetores generalizados de

$$(\mathbf{T}_{\text{entre}}, \mathbf{T}_{\text{intra}})$$

e ao subespaço discriminante que eles geram.

Para uma raiz positiva simples,

$$\lambda_j,$$

a direção normalizada

$$\alpha_j$$

satisfaz

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j$$

e

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1.$$

A normalização fixa a escala, mas permanece a indeterminação de sinal:

$$\alpha_j \quad \text{e} \quad -\alpha_j$$

representam o mesmo eixo discriminante.

A mudança de sinal transforma

$$z_j(\mathbf{x})$$

em

$$-z_j(\mathbf{x}),$$

sem modificar o subespaço nem as distâncias entre observações ou entre centroides projetados ao longo do eixo.

Quando uma raiz positiva possui multiplicidade maior que 1, as direções individuais associadas não são únicas. Como na Seção 18.9.4, diferentes bases ortonormais na métrica induzida por $\mathbf{T}_{\text{intra}}$ representam o mesmo autoespaço. Na formulação de Fisher, o objeto identificado é o subespaço discriminante associado à raiz repetida, e não uma base particular de direções.

19.15 Aprofundamentos metodológicos e aplicados

Leitura de aprofundamento

Esta parte trata das decisões de condução, interpretação e avaliação da Análise Discriminante: definição das probabilidades *a priori* e das perdas, avaliação das condições da análise, escolha entre LDA e QDA, interpretação das funções discriminantes e dos centroides, avaliação da classificação e correspondência com a implementação utilizada.

19.15.1 Definição das probabilidades *a priori* e consequências dos erros

A regra estimada requer probabilidades *a priori* para as classes. Os valores utilizados para essas probabilidades devem ser definidos antes da avaliação do desempenho da classificação, pois participam da própria regra e podem modificar as fronteiras e as classes atribuídas às observações.

Quando as proporções populacionais das classes são conhecidas ou podem ser estimadas por dados externos referentes à população na qual a regra será aplicada, esses valores podem ser utilizados como probabilidades *a priori*. As proporções observadas na amostra de treinamento podem cumprir essa função quando o mecanismo de amostragem permite interpretá-las como estimativas das proporções populacionais. Se os tamanhos dos grupos foram fixados pelo delineamento, balanceados intencionalmente ou obtidos por outro mecanismo que não reproduz a frequência das classes na população, as proporções amostrais não possuem essa interpretação.

Probabilidades iguais podem ser utilizadas quando se decide não incorporar à regra diferenças conhecidas nas frequências das classes ou quando as proporções populacionais não são conhecidas nem estimadas por dados externos. Essa escolha não implica que as classes sejam igualmente frequentes na população; ela atribui o mesmo peso *a priori* às classes na regra.

Quando diferentes tipos de erro possuem consequências distintas, a avaliação da regra não deve se limitar à proporção total de classificações corretas. A função de perda definida na Definição 19.11 representa essas diferenças por $L(a, k)$, a perda associada à ação a quando k é a classe verdadeira. Na condução da análise, as perdas devem ser definidas a partir do problema de decisão, e não escolhidas depois de observados os resultados da classificação.

19.15.2 Avaliação das condições da análise

Na LDA e na QDA normais, a hipótese de normalidade refere-se às distribuições das características condicionadas à classe. A avaliação deve, portanto, ser realizada separadamente dentro dos grupos. Observações atípicas podem alterar $\bar{\mathbf{x}}_k$, $\mathbf{S}_k$ e, na LDA, $\mathbf{S}_p$, modificando as funções e as fronteiras estimadas (Hair et al., 2009; Johnson; Wichern, 2002).

Na LDA, a igualdade das matrizes de covariâncias pode ser examinada pela comparação de $\mathbf{S}_1, \dots, \mathbf{S}_K$ e pelo teste M de Box. Nesse teste,

$$H_0 : \Sigma_1 = \dots = \Sigma_K.$$

A rejeição de H_0 fornece evidência contra a matriz de covariâncias comum da LDA. A não rejeição não demonstra igualdade das matrizes. O teste M de Box também é sensível a desvios da normalidade multivariada, de modo que sua interpretação pressupõe a avaliação prévia das distribuições condicionais (Hair et al., 2009; Johnson; Wichern, 2002).

As condições de posto da LDA e da QDA estão estabelecidas em Equação 19.46 e Equação 19.47. Mesmo com posto completo, autovalores muito pequenos de $\mathbf{S}_p$ ou de alguma $\mathbf{S}_k$ podem produzir inversões numericamente instáveis, conforme discutido em Definição 6.9. A QDA exige essa avaliação separadamente em cada classe.

A independência das unidades decorre do delineamento e do mecanismo de amostragem. Dependência temporal, espacial, longitudinal ou por agrupamentos não é diagnosticada pela matriz de classificação e exige uma formulação que represente essa dependência.

19.15.3 Escolha entre LDA e QDA

A LDA estima uma única matriz de covariâncias, com

$$\frac{p(p+1)}{2}$$

parâmetros distintos de covariância. A QDA estima uma matriz para cada classe, totalizando

$$K \frac{p(p+1)}{2}$$

parâmetros de covariância.

Sob covariância comum, a LDA utiliza as observações de todas as classes na estimação de $\mathbf{S}_p$. A QDA permite dispersões, correlações e orientações diferentes entre as classes, mas estima $\mathbf{S}_k$ separadamente para cada grupo. Essa diferença torna a QDA mais exigente em tamanho

amostral e mais sensível à instabilidade das matrizes de covariâncias (Johnson; Wichern, 2002).

Sob normalidade multivariada, diferenças populacionais entre as matrizes de covariâncias favorecem a fronteira quadrática da QDA. A rejeição do teste M de Box, entretanto, não determina automaticamente a escolha da QDA. A regra quadrática é particularmente sensível a desvios da normalidade, e diferenças entre matrizes amostrais também contêm variabilidade de estimação (Johnson; Wichern, 2002).

Quando LDA e QDA podem ser estimadas de forma estável, a comparação deve utilizar o desempenho em observações que não participaram do ajuste. As taxas de erro devem ser calculadas sob o mesmo esquema de validação, conforme Seção 19.15.7.

19.15.4 Importância e avaliação das funções discriminantes de Fisher

A raiz λ_j mede a separação entre os grupos na direção α_j relativamente à dispersão intragrupos, conforme a Equação 19.34. A razão definida na Equação 19.35,

$$\frac{\lambda_j}{\sum_{\ell=1}^r \lambda_\ell},$$

expressa a participação da função j na soma das raízes discriminantes positivas. Essa razão não corresponde à proporção da variância total das características.

A **correlação canônica** associada à função j pode ser relacionada diretamente às dispersões de Fisher. Pela normalização da Equação 19.33,

$$\alpha_j^\top \mathbf{T}_{\text{intra}} \alpha_j = 1,$$

e, pela Equação 19.34,

$$\alpha_j^\top \mathbf{T}_{\text{entre}} \alpha_j = \lambda_j.$$

Como

$$\mathbf{T}_{\text{total}} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}},$$

segue que

$$\alpha_j^\top \mathbf{T}_{\text{total}} \alpha_j = 1 + \lambda_j.$$

A razão entre a dispersão entre grupos e a dispersão total na direção α_j é, portanto,

$$\frac{\lambda_j}{1 + \lambda_j}.$$

Essa razão é o quadrado da correlação canônica associada à função discriminante:

$$\left[r_j^{(\text{can})} \right]^2 = \frac{\lambda_j}{1 + \lambda_j},$$

ou, equivalentemente,

$$r_j^{(\text{can})} = \sqrt{\frac{\lambda_j}{1 + \lambda_j}}. \quad (19.61)$$

Como a transformação é estritamente crescente em λ_j , a correlação canônica preserva a ordenação das raízes e expressa a mesma separação em uma escala limitada ao intervalo $(0, 1)$. Ela não deve ser confundida com as cargas discriminantes, que são correlações entre características observadas e escores discriminantes.

A separação remanescente depois das primeiras $j - 1$ funções pode ser resumida pela lambda de Wilks sequencial,

$$\Lambda_j = \prod_{\ell=j}^{r_F} \frac{1}{1 + \lambda_\ell}. \quad (19.62)$$

Para $j = 1$, Λ_1 utiliza todas as raízes positivas. Para $j > 1$, o produto utiliza somente as raízes das funções ainda não retiradas da sequência. O teste associado avalia se permanece separação populacional entre os grupos depois das primeiras $j - 1$ funções. Valores menores de Λ_j correspondem a maior separação nas funções incluídas no produto.

A fórmula de Λ_j não determina, isoladamente, seu valor p . A calibração depende do modelo, das dimensões e dos graus de liberdade. Na implementação utilizada neste capítulo, os testes sequenciais são calibrados por uma aproximação qui-quadrado de Bartlett.

Raiz discriminante, participação relativa, correlação canônica, lambda de Wilks e erro de classificação descrevem propriedades distintas: separação em uma direção, participação dessa direção na soma das raízes, reescala da raiz, evidência inferencial de separação remanescente e desempenho preditivo, respectivamente.

19.15.5 Coeficientes das funções discriminantes de Fisher

A função discriminante de Fisher

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}})$$

é determinada pela direção α_j . Seus coeficientes podem ser expressos sob diferentes normalizações, e sua interpretação pode ser complementada pelas correlações entre as características originais e os escores discriminantes.

Os elementos de α_j são os coeficientes utilizados para construir a coordenada discriminante

$$z_j(\mathbf{x}) = \alpha_j^\top (\mathbf{x} - \bar{\mathbf{x}}).$$

Esses coeficientes dependem da escala das características, das matrizes $\mathbf{T}_{\text{intra}}$ e $\mathbf{T}_{\text{entre}}$ que definem o problema de autovalores generalizados e da normalização adotada para a direção. O valor absoluto de um coeficiente, considerado isoladamente, não fornece, em geral, uma medida direta da importância da característica correspondente.

Uma mesma direção discriminante pode ser expressa em diferentes normalizações. Uma delas utiliza

$$\tilde{\alpha}_j = \frac{\alpha_j}{\|\alpha_j\|_2}. \quad (19.63)$$

Esse reescalonamento modifica a escala dos coeficientes, mas não a direção discriminante representada. Em geral, ele não preserva a condição de norma unitária na métrica intragrupos, $\tilde{\alpha}_j^\top \mathbf{T}_{\text{intra}} \tilde{\alpha}_j = 1$, correspondente à normalização da Equação 19.32.

Os **coeficientes normalizados** correspondem, portanto, a outra normalização da mesma direção discriminante. Eles não constituem uma medida de associação entre cada característica e a função discriminante e não devem ser confundidos com as cargas discriminantes.

As **cargas discriminantes**, também denominadas **correlações de estrutura**, são as correlações amostrais entre as características observadas e os escores discriminantes. Para a característica h e a função de Fisher j , define-se

$$r_{hj}^{(\text{estrutura})} = \text{Cor}(X_h, z_j). \quad (19.64)$$

A quantidade $r_{hj}^{(\text{estrutura})}$ mede a associação linear entre a característica h e o escore discriminante j .

Os coeficientes da direção e as cargas discriminantes possuem interpretações distintas. Os elementos de α_j determinam a combinação linear que produz $z_j(\mathbf{x})$; as cargas medem a correlação de cada característica com os escores obtidos nessa função. Como as características podem ser correlacionadas, um coeficiente de pequena magnitude pode coexistir com uma carga elevada.

Os coeficientes normalizados representam a mesma direção em outra escala. Eles não alteram o subespaço discriminante nem substituem as cargas como medidas de associação entre características e escores.

19.15.6 Centroides e interpretação dos grupos

O centroide $\bar{z}_{kj}$ definido na Equação 19.39 é a média dos escores discriminantes do grupo k na função j . Para uma função fixa, a comparação de

$$\bar{z}_{1j}, \dots, \bar{z}_{Kj}$$

mostra quais médias de grupos estão mais separadas ao longo da direção α_j (Hair et al., 2009; Johnson; Wichern, 2002).

Como os escores foram centralizados pela média global,

$$\sum_{k=1}^K n_k \bar{z}_{kj} = 0, \quad j = 1, \dots, r_F. \quad (19.65)$$

A origem corresponde, portanto, à média global no espaço discriminante.

As cargas discriminantes e os centroides têm funções diferentes na interpretação. As cargas descrevem a associação entre cada característica e a função discriminante; os centroides localizam os grupos nessa função. O sinal de uma carga indica a direção da associação com o escore, mas não determina, isoladamente, a ordenação das médias dos grupos na característica original. Essa ordenação deve ser verificada diretamente em $\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_K$.

O sinal de α_j é arbitrário. A substituição

$$\alpha_j \mapsto -\alpha_j$$

inverte os sinais dos escores, dos centroides e das cargas sem alterar as distâncias ou a separação representada. Por isso, a interpretação utiliza as posições relativas dos grupos e as associações entre características e funções, e não o sinal isolado de um centroide.

Quando $r_F \geq 2$, os centroides podem ser representados conjuntamente nas primeiras funções discriminantes. As distâncias nesse espaço descrevem a separação entre médias projetadas dos grupos; não representam, por si mesmas, probabilidades de classificação correta.

19.15.7 Erro aparente e erro em novas observações

A formulação da LDA e da QDA determina como construir uma regra de classificação. Avaliar o desempenho dessa regra constitui um problema adicional. Em particular, o erro observado nas mesmas unidades utilizadas para estimar a regra deve ser distinguido do erro obtido em observações que não participaram da estimação.

Considere uma amostra de treinamento formada por pares

$$(\mathbf{x}_i, c_i), \quad i = 1, \dots, n,$$

utilizados para construir uma regra $\hat{\psi}$. A proporção de classificações incorretas calculada nas próprias observações utilizadas no ajuste é o **erro aparente**,

$$\hat{R}_{\text{aparente}} = \frac{1}{n} \sum_{i=1}^n \mathbb{1} \{ \hat{\psi}(\mathbf{x}_i) \neq c_i \}, \quad (19.66)$$

em que $\mathbb{1}\{\cdot\}$ é a função indicadora.

Esse erro descreve o desempenho da regra nas unidades que também contribuíram para estimar seus parâmetros e tende a ser otimista como estimativa do erro em novas observações, porque os mesmos dados participam do ajuste e da avaliação (Johnson; Wichern, 2002).

Considere agora um conjunto de teste *holdout*, formado por m pares

$$(\mathbf{x}_i^*, c_i^*), \quad i = 1, \dots, m,$$

reservados antes do ajuste e não utilizados na estimação da regra. A proporção de classificações incorretas nesse conjunto é

$$\hat{R}_{\text{teste}} = \frac{1}{m} \sum_{i=1}^m \mathbb{1} \{ \hat{\psi}(\mathbf{x}_i^*) \neq c_i^* \}. \quad (19.67)$$

O erro aparente descreve o comportamento da regra nas observações utilizadas em sua construção, enquanto o erro de teste *holdout* descreve seu comportamento na parcela da amostra reservada para avaliação. O conjunto *holdout* não deve participar da estimação da regra nem de decisões orientadas pelo desempenho observado nesse próprio conjunto.

Uma amostra independente, obtida separadamente dos dados utilizados para construir e selecionar a regra, constitui outro regime de avaliação. Quando representa a população na qual a regra será aplicada, seu erro de classificação fornece uma avaliação externa do desempenho preditivo.

Na validação cruzada, cada observação ou subconjunto é classificado por uma regra estimada sem utilizar, naquele ajuste, as observações que estão sendo avaliadas. As observações podem participar dos ajustes correspondentes às demais partições, mas nenhuma observação deve participar da estimação da regra utilizada para produzir sua própria classificação. Esse procedimento não equivale a uma validação externa e não corrige limitações de representatividade da amostra.

A avaliação preditiva deve preservar a distinção entre erro aparente, erro obtido por validação cruzada, erro em um conjunto de teste *holdout* e erro observado em uma amostra independente. Esses valores correspondem a regimes de avaliação diferentes e não devem ser apresentados como estimativas intercambiáveis.

19.15.8 Matriz de classificação e desempenho por classe

A matriz de classificação cruza a classe observada com a classe atribuída pela regra. Os elementos da diagonal correspondem às classificações corretas, enquanto os elementos fora da diagonal mostram quais classes estão sendo confundidas.

A proporção global de acertos resume o desempenho da regra, mas pode ocultar diferenças entre as classes. As proporções de acerto calculadas dentro de cada classe medem a frequência com que observações daquela classe são classificadas corretamente e permitem identificar classes com desempenho particularmente baixo.

A proporção global de acertos também deve ser interpretada em relação a regras de referência que não utilizam as características discriminantes. Considere um conjunto de avaliação com m observações, das quais m_k pertencem à classe k , e defina

$$q_k = \frac{m_k}{m}, \quad k = 1, \dots, K.$$

O **critério de chance máxima** corresponde à proporção de acertos obtida por uma regra que atribui todas as observações à classe mais frequente:

$$A_{\max} = \max_{1 \leq k \leq K} q_k. \quad (19.68)$$

Esse critério mostra quanto seria possível acertar sem utilizar qualquer característica, apenas escolhendo sistematicamente a classe de maior frequência.

O **critério de chance proporcional** considera uma classificação aleatória que atribui uma observação à classe k com probabilidade q_k . A probabilidade de a classe atribuída coincidir com a classe verdadeira é

$$A_{\text{prop}} = \sum_{k=1}^K q_k^2. \quad (19.69)$$

Quando as K classes possuem a mesma frequência,

$$q_1 = \cdots = q_K = \frac{1}{K},$$

os dois critérios coincidem:

$$A_{\text{max}} = A_{\text{prop}} = \frac{1}{K}.$$

Com classes desbalanceadas, os dois valores podem diferir substancialmente. Em particular, uma proporção global de acertos aparentemente elevada pode representar pouco ganho classificatório se estiver próxima do desempenho obtido pela atribuição sistemática à classe majoritária (Hair et al., 2009).

Os critérios de chance máxima e chance proporcional são referências descritivas para contextualizar a proporção de acertos. Eles não substituem a avaliação em observações que não participaram da estimação e não constituem, por si mesmos, testes de desempenho preditivo. A comparação principal deve utilizar o mesmo regime de avaliação da regra: validação cruzada, conjunto de teste *holdout* ou amostra independente, conforme distinguido na Seção 19.15.7.

A matriz deve ser interpretada em conjunto com as probabilidades *a priori* e, quando pertinente, com as consequências dos diferentes erros discutidas na Seção 19.15.1. Uma regra pode apresentar elevada proporção global de acertos e desempenho baixo em uma classe pouco frequente.

Em problemas com duas classes, sensibilidade e especificidade exigem que uma das classes seja previamente definida como positiva ou de interesse. Essas medidas dependem dessa escolha e não se estendem de forma única a problemas com $K > 2$ classes.

19.15.9 Casos classificados incorretamente

Para uma observação de classe conhecida c_i , denote por

$$\hat{c}_i = \hat{\psi}(\mathbf{x}_i)$$

a classe atribuída pela regra. O erro ocorre quando

$$\hat{c}_i \neq c_i.$$

O par $(c_i, \hat{c}_i)$ identifica quais classes estão sendo confundidas. A concentração dos erros em determinados pares de classes complementa as frequências agregadas da matriz de classificação (Hair et al., 2009).

Sob perda zero-um, podem ser comparadas as probabilidades *a posteriori* da classe verdadeira e da classe atribuída:

$$P(C = c_i \mid \mathbf{X} = \mathbf{x}_i) \quad \text{e} \quad P(C = \hat{c}_i \mid \mathbf{X} = \mathbf{x}_i).$$

Uma pequena diferença entre essas probabilidades indica pouca separação entre as duas decisões segundo a regra ajustada. Quando elas são as duas maiores probabilidades *a posteriori*, valores próximos correspondem a uma observação próxima da fronteira entre essas classes. Com perdas gerais, a comparação deve utilizar os riscos condicionais da Equação 19.48.

Dentro de cada classe verdadeira, as características originais e os escores discriminantes podem ser comparados entre observações corretamente e incorretamente classificadas. Diferenças recorrentes localizam regiões do espaço das características em que os erros se concentram. Essas diferenças não identificam, por si mesmas, a causa dos erros (Hair et al., 2009).

Uma classificação incorreta não constitui motivo para excluir a observação. A exclusão requer evidência independente de erro de mensuração, registro ou rótulo. A sobreposição entre as distribuições pode produzir erros mesmo sob a regra populacional de Bayes.

Erros observados na amostra de treinamento pertencem ao erro aparente. Erros obtidos por validação cruzada, conjunto *holdout* ou amostra independente correspondem aos regimes definidos na Seção 19.15.7. A repetição do mesmo padrão de confusão fora da amostra de treinamento indica uma limitação persistente da regra, e não apenas ajuste excessivo às observações utilizadas na estimação.

19.15.10 Correspondência com a implementação utilizada

Nas atividades computacionais, a Análise Discriminante será realizada pelo módulo `snowCluster` (Seol, 2026) do `jamovi` (The jamovi project, 2026). A análise utilizada disponibiliza a **Análise Discriminante Linear (LDA)**; a QDA permanece no capítulo como parte da formulação estatística da técnica.

Tabela 19.5: Correspondência entre elementos da implementação e os objetos estatísticos desenvolvidos no capítulo.

Elemento da implementação	Correspondência estatística	Desenvolvimento no capítulo
Dependent variable / Grouping variable	classe conhecida utilizada na construção da regra de classificação e das direções discriminantes	Capítulo 19
Covariates / Variables	características quantitativas utilizadas para discriminar e classificar	Capítulo 19
Training proportion	proporção das observações utilizada para estimar a regra	Seção 19.15.7
Prior probability	probabilidades <i>a priori</i> utilizadas pela LDA	Seção 19.15.1
Coefficients of discriminants	coeficientes das direções discriminantes de Fisher	Seção 19.15.5
Normalized loadings	coeficientes das mesmas direções após normalização euclidiana	Equação 19.63
Structure coefficients	correlações entre as características e os escores discriminantes	Equação 19.64
Eigenvalue	raiz discriminante de Fisher λ_j	Equação 19.30
Variance explained	participação relativa da raiz discriminante na soma das raízes positivas	Equação 19.35
Canonical correlation	correlação canônica associada à função de Fisher	Equação 19.61
Training set	matriz de classificação das observações utilizadas no ajuste	Seção 19.15.8
Test set	matriz de classificação das observações separadas para teste	Seção 19.15.7
Wilks' Lambda tests	testes sequenciais da separação nas funções de Fisher remanescentes	Equação 19.62

A rotina utilizada pela implementação é baseada em `MASS::lda()` (Ripley; Venables, 2002). Na configuração auditada, as probabilidades *a priori* correspondem às proporções das classes

na amostra de treinamento. O item **Prior probability** apresenta esses valores como saída; a interface utilizada não permite substituí-los por probabilidades especificadas pelo usuário.

A opção **Training proportion** separa, de forma estratificada segundo a variável de classe, as observações utilizadas no ajuste daquelas reservadas para teste. Quando seu valor é 1, todas as observações são utilizadas no treinamento e não existe conjunto de teste separado. A tabela **Training set** corresponde, portanto, à avaliação aparente da regra. A tabela **Test set**, quando disponível, fornece uma avaliação *holdout*. Essa divisão não constitui validação cruzada.

Os **Coefficients of discriminants** correspondem às colunas da matriz `scaling` de `MASS::lda()`. Os **Normalized loadings** são obtidos pela normalização euclidiana dessas colunas. Os **Structure coefficients** são as correlações entre as características observadas e os escores discriminantes na amostra de treinamento. Esses três resultados correspondem aos objetos distinguidos na Seção 19.15.5 e não devem ser interpretados como medidas equivalentes.

Na configuração auditada, `MASS::lda()` utiliza o método de momentos e probabilidades *a priori* iguais às proporções das classes na amostra de treinamento. Se d_j denota o j -ésimo valor de `MASS::lda()$svd`, n é o tamanho dessa amostra e K é o número de classes, a raiz discriminante correspondente à formulação

$$\mathbf{T}_{\text{entre}}\alpha_j = \lambda_j \mathbf{T}_{\text{intra}}\alpha_j$$

é

$$\lambda_j = d_j^2 \frac{K-1}{n-K}.$$

A saída **Eigenvalue** apresenta essas raízes discriminantes. A saída **Variance explained** apresenta, em porcentagem, a participação relativa

$$100 \frac{\lambda_j}{\sum_{\ell=1} r_F} \%.$$

Essa quantidade foi definida na Equação 19.35 e não representa a proporção da variância total das características, como ocorre na ACP.

A saída **Canonical correlation** apresenta a correlação canônica $r_j^{(\text{can})}$ definida na Equação 19.61. Ela é uma transformação crescente da raiz discriminante para uma escala limitada entre 0 e 1.

Os **Wilks' Lambda tests** correspondem aos testes sequenciais descritos na Equação 19.62. Sob normalidade multivariada dentro das classes, independência entre unidades e matriz de

covariâncias comum, a implementação utiliza uma aproximação qui-quadrado de Bartlett para obter os valores p desses testes.

O teste iniciado na função j avalia a hipótese de ausência de separação populacional nas funções $j, \dots, r_F$, depois de retiradas as funções anteriores da sequência. Valores menores de Λ_j indicam maior separação nas funções incluídas no produto. Esses testes avaliam separação entre os grupos e não desempenho preditivo da regra de classificação.

19.16 Síntese

A Análise Discriminante considera grupos previamente conhecidos e desenvolve duas formulações relacionadas: uma regra probabilística de classificação e uma representação geométrica da separação entre os grupos.

Na formulação probabilística, cada classe possui probabilidade *a priori* π_k e densidade condicional $f_k(\mathbf{x})$. Sob perda zero-um, a regra de Bayes atribui $\mathbf{x}$ à classe que maximiza

$$\pi_k f_k(\mathbf{x}),$$

equivalentemente, a classe de maior probabilidade *a posteriori*.

Sob normalidade multivariada e matriz de covariâncias comum às classes, a regra de Bayes conduz à LDA e a fronteiras lineares. Com matrizes de covariâncias específicas por classe, obtém-se a QDA e, em geral, fronteiras quadráticas. As regras amostrais substituem os parâmetros populacionais desconhecidos por estimativas.

Na formulação de Fisher, a separação produzida por uma direção $\mathbf{a}$ é medida relativamente à dispersão intragrupos por

$$J_F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}}{\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a}}.$$

Quando

$$\mathbf{T}_{\text{intra}} \succ \mathbf{0},$$

as direções discriminantes satisfazem

$$\mathbf{T}_{\text{entre}} \alpha_j = \lambda_j \mathbf{T}_{\text{intra}} \alpha_j,$$

e o número de direções associadas a raízes positivas obedece a

$$r_F \leq \min(p, K - 1).$$

As coordenadas discriminantes são as projeções das observações nessas direções e representam a separação entre os grupos relativamente à dispersão intragrupos.

Para duas classes com normalidade multivariada e covariância comum, a direção populacional de Fisher é paralela ao vetor

$$\Sigma^{-1}(\mu_1 - \mu_2),$$

que também é normal à fronteira da LDA. Fisher determina uma direção de separação; a LDA determina uma regra de classificação. Na LDA, a posição da fronteira depende também das probabilidades *a priori* e, com perdas gerais, da função de perda.

A normalidade multivariada e a igualdade das matrizes de covariâncias não são necessárias para definir o critério geométrico de Fisher. Essas condições pertencem à formulação probabilística da LDA normal. A QDA mantém a normalidade multivariada, mas admite matrizes de covariâncias específicas por classe. As regras que utilizam inversas de matrizes de covariâncias exigem não singularidade e podem ser numericamente instáveis diante de quase dependências lineares.

Mesmo com os parâmetros populacionais conhecidos, distribuições condicionais sobrepostas podem produzir classificações incorretas. Sob perda zero-um, o erro de Bayes é a menor probabilidade global de classificação incorreta alcançável pela regra populacional de Bayes.

A relação com a MANOVA decorre do mesmo problema de autovalores generalizados quando ambas utilizam a mesma partição em grupos. A MANOVA utiliza as raízes para testar diferenças entre vetores de médias; Fisher utiliza os autovetores para construir direções de separação. A ACP determina direções pela variabilidade total sem utilizar rótulos de classes, enquanto a Análise de Agrupamentos constrói grupos que não são conhecidos previamente.

Exercícios de fixação do Módulo III

Os exercícios deste módulo retomam a formulação matemática e estatística das técnicas multivariadas desenvolvidas no Módulo III.

A lista está dividida em três partes, de acordo com a função do conteúdo no módulo.

Na **Parte I — Núcleo**, os exercícios verificam a compreensão do problema estatístico de cada técnica, seus objetos de entrada, a formulação matemática, as principais quantidades calculadas e a interpretação dos resultados.

Na **Parte II — Aprofundamentos teóricos**, os exercícios exploram propriedades, demonstrações, condições de existência, invariâncias, identificação, relações espectrais e resultados probabilísticos que explicam por que as formulações do núcleo funcionam.

Na **Parte III — Aprofundamentos metodológicos e aplicados**, os exercícios utilizam o R para examinar decisões de análise, adequação dos dados, escolha de dimensionalidade ou número de grupos, interpretação, diagnóstico e avaliação dos resultados.

Diretrizes gerais. A consulta aos capítulos faz parte da atividade. Definições, teoremas, proposições, propriedades, identidades e decomposições já estabelecidos nos Módulos I, II e III podem e devem ser utilizados diretamente, salvo quando uma demonstração ou derivação for solicitada explicitamente.

Sempre que um resultado dos módulos anteriores for utilizado, identifique o resultado empregado e verifique suas condições de validade. Não basta reproduzir uma fórmula ou uma saída de software. Quando forem necessárias condições de existência de momentos, definição positiva, invertibilidade, posto, independência, normalidade, tamanho amostral, graus de liberdade ou identificabilidade, essas condições devem ser indicadas.

Os exercícios do Módulo III devem combinar os fundamentos anteriores com o problema específico de cada técnica. Assim, projeções, quocientes de Rayleigh, SVD, autovalores generalizados, branqueamento, matrizes de covariâncias, distribuição Normal Multivariada, estimação, modelo linear multivariado, Wishart e resultados de inferência já desenvolvidos devem ser reutilizados.

Quando houver inferência, diferencie a construção algébrica ou geométrica da estatística. Quando houver escolha metodológica, explicita como a decisão adotada pode modificar a solução.

Parte I — Núcleo

Exercício 19.1 (Problemas estatísticos e estruturas das técnicas multivariadas). Considere as situações a seguir.

Situação A. Uma equipe possui seis medidas quantitativas de qualidade ambiental obtidas em 120 locais e deseja construir duas combinações lineares que representem a maior parte possível da variabilidade observada.

Situação B. Um questionário possui doze itens quantitativos destinados a medir dimensões não observadas de satisfação. O objetivo é representar as covariâncias entre os itens por um número menor de fatores comuns.

Situação C. Cem municípios são descritos por indicadores socioeconômicos e não existe uma classificação prévia. Deseja-se formar grupos de municípios internamente semelhantes.

Situação D. Uma tabela cruza quatro categorias de ocupação com cinco níveis de escolaridade. O objetivo é representar as associações entre as categorias das duas variáveis.

Situação E. Três tratamentos foram aplicados a grupos previamente definidos e quatro respostas quantitativas foram medidas em cada unidade. O objetivo é testar se os vetores de médias diferem entre os tratamentos.

Situação F. Três espécies previamente conhecidas são descritas por medidas morfométricas. Deseja-se representar sua separação e construir uma regra para classificar novos indivíduos.

1. Para cada situação, identifique a técnica do Módulo III mais diretamente associada ao problema.
2. Para cada técnica identificada, indique:
 - o objeto de entrada;
 - qual estrutura é fornecida previamente (rótulos de grupos, tratamentos, categorias observadas ou nenhuma dessas estruturas) e qual papel ela desempenha na análise;
 - o objeto matemático;
 - o principal critério de construção da solução;
 - se o objetivo principal é redução, estrutura latente, agrupamento, associação, comparação ou classificação.
3. Compare as Situações A e B. Explique por que ambas podem produzir poucas dimensões a partir de muitas variáveis, mas não resolvem o mesmo problema estatístico.

4. Compare as Situações C e F. Explique o papel dos grupos em cada técnica e por que a existência de rótulos conhecidos modifica a formulação do problema.
5. Compare as Situações D e A. Explique por que a Análise de Correspondência utiliza uma geometria de perfis e massas, enquanto a ACP parte de uma matriz de covariâncias ou correlações entre variáveis quantitativas.
6. Compare as Situações E e F. Explique por que MANOVA e Análise Discriminante podem compartilhar estruturas de dispersão entre e dentro dos grupos, embora possuam objetivos estatísticos diferentes.

Exercício 19.2 (ACP: variância, direções principais e representação). Considere um vetor aleatório bidimensional com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

1. Verifique que Σ é simétrica e positiva definida.
2. Determine seus autovalores e escolha uma base ortonormal de autovetores associados, ordenando os autovalores de forma decrescente.
3. Escreva as duas componentes principais populacionais

$$Y_j = \alpha_j^\top \mathbf{X}, \quad j = 1, 2.$$

4. Determine a variância de cada componente principal e verifique que a soma dessas variâncias é igual a

$$\text{tr}(\Sigma).$$

5. Calcule a proporção da variância total explicada pela primeira componente e a proporção acumulada pelas duas componentes.
6. Explique por que a primeira componente maximiza a variância entre todas as combinações lineares com vetor de coeficientes de norma igual a um. Relacione a argumentação ao problema de variância direcional praticado em Exercício 7.10 e à caracterização variacional das direções sucessivas estabelecida em Teorema 5.7.
7. Considere a observação centralizada

$$\mathbf{x} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Calcule seus escores nas duas componentes.

8. Reconstrua $\mathbf{x}$:

- utilizando as duas componentes;
- utilizando apenas a primeira componente.

Calcule o erro quadrático da reconstrução de uma componente e interprete o que foi descartado pela redução de dimensão. Relacione a reconstrução à projeção ortogonal praticada em Exercício 7.24.

9. Explique o que mudaria na interpretação se a ACP fosse construída a partir da matriz de correlações em vez da matriz de covariâncias.

Exercício 19.3 (Análise Fatorial: estrutura comum de covariâncias). Considere um modelo fatorial ortogonal para quatro variáveis padronizadas e dois fatores comuns, com matriz de cargas

$$\Phi = \begin{bmatrix} 0,8 & 0 \\ 0,6 & 0,2 \\ 0,1 & 0,7 \\ 0 & 0,8 \end{bmatrix}$$

e matriz de especificidades

$$\Psi = \text{diag}(0,36, 0,60, 0,50, 0,36).$$

1. Calcule a comunalidade de cada variável e verifique que, para todas elas,

$$h_i^2 + \psi_i = 1.$$

2. Construa a matriz de covariâncias comuns

$$\Phi\Phi^\top.$$

3. Obtenha a matriz reproduzida

$$\Sigma = \Phi\Phi^\top + \Psi.$$

4. Interprete:

- os elementos diagonais de $\Phi\Phi^\top$;
- os elementos fora da diagonal;
- os elementos diagonais de Ψ .

- Compare as covariâncias reproduzidas entre os pares (X_1, X_2) , (X_1, X_4) e (X_3, X_4) . Explique como as cargas compartilhadas pelos pares de variáveis determinam essas covariâncias.
- Considere uma matriz ortogonal

$$\mathbf{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e a matriz de cargas rotacionadas

$$\Phi^* = \Phi \mathbf{Q}.$$

Mostre que

$$\Phi^* \Phi^{*\top} = \Phi \Phi^\top.$$

- Explique por que a rotação altera as cargas individuais, mas não altera a matriz de covariâncias comuns reproduzida no modelo ortogonal.
- Explique, com base neste exemplo, por que uma carga fatorial não deve ser interpretada da mesma maneira que um coeficiente de uma componente principal.

Exercício 19.4 (Agrupamentos: partições, centroides e métodos hierárquicos). Considere seis observações bidimensionais:

$$\mathbf{x}_1 = (0, 0), \quad \mathbf{x}_2 = (0, 2), \quad \mathbf{x}_3 = (2, 0),$$

$$\mathbf{x}_4 = (8, 8), \quad \mathbf{x}_5 = (8, 10), \quad \mathbf{x}_6 = (10, 8).$$

- Calcule as distâncias euclidianas entre todos os pares de observações e organize os resultados em uma matriz de distâncias.
- Considere a partição

$$\mathcal{P}_A = \{\{1, 2, 3\}, \{4, 5, 6\}\}.$$

Determine os dois centroides e calcule o critério das K -médias

$$J_2(\mathcal{P}_A).$$

3. Considere agora

$$\mathcal{P}_B = \{\{1, 2, 4\}, \{3, 5, 6\}\}.$$

Calcule os centroides e $J_2(\mathcal{P}_B)$. Compare as duas partições.

4. Explique por que a partição com menor dispersão intragrupos também possui maior dispersão entre grupos quando $K = 2$ permanece fixado.
5. Começando com seis grupos unitários, determine qual ou quais fusões podem ocorrer primeiro segundo:
 - ligação simples;
 - ligação completa;
 - ligação média;
 - método de Ward.

Em caso de empate, indique todas as fusões possíveis.

Em seguida, suponha que a primeira fusão escolhida tenha sido entre as observações 1 e 2, formando o grupo $G = \{1, 2\}$. Calcule o critério utilizado para comparar G com o grupo unitário $\{3\}$ segundo ligação simples, ligação completa, ligação média e Ward. Explique por que as quatro regras deixam de ser equivalentes depois que aparecem grupos com mais de uma observação.

6. Para dois grupos unitários contendo $\mathbf{x}_i$ e $\mathbf{x}_j$, mostre que o incremento de Ward é

$$\Delta_{ij} = \frac{1}{2} \|\mathbf{x}_i - \mathbf{x}_j\|^2.$$

7. Explique por que o corte de um dendrograma de Ward em dois grupos não precisa coincidir, em geral, com o mínimo global do critério das K -médias para $K = 2$.

Exercício 19.5 (Análise de Correspondência: perfis, inércia e dimensão). Considere a tabela de contingência

$$\mathbf{N} = \begin{bmatrix} 30 & 10 & 10 \\ 10 & 20 & 20 \end{bmatrix},$$

em que as linhas representam duas categorias de uma variável e as colunas três categorias de outra.

1. Calcule:

- o total n ;

- a matriz de frequências relativas $\mathbf{P}$;
 - as massas das linhas;
 - as massas das colunas.
2. Determine os perfis das duas linhas e os perfis das três colunas.
 3. Sob independência, obtenha a matriz esperada de frequências relativas

$$\mathbf{r}\mathbf{c}^\top.$$

4. Calcule a distância qui-quadrado entre os dois perfis de linhas.
5. Calcule a estatística qui-quadrado de Pearson da tabela e obtenha a inércia total pela identidade

$$\mathcal{J} = \frac{\chi^2}{n}.$$

6. Construa a matriz de desvios padronizados

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

Nos itens seguintes, quando utilizar a decomposição dessa matriz, recupere a interpretação da SVD praticada em Exercício 7.13.

7. Determine o posto máximo possível de $\mathbf{Q}_{\text{CA}}$ neste problema e explique por que a representação possui, no máximo, uma dimensão não trivial.
8. Verifique que a soma dos quadrados dos elementos de $\mathbf{Q}_{\text{CA}}$ é igual à inércia total.
9. Explique por que a identidade $\chi^2 = n\mathcal{J}$ é exata para a tabela observada, enquanto a utilização de uma distribuição qui-quadrado para realizar um teste de independência exige uma formulação probabilística adicional.

Exercício 19.6 (MANOVA: matrizes de hipótese e erro e critérios multivariados). Considere uma hipótese multivariada para duas respostas cuja matriz de hipótese e matriz de erro sejam

$$\mathbf{H} = \begin{bmatrix} 8 & 0 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{E} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

1. Verifique que $\mathbf{E}$ é positiva definida.
2. Resolva o problema de autovalores generalizados

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e determine as duas raízes características em ordem decrescente. Utilize, quando necessário, a estrutura praticada em Exercício 7.11.

3. Identifique as direções generalizadas correspondentes e normalize-as na métrica de $\mathbf{E}$.
4. Para uma combinação linear $\mathbf{a}^\top \mathbf{Y}$, interprete

$$\frac{\mathbf{a}^\top \mathbf{H}\mathbf{a}}{\mathbf{a}^\top \mathbf{E}\mathbf{a}}.$$

5. Calcule:

- a lambda de Wilks;
- o traço de Pillai;
- o traço de Hotelling–Lawley;
- a maior raiz de Roy.

6. Explique como cada critério agrega as mesmas raízes características de forma diferente.
7. Repita conceitualmente o problema após a transformação de branqueamento pela matriz $\mathbf{E}$. Explique o que acontece com a métrica residual e relacione a transformação a Exercício 7.12.
8. Indique quais resultados dos itens anteriores são puramente algébricos e quais etapas adicionais seriam necessárias para transformar os critérios em testes inferenciais.

Exercício 19.7 (Análise Discriminante: LDA, Fisher e classificação). Considere duas populações com vetores de médias

$$\mu_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mu_2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e matriz de covariâncias comum

$$\Sigma = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 1 \end{bmatrix}.$$

Admita probabilidades *a priori* iguais e perda zero–um.

1. Verifique que Σ é positiva definida e calcule Σ^{-1} . Relacione a geometria induzida por Σ^{-1} ao que foi praticado em Exercício 7.8.
2. Escreva as duas funções discriminantes lineares populacionais da LDA, desprezando constantes comuns às classes.
3. Determine a fronteira de classificação entre as duas classes e mostre que ela pode ser escrita como

$$x_1 + x_2 = 2.$$

4. Classifique as observações

$$\mathbf{x}_A = \begin{bmatrix} 0,5 \\ 0,5 \end{bmatrix}$$

e

$$\mathbf{x}_B = \begin{bmatrix} 1,5 \\ 1,2 \end{bmatrix}.$$

5. Determine a direção populacional de Fisher para duas classes e mostre que ela é proporcional a

$$\Sigma^{-1} (\mu_2 - \mu_1).$$

Relacione essa direção ao tipo de problema espectral generalizado estudado em Exercício 7.11.

6. Explique por que, sob as condições deste exercício, a direção de Fisher e a direção que aparece na fronteira da LDA estão diretamente relacionadas.
7. Suponha agora que as probabilidades *a priori* deixem de ser iguais. Explique qual termo das funções discriminantes é alterado e por que a fronteira se desloca.
8. Explique por que a formulação geométrica de Fisher pode ser construída sem normalidade, enquanto a interpretação probabilística da LDA utilizada neste exercício depende do modelo normal com covariância comum.

Parte II — Aprofundamentos teóricos

Exercício 19.8 (ACP: propriedades espectrais, reconstrução e multiplicidade). Considere uma matriz de covariâncias populacional

$$\Sigma = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^\top,$$

em que $\mathbf{A}$ é ortogonal e

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

1. Demonstre que as componentes principais

$$Y_j = \alpha_j^\top \mathbf{X}$$

são não correlacionadas.

2. Mostre que

$$\sum_{j=1}^p \text{Var}(Y_j) = \text{tr}(\Sigma).$$

3. Para uma observação centralizada $\mathbf{x}$, escreva sua reconstrução utilizando as primeiras k direções principais e mostre que o vetor reconstruído é a projeção ortogonal de $\mathbf{x}$ sobre

$$\text{span}(\alpha_1, \dots, \alpha_k).$$

4. Mostre que o erro de reconstrução pode ser escrito como a soma dos quadrados dos escores descartados.
5. Considere uma matriz de dados centralizada $\mathbf{X}_c \in \mathbb{R}^{n \times p}$ e a matriz de covariâncias amostral

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Utilize os resultados de SVD e aproximação de posto reduzido já estudados no Módulo I, em particular Exercício 7.14 e Exercício 7.26, para relacionar a reconstrução pelas primeiras k componentes principais à melhor aproximação de posto k de $\mathbf{X}_c$.

6. Suponha agora que $\lambda_2 = \lambda_3$ seja um autovalor de multiplicidade exatamente dois, distinto dos demais autovalores.

Explique: - quais objetos continuam unicamente determinados; - por que os autovetores individuais associados a $\lambda_2 = \lambda_3$ não são únicos; - por que o autoespaço bidimensional correspondente permanece unicamente determinado.

7. Explique por que uma mudança de sinal de um autovetor altera o sinal dos escores correspondentes, mas não altera a variância explicada nem a reconstrução quando o mesmo sinal é utilizado de forma consistente.

Exercício 19.9 (Análise Fatorial: identificação, rotação e formulação normal). Considere o modelo fatorial ortogonal

$$\mathbf{X} = \mu + \Phi \mathbf{F} + \varepsilon,$$

com

$$E(\mathbf{F}) = \mathbf{0}, \quad \text{Cov}(\mathbf{F}) = \mathbf{I}_m,$$

$$E(\varepsilon) = \mathbf{0}, \quad \text{Cov}(\varepsilon) = \Psi,$$

em que $\Psi \succ \mathbf{0}$ é diagonal e

$$\text{Cov}(\mathbf{F}, \varepsilon) = \mathbf{0}.$$

1. Obtenha

$$\Sigma = \Phi \Phi^\top + \Psi.$$

2. Seja $\mathbf{Q}$ uma matriz ortogonal de ordem m . Mostre que

$$\Phi^* = \Phi \mathbf{Q}$$

gera a mesma matriz de covariâncias observável.

3. Explique por que o resultado anterior implica indeterminação rotacional e por que a rotação não corrige falta de ajuste da matriz reproduzida.
4. Inicialmente, conte os elementos livres de Φ e Ψ antes de considerar a indeterminação rotacional. Em seguida, utilize o fato de que o grupo de matrizes ortogonais de ordem m possui $m(m-1)/2$ graus de liberdade para determinar a dimensão efetiva da parametrização após descontar essa indeterminação.

Compare o resultado com os

$$\frac{p(p+1)}{2}$$

elementos distintos de Σ e obtenha a condição de contagem correspondente. Explique por que essa condição é necessária, mas não suficiente, para identificação do modelo fatorial.

5. Sob o modelo fatorial normal,

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m), \quad \varepsilon \sim N_p(\mathbf{0}, \Psi),$$

com independência entre os dois vetores, determine a distribuição marginal de $\mathbf{X}$.

6. Utilizando os resultados sobre a distribuição Normal Multivariada particionada estudados no Módulo II, em particular Exercício 12.2, obtenha

$$E(\mathbf{F} \mid \mathbf{X} = \mathbf{x}).$$

7. Explique por que a expressão obtida no item anterior fundamenta o escore fatorial por regressão, mas não transforma o fator latente em uma variável observada.

Exercício 19.10 (Agrupamentos: minimização, existência, invariâncias e Ward). Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p.$$

1. Para um grupo não vazio G , demonstre que o ponto

$$\bar{\mathbf{x}}_G = \frac{1}{|G|} \sum_{i \in G} \mathbf{x}_i$$

minimiza

$$\sum_{i \in G} \|\mathbf{x}_i - \mathbf{c}\|^2$$

em relação a $\mathbf{c} \in \mathbb{R}^p$.

2. Utilize o resultado anterior para justificar por que, fixada uma partição, o centroide é a escolha ótima no critério das K -médias.
3. Para $1 \leq K \leq n$, explique por que o conjunto de partições admissíveis das n observações em K grupos não vazios é finito. Conclua que o mínimo global W_K é atingido por pelo menos uma partição.
4. Mostre que, para $1 \leq K < n$,

$$W_{K+1} \leq W_K,$$

em que W_K é o mínimo global da dispersão intragrupos entre todas as partições em K grupos não vazios.

5. Explique por que a monotonicidade de W_K não fornece, sozinha, um número ótimo de grupos.
6. Mostre que translações comuns de todas as observações preservam o critério das K -médias.
7. Determine o efeito de multiplicar todas as coordenadas por uma constante $c \neq 0$ sobre:
 - as distâncias euclidianas;
 - o critério J_K ;
 - a partição que minimiza o critério.

Relacione a discussão de mudança de escala à geometria induzida já praticada em Exercício 7.8.

8. Considere dois grupos A e B , com tamanhos n_A e n_B e centroides $\bar{\mathbf{x}}_A$ e $\bar{\mathbf{x}}_B$. Obtenha o incremento de Ward

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$

9. Explique por que empates no critério de fusão podem produzir mais de uma hierarquia admissível.

Exercício 19.11 (Análise de Correspondência: posto, relações baricêntricas e reconstrução). Considere uma tabela ativa com I linhas, J colunas, massas estritamente positivas e matriz de desvios padronizados

$$\mathbf{Q}_{\text{CA}} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}^\top) \mathbf{D}_c^{-1/2}.$$

1. Mostre que

$$\mathbf{Q}_{\text{CA}} \mathbf{D}_c^{1/2} \mathbf{1}_J = \mathbf{0}$$

e

$$\mathbf{Q}_{\text{CA}}^\top \mathbf{D}_r^{1/2} \mathbf{1}_I = \mathbf{0}.$$

2. Utilize essas relações para justificar

$$\text{posto}(\mathbf{Q}_{\text{CA}}) \leq \min(I - 1, J - 1).$$

3. A partir da SVD

$$\mathbf{Q}_{\text{CA}} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

obtenha a decomposição da inércia total como soma das inércias principais. Utilize diretamente a estrutura de SVD praticada em Exercício 7.13.

4. Obtenha as relações baricêntricas entre coordenadas principais de uma margem e coordenadas padrão da outra.
5. Mostre que as coordenadas padrão e principais são centralizadas em relação às respectivas massas.
6. A partir da reconstrução completa dos desvios da independência, obtenha uma expressão para p_{ij} em função de r_i , c_j , dos valores singulares e das coordenadas padrão.
7. Considere uma reconstrução truncada nas primeiras k dimensões. Mostre que as marginais $\mathbf{r}$ e $\mathbf{c}$ são preservadas. Relacione a truncagem à aproximação de posto reduzido praticada em Exercício 7.14.
8. Explique por que a reconstrução truncada pode, apesar disso, produzir alguma célula negativa.

9. Mostre como a estatística de Pearson pode ser decomposta pelas dimensões e explique por que isso não implica automaticamente que cada termo dimensional possua, isoladamente, uma distribuição qui-quadrado de referência.

Exercício 19.12 (MANOVA: base probabilística, verossimilhança e invariância). Considere o modelo linear multivariado normal com matriz de covariâncias residual $\Sigma \succ \mathbf{0}$ e uma hipótese linear estimável que produz as matrizes aleatórias de hipótese e erro

$$\mathbf{H} \text{ e } \mathbf{E}.$$

Admita que os graus de liberdade residuais sejam suficientes para que $\mathbf{E} \succ \mathbf{0}$ quase certamente. Relacione essa condição aos resultados sobre posto e distribuição Wishart estudados no Módulo II e, ao distinguir resultados exatos e assintóticos, recupere Exercício 12.5.

1. Sob H_0 , identifique as distribuições de Wishart associadas a $\mathbf{H}$ e $\mathbf{E}$ e indique os respectivos graus de liberdade.
2. Explique por que a independência entre $\mathbf{H}$ e $\mathbf{E}$ é importante para a construção das distribuições dos critérios MANOVA.
3. Mostre que as raízes características podem ser obtidas a partir do problema simétrico

$$\mathbf{E}^{-1/2} \mathbf{H} \mathbf{E}^{-1/2} \mathbf{z} = \lambda \mathbf{z}.$$

Relacione a passagem ao problema simétrico com Exercício 7.11 e Exercício 7.12.

4. Obtenha

$$\Lambda_W = \frac{|\mathbf{E}|}{|\mathbf{H} + \mathbf{E}|} = \prod_{j=1}^s \frac{1}{1 + \lambda_j}.$$

5. Relacione a lambda de Wilks à razão de verossimilhanças entre o modelo restrito e o modelo irrestrito.
6. Suponha uma transformação não singular das respostas,

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{A}.$$

Mostre como $\mathbf{H}$ e $\mathbf{E}$ se transformam e prove que as raízes características permanecem inalteradas.

7. Conclua, a partir do item anterior, que Wilks, Pillai, Hotelling–Lawley e Roy são invariantes a transformações lineares não singulares das respostas quando a hipótese é transformada de forma compatível.

8. Considere o caso em que existe no máximo uma raiz não nula. Mostre que Pillai, Hotelling–Lawley e Roy são funções crescentes dessa raiz, enquanto a lambda de Wilks é decrescente, e explique por que os quatro critérios conduzem ao mesmo teste quando a calibração é realizada de forma consistente.

Exercício 19.13 (Análise Discriminante: risco, fronteiras e relações com Fisher). Considere K classes com densidades condicionais $f_k(\mathbf{x})$, probabilidades *a priori* π_k e perdas $L(j | k)$ associadas à decisão pela classe j quando a classe verdadeira é k .

1. Escreva o risco condicional de decidir pela classe j dado $\mathbf{x}$.
2. Mostre que, sob perda zero–um, a regra de Bayes escolhe a classe que maximiza

$$\pi_k f_k(\mathbf{x}).$$

3. Suponha populações normais multivariadas com matrizes de covariâncias específicas Σ_k . Obtenha a função discriminante quadrática, desprezando termos comuns às classes. Ao organizar a derivação, recupere a estrutura da distribuição Normal Multivariada praticada em Exercício 12.2.
4. Mostre que, quando

$$\Sigma_1 = \cdots = \Sigma_K = \Sigma,$$

os termos quadráticos em $\mathbf{x}$ comuns às classes se cancelam e a fronteira entre duas classes torna-se linear.

5. Para duas classes com covariância comum, obtenha a direção da fronteira da LDA e relacione-a a

$$\Sigma^{-1} (\mu_1 - \mu_2).$$

6. No caso de duas classes, mostre que a direção populacional de Fisher é proporcional à mesma quantidade quando a dispersão intragrupos é dada pela covariância comum.
7. Para K grupos, obtenha a decomposição

$$\Sigma = \Sigma_W + \Sigma_B$$

a partir da lei da covariância total.

8. Explique por que o problema espectral de Fisher compartilha a estrutura de dispersões dentro e entre grupos com a MANOVA, embora os objetivos de classificação/discriminação e teste de hipótese sejam diferentes. Relacione a construção espectral a Exercício 7.11 e, quando pertinente, ao branqueamento estudado em Exercício 7.12.
-

Parte III — Aprofundamentos metodológicos e aplicados

Nesta parte, utilize o R. Quando um objeto central da técnica puder ser construído diretamente por operações matriciais, faça primeiro essa construção e utilize funções prontas depois, como conferência ou para ampliar a análise.

As decisões metodológicas devem ser justificadas. Não escolha padronização, número de dimensões, número de fatores, número de grupos, rotação, regra de classificação ou procedimento inferencial apenas porque uma função produziu determinada saída.

Exercício 19.14 (ACP com os dados `USArrests`). Utilize o conjunto de dados `USArrests`.

1. Examine as quatro variáveis e compare suas escalas por meio de médias, desvios padrão, amplitudes e gráficos adequados. Explique por que a decisão entre utilizar a matriz de covariâncias ou a matriz de correlações pode alterar a ACP.
2. Realize duas análises:
 - ACP das variáveis centralizadas sem padronização;
 - ACP das variáveis centralizadas e padronizadas.

Utilize `prcomp()` apenas depois de identificar quais matrizes estão sendo decompostas em cada caso.

3. Para cada análise, obtenha:
 - autovalores;
 - proporções de variância;
 - proporções acumuladas;
 - coeficientes das componentes;
 - escores das observações.
4. Compare as duas soluções e identifique quais variáveis dominam as primeiras componentes quando os dados não são padronizados.
5. Para a ACP padronizada, examine o gráfico de declive e a proporção acumulada de variância. Proponha um número de componentes a manter e justifique a escolha.

6. Construa a reconstrução das observações utilizando apenas as componentes retidas. Para a ACP baseada nas variáveis padronizadas, calcule inicialmente o erro quadrático de reconstrução na própria escala padronizada utilizada para construir a solução. Identifique os estados com maior perda de representação e explique por que esses erros não devem ser interpretados diretamente nas unidades originais das quatro variáveis. Relacione a reconstrução à projeção ortogonal praticada em Exercício 7.24.
7. Interprete as duas primeiras componentes a partir dos coeficientes e das correlações variável-componente. Não trate automaticamente coeficientes elevados como equivalentes a correlações elevadas.
8. Faça um gráfico dos escores das duas primeiras componentes e descreva padrões de posição entre os estados sem transformar proximidade gráfica em evidência de agrupamentos populacionais.

Exercício 19.15 (Análise Fatorial com os dados `USJudgeRatings`). Utilize como variáveis ativas as onze avaliações de INTG a RTEN do conjunto `USJudgeRatings`. A variável `CONT`, que registra o número de contatos do advogado com o juiz, não deve participar da construção da estrutura fatorial.

1. Construa a matriz de correlações e examine:

- magnitude das correlações;
- determinante da matriz;
- autovalores.

Ao interpretar a matriz, retome a estrutura de covariâncias e correlações praticada em Exercício 12.1.

2. Calcule o teste de esfericidade de Bartlett a partir da matriz de correlações, do número de variáveis e do tamanho amostral. Informe a hipótese testada, a estatística, os graus de liberdade e o valor- p .
3. Calcule o KMO global por operações matriciais:
 - obtenha a inversa da matriz de correlações;
 - construa as correlações parciais;
 - utilize as somas dos quadrados das correlações e correlações parciais.

Interprete o resultado como medida de adequação à estrutura fatorial, sem tratá-lo como teste de existência de um modelo fatorial verdadeiro.

4. Examine o gráfico de declive dos autovalores da matriz de correlações como informação exploratória inicial. Em seguida, compare os ajustes por máxima verossimilhança com um, dois e três fatores. Não trate os autovalores da matriz de correlações original como se fossem automaticamente as raízes produzidas por todos os métodos de extração.

5. Ajuste modelos fatoriais por máxima verossimilhança com `factanal()` para os números de fatores admissíveis considerados, utilizando inicialmente `rotation = "none"`. Para cada solução:

- examine as unicidades;
- examine as cargas não rotacionadas;
- examine o teste de ajuste global quando disponível;
- construa a matriz reproduzida

$$\widehat{\mathbf{R}} = \widehat{\Phi}\widehat{\Phi}^\top + \widehat{\Psi}$$

e a matriz de resíduos

$$\mathbf{R} - \widehat{\mathbf{R}}.$$

Identifique os maiores resíduos em valor absoluto.

6. Escolha uma solução e aplique rotação Varimax. Compare as cargas antes e depois da rotação e verifique que a rotação ortogonal não altera as comunalidades nem a matriz de covariâncias comuns reproduzida.
7. Identifique as variáveis que mais caracterizam cada fator e proponha uma interpretação apenas quando o conjunto de cargas sustentar uma dimensão coerente.
8. Discuta se outra rotação, inclusive oblíqua, poderia ser plausível. Explique o que mudaria na interpretação se os fatores fossem autorizados a se correlacionar.

Exercício 19.16 (Agrupamentos com os dados `USArrests`). Utilize o conjunto `USArrests`.

1. Compare as escalas das quatro variáveis e execute a análise com os dados padronizados. Explique por que essa decisão é particularmente relevante em métodos baseados em distância euclidiana e relacione a discussão de métrica à geometria induzida praticada em Exercício 7.8.
2. Aplique K -médias para

$$K = 2, \dots, 6,$$

utilizando várias inicializações por meio do argumento `nstart`. Registre a dispersão intragrupos total de cada solução.

3. Construa o gráfico da dispersão intragrupos em função de K e identifique valores candidatos de K . Não faça ainda uma escolha definitiva apenas a partir desse gráfico.

4. Para pelo menos dois valores de K , repita o algoritmo com diferentes sementes e com `nstart = 1`. Investigue se diferentes inicializações produzem soluções distintas. Caso as soluções obtidas coincidam, explique por que essa coincidência não demonstra que o mínimo global foi encontrado.
5. Utilize `hclust()` com:
 - ligação simples;
 - ligação completa;
 - ligação média;
 - `ward.D2`.

Compare os dendrogramas e explique por que métodos diferentes podem produzir hierarquias diferentes sobre os mesmos dados.

6. Para os valores candidatos de K identificados no item 3, corte o dendrograma de Ward e compare as partições com as soluções das K -médias por meio de tabelas cruzadas de pertencas.
7. Utilize a silhueta, por meio do pacote `cluster`, para avaliar as soluções consideradas. Compare a silhueta média para diferentes números de grupos e, combinando esse resultado com o comportamento da dispersão intragrupos e a interpretação dos grupos, proponha um valor de K para a solução final.
8. Identifique observações cuja presença parece influenciar fortemente as soluções. Refaça, apenas como análise de sensibilidade, a solução após retirar uma dessas observações e descreva as alterações. Não utilize essa comparação como justificativa automática para excluir a observação da análise final.
9. Realize uma ACP das quatro variáveis padronizadas. Verifique que, quando todas as componentes são mantidas, as distâncias euclidianas entre as observações são preservadas pela transformação ortogonal. Em seguida, repita o agrupamento utilizando apenas as duas primeiras componentes e compare a solução com aquela obtida no espaço padronizado completo. Explique por que a redução de dimensão, ao contrário de uma transformação ortogonal completa, pode modificar o problema de agrupamento. Utilize, quando necessário, Exercício 7.24 e Exercício 7.26.

Exercício 19.17 (Análise de Correspondência com `HairEyeColor`). Utilize

```
tab <- apply(
  HairEyeColor,
  c(1, 2),
  sum
)
```

para obter uma tabela entre cor do cabelo e cor dos olhos, agregada sobre sexo.

1. Construa diretamente:
 - a matriz de frequências relativas $\mathbf{P}$;
 - as massas das linhas e colunas;
 - os perfis de linhas e colunas;
 - a matriz de desvios padronizados $\mathbf{Q}_{CA}$.
2. Calcule a estatística qui-quadrado de Pearson e a inércia total. Verifique numericamente

$$\chi^2 = n\mathcal{I}.$$

3. Aplique `svd()` a $\mathbf{Q}_{CA}$ e obtenha:

- valores singulares;
- inércias principais;
- proporções de inércia;
- proporções acumuladas.

Relacione a decomposição obtida à SVD e à aproximação truncada praticadas em Exercício 7.13 e Exercício 7.26.

4. Determine o número máximo de dimensões não triviais e proponha quantas dimensões utilizar na representação reduzida.
5. Construa as coordenadas padrão e principais das linhas e das colunas.
6. Verifique numericamente que as distâncias euclidianas entre coordenadas principais completas de uma mesma margem reproduzem as distâncias qui-quadrado entre os respectivos perfis.
7. Para as duas primeiras dimensões, calcule:
 - contribuições das categorias;
 - $\cos^2$;
 - qualidade de representação acumulada.

Identifique categorias importantes para construir cada dimensão e categorias bem representadas no plano.

8. Construa um mapa com as categorias de cabelo e olhos. Interprete:
 - posições dentro da nuvem de linhas;
 - posições dentro da nuvem de colunas;
 - associações sugeridas pela geometria conjunta.

Não interprete a distância euclidiana entre uma categoria de linha e uma categoria de coluna como uma distância qui-quadrado definida pela técnica.

Exercício 19.18 (MANOVA com os dados `iris`). Utilize `Species` como fator de grupos e as quatro medidas quantitativas de `iris` como vetor de respostas.

1. Determine:

- número de grupos;
- tamanho de cada grupo;
- dimensão do vetor resposta;
- vetores de médias amostrais;
- matrizes de covariâncias por grupo.

2. Ajuste o modelo multivariado

```
ajuste <- manova(  
  cbind(  
    Sepal.Length,  
    Sepal.Width,  
    Petal.Length,  
    Petal.Width  
  ) ~ Species,  
  data = iris  
)
```

3. Retome a construção das matrizes SQPC estudada no modelo linear multivariado do Módulo II, em particular Exercício 12.4. A partir do ajuste:

- obtenha a matriz residual e construa

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}};$$

- construa a SQPC total das respostas centralizadas;
- utilize a decomposição entre variação total, entre grupos e residual para obter $\mathbf{H}$;
- verifique numericamente que $\mathbf{E}$ é não singular.

Compare a função de $\mathbf{H}$ e $\mathbf{E}$ neste exercício com a SQPC de hipótese e a SQPC residual já estudadas no Módulo II.

4. Calcule as raízes características do problema

$$\mathbf{H}\mathbf{a} = \lambda\mathbf{E}\mathbf{a}$$

e, a partir delas, obtenha manualmente: - lambda de Wilks; - traço de Pillai; - traço de Hotelling–Lawley; - maior raiz de Roy.

5. Compare os valores do item anterior com as saídas de `summary()` para os quatro testes.
6. Examine separadamente:
 - quais informações seriam necessárias no delineamento ou no processo de amostragem para justificar a independência entre unidades;
 - a plausibilidade de covariância residual comum;
 - a não singularidade da matriz residual;
 - a plausibilidade da normalidade multivariada dos erros por meio dos diagnósticos disponíveis.

Explique quais dessas condições podem ser investigadas a partir dos dados observados e quais dependem do modo como os dados foram obtidos. Não trate ausência de evidência gráfica contra uma hipótese como demonstração de que ela é verdadeira.

7. Depois do teste multivariado global, examine os testes univariados para cada resposta. Explique por que esses testes não reproduzem a MANOVA e por que uma estratégia de acompanhamento deve considerar multiplicidade e finalidade da análise.
8. Compare os quatro critérios quanto à conclusão global. Explique por que valores numéricos diferentes não significam que estejam testando hipóteses multivariadas distintas.

Exercício 19.19 (Análise Discriminante com os dados `iris`). Utilize as quatro variáveis quantitativas de `iris` para classificar `Species`.

1. Fixe uma semente e divida os dados de cada espécie em uma amostra de treinamento com aproximadamente 70% das observações e uma amostra de teste com as restantes. Preserve todas as espécies nos dois conjuntos.
2. Na amostra de treinamento, calcule:
 - vetores de médias por classe;
 - matrizes de covariâncias por classe;
 - matriz de covariâncias agrupada;
 - probabilidades *a priori* empíricas.

Relacione a estimação das matrizes de covariâncias ao que foi praticado em Exercício 12.3.

3. Ajuste uma LDA com `MASS::lda()` utilizando primeiro probabilidades *a priori* iguais. Examine:
 - coeficientes discriminantes;
 - número de direções;
 - proporções associadas às raízes discriminantes;
 - coordenadas discriminantes das observações de treinamento.

4. Utilize a regra para classificar as observações da amostra de teste. Construa a matriz de classificação e calcule:
 - erro global;
 - proporção de acertos por classe;
 - tipos de erro mais frequentes.
5. Considere agora uma população-alvo hipotética na qual as proporções das três espécies sejam

$$\pi = \begin{bmatrix} 0,60 \\ 0,20 \\ 0,20 \end{bmatrix}.$$

Refça a LDA utilizando essas probabilidades *a priori* e compare as funções discriminantes e as classificações com aquelas obtidas sob probabilidades iguais. Explique por que a alteração das probabilidades *a priori* modifica a regra de decisão mesmo quando as médias e a matriz de covariâncias permanecem inalteradas.

6. Ajuste também uma QDA com `MASS::qda()`. Compare sua matriz de classificação com a da LDA e relacione as diferenças à hipótese de covariância comum.
7. Calcule o erro aparente da LDA na amostra de treinamento e compare com o erro na amostra de teste. Explique por que o erro aparente pode ser otimista.
8. Na amostra de treinamento, utilize `MASS::lda(..., CV = TRUE)` para obter a classificação por validação cruzada *leave-one-out*. Calcule a taxa de erro correspondente e compare:
 - erro aparente;
 - erro por validação cruzada;
 - erro na amostra de teste.

Explique por que essas três quantidades utilizam os dados de maneiras diferentes e não precisam coincidir.

9. Identifique observações mal classificadas e examine suas posições nas duas primeiras coordenadas discriminantes. Discuta se os erros ocorrem em regiões de sobreposição entre as classes.
10. Conclua indicando:
 - qual regra apresentou melhor desempenho sob a divisão treinamento–teste e as probabilidades *a priori* adotadas;
 - quais hipóteses, probabilidades *a priori*, critérios de avaliação e decisões metodológicas sustentam essa comparação;

- se as diferentes formas de estimar o erro conduzem à mesma conclusão;
- por que o desempenho observado neste exercício não deve ser tratado como propriedade populacional definitiva da regra.

Referências

ANDERSON, Theodore W. **An Introduction to Multivariate Statistical Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

ANDERSON, Theodore W.; RUBIN, Herman. Statistical Inference in Factor Analysis. *In*: Berkeley: University of California Press, 1956. Disponível em: <https://digitalassets.lib.berkeley.edu/math/ucb/text/math_s3_v5_article-10.pdf>. Acesso em: 3 ago. 2026

APOSTOL, Tom M. **Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability**. 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. **Métodos multivariados de análise estatística**. 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. **Measure, Integration & Real Analysis**. Cham: Springer, 2020. v. 282

BARTLETT, M. S. The Statistical Conception of Mental Factors. **British Journal of Psychology**, v. 28, p. 97–104, 1937.

BARTLETT, M. S. Tests of Significance in Factor Analysis. **British Journal of Psychology (Statistical Section)**, v. 3, p. 77–85, 1950.

BERGE}, {Jos M. F. }. {ten *et al.* [Some new results on correlation-preserving factor scores prediction methods](#). **Linear Algebra and Its Applications**, v. 289, n. 1-3, p. 311–318, 1 mar. 1999.

BOYD, Stephen; VANDENBERGHE, Lieven. **Convex Optimization**. Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury, 2002.

CHRISTENSEN, Ronald. **Plane Answers to Complex Questions: The Theory of Linear Models**. 4. ed. New York: Springer, 2011. p. 494

DEMME, James W. [Singular Value Decomposition](#). In: BAI, Zhaojun *et al.* (Orgs.). **Templates for the Solution of Algebraic Eigenvalue Problems: A Practical Guide**. Philadelphia: Society for Industrial; Applied Mathematics, 2000. p. 135–147.

DRISCOLL, Tobin A.; BRAUN, Richard J. [Fundamentals of Numerical Computation: Julia Edition](#). Philadelphia: Society for Industrial; Applied Mathematics, 2022. p. 614

EATON, Morris L. [Multivariate Statistics: A Vector Space Approach](#). Beachwood, OH: Institute of Mathematical Statistics, 2007. v. 53 p. 512

EVERITT, Brian S. *et al.* [Cluster Analysis](#). 5. ed. Chichester: John Wiley & Sons, 2011. p. 352

GOLUB, Gene H.; VAN LOAN, Charles F. [Matrix Computations](#). 4. ed. Baltimore: Johns Hopkins University Press, 2013.

GOWER, John C. [A General Coefficient of Similarity and Some of Its Properties](#). **Biometrics**, v. 27, n. 4, p. 857–871, 1971.

GRICE, James W. [Computing and Evaluating Factor Scores](#). **Psychological Methods**, v. 6, n. 4, p. 430–450, 2001.

GUPTA, Arjun K.; NAGAR, Daya K. [Matrix Variate Distributions](#). Boca Raton: Chapman & Hall/CRC, 1999.

HAIR, Jr., Joseph F. *et al.* **Análise Multivariada de Dados**. Tradução: Adonai Schlup Sant’Anna. 6. ed. Porto Alegre: Bookman, 2009.

HAIR, Jr., Joseph F. *et al.* [Multivariate Data Analysis](#). 8. ed. Andover: Cengage Learning, 2018.

HARVILLE, David A. [Matrix Algebra From a Statistician’s Perspective](#). New York: Springer, 1997. p. 634

HENDRICKSON, Alan E.; WHITE, Paul Owen. [Promax: A Quick Method for Rotation to Oblique Simple Structure](#). **British Journal of Statistical Psychology**, v. 17, n. 1, p. 65–70, 1964.

HORN, Roger A.; JOHNSON, Charles R. [Topics in Matrix Analysis](#). Cambridge: Cambridge University Press, 1991.

HORN, Roger A.; JOHNSON, Charles R. [Matrix Analysis](#). 2. ed. Cambridge: Cambridge University Press, 2013.

- HUANG, Zhexue. [Extensions to the \$k\$ -Means Algorithm for Clustering Large Data Sets with Categorical Values](#). **Data Mining and Knowledge Discovery**, v. 2, n. 3, p. 283–304, 1998.
- HUBERTY, Carl J.; OLEJNIK, Stephen. [Applied MANOVA and Discriminant Analysis](#). 2. ed. Hoboken, NJ: John Wiley & Sons, 2006.
- JENNRICH, Robert I. [Admissible Values of Gamma in Direct Oblimin Rotation](#). **Psychometrika**, v. 44, n. 2, p. 173–177, 1979.
- JENNRICH, Robert I.; SAMPSON, P. F. [Rotation for Simple Loadings](#). **Psychometrika**, v. 31, p. 313–323, 1966.
- JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 5. ed. Upper Saddle River, NJ: Prentice Hall, 2002.
- JOHNSON, Richard A.; WICHERN, Dean W. [Applied Multivariate Statistical Analysis](#). 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.
- JOLLIFFE, Ian T. [Principal Component Analysis](#). 2. ed. New York: Springer, 2002. p. 488
- KAISER, Henry F. [The Varimax Criterion for Analytic Rotation in Factor Analysis](#). **Psychometrika**, v. 23, n. 3, p. 187–200, 1958.
- KAUFMAN, Leonard; ROUSSEEUW, Peter J. [Finding Groups in Data: An Introduction to Cluster Analysis](#). New York: John Wiley & Sons, 1990.
- LAWLEY, D. N.; MAXWELL, A. E. [Factor Analysis as a Statistical Method](#). 2. ed. London: Butterworths, 1971.
- LÊ, Sébastien; JOSSE, Julie; HUSSON, François. [FactoMineR: A Package for Multivariate Analysis](#). **Journal of Statistical Software**, v. 25, n. 1, p. 1–18, 2008.
- LEBLAY, Thomas *et al.* **MEDA: Multivariate Exploratory Data Analysis with jamovi and FactoMineR**. Disponível em: <<https://sebastien-le.github.io/medasite/>>. Acesso em: 1 set. 2026.
- LEDOIT, Olivier; WOLF, Michael. [A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices](#). **Journal of Multivariate Analysis**, v. 88, n. 2, p. 365–411, 2004.
- MACQUEEN, James. Some Methods for Classification and Analysis of Multivariate Observations. In: Berkeley: University of California Press, 1967. Disponível em: <<https://projecteuclid.org/euclid.bsmsp/1200512992>>. Acesso em: 3 ago. 2026

- MAGNUS, Jan R.; NEUDECKER, Heinz. **Matrix Differential Calculus with Applications in Statistics and Econometrics**. 3. ed. Chichester: John Wiley & Sons, 2019. p. 504
- MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. **Métodos Estatísticos Multivariados: Uma Introdução**. 4. ed. Porto Alegre: Bookman, 2019. p. 254
- MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. **Multivariate Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2024. p. 592
- MARONNA, Ricardo A. *et al.* **Robust Statistics: Theory and Methods (with R)**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464
- MEYER, Carl D. **Matrix Analysis and Applied Linear Algebra**. 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991
- MINGOTI, Sueli Aparecida. **Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada**. Belo Horizonte: Editora UFMG, 2005.
- MUIRHEAD, Robb J. **Aspects of Multivariate Statistical Theory**. New York: John Wiley & Sons, 1982.
- PILLAI, K. C. S. **Some New Test Criteria in Multivariate Analysis**. **The Annals of Mathematical Statistics**, v. 26, n. 1, p. 117–121, 1955.
- RAO, C. Radhakrishna. **Linear Statistical Inference and Its Applications**. 2. ed. New York: John Wiley & Sons, 1973.
- RENCER, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2012.
- RIPLEY, Brian D.; VENABLES, William N. **Modern Applied Statistics with S**. Fourth ed. New York: Springer, 2002.
- SEOL, Hyunsoo. **snowCluster: Multivariate Analysis**. Disponível em: <<https://github.com/hyunsooseol/snowCluster>>. Acesso em: 1 set. 2026.
- SIDI, Avram. **Vector Extrapolation Methods with Applications**. Philadelphia: Society for Industrial; Applied Mathematics, 2017. p. 381
- SUZUKI, Ryota; SHIMODAIRA, Hidetoshi. **Pvclust: an R package for assessing the uncertainty in hierarchical clustering**. **Bioinformatics**, v. 22, n. 12, p. 1540–1542, 2006.
- THE JAMOVI PROJECT. **jamovi (Version 2.7) [Computer Software]**., 2026. Disponível

em: <<https://www.jamovi.org>>. Acesso em: 1 set. 2026

TIBSHIRANI, Robert; WALTHER, Guenther; HASTIE, Trevor. [Estimating the Number of Clusters in a Data Set via the Gap Statistic](#). **Journal of the Royal Statistical Society: Series B (Statistical Methodology)**, v. 63, n. 2, p. 411–423, 2001.

VAART, A. W. van der. [Asymptotic Statistics](#). Cambridge: Cambridge University Press, 1998. p. 462

WARD, Jr., Joe H. [Hierarchical Grouping to Optimize an Objective Function](#). **Journal of the American Statistical Association**, v. 58, n. 301, p. 236–244, 1963.

WILKS, Samuel S. [Certain Generalizations in the Analysis of Variance](#). **Biometrika**, v. 24, n. 3–4, p. 471–494, 1932.