

Fundamentos e Formulação da Análise Multivariada

Departamento de Estatística e Matemática Aplicada/CC/UFC

Laboratório de Inovação em Estatística - StatLab

Grupo de pesquisa de Inovação em Estatística e Ciência de Dados

Versão Preliminar
- Em Elaboração -



Índice

Informações Legais e Declaração de Uso de Inteligência Artificial	16
Direitos Autorais e Uso da Obra	16
Declaração sobre o Uso de Ferramentas de Inteligência Artificial	16
Prefácio	17
Identificação da Disciplina	18
EMENTA	18
OBJETIVO GERAL	18
OBJETIVOS ESPECÍFICOS	18
CONTEÚDO PROGRAMÁTICO	19
Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada	19
Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada	19
Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas	19
METODOLOGIA	20
AVALIAÇÃO	20
CRITÉRIOS DE AVALIAÇÃO	20
BIBLIOGRAFIA BÁSICA	21
BIBLIOGRAFIA COMPLEMENTAR	21
 I Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multi-	
 variada	22
 1 Vetores e representação dos dados multivariados	23
1.1 Escalares, vetores e matrizes	24
1.1.1 Vetor-coluna, vetor-linha e transposição	27
1.2 O espaço $\mathbb{R}^p$	28
1.3 Representação matricial de um conjunto de dados	31
1.3.1 Espaço das observações e espaço das variáveis	33
1.4 Operações elementares com vetores	34
1.4.1 Soma e subtração	34
1.4.2 Multiplicação por escalar	35
1.4.3 Combinações lineares	37
1.5 Produto interno, norma, ângulo e distância euclidiana	39
1.5.1 Produto interno euclidiano	39

1.5.2	Norma euclidiana	40
1.5.3	Desigualdade de Cauchy–Schwarz	41
1.5.4	Ângulo entre vetores	44
1.5.5	Distância euclidiana	46
1.5.6	Desigualdade triangular	48
1.5.7	Produto externo	49
1.6	Síntese do capítulo	51
2	Álgebra matricial aplicada	53
2.1	Operações matriciais fundamentais	54
2.1.1	Soma e subtração de matrizes	55
2.1.2	Produto matriz-vetor	58
2.1.3	Produto entre matrizes	61
2.1.4	Propriedades do produto matricial	65
2.1.5	Produto externo como caso particular do produto matricial	66
2.2	Transposição, simetria e traço	67
2.2.1	Transposição	67
2.2.2	Propriedades da transposição	68
2.2.3	Matrizes simétricas	70
2.2.4	Traço	74
2.3	Identidade, inversa, determinante, posto e sistemas lineares	77
2.3.1	Matriz identidade	77
2.3.2	Matriz inversa	78
2.3.3	Determinante	81
2.3.4	Interpretação geométrica do determinante	85
2.3.5	Posto	86
2.3.6	Sistemas lineares	89
2.3.7	Aprofundamento: pseudoinversa	93
2.4	Matrizes ortogonais, diagonais e triangulares	94
2.4.1	Matrizes ortogonais	95
2.4.2	Matrizes diagonais	97
2.4.3	Matrizes triangulares	100
2.4.4	Aprofundamento: sistemas triangulares	101
2.5	Formas bilineares, formas quadráticas e positividade	103
2.5.1	Formas bilineares	103
2.5.2	Formas quadráticas	104
2.5.3	Positividade	107
2.5.4	Superfícies de nível	109
2.6	Aprofundamento: matrizes particionadas e complemento de Schur	110
2.6.1	Matrizes particionadas	111
2.6.2	Soma e multiplicação por escalar	112
2.6.3	Transposição por blocos	113
2.6.4	Multiplicação por blocos	113

2.6.5	Complemento de Schur	115
2.6.6	Determinante de uma matriz particionada	116
2.6.7	Inversão em blocos	118
2.6.8	Positividade e complemento de Schur	118
2.7	Síntese do capítulo	120
3	Espaços vetoriais, bases e projeções	123
3.1	Espaços, subespaços e geração	123
3.1.1	Subespaços vetoriais	125
3.1.2	Subespaço gerado	127
3.2	Independência linear, bases e dimensão	128
3.2.1	Independência linear	128
3.2.2	Independência linear e sistemas homogêneos	130
3.2.3	Bases	133
3.2.4	Coordenadas em uma base	134
3.2.5	Base canônica	136
3.2.6	Bases ortogonais e ortonormais	137
3.2.7	Dimensão	139
3.3	Espaços fundamentais de uma matriz	141
3.3.1	Espaço nulo	141
3.3.2	Espaço coluna e imagem	144
3.3.3	Espaço linha	146
3.3.4	Espaço nulo à esquerda	148
3.3.5	Espaço nulo à esquerda	148
3.3.6	Teorema Posto–Nulidade	150
3.3.7	Os quatro espaços fundamentais	153
3.3.8	Complemento ortogonal	154
3.3.9	Relações de ortogonalidade	154
3.4	Produtos internos, bases ortonormais e matrizes de Gram	156
3.4.1	Produtos internos induzidos por matrizes	156
3.4.2	Norma e distância induzidas	158
3.4.3	Ortogonalidade induzida	159
3.4.4	Interpretação por transformação de coordenadas	160
3.4.5	Matrizes de Gram	161
3.4.6	Propriedades da matriz de Gram	163
3.4.7	Matrizes de Gram e bases ortonormais	165
3.4.8	Produtos cruzados em uma matriz de dados	166
3.4.9	Propriedades do complemento ortogonal	167
3.4.10	Dimensão do complemento ortogonal	169
3.4.11	Decomposição ortogonal	172
3.4.12	Decomposição dos espaços fundamentais	174
3.4.13	Projeção sobre uma direção	175
3.4.14	Projeção sobre um subespaço com base ortonormal	180

3.4.15	Projeção sobre o espaço coluna de uma matriz	183
3.4.16	Propriedades da matriz de projeção	187
3.4.17	Projeção sobre o complemento ortogonal	191
3.4.18	Projeção como melhor aproximação	197
3.4.19	Projeções e mínimos quadrados	200
3.5	Síntese do capítulo	204
4	Transformações lineares	213
4.1	Transformações lineares e representação matricial	213
4.1.1	Transformação determinada por uma base	215
4.1.2	Representação matricial nas bases canônicas	217
4.1.3	Imagem de um subespaço	219
4.2	Transformação de vetores e matrizes de dados	220
4.2.1	Novas variáveis como combinações lineares	222
4.2.2	Dimensão da configuração transformada	224
4.2.3	Efeito sobre diferenças e produtos internos	227
4.2.4	Transformação das matrizes de produtos internos	228
4.3	Composição, invertibilidade e perda de informação	229
4.3.1	Composição de transformações lineares	230
4.3.2	A ordem das transformações	231
4.3.3	Transformação inversa	233
4.3.4	Injetividade, sobrejetividade e bijetividade	235
4.3.5	Perda de informação	239
4.3.6	Redução de dimensionalidade	240
4.3.7	Transformações singulares	241
4.4	Transformações geométricas	242
4.4.1	Rotação	243
4.4.2	Reflexão	244
4.4.3	Escalonamento	246
4.4.4	Cisalhamento	247
4.4.5	Projeção	249
4.4.6	Comparação geométrica	249
4.4.7	Determinante, volume e orientação	251
4.5	Transformações ortogonais	252
4.5.1	Transformação de uma matriz de dados	254
4.5.2	Determinante e orientação	255
4.5.3	Matrizes ortogonais e bases ortonormais	256
4.5.4	Comparação com transformações não ortogonais	257
4.6	Mudanças de coordenadas e representação em bases	258
4.6.1	Conversão entre duas bases	260
4.6.2	Representação de uma transformação em bases gerais	261
4.6.3	Representação de um operador em uma nova base	264
4.6.4	Transformação ativa e mudança passiva	266

4.6.5	Mudança de coordenadas de uma matriz de dados	267
4.7	Transformações afins e pré-processamento	268
4.7.1	Translação	269
4.7.2	Transformação afim de uma matriz de dados	270
4.7.3	Centralização	271
4.7.4	Escalonamento das variáveis	273
4.7.5	Padronização	274
4.7.6	Ordem entre centralização e escalonamento	275
4.7.7	Composição e inversão de transformações afins	276
4.7.8	Comparação das operações de pré-processamento	277
4.8	Síntese do capítulo	278
5	Autovalores, autovetores e decomposição espectral	282
5.1	Direções invariantes, autovalores e autoespaços	282
5.2	Equação característica, multiplicidades e diagonalização	290
5.2.1	Determinação dos autovalores e autoespaços	292
5.2.2	Autovalores complexos de matrizes reais	294
5.2.3	Independência entre autovetores	295
5.2.4	Multiplicidades algébrica e geométrica	297
5.2.5	Diagonalização	299
5.2.6	Potências de uma matriz diagonalizável	302
5.3	Matrizes simétricas e decomposição espectral	303
5.3.1	Decomposição espectral do exemplo condutor	308
5.3.2	Forma aditiva da decomposição espectral	310
5.3.3	Projetores sobre autoespaços	311
5.3.4	Não unicidade da matriz de autovetores	313
5.4	Consequências da decomposição espectral	314
5.4.1	Traço, determinante, posto e invertibilidade	315
5.4.2	Formas quadráticas em coordenadas espectrais	318
5.4.3	Superfícies de nível em coordenadas espectrais	321
5.5	Quociente de Rayleigh e otimização espectral	324
5.5.1	Representação espectral	325
5.5.2	Exemplo bidimensional	328
5.5.3	Formulação com restrição de norma	331
5.5.4	Multiplicadores de Lagrange	331
5.5.5	Direções sucessivas	333
5.6	Funções espectrais de matrizes	335
5.6.1	Ação sobre os autoespaços	337
5.6.2	Potências inteiras	338
5.6.3	Inversa espectral	339
5.6.4	Raiz quadrada principal	340
5.6.5	Raiz quadrada inversa	341
5.6.6	Pseudoinversa espectral	342

5.6.7	Exponencial e logaritmo matriciais	344
5.7	Autovalores generalizados	345
5.7.1	Quociente de Rayleigh generalizado	347
5.7.2	Redução a um problema espectral ordinário	348
5.7.3	Ortogonalidade na métrica de $\mathbf{M}$	351
5.7.4	Diagonalização simultânea por congruência	352
5.7.5	Exemplo numérico	354
5.8	Síntese do capítulo	358
6	Decomposição em Valores Singulares	361
6.1	Definição e formas da Decomposição em Valores Singulares	362
6.1.1	Vetores singulares	364
6.1.2	Interpretação como composição de transformações	366
6.1.3	SVD completa	367
6.1.4	SVD compacta	368
6.1.5	SVD compacta e SVD truncada	369
6.1.6	Não unicidade dos vetores singulares	370
6.2	Construção da SVD e relação com a decomposição espectral	372
6.2.1	Simetria e semidefinição positiva	373
6.2.2	Construção dos vetores singulares	378
6.2.3	Demonstração da existência da SVD completa	381
6.2.4	Decomposições espectrais associadas	383
6.2.5	Exemplo de construção da SVD	384
6.2.6	Relação com a decomposição espectral de matrizes simétricas	388
6.3	Interpretação geométrica da SVD	390
6.3.1	Imagem da bola unitária	391
6.3.2	Alteração dos comprimentos	394
6.3.3	Exemplo geométrico no plano	396
6.3.4	Transformações de posto deficiente	397
6.4	Espaços fundamentais, posto, normas e condicionamento	398
6.4.1	Espaço coluna e espaço linha	399
6.4.2	Projetores ortogonais	403
6.4.3	Posto e nulidades	406
6.4.4	Produto interno de Frobenius	407
6.4.5	Normas e valores singulares	408
6.4.6	Invariância ortogonal	410
6.4.7	Determinante e invertibilidade	411
6.4.8	Menor valor singular	412
6.4.9	Número de condição	413
6.4.10	Posto exato e posto numérico	417
6.5	SVD de uma matriz de dados	418
6.5.1	Coordenadas no espaço das variáveis	419
6.5.2	Coordenadas no espaço das observações	420

6.5.3	Matrizes de Gram	421
6.5.4	Reconstrução das observações	423
6.5.5	Preservação de produtos internos	424
6.5.6	Centralização da matriz de dados	425
6.5.7	Relação com a matriz de covariâncias amostral	426
6.5.8	Magnitude quadrática da matriz centralizada	427
6.5.9	Representação exata e aproximação	429
6.6	Forma expandida e aproximações de posto reduzido	430
6.6.1	Parcelas de posto 1	431
6.6.2	Ortogonalidade das parcelas	431
6.6.3	SVD truncada	433
6.6.4	Ortogonalidade entre aproximação e diferença	434
6.6.5	Erro na norma espectral	435
6.6.6	Teorema de Eckart–Young–Mirsky	435
6.6.7	Unicidade da aproximação	440
6.6.8	Exemplo de aproximação de posto 1	441
6.6.9	Aproximação de uma matriz de dados	443
6.7	Pseudoinversa e soluções de mínimos quadrados	444
6.7.1	Relação com a pseudoinversa espectral	446
6.7.2	Condições de Moore–Penrose	447
6.7.3	Pseudoinversa e projetores	451
6.7.4	Sistemas lineares compatíveis	452
6.7.5	Solução de menor norma	454
6.7.6	Sistemas incompatíveis e mínimos quadrados	455
6.7.7	Resíduo de mínimos quadrados	457
6.7.8	Conjunto das soluções de mínimos quadrados	458
6.7.9	Expressão espectral da solução	461
6.7.10	Valores singulares pequenos e instabilidade	462
6.7.11	Pseudoinversa truncada	463
6.7.12	Exemplo com o sistema condutor	463
6.8	Síntese do capítulo	466
7	Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada	471
7.1	Funções, variações e diferenciais	471
7.1.1	Tipos de funções	471
7.1.2	Convenções de derivação	474
7.1.3	Variação de uma função	475
7.1.4	Diferencial	477
7.1.5	Aproximação ao longo de uma direção	478
7.1.6	Diferenciabilidade de funções vetoriais	480
7.2	Gradiente, derivada direcional, Jacobiana e Hessiana	481
7.2.1	Gradiente e derivada direcional	481
7.2.2	Gradiente e conjuntos de nível	483

7.2.3	Jacobiana	485
7.2.4	Regra da cadeia	488
7.2.5	Hessiana	490
7.3	Aproximações de Taylor e classificação local	492
7.3.1	Aproximação de Taylor de primeira ordem	492
7.3.2	Aproximação de Taylor de segunda ordem	494
7.3.3	Pontos estacionários	495
7.3.4	Classificação pela Hessiana	496
7.3.5	Caso inconclusivo	498
7.4	Convexidade e concavidade	499
7.4.1	Conjuntos convexos	499
7.4.2	Funções convexas	500
7.4.3	Caracterização de primeira ordem	500
7.4.4	Caracterização pela Hessiana	501
7.4.5	Consequências para otimização	502
7.4.6	Funções quadráticas	503
7.5	Otimização sem restrições	504
7.5.1	Método de Newton	505
7.6	Otimização com restrições de igualdade	506
7.6.1	Multiplicadores de Lagrange	507
7.6.2	Relação com problemas de autovalores	510
7.6.3	Restrições lineares	511
7.7	Derivadas de formas lineares, quadráticas e funções de resíduos	512
7.7.1	Formas lineares e bilineares	512
7.7.2	Formas quadráticas	513
7.7.3	Norma euclidiana	515
7.7.4	Funções de resíduos lineares	516
7.7.5	Equações normais	517
7.7.6	Mínimos quadrados ponderados	519
7.7.7	Funções compostas de resíduos	520
7.7.8	Mínimos quadrados não lineares	521
7.8	Diferenciais matriciais e cálculo por traços	522
7.8.1	Regras básicas do diferencial matricial	523
7.8.2	Identidades de traço	524
7.8.3	Função linear de uma matriz	526
7.8.4	Norma de Frobenius	527
7.8.5	Funções quadráticas de uma matriz	528
7.8.6	Funções matriciais de resíduos	529
7.8.7	Ponderação de observações e respostas	532
7.9	Derivadas de inversas, determinantes e log-determinantes	533
7.9.1	Diferencial da matriz inversa	533
7.9.2	Diferencial do determinante	535
7.9.3	Diferencial do log-determinante	536

7.9.4	Segunda variação do log-determinante	537
7.9.5	Traço envolvendo uma matriz inversa	538
7.9.6	Forma quadrática com matriz inversa	539
7.9.7	Crítério com log-determinante e traço	540
7.9.8	Parâmetros matriciais simétricos	543
7.10	Vetorização, produto de Kronecker e parâmetros matriciais	544
7.10.1	Operador de vetorização	544
7.10.2	Produto de Kronecker	546
7.10.3	Identidade de vetorização	547
7.10.4	Gradiente matricial e gradiente vetorizado	549
7.10.5	Hessiana de uma função matricial	549
7.10.6	Gradiente matricial e gradiente vetorizado	550
7.10.7	Hessiana de uma função matricial	551
7.10.8	Matriz de comutação	552
7.10.9	Meia vetorização de matrizes simétricas	553
7.10.10	Matriz de duplicação	554
7.10.11	Matriz de eliminação	555
7.10.12	Diferenciais de parâmetros simétricos	556
7.10.13	Jacobiana de transformações matriciais	557
7.11	Integração múltipla e mudança de variáveis	558
7.11.1	Integrais múltiplas	558
7.11.2	Teoremas de Tonelli e Fubini	559
7.11.3	Densidades multivariadas	560
7.11.4	Distribuições marginais	561
7.11.5	Esperanças de funções vetoriais	562
7.11.6	Mudança de variáveis	564
7.11.7	Transformação de densidades	565
7.11.8	Transformações afins	566
7.11.9	Interpretação geométrica do determinante Jacobiano	568
7.11.10	Coordenadas polares	569
7.11.11	Transformações elipsoidais	570
7.11.12	Diferenciação sob o sinal de integração	571
7.12	Aplicações à estimação e à inferência	577
7.12.1	Log-verossimilhança e vetor escore	577
7.12.2	Informação observada e informação de Fisher	578
7.12.3	Newton–Raphson	579
7.12.4	Método do escore de Fisher	580
7.12.5	Expansão local de um estimador	580
7.12.6	Método delta	581
7.12.7	Estimação de um vetor de médias	583
7.12.8	Crítério do modelo linear multivariado	584
7.13	Síntese do capítulo	585

II Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada 588

8 Matrizes de covariâncias e correlações 589

8.1	Momentos, centralização e covariância	589
8.1.1	Vetor de médias e centralização	589
8.1.2	Momentos de segunda ordem	590
8.1.3	Covariância entre duas variáveis	592
8.2	Matriz de covariâncias populacional	595
8.2.1	Definição e interpretação dos elementos	595
8.2.2	Variâncias e covariâncias de combinações lineares	599
8.2.3	Propriedades estruturais	602
8.2.4	Singularidade e dimensão efetiva	604
8.3	Covariâncias entre vetores e transformações	607
8.3.1	Covariâncias cruzadas e vetores particionados	607
8.3.2	Transformação afim da média e da covariância	611
8.3.3	Transformação das covariâncias cruzadas	615
8.4	Padronização e matriz de correlações	616
8.4.1	Matriz de correlações populacional	616
8.4.2	Propriedades e limites	618
8.4.3	Correlação nula e independência	620
8.4.4	Efeito das mudanças de escala	621
8.5	Geometria e medidas globais da dispersão	624
8.5.1	Eixos espectrais da covariância	624
8.5.2	Elipsoide associado à covariância	627
8.5.3	Variância total e variância generalizada	629
8.5.4	Unidades e efeito das transformações	633
8.6	Distância de Mahalanobis	634
8.6.1	Definição e interpretação espectral	635
8.6.2	Relação com o branqueamento	638
8.6.3	Invariância afim	641
8.6.4	Covariância singular	642
8.7	Representação descritiva a partir dos dados	643
8.7.1	Média observada e matriz centralizada	643
8.7.2	Matriz SSCP e covariância observada	646
8.7.3	Matriz de correlações observada	648
8.7.4	Covariâncias cruzadas observadas	650
8.8	Decomposição da dispersão por grupos	653
8.8.1	Parcelas total, intragrupos e entre grupos	654
8.8.2	Identidade de decomposição	655
8.8.3	Semidefinição positiva e limites de posto	656
8.8.4	Relação futura com o modelo linear multivariado	658
8.9	Síntese do capítulo	658

9	Distribuição Normal Multivariada	661
9.1	Definição e construção	661
9.1.1	Definição por combinações lineares	661
9.1.2	Construção afim a partir do vetor normal padrão	663
9.1.3	Determinação pelos parâmetros	665
9.1.4	Caso singular e suporte efetivo	667
9.2	Densidade no caso não singular	671
9.2.1	Função densidade e log-densidade	671
9.2.2	Papel da média e da matriz de covariâncias	673
9.2.3	Superfícies de igual densidade	674
9.3	Transformações, marginais e padronização	676
9.3.1	Fechamento sob transformações afins	676
9.3.2	Distribuição de combinações lineares	679
9.3.3	Distribuições marginais	680
9.3.4	Padronização marginal e branqueamento	682
9.4	Independência e distribuições condicionais	685
9.4.1	Independência entre blocos conjuntamente normais	685
9.4.2	Distribuição condicional	688
9.4.3	Média condicional e atualização linear	691
9.4.4	Covariância condicional e complemento de Schur	692
9.4.5	Caso bivariado	693
9.5	Distância de Mahalanobis e regiões de concentração	696
9.5.1	Distribuição qui-quadrado	696
9.5.2	Regiões elipsoidais de probabilidade	698
9.5.3	Avaliação de uma observação fixa	699
9.5.4	Extensão ao suporte efetivo no caso singular	701
9.6	Comparação entre distribuições normais	703
9.6.1	Médias distintas e covariância comum	703
9.6.2	Covariâncias distintas	704
9.6.3	Motivação para classificação futura	705
9.7	Papel da normalidade na Estatística Multivariada	705
9.7.1	Resultados que não exigem normalidade	706
9.7.2	Resultados específicos da família normal	707
9.7.3	Normalidade marginal e normalidade multivariada	707
9.7.4	Normalidade e inferência estatística	708
9.7.5	Limites da especificação por média e covariância	709
9.8	Síntese do capítulo	710
10	Estatísticas Amostrais e Estimação	712
10.1	Da população à amostra	712
10.1.1	Amostra aleatória multivariada	713
10.1.2	Matriz aleatória da amostra e matriz observada	715
10.1.3	Parâmetros, estatísticas, estimadores e estimativas	716

10.2	Propriedades dos estimadores multivariados	719
10.2.1	Viés e variabilidade	719
10.2.2	Erro quadrático médio e funções de perda	721
10.2.3	Consistência	723
10.2.4	Eficiência	725
10.2.5	Suficiência	726
10.2.6	Equivariância e robustez	728
10.3	Métodos de estimação	730
10.3.1	Método dos momentos	730
10.3.2	Verossimilhança e máxima verossimilhança	732
10.3.3	Invariância da máxima verossimilhança	739
10.4	Estimação do vetor de médias	741
10.4.1	Vetor de médias amostrais	742
10.4.2	Esperança e matriz de covariâncias	744
10.4.3	Combinações lineares	747
10.4.4	Consistência e equivariância	748
10.4.5	Variabilidade entre amostras	750
10.5	SSCP e estimação da matriz de covariâncias	751
10.5.1	Matriz amostral centralizada e SSCP	752
10.5.2	Decomposição em torno de um centro arbitrário	754
10.5.3	Esperança da SSCP	755
10.5.4	Estimador não viesado	757
10.5.5	Estimador de máxima verossimilhança	758
10.5.6	Consistência dos estimadores de covariância	759
10.5.7	Transformações, posto e singularidade	761
10.6	Estimação de covariâncias cruzadas e correlações	763
10.6.1	Covariâncias cruzadas entre blocos	764
10.6.2	Matriz de correlações amostral	769
10.6.3	Propriedades estruturais	771
10.6.4	Transformações de localização e escala	773
10.7	Dimensão, estabilidade e extensões da estimação	775
10.7.1	Relação entre p e n	775
10.7.2	Condicionamento e inversão	778
10.7.3	Regularização	780
10.7.4	Pseudoinversa e regularização	785
10.7.5	Sensibilidade e robustez	786
10.8	Exemplo integrado	789
10.9	Síntese do capítulo	793
11	Modelo Linear Multivariado e Hipóteses Lineares	796
11.1	Da resposta escalar à resposta vetorial	797
11.1.1	Respostas múltiplas por unidade	797
11.1.2	Equações por resposta	800

11.1.3	Representação matricial	801
11.2	Estrutura do modelo linear multivariado	803
11.2.1	Matrizes de respostas, delineamento e parâmetros	804
11.2.2	Hipóteses de primeira e segunda ordens	806
11.2.3	Condicionamento na matriz de delineamento	807
11.2.4	Forma vetorizada	808
11.2.5	Distribuição normal matricial	811
11.2.6	Transformações das respostas e das unidades	813
11.3	Estimação da matriz de parâmetros	815
11.3.1	Crítério de mínimos quadrados	816
11.3.2	Equações normais	817
11.3.3	Solução sob posto completo	818
11.3.4	Relação com máxima verossimilhança	820
11.3.5	Esperança e matriz de covariâncias	821
11.3.6	Modelo contendo somente intercepto	823
11.4	Valores ajustados, resíduos e projeções	825
11.4.1	Projetores do modelo e residual	825
11.4.2	Decomposição ortogonal	829
11.4.3	Ortogonalidade em relação ao delineamento	830
11.4.4	Esperança e covariâncias	832
11.4.5	Alavancagem	835
11.4.6	Interpretação geométrica	836
11.5	SSCP residual e estimação da covariância	838
11.5.1	Construção da SSCP residual	838
11.5.2	Esperança e graus de liberdade	841
11.5.3	Estimador não viesado	844
11.5.4	Estimador de máxima verossimilhança	845
11.5.5	Posto e singularidade	848
11.5.6	Modelo contendo somente intercepto	851
11.6	Decomposição da variação multivariada	852
11.6.1	SSCP total	852
11.6.2	SSCP explicada pelo modelo	854
11.6.3	Decomposição fundamental	857
11.6.4	Combinações lineares das respostas	859
11.6.5	Modelos sem intercepto	860
11.6.6	Modelo de grupos	862
11.7	Posto, parametrização e estimabilidade	865
11.7.1	Delineamento com posto deficiente	865
11.7.2	Soluções das equações normais	867
11.7.3	Funções estimáveis	870
11.7.4	Parametrizações equivalentes	875
11.7.5	Restrições de identificação	878
11.7.6	Posto numérico	881

11.8	Hipóteses lineares multivariadas	883
11.8.1	Contrastes sobre os parâmetros	884
11.8.2	Combinações lineares das respostas	885
11.8.3	Hipótese linear geral	887
11.8.4	Estimabilidade e dimensões	889
11.8.5	Matriz SSCP da hipótese	892
11.8.6	Modelos encaixados	894
11.8.7	Casos particulares	897
11.9	Exemplo integrado	901
11.9.1	Estimação das médias dos grupos	903
11.9.2	Valores ajustados e resíduos	903
11.9.3	SSCP residual e estimação da covariância	904
11.9.4	Decomposição da variação	905
11.9.5	Hipótese de igualdade entre os vetores de médias	906
11.9.6	Hipótese bilateral sobre a diferença entre respostas	908
11.10	Síntese do capítulo	909
12	Inferência Multivariada	916
12.1	Resultados exatos e assintóticos	916
12.1.1	Distribuição da média amostral	917
12.1.2	Teorema Central do Limite multivariado	920
12.2	Distribuição de Wishart	923
12.2.1	Construção e parametrização	923
12.2.2	Suporte, posto e densidade	925
12.2.3	Momentos e propriedades	927
12.2.4	Distribuição da covariância amostral	932
12.2.5	Independência entre média e covariância	936
12.3	Distribuições no modelo linear multivariado	938
12.3.1	Distribuição do estimador da matriz de parâmetros	939
12.3.2	Distribuição da SSCP residual	944
12.3.3	Independência entre estimador e resíduo	947
12.3.4	Distribuição da SSCP da hipótese	950
12.4	Princípios de testes multivariados	955
12.4.1	Hipóteses, nível, poder e não centralidade	955
12.4.2	Razão de verossimilhanças	961
12.4.3	Resultado assintótico de Wilks	965
12.5	Inferência sobre um vetor de médias	967
12.5.1	Covariância conhecida	968
12.5.2	Estatística T^2 de Hotelling	972
12.5.3	Região de confiança elipsoidal	976
12.5.4	Intervalos simultâneos	979
12.5.5	Hipóteses lineares sobre o vetor de médias	982

12.6	Comparação entre dois vetores de médias	989
12.6.1	Duas amostras independentes	989
12.6.2	Observações pareadas	997
12.7	Condições de validade	1003
12.7.1	Independência e normalidade	1003
12.7.2	Homogeneidade das covariâncias	1006
12.7.3	Posto, dimensão e tamanho amostral	1009
12.7.4	Observações atípicas e robustez	1013
12.7.5	Limites da inferência clássica em alta dimensão	1016
12.8	Decisão estatística e conexão com classificação	1020
12.8.1	Ação, perda e risco	1020
12.8.2	Regra de Bayes e custos de decisão	1022
12.9	Síntese do Módulo 2	1026

III Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas 1029

13	Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas	1030
13.1	Problemas e estruturas das técnicas multivariadas	1030
13.2	Formulação da Análise de Componentes Principais	1030
13.3	Formulação da Análise Fatorial	1030
13.4	Formulação da Análise de Agrupamentos	1030
13.5	Formulação do Escalonamento Multidimensional	1030
13.6	Formulação da Análise de Correspondência	1030
13.7	Formulação da MANOVA	1030
13.8	Formulação da Análise Discriminante	1030
13.9	Formulação da Correlação Canônica	1030
13.10	Formulação da Análise Conjunta	1030

Referências 1031

Informações Legais e Declaração de Uso de Inteligência Artificial

Direitos Autorais e Uso da Obra

© 2026 — Os autores.

Todos os direitos reservados. Esta obra é protegida pela legislação brasileira de direitos autorais (Lei nº 9.610/1998). É vedada a reprodução, distribuição, armazenamento ou transmissão total ou parcial deste livro, por qualquer meio ou processo, eletrônico ou mecânico, sem autorização expressa e por escrito dos autores, salvo nos casos permitidos pela legislação vigente para fins exclusivamente acadêmicos e não comerciais, com a devida citação da fonte.

A utilização do material em ambientes de ensino é permitida desde que preservada a integridade do conteúdo, mencionada a autoria e respeitados os princípios de uso responsável da informação científica. A reprodução para fins comerciais, bem como a modificação substancial do conteúdo sem autorização, constitui violação de direitos autorais.

Declaração sobre o Uso de Ferramentas de Inteligência Artificial

Durante a elaboração deste livro foram utilizadas ferramentas de Inteligência Artificial, em especial sistemas de apoio à escrita e organização textual, como recurso complementar no processo de produção acadêmica.

O uso de IA teve caráter **estritamente assistivo**, não substituindo o desenvolvimento conceitual, a formulação matemática, a interpretação estatística nem as decisões pedagógicas da obra. Todo conteúdo foi cuidadosamente revisado, validado e adaptado pelos autores, que assumem integral responsabilidade científica e intelectual pelo texto final.

Não foram delegadas à IA decisões metodológicas, inferenciais ou conclusões analíticas. A elaboração teórica, a seleção de exemplos, a validação matemática e a coerência didática resultam da experiência acadêmica e da atuação dos autores na área de Modelos de Regressão.

Reafirmamos que o uso responsável de tecnologias emergentes deve sempre preservar o rigor científico, a integridade acadêmica e o protagonismo intelectual humano.

Prefácio

Este livro foi elaborado como material de apoio ao estudo da Análise Multivariada no curso de Bacharelado em Estatística da Universidade Federal do Ceará.

A Análise Multivariada costuma ser apresentada por meio de um conjunto de métodos com finalidades distintas, como reduzir a dimensionalidade, identificar estruturas latentes, formar grupos, representar associações, comparar vetores de médias ou classificar observações. Quando essas técnicas são estudadas isoladamente, pode ser difícil perceber que muitas delas compartilham os mesmos objetos e operações: vetores e matrizes, combinações lineares, projeções, formas quadráticas, matrizes de covariâncias, decomposições espectrais, valores singulares, distâncias e modelos probabilísticos.

O livro foi organizado para tornar essas relações explícitas. O **Módulo I** apresenta os fundamentos matemáticos e geométricos necessários à representação e à transformação dos dados multivariados. O **Módulo II** desenvolve os fundamentos probabilísticos e inferenciais, incluindo matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência. O **Módulo III** mostra como esses resultados são combinados na formulação matemática e estatística das principais técnicas multivariadas.

A exposição busca equilibrar rigor e interpretação. As definições e propriedades são acompanhadas, sempre que possível, por representações geométricas, exemplos numéricos e conexões com os problemas estatísticos que motivam cada resultado. As demonstrações são incluídas quando contribuem diretamente para a compreensão da estrutura dos métodos; resultados mais especializados são apresentados de forma compatível com os objetivos de uma disciplina de graduação.

As técnicas são inicialmente estudadas a partir do problema que procuram resolver, dos dados que utilizam e dos objetos matemáticos que definem sua solução. A formulação conceitual antecede os algoritmos, os procedimentos computacionais e a interpretação aplicada. Essa organização permite compreender por que cada técnica assume determinada forma e quais fundamentos são necessários para utilizá-la adequadamente.

Identificação da Disciplina

Curso: Bacharelado em Estatística

Disciplina: Análise Multivariada

Carga Horária: 96 horas

Período Letivo: 2026.2

Professores: Dr. Rafael Bráz Azevedo Farias e Dra. Alessandra Cristina da Silva Farias

EMENTA

Fundamentos matemáticos, geométricos, probabilísticos e inferenciais da Análise Multivariada. Representação vetorial e matricial dos dados, espaços vetoriais, projeções, transformações lineares, decomposição espectral e decomposição em valores singulares. Matrizes de covariâncias e correlações, distribuição normal multivariada, estatísticas amostrais, estimação, modelo linear e inferência multivariada. Formulação matemática e estatística das principais técnicas multivariadas.

OBJETIVO GERAL

Compreender os fundamentos matemáticos, geométricos, probabilísticos e estatísticos que sustentam a Análise Multivariada e reconhecer como esses fundamentos são utilizados na formulação, na aplicação e na interpretação das principais técnicas multivariadas.

OBJETIVOS ESPECÍFICOS

Ao final da disciplina, o estudante deverá ser capaz de:

- representar dados multivariados por meio de vetores e matrizes;
- interpretar geometricamente observações, variáveis, distâncias, projeções e transformações;
- compreender o papel de autovalores, autovetores, decomposição espectral e decomposição em valores singulares;

- analisar a estrutura de matrizes de covariâncias e correlações;
- compreender os fundamentos da distribuição normal multivariada, da estimação e da inferência;
- identificar os problemas estatísticos que dão origem às principais técnicas multivariadas;
- relacionar cada técnica aos seus objetos matemáticos, critérios de otimização ou modelos probabilísticos;
- distinguir técnicas de redução de dimensionalidade, representação de estruturas latentes, agrupamento, associação, comparação e classificação;
- conduzir análises multivariadas com apoio computacional;
- interpretar criticamente os resultados e comunicar conclusões compatíveis com os dados e com os pressupostos adotados.

CONTEÚDO PROGRAMÁTICO

Módulo I – Fundamentos Matemáticos e Geométricos da Análise Multivariada

Vetores e representação dos dados multivariados
 Álgebra matricial aplicada
 Espaços vetoriais, bases e projeções
 Transformações lineares
 Autovalores, autovetores e decomposição espectral
 Decomposição em valores singulares
 Cálculo diferencial, integral e matricial aplicado à Estatística Multivariada

Módulo II – Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

Matrizes de covariâncias e correlações
 Distribuição normal multivariada
 Estatísticas amostrais e estimação
 Modelo linear multivariado e hipóteses lineares
 Inferência multivariada

Módulo III – Formulação Matemática e Estatística das Técnicas Multivariadas

Problemas e estruturas das técnicas multivariadas
 Análise de Componentes Principais
 Análise Fatorial
 Análise de Agrupamentos
 Escalonamento Multidimensional
 Análise de Correspondência

Análise Multivariada de Variância
Análise Discriminante
Correlação Canônica
Análise Conjunta

METODOLOGIA

A disciplina será desenvolvida por meio de aulas expositivo-dialogadas, atividades práticas em laboratório e exercícios de interpretação. Os fundamentos matemáticos, probabilísticos e inferenciais serão articulados à formulação e à aplicação das técnicas multivariadas.

Serão utilizados exemplos numéricos, representações geométricas, demonstrações selecionadas e conjuntos de dados reais ou simulados. A parte computacional será conduzida de modo a apoiar a compreensão dos métodos, a verificação dos pressupostos e a interpretação dos resultados.

AValiação

As avaliações contemplarão os fundamentos teóricos, a condução das análises e a interpretação dos resultados. Poderão ser utilizadas provas escritas, avaliações práticas em laboratório, exercícios e outras atividades definidas no plano de ensino da disciplina.

A aprovação seguirá as normas vigentes da Universidade Federal do Ceará.

CRITÉRIOS DE AVALIAÇÃO

Serão considerados:

- correção matemática e estatística;
- domínio conceitual;
- adequação das decisões metodológicas;
- interpretação dos resultados no contexto do problema;
- clareza e organização da exposição escrita;
- qualidade e reprodutibilidade das análises computacionais.

BIBLIOGRAFIA BÁSICA

ANDERSON, T. W.

An Introduction to Multivariate Statistical Analysis. 3rd ed. Wiley, 2003. (Anderson, 2003)

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

HAIR, J. F. et al.

Multivariate Data Analysis. (Hair et al., 2018)

BIBLIOGRAFIA COMPLEMENTAR

ARTES, R.; BARROSO, L. P.; PAULA, G. A.

Métodos Multivariados de Análise Estatística. (Artes; Barroso, 2023)

JOHNSON, R. A.; WICHERN, D. W.

Applied Multivariate Statistical Analysis. 6th ed. Pearson, 2007. (Johnson; Wichern, 2007)

MANLY, B. F. J.; ALBERTO, J. A. N.

Métodos Estatísticos Multivariados: Uma Introdução. (Manly; Navarro Alberto, 2019)

MARDIA, K. V.; KENT, J. T.; TAYLOR, C. C.

Multivariate Analysis. (Mardia; Kent; Taylor, 2024)

MINGOTI, S. A.

Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada. Belo Horizonte: Editora UFMG, 2005. (Mingoti, 2005)

RENCER, A. C.; CHRISTENSEN, W. F.

Methods of Multivariate Analysis. (Rencher; Christensen, 2012)

Parte I

Módulo I — Fundamentos Matemáticos e Geométricos da Análise Multivariada

1 Vetores e representação dos dados multivariados

Em estudos multivariados, cada unidade observacional é descrita por várias características registradas simultaneamente. Quando são observadas p variáveis quantitativas, esses valores podem ser organizados em um vetor de $\mathbb{R}^p$.

Para n unidades, os vetores formam uma matriz de dados de dimensão $n \times p$, na qual as linhas representam as observações e as colunas representam as variáveis.

Essa representação permite interpretar as observações como pontos em um espaço multidimensional e estudar suas relações por meio de operações vetoriais e conceitos geométricos.

O capítulo apresenta escalares, vetores, matrizes, o espaço $\mathbb{R}^p$, a matriz de dados, as operações com vetores, o produto interno, a norma, o ângulo, a distância euclidiana e o produto externo.

Convenções gerais de notação

As convenções abaixo indicam apenas como os objetos serão representados. Seus significados e propriedades serão definidos ao longo do capítulo.

- letras minúsculas sem negrito, como a , x e α , representam escalares;
- letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{y}$, representam vetores observados;
- letras maiúsculas em negrito, como $\mathbf{A}$ e $\mathbf{X}$, representam matrizes;
- letras maiúsculas sem negrito, como X , representam variáveis aleatórias escalares;
- o vetor aleatório multivariado será representado por $\mathbf{X}$;
- a realização observada de $\mathbf{X}$ será representada por $\mathbf{x}$;
- o elemento situado na posição i de um vetor será indicado por x_i ;
- o elemento situado na linha i e na coluna j de uma matriz será indicado por a_{ij} ;
- a i -ésima linha de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_i^\top$;
- a j -ésima coluna de uma matriz $\mathbf{A}$ será representada por $\mathbf{a}_{\cdot j}$;
- quando não houver ambiguidade, $\mathbf{a}_i^\top$ poderá ser utilizada como forma abreviada de $\mathbf{a}_i^\top$;
- o vetor-coluna associado à i -ésima linha será representado por $\mathbf{a}_i \in \mathbb{R}^p$;
- o ponto na notação matricial indica o índice que varia;
- $\mathbb{R}^p$ representa o espaço dos vetores reais com p componentes;
- $\mathbb{R}^{n \times p}$ representa o conjunto das matrizes reais com n linhas e p colunas;
- o símbolo $\top$ indica transposição;

- $\mathbf{0}$ representa um vetor ou uma matriz nula, com dimensão determinada pelo contexto.

Para a matriz de dados $\mathbf{X}$, será adotada a mesma convenção para as linhas: $\mathbf{x}_i \in \mathbb{R}^p$ representa a observação i , $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$ e $\mathbf{x}_{\cdot j} \in \mathbb{R}^n$ representa a coluna correspondente à variável j .

Quando houver risco de ambiguidade, a dimensão será indicada explicitamente.

1.1 Escalares, vetores e matrizes

Em uma análise univariada, cada observação é representada pelo valor de uma única variável. Quando várias variáveis são medidas na mesma unidade observacional, seus valores podem ser organizados em um vetor. Os vetores de todas as unidades formam uma matriz de dados.

Definição 1.1 (Escalar). Um **escalar** é um número real:

$$a \in \mathbb{R}.$$

Em uma aplicação estatística, um escalar pode representar uma medida observada ou o coeficiente de uma expressão matemática.

Em Estatística, uma variável aleatória escalar será representada por uma letra maiúscula, como X . Uma realização dessa variável será representada pela letra minúscula correspondente:

$$x \in \mathbb{R}.$$

Por exemplo, X pode representar a massa de uma unidade selecionada aleatoriamente, enquanto $x = 65$ representa um valor observado.

Definição 1.2 (Vetor aleatório e vetor observado). Um **vetor aleatório** de dimensão p é uma coleção ordenada de p variáveis aleatórias:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (X_1, X_2, \dots, X_p)^\top.$$

Uma realização de $\mathbf{X}$ é representada pelo vetor observado

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = (x_1, x_2, \dots, x_p)^\top \in \mathbb{R}^p.$$

Cada componente x_j corresponde ao valor observado da variável j , para $j = 1, \dots, p$.

Exemplo 1.1 (Exemplo: Representação de uma observação). Considere uma unidade descrita por três variáveis:

- X_1 : idade, em anos;
- X_2 : massa corporal, em quilogramas;
- X_3 : altura, em centímetros.

O vetor aleatório é

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}.$$

Para uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura, o vetor observado é

$$\mathbf{x} = \begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix}.$$

A ordem das componentes identifica a correspondência entre valores e variáveis. Assim,

$$\begin{bmatrix} 52 \\ 74 \\ 168 \end{bmatrix} \neq \begin{bmatrix} 74 \\ 52 \\ 168 \end{bmatrix}$$

O primeiro vetor representa uma unidade com 52 anos, 74 quilogramas e 168 centímetros de altura. O segundo representa uma unidade com 74 anos, 52 quilogramas e 168 centímetros de altura.

Neste momento, o vetor é utilizado apenas para organizar as medidas. A comparação geométrica de variáveis com unidades diferentes exigirá atenção às escalas.

Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

Definição 1.3 (Matriz). Uma **matriz** com n linhas e p colunas é um arranjo retangular de números:

$$\mathbf{A} = (a_{ij})_{n \times p} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento a_{ij} ocupa a linha i e a coluna j .

A dimensão de $\mathbf{A}$ é $n \times p$. O primeiro número indica a quantidade de linhas, e o segundo indica a quantidade de colunas.

Para a matriz $\mathbf{A}$ definida anteriormente, a i -ésima linha é o vetor-linha

$$\mathbf{a}_{i\cdot}^\top = [a_{i1} \quad a_{i2} \quad \cdots \quad a_{ip}] \in \mathbb{R}^{1 \times p},$$

enquanto a j -ésima coluna é o vetor-coluna

$$\mathbf{a}_{\cdot j} = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{nj} \end{bmatrix} \in \mathbb{R}^{n \times 1}.$$

O ponto na notação indica o índice que varia. Assim:

- em $\mathbf{a}_{i\cdot}^\top$, a linha i permanece fixa e o índice das colunas varia;
- em $\mathbf{a}_{\cdot j}$, a coluna j permanece fixa e o índice das linhas varia.

Notação abreviada para linhas

Quando não houver risco de ambiguidade, a notação das linhas da matriz $\mathbf{A}$ poderá ser simplificada. Em particular, o vetor associado à i -ésima linha será representado por

$$\mathbf{a}_i \in \mathbb{R}^p,$$

de modo que a i -ésima linha da matriz poderá ser escrita como

$$\mathbf{a}_i^\top = \mathbf{a}_{i\cdot}^\top.$$

A notação com ponto será utilizada quando for necessário distinguir explicitamente linhas e colunas da mesma matriz.

Essa convenção será especialmente útil para a matriz de dados $\mathbf{X}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa a i -ésima observação e $\mathbf{x}_i^\top$ representa essa observação como a i -ésima linha de $\mathbf{X}$. As colunas permanecerão representadas explicitamente por $\mathbf{x}_{.j}$.

Com essas convenções, a matriz pode ser representada por suas linhas,

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_{1.}^\top \\ \mathbf{a}_{2.}^\top \\ \vdots \\ \mathbf{a}_{n.}^\top \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix},$$

ou por suas colunas,

$$\mathbf{A} = [\mathbf{a}_{.1} \ \mathbf{a}_{.2} \ \cdots \ \mathbf{a}_{.p}].$$

1.1.1 Vetor-coluna, vetor-linha e transposição

Definição 1.4 (Vetor-coluna, vetor-linha e transposição). Um vetor-coluna com p componentes pode ser tratado como uma matriz de dimensão $p \times 1$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^{p \times 1}.$$

A **transposição** é a operação que troca as linhas de uma matriz por suas colunas e é indicada pelo símbolo $\top$.

A transposta do vetor-coluna $\mathbf{x}$ é o vetor-linha

$$\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p] \in \mathbb{R}^{1 \times p}.$$

Portanto,

$$\mathbf{x} \in \mathbb{R}^{p \times 1} \quad \implies \quad \mathbf{x}^\top \in \mathbb{R}^{1 \times p}.$$

A Tabela 1.1 resume a notação utilizada no capítulo.

Tabela 1.1: Notação utilizada para escalares, vetores e matrizes.

Objeto	Notação	Descrição
Escalar	a	Número real
Variável aleatória escalar	X	Variável que assume valores em $\mathbb{R}$
Realização escalar	x	Valor observado de X
Vetor aleatório	$\mathbf{X}$	Coleção ordenada de variáveis aleatórias
Vetor observado	$\mathbf{x}$	Realização de um vetor aleatório
Matriz genérica	$\mathbf{A}$	Arranjo retangular de números
Linha i de uma matriz	$\mathbf{a}_i^\top$ ou $\mathbf{a}_{i\cdot}^\top$	Vetor-linha formado pelos elementos da linha i de $\mathbf{A}$
Coluna j de uma matriz	$\mathbf{a}_{\cdot j}$	Vetor-coluna formado pelos elementos da coluna j de $\mathbf{A}$
Matriz de dados	$\mathbf{X}$	Matriz observada com linhas e colunas associadas às unidades e às variáveis

Um escalar representa uma medida, um vetor reúne as medidas de uma unidade e uma matriz organiza os valores de várias unidades. A representação dos vetores em $\mathbb{R}^p$ será desenvolvida na próxima seção.

1.2 O espaço $\mathbb{R}^p$

Os valores observados de p variáveis quantitativas podem ser organizados em um vetor com p componentes. O conjunto de todos os vetores desse tipo é denotado por $\mathbb{R}^p$.

Definição 1.5 (Espaço vetorial $\mathbb{R}^p$). O espaço vetorial real de dimensão p é definido por

$$\mathbb{R}^p = \{(x_1, x_2, \dots, x_p)^\top : x_j \in \mathbb{R}, j = 1, \dots, p\}.$$

Cada elemento de $\mathbb{R}^p$ é um vetor formado por p componentes reais. Com as operações usuais de adição de vetores e multiplicação por escalares, esses vetores constituem um espaço vetorial.

Uma observação descrita por p variáveis pode ser representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p,$$

em que x_{ij} é o valor da variável j observado na unidade i .

Neste livro, o espaço $\mathbb{R}^p$ no qual são representadas as unidades observacionais será denominado **espaço das observações**. Cada vetor representa uma unidade, e cada componente corresponde a uma variável.

A dimensão do espaço é determinada pelo número de variáveis:

- para $p = 1$, cada observação possui uma componente;
- para $p = 2$, cada observação possui duas componentes;
- para $p = 3$, cada observação possui três componentes;
- para $p > 3$, a representação permanece definida em $\mathbb{R}^p$, embora não possa ser visualizada diretamente em sua totalidade.

A Figura 1.1 apresenta os três casos que podem ser representados graficamente.




Figura 1.1: Representação de observações em espaços de uma, duas e três dimensões.

Exemplo 1.2 (Exemplo: Observação em duas dimensões). Considere duas variáveis quantitativas, X_1 e X_2 . A observação i é representada por

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \in \mathbb{R}^2.$$

Se $x_{i1} = 3$ e $x_{i2} = 5$, então

$$\mathbf{x}_i = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Esse vetor pode ser representado por uma seta que parte da origem e termina no ponto de coordenadas $(3, 5)$, como mostra a Figura 1.2.




Figura 1.2: Representação do vetor $\mathbf{x}_i = (3, 5)^\top$ no plano.

A extremidade da seta determina o ponto $(3, 5)$. Assim, o vetor $\mathbf{x}_i$ pode ser interpretado geometricamente como uma seta com origem em $(0, 0)$ e extremidade em $(3, 5)$.

O número de observações e o número de variáveis possuem funções distintas. Para um conjunto com n observações e p variáveis:

- n determina a quantidade de pontos;
- p determina a dimensão do espaço ambiente.

As n observações formam uma nuvem de pontos em $\mathbb{R}^p$.

Os vetores correspondentes às n observações serão organizados em uma matriz de dados na próxima seção.

1.3 Representação matricial de um conjunto de dados

Considere n unidades observacionais descritas pelas mesmas p variáveis quantitativas. A observação i é representada pelo vetor

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} \in \mathbb{R}^p, \quad i = 1, \dots, n.$$

Cada componente x_{ij} corresponde ao valor da variável j observado na unidade i . Os n vetores observados podem ser organizados nas linhas de uma matriz.

Definição 1.6 (Matriz de dados). A **matriz de dados** de n observações e p variáveis é definida por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

O elemento x_{ij} representa o valor da variável j observado na unidade i .

As linhas da matriz correspondem às observações, e as colunas correspondem às variáveis. Essa organização coincide com a estrutura usual de uma planilha ou de um banco de dados.

Com a notação estabelecida anteriormente, a matriz de dados pode ser representada por suas linhas como

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

ou por suas colunas como

$$\mathbf{X} = [\mathbf{x}_{\cdot 1} \ \mathbf{x}_{\cdot 2} \ \cdots \ \mathbf{x}_{\cdot p}].$$

Exemplo 1.3 (Exemplo: Matriz de dados com duas variáveis). Considere quatro unidades observacionais descritas pelas variáveis X_1 e X_2 . Os vetores observados são

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 1 \end{bmatrix},$$

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}, \quad \mathbf{x}_4 = \begin{bmatrix} 8 \\ 3 \end{bmatrix}.$$

A matriz de dados é

$$\mathbf{X} = \begin{bmatrix} 1 & 5 \\ 3 & 1 \\ 5 & 7 \\ 8 & 3 \end{bmatrix} \in \mathbb{R}^{4 \times 2}.$$

A terceira observação é

$$\mathbf{x}_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix},$$

e aparece na matriz como a terceira linha,

$$\mathbf{x}_3^\top = \begin{bmatrix} 5 & 7 \end{bmatrix}.$$

O elemento

$$x_{32} = 7$$

é o valor da segunda variável observado na terceira unidade.

1.3.1 Espaço das observações e espaço das variáveis

A organização da matriz de dados permite considerar dois conjuntos de vetores.

Pelas linhas,

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

cada vetor representa uma observação descrita pelas p variáveis.

Pelas colunas,

$$\mathbf{x}_{.j} \in \mathbb{R}^n, \quad j = 1, \dots, p,$$

cada vetor representa uma variável observada nas n unidades.

No **espaço das observações**, cada unidade observacional é representada por um ponto em $\mathbb{R}^p$, cujas coordenadas correspondem às variáveis.

No **espaço das variáveis**, cada variável é representada por um vetor em $\mathbb{R}^n$, cujas componentes correspondem às unidades observacionais.

A Tabela 1.2 resume essas duas representações.

Tabela 1.2: Representações da matriz de dados por linhas e colunas.

Representação	Vetor	Objeto representado	Espaço	Quantidade
Linhas de $\mathbf{X}$	$\mathbf{x}_i$	Observação i	$\mathbb{R}^p$	n vetores
Colunas de $\mathbf{X}$	$\mathbf{x}_{.j}$	Variável j	$\mathbb{R}^n$	p vetores

A interpretação utilizada depende do objeto de interesse. Relações entre unidades observacionais são estudadas a partir das linhas da matriz, enquanto relações entre variáveis são estudadas a partir de suas colunas.

1.4 Operações elementares com vetores

Considere os vetores

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in \mathbb{R}^p$$

e um escalar $\alpha \in \mathbb{R}$.

Dois vetores são iguais quando suas componentes correspondentes são iguais:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j, \quad j = 1, \dots, p.$$

1.4.1 Soma e subtração

A soma de dois vetores é realizada componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_p + y_p \end{bmatrix} \in \mathbb{R}^p.$$

A diferença também é calculada componente a componente:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix} \in \mathbb{R}^p.$$

O vetor $\mathbf{x} - \mathbf{y}$ representa o deslocamento de $\mathbf{y}$ até $\mathbf{x}$.

Exemplo 1.4 (Exemplo: Soma e subtração de vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ 1,5 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1,0 \\ 3,0 \end{bmatrix}.$$

A soma é

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} 2,0 + 1,0 \\ 1,5 + 3,0 \end{bmatrix} = \begin{bmatrix} 3,0 \\ 4,5 \end{bmatrix}.$$

A diferença é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 2,0 - 1,0 \\ 1,5 - 3,0 \end{bmatrix} = \begin{bmatrix} 1,0 \\ -1,5 \end{bmatrix}.$$

Definição 1.7 (Vetor nulo). O **vetor nulo** de $\mathbb{R}^p$ é definido por

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Ele é o elemento neutro da adição:

$$\mathbf{x} + \mathbf{0} = \mathbf{x}.$$

A Figura 1.3 apresenta a interpretação geométrica da soma em $\mathbb{R}^2$.

Na figura, os vetores $\mathbf{x}$ e $\mathbf{y}$ formam dois lados de um paralelogramo. A diagonal que parte da origem representa $\mathbf{x} + \mathbf{y}$.

1.4.2 Multiplicação por escalar

A multiplicação do vetor $\mathbf{x}$ pelo escalar α é definida por

$$\alpha \mathbf{x} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_p \end{bmatrix} \in \mathbb{R}^p.$$

A norma do vetor resultante satisfaz

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Portanto, para $\mathbf{x} \neq \mathbf{0}$:

- se $|\alpha| > 1$, o comprimento do vetor aumenta;




Figura 1.3: Soma de vetores pela regra do paralelogramo.

- se $0 < |\alpha| < 1$, o comprimento do vetor diminui;
- se $|\alpha| = 1$, o comprimento do vetor é preservado;
- se $\alpha = 0$, o resultado é o vetor nulo;
- se $\alpha < 0$, o sentido do vetor é invertido.

As alterações de comprimento dependem de $|\alpha|$, enquanto a inversão do sentido depende do sinal de α . Assim, um escalar negativo pode aumentar, diminuir ou preservar o comprimento do vetor.

Quando $\mathbf{x} = \mathbf{0}$, tem-se

$$\alpha \mathbf{x} = \mathbf{0}$$

para qualquer $\alpha \in \mathbb{R}$.

Exemplo 1.5 (Exemplo: Multiplicação por escalar). Para

$$\mathbf{x} = \begin{bmatrix} 2,0 \\ -1,5 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{x} = \begin{bmatrix} -2(2,0) \\ -2(-1,5) \end{bmatrix} = \begin{bmatrix} -4,0 \\ 3,0 \end{bmatrix}.$$

1.4.3 Combinações lineares

Uma combinação linear é construída por meio das duas operações apresentadas anteriormente: a multiplicação de vetores por escalares e a adição de vetores.

Definição 1.8 (Combinação linear de vetores). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}.$$

Uma **combinação linear** dos vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$ é qualquer vetor da forma

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k.$$

O resultado também pertence a $\mathbb{R}^p$, pois é obtido por multiplicações por escalares e somas de vetores de $\mathbb{R}^p$:

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \in \mathbb{R}^p.$$

Exemplo 1.6 (Exemplo: Combinação linear de vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

A combinação linear $2\mathbf{v}_1 - \mathbf{v}_2$ é

$$2\mathbf{v}_1 - \mathbf{v}_2 = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 5 \end{bmatrix}.$$

As combinações lineares permitem construir novos vetores a partir de vetores já conhecidos. Seus coeficientes determinam quanto cada vetor contribui para o resultado.

Exemplo 1.7 (Exemplo: Combinação linear das variáveis). Considere as variáveis X_1 , X_2 e X_3 e os coeficientes

$$a_1 = 2,0, \quad a_2 = -0,5, \quad a_3 = 3,0.$$

A combinação linear definida por esses coeficientes é

$$Y = 2,0X_1 - 0,5X_2 + 3,0X_3.$$

Para uma observação com valores

$$x_1 = 4,0, \quad x_2 = 2,0, \quad x_3 = 1,5,$$

o valor observado da combinação linear é

$$y = 2,0(4,0) - 0,5(2,0) + 3,0(1,5) = 11,5.$$

Em uma combinação linear, cada coeficiente determina a contribuição do vetor ou da variável correspondente para o resultado.

As operações anteriores produzem novos vetores ou novas variáveis. A próxima operação tem natureza diferente: o produto interno associa dois vetores a um número real e permite construir as noções de comprimento, ângulo, ortogonalidade e distância.

1.5 Produto interno, norma, ângulo e distância euclidiana

O produto interno associa dois vetores de $\mathbb{R}^p$ a um número real. A partir dessa operação, definem-se norma, ângulo, ortogonalidade e distância euclidiana.

1.5.1 Produto interno euclidiano

Definição 1.9 (Produto interno euclidiano). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o **produto interno euclidiano** entre $\mathbf{x}$ e $\mathbf{y}$ é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

Em termos das componentes,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + x_2 y_2 + \cdots + x_p y_p.$$

O resultado do produto interno é um escalar.

Exemplo 1.8 (Exemplo: Cálculo do produto interno). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}.$$

Então,

$$\langle \mathbf{x}, \mathbf{y} \rangle = 2(4) + 1(2) + 3(-1) = 7.$$

Proposição 1.1 (Propriedades do produto interno euclidiano). *Para quaisquer vetores $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$ e quaisquer escalares $\alpha, \beta \in \mathbb{R}$, o produto interno euclidiano satisfaz as seguintes propriedades:*

1. Simetria

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

2. Linearidade no primeiro argumento

$$\langle \alpha \mathbf{x} + \beta \mathbf{z}, \mathbf{y} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{z}, \mathbf{y} \rangle.$$

3. *Linearidade no segundo argumento*

$$\langle \mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z} \rangle = \alpha \langle \mathbf{x}, \mathbf{y} \rangle + \beta \langle \mathbf{x}, \mathbf{z} \rangle.$$

4. *Não negatividade*

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0.$$

5. *Positividade definida*

$$\langle \mathbf{x}, \mathbf{x} \rangle = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0}.$$

1.5.2 Norma euclidiana

Definição 1.10 (Norma euclidiana). A **norma euclidiana** de $\mathbf{x} \in \mathbb{R}^p$ é definida por

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}.$$

A norma representa o comprimento do vetor em relação à origem.

Para qualquer $\mathbf{x} \in \mathbb{R}^p$ e $\alpha \in \mathbb{R}$,

$$\|\mathbf{x}\| \geq 0,$$

$$\|\mathbf{x}\| = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{0},$$

e

$$\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|.$$

Exemplo 1.9 (Exemplo: Norma de um vetor). Para

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix},$$

tem-se

$$\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5.$$

A Figura 1.4 mostra a representação geométrica desse vetor no plano. O comprimento da seta corresponde à norma euclidiana do vetor.




Figura 1.4: A norma euclidiana corresponde ao comprimento do vetor.

Nesse caso, a norma coincide com a hipotenusa de um triângulo retângulo cujos catetos têm comprimentos 3 e 4.

1.5.3 Desigualdade de Cauchy–Schwarz

Teorema 1.1 (Desigualdade de Cauchy–Schwarz). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

A igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. (Meyer, 2023)

Comprovação. Se $\mathbf{y} = \mathbf{0}$, então

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0$$

e

$$\|\mathbf{x}\| \|\mathbf{y}\| = 0.$$

Portanto, a desigualdade é satisfeita com igualdade. Além disso,

$$\mathbf{y} = 0\mathbf{x},$$

de modo que um dos vetores é múltiplo escalar do outro.

Considere agora $\mathbf{y} \neq \mathbf{0}$. Para qualquer escalar $\alpha \in \mathbb{R}$, a não negatividade do produto interno implica

$$\langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \geq 0.$$

Escolha

$$\alpha = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2}.$$

Expandindo o produto interno,

$$\begin{aligned} 0 &\leq \langle \mathbf{x} - \alpha\mathbf{y}, \mathbf{x} - \alpha\mathbf{y} \rangle \\ &= \langle \mathbf{x}, \mathbf{x} \rangle - \alpha \langle \mathbf{x}, \mathbf{y} \rangle - \alpha \langle \mathbf{y}, \mathbf{x} \rangle + \alpha^2 \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 - 2\alpha \langle \mathbf{x}, \mathbf{y} \rangle + \alpha^2 \|\mathbf{y}\|^2. \end{aligned}$$

Na última igualdade, foi utilizada a simetria do produto interno:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle.$$

Substituindo o valor escolhido para α ,

$$\begin{aligned}
0 &\leq \|\mathbf{x}\|^2 - 2 \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \langle \mathbf{x}, \mathbf{y} \rangle \\
&\quad + \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{y}\|^2} \right)^2 \|\mathbf{y}\|^2 \\
&= \|\mathbf{x}\|^2 - \frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2}.
\end{aligned}$$

Logo,

$$\frac{\langle \mathbf{x}, \mathbf{y} \rangle^2}{\|\mathbf{y}\|^2} \leq \|\mathbf{x}\|^2.$$

Como $\|\mathbf{y}\|^2 > 0$, podemos multiplicar os dois lados por esse valor e obter

$$\langle \mathbf{x}, \mathbf{y} \rangle^2 \leq \|\mathbf{x}\|^2 \|\mathbf{y}\|^2.$$

Tomando a raiz quadrada dos dois lados,

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Resta examinar quando ocorre a igualdade. Na construção anterior, a igualdade é satisfeita se, e somente se,

$$\langle \mathbf{x} - \alpha \mathbf{y}, \mathbf{x} - \alpha \mathbf{y} \rangle = 0.$$

Pela positividade definida do produto interno, isso ocorre se, e somente se,

$$\mathbf{x} - \alpha \mathbf{y} = \mathbf{0},$$

ou seja,

$$\mathbf{x} = \alpha \mathbf{y}.$$

Portanto, quando $\mathbf{y} \neq \mathbf{0}$, a igualdade ocorre se, e somente se, $\mathbf{x}$ é múltiplo escalar de $\mathbf{y}$.

Reunindo os dois casos, concluímos que a igualdade ocorre se, e somente se, um dos vetores é múltiplo escalar do outro. $\square$

Para vetores não nulos, a desigualdade de Cauchy–Schwarz também implica

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Assim, a desigualdade fornece uma justificativa algébrica de que a razão utilizada no cálculo do ângulo pertence ao intervalo $[-1, 1]$, que é o domínio da função arccos.

1.5.4 Ângulo entre vetores

Definição 1.11 (Ângulo entre vetores). Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ não nulos, o **ângulo** entre os vetores é o único valor $\theta \in [0, \pi]$ que satisfaz

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

A existência desse ângulo é garantida pela desigualdade de Cauchy–Schwarz, pois

$$-1 \leq \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \leq 1.$$

Equivalentemente,

$$\theta = \arccos \left(\frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} \right).$$

A relação que define o ângulo também pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos(\theta).$$

Interpretação geométrica

A divisão pelo produto das normas retira o efeito dos comprimentos dos vetores. Desse modo, o valor de $\cos(\theta)$ descreve apenas o alinhamento entre suas direções.

Como $\|\mathbf{x}\|$ e $\|\mathbf{y}\|$ são positivos, o sinal do produto interno depende apenas do sinal de $\cos(\theta)$:

- se $0 \leq \theta < \frac{\pi}{2}$, o ângulo é agudo e

$$\langle \mathbf{x}, \mathbf{y} \rangle > 0;$$

- se $\theta = \frac{\pi}{2}$, o ângulo é reto e

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0;$$

- se $\frac{\pi}{2} < \theta \leq \pi$, o ângulo é obtuso e


$$\langle \mathbf{x}, \mathbf{y} \rangle < 0.$$

Geometricamente, o produto interno é positivo quando os vetores apontam para direções relativamente próximas, é nulo quando são ortogonais e é negativo quando apontam para direções relativamente opostas.


O ângulo não é definido quando um dos vetores é nulo, pois o vetor nulo não possui direção determinada e o denominador da expressão seria igual a zero.

A Figura 1.5 apresenta essas três situações.

Ângulo agudo



Ângulo reto



Ângulo obtuso




Figura 1.5: Sinal do produto interno segundo o ângulo formado entre dois vetores.

Definição 1.12 (Vetores ortogonais). Dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ são **ortogonais** quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

Se ambos forem não nulos, o ângulo entre eles é igual a 90° .

O vetor nulo é ortogonal a todos os vetores, pois

$$\langle \mathbf{0}, \mathbf{x} \rangle = 0.$$

O ângulo entre o vetor nulo e outro vetor não é definido porque $\|\mathbf{0}\| = 0$.

1.5.5 Distância euclidiana

Definição 1.13 (Distância euclidiana). A **distância euclidiana** entre $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Em termos das componentes,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

A distância euclidiana corresponde ao comprimento do segmento que liga os pontos representados por $\mathbf{x}$ e $\mathbf{y}$.

Exemplo 1.10 (Exemplo: Distância entre duas observações). Considere

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}.$$

A diferença entre os vetores é

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} -3 \\ -4 \end{bmatrix}.$$

Logo,

$$d_E(\mathbf{x}, \mathbf{y}) = \sqrt{(-3)^2 + (-4)^2} = 5.$$

Escalas das variáveis

A distância euclidiana depende das unidades e das escalas das variáveis. Uma variável com valores numericamente maiores pode contribuir mais para a distância entre as observações.




Figura 1.6: Os vetores x e y são representados por setas. A distância euclidiana é o comprimento do segmento que une suas extremidades.

A padronização e outras geometrias serão estudadas nos capítulos posteriores.

1.5.6 Desigualdade triangular

Teorema 1.2 (Desigualdade triangular). *Para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,*

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Consequentemente, para quaisquer pontos $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$,

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

(Meyer, 2023)

Comprovação. Pela definição da norma euclidiana,

$$\|\mathbf{x} + \mathbf{y}\|^2 = \langle \mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y} \rangle.$$

Usando a linearidade e a simetria do produto interno,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &= \langle \mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{y}, \mathbf{x} \rangle + \langle \mathbf{y}, \mathbf{y} \rangle \\ &= \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{y}\|^2. \end{aligned}$$

Pela desigualdade de Cauchy–Schwarz,

$$\langle \mathbf{x}, \mathbf{y} \rangle \leq |\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

Portanto,

$$\begin{aligned} \|\mathbf{x} + \mathbf{y}\|^2 &\leq \|\mathbf{x}\|^2 + 2\|\mathbf{x}\| \|\mathbf{y}\| + \|\mathbf{y}\|^2 \\ &= (\|\mathbf{x}\| + \|\mathbf{y}\|)^2. \end{aligned}$$

Como ambos os lados são não negativos, podemos tomar a raiz quadrada e obter

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

Para demonstrar a desigualdade triangular da distância euclidiana, observe que

$$\mathbf{x} - \mathbf{z} = (\mathbf{x} - \mathbf{y}) + (\mathbf{y} - \mathbf{z}).$$

Aplicando a desigualdade triangular da norma,

$$\|\mathbf{x} - \mathbf{z}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y} - \mathbf{z}\|.$$

Como

$$d_E(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|,$$

segue que

$$d_E(\mathbf{x}, \mathbf{z}) \leq d_E(\mathbf{x}, \mathbf{y}) + d_E(\mathbf{y}, \mathbf{z}).$$

□

O produto interno, em conjunto com as normas, determina o ângulo entre vetores. A norma mede o comprimento de um vetor, e a distância euclidiana mede a separação entre dois pontos. Esses conceitos completam a representação geométrica inicial dos dados multivariados.

1.5.7 Produto externo

O produto interno associa dois vetores de mesma dimensão a um escalar. Dois vetores também podem ser utilizados para construir uma matriz por meio do produto externo.

Definição 1.14 (Produto externo). Sejam

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p$$

e

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_q \end{bmatrix} \in \mathbb{R}^q.$$

O **produto externo** de $\mathbf{x}$ e $\mathbf{y}$ é a matriz

$$\mathbf{x}, \mathbf{y} \in \mathbb{R}^{p \times q},$$

dada por

$$\mathbf{x} \otimes \mathbf{y} = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \cdots & x_1 y_q \\ x_2 y_1 & x_2 y_2 & \cdots & x_2 y_q \\ \vdots & \vdots & \ddots & \vdots \\ x_p y_1 & x_p y_2 & \cdots & x_p y_q \end{bmatrix}.$$

O elemento localizado na linha i e na coluna j é

$$(\mathbf{x} \otimes \mathbf{y})_{ij} = x_i y_j.$$

A estrutura do produto externo pode ser observada por suas colunas:

$$\mathbf{x} \otimes \mathbf{y} = [y_1 \mathbf{x} \ y_2 \mathbf{x} \ \cdots \ y_q \mathbf{x}].$$

Portanto, cada coluna é um múltiplo escalar de $\mathbf{x}$.

Equivalentemente, considerando as linhas,

$$\mathbf{x} \otimes \mathbf{y} = \begin{bmatrix} x_1 \mathbf{y}^\top \\ x_2 \mathbf{y}^\top \\ \vdots \\ x_p \mathbf{y}^\top \end{bmatrix},$$

de modo que cada linha é um múltiplo escalar de $\mathbf{y}^\top$.

Exemplo 1.11 (Exemplo: Produto externo de dois vetores). Considere

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^2$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \\ 4 \end{bmatrix} \in \mathbb{R}^3.$$

Como

$$\mathbf{y}^\top = \begin{bmatrix} 3 & -1 & 4 \end{bmatrix},$$

tem-se

$$\mathbf{x} \otimes \mathbf{y} = \begin{bmatrix} 3 & -1 & 4 \\ 6 & -2 & 8 \end{bmatrix}.$$

O resultado possui dimensão 2×3 .

O produto interno e o produto externo produzem objetos diferentes. Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$\langle \mathbf{x}, \mathbf{y} \rangle \in \mathbb{R},$$

enquanto

$$\mathbf{x} \otimes \mathbf{y} \in \mathbb{R}^{p \times p}.$$

Assim, o produto interno produz um escalar, enquanto o produto externo produz uma matriz. As propriedades matriciais do produto externo serão estudadas no próximo capítulo.

1.6 Síntese do capítulo

Uma observação descrita por p variáveis quantitativas pode ser representada por um vetor

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Um conjunto formado por n observações e p variáveis é organizado na matriz de dados

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

As linhas de $\mathbf{X}$ representam as observações como pontos de $\mathbb{R}^p$, enquanto as colunas representam as variáveis como vetores de $\mathbb{R}^n$.

A soma, a subtração e a multiplicação por escalar permitem construir novos vetores. As combinações lineares permitem reunir diferentes vetores ou variáveis mediante coeficientes previamente definidos.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, o produto interno euclidiano é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{j=1}^p x_j y_j.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle},$$

e representa o comprimento do vetor.

Para vetores não nulos, o ângulo $\theta \in [0, \pi]$ é determinado por

$$\cos(\theta) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dois vetores são ortogonais quando

$$\langle \mathbf{x}, \mathbf{y} \rangle = 0.$$

A distância euclidiana entre dois pontos é definida por

$$d_E(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|.$$

Além das operações que produzem vetores ou escalares, dois vetores podem gerar uma matriz por meio do produto externo. Para

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q,$$

tem-se

$$\mathbf{x} \otimes \mathbf{y} \in \mathbb{R}^{p \times q}.$$

Esses conceitos permitem interpretar os dados multivariados simultaneamente como vetores, matrizes e uma nuvem de pontos. O próximo capítulo desenvolverá as operações e as propriedades matriciais necessárias para manipular essas representações.

2 Álgebra matricial aplicada

No capítulo anterior, vetores foram apresentados nas formas coluna e linha, e a matriz de dados foi construída a partir da organização conjunta das observações e das variáveis. O produto externo mostrou ainda como dois vetores podem gerar uma matriz. Essas representações estabelecem a passagem natural da linguagem vetorial para a linguagem matricial.

Este capítulo desenvolve as operações e propriedades necessárias para manipular matrizes. O produto matriz-vetor e o produto entre matrizes permitem combinar linhas e colunas de dimensões compatíveis, enquanto a transposição, a simetria e o traço descrevem propriedades estruturais importantes dessas operações. Nesse contexto, o produto externo será retomado como um caso particular do produto matricial.

Também serão estudadas a identidade, a inversa, o determinante, o posto e sua relação com sistemas lineares, além de classes particulares de matrizes e de formas bilineares e quadráticas. As seções finais introduzem matrizes particionadas e complemento de Schur, preparando estruturas que serão utilizadas posteriormente na formulação de resultados multivariados.

Convenções matriciais

As convenções gerais apresentadas no capítulo anterior permanecem válidas. Neste capítulo, serão utilizadas também as seguintes convenções:

- $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ representam matrizes gerais;
- $\mathbf{X}$ representa preferencialmente uma matriz de dados;
- $\mathbf{x}$, $\mathbf{y}$ e $\mathbf{b}$ representam vetores-coluna;
- a_{ij} representa o elemento localizado na linha i e na coluna j de $\mathbf{A}$;
- $\mathbf{A}_{n \times p}$ ou $\mathbf{A} \in \mathbb{R}^{n \times p}$ indica que $\mathbf{A}$ possui n linhas e p colunas;
- $\mathbf{A}^\top$ representa a transposta de $\mathbf{A}$;
- $\mathbf{A}^{-1}$ representa a inversa de $\mathbf{A}$, quando ela existe;
- $\mathbf{A}^+$ representa a pseudoinversa de Moore–Penrose;
- $\mathbf{I}_k$ representa a matriz identidade de ordem k ;
- $\mathbf{0}_{n \times p}$ representa a matriz nula de dimensão $n \times p$;
- $\det(\mathbf{A})$ representa o determinante de uma matriz quadrada;
- $\text{tr}(\mathbf{A})$ representa o traço de uma matriz quadrada;
- $\text{posto}(\mathbf{A})$ representa o posto de $\mathbf{A}$.

Quando as linhas ou colunas de uma matriz forem consideradas individualmente, serão mantidas as convenções estabelecidas no capítulo anterior. Em particular, $\mathbf{a}_i^\top$ representa,

de forma abreviada, a i -ésima linha de $\mathbf{A}$, enquanto $\mathbf{a}_{.j}$ representa sua j -ésima coluna. As condições de existência e as propriedades de cada operação serão apresentadas nas seções correspondentes.

2.1 Operações matriciais fundamentais

As dimensões das matrizes determinam quais operações podem ser realizadas. A igualdade, a soma, a subtração e a multiplicação por escalar atuam sobre elementos correspondentes. O produto matricial combina linhas da primeira matriz com colunas da segunda.

Definição 2.1 (Igualdade entre matrizes). Sejam

$$\mathbf{A} = (a_{ij})_{n \times p} \quad \text{e} \quad \mathbf{B} = (b_{ij})_{r \times s}.$$

As matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando possuem as mesmas dimensões e elementos correspondentes iguais:

$$\mathbf{A} = \mathbf{B} \quad \Longleftrightarrow \quad n = r, \quad p = s \quad \text{e} \quad a_{ij} = b_{ij}$$

para $i = 1, \dots, n$ e $j = 1, \dots, p$.

Assim,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

mas

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix}.$$

A posição de cada elemento faz parte da estrutura da matriz.

2.1.1 Soma e subtração de matrizes

Definição 2.2 (Soma e subtração de matrizes). Sejam $\mathbf{A} = (a_{ij})_{n \times p}$ e $\mathbf{B} = (b_{ij})_{n \times p}$. A soma e a subtração são definidas por

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times p}$$

e

$$\mathbf{A} - \mathbf{B} = (a_{ij} - b_{ij})_{n \times p}.$$

As duas operações exigem que as matrizes possuam as mesmas dimensões.

Exemplo 2.1 (Exemplo: Soma e subtração de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & -2 \\ 2 & 1 \end{bmatrix}.$$

A soma é

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 1+4 & 2+(-2) \\ -1+2 & 3+1 \end{bmatrix} = \begin{bmatrix} 5 & 0 \\ 1 & 4 \end{bmatrix}.$$

A subtração é

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} 1-4 & 2-(-2) \\ -1-2 & 3-1 \end{bmatrix} = \begin{bmatrix} -3 & 4 \\ -3 & 2 \end{bmatrix}.$$

Proposição 2.1 (Propriedades da adição matricial). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{C} \in \mathbb{R}^{n \times p}.$$

A matriz nula de dimensão $n \times p$ é

$$\mathbf{0}_{n \times p} = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

A adição de matrizes satisfaz as seguintes propriedades:

1. *Comutatividade*

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}.$$

2. *Associatividade*

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C}).$$

3. *Existência do elemento neutro*

$$\mathbf{A} + \mathbf{0}_{n \times p} = \mathbf{A}.$$

4. *Existência do elemento oposto*

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}_{n \times p}.$$

Definição 2.3 (Multiplicação de matriz por escalar). Seja $\mathbf{A} = (a_{ij})_{n \times p}$ e seja $\alpha \in \mathbb{R}$. A multiplicação de $\mathbf{A}$ por α é definida por

$$\alpha \mathbf{A} = (\alpha a_{ij})_{n \times p}.$$

Cada elemento da matriz é multiplicado pelo mesmo escalar.

Exemplo 2.2 (Exemplo: Multiplicação de matriz por escalar). Para

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix}$$

e $\alpha = -2$, tem-se

$$-2\mathbf{A} = -2 \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} -2 & -4 \\ 2 & -6 \end{bmatrix}.$$

Proposição 2.2 (Propriedades da multiplicação por escalar). *Sejam*

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p}$$

e

$$\alpha, \beta \in \mathbb{R}.$$

A multiplicação de uma matriz por um escalar satisfaz as seguintes propriedades:

1. Distributividade em relação à adição de matrizes

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

2. Distributividade em relação à adição de escalares

$$(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

3. Associatividade da multiplicação por escalares

$$\alpha(\beta\mathbf{A}) = (\alpha\beta)\mathbf{A}.$$

4. Elemento neutro da multiplicação escalar

$$1\mathbf{A} = \mathbf{A}.$$

A adição de matrizes e a multiplicação por escalar preservam as dimensões das matrizes envolvidas. O produto matricial, apresentado a seguir, utiliza uma regra diferente e pode produzir uma matriz com dimensões distintas das matrizes multiplicadas.

2.1.2 Produto matriz-vetor

O produto de uma matriz por um vetor é definido quando o número de colunas da matriz coincide com o número de componentes do vetor.

Para

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad \text{e} \quad \mathbf{x} \in \mathbb{R}^p,$$

cada linha de $\mathbf{A}$ pode ser associada a um produto interno com $\mathbf{x}$. A definição a seguir reúne esses produtos internos em um vetor de $\mathbb{R}^n$.

Definição 2.4 (Produto matriz-vetor). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{x} \in \mathbb{R}^p.$$

O produto de $\mathbf{A}$ por $\mathbf{x}$ é o vetor

$$\mathbf{Ax} = \begin{bmatrix} \langle \mathbf{a}_1, \mathbf{x} \rangle \\ \langle \mathbf{a}_2, \mathbf{x} \rangle \\ \vdots \\ \langle \mathbf{a}_n, \mathbf{x} \rangle \end{bmatrix} \in \mathbb{R}^n.$$

Escrevendo

$$\mathbf{A} = (a_{ij})_{n \times p}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

cada produto interno pode ser escrito como

$$\langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

Portanto,

$$\mathbf{Ax} = \begin{bmatrix} \sum_{j=1}^p a_{1j} x_j \\ \sum_{j=1}^p a_{2j} x_j \\ \vdots \\ \sum_{j=1}^p a_{nj} x_j \end{bmatrix}.$$

A componente i do vetor resultante é, portanto,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x} = \langle \mathbf{a}_i, \mathbf{x} \rangle = \sum_{j=1}^p a_{ij} x_j.$$

O mesmo produto admite outra interpretação. Escrevendo $\mathbf{A}$ por suas colunas,

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p],$$

tem-se

$$\mathbf{Ax} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_p \mathbf{a}_p.$$

Assim, o produto matriz-vetor possui duas interpretações complementares:

- **pelos linhas**, cada componente de $\mathbf{Ax}$ é um produto interno entre o vetor associado a uma linha de $\mathbf{A}$ e $\mathbf{x}$;
- **pelos colunas**, $\mathbf{Ax}$ é uma combinação linear das colunas de $\mathbf{A}$, com coeficientes dados pelas componentes de $\mathbf{x}$.

Exemplo 2.3 (Exemplo: Produto de uma matriz por um vetor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ -1 & 3 \\ 2 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \in \mathbb{R}^2.$$

Pelas linhas de $\mathbf{A}$,

$$\mathbf{Ax} = \begin{bmatrix} (1)(2) + (2)(-1) \\ (-1)(2) + (3)(-1) \\ (2)(2) + (0)(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}.$$

Cada componente é um produto interno entre $\mathbf{x}$ e uma linha de $\mathbf{A}$.

Pelas colunas,

$$\mathbf{a}_{.1} = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_{.2} = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\begin{aligned} \mathbf{Ax} &= 2\mathbf{a}_{.1} - \mathbf{a}_{.2} \\ &= 2 \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 \\ -5 \\ 4 \end{bmatrix}. \end{aligned}$$

As duas formas de cálculo produzem o mesmo vetor: pelas linhas, o resultado é obtido por produtos internos; pelas colunas, por uma combinação linear.

2.1.3 Produto entre matrizes

O produto entre matrizes estende o produto matriz-vetor. Se as colunas de uma matriz $\mathbf{B}$ são

$$\mathbf{b}_{.1}, \mathbf{b}_{.2}, \dots, \mathbf{b}_{.r},$$

então multiplicar $\mathbf{A}$ por $\mathbf{B}$ equivale a multiplicar $\mathbf{A}$ por cada uma dessas colunas:

$$\mathbf{AB} = \mathbf{A} [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] = [\mathbf{Ab}_{.1} \ \mathbf{Ab}_{.2} \ \dots \ \mathbf{Ab}_{.r}].$$

Como cada componente de $\mathbf{Ab}_{.j}$ é um produto interno entre uma linha de $\mathbf{A}$ e a coluna $\mathbf{b}_{.j}$, cada elemento do produto matricial também pode ser interpretado como um produto interno.

Definição 2.5 (Produto entre matrizes). Sejam

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{B} = [\mathbf{b}_{.1} \ \mathbf{b}_{.2} \ \dots \ \mathbf{b}_{.r}] \in \mathbb{R}^{p \times r}.$$

O produto de $\mathbf{A}$ por $\mathbf{B}$ é a matriz

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_{.1} & \mathbf{a}_1^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_1^\top \mathbf{b}_{.r} \\ \mathbf{a}_2^\top \mathbf{b}_{.1} & \mathbf{a}_2^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_2^\top \mathbf{b}_{.r} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_{.1} & \mathbf{a}_n^\top \mathbf{b}_{.2} & \dots & \mathbf{a}_n^\top \mathbf{b}_{.r} \end{bmatrix} \in \mathbb{R}^{n \times r}.$$

Portanto, o elemento localizado na linha i e na coluna j do produto é

$$(\mathbf{AB})_{ij} = \mathbf{a}_i^\top \mathbf{b}_{.j} = \langle \mathbf{a}_i, \mathbf{b}_{.j} \rangle.$$

Escrevendo

$$\mathbf{A} = (a_{ik})_{n \times p}$$

e

$$\mathbf{B} = (b_{kj})_{p \times r},$$

o mesmo elemento pode ser expresso como

$$(\mathbf{AB})_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

para

$$i = 1, \dots, n \quad \text{e} \quad j = 1, \dots, r.$$

Assim, o produto matricial admite duas leituras complementares:

- **pelos elementos**, cada entrada de $\mathbf{AB}$ é o produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$;
- **pelas colunas**, cada coluna de $\mathbf{AB}$ é obtida multiplicando $\mathbf{A}$ pela coluna correspondente de $\mathbf{B}$.

Compatibilidade dimensional

O produto $\mathbf{AB}$ é definido somente quando o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$:

$$\underset{n \times p}{\mathbf{A}} \underset{p \times r}{\mathbf{B}} = \underset{n \times r}{\mathbf{AB}}.$$

As dimensões internas devem coincidir. As dimensões externas determinam a dimensão do resultado.

Exemplo 2.4 (Exemplo: Produto entre duas matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 3 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$$

e

$$\mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 4 & 2 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Como o número de colunas de $\mathbf{A}$ coincide com o número de linhas de $\mathbf{B}$, o produto está definido e possui dimensão 2×2 .

Cada elemento é obtido pelo produto interno entre uma linha de $\mathbf{A}$ e uma coluna de $\mathbf{B}$. Por exemplo,

$$(\mathbf{AB})_{11} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 4 \end{bmatrix} = (1)(2) + (2)(0) + (0)(4) = 2,$$

enquanto

$$(\mathbf{AB})_{12} = \begin{bmatrix} 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = (1)(1) + (2)(-1) + (0)(2) = -1.$$

Procedendo da mesma forma para os demais elementos,

$$\mathbf{AB} = \begin{bmatrix} 2 & -1 \\ 2 & -2 \end{bmatrix}.$$

Exemplo 2.5 (Exemplo: Produtos envolvendo uma matriz de dados). Considere a matriz de dados

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 4 \\ 3 & 5 & 2 \\ 6 & 2 & 1 \\ 4 & 3 & 5 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

As quatro linhas correspondem às observações, e as três colunas correspondem às variáveis.

Considere ainda

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}.$$

O produto

$$\mathbf{Xa} = \begin{bmatrix} 0 \\ 11 \\ 9 \\ 5 \end{bmatrix}$$

pode ser escrito, em termos das colunas de $\mathbf{X}$, como

$$\mathbf{X}\mathbf{a} = \mathbf{x}_{\cdot 1} + 2\mathbf{x}_{\cdot 2} - \mathbf{x}_{\cdot 3}.$$

Portanto, o vetor resultante contém os valores da nova variável formada pela combinação linear

$$X_1 + 2X_2 - X_3.$$

O produto

$$\mathbf{X}^\top \mathbf{X} = \begin{bmatrix} 65 & 41 & 40 \\ 41 & 39 & 31 \\ 40 & 31 & 46 \end{bmatrix}$$

possui dimensão 3×3 . Cada elemento é o produto interno entre duas colunas de $\mathbf{X}$ e, portanto, relaciona duas variáveis. Em geral,

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \mathbf{x}_{\cdot j}^\top \mathbf{x}_{\cdot k} = \langle \mathbf{x}_{\cdot j}, \mathbf{x}_{\cdot k} \rangle.$$

Por exemplo,

$$(\mathbf{X}^\top \mathbf{X})_{12} = \begin{bmatrix} 2 & 3 & 6 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ 5 \\ 2 \\ 3 \end{bmatrix} = 41.$$

Por outro lado,

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} 21 & 19 & 18 & 31 \\ 19 & 38 & 30 & 37 \\ 18 & 30 & 41 & 35 \\ 31 & 37 & 35 & 50 \end{bmatrix}$$

possui dimensão 4×4 . Cada elemento é o produto interno entre duas linhas de $\mathbf{X}$ e, portanto, relaciona duas observações. Em geral,

$$(\mathbf{X}\mathbf{X}^\top)_{ih} = \mathbf{x}_i^\top \mathbf{x}_h = \langle \mathbf{x}_i, \mathbf{x}_h \rangle.$$

Por exemplo,

$$(\mathbf{X}\mathbf{X}^\top)_{12} = \begin{bmatrix} 2 & 1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \\ 2 \end{bmatrix} = 19.$$

Assim, a mesma matriz de dados gera dois produtos com interpretações distintas:

- $\mathbf{X}^\top \mathbf{X}$ relaciona as variáveis;
- $\mathbf{X}\mathbf{X}^\top$ relaciona as observações.

Esses produtos serão retomados no estudo de matrizes de Gram, produtos cruzados, covariâncias e decomposição em valores singulares.

2.1.4 Propriedades do produto matricial

Proposição 2.3 (Propriedades do produto matricial). *Para matrizes com dimensões compatíveis, o produto matricial satisfaz as seguintes propriedades:*

1. Associatividade

$$(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC}).$$

2. Distributividade à esquerda

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}.$$

3. Distributividade à direita

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC}.$$

4. Compatibilidade com a multiplicação por escalar

Para $\alpha \in \mathbb{R}$,

$$(\alpha \mathbf{A})\mathbf{B} = \alpha(\mathbf{AB}) = \mathbf{A}(\alpha \mathbf{B}).$$

O produto matricial, em geral, **não é comutativo**. Mesmo quando $\mathbf{AB}$ e $\mathbf{BA}$ estão ambos definidos e possuem a mesma dimensão, pode ocorrer

$$\mathbf{AB} \neq \mathbf{BA}.$$

Exemplo 2.6 (Exemplo: Não comutatividade do produto matricial). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Tem-se

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

enquanto

$$\mathbf{BA} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} \neq \mathbf{BA}.$$

2.1.5 Produto externo como caso particular do produto matricial

No capítulo anterior, o produto externo de

$$\mathbf{x} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{y} \in \mathbb{R}^q$$

foi definido como a matriz

$$\mathbf{xy}^\top \in \mathbb{R}^{p \times q}.$$

A regra do produto matricial permite agora interpretar essa operação pelas dimensões:

$$\underset{p \times 1}{\mathbf{x}} \underset{1 \times q}{\mathbf{y}}^\top = \underset{p \times q}{\mathbf{xy}}^\top.$$

Assim, o produto externo pode ser entendido como um caso particular do produto matricial.

Quando

$$\mathbf{x} \in \mathbb{R}^p,$$

o produto

$$\mathbf{xx}^\top \in \mathbb{R}^{p \times p}$$

será especialmente importante. Suas propriedades serão retomadas nas seções sobre transposição, simetria, traço, posto e positividade.

Com as principais operações matriciais estabelecidas, podemos estudar propriedades estruturais das matrizes. A primeira delas envolve a transposição e conduz naturalmente às matrizes simétricas.

2.2 Transposição, simetria e traço

A transposição troca as linhas de uma matriz por suas colunas. Essa operação permite reorganizar produtos matriciais e definir matrizes simétricas.

2.2.1 Transposição

Definição 2.6 (Matriz transposta). Seja

$$\mathbf{A} = (a_{ij})_{n \times p} \in \mathbb{R}^{n \times p}.$$

A **transposta** de $\mathbf{A}$ é a matriz

$$\mathbf{A}^\top = (a_{ji})_{p \times n} \in \mathbb{R}^{p \times n}.$$

O elemento que ocupa a linha i e a coluna j de $\mathbf{A}$ passa a ocupar a linha j e a coluna i de $\mathbf{A}^\top$.

Exemplo 2.7 (Exemplo: Transposição de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in \mathbb{R}^{2 \times 3}.$$

Sua transposta é

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transposta possui dimensão

$$\mathbf{X}^\top \in \mathbb{R}^{p \times n}.$$

As linhas de $\mathbf{X}$ tornam-se as colunas de $\mathbf{X}^\top$, e as colunas de $\mathbf{X}$ tornam-se suas linhas.

2.2.2 Propriedades da transposição

Para matrizes com dimensões compatíveis e $\alpha \in \mathbb{R}$,

$$(\mathbf{A}^\top)^\top = \mathbf{A},$$

$$(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top,$$

$$(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$$

e

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

A transposição de um produto inverte a ordem das matrizes.

Em particular, para vetores $\mathbf{x}$ e $\mathbf{y}$,

$$(\mathbf{xy}^\top)^\top = \mathbf{yx}^\top.$$

Essa propriedade será útil para reconhecer estruturas simétricas construídas a partir de produtos externos.

Exemplo 2.8 (Exemplo: Transposta de um produto). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} 7 & 9 \\ 2 & 4 \end{bmatrix},$$

de modo que

$$(\mathbf{AB})^\top = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Por outro lado,

$$\mathbf{B}^\top \mathbf{A}^\top = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ 9 & 4 \end{bmatrix}.$$

Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

No capítulo anterior, o produto interno euclidiano foi representado por

$$\langle \mathbf{x}, \mathbf{y} \rangle.$$

Após a introdução da transposição e do produto matricial, a mesma operação pode ser escrita como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

As duas notações serão utilizadas de acordo com o contexto: a primeira destaca a interpretação geométrica, enquanto a segunda destaca a representação matricial.

2.2.3 Matrizes simétricas

A simetria compara uma matriz quadrada com sua transposta.

Definição 2.7 (Matriz simétrica). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

é **simétrica** quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Em termos dos elementos,

$$a_{ij} = a_{ji}, \quad i, j = 1, \dots, n.$$

Em uma matriz simétrica, os elementos situados em posições opostas em relação à diagonal principal são iguais.

Exemplo 2.9 (Exemplo: Matriz simétrica). A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix}$$

é simétrica, pois

$$\mathbf{A}^\top = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 4 & 2 \\ -3 & 2 & 5 \end{bmatrix} = \mathbf{A}.$$

A soma de matrizes simétricas de mesma dimensão é simétrica. Se $\mathbf{A}$ é simétrica e $\alpha \in \mathbb{R}$, então $\alpha\mathbf{A}$ também é simétrica.

Um caso particularmente importante é obtido pelo produto externo de um vetor consigo mesmo. Para

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$(\mathbf{xx}^\top)^\top = \mathbf{xx}^\top.$$

Portanto,

$$\mathbf{xx}^\top$$

é uma matriz simétrica.

O produto de duas matrizes simétricas não é necessariamente simétrico. Para matrizes simétricas $\mathbf{A}$ e $\mathbf{B}$,

$$(\mathbf{AB})^\top = \mathbf{BA}.$$

Portanto, $\mathbf{AB}$ é simétrica quando

$$\mathbf{AB} = \mathbf{BA}.$$

Definição 2.8 (Matriz antissimétrica). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

é **antissimétrica** quando

$$\mathbf{A}^\top = -\mathbf{A}.$$

Os elementos da diagonal principal de uma matriz antissimétrica são iguais a zero. De fato,

$$a_{ii} = -a_{ii}$$

implica

$$a_{ii} = 0.$$

Uma matriz antissimétrica possui a forma

$$\mathbf{A} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ -a_{12} & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{1n} & -a_{2n} & \cdots & 0 \end{bmatrix}.$$

Aprofundamento

A decomposição seguinte mostra que toda matriz quadrada pode ser separada em uma parte simétrica e uma parte antissimétrica. A parte simétrica será particularmente importante no estudo das formas quadráticas.

Teorema 2.1 (Decomposição em partes simétrica e antissimétrica). *Toda matriz quadrada*

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

pode ser escrita de maneira única como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

é simétrica e

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. (Horn; Johnson, 2013)

Comprovação. A transposta de $\mathbf{S}$ é

$$\mathbf{S}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{S}.$$

Logo, $\mathbf{S}$ é simétrica.

Para $\mathbf{K}$,

$$\mathbf{K}^\top = \left(\frac{\mathbf{A} - \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top - \mathbf{A}}{2} = -\mathbf{K}.$$

Logo, $\mathbf{K}$ é antissimétrica. Além disso,

$$\mathbf{S} + \mathbf{K} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} + \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \mathbf{A}.$$

Para verificar a unicidade, suponha que

$$\mathbf{A} = \mathbf{S}_1 + \mathbf{K}_1,$$

em que $\mathbf{S}_1$ é simétrica e $\mathbf{K}_1$ é antissimétrica. Transpondo essa igualdade,

$$\mathbf{A}^\top = \mathbf{S}_1 - \mathbf{K}_1.$$

Somando e subtraindo as duas expressões, obtém-se

$$\mathbf{S}_1 = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$$

e

$$\mathbf{K}_1 = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Portanto, as partes simétrica e antissimétrica são únicas. □

Exemplo 2.10 (Exemplo: Partes simétrica e antissimétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix}.$$

A parte simétrica é

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} + \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

A parte antissimétrica é

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \left(\begin{bmatrix} 1 & 4 \\ -2 & 3 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ 4 & 3 \end{bmatrix} \right) = \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

Portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 3 \\ -3 & 0 \end{bmatrix}.$$

A parte simétrica será utilizada no estudo das formas quadráticas. As matrizes de covariâncias também pertencem à classe das matrizes simétricas.

2.2.4 Traço

O traço reúne os elementos da diagonal principal de uma matriz quadrada.

Definição 2.9 (Traço de uma matriz). Seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O **traço** de $\mathbf{A}$ é definido por

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}.$$

Exemplo 2.11 (Exemplo: Cálculo do traço). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ -1 & 4 & 3 \\ 2 & 5 & -3 \end{bmatrix},$$

tem-se

$$\text{tr}(\mathbf{A}) = 2 + 4 - 3 = 3.$$

Para matrizes $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\alpha \in \mathbb{R}$, o traço satisfaz

$$\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B}),$$

$$\text{tr}(\alpha \mathbf{A}) = \alpha \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A}).$$

Teorema 2.2 (Propriedade cíclica do traço). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p} \quad e \quad \mathbf{B} \in \mathbb{R}^{p \times n},$$

então

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}).$$

(Harville, 1997)

Comprovação. Pela definição do produto matricial,

$$\text{tr}(\mathbf{AB}) = \sum_{i=1}^n (\mathbf{AB})_{ii} = \sum_{i=1}^n \sum_{j=1}^p a_{ij} b_{ji}.$$

Trocando a ordem das somas,

$$\text{tr}(\mathbf{AB}) = \sum_{j=1}^p \sum_{i=1}^n b_{ji} a_{ij} = \text{tr}(\mathbf{BA}).$$

□

Para três matrizes com dimensões compatíveis,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem dos fatores pode ser deslocada ciclicamente, mas não pode ser alterada arbitrariamente.

Uma aplicação importante ocorre nas formas quadráticas. Como

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

é um escalar, ele pode ser identificado com seu próprio traço. Pela propriedade cíclica,

$$\begin{aligned} \mathbf{x}^\top \mathbf{A} \mathbf{x} &= \text{tr}(\mathbf{x}^\top \mathbf{A} \mathbf{x}) \\ &= \text{tr}(\mathbf{A} \mathbf{x} \mathbf{x}^\top). \end{aligned}$$

Essa identidade será utilizada em somas de quadrados, matrizes de covariâncias, funções de verossimilhança e cálculo matricial.

Exemplo 2.12 (Exemplo: Traço de produtos matriciais). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 2 & 1 \\ -1 & 4 \end{bmatrix}.$$

Os produtos são

$$\mathbf{AB} = \begin{bmatrix} 0 & 9 \\ -3 & 12 \end{bmatrix}$$

e

$$\mathbf{BA} = \begin{bmatrix} 2 & 7 \\ -1 & 10 \end{bmatrix}.$$

Embora

$$\mathbf{AB} \neq \mathbf{BA},$$

os traços são iguais:

$$\text{tr}(\mathbf{AB}) = 0 + 12 = 12$$

e

$$\text{tr}(\mathbf{BA}) = 2 + 10 = 12.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$\text{tr}(\mathbf{xx}^\top) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

Para uma matriz

$$\mathbf{A} = (a_{ij})_{n \times p},$$

tem-se

$$\text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^p a_{ij}^2.$$

O traço será utilizado na representação de somas de quadrados, variâncias totais e expressões envolvendo formas quadráticas. Sua relação com os autovalores será estabelecida no capítulo sobre decomposição espectral.

2.3 Identidade, inversa, determinante, posto e sistemas lineares

As matrizes identidade e inversa permitem representar operações que preservam ou recuperam vetores. A existência da inversa está relacionada ao determinante, ao posto e às soluções de sistemas lineares.

2.3.1 Matriz identidade

Definição 2.10 (Matriz identidade). A **matriz identidade** de ordem n é a matriz quadrada

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Seus elementos são definidos por

$$(\mathbf{I}_n)_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

A matriz identidade é o elemento neutro do produto matricial. Para

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathbf{I}_n \mathbf{A} = \mathbf{A}$$

e

$$\mathbf{A} \mathbf{I}_p = \mathbf{A}.$$

Para um vetor $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Exemplo 2.13 (Exemplo: Produto pela matriz identidade). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Então,

$$\mathbf{I}_2 \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{A} \mathbf{I}_2 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

2.3.2 Matriz inversa

Definição 2.11 (Matriz inversa). Uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n}$$

é **invertível** quando existe uma matriz

$$\mathbf{A}^{-1} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n.$$

A matriz $\mathbf{A}^{-1}$ é denominada **inversa** de $\mathbf{A}$.

Uma matriz que não possui inversa é denominada **singular**.

Teorema 2.3 (Unicidade da matriz inversa). *Se uma matriz possui inversa, essa inversa é única.*

Comprovação. Suponha que $\mathbf{B}$ e $\mathbf{C}$ sejam inversas de $\mathbf{A}$. Então,

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$$

e

$$\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n.$$

Assim,

$$\mathbf{B} = \mathbf{BI}_n = \mathbf{B}(\mathbf{AC}) = (\mathbf{BA})\mathbf{C} = \mathbf{I}_n\mathbf{C} = \mathbf{C}.$$

Logo, a inversa é única. □

Exemplo 2.14 (Exemplo: Verificação de uma matriz inversa). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Calculando os produtos,

$$\mathbf{AB} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$$

e

$$\mathbf{BA} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$$

e, para $\alpha \neq 0$,

$$(\alpha \mathbf{A})^{-1} = \frac{1}{\alpha} \mathbf{A}^{-1}.$$

Teorema 2.4 (Inversa de um produto). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes invertíveis de ordem n , então $\mathbf{AB}$ é invertível e*

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

Comprovação. Tem-se

$$(\mathbf{AB})(\mathbf{B}^{-1} \mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n \mathbf{A}^{-1} = \mathbf{I}_n.$$

Também,

$$(\mathbf{B}^{-1} \mathbf{A}^{-1})(\mathbf{AB}) = \mathbf{B}^{-1}(\mathbf{A}^{-1} \mathbf{A})\mathbf{B} = \mathbf{B}^{-1} \mathbf{I}_n \mathbf{B} = \mathbf{I}_n.$$

Logo,

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}.$$

□

A existência da inversa ainda não foi caracterizada. Essa condição será expressa por meio do determinante e do posto.

2.3.3 Determinante

O determinante associa uma matriz quadrada a um número real. Seu valor permite verificar a invertibilidade da matriz e quantificar alterações de área ou volume.

Definição 2.12 (Menor e cofator). Seja

$$\mathbf{A} = (a_{ij})_{n \times n}.$$

O **menor** M_{ij} é o determinante da matriz obtida pela retirada da linha i e da coluna j de $\mathbf{A}$.

O **cofator** do elemento a_{ij} é

$$C_{ij} = (-1)^{i+j} M_{ij}.$$

Definição 2.13 (Determinante). Para uma matriz de ordem um,

$$\mathbf{A} = [a_{11}],$$

define-se

$$\det(\mathbf{A}) = a_{11}.$$

Para $n \geq 2$, seja

$$\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}.$$

O determinante de $\mathbf{A}$ pode ser calculado recursivamente pela expansão em cofatores de qualquer linha fixa i :

$$\det(\mathbf{A}) = \sum_{j=1}^n a_{ij} C_{ij}.$$

Também pode ser calculado pela expansão de qualquer coluna fixa j :

$$\det(\mathbf{A}) = \sum_{i=1}^n a_{ij} C_{ij}.$$

Em cada termo, o cofator C_{ij} envolve o determinante de uma matriz de ordem $n - 1$. O caso de ordem um encerra a definição recursiva.

Para uma matriz de ordem dois,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = ad - bc.$$

Exemplo 2.15 (Exemplo: Determinante de uma matriz de ordem dois). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}.$$

O determinante é

$$\det(\mathbf{A}) = 3(4) - 1(2) = 10.$$

Para uma matriz de ordem três, a expansão pela primeira linha é

$$\det(\mathbf{A}) = a_{11}C_{11} + a_{12}C_{12} + a_{13}C_{13}.$$

Exemplo 2.16 (Exemplo: Determinante de uma matriz de ordem três). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 4 & 1 \end{bmatrix}.$$

Expandindo pela primeira linha,

$$\det(\mathbf{A}) = 1 \begin{vmatrix} 1 & 2 \\ 4 & 1 \end{vmatrix} - 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + 0 \begin{vmatrix} 3 & 1 \\ 0 & 4 \end{vmatrix}.$$

Portanto,

$$\det(\mathbf{A}) = 1(1 - 8) - 2(3 - 0) = -13.$$

Cálculo de determinantes

A expansão por cofatores é útil para compreender a definição do determinante e rea-

lizar cálculos de pequena ordem. Para matrizes maiores, a expansão direta se torna pouco eficiente. Nesses casos, o determinante costuma ser obtido por eliminação ou por decomposições matriciais, que serão estudadas posteriormente.

Teorema 2.5 (Propriedades do determinante). *Para matrizes quadradas de ordem n :*

1.

$$\det(\mathbf{I}_n) = 1.$$

2.

$$\det(\mathbf{A}^\top) = \det(\mathbf{A}).$$

3.

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}).$$

4. Para $\alpha \in \mathbb{R}$,

$$\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A}).$$

5. Se $\mathbf{A}$ é triangular, então

$$\det(\mathbf{A}) = \prod_{i=1}^n a_{ii}.$$

As operações elementares sobre as linhas modificam o determinante de maneira específica:

- a troca de duas linhas multiplica o determinante por -1 ;
- a multiplicação de uma linha por α multiplica o determinante por α ;
- a adição de um múltiplo de uma linha a outra linha não altera o determinante.

Se as linhas de $\mathbf{A}$ são linearmente dependentes, então

$$\det(\mathbf{A}) = 0.$$

A mesma conclusão vale quando as colunas são linearmente dependentes. A ocorrência de duas linhas ou duas colunas iguais é um caso particular dessa propriedade.

Teorema 2.6 (Determinante e invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$$\mathbf{A} \text{ é invertível} \iff \det(\mathbf{A}) \neq 0.$$

Quando $\mathbf{A}$ é invertível,

$$\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}.$$

De fato,

$$\det(\mathbf{A}\mathbf{A}^{-1}) = \det(\mathbf{I}_n) = 1,$$

e, pela propriedade multiplicativa,

$$\det(\mathbf{A}) \det(\mathbf{A}^{-1}) = 1.$$

Exemplo 2.17 (Exemplo: Verificação da invertibilidade). Para

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix},$$

tem-se

$$\det(\mathbf{A}) = 2(1) - 1(1) = 1.$$

Como

$$\det(\mathbf{A}) \neq 0,$$

a matriz é invertível.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}.$$

Nesse caso,

$$\det(\mathbf{B}) = 2(2) - 4(1) = 0.$$

A matriz $\mathbf{B}$ é singular.

2.3.4 Interpretação geométrica do determinante

Considere a transformação linear quadrada

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{n \times n}.$$

O determinante

$$\det(\mathbf{A})$$

é o fator orientado de alteração do volume n -dimensional produzido pela transformação. Seu valor absoluto,

$$|\det(\mathbf{A})|,$$

é o fator não negativo de alteração da medida geométrica:

- em uma dimensão, multiplica comprimentos;
- em duas dimensões, multiplica áreas;
- em três dimensões, multiplica volumes;
- em $\mathbb{R}^n$, multiplica volumes n -dimensionais.

O sinal do determinante registra o comportamento da orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, o volume n -dimensional é reduzido a zero e a imagem da transformação fica contida em um subespaço de dimensão inferior a n .

A Figura 2.1 apresenta essas situações em $\mathbb{R}^2$.

Na primeira situação, $\det(\mathbf{A}) = 2$: a área é multiplicada por 2 e a orientação é preservada. Na segunda, $\det(\mathbf{A}) = 0$: os vetores transformados são linearmente dependentes e a região bidimensional é comprimida em uma reta. Na terceira, $\det(\mathbf{A}) = -2$: a área também é multiplicada por 2, mas a orientação é invertida.




Figura 2.1: Interpretação geométrica do determinante em duas dimensões.

O determinante informa se uma matriz quadrada é invertível. O posto amplia essa análise para matrizes quadradas ou retangulares.

2.3.5 Posto

O posto mede a dimensão da informação linearmente independente representada por uma matriz. Ele identifica o número máximo de direções que não podem ser obtidas como combinações lineares umas das outras.

Definição 2.14 (Posto de uma matriz). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

O **posto** de $\mathbf{A}$, denotado por

$$\text{posto}(\mathbf{A}),$$

é a maior ordem de uma submatriz quadrada de $\mathbf{A}$ com determinante diferente de zero.

Equivalentemente, o posto é:

- o número máximo de colunas linearmente independentes de $\mathbf{A}$;
- o número máximo de linhas linearmente independentes de $\mathbf{A}$.

Esses dois números são sempre iguais. A interpretação do posto por meio dos espaços gerados pelas linhas e pelas colunas será desenvolvida no próximo capítulo.

O posto satisfaz

$$0 \leq \text{posto}(\mathbf{A}) \leq \min(n, p).$$

Uma matriz possui **posto completo** quando

$$\text{posto}(\mathbf{A}) = \min(n, p).$$

Um caso importante é o produto externo. Se

$$\mathbf{x} \neq \mathbf{0} \quad \text{e} \quad \mathbf{y} \neq \mathbf{0},$$

então

$$\text{posto}(\mathbf{xy}^\top) = 1.$$

De fato, todas as colunas de $\mathbf{xy}^\top$ são múltiplos escalares de $\mathbf{x}$ e, como $\mathbf{y} \neq \mathbf{0}$, pelo menos uma dessas colunas é não nula.

Essa estrutura será importante posteriormente nas decomposições matriciais, em que uma matriz poderá ser representada como soma de parcelas de posto 1.

Para uma matriz quadrada de ordem n ,

$$\text{posto}(\mathbf{A}) = n$$

equivale à existência de sua inversa.

Teorema 2.7 (Condições equivalentes de invertibilidade). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as afirmações seguintes são equivalentes:

$\mathbf{A}$ *é invertível,*

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n.$$

(Meyer, 2023)

Exemplo 2.18 (Exemplo: Posto de matrizes). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{A}) = 1(4) - 2(3) = -2,$$

tem-se

$$\text{posto}(\mathbf{A}) = 2.$$

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Como

$$\det(\mathbf{B}) = 0$$

e $\mathbf{B} \neq \mathbf{0}$,

$$\text{posto}(\mathbf{B}) = 1.$$

A segunda linha de $\mathbf{B}$ é o dobro da primeira, de modo que uma delas não acrescenta informação linear.

Para uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{posto}(\mathbf{X}) \leq \min(n, p).$$

Quando

$$\text{posto}(\mathbf{X}) < p,$$

existe redundância linear entre as variáveis. A interpretação do posto em termos de espaços gerados, independência linear e dimensão será desenvolvida no próximo capítulo.

2.3.6 Sistemas lineares

Um sistema de n equações lineares com p incógnitas pode ser escrito na forma matricial.

Definição 2.15 (Sistema linear). Sejam

$$\mathbf{A} \in \mathbb{R}^{n \times p}, \quad \mathbf{x} \in \mathbb{R}^p$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema linear associado é

$$\mathbf{Ax} = \mathbf{b}.$$

A matriz $\mathbf{A}$ contém os coeficientes, $\mathbf{x}$ contém as incógnitas e $\mathbf{b}$ contém os termos independentes.

Em componentes, o sistema é

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p &= b_2, \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p &= b_n. \end{aligned}$$

A matriz aumentada do sistema é

$$[\mathbf{A} \mid \mathbf{b}] = \begin{bmatrix} a_{11} & \cdots & a_{1p} & b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{n1} & \cdots & a_{np} & b_n \end{bmatrix}.$$

Teorema 2.8 (Existência e quantidade de soluções). *O sistema*

$$\mathbf{Ax} = \mathbf{b}$$

possui solução se, e somente se,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]).$$

Quando o sistema é consistente:

- *a solução é única se*

$$\text{posto}(\mathbf{A}) = p;$$

- *existem infinitas soluções se*

$$\text{posto}(\mathbf{A}) < p.$$

A Tabela 2.1 resume a classificação das soluções de um sistema linear.

Tabela 2.1: Classificação das soluções de um sistema linear.

Condição	Resultado
$\text{posto}(\mathbf{A}) \neq \text{posto}([\mathbf{A} \mid \mathbf{b}])$	Não existe solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = p$	Existe uma única solução
$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) < p$	Existem infinitas soluções

Exemplo 2.19 (Exemplo: Sistema com solução única). Considere

$$\begin{aligned}2x_1 + x_2 &= 5, \\ x_1 + x_2 &= 3.\end{aligned}$$

A forma matricial é

$$\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}.$$

Como

$$\det \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = 1,$$

a matriz de coeficientes é invertível. A solução é

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Exemplo 2.20 (Exemplo: Sistemas com infinitas soluções e sem solução). Considere inicialmente o sistema

$$\begin{aligned}x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 4.\end{aligned}$$

A segunda equação é o dobro da primeira. Portanto,

$$\text{posto}(\mathbf{A}) = \text{posto}([\mathbf{A} \mid \mathbf{b}]) = 1 < 2.$$

O sistema possui infinitas soluções, que podem ser escritas como

$$x_1 = 2 - t, \quad x_2 = t, \quad t \in \mathbb{R}.$$

Considere agora

$$\begin{aligned}x_1 + x_2 &= 2, \\ 2x_1 + 2x_2 &= 5.\end{aligned}$$

As linhas da matriz de coeficientes continuam proporcionais, mas os termos independentes não preservam a mesma proporção. Nesse caso,

$$\text{posto}(\mathbf{A}) = 1$$

e

$$\text{posto}([\mathbf{A} \mid \mathbf{b}]) = 2.$$

Como os postos são diferentes, o sistema não possui solução.

Para uma matriz quadrada invertível,

$$\mathbf{Ax} = \mathbf{b}$$

possui a solução única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

Cálculo da solução

A expressão

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

caracteriza a solução quando $\mathbf{A}$ é invertível. Em cálculos computacionais, sistemas lineares são resolvidos diretamente, sem calcular explicitamente a matriz inversa.

O número de equações e o número de incógnitas não determinam, isoladamente, a existência ou a quantidade de soluções:

- se $n > p$, o sistema é sobredeterminado;
- se $n < p$, o sistema é subdeterminado;
- se $n = p$, o sistema é quadrado.

A classificação completa depende dos postos de $\mathbf{A}$ e de $[\mathbf{A} \mid \mathbf{b}]$.

2.3.7 Aprofundamento: pseudoinversa

Leitura de aprofundamento

A pseudoinversa permite estender a resolução de sistemas lineares para matrizes retangulares ou singulares. Sua construção será desenvolvida no capítulo sobre decomposição em valores singulares. Nesta seção, são apresentadas sua definição e suas principais consequências.

Definição 2.16 (Pseudoinversa de Moore–Penrose). Seja

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é a única matriz

$$\mathbf{A}^+ \in \mathbb{R}^{p \times n}$$

que satisfaz simultaneamente:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Harville, 1997)

Quando $\mathbf{A}$ é quadrada e invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Considere o problema

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

O vetor

$$\mathbf{x}^+ = \mathbf{A}^+ \mathbf{b}$$

possui interpretações diferentes conforme a existência e a quantidade de soluções exatas.

Tabela 2.2: Interpretação da solução obtida pela pseudoinversa.

Situação do sistema	Interpretação de $\mathbf{x}^+ = \mathbf{A}^+ \mathbf{b}$
O sistema é consistente e possui solução única	$\mathbf{x}^+$ é a solução exata do sistema
O sistema é consistente e possui várias soluções	$\mathbf{x}^+$ é a solução exata de menor norma euclidiana
O sistema é inconsistente	$\mathbf{x}^+$ minimiza $\ \mathbf{Ax} - \mathbf{b}\ $ e possui a menor norma entre todos os minimizadores

No caso inconsistente, $\mathbf{x}^+$ resolve o problema de mínimos quadrados

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{Ax} - \mathbf{b}\|.$$

Pseudoinversa e inversa

Em geral,

$$\mathbf{A}^+ \mathbf{A} \neq \mathbf{I}_p$$

e

$$\mathbf{A} \mathbf{A}^+ \neq \mathbf{I}_n.$$

Portanto, a pseudoinversa não satisfaz todas as propriedades da inversa usual.

A construção de $\mathbf{A}^+$, sua interpretação por projeções e sua relação com o posto serão desenvolvidas no capítulo sobre decomposição em valores singulares.

2.4 Matrizes ortogonais, diagonais e triangulares

Algumas matrizes quadradas possuem estruturas que simplificam produtos, inversões e sistemas lineares. Nesta seção são consideradas as matrizes ortogonais, diagonais e triangulares.

2.4.1 Matrizes ortogonais

Definição 2.17 (Matriz ortogonal). Uma matriz

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

é **ortogonal** quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n.$$

A condição anterior implica que $\mathbf{Q}$ é invertível e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Consequentemente,

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_n.$$

Escrevendo as colunas de $\mathbf{Q}$ como

$$\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n],$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{q}_1 & \cdots & \mathbf{q}_1^\top \mathbf{q}_n \\ \vdots & \ddots & \vdots \\ \mathbf{q}_n^\top \mathbf{q}_1 & \cdots & \mathbf{q}_n^\top \mathbf{q}_n \end{bmatrix}.$$

Portanto, $\mathbf{Q}$ é ortogonal quando suas colunas satisfazem

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

As colunas possuem norma unitária e são ortogonais duas a duas. A mesma propriedade é satisfeita pelas linhas de $\mathbf{Q}$.

Exemplo 2.21 (Exemplo: Verificação da ortogonalidade). Considere

$$\mathbf{Q} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Sua transposta é

$$\mathbf{Q}^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Calculando o produto,

$$\mathbf{Q}^\top \mathbf{Q} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

Logo, $\mathbf{Q}$ é ortogonal e

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Teorema 2.9 (Preservação do produto interno). *Se $\mathbf{Q} \in \mathbb{R}^{n \times n}$ é ortogonal, então, para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,*

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Comprovação. Pela associatividade do produto matricial,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{y}.$$

Como

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n,$$

obtém-se

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{I}_n \mathbf{y} = \mathbf{x}^\top \mathbf{y}.$$

□

Tomando $\mathbf{y} = \mathbf{x}$, obtém-se

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Aplicando a mesma propriedade ao vetor $\mathbf{x} - \mathbf{y}$,

$$\|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| = \|\mathbf{x} - \mathbf{y}\|.$$

Portanto, matrizes ortogonais preservam produtos internos, normas e distâncias euclidianas.

Além disso,

$$\det(\mathbf{Q})^2 = \det(\mathbf{Q}^\top \mathbf{Q}) = \det(\mathbf{I}_n) = 1,$$

de modo que

$$\det(\mathbf{Q}) \in \{-1, 1\}.$$

O produto de matrizes ortogonais de mesma ordem também é ortogonal.

As interpretações das matrizes ortogonais como rotações, reflexões e mudanças de orientação serão desenvolvidas no capítulo sobre transformações lineares.

2.4.2 Matrizes diagonais

Definição 2.18 (Matriz diagonal). Uma matriz

$$\mathbf{D} = (d_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$$

é **diagonal** quando

$$d_{ij} = 0 \quad \text{para} \quad i \neq j.$$

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} = \text{diag}(d_1, d_2, \dots, d_n).$$

A matriz identidade é uma matriz diagonal:

$$\mathbf{I}_n = \text{diag}(1, 1, \dots, 1).$$

Toda matriz diagonal é simétrica, pois

$$\mathbf{D}^\top = \mathbf{D}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix},$$

o produto por uma matriz diagonal é

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} d_1 x_1 \\ d_2 x_2 \\ \vdots \\ d_n x_n \end{bmatrix}.$$

Cada componente de $\mathbf{x}$ é multiplicada pelo elemento correspondente da diagonal.

Exemplo 2.22 (Exemplo: Produto por uma matriz diagonal). Considere

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 4 \\ -2 \end{bmatrix}.$$

Então,

$$\mathbf{D}\mathbf{x} = \begin{bmatrix} 2(1) \\ -1(4) \\ 3(-2) \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \\ -6 \end{bmatrix}.$$

A soma e o produto de matrizes diagonais de mesma ordem também são diagonais. Se

$$\mathbf{D}_1 = \text{diag}(d_1, \dots, d_n)$$

e

$$\mathbf{D}_2 = \text{diag}(e_1, \dots, e_n),$$

então

$$\mathbf{D}_1 + \mathbf{D}_2 = \text{diag}(d_1 + e_1, \dots, d_n + e_n)$$

e

$$\mathbf{D}_1 \mathbf{D}_2 = \text{diag}(d_1 e_1, \dots, d_n e_n).$$

Duas matrizes diagonais de mesma ordem comutam:

$$\mathbf{D}_1 \mathbf{D}_2 = \mathbf{D}_2 \mathbf{D}_1.$$

O determinante de uma matriz diagonal é o produto dos elementos de sua diagonal:

$$\det(\mathbf{D}) = \prod_{i=1}^n d_i.$$

Logo, $\mathbf{D}$ é invertível se, e somente se,

$$d_i \neq 0, \quad i = 1, \dots, n.$$

Nesse caso,

$$\mathbf{D}^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right).$$

Para um inteiro positivo k ,

$$\mathbf{D}^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k).$$

As matrizes diagonais serão utilizadas nas decomposições matriciais estudadas nos capítulos posteriores.

2.4.3 Matrizes triangulares

Definição 2.19 (Matrizes triangulares). Uma matriz

$$\mathbf{U} = (u_{ij})_{n \times n}$$

é **triangular superior** quando

$$u_{ij} = 0 \quad \text{para} \quad i > j.$$

Sua forma geral é

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}.$$

Uma matriz

$$\mathbf{L} = (\ell_{ij})_{n \times n}$$

é **triangular inferior** quando

$$\ell_{ij} = 0 \quad \text{para} \quad i < j.$$

Sua forma geral é

$$\mathbf{L} = \begin{bmatrix} \ell_{11} & 0 & \cdots & 0 \\ \ell_{21} & \ell_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & \ell_{nn} \end{bmatrix}.$$

A transposta de uma matriz triangular superior é triangular inferior:

$\mathbf{U}^\top$ é triangular inferior.

Da mesma forma,

$\mathbf{L}^\top$ é triangular superior.

A soma e o produto de matrizes triangulares superiores de mesma ordem permanecem triangulares superiores. A mesma propriedade vale para matrizes triangulares inferiores.

O determinante de uma matriz triangular é o produto dos elementos de sua diagonal:

$$\det(\mathbf{U}) = \prod_{i=1}^n u_{ii}$$

e

$$\det(\mathbf{L}) = \prod_{i=1}^n \ell_{ii}.$$

Uma matriz triangular é invertível se, e somente se, todos os elementos de sua diagonal são diferentes de zero.

Exemplo 2.23 (Exemplo: Determinante de uma matriz triangular). Considere

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & -1 \\ 0 & 3 & 4 \\ 0 & 0 & 5 \end{bmatrix}.$$

Como $\mathbf{U}$ é triangular superior,

$$\det(\mathbf{U}) = 2(3)(5) = 30.$$

Como todos os elementos da diagonal são diferentes de zero, $\mathbf{U}$ é invertível.

2.4.4 Aprofundamento: sistemas triangulares

Leitura de aprofundamento

Os sistemas triangulares mostram como a estrutura de uma matriz pode simplificar a resolução de equações. Esses procedimentos também aparecem nas decomposições matriciais estudadas posteriormente.

Um sistema cuja matriz de coeficientes é triangular pode ser resolvido sequencialmente.

Para uma matriz triangular superior,

$$\mathbf{U}\mathbf{x} = \mathbf{b},$$

a última equação contém somente a incógnita x_n . Após determinar x_n , substitui-se seu valor na equação anterior. Esse procedimento continua até a determinação de x_1 e é denominado **substituição regressiva**.

Exemplo 2.24 (Exemplo: Sistema triangular superior). Considere o sistema

$$\begin{aligned}x_1 + 2x_2 - x_3 &= 4, \\2x_2 + 3x_3 &= 7, \\x_3 &= 1.\end{aligned}$$

Sua forma matricial é

$$\begin{bmatrix} 1 & 2 & -1 \\ 0 & 2 & 3 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ 1 \end{bmatrix}.$$

A última equação fornece

$$x_3 = 1.$$

Substituindo na segunda equação,

$$2x_2 + 3(1) = 7,$$

de modo que

$$x_2 = 2.$$

Substituindo os valores obtidos na primeira equação,

$$x_1 + 2(2) - 1 = 4,$$

resulta

$$x_1 = 1.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}.$$

Para um sistema

$$\mathbf{L}\mathbf{x} = \mathbf{b},$$

com $\mathbf{L}$ triangular inferior, a resolução começa pela primeira equação e segue até a última. Esse procedimento é denominado **substituição progressiva**.

As matrizes triangulares aparecem na resolução de sistemas e em decomposições matriciais. As formas bilineares e quadráticas serão estudadas na próxima seção.

2.5 Formas bilineares, formas quadráticas e positividade

As formas bilineares associam dois vetores a um escalar. Quando os dois vetores são iguais, obtém-se uma forma quadrática.

2.5.1 Formas bilineares

Definição 2.20 (Forma bilinear). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A função

$$B(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p,$$

é uma **forma bilinear** associada à matriz $\mathbf{A}$.

Em termos das componentes,

$$\mathbf{x}^\top \mathbf{A} \mathbf{y} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i y_j.$$

A bilinearidade significa que a expressão é linear em cada vetor quando o outro permanece fixo. Para $\alpha, \beta \in \mathbb{R}$,

$$B(\alpha \mathbf{x}_1 + \beta \mathbf{x}_2, \mathbf{y}) = \alpha B(\mathbf{x}_1, \mathbf{y}) + \beta B(\mathbf{x}_2, \mathbf{y})$$

e

$$B(\mathbf{x}, \alpha \mathbf{y}_1 + \beta \mathbf{y}_2) = \alpha B(\mathbf{x}, \mathbf{y}_1) + \beta B(\mathbf{x}, \mathbf{y}_2).$$

Exemplo 2.25 (Exemplo: Cálculo de uma forma bilinear). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

Tem-se

$$\mathbf{A}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} 5 \\ -6 \end{bmatrix}.$$

Logo,

$$\mathbf{x}^\top \mathbf{A}\mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 5 \\ -6 \end{bmatrix} = -7.$$

2.5.2 Formas quadráticas

Definição 2.21 (Forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A função

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^p,$$

é uma **forma quadrática** associada à matriz $\mathbf{A}$.

Em termos das componentes,

$$q(\mathbf{x}) = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j.$$

Para

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a forma quadrática é

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = ax_1^2 + (b+c)x_1x_2 + dx_2^2.$$

Teorema 2.10 (Parte simétrica de uma forma quadrática). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

Comprovação. A matriz $\mathbf{A}$ pode ser escrita como

$$\mathbf{A} = \mathbf{S} + \mathbf{K},$$

em que

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$$

é antissimétrica. Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x} + \mathbf{x}^\top \mathbf{K} \mathbf{x}.$$

O escalar $\mathbf{x}^\top \mathbf{K} \mathbf{x}$ satisfaz

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = (\mathbf{x}^\top \mathbf{K} \mathbf{x})^\top = \mathbf{x}^\top \mathbf{K}^\top \mathbf{x} = -\mathbf{x}^\top \mathbf{K} \mathbf{x}.$$

Portanto,

$$\mathbf{x}^\top \mathbf{K} \mathbf{x} = 0$$

e

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{S} \mathbf{x}.$$

□

Toda forma quadrática pode ser representada por uma matriz simétrica.

Exemplo 2.26 (Exemplo: Expansão de uma forma quadrática). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Efetuando os produtos,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 2x_1x_2 + 3x_2^2.$$

Para

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtém-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 2(1)^2 + 2(1)(2) + 3(2)^2 = 18.$$

2.5.3 Positividade

A classificação de uma matriz simétrica depende dos valores assumidos por sua forma quadrática.

Definição 2.22 (Classificação de matrizes simétricas pela forma quadrática). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. A classificação de $\mathbf{A}$ é determinada pelos valores da forma quadrática

$$q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

A matriz $\mathbf{A}$ é:

- **positiva definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$;

- **semidefinida positiva** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$;

- **negativa definida** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$$

para todo $\mathbf{x} \neq \mathbf{0}$;

- **semidefinida negativa** quando

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$$

para todo $\mathbf{x} \in \mathbb{R}^p$;

- **indefinida** quando existem vetores não nulos $\mathbf{x}$ e $\mathbf{y}$ tais que

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

e

$$\mathbf{y}^\top \mathbf{A} \mathbf{y} < 0.$$

Um exemplo importante de matriz semidefinida positiva é obtido pelo produto externo de um vetor consigo mesmo. Para $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{z}^\top (\mathbf{x} \mathbf{x}^\top) \mathbf{z} &= (\mathbf{x}^\top \mathbf{z})^2 \\ &\geq 0. \end{aligned}$$

Portanto,

$$\mathbf{x} \mathbf{x}^\top$$

é semidefinida positiva.

Exemplo 2.27 (Exemplo: Classificação de formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

tem-se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 2x_1^2 + 3x_2^2.$$

A expressão é positiva para todo $\mathbf{x} \neq \mathbf{0}$. Portanto, $\mathbf{A}$ é positiva definida.

Considere agora

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{B} \mathbf{x} = x_1^2 \geq 0.$$

A forma quadrática é igual a zero para vetores não nulos com $x_1 = 0$. Portanto, $\mathbf{B}$ é semidefinida positiva.

Para

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

tem-se

$$\mathbf{x}^\top \mathbf{C} \mathbf{x} = x_1^2 - x_2^2.$$

A expressão assume valores positivos e negativos. Portanto, $\mathbf{C}$ é indefinida.

2.5.4 Superfícies de nível

Uma superfície de nível de uma forma quadrática é definida por

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = c,$$

em que c é uma constante.

Quando $\mathbf{A}$ é positiva definida e $c > 0$, as superfícies de nível são elipsoides. Em duas dimensões, correspondem a elipses. Para $c = 0$, a superfície contém somente o vetor nulo, enquanto, para $c < 0$, não existem pontos que satisfaçam a equação.

Quando $\mathbf{A}$ é indefinida, a forma quadrática assume valores positivos e negativos. Em duas dimensões, no caso indefinido não singular, os níveis não nulos formam hipérbolas. O nível zero pode formar um par de retas que se cruzam na origem. Por exemplo,

$$x_1^2 - x_2^2 = 0$$

equivale a

$$x_2 = x_1 \quad \text{ou} \quad x_2 = -x_1.$$

A Figura 2.2 apresenta três formas quadráticas em $\mathbb{R}^2$.




Figura 2.2: Curvas de nível de formas quadráticas em duas dimensões. Na forma indefinida, níveis positivos, negativos e nulos são diferenciados também pelo tipo de linha.

A primeira forma produz circunferências. A segunda produz elipses com eixos de comprimentos diferentes. A terceira produz hipérboles.

Formas quadráticas aparecem em expressões de distância, variância e densidade. Os critérios baseados em autovalores serão apresentados no capítulo sobre decomposição espectral.

2.6 Aprofundamento: matrizes particionadas e complemento de Schur

Leitura de aprofundamento

Esta seção pode ser utilizada como referência nos capítulos posteriores. As operações por blocos e o complemento de Schur serão retomados no estudo de covariâncias particionadas, distribuições condicionais, regressão entre blocos e correlação canônica.

Uma matriz pode ser dividida em submatrizes denominadas blocos. O particionamento organiza os elementos sem alterar a matriz e permite realizar operações matriciais utilizando os blocos.

2.6.1 Matrizes particionadas

Definição 2.23 (Matriz particionada). Considere

$$\mathbf{A} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}.$$

Um particionamento de $\mathbf{A}$ em quatro blocos pode ser escrito como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{m_1 \times n_1}, \quad \mathbf{A}_{12} \in \mathbb{R}^{m_1 \times n_2},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{m_2 \times n_1}, \quad \mathbf{A}_{22} \in \mathbb{R}^{m_2 \times n_2}.$$

Os blocos de uma mesma linha do particionamento possuem o mesmo número de linhas. Os blocos de uma mesma coluna possuem o mesmo número de colunas.

Exemplo 2.28 (Exemplo: Particionamento de uma matriz). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}.$$

Separando as duas primeiras linhas e colunas das restantes,

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

com

$$\mathbf{A}_{11} = \begin{bmatrix} 1 & 2 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

$$\mathbf{A}_{21} = \begin{bmatrix} 7 & 8 \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} 9 \end{bmatrix}.$$

O particionamento pode ser definido de acordo com a organização do problema. Em uma matriz de dados, por exemplo, as colunas podem ser separadas em dois grupos de variáveis:

$$\mathbf{X} = [\mathbf{X}_1 \ \mathbf{X}_2],$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{n \times p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{n \times p_2}$$

e

$$p_1 + p_2 = p.$$

2.6.2 Soma e multiplicação por escalar

Considere matrizes com o mesmo particionamento:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

A soma pode ser realizada por blocos:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} \mathbf{A}_{11} + \mathbf{B}_{11} & \mathbf{A}_{12} + \mathbf{B}_{12} \\ \mathbf{A}_{21} + \mathbf{B}_{21} & \mathbf{A}_{22} + \mathbf{B}_{22} \end{bmatrix}.$$

Para $\alpha \in \mathbb{R}$,

$$\alpha \mathbf{A} = \begin{bmatrix} \alpha \mathbf{A}_{11} & \alpha \mathbf{A}_{12} \\ \alpha \mathbf{A}_{21} & \alpha \mathbf{A}_{22} \end{bmatrix}.$$

As operações exigem que os blocos correspondentes possuam as mesmas dimensões.

2.6.3 Transposição por blocos

A transposta de uma matriz particionada é

$$\mathbf{A}^\top = \begin{bmatrix} \mathbf{A}_{11}^\top & \mathbf{A}_{21}^\top \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22}^\top \end{bmatrix}.$$

Os blocos situados fora da diagonal trocam de posição e são transpostos.

Se $\mathbf{A}$ é simétrica, então

$$\mathbf{A}_{11}^\top = \mathbf{A}_{11}, \quad \mathbf{A}_{22}^\top = \mathbf{A}_{22}$$

e

$$\mathbf{A}_{21} = \mathbf{A}_{12}^\top.$$

Nesse caso, a matriz pode ser escrita como

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^\top & \mathbf{A}_{22} \end{bmatrix}.$$

2.6.4 Multiplicação por blocos

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix} \in \mathbb{R}^{(m_1+m_2) \times (n_1+n_2)}$$

e

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times (r_1+r_2)},$$

com

$$\mathbf{B}_{11} \in \mathbb{R}^{n_1 \times r_1}, \quad \mathbf{B}_{12} \in \mathbb{R}^{n_1 \times r_2},$$

$$\mathbf{B}_{21} \in \mathbb{R}^{n_2 \times r_1}, \quad \mathbf{B}_{22} \in \mathbb{R}^{n_2 \times r_2}.$$

O produto é

$$\mathbf{AB} = \begin{bmatrix} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{bmatrix}.$$

A regra é a mesma utilizada no produto matricial, com os elementos substituídos por blocos de dimensões compatíveis.

Exemplo 2.29 (Exemplo: Multiplicação de matrizes particionadas). Considere

$$\mathbf{A} = \left[\begin{array}{cc|c} 1 & 2 & 1 \\ 0 & 1 & 3 \\ \hline 2 & 0 & 4 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

e

$$\mathbf{B} = \left[\begin{array}{cc|c} 1 & 0 & 1 \\ 2 & 1 & 0 \\ \hline -1 & 2 & 3 \end{array} \right] = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}.$$

Os blocos da primeira linha do produto são

$$\mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} = \begin{bmatrix} 4 & 4 \\ -1 & 7 \end{bmatrix}$$

e

$$\mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}.$$

Os blocos da segunda linha são

$$\mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} = \begin{bmatrix} -2 & 8 \end{bmatrix}$$

e

$$\mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} = \begin{bmatrix} 14 \end{bmatrix}.$$

Portanto,

$$\mathbf{AB} = \left[\begin{array}{cc|c} 4 & 4 & 4 \\ -1 & 7 & 9 \\ \hline -2 & 8 & 14 \end{array} \right].$$

As operações por blocos permitem manipular grupos de linhas e colunas como unidades matriciais. O complemento de Schur utiliza essa estrutura para representar a parcela de um bloco ajustada pelo outro.

2.6.5 Complemento de Schur

O complemento de Schur é definido para matrizes quadradas particionadas em blocos, quando um dos blocos diagonais é invertível.

Considere

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\mathbf{A}_{11} \in \mathbb{R}^{p \times p}, \quad \mathbf{A}_{12} \in \mathbb{R}^{p \times q},$$

$$\mathbf{A}_{21} \in \mathbb{R}^{q \times p}, \quad \mathbf{A}_{22} \in \mathbb{R}^{q \times q}.$$

Definição 2.24 (Complemento de Schur). Se $\mathbf{A}_{22}$ é invertível, o **complemento de Schur de $\mathbf{A}_{22}$** em $\mathbf{A}$ é

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}.$$

Se $\mathbf{A}_{11}$ é invertível, o **complemento de Schur de $\mathbf{A}_{11}$** em $\mathbf{A}$ é

$$\mathbf{A}_{22.1} = \mathbf{A}_{22} - \mathbf{A}_{21} \mathbf{A}_{11}^{-1} \mathbf{A}_{12}.$$

O complemento $\mathbf{A}_{11.2}$ possui dimensão $p \times p$, e $\mathbf{A}_{22.1}$ possui dimensão $q \times q$.

Exemplo 2.30 (Exemplo: Cálculo de um complemento de Schur). Considere a matriz particionada

$$\mathbf{A} = \left[\begin{array}{cc|cc} 3 & 1 & 1 & 0 \\ 1 & 3 & 0 & 1 \\ \hline 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{array} \right] = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

em que

$$\begin{aligned} \mathbf{A}_{11} &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, & \mathbf{A}_{12} &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \\ \mathbf{A}_{21} &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} & \text{e} & \mathbf{A}_{22} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}. \end{aligned}$$

Como

$$\mathbf{A}_{22}^{-1} = \mathbf{I}_2,$$

o complemento de Schur de $\mathbf{A}_{22}$ é

$$\begin{aligned} \mathbf{A}_{11.2} &= \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

2.6.6 Determinante de uma matriz particionada

Teorema 2.11 (Determinante e complemento de Schur). *Para*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix},$$

se $\mathbf{A}_{22}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{22}) \det(\mathbf{A}_{11.2}).$$

Se $\mathbf{A}_{11}$ é invertível, então

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11}) \det(\mathbf{A}_{22.1}).$$

(Boyd; Vandenberghe, 2004)

Comprovação. Quando $\mathbf{A}_{22}$ é invertível, a matriz pode ser fatorada como

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_p & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I}_q \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11.2} & \mathbf{0} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

A primeira matriz possui determinante igual a 1. A segunda é triangular por blocos. Portanto,

$$\det(\mathbf{A}) = \det(\mathbf{A}_{11.2}) \det(\mathbf{A}_{22}).$$

A segunda identidade é obtida por uma fatoração análoga utilizando $\mathbf{A}_{11}$. □

No Exemplo 2.30,

$$\det(\mathbf{A}_{22}) = 1$$

e

$$\det(\mathbf{A}_{11.2}) = \det \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = 3.$$

Logo,

$$\det(\mathbf{A}) = 3.$$

2.6.7 Inversão em blocos

O complemento de Schur também permite escrever a inversa de uma matriz particionada.

Teorema 2.12 (Inversa em blocos). *Considere*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ e $\mathbf{A}_{11.2}$ são invertíveis, então

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11.2}^{-1} & -\mathbf{A}_{11.2}^{-1} \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{A}_{11.2}^{-1} & \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1} \mathbf{A}_{21} \mathbf{A}_{11.2}^{-1} \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \end{bmatrix}.$$

(Boyd; Vandenberghe, 2004)

Uma expressão equivalente pode ser obtida utilizando $\mathbf{A}_{22.1}$ quando $\mathbf{A}_{11}$ e $\mathbf{A}_{22.1}$ são invertíveis.

2.6.8 Positividade e complemento de Schur

Para matrizes simétricas, o complemento de Schur permite verificar a definição positiva utilizando matrizes de menor dimensão.

Teorema 2.13 (Positividade e complemento de Schur). *Considere a matriz simétrica*

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{12}^{\top} & \mathbf{A}_{22} \end{bmatrix}.$$

Se $\mathbf{A}_{22}$ é positiva definida, então

$\mathbf{A}$ é positiva definida

se, e somente se,

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^{\top}$$

é positiva definida. (Boyd; Vandenberghe, 2004)

Comprovação. Para $\mathbf{x} \in \mathbb{R}^p$ e $\mathbf{y} \in \mathbb{R}^q$,

$$\begin{aligned} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} &= \mathbf{x}^\top \mathbf{A}_{11} \mathbf{x} + 2\mathbf{x}^\top \mathbf{A}_{12} \mathbf{y} + \mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} \\ &= \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} \\ &\quad + (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x})^\top \mathbf{A}_{22} (\mathbf{y} + \mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}). \end{aligned}$$

Suponha inicialmente que $\mathbf{A}_{11.2}$ e $\mathbf{A}_{22}$ sejam positivas definidas. Para

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} \neq \mathbf{0},$$

se $\mathbf{x} \neq \mathbf{0}$, então

$$\mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0,$$

enquanto a segunda parcela é não negativa.

Se $\mathbf{x} = \mathbf{0}$, então $\mathbf{y} \neq \mathbf{0}$ e a forma quadrática reduz-se a

$$\mathbf{y}^\top \mathbf{A}_{22} \mathbf{y} > 0.$$

Portanto, $\mathbf{A}$ é positiva definida.

Reciprocamente, suponha que $\mathbf{A}$ seja positiva definida. Para qualquer $\mathbf{x} \neq \mathbf{0}$, escolha

$$\mathbf{y} = -\mathbf{A}_{22}^{-1} \mathbf{A}_{12}^\top \mathbf{x}.$$

Com essa escolha, a segunda parcela é igual a zero e

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix}^\top \mathbf{A} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} = \mathbf{x}^\top \mathbf{A}_{11.2} \mathbf{x} > 0.$$

Logo, $\mathbf{A}_{11.2}$ é positiva definida. □

Uma condição equivalente pode ser formulada utilizando $\mathbf{A}_{11}$ e o complemento $\mathbf{A}_{22.1}$.
Algebricamente, o termo

$$\mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

é a correção produzida pela eliminação do segundo bloco. O complemento de Schur

$$\mathbf{A}_{11.2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

é o bloco resultante após essa eliminação.

Essa interpretação é válida para matrizes particionadas gerais e não exige que os blocos representem variáveis ou covariâncias.

Quando $\mathbf{A}$ é uma matriz de covariâncias particionada, com

$$\mathbf{A}_{21} = \mathbf{A}_{12}^{\top},$$

o complemento de Schur possui uma interpretação estatística adicional: ele representa a matriz de covariâncias do resíduo obtido após o ajuste linear do primeiro bloco pelo segundo. Sob normalidade conjunta, ele também corresponde à matriz de covariâncias condicional.

Essa estrutura será retomada no estudo de covariâncias condicionais e de relações entre blocos de variáveis.

2.7 Síntese do capítulo

Uma matriz organiza valores em linhas e colunas e permite representar simultaneamente observações, variáveis, transformações e sistemas lineares. As dimensões determinam quais operações são possíveis e qual será a dimensão do resultado.

A tabela a seguir reúne os principais objetos desenvolvidos no capítulo.

Tabela 2.3: Principais objetos e operações matriciais desenvolvidos no capítulo.

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matriz-vetor	$\mathbf{Ax}$	Produz produtos internos pelas linhas e combinações lineares pelas colunas

Objeto ou operação	Expressão ou condição	Interpretação e utilização
Produto matricial	$\mathbf{A}_{n \times p} \mathbf{B}_{p \times r}$	Combina linhas e colunas de matrizes com dimensões compatíveis
Transposta	$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$	Troca linhas por colunas e reorganiza produtos
Matriz simétrica	$\mathbf{A}^\top = \mathbf{A}$	Estrutura presente em formas quadráticas e matrizes de covariâncias
Traço	$\text{tr}(\mathbf{A}) = \sum_i a_{ii}$	Resume a diagonal e reorganiza expressões matriciais
Matriz inversa	$\mathbf{A}^{-1} \mathbf{A} = \mathbf{I}_n$	Reverte a ação de uma matriz invertível
Determinante	$\det(\mathbf{A})$	Registra invertibilidade, alteração de volume e orientação
Posto	$\text{posto}(\mathbf{A})$	Mede a dimensão da informação linearmente independente
Matriz ortogonal	$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_n$	Preserva produtos internos, normas e distâncias
Forma bilinear	$\mathbf{x}^\top \mathbf{A} \mathbf{y}$	Relaciona dois vetores por meio de uma matriz
Forma quadrática	$\mathbf{x}^\top \mathbf{A} \mathbf{x}$	Representa variâncias, distâncias e superfícies de nível
Complemento de Schur	$\mathbf{A}_{11} - \mathbf{A}_{12} \mathbf{A}_{22}^{-1} \mathbf{A}_{21}$	Elimina um bloco e produz um bloco reduzido

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{n \times n},$$

as condições

$\mathbf{A}$ é invertível,

$$\det(\mathbf{A}) \neq 0$$

e

$$\text{posto}(\mathbf{A}) = n$$

são equivalentes.

O posto também permite classificar as soluções do sistema

$$\mathbf{Ax} = \mathbf{b}.$$

Quando a matriz não é invertível ou não é quadrada, a pseudoinversa permite formular soluções exatas de menor norma ou soluções de mínimos quadrados.

Para uma matriz simétrica, os valores da forma quadrática

$$\mathbf{x}^\top \mathbf{Ax}$$

permitem classificá-la como positiva definida, semidefinida positiva, negativa definida, semidefinida negativa ou indefinida.

As seções sobre pseudoinversa, sistemas triangulares, matrizes particionadas e complemento de Schur funcionam como aprofundamentos. Esses resultados serão retomados quando sua utilização estatística se tornar necessária.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar a compatibilidade dimensional das operações matriciais;
- calcular e interpretar produtos matriz-vetor e matriz-matriz;
- utilizar transposição, simetria e traço;
- relacionar inversa, determinante e posto;
- classificar as soluções de sistemas lineares;
- reconhecer matrizes ortogonais, diagonais e triangulares;
- calcular e interpretar formas bilineares e quadráticas;
- classificar matrizes simétricas por meio de suas formas quadráticas;
- operar com matrizes particionadas em situações introdutórias.

O próximo capítulo desenvolverá espaços vetoriais, bases, dimensão e projeções, fornecendo uma interpretação geométrica mais ampla para o posto, os sistemas lineares e as transformações matriciais.

3 Espaços vetoriais, bases e projeções

Os capítulos anteriores apresentaram a representação vetorial dos dados e as operações matriciais utilizadas para manipulá-los. Neste capítulo, os vetores são estudados como elementos de conjuntos que preservam as operações de adição e multiplicação por escalar.

Essa estrutura permite identificar subespaços, verificar relações de dependência linear e representar um espaço por meio de uma base. O posto de uma matriz será interpretado a partir das dimensões de seus espaços fundamentais.

A parte final do capítulo desenvolve a projeção ortogonal. Essa operação decompõe um vetor em uma componente pertencente a um subespaço e uma componente ortogonal, fornecendo a interpretação geométrica dos problemas de melhor aproximação e mínimos quadrados.

3.1 Espaços, subespaços e geração

Um espaço vetorial é um conjunto no qual a soma de vetores e a multiplicação por escalares permanecem definidas e satisfazem propriedades algébricas específicas.

Definição 3.1 (Espaço vetorial). Um conjunto não vazio V é um **espaço vetorial real** quando estão definidas:

- a soma $\mathbf{x} + \mathbf{y} \in V$, para $\mathbf{x}, \mathbf{y} \in V$;
- a multiplicação $\alpha \mathbf{x} \in V$, para $\alpha \in \mathbb{R}$ e $\mathbf{x} \in V$;

e, para quaisquer $\mathbf{x}, \mathbf{y}, \mathbf{z} \in V$ e $\alpha, \beta \in \mathbb{R}$, são satisfeitas as propriedades

$$\mathbf{x} + \mathbf{y} = \mathbf{y} + \mathbf{x},$$

$$(\mathbf{x} + \mathbf{y}) + \mathbf{z} = \mathbf{x} + (\mathbf{y} + \mathbf{z}),$$

$$\mathbf{x} + \mathbf{0} = \mathbf{x},$$

$$\mathbf{x} + (-\mathbf{x}) = \mathbf{0},$$

$$\alpha(\mathbf{x} + \mathbf{y}) = \alpha\mathbf{x} + \alpha\mathbf{y},$$

$$(\alpha + \beta)\mathbf{x} = \alpha\mathbf{x} + \beta\mathbf{x},$$

$$\alpha(\beta\mathbf{x}) = (\alpha\beta)\mathbf{x}$$

e

$$1\mathbf{x} = \mathbf{x}.$$

O espaço $\mathbb{R}^p$, com as operações usuais, é um espaço vetorial. O vetor nulo é

$$\mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix},$$

e o inverso aditivo de

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix}$$

é

$$-\mathbf{x} = \begin{bmatrix} -x_1 \\ \vdots \\ -x_p \end{bmatrix}.$$

O conjunto de todas as matrizes reais de dimensão $m \times n$,

$$\mathbb{R}^{m \times n},$$

também é um espaço vetorial com as operações usuais de soma e multiplicação por escalar.

3.1.1 Subespaços vetoriais

Um subconjunto de um espaço vetorial pode preservar a estrutura das operações.

Definição 3.2 (Subespaço vetorial). Seja V um espaço vetorial. Um subconjunto não vazio $W \subseteq V$ é um **subespaço vetorial** de V quando, para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha \in \mathbb{R}$,

$$\mathbf{x} + \mathbf{y} \in W$$

e

$$\alpha \mathbf{x} \in W.$$

As duas condições garantem que toda combinação linear de vetores de W também pertence a W .

Teorema 3.1 (Critério de subespaço). *Um subconjunto não vazio $W \subseteq V$ é um subespaço vetorial se, e somente se,*

$$\alpha \mathbf{x} + \beta \mathbf{y} \in W$$

para quaisquer $\mathbf{x}, \mathbf{y} \in W$ e $\alpha, \beta \in \mathbb{R}$. (Meyer, 2023)

O vetor nulo pertence a todo subespaço. De fato, para qualquer $\mathbf{x} \in W$,

$$0\mathbf{x} = \mathbf{0} \in W.$$

Exemplo 3.1 (Exemplo: Reta que é um subespaço). Considere

$$W = \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \subseteq \mathbb{R}^2.$$

Se

$$\mathbf{x} = \begin{bmatrix} t_1 \\ t_1 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} t_2 \\ t_2 \end{bmatrix}$$

pertencem a W , então

$$\alpha \mathbf{x} + \beta \mathbf{y} = \begin{bmatrix} \alpha t_1 + \beta t_2 \\ \alpha t_1 + \beta t_2 \end{bmatrix} \in W.$$

Portanto, W é um subespaço de $\mathbb{R}^2$.

Uma reta que não passa pela origem não é um subespaço.

Exemplo 3.2 (Exemplo: Reta que não é um subespaço). Considere

$$S = \left\{ \begin{bmatrix} t \\ t+1 \end{bmatrix} : t \in \mathbb{R} \right\}.$$

O vetor nulo não pertence a S . Portanto, S não é um subespaço de $\mathbb{R}^2$.

O conjunto S é uma translação do subespaço W e constitui um conjunto afim.

A Figura 3.1 compara uma reta que passa pela origem com uma reta afim paralela.




Figura 3.1: Comparação entre um subespaço de $\mathbb{R}^2$ e uma reta afim.

A reta do primeiro painel contém a origem e é fechada em relação às combinações lineares. A reta do segundo painel não contém a origem.

3.1.2 Subespaço gerado

As combinações lineares de um conjunto de vetores formam um subespaço.

Definição 3.3 (Subespaço gerado). Sejam

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V.$$

O **subespaço gerado** por esses vetores é

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_1, \dots, \alpha_k \in \mathbb{R}\}.$$

Esse conjunto também é denominado **envoltória linear** dos vetores.

O subespaço gerado é o menor subespaço que contém todos os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k$.

Exemplo 3.3 (Exemplo: Subespaço gerado por um vetor). Considere

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

O conjunto

$$\text{span}\{\mathbf{v}\} = \left\{ \alpha \begin{bmatrix} 1 \\ 2 \end{bmatrix} : \alpha \in \mathbb{R} \right\}$$

é uma reta que passa pela origem.

Exemplo 3.4 (Exemplo: Subespaço gerado por dois vetores). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma combinação linear desses vetores é

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix}.$$

Para qualquer vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2,$$

basta escolher

$$\alpha_2 = x_2$$

e

$$\alpha_1 = x_1 - x_2.$$

Portanto,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \mathbb{R}^2.$$

Um mesmo subespaço pode ser gerado por diferentes conjuntos de vetores. Alguns conjuntos podem conter vetores redundantes. A independência linear permite identificar quando um vetor acrescenta uma nova direção ao subespaço gerado.

3.2 Independência linear, bases e dimensão

Um conjunto de vetores pode gerar um subespaço mesmo quando contém vetores redundantes. A independência linear permite verificar se cada vetor acrescenta uma nova direção ao conjunto gerado.

3.2.1 Independência linear

Definição 3.4 (Independência linear). Os vetores

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in V$$

são **linearmente independentes** quando a igualdade

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \alpha_2 = \cdots = \alpha_k = 0.$$

Quando existe uma solução em que pelo menos um coeficiente é diferente de zero, os vetores são **linearmente dependentes**.

A solução

$$\alpha_1 = \alpha_2 = \cdots = \alpha_k = 0$$

é denominada **solução trivial**. Um conjunto é linearmente independente quando a solução trivial é a única combinação linear que produz o vetor nulo.

Exemplo 3.5 (Exemplo: Vetores linearmente dependentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

tem-se

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0}.$$

Os coeficientes 2 e -1 não são ambos nulos. Portanto, $\mathbf{v}_1$ e $\mathbf{v}_2$ são linearmente dependentes.

Além disso,

$$\text{span}\{\mathbf{v}_1, \mathbf{v}_2\} = \text{span}\{\mathbf{v}_1\}.$$

O vetor $\mathbf{v}_2$ não acrescenta uma nova direção ao subespaço gerado.

Exemplo 3.6 (Exemplo: Vetores linearmente independentes). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Suponha que

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 = \mathbf{0}.$$

Então,

$$\alpha_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha_1 + \alpha_2 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda equação fornece

$$\alpha_2 = 0,$$

e a primeira fornece

$$\alpha_1 = 0.$$

Portanto, os vetores são linearmente independentes.

A Figura 3.2 compara dois vetores dependentes com dois vetores independentes em $\mathbb{R}^2$.

No primeiro painel, os vetores pertencem à mesma reta e geram um subespaço unidimensional. No segundo, os vetores determinam duas direções distintas e geram $\mathbb{R}^2$.

3.2.2 Independência linear e sistemas homogêneos

Considere a matriz cujas colunas são os vetores analisados:

$$\mathbf{A} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_k].$$

A combinação linear

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

pode ser escrita como




Figura 3.2: Comparação entre vetores linearmente dependentes e independentes em $\mathbb{R}^2$.

$$\mathbf{A}\alpha = \mathbf{0},$$

em que

$$\alpha = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_k \end{bmatrix}.$$

Teorema 3.2 (Independência linear e sistema homogêneo). *As colunas de $\mathbf{A}$ são linearmente independentes se, e somente se, o sistema*

$$\mathbf{A}\alpha = \mathbf{0}$$

possui apenas a solução trivial

$$\alpha = \mathbf{0}.$$

Se $\mathbf{A} \in \mathbb{R}^{p \times k}$, suas colunas são linearmente independentes quando

$$\text{posto}(\mathbf{A}) = k.$$

Consequentemente, não pode haver mais de p vetores linearmente independentes em $\mathbb{R}^p$.

Teorema 3.3 (Propriedades da independência linear). *Sejam $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$.*

1. *Um conjunto que contém o vetor nulo é linearmente dependente.*
2. *Um conjunto formado por um único vetor é linearmente independente se, e somente se, esse vetor é diferente de zero.*
3. *Todo subconjunto de um conjunto linearmente independente também é linearmente independente.*
4. *Todo conjunto que contém um subconjunto linearmente dependente é linearmente dependente.*
5. *Se um vetor do conjunto pode ser escrito como combinação linear dos demais, o conjunto é linearmente dependente.*

A última propriedade fornece uma interpretação direta da redundância.

Teorema 3.4 (Dependência linear e redundância). *O conjunto*

$$\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$$

é linearmente dependente se, e somente se, pelo menos um de seus vetores pode ser escrito como combinação linear dos demais.

Comprovação. Suponha que o conjunto seja linearmente dependente. Então existem coeficientes, não todos nulos, tais que

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}.$$

Escolha um índice j para o qual $\alpha_j \neq 0$. Isolando $\mathbf{v}_j$,

$$\mathbf{v}_j = - \sum_{i \neq j} \frac{\alpha_i}{\alpha_j} \mathbf{v}_i.$$

Portanto, $\mathbf{v}_j$ é combinação linear dos demais.

Reciprocamente, se um vetor é combinação linear dos demais, essa igualdade pode ser reorganizada como uma combinação linear não trivial que produz o vetor nulo. Logo, o conjunto é linearmente dependente. $\square$

A independência linear permite retirar vetores redundantes sem alterar o subespaço gerado. Um conjunto gerador sem redundâncias fornece uma base do subespaço.

3.2.3 Bases

Um conjunto gerador pode conter vetores redundantes. Quando os vetores geram o espaço e são linearmente independentes, obtém-se uma base.

Definição 3.5 (Base). Seja V um espaço vetorial. Um conjunto

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k\}$$

é uma **base** de V quando:

1. os vetores $\mathbf{b}_1, \dots, \mathbf{b}_k$ são linearmente independentes;
2. os vetores geram V , isto é,

$$\text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_k\} = V.$$

Uma base fornece um conjunto de vetores suficiente para gerar o espaço sem incluir redundâncias.

Exemplo 3.7 (Exemplo: Uma base de $\mathbb{R}^2$). Considere

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Os vetores são linearmente independentes e geram $\mathbb{R}^2$. Portanto,

$$\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2\}$$

é uma base de $\mathbb{R}^2$.

Um mesmo espaço possui diferentes bases.

Exemplo 3.8 (Exemplo: Bases diferentes do mesmo espaço). Os conjuntos

$$\mathcal{B}_1 = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$$

e

$$\mathcal{B}_2 = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

são bases de $\mathbb{R}^2$.

Os vetores de cada conjunto são linearmente independentes e geram todo o espaço.

3.2.4 Coordenadas em uma base

Uma base permite representar cada vetor por meio dos coeficientes de sua combinação linear.

Teorema 3.5 (Representação única em uma base). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ pode ser escrito de maneira única como

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Comprovação. Como $\mathcal{B}$ gera V , existem escalares $c_1, \dots, c_k$ tais que

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Suponha que também exista outra representação:

$$\mathbf{x} = d_1 \mathbf{b}_1 + \dots + d_k \mathbf{b}_k.$$

Subtraindo as duas expressões,

$$(c_1 - d_1) \mathbf{b}_1 + \dots + (c_k - d_k) \mathbf{b}_k = \mathbf{0}.$$

Como os vetores da base são linearmente independentes,

$$c_i - d_i = 0, \quad i = 1, \dots, k.$$

Portanto,

$$c_i = d_i, \quad i = 1, \dots, k,$$

e a representação é única. □

Definição 3.6 (Coordenadas em uma base). Se

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k,$$

o vetor

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_k \end{bmatrix}$$

é o **vetor de coordenadas de $\mathbf{x}$** na base $\mathcal{B}$.

Considere a matriz formada pelos vetores da base:

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k].$$

A representação de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{B}[\mathbf{x}]_{\mathcal{B}}.$$

Exemplo 3.9 (Exemplo: Coordenadas de um vetor). Considere a base

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$$

e o vetor

$$\mathbf{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Deseja-se determinar c_1 e c_2 tais que

$$\begin{bmatrix} 4 \\ 2 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Isso produz o sistema

$$\begin{aligned} c_1 + c_2 &= 4, \\ c_1 - c_2 &= 2. \end{aligned}$$

Somando as equações,

$$2c_1 = 6,$$

de modo que

$$c_1 = 3.$$

Consequentemente,

$$c_2 = 1.$$

Logo,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

As coordenadas dependem da base escolhida. O vetor permanece o mesmo, mas os coeficientes que o representam podem mudar.

3.2.5 Base canônica

Definição 3.7 (Base canônica). A **base canônica** de $\mathbb{R}^p$ é

$$\mathcal{E} = \{\mathbf{e}_1, \dots, \mathbf{e}_p\},$$

em que $\mathbf{e}_j$ possui valor 1 na posição j e valor 0 nas demais posições.

Em $\mathbb{R}^3$,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix},$$

tem-se

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3.$$

Assim, as coordenadas de $\mathbf{x}$ na base canônica coincidem com suas componentes usuais.

3.2.6 Bases ortogonais e ortonormais

Definição 3.8 (Base ortogonal). Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é **ortogonal** quando

$$\mathbf{b}_i^\top \mathbf{b}_j = 0 \quad \text{para} \quad i \neq j.$$

Definição 3.9 (Base ortonormal). Uma base é **ortonormal** quando seus vetores são ortogonais e possuem norma igual a 1:

$$\mathbf{b}_i^\top \mathbf{b}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Utilizando o delta de Kronecker,

$$\mathbf{b}_i^\top \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{Q} = [\mathbf{b}_1 \quad \dots \quad \mathbf{b}_k]$$

possui como colunas os vetores de uma base ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Quando $\mathbf{Q}$ é quadrada,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Essa propriedade foi apresentada no capítulo anterior para matrizes ortogonais.

Teorema 3.6 (Existência de bases ortonormais). *Todo subespaço de dimensão finita de $\mathbb{R}^p$ possui uma base ortonormal.*

A partir de qualquer base do subespaço, uma base ortonormal pode ser construída pelo processo de ortogonalização de Gram–Schmidt.

Esse resultado garante que a geometria de um subespaço de dimensão finita pode ser descrita por direções mutuamente ortogonais e de norma unitária.

Em uma base ortogonal, os coeficientes da representação de um vetor podem ser determinados separadamente.

Teorema 3.7 (Coordenadas em uma base ortogonal). *Se*

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base ortogonal de V , então, para qualquer $\mathbf{x} \in V$,

$$\mathbf{x} = \sum_{j=1}^k \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j} \mathbf{b}_j.$$

Se a base é ortonormal,

$$\mathbf{x} = \sum_{j=1}^k (\mathbf{b}_j^\top \mathbf{x}) \mathbf{b}_j.$$

Comprovação. Escreva

$$\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_k \mathbf{b}_k.$$

Multiplicando ambos os lados por $\mathbf{b}_j^\top$,

$$\mathbf{b}_j^\top \mathbf{x} = \sum_{i=1}^k c_i \mathbf{b}_j^\top \mathbf{b}_i.$$

Como a base é ortogonal, todos os termos com $i \neq j$ são nulos. Assim,

$$\mathbf{b}_j^\top \mathbf{x} = c_j \mathbf{b}_j^\top \mathbf{b}_j,$$

e

$$c_j = \frac{\mathbf{b}_j^\top \mathbf{x}}{\mathbf{b}_j^\top \mathbf{b}_j}.$$

Quando a base é ortonormal,

$$\mathbf{b}_j^\top \mathbf{b}_j = 1.$$

□

A Figura 3.3 compara diferentes bases de $\mathbb{R}^2$.




Figura 3.3: Comparação entre a base canônica, uma base oblíqua e uma base ortonormal rotacionada de $\mathbb{R}^2$.

A base canônica e a base rotacionada são ortonormais. Na base oblíqua, os vetores são linearmente independentes, mas não são ortogonais.

3.2.7 Dimensão

Definição 3.10 (Dimensão). Se um espaço vetorial V possui uma base com k vetores, sua **dimensão** é

$$\dim(V) = k.$$

Todas as bases de um espaço vetorial de dimensão finita possuem o mesmo número de vetores.

Teorema 3.8 (Número de vetores de uma base). *Se V é um espaço vetorial de dimensão finita, todas as bases de V possuem a mesma quantidade de vetores.*

Como a base canônica de $\mathbb{R}^p$ possui p vetores,

$$\dim(\mathbb{R}^p) = p.$$

Exemplo 3.10 (Exemplo: Dimensão de subespaços). A reta

$$W_1 = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 1.

O plano

$$W_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3$$

possui dimensão 2.

O espaço $\mathbb{R}^3$ possui dimensão 3.

Teorema 3.9 (Independência, geração e dimensão). *Se $\dim(V) = k$, então:*

1. *qualquer conjunto com mais de k vetores é linearmente dependente;*
2. *qualquer conjunto com menos de k vetores não gera V ;*
3. *qualquer conjunto de k vetores linearmente independentes é uma base de V ;*
4. *qualquer conjunto de k vetores que gera V é uma base de V .*

Esses resultados relacionam bases, independência e geração. Para uma matriz, essa relação será expressa pelas dimensões de seus espaços coluna, linha e nulo.

3.3 Espaços fundamentais de uma matriz

Uma matriz determina subespaços associados às suas colunas, linhas e soluções de sistemas homogêneos. Esses subespaços descrevem as direções que podem ser produzidas pela matriz e as direções que são anuladas por sua ação.

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

A matriz define a aplicação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^n, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{Ax}.$$

O estudo geral das transformações lineares será desenvolvido no capítulo seguinte. Nesta seção, essa aplicação será utilizada para definir o espaço nulo e a imagem de uma matriz.

3.3.1 Espaço nulo

Definição 3.11 (Espaço nulo). O **espaço nulo**, também denominado **núcleo**, de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o conjunto

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\}.$$

O espaço nulo reúne todos os vetores do domínio que são enviados ao vetor nulo.

Teorema 3.10 (O espaço nulo é um subespaço). *Para qualquer matriz*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

o conjunto

$$\mathcal{N}(\mathbf{A})$$

é um subespaço de $\mathbb{R}^p$.

Comprovação. O vetor nulo pertence a $\mathcal{N}(\mathbf{A})$, pois

$$\mathbf{A}\mathbf{0} = \mathbf{0}.$$

Se

$$\mathbf{x}, \mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{A}\mathbf{x} = \mathbf{0} \quad \text{e} \quad \mathbf{A}\mathbf{y} = \mathbf{0}.$$

Para quaisquer $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned}\mathbf{A}(\alpha\mathbf{x} + \beta\mathbf{y}) &= \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{A}\mathbf{y} \\ &= \alpha\mathbf{0} + \beta\mathbf{0} \\ &= \mathbf{0}.\end{aligned}$$

Logo,

$$\alpha\mathbf{x} + \beta\mathbf{y} \in \mathcal{N}(\mathbf{A}),$$

e $\mathcal{N}(\mathbf{A})$ é um subespaço. □

A dimensão do espaço nulo é denominada **nulidade** da matriz:

$$\text{nul}(\mathbf{A}) = \dim \mathcal{N}(\mathbf{A}).$$

Exemplo 3.11 (Exemplo: Determinação do espaço nulo). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A})$, resolve-se

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

As duas equações são equivalentes, e o sistema reduz-se a

$$x_1 + 2x_2 - x_3 = 0.$$

Tomando

$$x_2 = s \quad \text{e} \quad x_3 = t,$$

obtém-se

$$x_1 = -2s + t.$$

Portanto,

$$\mathbf{x} = \begin{bmatrix} -2s + t \\ s \\ t \end{bmatrix} = s \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + t \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Os dois vetores são linearmente independentes. Assim,

$$\text{nul}(\mathbf{A}) = 2.$$

Se

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

as colunas de $\mathbf{A}$ são linearmente independentes. Nesse caso, o sistema homogêneo possui apenas a solução trivial.

3.3.2 Espaço coluna e imagem

Definição 3.12 (Espaço coluna). O **espaço coluna** de uma matriz

$$\mathbf{A} = [\mathbf{a}_{.1} \quad \mathbf{a}_{.2} \quad \cdots \quad \mathbf{a}_{.p}] \in \mathbb{R}^{n \times p}$$

é o subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{a}_{.1}, \dots, \mathbf{a}_{.p} \} \subseteq \mathbb{R}^n.$$

O produto matriz-vetor pode ser escrito como

$$\mathbf{A}\mathbf{x} = x_1 \mathbf{a}_{.1} + \cdots + x_p \mathbf{a}_{.p}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Portanto, todo vetor produzido por $\mathbf{A}$ é uma combinação linear de suas colunas.

Definição 3.13 (Imagem da aplicação associada a uma matriz). A **imagem** da aplicação

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^n, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

é o conjunto

$$\text{Im}(T_{\mathbf{A}}) = \{ \mathbf{A}\mathbf{x} : \mathbf{x} \in \mathbb{R}^p \}.$$

Como os vetores $\mathbf{A}\mathbf{x}$ são exatamente as combinações lineares das colunas de $\mathbf{A}$,

$$\text{Im}(T_{\mathbf{A}}) = \mathcal{C}(\mathbf{A}).$$

Assim, o **espaço coluna** descreve a estrutura associada à matriz, enquanto a **imagem** descreve os vetores produzidos pela aplicação $T_{\mathbf{A}}$. Neste caso, os dois conjuntos coincidem.

Teorema 3.11 (Consistência de um sistema linear). *O sistema*

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

possui pelo menos uma solução se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Comprovação. Se o sistema possui uma solução $\mathbf{x}$, então

$$\mathbf{b} = \mathbf{A}\mathbf{x},$$

de modo que $\mathbf{b}$ é uma combinação linear das colunas de $\mathbf{A}$. Portanto,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

existem escalares $x_1, \dots, x_p$ tais que

$$\mathbf{b} = x_1 \mathbf{a}_1 + \dots + x_p \mathbf{a}_p.$$

Definindo

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p,$$

obtem-se

$$\mathbf{A}\mathbf{x} = \mathbf{b}.$$

□

Exemplo 3.12 (Exemplo: Determinação do espaço coluna). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \quad \mathbf{a}_3 = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1$$

e

$$\mathbf{a}_3 = -\mathbf{a}_1,$$

tem-se

$$\mathcal{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{C}(\mathbf{A}) = 1.$$

A dimensão do espaço coluna é igual ao posto da matriz:

$$\dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Uma base do espaço coluna deve ser formada por colunas da matriz original. As posições das colunas pivô podem ser identificadas por escalonamento, mas os vetores da base são retirados de $\mathbf{A}$, e não da matriz escalonada.

3.3.3 Espaço linha

Definição 3.14 (Espaço linha). O **espaço linha** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é o subespaço de $\mathbb{R}^p$ gerado por suas linhas.

Escrevendo as linhas de $\mathbf{A}$ como

$$\mathbf{a}_1^\top, \mathbf{a}_2^\top, \dots, \mathbf{a}_n^\top,$$

o espaço linha pode ser representado por

$$\mathcal{L}(\mathbf{A}) = \text{span} \{ \mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \} \subseteq \mathbb{R}^p.$$

Equivalentemente, como as linhas de $\mathbf{A}$ são as colunas de $\mathbf{A}^\top$,

$$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top).$$

O espaço linha e o espaço coluna possuem a mesma dimensão:

$$\dim \mathcal{L}(\mathbf{A}) = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Essa igualdade permite interpretar o posto tanto como o número máximo de colunas linearmente independentes quanto como o número máximo de linhas linearmente independentes.

Exemplo 3.13 (Exemplo: Determinação do espaço linha). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

As linhas de $\mathbf{A}$ são

$$\mathbf{a}_1^\top = [1 \quad 2 \quad -1]$$

e

$$\mathbf{a}_2^\top = [2 \quad 4 \quad -2].$$

Os vetores-coluna associados a essas linhas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad \text{e} \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix}.$$

Como

$$\mathbf{a}_2 = 2\mathbf{a}_1,$$

tem-se

$$\mathcal{L}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{L}(\mathbf{A}) = 1.$$

As linhas não nulas de uma forma escalonada de $\mathbf{A}$ formam uma base de $\mathcal{L}(\mathbf{A})$. Diferentemente do espaço coluna, pode-se utilizar diretamente as linhas da matriz escalonada, pois as operações elementares por linhas preservam o espaço linha.

3.3.4 Espaço nulo à esquerda

3.3.5 Espaço nulo à esquerda

Definição 3.15 (Espaço nulo à esquerda). O **espaço nulo à esquerda** de

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

é definido por

$$\mathcal{N}(\mathbf{A}^\top) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{A}^\top \mathbf{y} = \mathbf{0}\}.$$

Um vetor $\mathbf{y}$ pertence a $\mathcal{N}(\mathbf{A}^\top)$ quando é ortogonal a todas as colunas de $\mathbf{A}$. De fato,

$$\mathbf{A}^\top \mathbf{y} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{y} \\ \mathbf{a}_2^\top \mathbf{y} \\ \vdots \\ \mathbf{a}_p^\top \mathbf{y} \end{bmatrix}.$$

Assim,

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

se, e somente se,

$$\mathbf{a}_j^\top \mathbf{y} = 0, \quad j = 1, \dots, p.$$

Portanto,

$$\mathcal{N}(\mathbf{A}^\top) \subseteq \mathbb{R}^n$$

é o conjunto das direções ortogonais ao espaço coluna de $\mathbf{A}$.

Exemplo 3.14 (Exemplo: Determinação do espaço nulo à esquerda). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix}.$$

Para determinar $\mathcal{N}(\mathbf{A}^\top)$, resolve-se

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}.$$

Assim,

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O sistema reduz-se a

$$y_1 + 2y_2 = 0.$$

Tomando

$$y_2 = t,$$

obtém-se

$$y_1 = -2t.$$

Portanto,

$$\mathbf{y} = t \begin{bmatrix} -2 \\ 1 \end{bmatrix},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

3.3.6 Teorema Posto–Nulidade

As dimensões do espaço nulo e do espaço coluna estão relacionadas ao número de colunas da matriz.

Teorema 3.12 (Teorema Posto–Nulidade). *Se*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

então

$$\text{posto}(\mathbf{A}) + \text{nul}(\mathbf{A}) = p.$$

(Meyer, 2023)

Comprovação. Uma base de um subespaço de dimensão finita pode ser completada para formar uma base do espaço que o contém.

Considere uma base do espaço nulo,

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s\},$$

em que

$$s = \dim \mathcal{N}(\mathbf{A}).$$

Complete esse conjunto para obter uma base de $\mathbb{R}^p$:

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como essa base possui p vetores,

$$s + r = p.$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma representação da forma

$$\mathbf{x} = \sum_{i=1}^s \alpha_i \mathbf{v}_i + \sum_{j=1}^r \beta_j \mathbf{w}_j.$$

Como

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad i = 1, \dots, s,$$

tem-se

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j.$$

Portanto,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

geram $\mathcal{C}(\mathbf{A})$.

Para verificar a independência linear, suponha que

$$\sum_{j=1}^r \beta_j \mathbf{A}\mathbf{w}_j = \mathbf{0}.$$

Então,

$$\mathbf{A} \left(\sum_{j=1}^r \beta_j \mathbf{w}_j \right) = \mathbf{0},$$

de modo que

$$\sum_{j=1}^r \beta_j \mathbf{w}_j \in \mathcal{N}(\mathbf{A}).$$

Esse vetor também pertence a

$$\text{span}\{\mathbf{w}_1, \dots, \mathbf{w}_r\}.$$

Como

$$\{\mathbf{v}_1, \dots, \mathbf{v}_s, \mathbf{w}_1, \dots, \mathbf{w}_r\}$$

é uma base de $\mathbb{R}^p$, a interseção entre esses dois subespaços contém somente o vetor nulo. Assim,

$$\beta_1 = \dots = \beta_r = 0.$$

Logo,

$$\mathbf{A}\mathbf{w}_1, \dots, \mathbf{A}\mathbf{w}_r$$

formam uma base de $\mathcal{C}(\mathbf{A})$. Portanto,

$$r = \dim \mathcal{C}(\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Logo,

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}) = p.$$

□

Aplicando o teorema a $\mathbf{A}^\top$,

$$\text{posto}(\mathbf{A}^\top) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Como

$$\text{posto}(\mathbf{A}^\top) = \text{posto}(\mathbf{A}),$$

obtém-se

$$\text{posto}(\mathbf{A}) + \dim \mathcal{N}(\mathbf{A}^\top) = n.$$

Para o exemplo utilizado nesta seção,

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \end{bmatrix},$$

tem-se

$$\text{posto}(\mathbf{A}) = 1,$$

$$\dim \mathcal{N}(\mathbf{A}) = 2$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = 1.$$

Portanto,

$$1 + 2 = 3$$

e

$$1 + 1 = 2,$$

de acordo com as dimensões do domínio e do contradomínio.

3.3.7 Os quatro espaços fundamentais

Os quatro subespaços associados a

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

são:

Tabela 3.1: Espaços fundamentais de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ com posto r .

Espaço	Definição	Subespaço de	Dimen- são
Espaço coluna	$\mathcal{C}(\mathbf{A})$	$\mathbb{R}^n$	r
Espaço linha	$\mathcal{L}(\mathbf{A}) = \mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	r
Espaço nulo	$\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	$p - r$
Espaço nulo à esquerda	$\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^n$	$n - r$

A Tabela 3.1 mostra que os espaços coluna e nulo à esquerda pertencem ao contradomínio $\mathbb{R}^n$, enquanto os espaços linha e nulo pertencem ao domínio $\mathbb{R}^p$.

3.3.8 Complemento ortogonal

Definição 3.16 (Complemento ortogonal). Seja S um subespaço de $\mathbb{R}^p$. O **complemento ortogonal** de S é

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

O complemento ortogonal reúne todos os vetores de $\mathbb{R}^p$ que são ortogonais a cada vetor de S . Essa definição permite descrever relações importantes entre os quatro espaços fundamentais de uma matriz.

3.3.9 Relações de ortogonalidade

Teorema 3.13 (Ortogonalidade entre os espaços fundamentais). *Para*

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

tem-se

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então

$$\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Cada componente de $\mathbf{A}\mathbf{x}$ é o produto interno entre uma linha de $\mathbf{A}$ e $\mathbf{x}$. Portanto, $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$ e, conseqüentemente, a todo vetor de $\mathcal{L}(\mathbf{A})$. Logo,

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Assim,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{L}(\mathbf{A})^\perp.$$

Reciprocamente, suponha que

$$\mathbf{x} \in \mathcal{L}(\mathbf{A})^\perp.$$

Então $\mathbf{x}$ é ortogonal a todas as linhas de $\mathbf{A}$. Cada componente de $\mathbf{Ax}$ é, portanto, igual a zero, de modo que

$$\mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

e

$$\mathcal{L}(\mathbf{A})^\perp \subseteq \mathcal{N}(\mathbf{A}).$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp.$$

De forma análoga, para

$$\mathbf{y} \in \mathbb{R}^n,$$

a condição

$$\mathbf{A}^\top \mathbf{y} = \mathbf{0}$$

equivale a $\mathbf{y}$ ser ortogonal a todas as colunas de $\mathbf{A}$. Portanto,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

□

Essas relações mostram que os espaços fundamentais se organizam em dois pares ortogonais:

$$\mathcal{L}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A})$$

no domínio $\mathbb{R}^p$, e

$$\mathcal{C}(\mathbf{A}) \perp \mathcal{N}(\mathbf{A}^\top)$$

no contradomínio $\mathbb{R}^n$.

A decomposição dos espaços ambientes em somas diretas desses pares será obtida posteriormente a partir do resultado geral sobre complementos ortogonais.

3.4 Produtos internos, bases ortonormais e matrizes de Gram

O produto interno euclidiano

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$$

define comprimentos, ângulos e ortogonalidade em $\mathbb{R}^p$. Essas noções podem ser modificadas atribuindo pesos e relações diferentes às coordenadas.

3.4.1 Produtos internos induzidos por matrizes

Considere uma matriz simétrica positiva definida

$$\mathbf{M} \in \mathbb{R}^{p \times p}.$$

Definição 3.17 (Produto interno induzido por uma matriz). O **produto interno induzido por $\mathbf{M}$** é definido por

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{R}^p.$$

A simetria de $\mathbf{M}$ garante que

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

pois

$$\mathbf{x}^\top \mathbf{M} \mathbf{y} = (\mathbf{x}^\top \mathbf{M} \mathbf{y})^\top = \mathbf{y}^\top \mathbf{M}^\top \mathbf{x} = \mathbf{y}^\top \mathbf{M} \mathbf{x}.$$

A definição positiva garante que

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Teorema 3.14 (Propriedades do produto interno induzido). *Para quaisquer*

$$\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^p$$

e $\alpha, \beta \in \mathbb{R}$,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathbf{M}},$$

$$\langle \alpha \mathbf{x} + \beta \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}} = \alpha \langle \mathbf{x}, \mathbf{z} \rangle_{\mathbf{M}} + \beta \langle \mathbf{y}, \mathbf{z} \rangle_{\mathbf{M}},$$

e

$$\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}} > 0 \quad \text{para} \quad \mathbf{x} \neq \mathbf{0}.$$

(Horn; Johnson, 2013)

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o produto interno euclidiano:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{I}_p} = \mathbf{x}^\top \mathbf{y}.$$

Exemplo 3.15 (Cálculo de um produto interno induzido). Considere

$$\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e

$$\mathbf{y} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Então,

$$\mathbf{M}\mathbf{y} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

Logo,

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3.$$

O produto interno euclidiano entre os mesmos vetores é

$$\mathbf{x}^{\top} \mathbf{y} = 1(2) + 2(-1) = 0.$$

Portanto, os vetores são ortogonais segundo o produto interno euclidiano, mas não segundo o produto interno induzido por $\mathbf{M}$.

3.4.2 Norma e distância induzidas

Definição 3.18 (Norma induzida). A norma associada ao produto interno induzido por $\mathbf{M}$ é

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbf{M}}} = \sqrt{\mathbf{x}^{\top} \mathbf{M} \mathbf{x}}.$$

A distância associada é

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_{\mathbf{M}},$$

ou, equivalentemente,

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^{\top} \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

Quando $\mathbf{M} = \mathbf{I}_p$, obtêm-se a norma e a distância euclidianas.

Exemplo 3.16 (Norma e distância induzidas). Considere

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\| = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

A norma induzida por $\mathbf{M}$ é

$$\begin{aligned} \|\mathbf{x}\|_{\mathbf{M}} &= \sqrt{\begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} \\ &= \sqrt{8}. \end{aligned}$$

A segunda coordenada recebe peso maior na geometria definida por $\mathbf{M}$.

3.4.3 Ortogonalidade induzida

Dois vetores $\mathbf{x}$ e $\mathbf{y}$ são ortogonais segundo $\mathbf{M}$ quando

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^{\top} \mathbf{M} \mathbf{y} = 0.$$

Uma base

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é $\mathbf{M}$ -ortonormal quando

$$\mathbf{b}_i^{\top} \mathbf{M} \mathbf{b}_j = \delta_{ij}.$$

Se

$$\mathbf{B} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_k],$$

essa condição pode ser escrita como

$$\mathbf{B}^\top \mathbf{M} \mathbf{B} = \mathbf{I}_k.$$

3.4.4 Interpretação por transformação de coordenadas

Como $\mathbf{M}$ é simétrica positiva definida, existe uma matriz invertível $\mathbf{C}$ tal que

$$\mathbf{M} = \mathbf{C}^\top \mathbf{C}.$$

Assim,

$$\begin{aligned} \langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} &= \mathbf{x}^\top \mathbf{C}^\top \mathbf{C} \mathbf{y} \\ &= (\mathbf{C} \mathbf{x})^\top (\mathbf{C} \mathbf{y}). \end{aligned}$$

O produto interno induzido por $\mathbf{M}$ equivale ao produto interno euclidiano aplicado aos vetores transformados

$$\mathbf{C} \mathbf{x} \quad \text{e} \quad \mathbf{C} \mathbf{y}.$$

Da mesma forma,

$$\|\mathbf{x}\|_{\mathbf{M}} = \|\mathbf{C} \mathbf{x}\|.$$

As curvas de nível

$$\|\mathbf{x}\|_{\mathbf{M}} = 1$$

satisfazem

$$\mathbf{x}^\top \mathbf{M} \mathbf{x} = 1.$$

Na geometria euclidiana, essas curvas são circunferências quando $\mathbf{M} = \mathbf{I}_2$ e elipses para outras matrizes positivas definidas.

A Figura 3.4 compara três geometrias em $\mathbb{R}^2$.




Figura 3.4: Curvas de norma unitária para diferentes produtos internos em $\mathbb{R}^2$.

A matriz identidade produz a circunferência euclidiana. Uma matriz diagonal com pesos distintos produz uma elipse alinhada aos eixos coordenados. Elementos fora da diagonal podem alterar a orientação da elipse.

Matrizes semidefinidas positivas

Se $\mathbf{M}$ é apenas semidefinida positiva, a expressão

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^T \mathbf{M} \mathbf{x}}$$

pode ser igual a zero para algum vetor $\mathbf{x} \neq \mathbf{0}$.

Nesse caso, a expressão define uma **seminorma**, e não uma norma.

Os produtos internos entre vários vetores podem ser organizados em uma matriz de Gram.

3.4.5 Matrizes de Gram

Os produtos internos entre um conjunto de vetores podem ser organizados em uma matriz.

Definição 3.19 (Matriz de Gram). Sejam

$$\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^p$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k] \in \mathbb{R}^{p \times k}.$$

A **matriz de Gram** dos vetores é

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}.$$

Seu elemento na posição (i, j) é

$$g_{ij} = \mathbf{v}_i^\top \mathbf{v}_j.$$

A diagonal de $\mathbf{G}$ contém os quadrados das normas:

$$g_{ii} = \mathbf{v}_i^\top \mathbf{v}_i = \|\mathbf{v}_i\|^2.$$

Os elementos fora da diagonal contêm os produtos internos entre vetores distintos.

Quando $\mathbf{v}_i$ e $\mathbf{v}_j$ são não nulos,

$$g_{ij} = \|\mathbf{v}_i\| \|\mathbf{v}_j\| \cos(\theta_{ij}).$$

Portanto, o produto interno depende tanto das normas quanto do ângulo entre os vetores.

Exemplo 3.17 (Exemplo: Construção de uma matriz de Gram). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

e

$$\mathbf{V} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

A matriz de Gram é

$$\begin{aligned} \mathbf{G} &= \mathbf{V}^\top \mathbf{V} \\ &= \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais são

$$\|\mathbf{v}_1\|^2 = \|\mathbf{v}_2\|^2 = 2,$$

e o elemento fora da diagonal é

$$\mathbf{v}_1^\top \mathbf{v}_2 = 1.$$

3.4.6 Propriedades da matriz de Gram

Teorema 3.15 (Propriedades da matriz de Gram). *Para*

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V},$$

tem-se:

1. $\mathbf{G}$ é simétrica;
2. $\mathbf{G}$ é semidefinida positiva;
3. $\mathbf{G}$ é positiva definida se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes;
4. $\text{posto}(\mathbf{G}) = \text{posto}(\mathbf{V})$. (*Horn; Johnson, 2013*)

Comprovação. A simetria decorre de

$$\mathbf{G}^\top = (\mathbf{V}^\top \mathbf{V})^\top = \mathbf{V}^\top \mathbf{V} = \mathbf{G}.$$

Para qualquer $\mathbf{c} \in \mathbb{R}^k$,

$$\begin{aligned} \mathbf{c}^\top \mathbf{G} \mathbf{c} &= \mathbf{c}^\top \mathbf{V}^\top \mathbf{V} \mathbf{c} \\ &= (\mathbf{V} \mathbf{c})^\top (\mathbf{V} \mathbf{c}) \\ &= \|\mathbf{V} \mathbf{c}\|^2 \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{G}$ é semidefinida positiva.

A forma quadrática é igual a zero quando

$$\mathbf{V} \mathbf{c} = \mathbf{0}.$$

Assim, $\mathbf{G}$ é positiva definida se, e somente se, o sistema homogêneo

$$\mathbf{V}\mathbf{c} = \mathbf{0}$$

possui apenas a solução trivial, o que equivale à independência linear das colunas de $\mathbf{V}$. Além disso,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}),$$

pois

$$\mathbf{V}^\top \mathbf{V}\mathbf{c} = \mathbf{0}$$

implica

$$\mathbf{c}^\top \mathbf{V}^\top \mathbf{V}\mathbf{c} = \|\mathbf{V}\mathbf{c}\|^2 = 0.$$

As duas matrizes possuem, portanto, a mesma nulidade. Pelo Teorema Posto–Nulidade,

$$\text{posto}(\mathbf{V}^\top \mathbf{V}) = \text{posto}(\mathbf{V}).$$

Reciprocamente, se

$$\mathbf{V}\mathbf{c} = \mathbf{0},$$

então

$$\mathbf{V}^\top \mathbf{V}\mathbf{c} = \mathbf{V}^\top \mathbf{0} = \mathbf{0}.$$

Portanto,

$$\mathcal{N}(\mathbf{V}^\top \mathbf{V}) = \mathcal{N}(\mathbf{V}).$$

□

Uma consequência é:

$$\det(\mathbf{V}^\top \mathbf{V}) > 0$$

se, e somente se, as colunas de $\mathbf{V}$ são linearmente independentes.

Quando as colunas são dependentes,

$$\det(\mathbf{V}^\top \mathbf{V}) = 0.$$

3.4.7 Matrizes de Gram e bases ortonormais

Se as colunas de $\mathbf{Q}$ formam um conjunto ortonormal, então

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Portanto, a matriz de Gram de um conjunto ortonormal é a matriz identidade.

Para uma base ortogonal não normalizada,

$$\mathbf{V}^\top \mathbf{V} = \text{diag}(\|\mathbf{v}_1\|^2, \dots, \|\mathbf{v}_k\|^2).$$

Exemplo 3.18 (Exemplo: Matriz de Gram de uma base ortogonal). Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0,$$

os vetores são ortogonais.

A matriz de Gram é

$$\mathbf{G} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Normalizando os vetores,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_2.$$

3.4.8 Produtos cruzados em uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}.$$

O produto

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de Gram das colunas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X}^\top \mathbf{X})_{jk} = \sum_{i=1}^n x_{ij} x_{ik}.$$

Assim:

- os elementos diagonais são somas de quadrados das variáveis;
- os elementos fora da diagonal são produtos cruzados entre pares de variáveis.

O produto

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram das linhas de $\mathbf{X}$. Seus elementos são

$$(\mathbf{X} \mathbf{X}^\top)_{ij} = \mathbf{x}_i^\top \mathbf{x}_j,$$

em que $\mathbf{x}_i^\top$ e $\mathbf{x}_j^\top$ representam duas observações.

A Tabela [3.2](#) resume as duas construções.

Tabela 3.2: Produtos de Gram associados a uma matriz de dados.

Produto	Dimensão	Vetores comparados	Elemento genérico
$\mathbf{X}^\top \mathbf{X}$	$p \times p$	Colunas ou variáveis	$\sum_{i=1}^n x_{ij}x_{ik}$
$\mathbf{X}\mathbf{X}^\top$	$n \times n$	Linhas ou observações	$\mathbf{x}_i^\top \mathbf{x}_j$

Quando as colunas da matriz de dados estão centradas, $\mathbf{X}^\top \mathbf{X}$ reúne as somas de quadrados e produtos cruzados utilizadas na construção da matriz de covariâncias. Essa relação será retomada no capítulo sobre covariâncias e correlações.

As matrizes de Gram também aparecem na construção da projeção de um vetor sobre o espaço gerado pelas colunas de uma matriz.

3.4.9 Propriedades do complemento ortogonal

O complemento ortogonal, introduzido anteriormente na descrição dos espaços fundamentais de uma matriz, será agora estudado para um subespaço arbitrário de $\mathbb{R}^p$.

Se

$$S = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_k\},$$

então basta verificar a ortogonalidade em relação aos vetores geradores:

$$S^\perp = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{s}_j^\top \mathbf{x} = 0, \quad j = 1, \dots, k\}.$$

Isso ocorre porque todo vetor de S é uma combinação linear dos vetores $\mathbf{s}_1, \dots, \mathbf{s}_k$. Portanto, um vetor ortogonal a todos os geradores é ortogonal a todo o subespaço.

Teorema 3.16 (O complemento ortogonal é um subespaço). *Se S é um subespaço de $\mathbb{R}^p$, então $S^\perp$ também é um subespaço de $\mathbb{R}^p$.*

Comprovação. O vetor nulo pertence a $S^\perp$, pois

$$\mathbf{0}^\top \mathbf{s} = 0$$

para todo $\mathbf{s} \in S$.

Se

$$\mathbf{x}, \mathbf{y} \in S^\perp,$$

então, para quaisquer $\alpha, \beta \in \mathbb{R}$ e $\mathbf{s} \in S$,

$$\begin{aligned} (\alpha \mathbf{x} + \beta \mathbf{y})^\top \mathbf{s} &= \alpha \mathbf{x}^\top \mathbf{s} + \beta \mathbf{y}^\top \mathbf{s} \\ &= 0. \end{aligned}$$

Portanto,

$$\alpha \mathbf{x} + \beta \mathbf{y} \in S^\perp,$$

e $S^\perp$ é um subespaço de $\mathbb{R}^p$. □

Exemplo 3.19 (Exemplo: Complemento ortogonal de uma reta). Considere

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \subseteq \mathbb{R}^2.$$

Um vetor

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

pertence a $S^\perp$ quando

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Assim,

$$x_1 + 2x_2 = 0.$$

Tomando $x_2 = t$, obtém-se

$$x_1 = -2t.$$

Logo,

$$S^\perp = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

3.4.10 Dimensão do complemento ortogonal

Teorema 3.17 (Dimensão do complemento ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então*

$$\dim(S) + \dim(S^\perp) = p.$$

Comprovação. Seja

$$\dim(S) = k.$$

Pelo Teorema 3.6, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Esse conjunto pode ser completado para uma base de $\mathbb{R}^p$. Aplicando o processo de Gram-Schmidt aos vetores adicionais, preservando os primeiros k vetores, obtém-se uma base ortonormal de $\mathbb{R}^p$:

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}.$$

Como a base é ortonormal,

$$\mathbf{q}_i^\top \mathbf{q}_j = 0, \quad i = 1, \dots, k, \quad j = k+1, \dots, p.$$

Portanto,

$$\mathbf{q}_{k+1}, \dots, \mathbf{q}_p \in S^\perp.$$

Além disso, esses vetores geram $S^\perp$. De fato, para qualquer

$$\mathbf{x} \in S^\perp,$$

como a coleção completa é uma base de $\mathbb{R}^p$, pode-se escrever

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{q}_j.$$

Para $i = 1, \dots, k$,

$$\mathbf{q}_i^\top \mathbf{x} = \alpha_i.$$

Como $\mathbf{x} \in S^\perp$,

$$\mathbf{q}_i^\top \mathbf{x} = 0,$$

e, portanto,

$$\alpha_i = 0, \quad i = 1, \dots, k.$$

Logo,

$$\mathbf{x} = \sum_{j=k+1}^p \alpha_j \mathbf{q}_j,$$

de modo que

$$\{\mathbf{q}_{k+1}, \dots, \mathbf{q}_p\}$$

é uma base de $S^\perp$.

Assim,

$$\dim(S^\perp) = p - k,$$

e, como $\dim(S) = k$,

$$\dim(S) + \dim(S^\perp) = p.$$

□

Consequentemente, se

$$\dim(S) = k,$$

então

$$\dim(S^\perp) = p - k.$$

Além disso,

$$S \cap S^\perp = \{\mathbf{0}\}.$$

De fato, se

$$\mathbf{x} \in S \cap S^\perp,$$

então $\mathbf{x}$ é ortogonal a todos os vetores de S , inclusive a si próprio. Portanto,

$$\mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 0,$$

o que implica

$$\mathbf{x} = \mathbf{0}.$$

Outra consequência importante é

$$(S^\perp)^\perp = S.$$

De fato,

$$S \subseteq (S^\perp)^\perp,$$

pois todo vetor de S é ortogonal a todos os vetores de $S^\perp$. Além disso,

$$\begin{aligned} \dim\left((S^\perp)^\perp\right) &= p - \dim(S^\perp) \\ &= p - (p - k) \\ &= k \\ &= \dim(S). \end{aligned}$$

Como um subespaço está contido no outro e ambos possuem a mesma dimensão,

$$(S^\perp)^\perp = S.$$

3.4.11 Decomposição ortogonal

Teorema 3.18 (Decomposição ortogonal). *Se S é um subespaço de $\mathbb{R}^p$, então todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como*

$$\mathbf{x} = \mathbf{x}_S + \mathbf{x}_{S^\perp},$$

em que

$$\mathbf{x}_S \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Equivalentemente,

$$\mathbb{R}^p = S \oplus S^\perp.$$

Comprovação. Pelo Teorema 3.6, existe uma base ortonormal

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

de S .

Defina

$$\mathbf{x}_S = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j$$

e

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S.$$

Por construção,

$$\mathbf{x}_S \in S.$$

Para cada $i = 1, \dots, k$,

$$\begin{aligned}
\mathbf{q}_i^\top \mathbf{x}_{S^\perp} &= \mathbf{q}_i^\top \mathbf{x} - \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_i^\top \mathbf{q}_j \\
&= \mathbf{q}_i^\top \mathbf{x} - \mathbf{q}_i^\top \mathbf{x} \\
&= 0.
\end{aligned}$$

Logo,

$$\mathbf{x}_{S^\perp} \in S^\perp,$$

o que demonstra a existência da decomposição.

Para demonstrar a unicidade, suponha que

$$\mathbf{x} = \mathbf{s}_1 + \mathbf{r}_1 = \mathbf{s}_2 + \mathbf{r}_2,$$

com

$$\mathbf{s}_1, \mathbf{s}_2 \in S$$

e

$$\mathbf{r}_1, \mathbf{r}_2 \in S^\perp.$$

Então,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{r}_2 - \mathbf{r}_1.$$

O lado esquerdo pertence a S , enquanto o lado direito pertence a $S^\perp$. Portanto, esse vetor pertence a

$$S \cap S^\perp = \{\mathbf{0}\}.$$

Assim,

$$\mathbf{s}_1 - \mathbf{s}_2 = \mathbf{0}$$

e

$$\mathbf{r}_2 - \mathbf{r}_1 = \mathbf{0}.$$

Logo,

$$\mathbf{s}_1 = \mathbf{s}_2 \quad \text{e} \quad \mathbf{r}_1 = \mathbf{r}_2.$$

Portanto, a decomposição é única. □

A componente $\mathbf{x}_S$ é a projeção ortogonal de $\mathbf{x}$ sobre S , enquanto

$$\mathbf{x}_{S^\perp} = \mathbf{x} - \mathbf{x}_S$$

é a componente ortogonal a S .

3.4.12 Decomposição dos espaços fundamentais

O resultado geral pode agora ser aplicado aos espaços fundamentais de uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}.$$

Como

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp,$$

o Teorema 3.18 fornece

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}).$$

Portanto, todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito de maneira única como

$$\mathbf{x} = \mathbf{x}_{\mathcal{L}} + \mathbf{x}_{\mathcal{N}},$$

em que

$$\mathbf{x}_{\mathcal{L}} \in \mathcal{L}(\mathbf{A})$$

e

$$\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}).$$

De modo análogo, como

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp,$$

tem-se

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

Assim, todo vetor $\mathbf{y} \in \mathbb{R}^n$ admite uma decomposição única em uma componente pertencente ao espaço coluna de $\mathbf{A}$ e outra pertencente ao espaço nulo à esquerda.

Essas decomposições mostram como os quatro espaços fundamentais organizam, em pares ortogonais, o domínio e o contradomínio associados à matriz $\mathbf{A}$.

3.4.13 Projeção sobre uma direção

Considere o subespaço unidimensional

$$S = \text{span}\{\mathbf{u}\},$$

em que

$$\mathbf{u} \neq \mathbf{0}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao próprio subespaço. Portanto, possui a forma

$$\text{proj}_S(\mathbf{x}) = \alpha \mathbf{u},$$

para algum $\alpha \in \mathbb{R}$.

O resíduo

$$\mathbf{r} = \mathbf{x} - \alpha \mathbf{u}$$

deve ser ortogonal a $\mathbf{u}$. Assim,

$$\mathbf{u}^\top (\mathbf{x} - \alpha \mathbf{u}) = 0.$$

Logo,

$$\mathbf{u}^\top \mathbf{x} - \alpha \mathbf{u}^\top \mathbf{u} = 0,$$

e, como $\mathbf{u} \neq \mathbf{0}$,

$$\alpha = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}.$$

Definição 3.20 (Projeção sobre uma direção). Se

$$S = \text{span}\{\mathbf{u}\}, \quad \mathbf{u} \neq \mathbf{0},$$

a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre S é

$$\text{proj}_S(\mathbf{x}) = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

A expressão pode ser reorganizada como

$$\begin{aligned} \text{proj}_S(\mathbf{x}) &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u} \\ &= \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}} \mathbf{x}. \end{aligned}$$

Portanto, definindo

$$\mathbf{P}_S = \frac{\mathbf{u} \mathbf{u}^\top}{\mathbf{u}^\top \mathbf{u}},$$

a projeção pode ser escrita na forma matricial

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x}.$$

A matriz

$$\mathbf{u} \mathbf{u}^\top$$

é o produto externo de $\mathbf{u}$ por ele próprio. Como visto nos capítulos anteriores, essa matriz é simétrica e, para $\mathbf{u} \neq \mathbf{0}$, possui posto 1. A normalização por $\mathbf{u}^\top \mathbf{u}$ produz a matriz que projeta ortogonalmente os vetores sobre a direção gerada por $\mathbf{u}$.

Se $\mathbf{u}$ possui norma igual a 1, então

$$\mathbf{u}^\top \mathbf{u} = 1,$$

e as expressões reduzem-se a

$$\text{proj}_S(\mathbf{x}) = (\mathbf{u}^\top \mathbf{x}) \mathbf{u}$$

e

$$\mathbf{P}_S = \mathbf{u}\mathbf{u}^\top.$$

Exemplo 3.20 (Exemplo: Projeção sobre uma reta). Considere

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

e

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Tomando

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\mathbf{u}^\top \mathbf{x} = 4$$

e

$$\mathbf{u}^\top \mathbf{u} = 2.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \frac{4}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Equivalentemente, a matriz de projeção é

$$\begin{aligned}\mathbf{P}_S &= \frac{\mathbf{u}\mathbf{u}^\top}{\mathbf{u}^\top\mathbf{u}} \\ &= \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

Assim,

$$\mathbf{P}_S\mathbf{x} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A ortogonalidade é verificada por

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Assim,

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

com a primeira componente em S e a segunda em $S^\perp$.

A Figura 3.5 representa essa decomposição.

A projeção pertence ao subespaço S , enquanto o resíduo pertence a $S^\perp$. Essa decomposição será estendida para subespaços gerados por vários vetores.




Figura 3.5: Decomposição de um vetor em sua projeção sobre um subespaço e em um resíduo ortogonal.

3.4.14 Projeção sobre um subespaço com base ortonormal

Considere um subespaço

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\} \subseteq \mathbb{R}^p,$$

em que

$$\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

é uma base ortonormal de S .

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S é obtida somando as projeções de $\mathbf{x}$ sobre cada vetor da base:

$$\text{proj}_S(\mathbf{x}) = \sum_{j=1}^k (\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j.$$

Como

$$(\mathbf{q}_j^\top \mathbf{x}) \mathbf{q}_j = \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \left(\sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top \right) \mathbf{x}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o produto externo do vetor $\mathbf{q}_j$ por ele próprio. Como $\mathbf{q}_j \neq \mathbf{0}$, cada uma dessas matrizes possui posto 1 e projeta sobre a direção gerada por $\mathbf{q}_j$.

Reunindo os vetores da base na matriz

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k] \in \mathbb{R}^{p \times k},$$

tem-se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_k.$$

Além disso,

$$\mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

Portanto,

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Teorema 3.19 (Projeção sobre uma base ortonormal). *Se as colunas de*

$$\mathbf{Q} \in \mathbb{R}^{p \times k}$$

formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

A matriz de projeção sobre S é

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top.$$

(Meyer, 2023)

O vetor

$$\mathbf{Q}^\top \mathbf{x} = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{q}_k^\top \mathbf{x} \end{bmatrix}$$

contém as coordenadas da projeção de $\mathbf{x}$ na base ortonormal de S . A multiplicação por $\mathbf{Q}$ utiliza essas coordenadas para reconstruir o vetor projetado no espaço original:

$$\mathbf{x} \xrightarrow{\mathbf{Q}^\top} \mathbf{Q}^\top \mathbf{x} \xrightarrow{\mathbf{Q}} \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Assim, $\mathbf{Q}^\top$ obtém as coordenadas no subespaço, enquanto $\mathbf{Q}$ reconstrói o vetor correspondente em $\mathbb{R}^p$.

Exemplo 3.21 (Exemplo: Projecção sobre um plano). Considere o subespaço

$$S = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3.$$

Uma base ortonormal de S é formada por

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Assim,

$$\mathbf{Q} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

A matriz de projecção é

$$\begin{aligned} \mathbf{P}_S &= \mathbf{Q}\mathbf{Q}^\top \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}. \end{aligned}$$

Equivalentemente,

$$\mathbf{P}_S = \mathbf{q}_1\mathbf{q}_1^\top + \mathbf{q}_2\mathbf{q}_2^\top.$$

Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

tem-se

$$\text{proj}_S(\mathbf{x}) = \mathbf{P}_S \mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_S(\mathbf{x}) = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix},$$

que pertence a $S^\perp$.

3.4.15 Projeção sobre o espaço coluna de uma matriz

Considere vetores linearmente independentes

$$\mathbf{a}_1, \dots, \mathbf{a}_k \in \mathbb{R}^p$$

e a matriz formada por esses vetores:

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_k] \in \mathbb{R}^{p \times k}.$$

Como os vetores foram previamente nomeados e depois reunidos em $\mathbf{A}$, a notação $\mathbf{a}_1, \dots, \mathbf{a}_k$ será mantida nesta subseção.

O subespaço gerado pelas colunas de $\mathbf{A}$ é

$$S = \mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_k\}.$$

A projeção de $\mathbf{x} \in \mathbb{R}^p$ sobre S deve pertencer ao espaço coluna de $\mathbf{A}$. Portanto, possui a forma

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

para algum vetor de coeficientes

$$\mathbf{c} \in \mathbb{R}^k.$$

O resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{A}\mathbf{c}$$

deve pertencer ao complemento ortogonal de $\mathcal{C}(\mathbf{A})$. Assim, ele deve ser ortogonal a todas as colunas de $\mathbf{A}$:

$$\mathbf{A}^\top (\mathbf{x} - \mathbf{A}\mathbf{c}) = \mathbf{0}.$$

Desenvolvendo,

$$\mathbf{A}^\top \mathbf{x} - \mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{0},$$

de modo que

$$\mathbf{A}^\top \mathbf{A}\mathbf{c} = \mathbf{A}^\top \mathbf{x}.$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

é a matriz de Gram das colunas de $\mathbf{A}$. Como essas colunas são linearmente independentes, $\mathbf{A}^\top \mathbf{A}$ é positiva definida e, portanto, invertível.

Assim,

$$\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Substituindo em

$$\hat{\mathbf{x}} = \mathbf{A}\mathbf{c},$$

obtém-se

$$\hat{\mathbf{x}} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x}.$$

Teorema 3.20 (Projeção sobre o espaço coluna). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes, a projeção ortogonal de $\mathbf{x} \in \mathbb{R}^p$ sobre

$$\mathcal{C}(\mathbf{A})$$

é

$$\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top}.$$

A matriz $\mathbf{P}_{\mathbf{A}}$ depende apenas do subespaço gerado pelas colunas de $\mathbf{A}$. Portanto, bases diferentes do mesmo subespaço produzem a mesma projeção ortogonal.

Quando as colunas de $\mathbf{A}$ são ortonormais,

$$\mathbf{A}^{\top} \mathbf{A} = \mathbf{I}_k,$$

e a expressão reduz-se a

$$\mathbf{P}_{\mathbf{A}} = \mathbf{A} \mathbf{A}^{\top}.$$

Esse é exatamente o resultado obtido anteriormente para uma matriz $\mathbf{Q}$ cujas colunas formam uma base ortonormal:

$$\mathbf{P}_S = \mathbf{Q} \mathbf{Q}^{\top}.$$

Portanto,

$$\boxed{\mathbf{Q} \mathbf{Q}^{\top}}$$

é o caso ortonormal da expressão geral

$$\boxed{\mathbf{A} (\mathbf{A}^{\top} \mathbf{A})^{-1} \mathbf{A}^{\top}}.$$

Exemplo 3.22 (Exemplo: Projeção utilizando uma base não ortogonal). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

As colunas de $\mathbf{A}$ são linearmente independentes. A matriz de Gram é

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

cujas inversa é

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Além disso,

$$\mathbf{A}^\top \mathbf{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Os coeficientes da projeção são

$$\begin{aligned} \mathbf{c} &= (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \\ &= \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} \\ &= \frac{1}{3} \begin{bmatrix} 1 \\ 7 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\begin{aligned}
\text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) &= \mathbf{A}\mathbf{c} \\
&= \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1/3 \\ 7/3 \end{bmatrix} \\
&= \begin{bmatrix} 1/3 \\ 8/3 \\ 7/3 \end{bmatrix}.
\end{aligned}$$

O resíduo é

$$\mathbf{r} = \mathbf{x} - \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}) = \begin{bmatrix} 2/3 \\ -2/3 \\ 2/3 \end{bmatrix}.$$

A ortogonalidade pode ser verificada por

$$\mathbf{A}^\top \mathbf{r} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

3.4.16 Propriedades da matriz de projeção

Teorema 3.21 (Propriedades da matriz de projeção). *Se*

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

possui colunas linearmente independentes e

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top,$$

então:

1. $\mathbf{P}_\mathbf{A}$ é simétrica;
2. $\mathbf{P}_\mathbf{A}$ é idempotente;
- 3.

$$\mathcal{C}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A});$$

4.

$$\mathcal{N}(\mathbf{P}_A) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top);$$

5.

$$\text{posto}(\mathbf{P}_A) = \text{posto}(\mathbf{A}) = k.$$

Comprovação. A simetria decorre de

$$\begin{aligned} \mathbf{P}_A^\top &= \left[\mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \right]^\top \\ &= \mathbf{A} \left[(\mathbf{A}^\top \mathbf{A})^{-1} \right]^\top \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_A, \end{aligned}$$

pois $\mathbf{A}^\top \mathbf{A}$ e sua inversa são simétricas.

Para verificar a idempotência,

$$\begin{aligned} \mathbf{P}_A^2 &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \\ &= \mathbf{P}_A. \end{aligned}$$

Para determinar o espaço coluna, observe inicialmente que, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_A \mathbf{x} = \mathbf{A} \left[(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{x} \right].$$

Portanto,

$$\mathbf{P}_A \mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

e, conseqüentemente,

$$\mathcal{C}(\mathbf{P}_A) \subseteq \mathcal{C}(\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A}),$$

então existe $\mathbf{c} \in \mathbb{R}^k$ tal que

$$\mathbf{y} = \mathbf{A}\mathbf{c}.$$

Assim,

$$\begin{aligned}\mathbf{P}_\mathbf{A}\mathbf{y} &= \mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top\mathbf{A}\mathbf{c} \\ &= \mathbf{A}\mathbf{c} \\ &= \mathbf{y}.\end{aligned}$$

Logo,

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{P}_\mathbf{A}),$$

e, portanto,

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}).$$

Para determinar o espaço nulo, observe que

$$\begin{aligned}\mathbf{A}^\top\mathbf{P}_\mathbf{A} &= \mathbf{A}^\top\mathbf{A}(\mathbf{A}^\top\mathbf{A})^{-1}\mathbf{A}^\top \\ &= \mathbf{A}^\top.\end{aligned}$$

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{P}_\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top\mathbf{x} = \mathbf{A}^\top\mathbf{P}_\mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{A}^\top \mathbf{x} = \mathbf{0},$$

e, conseqüentemente,

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{0}.$$

Assim,

$$\mathcal{N}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Finalmente, como

$$\mathcal{C}(\mathbf{P}_\mathbf{A}) = \mathcal{C}(\mathbf{A}),$$

tem-se

$$\text{posto}(\mathbf{P}_\mathbf{A}) = \text{posto}(\mathbf{A}).$$

Como as k colunas de $\mathbf{A}$ são linearmente independentes,

$$\text{posto}(\mathbf{A}) = k.$$

Portanto,

$$\text{posto}(\mathbf{P}_\mathbf{A}) = k.$$

□

A idempotência possui uma interpretação direta: depois que um vetor foi projetado sobre $\mathcal{C}(\mathbf{A})$, uma nova aplicação da mesma projeção não o modifica:

$$\mathbf{P}_{\mathbf{A}} (\mathbf{P}_{\mathbf{A}} \mathbf{x}) = \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Além disso, a igualdade

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^{\perp}$$

mostra que a projeção anula exatamente a componente de $\mathbf{x}$ ortogonal ao subespaço projetado.

3.4.17 Projeção sobre o complemento ortogonal

Considere

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

com colunas linearmente independentes e seja

$$\mathbf{P}_{\mathbf{A}}$$

a matriz de projeção ortogonal sobre $\mathcal{C}(\mathbf{A})$.

A componente de $\mathbf{x} \in \mathbb{R}^p$ que permanece fora desse subespaço é o resíduo

$$\mathbf{r} = \mathbf{x} - \mathbf{P}_{\mathbf{A}} \mathbf{x}.$$

Definindo

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

tem-se

$$\mathbf{r} = \mathbf{M}_{\mathbf{A}} \mathbf{x}.$$

Definição 3.21 (Matriz de projeção residual). A matriz

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}$$

é denominada **matriz de projeção residual**. Ela realiza a projeção ortogonal sobre

$$\mathcal{C}(\mathbf{A})^\perp.$$

Como

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

a matriz $\mathbf{M}_{\mathbf{A}}$ também pode ser interpretada como a matriz de projeção ortogonal sobre o espaço nulo à esquerda de $\mathbf{A}$.

A decomposição ortogonal de $\mathbf{x}$ pode ser escrita como

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}}\mathbf{x} + \mathbf{M}_{\mathbf{A}}\mathbf{x},$$

em que

$$\mathbf{P}_{\mathbf{A}}\mathbf{x} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Como essas duas componentes são ortogonais,

$$(\mathbf{P}_{\mathbf{A}}\mathbf{x})^\top (\mathbf{M}_{\mathbf{A}}\mathbf{x}) = 0.$$

Consequentemente, pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{P}_{\mathbf{A}}\mathbf{x}\|^2 + \|\mathbf{M}_{\mathbf{A}}\mathbf{x}\|^2.$$

Teorema 3.22 (Propriedades da matriz de projeção residual). *Se*

$$\mathbf{M}_{\mathbf{A}} = \mathbf{I}_p - \mathbf{P}_{\mathbf{A}},$$

então:

1. $\mathbf{M}_{\mathbf{A}}$ é simétrica;
2. $\mathbf{M}_{\mathbf{A}}$ é idempotente;
- 3.

$$\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} = \mathbf{0}$$

e

$$\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0};$$

- 4.

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top);$$

- 5.

$$\mathcal{N}(\mathbf{M}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A});$$

6. se $\mathbf{A}$ possui posto k , então

$$\text{posto}(\mathbf{M}_{\mathbf{A}}) = p - k.$$

Comprovação. Como $\mathbf{P}_{\mathbf{A}}$ é simétrica,

$$\begin{aligned}\mathbf{M}_{\mathbf{A}}^\top &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}}^\top \\ &= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\ &= \mathbf{M}_{\mathbf{A}}.\end{aligned}$$

Portanto, $\mathbf{M}_{\mathbf{A}}$ é simétrica.

Para verificar a idempotência,

$$\begin{aligned}
\mathbf{M}_{\mathbf{A}}^2 &= (\mathbf{I}_p - \mathbf{P}_{\mathbf{A}})^2 \\
&= \mathbf{I}_p - 2\mathbf{P}_{\mathbf{A}} + \mathbf{P}_{\mathbf{A}}^2 \\
&= \mathbf{I}_p - \mathbf{P}_{\mathbf{A}} \\
&= \mathbf{M}_{\mathbf{A}},
\end{aligned}$$

pois

$$\mathbf{P}_{\mathbf{A}}^2 = \mathbf{P}_{\mathbf{A}}.$$

Além disso,

$$\begin{aligned}
\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}} &= \mathbf{P}_{\mathbf{A}}(\mathbf{I}_p - \mathbf{P}_{\mathbf{A}}) \\
&= \mathbf{P}_{\mathbf{A}} - \mathbf{P}_{\mathbf{A}}^2 \\
&= \mathbf{0},
\end{aligned}$$

e, de forma análoga,

$$\mathbf{M}_{\mathbf{A}}\mathbf{P}_{\mathbf{A}} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\mathbf{P}_{\mathbf{A}}\mathbf{M}_{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{M}_{\mathbf{A}}\mathbf{x} \in \mathcal{N}(\mathbf{P}_{\mathbf{A}}).$$

Como

$$\mathcal{N}(\mathbf{P}_{\mathbf{A}}) = \mathcal{C}(\mathbf{A})^\perp,$$

tem-se

$$\mathcal{C}(\mathbf{M}_{\mathbf{A}}) \subseteq \mathcal{C}(\mathbf{A})^\perp.$$

Reciprocamente, se

$$\mathbf{y} \in \mathcal{C}(\mathbf{A})^\perp,$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{y} = \mathbf{0},$$

e, portanto,

$$\begin{aligned} \mathbf{M}_\mathbf{A} \mathbf{y} &= (\mathbf{I}_p - \mathbf{P}_\mathbf{A}) \mathbf{y} \\ &= \mathbf{y}. \end{aligned}$$

Assim,

$$\mathcal{C}(\mathbf{A})^\perp \subseteq \mathcal{C}(\mathbf{M}_\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{M}_\mathbf{A}) = \mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Agora, se

$$\mathbf{x} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{P}_\mathbf{A} \mathbf{x} = \mathbf{x}.$$

Consequentemente,

$$\mathbf{M}_\mathbf{A} \mathbf{x} = \mathbf{0},$$

e

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{M}_\mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{M}_\mathbf{A}),$$

então

$$(\mathbf{I}_p - \mathbf{P}_A) \mathbf{x} = \mathbf{0},$$

de modo que

$$\mathbf{x} = \mathbf{P}_A \mathbf{x}.$$

Como

$$\mathbf{P}_A \mathbf{x} \in \mathcal{C}(A),$$

segue que

$$\mathbf{x} \in \mathcal{C}(A).$$

Portanto,

$$\mathcal{N}(\mathbf{M}_A) = \mathcal{C}(A).$$

Finalmente,

$$\mathcal{C}(\mathbf{M}_A) = \mathcal{C}(A)^\perp.$$

Como

$$\dim \mathcal{C}(A) = k,$$

o teorema da dimensão do complemento ortogonal fornece

$$\dim \mathcal{C}(\mathbf{M}_A) = p - k.$$

Logo,

$$\text{posto}(\mathbf{M}_A) = p - k.$$

□

3.4.18 Projeção como melhor aproximação

A projeção ortogonal pode ser caracterizada por uma propriedade de otimização: entre todos os vetores de um subespaço, ela é o único vetor que possui a menor distância até o vetor original.

Teorema 3.23 (Teorema da melhor aproximação). *Seja S um subespaço de $\mathbb{R}^p$ e seja*

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x}).$$

Então, para qualquer $\mathbf{y} \in S$,

$$\|\mathbf{x} - \hat{\mathbf{x}}\| \leq \|\mathbf{x} - \mathbf{y}\|.$$

A igualdade ocorre se, e somente se,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

(Meyer, 2023)

Comprovação. Como

$$\hat{\mathbf{x}} \in S$$

e

$$\mathbf{y} \in S,$$

tem-se

$$\hat{\mathbf{x}} - \mathbf{y} \in S.$$

Por outro lado, como $\hat{\mathbf{x}}$ é a projeção ortogonal de $\mathbf{x}$ sobre S , o resíduo

$$\mathbf{x} - \hat{\mathbf{x}}$$

pertence a $S^\perp$.

Portanto,

$$\mathbf{x} - \hat{\mathbf{x}}$$

e

$$\hat{\mathbf{x}} - \mathbf{y}$$

são ortogonais.

Escrevendo

$$\mathbf{x} - \mathbf{y} = (\mathbf{x} - \hat{\mathbf{x}}) + (\hat{\mathbf{x}} - \mathbf{y}),$$

o Teorema de Pitágoras fornece

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \|\hat{\mathbf{x}} - \mathbf{y}\|^2.$$

Como

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 \geq 0,$$

segue que

$$\|\mathbf{x} - \mathbf{y}\|^2 \geq \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

A igualdade ocorre se, e somente se,

$$\|\hat{\mathbf{x}} - \mathbf{y}\|^2 = 0,$$

isto é,

$$\mathbf{y} = \hat{\mathbf{x}}.$$

□

Portanto,

$$\hat{\mathbf{x}} = \text{proj}_S(\mathbf{x})$$

é o único minimizador do problema

$$\hat{\mathbf{x}} = \underset{\mathbf{y} \in S}{\text{argmin}} \|\mathbf{x} - \mathbf{y}\|^2.$$

Essa formulação transforma a projeção ortogonal em um problema de melhor aproximação.

Quando

$$S = \mathcal{C}(\mathbf{A}),$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times k},$$

todo vetor de S pode ser escrito como

$$\mathbf{y} = \mathbf{A}\mathbf{c}, \quad \mathbf{c} \in \mathbb{R}^k.$$

Consequentemente,

$$\hat{\mathbf{c}} = \underset{\mathbf{c} \in \mathbb{R}^k}{\text{argmin}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2,$$

e o vetor projetado é

$$\hat{\mathbf{x}} = \mathbf{A}\hat{\mathbf{c}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{x}).$$

Essa é a interpretação geométrica do problema de mínimos quadrados desenvolvido a seguir.

3.4.19 Projeções e mínimos quadrados

Considere

$$\mathbf{A} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{b} \in \mathbb{R}^n.$$

O sistema

$$\mathbf{A}\beta = \mathbf{b}, \quad \beta \in \mathbb{R}^k,$$

possui solução exata se, e somente se,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

não existe vetor β capaz de reproduzir exatamente $\mathbf{b}$. Nesse caso, procura-se a combinação linear das colunas de $\mathbf{A}$ que mais se aproxima de $\mathbf{b}$ no sentido da distância euclidiana.

O problema de mínimos quadrados é

$$\hat{\beta} \in \underset{\beta \in \mathbb{R}^k}{\operatorname{argmin}} \|\mathbf{b} - \mathbf{A}\beta\|^2.$$

Pelo Teorema 3.23, o vetor ajustado

$$\hat{\mathbf{b}} = \mathbf{A}\hat{\beta}$$

é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna de $\mathbf{A}$:

$$\hat{\mathbf{b}} = \operatorname{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}).$$

O vetor de resíduos é

$$\hat{\mathbf{e}} = \mathbf{b} - \hat{\mathbf{b}} = \mathbf{b} - \mathbf{A}\hat{\beta}.$$

Como a projeção é ortogonal,

$$\hat{\mathbf{e}} \in \mathcal{C}(\mathbf{A})^\perp.$$

Pela relação entre os espaços fundamentais,

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top),$$

portanto

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Consequentemente,

$$\mathbf{A}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

Substituindo

$$\hat{\mathbf{e}} = \mathbf{b} - \mathbf{A}\hat{\beta},$$

obtém-se

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\beta}) = \mathbf{0},$$

e, portanto,

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}.$$

Definição 3.22 (Equações normais). As equações

$$\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{b}$$

são denominadas **equações normais** do problema de mínimos quadrados.

Se as colunas de $\mathbf{A}$ são linearmente independentes, então

$$\text{posto}(\mathbf{A}) = k$$

e a matriz de Gram

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. Nesse caso, as equações normais possuem solução única:

$$\hat{\beta} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

O vetor ajustado pode então ser escrito como

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\beta} \\ &= \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} \\ &= \mathbf{P}_\mathbf{A} \mathbf{b}, \end{aligned}$$

enquanto o vetor de resíduos é

$$\begin{aligned} \hat{\mathbf{e}} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= (\mathbf{I}_n - \mathbf{P}_\mathbf{A}) \mathbf{b} \\ &= \mathbf{M}_\mathbf{A} \mathbf{b}. \end{aligned}$$

Aqui,

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \in \mathbb{R}^{n \times n}$$

projeta sobre $\mathcal{C}(\mathbf{A})$, enquanto

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_n - \mathbf{P}_\mathbf{A} \in \mathbb{R}^{n \times n}$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Teorema 3.24 (Decomposição de mínimos quadrados). *No problema de mínimos quadrados,*

$$\mathbf{b} = \hat{\mathbf{b}} + \hat{\mathbf{e}},$$

em que

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\hat{\mathbf{b}}^\top \hat{\mathbf{e}} = 0$$

e

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\hat{\mathbf{e}}\|^2.$$

(Golub; Van Loan, 2013)

Essa decomposição é a aplicação direta da decomposição ortogonal

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

ao vetor $\mathbf{b}$.

Se as colunas de $\mathbf{A}$ são linearmente dependentes, as equações normais podem admitir mais de uma solução para β . Nesse caso, os coeficientes de mínimos quadrados podem não ser únicos.

Entretanto, o vetor ajustado

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b})$$

permanece único, pois a projeção depende apenas do subespaço $\mathcal{C}(\mathbf{A})$.

Utilizando a pseudoinversa de Moore–Penrose,

$$\hat{\beta} = \mathbf{A}^+ \mathbf{b}$$

fornece, entre as soluções de mínimos quadrados, a solução de menor norma. O vetor ajustado pode ser escrito como

$$\hat{\mathbf{b}} = \mathbf{A}\mathbf{A}^+\mathbf{b},$$

de modo que

$$\mathbf{P}_\mathbf{A} = \mathbf{A}\mathbf{A}^+.$$

A pseudoinversa foi introduzida no capítulo anterior. Sua construção por meio da Decomposição em Valores Singulares será desenvolvida posteriormente.

As projeções ponderadas podem ser obtidas substituindo o produto interno euclidiano por um produto interno induzido por uma matriz positiva definida. Essa extensão será retomada no estudo de problemas de mínimos quadrados ponderados.

3.5 Síntese do capítulo

Um subespaço vetorial é um subconjunto fechado em relação às combinações lineares. O subespaço gerado por

$$\mathbf{v}_1, \dots, \mathbf{v}_k$$

é

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}.$$

Um conjunto de vetores é linearmente independente quando

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \dots = \alpha_k = 0.$$

Uma base é um conjunto linearmente independente que gera o espaço. Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ possui uma representação única:

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

O número de vetores de uma base determina a dimensão do espaço.

Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{m \times n},$$

os quatro espaços fundamentais são:

$$\mathcal{C}(\mathbf{A}), \quad \mathcal{L}(\mathbf{A}), \quad \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A}^\top).$$

Se

$$r = \text{posto}(\mathbf{A}),$$

então

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = n - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = m - r.$$

As relações de ortogonalidade são

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Um produto interno pode ser induzido por uma matriz simétrica positiva definida:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}.$$

A norma e a distância correspondentes são

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

e

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

A matriz de Gram

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

organiza os produtos internos entre as colunas de $\mathbf{V}$. Ela é simétrica e semidefinida positiva, sendo positiva definida quando essas colunas são linearmente independentes.

Para um subespaço $S \subseteq \mathbb{R}^p$,

$$\mathbb{R}^p = S \oplus S^\perp.$$

Assim, todo vetor pode ser decomposto de maneira única como

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{r},$$

em que

$$\text{proj}_S(\mathbf{x}) \in S$$

e

$$\mathbf{r} \in S^\perp.$$

Se as colunas de $\mathbf{Q}$ formam uma base ortonormal de S , então

$$\text{proj}_S(\mathbf{x}) = \mathbf{Q}\mathbf{Q}^\top \mathbf{x}.$$

Se as colunas de $\mathbf{A}$ são linearmente independentes e

$$S = \mathcal{C}(\mathbf{A}),$$

a matriz de projeção é

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A projeção é o vetor de S que minimiza a distância até $\mathbf{x}$. Essa propriedade fornece a interpretação geométrica das equações normais e dos problemas de mínimos quadrados.

Os conceitos de base, núcleo, imagem e projeção serão utilizados no estudo das transformações lineares e de suas representações matriciais. ## Síntese do capítulo

Um subespaço vetorial é um subconjunto de um espaço vetorial fechado em relação às combinações lineares. O subespaço gerado por

$$\mathbf{v}_1, \dots, \mathbf{v}_k$$

é

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}.$$

Um conjunto de vetores é linearmente independente quando

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \dots = \alpha_k = 0.$$

Uma base é um conjunto linearmente independente que gera o espaço. Se

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_k\}$$

é uma base de V , então todo vetor $\mathbf{x} \in V$ possui uma representação única:

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_k \mathbf{b}_k.$$

O número de vetores de uma base determina a dimensão do espaço.

Para uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

os quatro espaços fundamentais são

$$\mathcal{C}(\mathbf{A}), \quad \mathcal{L}(\mathbf{A}), \quad \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A}^\top).$$

Se

$$r = \text{posto}(\mathbf{A}),$$

então

$$\dim \mathcal{C}(\mathbf{A}) = \dim \mathcal{L}(\mathbf{A}) = r,$$

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = n - r.$$

Esses espaços se organizam em pares ortogonais:

$$\mathcal{N}(\mathbf{A}) = \mathcal{L}(\mathbf{A})^\perp$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{A})^\perp.$$

Consequentemente,

$$\mathbb{R}^p = \mathcal{L}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A})$$

e

$$\mathbb{R}^n = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top).$$

O produto interno euclidiano pode ser generalizado por uma matriz simétrica positiva definida:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}.$$

A norma e a distância induzidas são

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}$$

e

$$d_{\mathbf{M}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{M} (\mathbf{x} - \mathbf{y})}.$$

A matriz de Gram

$$\mathbf{G} = \mathbf{V}^\top \mathbf{V}$$

organiza os produtos internos entre as colunas de $\mathbf{V}$. Ela é simétrica e semidefinida positiva e é positiva definida quando essas colunas são linearmente independentes.

Para um subespaço

$$S \subseteq \mathbb{R}^p,$$

todo vetor admite uma decomposição ortogonal única:

$$\mathbf{x} = \text{proj}_S(\mathbf{x}) + \mathbf{x}_{S^\perp},$$

com

$$\text{proj}_S(\mathbf{x}) \in S$$

e

$$\mathbf{x}_{S^\perp} \in S^\perp.$$

Se

$$S = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$$

e os vetores $\mathbf{q}_1, \dots, \mathbf{q}_k$ formam uma base ortonormal, então

$$\mathbf{P}_S = \mathbf{Q}\mathbf{Q}^\top = \sum_{j=1}^k \mathbf{q}_j \mathbf{q}_j^\top,$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_k].$$

Cada parcela

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é um produto externo e representa a projeção sobre uma direção da base.

Quando

$$S = \mathcal{C}(\mathbf{A}),$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times k}$$

e colunas linearmente independentes, a matriz de projeção é

$$\mathbf{P}_\mathbf{A} = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

A matriz complementar

$$\mathbf{M}_\mathbf{A} = \mathbf{I}_p - \mathbf{P}_\mathbf{A}$$

projeta sobre

$$\mathcal{C}(\mathbf{A})^\perp = \mathcal{N}(\mathbf{A}^\top).$$

Assim,

$$\mathbf{x} = \mathbf{P}_\mathbf{A} \mathbf{x} + \mathbf{M}_\mathbf{A} \mathbf{x}$$

é uma decomposição ortogonal.

A projeção ortogonal também é caracterizada como um problema de melhor aproximação. Para

$$S = \mathcal{C}(\mathbf{A}),$$

o problema

$$\min_{\mathbf{c}} \|\mathbf{x} - \mathbf{A}\mathbf{c}\|^2$$

é resolvido projetando $\mathbf{x}$ sobre o espaço coluna de $\mathbf{A}$.

No problema de mínimos quadrados,

$$\mathbf{A} \in \mathbb{R}^{n \times k}, \quad \mathbf{b} \in \mathbb{R}^n,$$

o vetor ajustado satisfaz

$$\hat{\mathbf{b}} = \text{proj}_{\mathcal{C}(\mathbf{A})}(\mathbf{b}),$$

enquanto o resíduo satisfaz

$$\hat{\mathbf{e}} \in \mathcal{N}(\mathbf{A}^\top).$$

Quando as colunas de $\mathbf{A}$ são linearmente independentes,

$$\hat{\beta} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Quando há dependência linear entre as colunas, os coeficientes de mínimos quadrados podem não ser únicos, mas o vetor projetado permanece único. A pseudoinversa fornece uma solução de menor norma.

Ao final deste capítulo, o estudante deverá ser capaz de:

- verificar se um conjunto é um subespaço vetorial;
- determinar subespaços gerados por conjuntos de vetores;
- verificar dependência e independência linear;
- identificar bases e determinar a dimensão de um subespaço;
- representar vetores por coordenadas em diferentes bases;
- interpretar bases ortogonais e ortonormais;
- determinar os espaços coluna, linha, nulo e nulo à esquerda de uma matriz;
- relacionar posto e nulidade às dimensões dos espaços fundamentais;
- interpretar as relações de ortogonalidade entre os quatro espaços fundamentais;
- utilizar produtos internos e normas induzidos por matrizes positivas definidas;
- interpretar matrizes de Gram;
- determinar complementos ortogonais;
- decompor vetores em componentes ortogonais;
- calcular projeções sobre direções e subespaços;
- interpretar matrizes de projeção e de projeção residual;
- relacionar projeções a problemas de melhor aproximação e mínimos quadrados.

O próximo capítulo desenvolverá as transformações lineares de forma geral. Os conceitos de domínio, imagem, núcleo, base, posto e projeção estudados aqui serão utilizados para interpretar como uma transformação atua sobre vetores e subespaços e como essa ação pode ser representada por matrizes.

4 Transformações lineares

Os capítulos anteriores apresentaram vetores, matrizes, espaços vetoriais, bases e projeções. Esses objetos permitem representar observações multivariadas e descrever relações lineares entre suas coordenadas.

Uma matriz também pode representar uma aplicação que transforma vetores. Essa aplicação pode alterar a orientação, a escala ou a dimensão da configuração original. Quando preserva combinações lineares, ela é denominada transformação linear.

Este capítulo desenvolve a definição e a representação matricial das transformações lineares, sua aplicação a matrizes de dados, a composição de operações, a invertibilidade e a perda de informação. Também são estudadas transformações geométricas, transformações ortogonais, mudanças de coordenadas e transformações afins utilizadas no pré-processamento de dados.

4.1 Transformações lineares e representação matricial

Uma aplicação entre espaços vetoriais associa a cada vetor do domínio um vetor do contradomínio. A linearidade exige que essa aplicação preserve as operações de adição e multiplicação por escalar.

Definição 4.1 (Transformação linear). Sejam V e W espaços vetoriais reais. Uma aplicação

$$T : V \longrightarrow W$$

é uma **transformação linear** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in V$ e escalares $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Tomando $\alpha = \beta = 1$, obtém-se a preservação da soma:

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}).$$

Tomando $\beta = 0$, obtém-se a preservação da multiplicação por escalar:

$$T(\alpha \mathbf{u}) = \alpha T(\mathbf{u}).$$

Assim, a imagem de uma combinação linear é a combinação linear das imagens:

$$T\left(\sum_{j=1}^k \alpha_j \mathbf{v}_j\right) = \sum_{j=1}^k \alpha_j T(\mathbf{v}_j).$$

A Figura 4.1 representa a preservação da soma. O paralelogramo formado pelos vetores originais é transformado em outro paralelogramo cujos lados são as imagens desses vetores.




Figura 4.1: Preservação da soma de vetores por uma transformação linear.

No primeiro painel, $\mathbf{u} + \mathbf{v}$ é a diagonal do paralelogramo formado pelos vetores originais. No segundo painel, a relação

$$T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

é preservada.

Teorema 4.1 (Propriedades elementares das transformações lineares). *Se*

$$T : V \longrightarrow W$$

é uma transformação linear, então:

1. $T(\mathbf{0}) = \mathbf{0}$;
2. $T(-\mathbf{x}) = -T(\mathbf{x})$;
3. $T(\mathbf{u} - \mathbf{v}) = T(\mathbf{u}) - T(\mathbf{v})$.

(Meyer, 2023)

Comprovação. Pela homogeneidade,

$$T(\mathbf{0}) = T(0\mathbf{x}) = 0T(\mathbf{x}) = \mathbf{0}.$$

Também pela homogeneidade,

$$T(-\mathbf{x}) = T((-1)\mathbf{x}) = -T(\mathbf{x}).$$

Consequentemente,

$$\begin{aligned} T(\mathbf{u} - \mathbf{v}) &= T(\mathbf{u} + (-\mathbf{v})) \\ &= T(\mathbf{u}) + T(-\mathbf{v}) \\ &= T(\mathbf{u}) - T(\mathbf{v}). \end{aligned}$$

□

A igualdade $T(\mathbf{0}) = \mathbf{0}$ é uma condição necessária para a linearidade. Se uma aplicação não envia o vetor nulo ao vetor nulo, ela não é uma transformação linear.

4.1.1 Transformação determinada por uma base

Uma transformação linear é determinada por sua ação sobre os vetores de uma base do domínio.

Teorema 4.2 (Determinação de uma transformação por uma base). *Seja*

$$\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$$

uma base de V . Uma transformação linear

$$T : V \longrightarrow W$$

fica completamente determinada pelos vetores

$$T(\mathbf{v}_1), \dots, T(\mathbf{v}_p).$$

(Meyer, 2023)

Comprovação. Todo vetor $\mathbf{x} \in V$ possui uma representação única na base $\mathcal{B}$:

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_p \mathbf{v}_p.$$

Pela linearidade,

$$T(\mathbf{x}) = c_1 T(\mathbf{v}_1) + \dots + c_p T(\mathbf{v}_p).$$

Portanto, conhecidas as imagens dos vetores da base, a imagem de qualquer vetor do domínio pode ser determinada. $\square$

Considere uma transformação

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

definida sobre os vetores da base canônica por

$$T(\mathbf{e}_1) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$T(\mathbf{e}_2) = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2,$$

tem-se

$$\begin{aligned}
T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + x_2 T(\mathbf{e}_2) \\
&= x_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + x_2 \begin{bmatrix} -1 \\ 3 \end{bmatrix} \\
&= \begin{bmatrix} 2x_1 - x_2 \\ x_1 + 3x_2 \end{bmatrix}.
\end{aligned}$$

Essa expressão pode ser escrita como

$$T(\mathbf{x}) = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

As colunas da matriz são as imagens dos vetores da base canônica.

4.1.2 Representação matricial nas bases canônicas

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Se

$$\mathcal{E}_p = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$$

é a base canônica de $\mathbb{R}^p$, defina

$$\mathbf{a}_j = T(\mathbf{e}_j), \quad j = 1, \dots, p.$$

Organizando esses vetores nas colunas de uma matriz, obtém-se

$$\mathbf{A} = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p] \in \mathbb{R}^{q \times p}.$$

Para

$$\mathbf{x} = x_1 \mathbf{e}_1 + \dots + x_p \mathbf{e}_p,$$

a linearidade fornece

$$\begin{aligned}
T(\mathbf{x}) &= x_1 T(\mathbf{e}_1) + \cdots + x_p T(\mathbf{e}_p) \\
&= x_1 \mathbf{a}_1 + \cdots + x_p \mathbf{a}_p \\
&= \mathbf{A}\mathbf{x}.
\end{aligned}$$

Teorema 4.3 (Representação matricial de uma transformação linear). *Toda transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

pode ser representada de maneira única por uma matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

tal que

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

A j -ésima coluna de $\mathbf{A}$ é a imagem do j -ésimo vetor da base canônica:

$$\mathbf{a}_j = T(\mathbf{e}_j).$$

Reciprocamente, toda matriz

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

define uma transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

por

$$T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

De fato,

$$\begin{aligned}
T_{\mathbf{A}}(\alpha \mathbf{u} + \beta \mathbf{v}) &= \mathbf{A}(\alpha \mathbf{u} + \beta \mathbf{v}) \\
&= \alpha \mathbf{A}\mathbf{u} + \beta \mathbf{A}\mathbf{v} \\
&= \alpha T_{\mathbf{A}}(\mathbf{u}) + \beta T_{\mathbf{A}}(\mathbf{v}).
\end{aligned}$$

A matriz apresentada nessa representação corresponde às bases canônicas do domínio e do contradomínio. A representação em bases gerais será desenvolvida posteriormente.

4.1.3 Imagem de um subespaço

Considere um subespaço

$$S = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} \subseteq V.$$

Todo vetor $\mathbf{x} \in S$ possui a forma

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k.$$

Aplicando T ,

$$T(\mathbf{x}) = \alpha_1 T(\mathbf{v}_1) + \dots + \alpha_k T(\mathbf{v}_k).$$

Portanto,

$$T(S) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_k)\}.$$

A imagem de um subespaço por uma transformação linear também é um subespaço do contradomínio.

A transformação preserva as combinações lineares, mas pode reduzir a dimensão do espaço gerado. Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ são linearmente independentes, mas

$$\mathbf{A}\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{A}\mathbf{e}_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

A segunda direção é eliminada e a imagem da transformação possui dimensão 1. A relação entre preservação da independência linear, núcleo, posto e injetividade será desenvolvida na seção sobre invertibilidade e perda de informação.

4.2 Transformação de vetores e matrizes de dados

A representação

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}$$

considera cada observação como um vetor-coluna. Em uma matriz de dados, as observações são organizadas nas linhas. A aplicação simultânea da transformação exige, portanto, a transposição da matriz que atua sobre cada vetor.

Considere

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p},$$

em que

$$\mathbf{x}_i \in \mathbb{R}^p, \quad i = 1, \dots, n,$$

representa a i -ésima observação.

Se

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada por

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

a imagem de cada observação é

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \in \mathbb{R}^q.$$

Transpondo essa igualdade,

$$\mathbf{y}_i^\top = \mathbf{x}_i^\top \mathbf{A}^\top.$$

Teorema 4.4 (Transformação de uma matriz de dados). *Se as observações estão organizadas nas linhas de*

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e cada observação é transformada por

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i, \quad \mathbf{A} \in \mathbb{R}^{q \times p},$$

então a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top \in \mathbb{R}^{n \times q}.$$

Comprovação. A i -ésima linha de $\mathbf{Y}$ é

$$\mathbf{x}_i^\top \mathbf{A}^\top.$$

Como

$$\mathbf{x}_i^\top \mathbf{A}^\top = (\mathbf{A}\mathbf{x}_i)^\top = \mathbf{y}_i^\top,$$

tem-se

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^\top \\ \mathbf{y}_2^\top \\ \vdots \\ \mathbf{y}_n^\top \end{bmatrix} = \mathbf{X}\mathbf{A}^\top.$$

□

As dimensões da multiplicação são

$$\underbrace{\mathbf{X}}_{n \times p} \underbrace{\mathbf{A}^\top}_{p \times q} = \underbrace{\mathbf{Y}}_{n \times q}.$$

A transposição não altera a transformação definida sobre vetores-coluna. Ela adapta a multiplicação à organização das observações nas linhas da matriz de dados.

Em R, essa operação pode ser realizada por:

```
Y <- X %*% t(A)
```

4.2.1 Novas variáveis como combinações lineares

Seja

$$\mathbf{w}_j \in \mathbb{R}^p$$

o vetor de coeficientes associado à j -ésima coordenada transformada. As linhas de $\mathbf{A}$ podem ser representadas por

$$\mathbf{A} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_q^\top \end{bmatrix},$$

de modo que

$$\mathbf{A}^\top = [\mathbf{w}_1 \quad \mathbf{w}_2 \quad \cdots \quad \mathbf{w}_q].$$

Consequentemente,

$$\mathbf{Y} = [\mathbf{X}\mathbf{w}_1 \quad \mathbf{X}\mathbf{w}_2 \quad \cdots \quad \mathbf{X}\mathbf{w}_q].$$

A j -ésima coluna da matriz transformada é

$$\mathbf{y}^{(j)} = \mathbf{X}\mathbf{w}_j.$$

Cada nova variável é, portanto, uma combinação linear das variáveis originais. Para a i -ésima observação,

$$y_{ij} = a_{j1}x_{i1} + a_{j2}x_{i2} + \cdots + a_{jp}x_{ip}.$$

Essa relação permite interpretar a transformação de duas maneiras complementares:

- cada linha de $\mathbf{Y}$ é a imagem de uma observação;
- cada coluna de $\mathbf{Y}$ é uma nova variável construída por combinação linear.

Exemplo 4.1 (Transformação de um conjunto de observações). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix}$$

e

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix}.$$

Para uma observação genérica,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{y}_i &= \mathbf{A}\mathbf{x}_i \\ &= \begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x_{i1} \\ x_{i2} \end{bmatrix} \\ &= \begin{bmatrix} x_{i1} + x_{i2} \\ 2x_{i1} - x_{i2} \end{bmatrix}. \end{aligned}$$

Como as observações estão nas linhas de $\mathbf{X}$,

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 0 \\ 4 & 5 \\ 6 & 0 \end{bmatrix}. \end{aligned}$$

A primeira variável transformada é a soma das duas variáveis originais:

$$\mathbf{y}^{(1)} = \mathbf{x}^{(1)} + \mathbf{x}^{(2)}.$$

A segunda é

$$\mathbf{y}^{(2)} = 2\mathbf{x}^{(1)} - \mathbf{x}^{(2)}.$$

4.2.2 Dimensão da configuração transformada

Quando

$$q = p,$$

a transformação atua entre espaços de mesma dimensão:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p.$$

e o domínio e o contradomínio possuem a mesma dimensão. A dimensão efetiva da imagem, entretanto, pode ser menor que p quando $\mathbf{A}$ não possui posto completo.

Quando

$$q < p,$$

a transformação produz vetores com menos coordenadas:

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Quando

$$q > p,$$

os vetores passam a ser representados em um espaço com mais coordenadas. Esse aumento do contradomínio não implica aumento da dimensão efetiva da imagem.

Se

$$\text{posto}(\mathbf{A}) = r,$$

então

$$\mathcal{C}(\mathbf{A}) \subseteq \mathbb{R}^q$$

possui dimensão r . Como

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i,$$

todas as observações transformadas pertencem a esse espaço:

$$\mathbf{y}_i \in \mathcal{C}(\mathbf{A}).$$

Portanto, a configuração transformada está contida em um subespaço de dimensão

$$r = \text{posto}(\mathbf{A}).$$

Se

$$r = q,$$

a imagem coincide com todo o contradomínio.

Se

$$r < q,$$

a imagem ocupa apenas um subespaço próprio de $\mathbb{R}^q$.

Quando

$$r < p,$$

a transformação elimina pelo menos uma direção do domínio. Existe, nesse caso, um vetor não nulo

$$\mathbf{v} \in \mathcal{N}(\mathbf{A})$$

tal que

$$\mathbf{A}\mathbf{v} = \mathbf{0}.$$

Para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Vetores distintos podem, portanto, produzir a mesma imagem quando diferem por um elemento do espaço nulo.

A Figura 4.2 compara os efeitos de diferentes matrizes sobre uma mesma configuração de pontos.




Figura 4.2: Efeito de diferentes transformações lineares sobre uma mesma configuração de pontos.

A rotação gira a configuração em relação aos eixos coordenados sem alterar sua forma. A reflexão também preserva a forma, mas inverte sua orientação. O escalonamento modifica os comprimentos em cada direção, enquanto o cisalhamento altera uma coordenada de acordo com a outra. A projeção elimina a segunda coordenada e reduz a configuração a uma reta.

As cinco operações preservam combinações lineares. Entretanto, não preservam necessariamente comprimentos, ângulos, áreas ou dimensão.

4.2.3 Efeito sobre diferenças e produtos internos

Se duas observações são representadas por $\mathbf{x}_i$ e $\mathbf{x}_j$, então

$$\begin{aligned}\mathbf{y}_i - \mathbf{y}_j &= \mathbf{A}\mathbf{x}_i - \mathbf{A}\mathbf{x}_j \\ &= \mathbf{A}(\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A transformação das diferenças determina o efeito sobre as distâncias. O quadrado da distância entre as imagens é

$$\begin{aligned}\|\mathbf{y}_i - \mathbf{y}_j\|^2 &= [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)]^\top [\mathbf{A}(\mathbf{x}_i - \mathbf{x}_j)] \\ &= (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{A}^\top \mathbf{A} (\mathbf{x}_i - \mathbf{x}_j).\end{aligned}$$

A matriz

$$\mathbf{A}^\top \mathbf{A}$$

descreve, no domínio, a geometria induzida pela transformação.

Para quaisquer vetores $\mathbf{x}, \mathbf{z} \in \mathbb{R}^p$,

$$\begin{aligned}T(\mathbf{x})^\top T(\mathbf{z}) &= (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{z}) \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{z}.\end{aligned}$$

Em particular,

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}.$$

Como

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0,$$

a matriz $\mathbf{A}^\top \mathbf{A}$ é simétrica e semidefinida positiva.

Se $\mathbf{A}$ possui posto completo nas colunas, então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$. Nesse caso,

$$\mathbf{A}^\top \mathbf{A} \succ 0,$$

e a expressão

$$\|\mathbf{x}\|_{\mathbf{A}} = \sqrt{\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}} = \|\mathbf{A} \mathbf{x}\|$$

define uma norma em $\mathbb{R}^p$.

Quando $\mathbf{A}$ não possui posto completo nas colunas, existem vetores não nulos em $\mathcal{N}(\mathbf{A})$ para os quais

$$\|\mathbf{x}\|_{\mathbf{A}} = 0.$$

Nesse caso, $\|\cdot\|_{\mathbf{A}}$ define uma seminorma.

4.2.4 Transformação das matrizes de produtos internos

A matriz de Gram entre as observações originais é

$$\mathbf{G}_{\mathbf{X}} = \mathbf{X} \mathbf{X}^\top.$$

Para

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^\top,$$

tem-se

$$\begin{aligned} \mathbf{G}_{\mathbf{Y}} &= \mathbf{Y} \mathbf{Y}^\top \\ &= \mathbf{X} \mathbf{A}^\top \mathbf{A} \mathbf{X}^\top. \end{aligned}$$

Portanto,

$$\mathbf{G}_Y = \mathbf{X}\mathbf{A}^\top \mathbf{A}\mathbf{X}^\top.$$

Se

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p,$$

então

$$\mathbf{G}_Y = \mathbf{X}\mathbf{X}^\top = \mathbf{G}_X.$$

Nesse caso, todos os produtos internos entre as observações são preservados.

A matriz de produtos cruzados entre as variáveis transformadas é

$$\begin{aligned}\mathbf{Y}^\top \mathbf{Y} &= (\mathbf{X}\mathbf{A}^\top)^\top (\mathbf{X}\mathbf{A}^\top) \\ &= \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.\end{aligned}$$

Logo,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{A}\mathbf{X}^\top \mathbf{X}\mathbf{A}^\top.$$

Essa expressão descreve como os produtos cruzados entre as novas variáveis são obtidos a partir dos produtos cruzados entre as variáveis originais.

Quando $\mathbf{X}$ está centralizada, a mesma estrutura permite descrever posteriormente a transformação da matriz de covariâncias. Por enquanto, a relação mostra que uma transformação linear modifica simultaneamente a geometria das observações e as relações entre as variáveis.

4.3 Composição, invertibilidade e perda de informação

Transformações lineares podem ser aplicadas sucessivamente. A matriz da transformação resultante é obtida pelo produto das matrizes que representam cada etapa.

4.3.1 Composição de transformações lineares

Considere

$$T_1 : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$T_2 : \mathbb{R}^q \longrightarrow \mathbb{R}^r,$$

representadas, respectivamente, por

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{r \times q}.$$

Para $\mathbf{x} \in \mathbb{R}^p$,

$$T_1(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Aplicando T_2 à imagem produzida por T_1 ,

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{B}(\mathbf{A}\mathbf{x}) \\ &= (\mathbf{B}\mathbf{A})\mathbf{x}. \end{aligned}$$

Teorema 4.5 (Matriz de uma composição). *Se T_1 é representada por $\mathbf{A}$ e T_2 é representada por $\mathbf{B}$, então a composição*

$$T_2 \circ T_1$$

é representada por

$$\mathbf{B}\mathbf{A}.$$

Em particular,

$$[T_2 \circ T_1] = [T_2][T_1].$$

A ordem do produto é interpretada da direita para a esquerda:

1. $\mathbf{A}$ atua primeiro;
2. $\mathbf{B}$ atua depois.

As dimensões refletem essa sequência:

$$\underbrace{\mathbf{B}}_{r \times q} \underbrace{\mathbf{A}}_{q \times p} \underbrace{\mathbf{x}}_{p \times 1} \in \mathbb{R}^r.$$

Se as observações estão nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a primeira transformação produz

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top.$$

A segunda produz

$$\begin{aligned} \mathbf{Z} &= \mathbf{Y}\mathbf{B}^\top \\ &= \mathbf{X}\mathbf{A}^\top\mathbf{B}^\top \\ &= \mathbf{X}(\mathbf{BA})^\top. \end{aligned}$$

Portanto, a composição aplicada à matriz de dados é

$$\mathbf{Z} = \mathbf{X}(\mathbf{BA})^\top.$$

4.3.2 A ordem das transformações

Em geral,

$$\mathbf{BA} \neq \mathbf{AB}.$$

Consequentemente,

$$T_2 \circ T_1 \neq T_1 \circ T_2.$$

Exemplo 4.2 (Composição de rotação e escalonamento). Considere uma rotação de 45° ,

$$\mathbf{Q}\left(\frac{\pi}{4}\right) = \begin{bmatrix} \cos(\pi/4) & -\sin(\pi/4) \\ \sin(\pi/4) & \cos(\pi/4) \end{bmatrix},$$

e um escalonamento não uniforme,

$$\mathbf{L} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

Aplicar primeiro a rotação e depois o escalonamento corresponde a

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right).$$

Aplicar primeiro o escalonamento e depois a rotação corresponde a

$$\mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L}.$$

Como

$$\mathbf{L}\mathbf{Q}\left(\frac{\pi}{4}\right) \neq \mathbf{Q}\left(\frac{\pi}{4}\right)\mathbf{L},$$

as duas sequências produzem transformações diferentes.

A Figura 4.3 compara as duas ordens de aplicação.

As duas composições utilizam as mesmas transformações, mas produzem configurações diferentes. Na primeira, a nuvem é rotacionada antes de ser escalonada em relação aos eixos coordenados. Na segunda, o escalonamento ocorre antes da mudança de orientação.




Figura 4.3: Efeito da ordem na composição de uma rotação e de um escalonamento não uniforme.

4.3.3 Transformação inversa

Uma transformação linear invertível permite recuperar de maneira única o vetor original a partir de sua imagem.

Definição 4.2 (Transformação inversa). Uma transformação linear

$$T : V \longrightarrow W$$

é invertível quando existe uma transformação

$$T^{-1} : W \longrightarrow V$$

tal que

$$T^{-1}(T(\mathbf{x})) = \mathbf{x}$$

para todo $\mathbf{x} \in V$ e

$$T(T^{-1}(\mathbf{y})) = \mathbf{y}$$

para todo $\mathbf{y} \in W$.

Considere uma transformação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representada por uma matriz quadrada e invertível

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Se

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

então

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

A transformação inversa é representada por $\mathbf{A}^{-1}$.

Teorema 4.6 (Inversa de uma composição). *Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas e invertíveis de dimensões compatíveis, então*

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

Comprovação. Tem-se

$$\begin{aligned} (\mathbf{BA}) (\mathbf{A}^{-1}\mathbf{B}^{-1}) &= \mathbf{B} (\mathbf{AA}^{-1}) \mathbf{B}^{-1} \\ &= \mathbf{BB}^{-1} \\ &= \mathbf{I}. \end{aligned}$$

De forma análoga,

$$\begin{aligned} (\mathbf{A}^{-1}\mathbf{B}^{-1}) (\mathbf{BA}) &= \mathbf{A}^{-1} (\mathbf{B}^{-1}\mathbf{B}) \mathbf{A} \\ &= \mathbf{A}^{-1}\mathbf{A} \\ &= \mathbf{I}. \end{aligned}$$

Logo,

$$(\mathbf{BA})^{-1} = \mathbf{A}^{-1}\mathbf{B}^{-1}.$$

□

A ordem é invertida porque a última transformação aplicada deve ser a primeira a ser desfeita.

4.3.4 Injetividade, sobrejetividade e bijetividade

As propriedades de injetividade e sobrejetividade descrevem, respectivamente, a possibilidade de distinguir vetores do domínio por suas imagens e a possibilidade de atingir todos os vetores do contradomínio.

Definição 4.3 (Injetividade, sobrejetividade e bijetividade). Uma transformação

$$T : V \longrightarrow W$$

é:

1. **injetiva** quando

$$T(\mathbf{x}_1) = T(\mathbf{x}_2) \implies \mathbf{x}_1 = \mathbf{x}_2;$$

2. **sobrejetiva** quando, para todo $\mathbf{y} \in W$, existe pelo menos um $\mathbf{x} \in V$ tal que

$$T(\mathbf{x}) = \mathbf{y};$$

3. **bijetiva** quando é simultaneamente injetiva e sobrejetiva.

Para uma transformação matricial

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

essas propriedades podem ser caracterizadas pelo núcleo, pelo espaço coluna e pelo posto.

Teorema 4.7 (Caracterizações por núcleo, imagem e posto). *Se*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

então:

1. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\};$$

2. $T_{\mathbf{A}}$ é injetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = p;$$

3. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q;$$

4. $T_{\mathbf{A}}$ é sobrejetiva se, e somente se,

$$\text{posto}(\mathbf{A}) = q.$$

Comprovação. Suponha que $T_{\mathbf{A}}$ seja injetiva. Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{Ax} = \mathbf{0} = \mathbf{A}\mathbf{0}.$$

Pela injetividade,

$$\mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}.$$

Reciprocamente, suponha que

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

e que

$$\mathbf{Ax}_1 = \mathbf{Ax}_2.$$

Então,

$$\mathbf{A}(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}),$$

o que implica

$$\mathbf{x}_1 = \mathbf{x}_2.$$

Assim, $T_{\mathbf{A}}$ é injetiva.

Pelo Teorema 3.12,

$$\dim(\mathcal{N}(\mathbf{A})) + \text{posto}(\mathbf{A}) = p.$$

Logo,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$$

se, e somente se,

$$\text{posto}(\mathbf{A}) = p.$$

A transformação é sobrejetiva quando todo vetor de $\mathbb{R}^q$ pertence à imagem de $T_{\mathbf{A}}$. Como essa imagem é $\mathcal{C}(\mathbf{A})$, a sobrejetividade equivale a

$$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q.$$

Essa igualdade ocorre se, e somente se,

$$\dim(\mathcal{C}(\mathbf{A})) = q,$$

isto é,

$$\text{posto}(\mathbf{A}) = q.$$

□

Uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$ pode ser injetiva somente quando

$$q \geq p.$$

De forma análoga, pode ser sobrejetiva somente quando

$$p \geq q.$$

Se a transformação é bijetiva, então

$$p = q$$

e

$$\text{posto}(\mathbf{A}) = p.$$

Combinando o Teorema 4.7 com o Teorema 2.7, obtém-se o resultado seguinte.

Teorema 4.8 (Equivalências para uma transformação quadrada). *Considere*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e a transformação linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

São equivalentes:

1. $T_{\mathbf{A}}$ é injetiva;
2. $T_{\mathbf{A}}$ é sobrejetiva;
3. $T_{\mathbf{A}}$ é bijetiva;
4. $\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$;
5. $\mathcal{C}(\mathbf{A}) = \mathbb{R}^p$;
6. $\text{posto}(\mathbf{A}) = p$;
7. $\det(\mathbf{A}) \neq 0$;
8. $\mathbf{A}^{-1}$ existe.

(Meyer, 2023)

A Tabela 4.1 resume as relações principais.

Tabela 4.1: Relações entre injetividade, sobrejetividade, bijetividade e posto.

Propriedade	Condição geométrica	Condição matricial
Injetividade	Vetores distintos possuem imagens distintas	$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\}$ e $\text{posto}(\mathbf{A}) = p$
Sobrejetividade	Todo vetor do contradomínio é atingido	$\mathcal{C}(\mathbf{A}) = \mathbb{R}^q$ e $\text{posto}(\mathbf{A}) = q$
Bijetividade	Há correspondência única entre domínio e contradomínio	$p = q = \text{posto}(\mathbf{A})$
Invertibilidade	A transformação pode ser desfeita	$\mathbf{A}$ é quadrada e $\det(\mathbf{A}) \neq 0$

4.3.5 Perda de informação

Quando a transformação não é injetiva, existem vetores distintos com a mesma imagem.

Se

$$\mathbf{v} \in \mathcal{N}(\mathbf{A}),$$

então, para qualquer $\mathbf{x} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{A}(\mathbf{x} + \mathbf{v}) &= \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{v} \\ &= \mathbf{A}\mathbf{x}.\end{aligned}$$

Portanto, todos os vetores do conjunto

$$\mathbf{x} + \mathcal{N}(\mathbf{A}) = \{\mathbf{x} + \mathbf{v} : \mathbf{v} \in \mathcal{N}(\mathbf{A})\}$$

produzem a mesma imagem.

Reciprocamente, se

$$\mathbf{A}\mathbf{x}_1 = \mathbf{A}\mathbf{x}_2,$$

então

$$\mathbf{x}_1 - \mathbf{x}_2 \in \mathcal{N}(\mathbf{A}).$$

A ambiguidade na recuperação do vetor original é, assim, determinada pelo espaço nulo. Se

$$\text{posto}(\mathbf{A}) = r,$$

o Teorema Posto–Nulidade fornece

$$\dim(\mathcal{N}(\mathbf{A})) = p - r.$$

A transformação elimina $p - r$ direções independentes e produz uma imagem de dimensão r .

4.3.6 Redução de dimensionalidade

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com

$$q < p.$$

Mesmo que

$$\text{posto}(\mathbf{A}) = q,$$

tem-se

$$\dim(\mathcal{N}(\mathbf{A})) = p - q > 0.$$

A perda de informação é inevitável quando a transformação é considerada sobre todo o espaço $\mathbb{R}^p$. Entretanto, sua restrição a um conjunto particular ou a um subespaço de dimensão menor ou igual a q pode ser injetiva. Assim, reduzir o número de coordenadas não implica necessariamente identificar observações distintas no conjunto de dados efetivamente analisado.

A redução pode ser útil quando a matriz é escolhida para preservar determinadas direções e eliminar outras. O critério utilizado para selecionar essas direções será desenvolvido posteriormente, no contexto das técnicas multivariadas.

4.3.7 Transformações singulares

Uma matriz quadrada é singular quando

$$\det(\mathbf{A}) = 0.$$

Nesse caso,

$$\text{posto}(\mathbf{A}) < p,$$

e a transformação leva $\mathbb{R}^p$ a um subespaço de menor dimensão.

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

transforma

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

em

$$\begin{bmatrix} x_1 \\ 0 \end{bmatrix}.$$

Todos os pontos com a mesma primeira coordenada produzem a mesma imagem.

A Figura 4.4 compara uma transformação invertível, a recuperação pela inversa e uma transformação singular.

A transformação representada por $\mathbf{A}$ modifica a configuração, mas mantém uma correspondência única entre os pontos originais e transformados. A aplicação de $\mathbf{A}^{-1}$ recupera a configuração inicial. A transformação singular elimina a segunda coordenada e reduz toda a nuvem a uma reta.

Para

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

as possibilidades podem ser resumidas da seguinte forma:




Figura 4.4: Transformação invertível, recuperação pela inversa e colapso provocado por uma transformação singular.

- se $q < p$, a transformação não pode ser injetiva;
- se $q > p$, a transformação não pode ser sobrejetiva;
- se $q = p$, ela é bijetiva quando $\text{posto}(\mathbf{A}) = p$;
- se $\text{posto}(\mathbf{A}) < \min(p, q)$, ela não é injetiva nem sobrejetiva.

Essas relações permitem interpretar o posto como o número de direções independentes preservadas na imagem. A seção seguinte examina os efeitos geométricos produzidos por classes particulares de matrizes.

4.4 Transformações geométricas

Matrizes distintas produzem efeitos geométricos diferentes sobre vetores e conjuntos de pontos. Algumas modificam apenas a orientação da configuração, enquanto outras alteram comprimentos, ângulos, áreas ou dimensão.

Nesta seção, são examinadas cinco transformações no plano:

- rotação;
- reflexão;
- escalonamento;
- cisalhamento;
- projeção.

Todas preservam combinações lineares e, portanto, são transformações lineares. As propriedades geométricas preservadas dependem da matriz utilizada.

4.4.1 Rotação

Uma rotação de ângulo θ em torno da origem é representada por

$$\mathbf{Q}(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

a imagem é

$$\mathbf{y} = \mathbf{Q}(\theta)\mathbf{x},$$

isto é,

$$\begin{aligned} y_1 &= x_1 \cos \theta - x_2 \sin \theta, \\ y_2 &= x_1 \sin \theta + x_2 \cos \theta. \end{aligned}$$

A matriz de rotação satisfaz

$$\mathbf{Q}(\theta)^\top \mathbf{Q}(\theta) = \mathbf{I}_2.$$

Consequentemente,

$$\mathbf{Q}(\theta)^{-1} = \mathbf{Q}(\theta)^\top = \mathbf{Q}(-\theta).$$

A transformação inversa corresponde a uma rotação pelo mesmo ângulo no sentido oposto.

Além disso,

$$\det(\mathbf{Q}(\theta)) = 1.$$

A rotação preserva comprimentos, distâncias, ângulos, áreas e orientação.

4.4.2 Reflexão

Uma reflexão no plano produz a imagem especular dos vetores em relação a uma reta que passa pela origem.

A reflexão em relação ao eixo horizontal é representada por

$$\mathbf{F}_1 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix},$$

de modo que

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} x_1 \\ -x_2 \end{bmatrix}.$$

A reflexão em relação ao eixo vertical é representada por

$$\mathbf{F}_2 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

e produz

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} -x_1 \\ x_2 \end{bmatrix}.$$

As duas matrizes satisfazem

$$\mathbf{F}^\top \mathbf{F} = \mathbf{I}_2$$

e

$$\mathbf{F}^{-1} = \mathbf{F}.$$

Assim,

$$\mathbf{F}^2 = \mathbf{I}_2.$$

Aplicar duas vezes a mesma reflexão recupera o vetor original.

Considere agora uma reta gerada por um vetor unitário

$$\mathbf{u} \in \mathbb{R}^2, \quad \|\mathbf{u}\| = 1.$$

A projeção de $\mathbf{x}$ sobre essa reta é

$$\mathbf{u}\mathbf{u}^\top \mathbf{x},$$

enquanto sua componente ortogonal é

$$(\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x}.$$

Na reflexão, a componente paralela é preservada e a componente ortogonal tem seu sinal invertido:

$$\begin{aligned} \mathbf{x}_{\text{ref}} &= \mathbf{u}\mathbf{u}^\top \mathbf{x} - (\mathbf{I}_2 - \mathbf{u}\mathbf{u}^\top) \mathbf{x} \\ &= (2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2) \mathbf{x}. \end{aligned}$$

Portanto, a reflexão em relação à reta gerada por $\mathbf{u}$ é representada por

$$\mathbf{F}_{\mathbf{u}} = 2\mathbf{u}\mathbf{u}^\top - \mathbf{I}_2.$$

Essa matriz satisfaz

$$\mathbf{F}_{\mathbf{u}}^\top \mathbf{F}_{\mathbf{u}} = \mathbf{I}_2$$

e

$$\det(\mathbf{F}_{\mathbf{u}}) = -1.$$

A reflexão preserva comprimentos, distâncias, ângulos e áreas, mas inverte a orientação.

Em dimensão p , a matriz

$$\mathbf{H}_{\mathbf{u}} = \mathbf{I}_p - 2\mathbf{u}\mathbf{u}^\top, \quad \|\mathbf{u}\| = 1,$$

representa a reflexão em relação ao hiperplano ortogonal a $\mathbf{u}$. Essa transformação é denominada reflexão de Householder.

4.4.3 Escalonamento

Um escalonamento modifica o comprimento dos vetores ao longo de direções determinadas.

No plano, o escalonamento em relação aos eixos coordenados é representado por

$$\mathbf{L} = \begin{bmatrix} s_1 & 0 \\ 0 & s_2 \end{bmatrix}.$$

A transformação correspondente é

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \mapsto \begin{bmatrix} s_1 x_1 \\ s_2 x_2 \end{bmatrix}.$$

Quando

$$s_1 = s_2 = s,$$

o escalonamento é uniforme:

$$\mathbf{L} = s\mathbf{I}_2.$$

Nesse caso, todos os comprimentos e todas as distâncias são multiplicados por $|s|$. Para $s \neq 0$, os ângulos são preservados.

Quando

$$s_1 \neq s_2,$$

o escalonamento é não uniforme. Cada direção coordenada é ampliada ou comprimida por um fator diferente, de modo que comprimentos, ângulos e proporções podem ser alterados.

O determinante da matriz é

$$\det(\mathbf{L}) = s_1 s_2.$$

A área de uma figura é, portanto, multiplicada por

$$|s_1 s_2|.$$

A transformação é invertível quando

$$s_1 \neq 0 \quad \text{e} \quad s_2 \neq 0.$$

Nesse caso,

$$\mathbf{L}^{-1} = \begin{bmatrix} 1/s_1 & 0 \\ 0 & 1/s_2 \end{bmatrix}.$$

Se algum fator de escala for igual a zero, uma direção é eliminada. Por exemplo,

$$\mathbf{L} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

leva todo o plano ao eixo horizontal.

O escalonamento das variáveis será retomado na seção sobre pré-processamento.

4.4.4 Cisalhamento

Um cisalhamento modifica uma coordenada adicionando a ela uma parcela proporcional a outra coordenada.

O cisalhamento horizontal é representado por

$$\mathbf{C}_{12}(k) = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}.$$

Nesse caso,

$$\begin{aligned} y_1 &= x_1 + kx_2, \\ y_2 &= x_2. \end{aligned}$$

A segunda coordenada permanece inalterada, enquanto a primeira é modificada de acordo com o valor de x_2 .

O cisalhamento vertical é representado por

$$\mathbf{C}_{21}(k) = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix},$$

e produz

$$\begin{aligned}y_1 &= x_1, \\y_2 &= kx_1 + x_2.\end{aligned}$$

Em dimensão p , um cisalhamento elementar pode ser escrito como

$$\mathbf{C}_{ij}(k) = \mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top, \quad i \neq j.$$

Essa transformação adiciona à coordenada i uma parcela proporcional à coordenada j .

Como

$$\left(\mathbf{e}_i\mathbf{e}_j^\top\right)^2 = \mathbf{0}$$

para $i \neq j$, tem-se

$$\begin{aligned}\mathbf{C}_{ij}(k)\mathbf{C}_{ij}(-k) &= \left(\mathbf{I}_p + k\mathbf{e}_i\mathbf{e}_j^\top\right)\left(\mathbf{I}_p - k\mathbf{e}_i\mathbf{e}_j^\top\right) \\ &= \mathbf{I}_p.\end{aligned}$$

Portanto,

$$\mathbf{C}_{ij}(k)^{-1} = \mathbf{C}_{ij}(-k).$$

O determinante de um cisalhamento elementar é

$$\det\left(\mathbf{C}_{ij}(k)\right) = 1.$$

Assim, o cisalhamento preserva áreas e volumes, mas altera comprimentos e ângulos. Retas e paralelismo são preservados.

4.4.5 Projeção

Uma projeção mantém a componente de um vetor pertencente a um subespaço e elimina a componente ortogonal.

Para uma direção unitária $\mathbf{u} \in \mathbb{R}^p$, a matriz de projeção é

$$\mathbf{P}_{\mathbf{u}} = \mathbf{u}\mathbf{u}^{\top}.$$

A imagem de $\mathbf{x}$ é

$$\mathbf{P}_{\mathbf{u}}\mathbf{x} = (\mathbf{u}^{\top}\mathbf{x})\mathbf{u}.$$

Como estudado no Capítulo 3,

$$\mathbf{P}_{\mathbf{u}}^2 = \mathbf{P}_{\mathbf{u}}$$

e

$$\mathbf{P}_{\mathbf{u}}^{\top} = \mathbf{P}_{\mathbf{u}}.$$

Se $p > 1$, a projeção sobre uma única direção possui posto 1. Consequentemente,

$$\det(\mathbf{P}_{\mathbf{u}}) = 0.$$

A projeção é uma transformação linear não invertível. Vetores que possuem a mesma componente na direção de $\mathbf{u}$ são enviados ao mesmo ponto.

4.4.6 Comparação geométrica

A Figura 4.5 mostra o efeito das transformações anteriores sobre o quadrado unitário.

A rotação gira o quadrado em relação aos eixos coordenados sem alterar sua forma, sua área ou sua orientação. A reflexão preserva a forma e a área, mas inverte a orientação. O escalonamento não uniforme transforma o quadrado em um retângulo. O cisalhamento transforma o quadrado em um paralelogramo com a mesma área. A projeção reduz a figura a um segmento de reta.




Figura 4.5: Efeito de diferentes transformações lineares sobre o quadrado unitário.

4.4.7 Determinante, volume e orientação

Para uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o valor absoluto do determinante representa o fator pelo qual volumes são multiplicados.

Teorema 4.9 (Alteração de volume por uma transformação linear). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e seja $E \subseteq \mathbb{R}^p$ um conjunto mensurável. Denote por

$$\mathbf{A}E = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in E\}$$

sua imagem pela transformação linear representada por $\mathbf{A}$.

Então,

$$\text{Vol}_p(\mathbf{A}E) = |\det(\mathbf{A})| \text{Vol}_p(E),$$

em que Vol_p representa o volume p -dimensional.

Se $\det(\mathbf{A}) = 0$, a imagem está contida em um subespaço de dimensão inferior a p e seu volume p -dimensional é igual a zero.

A demonstração formal desse resultado, baseada no Jacobiano de uma transformação linear, será apresentada no capítulo dedicado ao cálculo multivariado.

No plano, o resultado descreve a alteração de área. Em $\mathbb{R}^3$, descreve a alteração de volume. Em dimensão geral, descreve a alteração do hipervolume.

O sinal do determinante descreve a orientação:

- se $\det(\mathbf{A}) > 0$, a orientação é preservada;
- se $\det(\mathbf{A}) < 0$, a orientação é invertida;
- se $\det(\mathbf{A}) = 0$, ocorre redução de dimensão.

A Tabela 4.2 resume as propriedades das transformações estudadas.

Tabela 4.2: Propriedades das principais transformações geométricas no plano.

Transformação	Matriz no plano	Determinante	Efeito geométrico
Rotação	$\mathbf{Q}(\theta)$	1	Gira a configuração
Reflexão	$\mathbf{F}$	-1	Produz uma imagem especular
Escalonamento	$\text{diag}(s_1, s_2)$	$s_1 s_2$	Amplia ou comprime direções
Cisalhamento	$\begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$	1	Inclina a configuração
Projeção sobre uma reta	$\mathbf{u}\mathbf{u}^\top$	0	Elimina uma direção

A preservação de área ou volume não implica preservação de distâncias e ângulos. O cisalhamento possui determinante igual a 1, mas deforma a configuração. A preservação integral da geometria euclidiana será estudada na seção seguinte.

4.5 Transformações ortogonais

A linearidade não garante a preservação de comprimentos, distâncias ou ângulos. Essas propriedades são preservadas pelas transformações representadas por matrizes ortogonais.

Retomando a Definição 2.17, uma matriz

$$\mathbf{Q} \in \mathbb{R}^{p \times p}$$

é ortogonal quando

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Essa condição implica

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p.$$

A transformação

$$T_{\mathbf{Q}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{Q}}(\mathbf{x}) = \mathbf{Q}\mathbf{x},$$

é denominada **transformação ortogonal**.

Pelo Teorema 2.9, para quaisquer vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = \mathbf{x}^\top \mathbf{y}.$$

Assim, a transformação preserva o produto interno entre todos os pares de vetores.

Tomando $\mathbf{y} = \mathbf{x}$,

$$\begin{aligned} \|\mathbf{Q}\mathbf{x}\|^2 &= (\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^\top \mathbf{x} \\ &= \|\mathbf{x}\|^2. \end{aligned}$$

Portanto,

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Para dois vetores $\mathbf{x}$ e $\mathbf{y}$,

$$\begin{aligned} \|\mathbf{Q}\mathbf{x} - \mathbf{Q}\mathbf{y}\| &= \|\mathbf{Q}(\mathbf{x} - \mathbf{y})\| \\ &= \|\mathbf{x} - \mathbf{y}\|. \end{aligned}$$

Logo, todas as distâncias euclidianas são preservadas.

Para vetores não nulos, o ângulo θ é determinado por

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Como os produtos internos e as normas permanecem inalterados,

$$\frac{(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y})}{\|\mathbf{Q}\mathbf{x}\| \|\mathbf{Q}\mathbf{y}\|} = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, os ângulos também são preservados. Em particular,

$$\mathbf{x}^\top \mathbf{y} = 0$$

implica

$$(\mathbf{Q}\mathbf{x})^\top (\mathbf{Q}\mathbf{y}) = 0.$$

Transformações ortogonais preservam, assim:

- produtos internos;
- normas;
- distâncias;
- ângulos;
- ortogonalidade;
- áreas e volumes.

Elas podem modificar a orientação da configuração, mas não alteram suas relações métricas internas.

4.5.1 Transformação de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e uma transformação ortogonal representada por

$$\mathbf{Q} \in \mathbb{R}^{p \times p}.$$

Como as observações estão organizadas nas linhas, a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

Teorema 4.10 (Preservação da matriz de Gram). *Se*

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$$

e $\mathbf{Q}$ é ortogonal, então

$$\mathbf{Y}\mathbf{Y}^\top = \mathbf{X}\mathbf{X}^\top.$$

Comprovação. Tem-se

$$\begin{aligned}\mathbf{Y}\mathbf{Y}^\top &= (\mathbf{X}\mathbf{Q}^\top)(\mathbf{X}\mathbf{Q}^\top)^\top \\ &= \mathbf{X}\mathbf{Q}^\top\mathbf{Q}\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{I}_p\mathbf{X}^\top \\ &= \mathbf{X}\mathbf{X}^\top.\end{aligned}$$

□

A matriz de Gram reúne os produtos internos entre as observações. Sua preservação implica que permanecem inalterados:

- os quadrados das normas das observações;
- os produtos internos entre pares de observações;
- as distâncias entre as observações;
- os ângulos entre os vetores observados.

A nuvem de pontos pode ser rotacionada ou refletida, mas sua forma e suas relações internas permanecem as mesmas.

4.5.2 Determinante e orientação

Como

$$\mathbf{Q}^\top\mathbf{Q} = \mathbf{I}_p,$$

tem-se

$$\begin{aligned}1 &= \det(\mathbf{Q}^\top\mathbf{Q}) \\ &= \det(\mathbf{Q}^\top)\det(\mathbf{Q}) \\ &= \det(\mathbf{Q})^2.\end{aligned}$$

Portanto,

$$\det(\mathbf{Q}) = 1 \quad \text{ou} \quad \det(\mathbf{Q}) = -1.$$

Como

$$|\det(\mathbf{Q})| = 1,$$

áreas e volumes são preservados.

Quando

$$\det(\mathbf{Q}) = 1,$$

a transformação é denominada **ortogonal própria**. Ela preserva a orientação.

No plano, toda transformação ortogonal própria é uma rotação e pode ser representada por

$$\mathbf{Q} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Quando

$$\det(\mathbf{Q}) = -1,$$

a transformação é denominada **ortogonal imprópria**. Ela inverte a orientação.

No plano, toda transformação ortogonal imprópria corresponde a uma reflexão em relação a uma reta que passa pela origem. Em dimensões superiores, pode combinar uma reflexão com rotações em subespaços ortogonais.

4.5.3 Matrizes ortogonais e bases ortonormais

As colunas de uma matriz ortogonal formam uma base ortonormal de $\mathbb{R}^p$.

Se

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p],$$

então

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Como

$$\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}_p,$$

as linhas de $\mathbf{Q}$ também são ortonormais.

A mesma matriz pode ser interpretada de duas formas:

- como uma transformação que preserva a geometria euclidiana;
- como uma base ortonormal organizada em suas colunas.

A relação entre essas interpretações será desenvolvida na seção sobre mudanças de coordenadas.

4.5.4 Comparação com transformações não ortogonais

A Figura 4.6 compara o efeito de diferentes matrizes sobre a circunferência unitária e sobre duas direções ortogonais.




Figura 4.6: Efeito de transformações ortogonais e não ortogonais sobre a circunferência unitária e duas direções ortogonais.

A rotação e a reflexão mantêm a circunferência unitária e o ângulo reto entre as direções. O escalonamento transforma a circunferência em uma elipse. O cisalhamento também deforma a circunferência e altera o ângulo entre os vetores.

A Tabela 4.3 compara as propriedades dessas transformações.

Tabela 4.3: Comparação entre transformações ortogonais e não ortogonais.

Transformação	Ortogonal	Preserva normas	Preserva distâncias	Preserva ângulos	$ \det(\mathbf{A}) $
Rotação	Sim	Sim	Sim	Sim	1
Reflexão	Sim	Sim	Sim	Sim	1
Escalonamento uniforme	Somente se $ s = 1$	Somente se $ s = 1$	Somente se $ s = 1$	Sim, se $s \neq 0$	$ s ^p$
Escalonamento não uniforme	Não	Não	Não	Não, em geral	$\prod_j s_j $
Cisalhamento	Não	Não	Não	Não, em geral	1
Projeção própria	Não	Não	Não	Não, em geral	0

A condição

$$|\det(\mathbf{A})| = 1$$

não é suficiente para que uma matriz seja ortogonal. O cisalhamento possui determinante igual a 1 e preserva áreas, mas não preserva normas nem ângulos.

A condição que caracteriza a preservação da geometria euclidiana é

$$\mathbf{A}^\top \mathbf{A} = \mathbf{I}_p.$$

4.6 Mudanças de coordenadas e representação em bases

O Capítulo 3 mostrou que um vetor possui coordenadas diferentes quando é representado em bases distintas. O vetor geométrico permanece o mesmo; o que muda é o conjunto de coeficientes utilizado para descrevê-lo.

Retomando a Definição 3.6, seja

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

uma base de $\mathbb{R}^p$. Organizando seus vetores nas colunas de uma matriz, define-se

$$\mathbf{P}_{\mathcal{B}} = [\mathbf{b}_1 \quad \cdots \quad \mathbf{b}_p].$$

Como os vetores de $\mathcal{B}$ são linearmente independentes,

$$\mathbf{P}_{\mathcal{B}}$$

é invertível.

Se

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

é o vetor de coordenadas de $\mathbf{x}$ na base $\mathcal{B}$, então

$$\mathbf{x} = c_1 \mathbf{b}_1 + \cdots + c_p \mathbf{b}_p.$$

Em forma matricial,

$$\mathbf{x} = \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

Consequentemente,

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{P}_{\mathcal{B}}^{-1} \mathbf{x}.$$

A matriz $\mathbf{P}_{\mathcal{B}}$ converte coordenadas na base $\mathcal{B}$ em coordenadas canônicas. Sua inversa realiza a conversão no sentido contrário.

Quando $\mathcal{B}$ é uma base ortonormal, pela Definição 3.9,

$$\mathbf{P}_{\mathcal{B}}^{\top} \mathbf{P}_{\mathcal{B}} = \mathbf{I}_p.$$

Logo,

$$\mathbf{P}_{\mathcal{B}}^{-1} = \mathbf{P}_{\mathcal{B}}^{\top}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{P}_{\mathcal{B}}^{\top} \mathbf{x}.$$

Nesse caso,

$$[\mathbf{x}]_{\mathcal{B}} = \begin{bmatrix} \mathbf{b}_1^{\top} \mathbf{x} \\ \vdots \\ \mathbf{b}_p^{\top} \mathbf{x} \end{bmatrix}.$$

Cada coordenada é o produto interno entre o vetor e uma direção da base.

4.6.1 Conversão entre duas bases

Considere duas bases de $\mathbb{R}^p$:

$$\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$$

e

$$\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_p\}.$$

O mesmo vetor pode ser representado por

$$\mathbf{x} = \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}$$

e por

$$\mathbf{x} = \mathbf{P}_{\mathcal{C}} [\mathbf{x}]_{\mathcal{C}}.$$

Igualando as duas expressões,

$$\mathbf{P}_{\mathcal{C}} [\mathbf{x}]_{\mathcal{C}} = \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

Multiplicando por $\mathbf{P}_{\mathcal{C}}^{-1}$,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{P}_{\mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

Definição 4.4 (Matriz de mudança de base). A matriz que converte coordenadas da base $\mathcal{B}$ para a base $\mathcal{C}$ é

$$\mathbf{P}_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{P}_{\mathcal{B}}.$$

Assim,

$$[\mathbf{x}]_{\mathcal{C}} = \mathbf{P}_{\mathcal{C} \leftarrow \mathcal{B}} [\mathbf{x}]_{\mathcal{B}}.$$

A seta indica o sentido da conversão:

$$\mathcal{B} \longrightarrow \mathcal{C}.$$

A conversão no sentido contrário é dada por

$$\mathbf{P}_{\mathcal{B} \leftarrow \mathcal{C}} = \mathbf{P}_{\mathcal{B}}^{-1} \mathbf{P}_{\mathcal{C}}.$$

As duas matrizes são inversas:

$$\mathbf{P}_{\mathcal{B} \leftarrow \mathcal{C}} = (\mathbf{P}_{\mathcal{C} \leftarrow \mathcal{B}})^{-1}.$$

4.6.2 Representação de uma transformação em bases gerais

Considere uma transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

representada nas bases canônicas por

$$\mathbf{y} = \mathbf{A}\mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{q \times p}.$$

Seja $\mathcal{B}$ uma base do domínio e $\mathcal{C}$ uma base do contradomínio. As coordenadas canônicas do vetor de entrada são

$$\mathbf{x} = \mathbf{P}_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}},$$

enquanto as coordenadas da imagem na base $\mathcal{C}$ são

$$[T(\mathbf{x})]_{\mathcal{C}} = \mathbf{P}_{\mathcal{C}}^{-1}T(\mathbf{x}).$$

Substituindo a representação matricial de T ,

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= \mathbf{P}_{\mathcal{C}}^{-1}\mathbf{A}\mathbf{x} \\ &= \mathbf{P}_{\mathcal{C}}^{-1}\mathbf{A}\mathbf{P}_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}}. \end{aligned}$$

Teorema 4.11 (Matriz de uma transformação em bases gerais). *Se uma transformação linear*

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é representada nas bases canônicas por $\mathbf{A}$, sua matriz em relação à base $\mathcal{B}$ do domínio e à base $\mathcal{C}$ do contradomínio é

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{P}_{\mathcal{C}}^{-1}\mathbf{A}\mathbf{P}_{\mathcal{B}}.$$

Para todo $\mathbf{x} \in \mathbb{R}^p$,

$$[T(\mathbf{x})]_{\mathcal{C}} = [T]_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}.$$

(Meyer, 2023)

As colunas de

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}}$$

são as coordenadas, na base $\mathcal{C}$, das imagens dos vetores da base $\mathcal{B}$:

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_p)]_{\mathcal{C}} \end{bmatrix}.$$

Essa construção generaliza a representação matricial nas bases canônicas.

Exemplo 4.3 (Representação de uma transformação em bases distintas). Considere

$$T : \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

representada na base canônica por

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}.$$

Considere a base do domínio

$$\mathcal{B} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e a base do contradomínio

$$\mathcal{C} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

As matrizes das bases são

$$\mathbf{P}_{\mathcal{B}} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

e

$$\mathbf{P}_{\mathcal{C}} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

Como

$$\mathbf{P}_{\mathcal{C}}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} [T]_{\mathcal{C} \leftarrow \mathcal{B}} &= \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{A} \mathbf{P}_{\mathcal{B}} \\ &= \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}. \end{aligned}$$

A primeira coluna é

$$[T(\mathbf{b}_1)]_{\mathcal{C}} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

e a segunda é

$$[T(\mathbf{b}_2)]_{\mathcal{C}} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

4.6.3 Representação de um operador em uma nova base

Considere um operador linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

representado na base canônica por $\mathbf{A}$.

Quando a mesma base $\mathcal{B}$ é utilizada no domínio e no contradomínio, a matriz do operador nessa base é

$$\mathbf{A}_{\mathcal{B}} = \mathbf{P}_{\mathcal{B}}^{-1} \mathbf{A} \mathbf{P}_{\mathcal{B}}.$$

Definição 4.5 (Matrizes semelhantes). Duas matrizes quadradas $\mathbf{A}$ e $\mathbf{B}$ são **semelhantes** quando existe uma matriz invertível $\mathbf{P}$ tal que

$$\mathbf{B} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P}.$$

Matrizes semelhantes representam o mesmo operador linear em bases diferentes. Por essa razão, preservam propriedades que não dependem do sistema de coordenadas.

Teorema 4.12 (Invariantes por semelhança). *Sejam*

$$\mathbf{A}, \mathbf{B}, \mathbf{P} \in \mathbb{R}^{p \times p},$$

com $\mathbf{P}$ invertível. Se

$$\mathbf{B} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

então

$$\det(\mathbf{B}) = \det(\mathbf{A}),$$

$$\text{tr}(\mathbf{B}) = \text{tr}(\mathbf{A})$$

e

$$\text{posto}(\mathbf{B}) = \text{posto}(\mathbf{A}).$$

(Horn; Johnson, 2013)

Comprovação. Para o determinante,

$$\begin{aligned}\det(\mathbf{B}) &= \det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) \\ &= \det(\mathbf{P}^{-1})\det(\mathbf{A})\det(\mathbf{P}) \\ &= \det(\mathbf{A}).\end{aligned}$$

Para o traço, pela propriedade cíclica,

$$\begin{aligned}\text{tr}(\mathbf{B}) &= \text{tr}(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) \\ &= \text{tr}(\mathbf{A}\mathbf{P}\mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A}).\end{aligned}$$

Como a multiplicação à esquerda ou à direita por uma matriz invertível não altera o posto,

$$\text{posto}(\mathbf{P}^{-1}\mathbf{A}\mathbf{P}) = \text{posto}(\mathbf{A}).$$

□

A relação entre matrizes semelhantes, autovalores e a representação das direções invariantes em bases diferentes será desenvolvida no capítulo seguinte.

4.6.4 Transformação ativa e mudança passiva

Uma matriz pode representar a transformação de um vetor ou a alteração do sistema de coordenadas utilizado para descrevê-lo. Essas operações são relacionadas, mas não são idênticas.

Em uma **transformação ativa**, os eixos coordenados permanecem fixos e o vetor é modificado:

$$\mathbf{y} = \mathbf{Q}\mathbf{x}.$$

No caso de uma rotação, o vetor muda de posição em relação aos mesmos eixos.

Em uma **mudança passiva de coordenadas**, o vetor geométrico permanece fixo e a base é alterada.

Se as colunas de uma matriz ortogonal $\mathbf{Q}$ formam a nova base

$$\mathcal{B} = \{\mathbf{q}_1, \dots, \mathbf{q}_p\},$$

então

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x} = \mathbf{Q}^{-1} \mathbf{x}.$$

O vetor não se move. Apenas sua representação numérica é modificada.

Para a matriz de rotação $\mathbf{Q}(\theta)$,

$$\mathbf{Q}(\theta)^{-1} = \mathbf{Q}(\theta)^{\top} = \mathbf{Q}(-\theta).$$

Girar os eixos pelo ângulo θ transforma as coordenadas do vetor por uma rotação de ângulo $-\theta$.

A transformação ativa e a mudança passiva utilizam matrizes inversas:

$$\text{transformação ativa:} \quad \mathbf{y} = \mathbf{Q}\mathbf{x},$$

$$\text{mudança passiva:} \quad [\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{-1} \mathbf{x}.$$

Quando $\mathbf{Q}$ é ortogonal,

$$\mathbf{Q}^{-1} = \mathbf{Q}^{\top}.$$




Figura 4.7: Comparação entre uma transformação ativa e uma mudança passiva de coordenadas.

A Figura 4.7 compara as duas interpretações.

No primeiro painel, os eixos permanecem fixos e $\mathbf{x}$ é transformado em $\mathbf{Q}\mathbf{x}$. No segundo, o vetor permanece fixo e os novos eixos são definidos por $\mathbf{q}_1$ e $\mathbf{q}_2$.

4.6.5 Mudança de coordenadas de uma matriz de dados

Considere

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

com as observações organizadas nas linhas, e uma base ortonormal cujos vetores estão nas colunas de $\mathbf{Q}$.

As coordenadas da i -ésima observação na nova base são

$$\mathbf{z}_i = \mathbf{Q}^\top \mathbf{x}_i.$$

Transpondo,

$$\mathbf{z}_i^\top = \mathbf{x}_i^\top \mathbf{Q}.$$

Portanto, a matriz de novas coordenadas é

$$\mathbf{Z} = \mathbf{X}\mathbf{Q}.$$

Essa expressão deve ser distinguida da transformação ativa por $\mathbf{Q}$, que produz

$$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top.$$

A Tabela 4.4 resume as duas operações.

Tabela 4.4: Transformação ativa e mudança passiva para uma base ortonormal.

Operação	Vetor-coluna	Matriz de dados
Transformação ativa	$\mathbf{y} = \mathbf{Q}\mathbf{x}$	$\mathbf{Y} = \mathbf{X}\mathbf{Q}^\top$
Mudança passiva para a base de $\mathbf{Q}$	$\mathbf{z} = \mathbf{Q}^\top \mathbf{x}$	$\mathbf{Z} = \mathbf{X}\mathbf{Q}$

Na transformação ativa, a configuração é modificada em relação a um sistema de coordenadas fixo. Na mudança passiva, a configuração permanece a mesma e cada observação passa a ser descrita pelas coordenadas em uma nova base.

4.7 Transformações afins e pré-processamento

Toda transformação linear mantém o vetor nulo fixo:

$$T(\mathbf{0}) = \mathbf{0}.$$

Operações que incluem um deslocamento constante não satisfazem essa propriedade. Elas pertencem a uma classe mais ampla, formada pelas transformações afins.

Definição 4.6 (Transformação afim). Uma aplicação

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

é uma **transformação afim** quando pode ser escrita como

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A matriz $\mathbf{A}$ determina a parte linear da transformação, enquanto $\mathbf{b}$ determina o deslocamento.

Quando

$$\mathbf{b} = \mathbf{0},$$

a transformação afim reduz-se a uma transformação linear.

Quando

$$\mathbf{b} \neq \mathbf{0},$$

tem-se

$$T(\mathbf{0}) = \mathbf{b} \neq \mathbf{0},$$

e a transformação não é linear.

4.7.1 Translação

A translação é o caso particular

$$T(\mathbf{x}) = \mathbf{x} + \mathbf{b}.$$

Todos os pontos são deslocados pelo mesmo vetor $\mathbf{b}$.

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_j$,

$$\begin{aligned} T(\mathbf{x}_i) - T(\mathbf{x}_j) &= (\mathbf{x}_i + \mathbf{b}) - (\mathbf{x}_j + \mathbf{b}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Consequentemente,

$$\|T(\mathbf{x}_i) - T(\mathbf{x}_j)\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

A translação preserva:

- diferenças entre os pontos;
- distâncias;
- ângulos entre segmentos;
- forma;
- áreas e volumes.

Ela modifica apenas a posição da configuração em relação à origem.

4.7.2 Transformação afim de uma matriz de dados

Considere uma transformação afim aplicada a cada observação:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i + \mathbf{b}.$$

Se as observações estão organizadas nas linhas de

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a matriz transformada é

$$\mathbf{Y} = \mathbf{X}\mathbf{A}^\top + \mathbf{1}_n \mathbf{b}^\top,$$

em que

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n.$$

A matriz

$$\mathbf{1}_n \mathbf{b}^\top$$

possui n linhas iguais a $\mathbf{b}^\top$. Assim, o mesmo deslocamento é acrescentado a todas as observações.

No caso de uma translação pura,

$$\mathbf{A} = \mathbf{I}_p,$$

e

$$\mathbf{Y} = \mathbf{X} + \mathbf{1}_n \mathbf{b}^\top.$$

4.7.3 Centralização

A centralização desloca uma configuração para que um vetor de localização coincida com a origem.

Para um vetor fixo

$$\mathbf{m} \in \mathbb{R}^p,$$

define-se

$$\mathbf{x}_c = \mathbf{x} - \mathbf{m}.$$

Essa operação é afim:

$$T(\mathbf{x}) = \mathbf{I}_p \mathbf{x} - \mathbf{m}.$$

Quando

$$\mathbf{m} \neq \mathbf{0},$$

ela não é linear, pois

$$T(\mathbf{0}) = -\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

a centralização por $\mathbf{m}$ é

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \mathbf{m}^\top.$$

Quando o vetor de localização é a média amostral,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i,$$

tem-se

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top.$$

Retomando a matriz de centralização,

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top,$$

a matriz centralizada pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

De fato,

$$\begin{aligned} \mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\ &= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{1}_n^\top \mathbf{X} \right) \\ &= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \end{aligned}$$

A centralização de cada observação em torno de um vetor fixo é uma transformação afim. A aplicação

$$\mathbf{X} \mapsto \mathbf{H}_n \mathbf{X}$$

sobre o espaço das matrizes de dados é linear, pois $\mathbf{H}_n$ é uma matriz fixa.

Como

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0},$$

tem-se

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Portanto, cada coluna de $\mathbf{X}_c$ possui média igual a zero.

Teorema 4.13 (Preservação das distâncias pela centralização). *Se*

$$\mathbf{x}_{ci} = \mathbf{x}_i - \mathbf{m}$$

e

$$\mathbf{x}_{cj} = \mathbf{x}_j - \mathbf{m},$$

então

$$\|\mathbf{x}_{ci} - \mathbf{x}_{cj}\| = \|\mathbf{x}_i - \mathbf{x}_j\|.$$

Comprovação. Tem-se

$$\begin{aligned} \mathbf{x}_{ci} - \mathbf{x}_{cj} &= (\mathbf{x}_i - \mathbf{m}) - (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{x}_i - \mathbf{x}_j. \end{aligned}$$

Logo, as duas diferenças possuem a mesma norma. □

A centralização modifica a posição da nuvem em relação à origem, mas preserva sua configuração interna.

4.7.4 Escalonamento das variáveis

Considere uma matriz diagonal

$$\mathbf{L} = \text{diag}(\ell_1, \dots, \ell_p),$$

com

$$\ell_j > 0, \quad j = 1, \dots, p.$$

A transformação

$$\mathbf{y} = \mathbf{L}^{-1}\mathbf{x}$$

divide cada coordenada por sua escala correspondente:

$$y_j = \frac{x_j}{\ell_j}.$$

Essa operação é linear e, para uma matriz de dados, assume a forma

$$\mathbf{Y} = \mathbf{X}\mathbf{L}^{-1}.$$

A multiplicação ocorre à direita porque as variáveis ocupam as colunas de $\mathbf{X}$.

Quando as escalas são diferentes, o escalonamento modifica distâncias e ângulos. Para duas observações,

$$\|\mathbf{L}^{-1}\mathbf{x}_i - \mathbf{L}^{-1}\mathbf{x}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

O escalonamento induz, no espaço original, a geometria determinada por

$$\mathbf{L}^{-2}.$$

Variáveis associadas a escalas menores recebem maior peso nas distâncias transformadas.

4.7.5 Padronização

A padronização combina centralização e escalonamento.

Para um vetor de localização $\mathbf{m}$ e uma matriz diagonal de escalas positivas $\mathbf{L}$, define-se

$$\mathbf{z} = \mathbf{L}^{-1}(\mathbf{x} - \mathbf{m}).$$

Essa expressão pode ser reorganizada como

$$\mathbf{z} = \mathbf{L}^{-1}\mathbf{x} - \mathbf{L}^{-1}\mathbf{m}.$$

Portanto, a padronização é uma transformação afin com

$$\mathbf{A} = \mathbf{L}^{-1}$$

e

$$\mathbf{b} = -\mathbf{L}^{-1}\mathbf{m}.$$

Para uma matriz de dados,

$$\mathbf{Z} = (\mathbf{X} - \mathbf{1}_n \mathbf{m}^\top) \mathbf{L}^{-1}.$$

Quando $\mathbf{m} = \bar{\mathbf{x}}$ e os elementos diagonais de $\mathbf{L}$ são os desvios-padrão amostrais, cada coluna de $\mathbf{Z}$ possui média zero e desvio-padrão igual a 1.

Para duas observações padronizadas,

$$\begin{aligned} \mathbf{z}_i - \mathbf{z}_j &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{m}) - \mathbf{L}^{-1} (\mathbf{x}_j - \mathbf{m}) \\ &= \mathbf{L}^{-1} (\mathbf{x}_i - \mathbf{x}_j). \end{aligned}$$

Logo,

$$\|\mathbf{z}_i - \mathbf{z}_j\|^2 = (\mathbf{x}_i - \mathbf{x}_j)^\top \mathbf{L}^{-2} (\mathbf{x}_i - \mathbf{x}_j).$$

A translação associada à centralização não altera as diferenças entre observações. A alteração da geometria decorre do escalonamento.

4.7.6 Ordem entre centralização e escalonamento

A padronização usual é

$$\mathbf{z} = \mathbf{L}^{-1} (\mathbf{x} - \mathbf{m}).$$

Se o escalonamento for aplicado primeiro,

$$\mathbf{y} = \mathbf{L}^{-1} \mathbf{x},$$

o vetor de localização também deve ser expresso na nova escala:

$$\mathbf{L}^{-1} \mathbf{m}.$$

Assim,

$$\mathbf{z} = \mathbf{y} - \mathbf{L}^{-1}\mathbf{m}.$$

As duas sequências produzem o mesmo resultado quando o vetor de centralização é transformado juntamente com os dados.

4.7.7 Composição e inversão de transformações afins

Considere

$$T_1(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$$

e

$$T_2(\mathbf{y}) = \mathbf{Cy} + \mathbf{d}.$$

A composição é

$$\begin{aligned} T_2(T_1(\mathbf{x})) &= \mathbf{C}(\mathbf{Ax} + \mathbf{b}) + \mathbf{d} \\ &= \mathbf{CAx} + \mathbf{Cb} + \mathbf{d}. \end{aligned}$$

Portanto,

$$(T_2 \circ T_1)(\mathbf{x}) = \mathbf{CAx} + (\mathbf{Cb} + \mathbf{d}).$$

A composição de transformações afins também é afim.

Considere agora

$$\mathbf{y} = \mathbf{Ax} + \mathbf{b},$$

com $\mathbf{A}$ quadrada e invertível. Subtraindo $\mathbf{b}$ e multiplicando por $\mathbf{A}^{-1}$,

$$\mathbf{x} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}).$$

A transformação inversa é

$$T^{-1}(\mathbf{y}) = \mathbf{A}^{-1}\mathbf{y} - \mathbf{A}^{-1}\mathbf{b}.$$

Uma transformação afim é invertível quando sua parte linear é invertível.

4.7.8 Comparação das operações de pré-processamento

A Figura 4.8 compara centralização, escalonamento e padronização de uma mesma nuvem de pontos.




Figura 4.8: Efeito da centralização, do escalonamento e da padronização sobre uma mesma configuração de dados.

A centralização desloca a nuvem para que sua média coincida com a origem, sem modificar as distâncias entre as observações. O escalonamento altera as unidades das coordenadas e modifica a geometria. A padronização combina as duas operações.

A Tabela 4.5 resume as diferenças entre as transformações estudadas nesta seção.

Tabela 4.5: Comparação entre transformações lineares, transformações afins e operações de pré-processamento.

Operação	Expressão	Linear	Mantém a origem fixa
Transformação linear	$\mathbf{Ax}$	Sim	Sim
Translação	$\mathbf{x} + \mathbf{b}$	Não, se $\mathbf{b} \neq \mathbf{0}$	Não

Operação	Expressão	Linear	Mantém a origem fixa
Transformação afim	$\mathbf{Ax} + \mathbf{b}$	Não, em geral	Não, em geral
Centralização	$\mathbf{x} - \mathbf{m}$	Não, se $\mathbf{m} \neq \mathbf{0}$	Não
Escalonamento	$\mathbf{L}^{-1}\mathbf{x}$	Sim	Sim
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Não, em geral	Não, em geral

Transformações lineares modificam direção, escala ou dimensão mantendo a origem fixa. Transformações afins acrescentam a possibilidade de deslocar a configuração. A centralização e a padronização pertencem a essa segunda classe quando são consideradas como operações sobre observações individuais.

4.8 Síntese do capítulo

Uma transformação linear preserva combinações lineares. Conforme a Definição 4.1,

$$T(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v}).$$

Essa propriedade implica $T(\mathbf{0}) = \mathbf{0}$ e permite determinar a transformação a partir das imagens dos vetores de uma base.

Toda transformação linear

$$T : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

possui uma representação matricial única:

$$T(\mathbf{x}) = \mathbf{Ax}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Nas bases canônicas, as colunas de $\mathbf{A}$ são as imagens dos vetores da base do domínio. Quando as observações ocupam as linhas de uma matriz

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

a transformação simultânea de todas as observações é

$$\mathbf{Y} = \mathbf{XA}^\top.$$

Cada linha de $\mathbf{Y}$ representa uma observação transformada e cada coluna corresponde a uma combinação linear das variáveis originais.

O posto de $\mathbf{A}$ determina a dimensão da imagem, enquanto o espaço nulo reúne as direções eliminadas pela transformação:

$$\dim(\mathcal{N}(\mathbf{A})) + \text{posto}(\mathbf{A}) = p.$$

Quando $\mathcal{N}(\mathbf{A})$ contém vetores não nulos, diferentes vetores do domínio podem possuir a mesma imagem. Para uma matriz quadrada, posto completo, núcleo trivial, determinante não nulo, bijetividade e existência da inversa são condições equivalentes.

A composição de transformações é representada pelo produto de suas matrizes. Se T_1 é representada por $\mathbf{A}$ e T_2 por $\mathbf{B}$, então

$$[T_2 \circ T_1] = \mathbf{B}\mathbf{A}.$$

A matriz situada à direita atua primeiro. Como a multiplicação matricial não é comutativa, a ordem das transformações pode alterar o resultado.

As transformações geométricas estudadas produzem efeitos distintos sobre uma configuração de pontos. Rotações e reflexões preservam distâncias e ângulos. Escalonamentos modificam o comprimento das direções, cisalhamentos alteram ângulos e projeções eliminam componentes fora de um subespaço. Para uma transformação quadrada, $|\det(\mathbf{A})|$ representa o fator de alteração do volume, enquanto o sinal do determinante informa se a orientação é preservada ou invertida.

Transformações ortogonais são caracterizadas por

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_p.$$

Elas preservam produtos internos, normas, distâncias, ângulos e volumes. Também satisfazem

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top$$

e

$$\det(\mathbf{Q}) = \pm 1.$$

Uma transformação também pode ser representada em bases diferentes. Se $\mathcal{B}$ é uma base do domínio, $\mathcal{C}$ é uma base do contradomínio e $\mathbf{A}$ representa a transformação nas bases canônicas, então

$$[T]_{\mathcal{C} \leftarrow \mathcal{B}} = \mathbf{P}_{\mathcal{C}}^{-1} \mathbf{A} \mathbf{P}_{\mathcal{B}}.$$

Quando a mesma base é utilizada no domínio e no contradomínio, as matrizes resultantes são semelhantes e representam o mesmo operador em sistemas de coordenadas distintos.

A transformação ativa modifica o vetor em relação a eixos fixos. A mudança passiva mantém o vetor geométrico e modifica apenas suas coordenadas. Para uma base ortonormal organizada nas colunas de $\mathbf{Q}$, essas operações são representadas, respectivamente, por

$$\mathbf{y} = \mathbf{Q}\mathbf{x}$$

e

$$[\mathbf{x}]_{\mathcal{B}} = \mathbf{Q}^{\top} \mathbf{x}.$$

As transformações afins acrescentam uma translação à parte linear:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}.$$

A centralização é uma translação, o escalonamento é uma transformação linear e a padronização combina as duas operações. Para uma matriz de dados, a centralização pela média amostral pode ser escrita como

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

A Tabela 4.6 reúne as expressões principais desenvolvidas no capítulo.

Tabela 4.6: Síntese das transformações desenvolvidas no capítulo.

Objeto ou operação	Expressão	Interpretação
Transformação linear	$\mathbf{A}\mathbf{x}$	Preserva combinações lineares
Transformação dos dados	$\mathbf{X}\mathbf{A}^{\top}$	Transforma simultaneamente todas as observações
Composição	$\mathbf{B}\mathbf{A}\mathbf{x}$	Aplica $\mathbf{A}$ antes de $\mathbf{B}$
Transformação inversa	$\mathbf{A}^{-1}\mathbf{y}$	Recupera o vetor original
Rotação	$\mathbf{Q}(\theta)\mathbf{x}$	Gira a configuração preservando sua geometria
Reflexão	$\mathbf{F}\mathbf{x}$	Preserva a geometria e inverte a orientação
Escalaonamento	$\mathbf{L}\mathbf{x}$	Amplia ou comprime direções

Objeto ou operação	Expressão	Interpretação
Cisalhamento	$\mathbf{C}_{ij}(k)\mathbf{x}$	Inclina a configuração
Projeção	$\mathbf{P}\mathbf{x}$	Elimina componentes fora de um subespaço
Mudança de base	$\mathbf{P}_{\mathcal{B}}^{-1}\mathbf{x}$	Altera as coordenadas do vetor
Transformação afim	$\mathbf{A}\mathbf{x} + \mathbf{b}$	Combina transformação linear e translação
Centralização	$\mathbf{x} - \mathbf{m}$	Desloca o centro da configuração
Padronização	$\mathbf{L}^{-1}(\mathbf{x} - \mathbf{m})$	Ajusta localização e escala

O capítulo seguinte examina direções cuja orientação é preservada por uma transformação linear. Essas direções conduzem aos conceitos de autovalor, autovetor e decomposição espectral.

5 Autovalores, autovetores e decomposição espectral

No capítulo anterior, uma transformação linear foi representada por uma matriz e interpretada como uma operação capaz de modificar direções, comprimentos, ângulos e volumes. Quando o domínio e o contradomínio coincidem, a transformação é um operador linear

$$T_{\mathbf{A}} : \mathbb{R}^p \longrightarrow \mathbb{R}^p, \quad T_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

representado por uma matriz quadrada

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Em uma base arbitrária, a matriz pode combinar diferentes coordenadas, dificultando a interpretação de sua ação. Algumas direções, entretanto, possuem um comportamento mais simples: todos os vetores contidos nessas direções permanecem no mesmo subespaço após a transformação.

A identificação dessas direções conduz aos conceitos de autovalor, autovetor e autoespaço. Quando existem autovetores linearmente independentes em número suficiente, eles formam uma base na qual a matriz do operador é diagonal. Nessa representação, a transformação atua separadamente sobre cada coordenada.

Para matrizes simétricas, essa simplificação possui propriedades adicionais. Seus autovalores são reais e existe uma base ortonormal de autovetores. A decomposição resultante permite interpretar formas quadráticas, matrizes positivas definidas, elipsóides, funções de matrizes e problemas de otimização. Essas estruturas também serão utilizadas posteriormente no estudo de covariâncias e decomposições matriciais.

5.1 Direções invariantes, autovalores e autoespaços

Considere uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um subespaço

$$\mathcal{W} \subseteq \mathbb{R}^p$$

é **invariante** sob $\mathbf{A}$ quando

$$\mathbf{A}\mathbf{w} \in \mathcal{W}$$

para todo $\mathbf{w} \in \mathcal{W}$.

Uma reta que passa pela origem e é gerada por um vetor não nulo $\mathbf{v}$ possui a forma

$$\text{span}(\mathbf{v}) = \{c\mathbf{v} : c \in \mathbb{R}\}.$$

Essa reta é invariante sob $\mathbf{A}$ quando a imagem de $\mathbf{v}$ permanece na própria reta. Nesse caso, existe um escalar λ tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

Definição 5.1 (Autovalor e autovetor). Seja

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é um **autovalor** de $\mathbf{A}$ quando existe um vetor

$$\mathbf{v} \in \mathbb{R}^p, \quad \mathbf{v} \neq \mathbf{0},$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor** de $\mathbf{A}$ associado ao autovalor λ . O par $(\lambda, \mathbf{v})$ é denominado **autopar** de $\mathbf{A}$.

A equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

mostra que a transformação não combina a direção de $\mathbf{v}$ com outras direções do espaço. Sua ação sobre esse vetor consiste em alterar seu comprimento e, possivelmente, seu sentido.

O módulo de λ determina a alteração do comprimento:

- se $|\lambda| > 1$, ocorre expansão;
- se $0 < |\lambda| < 1$, ocorre contração;
- se $|\lambda| = 1$, o comprimento é preservado;
- se $\lambda = 0$, o vetor é transformado no vetor nulo.

O sinal determina o sentido:

- se $\lambda > 0$, o sentido é preservado;
- se $\lambda < 0$, o sentido é invertido.

Portanto, quando $\lambda = -1$, o vetor tem seu sentido invertido sem alteração do comprimento. Quando $\lambda = 0$, a reta gerada pelo autovetor continua sendo um subespaço invariante, pois toda a reta é enviada ao vetor nulo, mas sua direção deixa de aparecer na imagem da transformação.

Exemplo 5.1 (Direções invariantes de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Para o vetor

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{A}\mathbf{v}_1 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 4 \end{bmatrix} \\ &= 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \end{aligned}$$

Assim,

$$\mathbf{A}\mathbf{v}_1 = 4\mathbf{v}_1,$$

e $\mathbf{v}_1$ é um autovetor associado ao autovalor

$$\lambda_1 = 4.$$

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

obtém-se

$$\begin{aligned} \mathbf{A}\mathbf{v}_2 &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ -2 \end{bmatrix} \\ &= 2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{v}_2 = 2\mathbf{v}_2,$$

e $\mathbf{v}_2$ é um autovetor associado ao autovalor

$$\lambda_2 = 2.$$

Considere agora

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Sua imagem é

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Não existe um escalar λ que satisfaça

$$\begin{bmatrix} 3 \\ 1 \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Logo, $\mathbf{x}$ não é um autovetor de $\mathbf{A}$. A transformação modifica seu comprimento e sua direção.

A Figura 5.1 compara as imagens dos autovetores $\mathbf{v}_1$ e $\mathbf{v}_2$ com a imagem do vetor genérico $\mathbf{x}$.




Figura 5.1: Autovetores permanecem nas mesmas direções após a transformação, enquanto um vetor genérico pode ter sua direção modificada.

As retas tracejadas representam as direções geradas por $\mathbf{v}_1$ e $\mathbf{v}_2$. A transformação amplia os vetores por fatores diferentes, mas mantém cada um na reta correspondente. O vetor $\mathbf{x}$ não pertence a uma direção invariante e sua imagem ocupa outra direção.

A equação de autovalor também mostra que um autovetor não possui um representante único.

Teorema 5.1 (Múltiplos de um autovetor). *Se $\mathbf{v}$ é um autovetor de $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo*

$$c\mathbf{v}, \quad c \neq 0,$$

também é um autovetor associado a λ .

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

pela linearidade,

$$\begin{aligned}\mathbf{A}(c\mathbf{v}) &= c\mathbf{A}\mathbf{v} \\ &= c\lambda\mathbf{v} \\ &= \lambda(c\mathbf{v}).\end{aligned}$$

Como $c \neq 0$ e $\mathbf{v} \neq \mathbf{0}$, tem-se $c\mathbf{v} \neq \mathbf{0}$. Portanto, $c\mathbf{v}$ é um autovetor associado a λ . □

Para reunir todos os autovetores associados ao mesmo autovalor, reorganiza-se a equação

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

como

$$(\mathbf{A} - \lambda\mathbf{I}_p)\mathbf{v} = \mathbf{0}.$$

O conjunto de soluções é o núcleo de

$$\mathbf{A} - \lambda\mathbf{I}_p.$$

Definição 5.2 (Autoespaço). Se λ é um autovalor de

$$\mathbf{A} \in \mathbb{R}^{p \times p},$$

o **autoespaço** associado a λ é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Os autovetores associados a λ são os elementos não nulos de $\mathcal{E}_\lambda$:

$$\mathcal{E}_\lambda \setminus \{\mathbf{0}\}.$$

O vetor nulo pertence a todo autoespaço, mas não é considerado um autovetor. A igualdade

$$\mathbf{A}\mathbf{0} = \lambda\mathbf{0}$$

é satisfeita para qualquer λ e não identifica uma direção.

Teorema 5.2 (Estrutura e invariância do autoespaço). *Se λ é um autovalor de $\mathbf{A}$, então $\mathcal{E}_\lambda$ é um subespaço não trivial de $\mathbb{R}^p$ e é invariante sob $\mathbf{A}$.*

Comprovação. Como

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p),$$

o autoespaço é o núcleo de uma transformação linear e, portanto, é um subespaço de $\mathbb{R}^p$.

Como λ é um autovalor, existe pelo menos um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Logo,

$$\mathcal{E}_\lambda \neq \{\mathbf{0}\}.$$

Para qualquer $\mathbf{w} \in \mathcal{E}_\lambda$,

$$\mathbf{A}\mathbf{w} = \lambda\mathbf{w}.$$

Como $\mathcal{E}_\lambda$ é fechado pela multiplicação por escalares,

$$\lambda \mathbf{w} \in \mathcal{E}_\lambda.$$

Portanto,

$$\mathbf{A}\mathbf{w} \in \mathcal{E}_\lambda,$$

e o autoespaço é invariante sob $\mathbf{A}$. □

Quando

$$\dim(\mathcal{E}_\lambda) = 1,$$

o autoespaço determina uma única direção invariante. Todos os autovetores associados a λ são múltiplos não nulos de um mesmo vetor.

Quando

$$\dim(\mathcal{E}_\lambda) > 1,$$

o autovalor está associado a várias direções linearmente independentes. Nesse caso, o objeto geométrico determinado pela matriz é todo o autoespaço. Uma base específica desse subespaço não é necessariamente única.

A definição permite verificar se um vetor conhecido é um autovetor. Para determinar os autovalores a partir da matriz, é necessário identificar os valores de λ para os quais o sistema

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais. Essa condição conduz à equação característica.

5.2 Equação característica, multiplicidades e diagonalização

A definição de autovalor permite verificar se um vetor conhecido determina uma direção invariante. Para encontrar essas direções a partir de uma matriz, é necessário determinar os valores de λ para os quais

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}$$

possui soluções não triviais.

Esse é um sistema linear homogêneo. Se

$$\mathbf{A} - \lambda \mathbf{I}_p$$

fosse invertível, sua única solução seria $\mathbf{v} = \mathbf{0}$. Portanto, um autovalor deve tornar essa matriz singular.

Teorema 5.3 (Caracterização dos autovalores pelo determinante). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

Um escalar $\lambda \in \mathbb{R}$ é autovalor de $\mathbf{A}$ se, e somente se,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Comprovação. Se λ é autovalor de $\mathbf{A}$, existe um vetor não nulo $\mathbf{v}$ tal que

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Como o sistema possui uma solução não trivial, a matriz

$$\mathbf{A} - \lambda \mathbf{I}_p$$

não é invertível. Logo,

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0.$$

Reciprocamente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}_p) = 0,$$

a matriz é singular. Portanto, seu núcleo contém pelo menos um vetor não nulo $\mathbf{v}$, para o qual

$$(\mathbf{A} - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v},$$

e λ é autovalor de $\mathbf{A}$. □

Definição 5.3 (Polinômio e equação característicos). O **polinômio característico** de uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é definido por

$$p_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_p).$$

A equação

$$p_{\mathbf{A}}(\lambda) = 0$$

é denominada **equação característica** de $\mathbf{A}$. (Horn; Johnson, 2013)

Também é possível definir o polinômio característico por

$$\det(\lambda \mathbf{I}_p - \mathbf{A}).$$

As duas convenções diferem pelo fator $(-1)^p$ e possuem as mesmas raízes. Portanto, produzem os mesmos autovalores.

O polinômio característico de uma matriz de ordem p possui grau p . Consideradas suas multiplicidades, ele possui p raízes no conjunto dos números complexos. Uma matriz real pode ter autovalores reais, autovalores complexos ou ambos.

5.2.1 Determinação dos autovalores e autoespaços

Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Tem-se

$$\mathbf{A} - \lambda \mathbf{I}_2 = \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix}.$$

O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det \begin{bmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{bmatrix} \\ &= (3 - \lambda)^2 - 1 \\ &= \lambda^2 - 6\lambda + 8 \\ &= (\lambda - 4)(\lambda - 2). \end{aligned}$$

Assim, os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Para determinar o autoespaço associado a $\lambda_1 = 4$, resolve-se

$$(\mathbf{A} - 4\mathbf{I}_2) \mathbf{v} = \mathbf{0}.$$

Como

$$\mathbf{A} - 4\mathbf{I}_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix},$$

o sistema conduz a

$$-v_1 + v_2 = 0,$$

ou seja,

$$v_2 = v_1.$$

Portanto,

$$\mathcal{E}_4 = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda_2 = 2$,

$$\mathbf{A} - 2\mathbf{I}_2 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

e o sistema correspondente fornece

$$v_1 + v_2 = 0.$$

Logo,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}.$$

O procedimento possui duas etapas:

1. resolver

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

para obter os autovalores;

2. para cada autovalor λ , determinar

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

5.2.2 Autovalores complexos de matrizes reais

As definições de autovalor, autovetor, autoespaço e equação característica foram apresentadas inicialmente no espaço real. Elas se estendem ao espaço complexo substituindo

$$\mathbb{R}^p$$

por

$$\mathbb{C}^p$$

e permitindo

$$\lambda \in \mathbb{C}.$$

Nesse caso, um autovetor complexo é um vetor não nulo $\mathbf{v} \in \mathbb{C}^p$ que satisfaz

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A caracterização

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0$$

permanece válida no espaço complexo.

Nem toda matriz real possui autovalores reais. Considere a rotação de 90° ,

$$\mathbf{Q}\left(\frac{\pi}{2}\right) = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

Seu polinômio característico é

$$\begin{aligned} p_{\mathbf{Q}}(\lambda) &= \det \begin{bmatrix} -\lambda & -1 \\ 1 & -\lambda \end{bmatrix} \\ &= \lambda^2 + 1. \end{aligned}$$

A equação

$$\lambda^2 + 1 = 0$$

não possui raízes reais. Suas raízes complexas são

$$\lambda_1 = i \quad \text{e} \quad \lambda_2 = -i.$$

Portanto, a matriz não possui autovetores reais. Geometricamente, nenhuma reta real que passa pela origem permanece invariante sob uma rotação de 90° .

Quando o espaço é ampliado de $\mathbb{R}^2$ para $\mathbb{C}^2$, a matriz possui autovalores e autovetores complexos. Neste capítulo, a interpretação geométrica será desenvolvida principalmente para matrizes cujos autovalores e autovetores são reais. Em particular, as matrizes simétricas reais sempre satisfazem essa condição.

5.2.3 Independência entre autovetores

Os autovetores associados a autovalores distintos possuem uma propriedade que permite construir bases de direções invariantes.

Teorema 5.4 (Independência de autovetores associados a autovalores distintos). *Se*

$$\lambda_1, \dots, \lambda_r$$

são autovalores distintos de uma matriz $\mathbf{A}$ e

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são autovetores associados, respectivamente, a esses autovalores, então

$$\mathbf{v}_1, \dots, \mathbf{v}_r$$

são linearmente independentes.

Comprovação. A demonstração será feita por indução sobre r .

Para $r = 1$, o resultado é imediato porque um autovetor é não nulo.

Suponha que o resultado seja válido para $r - 1$ autovetores e considere

$$c_1 \mathbf{v}_1 + \dots + c_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando por $\mathbf{A}$,

$$c_1 \lambda_1 \mathbf{v}_1 + \cdots + c_r \lambda_r \mathbf{v}_r = \mathbf{0}.$$

Multiplicando a primeira igualdade por λ_r e subtraindo-a da segunda,

$$c_1 (\lambda_1 - \lambda_r) \mathbf{v}_1 + \cdots + c_{r-1} (\lambda_{r-1} - \lambda_r) \mathbf{v}_{r-1} = \mathbf{0}.$$

Pela hipótese de indução,

$$c_j (\lambda_j - \lambda_r) = 0, \quad j = 1, \dots, r-1.$$

Como os autovalores são distintos,

$$\lambda_j - \lambda_r \neq 0,$$

e, portanto,

$$c_1 = \cdots = c_{r-1} = 0.$$

A igualdade original reduz-se a

$$c_r \mathbf{v}_r = \mathbf{0}.$$

Como $\mathbf{v}_r \neq \mathbf{0}$, segue que $c_r = 0$. Logo, os autovetores são linearmente independentes. $\square$

Uma consequência imediata é que uma matriz de ordem p com p autovalores distintos possui uma base formada por autovetores. Essa condição é suficiente para a diagonalização, mas não é necessária: uma matriz também pode ser diagonalizável quando possui autovalores repetidos.

5.2.4 Multiplicidades algébrica e geométrica

Quando um autovalor aparece mais de uma vez como raiz do polinômio característico, é necessário distinguir sua repetição algébrica da dimensão do autoespaço correspondente.

Definição 5.4 (Multiplicidades de um autovalor). Seja λ um autovalor de $\mathbf{A}$.

A **multiplicidade algébrica** de λ , denotada por

$$m_a(\lambda),$$

é o número de vezes que λ aparece como raiz do polinômio característico.

A **multiplicidade geométrica** de λ , denotada por

$$m_g(\lambda),$$

é a dimensão do autoespaço correspondente:

$$m_g(\lambda) = \dim(\mathcal{E}_\lambda) = \dim \mathcal{N}(\mathbf{A} - \lambda \mathbf{I}_p).$$

Para todo autovalor,

$$1 \leq m_g(\lambda) \leq m_a(\lambda).$$

A multiplicidade geométrica é pelo menos 1 porque o autoespaço contém vetores não nulos. Ela representa o número máximo de autovetores linearmente independentes que podem ser escolhidos para aquele autovalor.

Considere duas matrizes com o mesmo polinômio característico:

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}.$$

Em ambos os casos,

$$p_{\mathbf{A}_j}(\lambda) = (2 - \lambda)^2.$$

Portanto,

$$m_a(2) = 2.$$

Para $\mathbf{A}_1$,

$$\mathbf{A}_1 - 2\mathbf{I}_2 = \mathbf{0},$$

de modo que

$$\mathcal{E}_2 = \mathbb{R}^2$$

e

$$m_g(2) = 2.$$

Todo vetor não nulo do plano é um autovetor de $\mathbf{A}_1$ associado a $\lambda = 2$.

Para $\mathbf{A}_2$,

$$\mathbf{A}_2 - 2\mathbf{I}_2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

O sistema correspondente impõe

$$v_2 = 0.$$

Assim,

$$\mathcal{E}_2 = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$$

e

$$m_g(2) = 1.$$

Nesse caso, existe somente uma direção invariante linearmente independente.




Figura 5.2: Matrizes com o mesmo autovalor repetido podem possuir autoespaços de dimensões diferentes.

A Figura 5.2 compara as estruturas dos dois autoespaços.

As duas matrizes possuem o mesmo autovalor com a mesma multiplicidade algébrica. A diferença entre as multiplicidades geométricas determina se existem autovetores suficientes para formar uma base.

5.2.5 Diagonalização

Uma transformação assume uma representação particularmente simples quando existe uma base formada por autovetores.

Definição 5.5 (Matriz diagonalizável). Uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é **diagonalizável sobre** $\mathbb{R}$ quando existem uma matriz invertível

$$\mathbf{P}_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{P}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{P}_{\mathbf{A}}^{-1}.$$

As colunas de $\mathbf{P}_{\mathbf{A}}$ são autovetores linearmente independentes:

$$\mathbf{P}_{\mathbf{A}} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p],$$

e a matriz diagonal contém os autovalores correspondentes:

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A ordem das colunas de $\mathbf{P}_{\mathbf{A}}$ deve coincidir com a ordem dos autovalores em $\Lambda_{\mathbf{A}}$.

Como

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{v}_j,$$

tem-se

$$\mathbf{A} \mathbf{P}_{\mathbf{A}} = \mathbf{P}_{\mathbf{A}} \Lambda_{\mathbf{A}}.$$

Multiplicando à direita por $\mathbf{P}_{\mathbf{A}}^{-1}$,

$$\mathbf{A} = \mathbf{P}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{P}_{\mathbf{A}}^{-1}.$$

Essa expressão é uma mudança de representação do operador. Conforme a Definição 4.5,

$$\Lambda_{\mathbf{A}} = \mathbf{P}_{\mathbf{A}}^{-1} \mathbf{A} \mathbf{P}_{\mathbf{A}}$$

é a matriz do mesmo operador na base formada pelos autovetores.

Se

$$\mathbf{x} = \mathbf{P}_{\mathbf{A}} \mathbf{z},$$

então

$$\begin{aligned}\mathbf{Ax} &= \mathbf{AP_Az} \\ &= \mathbf{P_A}\Lambda_{\mathbf{A}}\mathbf{z}.\end{aligned}$$

Nas coordenadas da base de autovetores, cada componente é transformada separadamente:

$$\Lambda_{\mathbf{A}}\mathbf{z} = \begin{bmatrix} \lambda_1 z_1 \\ \vdots \\ \lambda_p z_p \end{bmatrix}.$$

Teorema 5.5 (Critérios de diagonalização). *Seja*

$$\mathbf{A} \in \mathbb{F}^{p \times p},$$

em que $\mathbb{F}$ representa $\mathbb{R}$ ou $\mathbb{C}$, e suponha que seu polinômio característico se decompõe em fatores lineares sobre $\mathbb{F}$.

São equivalentes:

1. $\mathbf{A}$ é diagonalizável sobre $\mathbb{F}$;
2. $\mathbf{A}$ possui p autovetores linearmente independentes em $\mathbb{F}^p$;
3. existe uma base de $\mathbb{F}^p$ formada por autovetores de $\mathbf{A}$;
4. a soma das dimensões dos autoespaços é igual a p ;
5. para cada autovalor λ ,

$$m_g(\lambda) = m_a(\lambda).$$

(Horn; Johnson, 2013)

O requisito de decomposição do polinômio característico é necessário porque uma matriz real pode não possuir todos os seus autovalores em $\mathbb{R}$. A matriz de rotação $\mathbf{Q}(\pi/2)$ não é diagonalizável sobre $\mathbb{R}$, mas é diagonalizável sobre $\mathbb{C}$, pois possui dois autovalores complexos distintos.

Uma condição suficiente para a diagonalização é a existência de p autovalores distintos. Nesse caso, o Teorema 5.4 garante p autovetores linearmente independentes.

Autovalores repetidos não impedem a diagonalização. Para

$$\mathbf{A}_1 = 2\mathbf{I}_2,$$

tem-se

$$m_g(2) = m_a(2) = 2,$$

e a matriz é diagonalizável.

Para

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

tem-se

$$m_g(2) = 1 < m_a(2) = 2.$$

A matriz não possui autovetores linearmente independentes em número suficiente para formar uma base e, portanto, não é diagonalizável.

5.2.6 Potências de uma matriz diagonalizável

A representação diagonal também simplifica o cálculo de potências. Se

$$\mathbf{A} = \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1},$$

então

$$\begin{aligned} \mathbf{A}^2 &= \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1} \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1} \\ &= \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A}^2 \mathbf{P}_\mathbf{A}^{-1}. \end{aligned}$$

De forma geral, para todo inteiro $k \geq 0$,

$$\mathbf{A}^k = \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{P}_\mathbf{A}^{-1}.$$

Como $\Lambda_\mathbf{A}$ é diagonal,

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

A diagonalização reduz a aplicação repetida do operador à aplicação independente das potências dos autovalores em cada direção invariante.

Para matrizes quadradas arbitrárias, a diagonalização pode falhar. Para matrizes simétricas reais, existe sempre uma base ortonormal de autovetores. Essa propriedade conduz a uma diagonalização que preserva a geometria euclidiana.

5.3 Matrizes simétricas e decomposição espectral

A diagonalização estudada na seção anterior pode falhar para matrizes quadradas arbitrárias. Uma matriz pode não possuir autovalores reais ou pode não apresentar autovetores linearmente independentes em número suficiente para formar uma base.

As matrizes simétricas reais possuem uma estrutura mais regular. Retomando a Definição 2.7, uma matriz

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é simétrica quando

$$\mathbf{A}^\top = \mathbf{A}.$$

Para essa classe de matrizes, todos os autovalores são reais e os autoespaços associados a autovalores distintos são ortogonais. Como consequência, existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$.

Teorema 5.6 (Teorema Espectral para matrizes simétricas reais). *Seja*

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

uma matriz simétrica. Então:

1. *todos os autovalores de $\mathbf{A}$ são reais;*
2. *autoespaços associados a autovalores distintos são ortogonais;*
3. *existe uma base ortonormal de $\mathbb{R}^p$ formada por autovetores de $\mathbf{A}$;*
4. *existe uma matriz ortogonal*

$$\mathbf{Q}_\mathbf{A} \in \mathbb{R}^{p \times p}$$

e uma matriz diagonal

$$\Lambda_{\mathbf{A}} \in \mathbb{R}^{p \times p}$$

tais que

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top}.$$

(Horn; Johnson, 2013)

Comprovação. Para demonstrar que os autovalores são reais, considere um autovalor possivelmente complexo λ e um autovetor complexo não nulo $\mathbf{z}$, de modo que

$$\mathbf{A}\mathbf{z} = \lambda\mathbf{z}.$$

Como $\mathbf{A}$ é real e simétrica, ela também é hermitiana:

$$\mathbf{A}^* = \mathbf{A},$$

em que $*$ representa a transposta conjugada.

Multiplicando a equação de autovalor à esquerda por $\mathbf{z}^*$,

$$\mathbf{z}^* \mathbf{A} \mathbf{z} = \lambda \mathbf{z}^* \mathbf{z}.$$

A quantidade

$$\mathbf{z}^* \mathbf{A} \mathbf{z}$$

é real, pois

$$(\mathbf{z}^* \mathbf{A} \mathbf{z})^* = \mathbf{z}^* \mathbf{A}^* \mathbf{z} = \mathbf{z}^* \mathbf{A} \mathbf{z}.$$

Além disso,

$$\mathbf{z}^* \mathbf{z} > 0.$$

Portanto,

$$\lambda = \frac{\mathbf{z}^* \mathbf{A} \mathbf{z}}{\mathbf{z}^* \mathbf{z}}$$

é real.

Considere agora dois autovetores reais $\mathbf{v}_i$ e $\mathbf{v}_j$, associados a autovalores distintos λ_i e λ_j . Como

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{v}_i$$

e

$$\mathbf{A}\mathbf{v}_j = \lambda_j \mathbf{v}_j,$$

tem-se

$$\begin{aligned} \lambda_i \mathbf{v}_i^\top \mathbf{v}_j &= (\mathbf{A}\mathbf{v}_i)^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\ &= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\ &= \lambda_j \mathbf{v}_i^\top \mathbf{v}_j. \end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{v}_j = 0.$$

Portanto, os autoespaços associados a autovalores distintos são ortogonais.

A existência de uma base ortonormal de autovetores pode ser demonstrada por indução sobre a ordem p da matriz. Para $p = 1$, o resultado é imediato.

Suponha agora $p > 1$. Pelo Teorema Fundamental da Álgebra, o polinômio característico de $\mathbf{A}$ possui pelo menos uma raiz em $\mathbb{C}$. Pela primeira parte da demonstração, essa raiz é real. Denote-a por λ_1 .

Como

$$\det(\mathbf{A} - \lambda_1 \mathbf{I}_p) = 0,$$

a matriz real

$$\mathbf{A} - \lambda_1 \mathbf{I}_p$$

é singular e possui um vetor não nulo real em seu núcleo. Normalizando esse vetor, obtém-se um autovetor unitário $\mathbf{q}_1$.

Considere o complemento ortogonal

$$\mathcal{W} = \text{span}(\mathbf{q}_1)^\perp.$$

Para qualquer $\mathbf{x} \in \mathcal{W}$,

$$\mathbf{q}_1^\top \mathbf{x} = 0.$$

Como $\mathbf{A}$ é simétrica,

$$\begin{aligned}\mathbf{q}_1^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{q}_1)^\top \mathbf{x} \\ &= \lambda_1 \mathbf{q}_1^\top \mathbf{x} \\ &= 0.\end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{x} \in \mathcal{W},$$

e $\mathcal{W}$ é invariante sob $\mathbf{A}$.

A restrição de $\mathbf{A}$ a $\mathcal{W}$ permanece simétrica. Como

$$\dim(\mathcal{W}) = p - 1,$$

a hipótese de indução garante uma base ortonormal

$$\mathbf{q}_2, \dots, \mathbf{q}_p$$

de $\mathcal{W}$ formada por autovetores da restrição e, conseqüentemente, de $\mathbf{A}$.

Assim,

$$\mathbf{q}_1, \dots, \mathbf{q}_p$$

formam uma base ortonormal de $\mathbb{R}^p$ composta por autovetores de $\mathbf{A}$.

Organizando esses vetores nas colunas de

$$\mathbf{Q}_A = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p],$$

tem-se

$$\mathbf{Q}_A^\top \mathbf{Q}_A = \mathbf{I}_p.$$

Portanto,

$$\mathbf{Q}_A^{-1} = \mathbf{Q}_A^\top.$$

Definindo

$$\Lambda_A = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a relação

$$\mathbf{A} \mathbf{Q}_A = \mathbf{Q}_A \Lambda_A$$

fornece

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

□

A representação

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top$$

é denominada **decomposição espectral** de $\mathbf{A}$. Ela também pode ser interpretada como uma diagonalização ortogonal.

Nas coordenadas determinadas pela base de autovetores,

$$\mathbf{z} = \mathbf{Q}_A^\top \mathbf{x},$$

o vetor original é recuperado por

$$\mathbf{x} = \mathbf{Q}_A \mathbf{z}.$$

A transformação de $\mathbf{x}$ pode ser escrita como

$$\begin{aligned}\mathbf{Ax} &= \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top \mathbf{x} \\ &= \mathbf{Q}_A \Lambda_A \mathbf{z}.\end{aligned}$$

A operação ocorre em três etapas:

1. $\mathbf{Q}_A^\top$ converte o vetor para as coordenadas da base ortonormal de autovetores;
2. Λ_A multiplica separadamente cada coordenada pelo autovalor correspondente;
3. $\mathbf{Q}_A$ converte o resultado para as coordenadas canônicas.

A matriz simétrica atua, portanto, como um escalonamento independente em direções ortogonais.

5.3.1 Decomposição espectral do exemplo condutor

Exemplo 5.2 (Decomposição espectral de uma matriz simétrica). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os autovetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

são ortogonais, pois

$$\mathbf{v}_1^\top \mathbf{v}_2 = 0.$$

Normalizando-os, obtêm-se

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz ortogonal de autovetores é

$$\mathbf{Q}_A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix},$$

e a matriz diagonal de autovalores é

$$\Lambda_A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Consequentemente,

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top.$$

De fato,

$$\begin{aligned} \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Na direção de $\mathbf{q}_1$, a transformação multiplica o comprimento por 4. Na direção ortogonal $\mathbf{q}_2$, multiplica o comprimento por 2.

A Figura 5.3 mostra a esfera unitária em $\mathbb{R}^2$ e sua imagem pela matriz $\mathbf{A}$. Como os dois autovalores são positivos, a imagem é uma elipse cujos semieixos possuem comprimentos 4 e 2 e estão alinhados aos autovetores.

Na base canônica, a ação da matriz combina as duas coordenadas. Na base formada por $\mathbf{q}_1$ e $\mathbf{q}_2$, a transformação apenas multiplica as coordenadas por 4 e 2.

Para uma matriz simétrica arbitrária, os comprimentos dos semieixos da imagem da esfera unitária são determinados por




Figura 5.3: A decomposição espectral identifica as direções ortogonais nas quais uma matriz simétrica atua por escalonamentos independentes.

$$|\lambda_1|, \dots, |\lambda_p|.$$

Autovalores negativos também invertem o sentido ao longo das direções correspondentes. Autovalores nulos colapsam os respectivos eixos, reduzindo a dimensão da imagem.

5.3.2 Forma aditiva da decomposição espectral

Como

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p),$$

a decomposição espectral também pode ser escrita como

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}.$$

Cada matriz

$$\mathbf{q}_j \mathbf{q}_j^\top$$

é o projetor ortogonal sobre a reta gerada por $\mathbf{q}_j$. Assim,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top \mathbf{x}.$$

A transformação pode ser interpretada como:

1. projetar $\mathbf{x}$ sobre cada direção espectral;
2. multiplicar cada projeção pelo autovalor correspondente;
3. somar as parcelas resultantes.

No exemplo,

$$\mathbf{A} = 4\mathbf{q}_1 \mathbf{q}_1^\top + 2\mathbf{q}_2 \mathbf{q}_2^\top.$$

5.3.3 Projetores sobre autoespaços

Quando um autovalor possui multiplicidade maior que 1, os autovetores individuais associados a ele não são únicos. O autoespaço, entretanto, é determinado pela matriz.

Considere os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

de $\mathbf{A}$. Para cada autovalor $\lambda^{(h)}$, seja

$$\mathbf{Q}_h$$

uma matriz cujas colunas formam uma base ortonormal do autoespaço correspondente.

Define-se o projetor espectral

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top.$$

Esse projetor não depende da base ortonormal escolhida dentro do autoespaço.

Teorema 5.7 (Decomposição por projetores espectrais). *Se $\mathbf{A}$ é simétrica e possui autovalores distintos*

$$\lambda^{(1)}, \dots, \lambda^{(s)},$$

então

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

Além disso,

$$\Pi_{\lambda^{(h)}}^\top = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}}^2 = \Pi_{\lambda^{(h)}},$$

$$\Pi_{\lambda^{(h)}} \Pi_{\lambda^{(\ell)}} = \mathbf{0}, \quad h \neq \ell,$$

e

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

(Horn; Johnson, 2013)

Comprovação. As colunas de $\mathbf{Q}_h$ são ortonormais. Portanto,

$$\Pi_{\lambda^{(h)}} = \mathbf{Q}_h \mathbf{Q}_h^\top$$

é o projetor ortogonal sobre o autoespaço associado a $\lambda^{(h)}$. Pela Teorema 3.21, ele é simétrico e idempotente.

Autoespaços associados a autovalores distintos são ortogonais. Logo,

$$\mathbf{Q}_h^\top \mathbf{Q}_\ell = \mathbf{0}$$

para $h \neq \ell$, e

$$\begin{aligned}\Pi_{\lambda^{(h)}}\Pi_{\lambda^{(\ell)}} &= \mathbf{Q}_h\mathbf{Q}_h^\top\mathbf{Q}_\ell\mathbf{Q}_\ell^\top \\ &= \mathbf{0}.\end{aligned}$$

A soma direta ortogonal de todos os autoespaços é $\mathbb{R}^p$. Por isso,

$$\sum_{h=1}^s \Pi_{\lambda^{(h)}} = \mathbf{I}_p.$$

Agrupando na decomposição espectral todos os autovetores associados ao mesmo autovalor,

$$\mathbf{A} = \sum_{h=1}^s \lambda^{(h)} \Pi_{\lambda^{(h)}}.$$

□

A decomposição por projetores separa o que depende de uma escolha de base do que é determinado pelo operador. Quando um autovalor é simples, o projetor correspondente possui posto 1:

$$\Pi_\lambda = \mathbf{q}\mathbf{q}^\top.$$

Quando sua multiplicidade geométrica é maior que 1, o projetor representa todo o autoespaço e possui posto igual à sua dimensão.

5.3.4 Não unicidade da matriz de autovetores

A matriz

$$\mathbf{Q}_A$$

não é necessariamente única.

Mesmo quando todos os autovalores são distintos, cada autovetor pode ser substituído por seu oposto:

$$\mathbf{q}_j \longmapsto -\mathbf{q}_j.$$

A ordem dos autovetores também pode ser alterada, desde que a mesma alteração seja aplicada aos autovalores em

$$\Lambda_{\mathbf{A}}.$$

Quando há autovalores repetidos, qualquer base ortonormal do autoespaço correspondente pode ser utilizada.

Essas alterações não modificam a matriz original nem os projetores espectrais. O sinal, a ordem e a base escolhida dentro de um autoespaço são elementos da representação; os autovalores, os autoespaços e seus projetores são propriedades do operador.

A decomposição espectral fornece uma base ortonormal na qual formas quadráticas, determinantes, traços, postos, inversas e superfícies de nível podem ser analisados diretamente a partir dos autovalores.

5.4 Consequências da decomposição espectral

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^{\top},$$

em que

$$\mathbf{Q}_{\mathbf{A}} = [\mathbf{q}_1 \quad \cdots \quad \mathbf{q}_p]$$

é ortogonal e

$$\Lambda_{\mathbf{A}} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

A representação diagonal permite obter propriedades da matriz diretamente de seus autovalores e autoespaços.

5.4.1 Traço, determinante, posto e invertibilidade

Teorema 5.8 (Consequências espectrais básicas). *Se $\mathbf{A} \in \mathbb{R}^{p \times p}$ é simétrica e possui autovalores*

$$\lambda_1, \dots, \lambda_p,$$

contados com suas multiplicidades algébricas, então:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j,$$

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\},$$

e

$$\dim \mathcal{N}(\mathbf{A}) = \# \{j : \lambda_j = 0\}.$$

Além disso,

$$\mathbf{A} \text{ é invertível} \iff \lambda_j \neq 0 \text{ para todo } j.$$

Comprovação. Pela propriedade cíclica do traço,

$$\begin{aligned} \text{tr}(\mathbf{A}) &= \text{tr}(\mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top) \\ &= \text{tr}(\Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top \mathbf{Q}_\mathbf{A}) \\ &= \text{tr}(\Lambda_\mathbf{A}) \\ &= \sum_{j=1}^p \lambda_j. \end{aligned}$$

Para o determinante,

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{Q}_\mathbf{A}) \det(\Lambda_\mathbf{A}) \det(\mathbf{Q}_\mathbf{A}^\top) \\ &= \det(\Lambda_\mathbf{A}), \end{aligned}$$

pois

$$\det(\mathbf{Q}_{\mathbf{A}}) \det(\mathbf{Q}_{\mathbf{A}}^{\top}) = \det(\mathbf{I}_p) = 1.$$

Como $\Lambda_{\mathbf{A}}$ é diagonal,

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j.$$

As matrizes $\mathbf{A}$ e $\Lambda_{\mathbf{A}}$ estão relacionadas por uma mudança de base invertível e possuem o mesmo posto. O posto de uma matriz diagonal é igual ao número de elementos diagonais não nulos. Portanto,

$$\text{posto}(\mathbf{A}) = \# \{j : \lambda_j \neq 0\}.$$

Pelo Teorema Posto–Nulidade,

$$\begin{aligned} \dim \mathcal{N}(\mathbf{A}) &= p - \text{posto}(\mathbf{A}) \\ &= \# \{j : \lambda_j = 0\}. \end{aligned}$$

Por fim, $\mathbf{A}$ é invertível se, e somente se, seu determinante é diferente de zero. Como

$$\det(\mathbf{A}) = \prod_{j=1}^p \lambda_j,$$

isso ocorre exatamente quando todos os autovalores são não nulos. □

Os autoespaços também fornecem descrições diretas do núcleo e da imagem.

Teorema 5.9 (Núcleo e imagem em termos dos autovetores). *Se*

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^{\top}$$

é a decomposição espectral de uma matriz simétrica, então

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}$$

e

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Consequentemente,

$$\mathcal{C}(\mathbf{A}) = \mathcal{N}(\mathbf{A})^\perp.$$

Comprovação. Todo vetor $\mathbf{x} \in \mathbb{R}^p$ pode ser escrito na base ortonormal de autovetores como

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j,$$

em que

$$z_j = \mathbf{q}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^p \lambda_j z_j \mathbf{q}_j.$$

A igualdade

$$\mathbf{A}\mathbf{x} = \mathbf{0}$$

ocorre se, e somente se,

$$\lambda_j z_j = 0$$

para todo j . Portanto, as coordenadas de $\mathbf{x}$ podem ser não nulas apenas nas direções associadas a autovalores iguais a zero. Logo,

$$\mathcal{N}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j = 0 \}.$$

Toda imagem $\mathbf{A}\mathbf{x}$ é uma combinação linear dos autovetores associados a autovalores não nulos. Assim,

$$\mathcal{C}(\mathbf{A}) \subseteq \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Reciprocamente, se $\lambda_j \neq 0$, então

$$\mathbf{q}_j = \mathbf{A} \left(\frac{1}{\lambda_j} \mathbf{q}_j \right),$$

de modo que $\mathbf{q}_j \in \mathcal{C}(\mathbf{A})$. Portanto,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{q}_j : \lambda_j \neq 0 \}.$$

Como os autovetores formam uma base ortonormal, os dois subespaços são complementos ortogonais. $\square$

Cada autovalor nulo identifica uma direção eliminada pela transformação. Cada autovalor não nulo identifica uma direção que permanece representada na imagem.

5.4.2 Formas quadráticas em coordenadas espectrais

Retomando a Definição 2.21, considere

$$q_{\mathbf{A}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Defina as coordenadas espectrais de $\mathbf{x}$ por

$$\mathbf{z} = \mathbf{Q}_{\mathbf{A}}^\top \mathbf{x}.$$

Como

$$\mathbf{x} = \mathbf{Q}_{\mathbf{A}} \mathbf{z},$$

tem-se

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^\top \mathbf{A} \mathbf{x} \\ &= \mathbf{z}^\top \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top \mathbf{Q}_{\mathbf{A}} \mathbf{z} \\ &= \mathbf{z}^\top \Lambda_{\mathbf{A}} \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2. \end{aligned}$$

A mudança ortogonal de coordenadas elimina os produtos cruzados. A contribuição da direção $\mathbf{q}_j$ para a forma quadrática é

$$\lambda_j z_j^2.$$

O sinal da forma quadrática é determinado pelos sinais dos autovalores.

Teorema 5.10 (Positividade e sinais dos autovalores). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica. Então:*

1. $\mathbf{A}$ é positiva definida se, e somente se,

$$\lambda_j > 0$$

para todo j ;

2. $\mathbf{A}$ é semidefinida positiva se, e somente se,

$$\lambda_j \geq 0$$

para todo j ;

3. $\mathbf{A}$ é negativa definida se, e somente se,

$$\lambda_j < 0$$

para todo j ;

4. $\mathbf{A}$ é semidefinida negativa se, e somente se,

$$\lambda_j \leq 0$$

para todo j ;

5. $\mathbf{A}$ é indefinida se, e somente se, possui pelo menos um autovalor positivo e pelo menos um autovalor negativo.

(Horn; Johnson, 2013)

Comprovação. Para qualquer $\mathbf{x} \in \mathbb{R}^p$, escreva

$$\mathbf{x} = \sum_{j=1}^p z_j \mathbf{q}_j.$$

Então,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2.$$

Se todos os autovalores são positivos e $\mathbf{x} \neq \mathbf{0}$, pelo menos uma coordenada z_j é não nula. Portanto,

$$\sum_{j=1}^p \lambda_j z_j^2 > 0,$$

e $\mathbf{A}$ é positiva definida.

Reciprocamente, se $\mathbf{A}$ é positiva definida, para cada autovetor unitário $\mathbf{q}_j$,

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j > 0.$$

Logo, todos os autovalores são positivos.

As caracterizações semidefinidas e negativas seguem pelo mesmo argumento.

Se existem autovalores $\lambda_i > 0$ e $\lambda_j < 0$, então

$$\mathbf{q}_i^\top \mathbf{A} \mathbf{q}_i = \lambda_i > 0$$

e

$$\mathbf{q}_j^\top \mathbf{A} \mathbf{q}_j = \lambda_j < 0.$$

Assim, a forma quadrática assume valores positivos e negativos, e a matriz é indefinida.

Reciprocamente, se a matriz é indefinida, a expressão

$$\sum_{j=1}^p \lambda_j z_j^2$$

deve assumir ambos os sinais. Isso exige a existência de autovalores positivos e negativos. $\square$

Uma matriz simétrica positiva definida é necessariamente invertível, pois todos os seus autovalores são positivos. Uma matriz semidefinida positiva pode ser singular quando possui pelo menos um autovalor igual a zero.

5.4.3 Superfícies de nível em coordenadas espectrais

Considere uma matriz positiva definida e a superfície de nível

$$\mathcal{S}_c(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{x}^\top \mathbf{A} \mathbf{x} = c\}, \quad c > 0.$$

Nas coordenadas espectrais,

$$\sum_{j=1}^p \lambda_j z_j^2 = c.$$

Como todos os autovalores são positivos,

$$\sum_{j=1}^p \frac{z_j^2}{c/\lambda_j} = 1.$$

Essa é a equação de um elipsoide. Suas direções principais são os autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p,$$

e o comprimento do semieixo associado a $\mathbf{q}_j$ é

$$r_j = \sqrt{\frac{c}{\lambda_j}}.$$

Autovalores maiores correspondem a semieixos menores. Autovalores menores correspondem a maior extensão da superfície na direção associada.

Para uma superfície centralizada em um vetor fixo $\mathbf{x}_0$,

$$(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{A} (\mathbf{x} - \mathbf{x}_0) = c,$$

os autovetores e os comprimentos dos semieixos permanecem os mesmos. O vetor $\mathbf{x}_0$ determina o centro do elipsoide.

Quando $\mathbf{A}$ é semidefinida positiva e singular, existem direções do núcleo nas quais a forma quadrática não se altera. Para $c > 0$, a superfície de nível é ilimitada nessas direções.

Quando $\mathbf{A}$ é indefinida, a forma quadrática possui parcelas positivas e negativas. Suas superfícies de nível deixam de ser elipsoides e podem apresentar formas hiperbólicas.

Exemplo 5.3 (Forma quadrática na base espectral). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Na base canônica,

$$\begin{aligned} q_{\mathbf{A}}(\mathbf{x}) &= \mathbf{x}^{\top} \mathbf{A} \mathbf{x} \\ &= 3x_1^2 + 2x_1x_2 + 3x_2^2. \end{aligned}$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

As coordenadas espectrais são

$$z_1 = \mathbf{q}_1^{\top} \mathbf{x} = \frac{x_1 + x_2}{\sqrt{2}}$$

e

$$z_2 = \mathbf{q}_2^{\top} \mathbf{x} = \frac{x_1 - x_2}{\sqrt{2}}.$$

Nessas coordenadas,

$$q_{\mathbf{A}}(\mathbf{x}) = 4z_1^2 + 2z_2^2.$$

A superfície de nível

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 8$$

pode ser escrita como

$$4z_1^2 + 2z_2^2 = 8,$$

ou

$$\frac{z_1^2}{2} + \frac{z_2^2}{4} = 1.$$

O elipsoide possui semieixo de comprimento

$$\sqrt{2}$$

na direção de $\mathbf{q}_1$ e semieixo de comprimento

$$2$$

na direção de $\mathbf{q}_2$. A direção associada ao menor autovalor apresenta a maior extensão.

A representação

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

também permite comparar os valores assumidos pela forma quadrática entre vetores de mesmo comprimento.

Se

$$\|\mathbf{x}\| = 1,$$

então, como a mudança de coordenadas é ortogonal,

$$\|\mathbf{z}\| = 1$$

e

$$\sum_{j=1}^p z_j^2 = 1.$$

Nesse caso,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2$$

é uma média ponderada dos autovalores, com pesos não negativos que somam 1. Essa observação conduz ao quociente de Rayleigh e à caracterização variacional dos autovalores extremos.

5.5 Quociente de Rayleigh e otimização espectral

A decomposição espectral mostra que uma matriz simétrica atua por escalonamentos independentes em direções ortogonais. Essa estrutura permite identificar as direções nas quais uma forma quadrática assume seus maiores e menores valores.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

e um vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p.$$

Definição 5.6 (Quociente de Rayleigh). O **quociente de Rayleigh** de $\mathbf{A}$ avaliado em $\mathbf{a} \neq \mathbf{0}$ é

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}}.$$

O denominador normaliza a forma quadrática pelo comprimento ao quadrado do vetor. Por isso, o quociente depende da direção de $\mathbf{a}$, e não de sua magnitude.

Para qualquer escalar $c \neq 0$,

$$\begin{aligned}\mathcal{R}_{\mathbf{A}}(\mathbf{ca}) &= \frac{(\mathbf{ca})^\top \mathbf{A}(\mathbf{ca})}{(\mathbf{ca})^\top (\mathbf{ca})} \\ &= \frac{c^2 \mathbf{a}^\top \mathbf{A} \mathbf{a}}{c^2 \mathbf{a}^\top \mathbf{a}} \\ &= \mathcal{R}_{\mathbf{A}}(\mathbf{a}).\end{aligned}$$

Assim, todos os vetores não nulos de uma mesma reta produzem o mesmo valor.

Quando

$$\|\mathbf{a}\| = 1,$$

tem-se

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

Desse modo, estudar o quociente entre todos os vetores não nulos equivale a estudar a forma quadrática sobre a esfera unitária.

5.5.1 Representação espectral

Considere a decomposição espectral

$$\mathbf{A} = \mathbf{Q}_{\mathbf{A}} \Lambda_{\mathbf{A}} \mathbf{Q}_{\mathbf{A}}^\top,$$

com autovalores ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

Escreva

$$\mathbf{a} = \mathbf{Q}_{\mathbf{A}} \mathbf{z}.$$

Como $\mathbf{Q}_{\mathbf{A}}$ é ortogonal,

$$\mathbf{a}^\top \mathbf{a} = \mathbf{z}^\top \mathbf{z} = \sum_{j=1}^p z_j^2.$$

Além disso,

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{z}^\top \Lambda \mathbf{z} \\ &= \sum_{j=1}^p \lambda_j z_j^2.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

Definindo

$$\omega_j = \frac{z_j^2}{\sum_{\ell=1}^p z_\ell^2},$$

tem-se

$$\omega_j \geq 0$$

e

$$\sum_{j=1}^p \omega_j = 1.$$

Logo,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j.$$

O quociente de Rayleigh é uma média ponderada dos autovalores. Os pesos medem a participação da direção de $\mathbf{a}$ em cada autoespaço.

Teorema 5.11 (Extremos do quociente de Rayleigh). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ uma matriz simétrica, com autovalores ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p.$$

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p.$$

O máximo é atingido pelos autovetores associados a λ_1 , e o mínimo é atingido pelos autovetores associados a λ_p . (Horn; Johnson, 2013)

Comprovação. Como

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \sum_{j=1}^p \omega_j \lambda_j,$$

com pesos não negativos que somam 1, o quociente não pode ser menor que o menor autovalor nem maior que o maior:

$$\lambda_p \leq \sum_{j=1}^p \omega_j \lambda_j \leq \lambda_1.$$

Se $\mathbf{a}$ pertence ao autoespaço associado a λ_1 , então

$$\mathbf{A}\mathbf{a} = \lambda_1 \mathbf{a},$$

e

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \lambda_1 \mathbf{a}}{\mathbf{a}^\top \mathbf{a}} = \lambda_1.$$

Portanto, o limite superior é atingido.

Analogamente, se $\mathbf{a}$ pertence ao autoespaço associado a λ_p ,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \lambda_p,$$

e o limite inferior também é atingido. □

Se o maior autovalor é simples, as direções que maximizam o quociente são

$$\text{span}(\mathbf{q}_1).$$

Se sua multiplicidade é maior que 1, todo vetor não nulo do autoespaço correspondente produz o mesmo valor máximo. Nesse caso, a solução é um subespaço, e não uma direção individual única.

5.5.2 Exemplo bidimensional

Exemplo 5.4 (Quociente de Rayleigh em diferentes direções). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

Os autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Um vetor unitário do plano pode ser escrito como

$$\mathbf{a}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

Como

$$\mathbf{a}(\theta)^\top \mathbf{a}(\theta) = 1,$$

o quociente de Rayleigh é

$$\begin{aligned} \mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta)) &= \mathbf{a}(\theta)^\top \mathbf{A} \mathbf{a}(\theta) \\ &= 3 \cos^2 \theta + 2 \cos \theta \sin \theta + 3 \sin^2 \theta \\ &= 3 + \sin(2\theta). \end{aligned}$$

O valor máximo é

$$4,$$

atingido quando

$$\sin(2\theta) = 1.$$

Uma das direções correspondentes é

$$\theta = \frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

O valor mínimo é

$$2,$$

atingido quando

$$\sin(2\theta) = -1.$$

Uma direção correspondente é

$$\theta = -\frac{\pi}{4},$$

associada ao autovetor

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A Figura 5.4 mostra a variação de

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}(\theta))$$

ao longo das direções da esfera unitária.

As direções opostas representam a mesma reta e, por isso, produzem o mesmo valor do quociente. Os máximos aparecem em duas posições angulares separadas por π , assim como os mínimos.




Figura 5.4: O quociente de Rayleigh assume seus valores extremos nas direções dos autovetores associados aos autovalores máximo e mínimo.

5.5.3 Formulação com restrição de norma

A invariância à escala permite substituir o problema sobre vetores não nulos por um problema sobre a esfera unitária:

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^{\top} \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^{\top} \mathbf{a} = 1.$$

A restrição impede que a função objetivo seja aumentada apenas pela multiplicação de $\mathbf{a}$ por uma constante.

Sem essa restrição, se existe um vetor para o qual

$$\mathbf{a}^{\top} \mathbf{A} \mathbf{a} > 0,$$

então

$$(\mathbf{c} \mathbf{a})^{\top} \mathbf{A} (\mathbf{c} \mathbf{a}) = c^2 \mathbf{a}^{\top} \mathbf{A} \mathbf{a}$$

pode crescer indefinidamente à medida que $|c|$ aumenta.

5.5.4 Multiplicadores de Lagrange

Para obter as direções estacionárias do problema restrito, considere a função lagrangiana

$$\mathcal{L}(\mathbf{a}, \lambda) = \mathbf{a}^{\top} \mathbf{A} \mathbf{a} - \lambda (\mathbf{a}^{\top} \mathbf{a} - 1).$$

Como $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{a}} (\mathbf{a}^{\top} \mathbf{A} \mathbf{a}) = 2\mathbf{A} \mathbf{a},$$

e

$$\nabla_{\mathbf{a}} (\mathbf{a}^\top \mathbf{a}) = 2\mathbf{a}.$$

A condição de primeira ordem é

$$\nabla_{\mathbf{a}} \mathcal{L} = \mathbf{0},$$

isto é,

$$2\mathbf{A}\mathbf{a} - 2\lambda\mathbf{a} = \mathbf{0}.$$

Portanto,

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{a}.$$

As direções estacionárias do problema são autovetores de $\mathbf{A}$. Multiplicando a equação à esquerda por $\mathbf{a}^\top$ e utilizando

$$\mathbf{a}^\top \mathbf{a} = 1,$$

obtém-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A}\mathbf{a} &= \lambda \mathbf{a}^\top \mathbf{a} \\ &= \lambda. \end{aligned}$$

O valor da função objetivo em um autovetor unitário é o autovalor correspondente. Assim:

- o maior autovalor fornece o máximo global;
- o menor autovalor fornece o mínimo global;
- os demais autovalores correspondem a valores estacionários intermediários.

Teorema 5.12 (Autovalores como valores estacionários). *Seja $\mathbf{A} \in \mathbb{R}^{p \times p}$ simétrica. Os pontos estacionários do problema*

$$\text{otimizar} \quad \mathbf{a}^\top \mathbf{A}\mathbf{a}$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

são os autovetores unitários de $\mathbf{A}$. O valor da função objetivo em um autovetor associado a λ é igual a λ .

Esse resultado explica por que problemas de maximização de variância, separação ou associação conduzem frequentemente a equações de autovalores. Quando a função objetivo é uma forma quadrática e a restrição fixa o comprimento, as condições de primeira ordem produzem uma equação espectral.

5.5.5 Direções sucessivas

Depois de encontrar a direção associada ao maior autovalor, pode-se procurar a direção de maior valor entre aquelas ortogonais à primeira.

Considere

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

e uma base ortonormal de autovetores

$$\mathbf{q}_1, \dots, \mathbf{q}_p.$$

O segundo problema é

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_1 = 0.$$

A restrição de ortogonalidade elimina qualquer componente na direção de $\mathbf{q}_1$. O maior valor restante é λ_2 , atingido em $\mathbf{q}_2$ quando λ_2 é simples.

De forma geral, a k -ésima direção pode ser obtida por

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{a} = 1$$

e

$$\mathbf{a}^\top \mathbf{q}_j = 0, \quad j = 1, \dots, k-1.$$

Teorema 5.13 (Caracterização variacional de direções sucessivas). *Se $\mathbf{A}$ é simétrica e seus autovalores estão ordenados como*

$$\lambda_1 \geq \dots \geq \lambda_p,$$

então

$$\lambda_k = \max_{\substack{\mathbf{a}^\top \mathbf{a} = 1 \\ \mathbf{a}^\top \mathbf{q}_j = 0, j < k}} \mathbf{a}^\top \mathbf{A} \mathbf{a}.$$

O máximo é atingido por qualquer autovetor unitário associado a λ_k que satisfaça as restrições. (Horn; Johnson, 2013)

Comprovação. Se $\mathbf{a}$ é ortogonal a

$$\mathbf{q}_1, \dots, \mathbf{q}_{k-1},$$

sua expansão espectral possui a forma

$$\mathbf{a} = \sum_{j=k}^p z_j \mathbf{q}_j.$$

Como $\|\mathbf{a}\| = 1$,

$$\sum_{j=k}^p z_j^2 = 1.$$

Logo,

$$\begin{aligned}
\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \sum_{j=k}^p \lambda_j z_j^2 \\
&\leq \lambda_k \sum_{j=k}^p z_j^2 \\
&= \lambda_k.
\end{aligned}$$

Tomando

$$\mathbf{a} = \mathbf{q}_k,$$

obtém-se

$$\mathbf{q}_k^\top \mathbf{A} \mathbf{q}_k = \lambda_k.$$

Portanto, o limite superior é atingido. □

Quando há autovalores repetidos, as direções sucessivas dentro do mesmo autoespaço não são individualmente determinadas. Qualquer base ortonormal desse autoespaço fornece o mesmo valor da função objetivo e descreve o mesmo subespaço ótimo.

A caracterização variacional relaciona três objetos:

forma quadrática $\longleftrightarrow$ problema de otimização $\longleftrightarrow$ equação de autovalores.

A decomposição espectral também permite aplicar funções escalares aos autovalores e, desse modo, definir potências, raízes, inversas e outras funções de matrizes simétricas.

5.6 Funções espectrais de matrizes

A decomposição espectral permite construir novas matrizes aplicando uma função escalar aos autovalores. Esse procedimento fornece expressões para potências, inversas, raízes quadradas, exponenciais, logaritmos e pseudoinversas de matrizes simétricas.

Considere uma matriz simétrica

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Se f é uma função escalar definida em todos os autovalores de $\mathbf{A}$, pode-se aplicá-la aos elementos diagonais:

$$f(\Lambda_\mathbf{A}) = \text{diag}(f(\lambda_1), \dots, f(\lambda_p)).$$

Definição 5.7 (Função espectral de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica e seja f uma função definida no espectro de $\mathbf{A}$.

A **função espectral** $f(\mathbf{A})$ é definida por

$$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A} f(\Lambda_\mathbf{A}) \mathbf{Q}_\mathbf{A}^\top.$$

A definição não depende da base ortonormal escolhida dentro de um autoespaço associado a um autovalor repetido.

De fato, considerando os autovalores distintos

$$\lambda^{(1)}, \dots, \lambda^{(s)}$$

e os respectivos projetores espectrais, a função também pode ser escrita como

$$f(\mathbf{A}) = \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}}.$$

Os projetores são determinados pelos autoespaços, independentemente da base ortonormal utilizada para representá-los.

5.6.1 Ação sobre os autoespaços

Teorema 5.14 (Ação de uma função espectral). *Se $\mathbf{v}$ pertence ao autoespaço de $\mathbf{A}$ associado ao autovalor λ , então*

$$f(\mathbf{A})\mathbf{v} = f(\lambda)\mathbf{v}.$$

(Horn; Johnson, 1991)

Comprovação. Como

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor $\mathbf{v}$ pertence à imagem do projetor

$$\Pi_\lambda$$

e é anulado pelos projetores associados aos demais autovalores. Assim,

$$\begin{aligned} f(\mathbf{A})\mathbf{v} &= \sum_{h=1}^s f(\lambda^{(h)}) \Pi_{\lambda^{(h)}} \mathbf{v} \\ &= f(\lambda)\mathbf{v}. \end{aligned}$$

□

Portanto, todo autovetor de $\mathbf{A}$ também é autovetor de $f(\mathbf{A})$, com autovalor transformado em $f(\lambda)$.

A função pode fazer autovalores originalmente distintos assumirem o mesmo valor. Se

$$f(\lambda_i) = f(\lambda_j),$$

os autoespaços correspondentes passam a pertencer ao mesmo autoespaço de $f(\mathbf{A})$. Por isso, $f(\mathbf{A})$ pode possuir autoespaços de dimensão maior que os autoespaços individuais de $\mathbf{A}$.

5.6.2 Potências inteiras

Para um inteiro $k \geq 0$, escolha

$$f(\lambda) = \lambda^k.$$

Então,

$$\mathbf{A}^k = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^k \mathbf{Q}_\mathbf{A}^\top,$$

com

$$\Lambda_\mathbf{A}^k = \text{diag}(\lambda_1^k, \dots, \lambda_p^k).$$

Essa expressão coincide com a fórmula obtida pela diagonalização, mas a ortogonalidade de $\mathbf{Q}_\mathbf{A}$ fornece

$$\mathbf{Q}_\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A}^\top.$$

Exemplo 5.5 (Potência de uma matriz simétrica). Considere

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

com decomposição espectral

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Então,

$$\mathbf{A}^2 = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Efetuando a multiplicação,

$$\mathbf{A}^2 = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

A aplicação de $\mathbf{A}$ duas vezes multiplica a componente na direção de $\mathbf{q}_1$ por

$$4^2 = 16$$

e a componente na direção de $\mathbf{q}_2$ por

$$2^2 = 4.$$

5.6.3 Inversa espectral

Se todos os autovalores são diferentes de zero, define-se

$$f(\lambda) = \frac{1}{\lambda}.$$

Nesse caso,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

A inversa desfaz o escalonamento em cada direção espectral:

$$\mathbf{A}^{-1} \mathbf{q}_j = \frac{1}{\lambda_j} \mathbf{q}_j.$$

Para o exemplo anterior,

$$\mathbf{A}^{-1} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/2 \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top,$$

o que resulta em

$$\mathbf{A}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}.$$

Se pelo menos um autovalor é igual a zero, a inversa usual não existe.

5.6.4 Raiz quadrada principal

Para uma matriz semidefinida positiva, todos os autovalores são não negativos. Assim, pode-se definir

$$f(\lambda) = \sqrt{\lambda}.$$

Definição 5.8 (Raiz quadrada principal). Se

$$\mathbf{A} \succeq 0,$$

a **raiz quadrada principal** de $\mathbf{A}$ é

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{1/2} = \text{diag} \left(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p} \right).$$

A matriz $\mathbf{A}^{1/2}$ é simétrica, semidefinida positiva e satisfaz

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}.$$

Além disso, ela é a única matriz simétrica semidefinida positiva com essa propriedade.

Para

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix},$$

tem-se

$$\mathbf{A}^{1/2} = \mathbf{Q}_\mathbf{A} \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix} \mathbf{Q}_\mathbf{A}^\top.$$

Logo,

$$\mathbf{A}^{1/2} = \frac{1}{2} \begin{bmatrix} 2 + \sqrt{2} & 2 - \sqrt{2} \\ 2 - \sqrt{2} & 2 + \sqrt{2} \end{bmatrix}.$$

A raiz quadrada principal multiplica as componentes espectrais por

$$\sqrt{\lambda_j}.$$

Aplicada duas vezes, ela produz o escalonamento original por λ_j .

5.6.5 Raiz quadrada inversa

Se

$$\mathbf{A} \succ 0,$$

todos os autovalores são estritamente positivos. Define-se então

$$\mathbf{A}^{-1/2} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Essa matriz satisfaz

$$\mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} = \mathbf{I}_p.$$

De fato,

$$\begin{aligned} \mathbf{A}^{-1/2} \mathbf{A} \mathbf{A}^{-1/2} &= \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \Lambda_\mathbf{A} \Lambda_\mathbf{A}^{-1/2} \mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{Q}_\mathbf{A} \mathbf{I}_p \mathbf{Q}_\mathbf{A}^\top \\ &= \mathbf{I}_p. \end{aligned}$$

A transformação

$$\mathbf{z} = \mathbf{A}^{-1/2} \mathbf{x}$$

remove os diferentes fatores de escala determinados por $\mathbf{A}$. Ela também converte a forma quadrática associada à inversa em uma norma euclidiana:

$$\begin{aligned}
\mathbf{x}^\top \mathbf{A}^{-1} \mathbf{x} &= \mathbf{x}^\top \mathbf{A}^{-1/2} \mathbf{A}^{-1/2} \mathbf{x} \\
&= \mathbf{z}^\top \mathbf{z} \\
&= \|\mathbf{z}\|^2.
\end{aligned}$$

Essa transformação será retomada posteriormente como uma operação de branqueamento quando $\mathbf{A}$ representar uma matriz de covariâncias.

5.6.6 Pseudoinversa espectral

Quando uma matriz possui autovalores nulos, não é possível inverter sua ação em todas as direções. Ainda assim, é possível inverter os escalonamentos nas direções associadas a autovalores não nulos.

Definição 5.9 (Pseudoinversa de uma matriz simétrica). Seja

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top$$

uma matriz simétrica.

Define-se

$$\lambda_j^+ = \begin{cases} 1/\lambda_j, & \lambda_j \neq 0, \\ 0, & \lambda_j = 0. \end{cases}$$

A **pseudoinversa de Moore–Penrose** de $\mathbf{A}$ é

$$\mathbf{A}^+ = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A}^+ \mathbf{Q}_\mathbf{A}^\top,$$

em que

$$\Lambda_\mathbf{A}^+ = \text{diag}(\lambda_1^+, \dots, \lambda_p^+).$$

A pseudoinversa divide a componente associada a cada autovalor não nulo por esse autovalor e anula as componentes pertencentes ao núcleo.

Exemplo 5.6 (Pseudoinversa de uma matriz singular). Considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 0,$$

com autovetores unitários

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A matriz $\mathbf{A}_0$ não é invertível porque possui um autovalor nulo. Para a pseudoinversa,

$$(\Lambda_{\mathbf{A}_0})^+ = \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix}.$$

Portanto,

$$\begin{aligned} \mathbf{A}_0^+ &= \mathbf{Q}_{\mathbf{A}_0} \begin{bmatrix} 1/4 & 0 \\ 0 & 0 \end{bmatrix} \mathbf{Q}_{\mathbf{A}_0}^\top \\ &= \frac{1}{8} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}. \end{aligned}$$

A componente na direção de $\mathbf{q}_1$ é dividida por 4. A componente na direção de $\mathbf{q}_2$, pertencente ao núcleo de $\mathbf{A}_0$, é anulada.

Quando $\mathbf{A}$ é invertível,

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

A pseudoinversa será retomada no capítulo seguinte, no qual será definida para matrizes retangulares por meio da decomposição em valores singulares.

5.6.7 Exponencial e logaritmo matriciais

A função exponencial é definida para qualquer matriz simétrica por

$$\exp(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(e^{\lambda_1}, \dots, e^{\lambda_p}) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

Como

$$e^{\lambda_j} > 0,$$

a matriz $\exp(\mathbf{A})$ é positiva definida.

A exponencial matricial também pode ser representada pela série

$$\exp(\mathbf{A}) = \sum_{k=0}^{\infty} \frac{\mathbf{A}^k}{k!}.$$

Para uma matriz positiva definida, o logaritmo principal é

$$\log(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} \operatorname{diag}(\log \lambda_1, \dots, \log \lambda_p) \mathbf{Q}_{\mathbf{A}}^{\top}.$$

As identidades escalares são preservadas espectralmente:

$$\exp(\log(\mathbf{A})) = \mathbf{A}$$

para $\mathbf{A} \succ 0$, e

$$\log(\exp(\mathbf{A})) = \mathbf{A}$$

para toda matriz simétrica real.

A Tabela 5.1 reúne as principais funções desenvolvidas nesta seção.

Tabela 5.1: Principais funções espectrais de matrizes simétricas.

Função	Ação sobre λ_j	Condição
$\mathbf{A}^k$	λ_j^k	k inteiro não negativo
$\mathbf{A}^{-1}$	$1/\lambda_j$	$\lambda_j \neq 0$ para todo j
$\mathbf{A}^{1/2}$	$\sqrt{\lambda_j}$	$\mathbf{A} \succeq 0$
$\mathbf{A}^{-1/2}$	$1/\sqrt{\lambda_j}$	$\mathbf{A} \succ 0$

Função	Ação sobre λ_j	Condição
$\mathbf{A}^+$	$1/\lambda_j$ se $\lambda_j \neq 0$; 0 se $\lambda_j = 0$	$\mathbf{A}$ simétrica
$\exp(\mathbf{A})$	e^{λ_j}	$\mathbf{A}$ simétrica
$\log(\mathbf{A})$	$\log \lambda_j$	$\mathbf{A} \succ 0$

As funções espectrais transformam separadamente cada autoespaço. As raízes quadradas e suas inversas também permitem converter problemas definidos por duas formas quadráticas em problemas espectrais ordinários. Essa construção conduz aos autovalores generalizados.

5.7 Autovalores generalizados

O quociente de Rayleigh compara uma forma quadrática com a norma euclidiana do vetor. Em outros problemas, a normalização também é definida por uma forma quadrática:

$$\mathbf{a}^\top \mathbf{M} \mathbf{a},$$

em que

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Conforme a Definição 3.17, a matriz $\mathbf{M}$ determina o produto interno

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{M}} = \mathbf{x}^\top \mathbf{M} \mathbf{y}$$

e a norma

$$\|\mathbf{x}\|_{\mathbf{M}} = \sqrt{\mathbf{x}^\top \mathbf{M} \mathbf{x}}.$$

Nesse contexto, procura-se uma direção que compare as formas quadráticas associadas a duas matrizes.

Definição 5.10 (Autovalor e autovetor generalizados). Sejam

$$\mathbf{A}, \mathbf{M} \in \mathbb{R}^{p \times p},$$

com

$$\mathbf{A} = \mathbf{A}^\top$$

e

$$\mathbf{M} = \mathbf{M}^\top \succ 0.$$

Um escalar real

$$\lambda \in \mathbb{R}$$

é um **autovalor generalizado** do par $(\mathbf{A}, \mathbf{M})$ quando existe um vetor não nulo

$$\mathbf{v} \in \mathbb{R}^p$$

tal que

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}.$$

O vetor $\mathbf{v}$ é denominado **autovetor generalizado** associado a λ .

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

recupera-se o problema ordinário:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}.$$

A equação generalizada pode ser reorganizada como

$$(\mathbf{A} - \lambda\mathbf{M})\mathbf{v} = \mathbf{0}.$$

Para que existam soluções não triviais, é necessário que

$$\det(\mathbf{A} - \lambda\mathbf{M}) = 0.$$

Essa equação determina os autovalores generalizados do par.

5.7.1 Quociente de Rayleigh generalizado

Definição 5.11 (Quociente de Rayleigh generalizado). Para

$$\mathbf{a} \neq \mathbf{0},$$

o **quociente de Rayleigh generalizado** associado ao par $(\mathbf{A}, \mathbf{M})$ é

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{M} \mathbf{a}}.$$

Como $\mathbf{M} \succ 0$,

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Portanto, o quociente está definido em todas as direções não nulas.

Assim como no caso ordinário, ele é invariante à escala:

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(c\mathbf{a}) = \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a})$$

para todo $c \neq 0$.

O problema

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a})$$

é equivalente a

$$\max_{\mathbf{a}} \mathbf{a}^\top \mathbf{A} \mathbf{a},$$

sujeito a

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = 1.$$

A restrição fixa o comprimento de $\mathbf{a}$ segundo a geometria determinada por $\mathbf{M}$.

A função lagrangiana é

$$\mathcal{L}(\mathbf{a}, \lambda) = \mathbf{a}^\top \mathbf{A} \mathbf{a} - \lambda (\mathbf{a}^\top \mathbf{M} \mathbf{a} - 1).$$

Como $\mathbf{A}$ e $\mathbf{M}$ são simétricas,

$$\nabla_{\mathbf{a}} \mathcal{L} = 2\mathbf{A}\mathbf{a} - 2\lambda\mathbf{M}\mathbf{a}.$$

A condição de primeira ordem produz

$$\mathbf{A}\mathbf{a} = \lambda\mathbf{M}\mathbf{a}.$$

Portanto, os pontos estacionários do problema restrito são autovetores generalizados.

Multiplicando essa equação à esquerda por $\mathbf{a}^\top$,

$$\mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda \mathbf{a}^\top \mathbf{M}\mathbf{a}.$$

Se

$$\mathbf{a}^\top \mathbf{M}\mathbf{a} = 1,$$

então

$$\mathbf{a}^\top \mathbf{A}\mathbf{a} = \lambda.$$

O autovalor generalizado é o valor assumido pela função objetivo na direção generalizada normalizada.

5.7.2 Redução a um problema espectral ordinário

Como $\mathbf{M} \succ 0$, existem as matrizes simétricas

$$\mathbf{M}^{1/2}$$

e

$$\mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{u} = \mathbf{M}^{1/2}\mathbf{v}.$$

Consequentemente,

$$\mathbf{v} = \mathbf{M}^{-1/2}\mathbf{u}.$$

Substituindo na equação generalizada,

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}\mathbf{M}^{-1/2}\mathbf{u}.$$

Como

$$\mathbf{M}\mathbf{M}^{-1/2} = \mathbf{M}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{M}^{-1/2}\mathbf{u} = \lambda\mathbf{M}^{1/2}\mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{M}^{-1/2}$,

$$(\mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2})\mathbf{u} = \lambda\mathbf{u}.$$

Defina

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2}\mathbf{A}\mathbf{M}^{-1/2}.$$

Como $\mathbf{A}$ e $\mathbf{M}^{-1/2}$ são simétricas,

$$\tilde{\mathbf{A}}^\top = \tilde{\mathbf{A}}.$$

Assim, o problema generalizado é convertido em um problema ordinário para uma matriz simétrica:

$$\tilde{\mathbf{A}}\mathbf{u} = \lambda\mathbf{u}.$$

Essa transformação também converte o quociente generalizado em um quociente ordinário. Como

$$\mathbf{a} = \mathbf{M}^{-1/2}\mathbf{u},$$

tem-se

$$\begin{aligned}\mathbf{a}^\top \mathbf{M} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \mathbf{u}\end{aligned}$$

e

$$\begin{aligned}\mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{u}^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{u} \\ &= \mathbf{u}^\top \tilde{\mathbf{A}} \mathbf{u}.\end{aligned}$$

Portanto,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}).$$

A mudança de variáveis

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{v}$$

converte a norma induzida por $\mathbf{M}$ na norma euclidiana. A matriz $\mathbf{M}^{-1/2}$ realiza a transformação inversa, levando as coordenadas euclidianas de $\mathbf{u}$ novamente às coordenadas originais de $\mathbf{v}$. O problema generalizado pode, então, ser analisado pelos resultados do Teorema Espectral e do quociente de Rayleigh ordinário.

Teorema 5.15 (Extremos do quociente de Rayleigh generalizado). *Sejam $\mathbf{A}$ simétrica e $\mathbf{M}$ positiva definida. Denote por*

$$\lambda_1 \geq \dots \geq \lambda_p$$

os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$.

Então, para todo $\mathbf{a} \neq \mathbf{0}$,

$$\lambda_p \leq \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) \leq \lambda_1.$$

Além disso,

$$\max_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_1$$

e

$$\min_{\mathbf{a} \neq \mathbf{0}} \mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \lambda_p.$$

Comprovação. A transformação

$$\mathbf{u} = \mathbf{M}^{1/2} \mathbf{a}$$

é invertível e estabelece

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \mathcal{R}_{\tilde{\mathbf{A}}}(\mathbf{u}),$$

em que

$$\tilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}$$

é simétrica.

Os autovalores ordinários de $\tilde{\mathbf{A}}$ são os autovalores generalizados do par $(\mathbf{A}, \mathbf{M})$. Aplicando o Teorema 5.11 a $\tilde{\mathbf{A}}$, obtêm-se os limites e os extremos apresentados. $\square$

5.7.3 Ortogonalidade na métrica de $\mathbf{M}$

Os autovetores generalizados não precisam ser ortogonais segundo o produto interno euclidiano. Eles podem, entretanto, ser escolhidos ortonormais na geometria determinada por $\mathbf{M}$.

Teorema 5.16 (Ortogonalidade de autovetores generalizados). *Sejam $\mathbf{v}_i$ e $\mathbf{v}_j$ autovetores generalizados associados a autovalores distintos λ_i e λ_j do par $(\mathbf{A}, \mathbf{M})$.*

Então,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

(Horn; Johnson, 2013)

Comprovação. Como

$$\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{M} \mathbf{v}_i$$

e

$$\mathbf{A} \mathbf{v}_j = \lambda_j \mathbf{M} \mathbf{v}_j,$$

tem-se

$$\begin{aligned}
\lambda_i \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j &= (\mathbf{A} \mathbf{v}_i)^\top \mathbf{v}_j \\
&= \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{v}_j \\
&= \mathbf{v}_i^\top \mathbf{A} \mathbf{v}_j \\
&= \lambda_j \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j.
\end{aligned}$$

Logo,

$$(\lambda_i - \lambda_j) \mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

Como $\lambda_i \neq \lambda_j$,

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = 0.$$

□

Os autovetores podem ser normalizados para satisfazer

$$\mathbf{v}_j^\top \mathbf{M} \mathbf{v}_j = 1.$$

Assim, uma base de autovetores generalizados pode ser escolhida de modo que

$$\mathbf{v}_i^\top \mathbf{M} \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Essa é a ortonormalidade na métrica induzida por $\mathbf{M}$.

5.7.4 Diagonalização simultânea por congruência

Seja

$$\widetilde{\mathbf{A}} = \mathbf{Q}_g \mathbf{A}_g \mathbf{Q}_g^\top$$

a decomposição espectral da matriz transformada

$$\widetilde{\mathbf{A}} = \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Defina

$$\mathbf{P}_g = \mathbf{M}^{-1/2} \mathbf{Q}_g.$$

As colunas de $\mathbf{P}_g$ são autovetores generalizados. De fato,

$$\begin{aligned} \mathbf{A} \mathbf{P}_g &= \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \mathbf{M}^{1/2} \mathbf{Q}_g \Lambda_g \\ &= \mathbf{M} \mathbf{P}_g \Lambda_g. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{P}_g^\top \mathbf{M} \mathbf{P}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{M} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \mathbf{Q}_g \\ &= \mathbf{I}_p, \end{aligned}$$

e

$$\begin{aligned} \mathbf{P}_g^\top \mathbf{A} \mathbf{P}_g &= \mathbf{Q}_g^\top \mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2} \mathbf{Q}_g \\ &= \mathbf{Q}_g^\top \tilde{\mathbf{A}} \mathbf{Q}_g \\ &= \Lambda_g. \end{aligned}$$

Portanto,

$$\mathbf{P}_g^\top \mathbf{M} \mathbf{P}_g = \mathbf{I}_p$$

e

$$\mathbf{P}_g^\top \mathbf{A} \mathbf{P}_g = \Lambda_g.$$

As matrizes $\mathbf{A}$ e $\mathbf{M}$ são diagonalizadas simultaneamente por uma transformação de congruência. Essa operação difere da semelhança

$$\mathbf{P}^{-1} \mathbf{A} \mathbf{P},$$

utilizada para representar um único operador em outra base.

Na nova base:

- a forma quadrática associada a $\mathbf{M}$ torna-se a norma euclidiana;
- a forma quadrática associada a $\mathbf{A}$ torna-se diagonal.

Se

$$\mathbf{a} = \mathbf{P}_g \mathbf{z},$$

então

$$\mathbf{a}^\top \mathbf{M} \mathbf{a} = \mathbf{z}^\top \mathbf{z}$$

e

$$\mathbf{a}^\top \mathbf{A} \mathbf{a} = \mathbf{z}^\top \Lambda_g \mathbf{z}.$$

Consequentemente,

$$\mathcal{R}_{\mathbf{A}, \mathbf{M}}(\mathbf{a}) = \frac{\sum_{j=1}^p \lambda_j z_j^2}{\sum_{j=1}^p z_j^2}.$$

O quociente generalizado assume, nessa base, a mesma forma do quociente de Rayleigh ordinário.

5.7.5 Exemplo numérico

Exemplo 5.7 (Autovalores generalizados de duas formas quadráticas). Considere

$$\mathbf{A} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

e

$$\mathbf{M} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes são simétricas e $\mathbf{M}$ é positiva definida.

Os autovalores generalizados são obtidos por

$$\det(\mathbf{A} - \lambda \mathbf{M}) = 0.$$

Como

$$\mathbf{A} - \lambda \mathbf{M} = \begin{bmatrix} 5 - 2\lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix},$$

tem-se

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{M}) &= (5 - 2\lambda)(2 - \lambda) - 1 \\ &= 2\lambda^2 - 9\lambda + 9 \\ &= (2\lambda - 3)(\lambda - 3). \end{aligned}$$

Portanto,

$$\lambda_1 = 3$$

e

$$\lambda_2 = \frac{3}{2}.$$

Para $\lambda_1 = 3$,

$$\mathbf{A} - 3\mathbf{M} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema fornece

$$v_2 = v_1,$$

de modo que um autovetor generalizado é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

De fato,

$$\mathbf{A}\mathbf{v}_1 = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

e

$$3\mathbf{M}\mathbf{v}_1 = 3 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}.$$

Para

$$\lambda_2 = \frac{3}{2},$$

tem-se

$$\mathbf{A} - \frac{3}{2}\mathbf{M} = \begin{bmatrix} 2 & 1 \\ 1 & 1/2 \end{bmatrix}.$$

O sistema conduz a

$$v_2 = -2v_1.$$

Assim, pode-se escolher

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Esses vetores não são ortogonais no produto interno euclidiano:

$$\mathbf{v}_1^\top \mathbf{v}_2 = -1.$$

Entretanto,

$$\begin{aligned} \mathbf{v}_1^\top \mathbf{M} \mathbf{v}_2 &= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ &= 0. \end{aligned}$$

Logo, eles são ortogonais na geometria determinada por $\mathbf{M}$.

Suas normas nessa métrica são

$$\|\mathbf{v}_1\|_{\mathbf{M}} = \sqrt{3}$$

e

$$\|\mathbf{v}_2\|_{\mathbf{M}} = \sqrt{6}.$$

Os autovetores generalizados normalizados são

$$\mathbf{p}_{g,1} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{p}_{g,2} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

Reunindo-os nas colunas de

$$\mathbf{P}_g = [\mathbf{p}_{g,1} \quad \mathbf{p}_{g,2}],$$

obtêm-se

$$\mathbf{P}_g^{\top} \mathbf{M} \mathbf{P}_g = \mathbf{I}_2$$

e

$$\mathbf{P}_g^{\top} \mathbf{A} \mathbf{P}_g = \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

O maior valor da razão

$$\frac{\mathbf{a}^{\top} \mathbf{A} \mathbf{a}}{\mathbf{a}^{\top} \mathbf{M} \mathbf{a}}$$

é 3 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_1$. O menor valor é 3/2 e ocorre no autoespaço generalizado gerado por $\mathbf{v}_2$.

Os autovalores generalizados permitem comparar duas formas quadráticas em uma geometria definida por uma delas. Essa estrutura será utilizada posteriormente em problemas que comparam diferentes fontes de dispersão ou associação, sem antecipar aqui a formulação específica dessas técnicas.

5.8 Síntese do capítulo

Um autovetor identifica uma direção invariante de uma transformação linear. Para

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v},$$

o vetor não nulo $\mathbf{v}$ permanece no autoespaço associado, enquanto o autovalor λ determina o escalonamento nessa direção.

Os autovalores são obtidos pela equação característica

$$\det(\mathbf{A} - \lambda\mathbf{I}_p) = 0,$$

e o autoespaço correspondente é

$$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p).$$

A multiplicidade algébrica registra a repetição de um autovalor no polinômio característico. A multiplicidade geométrica é a dimensão de seu autoespaço. Uma matriz é diagonalizável quando possui uma base formada por autovetores:

$$\mathbf{A} = \mathbf{P}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{P}_\mathbf{A}^{-1}.$$

Nessa base, a transformação atua separadamente sobre cada coordenada.

Para matrizes simétricas reais, o Teorema Espectral garante uma base ortonormal de autovetores e a decomposição

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

A decomposição espectral permite escrever

$$\mathbf{A} = \sum_{j=1}^p \lambda_j \mathbf{q}_j \mathbf{q}_j^\top,$$

mostrando que a matriz atua por escalonamentos independentes em direções ortogonais.

Traço, determinante, posto, invertibilidade e positividade podem ser determinados pelos autovalores. Nas coordenadas espectrais,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{j=1}^p \lambda_j z_j^2,$$

de modo que os sinais dos autovalores caracterizam o sinal da forma quadrática. Quando $\mathbf{A} \succ 0$, suas superfícies de nível são elipsoides alinhados aos autovetores.

O quociente de Rayleigh,

$$\mathcal{R}_{\mathbf{A}}(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{A} \mathbf{a}}{\mathbf{a}^\top \mathbf{a}},$$

assume valores entre o menor e o maior autovalor. Seus extremos são atingidos nos autoespaços correspondentes. A mesma estrutura surge ao otimizar uma forma quadrática sob uma restrição de norma, pois as condições de primeira ordem conduzem a

$$\mathbf{A} \mathbf{a} = \lambda \mathbf{a}.$$

A decomposição espectral também permite definir funções de matrizes:

$$f(\mathbf{A}) = \mathbf{Q}_{\mathbf{A}} f(\Lambda_{\mathbf{A}}) \mathbf{Q}_{\mathbf{A}}^\top.$$

Potências, inversas, raízes quadradas, pseudoinversas, exponenciais e logaritmos são obtidos aplicando a função correspondente a cada autovalor.

Quando a normalização é definida por uma matriz positiva definida $\mathbf{M}$, obtém-se o problema generalizado

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{M} \mathbf{v}.$$

A mudança de variáveis determinada por $\mathbf{M}^{1/2}$ converte esse problema em um problema espectral ordinário para

$$\mathbf{M}^{-1/2} \mathbf{A} \mathbf{M}^{-1/2}.$$

Os autovetores generalizados podem ser escolhidos ortonormais segundo a métrica de $\mathbf{M}$.

A Tabela 5.2 reúne as expressões principais.

Tabela 5.2: Síntese dos principais objetos espectrais desenvolvidos no capítulo.

Objeto	Expressão	Interpretação
Equação de autovalor	$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$	Identifica uma direção invariante
Autoespaço	$\mathcal{E}_\lambda = \mathcal{N}(\mathbf{A} - \lambda\mathbf{I}_p)$	Reúne os vetores associados a λ
Diagonalização	$\mathbf{A} = \mathbf{P}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{P}_\mathbf{A}^{-1}$	Representa o operador em uma base de autovetores
Decomposição espectral	$\mathbf{A} = \mathbf{Q}_\mathbf{A}\Lambda_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top$	Diagonaliza ortogonalmente uma matriz simétrica
Forma quadrática	$\mathbf{x}^\top \mathbf{A}\mathbf{x} = \sum_j \lambda_j z_j^2$	Separa as contribuições das direções espectrais
Quociente de Rayleigh	$\mathcal{R}_\mathbf{A}(\mathbf{a})$	Caracteriza os autovalores extremos
Função espectral	$f(\mathbf{A}) = \mathbf{Q}_\mathbf{A}f(\Lambda_\mathbf{A})\mathbf{Q}_\mathbf{A}^\top$	Aplica uma função aos autovalores
Problema generalizado	$\mathbf{A}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}$	Compara duas formas quadráticas

A diagonalização depende da existência de uma base de autovetores, e a decomposição espectral é formulada para matrizes simétricas. O próximo capítulo apresenta uma decomposição aplicável a qualquer matriz real, inclusive matrizes retangulares e não simétricas. A Decomposição em Valores Singulares relacionará os espaços das linhas e das colunas, o posto, as normas matriciais e as aproximações de baixa dimensão.

6 Decomposição em Valores Singulares

No capítulo anterior, a decomposição espectral foi utilizada para representar uma matriz simétrica real na forma

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Essa representação identifica uma base ortonormal de autovetores na qual a transformação atua separadamente sobre cada coordenada. A decomposição espectral ortogonal, entretanto, depende da simetria da matriz e é formulada para operadores cujo domínio e contradomínio possuem a mesma dimensão.

Em Análise Multivariada, um dos objetos mais frequentes é a matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

cujas linhas representam observações e cujas colunas representam variáveis. Em geral,

$$n \neq p,$$

de modo que $\mathbf{X}$ é retangular. Mesmo quando uma matriz é quadrada, ela pode não ser simétrica nem possuir uma base ortonormal de autovetores.

A **Decomposição em Valores Singulares**, ou SVD, fornece uma representação aplicável a qualquer matriz real. Para uma transformação

$$T_\mathbf{A} : \mathbb{R}^p \longrightarrow \mathbb{R}^q, \quad T_\mathbf{A}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

a SVD relaciona duas bases ortonormais:

- uma base do espaço de origem $\mathbb{R}^p$;
- uma base do espaço de chegada $\mathbb{R}^q$.

A transformação associa determinadas direções dessas duas bases e multiplica os comprimentos por fatores não negativos denominados **valores singulares**.

Essa representação permite descrever:

- o posto da matriz;
- os espaços das linhas e das colunas;
- o núcleo e o núcleo da transposta;
- os fatores máximos e mínimos de alteração dos comprimentos;
- aproximações de posto reduzido;
- a pseudoinversa;
- soluções de mínimos quadrados.

A SVD também estabelece uma ligação entre os espaços das observações e das variáveis de uma matriz de dados. Essa dualidade será utilizada posteriormente na formulação de métodos de redução de dimensionalidade e de representação de estruturas matriciais.

6.1 Definição e formas da Decomposição em Valores Singulares

Considere uma matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

que representa uma transformação de $\mathbb{R}^p$ em $\mathbb{R}^q$.

A matriz pode ser retangular, quadrada, simétrica ou não simétrica. Nenhuma hipótese de invertibilidade ou de posto completo é necessária para a existência da SVD.

Teorema 6.1 (Existência da Decomposição em Valores Singulares). *Para toda matriz*

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

existem matrizes ortogonais

$$\mathbf{U} \in \mathbb{R}^{q \times q}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

e uma matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

tais que

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

As matrizes ortogonais satisfazem

$$\mathbf{U}^\top \mathbf{U} = \mathbf{U}\mathbf{U}^\top = \mathbf{I}_q$$

e

$$\mathbf{V}^\top \mathbf{V} = \mathbf{V}\mathbf{V}^\top = \mathbf{I}_p.$$

Os elementos diagonais não negativos de $\mathbf{D}$ podem ser ordenados como

$$d_1 \geq d_2 \geq \dots \geq d_{\min(q,p)} \geq 0.$$

Esses elementos são os **valores singulares** de $\mathbf{A}$. (Golub; Van Loan, 2013)

A matriz $\mathbf{D}$ é denominada diagonal retangular porque

$$D_{ij} = 0 \quad \text{quando } i \neq j.$$

Se

$$q > p,$$

a matriz $\mathbf{D}$ possui linhas nulas abaixo de sua parte diagonal. Se

$$p > q,$$

ela possui colunas nulas à direita da parte diagonal.

Por exemplo, quando $q > p$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & d_p \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Quando $p > q$,

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & d_q & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

Se

$$r = \text{posto}(\mathbf{A}),$$

então exatamente r valores singulares são positivos:

$$d_1 \geq d_2 \geq \cdots \geq d_r > 0,$$

enquanto os demais valores singulares são iguais a zero.

6.1.1 Vetores singulares

Escreva as matrizes ortogonais como

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

Definição 6.1 (Valores e vetores singulares). Na decomposição

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

os elementos diagonais não negativos

$$d_1, \dots, d_{\min(q,p)}$$

de $\mathbf{D}$ são os **valores singulares** de $\mathbf{A}$.

As colunas

$$\mathbf{v}_1, \dots, \mathbf{v}_p$$

de $\mathbf{V}$ são os **vetores singulares à direita**. Elas formam uma base ortonormal de $\mathbb{R}^p$.

As colunas

$$\mathbf{u}_1, \dots, \mathbf{u}_q$$

de $\mathbf{U}$ são os **vetores singulares à esquerda**. Elas formam uma base ortonormal de $\mathbb{R}^q$.

Para cada valor singular positivo,

$$d_j > 0, \quad j = 1, \dots, r,$$

os vetores singulares correspondentes satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

A primeira igualdade mostra como a transformação associa uma direção no espaço de origem a uma direção no espaço de chegada:

$$\mathbf{v}_j \xrightarrow{\mathbf{A}} d_j\mathbf{u}_j.$$

Como

$$\|\mathbf{v}_j\| = \|\mathbf{u}_j\| = 1,$$

tem-se

$$\|\mathbf{A}\mathbf{v}_j\| = d_j.$$

Portanto, d_j mede o fator de alteração do comprimento na direção $\mathbf{v}_j$:

- se $d_j > 1$, ocorre ampliação;
- se $0 < d_j < 1$, ocorre contração;

- se $d_j = 1$, o comprimento é preservado;
- se $d_j = 0$, a direção correspondente é eliminada.

Os valores singulares são sempre não negativos. Diferentemente dos autovalores, eles não representam inversões de sentido. Possíveis mudanças de orientação ficam incorporadas às matrizes ortogonais $\mathbf{U}$ e $\mathbf{V}$.

As colunas de $\mathbf{V}$ correspondentes às colunas nulas de $\mathbf{D}$ são transformadas no vetor nulo. Elas pertencem ao núcleo de $\mathbf{A}$. De maneira análoga, colunas de $\mathbf{U}$ que correspondem às linhas nulas de $\mathbf{D}$ pertencem ao núcleo de $\mathbf{A}^\top$. Essas relações serão formalizadas na seção dedicada aos espaços fundamentais.

6.1.2 Interpretação como composição de transformações

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

a ação de $\mathbf{A}$ pode ser escrita como

$$\mathbf{Ax} = \mathbf{UDV}^\top \mathbf{x}.$$

Essa transformação pode ser decomposta em três etapas:

$$\mathbf{x} \mapsto \mathbf{V}^\top \mathbf{x} \mapsto \mathbf{DV}^\top \mathbf{x} \mapsto \mathbf{UDV}^\top \mathbf{x}.$$

Na primeira etapa,

$$\mathbf{V}^\top \mathbf{x}$$

fornece as coordenadas de $\mathbf{x}$ na base dos vetores singulares à direita.

Na segunda etapa,

$$\mathbf{DV}^\top \mathbf{x}$$

multiplica separadamente as coordenadas pelos valores singulares. Como $\mathbf{D}$ pode ser retangular, essa etapa também pode alterar a dimensão do espaço.

Na terceira etapa, $\mathbf{U}$ expressa o resultado na base ortonormal dos vetores singulares à esquerda.

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais, essas duas matrizes preservam normas, distâncias, ângulos e produtos internos. As alterações de comprimento e a possível redução de dimensão são determinadas por $\mathbf{D}$.

6.1.3 SVD completa

Definição 6.2 (SVD completa). A representação

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com

$$\mathbf{U} \in \mathbb{R}^{q \times q}, \quad \mathbf{D} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{V} \in \mathbb{R}^{p \times p},$$

é denominada **SVD completa** de $\mathbf{A}$.

As dimensões e os papéis dos fatores são apresentados na Tabela 6.1.

Tabela 6.1: Dimensões das matrizes na SVD completa.

Matriz	Dimensão	Papel
$\mathbf{U}$	$q \times q$	Base ortonormal do espaço de chegada
$\mathbf{D}$	$q \times p$	Matriz diagonal retangular dos valores singulares
$\mathbf{V}$	$p \times p$	Base ortonormal do espaço de origem

A SVD completa descreve bases ortonormais de todo o espaço de origem e de todo o espaço de chegada. Por isso, ela contém também as direções associadas ao núcleo de $\mathbf{A}$ e ao núcleo de $\mathbf{A}^\top$.

6.1.4 SVD compacta

Quando

$$r = \text{posto}(\mathbf{A}),$$

defina

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \in \mathbb{R}^{q \times r},$$

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r] \in \mathbb{R}^{p \times r}$$

e

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r) \in \mathbb{R}^{r \times r}.$$

Definição 6.3 (SVD compacta). A representação

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

formada somente pelos valores singulares positivos e por seus vetores singulares correspondentes, é denominada **SVD compacta** de $\mathbf{A}$.

A SVD compacta reconstrói exatamente a matriz original. Ela não é uma aproximação.

As colunas de $\mathbf{U}_r$ e de $\mathbf{V}_r$ são ortonormais:

$$\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r.$$

Quando $r < q$, tem-se

$$\mathbf{U}_r \mathbf{U}_r^\top \neq \mathbf{I}_q.$$

Quando $r < p$,

$$\mathbf{V}_r \mathbf{V}_r^\top \neq \mathbf{I}_p.$$

Esses produtos são projetores ortogonais sobre os subespaços gerados pelas colunas das matrizes correspondentes. Sua interpretação será retomada na seção sobre os espaços fundamentais.

As dimensões da SVD compacta são apresentadas na Tabela 6.2.

Tabela 6.2: Dimensões das matrizes na SVD compacta.

Matriz	Dimensão	Conteúdo
$\mathbf{U}_r$	$q \times r$	Vetores singulares à esquerda associados aos valores positivos
$\mathbf{D}_r$	$r \times r$	Valores singulares positivos
$\mathbf{V}_r$	$p \times r$	Vetores singulares à direita associados aos valores positivos

A forma compacta contém toda a informação necessária para reconstruir $\mathbf{A}$ e utiliza somente as direções que participam efetivamente da transformação. A forma completa acrescenta bases ortonormais para os complementos dessas direções.

6.1.5 SVD compacta e SVD truncada

A **SVD compacta** e a **SVD truncada** representam objetos diferentes.

A SVD compacta conserva os r valores singulares positivos e satisfaz exatamente

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Uma SVD truncada conserva somente os k maiores valores singulares, com

$$1 \leq k < r.$$

Definindo

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_k],$$

$$\mathbf{D}_k = \text{diag}(d_1, \dots, d_k)$$

e

$$\mathbf{V}_k = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_k],$$

obtém-se

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Quando $k < r$,

$$\mathbf{A}_k \neq \mathbf{A}.$$

A matriz $\mathbf{A}_k$ é uma aproximação de posto k . Suas propriedades de otimalidade e os erros produzidos pelo truncamento serão desenvolvidos posteriormente.

Alguns textos utilizam as expressões **SVD reduzida** ou **SVD econômica** para formas que não incluem todas as colunas das matrizes ortogonais. Como essa terminologia não é uniforme, neste capítulo serão utilizadas as expressões:

- **SVD completa**, para a representação com bases ortonormais completas;
- **SVD compacta**, para a representação exata com os valores singulares positivos;
- **SVD truncada**, para a aproximação que conserva apenas os $k < r$ maiores valores singulares.

6.1.6 Não unicidade dos vetores singulares

Os valores singulares de uma matriz são determinados de maneira única quando apresentados em ordem decrescente e consideradas suas multiplicidades. Os vetores singulares, entretanto, podem não ser únicos.

Para cada par associado a um valor singular positivo, a substituição simultânea

$$\mathbf{u}_j \mapsto -\mathbf{u}_j$$

e

$$\mathbf{v}_j \mapsto -\mathbf{v}_j$$

não altera a parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

pois

$$d_j(-\mathbf{u}_j)(-\mathbf{v}_j)^\top = d_j\mathbf{u}_j\mathbf{v}_j^\top.$$

Assim, cada par singular associado a um valor positivo é determinado apenas a menos de uma mudança simultânea de sinal.

Considere agora um valor singular positivo d com multiplicidade m . Se

$$\mathbf{U}_d \in \mathbb{R}^{q \times m}$$

e

$$\mathbf{V}_d \in \mathbb{R}^{p \times m}$$

contêm bases ortonormais dos subespaços singulares correspondentes, a contribuição desse valor é

$$d\mathbf{U}_d\mathbf{V}_d^\top.$$

Para qualquer matriz ortogonal

$$\mathbf{R} \in \mathbb{R}^{m \times m},$$

tem-se

$$\begin{aligned} d(\mathbf{U}_d\mathbf{R})(\mathbf{V}_d\mathbf{R})^\top &= d\mathbf{U}_d\mathbf{R}\mathbf{R}^\top\mathbf{V}_d^\top \\ &= d\mathbf{U}_d\mathbf{V}_d^\top. \end{aligned}$$

Portanto, valores singulares positivos repetidos permitem rotações ortogonais simultâneas das bases à esquerda e à direita.

A situação é diferente nos subespaços associados ao valor singular zero. As colunas de $\mathbf{V}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}),$$

enquanto as colunas de $\mathbf{U}_0$ formam uma base de

$$\mathcal{N}(\mathbf{A}^\top).$$

Essas bases completam espaços diferentes e podem ser escolhidas independentemente, pois suas parcelas são multiplicadas por zero na SVD completa.

Portanto:

- os valores singulares são propriedades da matriz;
- os subespaços singulares associados aos valores positivos são propriedades da matriz;
- os núcleos de $\mathbf{A}$ e de $\mathbf{A}^\top$ são propriedades da matriz;
- sinais e bases ortonormais específicas dentro desses subespaços dependem da representação escolhida.

A existência da SVD e as relações entre os dois conjuntos de vetores singulares decorrem das decomposições espectrais das matrizes simétricas

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

A próxima seção constrói essa relação e demonstra por que os quadrados dos valores singulares aparecem como autovalores dessas duas matrizes.

6.2 Construção da SVD e relação com a decomposição espectral

A existência da SVD decorre das propriedades das matrizes

$$\mathbf{A}^\top \mathbf{A} \quad \text{e} \quad \mathbf{A} \mathbf{A}^\top.$$

Para

$$\mathbf{A} \in \mathbb{R}^{q \times p},$$

tem-se

$$\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{p \times p}$$

e

$$\mathbf{A} \mathbf{A}^\top \in \mathbb{R}^{q \times q}.$$

Mesmo que $\mathbf{A}$ seja retangular ou não simétrica, essas duas matrizes são quadradas, simétricas e semidefinidas positivas.

6.2.1 Simetria e semidefinição positiva

A simetria segue de

$$(\mathbf{A}^\top \mathbf{A})^\top = \mathbf{A}^\top \mathbf{A}$$

e

$$(\mathbf{A}\mathbf{A}^\top)^\top = \mathbf{A}\mathbf{A}^\top.$$

Para qualquer

$$\mathbf{x} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned}\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} &= (\mathbf{A} \mathbf{x})^\top (\mathbf{A} \mathbf{x}) \\ &= \|\mathbf{A} \mathbf{x}\|^2 \\ &\geq 0.\end{aligned}$$

Logo,

$$\mathbf{A}^\top \mathbf{A} \succeq 0.$$

De modo semelhante, para qualquer

$$\mathbf{y} \in \mathbb{R}^q,$$

$$\begin{aligned}\mathbf{y}^\top \mathbf{A} \mathbf{A}^\top \mathbf{y} &= (\mathbf{A}^\top \mathbf{y})^\top (\mathbf{A}^\top \mathbf{y}) \\ &= \|\mathbf{A}^\top \mathbf{y}\|^2 \\ &\geq 0.\end{aligned}$$

Portanto,

$$\mathbf{A} \mathbf{A}^\top \succeq 0.$$

Pelo Teorema 5.6, as duas matrizes possuem autovalores reais não negativos e bases ortonormais de autovetores.

Teorema 6.2 (Espectros associados à SVD). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A}).$$

Então:

1. *as matrizes*

$$\mathbf{A}^\top \mathbf{A}$$

e

$$\mathbf{A} \mathbf{A}^\top$$

possuem os mesmos r autovalores positivos, incluindo suas multiplicidades;

2. *esses autovalores podem ser escritos como*

$$d_1^2, \dots, d_r^2,$$

em que

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$;

3. *os núcleos satisfazem*

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A})$$

e

$$\mathcal{N}(\mathbf{A} \mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}).$$

Então,

$$\mathbf{Ax} = \mathbf{0},$$

e, consequentemente,

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}^\top \mathbf{A}).$$

Reciprocamente, se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}^\top \mathbf{A}),$$

então

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{x}^\top$,

$$\begin{aligned} 0 &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} \\ &= \|\mathbf{Ax}\|^2. \end{aligned}$$

Portanto,

$$\mathbf{Ax} = \mathbf{0},$$

e

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) \subseteq \mathcal{N}(\mathbf{A}).$$

Assim,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

O mesmo argumento, aplicado a $\mathbf{A}^\top$, fornece

$$\mathcal{N}(\mathbf{A}\mathbf{A}^\top) = \mathcal{N}(\mathbf{A}^\top).$$

Considere agora um autovalor positivo λ de

$$\mathbf{A}^\top \mathbf{A}$$

e um autovetor unitário $\mathbf{v}$ associado:

$$\mathbf{A}^\top \mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Como $\lambda > 0$, defina

$$\mathbf{u} = \frac{\mathbf{A} \mathbf{v}}{\sqrt{\lambda}}.$$

Esse vetor possui norma unitária, pois

$$\begin{aligned} \mathbf{u}^\top \mathbf{u} &= \frac{\mathbf{v}^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\lambda} \\ &= \frac{\lambda \mathbf{v}^\top \mathbf{v}}{\lambda} \\ &= 1. \end{aligned}$$

Além disso,

$$\begin{aligned} \mathbf{A} \mathbf{A}^\top \mathbf{u} &= \frac{\mathbf{A} \mathbf{A}^\top \mathbf{A} \mathbf{v}}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\mathbf{A}^\top \mathbf{A} \mathbf{v})}{\sqrt{\lambda}} \\ &= \frac{\mathbf{A} (\lambda \mathbf{v})}{\sqrt{\lambda}} \\ &= \lambda \mathbf{u}. \end{aligned}$$

Portanto, todo autovalor positivo de

$$\mathbf{A}^\top \mathbf{A}$$

também é autovalor de

$$\mathbf{A}\mathbf{A}^\top.$$

O argumento inverso é obtido começando por um autovetor de

$$\mathbf{A}\mathbf{A}^\top$$

e definindo

$$\mathbf{v} = \frac{\mathbf{A}^\top \mathbf{u}}{\sqrt{\lambda}}.$$

As transformações entre os autoespaços são inversíveis quando $\lambda > 0$. Por isso, as multiplicidades dos autovalores positivos também coincidem.

Como

$$\text{posto}(\mathbf{A}^\top \mathbf{A}) = \text{posto}(\mathbf{A}) = r,$$

existem exatamente r autovalores positivos. O mesmo ocorre para

$$\mathbf{A}\mathbf{A}^\top.$$

Definindo

$$d_j = \sqrt{\lambda_j},$$

obtêm-se os r valores singulares positivos de $\mathbf{A}$. □

As duas matrizes podem possuir quantidades diferentes de autovalores nulos. A matriz

$$\mathbf{A}^\top \mathbf{A}$$

tem ordem p , enquanto

$$\mathbf{A}\mathbf{A}^\top$$

tem ordem q . Entretanto, seus espectros positivos coincidem.

6.2.2 Construção dos vetores singulares

Considere a decomposição espectral

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \Lambda_V \mathbf{V}^\top,$$

em que

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p]$$

é ortogonal.

Ordene os autovalores de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$$

e

$$\lambda_{r+1} = \cdots = \lambda_p = 0.$$

Defina

$$d_j = \sqrt{\lambda_j}, \quad j = 1, \dots, r.$$

Para cada autovalor positivo, defina

$$\mathbf{u}_j = \frac{\mathbf{A}\mathbf{v}_j}{d_j}.$$

Os vetores assim construídos são ortonormais. Para $i, j \leq r$,

$$\begin{aligned}
\mathbf{u}_i^\top \mathbf{u}_j &= \frac{\mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_i d_j} \\
&= \frac{d_j^2 \mathbf{v}_i^\top \mathbf{v}_j}{d_i d_j} \\
&= \frac{d_j}{d_i} \mathbf{v}_i^\top \mathbf{v}_j.
\end{aligned}$$

Como os vetores $\mathbf{v}_j$ são ortonormais,

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Logo,

$$\mathbf{u}_i^\top \mathbf{u}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Portanto,

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam um conjunto ortonormal.

Além disso,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\begin{aligned}
\mathbf{A}^\top \mathbf{u}_j &= \frac{\mathbf{A}^\top \mathbf{A} \mathbf{v}_j}{d_j} \\
&= \frac{d_j^2 \mathbf{v}_j}{d_j} \\
&= d_j \mathbf{v}_j.
\end{aligned}$$

Assim, cada valor singular positivo associa um par de direções:

$$\mathbf{v}_j \in \mathbb{R}^p \quad \text{e} \quad \mathbf{u}_j \in \mathbb{R}^q.$$

Essas direções satisfazem

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j\mathbf{v}_j.$$

Reunindo os pares associados aos valores singulares positivos,

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r],$$

obtém-se

$$\mathbf{A}\mathbf{V}_r = \mathbf{U}_r\mathbf{D}_r.$$

Complete $\mathbf{V}_r$ com uma matriz $\mathbf{V}_0$ cujas colunas formam uma base ortonormal de $\mathcal{N}(\mathbf{A})$. Então,

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0]$$

é ortogonal e

$$\mathbf{I}_p = \mathbf{V}_r\mathbf{V}_r^\top + \mathbf{V}_0\mathbf{V}_0^\top.$$

Como

$$\mathbf{A}\mathbf{V}_0 = \mathbf{0},$$

tem-se

$$\begin{aligned}
\mathbf{A} &= \mathbf{A} \mathbf{I}_p \\
&= \mathbf{A} (\mathbf{V}_r \mathbf{V}_r^\top + \mathbf{V}_0 \mathbf{V}_0^\top) \\
&= \mathbf{A} \mathbf{V}_r \mathbf{V}_r^\top \\
&= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.
\end{aligned}$$

Essa é a SVD compacta.

6.2.3 Demonstração da existência da SVD completa

A construção anterior também demonstra o Teorema 6.1.

Comprovação. Os vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

estão associados ao autovalor zero de

$$\mathbf{A}^\top \mathbf{A}.$$

Pelo Teorema 6.2,

$$\mathcal{N}(\mathbf{A}^\top \mathbf{A}) = \mathcal{N}(\mathbf{A}).$$

Logo,

$$\mathbf{A} \mathbf{v}_j = \mathbf{0}, \quad j = r + 1, \dots, p.$$

Os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

formam uma base ortonormal do espaço coluna de $\mathbf{A}$. Complete esse conjunto com uma base ortonormal

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_q$$

de

$$\mathcal{N}(\mathbf{A}^\top).$$

Defina

$$\mathbf{U} = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_q]$$

e mantenha

$$\mathbf{V} = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_p].$$

As duas matrizes são ortogonais.

Construa a matriz diagonal retangular

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

colocando

$$d_1, \dots, d_r$$

em suas primeiras posições diagonais e zeros nas demais posições.

Para $j \leq r$,

$$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Para $j > r$,

$$\mathbf{A}\mathbf{v}_j = \mathbf{0}.$$

Essas relações podem ser reunidas em

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{D}.$$

Multiplicando à direita por $\mathbf{V}^\top$,

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Portanto, toda matriz real possui uma SVD completa. □

6.2.4 Decomposições espectrais associadas

A SVD compacta fornece diretamente as decomposições espectrais das duas matrizes de Gram:

$$\begin{aligned}\mathbf{A}^\top \mathbf{A} &= (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top)^\top (\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) \\ &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.\end{aligned}$$

Portanto,

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

Essa expressão possui dimensão $p \times p$, pois

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}, \quad \mathbf{D}_r^2 \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r^\top \in \mathbb{R}^{r \times p}.$$

De forma análoga,

$$\begin{aligned}\mathbf{A} \mathbf{A}^\top &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.\end{aligned}$$

Logo,

$$\mathbf{A} \mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top,$$

com dimensão $q \times q$.

Na forma completa, as decomposições são

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{p-r} \right) \mathbf{V}^\top$$

e

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U} \operatorname{diag} \left(d_1^2, \dots, d_r^2, \underbrace{0, \dots, 0}_{q-r} \right) \mathbf{U}^\top.$$

Essas expressões deixam explícito que:

- $\mathbf{A}^\top \mathbf{A}$ possui $p - r$ autovalores nulos;
- $\mathbf{A}\mathbf{A}^\top$ possui $q - r$ autovalores nulos;
- as duas matrizes possuem os mesmos r autovalores positivos.

Para cada $j = 1, \dots, r$,

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_j = d_j^2 \mathbf{v}_j$$

e

$$\mathbf{A}\mathbf{A}^\top \mathbf{u}_j = d_j^2 \mathbf{u}_j.$$

Assim, os valores singulares podem ser obtidos por

$$d_j = \sqrt{\lambda_j},$$

em que λ_j é um autovalor positivo de qualquer uma das duas matrizes de Gram.

6.2.5 Exemplo de construção da SVD

Exemplo 6.1 (Construção da SVD de uma matriz retangular). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

A matriz possui dimensão 3×2 . Inicialmente,

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}. \end{aligned}$$

Essa é a mesma matriz utilizada como exemplo condutor no capítulo anterior. Seus autovalores são

$$\lambda_1 = 4 \quad \text{e} \quad \lambda_2 = 2.$$

Os valores singulares são as raízes quadradas não negativas:

$$d_1 = 2 \quad \text{e} \quad d_2 = \sqrt{2}.$$

Autovetores unitários associados são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Portanto,

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O primeiro vetor singular à esquerda é

$$\begin{aligned} \mathbf{u}_1 &= \frac{\mathbf{A}\mathbf{v}_1}{d_1} \\ &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ &= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}. \end{aligned}$$

O segundo é

$$\begin{aligned}
\mathbf{u}_2 &= \frac{\mathbf{A}\mathbf{v}_2}{d_2} \\
&= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.
\end{aligned}$$

Logo,

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix}$$

e

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}.$$

A SVD compacta é

$$\mathbf{A} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top.$$

Como os dois valores singulares são positivos,

$$\text{posto}(\mathbf{A}) = 2.$$

Para construir a SVD completa, é necessário completar as colunas de $\mathbf{U}_2$ com um vetor unitário ortogonal a $\mathbf{u}_1$ e $\mathbf{u}_2$. Pode-se escolher

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Assim,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

e

$$\mathbf{D} = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}.$$

Como $\mathbf{V}_2$ já é uma matriz 2×2 ortogonal,

$$\mathbf{V} = \mathbf{V}_2.$$

A SVD completa é

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top.$$

Por outro lado,

$$\mathbf{A}\mathbf{A}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Seus autovalores são

$$4, \quad 2, \quad 0,$$

com autovetores unitários

$$\mathbf{u}_1, \quad \mathbf{u}_2, \quad \mathbf{u}_3,$$

respectivamente.

O exemplo mostra que:

- $\mathbf{A}^\top \mathbf{A}$ determina as direções singulares no espaço de origem $\mathbb{R}^2$;
- $\mathbf{A}\mathbf{A}^\top$ determina as direções singulares no espaço de chegada $\mathbb{R}^3$;
- os dois espaços são relacionados pelos mesmos valores singulares positivos.

6.2.6 Relação com a decomposição espectral de matrizes simétricas

Se $\mathbf{A}$ é quadrada e simétrica, sua decomposição espectral é

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Quando

$$\mathbf{A} \succeq 0,$$

todos os autovalores são não negativos. Nesse caso, após ordenar os autovalores,

$$\mathbf{U} = \mathbf{V} = \mathbf{Q}_\mathbf{A}$$

e

$$\mathbf{D} = \Lambda_\mathbf{A}.$$

Portanto, a SVD coincide com a decomposição espectral:

$$\mathbf{A} = \mathbf{Q}_\mathbf{A} \Lambda_\mathbf{A} \mathbf{Q}_\mathbf{A}^\top.$$

Se $\mathbf{A}$ é simétrica, mas indefinida, os valores singulares são os módulos dos autovalores:

$$d_j = |\lambda_j|.$$

Para tornar essa relação explícita, defina

$$\text{sgn}_0(t) = \begin{cases} 1, & t \geq 0, \\ -1, & t < 0. \end{cases}$$

Então,

$$\lambda_j = \text{sgn}_0(\lambda_j) |\lambda_j|.$$

Após ordenar os autovalores por seus módulos, uma possível SVD é obtida tomando

$$\mathbf{V} = \mathbf{Q}_\mathbf{A},$$

$$\mathbf{D} = \text{diag}(|\lambda_1|, \dots, |\lambda_p|)$$

e

$$\mathbf{U} = \mathbf{Q}_\mathbf{A} \text{diag}(\text{sgn}_0(\lambda_1), \dots, \text{sgn}_0(\lambda_p)).$$

Dessa forma,

$$\mathbf{U}\mathbf{D}\mathbf{V}^\top = \mathbf{Q}_\mathbf{A}\mathbf{\Lambda}_\mathbf{A}\mathbf{Q}_\mathbf{A}^\top = \mathbf{A}.$$

A decomposição espectral preserva o sinal dos autovalores na matriz diagonal. A SVD mantém valores singulares não negativos e transfere as mudanças de orientação para uma das matrizes ortogonais.

Para matrizes não simétricas, autovalores e valores singulares representam objetos diferentes. Os autovalores descrevem direções invariantes de um operador quadrado. Os valores singulares descrevem fatores de escalonamento entre direções ortonormais do domínio e do contradomínio e permanecem definidos para matrizes retangulares.

i Construção teórica e cálculo numérico

A decomposição espectral de

$$\mathbf{A}^\top \mathbf{A}$$

fornece uma demonstração da existência da SVD e permite realizar cálculos manuais em exemplos pequenos.

Em aplicações numéricas, a SVD não costuma ser calculada formando explicitamente

$$\mathbf{A}^\top \mathbf{A}.$$

Esse produto pode ampliar diferenças entre as magnitudes dos valores singulares e aumentar os efeitos de erros de arredondamento. Programas numéricos utilizam procedimentos específicos para calcular a SVD diretamente, com maior estabilidade.

A construção algébrica identifica os pares de direções associados pelos valores singulares. A interpretação geométrica mostra como essas direções transformam uma esfera unitária do domínio em uma elipse ou em um elipsoide no espaço de chegada.

6.3 Interpretação geométrica da SVD

A SVD descreve uma transformação linear por meio de duas bases ortonormais e de um escalonamento entre elas. Para

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

a matriz $\mathbf{V}^\top$ expressa os vetores nas coordenadas dos vetores singulares à direita, $\mathbf{D}$ altera separadamente essas coordenadas e $\mathbf{U}$ expressa o resultado nas direções singulares à esquerda.

Considere um vetor

$$\mathbf{x} \in \mathbb{R}^p.$$

Como as colunas de $\mathbf{V}$ formam uma base ortonormal, ele pode ser escrito como

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j,$$

em que

$$\alpha_j = \mathbf{v}_j^\top \mathbf{x}.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{A}\mathbf{x} &= \sum_{j=1}^p \alpha_j \mathbf{A}\mathbf{v}_j \\ &= \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j. \end{aligned}$$

As parcelas associadas aos vetores

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_p$$

desaparecem porque pertencem ao núcleo de $\mathbf{A}$.

A transformação pode, portanto, ser interpretada por meio das correspondências

$$\mathbf{v}_j \mapsto d_j \mathbf{u}_j, \quad j = 1, \dots, r.$$

Cada vetor singular à direita determina uma direção no domínio. O valor singular correspondente determina o fator de escala, enquanto o vetor singular à esquerda determina a direção resultante no contradomínio.

6.3.1 Imagem da bola unitária

Considere a bola unitária de $\mathbb{R}^p$:

$$\mathcal{B}_p = \{\mathbf{x} \in \mathbb{R}^p : \|\mathbf{x}\| \leq 1\}.$$

A SVD permite descrever geometricamente sua imagem pela transformação $\mathbf{A}$.

Teorema 6.3 (Imagem da bola unitária pela SVD). *Seja*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

a SVD compacta de uma matriz de posto r . A imagem da bola unitária por $\mathbf{A}$ é o elipsoide

$$\mathbf{A}(\mathcal{B}_p) = \left\{ \sum_{j=1}^r \beta_j \mathbf{u}_j : \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1 \right\}.$$

As direções principais desse elipsoide são

$$\mathbf{u}_1, \dots, \mathbf{u}_r,$$

e os comprimentos de seus semieixos são

$$d_1, \dots, d_r.$$

Comprovação. Escreva

$$\mathbf{x} = \sum_{j=1}^r \alpha_j \mathbf{v}_j + \mathbf{x}_0,$$

em que

$$\mathbf{x}_0 \in \mathcal{N}(\mathbf{A}).$$

Como os vetores singulares à direita e o núcleo formam subespaços ortogonais,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \alpha_j^2 + \|\mathbf{x}_0\|^2.$$

Se $\mathbf{x} \in \mathcal{B}_p$, então

$$\sum_{j=1}^r \alpha_j^2 \leq 1.$$

Aplicando a transformação,

$$\mathbf{Ax} = \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j.$$

Definindo

$$\beta_j = d_j \alpha_j,$$

obtém-se

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} = \sum_{j=1}^r \alpha_j^2 \leq 1.$$

Portanto, toda imagem de um vetor da bola unitária pertence ao elipsoide apresentado.

Reciprocamente, considere um vetor

$$\mathbf{y} = \sum_{j=1}^r \beta_j \mathbf{u}_j$$

que satisfaz

$$\sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1.$$

Defina

$$\mathbf{x} = \sum_{j=1}^r \frac{\beta_j}{d_j} \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^r \frac{\beta_j^2}{d_j^2} \leq 1,$$

de modo que $\mathbf{x} \in \mathcal{B}_p$. Além disso,

$$\mathbf{Ax} = \sum_{j=1}^r \beta_j \mathbf{u}_j = \mathbf{y}.$$

Logo, o conjunto apresentado coincide com a imagem da bola unitária. □

Quando $\mathbf{A}$ possui posto coluna completo,

$$r = p,$$

a imagem da esfera unitária

$$\{\mathbf{x} : \|\mathbf{x}\| = 1\}$$

é a superfície do elipsoide.

Quando

$$r < p,$$

existem direções não nulas eliminadas por $\mathbf{A}$. Nesse caso, a imagem da esfera também contém pontos do interior do elipsoide, pois parte da norma de $\mathbf{x}$ pode estar concentrada no núcleo da transformação.

Se

$$r < q,$$

o elipsoide está contido no subespaço

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} \subset \mathbb{R}^q.$$

Assim, a SVD também revela a dimensão efetiva da imagem da transformação.

6.3.2 Alteração dos comprimentos

A expansão de $\mathbf{x}$ na base dos vetores singulares fornece

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2.$$

Por outro lado,

$$\begin{aligned}\|\mathbf{Ax}\|^2 &= \left\| \sum_{j=1}^r d_j \alpha_j \mathbf{u}_j \right\|^2 \\ &= \sum_{j=1}^r d_j^2 \alpha_j^2,\end{aligned}$$

pois os vetores

$$\mathbf{u}_1, \dots, \mathbf{u}_r$$

são ortonormais.

Como

$$d_1 \geq d_j$$

para todo j ,

$$\begin{aligned}\|\mathbf{Ax}\|^2 &= \sum_{j=1}^r d_j^2 \alpha_j^2 \\ &\leq d_1^2 \sum_{j=1}^p \alpha_j^2 \\ &= d_1^2 \|\mathbf{x}\|^2.\end{aligned}$$

Portanto,

$$\|\mathbf{Ax}\| \leq d_1 \|\mathbf{x}\|.$$

A igualdade é atingida quando $\mathbf{x}$ pertence ao subespaço singular à direita associado ao maior valor singular.

Em particular,

$$\max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_1.$$

O maior valor singular é o maior fator de ampliação produzido pela transformação.

Se $\mathbf{A}$ possui posto coluna completo, então

$$r = p$$

e

$$d_p > 0.$$

Nesse caso,

$$\begin{aligned} \|\mathbf{Ax}\|^2 &= \sum_{j=1}^p d_j^2 \alpha_j^2 \\ &\geq d_p^2 \sum_{j=1}^p \alpha_j^2 \\ &= d_p^2 \|\mathbf{x}\|^2. \end{aligned}$$

Logo,

$$\|\mathbf{Ax}\| \geq d_p \|\mathbf{x}\|$$

e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = d_p.$$

Se $\mathbf{A}$ não possui posto coluna completo, existe um vetor unitário no núcleo. Nesse caso,

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

Esses extremos serão retomados na definição da norma espectral e do número de condição.

6.3.3 Exemplo geométrico no plano

Exemplo 6.2 (Transformação da circunferência unitária em uma elipse). Considere a matriz não simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

Sua SVD pode ser escrita como

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top,$$

com valores singulares aproximadamente iguais a

$$d_1 \approx 2,288$$

e

$$d_2 \approx 0,874.$$

A circunferência unitária pode ser parametrizada por

$$\mathbf{x}(\theta) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad 0 \leq \theta \leq 2\pi.$$

Sua imagem é

$$\mathbf{y}(\theta) = \mathbf{A}\mathbf{x}(\theta).$$

A SVD mostra que essa imagem é uma elipse com:

- semieixo maior de comprimento d_1 na direção $\mathbf{u}_1$;
- semieixo menor de comprimento d_2 na direção $\mathbf{u}_2$.

No domínio, as direções correspondentes são $\mathbf{v}_1$ e $\mathbf{v}_2$.




Figura 6.1: A SVD transforma as direções singulares à direita nos semieixos da elipse orientados pelos vetores singulares à esquerda.

A Figura 6.1 mostra as direções singulares no domínio e no contradomínio. No primeiro painel, $\mathbf{v}_1$ e $\mathbf{v}_2$ formam uma base ortonormal da circunferência unitária. No segundo, essas direções são transformadas em $d_1\mathbf{u}_1$ e $d_2\mathbf{u}_2$, que determinam os semieixos da elipse.

A figura representa uma transformação não simétrica. Por isso, as direções singulares à direita e à esquerda não coincidem. A matriz $\mathbf{V}^\top$ alinha inicialmente a circunferência às direções $\mathbf{v}_1$ e $\mathbf{v}_2$. A matriz $\mathbf{D}$ altera os comprimentos segundo d_1 e d_2 . A matriz $\mathbf{U}$ orienta os semieixos resultantes nas direções $\mathbf{u}_1$ e $\mathbf{u}_2$.

6.3.4 Transformações de posto deficiente

Quando algum valor singular é zero, a transformação colapsa uma direção do domínio.

Por exemplo, considere

$$\mathbf{A}_0 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

Seus valores singulares são

$$d_1 = 2 \quad \text{e} \quad d_2 = 0.$$

A bola unitária é transformada no segmento

$$\left\{ \begin{bmatrix} y_1 \\ 0 \end{bmatrix} : -2 \leq y_1 \leq 2 \right\}.$$

A direção correspondente ao valor singular nulo pertence ao núcleo. O elipsoide resultante é degenerado e possui dimensão inferior à dimensão do domínio.

De modo geral:

- cada valor singular positivo produz um semieixo da imagem;
- cada valor singular nulo elimina uma direção;
- o número de semieixos não nulos é o posto da matriz;
- o elipsoide está contido no espaço coluna de $\mathbf{A}$.

A descrição geométrica da SVD também identifica bases ortonormais dos quatro espaços fundamentais associados à matriz. Essas relações permitem interpretar posto, núcleo, projetores, normas e condicionamento diretamente a partir dos vetores e valores singulares.

6.4 Espaços fundamentais, posto, normas e condicionamento

A SVD fornece bases ortonormais para os quatro espaços fundamentais associados a uma matriz. Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

As colunas de

$$\mathbf{U}_r \in \mathbb{R}^{q \times r}$$

são os vetores singulares à esquerda associados aos valores singulares positivos. As colunas de

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}$$

são os vetores singulares à direita correspondentes.

Complete essas matrizes com bases ortonormais dos respectivos complementos:

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

e

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0],$$

em que

$$\mathbf{U}_0 \in \mathbb{R}^{q \times (q-r)}$$

e

$$\mathbf{V}_0 \in \mathbb{R}^{p \times (p-r)}.$$

Quando $r = q$, a matriz $\mathbf{U}_0$ não possui colunas. Quando $r = p$, o mesmo ocorre com $\mathbf{V}_0$.

6.4.1 Espaço coluna e espaço linha

Teorema 6.4 (Espaços fundamentais determinados pela SVD). *Se*

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de posto r , então

$$\mathcal{C}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\} = \mathcal{C}(\mathbf{U}_r),$$

$$\mathcal{C}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\} = \mathcal{C}(\mathbf{V}_r),$$

$$\mathcal{N}(\mathbf{A}) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_p\} = \mathcal{C}(\mathbf{V}_0),$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_q\} = \mathcal{C}(\mathbf{U}_0).$$

(Golub; Van Loan, 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{Ax} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^p$. Logo, toda imagem de $\mathbf{A}$ é uma combinação linear das colunas de $\mathbf{U}_r$:

$$\mathcal{C}(\mathbf{A}) \subseteq \mathcal{C}(\mathbf{U}_r).$$

Reciprocamente, para cada $j = 1, \dots, r$,

$$\mathbf{Av}_j = d_j \mathbf{u}_j.$$

Como $d_j > 0$,

$$\mathbf{u}_j = \mathbf{A} \left(\frac{1}{d_j} \mathbf{v}_j \right).$$

Portanto,

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

e

$$\mathcal{C}(\mathbf{U}_r) \subseteq \mathcal{C}(\mathbf{A}).$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r).$$

Aplicando o mesmo argumento a

$$\mathbf{A}^\top = \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top,$$

obtém-se

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r).$$

Considere agora a base ortonormal completa

$$\mathbf{V} = [\mathbf{V}_r \quad \mathbf{V}_0].$$

Todo vetor $\mathbf{x} \in \mathbb{R}^p$ possui uma decomposição única da forma

$$\mathbf{x} = \mathbf{V}_r \alpha + \mathbf{V}_0 \beta.$$

Aplicando $\mathbf{A}$,

$$\begin{aligned} \mathbf{Ax} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top (\mathbf{V}_r \alpha + \mathbf{V}_0 \beta) \\ &= \mathbf{U}_r \mathbf{D}_r \alpha, \end{aligned}$$

pois

$$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$$

e

$$\mathbf{V}_r^\top \mathbf{V}_0 = \mathbf{0}.$$

Como $\mathbf{D}_r$ é invertível,

$$\mathbf{Ax} = \mathbf{0}$$

se, e somente se,

$$\alpha = \mathbf{0}.$$

Logo,

$$\mathbf{x} \in \mathcal{N}(\mathbf{A})$$

se, e somente se,

$$\mathbf{x} = \mathbf{V}_0 \beta.$$

Portanto,

$$\mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

Aplicando o mesmo raciocínio a $\mathbf{A}^\top$,

$$\mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0).$$

□

As quatro bases fornecidas pela SVD podem ser organizadas como na Tabela 6.3.

Tabela 6.3: Espaços fundamentais e bases ortonormais fornecidas pela SVD.

Espaço	Subespaço de	Base ortonormal fornecida pela SVD	Dimensão
Espaço coluna $\mathcal{C}(\mathbf{A})$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_r$	r
Núcleo à esquerda $\mathcal{N}(\mathbf{A}^\top)$	$\mathbb{R}^q$	Colunas de $\mathbf{U}_0$	$q - r$
Espaço linha $\mathcal{C}(\mathbf{A}^\top)$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_r$	r
Núcleo $\mathcal{N}(\mathbf{A})$	$\mathbb{R}^p$	Colunas de $\mathbf{V}_0$	$p - r$

A SVD torna explícitas as decomposições ortogonais

$$\mathbb{R}^q = \mathcal{C}(\mathbf{A}) \oplus \mathcal{N}(\mathbf{A}^\top)$$

e

$$\mathbb{R}^p = \mathcal{C}(\mathbf{A}^\top) \oplus \mathcal{N}(\mathbf{A}).$$

O símbolo $\oplus$ indica uma soma direta ortogonal.

Todo vetor

$$\mathbf{y} \in \mathbb{R}^q$$

pode ser escrito de maneira única como

$$\mathbf{y} = \mathbf{y}_{\mathcal{C}} + \mathbf{y}_{\mathcal{N}},$$

com

$$\mathbf{y}_{\mathcal{C}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{y}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}^{\top}).$$

De modo análogo, todo vetor

$$\mathbf{x} \in \mathbb{R}^p$$

se decompõe em uma parcela no espaço linha e outra no núcleo de $\mathbf{A}$.

6.4.2 Projetores ortogonais

Como as colunas de $\mathbf{U}_r$ são ortonormais, a matriz

$$\mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^{\top}$$

é o projetor ortogonal sobre o espaço coluna de $\mathbf{A}$.

O projetor sobre o núcleo à esquerda é

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^{\top})} = \mathbf{U}_0 \mathbf{U}_0^{\top}.$$

Como

$$\mathbf{U} = [\mathbf{U}_r \quad \mathbf{U}_0]$$

é ortogonal,

$$\mathbf{U}_r \mathbf{U}_r^{\top} + \mathbf{U}_0 \mathbf{U}_0^{\top} = \mathbf{I}_q.$$

Portanto,

$$\mathbf{P}_{\mathcal{N}(\mathbf{A}^{\top})} = \mathbf{I}_q - \mathbf{U}_r \mathbf{U}_r^{\top}.$$

No espaço de origem,

$$\mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top$$

é o projetor sobre o espaço linha, enquanto

$$\mathbf{P}_{\mathcal{N}(\mathbf{A})} = \mathbf{V}_0 \mathbf{V}_0^\top = \mathbf{I}_p - \mathbf{V}_r \mathbf{V}_r^\top$$

projeta sobre o núcleo.

As matrizes

$$\mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{V}_r \mathbf{V}_r^\top$$

são simétricas e idempotentes, conforme as propriedades dos projetores ortogonais estudadas anteriormente.

Exemplo 6.3 (Espaços fundamentais do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua SVD completa foi construída com

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

e

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Os vetores singulares à direita são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Como os dois valores singulares são positivos,

$$r = 2.$$

Assim,

$$\mathcal{C}(\mathbf{A}) = \text{span} \{ \mathbf{u}_1, \mathbf{u}_2 \},$$

e

$$\mathcal{N}(\mathbf{A}^\top) = \text{span} \{ \mathbf{u}_3 \}.$$

A matriz possui posto coluna completo, pois

$$r = p = 2.$$

Consequentemente,

$$\mathcal{N}(\mathbf{A}) = \{ \mathbf{0} \}$$

e

$$\mathcal{C}(\mathbf{A}^\top) = \mathbb{R}^2.$$

O projetor sobre o espaço coluna é

$$\begin{aligned} \mathbf{U}_2 \mathbf{U}_2^\top &= \mathbf{u}_1 \mathbf{u}_1^\top + \mathbf{u}_2 \mathbf{u}_2^\top \\ &= \begin{bmatrix} 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \end{bmatrix}. \end{aligned}$$

O projetor sobre o núcleo à esquerda é

$$\mathbf{u}_3 \mathbf{u}_3^\top = \begin{bmatrix} 1/2 & 0 & -1/2 \\ 0 & 0 & 0 \\ -1/2 & 0 & 1/2 \end{bmatrix}.$$

A soma dos dois projetores é

$$\mathbf{U}_2 \mathbf{U}_2^\top + \mathbf{u}_3 \mathbf{u}_3^\top = \mathbf{I}_3.$$

6.4.3 Posto e nulidades

A quantidade de valores singulares positivos é igual ao posto:

$$\text{posto}(\mathbf{A}) = r.$$

Essa igualdade também pode ser observada a partir da SVD compacta. As matrizes

$$\mathbf{U}_r \quad \text{e} \quad \mathbf{V}_r$$

possuem posto coluna r , e

$$\mathbf{D}_r$$

é diagonal e invertível. Portanto,

$$\text{posto}(\mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top) = r.$$

Pelo Teorema Posto–Nulidade,

$$\dim \mathcal{N}(\mathbf{A}) = p - r$$

e

$$\dim \mathcal{N}(\mathbf{A}^\top) = q - r.$$

Os valores singulares nulos representam direções eliminadas pela transformação. A quantidade dessas direções depende do espaço considerado:

- no domínio, existem $p - r$ direções no núcleo de $\mathbf{A}$;
- no contradomínio, existem $q - r$ direções ortogonais à imagem.

6.4.4 Produto interno de Frobenius

O estudo das aproximações matriciais exige uma geometria para o espaço das matrizes.

Definição 6.4 (Produto interno de Frobenius). Para matrizes

$$\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{q \times p},$$

o produto interno de Frobenius é

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = \text{tr}(\mathbf{A}^\top \tilde{\mathbf{A}}).$$

Equivalentemente,

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = \sum_{i=1}^q \sum_{j=1}^p a_{ij} \tilde{a}_{ij}.$$

O produto interno de Frobenius trata uma matriz como um vetor formado por todos os seus elementos. Duas matrizes são ortogonais segundo esse produto quando

$$\langle \mathbf{A}, \tilde{\mathbf{A}} \rangle_F = 0.$$

A norma induzida por esse produto interno é a norma de Frobenius.

Definição 6.5 (Norma de Frobenius). A **norma de Frobenius** de

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{q \times p}$$

é

$$\|\mathbf{A}\|_F = \sqrt{\langle \mathbf{A}, \mathbf{A} \rangle_F}.$$

Equivalentemente,

$$\|\mathbf{A}\|_F = \sqrt{\text{tr}(\mathbf{A}^\top \mathbf{A})}$$

ou

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^q \sum_{j=1}^p a_{ij}^2}.$$

A norma de Frobenius mede a magnitude quadrática total dos elementos da matriz.

6.4.5 Normas e valores singulares

Definição 6.6 (Norma espectral). A **norma espectral**, ou norma matricial induzida pela norma euclidiana, é

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente,

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

A interpretação geométrica anterior mostra que a norma espectral é o maior fator de ampliação produzido pela transformação.

Teorema 6.5 (Normas matriciais e valores singulares). *Se*

$$d_1 \geq \dots \geq d_r > 0$$

são os valores singulares positivos de $\mathbf{A}$, então

$$\|\mathbf{A}\|_2 = d_1$$

e

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

(Golub; Van Loan, 2013)

Comprovação. Para a norma espectral, escreva

$$\mathbf{x} = \sum_{j=1}^p \alpha_j \mathbf{v}_j.$$

Então,

$$\|\mathbf{x}\|^2 = \sum_{j=1}^p \alpha_j^2$$

e

$$\|\mathbf{Ax}\|^2 = \sum_{j=1}^r d_j^2 \alpha_j^2.$$

Como $d_j \leq d_1$,

$$\|\mathbf{Ax}\|^2 \leq d_1^2 \|\mathbf{x}\|^2.$$

Logo,

$$\frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} \leq d_1.$$

Tomando

$$\mathbf{x} = \mathbf{v}_1,$$

obtém-se

$$\|\mathbf{Av}_1\| = d_1.$$

Portanto,

$$\|\mathbf{A}\|_2 = d_1.$$

Para a norma de Frobenius,

$$\begin{aligned}
\|\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{A}^\top \mathbf{A}) \\
&= \text{tr}(\mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top) \\
&= \text{tr}(\mathbf{D}_r^2 \mathbf{V}_r^\top \mathbf{V}_r) \\
&= \text{tr}(\mathbf{D}_r^2) \\
&= \sum_{j=1}^r d_j^2.
\end{aligned}$$

□

As duas normas medem aspectos diferentes:

- $\|\mathbf{A}\|_2$ depende somente do maior valor singular e representa o maior fator de ampliação;
- $\|\mathbf{A}\|_F$ reúne as contribuições quadráticas de todos os valores singulares.

Para qualquer matriz,

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2.$$

A primeira desigualdade decorre de

$$d_1^2 \leq \sum_{j=1}^r d_j^2.$$

A segunda decorre de

$$\sum_{j=1}^r d_j^2 \leq r d_1^2.$$

6.4.6 Invariância ortogonal

As normas espectral e de Frobenius são preservadas por multiplicações ortogonais.

Teorema 6.6 (Invariância ortogonal das normas). *Se $\mathbf{Q}_1$ e $\mathbf{Q}_2$ são matrizes ortogonais de dimensões compatíveis, então*

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_2 = \|\mathbf{A}\|_2$$

e

$$\|\mathbf{Q}_1 \mathbf{A} \mathbf{Q}_2\|_F = \|\mathbf{A}\|_F.$$

(Golub; Van Loan, 2013)

A SVD pode, portanto, ser interpretada como uma representação que remove fatores ortogonais sem alterar essas normas:

$$\|\mathbf{A}\|_2 = \|\mathbf{D}\|_2$$

e

$$\|\mathbf{A}\|_F = \|\mathbf{D}\|_F.$$

6.4.7 Determinante e invertibilidade

Quando

$$q = p,$$

a matriz $\mathbf{A}$ é quadrada. Pela SVD,

$$\det(\mathbf{A}) = \det(\mathbf{U}) \det(\mathbf{D}) \det(\mathbf{V}^\top).$$

Como $\mathbf{U}$ e $\mathbf{V}$ são ortogonais,

$$|\det(\mathbf{U})| = |\det(\mathbf{V})| = 1.$$

Portanto,

$$|\det(\mathbf{A})| = \prod_{j=1}^p d_j.$$

O módulo do determinante é o produto dos valores singulares.

Além disso,

$$\mathbf{A} \text{ é invertível} \iff d_j > 0 \text{ para todo } j.$$

Nesse caso,

$$r = p$$

e a SVD compacta coincide, em dimensão, com a SVD completa.

6.4.8 Menor valor singular

Se $\mathbf{A}$ possui posto coluna completo, isto é,

$$r = p \leq q,$$

seu menor valor singular é

$$d_p > 0.$$

Ele possui a caracterização

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

Portanto, d_p mede o menor fator de alteração do comprimento entre os vetores unitários do domínio.

Se

$$d_p$$

é pequeno, existe uma direção unitária cuja imagem possui comprimento pequeno. Nessa direção, a transformação aproxima-se de um colapso.

Se a matriz não possui posto coluna completo, existe um vetor unitário no núcleo e

$$\min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\| = 0.$$

6.4.9 Número de condição

Defina

$$s = \min(q, p).$$

Definição 6.7 (Número de condição na norma espectral). Se

$$\text{posto}(\mathbf{A}) = s,$$

o número de condição espectral é

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_s}.$$

Se

$$\text{posto}(\mathbf{A}) < s,$$

define-se

$$\kappa_2(\mathbf{A}) = \infty.$$

Quando $\mathbf{A}$ possui posto máximo, d_s é o menor valor singular positivo.

Se

$$q \geq p$$

e

$$r = p,$$

a matriz possui posto coluna completo. Nesse caso,

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e

$$d_p = \min_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|.$$

O número de condição compara diretamente os fatores máximo e mínimo de alteração dos comprimentos no domínio inteiro.

Se

$$q < p$$

e

$$r = q,$$

a matriz possui posto linha completo, mas

$$\dim \mathcal{N}(\mathbf{A}) = p - q.$$

Existem, portanto, direções eliminadas pela transformação. Nesse caso, o número de condição descreve a ação de $\mathbf{A}$ restrita ao espaço linha

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{N}(\mathbf{A})^\perp.$$

Nesse subespaço,

$$d_q = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \in \mathcal{C}(\mathbf{A}^\top)}} \|\mathbf{Ax}\|.$$

Para uma matriz quadrada invertível,

$$r = p = q$$

e

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2.$$

De fato,

$$\|\mathbf{A}\|_2 = d_1,$$

e os valores singulares de $\mathbf{A}^{-1}$ são

$$\frac{1}{d_p}, \dots, \frac{1}{d_1}.$$

Logo,

$$\|\mathbf{A}^{-1}\|_2 = \frac{1}{d_p}$$

e

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_p}.$$

A interpretação do número de condição deve considerar somente as direções associadas aos valores singulares positivos.

- Quando

$$\kappa_2(\mathbf{A}) \approx 1,$$

essas direções são transformadas por fatores semelhantes.

- Quando

$$\kappa_2(\mathbf{A})$$

é elevado, algumas direções ativas são preservadas ou ampliadas, enquanto outras são fortemente contraídas.

- Quando

$$\kappa_2(\mathbf{A}) = \infty,$$

o posto é menor que o máximo possível e há valores singulares nulos adicionais além daqueles impostos pelas dimensões retangulares da matriz.

Valores singulares positivos muito pequenos amplificam erros quando se tenta inverter a transformação em seu subespaço ativo. Esse efeito será retomado na seção sobre pseudoinversa e mínimos quadrados.

Exemplo 6.4 (Comparação entre duas transformações). Considere

$$\mathbf{A}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

e

$$\mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 0,02 \end{bmatrix}.$$

Os valores singulares de $\mathbf{A}_1$ são

$$2 \quad \text{e} \quad 2.$$

Portanto,

$$\kappa_2(\mathbf{A}_1) = 1.$$

A matriz amplia todas as direções pelo mesmo fator.

Para $\mathbf{A}_2$, os valores singulares são

$$2 \quad \text{e} \quad 0,02.$$

Logo,

$$\kappa_2(\mathbf{A}_2) = \frac{2}{0,02} = 100.$$

A primeira direção é ampliada por 2, enquanto a segunda é contraída por 0,02. A inversão exigiria multiplicar essa segunda componente por

$$\frac{1}{0,02} = 50.$$

Consequentemente, pequenas perturbações nessa direção podem produzir alterações acentuadas na solução invertida.

6.4.10 Posto exato e posto numérico

Matematicamente, o posto é o número de valores singulares estritamente positivos:

$$r = \# \{j : d_j > 0\}.$$

Em cálculos numéricos, resultados teoricamente nulos podem aparecer como números positivos muito pequenos devido a arredondamentos, ruído ou aproximações computacionais.

Por isso, programas numéricos utilizam uma tolerância τ e tratam como efetivamente nulos os valores singulares que satisfazem

$$d_j \leq \tau.$$

O número de valores singulares acima da tolerância é denominado **posto numérico**.

A tolerância não é uma propriedade puramente algébrica da matriz. Ela depende de:

- precisão numérica;
- escala dos dados;
- dimensões da matriz;
- finalidade da análise;
- nível de ruído considerado relevante.

Essa distinção será útil nas aproximações de posto reduzido. Nessas aproximações, valores singulares pequenos podem ser descartados deliberadamente, mesmo quando são matematicamente positivos.

A SVD fornece, assim, uma descrição integrada da estrutura da matriz:

$$\begin{aligned} \text{posto} &\longleftrightarrow \text{número de valores singulares positivos,} \\ \text{imagem} &\longleftrightarrow \text{vetores singulares à esquerda,} \\ \text{espaço linha} &\longleftrightarrow \text{vetores singulares à direita,} \\ \text{núcleos} &\longleftrightarrow \text{direções associadas a valores nulos,} \\ \text{ampliação máxima} &\longleftrightarrow d_1, \\ \text{contração mínima} &\longleftrightarrow d_r, \\ \text{condicionamento} &\longleftrightarrow d_1/d_r. \end{aligned}$$

Quando a matriz representa um conjunto de dados, as bases à esquerda e à direita descrevem, respectivamente, estruturas nos espaços das observações e das variáveis.

6.5 SVD de uma matriz de dados

Considere uma matriz de dados

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

em que as linhas representam n observações e as colunas representam p variáveis.

Se

$$r = \text{posto}(\mathbf{X}),$$

a SVD compacta é

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

com

$$\mathbf{U}_r \in \mathbb{R}^{n \times r}, \quad \mathbf{D}_r \in \mathbb{R}^{r \times r}$$

e

$$\mathbf{V}_r \in \mathbb{R}^{p \times r}.$$

Nesse contexto, os dois conjuntos de vetores singulares pertencem a espaços diferentes:

- as colunas de $\mathbf{U}_r$ pertencem ao espaço das observações $\mathbb{R}^n$;
- as colunas de $\mathbf{V}_r$ pertencem ao espaço das variáveis $\mathbb{R}^p$.

Os valores singulares conectam essas duas representações.

6.5.1 Coordenadas no espaço das variáveis

Multiplicando a SVD à direita por $\mathbf{V}_r$,

$$\begin{aligned}\mathbf{X}\mathbf{V}_r &= \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top\mathbf{V}_r \\ &= \mathbf{U}_r\mathbf{D}_r.\end{aligned}$$

Defina

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r.$$

Então,

$$\mathbf{Z} = \mathbf{U}_r\mathbf{D}_r.$$

A matriz

$$\mathbf{Z} \in \mathbb{R}^{n \times r}$$

contém as coordenadas das observações nas direções determinadas pelos vetores singulares à direita.

Sua j -ésima coluna é

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j.$$

Portanto, para cada direção $\mathbf{v}_j$ no espaço das variáveis, a multiplicação

$$\mathbf{X}\mathbf{v}_j$$

produz um vetor de n coordenadas, uma para cada observação.

Se a linha i de $\mathbf{X}$ é

$$\mathbf{x}_i^\top,$$

então o elemento z_{ij} é

$$z_{ij} = \mathbf{x}_i^\top \mathbf{v}_j.$$

Assim, z_{ij} é a projeção da observação i sobre a direção $\mathbf{v}_j$.

Como

$$\mathbf{z}_j = d_j \mathbf{u}_j,$$

o vetor singular à esquerda fornece a direção das coordenadas entre as observações, enquanto o valor singular determina sua magnitude.

6.5.2 Coordenadas no espaço das observações

A relação dual é obtida multiplicando a transposta da matriz de dados por $\mathbf{U}_r$:

$$\begin{aligned} \mathbf{X}^\top \mathbf{U}_r &= \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \\ &= \mathbf{V}_r \mathbf{D}_r. \end{aligned}$$

Logo,

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r.$$

A j -ésima coluna dessa matriz é

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Essa expressão representa as variáveis nas direções determinadas pelos vetores singulares à esquerda.

As duas relações

$$\mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r$$

e

$$\mathbf{X}^\top \mathbf{U}_r = \mathbf{V}_r \mathbf{D}_r$$

expressam a dualidade entre os espaços das observações e das variáveis.

Teorema 6.7 (Dualidade entre observações e variáveis). *Se*

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a SVD compacta de uma matriz de dados, então, para cada $j = 1, \dots, r$,

$$\mathbf{X} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{X}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Portanto, o mesmo valor singular d_j relaciona uma direção no espaço das variáveis a uma direção no espaço das observações.

6.5.3 Matrizes de Gram

As matrizes

$$\mathbf{X}^\top \mathbf{X}$$

e

$$\mathbf{X} \mathbf{X}^\top$$

descrevem produtos internos em espaços distintos.

A matriz

$$\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$$

é a matriz de produtos cruzados entre as variáveis. Pela SVD,

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top.$$

A matriz

$$\mathbf{X} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$$

é a matriz de Gram entre as observações:

$$\mathbf{X}\mathbf{X}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

As duas matrizes possuem os mesmos autovalores positivos:

$$d_1^2, \dots, d_r^2.$$

Entretanto, seus autovetores pertencem a espaços diferentes:

- $\mathbf{v}_j \in \mathbb{R}^p$ descreve uma direção entre as variáveis;
- $\mathbf{u}_j \in \mathbb{R}^n$ descreve uma direção entre as observações.

Essa relação permite escolher a menor das duas matrizes para determinadas análises teóricas. Quando

$$n \gg p,$$

a matriz

$$\mathbf{X}^\top \mathbf{X}$$

possui ordem menor. Quando

$$p \gg n,$$

a matriz

$$\mathbf{X}\mathbf{X}^\top$$

pode fornecer uma representação de menor dimensão.

Essa observação não altera a SVD: as duas matrizes compartilham os mesmos valores singulares positivos e representam lados complementares da mesma estrutura.

6.5.4 Reconstrução das observações

A SVD compacta pode ser escrita como

$$\mathbf{X} = (\mathbf{X}\mathbf{V}_r) \mathbf{V}_r^\top.$$

Como

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r,$$

tem-se

$$\mathbf{X} = \mathbf{Z}\mathbf{V}_r^\top.$$

A matriz $\mathbf{Z}$ contém as coordenadas das observações na base formada pelas colunas de $\mathbf{V}_r$. A multiplicação por $\mathbf{V}_r^\top$ reconstrói as observações no espaço original das variáveis.

Para a observação i ,

$$\mathbf{x}_i = \sum_{j=1}^r z_{ij} \mathbf{v}_j.$$

Portanto, todas as observações pertencem ao subespaço

$$\mathcal{C}(\mathbf{V}_r) \subseteq \mathbb{R}^p.$$

Se

$$r < p,$$

a nuvem de observações está contida em um subespaço próprio de $\mathbb{R}^p$. Nesse caso, existe redundância linear exata entre as variáveis.

6.5.5 Preservação de produtos internos

Como

$$\mathbf{Z} = \mathbf{X}\mathbf{V}_r,$$

tem-se

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{V}_r\mathbf{V}_r^\top\mathbf{X}^\top.$$

Como todas as linhas de $\mathbf{X}$ pertencem ao espaço linha

$$\mathcal{C}(\mathbf{V}_r),$$

vale

$$\mathbf{X}\mathbf{V}_r\mathbf{V}_r^\top = \mathbf{X}.$$

Logo,

$$\mathbf{Z}\mathbf{Z}^\top = \mathbf{X}\mathbf{X}^\top.$$

Portanto, a representação pelas r coordenadas singulares positivas preserva exatamente os produtos internos entre as observações.

Para duas observações $\mathbf{x}_i$ e $\mathbf{x}_\ell$, com coordenadas correspondentes $\mathbf{z}_i$ e $\mathbf{z}_\ell$,

$$\mathbf{x}_i^\top \mathbf{x}_\ell = \mathbf{z}_i^\top \mathbf{z}_\ell.$$

Consequentemente,

$$\|\mathbf{x}_i\| = \|\mathbf{z}_i\|$$

e

$$\|\mathbf{x}_i - \mathbf{x}_\ell\| = \|\mathbf{z}_i - \mathbf{z}_\ell\|.$$

A representação compacta reduz a dimensão de p para r quando a matriz possui posto deficiente, sem alterar a geometria euclidiana da nuvem de observações.

Essa redução é exata porque são mantidas todas as direções associadas a valores singulares positivos.

6.5.6 Centralização da matriz de dados

A posição da nuvem de observações depende do vetor de médias. Para estudar sua estrutura em torno do centro, utiliza-se a matriz centralizada

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

em que

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

é a matriz de centralização.

A SVD compacta de $\mathbf{X}_c$ é

$$\mathbf{X}_c = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Como as colunas de $\mathbf{X}_c$ possuem média zero,

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top.$$

Substituindo a SVD,

$$\mathbf{1}_n^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top = \mathbf{0}^\top.$$

Como $\mathbf{D}_r$ é invertível e $\mathbf{V}_r$ possui posto coluna completo,

$$\mathbf{1}_n^\top \mathbf{U}_r = \mathbf{0}^\top.$$

Portanto, cada vetor singular à esquerda associado a um valor singular positivo é ortogonal ao vetor de uns:

$$\mathbf{1}_n^\top \mathbf{u}_j = 0, \quad j = 1, \dots, r.$$

Isso significa que as coordenadas

$$\mathbf{z}_j = d_j \mathbf{u}_j$$

também possuem média zero.

6.5.7 Relação com a matriz de covariâncias amostral

A matriz de covariâncias amostral pode ser escrita como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Substituindo a SVD compacta,

$$\begin{aligned} \mathbf{S} &= \frac{1}{n-1} \mathbf{V}_r \mathbf{D}_r \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \left(\frac{\mathbf{D}_r^2}{n-1} \right) \mathbf{V}_r^\top. \end{aligned}$$

Logo,

$$\mathbf{S} = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Essa expressão mostra que:

- os vetores singulares à direita de $\mathbf{X}_c$ são autovetores de $\mathbf{S}$;
- os autovalores positivos de $\mathbf{S}$ são

$$\frac{d_j^2}{n-1};$$

- o posto de $\mathbf{S}$ é igual ao posto de $\mathbf{X}_c$.

Como

$$\text{posto}(\mathbf{H}_n) = n-1,$$

tem-se

$$\text{posto}(\mathbf{X}_c) \leq \min(n-1, p).$$

Consequentemente,

$$\text{posto}(\mathbf{S}) \leq \min(n-1, p).$$

Se

$$p \geq n,$$

a matriz de covariâncias amostral é necessariamente singular, pois

$$\text{posto}(\mathbf{S}) \leq n-1 < p.$$

Esse resultado será retomado no capítulo de covariâncias. Neste ponto, ele mostra que a SVD da matriz centralizada descreve diretamente a estrutura espectral da covariância amostral.

6.5.8 Magnitude quadrática da matriz centralizada

A norma de Frobenius da matriz centralizada é

$$\begin{aligned}\|\mathbf{X}_c\|_F^2 &= \text{tr}(\mathbf{X}_c^\top \mathbf{X}_c) \\ &= \sum_{j=1}^r d_j^2.\end{aligned}$$

Como

$$\mathbf{X}_c^\top \mathbf{X}_c = (n-1)\mathbf{S},$$

tem-se

$$\|\mathbf{X}_c\|_F^2 = (n-1) \text{tr}(\mathbf{S}).$$

Portanto,

$$\sum_{j=1}^r d_j^2 = (n-1) \text{tr}(\mathbf{S}).$$

A soma dos quadrados dos valores singulares de $\mathbf{X}_c$ corresponde à dispersão quadrática total da nuvem em torno da média, multiplicada por $n-1$.

Essa interpretação depende da centralização. Para uma matriz de dados não centralizada,

$$\|\mathbf{X}\|_F^2$$

mede a soma dos quadrados em relação à origem, e não a dispersão em relação ao vetor de médias.

Exemplo 6.5 (Coordenadas singulares de uma matriz de dados). Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix},$$

cuja SVD compacta é

$$\mathbf{X} = \mathbf{U}_2 \mathbf{D}_2 \mathbf{V}_2^\top,$$

com

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As coordenadas das observações nas direções singulares à direita são

$$\begin{aligned} \mathbf{Z} &= \mathbf{X} \mathbf{V}_2 \\ &= \mathbf{U}_2 \mathbf{D}_2 \\ &= \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ \sqrt{2} & 0 \end{bmatrix}. \end{aligned}$$

A primeira e a terceira observações possuem as mesmas coordenadas, pois suas linhas originais são iguais.

Além disso,

$$\mathbf{Z}\mathbf{Z}^\top = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} = \mathbf{X}\mathbf{X}^\top.$$

Portanto, os produtos internos e as distâncias entre as observações são preservados pela representação nas duas direções singulares positivas.

Nesse exemplo,

$$r = p = 2.$$

Por isso, a transformação por $\mathbf{V}_2$ representa apenas uma mudança ortogonal de coordenadas no espaço das variáveis. Não ocorre redução exata da dimensão.

Se o posto fosse menor que p , a representação por $\mathbf{Z}$ utilizaria menos colunas que a matriz original e ainda preservaria exatamente a geometria da nuvem.

6.5.9 Representação exata e aproximação

A SVD compacta produz a representação exata

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Quando todas as r direções associadas a valores singulares positivos são mantidas:

- a matriz é reconstruída exatamente;
- os produtos internos entre observações são preservados;
- as distâncias euclidianas entre observações são preservadas;
- nenhuma parcela da norma de Frobenius é descartada.

Uma representação de dimensão ainda menor utiliza somente os primeiros k valores singulares, com

$$k < r.$$

Nesse caso, a reconstrução deixa de ser exata. A forma expandida da SVD permite identificar a contribuição de cada direção e quantificar o erro produzido pelo truncamento.

6.6 Forma expandida e aproximações de posto reduzido

A SVD compacta pode ser desenvolvida como uma soma de matrizes de posto 1. Se

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

então

$$\mathbf{U}_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r],$$

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

e

$$\mathbf{V}_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r].$$

Efetuando o produto,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Essa expressão é denominada **forma expandida da SVD**.

Cada parcela

$$d_j \mathbf{u}_j \mathbf{v}_j^\top$$

representa a contribuição do j -ésimo par de direções singulares.

6.6.1 Parcelas de posto 1

Considere a matriz

$$\mathbf{u}_j \mathbf{v}_j^\top.$$

Suas colunas são múltiplos de $\mathbf{u}_j$:

$$\mathbf{u}_j \mathbf{v}_j^\top = [v_{1j} \mathbf{u}_j \quad \cdots \quad v_{pj} \mathbf{u}_j].$$

Como $\mathbf{u}_j$ e $\mathbf{v}_j$ são não nulos,

$$\text{posto}(\mathbf{u}_j \mathbf{v}_j^\top) = 1.$$

A matriz original é, portanto, construída pela soma de r estruturas de posto 1:

$$\mathbf{A} = d_1 \mathbf{u}_1 \mathbf{v}_1^\top + \cdots + d_r \mathbf{u}_r \mathbf{v}_r^\top.$$

Os valores singulares determinam a magnitude de cada parcela. Como

$$d_1 \geq \cdots \geq d_r > 0,$$

as parcelas são organizadas em ordem decrescente segundo sua contribuição para as normas espectral e de Frobenius.

6.6.2 Ortogonalidade das parcelas

As matrizes

$$\mathbf{u}_i \mathbf{v}_i^\top$$

e

$$\mathbf{u}_j \mathbf{v}_j^\top$$

são ortogonais segundo o produto interno de Frobenius quando $i \neq j$.

De fato,

$$\begin{aligned}
\left\langle \mathbf{u}_i \mathbf{v}_i^\top, \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F &= \text{tr} \left[(\mathbf{u}_i \mathbf{v}_i^\top)^\top (\mathbf{u}_j \mathbf{v}_j^\top) \right] \\
&= \text{tr} (\mathbf{v}_i \mathbf{u}_i^\top \mathbf{u}_j \mathbf{v}_j^\top) \\
&= (\mathbf{u}_i^\top \mathbf{u}_j) \text{tr} (\mathbf{v}_i \mathbf{v}_j^\top) \\
&= (\mathbf{u}_i^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_i).
\end{aligned}$$

Como os vetores singulares são ortonormais,

$$\mathbf{u}_i^\top \mathbf{u}_j = 0$$

e

$$\mathbf{v}_j^\top \mathbf{v}_i = 0$$

quando $i \neq j$. Logo,

$$\left\langle \mathbf{u}_i \mathbf{v}_i^\top, \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F = 0.$$

Além disso,

$$\begin{aligned}
\left\| \mathbf{u}_j \mathbf{v}_j^\top \right\|_F^2 &= \left\langle \mathbf{u}_j \mathbf{v}_j^\top, \mathbf{u}_j \mathbf{v}_j^\top \right\rangle_F \\
&= (\mathbf{u}_j^\top \mathbf{u}_j) (\mathbf{v}_j^\top \mathbf{v}_j) \\
&= 1.
\end{aligned}$$

Portanto,

$$\left\| d_j \mathbf{u}_j \mathbf{v}_j^\top \right\|_F = d_j.$$

A identidade

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2$$

pode ser interpretada como uma decomposição pitagórica da magnitude quadrática total da matriz.

6.6.3 SVD truncada

A forma expandida permite construir aproximações conservando somente as primeiras parcelas.

Definição 6.8 (SVD truncada). Seja

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

a SVD compacta expandida de uma matriz de posto r .

Para

$$1 \leq k < r,$$

a **SVD truncada no posto k** é

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Equivalentemente,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Como as colunas de $\mathbf{U}_k$ e $\mathbf{V}_k$ são linearmente independentes e os elementos diagonais de $\mathbf{D}_k$ são positivos,

$$\text{posto}(\mathbf{A}_k) = k.$$

A diferença entre a matriz original e sua aproximação é

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

A matriz $\mathbf{A}_k$ conserva as direções associadas aos k maiores valores singulares. A diferença reúne as direções descartadas.

6.6.4 Ortogonalidade entre aproximação e diferença

Como as parcelas singulares são ortogonais segundo o produto interno de Frobenius,

$$\langle \mathbf{A}_k, \mathbf{A} - \mathbf{A}_k \rangle_F = 0.$$

Consequentemente,

$$\|\mathbf{A}\|_F^2 = \|\mathbf{A}_k\|_F^2 + \|\mathbf{A} - \mathbf{A}_k\|_F^2.$$

As duas parcelas são

$$\|\mathbf{A}_k\|_F^2 = \sum_{j=1}^k d_j^2$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A razão

$$\frac{\|\mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

mede a proporção da magnitude quadrática da matriz preservada pela aproximação.

A parcela descartada é

$$\frac{\|\mathbf{A} - \mathbf{A}_k\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{\sum_{j=k+1}^r d_j^2}{\sum_{j=1}^r d_j^2}.$$

As duas proporções somam 1.

Para uma matriz genérica, essas quantidades devem ser interpretadas em termos da norma de Frobenius. Quando $\mathbf{A}$ é uma matriz de dados centralizada, elas também podem ser relacionadas à dispersão total da nuvem de observações.

6.6.5 Erro na norma espectral

O maior valor singular da diferença

$$\mathbf{A} - \mathbf{A}_k = \sum_{j=k+1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top$$

é

$$d_{k+1}.$$

Portanto,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Esse erro mede a maior diferença entre a ação de $\mathbf{A}$ e a ação de $\mathbf{A}_k$ sobre um vetor unitário:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = \max_{\|\mathbf{x}\|=1} \|(\mathbf{A} - \mathbf{A}_k) \mathbf{x}\|.$$

A direção em que o erro máximo é atingido é

$$\mathbf{v}_{k+1},$$

pois

$$(\mathbf{A} - \mathbf{A}_k) \mathbf{v}_{k+1} = d_{k+1} \mathbf{u}_{k+1}.$$

6.6.6 Teorema de Eckart–Young–Mirsky

A SVD truncada não é somente uma forma conveniente de produzir uma matriz de posto menor. Ela fornece uma aproximação ótima.

Teorema 6.8 (Teorema de Eckart–Young–Mirsky). *Seja*

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

uma matriz de posto r , com valores singulares

$$d_1 \geq \dots \geq d_r > 0.$$

Para

$$1 \leq k < r,$$

defina

$$\mathbf{A}_k = \sum_{j=1}^k d_j \mathbf{u}_j \mathbf{v}_j^\top.$$

Então $\mathbf{A}_k$ é uma solução dos problemas

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_2$$

e

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_F.$$

Os erros mínimos são

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_2 = d_{k+1}$$

e

$$\min_{\text{posto}(\widetilde{\mathbf{A}}) \leq k} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_F = \sqrt{\sum_{j=k+1}^r d_j^2}.$$

(Golub; Van Loan, 2013)

Comprovação. Considere inicialmente a norma espectral e uma matriz arbitrária

$$\widetilde{\mathbf{A}}$$

com

$$\text{posto}(\widetilde{\mathbf{A}}) \leq k.$$

Defina o subespaço

$$\mathcal{S}_{k+1} = \text{span} \{ \mathbf{v}_1, \dots, \mathbf{v}_{k+1} \}.$$

Como

$$\dim(\mathcal{S}_{k+1}) = k + 1$$

e a restrição de $\widetilde{\mathbf{A}}$ a esse subespaço possui imagem de dimensão no máximo k , existe um vetor unitário

$$\mathbf{x} \in \mathcal{S}_{k+1}$$

tal que

$$\widetilde{\mathbf{A}}\mathbf{x} = \mathbf{0}.$$

Escreva

$$\mathbf{x} = \sum_{j=1}^{k+1} \alpha_j \mathbf{v}_j,$$

com

$$\sum_{j=1}^{k+1} \alpha_j^2 = 1.$$

Então,

$$\begin{aligned} \left\| (\mathbf{A} - \widetilde{\mathbf{A}}) \mathbf{x} \right\|^2 &= \|\mathbf{A}\mathbf{x}\|^2 \\ &= \sum_{j=1}^{k+1} d_j^2 \alpha_j^2 \\ &\geq d_{k+1}^2 \sum_{j=1}^{k+1} \alpha_j^2 \\ &= d_{k+1}^2. \end{aligned}$$

Logo,

$$\|\mathbf{A} - \widetilde{\mathbf{A}}\|_2 \geq d_{k+1}.$$

Para a SVD truncada,

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}.$$

Portanto, $\mathbf{A}_k$ atinge o limite inferior e é uma solução ótima na norma espectral.

Para a norma de Frobenius, considere o projetor ortogonal

$$\mathbf{P}$$

sobre o espaço coluna de $\widetilde{\mathbf{A}}$. Como

$$\text{posto}(\widetilde{\mathbf{A}}) \leq k,$$

tem-se

$$\text{posto}(\mathbf{P}) \leq k.$$

Além disso,

$$\mathbf{P}\widetilde{\mathbf{A}} = \widetilde{\mathbf{A}}.$$

A diferença pode ser decomposta como

$$\mathbf{A} - \widetilde{\mathbf{A}} = (\mathbf{I}_q - \mathbf{P}) \mathbf{A} + (\mathbf{P}\mathbf{A} - \widetilde{\mathbf{A}}).$$

As duas parcelas são ortogonais segundo o produto interno de Frobenius, pois a primeira possui colunas no complemento ortogonal de $\mathcal{C}(\mathbf{P})$, enquanto a segunda possui colunas em $\mathcal{C}(\mathbf{P})$.

Assim,

$$\begin{aligned} \|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &= \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 \\ &\quad + \|\mathbf{P}\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 \\ &\geq \|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2. \end{aligned}$$

A primeira parcela pode ser escrita como

$$\|(\mathbf{I}_q - \mathbf{P}) \mathbf{A}\|_F^2 = \|\mathbf{A}\|_F^2 - \|\mathbf{P}\mathbf{A}\|_F^2.$$

Considere uma base ortonormal

$$\mathbf{w}_1, \dots, \mathbf{w}_s, \quad s \leq k,$$

do espaço projetado por $\mathbf{P}$. Então,

$$\mathbf{P} = \sum_{i=1}^s \mathbf{w}_i \mathbf{w}_i^\top$$

e

$$\begin{aligned} \|\mathbf{P}\mathbf{A}\|_F^2 &= \text{tr}(\mathbf{P}\mathbf{A}\mathbf{A}^\top) \\ &= \sum_{i=1}^s \mathbf{w}_i^\top \mathbf{A}\mathbf{A}^\top \mathbf{w}_i. \end{aligned}$$

Expandindo os vetores $\mathbf{w}_i$ na base dos vetores singulares à esquerda, obtém-se

$$\|\mathbf{P}\mathbf{A}\|_F^2 = \sum_{j=1}^r c_j d_j^2,$$

em que

$$0 \leq c_j \leq 1$$

e

$$\sum_{j=1}^r c_j \leq k.$$

Como os valores singulares estão ordenados,

$$\|\mathbf{P}\mathbf{A}\|_F^2 \leq \sum_{j=1}^k d_j^2.$$

Portanto,

$$\begin{aligned}\|\mathbf{A} - \widetilde{\mathbf{A}}\|_F^2 &\geq \|\mathbf{A}\|_F^2 - \sum_{j=1}^k d_j^2 \\ &= \sum_{j=k+1}^r d_j^2.\end{aligned}$$

Para

$$\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^\top,$$

tem-se

$$\mathbf{P}\mathbf{A} = \mathbf{A}_k.$$

Além disso,

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

Logo, $\mathbf{A}_k$ também atinge o limite inferior na norma de Frobenius. $\square$

O teorema mostra que nenhum outro procedimento pode produzir uma matriz de posto no máximo k com erro menor nas duas normas consideradas.

6.6.7 Unicidade da aproximação

A existência de uma aproximação ótima não implica sempre unicidade.

Na norma de Frobenius, a aproximação de posto k é única quando

$$d_k > d_{k+1}.$$

Se

$$d_k = d_{k+1},$$

o limite de truncamento atravessa um subespaço singular associado a um valor repetido. Nesse caso, diferentes escolhas de bases e subespaços dentro desse bloco podem produzir aproximações ótimas distintas.

Na norma espectral, $\mathbf{A}_k$ é uma aproximação ótima, mas outras matrizes de posto no máximo k também podem atingir o mesmo erro. A unicidade não deve ser presumida apenas pela existência de uma separação entre valores singulares.

Quando

$$k \geq r,$$

a aproximação exata é

$$\mathbf{A}_k = \mathbf{A},$$

e o erro é zero.

6.6.8 Exemplo de aproximação de posto 1

Exemplo 6.6 (Aproximação de posto 1 do exemplo condutor). Considere novamente

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Sua forma expandida é

$$\mathbf{A} = 2\mathbf{u}_1\mathbf{v}_1^\top + \sqrt{2}\mathbf{u}_2\mathbf{v}_2^\top,$$

em que

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e

$$\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A aproximação de posto 1 é

$$\begin{aligned}
\mathbf{A}_1 &= 2\mathbf{u}_1\mathbf{v}_1^\top \\
&= 2\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix}\right) \\
&= \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}.
\end{aligned}$$

A diferença entre a matriz original e a aproximação é

$$\mathbf{A} - \mathbf{A}_1 = \begin{bmatrix} 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

Como

$$d_1 = 2$$

e

$$d_2 = \sqrt{2},$$

o erro espectral é

$$\|\mathbf{A} - \mathbf{A}_1\|_2 = \sqrt{2}.$$

O erro de Frobenius também é

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{2},$$

pois somente um valor singular foi descartado.

A magnitude quadrática total é

$$\|\mathbf{A}\|_F^2 = 2^2 + (\sqrt{2})^2 = 6.$$

A aproximação preserva

$$\|\mathbf{A}_1\|_F^2 = 2^2 = 4.$$

Portanto, a proporção preservada é

$$\frac{\|\mathbf{A}_1\|_F^2}{\|\mathbf{A}\|_F^2} = \frac{4}{6} = \frac{2}{3}.$$

A primeira parcela reproduz exatamente a primeira e a terceira linhas da matriz. A segunda linha está inteiramente associada à direção singular descartada.

6.6.9 Aproximação de uma matriz de dados

Se

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é uma matriz de dados, sua aproximação de posto k é

$$\mathbf{X}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top.$$

Definindo

$$\mathbf{Z}_k = \mathbf{X} \mathbf{V}_k,$$

tem-se

$$\mathbf{Z}_k = \mathbf{U}_k \mathbf{D}_k$$

e

$$\mathbf{X}_k = \mathbf{Z}_k \mathbf{V}_k^\top.$$

A matriz $\mathbf{Z}_k$ fornece uma representação das observações em k coordenadas. A multiplicação por $\mathbf{V}_k^\top$ reconstrói uma aproximação das variáveis originais.

Para a observação i ,

$$\hat{\mathbf{x}}_{i,k} = \sum_{j=1}^k z_{ij} \mathbf{v}_j.$$

O vetor residual é

$$\mathbf{x}_i - \hat{\mathbf{x}}_{i,k} = \sum_{j=k+1}^r z_{ij} \mathbf{v}_j.$$

A SVD truncada escolhe o subespaço de dimensão k que minimiza a soma dos erros quadráticos de reconstrução de todas as observações:

$$\|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_{i,k}\|^2.$$

Quando $\mathbf{X}$ está centralizada,

$$\frac{\sum_{j=1}^k d_j^2}{\sum_{j=1}^r d_j^2}$$

representa a parcela da dispersão quadrática total preservada pelas primeiras k direções singulares.

Essa estrutura será retomada posteriormente na formulação de técnicas de redução de dimensionalidade. Neste capítulo, o resultado deve ser interpretado como uma propriedade geral da aproximação matricial de posto reduzido.

A SVD truncada descarta direções associadas a valores singulares menores. A pseudoinversa realiza uma operação diferente: ela conserva as direções associadas a valores singulares positivos e inverte os respectivos fatores de escala.

6.7 Pseudoinversa e soluções de mínimos quadrados

A inversa usual é definida somente para matrizes quadradas e invertíveis. A SVD permite construir uma transformação inversa generalizada para qualquer matriz real, inclusive matrizes:

- retangulares;
- singulares;
- deficientes em posto.

Essa transformação é a **pseudoinversa de Moore–Penrose**.

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

com posto

$$r = \text{posto}(\mathbf{A})$$

e SVD compacta

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top.$$

Como todos os elementos diagonais de

$$\mathbf{D}_r = \text{diag}(d_1, \dots, d_r)$$

são positivos, a matriz

$$\mathbf{D}_r^{-1} = \text{diag}\left(\frac{1}{d_1}, \dots, \frac{1}{d_r}\right)$$

está bem definida.

Definição 6.9 (Pseudoinversa de Moore–Penrose). A **pseudoinversa de Moore–Penrose** de

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top$$

é a matriz

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Sua dimensão é

$$\mathbf{A}^+ \in \mathbb{R}^{p \times q}.$$

A pseudoinversa inverte os escalonamentos associados aos valores singulares positivos:

$$\mathbf{A}^+ \mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j, \quad j = 1, \dots, r.$$

As componentes pertencentes ao núcleo de $\mathbf{A}^\top$ são anuladas. Se

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top),$$

então

$$\mathbf{A}^+ \mathbf{u} = \mathbf{0}.$$

Portanto, a pseudoinversa desfaz a ação de $\mathbf{A}$ somente nas direções efetivamente representadas pela transformação.

6.7.1 Relação com a pseudoinversa espectral

No capítulo anterior, a pseudoinversa de uma matriz simétrica foi definida por meio da decomposição espectral.

Se

$$\mathbf{A} = \mathbf{Q}_A \Lambda_A \mathbf{Q}_A^\top$$

é simétrica, a definição espectral produz

$$\mathbf{A}^+ = \mathbf{Q}_A \Lambda_A^+ \mathbf{Q}_A^\top,$$

em que cada autovalor não nulo é substituído por seu inverso.

A definição pela SVD coincide com essa construção, mas permanece válida quando $\mathbf{A}$ não é simétrica ou é retangular.

Se $\mathbf{A}$ é quadrada e invertível, todos os valores singulares são positivos e

$$\mathbf{A}^+ = \mathbf{A}^{-1}.$$

Assim, a pseudoinversa generaliza a inversa usual.

6.7.2 Condições de Moore–Penrose

A pseudoinversa é caracterizada por quatro identidades.

Teorema 6.9 (Condições de Moore–Penrose). *Para toda matriz real $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$ que satisfaz*

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+,$$

$$(\mathbf{A}\mathbf{A}^+)^{\top} = \mathbf{A}\mathbf{A}^+,$$

e

$$(\mathbf{A}^+\mathbf{A})^{\top} = \mathbf{A}^+\mathbf{A}.$$

(Golub; Van Loan, 2013)

Comprovação. Pela SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top}$$

e

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top}.$$

Então,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+\mathbf{A} &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \\ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \\ &= \mathbf{A}. \end{aligned}$$

De modo semelhante,

$$\begin{aligned} \mathbf{A}^+\mathbf{A}\mathbf{A}^+ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^{\top} \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \\ &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^{\top} \\ &= \mathbf{A}^+. \end{aligned}$$

Além disso,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$$

e

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top,$$

que são matrizes simétricas. Portanto, a matriz definida pela SVD satisfaz as quatro condições de Moore–Penrose.

Para demonstrar a unicidade, suponha que

$$\mathbf{G} \in \mathbb{R}^{p \times q}$$

também satisfaça as quatro condições.

A matriz $\mathbf{AG}$ é simétrica e

$$\begin{aligned} (\mathbf{AG})^2 &= \mathbf{AGAG} \\ &= (\mathbf{AGA})\mathbf{G} \\ &= \mathbf{AG}. \end{aligned}$$

Logo, $\mathbf{AG}$ é um projetor ortogonal.

Sua imagem está contida em $\mathcal{C}(\mathbf{A})$. Além disso, se

$$\mathbf{y} = \mathbf{Ax} \in \mathcal{C}(\mathbf{A}),$$

então

$$\mathbf{AGy} = \mathbf{AGAx} = \mathbf{Ax} = \mathbf{y}.$$

Portanto,

$$\mathbf{AG} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} = \mathbf{U}_r \mathbf{U}_r^\top.$$

De maneira análoga, $\mathbf{GA}$ é simétrica e idempotente.

Se

$$\mathbf{x} \in \mathcal{N}(\mathbf{A}),$$

então

$$\mathbf{GAx} = \mathbf{0}.$$

Reciprocamente, se

$$\mathbf{GAx} = \mathbf{0},$$

então

$$\mathbf{Ax} = \mathbf{AGAx} = \mathbf{0}.$$

Logo,

$$\mathcal{N}(\mathbf{GA}) = \mathcal{N}(\mathbf{A}).$$

Como $\mathbf{GA}$ é um projetor ortogonal,

$$\mathbf{GA} = \mathbf{P}_{\mathcal{N}(\mathbf{A})^\perp} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)} = \mathbf{V}_r \mathbf{V}_r^\top.$$

Da condição

$$\mathbf{GAG} = \mathbf{G},$$

segue que

$$\mathcal{C}(\mathbf{G}) \subseteq \mathcal{C}(\mathbf{GA}) = \mathcal{C}(\mathbf{A}^\top).$$

Considere agora um vetor singular à esquerda $\mathbf{u}_j$, com $j \leq r$. Como

$$\mathbf{u}_j \in \mathcal{C}(\mathbf{A}),$$

tem-se

$$\mathbf{AGu}_j = \mathbf{u}_j.$$

Como

$$\mathbf{G}\mathbf{u}_j \in \mathcal{C}(\mathbf{A}^\top),$$

esse vetor pode ser escrito como

$$\mathbf{G}\mathbf{u}_j = \sum_{\ell=1}^r c_\ell \mathbf{v}_\ell.$$

Aplicando $\mathbf{A}$,

$$\mathbf{u}_j = \sum_{\ell=1}^r c_\ell d_\ell \mathbf{u}_\ell.$$

Pela unicidade das coordenadas na base ortonormal,

$$c_\ell = \begin{cases} 1/d_j, & \ell = j, \\ 0, & \ell \neq j. \end{cases}$$

Portanto,

$$\mathbf{G}\mathbf{u}_j = \frac{1}{d_j} \mathbf{v}_j.$$

Considere, por fim,

$$\mathbf{u} \in \mathcal{N}(\mathbf{A}^\top).$$

Como $\mathbf{A}\mathbf{G}$ projeta sobre $\mathcal{C}(\mathbf{A})$,

$$\mathbf{A}\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Além disso,

$$\mathbf{G}\mathbf{u} \in \mathcal{C}(\mathbf{A}^\top).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \cap \mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

segue que

$$\mathbf{G}\mathbf{u} = \mathbf{0}.$$

Assim, $\mathbf{G}$ atua sobre a base ortonormal formada pelas colunas de $\mathbf{U}_r$ e de $\mathbf{U}_0$ exatamente como

$$\mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Logo,

$$\mathbf{G} = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top = \mathbf{A}^+.$$

Portanto, a pseudoinversa de Moore–Penrose existe e é única. □

6.7.3 Pseudoinversa e projetores

Os produtos

$$\mathbf{A}\mathbf{A}^+$$

e

$$\mathbf{A}^+ \mathbf{A}$$

possuem interpretações geométricas distintas.

Pela SVD,

$$\begin{aligned} \mathbf{A}\mathbf{A}^+ &= \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \\ &= \mathbf{U}_r \mathbf{U}_r^\top. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{C}(\mathbf{A})},$$

o projetor ortogonal sobre o espaço coluna de $\mathbf{A}$.

De modo semelhante,

$$\begin{aligned}\mathbf{A}^+\mathbf{A} &= \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top \\ &= \mathbf{V}_r \mathbf{V}_r^\top.\end{aligned}$$

Logo,

$$\mathbf{A}^+\mathbf{A} = \mathbf{P}_{\mathcal{C}(\mathbf{A}^\top)},$$

o projetor ortogonal sobre o espaço linha de $\mathbf{A}$.

Os complementos são

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+ = \mathbf{P}_{\mathcal{N}(\mathbf{A}^\top)}$$

e

$$\mathbf{I}_p - \mathbf{A}^+\mathbf{A} = \mathbf{P}_{\mathcal{N}(\mathbf{A})}.$$

A Tabela 6.4 resume essas relações.

Tabela 6.4: Projetores ortogonais determinados pela pseudoinversa.

Matriz	Espaço projetado
$\mathbf{A}\mathbf{A}^+$	$\mathcal{C}(\mathbf{A})$
$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+$	$\mathcal{N}(\mathbf{A}^\top)$
$\mathbf{A}^+\mathbf{A}$	$\mathcal{C}(\mathbf{A}^\top)$
$\mathbf{I}_p - \mathbf{A}^+\mathbf{A}$	$\mathcal{N}(\mathbf{A})$

6.7.4 Sistemas lineares compatíveis

Considere o sistema

$$\mathbf{A}\mathbf{x} = \mathbf{b},$$

em que

$$\mathbf{b} \in \mathbb{R}^q.$$

O sistema é compatível quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}).$$

Como

$$\mathbf{A}\mathbf{A}^+$$

é o projetor sobre esse espaço,

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}) \iff \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

Se o sistema é compatível, então

$$\mathbf{x}_0 = \mathbf{A}^+\mathbf{b}$$

é uma solução, pois

$$\mathbf{A}\mathbf{x}_0 = \mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{b}.$$

As demais soluções são obtidas acrescentando qualquer vetor do núcleo:

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{x}_{\mathcal{N}},$$

com

$$\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}).$$

Utilizando a base fornecida pela SVD,

$$\mathbf{x}_{\mathcal{N}} = \mathbf{V}_0\gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Portanto, o conjunto de soluções pode ser escrito como

$$\mathbf{x} = \mathbf{A}^+\mathbf{b} + \mathbf{V}_0\gamma.$$

Se

$$r = p,$$

então

$$\mathcal{N}(\mathbf{A}) = \{\mathbf{0}\},$$

e a solução é única:

$$\mathbf{x} = \mathbf{A}^+ \mathbf{b}.$$

6.7.5 Solução de menor norma

Quando um sistema compatível possui várias soluções, a pseudoinversa seleciona a solução de menor norma euclidiana.

Teorema 6.10 (Solução compatível de menor norma). *Se*

$$\mathbf{Ax} = \mathbf{b}$$

é compatível, então

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$$

é a única solução de menor norma euclidiana. (Golub; Van Loan, 2013)

Comprovação. Toda solução possui a forma

$$\mathbf{x} = \mathbf{A}^+ \mathbf{b} + \mathbf{x}_{\mathcal{N}},$$

com

$$\mathbf{x}_{\mathcal{N}} \in \mathcal{N}(\mathbf{A}).$$

A pseudoinversa produz um vetor no espaço linha:

$$\mathbf{A}^+ \mathbf{b} \in \mathcal{C}(\mathbf{A}^{\top}).$$

Como

$$\mathcal{C}(\mathbf{A}^\top) \perp \mathcal{N}(\mathbf{A}),$$

tem-se

$$(\mathbf{A}^+\mathbf{b})^\top \mathbf{x}_{\mathcal{N}} = 0.$$

Pelo Teorema de Pitágoras,

$$\|\mathbf{x}\|^2 = \|\mathbf{A}^+\mathbf{b}\|^2 + \|\mathbf{x}_{\mathcal{N}}\|^2.$$

Logo,

$$\|\mathbf{x}\| \geq \|\mathbf{A}^+\mathbf{b}\|,$$

com igualdade somente quando

$$\mathbf{x}_{\mathcal{N}} = \mathbf{0}.$$

Portanto,

$$\mathbf{x}^\star = \mathbf{A}^+\mathbf{b}$$

é a única solução de menor norma. □

6.7.6 Sistemas incompatíveis e mínimos quadrados

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

não possui solução exata.

Nesse caso, procura-se um vetor $\mathbf{x}$ que minimize a distância entre $\mathbf{Ax}$ e $\mathbf{b}$:

$$\min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|^2.$$

Esse é o problema de **mínimos quadrados**.

Definição 6.10 (Solução de mínimos quadrados). Um vetor

$$\hat{\mathbf{x}} \in \mathbb{R}^p$$

é uma solução de mínimos quadrados do sistema

$$\mathbf{Ax} = \mathbf{b}$$

quando

$$\|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\| = \min_{\mathbf{x} \in \mathbb{R}^p} \|\mathbf{b} - \mathbf{Ax}\|.$$

O vetor ajustado é a projeção ortogonal de $\mathbf{b}$ sobre o espaço coluna:

$$\hat{\mathbf{b}} = \mathbf{P}_{\mathcal{C}(\mathbf{A})} \mathbf{b}.$$

Pela pseudoinversa,

$$\hat{\mathbf{b}} = \mathbf{AA}^+ \mathbf{b}.$$

Uma solução de mínimos quadrados é

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b},$$

pois

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{AA}^+ \mathbf{b} = \hat{\mathbf{b}}.$$

6.7.7 Resíduo de mínimos quadrados

O vetor residual é

$$\mathbf{r} = \mathbf{b} - \hat{\mathbf{b}}.$$

Substituindo a expressão do vetor ajustado,

$$\mathbf{r} = (\mathbf{I}_q - \mathbf{A}\mathbf{A}^+) \mathbf{b}.$$

Como

$$\mathbf{I}_q - \mathbf{A}\mathbf{A}^+$$

projeta sobre

$$\mathcal{N}(\mathbf{A}^\top),$$

tem-se

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

Portanto,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

Como

$$\mathbf{r} = \mathbf{b} - \mathbf{A}\hat{\mathbf{x}},$$

segue que

$$\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}.$$

Reorganizando,

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Essas são as **equações normais** do problema de mínimos quadrados.

A interpretação geométrica é:

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r},$$

com

$$\hat{\mathbf{b}} \in \mathcal{C}(\mathbf{A})$$

e

$$\mathbf{r} \in \mathcal{N}(\mathbf{A}^\top).$$

As duas parcelas são ortogonais:

$$\hat{\mathbf{b}}^\top \mathbf{r} = 0.$$

Assim,

$$\|\mathbf{b}\|^2 = \|\hat{\mathbf{b}}\|^2 + \|\mathbf{r}\|^2.$$

6.7.8 Conjunto das soluções de mínimos quadrados

As equações normais podem possuir várias soluções quando $\mathbf{A}$ é deficiente em posto.

Teorema 6.11 (Soluções de mínimos quadrados pela SVD). *O conjunto de todas as soluções do problema*

$$\min_{\mathbf{x}} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|^2$$

é

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} + \mathbf{V}_0 \gamma,$$

em que

$$\gamma \in \mathbb{R}^{p-r}.$$

Entre essas soluções,

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}$$

é a única de menor norma. (Golub; Van Loan, 2013)

Comprovação. Todos os vetores da forma

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} + \mathbf{V}_0 \gamma$$

produzem o mesmo vetor ajustado, pois

$$\mathbf{A} \mathbf{V}_0 = \mathbf{0}.$$

Assim,

$$\begin{aligned} \mathbf{A} \hat{\mathbf{x}} &= \mathbf{A} \mathbf{A}^+ \mathbf{b} + \mathbf{A} \mathbf{V}_0 \gamma \\ &= \mathbf{A} \mathbf{A}^+ \mathbf{b}. \end{aligned}$$

Logo, todos esses vetores minimizam o mesmo resíduo.

Reciprocamente, duas soluções de mínimos quadrados produzem o mesmo vetor ajustado, que é a projeção de $\mathbf{b}$ sobre $\mathcal{C}(\mathbf{A})$. Portanto, a diferença entre elas pertence ao núcleo de $\mathbf{A}$ e pode ser escrita como

$$\mathbf{V}_0 \gamma.$$

A propriedade de menor norma segue da ortogonalidade entre

$$\mathcal{C}(\mathbf{A}^\top)$$

e

$$\mathcal{N}(\mathbf{A}),$$

pelo mesmo argumento utilizado no caso compatível. □

Quando

$$r = p,$$

a matriz possui posto coluna completo e a solução de mínimos quadrados é única:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{A}$$

é positiva definida e invertível. A pseudoinversa assume a forma

$$\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top.$$

Logo,

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Se $\mathbf{A}$ possui posto linha completo,

$$r = q \leq p,$$

então

$$\mathbf{A} \mathbf{A}^\top$$

é invertível e

$$\mathbf{A}^+ = \mathbf{A}^\top (\mathbf{A} \mathbf{A}^\top)^{-1}.$$

Essa expressão fornece a solução de menor norma dos sistemas compatíveis subdeterminados.

6.7.9 Expressão espectral da solução

A pseudoinversa permite decompor a solução nas direções singulares.

Como

$$\mathbf{A}^+ = \sum_{j=1}^r \frac{1}{d_j} \mathbf{v}_j \mathbf{u}_j^\top,$$

tem-se

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b} = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

A solução é construída em três etapas:

1. calcula-se a componente de $\mathbf{b}$ na direção $\mathbf{u}_j$:

$$\mathbf{u}_j^\top \mathbf{b};$$

2. divide-se essa componente pelo valor singular:

$$\frac{\mathbf{u}_j^\top \mathbf{b}}{d_j};$$

3. expressa-se o resultado na direção $\mathbf{v}_j$.

A componente de $\mathbf{b}$ no núcleo de $\mathbf{A}^\top$ não aparece na solução, pois não pode ser reproduzida por nenhum vetor da forma $\mathbf{Ax}$.

O vetor ajustado é

$$\hat{\mathbf{b}} = \sum_{j=1}^r (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j,$$

enquanto o resíduo é

$$\mathbf{r} = \sum_{j=r+1}^q (\mathbf{u}_j^\top \mathbf{b}) \mathbf{u}_j.$$

6.7.10 Valores singulares pequenos e instabilidade

A expressão

$$\hat{\mathbf{x}}^* = \sum_{j=1}^r \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j$$

mostra que valores singulares pequenos podem produzir coeficientes elevados.

Considere uma perturbação

$$\mathbf{b} \mapsto \mathbf{b} + \varepsilon.$$

A alteração na solução de menor norma é

$$\begin{aligned} \Delta \hat{\mathbf{x}} &= \mathbf{A}^+ \varepsilon \\ &= \sum_{j=1}^r \frac{\mathbf{u}_j^\top \varepsilon}{d_j} \mathbf{v}_j. \end{aligned}$$

Se d_j é pequeno, uma pequena componente de ε na direção $\mathbf{u}_j$ pode ser ampliada por

$$\frac{1}{d_j}.$$

Esse comportamento relaciona:

- valores singulares pequenos;
- número de condição elevado;
- sensibilidade a perturbações;
- instabilidade de soluções inversas.

Descartar ou modificar a inversão de valores singulares pequenos pode reduzir essa instabilidade. Esses procedimentos pertencem ao estudo da regularização e não serão desenvolvidos neste capítulo.

6.7.11 Pseudoinversa truncada

A SVD truncada sugere uma inversão aproximada que conserva somente os k maiores valores singulares:

$$\mathbf{A}_k^+ = \mathbf{V}_k \mathbf{D}_k^{-1} \mathbf{U}_k^\top.$$

A solução correspondente é

$$\hat{\mathbf{x}}_k = \mathbf{A}_k^+ \mathbf{b} = \sum_{j=1}^k \frac{\mathbf{u}_j^\top \mathbf{b}}{d_j} \mathbf{v}_j.$$

Essa expressão elimina as contribuições associadas às direções singulares descartadas.

A pseudoinversa truncada pode produzir uma solução menos sensível a componentes ligadas a valores singulares pequenos, mas também introduz erro por omitir parte da estrutura da matriz. A escolha de k depende do problema e não será tratada como um procedimento geral neste módulo.

6.7.12 Exemplo com o sistema condutor

Exemplo 6.7 (Pseudoinversa e mínimos quadrados no exemplo condutor). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}.$$

A SVD compacta de $\mathbf{A}$ possui

$$\mathbf{U}_2 = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 1 \\ 1/\sqrt{2} & 0 \end{bmatrix},$$

$$\mathbf{D}_2 = \begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{bmatrix}$$

e

$$\mathbf{V}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_2 \mathbf{D}_2^{-1} \mathbf{U}_2^\top.$$

Efetuando os produtos,

$$\mathbf{A}^+ = \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\begin{aligned} \hat{\mathbf{x}} &= \mathbf{A}^+ \mathbf{b} \\ &= \begin{bmatrix} 1/4 & 1/2 & 1/4 \\ 1/4 & -1/2 & 1/4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix}. \end{aligned}$$

O vetor ajustado é

$$\begin{aligned} \hat{\mathbf{b}} &= \mathbf{A} \hat{\mathbf{x}} \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 5/4 \\ -3/4 \end{bmatrix} \\ &= \begin{bmatrix} 1/2 \\ 2 \\ 1/2 \end{bmatrix}. \end{aligned}$$

O resíduo é

$$\begin{aligned} \mathbf{r} &= \mathbf{b} - \hat{\mathbf{b}} \\ &= \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}. \end{aligned}$$

O vetor

$$\mathbf{u}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

forma uma base do núcleo de $\mathbf{A}^\top$. De fato,

$$\mathbf{r} = \frac{1}{\sqrt{2}} \mathbf{u}_3.$$

Consequentemente,

$$\mathbf{A}^\top \mathbf{r} = \mathbf{0}.$$

O sistema original é incompatível porque a primeira e a terceira equações exigiriam simultaneamente

$$x_1 + x_2 = 1$$

e

$$x_1 + x_2 = 0.$$

A solução de mínimos quadrados substitui esses dois valores pela projeção comum

$$x_1 + x_2 = \frac{1}{2}.$$

Como $\mathbf{A}$ possui posto coluna completo, a solução de mínimos quadrados é única.

A pseudoinversa reúne, em uma única construção:

- inversão nas direções associadas a valores singulares positivos;
- projeção sobre os espaços fundamentais;
- solução de sistemas compatíveis;
- seleção da solução de menor norma;
- solução de mínimos quadrados para sistemas incompatíveis.

Essas relações encerram a estrutura algébrica da SVD. A síntese do capítulo organiza as formas da decomposição, suas interpretações e suas principais consequências.

6.8 Síntese do capítulo

A Decomposição em Valores Singulares representa qualquer matriz real

$$\mathbf{A} \in \mathbb{R}^{q \times p}$$

na forma

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são ortogonais e $\mathbf{D}$ contém os valores singulares não negativos.

Para cada valor singular positivo,

$$\mathbf{A} \mathbf{v}_j = d_j \mathbf{u}_j$$

e

$$\mathbf{A}^\top \mathbf{u}_j = d_j \mathbf{v}_j.$$

Assim, $\mathbf{v}_j$ determina uma direção no domínio, d_j determina o fator de escala e $\mathbf{u}_j$ determina a direção correspondente no contradomínio.

A SVD completa utiliza bases ortonormais de todo o domínio e de todo o contradomínio. A SVD compacta,

$$\mathbf{A} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

conserva somente os r valores singulares positivos e reconstrói exatamente a matriz. A SVD truncada,

$$\mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^\top, \quad k < r,$$

produz uma aproximação de posto reduzido.

Os valores singulares são obtidos pelas decomposições espectrais

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r \mathbf{D}_r^2 \mathbf{V}_r^\top$$

e

$$\mathbf{A}\mathbf{A}^\top = \mathbf{U}_r \mathbf{D}_r^2 \mathbf{U}_r^\top.$$

As duas matrizes possuem os mesmos autovalores positivos,

$$d_1^2, \dots, d_r^2,$$

mas seus autovetores pertencem a espaços diferentes.

A interpretação geométrica mostra que a SVD transforma a bola unitária em um elipsoide. Suas direções principais são os vetores singulares à esquerda, e os comprimentos dos semieixos são os valores singulares. O maior valor singular satisfaz

$$\|\mathbf{A}\|_2 = d_1$$

e representa o maior fator de ampliação da transformação.

A SVD fornece bases ortonormais para os quatro espaços fundamentais:

$$\mathcal{C}(\mathbf{A}) = \mathcal{C}(\mathbf{U}_r), \quad \mathcal{N}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{U}_0),$$

$$\mathcal{C}(\mathbf{A}^\top) = \mathcal{C}(\mathbf{V}_r), \quad \mathcal{N}(\mathbf{A}) = \mathcal{C}(\mathbf{V}_0).$$

O posto é o número de valores singulares positivos:

$$\text{posto}(\mathbf{A}) = r.$$

A norma de Frobenius é

$$\|\mathbf{A}\|_F^2 = \sum_{j=1}^r d_j^2.$$

Quando

$$r = \min(q, p),$$

o número de condição espectral é

$$\kappa_2(\mathbf{A}) = \frac{d_1}{d_{\min(q,p)}}.$$

Se o posto é menor que o máximo possível, adota-se

$$\kappa_2(\mathbf{A}) = \infty.$$

Para matrizes largas com posto linha completo, esse número descreve a ação da transformação no complemento ortogonal de seu núcleo.

Quando $\mathbf{X}$ é uma matriz de dados,

$$\mathbf{X} = \mathbf{U}_r \mathbf{D}_r \mathbf{V}_r^\top,$$

as coordenadas das observações nas direções singulares à direita são

$$\mathbf{Z} = \mathbf{X} \mathbf{V}_r = \mathbf{U}_r \mathbf{D}_r.$$

Se $\mathbf{X}_c$ está centralizada,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \mathbf{V}_r \frac{\mathbf{D}_r^2}{n-1} \mathbf{V}_r^\top.$$

Portanto, os vetores singulares à direita são autovetores da matriz de covariâncias amostral, e seus autovalores positivos são $d_j^2/(n-1)$.

A forma expandida,

$$\mathbf{A} = \sum_{j=1}^r d_j \mathbf{u}_j \mathbf{v}_j^\top,$$

decompõe a matriz em parcelas ortogonais de posto 1. Pelo Teorema de Eckart–Young–Mirsky, a SVD truncada fornece uma aproximação ótima:

$$\|\mathbf{A} - \mathbf{A}_k\|_2 = d_{k+1}$$

e

$$\|\mathbf{A} - \mathbf{A}_k\|_F^2 = \sum_{j=k+1}^r d_j^2.$$

A pseudoinversa é

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^\top.$$

Ela determina os projetores

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r\mathbf{U}_r^\top$$

e

$$\mathbf{A}^+\mathbf{A} = \mathbf{V}_r\mathbf{V}_r^\top,$$

e fornece a solução de mínimos quadrados de menor norma:

$$\hat{\mathbf{x}}^* = \mathbf{A}^+\mathbf{b}.$$

A Tabela 6.5 reúne as relações principais.

Tabela 6.5: Síntese das principais relações da Decomposição em Valores Singulares.

Objeto	Expressão	Interpretação
SVD completa	$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$	Bases ortonormais completas
SVD compacta	$\mathbf{A} = \mathbf{U}_r\mathbf{D}_r\mathbf{V}_r^\top$	Representação exata com valores positivos
Pares singulares	$\mathbf{A}\mathbf{v}_j = d_j\mathbf{u}_j$	Associação entre domínio e contradomínio
Matrizes de Gram	$\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$	Determinam d_j^2 e os vetores singulares
Posto	$r = \#\{j : d_j > 0\}$	Dimensão efetiva da transformação
Normas	$\ \mathbf{A}\ _2 = d_1$ e $\ \mathbf{A}\ _F^2 = \sum_j d_j^2$	Ampliação máxima e magnitude quadrática
Forma expandida	$\mathbf{A} = \sum_j d_j\mathbf{u}_j\mathbf{v}_j^\top$	Soma de parcelas de posto 1
SVD truncada	$\mathbf{A}_k = \mathbf{U}_k\mathbf{D}_k\mathbf{V}_k^\top$	Aproximação de posto reduzido
Pseudoinversa	$\mathbf{A}^+ = \mathbf{V}_r\mathbf{D}_r^{-1}\mathbf{U}_r^\top$	Inversão nas direções ativas
Mínimos quadrados	$\hat{\mathbf{x}}^* = \mathbf{A}^+\mathbf{b}$	Solução de menor norma

Ao concluir o capítulo, o estudante deverá ser capaz de:

1. distinguir as formas completa, compacta e truncada da SVD;
2. obter valores e vetores singulares a partir das matrizes de Gram;
3. interpretar geometricamente os valores singulares;
4. identificar os quatro espaços fundamentais;

5. relacionar valores singulares a posto, normas e condicionamento;
6. construir aproximações de posto reduzido;
7. utilizar a pseudoinversa em sistemas lineares e mínimos quadrados.

O próximo capítulo desenvolve cálculo diferencial, integral e matricial aplicado à Estatística Multivariada. As normas, formas quadráticas, projeções e problemas de mínimos quadrados estudados até aqui serão retomados na formulação de gradientes, Hessianas, funções objetivo, condições de otimalidade e procedimentos de estimação.

7 Cálculo Diferencial, Integral e Matricial Aplicado à Estatística Multivariada

Os capítulos anteriores desenvolveram a representação vetorial dos dados, a álgebra matricial, os espaços vetoriais, as transformações lineares e as principais decomposições matriciais. Este capítulo estuda funções cujos argumentos e resultados podem ser escalares, vetores ou matrizes.

O cálculo diferencial descreve como essas funções variam localmente. Gradientes, Jacobianas e Hessianas permitem construir aproximações, identificar direções de variação e formular condições de otimização. O cálculo matricial permite diferenciar expressões que envolvem traços, produtos, inversas e determinantes.

O cálculo integral será utilizado para representar probabilidades, esperanças, distribuições marginais e transformações de vetores aleatórios. Nessas transformações, o determinante Jacobiano descreve a alteração local de volume.

O objetivo é reunir as ferramentas de cálculo utilizadas nos capítulos probabilísticos e inferenciais, sem desenvolver antecipadamente os modelos e procedimentos específicos desses capítulos.

7.1 Funções, variações e diferenciais

7.1.1 Tipos de funções

Uma função real de uma variável real possui a forma

$$f : \mathbb{R} \longrightarrow \mathbb{R}.$$

Em problemas multivariados, o domínio ou o contradomínio pode ter dimensão maior que um. A natureza desses espaços determina a forma da derivada.

Uma função escalar de um vetor é representada por

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix},$$

escreve-se

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

São exemplos:

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

e

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{A} \mathbf{x}\|^2.$$

Essas funções associam um escalar a cada vetor do domínio.

Uma função vetorial de um vetor possui a forma

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q.$$

Ela pode ser escrita como

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

em que cada componente

$$g_i : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função escalar.

Uma transformação linear é um caso particular:

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \mathbf{A} \in \mathbb{R}^{q \times p}.$$

Também são utilizadas funções escalares de matrizes:

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

São exemplos:

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$$

e

$$\phi(\mathbf{X}) = \|\mathbf{X}\|_F^2.$$

Uma função matricial de uma matriz possui a forma

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

São exemplos:

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^\top \mathbf{X},$$

$$\mathcal{G}(\mathbf{X}) = \mathbf{A}\mathbf{X}\mathbf{B}$$

e, para matrizes quadradas invertíveis,

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{-1}.$$

A Tabela 7.1 resume os tipos de funções utilizados no capítulo.

Tabela 7.1: Tipos de funções e objetos diferenciais correspondentes.

Função	Domínio	Contradomínio	Objeto diferencial
$f(x)$	$\mathbb{R}$	$\mathbb{R}$	Derivada escalar
$f(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}$	Gradiente
$\mathbf{g}(\mathbf{x})$	$\mathbb{R}^p$	$\mathbb{R}^q$	Jacobiana
$\phi(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}$	Gradiente matricial
$\mathcal{G}(\mathbf{X})$	$\mathbb{R}^{m \times n}$	$\mathbb{R}^{r \times s}$	Operador diferencial

Função	Domínio	Contradomínio	Objeto diferencial
--------	---------	---------------	--------------------

As dimensões do domínio e do contradomínio devem ser identificadas antes da diferenciação. Elas determinam a dimensão do gradiente, da Jacobiana ou do operador diferencial.

7.1.2 Convenções de derivação

Neste capítulo, o gradiente de uma função escalar de um vetor será um vetor-coluna:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix} \in \mathbb{R}^p.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a Jacobiana será definida por

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \dots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$

A Hessiana de uma função escalar será representada por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \in \mathbb{R}^{p \times p}.$$

Para uma função escalar de uma matriz,

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

o gradiente matricial terá a mesma dimensão do argumento:

$$\nabla_{\mathbf{X}} \phi(\mathbf{X}) \in \mathbb{R}^{m \times n}.$$

Ele será identificado pela relação

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{x}} \phi)^\top d\mathbf{X} \right].$$

Essa convenção utiliza o produto interno de Frobenius entre o gradiente e a perturbação da matriz.

7.1.3 Variação de uma função

Considere uma função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R},$$

um ponto interior

$$\mathbf{x} \in \mathcal{U}$$

e uma perturbação

$$\mathbf{h} \in \mathbb{R}^p$$

tal que $\mathbf{x} + \mathbf{h} \in \mathcal{U}$.

A variação exata da função é

$$\Delta f = f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}).$$

Essa diferença mede a alteração total no valor da função. Para perturbações pequenas, procura-se representar sua parcela dominante por uma função linear de $\mathbf{h}$.

Definição 7.1 (Diferenciabilidade de uma função escalar). A função

$$f : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}$$

é diferenciável em $\mathbf{x}$ quando existe uma transformação linear

$$L_{\mathbf{x}} : \mathbb{R}^p \longrightarrow \mathbb{R}$$

tal que

$$f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = L_{\mathbf{x}}(\mathbf{h}) + r_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{r_{\mathbf{x}}(\mathbf{h})}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

A função linear $L_{\mathbf{x}}$ fornece a aproximação de primeira ordem da variação. No espaço euclidiano, existe um único vetor

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \in \mathbb{R}^p$$

tal que

$$L_{\mathbf{x}}(\mathbf{h}) = \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

Portanto,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + r_{\mathbf{x}}(\mathbf{h}),$$

em que o termo residual é pequeno em relação a $\|\mathbf{h}\|$.

Utilizando a notação de ordem,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A aproximação linear é

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h}.$$

7.1.4 Diferencial

O diferencial de f em $\mathbf{x}$ é a parte linear de sua variação:

$$df = \nabla_{\mathbf{x}} f(\mathbf{x})^\top d\mathbf{x}.$$

Em coordenadas,

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

O vetor

$$d\mathbf{x} = \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}$$

representa uma perturbação infinitesimal do argumento. O diferencial é linear em relação a essa perturbação.

Exemplo 7.1 (Diferencial de uma função linear). Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante.

A variação é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= \mathbf{a}^\top (\mathbf{x} + \mathbf{h}) - \mathbf{a}^\top \mathbf{x} \\ &= \mathbf{a}^\top \mathbf{h}. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{a}$$

e

$$df = \mathbf{a}^\top d\mathbf{x}.$$

Como a função é linear, a aproximação de primeira ordem coincide com a variação exata.

Exemplo 7.2 (Diferencial do quadrado da norma). Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2.$$

A variação exata é

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) &= (\mathbf{x} + \mathbf{h})^\top (\mathbf{x} + \mathbf{h}) - \mathbf{x}^\top \mathbf{x} \\ &= 2\mathbf{x}^\top \mathbf{h} + \mathbf{h}^\top \mathbf{h}. \end{aligned}$$

O termo

$$2\mathbf{x}^\top \mathbf{h}$$

é linear em $\mathbf{h}$, enquanto

$$\mathbf{h}^\top \mathbf{h} = \|\mathbf{h}\|^2$$

é de segunda ordem.

Portanto,

$$df = 2\mathbf{x}^\top d\mathbf{x}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{x}.$$

7.1.5 Aproximação ao longo de uma direção

Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2,$$

o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}$$

e o vetor unitário

$$\mathbf{h} = \begin{bmatrix} -4/5 \\ 3/5 \end{bmatrix}.$$

A restrição da função à reta que passa por $\mathbf{x}_0$ na direção $\mathbf{h}$ é

$$\varphi(t) = f(\mathbf{x}_0 + t\mathbf{h}).$$

Em torno de $t = 0$,

$$\varphi(t) \approx \varphi(0) + \varphi'(0)t.$$

A Figura 7.1 compara a função exata ao longo dessa reta com sua aproximação linear.




Figura 7.1: Função exata ao longo de uma direção e aproximação linear no ponto $t = 0$.

No ponto $t = 0$, a função e sua aproximação linear possuem o mesmo valor e a mesma inclinação. À medida que $|t|$ aumenta, os termos de segunda ordem passam a contribuir mais para a variação.

7.1.6 Diferenciabilidade de funções vetoriais

Para uma função

$$\mathbf{g} : \mathcal{U} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

a aproximação de primeira ordem é uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^q$.

Definição 7.2 (Diferenciabilidade de uma função vetorial). A função $\mathbf{g}$ é diferenciável em $\mathbf{x}$ quando existe uma matriz

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) \in \mathbb{R}^{q \times p}$$

tal que

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) - \mathbf{g}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + \mathbf{r}_{\mathbf{x}}(\mathbf{h}),$$

com

$$\frac{\|\mathbf{r}_{\mathbf{x}}(\mathbf{h})\|}{\|\mathbf{h}\|} \longrightarrow 0 \quad \text{quando} \quad \|\mathbf{h}\| \longrightarrow 0.$$

Assim,

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) \approx \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h},$$

e o diferencial é

$$d\mathbf{g} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

Para a transformação linear

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}$$

em todos os pontos. Portanto,

$$d\mathbf{g} = \mathbf{A} d\mathbf{x},$$

e a aproximação linear é exata.

Gradiente e Jacobiana representam a mesma ideia em contradomínios diferentes. O gradiente representa a parte linear da variação de uma função escalar. A Jacobiana representa a parte linear da variação de uma função vetorial.

7.2 Gradiente, derivada direcional, Jacobiana e Hessiana

7.2.1 Gradiente e derivada direcional

Para uma função diferenciável

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

o gradiente reúne as derivadas parciais:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{bmatrix}.$$

A derivada parcial em relação a x_j mede a variação da função na direção do vetor canônico $\mathbf{e}_j$. A variação em uma direção arbitrária é descrita pela derivada direcional.

Definição 7.3 (Derivada direcional). Seja

$$\mathbf{u} \in \mathbb{R}^p.$$

A derivada direcional de f no ponto $\mathbf{x}$ na direção de $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t},$$

quando esse limite existe.

Considere a função de uma variável

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

Pela regra da cadeia,

$$\begin{aligned}\varphi'(0) &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \frac{d}{dt}(\mathbf{x} + t\mathbf{u}) \Big|_{t=0} \\ &= \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.\end{aligned}$$

Portanto, se f é diferenciável,

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla_{\mathbf{x}}f(\mathbf{x})^\top \mathbf{u}.$$

Quando $\mathbf{u}$ é unitário, a derivada direcional mede a taxa de variação por unidade de deslocamento.

Se θ é o ângulo entre $\nabla_{\mathbf{x}}f(\mathbf{x})$ e $\mathbf{u}$, então

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\| \cos \theta.$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \cos \theta.$$

Teorema 7.1 (Direções de maior crescimento e redução). *Se*

$$\nabla_{\mathbf{x}}f(\mathbf{x}) \neq \mathbf{0},$$

então, entre todas as direções unitárias,

$$\max_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = \|\nabla_{\mathbf{x}}f(\mathbf{x})\|,$$

e o máximo é atingido na direção

$$\mathbf{u}_{\max} = \frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|}.$$

A maior redução ocorre na direção oposta:

$$\mathbf{u}_{\min} = -\frac{\nabla_{\mathbf{x}}f(\mathbf{x})}{\|\nabla_{\mathbf{x}}f(\mathbf{x})\|},$$

com

$$\min_{\|\mathbf{u}\|=1} D_{\mathbf{u}}f(\mathbf{x}) = -\|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

(Apostol, 1969)

Comprovação. Pela desigualdade de Cauchy–Schwarz,

$$\begin{aligned} D_{\mathbf{u}}f(\mathbf{x}) &= \nabla_{\mathbf{x}}f(\mathbf{x})^{\top} \mathbf{u} \\ &\leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\| \|\mathbf{u}\|. \end{aligned}$$

Para $\|\mathbf{u}\| = 1$,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla_{\mathbf{x}}f(\mathbf{x})\|.$$

A igualdade ocorre quando $\mathbf{u}$ possui a mesma direção e o mesmo sentido do gradiente. A aplicação do mesmo argumento a $-\mathbf{u}$ fornece o resultado para a maior redução. $\square$

Se

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \mathbf{0},$$

todas as derivadas direcionais de primeira ordem são nulas. Nesse caso, a aproximação linear não indica crescimento ou redução local.

7.2.2 Gradiente e conjuntos de nível

Um conjunto de nível de f é definido por

$$\mathcal{S}_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\},$$

em que c é constante.

Considere uma curva diferenciável

$$\gamma(t)$$

contida em $\mathcal{S}_c$. Então,

$$f(\gamma(t)) = c.$$

Derivando,

$$\nabla_{\mathbf{x}} f(\gamma(t))^{\top} \gamma'(t) = 0.$$

O vetor $\gamma'(t)$ é tangente ao conjunto de nível. Portanto, o gradiente é ortogonal a todas as direções tangentes.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}) \neq \mathbf{0},$$

o gradiente é um vetor normal ao conjunto de nível no ponto $\mathbf{x}$.

Exemplo 7.3 (Gradiente de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix},$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

e

$$\|\nabla_{\mathbf{x}} f(\mathbf{x}_0)\| = 2\sqrt{2}.$$

A direção de maior crescimento é

$$\mathbf{u}_{\max} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Uma direção tangente à curva de nível é

$$\mathbf{u}_{\tan} = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{u}_{\tan} = 0,$$

a derivada direcional nessa direção é nula.

A Figura 7.2 representa as curvas de nível da função, o gradiente e uma direção tangente no ponto $\mathbf{x}_0$.

A direção do gradiente depende do ponto. Para a função considerada, as curvas de nível são elipses e o gradiente aponta para fora, perpendicularmente à curva correspondente.

7.2.3 Jacobiana

A derivada de uma função vetorial é representada por sua matriz Jacobiana.

Definição 7.4 (Matriz Jacobiana). Seja

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix}.$$

A matriz Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_q}{\partial x_1} & \cdots & \frac{\partial g_q}{\partial x_p} \end{bmatrix} \in \mathbb{R}^{q \times p}.$$




Figura 7.2: O gradiente é perpendicular à curva de nível e aponta na direção de maior crescimento local.

Cada linha da Jacobiana é o gradiente transposto de uma componente:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \begin{bmatrix} \nabla_{\mathbf{x}} g_1(\mathbf{x})^\top \\ \vdots \\ \nabla_{\mathbf{x}} g_q(\mathbf{x})^\top \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana transforma uma pequena variação no domínio em uma aproximação da variação correspondente no contradomínio.

Exemplo 7.4 (Jacobiana de uma função de $\mathbb{R}^2$ em $\mathbb{R}^2$). Considere

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1^2 + x_2 \\ x_1 x_2 \end{bmatrix}.$$

Os gradientes das componentes são

$$\nabla_{\mathbf{x}} g_1 = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix}$$

e

$$\nabla_{\mathbf{x}} g_2 = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}.$$

Logo,

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{bmatrix}.$$

No ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

tem-se

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}_0) = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

Para uma pequena perturbação

$$\mathbf{h} = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix},$$

a alteração é aproximada por

$$\mathbf{g}(\mathbf{x}_0 + \mathbf{h}) - \mathbf{g}(\mathbf{x}_0) \approx \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

Para uma transformação afim

$$\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b},$$

a Jacobiana é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

O vetor $\mathbf{b}$ altera a posição da imagem, mas não altera a transformação linear local.

7.2.4 Regra da cadeia

A composição de funções exige a composição de suas aproximações lineares.

Teorema 7.2 (Regra da cadeia para funções vetoriais). *Considere funções diferenciáveis*

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e

$$\mathbf{h} : \mathbb{R}^q \longrightarrow \mathbb{R}^r.$$

Para

$$\mathbf{f} = \mathbf{h} \circ \mathbf{g},$$

a Jacobiana é

$$\mathbf{J}_f(\mathbf{x}) = \mathbf{J}_h(\mathbf{g}(\mathbf{x})) \mathbf{J}_g(\mathbf{x}).$$

(Apostol, 1969)

As dimensões do produto são

$$(r \times q)(q \times p) = r \times p.$$

A ordem das matrizes acompanha a ordem inversa da aplicação das aproximações lineares: primeiro atua a Jacobiana de $\mathbf{g}$ e, depois, a Jacobiana de $\mathbf{h}$.

No caso de uma composição escalar

$$f(\mathbf{x}) = h(\mathbf{g}(\mathbf{x})),$$

em que

$$h: \mathbb{R}^q \longrightarrow \mathbb{R},$$

a regra da cadeia assume a forma

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{J}_g(\mathbf{x})^\top \nabla_{\mathbf{y}} h(\mathbf{y}) \Big|_{\mathbf{y}=\mathbf{g}(\mathbf{x})}.$$

Exemplo 7.5 (Gradiente de uma função composta). Considere

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$$

e

$$h(\mathbf{y}) = \mathbf{y}^\top \mathbf{y}.$$

A função composta é

$$f(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2.$$

Como

$$\mathbf{J}_g(\mathbf{x}) = \mathbf{A}$$

e

$$\nabla_{\mathbf{y}} h(\mathbf{y}) = 2\mathbf{y},$$

segue que

$$\begin{aligned}\nabla_{\mathbf{x}} f(\mathbf{x}) &= \mathbf{A}^\top [2(\mathbf{Ax} - \mathbf{b})] \\ &= 2\mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}).\end{aligned}$$

Essa expressão será retomada no estudo das funções de mínimos quadrados.

7.2.5 Hessiana

A Hessiana descreve a variação local do gradiente.

Definição 7.5 (Matriz Hessiana). Seja

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

uma função duas vezes diferenciável. Sua matriz Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{bmatrix} \in \mathbb{R}^{p \times p}.$$

A Hessiana é a Jacobiana do gradiente:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{J}_{\nabla f}(\mathbf{x}).$$

Se as derivadas parciais de segunda ordem são contínuas em uma vizinhança do ponto, então

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i},$$

e a Hessiana é simétrica:

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \nabla_{\mathbf{x}}^2 f(\mathbf{x})^\top.$$

O segundo diferencial é

$$d^2 f = d\mathbf{x}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) d\mathbf{x}.$$

Para uma direção $\mathbf{u}$, considere novamente

$$\varphi(t) = f(\mathbf{x} + t\mathbf{u}).$$

A primeira derivada é

$$\varphi'(0) = \nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{u}.$$

A segunda derivada é

$$\varphi''(0) = \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}) \mathbf{u}.$$

Essa forma quadrática representa a curvatura da função na direção $\mathbf{u}$.

Exemplo 7.6 (Hessiana de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$

O gradiente é

$$\nabla_{\mathbf{x}} f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}.$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(x_1, x_2) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Para

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix},$$

a curvatura direcional é

$$\begin{aligned} \mathbf{u}^\top \nabla_{\mathbf{x}}^2 f \mathbf{u} &= \begin{bmatrix} u_1 & u_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\ &= 2u_1^2 + 4u_2^2. \end{aligned}$$

Ela é positiva para todo vetor não nulo. A curvatura é maior em direções com componente mais acentuada no segundo eixo.

Para a função quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A curvatura da função é determinada pela matriz $\mathbf{A}$. A relação entre a Hessiana, a aproximação de segunda ordem, a convexidade e a classificação de pontos estacionários será desenvolvida na próxima seção.

7.3 Aproximações de Taylor e classificação local

7.3.1 Aproximação de Taylor de primeira ordem

A diferenciabilidade fornece uma aproximação linear da função em uma vizinhança de um ponto.

Para

$$f : \mathbb{R}^p \longrightarrow \mathbb{R},$$

diferenciável em $\mathbf{x}_0$,

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} + o(\|\mathbf{h}\|).$$

Tomando

$$\mathbf{h} = \mathbf{x} - \mathbf{x}_0,$$

obtém-se

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0).$$

Essa é a aproximação de Taylor de primeira ordem.

Para funções de uma variável, ela corresponde à reta tangente. Para funções de duas variáveis, corresponde ao plano tangente. Em dimensão geral, corresponde a uma função afim que aproxima localmente f .

Exemplo 7.7 (Aproximação linear de uma função quadrática). Considere

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

e o ponto

$$\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

Tem-se

$$f(\mathbf{x}_0) = 1^2 + 2 \left(\frac{1}{2}\right)^2 = \frac{3}{2}$$

e

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

A aproximação de primeira ordem é

$$\begin{aligned} f(\mathbf{x}) &\approx \frac{3}{2} + [2 \quad 2] \left[\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1/2 \end{bmatrix} \right] \\ &= \frac{3}{2} + 2(x_1 - 1) + 2\left(x_2 - \frac{1}{2}\right). \end{aligned}$$

A aproximação linear descreve a variação determinada pelo gradiente. Ela não representa a curvatura da função.

7.3.2 Aproximação de Taylor de segunda ordem

Quando f é duas vezes diferenciável, a Hessiana permite incorporar a curvatura local.

Teorema 7.3 (Expansão de Taylor de segunda ordem). *Se*

$$f : \mathbb{R}^p \longrightarrow \mathbb{R}$$

possui derivadas de segunda ordem contínuas em uma vizinhança de $\mathbf{x}_0$, então

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) \mathbf{h} + o(\|\mathbf{h}\|^2). \end{aligned}$$

(Apostol, 1969)

Em termos de $\mathbf{x} - \mathbf{x}_0$,

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}_0) + \nabla_{\mathbf{x}} f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0). \end{aligned}$$

Os três termos possuem funções distintas:

- $f(\mathbf{x}_0)$ determina o nível da aproximação;
- o gradiente determina a inclinação local;
- a Hessiana determina a curvatura local.

Quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}_0) = \mathbf{0},$$

o termo linear desaparece e a forma quadrática associada à Hessiana passa a determinar o comportamento local dominante.

Exemplo 7.8 (Expansão de uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

Como a função é quadrática, a expansão de Taylor de segunda ordem é exata:

$$\begin{aligned} f(\mathbf{x}_0 + \mathbf{h}) &= f(\mathbf{x}_0) + (\mathbf{A} \mathbf{x}_0 - \mathbf{b})^\top \mathbf{h} \\ &\quad + \frac{1}{2} \mathbf{h}^\top \mathbf{A} \mathbf{h}. \end{aligned}$$

Não existe termo residual de ordem superior.

7.3.3 Pontos estacionários

Definição 7.6 (Ponto estacionário). Um ponto

$$\mathbf{x}^*$$

é estacionário para uma função diferenciável f quando

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Em um ponto estacionário, todas as derivadas direcionais de primeira ordem são nulas:

$$D_{\mathbf{u}}f(\mathbf{x}^*) = 0$$

para toda direção $\mathbf{u}$.

Todo ponto interior em que uma função diferenciável possui máximo ou mínimo local é estacionário. A recíproca não é necessariamente verdadeira: um ponto estacionário pode ser mínimo, máximo ou ponto de sela.

7.3.4 Classificação pela Hessiana

Teorema 7.4 (Teste da Hessiana em um ponto estacionário). *Considere uma função duas vezes continuamente diferenciável e um ponto estacionário $\mathbf{x}^*$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0},$$

então $\mathbf{x}^$ é um mínimo local estrito.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \prec \mathbf{0},$$

então $\mathbf{x}^$ é um máximo local estrito. Se a Hessiana é indefinida, então $\mathbf{x}^*$ é um ponto de sela. Se a Hessiana é semidefinida positiva ou semidefinida negativa, o teste pode ser inconclusivo. (Apostol, 1969)*

Comprovação. Como

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0},$$

a expansão de Taylor fornece

$$f(\mathbf{x}^* + \mathbf{h}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{h}^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Se a Hessiana é positiva definida, a forma quadrática é positiva para todo $\mathbf{h} \neq \mathbf{0}$. Para perturbações suficientemente pequenas, o termo quadrático domina o restante, produzindo um mínimo local estrito.

O argumento é análogo para uma Hessiana negativa definida.

Se a Hessiana é indefinida, existem direções $\mathbf{u}_1$ e $\mathbf{u}_2$ tais que

$$\mathbf{u}_1^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{u}_1 > 0$$

e

$$\mathbf{u}_2^\top \nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \mathbf{u}_2 < 0.$$

A função aumenta em algumas direções e diminui em outras. Portanto, o ponto é de sela. $\square$

Exemplo 7.9 (Mínimo, máximo e ponto de sela). Considere as funções

$$f_1(x_1, x_2) = x_1^2 + x_2^2,$$

$$f_2(x_1, x_2) = -x_1^2 - x_2^2$$

e

$$f_3(x_1, x_2) = x_1^2 - x_2^2.$$

As três possuem ponto estacionário na origem.

Para f_1 ,

$$\nabla_{\mathbf{x}}^2 f_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \succ \mathbf{0}.$$

Logo, a origem é um mínimo estrito.

Para f_2 ,

$$\nabla_{\mathbf{x}}^2 f_2 = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \prec \mathbf{0}.$$

Logo, a origem é um máximo estrito.

Para f_3 ,

$$\nabla_{\mathbf{x}}^2 f_3 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

A Hessiana possui um autovalor positivo e outro negativo. Portanto, a origem é um ponto de sela.

A Figura 7.3 compara as curvas de nível dos três casos.




Figura 7.3: Curvas de nível associadas a um mínimo, um máximo e um ponto de sela.

7.3.5 Caso inconclusivo

Considere

$$f(x_1, x_2) = x_1^4 + x_2^4.$$

A origem é um ponto estacionário e

$$\nabla_{\mathbf{x}}^2 f(0,0) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

A Hessiana é semidefinida positiva, mas não positiva definida. Ainda assim,

$$f(x_1, x_2) \geq 0$$

para todos os pontos, com igualdade somente na origem. Portanto, a origem é um mínimo estrito.

Considere agora

$$g(x_1, x_2) = x_1^4 - x_2^4.$$

A Hessiana na origem também é nula. Entretanto, a função assume valores positivos e negativos em qualquer vizinhança da origem. O ponto é de sela.

Esses exemplos mostram que, quando o termo quadrático se anula em determinadas direções, é necessário examinar termos de ordem superior ou utilizar outro argumento.

7.4 Convexidade e concavidade

7.4.1 Conjuntos convexos

Definição 7.7 (Conjunto convexo). Um conjunto

$$\mathcal{C} \subseteq \mathbb{R}^p$$

é convexo quando, para quaisquer

$$\mathbf{x}, \mathbf{y} \in \mathcal{C}$$

e

$$t \in [0, 1],$$

tem-se

$$t\mathbf{x} + (1 - t)\mathbf{y} \in \mathcal{C}.$$

O vetor

$$t\mathbf{x} + (1 - t)\mathbf{y}$$

percorre o segmento de reta entre $\mathbf{x}$ e $\mathbf{y}$. Assim, um conjunto é convexo quando contém todos os segmentos que ligam seus pontos.

Subespaços, hiperplanos, bolas, regiões elipsoidais da forma

$$\{\mathbf{x} : (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu) \leq c\},$$

com $\mathbf{A} \succ \mathbf{0}$ e $c > 0$, e o cone das matrizes positivas definidas são exemplos de conjuntos convexos.

7.4.2 Funções convexas

Definição 7.8 (Função convexa). Uma função

$$f : \mathcal{C} \longrightarrow \mathbb{R},$$

definida em um conjunto convexo $\mathcal{C}$, é convexa quando

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ e $t \in [0, 1]$.

A função é estritamente convexa quando a desigualdade é estrita para $\mathbf{x} \neq \mathbf{y}$ e $t \in (0, 1)$.

Uma função é côncava quando $-f$ é convexa.

Geometricamente, o gráfico de uma função convexa permanece abaixo das cordas que ligam dois pontos de seu gráfico.

7.4.3 Caracterização de primeira ordem

Teorema 7.5 (Critério de primeira ordem para convexidade). *Se f é diferenciável em um conjunto convexo aberto $\mathcal{C}$, então f é convexa se, e somente se,*

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para quaisquer $\mathbf{x}, \mathbf{y} \in \mathcal{C}$. (Boyd; Vandenberghe, 2004)

A expressão

$$f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

é a aproximação afim determinada pelo plano tangente em $\mathbf{x}$. Para uma função convexa, essa aproximação é um limite inferior global.

7.4.4 Caracterização pela Hessiana

Teorema 7.6 (Critério da Hessiana para convexidade). *Considere uma função duas vezes continuamente diferenciável em um conjunto convexo aberto $\mathcal{C}$.*

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succeq \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é convexa.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \succ \mathbf{0}$$

para todo $\mathbf{x} \in \mathcal{C}$, então f é estritamente convexa.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \preceq \mathbf{0},$$

a função é côncava.

Se

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \prec \mathbf{0},$$

a função é estritamente côncava. (Boyd; Vandenberghe, 2004)

A positividade da Hessiana deve ser verificada para todos os pontos do domínio considerado, e não somente em um ponto estacionário.

7.4.5 Consequências para otimização

Teorema 7.7 (Pontos estacionários de funções convexas). *Se f é diferenciável e convexa em um conjunto convexo, qualquer ponto*

$$\mathbf{x}^*$$

que satisfaça

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}$$

é um mínimo global.

Se f é estritamente convexa, esse mínimo global é único. (Boyd; Vandenberghe, 2004)

Comprovação. Pela caracterização de primeira ordem,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla_{\mathbf{x}} f(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Como o gradiente é nulo,

$$f(\mathbf{x}) \geq f(\mathbf{x}^*)$$

para todo $\mathbf{x}$ do domínio.

Se a função é estritamente convexa, a igualdade só pode ocorrer em $\mathbf{x} = \mathbf{x}^*$. □

Essa propriedade diferencia a otimização convexa da otimização geral. Para uma função convexa, não existem mínimos locais que deixem de ser globais.

7.4.6 Funções quadráticas

Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + c,$$

com $\mathbf{A}$ simétrica.

Como

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A},$$

tem-se:

- f é convexa se $\mathbf{A} \succeq \mathbf{0}$;
- f é estritamente convexa se $\mathbf{A} \succ \mathbf{0}$;
- f é côncava se $\mathbf{A} \preceq \mathbf{0}$;
- f é estritamente côncava se $\mathbf{A} \prec \mathbf{0}$.

Se

$$\mathbf{A} \succ \mathbf{0},$$

o ponto estacionário satisfaz

$$\mathbf{A} \mathbf{x}^* = \mathbf{b},$$

e

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}.$$

Esse ponto é o único mínimo global.

Se

$$\mathbf{A} \succeq \mathbf{0}$$

é singular, a existência de minimizadores depende de $\mathbf{b}$.

Quando

$$\mathbf{b} \in \mathcal{C}(\mathbf{A}),$$

o sistema

$$\mathbf{Ax} = \mathbf{b}$$

possui solução. Nesse caso, os minimizadores formam o conjunto afim

$$\mathbf{x}_0 + \mathcal{N}(\mathbf{A}),$$

em que $\mathbf{x}_0$ é uma solução particular.

Quando

$$\mathbf{b} \notin \mathcal{C}(\mathbf{A}),$$

a função é ilimitada inferiormente e não possui minimizador.

7.5 Otimização sem restrições

Um problema de minimização sem restrições possui a forma

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x}).$$

Quando f é diferenciável, a condição de primeira ordem para um mínimo interior é

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) = \mathbf{0}.$$

Essa condição é necessária, mas não suficiente no caso geral.

Uma condição suficiente de segunda ordem é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^*) \succ \mathbf{0}.$$

Para funções convexas, a condição de gradiente nulo já é suficiente para um mínimo global (Boyd; Vandenberghe, 2004).

7.5.1 Método de Newton

O método de Newton utiliza a aproximação quadrática local de f .

Em torno de um ponto $\mathbf{x}^{(t)}$,

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})^{\top} (\mathbf{x} - \mathbf{x}^{(t)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t)})^{\top} \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}).$$

O gradiente dessa aproximação em relação a $\mathbf{x}$ é

$$\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}) + \nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}).$$

Igualando a zero,

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) (\mathbf{x} - \mathbf{x}^{(t)}) = -\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Se a Hessiana é invertível, obtém-se a atualização

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - [\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)})]^{-1} \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

A direção de Newton é a solução do sistema linear

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}^{(t)}) \mathbf{d}^{(t)} = -\nabla_{\mathbf{x}} f(\mathbf{x}^{(t)}).$$

Na implementação computacional, é preferível resolver esse sistema sem calcular explicitamente a inversa da Hessiana.

O método depende de:

- existência das derivadas de segunda ordem;
- Hessiana invertível;
- escolha adequada do ponto inicial;
- comportamento local da função.

Longe da solução, uma etapa de Newton pode não reduzir a função. Métodos numéricos costumam combinar a direção de Newton com controle do comprimento da etapa (Boyd; Vandenberghe, 2004).

Exemplo 7.10 (Newton para uma função quadrática). Considere

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

com $\mathbf{A} \succ \mathbf{0}$.

O gradiente é

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b},$$

e a Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A}.$$

A atualização de Newton é

$$\begin{aligned} \mathbf{x}^{(t+1)} &= \mathbf{x}^{(t)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(t)} - \mathbf{b}) \\ &= \mathbf{A}^{-1} \mathbf{b}. \end{aligned}$$

Assim, para uma função quadrática com Hessiana positiva definida, Newton encontra o minimizador em uma única etapa, independentemente do ponto inicial.

7.6 Otimização com restrições de igualdade

Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^p} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0},$$

em que

$$\mathbf{c} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$$

é uma função vetorial de restrições:

$$\mathbf{c}(\mathbf{x}) = \begin{bmatrix} c_1(\mathbf{x}) \\ \vdots \\ c_m(\mathbf{x}) \end{bmatrix}.$$

O conjunto viável é

$$\mathcal{F} = \{\mathbf{x} : \mathbf{c}(\mathbf{x}) = \mathbf{0}\}.$$

Em um ponto regular, os gradientes das restrições determinam as direções normais ao conjunto viável.

Uma direção tangente $\mathbf{d}$ satisfaz

$$\mathbf{J}_c(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

Em um ótimo restrito, a derivada direcional de f deve ser nula em todas as direções tangentes:

$$\nabla_{\mathbf{x}} f(\mathbf{x})^\top \mathbf{d} = 0$$

para todo $\mathbf{d}$ tal que

$$\mathbf{J}_c(\mathbf{x})\mathbf{d} = \mathbf{0}.$$

Isso implica que o gradiente da função objetivo pertence ao espaço gerado pelos gradientes das restrições.

7.6.1 Multiplicadores de Lagrange

Teorema 7.8 (Condição de Lagrange). *Considere um ponto $\mathbf{x}^*$ que é ótimo local do problema*

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a

$$\mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Suponha que as linhas da Jacobiana

$$\mathbf{J}_c(\mathbf{x}^*)$$

sejam linearmente independentes.

Então existe um vetor

$$\lambda^* \in \mathbb{R}^m$$

tal que

$$\nabla_{\mathbf{x}} f(\mathbf{x}^*) + \mathbf{J}_{\mathbf{c}}(\mathbf{x}^*)^\top \lambda^* = \mathbf{0}.$$

(Apostol, 1969)

A função lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda^\top \mathbf{c}(\mathbf{x}).$$

As condições de primeira ordem são

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{0}$$

e

$$\nabla_{\lambda} \mathcal{L}(\mathbf{x}, \lambda) = \mathbf{c}(\mathbf{x}) = \mathbf{0}.$$

Os multiplicadores ajustam a condição de gradiente nulo para levar em conta as direções que não estão disponíveis devido às restrições.

Exemplo 7.11 (Otimização com restrição de norma). Considere

$$\max_{\mathbf{x}} \mathbf{a}^\top \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1.$$

Escreva a restrição como

$$c(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} - 1 = 0.$$

A lagrangiana pode ser definida por

$$\mathcal{L}(\mathbf{x}, \lambda) = -\mathbf{a}^\top \mathbf{x} + \lambda (\mathbf{x}^\top \mathbf{x} - 1),$$

convertendo a maximização em minimização.

A condição em relação a $\mathbf{x}$ é

$$-\mathbf{a} + 2\lambda \mathbf{x} = \mathbf{0}.$$

Logo,

$$\mathbf{x} = \frac{1}{2\lambda} \mathbf{a}.$$

A restrição implica

$$\frac{\|\mathbf{a}\|^2}{4\lambda^2} = 1.$$

Para maximizar $\mathbf{a}^\top \mathbf{x}$, escolhe-se

$$\mathbf{x}^* = \frac{\mathbf{a}}{\|\mathbf{a}\|}.$$

O valor máximo é

$$\mathbf{a}^\top \mathbf{x}^* = \|\mathbf{a}\|.$$

Esse resultado coincide com a igualdade na desigualdade de Cauchy–Schwarz.

7.6.2 Relação com problemas de autovalores

Considere o problema

$$\max_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

sujeito a

$$\mathbf{x}^\top \mathbf{x} = 1,$$

com $\mathbf{A}$ simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \lambda (\mathbf{x}^\top \mathbf{x} - 1).$$

A condição de primeira ordem é

$$2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0},$$

ou

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

O problema de otimização conduz, portanto, a um problema de autovalores. O maior valor da função objetivo é o maior autovalor de $\mathbf{A}$.

Essa relação foi desenvolvida no capítulo de decomposição espectral. Aqui, ela mostra como os multiplicadores de Lagrange produzem a equação de autovalores a partir de uma restrição de norma.

7.6.3 Restrições lineares

Considere o problema quadrático

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

sujeito a

$$\mathbf{C} \mathbf{x} = \mathbf{d},$$

em que $\mathbf{A}$ é simétrica.

A lagrangiana é

$$\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + \lambda^\top (\mathbf{C} \mathbf{x} - \mathbf{d}).$$

As condições de primeira ordem são

$$\mathbf{A} \mathbf{x} - \mathbf{b} + \mathbf{C}^\top \lambda = \mathbf{0}$$

e

$$\mathbf{C} \mathbf{x} = \mathbf{d}.$$

Essas condições podem ser organizadas no sistema em blocos

$$\begin{bmatrix} \mathbf{A} & \mathbf{C}^\top \\ \mathbf{C} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}.$$

A solução exige condições de posto e invertibilidade compatíveis com a matriz do sistema.

As ferramentas desta seção serão aplicadas a funções de resíduos, critérios quadráticos e funções de parâmetros matriciais.

7.7 Derivadas de formas lineares, quadráticas e funções de resíduos

7.7.1 Formas lineares e bilineares

Considere

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante. Como

$$df = \mathbf{a}^\top d\mathbf{x},$$

tem-se

$$\nabla_{\mathbf{x}} f = \mathbf{a}$$

e

$$\nabla_{\mathbf{x}}^2 f = \mathbf{0}.$$

Para a forma bilinear

$$f(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{A} \mathbf{y},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times q},$$

o diferencial é

$$df = d\mathbf{x}^\top \mathbf{A} \mathbf{y} + \mathbf{x}^\top \mathbf{A} d\mathbf{y}.$$

Reescrevendo o primeiro termo,

$$d\mathbf{x}^\top \mathbf{A} \mathbf{y} = (\mathbf{A} \mathbf{y})^\top d\mathbf{x},$$

e o segundo,

$$\mathbf{x}^\top \mathbf{A} d\mathbf{y} = (\mathbf{A}^\top \mathbf{x})^\top d\mathbf{y}.$$

Logo,

$$\nabla_{\mathbf{x}} f = \mathbf{A} \mathbf{y}$$

e

$$\nabla_{\mathbf{y}} f = \mathbf{A}^\top \mathbf{x}.$$

7.7.2 Formas quadráticas

Considere

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

O diferencial é

$$\begin{aligned} df &= d\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= \mathbf{x}^\top \mathbf{A}^\top d\mathbf{x} + \mathbf{x}^\top \mathbf{A} d\mathbf{x} \\ &= [(\mathbf{A} + \mathbf{A}^\top) \mathbf{x}]^\top d\mathbf{x}. \end{aligned}$$

Portanto,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = \mathbf{A} + \mathbf{A}^\top.$$

A forma quadrática depende somente da parte simétrica da matriz:

$$\mathbf{A}_s = \frac{\mathbf{A} + \mathbf{A}^\top}{2}.$$

Assim,

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{A}_s \mathbf{x},$$

e

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}_s \mathbf{x}.$$

Quando $\mathbf{A}$ é simétrica,

$$\nabla_{\mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A}.$$

Teorema 7.9 (Derivadas de uma forma quadrática deslocada). *Se $\mathbf{A}$ é simétrica e*

$$f(\mathbf{x}) = (\mathbf{x} - \mu)^\top \mathbf{A} (\mathbf{x} - \mu),$$

então

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A} (\mathbf{x} - \mu)$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}.$$

Comprovação. Defina

$$\mathbf{z} = \mathbf{x} - \mu.$$

Como

$$d\mathbf{z} = d\mathbf{x},$$

tem-se

$$\begin{aligned} df &= d\mathbf{z}^\top \mathbf{A} \mathbf{z} + \mathbf{z}^\top \mathbf{A} d\mathbf{z} \\ &= 2\mathbf{z}^\top \mathbf{A} d\mathbf{x}, \end{aligned}$$

pois $\mathbf{A}$ é simétrica. Portanto,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{z} = 2\mathbf{A} (\mathbf{x} - \mu).$$

A diferenciação do gradiente fornece a Hessiana. □

Se

$$\mathbf{A} \succeq \mathbf{0},$$

a forma quadrática deslocada é convexa. Se

$$\mathbf{A} \succ \mathbf{0},$$

ela é estritamente convexa e possui mínimo único em

$$\mathbf{x} = \mu.$$

7.7.3 Norma euclidiana

Como

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x},$$

segue que

$$\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = 2\mathbf{x}$$

e

$$\nabla_{\mathbf{x}}^2 \|\mathbf{x}\|^2 = 2\mathbf{I}_p.$$

Para $\mathbf{x} \neq \mathbf{0}$,

$$\|\mathbf{x}\| = (\mathbf{x}^\top \mathbf{x})^{1/2}.$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} \|\mathbf{x}\| = \frac{\mathbf{x}}{\|\mathbf{x}\|}.$$

A norma euclidiana não é diferenciável em $\mathbf{x} = \mathbf{0}$.

7.7.4 Funções de resíduos lineares

Considere

$$\mathbf{A} \in \mathbb{R}^{q \times p}, \quad \mathbf{b} \in \mathbb{R}^q,$$

e defina o vetor de resíduos

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) = -\mathbf{A}.$$

A soma de quadrados dos resíduos é

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2 = (\mathbf{b} - \mathbf{A}\mathbf{x})^\top (\mathbf{b} - \mathbf{A}\mathbf{x}).$$

Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^\top \mathbf{r}(\mathbf{x}) \\ &= -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}). \end{aligned}$$

Equivalentemente,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}).$$

A Hessiana é

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{A}^\top \mathbf{A}.$$

Como

$$\mathbf{A}^\top \mathbf{A} \succeq \mathbf{0},$$

a função é convexa.

Se $\mathbf{A}$ possui posto coluna completo,

$$\mathbf{A}^\top \mathbf{A} \succ \mathbf{0},$$

e a função é estritamente convexa.

7.7.5 Equações normais

Uma solução de mínimos quadrados deve satisfazer

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \mathbf{0}.$$

Logo,

$$\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}) = \mathbf{0},$$

ou

$$\mathbf{A}^\top \mathbf{A}\mathbf{x} = \mathbf{A}^\top \mathbf{b}.$$

Essas são as equações normais.

A condição também pode ser escrita como

$$\mathbf{A}^\top \mathbf{r}(\mathbf{x}) = \mathbf{0}.$$

Portanto, no ponto de mínimo, o vetor residual é ortogonal ao espaço coluna de $\mathbf{A}$.

Quando $\mathbf{A}$ possui posto coluna completo, a solução é única:

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}.$$

Quando $\mathbf{A}$ é deficiente em posto, as equações normais podem possuir várias soluções. A pseudoinversa fornece a solução de menor norma:

$$\hat{\mathbf{x}}^* = \mathbf{A}^+ \mathbf{b}.$$

A geometria das soluções de mínimos quadrados e a construção pela SVD foram desenvolvidas no capítulo anterior.

Exemplo 7.12 (Média como solução de mínimos quadrados). Considere valores

$$z_1, \dots, z_n$$

e a função

$$f(m) = \sum_{i=1}^n (z_i - m)^2.$$

A derivada é

$$\begin{aligned} f'(m) &= -2 \sum_{i=1}^n (z_i - m) \\ &= 2nm - 2 \sum_{i=1}^n z_i. \end{aligned}$$

A condição

$$f'(m) = 0$$

fornece

$$m = \frac{1}{n} \sum_{i=1}^n z_i.$$

Como

$$f''(m) = 2n > 0,$$

a média aritmética é o único minimizador da soma dos quadrados dos desvios.

7.7.6 Mínimos quadrados ponderados

Considere pesos

$$\omega_1, \dots, \omega_q$$

e a matriz diagonal

$$\Omega = \text{diag}(\omega_1, \dots, \omega_q).$$

A função de mínimos quadrados ponderados é

$$f_\omega(\mathbf{x}) = (\mathbf{b} - \mathbf{Ax})^\top \Omega (\mathbf{b} - \mathbf{Ax}).$$

Quando Ω é simétrica,

$$\nabla_{\mathbf{x}} f_\omega(\mathbf{x}) = -2\mathbf{A}^\top \Omega (\mathbf{b} - \mathbf{Ax})$$

e

$$\nabla_{\mathbf{x}}^2 f_\omega(\mathbf{x}) = 2\mathbf{A}^\top \Omega \mathbf{A}.$$

Se

$$\Omega \succeq \mathbf{0},$$

a função é convexa.

As equações normais ponderadas são

$$\mathbf{A}^\top \Omega \mathbf{Ax} = \mathbf{A}^\top \Omega \mathbf{b}.$$

Se

$$\Omega \succ \mathbf{0}$$

e $\mathbf{A}$ possui posto coluna completo, então

$$\mathbf{A}^\top \Omega \mathbf{A} \succ \mathbf{0},$$

e o minimizador é único:

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \Omega \mathbf{A})^{-1} \mathbf{A}^\top \Omega \mathbf{b}.$$

A matriz Ω modifica a importância relativa dos resíduos. Para uma matriz diagonal, cada observação recebe um peso próprio.

7.7.7 Funções compostas de resíduos

Considere uma função diferenciável

$$\rho : \mathbb{R} \longrightarrow \mathbb{R}$$

e resíduos escalares

$$r_i(\mathbf{x}), \quad i = 1, \dots, q.$$

Uma função de ajuste pode ser escrita como

$$f(\mathbf{x}) = \sum_{i=1}^q \rho(r_i(\mathbf{x})).$$

Pela regra da cadeia,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^q \rho'(r_i(\mathbf{x})) \nabla_{\mathbf{x}} r_i(\mathbf{x}).$$

Se

$$\rho(t) = t^2,$$

então

$$\rho'(t) = 2t,$$

e recupera-se a soma de quadrados.

Essa formulação mostra que diferentes funções de perda modificam a contribuição de cada resíduo no gradiente.

7.7.8 Mínimos quadrados não lineares

Considere uma função residual diferenciável

$$\mathbf{r} : \mathbb{R}^p \longrightarrow \mathbb{R}^q$$

e o critério

$$f(\mathbf{x}) = \|\mathbf{r}(\mathbf{x})\|^2.$$

A Jacobiana dos resíduos é

$$\mathbf{J}_{\mathbf{r}}(\mathbf{x}) \in \mathbb{R}^{q \times p}.$$

Teorema 7.10 (Derivadas de uma soma de quadrados não linear). *Para*

$$f(\mathbf{x}) = \sum_{i=1}^q r_i(\mathbf{x})^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x})$$

e

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) = 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{J}_{\mathbf{r}}(\mathbf{x}) + 2 \sum_{i=1}^q r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Comprovação. Pela regra da cadeia,

$$\begin{aligned} \nabla_{\mathbf{x}} f(\mathbf{x}) &= \sum_{i=1}^q 2r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x}) \\ &= 2\mathbf{J}_{\mathbf{r}}(\mathbf{x})^{\top} \mathbf{r}(\mathbf{x}). \end{aligned}$$

Diferenciando novamente cada parcela,

$$\nabla_{\mathbf{x}} [r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})] = \nabla_{\mathbf{x}} r_i(\mathbf{x}) \nabla_{\mathbf{x}} r_i(\mathbf{x})^{\top} + r_i(\mathbf{x}) \nabla_{\mathbf{x}}^2 r_i(\mathbf{x}).$$

Somando sobre i , obtém-se a expressão da Hessiana. □

O primeiro termo da Hessiana,

$$2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}),$$

é semidefinido positivo.

O segundo termo depende:

- dos valores dos resíduos;
- das Hessianas das funções residuais;
- da não linearidade do modelo.

Quando os resíduos são pequenos, pode-se aproximar a Hessiana por

$$\nabla_{\mathbf{x}}^2 f(\mathbf{x}) \approx 2\mathbf{J}_r(\mathbf{x})^\top \mathbf{J}_r(\mathbf{x}).$$

Essa aproximação conduz ao método de Gauss–Newton. Seu desenvolvimento computacional não será necessário neste capítulo.

As mesmas ideias serão estendidas a funções cujos argumentos são matrizes. Nesse caso, os diferenciais e as identidades de traço permitem organizar as derivadas sem decompor a matriz em todos os seus elementos.

7.8 Diferenciais matriciais e cálculo por traços

Uma função escalar pode depender de todos os elementos de uma matriz. A diferenciação elemento a elemento é possível, mas se torna extensa quando a dimensão aumenta. Os diferenciais matriciais e as identidades de traço permitem organizar essas derivadas preservando a estrutura dos produtos.

Considere uma função

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R},$$

cujo argumento é

$$\mathbf{X} = (x_{ij}).$$

O diferencial total pode ser escrito como

$$d\phi = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial \phi}{\partial x_{ij}} dx_{ij}.$$

Defina o gradiente matricial por

$$\nabla_{\mathbf{X}} \phi = \left(\frac{\partial \phi}{\partial x_{ij}} \right) \in \mathbb{R}^{m \times n}.$$

Utilizando o produto interno de Frobenius,

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \text{tr} (\mathbf{A}^\top \mathbf{B}),$$

o diferencial assume a forma

$$d\phi = \langle \nabla_{\mathbf{X}} \phi, d\mathbf{X} \rangle_F.$$

Portanto,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa identidade será utilizada para reconhecer o gradiente após reorganizar o diferencial.

7.8.1 Regras básicas do diferencial matricial

Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes constantes e $\mathbf{X}$ é variável, então

$$d\mathbf{A} = \mathbf{0}$$

e

$$d\mathbf{B} = \mathbf{0}.$$

O diferencial é linear:

$$d(\mathbf{X} + \mathbf{Y}) = d\mathbf{X} + d\mathbf{Y},$$

e, para escalares constantes α e β ,

$$d(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha d\mathbf{X} + \beta d\mathbf{Y}.$$

Para um produto de matrizes variáveis,

$$d(\mathbf{XY}) = d\mathbf{X} \mathbf{Y} + \mathbf{X} d\mathbf{Y}.$$

Para três fatores,

$$\begin{aligned} d(\mathbf{XYZ}) &= d\mathbf{X} \mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} d\mathbf{Y} \mathbf{Z} \\ &\quad + \mathbf{X} \mathbf{Y} d\mathbf{Z}. \end{aligned}$$

A transposição comuta com o diferencial:

$$d(\mathbf{X}^\top) = (d\mathbf{X})^\top.$$

Quando $\mathbf{A}$ e $\mathbf{B}$ são constantes,

$$d(\mathbf{AXB}) = \mathbf{A} d\mathbf{X} \mathbf{B}.$$

Para o produto cruzado,

$$d(\mathbf{X}^\top \mathbf{X}) = d\mathbf{X}^\top \mathbf{X} + \mathbf{X}^\top d\mathbf{X}.$$

Essas regras mantêm a ordem dos fatores. Em geral, os produtos matriciais não podem ser reorganizados por comutatividade.

7.8.2 Identidades de traço

O traço transforma expressões matriciais quadradas em escalares e permite realizar permutações cíclicas dos fatores:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}),$$

quando os produtos são definidos.

Para três fatores,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

A ordem cíclica pode ser alterada, mas não uma ordem arbitrária. Em geral,

$$\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB}).$$

Também são válidas as identidades

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

e

$$\text{tr}(\mathbf{A}^\top \mathbf{B}) = \text{tr}(\mathbf{B}^\top \mathbf{A}).$$

Para reorganizar diferenciais, será utilizada a relação

$$\text{tr}(\mathbf{A} d\mathbf{X}^\top) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

De modo semelhante,

$$\text{tr}(d\mathbf{X}^\top \mathbf{A}) = \text{tr}(\mathbf{A}^\top d\mathbf{X}).$$

O objetivo dessas transformações é escrever o diferencial na forma

$$d\phi = \text{tr}(\mathbf{G}^\top d\mathbf{X}).$$

Nesse caso,

$$\nabla_{\mathbf{X}} \phi = \mathbf{G}.$$

7.8.3 Função linear de uma matriz

Teorema 7.11 (Gradiente de uma função matricial linear). *Se*

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}),$$

em que $\mathbf{A}$ é constante e possui a mesma dimensão de $\mathbf{X}$, então

$$\nabla_{\mathbf{X}} \phi = \mathbf{A}.$$

(Magnus; Neudecker, 2019)

Comprovação. O diferencial é

$$\begin{aligned} d\phi &= d \text{tr}(\mathbf{A}^\top \mathbf{X}) \\ &= \text{tr}(\mathbf{A}^\top d\mathbf{X}). \end{aligned}$$

Comparando com

$$d\phi = \text{tr}[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X}],$$

obtém-se

$$\nabla_{\mathbf{X}} \phi = \mathbf{A}.$$

□

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij},$$

essa função é o equivalente matricial da forma linear $\mathbf{a}^\top \mathbf{x}$.

7.8.4 Norma de Frobenius

A norma de Frobenius satisfaz

$$\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X}).$$

Seu diferencial é

$$\begin{aligned} d\|\mathbf{X}\|_F^2 &= d \text{tr}(\mathbf{X}^\top \mathbf{X}) \\ &= \text{tr}(d\mathbf{X}^\top \mathbf{X}) + \text{tr}(\mathbf{X}^\top d\mathbf{X}). \end{aligned}$$

Como

$$\text{tr}(d\mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{X}^\top d\mathbf{X}),$$

segue que

$$d\|\mathbf{X}\|_F^2 = 2 \text{tr}(\mathbf{X}^\top d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}.$$

Para uma matriz constante $\mathbf{M}$,

$$\phi(\mathbf{X}) = \|\mathbf{X} - \mathbf{M}\|_F^2$$

possui gradiente

$$\nabla_{\mathbf{X}} \phi = 2(\mathbf{X} - \mathbf{M}).$$

O único minimizador é

$$\mathbf{X} = \mathbf{M}.$$

7.8.5 Funções quadráticas de uma matriz

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{A} \in \mathbb{R}^{m \times m}$$

e

$$\Gamma \in \mathbb{R}^{n \times n}.$$

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) \\ &\quad + \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma). \end{aligned}$$

O primeiro termo pode ser escrito como

$$\text{tr}(d\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma) = \text{tr}[(\mathbf{A} \mathbf{X} \Gamma)^\top d\mathbf{X}].$$

No segundo termo, pela propriedade cíclica,

$$\begin{aligned} \text{tr}(\mathbf{X}^\top \mathbf{A} d\mathbf{X} \Gamma) &= \text{tr}(\Gamma \mathbf{X}^\top \mathbf{A} d\mathbf{X}) \\ &= \text{tr}[(\mathbf{A}^\top \mathbf{X} \Gamma^\top)^\top d\mathbf{X}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{X}} \phi = \mathbf{A} \mathbf{X} \Gamma + \mathbf{A}^\top \mathbf{X} \Gamma^\top.$$

Se $\mathbf{A}$ e Γ são simétricas,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A} \mathbf{X} \Gamma.$$

Exemplo 7.13 (Soma ponderada de produtos quadráticos). Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

com $\mathbf{A}$ simétrica.

Esse é o caso particular

$$\Gamma = \mathbf{I}_n.$$

Portanto,

$$\nabla_{\mathbf{X}} \phi = 2\mathbf{A}\mathbf{X}.$$

Se as colunas de $\mathbf{X}$ são

$$\mathbf{x}_1, \dots, \mathbf{x}_n,$$

então

$$\phi(\mathbf{X}) = \sum_{j=1}^n \mathbf{x}_j^\top \mathbf{A} \mathbf{x}_j.$$

O gradiente reúne, em suas colunas, os gradientes das formas quadráticas individuais:

$$2\mathbf{A}\mathbf{x}_1, \dots, 2\mathbf{A}\mathbf{x}_n.$$

7.8.6 Funções matriciais de resíduos

Considere o modelo matricial

$$\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathcal{E},$$

em que

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}$$

e

$$\mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para um valor genérico de $\mathbf{B}$, defina a matriz de resíduos

$$\mathcal{E}(\mathbf{B}) = \mathbf{Y} - \mathbf{XB}.$$

A função de soma de quadrados é

$$Q(\mathbf{B}) = \|\mathcal{E}(\mathbf{B})\|_F^2.$$

Equivalentemente,

$$Q(\mathbf{B}) = \text{tr} [\mathcal{E}(\mathbf{B})^\top \mathcal{E}(\mathbf{B})].$$

Como

$$d\mathcal{E} = -\mathbf{X} d\mathbf{B},$$

tem-se

$$\begin{aligned} dQ &= 2 \text{tr} (\mathcal{E}^\top d\mathcal{E}) \\ &= -2 \text{tr} (\mathcal{E}^\top \mathbf{X} d\mathbf{B}) \\ &= -2 \text{tr} [(\mathbf{X}^\top \mathcal{E})^\top d\mathbf{B}]. \end{aligned}$$

Logo,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = -2\mathbf{X}^\top \mathcal{E}(\mathbf{B}).$$

Substituindo a matriz de resíduos,

$$\nabla_{\mathbf{B}} Q(\mathbf{B}) = 2\mathbf{X}^\top (\mathbf{XB} - \mathbf{Y}).$$

A condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{XB}) = \mathbf{0},$$

ou

$$\mathbf{X}^\top \mathbf{X} \mathbf{B} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as equações normais matriciais.

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Cada coluna de $\widehat{\mathbf{B}}$ corresponde ao ajuste de uma coluna de $\mathbf{Y}$ sobre a mesma matriz de delineamento $\mathbf{X}$.

Teorema 7.12 (Convexidade dos mínimos quadrados matriciais). *A função*

$$Q(\mathbf{B}) = \|\mathbf{Y} - \mathbf{X}\mathbf{B}\|_F^2$$

é convexa em $\mathbf{B}$.

Ela é estritamente convexa quando $\mathbf{X}$ possui posto coluna completo.

Comprovação. Considere uma perturbação

$$d\mathbf{B}.$$

A segunda variação de Q é

$$d^2Q = 2 \operatorname{tr} (d\mathbf{B}^\top \mathbf{X}^\top \mathbf{X} d\mathbf{B}).$$

Equivalentemente,

$$d^2Q = 2 \|\mathbf{X} d\mathbf{B}\|_F^2 \geq 0.$$

Portanto, a função é convexa.

Se $\mathbf{X}$ possui posto coluna completo, então

$$\mathbf{X} d\mathbf{B} = \mathbf{0}$$

implica

$$d\mathbf{B} = \mathbf{0}.$$

Assim, a segunda variação é positiva para toda perturbação não nula, e a função é estritamente convexa. $\square$

7.8.7 Ponderação de observações e respostas

Considere uma matriz diagonal de pesos das observações

$$\Omega = \text{diag}(\omega_1, \dots, \omega_n) \succeq \mathbf{0}$$

e uma matriz simétrica positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}.$$

O critério ponderado é

$$Q_{\Omega, \Sigma}(\mathbf{B}) = \text{tr} [\Sigma^{-1} \mathcal{E}(\mathbf{B})^\top \Omega \mathcal{E}(\mathbf{B})].$$

A matriz Ω pondera as linhas da matriz de resíduos. A matriz Σ^{-1} pondera as combinações entre as colunas.

Como Ω e Σ^{-1} são simétricas,

$$\begin{aligned} dQ_{\Omega, \Sigma} &= 2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega d\mathcal{E}] \\ &= -2 \text{tr} [\Sigma^{-1} \mathcal{E}^\top \Omega \mathbf{X} d\mathbf{B}]. \end{aligned}$$

Pela propriedade cíclica,

$$dQ_{\Omega, \Sigma} = -2 \text{tr} [(\mathbf{X}^\top \Omega \mathcal{E} \Sigma^{-1})^\top d\mathbf{B}].$$

Portanto,

$$\nabla_{\mathbf{B}} Q_{\Omega, \Sigma}(\mathbf{B}) = -2 \mathbf{X}^\top \Omega \mathcal{E}(\mathbf{B}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{X}\mathbf{B}) \Sigma^{-1} = \mathbf{0}.$$

Como Σ^{-1} é invertível,

$$\mathbf{X}^\top \Omega (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Logo,

$$\mathbf{X}^\top \Omega \mathbf{XB} = \mathbf{X}^\top \Omega \mathbf{Y}.$$

Se

$$\mathbf{X}^\top \Omega \mathbf{X}$$

é invertível, o minimizador é

$$\widehat{\mathbf{B}} = (\mathbf{X}^\top \Omega \mathbf{X})^{-1} \mathbf{X}^\top \Omega \mathbf{Y}.$$

Nesse critério, a ponderação invertível entre as respostas altera o valor da função e sua geometria, mas não altera o ponto de mínimo em relação a $\mathbf{B}$. A ponderação das observações, por outro lado, modifica as equações normais e o estimador.

As próximas identidades tratam funções que envolvem inversas e determinantes. Esses objetos aparecem em critérios definidos sobre o conjunto das matrizes positivas definidas.

7.9 Derivadas de inversas, determinantes e log-determinantes

As matrizes inversas e os determinantes aparecem em transformações de coordenadas, funções de densidade e critérios de estimação. Suas derivadas exigem condições de invertibilidade e, em aplicações com matrizes de covariâncias, definição positiva.

7.9.1 Diferencial da matriz inversa

Considere uma matriz invertível

$$\mathbf{X} \in \mathbb{R}^{p \times p}.$$

A identidade

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p$$

permite obter o diferencial da inversa.

Teorema 7.13 (Diferencial da matriz inversa). *Se $\mathbf{X}$ é invertível, então*

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

(Magnus; Neudecker, 2019)

Comprovação. Diferenciando

$$\mathbf{X}\mathbf{X}^{-1} = \mathbf{I}_p,$$

obtém-se

$$d\mathbf{X}\mathbf{X}^{-1} + \mathbf{X}d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Multiplicando à esquerda por $\mathbf{X}^{-1}$,

$$\mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1} + d(\mathbf{X}^{-1}) = \mathbf{0}.$$

Logo,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(d\mathbf{X})\mathbf{X}^{-1}.$$

□

O sinal negativo indica que o aumento de uma matriz positiva definida em determinada direção produz redução de sua inversa na direção correspondente, segundo a ordem matricial apropriada.

Para uma perturbação $d\mathbf{X}$,

$$(\mathbf{X} + d\mathbf{X})^{-1} \approx \mathbf{X}^{-1} - \mathbf{X}^{-1}d\mathbf{X}\mathbf{X}^{-1}.$$

Essa aproximação é válida para perturbações suficientemente pequenas que preservem a invertibilidade.

Exemplo 7.14 (Caso escalar). Para

$$x \neq 0,$$

a função inversa é

$$f(x) = \frac{1}{x}.$$

A fórmula matricial reduz-se a

$$d(x^{-1}) = -x^{-1}(dx)x^{-1} = -\frac{1}{x^2}dx.$$

Portanto,

$$f'(x) = -\frac{1}{x^2}.$$

7.9.2 Diferencial do determinante

O determinante é uma função escalar definida sobre matrizes quadradas:

$$\det : \mathbb{R}^{p \times p} \longrightarrow \mathbb{R}.$$

Sua derivada é descrita pela fórmula de Jacobi.

Teorema 7.14 (Fórmula de Jacobi). *Se $\mathbf{X}$ é invertível, então*

$$d \det(\mathbf{X}) = \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

(Magnus; Neudecker, 2019)

Como

$$d \det(\mathbf{X}) = \operatorname{tr} \left[(\nabla_{\mathbf{X}} \det(\mathbf{X}))^{\top} d\mathbf{X} \right],$$

segue que

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

e

$$\nabla_{\mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-1}.$$

A fórmula pode ser estendida a matrizes singulares por meio da matriz adjunta, mas a forma envolvendo $\mathbf{X}^{-1}$ exige invertibilidade.

7.9.3 Diferencial do log-determinante

Para matrizes positivas definidas,

$$\mathbf{X} \succ \mathbf{0},$$

o determinante é positivo e a função

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

está bem definida.

Teorema 7.15 (Diferencial do log-determinante). *Se $\mathbf{X} \succ \mathbf{0}$, então*

$$d \log \det(\mathbf{X}) = \text{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Consequentemente,

$$\nabla_{\mathbf{X}} \log \det(\mathbf{X}) = \mathbf{X}^{-1}.$$

Comprovação. Pela regra da cadeia,

$$d \log \det(\mathbf{X}) = \frac{1}{\det(\mathbf{X})} d \det(\mathbf{X}).$$

Aplicando a fórmula de Jacobi,

$$\begin{aligned} d \log \det(\mathbf{X}) &= \frac{1}{\det(\mathbf{X})} \det(\mathbf{X}) \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}) \\ &= \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}). \end{aligned}$$

Como $\mathbf{X}$ é simétrica,

$$\mathbf{X}^{-\top} = \mathbf{X}^{-1},$$

o que fornece o gradiente. □

Para uma matriz invertível não necessariamente simétrica, a função

$$\log |\det(\mathbf{X})|$$

satisfaz

$$\nabla_{\mathbf{X}} \log |\det(\mathbf{X})| = \mathbf{X}^{-\top}$$

em qualquer região em que o sinal do determinante permaneça constante.

7.9.4 Segunda variação do log-determinante

Considere uma matriz positiva definida $\mathbf{X}$ e uma perturbação simétrica $d\mathbf{X}$.

A primeira variação é

$$d\phi = \operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X}).$$

Utilizando o diferencial da inversa,

$$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1},$$

a segunda variação na mesma direção é

$$d^2 \phi = -\operatorname{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}).$$

Como

$$\mathbf{X}^{-1/2} d\mathbf{X} \mathbf{X}^{-1/2}$$

é simétrica,

$$\begin{aligned} \text{tr}(\mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1} d\mathbf{X}) &= \|\mathbf{X}^{-1/2} d\mathbf{X} \mathbf{X}^{-1/2}\|_F^2 \\ &\geq 0. \end{aligned}$$

Logo,

$$d^2\phi \leq 0.$$

Teorema 7.16 (Concavidade do log-determinante). *A função*

$$\phi(\mathbf{X}) = \log \det(\mathbf{X})$$

é estritamente côncava no conjunto das matrizes simétricas positivas definidas. (Boyd; Vandenberghe, 2004)

Consequentemente,

$$-\log \det(\mathbf{X})$$

é estritamente convexa nesse domínio.

7.9.5 Traço envolvendo uma matriz inversa

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{A} \mathbf{X}^{-1}),$$

em que $\mathbf{A}$ é constante e $\mathbf{X}$ é invertível.

O diferencial é

$$\begin{aligned} d\phi &= \text{tr}[\mathbf{A} d(\mathbf{X}^{-1})] \\ &= -\text{tr}(\mathbf{A} \mathbf{X}^{-1} d\mathbf{X} \mathbf{X}^{-1}). \end{aligned}$$

Pela propriedade cíclica,

$$d\phi = -\operatorname{tr}(\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}d\mathbf{X}).$$

Portanto,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{A}^{\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{A}$ e $\mathbf{X}$ são simétricas,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{A}\mathbf{X}^{-1}.$$

Exemplo 7.15 (Traço da inversa). Para

$$\phi(\mathbf{X}) = \operatorname{tr}(\mathbf{X}^{-1}),$$

tem-se $\mathbf{A} = \mathbf{I}_p$. Logo,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-\top}\mathbf{X}^{-\top}.$$

Se $\mathbf{X}$ é simétrica positiva definida,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-2}.$$

7.9.6 Forma quadrática com matriz inversa

Considere

$$\phi(\mathbf{X}) = \mathbf{a}^{\top}\mathbf{X}^{-1}\mathbf{a},$$

em que $\mathbf{a} \in \mathbb{R}^p$ é constante e $\mathbf{X} \succ \mathbf{0}$.

A função pode ser escrita como

$$\phi(\mathbf{X}) = \operatorname{tr}(\mathbf{X}^{-1}\mathbf{a}\mathbf{a}^{\top}).$$

Aplicando o resultado anterior,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{a}\mathbf{a}^{\top}\mathbf{X}^{-1}.$$

Equivalentemente,

$$\nabla_{\mathbf{X}}\phi = -(\mathbf{X}^{-1}\mathbf{a})(\mathbf{X}^{-1}\mathbf{a})^{\top}.$$

Essa matriz é semidefinida negativa.

Se o vetor também varia, considere

$$\phi(\mathbf{x}, \mathbf{X}) = \mathbf{x}^{\top} \mathbf{X}^{-1} \mathbf{x}.$$

Em relação ao vetor,

$$\nabla_{\mathbf{x}}\phi = 2\mathbf{X}^{-1}\mathbf{x},$$

enquanto, em relação à matriz,

$$\nabla_{\mathbf{X}}\phi = -\mathbf{X}^{-1}\mathbf{x}\mathbf{x}^{\top}\mathbf{X}^{-1}.$$

7.9.7 Critério com log-determinante e traço

Considere

$$L(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}),$$

em que

$$\Sigma \succ \mathbf{0}$$

é variável e

$$\mathbf{G} \succeq \mathbf{0}$$

é constante e simétrica.

O diferencial é

$$\begin{aligned} dL &= \frac{n}{2} \text{tr}(\Sigma^{-1}d\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{G}\Sigma^{-1}d\Sigma). \end{aligned}$$

Logo,

$$\nabla_{\Sigma} L = \frac{n}{2} \Sigma^{-1} - \frac{1}{2} \Sigma^{-1} \mathbf{G} \Sigma^{-1}.$$

A condição de primeira ordem é

$$n \Sigma^{-1} = \Sigma^{-1} \mathbf{G} \Sigma^{-1}.$$

Multiplicando à esquerda e à direita por Σ ,

$$n \Sigma = \mathbf{G}.$$

Portanto, o ponto estacionário é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Para que esse ponto pertença ao domínio

$$\Sigma \succ \mathbf{0},$$

é necessário que

$$\mathbf{G} \succ \mathbf{0}.$$

Teorema 7.17 (Minimização do critério de covariância). *Se*

$$\mathbf{G} \succ \mathbf{0},$$

a função

$$L(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G})$$

possui minimizador único no conjunto das matrizes positivas definidas:

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}.$$

Comprovação. Defina

$$\mathbf{Z} = \mathbf{G}^{1/2} \Sigma^{-1} \mathbf{G}^{1/2}.$$

Como $\mathbf{G}$ e Σ são positivas definidas,

$$\mathbf{Z} \succ \mathbf{0}.$$

Além disso,

$$\text{tr}(\Sigma^{-1} \mathbf{G}) = \text{tr}(\mathbf{Z})$$

e

$$\log \det(\Sigma) = \log \det(\mathbf{G}) - \log \det(\mathbf{Z}).$$

Assim, a menos de uma constante,

$$L(\Sigma) = \frac{1}{2} [\text{tr}(\mathbf{Z}) - n \log \det(\mathbf{Z})].$$

Se

$$z_1, \dots, z_p$$

são os autovalores positivos de $\mathbf{Z}$, então

$$L(\Sigma) = \text{constante} + \frac{1}{2} \sum_{j=1}^p (z_j - n \log z_j).$$

Para cada $z_j > 0$, a função

$$h(z) = z - n \log z$$

possui derivada

$$h'(z) = 1 - \frac{n}{z}$$

e segunda derivada

$$h''(z) = \frac{n}{z^2} > 0.$$

Seu único mínimo ocorre em

$$z = n.$$

Portanto,

$$\mathbf{Z} = n\mathbf{I}_p.$$

Essa igualdade equivale a

$$\Sigma = \frac{1}{n}\mathbf{G}.$$

□

Se $\mathbf{G}$ é singular, o candidato

$$\frac{1}{n}\mathbf{G}$$

não pertence ao domínio positivo definido. Nesse caso, o critério não possui minimizador interior. É possível fazer alguns autovalores de Σ tenderem a zero em direções pertencentes ao núcleo de $\mathbf{G}$, fazendo o log-determinante tender a $-\infty$ sem aumento compensatório no termo de traço.

7.9.8 Parâmetros matriciais simétricos

As fórmulas anteriores foram escritas utilizando matrizes completas. Entretanto, uma matriz simétrica

$$\Sigma = \Sigma^\top$$

possui apenas

$$\frac{p(p+1)}{2}$$

elementos distintos.

Quando o argumento é restrito ao espaço das matrizes simétricas, as perturbações admissíveis também devem ser simétricas:

$$d\Sigma = d\Sigma^\top.$$

Para uma função escalar $\phi(\Sigma)$, somente a parte simétrica do gradiente contribui para o diferencial:

$$\text{tr} \left[(\nabla_\Sigma \phi)^\top d\Sigma \right] = \text{tr} \left[\left(\frac{\nabla_\Sigma \phi + \nabla_\Sigma \phi^\top}{2} \right)^\top d\Sigma \right].$$

Nos resultados anteriores, os gradientes obtidos para argumentos positivos definidos já são simétricos quando as matrizes constantes envolvidas também são simétricas.

Uma parametrização explícita dos elementos distintos será desenvolvida com os operadores de vetorização e meia vetorização.

7.10 Vetorização, produto de Kronecker e parâmetros matriciais

A vetorização transforma uma matriz em um vetor. Essa operação permite representar transformações matriciais por matrizes usuais e aplicar resultados de cálculo vetorial a parâmetros matriciais.

7.10.1 Operador de vetorização

Definição 7.9 (Operador de vetorização). Para

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{m1} & \cdots & x_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n},$$

o vetor

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}$$

é obtido pelo empilhamento das colunas de $\mathbf{X}$:

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} x_{11} \\ \vdots \\ x_{m1} \\ x_{12} \\ \vdots \\ x_{m2} \\ \vdots \\ x_{1n} \\ \vdots \\ x_{mn} \end{bmatrix}.$$

Exemplo 7.16 (Vetorização de uma matriz). Considere

$$\mathbf{X} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

Então,

$$\text{vec}(\mathbf{X}) = \begin{bmatrix} 1 \\ 4 \\ 2 \\ 5 \\ 3 \\ 6 \end{bmatrix}.$$

A vetorização é linear:

$$\text{vec}(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha \text{vec}(\mathbf{X}) + \beta \text{vec}(\mathbf{Y}).$$

Além disso,

$$\|\mathbf{X}\|_F = \|\text{vec}(\mathbf{X})\|.$$

Isso ocorre porque os dois lados reúnem os mesmos elementos ao quadrado:

$$\|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2.$$

7.10.2 Produto de Kronecker

Definição 7.10 (Produto de Kronecker). Considere

$$\mathbf{A} = (a_{ij}) \in \mathbb{R}^{m \times n}$$

e

$$\mathbf{C} \in \mathbb{R}^{r \times s}.$$

O produto de Kronecker é a matriz

$$\mathbf{A} \otimes \mathbf{C} = \begin{bmatrix} a_{11}\mathbf{C} & \cdots & a_{1n}\mathbf{C} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{C} & \cdots & a_{mn}\mathbf{C} \end{bmatrix} \in \mathbb{R}^{mr \times ns}.$$

Exemplo 7.17 (Produto de Kronecker). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$\mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

Então,

$$\begin{aligned} \mathbf{A} \otimes \mathbf{C} &= \begin{bmatrix} 1\mathbf{C} & 2\mathbf{C} \\ 3\mathbf{C} & 4\mathbf{C} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & -1 & 0 & -2 \\ 3 & 0 & 4 & 0 \\ 0 & -3 & 0 & -4 \end{bmatrix}. \end{aligned}$$

(Magnus; Neudecker, 2019)

O produto de Kronecker satisfaz:

$$(\mathbf{A} \otimes \mathbf{C})^\top = \mathbf{A}^\top \otimes \mathbf{C}^\top,$$

e, para produtos de dimensões compatíveis,

$$(\mathbf{A}_1 \otimes \mathbf{C}_1)(\mathbf{A}_2 \otimes \mathbf{C}_2) = (\mathbf{A}_1 \mathbf{A}_2) \otimes (\mathbf{C}_1 \mathbf{C}_2).$$

Se $\mathbf{A}$ e $\mathbf{C}$ são invertíveis,

$$(\mathbf{A} \otimes \mathbf{C})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{C}^{-1}.$$

Se $\mathbf{A}$ e $\mathbf{C}$ são simétricas positivas definidas, então

$$\mathbf{A} \otimes \mathbf{C} \succ \mathbf{0}.$$

7.10.3 Identidade de vetorização

A relação entre vetorização e produto de Kronecker permite representar um produto matricial como uma transformação linear do vetor de elementos da matriz.

Teorema 7.18 (Identidade fundamental da vetorização). *Considere*

$$\mathbf{A} \in \mathbb{R}^{r \times m}, \quad \mathbf{X} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{n \times s}.$$

Então,

$$\text{vec}(\mathbf{A}\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

(Magnus; Neudecker, 2019)

O lado esquerdo possui dimensão rs . No lado direito,

$$\Gamma^\top \otimes \mathbf{A} \in \mathbb{R}^{rs \times mn},$$

e

$$\text{vec}(\mathbf{X}) \in \mathbb{R}^{mn}.$$

Casos particulares importantes são

$$\text{vec}(\mathbf{AX}) = (\mathbf{I}_n \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

e

$$\text{vec}(\mathbf{X}\Gamma) = (\Gamma^\top \otimes \mathbf{I}_m) \text{vec}(\mathbf{X}).$$

Exemplo 7.18 (Vetorização de um produto matricial). Considere

$$\mathbf{Y} = \mathbf{AX}\Gamma.$$

Uma pequena perturbação de $\mathbf{X}$ produz

$$d\mathbf{Y} = \mathbf{A} d\mathbf{X} \Gamma.$$

Vetorizando,

$$d \text{vec}(\mathbf{Y}) = (\Gamma^\top \otimes \mathbf{A}) d \text{vec}(\mathbf{X}).$$

Portanto, a Jacobiana da transformação vetorizada é

$$\frac{\partial \text{vec}(\mathbf{Y})}{\partial \text{vec}(\mathbf{X})^\top} = \Gamma^\top \otimes \mathbf{A}.$$

7.10.4 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr} (\mathbf{A}^\top \Gamma) = \text{vec}(\mathbf{A})^\top \text{vec}(\Gamma),$$

tem-se

$$d\phi = \text{vec} (\nabla_{\mathbf{X}} \phi)^\top d \text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})} \phi = \text{vec} (\nabla_{\mathbf{X}} \phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.5 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2 \phi = \frac{\partial \text{vec} (\nabla_{\mathbf{X}} \phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr} (\mathbf{X}^\top \mathbf{A} \mathbf{X} \Gamma),$$

com $\mathbf{A}$ e Γ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\Gamma.$$

Vetorizando,

$$\begin{aligned}\text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\Gamma) \\ &= 2(\Gamma \otimes \mathbf{A})\text{vec}(\mathbf{X}).\end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\Gamma \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\Gamma \succeq \mathbf{0},$$

a Hessiana é semidefinida positiva e a função é convexa.

7.10.6 Gradiente matricial e gradiente vetorizado

Considere

$$\phi : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}.$$

Pela definição do gradiente matricial,

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}}\phi)^\top d\mathbf{X} \right].$$

Como

$$\text{tr}(\mathbf{A}^\top \mathbf{C}) = \text{vec}(\mathbf{A})^\top \text{vec}(\mathbf{C}),$$

tem-se

$$d\phi = \text{vec}(\nabla_{\mathbf{X}}\phi)^\top d\text{vec}(\mathbf{X}).$$

Logo,

$$\nabla_{\text{vec}(\mathbf{X})}\phi = \text{vec}(\nabla_{\mathbf{X}}\phi).$$

A forma matricial e a forma vetorizada representam a mesma derivada, organizadas em estruturas diferentes.

7.10.7 Hessiana de uma função matricial

Para uma função escalar de matriz, a Hessiana vetorizada é definida por

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = \frac{\partial \text{vec}(\nabla_{\mathbf{X}}\phi)}{\partial \text{vec}(\mathbf{X})^\top}.$$

Considere

$$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \mathbf{C}),$$

com $\mathbf{A}$ e $\mathbf{C}$ simétricas.

Foi obtido que

$$\nabla_{\mathbf{X}}\phi = 2\mathbf{A}\mathbf{X}\mathbf{C}.$$

Vetorizando,

$$\begin{aligned} \text{vec}(\nabla_{\mathbf{X}}\phi) &= 2\text{vec}(\mathbf{A}\mathbf{X}\mathbf{C}) \\ &= 2(\mathbf{C} \otimes \mathbf{A})\text{vec}(\mathbf{X}). \end{aligned}$$

Portanto,

$$\nabla_{\text{vec}(\mathbf{X})}^2\phi = 2(\mathbf{C} \otimes \mathbf{A}).$$

Se

$$\mathbf{A} \succeq \mathbf{0}$$

e

$$\mathbf{C} \succeq \mathbf{0},$$

a Hessiana é semidefinida positiva e a função é convexa.

7.10.8 Matriz de comutação

A vetorização de uma matriz e de sua transposta possui ordenações diferentes.

Definição 7.11 (Matriz de comutação). A matriz de comutação

$$\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$$

é a matriz de permutação que satisfaz

$$\mathbf{K}_{m,n} \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{X}^\top)$$

para toda

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

A transposição pode ser desfeita:

$$\mathbf{K}_{n,m} \mathbf{K}_{m,n} = \mathbf{I}_{mn}.$$

Logo,

$$\mathbf{K}_{m,n}^{-1} = \mathbf{K}_{n,m} = \mathbf{K}_{m,n}^\top.$$

Para matrizes quadradas,

$$\mathbf{K}_{p,p} = \mathbf{K}_{p,p}^\top$$

e

$$\mathbf{K}_{p,p}^2 = \mathbf{I}_{p^2}.$$

Considere

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

e

$$\Gamma \in \mathbb{R}^{r \times s}.$$

A matriz de comutação satisfaz

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) = (\Gamma \otimes \mathbf{A}) \mathbf{K}_{n,s}.$$

Equivalentemente,

$$\mathbf{K}_{m,r} (\mathbf{A} \otimes \Gamma) \mathbf{K}_{s,n} = \Gamma \otimes \mathbf{A}.$$

7.10.9 Meia vetorização de matrizes simétricas

Uma matriz simétrica possui elementos repetidos acima e abaixo da diagonal. O operador vech conserva somente os elementos da parte triangular inferior.

Definição 7.12 (Operador de meia vetorização). Para uma matriz simétrica

$$\mathbf{S} = \mathbf{S}^\top \in \mathbb{R}^{p \times p},$$

o vetor

$$\text{vech}(\mathbf{S}) \in \mathbb{R}^{p(p+1)/2}$$

é obtido pelo empilhamento, por colunas, dos elementos da parte triangular inferior, incluindo a diagonal.

Exemplo 7.19 (Meia vetorização de uma matriz simétrica). Considere

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & s_{13} \\ s_{12} & s_{22} & s_{23} \\ s_{13} & s_{23} & s_{33} \end{bmatrix}.$$

Então,

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{13} \\ s_{22} \\ s_{23} \\ s_{33} \end{bmatrix}.$$

A ordem acompanha as colunas da parte triangular inferior:

- primeira coluna: s_{11}, s_{12}, s_{13} ;
- segunda coluna: s_{22}, s_{23} ;
- terceira coluna: s_{33} .

O operador vech elimina a duplicação dos elementos simétricos. Enquanto

$$\text{vec}(\mathbf{S})$$

possui p^2 elementos,

$$\text{vech}(\mathbf{S})$$

possui

$$\frac{p(p+1)}{2}$$

elementos.

7.10.10 Matriz de duplicação

Definição 7.13 (Matriz de duplicação). A matriz de duplicação

$$\mathbf{D}_p^{\text{dup}} \in \mathbb{R}^{p^2 \times p(p+1)/2}$$

é definida pela identidade

$$\text{vec}(\mathbf{S}) = \mathbf{D}_p^{\text{dup}} \text{vech}(\mathbf{S})$$

para toda matriz simétrica

$$\mathbf{S} \in \mathbb{R}^{p \times p}.$$

A matriz de duplicação repete os elementos fora da diagonal nas posições correspondentes de $\text{vec}(\mathbf{S})$.

Para $p = 2$,

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} \\ s_{12} & s_{22} \end{bmatrix},$$

e

$$\text{vech}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{22} \end{bmatrix}.$$

Como

$$\text{vec}(\mathbf{S}) = \begin{bmatrix} s_{11} \\ s_{12} \\ s_{12} \\ s_{22} \end{bmatrix},$$

tem-se

$$\mathbf{D}_2^{\text{dup}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

7.10.11 Matriz de eliminação

Definição 7.14 (Matriz de eliminação). A matriz de eliminação

$$\mathbf{L}_p^{\text{elim}} \in \mathbb{R}^{p(p+1)/2 \times p^2}$$

é definida por

$$\text{vech}(\mathbf{S}) = \mathbf{L}_p^{\text{elim}} \text{vec}(\mathbf{S})$$

para toda matriz simétrica $\mathbf{S}$.

A matriz de eliminação seleciona da vetorização completa os elementos pertencentes à parte triangular inferior.

As duas matrizes satisfazem

$$\mathbf{L}_p^{\text{elim}} \mathbf{D}_p^{\text{dup}} = \mathbf{I}_{p(p+1)/2}.$$

Em geral,

$$\mathbf{D}_p^{\text{dup}} \mathbf{L}_p^{\text{elim}}$$

não é a identidade em $\mathbb{R}^{p^2}$, pois o produto atua sobre vetores que podem representar matrizes não simétricas.

7.10.12 Diferenciais de parâmetros simétricos

Se

$$\Sigma = \Sigma^\top$$

é um parâmetro matricial simétrico, então

$$d \text{vec}(\Sigma) = \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Considere uma função escalar

$$\phi(\Sigma)$$

com gradiente matricial

$$\nabla_\Sigma \phi.$$

Seu diferencial é

$$d\phi = \text{vec}(\nabla_\Sigma \phi)^\top d \text{vec}(\Sigma).$$

Substituindo a matriz de duplicação,

$$d\phi = \text{vec}(\nabla_\Sigma \phi)^\top \mathbf{D}_p^{\text{dup}} d \text{vech}(\Sigma).$$

Portanto,

$$\nabla_{\text{vech}(\Sigma)}\phi = (\mathbf{D}_p^{\text{dup}})^{\top} \text{vec}(\nabla_{\Sigma}\phi).$$

Essa expressão transforma o gradiente matricial em um gradiente relativo somente aos elementos distintos do parâmetro simétrico.

7.10.13 Jacobiana de transformações matriciais

Considere uma transformação

$$\mathcal{G} : \mathbb{R}^{m \times n} \longrightarrow \mathbb{R}^{r \times s}.$$

Sua representação vetorizada é

$$\mathbf{g}(\text{vec}(\mathbf{X})) = \text{vec}(\mathcal{G}(\mathbf{X})).$$

A Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = \frac{\partial \text{vec}(\mathcal{G}(\mathbf{X}))}{\partial \text{vec}(\mathbf{X})^{\top}}.$$

Ela satisfaz

$$d \text{vec}(\mathcal{G}(\mathbf{X})) = \mathbf{J}_{\mathcal{G}}(\mathbf{X}) d \text{vec}(\mathbf{X}).$$

Exemplo 7.20 (Jacobiana de $\mathbf{X}^{\top} \mathbf{X}$). Considere

$$\mathcal{G}(\mathbf{X}) = \mathbf{X}^{\top} \mathbf{X},$$

com

$$\mathbf{X} \in \mathbb{R}^{m \times n}.$$

O diferencial é

$$d\mathcal{G} = d\mathbf{X}^{\top} \mathbf{X} + \mathbf{X}^{\top} d\mathbf{X}.$$

Vetorizando o primeiro termo,

$$\begin{aligned}\text{vec}(d\mathbf{X}^\top \mathbf{X}) &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \text{vec}(d\mathbf{X}^\top) \\ &= (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} \text{vec}(d\mathbf{X}).\end{aligned}$$

Para o segundo termo,

$$\text{vec}(\mathbf{X}^\top d\mathbf{X}) = (\mathbf{I}_n \otimes \mathbf{X}^\top) \text{vec}(d\mathbf{X}).$$

Logo,

$$\begin{aligned}d \text{vec}(\mathbf{X}^\top \mathbf{X}) &= [(\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top] \\ &\quad \times d \text{vec}(\mathbf{X}).\end{aligned}$$

Portanto, a Jacobiana vetorizada é

$$\mathbf{J}_{\mathcal{G}}(\mathbf{X}) = (\mathbf{X}^\top \otimes \mathbf{I}_n) \mathbf{K}_{m,n} + \mathbf{I}_n \otimes \mathbf{X}^\top.$$

A vetorização e o produto de Kronecker permitem representar derivadas matriciais por matrizes usuais. Essa representação será útil para covariâncias de vetores matriciais, Hessianas e aproximações de funções de parâmetros matriciais.

7.11 Integração múltipla e mudança de variáveis

O cálculo integral permite obter probabilidades, esperanças e distribuições marginais. Para vetores aleatórios contínuos, as integrais são realizadas sobre subconjuntos de $\mathbb{R}^p$.

7.11.1 Integrais múltiplas

Considere uma função

$$f : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}.$$

Sua integral sobre $\mathcal{D}$ é representada por

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x},$$

em que

$$d\mathbf{x} = dx_1 \cdots dx_p.$$

Em duas dimensões,

$$\int_{\mathcal{D}} f(x_1, x_2) dx_1 dx_2$$

representa a acumulação dos valores da função sobre uma região do plano.

Quando

$$\mathcal{D} = \mathcal{D}_1 \times \cdots \times \mathcal{D}_p$$

é um produto cartesiano, a integral pode ser escrita como integral iterada:

$$\int_{\mathcal{D}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}_p} \cdots \int_{\mathcal{D}_1} f(x_1, \dots, x_p) dx_1 \cdots dx_p,$$

desde que sejam satisfeitas as condições que permitem a integração sucessiva.

7.11.2 Teoremas de Tonelli e Fubini

Teorema 7.19 (Teorema de Tonelli). *Se*

$$f : \mathcal{D}_1 \times \mathcal{D}_2 \longrightarrow [0, \infty]$$

é mensurável e não negativa, então

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) dx_1 dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) dx_1 \right] dx_2, \end{aligned}$$

permitindo valores infinitos. (Axler, 2020)

Para funções não negativas, a ordem de integração pode ser alterada mesmo quando a integral total não é finita.

Teorema 7.20 (Teorema de Fubini). *Se*

$$\int_{\mathcal{D}_1 \times \mathcal{D}_2} |f(x_1, x_2)| \, dx_1 \, dx_2 < \infty,$$

então as integrais iteradas existem, são finitas e satisfazem

$$\begin{aligned} \int_{\mathcal{D}_1 \times \mathcal{D}_2} f(x_1, x_2) \, dx_1 \, dx_2 &= \int_{\mathcal{D}_1} \left[\int_{\mathcal{D}_2} f(x_1, x_2) \, dx_2 \right] dx_1 \\ &= \int_{\mathcal{D}_2} \left[\int_{\mathcal{D}_1} f(x_1, x_2) \, dx_1 \right] dx_2. \end{aligned}$$

A integrabilidade absoluta é uma condição suficiente para trocar a ordem de integração.

7.11.3 Densidades multivariadas

Considere um vetor aleatório contínuo

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Uma função

$$f_{\mathbf{X}} : \mathbb{R}^p \longrightarrow [0, \infty)$$

é uma densidade conjunta quando

$$f_{\mathbf{X}}(\mathbf{x}) \geq 0$$

e

$$\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x} = 1.$$

Para um conjunto mensurável

$$\mathcal{A} \subseteq \mathbb{R}^p,$$

a probabilidade é

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em duas dimensões,

$$P[(X_1, X_2) \in \mathcal{A}] = \iint_{\mathcal{A}} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2.$$

7.11.4 Distribuições marginais

Considere a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix},$$

com

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

A densidade marginal de $\mathbf{X}_1$ é obtida integrando a densidade conjunta em relação às componentes de $\mathbf{X}_2$:

$$f_{\mathbf{X}_1}(\mathbf{x}_1) = \int_{\mathbb{R}^{p_2}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_2.$$

De modo semelhante,

$$f_{\mathbf{X}_2}(\mathbf{x}_2) = \int_{\mathbb{R}^{p_1}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1.$$

A marginalização elimina as variáveis que não aparecem no resultado, acumulando a densidade conjunta sobre todos os seus valores possíveis.

Exemplo 7.21 (Densidade marginal em uma região triangular). Considere a densidade conjunta

$$f_{\mathbf{X}_1, \mathbf{X}_2}(x_1, x_2) = 2,$$

para

$$0 < x_2 < x_1 < 1,$$

e zero fora dessa região.

A densidade marginal de $\mathbf{X}_1$ é

$$\begin{aligned} f_{\mathbf{X}_1}(x_1) &= \int_0^{x_1} 2 \, dx_2 \\ &= 2x_1, \quad 0 < x_1 < 1. \end{aligned}$$

A densidade marginal de $\mathbf{X}_2$ é

$$\begin{aligned} f_{\mathbf{X}_2}(x_2) &= \int_{x_2}^1 2 \, dx_1 \\ &= 2(1 - x_2), \quad 0 < x_2 < 1. \end{aligned}$$

As duas densidades integram 1 em seus respectivos domínios.

7.11.5 Esperanças de funções vetoriais

Se

$$h : \mathbb{R}^p \longrightarrow \mathbb{R}$$

é uma função integrável, sua esperança é

$$E[h(\mathbf{X})] = \int_{\mathbb{R}^p} h(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x}.$$

Para uma função vetorial

$$\mathbf{g} : \mathbb{R}^p \longrightarrow \mathbb{R}^q,$$

com

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} g_1(\mathbf{x}) \\ \vdots \\ g_q(\mathbf{x}) \end{bmatrix},$$

a esperança é definida componente a componente:

$$E[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} E[g_1(\mathbf{X})] \\ \vdots \\ E[g_q(\mathbf{X})] \end{bmatrix}.$$

Equivalentemente,

$$E[\mathbf{g}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Para uma função matricial

$$\mathcal{G} : \mathbb{R}^p \longrightarrow \mathbb{R}^{m \times n},$$

a esperança também é calculada elemento a elemento:

$$E[\mathcal{G}(\mathbf{X})] = \int_{\mathbb{R}^p} \mathcal{G}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

Em particular,

$$E[\mathbf{X}\mathbf{X}^\top] = \int_{\mathbb{R}^p} \mathbf{x}\mathbf{x}^\top f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}.$$

A existência da esperança vetorial ou matricial exige integrabilidade dos elementos correspondentes.

7.11.6 Mudança de variáveis

Uma transformação diferenciável altera a posição dos pontos e o volume dos elementos infinitesimais. O determinante da Jacobiana mede essa alteração local de volume.

Considere uma transformação

$$\mathbf{g} : \mathcal{D} \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^p$$

e defina

$$\mathbf{y} = \mathbf{g}(\mathbf{x}).$$

A aproximação local é

$$d\mathbf{y} = \mathbf{J}_{\mathbf{g}}(\mathbf{x})d\mathbf{x}.$$

O fator local de alteração de volume é

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

O valor absoluto é necessário porque o determinante pode ser negativo quando a transformação altera a orientação do espaço.

Teorema 7.21 (Teorema da Mudança de Variáveis). *Considere conjuntos abertos*

$$\mathcal{D}, \mathcal{G} \subseteq \mathbb{R}^p$$

e uma transformação bijetiva

$$\mathbf{g} : \mathcal{D} \longrightarrow \mathcal{G}$$

continuamente diferenciável, com inversa continuamente diferenciável e

$$\det \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \neq 0$$

para todo $\mathbf{x} \in \mathcal{D}$.

Então, para uma função integrável h ,

$$\int_{\mathcal{G}} h(\mathbf{y}) \, d\mathbf{y} = \int_{\mathcal{D}} h(\mathbf{g}(\mathbf{x})) |\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})| \, d\mathbf{x}.$$

(Apostol, 1969)

Utilizando a transformação inversa

$$\mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

tem-se

$$d\mathbf{x} = |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| \, d\mathbf{y}.$$

Como

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = [\mathbf{J}_{\mathbf{g}}(\mathbf{x})]^{-1},$$

segue que

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})| = \frac{1}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

7.11.7 Transformação de densidades

Teorema 7.22 (Densidade de uma transformação invertível). *Considere um vetor aleatório contínuo $\mathbf{X}$ com densidade $f_{\mathbf{X}}$ e a transformação*

$$\mathbf{Y} = \mathbf{g}(\mathbf{X}),$$

satisfazendo as condições do Teorema da Mudança de Variáveis.

Então,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y})) |\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y})|.$$

Equivalentemente, com

$$\mathbf{y} = \mathbf{g}(\mathbf{x}),$$

tem-se

$$f_{\mathbf{Y}}(\mathbf{g}(\mathbf{x})) = \frac{f_{\mathbf{X}}(\mathbf{x})}{|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|}.$$

A densidade é reduzida em regiões expandidas pela transformação e aumentada em regiões contraídas, de modo que a probabilidade total permaneça igual a 1.

Quando a transformação não é injetiva em todo o domínio, o domínio deve ser particionado em regiões de injetividade. As contribuições das diferentes pré-imagens são somadas.

7.11.8 Transformações afins

Considere

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

é invertível e

$$\mathbf{b} \in \mathbb{R}^p.$$

A transformação inversa é

$$\mathbf{X} = \mathbf{A}^{-1}(\mathbf{Y} - \mathbf{b}).$$

A Jacobiana da transformação é constante:

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{A}.$$

A Jacobiana da inversa é

$$\mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{y}) = \mathbf{A}^{-1}.$$

Logo,

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}[\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})] \frac{1}{|\det(\mathbf{A})|}.$$

A translação $\mathbf{b}$ altera a posição da distribuição, mas não altera o fator de volume. Esse fator depende apenas da parte linear.

Exemplo 7.22 (Transformação afim em uma dimensão). Considere

$$Y = aX + b,$$

com $a \neq 0$.

A transformação inversa é

$$X = \frac{Y - b}{a},$$

e

$$\left| \frac{dx}{dy} \right| = \frac{1}{|a|}.$$

Portanto,

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \frac{1}{|a|}.$$

7.11.9 Interpretação geométrica do determinante Jacobiano

Considere a transformação não linear

$$\mathbf{g}(x_1, x_2) = \begin{bmatrix} x_1 + 0.35x_1x_2 \\ x_2 + 0.20x_1^2 \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(x_1, x_2) = \begin{bmatrix} 1 + 0.35x_2 & 0.35x_1 \\ 0.40x_1 & 1 \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(x_1, x_2) = 1 + 0.35x_2 - 0.14x_1^2.$$

O fator de alteração de área varia de acordo com o ponto. A Figura 7.4 mostra uma grade no domínio e sua imagem pela transformação.




Figura 7.4: Transformação de uma grade e alteração local de área determinada pelo Jacobiano.

Uma pequena região em torno de $\mathbf{x}$ tem sua área multiplicada aproximadamente por

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|.$$

A imagem da grade apresenta expansão e contração diferentes ao longo do domínio porque o determinante Jacobiano não é constante.

7.11.10 Coordenadas polares

Em duas dimensões, defina

$$x_1 = r \cos \theta$$

e

$$x_2 = r \sin \theta,$$

com

$$r > 0$$

e

$$0 \leq \theta < 2\pi.$$

A transformação é

$$\mathbf{g}(r, \theta) = \begin{bmatrix} r \cos \theta \\ r \sin \theta \end{bmatrix}.$$

Sua Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(r, \theta) = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}.$$

O determinante é

$$\det \mathbf{J}_{\mathbf{g}}(r, \theta) = r.$$

Portanto,

$$dx_1 dx_2 = r dr d\theta.$$

Assim,

$$\iint_{\mathbb{R}^2} h(x_1, x_2) dx_1 dx_2 = \int_0^{2\pi} \int_0^\infty h(r \cos \theta, r \sin \theta) r dr d\theta,$$

quando a função é integrável.

O fator r representa o aumento da área dos setores à medida que a distância à origem cresce.

7.11.11 Transformações elipsoidais

Considere uma matriz positiva definida

$$\Sigma \in \mathbb{R}^{p \times p}$$

e uma transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

A Jacobiana é

$$\mathbf{J}_{\mathbf{g}}(\mathbf{z}) = \Sigma^{1/2}.$$

Logo,

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{z})| = \det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

A transformação inversa é

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

com fator

$$|\det \mathbf{J}_{\mathbf{g}^{-1}}(\mathbf{x})| = \det(\Sigma)^{-1/2}.$$

Além disso,

$$\begin{aligned} \mathbf{z}^\top \mathbf{z} &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \end{aligned}$$

A transformação converte esferas no espaço de $\mathbf{z}$ em elipsóides no espaço de $\mathbf{x}$. Essa relação será utilizada na construção de densidades multivariadas.

7.11.12 Diferenciação sob o sinal de integração

Considere um conjunto mensurável

$$\mathcal{D} \subseteq \mathbb{R}^p,$$

uma região aberta

$$\mathcal{V} \subseteq \mathbb{R}^k$$

e uma função

$$h : \mathcal{D} \times \mathcal{V} \longrightarrow \mathbb{R}.$$

A função depende da variável de integração $\mathbf{x}$ e do parâmetro

$$\theta \in \mathcal{V}.$$

Defina

$$F(\theta) = \int_{\mathcal{D}} h(\mathbf{x}, \theta) d\mathbf{x}.$$

A troca entre diferenciação e integração pode ser justificada pelo Teorema da Convergência Dominada.

Teorema 7.23 (Teorema da Convergência Dominada). *Considere uma sequência de funções mensuráveis*

$$g_1, g_2, \dots$$

definidas em $\mathcal{D}$ e suponha que

$$g_m(\mathbf{x}) \longrightarrow g(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

Se existe uma função integrável

$$M : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$|g_m(\mathbf{x})| \leq M(\mathbf{x})$$

para todo m e quase todo $\mathbf{x} \in \mathcal{D}$, então g é integrável e

$$\lim_{m \rightarrow \infty} \int_{\mathcal{D}} g_m(\mathbf{x}) d\mathbf{x} = \int_{\mathcal{D}} g(\mathbf{x}) d\mathbf{x}.$$

(Axler, 2020)

O teorema permite trocar um limite e uma integral quando todas as funções da sequência são dominadas por uma mesma função integrável. A diferenciação sob o sinal de integração decorre da aplicação desse resultado aos quocientes de diferenças.

Teorema 7.24 (Diferenciação sob o sinal de integração). *Considere um ponto*

$$\theta_0 \in \mathcal{V}$$

e uma componente

$$j \in \{1, \dots, k\}.$$

Suponha que:

1. para todo $\theta \in \mathcal{V}$, a função

$$\mathbf{x} \mapsto h(\mathbf{x}, \theta)$$

seja mensurável e integrável em $\mathcal{D}$;

2. exista $\delta > 0$ tal que

$$\theta_0 + t\mathbf{e}_j \in \mathcal{V}$$

para todo t com $|t| < \delta$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica de $\mathbb{R}^k$;

3. para quase todo $\mathbf{x} \in \mathcal{D}$, a função

$$t \mapsto h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)$$

seja diferenciável em $(-\delta, \delta)$;

4. exista uma função integrável

$$M_j : \mathcal{D} \longrightarrow [0, \infty)$$

tal que

$$\left| \frac{\partial h(\mathbf{x}, \theta_0 + t\mathbf{e}_j)}{\partial \theta_j} \right| \leq M_j(\mathbf{x})$$

para todo t com $|t| < \delta$ e quase todo $\mathbf{x} \in \mathcal{D}$;

5. a função

$$\mathbf{x} \mapsto \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}$$

seja mensurável.

Então, F é parcialmente diferenciável em relação a θ_j no ponto θ_0 e

$$\frac{\partial F(\theta_0)}{\partial \theta_j} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Comprovação. Considere uma sequência arbitrária de números não nulos

$$t_1, t_2, \dots$$

tal que

$$t_m \longrightarrow 0$$

e

$$|t_m| < \delta.$$

Defina o quociente de diferenças

$$q_m(\mathbf{x}) = \frac{h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) - h(\mathbf{x}, \theta_0)}{t_m}.$$

Para quase todo $\mathbf{x} \in \mathcal{D}$, a diferenciabilidade em relação a θ_j implica

$$q_m(\mathbf{x}) \longrightarrow \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j}.$$

Pelo Teorema do Valor Médio aplicado à função

$$t \longmapsto h(\mathbf{x}, \theta_0 + t \mathbf{e}_j),$$

existe um número $\xi_m(\mathbf{x})$ situado entre 0 e t_m tal que

$$q_m(\mathbf{x}) = \frac{\partial h(\mathbf{x}, \theta_0 + \xi_m(\mathbf{x}) \mathbf{e}_j)}{\partial \theta_j}.$$

Como

$$|\xi_m(\mathbf{x})| < \delta,$$

a hipótese de dominação fornece

$$|q_m(\mathbf{x})| \leq M_j(\mathbf{x})$$

para quase todo $\mathbf{x} \in \mathcal{D}$.

O Teorema da Convergência Dominada implica

$$\begin{aligned} \lim_{m \rightarrow \infty} \int_{\mathcal{D}} q_m(\mathbf{x}) \, d\mathbf{x} &= \int_{\mathcal{D}} \lim_{m \rightarrow \infty} q_m(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} \, d\mathbf{x}. \end{aligned}$$

Por outro lado,

$$\begin{aligned}\int_{\mathcal{D}} q_m(\mathbf{x}) d\mathbf{x} &= \frac{\int_{\mathcal{D}} h(\mathbf{x}, \theta_0 + t_m \mathbf{e}_j) d\mathbf{x} - \int_{\mathcal{D}} h(\mathbf{x}, \theta_0) d\mathbf{x}}{t_m} \\ &= \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m}.\end{aligned}$$

Logo,

$$\lim_{m \rightarrow \infty} \frac{F(\theta_0 + t_m \mathbf{e}_j) - F(\theta_0)}{t_m} = \int_{\mathcal{D}} \frac{\partial h(\mathbf{x}, \theta_0)}{\partial \theta_j} d\mathbf{x}.$$

Como a sequência $t_m \rightarrow 0$ foi escolhida arbitrariamente, a derivada parcial existe e satisfaz a igualdade enunciada. $\square$

Quando as condições do Teorema 7.24 são satisfeitas para todas as componentes do parâmetro,

$$\nabla_{\theta} F(\theta_0) = \int_{\mathcal{D}} \nabla_{\theta} h(\mathbf{x}, \theta_0) d\mathbf{x}.$$

A função dominante pode ser diferente para cada componente do gradiente, desde que cada uma seja integrável.

O resultado pressupõe que o domínio $\mathcal{D}$ não depende de θ . Quando o domínio ou a fronteira da região de integração varia com o parâmetro, a derivação pode produzir termos adicionais. Esse caso não será desenvolvido neste capítulo.

Exemplo 7.23 (Derivação de uma identidade de normalização). Considere uma família de densidades

$$f(\mathbf{x}; \theta),$$

definida sobre um suporte comum

$$\mathcal{D}$$

que não depende de θ .

Para todo θ ,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} = 1.$$

Suponha que as condições do Teorema 7.24 sejam satisfeitas para todas as componentes de θ . Então,

$$\begin{aligned}\mathbf{0} &= \nabla_{\theta} 1 \\ &= \nabla_{\theta} \int_{\mathcal{D}} f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int_{\mathcal{D}} \nabla_{\theta} f(\mathbf{x}; \theta) d\mathbf{x}.\end{aligned}$$

Se

$$f(\mathbf{x}; \theta) > 0$$

para quase todo $\mathbf{x} \in \mathcal{D}$, então

$$\nabla_{\theta} f(\mathbf{x}; \theta) = f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta).$$

Portanto,

$$\int_{\mathcal{D}} f(\mathbf{x}; \theta) \nabla_{\theta} \log f(\mathbf{x}; \theta) d\mathbf{x} = \mathbf{0}.$$

Se

X

possui densidade $f(\mathbf{x}; \theta)$, segue que

$$E_{\theta} [\nabla_{\theta} \log f(\mathbf{X}; \theta)] = \mathbf{0}.$$

Essa é a identidade de média nula do escore para uma observação. Sua validade depende do suporte comum e das condições de dominação que justificam a troca entre diferenciação e integração.

As integrais múltiplas, a marginalização e a mudança de variáveis fornecem a base para o estudo das distribuições multivariadas. A diferenciação sob o sinal de integração conecta essas ferramentas às funções de verossimilhança, ao vetor escore e à informação de Fisher.

7.12 Aplicações à estimação e à inferência

As ferramentas de diferenciação permitem formular condições de estimação, construir aproximações locais e estudar transformações de estimadores. Nesta seção, essas aplicações serão apresentadas apenas em sua estrutura matemática.

7.12.1 Log-verossimilhança e vetor escore

Considere uma amostra

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

de uma distribuição com função de densidade ou de probabilidade

$$f(\mathbf{x}; \theta),$$

em que

$$\theta \in \Theta \subseteq \mathbb{R}^k$$

é o vetor de parâmetros.

Sob independência, a função de verossimilhança é

$$L_n(\theta) = \prod_{i=1}^n f(\mathbf{x}_i; \theta).$$

A log-verossimilhança é

$$\ell_n(\theta) = \log L_n(\theta) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta).$$

Como o logaritmo é estritamente crescente, maximizar L_n equivale a maximizar ℓ_n .

Definição 7.15 (Vetor escore). O vetor escore é o gradiente da log-verossimilhança:

$$\mathbf{s}_n(\theta) = \nabla_{\theta} \ell_n(\theta) \in \mathbb{R}^k.$$

Em coordenadas,

$$\mathbf{s}_n(\theta) = \begin{bmatrix} \frac{\partial \ell_n}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ell_n}{\partial \theta_k} \end{bmatrix}.$$

Um estimador de máxima verossimilhança interior deve satisfazer

$$\mathbf{s}_n(\hat{\theta}) = \mathbf{0}.$$

Essa condição é necessária, mas pode não ser suficiente para identificar um máximo. Também devem ser examinados:

- a curvatura da log-verossimilhança;
- a existência e a unicidade da solução;
- os limites do espaço paramétrico;
- possíveis máximos na fronteira.

7.12.2 Informação observada e informação de Fisher

Definição 7.16 (Informação observada). A matriz de informação observada é

$$\mathcal{J}_n(\theta) = -\nabla_{\theta}^2 \ell_n(\theta).$$

Quando

$$\mathcal{J}_n(\hat{\theta}) \succ \mathbf{0},$$

a Hessiana da log-verossimilhança é negativa definida no ponto estimado, fornecendo uma condição suficiente de máximo local estrito.

A informação observada pode ser singular ou apenas semidefinida quando:

- há parâmetros não identificados;
- existem redundâncias na parametrização;
- o máximo ocorre na fronteira;
- a log-verossimilhança apresenta pouca curvatura em determinadas direções.

Definição 7.17 (Informação de Fisher). A informação de Fisher é definida por

$$\mathcal{J}_n(\theta) = E_\theta [\mathcal{J}_n(\theta)],$$

quando essa esperança existe. (Casella; Berger, 2002)

Sob condições que permitem diferenciar a densidade sob o sinal de integração,

$$E_\theta [\mathbf{s}_n(\theta)] = \mathbf{0}.$$

Sob condições adicionais de regularidade,

$$\mathcal{J}_n(\theta) = E_\theta [\mathbf{s}_n(\theta)\mathbf{s}_n(\theta)^\top].$$

Essa identidade não deve ser utilizada sem verificar as condições de regularidade e a independência do suporte em relação ao parâmetro.

7.12.3 Newton–Raphson

A estimação por máxima verossimilhança pode exigir a solução numérica de

$$\mathbf{s}_n(\theta) = \mathbf{0}.$$

A expansão de primeira ordem do escore em torno de um valor atual $\theta^{(t)}$ é

$$\mathbf{s}_n(\theta) \approx \mathbf{s}_n(\theta^{(t)}) + \nabla_\theta^2 \ell_n(\theta^{(t)}) (\theta - \theta^{(t)}).$$

Igualando a aproximação a zero,

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - [\nabla_\theta^2 \ell_n(\theta^{(t)})]^{-1} \mathbf{s}_n(\theta^{(t)}) \\ &= \theta^{(t)} + \mathcal{J}_n(\theta^{(t)})^{-1} \mathbf{s}_n(\theta^{(t)}). \end{aligned}$$

Na implementação, a atualização deve ser obtida pela solução do sistema

$$\mathcal{J}_n(\theta^{(t)}) \mathbf{d}^{(t)} = -\mathbf{s}_n(\theta^{(t)}),$$

seguida de

$$\theta^{(t+1)} = \theta^{(t)} + \mathbf{d}^{(t)}.$$

Isso evita calcular explicitamente a inversa da informação observada.

7.12.4 Método do escore de Fisher

O método do escore de Fisher substitui a informação observada pela informação esperada:

$$\theta^{(t+1)} = \theta^{(t)} + \mathcal{J}_n \left(\theta^{(t)} \right)^{-1} \mathbf{s}_n \left(\theta^{(t)} \right).$$

Os dois métodos coincidem quando

$$\mathcal{J}_n(\theta) = \mathcal{J}_n(\theta)$$

ou quando essas matrizes produzem a mesma atualização.

7.12.5 Expansão local de um estimador

Suponha que um estimador

$$\hat{\theta}$$

satisfaça a equação

$$\mathbf{s}_n \left(\hat{\theta} \right) = \mathbf{0}.$$

Expandindo o escore em torno do parâmetro verdadeiro θ_0 ,

$$\begin{aligned} \mathbf{0} &= \mathbf{s}_n \left(\hat{\theta} \right) \\ &\approx \mathbf{s}_n \left(\theta_0 \right) + \nabla_{\theta}^2 \ell_n \left(\theta_0 \right) \left(\hat{\theta} - \theta_0 \right). \end{aligned}$$

Como

$$\nabla_{\theta}^2 \ell_n \left(\theta_0 \right) = -\mathcal{J}_n \left(\theta_0 \right),$$

obtém-se a aproximação

$$\hat{\theta} - \theta_0 \approx \mathcal{J}_n(\theta_0)^{-1} \mathbf{s}_n(\theta_0).$$

Essa relação mostra que o erro do estimador pode ser aproximado pelo produto entre:

- a inversa da curvatura da log-verossimilhança;
- o escore calculado no parâmetro verdadeiro.

A obtenção de uma distribuição assintótica exige resultados probabilísticos adicionais sobre consistência, convergência da informação e distribuição limite do escore.

7.12.6 Método delta

O método delta utiliza a aproximação de Taylor para obter a distribuição aproximada de uma transformação de um estimador.

Teorema 7.25 (Método delta multivariado). *Suponha que*

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_k(\mathbf{0}, \Xi),$$

em que

$$\Xi \in \mathbb{R}^{k \times k}.$$

Considere uma função diferenciável

$$\mathbf{g} : \mathbb{R}^k \longrightarrow \mathbb{R}^q.$$

Então,

$$\sqrt{n}[\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta)] \xrightarrow{d} N_q(\mathbf{0}, \mathbf{J}_{\mathbf{g}}(\theta)\Xi\mathbf{J}_{\mathbf{g}}(\theta)^\top).$$

(Vaart, 1998)

A aproximação de primeira ordem é

$$\mathbf{g}(\hat{\theta}) - \mathbf{g}(\theta) \approx \mathbf{J}_{\mathbf{g}}(\theta) (\hat{\theta} - \theta).$$

A covariância aproximada é

$$\text{Cov} [\mathbf{g}(\hat{\theta})] \approx \frac{1}{n} \mathbf{J}_{\mathbf{g}}(\theta) \Xi \mathbf{J}_{\mathbf{g}}(\theta)^{\top}.$$

Para uma função escalar

$$g : \mathbb{R}^k \longrightarrow \mathbb{R},$$

a variância aproximada é

$$\text{Var} [g(\hat{\theta})] \approx \frac{1}{n} \nabla_{\theta} g(\theta)^{\top} \Xi \nabla_{\theta} g(\theta).$$

Exemplo 7.24 (Método delta para uma razão). Considere

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \quad \theta_2 \neq 0,$$

e

$$g(\theta) = \frac{\theta_1}{\theta_2}.$$

O gradiente é

$$\nabla_{\theta} g = \begin{bmatrix} \frac{1}{\theta_2} \\ \frac{\theta_1}{\theta_2^2} \\ -\frac{\theta_1}{\theta_2^2} \end{bmatrix}.$$

Se

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_2(\mathbf{0}, \Xi),$$

então

$$\sqrt{n} \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$$

converge em distribuição para uma normal com variância

$$\nabla_{\theta} g^{\top} \Xi \nabla_{\theta} g.$$

7.12.7 Estimação de um vetor de médias

Considere observações

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

e uma matriz positiva definida conhecida

$$\Sigma.$$

Considere o critério

$$Q(\mu) = \sum_{i=1}^n (\mathbf{x}_i - \mu)^{\top} \Sigma^{-1} (\mathbf{x}_i - \mu).$$

O gradiente é

$$\nabla_{\mu} Q = -2\Sigma^{-1} \sum_{i=1}^n (\mathbf{x}_i - \mu).$$

A condição de primeira ordem é

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}.$$

Logo,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

A Hessiana é

$$\nabla_{\mu}^2 Q = 2n\Sigma^{-1} \succ \mathbf{0}.$$

Portanto, o vetor de médias amostrais é o único minimizador do critério.

7.12.8 Critério do modelo linear multivariado

Considere

$$\mathbf{Y} = \mathbf{XB} + \mathcal{E},$$

com

$$\mathbf{Y} \in \mathbb{R}^{n \times p}, \quad \mathbf{X} \in \mathbb{R}^{n \times k}, \quad \mathbf{B} \in \mathbb{R}^{k \times p}.$$

Para

$$\Sigma \succ \mathbf{0},$$

considere

$$\begin{aligned} L(\mathbf{B}, \Sigma) &= \frac{n}{2} \log \det(\Sigma) \\ &\quad + \frac{1}{2} \operatorname{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{XB})^{\top} (\mathbf{Y} - \mathbf{XB}) \right]. \end{aligned}$$

Para Σ fixada,

$$\nabla_{\mathbf{B}} L = -\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) \Sigma^{-1}.$$

A condição de primeira ordem é

$$\mathbf{X}^{\top} (\mathbf{Y} - \mathbf{XB}) = \mathbf{0}.$$

Se $\mathbf{X}$ possui posto coluna completo,

$$\widehat{\mathbf{B}} = (\mathbf{X}^{\top} \mathbf{X})^{-1} \mathbf{X}^{\top} \mathbf{Y}.$$

Defina a matriz de Gram dos resíduos

$$\mathbf{G}_{\mathcal{E}} = (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}})^{\top} (\mathbf{Y} - \mathbf{X}\widehat{\mathbf{B}}).$$

Para $\mathbf{B} = \widehat{\mathbf{B}}$, o critério em relação a Σ é

$$L(\Sigma) = \frac{n}{2} \log \det(\Sigma) + \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{G}_{\mathcal{E}}).$$

Se

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0},$$

o minimizador interior é

$$\widehat{\Sigma} = \frac{1}{n} \mathbf{G}_{\mathcal{E}}.$$

A condição

$$\mathbf{G}_{\mathcal{E}} \succ \mathbf{0}$$

exige que a matriz residual possua posto coluna completo. Quando $\mathbf{G}_{\mathcal{E}}$ é singular, o critério não possui minimizador no interior do conjunto das matrizes positivas definidas.

A interpretação probabilística desse critério e as propriedades dos estimadores serão desenvolvidas nos capítulos de estimação e modelo linear multivariado.

7.13 Síntese do capítulo

O cálculo diferencial descreve a variação local de funções escalares, vetoriais e matriciais. Para uma função escalar de vetor, o gradiente determina a aproximação linear:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^{\top} \mathbf{h} + o(\|\mathbf{h}\|).$$

A Jacobiana representa a transformação linear local de uma função vetorial:

$$\mathbf{g}(\mathbf{x} + \mathbf{h}) = \mathbf{g}(\mathbf{x}) + \mathbf{J}_{\mathbf{g}}(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|).$$

A Hessiana descreve a curvatura de uma função escalar. Em um ponto estacionário, sua definitude permite distinguir mínimos, máximos e pontos de sela. Para funções convexas, qualquer ponto estacionário é um mínimo global.

A diferenciação de funções de resíduos conduz às equações normais. Para

$$f(\mathbf{x}) = \|\mathbf{b} - \mathbf{Ax}\|^2,$$

tem-se

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{Ax}),$$

e a condição de primeira ordem é

$$\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}.$$

O cálculo matricial organiza derivadas de funções cujos argumentos são matrizes. O gradiente matricial é definido por

$$d\phi = \text{tr} \left[(\nabla_{\mathbf{X}} \phi)^\top d\mathbf{X} \right].$$

Essa representação permite diferenciar normas de Frobenius, funções de resíduos matriciais, produtos quadráticos, inversas, determinantes e log-determinantes.

A vetorização transforma uma matriz em um vetor e permite representar transformações matriciais por produtos de Kronecker:

$$\text{vec}(\mathbf{AX}\Gamma) = (\Gamma^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}).$$

Para matrizes simétricas, o operador vech elimina elementos repetidos. As matrizes de duplicação e eliminação relacionam as parametrizações por vec e vech.

O cálculo integral fornece probabilidades, esperanças e distribuições marginais. A mudança de variáveis incorpora o fator

$$|\det \mathbf{J}_{\mathbf{g}}(\mathbf{x})|,$$

que representa a alteração local de volume produzida pela transformação.

Na estimação, o gradiente da log-verossimilhança define o vetor escore, enquanto sua Hessiana negativa define a informação observada. Expansões de Taylor sustentam métodos iterativos de estimação e aproximações como o método delta.

A Tabela 7.2 reúne algumas das identidades utilizadas ao longo do capítulo.

Tabela 7.2: Identidades selecionadas de cálculo vetorial e matricial.

Função	Derivada ou diferencial
$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$	$\nabla_{\mathbf{x}} f = \mathbf{a}$
$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$	$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$
$f(\mathbf{x}) = \ \mathbf{b} - \mathbf{A} \mathbf{x}\ ^2$	$\nabla_{\mathbf{x}} f = -2\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \mathbf{x})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A}$
$\phi(\mathbf{X}) = \ \mathbf{X}\ _F^2$	$\nabla_{\mathbf{X}} \phi = 2\mathbf{X}$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X} \mathbf{\Gamma})$	$\nabla_{\mathbf{X}} \phi = \mathbf{A} \mathbf{X} \mathbf{\Gamma} + \mathbf{A}^\top \mathbf{X} \mathbf{\Gamma}^\top$
$\mathbf{X} \mapsto \mathbf{X}^{-1}$	$d(\mathbf{X}^{-1}) = -\mathbf{X}^{-1} (d\mathbf{X}) \mathbf{X}^{-1}$
$\phi(\mathbf{X}) = \log \det(\mathbf{X}), \mathbf{X} \succ \mathbf{0}$	$d\phi = \text{tr}(\mathbf{X}^{-1} d\mathbf{X})$
$\phi(\mathbf{X}) = \text{tr}(\mathbf{A} \mathbf{X}^{-1})$	$\nabla_{\mathbf{X}} \phi = -\mathbf{X}^{-\top} \mathbf{A}^\top \mathbf{X}^{-\top}$
$\mathbf{Y} = \mathbf{A} \mathbf{X} \mathbf{\Gamma}$	$\text{vec}(\mathbf{Y}) = (\mathbf{\Gamma}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$

Ao final do capítulo, o estudante deverá ser capaz de:

- distinguir gradiente, Jacobiana, Hessiana e gradiente matricial;
- construir aproximações de Taylor de primeira e segunda ordens;
- classificar pontos estacionários por meio da Hessiana;
- reconhecer condições de convexidade e concavidade;
- formular condições de primeira ordem em problemas com e sem restrições;
- diferenciar formas quadráticas, critérios de resíduos e funções matriciais;
- utilizar diferenciais de inversas, determinantes e log-determinantes;
- aplicar vetorização, produto de Kronecker e meia vetorização;
- interpretar o determinante Jacobiano em mudanças de variáveis;
- reconhecer o papel do cálculo em problemas de estimação e inferência.

O próximo capítulo inicia o estudo probabilístico dos dados multivariados por meio das matrizes de covariâncias e correlações. Essas matrizes combinam expectativas, produtos cruzados, formas quadráticas e transformações lineares, reunindo os principais objetos desenvolvidos ao longo do Módulo 1.

Parte II

Módulo II — Fundamentos Probabilísticos e Inferenciais da Análise Multivariada

8 Matrizes de covariâncias e correlações

A variância descreve a dispersão de uma variável em torno de sua média. Quando várias variáveis são observadas conjuntamente, também é necessário representar como suas variações se relacionam. A análise separada das variâncias não registra se duas componentes tendem a aumentar juntas, se variam em sentidos opostos ou se apresentam redundância linear.

A matriz de covariâncias reúne as variâncias individuais e as covariâncias entre todos os pares de componentes de um vetor aleatório. Sua estrutura permite calcular a variância de combinações lineares, identificar relações lineares entre variáveis e definir uma geometria ajustada à dispersão da população (Johnson; Wichern, 2007).

A matriz de correlações resulta da padronização das variáveis. Ela expressa as associações lineares em uma escala adimensional, permitindo comparar variáveis originalmente medidas em unidades distintas.

O objetivo deste capítulo é desenvolver essas estruturas nos níveis populacional e descritivo amostral. As propriedades inferenciais das estatísticas amostrais serão estudadas no Capítulo 10, enquanto a distribuição normal multivariada, apresentada no próximo capítulo, permitirá atribuir interpretações probabilísticas adicionais aos objetos geométricos construídos aqui.

8.1 Momentos, centralização e covariância

8.1.1 Vetor de médias e centralização

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p.$$

Uma realização de $\mathbf{X}$ será representada por $\mathbf{x} \in \mathbb{R}^p$. Uma coleção de n realizações observadas será posteriormente organizada em uma matriz de dados $\mathbf{X} \in \mathbb{R}^{n \times p}$.

Admitindo que as esperanças das componentes existam, o vetor de médias populacional é

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}.$$

O vetor $\mu \in \mathbb{R}^p$ representa a posição média da distribuição no espaço das observações.

A versão centralizada do vetor aleatório é definida por

$$\mathbf{X}_c = \mathbf{X} - \mu.$$

Pela linearidade da esperança,

$$\begin{aligned} E(\mathbf{X}_c) &= E(\mathbf{X} - \mu) \\ &= E(\mathbf{X}) - \mu \\ &= \mathbf{0}. \end{aligned}$$

A centralização desloca o centro da distribuição para a origem. Como o mesmo vetor é subtraído de todas as realizações, as diferenças entre pares de pontos permanecem inalteradas:

$$(\mathbf{x}_i - \mu) - (\mathbf{x}_j - \mu) = \mathbf{x}_i - \mathbf{x}_j.$$

Consequentemente, a centralização modifica a posição da distribuição, mas preserva as distâncias entre suas realizações e sua estrutura de dispersão.

8.1.2 Momentos de segunda ordem

A análise das variâncias e covariâncias exige a existência de momentos de segunda ordem. Neste capítulo, assume-se que

$$E(X_j^2) < \infty, \quad j = 1, \dots, p.$$

Essa condição garante a existência dos produtos cruzados esperados. Para quaisquer componentes X_j e X_k , a desigualdade de Cauchy–Schwarz fornece

$$E(|X_j X_k|) \leq \sqrt{E(X_j^2)E(X_k^2)} < \infty.$$

A matriz de segundos momentos em relação à origem é

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

O produto externo presente nessa expressão é

$$\mathbf{X}\mathbf{X}^\top = \begin{bmatrix} X_1^2 & X_1X_2 & \cdots & X_1X_p \\ X_2X_1 & X_2^2 & \cdots & X_2X_p \\ \vdots & \vdots & \ddots & \vdots \\ X_pX_1 & X_pX_2 & \cdots & X_p^2 \end{bmatrix}.$$

Portanto,

$$\mathbf{M}_2 = \begin{bmatrix} E(X_1^2) & E(X_1X_2) & \cdots & E(X_1X_p) \\ E(X_2X_1) & E(X_2^2) & \cdots & E(X_2X_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(X_pX_1) & E(X_pX_2) & \cdots & E(X_p^2) \end{bmatrix}.$$

A matriz $\mathbf{M}_2$ utiliza a origem como referência. Por esse motivo, ela combina informações sobre a posição e a dispersão da distribuição.

A dispersão em torno do vetor de médias é descrita pelo segundo momento central:

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Expandindo o produto,

$$\begin{aligned} \Sigma &= E[\mathbf{X}\mathbf{X}^\top - \mathbf{X}\mu^\top - \mu\mathbf{X}^\top + \mu\mu^\top] \\ &= E(\mathbf{X}\mathbf{X}^\top) - E(\mathbf{X})\mu^\top - \mu E(\mathbf{X})^\top + \mu\mu^\top. \end{aligned}$$

Como $E(\mathbf{X}) = \mu$, segue que

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top. \quad (8.1)$$

A identidade Equação 8.1 generaliza a relação univariada

$$\text{Var}(X) = E(X^2) - [E(X)]^2.$$

A diferença entre $\mathbf{M}_2$ e Σ está no ponto utilizado como referência. A matriz $\mathbf{M}_2$ mede produtos em relação à origem, enquanto Σ mede a dispersão em relação à média.

Exemplo 8.1 (Matriz de segundos momentos e covariância). Considere

$$\mu = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

e

$$\mathbf{M}_2 = \begin{bmatrix} 6 & 3 \\ 3 & 3 \end{bmatrix}.$$

O produto externo do vetor de médias é

$$\mu\mu^\top = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}.$$

Pela identidade Equação 8.1,

$$\begin{aligned} \Sigma &= \mathbf{M}_2 - \mu\mu^\top \\ &= \begin{bmatrix} 6 & 3 \\ 3 & 3 \end{bmatrix} - \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \end{aligned}$$

Os elementos diagonais representam as variâncias das duas componentes. Os elementos fora da diagonal registram sua covariância.

8.1.3 Covariância entre duas variáveis

Considere duas variáveis aleatórias X e Y , definidas no mesmo espaço de probabilidade, com médias

$$\mu_X = E(X) \quad \text{e} \quad \mu_Y = E(Y).$$

Definição 8.1 (Covariância populacional). Se $E(X^2) < \infty$ e $E(Y^2) < \infty$, a covariância populacional entre X e Y é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

A covariância é a esperança do produto dos desvios das duas variáveis em relação às respectivas médias. Seu sinal descreve o sentido predominante da associação linear:

- uma covariância positiva ocorre quando desvios de mesmo sinal tendem a aparecer conjuntamente;
- uma covariância negativa ocorre quando desvios de sinais opostos tendem a aparecer conjuntamente;
- uma covariância nula indica ausência de associação linear líquida.

A Figura 8.1 apresenta três configurações com covariâncias positiva, aproximadamente nula e negativa.




Figura 8.1: Padrões de dispersão associados ao sinal da covariância.

O sinal da covariância resume o sentido da associação linear. Ele não descreve sozinho a intensidade da associação nem todas as características da distribuição conjunta.

Expandindo o produto dos desvios,

$$\begin{aligned}
 \text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\
 &= E(XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y) \\
 &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y.
 \end{aligned}$$

Como $E(X) = \mu_X$ e $E(Y) = \mu_Y$,

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y). \quad (8.2)$$

A expressão Equação 8.2 mostra que a covariância é a diferença entre o momento conjunto $E(XY)$ e o produto dos momentos individuais.

Quando as duas variáveis coincidem,

$$\text{Cov}(X, X) = E[(X - \mu_X)^2] = \text{Var}(X).$$

A covariância também é simétrica:

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Para constantes a , b , c e d ,

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y). \quad (8.3)$$

A identidade Equação 8.3 mostra que translações não alteram a covariância. Mudanças de escala multiplicam seu valor pelo produto dos fatores aplicados às duas variáveis.

Essa dependência das unidades impede a comparação direta entre covariâncias calculadas para pares de variáveis em escalas distintas. Se uma variável medida em metros for convertida para centímetros, sua covariância com qualquer outra variável será multiplicada por 100.

Pela desigualdade de Cauchy–Schwarz,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}. \quad (8.4)$$

O limite Equação 8.4 será utilizado na definição da correlação, que remove o efeito das escalas individuais.

Covariância nula e independência

A covariância nula indica ausência de associação linear líquida. Ela não implica independência em uma distribuição geral. Relações não lineares podem produzir covariância igual a zero.

Exemplo 8.2 (Dependência não linear com covariância nula). Considere

$$X \sim \text{Uniforme}(-2, 2)$$

e

$$Y = X^2 + \varepsilon,$$

em que ε é independente de X e possui média zero.

A simetria da distribuição de X em torno de zero implica

$$E(X) = 0 \quad \text{e} \quad E(X^3) = 0.$$

Além disso,

$$E(X\varepsilon) = E(X)E(\varepsilon) = 0.$$

Portanto,

$$\begin{aligned} \text{Cov}(X, Y) &= \text{Cov}(X, X^2 + \varepsilon) \\ &= E(X^3) + E(X\varepsilon) - E(X)E(Y) \\ &= 0. \end{aligned}$$

Apesar da covariância nula, X e Y não são independentes, pois

$$E(Y \mid X = x) = x^2.$$

A Figura 8.2 ilustra essa relação.

A configuração parabólica evidencia uma relação entre as variáveis que não é registrada pela covariância. Esse exemplo delimita a interpretação da covariância como medida de associação linear.

As variâncias das componentes e as covariâncias entre todos os pares de variáveis serão reunidas, na seção seguinte, em uma única matriz populacional.

8.2 Matriz de covariâncias populacional

8.2.1 Definição e interpretação dos elementos

A covariância entre duas variáveis pode ser estendida simultaneamente a todas as componentes de um vetor aleatório.

Definição 8.2 (Matriz de covariâncias populacional). Seja

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$




Figura 8.2: Dependência não linear com covariância aproximadamente nula na amostra simulada.

com vetor de médias

$$\mu = E(\mathbf{X}),$$

e suponha que $E(X_j^2) < \infty$ para $j = 1, \dots, p$. A **matriz de covariâncias populacional** de $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top]. \quad (8.5)$$

A matriz Σ pertence a $\mathbb{R}^{p \times p}$.

O vetor de desvios em relação à média é

$$\mathbf{X} - \mu = \begin{bmatrix} X_1 - \mu_1 \\ X_2 - \mu_2 \\ \vdots \\ X_p - \mu_p \end{bmatrix}.$$

Seu produto externo $(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top$ é

$$\begin{bmatrix} (X_1 - \mu_1)^2 & (X_1 - \mu_1)(X_2 - \mu_2) & \cdots & (X_1 - \mu_1)(X_p - \mu_p) \\ (X_2 - \mu_2)(X_1 - \mu_1) & (X_2 - \mu_2)^2 & \cdots & (X_2 - \mu_2)(X_p - \mu_p) \\ \vdots & \vdots & \ddots & \vdots \\ (X_p - \mu_p)(X_1 - \mu_1) & (X_p - \mu_p)(X_2 - \mu_2) & \cdots & (X_p - \mu_p)^2 \end{bmatrix}.$$

Aplicando a esperança a cada elemento, obtém-se

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_p, X_1) & \text{Cov}(X_p, X_2) & \cdots & \text{Var}(X_p) \end{bmatrix}. \quad (8.6)$$

O elemento situado na linha j e na coluna k é

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j, k = 1, \dots, p.$$

Assim,

$$\Sigma = (\sigma_{jk})_{p \times p}.$$

Os elementos da diagonal principal são as variâncias:

$$\sigma_{jj} = \text{Var}(X_j), \quad j = 1, \dots, p.$$

Os elementos fora da diagonal são as covariâncias entre componentes distintas:

$$\sigma_{jk} = \text{Cov}(X_j, X_k), \quad j \neq k.$$

A unidade de cada elemento depende das variáveis envolvidas. Se X_j é medida na unidade u_j e X_k na unidade u_k , então

$$\sigma_{jj} \text{ é medida em } u_j^2,$$

enquanto

$$\sigma_{jk} \text{ é medida em } u_j u_k.$$

Essa dependência das unidades dificulta a comparação direta entre covariâncias de pares distintos de variáveis.

Como

$$\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j),$$

os elementos satisfazem

$$\sigma_{jk} = \sigma_{kj}.$$

Portanto, a matriz é determinada por seus elementos diagonais e por uma de suas partes triangulares. Para p variáveis, existem

$$p$$

variâncias e

$$\frac{p(p-1)}{2}$$

covariâncias distintas. O número total de elementos distintos é

$$p + \frac{p(p-1)}{2} = \frac{p(p+1)}{2}.$$

8.2.2 Variâncias e covariâncias de combinações lineares

Uma combinação linear das componentes de $\mathbf{X}$ é uma variável aleatória da forma

$$Y = \mathbf{a}^\top \mathbf{X},$$

em que

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} \in \mathbb{R}^p.$$

A combinação pode ser escrita como

$$Y = a_1 X_1 + a_2 X_2 + \cdots + a_p X_p.$$

O vetor $\mathbf{a}$ especifica os pesos atribuídos às componentes e define uma direção no espaço das variáveis.

Teorema 8.1 (Momentos de combinações lineares). *Seja $\mathbf{X} \in \mathbb{R}^p$ um vetor aleatório com média μ e matriz de covariâncias Σ . Para quaisquer vetores fixos $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$,*

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu, \quad (8.7)$$

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a} \quad (8.8)$$

e

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{b}. \quad (8.9)$$

Comprovação. Pela linearidade da esperança,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top E(\mathbf{X}) = \mathbf{a}^\top \mu.$$

A variável centralizada correspondente é

$$\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \mu = \mathbf{a}^\top (\mathbf{X} - \mu).$$

Portanto,

$$\begin{aligned}
\text{Var}(\mathbf{a}^\top \mathbf{X}) &= E\left[\{\mathbf{a}^\top (\mathbf{X} - \mu)\}^2\right] \\
&= E\left[\mathbf{a}^\top (\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top \mathbf{a}\right] \\
&= \mathbf{a}^\top E\left[(\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top\right] \mathbf{a} \\
&= \mathbf{a}^\top \Sigma \mathbf{a}.
\end{aligned}$$

De forma semelhante,

$$\begin{aligned}
\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{X}) &= E\left[\mathbf{a}^\top (\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top \mathbf{b}\right] \\
&= \mathbf{a}^\top \Sigma \mathbf{b}.
\end{aligned}$$

□

A expressão Equação 8.8 mostra que a matriz de covariâncias determina a variabilidade em qualquer direção definida por $\mathbf{a}$. Desenvolvendo a forma quadrática,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sum_{j=1}^p a_j^2 \sigma_{jj} + 2 \sum_{j < k} a_j a_k \sigma_{jk}.$$

A variância de uma combinação linear depende das variâncias individuais e das covariâncias entre as componentes. Ignorar os elementos fora da diagonal equivale a desconsiderar a contribuição das associações lineares para a variabilidade da combinação.

Exemplo 8.3 (Matriz de covariâncias com três variáveis). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}$$

com matriz de covariâncias

$$\Sigma = \begin{bmatrix} 4 & 1.5 & -0.8 \\ 1.5 & 9 & 0 \\ -0.8 & 0 & 1 \end{bmatrix}.$$

As variâncias são

$$\text{Var}(X_1) = 4, \quad \text{Var}(X_2) = 9$$

e

$$\text{Var}(X_3) = 1.$$

Os desvios-padrão correspondentes são

$$\sigma_1 = 2, \quad \sigma_2 = 3$$

e

$$\sigma_3 = 1.$$

As covariâncias distintas são

$$\text{Cov}(X_1, X_2) = 1.5,$$

$$\text{Cov}(X_1, X_3) = -0.8$$

e

$$\text{Cov}(X_2, X_3) = 0.$$

Considere agora a combinação linear

$$Y = X_1 + 0.5X_2 - X_3.$$

Seu vetor de coeficientes é

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0.5 \\ -1 \end{bmatrix}.$$

Pela expressão Equação [8.8](#),

$$\begin{aligned}
\text{Var}(Y) &= \mathbf{a}^\top \Sigma \mathbf{a} \\
&= \begin{bmatrix} 1 & 0.5 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1.5 & -0.8 \\ 1.5 & 9 & 0 \\ -0.8 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0.5 \\ -1 \end{bmatrix} \\
&= 10.35.
\end{aligned}$$

A variância de Y incorpora as variâncias das três componentes e as covariâncias ponderadas pelos respectivos coeficientes. Em particular, a covariância negativa entre X_1 e X_3 contribui positivamente porque os coeficientes dessas duas variáveis possuem sinais opostos.

8.2.3 Propriedades estruturais

A matriz de covariâncias pertence à classe das matrizes simétricas positivas semidefinidas. Essa estrutura decorre diretamente de sua interpretação probabilística e da representação das variâncias das combinações lineares por formas quadráticas (Eaton, 2007).

Teorema 8.2 (Simetria e semidefinição positiva). *Se Σ é a matriz de covariâncias de um vetor aleatório $\mathbf{X} \in \mathbb{R}^p$, então:*

1. Σ é simétrica;
2. Σ é positiva semidefinida;
3. seus elementos diagonais são não negativos;
4. toda submatriz principal de Σ também é uma matriz de covariâncias e, portanto, é positiva semidefinida.

Comprovação. A simetria decorre de

$$\sigma_{jk} = \text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j) = \sigma_{kj}.$$

Logo,

$$\Sigma^\top = \Sigma.$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.$$

Portanto, Σ é positiva semidefinida.

Tomando $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica,

$$\mathbf{e}_j^\top \Sigma \mathbf{e}_j = \sigma_{jj} = \text{Var}(X_j) \geq 0.$$

Por fim, uma submatriz principal corresponde à matriz de covariâncias de um subvetor formado por um subconjunto das componentes de $\mathbf{X}$. A propriedade de semidefinição positiva aplica-se também a esse subvetor. $\square$

A semidefinição positiva impõe restrições aos elementos da matriz. Para duas componentes X_j e X_k , a submatriz principal

$$\begin{bmatrix} \sigma_{jj} & \sigma_{jk} \\ \sigma_{jk} & \sigma_{kk} \end{bmatrix}$$

deve ser positiva semidefinida. Consequentemente,

$$\sigma_{jj}\sigma_{kk} - \sigma_{jk}^2 \geq 0,$$

ou, de forma equivalente,

$$|\sigma_{jk}| \leq \sqrt{\sigma_{jj}\sigma_{kk}}.$$

Essa desigualdade coincide com o limite para a covariância apresentado em Equação 8.4.

Nem toda matriz simétrica é uma matriz de covariâncias. Para representar uma estrutura de covariâncias válida, a matriz também deve ser positiva semidefinida.

Exemplo 8.4 (Matriz simétrica que não pode ser uma matriz de covariâncias). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

A matriz é simétrica, mas, para

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ &= -2. \end{aligned}$$

Se $\mathbf{A}$ fosse uma matriz de covariâncias, esse valor representaria a variância de $X_1 - X_2$, o que é impossível. Portanto, a simetria não é suficiente: a semidefinição positiva também é necessária.

Como Σ é simétrica e positiva semidefinida, seus autovalores são reais e não negativos. Essa consequência será utilizada posteriormente para interpretar a dispersão da distribuição por meio da decomposição espectral.

8.2.4 Singularidade e dimensão efetiva

Uma matriz de covariâncias é positiva definida quando

$$\mathbf{a}^\top \Sigma \mathbf{a} > 0$$

para todo vetor não nulo $\mathbf{a} \in \mathbb{R}^p$. Pela expressão Equação 8.8, essa condição equivale a exigir que toda combinação linear não constante das componentes possua variância positiva.

Teorema 8.3 (Caracterização da singularidade). *Seja Σ a matriz de covariâncias de $\mathbf{X} \in \mathbb{R}^p$. As seguintes afirmações são equivalentes:*

1. Σ é singular;
2. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0;$$

3. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0;$$

4. existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

Comprovação. Como Σ é simétrica e positiva semidefinida, ela é singular se, e somente se, possui um autovalor igual a zero. Nesse caso, existe $\mathbf{a} \neq \mathbf{0}$ tal que

$$\Sigma \mathbf{a} = \mathbf{0},$$

o que implica

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

Reciprocamente, para uma matriz positiva semidefinida,

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0$$

implica que $\mathbf{a}$ pertence ao núcleo de Σ , de modo que a matriz é singular.

Pela expressão Equação 8.8,

$$\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{X}).$$

Assim, as duas condições seguintes são equivalentes.

Por fim, uma variável aleatória possui variância zero se, e somente se, é constante quase certamente. Como

$$E[\mathbf{a}^\top (\mathbf{X} - \mu)] = 0,$$

essa constante deve ser igual a zero. Logo,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = 0$$

se, e somente se,

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0 \quad \text{quase certamente.}$$

□

A última condição do Teorema 8.3 pode ser escrita como

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \mu \quad \text{quase certamente.}$$

Portanto, a singularidade indica a existência de uma relação afim exata entre as componentes de $\mathbf{X}$. Nas variáveis centralizadas, essa relação é linear.

Exemplo 8.5 (Relação linear exata e singularidade). Suponha que

$$X_3 = 2X_1 - X_2$$

quase certamente. Então,

$$X_3 - 2X_1 + X_2 = 0.$$

Definindo

$$\mathbf{a} = \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix},$$

obtém-se

$$\mathbf{a}^\top \mathbf{X} = 0$$

e, conseqüentemente,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a} = 0.$$

A matriz Σ é singular porque uma de suas componentes é determinada exatamente pelas outras duas. Embora o vetor tenha três componentes, sua dispersão está restrita a um subespaço de dimensão no máximo dois.

O posto de Σ satisfaz

$$0 \leq \text{posto}(\Sigma) \leq p.$$

Quando

$$\text{posto}(\Sigma) = p,$$

a matriz é positiva definida e a dispersão ocorre em todas as direções de $\mathbb{R}^p$.

Quando

$$\text{posto}(\Sigma) = r < p,$$

a variabilidade está restrita a um subespaço de dimensão r . As direções pertencentes ao núcleo de Σ possuem variância nula.

A matriz de covariâncias também pode relacionar dois vetores aleatórios distintos. Essa extensão produzirá matrizes retangulares de covariâncias cruzadas e permitirá estudar a associação linear entre blocos de variáveis.

8.3 Covariâncias entre vetores e transformações

8.3.1 Covariâncias cruzadas e vetores particionados

A covariância também pode relacionar componentes pertencentes a dois vetores aleatórios distintos. Considere

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X}) \in \mathbb{R}^p$$

e

$$\mu_Y = E(\mathbf{Y}) \in \mathbb{R}^q.$$

Admite-se que todas as componentes possuam momentos de segunda ordem finitos.

Definição 8.3 (Matriz de covariâncias cruzadas). A **matriz de covariâncias cruzadas** entre $\mathbf{X}$ e $\mathbf{Y}$ é

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right]. \quad (8.10)$$

A matriz Σ_{XY} pertence a $\mathbb{R}^{p \times q}$.

O elemento situado na linha j e na coluna k é

$$(\Sigma_{XY})_{jk} = \text{Cov}(X_j, Y_k),$$

para

$$j = 1, \dots, p \quad \text{e} \quad k = 1, \dots, q.$$

Assim,

$$\Sigma_{XY} = \begin{bmatrix} \text{Cov}(X_1, Y_1) & \cdots & \text{Cov}(X_1, Y_q) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_p, Y_1) & \cdots & \text{Cov}(X_p, Y_q) \end{bmatrix}.$$

A ordem dos vetores determina a orientação da matriz. Invertendo essa ordem,

$$\begin{aligned}\Sigma_{YX} &= E \left[(\mathbf{Y} - \mu_Y) (\mathbf{X} - \mu_X)^\top \right] \\ &= \Sigma_{XY}^\top.\end{aligned}\tag{8.11}$$

Em geral,

$$\Sigma_{XY} \neq \Sigma_{YX},$$

porque as duas matrizes podem ter dimensões distintas. A relação correta é a transposição indicada em Equação 8.11.

Se

$$U = \mathbf{a}^\top \mathbf{X}$$

e

$$V = \mathbf{b}^\top \mathbf{Y},$$

com

$$\mathbf{a} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^q,$$

a covariância entre essas combinações lineares é determinada pela matriz de covariâncias cruzadas.

Teorema 8.4 (Covariância entre combinações de dois vetores). *Para quaisquer vetores fixos $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^q$,*

$$\text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \Sigma_{XY} \mathbf{b}.\tag{8.12}$$

Comprovação. As versões centralizadas das duas combinações são

$$\mathbf{a}^\top (\mathbf{X} - \mu_X)$$

e

$$\mathbf{b}^\top (\mathbf{Y} - \mu_Y).$$

Portanto,

$$\begin{aligned}
& \text{Cov}(\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y}) \\
&= E \left[\mathbf{a}^\top (\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \mathbf{b} \right] \\
&= \mathbf{a}^\top E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \mathbf{b} \\
&= \mathbf{a}^\top \Sigma_{XY} \mathbf{b}.
\end{aligned}$$

□

A matriz Σ_{XY} registra todas as covariâncias necessárias para calcular a associação linear entre combinações dos dois blocos. Essa estrutura será utilizada posteriormente no estudo de relações entre conjuntos de variáveis.

Os vetores podem ser reunidos em um único vetor particionado:

$$\mathbf{V} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}.$$

Seu vetor de médias é

$$\mu_V = \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}.$$

A matriz de covariâncias de $\mathbf{V}$ é

$$\Sigma_V = \text{Cov}(\mathbf{V}) = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}, \quad (8.13)$$

em que

$$\Sigma_{XX} = \text{Cov}(\mathbf{X})$$

e

$$\Sigma_{YY} = \text{Cov}(\mathbf{Y}).$$

Os blocos diagonais descrevem a dispersão interna de cada vetor. Os blocos fora da diagonal descrevem as relações lineares entre suas componentes.

Como Σ_V é uma matriz de covariâncias, ela é simétrica e positiva semidefinida. Essa propriedade impõe restrições conjuntas aos quatro blocos. Em particular, Σ_{XY} não pode ser escolhida arbitrariamente depois de fixadas as matrizes Σ_{XX} e Σ_{YY} .

Se Σ_{YY} é positiva definida, o complemento de Schur correspondente ao bloco Σ_{YY} é

$$\Sigma_{XX \cdot Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}. \quad (8.14)$$

A matriz em Equação 8.14 é positiva semidefinida. Ela representa a parte da covariância de $\mathbf{X}$ que permanece depois da remoção de sua melhor relação linear com $\mathbf{Y}$. A interpretação como matriz de covariâncias condicionais exige hipóteses probabilísticas adicionais e será desenvolvida no capítulo sobre a distribuição normal multivariada (Harville, 1997).

Exemplo 8.6 (Covariâncias entre dois blocos). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

e

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix},$$

com matriz de covariâncias cruzadas

$$\Sigma_{XY} = \begin{bmatrix} 2 & -1 & 0.5 \\ 1 & 3 & -2 \end{bmatrix}.$$

A primeira linha contém as covariâncias entre X_1 e as três componentes de $\mathbf{Y}$. A segunda linha contém as covariâncias correspondentes a X_2 .

Considere as combinações

$$U = X_1 - 2X_2$$

e

$$V = Y_1 + Y_2.$$

Os vetores de coeficientes são

$$\mathbf{a} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

e

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Pela expressão Equação 8.12,

$$\begin{aligned} \text{Cov}(U, V) &= \mathbf{a}^\top \Sigma_{XY} \mathbf{b} \\ &= \begin{bmatrix} 1 & -2 \end{bmatrix} \begin{bmatrix} 2 & -1 & 0.5 \\ 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \\ &= -7. \end{aligned}$$

A covariância negativa resulta da combinação de todas as covariâncias entre as componentes utilizadas na construção de U e V .

8.3.2 Transformação afim da média e da covariância

Considere uma transformação afim

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{X} \in \mathbb{R}^p, \quad \mathbf{A} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{b} \in \mathbb{R}^q.$$

A transformação pode alterar a dimensão, a escala e a orientação do vetor aleatório. O vetor $\mathbf{b}$ produz uma translação, enquanto a matriz $\mathbf{A}$ determina a parte linear da transformação.

Teorema 8.5 (Média e covariância sob transformação afim). *Se $\mathbf{X}$ possui média μ_X e matriz de covariâncias Σ_{XX} , então*

$$E(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\mu_X + \mathbf{b} \quad (8.15)$$

e

$$\text{Cov}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \quad (8.16)$$

Comprovação. Pela linearidade da esperança,

$$\begin{aligned} E(\mathbf{AX} + \mathbf{b}) &= \mathbf{A}E(\mathbf{X}) + \mathbf{b} \\ &= \mathbf{A}\mu_X + \mathbf{b}. \end{aligned}$$

A versão centralizada do vetor transformado é

$$\begin{aligned} (\mathbf{AX} + \mathbf{b}) - (\mathbf{A}\mu_X + \mathbf{b}) \\ = \mathbf{A}(\mathbf{X} - \mu_X). \end{aligned}$$

Assim,

$$\begin{aligned} \text{Cov}(\mathbf{AX} + \mathbf{b}) \\ &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top \mathbf{A}^\top\right] \\ &= \mathbf{A}E\left[(\mathbf{X} - \mu_X)(\mathbf{X} - \mu_X)^\top\right] \mathbf{A}^\top \\ &= \mathbf{A}\Sigma_{XX}\mathbf{A}^\top. \end{aligned}$$

□

A ausência de $\mathbf{b}$ em Equação 8.16 confirma que translações não alteram a estrutura de covariâncias.

Se $q = 1$ e

$$\mathbf{A} = \mathbf{a}^\top,$$

a expressão Equação 8.16 reduz-se a

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma_{XX} \mathbf{a}.$$

Portanto, a variância de uma combinação linear é um caso particular da transformação de uma matriz de covariâncias.

Se

$$\mathbf{A} = \text{diag}(c_1, \dots, c_p),$$

cada componente é multiplicada por seu próprio fator de escala. A matriz transformada possui elementos

$$\text{Cov}(c_j X_j, c_k X_k) = c_j c_k \sigma_{jk}.$$

Em particular,

$$\text{Var}(c_j X_j) = c_j^2 \sigma_{jj}.$$

Se $\mathbf{Q} \in \mathbb{R}^{p \times p}$ é ortogonal, então

$$\text{Cov}(\mathbf{Q}\mathbf{X}) = \mathbf{Q}\Sigma_{XX}\mathbf{Q}^\top.$$

Essa transformação expressa a mesma estrutura de dispersão em um sistema de eixos ortogonalmente transformado.

Se $\mathbf{P}$ é uma matriz de projeção ortogonal, a matriz

$$\mathbf{P}\Sigma_{XX}\mathbf{P}$$

descreve a dispersão do vetor projetado. Como a imagem de $\mathbf{P}$ possui dimensão inferior a p quando a projeção é própria, a matriz resultante é singular no espaço original.

Exemplo 8.7 (Transformação de duas variáveis). Considere

$$\Sigma_{XX} = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}$$

e a transformação

$$\mathbf{Y} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

As novas componentes são

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2.$$

Pela expressão Equação [8.16](#),

$$\begin{aligned} \Sigma_{YY} &= \mathbf{A} \Sigma_{XX} \mathbf{A}^\top \\ &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 17 & -5 \\ -5 & 9 \end{bmatrix}. \end{aligned}$$

Logo,

$$\text{Var}(Y_1) = 17,$$

$$\text{Var}(Y_2) = 9$$

e

$$\text{Cov}(Y_1, Y_2) = -5.$$

A transformação altera as variâncias das componentes e a covariância entre elas.

8.3.3 Transformação das covariâncias cruzadas

Considere agora dois vetores transformados:

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{a}$$

e

$$\mathbf{V} = \mathbf{B}\mathbf{Y} + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{r \times p}$$

e

$$\mathbf{B} \in \mathbb{R}^{s \times q}.$$

As translações não afetam a covariância cruzada.

Teorema 8.6 (Covariância cruzada sob transformações afins). *Sob as condições anteriores,*

$$\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}\Sigma_{XY}\mathbf{B}^\top. \quad (8.17)$$

Comprovação. As versões centralizadas dos vetores transformados são

$$\mathbf{U} - E(\mathbf{U}) = \mathbf{A}(\mathbf{X} - \mu_X)$$

e

$$\mathbf{V} - E(\mathbf{V}) = \mathbf{B}(\mathbf{Y} - \mu_Y).$$

Portanto,

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{V}) &= E\left[\mathbf{A}(\mathbf{X} - \mu_X)(\mathbf{Y} - \mu_Y)^\top \mathbf{B}^\top\right] \\ &= \mathbf{A}\Sigma_{XY}\mathbf{B}^\top. \end{aligned}$$

□

A expressão Equação 8.17 reúne várias propriedades escalares em uma única identidade. Se $r = s = 1$, com

$$\mathbf{A} = \mathbf{c}^\top$$

e

$$\mathbf{B} = \mathbf{d}^\top,$$

obtém-se

$$\text{Cov}(\mathbf{c}^\top \mathbf{X}, \mathbf{d}^\top \mathbf{Y}) = \mathbf{c}^\top \Sigma_{XY} \mathbf{d}.$$

As transformações afins mostram como médias, variâncias e covariâncias respondem a mudanças de localização, escala e sistema de coordenadas. A padronização utiliza uma transformação diagonal específica para retirar as unidades de medida e produzir a matriz de correlações.

8.4 Padronização e matriz de correlações

8.4.1 Matriz de correlações populacional

As covariâncias dependem das unidades de medida das variáveis. Para retirar esse efeito, cada componente pode ser centralizada e dividida por seu desvio-padrão populacional.

Suponha que

$$\sigma_j^2 = \text{Var}(X_j) > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal de desvios-padrão por

$$\mathbf{D}_\sigma = \text{diag}(\sigma_1, \dots, \sigma_p).$$

Como todas as variâncias são positivas, $\mathbf{D}_\sigma$ é invertível.

Definição 8.4 (Vetor aleatório padronizado). O vetor aleatório padronizado correspondente a $\mathbf{X}$ é

$$\mathbf{Z} = \mathbf{D}_\sigma^{-1} (\mathbf{X} - \boldsymbol{\mu}). \quad (8.18)$$

A componente j de $\mathbf{Z}$ é

$$Z_j = \frac{X_j - \mu_j}{\sigma_j}.$$

Cada componente padronizada possui média zero:

$$E(Z_j) = 0,$$

e variância unitária:

$$\text{Var}(Z_j) = 1.$$

A padronização é uma transformação afim. Pela expressão Equação 8.16,

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \text{Cov}[\mathbf{D}_\sigma^{-1}(\mathbf{X} - \mu)] \\ &= \mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1}. \end{aligned}$$

Definição 8.5 (Matriz de correlações populacional). A **matriz de correlações populacional** de $\mathbf{X}$ é

$$\mathcal{R} = \text{Cov}(\mathbf{Z}) = \mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1}. \quad (8.19)$$

A adoção de $\mathcal{R}$ para a matriz populacional preserva o símbolo $\mathbf{R}$ para a matriz de correlações calculada a partir dos dados observados.

A matriz $\mathcal{R}$ pode ser escrita como

$$\mathcal{R} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix},$$

em que

$$\rho_{jk} = \text{Corr}(X_j, X_k) = \frac{\sigma_{jk}}{\sigma_j \sigma_k}. \quad (8.20)$$

A correlação é a covariância entre as versões padronizadas das duas variáveis:

$$\rho_{jk} = \text{Cov}(Z_j, Z_k).$$

Como o numerador e o denominador de Equação 8.20 possuem as mesmas unidades, ρ_{jk} é adimensional.

A relação Equação 8.19 também pode ser invertida:

$$\Sigma = \mathbf{D}_\sigma \mathcal{R} \mathbf{D}_\sigma. \quad (8.21)$$

Assim, a matriz de covariâncias pode ser decomposta em duas partes:

- $\mathbf{D}_\sigma$ registra as escalas marginais;
- $\mathcal{R}$ registra a estrutura de associação linear padronizada.

A matriz de correlações não contém as variâncias originais. Para recuperar Σ por meio de Equação 8.21, também é necessário conhecer os desvios-padrão populacionais.

8.4.2 Propriedades e limites

Teorema 8.7 (Propriedades da matriz de correlações). *Se todas as componentes de $\mathbf{X}$ possuem variância positiva, então a matriz de correlações populacional $\mathcal{R}$ satisfaz:*

1. $\mathcal{R}$ é simétrica;
2. $\mathcal{R}$ é positiva semidefinida;
3. seus elementos diagonais são iguais a 1;
4. seus elementos pertencem ao intervalo $[-1, 1]$;
5. $\mathcal{R}$ é positiva definida se, e somente se, Σ é positiva definida.

Comprovação. Como Σ é simétrica,

$$\begin{aligned} \mathcal{R}^\top &= (\mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1})^\top \\ &= \mathbf{D}_\sigma^{-1} \Sigma^\top \mathbf{D}_\sigma^{-1} \\ &= \mathcal{R}. \end{aligned}$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathcal{R} \mathbf{a} &= \mathbf{a}^\top \mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1} \mathbf{a} \\ &= (\mathbf{D}_\sigma^{-1} \mathbf{a})^\top \Sigma (\mathbf{D}_\sigma^{-1} \mathbf{a}) \geq 0. \end{aligned}$$

Logo, $\mathcal{R}$ é positiva semidefinida.

Para os elementos diagonais,

$$\rho_{jj} = \frac{\sigma_{jj}}{\sigma_j^2} = 1.$$

Pelo limite para a covariância apresentado em Equação 8.4,

$$|\sigma_{jk}| \leq \sigma_j \sigma_k.$$

Dividindo os dois lados por $\sigma_j \sigma_k > 0$,

$$|\rho_{jk}| \leq 1.$$

Finalmente, como $\mathbf{D}_\sigma$ é invertível, a transformação por congruência

$$\mathcal{R} = \mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1}$$

preserva a definição positiva. □

A condição

$$\rho_{jk} = 1$$

ocorre quando existe uma relação linear crescente exata entre as versões centralizadas das variáveis:

$$X_k - \mu_k = c(X_j - \mu_j)$$

quase certamente, para algum $c > 0$.

De forma semelhante,

$$\rho_{jk} = -1$$

ocorre quando a relação linear exata possui inclinação negativa:

$$X_k - \mu_k = c(X_j - \mu_j)$$

quase certamente, para algum $c < 0$.

Em ambos os casos, o subvetor formado por X_j e X_k possui matriz de covariâncias singular.

Uma matriz simétrica com diagonal unitária não é necessariamente uma matriz de correlações válida. A semidefinição positiva também é necessária.

Exemplo 8.8 (Matriz com diagonal unitária que não é uma matriz de correlações). Considere

$$\mathbf{A} = \begin{bmatrix} 1 & 0.9 & 0.9 \\ 0.9 & 1 & -0.9 \\ 0.9 & -0.9 & 1 \end{bmatrix}.$$

Todos os elementos estão no intervalo $[-1, 1]$, e a diagonal é unitária. Entretanto,

$$\det(\mathbf{A}) = -2.888 < 0.$$

Uma matriz positiva semidefinida não pode possuir determinante negativo. Portanto, $\mathbf{A}$ não representa uma estrutura de correlações válida.

Esse exemplo mostra que correlações definidas par a par devem ser compatíveis com uma única estrutura conjunta.

8.4.3 Correlação nula e independência

Duas variáveis X_j e X_k são não correlacionadas quando

$$\rho_{jk} = 0.$$

Como as variâncias são positivas, essa condição é equivalente a

$$\sigma_{jk} = 0.$$

A correlação nula indica ausência de associação linear líquida. Ela não implica independência em uma distribuição geral, conforme mostrou o Exemplo 8.2.

Se X_j e X_k são independentes e possuem segundos momentos finitos, então

$$E(X_j X_k) = E(X_j)E(X_k),$$

de modo que

$$\text{Cov}(X_j, X_k) = 0$$

e

$$\rho_{jk} = 0.$$

Portanto,

$$\text{independência} \implies \text{correlação nula},$$

mas a recíproca exige hipóteses adicionais (Johnson; Wichern, 2007).

Correlação e independência

A equivalência entre correlação nula e independência não é uma propriedade geral. No caso de um vetor com distribuição normal multivariada, a covariância nula entre blocos terá uma consequência mais forte, desenvolvida no próximo capítulo.

Uma matriz de correlações diagonal,

$$\mathcal{R} = \mathbf{I}_p,$$

indica que todas as componentes são duas a duas não correlacionadas. Essa condição, isoladamente, não garante independência conjunta.

8.4.4 Efeito das mudanças de escala

Considere a transformação componente a componente

$$\mathbf{Y} = \mathbf{C}\mathbf{X} + \mathbf{b},$$

em que

$$\mathbf{C} = \text{diag}(c_1, \dots, c_p)$$

e todos os fatores c_j são não nulos.

A covariância entre duas componentes transformadas é

$$\text{Cov}(Y_j, Y_k) = c_j c_k \sigma_{jk}.$$

Os desvios-padrão transformados são

$$\sigma_{Y_j} = |c_j| \sigma_j.$$

Portanto,

$$\begin{aligned} \text{Corr}(Y_j, Y_k) &= \frac{c_j c_k \sigma_{jk}}{|c_j| \sigma_j |c_k| \sigma_k} \\ &= \text{sgn}(c_j) \text{sgn}(c_k) \rho_{jk}. \end{aligned} \tag{8.22}$$

Se todos os fatores de escala são positivos,

$$\text{Corr}(Y_j, Y_k) = \rho_{jk}.$$

Assim, conversões usuais entre unidades de medida, como metros para centímetros ou quilogramas para gramas, não alteram as correlações.

Se uma das variáveis é multiplicada por uma constante negativa, o sinal de todas as suas correlações é invertido. A intensidade da associação linear permanece a mesma.

Em forma matricial, defina

$$\mathbf{S}_c = \text{diag} [\text{sgn}(c_1), \dots, \text{sgn}(c_p)].$$

A matriz de correlações do vetor transformado é

$$\mathcal{R}_Y = \mathbf{S}_c \mathcal{R}_X \mathbf{S}_c.$$

A translação determinada por $\mathbf{b}$ não altera covariâncias nem correlações.

A Figura 8.3 compara uma nuvem de dados em suas unidades originais com a mesma nuvem após a padronização marginal.

A padronização desloca o centro da nuvem para a origem e atribui variância unitária a cada eixo. A associação linear entre as componentes é preservada porque os fatores de escala utilizados são positivos.

Exemplo 8.9 (Conversão de covariâncias em correlações). Retome a matriz de covariâncias do Exemplo 8.3:

$$\Sigma = \begin{bmatrix} 4 & 1.5 & -0.8 \\ 1.5 & 9 & 0 \\ -0.8 & 0 & 1 \end{bmatrix}.$$




Figura 8.3: Efeito da padronização marginal sobre localização e escala.

A matriz de desvios-padrão é

$$\mathbf{D}_\sigma = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Pela expressão Equação 8.19,

$$\begin{aligned} \mathcal{R} &= \mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1} \\ &= \begin{bmatrix} 1 & 0.25 & -0.4 \\ 0.25 & 1 & 0 \\ -0.4 & 0 & 1 \end{bmatrix}. \end{aligned}$$

Por exemplo,

$$\rho_{12} = \frac{1.5}{2 \cdot 3} = 0.25$$

e

$$\rho_{13} = \frac{-0.8}{2 \cdot 1} = -0.4.$$

Embora

$$|\sigma_{12}| > |\sigma_{13}|,$$

a associação padronizada entre X_1 e X_3 possui maior intensidade:

$$|\rho_{13}| > |\rho_{12}|.$$

A diferença ocorre porque a covariância depende das escalas marginais, enquanto a correlação compara as associações após a padronização.

A escolha entre covariâncias e correlações modifica a geometria utilizada para representar a dispersão. A matriz de covariâncias preserva as unidades e as variabilidades originais. A matriz de correlações atribui a mesma variância marginal a todas as componentes. As consequências geométricas dessas escolhas serão desenvolvidas na seção seguinte.

8.5 Geometria e medidas globais da dispersão

8.5.1 Eixos espectrais da covariância

A matriz de covariâncias associa a cada direção $\mathbf{a} \in \mathbb{R}^p$ a variância

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Quando $\|\mathbf{a}\| = 1$, essa expressão mede a dispersão do vetor aleatório ao longo da direção unitária $\mathbf{a}$. Direções distintas podem apresentar variâncias distintas, mesmo quando as variâncias marginais das componentes são semelhantes.

Como Σ é simétrica e positiva semidefinida, ela admite a decomposição espectral

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top, \tag{8.23}$$

em que

$$\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_p]$$

é uma matriz ortogonal e

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

contém os autovalores não negativos de Σ .

Os autovetores podem ser escolhidos de modo que

$$\mathbf{q}_j^\top \mathbf{q}_k = \begin{cases} 1, & j = k, \\ 0, & j \neq k. \end{cases}$$

A transformação ortogonal

$$\mathbf{Y} = \mathbf{Q}^\top (\mathbf{X} - \mu) \quad (8.24)$$

expressa o vetor centralizado no sistema de coordenadas determinado pelos autovetores de Σ .

Pela regra de transformação da covariância,

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \mathbf{Q}^\top \Sigma \mathbf{Q} \\ &= \mathbf{Q}^\top \mathbf{Q} \Lambda \mathbf{Q}^\top \mathbf{Q} \\ &= \Lambda. \end{aligned} \quad (8.25)$$

Portanto, as componentes de $\mathbf{Y}$ são não correlacionadas e satisfazem

$$\text{Var}(Y_j) = \lambda_j.$$

Os vetores $\mathbf{q}_1, \dots, \mathbf{q}_p$ serão denominados **eixos espectrais da covariância**. Cada autovalor λ_j quantifica a variância na direção $\mathbf{q}_j$.

Se os autovalores são ordenados como

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0,$$

então $\mathbf{q}_1$ é uma direção de variância máxima entre os vetores unitários. Esse resultado decorre do quociente de Rayleigh desenvolvido no Capítulo 5:

$$\lambda_p \leq \mathbf{a}^\top \Sigma \mathbf{a} \leq \lambda_1, \quad \|\mathbf{a}\| = 1. \quad (8.26)$$

Os limites são alcançados nas direções dos autovetores associados aos autovalores extremos.

Neste capítulo, a decomposição espectral é utilizada para interpretar a estrutura de dispersão. A construção de técnicas baseadas na escolha de direções de variabilidade será realizada posteriormente.

Exemplo 8.10 (Variâncias em eixos espectrais). Considere uma matriz de covariâncias com decomposição

$$\Sigma = \mathbf{Q} \begin{bmatrix} 9 & 0 \\ 0 & 1 \end{bmatrix} \mathbf{Q}^\top,$$

em que $\mathbf{Q}$ é ortogonal.

A variância ao longo de $\mathbf{q}_1$ é

$$\text{Var}(\mathbf{q}_1^\top \mathbf{X}) = 9,$$

enquanto a variância ao longo de $\mathbf{q}_2$ é

$$\text{Var}(\mathbf{q}_2^\top \mathbf{X}) = 1.$$

Os desvios-padrão nessas direções são, respectivamente,

$$\sqrt{9} = 3$$

e

$$\sqrt{1} = 1.$$

A distribuição apresenta maior extensão ao longo de $\mathbf{q}_1$. A razão entre as variâncias direcionais é 9, enquanto a razão entre as extensões medidas em desvios-padrão é 3.

Quando

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_p^2 \end{bmatrix},$$

os eixos espectrais coincidem com os eixos coordenados. As componentes são não correlacionadas, e a dispersão ao longo do eixo j é σ_j^2 .

No caso particular

$$\Sigma = \sigma^2 \mathbf{I}_p, \tag{8.27}$$

todas as direções unitárias possuem a mesma variância:

$$\mathbf{a}^\top \Sigma \mathbf{a} = \sigma^2, \quad \|\mathbf{a}\| = 1.$$

A condição Equação 8.27 descreve uma estrutura de segunda ordem isotrópica. Ela não implica, isoladamente, que toda a distribuição seja esfericamente simétrica.

8.5.2 Elipsoide associado à covariância

Suponha inicialmente que Σ seja positiva definida. Para uma constante $c > 0$, considere o conjunto

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq c^2\}. \quad (8.28)$$

Esse conjunto é um elipsoide centrado em μ . Para identificar seus eixos e suas extensões, escreva

$$\Sigma^{-1} = \mathbf{Q} \Lambda^{-1} \mathbf{Q}^\top$$

e defina

$$\mathbf{y} = \mathbf{Q}^\top (\mathbf{x} - \mu).$$

A condição que define o elipsoide torna-se

$$\mathbf{y}^\top \Lambda^{-1} \mathbf{y} \leq c^2,$$

ou

$$\sum_{j=1}^p \frac{y_j^2}{c^2 \lambda_j} \leq 1. \quad (8.29)$$

A expressão Equação 8.29 mostra que:

- o centro do elipsoide é μ ;
- seus eixos possuem as direções $\mathbf{q}_1, \dots, \mathbf{q}_p$;
- o semieixo correspondente a $\mathbf{q}_j$ possui comprimento

$$c\sqrt{\lambda_j}.$$

Autovalores maiores produzem maior extensão na direção correspondente. Autovalores menores produzem maior concentração geométrica.

A Figura 8.4 representa uma matriz de covariâncias bidimensional, seus eixos espectrais e o contorno definido por $c = 2$.




Figura 8.4: Elipse associada a uma matriz de covariâncias e seus eixos espectrais.

A orientação da elipse é determinada pelos autovetores, enquanto suas extensões dependem das raízes quadradas dos autovalores. A matriz de covariâncias descreve, portanto, uma geometria de segunda ordem para a dispersão do vetor aleatório.

Interpretação probabilística do elipsoide

O conjunto $\mathcal{E}_c$ é definido geometricamente pela média e pela matriz de covariâncias. Sem uma hipótese sobre a distribuição de $\mathbf{X}$, não se pode atribuir a esse elipsoide uma

probabilidade específica nem interpretá-lo automaticamente como região de confiança. Essas interpretações exigem um modelo probabilístico e uma calibração da constante c .

Se Σ é singular, a expressão Equação 8.28 não pode ser utilizada diretamente, pois Σ^{-1} não existe. Nesse caso, o elipsoide degenerado associado à covariância pode ser definido como

$$\mathcal{E}_c^{(r)} = \left\{ \mu + \Sigma^{1/2} \mathbf{u} : \|\mathbf{u}\| \leq c \right\}. \quad (8.30)$$

Se

$$r = \text{posto}(\Sigma),$$

o conjunto $\mathcal{E}_c^{(r)}$ está contido no subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r . Seus semieixos não nulos possuem direções dadas pelos autovetores associados aos autovalores positivos e comprimentos

$$c\sqrt{\lambda_j}.$$

Uma representação equivalente utiliza a pseudoinversa:

$$\mathcal{E}_c^{(r)} = \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \quad (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq c^2 \right\}. \quad (8.31)$$

A restrição ao espaço coluna é necessária. Sem ela, a forma quadrática baseada na pseudoinversa não distingue deslocamentos pertencentes ao núcleo de Σ (Eaton, 2007).

8.5.3 Variância total e variância generalizada

Uma matriz de covariâncias contém várias variâncias e covariâncias. Algumas funções escalares da matriz resumem aspectos específicos da dispersão, mas nenhuma delas preserva toda a informação contida em Σ .

Definição 8.6 (Variância total). A **variância total** de um vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ é

$$\text{VT}(\mathbf{X}) = \text{tr}(\Sigma). \quad (8.32)$$

Como o traço é a soma dos elementos diagonais,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \text{Var}(X_j). \quad (8.33)$$

Pela decomposição espectral,

$$\text{tr}(\Sigma) = \sum_{j=1}^p \lambda_j. \quad (8.34)$$

A variância total pode ser interpretada de três maneiras equivalentes:

- soma das variâncias marginais;
- soma das variâncias nos eixos espectrais;
- esperança do quadrado da distância euclidiana ao vetor de médias.

A terceira interpretação decorre de

$$\begin{aligned} E[\|\mathbf{X} - \mu\|^2] &= E[(\mathbf{X} - \mu)^\top (\mathbf{X} - \mu)] \\ &= E[\text{tr}\{(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top\}] \\ &= \text{tr}(\Sigma). \end{aligned} \quad (8.35)$$

Dividindo a variância total pelo número de componentes, obtém-se a variância média:

$$\text{VM}(\mathbf{X}) = \frac{1}{p} \text{tr}(\Sigma).$$

Essa quantidade representa a média aritmética das variâncias marginais ou, de forma equivalente, a média dos autovalores.

A variância total depende das escalas das variáveis. Componentes medidas em unidades numericamente maiores podem dominar a soma.

Definição 8.7 (Variância generalizada). A **variância generalizada** de $\mathbf{X}$ é

$$\text{VG}(\mathbf{X}) = \det(\Sigma). \quad (8.36)$$

Como o determinante é o produto dos autovalores,

$$\det(\Sigma) = \prod_{j=1}^p \lambda_j. \quad (8.37)$$

A utilização de $\det(\Sigma)$ como medida escalar da dispersão multivariada é denominada variância generalizada (Johnson; Wichern, 2007).

A variância generalizada reúne multiplicativamente as dispersões nos eixos espectrais. Se qualquer autovalor é zero, então

$$\det(\Sigma) = 0.$$

Portanto, a variância generalizada é nula quando a dispersão está restrita a um subespaço de dimensão inferior a p .

A variância generalizada não é o volume do elipsoide. Ela participa da expressão desse volume por meio de sua raiz quadrada.

Se Σ é positiva definida, o volume do elipsoide $\mathcal{E}_c$ definido em Equação 8.28 é

$$\text{Vol}(\mathcal{E}_c) = \kappa_p c^p \det(\Sigma)^{1/2}, \quad (8.38)$$

em que

$$\kappa_p = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da esfera unitária de $\mathbb{R}^p$.

A expressão Equação 8.38 mostra que

$$\det(\Sigma)^{1/2}$$

é o fator de escala do volume associado à transformação da esfera unitária no elipsoide de covariância.

Exemplo 8.11 (Comparação entre variância total e variância generalizada). Considere duas matrizes diagonais:

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

e

$$\Sigma_2 = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}.$$

As duas matrizes possuem a mesma variância total:

$$\text{tr}(\Sigma_1) = 8$$

e

$$\text{tr}(\Sigma_2) = 8.$$

Entretanto,

$$\det(\Sigma_1) = 16,$$

enquanto

$$\det(\Sigma_2) = 7.$$

A primeira matriz distribui a variabilidade igualmente entre as duas direções. A segunda concentra maior variabilidade em um eixo e menor variabilidade no outro.

A variância total registra a soma das dispersões direcionais, mas não distingue essas duas configurações. A variância generalizada é menor na configuração mais alongada porque depende do produto das dispersões nos eixos.

8.5.4 Unidades e efeito das transformações

Se as componentes de $\mathbf{X}$ possuem unidades

$$u_1, \dots, u_p,$$

a variância generalizada possui unidade

$$u_1^2 u_2^2 \cdots u_p^2.$$

Sua raiz quadrada possui unidade

$$u_1 u_2 \cdots u_p,$$

compatível com uma medida de volume no espaço das variáveis.

A soma de variâncias que compõe $\text{tr}(\Sigma)$ também exige cautela quando as variáveis possuem unidades diferentes. Embora o cálculo seja definido, a soma pode não ter uma interpretação física simples.

Considere uma transformação linear quadrada

$$\mathbf{Y} = \mathbf{A}\mathbf{X},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}.$$

A matriz de covariâncias transformada é

$$\Sigma_{YY} = \mathbf{A} \Sigma_{XX} \mathbf{A}^\top.$$

Se $\mathbf{A}$ é invertível,

$$\begin{aligned} \det(\Sigma_{YY}) &= \det(\mathbf{A} \Sigma_{XX} \mathbf{A}^\top) \\ &= \det(\mathbf{A}) \det(\Sigma_{XX}) \det(\mathbf{A}^\top) \\ &= \det(\mathbf{A})^2 \det(\Sigma_{XX}). \end{aligned} \tag{8.39}$$

Consequentemente,

$$\det(\Sigma_{YY})^{1/2} = |\det(\mathbf{A})| \det(\Sigma_{XX})^{1/2}. \quad (8.40)$$

A expressão Equação 8.40 coincide com a alteração de volume produzida por uma transformação linear.

Se $\mathbf{Q}$ é ortogonal,

$$|\det(\mathbf{Q})| = 1.$$

Logo,

$$\det(\mathbf{Q}\Sigma\mathbf{Q}^\top) = \det(\Sigma).$$

A variância total também é preservada por transformações ortogonais:

$$\begin{aligned} \text{tr}(\mathbf{Q}\Sigma\mathbf{Q}^\top) &= \text{tr}(\mathbf{Q}^\top\mathbf{Q}\Sigma) \\ &= \text{tr}(\Sigma). \end{aligned}$$

Portanto, rotações e reflexões alteram a orientação dos eixos, mas preservam a variância total, a variância generalizada e as extensões do elipsoide.

Transformações gerais de escala modificam essas medidas. A comparação entre valores de variância total ou variância generalizada exige, por isso, que as variáveis estejam expressas em escalas compatíveis ou que o efeito das unidades seja considerado explicitamente.

A forma quadrática que define o elipsoide também fornece uma medida de separação adaptada à matriz de covariâncias. Essa construção conduz à distância de Mahalanobis.

8.6 Distância de Mahalanobis

A distância euclidiana entre uma observação $\mathbf{x} \in \mathbb{R}^p$ e o vetor de médias μ é

$$d_E(\mathbf{x}, \mu) = \|\mathbf{x} - \mu\| = \sqrt{(\mathbf{x} - \mu)^\top (\mathbf{x} - \mu)}.$$

Essa distância utiliza a geometria euclidiana original. Todas as coordenadas recebem o mesmo peso, independentemente de suas variâncias e das covariâncias existentes entre as variáveis.

No caso univariado, o afastamento entre um valor x e a média μ pode ser ajustado pelo desvio-padrão:

$$\frac{|x - \mu|}{\sigma}.$$

A distância de Mahalanobis estende essa padronização ao espaço multivariado por meio da matriz de covariâncias completa, ajustando simultaneamente as escalas marginais e as associações lineares entre as componentes (Mardia; Kent; Taylor, 2024).

8.6.1 Definição e interpretação espectral

Considere um vetor aleatório $\mathbf{X} \in \mathbb{R}^p$, com vetor de médias μ e matriz de covariâncias positiva definida:

$$\Sigma \succ \mathbf{0}.$$

Definição 8.8 (Distância de Mahalanobis). A **distância de Mahalanobis** entre dois pontos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, em relação à matriz de covariâncias Σ , é

$$d_M(\mathbf{x}, \mathbf{y}; \Sigma) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{y})}. \quad (8.41)$$

A distância de uma observação $\mathbf{x}$ ao vetor de médias é

$$d_M(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)}. \quad (8.42)$$

Seu quadrado é

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu). \quad (8.43)$$

A matriz Σ^{-1} ajusta o afastamento levando em consideração:

- as variâncias individuais;
- as unidades de medida;
- as covariâncias entre as componentes;
- as direções de maior e menor dispersão.

Quando $p = 1$,

$$\Sigma = [\sigma^2],$$

e a expressão Equação 8.42 reduz-se a

$$\begin{aligned} d_M(x, \mu) &= \sqrt{\frac{(x - \mu)^2}{\sigma^2}} \\ &= \frac{|x - \mu|}{\sigma}. \end{aligned}$$

A distância padronizada univariada é, portanto, um caso particular da distância de Mahalanobis.

Quando

$$\Sigma = \mathbf{I}_p,$$

tem-se

$$d_M(\mathbf{x}, \mathbf{y}; \mathbf{I}_p) = d_E(\mathbf{x}, \mathbf{y}).$$

Nesse caso, as variáveis possuem variância unitária e covariâncias nulas.

Como Σ^{-1} é positiva definida, a expressão

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\Sigma^{-1}} = \mathbf{x}^\top \Sigma^{-1} \mathbf{y}$$

define um produto interno. A distância em Equação 8.41 é a distância induzida por esse produto interno e satisfaz:

$$d_M(\mathbf{x}, \mathbf{y}) \geq 0,$$

$$d_M(\mathbf{x}, \mathbf{y}) = 0 \iff \mathbf{x} = \mathbf{y},$$

$$d_M(\mathbf{x}, \mathbf{y}) = d_M(\mathbf{y}, \mathbf{x})$$

e

$$d_M(\mathbf{x}, \mathbf{z}) \leq d_M(\mathbf{x}, \mathbf{y}) + d_M(\mathbf{y}, \mathbf{z}).$$

A decomposição espectral da matriz de covariâncias é

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

e

$$\lambda_j > 0, \quad j = 1, \dots, p.$$

Sua inversa é

$$\Sigma^{-1} = \mathbf{Q}\Lambda^{-1}\mathbf{Q}^\top.$$

Defina as coordenadas do afastamento nos eixos espectrais por

$$\mathbf{u} = \mathbf{Q}^\top (\mathbf{x} - \mu).$$

Substituindo essa expressão em Equação 8.43,

$$\begin{aligned} d_M^2(\mathbf{x}, \mu) &= (\mathbf{x} - \mu)^\top \mathbf{Q}\Lambda^{-1}\mathbf{Q}^\top (\mathbf{x} - \mu) \\ &= \mathbf{u}^\top \Lambda^{-1} \mathbf{u} \\ &= \sum_{j=1}^p \frac{u_j^2}{\lambda_j}. \end{aligned} \tag{8.44}$$

A expressão Equação 8.44 mostra que cada afastamento direcional é dividido pela variância existente naquela direção.

Um deslocamento em um eixo associado a um autovalor elevado recebe menor peso. O mesmo deslocamento em um eixo de pequena variância recebe maior peso. A distância de Mahalanobis mede, portanto, o afastamento em relação à estrutura de dispersão da população.

Exemplo 8.12 (Afastamentos em direções com variâncias distintas). Considere uma matriz de covariâncias cujos autovalores são

$$\lambda_1 = 9 \quad \text{e} \quad \lambda_2 = 1.$$

Dois pontos apresentam afastamento de magnitude 2 em relação ao centro, mas em eixos espectrais distintos.

Para o ponto situado no primeiro eixo,

$$d_M^2 = \frac{2^2}{9} = \frac{4}{9}.$$

Para o ponto situado no segundo eixo,

$$d_M^2 = \frac{2^2}{1} = 4.$$

Os dois pontos possuem a mesma distância euclidiana ao centro. O afastamento no segundo eixo apresenta maior distância de Mahalanobis porque ocorre em uma direção com menor variabilidade.

8.6.2 Relação com o branqueamento

A raiz quadrada inversa simétrica da matriz de covariâncias é

$$\Sigma^{-1/2} = \mathbf{Q}\Lambda^{-1/2}\mathbf{Q}^\top.$$

Considere a transformação

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu). \quad (8.45)$$

Então,

$$\begin{aligned} \|\mathbf{z}\|^2 &= \mathbf{z}^\top \mathbf{z} \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1/2} \Sigma^{-1/2} (\mathbf{x} - \mu) \\ &= (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \\ &= d_M^2(\mathbf{x}, \mu). \end{aligned}$$

Consequentemente,

$$d_M(\mathbf{x}, \mu) = \left\| \Sigma^{-1/2} (\mathbf{x} - \mu) \right\|. \quad (8.46)$$

A transformação em Equação 8.45:

1. centraliza o ponto;
2. reorienta suas coordenadas segundo os eixos espectrais;
3. divide cada coordenada pelo desvio-padrão correspondente;
4. retorna o resultado ao sistema de coordenadas original.

No vetor aleatório,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu)$$

possui matriz de covariâncias

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Sigma^{-1/2} \Sigma \Sigma^{-1/2} \\ &= \mathbf{I}_p. \end{aligned}$$

Essa transformação é denominada **branqueamento**. O resultado possui variâncias unitárias e covariâncias nulas.

A matriz utilizada no branqueamento não é única. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2}$$

também produz uma matriz de covariâncias igual a $\mathbf{I}_p$. As diferentes escolhas diferem por uma transformação ortogonal e preservam as distâncias euclidianas no espaço branqueado (Mardia; Kent; Taylor, 2024).

A padronização marginal utiliza

$$\mathbf{D}_\sigma^{-1} (\mathbf{x} - \mu)$$

e ajusta apenas as variâncias individuais. Sua matriz de covariâncias é $\mathcal{R}$, que pode conter elementos fora da diagonal.

O branqueamento utiliza a matriz completa $\Sigma^{-1/2}$ e ajusta simultaneamente variâncias e covariâncias. Por essa razão, a distância de Mahalanobis não coincide, em geral, com a distância euclidiana calculada apenas após a padronização marginal.

Para uma constante $c > 0$, o conjunto

$$\{\mathbf{x} \in \mathbb{R}^p : d_M(\mathbf{x}, \mu) = c\}$$

pode ser escrito como

$$\left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = c^2 \right\}.$$

Esse conjunto corresponde à fronteira do elipsoide definido em Equação 8.28. Seus semieixos possuem comprimentos

$$c\sqrt{\lambda_j}, \quad j = 1, \dots, p.$$

A Figura 8.5 compara dois pontos que possuem a mesma distância euclidiana ao centro, mas estão situados em eixos com variâncias distintas.




Figura 8.5: Pontos com a mesma distância euclidiana podem apresentar distâncias de Mahalanobis distintas.

O ponto situado no eixo de menor variância pertence a uma curva de maior distância de Mahalanobis. A comparação mostra que essa distância avalia o deslocamento em relação à variabilidade disponível em cada direção.

8.6.3 Invariância afim

A distância de Mahalanobis é preservada por transformações afins invertíveis quando o centro e a matriz de covariâncias são transformados de maneira correspondente.

Teorema 8.8 (Invariância afim da distância de Mahalanobis). *Considere*

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

em que $\mathbf{A} \in \mathbb{R}^{p \times p}$ é invertível. Se

$$\mu_Y = \mathbf{A}\mu_X + \mathbf{b}$$

e

$$\Sigma_{YY} = \mathbf{A}\Sigma_{XX}\mathbf{A}^\top,$$

então

$$d_M(\mathbf{y}, \mu_Y; \Sigma_{YY}) = d_M(\mathbf{x}, \mu_X; \Sigma_{XX}). \quad (8.47)$$

Comprovação. A diferença transformada é

$$\mathbf{y} - \mu_Y = \mathbf{A}(\mathbf{x} - \mu_X).$$

Como $\mathbf{A}$ e Σ_{XX} são invertíveis,

$$(\mathbf{A}\Sigma_{XX}\mathbf{A}^\top)^{-1} = \mathbf{A}^{-\top}\Sigma_{XX}^{-1}\mathbf{A}^{-1}.$$

Portanto,

$$\begin{aligned}
d_M^2(\mathbf{y}, \mu_Y; \Sigma_{YY}) &= [\mathbf{A}(\mathbf{x} - \mu_X)]^\top \mathbf{A}^{-\top} \Sigma_{XX}^{-1} \mathbf{A}^{-1} [\mathbf{A}(\mathbf{x} - \mu_X)] \\
&= (\mathbf{x} - \mu_X)^\top \Sigma_{XX}^{-1} (\mathbf{x} - \mu_X) \\
&= d_M^2(\mathbf{x}, \mu_X; \Sigma_{XX}).
\end{aligned}$$

Como as distâncias são não negativas, a igualdade entre seus quadrados implica Equação 8.47. $\square$

Mudanças de unidade, rotações, reflexões e outras reparametrizações lineares invertíveis não alteram o afastamento de Mahalanobis, desde que a matriz de covariâncias seja transformada juntamente com os pontos.

8.6.4 Covariância singular

A definição em Definição 8.8 exige uma matriz de covariâncias positiva definida, pois utiliza Σ^{-1} .

Quando Σ é singular, uma extensão algébrica pode ser construída com a pseudoinversa de Moore–Penrose:

$$d_{M,+}^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \Sigma^+ (\mathbf{x} - \mathbf{y}). \quad (8.48)$$

Se

$$\Sigma = \mathbf{Q} \text{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0) \mathbf{Q}^\top,$$

com

$$\lambda_j > 0, \quad j = 1, \dots, r,$$

então

$$\Sigma^+ = \mathbf{Q} \text{diag}(\lambda_1^{-1}, \dots, \lambda_r^{-1}, 0, \dots, 0) \mathbf{Q}^\top.$$

A expressão Equação 8.48 considera apenas as direções associadas aos autovalores positivos. Diferenças pertencentes ao núcleo de Σ recebem valor zero.

Interpretação no caso singular

Em todo o espaço $\mathbb{R}^p$, a expressão baseada na pseudoinversa é uma pseudodistância: pontos distintos podem apresentar valor zero quando sua diferença pertence ao núcleo de Σ .

Ela define uma distância no subespaço efetivo da dispersão ou, equivalentemente, no espaço quociente em que diferenças pertencentes ao núcleo são identificadas (Eaton, 2007).

Neste capítulo, a distância de Mahalanobis é uma construção geométrica determinada por Σ . Sob modelos probabilísticos específicos, seu quadrado poderá possuir uma distribuição conhecida e fornecer regiões de concentração, testes e procedimentos de diagnóstico. Essas propriedades serão desenvolvidas nos capítulos seguintes.

A matriz de covariâncias populacional descreve a dispersão de um vetor aleatório. Para dados observados, a mesma estrutura será representada por matrizes de produtos cruzados, covariâncias e correlações calculadas a partir da amostra.

8.7 Representação descritiva a partir dos dados

As matrizes Σ e $\mathcal{R}$ são parâmetros populacionais. Quando se dispõe de um conjunto de dados observado, a localização e a dispersão podem ser representadas por quantidades calculadas a partir das linhas da matriz de dados.

Nesta seção, $\bar{\mathbf{x}}$, $\mathbf{S}$ e $\mathbf{R}$ representam valores obtidos de um conjunto específico de observações. Se as linhas forem consideradas realizações de uma amostra aleatória, esses valores serão realizações das estatísticas aleatórias $\bar{\mathbf{X}}$, $\mathbf{S}$ e $\mathbf{R}$. Suas propriedades como estimadores serão desenvolvidas no Capítulo 10.

8.7.1 Média observada e matriz centralizada

Considere n observações de p variáveis, organizadas na matriz

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Cada linha $\mathbf{x}_i^\top$ representa uma observação, e cada coluna contém os valores observados de uma variável.

O vetor de médias das colunas é

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix} \in \mathbb{R}^p,$$

em que

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad j = 1, \dots, p.$$

Em notação matricial,

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n, \quad (8.49)$$

em que $\mathbf{1}_n \in \mathbb{R}^n$ é o vetor cujos elementos são iguais a 1.

A matriz de dados centralizada é obtida subtraindo $\bar{\mathbf{x}}$ de cada linha de $\mathbf{X}$:

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \quad (8.50)$$

Sua linha i é

$$(\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e sua forma explícita é

$$\mathbf{X}_c = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \cdots & x_{1p} - \bar{x}_p \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{2p} - \bar{x}_p \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} - \bar{x}_1 & x_{n2} - \bar{x}_2 & \cdots & x_{np} - \bar{x}_p \end{bmatrix}.$$

Cada coluna de $\mathbf{X}_c$ possui soma igual a zero:

$$\mathbf{1}_n^\top \mathbf{X}_c = \mathbf{0}^\top. \quad (8.51)$$

A centralização também pode ser expressa pela matriz

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (8.52)$$

A matriz $\mathbf{H}_n \in \mathbb{R}^{n \times n}$ é simétrica,

$$\mathbf{H}_n^\top = \mathbf{H}_n,$$

idempotente,

$$\mathbf{H}_n^2 = \mathbf{H}_n,$$

e satisfaz

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0}.$$

Aplicando-a à matriz de dados,

$$\begin{aligned} \mathbf{H}_n \mathbf{X} &= \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X} \\ &= \mathbf{X} - \mathbf{1}_n \left(\frac{1}{n} \mathbf{X}^\top \mathbf{1}_n \right)^\top \\ &= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top. \end{aligned}$$

Portanto,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}. \quad (8.53)$$

A matriz $\mathbf{H}_n$ representa a projeção ortogonal sobre o subespaço de $\mathbb{R}^n$ formado pelos vetores cujas componentes somam zero. Aplicá-la às colunas de $\mathbf{X}$ remove a componente na direção de $\mathbf{1}_n$.

A matriz original pode ser decomposta como

$$\mathbf{X} = \mathbf{1}_n \bar{\mathbf{x}}^\top + \mathbf{X}_c. \quad (8.54)$$

O primeiro termo contém o centro observado repetido em todas as linhas. O segundo reúne os desvios das observações em relação a esse centro.

8.7.2 Matriz SSCP e covariância observada

Definição 8.9 (Matriz total de somas de quadrados e produtos cruzados). A **matriz total de somas de quadrados e produtos cruzados**, ou matriz total SSCP, é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (8.55)$$

A sigla SSCP deriva da expressão em inglês *sum of squares and cross-products*. Utilizando a matriz de dados centralizada,

$$\mathbf{T} = \mathbf{X}_c^\top \mathbf{X}_c. \quad (8.56)$$

Pela expressão Equação 8.53 e pelas propriedades de $\mathbf{H}_n$,

$$\begin{aligned} \mathbf{T} &= (\mathbf{H}_n \mathbf{X})^\top (\mathbf{H}_n \mathbf{X}) \\ &= \mathbf{X}^\top \mathbf{H}_n^\top \mathbf{H}_n \mathbf{X} \\ &= \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \end{aligned}$$

Logo,

$$\mathbf{T} = \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.57)$$

O elemento situado na linha j e na coluna k de $\mathbf{T}$ é

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k). \quad (8.58)$$

Quando $j = k$,

$$t_{jj} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2,$$

que é a soma dos quadrados dos desvios da variável j .

Quando $j \neq k$,

$$t_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k),$$

que é a soma dos produtos cruzados entre as variáveis j e k .

A matriz $\mathbf{T}$ é simétrica e positiva semidefinida. Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \mathbf{T} \mathbf{a} &= \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{X}_c \mathbf{a} \\ &= (\mathbf{X}_c \mathbf{a})^\top (\mathbf{X}_c \mathbf{a}) \\ &= \|\mathbf{X}_c \mathbf{a}\|^2 \\ &\geq 0.\end{aligned}\tag{8.59}$$

O vetor $\mathbf{X}_c \mathbf{a}$ contém os valores centralizados da combinação linear das colunas de $\mathbf{X}$ determinada por $\mathbf{a}$. A forma quadrática em Equação 8.59 é a soma dos quadrados desses valores.

O produto

$$\mathbf{X}^\top \mathbf{X}$$

reúne somas de quadrados e produtos cruzados em relação à origem. A decomposição Equação 8.54 permite separar a posição e a dispersão:

$$\mathbf{X}^\top \mathbf{X} = n \overline{\mathbf{x}} \overline{\mathbf{x}}^\top + \mathbf{T}.\tag{8.60}$$

A identidade Equação 8.60 é a versão matricial da expressão univariada

$$\sum_{i=1}^n x_i^2 = n \bar{x}^2 + \sum_{i=1}^n (x_i - \bar{x})^2.$$

O termo

$$n \overline{\mathbf{x}} \overline{\mathbf{x}}^\top$$

registra a posição do centro observado em relação à origem. A matriz $\mathbf{T}$ registra a dispersão em relação a esse centro.

Definição 8.10 (Matriz de covariâncias observada). A matriz de covariâncias calculada a partir das observações é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{T}.$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{X}. \quad (8.61)$$

O elemento (j, k) de $\mathbf{S}$ é

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k). \quad (8.62)$$

Os elementos diagonais são as variâncias calculadas para as colunas:

$$s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2.$$

Os elementos fora da diagonal são as covariâncias calculadas entre pares de colunas:

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), \quad j \neq k.$$

Como $\mathbf{S}$ é um múltiplo positivo de $\mathbf{T}$, ela é simétrica e positiva semidefinida.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = \frac{1}{n-1} \|\mathbf{X}_c \mathbf{a}\|^2. \quad (8.63)$$

A expressão Equação 8.63 é a variância calculada para a combinação linear das colunas de $\mathbf{X}$ definida por $\mathbf{a}$.

O divisor $n-1$ é adotado nesta seção como convenção para a descrição da covariância observada. Sua relação com graus de liberdade, ausência de viés e máxima verossimilhança será desenvolvida no Capítulo 10.

8.7.3 Matriz de correlações observada

Suponha que todas as variâncias observadas sejam positivas:

$$s_{jj} > 0, \quad j = 1, \dots, p.$$

Defina a matriz diagonal dos desvios-padrão observados por

$$\mathbf{D}_s = \text{diag}(\sqrt{s_{11}}, \dots, \sqrt{s_{pp}}).$$

Definição 8.11 (Matriz de correlações observada). A matriz de correlações calculada a partir dos dados é

$$\mathbf{R} = \mathbf{D}_s^{-1} \mathbf{S} \mathbf{D}_s^{-1}. \quad (8.64)$$

Seu elemento (j, k) é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (8.65)$$

A diagonal de $\mathbf{R}$ é unitária, e seus elementos pertencem ao intervalo $[-1, 1]$.

A relação inversa é

$$\mathbf{S} = \mathbf{D}_s \mathbf{R} \mathbf{D}_s. \quad (8.66)$$

Assim como no nível populacional, $\mathbf{S}$ reúne as escalas e as associações lineares, enquanto $\mathbf{R}$ registra a estrutura padronizada.

A matriz $\mathbf{R}$ também pode ser obtida pela padronização das colunas de $\mathbf{X}_c$. Defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}_s^{-1}. \quad (8.67)$$

A coluna j de $\mathbf{Z}$ contém os desvios da variável j divididos pelo desvio-padrão observado correspondente. Então,

$$\begin{aligned} \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z} &= \frac{1}{n-1} \mathbf{D}_s^{-1} \mathbf{X}_c^\top \mathbf{X}_c \mathbf{D}_s^{-1} \\ &= \mathbf{D}_s^{-1} \mathbf{S} \mathbf{D}_s^{-1} \\ &= \mathbf{R}. \end{aligned}$$

Portanto,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z}. \quad (8.68)$$

A expressão Equação 8.68 mostra que a matriz de correlações observada é uma matriz de Gram das colunas padronizadas, ajustada pelo fator $1/(n-1)$.

8.7.4 Covariâncias cruzadas observadas

Considere duas matrizes de dados observados,

$$\mathbf{X} \in \mathbb{R}^{n \times p}$$

e

$$\mathbf{Y} \in \mathbb{R}^{n \times q},$$

cujas linhas correspondem às mesmas n unidades observacionais.

Os vetores de médias das colunas são

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n$$

e

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n.$$

As matrizes centralizadas são

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}$$

e

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y}.$$

Definição 8.12 (Matriz de somas de produtos cruzados entre blocos). A matriz de somas de produtos cruzados entre os blocos $\mathbf{X}$ e $\mathbf{Y}$ é

$$\mathbf{T}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{T}_{XY} = \mathbf{X}^\top \mathbf{H}_n \mathbf{Y}. \quad (8.69)$$

Como $\mathbf{X}_c$ possui p colunas e $\mathbf{Y}_c$ possui q colunas,

$$\mathbf{T}_{XY} \in \mathbb{R}^{p \times q}.$$

Seu elemento (j, k) é

$$(\mathbf{T}_{XY})_{jk} = \sum_{i=1}^n (x_{ij} - \bar{x}_j) (y_{ik} - \bar{y}_k).$$

A orientação dos blocos determina a orientação da matriz:

$$\mathbf{T}_{YX} = \mathbf{T}_{XY}^\top.$$

Definição 8.13 (Matriz de covariâncias cruzadas observada). A matriz de covariâncias cruzadas calculada a partir dos dados é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c.$$

Equivalentemente,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{H}_n \mathbf{Y}. \quad (8.70)$$

Seu elemento (j, k) é

$$s_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j) (y_{ik} - \bar{y}_k).$$

A matriz $\mathbf{S}_{XY}$ não precisa ser quadrada nem simétrica. Sua transposta satisfaz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top. \quad (8.71)$$

Considere as combinações lineares calculadas para as observações:

$$\mathbf{u} = \mathbf{X}\mathbf{a}, \quad \mathbf{a} \in \mathbb{R}^p,$$

e

$$\mathbf{v} = \mathbf{Y}\mathbf{b}, \quad \mathbf{b} \in \mathbb{R}^q.$$

As versões centralizadas são

$$\mathbf{u}_c = \mathbf{X}_c \mathbf{a}$$

e

$$\mathbf{v}_c = \mathbf{Y}_c \mathbf{b}.$$

A covariância observada entre essas combinações é

$$\begin{aligned} s_{uv} &= \frac{1}{n-1} \mathbf{u}_c^\top \mathbf{v}_c \\ &= \frac{1}{n-1} \mathbf{a}^\top \mathbf{X}_c^\top \mathbf{Y}_c \mathbf{b} \\ &= \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \end{aligned} \tag{8.72}$$

A expressão Equação 8.72 é a contraparte descritiva de Equação 8.12.

As matrizes dos dois blocos podem ser concatenadas horizontalmente:

$$\mathbf{X}_{XY} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{n \times (p+q)}.$$

A matriz de covariâncias calculada para o conjunto completo possui a estrutura

$$\mathbf{S}_{XY, \text{conj}} = \begin{bmatrix} \mathbf{S}_{XX} & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_{YY} \end{bmatrix}. \tag{8.73}$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto. Os blocos fora da diagonal descrevem as covariâncias entre variáveis pertencentes a conjuntos distintos.

Se todas as variâncias observadas são positivas, definem-se

$$\mathbf{D}_X = \text{diag} \left(\sqrt{s_{X_1 X_1}}, \dots, \sqrt{s_{X_p X_p}} \right)$$

e

$$\mathbf{D}_Y = \text{diag} \left(\sqrt{s_{Y_1 Y_1}}, \dots, \sqrt{s_{Y_q Y_q}} \right).$$

A matriz de correlações cruzadas observada é

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1} \mathbf{S}_{XY} \mathbf{D}_Y^{-1}. \tag{8.74}$$

Seu elemento (j, k) é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}}.$$

Cada elemento mede a associação linear padronizada entre uma variável do primeiro bloco e uma variável do segundo. A matriz $\mathbf{R}_{XY}$ não reúne isoladamente toda a estrutura dos dois conjuntos, pois as correlações internas contidas em $\mathbf{R}_{XX}$ e $\mathbf{R}_{YY}$ também participam das relações entre combinações lineares dos blocos.

A matriz $\mathbf{T}$ descreve a dispersão total das observações em torno de $\bar{\mathbf{x}}$. Quando as observações pertencem a grupos previamente identificados, essa dispersão pode ser decomposta em uma parcela interna aos grupos e outra associada às diferenças entre seus centros.

8.8 Decomposição da dispersão por grupos

Considere as n observações da matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$ distribuídas em G grupos não vazios. O grupo g contém n_g observações, com

$$n_1 + \cdots + n_G = n.$$

Represente a observação i do grupo g por

$$\mathbf{x}_{ig} \in \mathbb{R}^p,$$

para

$$i = 1, \dots, n_g \quad \text{e} \quad g = 1, \dots, G.$$

O vetor de médias do grupo g é

$$\bar{\mathbf{x}}_g = \frac{1}{n_g} \sum_{i=1}^{n_g} \mathbf{x}_{ig}, \quad (8.75)$$

enquanto o vetor de médias de todas as observações é

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{g=1}^G \sum_{i=1}^{n_g} \mathbf{x}_{ig}.$$

A média total também pode ser escrita como uma média ponderada das médias dos grupos:

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{g=1}^G n_g \bar{\mathbf{x}}_g. \quad (8.76)$$

A dispersão total em torno de $\bar{\mathbf{x}}$ pode ser separada em duas parcelas:

- variação das observações em torno das médias de seus grupos;
- variação das médias dos grupos em torno da média total.

8.8.1 Parcelas total, intragrupos e entre grupos

A matriz total SSCP é

$$\mathbf{T} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}) (\mathbf{x}_{ig} - \bar{\mathbf{x}})^\top. \quad (8.77)$$

Definição 8.14 (Matriz de dispersão intragrupos). A **matriz de dispersão intragrupos** é

$$\mathbf{T}_{\text{intra}} = \sum_{g=1}^G \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)^\top. \quad (8.78)$$

A matriz $\mathbf{T}_{\text{intra}}$ reúne a dispersão existente dentro dos grupos. Cada observação é comparada com a média do grupo ao qual pertence.

Definição 8.15 (Matriz de dispersão entre grupos). A **matriz de dispersão entre grupos** é

$$\mathbf{T}_{\text{entre}} = \sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})^\top. \quad (8.79)$$

A ponderação por n_g registra quantas observações são representadas por cada média de grupo. Grupos maiores contribuem proporcionalmente mais para a dispersão entre os centros.

8.8.2 Identidade de decomposição

Teorema 8.9 (Decomposição da dispersão total). *Para uma partição das observações em G grupos não vazios,*

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \quad (8.80)$$

Comprovação. Para cada observação do grupo g ,

$$\mathbf{x}_{ig} - \bar{\mathbf{x}} = (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) + (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}).$$

Defina

$$\mathbf{u}_{ig} = \mathbf{x}_{ig} - \bar{\mathbf{x}}_g$$

e

$$\mathbf{v}_g = \bar{\mathbf{x}}_g - \bar{\mathbf{x}}.$$

Então,

$$\mathbf{x}_{ig} - \bar{\mathbf{x}} = \mathbf{u}_{ig} + \mathbf{v}_g.$$

O produto externo correspondente é

$$\begin{aligned} & (\mathbf{x}_{ig} - \bar{\mathbf{x}}) (\mathbf{x}_{ig} - \bar{\mathbf{x}})^\top \\ &= \mathbf{u}_{ig} \mathbf{u}_{ig}^\top + \mathbf{u}_{ig} \mathbf{v}_g^\top + \mathbf{v}_g \mathbf{u}_{ig}^\top + \mathbf{v}_g \mathbf{v}_g^\top. \end{aligned}$$

Somando sobre as observações do grupo g ,

$$\sum_{i=1}^{n_g} \mathbf{u}_{ig} = \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g) = \mathbf{0}.$$

Consequentemente, os termos cruzados desaparecem:

$$\sum_{i=1}^{n_g} \mathbf{u}_{ig} \mathbf{v}_g^\top = \mathbf{0}$$

e

$$\sum_{i=1}^{n_g} \mathbf{v}_g \mathbf{u}_{ig}^\top = \mathbf{0}.$$

Como $\mathbf{v}_g$ é constante dentro do grupo,

$$\sum_{i=1}^{n_g} \mathbf{v}_g \mathbf{v}_g^\top = n_g \mathbf{v}_g \mathbf{v}_g^\top.$$

Portanto,

$$\begin{aligned} \mathbf{T} &= \sum_{g=1}^G \sum_{i=1}^{n_g} \mathbf{u}_{ig} \mathbf{u}_{ig}^\top + \sum_{g=1}^G n_g \mathbf{v}_g \mathbf{v}_g^\top \\ &= \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}. \end{aligned}$$

□

A identidade Equação 8.80 é algébrica. Ela depende apenas da definição das médias e da partição das observações. Não exige normalidade, independência ou qualquer modelo probabilístico (Rencher; Christensen, 2012).

Para qualquer direção $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} + \mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a}. \quad (8.81)$$

Cada termo de Equação 8.81 possui uma interpretação univariada. A primeira parcela representa a soma dos quadrados dentro dos grupos para a combinação linear $\mathbf{a}^\top \mathbf{x}$. A segunda representa a soma dos quadrados entre as médias dos grupos dessa combinação.

8.8.3 Semidefinição positiva e limites de posto

As três matrizes da decomposição são simétricas e positivas semidefinidas.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T}_{\text{intra}} \mathbf{a} = \sum_{g=1}^G \sum_{i=1}^{n_g} [\mathbf{a}^\top (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)]^2 \geq 0$$

e

$$\mathbf{a}^\top \mathbf{T}_{\text{entre}} \mathbf{a} = \sum_{g=1}^G n_g [\mathbf{a}^\top (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})]^2 \geq 0.$$

A matriz total satisfaz

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1), \quad (8.82)$$

porque as n linhas centralizadas possuem soma igual a zero.

Dentro de cada grupo, os desvios em relação à média do grupo também somam zero. Como são impostas G restrições de centralização, uma por grupo,

$$\text{posto}(\mathbf{T}_{\text{intra}}) \leq \min(p, n - G). \quad (8.83)$$

Para a dispersão entre grupos,

$$\sum_{g=1}^G n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}}) = \mathbf{0}.$$

Assim, os G vetores de desvios entre as médias dos grupos e a média total possuem uma relação linear ponderada, o que implica

$$\text{posto}(\mathbf{T}_{\text{entre}}) \leq \min(p, G - 1). \quad (8.84)$$

Os limites de posto mostram que:

- a dispersão total ocupa no máximo $n - 1$ direções;
- a dispersão intragrupos ocupa no máximo $n - G$ direções;
- a dispersão entre grupos ocupa no máximo $G - 1$ direções.

Esses limites podem ser estritos quando há relações lineares adicionais entre as variáveis ou entre os centros dos grupos.

Exemplo 8.13 (Decomposição em uma direção). Considere uma direção $\mathbf{a} \in \mathbb{R}^p$ e defina

$$y_{ig} = \mathbf{a}^\top \mathbf{x}_{ig}.$$

A média da variável projetada no grupo g é

$$\bar{y}_g = \mathbf{a}^\top \bar{\mathbf{x}}_g,$$

e sua média total é

$$\bar{y} = \mathbf{a}^\top \bar{\mathbf{x}}.$$

Aplicando a forma quadrática à identidade Equação 8.80,

$$\sum_{g=1}^G \sum_{i=1}^{n_g} (y_{ig} - \bar{y})^2 = \sum_{g=1}^G \sum_{i=1}^{n_g} (y_{ig} - \bar{y}_g)^2 + \sum_{g=1}^G n_g (\bar{y}_g - \bar{y})^2.$$

A decomposição matricial contém simultaneamente essa identidade para todas as combinações lineares das variáveis.

8.8.4 Relação futura com o modelo linear multivariado

A decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}$$

organiza a dispersão observada segundo dois referenciais:

- as médias internas dos grupos;
- a média total.

No modelo linear multivariado, essa mesma estrutura será expressa por matrizes de projeção. A parcela intragrupos será associada à dispersão residual, enquanto a parcela entre grupos será relacionada à variação atribuída às diferenças entre os vetores de médias.

Neste capítulo, a decomposição é utilizada apenas como identidade geométrica das observações. Sua interpretação por meio de parâmetros, hipóteses lineares, estimadores e distribuições amostrais pertence aos Capítulos 11 e 12.

8.9 Síntese do capítulo

A matriz de covariâncias representa a variabilidade conjunta de um vetor aleatório por meio de um momento central de segunda ordem:

$$\Sigma = E \left[(\mathbf{X} - \mu) (\mathbf{X} - \mu)^\top \right].$$

Ela é simétrica e positiva semidefinida e determina a variância de qualquer combinação linear:

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

A padronização das componentes separa as escalas marginais da estrutura de associação linear:

$$\mathcal{R} = \mathbf{D}_\sigma^{-1} \Sigma \mathbf{D}_\sigma^{-1}.$$

A decomposição espectral de Σ fornece eixos ortogonais de dispersão, enquanto seu traço, seu determinante e sua inversa produzem medidas com funções distintas. A distância de Mahalanobis utiliza a matriz completa de covariâncias para comparar deslocamentos em relação à variabilidade existente em cada direção:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Nos dados observados, a centralização é realizada por

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X},$$

e a matriz de covariâncias amostral observada é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Quando as observações pertencem a grupos, a dispersão total admite a decomposição

$$\mathbf{T} = \mathbf{T}_{\text{intra}} + \mathbf{T}_{\text{entre}}.$$

Ao concluir o capítulo, o estudante deve ser capaz de:

- distinguir covariâncias e correlações populacionais e amostrais;
- calcular a variância e a covariância de combinações lineares;
- verificar simetria, semidefinição positiva, posto e singularidade;
- representar covariâncias entre blocos de variáveis;
- transformar médias e covariâncias sob aplicações afins;
- interpretar os eixos espectrais e as medidas globais de dispersão;
- relacionar a distância de Mahalanobis ao branqueamento;
- expressar centralização, covariâncias e correlações por operações matriciais;
- decompor a dispersão total em parcelas intragrupos e entre grupos.

A matriz de covariâncias descreve a estrutura de segunda ordem de um vetor aleatório, mas não determina, em geral, sua distribuição conjunta. O próximo capítulo introduz a distribuição normal multivariada, na qual o vetor de médias e a matriz de covariâncias determinam a distribuição e permitem desenvolver resultados sobre densidade, marginais, condicionais e independência.

9 Distribuição Normal Multivariada

O Capítulo 8 desenvolveu o vetor de médias, a matriz de covariâncias e a geometria associada à dispersão de um vetor aleatório. Em uma distribuição geral, esses dois primeiros momentos não determinam completamente o comportamento conjunto das componentes. Vetores aleatórios com distribuições distintas podem possuir o mesmo vetor de médias e a mesma matriz de covariâncias.

Na família normal multivariada, essa situação é diferente. O vetor de médias e a matriz de covariâncias determinam toda a distribuição. Além disso, combinações lineares, transformações afins, distribuições marginais e distribuições condicionais permanecem dentro da família normal (Mardia; Kent; Taylor, 2024).

O objetivo deste capítulo é construir esse modelo probabilístico e relacioná-lo aos resultados geométricos do capítulo anterior. Serão estudados os casos não singular e singular, a função densidade, as distribuições marginais e condicionais, a independência entre blocos, o branqueamento e a distribuição probabilística da distância de Mahalanobis.

9.1 Definição e construção

9.1.1 Definição por combinações lineares

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p,$$

com vetor de médias

$$E(\mathbf{X}) = \mu$$

e matriz de covariâncias

$$\text{Cov}(\mathbf{X}) = \Sigma.$$

A distribuição normal multivariada pode ser caracterizada pela normalidade de todas as combinações lineares de suas componentes, incluindo combinações degeneradas com variância igual a zero (Eaton, 2007).

Definição 9.1 (Distribuição normal multivariada). O vetor aleatório $\mathbf{X} \in \mathbb{R}^p$ possui **distribuição normal multivariada** se, para todo vetor constante $\mathbf{a} \in \mathbb{R}^p$, a combinação linear

$$\mathbf{a}^\top \mathbf{X}$$

possui distribuição normal univariada, admitindo-se o caso degenerado em que sua variância é zero.

Quando

$$E(\mathbf{X}) = \mu$$

e

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

escreve-se

$$\mathbf{X} \sim N_p(\mu, \Sigma). \quad (9.1)$$

Pelas propriedades da média e da covariância, para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$E(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mu$$

e

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Consequentemente,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.2)$$

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

a distribuição normal da combinação linear é degenerada, e

$$\mathbf{a}^\top \mathbf{X} = \mathbf{a}^\top \boldsymbol{\mu}$$

com probabilidade 1.

Escolhendo $\mathbf{a} = \mathbf{e}_j$, em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, obtém-se

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

Portanto, cada componente de um vetor normal multivariado possui distribuição normal univariada.

Normalidade marginal e normalidade conjunta

A normalidade de cada componente, considerada separadamente, não é suficiente para garantir que o vetor possua distribuição normal multivariada. A definição exige a normalidade de **todas** as combinações lineares das componentes.

Quando $\|\mathbf{a}\| = 1$, a variável $\mathbf{a}^\top \mathbf{X}$ pode ser interpretada como a coordenada da projeção de $\mathbf{X}$ na direção de $\mathbf{a}$. A definição estabelece, assim, que toda projeção unidimensional do vetor possui distribuição normal.

9.1.2 Construção afim a partir do vetor normal padrão

A distribuição normal multivariada pode ser construída a partir de um vetor cujas componentes são normais padrão independentes.

Considere

$$\mathbf{Z} = \begin{bmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_r \end{bmatrix} \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

Nessa notação, as componentes satisfazem

$$Z_j \sim N(0, 1), \quad j = 1, \dots, r,$$

e são mutuamente independentes.

Sejam ainda

$$\mathbf{A} \in \mathbb{R}^{p \times r}$$

e

$$\mu \in \mathbb{R}^p.$$

Teorema 9.1 (Construção afim de um vetor normal). *Defina*

$$\mathbf{X} = \mu + \mathbf{AZ}. \quad (9.3)$$

Então,

$$\mathbf{X} \sim N_p(\mu, \mathbf{AA}^\top). \quad (9.4)$$

Comprovação. A média de $\mathbf{X}$ é

$$\begin{aligned} E(\mathbf{X}) &= E(\mu + \mathbf{AZ}) \\ &= \mu + \mathbf{A}E(\mathbf{Z}) \\ &= \mu. \end{aligned}$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \text{Cov}(\mathbf{AZ}) \\ &= \mathbf{A} \text{Cov}(\mathbf{Z}) \mathbf{A}^\top \\ &= \mathbf{A} \mathbf{I}_r \mathbf{A}^\top \\ &= \mathbf{AA}^\top. \end{aligned} \quad (9.5)$$

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{X} &= \mathbf{a}^\top \mu + \mathbf{a}^\top \mathbf{AZ} \\ &= \mathbf{a}^\top \mu + (\mathbf{A}^\top \mathbf{a})^\top \mathbf{Z}. \end{aligned}$$

Como toda combinação linear das componentes de $\mathbf{Z}$ é normal, segue que $\mathbf{a}^\top \mathbf{X}$ é normal para todo $\mathbf{a}$. Portanto, $\mathbf{X}$ possui distribuição normal multivariada. $\square$

O resultado mostra que a dependência entre as componentes de $\mathbf{X}$ é introduzida pela transformação linear determinada por $\mathbf{A}$. Embora as componentes de $\mathbf{Z}$ sejam independentes, as componentes de $\mathbf{AZ}$ podem ser correlacionadas.

Toda matriz simétrica e semidefinida positiva admite uma fatoração da forma

$$\Sigma = \mathbf{A}\mathbf{A}^\top. \quad (9.6)$$

Para construir essa fatoração, considere a decomposição espectral

$$\Sigma = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

em que os autovalores são não negativos. Definindo

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}^{1/2},$$

obtém-se

$$\mathbf{A}\mathbf{A}^\top = \mathbf{Q}\mathbf{\Lambda}^{1/2}\mathbf{\Lambda}^{1/2}\mathbf{Q}^\top = \Sigma.$$

Portanto, para qualquer vetor $\mu \in \mathbb{R}^p$ e qualquer matriz simétrica e semidefinida positiva Σ , pode-se construir um vetor com distribuição

$$N_p(\mu, \Sigma).$$

Quando Σ é positiva definida, pode-se utilizar sua raiz quadrada simétrica e escrever

$$\mathbf{X} = \mu + \Sigma^{1/2}\mathbf{Z}, \quad \mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.7)$$

9.1.3 Determinação pelos parâmetros

Em uma distribuição geral, o vetor de médias e a matriz de covariâncias não determinam a distribuição conjunta. O Teorema de Cramér–Wold estabelece que a distribuição de um vetor aleatório é determinada pelo conjunto das distribuições de todas as suas projeções lineares unidimensionais (Eaton, 2007).

Teorema 9.2 (Teorema de Cramér–Wold). *Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios em $\mathbb{R}^p$. Então,*

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}$$

se, e somente se,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo vetor $\mathbf{a} \in \mathbb{R}^p$.

A implicação direta é imediata: vetores com a mesma distribuição produzem combinações lineares com a mesma distribuição. A implicação inversa constitui o conteúdo central do teorema. Ela estabelece que o conjunto de todas as distribuições das projeções lineares determina a distribuição conjunta do vetor.

Alcance do Teorema de Cramér–Wold

O Teorema de Cramér–Wold é um resultado geral sobre distribuições multivariadas e não depende da normalidade. Sua demonstração usual utiliza funções características, que não serão desenvolvidas neste capítulo.

O resultado será empregado aqui para mostrar que uma distribuição normal multivariada é completamente determinada por seu vetor de médias e sua matriz de covariâncias.

Teorema 9.3 (Determinação da distribuição normal pelos parâmetros). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\mathbf{Y} \sim N_p(\mu, \Sigma),$$

então

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

Comprovação. Para qualquer vetor $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a})$$

e

$$\mathbf{a}^\top \mathbf{Y} \sim N(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}).$$

Portanto,

$$\mathbf{a}^\top \mathbf{X} \stackrel{d}{=} \mathbf{a}^\top \mathbf{Y}$$

para todo $\mathbf{a} \in \mathbb{R}^p$. Pelo Teorema de Cramér–Wold,

$$\mathbf{X} \stackrel{d}{=} \mathbf{Y}.$$

□

Assim, na família normal multivariada, o vetor de médias e a matriz de covariâncias especificam completamente a distribuição. Essa propriedade justifica a notação utilizada em Equação 9.1.

9.1.4 Caso singular e suporte efetivo

A matriz $\boldsymbol{\Sigma}$ de uma distribuição normal multivariada pode ser semidefinida positiva e singular. Nesse caso, algumas combinações lineares possuem variância zero e a distribuição fica concentrada em um subespaço afim de dimensão inferior a p (Eaton, 2007).

Definição 9.2 (Distribuição normal multivariada singular). Uma distribuição

$$N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

é denominada **singular** ou **degenerada** quando

$$\text{posto}(\boldsymbol{\Sigma}) = r < p.$$

Quando

$$\text{posto}(\boldsymbol{\Sigma}) = p,$$

a distribuição é denominada **não singular**.

Se $\text{posto}(\Sigma) = r$, a decomposição espectral pode ser escrita como

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\mathbf{Q}_r \in \mathbb{R}^{p \times r}$$

contém os autovetores associados aos autovalores positivos e

$$\Lambda_r = \text{diag}(\lambda_1, \dots, \lambda_r), \quad \lambda_j > 0.$$

Definindo

$$\mathbf{A}_r = \mathbf{Q}_r \Lambda_r^{1/2},$$

tem-se

$$\Sigma = \mathbf{A}_r \mathbf{A}_r^\top$$

e a representação

$$\mathbf{X} \stackrel{d}{=} \mu + \mathbf{A}_r \mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.8)$$

Teorema 9.4 (Suporte efetivo da normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r < p,$$

então

$$P[\mathbf{X} \in \mu + \mathcal{C}(\Sigma)] = 1. \quad (9.9)$$

O suporte efetivo da distribuição é o subespaço afim

$$\mu + \mathcal{C}(\Sigma),$$

de dimensão r .

Como

$$\mathcal{C}(\mathbf{A}_r \mathbf{A}_r^\top) = \mathcal{C}(\mathbf{A}_r),$$

a representação Equação 9.8 mostra que todos os valores possíveis de $\mathbf{X}$ pertencem a

$$\mu + \mathcal{C}(\Sigma).$$

Equivalentemente, se

$$\mathbf{a} \in \mathcal{N}(\Sigma),$$

então

$$\text{Var}[\mathbf{a}^\top (\mathbf{X} - \mu)] = \mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

de modo que

$$\mathbf{a}^\top (\mathbf{X} - \mu) = 0$$

com probabilidade 1.

A distribuição singular não possui densidade em relação ao volume de dimensão p em $\mathbb{R}^p$, pois toda a probabilidade está concentrada em um subconjunto de dimensão inferior. Ela pode, entretanto, ser descrita por uma densidade em relação à medida de Lebesgue de dimensão r induzida em seu suporte afim.

Exemplo 9.1 (Normal bivariada concentrada em uma reta). Considere

$$Z \sim N(0, 1)$$

e defina

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z \end{bmatrix}.$$

Essa construção pode ser escrita como

$$\mathbf{X} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} Z.$$

Logo,

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

A matriz de covariâncias possui posto 1, pois sua segunda coluna é o dobro da primeira. Além disso,

$$X_2 = 2X_1$$

com probabilidade 1.

Toda a distribuição está concentrada na reta

$$x_2 = 2x_1,$$

e não em todo o plano $\mathbb{R}^2$.

Quando

$$\Sigma \succ \mathbf{0},$$

a distribuição é não singular,

$$\det(\Sigma) > 0,$$

e Σ^{-1} existe. Nesse caso, a distribuição possui uma função densidade em todo o espaço $\mathbb{R}^p$, que será desenvolvida na seção seguinte.

9.2 Densidade no caso não singular

A definição por combinações lineares também abrange distribuições normais singulares. Uma função densidade em relação à medida de Lebesgue em $\mathbb{R}^p$, entretanto, existe somente quando a matriz de covariâncias é positiva definida (Mardia; Kent; Taylor, 2024):

$$\Sigma \succ \mathbf{0}.$$

Nessa situação, Σ é invertível e

$$\det(\Sigma) > 0.$$

9.2.1 Função densidade e log-densidade

Definição 9.3 (Função densidade da normal multivariada). Se

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$, então a função densidade de $\mathbf{X}$ é

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right\}, \quad (9.10)$$

para todo $\mathbf{x} \in \mathbb{R}^p$.

Como a distribuição é contínua,

$$P(\mathbf{X} = \mathbf{x}) = 0$$

para qualquer ponto fixo $\mathbf{x} \in \mathbb{R}^p$.

As probabilidades são obtidas pela integração da densidade sobre regiões do espaço:

$$P(\mathbf{X} \in \mathcal{A}) = \int_{\mathcal{A}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}, \quad (9.11)$$

em que

$$\mathcal{A} \subseteq \mathbb{R}^p.$$

A constante presente em Equação 9.10 garante que

$$\int_{\mathbb{R}^p} f_{\mathbf{x}}(\mathbf{x}) d\mathbf{x} = 1.$$

Essa normalização pode ser compreendida pela transformação

$$\mathbf{x} = \mu + \Sigma^{1/2} \mathbf{z}.$$

Como

$$\mathbf{z} = \Sigma^{-1/2} (\mathbf{x} - \mu),$$

tem-se

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \mathbf{z}^\top \mathbf{z}.$$

O valor absoluto do determinante da Jacobiana da transformação é

$$\det(\Sigma^{1/2}) = \det(\Sigma)^{1/2}.$$

Consequentemente,

$$d\mathbf{x} = \det(\Sigma)^{1/2} d\mathbf{z},$$

e a integral da densidade é transformada na integral da densidade normal padrão em $\mathbb{R}^p$.

A forma quadrática no expoente é o quadrado da distância de Mahalanobis ao vetor de médias:

$$d_M^2(\mathbf{x}, \mu) = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Assim, a densidade também pode ser escrita como

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} d_M^2(\mathbf{x}, \mu) \right\}. \quad (9.12)$$

Para parâmetros fixos, a densidade de um ponto depende de sua posição apenas por meio da distância de Mahalanobis ao centro.

A log-densidade é

$$\begin{aligned}\log f_{\mathbf{x}}(\mathbf{x}) = & -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log \det(\Sigma) \\ & - \frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).\end{aligned}\tag{9.13}$$

A expressão contém três parcelas:

- uma constante determinada pela dimensão p ;
- um termo de volume determinado por $\det(\Sigma)$;
- um termo de afastamento determinado pela distância de Mahalanobis.

A estrutura formada por log-determinante e forma quadrática aparecerá novamente na construção da função de verossimilhança para amostras normais multivariadas.

Quando $p = 1$, tem-se

$$\Sigma = [\sigma^2],$$

e Equação 9.10 reduz-se à densidade normal univariada:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}.$$

9.2.2 Papel da média e da matriz de covariâncias

O vetor μ determina a localização da distribuição. Como a forma quadrática de Mahalanobis é não negativa e assume valor zero em $\mathbf{x} = \mu$, a densidade atinge seu máximo no vetor de médias:

$$f_{\mathbf{x}}(\mu) = \frac{1}{(2\pi)^{p/2} \det(\Sigma)^{1/2}}.\tag{9.14}$$

A matriz Σ determina a escala e a orientação da distribuição. Seu determinante controla a escala volumétrica, enquanto sua inversa pondera os afastamentos na forma quadrática presente no expoente da densidade.

Deslocamentos em direções de pequena variância recebem maior peso na distância de Mahalanobis. Deslocamentos em direções de grande variância recebem menor peso. Assim, a densidade considera o afastamento de um ponto em relação à estrutura conjunta de dispersão, e não somente sua distância euclidiana ao centro.

9.2.3 Superfícies de igual densidade

Pela expressão Equação 9.12, dois pontos possuem a mesma densidade quando apresentam a mesma distância de Mahalanobis ao vetor de médias.

Para uma constante $c > 0$, defina

$$\mathcal{S}_c = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = c \right\}. \quad (9.15)$$

Todos os pontos de $\mathcal{S}_c$ possuem densidade

$$\frac{1}{(2\pi)^{p/2} \det(\boldsymbol{\Sigma})^{1/2}} \exp\left(-\frac{c}{2}\right).$$

Esses conjuntos são denominados **superfícies de igual densidade** ou **superfícies de nível**. Em duas dimensões, são elipses; em três dimensões, são elipsoides.

Utilizando a decomposição espectral

$$\boldsymbol{\Sigma} = \mathbf{Q}\boldsymbol{\Lambda}\mathbf{Q}^\top$$

e as coordenadas

$$\mathbf{z} = \mathbf{Q}^\top (\mathbf{x} - \boldsymbol{\mu}),$$

a equação da superfície torna-se

$$\sum_{j=1}^p \frac{z_j^2}{c\lambda_j} = 1. \quad (9.16)$$

Portanto, a superfície está centrada em $\boldsymbol{\mu}$, possui eixos orientados pelos autovetores de $\boldsymbol{\Sigma}$ e semieixos de comprimentos

$$\sqrt{c\lambda_j}, \quad j = 1, \dots, p.$$

A geometria desses elipsoides foi desenvolvida no Capítulo 8. A consequência específica do modelo normal é que eles representam também superfícies de densidade constante.

A Figura 9.1 apresenta o mapa de densidade e as curvas de nível de uma distribuição normal bivariada.




Figura 9.1: Mapa de densidade e curvas de nível de uma distribuição normal bivariada.

A orientação inclinada das curvas decorre da covariância positiva entre as componentes. A maior extensão ocorre na direção associada ao maior autovalor de Σ .

A superfície $\mathcal{S}_c$ contém apenas os pontos cuja distância quadrática de Mahalanobis é exatamente c . A região interna correspondente é

$$\mathcal{E}_c = \{\mathbf{x} \in \mathbb{R}^p : d_M^2(\mathbf{x}, \mu) \leq c\}. \quad (9.17)$$

A probabilidade contida em $\mathcal{E}_c$ ainda depende da escolha de c . Essa probabilidade será determinada posteriormente por meio da distribuição qui-quadrado da distância de Mahalanobis.

A família normal também permanece estável quando o vetor é projetado, reescalado ou submetido a uma transformação afim. Essa propriedade permitirá obter diretamente as distribuições de combinações lineares, subvetores e versões padronizadas.

9.3 Transformações, marginais e padronização

A família normal multivariada é fechada sob transformações lineares e afins. Essa propriedade permite obter diretamente as distribuições de combinações lineares, subvetores, projeções e versões padronizadas, sem integrar a densidade conjunta em cada caso (Anderson, 2003).

9.3.1 Fechamento sob transformações afins

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

uma matriz constante

$$\mathbf{A} \in \mathbb{R}^{m \times p}$$

e um vetor constante

$$\mathbf{b} \in \mathbb{R}^m.$$

Teorema 9.5 (Transformação afim de um vetor normal). *Se*

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}, \quad (9.18)$$

então

$$\mathbf{Y} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top). \quad (9.19)$$

Comprovação. A média de $\mathbf{Y}$ é

$$\begin{aligned} E(\mathbf{Y}) &= E(\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= \mathbf{A}E(\mathbf{X}) + \mathbf{b} \\ &= \mathbf{A}\boldsymbol{\mu} + \mathbf{b}. \end{aligned}$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top. \end{aligned}$$

Para mostrar a normalidade conjunta, considere qualquer vetor

$$\mathbf{c} \in \mathbb{R}^m.$$

A combinação linear das componentes de $\mathbf{Y}$ é

$$\begin{aligned} \mathbf{c}^\top \mathbf{Y} &= \mathbf{c}^\top (\mathbf{A}\mathbf{X} + \mathbf{b}) \\ &= (\mathbf{A}^\top \mathbf{c})^\top \mathbf{X} + \mathbf{c}^\top \mathbf{b}. \end{aligned}$$

Como $\mathbf{X}$ é normal multivariado, a variável

$$(\mathbf{A}^\top \mathbf{c})^\top \mathbf{X}$$

é normal. A adição da constante $\mathbf{c}^\top \mathbf{b}$ preserva a normalidade. Portanto, toda combinação linear das componentes de $\mathbf{Y}$ é normal, o que demonstra o resultado. $\square$

O teorema permanece válido quando $\mathbf{A}$ não possui posto completo. Nesse caso,

$$\mathbf{A}\Sigma\mathbf{A}^\top$$

pode ser singular, e a distribuição de $\mathbf{Y}$ fica concentrada em um subespaço afim de dimensão inferior a m .

Se $\mathbf{A}$ é quadrada e invertível, a transformação produz uma reparametrização afim do espaço. Se $\mathbf{A}$ possui menos linhas que colunas, a transformação pode representar uma projeção ou redução de dimensão. Se possui mais linhas que colunas, a distribuição transformada é necessariamente singular quando

$$m > p.$$

Exemplo 9.2 (Transformação de um vetor normal bivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Defina

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \mathbf{X} + \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

As componentes transformadas são

$$Y_1 = X_1 + X_2$$

e

$$Y_2 = X_1 - X_2 + 3.$$

O vetor de médias é

$$\begin{aligned} E(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} 3 \\ 4 \end{bmatrix}. \end{aligned}$$

A matriz de covariâncias é

$$\begin{aligned}\text{Cov}(\mathbf{Y}) &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix}.\end{aligned}$$

Portanto,

$$\mathbf{Y} \sim N_2 \left(\begin{bmatrix} 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 8 & 2 \\ 2 & 4 \end{bmatrix} \right).$$

9.3.2 Distribuição de combinações lineares

A distribuição de uma combinação linear é um caso particular de Teorema 9.5.

Se

$$\mathbf{a} \in \mathbb{R}^p$$

e

$$Y = \mathbf{a}^\top \mathbf{X} + b,$$

então

$$Y \sim N(\mathbf{a}^\top \mu + b, \mathbf{a}^\top \Sigma \mathbf{a}). \quad (9.20)$$

Essa propriedade permite obter diretamente a distribuição de:

- somas e diferenças entre componentes;
- médias ponderadas;
- contrastes;
- projeções em direções específicas;
- índices construídos como combinações lineares.

Exemplo 9.3 (Soma e diferença de componentes conjuntamente normais). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \right).$$

Para

$$Y_1 = X_1 + X_2,$$

tem-se

$$Y_1 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\sigma_{12}).$$

Para

$$Y_2 = X_1 - X_2,$$

tem-se

$$Y_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\sigma_{12}).$$

A covariância entre X_1 e X_2 aumenta a variância da soma e reduz a variância da diferença quando $\sigma_{12} > 0$. Quando $\sigma_{12} < 0$, ocorre o efeito oposto.

Se

$$\mathbf{a}^\top \Sigma \mathbf{a} = 0,$$

a combinação linear é degenerada:

$$\mathbf{a}^\top \mathbf{X} + b = \mathbf{a}^\top \mu + b$$

com probabilidade 1.

9.3.3 Distribuições marginais

Uma distribuição marginal é obtida selecionando apenas algumas componentes do vetor aleatório.

Considere o particionamento

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.21)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2},$$

e

$$p_1 + p_2 = p.$$

Teorema 9.6 (Distribuições marginais da normal multivariada). *Sob o particionamento em Equação 9.21,*

$$\mathbf{X}_1 \sim N_{p_1}(\mu_1, \Sigma_{11}) \quad (9.22)$$

e

$$\mathbf{X}_2 \sim N_{p_2}(\mu_2, \Sigma_{22}). \quad (9.23)$$

Comprovação. O primeiro bloco pode ser escrito como

$$\mathbf{X}_1 = \mathbf{A}_1 \mathbf{X},$$

em que

$$\mathbf{A}_1 = [\mathbf{I}_{p_1} \quad \mathbf{0}].$$

Pelo teorema da transformação afim,

$$\mathbf{X}_1 \sim N_{p_1}(\mathbf{A}_1 \mu, \mathbf{A}_1 \Sigma \mathbf{A}_1^\top).$$

Pela estrutura particionada,

$$\mathbf{A}_1 \mu = \mu_1$$

e

$$\mathbf{A}_1 \Sigma \mathbf{A}_1^\top = \Sigma_{11}.$$

O resultado para $\mathbf{X}_2$ é obtido de modo análogo. □

A distribuição marginal de um bloco depende apenas de seu vetor de médias e de sua matriz de covariâncias. O bloco de covariâncias cruzadas

$$\Sigma_{12}$$

não aparece na densidade marginal de $\mathbf{X}_1$, embora seja necessário para descrever a dependência conjunta entre os dois blocos.

Exemplo 9.4 (Marginal de um vetor normal trivariado). Considere

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N_3 \left(\begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0.5 \\ -1 & 0.5 & 2 \end{bmatrix} \right).$$

Selecionando as componentes X_1 e X_3 ,

$$\begin{bmatrix} X_1 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \right).$$

A média marginal é formada pelas posições correspondentes do vetor de médias, e a covariância marginal é a submatriz principal associada às variáveis selecionadas.

As distribuições marginais permanecem normais mesmo quando a distribuição conjunta é singular. A matriz de covariâncias marginal pode ser positiva definida ou singular, dependendo das componentes selecionadas.

9.3.4 Padronização marginal e branqueamento

A padronização marginal remove as médias e divide cada componente por seu desvio-padrão.

Suponha que

$$\sigma_{jj} > 0, \quad j = 1, \dots, p,$$

e defina

$$\mathbf{D}_\sigma = \text{diag}(\sigma_1, \dots, \sigma_p),$$

em que

$$\sigma_j = \sqrt{\sigma_{jj}}.$$

O vetor marginalmente padronizado é

$$\mathbf{Z}_{\text{pad}} = \mathbf{D}_{\sigma}^{-1} (\mathbf{X} - \mu). \quad (9.24)$$

Pelo teorema da transformação afim,

$$\mathbf{Z}_{\text{pad}} \sim N_p(\mathbf{0}, \mathcal{R}), \quad (9.25)$$

em que

$$\mathcal{R} = \mathbf{D}_{\sigma}^{-1} \Sigma \mathbf{D}_{\sigma}^{-1}$$

é a matriz de correlações populacional.

Cada componente satisfaz

$$Z_{\text{pad},j} \sim N(0, 1).$$

Entretanto, as componentes do vetor padronizado não são necessariamente independentes, pois sua matriz de covariâncias é $\mathcal{R}$ e pode possuir elementos não nulos fora da diagonal.

Padronização não implica independência

A padronização marginal transforma cada componente em uma variável normal padrão, mas não remove as correlações entre as componentes. As variáveis padronizadas serão independentes somente quando

$$\mathcal{R} = \mathbf{I}_p.$$

Quando

$$\Sigma \succ \mathbf{0},$$

pode-se realizar o branqueamento:

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu). \quad (9.26)$$

Pela transformação afim,

$$\begin{aligned}\mathbf{Z} &\sim N_p(\mathbf{0}, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) \\ &= N_p(\mathbf{0}, \mathbf{I}_p).\end{aligned}$$

Portanto,

$$\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (9.27)$$

Como o vetor branqueado é conjuntamente normal e possui matriz de covariâncias identidade, suas componentes são normais padrão independentes.

A distinção entre padronização marginal e branqueamento é:

$$\mathbf{D}_\sigma^{-1}(\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathcal{R}),$$

enquanto

$$\Sigma^{-1/2}(\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

A primeira transformação remove as escalas marginais. A segunda remove simultaneamente escalas e correlações.

A matriz de branqueamento não é única. Se $\mathbf{Q}_0$ é ortogonal, então

$$\mathbf{Q}_0 \Sigma^{-1/2}(\mathbf{X} - \mu)$$

também possui distribuição

$$N_p(\mathbf{0}, \mathbf{I}_p).$$

A não unicidade corresponde a uma rotação ou reflexão adicional no espaço branqueado.

No caso singular, com

$$\text{posto}(\Sigma) = r < p,$$

pode-se utilizar a decomposição reduzida

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top$$

e definir

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu). \quad (9.28)$$

Então,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r). \quad (9.29)$$

Essa transformação atua apenas nas direções com variância positiva e representa a distribuição no espaço efetivo de dimensão r .

O fechamento por transformações afins também permite analisar conjuntamente blocos de variáveis. Na família normal, a ausência de covariância entre blocos possui uma consequência mais forte do que em distribuições gerais: ela implica independência.

9.4 Independência e distribuições condicionais

Em distribuições gerais, covariância nula e independência são propriedades distintas. Variáveis dependentes podem apresentar covariância igual a zero quando sua associação não é adequadamente representada por uma relação linear.

Para blocos pertencentes ao mesmo vetor normal multivariado, a situação é mais restritiva: a covariância cruzada nula é equivalente à independência entre os blocos. Essa equivalência depende da normalidade conjunta e permanece válida no caso normal singular (Anderson, 2003).

9.4.1 Independência entre blocos conjuntamente normais

Considere o vetor particionado

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right), \quad (9.30)$$

em que

$$\mathbf{X}_1 \in \mathbb{R}^{p_1}, \quad \mathbf{X}_2 \in \mathbb{R}^{p_2}$$

e

$$p_1 + p_2 = p.$$

Se os dois blocos são independentes, suas covariâncias cruzadas são nulas:

$$\mathbf{X}_1 \perp \mathbf{X}_2 \implies \Sigma_{12} = \mathbf{0}.$$

Essa implicação vale para quaisquer vetores aleatórios independentes com segundos momentos finitos. A implicação inversa exige hipóteses adicionais e, em particular, não é válida para distribuições conjuntas gerais.

Teorema 9.7 (Independência de blocos conjuntamente normais). *Para os blocos do vetor normal multivariado em Equação 9.30,*

$$\mathbf{X}_1 \perp \mathbf{X}_2$$

se, e somente se,

$$\Sigma_{12} = \mathbf{0}. \tag{9.31}$$

Comprovação. Se

$$\mathbf{X}_1 \perp \mathbf{X}_2,$$

então

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \mathbf{0}.$$

Para demonstrar a implicação inversa, suponha que

$$\Sigma_{12} = \mathbf{0}.$$

A matriz de covariâncias conjunta possui, então, a forma diagonal em blocos:

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix}.$$

Escolha matrizes $\mathbf{A}_1$ e $\mathbf{A}_2$ tais que

$$\Sigma_{11} = \mathbf{A}_1 \mathbf{A}_1^\top$$

e

$$\Sigma_{22} = \mathbf{A}_2 \mathbf{A}_2^\top.$$

Considere vetores normais padrão independentes,

$$\mathbf{Z}_1 \perp \mathbf{Z}_2,$$

e defina

$$\mathbf{Y}_1 = \mu_1 + \mathbf{A}_1 \mathbf{Z}_1$$

e

$$\mathbf{Y}_2 = \mu_2 + \mathbf{A}_2 \mathbf{Z}_2.$$

Os vetores $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são independentes. Além disso,

$$\begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{bmatrix} \right).$$

Como uma distribuição normal multivariada é determinada por seu vetor de médias e por sua matriz de covariâncias,

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \stackrel{d}{=} \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}.$$

Portanto,

$$\mathbf{X}_1 \perp \mathbf{X}_2.$$

□

O resultado permanece válido quando a matriz de covariâncias conjunta é singular. A independência decorre da estrutura diagonal em blocos e não da existência de uma densidade em todo o espaço $\mathbb{R}^p$.

Como caso particular, se

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e Σ é diagonal, então as componentes

$$X_1, \dots, X_p$$

são mutuamente independentes.

A normalidade deve ser conjunta

A equivalência entre covariância nula e independência exige que as variáveis pertençam ao mesmo vetor normal multivariado. Não basta que cada variável possua, separadamente, uma distribuição normal.

9.4.2 Distribuição condicional

Em um vetor normal multivariado particionado, a distribuição de um bloco condicionada ao valor do outro permanece normal. Sua média é uma função afim do bloco condicionante e sua matriz de covariâncias é dada pelo complemento de Schur correspondente (Anderson, 2003).

Considere novamente

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

com

$$\Sigma \succ \mathbf{0}.$$

Como Σ_{22} é uma submatriz principal de uma matriz positiva definida,

$$\Sigma_{22} \succ \mathbf{0}$$

e sua inversa existe.

Defina

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2) \quad (9.32)$$

e

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}. \quad (9.33)$$

Teorema 9.8 (Distribuição condicional da normal multivariada). *Sob as condições anteriores,*

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1} \left(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2} \right). \quad (9.34)$$

Comprovação. Defina o vetor residual

$$\mathbf{E}_{1|2} = \mathbf{X}_1 - \mu_1 - \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{X}_2 - \mu_2). \quad (9.35)$$

Como $\mathbf{E}_{1|2}$ e $\mathbf{X}_2$ são transformações afins de um vetor normal multivariado, o vetor conjunto

$$\begin{bmatrix} \mathbf{E}_{1|2} \\ \mathbf{X}_2 \end{bmatrix}$$

também possui distribuição normal multivariada.

A covariância cruzada entre o resíduo e o bloco condicionante é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}, \mathbf{X}_2) &= \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \\ &= \mathbf{0}. \end{aligned}$$

Pelo Teorema Teorema 9.7,

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2. \quad (9.36)$$

A média do resíduo é

$$E(\mathbf{E}_{1|2}) = \mathbf{0}.$$

Sua matriz de covariâncias é

$$\begin{aligned} \text{Cov}(\mathbf{E}_{1|2}) &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \\ &= \Sigma_{11 \cdot 2}. \end{aligned}$$

Logo,

$$\mathbf{E}_{1|2} \sim N_{p_1}(\mathbf{0}, \Sigma_{11 \cdot 2}).$$

Reorganizando Equação 9.35,

$$\mathbf{X}_1 = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \mu_2) + \mathbf{E}_{1|2}.$$

Ao fixar

$$\mathbf{X}_2 = \mathbf{x}_2,$$

o primeiro e o segundo termos tornam-se constantes. O resíduo mantém sua distribuição, pois é independente de $\mathbf{X}_2$. Portanto,

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11 \cdot 2}).$$

□

A demonstração fornece também a decomposição

$$\mathbf{X}_1 = \mu_{1|2}(\mathbf{X}_2) + \mathbf{E}_{1|2}, \quad (9.37)$$

em que

$$\mathbf{E}_{1|2} \perp \mathbf{X}_2.$$

A parte

$$\mu_{1|2}(\mathbf{X}_2)$$

descreve a variação de $\mathbf{X}_1$ associada linearmente a $\mathbf{X}_2$. O vetor $\mathbf{E}_{1|2}$ representa a parcela residual.

9.4.3 Média condicional e atualização linear

A média condicional é uma função afim do valor observado:

$$E(\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2). \quad (9.38)$$

A diferença

$$\mathbf{x}_2 - \mu_2$$

mede o afastamento do valor conhecido em relação à média do segundo bloco. A matriz

$$\Sigma_{12}\Sigma_{22}^{-1}$$

transforma esse afastamento em um ajuste para a média do primeiro bloco.

Quando

$$\mathbf{x}_2 = \mu_2,$$

não há deslocamento:

$$\mu_{1|2}(\mu_2) = \mu_1.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

a média condicional não depende de $\mathbf{x}_2$:

$$\mu_{1|2}(\mathbf{x}_2) = \mu_1.$$

Nesse caso, a ausência de atualização é consequência da independência dos blocos.

A decomposição Equação 9.37 possui a forma de uma relação linear entre blocos, acrescida de um vetor residual independente. Essa estrutura será retomada no estudo do modelo linear multivariado.

9.4.4 Covariância condicional e complemento de Schur

A matriz de covariâncias condicionais é

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}.$$

Ela é o complemento de Schur de Σ_{22} em Σ .

Como $\Sigma \succ \mathbf{0}$,

$$\Sigma_{11 \cdot 2} \succ \mathbf{0}. \quad (9.39)$$

A matriz condicional não depende do valor específico $\mathbf{x}_2$. Diferentes valores do bloco condicionante alteram a média condicional, mas preservam a mesma matriz de covariâncias.

A diferença entre as covariâncias marginal e condicional é

$$\Sigma_{11} - \Sigma_{11 \cdot 2} = \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \quad (9.40)$$

Para qualquer vetor $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\begin{aligned} & \mathbf{a}^\top \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \mathbf{a} \\ &= \left(\Sigma_{22}^{-1/2} \Sigma_{21} \mathbf{a} \right)^\top \left(\Sigma_{22}^{-1/2} \Sigma_{21} \mathbf{a} \right) \\ &\geq 0. \end{aligned}$$

Portanto,

$$\Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \succeq \mathbf{0}$$

e

$$\Sigma_{11 \cdot 2} \preceq \Sigma_{11}. \quad (9.41)$$

No sentido da ordem de Loewner, a variabilidade condicional não supera a variabilidade marginal. O conhecimento de $\mathbf{X}_2$ reduz ou mantém a incerteza sobre combinações lineares de $\mathbf{X}_1$.

Para qualquer $\mathbf{a} \in \mathbb{R}^{p_1}$,

$$\text{Var} [\mathbf{a}^\top \mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2] = \mathbf{a}^\top \Sigma_{11 \cdot 2} \mathbf{a} \leq \mathbf{a}^\top \Sigma_{11} \mathbf{a}.$$

Quando

$$\Sigma_{12} = \mathbf{0},$$

tem-se

$$\Sigma_{11 \cdot 2} = \Sigma_{11}.$$

Nesse caso, conhecer o segundo bloco não altera a média nem a covariância do primeiro, confirmando a independência.

9.4.5 Caso bivariado

Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \right), \quad (9.42)$$

com

$$\sigma_1 > 0, \quad \sigma_2 > 0$$

e

$$-1 < \rho < 1.$$

Aplicando Equação 9.32,

$$\begin{aligned} E(X_1 | X_2 = x_2) &= \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2} (x_2 - \mu_2) \\ &= \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2). \end{aligned} \quad (9.43)$$

A variância condicional é

$$\begin{aligned} \text{Var}(X_1 | X_2 = x_2) &= \sigma_1^2 - \frac{\rho^2 \sigma_1^2 \sigma_2^2}{\sigma_2^2} \\ &= \sigma_1^2 (1 - \rho^2). \end{aligned} \quad (9.44)$$

Portanto,

$$X_1 \mid X_2 = x_2 \sim N \left[\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right]. \quad (9.45)$$

Se $\rho > 0$, valores de X_2 acima de μ_2 deslocam a média condicional de X_1 para valores maiores. Se $\rho < 0$, o deslocamento ocorre na direção oposta.

A intensidade do deslocamento depende de:

- ρ , que determina o sentido e a força da associação;
- σ_1/σ_2 , que ajusta as diferentes escalas;
- $x_2 - \mu_2$, que mede o afastamento do valor condicionado.

A variância condicional depende de ρ^2 . Quanto maior o valor absoluto da correlação, menor é a variância remanescente de X_1 depois de conhecido X_2 .

Quando

$$\rho = 0,$$

tem-se

$$E(X_1 \mid X_2 = x_2) = \mu_1$$

e

$$\text{Var}(X_1 \mid X_2 = x_2) = \sigma_1^2.$$

Assim, a distribuição condicional coincide com a distribuição marginal, como esperado pela independência das componentes.

Exemplo 9.5 (Condicional em uma normal bivariada padronizada). Considere

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix} \right).$$

Para

$$X_2 = 1,$$

a média condicional é

$$E(X_1 | X_2 = 1) = 0.8$$

e a variância condicional é

$$\text{Var}(X_1 | X_2 = 1) = 1 - 0.8^2 = 0.36.$$

Logo,

$$X_1 | X_2 = 1 \sim N(0.8, 0.36).$$

A Figura 9.2 apresenta as curvas de nível da distribuição conjunta e a densidade condicional de X_1 quando $X_2 = 1$.




Figura 9.2: Distribuição normal bivariada e densidade condicional de X_1 para $X_2 = 1$.

O corte horizontal no primeiro painel fixa $X_2 = 1$. O segundo painel mostra a distribuição condicional resultante para X_1 , com média igual a 0.8 e desvio-padrão igual a 0.6.

O branqueamento transforma um vetor normal não singular em componentes normais padrão independentes. A soma dos quadrados dessas componentes fornecerá, na seção seguinte, a distribuição probabilística da distância de Mahalanobis.

9.5 Distância de Mahalanobis e regiões de concentração

O Capítulo 8 apresentou a distância de Mahalanobis como medida geométrica adaptada à matriz de covariâncias. Para um vetor normal multivariado não singular, a distância quadrática ao vetor de médias possui distribuição qui-quadrado, resultado que permite construir regiões elipsoidais com probabilidade populacional especificada (Mardia; Kent; Taylor, 2024).

Considere

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

A distância quadrática de Mahalanobis entre o vetor aleatório e seu centro é

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu). \quad (9.46)$$

A notação D_M^2 representa agora uma variável aleatória, pois depende de $\mathbf{X}$.

9.5.1 Distribuição qui-quadrado

Teorema 9.9 (Distribuição da distância quadrática de Mahalanobis). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$, então

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2. \quad (9.47)$$

Comprovação. Pelo branqueamento,

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p).$$

Logo, as componentes

$$Z_1, \dots, Z_p$$

são normais padrão independentes.

Além disso,

$$\begin{aligned}
 D_M^2 &= (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \\
 &= [\Sigma^{-1/2} (\mathbf{X} - \mu)]^\top [\Sigma^{-1/2} (\mathbf{X} - \mu)] \\
 &= \mathbf{Z}^\top \mathbf{Z} \\
 &= \sum_{j=1}^p Z_j^2.
 \end{aligned}$$

A soma dos quadrados de p variáveis normais padrão independentes possui distribuição qui-quadrado com p graus de liberdade. Portanto,

$$D_M^2 \sim \chi_p^2.$$

□

O número de graus de liberdade corresponde à dimensão do espaço efetivo da distribuição. No caso não singular, essa dimensão é p .

Como consequência,

$$E(D_M^2) = p$$

e

$$\text{Var}(D_M^2) = 2p. \quad (9.48)$$

A distância quadrática de Mahalanobis não se concentra em torno de zero. Seu valor médio cresce com a dimensão, pois incorpora simultaneamente os afastamentos ao longo de p direções independentes no espaço branqueado.

Parâmetros populacionais e quantidades estimadas

O resultado Equação 9.47 utiliza os parâmetros populacionais μ e Σ .

Quando esses parâmetros são substituídos por estimativas calculadas a partir da mesma amostra, a distribuição da forma quadrática resultante não é, em geral, χ_p^2 . Esse problema será estudado nos capítulos de estimação e inferência.

9.5.2 Regiões elipsoidais de probabilidade

Seja

$$\chi_{p,1-\alpha}^2$$

o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com p graus de liberdade, definido por

$$P(\chi_p^2 \leq \chi_{p,1-\alpha}^2) = 1 - \alpha.$$

Definição 9.4 (Região elipsoidal de probabilidade). Para

$$0 < \alpha < 1,$$

a região

$$\mathcal{E}_{1-\alpha} = \left\{ \mathbf{x} \in \mathbb{R}^p : (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \leq \chi_{p,1-\alpha}^2 \right\} \quad (9.49)$$

é uma região elipsoidal que contém probabilidade populacional $1 - \alpha$.

De fato,

$$\begin{aligned} P(\mathbf{X} \in \mathcal{E}_{1-\alpha}) &= P\left[(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \leq \chi_{p,1-\alpha}^2\right] \\ &= P(\chi_p^2 \leq \chi_{p,1-\alpha}^2) \\ &= 1 - \alpha. \end{aligned} \quad (9.50)$$

A fronteira da região é a superfície

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) = \chi_{p,1-\alpha}^2.$$

Pela decomposição espectral

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^\top,$$

os semieixos da região possuem comprimentos

$$\sqrt{\chi_{p,1-\alpha}^2 \lambda_j}, \quad j = 1, \dots, p. \quad (9.51)$$

Portanto, o nível de probabilidade altera simultaneamente todos os semieixos pelo fator

$$\sqrt{\chi_{p,1-\alpha}^2},$$

enquanto a forma relativa da região continua determinada pelos autovalores e autovetores de Σ .

A transformação de branqueamento converte a região elipsoidal em uma esfera:

$$\mathcal{B}_{1-\alpha} = \{\mathbf{z} \in \mathbb{R}^p : \mathbf{z}^\top \mathbf{z} \leq \chi_{p,1-\alpha}^2\}. \quad (9.52)$$

Assim, a região elipsoidal na escala original corresponde a uma região esférica no espaço das componentes normais padrão independentes.

Curvas de nível e regiões de probabilidade

As superfícies de igual densidade e as fronteiras das regiões de probabilidade possuem a mesma forma geométrica, pois ambas são definidas por valores constantes da distância de Mahalanobis.

A diferença está na escolha da constante. Em uma região de probabilidade $1 - \alpha$, a constante é determinada por um quantil da distribuição χ_p^2 .

9.5.3 Avaliação de uma observação fixa

Considere uma observação fixa

$$\mathbf{x}_0 \in \mathbb{R}^p.$$

Sua distância quadrática de Mahalanobis em relação ao modelo é

$$d_M^2(\mathbf{x}_0, \mu) = (\mathbf{x}_0 - \mu)^\top \Sigma^{-1} (\mathbf{x}_0 - \mu). \quad (9.53)$$

A observação está dentro da região $\mathcal{E}_{1-\alpha}$ quando

$$d_M^2(\mathbf{x}_0, \mu) \leq \chi_{p,1-\alpha}^2. \quad (9.54)$$

Quando

$$d_M^2(\mathbf{x}_0, \mu) > \chi_{p,1-\alpha}^2,$$

a observação está fora da região elipsoidal que contém probabilidade populacional $1 - \alpha$.

Essa comparação descreve a posição geométrica de $\mathbf{x}_0$ em relação ao modelo. Ela não atribui uma probabilidade à observação depois de seu valor ter sido fixado.

Também é possível associar ao valor observado da distância a probabilidade de cauda

$$p_M = P[\chi_p^2 \geq d_M^2(\mathbf{x}_0, \mu)] . \quad (9.55)$$

Um valor pequeno de p_M indica que a observação apresenta distância maior do que a maioria dos vetores gerados pelo modelo normal especificado.

Essa avaliação depende de:

- adequação da distribuição normal multivariada;
- especificação correta de μ ;
- especificação correta de Σ ;
- uso de parâmetros populacionais conhecidos.

Ela não deve ser confundida com um procedimento amostral de identificação de observações atípicas baseado em parâmetros estimados.

Exemplo 9.6 (Avaliação de uma observação em uma normal bivariada). Considere

$$\mathbf{X} \sim N_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix} \right)$$

e a observação

$$\mathbf{x}_0 = \begin{bmatrix} 3 \\ 1 \end{bmatrix} .$$

A inversa da matriz de covariâncias é

$$\Sigma^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} .$$

A distância quadrática de Mahalanobis é

$$\begin{aligned} d_M^2(\mathbf{x}_0, \mu) &= \begin{bmatrix} 3 & 1 \end{bmatrix} \frac{1}{3} \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} \\ &= \frac{7}{3} \\ &\approx 2.33. \end{aligned}$$

Para uma região com probabilidade 0.95,

$$\chi_{2,0.95}^2 \approx 5.99.$$

Como

$$2.33 < 5.99,$$

a observação está dentro da região elipsoidal que contém 95% da probabilidade populacional.

A mesma distância de Mahalanobis pode corresponder a deslocamentos euclidianos diferentes, dependendo da direção. Um afastamento relativamente grande em uma direção de alta variabilidade pode permanecer dentro da região, enquanto um afastamento menor em uma direção de baixa variabilidade pode situar-se fora dela.

9.5.4 Extensão ao suporte efetivo no caso singular

Considere agora

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

com

$$\text{posto}(\Sigma) = r < p.$$

Utilizando a decomposição espectral reduzida,

$$\Sigma = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

defina o vetor branqueado no espaço efetivo:

$$\mathbf{Z}_r = \Lambda_r^{-1/2} \mathbf{Q}_r^\top (\mathbf{X} - \mu).$$

Como demonstrado anteriormente,

$$\mathbf{Z}_r \sim N_r(\mathbf{0}, \mathbf{I}_r).$$

A forma quadrática baseada na pseudoinversa é

$$\begin{aligned} & (\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \\ &= \mathbf{Z}_r^\top \mathbf{Z}_r. \end{aligned}$$

Consequentemente,

Teorema 9.10 (Distância de Mahalanobis no caso normal singular). *Se*

$$\mathbf{X} \sim N_p(\mu, \Sigma)$$

e

$$\text{posto}(\Sigma) = r,$$

então

$$(\mathbf{X} - \mu)^\top \Sigma^+ (\mathbf{X} - \mu) \sim \chi_r^2. \quad (9.56)$$

O número de graus de liberdade é r , e não p , pois apenas r direções possuem variância positiva.

Uma região de probabilidade $1 - \alpha$ no suporte efetivo é

$$\begin{aligned} \mathcal{E}_{1-\alpha}^{(r)} = & \left\{ \mathbf{x} \in \mathbb{R}^p : \mathbf{x} - \mu \in \mathcal{C}(\Sigma), \right. \\ & \left. (\mathbf{x} - \mu)^\top \Sigma^+ (\mathbf{x} - \mu) \leq \chi_{r,1-\alpha}^2 \right\}. \end{aligned} \quad (9.57)$$

A restrição

$$\mathbf{x} - \mu \in \mathcal{C}(\Sigma)$$

é necessária porque a distribuição está inteiramente concentrada nesse subespaço afim.

A distância de Mahalanobis e a estrutura da densidade também permitem comparar distribuições normais com diferentes vetores de médias e matrizes de covariâncias. Essa comparação fornecerá uma motivação probabilística para os métodos de classificação desenvolvidos posteriormente.

9.6 Comparação entre distribuições normais

Considere duas distribuições normais multivariadas:

$$\mathbf{x}^{(1)} \sim N_p(\mu_1, \Sigma_1)$$

e

$$\mathbf{x}^{(2)} \sim N_p(\mu_2, \Sigma_2),$$

com matrizes de covariâncias positivas definidas.

As distribuições podem diferir quanto à localização, à escala, à orientação e à forma de suas regiões de concentração. Essas diferenças são determinadas pelos vetores de médias e pelas matrizes de covariâncias.

9.6.1 Médias distintas e covariância comum

Suponha que

$$\Sigma_1 = \Sigma_2 = \Sigma,$$

mas

$$\mu_1 \neq \mu_2.$$

As distribuições possuem a mesma forma, orientação e escala volumétrica, mas estão centradas em pontos diferentes.

Nesse caso, a diferença entre as log-densidades é

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \mathbf{x}^\top \Sigma^{-1} (\mu_1 - \mu_2) \\ &\quad - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_2^\top \Sigma^{-1} \mu_2). \end{aligned} \tag{9.58}$$

Essa expressão é afim em $\mathbf{x}$. Consequentemente, o conjunto dos pontos nos quais as duas densidades são iguais é um hiperplano.

A orientação desse hiperplano depende da direção

$$\Sigma^{-1}(\mu_1 - \mu_2),$$

de modo que a comparação entre os centros ocorre segundo a geometria induzida pela matriz de covariâncias.

9.6.2 Covariâncias distintas

Quando

$$\Sigma_1 \neq \Sigma_2,$$

as distribuições podem apresentar formas, orientações, extensões e densidades máximas diferentes.

A diferença entre suas log-densidades é

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2} \log \frac{\det(\Sigma_1)}{\det(\Sigma_2)} \\ &\quad - \frac{1}{2} (\mathbf{x} - \mu_1)^\top \Sigma_1^{-1} (\mathbf{x} - \mu_1) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mu_2)^\top \Sigma_2^{-1} (\mathbf{x} - \mu_2). \end{aligned} \tag{9.59}$$

Como as matrizes inversas são diferentes, a expressão contém, em geral, um termo quadrático em $\mathbf{x}$. Por isso, o conjunto de igualdade entre as densidades não precisa ser um hiperplano.

A Figura 9.3 apresenta duas situações: médias distintas com covariância comum e médias e covariâncias distintas.

A Figura 9.3 apresenta duas situações: médias distintas com covariância comum e médias e covariâncias distintas.

No primeiro painel, as curvas possuem a mesma forma e orientação, mas centros diferentes. No segundo, as matrizes de covariâncias alteram também a extensão e a orientação das curvas.




Figura 9.3: Comparação entre distribuições normais bivariadas com covariância comum e com covariâncias distintas.

9.6.3 Motivação para classificação futura

A comparação entre densidades fornece uma base probabilística para decidir de qual população uma observação pode ter se originado.

Quando as populações normais possuem uma matriz de covariâncias comum, as diferenças entre suas log-densidades são funções afins das observações. Quando as matrizes de covariâncias são distintas, essas diferenças são, em geral, funções quadráticas. Essas duas estruturas originam, respectivamente, as regras discriminantes linear e quadrática (Johnson; Wichern, 2007).

A construção dessas regras exige ainda probabilidades dos grupos, possíveis custos de decisão e estimação dos parâmetros desconhecidos. Esses elementos serão desenvolvidos posteriormente na formulação da Análise Discriminante.

9.7 Papel da normalidade na Estatística Multivariada

A distribuição normal multivariada ocupa uma posição central na teoria estatística porque combina uma estrutura probabilística completa com propriedades algébricas simples. O vetor de médias e a matriz de covariâncias determinam a distribuição, e a família permanece fechada sob transformações afins, marginalização e condicionamento.

Essa importância não significa que toda análise multivariada dependa da hipótese de normalidade. É necessário distinguir os resultados puramente algébricos ou descritivos daqueles que utilizam um modelo probabilístico específico.

9.7.1 Resultados que não exigem normalidade

A definição e o cálculo dos seguintes objetos exigem apenas a existência dos momentos correspondentes:

- vetor de médias;
- matriz de covariâncias;
- matriz de correlações;
- variância de combinações lineares;
- transformação afim da média e da covariância;
- decomposição espectral da matriz de covariâncias;
- distância de Mahalanobis como medida geométrica;
- centralização da matriz de dados;
- matrizes de produtos cruzados;
- decomposição da dispersão total em parcelas intragrupos e entre grupos.

Por exemplo, para qualquer vetor aleatório com segundos momentos finitos,

$$\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Esse resultado decorre das propriedades da covariância e não pressupõe uma distribuição normal.

Da mesma forma, a transformação

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$$

satisfaz

$$E(\mathbf{Y}) = \mathbf{A}\mu + \mathbf{b}$$

e

$$\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$$

sempre que os momentos necessários existirem.

9.7.2 Resultados específicos da família normal

Outros resultados desenvolvidos neste capítulo dependem diretamente da normalidade conjunta.

Entre eles estão:

- toda transformação afim permanece normal multivariada;
- toda distribuição marginal é normal multivariada;
- covariância cruzada nula implica independência entre blocos;
- a distribuição condicional é normal;
- a média condicional é uma função afim do bloco condicionante;
- a covariância condicional não depende do valor condicionado;
- o vetor branqueado possui componentes normais padrão independentes;
- a distância quadrática de Mahalanobis populacional possui distribuição qui-quadrado.

A equivalência

$$\Sigma_{12} = \mathbf{0} \iff \mathbf{X}_1 \perp \mathbf{X}_2$$

é um exemplo particularmente importante. A implicação da direita para a esquerda vale para vetores aleatórios gerais com segundos momentos finitos. A implicação inversa é uma propriedade da normalidade conjunta.

De modo semelhante,

$$D_M^2 = (\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2$$

não decorre apenas da existência de μ e Σ . O resultado exige que $\mathbf{X}$ possua distribuição normal multivariada não singular.

9.7.3 Normalidade marginal e normalidade multivariada

Se

$$\mathbf{X} \sim N_p(\mu, \Sigma),$$

então cada componente possui distribuição normal univariada:

$$X_j \sim N(\mu_j, \sigma_{jj}).$$

A recíproca não é válida. Todas as componentes podem apresentar distribuições normais quando analisadas individualmente sem que o vetor seja normal multivariado.

A normalidade conjunta exige que

$$\mathbf{a}^\top \mathbf{X}$$

seja normal para todo vetor $\mathbf{a} \in \mathbb{R}^p$. Portanto, a inspeção isolada das distribuições marginais não caracteriza completamente a distribuição conjunta.

Marginais normais não garantem normalidade conjunta

A normalidade de $X_1, \dots, X_p$ separadamente é uma condição necessária, mas não suficiente, para a normalidade multivariada. A dependência entre as componentes também faz parte da especificação da distribuição conjunta.

9.7.4 Normalidade e inferência estatística

A normalidade multivariada sustenta diversos resultados exatos da inferência clássica. Sob esse modelo, podem ser obtidas distribuições amostrais para estatísticas construídas a partir de:

- médias amostrais;
- matrizes de covariâncias;
- formas quadráticas;
- determinantes;
- raízes características;
- matrizes de produtos cruzados.

Esses resultados permitem construir testes de hipóteses, regiões de confiança e procedimentos de estimação com distribuições conhecidas.

A normalidade também simplifica a função de verossimilhança. Para uma observação, sua contribuição contém os termos

$$\log \det (\Sigma)$$

e

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu).$$

Essa estrutura será utilizada no capítulo seguinte para desenvolver a estimação do vetor de médias e da matriz de covariâncias.

A ausência de normalidade não torna automaticamente inválida toda análise multivariada. Algumas técnicas possuem formulação predominantemente geométrica ou algébrica, enquanto outras dependem da normalidade apenas para determinadas etapas inferenciais.

A relevância da hipótese deve ser avaliada de acordo com:

- o objetivo da análise;
- a estatística utilizada;
- o resultado probabilístico pretendido;
- o tamanho da amostra;
- a dimensão do problema;
- a sensibilidade do procedimento a desvios do modelo.

9.7.5 Limites da especificação por média e covariância

Na família normal,

$$\mu \text{ e } \Sigma$$

determinam toda a distribuição. Fora dessa família, esses parâmetros descrevem apenas a estrutura de primeira e segunda ordens.

Duas distribuições não normais podem apresentar o mesmo vetor de médias e a mesma matriz de covariâncias, mas diferir quanto a:

- assimetria;
- curtose;
- comportamento das caudas;
- concentração de probabilidade;
- dependência não linear;
- ocorrência de valores extremos;
- forma das distribuições condicionais.

Por isso, a matriz de covariâncias não representa toda a dependência existente em uma distribuição geral.

Alcance do modelo normal

A distribuição normal multivariada fornece um modelo completo determinado por média e covariância. Sua adequação não decorre apenas da disponibilidade desses dois parâmetros, mas da compatibilidade entre a estrutura probabilística do fenômeno e as propriedades da família normal.

Neste capítulo, os parâmetros μ e Σ foram tratados como conhecidos. Em uma aplicação, eles precisam ser estimados a partir de uma amostra. Essa passagem do modelo populacional para as estatísticas amostrais será desenvolvida no próximo capítulo.

9.8 Síntese do capítulo

A distribuição normal multivariada pode ser caracterizada pela normalidade de todas as combinações lineares de suas componentes. Pelo Teorema de Cramér–Wold, as distribuições dessas projeções determinam a distribuição conjunta. Na família normal, isso implica que o vetor de médias e a matriz de covariâncias especificam completamente a distribuição.

Uma representação fundamental é

$$\mathbf{X} = \mu + \mathbf{A}\mathbf{Z}, \quad \mathbf{Z} \sim N_r(\mathbf{0}, \mathbf{I}_r),$$

com

$$\Sigma = \mathbf{A}\mathbf{A}^\top.$$

Quando Σ é singular, a distribuição fica concentrada no suporte afim

$$\mu + \mathcal{C}(\Sigma).$$

Quando $\Sigma \succ \mathbf{0}$, a distribuição possui densidade em $\mathbb{R}^p$. Suas superfícies de igual densidade são elipsoides definidos por valores constantes da distância de Mahalanobis.

A família normal permanece fechada sob transformações afins. Como consequências, combinações lineares e distribuições marginais continuam normais. A padronização marginal produz matriz de covariâncias igual à matriz de correlações, enquanto o branqueamento produz componentes normais padrão independentes.

Para blocos conjuntamente normais,

$$\mathbf{X}_1 \perp \mathbf{X}_2 \iff \Sigma_{12} = \mathbf{0}.$$

Além disso,

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{p_1}(\mu_{1|2}(\mathbf{x}_2), \Sigma_{11.2}),$$

em que a média condicional é uma função afim do valor condicionado e a covariância condicional é o complemento de Schur de Σ_{22} .

No caso não singular,

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi_p^2.$$

Esse resultado permite construir regiões elipsoidais com probabilidade populacional especificada. No caso singular, utiliza-se a pseudoinversa, os graus de liberdade correspondem ao posto de Σ e a região deve ser restrita ao suporte efetivo.

Ao término do capítulo, deve-se ser capaz de:

- caracterizar e construir uma distribuição normal multivariada;
- distinguir os casos singular e não singular;
- interpretar a densidade e suas superfícies de nível;
- obter distribuições de transformações afins e subvetores;
- diferenciar padronização marginal e branqueamento;
- relacionar covariância nula e independência sob normalidade conjunta;
- determinar a distribuição condicional entre blocos;
- utilizar a distribuição qui-quadrado da distância de Mahalanobis;
- distinguir resultados gerais de segunda ordem daqueles específicos da normalidade.

Neste capítulo, μ e Σ foram tratados como parâmetros conhecidos. O próximo capítulo introduzirá amostras aleatórias multivariadas, estatísticas e estimadores, estabelecendo a passagem do modelo populacional para as quantidades calculadas a partir dos dados.

10 Estatísticas Amostrais e Estimação

Os Capítulos 8 e 9 apresentaram o vetor de médias e a matriz de covariâncias como características da distribuição populacional. Em uma aplicação, esses parâmetros geralmente são desconhecidos e precisam ser estimados a partir de uma amostra.

O objetivo deste capítulo é construir os principais estimadores utilizados no contexto multivariado e examinar suas propriedades estatísticas e algébricas. Serão estudados o vetor de médias amostrais, a matriz de somas de quadrados e produtos cruzados, os estimadores da matriz de covariâncias, a matriz de correlações e as covariâncias cruzadas entre blocos de variáveis.

A distinção entre objetos populacionais, estatísticas aleatórias e valores observados será mantida ao longo do capítulo. Em particular,

- μ e Σ representam parâmetros populacionais;
- $\mathbf{X}$ e $\mathbf{S}$ representam estatísticas aleatórias;
- $\bar{\mathbf{x}}$ e $\mathbf{S}$ representam os valores calculados após a observação da amostra.

Os métodos dos momentos e da máxima verossimilhança serão utilizados para obter estimadores específicos. A diferenciação matricial e as propriedades gerais da verossimilhança desenvolvidas no Capítulo 7 serão aplicadas sem nova exposição de sua teoria.

As distribuições amostrais exatas, a distribuição de Wishart, a independência entre o vetor de médias e a matriz de covariâncias amostrais e os procedimentos de inferência serão desenvolvidos no Capítulo 12. Neste capítulo, a atenção estará voltada à construção dos estimadores, às suas propriedades e às limitações impostas pela dimensão da amostra.

10.1 Da população à amostra

Considere um vetor aleatório

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \in \mathbb{R}^p$$

com distribuição pertencente a uma família

$$\{F_\theta : \theta \in \Theta\},$$

em que θ representa o conjunto de parâmetros desconhecidos e Θ é o espaço paramétrico.

Quando existem momentos de primeira e segunda ordens, a distribuição possui vetor de médias

$$\mu = E(\mathbf{X}) \in \mathbb{R}^p$$

e matriz de covariâncias

$$\Sigma = \text{Cov}(\mathbf{X}) \in \mathbb{R}^{p \times p}.$$

Esses parâmetros são características fixas da população. A variabilidade entre possíveis amostras pertence às estatísticas utilizadas para estimá-los.

10.1.1 Amostra aleatória multivariada

A unidade amostral de um estudo multivariado é um vetor. Cada unidade fornece simultaneamente os valores das p variáveis que compõem $\mathbf{X}$.

Definição 10.1 (Amostra aleatória multivariada). Uma amostra aleatória multivariada de tamanho n proveniente de F_θ é uma coleção de vetores aleatórios

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

independentes e com a mesma distribuição:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta. \quad (10.1)$$

A notação **iid** reúne duas condições. A distribuição idêntica estabelece que todos os vetores são provenientes da mesma população. A independência estabelece que o resultado observado em uma unidade não altera a distribuição dos resultados das demais unidades.

A independência entre os vetores da amostra implica que sua função de distribuição conjunta pode ser escrita como

$$F_\theta^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n F_\theta(\mathbf{x}_i). \quad (10.2)$$

Quando a distribuição possui densidade em relação a uma medida comum, a densidade conjunta da amostra é

$$f_{\theta}^{(n)}(\mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f_{\theta}(\mathbf{x}_i). \quad (10.3)$$

As duas fatorações decorrem da independência entre as unidades amostrais. A dependência entre as componentes de cada vetor permanece representada pela distribuição multivariada F_{θ} ou por sua densidade f_{θ} .

Cada vetor da amostra possui a forma

$$\mathbf{X}_i = \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{ip} \end{bmatrix}, \quad i = 1, \dots, n,$$

em que X_{ij} representa a variável j observada na unidade i .

A independência entre os vetores

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

não implica independência entre as componentes de um mesmo vetor. As variáveis

$$X_{i1}, \dots, X_{ip}$$

podem apresentar covariâncias e outras formas de dependência dentro da unidade i .

Quando os momentos de segunda ordem existem,

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma$$

para todo i . Para duas unidades distintas,

$$\text{Cov}(\mathbf{X}_i, \mathbf{X}_{\ell}) = \mathbf{0}, \quad i \neq \ell,$$

como consequência da independência.

No caso normal multivariado, a especificação amostral é

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma). \quad (10.4)$$

A normalidade não é necessária para definir médias, covariâncias ou correlações amostrais. Ela será necessária para a obtenção dos estimadores de máxima verossimilhança apresentados neste capítulo e para os resultados exatos desenvolvidos no Capítulo 12.

10.1.2 Matriz aleatória da amostra e matriz observada

Os vetores da amostra podem ser organizados nas linhas de uma matriz aleatória.

Definição 10.2 (Matriz aleatória da amostra). A matriz aleatória associada à amostra é

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (10.5)$$

Antes da coleta dos dados, os elementos de $\mathcal{X}$ são variáveis aleatórias. Cada possível resultado do processo amostral corresponde a uma matriz numérica.

Após a observação da amostra,

$$\mathcal{X} = \mathbf{X},$$

em que

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p} \quad (10.6)$$

é a matriz de dados observada.

A diferença tipográfica registra a natureza dos objetos:

- $\mathcal{X}$ é uma matriz aleatória;
- $\mathbf{X}$ é uma realização da matriz aleatória;
- $\mathbf{X}_i$ é o vetor aleatório correspondente à unidade i ;

- $\mathbf{x}_i$ é o vetor observado para essa unidade;
- X_{ij} é uma variável aleatória;
- x_{ij} é seu valor observado.

O espaço amostral pode ser representado por

$$(\mathbb{R}^p)^n,$$

ou, de forma equivalente, pelo conjunto das matrizes reais de dimensão $n \times p$.

Uma estatística associa a cada possível matriz da amostra um valor escalar, vetorial ou matricial. Antes da observação, esse resultado é aleatório. Depois da observação, torna-se uma quantidade calculada a partir de $\mathbf{X}$.

10.1.3 Parâmetros, estatísticas, estimadores e estimativas

Um parâmetro é uma característica fixa da distribuição populacional. Ele pode ser escalar, vetorial ou matricial.

No contexto deste capítulo, os principais parâmetros são

$$\mu, \quad \Sigma \quad \text{e} \quad \mathcal{R}.$$

No modelo normal multivariado não singular, o parâmetro completo pode ser representado por

$$\theta = (\mu, \Sigma),$$

com espaço paramétrico

$$\Theta = \{(\mu, \Sigma) : \mu \in \mathbb{R}^p, \Sigma \succ \mathbf{0}\}.$$

Definição 10.3 (Estatística amostral). Uma estatística é uma função da amostra que não contém parâmetros desconhecidos em sua expressão:

$$\mathbf{T} = T(\mathcal{X}). \tag{10.7}$$

A estatística pode assumir valores escalares, vetoriais ou matriciais.

Embora sua fórmula não dependa de parâmetros desconhecidos, a distribuição de uma estatística geralmente depende da distribuição populacional e de seus parâmetros.

O vetor de médias amostrais é um exemplo de estatística vetorial:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i. \quad (10.8)$$

Após a observação da amostra, obtém-se

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i. \quad (10.9)$$

A distribuição de probabilidade de uma estatística é denominada **distribuição amostral**. Ela descreve como a estatística varia entre todas as possíveis amostras de tamanho n provenientes da mesma população.

Distribuição populacional e distribuição amostral

A distribuição

$$\mathbf{X} \sim F_\theta$$

descreve a variabilidade de uma unidade populacional.

A distribuição de

$$\mathbf{T} = T(\mathcal{X})$$

descreve a variabilidade de uma função calculada sobre uma amostra inteira. As duas distribuições representam objetos distintos.

Uma estatística torna-se um estimador quando é utilizada para aproximar um parâmetro desconhecido.

Definição 10.4 (Estimador e estimativa). Um estimador de um parâmetro θ é uma estatística

$$\hat{\theta} = T(\mathcal{X}) \quad (10.10)$$

utilizada para inferir o valor de θ .

A estimativa é o valor assumido pelo estimador após a observação da amostra:

$$\hat{\theta}_{\text{obs}} = T(\mathbf{X}). \quad (10.11)$$

Assim,

$$\bar{\mathbf{x}}$$

é um estimador de μ , enquanto

$$\bar{x}$$

é a estimativa obtida para uma amostra específica.

De modo semelhante,

$$\mathbf{S}$$

representará um estimador matricial de Σ , e

$$\mathbf{s}$$

representará seu valor observado.

O erro de estimação é a diferença entre o estimador e o parâmetro:

$$\hat{\theta} - \theta. \tag{10.12}$$

Antes da observação da amostra, esse erro é aleatório. Sua distribuição permite avaliar o desempenho do estimador.

Um mesmo parâmetro pode possuir diferentes estimadores. Para a matriz de covariâncias, por exemplo, serão estudados um estimador não viesado e o estimador de máxima verossimilhança sob normalidade. A escolha entre eles depende das propriedades consideradas e do modelo probabilístico adotado.

A estimação pontual produz um único valor vetorial ou matricial como aproximação do parâmetro. A estimação por regiões produz um conjunto de valores plausíveis, associado a um nível de confiança. Neste capítulo será desenvolvida a estimação pontual. As regiões de confiança serão construídas no Capítulo 12.

A comparação entre diferentes estimadores exige critérios que descrevam seu comportamento ao longo das possíveis amostras. Viés, variabilidade, erro quadrático médio, consistência, eficiência, suficiência, equivariância e robustez serão examinados na seção seguinte.

10.2 Propriedades dos estimadores multivariados

A existência de um estimador não determina sua adequação. Diferentes estatísticas podem ser utilizadas para estimar o mesmo parâmetro e apresentar comportamentos distintos entre as possíveis amostras.

Considere um parâmetro vetorial

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e um estimador

$$\hat{\theta} = T(\mathcal{X}) \in \mathbb{R}^r.$$

A avaliação de $\hat{\theta}$ depende de sua distribuição amostral e do critério utilizado para comparar procedimentos. Viés, variabilidade e erro quadrático médio descrevem seu comportamento para um tamanho amostral fixo. Consistência e eficiência assintótica descrevem seu comportamento quando o tamanho da amostra aumenta. Suficiência, equivariância e robustez examinam, respectivamente, a informação preservada, a coerência sob transformações e a estabilidade diante de perturbações (Casella; Berger, 2002).

10.2.1 Viés e variabilidade

O viés mede a diferença entre o valor esperado do estimador e o parâmetro que se deseja estimar.

Definição 10.5 (Viés de um estimador). Se $E(\hat{\theta})$ existe, o viés de $\hat{\theta}$ na estimação de θ é

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (10.13)$$

O estimador é não viesado quando

$$E(\hat{\theta}) = \theta,$$

ou, equivalentemente,

$$\text{Bias}(\hat{\theta}) = \mathbf{0}.$$

O viés é um vetor em $\mathbb{R}^r$. Sua componente j é o viés do estimador de θ_j :

$$\left[\text{Bias} \left(\hat{\theta} \right) \right]_j = E \left(\hat{\theta}_j \right) - \theta_j.$$

A ausência de viés significa que o estimador não apresenta afastamento sistemático quando considerado sobre todas as possíveis amostras. Essa propriedade não garante que a estimativa obtida em uma amostra específica esteja próxima do parâmetro.

Para um parâmetro matricial

$$\Theta \in \mathbb{R}^{a \times b}$$

e um estimador

$$\widehat{\Theta} \in \mathbb{R}^{a \times b},$$

o viés é definido elemento a elemento:

$$\text{Bias} \left(\widehat{\Theta} \right) = E \left(\widehat{\Theta} \right) - \Theta. \quad (10.14)$$

O estimador matricial é não viesado quando

$$E \left(\widehat{\Theta} \right) = \Theta.$$

A variabilidade de um estimador vetorial é descrita por sua matriz de covariâncias:

$$\text{Cov} \left(\hat{\theta} \right) = E \left[\begin{array}{c} \left\{ \hat{\theta} - E \left(\hat{\theta} \right) \right\} \\ \left\{ \hat{\theta} - E \left(\hat{\theta} \right) \right\}^\top \end{array} \right]. \quad (10.15)$$

Os elementos diagonais são as variâncias dos estimadores dos componentes:

$$\left[\text{Cov} \left(\hat{\theta} \right) \right]_{jj} = \text{Var} \left(\hat{\theta}_j \right).$$

Os elementos fora da diagonal são as covariâncias entre os erros de estimação:

$$\left[\text{Cov} \left(\hat{\theta} \right) \right]_{jk} = \text{Cov} \left(\hat{\theta}_j, \hat{\theta}_k \right).$$

A matriz de covariâncias descreve simultaneamente a precisão dos componentes e a forma como seus erros variam em conjunto. Para qualquer vetor $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}(\mathbf{a}^\top \hat{\theta}) = \mathbf{a}^\top \text{Cov}(\hat{\theta}) \mathbf{a}.$$

Uma medida escalar da variabilidade total é

$$\text{tr}[\text{Cov}(\hat{\theta})] = \sum_{j=1}^r \text{Var}(\hat{\theta}_j).$$

Essa medida depende da escala e da parametrização adotadas. Ela reúne as variâncias marginais, mas não substitui a matriz de covariâncias quando a dependência entre os componentes é relevante.

Para um estimador matricial, a variabilidade pode ser representada por

$$\text{Cov}[\text{vec}(\hat{\Theta})],$$

em que o operador vec organiza os elementos da matriz em um vetor.

10.2.2 Erro quadrático médio e funções de perda

A comparação entre estimadores exige a especificação das consequências atribuídas aos diferentes erros de estimação. Essa escolha é formalizada por uma função de perda, e o valor esperado dessa perda define o risco do procedimento (Casella; Berger, 2002).

Para um estimador vetorial, uma possibilidade é a perda quadrática euclidiana:

$$L(\hat{\theta}, \theta) = \|\hat{\theta} - \theta\|^2. \quad (10.16)$$

Essa perda atribui o mesmo peso a todas as coordenadas do parâmetro. Outros problemas podem exigir ponderações ou perdas diferentes.

Definição 10.6 (Erro quadrático médio vetorial). Sob a perda quadrática euclidiana, o erro quadrático médio de $\hat{\theta}$ é

$$\text{EQM}(\hat{\theta}) = E[\|\hat{\theta} - \theta\|^2]. \quad (10.17)$$

A diferença entre o estimador e o parâmetro pode ser decomposta como

$$\begin{aligned}\hat{\theta} - \theta &= \hat{\theta} - E(\hat{\theta}) \\ &\quad + E(\hat{\theta}) - \theta.\end{aligned}$$

O primeiro termo é aleatório e possui média zero. O segundo é o vetor de viés.

Teorema 10.1 (Decomposição do erro quadrático médio). *Se $\hat{\theta}$ possui segundos momentos finitos, então*

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2. \quad (10.18)$$

Comprovação. Defina

$$\mathbf{U} = \hat{\theta} - E(\hat{\theta})$$

e

$$\mathbf{b} = E(\hat{\theta}) - \theta.$$

Então,

$$E(\mathbf{U}) = \mathbf{0}$$

e

$$\hat{\theta} - \theta = \mathbf{U} + \mathbf{b}.$$

Consequentemente,

$$\begin{aligned}E[\|\hat{\theta} - \theta\|^2] &= E[(\mathbf{U} + \mathbf{b})^\top (\mathbf{U} + \mathbf{b})] \\ &= E(\mathbf{U}^\top \mathbf{U}) + 2\mathbf{b}^\top E(\mathbf{U}) + \mathbf{b}^\top \mathbf{b} \\ &= \text{tr} [\text{Cov}(\hat{\theta})] + \|\mathbf{b}\|^2.\end{aligned}$$

Como $\mathbf{b}$ é o vetor de viés, obtém-se o resultado. □

Quando o estimador é não viesado,

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})].$$

A ausência de viés não implica erro quadrático médio mínimo. Um estimador com pequeno viés pode apresentar menor EQM se a redução de sua variabilidade compensar o aumento produzido pelo viés. Essa possibilidade será retomada na discussão sobre regularização.

Para um estimador matricial, uma escolha correspondente é a perda quadrática de Frobenius:

$$L_F(\hat{\Theta}, \Theta) = \|\hat{\Theta} - \Theta\|_F^2.$$

O erro quadrático médio matricial é

$$\text{EQM}_F(\hat{\Theta}) = E \left[\|\hat{\Theta} - \Theta\|_F^2 \right]. \quad (10.19)$$

Como

$$\|\hat{\Theta} - \Theta\|_F = \|\text{vec}(\hat{\Theta} - \Theta)\|,$$

tem-se

$$\begin{aligned} \text{EQM}_F(\hat{\Theta}) &= \text{tr} \left\{ \text{Cov} [\text{vec}(\hat{\Theta})] \right\} \\ &\quad + \|\text{Bias}(\hat{\Theta})\|_F^2. \end{aligned} \quad (10.20)$$

A escolha da norma de Frobenius também representa uma decisão sobre a perda. Em problemas que envolvem matrizes de covariâncias, outras funções podem atribuir pesos diferentes aos autovalores, às direções ou ao erro de inversão.

10.2.3 Consistência

A consistência descreve o comportamento de uma sequência de estimadores quando o tamanho da amostra aumenta e estabelece a convergência do estimador para o parâmetro segundo o modo de convergência especificado (Vaart, 1998).

Definição 10.7 (Consistência). Uma sequência de estimadores

$$\hat{\theta}_n$$

é consistente para θ quando

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (10.21)$$

à medida que $n \rightarrow \infty$.

A convergência em probabilidade significa que, para todo $\varepsilon > 0$,

$$P\left(\|\hat{\theta}_n - \theta\| > \varepsilon\right) \rightarrow 0. \quad (10.22)$$

A consistência é uma propriedade assintótica. Ela não garante pequena imprecisão para um tamanho amostral específico. O resultado estabelece que a probabilidade de um afastamento superior a qualquer valor fixado tende a zero.

Para estimadores matriciais, pode-se utilizar a norma de Frobenius:

$$\widehat{\Theta}_n \xrightarrow{P} \Theta$$

quando, para todo $\varepsilon > 0$,

$$P\left(\|\widehat{\Theta}_n - \Theta\|_F > \varepsilon\right) \rightarrow 0. \quad (10.23)$$

Se

$$\hat{\theta}_n \xrightarrow{P} \theta$$

e g é uma função contínua em θ , o Teorema do Mapeamento Contínuo fornece (Vaart, 1998):

$$g\left(\hat{\theta}_n\right) \xrightarrow{P} g\left(\theta\right). \quad (10.24)$$

Esse resultado permite obter a consistência de estimadores construídos como funções contínuas de outros estimadores consistentes. Por exemplo, se as variâncias populacionais são positivas, a consistência de um estimador da matriz de covariâncias implica a consistência da matriz de correlações obtida por padronização.

As definições anteriores consideram que a dimensão do parâmetro permanece fixa enquanto n aumenta. Quando a dimensão também cresce com o tamanho amostral, a norma utilizada e a taxa de crescimento passam a fazer parte da formulação da consistência. Essa distinção será retomada na seção sobre dimensão e estabilidade.

10.2.4 Eficiência

Dois estimadores podem ser não viesados e consistentes, mas apresentar diferentes matrizes de covariâncias.

Considere dois estimadores não viesados de θ :

$$\hat{\theta}_1 \quad \text{e} \quad \hat{\theta}_2.$$

O estimador $\hat{\theta}_1$ é uniformemente pelo menos tão eficiente quanto $\hat{\theta}_2$, segundo a ordem de Loewner, quando

$$\text{Cov}_\theta(\hat{\theta}_1) \preceq \text{Cov}_\theta(\hat{\theta}_2) \quad \text{para todo } \theta \in \Theta. \quad (10.25)$$

Essa condição equivale a

$$\text{Cov}_\theta(\hat{\theta}_2) - \text{Cov}_\theta(\hat{\theta}_1) \succeq \mathbf{0} \quad \text{para todo } \theta \in \Theta.$$

Consequentemente, para todo $\theta \in \Theta$ e toda combinação linear definida por $\mathbf{a} \in \mathbb{R}^r$,

$$\text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_1) \leq \text{Var}_\theta(\mathbf{a}^\top \hat{\theta}_2).$$

A ordem de Loewner é parcial. Duas matrizes de covariâncias podem não ser comparáveis, pois sua diferença pode ser indefinida. Nessa situação, um estimador pode ser mais preciso em determinadas direções e menos preciso em outras.

Uma comparação escalar pode utilizar, por exemplo,

$$\text{tr} [\text{Cov}(\hat{\theta})].$$

Esse critério corresponde à perda quadrática euclidiana para estimadores não viesados. Outro critério pode produzir uma ordenação diferente.

Quando os estimadores são viesados, a comparação baseada somente nas matrizes de covariâncias é insuficiente. Deve-se considerar o risco associado a uma função de perda, como o erro quadrático médio.

A eficiência assintótica compara as matrizes que aparecem nas distribuições-limite. Sob condições regulares, a máxima verossimilhança pode alcançar o limite associado à informação de Fisher. A teoria correspondente foi desenvolvida no Capítulo 7 e será utilizada apenas quando as condições do modelo forem declaradas.

10.2.5 Suficiência

Uma estatística suficiente preserva toda a informação da amostra sobre o parâmetro no sentido probabilístico de que, condicionado ao valor dessa estatística, o restante da distribuição amostral não depende do parâmetro (Casella; Berger, 2002).

Definição 10.8 (Estatística suficiente). Uma estatística

$$\mathbf{T} = T(\mathcal{X})$$

é suficiente para θ quando a distribuição condicional da amostra dado $\mathbf{T}$ não depende de θ .

Para famílias dominadas por uma medida comum, o Teorema da Fatoração de Neyman–Fisher fornece um critério necessário e suficiente para verificar essa propriedade (Casella; Berger, 2002).

Teorema 10.2 (Teorema da Fatoração de Neyman–Fisher). *Considere uma família de distribuições dominada por uma medida comum, com densidade ou função de probabilidade conjunta*

$$f_{\theta}(\mathbf{x}), \quad \theta \in \Theta.$$

A estatística

$$T(\mathbf{x})$$

é suficiente para θ se, e somente se, existem funções não negativas g_{θ} e h tais que

$$f_{\theta}(\mathbf{x}) = g_{\theta}[T(\mathbf{x})] h(\mathbf{x}), \quad (10.26)$$

em que h não depende de θ .

A fatoração mostra que toda a dependência da distribuição conjunta em relação ao parâmetro ocorre por meio da estatística.

No modelo normal multivariado com média e matriz de covariâncias desconhecidas, o vetor de médias amostrais e a matriz de somas de quadrados e produtos cruzados formam conjuntamente uma estatística suficiente para os dois parâmetros (Anderson, 2003).

Teorema 10.3 (Suficiência no modelo normal multivariado). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com $\Sigma \succ \mathbf{0}$. Defina

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$$

e

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) (\mathbf{X}_i - \bar{\mathbf{X}})^\top. \quad (10.27)$$

Então,

$$(\bar{\mathbf{X}}, \mathbf{A})$$

é suficiente para

$$(\mu, \Sigma).$$

Comprovação. Para uma realização $\mathbf{x}_1, \dots, \mathbf{x}_n$, a densidade conjunta é

$$\begin{aligned} f_{\mu, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_n) &= (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \\ &\times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \end{aligned}$$

A soma das formas quadráticas pode ser escrita como

$$\begin{aligned} &\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \\ &= \mathbf{A} + n (\bar{\mathbf{x}} - \mu) (\bar{\mathbf{x}} - \mu)^\top, \end{aligned}$$

em que

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Logo, a densidade conjunta pode ser escrita como uma função de

$$(\bar{\mathbf{x}}, \mathbf{A})$$

e dos parâmetros, multiplicada por uma função que não depende dos parâmetros. Pelo Teorema da Fatoração de Neyman–Fisher, o par é suficiente. $\square$

A suficiência não implica, isoladamente, ausência de viés, consistência ou eficiência. Ela afirma que nenhuma informação sobre os parâmetros, contida na amostra sob o modelo adotado, é perdida quando a amostra é reduzida à estatística suficiente.

10.2.6 Equivariância e robustez

Equivariância. Uma transformação dos dados geralmente induz uma transformação correspondente no parâmetro. A equivariância exige que o procedimento de estimação respeite essa relação.

Definição 10.9 (Equivariância de um estimador). Considere uma transformação h aplicada à amostra e uma transformação g aplicada ao parâmetro. Um estimador T é equivariante em relação a essas transformações quando

$$T[h(\mathcal{X})] = g[T(\mathcal{X})]. \quad (10.28)$$

A expressão afirma que transformar os dados e depois estimar produz o mesmo resultado que estimar primeiro e aplicar a transformação correspondente ao estimador.

Considere, por exemplo,

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p} \quad \text{e} \quad \mathbf{d} \in \mathbb{R}^q.$$

Os parâmetros transformados são

$$\mu_Y = \mathbf{C}\mu + \mathbf{d}$$

e

$$\Sigma_Y = \mathbf{C}\Sigma\mathbf{C}^\top.$$

Os estimadores usuais da média e da covariância satisfarão relações da forma

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top.$$

Essas propriedades serão demonstradas nas seções dedicadas aos respectivos estimadores.

A equivariância é uma propriedade do procedimento em relação a um grupo ou classe de transformações. Ela deve ser distinguida da invariância da máxima verossimilhança, que trata da estimação de uma função do parâmetro depois que o estimador de máxima verossimilhança foi obtido.

Robustez. As propriedades anteriores são definidas em relação a um modelo ou a uma classe de distribuições. A robustez examina a estabilidade do estimador quando os dados ou o modelo sofrem perturbações.

A caracterização de robustez exige especificar:

- a classe de perturbações considerada;
- o aspecto do estimador que deve permanecer estável;
- a medida utilizada para quantificar a alteração.

Por isso, não existe uma única propriedade denominada robustez que ordene todos os estimadores.

O vetor de médias amostrais e a matriz de covariâncias amostral podem ser fortemente alterados por observações extremas. Como várias técnicas multivariadas utilizam esses objetos, a alteração pode se propagar para distâncias, autovalores, direções, regiões e regras de classificação.

Estimadores robustos de localização e dispersão procuram reduzir essa sensibilidade. Essa estabilidade pode envolver perda de eficiência quando o modelo ideal é válido, maior custo computacional ou estimação de um funcional populacional diferente daquele associado aos estimadores clássicos.

Robustez também deve ser distinguida de consistência. Um estimador pode ser consistente sob o modelo especificado e apresentar alta sensibilidade a pequenas contaminações. Outro pode ser estável diante de determinadas perturbações sem ser consistente para o parâmetro originalmente definido.

As propriedades apresentadas não formam uma hierarquia universal. A escolha de um estimador depende do parâmetro, da função de perda, do modelo probabilístico, do tamanho amostral, da dimensão e do objetivo da análise. Os métodos dos momentos e da máxima verossimilhança fornecem dois princípios gerais para construir os estimadores examinados neste capítulo.

10.3 Métodos de estimação

Um estimador pode ser construído a partir de diferentes princípios. O método dos momentos iguala características amostrais a momentos especificados pelo modelo populacional. A máxima verossimilhança escolhe os valores dos parâmetros que maximizam a função de verossimilhança para os dados observados (Casella; Berger, 2002).

Os dois métodos podem produzir o mesmo estimador em determinados modelos, mas essa coincidência não ocorre em geral. A forma de obtenção do estimador também não garante, isoladamente, ausência de viés, consistência ou eficiência. Essas propriedades precisam ser analisadas com base na distribuição amostral e nas condições do modelo.

10.3.1 Método dos momentos

Considere um parâmetro

$$\theta \in \Theta \subseteq \mathbb{R}^r$$

e uma função vetorial

$$\mathbf{q}(\mathbf{X}) \in \mathbb{R}^r$$

cuja esperança depende de θ :

$$\mathbf{m}(\theta) = E_{\theta}[\mathbf{q}(\mathbf{X})]. \quad (10.29)$$

O correspondente amostral é

$$\widehat{\mathbf{m}} = \frac{1}{n} \sum_{i=1}^n \mathbf{q}(\mathbf{X}_i). \quad (10.30)$$

Definição 10.10 (Estimador pelo método dos momentos). Um estimador de momentos de θ é uma solução de

$$\mathbf{m}(\hat{\theta}_{\text{MM}}) = \widehat{\mathbf{m}}. \quad (10.31)$$

A construção exige que os momentos escolhidos existam e forneçam informação suficiente para determinar o parâmetro. O sistema em Equação 10.31 pode não possuir solução, apresentar mais de uma solução ou produzir valores fora do espaço paramétrico.

Considere uma população multivariada com

$$E(\mathbf{X}) = \mu.$$

O primeiro momento amostral é

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \bar{\mathbf{X}}.$$

Consequentemente,

$$\hat{\mu}_{\text{MM}} = \bar{\mathbf{X}}. \quad (10.32)$$

Para construir um estimador de Σ , considere o segundo momento não central:

$$\mathbf{M}_2 = E(\mathbf{X}\mathbf{X}^\top).$$

A relação entre o segundo momento, a média e a covariância é

$$\Sigma = \mathbf{M}_2 - \mu\mu^\top. \quad (10.33)$$

O correspondente momento amostral é

$$\widehat{\mathbf{M}}_2 = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top.$$

Substituindo os momentos populacionais por seus correspondentes amostrais,

$$\begin{aligned}\widehat{\Sigma}_{\text{MM}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.\end{aligned}\tag{10.34}$$

O estimador de momentos utiliza o divisor n . Sua construção exige somente a existência dos momentos de segunda ordem e não depende da normalidade multivariada.

O estimador em Equação 10.34 é semidefinido positivo, pois, para todo $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned}\mathbf{a}^\top \widehat{\Sigma}_{\text{MM}} \mathbf{a} &= \frac{1}{n} \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{x}_i - \bar{\mathbf{x}})]^2 \\ &\geq 0.\end{aligned}$$

Ele pode ser singular quando os vetores centralizados não geram todo o espaço $\mathbb{R}^p$.

Existência e admissibilidade da solução

O método dos momentos não garante que a solução pertença ao espaço paramétrico. Em modelos com restrições de positividade, ordem ou identificabilidade, os momentos amostrais podem produzir uma solução inadmissível.

A existência e a unicidade do estimador precisam ser verificadas para o modelo considerado.

10.3.2 Verossimilhança e máxima verossimilhança

Considere uma família de distribuições dominada por uma medida comum, com densidade ou função de probabilidade

$$f(\mathbf{x}; \theta), \quad \theta \in \Theta.$$

Para uma amostra aleatória independente e identicamente distribuída,

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} f(\mathbf{x}; \theta),$$

a densidade conjunta é o produto das contribuições individuais.

Definição 10.11 (Função de verossimilhança). Para uma amostra observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n,$$

a função de verossimilhança é

$$L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(\mathbf{x}_i; \theta). \quad (10.35)$$

Na função de verossimilhança, os dados observados são mantidos fixos e θ varia no espaço paramétrico. A verossimilhança não é, em geral, uma distribuição de probabilidade sobre os parâmetros.

A log-verossimilhança é

$$\ell(\theta) = \log L(\theta).$$

Sob independência,

$$\ell(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n) = \sum_{i=1}^n \log f(\mathbf{x}_i; \theta). \quad (10.36)$$

Como o logaritmo é estritamente crescente, os máximos da verossimilhança e da log-verossimilhança coincidem.

Definição 10.12 (Estimador de máxima verossimilhança). Um estimador de máxima verossimilhança de θ é uma estatística

$$\hat{\theta}_{\text{MV}}$$

que satisfaz

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathcal{X}). \quad (10.37)$$

Após a observação da amostra,

$$\hat{\theta}_{\text{MV,obs}} \in \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}_1, \dots, \mathbf{x}_n).$$

A notação de conjunto em Equação 10.37 permite a existência de mais de um máximo. Em aplicações regulares, procura-se uma solução única e interior, mas essas propriedades não decorrem da definição.

As equações obtidas pela anulação do vetor escore fornecem candidatos a máximos interiores:

$$\nabla_{\theta} \ell(\theta) = \mathbf{0}.$$

Essas equações não garantem a existência nem a natureza do ponto encontrado. A solução precisa ser confrontada com:

- o espaço paramétrico;
- as condições de segunda ordem;
- possíveis máximos na fronteira;
- identificabilidade;
- existência e unicidade do máximo.

As ferramentas de diferenciação e otimização utilizadas nessa análise foram desenvolvidas no Capítulo 7.

10.3.2.1 Máxima verossimilhança no modelo normal multivariado

A maximização da verossimilhança normal multivariada produz o vetor de médias amostrais como estimador de μ e a SSCP dividida por n como estimador de Σ , desde que o máximo exista no espaço das matrizes positivas definidas (Anderson, 2003).

Considere

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad \text{e} \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, a verossimilhança é

$$\begin{aligned} L(\mu, \Sigma) &= (2\pi)^{-np/2} \det(\Sigma)^{-n/2} \\ &\times \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \right\}. \end{aligned} \quad (10.38)$$

A log-verossimilhança é

$$\begin{aligned}\ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu).\end{aligned}\tag{10.39}$$

Defina

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top.\tag{10.40}$$

A decomposição em torno da média amostral fornece

$$\begin{aligned}\sum_{i=1}^n (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top \\ = \mathbf{A} + n(\bar{\mathbf{x}} - \mu)(\bar{\mathbf{x}} - \mu)^\top.\end{aligned}\tag{10.41}$$

Consequentemente,

$$\begin{aligned}\ell(\mu, \Sigma) &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log \det(\Sigma) \\ &\quad - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{A}) \\ &\quad - \frac{n}{2} (\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu).\end{aligned}\tag{10.42}$$

Para uma matriz $\Sigma \succ \mathbf{0}$ fixa, o último termo é maximizado quando

$$\mu = \bar{\mathbf{x}}.$$

Substituindo esse valor, a log-verossimilhança perfilada para Σ torna-se

$$\ell_p(\Sigma) = C - \frac{n}{2} \left\{ \log \det(\Sigma) + \text{tr} \left[\Sigma^{-1} \left(\frac{\mathbf{A}}{n} \right) \right] \right\},\tag{10.43}$$

em que C não depende de Σ .

Teorema 10.4 (Estimadores de máxima verossimilhança no modelo normal). *Considere*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\mu \in \mathbb{R}^p \quad e \quad \Sigma \succ \mathbf{0}.$$

Para uma amostra observada, defina

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Se

$$\text{posto}(\mathbf{A}) = p,$$

a função de verossimilhança possui máximo único no espaço paramétrico, dado por

$$\hat{\mu}_{\text{MV,obs}} = \bar{\mathbf{x}}$$

e

$$\hat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{A}}{n}.$$

No conjunto dos resultados amostrais em que essa condição de posto se verifica, as regras de estimação correspondentes são

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{x}} \tag{10.44}$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \tag{10.45}$$

Comprovação. A maximização em relação a μ decorre de Equação 10.42. Como $\Sigma^{-1} \succ \mathbf{0}$,

$$(\bar{\mathbf{x}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu) \geq 0,$$

com igualdade somente quando

$$\mu = \bar{\mathbf{x}}.$$

Para maximizar em relação a Σ , defina

$$\mathbf{C} = \frac{\mathbf{A}}{n}.$$

Pela hipótese de posto completo,

$$\mathbf{C} \succ \mathbf{0}.$$

A maximização da log-verossimilhança equivale à minimização de

$$\log \det (\Sigma) + \operatorname{tr} \left(\Sigma^{-1} \mathbf{C} \right).$$

Defina

$$\mathbf{M} = \mathbf{C}^{-1/2} \Sigma \mathbf{C}^{-1/2}.$$

Então,

$$\log \det (\Sigma) = \log \det (\mathbf{C}) + \log \det (\mathbf{M})$$

e

$$\operatorname{tr} \left(\Sigma^{-1} \mathbf{C} \right) = \operatorname{tr} \left(\mathbf{M}^{-1} \right).$$

Se $m_1, \dots, m_p$ são os autovalores positivos de $\mathbf{M}$, a parcela que depende de $\mathbf{M}$ é

$$\sum_{j=1}^p \left(\log m_j + \frac{1}{m_j} \right).$$

Para $m > 0$, a função

$$\log m + \frac{1}{m}$$

assume seu mínimo em $m = 1$. Portanto,

$$\mathbf{M} = \mathbf{I}_p,$$

o que implica

$$\Sigma = \mathbf{C} = \frac{\mathbf{A}}{n}.$$

□

A condição

$$\text{posto}(\mathbf{A}) = p$$

exige que os vetores observados após a centralização gerem $\mathbb{R}^p$. Como

$$\text{posto}(\mathbf{A}) \leq \min(p, n-1),$$

uma condição necessária para que $\mathbf{A}$ tenha posto completo é

$$n \geq p+1.$$

Essa desigualdade não é suficiente para uma amostra arbitrária, pois as colunas da matriz de dados centralizada ainda podem apresentar dependência linear. Sob uma distribuição normal multivariada não singular e com $n \geq p+1$, a condição de posto completo ocorre com probabilidade 1.

Quando $\mathbf{A}$ é singular, existe uma direção não nula pertencente ao seu núcleo. É possível fazer um autovalor de Σ tender a zero nessa direção sem aumentar o termo

$$\text{tr}(\Sigma^{-1}\mathbf{A}),$$

enquanto

$$-\frac{n}{2} \log \det(\Sigma)$$

tende a $+\infty$. Portanto, a verossimilhança é ilimitada superiormente quando Σ se aproxima da fronteira do cone positivo definido.

Nesse caso, não existe estimador de máxima verossimilhança de Σ no espaço

$$\{\Sigma \in \mathbb{R}^{p \times p} : \Sigma \succ \mathbf{0}\}.$$

A matriz

$$\frac{\mathbf{A}}{n}$$

continua sendo uma matriz semidefinida positiva calculável e corresponde ao estimador de momentos, mas não é um estimador de máxima verossimilhança no modelo normal multivariado não singular.

O estimador de Σ em Equação 10.45 coincide com o estimador obtido pelo método dos momentos. Ele utiliza o divisor n e, como será demonstrado posteriormente, é viesado para Σ .

10.3.3 Invariância da máxima verossimilhança

A máxima verossimilhança possui uma propriedade que permite estimar funções do parâmetro sem realizar uma nova maximização desde o início.

Considere

$$\psi = g(\theta).$$

Quando g não é injetiva, diferentes valores de θ podem produzir o mesmo valor de ψ . A verossimilhança perfilada de ψ é definida por

$$L_g(\psi) = \sup_{\theta \in \Theta: g(\theta) = \psi} L(\theta). \quad (10.46)$$

Teorema 10.5 (Invariância da máxima verossimilhança). *Se*

$$\hat{\theta}_{\text{MV}}$$

é um estimador de máxima verossimilhança de θ e

$$\psi = g(\theta),$$

então

$$g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de ψ , em relação à verossimilhança perfilada definida em Equação 10.46.

Comprovação. Como

$$\hat{\theta}_{\text{MV}} \in \arg \max_{\theta \in \Theta} L(\theta),$$

tem-se

$$L(\hat{\theta}_{\text{MV}}) \geq L(\theta)$$

para todo $\theta \in \Theta$.

Defina

$$\hat{\psi} = g(\hat{\theta}_{\text{MV}}).$$

A fibra correspondente a $\hat{\psi}$ contém $\hat{\theta}_{\text{MV}}$. Portanto,

$$L_g(\hat{\psi}) = L(\hat{\theta}_{\text{MV}}).$$

Nenhum outro valor de ψ pode produzir uma verossimilhança perfilada maior, pois isso exigiria um valor de θ com verossimilhança superior ao máximo global. Logo,

$$\hat{\psi} = g(\hat{\theta}_{\text{MV}})$$

é um estimador de máxima verossimilhança de ψ . □

A invariância da máxima verossimilhança não é a mesma propriedade que a equivariância de um estimador.

- **Equivariância** compara o efeito de uma transformação aplicada aos dados com a transformação correspondente do estimador.
- **Invariância da máxima verossimilhança** permite estimar uma função do parâmetro aplicando essa função ao estimador de máxima verossimilhança.

Considere a matriz de correlações populacional

$$\mathcal{R} = \mathbf{D}_{\sigma}^{-1} \Sigma \mathbf{D}_{\sigma}^{-1},$$

em que

$$\mathbf{D}_{\sigma} = \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}}).$$

Quando o estimador normal de máxima verossimilhança de Σ existe, a invariância fornece

$$\widehat{\mathcal{R}}_{\text{MV}} = \widehat{\mathbf{D}}_{\sigma, \text{MV}}^{-1} \widehat{\Sigma}_{\text{MV}} \widehat{\mathbf{D}}_{\sigma, \text{MV}}^{-1}. \quad (10.47)$$

Como a multiplicação de uma matriz de covariâncias por uma constante positiva comum não altera suas correlações, a matriz em Equação 10.47 coincide com a matriz de correlações obtida a partir do estimador de covariâncias com divisor $n - 1$.

A propriedade também permite construir estimadores de máxima verossimilhança para funções como

$$\det(\Sigma), \quad \text{tr}(\Sigma), \quad \Sigma^{-1}$$

e os autovalores de Σ , desde que as funções estejam definidas no estimador obtido.

A invariância é uma propriedade de otimização. Ela não garante ausência de viés nem estabilidade numérica. Por exemplo,

$$\left(\widehat{\Sigma}_{\text{MV}}\right)^{-1}$$

pode existir e ser um estimador de máxima verossimilhança de Σ^{-1} sem ser não viesado. Quando a matriz estimada é mal condicionada, sua inversão também pode ser numericamente instável.

Os métodos apresentados produzem, no modelo normal, o vetor de médias amostrais e uma matriz de covariâncias com divisor n . A seção seguinte examina primeiro o estimador de μ , suas propriedades e sua interpretação geométrica.

10.4 Estimação do vetor de médias

O vetor de médias populacional

$$\mu = E(\mathbf{X})$$

descreve a localização da distribuição em $\mathbb{R}^p$. Sua estimação é realizada a partir do centro das observações que compõem a amostra.

Considere

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta,$$

com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma, \quad i = 1, \dots, n.$$

A normalidade multivariada não é necessária para definir o estimador nem para obter suas propriedades de primeira e segunda ordens.

10.4.1 Vetor de médias amostrais

O vetor de médias amostrais foi definido em Equação 10.8 por

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Componente a componente,

$$\bar{\mathbf{X}} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix},$$

em que

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij}, \quad j = 1, \dots, p. \quad (10.48)$$

Portanto, cada componente de $\bar{\mathbf{X}}$ é a média amostral da variável correspondente.

Utilizando a matriz aleatória da amostra,

$$\mathcal{X} \in \mathbb{R}^{n \times p},$$

o vetor pode ser escrito como

$$\bar{\mathbf{X}} = \frac{1}{n} \mathcal{X}^\top \mathbf{1}_n, \quad (10.49)$$

em que $\mathbf{1}_n$ é o vetor de dimensão n cujos elementos são iguais a 1.

Após a observação da amostra,

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n. \quad (10.50)$$

O vetor de médias amostrais é obtido tanto pelo método dos momentos quanto pela máxima verossimilhança sob o modelo normal:

$$\hat{\mu}_{\text{MM}} = \hat{\mu}_{\text{MV}} = \bar{\mathbf{x}}. \quad (10.51)$$

A coincidência dos estimadores decorre das estruturas específicas dos momentos e da verossimilhança normal. As propriedades examinadas a seguir dependem somente da amostragem aleatória e da existência dos momentos indicados.

O vetor observado $\bar{\mathbf{x}}$ também possui uma interpretação geométrica: ele é o centroide da nuvem de pontos formada pelas observações.

Teorema 10.6 (Caracterização da média amostral como centroide). *Para observações*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

o vetor de médias amostrais é o único minimizador de

$$Q(\mathbf{m}) = \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2, \quad \mathbf{m} \in \mathbb{R}^p.$$

Portanto,

$$\bar{\mathbf{x}} = \arg \min_{\mathbf{m} \in \mathbb{R}^p} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2. \quad (10.52)$$

Comprovação. Para qualquer $\mathbf{m} \in \mathbb{R}^p$,

$$\mathbf{x}_i - \mathbf{m} = (\mathbf{x}_i - \bar{\mathbf{x}}) + (\bar{\mathbf{x}} - \mathbf{m}).$$

Consequentemente,

$$\begin{aligned}
\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\
&\quad + 2(\bar{\mathbf{x}} - \mathbf{m})^\top \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) \\
&\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2.
\end{aligned}$$

Como

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0},$$

obtém-se

$$\begin{aligned}
\sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 &= \sum_{i=1}^n \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \\
&\quad + n \|\bar{\mathbf{x}} - \mathbf{m}\|^2.
\end{aligned} \tag{10.53}$$

A primeira parcela não depende de $\mathbf{m}$. A segunda é não negativa e assume valor zero somente quando

$$\mathbf{m} = \bar{\mathbf{x}}.$$

Logo, $\bar{\mathbf{x}}$ é o único minimizador. □

A identidade em Equação 10.53 separa a dispersão em torno de um ponto arbitrário em duas parcelas: a dispersão em torno do centroide e o afastamento entre esse ponto e o centroide. Sua forma matricial será retomada na construção da matriz de somas de quadrados e produtos cruzados.

10.4.2 Esperança e matriz de covariâncias

Para uma amostra aleatória de vetores independentes e identicamente distribuídos com segundos momentos finitos, o vetor de médias amostrais é não viesado para μ e possui matriz de covariâncias Σ/n (Anderson, 2003).

Teorema 10.7 (Esperança e covariância do vetor de médias amostrais). *Considere uma amostra aleatória multivariada com*

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$E(\bar{\mathbf{X}}) = \mu \quad (10.54)$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}. \quad (10.55)$$

Comprovação. Pela linearidade da esperança,

$$\begin{aligned} E(\bar{\mathbf{X}}) &= E\left(\frac{1}{n} \sum_{i=1}^n \mathbf{X}_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu \\ &= \mu. \end{aligned}$$

Para a matriz de covariâncias,

$$\begin{aligned} \text{Cov}(\bar{\mathbf{X}}) &= \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n \mathbf{X}_i\right) \\ &= \frac{1}{n^2} \text{Cov}\left(\sum_{i=1}^n \mathbf{X}_i\right). \end{aligned}$$

Como os vetores da amostra são independentes,

$$\text{Cov} \left(\sum_{i=1}^n \mathbf{X}_i \right) = \sum_{i=1}^n \text{Cov} (\mathbf{X}_i) = n\Sigma.$$

Portanto,

$$\text{Cov} (\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

□

O resultado Equação 10.54 mostra que

$$\text{Bias} (\bar{\mathbf{X}}) = \mathbf{0}.$$

Assim, $\bar{\mathbf{X}}$ é um estimador não viesado de μ .

Os elementos da matriz em Equação 10.55 são

$$\text{Var} (\bar{X}_j) = \frac{\sigma_{jj}}{n}$$

e

$$\text{Cov} (\bar{X}_j, \bar{X}_k) = \frac{\sigma_{jk}}{n}.$$

O tamanho amostral reduz pelo mesmo fator as variâncias das médias individuais e as covariâncias entre seus erros de estimação. A estrutura de orientação e dependência permanece determinada por Σ .

Sob a perda quadrática euclidiana, o estimador é não viesado e, portanto,

$$\begin{aligned} \text{EQM} (\bar{\mathbf{X}}) &= \text{tr} [\text{Cov} (\bar{\mathbf{X}})] \\ &= \frac{1}{n} \text{tr} (\Sigma). \end{aligned} \tag{10.56}$$

A variância total da população determina a magnitude global do erro de estimação segundo essa perda, enquanto o aumento de n reduz o erro na razão $1/n$.

10.4.3 Combinações lineares

Considere o parâmetro escalar

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

A invariância da máxima verossimilhança e a linearidade do método dos momentos conduzem ao estimador

$$\mathbf{a}^\top \bar{\mathbf{X}}.$$

Pela linearidade da esperança,

$$E(\mathbf{a}^\top \bar{\mathbf{X}}) = \mathbf{a}^\top \mu.$$

Logo, o estimador é não viesado para a combinação linear populacional.

Sua variância é

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \bar{\mathbf{X}}) &= \mathbf{a}^\top \text{Cov}(\bar{\mathbf{X}}) \mathbf{a} \\ &= \frac{1}{n} \mathbf{a}^\top \Sigma \mathbf{a}. \end{aligned} \tag{10.57}$$

A precisão depende da direção definida por $\mathbf{a}$. Combinações lineares com maior variabilidade populacional também apresentam maior variabilidade entre amostras.

Quando

$$\mathbf{a} = \mathbf{e}_j,$$

em que $\mathbf{e}_j$ é o j -ésimo vetor da base canônica, recupera-se

$$\text{Var}(\bar{X}_j) = \frac{\sigma_{jj}}{n}.$$

Para uma matriz constante

$$\mathbf{C} \in \mathbb{R}^{q \times p},$$

o estimador de

$$\mathbf{C}\mu$$

é

$$\mathbf{C}\bar{\mathbf{X}},$$

com

$$E(\mathbf{C}\bar{\mathbf{X}}) = \mathbf{C}\mu$$

e

$$\text{Cov}(\mathbf{C}\bar{\mathbf{X}}) = \frac{1}{n} \mathbf{C}\Sigma\mathbf{C}^\top. \quad (10.58)$$

Essas expressões serão utilizadas posteriormente na estimação de contrastes e combinações lineares de vetores de médias.

10.4.4 Consistência e equivariância

A redução da matriz de covariâncias pelo fator $1/n$ implica a concentração do estimador em torno de μ quando a dimensão p é fixa.

Teorema 10.8 (Consistência do vetor de médias amostrais). *Se*

$$E(\|\mathbf{X}\|^2) < \infty,$$

então

$$\bar{\mathbf{X}} \xrightarrow{P} \mu \quad (10.59)$$

quando $n \rightarrow \infty$.

Comprovação. Por Equação 10.56,

$$E \left[\|\bar{\mathbf{X}} - \mu\|^2 \right] = \frac{\text{tr}(\Sigma)}{n}.$$

Para qualquer $\varepsilon > 0$, a desigualdade de Markov aplicada à variável não negativa

$$\|\bar{\mathbf{X}} - \mu\|^2$$

fornece

$$\begin{aligned} P(\|\bar{\mathbf{X}} - \mu\| > \varepsilon) &\leq \frac{E \left[\|\bar{\mathbf{X}} - \mu\|^2 \right]}{\varepsilon^2} \\ &= \frac{\text{tr}(\Sigma)}{n\varepsilon^2}. \end{aligned}$$

O último termo converge para zero quando $n \rightarrow \infty$, o que estabelece a convergência em probabilidade. $\square$

A prova utiliza segundos momentos finitos. A consistência também pode ser obtida pela Lei dos Grandes Números sob condições mais gerais de integrabilidade, aplicada componente a componente quando p é fixo.

O vetor de médias amostrais também respeita transformações afins dos dados.

Teorema 10.9 (Equivariância afim do vetor de médias amostrais). *Considere*

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

em que

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Então,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}. \tag{10.60}$$

Comprovação. Pela definição do vetor de médias amostrais,

$$\begin{aligned}\bar{\mathbf{Y}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{Y}_i \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{C}\mathbf{X}_i + \mathbf{d}) \\ &= \mathbf{C} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \right) + \mathbf{d} \\ &= \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}.\end{aligned}$$

□

A média da população transformada é

$$\mu_Y = \mathbf{C}\mu + \mathbf{d}.$$

Portanto, a transformação que relaciona os parâmetros populacionais também relaciona seus estimadores. Essa propriedade garante coerência diante de translações, mudanças de unidade, rotações, seleção de variáveis e construção de combinações lineares.

10.4.5 Variabilidade entre amostras

A estimativa $\bar{\mathbf{x}}$ depende da amostra observada. Diferentes amostras da mesma população produzem diferentes centroides.

A Figura 10.1 apresenta os vetores de médias obtidos em amostras bivariadas de tamanhos 5 e 50, todas provenientes da mesma distribuição. O símbolo em forma de cruz indica o vetor de médias populacional.

Nos dois painéis, os vetores de médias amostrais se distribuem ao redor de μ . Quando o tamanho da amostra aumenta de 5 para 50, a nuvem torna-se mais concentrada.

Esse comportamento decorre de

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

A forma da dispersão entre as médias amostrais permanece determinada por Σ , enquanto sua magnitude diminui com o crescimento de n .

O vetor de médias amostrais estima a localização da população. A estimação da dispersão exige considerar os desvios das observações em relação a esse centro. Esses desvios conduzem à matriz de somas de quadrados e produtos cruzados e aos estimadores da matriz de covariâncias.




Figura 10.1: Vetores de médias amostrais em amostras bivariadas de tamanhos 5 e 50.

10.5 SSCP e estimação da matriz de covariâncias

O vetor de médias amostrais estima a localização da população. A estimação da matriz de covariâncias utiliza os desvios das observações em relação a esse centro.

Considere uma amostra aleatória multivariada com segundos momentos finitos:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_{\theta},$$

com

$$E(\mathbf{X}_i) = \mu$$

e

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

A matriz de covariâncias populacional pode ser escrita como

$$\Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^{\top}].$$

A construção amostral substitui o centro populacional desconhecido pelo vetor de médias amostrais.

10.5.1 Matriz amostral centralizada e SSCP

A matriz de centralização é

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (10.61)$$

Ela é simétrica e idempotente:

$$\mathbf{H}_n^\top = \mathbf{H}_n$$

e

$$\mathbf{H}_n^2 = \mathbf{H}_n.$$

Além disso,

$$\mathbf{H}_n \mathbf{1}_n = \mathbf{0}$$

e

$$\text{posto}(\mathbf{H}_n) = n - 1.$$

Aplicando essa matriz à matriz aleatória da amostra, obtém-se

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X} = \begin{bmatrix} (\mathbf{X}_1 - \bar{\mathbf{X}})^\top \\ \vdots \\ (\mathbf{X}_n - \bar{\mathbf{X}})^\top \end{bmatrix}. \quad (10.62)$$

Após a observação dos dados,

$$\mathbf{X}_c = \mathbf{H}_n \mathbf{X}.$$

As colunas de $\mathcal{X}_c$ possuem soma igual a zero:

$$\mathbf{1}_n^\top \mathcal{X}_c = \mathbf{0}^\top.$$

Definição 10.13 (Matriz de somas de quadrados e produtos cruzados). A matriz aleatória de somas de quadrados e produtos cruzados, denominada **SSCP amostral**, é

$$\mathbf{A} = \mathcal{X}_c^\top \mathcal{X}_c. \quad (10.63)$$

Equivalentemente,

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.64)$$

Para a amostra observada,

$$\mathbf{A} = \mathbf{X}_c^\top \mathbf{X}_c = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.65)$$

O elemento (j, k) de $\mathbf{A}$ é

$$a_{jk} = \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.66)$$

Na diagonal aparecem as somas de quadrados:

$$a_{jj} = \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2.$$

Fora da diagonal aparecem os produtos cruzados entre pares de variáveis.

A matriz $\mathbf{A}$ é simétrica e semidefinida positiva. Para qualquer vetor $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{A} \mathbf{a} &= \mathbf{a}^\top \mathcal{X}_c^\top \mathcal{X}_c \mathbf{a} \\ &= \|\mathcal{X}_c \mathbf{a}\|^2 \\ &= \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{x}_i - \bar{\mathbf{x}})]^2 \\ &\geq 0. \end{aligned} \quad (10.67)$$

A forma quadrática representa a soma de quadrados da combinação linear definida por $\mathbf{a}$, após sua centralização amostral.

10.5.2 Decomposição em torno de um centro arbitrário

A média amostral possui uma propriedade de decomposição que será utilizada na obtenção da esperança da SSCP e na estimação por máxima verossimilhança.

Teorema 10.10 (Decomposição em torno de um centro arbitrário). *Para qualquer vetor constante*

$$\mathbf{c} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \\ = \mathbf{A} + n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned} \tag{10.68}$$

Comprovação. Para cada unidade,

$$\mathbf{X}_i - \mathbf{c} = (\mathbf{X}_i - \bar{\mathbf{X}}) + (\bar{\mathbf{X}} - \mathbf{c}).$$

Substituindo essa expressão no produto exterior e somando sobre i , obtêm-se quatro parcelas. As duas parcelas cruzadas desaparecem porque

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) = \mathbf{0}.$$

A parcela formada pelos desvios em relação à média é $\mathbf{A}$, enquanto a parcela constante aparece n vezes. Logo,

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \\ = \mathbf{A} + n(\bar{\mathbf{X}} - \mathbf{c})(\bar{\mathbf{X}} - \mathbf{c})^\top. \end{aligned}$$

□

A segunda parcela é semidefinida positiva. Portanto,

$$\sum_{i=1}^n (\mathbf{X}_i - \mathbf{c})(\mathbf{X}_i - \mathbf{c})^\top \succeq \mathbf{A}. \quad (10.69)$$

A média amostral minimiza, segundo a ordem de Loewner, a matriz de dispersão calculada em torno de um centro comum. Tomando o traço, recupera-se a caracterização da média como minimizadora da soma das distâncias euclidianas quadráticas.

Para

$$\mathbf{c} = \mu,$$

a identidade torna-se

$$\begin{aligned} \sum_{i=1}^n (\mathbf{X}_i - \mu)(\mathbf{X}_i - \mu)^\top \\ = \mathbf{A} + n(\bar{\mathbf{X}} - \mu)(\bar{\mathbf{X}} - \mu)^\top. \end{aligned} \quad (10.70)$$

Essa expressão separa a dispersão em torno da média populacional em:

- dispersão das observações em torno da média amostral;
- dispersão da média amostral em torno da média populacional.

10.5.3 Esperança da SSCP

A centralização pela média amostral impõe uma restrição linear aos vetores de desvios e reduz em uma unidade os graus de liberdade disponíveis. Como consequência, o valor esperado da SSCP é $(n-1)\Sigma$ (Anderson, 2003).

Teorema 10.11 (Esperança da matriz SSCP). *Se*

$$E(\|\mathbf{X}\|^2) < \infty,$$

então

$$E(\mathbf{A}) = (n-1)\Sigma. \quad (10.71)$$

Comprovação. Tomando a esperança em Equação 10.70, a parcela do lado esquerdo satisfaz

$$E \left[\sum_{i=1}^n (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^\top \right] = \sum_{i=1}^n \Sigma \\ = n\Sigma.$$

Como

$$E(\bar{\mathbf{X}}) = \mu,$$

tem-se

$$E \left[n (\bar{\mathbf{X}} - \mu) (\bar{\mathbf{X}} - \mu)^\top \right] \\ = n \text{Cov}(\bar{\mathbf{X}}) \\ = n \frac{\Sigma}{n} \\ = \Sigma.$$

Portanto,

$$n\Sigma = E(\mathbf{A}) + \Sigma,$$

o que implica

$$E(\mathbf{A}) = (n - 1)\Sigma.$$

□

O fator $n - 1$ decorre da estimação do vetor de médias a partir da mesma amostra. Após a centralização, os n vetores de desvios satisfazem a restrição

$$\sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) = \mathbf{0}.$$

Assim, somente $n - 1$ desses vetores podem variar livremente.

10.5.4 Estimador não viesado

O resultado Equação 10.71 determina o divisor necessário para obter um estimador não viesado da matriz de covariâncias.

Definição 10.14 (Matriz de covariâncias amostral). Para $n \geq 2$, a matriz de covariâncias amostral é

$$\mathbf{S} = \frac{1}{n-1} \mathbf{A}. \quad (10.72)$$

Equivalentemente,

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top. \quad (10.73)$$

Para a amostra observada,

$$\mathbf{S} = \frac{1}{n-1} \mathbf{A} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c. \quad (10.74)$$

O elemento (j, k) de $\mathbf{S}$ é

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k). \quad (10.75)$$

Na diagonal,

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

é a variância amostral da variável j .

Para $j \neq k$,

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (X_{ik} - \bar{X}_k)$$

é a covariância amostral entre as variáveis j e k .

Teorema 10.12 (Ausência de viés da matriz de covariâncias amostral). *Se a população possui segundos momentos finitos, então*

$$E(\mathbf{S}) = \Sigma. \quad (10.76)$$

Comprovação. Pela definição de $\mathbf{S}$ e pelo resultado Equação 10.71,

$$\begin{aligned} E(\mathbf{S}) &= \frac{1}{n-1} E(\mathbf{A}) \\ &= \frac{1}{n-1} (n-1)\Sigma \\ &= \Sigma. \end{aligned}$$

□

A ausência de viés é uma propriedade matricial. Em particular,

$$E(S_{jk}) = \sigma_{jk}$$

para todos os pares (j, k) .

10.5.5 Estimador de máxima verossimilhança

Sob o modelo normal multivariado não singular e quando a SSCP observada possui posto completo, o estimador de máxima verossimilhança é

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{A}.$$

A relação entre os dois estimadores é

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}. \quad (10.77)$$

O valor esperado do estimador de máxima verossimilhança é

$$\begin{aligned} E(\widehat{\Sigma}_{\text{MV}}) &= \frac{1}{n} E(\mathbf{A}) \\ &= \frac{n-1}{n} \Sigma. \end{aligned} \quad (10.78)$$

Logo,

$$\text{Bias}(\widehat{\Sigma}_{\text{MV}}) = -\frac{1}{n}\Sigma. \quad (10.79)$$

O viés converge para a matriz nula quando n aumenta.

Os divisores n e $n - 1$ correspondem a critérios distintos:

- o divisor n decorre do método dos momentos e da maximização da verossimilhança sob o modelo normal;
- o divisor $n - 1$ corrige o valor esperado da SSCP e produz um estimador não viesado da matriz de covariâncias.

A interpretação como estimador de máxima verossimilhança depende da especificação normal e da existência do máximo no espaço paramétrico. A ausência de viés de $\mathbf{S}$ exige independência entre as unidades, distribuição idêntica e segundos momentos finitos, mas não exige normalidade (Anderson, 2003).

10.5.6 Consistência dos estimadores de covariância

A matriz de covariâncias amostral também é consistente quando a dimensão permanece fixa.

Teorema 10.13 (Consistência da matriz de covariâncias amostral). *Considere uma amostra aleatória multivariada com dimensão fixa p e segundos momentos finitos. Então,*

$$\mathbf{S} \xrightarrow{P} \Sigma \quad (10.80)$$

quando $n \rightarrow \infty$.

Além disso,

$$\widehat{\Sigma}_{\text{MV}} \xrightarrow{P} \Sigma. \quad (10.81)$$

Comprovação. A matriz de covariâncias com divisor n pode ser escrita como

$$\widehat{\Sigma}_{\text{MV}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top.$$

Pela Lei dos Grandes Números, aplicada elemento a elemento,

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top \xrightarrow{P} E(\mathbf{x} \mathbf{x}^\top).$$

Os segundos momentos finitos garantem a integrabilidade dos produtos $X_j X_k$. Também,

$$\bar{\mathbf{X}} \xrightarrow{P} \mu.$$

Pelo teorema do mapeamento contínuo,

$$\bar{\mathbf{X}}\bar{\mathbf{X}}^\top \xrightarrow{P} \mu\mu^\top.$$

Portanto,

$$\widehat{\Sigma}_{\text{MV}} \xrightarrow{P} E(\mathbf{X}\mathbf{X}^\top) - \mu\mu^\top = \Sigma.$$

Como

$$\mathbf{S} = \frac{n}{n-1} \widehat{\Sigma}_{\text{MV}}$$

e

$$\frac{n}{n-1} \longrightarrow 1,$$

conclui-se que

$$\mathbf{S} \xrightarrow{P} \Sigma.$$

□

A consistência apresentada é formulada para p fixo. Quando p cresce com n , a convergência elemento a elemento pode não garantir estabilidade espectral, precisão da inversa ou proximidade em norma matricial. Esses aspectos serão tratados na seção sobre dimensão e estabilidade.

10.5.7 Transformações, posto e singularidade

Considere uma transformação afim das observações:

$$\mathbf{Y}_i = \mathbf{C}\mathbf{X}_i + \mathbf{d}, \quad i = 1, \dots, n,$$

com

$$\mathbf{C} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{d} \in \mathbb{R}^q.$$

Pela equivariância da média,

$$\bar{\mathbf{Y}} = \mathbf{C}\bar{\mathbf{X}} + \mathbf{d}.$$

Logo,

$$\mathbf{Y}_i - \bar{\mathbf{Y}} = \mathbf{C}(\mathbf{X}_i - \bar{\mathbf{X}}).$$

Consequentemente,

$$\mathbf{A}_Y = \mathbf{C}\mathbf{A}_X\mathbf{C}^\top \quad (10.82)$$

e

$$\mathbf{S}_Y = \mathbf{C}\mathbf{S}_X\mathbf{C}^\top. \quad (10.83)$$

A translação $\mathbf{d}$ não altera a matriz de covariâncias. A transformação linear $\mathbf{C}$ atua sobre a estimativa da mesma forma que atua sobre a matriz de covariâncias populacional:

$$\Sigma_Y = \mathbf{C}\Sigma_X\mathbf{C}^\top.$$

Portanto, $\mathbf{S}$ é equivariante sob transformações afins.

A estrutura de posto da matriz de covariâncias amostral decorre de sua representação como matriz de Gram.

Teorema 10.14 (Posto da matriz de covariâncias amostral). *Para uma amostra com n observações e p variáveis,*

$$\text{posto}(\mathbf{S}) = \text{posto}(\mathcal{X}_c) \leq \min(p, n-1). \quad (10.84)$$

A matriz $\mathbf{S}$ é positiva definida se, e somente se,

$$\text{posto}(\mathcal{X}_c) = p. \quad (10.85)$$

Comprovação. Como

$$\mathbf{S} = \frac{1}{n-1} \mathcal{X}_c^\top \mathcal{X}_c,$$

a multiplicação pelo escalar positivo $(n-1)^{-1}$ não altera o posto. Além disso,

$$\text{posto}(\mathcal{X}_c^\top \mathcal{X}_c) = \text{posto}(\mathcal{X}_c).$$

Como

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X},$$

tem-se

$$\text{posto}(\mathcal{X}_c) \leq \min\{\text{posto}(\mathbf{H}_n), p\} = \min(n-1, p).$$

Finalmente, $\mathbf{S}$ é positiva definida se, e somente se,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. Pela representação de Gram, isso ocorre exatamente quando

$$\mathcal{X}_c \mathbf{a} \neq \mathbf{0}$$

para todo $\mathbf{a} \neq \mathbf{0}$, isto é, quando $\mathcal{X}_c$ possui posto coluna completo. □

Uma condição necessária para a definição positiva é

$$n - 1 \geq p,$$

ou seja,

$$n \geq p + 1.$$

Se

$$p \geq n,$$

então

$$\text{posto}(\mathbf{S}) \leq n - 1 < p,$$

e a matriz é necessariamente singular.

Mesmo quando $n \geq p + 1$, a matriz pode ser singular se existir dependência linear exata entre as variáveis centralizadas. Assim, a relação entre n e p fornece uma condição necessária, mas a definição positiva depende também da configuração observada.

A singularidade impede o cálculo da inversa ordinária de $\mathbf{S}$ e afeta procedimentos que utilizam a matriz de precisão, distâncias de Mahalanobis estimadas ou problemas de autovalores generalizados. A pseudoinversa pode fornecer uma solução no suporte amostral, mas não produz o mesmo objeto que uma estimativa regularizada positiva definida.

A seção seguinte utiliza os mesmos princípios para estimar covariâncias entre dois blocos de variáveis e construir a matriz de correlações amostral.

10.6 Estimação de covariâncias cruzadas e correlações

Alguns problemas multivariados organizam as variáveis em dois blocos observados sobre as mesmas unidades. Um bloco pode conter características físicas e o outro resultados laboratoriais, ou os dois blocos podem representar conjuntos distintos de respostas.

As covariâncias cruzadas descrevem a dependência linear entre os blocos em suas unidades originais. As correlações padronizam essas relações e permitem comparar variáveis medidas em escalas diferentes.

10.6.1 Covariâncias cruzadas entre blocos

Considere os vetores aleatórios

$$\mathbf{X} \in \mathbb{R}^p \quad \text{e} \quad \mathbf{Y} \in \mathbb{R}^q,$$

com vetores de médias

$$\mu_X = E(\mathbf{X})$$

e

$$\mu_Y = E(\mathbf{Y}).$$

A matriz de covariâncias cruzadas populacional é

$$\Sigma_{XY} = E \left[(\mathbf{X} - \mu_X) (\mathbf{Y} - \mu_Y)^\top \right] \in \mathbb{R}^{p \times q}. \quad (10.86)$$

Seu elemento (j, k) é

$$[\Sigma_{XY}]_{jk} = \text{Cov}(X_j, Y_k).$$

Em geral, Σ_{XY} não é quadrada nem simétrica. A inversão da ordem dos blocos produz

$$\Sigma_{YX} = \Sigma_{XY}^\top. \quad (10.87)$$

A matriz de covariâncias do vetor conjunto

$$\mathbf{Z} = \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \in \mathbb{R}^{p+q}$$

é particionada como

$$\Sigma_Z = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}. \quad (10.88)$$

Os blocos diagonais descrevem a dispersão interna de cada conjunto. Os blocos fora da diagonal descrevem as relações lineares entre os dois conjuntos.

Para estimar Σ_{XY} , é necessária uma amostra pareada:

$$(\mathbf{X}_1, \mathbf{Y}_1), \dots, (\mathbf{X}_n, \mathbf{Y}_n),$$

independente e identicamente distribuída segundo a distribuição conjunta de

$$(\mathbf{X}, \mathbf{Y}).$$

O pareamento significa que $\mathbf{X}_i$ e $\mathbf{Y}_i$ pertencem à mesma unidade amostral. Permutar as linhas de apenas um dos blocos altera as covariâncias estimadas.

Organize os blocos nas matrizes aleatórias

$$\mathcal{X} = \begin{bmatrix} \mathbf{X}_1^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}$$

e

$$\mathcal{Y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times q}.$$

As matrizes centralizadas são

$$\mathcal{X}_c = \mathbf{H}_n \mathcal{X}$$

e

$$\mathcal{Y}_c = \mathbf{H}_n \mathcal{Y}.$$

Definição 10.15 (Matriz de produtos cruzados entre blocos). A matriz de produtos cruzados entre os dois blocos é

$$\mathbf{A}_{XY} = \mathcal{X}_c^\top \mathcal{Y}_c. \quad (10.89)$$

Equivalentemente,

$$\mathbf{A}_{XY} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (10.90)$$

Após a observação da amostra,

$$\mathbf{A}_{XY} = \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.91)$$

A inversão da ordem dos blocos fornece

$$\mathbf{A}_{YX} = \mathbf{A}_{XY}^\top.$$

Definição 10.16 (Matriz de covariâncias cruzadas amostral). Para $n \geq 2$, a matriz de covariâncias cruzadas amostral é

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{A}_{XY}. \quad (10.92)$$

Para a amostra observada,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{Y}_c. \quad (10.93)$$

O elemento (j, k) de $\mathbf{S}_{XY}$ é

$$S_{X_j Y_k} = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \bar{X}_j) (Y_{ik} - \bar{Y}_k). \quad (10.94)$$

Esse elemento estima

$$\text{Cov}(X_j, Y_k).$$

Teorema 10.15 (Ausência de viés da covariância cruzada amostral). *Se o vetor conjunto*

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix}$$

possui segundos momentos finitos, então

$$E(\mathbf{S}_{XY}) = \Sigma_{XY}. \quad (10.95)$$

Comprovação. A matriz de covariâncias amostral do vetor conjunto pode ser particionada como

$$\mathbf{s}_Z = \begin{bmatrix} \mathbf{s}_{XX} & \mathbf{s}_{XY} \\ \mathbf{s}_{YX} & \mathbf{s}_{YY} \end{bmatrix}.$$

Pela ausência de viés da matriz de covariâncias amostral,

$$E(\mathbf{s}_Z) = \Sigma_Z.$$

A igualdade entre os blocos superiores direitos das duas matrizes fornece

$$E(\mathbf{s}_{XY}) = \Sigma_{XY}.$$

□

Sob normalidade conjunta,

$$\begin{bmatrix} \mathbf{X}_i \\ \mathbf{Y}_i \end{bmatrix} \stackrel{\text{iid}}{\sim} N_{p+q} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \Sigma_Z \right),$$

o estimador de máxima verossimilhança do bloco cruzado, quando o estimador positivo definido de Σ_Z existe, é

$$\widehat{\Sigma}_{XY, \text{MV}} = \frac{1}{n} \mathbf{A}_{XY}. \quad (10.96)$$

Sua relação com o estimador não viesado é

$$\widehat{\Sigma}_{XY, \text{MV}} = \frac{n-1}{n} \mathbf{s}_{XY}.$$

Consequentemente,

$$E(\widehat{\Sigma}_{XY, \text{MV}}) = \frac{n-1}{n} \Sigma_{XY}.$$

A matriz de covariâncias cruzadas também respeita transformações lineares. Considere

$$\mathbf{U} = \mathbf{C}\mathbf{X} + \mathbf{c}$$

e

$$\mathbf{V} = \mathbf{D}\mathbf{Y} + \mathbf{d},$$

com

$$\mathbf{C} \in \mathbb{R}^{r \times p} \quad \text{e} \quad \mathbf{D} \in \mathbb{R}^{s \times q}.$$

Então,

$$\mathbf{S}_{UV} = \mathbf{C}\mathbf{S}_{XY}\mathbf{D}^\top. \quad (10.97)$$

Para combinações lineares escalares,

$$U = \mathbf{a}^\top \mathbf{X} \quad \text{e} \quad V = \mathbf{b}^\top \mathbf{Y},$$

a covariância amostral correspondente é

$$S_{UV} = \mathbf{a}^\top \mathbf{S}_{XY} \mathbf{b}. \quad (10.98)$$

Assim, $\mathbf{S}_{XY}$ reúne as covariâncias amostrais entre todas as combinações lineares dos dois blocos.

O posto dessa matriz satisfaz

$$\text{posto}(\mathbf{S}_{XY}) \leq \min(p, q, n - 1). \quad (10.99)$$

A limitação decorre da centralização e das dimensões dos dois blocos. A matriz cruzada pode apresentar posto reduzido quando existem redundâncias lineares em qualquer um dos conjuntos de variáveis.

10.6.2 Matriz de correlações amostral

A matriz de covariâncias preserva as unidades de medida. A padronização de cada covariância pelos respectivos desvios-padrão produz uma medida adimensional de associação linear.

Considere a matriz de covariâncias amostral

$$\mathbf{S} = (S_{jk}) \in \mathbb{R}^{p \times p}.$$

Defina a matriz diagonal aleatória

$$\mathbf{D}_S = \text{diag}(S_{11}, \dots, S_{pp}).$$

A construção da matriz de correlações exige

$$S_{jj} > 0, \quad j = 1, \dots, p.$$

Definição 10.17 (Matriz de correlações amostral). Quando todas as variâncias amostrais são positivas, a matriz de correlações amostral é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}. \quad (10.100)$$

Após a observação da amostra,

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}, \quad (10.101)$$

em que

$$\mathbf{D}_S = \text{diag}(s_{11}, \dots, s_{pp}).$$

O elemento (j, k) de $\mathbf{R}$ é

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \quad (10.102)$$

A diagonal é unitária:

$$r_{jj} = 1, \quad j = 1, \dots, p.$$

A matriz de correlações também pode ser obtida a partir da matriz de dados padronizados. Defina

$$\mathbf{Z} = \mathbf{X}_c \mathbf{D}_S^{-1/2}. \quad (10.103)$$

Cada coluna de $\mathbf{Z}$ possui média zero e variância amostral igual a 1. Como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c,$$

segue que

$$\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^\top \mathbf{Z}. \quad (10.104)$$

Portanto, $\mathbf{R}$ é a matriz de covariâncias das variáveis padronizadas.

Além disso,

$$r_{jk} = \frac{\mathbf{z}_{\cdot j}^\top \mathbf{z}_{\cdot k}}{\|\mathbf{z}_{\cdot j}\| \|\mathbf{z}_{\cdot k}\|}.$$

Assim, r_{jk} é o cosseno do ângulo entre as colunas centralizadas e padronizadas:

$$r_{jk} = \cos(\theta_{jk}). \quad (10.105)$$

Essa interpretação implica

$$-1 \leq r_{jk} \leq 1.$$

Os valores extremos correspondem a dependência linear exata entre as duas colunas padronizadas.

Existência da correlação amostral

A correlação envolvendo uma variável não está definida quando sua variância amostral é zero.

Uma coluna constante não pode ser padronizada porque

$$s_{jj} = 0$$

e, conseqüentemente, $s_{jj}^{-1/2}$ não existe.

10.6.3 Propriedades estruturais

A matriz de correlações amostral herda propriedades da matriz de covariâncias.

Teorema 10.16 (Propriedades da matriz de correlações amostral). *Quando todas as variâncias amostrais são positivas, a matriz $\mathbf{R}$ é:*

1. *simétrica;*
2. *semidefinida positiva;*
3. *unitária na diagonal.*

Além disso,

$$\text{posto}(\mathbf{R}) = \text{posto}(\mathbf{S}). \quad (10.106)$$

Consequentemente,

$$\mathbf{R} \succ \mathbf{0} \iff \mathbf{S} \succ \mathbf{0}. \quad (10.107)$$

Comprovação. A simetria decorre de

$$\mathbf{S}^\top = \mathbf{S}$$

e da diagonalidade de $\mathbf{D}_S^{-1/2}$.

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\begin{aligned} \mathbf{a}^\top \mathbf{R} \mathbf{a} &= \mathbf{a}^\top \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2} \mathbf{a} \\ &= (\mathbf{D}_S^{-1/2} \mathbf{a})^\top \mathbf{S} (\mathbf{D}_S^{-1/2} \mathbf{a}) \\ &\geq 0. \end{aligned}$$

Logo, $\mathbf{R}$ é semidefinida positiva.

A diagonal unitária decorre diretamente da padronização:

$$R_{jj} = \frac{S_{jj}}{S_{jj}} = 1.$$

Como $\mathbf{D}_S^{-1/2}$ é invertível, a transformação por congruência preserva o posto e a definição positiva. $\square$

Uma matriz simétrica com diagonal unitária e elementos no intervalo $[-1, 1]$ não é necessariamente uma matriz de correlações válida. A semidefinição positiva também é necessária.

A condição de definição positiva pode ser expressa como

$$\text{posto}(\mathbf{Z}) = p.$$

Portanto, são necessárias:

- variâncias amostrais positivas;
- ausência de dependência linear entre as variáveis centralizadas;
- dimensão suficiente para que $n - 1 \geq p$.

A desigualdade

$$n \geq p + 1$$

é necessária, mas não garante isoladamente a definição positiva. Quando

$$p \geq n,$$

tem-se

$$\text{posto}(\mathbf{R}) \leq n - 1 < p,$$

e a matriz é necessariamente singular.

O determinante satisfaz

$$\det(\mathbf{R}) = \frac{\det(\mathbf{S})}{\prod_{j=1}^p s_{jj}}. \quad (10.108)$$

A padronização remove as escalas marginais, mas não altera o posto nem elimina dependências lineares.

A matriz de correlações obtida a partir do estimador de máxima verossimilhança normal da covariância coincide com $\mathbf{R}$. De fato,

$$\widehat{\Sigma}_{\text{MV}} = \frac{n-1}{n} \mathbf{S}.$$

O fator comum $(n-1)/n$ aparece nas covariâncias e nas variâncias e desaparece na padronização. Pela invariância da máxima verossimilhança,

$$\widehat{\mathcal{R}}_{\text{MV}} = \mathbf{R}, \quad (10.109)$$

quando o estimador normal de máxima verossimilhança da matriz de covariâncias existe.

Essa igualdade não implica ausência de viés. Em geral,

$$E(R_{jk}) \neq \rho_{jk}.$$

A correlação amostral é uma razão de estatísticas aleatórias, e sua esperança não é obtida pela razão entre as respectivas esperanças.

Quando $\mathbf{S}$ é consistente para Σ e todas as variâncias populacionais são positivas, o teorema do mapeamento contínuo fornece

$$\mathbf{R} \xrightarrow{P} \mathcal{R}. \quad (10.110)$$

10.6.4 Transformações de localização e escala

Considere transformações individuais das variáveis:

$$Y_j = a_j + b_j X_j, \quad b_j \neq 0.$$

As constantes de localização a_j desaparecem após a centralização. Para duas variáveis transformadas,

$$r_{Y_j Y_k} = \text{sgn}(b_j) \text{sgn}(b_k) r_{X_j X_k}. \quad (10.111)$$

Se os dois fatores de escala são positivos, a correlação permanece inalterada. Se o sinal de apenas uma variável é invertido, o sinal da correlação também é invertido.

Em forma matricial, considere

$$\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathbf{1}_n \mathbf{a}^\top,$$

em que

$$\mathbf{B} = \text{diag}(b_1, \dots, b_p)$$

possui elementos diagonais não nulos. Defina

$$\mathbf{D}_{\text{sgn}} = \text{diag} [\text{sgn} (b_1) , \dots , \text{sgn} (b_p)] .$$

Então,

$$\mathbf{R}_Y = \mathbf{D}_{\text{sgn}} \mathbf{R}_X \mathbf{D}_{\text{sgn}} . \quad (10.112)$$

Quando todos os fatores de escala são positivos,

$$\mathbf{R}_Y = \mathbf{R}_X .$$

A matriz de correlações cruzadas entre dois blocos é obtida pela padronização de $\mathbf{S}_{XY}$. Defina

$$\mathbf{D}_X = \text{diag} (s_{X_1 X_1} , \dots , s_{X_p X_p})$$

e

$$\mathbf{D}_Y = \text{diag} (s_{Y_1 Y_1} , \dots , s_{Y_q Y_q}) .$$

Quando todas as variâncias são positivas,

$$\mathbf{R}_{XY} = \mathbf{D}_X^{-1/2} \mathbf{S}_{XY} \mathbf{D}_Y^{-1/2} . \quad (10.113)$$

Seu elemento (j, k) é

$$r_{X_j Y_k} = \frac{s_{X_j Y_k}}{\sqrt{s_{X_j X_j} s_{Y_k Y_k}}} .$$

Além disso,

$$\mathbf{R}_{YX} = \mathbf{R}_{XY}^\top .$$

A matriz de correlações do vetor conjunto possui a forma

$$\mathbf{R}_Z = \begin{bmatrix} \mathbf{R}_{XX} & \mathbf{R}_{XY} \\ \mathbf{R}_{YX} & \mathbf{R}_{YY} \end{bmatrix} . \quad (10.114)$$

Os blocos cruzados serão utilizados posteriormente para estudar associações entre dois conjuntos de variáveis. Antes disso, é necessário examinar as limitações dos estimadores clássicos quando a dimensão é elevada, as variáveis são fortemente redundantes ou a amostra contém observações de grande influência.

10.7 Dimensão, estabilidade e extensões da estimação

A matriz de covariâncias de um vetor com p componentes possui

$$\frac{p(p+1)}{2}$$

parâmetros distintos. O número de quantidades a estimar cresce quadraticamente com a dimensão, enquanto o número de unidades amostrais permanece igual a n .

Essa relação afeta o posto, a estabilidade espectral e a possibilidade de inverter a matriz de covariâncias amostral. Uma matriz pode ser invertível e, ainda assim, produzir estimativas instáveis quando alguns de seus autovalores são muito pequenos.

Regularização e estimação robusta respondem a problemas diferentes:

- a regularização procura reduzir instabilidade causada pela dimensão, redundância ou pequeno tamanho amostral;
- a estimação robusta procura reduzir sensibilidade a observações extremas e desvios do modelo.

As duas abordagens podem ser combinadas, mas não devem ser tratadas como equivalentes.

10.7.1 Relação entre p e n

O comportamento da matriz de covariâncias amostral depende da relação entre a dimensão p e o tamanho amostral n . No regime clássico, p permanece fixo enquanto n cresce. Quando p não é pequeno em relação a n , a estimação do espectro, da inversa e do determinante pode tornar-se instável, mesmo antes da singularidade (Mardia; Kent; Taylor, 2024).

O limite de posto obtido em Equação 10.84 é

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Essa desigualdade permite distinguir três situações conceituais.

10.7.1.1 Dimensão fixa e crescimento do tamanho amostral

No regime clássico, p permanece fixo enquanto

$$n \rightarrow \infty.$$

Nesse caso, a quantidade de parâmetros da matriz de covariâncias permanece fixa, e cada covariância é estimada com um número crescente de observações.

Sob segundos momentos finitos,

$$\mathbf{S} \xrightarrow{P} \Sigma$$

elemento a elemento e em qualquer norma matricial equivalente em dimensão fixa.

Se

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade tendendo a 1,

$$\mathbf{S} \succ \mathbf{0}$$

para amostras suficientemente grandes.

10.7.1.2 Dimensão não desprezível em relação ao tamanho amostral

Quando p cresce com n e a razão

$$\frac{p}{n}$$

não é pequena, a matriz de covariâncias amostral pode possuir posto completo e ainda apresentar elevada variabilidade.

Nesse regime, a convergência de cada elemento de $\mathbf{S}$ não garante, isoladamente, que:

- os autovalores estejam próximos dos autovalores populacionais;
- os autovetores estejam bem estimados;
- a inversa seja estável;
- o determinante seja estimado com precisão;
- as distâncias construídas com $\mathbf{S}^{-1}$ sejam estáveis.

O aumento de p também amplia o número de covariâncias fora da diagonal:

$$\frac{p(p-1)}{2}.$$

Essas quantidades são estimadas a partir das mesmas n unidades. O crescimento da dimensão aumenta a quantidade de relações que precisam ser determinadas, mas não acrescenta novas observações.

Não existe um valor universal da razão p/n que separe matrizes estáveis e instáveis. O comportamento também depende:

- da estrutura de Σ ;
- da separação entre seus autovalores;
- do grau de correlação entre as variáveis;
- da distribuição populacional;
- da função da matriz utilizada na análise.

10.7.1.3 Dimensão maior ou igual ao tamanho amostral

Quando

$$p \geq n,$$

tem-se necessariamente

$$\text{posto}(\mathbf{S}) \leq n - 1 < p.$$

Portanto,

$$\mathbf{S}$$

é singular.

A singularidade não significa ausência de informação na amostra. Ela indica que os vetores centralizados pertencem a um subespaço de dimensão não superior a $n - 1$.

Existem, nesse caso, vetores não nulos $\mathbf{a} \in \mathbb{R}^p$ tais que

$$\mathcal{X}_c \mathbf{a} = \mathbf{0}.$$

Consequentemente,

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = 0.$$

A combinação linear definida por $\mathbf{a}$ apresenta variância amostral nula, mesmo que a variância populacional correspondente seja positiva.

Posto amostral e posto populacional

A singularidade de $\mathbf{S}$ não implica necessariamente singularidade de Σ .

Quando $p \geq n$, a singularidade amostral decorre da quantidade insuficiente de direções independentes disponíveis após a centralização, mesmo que a matriz de covariâncias populacional seja positiva definida.

10.7.2 Condicionamento e inversão

Considere a decomposição espectral de uma matriz de covariâncias observada positiva definida:

$$\mathbf{S} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top,$$

em que

$$\mathbf{\Lambda} = \text{diag}(\ell_1, \dots, \ell_p)$$

e

$$\ell_1 \geq \dots \geq \ell_p > 0.$$

Sua inversa é

$$\mathbf{S}^{-1} = \mathbf{Q} \mathbf{\Lambda}^{-1} \mathbf{Q}^\top,$$

com

$$\mathbf{\Lambda}^{-1} = \text{diag}\left(\frac{1}{\ell_1}, \dots, \frac{1}{\ell_p}\right).$$

Autovalores pequenos tornam-se autovalores grandes na matriz inversa. Assim, erros de estimação em direções de pequena variabilidade podem ser amplificados pela inversão.

Definição 10.18 (Número de condição espectral). Para uma matriz simétrica positiva definida $\mathbf{S}$, o número de condição espectral é

$$\kappa_2(\mathbf{S}) = \frac{\ell_{\max}(\mathbf{S})}{\ell_{\min}(\mathbf{S})}. \quad (10.115)$$

Quando os autovalores possuem magnitudes semelhantes,

$$\kappa_2(\mathbf{S})$$

fica próximo de 1. Quando o menor autovalor se aproxima de zero, o número de condição aumenta.

Para uma matriz singular,

$$\ell_{\min}(\mathbf{S}) = 0,$$

e o número de condição é considerado infinito.

Uma matriz com número de condição elevado é denominada mal condicionada. Pequenas perturbações nos dados ou nos elementos de $\mathbf{S}$ podem produzir alterações relevantes em:

$$\mathbf{S}^{-1},$$

$$\det(\mathbf{S}),$$

nos autovalores e nos autovetores associados a autovalores próximos.

A existência algébrica da inversa não garante sua estabilidade estatística. Quando

$$\ell_{\min}(\mathbf{S})$$

é positivo, mas muito pequeno, a matriz é invertível e pode produzir resultados altamente sensíveis à amostra.

Considere, por exemplo, a distância construída com a covariância estimada:

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = (\mathbf{x} - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

Em coordenadas espectrais,

$$d_{\mathbf{S}}^2(\mathbf{x}, \bar{\mathbf{x}}) = \sum_{j=1}^p \frac{z_j^2}{\ell_j}.$$

Direções associadas a autovalores pequenos recebem pesos elevados. Se esses autovalores forem estimados com grande erro, a distância também poderá ser instável.

10.7.3 Regularização

A regularização modifica o estimador amostral para reduzir sua variabilidade, melhorar seu condicionamento ou garantir a existência de uma inversa. Essa modificação geralmente introduz viés e deve ser avaliada por seu risco, e não somente pela proximidade elemento a elemento da matriz estimada.

Uma estratégia de contração combina a matriz de covariâncias amostral com uma matriz-alvo de estrutura mais simples. Em problemas de grande dimensão, essa combinação pode produzir estimadores mais estáveis e melhor condicionados que a matriz amostral não regularizada (Ledoit; Wolf, 2004).

Definição 10.19 (Estimador de covariância por contração). Considere uma matriz-alvo simétrica

$$\Gamma \in \mathbb{R}^{p \times p}$$

e um peso

$$0 \leq \lambda \leq 1.$$

O estimador por contração é

$$\hat{\Sigma}_{\lambda} = (1 - \lambda)\mathbf{S} + \lambda\Gamma. \quad (10.116)$$

Na definição anterior, Γ e λ são quantidades fixadas. Em aplicações, a matriz-alvo, o peso de contração ou ambos podem ser escolhidos a partir da própria amostra.

Quando o alvo é estimado, utiliza-se a notação

$$\hat{\Gamma}$$

e o estimador assume a forma

$$\widehat{\Sigma}_{\hat{\lambda}} = (1 - \hat{\lambda}) \mathbf{S} + \hat{\lambda} \widehat{\Gamma}. \quad (10.117)$$

Nesse caso, a aleatoriedade de $\widehat{\Gamma}$ e de $\hat{\lambda}$ também contribui para o viés e para a variabilidade do estimador. As propriedades de risco não podem ser obtidas tratando essas quantidades como constantes.

Os resultados algébricos sobre semidefinição ou definição positiva continuam válidos para cada amostra sempre que o alvo estimado satisfizer as condições matriciais correspondentes.

Quando

$$\lambda = 0,$$

recupera-se a matriz de covariâncias amostral:

$$\widehat{\Sigma}_0 = \mathbf{S}.$$

Quando

$$\lambda = 1,$$

o estimador coincide com o alvo:

$$\widehat{\Sigma}_1 = \Gamma.$$

Para valores intermediários, o estimador combina a informação da amostra com a estrutura imposta pelo alvo.

A matriz-alvo precisa possuir as mesmas dimensões e ser compatível com a escala das variáveis. Entre as possibilidades conceituais estão:

- uma matriz diagonal, que preserva estimativas das variâncias e reduz as covariâncias;
- uma matriz esférica $\tau \mathbf{I}_p$, quando as variáveis são comparáveis em escala;
- a identidade $\mathbf{I}_p$ para a regularização de uma matriz de correlações;
- uma estrutura definida por conhecimento substantivo.

A utilização direta de

$$\Gamma = \mathbf{I}_p$$

como alvo de uma matriz de covariâncias pressupõe variáveis adimensionais ou medidas em escalas comparáveis. Caso contrário, o valor 1 não possui o mesmo significado para todas as variâncias.

Uma alternativa esférica baseada na escala média observada é

$$\hat{\tau} = \frac{1}{p} \text{tr}(\mathbf{S}) \quad (10.118)$$

e

$$\hat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\hat{\tau}\mathbf{I}_p. \quad (10.119)$$

Essa escolha é adequada somente quando uma variância média comum possui interpretação para o conjunto de variáveis. Quando as unidades são distintas, pode-se trabalhar com a matriz de correlações ou utilizar um alvo que preserve as escalas marginais.

Um alvo diagonal é

$$\hat{\Gamma}_{\text{diag}} = \text{diag}(S_{11}, \dots, S_{pp}).$$

Nesse caso,

$$\hat{\Sigma}_{\lambda, \text{diag}} = (1 - \lambda)\mathbf{S} + \lambda\hat{\Gamma}_{\text{diag}}. \quad (10.120)$$

As variâncias amostrais permanecem inalteradas, enquanto as covariâncias são multiplicadas por $1 - \lambda$.

Teorema 10.17 (Definição positiva do estimador por contração). *Se*

$$\mathbf{S} \succeq \mathbf{0},$$

$$\Gamma \succ \mathbf{0}$$

e

$$0 < \lambda \leq 1,$$

então

$$\widehat{\Sigma}_\lambda \succ \mathbf{0}. \quad (10.121)$$

Comprovação. Para qualquer vetor não nulo $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} = (1 - \lambda) \mathbf{a}^\top \mathbf{S} \mathbf{a} + \lambda \mathbf{a}^\top \Gamma \mathbf{a}.$$

A primeira parcela é não negativa. Como $\Gamma \succ \mathbf{0}$, a segunda é estritamente positiva. Portanto,

$$\mathbf{a}^\top \widehat{\Sigma}_\lambda \mathbf{a} > 0$$

para todo $\mathbf{a} \neq \mathbf{0}$. □

Esse resultado permite obter uma matriz invertível mesmo quando

$$p \geq n$$

ou quando existem dependências lineares exatas na amostra.

Considere o alvo

$$\Gamma = \tau \mathbf{I}_p, \quad \tau > 0.$$

Se

$$\mathbf{S} = \mathbf{Q} \operatorname{diag}(L_1, \dots, L_p) \mathbf{Q}^\top,$$

então

$$\widehat{\Sigma}_\lambda = \mathbf{Q} \operatorname{diag}[(1 - \lambda)L_1 + \lambda\tau, \dots, (1 - \lambda)L_p + \lambda\tau] \mathbf{Q}^\top. \quad (10.122)$$

Os autovetores permanecem os mesmos, enquanto cada autovalor é deslocado na direção de τ :

$$L_{j,\lambda} = (1 - \lambda)L_j + \lambda\tau. \quad (10.123)$$

Em particular, se $L_j = 0$ e $\lambda > 0$,

$$L_{j,\lambda} = \lambda \tau > 0.$$

A contração reduz a dispersão entre os autovalores e melhora o condicionamento quando o alvo esférico é adequadamente escolhido.

A Figura 10.2 compara os autovalores de matrizes de covariâncias amostrais e de suas versões regularizadas em dois regimes dimensionais.




Figura 10.2: Espectros da matriz de covariâncias amostral e de sua versão regularizada em dois regimes dimensionais.

No regime $p < n$, a matriz amostral simulada possui posto completo, mas seus menores autovalores são mais sensíveis. A regularização desloca o espectro na direção do alvo.

No regime $p \geq n$, a matriz amostral apresenta autovalores nulos em decorrência do limite de posto. A versão regularizada substitui esses valores por autovalores positivos e produz uma matriz invertível.

A figura ilustra um efeito algébrico da regularização. A escolha de λ e da matriz-alvo é um problema estatístico e não pode ser determinada apenas pela exigência de invertibilidade.

Um valor elevado de λ reduz a influência da amostra e aumenta a influência do alvo. Um valor pequeno preserva mais da estrutura empírica, mas pode produzir menor ganho de estabilidade.

Os procedimentos específicos para selecionar λ não serão desenvolvidos neste capítulo. A escolha deve considerar o critério de perda, a estrutura assumida para Σ e o objetivo da estimação.

10.7.4 Pseudoinversa e regularização

Quando $\mathbf{S}$ é singular, sua pseudoinversa de Moore–Penrose pode ser obtida pela decomposição espectral.

Considere

$$\mathbf{S} = \mathbf{Q}_r \Lambda_r \mathbf{Q}_r^\top,$$

em que

$$\Lambda_r = \text{diag}(\ell_1, \dots, \ell_r)$$

contém os r autovalores positivos. A pseudoinversa é

$$\mathbf{S}^+ = \mathbf{Q}_r \Lambda_r^{-1} \mathbf{Q}_r^\top. \quad (10.124)$$

A pseudoinversa atua como a inversa ordinária na imagem de $\mathbf{S}$ e atribui valor zero às direções pertencentes ao núcleo.

Se

$$\mathbf{a} \in \mathcal{N}(\mathbf{S}),$$

então

$$\mathbf{S}^+ \mathbf{a} = \mathbf{0}.$$

Uma matriz regularizada positiva definida produz um comportamento diferente. Para o alvo esférico,

$$\mathbf{S}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\tau\mathbf{I}_p,$$

tem-se

$$\mathbf{S}_\lambda^{-1} = \mathbf{Q} \operatorname{diag} \left[\frac{1}{(1-\lambda)\ell_j + \lambda\tau} \right] \mathbf{Q}^\top. \quad (10.125)$$

Nas direções em que

$$\ell_j = 0,$$

a inversa regularizada atribui peso

$$\frac{1}{\lambda\tau},$$

enquanto a pseudoinversa atribui peso zero.

Assim:

- a pseudoinversa restringe a operação ao suporte observado;
- a regularização introduz variabilidade positiva em todas as direções;
- a pseudoinversa preserva os autovalores positivos originais;
- a regularização modifica o espectro;
- a pseudoinversa não resolve o mau condicionamento causado por autovalores positivos muito pequenos;
- a regularização pode limitar a amplificação produzida pela inversão.

A escolha entre os dois objetos depende da interpretação do problema. A pseudoinversa é uma extensão algébrica da inversa para uma matriz singular. A regularização corresponde à adoção de um novo estimador da matriz de covariâncias.

Invertibilidade não implica validade inferencial

Substituir $\mathbf{S}^{-1}$ por uma pseudoinversa ou por uma inversa regularizada altera o procedimento estatístico.

Distribuições amostrais e calibrações inferenciais derivadas para a inversa clássica de $\mathbf{S}$ não podem ser transferidas automaticamente para essas substituições.

10.7.5 Sensibilidade e robustez

O vetor de médias e a matriz de covariâncias amostral possuem sensibilidade não limitada a observações extremas: uma contaminação suficientemente afastada pode produzir alterações arbitrariamente grandes nas estimativas de localização e dispersão (Maronna et al., 2019).

Considere uma amostra observada

$$\mathbf{x}_1, \dots, \mathbf{x}_n$$

e substitua a observação $\mathbf{x}_k$ por $\mathbf{x}_k^*$. A nova média é

$$\bar{\mathbf{x}}^* = \bar{\mathbf{x}} + \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k). \quad (10.126)$$

Portanto,

$$\bar{\mathbf{x}}^* - \bar{\mathbf{x}} = \frac{1}{n} (\mathbf{x}_k^* - \mathbf{x}_k).$$

O efeito pode assumir magnitude arbitrariamente grande quando $\mathbf{x}_k^*$ se afasta da nuvem de dados.

Na matriz de covariâncias, a influência pode ser ainda maior porque aparecem produtos quadráticos dos desvios:

$$(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Uma observação afastada pode alterar simultaneamente:

- o vetor de médias;
- as variâncias;
- as covariâncias;
- as correlações;
- os autovalores;
- os autovetores;
- o determinante;
- a inversa;
- as distâncias construídas a partir da matriz estimada.

A presença de uma observação influente não implica automaticamente erro de medição. Ela pode representar:

- uma unidade válida de uma região pouco frequente da população;
- uma observação proveniente de outra população;
- uma falha de registro;
- uma distribuição com caudas mais pesadas;
- assimetria ou heterogeneidade não representada pelo modelo.

A decisão de manter, corrigir ou retirar uma observação exige informação sobre o processo de coleta e o contexto substantivo.

Estimadores robustos de localização e dispersão procuram limitar alterações excessivas diante de classes especificadas de contaminação. Sua avaliação envolve compromissos entre resistência, eficiência, equivariância e condições de existência (Maronna et al., 2019). Entre os critérios relevantes estão:

- sensibilidade local;
- proporção de contaminação tolerada;
- equivariância sob transformações;
- eficiência no modelo de referência;
- existência em relação a n e p ;
- custo computacional;
- parâmetro ou funcional populacional estimado.

Não existe um estimador robusto superior segundo todos esses critérios.

Um estimador de localização pode ser resistente a observações extremas e não respeitar transformações afins gerais. Um estimador de dispersão pode ser robusto em baixa dimensão e deixar de existir quando p é grande em relação a n . Outro procedimento pode preservar equivariância afim e exigir amostras maiores.

Também é necessário distinguir três problemas:

1. **observações extremas**, relacionadas à sensibilidade dos estimadores;
2. **alta dimensão**, relacionada à quantidade de parâmetros e ao posto;
3. **má especificação do modelo**, relacionada à inadequação da família probabilística adotada.

Um mesmo conjunto de dados pode apresentar mais de um desses problemas, mas cada um exige uma análise própria.

A inspeção da estimação de uma matriz de covariâncias deve considerar, de forma conjunta:

- tamanho amostral e dimensão;
- posto;
- autovalores;
- número de condição;
- estabilidade da inversa;
- sensibilidade a observações;
- coerência das unidades;
- necessidade de regularização;
- objetivo da utilização posterior da matriz.

O exemplo seguinte reúne a estimação da média, da covariância, das correlações e das covariâncias cruzadas em uma única amostra, preservando a distinção entre parâmetros, estimadores e estimativas.

10.8 Exemplo integrado

O exemplo reúne a estimação da localização, da dispersão e das relações entre dois blocos de variáveis. Os cálculos são apresentados para uma amostra observada; portanto, os resultados são estimativas, representadas por letras em negrito sem fonte de aleatoriedade.

Exemplo 10.1 (Estimação em dois blocos de variáveis). Considere seis unidades amostrais nas quais foram observados dois blocos de variáveis. O primeiro bloco contém três variáveis:

$$\mathbf{X} = \begin{bmatrix} 2 & 4 & 1 \\ 3 & 5 & 3 \\ 5 & 6 & 4 \\ 6 & 8 & 6 \\ 4 & 7 & 2 \\ 7 & 9 & 7 \end{bmatrix} \in \mathbb{R}^{6 \times 3}.$$

O segundo bloco contém duas variáveis observadas nas mesmas unidades:

$$\mathbf{Y} = \begin{bmatrix} 1 & 3 \\ 3 & 2 \\ 4 & 5 \\ 5 & 7 \\ 3 & 4 \\ 8 & 6 \end{bmatrix} \in \mathbb{R}^{6 \times 2}.$$

A correspondência entre as linhas de $\mathbf{X}$ e $\mathbf{Y}$ é necessária para estimar as covariâncias cruzadas entre os dois blocos.

Os vetores de médias observados são

$$\bar{\mathbf{x}} = \frac{1}{6} \mathbf{X}^\top \mathbf{1}_6 = \begin{bmatrix} 4.5 \\ 6.5 \\ 3.833 \end{bmatrix}$$

e

$$\bar{\mathbf{y}} = \frac{1}{6} \mathbf{Y}^\top \mathbf{1}_6 = \begin{bmatrix} 4.0 \\ 4.5 \end{bmatrix}.$$

Para o primeiro bloco, a matriz de somas de quadrados e produtos cruzados é

$$\begin{aligned} \mathbf{A}_X &= \mathbf{X}_c^\top \mathbf{X}_c \\ &= \begin{bmatrix} 17.5 & 16.5 & 20.5 \\ 16.5 & 17.5 & 18.5 \\ 20.5 & 18.5 & 26.833 \end{bmatrix}. \end{aligned}$$

A matriz de covariâncias amostral, com divisor $n - 1 = 5$, é

$$\begin{aligned} \mathbf{S}_X &= \frac{1}{5} \mathbf{A}_X \\ &= \begin{bmatrix} 3.500 & 3.300 & 4.100 \\ 3.300 & 3.500 & 3.700 \\ 4.100 & 3.700 & 5.367 \end{bmatrix}. \end{aligned} \tag{10.127}$$

Essa matriz é a estimativa não viesada de Σ_{XX} sob amostragem aleatória e existência de segundos momentos.

Se for adotado o modelo normal multivariado, o estimador de máxima verossimilhança é

$$\begin{aligned} \hat{\Sigma}_{XX, MV} &= \frac{1}{6} \mathbf{A}_X \\ &= \begin{bmatrix} 2.917 & 2.750 & 3.417 \\ 2.750 & 2.917 & 3.083 \\ 3.417 & 3.083 & 4.472 \end{bmatrix}. \end{aligned} \tag{10.128}$$

Os dois estimadores estão relacionados por

$$\hat{\Sigma}_{XX, MV} = \frac{5}{6} \mathbf{S}_X.$$

Portanto, possuem os mesmos autovetores, o mesmo posto e o mesmo número de condição. Seus autovalores diferem pelo fator $5/6$.

A matriz de correlações do primeiro bloco é

$$\mathbf{R}_X = \begin{bmatrix} 1.000 & 0.943 & 0.946 \\ 0.943 & 1.000 & 0.854 \\ 0.946 & 0.854 & 1.000 \end{bmatrix}. \tag{10.129}$$

As três correlações são positivas e elevadas. A maior associação linear amostral ocorre entre as variáveis X_1 e X_3 :

$$r_{13} \approx 0.946.$$

A menor ocorre entre X_2 e X_3 :

$$r_{23} \approx 0.854.$$

Os autovalores de $\mathbf{S}_X$, em ordem decrescente, são aproximadamente

$$\ell_1 = 11.648, \quad \ell_2 = 0.627 \quad \text{e} \quad \ell_3 = 0.092.$$

Como todos são positivos,

$$\text{posto}(\mathbf{S}_X) = 3,$$

e a matriz é positiva definida.

Seu número de condição espectral é

$$\begin{aligned} \kappa_2(\mathbf{S}_X) &= \frac{\ell_1}{\ell_3} \\ &\approx 126.8. \end{aligned}$$

A matriz é invertível, mas o menor autovalor é muito inferior ao maior. Assim, a amostra apresenta uma direção com variabilidade reduzida e a inversão de $\mathbf{S}_X$ pode ser sensível a pequenas alterações nos dados.

Para estimar as relações entre os dois blocos, utiliza-se

$$\mathbf{S}_{XY} = \frac{1}{5} \mathbf{X}_c^\top \mathbf{Y}_c.$$

O resultado é

$$\mathbf{S}_{XY} = \begin{bmatrix} 4.2 & 3.1 \\ 4.0 & 2.9 \\ 5.2 & 3.5 \end{bmatrix}. \quad (10.130)$$

Por exemplo,

$$s_{X_3Y_1} = 5.2$$

é a covariância amostral entre a terceira variável do primeiro bloco e a primeira variável do segundo bloco.

A mudança da ordem dos blocos produz

$$\mathbf{S}_{YX} = \mathbf{S}_{XY}^\top = \begin{bmatrix} 4.2 & 4.0 & 5.2 \\ 3.1 & 2.9 & 3.5 \end{bmatrix}.$$

A matriz de covariâncias do segundo bloco é

$$\mathbf{S}_Y = \begin{bmatrix} 5.6 & 3.2 \\ 3.2 & 3.5 \end{bmatrix}.$$

Reunindo as cinco variáveis na matriz

$$\mathbf{Z} = [\mathbf{X} \quad \mathbf{Y}] \in \mathbb{R}^{6 \times 5},$$

obtém-se a matriz de covariâncias conjunta

$$\mathbf{S}_Z = \begin{bmatrix} \mathbf{S}_X & \mathbf{S}_{XY} \\ \mathbf{S}_{YX} & \mathbf{S}_Y \end{bmatrix}.$$

Numericamente,

$$\mathbf{S}_Z = \begin{bmatrix} 3.500 & 3.300 & 4.100 & 4.200 & 3.100 \\ 3.300 & 3.500 & 3.700 & 4.000 & 2.900 \\ 4.100 & 3.700 & 5.367 & 5.200 & 3.500 \\ 4.200 & 4.000 & 5.200 & 5.600 & 3.200 \\ 3.100 & 2.900 & 3.500 & 3.200 & 3.500 \end{bmatrix}. \quad (10.131)$$

Como existem seis observações e cinco variáveis,

$$\text{posto}(\mathbf{S}_Z) \leq \min(5, 6 - 1) = 5.$$

Neste exemplo,

$$\text{posto}(\mathbf{S}_Z) = 5.$$

A matriz conjunta é positiva definida, embora esse seja o menor tamanho amostral que permite posto completo para cinco variáveis centralizadas.

O exemplo mostra que:

1. $\bar{\mathbf{x}}$ e $\bar{\mathbf{y}}$ estimam as localizações dos dois blocos;
2. $\mathbf{A}_X$ reúne as somas de quadrados e os produtos cruzados;
3. os divisores $n - 1$ e n produzem estimadores com propriedades diferentes;
4. $\mathbf{R}_X$ remove as escalas marginais das covariâncias;
5. posto completo não garante bom condicionamento;
6. $\mathbf{S}_{XY}$ depende do pareamento entre os blocos;
7. a matriz conjunta reúne dispersões internas e relações cruzadas em uma única estrutura.

A estimação produz, portanto, uma representação integrada da localização e da variabilidade conjunta da amostra. Esses objetos serão utilizados nos capítulos seguintes para construir modelos, formular hipóteses e obter procedimentos de inferência.

10.9 Síntese do capítulo

Uma amostra aleatória multivariada é formada por vetores independentes e com a mesma distribuição:

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} F_\theta.$$

Antes da observação dos dados, esses vetores compõem a matriz aleatória $\mathcal{X}$. Depois da coleta, obtém-se a matriz observada $\mathbf{X}$. Essa distinção permite separar parâmetros populacionais, estatísticas aleatórias, estimadores e estimativas.

A avaliação de um estimador exige a definição do critério empregado. Viés e matriz de covariâncias descrevem, respectivamente, o afastamento sistemático e a variabilidade entre amostras. Sob perda quadrática euclidiana,

$$\text{EQM}(\hat{\theta}) = \text{tr} [\text{Cov}(\hat{\theta})] + \|\text{Bias}(\hat{\theta})\|^2.$$

A consistência descreve o comportamento quando o tamanho amostral aumenta. A eficiência depende de uma ordem matricial ou de uma função de perda. A suficiência trata da informação preservada por uma estatística. A equivariância examina a coerência sob transformações dos dados, enquanto a robustez avalia a estabilidade diante de perturbações e desvios do modelo.

O método dos momentos e a máxima verossimilhança fornecem princípios gerais de estimação. No modelo normal multivariado, quando a SSCP observada possui posto completo,

$$\hat{\mu}_{\text{MV}} = \bar{\mathbf{X}}$$

e

$$\hat{\Sigma}_{\text{MV}} = \frac{1}{n} \mathbf{A}.$$

O vetor de médias amostrais

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

é não viesado para μ e possui matriz de covariâncias

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Ele também é consistente, equivariante sob transformações afins e, para a amostra observada, corresponde ao centroide da nuvem de pontos.

A matriz de somas de quadrados e produtos cruzados é

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^\top.$$

Como

$$E(\mathbf{A}) = (n-1)\Sigma,$$

a matriz

$$\mathbf{S} = \frac{1}{n-1} \mathbf{A}$$

é um estimador não viesado de Σ . O estimador normal de máxima verossimilhança utiliza o divisor n . Ambos são consistentes no regime em que p permanece fixo e os segundos momentos existem.

Para dois blocos de variáveis observados sobre as mesmas unidades,

$$\mathbf{S}_{XY} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{y}_i - \bar{\mathbf{Y}})^\top$$

estima a matriz de covariâncias cruzadas. A construção exige preservar o pareamento entre as linhas dos dois blocos.

Quando todas as variâncias amostrais são positivas, a matriz de correlações é

$$\mathbf{R} = \mathbf{D}_S^{-1/2} \mathbf{S} \mathbf{D}_S^{-1/2}.$$

Ela é simétrica, semidefinida positiva, possui diagonal unitária e tem o mesmo posto de $\mathbf{S}$.

A estrutura de posto satisfaz

$$\text{posto}(\mathbf{S}) \leq \min(p, n - 1).$$

Por isso, a matriz de covariâncias amostral é necessariamente singular quando $p \geq n$. Mesmo quando é invertível, autovalores pequenos podem tornar sua inversa instável.

A regularização modifica o estimador para reduzir variabilidade ou melhorar o condicionamento. Um estimador por contração possui a forma

$$\widehat{\Sigma}_\lambda = (1 - \lambda)\mathbf{S} + \lambda\Gamma.$$

A regularização deve ser distinguida da pseudoinversa. A pseudoinversa opera no suporte amostral e atribui peso zero ao núcleo, enquanto a regularização altera o espectro e pode produzir uma matriz positiva definida. Nenhuma dessas substituições preserva automaticamente as distribuições inferenciais derivadas para a inversa clássica.

Ao término do capítulo, deve-se ser capaz de:

- distinguir parâmetros, estatísticas, estimadores e estimativas;
- avaliar estimadores por viés, variabilidade, erro quadrático médio e consistência;
- diferenciar suficiência, equivariância, invariância da máxima verossimilhança e robustez;
- obter os estimadores da média e da matriz de covariâncias;
- explicar a diferença entre os divisores n e $n - 1$;
- construir covariâncias cruzadas e correlações amostrais;
- determinar as condições de posto e definição positiva;
- reconhecer problemas de mau condicionamento e alta dimensão;
- distinguir pseudoinversa e regularização.

Os estimadores construídos neste capítulo fornecem a base amostral para o modelo linear multivariado. No próximo capítulo, várias variáveis-resposta serão relacionadas simultaneamente a uma matriz de delineamento, e as hipóteses sobre os parâmetros serão expressas por meio de restrições matriciais.

11 Modelo Linear Multivariado e Hipóteses Lineares

O capítulo anterior desenvolveu a estimação do vetor de médias e da matriz de covariâncias a partir de uma amostra aleatória multivariada. Nesse contexto, todas as unidades foram tratadas como provenientes de uma população com o mesmo vetor de médias.

Em muitas aplicações, as médias das respostas podem variar sistematicamente entre unidades em função de tratamentos, grupos, períodos, condições experimentais ou características quantitativas. Cada unidade continua fornecendo um vetor de respostas, mas sua média passa a depender de um conjunto de variáveis explicativas.

O modelo linear multivariado representa essa estrutura por meio de

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

em que:

- $\mathbf{y}$ é a matriz aleatória de respostas;
- $\mathbf{Z}$ é a matriz de delineamento;
- $\mathbf{B}$ é a matriz de parâmetros;
- $\mathcal{E}$ é a matriz aleatória de erros.

O modelo linear multivariado reúne, em uma mesma formulação, a estimação de vetores de médias, a regressão com várias respostas e a construção de hipóteses lineares sobre termos do modelo e combinações das respostas (Renchert; Christensen, 2012). Essa estrutura abrange:

- estimação de um vetor de médias;
- comparação de dois ou mais grupos;
- regressão com várias respostas;
- modelos com fatores e covariáveis;
- contrastes entre parâmetros;
- hipóteses sobre combinações das respostas.

O objetivo deste capítulo é construir essa formulação, obter o estimador da matriz de parâmetros, interpretar valores ajustados e resíduos como projeções, estimar a matriz de covariâncias residual e representar hipóteses lineares em forma matricial.

As distribuições amostrais exatas dos estimadores e das matrizes de somas de quadrados e produtos cruzados serão desenvolvidas no próximo capítulo. Aqui, a ênfase recai sobre a estrutura algébrica, geométrica e estatística do modelo e sobre a construção das quantidades utilizadas posteriormente na inferência.

11.1 Da resposta escalar à resposta vetorial

11.1.1 Respostas múltiplas por unidade

No modelo linear univariado, cada unidade amostral fornece uma única resposta aleatória:

$$Y_i \in \mathbb{R}.$$

Sua média condicional é representada por uma combinação linear dos termos do modelo:

$$E(Y_i | \mathbf{z}_i) = \mathbf{z}_i^\top \beta,$$

em que

$$\mathbf{z}_i \in \mathbb{R}^q$$

contém os valores dos q termos do modelo para a unidade i , e

$$\beta \in \mathbb{R}^q$$

contém os coeficientes correspondentes.

A resposta pode ser escrita como

$$Y_i = \mathbf{z}_i^\top \beta + \varepsilon_i,$$

em que ε_i representa a parcela não explicada pelos termos incluídos no modelo.

No modelo linear multivariado, cada unidade fornece simultaneamente p respostas. O vetor aleatório da unidade i é

$$\mathbf{Y}_i = \begin{bmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{ip} \end{bmatrix} \in \mathbb{R}^p. \quad (11.1)$$

Uma unidade experimental pode, por exemplo, ser descrita por diferentes medidas físicas, químicas, biológicas, sensoriais ou de desempenho. As respostas são observadas conjuntamente e podem apresentar dependência mesmo depois de considerada a influência das variáveis explicativas.

O vetor de médias condicionais é

$$E(\mathbf{Y}_i | \mathbf{z}_i) = \begin{bmatrix} E(Y_{i1} | \mathbf{z}_i) \\ E(Y_{i2} | \mathbf{z}_i) \\ \vdots \\ E(Y_{ip} | \mathbf{z}_i) \end{bmatrix} \in \mathbb{R}^p.$$

As mesmas entradas de $\mathbf{z}_i$ são utilizadas para modelar todas as respostas, mas cada resposta possui seu próprio vetor de coeficientes.

Para a resposta j , defina

$$\beta_j = \begin{bmatrix} \beta_{1j} \\ \beta_{2j} \\ \vdots \\ \beta_{qj} \end{bmatrix} \in \mathbb{R}^q.$$

Sua média condicional é

$$E(Y_{ij} | \mathbf{z}_i) = \mathbf{z}_i^\top \beta_j. \quad (11.2)$$

Os vetores de coeficientes das p respostas são reunidos na matriz

$$\mathbf{B} = \begin{bmatrix} \beta_1 & \beta_2 & \cdots & \beta_p \end{bmatrix} \in \mathbb{R}^{q \times p}. \quad (11.3)$$

Explicitamente,

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1p} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qp} \end{bmatrix}.$$

A coluna j contém os coeficientes da resposta j . A linha h contém os coeficientes associados ao h -ésimo termo do modelo para todas as respostas.

Como

$$\mathbf{B}^\top \in \mathbb{R}^{p \times q},$$

o vetor de médias condicionais da unidade i pode ser escrito como

$$E(\mathbf{Y}_i \mid \mathbf{z}_i) = \mathbf{B}^\top \mathbf{z}_i. \quad (11.4)$$

De forma equivalente,

$$E(\mathbf{Y}_i^\top \mid \mathbf{z}_i) = \mathbf{z}_i^\top \mathbf{B}.$$

Definição 11.1 (Modelo linear multivariado para uma unidade). A resposta vetorial da unidade i é representada por

$$\mathbf{Y}_i = \mathbf{B}^\top \mathbf{z}_i + \varepsilon_i, \quad (11.5)$$

em que

$$\varepsilon_i = \begin{bmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \vdots \\ \varepsilon_{ip} \end{bmatrix} \in \mathbb{R}^p$$

é o vetor aleatório de erros da unidade.

O vetor de erros representa o afastamento da resposta em relação à sua média condicional:

$$\varepsilon_i = \mathbf{Y}_i - E(\mathbf{Y}_i \mid \mathbf{z}_i).$$

As componentes de ε_i podem ser correlacionadas. Essa dependência residual constitui uma das diferenças centrais entre o modelo linear univariado e o multivariado.

11.1.2 Equações por resposta

A equação vetorial em Equação 11.5 reúne p modelos lineares:

$$\begin{aligned} Y_{i1} &= \mathbf{z}_i^\top \beta_1 + \varepsilon_{i1}, \\ Y_{i2} &= \mathbf{z}_i^\top \beta_2 + \varepsilon_{i2}, \\ &\vdots \\ Y_{ip} &= \mathbf{z}_i^\top \beta_p + \varepsilon_{ip}. \end{aligned} \tag{11.6}$$

Cada resposta possui seu próprio vetor de coeficientes, mas todas utilizam a mesma representação $\mathbf{z}_i$ dos termos do modelo.

A escrita por componentes é

$$Y_{ij} = \sum_{h=1}^q z_{ih} \beta_{hj} + \varepsilon_{ij}, \quad i = 1, \dots, n, \quad j = 1, \dots, p. \tag{11.7}$$

O parâmetro β_{hj} descreve a contribuição do termo h para a média da resposta j , segundo a parametrização definida pela matriz de delineamento.

A matriz de covariâncias residuais de uma unidade será denotada por

$$\Sigma = \text{Cov}(\varepsilon_i \mid \mathbf{z}_i) = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}. \tag{11.8}$$

Os elementos diagonais são as variâncias residuais:

$$\text{Var}(\varepsilon_{ij} \mid \mathbf{z}_i) = \sigma_{jj}.$$

Para $j \neq k$, os elementos fora da diagonal são as covariâncias residuais:

$$\text{Cov}(\varepsilon_{ij}, \varepsilon_{ik} \mid \mathbf{z}_i) = \sigma_{jk}.$$

Essas covariâncias medem a associação entre duas respostas da mesma unidade que permanece depois de considerada a parte sistemática representada por $\mathbf{z}_i^\top \mathbf{B}$.

Uma associação marginal entre duas respostas pode decorrer de diferenças sistemáticas explicadas pelos termos do modelo, de dependência residual ou de ambas. O modelo linear multivariado permite representar separadamente essas duas fontes.

11.1.3 Representação matricial

Considere n unidades, p respostas e q termos especificados no modelo.

Definição 11.2 (Matriz aleatória de respostas). A matriz aleatória de respostas é

$$\mathcal{Y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \mathbf{Y}_2^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.9)$$

Seu elemento (i, j) é a resposta aleatória Y_{ij} da unidade i na variável j .

Após a observação dos dados, obtém-se a realização

$$\mathbf{Y} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1p} \\ y_{21} & y_{22} & \cdots & y_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.10)$$

Cada linha de $\mathcal{Y}$ corresponde a uma unidade, enquanto cada coluna corresponde a uma resposta. A coluna aleatória associada à resposta j é

$$\mathbf{y}_j = \begin{bmatrix} Y_{1j} \\ Y_{2j} \\ \vdots \\ Y_{nj} \end{bmatrix} \in \mathbb{R}^n.$$

Os termos do modelo são organizados na matriz de delineamento

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1q} \\ z_{21} & z_{22} & \cdots & z_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ z_{n1} & z_{n2} & \cdots & z_{nq} \end{bmatrix} \in \mathbb{R}^{n \times q}. \quad (11.11)$$

A linha $\mathbf{z}_i^\top$ contém os valores dos termos do modelo para a unidade i . As colunas podem representar:

- intercepto;
- covariáveis quantitativas;
- indicadores de grupos ou tratamentos;
- contrastes codificados;

- interações;
- termos polinomiais;
- combinações de fatores e covariáveis.

Quando o modelo contém intercepto,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

em que $\mathcal{C}(\mathbf{Z})$ é o espaço coluna da matriz de delineamento.

Os vetores de erros são organizados na matriz aleatória

$$\mathcal{E} = \begin{bmatrix} \varepsilon_1^\top \\ \varepsilon_2^\top \\ \vdots \\ \varepsilon_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}. \quad (11.12)$$

Reunindo as equações das n unidades, obtém-se a formulação matricial.

Definição 11.3 (Modelo linear multivariado). O modelo linear multivariado é

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E}, \quad (11.13)$$

com

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p}$$

e

$$\mathcal{E} \in \mathbb{R}^{n \times p}.$$

As dimensões do produto são

$$(n \times q)(q \times p) = n \times p,$$

de modo que $\mathbf{ZB}$ possui a mesma dimensão da matriz de respostas.

A matriz

$$\mathbf{ZB} = \begin{bmatrix} \mathbf{z}_1^\top \mathbf{B} \\ \mathbf{z}_2^\top \mathbf{B} \\ \vdots \\ \mathbf{z}_n^\top \mathbf{B} \end{bmatrix}$$

reúne os vetores de médias condicionais transpostos. Seu elemento (i, j) é

$$[\mathbf{ZB}]_{ij} = \mathbf{z}_i^\top \boldsymbol{\beta}_j.$$

Portanto,

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}$$

quando a matriz de erros possui esperança condicional nula.

A representação matricial mostra duas estruturas simultâneas:

- cada coluna de $\mathcal{Y}$ segue um modelo linear com a mesma matriz de delineamento;
- as respostas de uma mesma linha podem apresentar dependência residual descrita por Σ .

A próxima seção especificará as hipóteses de primeira e segunda ordens, a estrutura vetorizada e a distribuição normal matricial associada ao modelo.

11.2 Estrutura do modelo linear multivariado

A formulação

$$\mathcal{Y} = \mathbf{ZB} + \mathcal{E}$$

separa a resposta em duas parcelas:

$$\underbrace{\mathbf{ZB}}_{\text{estrutura sistemática}} \quad \text{e} \quad \underbrace{\mathcal{E}}_{\text{variação residual}}.$$

A primeira parcela representa os vetores de médias condicionais determinados pelo delineamento e pelos parâmetros. A segunda reúne os afastamentos aleatórios em relação a essas médias. Essa formulação equivale a ajustar, para cada resposta, um modelo linear com a mesma matriz de delineamento, preservando em uma única matriz a estrutura de covariâncias entre as respostas (Rencher; Christensen, 2012).

11.2.1 Matrizes de respostas, delineamento e parâmetros

Considere:

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p}.$$

A matriz aleatória de respostas pode ser representada por suas linhas:

$$\mathbf{y} = \begin{bmatrix} \mathbf{Y}_1^\top \\ \vdots \\ \mathbf{Y}_n^\top \end{bmatrix},$$

ou por suas colunas:

$$\mathbf{y} = \begin{bmatrix} \mathbf{y}_1 & \cdots & \mathbf{y}_p \end{bmatrix}.$$

A linha i contém o vetor de respostas da unidade i :

$$\mathbf{Y}_i \in \mathbb{R}^p.$$

A coluna j contém os valores da resposta j nas n unidades:

$$\mathbf{y}_j \in \mathbb{R}^n.$$

A matriz de delineamento pode ser escrita como

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} = \begin{bmatrix} \mathbf{z}_{\cdot 1} & \cdots & \mathbf{z}_{\cdot q} \end{bmatrix}.$$

Suas linhas representam as unidades, enquanto suas colunas representam os termos do modelo.

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \beta_1 & \cdots & \beta_p \end{bmatrix}.$$

A coluna β_j contém os parâmetros da resposta j . A linha h contém os efeitos do termo h sobre todas as respostas.

A matriz de médias condicionais é

$$\Xi = E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}. \quad (11.14)$$

Seu elemento (i, j) é

$$\xi_{ij} = \mathbf{z}_i^\top \beta_{j\cdot}.$$

A coluna j da matriz de médias é

$$E(\mathbf{y}_j \mid \mathbf{Z}) = \mathbf{Z}\beta_{j\cdot}.$$

A linha i é

$$E(\mathbf{Y}_i^\top \mid \mathbf{Z}) = \mathbf{z}_i^\top \mathbf{B}.$$

O espaço coluna de $\mathbf{Z}$ determina os vetores de médias que podem ser representados para cada resposta. Se

$$r = \text{posto}(\mathbf{Z}), \quad (11.15)$$

então

$$r \leq \min(n, q).$$

Para cada resposta, o vetor de médias pertence ao subespaço

$$\mathcal{C}(\mathbf{Z}) \subseteq \mathbb{R}^n,$$

cuja dimensão é r .

O modelo pode apresentar q colunas em $\mathbf{Z}$, mas somente r direções linearmente independentes no espaço de médias. Essa distinção será utilizada nas seções sobre estimação, graus de liberdade e estimabilidade.

11.2.2 Hipóteses de primeira e segunda ordens

A primeira hipótese especifica a esperança condicional dos erros.

Definição 11.4 (Hipótese de média residual nula). Assume-se que

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0}, \quad i = 1, \dots, n. \quad (11.16)$$

Equivalentemente,

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}_{n \times p}.$$

Essa condição implica

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

A segunda hipótese descreve a variabilidade conjunta das respostas de cada unidade.

Definição 11.5 (Estrutura de covariâncias residuais). Assume-se que

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma, \quad i = 1, \dots, n, \quad (11.17)$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}$$

é simétrica e semidefinida positiva.

Também se assume que

$$\text{Cov}(\varepsilon_i, \varepsilon_k \mid \mathbf{Z}) = \mathbf{0}, \quad i \neq k. \quad (11.18)$$

A matriz Σ é comum às unidades. Seu elemento σ_{jk} satisfaz

$$\sigma_{jk} = \text{Cov}(\varepsilon_{ij}, \varepsilon_{ik} \mid \mathbf{Z}).$$

A diagonal contém as variâncias residuais:

$$\sigma_{jj} = \text{Var}(\varepsilon_{ij} \mid \mathbf{Z}).$$

As entradas fora da diagonal representam a dependência linear entre respostas da mesma unidade que permanece após o ajuste do modelo.

A ausência de covariância entre unidades distintas não implica independência em uma distribuição geral. Sob normalidade conjunta, entretanto, a covariância cruzada nula implica independência.

A estrutura de covariâncias entre todos os elementos da matriz de erros pode ser resumida por

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.19)$$

Essa expressão será derivada após a definição da convenção de vetorização.

11.2.3 Condicionamento na matriz de delineamento

A matriz $\mathbf{Z}$ será tratada como fixa ou como condicionada nos valores observados. Assim, as esperanças e covariâncias serão escritas na forma

$$E(\mathcal{Y} \mid \mathbf{Z})$$

e

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}].$$

Essa formulação abrange duas situações.

Na primeira, os valores de $\mathbf{Z}$ são definidos pelo delineamento do estudo, como ocorre em experimentos com tratamentos previamente determinados.

Na segunda, algumas colunas de $\mathbf{Z}$ correspondem a covariáveis observadas. A análise descreve então a distribuição condicional das respostas, dados os valores dessas covariáveis.

O condicionamento em $\mathbf{Z}$ permite concentrar a formulação na variabilidade das respostas e dos erros. A distribuição marginal conjunta de respostas e covariáveis exigiria um modelo probabilístico adicional para a matriz de delineamento.

A linearidade do modelo refere-se aos parâmetros:

$$E(\mathcal{Y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

As colunas de $\mathbf{Z}$ podem conter transformações conhecidas de variáveis explicativas, como:

$$x, \quad x^2, \quad \log x, \quad xz.$$

O modelo continua linear em $\mathbf{B}$ mesmo quando as entradas de $\mathbf{Z}$ são construídas por funções não lineares das variáveis originais.

A especificação da matriz de delineamento determina:

- o espaço de médias;
- os efeitos representados;
- as funções paramétricas identificáveis;
- os graus de liberdade;
- os modelos reduzidos que podem ser comparados;
- as hipóteses lineares que podem ser formuladas.

Por isso, a interpretação de cada elemento de $\mathbf{B}$ depende da codificação adotada em $\mathbf{Z}$.

11.2.4 Forma vetorizada

A vetorização transforma uma matriz em um vetor empilhando suas colunas.

Definição 11.6 (Vetorização por colunas). Para uma matriz

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_m \end{bmatrix},$$

define-se

$$\text{vec}(\mathbf{A}) = \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_m \end{bmatrix}. \quad (11.20)$$

Como

$$\mathcal{Y} \in \mathbb{R}^{n \times p},$$

tem-se

$$\text{vec}(\mathcal{Y}) \in \mathbb{R}^{np}.$$

A identidade

$$\text{vec}(\mathbf{AXC}) = (\mathbf{C}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$$

fornece

$$\text{vec}(\mathbf{ZB}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}). \quad (11.21)$$

Aplicando a vetorização ao modelo,

$$\text{vec}(\mathcal{Y}) = (\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}) + \text{vec}(\mathcal{E}). \quad (11.22)$$

A forma vetorizada possui a estrutura de um modelo linear para um vetor com np componentes. Sua matriz de delineamento ampliada é

$$\mathbf{I}_p \otimes \mathbf{Z} \in \mathbb{R}^{np \times qp}.$$

O vetor de parâmetros é

$$\text{vec}(\mathbf{B}) \in \mathbb{R}^{qp}.$$

A covariância do erro vetorizado pode ser derivada a partir da estrutura entre linhas e colunas da matriz de erros.

Teorema 11.1 (Covariância do erro vetorizado). *Sob as hipóteses*

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_k \mid \mathbf{Z}) = \mathbf{0} \quad \text{para } i \neq k,$$

tem-se

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.23)$$

Comprovação. A vetorização por colunas organiza inicialmente os n erros da primeira resposta, depois os n erros da segunda resposta e assim sucessivamente.

O bloco (j, k) da matriz de covariâncias vetorizada é

$$\text{Cov}(\varepsilon_{.j}, \varepsilon_{.k} \mid \mathbf{Z}),$$

em que

$$\varepsilon_{.j} = \begin{bmatrix} \varepsilon_{1j} \\ \vdots \\ \varepsilon_{nj} \end{bmatrix}.$$

Como unidades distintas possuem covariância residual nula e a covariância entre as respostas j e k da mesma unidade é σ_{jk} ,

$$\text{Cov}(\varepsilon_{.j}, \varepsilon_{.k} \mid \mathbf{Z}) = \sigma_{jk} \mathbf{I}_n.$$

A matriz completa possui, portanto, o bloco $\sigma_{jk} \mathbf{I}_n$ na posição (j, k) , o que corresponde a

$$\Sigma \otimes \mathbf{I}_n.$$

□

Como $\mathbf{ZB}$ é não aleatória condicionalmente a $\mathbf{Z}$,

$$\text{Cov}[\text{vec}(\mathcal{Y}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n. \quad (11.24)$$

A matriz de covariâncias vetorizada separa duas estruturas:

- Σ descreve a dependência entre respostas da mesma unidade;
- $\mathbf{I}_n$ representa ausência de covariância entre unidades distintas.

11.2.5 Distribuição normal matricial

A distribuição normal matricial representa uma matriz aleatória por meio da distribuição normal de sua vetorização, com uma estrutura de covariâncias separável expressa por um produto de Kronecker (Gupta; Nagar, 1999).

Definição 11.7 (Distribuição normal matricial). Sejam

$$\mathcal{A} \in \mathbb{R}^{n \times p}, \quad \Xi \in \mathbb{R}^{n \times p},$$

$$\mathbf{U} \in \mathbb{R}^{n \times n} \quad \text{e} \quad \mathbf{V} \in \mathbb{R}^{p \times p},$$

com $\mathbf{U}$ e $\mathbf{V}$ simétricas e semidefinidas positivas.

A matriz aleatória $\mathcal{A}$ segue uma distribuição normal matricial com matriz de médias Ξ , fator de covariância entre linhas $\mathbf{U}$ e fator de covariância entre colunas $\mathbf{V}$ quando

$$\text{vec}(\mathcal{A}) \sim N_{np}[\text{vec}(\Xi), \mathbf{V} \otimes \mathbf{U}].$$

Utiliza-se a notação

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V}). \quad (11.25)$$

Quando $\mathbf{U}$ e $\mathbf{V}$ são positivas definidas, a distribuição de $\text{vec}(\mathcal{A})$ é não singular. Se pelo menos uma delas for singular, a distribuição normal matricial é degenerada e não possui densidade em relação à medida de Lebesgue em $\mathbb{R}^{np}$.

Na parametrização normal matricial geral, os fatores $\mathbf{U}$ e $\mathbf{V}$ não possuem escalas separadamente identificáveis, porque apenas o produto de Kronecker $\mathbf{V} \otimes \mathbf{U}$ determina a matriz de covariâncias da vetorização (Gupta; Nagar, 1999). De fato, para qualquer $c > 0$,

$$\mathbf{V} \otimes \mathbf{U} = (c^{-1}\mathbf{V}) \otimes (c\mathbf{U}).$$

No modelo linear multivariado, essa indeterminação não ocorre porque a estrutura entre unidades é fixada em $\mathbf{I}_n$.

Definição 11.8 (Modelo linear normal multivariado). O modelo linear normal multivariado é definido por

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma). \quad (11.26)$$

Consequentemente,

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{Z}\mathbf{B}, \mathbf{I}_n, \Sigma). \quad (11.27)$$

A forma vetorizada equivalente é

$$\text{vec}(\mathbf{y}) \mid \mathbf{Z} \sim N_{np}[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n]. \quad (11.28)$$

A normal matricial implica que as linhas são independentes e possuem distribuições

$$\mathbf{Y}_i \mid \mathbf{z}_i \sim N_p(\mathbf{B}^\top \mathbf{z}_i, \Sigma), \quad i = 1, \dots, n. \quad (11.29)$$

Para a coluna correspondente à resposta j ,

$$\mathbf{y}_j \mid \mathbf{Z} \sim N_n(\mathbf{Z}\beta_j, \sigma_{jj}\mathbf{I}_n). \quad (11.30)$$

Para duas respostas j e k ,

$$\text{Cov}(\mathbf{y}_j, \mathbf{y}_k \mid \mathbf{Z}) = \sigma_{jk}\mathbf{I}_n. \quad (11.31)$$

A densidade condicional da matriz observada $\mathbf{Y}$ é

$$\begin{aligned} f(\mathbf{Y} \mid \mathbf{Z}; \mathbf{B}, \Sigma) &= (2\pi)^{-np/2} |\Sigma|^{-n/2} \\ &\times \exp \left\{ -\frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{Z}\mathbf{B})^\top (\mathbf{Y} - \mathbf{Z}\mathbf{B}) \right] \right\}, \end{aligned} \quad (11.32)$$

quando

$$\Sigma \succ \mathbf{0}.$$

A função log-verossimilhança, desconsiderando constantes que não dependem dos parâmetros, é

$$\begin{aligned} \ell(\mathbf{B}, \Sigma) = & -\frac{n}{2} \log |\Sigma| \\ & -\frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{ZB})^\top (\mathbf{Y} - \mathbf{ZB}) \right]. \end{aligned} \quad (11.33)$$

Essa expressão relaciona a estimação da matriz de parâmetros à minimização de uma forma quadrática matricial dos resíduos.

11.2.6 Transformações das respostas e das unidades

A distribuição normal matricial é preservada por transformações lineares aplicadas às linhas e às colunas.

Teorema 11.2 (Transformação de uma matriz normal). *Se*

$$\mathcal{A} \sim N_{n \times p}(\Xi, \mathbf{U}, \mathbf{V}),$$

e

$$\mathbf{L} \in \mathbb{R}^{m \times n}, \quad \mathbf{R} \in \mathbb{R}^{p \times s},$$

então

$$\mathbf{L}\mathcal{A}\mathbf{R} \sim N_{m \times s}(\mathbf{L}\Xi\mathbf{R}, \mathbf{L}\mathbf{U}\mathbf{L}^\top, \mathbf{R}^\top\mathbf{V}\mathbf{R}). \quad (11.34)$$

Comprovação. Pela identidade da vetorização,

$$\text{vec}(\mathbf{L}\mathcal{A}\mathbf{R}) = (\mathbf{R}^\top \otimes \mathbf{L}) \text{vec}(\mathcal{A}).$$

Como uma transformação linear de um vetor normal permanece normal, a média transformada é

$$(\mathbf{R}^\top \otimes \mathbf{L}) \text{vec}(\Xi) = \text{vec}(\mathbf{L}\Xi\mathbf{R}).$$

A matriz de covariâncias é

$$\begin{aligned} & (\mathbf{R}^\top \otimes \mathbf{L}) (\mathbf{V} \otimes \mathbf{U}) (\mathbf{R} \otimes \mathbf{L}^\top) \\ &= (\mathbf{R}^\top \mathbf{V} \mathbf{R}) \otimes (\mathbf{L} \mathbf{U} \mathbf{L}^\top). \end{aligned}$$

Esse resultado corresponde à distribuição normal matricial indicada. $\square$

No modelo linear multivariado, uma transformação das respostas é obtida por

$$\mathbf{y}^* = \mathbf{y} \mathbf{R},$$

com

$$\mathbf{R} \in \mathbb{R}^{p \times s}.$$

Então,

$$\mathbf{y}^* = \mathbf{Z} (\mathbf{B} \mathbf{R}) + \mathcal{E} \mathbf{R}. \quad (11.35)$$

Sob normalidade,

$$\mathbf{y}^* \mid \mathbf{Z} \sim N_{n \times s} (\mathbf{Z} \mathbf{B} \mathbf{R}, \mathbf{I}_n, \mathbf{R}^\top \Sigma \mathbf{R}). \quad (11.36)$$

Cada coluna de $\mathbf{y}^*$ é uma combinação linear das respostas originais. Essa propriedade será utilizada na formulação de hipóteses sobre médias, diferenças ou contrastes entre respostas.

Uma transformação das unidades é obtida por

$$\mathbf{y}^\dagger = \mathbf{L} \mathbf{y},$$

com

$$\mathbf{L} \in \mathbb{R}^{m \times n}.$$

Nesse caso,

$$\mathbf{y}^\dagger = (\mathbf{L} \mathbf{Z}) \mathbf{B} + \mathbf{L} \mathcal{E}. \quad (11.37)$$

Sob normalidade,

$$y^\dagger \mid \mathbf{Z} \sim N_{m \times p}(\mathbf{LZB}, \mathbf{LL}^\top, \Sigma). \quad (11.38)$$

Em geral,

$$\mathbf{LL}^\top \neq \mathbf{I}_m.$$

Portanto, combinações lineares das unidades podem introduzir covariância entre as novas linhas, mesmo quando as unidades originais são independentes.

Quando $\mathbf{L}$ possui linhas ortonormais,

$$\mathbf{LL}^\top = \mathbf{I}_m,$$

e a estrutura de independência entre as linhas transformadas é preservada sob normalidade.

As transformações à direita atuam sobre o espaço das respostas. As transformações à esquerda atuam sobre o espaço das unidades. Essa distinção será utilizada posteriormente:

- os projetores do modelo atuarão à esquerda;
- as combinações de respostas nas hipóteses lineares atuarão à direita;
- os contrastes sobre os parâmetros atuarão sobre as linhas de $\mathbf{B}$.

11.3 Estimação da matriz de parâmetros

A estimação de $\mathbf{B}$ busca determinar a matriz de coeficientes cuja estrutura sistemática

$$\mathbf{ZB}$$

se aproxima da matriz observada de respostas $\mathbf{Y}$ segundo o critério adotado.

Quando todas as respostas utilizam a mesma matriz de delineamento, a minimização da norma de Frobenius equivale a minimizar separadamente a soma de quadrados residual de cada coluna de $\mathbf{Y}$. A formulação matricial reúne essas estimações e preserva a estrutura necessária para estimar conjuntamente a matriz de covariâncias residual (Rencher; Christensen, 2012).

11.3.1 Critério de mínimos quadrados

Considere uma matriz candidata

$$\mathbf{G} \in \mathbb{R}^{q \times p}.$$

A matriz de resíduos associada a essa candidata é

$$\mathbf{Y} - \mathbf{ZG}.$$

Definição 11.9 (Critério de mínimos quadrados multivariado). O critério de mínimos quadrados é

$$Q(\mathbf{G}) = \|\mathbf{Y} - \mathbf{ZG}\|_F^2. \quad (11.39)$$

Equivalentemente,

$$Q(\mathbf{G}) = \text{tr} [(\mathbf{Y} - \mathbf{ZG})^\top (\mathbf{Y} - \mathbf{ZG})]. \quad (11.40)$$

A norma de Frobenius soma os quadrados de todos os resíduos:

$$Q(\mathbf{G}) = \sum_{j=1}^p \sum_{i=1}^n (y_{ij} - \mathbf{z}_i^\top \mathbf{g}_j)^2,$$

em que $\mathbf{g}_j$ é a coluna j de $\mathbf{G}$.

O critério também pode ser escrito como

$$Q(\mathbf{G}) = \sum_{j=1}^p \|\mathbf{y}_j - \mathbf{Zg}_j\|^2. \quad (11.41)$$

Portanto, minimizar $Q(\mathbf{G})$ equivale a minimizar simultaneamente as somas de quadrados residuais das p respostas.

O critério de mínimos quadrados não utiliza diretamente as covariâncias fora da diagonal de Σ . Mesmo assim, a estrutura multivariada será relevante para:

- a covariância entre as colunas estimadas de $\mathbf{B}$;
- a estimação da matriz de covariâncias residual;
- a construção de hipóteses conjuntas sobre várias respostas;
- a inferência desenvolvida no capítulo seguinte.

11.3.2 Equações normais

Para obter um ponto estacionário, expanda o critério:

$$Q(\mathbf{G}) = \text{tr}(\mathbf{Y}^\top \mathbf{Y}) - 2 \text{tr}(\mathbf{G}^\top \mathbf{Z}^\top \mathbf{Y}) + \text{tr}(\mathbf{G}^\top \mathbf{Z}^\top \mathbf{Z} \mathbf{G}). \quad (11.42)$$

O gradiente matricial em relação a $\mathbf{G}$ é

$$\nabla_{\mathbf{G}} Q(\mathbf{G}) = -2\mathbf{Z}^\top \mathbf{Y} + 2\mathbf{Z}^\top \mathbf{Z} \mathbf{G}.$$

Igualando o gradiente a zero, obtêm-se as equações normais.

Teorema 11.3 (Equações normais do modelo linear multivariado). *Toda solução de mínimos quadrados satisfaz*

$$\mathbf{Z}^\top \widehat{\mathbf{ZB}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.43)$$

Equivalentemente,

$$\mathbf{Z}^\top (\mathbf{Y} - \widehat{\mathbf{ZB}}_{\text{obs}}) = \mathbf{0}_{q \times p}. \quad (11.44)$$

A segunda expressão mostra que cada coluna da matriz de resíduos é ortogonal a todas as colunas da matriz de delineamento.

Se

$$\widehat{\mathbf{U}} = \mathbf{Y} - \widehat{\mathbf{ZB}}_{\text{obs}},$$

então

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Assim, o ajuste e o resíduo são separados pela geometria do espaço coluna de $\mathbf{Z}$.

As equações normais podem possuir:

- uma única solução;
- várias soluções;
- representações diferentes do mesmo vetor ajustado.

A unicidade da matriz de coeficientes depende do posto da matriz de delineamento.

11.3.3 Solução sob posto completo

Suponha que

$$\text{posto}(\mathbf{Z}) = q. \quad (11.45)$$

Nesse caso,

$$q \leq n$$

e

$$\mathbf{Z}^\top \mathbf{Z}$$

é positiva definida e invertível.

Teorema 11.4 (Estimador de mínimos quadrados sob posto completo). *Se*

$$\text{posto}(\mathbf{Z}) = q,$$

a solução única das equações normais é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.46)$$

Para a matriz observada de respostas,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}. \quad (11.47)$$

A coluna j do estimador é

$$\widehat{\beta}_j = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}_j. \quad (11.48)$$

Portanto, cada coluna coincide com o estimador de mínimos quadrados do modelo linear correspondente àquela resposta.

A matriz de coeficientes também pode ser caracterizada por uma decomposição do critério.

Teorema 11.5 (Decomposição do critério de mínimos quadrados). *Sob posto coluna completo, para qualquer*

$$\mathbf{G} \in \mathbb{R}^{q \times p},$$

tem-se

$$\begin{aligned} Q(\mathbf{G}) &= Q(\widehat{\mathbf{B}}_{\text{obs}}) \\ &+ \text{tr} \left[(\mathbf{G} - \widehat{\mathbf{B}}_{\text{obs}})^\top \mathbf{Z}^\top \mathbf{Z} (\mathbf{G} - \widehat{\mathbf{B}}_{\text{obs}}) \right]. \end{aligned} \quad (11.49)$$

Comprovação. Escreva

$$\mathbf{Y} - \mathbf{Z}\mathbf{G} = \widehat{\mathbf{U}} - \mathbf{Z}(\mathbf{G} - \widehat{\mathbf{B}}_{\text{obs}}).$$

A norma quadrática correspondente é

$$\begin{aligned} Q(\mathbf{G}) &= \text{tr}(\widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}) \\ &- 2 \text{tr} \left[(\mathbf{G} - \widehat{\mathbf{B}}_{\text{obs}})^\top \mathbf{Z}^\top \widehat{\mathbf{U}} \right] \\ &+ \text{tr} \left[(\mathbf{G} - \widehat{\mathbf{B}}_{\text{obs}})^\top \mathbf{Z}^\top \mathbf{Z} (\mathbf{G} - \widehat{\mathbf{B}}_{\text{obs}}) \right]. \end{aligned}$$

Pelas equações normais,

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Logo, o termo cruzado é nulo e obtém-se a decomposição.

Como $\mathbf{Z}^\top \mathbf{Z}$ é positiva definida, a segunda parcela é não negativa e se anula somente quando

$$\mathbf{G} = \widehat{\mathbf{B}}_{\text{obs}}.$$

□

A decomposição mostra que a estimativa encontrada é o minimizador global e único do critério.

11.3.4 Relação com máxima verossimilhança

Sob o modelo linear normal multivariado com matriz de covariâncias residual positiva definida, a maximização da verossimilhança em relação à matriz de parâmetros conduz às mesmas equações normais obtidas pelo critério de mínimos quadrados (Anderson, 2003). A log-verossimilhança é

$$\ell(\mathbf{G}, \Sigma) = -\frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{ZG})^\top (\mathbf{Y} - \mathbf{ZG}) \right],$$

desconsiderando constantes.

Para Σ fixa e positiva definida, maximizar a log-verossimilhança em relação a $\mathbf{G}$ equivale a minimizar

$$Q_\Sigma(\mathbf{G}) = \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{ZG})^\top (\mathbf{Y} - \mathbf{ZG}) \right]. \quad (11.50)$$

O gradiente desse critério é

$$\nabla_{\mathbf{G}} Q_\Sigma(\mathbf{G}) = -2\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZG}) \Sigma^{-1}.$$

Como Σ^{-1} é invertível, a condição de primeira ordem é

$$\mathbf{Z}^\top (\mathbf{Y} - \mathbf{ZG}) = \mathbf{0}.$$

Essa é a mesma equação normal obtida pelos mínimos quadrados não ponderados.

Teorema 11.6 (Equivalência na estimação da matriz de parâmetros). *Sob o modelo linear normal multivariado e a condição*

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de máxima verossimilhança de $\mathbf{B}$ coincide com o estimador de mínimos quadrados:

$$\widehat{\mathbf{B}}_{\text{MV}} = \widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}. \quad (11.51)$$

A coincidência ocorre porque todas as respostas utilizam a mesma matriz de delineamento e a covariância entre unidades é proporcional a $\mathbf{I}_n$.

A matriz Σ altera a covariância conjunta dos coeficientes estimados, mas não altera a expressão de $\widehat{\mathbf{B}}$.

Esse resultado não se estende automaticamente a modelos nos quais:

- respostas diferentes possuem delineamentos diferentes;
- as unidades apresentam covariância residual não proporcional à identidade;
- há dados ausentes com padrões distintos entre respostas;
- são impostas restrições adicionais aos parâmetros.

11.3.5 Esperança e matriz de covariâncias

Substituindo o modelo no estimador,

$$\begin{aligned}\widehat{\mathbf{B}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{Z}\mathbf{B} + \mathcal{E}) \\ &= \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}.\end{aligned}\tag{11.52}$$

Essa expressão separa o parâmetro fixo do erro de estimação.

Teorema 11.7 (Esperança e covariância do estimador da matriz de parâmetros). *Sob as hipóteses de primeira e segunda ordens e com*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}.\tag{11.53}$$

Além disso,

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.\tag{11.54}$$

Comprovação. Pela hipótese de média residual nula,

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0}.$$

Aplicando esperança em Equação 11.52,

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B}.$$

Para a covariância, defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Então,

$$\widehat{\mathbf{B}} - \mathbf{B} = \mathbf{A}_Z \mathcal{E}.$$

Pela identidade da vetorização,

$$\text{vec}(\widehat{\mathbf{B}} - \mathbf{B}) = (\mathbf{I}_p \otimes \mathbf{A}_Z) \text{vec}(\mathcal{E}).$$

Assim,

$$\begin{aligned} \text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] &= (\mathbf{I}_p \otimes \mathbf{A}_Z) (\Sigma \otimes \mathbf{I}_n) (\mathbf{I}_p \otimes \mathbf{A}_Z^\top) \\ &= \Sigma \otimes (\mathbf{A}_Z \mathbf{A}_Z^\top). \end{aligned}$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

obtém-se o resultado. □

Para duas respostas j e k ,

$$\text{Cov}(\hat{\beta}_j, \hat{\beta}_k \mid \mathbf{Z}) = \sigma_{jk} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.55)$$

Em particular,

$$\text{Cov}(\hat{\beta}_j \mid \mathbf{Z}) = \sigma_{jj} (\mathbf{Z}^\top \mathbf{Z})^{-1}. \quad (11.56)$$

A matriz

$$(\mathbf{Z}^\top \mathbf{Z})^{-1}$$

descreve a contribuição do delineamento para a variabilidade dos coeficientes. A matriz Σ descreve a contribuição da variabilidade residual e da dependência entre as respostas.

Para vetores

$$\mathbf{c} \in \mathbb{R}^q \quad \text{e} \quad \mathbf{m} \in \mathbb{R}^p,$$

o estimador da combinação escalar

$$\mathbf{c}^\top \mathbf{B} \mathbf{m}$$

é

$$\mathbf{c}^\top \widehat{\mathbf{B}} \mathbf{m}.$$

Sua variância condicional é

$$\text{Var} \left(\mathbf{c}^\top \widehat{\mathbf{B}} \mathbf{m} \mid \mathbf{Z} \right) = \left[\mathbf{c}^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{c} \right] (\mathbf{m}^\top \Sigma \mathbf{m}). \quad (11.57)$$

A expressão separa:

- a informação do delineamento, representada pelo primeiro fator;
- a variabilidade da combinação de respostas, representada pelo segundo.

11.3.6 Modelo contendo somente intercepto

Considere o modelo

$$\mathbf{Y}_i = \mu + \varepsilon_i, \quad i = 1, \dots, n. \quad (11.58)$$

Nesse caso,

$$\mathbf{Z} = \mathbf{1}_n \in \mathbb{R}^{n \times 1}$$

e

$$\mathbf{B} = \mu^\top \in \mathbb{R}^{1 \times p}.$$

Como

$$\mathbf{Z}^\top \mathbf{Z} = n,$$

o estimador é

$$\begin{aligned}\widehat{\mathbf{B}} &= \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} \\ &= \bar{\mathbf{Y}}^\top,\end{aligned}\tag{11.59}$$

em que

$$\bar{\mathbf{Y}} = \frac{1}{n} \sum_{i=1}^n \mathbf{Y}_i.$$

Para a amostra observada,

$$\widehat{\mathbf{B}}_{\text{obs}} = \bar{\mathbf{y}}^\top.$$

Portanto,

$$\bar{\mathbf{Y}}^\top$$

é o estimador de mínimos quadrados da matriz de parâmetros no modelo contendo somente intercepto, enquanto

$$\bar{\mathbf{y}}^\top$$

é sua estimativa observada.

A matriz de covariâncias do vetor aleatório de médias amostrais é

$$\text{Cov}(\bar{\mathbf{Y}}) = \frac{\Sigma}{n},$$

pois

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{n}.$$

Esse caso mostra que a estimação do vetor de médias é uma situação particular da estimação de uma estrutura de médias representada por uma matriz de delineamento.

11.4 Valores ajustados, resíduos e projeções

Os valores ajustados e os resíduos são obtidos pela decomposição ortogonal de cada coluna da matriz de respostas em:

- uma componente pertencente ao espaço coluna de $\mathbf{Z}$;
- uma componente pertencente ao complemento ortogonal desse espaço.

A construção depende de $\mathcal{C}(\mathbf{Z})$, e não da parametrização particular utilizada para representar esse espaço. Por isso, os valores ajustados e os resíduos permanecem únicos mesmo quando a matriz de parâmetros não possui uma estimativa única (Christensen, 2011).

11.4.1 Projetores do modelo e residual

Considere

$$r = \text{posto}(\mathbf{Z}).$$

A projeção ortogonal sobre o espaço coluna de $\mathbf{Z}$ pode ser definida utilizando a pseudoinversa de Moore–Penrose.

Definição 11.10 (Projetores do modelo e residual). O projetor ortogonal sobre o espaço coluna de $\mathbf{Z}$ é

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+. \quad (11.60)$$

O projetor residual é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z. \quad (11.61)$$

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

a pseudoinversa é

$$\mathbf{Z}^+ = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top,$$

e o projetor do modelo assume a forma

$$\mathbf{P}_Z = \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top. \quad (11.62)$$

Os dois projetores possuem dimensão $n \times n$ e atuam à esquerda da matriz de respostas. Assim, eles transformam as colunas de $\mathcal{Y}$ sem combinar respostas diferentes.

Teorema 11.8 (Propriedades dos projetores do modelo). *Os projetores $\mathbf{P}_Z$ e $\mathbf{M}_Z$ satisfazem:*

$$\mathbf{P}_Z^\top = \mathbf{P}_Z, \quad \mathbf{P}_Z^2 = \mathbf{P}_Z,$$

$$\mathbf{M}_Z^\top = \mathbf{M}_Z, \quad \mathbf{M}_Z^2 = \mathbf{M}_Z,$$

e

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{M}_Z \mathbf{P}_Z = \mathbf{0}. \quad (11.63)$$

Além disso,

$$\mathcal{C}(\mathbf{P}_Z) = \mathcal{C}(\mathbf{Z}),$$

$$\mathcal{C}(\mathbf{M}_Z) = \mathcal{N}(\mathbf{Z}^\top) = \mathcal{C}(\mathbf{Z})^\perp,$$

e

$$\mathbf{P}_Z \mathbf{Z} = \mathbf{Z}, \quad \mathbf{M}_Z \mathbf{Z} = \mathbf{0}. \quad (11.64)$$

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\text{posto}(\mathbf{P}_Z) = \text{tr}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r. \quad (11.65)$$

Comprovação. A pseudoinversa satisfaz

$$\mathbf{Z}\mathbf{Z}^+\mathbf{Z} = \mathbf{Z}$$

e

$$(\mathbf{Z}\mathbf{Z}^+)^{\top} = \mathbf{Z}\mathbf{Z}^+.$$

Portanto,

$$\mathbf{P}_Z^{\top} = \mathbf{P}_Z$$

e

$$\begin{aligned}\mathbf{P}_Z^2 &= \mathbf{Z}\mathbf{Z}^+\mathbf{Z}\mathbf{Z}^+ \\ &= \mathbf{Z}\mathbf{Z}^+ \\ &= \mathbf{P}_Z.\end{aligned}$$

Como

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z,$$

a simetria e a idempotência de $\mathbf{M}_Z$ decorrem das propriedades de $\mathbf{P}_Z$.

Também se tem

$$\begin{aligned}\mathbf{P}_Z\mathbf{M}_Z &= \mathbf{P}_Z(\mathbf{I}_n - \mathbf{P}_Z) \\ &= \mathbf{P}_Z - \mathbf{P}_Z^2 \\ &= \mathbf{0}.\end{aligned}$$

A igualdade

$$\mathcal{C}(\mathbf{P}_Z) = \mathcal{C}(\mathbf{Z})$$

decorre do fato de $\mathbf{P}_Z$ ser o projetor ortogonal sobre esse espaço. Seu complemento ortogonal é

$$\mathcal{N}(\mathbf{Z}^{\top}),$$

que corresponde à imagem de $\mathbf{M}_Z$.

Os autovalores de uma matriz simétrica e idempotente são iguais a zero ou um. Por isso, seu traço coincide com seu posto. Como

$$\text{posto}(\mathbf{P}_Z) = r,$$

segue que

$$\text{posto}(\mathbf{M}_Z) = n - r.$$

□

A dimensão r corresponde ao número de direções linearmente independentes do espaço de médias de cada resposta. O número total de funções paramétricas identificáveis em $\mathbf{B}$ é rp , mas o projetor possui traço r porque atua separadamente sobre cada uma das p colunas da matriz de respostas.

Definição 11.11 (Valores ajustados e resíduos). A matriz aleatória de valores ajustados é

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}. \quad (11.66)$$

A matriz aleatória de resíduos é

$$\hat{\mathbf{u}} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{M}_Z \mathbf{y}. \quad (11.67)$$

Para a matriz observada $\mathbf{Y}$, obtêm-se

$$\hat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y} \quad (11.68)$$

e

$$\hat{\mathbf{U}} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{M}_Z \mathbf{Y}. \quad (11.69)$$

Sob posto coluna completo,

$$\hat{\mathbf{y}} = \mathbf{Z} \hat{\mathbf{B}}$$

e

$$\hat{\mathbf{Y}} = \mathbf{Z} \hat{\mathbf{B}}_{\text{obs}}.$$

Quando $\mathbf{Z}$ possui posto deficiente, diferentes soluções das equações normais podem produzir diferentes matrizes de coeficientes, mas todas produzem a mesma matriz ajustada:

$$\mathbf{Z}\widehat{\mathbf{B}}_{\text{obs}} = \mathbf{P}_Z \mathbf{Y}.$$

A unicidade dos valores ajustados decorre da unicidade da projeção ortogonal sobre $\mathcal{C}(\mathbf{Z})$.

11.4.2 Decomposição ortogonal

Como

$$\mathbf{P}_Z + \mathbf{M}_Z = \mathbf{I}_n,$$

a matriz de respostas admite a decomposição

$$\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{u}}. \quad (11.70)$$

Para os dados observados,

$$\mathbf{Y} = \widehat{\mathbf{Y}} + \widehat{\mathbf{U}}. \quad (11.71)$$

Cada coluna de $\mathbf{Y}$ é decomposta em sua projeção sobre $\mathcal{C}(\mathbf{Z})$ e no resíduo pertencente a $\mathcal{C}(\mathbf{Z})^\perp$:

$$\mathbf{y}_j = \hat{\mathbf{y}}_j + \hat{\mathbf{u}}_j, \quad j = 1, \dots, p.$$

As componentes ajustada e residual são ortogonais.

Teorema 11.9 (Ortogonalidade entre valores ajustados e resíduos). *Para a matriz observada,*

$$\widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} = \mathbf{0}_{p \times p}. \quad (11.72)$$

Consequentemente,

$$\|\mathbf{Y}\|_F^2 = \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2. \quad (11.73)$$

Comprovação. Como

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y}$$

e

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y},$$

tem-se

$$\begin{aligned} \widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}} &= \mathbf{Y}^\top \mathbf{P}_Z^\top \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{Y}^\top \mathbf{P}_Z \mathbf{M}_Z \mathbf{Y} \\ &= \mathbf{0}. \end{aligned}$$

Expandindo a norma da soma,

$$\begin{aligned} \|\mathbf{Y}\|_F^2 &= \|\widehat{\mathbf{Y}} + \widehat{\mathbf{U}}\|_F^2 \\ &= \|\widehat{\mathbf{Y}}\|_F^2 + \|\widehat{\mathbf{U}}\|_F^2 + 2 \operatorname{tr}(\widehat{\mathbf{Y}}^\top \widehat{\mathbf{U}}). \end{aligned}$$

O último termo é nulo, o que fornece a decomposição. $\square$

A igualdade da norma de Frobenius considera os produtos internos em relação à origem. Quando o modelo contém intercepto, a decomposição da variação em torno do vetor de médias amostrais será expressa posteriormente por matrizes de somas de quadrados e produtos cruzados.

11.4.3 Ortogonalidade em relação ao delineamento

A matriz de resíduos satisfaz uma condição mais específica que a ortogonalidade em relação aos valores ajustados.

Teorema 11.10 (Ortogonalidade dos resíduos ao delineamento). *A matriz observada de resíduos satisfaz*

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}_{q \times p}. \quad (11.74)$$

Assim, cada coluna de $\widehat{\mathbf{U}}$ pertence a

$$\mathcal{N}(\mathbf{Z}^\top) = \mathcal{C}(\mathbf{Z})^\perp.$$

Comprovação. Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}$$

e

$$\mathbf{Z}^\top \mathbf{M}_Z = \mathbf{0},$$

segue que

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{Z}^\top \mathbf{M}_Z \mathbf{Y} = \mathbf{0}.$$

□

Para a resposta j ,

$$\mathbf{Z}^\top \hat{\mathbf{u}}_j = \mathbf{0}.$$

Isso significa que o vetor residual não possui componente linear nas direções utilizadas para representar a média da resposta.

Quando o modelo contém intercepto,

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}).$$

Nesse caso,

$$\mathbf{1}_n^\top \widehat{\mathbf{U}} = \mathbf{0}^\top, \quad (11.75)$$

e, portanto,

$$\sum_{i=1}^n \hat{u}_{ij} = 0, \quad j = 1, \dots, p.$$

A média dos resíduos observados é zero para cada resposta.

Erros e resíduos

A matriz de erros $\mathcal{E}$ pertence ao modelo probabilístico e não é observada diretamente. Suas linhas representam os afastamentos das respostas em relação às médias populacionais condicionais.

A matriz de resíduos $\widehat{\mathbf{U}}$ é calculada depois da estimação e depende de todas as observações por meio do projetor $\mathbf{M}_Z$. Seus elementos estão sujeitos às restrições

$$\mathbf{Z}^\top \widehat{\mathbf{U}} = \mathbf{0}.$$

Erros de unidades distintas podem ser não correlacionados, enquanto os resíduos correspondentes geralmente apresentam covariâncias diferentes de zero.

11.4.4 Esperança e covariâncias

Os valores ajustados e os resíduos são transformações lineares da matriz de respostas. Suas esperanças e covariâncias decorrem das propriedades dos projetores.

Teorema 11.11 (Momentos dos valores ajustados e dos resíduos). *Sob as hipóteses de primeira e segunda ordens,*

$$E(\widehat{\mathbf{y}} | \mathbf{Z}) = \mathbf{Z}\mathbf{B} \quad (11.76)$$

e

$$E(\widehat{\mathbf{U}} | \mathbf{Z}) = \mathbf{0}. \quad (11.77)$$

As matrizes de covariâncias vetorizadas são

$$\text{Cov}[\text{vec}(\widehat{\mathbf{y}}) | \mathbf{Z}] = \Sigma \otimes \mathbf{P}_Z \quad (11.78)$$

e

$$\text{Cov}[\text{vec}(\widehat{\mathbf{U}}) | \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z. \quad (11.79)$$

Além disso,

$$\text{Cov}[\text{vec}(\widehat{\mathbf{y}}), \text{vec}(\widehat{\mathbf{U}}) | \mathbf{Z}] = \mathbf{0}. \quad (11.80)$$

Comprovação. Como

$$\hat{\mathcal{Y}} = \mathbf{P}_Z \mathcal{Y},$$

tem-se

$$\begin{aligned} E(\hat{\mathcal{Y}} \mid \mathbf{Z}) &= \mathbf{P}_Z E(\mathcal{Y} \mid \mathbf{Z}) \\ &= \mathbf{P}_Z \mathbf{Z} \mathbf{B} \\ &= \mathbf{Z} \mathbf{B}. \end{aligned}$$

De forma semelhante,

$$\begin{aligned} E(\hat{\mathcal{U}} \mid \mathbf{Z}) &= \mathbf{M}_Z \mathbf{Z} \mathbf{B} \\ &= \mathbf{0}. \end{aligned}$$

Pela identidade da vetorização,

$$\text{vec}(\hat{\mathcal{Y}}) = (\mathbf{I}_p \otimes \mathbf{P}_Z) \text{vec}(\mathcal{Y}).$$

Logo,

$$\begin{aligned} &\text{Cov}[\text{vec}(\hat{\mathcal{Y}}) \mid \mathbf{Z}] \\ &= (\mathbf{I}_p \otimes \mathbf{P}_Z) (\Sigma \otimes \mathbf{I}_n) (\mathbf{I}_p \otimes \mathbf{P}_Z) \\ &= \Sigma \otimes \mathbf{P}_Z. \end{aligned}$$

O mesmo argumento fornece

$$\text{Cov}[\text{vec}(\hat{\mathcal{U}}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{M}_Z.$$

A covariância cruzada contém o fator

$$\mathbf{P}_Z \mathbf{M}_Z = \mathbf{0},$$

o que produz a matriz nula. □

Se h_{ik} e m_{ik} são, respectivamente, os elementos (i, k) de $\mathbf{P}_Z$ e $\mathbf{M}_Z$, então

$$\text{Cov}(\widehat{\mathbf{Y}}_i, \widehat{\mathbf{Y}}_k \mid \mathbf{Z}) = h_{ik} \Sigma \quad (11.81)$$

e

$$\text{Cov}(\widehat{\mathbf{U}}_i, \widehat{\mathbf{U}}_k \mid \mathbf{Z}) = m_{ik} \Sigma. \quad (11.82)$$

Para a mesma unidade,

$$\text{Cov}(\widehat{\mathbf{U}}_i \mid \mathbf{Z}) = (1 - h_{ii}) \Sigma, \quad (11.83)$$

pois

$$m_{ii} = 1 - h_{ii}.$$

Para unidades distintas,

$$i \neq k,$$

tem-se

$$m_{ik} = -h_{ik},$$

e, portanto,

$$\text{Cov}(\widehat{\mathbf{U}}_i, \widehat{\mathbf{U}}_k \mid \mathbf{Z}) = -h_{ik} \Sigma. \quad (11.84)$$

O ajuste introduz dependência entre os resíduos mesmo quando os erros das unidades originais não são correlacionados.

Sob o modelo normal matricial, os valores ajustados e os resíduos são conjuntamente normais. A covariância cruzada nula implica, nesse caso, independência entre as duas matrizes. Esse resultado será retomado no desenvolvimento das distribuições amostrais.

11.4.5 Alavancagem

Os elementos diagonais do projetor $\mathbf{P}_Z$ descrevem a participação de cada unidade na determinação de seu próprio valor ajustado.

Definição 11.12 (Alavancagem). A alavancagem da unidade i é

$$h_{ii} = [\mathbf{P}_Z]_{ii}. \quad (11.85)$$

Sob posto coluna completo,

$$h_{ii} = \mathbf{z}_i^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_i. \quad (11.86)$$

As alavancagens satisfazem

$$0 \leq h_{ii} \leq 1$$

e

$$\sum_{i=1}^n h_{ii} = \text{tr}(\mathbf{P}_Z) = r. \quad (11.87)$$

A alavancagem média é

$$\frac{1}{n} \sum_{i=1}^n h_{ii} = \frac{r}{n}.$$

A mesma alavancagem se aplica às p respostas porque o mesmo projetor atua sobre todas as colunas de $\mathcal{Y}$.

A linha ajustada da unidade i pode ser escrita como

$$\hat{\mathbf{Y}}_i^\top = \sum_{k=1}^n h_{ik} \mathbf{Y}_k^\top. \quad (11.88)$$

Assim, o vetor ajustado de uma unidade é uma combinação linear dos vetores de respostas de todas as unidades, com pesos determinados exclusivamente pelo delineamento.

Uma alavancagem elevada indica que $\mathbf{z}_i$ ocupa uma posição incomum no espaço definido pelas variáveis explicativas. Ela não implica, por si só, que a unidade apresente resposta atípica ou grande resíduo.

Como

$$\text{Cov}(\widehat{\mathbf{U}}_i | \mathbf{Z}) = (1 - h_{ii}) \Sigma,$$

unidades com alavancagens diferentes possuem variabilidades residuais diferentes. Essa propriedade motiva a padronização dos resíduos em procedimentos de diagnóstico.

11.4.6 Interpretação geométrica

Cada coluna da matriz de respostas é um vetor em $\mathbb{R}^n$:

$$\mathbf{y}_j = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{nj} \end{bmatrix}.$$

O modelo decompõe esse vetor em

$$\mathbf{y}_j = \mathbf{P}_Z \mathbf{y}_j + \mathbf{M}_Z \mathbf{y}_j.$$

A primeira parcela pertence a $\mathcal{C}(\mathbf{Z})$ e representa a estrutura de médias permitida pelo modelo. A segunda pertence a $\mathcal{C}(\mathbf{Z})^\perp$ e representa a parte da resposta que não pode ser reproduzida por combinações lineares das colunas do delineamento.

O mesmo espaço $\mathcal{C}(\mathbf{Z})$ é utilizado para todas as respostas. As colunas ajustadas podem ocupar posições diferentes dentro desse espaço porque seus vetores de coeficientes são diferentes.

Considere um modelo com intercepto, uma variável explicativa quantitativa e duas respostas:

$$\mathbf{Z} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}.$$

A Figura 11.1 representa, em painéis separados, as duas colunas da matriz de respostas. Os segmentos verticais ligam cada valor observado ao correspondente valor ajustado.

As duas respostas utilizam a mesma matriz de delineamento e o mesmo projetor $\mathbf{P}_Z$. Cada uma, porém, possui seus próprios coeficientes, valores ajustados e resíduos.

Os gráficos separados não representam diretamente a dependência residual entre as duas respostas. Essa dependência será resumida pela matriz de somas de quadrados e produtos cruzados residuais.

No modelo contendo somente intercepto,




Figura 11.1: Valores observados, retas ajustadas e resíduos para duas respostas modeladas pela mesma variável explicativa.

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top = \mathbf{H}_n. \quad (11.89)$$

Os valores ajustados são

$$\widehat{\mathbf{Y}} = \mathbf{1}_n \bar{\mathbf{y}}^\top,$$

de modo que todas as unidades recebem o mesmo vetor ajustado $\bar{\mathbf{y}}$. A matriz residual é

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y},$$

que coincide com a matriz amostral centralizada estudada no capítulo anterior.

A próxima seção utilizará $\widehat{\mathbf{U}}$ para construir a SSCP residual, determinar seus graus de liberdade e estimar a matriz de covariâncias Σ .

11.5 SSCP residual e estimação da covariância

A matriz de resíduos reúne os afastamentos das respostas observadas em relação aos valores ajustados:

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y}.$$

Cada coluna contém os resíduos de uma resposta. Cada linha contém o vetor residual de uma unidade.

As variâncias e covariâncias residuais são estimadas a partir dos produtos cruzados entre essas colunas. A matriz resultante generaliza a SSCP amostral construída no modelo contendo somente intercepto.

11.5.1 Construção da SSCP residual

Definição 11.13 (Matriz de somas de quadrados e produtos cruzados residuais). A SSCP residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}}. \quad (11.90)$$

Como

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{y},$$

e $\mathbf{M}_Z$ é simétrica e idempotente,

$$\mathbf{E}_{\text{res}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}. \quad (11.91)$$

Para a matriz observada de respostas, utiliza-se

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.92)$$

A matriz

$$\mathbf{E} \in \mathbb{R}^{p \times p}$$

é simétrica e semidefinida positiva.

Seu elemento (j, k) é

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}. \quad (11.93)$$

Quando

$$j = k,$$

obtem-se a soma de quadrados residual da resposta j :

$$e_{jj} = \sum_{i=1}^n \hat{u}_{ij}^2.$$

Quando

$$j \neq k,$$

obtem-se o produto cruzado residual entre as respostas j e k :

$$e_{jk} = \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}.$$

A SSCP residual também pode ser escrita em função da matriz aleatória de erros. Como

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E}$$

e

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathcal{E}. \quad (11.94)$$

Consequentemente,

$$\mathbf{E}_{\text{res}} = \mathcal{E}^\top \mathbf{M}_Z \mathcal{E}. \quad (11.95)$$

A matriz não depende diretamente de $\mathbf{B}$. A influência da estimação da estrutura de médias aparece no projetor residual $\mathbf{M}_Z$.

Para qualquer vetor

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{E} \mathbf{a} &= \mathbf{a}^\top \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \mathbf{a} \\ &= \|\widehat{\mathbf{U}} \mathbf{a}\|^2 \\ &\geq 0. \end{aligned} \quad (11.96)$$

A forma quadrática representa a soma de quadrados residual da combinação linear das respostas definida por $\mathbf{a}$.

Se

$$\mathbf{y}_\mathbf{a} = \mathbf{Y} \mathbf{a},$$

então

$$\hat{\mathbf{u}}_\mathbf{a} = \mathbf{M}_Z \mathbf{Y} \mathbf{a} = \widehat{\mathbf{U}} \mathbf{a},$$

e

$$\hat{\mathbf{u}}_\mathbf{a}^\top \hat{\mathbf{u}}_\mathbf{a} = \mathbf{a}^\top \mathbf{E} \mathbf{a}. \quad (11.97)$$

Assim, a matriz $\mathbf{E}$ reúne as somas de quadrados residuais de todas as combinações lineares das respostas.

Uma transformação linear das respostas também transforma a SSCP residual de maneira compatível. Se

$$\mathbf{Y}^* = \mathbf{Y} \mathbf{R}, \quad \mathbf{R} \in \mathbb{R}^{p \times s},$$

então

$$\widehat{\mathbf{U}}^* = \mathbf{M}_Z \mathbf{Y}^* = \widehat{\mathbf{U}} \mathbf{R},$$

e

$$\mathbf{E}^* = \mathbf{R}^\top \mathbf{E} \mathbf{R}. \quad (11.98)$$

Essa propriedade será utilizada na formulação de hipóteses sobre combinações das respostas.

11.5.2 Esperança e graus de liberdade

O valor esperado da SSCP residual depende do posto do espaço de médias removido pelo ajuste. Como o projetor residual possui posto e traço iguais a $n - r$, a SSCP residual dispõe de $n - r$ graus de liberdade (Rencher; Christensen, 2012).

Considere

$$r = \text{posto}(\mathbf{Z}).$$

Como

$$\text{posto}(\mathbf{M}_Z) = \text{tr}(\mathbf{M}_Z) = n - r,$$

o ajuste deixa

$$n - r$$

direções residuais no espaço das unidades.

Definição 11.14 (Graus de liberdade residuais). Os graus de liberdade residuais do modelo são

$$\nu_E = n - r, \quad (11.99)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e

$$\nu_E = n - q.$$

A utilização do posto, em vez do número de colunas da matriz de delineamento, permite incluir parametrizações redundantes.

Teorema 11.12 (Esperança da SSCP residual). *Sob as hipóteses*

$$E(\mathcal{E} \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma$$

e

$$\text{Cov}(\varepsilon_i, \varepsilon_k \mid \mathbf{Z}) = \mathbf{0} \quad \text{para } i \neq k,$$

tem-se

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \quad (11.100)$$

Comprovação. Considere os elementos (j, k) da SSCP residual:

$$[\mathbf{E}_{\text{res}}]_{jk} = \varepsilon_{\cdot j}^{\top} \mathbf{M}_Z \varepsilon_{\cdot k},$$

em que

$$\varepsilon_{\cdot j} = \begin{bmatrix} \varepsilon_{1j} \\ \vdots \\ \varepsilon_{nj} \end{bmatrix}.$$

Expandindo a forma bilinear,

$$\varepsilon_{.j}^\top \mathbf{M}_{Z\varepsilon.k} = \sum_{i=1}^n \sum_{\ell=1}^n m_{i\ell} \varepsilon_{ij} \varepsilon_{\ell k}.$$

Para

$$i \neq \ell,$$

a covariância entre unidades é nula e as médias dos erros são zero. Portanto,

$$E(\varepsilon_{ij} \varepsilon_{\ell k} \mid \mathbf{Z}) = 0.$$

Para

$$i = \ell,$$

tem-se

$$E(\varepsilon_{ij} \varepsilon_{ik} \mid \mathbf{Z}) = \sigma_{jk}.$$

Logo,

$$\begin{aligned} E[\varepsilon_{.j}^\top \mathbf{M}_{Z\varepsilon.k} \mid \mathbf{Z}] &= \sum_{i=1}^n m_{ii} \sigma_{jk} \\ &= \text{tr}(\mathbf{M}_Z) \sigma_{jk} \\ &= (n - r) \sigma_{jk}. \end{aligned}$$

Como o resultado vale para todos os elementos,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r) \Sigma.$$

□

A redução de n para $n - r$ decorre da estimação da estrutura de médias. O projetor residual elimina r direções do espaço das unidades e preserva $n - r$ direções ortogonais ao modelo.

Essa interpretação generaliza a perda de um grau de liberdade produzida pela estimação do vetor de médias no modelo contendo somente intercepto.

11.5.3 Estimador não viesado

Como o valor esperado da SSCP residual é $(n - r)\Sigma$, sua divisão pelos graus de liberdade residuais produz um estimador não viesado da matriz de covariâncias residual (Rencher; Christensen, 2012).

Definição 11.15 (Estimador não viesado da matriz de covariâncias residual). Se

$$n - r > 0,$$

define-se

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}. \quad (11.101)$$

Para a amostra observada,

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}. \quad (11.102)$$

Pela linearidade da esperança,

$$E(\widehat{\Sigma} \mid \mathbf{Z}) = \Sigma. \quad (11.103)$$

Os elementos do estimador são

$$\hat{\sigma}_{jk} = \frac{e_{jk}}{n - r}.$$

Em particular,

$$\hat{\sigma}_{jj} = \frac{1}{n - r} \sum_{i=1}^n \hat{u}_{ij}^2$$

é o estimador não viesado da variância residual da resposta j .

Para

$$j \neq k,$$

a quantidade

$$\hat{\sigma}_{jk} = \frac{1}{n-r} \sum_{i=1}^n \hat{u}_{ij} \hat{u}_{ik}$$

estima a covariância residual entre as respostas j e k .

A matriz de correlações residuais estimada pode ser construída por

$$\widehat{\mathbf{R}}_{\text{res}} = \widehat{\mathbf{D}}_{\Sigma}^{-1/2} \widehat{\Sigma}_{\text{obs}} \widehat{\mathbf{D}}_{\Sigma}^{-1/2}, \quad (11.104)$$

em que

$$\widehat{\mathbf{D}}_{\Sigma} = \text{diag}(\hat{\sigma}_{11}, \dots, \hat{\sigma}_{pp}).$$

Como a multiplicação da matriz de covariâncias por um escalar positivo não altera suas correlações, a mesma matriz de correlações é obtida diretamente a partir de $\mathbf{E}$:

$$\widehat{\mathbf{R}}_{\text{res}} = \mathbf{D}_E^{-1/2} \mathbf{E} \mathbf{D}_E^{-1/2},$$

quando todos os elementos diagonais de $\mathbf{E}$ são positivos.

Covariância marginal e covariância residual

A matriz de covariâncias calculada diretamente a partir das respostas mede a variabilidade total observada.

A matriz

$$\widehat{\Sigma}_{\text{obs}}$$

mede a variabilidade que permanece depois de ajustada a estrutura de médias definida por $\mathbf{Z}$.

As duas matrizes coincidem somente em situações particulares, como no modelo contendo apenas intercepto.

11.5.4 Estimador de máxima verossimilhança

Sob o modelo normal matricial, a maximização conjunta da verossimilhança produz a SSCP residual dividida por n como estimativa de máxima verossimilhança de Σ , desde que a SSCP residual observada seja positiva definida (Anderson, 2003). A função log-verossimilhança é

$$\begin{aligned}\ell(\mathbf{B}, \Sigma) = & -\frac{n}{2} \log |\Sigma| \\ & -\frac{1}{2} \text{tr} \left[\Sigma^{-1} (\mathbf{Y} - \mathbf{ZB})^\top (\mathbf{Y} - \mathbf{ZB}) \right],\end{aligned}$$

desconsiderando constantes.

Depois de maximizar em relação a $\mathbf{B}$, a log-verossimilhança concentrada é

$$\ell_c(\Sigma) = -\frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{E}). \quad (11.105)$$

Se

$$\mathbf{E} \succ \mathbf{0},$$

a maximização produz

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}. \quad (11.106)$$

A regra de estimação correspondente é

$$\widehat{\Sigma}_{\text{MV}} = \frac{\mathbf{E}_{\text{res}}}{n}. \quad (11.107)$$

Teorema 11.13 (Relação entre os estimadores da covariância residual). *Os estimadores com divisores $n - r$ e n satisfazem*

$$\widehat{\Sigma}_{\text{MV}} = \frac{n - r}{n} \widehat{\Sigma}. \quad (11.108)$$

Além disso,

$$E(\widehat{\Sigma}_{\text{MV}} \mid \mathbf{Z}) = \frac{n - r}{n} \Sigma, \quad (11.109)$$

e seu viés é

$$\text{Bias}(\widehat{\Sigma}_{\text{MV}} \mid \mathbf{Z}) = -\frac{r}{n} \Sigma. \quad (11.110)$$

O divisor n decorre da maximização da verossimilhança. O divisor $n - r$ corrige o efeito da estimação da estrutura de médias e produz ausência de viés.

Os dois estimadores são múltiplos escalares positivos da mesma SSCP residual. Portanto, possuem:

- os mesmos autovetores;
- o mesmo posto;
- o mesmo número de condição;
- a mesma matriz de correlações;
- as mesmas direções principais de dispersão residual.

A diferença está na escala dos autovalores e das variâncias estimadas.

Existência do máximo de verossimilhança

Depois da maximização em relação à estrutura de médias, a estimativa

$$\hat{\Sigma}_{MV,obs} = \frac{\mathbf{E}}{n}$$

é o máximo de verossimilhança no espaço paramétrico

$$\Sigma \succ \mathbf{0}$$

se, e somente se,

$$\mathbf{E} \succ \mathbf{0}.$$

Como

$$\mathbf{E} = \hat{\mathbf{U}}^\top \hat{\mathbf{U}},$$

essa condição equivale a

$$\text{posto}(\hat{\mathbf{U}}) = p.$$

Como a matriz residual possui no máximo $n - r$ linhas linearmente independentes,

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r).$$

Portanto, uma condição necessária para a existência do máximo é

$$n - r \geq p.$$

Sob o modelo normal matricial com

$$\Sigma \succ \mathbf{0},$$

se

$$n - r \geq p,$$

então

$$\mathbf{E} \succ \mathbf{0}$$

com probabilidade 1. Se

$$n - r < p,$$

a matriz $\mathbf{E}$ é singular para qualquer conjunto de dados.

Quando $\mathbf{E}$ é singular, a log-verossimilhança é ilimitada à medida que Σ se aproxima da fronteira do cone positivo definido nas direções pertencentes ao núcleo de $\mathbf{E}$. Nesse caso, não existe estimador de máxima verossimilhança no modelo normal matricial não singular.

A matriz

$$\frac{\mathbf{E}}{n}$$

continua sendo calculável e semidefinida positiva, mas não constitui uma estimativa de máxima verossimilhança no espaço

$$\Sigma \succ \mathbf{0}.$$

11.5.5 Posto e singularidade

Como

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}},$$

tem-se

$$\text{posto}(\mathbf{E}) = \text{posto}(\widehat{\mathbf{U}}).$$

A matriz residual satisfaz

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y},$$

e, portanto,

$$\text{posto}(\widehat{\mathbf{U}}) \leq \min[\text{posto}(\mathbf{M}_Z), p].$$

Como

$$\text{posto}(\mathbf{M}_Z) = n - r,$$

obtém-se o limite fundamental.

Teorema 11.14 (Posto da SSCP residual). *A SSCP residual satisfaz*

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.111)$$

Consequentemente, se

$$p > n - r,$$

a matriz $\mathbf{E}$ é necessariamente singular.

Nesse caso, tanto

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}$$

quanto

$$\frac{\mathbf{E}}{n}$$

são singulares.

Uma condição necessária para obter uma estimativa positiva definida é

$$n - r \geq p. \quad (11.112)$$

Essa desigualdade não garante definição positiva em uma amostra arbitrária. Também é necessário que a matriz de resíduos apresente posto coluna completo:

$$\text{posto}(\widehat{\mathbf{U}}) = p.$$

Sob o modelo normal matricial com

$$\Sigma \succ \mathbf{0},$$

tem-se, com probabilidade 1,

$$\text{posto}(\mathbf{E}) = \min(p, n - r). \quad (11.113)$$

Assim, sob normalidade não singular,

$$\mathbf{E} \succ \mathbf{0}$$

com probabilidade 1 quando

$$n - r \geq p.$$

A existência de posto completo não garante estabilidade numérica. Se o menor autovalor de $\mathbf{E}$ for positivo, mas muito pequeno, a matriz de covariâncias estimada pode ser mal condicionada.

A inversão de

$$\widehat{\Sigma}_{\text{obs}}$$

deve considerar:

- o número de graus de liberdade residuais;
- a dimensão p ;
- a presença de respostas quase linearmente dependentes;
- a magnitude dos menores autovalores;
- o número de condição.

Quando a matriz é singular ou instável, podem ser utilizadas pseudoinversas ou estimadores regularizados. Essas alternativas modificam o procedimento estatístico e exigem formulações inferenciais próprias.

11.5.6 Modelo contendo somente intercepto

Considere

$$\mathbf{Z} = \mathbf{1}_n.$$

Nesse caso,

$$r = 1,$$

$$\mathbf{P}_Z = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top$$

e

$$\mathbf{M}_Z = \mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

A matriz de resíduos observada é

$$\widehat{\mathbf{U}} = \mathbf{H}_n \mathbf{Y} = \begin{bmatrix} (\mathbf{y}_1 - \bar{\mathbf{y}})^\top \\ \vdots \\ (\mathbf{y}_n - \bar{\mathbf{y}})^\top \end{bmatrix}.$$

A SSCP residual é

$$\begin{aligned} \mathbf{E} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\ &= \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \end{aligned} \tag{11.114}$$

Essa é a SSCP amostral desenvolvida no capítulo anterior.

Como

$$n - r = n - 1,$$

o estimador não viesado é

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - 1} = \mathbf{S}. \tag{11.115}$$

Sob normalidade e quando $\mathbf{E}$ possui posto completo, o estimador de máxima verossimilhança é

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}.$$

Portanto, o modelo contendo somente intercepto recupera simultaneamente:

- o vetor de médias amostrais como estimador da matriz de parâmetros;
- a centralização amostral como projeção residual;
- a SSCP amostral como SSCP residual;
- a matriz de covariâncias amostral como estimador não viesado de Σ .

O modelo linear multivariado amplia esses resultados ao substituir a média comum por uma estrutura de médias pertencente ao espaço coluna de uma matriz de delineamento.

11.6 Decomposição da variação multivariada

Quando o modelo contém intercepto, a matriz de respostas pode ser decomposta em três níveis:

- afastamentos das observações em relação ao vetor de médias amostrais;
- afastamentos dos valores ajustados em relação ao vetor de médias amostrais;
- afastamentos das observações em relação aos valores ajustados.

Essa decomposição generaliza a identidade entre variação total, variação explicada e variação residual do modelo linear univariado. No caso multivariado, cada parcela é representada por uma matriz de somas de quadrados e produtos cruzados.

11.6.1 SSCP total

Considere a matriz de centralização

$$\mathbf{H}_n = \mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top.$$

O vetor de médias amostrais das respostas é

$$\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}^\top \mathbf{1}_n \in \mathbb{R}^p.$$

A matriz de respostas centralizada é

$$\mathbf{Y}_c = \mathbf{H}_n \mathbf{Y} = \mathbf{Y} - \mathbf{1}_n \bar{\mathbf{y}}^\top. \quad (11.116)$$

Definição 11.16 (SSCP total corrigida). A matriz de somas de quadrados e produtos cruzados total, corrigida em relação ao vetor de médias amostrais, é

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y}. \quad (11.117)$$

Equivalentemente,

$$\mathbf{T} = \mathbf{Y}_c^\top \mathbf{Y}_c$$

ou

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top. \quad (11.118)$$

A matriz

$$\mathbf{T} \in \mathbb{R}^{p \times p}$$

é simétrica e semidefinida positiva.

Seu elemento (j, k) é

$$t_{jk} = \sum_{i=1}^n (y_{ij} - \bar{y}_j) (y_{ik} - \bar{y}_k).$$

Os elementos diagonais são as somas de quadrados totais das respostas. Os elementos fora da diagonal são os produtos cruzados totais.

A matriz de covariâncias amostral das respostas é

$$\mathbf{S}_Y = \frac{\mathbf{T}}{n-1}.$$

A SSCP total representa a variabilidade observada antes de descontar os efeitos descritos pela matriz de delineamento.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \sum_{i=1}^n [\mathbf{a}^\top (\mathbf{y}_i - \bar{\mathbf{y}})]^2. \quad (11.119)$$

Essa forma quadrática é a soma de quadrados total da combinação linear

$$\mathbf{Y} \mathbf{a}.$$

11.6.2 SSCP explicada pelo modelo

Suponha que o modelo contenha intercepto:

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}). \quad (11.120)$$

O projetor sobre o espaço das constantes é

$$\mathbf{P}_1 = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top. \quad (11.121)$$

Como

$$\mathcal{C}(\mathbf{1}_n) \subseteq \mathcal{C}(\mathbf{Z}),$$

tem-se

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1. \quad (11.122)$$

A matriz

$$\mathbf{P}_Z - \mathbf{P}_1$$

é o projetor ortogonal sobre a parte do espaço do modelo que é ortogonal ao vetor constante.

Teorema 11.15 (Projetor do modelo além do intercepto). *Quando*

$$\mathbf{1}_n \in \mathcal{C}(\mathbf{Z}),$$

a matriz

$$\mathbf{P}_Z - \mathbf{P}_1$$

é simétrica e idempotente.

Sua imagem é

$$\mathcal{C}(\mathbf{Z}) \cap \mathcal{C}(\mathbf{1}_n)^\perp,$$

e seu posto é

$$\text{posto}(\mathbf{P}_Z - \mathbf{P}_1) = r - 1, \quad (11.123)$$

em que

$$r = \text{posto}(\mathbf{Z}).$$

Comprovação. A simetria decorre da simetria de $\mathbf{P}_Z$ e $\mathbf{P}_1$.

Utilizando

$$\mathbf{P}_Z \mathbf{P}_1 = \mathbf{P}_1 \mathbf{P}_Z = \mathbf{P}_1,$$

obtém-se

$$\begin{aligned} (\mathbf{P}_Z - \mathbf{P}_1)^2 &= \mathbf{P}_Z^2 - \mathbf{P}_Z \mathbf{P}_1 - \mathbf{P}_1 \mathbf{P}_Z + \mathbf{P}_1^2 \\ &= \mathbf{P}_Z - \mathbf{P}_1 - \mathbf{P}_1 + \mathbf{P}_1 \\ &= \mathbf{P}_Z - \mathbf{P}_1. \end{aligned}$$

Portanto, a matriz é um projetor ortogonal.

Como o espaço das constantes possui dimensão 1 e está contido em $\mathcal{C}(\mathbf{Z})$, a dimensão da parcela ortogonal ao intercepto é

$$r - 1.$$

□

Definição 11.17 (SSCP explicada pelo modelo). Quando o modelo contém intercepto, a SSCP explicada pelos termos além da média geral é

$$\mathbf{H}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \quad (11.124)$$

A notação $\mathbf{H}_{\text{mod}}$ diferencia essa matriz da SSCP associada a uma hipótese linear específica, que será denotada posteriormente por $\mathbf{H}$.

A matriz explicada também pode ser escrita como

$$\mathbf{H}_{\text{mod}} = \widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c, \quad (11.125)$$

em que

$$\widehat{\mathbf{Y}}_c = \widehat{\mathbf{Y}} - \mathbf{1}_n \bar{\mathbf{y}}^\top.$$

De fato,

$$\begin{aligned} \widehat{\mathbf{Y}}_c &= \mathbf{P}_Z \mathbf{Y} - \mathbf{P}_1 \mathbf{Y} \\ &= (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}. \end{aligned}$$

Como $\mathbf{P}_Z - \mathbf{P}_1$ é simétrica e idempotente,

$$\widehat{\mathbf{Y}}_c^\top \widehat{\mathbf{Y}}_c = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

O elemento (j, k) de $\mathbf{H}_{\text{mod}}$ mede o produto cruzado entre os valores ajustados centralizados das respostas j e k .

Para qualquer $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{H}_{\text{mod}} \mathbf{a} = \|(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} \mathbf{a}\|^2. \quad (11.126)$$

Essa é a soma de quadrados explicada pelo modelo para a combinação linear das respostas definida por $\mathbf{a}$.

11.6.3 Decomposição fundamental

Quando o modelo contém intercepto,

$$\mathbf{H}_n = \mathbf{I}_n - \mathbf{P}_1.$$

Como

$$\mathbf{I}_n = \mathbf{P}_Z + \mathbf{M}_Z,$$

tem-se

$$\begin{aligned}\mathbf{H}_n &= \mathbf{P}_Z + \mathbf{M}_Z - \mathbf{P}_1 \\ &= (\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z.\end{aligned}\tag{11.127}$$

As duas parcelas são projetores ortogonais, pois

$$(\mathbf{P}_Z - \mathbf{P}_1) \mathbf{M}_Z = \mathbf{0}.$$

Essa identidade produz a decomposição das matrizes de somas de quadrados e produtos cruzados.

Teorema 11.16 (Decomposição da SSCP total). *Quando o modelo contém intercepto,*

$$\mathbf{T} = \mathbf{H}_{\text{mod}} + \mathbf{E},\tag{11.128}$$

em que

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

$$\mathbf{H}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Comprovação. Substituindo a decomposição do projetor de centralização,

$$\begin{aligned}
\mathbf{T} &= \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y} \\
&= \mathbf{Y}^\top [(\mathbf{P}_Z - \mathbf{P}_1) + \mathbf{M}_Z] \mathbf{Y} \\
&= \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y} \\
&= \mathbf{H}_{\text{mod}} + \mathbf{E}.
\end{aligned}$$

□

As três matrizes são simétricas e semidefinidas positivas.

A decomposição também pode ser escrita diretamente a partir dos vetores observados:

$$\begin{aligned}
&\sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top \\
&= \sum_{i=1}^n (\hat{\mathbf{y}}_i - \bar{\mathbf{y}}) (\hat{\mathbf{y}}_i - \bar{\mathbf{y}})^\top \\
&\quad + \sum_{i=1}^n (\mathbf{y}_i - \hat{\mathbf{y}}_i) (\mathbf{y}_i - \hat{\mathbf{y}}_i)^\top.
\end{aligned} \tag{11.129}$$

O termo cruzado desaparece porque os ajustes centralizados e os resíduos pertencem a subespaços ortogonais.

A decomposição dos postos dos projetores fornece a decomposição dos graus de liberdade:

$$n - 1 = (r - 1) + (n - r). \tag{11.130}$$

As parcelas correspondem a:

Fonte	Projetor	Graus de liberdade
Total corrigido	$\mathbf{H}_n$	$n - 1$
Modelo além do intercepto	$\mathbf{P}_Z - \mathbf{P}_1$	$r - 1$
Residual	$\mathbf{M}_Z$	$n - r$

Os graus de liberdade descrevem dimensões dos subespaços no espaço das unidades. Eles não devem ser confundidos com o posto das matrizes $\mathbf{T}$, $\mathbf{H}_{\text{mod}}$ e $\mathbf{E}$, que também depende do número de respostas.

Os postos satisfazem

$$\text{posto}(\mathbf{T}) \leq \min(p, n - 1),$$

$$\text{posto}(\mathbf{H}_{\text{mod}}) \leq \min(p, r - 1)$$

e

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r). \quad (11.131)$$

11.6.4 Combinações lineares das respostas

A decomposição matricial contém simultaneamente a decomposição univariada de todas as combinações lineares das respostas.

Para

$$\mathbf{a} \in \mathbb{R}^p,$$

defina

$$\mathbf{y}_{\mathbf{a}} = \mathbf{Y}\mathbf{a} \in \mathbb{R}^n.$$

A média amostral da combinação é

$$\bar{y}_{\mathbf{a}} = \bar{\mathbf{y}}^{\top} \mathbf{a}.$$

A soma de quadrados total é

$$\text{SQ}_T(\mathbf{a}) = \mathbf{a}^{\top} \mathbf{T} \mathbf{a}.$$

A soma de quadrados explicada é

$$\text{SQ}_H(\mathbf{a}) = \mathbf{a}^{\top} \mathbf{H}_{\text{mod}} \mathbf{a}.$$

A soma de quadrados residual é

$$\text{SQ}_E(\mathbf{a}) = \mathbf{a}^{\top} \mathbf{E} \mathbf{a}.$$

Pela decomposição matricial,

$$\text{SQ}_T(\mathbf{a}) = \text{SQ}_H(\mathbf{a}) + \text{SQ}_E(\mathbf{a}) \quad (11.132)$$

para toda combinação linear $\mathbf{a}$.

Essa propriedade mostra que a identidade

$$\mathbf{T} = \mathbf{H}_{\text{mod}} + \mathbf{E}$$

não resume apenas as respostas originais. Ela representa todas as projeções univariadas do vetor de respostas.

Uma direção $\mathbf{a}$ pode apresentar grande variação explicada mesmo quando outras direções apresentam pouca separação entre ajustes e resíduos. Os procedimentos inferenciais multivariados examinarão conjuntamente o comportamento dessas formas quadráticas.

Quando

$$\mathbf{E} \succ \mathbf{0},$$

a razão

$$\frac{\mathbf{a}^\top \mathbf{H}_{\text{mod}} \mathbf{a}}{\mathbf{a}^\top \mathbf{E} \mathbf{a}} \quad (11.133)$$

compara a variação explicada à variação residual na direção $\mathbf{a}$.

A maximização dessa razão conduz ao problema de autovalores generalizados

$$\mathbf{H}_{\text{mod}} \mathbf{a} = \lambda \mathbf{E} \mathbf{a}. \quad (11.134)$$

Essa relação será utilizada posteriormente na formulação da MANOVA e da análise discriminante. Neste capítulo, ela apenas evidencia como as matrizes explicada e residual definem direções de maior separação relativa.

11.6.5 Modelos sem intercepto

Quando

$$\mathbf{1}_n \notin \mathcal{C}(\mathbf{Z}),$$

o projetor $\mathbf{P}_1$ não está contido no espaço do modelo. Nesse caso,

$$\mathbf{P}_Z - \mathbf{P}_1$$

não é necessariamente um projetor e a decomposição

$$\mathbf{T} = \mathbf{H}_{\text{mod}} + \mathbf{E}$$

não se aplica na forma anterior.

Permanece válida a decomposição em relação à origem:

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y} + \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}. \quad (11.135)$$

Define-se, nesse contexto, a SSCP do modelo calculada em relação à origem:

$$\mathbf{H}_{\text{orig}} = \mathbf{Y}^\top \mathbf{P}_Z \mathbf{Y},$$

enquanto a SSCP residual permanece

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

A matriz $\mathbf{H}_{\text{orig}}$ mede a magnitude dos valores ajustados em relação à origem, e não em relação ao vetor de médias amostrais. Por isso, ela não deve ser interpretada automaticamente como variação explicada em torno da média geral.

Também não se obtém, em geral,

$$n - 1 = (r - 1) + (n - r).$$

A decomposição não corrigida possui

$$n = r + (n - r)$$

graus de liberdade associados aos projetores $\mathbf{I}_n$, $\mathbf{P}_Z$ e $\mathbf{M}_Z$.

Interpretação de modelos sem intercepto

A retirada do intercepto altera:

- o espaço de médias;
- a soma dos resíduos;
- a decomposição da variação;
- os graus de liberdade;
- a interpretação da parcela explicada.

Modelos com e sem intercepto representam problemas estatísticos diferentes. A escolha

não deve ser tratada somente como alteração algébrica da matriz de delineamento.

11.6.6 Modelo de grupos

Considere g grupos mutuamente exclusivos e não vazios. Seja

$$n_h$$

o número de unidades do grupo h , com

$$\sum_{h=1}^g n_h = n.$$

Uma parametrização por médias de grupos utiliza a matriz indicadora

$$\mathbf{Z} = \begin{bmatrix} z_{11} & \cdots & z_{1g} \\ \vdots & \ddots & \vdots \\ z_{n1} & \cdots & z_{ng} \end{bmatrix},$$

em que

$$z_{ih} = \begin{cases} 1, & \text{se a unidade } i \text{ pertence ao grupo } h, \\ 0, & \text{caso contrário.} \end{cases}$$

Como todos os grupos são não vazios,

$$\text{posto}(\mathbf{Z}) = g.$$

Além disso,

$$\mathbf{Z}^\top \mathbf{Z} = \text{diag}(n_1, \dots, n_g).$$

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \vdots \\ \mu_g^\top \end{bmatrix},$$

em que

$$\mu_h \in \mathbb{R}^p$$

é o vetor de médias do grupo h .

O modelo é

$$\mathbf{Y}_i = \mu_{g(i)} + \varepsilon_i, \quad (11.136)$$

em que $g(i)$ identifica o grupo da unidade i .

Para os dados observados, a estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} \bar{\mathbf{y}}_1^\top \\ \vdots \\ \bar{\mathbf{y}}_g^\top \end{bmatrix}, \quad (11.137)$$

em que

$$\bar{\mathbf{y}}_h = \frac{1}{n_h} \sum_{i \in G_h} \mathbf{y}_i$$

é o vetor de médias amostrais do grupo h .

O vetor ajustado da unidade i é a média de seu grupo:

$$\hat{\mathbf{y}}_i = \bar{\mathbf{y}}_{g(i)}.$$

A SSCP residual é

$$\mathbf{E} = \sum_{h=1}^g \sum_{i \in G_h} (\mathbf{y}_i - \bar{\mathbf{y}}_h) (\mathbf{y}_i - \bar{\mathbf{y}}_h)^\top. \quad (11.138)$$

Essa matriz representa a variabilidade dentro dos grupos.

Como

$$\mathbf{1}_n = \mathbf{Z}\mathbf{1}_g,$$

o modelo contém intercepto. A SSCP explicada é

$$\mathbf{H}_{\text{mod}} = \sum_{h=1}^g n_h (\bar{\mathbf{y}}_h - \bar{\mathbf{y}}) (\bar{\mathbf{y}}_h - \bar{\mathbf{y}})^\top. \quad (11.139)$$

Essa matriz representa a variabilidade entre os vetores de médias dos grupos.

A SSCP total é

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})^\top.$$

A decomposição torna-se

$$\mathbf{T} = \mathbf{H}_{\text{mod}} + \mathbf{E}, \quad (11.140)$$

com graus de liberdade

$$n - 1 = (g - 1) + (n - g). \quad (11.141)$$

Essa é a decomposição total, entre grupos e dentro dos grupos desenvolvida anteriormente a partir dos centroides. No modelo linear multivariado, ela surge como consequência da decomposição ortogonal produzida pelos projetores.

Uma parametrização com intercepto e $g - 1$ indicadores também representa o mesmo espaço de médias. Embora os elementos de $\mathbf{B}$ sejam diferentes, permanecem iguais:

- o espaço coluna de $\mathbf{Z}$;
- o projetor $\mathbf{P}_Z$;
- os valores ajustados;
- os resíduos;
- as matrizes $\mathbf{H}_{\text{mod}}$ e $\mathbf{E}$.

Essa invariância em relação à parametrização conduz ao estudo de posto, identificabilidade e funções estimáveis.

11.7 Posto, parametrização e estimabilidade

A expressão

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{y}$$

pressupõe que as colunas da matriz de delineamento sejam linearmente independentes. Essa condição garante a identificação de todos os elementos da matriz de parâmetros.

Em algumas parametrizações, a matriz de delineamento contém colunas redundantes. O modelo ainda pode representar uma estrutura de médias bem definida, mas diferentes matrizes de parâmetros podem produzir a mesma matriz

ZB.

Quando $\mathbf{Z}$ possui posto deficiente, a matriz $\mathbf{B}$ não é identificada de forma única. Permanecem identificados os valores médios ajustados e as funções lineares dos parâmetros que são invariantes entre todas as parametrizações equivalentes (Christensen, 2011).

11.7.1 Delineamento com posto deficiente

Considere

$$\mathbf{Z} \in \mathbb{R}^{n \times q}$$

com

$$r = \text{posto}(\mathbf{Z}) < q. \quad (11.142)$$

Como a nulidade de $\mathbf{Z}$ é

$$\text{nul}(\mathbf{Z}) = q - r,$$

existem vetores não nulos

$$\mathbf{d} \in \mathcal{N}(\mathbf{Z})$$

tais que

$$\mathbf{Z}\mathbf{d} = \mathbf{0}.$$

Considere uma matriz

$$\mathbf{D} \in \mathbb{R}^{q \times p}$$

cujas colunas pertencem ao núcleo de $\mathbf{Z}$. Então,

$$\mathbf{Z}\mathbf{D} = \mathbf{0}_{n \times p}.$$

Consequentemente,

$$\begin{aligned} \mathbf{Z}(\mathbf{B} + \mathbf{D}) &= \mathbf{Z}\mathbf{B} + \mathbf{Z}\mathbf{D} \\ &= \mathbf{Z}\mathbf{B}. \end{aligned} \tag{11.143}$$

Portanto, $\mathbf{B}$ e $\mathbf{B} + \mathbf{D}$ representam a mesma matriz de médias condicionais.

Definição 11.18 (Matrizes de parâmetros equivalentes). Duas matrizes

$$\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{q \times p}$$

são equivalentes em relação à matriz de delineamento $\mathbf{Z}$ quando

$$\mathbf{Z}\mathbf{B}_1 = \mathbf{Z}\mathbf{B}_2. \tag{11.144}$$

Equivalentemente,

$$\mathbf{B}_1 - \mathbf{B}_2$$

possui todas as suas colunas em

$$\mathcal{N}(\mathbf{Z}).$$

A classe de matrizes equivalentes a $\mathbf{B}$ é

$$\{\mathbf{B} + \mathbf{D} : \mathbf{ZD} = \mathbf{0}\}. \quad (11.145)$$

A matriz de parâmetros contém qp elementos. Quando o posto de $\mathbf{Z}$ é r , a matriz de médias possui r direções identificáveis para cada uma das p respostas. Assim, o número de funções paramétricas linearmente independentes identificadas pela estrutura de médias é

$$rp. \quad (11.146)$$

A dimensão da parcela não identificada é

$$(q - r)p. \quad (11.147)$$

A deficiência de posto não significa que o modelo ajustado seja indefinido. Ela significa que a mesma estrutura sistemática admite várias representações paramétricas.

A distinção central é

matriz de parâmetros não única e matriz de médias única.

Os valores ajustados, os resíduos e as SSCP dependem de

$$\mathcal{C}(\mathbf{Z}),$$

e não de uma escolha específica entre matrizes de parâmetros equivalentes.

11.7.2 Soluções das equações normais

As equações normais continuam sendo

$$\mathbf{Z}^\top \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \mathbf{Z}^\top \mathbf{Y}. \quad (11.148)$$

Quando $r < q$, a matriz $\mathbf{Z}^\top \mathbf{Z}$ é singular e as equações possuem infinitas soluções.

A pseudoinversa de Moore–Penrose fornece uma solução particular:

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{Y}. \quad (11.149)$$

Teorema 11.17 (Soluções de mínimos quadrados sob posto deficiente). *Se*

$$\text{posto}(\mathbf{Z}) = r \leq q,$$

todas as soluções de mínimos quadrados podem ser escritas como

$$\widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{Z}^+ \mathbf{Y} + (\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) \mathbf{K}, \quad (11.150)$$

em que

$$\mathbf{K} \in \mathbb{R}^{q \times p}$$

é arbitrária.

Todas essas soluções produzem a mesma matriz ajustada:

$$\mathbf{Z} \widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{Z} \mathbf{Z}^+ \mathbf{Y} = \mathbf{P}_{\mathbf{Z}} \mathbf{Y}. \quad (11.151)$$

Comprovação. A matriz

$$\mathbf{Z}^+ \mathbf{Z}$$

é o projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z}^\top),$$

enquanto

$$\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}$$

é o projetor ortogonal sobre

$$\mathcal{N}(\mathbf{Z}).$$

Portanto,

$$\mathbf{Z}(\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) = \mathbf{0}.$$

Multiplicando a solução geral por $\mathbf{Z}$,

$$\begin{aligned}\mathbf{Z}\widehat{\mathbf{B}}_{\mathbf{K}} &= \mathbf{Z}\mathbf{Z}^+\mathbf{Y} + \mathbf{Z}(\mathbf{I}_q - \mathbf{Z}^+\mathbf{Z})\mathbf{K} \\ &= \mathbf{Z}\mathbf{Z}^+\mathbf{Y}.\end{aligned}$$

Logo, todas as soluções produzem a projeção de $\mathbf{Y}$ sobre $\mathcal{C}(\mathbf{Z})$.

Reciprocamente, duas soluções de mínimos quadrados possuem a mesma matriz ajustada. Sua diferença pertence ao núcleo de $\mathbf{Z}$ e pode ser representada por

$$(\mathbf{I}_q - \mathbf{Z}^+\mathbf{Z})\mathbf{K}$$

para alguma matriz $\mathbf{K}$. □

Entre todas as soluções, a matriz

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+\mathbf{Y}$$

possui a menor norma de Frobenius:

$$\|\widehat{\mathbf{B}}_0\|_F \leq \|\widehat{\mathbf{B}}_{\mathbf{K}}\|_F. \quad (11.152)$$

Essa propriedade seleciona uma solução algébrica específica. Ela não torna os parâmetros individuais identificáveis.

A pseudoinversa escolhe um representante da classe de soluções, enquanto a informação disponível nos dados continua determinada pelo espaço coluna de $\mathbf{Z}$.

Independentemente da solução escolhida, permanecem únicos:

$$\widehat{\mathbf{Y}} = \mathbf{P}_Z \mathbf{Y},$$

$$\widehat{\mathbf{U}} = \mathbf{M}_Z \mathbf{Y},$$

e

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Os graus de liberdade residuais continuam sendo

$$\nu_E = n - r.$$

Assim, o divisor do estimador não viesado da covariância residual é determinado pelo posto efetivo:

$$\widehat{\Sigma}_{\text{obs}} = \frac{\mathbf{E}}{n - r}.$$

11.7.3 Funções estimáveis

Quando $\mathbf{B}$ não é identificada integralmente, a inferência deve ser formulada sobre funções estimáveis, isto é, funções dos parâmetros que permanecem determinadas pela distribuição das respostas e assumem o mesmo valor em todas as parametrizações equivalentes (Christensen, 2011).

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função paramétrica

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina as linhas da matriz de parâmetros.

Definição 11.19 (Função estimável). A função linear

$$\mathbf{CB}$$

é estimável quando existe uma matriz

$$\mathbf{A} \in \mathbb{R}^{n \times g}$$

tal que

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{CB}$$

para toda matriz de parâmetros $\mathbf{B}$.

Como

$$E(\mathbf{A}^\top \mathbf{y} \mid \mathbf{Z}) = \mathbf{A}^\top \mathbf{Z} \mathbf{B},$$

a função é estimável quando

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}. \quad (11.153)$$

Essa igualdade exige que as linhas de $\mathbf{C}$ pertençam ao espaço linha de $\mathbf{Z}$, condição que caracteriza a estimabilidade das funções lineares no modelo (Christensen, 2011).

Teorema 11.18 (Caracterização das funções estimáveis). *Para*

$$\mathbf{C} \in \mathbb{R}^{g \times q},$$

as seguintes condições são equivalentes:

1. $\mathbf{CB}$ é estimável;
2. existe $\mathbf{A} \in \mathbb{R}^{n \times g}$ tal que

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z};$$

3. as linhas de $\mathbf{C}$ pertencem ao espaço linha de $\mathbf{Z}$:

$$\mathcal{C}(\mathbf{C}^\top) \subseteq \mathcal{C}(\mathbf{Z}^\top);$$

4. $\mathbf{C}$ é invariante sob a projeção sobre o espaço linha de $\mathbf{Z}$:

$$\mathbf{C} = \mathbf{C} \mathbf{Z}^+ \mathbf{Z};$$

5. $\mathbf{C}$ anula as direções não identificáveis:

$$\mathbf{C}(\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) = \mathbf{0}.$$

Essas condições podem ser resumidas por

$$\mathbf{CB} \text{ é estimável} \iff \mathbf{C} = \mathbf{C} \mathbf{Z}^+ \mathbf{Z}. \quad (11.154)$$

Comprovação. Se $\mathbf{CB}$ é estimável, existe $\mathbf{A}$ tal que

$$\mathbf{A}^\top \mathbf{Z} = \mathbf{C}.$$

Logo, cada linha de $\mathbf{C}$ é combinação linear das linhas de $\mathbf{Z}$.

Reciprocamente, se as linhas de $\mathbf{C}$ pertencem a $\mathcal{C}(\mathbf{Z}^\top)$, existe uma matriz $\mathbf{A}$ satisfazendo

$$\mathbf{C} = \mathbf{A}^\top \mathbf{Z}.$$

Nesse caso,

$$\mathbf{A}^\top \mathbf{y}$$

é um estimador linear não viesado de $\mathbf{CB}$.

Como

$$\mathbf{Z}^+ \mathbf{Z}$$

é o projetor ortogonal sobre $\mathcal{C}(\mathbf{Z}^\top)$, uma matriz cujas linhas pertencem a esse espaço satisfaz

$$\mathbf{C} = \mathbf{C} \mathbf{Z}^+ \mathbf{Z}.$$

Finalmente,

$$\mathbf{C} = \mathbf{C} \mathbf{Z}^+ \mathbf{Z}$$

é equivalente a

$$\mathbf{C} (\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) = \mathbf{0}.$$

□

Para uma única combinação,

$$\mathbf{c}^\top \mathbf{B}, \quad \mathbf{c} \in \mathbb{R}^q,$$

a condição torna-se

$$\mathbf{c} \in \mathcal{C}(\mathbf{Z}^\top). \quad (11.155)$$

Equivalentemente,

$$\mathbf{c} \perp \mathcal{N}(\mathbf{Z}).$$

Essa formulação mostra que uma função estimável não varia quando a matriz de parâmetros é deslocada em uma direção pertencente ao núcleo do delineamento.

Se

$$\mathbf{B}_2 = \mathbf{B}_1 + \mathbf{D}$$

e

$$\mathbf{ZD} = \mathbf{0},$$

então, para uma função estimável,

$$\mathbf{CB}_2 = \mathbf{CB}_1. \quad (11.156)$$

Uma estimativa conveniente é

$$\widehat{\Theta}_C = \mathbf{CZ}^+\mathbf{Y}. \quad (11.157)$$

Sua esperança é

$$\begin{aligned} E(\widehat{\Theta}_C \mid \mathbf{Z}) &= \mathbf{CZ}^+\mathbf{ZB} \\ &= \mathbf{CB}, \end{aligned}$$

quando

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}.$$

A mesma estimativa é obtida utilizando qualquer solução das equações normais.

Teorema 11.19 (Unicidade da estimativa de uma função estimável). *Se $\mathbf{CB}$ é estimável e*

$$\widehat{\mathbf{B}}_1 \quad e \quad \widehat{\mathbf{B}}_2$$

são duas soluções das equações normais, então

$$\mathbf{C}\widehat{\mathbf{B}}_1 = \mathbf{C}\widehat{\mathbf{B}}_2 = \mathbf{CZ}^+\mathbf{Y}. \quad (11.158)$$

Comprovação. Como as duas soluções produzem os mesmos valores ajustados,

$$\mathbf{Z}(\widehat{\mathbf{B}}_1 - \widehat{\mathbf{B}}_2) = \mathbf{0}.$$

Logo, as colunas da diferença pertencem a $\mathcal{N}(\mathbf{Z})$.

Como as linhas de $\mathbf{C}$ pertencem a

$$\mathcal{N}(\mathbf{Z})^\perp,$$

tem-se

$$\mathbf{C}(\widehat{\mathbf{B}}_1 - \widehat{\mathbf{B}}_2) = \mathbf{0}.$$

Portanto,

$$\mathbf{C}\widehat{\mathbf{B}}_1 = \mathbf{C}\widehat{\mathbf{B}}_2.$$

□

Considere também uma matriz fixa

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

A função bilateral

$$\mathbf{CBM} \in \mathbb{R}^{g \times s}$$

combina simultaneamente:

- termos do modelo, por meio de $\mathbf{C}$;
- respostas, por meio de $\mathbf{M}$.

Se $\mathbf{CB}$ é estimável, então

$$\mathbf{CBM}$$

é estimável para qualquer matriz fixa $\mathbf{M}$, com estimativa

$$\mathbf{CZ}^+\mathbf{YM}. \quad (11.159)$$

Quando $\mathbf{M} \neq \mathbf{0}$, a condição

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}$$

também é necessária para que a função bilateral seja invariante em relação a todas as parametrizações equivalentes.

Essa estrutura será utilizada na formulação da hipótese linear multivariada geral.

11.7.4 Parametrizações equivalentes

Diferentes matrizes de delineamento podem representar o mesmo conjunto de matrizes de médias.

Definição 11.20 (Parametrizações equivalentes). Duas matrizes de delineamento

$$\mathbf{Z}_1 \quad \text{e} \quad \mathbf{Z}_2$$

definem parametrizações equivalentes quando

$$\mathcal{C}(\mathbf{Z}_1) = \mathcal{C}(\mathbf{Z}_2). \quad (11.160)$$

Parametrizações equivalentes possuem o mesmo projetor:

$$\mathbf{P}_{\mathbf{Z}_1} = \mathbf{P}_{\mathbf{Z}_2}. \quad (11.161)$$

Consequentemente, produzem:

$$\widehat{\mathbf{Y}}_1 = \widehat{\mathbf{Y}}_2,$$

$$\widehat{\mathbf{U}}_1 = \widehat{\mathbf{U}}_2$$

e

$$\mathbf{E}_1 = \mathbf{E}_2. \quad (11.162)$$

Os elementos das matrizes de parâmetros podem possuir significados diferentes porque cada parametrização utiliza um sistema de coordenadas distinto para o mesmo espaço de médias.

Exemplo 11.1 (Parametrizações de um modelo com três grupos). Considere três grupos não vazios e mutuamente exclusivos. Sejam

$$\mathbf{g}_1, \mathbf{g}_2, \mathbf{g}_3 \in \mathbb{R}^n$$

seus vetores indicadores. Como cada unidade pertence a exatamente um grupo,

$$\mathbf{1}_n = \mathbf{g}_1 + \mathbf{g}_2 + \mathbf{g}_3. \quad (11.163)$$

Uma parametrização por médias de grupos utiliza

$$\mathbf{Z}_{\text{med}} = [\mathbf{g}_1 \quad \mathbf{g}_2 \quad \mathbf{g}_3]$$

e

$$\mathbf{B}_{\text{med}} = \begin{bmatrix} \mu_1^\top \\ \mu_2^\top \\ \mu_3^\top \end{bmatrix}. \quad (11.164)$$

A matriz possui posto 3, e os parâmetros são diretamente os vetores de médias dos grupos.

Uma parametrização com grupo de referência utiliza

$$\mathbf{Z}_{\text{ref}} = [\mathbf{1}_n \quad \mathbf{g}_2 \quad \mathbf{g}_3]$$

e

$$\mathbf{B}_{\text{ref}} = \begin{bmatrix} \mu_1^\top \\ (\mu_2 - \mu_1)^\top \\ (\mu_3 - \mu_1)^\top \end{bmatrix}. \quad (11.165)$$

Nessa representação, a primeira linha contém a média do grupo de referência e as demais contêm diferenças em relação a esse grupo.

Também é possível utilizar a parametrização redundante

$$\mathbf{Z}_{\text{sup}} = [\mathbf{1}_n \quad \mathbf{g}_1 \quad \mathbf{g}_2 \quad \mathbf{g}_3]. \quad (11.166)$$

Como

$$\mathbf{1}_n - \mathbf{g}_1 - \mathbf{g}_2 - \mathbf{g}_3 = \mathbf{0},$$

tem-se

$$\text{posto}(\mathbf{Z}_{\text{sup}}) = 3 < 4.$$

Escreva

$$\mathbf{B}_{\text{sup}} = \begin{bmatrix} \beta_0^\top \\ \beta_1^\top \\ \beta_2^\top \\ \beta_3^\top \end{bmatrix}.$$

Os vetores de médias são

$$\mu_h = \beta_0 + \beta_h, \quad h = 1, 2, 3. \quad (11.167)$$

Para qualquer

$$\delta \in \mathbb{R}^p,$$

a transformação

$$\beta_0^* = \beta_0 + \delta$$

e

$$\beta_h^* = \beta_h - \delta, \quad h = 1, 2, 3,$$

preserva todos os vetores de médias.

Os coeficientes individuais da parametrização redundante não são identificáveis. Permanecem estimáveis:

$$\mu_1, \quad \mu_2, \quad \mu_3,$$

e contrastes como

$$\mu_1 - \mu_2 = \beta_1 - \beta_2.$$

As três matrizes de delineamento satisfazem

$$\mathcal{C}(\mathbf{Z}_{\text{med}}) = \mathcal{C}(\mathbf{Z}_{\text{ref}}) = \mathcal{C}(\mathbf{Z}_{\text{sup}}). \quad (11.168)$$

Elas produzem os mesmos valores ajustados, resíduos e SSCP residuais, embora seus coeficientes possuam interpretações diferentes.

As conclusões substantivas devem ser expressas por meio de:

- médias ajustadas;
- diferenças entre médias;
- contrastes;
- tendências;
- outras funções estimáveis.

Coefficientes isolados devem ser interpretados de acordo com a codificação que os define.

11.7.5 Restrições de identificação

Uma parametrização redundante pode ser convertida em uma representação única pela imposição de restrições.

Considere

$$\mathbf{R} \in \mathbb{R}^{(q-r) \times q}$$

e as restrições homogêneas

$$\mathbf{RB} = \mathbf{0}. \quad (11.169)$$

O objetivo é selecionar um único representante de cada classe de matrizes equivalentes.

Teorema 11.20 (Condição para restrições de identificação). *Suponha que*

$$\text{posto}(\mathbf{Z}) = r < q$$

e que

$$\text{posto}(\mathbf{R}) = q - r.$$

As restrições

$$\mathbf{RB} = \mathbf{0}$$

identificam uma única matriz de parâmetros para cada matriz de médias representável quando

$$\mathcal{N}(\mathbf{Z}) \cap \mathcal{N}(\mathbf{R}) = \{\mathbf{0}\}. \quad (11.170)$$

Equivalentemente,

$$\text{posto} \begin{bmatrix} \mathbf{Z} \\ \mathbf{R} \end{bmatrix} = q. \quad (11.171)$$

Comprovação. Considere duas matrizes de parâmetros equivalentes que satisfazem as restrições:

$$\mathbf{ZB}_1 = \mathbf{ZB}_2$$

e

$$\mathbf{RB}_1 = \mathbf{RB}_2 = \mathbf{0}.$$

A diferença

$$\mathbf{D} = \mathbf{B}_1 - \mathbf{B}_2$$

satisfaz

$$\mathbf{ZD} = \mathbf{0}$$

e

$$\mathbf{RD} = \mathbf{0}.$$

Cada coluna de $\mathbf{D}$ pertence simultaneamente a

$$\mathcal{N}(\mathbf{Z})$$

e

$$\mathcal{N}(\mathbf{R}).$$

Se a interseção contém somente o vetor nulo, então

$$\mathbf{D} = \mathbf{0},$$

e a representação é única.

A condição sobre o posto da matriz ampliada é equivalente à ausência de uma direção não nula anulada simultaneamente por $\mathbf{Z}$ e $\mathbf{R}$. $\square$

No modelo superparametrizado de grupos, uma restrição possível é selecionar o primeiro grupo como referência:

$$\beta_1 = \mathbf{0}.$$

Nesse caso,

$$\beta_0 = \mu_1$$

e

$$\beta_h = \mu_h - \mu_1, \quad h = 2, 3.$$

Outra possibilidade é impor

$$\beta_1 + \beta_2 + \beta_3 = \mathbf{0}. \quad (11.172)$$

Essa restrição representa os efeitos dos grupos como desvios em relação à média não ponderada dos três vetores de médias.

Se o objetivo for utilizar a média geral ponderada pelos tamanhos dos grupos, pode-se impor

$$n_1\beta_1 + n_2\beta_2 + n_3\beta_3 = \mathbf{0}. \quad (11.173)$$

As restrições alteram os valores e as interpretações dos coeficientes individuais. Elas não alteram:

- o espaço de médias;
- os valores ajustados;
- as funções estimáveis;
- as conclusões expressas por contrastes equivalentes.

Restrição de identificação e hipótese substantiva

Uma restrição de identificação escolhe coordenadas para representar um modelo que já possui o mesmo espaço de médias. Ela não expressa, por si só, uma afirmação científica a ser testada.

Por exemplo,

$$\beta_1 = \mathbf{0}$$

pode definir um grupo de referência sem afirmar que o efeito substantivo desse grupo seja nulo.

As hipóteses estatísticas serão formuladas sobre funções estimáveis, independentemente da restrição usada para identificar os coeficientes.

11.7.6 Posto numérico

O posto algébrico trata relações lineares exatas. Em aplicações, as colunas de $\mathbf{Z}$ podem ser quase linearmente dependentes.

Considere os valores singulares positivos de $\mathbf{Z}$:

$$s_1 \geq s_2 \geq \cdots \geq s_r > 0.$$

O número de condição espectral, restrito ao espaço identificado, é

$$\kappa_2(\mathbf{Z}) = \frac{s_1}{s_r}. \quad (11.174)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$r = q,$$

e um valor elevado de $\kappa_2(\mathbf{Z})$ indica que existe uma combinação das colunas com magnitude muito pequena em relação às demais direções.

Além disso,

$$\kappa_2(\mathbf{Z}^\top \mathbf{Z}) = \kappa_2(\mathbf{Z})^2. \quad (11.175)$$

Por isso, formar e inverter explicitamente $\mathbf{Z}^\top \mathbf{Z}$ pode ampliar problemas numéricos.

Uma definição computacional de posto utiliza uma tolerância $\tau > 0$:

$$\text{posto}_\tau(\mathbf{Z}) = \# \{j : s_j > \tau s_1\}. \quad (11.176)$$

O posto numérico pode depender:

- da escala das colunas;
- da precisão computacional;
- da tolerância adotada;
- do método de decomposição;
- da magnitude relativa dos valores singulares.

O posto algébrico e o posto numérico respondem a problemas diferentes. O primeiro caracteriza identificabilidade exata. O segundo avalia a estabilidade prática da estimação.

Em situações de quase dependência linear:

- os valores ajustados podem permanecer relativamente estáveis;
- os coeficientes individuais podem variar intensamente;
- pequenos erros nos dados podem produzir grandes alterações nas estimativas;
- funções estimáveis bem determinadas podem ser mais estáveis que os coeficientes isolados;
- erros-padrão associados a determinadas direções podem ser elevados.

Decomposições QR e SVD permitem calcular ajustes e diagnosticar o posto sem depender da inversão explícita de

$$\mathbf{Z}^\top \mathbf{Z}.$$

A pseudoinversa também deve ser interpretada com base em uma tolerância numérica quando valores singulares muito pequenos estão presentes.

A deficiência de posto, a quase colinearidade e a não identificabilidade não devem ser tratadas como sinônimos:

- a deficiência de posto corresponde a dependência linear exata;
- a quase colinearidade corresponde a dependência aproximada e instabilidade;
- a não identificabilidade refere-se à impossibilidade de determinar separadamente determinadas funções dos parâmetros.

A formulação das hipóteses lineares deve respeitar o espaço de funções estimáveis. Na próxima seção, combinações das linhas e das colunas de $\mathbf{B}$ serão reunidas na forma

$$\mathbf{CBM},$$

permitindo representar contrastes sobre parâmetros, grupos e respostas em uma única estrutura.

11.8 Hipóteses lineares multivariadas

O modelo linear multivariado permite formular hipóteses simultaneamente sobre:

- os termos representados nas linhas de $\mathbf{B}$;
- as respostas representadas nas colunas de $\mathbf{B}$;
- combinações dos termos e das respostas.

A hipótese linear geral é construída por multiplicações à esquerda e à direita da matriz de parâmetros:

$$\mathbf{CBM}.$$

A matriz $\mathbf{C}$ define contrastes sobre os termos do modelo, enquanto $\mathbf{M}$ define combinações lineares das respostas. Essa formulação bilateral abrange comparações entre grupos, testes de efeitos, tendências e hipóteses sobre respostas transformadas (Rao, 1973).

11.8.1 Contrastes sobre os parâmetros

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}.$$

A função

$$\mathbf{CB} \in \mathbb{R}^{g \times p}$$

combina as linhas da matriz de parâmetros.

Cada linha de $\mathbf{C}$ define uma combinação linear dos termos do modelo. Se

$$\mathbf{c}^\top \in \mathbb{R}^{1 \times q}$$

é uma linha de $\mathbf{C}$, então

$$\mathbf{c}^\top \mathbf{B} \in \mathbb{R}^{1 \times p}$$

é um vetor contendo a mesma combinação paramétrica para todas as respostas.

Na parametrização por médias de g_0 grupos,

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \mu_2^\top \\ \vdots \\ \mu_{g_0}^\top \end{bmatrix},$$

a matriz

$$\mathbf{C} = [1 \quad -1 \quad 0 \quad \cdots \quad 0]$$

produz

$$\mathbf{CB} = (\mu_1 - \mu_2)^\top.$$

Para comparar simultaneamente três grupos com o primeiro, pode-se utilizar

$$\mathbf{C} = \begin{bmatrix} 1 & -1 & 0 \\ 1 & 0 & -1 \end{bmatrix}.$$

Nesse caso,

$$\mathbf{CB} = \begin{bmatrix} (\mu_1 - \mu_2)^\top \\ (\mu_1 - \mu_3)^\top \end{bmatrix}.$$

Uma matriz de contrastes deve ser construída de acordo com a parametrização adotada. O mesmo efeito substantivo pode exigir matrizes $\mathbf{C}$ diferentes em parametrizações por médias, grupos de referência ou efeitos com restrição de soma nula.

A função paramétrica, entretanto, permanece a mesma quando os contrastes são corretamente traduzidos entre parametrizações equivalentes.

11.8.2 Combinações lineares das respostas

Considere

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

A função

$$\mathbf{BM} \in \mathbb{R}^{q \times s}$$

combina as colunas de $\mathbf{B}$ e, portanto, as respostas.

Cada coluna de $\mathbf{M}$ define uma combinação linear das p respostas. Para

$$\mathbf{m} \in \mathbb{R}^p,$$

a combinação das respostas é

$$W_i = \mathbf{m}^\top \mathbf{Y}_i.$$

Sua média condicional é

$$\begin{aligned} E(W_i \mid \mathbf{z}_i) &= \mathbf{m}^\top \mathbf{B}^\top \mathbf{z}_i \\ &= \mathbf{z}_i^\top \mathbf{Bm}. \end{aligned} \tag{11.177}$$

O vetor de coeficientes da nova resposta é

$$\mathbf{B}\mathbf{m} \in \mathbb{R}^q.$$

Sua variância residual é

$$\text{Var}(\mathbf{m}^\top \varepsilon_i \mid \mathbf{Z}) = \mathbf{m}^\top \Sigma \mathbf{m}. \quad (11.178)$$

Quando $\mathbf{M}$ possui s colunas, a matriz transformada de respostas é

$$\mathcal{Y}_M = \mathcal{Y}\mathbf{M} \in \mathbb{R}^{n \times s}.$$

O modelo correspondente é

$$\mathcal{Y}_M = \mathbf{Z}(\mathbf{B}\mathbf{M}) + \mathcal{E}\mathbf{M}. \quad (11.179)$$

Sua matriz de covariâncias residuais é

$$\Sigma_M = \mathbf{M}^\top \Sigma \mathbf{M}. \quad (11.180)$$

Se

$$\Sigma \succ \mathbf{0}$$

e $\mathbf{M}$ possui posto coluna completo, então

$$\Sigma_M \succ \mathbf{0}.$$

Para comparar duas respostas, pode-se utilizar

$$\mathbf{m} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A nova resposta é

$$W_i = Y_{i1} - Y_{i2}.$$

Para estudar a média de três respostas, pode-se utilizar

$$\mathbf{m} = \frac{1}{3} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

A matriz $\mathbf{M}$ pode conter várias dessas combinações simultaneamente.

11.8.3 Hipótese linear geral

A multiplicação bilateral reúne contrastes sobre termos e combinações de respostas.

Definição 11.21 (Função paramétrica bilateral). Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p}$$

e

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

A função paramétrica bilateral é

$$\Theta = \mathbf{CBM} \in \mathbb{R}^{g \times s}. \quad (11.181)$$

As dimensões do produto são

$$(g \times q)(q \times p)(p \times s) = g \times s.$$

As linhas de Θ correspondem às combinações definidas por $\mathbf{C}$. As colunas correspondem às combinações das respostas definidas por $\mathbf{M}$.

Definição 11.22 (Hipótese linear geral multivariada). A hipótese linear geral é

$$H_0 : \mathbf{CBM} = \Theta_0, \quad (11.182)$$

em que

$$\Theta_0 \in \mathbb{R}^{g \times s}$$

é uma matriz conhecida.

A hipótese alternativa é

$$H_1 : \mathbf{CBM} \neq \Theta_0.$$

Quando

$$\Theta_0 = \mathbf{0},$$

a hipótese é homogênea:

$$H_0 : \mathbf{CBM} = \mathbf{0}. \quad (11.183)$$

Casos particulares incluem:

$$H_0 : \mathbf{CB} = \Theta_0$$

quando

$$\mathbf{M} = \mathbf{I}_p,$$

e

$$H_0 : \mathbf{BM} = \Theta_0$$

quando

$$\mathbf{C} = \mathbf{I}_q.$$

Para uma única combinação de termos e uma única combinação de respostas,

$$g = s = 1,$$

a hipótese reduz-se a

$$H_0 : \mathbf{c}^\top \mathbf{Bm} = \theta_0. \quad (11.184)$$

Embora o lado esquerdo seja construído a partir de uma matriz de parâmetros, a hipótese pode assumir dimensão escalar, vetorial ou matricial.

11.8.4 Estimabilidade e dimensões

A hipótese deve ser formulada sobre uma função paramétrica estimável.

Quando $\mathbf{M} \neq \mathbf{0}$, a função

$$\mathbf{CBM}$$

é estimável para todas as matrizes de parâmetros equivalentes se, e somente se,

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z}. \quad (11.185)$$

Essa é a mesma condição exigida para a estimabilidade de $\mathbf{CB}$.

Para verificar a necessidade, considere uma direção não identificável

$$\mathbf{d} \in \mathcal{N}(\mathbf{Z}).$$

Uma alteração da forma

$$\mathbf{B}^* = \mathbf{B} + \mathbf{d}\mathbf{v}^\top$$

preserva a matriz de médias, pois

$$\mathbf{Z}\mathbf{d}\mathbf{v}^\top = \mathbf{0}.$$

A função bilateral permanece invariável para qualquer $\mathbf{v}$ somente quando

$$\mathbf{C}\mathbf{d} = \mathbf{0}$$

para todas as direções do núcleo de $\mathbf{Z}$. Isso equivale a exigir que as linhas de $\mathbf{C}$ pertençam ao espaço linha de $\mathbf{Z}$.

A estimativa da função bilateral é

$$\widehat{\Theta} = \mathbf{C}\widehat{\mathbf{B}}\mathbf{M}. \quad (11.186)$$

Quando o delineamento possui posto deficiente, pode-se escrever

$$\widehat{\Theta} = \mathbf{CZ}^+\mathbf{y}\mathbf{M}. \quad (11.187)$$

Para os dados observados,

$$\widehat{\Theta}_{\text{obs}} = \mathbf{CZ}^+ \mathbf{Y}\mathbf{M}. \quad (11.188)$$

Sob estimabilidade,

$$E(\widehat{\Theta} \mid \mathbf{Z}) = \mathbf{C}\mathbf{B}\mathbf{M}. \quad (11.189)$$

Defina

$$\mathbf{A}_C = \mathbf{CZ}^+ \in \mathbb{R}^{g \times n}. \quad (11.190)$$

Então,

$$\widehat{\Theta} - \Theta = \mathbf{A}_C \mathcal{E}\mathbf{M}.$$

A matriz associada à variabilidade das combinações dos parâmetros é

$$\mathbf{G}_C = \mathbf{A}_C \mathbf{A}_C^\top = \mathbf{CZ}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}^{\top}. \quad (11.191)$$

Quando $\mathbf{Z}$ possui posto coluna completo,

$$\mathbf{G}_C = \mathbf{C} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}^{\top}. \quad (11.192)$$

Teorema 11.21 (Covariância da função bilateral estimada). *Sob as hipóteses de segunda ordem,*

$$\text{Cov} [\text{vec}(\widehat{\Theta}) \mid \mathbf{Z}] = (\mathbf{M}^{\top} \Sigma \mathbf{M}) \otimes \mathbf{G}_C. \quad (11.193)$$

Comprovação. Pela identidade da vetorização,

$$\text{vec}(\widehat{\Theta} - \Theta) = (\mathbf{M}^{\top} \otimes \mathbf{A}_C) \text{vec}(\mathcal{E}).$$

Como

$$\text{Cov} [\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n,$$

tem-se

$$\begin{aligned}
& \text{Cov} \left[\text{vec} \left(\widehat{\Theta} \right) \mid \mathbf{Z} \right] \\
&= (\mathbf{M}^\top \otimes \mathbf{A}_C) (\Sigma \otimes \mathbf{I}_n) (\mathbf{M} \otimes \mathbf{A}_C^\top) \\
&= (\mathbf{M}^\top \Sigma \mathbf{M}) \otimes (\mathbf{A}_C \mathbf{A}_C^\top).
\end{aligned}$$

A segunda parcela é $\mathbf{G}_C$. □

A matriz $\mathbf{G}_C$ possui dimensão $g \times g$. Sua diagonal mede a contribuição do delineamento para a variabilidade de cada combinação definida por $\mathbf{C}$. Os elementos fora da diagonal representam relações entre essas combinações.

Se as linhas de $\mathbf{C}$ contêm restrições redundantes, então

$$\mathbf{G}_C$$

é singular. As hipóteses redundantes devem ser retiradas ou representadas por uma matriz de posto linha completo.

Defina

$$h = \text{posto}(\mathbf{G}_C). \quad (11.194)$$

O número h representa a quantidade de combinações linearmente independentes dos termos do modelo incluídas na hipótese.

De modo semelhante, deve-se verificar

$$s_M = \text{posto}(\mathbf{M}).$$

Se

$$s_M < s,$$

as colunas de $\mathbf{M}$ contêm combinações redundantes das respostas. Nesse caso, a hipótese pode ser reescrita utilizando uma base para $\mathcal{C}(\mathbf{M})$.

A remoção de redundâncias não altera o conteúdo substantivo da hipótese. Ela produz uma representação com dimensões efetivas bem definidas.

11.8.5 Matriz SSCP da hipótese

A SSCP da hipótese transforma o afastamento observado de uma função estimável em uma matriz de dimensão associada às combinações das respostas, ponderando os contrastes pela variabilidade induzida pelo delineamento (Rencher; Christensen, 2012). Considere o desvio observado:

$$\widehat{\Delta} = \mathbf{C}\widehat{\mathbf{B}}_{\text{obs}}\mathbf{M} - \Theta_0 \in \mathbb{R}^{g \times s}. \quad (11.195)$$

Suponha que:

$$\mathbf{CBM}$$

seja estimável e que as restrições tenham sido representadas sem redundância, de modo que

$$\mathbf{G}_C \succ \mathbf{0}.$$

Definição 11.23 (SSCP da hipótese linear). A matriz de somas de quadrados e produtos cruzados associada à hipótese é

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{G}_C^{-1} \widehat{\Delta}. \quad (11.196)$$

A matriz

$$\mathbf{H} \in \mathbb{R}^{s \times s}$$

é simétrica e semidefinida positiva.

Para qualquer

$$\mathbf{a} \in \mathbb{R}^s,$$

tem-se

$$\begin{aligned} \mathbf{a}^\top \mathbf{H} \mathbf{a} &= \mathbf{a}^\top \widehat{\Delta}^\top \mathbf{G}_C^{-1} \widehat{\Delta} \mathbf{a} \\ &= \left\| \mathbf{G}_C^{-1/2} \widehat{\Delta} \mathbf{a} \right\|^2 \\ &\geq 0. \end{aligned} \quad (11.197)$$

A forma quadrática mede o afastamento da hipótese para a combinação das respostas definida por $\mathbf{a}$, ponderado pela variabilidade induzida pelo delineamento.

Se

$$\widehat{\Delta} = \mathbf{0},$$

então

$$\mathbf{H} = \mathbf{0}.$$

Quanto maior o afastamento estimado em relação a Θ_0 , em comparação com a variabilidade associada aos contrastes, maior tende a ser a magnitude de $\mathbf{H}$.

Quando $\mathbf{G}_C$ é singular por causa de restrições redundantes, existem duas possibilidades:

- substituir $\mathbf{C}$ por uma matriz com linhas linearmente independentes;
- utilizar a pseudoinversa $\mathbf{G}_C^+$.

Na segunda representação,

$$\mathbf{H} = \widehat{\Delta}^\top \mathbf{G}_C^+ \widehat{\Delta}. \quad (11.198)$$

A primeira alternativa torna mais explícito o número efetivo de restrições e será preferida na formulação inferencial.

A SSCP residual correspondente às respostas transformadas por $\mathbf{M}$ é

$$\mathbf{E}_M = \mathbf{M}^\top \mathbf{E} \mathbf{M}. \quad (11.199)$$

A matriz $\mathbf{E}_M$ possui dimensão $s \times s$ e representa a variação residual das combinações de respostas incluídas na hipótese.

Assim, a formulação bilateral produz o par

$$(\mathbf{H}, \mathbf{E}_M).$$

A matriz $\mathbf{H}$ representa o afastamento em relação à hipótese. A matriz $\mathbf{E}_M$ representa a variabilidade residual disponível para avaliar esse afastamento.

O próximo capítulo construirá estatísticas de teste a partir das raízes associadas a essas duas matrizes.

Quando

$$\mathbf{M} = \mathbf{I}_p,$$

obtém-se

$$\mathbf{E}_M = \mathbf{E}$$

e

$$\mathbf{H} \in \mathbb{R}^{p \times p}.$$

Quando

$$s = 1,$$

as matrizes $\mathbf{H}$ e $\mathbf{E}_M$ reduzem-se a escalares. A hipótese corresponde, então, a um problema univariado aplicado à combinação de respostas definida pela coluna de $\mathbf{M}$.

11.8.6 Modelos encaixados

Uma hipótese linear também pode ser representada pela comparação entre dois espaços de médias encaixados. A diferença entre os respectivos projetores isola a parcela do espaço de médias acrescentada pelo modelo completo (Christensen, 2011).

Considere um modelo completo com matriz de delineamento

$$\mathbf{Z}_F$$

e um modelo reduzido com matriz

$$\mathbf{Z}_R,$$

tais que

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F). \quad (11.200)$$

Defina

$$r_F = \text{posto}(\mathbf{Z}_F)$$

e

$$r_R = \text{posto}(\mathbf{Z}_R).$$

Os projetores são

$$\mathbf{P}_F = \mathbf{Z}_F \mathbf{Z}_F^+$$

e

$$\mathbf{P}_R = \mathbf{Z}_R \mathbf{Z}_R^+.$$

Como os espaços são encaixados,

$$\mathbf{P}_F \mathbf{P}_R = \mathbf{P}_R \mathbf{P}_F = \mathbf{P}_R. \quad (11.201)$$

A diferença

$$\mathbf{P}_F - \mathbf{P}_R$$

é um projetor ortogonal.

Teorema 11.22 (Projetor associado à diferença entre modelos). *Se*

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

então

$$\mathbf{P}_F - \mathbf{P}_R$$

é o projetor ortogonal sobre

$$\mathcal{C}(\mathbf{Z}_F) \cap \mathcal{C}(\mathbf{Z}_R)^\perp.$$

Seu posto é

$$\text{posto}(\mathbf{P}_F - \mathbf{P}_R) = r_F - r_R. \quad (11.202)$$

A SSCP residual do modelo reduzido é

$$\mathbf{E}_R = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_R) \mathbf{Y}.$$

A SSCP residual do modelo completo é

$$\mathbf{E}_F = \mathbf{Y}^\top (\mathbf{I}_n - \mathbf{P}_F) \mathbf{Y}.$$

Como

$$\mathbf{I}_n - \mathbf{P}_R = (\mathbf{P}_F - \mathbf{P}_R) + (\mathbf{I}_n - \mathbf{P}_F),$$

obtém-se a decomposição:

Teorema 11.23 (Decomposição das SSCP de modelos encaixados). *Para dois modelos encaixados,*

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F, \quad (11.203)$$

em que

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}. \quad (11.204)$$

A matriz $\mathbf{H}$ mede a redução da SSCP residual obtida ao passar do modelo reduzido para o modelo completo:

$$\mathbf{H} = \mathbf{E}_R - \mathbf{E}_F. \quad (11.205)$$

Os graus de liberdade associados são:

$$\nu_H = r_F - r_R \quad (11.206)$$

e

$$\nu_E = n - r_F. \quad (11.207)$$

A comparação pergunta se as direções acrescentadas pelo modelo completo produzem uma redução relevante da variabilidade residual.

Para respostas transformadas,

$$\mathbf{Y}_M = \mathbf{Y}\mathbf{M},$$

as matrizes correspondentes são

$$\mathbf{H}_M = \mathbf{M}^\top \mathbf{H} \mathbf{M}$$

e

$$\mathbf{E}_{F,M} = \mathbf{M}^\top \mathbf{E}_F \mathbf{M}. \quad (11.208)$$

Hipóteses homogêneas da forma

$$H_0 : \mathbf{C}\mathbf{B} = \mathbf{0}$$

podem ser representadas por um modelo reduzido cujo espaço de médias incorpora as restrições definidas por $\mathbf{C}$.

Sob as condições adequadas de estimabilidade e ausência de redundância, a SSCP obtida pela diferença dos modelos coincide com a construção

$$\mathbf{H} = (\mathbf{C}\widehat{\mathbf{B}}_{\text{obs}})^\top [\mathbf{C}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top]^{-1} (\mathbf{C}\widehat{\mathbf{B}}_{\text{obs}})$$

no caso de posto coluna completo.

A formulação por contrastes explicita os parâmetros testados. A formulação por modelos encaixados explicita a diferença entre os espaços de médias. As duas perspectivas descrevem a mesma restrição linear quando são construídas de forma compatível.

11.8.7 Casos particulares

11.8.7.1 Ausência de efeito de um termo

Considere o modelo de posto completo e suponha que a linha h de $\mathbf{B}$ contenha os coeficientes de uma covariável ou de um termo específico.

Defina

$$\mathbf{C} = \mathbf{e}_h^\top,$$

em que $\mathbf{e}_h$ é o h -ésimo vetor da base canônica de $\mathbb{R}^q$.

Com

$$\mathbf{M} = \mathbf{I}_p,$$

a hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} = \mathbf{0}^\top \quad (11.209)$$

afirma que o termo não altera a média de nenhuma das p respostas.

A hipótese contém um contraste sobre os parâmetros e considera todas as respostas simultaneamente.

11.8.7.2 Igualdade entre dois vetores de médias

Na parametrização por médias de grupos, considere os grupos a e b . Utilize

$$\mathbf{C} = \begin{bmatrix} 0 & \cdots & 1 & \cdots & -1 & \cdots & 0 \end{bmatrix},$$

com os coeficientes 1 e -1 nas posições correspondentes.

Com

$$\mathbf{M} = \mathbf{I}_p,$$

a hipótese é

$$H_0 : \mu_a = \mu_b. \quad (11.210)$$

Equivalentemente,

$$H_0 : \mu_a - \mu_b = \mathbf{0}.$$

Essa é uma hipótese sobre todas as respostas.

11.8.7.3 Igualdade entre várias médias de grupos

Para três grupos, a hipótese

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

pode ser representada por

$$\mathbf{C} = \begin{bmatrix} 1 & -1 & 0 \\ 1 & 0 & -1 \end{bmatrix}, \quad \mathbf{M} = \mathbf{I}_p$$

e

$$\Theta_0 = \mathbf{0}_{2 \times p}. \quad (11.211)$$

A matriz $\mathbf{C}$ possui posto 2, que corresponde ao número de diferenças independentes necessárias para representar a igualdade entre três vetores.

11.8.7.4 Efeito sobre uma combinação das respostas

Considere uma linha de contrastes $\mathbf{c}^\top$ e um vetor

$$\mathbf{m} \in \mathbb{R}^p.$$

A hipótese

$$H_0 : \mathbf{c}^\top \mathbf{B} \mathbf{m} = 0 \quad (11.212)$$

avalia se o contraste definido por $\mathbf{c}$ é nulo para a combinação de respostas definida por $\mathbf{m}$.

Por exemplo, para três respostas,

$$\mathbf{m} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

avalia o efeito sobre a diferença entre as duas primeiras respostas.

11.8.7.5 Igualdade entre efeitos em duas respostas

Considere a linha h da matriz de parâmetros e duas respostas j e k . Defina

$$\mathbf{C} = \mathbf{e}_h^\top$$

e

$$\mathbf{M} = \mathbf{e}_j - \mathbf{e}_k.$$

A hipótese

$$H_0 : \mathbf{e}_h^\top \mathbf{B} (\mathbf{e}_j - \mathbf{e}_k) = 0 \quad (11.213)$$

equivale a

$$H_0 : \beta_{hj} = \beta_{hk}.$$

Ela compara o efeito do mesmo termo em duas respostas.

11.8.7.6 Hipóteses entre e dentro das unidades

Quando as colunas de $\mathbf{M}$ representam contrastes entre condições observadas na mesma unidade, enquanto $\mathbf{C}$ representa comparações entre grupos ou termos do delineamento, a função

$$\mathbf{CBM}$$

combina efeitos entre unidades e contrastes dentro das unidades.

Por exemplo, suponha que

$$\mathbf{B} \in \mathbb{R}^{q \times 3}$$

e que suas três colunas contenham os parâmetros das respostas observadas nos momentos 1, 2 e 3. A multiplicação de $\mathbf{B}$ à direita por uma matriz de contrastes permite comparar esses momentos para cada termo representado no delineamento.

Os contrastes

$$\mathbf{M} = \begin{bmatrix} -1 & -1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

produzem:

momento 2 – momento 1

e

momento 3 – momento 1.

Uma matriz $\mathbf{C}$ que compare dois grupos permite testar se essas mudanças temporais são iguais entre os grupos:

$$H_0 : \mathbf{CBM} = \mathbf{0}. \quad (11.214)$$

Essa formulação contém a estrutura básica dos modelos de medidas repetidas multivariados. A distribuição das estatísticas correspondentes será desenvolvida no capítulo seguinte.

11.9 Exemplo integrado

Exemplo 11.2 (Modelo com três grupos e duas respostas). Considere seis unidades distribuídas em três grupos. Para cada unidade, foram observadas duas respostas quantitativas.

Unidade	Grupo	Y_1	Y_2
1	1	2	5
2	1	4	4
3	2	5	7
4	2	6	8
5	3	8	6
6	3	9	7

A matriz observada de respostas é

$$\mathbf{Y} = \begin{bmatrix} 2 & 5 \\ 4 & 4 \\ 5 & 7 \\ 6 & 8 \\ 8 & 6 \\ 9 & 7 \end{bmatrix}.$$

Utilize uma parametrização por médias de grupos. A matriz de delineamento é

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix}. \quad (11.215)$$

A matriz de parâmetros é

$$\mathbf{B} = \begin{bmatrix} \mu_1^\top \\ \mu_2^\top \\ \mu_3^\top \end{bmatrix},$$

em que μ_h é o vetor de médias populacionais do grupo h .

Como os três grupos são não vazios,

$$\text{posto}(\mathbf{Z}) = 3.$$

Além disso,

$$\mathbf{Z}^\top \mathbf{Z} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix} = 2\mathbf{I}_3$$

e

$$(\mathbf{Z}^\top \mathbf{Z})^{-1} = \frac{1}{2}\mathbf{I}_3.$$

11.9.1 Estimação das médias dos grupos

A estimativa de mínimos quadrados é

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

As médias observadas dos grupos são

$$\bar{\mathbf{y}}_1 = \begin{bmatrix} 3 \\ 4,5 \end{bmatrix}, \quad \bar{\mathbf{y}}_2 = \begin{bmatrix} 5,5 \\ 7,5 \end{bmatrix}$$

e

$$\bar{\mathbf{y}}_3 = \begin{bmatrix} 8,5 \\ 6,5 \end{bmatrix}.$$

Portanto,

$$\widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 3 & 4,5 \\ 5,5 & 7,5 \\ 8,5 & 6,5 \end{bmatrix}. \quad (11.216)$$

A primeira coluna contém as médias de Y_1 nos três grupos. A segunda contém as médias de Y_2 .

11.9.2 Valores ajustados e resíduos

Os valores ajustados são as médias correspondentes aos grupos:

$$\widehat{\mathbf{Y}} = \mathbf{Z} \widehat{\mathbf{B}}_{\text{obs}} = \begin{bmatrix} 3 & 4,5 \\ 3 & 4,5 \\ 5,5 & 7,5 \\ 5,5 & 7,5 \\ 8,5 & 6,5 \\ 8,5 & 6,5 \end{bmatrix}. \quad (11.217)$$

A matriz de resíduos é

$$\begin{aligned}\widehat{\mathbf{U}} &= \mathbf{Y} - \widehat{\mathbf{Y}} \\ &= \begin{bmatrix} -1 & 0,5 \\ 1 & -0,5 \\ -0,5 & -0,5 \\ 0,5 & 0,5 \\ -0,5 & -0,5 \\ 0,5 & 0,5 \end{bmatrix}.\end{aligned}\tag{11.218}$$

Dentro de cada grupo, os resíduos somam zero em cada resposta.

O projetor do modelo pode ser escrito em blocos como

$$\mathbf{P}_Z = \text{diag}\left(\frac{1}{2}\mathbf{1}_2\mathbf{1}_2^\top, \frac{1}{2}\mathbf{1}_2\mathbf{1}_2^\top, \frac{1}{2}\mathbf{1}_2\mathbf{1}_2^\top\right).$$

Cada bloco substitui as respostas das duas unidades pela média do respectivo grupo.

O projetor residual é

$$\mathbf{M}_Z = \text{diag}(\mathbf{H}_2, \mathbf{H}_2, \mathbf{H}_2),$$

em que

$$\mathbf{H}_2 = \begin{bmatrix} 1/2 & -1/2 \\ -1/2 & 1/2 \end{bmatrix}.$$

11.9.3 SSCP residual e estimação da covariância

A SSCP residual é

$$\begin{aligned}\mathbf{E} &= \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} \\ &= \begin{bmatrix} 3 & 0 \\ 0 & 1,5 \end{bmatrix}.\end{aligned}\tag{11.219}$$

Como

$$n = 6 \quad \text{e} \quad r = 3,$$

os graus de liberdade residuais são

$$\nu_E = n - r = 3.$$

O estimador não viesado da matriz de covariâncias residual é

$$\begin{aligned}\widehat{\Sigma}_{\text{obs}} &= \frac{\mathbf{E}}{3} \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 0,5 \end{bmatrix}.\end{aligned}\tag{11.220}$$

A covariância residual estimada entre as duas respostas é zero nesse conjunto de dados. Isso não significa que as respostas sejam marginalmente não correlacionadas, pois as médias dos grupos variam conjuntamente.

Sob o modelo normal matricial, a estimativa de máxima verossimilhança seria

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{6} = \begin{bmatrix} 0,5 & 0 \\ 0 & 0,25 \end{bmatrix}.$$

11.9.4 Decomposição da variação

O vetor de médias geral é

$$\bar{\mathbf{y}} = \begin{bmatrix} 17/3 \\ 37/6 \end{bmatrix} \approx \begin{bmatrix} 5,667 \\ 6,167 \end{bmatrix}.$$

A SSCP total corrigida é

$$\mathbf{T} = \begin{bmatrix} 100/3 & 31/3 \\ 31/3 & 65/6 \end{bmatrix} \approx \begin{bmatrix} 33,333 & 10,333 \\ 10,333 & 10,833 \end{bmatrix}.\tag{11.221}$$

A SSCP explicada pelas diferenças entre as médias dos grupos é

$$\mathbf{H}_{\text{mod}} = \begin{bmatrix} 91/3 & 31/3 \\ 31/3 & 28/3 \end{bmatrix} \approx \begin{bmatrix} 30,333 & 10,333 \\ 10,333 & 9,333 \end{bmatrix}.\tag{11.222}$$

Verifica-se que

$$\begin{aligned}\mathbf{H}_{\text{mod}} + \mathbf{E} &= \begin{bmatrix} 91/3 & 31/3 \\ 31/3 & 28/3 \end{bmatrix} + \begin{bmatrix} 3 & 0 \\ 0 & 3/2 \end{bmatrix} \\ &= \begin{bmatrix} 100/3 & 31/3 \\ 31/3 & 65/6 \end{bmatrix} \\ &= \mathbf{T}.\end{aligned}$$

Os graus de liberdade também se decompõem:

$$5 = 2 + 3,$$

isto é,

$$n - 1 = (r - 1) + (n - r).$$

11.9.5 Hipótese de igualdade entre os vetores de médias

Considere a hipótese

$$H_0 : \mu_1 = \mu_2 = \mu_3.$$

Uma matriz de contrastes é

$$\mathbf{C} = \begin{bmatrix} 1 & -1 & 0 \\ 1 & 0 & -1 \end{bmatrix}.$$

Como todas as respostas são incluídas,

$$\mathbf{M} = \mathbf{I}_2.$$

A hipótese pode ser escrita como

$$H_0 : \mathbf{CB} = \mathbf{0}_{2 \times 2}.$$

A estimativa dos contrastes é

$$\begin{aligned}\widehat{\Delta} &= \mathbf{CB}_{\text{obs}} \\ &= \begin{bmatrix} -2,5 & -3 \\ -5,5 & -2 \end{bmatrix}.\end{aligned}\tag{11.223}$$

A primeira linha compara os grupos 1 e 2. A segunda compara os grupos 1 e 3.

A matriz associada à variabilidade dos contrastes é

$$\begin{aligned}\mathbf{G}_C &= \mathbf{C} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top \\ &= \frac{1}{2} \mathbf{C} \mathbf{C}^\top \\ &= \begin{bmatrix} 1 & 0,5 \\ 0,5 & 1 \end{bmatrix}.\end{aligned}$$

Sua inversa é

$$\mathbf{G}_C^{-1} = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix}.$$

A SSCP da hipótese é

$$\begin{aligned}\mathbf{H} &= \widehat{\Delta}^\top \mathbf{G}_C^{-1} \widehat{\Delta} \\ &= \begin{bmatrix} 91/3 & 31/3 \\ 31/3 & 28/3 \end{bmatrix}.\end{aligned}\tag{11.224}$$

Nesse caso,

$$\mathbf{H} = \mathbf{H}_{\text{mod}}.$$

A igualdade ocorre porque o modelo completo permite uma média distinta para cada grupo, enquanto a hipótese nula reduz o espaço de médias ao modelo contendo somente a média geral.

A comparação entre o modelo completo e o modelo reduzido produz

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E} = \mathbf{T}.$$

A SSCP residual do modelo reduzido é a própria SSCP total corrigida.

O par de matrizes que será utilizado na inferência é

$$(\mathbf{H}, \mathbf{E}).$$

A matriz $\mathbf{H}$ representa as diferenças entre os vetores de médias dos grupos. A matriz $\mathbf{E}$ representa a variação dentro dos grupos.

11.9.6 Hipótese bilateral sobre a diferença entre respostas

Considere agora a comparação entre os grupos 1 e 2:

$$\mathbf{C}_{12} = \begin{bmatrix} 1 & -1 & 0 \end{bmatrix}.$$

Considere também a diferença entre as duas respostas:

$$\mathbf{m} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A hipótese é

$$H_0 : \mathbf{C}_{12} \mathbf{B} \mathbf{m} = 0. \quad (11.225)$$

Em termos das médias, essa hipótese é

$$H_0 : (\mu_{11} - \mu_{12}) - (\mu_{21} - \mu_{22}) = 0.$$

Ela afirma que a diferença entre as respostas Y_1 e Y_2 é a mesma nos grupos 1 e 2.

A estimativa é

$$\begin{aligned} \hat{\theta} &= \mathbf{C}_{12} \widehat{\mathbf{B}}_{\text{obs}} \mathbf{m} \\ &= 0,5. \end{aligned}$$

A matriz de variabilidade do contraste entre grupos é escalar:

$$\begin{aligned} G_{C_{12}} &= \mathbf{C}_{12} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}_{12}^\top \\ &= 1. \end{aligned}$$

A SSCP da hipótese reduz-se a

$$H = \frac{\hat{\theta}^2}{G_{C_{12}}} = 0,25.$$

A SSCP residual da diferença entre as respostas é

$$\begin{aligned} E_m &= \mathbf{m}^\top \mathbf{E} \mathbf{m} \\ &= 4,5. \end{aligned}$$

O problema multivariado original foi reduzido, nesse caso, a uma hipótese univariada sobre uma combinação específica das respostas.

A decisão inferencial não será realizada neste capítulo. No capítulo seguinte, as matrizes de hipótese e erro serão relacionadas às suas distribuições amostrais e às estatísticas de teste correspondentes.

11.10 Síntese do capítulo

O modelo linear multivariado representa conjuntamente p respostas observadas nas mesmas n unidades:

$$\mathbf{y} = \mathbf{ZB} + \mathcal{E},$$

com

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p}.$$

A matriz $\mathbf{Z}$ contém os termos do modelo. A coluna j de $\mathbf{B}$ contém os coeficientes da resposta j , enquanto sua linha h reúne os coeficientes associados ao termo h em todas as respostas.

A estrutura de médias condicionais é

$$E(\mathbf{y} \mid \mathbf{Z}) = \mathbf{ZB}.$$

As linhas da matriz de erros possuem média nula e matriz de covariâncias comum:

$$E(\varepsilon_i \mid \mathbf{Z}) = \mathbf{0},$$

$$\text{Cov}(\varepsilon_i \mid \mathbf{Z}) = \Sigma.$$

Quando unidades distintas não apresentam covariância residual,

$$\text{Cov}[\text{vec}(\mathcal{E}) \mid \mathbf{Z}] = \Sigma \otimes \mathbf{I}_n.$$

Sob normalidade, o modelo pode ser escrito como

$$\mathbf{y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{ZB}, \mathbf{I}_n, \Sigma).$$

Equivalentemente,

$$\text{vec}(\mathcal{Y}) \mid \mathbf{Z} \sim N_{np} \left[(\mathbf{I}_p \otimes \mathbf{Z}) \text{vec}(\mathbf{B}), \Sigma \otimes \mathbf{I}_n \right].$$

A forma vetorizada mostra que o modelo matricial corresponde a um modelo linear para um vetor com np componentes, mas preserva a separação entre a estrutura das unidades, descrita por $\mathbf{Z}$, e a dependência entre respostas, descrita por Σ .

Quando

$$\text{posto}(\mathbf{Z}) = q,$$

o estimador de mínimos quadrados da matriz de parâmetros é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{Y}.$$

Para a matriz observada,

$$\widehat{\mathbf{B}}_{\text{obs}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}.$$

Esse estimador também maximiza a verossimilhança em relação a $\mathbf{B}$ no modelo normal matricial. Sua esperança é

$$E(\widehat{\mathbf{B}} \mid \mathbf{Z}) = \mathbf{B},$$

e sua matriz de covariâncias vetorizada é

$$\text{Cov}[\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z}] = \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1}.$$

A geometria do ajuste é determinada pelo espaço coluna de $\mathbf{Z}$. O projetor sobre esse espaço é

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+,$$

e o projetor residual é

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z.$$

Os valores ajustados e os resíduos são

$$\hat{\mathbf{y}} = \mathbf{P}_Z \mathbf{y}$$

e

$$\hat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}.$$

Para os dados observados,

$$\mathbf{Y} = \hat{\mathbf{Y}} + \hat{\mathbf{U}},$$

com

$$\hat{\mathbf{Y}}^\top \hat{\mathbf{U}} = \mathbf{0}$$

e

$$\mathbf{Z}^\top \hat{\mathbf{U}} = \mathbf{0}.$$

Assim, cada coluna da matriz de respostas é decomposta em uma parcela pertencente ao espaço de médias do modelo e uma parcela pertencente ao seu complemento ortogonal.

Se

$$r = \text{posto}(\mathbf{Z}),$$

então

$$\text{posto}(\mathbf{P}_Z) = r$$

e

$$\text{posto}(\mathbf{M}_Z) = n - r.$$

Os graus de liberdade residuais são, portanto,

$$\nu_E = n - r.$$

A matriz de somas de quadrados e produtos cruzados residuais é

$$\mathbf{E} = \widehat{\mathbf{U}}^\top \widehat{\mathbf{U}} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Sua esperança é

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma.$$

Consequentemente,

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r}$$

é um estimador não viesado da matriz de covariâncias residual.

Sob normalidade, quando a SSCP residual observada é positiva definida, o estimador de máxima verossimilhança é

$$\widehat{\Sigma}_{\text{MV,obs}} = \frac{\mathbf{E}}{n}.$$

A SSCP residual satisfaz

$$\text{posto}(\mathbf{E}) \leq \min(p, n - r).$$

Por isso, ela é necessariamente singular quando

$$p > n - r.$$

Mesmo quando é invertível, autovalores muito pequenos podem produzir instabilidade numérica em procedimentos que dependem de sua inversa.

Quando o modelo contém intercepto, a SSCP total corrigida é

$$\mathbf{T} = \mathbf{Y}^\top \mathbf{H}_n \mathbf{Y},$$

e a SSCP explicada pelos termos além da média geral é

$$\mathbf{H}_{\text{mod}} = \mathbf{Y}^\top (\mathbf{P}_Z - \mathbf{P}_1) \mathbf{Y}.$$

A decomposição fundamental é

$$\mathbf{T} = \mathbf{H}_{\text{mod}} + \mathbf{E},$$

com graus de liberdade

$$n - 1 = (r - 1) + (n - r).$$

Para qualquer combinação linear das respostas definida por $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}^\top \mathbf{T} \mathbf{a} = \mathbf{a}^\top \mathbf{H}_{\text{mod}} \mathbf{a} + \mathbf{a}^\top \mathbf{E} \mathbf{a}.$$

A decomposição matricial contém, portanto, as decomposições univariadas de todas as combinações lineares das respostas.

Quando a matriz de delineamento possui posto deficiente,

$$r < q,$$

a matriz de parâmetros não é identificada de forma única. Todas as soluções de mínimos quadrados podem ser escritas como

$$\widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{Z}^+ \mathbf{Y} + (\mathbf{I}_q - \mathbf{Z}^+ \mathbf{Z}) \mathbf{K}.$$

Apesar da não unicidade dos coeficientes, os valores ajustados permanecem únicos:

$$\mathbf{Z} \widehat{\mathbf{B}}_{\mathbf{K}} = \mathbf{P}_Z \mathbf{Y}.$$

Uma função linear

$$\mathbf{CB}$$

é estimável quando suas linhas pertencem ao espaço linha de $\mathbf{Z}$. Essa condição pode ser escrita como

$$\mathbf{C} = \mathbf{C} \mathbf{Z}^+ \mathbf{Z}.$$

Funções estimáveis possuem o mesmo valor em todas as parametrizações equivalentes e estimativas únicas, mesmo quando os elementos individuais de $\mathbf{B}$ não são identificáveis.

A hipótese linear multivariada geral é

$$H_0 : \mathbf{CBM} = \Theta_0,$$

em que:

- $\mathbf{C}$ combina os termos do modelo;
- $\mathbf{M}$ combina as respostas;
- Θ_0 contém os valores especificados pela hipótese.

A estimativa da função bilateral é

$$\widehat{\Theta}_{\text{obs}} = \mathbf{CZ}^+ \mathbf{YM}.$$

A matriz associada à variabilidade dos contrastes é

$$\mathbf{G}_C = \mathbf{CZ}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}^{\top}.$$

Sob posto coluna completo,

$$\mathbf{G}_C = \mathbf{C} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{C}^{\top}.$$

A SSCP da hipótese é

$$\mathbf{H} = (\widehat{\Theta}_{\text{obs}} - \Theta_0)^{\top} \mathbf{G}_C^{-1} (\widehat{\Theta}_{\text{obs}} - \Theta_0),$$

quando $\mathbf{G}_C$ é positiva definida.

A SSCP residual das respostas transformadas é

$$\mathbf{E}_M = \mathbf{M}^{\top} \mathbf{E} \mathbf{M}.$$

O par

$$(\mathbf{H}, \mathbf{E}_M)$$

resume o afastamento em relação à hipótese e a variabilidade residual das combinações de respostas analisadas.

A mesma hipótese pode ser representada pela comparação de modelos encaixados. Se

$$\mathcal{C}(\mathbf{Z}_R) \subseteq \mathcal{C}(\mathbf{Z}_F),$$

então

$$\mathbf{E}_R = \mathbf{H} + \mathbf{E}_F,$$

com

$$\mathbf{H} = \mathbf{Y}^\top (\mathbf{P}_F - \mathbf{P}_R) \mathbf{Y}.$$

A matriz $\mathbf{H}$ representa a redução da SSCP residual obtida com a inclusão das direções presentes no modelo completo e ausentes no modelo reduzido.

Ao término do capítulo, deve-se ser capaz de:

- representar várias respostas em um modelo linear matricial;
- distinguir a estrutura de médias da estrutura de covariâncias residuais;
- escrever o modelo em forma vetorizada e normal matricial;
- estimar a matriz de parâmetros por mínimos quadrados;
- interpretar valores ajustados e resíduos como projeções;
- construir a SSCP residual e estimar Σ ;
- determinar graus de liberdade a partir do posto da matriz de delineamento;
- decompor a variação total em parcelas explicada e residual;
- reconhecer parametrizações redundantes;
- identificar funções estimáveis;
- formular hipóteses da forma $\mathbf{CBM} = \Theta_0$;
- construir as matrizes SSCP da hipótese e do erro;
- relacionar contrastes lineares à comparação entre modelos encaixados.

O próximo capítulo desenvolverá as distribuições amostrais associadas a

$$\widehat{\mathbf{B}}, \quad \mathbf{H} \quad \text{e} \quad \mathbf{E}.$$

Esses resultados permitirão construir testes, regiões de confiança e critérios inferenciais para hipóteses sobre vetores de médias, parâmetros de regressão e combinações lineares das respostas.

12 Inferência Multivariada

Os Capítulos 8 a 11 construíram os principais objetos probabilísticos e estatísticos utilizados na análise multivariada. Foram definidos o vetor de médias, a matriz de covariâncias, a distribuição normal multivariada, as estatísticas amostrais e o modelo linear multivariado. O objetivo deste capítulo é estabelecer as distribuições amostrais desses objetos e utilizá-las na formulação de testes de hipóteses, regiões de confiança e procedimentos de comparação entre vetores de médias.

A teoria exata será desenvolvida principalmente sob normalidade multivariada. Quando a distribuição populacional não for especificada, resultados assintóticos permitirão construir aproximações sob condições de regularidade. A distinção entre resultados exatos e assintóticos será mantida ao longo do capítulo, pois suas condições de validade e interpretações são diferentes.

O capítulo começa com a distribuição do vetor de médias amostral e a distribuição de Wishart. Em seguida, essas distribuições são aplicadas ao modelo linear multivariado, à estatística T^2 de Hotelling e à comparação entre uma ou duas populações. A parte final reúne as condições de validade da inferência clássica e delimita sua aplicação em problemas de alta dimensão.

12.1 Resultados exatos e assintóticos

A inferência estatística depende da distribuição amostral das estatísticas utilizadas. Em alguns modelos, essa distribuição pode ser determinada para qualquer tamanho amostral. Em outros, conhece-se apenas seu comportamento limite quando o tamanho da amostra cresce. Resultados assintóticos exigem condições de regularidade e sua utilização em amostras finitas constitui uma aproximação (Vaart, 1998).

Definição 12.1 (Resultados exatos e assintóticos). Um **resultado exato** descreve a distribuição de uma estatística para um tamanho amostral finito. Sua validade depende das hipóteses probabilísticas utilizadas na derivação.

Um **resultado assintótico** descreve o comportamento limite de uma estatística quando o tamanho amostral tende ao infinito. Sua utilização em amostras finitas constitui uma aproximação cuja qualidade depende da distribuição populacional, da dimensão e do tamanho da amostra.

A teoria exata apresentada neste capítulo será baseada, em grande parte, em amostras provenientes de uma população normal multivariada. A teoria assintótica considerará, em geral, a dimensão p fixa e

$$n \longrightarrow \infty.$$

Essa distinção será indicada explicitamente em cada resultado.

12.1.1 Distribuição da média amostral

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$$

de uma população com vetor de médias

$$E(\mathbf{X}_i) = \mu \in \mathbb{R}^p$$

e matriz de covariâncias

$$\text{Cov}(\mathbf{X}_i) = \Sigma \in \mathbb{R}^{p \times p}.$$

O vetor de médias amostral é

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Como estabelecido no Capítulo 10,

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Essas identidades dependem da existência dos momentos de primeira e segunda ordens, mas não exigem normalidade.

Teorema 12.1 (Distribuição da média amostral sob normalidade). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

então

$$\bar{\mathbf{X}} \sim N_p\left(\mu, \frac{\Sigma}{n}\right). \quad (12.1)$$

O resultado é exato para qualquer tamanho amostral n .

Comprovação. O vetor de médias amostral é uma combinação linear dos vetores da amostra:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i.$$

Como os vetores são independentes e normais multivariados, sua combinação linear também possui distribuição normal multivariada.

A esperança é

$$\begin{aligned} E(\bar{\mathbf{X}}) &= \frac{1}{n} \sum_{i=1}^n E(\mathbf{X}_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu \\ &= \mu. \end{aligned}$$

Pela independência,

$$\begin{aligned} \text{Cov}(\bar{\mathbf{X}}) &= \frac{1}{n^2} \sum_{i=1}^n \text{Cov}(\mathbf{X}_i) \\ &= \frac{1}{n^2} \sum_{i=1}^n \Sigma \\ &= \frac{\Sigma}{n}. \end{aligned}$$

Esses parâmetros determinam a distribuição apresentada no enunciado. □

O mesmo resultado pode ser verificado por combinações lineares. Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

tem-se

$$\mathbf{a}^\top \bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{a}^\top \mathbf{X}_i.$$

Como

$$\mathbf{a}^\top \mathbf{X}_i \sim N(\mathbf{a}^\top \mu, \mathbf{a}^\top \Sigma \mathbf{a}),$$

segue que

$$\mathbf{a}^\top \bar{\mathbf{X}} \sim N\left(\mathbf{a}^\top \mu, \frac{\mathbf{a}^\top \Sigma \mathbf{a}}{n}\right).$$

Portanto, todas as combinações lineares de $\bar{\mathbf{X}}$ possuem distribuições normais com os parâmetros correspondentes a Equação 12.1.

Se

$$\Sigma \succ \mathbf{0},$$

a média amostral pode ser padronizada:

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \sim N_p(\mathbf{0}, \mathbf{I}_p). \quad (12.2)$$

A norma quadrática do vetor normal padrão possui distribuição qui-quadrado. Consequentemente,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \sim \chi_p^2. \quad (12.3)$$

A expressão em Equação 12.3 é o quadrado da distância de Mahalanobis entre $\bar{\mathbf{X}}$ e μ , calculado na escala da matriz de covariâncias da média amostral.

Esse resultado será utilizado posteriormente para construir o teste e a região de confiança do vetor de médias quando Σ for conhecida.

Considere agora uma transformação afim

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b},$$

em que

$$\mathbf{A} \in \mathbb{R}^{r \times p} \quad \text{e} \quad \mathbf{b} \in \mathbb{R}^r$$

são fixos. O vetor de médias transformado é

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}} + \mathbf{b}.$$

Sob normalidade,

$$\bar{\mathbf{U}} \sim N_r \left(\mathbf{A}\mu + \mathbf{b}, \frac{\mathbf{A}\Sigma\mathbf{A}^\top}{n} \right). \quad (12.4)$$

Essa propriedade permite formular inferência sobre combinações lineares ou subconjuntos das médias populacionais. Os resultados desta subseção são clássicos na teoria normal multivariada.

12.1.2 Teorema Central do Limite multivariado

Quando a população não é normal, a distribuição exata de

$$\bar{\mathbf{X}}$$

depende da distribuição conjunta das observações. Para vetores independentes e identicamente distribuídos, com dimensão fixa e matriz de covariâncias finita, o Teorema Central do Limite multivariado estabelece a convergência da média amostral padronizada para uma distribuição normal multivariada (Vaart, 1998).

Teorema 12.2 (Teorema Central do Limite multivariado). *Considere, para uma dimensão fixa p , vetores aleatórios independentes e identicamente distribuídos*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p,$$

com

$$E(\mathbf{X}_i) = \mu$$

e matriz de covariâncias finita

$$\text{Cov}(\mathbf{X}_i) = \Sigma.$$

Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma). \quad (12.5)$$

Comprovação. Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

considere a combinação linear

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \mu).$$

As variáveis aleatórias

$$\mathbf{a}^\top \mathbf{X}_1, \dots, \mathbf{a}^\top \mathbf{X}_n$$

são independentes e identicamente distribuídas, com média

$$\mathbf{a}^\top \mu$$

e variância finita

$$\mathbf{a}^\top \Sigma \mathbf{a}.$$

Pelo Teorema Central do Limite univariado,

$$\sqrt{n} \mathbf{a}^\top (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Como essa convergência vale para toda combinação linear fixa, o princípio de Cramér–Wold fornece a convergência multivariada apresentada em Equação 12.5. $\square$

O teorema implica que, para amostras suficientemente grandes,

$$\bar{\mathbf{X}}$$

pode ser aproximado por uma distribuição

$$N_p \left(\mu, \frac{\Sigma}{n} \right). \quad (12.6)$$

A expressão em Equação 12.6 é exata sob normalidade populacional e assintótica sob as condições do Teorema 12.2.

Se

$$\Sigma \succ \mathbf{0},$$

a aplicação de uma transformação linear contínua em Equação 12.5 fornece

$$\sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p (\mathbf{0}, \mathbf{I}_p). \quad (12.7)$$

Pelo teorema da aplicação contínua,

$$n (\bar{\mathbf{X}} - \mu)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu) \xrightarrow{d} \chi_p^2. \quad (12.8)$$

Sob normalidade, Equação 12.3 é uma identidade distribucional exata. Sem normalidade, Equação 12.8 fornece uma aproximação assintótica.

Limites da aproximação assintótica

O Teorema Central do Limite multivariado apresentado nesta seção considera p fixo e exige a existência de uma matriz de covariâncias finita.

O aumento de n não corrige automaticamente:

- dependência entre unidades não incorporada ao modelo;
- inexistência de momentos de segunda ordem;
- observações extremamente influentes;
- crescimento da dimensão em ritmo comparável ao tamanho amostral;
- singularidade ou instabilidade de estimadores de covariância.

Essas situações exigem resultados ou procedimentos diferentes dos desenvolvidos pela inferência clássica.

A distribuição da média amostral descreve a incerteza associada à localização. Quando a matriz de covariâncias populacional é desconhecida, sua substituição por uma estatística amostral exige conhecer a distribuição dessa estatística e sua relação com a média amostral. A distribuição de Wishart fornece essa base.

12.2 Distribuição de Wishart

A inferência sobre a matriz de covariâncias depende da distribuição da SSCP amostral. No caso univariado, a soma de quadrados de variáveis normais padronizadas possui distribuição qui-quadrado. A distribuição de Wishart estende essa construção para somas de produtos externos de vetores normais e constitui a principal distribuição matricial da inferência normal multivariada (Muirhead, 1982).

12.2.1 Construção e parametrização

Considere vetores aleatórios independentes

$$\mathbf{Z}_1, \dots, \mathbf{Z}_\nu \in \mathbb{R}^p$$

tais que

$$\mathbf{Z}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 1, \dots, \nu,$$

em que

$$\Sigma \in \mathbb{R}^{p \times p}$$

é simétrica e positiva definida.

Cada produto externo

$$\mathbf{Z}_j \mathbf{Z}_j^\top$$

é uma matriz simétrica, semidefinida positiva e de posto igual a 1, exceto no evento de probabilidade zero em que o vetor é nulo.

Definição 12.2 (Distribuição de Wishart). Se

$$\mathbf{Z}_1, \dots, \mathbf{Z}_\nu \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma),$$

com $\nu \in \mathbb{N}$, a matriz aleatória

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{Z}_j \mathbf{Z}_j^\top \quad (12.9)$$

segue uma distribuição de Wishart com ν graus de liberdade e matriz de escala Σ .

Utiliza-se a notação

$$\mathbf{W} \sim W_p(\nu, \Sigma). \quad (12.10)$$

A parametrização adotada neste capítulo satisfaz

$$E(\mathbf{W}) = \nu \Sigma.$$

Por isso, Σ é denominada **matriz de escala**. A literatura também utiliza parametrizações baseadas na matriz de escala inversa ou em normalizações distintas. Assim, fórmulas de densidade, momentos e verossimilhança devem ser interpretadas de acordo com a parametrização declarada (Muirhead, 1982).

A distribuição qui-quadrado é recuperada quando

$$p = 1.$$

Nesse caso, se

$$\Sigma = [\sigma^2],$$

então

$$W = \sum_{j=1}^{\nu} Z_j^2$$

e

$$\frac{W}{\sigma^2} \sim \chi_\nu^2. \quad (12.11)$$

A distribuição de Wishart é, portanto, uma generalização matricial da distribuição qui-quadrado.

12.2.2 Suporte, posto e densidade

A matriz em Equação 12.9 pode ser escrita como

$$\mathbf{W} = \mathcal{Z}^\top \mathcal{Z}, \quad (12.12)$$

em que

$$\mathcal{Z} = \begin{bmatrix} \mathbf{Z}_1^\top \\ \vdots \\ \mathbf{Z}_\nu^\top \end{bmatrix} \in \mathbb{R}^{\nu \times p}.$$

Essa representação mostra que $\mathbf{W}$ é uma matriz de Gram. Logo,

$$\mathbf{W} \succeq \mathbf{0}$$

e

$$\text{posto}(\mathbf{W}) = \text{posto}(\mathcal{Z}) \leq \min(\nu, p).$$

Teorema 12.3 (Posto de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com $\nu \in \mathbb{N}$ e

$$\Sigma \succ \mathbf{0},$$

então, com probabilidade 1,

$$\text{posto}(\mathbf{W}) = \min(\nu, p). \quad (12.13)$$

Consequentemente:

- se $\nu \geq p$, então

$$\mathbf{W} \succ \mathbf{0}$$

com probabilidade 1;

- se $\nu < p$, então $\mathbf{W}$ é singular e possui posto ν com probabilidade 1.

A condição

$$\nu \geq p$$

é necessária para que a construção clássica produza uma matriz positiva definida.

Quando

$$\nu > p - 1$$

é um número real, a distribuição de Wishart não singular também pode ser definida diretamente por sua densidade no cone das matrizes simétricas positivas definidas.

Teorema 12.4 (Densidade da distribuição de Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

com

$$\nu > p - 1 \quad e \quad \Sigma \succ \mathbf{0},$$

sua densidade é

$$f_{\mathbf{W}}(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-p-1)/2} \exp \left[-\frac{1}{2} \text{tr}(\Sigma^{-1}\mathbf{W}) \right]}{2^{\nu p/2} |\Sigma|^{\nu/2} \Gamma_p(\nu/2)}, \quad (12.14)$$

para

$$\mathbf{W} \succ \mathbf{0},$$

e é igual a zero fora desse conjunto.

A função gama multivariada é

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad (12.15)$$

definida para

$$a > \frac{p-1}{2}.$$

Na construção por soma de vetores normais, ν é inteiro. Quando $\nu < p$, a matriz é singular e não possui densidade em relação à medida de Lebesgue no espaço das matrizes simétricas de dimensão

$$\frac{p(p+1)}{2}.$$

Nesse caso, a distribuição está concentrada no subconjunto de matrizes semidefinidas positivas com posto não superior a ν .

Duas formas de introduzir a distribuição

A construção

$$\mathbf{W} = \sum_{j=1}^{\nu} \mathbf{z}_j \mathbf{z}_j^{\top}$$

define a distribuição para graus de liberdade inteiros.

A densidade em Equação 12.14 estende a distribuição não singular para valores reais

$$\nu > p - 1.$$

No desenvolvimento das distribuições amostrais deste capítulo, os graus de liberdade surgirão como inteiros determinados pelo tamanho da amostra e pelo posto de matrizes de projeção.

12.2.3 Momentos e propriedades

A distribuição de Wishart preserva, em forma matricial, várias propriedades da distribuição qui-quadrado.

Teorema 12.5 (Momentos de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma),$$

então

$$E(\mathbf{W}) = \nu \Sigma. \quad (12.16)$$

Para os elementos

$$W_{jk} \quad \text{e} \quad W_{\ell m},$$

tem-se

$$\text{Cov}(W_{jk}, W_{\ell m}) = \nu (\sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}). \quad (12.17)$$

Comprovação. Pela construção em Equação 12.9,

$$W_{jk} = \sum_{h=1}^{\nu} Z_{hj} Z_{hk}.$$

Como

$$E(Z_{hj} Z_{hk}) = \sigma_{jk},$$

segue que

$$\begin{aligned} E(W_{jk}) &= \sum_{h=1}^{\nu} E(Z_{hj} Z_{hk}) \\ &= \nu \sigma_{jk}. \end{aligned}$$

A igualdade vale para todos os elementos, o que fornece

$$E(\mathbf{W}) = \nu \Sigma.$$

Para a covariância entre dois elementos, a independência dos vetores associados a índices h distintos elimina os termos cruzados. Para um vetor normal com média zero, a identidade dos momentos de quarta ordem fornece

$$E(\mathbf{Z}_j \mathbf{Z}_k \mathbf{Z}_\ell \mathbf{Z}_m) = \sigma_{jk} \sigma_{\ell m} + \sigma_{j\ell} \sigma_{km} + \sigma_{jm} \sigma_{k\ell}.$$

Subtraindo o produto das médias e somando as ν contribuições independentes, obtém-se Equação 12.17. $\square$

Em particular, para um elemento diagonal,

$$\text{Var}(W_{jj}) = 2\nu\sigma_{jj}^2. \quad (12.18)$$

Para um elemento fora da diagonal,

$$\text{Var}(W_{jk}) = \nu(\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2), \quad j \neq k. \quad (12.19)$$

A esperança cresce linearmente com ν , enquanto a variabilidade dos elementos também é proporcional aos graus de liberdade. A matriz média por grau de liberdade,

$$\frac{\mathbf{W}}{\nu},$$

possui esperança Σ e torna-se mais concentrada em torno dessa matriz à medida que ν cresce.

A propriedade qui-quadrado também vale para qualquer direção fixa.

Teorema 12.6 (Forma quadrática de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

e

$$\mathbf{a} \in \mathbb{R}^p$$

é não nulo, então

$$\frac{\mathbf{a}^\top \mathbf{W} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \sim \chi_\nu^2. \quad (12.20)$$

Comprovação. Pela construção da matriz Wishart,

$$\mathbf{a}^\top \mathbf{W} \mathbf{a} = \sum_{j=1}^{\nu} (\mathbf{a}^\top \mathbf{Z}_j)^2.$$

Cada combinação linear satisfaz

$$\mathbf{a}^\top \mathbf{Z}_j \sim N(0, \mathbf{a}^\top \Sigma \mathbf{a}).$$

Logo,

$$\frac{\mathbf{a}^\top \mathbf{Z}_j}{\sqrt{\mathbf{a}^\top \Sigma \mathbf{a}}} \sim N(0, 1).$$

A soma dos quadrados de ν variáveis normais padrão independentes possui distribuição χ_ν^2 . $\square$

A forma quadrática em Equação 12.20 mostra que a distribuição de Wishart reúne simultaneamente as distribuições das somas de quadrados de todas as combinações lineares dos vetores normais.

A soma de matrizes Wishart independentes com a mesma escala também permanece na família.

Teorema 12.7 (Aditividade da distribuição de Wishart). *Se*

$$\mathbf{W}_1 \sim W_p(\nu_1, \Sigma)$$

e

$$\mathbf{W}_2 \sim W_p(\nu_2, \Sigma)$$

são independentes, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\nu_1 + \nu_2, \Sigma). \quad (12.21)$$

A exigência de uma escala comum é necessária. A soma de matrizes Wishart independentes com escalas diferentes não possui, em geral, uma distribuição Wishart.

As transformações lineares produzem uma propriedade de equivariância.

Teorema 12.8 (Transformação linear de uma matriz Wishart). *Se*

$$\mathbf{W} \sim W_p(\nu, \Sigma)$$

e

$$\mathbf{A} \in \mathbb{R}^{r \times p}$$

é uma matriz fixa com posto linha completo r , então

$$\mathbf{A}\mathbf{W}\mathbf{A}^\top \sim W_r(\nu, \mathbf{A}\Sigma\mathbf{A}^\top). \quad (12.22)$$

Comprovação. Pela construção de Wishart,

$$\begin{aligned} \mathbf{A}\mathbf{W}\mathbf{A}^\top &= \mathbf{A} \left(\sum_{j=1}^{\nu} \mathbf{z}_j \mathbf{z}_j^\top \right) \mathbf{A}^\top \\ &= \sum_{j=1}^{\nu} (\mathbf{A}\mathbf{z}_j) (\mathbf{A}\mathbf{z}_j)^\top. \end{aligned}$$

Como

$$\mathbf{A}\mathbf{z}_j \sim N_r(\mathbf{0}, \mathbf{A}\Sigma\mathbf{A}^\top),$$

e esses vetores permanecem independentes, a soma possui a distribuição apresentada no enunciado. $\square$

O posto linha completo garante que

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

Se $\mathbf{A}$ tiver posto inferior a r , a matriz transformada continuará semidefinida positiva, mas sua distribuição será singular e ficará concentrada em um subespaço de menor dimensão.

Para uma matriz quadrada não singular $\mathbf{A}$,

$$\mathbf{A}\mathbf{W}\mathbf{A}^\top \sim W_p(\nu, \mathbf{A}\Sigma\mathbf{A}^\top).$$

Em particular, utilizando

$$\mathbf{A} = \Sigma^{-1/2},$$

obtém-se a padronização

$$\Sigma^{-1/2} \mathbf{W} \Sigma^{-1/2} \sim W_p(\nu, \mathbf{I}_p). \quad (12.23)$$

12.2.4 Distribuição da covariância amostral

No Capítulo 10, a SSCP amostral aleatória foi definida por

$$\mathbf{A} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^\top,$$

e a matriz de covariâncias amostral por

$$\mathbf{S} = \frac{\mathbf{A}}{n-1}.$$

A distribuição de Wishart descreve exatamente a variabilidade da SSCP sob amostragem normal.

Teorema 12.9 (Distribuição da SSCP e da covariância amostral). *Se*

$$\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2 \quad e \quad \Sigma \succ \mathbf{0},$$

então

$$\mathbf{A} = (n-1)\mathbf{S} \sim W_p(n-1, \Sigma). \quad (12.24)$$

Comprovação. Organize os vetores da amostra nas linhas da matriz aleatória

$$\mathcal{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Considere uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

cuja primeira linha seja

$$\frac{1}{\sqrt{n}} \mathbf{1}_n^\top.$$

Defina

$$\mathcal{Z} = \mathbf{Q}\mathcal{X}.$$

A primeira linha de $\mathcal{Z}$ é

$$\mathbf{z}_1^\top = \sqrt{n} \bar{\mathbf{x}}^\top.$$

As demais linhas correspondem a combinações lineares das observações cujos coeficientes somam zero. Portanto, elas possuem média nula.

Como $\mathbf{Q}$ é ortogonal, a transformação preserva a estrutura de covariâncias entre as linhas. Sob normalidade conjunta, as linhas transformadas são independentes, com

$$\mathbf{z}_j \sim N_p(\mathbf{0}, \Sigma), \quad j = 2, \dots, n.$$

A matriz de centralização pode ser escrita como

$$\mathbf{H}_n = \mathbf{Q}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ 0 & \mathbf{I}_{n-1} \end{bmatrix} \mathbf{Q}.$$

Logo,

$$\begin{aligned}
\mathbf{A} &= \mathcal{X}^\top \mathbf{H}_n \mathcal{X} \\
&= \mathcal{Z}^\top \begin{bmatrix} 0 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{I}_{n-1} \end{bmatrix} \mathcal{Z} \\
&= \sum_{j=2}^n \mathbf{z}_j \mathbf{z}_j^\top.
\end{aligned}$$

Essa é a soma de $n - 1$ produtos externos de vetores independentes com distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Portanto,

$$\mathbf{A} \sim W_p(n - 1, \Sigma).$$

□

A esperança da SSCP é

$$E(\mathbf{A}) = (n - 1)\Sigma.$$

Consequentemente,

$$E(\mathbf{S}) = \Sigma,$$

recuperando a ausência de viés estabelecida no Capítulo 10.

A distribuição de $\mathbf{S}$ pode ser expressa por

$$(n - 1)\mathbf{S} \sim W_p(n - 1, \Sigma),$$

ou, de maneira equivalente,

$$\mathbf{S} \sim \frac{1}{n - 1} W_p(n - 1, \Sigma).$$

A segunda notação representa uma matriz Wishart reescalada e não uma nova parametrização da família.

Para os elementos de $\mathbf{S}$,

$$\text{Cov}(\mathbf{S}_{jk}, \mathbf{S}_{\ell m}) = \frac{\sigma_{j\ell}\sigma_{km} + \sigma_{jm}\sigma_{k\ell}}{n-1}. \quad (12.25)$$

Em particular,

$$\text{Var}(\mathbf{S}_{jj}) = \frac{2\sigma_{jj}^2}{n-1}$$

e

$$\text{Var}(\mathbf{S}_{jk}) = \frac{\sigma_{jj}\sigma_{kk} + \sigma_{jk}^2}{n-1}, \quad j \neq k.$$

Essas expressões são exatas sob normalidade.

O posto da covariância amostral satisfaz, com probabilidade 1,

$$\text{posto}(\mathbf{S}) = \min(p, n-1). \quad (12.26)$$

Portanto:

- se

$$n-1 \geq p,$$

então $\mathbf{S}$ é positiva definida com probabilidade 1;

- se

$$p \geq n,$$

então $\mathbf{S}$ é singular com probabilidade 1.

A condição necessária para a utilização da inversa clássica de $\mathbf{S}$ é

$$n > p. \quad (12.27)$$

Essa condição aparecerá na distribuição exata da estatística T^2 de Hotelling.

12.2.5 Independência entre média e covariância

A transformação ortogonal utilizada na prova do Teorema 12.9 também separa a informação sobre a média da informação sobre a dispersão.

A primeira linha da matriz transformada depende exclusivamente de

$$\bar{\mathbf{X}},$$

enquanto as demais linhas determinam

$$\mathbf{A}$$

e

$$\mathbf{S}.$$

Sob normalidade, essas linhas são independentes.

Teorema 12.10 (Independência entre média e covariância amostral). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$n \geq 2 \quad e \quad \Sigma \succ \mathbf{0},$$

então

$$\bar{\mathbf{X}} \perp \mathbf{A}.$$

Como

$$\mathbf{S} = \frac{\mathbf{A}}{n-1},$$

também se tem

$$\bar{\mathbf{X}} \perp \mathbf{S}. \tag{12.28}$$

Comprovação. Na transformação utilizada na prova do Teorema 12.9, a primeira linha é

$$\mathbf{Z}_1^\top = \sqrt{n} \bar{\mathbf{X}}^\top.$$

A SSCP é função apenas das demais linhas:

$$\mathbf{A} = \sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j^\top.$$

As linhas

$$\mathbf{Z}_1, \dots, \mathbf{Z}_n$$

são conjuntamente normais. A ortogonalidade da transformação produz covariâncias cruzadas nulas entre linhas distintas e, sob normalidade conjunta, covariância nula implica independência.

Assim,

$$\mathbf{Z}_1 \perp (\mathbf{Z}_2, \dots, \mathbf{Z}_n).$$

Como $\bar{\mathbf{X}}$ é função de $\mathbf{Z}_1$ e $\mathbf{A}$ é função das demais linhas, conclui-se que

$$\bar{\mathbf{X}} \perp \mathbf{A}.$$

A independência entre $\bar{\mathbf{X}}$ e $\mathbf{S}$ decorre do fato de $\mathbf{S}$ ser uma transformação determinística de $\mathbf{A}$. $\square$

A independência em Equação 12.28 é um resultado exato e depende da normalidade multivariada. Para uma população geral, mesmo quando as observações são independentes e possuem momentos finitos,

$$\bar{\mathbf{X}}$$

e

$$\mathbf{S}$$

não são, em geral, independentes.

Papel da normalidade

As identidades

$$E(\bar{\mathbf{X}}) = \mu$$

e

$$E(\mathbf{S}) = \Sigma$$

não exigem normalidade.

Em contraste, os resultados

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}$$

são propriedades da amostragem normal. Sem essa hipótese, a distribuição exata da covariância amostral depende de momentos de ordem superior e da distribuição conjunta da população.

A distribuição da média, a distribuição de Wishart da SSCP e a independência entre esses dois objetos fornecem a base para substituir Σ por $\mathbf{S}$ em procedimentos inferenciais exatos. A mesma estrutura aparecerá no modelo linear multivariado, com a média amostral substituída pelo estimador da matriz de parâmetros e os $n-1$ graus de liberdade substituídos pelos graus de liberdade residuais.

12.3 Distribuições no modelo linear multivariado

O Capítulo 11 formulou o modelo linear multivariado, construiu os estimadores, os resíduos e as matrizes de somas de quadrados e produtos cruzados. Sob o modelo normal matricial, esses objetos possuem distribuições normais matriciais ou de Wishart, e a ortogonalidade entre as projeções permite estabelecer independências utilizadas na inferência exata (Anderson, 2003).

Considere

$$\mathbf{y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

em que

$$\mathbf{y} \in \mathbb{R}^{n \times p}, \quad \mathbf{Z} \in \mathbb{R}^{n \times q}, \quad \mathbf{B} \in \mathbb{R}^{q \times p},$$

e

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma),$$

com

$$\Sigma \succ \mathbf{0}.$$

Equivalentemente,

$$\mathcal{Y} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{ZB}, \mathbf{I}_n, \Sigma). \quad (12.29)$$

A matriz de delineamento é tratada como fixa ou condicionada nos valores observados. Defina

$$r = \text{posto}(\mathbf{Z}) \leq q,$$

$$\mathbf{P}_Z = \mathbf{Z}\mathbf{Z}^+$$

e

$$\mathbf{M}_Z = \mathbf{I}_n - \mathbf{P}_Z.$$

As distribuições desta seção são condicionais a $\mathbf{Z}$. Essa indicação será mantida nos resultados principais.

12.3.1 Distribuição do estimador da matriz de parâmetros

Quando

$$r = q,$$

a matriz de parâmetros é identificada e o estimador de mínimos quadrados é

$$\widehat{\mathbf{B}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{Y}.$$

Substituindo o modelo,

$$\widehat{\mathbf{B}} = \mathbf{B} + (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathcal{E}. \quad (12.30)$$

A segunda parcela é uma transformação linear da matriz normal de erros.

Teorema 12.11 (Distribuição do estimador da matriz de parâmetros). *Sob o modelo normal matricial e a condição*

$$\text{posto}(\mathbf{Z}) = q,$$

tem-se

$$\widehat{\mathbf{B}} \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{B}, (\mathbf{Z}^\top \mathbf{Z})^{-1}, \Sigma \right]. \quad (12.31)$$

Equivalentemente,

$$\text{vec}(\widehat{\mathbf{B}}) \mid \mathbf{Z} \sim N_{pq} \left[\text{vec}(\mathbf{B}), \Sigma \otimes (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]. \quad (12.32)$$

Comprovação. Defina

$$\mathbf{A}_Z = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top.$$

Pela Equação 12.30,

$$\widehat{\mathbf{B}} = \mathbf{B} + \mathbf{A}_Z \mathcal{E}.$$

A propriedade de transformação da distribuição normal matricial fornece

$$\mathbf{A}_Z \mathcal{E} \mid \mathbf{Z} \sim N_{q \times p}(\mathbf{0}, \mathbf{A}_Z \mathbf{A}_Z^\top, \Sigma).$$

Como

$$\begin{aligned} \mathbf{A}_Z \mathbf{A}_Z^\top &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1}, \end{aligned}$$

obtém-se a distribuição matricial do enunciado. A forma vetorizada decorre da definição da distribuição normal matricial. $\square$

Para os elementos do estimador,

$$\text{Cov}(\widehat{B}_{hj}, \widehat{B}_{\ell k} \mid \mathbf{Z}) = \left[(\mathbf{Z}^\top \mathbf{Z})^{-1} \right]_{h\ell} \sigma_{jk}. \quad (12.33)$$

A covariância entre dois coeficientes estimados combina:

- a relação entre os termos do delineamento;
- a covariância residual entre as respostas.

Quando a matriz de delineamento possui posto deficiente, a matriz $\mathbf{B}$ não é identificada de forma única. A pseudoinversa produz o representante

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y},$$

cuja distribuição é

$$\widehat{\mathbf{B}}_0 \mid \mathbf{Z} \sim N_{q \times p} \left[\mathbf{Z}^+ \mathbf{Z} \mathbf{B}, \mathbf{Z}^+ (\mathbf{Z}^+)^{\top}, \Sigma \right]. \quad (12.34)$$

A média dessa distribuição é

$$\mathbf{Z}^+ \mathbf{Z} \mathbf{B},$$

e não necessariamente $\mathbf{B}$. Esse resultado reflete a não identificação dos componentes de $\mathbf{B}$ pertencentes ao núcleo de $\mathbf{Z}$.

A inferência deve ser formulada sobre funções estimáveis.

Considere

$$\mathbf{C} \in \mathbb{R}^{g \times q}$$

satisfazendo

$$\mathbf{C} = \mathbf{C} \mathbf{Z}^+ \mathbf{Z}, \quad (12.35)$$

e uma matriz fixa

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

A função paramétrica bilateral é

$$\Theta = \mathbf{CBM} \in \mathbb{R}^{g \times s}.$$

Seu estimador é

$$\widehat{\Theta} = \mathbf{CZ}^+ \mathbf{yM}. \quad (12.36)$$

Defina

$$\mathbf{G}_C = \mathbf{CZ}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}^{\top} \in \mathbb{R}^{g \times g} \quad (12.37)$$

e

$$\Sigma_M = \mathbf{M}^{\top} \Sigma \mathbf{M} \in \mathbb{R}^{s \times s}. \quad (12.38)$$

Teorema 12.12 (Distribuição de uma função estimável). *Sob o modelo normal matricial, se*

$$\mathbf{C} = \mathbf{CZ}^+ \mathbf{Z},$$

então

$$\widehat{\Theta} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{CBM}, \mathbf{G}_C, \Sigma_M). \quad (12.39)$$

Equivalentemente,

$$\text{vec}(\widehat{\Theta}) \mid \mathbf{Z} \sim N_{gs}[\text{vec}(\mathbf{CBM}), \Sigma_M \otimes \mathbf{G}_C]. \quad (12.40)$$

Comprovação. Substituindo o modelo em Equação 12.36,

$$\begin{aligned} \widehat{\Theta} &= \mathbf{CZ}^+ (\mathbf{ZB} + \mathcal{E}) \mathbf{M} \\ &= \mathbf{CZ}^+ \mathbf{ZBM} + \mathbf{CZ}^+ \mathcal{E} \mathbf{M}. \end{aligned}$$

Pela condição de estimabilidade,

$$\mathbf{CZ}^+ \mathbf{Z} = \mathbf{C}.$$

Logo,

$$\widehat{\Theta} = \mathbf{CBM} + \mathbf{CZ}^+ \mathcal{E}\mathbf{M}.$$

Aplicando a propriedade de transformação da normal matricial,

$$\mathbf{CZ}^+ \mathcal{E}\mathbf{M} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{G}_C, \Sigma_M),$$

o que fornece o resultado. □

Se as linhas de $\mathbf{C}$ representam funções estimáveis linearmente independentes, então

$$\mathbf{G}_C \succ \mathbf{0}.$$

Se $\mathbf{M}$ possui posto coluna completo e

$$\Sigma \succ \mathbf{0},$$

então

$$\Sigma_M \succ \mathbf{0}.$$

Restrições redundantes ou combinações redundantes das respostas produzem distribuições normais singulares. Nesse caso, a hipótese deve ser reescrita utilizando bases dos espaços correspondentes.

Sob posto coluna completo de $\mathbf{Z}$,

$$\mathbf{Z}^+ = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top$$

e

$$\mathbf{G}_C = \mathbf{C} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top.$$

Assim, o resultado geral recupera a distribuição usual de contrastes do modelo de posto completo.

12.3.2 Distribuição da SSCP residual

A matriz aleatória de resíduos é

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathbf{y}.$$

Como

$$\mathbf{M}_Z \mathbf{Z} = \mathbf{0},$$

tem-se

$$\widehat{\mathbf{u}} = \mathbf{M}_Z \mathcal{E}. \quad (12.41)$$

Pela transformação da distribuição normal matricial,

$$\widehat{\mathbf{u}} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{M}_Z, \Sigma). \quad (12.42)$$

Essa distribuição é singular sempre que

$$r > 0,$$

pois

$$\text{posto}(\mathbf{M}_Z) = n - r < n.$$

A SSCP residual aleatória é

$$\mathbf{E}_{\text{res}} = \widehat{\mathbf{u}}^\top \widehat{\mathbf{u}} = \mathbf{y}^\top \mathbf{M}_Z \mathbf{y}. \quad (12.43)$$

Para a matriz observada de respostas,

$$\mathbf{E} = \mathbf{Y}^\top \mathbf{M}_Z \mathbf{Y}.$$

Teorema 12.13 (Distribuição da SSCP residual). *Sob o modelo linear normal multivariado,*

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.44)$$

Consequentemente,

$$E(\mathbf{E}_{\text{res}} \mid \mathbf{Z}) = (n - r)\Sigma. \quad (12.45)$$

Comprovação. Como $\mathbf{M}_Z$ é um projetor ortogonal de posto $n - r$, existe uma matriz ortogonal

$$\mathbf{Q} \in \mathbb{R}^{n \times n}$$

tal que

$$\mathbf{M}_Z = \mathbf{Q}^\top \begin{bmatrix} \mathbf{I}_{n-r} & \mathbf{0} \\ \mathbf{0} & \mathbf{0}_r \end{bmatrix} \mathbf{Q}.$$

Defina

$$\mathcal{A} = \mathbf{Q}\mathcal{E}.$$

Como $\mathbf{Q}$ é ortogonal,

$$\mathcal{A} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma).$$

Portanto, suas linhas

$$\mathbf{A}_1, \dots, \mathbf{A}_n$$

são independentes e possuem distribuição

$$N_p(\mathbf{0}, \Sigma).$$

Além disso,

$$\begin{aligned}
\mathbf{E}_{\text{res}} &= \mathcal{E}^\top \mathbf{M}_Z \mathcal{E} \\
&= \mathcal{A}^\top \begin{bmatrix} \mathbf{I}_{n-r} & \mathbf{0} \\ \mathbf{0} & \mathbf{0}_r \end{bmatrix} \mathcal{A} \\
&= \sum_{j=1}^{n-r} \mathbf{A}_j \mathbf{A}_j^\top.
\end{aligned}$$

Essa é a construção de uma matriz Wishart com $n - r$ graus de liberdade e matriz de escala Σ . $\square$

O estimador não viesado da matriz de covariâncias residual é

$$\widehat{\Sigma} = \frac{\mathbf{E}_{\text{res}}}{n - r},$$

quando

$$n - r > 0.$$

Sua distribuição pode ser expressa por

$$(n - r)\widehat{\Sigma} \mid \mathbf{Z} \sim W_p(n - r, \Sigma). \quad (12.46)$$

Para qualquer vetor não nulo

$$\mathbf{a} \in \mathbb{R}^p,$$

segue da propriedade direcional da Wishart que

$$\frac{(n - r)\mathbf{a}^\top \widehat{\Sigma} \mathbf{a}}{\mathbf{a}^\top \Sigma \mathbf{a}} \mid \mathbf{Z} \sim \chi_{n-r}^2. \quad (12.47)$$

Essa expressão descreve a distribuição exata da variância residual estimada para qualquer combinação linear das respostas.

O posto da SSCP residual satisfaz, com probabilidade 1,

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r). \quad (12.48)$$

Portanto, a condição necessária e suficiente, com probabilidade 1 sob o modelo normal não singular, para que

$$\mathbf{E}_{\text{res}} \succ \mathbf{0}$$

é

$$n - r \geq p. \quad (12.49)$$

Quando

$$p > n - r,$$

a SSCP residual e o estimador de covariâncias são necessariamente singulares.

12.3.3 Independência entre estimador e resíduo

A distribuição exata dos procedimentos inferenciais depende da separação entre:

- a informação utilizada para estimar as funções paramétricas;
- a informação residual utilizada para estimar Σ .

Essa separação é produzida por projeções ortogonais.

Considere o representante de mínimos quadrados obtido pela pseudoinversa:

$$\widehat{\mathbf{B}}_0 = \mathbf{Z}^+ \mathbf{y}.$$

Seu erro em relação ao representante populacional correspondente é

$$\widehat{\mathbf{B}}_0 - \mathbf{Z}^+ \mathbf{Z} \mathbf{B} = \mathbf{Z}^+ \mathcal{E}.$$

A matriz residual é

$$\widehat{\mathcal{U}} = \mathbf{M}_Z \mathcal{E}.$$

As transformações aplicadas às linhas dos erros satisfazem

$$\mathbf{Z}^+ \mathbf{M}_Z = \mathbf{0}. \quad (12.50)$$

Teorema 12.14 (Independência entre estimador e resíduo). *Sob o modelo linear normal multivariado,*

$$\widehat{\mathbf{B}}_0 \perp \widehat{\mathbf{U}} \mid \mathbf{Z}. \quad (12.51)$$

Consequentemente,

$$\widehat{\mathbf{B}}_0 \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.52)$$

Para qualquer função estimável,

$$\widehat{\boldsymbol{\theta}} = \mathbf{C}\widehat{\mathbf{B}}_0\mathbf{M},$$

tem-se

$$\widehat{\boldsymbol{\theta}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.53)$$

Comprovação. As matrizes

$$\mathbf{Z}^+\mathcal{E}$$

e

$$\mathbf{M}_Z\mathcal{E}$$

são transformações lineares da mesma matriz normal. Portanto, são conjuntamente normais.

A covariância cruzada entre suas linhas é determinada por

$$\mathbf{Z}^+\mathbf{I}_n\mathbf{M}_Z^\top.$$

Como $\mathbf{M}_Z$ é simétrica e

$$\begin{aligned} \mathbf{Z}^+\mathbf{M}_Z &= \mathbf{Z}^+(\mathbf{I}_n - \mathbf{Z}\mathbf{Z}^+) \\ &= \mathbf{Z}^+ - \mathbf{Z}^+\mathbf{Z}\mathbf{Z}^+ \\ &= \mathbf{0}, \end{aligned}$$

a covariância cruzada é nula.

Sob normalidade conjunta, covariância cruzada nula implica independência. Logo,

$$\mathbf{Z}^+ \mathcal{E} \perp \mathbf{M}_Z \mathcal{E}.$$

A adição da matriz não aleatória

$$\mathbf{Z}^+ \mathbf{Z} \mathbf{B}$$

não altera a independência. Como a SSCP residual é uma função de $\widehat{\mathcal{U}}$, conclui-se também a independência entre o estimador e a SSCP. $\square$

Sob posto coluna completo,

$$\widehat{\mathbf{B}}_0 = \widehat{\mathbf{B}},$$

e o resultado reduz-se a

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z}. \quad (12.54)$$

Essa propriedade generaliza a independência entre a média e a covariância amostrais. No modelo contendo somente intercepto,

$$\widehat{\mathbf{B}} = \bar{\mathbf{X}}^\top$$

e

$$\mathbf{E}_{\text{res}} = (n-1)\mathbf{S}.$$

A independência não decorre apenas da ortogonalidade algébrica das projeções. A passagem de covariância cruzada nula para independência utiliza a normalidade conjunta dos erros.

12.3.4 Distribuição da SSCP da hipótese

Considere a hipótese linear bilateral

$$H_0 : \mathbf{CBM} = \Theta_0, \quad (12.55)$$

em que

$$\mathbf{C} \in \mathbb{R}^{g \times q}, \quad \mathbf{M} \in \mathbb{R}^{p \times s}, \quad \Theta_0 \in \mathbb{R}^{g \times s}.$$

Suponha que:

$$\mathbf{C} = \mathbf{CZ}^+\mathbf{Z};$$

as linhas de $\mathbf{C}$ representem g funções estimáveis linearmente independentes; e $\mathbf{M}$ possua posto coluna completo s .

Nessas condições,

$$\mathbf{G}_C = \mathbf{CZ}^+(\mathbf{Z}^+)^{\top} \mathbf{C}^{\top} \succ \mathbf{0}$$

e

$$\Sigma_M = \mathbf{M}^{\top} \Sigma \mathbf{M} \succ \mathbf{0}.$$

Defina a matriz aleatória de discrepâncias:

$$\mathcal{D} = \mathbf{CZ}^+\mathbf{Y}\mathbf{M} - \Theta_0. \quad (12.56)$$

Para os dados observados, sua realização é

$$\widehat{\Delta} = \mathbf{CZ}^+\mathbf{Y}\mathbf{M} - \Theta_0.$$

A SSCP aleatória da hipótese é

$$\mathbf{H} = \mathcal{D}^{\top} \mathbf{G}_C^{-1} \mathcal{D}. \quad (12.57)$$

Sua realização observada é a matriz definida no Capítulo 11:

$$\mathbf{H} = \widehat{\Delta}^{\top} \mathbf{G}_C^{-1} \widehat{\Delta}.$$

Sob a hipótese nula,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{G}_C, \Sigma_M). \quad (12.58)$$

Teorema 12.15 (Distribuição da SSCP da hipótese). *Considere o modelo linear normal multivariado*

$$\mathcal{Y} = \mathbf{Z}\mathbf{B} + \mathcal{E},$$

com

$$\mathcal{E} \mid \mathbf{Z} \sim N_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma), \quad \Sigma \succ \mathbf{0},$$

e defina

$$r = \text{posto}(\mathbf{Z}), \quad n - r \geq 1.$$

Considere a hipótese

$$H_0 : \mathbf{CBM} = \Theta_0,$$

em que

$$\mathbf{C} \in \mathbb{R}^{g \times q}, \quad \mathbf{M} \in \mathbb{R}^{p \times s}, \quad \Theta_0 \in \mathbb{R}^{g \times s}.$$

Suponha que

$$\mathbf{C} = \mathbf{C}\mathbf{Z}^+\mathbf{Z},$$

$$\text{posto}(\mathbf{C}) = g$$

e

$$\text{posto}(\mathbf{M}) = s.$$

Defina

$$\mathbf{G}_C = \mathbf{C}\mathbf{Z}^+ (\mathbf{Z}^+)^{\top} \mathbf{C}^{\top}$$

e

$$\Sigma_M = \mathbf{M}^{\top} \Sigma \mathbf{M}.$$

Sob H_0 , a SSCP da hipótese satisfaz

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_M). \quad (12.59)$$

A SSCP residual transformada,

$$\mathbf{E}_M = \mathbf{M}^{\top} \mathbf{E}_{\text{res}} \mathbf{M}, \quad (12.60)$$

satisfaz

$$\mathbf{E}_M \mid \mathbf{Z} \sim W_s(n - r, \Sigma_M). \quad (12.61)$$

Além disso,

$$\mathbf{H} \perp \mathbf{E}_M \mid \mathbf{Z}. \quad (12.62)$$

Comprovação. Sob H_0 ,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{G}_C, \Sigma_M).$$

Padronizando as linhas,

$$\mathbf{G}_C^{-1/2} \mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\mathbf{0}, \mathbf{I}_g, \Sigma_M).$$

As g linhas da matriz padronizada são independentes e possuem distribuição

$$N_s(\mathbf{0}, \Sigma_M).$$

Como

$$\begin{aligned}\mathbf{H} &= \mathcal{D}^\top \mathbf{G}_C^{-1} \mathcal{D} \\ &= \left(\mathbf{G}_C^{-1/2} \mathcal{D} \right)^\top \left(\mathbf{G}_C^{-1/2} \mathcal{D} \right),\end{aligned}$$

a matriz possui distribuição

$$W_s(g, \Sigma_M).$$

Pela propriedade de transformação da Wishart,

$$\begin{aligned}\mathbf{E}_M &= \mathbf{M}^\top \mathbf{E}_{\text{res}} \mathbf{M} \\ &\sim W_s(n - r, \mathbf{M}^\top \Sigma \mathbf{M}).\end{aligned}$$

Por fim, $\mathbf{H}$ é função de

$$\widehat{\Theta} = \mathbf{C} \mathbf{Z}^+ y \mathbf{M},$$

enquanto $\mathbf{E}_M$ é função da matriz residual. A independência estabelecida no Teorema [12.14](#) fornece o último resultado. $\square$

O par de distribuições pode ser resumido por

$$\mathbf{H} \mid \mathbf{Z} \sim W_s(g, \Sigma_M),$$

$$\mathbf{E}_M \mid \mathbf{Z} \sim W_s(n - r, \Sigma_M),$$

com

$$\mathbf{H} \perp \mathbf{E}_M \mid \mathbf{Z}. \tag{12.63}$$

As duas matrizes possuem a mesma escala Σ_M , mas graus de liberdade distintos:

- g corresponde ao número de restrições paramétricas independentes;
- $n - r$ corresponde aos graus de liberdade residuais.

Essa estrutura constitui a base probabilística dos testes multivariados no modelo linear.

Sob a hipótese alternativa, defina a discrepância populacional

$$\Delta_0 = \mathbf{CBM} - \Theta_0. \quad (12.64)$$

Nesse caso,

$$\mathcal{D} \mid \mathbf{Z} \sim N_{g \times s}(\Delta_0, \mathbf{G}_C, \Sigma_M).$$

A matriz $\mathbf{H}$ possui uma distribuição de Wishart não central. Na parametrização baseada no branqueamento das respostas, sua matriz de não centralidade é

$$\Omega = \Sigma_M^{-1/2} \Delta_0^\top \mathbf{G}_C^{-1} \Delta_0 \Sigma_M^{-1/2}. \quad (12.65)$$

A matriz Ω é simétrica e semidefinida positiva. Ela mede o afastamento da hipótese nula depois de considerar:

- a precisão das combinações paramétricas, por meio de $\mathbf{G}_C^{-1}$;
- a escala e a dependência entre as respostas transformadas, por meio de $\Sigma_M^{-1/2}$.

A esperança da SSCP da hipótese sob a alternativa é

$$E(\mathbf{H} \mid \mathbf{Z}) = g\Sigma_M + \Delta_0^\top \mathbf{G}_C^{-1} \Delta_0. \quad (12.66)$$

Sob H_0 ,

$$\Delta_0 = \mathbf{0}$$

e

$$\Omega = \mathbf{0},$$

recuperando a distribuição Wishart central.

A matriz de não centralidade será utilizada para interpretar o poder dos testes. Quanto maior o afastamento padronizado em relação à hipótese nula, maior tende a ser a separação entre as distribuições da estatística sob H_0 e sob a alternativa.

As distribuições obtidas nesta seção são resultados exatos do modelo normal matricial. Elas fornecem a base para construir testes a partir das matrizes de hipótese e erro. A próxima seção introduzirá nível de significância, poder, não centralidade e razão de verossimilhanças antes de aplicar esses princípios à inferência sobre vetores de médias.

12.4 Princípios de testes multivariados

Um teste de hipóteses utiliza a informação amostral para avaliar uma afirmação sobre um parâmetro populacional. No contexto multivariado, essa afirmação pode envolver:

- um vetor de médias;
- uma matriz de covariâncias;
- a matriz de parâmetros de um modelo linear;
- uma função estimável dos parâmetros;
- várias combinações das respostas simultaneamente.

A construção de um teste exige especificar as hipóteses, definir uma estatística e uma região crítica e determinar sua distribuição sob a hipótese nula. O nível controla a probabilidade de rejeição indevida dentro do espaço nulo, enquanto o poder descreve a probabilidade de rejeição sob alternativas (Casella; Berger, 2002).

12.4.1 Hipóteses, nível, poder e não centralidade

Considere um modelo estatístico indexado por um parâmetro

$$\vartheta \in \mathcal{P},$$

em que $\mathcal{P}$ é o espaço paramétrico. As hipóteses podem ser escritas como

$$H_0 : \vartheta \in \mathcal{P}_0$$

e

$$H_1 : \vartheta \in \mathcal{P}_1,$$

com

$$\mathcal{P}_0 \cap \mathcal{P}_1 = \emptyset$$

e, em geral,

$$\mathcal{P}_1 = \mathcal{P} \setminus \mathcal{P}_0.$$

Uma hipótese é **simples** quando especifica completamente o parâmetro. Por exemplo,

$$H_0 : \mu = \mu_0.$$

Uma hipótese é **composta** quando admite mais de um valor do parâmetro. No modelo linear multivariado, a hipótese

$$H_0 : \mathbf{CBM} = \Theta_0$$

é geralmente composta porque não especifica todos os elementos de $\mathbf{B}$ e de Σ .

Uma regra de teste pode ser definida por uma região crítica

$$\mathcal{R},$$

formada pelos resultados amostrais que conduzem à rejeição de H_0 .

Se $\mathcal{X}$ representa os dados aleatórios, a função de teste não aleatorizada é

$$\varphi(\mathcal{X}) = \begin{cases} 1, & \mathcal{X} \in \mathcal{R}, \\ 0, & \mathcal{X} \notin \mathcal{R}. \end{cases} \quad (12.67)$$

O valor 1 representa a rejeição da hipótese nula, enquanto o valor 0 representa sua não rejeição.

Definição 12.3 (Tamanho e nível de significância). O **tamanho** de um teste é

$$\sup_{\vartheta \in \mathcal{P}_0} P_{\vartheta} [\varphi(\mathcal{X}) = 1]. \quad (12.68)$$

O teste possui **nível de significância** α quando

$$\sup_{\vartheta \in \mathcal{P}_0} P_{\vartheta} [\varphi(\mathcal{X}) = 1] \leq \alpha. \quad (12.69)$$

A rejeição de uma hipótese nula verdadeira constitui o erro do tipo I. O nível α limita a maior probabilidade desse erro entre os valores do parâmetro permitidos por H_0 .

Quando a probabilidade de rejeição é exatamente α para algum valor ou para todos os valores relevantes sob H_0 , diz-se que o teste possui tamanho α .

Valores frequentemente adotados são

$$\alpha = 0,10, \quad \alpha = 0,05$$

e

$$\alpha = 0,01.$$

A escolha deve ser realizada antes da observação dos resultados e considerar as consequências de uma rejeição incorreta.

Quando H_0 é falsa, a não rejeição constitui o erro do tipo II.

Definição 12.4 (Função poder). A função poder de um teste é

$$\pi(\vartheta) = P_{\vartheta}[\varphi(\mathcal{X}) = 1]. \quad (12.70)$$

Para

$$\vartheta \in \mathcal{P}_1,$$

a probabilidade do erro do tipo II é

$$\beta(\vartheta) = 1 - \pi(\vartheta). \quad (12.71)$$

Um teste de nível α satisfaz

$$\pi(\vartheta) \leq \alpha, \quad \vartheta \in \mathcal{P}_0.$$

Sob a hipótese alternativa, são desejáveis valores elevados de

$$\pi(\vartheta).$$

O nível controla a probabilidade de rejeição incorreta. O poder descreve a capacidade de detectar desvios em relação à hipótese nula. Um teste pode controlar adequadamente o erro do tipo I e, ao mesmo tempo, possuir baixo poder para alternativas próximas.

12.4.1.1 Não centralidade

Sob a hipótese nula, muitas estatísticas possuem distribuições centrais, como:

$$\chi^2, \quad F$$

ou Wishart central.

Sob a hipótese alternativa, as mesmas estatísticas podem possuir distribuições não centrais. O parâmetro de não centralidade quantifica o afastamento da hipótese nula na escala determinada pela variabilidade do problema.

Considere, por exemplo, a hipótese

$$H_0 : \mu = \mu_0$$

para uma população com matriz de covariâncias conhecida e positiva definida.

A distância quadrática entre o vetor verdadeiro e o valor especificado é

$$\delta^2 = (\mu - \mu_0)^\top \Sigma^{-1} (\mu - \mu_0). \quad (12.72)$$

Para uma amostra de tamanho n , o parâmetro de não centralidade é

$$\lambda = n\delta^2 = n (\mu - \mu_0)^\top \Sigma^{-1} (\mu - \mu_0). \quad (12.73)$$

Sob H_0 ,

$$\lambda = 0.$$

Sob uma alternativa diferente de μ_0 ,

$$\lambda > 0.$$

A não centralidade aumenta quando:

- o tamanho amostral cresce;
- o afastamento entre os parâmetros cresce;
- a variabilidade diminui nas direções em que ocorre o afastamento.

A matriz

$$\Omega = \Sigma_M^{-1/2} \Delta_0^\top \mathbf{G}_C^{-1} \Delta_0 \Sigma_M^{-1/2},$$

definida na seção anterior, exerce função análoga para a hipótese linear multivariada. No problema escalar, a não centralidade é um número. Em hipóteses matriciais, o afastamento pode ser representado por uma matriz semidefinida positiva.

O poder não aumenta necessariamente com a inclusão de novas respostas. Variáveis que acrescentam informação sobre a diferença investigada podem elevar a não centralidade. Variáveis pouco informativas aumentam a dimensão e exigem a estimação de novas variâncias e covariâncias.

A matriz de covariâncias de p respostas possui

$$\frac{p(p+1)}{2}$$

elementos distintos. Por isso, o crescimento de p sem aumento correspondente de n pode reduzir a precisão, prejudicar o poder e impedir a inversão das matrizes necessárias aos procedimentos clássicos.

12.4.1.2 Teste global e testes marginais

Uma hipótese vetorial como

$$H_0 : \mu = \mu_0$$

representa uma única afirmação global. Realizar separadamente os testes

$$H_{0j} : \mu_j = \mu_{0j}, \quad j = 1, \dots, p,$$

todos com nível α , não garante que a probabilidade de pelo menos uma rejeição incorreta seja igual a α .

Se os testes forem independentes, essa probabilidade será

$$1 - (1 - \alpha)^p. \tag{12.74}$$

Para

$$p = 5$$

e

$$\alpha = 0,05,$$

obtém-se

$$1 - (1 - 0,05)^5 = 1 - 0,95^5 \approx 0,226.$$

Nesse caso, a probabilidade de pelo menos uma rejeição incorreta é aproximadamente

$$22,6\%.$$

Quando os testes são dependentes, Equação 12.74 não se aplica diretamente. A realização de vários testes marginais também não controla automaticamente o nível global.

Testes marginais não substituem o teste global

Um teste multivariado considera conjuntamente a hipótese e a estrutura de covariâncias entre as respostas.

A rejeição da hipótese global não identifica automaticamente quais componentes ou combinações são responsáveis pelo resultado. Essa identificação exige procedimentos posteriores, como contrastes ou intervalos simultâneos, com controle adequado da multiplicidade.

12.4.1.3 Valor-p e decisão

Considere uma estatística T para a qual valores elevados fornecem evidência contra H_0 . O valor-p observado é

$$p_{\text{obs}} = P_{H_0}(T \geq t_{\text{obs}}). \quad (12.75)$$

A regra usual é

$$\begin{cases} \text{rejeitar } H_0, & p_{\text{obs}} \leq \alpha, \\ \text{não rejeitar } H_0, & p_{\text{obs}} > \alpha. \end{cases}$$

Não rejeitar H_0 não demonstra que a hipótese seja verdadeira. A decisão indica que os dados não produziram evidência suficiente para rejeitá-la no nível adotado.

O valor-p também não mede:

- o tamanho do efeito;
- a relevância prática da diferença;
- a probabilidade de H_0 ser verdadeira;
- o poder do teste.

A interpretação deve considerar as estimativas, as regiões de confiança, o tamanho amostral e o contexto substantivo.

12.4.2 Razão de verossimilhanças

A razão de verossimilhanças compara a verossimilhança maximizada sob a hipótese nula com a verossimilhança maximizada no espaço paramétrico completo. Valores pequenos indicam que a restrição imposta por H_0 reduz substancialmente o melhor ajuste alcançável pelo modelo (Casella; Berger, 2002).

Considere a verossimilhança

$$L(\vartheta; \mathbf{y}),$$

com

$$\vartheta \in \mathcal{P},$$

e a hipótese

$$H_0 : \vartheta \in \mathcal{P}_0, \quad \mathcal{P}_0 \subseteq \mathcal{P}.$$

Defina o estimador irrestrito por

$$\hat{\vartheta} = \arg \max_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})$$

e o estimador restrito por

$$\tilde{\vartheta} = \arg \max_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y}).$$

Definição 12.5 (Estatística da razão de verossimilhanças). A estatística da razão de verossimilhanças é

$$\Lambda_{\text{RV}} = \frac{\sup_{\vartheta \in \mathcal{P}_0} L(\vartheta; \mathbf{y})}{\sup_{\vartheta \in \mathcal{P}} L(\vartheta; \mathbf{y})}. \quad (12.76)$$

Quando os máximos são atingidos,

$$\Lambda_{\text{RV}} = \frac{L(\tilde{\vartheta}; \mathbf{y})}{L(\hat{\vartheta}; \mathbf{y})}.$$

Como

$$\mathcal{P}_0 \subseteq \mathcal{P},$$

tem-se

$$0 \leq \Lambda_{\text{RV}} \leq 1.$$

Valores próximos de 1 indicam que as restrições de H_0 produzem pequena redução na verossimilhança máxima. Valores reduzidos indicam que o ajuste restrito é substancialmente inferior ao ajuste irrestrito.

A região crítica pode ser escrita como

$$\mathcal{R} = \{\mathbf{y} : \Lambda_{\text{RV}} \leq c_\alpha\}.$$

É comum utilizar a transformação

$$-2 \log \Lambda_{\text{RV}} = 2 \left[\ell(\hat{\vartheta}) - \ell(\tilde{\vartheta}) \right], \quad (12.77)$$

em que

$$\ell(\vartheta) = \log L(\vartheta; \mathbf{y}).$$

A estatística em Equação 12.77 é não negativa. Valores elevados representam uma perda de ajuste relevante causada pelas restrições da hipótese nula.

12.4.2.1 Razão de verossimilhanças em modelos encaixados

Considere dois modelos lineares multivariados encaixados:

- um modelo completo, com SSCP residual observada $\mathbf{E}_F$;
- um modelo reduzido, com SSCP residual observada $\mathbf{E}_R$.

Como estabelecido no Capítulo 11,

$$\mathbf{E}_R = \mathbf{E}_F + \mathbf{H}, \quad (12.78)$$

em que $\mathbf{H}$ é a SSCP associada às restrições que diferenciam os modelos.

Sob normalidade matricial, depois da maximização em relação à matriz de covariâncias, a verossimilhança maximizada é proporcional a

$$|\mathbf{E}|^{-n/2},$$

quando a SSCP residual é positiva definida. Assim,

$$\Lambda_{RV} = \left(\frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} \right)^{n/2}. \quad (12.79)$$

No modelo linear multivariado normal, a comparação entre modelos encaixados conduz a uma razão de determinantes das matrizes residuais. Esse critério, denominado lambda de Wilks, constitui uma das formulações clássicas da análise de variância multivariada (Wilks, 1932):

$$\Lambda_W = \frac{|\mathbf{E}_F|}{|\mathbf{E}_R|} = \frac{|\mathbf{E}_F|}{|\mathbf{E}_F + \mathbf{H}|} \quad (12.80)$$

é denominada **lambda de Wilks**. Portanto,

$$\Lambda_{RV} = \Lambda_W^{n/2}. \quad (12.81)$$

Os dois critérios são funções monotônicas um do outro e produzem a mesma ordenação das evidências contra a hipótese nula.

A notação distingue:

- Λ_{RV} : razão entre as verossimilhanças maximizadas;
- Λ_W : razão entre os determinantes das SSCP residuais.

Quando

$$\mathbf{E}_F \succ \mathbf{0},$$

a lambda de Wilks pode ser escrita como

$$\Lambda_W = \frac{1}{|\mathbf{I}_p + \mathbf{E}_F^{-1} \mathbf{H}|}. \quad (12.82)$$

Se

$$\lambda_1, \dots, \lambda_m$$

são as raízes não nulas do problema

$$\mathbf{H}\mathbf{v} = \lambda \mathbf{E}_F \mathbf{v},$$

então

$$\Lambda_W = \prod_{j=1}^m \frac{1}{1 + \lambda_j}. \quad (12.83)$$

Essa expressão mostra que Λ_W reúne os afastamentos entre hipótese e erro ao longo das direções determinadas pelas duas SSCP. O desenvolvimento dos critérios multivariados baseados nessas raízes pertence à formulação da MANOVA no Módulo 3.

Existência da razão de determinantes clássica

A forma em Equação 12.80 exige que as matrizes residuais sejam positivas definidas. Sob o modelo normal, isso requer graus de liberdade residuais suficientes em relação ao número de respostas. Quando a SSCP residual é singular, determinantes e inversas não fornecem a calibração clássica. O uso de pseudoinversas ou regularização define outros procedimentos e não recupera automaticamente a distribuição nula usual.

12.4.3 Resultado assintótico de Wilks

Em muitos problemas, a distribuição exata de

$$\Lambda_{\text{RV}}$$

não possui uma forma simples. Em modelos paramétricos regulares, com dimensão fixa e parâmetro verdadeiro no interior do espaço paramétrico, a transformação logarítmica da razão de verossimilhanças possui distribuição limite qui-quadrado (Vaart, 1998).

Teorema 12.16 (Resultado assintótico de Wilks). *Considere um modelo paramétrico regular com parâmetro*

$$\vartheta \in \mathcal{P} \subseteq \mathbb{R}^k.$$

Suponha que:

1. *o modelo seja identificável;*
2. *o parâmetro verdadeiro pertença ao interior do espaço paramétrico;*
3. *a log-verossimilhança seja suficientemente diferenciável em uma vizinhança do parâmetro verdadeiro;*
4. *a informação de Fisher seja finita e positiva definida;*
5. *a hipótese nula seja definida localmente por d restrições suaves e linearmente independentes;*
6. *a dimensão paramétrica permaneça fixa quando $n \rightarrow \infty$;*
7. *as demais condições de regularidade necessárias à consistência e à normalidade assintótica dos estimadores de máxima verossimilhança sejam satisfeitas.*

Então, sob H_0 ,

$$-2 \log \Lambda_{\text{RV}} \xrightarrow{d} \chi_d^2, \quad (12.84)$$

em que d é a diferença entre as dimensões locais do modelo irrestrito e do modelo restrito.

A aproximação produz a região crítica

$$-2 \log \Lambda_{\text{RV}} > \chi_{d;1-\alpha}^2, \quad (12.85)$$

em que

$$\chi_{d;1-\alpha}^2$$

é o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com d graus de liberdade.

O valor-p aproximado é

$$P[\chi_d^2 \geq -2 \log \Lambda_{\text{RV,obs}}] . \quad (12.86)$$

O resultado em Equação 12.84 é assintótico. Em determinados modelos normais, a estatística da razão de verossimilhanças pode possuir uma distribuição exata ou admitir uma transformação exata para outra distribuição conhecida. Esses casos devem utilizar a distribuição exata em vez da aproximação geral.

Sob alternativas fixas afastadas de H_0 , a estatística

$$-2 \log \Lambda_{\text{RV}}$$

tende a crescer com n , conduzindo o poder a 1 sob condições usuais de consistência.

Sob alternativas locais que se aproximam de H_0 à taxa

$$n^{-1/2},$$

a distribuição limite é frequentemente uma qui-quadrado não central. Seu parâmetro de não centralidade depende da direção do afastamento e da informação de Fisher.

Situações não regulares

A aproximação qui-quadrado do Teorema 12.16 pode falhar quando:

- o parâmetro verdadeiro está na fronteira;
- o modelo não é identificável;
- existem parâmetros redundantes;
- a informação de Fisher é singular;
- o suporte depende do parâmetro de modo não regular;
- a dimensão aumenta com o tamanho amostral;
- a solução de máxima verossimilhança não é interior;
- matrizes necessárias ao modelo são singulares.

Nessas situações, a distribuição limite pode ser uma mistura de distribuições, depender de parâmetros desconhecidos ou exigir calibração por outros métodos.

A razão de verossimilhanças fornece um princípio geral de comparação entre modelos e hipóteses. Nas próximas seções, esse princípio será aplicado à inferência sobre um vetor de médias. Primeiro será considerado o caso em que a matriz de covariâncias populacional é conhecida. Em seguida, sua substituição pela covariância amostral conduzirá à estatística T^2 de Hotelling.

12.5 Inferência sobre um vetor de médias

Considere uma amostra aleatória

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

em que

$$\mu \in \mathbb{R}^p$$

é o vetor de médias populacional e

$$\Sigma \in \mathbb{R}^{p \times p}$$

é uma matriz de covariâncias positiva definida.

O problema central desta seção é testar

$$H_0 : \mu = \mu_0$$

contra

$$H_1 : \mu \neq \mu_0,$$

em que

$$\mu_0 \in \mathbb{R}^p$$

é um vetor conhecido.

Primeiro será considerado o caso em que Σ é conhecida. Em seguida, sua substituição pela matriz de covariâncias amostral conduzirá à estatística T^2 de Hotelling.

12.5.1 Covariância conhecida

Pelo Teorema 12.1,

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right).$$

Sob a hipótese nula,

$$\bar{\mathbf{X}} - \mu_0 \sim N_p \left(\mathbf{0}, \frac{\Sigma}{n} \right).$$

Como

$$\Sigma \succ \mathbf{0},$$

o vetor padronizado

$$\mathbf{Z}_\mu = \sqrt{n} \Sigma^{-1/2} (\bar{\mathbf{X}} - \mu_0) \quad (12.87)$$

possui, sob H_0 , distribuição

$$\mathbf{Z}_\mu \sim N_p (\mathbf{0}, \mathbf{I}_p).$$

A soma dos quadrados de seus componentes é

$$\mathbf{Z}_\mu^\top \mathbf{Z}_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0).$$

Definição 12.6 (Estatística para a média com covariância conhecida). A estatística para testar

$$H_0 : \mu = \mu_0$$

quando Σ é conhecida é

$$Q_\mu = n (\bar{\mathbf{X}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0). \quad (12.88)$$

A estatística Q_μ é a distância de Mahalanobis quadrática entre a média amostral e o vetor especificado pela hipótese, multiplicada por n .

Ela considera simultaneamente:

- as variâncias das componentes;
- as covariâncias entre as variáveis;
- a precisão da média decorrente do tamanho amostral.

Teorema 12.17 (Distribuição com covariância conhecida). *Sob*

$$H_0 : \mu = \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2. \quad (12.89)$$

Sob uma alternativa fixa

$$\mu \neq \mu_0,$$

tem-se

$$Q_\mu \sim \chi_p^2(\lambda_\mu), \quad (12.90)$$

em que

$$\lambda_\mu = n (\mu - \mu_0)^\top \Sigma^{-1} (\mu - \mu_0). \quad (12.91)$$

Comprovação. Sob H_0 , o vetor definido em Equação 12.87 possui distribuição normal padrão multivariada. Portanto,

$$Q_\mu = \mathbf{Z}_\mu^\top \mathbf{Z}_\mu \sim \chi_p^2.$$

Sob a alternativa,

$$\mathbf{Z}_\mu \sim N_p \left[\sqrt{n} \Sigma^{-1/2} (\mu - \mu_0), \mathbf{I}_p \right].$$

A norma quadrática de um vetor normal com covariância identidade possui distribuição qui-quadrado não central. O parâmetro de não centralidade é a norma quadrática de seu vetor de médias:

$$\begin{aligned}\lambda_\mu &= \left\| \sqrt{n} \Sigma^{-1/2} (\mu - \mu_0) \right\|^2 \\ &= n (\mu - \mu_0)^\top \Sigma^{-1} (\mu - \mu_0).\end{aligned}$$

□

O teste de nível α rejeita H_0 quando

$$Q_{\mu, \text{obs}} > \chi_{p; 1-\alpha}^2, \quad (12.92)$$

em que

$$Q_{\mu, \text{obs}} = n (\bar{\mathbf{x}} - \mu_0)^\top \Sigma^{-1} (\bar{\mathbf{x}} - \mu_0) \quad (12.93)$$

e

$$\chi_{p; 1-\alpha}^2$$

é o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com p graus de liberdade.

O valor-p é

$$P(\chi_p^2 \geq Q_{\mu, \text{obs}}). \quad (12.94)$$

A função poder é

$$\pi(\mu) = P[\chi_p^2(\lambda_\mu) > \chi_{p; 1-\alpha}^2]. \quad (12.95)$$

O poder aumenta com a distância de Mahalanobis entre μ e μ_0 e com o tamanho amostral.

A estatística também pode ser escrita no espaço branqueado. Defina

$$\bar{\mathbf{U}} = \Sigma^{-1/2} \bar{\mathbf{X}}$$

e

$$\mu_{0U} = \Sigma^{-1/2} \mu_0.$$

Então,

$$Q_\mu = n \left\| \bar{\mathbf{U}} - \mu_{0U} \right\|^2. \quad (12.96)$$

No espaço branqueado, o teste utiliza a distância euclidiana entre as médias transformadas.

O procedimento é invariante a transformações afins inversíveis. Se

$$\mathbf{Y}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b},$$

com

$$\mathbf{A} \in \mathbb{R}^{p \times p}$$

não singular, então a estatística calculada para

$$\nu = \mathbf{A}\mu + \mathbf{b}$$

e

$$\nu_0 = \mathbf{A}\mu_0 + \mathbf{b}$$

é igual à estatística calculada na representação original.

No modelo normal com Σ conhecida, a estatística também coincide com a transformação da razão de verossimilhanças:

$$-2 \log \Lambda_{\text{RV}} = Q_\mu. \quad (12.97)$$

Quando

$$p = 1,$$

a estatística reduz-se a

$$Q_\mu = \frac{n(\bar{X} - \mu_0)^2}{\sigma^2} = Z^2,$$

em que

$$Z = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}.$$

O procedimento é a extensão multivariada do teste para uma média com variância conhecida.

12.5.2 Estatística T^2 de Hotelling

Na maioria das aplicações, Σ é desconhecida. Sua substituição pela matriz de covariâncias amostral altera a distribuição exata da forma quadrática e conduz à estatística T^2 , introduzida por Hotelling como generalização multivariada da razão de Student (Hotelling, 1931).

Definição 12.7 (Estatística T^2 de Hotelling para uma amostra). A estatística T^2 de Hotelling para testar

$$H_0 : \mu = \mu_0$$

é

$$T^2 = n(\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu_0). \quad (12.98)$$

A estatística é definida quando $\mathbf{S}$ é inversível. Sob normalidade multivariada e

$$\Sigma \succ \mathbf{0},$$

isso ocorre com probabilidade 1 quando

$$n > p. \quad (12.99)$$

O fator n aparece porque

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{\Sigma}{n}.$$

Portanto, T^2 mede a distância entre $\bar{\mathbf{X}}$ e μ_0 na escala da incerteza associada à média, e não na escala de uma observação individual.

Teorema 12.18 (Distribuição exata de T^2). *Se*

$$\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma),$$

com

$$\Sigma \succ \mathbf{0} \quad e \quad n > p,$$

então, sob

$$H_0 : \mu = \mu_0,$$

tem-se

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}. \quad (12.100)$$

Sob uma alternativa fixa,

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}(\lambda_\mu), \quad (12.101)$$

com

$$\lambda_\mu = n (\mu - \mu_0)^\top \Sigma^{-1} (\mu - \mu_0).$$

O resultado decorre conjuntamente de:

$$\sqrt{n} (\bar{\mathbf{X}} - \mu_0) \sim N_p(\mathbf{0}, \Sigma)$$

sob H_0 ,

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

A independência entre os dois objetos é necessária para a distribuição exata.

O teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{obs}}^2 > \frac{p(n-1)}{n-p} F_{p, n-p; 1-\alpha}, \quad (12.102)$$

em que

$$\mathbf{T}_{\text{obs}}^2 = n \left(\bar{\mathbf{x}} - \mu_0 \right)^\top \mathbf{S}^{-1} \left(\bar{\mathbf{x}} - \mu_0 \right). \quad (12.103)$$

A estatística transformada observada é

$$\mathbf{F}_{\text{obs}} = \frac{n-p}{p(n-1)} \mathbf{T}_{\text{obs}}^2. \quad (12.104)$$

O valor-p é

$$P(F_{p, n-p} \geq \mathbf{F}_{\text{obs}}). \quad (12.105)$$

A rejeição indica que o vetor populacional difere de μ_0 em pelo menos uma direção do espaço das variáveis. O teste não identifica automaticamente quais componentes ou combinações lineares produzem a diferença.

A estatística T^2 é invariante a transformações afins inversíveis. Considere

$$\mathbf{Y}_i = \mathbf{A}\mathbf{X}_i + \mathbf{b},$$

com $\mathbf{A}$ não singular. Então,

$$\bar{\mathbf{Y}} = \mathbf{A}\bar{\mathbf{X}} + \mathbf{b}$$

e

$$\mathbf{S}_Y = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

Como

$$\mathbf{S}_Y^{-1} = (\mathbf{A}^\top)^{-1} \mathbf{S}^{-1} \mathbf{A}^{-1},$$

a forma quadrática permanece inalterada:

$$\mathbf{T}_Y^2 = \mathbf{T}_X^2. \quad (12.106)$$

Mudanças não singulares de unidade, escala ou sistema de coordenadas não alteram a conclusão do teste.

Quando p permanece fixo e

$$n \longrightarrow \infty,$$

tem-se

$$\mathbf{S} \xrightarrow{p} \Sigma.$$

Consequentemente, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \quad (12.107)$$

A distribuição qui-quadrado é uma aproximação assintótica. Sob normalidade e em amostras finitas, a distribuição F em Equação 12.100 fornece a calibração exata.

Quando

$$p = 1,$$

tem-se

$$\mathbf{T}^2 = \frac{n(\bar{X} - \mu_0)^2}{S^2} = \mathbf{t}^2, \quad (12.108)$$

em que

$$\mathbf{t} = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \sim t_{n-1}$$

sob H_0 .

Como

$$\mathbf{t}_{n-1}^2 \sim F_{1,n-1},$$

o resultado multivariado recupera exatamente o teste t de Student.

Tabela 12.1: Correspondência entre a inferência univariada e o teste T^2 para uma amostra.

Inferência univariada	Inferência multivariada
Média μ	Vetor de médias μ
Variância σ^2	Matriz de covariâncias Σ
Variância amostral S^2	Covariância amostral $\mathbf{S}$
Distribuição qui-quadrado	Distribuição de Wishart
Estatística t	Estatística T^2
$t^2 \sim F_{1,n-1}$	$\frac{n-p}{p(n-1)} T^2 \sim F_{p,n-p}$

12.5.3 Região de confiança elipsoidal

A inversão do teste T^2 produz uma região de confiança simultânea para todo o vetor μ . A forma elipsoidal decorre da métrica definida pela inversa da matriz de covariâncias amostral (Rencher; Christensen, 2012).

Defina

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.109)$$

Teorema 12.19 (Região de confiança para o vetor de médias). *Sob as condições do Teorema 12.18, a região aleatória*

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n (\bar{\mathbf{X}} - \theta)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \theta) \leq c_{\alpha,p,n} \right\} \quad (12.110)$$

satisfaz

$$P_{\mu,\Sigma}(\mu \in \mathcal{C}_{1-\alpha}) = 1 - \alpha. \quad (12.111)$$

Após a observação da amostra, a região é

$$\mathcal{C}_{1-\alpha} = \left\{ \theta \in \mathbb{R}^p : (\theta - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\theta - \bar{\mathbf{x}}) \leq \frac{c_{\alpha,p,n}}{n} \right\}. \quad (12.112)$$

Um vetor μ_0 pertence à região se, e somente se, a hipótese

$$H_0 : \mu = \mu_0$$

não for rejeitada pelo teste T^2 de nível α :

$$\mu_0 \in \mathcal{C}_{1-\alpha} \iff T_{\text{obs}}^2(\mu_0) \leq c_{\alpha,p,n}. \quad (12.113)$$

12.5.3.1 Geometria da região

A região observada é um elipsoide centrado em

$$\bar{\mathbf{x}}.$$

Considere a decomposição espectral

$$\mathbf{S} = \mathbf{V}\Lambda\mathbf{V}^\top,$$

em que

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

e as colunas de $\mathbf{V}$ são autovetores ortonormais.

Defina

$$\mathbf{z} = \mathbf{V}^\top (\theta - \bar{\mathbf{x}}).$$

A fronteira do elipsoide pode ser escrita como

$$\sum_{j=1}^p \frac{z_j^2}{c_{\alpha,p,n} \lambda_j / n} = 1. \quad (12.114)$$

Portanto:

- os eixos principais têm direções $\mathbf{v}_1, \dots, \mathbf{v}_p$;
- o comprimento do j -ésimo semieixo é

$$a_j = \sqrt{\frac{c_{\alpha,p,n} \lambda_j}{n}}.$$

Direções com maior variância amostral produzem semieixos mais longos. Direções com menor variância produzem maior precisão na estimação da média.

A Figura 12.1 compara duas regiões bidimensionais com a mesma média, o mesmo tamanho amostral e o mesmo nível de confiança, mas com estruturas de covariância distintas.




Figura 12.1: Efeito da matriz de covariâncias sobre a forma e a orientação da região de confiança para o vetor de médias.

Na primeira configuração da Figura 12.1, a covariância nula mantém os eixos do elipsoide alinhados às coordenadas originais. Na segunda, a covariância positiva produz uma rotação. A direção de maior incerteza corresponde, então, a uma combinação das duas médias.

O volume da região é

$$\text{Vol}(\mathcal{C}_{1-\alpha}) = \frac{\pi^{p/2}}{\Gamma(p/2 + 1)} \left(\frac{c_{\alpha,p,n}}{n} \right)^{p/2} |\mathbf{S}|^{1/2}. \quad (12.115)$$

O fator

$$\frac{\pi^{p/2}}{\Gamma(p/2 + 1)}$$

é o volume da bola unitária em $\mathbb{R}^p$. A quantidade

$$|\mathbf{S}|^{1/2}$$

é o fator de escala de volume determinado pela covariância amostral.

Quando p permanece fixo e n aumenta, os comprimentos dos semieixos diminuem na ordem de

$$n^{-1/2}.$$

Isso representa o aumento da precisão da média amostral.

A região pode ser interpretada como a transformação de uma bola. Defina

$$\mathbf{u} = \sqrt{n} \mathbf{S}^{-1/2} (\theta - \bar{\mathbf{x}}).$$

Então,

$$\mathcal{C}_{1-\alpha} = \{\theta : \|\mathbf{u}\|^2 \leq c_{\alpha,p,n}\}. \quad (12.116)$$

No espaço padronizado, a região é uma bola de raio

$$\sqrt{c_{\alpha,p,n}}.$$

A transformação inversa produz o elipsoide no espaço original.

Interpretação frequentista da cobertura

Antes da observação dos dados,

$$\mathcal{C}_{1-\alpha}$$

é uma região aleatória e contém o verdadeiro vetor μ com probabilidade $1 - \alpha$.

Após a observação da amostra, a região está fixada. Na interpretação frequentista, o parâmetro não é aleatório. O coeficiente $1 - \alpha$ descreve a proporção de regiões que conteriam μ em repetições independentes do procedimento.

12.5.4 Intervalos simultâneos

A região elipsoidal permite construir intervalos simultâneos para qualquer combinação linear

$$\mathbf{a}^\top \mu, \quad \mathbf{a} \in \mathbb{R}^p.$$

Teorema 12.20 (Intervalos simultâneos de Hotelling). *Sob as condições do Teorema 12.18, os intervalos*

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n}} \mathbf{a}^\top \mathbf{S} \mathbf{a}, \quad \mathbf{a} \in \mathbb{R}^p, \quad (12.117)$$

possuem cobertura simultânea $1 - \alpha$ para todas as combinações lineares:

$$P \left[|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\frac{c_{\alpha,p,n}}{n}} \mathbf{a}^\top \mathbf{S} \mathbf{a} \text{ para todo } \mathbf{a} \in \mathbb{R}^p \right] = 1 - \alpha. \quad (12.118)$$

Comprovação. Dentro da região de confiança, defina

$$\mathbf{d} = \mu - \bar{\mathbf{X}}.$$

A condição que define o elipsoide é

$$\mathbf{d}^\top \mathbf{S}^{-1} \mathbf{d} \leq \frac{c_{\alpha,p,n}}{n}.$$

Escreva

$$\mathbf{a}^\top \mathbf{d} = (\mathbf{S}^{1/2} \mathbf{a})^\top (\mathbf{S}^{-1/2} \mathbf{d}).$$

Pela desigualdade de Cauchy–Schwarz,

$$|\mathbf{a}^\top \mathbf{d}| \leq \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \sqrt{\mathbf{d}^\top \mathbf{S}^{-1} \mathbf{d}}.$$

Utilizando a restrição do elipsoide,

$$|\mathbf{a}^\top (\mu - \bar{\mathbf{X}})| \leq \sqrt{\frac{c_{\alpha,p,n}}{n}} \mathbf{a}^\top \mathbf{S} \mathbf{a}.$$

A desigualdade vale simultaneamente para todas as direções $\mathbf{a}$ sempre que μ pertence à região elipsoidal. $\square$

Após a observação dos dados, o intervalo é

$$\mathbf{a}^\top \bar{\mathbf{x}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n}} \mathbf{a}^\top \mathbf{S} \mathbf{a}. \quad (12.119)$$

Para uma componente individual, tome

$$\mathbf{a} = \mathbf{e}_j.$$

Obtém-se

$$\mu_j \in \bar{X}_j \pm \sqrt{\frac{c_{\alpha,p,n} S_{jj}}{n}}, \quad j = 1, \dots, p. \quad (12.120)$$

Para a diferença entre duas componentes, utilize

$$\mathbf{a} = \mathbf{e}_j - \mathbf{e}_k.$$

Como

$$\mathbf{a}^\top \mathbf{S} \mathbf{a} = S_{jj} + S_{kk} - 2S_{jk},$$

o intervalo é

$$\mu_j - \mu_k \in \bar{X}_j - \bar{X}_k \pm \sqrt{\frac{c_{\alpha,p,n}}{n}} (S_{jj} + S_{kk} - 2S_{jk}). \quad (12.121)$$

A covariância afeta diretamente sua amplitude:

- uma covariância positiva reduz a variância da diferença;
- uma covariância negativa aumenta a variância da diferença.

Para uma combinação linear escolhida previamente, o intervalo individual usual é

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm t_{n-1;1-\alpha/2} \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}}. \quad (12.122)$$

Esse intervalo possui cobertura individual $1 - \alpha$ para a combinação fixada, mas não protege simultaneamente todas as direções.

Quando o interesse envolve apenas m combinações previamente especificadas,

$$\mathbf{a}_1^\top \mu, \dots, \mathbf{a}_m^\top \mu,$$

podem ser utilizados os intervalos de Bonferroni:

$$\mathbf{a}_k^\top \bar{\mathbf{X}} \pm t_{n-1; 1-\alpha/(2m)} \sqrt{\frac{\mathbf{a}_k^\top \mathbf{S} \mathbf{a}_k}{n}}, \quad k = 1, \dots, m. \quad (12.123)$$

A desigualdade de Bonferroni garante cobertura conjunta de pelo menos $1 - \alpha$.

Tabela 12.2: Comparação entre intervalos individuais, de Bonferroni e derivados da região de Hotelling.

Procedimento	Conjunto protegido	Garantia de cobertura
Intervalo individual	Uma combinação previamente especificada	$1 - \alpha$ individual
Bonferroni	m combinações especificadas	Pelo menos $1 - \alpha$ conjunta
Hotelling	Todas as combinações lineares	$1 - \alpha$ conjunta

Os intervalos de Bonferroni podem ser mais estreitos quando o número de combinações previamente especificadas é pequeno. Os intervalos de Hotelling são apropriados quando se deseja proteção para todas as direções ou quando as combinações serão examinadas depois do teste global.

12.5.5 Hipóteses lineares sobre o vetor de médias

A hipótese

$$H_0 : \mu = \mu_0$$

especifica todas as componentes do vetor. Em algumas aplicações, o interesse recai apenas sobre determinadas combinações lineares.

Considere

$$\mathbf{A} \in \mathbb{R}^{h \times p},$$

com

$$\text{posto}(\mathbf{A}) = h \leq p,$$

e um vetor conhecido

$$\mathbf{d} \in \mathbb{R}^h.$$

A hipótese linear é

$$H_0 : \mathbf{A}\mu = \mathbf{d} \quad (12.124)$$

contra

$$H_1 : \mathbf{A}\mu \neq \mathbf{d}.$$

Cada linha de $\mathbf{A}$ define uma restrição linear. O posto linha completo elimina restrições redundantes.

Defina os vetores transformados

$$\mathbf{U}_i = \mathbf{A}\mathbf{X}_i.$$

Então,

$$\mathbf{U}_i \sim N_h(\mathbf{A}\mu, \mathbf{A}\Sigma\mathbf{A}^\top). \quad (12.125)$$

Como $\mathbf{A}$ possui posto linha completo e $\Sigma \succ \mathbf{0}$,

$$\mathbf{A}\Sigma\mathbf{A}^\top \succ \mathbf{0}.$$

A média e a covariância amostrais transformadas são

$$\bar{\mathbf{U}} = \mathbf{A}\bar{\mathbf{X}}$$

e

$$\mathbf{S}_U = \mathbf{A}\mathbf{S}\mathbf{A}^\top.$$

O problema reduz-se, portanto, à inferência sobre o vetor de médias h -dimensional dos dados transformados.

12.5.5.1 Covariância conhecida

Quando Σ é conhecida, define-se

$$Q_A = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.126)$$

Sob H_0 ,

$$Q_A \sim \chi_h^2. \quad (12.127)$$

O teste de nível α rejeita H_0 quando

$$Q_{A,\text{obs}} > \chi_{h;1-\alpha}^2.$$

12.5.5.2 Covariância desconhecida

Quando Σ é desconhecida, define-se

$$T_A^2 = n (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \mathbf{d}). \quad (12.128)$$

Sob normalidade,

$$\mathbf{A}\mathbf{S}\mathbf{A}^\top$$

é positiva definida com probabilidade 1 quando

$$n > h. \quad (12.129)$$

Essa condição depende do número de restrições independentes, e não necessariamente da dimensão original p .

Teorema 12.21 (Distribuição para hipóteses lineares sobre a média). *Sob*

$$H_0 : \mathbf{A}\mu = \mathbf{d},$$

tem-se

$$\frac{n-h}{h(n-1)} T_A^2 \sim F_{h,n-h}. \quad (12.130)$$

Sob uma alternativa fixa,

$$\frac{n-h}{h(n-1)} \mathbf{T}_A^2 \sim F_{h,n-h}(\lambda_A), \quad (12.131)$$

em que

$$\lambda_A = n (\mathbf{A}\mu - \mathbf{d})^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} (\mathbf{A}\mu - \mathbf{d}). \quad (12.132)$$

O teste de nível α rejeita H_0 quando

$$\mathbf{T}_{A,\text{obs}}^2 > \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha}, \quad (12.133)$$

em que

$$\mathbf{T}_{A,\text{obs}}^2 = n (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d})^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{x}} - \mathbf{d}).$$

O valor-p é calculado a partir de

$$\mathbf{F}_{A,\text{obs}} = \frac{n-h}{h(n-1)} \mathbf{T}_{A,\text{obs}}^2$$

e da distribuição

$$F_{h,n-h}.$$

Quando

$$h = 1,$$

escreva

$$\mathbf{A} = \mathbf{a}^\top$$

e

$$\mathbf{d} = [d].$$

A hipótese é

$$H_0 : \mathbf{a}^\top \mu = d.$$

A estatística reduz-se a

$$\mathbf{t}_{\mathbf{a}} = \frac{\sqrt{n}(\mathbf{a}^\top \bar{\mathbf{X}} - d)}{\sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}}}, \quad (12.134)$$

com

$$\mathbf{t}_{\mathbf{a}} \sim t_{n-1}$$

sob H_0 , e

$$\mathbb{T}_A^2 = \mathbf{t}_{\mathbf{a}}^2.$$

Para testar uma componente individual,

$$H_0 : \mu_j = \mu_{j0},$$

utiliza-se

$$\mathbf{A} = \mathbf{e}_j^\top.$$

Para testar a igualdade entre duas componentes,

$$H_0 : \mu_j = \mu_k,$$

utiliza-se

$$\mathbf{A} = (\mathbf{e}_j - \mathbf{e}_k)^\top$$

e

$$d = 0.$$

A estatística correspondente é

$$t_{jk} = \frac{\sqrt{n}(\bar{X}_j - \bar{X}_k)}{\sqrt{S_{jj} + S_{kk} - 2S_{jk}}}. \quad (12.135)$$

A comparação somente possui interpretação substantiva direta quando as componentes estão em escalas comparáveis e sua diferença é significativa no contexto estudado.

A hipótese

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_p$$

pode ser representada por

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 0 & \cdots & 0 \\ 0 & 1 & -1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 & -1 \end{bmatrix}$$

e

$$\mathbf{d} = \mathbf{0}_{p-1}.$$

Nesse caso,

$$h = p - 1.$$

A região de confiança para

$$\mathbf{A}\mu$$

é

$$\mathcal{C}_{A,1-\alpha} = \left\{ \theta \in \mathbb{R}^h : n(\mathbf{A}\bar{\mathbf{X}} - \theta)^\top (\mathbf{A}\mathbf{S}\mathbf{A}^\top)^{-1} (\mathbf{A}\bar{\mathbf{X}} - \theta) \leq \frac{h(n-1)}{n-h} F_{h,n-h;1-\alpha} \right\}. \quad (12.136)$$

A hipótese

$$H_0 : \mathbf{A}\mu = \mathbf{d}$$

não é rejeitada se, e somente se,

$$\mathbf{d} \in \mathcal{C}_{A,1-\alpha}.$$

12.5.5.3 Relação com o modelo linear multivariado

O modelo para uma única população pode ser escrito como

$$y = \mathbf{1}_n \mu^\top + \mathcal{E}.$$

Nesse modelo,

$$\mathbf{Z} = \mathbf{1}_n$$

e

$$\mathbf{B} = \mu^\top.$$

Na hipótese bilateral do Capítulo 11,

$$H_0 : \mathbf{CBM} = \Theta_0,$$

escolha

$$\mathbf{C} = [1], \quad \mathbf{M} = \mathbf{A}^\top$$

e

$$\Theta_0 = \mathbf{d}^\top.$$

Então,

$$\mathbf{CBM} = \mu^\top \mathbf{A}^\top = (\mathbf{A}\mu)^\top.$$

Portanto,

$$H_0 : \mathbf{CBM} = \Theta_0$$

é equivalente a

$$H_0 : \mathbf{A}\mu = \mathbf{d}.$$

A inferência sobre combinações lineares de um único vetor de médias é, assim, um caso particular da hipótese linear multivariada geral. A próxima seção estende essa estrutura à comparação entre vetores de médias de duas populações.

12.6 Comparação entre dois vetores de médias

A comparação entre duas populações depende da relação entre as unidades observadas. Há duas estruturas principais:

- amostras independentes, formadas por unidades distintas;
- observações pareadas, nas quais cada unidade ou par de unidades fornece duas medições relacionadas.

A escolha entre os procedimentos deve ser determinada pelo delineamento amostral. No caso independente, a variabilidade da diferença envolve as covariâncias das duas amostras. No caso pareado, a análise deve ser realizada sobre os vetores de diferenças, preservando a covariância entre as medições de cada par (Rencher; Christensen, 2012).

12.6.1 Duas amostras independentes

Considere duas amostras aleatórias independentes:

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma).$$

As duas populações possuem vetores de médias possivelmente diferentes e a mesma matriz de covariâncias positiva definida:

$$\Sigma \succ \mathbf{0}.$$

A independência ocorre:

- entre observações da primeira amostra;

- entre observações da segunda amostra;
- entre as duas amostras.

O parâmetro de interesse é a diferença

$$\delta = \mu_1 - \mu_2 \in \mathbb{R}^p. \quad (12.137)$$

A hipótese geral é

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (12.138)$$

contra

$$H_1 : \mu_1 - \mu_2 \neq \delta_0,$$

em que

$$\delta_0 \in \mathbb{R}^p$$

é um vetor conhecido.

A hipótese de igualdade dos vetores de médias é obtida com

$$\delta_0 = \mathbf{0}.$$

12.6.1.1 Distribuição da diferença entre as médias

As médias amostrais são

$$\bar{\mathbf{x}}_1 = \frac{1}{n_1} \sum_{i=1}^{n_1} \mathbf{x}_{1i}$$

e

$$\bar{\mathbf{x}}_2 = \frac{1}{n_2} \sum_{j=1}^{n_2} \mathbf{x}_{2j}.$$

Pela independência entre as amostras,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim N_p \left[\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right]. \quad (12.139)$$

Defina o tamanho amostral efetivo:

$$n_{\text{ef}} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} = \frac{n_1 n_2}{n_1 + n_2}. \quad (12.140)$$

Então,

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma}{n_{\text{ef}}}.$$

O tamanho amostral efetivo é inferior ao tamanho da menor amostra e é mais reduzido quando os tamanhos são muito desiguais.

12.6.1.2 Covariância agrupada

As matrizes de covariâncias amostrais são

$$\mathbf{S}_1 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (\mathbf{x}_{1i} - \bar{\mathbf{x}}_1) (\mathbf{x}_{1i} - \bar{\mathbf{x}}_1)^\top$$

e

$$\mathbf{S}_2 = \frac{1}{n_2 - 1} \sum_{j=1}^{n_2} (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2) (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)^\top.$$

Sob a hipótese de uma covariância populacional comum, as duas SSCP estimam múltiplos da mesma matriz Σ . A matriz de covariâncias agrupada é

$$\mathbf{S}_p = \frac{(n_1 - 1) \mathbf{S}_1 + (n_2 - 1) \mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.141)$$

A notação $\mathbf{S}_p$ indica uma estatística aleatória. Para os dados observados, utiliza-se

$$\mathbf{S}_p = \frac{(n_1 - 1) \mathbf{S}_1 + (n_2 - 1) \mathbf{S}_2}{n_1 + n_2 - 2}. \quad (12.142)$$

Teorema 12.22 (Distribuição da covariância agrupada). *Sob normalidade, independência e igualdade das matrizes de covariâncias,*

$$(n_1 + n_2 - 2) \mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma). \quad (12.143)$$

Além disso,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \perp \mathbf{S}_p. \quad (12.144)$$

Comprovação. Para cada amostra,

$$(n_h - 1) \mathbf{S}_h \sim W_p(n_h - 1, \Sigma), \quad h = 1, 2.$$

As duas matrizes são independentes porque as amostras são independentes. Pela aditividade da distribuição de Wishart,

$$\begin{aligned} & (n_1 - 1) \mathbf{S}_1 + (n_2 - 1) \mathbf{S}_2 \\ & \sim W_p(n_1 + n_2 - 2, \Sigma). \end{aligned}$$

A soma no lado esquerdo é

$$(n_1 + n_2 - 2) \mathbf{S}_p.$$

Sob normalidade, cada média amostral é independente da covariância calculada na mesma amostra. A independência entre as duas amostras completa a separação entre

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$$

e

$$\mathbf{S}_p.$$

□

A matriz agrupada é um estimador não viesado da covariância comum:

$$E(\mathbf{S}_p) = \Sigma.$$

Com probabilidade 1,

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2). \quad (12.145)$$

Portanto, sua inversa existe com probabilidade 1 quando

$$n_1 + n_2 - 2 \geq p. \quad (12.146)$$

12.6.1.3 Estatística T^2 para duas amostras

Definição 12.8 (Estatística T^2 para duas amostras independentes). A estatística T^2 para testar

$$H_0 : \mu_1 - \mu_2 = \delta_0$$

é

$$T_{\text{ind}}^2 = n_{\text{ef}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)^\top \mathbf{S}_p^{-1} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0), \quad (12.147)$$

em que

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}.$$

Teorema 12.23 (Distribuição exata de T^2 para duas amostras). *Considere duas amostras mutuamente independentes:*

$$\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma)$$

e

$$\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma),$$

com

$$n_1 \geq 2, \quad n_2 \geq 2$$

e

$$\Sigma \succ \mathbf{0}.$$

Defina

$$n_{\text{ef}} = \frac{n_1 n_2}{n_1 + n_2}$$

e considere a hipótese

$$H_0 : \mu_1 - \mu_2 = \delta_0.$$

Se

$$n_1 + n_2 > p + 1,$$

então, sob H_0 ,

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} T_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}. \quad (12.148)$$

Sob uma alternativa fixa,

$$\frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} T_{\text{ind}}^2 \sim F_{p, n_1 + n_2 - p - 1}(\lambda_{\text{ind}}), \quad (12.149)$$

em que

$$\lambda_{\text{ind}} = n_{\text{ef}} \left(\mu_1 - \mu_2 - \delta_0 \right)^\top \Sigma^{-1} \left(\mu_1 - \mu_2 - \delta_0 \right). \quad (12.150)$$

A condição

$$n_1 + n_2 > p + 1$$

equivale a

$$n_1 + n_2 - 2 \geq p$$

para valores inteiros. Ela garante a inversibilidade da covariância agrupada e graus de liberdade positivos na distribuição F .

Para os dados observados,

$$\mathbf{T}_{\text{ind,obs}}^2 = n_{\text{ef}} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0)^\top \mathbf{S}_p^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \delta_0). \quad (12.151)$$

O teste de nível α rejeita H_0 quando

$$\mathbf{T}_{\text{ind,obs}}^2 > \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.152)$$

A estatística transformada é

$$\mathbf{F}_{\text{ind,obs}} = \frac{n_1 + n_2 - p - 1}{p(n_1 + n_2 - 2)} \mathbf{T}_{\text{ind,obs}}^2.$$

O valor-p é

$$P[F_{p, n_1 + n_2 - p - 1} \geq \mathbf{F}_{\text{ind,obs}}]. \quad (12.153)$$

A rejeição indica que os vetores de médias diferem em pelo menos uma combinação linear das variáveis.

Quando

$$p = 1$$

e

$$\delta_0 = 0,$$

a estatística reduz-se a

$$\mathsf{T}_{\text{ind}}^2 = \frac{(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)^2}{\mathsf{S}_p^2 (1/n_1 + 1/n_2)} = \mathsf{t}_p^2, \quad (12.154)$$

em que t_p é a estatística t de Student para duas amostras independentes com variâncias iguais e

$$n_1 + n_2 - 2$$

graus de liberdade.

12.6.1.4 Região de confiança para a diferença

Defina

$$c_{\alpha, \text{ind}} = \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1; 1 - \alpha}. \quad (12.155)$$

Uma região de confiança de nível $1 - \alpha$ para

$$\delta = \mu_1 - \mu_2$$

é

$$\mathcal{C}_{\delta, 1 - \alpha} = \left\{ \theta \in \mathbb{R}^p : n_{\text{ef}} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta)^\top \mathbf{S}_p^{-1} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \theta) \leq c_{\alpha, \text{ind}} \right\}. \quad (12.156)$$

Para qualquer vetor fixo

$$\mathbf{a} \in \mathbb{R}^p,$$

os intervalos simultâneos derivados dessa região são

$$\mathbf{a}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) \pm \sqrt{\frac{c_{\alpha, \text{ind}}}{n_{\text{ef}}}} \mathbf{a}^\top \mathbf{S}_p \mathbf{a}. \quad (12.157)$$

Eles protegem simultaneamente todas as combinações lineares de

$$\mu_1 - \mu_2.$$

Para a componente j , utilize

$$\mathbf{a} = \mathbf{e}_j.$$

O intervalo correspondente é

$$\mu_{1j} - \mu_{2j} \in \bar{X}_{1j} - \bar{X}_{2j} \pm \sqrt{\frac{c_{\alpha, \text{ind}}}{n_{\text{ef}}}} S_{p, jj}. \quad (12.158)$$

Covariâncias populacionais diferentes

A distribuição exata em Equação 12.148 depende da igualdade

$$\Sigma_1 = \Sigma_2 = \Sigma.$$

Quando as covariâncias populacionais diferem, a matriz agrupada não estima uma única covariância comum e a calibração clássica pela distribuição F deixa de ser exata. Esse problema constitui a extensão multivariada do problema de Behrens–Fisher e exige aproximações ou procedimentos específicos (Anderson, 2003).

Substituir a covariância agrupada por outra matriz ou utilizar uma aproximação de graus de liberdade define um procedimento distinto. A validade desse procedimento deve ser justificada pelas condições e pela aproximação adotadas.

A igualdade das covariâncias não deve ser considerada automaticamente verdadeira apenas porque um teste preliminar não a rejeitou. Testes de homogeneidade podem apresentar baixo poder, especialmente com amostras pequenas, e a realização sequencial de testes altera a interpretação do procedimento global.

12.6.2 Observações pareadas

Em um delineamento pareado, cada unidade fornece dois vetores relacionados ou cada unidade da primeira condição é associada a uma unidade comparável da segunda condição.

Considere os pares

$$(\mathbf{X}_i, \mathbf{Y}_i), \quad i = 1, \dots, n,$$

em que

$$\mathbf{X}_i, \mathbf{Y}_i \in \mathbb{R}^p.$$

Os pares são independentes entre si, mas os vetores dentro de cada par podem ser dependentes.

Defina o vetor de diferenças:

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i. \quad (12.159)$$

O parâmetro de interesse é

$$\delta = E(\mathbf{D}_i) = \mu_X - \mu_Y. \quad (12.160)$$

A matriz de covariâncias das diferenças é

$$\begin{aligned} \Sigma_D &= \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i) \\ &= \Sigma_X + \Sigma_Y - \Sigma_{XY} - \Sigma_{YX}, \end{aligned} \quad (12.161)$$

em que

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}_i, \mathbf{Y}_i)$$

e

$$\Sigma_{YX} = \Sigma_{XY}^\top.$$

A covariância dentro dos pares influencia diretamente a precisão das diferenças. Quando as medições correspondentes são positivamente associadas, a variabilidade das diferenças pode ser menor que a variabilidade obtida ao tratar as duas condições como independentes.

A hipótese é

$$H_0 : \delta = \delta_0 \quad (12.162)$$

contra

$$H_1 : \delta \neq \delta_0.$$

Para comparar diretamente as condições, utiliza-se

$$\delta_0 = \mathbf{0}.$$

O problema pareado é reduzido a um problema de uma amostra aplicada aos vetores

$$\mathbf{D}_1, \dots, \mathbf{D}_n.$$

Suponha que

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}.$$

A média das diferenças é

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{i=1}^n \mathbf{D}_i = \bar{\mathbf{X}} - \bar{\mathbf{Y}}. \quad (12.163)$$

A matriz de covariâncias amostral das diferenças é

$$\mathbf{S}_D = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{D}_i - \bar{\mathbf{D}})(\mathbf{D}_i - \bar{\mathbf{D}})^\top. \quad (12.164)$$

Ela pode ser escrita como

$$\mathbf{S}_D = \mathbf{S}_X + \mathbf{S}_Y - \mathbf{S}_{XY} - \mathbf{S}_{YX}, \quad (12.165)$$

quando todas as matrizes são calculadas com o mesmo divisor $n-1$ e com a correspondência entre os pares preservada.

Definição 12.9 (Estatística T^2 para observações pareadas). A estatística para testar

$$H_0 : \delta = \delta_0$$

é

$$\mathsf{T}_{\text{par}}^2 = n (\bar{\mathbf{D}} - \delta_0)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \delta_0). \quad (12.166)$$

Teorema 12.24 (Distribuição exata de T^2 para observações pareadas). *Considere n pares completos e defina*

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i, \quad i = 1, \dots, n.$$

Suponha que os vetores de diferenças sejam independentes e identicamente distribuídos:

$$\mathbf{D}_1, \dots, \mathbf{D}_n \stackrel{\text{iid}}{\sim} N_p(\delta, \Sigma_D),$$

com

$$\Sigma_D \succ \mathbf{0}$$

e

$$n > p.$$

Considere a hipótese

$$H_0 : \delta = \delta_0.$$

Sob H_0 ,

$$\frac{n-p}{p(n-1)} T_{\text{par}}^2 \sim F_{p, n-p}. \quad (12.167)$$

Sob uma alternativa fixa,

$$\frac{n-p}{p(n-1)} T_{\text{par}}^2 \sim F_{p, n-p}(\lambda_{\text{par}}), \quad (12.168)$$

em que

$$\lambda_{\text{par}} = n(\delta - \delta_0)^\top \Sigma_D^{-1} (\delta - \delta_0). \quad (12.169)$$

O resultado é uma aplicação direta do Teorema 12.18 aos vetores de diferenças.

Para os dados observados,

$$\mathsf{T}_{\text{par,obs}}^2 = n \left(\bar{\mathbf{d}} - \delta_0 \right)^\top \mathbf{S}_D^{-1} \left(\bar{\mathbf{d}} - \delta_0 \right). \quad (12.170)$$

O teste rejeita H_0 quando

$$\mathsf{T}_{\text{par,obs}}^2 > \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}. \quad (12.171)$$

Quando

$$p = 1,$$

a estatística reduz-se ao quadrado do teste t pareado:

$$\mathsf{T}_{\text{par}}^2 = \frac{n \left(\bar{D} - \delta_0 \right)^2}{S_D^2} = \mathsf{t}_{\text{par}}^2. \quad (12.172)$$

Uma região de confiança para o vetor médio das diferenças é

$$\mathcal{C}_{D,1-\alpha} = \left\{ \theta \in \mathbb{R}^p : n \left(\bar{\mathbf{D}} - \theta \right)^\top \mathbf{S}_D^{-1} \left(\bar{\mathbf{D}} - \theta \right) \leq \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha} \right\}. \quad (12.173)$$

Os intervalos simultâneos para

$$\mathbf{a}^\top \delta$$

são

$$\mathbf{a}^\top \bar{\mathbf{D}} \pm \sqrt{\frac{c_{\alpha,p,n}}{n} \mathbf{a}^\top \mathbf{S}_D \mathbf{a}}, \quad (12.174)$$

em que

$$c_{\alpha,p,n} = \frac{p(n-1)}{n-p} F_{p,n-p;1-\alpha}.$$

Preservação do pareamento

O procedimento deve ser aplicado aos vetores de diferenças construídos com a correspondência correta entre as unidades.

Permutar as observações de uma das condições destrói as covariâncias intrapares e altera

$$\mathbf{S}_D.$$

Tratar observações pareadas como duas amostras independentes descarta a informação do pareamento e utiliza uma estimativa de variabilidade incompatível com o delineamento.

A normalidade exigida pelo procedimento pareado refere-se à distribuição dos vetores de diferenças:

$$\mathbf{D}_i = \mathbf{X}_i - \mathbf{Y}_i.$$

Não é necessário exigir separadamente que cada vetor observado em cada condição tenha distribuição normal, desde que a distribuição conjunta produza diferenças normais e os pares sejam independentes.

Tabela 12.3: Comparação entre os procedimentos para duas amostras independentes e observações pareadas.

Característica	Amostras independentes	Observações pareadas
Unidades	Distintas entre os grupos	Relacionadas dentro de cada par
Parâmetro	$\mu_1 - \mu_2$	$E(\mathbf{D}_i)$
Covariância utilizada	Covariância agrupada $\mathbf{S}_p$	Covariância das diferenças $\mathbf{S}_D$
Graus de liberdade para a covariância	$n_1 + n_2 - 2$	$n - 1$
Condição de inversão	$n_1 + n_2 > p + 1$	$n > p$
Hipótese de covariância	Covariância comum entre populações	Covariância não singular das diferenças
Dependência admitida	Nenhuma entre amostras	Dependência dentro dos pares

Os testes desta seção são casos particulares da inferência no modelo linear multivariado. Sua validade depende das estruturas de independência, normalidade, covariância e posto especificadas em cada resultado. Essas condições serão reunidas e avaliadas na próxima seção.

12.7 Condições de validade

Os resultados exatos desenvolvidos neste capítulo dependem de hipóteses probabilísticas, condições de posto e relações entre dimensão e tamanho amostral. Essas condições determinam:

- a existência das inversas utilizadas nas estatísticas;
- a distribuição exata das SSCP;
- a independência entre estimadores e resíduos;
- a validade dos níveis de significância e das regiões de confiança;
- a qualidade de aproximações assintóticas.

A avaliação dessas condições deve combinar o delineamento do estudo, a estrutura probabilística assumida e o comportamento observado dos dados. Diagnósticos amostrais podem revelar incompatibilidades, mas não demonstram isoladamente a validade completa do modelo (Mardia; Kent; Taylor, 2024).

12.7.1 Independência e normalidade

12.7.1.1 Independência entre unidades

Nos resultados para uma amostra, assume-se que

$$\mathbf{X}_1, \dots, \mathbf{X}_n$$

sejam independentes.

Para duas amostras independentes, exige-se adicionalmente independência entre os grupos. No caso pareado, admite-se dependência entre as duas medições do mesmo par, mas os pares devem ser independentes entre si.

A independência entre unidades é determinada principalmente pelo delineamento amostral. Ela pode ser violada por estruturas como:

- medidas repetidas na mesma unidade;
- observações agrupadas em escolas, famílias, empresas ou regiões;
- dependência espacial;
- dependência temporal;
- amostragem por conglomerados;
- reutilização da mesma unidade como se fossem observações distintas.

Quando existe dependência não incorporada ao modelo,

$$\text{Cov}(\bar{\mathbf{X}})$$

não é necessariamente igual a

$$\frac{\Sigma}{n}.$$

A variabilidade da média pode ser maior ou menor que a indicada pela expressão utilizada nos testes clássicos. Consequentemente, os níveis de significância e as regiões de confiança podem ficar incorretamente calibrados.

Independência não é diagnosticada apenas pelos valores observados

Um gráfico ou teste aplicado aos dados não estabelece, por si só, que as unidades sejam independentes.

A avaliação deve começar pelo modo como as observações foram selecionadas, agrupadas e mensuradas. Quando a dependência decorre do delineamento, ela deve ser representada por um modelo compatível com essa estrutura.

12.7.1.2 Papel da normalidade multivariada

A normalidade multivariada sustenta os seguintes resultados exatos:

$$\bar{\mathbf{X}} \sim N_p \left(\mu, \frac{\Sigma}{n} \right),$$

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma),$$

e

$$\bar{\mathbf{X}} \perp \mathbf{S}.$$

Essas propriedades conduzem à distribuição exata

$$\frac{n-p}{p(n-1)} \mathbf{T}^2 \sim F_{p, n-p}$$

para uma amostra.

No modelo linear multivariado, a normalidade dos erros sustenta:

$$\widehat{\mathbf{B}} \perp \mathbf{E}_{\text{res}} \mid \mathbf{Z},$$

$$\mathbf{E}_{\text{res}} \mid \mathbf{Z} \sim W_p(n - r, \Sigma)$$

e as distribuições exatas das matrizes de hipótese e erro.

Sem normalidade:

- a média amostral ainda pode ser não viesada;
- a covariância amostral ainda pode ser não viesada;
- a consistência pode permanecer válida;
- a distribuição Wishart deixa de ser, em geral, exata;
- média e covariância amostrais podem deixar de ser independentes;
- a calibração finita pela distribuição F pode deixar de ser exata.

Quando p é fixo, as observações são independentes e existem momentos de segunda ordem, o Teorema Central do Limite fornece

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma).$$

Se, adicionalmente,

$$\mathbf{S} \xrightarrow{p} \Sigma$$

e

$$\Sigma \succ \mathbf{0},$$

o teorema de Slutsky fornece, sob H_0 ,

$$\mathbf{T}^2 \xrightarrow{d} \chi_p^2. \tag{12.175}$$

O resultado em Equação 12.175 é assintótico. Ele não implica que a transformação finita para a distribuição F permaneça exata fora da população normal.

12.7.1.3 Avaliação da normalidade

A normalidade multivariada envolve a distribuição conjunta das variáveis. A verificação separada da normalidade de cada componente é insuficiente, pois marginais normais não garantem normalidade conjunta.

A avaliação pode considerar:

- distribuições marginais;
- assimetrias e caudas;
- combinações lineares;
- distâncias de Mahalanobis;
- gráficos quantil-quantil das distâncias;
- observações com influência elevada;
- conhecimento sobre o processo gerador dos dados.

Sob normalidade multivariada e parâmetros conhecidos,

$$(\mathbf{X}_i - \mu)^\top \Sigma^{-1} (\mathbf{X}_i - \mu) \sim \chi_p^2.$$

Quando μ e Σ são estimados na mesma amostra, as distâncias amostrais não são observações independentes de uma distribuição χ_p^2 exata. Gráficos baseados nessa comparação devem ser interpretados como instrumentos diagnósticos, e não como demonstrações formais da normalidade.

Não rejeição não comprova normalidade

Testes de normalidade podem apresentar baixo poder em amostras pequenas e rejeitar desvios pouco relevantes em amostras muito grandes.

A decisão sobre a utilização de um procedimento deve reunir a magnitude dos desvios, a presença de observações influentes, a dimensão, o tamanho amostral e a finalidade da inferência.

12.7.2 Homogeneidade das covariâncias

O teste T^2 para duas amostras independentes foi construído sob

$$\Sigma_1 = \Sigma_2 = \Sigma. \quad (12.176)$$

Essa condição permite reunir as SSCP dos dois grupos e obter

$$(n_1 + n_2 - 2) \mathbf{S}_p \sim W_p(n_1 + n_2 - 2, \Sigma).$$

Quando

$$\Sigma_1 \neq \Sigma_2,$$

a covariância da diferença entre as médias é

$$\text{Cov}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}, \quad (12.177)$$

e não

$$\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma.$$

Nesse caso, a matriz agrupada não estima diretamente a covariância em Equação 12.177, e a distribuição F apresentada para o teste clássico deixa de ser exata.

A heterogeneidade pode envolver:

- diferenças nas variâncias individuais;
- diferenças nas correlações;
- diferenças simultâneas de escala e orientação;
- singularidade em algum grupo;
- estruturas distintas causadas por subpopulações.

A igualdade das variâncias marginais não garante igualdade das matrizes de covariâncias. Duas populações podem possuir as mesmas variâncias em cada componente e correlações diferentes.

No modelo linear multivariado, a hipótese usual é

$$\text{Cov}(\varepsilon_i | \mathbf{Z}) = \Sigma$$

para todas as unidades. Isso significa que a matriz residual é comum às condições representadas no delineamento.

Se as covariâncias variam entre grupos ou condições, a distribuição Wishart única para a SSCP residual pode deixar de ser apropriada.

12.7.2.1 Amostras balanceadas e desbalanceadas

A influência da heterogeneidade depende também dos tamanhos dos grupos.

Quando os tamanhos são semelhantes, algumas estatísticas podem apresentar menor sensibilidade a determinados padrões de heterogeneidade. Essa estabilidade não é uma garantia universal.

Em delineamentos desbalanceados, a combinação entre:

- tamanhos amostrais;
- magnitudes das covariâncias;
- direções das diferenças entre médias;

pode produzir distorções mais acentuadas.

Uma situação especialmente desfavorável ocorre quando o grupo menor apresenta maior variabilidade. Nesse caso, a incerteza do grupo menos representado recebe menor peso na covariância agrupada.

12.7.2.2 Testes preliminares de homogeneidade

Um teste de igualdade de covariâncias formula uma hipótese distinta da comparação entre vetores de médias. Sua não rejeição não comprova que as covariâncias sejam iguais.

A estratégia

1. testar a homogeneidade;
2. escolher o teste de médias conforme o resultado;

produz um procedimento composto cuja distribuição global não coincide automaticamente com a distribuição de nenhum dos testes isolados.

A avaliação da homogeneidade deve considerar:

- estimativas das matrizes em cada grupo;
- variâncias e correlações;
- tamanhos amostrais;
- gráficos e medidas de dispersão;
- plausibilidade substantiva da covariância comum;
- sensibilidade das conclusões.

Homogeneidade como hipótese do modelo

A matriz de covariâncias comum deve ser tratada como parte da especificação do modelo. Quando essa condição não é plausível, deve-se utilizar um procedimento construído para

covariâncias distintas. A substituição informal da covariância agrupada por outra matriz não preserva a distribuição exata do teste clássico.

No problema pareado, não se exige

$$\Sigma_X = \Sigma_Y.$$

A inferência é construída sobre

$$\Sigma_D = \text{Cov}(\mathbf{X}_i - \mathbf{Y}_i).$$

A condição relevante é que os vetores de diferenças sejam independentes entre pares, tenham a distribuição especificada e possuam matriz de covariâncias adequada ao procedimento.

12.7.3 Posto, dimensão e tamanho amostral

As estatísticas clássicas utilizam inversas de matrizes de covariâncias ou de SSCP. Sua existência depende do posto dessas matrizes.

12.7.3.1 Uma amostra

Sob normalidade não singular,

$$\text{posto}(\mathbf{S}) = \min(p, n - 1)$$

com probabilidade 1.

Para que

$$\mathbf{S}^{-1}$$

exista, é necessário e suficiente, com probabilidade 1, que

$$n > p.$$

A distribuição exata de T^2 utiliza

$$F_{p, n-p}.$$

Portanto, o segundo grau de liberdade também exige

$$n - p > 0.$$

Quando n é pouco maior que p , a inversa pode existir e, ainda assim, ser numericamente instável.

12.7.3.2 Duas amostras independentes

A covariância agrupada satisfaz

$$\text{posto}(\mathbf{S}_p) = \min(p, n_1 + n_2 - 2)$$

com probabilidade 1 sob o modelo normal com covariância comum.

Sua inversa existe quando

$$n_1 + n_2 - 2 \geq p.$$

A distribuição exata utiliza o grau de liberdade

$$n_1 + n_2 - p - 1,$$

que deve ser positivo.

12.7.3.3 Modelo linear multivariado

No modelo com delineamento de posto

$$r = \text{posto}(\mathbf{Z}),$$

a SSCP residual possui

$$n - r$$

graus de liberdade e

$$\text{posto}(\mathbf{E}_{\text{res}}) = \min(p, n - r)$$

com probabilidade 1.

A condição para positividade definida é

$$n - r \geq p. \quad (12.178)$$

Para respostas transformadas por

$$\mathbf{M} \in \mathbb{R}^{p \times s},$$

com posto coluna completo, a SSCP residual transformada é

$$\mathbf{E}_M = \mathbf{M}^\top \mathbf{E}_{\text{res}} \mathbf{M}.$$

Sua inversão clássica requer

$$n - r \geq s. \quad (12.179)$$

Essa condição depende da dimensão efetiva s das respostas consideradas na hipótese, e não necessariamente do número original p .

12.7.3.4 Restrições redundantes

Na hipótese

$$H_0 : \mathbf{CBM} = \Theta_0,$$

restrições redundantes produzem matrizes singulares.

As linhas de $\mathbf{C}$ devem representar funções estimáveis linearmente independentes. As colunas de $\mathbf{M}$ devem representar combinações independentes das respostas.

Se

$$g = \text{posto}(\mathbf{C})$$

e

$$s = \text{posto}(\mathbf{M}),$$

o número de restrições escalares independentes é

gs.

A representação deve ser reduzida a uma base antes da construção das inversas associadas à hipótese.

12.7.3.5 Tamanho amostral e precisão

Satisfazer uma condição de inversibilidade não garante precisão adequada.

Quando n é próximo de p , a covariância amostral pode apresentar:

- autovalores muito pequenos;
- número de condição elevado;
- inversa sensível a pequenas perturbações;
- grande variabilidade nas distâncias de Mahalanobis;
- regiões de confiança extensas;
- baixo poder.

Considere os autovalores de $\mathbf{S}$:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0.$$

O número de condição espectral é

$$\kappa_2(\mathbf{S}) = \frac{\lambda_1}{\lambda_p}. \quad (12.180)$$

Valores elevados indicam que a inversa amplifica fortemente a incerteza nas direções associadas aos menores autovalores.

Existência e estabilidade são condições diferentes

Uma matriz pode ser teoricamente inversível e numericamente instável.

A avaliação deve considerar:

- posto;
- autovalores;
- número de condição;
- relação entre p e os graus de liberdade residuais;
- sensibilidade das conclusões a pequenas alterações nos dados.

12.7.4 Observações atípicas e robustez

A média amostral e a matriz de covariâncias amostral são sensíveis a observações extremas, e essa sensibilidade se transmite às distâncias de Mahalanobis, às regiões de confiança e às estatísticas que utilizam a inversa da covariância (Mardia; Kent; Taylor, 2024).

Uma única observação afastada pode alterar simultaneamente:

- o centro da amostra;
- as variâncias;
- as covariâncias;
- a orientação dos eixos principais;
- as distâncias de Mahalanobis;
- o valor da estatística T^2 .

Essa sensibilidade é ampliada porque a mesma observação participa da estimação de

$$\bar{\mathbf{x}}$$

e

$$\mathbf{S}.$$

Uma observação pode ser atípica:

- em uma variável individual;
- em várias variáveis;
- apenas em uma combinação linear;
- em relação à estrutura de um grupo;
- em relação ao modelo ajustado.

Uma observação que não é extrema em nenhuma margem pode ser atípica no espaço multivariado devido à combinação de seus valores.

12.7.4.1 Distância de Mahalanobis amostral

Uma medida usual é

$$d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^\top \mathbf{S}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}). \quad (12.181)$$

Valores elevados indicam observações afastadas do centro segundo a geometria estimada.

Entretanto, a própria observação influencia

$$\bar{\mathbf{x}}$$

e

S.

Um conjunto de observações extremas pode deslocar o centro e inflar a covariância, reduzindo suas próprias distâncias. Esse efeito é conhecido como mascaramento.

Também pode ocorrer o efeito oposto: uma observação extrema altera a estimação de modo que observações regulares passem a apresentar distâncias elevadas.

Por isso, a distância de Mahalanobis amostral deve ser combinada com outras informações:

- gráficos marginais;
- projeções;
- análise por grupos;
- resíduos;
- alavancagem;
- conhecimento sobre erros de mensuração;
- sensibilidade do resultado à remoção justificada de observações.

12.7.4.2 Robustez dos testes

Não existe uma afirmação universal de que o T^2 seja robusto ou não robusto à ausência de normalidade.

Seu comportamento depende de:

- assimetria;
- peso das caudas;
- tamanho amostral;
- dimensão;
- balanceamento;
- heterogeneidade das covariâncias;
- presença de observações influentes;
- direção da alternativa.

Com p fixo, momentos finitos e amostras grandes, a aproximação assintótica pode ser adequada. Distribuições com caudas pesadas podem exigir amostras consideravelmente maiores, pois a estimação da covariância depende de produtos de componentes e é sensível a valores extremos.

A existência de segundos momentos é suficiente para determinadas propriedades da média e da covariância. A variabilidade assintótica dos elementos da covariância amostral envolve, em geral, momentos de quarta ordem.

Se esses momentos não existem, aproximações usuais para a covariância amostral podem falhar.

12.7.4.3 Procedimentos robustos

É possível substituir a média e a covariância clássicas por estimadores robustos. Essa substituição altera a estatística e sua distribuição.

Em geral,

$$n \left(\hat{\mu}_{\text{rob}} - \mu_0 \right)^{\top} \widehat{\Sigma}_{\text{rob}}^{-1} \left(\hat{\mu}_{\text{rob}} - \mu_0 \right)$$

não possui automaticamente a mesma distribuição F do T^2 clássico.

A calibração pode exigir:

- resultados assintóticos específicos;
- correções de escala;
- reamostragem;
- simulação sob o modelo;
- distribuições de referência próprias do estimador.

Remoção de observações

Uma observação não deve ser removida apenas porque produz uma estatística elevada ou altera a conclusão.

A investigação deve distinguir:

- erro de registro;
- erro de mensuração;
- unidade pertencente a outra população;
- evento raro compatível com a população;
- observação influente substantivamente válida.

A exclusão modifica o problema inferencial e deve ser documentada e justificada.

12.7.5 Limites da inferência clássica em alta dimensão

Os resultados anteriores foram desenvolvidos principalmente no regime clássico:

$$p \text{ fixo} \quad \text{e} \quad n \longrightarrow \infty. \quad (12.182)$$

Quando p cresce com n , autovalores, inversas, determinantes e formas quadráticas amostrais podem apresentar comportamentos diferentes dos previstos pela teoria de dimensão fixa. Nesse regime, singularidade e mau condicionamento exigem métodos construídos especificamente para alta dimensão (Mardia; Kent; Taylor, 2024).

12.7.5.1 Singularidade quando $p \geq n$

Para uma amostra,

$$\text{posto}(\mathbf{S}) \leq n - 1.$$

Portanto, se

$$p \geq n,$$

então

$$\det(\mathbf{S}) = 0$$

e

$$\mathbf{S}^{-1}$$

não existe.

Nesse regime, a estatística clássica

$$T^2 = n (\bar{\mathbf{X}} - \mu_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \mu_0)$$

não está definida.

Para duas amostras independentes, a covariância agrupada é singular quando

$$p > n_1 + n_2 - 2.$$

No modelo linear multivariado, a SSCP residual é singular quando

$$p > n - r.$$

12.7.5.2 Instabilidade antes da singularidade

Mesmo quando

$$p < n,$$

a inferência clássica pode tornar-se instável se p estiver próximo de n .

Nesse regime:

- os autovalores amostrais apresentam elevada variabilidade;
- os menores autovalores podem ser fortemente subestimados;
- a inversa amplifica o ruído;
- distâncias de Mahalanobis tornam-se instáveis;
- aproximações assintóticas com p fixo podem ser inadequadas;
- o poder pode diminuir com a inclusão de respostas pouco informativas.

O fato de a matriz ser inversível não garante que sua inversa seja uma estimativa adequada de

$$\Sigma^{-1}.$$

12.7.5.3 Pseudoinversa

A pseudoinversa pode produzir a quantidade

$$n \left(\bar{\mathbf{X}} - \mu_0 \right)^\top \mathbf{S}^+ \left(\bar{\mathbf{X}} - \mu_0 \right). \quad (12.183)$$

Essa expressão mede o afastamento apenas no espaço imagem de $\mathbf{S}$.

Ela não possui automaticamente a distribuição

$$\frac{p(n-1)}{n-p} F_{p, n-p}$$

e não recupera a calibração do T^2 clássico. A dimensão efetiva do espaço amostral, a aleatoriedade desse espaço e o comportamento dos autovalores precisam ser considerados.

Pseudoinversa não restaura o teste clássico

Substituir

$$\mathbf{S}^{-1}$$

por

$$\mathbf{S}^{+}$$

produz outra estatística.

Para utilizá-la como teste, é necessário determinar sua distribuição ou adotar uma calibração justificada. A distribuição F do T^2 clássico não permanece válida por simples substituição algébrica.

12.7.5.4 Regularização

Uma matriz regularizada pode ser definida, por exemplo, por

$$\mathbf{S}_{\lambda} = (1 - \lambda) \mathbf{S} + \lambda \mathbf{T}, \quad (12.184)$$

em que:

- $0 \leq \lambda \leq 1$;
- $\mathbf{T} \succ \mathbf{0}$ é uma matriz-alvo.

Outra possibilidade é

$$\mathbf{S}_{\lambda} = \mathbf{S} + \lambda \mathbf{I}_p, \quad \lambda > 0. \quad (12.185)$$

A regularização pode:

- garantir invertibilidade;
- reduzir o número de condição;
- estabilizar distâncias;
- diminuir a variabilidade da inversa.

Ela também introduz viés e modifica a estatística. O parâmetro de regularização e a distribuição de referência precisam ser definidos pelo procedimento adotado.

12.7.5.5 Redução da dimensão

Quando o interesse substantivo pode ser representado por

$$s < p$$

combinações previamente definidas, considere

$$\mathbf{U}_i = \mathbf{M}^\top \mathbf{X}_i,$$

com

$$\mathbf{M} \in \mathbb{R}^{p \times s}.$$

A inferência pode ser realizada no espaço transformado, desde que:

- as combinações tenham sido definidas de forma justificável;
- $\mathbf{M}$ possua posto coluna completo;
- a seleção não seja utilizada sem ajuste para maximizar artificialmente a evidência;
- a matriz transformada possua posto suficiente.

A covariância transformada é

$$\Sigma_U = \mathbf{M}^\top \Sigma \mathbf{M}.$$

A condição de inversão passa a depender de s .

Uma redução escolhida a partir dos mesmos dados altera a distribuição do procedimento. Selecionar direções que maximizam diferenças observadas e depois tratá-las como previamente fixadas produz viés de seleção.

12.7.5.6 Reamostragem e testes especializados

Em problemas de alta dimensão, podem ser utilizados:

- testes baseados em traços;
- estatísticas regularizadas;
- testes por permutação compatíveis com o delineamento;
- procedimentos de reamostragem;
- aproximações fundamentadas em teoria de matrizes aleatórias;
- métodos baseados em projeções;

- testes para estruturas de covariância específicas.

Esses procedimentos possuem hipóteses e distribuições próprias. Eles não são versões automáticas do teste T^2 clássico.

Tabela 12.4: Limitações de posto e consequências para a inferência multivariada clássica.

Situação	Consequência
$p < n$, mas p próximo de n	Inversa existente, possivelmente instável
$p \geq n$ em uma amostra	Covariância amostral singular
$p > n_1 + n_2 - 2$	Covariância agrupada singular
$p > n - r$ no modelo linear	SSCP residual singular
Uso de pseudoinversa	Nova estatística, sem calibração F automática
Uso de regularização	Viés e distribuição de referência modificados
Seleção de direções nos mesmos dados	Necessidade de considerar a seleção na inferência

A inferência clássica continua apropriada quando suas hipóteses são compatíveis com o problema e a dimensão é pequena em relação à informação disponível. Fora desse regime, a análise deve utilizar procedimentos construídos para a estrutura dimensional observada.

As condições desta seção delimitam a interpretação dos testes e regiões de confiança. A próxima seção introduzirá uma formulação elementar de decisão estatística, relacionando hipóteses, ações, perdas e risco. Essa perspectiva também fornecerá a transição para problemas de classificação desenvolvidos no Módulo 3.

12.8 Decisão estatística e conexão com classificação

Os testes de hipóteses estabelecem regras para rejeitar ou não rejeitar uma afirmação, controlando probabilidades de erro. A teoria da decisão estatística amplia essa formulação ao representar explicitamente o conjunto de ações, as perdas associadas e o risco de cada regra (Berger, 1985).

Essa perspectiva é especialmente útil em problemas de classificação, nos quais erros distintos podem produzir consequências diferentes.

12.8.1 Ação, perda e risco

Considere um modelo estatístico indexado por

$$\vartheta \in \mathcal{P},$$

em que $\mathcal{P}$ é o espaço paramétrico, e seja $\mathcal{A}$ o conjunto das ações disponíveis.

Definição 12.10 (Regra de decisão). Uma regra de decisão é uma função

$$\psi : \mathcal{X} \longrightarrow \mathcal{A},$$

que associa cada resultado amostral

$$\mathbf{x} \in \mathcal{X}$$

a uma ação

$$\psi(\mathbf{x}) \in \mathcal{A}.$$

Uma ação pode representar uma estimativa, a rejeição de uma hipótese, a escolha de um tratamento ou a atribuição de uma observação a uma classe.

Definição 12.11 (Função de perda). Uma função de perda é uma aplicação

$$L : \mathcal{A} \times \mathcal{P} \longrightarrow [0, \infty),$$

em que

$$L(\mathbf{a}, \vartheta)$$

quantifica a consequência de escolher a ação $\mathbf{a}$ quando o verdadeiro valor do parâmetro é ϑ .

Em um problema de estimação vetorial, uma possibilidade é a perda quadrática

$$L(\mathbf{a}, \vartheta) = \|\mathbf{a} - \vartheta\|^2.$$

Quando as componentes recebem ponderações diferentes, pode-se utilizar

$$L(\mathbf{a}, \vartheta) = (\mathbf{a} - \vartheta)^\top \mathbf{K} (\mathbf{a} - \vartheta),$$

em que

$$\mathbf{K} \succeq \mathbf{0}$$

é uma matriz de ponderação.

A matriz $\mathbf{K}$ representa as consequências atribuídas aos erros nas diferentes direções. Ela não deve ser confundida com a matriz de covariâncias do modelo.

Definição 12.12 (Função de risco). O risco de uma regra de decisão ψ no ponto paramétrico ϑ é

$$R(\vartheta, \psi) = E_{\vartheta} [L(\psi(\mathcal{X}), \vartheta)].$$

O risco é a perda média produzida pela regra quando os dados seguem a distribuição determinada por ϑ .

Nos testes de hipóteses, as ações podem ser:

$$a_0 = \text{não rejeitar } H_0$$

e

$$a_1 = \text{rejeitar } H_0.$$

A rejeição de uma hipótese verdadeira e a não rejeição de uma hipótese falsa podem receber perdas distintas. A formulação por nível de significância controla a probabilidade do erro do tipo I, enquanto a formulação decisória permite considerar explicitamente as consequências dos dois tipos de erro.

Evidência e consequência

O valor-p descreve a incompatibilidade entre os dados e a hipótese nula segundo o modelo e a estatística adotados.

A função de perda descreve as consequências das ações. Ela depende do contexto e não é determinada pela distribuição amostral.

12.8.2 Regra de Bayes e custos de decisão

Na abordagem bayesiana, a incerteza sobre o parâmetro é representada por uma distribuição a priori

$$\pi(\vartheta).$$

Após a observação de $\mathbf{x}$, essa distribuição é atualizada pela verossimilhança, produzindo a distribuição a posteriori

$$\pi(\vartheta \mid \mathbf{x}).$$

Uma ação de Bayes minimiza a perda posterior esperada e, conseqüentemente, o risco integrado em relação à distribuição a priori (Berger, 1985).

A perda posterior esperada de uma ação $\mathbf{a}$ é

$$\rho(\mathbf{a} \mid \mathbf{x}) = E[L(\mathbf{a}, \vartheta) \mid \mathbf{x}].$$

Definição 12.13 (Regra de Bayes). Uma regra de Bayes escolhe uma ação que minimiza a perda posterior esperada:

$$\psi_B(\mathbf{x}) \in \arg \min_{\mathbf{a} \in \mathcal{A}} \rho(\mathbf{a} \mid \mathbf{x}).$$

A regra depende conjuntamente do modelo probabilístico, das probabilidades a priori e da função de perda.

12.8.2.1 Classificação como problema de decisão

Considere uma variável de classe

$$G \in \{1, \dots, K\}$$

e um vetor de características

$$\mathbf{X} \in \mathbb{R}^p.$$

Seja

$$\pi_g = P(G = g)$$

a probabilidade a priori da classe g , e seja

$$f_g(\mathbf{x})$$

a densidade de $\mathbf{X}$ condicionada a essa classe.

Pelo teorema de Bayes,

$$P(G = g \mid \mathbf{X} = \mathbf{x}) = \frac{\pi_g f_g(\mathbf{x})}{\sum_{h=1}^K \pi_h f_h(\mathbf{x})}.$$

Se $L(a, g)$ é a perda de classificar uma unidade da classe verdadeira g como pertencente à classe a , o risco condicional da ação a é

$$\rho(a \mid \mathbf{x}) = \sum_{g=1}^K L(a, g) P(G = g \mid \mathbf{X} = \mathbf{x}).$$

Teorema 12.25 (Regra de Bayes para classificação). *A regra de Bayes atribui a observação $\mathbf{x}$ à classe*

$$\psi_B(\mathbf{x}) \in \arg \min_{a \in \{1, \dots, K\}} \sum_{g=1}^K L(a, g) P(G = g \mid \mathbf{X} = \mathbf{x}).$$

Sob perda zero-um,

$$L(a, g) = \begin{cases} 0, & a = g, \\ 1, & a \neq g, \end{cases}$$

a regra escolhe a classe de maior probabilidade posterior:

$$\psi_B(\mathbf{x}) \in \arg \max_{g \in \{1, \dots, K\}} P(G = g \mid \mathbf{X} = \mathbf{x}).$$

Equivalentemente,

$$\psi_B(\mathbf{x}) \in \arg \max_{g \in \{1, \dots, K\}} \pi_g f_g(\mathbf{x}).$$

Probabilidades a priori diferentes podem alterar a classificação mesmo quando as densidades condicionais permanecem iguais.

Em um problema com duas classes, suponha que as classificações corretas tenham perda zero e que

$$L(1, 2) = c_{12}$$

e

$$L(2, 1) = c_{21}.$$

A classe 1 é escolhida quando

$$c_{12}P(\mathbf{G} = 2 \mid \mathbf{x}) < c_{21}P(\mathbf{G} = 1 \mid \mathbf{x}),$$

ou, de maneira equivalente, quando

$$\frac{P(\mathbf{G} = 1 \mid \mathbf{x})}{P(\mathbf{G} = 2 \mid \mathbf{x})} > \frac{c_{12}}{c_{21}}.$$

O aumento de c_{21} , custo de classificar uma unidade da classe 1 como pertencente à classe 2, reduz o limiar necessário para escolher a classe 1.

Probabilidades a priori e custos

As probabilidades a priori podem representar prevalências populacionais ou conhecimento anterior.

Os custos representam as consequências das classificações incorretas. Eles não são determinados automaticamente pelas frequências amostrais nem pelas matrizes de covariâncias.

Se

$$\mathbf{X} \mid \mathbf{G} = g \sim N_p(\mu_g, \Sigma_g),$$

a regra de classificação depende dos vetores de médias, das matrizes de covariâncias, das probabilidades a priori e dos custos.

Quando as classes compartilham a mesma matriz de covariâncias, as fronteiras de decisão são lineares. Quando as covariâncias diferem, as fronteiras são, em geral, quadráticas.

A derivação dessas fronteiras, a estimação dos parâmetros e a relação com as direções discriminantes serão desenvolvidas no capítulo de Análise Discriminante do Módulo 3.

12.9 Síntese do Módulo 2

O Módulo 2 desenvolveu os fundamentos probabilísticos e inferenciais da Análise Multivariada. O percurso começou com a representação da variabilidade conjunta, passou pela formulação de modelos probabilísticos e pela estimação de seus parâmetros e terminou com a construção de procedimentos inferenciais para vetores e matrizes.

Essa sequência pode ser representada por

covariância $\rightarrow$ modelo probabilístico $\rightarrow$ estimação $\rightarrow$ modelo linear $\rightarrow$ inferência.

A matriz de covariâncias organizou as variâncias e covariâncias das componentes de um vetor aleatório e determinou a variabilidade de suas combinações lineares. A distribuição normal multivariada acrescentou uma especificação probabilística na qual transformações afins, formas quadráticas e distâncias de Mahalanobis possuem propriedades particularmente úteis.

As estatísticas amostrais permitiram distinguir os parâmetros populacionais, as estatísticas aleatórias e seus valores observados. A média amostral e a matriz de covariâncias amostral passaram a ser tratadas como estimadores, com propriedades avaliadas por suas distribuições amostrais, seus vieses e suas variabilidades.

O modelo linear multivariado reuniu várias respostas em uma única estrutura e introduziu uma formulação geral para hipóteses lineares. As matrizes de hipótese e erro passaram a representar, respectivamente, o afastamento em relação às restrições avaliadas e a variabilidade residual do modelo.

Neste capítulo, a distribuição de Wishart forneceu a base para a inferência sobre matrizes de covariâncias e SSCP. Sob normalidade, ela permitiu estabelecer a distribuição exata da covariância amostral, a independência entre média e covariância e as distribuições das matrizes de hipótese e erro no modelo linear multivariado.

A distinção entre resultados exatos e assintóticos permaneceu explícita. Os resultados exatos dependem das hipóteses probabilísticas utilizadas em sua derivação. Os resultados assintóticos descrevem o comportamento das estatísticas quando o tamanho amostral cresce, geralmente mantendo a dimensão fixa.

A Tabela 12.5 organiza os objetos centrais e a contribuição de cada capítulo.

Tabela 12.5: Objetos e contribuições dos capítulos do Módulo 2.

Capítulo	Objeto central	Contribuição para a inferência multivariada
8. Matrizes de covariâncias e correlações	Σ , formas quadráticas e matrizes de dispersão	Representação da variabilidade e da dependência linear
9. Distribuição normal multivariada	$N_p(\mu, \Sigma)$	Modelo probabilístico, transformações afins e geometria de Mahalanobis
10. Estatísticas amostrais e estimação	$\bar{\mathbf{X}}$, $\mathbf{S}$ e estimadores	Passagem dos parâmetros populacionais para a informação amostral
11. Modelo linear multivariado	$\mathbf{y} = \mathbf{ZB} + \mathcal{E}$	Estimação de efeitos, funções estimáveis e hipóteses lineares
12. Inferência multivariada	Wishart, razão de verossimilhanças e T^2	Testes, regiões de confiança e comparação entre vetores de médias

Os cinco capítulos compartilham algumas estruturas recorrentes. Formas quadráticas medem afastamentos na escala da variabilidade. Determinantes representam alterações de volume e participam de razões de verossimilhanças. Projetores decompõem a informação entre ajuste e resíduo. Distribuições normais e Wishart fornecem as distribuições exatas necessárias aos testes clássicos.

A estatística T^2 de Hotelling reuniu esses elementos na inferência sobre vetores de médias. Sua formulação considera simultaneamente as variâncias, as covariâncias e o tamanho amostral. A inversão do teste produziu regiões de confiança elipsoidais e intervalos simultâneos para combinações lineares.

Na comparação entre duas populações, o delineamento determinou o procedimento. Amostras independentes exigiram uma formulação baseada na diferença entre médias e, no procedimento clássico, uma matriz de covariâncias comum. Observações pareadas foram analisadas por meio dos vetores de diferenças, preservando a dependência existente dentro de cada par.

A validade desses procedimentos depende de condições específicas. Independência, normalidade, homogeneidade das covariâncias, posto das matrizes e relação entre dimensão e tamanho amostral não são exigências intercambiáveis. Cada uma sustenta uma parte da distribuição ou da interpretação do procedimento.

A existência de uma inversa também deve ser distinguida de sua estabilidade. Quando a dimensão se aproxima dos graus de liberdade disponíveis, a covariância amostral pode ser inversível e, ainda assim, produzir resultados sensíveis. Quando a dimensão excede o posto máximo da matriz, a inferência clássica baseada na inversa deixa de estar definida.

Pseudoinversas e regularização originam outros procedimentos e não preservam automaticamente as distribuições clássicas.

A formulação por decisão estatística acrescentou as ações e suas consequências ao problema inferencial. Perdas, riscos, probabilidades a priori e custos de classificação serão retomados quando forem construídas as regras discriminantes.

Ao término do Módulo 2, deve-se ser capaz de:

- representar a variabilidade conjunta por matrizes de covariâncias e correlações;
- utilizar as propriedades da distribuição normal multivariada;
- distinguir parâmetros, estatísticas, estimadores e estimativas;
- reconhecer a distribuição de Wishart e suas condições de posto;
- explicar a independência entre média e covariância amostrais sob normalidade;
- formular e interpretar o modelo linear multivariado;
- representar hipóteses por funções estimáveis e matrizes de contraste;
- distinguir resultados exatos de aproximações assintóticas;
- aplicar a estatística T^2 em problemas de uma e duas amostras;
- construir regiões de confiança e intervalos simultâneos;
- avaliar as condições de validade dos procedimentos;
- reconhecer os limites da inferência clássica em alta dimensão;
- relacionar evidência estatística, ações, perdas e custos.

O Módulo 3 utilizará esses fundamentos na formulação das técnicas multivariadas. As técnicas serão diferenciadas pelo problema estatístico, pelo objeto matemático analisado, pelo critério que define a solução e pela interpretação atribuída aos resultados.

Matrizes de covariâncias serão decompostas, modeladas ou particionadas. Projeções e decomposições espectrais definirão representações de menor dimensão. Matrizes de distâncias serão utilizadas na formação de grupos e na construção de configurações geométricas. As matrizes de hipótese e erro serão retomadas na MANOVA, enquanto probabilidades, covariâncias e custos serão combinados na Análise Discriminante.

A passagem para o Módulo 3 corresponde à utilização integrada dos fundamentos matemáticos, probabilísticos e inferenciais na construção de métodos destinados a problemas multivariados específicos.

Parte III

Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13 Módulo III — Formulação Matemática e Estatística das Técnicas Multivariadas

13.1 Problemas e estruturas das técnicas multivariadas

13.2 Formulação da Análise de Componentes Principais

13.3 Formulação da Análise Fatorial

13.4 Formulação da Análise de Agrupamentos

13.5 Formulação do Escalonamento Multidimensional

13.6 Formulação da Análise de Correspondência

13.7 Formulação da MANOVA

13.8 Formulação da Análise Discriminante

13.9 Formulação da Correlação Canônica

13.10 Formulação da Análise Conjunta

Referências

ANDERSON, Theodore W. **An Introduction to Multivariate Statistical Analysis**. 3. ed. Hoboken, NJ: John Wiley & Sons, 2003. p. 752

APOSTOL, Tom M. **Calculus, Volume II: Multi-Variable Calculus and Linear Algebra, with Applications to Differential Equations and Probability**. 2. ed. New York: John Wiley & Sons, 1969.

ARTES, Rinaldo; BARROSO, Lúcia Pereira. **Métodos multivariados de análise estatística**. 1. ed. São Paulo: Blucher, 2023. p. 534

AXLER, Sheldon. **Measure, Integration & Real Analysis**. Cham: Springer, 2020. v. 282

BERGER, James O. **Statistical Decision Theory and Bayesian Analysis**. 2. ed. New York: Springer, 1985. p. 618

BOYD, Stephen; VANDENBERGHE, Lieven. **Convex Optimization**. Cambridge: Cambridge University Press, 2004.

CASELLA, George; BERGER, Roger L. **Statistical Inference**. 2. ed. Pacific Grove, CA: Duxbury, 2002.

CHRISTENSEN, Ronald. **Plane Answers to Complex Questions: The Theory of Linear Models**. 4. ed. New York: Springer, 2011. p. 494

EATON, Morris L. **Multivariate Statistics: A Vector Space Approach**. Beachwood, OH: Institute of Mathematical Statistics, 2007. v. 53 p. 512

GOLUB, Gene H.; VAN LOAN, Charles F. **Matrix Computations**. 4. ed. Baltimore: Johns Hopkins University Press, 2013.

GUPTA, Arjun K.; NAGAR, Daya K. **Matrix Variate Distributions**. Boca Raton: Chapman & Hall/CRC, 1999.

HAIR, Jr., Joseph F. *et al.* **Multivariate Data Analysis**. 8. ed. Andover: Cengage Learning, 2018.

HARVILLE, David A. **Matrix Algebra From a Statistician's Perspective**. New York: Springer, 1997. p. 634

HORN, Roger A.; JOHNSON, Charles R. **Topics in Matrix Analysis**. Cambridge: Cambridge University Press, 1991.

HORN, Roger A.; JOHNSON, Charles R. **Matrix Analysis**. 2. ed. Cambridge: Cambridge University Press, 2013.

HOTELLING, Harold. **The Generalization of Student's Ratio**. **The Annals of Mathematical Statistics**, v. 2, n. 3, p. 360–378, 1931.

JOHNSON, Richard A.; WICHERN, Dean W. **Applied Multivariate Statistical Analysis**. 6. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.

LEDOIT, Olivier; WOLF, Michael. **A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices**. **Journal of Multivariate Analysis**, v. 88, n. 2, p. 365–411, 2004.

MAGNUS, Jan R.; NEUDECKER, Heinz. **Matrix Differential Calculus with Applications in Statistics and Econometrics**. 3. ed. Chichester: John Wiley & Sons, 2019. p. 504

MANLY, Bryan F. J.; NAVARRO ALBERTO, Jorge A. **Métodos Estatísticos Multivariados: Uma Introdução**. 4. ed. Porto Alegre: Bookman, 2019. p. 254

MARDIA, Kanti V.; KENT, John T.; TAYLOR, Charles C. **Multivariate Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2024. p. 592

MARONNA, Ricardo A. *et al.* **Robust Statistics: Theory and Methods (with R)**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2019. p. 464

MEYER, Carl D. **Matrix Analysis and Applied Linear Algebra**. 2. ed. Philadelphia: Society for Industrial; Applied Mathematics, 2023. p. 991

MINGOTI, Sueli Aparecida. **Análise de Dados Através de Métodos de Estatística Multivariada: Uma Abordagem Aplicada**. Belo Horizonte: Editora UFMG, 2005.

MUIRHEAD, Robb J. **Aspects of Multivariate Statistical Theory**. New York: John Wiley & Sons, 1982.

RAO, C. Radhakrishna. **Linear Statistical Inference and Its Applications**. 2. ed. New York: John Wiley & Sons, 1973.

RENCER, Alvin C.; CHRISTENSEN, William F. **Methods of Multivariate Analysis**. 3.

ed. Hoboken, NJ: John Wiley & Sons, 2012.

VAART, A. W. van der. [Asymptotic Statistics](#). Cambridge: Cambridge University Press, 1998. p. 462

WILKS, Samuel S. [Certain Generalizations in the Analysis of Variance](#). **Biometrika**, v. 24, n. 3–4, p. 471–494, 1932.